

OPTIMIZACIÓN

ICS1113 – Sección 3

CONVEXIDAD Y UNICIDAD

CAMILA BALBONTIN

✉ camila.balbontin@uc.cl



Departamento de Transporte y Logística



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Primer Semestre, 2024

CONCEPTOS BÁSICOS, CONVEXIDAD Y MODELOS EQUIVALENTES

CONCEPTOS BÁSICOS

Recordando lo que
vimos el lunes...

CONCEPTOS BÁSICOS: MODELO

➤ Un problema de optimización P, está dado por:

$$P : \min_{x \in D} f(x)$$

donde

- x es un vector de **variables** de decisión
- D es el **dominio** de valores de x factibles
- $f(x) \in \mathbb{R}$ es la **función objetivo**

CONCEPTOS BÁSICOS: SOLUCIÓN FACTIBLE

$$P : \min_{x \in D} f(x)$$

- Una solución x' de P es una configuración de valores del vector de variables
- x' es **solución factible** si $x' \in D$, de lo contrario, es infactible
- Un dominio D es vacío (o infactible) si no tiene solución factible

CONCEPTOS BÁSICOS: SOLUCIÓN ÓPTIMA

$$P : \min_{x \in D} f(x)$$

- Una solución x^* es **óptima** (i.e., **mínimo global**) de P si:

$$f(x^*) \leq f(x), \quad \forall x \in D$$

- Una solución factible x' es **mínimo local** de P si existe valor $r > 0$, tal que:

$$f(x') \leq f(x), \quad \forall x \in D: \|x' - x\| < r$$

- ¿Y si la función objetivo es maximizar?
- Si las desigualdades son $<$ se dicen estrictas

CONCEPTOS BÁSICOS: VALOR ÓPTIMO

$$P : \min_{x \in D} f(x)$$

➤ El **valor óptimo** v^* (o ínfimo) del problema P es el valor que cumple:

$$v^* \leq f(x), \quad \forall x \in D$$

- Si existe $x^* \in D$ tal que $f(x^*) = v^*$, entonces x^* es solución óptima
- Pueden existir múltiples soluciones óptimas, pero **valor óptimo** es **único**
- Puede existir valor óptimo sin que exista solución óptima
- Puede que no exista ni valor ni solución óptima

CONVEXIDAD

CONVEXIDAD

➤ La convexidad de la región factible es esencial para encontrar la solución óptima de un problema no lineal

➤ Un conjunto D es convexo si




$$x = \lambda x_1 + (1 - \lambda) x_2, \quad x \in D, \forall x_1, x_2 \in D, \forall \lambda \in [0, 1]$$

1. La intersección entre conjuntos convexos es también convexo

- La unión de conjuntos convexos no es siempre convexa

2. Un dominio lineal es convexo

3. El conjunto vacío y $\mathbb{R}^n$ son convexos



CONVEXIDAD

Ejemplo: ¿son convexos los dominios?

1. $\{(x_1, x_2): x_1 + x_2 \leq 1\}$
2. $\{(x_1, x_2): x_1 + x_2 \geq 1\}$
3. $\{(x_1, x_2): x_1 + x_2 = 1\}$
4. $\{(x_1, x_2): x_1^2 + x_2^2 \leq 1\}$
5. $\{(x_1, x_2): x_1^2 + x_2^2 \geq 1\}$
6. $\{(x_1, x_2): x_1^2 + x_2^2 = 1\}$
7. $\{(x_1, x_2): |x_1 + x_2| \leq 1\}$
8. $\{(x_1, x_2): |x_1 + x_2| \geq 1\}$
9. $\{(x_1, x_2): \max(x_1, x_2) \leq 2\}$
10. $\{(x_1, x_2): \max(x_1, x_2) \geq 2\}$


FUNCIÓN CONVEXA

➤ Si D es un conjunto convexo, entonces la función $f(x)$ es convexo en el dominio D si:

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2), \quad \forall x_1, x_2 \in D, \forall \lambda \in [0,1]$$

- $f(x)$ es estrictamente convexo si la desigualdad anterior es estricta ($<$)
- $f(x)$ es cóncavo si $-f(x)$ es convexo
- Una función lineal es cóncava y convexa


Recordar que x_1 y x_2 representan puntos del dominio, se debería cumplir para todos los puntos del dominio



FUNCIÓN CONVEXA: EJEMPLO

➤ Veamos si la siguiente función es convexa en el dominio entre 2 y 4:

$$f(x) = x^2 - 3$$



¿Podemos decir gráficamente que es convexo?

Revisamos la condición necesaria para asegurar que es un conjunto convexo en el dominio entre 2 y 4. Esto es sólo un ejemplo, y tomamos tres valores de λ , pero para demostrarlo se tendría que cumplir para todos los valores de $\lambda \in [0,1]$.

Demostremoslo con la ecuación:

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2), \quad \forall x_1, x_2 \in D, \forall \lambda \in [0,1]$$

- Para $\lambda = 0$:

$$f(0 \cdot 2 + (1-0) \cdot 4) \leq 0 \cdot f(2) + (1-0) \cdot f(4)$$

$$\rightarrow f(4) \leq f(4)$$

- Para $\lambda = 0.5$:

$$f(0.5 \cdot 2 + (1-0.5) \cdot 4) \leq 0.5 \cdot f(2) + (1-0.5) \cdot f(4)$$

$$\rightarrow f(3) \leq 0.5 \cdot 1 + 0.5 \cdot 13 \rightarrow 6 \leq 7$$

- Para $\lambda = 1$:

$$f(1 \cdot 2 + (1-1) \cdot 4) \leq 1 \cdot f(2) + (1-1) \cdot f(4)$$

$$\rightarrow f(2) \leq f(2)$$

FUNCIÓN CONVEXA

➤ Condición de primer orden:

- Si D es un conjunto convexo y $f(x)$ es **diferenciable en D** , entonces $f(x)$ es convexo en D si y sólo si:

$$f(x_1) \geq f(x_2) + (x_1 - x_2)^t \nabla f(x_2), \quad \forall x_1, x_2 \in D$$

➤ Condición de segundo orden:

- Si D es un conjunto convexo y $f(x)$ es **diferenciable dos veces en D** , entonces $f(x)$ es convexo en D si y sólo si $\nabla^2 f(x)$ es semidefinida positiva para todo $x \in D$

$$\nabla^2 f(x) \geq 0, \quad \forall x \in D$$

Y es estrictamente convexo si $\nabla^2 f(x)$ es definida positiva

FUNCIÓN CONVEXA

➤ Recordando que $\nabla^2 f(x)$ es la matriz Hessiana $n \times n$ de f :

$$\nabla^2 f = Hf(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- ❖ donde H es **semidefinida positiva** si: Todos los menores principales son no negativos
- ❖ donde H es **definida positiva** si: Todos los menores principales son positivos

FUNCIÓN CONVEXA

¿Qué son los **menores principales**?

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

Diagram illustrating the principal minors of matrix A :

- Δ_1 (green box) highlights the element a_{11} .
- Δ_2 (blue box) highlights the top-left 2×2 submatrix $\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$.
- Δ_3 (orange box) highlights the entire 3×3 matrix A .

$$H_1 = \{ \det(a_{11}), \det(a_{22}), \det(a_{33}) \}$$

$$H_2 = \left\{ \left| \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \right|, \left| \begin{bmatrix} a_{11} & a_{13} \\ a_{31} & a_{33} \end{bmatrix} \right|, \left| \begin{bmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{bmatrix} \right| \right\}$$

$$H_3 = \det(A)$$

$$\left| \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \right| = a_{11} \cdot a_{22} - a_{12} \cdot a_{21}$$

FUNCIÓN CONVEXA

➤ Recordando que $\nabla^2 f(x)$ es la matriz Hessiana $n \times n$ de f :

$$\nabla^2 f = Hf(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- ❖ donde H es **semidefinida positiva** si: $x^T H x \geq 0, \forall x \in \mathbb{R}^n$
- ❖ donde H es **definida positiva** si: $x^T H x > 0, \forall x \in \mathbb{R}^n, x \neq 0$

FUNCIÓN CONVEXA

Propiedades:

1. La suma de funciones convexas es una función convexa
2. Si $f(x)$ es convexa, entonces $k \cdot f(x)$ es convexa para cualquier $k > 0$
3. La composición preserva convexidad: Sea $f(x)$ y $g(x)$ convexas. Si $g(x)$ es no decreciente, entonces $g(f(x))$ es convexa
4. $f(x)$ es convexa si y sólo si el conjunto epígrafe dado por $\{x \in D, y \in \mathbb{R}: f(x) \leq y\} \in D \times \mathbb{R}$ es convexo

CONVEXIDAD VS UNICIDAD DE SOLUCIÓN

CONVEXIDAD VS UNICIDAD

Se dice que el problema $P: \min_{x \in D} f(x)$ es convexo si:

1. Si $f(x)$ es continua y convexa sobre D
2. D es un conjunto convexo

Teorema: Mínimo local = global

Si P es convexo $\Rightarrow$ Todo mínimo local de P es global.

Corolario: En modelos lineales continuos, cualquier mínimo local es global


Teorema: Unicidad de solución

Si P es convexo, admite solución óptima y $f(x)$ es estrictamente convexa $\Rightarrow P$ tiene solución óptima **única**.

CONVEXIDAD VS MAX/MIN GLOBAL


➤ Convexo

$$f(x) = x^2 - 3$$



➤ Cóncavo


$$f(x) = -x^2$$



- ❖ ¿Pueden identificar un mínimo o máximo global (considerando cualquier valor de x)?
- ❖ En una función convexa podemos encontrar un mínimo global
- ❖ ¿Podemos transformar esta función cóncava en una convexa?
- ❖ ¿Podemos transformar un problema de maximización en uno de minimización?

ÓPTIMO GLOBAL Y LOCAL


- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**
- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en D , si hay un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo global**
- ❑ No siempre vamos a encontrar un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicará que el mínimo global está en una frontera y, en ese caso, x^* puede ser un mínimo global con $\nabla f(x^*) \neq 0$
- ❑ Si $D = \mathbb{R}^n$, el problema de optimización es no restringido, y x^* es un mínimo global si y sólo si $\nabla f(x^*) = 0$



- 1: Mínimo local
- 2: Mínimo local (es mínimo global, pero no puedo garantizarlo)

ÓPTIMO GLOBAL Y LOCAL


- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**
- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en D , si hay un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo global**
 - No siempre vamos a encontrar un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicará que el mínimo global está en una frontera y, en ese caso, x^* puede ser un mínimo global con $\nabla f(x^*) \neq 0$
 - Si $D = \mathbb{R}^n$, el problema de optimización es no restringido, y x^* es un mínimo global si y sólo si $\nabla f(x^*) = 0$



1: Mínimo global garantizado

ÓPTIMO GLOBAL Y LOCAL


- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**
- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en D , si hay un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo global**
- ❑ No siempre vamos a encontrar un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicará que el mínimo global está en una frontera y, en ese caso, x^* puede ser un mínimo global con $\nabla f(x^*) \neq 0$
- ❑ Si $D = \mathbb{R}^n$, el problema de optimización es no restringido, y x^* es un mínimo global si y sólo si $\nabla f(x^*) = 0$



1: Mínimo global garantizado pero, ¿cómo lo encuentro?

ÓPTIMO GLOBAL Y LOCAL


- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**
- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en D , si hay un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo global**
 - ❑ No siempre vamos a encontrar un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicará que el mínimo global está en una frontera y, en ese caso, x^* puede ser un mínimo global con $\nabla f(x^*) \neq 0$
 - ❑ Si $D = \mathbb{R}^n$, el problema de optimización es no restringido, y x^* es un mínimo global si y sólo si $\nabla f(x^*) = 0$



Ningún punto satisface $\nabla f(x^*) = 0$, por lo que no hay mínimo global

ÓPTIMO GLOBAL Y LOCAL


- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo local**
- Si D es un conjunto convexo y $f(x)$ es una función convexa y diferenciable en D , si hay un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, entonces x^* es un **mínimo global**
 - No siempre vamos a encontrar un punto $x^* \in D$ tal que $\nabla f(x^*) = 0$, lo que implicará que el mínimo global está en una frontera y, en ese caso, x^* puede ser un mínimo global con $\nabla f(x^*) \neq 0$
 - Si $D = \mathbb{R}^n$, el problema de optimización es no restringido, y x^* es un mínimo global si y sólo si $\nabla f(x^*) = 0$



1: Mínimo global garantizado

ÓPTIMO GLOBAL Y LOCAL

- Podemos encontrar todos los puntos estacionarios de una función $f(x)$ en un dominio D encontrando todos los puntos donde su primera derivada es igual a 0
- Podemos evaluar si cada punto estacionario es mínimo/máximo local o punto silla usando la matriz hessiana:
 1. La matriz hessiana es semidefinida positiva en ese punto, entonces es un **mínimo local**
 2. La matriz hessiana es semidefinida negativa en ese punto, entonces es un **máximo local**
 3. La matriz hessiana es indefinida (valores propios positivos y negativos), es un **punto silla**



EJERCICIOS CONVEXIDAD

EJERCICIOS CONVEXIDAD

Ejercicios:

Determine si las siguientes funciones son convexas (y en qué dominio):

1. $f(x) = -\ln(x_1 + 1) - x_2, \forall x_1 \in (-1, \infty); x_2 \in \mathbb{R}$

2. $f(x) = 2x_1 + x_2 - 3$

3. $f(x) = \exp(x_1) + 2x_2^3$


EJERCICIOS CONVEXIDAD

Ejercicios:

1. $f(x) = -\ln(x_1 + 1) - x_2, \forall x_1 \in (-1, \infty); x_2 \in \mathbb{R}$

$$Hf(x) = \begin{bmatrix} \frac{1}{(x_1 + 1)^2} & 0 \\ 0 & 0 \end{bmatrix}$$

Gráfico: $-\ln(x_1 + 1) - x_2 = 0$



Los menores principales son positivos para todos los valores de x_1 y $x_2 \rightarrow$ la matriz Hessiana es semidefinida positiva en todo el dominio


EJERCICIOS CONVEXIDAD

Ejercicios:

2. $f(x) = 2x_1 + x_2 - 3$

$$Hf(x) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

Gráfico: $2x_1 + x_2 - 3 = 0$



Los menores principales son positivos para todos los valores de x_1 y $x_2 \rightarrow$ la matriz Hessiana es semidefinida positiva en todo el dominio

EJERCICIOS CONVEXIDAD

Ejercicios:

3. $f(x) = \exp(x_1) + 2x_2^3$

$$Hf(x) = \begin{bmatrix} e^{x_1} & 0 \\ 0 & 12x_2 \end{bmatrix} \longrightarrow \begin{aligned} \det(\Delta_1) &= e^{x_1} \\ \det(\Delta_2) &= 12x_2 e^{x_1} \end{aligned}$$

La función exponencial es siempre positiva, así que tenemos que asegurarnos solamente que x_2 sea positivo para que la matriz Hessiana sea semidefinida positiva

Convexa: $x_2 \in [0, \infty)$

OPTIMIZACIÓN

ICS1113 – Sección 3

CONVEXIDAD Y UNICIDAD

CAMILA BALBONTIN

✉ camila.balbontin@uc.cl



Departamento de Transporte y Logística



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Primer Semestre, 2024