

OPTIMIZACIÓN

ICS1113 – Sección 3

CONVEXIDAD Y MODELOS EQUIVALENTES

CAMILA BALBONTIN

✉ camila.balbontin@uc.cl



Departamento de Transporte y Logística



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Primer Semestre, 2024



DEPARTAMENTO DE INGENIERÍA DE
TRANSPORTE Y LOGÍSTICA
ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA


LANZAMIENTO AÑO ACADÉMICO 2024



BIENVENIDA
Ricardo Giesen
Director del DITL

INVITADO ESPECIAL

Juan de Dios Ortúzar
Profesor Emérito de nuestro
departamento



¡TE ESPERAMOS!

Miércoles 24 Abril - 13:30 hrs

Auditorio del Complejo Andrónico Luksic

Inscripciones: bit.ly/LanzamientoDITL2024


¡Búscanos!



ING.UC.CL/TRANSPORTE-Y-LOGISTICA/



@ING_TRANSPORTE_UC



CONTENIDOS I1

- Modelamiento
- Conceptos básicos
- Existencia de solución óptima
- Convexidad y unicidad

Ayudantía transversal a realizarse en formato online este sábado a las 9:00 hrs.

CONVEXIDAD

CONVEXIDAD

- La convexidad de la región factible es esencial para encontrar la solución óptima de un problema no lineal
- Un conjunto D es convexo si




$$x = \lambda x_1 + (1 - \lambda) x_2, \quad x \in D, \forall x_1, x_2 \in D, \forall \lambda \in [0, 1]$$

1. La intersección entre conjuntos convexos es también convexo

- La unión de conjuntos convexos no es siempre convexa

2. Un dominio lineal es convexo

3. El conjunto vacío y $\mathbb{R}^n$ son convexos




FUNCIÓN CONVEXA

➤ Si **D** es un conjunto convexo, entonces la función $f(x)$ es convexo en el dominio D si:

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2), \quad \forall x_1, x_2 \in D, \forall \lambda \in [0,1]$$

- $f(x)$ es estrictamente convexo si la desigualdad anterior es estricta ($<$)
- $f(x)$ es cóncavo si $-f(x)$ es convexo
- Una función lineal es cóncava y convexa


Recordar que x_1 y x_2 representan puntos del dominio, se debería cumplir para todos los puntos del dominio



FUNCIÓN CONVEXA

- Si **D** es un conjunto convexo, entonces la función $f(x)$ es **estrictamente convexa** en el dominio D si:

$$f(\lambda x_1 + (1-\lambda)x_2) < \lambda f(x_1) + (1-\lambda)f(x_2), \quad \forall x_1, x_2 \in D, \forall \lambda \in (0,1)$$



FUNCIÓN CONVEXA

➤ ¿Por qué D tiene que ser un conjunto convexo?

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2), \quad \forall x_1, x_2 \in D, \forall \lambda \in [0,1]$$

Porque necesitamos que la función esté definida en D para toda combinación:

$$\lambda x_1 + (1-\lambda)x_2$$

Por lo que todas estas combinaciones deben pertenecer a D, lo que se cumple si D es convexo.

FUNCIÓN CONVEXA

➤ Condición de segundo orden:

- Si D es un conjunto convexo y $f(x)$ es **diferenciable dos veces in D** , entonces $f(x)$ es convexo en D si y sólo si $\nabla^2 f(x)$ es semidefinida positiva para todo $x \in D$

$$\nabla^2 f(x) \geq 0, \quad \forall x \in D$$

Y es estrictamente convexo si $\nabla^2 f(x)$ es definida positiva

FUNCIÓN CONVEXA

Propiedades:

1. La suma de funciones convexas es una función convexa
2. Si $f(x)$ es convexa, entonces $k \cdot f(x)$ es convexa para cualquier $k > 0$
3. La composición preserva convexidad: Sea $f(x)$ y $g(x)$ convexas. Si $g(x)$ es no decreciente, entonces $g(f(x))$ es convexa
4. $f(x)$ es convexa si y sólo si el conjunto epígrafe dado por $\{x \in D, y \in \mathbb{R}: f(x) \leq y\} \in D \times \mathbb{R}$ es convexo

FUNCIÓN CONVEXA

➤ ¿Por qué $g(x)$ tiene que ser no decreciente para que se cumpla la propiedad 3?

$$h(x) = g(f(x)) \rightarrow h(\lambda x_1 + (1-\lambda)x_2) \leq \lambda h(x_1) + (1-\lambda)h(x_2)?$$

$$(a) f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2), \quad \forall x_1, x_2 \in D, \forall \lambda \in [0,1]$$

$$(b) g(\lambda x_1 + (1-\lambda)x_2) \leq \lambda g(x_1) + (1-\lambda)g(x_2), \quad \forall x_1, x_2 \in D, \forall \lambda \in [0,1]$$

$$\Rightarrow \text{si } g(x) \text{ es no decreciente (NC): } y_1 \leq y_2 \rightarrow g(y_1) \leq g(y_2)$$

$$h(\lambda x_1 + (1-\lambda)x_2) = g(f(\lambda x_1 + (1-\lambda)x_2))$$

$$y_1 = f(\lambda x_1 + (1-\lambda)x_2), \quad y_2 = \lambda f(x_1) + (1-\lambda)f(x_2)$$

$$\rightarrow g(f(\lambda x_1 + (1-\lambda)x_2)) \underset{(a) \ \& \ g \text{ NC}}{\leq} g(\lambda f(x_1) + (1-\lambda)f(x_2)) \underset{(b)}{\leq} \lambda g(f(x_1)) + (1-\lambda)g(f(x_2))$$

FUNCIÓN CONVEXA

➤ ¿Por qué $g(x)$ tiene que ser no decreciente para que se cumpla la propiedad 3?

Por ejemplo:

$$g(x) = x^2, f(x) = x^2 - 1$$

$$h(x) = g(f(x)) = x^4 - 2x^2 + 1$$

$$\rightarrow \Delta_1 h(x) = 12x^2 - 4$$

$$\rightarrow \text{Convexa en el dominio: } x \in (-\infty, -1/3], [1/3, \infty)$$

Es decir, no es convexa en todo el dominio D como sí lo son g y f .

CONVEXIDAD VS UNICIDAD

Se dice que el problema $P: \min_{x \in D} f(x)$ es convexo si:

1. Si $f(x)$ es continua y convexa sobre D
2. D es un conjunto convexo

Teorema: Mínimo local = global

Si P es convexo $\Rightarrow$ Todo mínimo local de P es global.

Corolario: En modelos lineales continuos, cualquier mínimo local es global

Teorema: Unicidad de solución

Si P es convexo, admite solución óptima y $f(x)$ es estrictamente convexa $\Rightarrow P$ tiene solución óptima **única**.

CONVEXIDAD VS UNICIDAD

➤ ¿Por qué es necesario que la función sea estrictamente convexa en D para que haya una solución óptima única?

Suponga que el problema definido por: $P: \min_{x \in D} f(x)$

Tiene dos soluciones óptimas: $x, y \in \mathbb{R}^n$

Esto quiere decir que ambas pertenecen al dominio D , y que:

$$f(x) = f(y) \leq f(z) \quad \forall z \in D \quad (1)$$

Consideremos ahora un $z = \frac{x+y}{2} \in D$, y por convexidad estricta tenemos que:

$$f(z) = f\left(\frac{x+y}{2}\right) < \frac{1}{2} f(x) + \frac{1}{2} f(y) = f(x)$$

$$f(z) < f(x)$$

Lo que es inconsistente con (1), entonces si es estrictamente convexa no permite dos soluciones óptimas.

MODELOS EQUIVALENTES

MODELOS EQUIVALENTES

Consideremos dos modelos de optimización:

$$P1: \min_{x \in D} f(x)$$

$$P2: \min_{x \in Q} g(x)$$

P_1 y P_2 son modelos **equivalentes** si ambos tienen el mismo conjunto de soluciones óptimas o si existe una transformación simple que permite construir el conjunto de soluciones óptima de uno a partir de las soluciones óptimas del otro.

Dos modelos son equivalentes si al resolver uno, resolvemos el otro.

La notación $P_1 \sim P_2$ equivale a señalar que los modelos son equivalentes.

MODELOS EQUIVALENTES: Max/min

Consideremos dos modelos de optimización:

$$P1: \min_{x \in D} f(x) \quad \sim$$


$$P2: \max_{x \in D} -f(x)$$

x^* es solución óptima de P_1 , con valor óptimo v

$\Leftrightarrow$

x^* es solución óptima de P_2 , con valor óptimo $-v$

En D unidimensional:



MODELOS EQUIVALENTES: Linealización de objetivo

Consideremos dos modelos de optimización:

$$P1: \min_{x \in D} f(x)$$

~

$$P2: \min_{\mu \in \mathbb{R}, x \in D} \mu$$


$$\text{s.a. } \mu \geq f(x)$$

x^* es solución óptima de P_1 , con valor óptimo v

$\Leftrightarrow$

$(x^*, f(x^*))$ es solución óptima de P_2 , con valor óptimo v

En D unidimensional:



MODELOS EQUIVALENTES: Mínimo de máximos

Consideremos dos modelos de optimización:

$$P1: \min_{x \in D} \max_{i \in \{1, \dots, m\}} f_i(x)$$

$\sim$

$$P2: \min_{\mu \in \mathbb{R}, x \in D} \mu$$

$$P1 \rightarrow P2: \min_{\mu \in \mathbb{R}, x \in D} \mu$$

$$s.a. \quad \mu \geq \max_{i \in \{1, \dots, m\}} f_i(x)$$


$$s.a. \quad \mu \geq f_i(x), \quad \forall i \in \{1, \dots, m\}$$

x^* es solución óptima de P_1 , con valor óptimo v

$\Leftrightarrow$

$(x^*, \max_{i \in \{1, \dots, m\}} f_i(x^*))$ es solución óptima de P_2 , con valor óptimo v

En D unidimensional:



MODELOS EQUIVALENTES: Suma de funciones

Consideremos dos modelos de optimización:

$$P1: \min_{x \in D} \sum_{i=1}^m f_i(x)$$

~

$$P2: \min_{\mu \in \mathbb{R}^m, x \in D} \sum_{i=1}^m \mu_i$$

$$s.a. \quad \mu_i \geq f_i(x), \quad \forall i \in \{1, \dots, m\}$$

x^* es solución óptima de P_1 , con valor óptimo v

$\Leftrightarrow$

$(x^*, f_1(x^*), \dots, f_m(x^*))$ es solución óptima de P_2 , con valor óptimo v

MODELOS EQUIVALENTES: Composición

Considere $g: \mathbb{R} \rightarrow \mathbb{R}$ una función estrictamente creciente sobre la imagen de f :

$$P1: \min_{x \in D} f(x)$$

$\sim$

$$P2: \min_{x \in D} g(f(x))$$

x^* es solución óptima de P_1 , con valor óptimo v

$\Leftrightarrow$


x^* es solución óptima de P_2 , con valor óptimo $g(v)$

x	f(x)	T1	T2	T3
	$\text{EXP}(2 \cdot x + 1) + \text{EXP}(-x - 2)$	$\text{LN}(f(x))$	$f(x)^2$	$f(x)^{(1/2)}$
-5	20,1	3,0	403,4	4,5
-4	7,4	2,0	54,6	2,7
-3	2,7	1,0	7,4	1,7
-2	1,0	0,0	1,1	1,0
-1	0,7	-0,3	0,5	0,9
0	2,9	1,0	8,1	1,7
1	20,1	3,0	405,4	4,5
2	148,4	5,0	22031,9	12,2
3	1096,6	7,0	1202619,1	33,1
4	8103,1	9,0	65660009,3	90,0
5	59874,1	11,0	3584912955,3	244,7

MODELOS EQUIVALENTES: Composición


Ejemplo **estrictamente creciente**
sobre imagen de f:

●	$g(x) = \ln(e^{2x+1} + e^{-x-2})$
●	$f(x) = e^{2x+1} + e^{-x-2}$
●	$h(x) = (e^{2x+1} + e^{-x-2})^2$



Ejemplo **creciente y decreciente**
sobre imagen de f:

●	$g(x) = x^2 + 8x + 16$
●	$f(x) = x + 4$





ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

OPTIMIZACIÓN

ICS1113 – Sección 3

CONVEXIDAD Y MODELOS EQUIVALENTES

CAMILA BALBONTIN



camila.balbontin@uc.cl



Departamento de Transporte y Logística

Primer Semestre, 2024