

# OPTIMIZACIÓN

## ICS1113 – Sección 3

PLANOS CORTANTES Y PROGRAMACIÓN NO LINEAL

CAMILA BALBONTIN

✉ camila.balbontin@uc.cl

🏢 Departamento de Transporte y Logística

Primer Semestre, 2024

Estas clases han sido basadas en el material desarrollado por el Prof. Mathias Klapp, junto con elementos extraídos de los textos bibliográficos y otros apuntes.



ESCUELA DE INGENIERÍA  
FACULTAD DE INGENIERÍA

# PROGRAMACIÓN LINEAL ENTERA

# PLANOS CORTANTES

- ❖ Conceptos básicos
- ❖ Algoritmo Branch & Bound
- ❖ **Planos cortantes**

# PLANOS CORTANTES DE GOMORY

Se toma el ILP estandarizado:

$$v = \min_{x \in \mathbb{Z}_+} \{c^T x \text{ s.a. } Ax = b\}$$

Sea  $B$  una configuración de base óptima para la relajación lineal:

$$\bar{b} = A_B^{-1}b \geq 0$$

$$r_N^T = c_N^T - r_B^T \bar{A}_N \geq 0$$

- Si  $\bar{b} \in \mathbb{Z}^m$ , entonces es también solución óptima del problema entero
- Pero si  $\bar{b} \notin \mathbb{Z}^m$ , el vértice es infactible para el problema entero  
Existe variable básica  $k \in B$  de valor  $\bar{b}_k$  fraccionario

# PLANOS CORTANTES DE GOMORY

- Tome la fila  $k$  de  $x_B + \bar{A}_N x_N = \bar{b}$  dada por:

$$x_k + \sum_{j \in D} \bar{a}_{kj} x_j = \bar{b}_k$$

- Divida lo integral de lo fraccionario:  $f_{\bar{a}_{kj}}^- = \bar{a}_{kj} - \lfloor \bar{a}_{kj} \rfloor$  y  $f_{\bar{b}_k}^- = \bar{b}_k - \lfloor \bar{b}_k \rfloor$ , y reordene:


$$x_k + \sum_{j \in D} \lfloor \bar{a}_{kj} \rfloor x_j - \lfloor \bar{b}_k \rfloor = f_{\bar{b}_k}^- - \sum_{j \in D} f_{\bar{a}_{kj}}^- x_j$$

- Implica que  $f_{\bar{b}_k}^- - \sum_{j \in D} f_{\bar{a}_{kj}}^- x_j$  debe ser entero. Hay dos casos:

$$f_{\bar{b}_k}^- - \sum_{j \in D} f_{\bar{a}_{kj}}^- x_j \leq 0 \quad \text{o} \quad f_{\bar{b}_k}^- - \sum_{j \in D} f_{\bar{a}_{kj}}^- x_j \geq 1$$

- La segunda situación es imposible, por lo que el **corte de Gomory** es:  $\sum_{j \in D} f_{\bar{a}_{kj}}^- x_j \geq f_{\bar{b}_k}^-$

# PLANOS CORTANTES DE GOMORY: GRAFICAMENTE



- $\sum_{j \in D} f_{a_{kj}}^- x_j \geq f_{\bar{b}_k}$  elimina el óptimo relajado fraccionario, fuerza a levantar variables fuera de base y no corta soluciones enteras

# PLANOS CORTANTES DE GOMORY: GRAFICAMENTE

$$\min_{x \in Z_+^5} 20x_1 + 30x_2$$

$$s.a. \quad 3x_1 + 4x_2 - x_3 = 48$$

$$x_1 + 2x_2 - x_4 = 19$$

$$x_3 + x_4 - x_5 = 1$$


↓  
Es equivalente  
(despejando  $x_3$  y  $x_4$   
en R1 y R2 y  
reemplazando en la  
R3)

$$\min_{x \in Z_+^5} 20x_1 + 30x_2$$

$$s.a. \quad 3x_1 + 4x_2 \geq 48$$

$$x_1 + 2x_2 \geq 19$$

$$2x_1 + 3x_2 \geq 34$$



# PLANOS CORTANTES DE GOMORY: ALGORITMO

## Algoritmo:

- Se agrega corte,
- Se resuelve LP,
- Se repite hasta tener solución entera

**Teorema:** Converge a solución óptima en un número finito de planos (aunque puede ser muy grande)

- Los cortes fortalecen la formulación
- En todos los casos, los cortes deben reducir el espacio solución del problema entero relajado (lineal), pero no deben cortar las partes factibles del problema entero.

# PLANOS CORTANTES: COVERS

- Para dominios con restricciones de tipo mochila **binaria**:

$$\sum_{i=1}^n v_i x_i \leq b, \quad x \in \{0,1\}^n$$

- Un **cubrimiento** o **cover**  $C \subseteq \{1, \dots, n\}$  es subconjunto de variables binarias que **no pueden** todas valer uno al mismo tiempo
- Es decir,  $C$  es un cover si:  $\sum_{i \in C} v_i > b$

Se deduce al siguiente plano cortante:

$$\sum_{i \in C} x_i \leq |C| - 1$$

# PLANOS CORTANTES: COVERS

Por ejemplo:

$$\begin{array}{ll} \max & 50x_1 + 20x_2 + 2x_3 + 5x_4 + 6x_5 + x_6 \\ & x \in \{0,1\}^n \\ \text{s.a.} & 20x_1 + 5x_2 + x_3 + 6x_4 + 10x_5 + 2x_6 \leq 30 \end{array}$$

- Las variables  $x_1, x_2$  y  $x_4$  forman un **cubrimiento**, ya que simultáneamente las tres variables no pueden tomar el valor 1 y satisfacer la restricción.
- Por lo tanto,  $C = \{1,2,4\}$  es el cubrimiento formado por las variables  $x_1, x_2$  y  $x_4$  que se deduce al siguiente plano cortante (desigualdad asociada):  $x_1 + x_2 + x_4 \leq 2$
- ¿Existe algún otro cover mínimo?  
 $C = \{1,2,5\}$ ;  $C = \{1,3,5\}$ ;  $C = \{1,2,4,5\}$ ; etc...

# PLANOS CORTANTES: COVERS

Por ejemplo:

$$\begin{array}{ll} \max_{x \in \{0,1\}^n} & 50x_1 + 20x_2 + 2x_3 + 5x_4 + 6x_5 + x_6 \\ \text{s.a.} & 20x_1 + 5x_2 + x_3 + 6x_4 + 10x_5 + 2x_6 \leq 30 \end{array}$$

Solución relajada:

$$\rightarrow x^R = \left[ 1; 1; 1; \frac{2}{3}; 0; 0 \right]$$

➤ Cover  $C = \{1,2,4\}$ :

$$\begin{array}{ll} \max_{x \in \{0,1\}^n} & 50x_1 + 20x_2 + 2x_3 + 5x_4 + 6x_5 + x_6 \\ \text{s.a.} & 20x_1 + 5x_2 + x_3 + 6x_4 + 10x_5 + 2x_6 \leq 30 \\ & x_1 + x_2 + x_4 \leq 2 \end{array}$$

Solución relajada:

$$\rightarrow x^R = \left[ 1; 1; 1; 0; \frac{2}{5}; 0 \right]$$

➤ Cover  $C = \{1,2,5\}$ :

$$\begin{array}{ll} \max_{x \in \{0,1\}^n} & 50x_1 + 20x_2 + 2x_3 + 5x_4 + 6x_5 + x_6 \\ \text{s.a.} & 20x_1 + 5x_2 + x_3 + 6x_4 + 10x_5 + 2x_6 \leq 30 \\ & x_1 + x_2 + x_4 \leq 2 \\ & x_1 + x_2 + x_5 \leq 2 \end{array}$$

Solución relajada:

$$\rightarrow x^R = [1; 1; 1; 0; 0; 1]$$

Solución óptima:


$$\rightarrow x^* = [1; 1; 1; 0; 0; 1]$$

# PROGRAMACIÓN NO LINEAL

# CONTENIDOS

- **Parte I: Motivación, modelación y conceptos básicos**
  - Introducción
  - Modelos de optimización
  - Conceptos básicos, convexidad, existencia y unicidad de soluciones
  - Modelos equivalentes
- **Parte II: Programación lineal**
  - Introducción
  - Geometría de poliedros
  - Simplex
  - Sensibilidad
  - Dualidad
- **Parte III: Programación lineal entera**
  - Conceptos básicos
  - Algoritmos: Branch & bound (ramificación y acotamiento) y planos cortantes
- **Parte IV: Programación no lineal**
  - Optimización no lineal irrestricta: condiciones de 1er y 2do orden
  - Optimización con restricciones de igualdad y desigualdad, condiciones KKT

# CONTENIDOS



# HASTA AHORA...

- Sabemos modelar, analizar y resolver problemas de programación lineal
- Nociones generales de cómo resolver problemas enteros o enteros mixtos
- ¿Y si queremos modelar interacciones no lineales en restricciones y/o función objetivo como las que vimos en la sección de modelamiento no lineal?
- Por ejemplo, economías de escala, error cuadrático medio (regresión lineal), distancia euclidiana...

# PROGRAMACIÓN NO LINEAL IRRESTRICTA

# MODELO DE OPTIMIZACIÓN NO LINEAL IRRESTRICTA

- ❖ **Modelo de optimización no lineal irrestricta**
- ❖ Condiciones necesarias y suficientes de optimalidad
- ❖ Condiciones necesarias y suficientes en problemas convexos

# MODELO DE OPTIMIZACIÓN NO LINEAL

$$\min_{x \in X} f(x)$$

Donde  $X := \{x \in \mathbb{R}^n : g_i(x) \leq 0, \quad i = 1, \dots, m\}$

- Dominio irrestricto cuando  $X = \mathbb{R}^n$
- Supondremos que función objetivo es continuamente diferenciable o  $f \in \mathcal{C}^1$ , es decir, tiene primera derivada parcial y es continua

# REPASO: VECTOR GRADIENTE $\nabla f(x)$

➤ Para  $f \in \mathcal{C}^1$  sobre  $x \in \mathbb{R}^n$  se define su **gradiente** como el vector de primeras derivadas parciales:

$$\nabla f(x) = \left[ \frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_i}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^T$$

## Comentarios:

- Conceptualmente, indica la magnitud y dirección de máximo crecimiento de  $f$  en un valor  $x$  dado
- El producto con un vector  $d \in \mathbb{R}^n$  dado por  $\nabla f(x)^T d$  es el cambio marginal de  $f$  al avanzar en la dirección  $d$  desde  $x$ , es decir:


$$\nabla f(x)^T d = \lim_{t \rightarrow 0^+} \frac{f(x + t \cdot d) - f(x)}{t}$$

# REPASO: VECTOR GRADIENTE $\nabla f(x)$

➤ Ejemplo:

$$f(x) = x_1^2 + x_1x_2 + 0,5x_2^2$$

$$\rightarrow \nabla f(x) = [2x_1 + x_2, x_1 + x_2]$$




$$\nabla f(0, 0,5) = [0,5, 0,5]$$

$$d = [1,0]$$


$$\nabla f(0, 0,5)^T d = 0,5$$

Es decir, moverse  
marginalmente hacia  $d$   
genera un ascenso de 0,5 por  
unidad avanzada



# DIRECCIÓN DE DESCENSO

- Una **dirección de descenso** de  $f$  en el punto  $x \in \mathbb{R}^n$  es un vector  $d \in \mathbb{R}^n$  tal que  $\nabla f(x)^T d < 0$




**Propiedad 1:** Si  $|\nabla f(x)| \neq 0$ , entonces  $d = -\nabla f(x)$  es una dirección de descenso

# REPASO: TEOREMA DEL VALOR MEDIO (TVM)

$\forall x, d \in \mathbb{R}^n$  existe un valor  $t \in [0,1]$  tal que:

$$f(x + d) - f(x) = \nabla f(x + t \cdot d)^T d$$



# REPASO: TEOREMA DEL VALOR MEDIO (TVM)

$\forall x, d \in \mathbb{R}^n$  existe un valor  $t \in [0,1]$  tal que:

$$f(x + d) - f(x) = \nabla f(x + t \cdot d)^T d$$

**Demostración:**

TVM clásico: Si una función  $f$  es continua en el intervalo cerrado  $[a, b]$  y derivable en el intervalo abierto  $(a, b)$ , entonces existe al menos un punto  $c$  en el intervalo  $(a, b)$  tal que:

$$f'(c) = \frac{f(b) - f(a)}{b - a}$$

Ahora imaginemos que tenemos una función  $g(t) = f(x + td)$  continua en  $[0,1]$  y derivable en  $(0,1)$ , por lo que existe un  $t'$  tal que:  $g'(t') = \frac{g(1) - g(0)}{1 - 0}$

$$\text{Y } g'(t) = \nabla f(x + t \cdot d)^T d$$

$$\text{Como } g(1) = f(x + d); g(0) = f(x)$$

$$\rightarrow \nabla f(x + t' \cdot d)^T d = f(x + d) - f(x)$$

# DIRECCIÓN DE DESCENSO

**Propiedad 2:** Si existe una dirección de descenso de  $f$  en  $x$ , entonces  $x$  no es mínimo local (ML)

## Prueba:

- Supongamos (por contradicción) que  $x$  es ML y existe  $d: d^T \nabla f(x) < 0$ 
  - Por continuidad, se puede re-escalar  $d$  y mantener  $x + d$  en vecindad de  $x$
- Por TVM, existe un valor puntual  $t$  tal que

$$f(x + d) - f(x) = d^T \nabla f(x + t \cdot d) < 0$$

- Es decir,  $x^0 = x + d$  cumple que  $f(x^0) < f(x)$ . Luego,  $x$  no es ML (contradicción)

# REPASO EXISTENCIA DE SOLUCIÓN

## Teorema Bolzano-Weierstrass (extendido)

Si para  $P$  dado por  $\min_{x \in D} f(x)$  se cumple que:

1.  $f(x)$  es continua sobre  $D$
2.  $D$  es cerrado
3.  $D \neq \emptyset$
4.  $f(x) \rightarrow \infty$  cuando  $\|x\| \rightarrow \infty$ , para todo  $x \in D$  (función coercitiva)


Entonces el problema  $P$  admite al menos una solución óptima.

# CONDICIONES NECESARIAS Y SUFICIENTES DE OPTIMALIDAD

- ❖ Modelo de optimización no lineal irrestricta
- ❖ **Condiciones necesarias y suficientes de optimalidad**
- ❖ Condiciones necesarias y suficientes en problemas convexos

# CONDICIÓN NECESARIA DE PRIMER ORDEN

Si  $x^* \in \mathbb{R}^n$  es mínimo local de  $f(x)$ , entonces  $\nabla f(x^*) = 0$



# CONDICIÓN NECESARIA DE PRIMER ORDEN

Si  $x^* \in \mathbb{R}^n$  es mínimo local de  $f(x)$ , entonces  $\nabla f(x^*) = 0$

La condición **es necesaria** para optimalidad local, es decir que  $x^*$  sea mínimo local implica que  $\nabla f(x^*) = 0$

Sin embargo, **no es suficiente** para garantizar optimalidad local. Es decir, un punto  $x^0$  que cumpla  $\nabla f(x^0) = 0$  no es necesariamente mínimo local (puede ser máximo local, punto silla, etc...)

# REPASO: MATRIZ HESSIANA (O HESSIANO)

Para  $f \in \mathcal{C}^2$  sobre un  $x \in \mathbb{R}^n$  se define un **Hessiano**  $H_f(x)$  como la matriz de sus segundas derivadas parciales en  $x$ :

$$\nabla^2 f = H_f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} = \left[ \frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{i=1, \dots, n, j=1, \dots, n}$$

## Comentarios:

Es siempre simétrica

Indica convexidad y curvatura de la función  $f$

# REPASO: EXPANSIÓN DE TAYLOR

Para  $f \in \mathcal{C}^2$ :

$\forall x, x^0 \in \mathbb{R}^n$  tal que  $d = x - x^0$  se cumple que:

$$f(x) = f(x^0) + \nabla f(x^0)^T d + \frac{1}{2} d^T H_f(x^0) d + o(\|d\|^2)$$

## Comentarios:

- $o(\|d\|^2)$ : Error de orden mayor a cuadrático
- $f(x) \approx f(x^0) + \nabla f(x^0)^T d + \frac{1}{2} d^T H_f(x^0) d$
- Es decir, el cambio  $f(x^0 + d) - f(x^0)$  sobre una dirección de movimiento  $d = x - x^0$  partiendo en  $x^0$  se puede aproximar por  $\nabla f(x^0)^T d + \frac{1}{2} d^T H_f(x^0) d$


# REPASO: EXPANSIÓN DE TAYLOR

Ejemplo: Aproximar  $e^x$  en torno a  $x^0 = 1$ :

$$f(x) \approx f(x^0) + \nabla f(x^0)^T d + \frac{1}{2} d^T H_f(x^0) d$$

$$d = x - x^0 = x - 1$$

$$e^x \approx e + e \cdot (x-1) + \frac{e}{2} \cdot (x-1)^2 = \frac{e}{2} \cdot (x^2 + 1)$$



# REPASO: MATRIZ (SEMI)DEFINIDA POSITIVA

Una matriz simétrica  $H$  es semidefinida positiva (s.d.p.) si:

$$d^T H d \geq 0, \forall d \in \mathbb{R}^n$$

Es definida positiva (d.p.) si:

$$d^T H d > 0, \forall d \in \mathbb{R}^n$$

¿Cómo determinarlo?

- $H$  es s.d.p. (d.p.)  $\Leftrightarrow$  valores propios son  $\geq 0$  ( $> 0$ )
- $H$  es s.d.p. (d.p.) si determinantes de menores principales son  $\geq 0$  ( $> 0$ )

$H$  es (semi)definida negativa  $\Leftrightarrow -H$  es (semi)definida positiva

# CONDICIÓN NECESARIA DE SEGUNDO ORDEN

Si  $x^* \in \mathbb{R}^n$  es mínimo local de  $f(x)$ , entonces  $\nabla f(x^*) = 0$  y  $H_f(x^*)$  es semi-definida positiva

## Idea básica de la prueba:

De la expansión de Taylor y asumiendo  $\nabla f(x^*) = 0$ , se cumple para un movimiento  $d$  infinitesimal desde  $x^*$  que:

$$f(x^* + d) - f(x^*) \approx \frac{1}{2} d^T H_f(x^*) d$$

- Si existe un  $d$  tal que  $d^T H_f(x^*) d < 0$ , implicaría que  $f(x^* + d) < f(x^*)$
- Por lo mismo, un  $x^*$  mínimo local requiere  $d^T H_f(x^*) d \geq 0, \forall d \in \mathbb{R}^n$ , es decir, que sea s.d.p.

# CONDICIÓN SUFICIENTE DE SEGUNDO ORDEN

Si  $H_f(x^*)$  es definida positiva y  $\nabla f(x^*) = 0$ , entonces  $x^*$  es mínimo local de  $f(x)$ .

## Idea básica de la prueba:

De la expansión de Taylor y asumiendo  $\nabla f(x^*) = 0$ , se cumple para un movimiento  $d \neq 0$  infinitesimal desde  $x^*$  que:

$$f(x^* + d) - f(x^*) \approx \frac{1}{2} d^T H_f(x^*) d > 0$$

- Es decir, para todo movimiento  $d \neq 0$  infinitesimal alrededor de  $x^*$  se cumple que  $f(x^* + d) > f(x^*)$
- Luego,  $x^*$  es mínimo local

# EJEMPLO 1

$$\min_{x_1, x_2} (x_1 - 3x_2)^4 + (x_1 - 1)^2$$


Claramente, existe solución óptima

Condiciones necesarias de primer y segundo orden:

$$\nabla f(x) = \begin{bmatrix} 4(x_1 - 3x_2)^3 + 2(x_1 - 1); -12(x_1 - 3x_2)^3 \end{bmatrix} = 0$$

$$H_f(x) = \begin{bmatrix} 12(x_1 - 3x_2)^2 + 2 & -36(x_1 - 3x_2)^2 \\ -36(x_1 - 3x_2)^2 & 108(x_1 - 3x_2)^2 \end{bmatrix} \rightarrow s.d.p.$$

El único punto candidato a **mínimo local** es  $\left[1, \frac{1}{3}\right]$ . Como existe solución óptima, debe ser el **óptimo global**.



# EJEMPLO 1

$$\min_{x_1, x_2} (x_1 - 3x_2)^4 + (x_1 - 1)^2$$

$$\nabla f(x) = \begin{bmatrix} 4(x_1 - 3x_2)^3 + 2(x_1 - 1); -12(x_1 - 3x_2)^3 \end{bmatrix} = 0$$

$$H_f(x) = \begin{bmatrix} 12(x_1 - 3x_2)^2 + 2 & -36(x_1 - 3x_2)^2 \\ -36(x_1 - 3x_2)^2 & 108(x_1 - 3x_2)^2 \end{bmatrix}$$

$$\rightarrow y = (x_1 - 3x_2)^2$$

$$\rightarrow |H_f(x)| = 108y(12y + 2) - 36^2 y^2 \geq 0$$

$$= 36y^2 + 6y - 36y^2 \geq 0 \rightarrow 6y \geq 0$$

Como  $H_f(x)_{11}, H_f(x)_{22}, |H_f(x)| \geq 0 \rightarrow \text{s.d.p.}$

# OPTIMIZACIÓN

## ICS1113 – Sección 3

PROGRAMACIÓN NO LINEAL

CAMILA BALBONTIN

✉ [camila.balbontin@uc.cl](mailto:camila.balbontin@uc.cl)



Departamento de Transporte y Logística



ESCUELA DE INGENIERÍA  
FACULTAD DE INGENIERÍA

Primer Semestre, 2024