

# OPTIMIZACIÓN

## ICS1113 – Sección 3

PROGRAMACIÓN NO LINEAL

CAMILA BALBONTIN

✉ camila.balbontin@uc.cl



Departamento de Transporte y Logística

Primer Semestre, 2024

Estas clases han sido basadas en el material desarrollado por el Prof. Mathias Klapp, junto con elementos extraídos de los textos bibliográficos y otros apuntes.



ESCUELA DE INGENIERÍA  
FACULTAD DE INGENIERÍA

# PARTICIPACIÓN VOLUNTARIA EXPERIMENTO TRANSPORTE

¿Te gustaría participar de un experimento innovador de investigación en movilidad en Santiago desarrollado en proyecto FONDEF?

El experimento se llama **EMOV**, consiste en identificar **emociones** vivenciadas en los viajes en transporte público usando una **pulsera sensorizada** y una **aplicación móvil** durante dos semanas.

Requisitos para participar:

1. Tener celular con sistema Android (igual o superior a versión 4.1)
2. Tener datos móviles durante los viajes.

Te puedes inscribir [aquí](#). Y puedes compartirlo con quien quieras.

Si quieres saber más de la motivación de este estudio, te invito a ver el siguiente capítulo:

[Cápsulas 13C “Personas en Movimiento”: Transporte y Emociones](#)

# PROGRAMACIÓN NO LINEAL

# PROGRAMACIÓN NO LINEAL IRRESTRICTA

# MODELO DE OPTIMIZACIÓN NO LINEAL IRRESTRICTA

- ❖ **Modelo de optimización no lineal irrestricta**
- ❖ Condiciones necesarias y suficientes de optimalidad
- ❖ Condiciones necesarias y suficientes en problemas convexos

# MODELO DE OPTIMIZACIÓN NO LINEAL

$$\min_{x \in X} f(x)$$

Donde  $X := \{x \in \mathbb{R}^n : g_i(x) \leq 0, \quad i = 1, \dots, m\}$

- Dominio irrestricto cuando  $X = \mathbb{R}^n$
- Supondremos que función objetivo es continuamente diferenciable o  $f \in \mathcal{C}^1$ , es decir, tiene primera derivada parcial y es continua

# DIRECCIÓN DE DESCENSO

**Propiedad 2:** Si existe una dirección de descenso de  $f$  en  $x$  ( $d: d^T \nabla f(x) < 0$ ), entonces  $x$  no es mínimo local (ML)

## Prueba:

- Supongamos (por contradicción) que  $x$  es ML y existe  $d: d^T \nabla f(x) < 0$ 
  - Por continuidad, se puede re-escalar  $d$  y mantener  $x + d$  en vecindad de  $x$
- Por TVM, existe un valor puntual  $t$  tal que

$$f(x + d) - f(x) = d^T \nabla f(x + t \cdot d) < 0$$

- Es decir,  $x^0 = x + d$  cumple que  $f(x^0) < f(x)$ . Luego,  $x$  no es ML (contradicción)

# REPASO EXISTENCIA DE SOLUCIÓN

## Teorema Bolzano-Weierstrass (extendido)

Si para  $P$  dado por  $\min_{x \in D} f(x)$  se cumple que:

1.  $f(x)$  es continua sobre  $D$
2.  $D$  es cerrado
3.  $D \neq \emptyset$
4.  $f(x) \rightarrow \infty$  cuando  $\|x\| \rightarrow \infty$ , para todo  $x \in D$  (función coercitiva)

Entonces el problema  $P$  admite al menos una solución óptima.

# CONDICIONES NECESARIAS Y SUFICIENTES DE OPTIMALIDAD

- ❖ Modelo de optimización no lineal irrestricta
- ❖ **Condiciones necesarias y suficientes de optimalidad**
- ❖ Condiciones necesarias y suficientes en problemas convexos

# CONDICIÓN NECESARIA DE PRIMER ORDEN

Si  $x^* \in \mathbb{R}^n$  es mínimo local de  $f(x)$ , entonces  $\nabla f(x^*) = 0$

La condición **es necesaria** para optimalidad local, es decir que  $x^*$  sea mínimo local implica que  $\nabla f(x^*) = 0$

Sin embargo, **no es suficiente** para garantizar optimalidad local. Es decir, un punto  $x^0$  que cumpla  $\nabla f(x^0) = 0$  no es necesariamente mínimo local (puede ser máximo local, punto silla, etc...)

# CONDICIÓN NECESARIA DE SEGUNDO ORDEN

Si  $x^* \in \mathbb{R}^n$  es mínimo local de  $f(x)$ , entonces  $\nabla f(x^*) = 0$  y  $H_f(x^*)$  es semi-definida positiva

## Idea básica de la prueba:

De la expansión de Taylor y asumiendo  $\nabla f(x^*) = 0$ , se cumple para un movimiento  $d$  infinitesimal desde  $x^*$  que:

$$f(x^* + d) - f(x^*) \approx \frac{1}{2} d^T H_f(x^*) d$$

- Si existe un  $d$  tal que  $d^T H_f(x^*) d < 0$ , implicaría que  $f(x^* + d) < f(x^*)$
- Por lo mismo, un  $x^*$  mínimo local requiere  $d^T H_f(x^*) d \geq 0, \forall d \in \mathbb{R}^n$ , es decir, que sea s.d.p.

# CONDICIÓN SUFICIENTE DE SEGUNDO ORDEN

Si  $H_f(x^*)$  es definida positiva y  $\nabla f(x^*) = 0$ , entonces  $x^*$  es mínimo local de  $f(x)$ .

## Idea básica de la prueba:

De la expansión de Taylor y asumiendo  $\nabla f(x^*) = 0$ , se cumple para un movimiento  $d \neq 0$  infinitesimal desde  $x^*$  que:

$$f(x^* + d) - f(x^*) \approx \frac{1}{2} d^T H_f(x^*) d > 0$$

- Es decir, para todo movimiento  $d \neq 0$  infinitesimal alrededor de  $x^*$  se cumple que  $f(x^* + d) > f(x^*)$
- Luego,  $x^*$  es mínimo local

# EJEMPLO 1

$$\min_{x_1, x_2} (x_1 - 3x_2)^4 + (x_1 - 1)^2$$


Claramente, existe solución óptima

Condiciones necesarias de primer y segundo orden:

$$\nabla f(x) = \begin{bmatrix} 4(x_1 - 3x_2)^3 + 2(x_1 - 1); -12(x_1 - 3x_2)^3 \end{bmatrix} = 0$$

$$H_f(x) = \begin{bmatrix} 12(x_1 - 3x_2)^2 + 2 & -36(x_1 - 3x_2)^2 \\ -36(x_1 - 3x_2)^2 & 108(x_1 - 3x_2)^2 \end{bmatrix} \rightarrow s.d.p.$$

El único punto candidato a **mínimo local** es  $\left[1, \frac{1}{3}\right]$ . Como existe solución óptima, debe ser el **óptimo global**.



# EJEMPLO 1

$$\min_{x_1, x_2} (x_1 - 3x_2)^4 + (x_1 - 1)^2$$

$$\nabla f(x) = \begin{bmatrix} 4(x_1 - 3x_2)^3 + 2(x_1 - 1); -12(x_1 - 3x_2)^3 \end{bmatrix} = 0$$

$$H_f(x) = \begin{bmatrix} 12(x_1 - 3x_2)^2 + 2 & -36(x_1 - 3x_2)^2 \\ -36(x_1 - 3x_2)^2 & 108(x_1 - 3x_2)^2 \end{bmatrix}$$

$$\rightarrow y = (x_1 - 3x_2)^2$$

$$\rightarrow |H_f(x)| = 108y(12y + 2) - 36^2 y^2 \geq 0$$

$$= 36y^2 + 6y - 36y^2 \geq 0 \rightarrow 6y \geq 0$$

$$\text{Como } H_f(x)_{11}, H_f(x)_{22}, |H_f(x)| \geq 0 \rightarrow \text{s.d.p.}$$



Hasta acá  
llegamos el  
lunes

## EJEMPLO 2

$$\min_{x_1, x_2} -x_1 + x_1^3 + x_2 + x_2^2$$

Busquemos puntos que cumplen la condición necesaria de primer orden:

$$\nabla f(x) = [-1 + 3x_1^2; 1 + 2x_2] = 0$$

Dos candidatos a mínimo local:

$$x' = \left[-\frac{1}{\sqrt{3}}; -\frac{1}{2}\right]; x'' = \left[\frac{1}{\sqrt{3}}; -\frac{1}{2}\right]$$

Revisamos la matriz hessiana:

$$H_f(x) = \begin{bmatrix} 6x_1 & 0 \\ 0 & 2 \end{bmatrix}$$

$$H_f(x') = \begin{bmatrix} -\frac{6}{\sqrt{3}} & 0 \\ 0 & 2 \end{bmatrix} \rightarrow \text{indefinida}$$


$$H_f(x'') = \begin{bmatrix} \frac{6}{\sqrt{3}} & 0 \\ 0 & 2 \end{bmatrix} \rightarrow \text{definida positiva, mínimo local (CS)}$$

# EJEMPLO 2

$$\min_{x_1, x_2} -x_1 + x_1^3 + x_2 + x_2^2$$

Pero este problema no tiene solución

Tome  $x = \begin{bmatrix} -t \\ 0 \end{bmatrix}$  con  $t \rightarrow \infty$



# EJEMPLO 3: FUNCIÓN “BANANA” DE ROSENBROCK

$$\min_{x_1, x_2} (x_2 - x_1^2)^2 + (1 - x_1)^2$$

Busquemos puntos que cumplen la condición necesaria de primer orden:

$$\nabla f(x) = \begin{bmatrix} -4(x_2 - x_1^2)x_1 - 2(1 - x_1) \\ 2(x_2 - x_1^2) \end{bmatrix} = 0$$


Candidato único

$$x' = [1; 1]$$

Revisamos la matriz hessiana:

$$H_f(x) = \begin{bmatrix} -4x_2 + 12x_1^2 + 2 & -4x_1 \\ -4x_1 & 2 \end{bmatrix}$$

$$H_f(x') = \begin{bmatrix} 10 & -4 \\ -4 & 2 \end{bmatrix} \rightarrow \text{definida positiva}$$



# CONDICIONES NECESARIAS Y SUFICIENTES EN PROBLEMAS CONVEXOS


- ❖ Modelo de optimización no lineal irrestricta
- ❖ Condiciones necesarias y suficientes de optimalidad
- ❖ **Condiciones necesarias y suficientes en problemas convexos**

# CONVEXIDAD

Si  $f(x^*)$  es convexa en  $\mathbb{R}^n$ . Se cumple que para todo  $x, x_0 \in \mathbb{R}^n$ :

$$f(x) \geq f(x_0) + \nabla f(x_0)^T (x - x_0)$$

Hiperplano tangente a  $x_0$  pasa por debajo de la función.



# CONVEXIDAD

Si  $f(x^*)$  es convexa en  $\mathbb{R}^n$ . Se cumple que para todo  $x, x_0 \in \mathbb{R}^n$ :

$$f(x) \geq f(x_0) + \nabla f(x_0)^T (x - x_0)$$

## Demostración:

- Sea  $\lambda x + (1 - \lambda)x_0 = x_0 + \lambda(x - x_0)$  una combinación convexa de  $x_0$  y  $x$
- Por convexidad:  $f(x_0 + \lambda(x - x_0)) \leq \lambda f(x) + (1 - \lambda)f(x_0)$
- Reformulando:  $\frac{f(x_0 + \lambda(x - x_0)) - f(x_0)}{\lambda} \leq f(x) - f(x_0)$
- Tomando  $\lim_{\lambda \rightarrow 0^+}$ :  $\frac{f(x_0 + \lambda(x - x_0)) - f(x_0)}{\lambda}$

# CONVEXIDAD

Si  $f(x^*)$  es convexa en  $\mathbb{R}^n$ . Se cumple que para todo  $x, x_0 \in \mathbb{R}^n$ :

$$f(x) \geq f(x_0) + \nabla f(x_0)^T (x - x_0)$$

**Demostración:**

- $\lim_{\lambda \rightarrow 0^+} \frac{f(x_0 + \lambda(x - x_0)) - f(x_0)}{\lambda}$

- Si tomamos  $h = \lambda(x - x_0)$ , cuando  $\lambda \rightarrow 0^+$ ,  $h \rightarrow 0$ . Podemos reescribirlo como:  $\lambda = \frac{h}{(x - x_0)}$

- $\Rightarrow \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h} (x - x_0) = \nabla f(x_0)^T (x - x_0)$

- $\rightarrow \nabla f(x_0)^T (x - x_0) \leq f(x) - f(x_0)$

# CONVEXIDAD Y OPTIMALIDAD GLOBAL

Si  $f(x)$  es convexa en  $\mathbb{R}^n$ :

$x^*$  es mínimo global  $\Leftrightarrow \nabla f(x^*) = 0$

**Demostración:**

■  $(\Rightarrow)$

$x^*$  mínimo global  $\Rightarrow x^*$  mínimo local  $\Rightarrow \nabla f(x^*) = 0$  (condición necesaria)

■  $(\Leftarrow)$

Por convexidad y  $\nabla f(x^*) = 0$  se tiene que  $f(x^*) + \nabla f(x^*)^T(x - x^*) \leq f(x)$ , que colapsa a  $f(x^*) \leq f(x)$  para todo  $x \in \mathbb{R}^n$ . Es decir,  $x^*$  mínimo global

# CONVEXIDAD Y OPTIMALIDAD GLOBAL

Si  $f(x)$  es convexa en  $\mathbb{R}^n$ :


$x^*$  es mínimo global  $\Leftrightarrow \nabla f(x^*) = 0$

## Comentarios:

- Si  $f(x)$  es cóncava:  $x^*$  es máximo global  $\Leftrightarrow \nabla f(x^*) = 0$
- Si  $H_f(x)$  es s.d.p.  $\forall x \in \mathbb{R}^n$ , entonces  $f(x)$  es convexa
- Si  $H_f(x)$  es s.d.n.  $\forall x \in \mathbb{R}^n$ , entonces  $f(x)$  es cóncava

# EJEMPLO 4: REGRESIÓN LINEAL

- Usted posee  $n$  pares de datos  $(x_i, y_i)$ , con  $i = 1, \dots, n$
- Se pide ajustar una función lineal  $a + bx_i$  que minimice error cuadrático medio (ECM) con respecto a  $y_i$
- Supuesto: los datos  $x_i$  están normalizados, es decir  $\frac{1}{n} \sum_i x_i = 0$
- $\min_{a,b} \frac{1}{n} \sum_{i=1}^n (a + bx_i - y_i)^2$



# EJEMPLO 4: REGRESIÓN LINEAL

$$\min_{a,b} \frac{1}{n} \sum_{i=1}^n (a + bx_i - y_i)^2$$

$$\nabla f(a,b) = \left[ \sum_{i=1}^n 2(a + bx_i - y_i); \sum_{i=1}^n 2x_i(a + bx_i - y_i) \right] = 0$$

$$\rightarrow a^* = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}$$

$$\rightarrow b^* = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} = \frac{x^T y}{|x|^2}$$

# EJEMPLO 4: REGRESIÓN LINEAL

$$\min_{a,b} \frac{1}{n} \sum_{i=1}^n (a + bx_i - y_i)^2$$

$$\nabla f(a,b) = \left[ \sum_{i=1}^n 2(a + bx_i - y_i); \sum_{i=1}^n 2x_i(a + bx_i - y_i) \right] = 0$$

$$H_f(a,b) = 2 \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix} = 2 \begin{bmatrix} n & 0 \\ 0 & \sum_{i=1}^n x_i^2 \end{bmatrix}$$

$$H_f(a,b) \text{ d.p. } \forall (a,b) \text{ si } \sum_{i=1}^n x_i^2 > 0$$

$\rightarrow f(a,b)$  es convexa  $\rightarrow (a^*, b^*)$  mínimo global.

# RESUMEN: OPTIMIZACIÓN NO LINEAL IRRESTRICTA

## □ CASO 1:

Si  $f$  es convexa, hacer  $\nabla f(x) = 0$  para buscar mínimo global

## □ CASO 2:

Si  $f$  no es convexa

Debemos:

- Demostrar existencia de solución óptima
- Obtener lista de candidatos a mínimo local (condiciones necesarias de 1er y 2do orden)
- Evaluar candidatos no descartados (al menos uno es mínimo global)

# PROGRAMACIÓN NO LINEAL Estricta

# PROBLEMA UNIDIMENSIONAL ACOTADO

- ❖ **Problema unidimensional acotado**
- ❖ Condiciones de Lagrange (restricciones de igualdad)
- ❖ Condiciones de Karush-Kuhn-Tucker (KKT)

# PROBLEMA UNIDIMENSIONAL ACOTADO

$$\min_{x \in \mathbb{R}: a \leq x \leq b} f(x)$$


Supuesto:  $f \in \mathcal{C}^1$

Con restricciones, es posible que  $f'(x^*) \neq 0$

# PROBLEMA UNIDIMENSIONAL ACOTADO

Condición **necesaria** de **primer orden** para que  $x^*$  sea mínimo local:


1. Si  $a < x^* < b$  (interior), entonces:  $f'(x^*) = 0$
2. Si  $x^* = a$  (borde izquierdo), entonces:  $f'(a) \geq 0$
3. Si  $x^* = b$  (borde derecho), entonces:  $f'(b) \leq 0$



# PROBLEMA UNIDIMENSIONAL ACOTADO

Condición **suficiente** de **primer orden** para que  $x^*$  sea mínimo local:


1. Si  $a < x^* < b$  (interior), entonces: no hay suficiencia de primer orden
2. Si  $x^* = a$  (borde izquierdo), entonces:  $f'(a) > 0$
3. Si  $x^* = b$  (borde derecho), entonces:  $f'(b) < 0$



# PROBLEMA UNIDIMENSIONAL ACOTADO

Condición **necesaria** de **segundo orden** para que  $x^*$  sea mínimo local:


1. Si  $a < x^* < b$  (interior), entonces:  $f'(x^*) = 0, f''(x^*) \geq 0$
2. Si  $x^* = a$  (borde izquierdo), entonces:  $f'(a) > 0$  o  $(f''(a) \geq 0, f'(a) = 0)$
3. Si  $x^* = b$  (borde derecho), entonces:  $f'(b) < 0$  o  $(f''(b) \geq 0, f'(b) = 0)$



# PROBLEMA UNIDIMENSIONAL ACOTADO

Condición **suficiente** de **segundo orden** para que  $x^*$  sea mínimo local:

1. Si  $a < x^* < b$  (interior), entonces:  $f'(x^*) = 0, f''(x^*) > 0$
2. Si  $x^* = a$  (borde izquierdo), entonces:  $f'(a) > 0$  o  $(f''(a) > 0, f'(a) = 0)$
3. Si  $x^* = b$  (borde derecho), entonces:  $f'(b) < 0$  o  $(f''(b) > 0, f'(b) = 0)$



# OPTIMIZACIÓN

## ICS1113 – Sección 3

PROGRAMACIÓN NO LINEAL

CAMILA BALBONTIN

✉ [camila.balbontin@uc.cl](mailto:camila.balbontin@uc.cl)



Departamento de Transporte y Logística



ESCUELA DE INGENIERÍA  
FACULTAD DE INGENIERÍA

Primer Semestre, 2024