

OPTIMIZACIÓN

ICS1113 – Sección 3

PROGRAMACIÓN NO LINEAL

CAMILA BALBONTIN

✉ camila.balbontin@uc.cl



Departamento de Transporte y Logística

Primer Semestre, 2024

Estas clases han sido basadas en el material desarrollado por el Prof. Mathias Klapp, junto con elementos extraídos de los textos bibliográficos y otros apuntes.



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

ENCUESTA DOCENTE EN CANVAS


Plazo: 15 de julio, 2024



Source: <https://www.freepik.com/>

PROGRAMACIÓN NO LINEAL

CONTENIDOS



CONTENIDOS

- **Parte I: Motivación, modelación y conceptos básicos**
 - Introducción
 - Modelos de optimización
 - Conceptos básicos, convexidad, existencia y unicidad de soluciones
 - Modelos equivalentes
- **Parte II: Programación lineal**
 - Introducción
 - Geometría de poliedros
 - Simplex
 - Sensibilidad
 - Dualidad
- **Parte III: Programación lineal entera**
 - Conceptos básicos
 - Algoritmos: Branch & bound (ramificación y acotamiento) y planos cortantes
- **Parte IV: Programación no lineal**
 - Optimización no lineal irrestricta: condiciones de 1er y 2do orden
 - Optimización con restricciones de igualdad y desigualdad, condiciones KKT

PROGRAMACIÓN NO LINEAL Estricta

CONDICIONES DE LAGRANGE (RESTRICCIONES DE IGUALDAD)

- ❖ Problema unidimensional acotado
- ❖ **Condiciones de Lagrange (restricciones de igualdad)**
- ❖ Condiciones de Karush-Kuhn-Tucker (KKT)

CONDICIONES DE LAGRANGE (CN DE 1er ORDEN)

- Sea x^* un punto **factible** y **regular** del problema:

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{s. a.} \quad h_i(x) = b_i, \forall i = 1, \dots, r$$

- Para que x^* sea mínimo local, debe existir $\lambda \in \mathbb{R}^r$ tal que:

$$-\nabla f(x^*) = \sum_{i=1}^r \lambda_i \nabla h_i(x^*)$$

es decir, $-\nabla f(x^*)$ es generado por combinación lineal de gradientes de restricciones $\nabla h_i(x^*)$.

PROBLEMA DE LAGRANGE

- Las condiciones de Lagrange equivalen a hacer CN de 1er orden sobre el siguiente problema irrestricto:

$$\min_{x \in \mathbb{R}^n, \lambda \in \mathbb{R}^r} L(x, \lambda) = f(x) + \sum_{i=1}^r \lambda_i (h_i(x) - b_i)$$

Donde $L(x, \lambda)$ es la **función de Lagrange** o **Lagrangeano**

Veamos:

La condición necesaria del problema irrestricto es $\nabla L(x, \lambda) = 0$ e implica:

- $\frac{dL}{dx_j} = \frac{df}{dx_j} + \sum_{i=1}^r \lambda_i \frac{dh_i}{dx_j} = 0, \quad \forall j = 1, \dots, n$ (Condiciones de Lagrange)
- $\frac{dL}{d\lambda_i} = h_i(x) - b_i = 0, \quad \forall i = 1, \dots, r$ (Factibilidad)

CONDICIONES DE LAGRANGE (CN y CS 2do ORDEN)

- Condiciones de Lagrange (CN-1) no distinguen entre mínimos, máximos y puntos silla

- Condición **necesaria** de 2do orden:

$$d^T H_L(x^*, \lambda^*) d \geq 0, \quad \forall d : d^T \nabla h_i(x) = 0$$

- Si $H_L(x^*, \lambda^*)$ es s.d.p. estas condiciones se cumplen

- Condición **suficiente** de 2do orden:

$$d^T H_L(x^*, \lambda^*) d > 0, \quad \forall d \neq 0 : d^T \nabla h_i(x) = 0$$

CONDICIONES DE KARUSH-KUHN- TUCKER (KKT)

- ❖ Problema unidimensional acotado
- ❖ Condiciones de Lagrange (restricciones de igualdad)
- ❖ **Condiciones de Karush-Kuhn-Tucker (KKT)**

CONDICIONES DE KARUSH-KUHN-TUCKER (KKT)

- Sea x^* un punto **factible** y **regular** del problema:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} & f(x) \\ \text{s.a. } & g_i(x) \leq b_i, \forall i = 1, \dots, m \end{aligned}$$

- Para que x^* sea mínimo local, debe existir $\mu \in \mathbb{R}_+^m$ tal que:

$$\begin{aligned} \sum_{i=1}^m \mu_i \nabla g_i(x^*) &= -\nabla f(x^*) \\ \mu_i (b_i - g_i(x^*)) &= 0, \quad \forall i = 1, \dots, m \end{aligned}$$

CONDICIONES KKT EN LAGRANGEANO

- Las condiciones de KKT son las siguientes condiciones de 1er orden sobre la siguiente función irrestricta:

$$L(x, \mu) = f(x) + \sum_{i=1}^m \mu_i (g_i(x) - b_i)$$

- $\bullet \frac{dL}{dx_j} = \frac{df}{dx_j} + \sum_{i=1}^m \mu_i \frac{dg_i}{dx_j} = 0, \quad \forall j = 1, \dots, n$
- $\bullet \frac{dL}{d\mu_i} \mu_i = (g_i(x) - b_i) \mu_i = 0, \quad \forall i = 1, \dots, m$
- $\bullet \frac{dL}{d\mu_i} = g_i(x) - b_i \leq 0, \quad \forall i = 1, \dots, m$
- $\bullet \mu_i \geq 0, \quad \forall i = 1, \dots, m$

¿Y qué pasa con KKT si ahora las variables son **no-negativas**?

KKT CON VARIABLES NO NEGATIVAS

- Las condiciones KKT del problema:
$$\min_{x \in \mathbb{R}_+^n} f(x)$$
$$\text{s.a. } g_i(x) \leq b_i, \forall i = 1, \dots, m$$
- Podemos sacar el ϕ (cambiar por desigualdades o reemplazando):

$$\bullet \frac{dL}{dx_j} = \frac{df}{dx_j} + \sum_{i=1}^m \mu_i \frac{dg_i}{dx_j} \geq 0, \quad \forall j = 1, \dots, n$$

$$\bullet \frac{dL}{dx_j} x_j = x_j \left(\frac{df}{dx_j} + \sum_{i=1}^m \mu_i \frac{dg_i}{dx_j} \right) = 0, \quad \forall j = 1, \dots, n$$

$$\bullet x_j \geq 0, \quad \forall j = 1, \dots, n$$

$$\bullet g_i(x) \leq b_i, \quad \forall i = 1, \dots, m$$

$$\bullet \mu_i (g_i(x) - b_i) = 0, \quad \forall i = 1, \dots, m$$

$$\bullet \mu_i \geq 0, \quad \forall i = 1, \dots, m$$

KKT Y CONVEXIDAD

Si el problema **es convexo**: entonces un punto regular que cumpla condiciones KKT es mínimo global

Si el problema **no es convexo**: Hay que probar existencia de solución y después evaluar cuál de los candidatos al óptimo minimiza el objetivo. Este será la solución óptima

EJEMPLO 1

- Obtenga condiciones KKT para el siguiente problema:

$$\min_{x \in \mathbb{R}_+^2} (x_1 - 3)^2 + (x_2 - 5)^2$$

s.a. $x_1 + x_2 \leq 6$

Luego, identifique su solución óptima

Hay existencia de solución, pues objetivo es continuo, dominio es compacto y factible



Hasta acá
llegamos el
lunes

EJEMPLO 1

$$\min_{x \in \mathbb{R}_+^2} (x_1 - 3)^2 + (x_2 - 5)^2$$

$$\text{s.a.} \quad x_1 + x_2 \leq 6$$

$$L(x, \mu) = (x_1 - 3)^2 + (x_2 - 5)^2 + \mu(x_1 + x_2 - 6)$$

$$J = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\frac{dL}{dx_1} x_1 = (2(x_1 - 3) + \mu)x_1 = 0$$

$$\frac{dL}{dx_1} = 2(x_1 - 3) + \mu \geq 0$$

$$\frac{dL}{dx_2} x_2 = (2(x_2 - 5) + \mu)x_2 = 0$$

$$\frac{dL}{dx_2} = 2(x_2 - 5) + \mu \geq 0$$


$$\frac{dL}{d\mu} \mu = (x_1 + x_2 - 6)\mu = 0$$

$$\frac{dL}{d\mu} = x_1 + x_2 - 6 \leq 0$$

$$x_1, x_2, \mu \geq 0$$

¿Dónde podría estar la solución óptima?

- **Caso 1:** solución óptima es punto interior (es decir, ninguna restricción está activa)
- **Caso 2:** está en un borde donde la restricción está activa
- **Caso 3:** está en un borde donde la no negatividad de x_1 está activa
- **Caso 4:** no-negatividad x_2 está activa
- **Caso 5-7:** vértices



EJEMPLO 1

$$\min_{x \in \mathbb{R}_+^2} (x_1 - 3)^2 + (x_2 - 5)^2$$

$$s.a. \quad x_1 + x_2 \leq 6$$

Es equivalente a:

$$L(x, \mu) = (x_1 - 3)^2 + (x_2 - 5)^2 + \mu(x_1 + x_2 - 6) + \phi_1(-x_1) + \phi_2(-x_2)$$

$$\frac{dL}{dx_1} = 2(x_1 - 3) + \mu - \phi_1 = 0$$

$$\frac{dL}{d\phi_1} \phi_1 = -x_1 \phi_1 = 0$$

$$\frac{dL}{dx_2} = 2(x_2 - 5) + \mu - \phi_2 = 0$$

$$\frac{dL}{d\phi_1} = -x_1 \leq 0$$

$$\frac{dL}{d\mu} \mu = (x_1 + x_2 - 6) \mu = 0$$

$$\frac{dL}{d\phi_2} \phi_2 = -x_2 \phi_2 = 0$$


$$\frac{dL}{d\mu} = x_1 + x_2 - 6 \leq 0$$

$$\frac{dL}{d\phi_2} = -x_2 \leq 0$$

$$\mu, \phi_1, \phi_2 \geq 0$$

¿Dónde podría estar la solución óptima?

- **Caso 1:** solución óptima es punto interior (es decir, ninguna restricción está activa)
- **Caso 2:** está en un borde donde la restricción está activa
- **Caso 3:** está en un borde donde la no negatividad de x_1 está activa
- **Caso 4:** no-negatividad x_2 está activa
- **Caso 5-7:** vértices



EJEMPLO 1

$$\min_{x \in \mathbb{R}_+^2} (x_1 - 3)^2 + (x_2 - 5)^2$$

$$\text{s.a.} \quad x_1 + x_2 \leq 6$$

Comparemos:

$$L(x, \mu) = (x_1 - 3)^2 + (x_2 - 5)^2 + \mu(x_1 + x_2 - 6)$$

$$\frac{dL}{dx_1} x_1 = (2(x_1 - 3) + \mu)x_1 = 0 \quad (1)$$

$$\frac{dL}{dx_1} = 2(x_1 - 3) + \mu \geq 0 \quad (2)$$

$$\frac{dL}{dx_2} x_2 = (2(x_2 - 5) + \mu)x_2 = 0 \quad (3)$$

$$\frac{dL}{dx_2} = 2(x_2 - 5) + \mu \geq 0 \quad (4)$$

$$\frac{dL}{d\mu} \mu = (x_1 + x_2 - 6)\mu = 0 \quad (5)$$

$$\frac{dL}{d\mu} = x_1 + x_2 - 6 \leq 0 \quad (6)$$

$$x_1, x_2, \mu \geq 0 \quad (7)$$

$$L(x, \mu) = (x_1 - 3)^2 + (x_2 - 5)^2 + \mu(x_1 + x_2 - 6) + \phi_1(-x_1) + \phi_2(-x_2)$$

$$\frac{dL}{dx_1} = 2(x_1 - 3) + \mu - \phi_1 = 0 \quad (2) \quad \frac{dL}{d\phi_1} \phi_1 = -x_1 \phi_1 = 0 \quad (1)$$

$$\frac{dL}{dx_2} = 2(x_2 - 5) + \mu - \phi_2 = 0 \quad (4) \quad \frac{dL}{d\phi_1} = -x_1 \leq 0 \quad (7)$$

$$\frac{dL}{d\mu} \mu = (x_1 + x_2 - 6)\mu = 0 \quad (5) \quad \frac{dL}{d\phi_2} \phi_2 = -x_2 \phi_2 = 0 \quad (3)$$

$$\frac{dL}{d\mu} = x_1 + x_2 - 6 \leq 0 \quad (6) \quad \frac{dL}{d\phi_2} = -x_2 \leq 0 \quad (7)$$

$$\mu, \phi_1, \phi_2 \geq 0 \quad (7)$$

EJEMPLO 1

$$\min_{x \in \mathbb{R}_+^2} (x_1 - 3)^2 + (x_2 - 5)^2$$

$$\text{s.a.} \quad x_1 + x_2 \leq 6$$

$$L(x, \mu) = (x_1 - 3)^2 + (x_2 - 5)^2 + \mu(x_1 + x_2 - 6)$$

$$\frac{dL}{dx_1} x_1 = (2(x_1 - 3) + \mu)x_1 = 0$$

$$\frac{dL}{dx_1} = 2(x_1 - 3) + \mu \geq 0$$

$$\frac{dL}{dx_2} x_2 = (2(x_2 - 5) + \mu)x_2 = 0$$

$$\frac{dL}{dx_2} = 2(x_2 - 5) + \mu \geq 0$$

$$\frac{dL}{d\mu} \mu = (x_1 + x_2 - 6)\mu = 0$$

$$\frac{dL}{d\mu} \mu = x_1 + x_2 - 6 \leq 0$$

$$x_1, x_2, \mu \geq 0$$

- **Caso 1:** solución óptima es punto interior
(es decir, ninguna restricción está activa)
 $x_1 > 0, x_2 > 0, x_1 + x_2 - 6 < 0$

$$2(x_1 - 3) + \mu = 0$$

$$2(x_2 - 5) + \mu = 0$$

$$\mu = 0$$

$$\Rightarrow x_1 = 3, x_2 = 5$$

Es un punto infactible: $\frac{dL}{dx_1} = 0 \geq 0$

$$\frac{dL}{dx_2} = 0 \geq 0$$

$$\frac{dL}{d\mu} \mu = 2 \leq 0$$

EJEMPLO 1

$$\min_{x \in \mathbb{R}_+^2} (x_1 - 3)^2 + (x_2 - 5)^2$$

$$\text{s.a.} \quad x_1 + x_2 \leq 6$$

$$L(x, \mu) = (x_1 - 3)^2 + (x_2 - 5)^2 + \mu(x_1 + x_2 - 6)$$

$$\frac{dL}{dx_1} x_1 = (2(x_1 - 3) + \mu)x_1 = 0$$

$$\frac{dL}{dx_1} = 2(x_1 - 3) + \mu \geq 0$$

$$\frac{dL}{dx_2} x_2 = (2(x_2 - 5) + \mu)x_2 = 0$$

$$\frac{dL}{dx_2} = 2(x_2 - 5) + \mu \geq 0$$

$$\frac{dL}{d\mu} \mu = (x_1 + x_2 - 6)\mu = 0$$

$$\frac{dL}{d\mu} \mu = x_1 + x_2 - 6 \leq 0$$

$$x_1, x_2, \mu \geq 0$$

- **Caso 2:** está en un borde donde solamente está la restricción activa

$$x_1 > 0, x_2 > 0, x_1 + x_2 - 6 = 0$$

$$x_1 + x_2 - 6 = 0$$

$$2(x_1 - 3) + \mu = 0$$

$$2(x_2 - 5) + \mu = 0$$

$$\Rightarrow \mu = 2, x_1 = 2, x_2 = 4$$

$$\text{Es factible: } \frac{dL}{dx_1} = 0 \geq 0$$

$$\frac{dL}{dx_2} = 0 \geq 0$$


$$\frac{dL}{d\mu} \mu = 0 \leq 0$$

EJEMPLO 1

$$\min_{x \in \mathbb{R}_+^2} (x_1 - 3)^2 + (x_2 - 5)^2$$

$$s.a. \quad x_1 + x_2 \leq 6$$

$$L(x, \mu) = (x_1 - 3)^2 + (x_2 - 5)^2 + \mu(x_1 + x_2 - 6)$$



EJEMPLO 2

$$\min_{x \in \mathbb{R}^2} x_1^2 + x_2^2$$

$$s.a. \ x_1^2 + 2x_1 + x_2^2 \leq 3$$

$$x_1 \geq -3$$

$$x_2 \geq 0$$

Hay existencia, pues objetivo es continuo, dominio es compacto y factible (revisar)

EJEMPLO 2

$$\min_{x \in \mathbb{R}^2} x_1^2 + x_2^2$$

$$s.a. \ x_1^2 + 2x_1 + x_2^2 \leq 3$$

$$x_1 \geq -3$$

$$x_2 \geq 0$$

$$L = x_1^2 + x_2^2 + \mu_1(x_1^2 + 2x_1 + x_2^2 - 3) + \mu_2(-x_1 - 3)$$

$$J = \begin{bmatrix} 2x_1 + 2 & 2x_2 \\ -1 & 0 \end{bmatrix}$$

En este caso, hay puntos singulares cuando ambas restricciones están activas y $x_2 = 0$. Es el caso en $[-3; 0]$

EJEMPLO 2

Gráficamente:

$$\min_{x \in \mathbb{R}^2} x_1^2 + x_2^2$$


$$\text{s.a. } x_1^2 + 2x_1 + x_2^2 \leq 3$$

$$x_1 \geq -3$$

$$x_2 \geq 0$$

El mínimo global entre estos:

- $f(-3,0) = 9$
- $f(0,0) = 0$ (óptimo)



Punto
singular

Punto
KKT

KKT Y PROBLEMAS LINEALES

¿Condiciones KKT en problema $\min_{x \geq 0} \{c^T x : Ax \leq b\}$?

$$L = c^T x + \mu^T (Ax - b)$$

Las condiciones colapsan a:

$$\frac{dL}{dx_j} = c_j + \mu^T A^j \geq 0, \quad \forall j = 1, \dots, n$$

$$\frac{dL}{dx_j} x_j = x_j (c_j + \mu^T A^j) = 0, \quad \forall j = 1, \dots, n$$

$$x_j \geq 0, \quad \forall j = 1, \dots, n$$

$$\frac{dL}{d\mu_i} = b_i - a_i^T x \geq 0, \quad \forall i = 1, \dots, m$$

$$\frac{dL}{d\mu_i} \mu_i = \mu_i (b_i - a_i^T x) = 0, \quad \forall i = 1, \dots, m$$

$$\mu_i \geq 0, \quad \forall i = 1, \dots, m$$

KKT colapsa a condiciones de factibilidad y optimalidad lineales:

- Factibilidad primal (3 y 4)
- Factibilidad dual (1 y 6)
- Complementariedad de holgura dual y primal (2 y 5)

EJERCICIO PROPUESTO

$$\min_{x \in \mathbb{R}^2} (x_1 - 2)^2 + (x_1 - 1)^2$$

$$s.a. \quad x_1^2 - x_2 \leq 0$$

$$x_1 + x_2 \geq 2$$

$$x_1 \geq 0$$

ALGORITMOS NUMÉRICOS DE SOLUCIÓN NO LINEAL IRRESTRICTO

ALGORITMOS NUMÉRICOS DE SOLUCIÓN

- Los algoritmos para minimización sin restricciones necesitan de un punto inicial que se denotará por x_0
- Comenzando en x_0 , los algoritmos de optimización generan iteraciones que terminan cuando el algoritmo no puede progresar más o se cumplan ciertas condiciones de término
- Algunos algoritmos:
 - Método de Newton
 - Método del gradiente o de Cauchy

MÉTODO DE NEWTON

- Este método funciona para funciones dos veces diferenciables
- Se puede usar para múltiples variables, pero lo presentaré para una variable solamente
- La idea básica detrás del método de Newton es aproximar $f(x)$ a la vecindad de la solución de prueba inicial mediante una función cuadrática y maximizar/minimizar la función aproximada exactamente para obtener la nueva solución de prueba y así iniciar la siguiente iteración
- La función cuadrática de aproximación se obtiene al truncar la serie de Taylor después del término de la 2da derivada

MÉTODO DE NEWTON

$$q(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2$$

La condición de primer orden será:


$$\frac{dq}{dx} = f'(x_k) + f''(x_k)(x - x_k) = 0$$

de donde despejando nos queda la siguiente relación:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}.$$

Este método iterativo se aproximará a un óptimo local. Sin embargo, podría tardar infinitas iteraciones en alcanzarlo. Por eso, se puede definir un criterio de parada. Por ejemplo:

parar si $(x_k - x_{k+1}) \rightarrow 0$, o si $(f(x_k) - f(x_{k+1})) \rightarrow 0$



Fuente: Ferrer, J.C., Muñoz, J.C. (2006) Apuntes Optimización

MÉTODO DE GRADIENTE O DE CAUCHY

Este algoritmo también se utiliza para resolver problemas de optimización multidimensionales sin restricciones. Se basa en:

1. Tomar un punto conocido $\vec{x}_k$
2. Escoger una dirección de movimiento al gradiente de la función objetivo en dicho punto, pero con signo contrario
3. Determinar el mínimo relativo de $f(\vec{x})$ en esta dirección


De esta forma $\vec{x}_{k+1} = \vec{x}_k - \alpha \nabla f(\vec{x}_k)$. El siguiente paso consiste en encontrar el α que minimiza $f(\vec{x}_{k+1})$, es decir,

$$\min_{\alpha \geq 0} f(\vec{x}_k - \alpha \nabla f(\vec{x}_k)),$$

Esto lo reduce a un problema unidimensional (α) que puede ser resuelto algebraicamente o con el método de Newton.


REPASO B&B POR MÚLTIPLES PREGUNTAS

BRANCH AND BOUND



- ¿Cómo vemos si es de maximización o minimización?
- ¿Cuál es el óptimo?
- ¿Cómo actualizamos la cota inferior/superior?
- ¿Por qué podemos cada una de las ramas?

BRANCH AND BOUND



- ¿Cómo vemos si es de maximización o minimización?

$$\max_x z = 2x_1 + x_2 + 2x_3$$

$$s.a. \quad x_1 + 2x_2 + x_3 \leq 3$$

$$2x_1 + 2x_2 + 2x_3 \leq 3$$

$$x_1 + 2x_2 + 2x_3 \leq 4$$


$$x_1, x_2, x_3 \in \{0, 1\}$$

- ¿Cuál es el óptimo?

$$(x_1; x_2; x_3)^* = (0; 0; 1) \text{ and } (1; 0; 0)$$

$$Z^* = 2$$


BRANCH AND BOUND



- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.


BRANCH AND BOUND



- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.


BRANCH AND BOUND



- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.


BRANCH AND BOUND



- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.

BRANCH AND BOUND




$$v_{HB} = \max(v_{P2}^R, v_{P4}^R, v_{P5}^R) = 2.5$$

- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.

BRANCH AND BOUND




$$v_{HB} = \max(v_{P2}^R, v_{P4}^R, v_{P5}^R) = 2.5$$

- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.

BRANCH AND BOUND




- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.

$$v_{HB} = \max(v_{P2}^R, v_{P6}^R, v_{P7}^R, v_{P5}^R) = 2.5$$

BRANCH AND BOUND




- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.

$$v_{HB} = \max(v_{P2}^R, v_{P6}^R, v_{P7}^R, v_{P5}^R) = 2.5$$

BRANCH AND BOUND




- ¿Cómo actualizamos la cota inferior/superior?

Para empezar, como es un problema de maximización tenemos cotas superiores, que es definida como la **menor cota superior demostrable** del valor óptimo. Empieza como la del problema original relajado, P1.

$$v_{HB} = \max(v_{P8}^R, v_{P9}^R, v_{P6}^R, v_{P7}^R) = 2$$

BRANCH AND BOUND



- ¿Por qué podemos cada una de las ramas?

P8: Solución entera

P9: Valor óptimo del problema relajado
no es mejor que el incumbente

P6: Solución entera

P7: Infactible

P5: Infactible

TODO LO QUE APRENDIMOS

- **Parte I: Motivación, modelación y conceptos básicos**
 - Introducción
 - Modelos de optimización
 - Conceptos básicos, convexidad, existencia y unicidad de soluciones
 - Modelos equivalentes
- **Parte II: Programación lineal**
 - Introducción
 - Geometría de poliedros
 - Simplex
 - Sensibilidad
 - Dualidad
- **Parte III: Programación lineal entera**
 - Conceptos básicos
 - Algoritmos: Branch & bound (ramificación y acotamiento) y planos cortantes
- **Parte IV: Programación no lineal**
 - Optimización no lineal irrestricta: condiciones de 1er y 2do orden
 - Optimización con restricciones de igualdad y desigualdad, condiciones KKT

ICS1113 es solo un punto de partida:

- **Métodos de optimización** (ICS2121): Métodos y algoritmos para optimización lineal, no lineal y entera desafiantes.
- **Flujo en Redes** (ICT2233): Modelación y solución de problemas con inherente estructura de red.
- **Programación Entera** (ICS3143): Teoría y solución de problemas lineales enteros y mixtos.
- **Optimización Dinámica** (ICS3105): Decisiones secuenciales en el tiempo en ambientes con dinamismo de información.
- **Optimización bajo incertidumbre** (ICS3151): Optimización con incertidumbre en sus parámetros.
- **Optimización avanzada** (IMT3830): Teoría, geometría y algoritmos para optimización convexa.
- **Ruteo de Vehículos** (ICT3464): Optimización de rutas y operación logística de distribución.

OPTIMIZACIÓN

ICS1113 – Sección 3

PROGRAMACIÓN NO LINEAL

CAMILA BALBONTIN



camila.balbontin@uc.cl



Departamento de Transporte y Logística



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Primer Semestre, 2024