



Observaciones de lo dicho en cátedra EYP1113

Tips I1

- El $A \cap S = A$, se puede ocupar para reescribir A en función de una partición. Lo vamos a utilizar para trucazos. Sirve para demostrar varias igualdades.
- Una unión no es una suma. Aplica lo mismo para la intersección y multiplicación.
- Si dejas $P(E) < 0$ ó $P(E) > 1$, decir que está malo para que no descuenten puntaje.
- Si utilizamos probabilidad clásica, no olvidar anotar $P(A) = \frac{\#A}{\#S}$.
- Los conjuntos independientes de a pares, no necesariamente son independientes de a tres o más.
- Hay que saber definir bien los eventos.
- No olvidar que en las ramas de los árboles, las probabilidades deben sumar 1.
- En las combinatorias, los números de arriba deben sumar n y los de abajo k . Ejemplo:

$$P(A) = \frac{\binom{9}{0}\binom{6}{3}}{\binom{15}{3}}$$
$$9 + 6 = 15, 0 + 3 = 3$$

- Fijarse bien en las relaciones de dependencia, que depende de cada cosa.
- Es importante visualizar el árbol e imaginar apropiadamente el fenómeno.
- Cuando uno calcula $\#S$, no hay que considerar ninguna restricción/condición.
- Me parece que cuando hay temas de probabilidades condicionales y relaciones de dependencias, primero es mejor partir definiendo los eventos y luego dibujar el árbol, para así tener claridad que es lo que va primero, en caso de que no sea muy claro.
- Cuando pensamos en las particiones artificiales y el principio de multiplicación (experimentos). Pensar en que cuando particionamos grupos, tenemos distintos experimentos independientes y por eso, por ejemplo, multiplicamos combinatorias. Ejemplo: cuando tenemos personas, de ellas hay gente con covid y sin covid. Con eso ya hay una partición artificial de nuestro grupo y por eso, se explica, por ejemplo porque se multiplican las combinatorias (principio de multiplicación con distintos experimentos).
- No olvidar que $A = A \cap S = A \cap (\cup_{i=1}^n E_i)$. Esto nos sirve para hacer aparecer probabilidades
- Probabilidades condicionales: multiplicación de eventos $\rightarrow$ árbol de eventos.

- Si tenemos $P(A \cap B \cap C)$ y nos piden $P(A \cap C)$, lo podemos hacer aparecer como:

$$= P(A \cap C \cap \Omega) \\ = P(A \cap C \cap (B \cup \bar{B}))$$

y de ahí es cosa de seguir desarrollando.

- No olvidar que para función de probabilidad puntual se debe cumplir

$$p_x(x) > 0 \\ \sum_{x \in \Theta_x} p_x(x) = 1$$

y que para la función de densidad se debe cumplir

$$f_x(x) \geq 0 \\ \int_{x \in \Theta_x} f_x(x) dx = 1$$

- Importante la relación de la n -ésima derivada de la función generadora de momentos con el n -ésimo momento central

$$M_x^{(n)}(0) = E(X^n)$$

- Recomendable hacer las definiciones antes que hacer el árbol.
- Escribir lo que nos piden de forma algebraica (con los eventos definidos, dan puntaje). Como por ejemplo, reescribir lo que nos piden usando el teorema de probabilidades totales o Bayes, cuando se pueda.
- Un skewness negativo, indica que los valores están más concentrados hacia la derecha.
- Para determinar valores de percentiles, usamos la función acumulada.
- Una potente relación es $P(A \cap \bar{B}) = P(A) - P(A \cap B)$

Tips I2

Distribuciones

Comentarios sobre distribución Normal

- En el curso se usará la notación $X \sim N(\mu, \sigma)$, pero igual hay que tener ojo en lo que dicen el enunciado. En libros antiguos aparece $X \sim N(\mu, \sigma^2)$.
- Es **muy importante**, la distribución normal estándar y su relación con otras distribuciones.
- Cuando tenemos $X \sim N(0, 1)$, se tiene que

$$P(X \leq x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$

- Se define a

$$\Phi(s) = F_s(s) = \int_{-\infty}^s \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx \\ \Phi(s_p) = \int_{-\infty}^{s_p} f_X(x) dx = p$$

la cual es una distribución simétrica, está tabulada para $-3 < s < 3$. Es simétrica en torno a 0. Propiedades **importantes** son:

$$S_p = \Phi^{-1}(p) = -\Phi^{-1}(1-p) \quad \Phi(-s) = 1 - \Phi(s)$$

- Notar que de la distribución normal, se puede pasar a la distribución normal estándar con el cambio de variable $s = \frac{x-\mu}{\sigma}$, por lo que la integral queda de la forma

$$F_X(x) = \int_{-\infty}^{\frac{x-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} e^{-s^2/2} ds = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

- La tabla normal estándar contiene $\Phi(S_p) = p$
- Es importante saber como determinar μ y σ_x de las palabras que nos dan. Hay que intentar ser lo más formal posible y no poner valores a diestra y siniestra.
- **Revisar el ejercicio 6 del Capítulo 3, típica pregunta de prueba.**
- En el caso continuo da lo mismo si es $< o \leq$, no así para el caso discreto.

Comentarios sobre distribución Log-Normal

- **Propiedad:** $\ln X \sim \text{Normal}(\lambda, \zeta)$
- Para la distribución Log-Normal, es importante tener un sistema de ecuaciones para sacar λ y ζ a partir de μ y σ .
- Para la distribución Log-Normal, es decir, si tenemos que $X \sim \text{Log-Normal}(\lambda, \zeta)$ es **muy importante saber**

$$\mu_X = e^{(\lambda + \zeta^2/2)} \quad \sigma_x^2 = \mu_X^2 (e^{\zeta^2} - 1) \quad \zeta = \sqrt{\ln(1 + \delta_X^2)}$$

Es importante saber hacer bien el despeje, es **importante memorizar las relaciones anteriores**

- Notar que si tenemos que $X \sim \text{Log-Normal}(\lambda, \zeta)$, tenemos que la función acumulada es

$$P(X \leq x) = \int_0^x \frac{1}{\sqrt{2\pi}} \frac{1}{(\zeta y)} e^{-\frac{1}{2} \left(\frac{\ln(y) - \lambda}{\zeta} \right)^2} dy$$

con el cambio de variable $s = \frac{\ln(y) - \lambda}{\zeta}$ obtendremos que

$$P(X \leq x) = \Phi\left(\frac{\ln(x) - \lambda}{\zeta}\right)$$

- Tener ojo con los trucos algebraicos, son siempre los mismos.
- Cada vez que el c.o.v $< 30\%$, puedo decir que $\zeta = \delta$.

Comentarios sobre Distribución Binomial y Bernoulli

- $X \sim \text{Ber}(p)$, $P(X=x) = (1-p)^{1-x} p^x$
- $x = \begin{cases} 1 & \text{con prob } p \rightarrow \text{éxito} \\ 0 & \text{con prob } 1-p \rightarrow \text{fracaso} \end{cases}$
- Una sucesión De Bernoulli:

1. Tiene dos resultados posibles.
 2. $p = P(\text{éxito})$
 3. Existe independencia
- Dada una secuencia Bernoulli, si X es el número de ocurrencias del evento éxito entre los n experimentos, con probabilidad de ocurrencia igual a p , entonces la probabilidad que ocurran **exactamente x éxitos en los n experimentos** está representado por la **Binomial**:

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x}$$

la combinatoria corresponde a la elección de las x celdas para los éxitos. x es el número de éxitos en los n experimentos.

- Se dice que $X \sim \text{bin}(n, p)$, $n \in \mathbb{N}$, $p \in (0,1)$
- Una típica pregunta es conocer p .

Comentarios sobre Distribución Geométrica

- Dada una secuencia Bernoulli, el número de experimentos hasta la ocurrencia del primer evento exitoso sigue una distribución geométrica.
- Si el primer éxito ocurre en el n -ésimo experimento, los primeros $n-1$ fueron fracasos. Si N es la variable aleatoria que representa el número de experimentos hasta el primer éxito, entonces

$$P(N = n) = p(1-p)^{n-1}$$

- **Comentario para mi:** Creo que puedo interpretar el $P(N=n)$, como, cual es la probabilidad de que tenga éxito en el experimento n . Si N = num de años hasta observar la 1era ola. $N = n$, sería como estando en el año n , cual es la probabilidad de que ahí registre mi primera ola.
- **Es muy importante notar que N = número de "eventos Bernoulli" HASTA encontrar el primer éxito.** En R la variable aleatoria geométrica se define como X = número de eventos Bernoulli **ANTES** del primer éxito.
- En algunos problemas, el tiempo T es discretizado en intervalos, $T = N$, y puede ser modelado por secuencia Bernoulli. El número de intervalos ocurridos hasta observar el primer evento exitoso se denomina tiempo de recurrencia y corresponde al tiempo entre recurrencias. Este tiempo se conoce como período de retorno (esperanza matemática).

$$\bar{T} = E(T) = \sum_{t=1}^{\infty} t p (1-p)^{t-1} = \frac{1}{p}$$

- Otra forma de interpretar esta distribución es: ¿Cuál es la probabilidad de que tenga que esperar hasta el evento/experimento n -ésimo para que ocurra el primer éxito.


Comentarios sobre Distribución Binomial Negativa

- La distribución geométrica permite modelar el número de experimentos hasta la **primera ocurrencia**. El número de experimentos hasta la **k -ésima ocurrencia** de un éxito es modelada por la distribución binomial negativa.

$$P(T_k = x) = \binom{x-1}{k-1} p^k (1-p)^{x-k}$$

donde el factor de combinatoria, corresponde a donde poner los éxitos. Se interpreta como: cual es la probabilidad de que la k -ésima ocurrencia tenga lugar en el x -ésimo experimento. Ejemplo: La segunda ocurrencia en el octavo lugar.

- Del enunciado tendremos que deducir si es binomial, geométrica o binomial negativa. Solo nos dirán explícitamente si es Poisson. La pregunta va a indicar el tipo de distribución a utilizar (implícito)



Comentarios sobre Distribución de Poisson

- Interés en los eventos en cualquier punto en el tiempo y/o espacio.
- Ojo con la tasa de las cosas que me preguntan.
- Supuestos de un proceso de Poisson:
 - Un evento puede ocurrir al azar y en cualquier instante de tiempo o en cualquier punto en el espacio.
 - La ocurrencia(s) de un evento en un intervalo de tiempo dado (o espacio) es estadísticamente a lo que ocurra en otros intervalos (o espacios) que no se solapen.
 - La probabilidad de ocurrencia de un evento en un pequeño intervalo Δt es proporcional a Δt , y puede estar dada por $\nu \Delta t$, donde ν es la tasa de incidencia media del evento.
 - La probabilidad de dos o más eventos en Δt es insignificante.

Bajo estos supuestos, el número de eventos estadísticamente independientes en t (tiempo o espacio), está regido por la función de probabilidad del modelo Poisson, donde la variable aleatoria X_t : número de eventos en el intervalo de tiempo $(0, t)$ (una recomendación es usar $t = 1$)

$$P(X_t = x) = \frac{(\nu t)^x e^{-\nu t}}{x!} = \frac{\lambda^x e^{-\lambda}}{x!}$$

donde ν es la tasa de ocurrencia media por unidad de tiempo y λ su esperanza en $(0, t)$

- Revisar ejercicio de emergencias apuntes del profe
- **Relación Exponencial con Poisson:** En un proceso de Poisson el tiempo transcurrido entre la ocurrencia de eventos puede ser descrito por una distribución exponencial. Todos los tiempos entre eventos $Poisson(vt)$ distribuyen $Exponencial(v)$ (intentar sacar esto por mi cuenta)
- Esta distribución al igual que la geométrica tiene carencia de memoria. Lo importante es cuanto tiempo me falta, no cuanto ha transcurrido. La historia no importa.
- Ojo por ejemplo cuando nos preguntan, por ejemplo, sobre que la cantidad de sismos en un intervalo de tiempo distribuye Poisson y si nos dicen que acabamos de observar el tercer sismo, ¿Cuánto tiempo tendremos que esperar hasta el quinto sismo?. Ahí nuestra gamma tiene que considerar 2 eventos, el cuarto sismo y el quinto. Es lo mismo calcular del tercer a quinto sismo, que del sismo 0 al segundo. Hay que tener mucho ojo con el lenguaje y como lo preguntan, ya que ahí podría cambiar la cantidad de eventos a considerar.
- Ojo cuando por ejemplo nos dan la tasa de un cierto fenómeno que tiene ciertas condiciones. Por ejemplo, es distinto decir la cantidad de olas en un intervalo de tiempo, a la cantidad de olas sobre 3 metros en un intervalo de tiempo. Si la cantidad de olas distribuye $Poisson(vt)$ y la probabilidad de que las olas sean mayores o iguales a 3 metros es p, entonces la cantidad de olas sobre 3 metros distribuye $Poisson(vpt)$, en el fondo hay que incluir la probabilidad de que ocurra un cierto evento.

Comentarios sobre Distribución Exponencial


- La traslación de una distribución exponencial se da cuando se interrumpen los eventos. Ej: Frente a un accidente, la carretera se cierra a minutos.
- Cuando existe una traslación, se desplazan los parámetros de posición. No así la varianza, kurtosis y coeficiente de asimetría.

Comentarios sobre Distribución Gamma

- Sirve para tiempos, resistencia, duraciones. Bastante utilizada en demografía.
- La notación es $X \sim Gamma(k, v)$. Donde k y v son parámetros pertenecientes a los reales positivos.
- La función gamma permite ver el tiempo entre eventos
- **Relación Gamma con Poisson:** En un proceso de Poisson el **tiempo transcurrido hasta la ocurrencia del k-ésimo evento** puede ser descrito por una distribución Gamma. Si T_k representa al tiempo transcurrido hasta la ocurrencia del k-ésimo evento en un proceso de Poisson, el evento $T_k > t$ implica que en el intervalo (0, t) ocurren a lo más k-1 eventos, es decir

$$P(T_k > t) = P(X_t \leq k - 1) = \sum_{x=0}^{k-1} \frac{(vt)^x e^{-vt}}{x!}$$

- Para el tiempo **entre** k eventos, se consideran k-1.



Comentarios sobre Distribución Hipergeométrica

- Para estos casos se considera una población finita dividida en dos grupos, los defectuosos y no defectuosos.
- Se dice que $X \sim \text{Hipergeométrica}(n, N, m)$, donde n es la cantidad a elegir, N es el total y m son los defectuosos. Si N y $m \gg n$, entonces se puede aproximar X como una binomial, tal que $X \sim \text{Bin}(n, p = \frac{m}{N})$
- A medida que voy sacando elementos de mi conjunto muestral, va cambiando la probabilidad, por eso, por ejemplo en la pregunta 2, inciso c) de la I2 2013-02 no podría ser una binomial. Tener bien en claro los supuestos de sucesión de Bernoulli para no confundir con hipergeométrica (nota para mí).

Comentarios sobre Distribución Beta

- Modela bien las probabilidades. Los parámetros q y r definen la forma.

Comentarios sobre Distribución Weibull

- Se usa mucho en modelos eólicos.
- Los parámetros η y β se pueden calcular con los percentiles.

Comentarios sobre Distribución t-Student

- Sirve para inferencia con datos pequeños
- Si $\nu \rightarrow \infty$ se acerca a la normal.

Comentarios sobre Distribución Fisher

- Sirve para diseños experimentales.

Otros

- Mucho ojo cuando en distribuciones nos preguntan sobre el x % **mayor o menor** de una variable aleatoria. Cambia totalmente la desigualdad. Ejemplo: Cantidad de salmones macho que pertenecen al 20% de mayor peso. Si X es el peso, sería $P(X > 20)$. Si fuese menor peso sería $P(X < 20)$.

Múltiples variables aleatorias

- Es **muy importante** fijarse en el soporte de las variables aleatorias.
- Para el evento $(X=x, Y=y)$ la coma se entiende como una intersección.
- Entender bien las distribuciones marginales.
- $(x, y) = \begin{cases} p(x, y) \rightarrow \text{discreto} \\ f(x, y) \rightarrow \text{continuo} \end{cases}$
- Es **muy importante** el orden de integración.
 - Dominio de tipo 1 (líneas verticales): $dydx$
 - Dominio de tipo 2 (líneas horizontales): $dx dy$
- Se recomienda dibujar el soporte de las variables aleatorias.
- En el caso mixto (que alguna variable sea discreta y la otra continua), el cálculo de las probabilidades marginales es aplicando el teorema de probabilidades totales (no existe representación exacta, a integrar pibe).
- En el **caso independiente**, se tiene:

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y) \qquad f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$$

- Lo siguiente es **muy importante, siempre se pregunta en las I2**. Si tenemos que $X \sim \text{Poisson}(v)$ y que $Y|X = x \sim \text{bin}(x, p)$, entonces se tiene que

$$p_Y(y) = \frac{e^{-vp}(vp)^y}{y!}$$

En resumen, si $X \sim \text{Poisson}(v)$ y $Y|X = x \sim \text{bin}(x, p)$, entonces $Y \sim \text{Poisson}(vp)$

- Cuando tengo un vector normal, entonces sus marginales son normales.
- En las integrales y todo eso, siempre hay que tratar de reconocer algo ya conocido.
- **No confundir** c.o.v con correlación y covarianza (cov).
- No olvidar

$$\mathbb{E}(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_{X,Y}(x, y) \, dx dy$$

- No olvidar también que cuando tengo una integral de 0 a infinito y por ahí tengo metido un e^{-algo} ver si lo puedo transformar a la función Gamma.
- El **teorema de la esperanza iterada** es **god** y el pedazo de herramienta para cuando no se sabe como distribuye Y, es imposible sacarla o muy latero, pero si se tiene la probabilidad condicional.

- Un paso **crucial** en muchos desarrollos es el siguiente:

$$\begin{aligned}\mathbb{E}(XY) &= \mathbb{E}(\mathbb{E}(XY|X)) \\ &= \mathbb{E}(X \cdot \mathbb{E}(Y|X))\end{aligned}$$

esto lo podemos hacer ya que nuestra probabilidad está condicionada a X , es decir, **ya sabemos de antemano su valor, deja de ser una variable aleatoria y pasa a ser algo conocido**, es un **trucazo god**. Mencionar que lo podemos condicionar a cualquier cosa (algo que me sirva). El profe dijo que siempre se pregunta algo relacionado a esperanza iterada.

- Observaciones:

$$\mathbb{E}(KX) = K\mathbb{E}(X)$$

$$Var(KX) = K^2 Var(X)$$

- Es muy importante saber la probabilidad condicional de una variable aleatoria que junto a otra distribuyen normal-bivariada, puede que lo pregunten (fórmula está en el formulario).
- No olvidar poner el soporte de las funciones de probabilidad.
- Leer muy bien, cuando la probabilidad de algo está condicionado a otro experimento, ya sea de forma explícita o implícita. Ej: es distinto el número de errores, a el número de errores en un cierto intervalo.
- No olvidar poner el soporte de las funciones de probabilidad.
- **Leer muy bien.** Cuando la probabilidad de algo está condicionado a otro experimento. Ej: es distinto el número de errores, a el número de errores **en** un cierto intervalo.
- Cuando me piden c.o.v y tengo la probabilidad condicionada, aplicar esperanza iterada y lo mismo para obtener la desviación estándar.
- Ojo cuando nos dicen: la v.a X en/cuando está en momento/instante Y . Y de ahí nos dan la distribución de $Y \rightarrow$ probabilidad condicional de X respecto a Y .
- Importante revisar bien el soporte cuando nos piden obtener una constante.
- Fijarse bien en el soporte de la acumulada.
- Recordar que el mejor predictor está dado por $\mathbb{E}(Y|X)$, en el caso de una normal bivariada es $\mathbb{E}(Y|X) = \left(\mu_y - \mu_x \frac{\rho\sigma_y}{\sigma_x}\right) + X \frac{\rho\sigma_y}{\sigma_x}$, que vendría simplemente a ser una expresión desarrollada de la media de $Y|X = x$ (no es necesario saberla de memoria, se puede extraer del formulario).
- Si x, y son independientes $\rightarrow Cov(X, Y) = 0$. Si $Cov(X, Y) = 0$ no implica que x e y sean independientes.
- El tiempo entre k eventos $\rightarrow Gamma(k-1, \nu)$. Si es a partir de un cierto instante, si se consideran los k eventos.
- Cuando tengamos duda si es probabilidad condicional, pensar si el valor de la variable **depende de** donde estemos/cuando/en que instante/de cuantos.

I3

- No olvidar que $\mathbb{E}(a + bX) = a + b\mathbb{E}(X)$ y que $V(a + bX) = b^2V(X)$

Si tenemos

$$Y = g(X) \rightarrow g^{-1}(Y) = X$$

$$P(X = x) = p_X(x) \rightarrow P(X = g^{-1}(y)) = p_X(g^{-1}(y)) = p_Y(y)$$

Para la fórmula

$$f_Y(y) = f_X[g^{-1}(y)] \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

da lo mismo si la función es creciente o decreciente. Con esto podemos determinar la función de Y a partir de X.

- Lo único que hay que saber es calcular $g^{-1}(y)$ y su(s) derivada(s).
- Observación: Cuando $X \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2})$ se llama χ^2 .
- El profe pone harto énfasis en la **independencia** entre variables aleatorias.
- Si $X_i \sim \text{Poisson}(\lambda_i), \forall i = 1, \dots, n$ son variables independientes, entonces $Y = \sum_{i=1}^n X_i \sim \text{Poisson}\left(\sum_{i=1}^n \lambda_i\right)$.

Este es un resultado **importante**.

- Sean $X_1, \dots, X_n$ iid¹ $\text{Exp}(v) \rightarrow \sum_{i=1}^n X_i \sim \text{Gamma}(n, v)$.
- Generalización: Sea $X_i \sim \text{Gamma}(k_i, v)$ variables independientes $\rightarrow \sum_{i=1}^n X_i \sim \text{Gamma}\left(\sum_{i=1}^n k_i, v\right)$.

Observación: $\text{c} \cdot \sum_{i=1}^m X_i \sim \text{Gamma}\left(\sum_{i=1}^n k_i, \frac{v}{\text{c}}\right)$

- Si tenemos $X \sim \text{Gamma}(k, v) \rightarrow aX \sim \text{Gamma}(k, \frac{v}{a})$.
- Si tenemos $X \sim \text{Normal}(0, 1) \rightarrow X^2 \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2})$
- Si dos variables son independientes, cualquier transformación entre ellas, también es independiente.
- El ejercicio de variables aleatorias log-normales independientes es un clásico, verlo bien.
- Lo primero y más importante es determinar el recorrido de la nueva variable aleatoria.

- Resumen: Si tenemos que $X \sim \text{Normal}(\mu, \sigma)$

$$\begin{cases} \frac{x-\mu}{\sigma} \sim \text{Normal}(0, 1) \\ \left(\frac{x-\mu}{\sigma}\right)^2 \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2}) \\ \text{c} \cdot \left(\frac{x-\mu}{\sigma}\right)^2 \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2\text{c}}) \\ e^x \sim \text{log-normal}(\mu, \sigma) \end{cases}$$
- Resumen: Si tenemos que $X \sim \text{Log-Normal}(\lambda, \zeta)$

$$\begin{cases} \ln(X) \sim \text{Normal}(\lambda, \zeta) \\ \text{c} \cdot X^K \sim \text{Log-Normal}(k\lambda + \ln(\text{c}), |k|\zeta), \text{ c} > 0, \forall k \neq 0 \end{cases}$$

¹independientes e idénticamente distribuidas

- Sea $X_i \sim \text{Normal}(\mu_i, \sigma_i) \forall i = 1, \dots, n$ independientes $\rightarrow \sum_{i=1}^n a_i X_i \sim \text{Normal}\left(\sum_{i=1}^n a_i \mu_i, \sqrt{\sum_{i=1}^n a_i^2 \sigma_i^2}\right)$
- Sea $X_i \sim \text{log-normal}(\lambda_i, \zeta_i) \forall i = 1, \dots, n$ independientes $\rightarrow Z = \prod_{i=1}^n X_i^{a_i} \sim \text{log-normal}\left(\sum_{i=1}^n a_i \lambda_i, \sqrt{\sum_{i=1}^n a_i^2 \zeta_i^2}\right)$
- En varias ocasiones se considera un n grande cuando $n \geq 30$.
- Teorema del límite central: Si $X_1, \dots, X_n$ son variables aleatorias iid, con

$$\mathbb{E}(X_i) = \mu \quad \text{Var}(X_i) = \sigma^2$$

para todo $i = 1, \dots, n$. Se cumple que

$$\sum_{i=1}^n X_i \stackrel{\text{aprox}}{\sim} \text{Normal}(n\mu, \sqrt{n}\sigma) \quad \frac{1}{n} \sum_{i=1}^n X_i \stackrel{\text{aprox}}{\sim} \text{Normal}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

- Si nos piden la probabilidad aproximada, es un indicio de usar el teorema del límite central.
- No olvidar la corrección por continuidad para cuando aproximamos una distribución discreta mediante la normal.
- La suma de geométricas es binomial negativa.
- En el caso que $X_1, \dots, X_n$ sean v.a independientes con funciones generadoras de momentos $M_{X_1}, \dots, M_{X_n}$ respectivamente, se tiene que la fgm de

$$Z = \sum_{i=1}^n X_i$$

es

$$M_Z(t) = \prod_{i=1}^n M_{X_i}(t)$$

- **No olvidarse de las esperanzas iteradas.** Revisar ejemplo clase 25 octubre profesor aravena ejemplo de la variable T.
- Aproximaciones de primer orden para media y varianza son

$$E[g(X)] = g(\mu_x) \quad \text{Var}[g(X)] = \text{Var}(X) \left[\frac{d}{dX} g(\mu_x) \right]^2$$

El profe dijo que siempre se pregunta respecto a esto y que es solo saber ocupar la fórmula, **ojo**.

- Recordar que la correlación, de una variable con si misma, es 1. $\rho_{i,i} = 1$
- Cuando se habla de valores extremos, se considera el mayor y menor valor de una muestra de tamaño n de una distribución conocida.

Propiedades importantes a tener en cuenta son:

- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- $\text{Cov}(X, X) = \text{Var}(X)$

- $\text{Cov}(aX, Y) = a\text{Cov}(X, Y)$
- $\text{Cov}(X, Y \pm Z) = \text{Cov}(X, Y) \pm \text{Cov}(X, Z)$

El error cuadrático medio se define como:

$$ECM(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + B^2(\hat{\theta})$$

con $B(\hat{\theta}) = E(\hat{\theta}) - \theta$.

Sea $\hat{\theta} = T(X_1, \dots, X_n)$ estimador de θ .

- Se dice que $\hat{\theta}$ es insesgado si

$$E(\hat{\theta}) = \theta$$

- Se dice que $\hat{\theta}$ es consistente en ECM si

$$\lim_{n \rightarrow \infty} ECM(\hat{\theta}) \rightarrow 0$$

- $\hat{\theta}_1$ es más eficiente (suficiencia) que $\hat{\theta}_2$ si

$$ECM(\hat{\theta}_1) < ECM(\hat{\theta}_2)$$

Método de los momentos: Teniendo

$$\mu_k = \mathbb{E}(X^k)$$

$$m_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

$$\rightarrow \mu_k = m_k$$

y con esto despejamos nuestros parámetros de interés.

- Fijarse bien el enunciado cuando nos piden sacar algún parámetro y nos dan la **correlación** entre variables. Puede que sea un indicio de que tengamos que usar aproximaciones de primer orden.
- **IMPORTANTE:** En el formulario **no está la aproximación de segundo orden para la esperanza, la cual es:**

$$\mathbb{E}(Y) \simeq g[(\mu_{x_1}, \dots, \mu_{x_n})] + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \rho_{ij} \sigma_{X_i} \sigma_{X_j} \left(\frac{\partial^2 g}{\partial X_i \partial X_j} \right)$$

- Recordar la aproximación de 1er orden para

$$\mathbb{E}(g(X_1, \dots, X_n)) = g(\mu_1, \dots, \mu_2)$$

- **Propiedades de la distribución χ^2 :**

- Si tenemos que $\chi^2(r)$ es independiente con $\chi^2(s) \implies \chi^2(r) + \chi^2(s) = \chi^2(r+s)$
- $\mathbb{E}(\chi^2(r)) = r$
- $V(\chi^2(r)) = 2r$

- Si $X \sim \text{Exp}(\nu)$ obtener distribución de $y = [x]$

$$\begin{aligned} P(Y = y) &= P([x] = y) \\ &= P(y \leq x < y+1) \\ &= F_x(y+1) - F_x(y) \end{aligned}$$

- **Importante: No olvidar la fórmula para la ECM**
- Sea $X \sim N(\mu_x, \sigma_x)$ e $Y \sim N(\mu_y, \sigma_y)$ **variables dependientes** con $\rho = \frac{Cov(X,Y)}{\sigma_x \sigma_y}$ entonces se tiene que

$$Z = X \pm Y \sim N\left(\mu_x \pm \mu_y, \sqrt{\sigma_x^2 + \sigma_y^2 \pm 2\rho\sigma_x\sigma_y}\right)$$

- Si tenemos que $X_i \sim Exp(\nu) \forall i = 1, \dots, n$, la distribución del mínimo es $Y_1 \sim Exp(n\nu)$.
- Si tenemos que $X \sim Gamma(\frac{n}{2}, \frac{1}{2})$, es lo mismo que decir que $X \sim \chi^2(n)$.
- Importante el estimador de percentiles, puede que lo pregunten. $F(x_p) = p$

Un desarrollo que parece que se puede ocupar en muchas ocasiones cuando tenemos que calcular ciertas cosas que nos piden, como el ECM, Varianza o ese estilo de cosas es el siguiente. Ejercicios donde se tienen **variables independientes e idénticamente distribuidas**. Un ejercicio tipo es el problema 2 de la I3 2019-1.

Problema 2

La distribución Gamma-Inversa(α, β) es una alternativa a las clásicas distribuciones con asimetría positiva. Su función de densidad está dada por la siguiente expresión:

$$f_X(x) = \frac{x^{-(\alpha+1)} e^{-1/(\beta x)}}{\Gamma(\alpha) \beta^\alpha},$$

con $x \geq 0$, $\alpha > 2$ y $\beta > 0$. En base a una muestra aleatoria de tamaño n , independiente con idéntica distribución, se proponen dos estimadores para β con α conocido:

$$\hat{\beta} = \frac{n}{(\alpha - 1) \sum_{i=1}^n X_i} \quad \text{y} \quad \tilde{\beta} = \frac{1}{n\alpha} \sum_{i=1}^n \frac{1}{X_i}.$$

Obtenga el ECM aproximado de 1er orden de $\hat{\beta}$ y exacto para $\tilde{\beta}$. ¿Cuál es más eficiente? Justifique.

Hint: Si $X \sim \text{Gamma-Inversa}(\alpha, \beta)$, entonces $\mu_X = \frac{1}{\beta(\alpha - 1)}$ y $\sigma_X^2 = \frac{1}{\beta^2(\alpha - 1)^2(\alpha - 2)}$.

Para sacar el ECM necesitamos la Varianza y el Bias. Si queremos obtener la $\mathbb{E}(\hat{\beta})$ aproximada, hacemos lo siguiente

$$\begin{aligned} \mathbb{E}(\hat{\beta}) &= \mathbb{E}\left(\frac{n}{(\alpha - 1) \sum_{i=1}^n X_i}\right) \\ &= \frac{1}{\alpha - 1} \mathbb{E}\left(\frac{1}{\frac{1}{n} \sum_{i=1}^n X_i}\right) = \frac{1}{\alpha - 1} \mathbb{E}\left(\frac{1}{\bar{X}_n}\right) \\ &\approx \frac{1}{(\alpha - 1)\mu_X} = \beta \\ \therefore \mathbb{E}(\hat{\beta}) &= \beta \end{aligned}$$

Ahora, para sacar la varianza debemos tener en cuenta la siguiente fórmula para aproximar

$$\begin{aligned} Var(Y) &\approx \sum_{i=1}^n \sum_{j=1}^n \rho_{ij} \sigma_{X_i} \sigma_{X_j} \left[\frac{\partial}{\partial X_i} g(\vec{\mu}) \cdot \frac{\partial}{\partial X_j} g(\vec{\mu}) \right] \\ &= \sum_{i=1}^n \sum_{j=1}^n Cov(X_i, X_j) \left[\frac{\partial}{\partial X_i} g(\vec{\mu}) \cdot \frac{\partial}{\partial X_j} g(\vec{\mu}) \right] \end{aligned}$$

En donde $\text{Cov}(X_i, X_j) = 0 \ \forall i \neq j$, ya que son variables independientes. Si $i = j \implies \text{Cov}(X_i, X_i) = \text{Var}(X_i)$. Por tanto, nos quedaríamos con

$$\begin{aligned}\text{Var}(Y) &= \sum_{i=1}^n \text{Var}(X_i) \left[\frac{\partial}{\partial X_i} g(\vec{\mu}) \right]^2 \\ &= n \text{Var}(X_i) \left[\frac{\partial}{\partial X_i} g(\vec{\mu}) \right]^2\end{aligned}$$

Ahora, para ocupar lo obtenido, se calculará la Varianza. Teniendo

$$\hat{\beta} = \frac{n}{(\alpha - 1) \sum_{i=1}^n X_i} = \frac{n}{\alpha - 1} \left(\sum_{i=1}^n X_i \right)^{-1}$$

De aquí, se deriva y se obtiene

$$\frac{\partial \hat{\beta}}{\partial X_i}(\vec{x}) = -\frac{n}{(\alpha - 1)(\sum_{i=1}^n X_i)^2}$$

Entonces, la Varianza finalmente es

$$\begin{aligned}\text{Var}(\hat{\beta}) &= n \text{Var}(X_i) \left[\frac{\partial \hat{\beta}}{\partial x}(\mu_x) \right]^2 \\ &= n \sigma_x^2 \left(-\frac{n}{(\alpha - 1)(n \mu_x)^2} \right)^2 \\ &= n \sigma_x^2 \left(-\frac{\beta^2 (\alpha - 1)}{n} \right)^2\end{aligned}$$

que es el resultado que aparece en la pauta. (Grande José Suazo ☺).

I4

- **Método de máxima verosimilitud:** Sea X una v.a con función de probabilidad $f_X(x, \theta)$, donde θ es el parámetro de interés. Teniendo una muestra (valores observados) de $x_1, \dots, x_n$, nos preguntamos por el valor más probable de θ que produzca estos valores. Se tiene entonces que la función de verosimilitud es (para una muestra aleatoria, es decir, independiente e idénticamente distribuida):

$$L(x_1, x_2, \dots, x_n, \theta) = \prod_{i=1}^n f_X(x_i, \theta)$$

El estimador de máxima verosimilitud (EMV) es el valor de θ que maximiza la función de verosimilitud L . Es decir:

$$\frac{\partial}{\partial \theta} L(x_1, \dots, x_n, \theta) = 0 \implies \hat{\theta} = \theta$$

Maximizar lo anterior, es lo mismo a maximizar $\ln(L)$:

$$\frac{\partial}{\partial \theta} \ln L(x_1, \dots, x_n, \theta) = 0$$

Debido a que la función $\ln(x)$ es una función estrictamente creciente (flashbacks de opti). Si la función L depende de más de un parámetro, los EMV respectivos son

$$\frac{\partial}{\partial \theta_j} \ln L(x_1, \dots, x_n, \theta_1, \dots, \theta_m) = 0 \quad j = 1, 2, \dots, m$$

Notar que lo anterior es muy parecido a plantear el lagrangeano y luego maximizar esta función. Es decir, estamos en presencia de una aplicación de los multiplicadores de Lagrange (donde no hay restricciones de igualdad).

- **Principio de invarianza:** Ocupamos el EMV y utilizamos la varianza.
- Sea $X_1, \dots, X_n$ una sucesión de v.a independientes con función de probabilidad $p_X(x)$ o de densidad $f_X(x)$. Si $\mathbb{E}(X) = \mu$ y $Var(X) = \sigma^2$, entonces el valores esperado y varianza de $\bar{X}_n$

$$\mu_{\bar{X}_n} = \mathbb{E}(\bar{X}_n) = \mu \quad \sigma_{\bar{X}_n}^2 = Var(\bar{X}_n) = \frac{\sigma^2}{n}$$

Si la distribución es Normal:

$$\bar{X}_n \sim Normal\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

En el caso de que la distribución no sea normal, aplicando el TLC, tenemos que:

$$\bar{X} \stackrel{aprox}{\sim} N\left(\mu, \frac{\sigma}{\sqrt{n}}\right) \implies \underbrace{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}_{\text{pivote}} \stackrel{aprox}{\sim} Normal(0, 1)$$

Las características de un pivote son

- Contiene... **RELLENAR, NO ENTIENDO MI LETRA**
- Contiene parámetros de interés
- Tiene distribución conocida.

$$\bar{X} - \mu \begin{cases} \approx 0 & \rightarrow \text{muy cercano a } \mu_0 \\ << 0 & \rightarrow \text{menor valor a } \mu_0 \\ >> 0 & \rightarrow \text{mayor valor a } \mu_0 \end{cases}$$

- En caso de que no conozcamos σ^2 , lo podemos reemplazar por su estimador muestral S^2 , el cual es un buen estimador para σ^2 e insesgado.

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Así obtenemos el pivote, que solo depende de μ :

$$\Psi : \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t - \text{student}(n-1)$$

- Lo ideal es que Ψ tenga una distribución conocida.
- Nos interesan pivotes sobre parámetros de interés.
- **Prueba de hipótesis:** Una hipótesis es una afirmación con respecto a **a uno o más parámetros** de una población. Generalmente se contrastan las hipótesis:
 - Hipótesis nula: H_0
 - Hipótesis alternativa, H_a .

Para la hipótesis nula **SIEMPRE se pone la igualdad**. Ya sea $\geq$, $\leq$ o $=$. La hipótesis alternativa va con $\neq$, $<$ o $>$. Se le conoce a esta última como hipótesis de trabajo.

- Pasos necesarios en prueba de hipótesis

1. Definir la hipótesis nula y alternativa:

$$H_0 : \mu = \mu_0 \text{ vs } H_a : \mu \neq \mu_0$$

$$H_0 : \mu = \mu_0 \text{ vs } H_a : \mu > \mu_0$$

$$H_0 : \mu = \mu_0 \text{ vs } H_a : \mu < \mu_0$$

Es necesario elegir una de las anteriores.

2. Identificar la prueba estadística adecuada y su distribución (Ψ).
3. Basado en una muestra de datos observados estime el estadístico de prueba. $\rightarrow$ bajo H_0
4. Especifique el nivel de significancia (α), que corresponde a la probabilidad de equivocarse.

$$\alpha = \begin{cases} 1\% \\ 5\% \\ 10\% \end{cases}$$

Este número se especifica a priori.

- Ojo con las palabras que aparecen en el enunciado, al momento de plantear la hipótesis alternativa.

- Los errores que se pueden cometer con un estadístico de prueba son:
 - **Error tipo I:** Se rechaza H_0 dado que era correcta.
 - **Error tipo II:** No se rechaza H_0 dado que no era correcta.
- La probabilidad de **error tipo I** se denota como α .
- Es **muy importante** el criterio del valor p.
- **Valor-p:** Representa la probabilidad de observar "el valor del pivote"(o uno "peor") bajo el supuesto que la H_0 es verdadera. El valor-p corresponde a la probabilidad real de cometer **error tipo I**. La regla es

Rechazar H_0 en favor de H_1 si

$valor - p < \alpha$

Para ver un ejemplo de lo anterior, ver clase profe aravena 10 noviembre.

- Cuando tenemos más de 30 grados de libertad en una t-student, usamos la Normal (TCL) para aproximar la probabilidad.
- Pasos importantes a tener en cuenta
 1. Darse cuenta sobre que se quiere testear
 2. ver las condiciones
 3. ver valor de n
 4. sigma conocido o no
- Si nos dicen **desviación estándar** $\rightarrow S$ (no sé si es S^2). Si dicen **variabilidad** $\rightarrow \sigma$ (No sé si es σ^2).
- No olvidar poner la conclusión. Ejemplo: No hay evidencia suficiente para rechazar/afirmar tal afirmación.
- La última línea de la tabla t-student es $k_{1-\alpha} \rightarrow$ valor crítico.
- Cuando mencionen el menor nivel de significancia, es el valor-p.

Tablas Resumen Test de Hipótesis

Test sobre μ, σ conocido, distribución normal

H_0	H_1	Test	Valor Crítico	valor-p
$\mu = \mu_0$	$\mu \neq \mu_0$	$Z_0 = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$	$ Z_0 > k_{1-\alpha/2}$	$2P(Z > Z_0)$
	$\mu > \mu_0$		$Z_0 > k_{1-\alpha}$	$P(Z > Z_0)$
	$\mu < \mu_0$		$Z_0 < k_a = -k_{1-\alpha}$	$P(Z < Z_0)$

Rechazar si $valor-p < \alpha$. $k_p \rightarrow P(Z \leq k_p) = p$. Valor de tabla

Test sobre μ, σ desconocido, distribución normal

H_0	H_1	Test	Valor Crítico	valor-p
$\mu = \mu_0$	$\mu \neq \mu_0$	$T_0 = \frac{\bar{X} - \mu_0}{S / \sqrt{n}} \sim t\text{-student}(n-1)$	$ T_0 > T_{1-\alpha/2}(n-1)$	$2P(T > T_0)$
	$\mu > \mu_0$		$T_0 > T_{1-\alpha}(n-1)$	$P(T > T_0)$
	$\mu < \mu_0$		$T_0 < t_a(n-1)$	$P(T < T_0)$

donde $s = \sqrt{\frac{1}{n-1} \sum (X_i - \bar{X})^2}$

Test sobre σ , μ desconocido, distribución normal

H_0	H_1	Test	Valor Crítico	valor-p
$\sigma = \sigma_0$	$\sigma \neq \sigma_0$ $\sigma > \sigma_0$ $\sigma < \sigma_0$	$C_0 = \frac{(n-1)s^2}{\sigma_0^2}$	$< C_{\alpha/2} \vee > C_{1-\alpha/2}$ $C_0 > C_{1-\alpha}(n-1)$ $C_0 < C_{\alpha}(n-1)$	** $P(\chi^2 > C_0)$ $P(\chi^2 < C_0)$

Test de proporción

Sea $X_1, \dots, X_n$ iid $\text{Ber}(p)$, $p \in (0, 1)$. Se sabe que $\hat{p} = \frac{\sum X_i}{n} = \bar{X}$ es EMV de P y

$$\hat{p} \stackrel{\text{aprox}}{\sim} N\left(p, \sqrt{\frac{p(1-p)}{n}}\right) \rightarrow Z = \frac{\hat{p} - p}{\underbrace{\sqrt{\frac{p(1-p)}{n}}}_{\text{pivote}}}$$

H_0	H_1	Test	Valor Crítico	valor-p
$p = p_0$	$p \neq p_0$ $p > p_0$ $p < p_0$	$Z_0 = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$	$ Z_0 > k_{1-\alpha/2}$ $Z_0 > k_{1-\alpha}$ $Z_0 < k_{\alpha} = -k_{1-\alpha}$	$2P(Z > Z_0)$ $P(Z > Z_0)$ $P(Z < Z_0)$

- La parte izquierda del formulario, corresponden a los test de hipótesis. La parte derecha corresponde a los intervalos de confianza.
- Curvas de potencia $\rightarrow$ cuan potente son los test.
- Se tiene que $\beta = P(\text{No rechazar } H_0 | H_0 \text{ es falsa})$. Es la probabilidad de cometer un error de tipo II. El complemento se le conoce como la potencia del test. Potencia = $P(\text{Rechazar } H_0 | H_0 \text{ es falsa})$. Potencia = $1 - \beta$

Si queremos contrastar

$$H_0 : \mu = \mu_0 \text{ vs } H_a : \mu \neq \mu_0 \quad (1)$$

$$H_0 : \mu \leq \mu_0 \text{ vs } H_a : \mu > \mu_0 \quad (2)$$

$$H_0 : \mu \geq \mu_0 \text{ vs } H_a : \mu < \mu_0 \quad (3)$$

Para (1) se rechaza H_0 si $|Z_0| > k_{1-\alpha/2}$

$$\begin{aligned} \text{Potencia} &= 1 - \beta \\ &= 1 - \Phi\left(k_{1-\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma}\right) + \Phi\left(k_{\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma}\right) \rightarrow \text{para } \Delta \neq 0 \end{aligned}$$

Cuando $\mu \rightarrow \mu_0$ y $\Delta = 0$, la potencia es igual a α .

Para (2) se rechaza H_0 si $Z_0 > k_{1-\alpha}$

$$\begin{aligned} \text{Potencia} &= 1 - \beta \\ &= 1 - \Phi\left(k_{1-\alpha} - \Delta \frac{\sqrt{n}}{\sigma}\right) \rightarrow \text{para } \Delta > 0 \end{aligned}$$

Para (3) se rechaza H_0 si $Z_0 < k_{\alpha}$

$$\begin{aligned} \text{Potencia} &= 1 - \beta \\ &= \Phi\left(k_{\alpha} - \Delta \frac{\sqrt{n}}{\sigma}\right) \rightarrow \text{para } \Delta < 0 \end{aligned}$$

- Intervalos de confianza. Un intervalo para contener el verdadero valor de algo de interés. Ejemplo: (μ_1, μ_2) intervalo para contener el verdadero valor de μ . Generalmente se hace al 95%.
- Primero hay que pasar sobre el test de comparación de varianzas antes de comparar los μ . Para la varianza, siempre hacemos $\frac{\text{mayor}}{\text{menor}}$
- **Siempre plantear** específicamente la hipótesis nula y alternativa y al final poner la conclusión, son puntos regalados.
- El test de Kolmogorov-Smirnov nos sirve para ver si un conjunto de datos proviene de una distribución específica. En R se hace `ks.test(datos, "distr")`. El único valor que nos interesa es el valor-p. Para este test se recomiendan al menos 50 datos.
- Para el test chi-cuadrado, se comparan las frecuencias observadas $O_1, \dots, O_n$ de k valores (o k intervalos) de la variable con sus correspondientes frecuencias teóricas $E_1, \dots, E_k$ que calculados suponiendo la distribución teórica. Para evaluar la calidad del ajuste se usa:

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

cuya distribución se aproxima por una $\chi^2(k-1)$. Si tenemos que estimar parámetros, entonces la distribución aproximada es $\chi^2(k-1-\nu)$ donde ν es el número de parámetros estimados. Si $X^2 > c_{1-\alpha}(f)$, se rechaza H_0 . Se recomienda usar este test cuando $k \geq 5$ y $E_i \geq 5$.

- Para distintos grados de libertad $\rightarrow$ se compara el valor p y el que sea más grande, es el que ajusta mejor. Si tenemos la misma cantidad de grados de libertad comparamos las χ^2 .
- Si en el test chi-cuadrado, tenemos un $E_i < 5$, podemos colapsarlo arriba o abajo.
- La curva de regresión de Y sobre x es

$$y_i = E(Y_i|x_i) = \mu(x_i)$$

- Si la relación funcional es lineal en los parámetros:

$$\mu(X_i) = \beta_0 + \beta_1 X_i$$

el modelo se llama regresión lineal simple.

- Considérese el modelo de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad \forall i \in \{1, \dots, n\}$$

Supuestos

1. Linealidad: La media condicional de Y sobre x es lineal

$$y = \mathbb{E}(Y|x) = \beta_0 + \beta_1 x$$

2. Homocedasticidad: La varianza asociada a $f_{Y|x}(y)$ es la misma para todo x e igual a σ^2 .
3. Independencia: Las distribuciones condicionales son variables aleatorias independientes para todo x .
4. Normalidad: $f_{Y|x}(y)$ tiene distribución Normal para todo x .
5. $Y|X_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$. $V(Y|X_i) = \sigma^2$

- β_0 : Intercepto, $\beta_0 = \mathbb{E}(Y|X=0)$

- β_1 : Pendiente.
- Observación

$$H_0 : \text{no } \exists \text{ regresion} \iff H_0 : \beta_1 = 0$$

$$H_1 : \exists \text{ regresion} \iff H_1 : \beta_1 \neq 0$$

- Si $F_{calculado} > F_{1-\alpha}(1, n-2)$ se rechaza H_0 .
- El coeficiente R^2 corresponde a la calidad de ajuste,
- El valor-p del test F es el mismo valor-p que el del test T.
- La relación entre el test F y test T es: $F = T^2$ (Estadístico de prueba)

Algunas relaciones importantes son:

- $n = \left(\frac{k_{1-\alpha/2}\sigma}{w} \right)^2 \rightarrow$ tamaño de muestra para cierta precisión.
- $F = \frac{SCR}{SCE}(n-2)$
- $t - value = \frac{\text{Estimate}}{\text{Std. Error}}$
- Residual Standard Error = RSE = $S_{Y|X} = \sqrt{\frac{SCE}{n-2}}$. n-2 son los grados de libertad
- Multiple R-squared = R^2
- Adjusted R-squared = r^2
- $R^2 = 1 - (1 - r^2) \frac{n-2}{n-1}$

