



PROBABILIDADES Y ESTADÍSTICA

Libro Apunte: EYP1113

Realizado por : Michael Ramón

2 de junio de 2023

— Cuarta Edición (En Progreso) —

Índice general

1. Fundamentos de los modelos de probabilidad	1
Definiciones Importantes	1
Elementos de teoría de conjuntos	1
Igualdad de conjuntos	1
Conjunto complemento	2
Ley Conmutativa	2
Ley Asociativa	2
Ley Distributiva	2
Ley de De Morgan	2
Matemática de la probabilidad	3
Ley Aditiva	3
Probabilidad clásica	3
Métodos de conteo	4
Principio de la multiplicación	4
Permutación	4
Combinación	4
Ordenamiento multinomial	5
Probabilidad condicional	5
Independencia estadística	5
Ley multiplicativa	6
Teorema de probabilidades totales	6
Teorema de Bayes	6
2. Modelos analíticos de fenómenos aleatorios	7
Variables Aleatorias	7
Distribución de probabilidad de una variable aleatoria	8
Función de distribución de probabilidad acumulada	8
Variables aleatorias discretas y continuas	8
Variable aleatoria discreta	8
Variable aleatoria continua	8
Propiedades de variables aleatorias	9
Medidas descriptivas de variables aleatorias	9
Función generadora de Momentos	9
Valores centrales	10
Esperanza Matemática	11
Medidas de dispersión	11
Medida de asimetría (Skewness)	12
Medida de Kurtosis	12
Cálculo de Probabilidades Acumuladas	13
Distribuciones de Probabilidad	13
Distribución Normal(μ, σ)	14
Distribución Normal(0,1)	14
Distribución Log-Normal(λ, ζ)	16
Distribución Bernoulli(p)	17
Distribución Binomial(n, p)	18
Distribución Geométrica(p)	18
Distribución Binomial Negativa(k, p)	19
Distribución Poisson(λ)	20
Distribución Exponencial(ν)	21

Distribución Gamma(k, ν)	23
Distribución $\chi^2(n)$	26
Distribución Hipergeométrica(n, N, m)	27
Distribución Beta(q, r)	29
Distribución Weibull(η, β)	30
Distribución Logística(μ, σ)	30
Distribución Log-Logística(μ, σ)	31
Distribución t-Student(ν)	32
Distribución Fisher(η, ν)	32
Distribución Uniforme Discreta($x_1, \dots, x_n$)	33
Distribución Uniforme Continua(a, b)	33
Distribuciones de Probabilidad Desplazadas	34
Múltiples variables aleatorias	36
Distribución de probabilidad conjunta	36
Variables aleatorias discretas	36
Variables aleatorias continuas	36
Distribuciones Marginales	37
DM: Caso discreto	37
DM: Caso continuo	37
Distribuciones Condicionales	37
PC: Caso discreto	37
PC: Caso continuo	37
Distribuciones Marginales mediante Condicionales	37
DM: Caso discreto	38
DM: Caso continuo	38
DM: Caso mixto	38
Soportes Conjuntos y Condicionales	38
Independencia entre variables aleatorias	40
Distribución Normal Bivariada($\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho$)	40
Distribución Normal Bivariada($0, 0, 1, 1, \rho$)	41
Covarianza	41
Correlación	42
Esperanza Condicional	42
Teorema de probabilidades totales para valor esperado	42
Teorema de Esperanza Iterada	43
Predicción	44
3. Funciones de variables aleatorias	45
Funciones de variables aleatorias	45
Función de probabilidad: Caso discreto con raíz única	45
Función de densidad: Caso continuo con raíz única	45
Función de distribución de probabilidad acumulada	45
Función de probabilidad: Caso discreto con varias raíces	47
Función de densidad: Caso continuo con varias raíces	47
Transformaciones típicas de la distribución Normal y Log-Normal	48
Función de múltiples variables aleatorias	48
Función de probabilidad: Caso discreto	49
Función de densidad: Caso continuo	50
Ejemplo: Suma de variables aleatorias DISCRETAS	52
Ejemplo: Suma de variables aleatorias CONTINUAS	53
Ejemplo: Producto de variables aleatorias CONTINUAS	54
Caso especial: Producto de variables independientes Log-Normal (Caso especial de suma de Normales)	55
TEOREMA CENTRAL DEL LÍMITE	55
Aproximación de variable discreta	56
Distribución de valores Extremos	57
Distribución de máximo	57
Distribución de mínimo	57
Distribución conjunta del mínimo y máximo	57
Momentos de Funciones de Variables Aleatorias	58
Esperanza matemática de una función	58

Transformaciones Lineales de Variables Aleatorias	59
Media y Varianza de una función general (Método Delta)	60
4. Inferencia Estadística	62
Definición y Propiedades	62
Propiedades deseables para un estimador	62
Métodos de Estimación	63
Método de Momentos	63
Método de máxima Verosimilitud	64
Propiedades de los estimadores Máximo Verosímiles	67
Cálculo de EM y EMV usando R	67
Distribuciones muestrales	68
Distribución de la Media con Varianza Conocida	68
Distribución de la Media con Varianza Desconocida	68
Distribución de la Varianza estimada con Media Desconocida	69
Distribución de la Varianza estimada con Media Conocida	69
PRUEBA DE HIPÓTESIS	70
Procedimiento para una Prueba de Hipótesis	70
Prueba de hipótesis para μ con σ^2 conocido	71
Prueba de hipótesis para μ con σ^2 desconocido	72
Prueba de hipótesis para σ^2 con μ desconocido	74
Prueba de hipótesis: Casos generales	75
Cálculo del valor-p en R	78
Para μ con σ^2 conocido (z.test())	78
Para μ con σ^2 desconocido (t.test())	78
Para σ^2 con μ desconocido (sigma.test())	78
Caso general (z.test())	78
Caso especial: Test de proporción (prop.test())	79
Potencia y β	79
Intervalos de Confianza para la Media	80
Intervalo de Confianza para μ con σ^2 conocido	81
Intervalo de Confianza para μ con σ^2 desconocido	81
Determinación del Tamaño Muestral	81
Intervalos de Confianza para σ^2 con μ desconocido	82
Intervalos de Confianza Asintóticos	82
Comparación de 2 Poblaciones	84
Caso bajo Normalidad	84
Caso fuera de Normalidad: Bernoulli	85
Caso fuera de Normalidad: Poisson	86
Caso fuera de Normalidad: Exponencial	87
Estimador en común	87
Anexo I: Valores-p y Valores Críticos para Pruebas de Hipótesis	88
Anexo II: Obtención de los estimadores en común para test de comparaciones de poblaciones fuera de Normalidad	94
5. Determinación de Modelos de Probabilidad	98
Introducción	98
Gráficos de Probabilidad	98
QQ-Plot: Distribución Normal	99
QQ-Plot: Distribución Log-Normal	99
QQ-Plot: Distribución Exponencial Desplazada	99
QQ-Plot: Distribución Weibull	100
QQ-Plot: Distribución Logística	100
QQ-Plot: Distribución Log-Logística	100
Uso de R para gráficos de probabilidad	101
Test de Bondad de Ajuste	101
Test de Kolmogorov-Smirnov	101
Test Chi-cuadrado χ^2	101
Uso de R para test de Bondad de Ajuste	102
Test de Kolmogorov-Smirnov (ks.test())	102
Test de Chi-cuadrado χ^2 (chisq.test())	103

Comparación de Distribuciones	105
6. Regresión Lineal	108
Introducción	108
Regresión Lineal Simple	109
Estimación del modelo	109
Máxima Verosimilitud	109
Estimación por Mínimos Cuadrados	110
Propiedades de los estimadores	110
Inferencia estadística del modelo	110
Análisis de Varianza (ANOVA)	111
Coefficiente de Determinación	113
Uso de R para regresión lineal simple	114
Regresión Múltiple	115
Estimación del modelo	116
Estimación de σ^2	117
Inferencia en el modelo	117
Coefficiente de Determinación y Análisis de Varianza	118
Coefficient de Determinación R^2	118
Coefficient de Determinación Ajustado $\bar{R}^2$	118
Coefficient de Correlación Múltiple	118
Análisis de Varianza (ANOVA)	119
Selección del Modelo	119
Análisis del Mejor Modelo de Regresión	120
Multicolinealidad	121
Independencia	121
Outliers, Leverage e Influyentes	122
Uso de R para modelos de regresión lineal múltiple	122
7. Laboratorio: Uso de R	124
Operadores básicos	124
Funciones matemáticas	124
Variables	124
Variables numéricas	124
Variables booleanas	124
Variables de texto	125
Vectores	125
Operadores con vectores	125
Operadores lógicos	125
Manipulación de vectores	126
Ayuda en R	126
Matrices	126
Funciones asociadas a matrices en R	127
Bases de datos	127
Listas	128
Instalación de paquetes	128
Lectura de base de datos	128
Otras funciones útiles de R	129
Estadística descriptiva	129
Funciones de R para estadística descriptiva	129
Programación básica	129
if, else, else if	129
for, while	129
ifelse	130
Cerrar funciones	130
Más funciones útiles	130
Funciones apply	130
Gráficos	131
Argumentos adicionales de <code>plot()</code>	131
Comando <code>boxplot()</code>	131
Comando <code>hist()</code>	131

Comando <code>barplot()</code>	132
Modelos de probabilidad	132
Semillas	132
Medidas descriptivas Teóricas vs Empíricas	132
Paquete <code>dplyr</code>	135
Funciones de <code>dplyr</code>	135
<code>filter</code>	135
<code>slice</code>	135
<code>arrange</code>	135
<code>select</code>	135
<code>rename</code>	135
<code>distinct</code>	136
<code>mutate</code>	136
<code>transmute</code>	136
<code>summarise</code>	136
<code>sample_n</code>	136
<code>sample_frac</code>	136
Operador Pipe	136
<code>group_by</code>	136
<code>which</code>	137
Operador <code>%in%</code>	137
Múltiples variables aleatorias	137
Función de probabilidad conjunta mediante condicionales	137
Gráfica de función de probabilidad conjunta (Discreto)	138
Gráfica de función de densidad conjunta (Continuo)	138
Normal Bivariada	138
Filtrado de base de datos avanzado	140

ADVERTENCIA

El siguiente documento tiene la función de ser una guía adicional de contenido del curso EYP1113: Probabilidades y Estadística mas no reemplaza los apuntes y formularios oficiales proporcionados por el equipo docente, por lo que es responsabilidad del lector verificar la información contenida en este medio con la información oficial. Continuamente se está revisando y agregando la información necesaria para reducir lo máximo posible los errores presentes.

Capítulo 1

Fundamentos de los modelos de probabilidad

Definiciones importantes

- **Espacio muestral:** Conjunto de todos los resultados posibles (Discreto o Continuo)
- **Punto muestral:** Un resultado particular
- **Evento:** Subconjunto de resultados posibles
- **Evento imposible:** Denotado por ϕ es un evento sin puntos muestrales
- **Evento certeza:** Denotado por S u Ω , es un evento que contiene a todos los puntos muestrales
- **Evento complemento:** Denotado por $\overline{E}$, contiene todos los puntos muestrales de S que no están contenidos en un evento E
- **Unión de eventos:** Para dos eventos E_1 y E_2 , su unión forma un nuevo conjunto que contiene los puntos muestrales de E_1 y los contenidos en E_2 que no se encuentran en E_1 ($E_1 \cup E_2$).
- **Intersección de eventos:** Para dos eventos E_1 y E_2 , su intersección forma un nuevo evento que contiene los puntos muestrales contenidos en E_1 y en E_2 a la vez ($E_1 \cap E_2$).
- **Diferencia de conjuntos:** Para dos eventos E_1 y E_2 , la diferencia de E_1 menos E_2 es otro conjunto cuyos elementos son todos aquellos elementos de E_1 que no pertenecen a E_2 . Otra manera alternativa de expresarlo es que la diferencia entre los dos eventos es la intersección entre el evento E_1 y el evento $\overline{E_2}$ ($E_1 - E_2 = E_1 \cap \overline{E_2}$). La diferencia entre E_1 y E_2 , por lo general, no es igual que la diferencia entre E_2 y E_1 ($E_1 - E_2 \neq E_2 - E_1$).
- **Eventos mutuamente excluyentes (Disjuntos):** Son eventos en los que su intersección es vacía ($E_1 \cap E_2 = \phi$).
- **Eventos colectivamente exhaustivos:** Son eventos que unidos conforman el espacio muestral ($E_1 \cup E_2 = S$).
- **Partición:** Son eventos que conforman un evento colectivamente exhaustivo y a la vez son mutuamente excluyentes por pares ($E_1 \cap E_2 = \phi$ y $E_1 \cup E_2 = S$).

Elementos de teoría de conjuntos

Igualdad de conjuntos

Dos conjuntos son iguales si y solo si ambos conjuntos contienen exactamente los mismos puntos muestrales. Un caso básico es el siguiente

$$A \cup \phi = A$$

donde ϕ representa un conjunto vacío.

También se tiene que

$$A \cap \phi = \phi$$

Por lo tanto

$$A \cup A = A \quad \text{y} \quad A \cap A = A$$

Una relación muy útil es la siguiente

$$A \cup S = S \quad \text{y} \quad A \cap S = A$$

Conjunto complemento

Con respecto a un evento E y su complemento $\overline{E}$, se observa que

$$E \cup \overline{E} = S \quad \text{y} \quad E \cap \overline{E} = \phi$$

Finalmente

$$\overline{\overline{E}} = E$$

Ley Conmutativa

La unión e intersección de conjuntos son conmutativas, es decir, para dos conjuntos A y B se cumple que

$$A \cup B = B \cup A$$

$$A \cap B = B \cap A$$

Ley Asociativa

La unión e intersección de conjuntos es asociativa, es decir, para 3 conjuntos A , B y C se cumple que

$$(A \cup B) \cup C = A \cup (B \cup C) = B \cup (A \cup C)$$

$$(A \cap B) \cap C = A \cap (B \cap C) = B \cap (A \cap C)$$

Ley Distributiva

La unión e intersección de conjuntos es distributiva, es decir, para 3 conjuntos A , B y C se cumple que

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$$

$$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$$

Ésta es una relación muy útil

Ley de De Morgan

Ésta ley relaciona conjuntos y sus complementos.

Para dos conjuntos (eventos), E_1 y E_2 , la ley de De Morgan dice que

$$\overline{(E_1 \cup E_2)} = \overline{E_1} \cap \overline{E_2}$$

$$\overline{(E_1 \cap E_2)} = \overline{E_1} \cup \overline{E_2}$$

Generalizando

$$\overline{(E_1 \cup E_2 \cup \dots \cup E_n)} = \overline{E_1} \cap \overline{E_2} \cap \dots \cap \overline{E_n}$$

$$\overline{(E_1 \cap E_2 \cap \dots \cap E_n)} = \overline{E_1} \cup \overline{E_2} \cup \dots \cup \overline{E_n}$$

Matemática de la probabilidad

Los axiomas son los siguientes

- **Axioma 1:** Para cada evento E contenido en un espacio muestral S se tiene que

$$P(E) \geq 0$$

- **Axioma 2:** La probabilidad del evento certeza S es

$$P(S) = 1$$

- **Axioma 3:** Para dos eventos E_1 y E_2 mutuamente excluyentes (disjuntos)

$$P(E_1 \cup E_2) = P(E_1) + P(E_2)$$

Además de los axiomas también se presentan algunas leyes

Ley Aditiva

Sea dos eventos E_1 y E_2 cualquiera, la ley aditiva dice que

$$P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2)$$

Para 3 eventos, E_1 , E_2 y E_3 , la ley aditiva dice

$$P(E_1 \cup E_2 \cup E_3) = P(E_1) + P(E_2) + P(E_3) - P(E_1 \cap E_2) - P(E_1 \cap E_3) - P(E_2 \cap E_3) + P(E_1 \cap E_2 \cap E_3)$$

Ahora, si se tiene que un evento E es la unión de N eventos A_i ,

$$E = \bigcup_{i=1}^N A_i$$

entonces, la probabilidad de E es la siguiente,

$$P(E) = \sum_{i=1}^N P(A_i) - \sum_{i,j|i < j} P(A_i \cap A_j) + \sum_{i,j,k|i < j < k} P(A_i \cap A_j \cap A_k) - \dots (-1)^{N-1} P\left(\bigcap_{i=1}^N A_i\right)$$

Si se tiene N eventos mutuamente excluyentes

$$P(E_1 \cup E_2 \cup \dots \cup E_N) = \sum_{i=1}^N P(E_i)$$

ecuación muy útil

Probabilidad clásica

Si se tiene un espacio muestral S finito

$$S = \{\omega_1, \dots, \omega_N\}$$

y la probabilidad de que ocurra cada evento en S es

$$p_i = P(\{\omega_i\}), \quad i = 1, \dots, N$$

La probabilidad clásica de un evento A es

$$P(A) = \frac{\#A}{\#S}$$

El problema ocurre al momento de contar la cantidad de casos posibles de A cuando es muy grande, para esto se utilizan las técnicas de conteo

Métodos de conteo

Principio de la multiplicación

Si un experimento está compuesto de k experimentos con tamaños muestrales $n_1, \dots, n_k$, entonces

$$\#S = n_1 \times n_2 \times \dots \times n_k$$

Permutación

Considerando un conjunto de objetos

$$C = \{c_1, \dots, c_m\}$$

y se quiere seleccionar una muestra de r objetos, ¿de cuantas maneras se puede hacer?, para responder a esta pregunta se toman los siguientes dos casos

- **Muestreo CON reemplazo:** n^r
- **Muestreo SIN reemplazo :** $n \times (n-1) \times (n-2) \times \dots \times (n-r+1) = \frac{n!}{(n-r)!}$

Observación: En la permutación SI importa el orden

Nota: En las calculadoras científicas, es común encontrar el botón **nPr** para la *permutación*

Combinación

Combinación sin reemplazo

Considerando un muestreo SIN reemplazo. Si interesa obtener una muestra del conjunto total, la cantidad de muestras distintas de tamaño r son

$$\binom{n}{r} = \frac{n!}{r! \times (n-r)!}$$

Estos “números” se conocen como coeficientes binomiales y tiene la siguiente propiedad

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$$

Nota: En las calculadoras científicas, es común encontrar el botón **nCr** para la *combinación*

R: En R se utiliza `choose(n,r)`

Combinación con reemplazo

Ahora, considerando un muestreo CON reemplazo, si interesa obtener una muestra del conjunto total, la cantidad de muestras distintas de tamaño r son

$$\binom{n+r-1}{r} = \frac{(n+r-1)!}{r! \times (n-1)!}$$

Observación: Para ambos casos, combinación con o sin reemplazo; el orden con el cuál son seleccionados los elementos NO importa.

R: En R se utiliza `choose(n+r-1,r)`

Ordenamiento multinomial

Si se quiere asignar n objetos a k grupos distintos de tamaños $n_1, \dots, n_k$, con $\sum_{i=1}^k n_i = n$. El número de grupos distintos con las características dadas son

$$\binom{n}{n_1 \ n_2 \ \dots \ n_k} = \frac{n!}{n_1! \times \dots \times n_k!}$$

Estos “números” se conocen como ordenamientos multinomiales y tienen la siguiente propiedad

$$(x_1 + \dots + x_k)^n = \sum_{n_1=0}^n \sum_{n_2=0}^{n-n_1} \dots \sum_{n_k=0}^{n-n_1-\dots-n_{k-1}} \frac{n!}{n_1! \times \dots \times n_k!} x_1^{n_1} \times \dots \times x_k^{n_k}$$

Probabilidad condicional

Cuando la ocurrencia de un evento (o no ocurrencia) depende de otro evento, es relevante ver la probabilidad como una probabilidad condicional.

Se define la probabilidad condicional que un evento E_1 ocurra bajo el supuesto que otro evento E_2 ocurre con certeza es

$$P(E_1|E_2) = \frac{P(E_1 \cap E_2)}{P(E_2)}$$

En general, la probabilidad de un evento E ya está condicionada a la ocurrencia del evento certeza S

$$P(E|S) = \frac{P(E \cap S)}{P(S)} = P(E)$$

Considerando un evento E_1 y su complemento $\overline{E_1}$ condicionados a la ocurrencia previa de un evento E_2

$$P(E_1|E_2) = \frac{P(E_1 \cap E_2)}{P(E_2)}$$

$$P(\overline{E_1}|E_2) = \frac{P(\overline{E_1} \cap E_2)}{P(E_2)}$$

si se suman se tiene que

$$P(\overline{E_1}|E_2) = 1 - P(E_1|E_2)$$

Independencia estadística

2 eventos E_1 y E_2 se dice que son estadísticamente independientes si la ocurrencia de un evento no depende de la ocurrencia del otro, es decir

$$P(E_1|E_2) = P(E_1) \quad \text{o} \quad P(E_2|E_1) = P(E_2)$$

A partir de esto se tiene que

$$P(E_1 \cap E_2) = P(E_1|E_2) \cdot P(E_2)$$

$$P(E_1 \cap E_2) = P(E_2|E_1) \cdot P(E_1)$$

Si son independientes se tiene que

$$P(E_1 \cap E_2) = P(E_1) \cdot P(E_2)$$

Generalizando, se tiene que si $E_1, \dots, E_n$ son estadísticamente independientes, entonces

$$P(E_1 \cap E_2 \cap \dots \cap E_n) = P(E_1) \times P(E_2) \times \dots \times P(E_n)$$

Observación: NO confundir eventos estadísticamente independientes con eventos disjuntos, son dos definiciones completamente diferentes sin ninguna relación.

Ley multiplicativa

Propiedades

- Si E_1 y E_2 son eventos estadísticamente independientes, entonces $\overline{E_1}$ y $\overline{E_2}$ también lo son
- Si E_1 y E_2 son eventos estadísticamente independientes dado un evento A , entonces

$$P(E_1 \cap E_2 | A) = P(E_1 | A) \cdot P(E_2 | A)$$

- Si para dos eventos cualquiera E_1 y E_2 se tiene que

$$P(E_1 \cup E_2 | A) = P(E_1 | A) + P(E_2 | A) - P(E_1 \cap E_2 | A)$$

Teorema de probabilidades totales

Considerando n eventos posibles $E_1, E_2, \dots, E_n$ colectivamente exhaustivos y mutuamente excluyentes, el teorema de probabilidades totales dice que la probabilidad de un evento A es la siguiente

$$P(A) = \sum_{i=1}^n P(A \cap E_i) = \sum_{i=1}^n P(A | E_i) \cdot P(E_i)$$

Teorema de Bayes

Si cada evento E_k de la partición de S y el evento A son posibles, entonces por ley multiplicativa se tiene que

$$P(A | E_j) \cdot P(E_j) = P(E_j | A) \cdot P(A)$$

Es decir

$$P(E_j | A) = \frac{P(A | E_j) \cdot P(E_j)}{P(A)}$$

Aplicando teorema de probabilidades totales se tiene que

$$P(E_j | A) = \frac{P(A | E_j) \cdot P(E_j)}{\sum_{i=1}^n P(A | E_i) \cdot P(E_i)}$$

Esto se conoce como teorema de Bayes

Capítulo 2

Modelos analíticos de fenómenos aleatorios

En el anterior capítulo se desarrollaron los conceptos fundamentales y herramientas para definir la ocurrencia de fenómenos aleatorios y la determinación de las probabilidades asociadas. En este capítulo se continuará con el análisis de esos conceptos introduciendo el concepto de *Variable Aleatoria* y *Distribuciones de Probabilidad*.

Variables Aleatorias

Una variable aleatorias es un vehículo matemático que representa un evento de una forma analítica. En cursos previos siempre se ha trabajado con *variables deterministas* las cuales tienen siempre un valor fijo, el valor de las variables aleatorias puede estar definido en un rango de posibles valores¹.

Si X se define como una variable aleatoria², entonces $X = x$, $X < x$, $X > x$ o $a \leq X \leq b$ representan diferentes eventos. Intuitivamente, una variable aleatoria puede ser definida matemáticamente como una función que *mapea* los eventos en un espacio muestral en un sistema numérico dentro de la recta real.




Figura 2.1³: Mapeo de eventos de un espacio muestral S en la recta real $\mathbb{R}$

En base a la figura 2.1, los eventos A y B son mapeados a la recta real a través de la variable aleatoria X , estos eventos pueden ser escritos de la siguiente forma:

$$\begin{aligned} A &= a < X \leq b \\ B &= c < X \leq d \\ \overline{A \cup B} &= (X \leq a) + (X > d) \\ A \cap B &= c < X \leq b \end{aligned}$$

Una variable aleatoria puede ser *discreta* como *continua*.

¹Un ejemplo para mostrar esto es la temperatura en distintos días a la misma hora, es razonable que, dependiendo de varios efectos climatológicos, la temperatura no sea exactamente la misma.

²Las variables aleatorias se denotan por una letra en MAYÚSCULA, mientras que un valor medido de la variable aleatoria se denota por la misma letra pero en minúscula.

³Adaptado de la figura 3.1 del libro *Probability Concepts in Engineering: Emphasis on Applications to Civil and Environmental Engineering*.

Distribución de probabilidad de una variable aleatoria

Función de distribución de probabilidad acumulada:

Las probabilidades medidas de una variable aleatoria pueden ser asignadas de acuerdo a reglas prescritas que son llamadas *distribuciones de probabilidad*.

Si X es una variable aleatorias, su distribución de probabilidad siempre puede ser descrita por su *función de distribución de probabilidad acumulada*, la cual se denota a continuación.

$$F_X(x) = P(X \leq x) \quad \forall x \in \mathbb{R}$$

Por lo general, la forma característica de una función de distribución de probabilidad acumulada es de una S, como se muestra en la figura 2.2, desde la probabilidad 0 en el primer punto del dominio hasta la probabilidad 1 al final del dominio de la variable aleatoria.




Figura 2.2: Curva S de una función de probabilidad acumulada $F_X(x)$

Variables aleatorias discretas y continuas

Variable aleatoria discreta:

Si X es una variable aleatoria discreta, entonces su *función de probabilidad*⁴ es:

$$p_X(x) = P(X = x)$$

y su función de distribución de probabilidad acumulada es

$$F_X(x) = P(X \leq x) = \sum_{x_i \leq x} P(X = x_i) = \sum_{x_i \leq x} p_X(x)$$

con $x_i \in \Theta_X$, donde Θ_X es el soporte de X .

Variable aleatoria continua:

Si X es una variable aleatoria continua, las probabilidades están asociadas a los intervalos de x , porque los eventos están definidos como intervalos en la recta real. Por lo tanto, en un específico valor de x , como $X = x$, solo la *función de densidad* está definida y es:

$$f_X(x) = \frac{d}{dx} F_X(x)$$

donde $F_X(x)$ es su función de distribución de probabilidad acumulada

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(x) dx$$

Es necesario recalcar que las probabilidades puntuales para una variable aleatoria continua son nulas, $P(X = x) = 0$, la función de densidad no representa probabilidades puntuales como en el caso discreto.

⁴Se suele llamar también como la *probabilidad puntual*.

Propiedades de variables aleatorias

Las propiedades de las variables aleatorias están escritas en base a la función de distribución de probabilidad acumulada⁵ y se muestran a continuación.

- $F_X(-\infty) = 0$ y $F_X(\infty) = 1 \rightarrow P(\phi) = 0$ y $P(S) = 1$
- $F_X(x) \geq 0$ para todo x y no es decreciente
- $F_X(x)$ es continua por la derecha
- $P(a < X \leq b) = F_X(b) - F_X(a)$

Medidas descriptivas de variables aleatorias

Las propiedades probabilísticas de una variable aleatoria pueden ser descritas completamente mediante la distribución de probabilidad, en términos de su función de probabilidad o densidad o de la función de probabilidad acumulada, y sus parámetros asociados. En la práctica, la forma exacta de la distribución es desconocida, en estos casos, se puede realizar una descripción aproximada de una variable aleatoria en términos de sus *medidas descriptivas*.

Por completitud, incluso cuando la distribución de probabilidad es conocida, las medidas descriptivas siguen siendo de utilidad, porque contienen información de las propiedades de la variable aleatoria que son muy importantes en muchas aplicaciones prácticas. Además, los parámetros de una conocida distribución pueden ser derivados a partir de estas cantidades.

Función generadora de Momentos

La *función generadora de momentos* (F.G.M.) de una variable aleatoria X es $M_X(t) = E[e^{Xt}]$ y se calcula como sigue:

$$M_X(t) = E[e^{Xt}] = \begin{cases} \sum_{x \in \Theta_X} e^{xt} \cdot p_X(x), & \text{Caso discreto} \\ \int_{x \in \Theta_X} e^{xt} \cdot f_X(x) dx, & \text{Caso continuo} \end{cases}$$

Curiosidad: Para el caso continuo, la función generadora de momentos es en esencia una transformada de Laplace con $-s = t$.

$$\mathcal{L}\{f(x)\} = \int_{-\infty}^{\infty} f(x) e^{-sx} dx$$

La F.G.M. tiene las siguientes propiedades:

- **Propiedad A:** Si dos variables aleatorias tienen la misma F.G.M., entonces ambas tienen la misma distribución⁶.
- **Propiedad B:** Si la función generadora de momentos existe para t en un intervalo abierto que contiene al cero, entonces:

$$\left. \frac{d^r}{dt^r} M_X(t) \right|_{t=0} = M^{(r)}(0) = E(X^r)$$

- **Propiedad C:** Si X tiene F.G.M. $M_X(t)$ y se tiene que⁷ $Y = a + bX$, entonces, la F.G.M. de Y es⁸:

$$M_Y(t) = e^{at} M_X(bt)$$

⁵Se pueden deducir de la figura 2.2.

⁶En otras palabras, la F.G.M. es única para cada distribución de probabilidad.

⁷Se pueden generar relaciones entre dos variables aleatorias mediante funciones del estilo $Y = g(X)$, pero esto se verá en el siguiente capítulo.

⁸Esto será útil para las versiones desplazadas de las distribuciones.

- **Propiedad D:** Si X e Y son independientes⁹ con F.G.M. $M_X(t)$ y $M_Y(t)$ y se tiene que $Z = X + Y$, entonces:

$$M_Z(t) = M_X(t) \cdot M_Y(t)$$

en un intervalo donde ambas F.G.M. existan.

Valores centrales

Como hay un rango de posibles valores de una variable aleatoria, algunos *valores centrales* de este rango, como el valor promedio, naturalmente pueden ser de especial interés.

Las cantidades que representan valores centrales son el valor esperado, la moda y la mediana.

- **Valor esperado:** O también llamada *media ponderada*, *valor medio* o simplemente *media*, es el centro de masa de la distribución.

$$\mu_X = M'_X(0) = E(X) = \begin{cases} \sum_{x \in \Theta_X} x \cdot p_X(x), & \text{Caso discreto} \\ \int_{x \in \Theta_X} x \cdot f_X(x) dx, & \text{Caso continuo} \end{cases}$$

- **Moda:** Valor mas frecuente o con mayor probabilidad para el caso discreto, es el valor máximo de la función de densidad para el caso continuo. Para una variable continua, la moda se obtiene mediante,

$$\frac{d}{dx} f_X(x_{\text{Moda}}) = 0 \quad \text{o} \quad \frac{d}{dx} f_X(x_{\text{Moda}}) = \nexists$$




Figura 2.3: Moda y valor esperado de una distribución con $f_X(x)$

- **Mediana:** Valor tal que se acumula un 50 % de probabilidad

$$F_X(x_{\text{Med}}) = \frac{1}{2} \quad \text{o} \quad P(X \geq x_{\text{Med}}) = \frac{1}{2}$$




Figura 2.4: Representación de la mediana en una función de densidad $f_X(x)$

⁹La independencia entre variables aleatorias se estudiará más adelante en este capítulo.

Observación: En general, la media, moda y mediana de una variable aleatoria son diferentes, especialmente si la distribución es asimétrica. Sin embargo, si la distribución es simétrica y unimodal¹⁰, estas cantidades son iguales.

Esperanza Matemática

La definición del valor medio, descrito anteriormente, puede ser generalizado para una función de X . Dada una función $g(X)$, su valor esperado, $E[g(X)]$, es:

$$E[g(X)] = \begin{cases} \sum_{x \in \Theta_X} g(x) \cdot p_X(x), & \text{Caso discreto} \\ \int_{x \in \Theta_X} g(x) \cdot f_X(x) dx, & \text{Caso continuo} \end{cases}$$

Medidas de dispersión

De nuevo, como hay un rango de posibles valores de una variable aleatoria asociados con diferentes probabilidades, algunas *medidas de dispersión* son necesarias para indicar que tan grande o pequeña es la dispersión de los valores de la variable aleatoria.

Es de especial interés una cantidad que mida que tan cerca o lejos los valores de la variable se agrupan alrededor de un valor central.

Las cantidades que representan medidas de dispersión son la varianza, la desviación estándar, el coeficiente de variación, el rango y rango intercuartílico.

- **Varianza:** Representa la variabilidad de los datos respecto a la media.

$$\sigma_X^2 = \text{Var}(X) = E[(X - \mu_X)^2] = \begin{cases} \sum_{x \in \Theta_X} (x - \mu_X)^2 \cdot p_X(x), & \text{Caso discreto} \\ \int_{x \in \Theta_X} (x - \mu_X)^2 \cdot f_X(x) dx, & \text{Caso continuo} \end{cases}$$

Resolviendo, ya sea la suma o la integral, se puede llegar al siguiente resultado importante:

$$\sigma_X^2 = E(X^2) - \mu_X^2$$

- **Desviación estándar:** Su interpretación es similar a la varianza. Se utiliza ya que se trabaja con las mismas unidades de medida de la variable aleatoria.

$$\sigma_X = \sqrt{\text{Var}(X)}$$

- **Coeficiente de variación (c.o.v.):** Muestra la dispersión relativa respecto al valor central. Se usa comúnmente para poder comparar la dispersión de dos fenómenos distintos.

$$\delta_X = \frac{\sigma_X}{\mu_X}$$

donde $\mu_X > 0$.

- **Rango:** Muestra la diferencia entre el valor máximo y el mínimo de una muestra. Utilizado para obtener la dispersión total.

$$\text{Rango} = \max - \min$$

- **Rango intercuartílico:** Diferencia entre el primer y el tercer cuartil, utilizado como medida de dispersión.

$$\text{IQR} = x_{0.75} - x_{0.25}$$

Donde $x_{0.75}$ y $x_{0.25}$ son los percentiles¹¹ 75 % y 25 % respectivamente

¹⁰Solo existe un único valor para la moda.

¹¹Un percentil $p \times 100\%$, x_p , es un valor x tal que $P(X \leq x_p) = p$.

Medida de asimetría (skewness)

Otra útil e importante propiedad de una variable aleatoria es la asimetría o asimetría de su función de densidad o de probabilidad. Una medida de esta asimetría es el *tercer momento central*:

$$E[(X - \mu_X)^3] = \begin{cases} \sum_{x_i \in \Theta_X} (x_i - \mu_X)^3 \cdot p_X(x_i), & \text{Caso discreto} \\ \int_{x \in \Theta_X} (x - \mu_X)^3 \cdot f_X(x) dx, & \text{Caso continuo} \end{cases}$$

Así como el coeficiente de variación, se puede definir al grado de asimetría mediante el coeficiente de asimetría o *skewness* de la siguiente forma:

$$\theta_X = \frac{E[(X - \mu_X)^3]}{\sigma_X^3} = \frac{E(X^3) - 3\mu_X E(X^2) + 2\mu_X^3}{\sigma_X^3}$$

El coeficiente de asimetría es adimensional y tiene las siguientes propiedades:

- 1) Si $\theta_X = 0$, la distribución es perfectamente simétrica.
- 2) Si $\theta_X > 0$, la distribución tiene asimetría positiva.
- 3) Si $\theta_X < 0$, la distribución tiene asimetría negativa.
- 4) Si $\theta_X \approx 0$, la distribución es aproximadamente simétrica.




Figura 2.5: Simetría y asimetría de una función de densidad $f_X(x)$ a través del θ_X

Medida de kurtosis

Finalmente, otra propiedad muy útil es el *cuarto momento central* de una variable aleatoria conocido como *kurtosis*:

$$E[(X - \mu_X)^4] = \begin{cases} \sum_{x_i \in \Theta_X} (x_i - \mu_X)^4 \cdot p_X(x_i), & \text{Caso discreto} \\ \int_{x \in \Theta_X} (x - \mu_X)^4 \cdot f_X(x) dx, & \text{Caso continuo} \end{cases}$$

Se puede medir la kurtosis utilizando el *coeficiente de kurtosis* definido como¹²:

$$\kappa_X = \frac{E[(X - \mu_X)^4]}{\sigma_X^4} - 3 = \frac{E(X^4) - 4\mu_X E(X^3) + 6\mu_X^2 E(X^2) - 3\mu_X^4}{\sigma_X^4} - 3$$

El coeficiente de kurtosis mide que tan concentrados o alejados se encuentran los datos en torno a la media y tiene las siguientes propiedades:

- 1) Si $\kappa_X > 0$, los datos están muy concentrados en torno a la media, la distribución es *leptocúrtica*.
- 2) Si $\kappa_X < 0$, los datos están muy alejados de la media, la distribución es *platicúrtica*.
- 3) Si $\kappa_X = 0$, los datos distribuyen Normal, la distribución es *mesocúrtica*.
- 4) Si $\kappa_X \approx 0$, los datos distribuyen aproximadamente Normal, la distribución es aproximadamente *mesocúrtica*.

¹² κ_X se suele llamar *exceso de kurtosis*, esto debido a que se debe restar 3 con el objetivo de generar un coeficiente que valga 0 para la Normal y tome a ésta como referencia de Kurtosis.




Figura 2.6: Representación gráfica de la kurtosis

Cálculo de Probabilidades Acumuladas

En varios casos, calcular probabilidades acumuladas manualmente puede ser complicado, por lo que se tendrá que recurrir a aproximaciones o a condiciones para que sea más cómo calcularlas mediante calculadoras comunes.

En el **caso discreto**, el cálculo de probabilidades acumuladas será la suma de las probabilidades puntuales hasta el valor x deseado:

$$X \sim p_X(x)$$

$$F_X(x) = P(X \leq x) = \sum_{x_i=x_0}^x p_X(x_i) = p_X(x_0) + p_X(x_0 + 1) + \cdots + p_X(x)$$

donde $\Theta_X \in [x_0, x_f]$ (x_0 y x_f dependerá de cada distribución), entonces, para poder calcular fácilmente la probabilidad acumulada en una calculadora, el intervalo $[x_0, x]$ de la suma es tal que involucre pocos elementos a sumar. En el caso que la suma involucre demasiados términos, entonces se tendrá que hacer una aproximación a una distribución Normal para poder utilizar la tabla Normal(0,1) y facilitar el cálculo, esto se explicará al introducir el **Teorema del Límite Central**.

En el **caso continuo**, el cálculo de probabilidades acumuladas será la integral de la función de densidad desde el inicio del soporte hasta el valor de x deseado:

$$X \sim f_X(x)$$

$$F_X(x) = P(X \leq x) = \int_{x_0}^x f_X(x) dx$$

donde $\Theta \in [x_0, x_f]$ (Θ_X dependerá de la distribución), entonces, si $f_X(x)$ es sencillo de integrar entonces el cálculo de $F_X(x)$ es directo y exacto, por otro lado, si $f_X(x)$ es difícil o imposible de integrar, entonces se tendrá que hacer una aproximación a una distribución Normal para poder utilizar la tabla Normal(0,1) y facilitar el cálculo, esto se explicará al introducir el **Teorema del Límite Central**.

Si se está trabajando mediante software ([R](#), [Wolfram](#), Python, etc.), entonces no es necesario realizar las aproximaciones antes mencionadas ya que se pueden obtener valores exactos de cualquier distribución.

Distribuciones de Probabilidad

Teóricamente, cualquier función que posea las propiedades de las variables aleatorias descritas anteriormente puede ser usada para representar la distribución de probabilidad de esta variable. Para propósitos prácticos, hay ciertas distribuciones continuas y discretas que son especialmente útiles debido a las siguientes razones:

- Es resultado de proceso físico y puede ser derivado en ases a supuestos físicos razonables.
- La función es el resultado de algún proceso límite.
- Es ampliamente conocida y la información estadística necesaria está disponible.

Varias de estas distribuciones de probabilidades son presentadas junto a sus propiedades especiales a lo largo del capítulo.

Distribución Normal

$$X \sim \text{Normal}(\mu, \sigma)$$

La distribución de probabilidad más conocida y ampliamente usada sin dudas es la *distribución Normal* o también llamada *distribución Gausseana*. Su función de densidad es:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right], \quad \Theta_X \in \mathbb{R}$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right] dx$$




Figura 2.7: Gráfico de la distribución Normal(μ, σ)

Los parámetros de esta distribución son μ , representa donde está centrada, y σ , representa la forma de $f_X(x)$.

Propiedades:

- **Valor esperado:** $E(X) = \mu$
- **Varianza:** $\text{Var}(X) = \sigma^2$
- **Función generadora de momentos:** $M_X(t) = \exp \left(\mu t + \frac{\sigma^2 t^2}{2} \right)$
- **Skewness:** $\theta_X = 0$
- **Kurtosis:** $\kappa_X = 0$

R: En R se utiliza `[p,d,r,q]norm(x, mean = mu, sd = sigma)`

Distribución Normal Estándar

$$Z \sim \text{Normal}(0, 1)$$

Este es un caso especial donde $\mu = 0$ y $\sigma = 1$, su función de densidad¹³ es

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} z^2 \right), \quad \Theta_Z \in \mathbb{R}$$

¹³Para esta distribución es común utilizar la letra Z para representar a la variable aleatoria.

Su función de distribución de probabilidad acumulada, que se denota por $\Phi(\cdot)$, es

$$\Phi(z) = F_Z(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right) dz$$

Algunas características de $\Psi(\cdot)$ y los percentiles¹⁴ son:

- $z_p = \Phi^{-1}(p) = -\Phi^{-1}(1-p)$
- $\Phi(-z) = 1 - \Phi(z)$




Figura 2.8: Gráfico de la distribución Normal Estándar

Propiedades:

- **Valor esperado:** $E(Z) = 0$
- **Varianza:** $\text{Var}(Z) = 1$
- **Función generadora de momentos:** $M_Z(t) = \exp\left(\frac{t^2}{2}\right)$

Se puede relacionar la distribución normal con la normal estándar de la siguiente forma:

Si $X \sim \text{Normal}(\mu, \sigma)$, entonces

$$F_X(x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

La relación entre los percentiles x_p y la probabilidad $p \times 100\%$ es la siguiente:

$$x_p = \mu + \sigma \cdot \Phi^{-1}(p)$$

donde $\Phi^{-1}(p)$ es el percentil z_p y se obtiene a partir de la tabla Normal(0,1).

Observación: Esta relación, entre normal y normal estándar, es muy útil, en especial si se desea obtener los parámetros μ y σ mediante percentiles dados. Además, esto ayuda a calcular probabilidades acumuladas solamente con el uso de una tabla de probabilidades Normal(0,1)¹⁵.

R: En R se utiliza `[p,d,r,q]norm(x, mean = 0, sd = 1)` o simplemente `[p,d,r,q]norm(x)`

¹⁴En los siguientes capítulos y en algunos libros, se denotan a los percentiles con la letra k , k_p .

¹⁵Este proceso se llama *estandarización*, gracias a esto se puede utilizar la tabla Normal(0,1) para cualquier distribución Normal, por lo que **NO SE DEBE UTILIZAR** $F_X(x)$ mediante la integral para calcular probabilidad ya que es imposible resolverla de forma exacta.

Distribución Log-Normal

$$X \sim \text{Log-Normal}(\lambda, \zeta)$$

La *distribución Normal Logarítmica* o comúnmente conocida como *distribución Log-Normal* es una distribución de probabilidad igualmente popular. Su función de densidad es

$$f_X(x) = \frac{1}{\zeta x \sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{\ln(x) - \lambda}{\zeta} \right)^2 \right], \quad \Theta_X \in (0, \infty)$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \int_0^x \frac{1}{\sqrt{2\pi}} \frac{1}{(\zeta x)} \exp \left[-\frac{1}{2} \left(\frac{\ln(x) - \lambda}{\zeta} \right)^2 \right] dx$$

donde $\lambda = E[\ln(X)]$ y $\zeta = \sqrt{\text{Var}(\ln(X))}$, son los parámetros de la distribución.




Figura 2.9: Gráfico de la distribución Log-Normal(λ, ζ)

Propiedades:

E. **Valor esperado:** $E(X) = \exp \left(\lambda + \frac{\zeta^2}{2} \right)$

M. **Varianza:** $\text{Var}(X) = \mu_X^2 \left(e^{\zeta^2} - 1 \right)$

I. **Relación ζ - c.o.v.:** $\zeta = \sqrt{\ln(1 + \delta_X^2)}$, si $\delta_X \leq 0.3$, entonces se puede aproximar $\zeta \approx \delta_X$.

L. **Mediana:** $x_{\text{Med}} = e^\lambda$

I. **k-ésimo momento:** $E(X^k) = e^{\lambda k} \cdot M_Z(\zeta k)$, con $Z \sim \text{Normal}(0, 1)$, $E(X^k) = \exp \left(\lambda k + \frac{(k\zeta)^2}{2} \right)$

A. **Relación mediana, media y c.o.v.:** $\mu_X = x_{\text{Med}} \sqrt{1 + \delta_X^2}$

Se puede relacionar la distribución Log-Normal con la normal estándar de la siguiente forma:

Si $X \sim \text{Log-Normal}(\lambda, \zeta)$, entonces

$$F_X(x) = \Phi \left(\frac{\ln(x) - \lambda}{\zeta} \right)$$

La relación entre los logaritmos de los percentiles x_p , $\ln(x_p)$, y la probabilidad $p \times 100\%$ es la siguiente:

$$\ln(x_p) = \lambda + \zeta \cdot \Phi^{-1}(p)$$

donde $\Phi^{-1}(p)$ es el percentil z_p y se obtiene a partir de la tabla Normal(0,1).

Observación: Esta relación, entre log-normal y normal estándar, es muy útil en especial si se desea obtener los parámetros λ y ζ mediante un percentiles dados. Además, esto ayuda a calcular probabilidades acumuladas solamente con el uso de una tabla de probabilidades Normal(0,1)¹⁶.

R: En R se utiliza `[p,d,r,q]lnorm(x, meanlog = lambda, sdlog = zeta)`

Distribución Bernoulli

$X \sim \text{Bernoulli}(p)$

En muchas aplicaciones de ingeniería, a menudo hay varios problemas relacionados a la ocurrencia o recurrencia de un evento en una secuencia de *intentos* discretos. Estos intentos o *experimentos* contienen dos posibilidades, el evento *ocurre* (*éxito*) o *no ocurre* (*fracaso*)¹⁷ en cada experimento.

Problemas del tipo que se acabó de describir pueden ser modelados por una *distribución Bernoulli*¹⁸, las cuales están basadas en los siguientes supuestos:

1. En cada intento o experimento, solo hay dos posibles resultados, la *ocurrencia* o *éxito* y la *no ocurrencia* o *fracaso*.
2. La probabilidad de ocurrencia del evento en cada intento es *constante*.
3. Los intentos son estadísticamente independientes.

La forma usual de identificar a esta distribución es definiendo a la variable aleatoria con la siguiente estructura:

X : Número de éxitos en un único experimento (o intento) independientes

La función de probabilidad es

$$p_X(x) = p^x(1-p)^{1-x}, \quad \Theta_X \in \{0, 1\}$$

donde 0 representa *fracaso* y 1 representa *éxito*. Su función de distribución de probabilidad acumulada es

$$F_X(x) = \begin{cases} 0, & x < 0 \\ 1 - p, & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

Propiedades:

- **Función generadora de momentos:** $M_X(t) = pe^t + 1 - p$
- **Valor esperado:** $\mu_X = p$
- **Varianza:** $\sigma_X^2 = p(1 - p)$
- **Momento m-ésimo:** $E(X^m) = p$

R: En R se utiliza `[p,d,r,q]binom(x, size = 1, prob = p)`

¹⁶ Así como en el caso de una distribución Normal, mediante la estandarización se puede utilizar la tabla Normal(0,1) para cualquier distribución Log-Normal, por lo que **NO SE DEBE UTILIZAR** $F_X(x)$ en base a la integral para calcular probabilidades.

¹⁷ En este texto se utilizará frecuentemente el término *éxito* o *fracaso* para referirse a la ocurrencia o no ocurrencia.

¹⁸ Se la suele conocer también como *secuencia Bernoulli* o *experimento Bernoulli*.

Distribución Binomial

$$X \sim \text{Binomial}(n, p)$$

En una secuencia de variables aleatorias Bernoulli, si X se define mediante la siguiente estructura:

X : Número de éxitos en “ n ” experimentos Bernoulli independientes

en donde la probabilidad de éxito del evento en cada experimento es p , entonces la probabilidad de exactamente x ocurrencias entre los n experimentos está gobernado por la *distribución Binomial*, la función de probabilidad es

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad \Theta_X \in \{0, 1, 2, \dots, n\}$$

donde n y p son los parámetros de la distribución. La función de distribución de probabilidad acumulada es

$$F_X(x) = \sum_{k=0}^x \binom{n}{k} p^k (1-p)^{n-k}, \quad \Theta_X = \{0, 1, 2, \dots, n\}$$

Propiedades:

- **Función generadora de momentos:** $M_X(t) = (pe^t + (1-p))^n$
- **Valor esperado:** $\mu_X = np$
- **Varianza:** $\sigma_X^2 = np(1-p)$
- **Relación Bernoulli-Binomial**¹⁹: Si $n = 1$, entonces $\text{Binomial}(n = 1, p) = \text{Bernoulli}(p)$.

R: En R se utiliza `[p,d,r,q]binom(x, size = n, prob = p)`

Distribución Geométrica

$$N \sim \text{Geométrica}(p)$$

En una secuencia Bernoulli, si N está definida bajo la siguiente estructura:

N : Número de experimentos Bernoulli independientes hasta obtener el 1^{er} éxito

en donde la probabilidad de éxito en cada experimento es p , entonces N está gobernado por la *distribución Geométrica*. La función de probabilidad es

$$p_N(n) = p(1-p)^{n-1}, \quad \Theta_N \in \mathbb{N}$$

Su función de distribución de probabilidad acumulada es

$$F_N(n) = \sum_{k=1}^n p(1-p)^{k-1} = 1 - (1-p)^n, \quad \Theta_N \in \mathbb{N}$$

Propiedades:

- **Función generadora de momentos:** $M_N(t) = \frac{pe^t}{1 - (1-p)e^t}, \quad t < -\ln(1-p)$
- **Valor esperado:** $\mu_N = \frac{1}{p}$
- **Varianza:** $\sigma_N^2 = \frac{1-p}{p^2}$

¹⁹En el siguiente capítulo se entenderá que la suma de variables Bernoulli reproducen a la distribución Binomial.

R: En R se utiliza `[p,d,r,q]geom(n-1, prob = p)`

Observación: En este texto se utiliza la notación $\mathbb{N}$ para indicar al conjunto de números naturales sin incluir el cero ($\mathbb{N} = \{1, 2, 3, \dots\}$), si se incluye el cero se utilizará $\mathbb{N}_0$.

Una de sus aplicaciones tiene que ver con el **Tiempo de recurrencia o periodo de retorno**:

En un problema de tiempo (o espacio) que es aproximadamente discretizado en intervalos de tiempo (o espacio), cada intervalo de tiempo puede ser modelado por una secuencia Bernoulli, entonces se puede definir a la siguiente variable aleatoria:

T : Intervalos de tiempo transcurridos hasta observar el primer evento exitoso

Se observa que la distribución de T es Geométrica,

$$T \sim \text{Geométrica}(p)$$

El número de intervalos ocurridos hasta observar el primer evento exitoso se denomina *primer tiempo de recurrencia*.

El *tiempo medio de recurrencia*, popularmente conocido en ingeniería como el *periodo de retorno*, es

$$\bar{T} = E(T) = \sum_{t=1}^{\infty} t \cdot p(1-p)^{t-1} = \frac{1}{p}$$

Distribución Binomial Negativa

$$N_k \sim \text{Bin-Negativa}(k, p)$$

En una secuencia Bernoulli, si N_k se define mediante la siguiente estructura:

N_k : Número de experimentos Bernoulli independientes hasta observar el k^{mo} éxito

en donde la probabilidad de éxito en cada experimento es p , entonces N_k está gobernado por la *distribución Binomial-Negativa*. La función de probabilidad es

$$p_{N_k}(n) = \binom{n-1}{k-1} p^k (1-p)^{n-k}, \quad \Theta_{N_k} \in \{k, k+1, k+2, \dots\}$$

Su función de distribución de probabilidad acumulada es

$$F_{N_k}(n) = \sum_{i=k}^n \binom{i-1}{k-1} p^k (1-p)^{i-k}, \quad \Theta_{N_k} = k, k+1, k+2, \dots$$

Propiedades:

- **F. generadora de momentos:** $M_{N_k}(t) = \left(\frac{pe^t}{1 - (1-p)e^t} \right)^k$, $t < -\ln(1-p)$
- **Valor esperado:** $\mu_{N_k} = \frac{k}{p}$
- **Varianza:** $\sigma_{N_k}^2 = \frac{k(1-p)}{p^2}$
- **Relación Geométrica-Bin-Neg²⁰:** Si $k = 1$, entonces $\text{Bin-Negativa}(k = 1, p) = \text{Geométrica}(p)$.

R: En R se utiliza `[p,d,r,q]nbinom(n-k, size = k, prob = p)`

²⁰En el siguiente capítulo se entenderá que la suma de variables Geométricas reproducen la distribución Binomial-Negativa.

Distribución de Poisson

$$X_t \sim \text{Poisson}(\nu t) \text{ o } X_t \sim \text{Poisson}(\lambda)$$

Muchos problemas físicos de interés para los ingenieros y científicos involucran la posible ocurrencia de eventos en un punto en el tiempo y/o espacio, un ejemplo típico son los accidentes de tráfico, estos pueden ocurrir en cualquier tiempo en una cierta carretera. Estos problemas de espacio-tiempo pueden ser modelados también como secuencias Bernoulli, dividiendo el tiempo o espacio en pequeños intervalos apropiados, y asumiendo que un evento puede ocurrir o no dentro de cada intervalo, constituyendo así un experimento Bernoulli. Sin embargo, si el evento puede ocurrir aleatoriamente en cualquier instante de tiempo (o en cualquier punto del espacio), también puede ocurrir más de una vez en cualquier intervalo de tiempo/espacio. En estos casos, la ocurrencia del evento puede ser modelarla mediante un *proceso o secuencia Poisson*.

Formalmente, el proceso Poisson está basado en las siguientes suposiciones:

1. Un evento puede ocurrir al azar y en cualquier instante punto del tiempo o espacio.
2. La ocurrencia(s) de un evento en un cierto intervalo de tiempo (o espacio) es estadísticamente independiente de cualquier otro intervalo que no se superponga.
3. La probabilidad de ocurrencia de un evento en un intervalo pequeño Δt es proporcional a Δt , y puede estar dada por $\nu \Delta t$, donde ν es la *tasa de ocurrencia promedio* del evento²¹ (se sume que es constante).
4. La probabilidad de dos o mas eventos en Δt es despreciable.

En base a estos supuestos, si X es el *número de ocurrencias estadísticamente independientes de un evento en t* ²² (tiempo o espacio), entonces X está gobernado por la *distribución Poisson*. La función de probabilidad es

$$p_{X_t}(x) = \frac{(\nu t)^x e^{-\nu t}}{x!} = \frac{\lambda^x e^{-\lambda}}{x!}, \quad \Theta_{X_t} \in \mathbb{N}_0$$

Su función de distribución de probabilidad acumulada es

$$F_{X_t}(x) = \sum_{k=0}^x \frac{(\nu t)^k e^{-\nu t}}{k!} = \sum_{k=0}^x \frac{\lambda^k e^{-\lambda}}{k!}, \quad \Theta_{X_t} \in \mathbb{N}_0$$

donde ν es la tasa de ocurrencia promedio (mencionada anteriormente) y λ es el *número promedio* de ocurrencias en el tiempo t . Existen dos formas de derivar la función de probabilidad de la distribución Poisson, en este texto solo se mostrará una de ellas²³.

Demostración: Derivación de la función de probabilidad de la distribución Poisson

Aproximación mediante la distribución Binomial

En la distribución Binomial, el parámetro p es la probabilidad de éxito y n son la cantidad de intentos, entonces, se puede utilizar la siguiente relación con λ :

$$p = \frac{\text{Número promedio de ocurrencias}}{\text{Número total de experimentos}} = \frac{\lambda}{n} = \nu \cdot \frac{t}{n}$$

esto representa que se está subdividiendo al tiempo t en intervalos más cortos. Reemplazando p en la función de probabilidad de la distribución Binomial se obtiene:

$$P(x \text{ ocurrencias en } t) = \binom{n}{x} \left(\frac{\nu t}{n} \right)^x \left(1 - \frac{\nu t}{n} \right)^{n-x}$$

Si el evento puede ocurrir en cualquier momento, el tiempo t deberá subdividirse en una gran

²¹El parámetro ν tiene unidades de medida de Cantidad/Tiempo o Cantidad/Espacio.

²²O en un intervalo de tiempo/espacio $(0, t)$.

²³La otra demostración la puede encontrar en el **Apéndice C** del libro *Probability Concepts in Engineering: Emphasis on Applications to Civil and Environmental Engineering*.

cantidad de intervalos, es decir, $n \rightarrow \infty$, entonces:

$$\begin{aligned} P(x \text{ ocurrencias en } t) &= \lim_{n \rightarrow \infty} \binom{n}{x} \left(\frac{\nu t}{n}\right)^x \left(1 - \frac{\nu t}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{n!}{x!(n-x)!} \left(\frac{\nu t}{n}\right)^x \left(1 - \frac{\nu t}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{n!}{x!(n-x)!} \frac{(\nu t)^x}{n^x} \left(1 - \frac{\nu t}{n}\right)^n \left(1 - \frac{\nu t}{n}\right)^{-x} \end{aligned}$$

Se observa que

$$\begin{aligned} \lim_{n \rightarrow \infty} \left(1 - \frac{\nu t}{n}\right)^n &= e^{-\nu t} \\ \lim_{n \rightarrow \infty} \left(1 - \frac{\nu t}{n}\right)^{-x} &= 1^{-x} = 1 \\ \lim_{n \rightarrow \infty} \frac{n!}{(n-x)!n^x} &= \frac{n}{n} \frac{(n-1)}{n} \dots \frac{(n-x+1)}{n} = 1 \end{aligned}$$

Por lo tanto, en el límite, como $n \rightarrow \infty$, se obtiene la función de probabilidad de la distribución Poisson:

$$P(x \text{ ocurrencias en } t) = \frac{(\nu t)^x}{x!} e^{-\nu t}$$

Propiedades:

- **F. generadora de momentos:** $M_{X_t}(t) = e^{\lambda(e^t - 1)}$, $\forall t \in \mathbb{R}$
- **Valor esperado:** $\mu_{X_t} = \lambda = \nu t$
- **Varianza:** $\sigma_{X_t}^2 = \lambda = \nu t$
- **c.o.v.:** $\delta_{X_t} = \frac{1}{\sqrt{\lambda}} = \frac{1}{\sqrt{\nu t}}$

R: En R se utiliza `[p,d,r,q]pois(x ,lambda = lambda/nu*t)`

Distribución Exponencial

$X \sim \text{Exponencial}(\nu)$

Se vio anteriormente que en el caso de una secuencia Bernoulli, la probabilidad del tiempo de recurrencia entre eventos es descrito por la distribución Geométrica. Por otra parte, si la ocurrencia de un evento se modela por un proceso Poisson, el tiempo de recurrencia puede ser descrito por la *distribución Exponencial*.

Si X es gobernado por la distribución Exponencial, la función de densidad es

$$f_X(x) \nu e^{-\nu x}, \quad \Theta_X \in [0, \infty)$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = 1 - e^{-\nu x}, \quad \Theta_X \in [0, \infty)$$

Propiedades:

- **Función generadora de momentos:** $M_X(t) = \frac{\nu}{\nu - t}$, $t < \nu$
- **Valor esperado:** $\mu_X = \frac{1}{\nu}$
- **Varianza:** $\sigma_X^2 = \frac{1}{\nu^2}$

- **c.o.v.:** $\delta_X = 1$
- **Skewness:** $\theta_X = 2$
- **Kurtosis:** $\kappa_X = 6$

R: En R se utiliza `[p,d,r,q]exp(x, rate = nu)`

Distribución Exponencial desplazada en a

Se llama trasladada en a si su función de densidad es

$$f_X(x) = \nu e^{-\nu(x-a)}, \quad \Theta_X \in [a, \infty)$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = 1 - e^{-\nu(x-a)}, \quad \Theta_X \in [a, \infty)$$

Propiedades:

- **Función generadora de momentos:** $M_X(t) = \frac{e^{at}\nu}{\nu - t}, \quad t < \nu$
- **Valor esperado:** $\mu_X = \frac{1}{\nu} + a$
- **Varianza:** $\sigma_X^2 = \frac{1}{\nu^2}$
- **c.o.v.:** $\delta_X = \frac{1}{1 + \nu a}$
- **Skewness:** $\theta_X = 2$
- **Kurtosis:** $\kappa_X = 6$

Se puede observar que las medidas de dispersión (exceptuando al coeficiente de variación) no se ven alteradas al desplazar la distribución en a .

Relación Poisson - Exponencial

En un proceso Poisson, se observa que si X_t se describe como:

X_t : Número de eventos estadísticamente independientes entre el intervalo $[0, t]$

$$X_t \sim \text{Poisson}(\nu t)$$

entonces, la variable T_1 puede ser descrita de la siguiente forma:

T_1 : Tiempo transcurrido hasta la ocurrencia del primer evento (o entre cada evento)

por lo tanto, el evento $(T_1 > t)$ significa que en el intervalo $[0, t]$ no ocurre ningún evento, es decir

$$P(T_1 > t) = P(X_t = 0) = \frac{(\nu t)^0 e^{-\nu t}}{0!} = e^{-\nu t}$$

debido a esto, la función de distribución de probabilidad acumulada de T_1 está dada por

$$F_{T_1}(t) = P(T_1 \leq t) = 1 - P(T_1 > t) = 1 - e^{-\nu t}$$

y su función de densidad es

$$f_{T_1}(t) = \frac{d}{dt} F_{T_1}(t) = \nu e^{-\nu t}$$

finalmente se concluye que T_1 distribuye Exponencial de parámetro ν

$$T_1 \sim \text{Exponencial}(\nu)$$

Si la tasa de ocurrencia promedio, ν , es constante, el tiempo promedio de recurrencia, $E(T_1)$, o periodo de retorno para un proceso Poisson es

$$E(T_1) = \frac{1}{\nu}$$

Observación: Aquí hay que tener cuidado con la relación Poisson – Exponencial, utilizando la definición de X_t y T_1 se tiene el siguiente cálculo de probabilidades:

- Si se desea calcular la probabilidad de que el primer evento ocurra después de un tiempo t , entonces se tiene las siguientes dos alternativas:

$$P(T_1 > t) = P(X_t = 0) = e^{-\nu t}$$

- Si se desea calcular la probabilidad de que el primer evento ocurra en un tiempo t , entonces se tiene las siguientes dos alternativas:

$$P(T_1 \leq t) = P(X_t \geq 1) = 1 - e^{-\nu t}$$

para X_t se tiene que es mayor o igual a 1 ya que, aunque el primer evento suceda dentro de un tiempo t , también existe la posibilidad de que haya un segundo evento, un tercero y así, por lo que el evento $(X_t \geq 1)$ incluye todos esos casos.

Propiedad carencia de memoria

Esta distribución tiene la propiedad de la carencia de memoria, es decir, si $T \sim \text{Exponencial}(\nu)$ entonces se tiene que

$$P(T > t + s \mid T > s) = P(T > t)$$

Este resultado permite asumir que todos los tiempos entre eventos Poisson(νt) distribuyen Exponencial(ν).

Demostración: Carencia de memoria

Por definición, esta probabilidad condicionada es:

$$P(T > t + s \mid T > s) = \frac{P[(T > t + s) \cap (T > s)]}{P(T > s)}$$

El evento $(T > t + s)$ representa que la primera ocurrencia sea después de un tiempo $t + s$, mientras que el evento $(T > s)$ representa que la primera ocurrencia se después de un tiempo s , entonces la intersección $(T > t + s) \cap (T > s)$ es la ocurrencia que el primer evento sucede después de un tiempo $t + s$ y s , para que sucedan los dos a la vez entonces el primer evento debe suceder después de $t + s$, por lo tanto:

$$(T > t + s) \cap (T > s) = (T > t + s)$$

finalmente

$$\begin{aligned} P(T > t + s \mid T > s) &= \frac{P(T > t + s)}{P(T > s)} \\ &= \frac{e^{-\nu(t+s)}}{e^{-\nu s}} \\ &= \frac{e^{-\nu t} e^{-\nu s}}{e^{-\nu s}} \\ &= e^{-\nu t} \\ &= P(T > t) \end{aligned}$$

Nota: Este fenómeno ocurre igual con la distribución Geométrica

Distribución Gamma

$X \sim \text{Gamma}(k, \nu)$

En general, la *distribución Gamma* para una variable aleatoria X tiene la siguiente función de densidad

$$f_X(x) = \frac{\nu^k}{\Gamma(k)} x^{k-1} e^{-\nu x}, \quad \Theta_X \in [0, \infty)$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \int_0^x \frac{\nu^k}{\Gamma(k)} x^{k-1} e^{-\nu x} dx$$

Donde ν y k son los parámetros de esta distribución de probabilidad.

Esta distribución contiene a la función Gamma²⁴ $\Gamma(\alpha)$, la cual tiene las siguientes propiedades:

- $\Gamma(\alpha) = \int_0^\infty u^{\alpha-1} e^{-u} du$
- $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$
- $\Gamma(n + 1) = n!$ si $n \in \mathbb{N}_0$
- $\Gamma(1/2) = \sqrt{\pi}$

Propiedades:

- **Función generadora de momentos:** $M_X(t) = \left(\frac{\nu}{\nu - t} \right)^k$, $t < \nu$
- **Valor esperado:** $\mu_X = \frac{k}{\nu}$
- **Varianza:** $\sigma_X^2 = \frac{k}{\nu^2}$
- **c.o.v.:** $\delta_X = \frac{1}{\sqrt{k}}$
- **Relación Exponencial-Gamma**²⁵: Si $k = 1$, entonces $\text{Gamma}(k = 1, \nu) = \text{Exponencial}(\nu)$.

R: En R se utiliza `[p,d,r,q]gamma(x, shape = k, rate = nu)`

Relación Poisson - Gamma: Caso 1

En un proceso Poisson, si se define a la variable X_t como:

X_t : Número de eventos estadísticamente independientes en el intervalo $[0, t]$

$$X_t \sim \text{Poisson}(\nu t)$$

entonces, se puede definir a la variable T_k como:

T_k : Tiempo transcurrido hasta la ocurrencia del k -ésimo evento

T_k está gobernada por la distribución Gamma

$$T_k \sim \text{Gamma}(k, \nu)$$

por lo tanto, el evento $(T_k > t)$ significa que en el intervalo $[0, t]$ ocurren a lo más $k - 1$ eventos, es decir

$$P(T_k > t) = P(X_t \leq k - 1) = \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

Por lo que la función de distribución de probabilidad acumulada es

$$F_{T_k}(t) = 1 - \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

y su función de densidad es

$$f_{T_k}(t) = \frac{d}{dt} F_{T_k}(t) = \frac{\nu^k}{\Gamma(k)} t^{k-1} e^{-\nu t}$$

²⁴La función Gamma que es la generalización de la operación factorial para números no enteros.

²⁵Más adelante se entenderá que la suma de variables Exponenciales reproducen la distribución Gamma

Demostración: Cálculo de la función de densidad de la distribución Gamma

Se tiene que si $k \in \mathbb{N}$, entonces se puede utilizar

$$F_{T_k}(t) = 1 - \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

derivando $F_{T_k}(t)$ se puede obtener $f_{T_k}(t)$

$$\begin{aligned} f_{T_k}(t) &= \frac{d}{dt} F_{T_k}(t) \\ &= \frac{d}{dt} \left[1 - \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!} \right] \\ &= - \sum_{x=0}^{k-1} \frac{d}{dt} \frac{(\nu t)^x e^{-\nu t}}{x!} \\ &= - \sum_{x=0}^{k-1} \frac{x(\nu t)^{x-1} e^{-\nu t} - \nu(\nu t)^x e^{-\nu t}}{x!} \\ &= \frac{(\nu t)^{k-1} \nu e^{-\nu t}}{(k-1)!} \\ &= \frac{\nu^k}{\Gamma(k)} t^{k-1} e^{-\nu t} \end{aligned}$$

Sugerencia: En modalidad de prueba online, esto no tiene mucha utilidad ya que R puede hacer el cálculo directo, en modalidad de prueba presencial se recomienda saber utilizar la función de distribución acumulada de la distribución Poisson para calcular probabilidades de una variable con distribución exponencial, como se mostró anteriormente.

$$F_{T_k}(t) = 1 - F_{X_t}(k-1)$$

La ecuación anterior es válida si $k \in \mathbb{N}$.

Observación: Aquí hay que tener cuidado con la relación Poisson – Gamma, utilizando la definición de X_t y T_k se tiene el siguiente cálculo de probabilidades:

- Si se desea calcular la probabilidad de que el k -ésimo evento ocurra después de un tiempo t , entonces se tiene las siguientes dos alternativas:

$$P(T_k > t) = P(X_t \leq k-1) = \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

- Si se desea calcular la probabilidad de que el k -ésimo evento ocurra en un tiempo t , entonces se tiene las siguientes dos alternativas:

$$P(T_k \leq t) = P(X_t \geq k) = 1 - \sum_{x=0}^{k-1} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

para X_t se tiene que es mayor o igual a k ya que, aunque el k -ésimo evento suceda dentro de un tiempo t , también existe la posibilidad de que ocurra un evento $k+1$, $k+2$ y así, por lo que el evento $(X_t \geq k)$ incluye todos esos casos.

Relación Poisson - Gamma: Caso 2

El caso 2 está relacionada al cálculo de probabilidad entre eventos. En un proceso Poisson, si se define a la variable X_t como:

X_t : Número de intervalos²⁶ entre k eventos en el tiempo t

$$X_t \sim \text{Poisson}(\nu t)$$

entonces, se puede definir a la variable T_k como:

T_k : Tiempo transcurrido entre k eventos

Como entre k eventos hay $k - 1$ intervalos, entonces la distribución de T_k es Gamma

$$T_k \sim \text{Gamma}(k - 1, \nu)$$

El evento $(T_k > t)$ significa que en el tiempo t ocurren como máximo $k - 2$ intervalos, por lo tanto, la probabilidad de que el tiempo entre k eventos sea superior a t es:

$$P(T_k > t) = P(X_t \leq k - 2) = \sum_{x=0}^{k-2} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

La probabilidad de que el tiempo entre k eventos sea t es entonces

$$P(T_k \leq t) = P(X_t > k - 2) = 1 - \sum_{x=0}^{k-2} \frac{(\nu t)^x e^{-\nu t}}{x!}$$

Caso particular: Distribución χ^2

Si X distribuye Gamma con parámetros $k = n/2$ y $\nu = 1/2$, entonces se obtiene la distribución χ^2

$$X \sim \text{Gamma}\left(k = \frac{n}{2}, \nu = \frac{1}{2}\right) \implies X \sim \chi^2(n)$$

Nota: Esta distribución es especialmente útil en los capítulos de inferencia estadística y bondad de ajuste. El parámetro de la distribución chi-cuadrado se denomina *grados de libertad*. En **R** se utiliza el comando `[p,d,r,q]chisq(x, df = n)`.

Distribución Gamma desplazada en γ

Se llama trasladada en γ si su función de densidad es

$$f_X(x) = \frac{\nu^k}{\Gamma(k)} (x - \gamma)^{k-1} e^{-\nu(x-\gamma)}, \quad \Theta_X \in [\gamma, \infty)$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \int_{\gamma}^x \frac{\nu^k}{\Gamma(k)} (x - \gamma)^{k-1} e^{-\nu(x-\gamma)} dx$$

Propiedades:

- **Valor esperado:** $\mu_X = \frac{k}{\nu} + \gamma$
- **Varianza:** $\sigma_X^2 = \frac{k}{\nu^2}$

²⁶Los intervalos es el espacio entre un evento y su evento siguiente.

Relación Exponencial - Gamma

Se puede relacionar la distribución Exponencial con la distribución Gamma de la siguiente forma:

T_i : Tiempo de ocurrencia entre los eventos i e $i + 1$ (tiempo entre cada evento)

$$T_i \sim \text{Exponencial}(\nu)$$

T_n : Tiempo de ocurrencia entre el evento i e $i + n$ (Tiempo entre n eventos)

El evento T_n es la suma de todos los tiempos entre los eventos i e $i + 1$ mas los eventos $i + 1$ e $i + 2$ hasta $i + n - 1$ e $i + n$, es decir:

$$T_n = T_i + T_{i+1} + \cdots + T_{i+n} = \sum_{j=0}^n T_{i+j}$$

Entonces, T_n distribuye Gamma con parámetros $k = n$ y ν .

$$T_n \sim \text{Gamma}(k = n, \nu)$$

Distribución Hipergeométrica

$$X \sim \text{Hipergeométrica}(n, N, m)$$

La *distribución Hipergeométrica* surge cuando las muestras de una población finita, conformada en dos tipos de elementos, están siendo examinados. Es la distribución básica subyacente a muchos planes de muestreos utilizados en relación con el muestreo de aceptación y el control de calidad. Se podría pensar que, si solo hay dos casos, entonces la distribución podría ser binomial, pero en este caso existe un detalle que se mostrará enseguida con relación al tipo de muestreo.

Considere una población finita de N elementos dividida en 2 grupos: m éxitos y $N - m$ fracasos, si se toma una muestra aleatoria de tamaño n al azar, la probabilidad de que x sean éxitos está dada por la función de probabilidad

$$p_X(x) = \frac{\binom{m}{x} \binom{N-m}{n-x}}{\binom{N}{n}}, \quad \Theta_X \in [i, f]$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \sum_{k=i}^x \frac{\binom{m}{k} \binom{N-m}{n-k}}{\binom{N}{n}}, \quad \Theta_X \in [i, f]$$

Donde $i = \max(0, n + m - N)$ y $f = \min(n, m)$

Propiedades:

- **Valor esperado:** $\mu_X = n \cdot \frac{m}{N}$
- **Varianza:** $\sigma_X^2 = \left(\frac{N-n}{N-1}\right) \cdot n \cdot \frac{m}{N} \cdot \left(1 - \frac{m}{N}\right)$

R: En R se utiliza `[d,p,r,q]hyper(x, m = m, n = N-m, k = n)`

Existen 2 casos de muestreo que involucran a la distribución binomial e hipergeométrica:

- **Muestreo con replazo:**
 $X \sim \text{Binomial}(n, p = \frac{m}{N})$

- **Muestreo sin remplazo:**
 $X \sim \text{Hipergeométrica}(n, N, m)$

Se puede determinar (o aproximar) la cantidad de una población N utilizando la siguiente ecuación

$$N = \frac{m \cdot n}{x}$$

Aproximación Hipergeométrica a Binomial

En ciertas ocasiones se desea poder aproximar²⁷ una distribución Hipergeométrica a una Binomial, un motivo puede ser para realizar cálculos rápidos. Se puede aproximar la distribución Hipergeométrica a una Binomial siempre que la muestra seleccionada n no sea mayor a un 5% de la población total N , es decir:

$$\frac{n}{N} \leq 0.05$$

Esta condición asegura que los errores en el cálculo de las probabilidades sea despreciable.

Importancia de definir los éxitos y fracasos

Es importante cómo se definen los éxitos y fracasos en las distribuciones Hipergeométrica y Binomial, ya que la forma de calcular probabilidades puede variar para obtener el mismo resultado.

- **Caso Hipergeométrica:** De una población de N elementos, considerando a m como los éxitos y a $N - m$ como los fracasos (Evento X), al tomar una muestra n al azar, la probabilidad de que existan x éxitos es:

$$p_X(x) = P(X = x) = p$$

El mismo resultado se puede obtener si se define a $N - m$ como los éxitos y a m como los fracasos (evento Y), la probabilidad de obtener x éxitos en la situación anterior es igual a obtener $n - x$ éxitos con la nueva definición:

$$p_Y(n - x) = P(Y = n - x) = p$$

es decir:

$$P(X = x) = P(Y = n - x)$$

En el caso de las probabilidades acumuladas, se cumple lo siguiente:

$$P(X \leq x) = P(Y \geq n - x)$$

$$P(X \geq x) = P(Y \leq n - x)$$

- **Caso Binomial:** Con la distribución Binomial sucede lo mismo que con la distribución Hipergeométrica. Si se realizan n experimentos Bernoulli con una probabilidad de éxitos p y de fracasos $1 - p$ (evento X), la probabilidad de observar x éxitos es:

$$p_X(x) = P(X = x) = p$$

El mismo resultado se obtiene si se define a $1 - p$ como la probabilidad de éxitos y a p como la probabilidad de fracasos (evento Y), entonces, la probabilidad de observar x éxitos de la situación anterior es igual a obtener $n - x$ éxitos con la nueva definición:

$$p_Y(n - x) = P(Y = n - x) = p$$

es decir:

$$P(X = x) = P(Y = n - x)$$

En el caso de las probabilidades acumuladas, se cumple lo siguiente:

$$P(X \leq x) = P(Y \geq n - x)$$

$$P(X \geq x) = P(Y \leq n - x)$$

²⁷Esto es solo una recomendación, no es una regla.

Distribución Beta

$$X \sim \text{Beta}(q, r)$$

Muchas de las distribuciones de probabilidad son para variables aleatorias las cuales sus rango de valores no están limitados en una o ambas direcciones. De hecho, todas las distribuciones de probabilidad continuas que se han visto hasta ahora tienen esta característica. En algunas aplicaciones de ingeniería, puede existir problemas en donde hay finitos valores mínimos y máximos para los límites de la variable aleatoria, en estos casos, distribuciones de probabilidad con límites finitos máximos y mínimos pueden ser apropiadas²⁸.

La *distribución Beta* es una de algunas distribuciones apropiadas para variables aleatorias cuyo rango de posibles valores son acotados, por ejemplo, entre a y b . La función de densidad es

$$f_X(x) = \frac{1}{B(q, r)} \cdot \frac{(x-a)^{q-1}(b-x)^{r-1}}{(b-a)^{q+r-1}}, \quad \Theta_X \in [a, b]$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \int_a^x \frac{1}{B(q, r)} \cdot \frac{(x-a)^{q-1}(b-x)^{r-1}}{(b-a)^{q+r-1}} dx$$

Esta distribución contiene a la función Beta que está dada por

$$B(q, r) = \int_0^1 x^{q-1}(1-x)^{r-1} dx = \frac{\Gamma(q)\Gamma(r)}{\Gamma(q+r)}$$

Propiedades:

- **Valor esperado:** $\mu_X = a + \frac{q}{q+r}(b-a)$
- **Varianza:** $\sigma_X^2 = \frac{qr(b-a)^2}{(q+r)^2(q+r+1)}$
- **Skewness:** $\theta_X = \frac{2(r-q)(b-a)}{\sigma_X(q+r)(q+r+2)}$
- **Moda:** $x_{\text{Moda}} = a + \frac{(1-q)(b-a)}{2-q-r}$

R: En R se utiliza `[d,p,r,q]beta((x-a)/(b-a), shape1 = q, shape2 = r)`

Distribución Beta Estándar

Si el valor mínimo y máximo de la variable están acotados entre $a = 0$ y $b = 1$, entonces se tiene la *distribución Beta Estándar*, la función de densidad es

$$f_X(x) = \frac{1}{B(q, r)} x^{q-1}(1-x)^{r-1}, \quad \Theta_X \in [0, 1]$$

Este caso específico para la distribución Beta es generalmente utilizado cuando la variable aleatoria X representa, por ejemplo, la probabilidad de ocurrencia de algún fenómeno, como una probabilidad es un número entre 0 y 1, entonces se puede ajustar bien a una distribución Beta Estándar.

²⁸Si se tiene un conjunto de datos donde exista un mínimo y máximo finitos, esto no significa que solo se pueden ajustar a distribuciones de probabilidad con soportes finitos, depende de la calidad del ajuste se pueden representar estos datos con una distribución con soporte no limitado, saber si que distribución de probabilidad ajusta mejor a una serie de datos se verá en el capítulo de *Bondad de Ajuste* mas adelante.

Distribución Weibull

$$X \sim \text{Weibull}(\eta, \beta)$$

Si la variable X está gobernada por la *distribución Weibull*, entonces la función de densidad es

$$f_X(x) = \frac{\beta}{\eta} \left(\frac{x}{\eta}\right)^{\beta-1} \exp\left[-\left(\frac{x}{\eta}\right)^\beta\right], \quad \Theta_X \in (0, \infty)$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = 1 - \exp\left[-\left(\frac{x}{\eta}\right)^\beta\right], \quad \Theta_X \in (0, \infty)$$

Donde $\beta > 0$ es un parámetro de forma y $\eta > 0$ es un parámetro de escala.

Relación Percentil-Probabilidad

Si x_p es el percentil $p \times 100\%$, entonces existe una relación entre ambos valores que se muestra a continuación

$$\begin{aligned}\Phi_{\text{Weibull}}^{-1}(p) &= \ln[-\ln(1-p)] \\ \ln(x_p) &= \ln(\eta) + \frac{1}{\beta} \cdot \Phi_{\text{Weibull}}^{-1}(p)\end{aligned}$$

Observación: Mediante esta ecuación para calcular un percentil x_p es posible determinar los parámetros de β y η de acuerdo a percentiles dados.

Propiedades:

- **Función generadora de momentos:** $M_X(t) = \sum_{n=0}^{\infty} \frac{t^n \eta^n}{n!} \Gamma\left(1 + \frac{n}{\beta}\right)$
- **m-ésimo momento:** $E(X^m) = \eta^m \Gamma\left(1 + \frac{m}{\beta}\right)$
- **Valor esperado:** $\mu_X = \eta \Gamma\left(1 + \frac{1}{\beta}\right)$
- **Varianza:** $\sigma_X^2 = \eta^2 \left[\Gamma\left(1 + \frac{2}{\beta}\right) - \Gamma^2\left(1 + \frac{1}{\beta}\right) \right]$
- **Moda:** $x_{\text{Moda}} = \eta \left(\frac{\beta-1}{\beta}\right)^{1/\beta}$
- **Relación Weibull-Exponencial:** Si $\beta = 1$, entonces $\text{Weibull}(\eta, \beta = 1) = \text{Exponencial}(\eta)$.

R: En R se utiliza `[d,p,r,q]weibull(x, shape = beta, scale = eta)`

Distribución Logística

$$X \sim \text{Logística}(\mu, \sigma)$$

Si X está gobernada por la *distribución Logística*, entonces su función de densidad es

$$f_X(x) = \frac{1}{\sigma} \phi_{\text{Logística}}\left(\frac{x-\mu}{\sigma}\right), \quad \Theta_X \in \mathbb{R}$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \Phi_{\text{Logística}}\left(\frac{x - \mu}{\sigma}\right), \quad \Theta_X \in \mathbb{R}$$

Donde

$$\Phi_{\text{Logística}}(z) = \frac{\exp(z)}{1 + \exp(z)}$$

$$\phi_{\text{Logística}}(z) = \frac{\exp(z)}{(1 + \exp(z))^2}$$

Esta distribución es la base para la *Regresión Logística* y determinados tipos de redes neuronales, pero esto no es tema de este curso.

Relación Percentil-Probabilidad

Si x_p es el percentil $p \times 100\%$, entonces se tiene la siguiente relación

$$\Phi_{\text{Logística}}^{-1}(p) = \log\left(\frac{p}{1-p}\right)$$

$$x_p = \mu + \sigma \Phi_{\text{Logística}}^{-1}(p)$$

Observación: Mediante esta ecuación para calcular un percentil x_p es posible determinar los parámetros de μ y σ de acuerdo a percentiles dados.

Propiedades:

- **Valor esperado:** $\mu_X = \mu$
- **Varianza:** $\sigma_X^2 = \frac{\sigma^2 \pi^2}{3}$

R: En R se utiliza `[d,p,r,q]logis(x, location = mu, scale = sigma)`

Distribución Log-Logística

$X \sim \text{Log-Logística}(\mu, \sigma)$

Si X está gobernado por la *distribución Log-Logística*, entonces su función de densidad es

$$f_X(x) = \frac{1}{\sigma x} \phi_{\text{Logística}}\left(\frac{\ln(x) - \mu}{\sigma}\right), \quad \Theta_X \in (0, \infty)$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \Phi_{\text{Logística}}\left(\frac{\ln(x) - \mu}{\sigma}\right), \quad \Theta_X \in (0, \infty)$$

donde μ es un parámetro de escala y $\sigma > 0$ es un parámetro de forma.

Relación Percentil-Probabilidad

Si x_p es el percentil $p \times 100\%$, entonces

$$\ln(x_p) = \mu + \sigma \Phi_{\text{Logística}}^{-1}(p)$$

Observación: Mediante esta ecuación para calcular un percentil x_p es posible determinar los parámetros de μ y σ de acuerdo a percentiles dados.

Propiedades:

- **M-ésimo momento:** $E(X^m) = e^{m\mu}\Gamma(1+m\sigma)\Gamma(1-m\sigma)$, si $m\sigma > 1$.
- **Valor esperado:** $\mu_X = e^\mu\Gamma(1+\sigma)\Gamma(1-\sigma)$, si $\sigma < 1$.
- **Varianza:** $\sigma_X^2 = e^{2\mu}[\Gamma(1+2\sigma)\Gamma(1-2\sigma) - \Gamma^2(1+\sigma)\Gamma^2(1-\sigma)]$, si $\sigma < 1/2$.

R: En R se utiliza:

- `plogis((log(x)-mu)/sigma, location = 0, scale = 1)` (Para probabilidad acumulada)
- `dlogis((log(x)-mu)/sigma, location = 0, scale = 1)/(x*sigma)` (Para densidad de probabilidad)

Distribución t-Student

$X \sim \text{t-Student}(\nu)$

La *distribución t-Student* es una distribución de probabilidad que surge del problema de estimar la media²⁹ de una población normalmente distribuida cuando el tamaño de muestra es pequeño y la desviación estándar poblacional³⁰ es desconocida.

Si X está gobernada por la distribución t-Student, entonces su función de densidad es

$$f_X(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\pi\nu} \Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \quad \Theta_X \in \mathbb{R}$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \int_{-\infty}^x \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\pi\nu} \Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}} dx$$

Propiedades:

- **Valor esperado:** $\mu_X = 0$, si $\nu > 1$.
- **Varianza:** $\sigma_X^2 = \frac{\nu}{\nu-2}$, si $\nu > 2$.
- **Relación Normal-t-Student:** Si $\nu \rightarrow \infty$, entonces $\text{t-Student}(\nu \rightarrow \infty) \rightarrow \text{Normal}(0, 1)$
- **Kurtosis:** $\kappa_X = \frac{6}{\nu-4}$, si $\nu > 4$.

R: En R se utiliza `[d,p,r,q]t(x, df = nu)`

Distribución Fisher

$X \sim \text{Fisher}(\eta, \nu)$

La *distribución Fisher* es una distribución de probabilidad que surge del problema de querer analizar las varianzas de dos poblaciones y/o la varianza de un modelo de regresión lineal.

Si X está gobernada por la distribución Fisher, entonces su función de distribución es

²⁹Esta distribución y la distribución Fisher toman relevancia en los capítulos de *Inferencia Estadística y Regresión Lineal*.

³⁰La desviación estándar **poblacional** es σ y proviene de la distribución Normal, la desviación estándar **muestral** es S y proviene de los datos de una muestra, en general, $\sigma \neq S$.

$$f_X(x) = \frac{\Gamma\left(\frac{\eta+\nu}{2}\right)}{\Gamma\left(\frac{\eta}{2}\right)\Gamma\left(\frac{\nu}{2}\right)} \left(\frac{\eta}{\nu}\right)^{\frac{\eta}{2}} \frac{x^{\frac{\eta}{2}-1}}{\left(\frac{\eta}{\nu}x + 1\right)^{\frac{\eta+\nu}{2}}}, \quad \Theta_X > 0$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \int_0^x \frac{\Gamma\left(\frac{\eta+\nu}{2}\right)}{\Gamma\left(\frac{\eta}{2}\right)\Gamma\left(\frac{\nu}{2}\right)} \left(\frac{\eta}{\nu}\right)^{\frac{\eta}{2}} \frac{x^{\frac{\eta}{2}-1}}{\left(\frac{\eta}{\nu}x + 1\right)^{\frac{\eta+\nu}{2}}} dx$$

Propiedades:

- **Valor esperado:** $\mu_X = \frac{\nu}{\nu - 2}$, si $\nu > 2$
- **Varianza:** $\sigma_X^2 = \frac{2\nu^2(\eta + \nu - 2)}{\eta(\nu - 2)^2(\nu - 4)}$, si $\nu > 4$

R: En R se utiliza `[d,p,r,q]f(x, df1 = eta, df2 = nu)`

Distribución Uniforme Discreta

$X \sim \text{Uniforme}(x_1, \dots, x_n)$

La *distribución Uniforme Discreta* surge cuando se tiene que la variable se comporta de forma discreta y cualquier valor tiene la misma probabilidad de ser obtenido.

Si X es gobernada por la distribución Uniforme Discreta, entonces su función de probabilidad es

$$p_X(x) = \begin{cases} \frac{1}{n}, & x = x_1, x_2, \dots, x_n \\ 0, & \text{En otro caso} \end{cases}$$

Propiedades:

- **Valor esperado:** $\mu_X = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$
- **Varianza:** $\sigma_X^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_X)^2$
- **N-ésimo momento:** $E(X^n) = \frac{1}{n} \sum_{i=1}^n x_i^n$
- **Función generadora de momentos:** $M_X(t) = \frac{1}{n} \sum_{i=1}^n e^{tx_i}$

Distribución Uniforme Continua

$X \sim \text{Uniforme}(a, b)$

La *distribución Uniforme Continua*, o solamente Uniforme, surge cuando la variable aleatoria tiene un comportamiento continuo y cada valor tiene la misma probabilidad de ser obtenido.

Si X está gobernado por la distribución Uniforme, entonces su función de densidad es

$$f_X(x) = \frac{1}{b - a} \quad \Theta_X \in [a, b]$$

Su función de distribución de probabilidad acumulada es

$$F_X(x) = \frac{x-a}{b-a} \quad \Theta_X \in [a, b]$$

Propiedades:

- **Función generadora de momentos:** $M_X(t) = \frac{e^{tb} - e^{ta}}{t(b-a)}$, si $t \in \mathbb{R}$
- **N-ésimo momento:** $E(X^n) = \frac{b^{n+1} - a^{n+1}}{(n+1)(b-a)}$, si $n \in \mathbb{N}$.
- **Valor esperado:** $\mu_X = \frac{a+b}{2}$
- **Varianza:** $\sigma_X^2 = \frac{(b-a)^2}{12}$

R: En R se utiliza `[d,p,r,q]unif(x, min = a, max = b)`

Distribuciones de Probabilidad Desplazadas

Al introducir a la distribución Exponencial y la distribución Gamma se pudo observar sus versiones desplazadas, esta idea se puede generalizar a cualquier distribución de probabilidad.

Sea X un fenómeno aleatorio con una distribución de probabilidad **desplazada** y sea Y una variable aleatoria con la misma distribución pero sin desplazamiento, entonces, la relación entre X e Y es la siguiente:

$$X = Y + \alpha$$

con $\alpha \in \mathbb{R}$ el desplazamiento. La distribución de X en función de la distribución de Y es la siguiente (ver capítulo 3: Funciones de Variables Aleatorias):

$$f_X(x) = f_Y(x - \alpha) \quad \text{o} \quad p_X(x) = p_Y(x - \alpha)$$

$$F_X(x) = F_Y(x - \alpha)$$

Medidas estadísticas como la media, moda, mediana y coeficiente de variación **SI** se ven alteradas por el desplazamiento, pero medidas como la varianza, desviación estándar, rango e IQR **NO** se ven alteradas por el desplazamiento.

- **Media:** $E(X) = E(Y) + \alpha$
- **Mediana:** $x_{med} = y_{med} + \alpha$
- **Moda:** $x_{Moda} = y_{Moda} + \alpha$
- **Varianza:** $\text{Var}(X) = \text{Var}(Y)$

Ejemplo: Calculo de probabilidades con distribuciones desplazadas

El tiempo de desplazamiento entre su casa y el campus San Joaquín se puede modelar mediante 2 distribuciones, Normal y Log-Normal, las dos trasladadas. Usted desea evaluar la probabilidad que, en un día cualquiera, el tiempo que le toma de llegar desde su casa hasta el campus sea más de 30 minutos.

Para evaluar la probabilidad, utiliza la información obtenida en los viajes previos, la cual se presenta a continuación:

Min.	Median	Mean	Max.
6	18	20	73

Nota: Para la Normal considere la media y mediana igual a 20 y una desviación estándar de 5 min.

Solución:

Sea T el tiempo entre su casa y el campus San Joaquín.

Distribución Normal: Se tiene que la distribución Normal trasladada es:

$$T \sim \text{Normal}(\mu, \sigma, \alpha)$$

con α el desplazamiento. Sea X una variable aleatoria auxiliar con distribución Normal sin trasladar, $X \sim \text{Normal}(\mu, \sigma)$, por lo que $T = X + \alpha$. Mediante los datos proporcionados se tiene que:

$$\alpha = \text{Min.} = 6$$

Se debe encontrar μ y σ , para eso se tiene lo siguiente:

$$E(T) = E(X) + \alpha = \mu + 6 = \text{Mean} \longrightarrow \mu = \text{Mean} - 6 = 20 - 6 = 14$$

$$\text{Var}(T) = \text{Var}(X) = \sigma^2 = 5^2 \longrightarrow \sigma = 5$$

Entonces,

$$T \sim \text{Normal}(\mu = 14, \sigma = 5, \alpha = 6)$$

Se pide $P(T > 30)$:

$$\begin{aligned} P(T > 30) &= P(T - \alpha > 30 - \alpha) \\ &= P(X > 30 - \alpha) \\ &= P(X > 30 - 6) \\ &= P(X > 24) \\ &= 1 - P(X \leq 24) \\ &= 0.02275013 \end{aligned}$$

Distribución Log-Normal: Se tiene que la distribución Log-Normal trasladada es:

$$T \sim \text{Log-Normal}(\lambda, \zeta, \alpha)$$

con α el desplazamiento. Sea X una variable aleatoria auxiliar con distribución Normal sin trasladar, $X \sim \text{Log-Normal}(\lambda, \zeta)$, por lo que $T = X + \alpha$. Mediante los datos proporcionados se tiene que:

$$\alpha = \text{Min.} = 6$$

Se debe encontrar λ y ζ , para eso se tiene lo siguiente:

$$t_{med} = x_{med} + \alpha = e^\lambda + \alpha = \text{Median} \longrightarrow \lambda = \ln(\text{Median} - \alpha) = \ln(18 - 6) = \ln(12) = 2.48491$$

$$E(T) = E(X) + \alpha = \exp\left(\lambda + \frac{\zeta^2}{2}\right) + \alpha = \text{Mean} \longrightarrow \zeta = \sqrt{2 \ln(\text{Mean} - \alpha) - 2\lambda} = 0.555249$$

Entonces:

$$T \sim \text{Log-Normal}(\lambda = 2.48491, \zeta = 0.5552, \alpha = 6)$$

Se pide $P(T > 30)$:

$$\begin{aligned} P(T > 30) &= P(T - \alpha > 30 - \alpha) \\ &= P(X > 30 - \alpha) \\ &= P(X > 30 - 6) \\ &= P(X > 24) \\ &= 1 - P(X \leq 24) \\ &= 0.1059519 \end{aligned}$$

Múltiples variables aleatorias

Los conceptos definidos para una variable aleatoria se pueden extender a dos o mas con la correspondientes distribución de probabilidades conjunta

$$(X = x, Y = y) = (X = x \cap Y = y) = (A \cap B)$$

$$(X_1 = x_1, \dots, X_n = x_n) = \left[\bigcap_{i=1}^n (X_i = x_i) \right] = \left(\bigcap_{i=1}^n A_i \right)$$

Distribución de probabilidad conjunta

Para el par de variables X e Y se define la función de probabilidad acumulada como

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$$

la cual satisface la axiomática fundamental de probabilidades:

- $F_{X,Y}(-\infty, -\infty) = 0 \rightarrow P(\phi \cap \phi)$
- $F_{X,Y}(-\infty, y) = 0 \rightarrow P(\phi \cap A)$
- $F_{X,Y}(x, -\infty) = 0 \rightarrow P(B \cap \phi)$
- $F_{X,Y}(x, \infty) = F_X(x) \rightarrow P(B \cap S)$
- $F_{X,Y}(\infty, y) = F_Y(y) \rightarrow P(S \cap A)$
- $F_{X,Y}(\infty, \infty) = 1 \rightarrow P(S \cap S)$

Variables aleatorias discretas

Si X e Y son discretas, entonces la función de distribución de probabilidad conjunta es

$$p_{X,Y}(x, y) = P(X = x, Y = y)$$

Su función de distribución de probabilidad acumulada es

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{X,Y}(x_i, y_j)$$

con $(x_i, y_j) \in \Theta_{X,Y}$.

Además

$$P(a \leq X \leq b, c \leq Y \leq d) = \sum_{x=a}^b \sum_{y=c}^d p_{X,Y}(x, y)$$

Variables aleatorias continuas

Si X e Y son continuas, entonces la función de densidad de probabilidad conjunta se define como

$$f_{X,Y}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y)$$

donde $F_{X,Y}(x, y)$ es la función de distribución de probabilidad acumulada

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) \, dv du$$

con $(x, y) \in \Theta_{X,Y}$.

Además

$$P(a \leq X \leq b, c \leq Y \leq d) = \int_a^b \int_c^d f_{X,Y}(x, y) \, dx dy$$

Distribuciones Marginales

La distribución marginal de una variable aleatoria se puede obtener utilizando la distribución conjunta y gracias al *teorema de probabilidades totales*.

Caso discreto

La distribución marginal de X , $p_X(x)$, es

$$p_X(x) = \sum_{y \in \Theta_{X,Y}} p_{X,Y}(x, y)$$

La distribución marginal de Y , $p_Y(y)$, es

$$p_Y(y) = \sum_{x \in \Theta_{X,Y}} p_{X,Y}(x, y)$$

Caso continuo

La función de densidad marginal de X , $f_X(x)$, es

$$f_X(x) = \int_{y \in \Theta_{X,Y}} f_{X,Y}(x, y) \, dy$$

La función de densidad marginal de Y , $f_Y(y)$, es

$$f_Y(y) = \int_{x \in \Theta_{X,Y}} f_{X,Y}(x, y) \, dx$$

Distribuciones Condicionales

Sean X , Y variables aleatoria, la probabilidad de ($X = x$) condicionado a ($Y = y$) tiene asociada una función de distribución de probabilidad condicional, que es la siguiente

$$P(X = x \mid Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)} = \frac{\text{Probabilidad Conjunta}}{\text{Probabilidad Marginal}}$$

Probabilidad condicional: Caso discreto

La función de distribución de probabilidad condicional de X dado a la ocurrencia previa de $Y = y$ es

$$p_{X|Y=y}(x) = \frac{p_{X,Y}(x, y)}{p_Y(y)}$$

La función de distribución de probabilidad condicional de Y dado la ocurrencia previa de $X = x$ es

$$p_{Y|X=x}(y) = \frac{p_{X,Y}(x, y)}{p_X(x)}$$

Probabilidad condicional: Caso continuo

La función de densidad condicional de X dado la ocurrencia previa de $Y = y$ es

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

La función de densidad condicional de Y dado la ocurrencia previa de $X = x$ es

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

Distribuciones Marginales mediante Condicionales

Se pueden calcular las distribuciones marginales mediante distribuciones condicionales utilizando el teorema de probabilidades totales de la siguiente forma.

Distribución marginal: Caso discreto

La distribución marginal de X , $p_X(x)$, es

$$p_X(x) = \sum_{y \in \Theta_{X,Y}} p_{X|Y=y}(x) \cdot p_Y(y)$$

La distribución marginal de Y , $p_Y(y)$, es

$$p_Y(y) = \sum_{x \in \Theta_{X,Y}} p_{Y|X=x}(y) \cdot p_X(x)$$

Distribución marginal: Caso continuo

La función de densidad marginal de X , $f_X(x)$, es

$$f_X(x) = \int_{y \in \Theta_{X,Y}} f_{X|Y=y}(x) \cdot f_Y(y) dy$$

La función de densidad marginal de Y , $f_Y(y)$, es

$$f_Y(y) = \int_{x \in \Theta_{X,Y}} f_{Y|X=x}(y) \cdot f_X(x) dx$$

Caso mixto

Si X es discreta e Y es continua, entonces las respectivas marginales son

$$p_X(x) = \int_{y \in \Theta_{X,Y}} p_{X|Y=y}(x) \cdot f_Y(y) dy$$

$$f_Y(y) = \sum_{x \in \Theta_{X,Y}} f_{Y|X=x}(y) \cdot p_X(x)$$

Soportes Conjuntos y Condicionales

Es importante saber definir correctamente el soporte de las variables conjuntas y condicionadas para obtener resultados correctos.

Sea X e Y dos variables aleatorias con soportes $\Theta_X \in [a, b]$ y $\Theta_Y \in [c, d]$, entonces el soporte conjunto del par aleatorio X e Y es aquél subconjunto de intersección entre ambos soportes. Suponiendo que los soportes mostrados anteriormente coinciden, entonces:

$$\Theta_{X,Y} = \{(x, y) \in \mathbb{R}^2 \mid a \leq x \leq b, c \leq y \leq d\}$$

El soporte de las variables condicionadas es el mismo que el de las variables conjuntas pero fijando el valor a la variable que se está condicionando (el evento previo). Los soportes de las variables condicionadas $X|Y = y$ y $Y|X = x$ son los siguientes:

$$\Theta_{X|Y=y} = \{(x, y) \in \mathbb{R}^2 \mid a \leq x \leq b, y = y\}$$

$$\Theta_{Y|X=x} = \{(x, y) \in \mathbb{R}^2 \mid x = x, c \leq y \leq d\}$$

Nota: Es importante tener cuidado en la siguiente notación ya que no siempre es válido la igualdad:

$$x \in \Theta_X \neq x \in \Theta_{X,Y}$$

$$y \in \Theta_Y \neq y \in \Theta_{X,Y}$$

Ejemplo: Modificación del parámetro λ de un modelo Poisson

Considerando una autopista concesionada y un p rtico TAG en particular. Datos hist ricos indican que el $p \times 100\%$ de los autom viles adulteran su placa patente para no pagar TAG. Suponiendo que en promedio pasan en una hora ν autom viles seg n un proceso de Poisson.

Proponer una distribuci n conjunta para las siguientes variables aleatorias:

- X_t : N mero de veh culos que pasan en t horas por el p rtico.
- Y_t : N mero de veh culos que pasan con patente adulterada en t horas por el p rtico.

Adem s, determine la distribuci n de Y_t .

Soluci n:

Por enunciado, la distribuci n de X_t es Poisson con par metro ν a determinar, utilizando el valor esperado se obtiene:

$$E(X_t) = \lambda = \nu \times 1 \text{ hora} = \nu \text{ veh culos}$$

$$\nu = \nu \frac{\text{veh culos}}{\text{hora}}$$

$$X_t \sim \text{Poisson}(\nu t)$$

Suponiendo que en t horas pasan x veh culos por el p rtico, analizando cada veh culo que pasa se puede determinar si hay fraude o no, entonces, el n mero de veh culos que hacen fraude ( xito) dado una cantidad x de veh culos en total que pasaron por el p rtico (experimentos Bernoulli) es un evento condicionado y se escribe de la siguiente forma:

$$Y_t | X_t = x \sim \text{Binomial}(n = x, p)$$

La distribuci n conjunta de X_t e Y_t es la siguiente

$$\begin{aligned} p_{X_t, Y_t}(x, y) &= p_{Y_t | X_t = x}(y) \cdot p_X(x) \\ &= \binom{x}{y} p^y (1-p)^{x-y} \cdot \frac{(\nu t)^x e^{-\nu t}}{x!} \end{aligned}$$

El soporte condicionado de $Y_t | X_t = x$, al ser una distribuci n Binomial, es el siguiente:

$$\Theta_{Y_t | X_t = x} = \{(x, y) \in \mathbb{R}^2 \mid x = x, 0 \leq y \leq x\}$$

Es decir, los valores de y dado un valor fijo de x donde la distribuci n est  definida var an desde la recta $y = 0$ hasta la recta $y = x$, por lo tanto, el soporte conjunto de X e Y son todos los valores de x desde $x = y$ hasta $x = \infty$ y todos los valores de y desde $y = 0$ hasta $y = x$:

$$\Theta_{X_t, Y_t} = \{(x, y) \in \mathbb{R}^2 \mid y \leq x < \infty, 0 \leq y \leq x\}$$

La distribuci n de Y_t se obtiene de la siguiente forma:

$$\begin{aligned} p_{Y_t}(y) &= \sum_{x \in \Theta_{X_t, Y_t}} p_{Y_t | X_t = x}(y) \cdot p_{X_t}(x) \\ &= \sum_{x=y}^{\infty} \binom{x}{y} p^y (1-p)^{x-y} \cdot \frac{(\nu t)^x e^{-\nu t}}{x!} \\ &= \sum_{x=y}^{\infty} \frac{x!}{y!(x-y)!} p^y (1-p)^{x-y} \cdot \frac{(\nu t)^x e^{-\nu t}}{x!} \\ &= \frac{p^y e^{-\nu t}}{y!} \sum_{x=y}^{\infty} \frac{x!}{(x-y)!} (1-p)^{x-y} \cdot \frac{(\nu t)^x}{x!} \quad (z = x - y) \\ &= \frac{p^y e^{-\nu t} (\nu t)^y}{y!} \sum_{z=0}^{\infty} \frac{(1-p)^z (\nu t)^z}{z!} \quad \left(\sum_{k=0}^{\infty} \frac{\alpha^k}{k!} = e^\alpha \right) \\ &= \frac{p^y e^{-\nu t} (\nu t)^y}{y!} \cdot e^{(1-p)\nu t} = \frac{e^{-\nu p t} (\nu p t)^y}{y!} \end{aligned}$$

Es decir, Y_t distribuye Poisson con parámetro $\lambda = \nu pt$.

$$Y_t \sim \text{Poisson}(\nu pt)$$

Este resultado se puede generalizar de la siguiente forma:

Sea X_t una variable aleatoria que sigue un proceso Poisson y modela la ocurrencia de un cierto evento con una tasa ν por unidad de tiempo, además; Sea Y_t una variable aleatoria que modela la ocurrencia de un éxito o sub-eventos asociados al evento en X_t con una probabilidad p de que ocurra dicho éxito o sub-evento, entonces, Y_t distribuye Poisson de parámetro $\lambda = \nu pt$:

$$X_t \sim \text{Poisson}(\nu t) \longrightarrow Y_t \sim \text{Poisson}(\nu pt)$$

Lo que en realidad hace Y_t es que de la tasa de ocurrencia ν total, al ser multiplicada por p se realiza una selección de los casos favorables, por lo que νp es la tasa de ocurrencia de éxitos o sub-eventos. Como se acaba de demostrar, esto se debe a la existencia del evento condicionado $Y_t|X_t = x \sim \text{Binomial}(x, p)$.

Independencia entre variables aleatorias

Los conceptos de independencia vistos anteriormente también pueden ser aplicados a las variables aleatorias.

Si X e Y son independientes, entonces se cumple lo siguiente:

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y)$$

$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$$

Otra manera de verlo es

$$p_{X|Y=y}(x) = p_X(x) \quad p_{Y|X=x}(y) = p_Y(y)$$

$$f_{X|Y=y}(x) = f_X(x) \quad f_{Y|X=x}(y) = f_Y(y)$$

En términos de probabilidades acumuladas

$$F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y)$$

$$P(X \leq x, Y \leq y) = P(X \leq x) \cdot P(Y \leq y)$$

La independencia es un concepto muy importante al tratar con variables aleatorias, la presencia o ausencia de ésta puede generar cambios significativos en el comportamiento de un suceso aleatorio conjunto.

Normal Bivariada

Dos variables aleatorias X e Y tienen distribución conjunta Normal-Bivariada si su función de densidad conjunta está dada por

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp \left[-\frac{1}{2(1-\rho^2)} \left[\left(\frac{x-\mu_X}{\sigma_X} \right)^2 + \left(\frac{y-\mu_Y}{\sigma_Y} \right)^2 - 2\rho \left(\frac{x-\mu_X}{\sigma_X} \right) \left(\frac{y-\mu_Y}{\sigma_Y} \right) \right] \right]$$

A partir de esto se puede deducir cómo distribuyen X e Y por separado y cual es la distribución de la variable condicionada $Y|X = x$:

$$X \sim \text{Normal}(\mu_X, \sigma_X) \quad Y \sim \text{Normal}(\mu_Y, \sigma_Y)$$

$$Y|X = x \sim \text{Normal} \left(\mu_Y + \frac{\rho\sigma_Y}{\sigma_X}(x - \mu_X), \sigma_Y\sqrt{1-\rho^2} \right)$$

Una notación para la normal bivariada es la siguiente

$$(X, Y) \sim N_2(\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho)$$

$$(X, Y) \sim N_2\left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \rho \sigma_X \sigma_Y \\ \rho \sigma_X \sigma_Y & \sigma_Y^2 \end{bmatrix}\right)$$

donde ρ es una parámetro de asociación llamado correlación (se verá en los siguientes temas). La función de densidad conjunta se puede reescribir como

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sqrt{\det\Sigma}} \exp\left(-\frac{1}{2} \mu^T \Sigma^{-1} \vec{\mu}\right)$$

donde $\vec{\mu} = \begin{bmatrix} x - \mu_X \\ y - \mu_Y \end{bmatrix}$ y $\Sigma = \begin{bmatrix} \sigma_X^2 & \rho \sigma_X \sigma_Y \\ \rho \sigma_X \sigma_Y & \sigma_Y^2 \end{bmatrix}$.

R: El código en R para utilizar la distribución Normal Bivariada se encuentra en el capítulo *Laboratorio: Uso de R* de este documento.

Normal Bivariada Estándar

Se dice que X e Y distribuyen conjunta Normal-Bivariada Estándar si su función de densidad es

$$(X, Y) \sim N_2(0, 0, 1, 1, \rho)$$

$$(X, Y) \sim N_2\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}\right)$$

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2(1-\rho^2)} (x^2 + y^2 - 2\rho xy)\right]$$

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sqrt{\det\Sigma}} \exp\left(-\frac{1}{2} \mu_0^T \Sigma^{-1} \vec{\mu}_0\right)$$

donde $\vec{\mu}_0 = \begin{bmatrix} x \\ y \end{bmatrix}$ y $\Sigma = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}$

Covarianza

En ciertas ocasiones las variables aleatorias X e Y pueden tener alguna relación, en particular, la presencia o ausencia de relación estadística lineal se determina observando el primer momento conjunto de X e Y definido como

$$E(XY) = \begin{cases} \iint_{(x,y) \in \Theta_{X,Y}} xy \cdot f_{X,Y}(x, y) \, dx dy, & \text{(Caso continuo)} \\ \sum_{(x,y) \in \Theta_{X,Y}} xy \cdot p_{X,Y}(x, y), & \text{(Caso discreto)} \end{cases}$$

Si X e Y son estadísticamente independientes, entonces

$$E(XY) = E(X) \cdot E(Y)$$

La **covarianza** corresponde al segundo momento central y se define como

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(XY) - \mu_X \mu_Y$$

Si X e Y son estadísticamente independientes, entonces

$$\text{Cov}(X, Y) = 0$$

Algunas características son:

- Si $\text{Cov}(X, Y)$ es grande y positivo, los valores de X e Y tienden a ser grandes o pequeños en relación a sus medias.
- Si $\text{Cov}(X, Y)$ es grande y negativo, los valores de X tienden a ser grandes con respecto a su media, mientras que los de Y tienden a ser pequeños y viceversa.
- Si $\text{Cov}(X, Y)$ es pequeña o cero, la relación lineal entre X e Y es poca o nula, o bien la relación es **no** lineal.

Correlación

En la mayoría de los casos es preferible normalizar la covarianza, esto resulta en una nueva medida llamada **correlación**, que al igual que la covarianza sirve para poder cuantificar la magnitud de la relación entre dos variables.

La correlación está definida como

$$\text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Este coeficiente toma valores en el intervalo $(-1, 1)$.

Esperanza Condicional

El valor esperado de una variable aleatoria Y condicionado a la realización x de una variable aleatoria X está dado por

$$E(Y|X=x) = \begin{cases} \sum_{y \in \Theta_{Y|X=x}} y \cdot p_{Y|X=x}(y) & \text{Caso Discreto} \\ \int_{y \in \Theta_{Y|X=x}} y \cdot f_{Y|X=x}(y) dy & \text{Caso Continuo} \end{cases}$$

Si se tiene una función de Y , $h(Y)$, el valor esperado condicional está dado por

$$E[h(Y)|X=x] = \begin{cases} \sum_{y \in \Theta_{Y|X=x}} h(y) \cdot p_{Y|X=x}(y) & \text{Caso Discreto} \\ \int_{y \in \Theta_{Y|X=x}} h(y) \cdot f_{Y|X=x}(y) dy & \text{Caso Continuo} \end{cases}$$

Teorema de probabilidades totales para valor esperado

Si se desea conocer la esperanza de una variable X y se dispone de la información de la distribución de la variable condicionada $X|Y=y$ y de la distribución de la variable Y , entonces se debe calcular lo siguiente dependiendo de la naturaleza de cada distribución de probabilidad:

$$E(X) = \begin{cases} \sum_{y \in \Theta_Y} \left[\sum_{x \in \Theta_{X|Y=y}} x \cdot p_{X|Y=y}(x) \right] p_Y(y) & \text{Caso Discreto-Discreto} \\ \int_{y \in \Theta_Y} \left[\int_{x \in \Theta_{X|Y=y}} x \cdot f_{X|Y=y}(x) dx \right] f_Y(y) dy & \text{Caso Continuo-Continuo} \\ \int_{y \in \Theta_Y} \left[\sum_{x \in \Theta_{X|Y=y}} x \cdot p_{X|Y=y}(x) \right] f_Y(y) dy & \text{Caso Discreto-Continuo} \\ \sum_{y \in \Theta_Y} \left[\int_{x \in \Theta_{X|Y=y}} x \cdot f_{X|Y=y}(x) dx \right] p_Y(y) & \text{Caso Continuo-Discreto} \end{cases}$$

Teorema de la Esperanza Iterada

Si se desea conocer el valor esperado de una función de Y , $g(Y)$, sin ser necesario calcular primero la función de densidad o probabilidad, entonces se puede utilizar el siguiente resultado derivado del teorema de probabilidades totales para valor esperado:

$$\begin{aligned} E(g(Y)) &= E[E(g(Y)|X)] \\ \text{Var}(g(Y)) &= \text{Var}[E(g(Y)|X)] + E[\text{Var}(g(Y)|X)] \end{aligned}$$

Debido a la naturaleza de la esperanza y varianza, sea $\alpha \in \mathbb{R}$ una constante, entonces:

$$\begin{aligned} E(\alpha X) &= \alpha E(X) \\ \text{Var}(\alpha X) &= \alpha^2 \text{Var}(X) \end{aligned}$$

Ejemplo: Modificación del parámetro λ de un modelo Poisson (Continuación)

Basándose en el ejemplo acerca del TAG y los fraudes, determinar, mediante el teorema de esperanza iterada, la distribución de Y_t sabiendo lo siguiente:

$$X_t \sim \text{Poisson}(\nu t) \quad Y_t | X_t = x \sim \text{Binomial}(x, p)$$

Solución:

De la distribución de X_t e $Y_t | X_t = x$ se obtiene lo siguiente:

- $E(X) = \nu t$
- $E(Y|X = x) = xp$ (Al evaluar X en x se pierde el comportamiento aleatorio)
- $E(Y|X) = Xp$ (Sin evaluar X en x aún se mantiene el comportamiento aleatorio)

Entonces, la esperanza de Y es:

$$\begin{aligned} E(Y) &= E[E(Y|X)] \\ &= E(Xp) = pE(X) \\ &= p\nu t \end{aligned}$$

y la varianza de Y es:

$$\begin{aligned} \text{Var}(Y) &= \text{Var}[E(Y|X)] + E[\text{Var}(Y|X)] \\ &= \text{Var}(Xp) + E[Xp(1-p)] \\ &= p^2 \text{Var}(X) + p(1-p)E(X) \\ &= p^2 \nu t + p(1-p)\nu t \\ &= \nu p t \end{aligned}$$

Este resultado coincide con la esperanza y varianza de una distribución Poisson de parámetro $\lambda = \nu pt$, por lo que se concluye que:

$$Y_t \sim \text{Poisson}(\nu pt)$$

Para comprobar al 100 % el resultado, se realiza todo el desarrollo hecho en el ejemplo anterior.

Predicción

Predecir la realización de una variable aleatoria Y : el “mejor” valor c para predecir la realización de Y se puede obtener minimizando el error cuadrático medio definido como

$$\text{ECM} = E[(Y - c)^2]$$

donde la constante c que minimiza el ECM es $E(Y)$, este es el **mejor predictor** de Y .

Si se quiere predecir Y basado en una función de una variable aleatoria X , $h(X)$, que minimice el error cuadrático medio definido como

$$\begin{aligned} \text{ECM} &= E\{[Y - h(X)]^2\} \\ \text{ECM} &= E(E\{[Y - h(X)]^2 | X\}) \end{aligned}$$

Entonces, la función $h(X)$ que minimiza ECM necesariamente debe corresponder a $E(Y|X)$, este es el **mejor predictor** de Y en función de X .

Ejemplo: Mejor predictor para una distribución Normal Bivariada

Determine cual es el mejor predictor para dos variables aleatorias X e Y que distribuyen conjuntamente Normal Bivariada.

Solución:

Si X e Y distribuye conjuntamente una Normal Bivariada, entonces el mejor predictor Y basado en X es una función lineal dada por

$$E(Y|X) = \left(\mu_Y - \mu_X \frac{\rho\sigma_Y}{\sigma_X} \right) + X \frac{\rho\sigma_Y}{\sigma_X}$$

Esta recta es denominada recta de regresión lineal simple, que tiene una estructura de la siguiente forma

$$y(X) = E(Y|X) = \beta_0 + \beta_1 X$$

Esta recta se estudiará con más detalle en el *Capítulo 6: Regresión Lineal*.

Capítulo 3

Funciones de variables aleatorias

Funciones de variables aleatorias

Sea una función de una variable aleatoria X

$$Y = g(X)$$

Si $Y = y$, entonces $X = g^{-1}(Y)$, donde g^{-1} es la función inversa de g .

Función de probabilidad: Caso discreto con raíz única

Si X es una variable aleatoria discreta, la nueva variable aleatoria, Y , también lo será y su función de probabilidad es

$$p_Y(y) = p_X[g^{-1}(y)]$$

Función de densidad: Caso continuo con raíz única

Si X es una variable aleatoria continua, la nueva variable aleatoria, Y , también lo será, y su función de densidad de probabilidad es

$$f_Y(y) = f_X[g^{-1}(y)] \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

Función de distribución de probabilidad acumulada

La función de distribución de probabilidad acumulada de Y está dada por

$$F_Y(y) = P(Y \leq y) = \begin{cases} P[X \leq g^{-1}(y)] & \text{si } g(\cdot) \text{ es creciente} \\ P[X \geq g^{-1}(y)] & \text{si } g(\cdot) \text{ es decreciente} \end{cases}$$

FDPA: Caso discreto:

Cuando y crece con x

$$F_Y(y) = \sum_{x \leq g^{-1}(y)} p_X(x)$$

$$F_Y(y) = F_X[g^{-1}(y)]$$

Cuando y decrece con x

$$F_Y(y) = \sum_{x \geq g^{-1}(y)} p_X(x)$$

$$F_Y(y) = 1 - F_X[g^{-1}(y) - 1]$$

FDPA: Caso continuo

Cuando y crece con x

$$F_Y(y) = \int_{x \leq g^{-1}(y)} f_X(x) dx = \int_{-\infty}^{g^{-1}(y)} f_X(x) dx$$

$$F_Y(y) = \int_{-\infty}^y f_X[g^{-1}(v)] \cdot \left| \frac{d}{dv} g^{-1}(v) \right| dv$$

$$F_Y(y) = F_X[g^{-1}(y)]$$

Cuando y decrece con x

$$F_Y(y) = \int_{x \geq g^{-1}(y)} f_X(x) dx = \int_{g^{-1}(y)}^{\infty} f_X(x) dx$$

$$F_Y(y) = \int_y^{\infty} f_X[g^{-1}(v)] \cdot \left| \frac{d}{dv} g^{-1}(v) \right| dv$$

$$F_Y(y) = 1 - F_X[g^{-1}(y)]$$

Ejemplos de funciones de variables aleatorias

Ejemplo: Normal a Normal Estándar

Sea $X \sim \text{Normal}(\mu, \sigma)$, si $Y = \frac{X - \mu}{\sigma}$, entonces,

$$Y = \frac{X - \mu}{\sigma} \longrightarrow X = \mu + \sigma \cdot Y$$

$$f_Y(y) = f_X[g^{-1}(y)] \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

$$f_Y(y) = f_X(\mu + \sigma \cdot y) \cdot |\sigma|$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}|\sigma|} \exp \left[-\frac{1}{2} \left(\frac{\mu + \sigma \cdot y - \mu}{\sigma} \right)^2 \right] \cdot |\sigma|$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{y^2}{2} \right)$$

Por lo tanto, $Y \sim \text{Normal}(0, 1)$

Ejemplo: Log-Normal a Normal

Sea $X \sim \text{Log-Normal}(\lambda, \zeta)$, si $Y = \ln(X)$, entonces

$$Y = \ln(X) \longrightarrow X = e^Y$$

$$f_Y(y) = f_X[g^{-1}(y)] \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

$$f_Y(y) = f_X(e^y) \cdot |e^y|$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{e^y \zeta} \exp \left[-\frac{1}{2} \left(\frac{\ln(e^y) - \lambda}{\zeta} \right)^2 \right] \cdot |e^y|$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi\zeta^2}} \exp \left[-\frac{1}{2} \left(\frac{y - \lambda}{\zeta} \right)^2 \right]$$

Por lo tanto, $Y \sim \text{Normal}(\lambda, \zeta)$

Ejemplo: Normal a Log-Normal

Sea $X \sim \text{Normal}(\mu, \sigma)$, si $Y = e^X$, entonces

$$Y = e^X \longrightarrow X = \ln(Y)$$

$$f_Y(y) = f_X[g^{-1}(y)] \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp \left[-\frac{1}{2} \left(\frac{\ln(y) - \mu}{\sigma} \right)^2 \right] \cdot \frac{1}{y}$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{y\sigma} \exp \left[-\frac{1}{2} \left(\frac{\ln(y) - \mu}{\sigma} \right)^2 \right]$$

Por lo tanto, $Y \sim \text{Log-Normal}(\mu, \sigma)$

Ejemplo: Weibull a Exponencial

Sea $X \sim \text{Weibull}(\eta, \beta)$, si $Y = \left(\frac{X}{\eta} \right)^\beta$, entonces

$$Y = \left(\frac{X}{\eta} \right)^\beta \longrightarrow X = \eta \cdot Y^{\frac{1}{\beta}}$$

$$f_Y(y) = f_X[g^{-1}(y)] \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

$$f_Y(y) = f_X(\eta \cdot y^{\frac{1}{\beta}}) \cdot \left| \frac{\eta}{\beta} y^{\frac{1}{\beta}-1} \right|$$

$$f_Y(y) = \frac{\beta}{\eta} \left(\frac{\eta y^{\frac{1}{\beta}}}{\eta} \right)^{\beta-1} \exp \left[-\left(\frac{\eta y^{\frac{1}{\beta}}}{\eta} \right)^\beta \right] \cdot \frac{\eta}{\beta} y^{\frac{1}{\beta}-1}$$

$$f_Y(y) = y^{1-\frac{1}{\beta}} e^{-y} \cdot y^{\frac{1}{\beta}-1} \longrightarrow f_Y(y) = e^{-y}$$

Por lo tanto, $Y \sim \text{Exponencial}(1)$

Función de probabilidad: Caso discreto con varias raíces

Cuando $g^{-1}(y)$ no tiene solución única, es decir

$$g^{-1}(y) = x_1, x_2, x_3, \dots, x_k$$

Entonces

$$(Y = y) = \bigcup_{i=1}^k (X = x_i)$$

Si X es una variable aleatoria discreta, la nueva variable aleatoria, Y , también lo será y su función de probabilidad es

$$p_Y(y) = \sum_{i=1}^k p_X[g_i^{-1}(y)]$$

Función de densidad: Caso continuo con varias raíces

Si X es una variable aleatoria continua, la nueva variable aleatoria, Y , también lo será, y su función de densidad de probabilidad es

$$f_Y(y) = \sum_{i=1}^k f_X[g_i^{-1}(y)] \cdot \left| \frac{d}{dy} g_i^{-1}(y) \right|$$

Ejemplos de funciones de variables aleatorias

Ejemplo: Log-Normal a Log-Normal (Propiedad)

Sea $X \sim \text{Log-Normal}(\lambda, \zeta)$, si $Y = X^k$, entonces,

$$Y \sim \text{Log-Normal}(\lambda k, |k|\zeta)$$

con $k \neq 0$

Ejemplo: Normal Estándar a Gamma

Sea $X \sim \text{Normal}(0, 1)$, si $Y = c \cdot X^2$, entonces,

$$Y \sim \text{Gamma}\left(k = \frac{1}{2}, \nu = \frac{1}{2c}\right)$$

Transformaciones típicas de distribución Normal y Log-Normal

■ Normal

$$X \sim \text{Normal}(\mu, \sigma) = \begin{cases} \left(\frac{X - \mu}{\sigma}\right) \sim \text{Normal}(0, 1) \\ e^X \sim \text{Log-Normal}(\mu, \sigma) \\ \left(\frac{X - \mu}{\sigma}\right)^2 \sim \text{Gamma}\left(\frac{1}{2}, \frac{1}{2}\right) = \chi^2(1) \\ c \left(\frac{X - \mu}{\sigma}\right)^2 \sim \text{Gamma}\left(\frac{1}{2}, \frac{1}{2c}\right) \end{cases}$$

■ Log-Normal

$$X \sim \text{Log-Normal}(\lambda, \zeta) = \begin{cases} \ln(X) \sim \text{Normal}(\lambda, \zeta) \\ X^k \sim \text{Log-Normal}(k\lambda, |k|\zeta), & k \neq 0 \\ cX^k \sim \text{Log-Normal}(\ln(c) + k\lambda, |k|\zeta), & c > 0, k \neq 0 \end{cases}$$

Observación: Estas propiedades serán útiles en capítulos siguientes.

Funciones de múltiples variables aleatorias

En el caso que una variable dependa de otras dos o más variables aleatorias, ésta también es una variable aleatoria y por tanto su distribución de probabilidad puede ser obtenida a partir de ellas.

Si se considera el caso

$$Z = g(X, Y)$$

donde X e Y son variables aleatorias.

Función de probabilidad: Caso discreto

Si X e Y son discretas, se tiene

$$(Z = z) = (g(X, Y) = z) = \bigcup_{g(x, y) = z} (X = x, Y = y)$$

y su función de probabilidad está dada por

$$p_Z(z) = \sum_{g(x, y) = z} p_{X, Y}(x, y)$$

La correspondiente función de distribución de probabilidad acumulada es

$$F_Z(z) = \sum_{g(x, y) \leq z} p_{X, Y}(x, y)$$

Ejemplo: Calculo de función de probabilidad

En una cierta carretera, la cantidad X de accidentes diarios puede ser modelado según una distribución Poisson(λ). Además, en un días se observan accidentes mortales con probabilidad de ocurrencia $p \times 100\%$. Determine la distribución de $W = X \cdot Y$ donde Y representa la variable aleatoria de observar o no accidentes mortales en un día. Asuma independencia entre X e Y .

Solución:

De enunciado se tiene que:

$$X \sim \text{Poisson}(\lambda) \quad Y \sim \text{Bernoulli}(p)$$

con soportes $\Theta_X = \mathbb{N}$ y $\Theta_Y = \{0, 1\}$ con 0 es *no observar accidentes mortales* y 1 es *observar accidentes mortales*.

la función de probabilidad conjunta, por independencia, es:

$$\begin{aligned} p_{X, Y}(x, y) &= p_X(x) \cdot p_Y(y) \\ &= \frac{\lambda^x e^{-\lambda}}{x!} \cdot p^y (1-p)^{1-y} \end{aligned}$$

Se tiene que los valores que puede tomar Z dada la fórmula de $g(X, Y)$ son números naturales entre 0 y el infinito, $\Theta_Z = \mathbb{N}$. Existen dos alternativas para calcular la función de probabilidad de Z :

Alternativa 1: Mediante la fórmula expuesta anteriormente. Se tiene lo siguiente:

$$Z = X \cdot Y \longrightarrow Y = \frac{Z}{X}$$

entonces:

$$p_Z(z) = \sum_{x \cdot y = z} p_X(x) p_Y\left(\frac{z}{x}\right)$$

con la función de probabilidad de X no hay problema, pero hay que ver para que condiciones de z y x la función de probabilidad de Y está definida. Del soporte de Y se tiene lo siguiente:

$$\begin{aligned} \{y = 0, y = 1\} &\longrightarrow \left\{ \frac{z}{x} = 0, \frac{z}{x} = 1 \right\} \\ \left\{ \frac{x}{z} = \infty, \frac{x}{z} = 1 \right\} &\longrightarrow \{x = \infty, x = z\} \end{aligned}$$

si $z \neq 0$. como la la función de probabilidad de Y está definida para dos valores de x , la suma solo será de dos términos y lo demás será cero, por lo tanto:

$$\begin{aligned} p_Z(z) &= \frac{\lambda^\infty e^{-\lambda}}{\infty!} \cdot p^0 (1-p)^{1-0} + \frac{\lambda^z e^{-\lambda}}{z!} \cdot p^1 (1-p)^0 \\ &= \frac{\lambda^z e^{-\lambda}}{z!} \cdot p \end{aligned}$$

para $z > 0$. Falta el caso para $z = 0$, para esto hay que determinar para que valores de X e Y se obtiene $Z = 0$. Se tiene que si X es cualquier valor e Y es igual a cero, entonces $Z = 0$, también se tiene que si Y es igual a uno, entonces X tiene que ser cero, por lo tanto:

$$\begin{aligned} p_Z(0) &= P(Z = 0) = P(X = 0, Y = 1) + \sum_{i=0}^{\infty} P(X = i, Y = 0) \\ &= P(X = 0) \cdot P(Y = 1) + \sum_{i=0}^{\infty} P(X = i) \cdot P(Y = 0) \\ &= e^{-\lambda} \cdot p + P(Y = 0) \sum_{i=0}^{\infty} P(X = i) \\ &= e^{-\lambda} \cdot p + (1 - p) \sum_{i=0}^{\infty} \frac{\lambda^i e^{-\lambda}}{i!} \\ &= e^{-\lambda} \cdot p + (1 - p) \cdot 1 \end{aligned}$$

Alternativa 2: Mediante análisis de los valores de Z . Se puede dividir el problema en dos, buscar la función de probabilidad para $Z > z$ y para $Z = 0$, en el primer caso se tiene que para obtener un valor distinto de cero de Z , entonces el valor de X tiene que ser distinto de cero e Y tiene que ser siempre uno, es decir:

$$\begin{aligned} p_Z(z) &= P(Z = z) = P(X = z, Y = 1) \\ &= P(X = z) \cdot P(Y = 1) \\ &= \frac{\lambda^z e^{-\lambda}}{z!} \cdot p \end{aligned}$$

Para $Z = 0$ se puede seguir el mismo análisis que la alternativa 1.

Resumiendo, la función de probabilidad de Z es:

$$p_Z(z) = \begin{cases} \frac{\lambda^z e^{-\lambda}}{z!} \cdot p & , \text{ si } z > 0 \\ e^{-\lambda} p + (1 - p) & , \text{ si } z = 0 \end{cases}$$

Función de densidad: Caso continuo

Si X e Y son continuas, la función de distribución de probabilidad acumulada de Z está dada por

$$\begin{aligned} F_Z(z) &= \iint_{g(x,y) \leq z} f_{X,Y}(x,y) dx dy \\ F_Z(z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{g^{-1}} f_{X,Y}(x,y) dx dy \end{aligned}$$

donde $g^{-1} = g^{-1}(z, y)$.

Cambiando la variable de integración de x a z , se tiene

$$F_Z(z) = \int_{-\infty}^{\infty} \int_{-\infty}^z f_{X,Y}(g^{-1}, y) \left| \frac{\partial}{\partial z} g^{-1} \right| dz dy$$

Derivando con respecto a z , se obtiene la función de densidad de Z para 2 casos

$$f_Z(z) = \begin{cases} \int_{-\infty}^{\infty} f_{X,Y}(g^{-1}, y) \left| \frac{\partial}{\partial z} g^{-1} \right| dy, & g^{-1} = g^{-1}(z, y) \\ \int_{-\infty}^{\infty} f_{X,Y}(x, g^{-1}) \left| \frac{\partial}{\partial z} g^{-1} \right| dx, & g^{-1} = g^{-1}(x, z) \end{cases}$$

Ejemplo: Calculo de función de densidad

Sean X e Y dos variables aleatorias independientes con distribución Uniforme, con soporte en los intervalos $\Theta_X \in (0, 1)$ y $\Theta_Y \in (0, 2)$. Determinar la función de densidad de $Z = X + Y$.

Ayuda: Podría ser de ayuda considerar los siguientes intervalos para Z : $0 < z < 1$, $1 \leq z < 2$ y $2 \leq z < 3$.

Solución:

De enunciado se tiene que:

$$X \sim \text{Uniforme}(0, 1) \quad Y \sim \text{Uniforme}(0, 2)$$

La función de densidad conjunta, por independencia, es:

$$\begin{aligned} f_{X,Y}(x, y) &= f_X(x) \cdot f_Y(y) \\ &= 1 \cdot \frac{1}{2} = \frac{1}{2} \end{aligned}$$

Se tiene que los valores que puede tomar Z dada la fórmula de $g(X, Y)$ son números entre el cero y el tres, $0 < z < 3$, por lo tanto el soporte de Z es $\Theta_Z \in (0, 3)$.

Despejando Y se tiene lo siguiente:

$$\begin{aligned} Z = g(X, Y) = X + Y &\longrightarrow Y = g^{-1}(X, Z) = Z - X \\ \frac{\partial}{\partial z} g^{-1} &= 1 \end{aligned}$$

entonces la función de densidad de Z se calcula como:

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{\infty} f_{X,Y}(x, z-x) \left| \frac{\partial}{\partial z} g^{-1} \right| dx \\ &= \int_{-\infty}^{\infty} f_X(x) \cdot f_Y(z-x) \cdot |1| dx \end{aligned}$$

Los límites de integración son tales que las funciones de densidad de X e Y estén definidas. Para X no hay restricción, por lo que $0 < x < 1$; para Y se tiene que está definida en $0 < y < 2$, por lo tanto:

$$\begin{aligned} 0 &< y < 2 \\ 0 &< z - x < 2 \\ -z &< -x < 2 - z \\ z - 2 &< x < z \end{aligned}$$

por lo que:

$$f_Z(z) = \int_{z-2}^z f_X(x) \cdot f_Y(z-x) dx$$

Analizando para los distintos intervalos de Z se tiene:

- Intervalo $0 < z < 1$: Considerando los casos extremos:

$$\begin{aligned} z = 0 &\longrightarrow -2 < x < 0 \\ z = 1 &\longrightarrow -1 < x < 1 \end{aligned}$$

Se observa que el valor inferior del intervalo de x entre $0 < z < 1$ da valores de $-2 < x_{inf} < -1$, por lo que la función de densidad de X sería cero, mientras que el valor superior del intervalo de x entre $0 < z < 1$ no presenta ningún problema ya que $0 < x_{sup} < 1$, por lo que la función de densidad de X e Y estarían definidas, entonces, el intervalo acotado de x para evaluar la integral es:

$$0 < x < z$$

la función de densidad en $0 < z < 1$:

$$f_Z(z) = \int_0^z \frac{1}{2} dx = \frac{z}{2}$$

- Intervalo $1 \leq z < 2$: Considerando los casos extremos:

$$z = 1 \longrightarrow -1 < x < 1$$

$$z = 2 \longrightarrow 0 < x < 2$$

Se observa que el valor inferior del intervalo de x da valores de $-1 < x_{inf} < 0$, por lo que la función de densidad de X sería cero; mientras que el valor superior del intervalo de x da valores de $1 < x_{sup} < 2$, por lo que la función de densidad de X sería cero; entonces, el intervalo acotado de x para evaluar la integral es:

$$0 < x < 1$$

la función de densidad en $1 \leq z < 2$:

$$f_Z(z) = \int_0^1 \frac{1}{2} dx = \frac{1}{2}$$

- Intervalo $2 \leq z < 3$: Considerando los casos extremos:

$$z = 2 \longrightarrow 0 < x < 2$$

$$z = 3 \longrightarrow 1 < x < 3$$

Se observa que el valor inferior del intervalo de x da valores de $0 < x_{inf} < 1$, por lo que la función de densidad de X e Y estarían definidas; mientras que el valor superior del intervalo de x da valores de $1 < x_{sup} < 3$, por lo que la función de densidad de X sería cero; entonces, el intervalo acotado de x para evaluar la integral es:

$$z - 2 < x < 1$$

La función de densidad en $2 \leq z < 3$:

$$f_Z(z) = \int_{z-2}^1 \frac{1}{2} dx = \frac{3-z}{2}$$

Finalmente, la función de densidad de Z es:

$$f_Z(z) = \begin{cases} \frac{z}{2} & , \text{ si } 0 < z < 1 \\ \frac{1}{2} & , \text{ si } 1 \leq z < 2 \\ \frac{3-z}{2} & , \text{ si } 2 \leq z < 3 \end{cases}$$

Suma de variables aleatorias DISCRETAS

Considere la suma de 2 variables aleatorias discreta, $Z = X + Y$. En este caso, la función de probabilidad de Z esta dada por

$$p_Z(z) = \sum_{x+y=z} p_{X,Y}(x,y) = \begin{cases} \sum_{x \in \Theta_X} p_{X,Y}(x, z-x), & g^{-1}(z, x) = z-x \\ \sum_{y \in \Theta_Y} p_{X,Y}(z-y, y), & g^{-1}(z, y) = z-y \end{cases}$$

Si X e Y son independientes, entonces

$$p_{X,Y} = p_X(x) \cdot p_Y(y)$$

Ejemplo: Suma de variables independientes Poisson

Determine como distribuye $Z = X + Y$ si X e Y distribuyen independientemente Poisson. Generalice a la suma de k variables aleatorias independientes Poisson de parámetro λ_i .

$$X \sim \text{Poisson}(\nu) \quad Y \sim \text{Poisson}(\mu)$$

Solución:

Si X e Y son variables aleatorias independientes con distribución Poisson con parámetros ν y μ respectivamente, si $Z = X + Y$, entonces,

$$p_Z(z) = \sum_{x=0}^{\infty} p_X(x) \cdot p_Y(z-x)$$

$$p_Z(z) = \sum_{x=0}^z \frac{\nu^x e^{-\nu}}{x!} \cdot \frac{\mu^{z-x} e^{-\mu}}{(z-x)!}$$

$$p_Z(z) = \frac{(\mu + \nu)^z e^{-(\mu+\nu)}}{z!}$$

$$Z = X + Y \sim \text{Poisson}(\nu + \mu)$$

Generalizando, si $X_i \sim \text{Poisson}(\lambda_i)$ son variables aleatorias independientes, entonces

$$Z = \sum_{i=1}^k X_i \sim \text{Poisson}\left(\sum_{i=1}^k \lambda_i\right)$$

Suma de variables aleatorias CONTINUAS

Considerando la suma de 2 variables aleatorias continuas, $Z = aX + bY$. En este caso, la función de densidad de Z esta dada por

$$f_Z(z) = \begin{cases} \int_{-\infty}^{\infty} f_{X,Y}\left(\frac{z-by}{a}, y\right) \frac{1}{a} dy, & g^{-1}(z, y) = \frac{z-by}{a} \\ \int_{-\infty}^{\infty} f_{X,Y}\left(x, \frac{z-ax}{b}\right) \frac{1}{b} dx, & g^{-1}(z, x) = \frac{z-ax}{b} \end{cases}$$

Si X e Y son independientes, entonces

$$f_{X,Y} = f_X(x) \cdot f_Y(y)$$

Ejemplo: Suma de variables independientes Gamma

Determine como distribuye $Z = X + Y$ si X e Y distribuyen independientemente Gamma. Generalice a la suma de n variables aleatorias independientes Gamma de parámetros k_i y ν .

$$X \sim \text{Gamma}(\alpha, \nu) \quad Y \sim \text{Gamma}(\beta, \nu)$$

Solución:

Si X e Y son variables aleatorias independientes con distribución $\text{Gamma}(\alpha, \nu)$ y $\text{Gamma}(\beta, \nu)$ respectivamente, entonces $Z = X + Y$ distribuye,

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(z-y) \cdot f_Y(y) |1| dy$$

$$f_Z(z) = \int_0^z \frac{\nu^\alpha}{\Gamma(\alpha)} (z-y)^{\alpha-1} e^{-\nu(z-y)} \cdot \frac{\nu^\beta}{\Gamma(\beta)} y^{\beta-1} e^{-\nu y} dy$$

$$f_Z(z) = \frac{\nu^{\alpha+\beta}}{\Gamma(\alpha+\beta)} z^{\alpha+\beta-1} e^{-\nu z}$$

$$Z = X + Y \sim \text{Gamma}(\alpha + \beta, \nu)$$

Generalizando, si $X_i \sim \text{Gamma}(k_i, \nu)$ son variables aleatorias independientes, entonces

$$Z = \sum_{i=1}^n X_i \sim \text{Gamma}\left(\sum_{i=1}^n k_i, \nu\right)$$

$$Z = c \sum_{i=1}^n X_i \sim \text{Gamma}\left(\sum_{i=1}^n k_i, \frac{\nu}{c}\right)$$

Ejemplo: Suma de variables independientes Normal

Determine como distribuye $Z = a + bX + cY$ si X e Y distribuyen independientemente Normal. Generalice a la suma de n variables aleatorias independientes Normal de parámetros μ_{X_i} y σ_{X_i} .

$$X \sim \text{Normal}(\mu_X, \sigma_X) \quad Y \sim \text{Normal}(\mu_Y, \sigma_Y)$$

Solución:

Considerando X e Y variables aleatorias independientes con distribución $\text{Normal}(\mu_X, \sigma_X)$ y $\text{Normal}(\mu_Y, \sigma_Y)$ respectivamente, entonces

$$Z = a + bX + cY \sim \text{Normal}(\mu_Z, \sigma_Z)$$

donde

- $\mu_Z = a + b\mu_X + c\mu_Y$
- $\sigma_Z = \sqrt{b^2\sigma_X^2 + c^2\sigma_Y^2}$
- a y b son constantes

Generalizando, si $X_i \sim \text{Normal}(\mu_{X_i}, \sigma_{X_i})$ son variables aleatorias independientes, entonces,

$$Z = a_0 + \sum_{i=1}^n a_i X_i \sim \text{Normal}(\mu_Z, \sigma_Z)$$

donde

- $\mu_Z = a_0 + \sum_{i=1}^n a_i \mu_{X_i}$
- $\sigma_Z = \sqrt{\sum_{i=1}^n a_i^2 \sigma_{X_i}^2}$

Producto y cociente de variables aleatorias CONTINUAS

Sea $Z = XY$, entonces la función de densidad de Z esta dada por

$$f_Z(z) = \begin{cases} \int_{-\infty}^{\infty} \left| \frac{1}{y} \right| f_{X,Y} \left(\frac{z}{y}, y \right) dy, & g^{-1}(z, y) = \frac{z}{y} \\ \int_{-\infty}^{\infty} \left| \frac{1}{x} \right| f_{X,Y} \left(x, \frac{z}{x} \right) dx, & g^{-1}(z, x) = \frac{z}{x} \end{cases}$$

Si $Z = \frac{X}{Y}$, la función de densidad de Z esta dada por

$$f_Z(z) = \begin{cases} \int_{-\infty}^{\infty} |y| f_{X,Y}(zy, y) dy, & g^{-1}(z, y) = zy \\ \int_{-\infty}^{\infty} |x| f_{X,Y}(x, zx) dx, & g^{-1}(z, x) = zx \end{cases}$$

Ejemplo: Cociente y producto de variables aleatorias

Si Z es una variable aleatoria Normal(0,1) y $U \sim \text{Gamma}\left(\frac{\nu}{2}, \frac{1}{2}\right)$, ambas independientes, entonces

$$T = \frac{Z}{\sqrt{U/\nu}} \sim \text{T-Student}(\nu)$$

y

$$H = T^2 \sim \text{Fisher}(1, \nu)$$

Observación: El resultado de este ejemplo será de especial interés en el capítulo de *Inferencia estadística y Regresión Lineal*.

Producto de variables independientes Log-Normal (Caso especial de suma de Normales)

Desde un punto de vista práctico, el producto y cociente de variables aleatorias Log-Normal es de especial interés. En particular, se observa que el producto o cociente de variables aleatorias Log-Normal independientes es también Log-Normal. Esto puede ser mostrado de la siguiente forma, se supone que

$$Z = \prod_{i=1}^n X_i$$

donde $X_i \sim \text{Log-Normal}(\lambda_{X_i}, \zeta_{X_i})$ independientes, entonces

$$\ln(Z) = \sum_{i=1}^n \ln(X_i)$$

donde $\ln(X_i) \sim \text{Normal}(\lambda_{X_i}, \zeta_{X_i})$, por lo tanto $\ln(Z)$ es la suma de variables normales y, en consecuencia, también es Normal de media y varianza:

- Media de Z : $\lambda_Z = E(\ln(Z)) = \sum_{i=1}^n \lambda_{X_i}$
- Varianza de Z : $\zeta_Z^2 = \text{Var}(\ln(Z)) = \sum_{i=1}^n \zeta_{X_i}^2$

Finalmente,

$$Z \sim \text{Log-Normal}(\lambda_Z, \zeta_Z)$$

TEOREMA CENTRAL DEL LÍMITE

La suma de un número de variables aleatorias, donde ninguna es dominante, tiende a la distribución Normal cuando el número de variables aleatorias se incrementa.

El teorema dice que si $X_1, \dots, X_n$ son variables aleatorias **independientes e idénticamente distribuidas** (iid) con

$$E(X_i) = \mu \quad \text{y} \quad \text{Var}(X_i) = \sigma^2$$

para todo $i = 1, \dots, n$.

Entonces,

$$Z_n = \frac{\sum_{i=1}^n X_i - n \cdot \mu}{\sqrt{n}\sigma} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \rightarrow Z \sim \text{Normal}(0, 1)$$

cuando $n \rightarrow \infty$

Escrito de otra forma,

$$\sum_{i=1}^n X_i \sim \text{Normal}(n\mu, \sqrt{n}\sigma) \quad \text{o} \quad \frac{1}{n} \sum_{i=1}^n X_i \sim \text{Normal}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Observación: El símbolo ($\sim$) significa que la variable aleatoria *distribuye aproximadamente*, mientras que el símbolo ($\stackrel{\text{iid}}{\sim}$) significa que las variables aleatorias *distribuyen independientemente e igual*.

Algunos ejemplos:

Ejemplo: Distribución aproximada de variables iid Bernoulli

Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$, entonces,

$$S_n = \sum_{i=1}^n X_i \sim \text{Binomial}(n, p) \sim \text{Normal}\left(np, \sqrt{np(1-p)}\right)$$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim \text{Normal}\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$$

Ejemplo: Distribución aproximada de variables iid Exponencial

Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\nu)$, entonces,

$$S_n = \sum_{i=1}^n X_i \sim \text{Gamma}(n, \nu) \sim \text{Normal}\left(\frac{n}{\nu}, \frac{\sqrt{n}}{\nu}\right)$$

Ejemplo: Distribución aproximada de variables iid Poisson

Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda)$, entonces,

$$S_n = \sum_{i=1}^n X_i \sim \text{Poisson}(n\lambda) \sim \text{Normal}\left(n\lambda, \sqrt{n\lambda}\right)$$

Aproximación de variable discreta

Cuando se aproxima una variable aleatoria discreta por una continua se recomienda realizar una corrección por continuidad.

Si se tiene una variable aleatoria que puede ser aproximada por una $\text{Normal}(n\mu_X, \sqrt{n\sigma_X^2})$, entonces el calculo de probabilidad es el siguiente

$$P(X \leq x) = P(X < x + 0.5)$$

Distribuciones de Valores Extremos

Los extremos (mínimo y máximo) de un fenómeno a menudo son de especial interés e importancia en ingeniería.

Cuando se habla de valores extremos, se considera el mayor y menor valor de una muestra de tamaño n de una distribución conocida. Por tanto, es de interés determinar su distribución exacta o asintótica.

Se considera una variable aleatoria X con función de densidad $f_X(x)$ o de distribución acumulada $F_X(x)$.

Para una muestra $X_1, \dots, X_n$ (iid) de esta distribución se definen:

$$Y_n = \max\{X_1, \dots, X_n\}, \quad Y_1 = \min\{X_1, \dots, X_n\}$$

Distribución del máximo

La función de densidad de Y_n esta dada por

$$f_{Y_n}(y) = n[F_X(y)]^{n-1}f_X(y)$$

La función de distribución de probabilidad acumulada es

$$F_{Y_n}(y) = [F_X(y)]^n$$

Distribución del mínimo

La función de densidad de Y_1 esta dada por

$$f_{Y_1}(y) = n[1 - F_X(y)]^{n-1}f_X(y)$$

La función de distribución de probabilidad acumulada es

$$F_{Y_1}(y) = 1 - [1 - F_X(y)]^n$$

Distribución conjunta de mínimo y máximo

La distribución conjunta entre Y_1 e Y_n está dada por

$$f_{Y_1 Y_n}(u, v) = n(n-1)[F_X(v) - F_X(u)]^{n-2}f_X(v)f_X(u), \quad u \leq v$$

Ejemplo: Distribución del mínimo de la distribución Weibull

Determine la distribución del mínimo para una muestra aleatoria iid Weibull con parámetros β y η .

Solución:

Para una muestra $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Weibull}(\eta, \beta)$, entonces la distribución de $Y_1 = \min\{X_1, \dots, X_n\}$ es

$$f_X(x) = \frac{\beta}{\eta} \left(\frac{x}{\eta}\right)^{\beta-1} \exp\left[-\left(\frac{x}{\eta}\right)^\beta\right]$$

$$F_X(x) = 1 - \exp\left[-\left(\frac{x}{\eta}\right)^\beta\right]$$

$$F_{Y_1}(y) = 1 - \left(1 - \exp\left[-\left(\frac{y}{\eta}\right)^\beta\right]\right)^n$$

$$F_{Y_1}(y) = 1 - \exp\left[-\left(\frac{y}{\eta}\right)^\beta \cdot n\right] = 1 - \exp\left[-\left(\frac{y \cdot n^{\frac{1}{\beta}}}{\eta}\right)^\beta\right]$$

Por lo tanto, la distribución del mínimo de variables aleatorias iid Weibull es

$$Y_1 \sim \text{Weibull}\left(\frac{\eta}{n^{\frac{1}{\beta}}}, \beta\right)$$

Caso especial: Si $\beta = 1$, entonces

$$Y_1 \sim \text{Weibull}\left(\frac{\eta}{n}, 1\right) = \text{Exponencial}\left(\frac{n}{\eta}\right)$$

Ejemplo: Distribución del mínimo de la distribución Exponencial

Determine la distribución del mínimo para una muestra aleatoria iid Exponencial con parámetro ν .

Solución:

Para una muestra $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\nu)$, entonces la distribución del mínimo, Y_1 , es

$$f_X(x) = \nu e^{-\nu x}$$

$$F_X(x) = 1 - e^{-\nu x}$$

$$F_{Y_1}(y) = 1 - (1 - 1 + e^{-\nu y})^n = 1 - e^{-\nu n \cdot y}$$

Por lo tanto, la distribución del mínimo de variables aleatorias iid Exponenciales es

$$Y_1 \sim \text{Exponencial}(\nu n)$$

Momentos de Funciones de Variables Aleatorias

Algunas distribuciones de funciones pueden ser difíciles o imposibles de obtener de una manera analítica, por lo que es necesario disponer de métodos que permitan obtener algunos momentos o una aproximación de éstos.

Estos momentos están relacionados con los momentos de las variables originales.

Esperanza matemática de una función

Un valor esperado de una función de variables aleatorias se denomina esperanza matemática.

Si $Z = g(X_1, \dots, X_n)$, entonces la esperanza de Z puede ser obtenida como sigue

$$E(Z) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(x_1, \dots, x_n) f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_n \cdots dx_1$$

En el caso de variables aleatorias discretas es,

$$E(Z) = \sum_{x_1 \in \Theta_{X_1}} \cdots \sum_{x_n \in \Theta_{X_n}} g(x_1, \dots, x_n) p_{X_1, \dots, X_n}(x_1, \dots, x_n)$$

En el caso de que $X_1, \dots, X_n$ sean variables aleatorias independientes con funciones generadoras de momentos $M_{X_1}, \dots, M_{X_n}$ respectivamente, se tiene, por ejemplo, que la función generadora de momentos de

$$Z = \sum_{i=1}^n X_i$$

es

$$M_Z(t) = M_{X_1}(t) \times \cdots \times M_{X_n}(t)$$

Observación: Este resultado es útil para determinar como distribuye la suma de variables aleatorias independientes de modelos conocidos.

Ejemplo: Suma de variables iid Geométricas

Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Geométrica}(p)$, entonces,

$$Z = \sum_{i=1}^n X_i$$

$$M_Z(t) = \prod_{i=1}^n \frac{e^t p}{1 - (1-p)e^t} = \left(\frac{e^t p}{1 - (1-p)e^t} \right)^n$$

$$Z = \sum_{i=1}^n X_i \sim \text{Binomial-Negativa}(k = n, p)$$

Ejemplo: Suma de variables iid Normal

Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Normal}(\mu_i, \sigma_i^2)$, entonces,

$$Z = \sum_{i=1}^n X_i$$

$$M_Z(t) = \prod_{i=1}^n \exp\left(\mu_i t + \frac{1}{2} t^2 \sigma_i^2\right) = \exp\left(t \sum_{i=1}^n \mu_i + \frac{1}{2} t^2 \sum_{i=1}^n \sigma_i^2\right)$$

$$Z = \sum_{i=1}^n X_i \sim \text{Normal}\left(\sum_{i=1}^n \mu_i, \sqrt{\sum_{i=1}^n \sigma_i^2}\right)$$

Transformaciones o Combinaciones Lineales de Variables Aleatorias

Las **transformaciones lineales** tienen propiedades interesantes que se verán a continuación.

Sean $X_1, \dots, X_n$ y $Y_1, \dots, Y_m$ variables aleatorias y $a_0, a_1, \dots, a_n, b_0, b_1, \dots, b_m$ constantes conocidas, entonces,

- $E\left(a_0 + \sum_{i=1}^n a_i \cdot X_i\right) = a_0 + \sum_{i=1}^n a_i \cdot E(X_i)$
 - $\text{Cov}\left(a_0 + \sum_{i=1}^n a_i \cdot X_i, b_0 + \sum_{j=1}^m b_j \cdot Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m a_i \cdot b_j \cdot \text{Cov}(X_i, Y_j)$
 - $\text{Var}\left(a_0 + \sum_{i=1}^n a_i \cdot X_i\right) = \sum_{i=1}^n \sum_{j=1}^n a_i \cdot a_j \cdot \text{Cov}(X_i, X_j)$
 - Si $X_1, \dots, X_n$ son variables aleatorias independientes, entonces
- $$\text{Var}\left(a_0 + \sum_{i=1}^n a_i \cdot X_i\right) = \sum_{i=1}^n a_i^2 \cdot \text{Var}(X_i)$$

Ejemplo: Suma de variables aleatorias Normal

Sean X e Y variables aleatorias con distribución Normal, entonces

$$Z = aX \pm bY \sim \text{Normal}(\mu_Z, \sigma_Z)$$

mediante las propiedades de la combinación lineal, se tiene que μ_Z y σ_Z son

- $\mu_Z = a \cdot \mu_X \pm b \cdot \mu_Y$
- $\sigma_Z^2 = a^2 \sigma_X^2 + b^2 \sigma_Y^2 \pm 2ab \cdot \rho \cdot \sigma_X \sigma_Y$

El factor ρ es la correlación entre la variable X e Y

$$\rho = \text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

Media y Varianza de una función general

Sea $Y = g(X)$, con X variable aleatorias con función de densidad $f_X(x)$, entonces,

$$\mu_Y = E(Y) = \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

$$\sigma_Y^2 = \text{Var}(Y) = \int_{-\infty}^{\infty} (g(x) - \mu_Y)^2 f_X(x) dx$$

Si no es posible determinar la densidad de X , se puede expandir $g(x)$ en una serie de Taylor en torno a $E(X)$, es decir,

$$g(X) \approx g(\mu_X) + (X - \mu_X) \frac{dg}{dx} + \frac{1}{2} (X - \mu_X)^2 \frac{d^2g}{dx^2} + \dots$$

Evaluando las derivadas en μ_X y truncando hasta el término lineal se tiene la aproximación de **primer orden** para la media y varianza

$$E[g(X)] \approx g(\mu_X) \quad \text{y} \quad \text{Var}[g(X)] \approx \text{Var}(X) \left[\frac{d}{dX} g(\mu_X) \right]^2$$

Si se incluye el segundo orden de la serie de Taylor, entonces se puede mostrar la aproximación de **segundo orden** correspondiente,

$$E(Y) \approx g(\mu_X) + \frac{1}{2} \text{Var}(X) \frac{d^2g}{dX^2}$$
$$\text{Var}(Y) \approx \sigma_X^2 \left(\frac{dg}{dX} \right)^2 - \frac{1}{4} \sigma_X^2 \left(\frac{d^2g}{dX^2} \right)^2 + E(X - \mu_X)^3 \frac{dg}{dX} \frac{d^2g}{dX^2} + \frac{1}{4} E(X - \mu_X)^4 \left(\frac{d^2g}{dX^2} \right)^2$$

Es preferible usar la aproximación de segundo orden para la varianza ya que con agregar mas órdenes de la serie de Taylor se extiende el calculo de la varianza; para la esperanza, se puede agregar mas términos y el calculo no llega a ser tan complicado, a continuación se muestra una aproximación de cuarto orden,

$$E(Y) \approx \underbrace{g(\mu_X)}_{1^{\text{er Orden}}} + \underbrace{\frac{g''(X) \cdot \sigma_X^2}{2!}}_{2^{\text{do Orden}}} + \underbrace{\frac{g'''(X) \cdot \theta_X \sigma_X^3}{3!}}_{3^{\text{er Orden}}} + \underbrace{\frac{g^{(4)}(X) \cdot (\kappa_X + 3) \sigma_X^4}{4!}}_{4^{\text{to Orden}}}$$

donde θ_X y κ_X son el coeficiente de asimetría y la kurtosis respectivamente.

Si $Y = g(X_1, \dots, X_n)$, se tiene que la expansión de Taylor entorno a los valores esperados $(\mu_{X_1}, \dots, \mu_{X_n})$ está dada por

$$Y = g[(\mu_{X_1}, \dots, \mu_{X_n})] + \sum_{i=1}^n (X_i - \mu_{X_i}) \frac{\partial g}{\partial X_i} + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (X_i - \mu_{X_i})(X_j - \mu_{X_j}) \frac{\partial^2 g}{\partial X_i \partial X_j} + \dots$$

Para el caso de una aproximación de **primer orden** se tiene que

$$E(Y) \approx g[(\mu_{X_1}, \dots, \mu_{X_n})] \quad \text{y} \quad \text{Var}(Y) \approx \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(X_i, X_j) \frac{\partial g}{\partial X_i} \frac{\partial g}{\partial X_j}$$

Para el caso de una aproximación de **segundo orden** se tiene que

$$E(Y) \approx g[(\mu_{X_1}, \dots, \mu_{X_n})] + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(X_i, X_j) \frac{\partial^2 g}{\partial X_i \partial X_j}$$

La covarianza se puede escribir como $\text{Cov}(X_i, X_j) = \rho_{ij} \sigma_{X_i} \sigma_{X_j}$.

Ejemplo: Cociente aproximado entre variables aleatorias

Sean X_1 y X_2 variables aleatorias, sea $Y = \frac{X_1}{X_2}$ otra variable aleatoria, entonces,

$$Y = \frac{X_1}{X_2} \approx \frac{\mu_1}{\mu_2} + (X_1 - \mu_1) \frac{1}{\mu_2} - (X_2 - \mu_2) \frac{\mu_1}{\mu_2^2}$$

La aproximación de primero orden para el valor esperado y varianza es

$$E(Y) \approx \frac{\mu_1}{\mu_2} \quad \text{y} \quad \text{Var}(Y) \approx \left(\frac{1}{\mu_2} \right)^2 \cdot \sigma_1^2 + \left(-\frac{\mu_1}{\mu_2^2} \right) \cdot \sigma_2^2 + 2 \left(\frac{1}{\mu_2} \right) \left(-\frac{\mu_1}{\mu_2^2} \right) \cdot \rho \sigma_1 \sigma_2$$

Ejemplo: Suma aproximada de variables independientes Exponencial

Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\nu)$, sea $Y = \frac{1}{\bar{X}}$, donde $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, entonces el valor esperado es,

■ Forma 1: Exacta:

$$U = \bar{X} \sim \text{Gamma}(n, n\nu)$$

$$E(Y) = E\left(\frac{1}{U}\right) = \int_0^\infty \frac{1}{u} \frac{(n\nu)^n}{\Gamma(n)} u^{n-1} e^{-n\nu u} du$$

$$E(Y) = \frac{\nu n}{n-1} = \frac{\nu}{1-1/n} \xrightarrow{n \rightarrow \infty} \nu$$

■ Forma 2: Aproximada:

$$E(Y) = E\left(\frac{n}{\sum X_i}\right) \stackrel{\text{ind}}{\approx} \frac{n}{n/\nu} = \nu$$

Capítulo 4


Inferencia Estadística

Definiciones y Propiedades

Hasta ahora se han visto de manera introductoria como dada una distribución $(p_X(x), f_X(x), F_X(x))$ de una variable aleatorias X y el valor de sus parámetros se pueden obtener probabilidades.

El calculo de probabilidades depende del valor de los parámetros, por tanto, es de interés disponer de métodos que permitan seleccionar adecuadamente valores de estos para las distribuciones de importancia práctica.

Para realizar lo anteriormente expuesto, se requiere información “del mundo real”. Con base a estos datos, los parámetros pueden ser estimados estadísticamente, y con información sobre el fenómeno inferir la distribución de probabilidad.



La estimación clásica de parámetros consiste en 2 tipos:

- **Puntual:** Indica un valor único, basado en los datos para representar el parámetro de interés
- **Intervalar:** Entrega un conjunto de valores donde el parámetro puede estar con cierto nivel de confianza

Propiedades deseables para un estimador

- **Insesgamiento:** Valor esperado del estimador sea igual al parámetro de interés, $E(\hat{\theta}) = \theta$. Si $\hat{\theta}$ no es insesgado, la diferencia $E(\hat{\theta}) - \theta$ se conoce como el **sesgo** de $\hat{\theta}$.
- **Consistencia:** Implica que si $n \rightarrow \infty$, el estimador converge al parámetro, un estimador es consistente cuando $\text{Var}(\hat{\theta}) \xrightarrow{n \rightarrow \infty} 0$, también, si $\text{ECM} = E((\hat{\theta} - \theta)^2) = \text{Var}(\hat{\theta}) + \text{Sesgo}^2 \xrightarrow{n \rightarrow \infty} 0$, esto se conoce como consistencia en media cuadrática.
- **Eficiencia:** Se refiere a que la varianza del estimador. Dado un conjunto de datos, θ_1 es más eficiente que θ_2 para estimar θ si tiene menor varianza.
- **Suficiencia:** Un estimador se dice suficiente si utiliza toda la información contenida en la muestra para estimar el parámetro.

Métodos de Estimación

Método de los Momentos:

El método propone igualar los momentos teóricos no centrales de una variable aleatoria X , denotado por μ_k , con los momentos empíricos, basados en los datos, m_k , y despejar los parámetros de interés. Es decir,

$$\mu_k = E(X^k) \quad \text{y} \quad m_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

en el que el valor x_i está asociado a la variable aleatoria X_i . Entonces

$$\mu_k = m_k, \quad k = 1, 2, \dots$$

donde k es la cantidad de ecuaciones que se deben utilizar para estimar todos los parámetros.

A continuación se muestran algunos ejemplos de estimaciones, sean $X_1, \dots, X_n$ una muestra aleatoria cuya distribución de probabilidad son las siguientes:

Ejemplo: Estimación con distribución Bernoulli

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$, entonces,

$$\mu_1 = \hat{p} = \bar{X} = m_1$$

donde $\hat{p}$ es el estimador de p

$$\blacksquare E(\hat{p}) = E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \sum_{i=1}^n \frac{1}{n} E(X_i) \stackrel{\text{ind}}{=} \frac{np}{n} = p$$

$\therefore \hat{p} = \bar{X}$ Es un estimador insesgado para p

$$\blacksquare \text{Var}(\hat{p}) = \text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \stackrel{\text{ind}}{=} \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \stackrel{\text{ind}}{=} \frac{np(1-p)}{n^2}$$

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \xrightarrow{n \rightarrow \infty} 0$$

$\therefore \hat{p}$ Es un estimador consistente para p

Ejemplo: Estimación con distribución Poisson

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda)$, entonces,

$$\mu_1 = \hat{\lambda} = \bar{X} = m_1$$

donde $\hat{\lambda}$ es un estimador de λ

$$\blacksquare E(\hat{\lambda}) = \lambda, \text{ entonces } \hat{\lambda} = \bar{X} \text{ es un estimador isesgado para } \lambda$$

$$\blacksquare \text{Var}(\hat{\lambda}) = \frac{\lambda}{n} \xrightarrow{n \rightarrow \infty} 0, \text{ entonces } \hat{\lambda} \text{ es un estimador consistente para } \lambda$$

Ejemplo: Estimación con distribución Exponencial

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\nu)$, entonces,

$$\mu_1 = \frac{1}{\nu} = \bar{X} = m_1 \Rightarrow \hat{\nu} = \frac{1}{\bar{X}}$$

donde $\hat{\nu}$ es un estimador de ν . Ya que $Y = \bar{X} \sim \text{Gamma}(n, n\nu)$, entonces.

- $E(\hat{\nu}) = \frac{\nu}{1 - 1/n} \neq \nu$, por lo que es un estimador sesgado, pero $E(\hat{\nu}) \xrightarrow{n \rightarrow \infty} \nu$, entonces el estimador es asintóticamente insesgado para ν

Ejemplo: Estimación con distribución Gamma

Si la distribución de variables $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Gamma}(k, \nu)$, entonces,

$$\begin{cases} \mu_1 = \frac{k}{\nu} = \bar{X} = m_1 \\ \mu_2 = \frac{k(k+1)}{\nu^2} = \bar{X}^2 = m_2 \end{cases}$$

Resolviendo el sistema de ecuaciones se tiene que

$$\begin{cases} \hat{\nu} = \frac{\bar{X}}{\bar{X}^2 - (\bar{X})^2} \\ \hat{k} = \frac{(\bar{X})^2}{\bar{X}^2 - (\bar{X})^2} \end{cases}$$

donde $\hat{\nu}$ y $\hat{k}$ son estimadores de ν y k respectivamente

Ejemplo: Estimación con distribución Normal

Si la distribución de variables $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Normal}(\mu, \sigma)$, entonces,

$$\begin{cases} \mu_1 = \mu = \bar{X} = m_1 \\ \mu_2 = \sigma^2 + \mu^2 = \bar{X}^2 = m_2 \end{cases}$$

Resolviendo el sistema de ecuaciones se tiene que

$$\begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \end{cases}$$

donde $\hat{\mu}$ y $\hat{\sigma}$ son estimadores de μ y σ respectivamente

Método de Máxima Verosimilitud:

Este método deriva directamente el estimador puntual del parámetro de interés.

Sea X variable aleatoria con función de probabilidad $f_X(x, \theta)$, donde θ es el parámetro de interés.

Dada una muestra (valores observados) $x_1, \dots, x_n$ asociadas a las variables aleatorias $X_1, \dots, X_n$ respectivamente, nos preguntamos cuál es el valor más probable de θ que produzca estos valores, es decir, cuál es el que maximiza la verosimilitud de los valores observados.

La función de verosimilitud, L ; de una muestra aleatoria $x_1, \dots, x_n$ es,

$$L(x_1, \dots, x_n, \theta) = f_{X_1, \dots, X_n}(x_1, \dots, x_n, \theta)$$

Si la muestra está asociada a V.A. independientes y también iid, entonces L para cada caso es

$$L(x_1, \dots, x_n, \theta) \stackrel{\text{iid}}{=} \prod_{i=1}^n f_{X_i}(x_i, \theta) \quad L(x_1, \dots, x_n, \theta) \stackrel{\text{iid}}{=} \prod_{i=1}^n f_X(x_i, \theta)$$

Se define el estimador de máxima verosimilitud (EMV) como el valor de θ que maximiza la función de verosimilitud L , es decir,

$$\frac{\partial}{\partial \theta} L(x_1, \dots, x_n, \theta) = 0 \rightarrow \hat{\theta} = \theta$$

Maximizar L es equivalente a maximizar $\ln(L)$, es decir,

$$\frac{\partial}{\partial \theta} \ln[L(x_1, \dots, x_n, \theta)] = 0$$

Si la función de distribución depende de más de un parámetro, $\theta_1, \dots, \theta_m$, los EMV respectivos son las soluciones de las m ecuaciones

$$\frac{\partial}{\partial \theta_j} \ln[L(x_1, \dots, x_n, \theta_1, \dots, \theta_m)] = 0, \quad j = 1, 2, \dots, m$$

Los EMV son estimadores que poseen las propiedades deseables descritas anteriormente.

En particular, para n grande, son “los mejores” estimadores (en el sentido de varianza mínima).

Ejemplo: Estimación con distribución Bernoulli

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$, entonces,

$$L(p) \stackrel{\text{iid}}{=} \prod_{i=1}^n p^{X_i} (1-p)^{1-X_i} = p^{\sum X_i} (1-p)^{n-\sum X_i}$$

$$\ln(L(p)) = \left(\sum X_i \right) \ln(p) + (n - \sum X_i) \ln(1-p)$$

$$\frac{\partial}{\partial p} \ln(L) = \frac{\sum X_i}{p} - \frac{n - \sum X_i}{1-p} = 0$$

despejando p se obtiene

$$\hat{p} = \bar{X}$$

Ejemplo: Estimación con distribución Poisson

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda)$, entonces,

$$L(\lambda) \stackrel{\text{iid}}{=} \prod_{i=1}^n \frac{\lambda^{X_i} e^{-\lambda}}{X_i!} = \lambda^{\sum X_i} e^{-n\lambda} \left(\prod_{i=1}^n X_i! \right)^{-1}$$

$$\ln(L) = \left(\sum X_i \right) \ln(\lambda) - n \cdot \lambda - \sum_{i=1}^n \ln(X_i!)$$

$$\frac{\partial}{\partial \lambda} \ln(L) = \frac{\sum X_i}{\lambda} - n = 0$$

despejando λ se obtiene

$$\hat{\lambda} = \bar{X}$$

Ejemplo: Estimación con distribución Exponencial

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\nu)$, entonces,

$$L(\nu) \stackrel{\text{iid}}{=} \prod_{i=1}^n \nu e^{-\nu X_i} = \nu^n e^{-\nu \sum X_i}$$

$$\ln(L) = n \ln(\nu) - \nu \sum X_i$$

$$\frac{\partial}{\partial \nu} \ln(L) = \frac{n}{\nu} - \sum X_i = 0$$

despejando ν se obtiene

$$\hat{\nu} = \frac{1}{\bar{X}}$$

Ejemplo: Estimación con distribución Gamma

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Gamma}(k, \nu)$, entonces,

$$L(k, \nu) \stackrel{\text{iid}}{=} \prod_{i=1}^n \frac{\nu^k}{\Gamma(k)} X_i^{k-1} e^{-\nu X_i} = \nu^{nk} \left(\prod X_i \right)^{k-1} e^{-\nu \sum X_i} (\Gamma(k))^{-n}$$

$$\ln(L) = nk \cdot \ln(\nu) + (k-1) \sum \ln(X_i) - \nu \sum X_i - n \cdot \ln(\Gamma(k))$$

$$\frac{\partial}{\partial \nu} \ln(L) = \frac{nk}{\nu} - \sum X_i = 0$$

despejando ν se obtiene

$$\hat{\nu} = \frac{\hat{k}}{\bar{X}}$$

como un estimador no puede quedar en función de otro estimador se busca el valor de $\hat{k}$, el cual se puede obtener de

$$\frac{\partial}{\partial k} \ln(L) = n \cdot \ln(\nu) + \sum \ln(X_i) - \frac{n}{\Gamma(k)} \frac{d\Gamma(k)}{dk} = 0$$

En esta ecuación es imposible obtener una expresión analítica de $\hat{k}$, por lo que se requiere de técnicas en métodos numéricos para obtener el valor, más adelante se verá que R permite obtener valores numéricos de este estimador.

Ejemplo: Estimación con idistribución Normal

Si la distribución de las variables es $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Normal}(\mu, \sigma)$, entonces,

$$L(\mu, \sigma) \stackrel{\text{iid}}{=} \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2} \left(\frac{X_i - \mu}{\sigma} \right)^2 \right] = (2\pi)^{-\frac{n}{2}} \sigma^{-n} \exp \left[-\frac{1}{2\sigma^2} \sum (X_i - \mu)^2 \right]$$

$$\ln(L) = -\frac{n}{2} \ln(2\pi) - n \cdot \ln(\sigma) - \frac{1}{2\sigma^2} \sum (X_i - \mu)^2$$

Para estimar la media

$$\frac{\partial}{\partial \mu} \ln(L) = \frac{1}{2\sigma^2} \sum 2(X_i - \mu) = 0$$

despejando μ se obtiene

$$\hat{\mu} = \bar{X}$$

Para estimar la varianza

$$\frac{\partial}{\partial \sigma} \ln(L) = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum (X_i - \mu)^2 = 0$$

despejando σ se obtiene

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

Ejemplo: Estimación con distribución Log-Normal

Si la distribución de las variables $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Log-Normal}(\lambda, \zeta)$, entonces

$$L(\lambda) \stackrel{\text{iid}}{=} \left(\frac{1}{\sqrt{2\pi}\zeta} \right)^n \cdot \prod_{i=1}^n \frac{1}{X_i} \cdot \exp \left[-\frac{1}{2} \sum \left(\frac{\ln(X_i) - \lambda}{\zeta} \right)^2 \right]$$
$$\ln(L) = n \cdot \ln \left(\frac{1}{\sqrt{2\pi}\zeta} \right) + \sum_{i=1}^n \ln \left(\frac{1}{x_i} \right) - \frac{1}{2} \sum_{i=1}^n \left(\frac{\ln(X_i) - \lambda}{\zeta} \right)^2$$

Para estimar el parámetro λ

$$\frac{\partial}{\partial \lambda} \ln(L) = \sum_{i=1}^n \left(\frac{\ln(X_i) - \lambda}{\zeta} \right) \cdot \frac{1}{\zeta} = 0$$

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n \ln(X_i) = \ln(\bar{X})$$

Para estimar el parámetro ζ

$$\frac{\partial}{\partial \zeta} \ln(L) = -\frac{n}{\zeta} + \frac{1}{\zeta^3} \sum_{i=1}^n (\ln(X_i) - \ln(\bar{X}))^2 = 0$$

Despejando ζ se obtiene

$$\hat{\zeta} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\ln(X_i) - \ln(\bar{X}))^2}$$

Nota: Algunos de estos ejemplos han aparecido en pruebas históricas, por lo que podrían ser reutilizadas.

Propiedades de los Estimadores Máximo Verosímiles

- *Asintóticamente Insesgados:* $E(\hat{\theta}) \rightarrow \theta$, cuando $n \rightarrow \infty$
- *Varianza alcanza la cota de Cramer-Rao:* $\text{Var}(\hat{\theta}_n) = \frac{1}{I_n(\theta)}$, con
$$I_n(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \ln(L(\theta)) \right] \quad (I_n \text{ se denomina Información de Fisher})$$
- *Distribución Asintótica:* Normal
- *Invarianza:* Si $\hat{\theta}_n$ es el estimador máximo verosímil de θ , entonces $g(\hat{\theta}_n)$ es el estimador máximo verosímil de $g(\theta)$ cuya distribución asintótica es

$$g(\hat{\theta}) \sim \text{Norma} \left(g(\theta), \sqrt{\frac{[g'(\theta)]^2}{I_n(\theta)}} \right)$$

Calculo de EM y EMV usando R

Importante, tener instalado el paquete “fitdistrplus”.

```
install.packages("fitdistrplus")  
library(fitdistrplus)
```

Para utilizar el comando para calcular los estimadores de momento (EM) se escribe la siguiente línea de código,

```
R: fitdist(data=BASE,distr="Distribución",method="mme")$estimate
```

Para utilizar el comando para calcular los estimadores de máximo verosímil (EMV) se escribe la siguiente línea de código,

```
R: fitdist(data=BASE,distr="Distribución",method="mle")$estimate
```

Para determinar la cota de Cramer-Rao se utiliza la siguiente línea de código

```
R: fitdist(data=BASE,distr="Distribución",method="mle")$sd**2
```

Distribuciones Muestrales

Distribución de la Media con Varianza Conocida

Sea $X_1, \dots, X_n$ una sucesión de variables aleatorias independientes con función de probabilidad $p_X(x)$ o de densidad $f_X(x)$.

Si $E(X) = \mu$ y $\text{Var}(X) = \sigma^2$, entonces el valor esperado y varianza de $\bar{X}_n$ son

$$\mu_{\bar{X}_n} = E(\bar{X}_n) = \mu$$

$$\sigma_{\bar{X}_n}^2 = \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$$

Si la distribución subyacente es Normal, entonces

$$\bar{X}_n \sim \text{Normal}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

En el caso que la distribución NO sea Normal, por el Teorema del Límite Central para n grande se cumple que

$$\bar{X}_n \sim \text{Normal}\left(\mu, \frac{\sigma}{\sqrt{n}}\right) \longrightarrow \underbrace{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}_{\text{Pivote}} \sim \text{Normal}(0, 1)$$

Distribución de la Media con Varianza Desconocida

Sea $X_1, \dots, X_n$ una sucesión de variables aleatorias independientes con función de probabilidad $p_X(x)$ o de densidad $f_X(x)$ tal que $E(X) = \mu$ y $\text{Var}(X) = \sigma^2$.

Generalmente la varianza poblacional es desconocida.

Para el caso, si se reemplaza σ^2 por su estimador muestral S^2 se tiene que

$$\frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim \text{t-Student}(n-1)$$

con

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{\hat{\sigma}^2 n}{n-1}$$

donde $\hat{\sigma}$ es el EMV de σ y S es el estimador insesgado para σ .

Distribución de la Varianza estimada con Media Desconocida

La varianza muestral está definida como

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1)$$

La varianza estimada (ya sea con método de momentos o máximo verosímil) sabiendo que μ es desconocido es

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (2)$$

En (1) se cumple la siguiente igualdad

$$\sum_{i=1}^n (X_i - \mu)^2 = (n-1)S^2 + n(\bar{X}_n - \mu)^2$$

Dividiendo en ambos lados por σ^2 se obtiene

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 = \underbrace{\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2}_{\chi^2(n)} - \underbrace{\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2}_{\chi^2(1)}$$

La resta de dos variables que distribuyen χ^2 también distribuye χ^2 con la resta de grados de libertad, es decir

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Además, en (2) se puede multiplicar en ambos lados con n y dividir en ambos lados con σ^2 y se tiene

$$\frac{n\hat{\sigma}^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \chi^2(n-1)$$

Como

$$\frac{n\hat{\sigma}^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2}$$

Entonces ambos distribuyen

$$\frac{n\hat{\sigma}^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Distribución de la Varianza estimada con Media Conocida

La varianza estimada (ya sea con método de momentos o máximo verosímil) sabiendo que μ es conocido es

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

Si se pasa el n al otro lado de la igualdad multiplicando a S^2 y de divide en ambos lado con σ^2 , entonces esto resulta en el siguiente pivote

$$\frac{n\hat{\sigma}^2}{\sigma^2} = \underbrace{\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2}_{\chi^2(n)}$$

Por lo tanto

$$\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n)$$

PRUEBA DE HIPÓTESIS

Una prueba de hipótesis es un método estadístico inferencial para la toma de decisiones sobre una población en base a la información proporcionada por los datos de una muestra.

La inferencia puede hacerse con respecto a uno a más parámetros de la población o también para un modelo de distribución.

Una hipótesis es una afirmación con respecto a uno a más parámetros de una población. Usualmente son dos las hipótesis que se contrastan:

- Hipótesis nula H_0 (Conservadora)
- Hipótesis alternativa H_a (Lo que se quiere probar)

La hipótesis nula es formulada como una igualdad, mientras que la hipótesis alternativa es normalmente un inequación.

Hipótesis nula: $H_0 : \mu = \mu_0$

Hipótesis alternativa: $H_a : \mu \neq \mu_0$

donde μ es un parámetro de la población y μ_0 es el parámetro específico o requerido estándar.

Procedimiento para una Prueba de Hipótesis

Los pasos necesarios en las pruebas de hipótesis son:

- Defina la hipótesis nula y alternativa.

$$H_0 : \mu = \mu_0 \quad vs \quad H_a : \mu \neq \mu_0$$

$$H_0 : \mu = \mu_0 \quad vs \quad H_a : \mu > \mu_0$$

$$H_0 : \mu = \mu_0 \quad vs \quad H_a : \mu < \mu_0$$

- Identificar la prueba estadística adecuada y su distribución.
- Basado en una muestra de datos observados estimar el estadístico de prueba
- Especificar el nivel de significancia (Riesgo).

Dado que el estadístico de prueba es una variable aleatoria, la probabilidad de una decisión errónea puede ser controlada. Los errores que se pueden cometer son

- **Error Tipo I:** Se rechaza H_0 dado que era correcta.
- **Error Tipo II:** No se rechaza H_0 dado que no era correcta.

La probabilidad de **Error Tipo I** se denota como α , la cual corresponde al nivel de significancia de la prueba de hipótesis.

La probabilidad real de cometer **Error Tipo I** se conoce como **Valor-p**.

Se tiene que si $\text{valor-p} < \alpha$, entonces se rechaza H_0 .



Prueba de hipótesis para μ con σ^2 conocido:

Sea $X_1, \dots, X_n$ una muestra aleatoria proveniente de una distribución Normal(μ, σ), entonces las hipótesis son,

$$H_0 : \mu = \mu_0 \quad vs \quad H_a : \mu \neq, <, > \mu_0$$

El estimador de μ es,


$$\hat{\mu} = \bar{X} \sim \text{Normal}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

entonces,


$$Z = \frac{\hat{\mu} - \mu}{\sigma/\sqrt{n}} \sim \text{Normal}(0, 1)$$

Se supone que H_0 es correcto ($\mu = \mu_0$)

$$Z_0 = \underbrace{\frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}}}_{\text{Estadístico de prueba}} \sim \text{Normal}(0, 1)$$



- $H_a : \mu \neq \mu_0$, entonces el valor-p es




$$\text{Valor-p} = 2 \cdot P(Z > |Z_0|)$$

- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

```
R: valor.p = 2*(1-pnorm(abs(Z0)))
```

- $H_a : \mu > \mu_0$, entonces el valor-p es




$$\text{Valor-p} = P(Z > Z_0)$$

- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

R: valor.p = 1-pnorm(Z0)

- $H_a : \mu < \mu_0$, entonces el valor-p es



$$\text{Valor-p} = P(Z < Z_0)$$

- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

R: valor.p = pnorm(Z0)


Prueba de hipótesis para μ con σ^2 desconocido:

Como este caso no se conoce el valor de σ^2 , entonces se tiene


$$T = \frac{\hat{\mu} - \mu}{S/\sqrt{n}} \sim \text{t-Student}(n-1)$$

Se supone que H_0 es correcto ($\mu = \mu_0$)

$$\underbrace{T_0 = \frac{\hat{\mu} - \mu_0}{S/\sqrt{n}}}_{\text{Estadístico de prueba}} \sim \text{t-Student}(n-1)$$



- $H_a : \mu \neq \mu_0$, entonces el valor-p es




$$\text{Valor-p} = 2 \cdot P(T > |T_0|)$$

- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

R: `valor.p = 2*(1-pt(abs(T0),n-1))`

- $H_a : \mu > \mu_0$, entonces el valor-p es




$$\text{Valor-p} = P(T > T_0)$$

- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

R: `valor.p = 1-pt(T0,n-1)`

- $H_a : \mu < \mu_0$, entonces el valor-p es



- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

R: `valor.p = pt(T0,n-1)`

Prueba de hipótesis para σ^2 con μ desconocido:


Si se quiere realizar una prueba de hipótesis para la varianza sin conocer el valor de μ , entonces se tiene

$$C = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$


Se supone que H_0 es correcto ($\sigma = \sigma_0$)

$$C_0 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$$

Estadístico de prueba




- $H_a : \sigma \neq \sigma_0$, entonces el valor-p es



- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

$$R: \text{valor.p} = \begin{cases} 2*(1-\text{pchisq}(C_0, n-1)), & \text{Si } C_0 > n-1 \\ 2*\text{pchisq}(C_0, n-1), & \text{Si } C_0 < n-1 \end{cases}$$

- $H_a : \sigma > \sigma_0$, entonces el valor-p es




$$\text{Valor-p} = P(C > C_0)$$

- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

$$R: \text{valor.p} = 1-\text{pchisq}(C_0, n-1)$$

- $H_a : \sigma < \sigma_0$, entonces el valor-p es



$$\text{Valor-p} = P(C < C_0)$$

- Si valor-p $< \alpha$, entonces se rechaza H_0
- Si valor-p $> \alpha$, entonces no se rechaza H_0

$$R: \text{valor.p} = \text{pchisq}(C_0, n-1)$$

Observación: Si la media es conocida, entonces se utiliza el estadístico de prueba $C_0 = \frac{n\hat{\sigma}^2}{\sigma_0^2} \sim \chi^2(n)$, por lo que se puede utilizar todo lo relacionado del caso de media desconocida pero utilizando n enés de $n-1$.

Prueba de hipótesis: Casos generales

Sea $X_1, \dots, X_n$ una muestra aleatoria proveniente de una distribución cuya función densidad f_θ depende de un parámetro θ y $\hat{\theta}$ es el estimador de máxima verosimilitud, entonces para las hipótesis

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_a : \theta \neq, <, > \theta_0$$

Un estadístico de prueba aproximado sería

$$Z_0 = \sqrt{I_n(\theta_0)}(\hat{\theta} - \theta_0) \sim \text{Normal}(0, 1)$$

Ejemplo: Estadístico de prueba para distribución Bernoulli

Si $X_1, \dots, X_n$ distribuyen iid Bernoulli(p), entonces

$$H_0 : p = p_0 \quad vs \quad H_a : p < p_0$$

Si el estimador de p distribuye aproximadamente

$$\hat{p} = \bar{X} \sim \text{Normal}\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$$

Entonces el estadístico de prueba es

$$Z_0 = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim \text{Normal}(0, 1)$$

Ejemplo: Estadístico de prueba para distribución Poisson

Si $X_1, \dots, X_n$ distribuye iid Poisson(λ), entonces

$$H_0 : \lambda = \lambda_0 \quad vs \quad H_a : \lambda < \lambda_0$$

Si el estimador de λ distribuye aproximadamente

$$\hat{\lambda} = \bar{X} \sim \text{Normal}\left(\lambda, \sqrt{\frac{\lambda}{n}}\right)$$

Entonces el estadístico de prueba es

$$Z_0 = \frac{\hat{\lambda} - \lambda_0}{\sqrt{\frac{\lambda_0}{n}}} \sim \text{Normal}(0, 1)$$

Ejemplo: Estadístico de prueba para distribución Exponencial

Si $X_1, \dots, X_n$ distribuye iid Exponencial(ν), entonces

$$H_0 : \nu = \nu_0 \quad vs \quad H_a : \nu < \nu_0$$

Para obtener el estimador de ν se utiliza el método de máximo verosimilitud

$$L(\nu) \stackrel{\text{iid}}{=} \nu^n e^{-\nu \sum X_i}$$

$$\ln(L) = n \cdot \ln(\nu) - \nu \sum X_i$$

$$\frac{\partial}{\partial \nu} \ln(L) = \frac{n}{\nu} - \sum X_i = 0 \rightarrow \hat{\nu} = \frac{1}{\bar{X}}$$

La segunda derivada de $\ln(L)$ es

$$\frac{\partial^2}{\partial \nu^2} \ln(L) = -\frac{n}{\nu^2}$$

La información de Fisher es

$$I_n(\nu) = -E\left(\frac{\partial^2}{\partial \nu^2} \ln(L)\right) = -E\left(\frac{n}{\nu^2}\right) = \frac{n}{\nu^2}$$

Si el estimador de ν distribuye aproximadamente

$$\hat{\nu} = \frac{1}{\bar{X}} \sim \text{Normal}\left(\nu, \sqrt{\frac{\nu^2}{n}}\right)$$

Entonces el estadístico de prueba es

$$Z_0 = \frac{\hat{\nu} - \nu_0}{\sqrt{\frac{\nu_0^2}{n}}} \sim \text{Normal}(0, 1)$$

Ejemplo: Estadístico de prueba para distribución Log-Normal

Si $X_1, \dots, X_n$ distribuyen iid Log-Normal(λ, ζ), entonces

■ **Alternativa 1 (Test de hipótesis sobre la mediana)**

$$H_0 : e^\lambda = e^{\lambda_0} \quad \text{vs} \quad H_a : e^\lambda \neq, <, > e^{\lambda_0}$$

Para obtener el estimador de λ se utiliza el método de máximo verosimilitud asumiendo ζ conocido

$$L(\lambda) \stackrel{\text{iid}}{=} \left(\frac{1}{\sqrt{2\pi}\zeta}\right)^n \cdot \prod_{i=1}^n \frac{1}{X_i} \cdot \exp\left[-\frac{1}{2} \sum \left(\frac{\ln(X_i) - \lambda}{\zeta}\right)^2\right]$$

$$\ln(L) = n \cdot \ln\left(\frac{1}{\sqrt{2\pi}\zeta}\right) + \sum_{i=1}^n \ln\left(\frac{1}{x_i}\right) - \frac{1}{2} \sum_{i=1}^n \left(\frac{\ln(X_i) - \lambda}{\zeta}\right)^2$$

$$\frac{\partial}{\partial \lambda} \ln(L) = \sum_{i=1}^n \left(\frac{\ln(X_i) - \lambda}{\zeta}\right) \cdot \frac{1}{\zeta} = 0$$

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n \ln(X_i)$$

La segunda derivada de $\ln(L)$ es

$$\frac{\partial^2}{\partial \lambda^2} \ln(L) = -\frac{n}{\zeta^2}$$

La información de Fisher es

$$I_n(\lambda) = -E\left(\frac{\partial^2}{\partial \lambda^2} \ln(L)\right) = -E\left(-\frac{n}{\zeta^2}\right) = \frac{n}{\zeta^2}$$

Si el estimador $g(\hat{\lambda}) = e^{\hat{\lambda}}$ distribuye aproximadamente

$$e^{\hat{\lambda}} = \sum_{i=1}^n X_i^{\frac{1}{n}} \sim \text{Normal}\left(e^\lambda, \sqrt{\frac{\zeta^2 e^{2\lambda}}{n}}\right)$$

Entonces el estadístico de prueba es

$$Z_0 = \frac{e^{\hat{\lambda}} - e^{\lambda_0}}{\sqrt{\frac{\zeta^2 e^{2\lambda}}{n}}} \sim \text{Normal}(0, 1)$$

■ **Alternativa 2 (Test de hipótesis sobre el estimador)**

$$H_0 : \lambda = \lambda_0 \quad \text{vs} \quad H_a : \lambda \neq, <, > \lambda_0$$

De la alternativa 1 se tiene que el estimador de λ con ζ conocido es

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n \ln(X_i)$$

La información de Fisher sigue siendo la misma

$$I_n(\lambda) = -E\left(\frac{\partial^2}{\partial \lambda^2} \ln(L)\right) = -E\left(-\frac{n}{\zeta^2}\right) = \frac{n}{\zeta^2}$$

Si el estimador $\hat{\lambda}$ distribuye aproximadamente

$$\hat{\lambda} = \sum_{i=1}^n \ln(X_i) \sim \text{Normal}\left(\lambda, \sqrt{\frac{\zeta^2}{n}}\right)$$

Entonces el estadístico de prueba es

$$Z_0 = \frac{\lambda - \lambda_0}{\sqrt{\frac{\zeta^2}{n}}}$$

Cálculo del valor-p en R

Para μ con σ^2 conocido (z.test())

Como σ es conocido, entonces

$$Z_0 \sim \text{Normal}(0, 1)$$

para determinar el valor-p se utiliza el siguiente código

```
R: install.packages("TeachingDemos")
library(TeachingDemos)

z.test(x=Base,mu=mu0,sd=sigma,alternative="Dirección")$p.value
```

Para μ con σ^2 desconocido (t.test())

Como σ^2 es desconocido entonces

$$T_0 \sim \text{t-Student}(n - 1)$$

para determinar el valor-p se utiliza el siguiente código

```
R: t.test(x=Base,mu=mu0,alternative="Dirección")$p.value
```

Para σ^2 con μ desconocido (sigma.test())

Para realizar una prueba de hipótesis con respecto a la desviación estándar se utiliza lo siguiente

```
R: sigma.test(x=Base,sigma=sigma0,alternative="Dirección")$p.value
```

Caso general (z.test())

Si $X_1, \dots, X_n$ distribuyen iid f_θ , y las hipótesis son $H_0 : \theta = \theta_0$ vs $H_a : \theta \neq, <, > \theta_0$, entonces para calcular el valor-p se necesita lo siguiente

```
R: install.packages("TeachingDemos")
library(TeachingDemos)

X=Base
z.test(x=theta.hat,mu=theta0,stdev=sqrt(CCR),alternative="Dirección") $p.value
```

Donde

- CCR es la cota de Cramer-Rao.
- `theta.hat` es el estimador del parámetros $\hat{\theta}$
- `theta0` es el parámetro a testear θ_0

Caso especial, test para proporción

Si $X_1, \dots, X_n$ distribuyen iid Bernoulli(p), y las hipótesis son $H_0 : p = p_0$ vs $H_a : p \neq, <, > p_0$, entonces para calcular el valor-p se utiliza lo siguiente

$$Z_0 = \frac{p - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim \text{Normal}(0, 1)$$

```
R: prop.test(x=X,n=N,p=p0,alternative="Dirección",correct=FALSE)
```

Donde

- `X` es la cantidad de éxitos o fracasos que se obtuvieron
- `N` es la cantidad total de experimentos
- `p0` es el parámetro a testear p_0

Nota: Si se utiliza el `z.test()`, entonces el comando para el test de proporciones es el siguiente

```
R: z.test(x=X/N,mu=p0,stdev=sqrt(p0(1-p0)/N),alternative="Dirección")$p.value
```

Para cada caso, con "Dirección" se refiere con respecto a la hipótesis alternativa, existen 3 casos

- `alternative="greater":` $H_a : \theta > \theta$
- `alternative="two.sided":` $H_a : \theta \neq \theta$
- `alternative="less":` $H_a : \theta < \theta$

Potencia y β

Se denota como β a la probabilidad de cometer un error de tipo II en una prueba de hipótesis, teniendo en cuenta el nivel de significancia α , Mientras que su complemento se conoce como la potencia de un test, es decir

$$\beta = P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa})$$
$$\text{Potencia} = P(\text{Rechazar } H_0 \mid H_0 \text{ es falsa}) = 1 - \beta$$

Por ejemplo, considerando $X_1, \dots, X_n$ una muestra aleatoria proveniente de una distribución Normal(μ, σ). Tenemos que $\bar{X}_n$ es un estimador insesgado y consistente para el parámetro μ , con distribución Normal($\mu, \sigma/\sqrt{n}$).

Si se quiere contrastar las siguientes hipótesis

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu \neq \mu_0$$

$$H_0 : \mu \leq \mu_0 \quad \text{vs} \quad H_a : \mu > \mu_0$$

$$H_0 : \mu \geq \mu_0 \quad \text{vs} \quad H_a : \mu < \mu_0$$

El estadístico de prueba, bajo el supuesto que H_0 es correcta y σ conocido es

$$Z_0 = \frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}} \sim \text{Normal}(0, 1)$$

- Para la primera hipótesis se rechaza H_0 si $|Z_0| > k_{1-\alpha/2}$, entonces

$$\text{Potencia}(Pt) = 1 - \beta$$

$$Pt = 1 - P(\text{No rechazar } H_0 | H_0 \text{ es falsa}) = P(\text{Rechazar } H_0 | H_0 \text{ es falsa})$$

$$Pt = P(|Z_0| > k_{1-\alpha/2} | \hat{\mu} = \mu_0 + \Delta)$$

$$Pt = P\left(\left|\frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}}\right| > k_{1-\alpha/2} \mid \hat{\mu} = \mu_0 + \Delta\right)$$

$$Pt = P\left(\frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}} > k_{1-\alpha/2} \mid \hat{\mu} = \mu_0 + \Delta\right) + P\left(\frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}} < -k_{1-\alpha/2} \mid \hat{\mu} = \mu_0 + \Delta\right)$$

$$Pt = 1 - \Phi\left(k_{1-\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma}\right) + \Phi\left(k_{\alpha/2} - \Delta \frac{\sqrt{n}}{\sigma}\right)$$

Notar que para $\Delta = 0 \rightarrow \hat{\mu} = \mu_0$ y la Potencia es igual a α .

- Para la segunda hipótesis se rechaza H_0 si $Z_0 > k_{1-\alpha}$, entonces

$$\text{Potencia}(Pt) = 1 - \beta$$

$$Pt = 1 - P(\text{No rechazar } H_0 | H_0 \text{ es falsa}) = P(\text{Rechazar } H_0 | H_0 \text{ es falsa})$$

$$Pt = P(Z_0 > k_{1-\alpha} | \hat{\mu} = \mu_0 + \Delta)$$

$$Pt = P\left(\frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}} > k_{1-\alpha} \mid \hat{\mu} = \mu_0 + \Delta\right)$$

$$Pt = 1 - \Phi\left(k_{1-\alpha} - \Delta \frac{\sqrt{n}}{\sigma}\right)$$

Notar que para $\Delta = 0 \rightarrow \hat{\mu} = \mu_0$ y la Potencia es igual a α .

- Para la tercera hipótesis se rechaza H_0 si $Z_0 < k_\alpha$, entonces

$$\text{Potencia}(Pt) = 1 - \beta$$

$$Pt = 1 - P(\text{No rechazar } H_0 | H_0 \text{ es falsa}) = P(\text{Rechazar } H_0 | H_0 \text{ es falsa})$$

$$Pt = P(Z_0 < k_\alpha | \hat{\mu} = \mu_0 + \Delta)$$

$$Pt = P\left(\frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}} < k_\alpha \mid \hat{\mu} = \mu_0 + \Delta\right)$$

$$Pt = \Phi\left(k_\alpha - \Delta \frac{\sqrt{n}}{\sigma}\right)$$

Notar que para $\Delta = 0 \rightarrow \hat{\mu} = \mu_0$ y la Potencia es igual a α .

Observación: El valor de Δ se obtiene mediante la condicional, es decir, $\Delta = \hat{\mu} - \mu_0$

Intervalos de Confianza para la media

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población cuya distribución es $\text{Normal}(\mu, \sigma)$.

Ya vimos que un estimador insesgado y consistente para μ esta dado por

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim \text{Normal}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Intervalo de Confianza para μ con σ^2 conocido

Se tiene que

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \text{Normal}(0, 1)$$

Luego, se puede mostrar que el intervalo para el parámetro μ a un nivel de confianza de $1 - \alpha$ es

$$\langle \mu \rangle_{1-\alpha} \in \bar{X}_n \pm k_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

donde

- $k_{1-\alpha/2} = \Phi^{-1}(1 - \alpha/2) = \text{qnorm}(1-\alpha/2)$

Intervalo de Confianza para μ con σ^2 desconocido

Se tiene que

$$T_n = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim \text{t-Student}(n-1)$$

Luego, se puede mostrar que el intervalo para el parámetro μ a un nivel de confianza de $1 - \alpha$ es

$$\langle \mu \rangle_{1-\alpha} \in \bar{X}_n \pm t_{1-\alpha/2}(n-1) \cdot \frac{S}{\sqrt{n}}$$

donde

- $S = \text{sd}(X)$
- $t_{1-\alpha/2}(n-1) = \text{qt}(1-\alpha/2, \text{df}=n-1)$

Determinación del Tamaño de Muestra

Como se aprecia en la construcción de los Intervalos de Confianza, el tamaño de muestra es fundamental

Al observar el Intervalo de Confianza para μ , se aprecia que el semiancho está dado por

$$k_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} = \omega$$

Lo anterior se conoce como **Error de Estimación**.

Por lo tanto, para una precisión w dada, es posible determinar el tamaño de muestra necesaria, con σ y α fijos, dado por

$$n = \left(\frac{\sigma \cdot k_{1-\alpha/2}}{\omega} \right)^2$$

Si σ es desconocido, entonces se utiliza S^2 , por lo que el tamaño de muestra se determina como sigue

$$n = \left(\frac{S \cdot t_{1-\alpha/2}(n-1)}{\omega} \right)^2$$

Este último caso no es posible realizarlo fácilmente, por lo que se utilizará la fórmula para σ conocido.

Intervalos de Confianza para σ^2 con μ desconocido

Considerando una muestra aleatorias $X_1, \dots, X_n$ proveniente de una población cuya distribución es $\text{Normal}(\mu, \sigma)$.

Recordando que un estimador insesgado y consistente para σ^2 esta dado por

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \Rightarrow \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Se tiene que

$$C_n = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Luego, se puede mostrar que el intervalo para el parámetro σ^2 a un nivel de confianza de $1 - \alpha$ es

$$\langle \sigma^2 \rangle_{1-\alpha} \in \left[\frac{(n-1)S^2}{c_{1-\alpha/2}(n-1)}; \frac{(n-1)S^2}{c_{\alpha/2}(n-1)} \right]$$

donde

- $c_{1-\alpha/2}(n-1) = \text{qchisq}(1-\alpha/2, n-1)$
- $c_{\alpha/2}(n-1) = \text{qchisq}(\alpha/2, n-1)$

Intervalos de Confianza Asintóticos

¿Qué sucede fuera de la Normalidad?

Sea $\hat{\theta}$ el estimador de máxima verosimilitud de un parámetro θ . A partir del siguiente pivote

$$Z_n = \frac{\hat{\theta} - \theta}{\sqrt{\widehat{\text{Var}}(\hat{\theta})}} \sim \text{Normal}(0, 1)$$

se tiene que el intervalo para el parámetro θ a un nivel de confianza de $1 - \alpha$ es

$$\langle \theta \rangle_{1-\alpha} \in \hat{\theta} \pm k_{1-\alpha/2} \cdot \sqrt{\widehat{\text{Var}}(\hat{\theta})}$$

donde

- $\widehat{\text{Var}}(\hat{\theta}) = \frac{1}{I_n(\hat{\theta})}$: Varianza del estimador estimada

Utilizando la propiedad de invarianza de los estimadores de máxima verosimilitud, si se tiene una función del del parámetro θ , $g(\theta)$, entonces $g(\hat{\theta})$ es su EMV, El pivote en este caso es:

$$Z_n = \frac{g(\hat{\theta}) - g(\theta)}{\sqrt{\widehat{\text{Var}}(g(\hat{\theta}))}} \sim \text{Normal}(0, 1)$$

El intervalo para $g(\theta)$ a un nivel de confianza de $1 - \alpha$ es

$$\langle g(\theta) \rangle_{1-\alpha} \in g(\hat{\theta}) \pm k_{1-\alpha/2} \cdot \sqrt{\widehat{\text{Var}}(g(\hat{\theta}))}$$

donde

- $\widehat{\text{Var}}(g(\hat{\theta})) = \frac{[g'(\hat{\theta})]^2}{I_n(\hat{\theta})}$: Varianza de la función del estimador estimada

A continuación se muestra un ejemplo del intervalo para el parámetro p de una muestra Bernoulli a un nivel de confianza $1 - \alpha$.

Ejemplo: Intervalo de Confianza para distribución Bernoulli (Proporción)

Considerando una muestra aleatoria $X_1, \dots, X_n$ proveniente de una población cuya distribución es Bernoulli(p).

Un estimado insesgado y consistente para p está dado por

$$\hat{p} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim \text{Normal} \left(p, \sqrt{\frac{p(1-p)}{n}} \right)$$

El pivote a utilizar es el siguiente

$$Z_n = \frac{\hat{p} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \sim \text{Normal}(0, 1)$$

ya que $\widehat{\text{Var}}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ Reemplazando con el estimador de p se tiene

$$Z_n = \frac{\bar{X}_n - p}{\sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}}} \sim \text{Normal}(0, 1)$$

Luego, el Intervalo de Confianza es

$$\langle p \rangle_{1-\alpha} \in \bar{X}_n \pm k_{1-\alpha/2} \cdot \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}}$$

Así como se definieron las ecuaciones para el tamaño muestral en el caso Normal, se pueden encontrar expresiones cuando las variables están fuera de la normalidad, a continuación se muestra el caso cuando las variables aleatorias tienen distribución Bernoulli(p).

Ejemplo: Tamaño muestral de distribución Bernoulli (Proporción)

Si se calcula el tamaño muestral para proporciones, entonces se tiene los siguiente

$$\omega = k_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

$$n = \left(\frac{k_{1-\alpha/2} \sqrt{p(1-p)}}{\omega} \right)^2$$

La pregunta ahora es, ¿qué p se utiliza?, existen 2 opciones

- Utilizar un valor p de un estudio previo o dado
- Utilizar un valor de p que maximiza la varianza (*Criterio de varianza máxima*)

Para esta segunda opción se tiene que el valor de p que maximiza la varianza es $p = \frac{1}{2}$, por lo que el tamaño muestral es

$$n = \left(\frac{k_{1-\alpha/2}}{2\omega} \right)^2$$

Nota: Si se desea obtener el intervalo de confianza, ya sea para la media, varianza o algún otro parámetro θ ; para un nivel de confianza $1 - \alpha$, se puede utilizar un argumento extra en los comandos vistos en *Cálculo del vapor-p en R*, este argumento es `conf.level=1-alfa`

Comparación de dos Poblaciones e Intervalos de Confianza

Caso bajo Normalidad

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras independientes con distribución $\text{Normal}(\mu_X, \sigma_X)$ y $\text{Normal}(\mu_Y, \sigma_Y)$ respectivamente.

Con medias y varianzas muestrales dadas por

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \bar{Y}_m = \frac{1}{m} \sum_{j=1}^m Y_j$$
$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad S_Y^2 = \frac{1}{m-1} \sum_{j=1}^m (Y_j - \bar{Y}_m)^2$$

Se tiene lo siguiente

$$\underbrace{\bar{X}_n \sim \text{Normal}(\mu_X, \sigma_X/\sqrt{n}), \bar{Y}_m \sim \text{Normal}(\mu_Y, \sigma_Y/\sqrt{m})}_{\text{Independientes}}$$
$$\underbrace{C_X = \frac{(n-1)S_X^2}{\sigma_X^2} \sim \chi^2(n-1), C_Y = \frac{(m-1)S_Y^2}{\sigma_Y^2} \sim \chi^2(m-1)}_{\text{Independientes}}$$

Comparando las medias y varianzas

$$\underbrace{\bar{X}_n - \bar{Y}_m \approx 0}_{\text{Iguales}} \quad \underbrace{\frac{S_X^2}{S_Y^2} \approx 1}_{\text{Iguales}}$$

Test de comparación de medias

Si las hipótesis planteadas son

$$H_0 : \mu_X = \mu_Y \quad \text{vs} \quad H_a : \mu_X <, \neq, > \mu_Y$$

Entonces se tienen los siguientes estadísticos de prueba.

- Para μ_X y μ_Y si σ_X y σ_Y son conocidos:

$$Z_0 = \frac{\bar{X}_n - \bar{Y}_m}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim \text{Normal}(0, 1)$$

```
R: z.test(x=X,y=Y,alternative="Dirección",mu=0,sigma.x=sd(X),sigma.y=sd(Y))
```

- Para μ_X y μ_Y si σ_X y σ_Y son desconocidos pero iguales:

$$T_0 = \frac{\bar{X}_n - \bar{Y}_m}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim \text{t-Student}(n+m-2)$$

Donde

$$S_p^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$$

```
R: t.test(x=X,y=Y,alternative="Dirección",mu=0,var.equal=TRUE)
```

- Para μ_X y μ_Y si σ_X y σ_Y son desconocidos pero diferentes:

$$T_0 = \frac{\bar{X}_n - \bar{Y}_m}{\sqrt{\frac{S_X^2}{n} + \frac{S_Y^2}{m}}} \sim \text{t-Student}(\nu)$$

Donde

$$\bullet \nu = \frac{\left(\frac{S_X^2}{n} + \frac{S_Y^2}{m}\right)^2}{\frac{(S_X^2/n)^2}{n-1} + \frac{(S_Y^2/m)^2}{m-1}}$$

R: `t.test(x=X,y=Y,alternative="Dirección",mu=0,var.equal=FALSE)`

Test de comparación de varianzas

Si las hipótesis planteadas son

$$H_0 : \sigma_X^2 = \sigma_Y^2 \quad vs \quad H_a : \sigma_X^2 <, \neq, > \sigma_Y^2$$

Entonces se tienen los siguientes estadísticos de prueba.

- Para σ_X^2 y σ_Y^2 con μ_X y μ_Y son desconocidos:

$$F_0 = \frac{[(n-1)S_X^2/\sigma_X^2]/(n-1)}{[(m-1)S_Y^2/\sigma_Y^2]/(m-1)} = \frac{S_X^2}{S_Y^2} \sim \text{Fisher}(n-1, m-1)$$

Nota: Este resultado aparece debido a la siguiente propiedad:

$$\underbrace{U \sim \chi^2(\nu), V \sim \chi^2(\eta)}_{\text{Independientes}}$$

Entonces

$$F = \frac{U/\nu}{V/\eta} \sim \text{Fisher}(\nu, \eta)$$

R: `var.test(x=X,y=Y,alternative="Dirección")`

Nota: Si se desea realizar un test de comparación de medias y los valores de las varianzas son desconocidos, entonces se debe realizar como primer paso un test de comparación de varianzas para determinar si se puede asumir que las varianzas poblacionales (σ_X^2, σ_Y^2) son iguales o no, dependiendo el resultado se utiliza el test de comparación de medias con varianzas desconocidas iguales o diferentes.

Caso fuera de Normalidad: Bernoulli

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras independientes con distribución Bernoulli(p_X) y Bernoulli(p_Y) respectivamente, entonces

$$H_0 : p_X = p_Y \quad vs \quad H_a : p_X <, \neq, > p_Y$$

$$\frac{\bar{X}_n - \bar{Y}_m}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n} + \frac{1}{m}\right)}} \sim \text{Normal}(0, 1)$$

Para test de hipótesis

$$\frac{(\bar{X}_n - \bar{Y}_m) - (p_X - p_Y)}{\sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n} + \frac{\bar{Y}_m(1-\bar{Y}_m)}{m}}} \sim \text{Normal}(0, 1)$$

Para Intervalos de Confianza

En el segundo caso, mediante el pivote se puede construir el intervalo de confianza para la diferencia de proporciones poblacionales:

$$\langle p_X - p_Y \rangle_{1-\alpha} \in (\bar{X}_n - \bar{Y}_m) \pm k_{1-\alpha/2} \cdot \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n} + \frac{\bar{Y}_m(1-\bar{Y}_m)}{m}}$$

R: `z.test(x=X/n-Y/m, stdev=sqrt(p*(1-p)*(1/n+1/m)), mu=0, alternativa="Dirección")`
o también: `prop.test(x=c(X,Y), n=c(n,m), correct=FALSE, alternative="Dirección")`
Donde:

- **X, Y:** Cantidad de éxitos o fracasos de las variables X e Y respectivamente
- **n, m:** Cantidad total de experimentos de las variables X e Y respectivamente
- **p:** Estimador en común, $p_X = p_Y = p$

Caso fuera de Normalidad: Poisson

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras independientes con distribución $\text{Poisson}(\lambda_X)$ y $\text{Poisson}(\lambda_Y)$ respectivamente, entonces

$$H_0 : \lambda_X = \lambda_Y \quad \text{vs} \quad H_a : \lambda_X <, \neq, > \lambda_Y$$

$$\frac{\bar{X}_n - \bar{Y}_m}{\sqrt{\hat{\lambda}\left(\frac{1}{n} + \frac{1}{m}\right)}} \sim \text{Normal}(0, 1)$$

Para test de hipótesis

$$\frac{(\bar{X}_n - \bar{Y}_m) - (\lambda_X - \lambda_Y)}{\sqrt{\frac{\bar{X}_n}{n} + \frac{\bar{Y}_m}{m}}} \sim \text{Normal}(0, 1)$$

Para Intervalos de Confianza

En el segundo caso, mediante el pivote se puede construir el intervalo de confianza para la diferencia de eventos ocurridos en un intervalo de tiempo/espacio poblacionales:

$$\langle \lambda_X - \lambda_Y \rangle_{1-\alpha} \in (\bar{X}_n - \bar{Y}_m) \pm k_{1-\alpha/2} \cdot \sqrt{\frac{\bar{X}_n}{n} + \frac{\bar{Y}_m}{m}}$$

R: `z.test(x=lambdaX-lambdaY, stdev=sqrt(lambda*(1/n+1/m)), mu=0, alternative="Dir")`
Donde:

- **n, m:** Cantidad total de datos de las variables X e Y respectivamente
- **lambda:** Estimador en común, $\lambda_X = \lambda_Y = \lambda$

Caso fuera de Normalidad: Exponencial

Sean $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$ dos muestras independientes con distribución Exponencial(ν_X) y Exponencial(ν_Y) respectivamente, entonces

$$H_0 : \mu_X = \frac{1}{\nu_X} = \frac{1}{\nu_Y} = \mu_Y \quad vs \quad H_a : \mu_X = \frac{1}{\nu_X} <, \neq, > \frac{1}{\nu_Y} = \mu_Y$$

$$\underbrace{\frac{\bar{X}_n - \bar{Y}_m}{\hat{\nu} \sqrt{\frac{1}{n} + \frac{1}{m}}}}_{\text{Para test de hipótesis}} \sim \text{Normal}(0, 1)$$

$$\underbrace{\frac{(\bar{X}_n - \bar{Y}_m) - \left(\frac{1}{\nu_X} - \frac{1}{\nu_Y}\right)}{\sqrt{\frac{\bar{X}_n^2}{n} + \frac{\bar{Y}_m^2}{m}}}}_{\text{Para Intervalos de Confianza}} \sim \text{Normal}(0, 1)$$

En el segundo caso, mediante el pivote se puede construir el intervalo de confianza para la diferencia de las tasas de ocurrencia poblacionales:

$$\left\langle \frac{1}{\nu_X} - \frac{1}{\nu_Y} \right\rangle_{1-\alpha} \in (\bar{X}_n - \bar{Y}_m) \pm k_{1-\alpha/2} \cdot \sqrt{\frac{\bar{X}_n^2}{n} + \frac{\bar{Y}_m^2}{m}}$$

R: `z.test(x=1/vX-1/vY,stdev=(1/v)*sqrt(1/n+1/m),mu=0,alternative="Dirección")`

Donde:

- **n, m:** Cantidad total de datos de las variables X e Y respectivamente
- **v:** Estimador en común, $\nu_X = \nu_Y = \nu$

Estimadores en común

Cuando se realizan los test de comparación de poblaciones de los casos Bernoulli, Poisson y Exponencial, bajo la hipótesis nula $H_0, \theta_X = \theta_Y = \theta$, pero no se conoce cual es dicho valor de θ y no se pueden utilizar los estimadores de θ_X y θ_Y ya que por lo general no son iguales, por lo que es necesario determinar un estimador común de dicho parámetro, para eso se supone que la muestra de n variables aleatorias X y m variables aleatorias Y tienen la misma distribución con el mismo parámetro y mediante el método de máxima verosimilitud es posible encontrar $\hat{\theta}$. A continuación se muestran los estimadores en común para el caso Bernoulli, Poisson y Exponencial bajo las siguientes hipótesis:

$$H_0 : \theta_X = \theta_Y \quad vs \quad H_a : \theta_X \neq \theta_Y$$

Entonces bajo H_0 se tiene que $\hat{\theta}_X = \hat{\theta}_Y = \hat{\theta}$

- **Caso Bernoulli:** Bajo H_0 el estimador en común es

$$\hat{p} = \frac{n\bar{X} + m\bar{Y}}{n + m}$$

- **Caso Poisson:** Bajo H_0 el estimador en común es

$$\hat{\lambda} = \frac{n\bar{X} + m\bar{Y}}{n + m}$$

- **Caso Exponencial:** Bajo H_0 el estimador en común es

$$\hat{\nu} = \frac{n + m}{n\bar{X} + m\bar{Y}}$$

Anexo I: Valores-p y Valores Críticos para Pruebas de Hipótesis

El valor-p se define como la probabilidad real de cometer Error Tipo I y su calculo depende de la hipótesis alternativa, el valor crítico es un valor tal que acumula una probabilidad igual al nivel de significancia α , es decir, $P(X < x_c) = \alpha$ o $P(X > x_c) = \alpha$, para determinarlo es necesario conocer la hipótesis alternativa.

Prueba de Hipótesis para la Media con Varianza Conocida (Test Z)

Si $X_1, \dots, X_n$ es una muestra aleatoria con distribución Normal(μ, σ) y el valor de σ es conocido previamente, entonces el estadístico de prueba para la media y su distribución exacta es:

$$Z_0 = \frac{\hat{\mu} - \mu_0}{\sigma/\sqrt{n}} \sim \text{Normal}(0, 1)$$

donde:

- $\hat{\mu}$ es el estimador de μ : $\hat{\mu} = \bar{X}$
- μ_0 es el valor de μ a probar
- σ es el valor de la desviación estándar poblacional, es decir, corresponde a la distribución Normal
- n es el tamaño de la muestra

La hipótesis nula y alternativa son las siguientes:

$$H_0 : \mu = \mu_0 \quad H_a : \mu \neq, >, < \mu_0$$

El valor-p y el valor crítico son los siguientes:

- Si $H_a : \mu \neq \mu_0$:

$$\text{valor-p} = 2 \cdot P(Z \geq |Z_0|)$$

$$Z_c = k_{1-\alpha/2}$$

donde $k_{1-\alpha/2}$ es un valor k tal que $\Phi(k) = 1 - \alpha/2$.

- Si $H_a : \mu > \mu_0$:

$$\text{valor-p} = P(Z \geq Z_0)$$

$$Z_c = k_{1-\alpha}$$

donde $k_{1-\alpha}$ es un valor de k tal que $\Phi(k) = 1 - \alpha$.

- Si $H_a : \mu < \mu_0$

$$\text{valor-p} = P(Z \leq Z_0)$$

$$Z_c = k_\alpha$$

donde k_α es un valor de k tal que $\Phi(k) = \alpha$.

Criterio de Rechazo con Valores-p para Test Z

Al trabajar con una distribución Normal, calcular el valor-p es muy sencillo con el uso de la tabla Normal(0,1), por lo que:

$$\text{valor-p} \leq \alpha : \text{Rechazo } H_0$$

$$\text{valor-p} > \alpha : \text{No rechazo } H_0$$

Criterio de Rechazo con Valores Críticos para Test Z

En el caso de utilizar valores críticos Z_c , el criterio de rechazo es diferente de acuerdo con la hipótesis alternativa:

- Si $H_a : \mu \neq \mu_0$, se rechaza H_0 si:

$$Z_0 \leq k_{\alpha/2} \quad \text{o} \quad Z_0 \geq k_{1-\alpha/2} \longrightarrow |Z_0| \geq k_{1-\alpha/2}$$

El valor de $k_{1-\alpha/2}$ no presenta problemas para encontrarlo en la tabla, pero si el de $k_{\alpha/2}$ ya que, por lo general, es un valor negativo y la tabla solo cuenta con valores positivos, por lo que se puede utilizar la siguiente relación:

$$k_{\alpha/2} = -k_{1-\alpha/2}$$

- Si $H_a : \mu > \mu_0$, se rechaza H_0 si:

$$Z_0 \geq k_{1-\alpha}$$

El valor de $k_{1-\alpha}$ se puede encontrar fácilmente en la tabla Normal(0,1).

- Si $H_a : \mu < \mu_0$, se rechaza H_0 si:

$$Z_0 \leq k_\alpha$$

El valor de k_α por lo general es un número negativo, por lo que no está en la tabla Normal(0,1) ya que esta cuenta solamente con valores positivos, por lo que se puede utilizar la siguiente relación:

$$k_\alpha = -k_{1-\alpha}$$

Prueba de Hipótesis para la Media con Varianza Desconocida (Test T)

Si $X_1, \dots, X_n$ es una muestra aleatoria con distribución Normal(μ, σ) y el valor de σ no es conocido previamente, entonces el estadístico de prueba para la media y su distribución exacta es:

$$T_0 = \frac{\hat{\mu} - \mu_0}{S/\sqrt{n}} \sim \text{t-Student}(n-1)$$

donde:

- $\hat{\mu}$ es el estimador de μ : $\hat{\mu} = \bar{X}$
- μ_0 es el valor de μ a probar
- S es la desviación estándar muestral y se utiliza para estimar a σ , el valor depende de la muestra
- n es el tamaño de la muestra

La hipótesis nula y alternativa son las siguientes:

$$H_0 : \mu = \mu_0 \quad H_a : \mu \neq, >, < \mu_0$$

El valor-p y el valor crítico son los siguientes:

- Si $H_a : \mu \neq \mu_0$:

$$\text{valor-p} = 2 \cdot P(T \geq |T_0|)$$

$$T_c = t_{1-\alpha/2}(n-1)$$

donde $t_{1-\alpha/2}(n-1)$ es un valor de t tal que $P(T \leq t) = 1 - \alpha/2$.

- Si $H_a : \mu > \mu_0$:

$$\text{valor-p} = P(T \geq T_0)$$

$$T_c = t_{1-\alpha}(n-1)$$

donde $t_{1-\alpha}(n-1)$ es un valor de t tal que $P(T \leq t) = 1 - \alpha$.

- Si $H_a : \mu < \mu_0$:

$$\text{valor-p} = P(T \leq T_0)$$

$$T_c = t_\alpha(n-1)$$

donde $t_\alpha(n-1)$ es un valor de t tal que $P(T \leq t) = \alpha$.

Criterio de Rechazo con Valores-p para test T

Calcular valores-p exactos mediante una distribución t-Student es complicado ya que no hay una tabla similar a la tabla Normal(0,1), la tabla de la distribución t-Student muestra únicamente los percentiles para ciertas probabilidades, es decir, dada una cierta probabilidad acumulada p y un cierto grado de libertad ν se puede encontrar el percentil $t_p(\nu)$ tal que $P(T \leq t) = p$, debido a esto conviene hacer una aproximación del valr-p mediante un intervalo en donde puede estar el verdadero valor, para mostrar esto se utiliza el siguiente ejemplo.

Ejemplo: Aproximación de Valor-p

Suponiendo que se tiene la hipótesis nulas y alternativa de la siguiente forma:

$$H_0 : \mu = \mu_0 \quad H_a : \mu > \mu_0$$

y el estadístico de prueba resulta en un valor de:

$$T_0 = 2$$

$$T_0 \sim \text{t-Student}(20)$$

el valor-p a calcular de acuerdo a la hipótesis nula es:

$$\begin{aligned}\text{valor-p} &= P(T > T_0) \\ &= P(T > 2) \\ &= 1 - P(T \leq 2)\end{aligned}$$

para determinar el valor-p es necesario obtener el valor de $P(T \leq 2)$, para esto se fija en la tabla t-Student $\nu = 20$ y se busca dos valores en donde pueda estar 2, estos valores son 1.725 y 2.082. Estos dos valores cumplen con la siguiente característica:

$$t_{0.95}(20) = 1.725 \longrightarrow P(T \leq 1.725) = 0.95$$

$$t_{0.975}(20) = 2.082 \longrightarrow P(T \leq 2.082) = 0.975$$

En base a estos dos valores se tiene un intervalo para T_0 :

$$1.725 < 2 < 2.082$$

Aplicando la probabilidad $P(T \leq t)$ a la inecuación se tiene el siguiente intervalo para $P(T \leq 2)$:

$$P(T \leq 1.725) < P(T \leq 2) < P(T \leq 2.082)$$

$$0.95 < P(T \leq 2) < 0.975$$

Finalmente, multiplicando por -1 y sumando 1 a la inecuación se obtiene un intervalo para el valor-p pedido:

$$-0.975 < -P(T \leq 2) < -0.95$$

$$1 - 0.975 < 1 - P(T \leq 2) < 1 - 0.95$$

$$0.025 < P(T > 2) < 0.05$$

$$2.5 \% < \text{valor-p} < 5 \%$$

En base a este rango, se rechaza H_0 si $\alpha \geq 5 \%$ y no se rechaza H_0 si $\alpha \leq 2.5 \%$.

Criterio de Rechazo con Valores Críticos para test T

En el caso de utilizar valores críticos T_c , el criterio de rechazo es diferente de acuerdo con la hipótesis alternativa:

- Si $H_a : \mu \neq \mu_0$, se rechaza H_0 si:

$$T_0 \leq t_{\alpha/2}(n-1) \quad \text{o} \quad T_0 \geq t_{1-\alpha/2}(n-1) \longrightarrow |T_0| \geq t_{1-\alpha/2}(n-1)$$

El valor de $t_{1-\alpha/2}(n-1)$ es posible determinarlo por tabla, pero el valor de $t_{\alpha/2}(n-1)$, al ser un número negativo, no es posible encontrarlo directamente de la tabla ya que esta solo presenta valores de t positivos, por lo que se puede utilizar la siguiente relación:

$$t_{\alpha/2}(n-1) = -t_{1-\alpha/2}(n-1)$$

- Si $H_a : \mu > \mu_0$, se rechaza H_0 si:

$$T_0 \geq t_{1-\alpha}(n-1)$$

El valor de $t_{1-\alpha}$ es posible encontrarlo en la tabla t-Student ya que suele ser un valor de t positivo.

- Si $H_a : \mu < \mu_0$, se rechaza H_0 si:

$$T_0 \leq t_\alpha(n-1)$$

Como el valor de $t_\alpha(n-1)$ suele ser un valor de t negativo, entonces se puede utilizar la siguiente relación:

$$t_\alpha(n-1) = -t_{1-\alpha}(n-1)$$

Prueba de Hipótesis para la Varianza/Desv. Estándar con Media Desconocida (Test C)

Si $X_1, \dots, X_n$ es una muestra aleatoria con distribución Normal(μ, σ) y el valor de μ no es conocido previamente, entonces el estadístico de prueba para la varianza/desviación estándar y su distribución exacta es:

$$C_0 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$$

donde:

- S es la desviación estándar muestral y se utiliza para estimar a σ , el valor depende de la muestra
- σ_0 es el valor de σ a probar
- n es el tamaño de la muestra

La hipótesis nula y alternativa son las siguientes:

$$H_0 : \sigma = \sigma_0 \quad H_a : \sigma \neq, >, < \sigma_0$$

El valor-p y el valor crítico son los siguientes:

- Si $H_a : \sigma \neq \sigma_0$:

$$\text{valor-p} = \begin{cases} 2 \cdot P(C \geq C_0), & \text{si } C_0 > n-1 \\ 2 \cdot P(C \leq C_0), & \text{si } C_0 < n-1 \end{cases}$$

$$C_c = \begin{cases} c_{1-\alpha/2}(n-1), & \text{si } C_0 > n-1 \\ c_{\alpha/2}(n-1), & \text{si } C_0 < n-1 \end{cases}$$

donde $c_{\alpha/2}(n-1)$ y $c_{1-\alpha/2}(n-1)$ son valores de c tal que $P(C \leq c) = \alpha/2$ y $P(C \leq c) = 1 - \alpha/2$ respectivamente.

- Si $H_a : \sigma > \sigma_0$:

$$\text{valor-p} = P(C \geq C_0)$$

$$C_c = c_{1-\alpha}(n-1)$$

donde $c_{1-\alpha}(n-1)$ es un valor de c tal que $P(C \leq c) = 1 - \alpha$.

- Si $H_a : \sigma < \sigma_0$:

$$\text{valor-p} = P(C \leq C_0)$$

$$C_c = c_\alpha(n-1)$$

donde $c_\alpha(n-1)$ es un valor de c tal que $P(C \leq c) = \alpha$.

Criterio de Rechazo con Valor-p para test C

Al igual que el test T , se debe aproximar el valor-p a algún intervalo donde pueda estar su verdadero valor. Para mostrar esto se utiliza el siguiente ejemplo.

Ejemplo: Aproximación de Valor-p

Suponiendo que se tiene la hipótesis nula y alternativa de la siguiente forma:

$$H_0 : \sigma = \sigma_0 \quad H_a : \sigma \neq \sigma_0$$

y el estadístico de prueba resulta en un valor de:

$$C_0 = 7.5$$

$$C_0 \sim \chi^2(15)$$

ya que $C_0 < 15$, el valor-p a calcular de acuerdo a la hipótesis nula es:

$$\begin{aligned}\text{valor-p} &= 2 \cdot P(C \leq C_0) \\ &= 2 \cdot P(C \leq 7.5)\end{aligned}$$

Para determinar el valor-p es necesario determinar la probabilidad $P(C \leq 7.5)$, para esto se fija en la tabla Chi-cuadrado $\nu = 15$ y se busca dos valores en donde pueda estar 7.5, estos valores son 7.26 y 8.55. Estos dos valores cumplen con la siguiente característica:

$$c_{0.05}(15) = 7.26 \longrightarrow P(C \leq 7.26) = 0.05$$

$$c_{0.1}(15) = 8.55 \longrightarrow P(C \leq 8.55) = 0.1$$

En base a estos dos valores se tiene un intervalo para C_0 :

$$7.26 < 7.5 < 8.55$$

Aplicando la probabilidad $P(C \leq c)$ a la inecuación se tiene el siguiente intervalo para $P(C \leq 7.5)$:

$$P(C \leq 7.26) < P(C \leq 7.5) < P(C \leq 8.55)$$

$$0.05 < P(C \leq 7.5) < 0.1$$

Finalmente, multiplicando por 2 a la inecuación se obtiene un intervalo para el valor-p pedido:

$$2 \cdot 0.05 < 2 \cdot P(C \leq 7.5) < 2 \cdot 0.1$$

$$0.1 < \text{valor-p} < 0.2$$

$$10\% < \text{valor-p} < 20\%$$

En base a este rango, se rechaza H_0 si $\alpha \geq 20\%$ y no se rechaza H_0 si $\alpha \leq 10\%$.

Criterio de Rechazo con Valores Críticos para test C

En el caso de utilizar valores críticos C_c , e criterio de rechazo es diferente de acuerdo con la hipótesis alternativa:

- Si $H_a : \sigma \neq \sigma_0$, se rechaza H_0 si:

$$C_0 \leq c_{\alpha/2}(n-1) \quad \text{o} \quad C_0 \geq c_{1-\alpha/2}(n-1)$$

Los valores de $c_{\alpha/2}(n-1)$ y $c_{1-\alpha/2}(n-1)$ se pueden encontrar en la tabla Chi-cuadrado ya que esta distribución no es simétrica, por lo que no existe una relación como en los casos anteriores.

- Si $H_a : \sigma > \sigma_0$, se rechaza H_0 si:

$$C_0 \geq c_{1-\alpha}(n-1)$$

El valor de $c_{1-\alpha}(n-1)$ es posible encontrarlo en la tabla fácilmente.

- Si $H_a : \sigma < \sigma_0$, se rechaza H_0 si:

$$C_0 \leq c_{\alpha}(n-1)$$

El valor de $c_{\alpha}(n-1)$ es posible encontrarlo en la tabla fácilmente.

Prueba de Hipótesis: Caso General (Test Z Aproximado)

Si $X_1, \dots, X_n$ es una muestra aleatoria con alguna distribución, si se desea realizar un test de hipótesis para el parámetro θ de la distribución, entonces el estadístico de prueba para este parámetro y su distribución aproximada es:

$$Z_0 = \sqrt{I_n(\theta)}(\hat{\theta} - \theta_0) \sim \text{Normal}(0, 1)$$

donde:

- $\hat{\theta}$ es el estimador de máxima verosimilitud del parámetro θ
- $I_n(\theta)$ es la *Información de Fisher* del parámetro θ : $I_n(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \ln(L(\theta)) \right]$

- θ_0 es el valor de θ a probar

El calculo del valor-p, valor crítico y los criterios de rechazo son los mismos que en el test Z .

Si se desea realizar un test de hipótesis para alguna función dependiente del parámetro θ , $g(\theta)$, entonces el estadístico de prueba para esta función y su distribución aproximada es:

$$Z_0 = \frac{g(\hat{\theta}) - g(\theta_0)}{\sqrt{\frac{[g'(\theta)]^2}{I_n(\theta)}}} \sim \text{Normal}(0, 1)$$

donde:

- $g(\hat{\theta})$ es el estimador de máxima verosimilitud de $g(\theta)$
- $I_n(\theta)$ es la *Información de Fisher* del parámetro θ : $I_n(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \ln(L(\theta)) \right]$
- $g(\theta_0)$ es el valor de $g(\theta)$ a probar

El calculo del valor-p, valor crítico y los criterios de rechazo son los mismos que en el test Z .

Prueba de Hipótesis: Test de Proporción

Este test es cuando se quiere analizar una proporción (un porcentaje) de una muestra. Si $X_1, \dots, X_n$ es una muestra aleatoria con distribución Bernoulli(p), entonces el estadístico de prueba para p y su distribución aproximada es:

$$Z_0 = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}} \sim \text{Normal}(0, 1)$$

donde:

- $\hat{p}$ es el estimador para p : $\hat{p} = \bar{X}$
- p_0 es el valor de p a probar
- n es el tamaño de la muestra

Cómo el estadístico de prueba distribuye asintóticamente Normal, entonces el cálculo de los valores-p y valores críticos así como los criterios de rechazo de acuerdo a la hipótesis alternativa son iguales que los del test Z .

Prueba de Hipótesis: Distribución Poisson

Este test es cuando se quiere analizar la cantidad de eventos ocurridos en un cierto intervalo de tiempo o espacio. Si $X_1, \dots, X_n$ es una muestra aleatoria con distribución Poisson(λ), entonces el estadístico de prueba para λ y su distribución aproximada es:

$$Z_0 = \frac{\hat{\lambda} - \lambda_0}{\sqrt{\frac{\lambda_0}{n}}} \sim \text{Normal}(0, 1)$$

donde:

- $\hat{\lambda}$ es el estimador de λ : $\hat{\lambda} = \bar{X}$
- λ_0 es el valor de λ a probar
- n es el tamaño de la muestra

Cómo el estadístico de prueba distribuye asintóticamente Normal, entonces el cálculo de los valores-p y valores críticos así como los criterios de rechazo de acuerdo a la hipótesis alternativa son iguales que los del test Z .

Prueba de Hipótesis: Distribución Exponencial

Si $X_1, \dots, X_n$ es una muestra aleatoria con distribución Exponencial(ν), si se quiere analizar la tasa de ocurrencia de un cierto evento, entonces el estadístico de prueba para ν y su distribución aproximada es:

$$Z_0 = \frac{\hat{\nu} - \nu_0}{\sqrt{\frac{\nu_0^2}{n}}} \sim \text{Normal}(0, 1)$$

donde:

- $\hat{\nu}$ es el estimador de ν : $\hat{\nu} = \frac{1}{\bar{X}}$
- ν_0 es el valor de ν a probar
- n es el tamaño de la muestra

Si se desea analizar el tiempo medio entre eventos, entonces se define la siguiente función $g(\nu) = \mu = \frac{1}{\nu}$, entonces el estadístico de prueba para $g(\nu)$ y su distribución aproximada es:

$$Z_0 = \frac{\hat{\mu} - \mu_0}{\sqrt{\frac{[g'(\theta)]^2}{I_n(\theta)}}} = \frac{g(\hat{\nu}) - g(\nu_0)}{\sqrt{\frac{1}{\nu_0^2 n}}} \sim \text{Normal}(0, 1)$$

donde:

- $g(\hat{\nu})$ es el estimador de máxima verosimilitud de $g(\nu)$: $g(\hat{\nu}) = \frac{1}{\hat{\nu}} = \bar{X}$
- $g(\nu_0)$ es el valor de $g(\nu)$ a probar: $g(\nu_0) = \frac{1}{\nu_0}$
- n es el tamaño de la población.

Cómo los estadísticos de prueba distribuyen asintóticamente Normal, entonces el cálculo de los valores-p y valores críticos así como los criterios de rechazo de acuerdo a la hipótesis alternativa son iguales que los del test Z .

Anexo II: Obtención de los estimadores en común para test de comparaciones de poblaciones fuera de Normalidad

Los estimadores en común para los test de comparación de poblaciones fuera de la Normalidad no se encuentran en el formulario oficial del curso, una forma de aprenderlos es que son *promedios*, esto se puede ver con el caso Bernoulli, Poisson y Exponencial (este último es un poco especial pero se basa en la misma idea), pero otra forma es saber como obtenerlos. Para un test de comparación de proporciones se tienen las siguientes hipótesis:

$$H_0 : \theta_X = \theta_Y \quad \text{vs} \quad H_a : \theta_X \neq, >, < \theta_Y$$

Los estadísticos de prueba aproximados se construyen bajo H_0 , es decir, se supone que H_0 es previamente verdadero y el test se encarga en invalidar o confirmar esta suposición, por lo tanto, para encontrar los estimadores en común de dos muestras se suponen que los parámetros son iguales (gracias a H_0), a continuación se muestra el desarrollo para el caso Bernoulli, Poisson y Exponencial.

- **Caso Bernoulli:** Sean dos muestras aleatorias, $X_1, \dots, X_n$ iid Bernoulli e $Y_1, \dots, Y_m$ iid Bernoulli, ambos con parámetro igual a p ,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$$

$$Y_1, \dots, Y_m \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$$

La función de verosimilitud es:

$$\begin{aligned} L(p) &\stackrel{\text{iid}}{=} \prod_{i=1}^n p_X(X_i) \times \prod_{j=1}^m p_Y(Y_j) \\ &= \prod_{i=1}^n p^{X_i} (1-p)^{1-X_i} \times \prod_{j=1}^m p^{Y_j} (1-p)^{1-Y_j} \\ &= p^{\sum X_i} (1-p)^{\sum (1-X_i)} p^{\sum Y_j} (1-p)^{\sum (1-Y_j)} \end{aligned}$$

La función de log-verosimilitud es:

$$\ln[L(p)] = \sum_{i=1}^n X_i \ln(p) + \sum_{i=1}^n (1-X_i) \ln(1-p) + \sum_{j=1}^m Y_j \ln(p) + \sum_{j=1}^m (1-Y_j) \ln(1-p)$$

Derivando respecto a p e igualando a cero se obtiene el estimador p :

$$\begin{aligned} \frac{d}{dp} \ln[L(p)] &= 0 \\ \frac{1}{p} \sum_{i=1}^n X_i - \frac{1}{1-p} \sum_{i=1}^n (1-X_i) + \frac{1}{p} \sum_{j=1}^m Y_j - \frac{1}{1-p} \sum_{j=1}^m (1-Y_j) &= 0 \\ \frac{1}{p} \sum_{i=1}^n X_i - \frac{n}{1-p} + \frac{1}{1-p} \sum_{i=1}^n X_i + \frac{1}{p} \sum_{j=1}^m Y_j - \frac{m}{1-p} + \frac{1}{1-p} \sum_{j=1}^m Y_j &= 0 \\ \frac{1}{p} \left(\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j \right) + \frac{1}{1-p} \left(-n + \sum_{i=1}^n X_i - m + \sum_{j=1}^m Y_j \right) &= 0 \\ \frac{1}{p} \left(\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j \right) &= \frac{1}{1-p} \left(n - \sum_{i=1}^n X_i + m - \sum_{j=1}^m Y_j \right) \\ \frac{1-p}{p} &= \frac{1}{p} - 1 = \frac{n - \sum_{i=1}^n X_i + m - \sum_{j=1}^m Y_j}{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j} \\ \frac{1}{p} &= \frac{n+m}{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j} \\ \hat{p} &= \frac{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j}{n+m} \\ \hat{p} &= \frac{n\bar{X}_n + m\bar{Y}_m}{n+m} \end{aligned}$$

- **Caso Poisson:** Sean dos muestras aleatorias, $X_1, \dots, X_n$ iid Poisson e $Y_1, \dots, Y_m$ iid Poisson, ambos con parámetro igual a λ ,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda)$$

$$Y_1, \dots, Y_m \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda)$$

La función de verosimilitud es:

$$\begin{aligned} L(\lambda) &\stackrel{\text{iid}}{=} \prod_{i=1}^n p_X(X_i) \times \prod_{j=1}^m p_Y(Y_j) \\ &= \prod_{i=1}^n \frac{\lambda^{X_i} e^{-\lambda}}{X_i!} \times \prod_{j=1}^m \frac{\lambda^{Y_j} e^{-\lambda}}{Y_j!} \\ &= \lambda^{\sum X_i} e^{-n\lambda} \left(\prod_{i=1}^n X_i! \right)^{-1} \lambda^{\sum Y_j} e^{-m\lambda} \left(\prod_{j=1}^m Y_j! \right)^{-1} \end{aligned}$$

La función de log-verosimilitud es:

$$\ln[L(\lambda)] = \sum_{i=1}^n X_i \ln(\lambda) - n\lambda - \sum_{i=1}^n \ln(X_i!) + \sum_{j=1}^m Y_j \ln(\lambda) - m\lambda - \sum_{j=1}^m \ln(Y_j!)$$

Derivando respecto a λ e igualando a cero se obtiene el estimador de λ :

$$\begin{aligned} \frac{d}{d\lambda} \ln[L(\lambda)] &= 0 \\ \frac{1}{\lambda} \sum_{i=1}^n X_i - n + \frac{1}{\lambda} \sum_{j=1}^m Y_j - m &= 0 \\ \frac{1}{\lambda} \left(\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j \right) &= n + m \\ \frac{1}{\lambda} &= \frac{n + m}{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j} \\ \hat{\lambda} &= \frac{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j}{n + m} \\ \hat{\lambda} &= \frac{n\bar{X}_n + m\bar{Y}_m}{n + m} \end{aligned}$$

- **Caso Exponencial:** Sean dos muestras aleatorias, $X_1, \dots, X_n$ iid Exponencial e $Y_1, \dots, Y_m$ iid Exponencial, ambos con parámetro igual a ν ,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exponencial}(\nu)$$

$$Y_1, \dots, Y_m \stackrel{\text{iid}}{\sim} \text{Exponencial}(\nu)$$

La función de verosimilitud es:

$$\begin{aligned} L(\lambda) &\stackrel{\text{iid}}{=} \prod_{i=1}^n f_X(X_i) \times \prod_{j=1}^m f_Y(Y_j) \\ &= \prod_{i=1}^n \nu e^{-\nu X_i} \times \prod_{j=1}^m \nu e^{-\nu Y_j} \\ &= \nu^n e^{-\nu \sum X_i} \nu^m e^{-\nu \sum Y_j} \end{aligned}$$

La función de log-verosimilitud es:

$$\ln[L(\nu)] = n \ln(\nu) - \nu \sum_{i=1}^n X_i + m \ln(\nu) - \nu \sum_{j=1}^m Y_j$$

Derivando respecto a ν e igualando a cero se obtiene el estimador de ν :

$$\begin{aligned} \frac{d}{d\nu} \ln[L(\nu)] &= 0 \\ \frac{n}{\nu} - \sum_{i=1}^n X_i + \frac{m}{\nu} - \sum_{j=1}^m Y_j &= 0 \\ \frac{1}{\nu} (n + m) &= \sum_{i=1}^n X_i + \sum_{j=1}^m Y_j \end{aligned}$$

$$\frac{1}{\nu} = \frac{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j}{n+m}$$

$$\hat{\nu} = \frac{n+m}{\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j}$$

$$\hat{\nu} = \frac{n+m}{n\bar{X}_n + m\bar{Y}_m}$$

Capítulo 5

Determinación de Modelos de Probabilidad

Introducción

El modelo de distribución de probabilidad apropiado para describir un fenómeno es generalmente desconocido.

Bajo ciertas circunstancias, las propiedades básicas del proceso físico subyacente del fenómeno aleatorio sugiere la forma de la distribución de probabilidades

Ejemplos

- Cumple vs No cumple $\rightarrow$ Bernoulli
- Número de “eventos” en periodos $\rightarrow$ Poisson
- Tiempos de duración o espera $\rightarrow$ Exponencial, Gamma, Weibull
- Suma de eventos individuales $\rightarrow$ Normal
- Condiciones extremas de un proceso $\rightarrow$ Valor Extremo

En muchas situaciones, la distribución de probabilidad debe ser determinada empíricamente a partir de los datos.

Inicialmente, aproximaciones gráficas (Histograma v/s Densidad) nos pueden ayudar a inferir “visualmente” sobre la distribución.

También, con datos disponibles, pueden obtenerse los gráficos de probabilidad (Probability Papers) para distribuciones dadas (si los puntos están en línea recta, la distribución es apropiada).

Por ultimo, dada una distribución a priori puede evaluarse la “bondad de ajuste” (Test χ^2 , Test de Kolmogorov-Smirnov o el Test de Anderson-Darling, entre otros).

Gráficos de Probabilidad

Es la representación gráfica de los datos observados y sus correspondientes frecuencias acumuladas.

Para un conjunto de N observaciones, $x_1, \dots, x_N$, ordenados de menor a mayor, el m -ésimo valor es graficado contra la probabilidad acumulada de $\frac{m}{N+1}$.

La utilidad del “papel” de probabilidad es reflejar el “ajuste” que presentan los datos con respecto a la distribución subyacente.

La linealidad o falta de esta nos indica lo adecuado o inadecuado de la distribución.

Gráfico de probabilidad de Distribución Normal

Sean $x_1, \dots, x_N$ observaciones ordenadas de menor a mayor y $p_1 = \frac{1}{N+1}, \dots, p_N = \frac{N}{N+1}$ sus respectivas probabilidades empíricas.

Calculando los percentiles teóricos, $\Phi^{-1}(p_i)$, de una distribución Normal Estándar para cada p_i , con $i = 1, \dots, N$.

Si los x 's distribuyen $\text{Normal}(\mu, \sigma)$, entonces la siguiente relación lineal se debe cumplir

$$x_{p_q} = \mu + \sigma \cdot \Phi^{-1}(p_q)$$

Donde

- Pendiente: σ
- Intercepto: μ

Gráfico de probabilidad de Distribución Log-Normal

Sean $x_1, \dots, x_N$ observaciones ordenadas de menor a mayor y $p_1 = \frac{1}{N+1}, \dots, p_N = \frac{N}{N+1}$ sus respectivas probabilidades empíricas.

Calculando los percentiles teóricos, $\Phi^{-1}(p_i)$, de una distribución Normal Estándar para cada p_i , con $i = 1, \dots, N$.

Si los x 's distribuyen $\text{Log-Normal}(\lambda, \zeta)$, entonces la siguiente relación lineal se debe cumplir

$$\ln(x_{p_q}) = \lambda + \zeta \cdot \Phi^{-1}(p_q)$$

Donde

- Pendiente: ζ
- Intercepto: λ

Gráfico de probabilidad de Distribución Exponencial

Sean $x_1, \dots, x_N$ observaciones ordenadas de menor a mayor y $p_1 = \frac{1}{N+1}, \dots, p_N = \frac{N}{N+1}$ sus respectivas probabilidades empíricas.

Calculando los percentiles teóricos, $-\ln(1 - p_i)$, de una distribución Exponencial(1) para cada p_i , con $i = 1, \dots, N$.

Si los x 's distribuyen $\text{Exponencial}(\nu)$ trasladada en α , entonces la siguiente relación lineal se debe cumplir

$$x_{p_q} = \alpha + \frac{1}{\nu} \cdot [-\ln(1 - p_q)]$$

Donde

- Pendiente: $\frac{1}{\nu}$
- Intercepto: α

Gráfico de probabilidad de Distribución Weibull

Sean $x_1, \dots, x_N$ observaciones ordenadas de menor a mayor y $p_1 = \frac{1}{N+1}, \dots, p_N = \frac{N}{N+1}$ sus respectivas probabilidades empíricas.

Calculando los percentiles teóricos, $\ln(-\ln(1-p_i))$, para cada p_i , con $i = 1, \dots, N$.

Si los x 's distribuyen Weibull(η, β), entonces la siguiente relación lineal se debe cumplir

$$\ln(x_{p_q}) = \ln(\eta) + \frac{1}{\beta} \cdot \ln(-\ln(1-p_q))$$

Donde

- Pendiente: $\frac{1}{\beta}$
- Intercepto: $\ln(\eta)$

Gráfico de probabilidad de Distribución Logística

Sean $x_1, \dots, x_N$ observaciones ordenadas de menor a mayor y $p_1 = \frac{1}{N+1}, \dots, p_N = \frac{N}{N+1}$ sus respectivas probabilidades empíricas.

Calculando los percentiles teóricos, $\log\left(\frac{p}{1-p}\right)$, para cada p_i , con $i = 1, \dots, N$.

Si los x 's distribuyen Logística(μ, σ), entonces la siguiente relación lineal se debe cumplir

$$x_{p_q} = \mu + \sigma \cdot \log\left(\frac{p_q}{1-p_q}\right)$$

Donde

- Pendiente: σ
- Intercepto: μ

Gráfico de probabilidad de Distribución Log-Logística

Sean $x_1, \dots, x_N$ observaciones ordenadas de menor a mayor y $p_1 = \frac{1}{N+1}, \dots, p_N = \frac{N}{N+1}$ sus respectivas probabilidades empíricas.

Calculando los percentiles teóricos, $\log\left(\frac{p}{1-p}\right)$, para cada p_i , con $i = 1, \dots, N$.

Si los x 's distribuyen Log-Logística(μ, σ), entonces la siguiente relación lineal se debe cumplir

$$\ln(x_{p_q}) = \mu + \sigma \cdot \log\left(\frac{p_q}{1-p_q}\right)$$

Donde

- Pendiente: σ
- Intercepto: μ

Observación: En algunas ocasiones no estará explícito cual es la distribución asociada a un gráfico de probabilidad, para es necesario observar la construcción de la variable dependiente (Y) y de la variable independiente (X) en el gráfico para saber a que distribución está asociada.

Uso de R para gráficos de probabilidad

Si se quieren estimar los parámetros θ y ω de la siguiente relación lineal asociada a una distribución de probabilidad

$$Y(x_p) = b(\theta) + m(\omega) \cdot X(p)$$

Para crear el gráfico de probabilidades (QQ-Plot) se siguen los siguientes pasos

```
R: X = Base # Importar la base de datos y filtrar la variable a utilizar
xp = sort(X) # Se ordenan los datos de menor a mayor, son los percentiles
empíricos
n = length(X) # Se obtiene el largo de X

P = (1:n)/(n+1) # Se crea un vector con las probabilidades empíricas

xt = X(P) # Percentiles teóricos, Q(P) cambia con la distribución

plot(xt, Y(xp), ...) # Gráfico de probabilidad de Y(xp) vs xt

abline(lm(Y(xp) ~ xt),...) # Crea la línea de ajuste entre Y(xp) y xt

recta = lm(Y(xp) ~ xt)$coef # Muestra el intercepto y la pendiente

b(theta) = recta[1] # De aquí se puede despejar el valor de theta
m(omega) = recta[2] # De aquí se puede despejar el valor de omega
```

Test de Bondad de Ajuste

Test de Kolmogorov-Smirnov

Si se tiene una muestra observada de datos y se desea conocer cuál es la distribución que ajusta de mejor ajusta a estos datos, se puede utilizar el test de Kolmogorov-Smirnov, conocido también como test KS, para eso se suponen las siguientes dos hipótesis:

$$H_0 : X \sim f_X(x) \quad \text{vs} \quad H_a : X \not\sim f_X(x)$$

donde X es la variable aleatoria asociada a los datos observados y $f_X(x)$ es la distribución a la que se está suponiendo que los datos pueden distribuir. Bajo H_0 se tiene el siguiente estadístico de prueba:

$$D = \max\{|F_n(x) - F_X(x)|\}$$

Con $F_n(x)$ función de distribución acumulada empírica, es decir, asociada a la muestra observada, y $F_X(x)$ función de distribución acumulada teórica del modelo que se quiere ajustar.

Los criterios de rechazo son los mismos que en prueba de hipótesis, si valor-p $> \alpha$, no se rechaza H_0 , por lo que la distribución supuesta ajusta a los datos muestrales.

Test Chi-cuadrado χ^2

Caso parámetros conocidos

Considerando una muestra de n valores observados de una variables aleatoria X y suponiendo una distribución de probabilidad subyacente $f_X(x)$, se tiene las siguientes hipótesis a comprobar:

$$H_0 : X \sim f_X(x) \quad \text{vs} \quad H_a : X \not\sim f_X(x)$$

El test χ^2 de bondad de ajuste compara las frecuencias observadas $O_1, \dots, O_k$ de k valores (o k intervalos) de la variable con sus correspondientes frecuencias teóricas $E_1, \dots, E_k$ calculados suponiendo la distribución teórica para cada valor i o intervalo i ($[i-1, i]$) con $i = 1, \dots, k$, es decir:

$$E_i = n \cdot P(X \leq i) = n \cdot F_X(i) \quad \text{o} \quad E_i = n \cdot (i-1 \leq X \leq i) = F_X(i) - F_X(i-1)$$

Tener cuidado con el cálculo de probabilidades teóricas con distribuciones discretas.

Para evaluar la calidad del ajuste se usa el siguiente estadístico de prueba

$$X^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi^2(k-1)$$

El criterio para aceptar la hipótesis nula es el siguiente:

- Si $X^2 < c_{1-\alpha}(k-1)$, se acepta H_0 , los datos se ajustan por la distribución supuesta.
- Si valor-p $> \alpha$, se acepta H_0 , los datos se ajustan por la distribución supuesta.

En cada caso:

- $c_{1-\alpha}(k-1) = \text{qchisq}(1-\alpha, \text{df}=f)$ es tal que $P(C \leq c) = 1 - \alpha$.
- valor-p $= P(C > X^2) = 1 - \text{pchisq}(X^2, \text{df}=k-1)$.

Sugerencia: Se sugiere utilizar este test cuando $k \geq 5$ y $E_i \geq 5$.

Caso parámetros desconocidos

Utilizando las hipótesis anteriormente planteadas, si los parámetros de la distribución a la que está queriendo ajustar los datos son desconocidos, estos deben ser estimados a partir de la muestra observada (puede ser por EM, EMV, QQ-Plot) y debe ser descontado de los grados de libertad de la distribución (por cada parámetro estimado).

El estadístico de prueba tendrá una distribución aproximada $\chi^2(f)$, donde el parámetro f es $f = k - 1 - \nu$, con ν la cantidad de parámetros estimados para la distribución $f_X(x)$.

El criterio para aceptar la hipótesis nula es el siguiente:

- Si $X^2 < c_{1-\alpha}(f)$, se acepta H_0 , los datos se ajustan por la distribución supuesta.
- Si valor-p $> \alpha$, se acepta H_0 , los datos se ajustan por la distribución supuesta.

En cada caso:

- $c_{1-\alpha}(f) = \text{qchisq}(1-\alpha, \text{df}=f)$ es tal que $P(C \leq c) = 1 - \alpha$.
- valor-p $= P(C > X^2) = 1 - \text{pchisq}(X^2, \text{df}=f)$.

Sugerencia: Se sugiere utilizar este test cuando $k \geq 5$ y $E_i \geq 5$.

Uso de R para test de Bondad de Ajuste

Test de Kolmogorov-Smirnov `ks.test()`

Si se quiere hacer el test de Kolmogorov-Smirnov para una variable proveniente de una base de datos suponiendo que podría ajustar alguna distribución se toman las siguientes hipótesis

H_0 : La distribución ajusta a los datos obtenidos

H_a : La distribución no ajusta a los datos obtenidos

Para realizar este test de hipótesis se utiliza el siguiente comando

```
R: ks.test(x=Base, "Distribución", par1 = , par2= , ..., parn= )
```

Donde

- **Base:** Contiene los datos de la variable a utilizar
- **"Distribución":** Se utiliza la distribución supuesta
- **par1,...,parn:** Son los parámetros de la distribución escogida

Al aplicar este comando se obtiene lo siguiente

```
One-Sample Kolmogorov-Smirnov test

data: Base
D = ____ , p-value= _____
alternative hypothesis: two-sided
```

Donde

- **D:** Es el estadístico de prueba del test
- **p-value:** es el valor-p correspondiente a D

Para llamar directamente al estadístico o al valor-p se utiliza lo siguiente

```
R: ks.test()$statistic # Llama al valor del estadístico
ks.test()$p.value # Llama al valor-p
```

Si se utiliza un valor de α , entonces

- **Valor-p < α :** Se rechaza H_0 , los datos no distribuyen la distribución escogida
- **Valor-p > α :** No se rechaza H_0 , los datos distribuyen la distribución escogida

Test de Chi-cuadrado χ^2 `chisq.test()`

Si se quiere hacer el test de χ^2 para una variable proveniente de una base de datos suponiendo que podría ajustar alguna distribución y utilizando una cantidad de intervalos, entonces se timan las siguientes hipótesis

H_0 : La distribución ajusta a los datos obtenidos

H_a : La distribución no ajusta a los datos obtenidos

Para realizar este test de hipótesis se utiliza lo siguiente

Se supone que los intervalos son (Dependiendo el problema pueden ser más)

$$(-\infty, a); [a, b); [b, \infty)$$

Entonces

```
R: X=base
par1,...,parn= # Cuando no se entregan los parámetros

# Cálculo de frecuencias observadas
# Método manual (No recomendable con gran cantidad de intervalos)
O = c(sum(X<a), sum(X<b) - sum(X<=a), sum(X>=b))
# Método rápido
x=c(-Inf,a,b,Inf)
O = hist(X, plot=F, breaks = x, right = F/T)$count
  ▪ right = T: Se considera que los intervalos son cerrados por la derecha (]
  ▪ right = F: Se considera que los intervalos son cerrados por la izquierda [) (Si no se coloca
    right=F, el comando asume esto por defecto)
k=length(O) # Es el número de grupos o intervalos
```

```
n = sum(0) # equivalente a length(X)

# Calculo de la probabilidades teóricas
# Uso del comando diff()
p = diff(pDISTR(c(-Inf,a,b,Inf),par1= ,...,parn= ))

# Sin el uso de diff()
p = c(pDISTR(a,...), pDISTR(b,...)-pDISTR(a,...), 1-pDISTR(b,...))
# p = (P(X<a), P(a<= X <b), P(X>=b))
```

Nota1: Tener cuidado al trabajar con distribuciones discretas

```
# Uso del comando chisq.test()
X2 = chisq.test(x=0, p=p)$statistic
```

```
# Calculo del valor-p
valor.p=1-pchisq(X2, df=k-1-nu)
```

Nota2: Si no se estimó ningún parámetro de la distribución, nu=0

Nota3: Tener cuidado con los intervalos

Nota4: Verificar que sum(p)=1

Ejemplo: Uso de test Chi-cuadrado

Se lanza 90 veces un dado y se registra la cantidad de veces que aparece cada número, determine si el dado corresponde a un dado honesto

Solución:

El enunciado pide demostrar si el conjunto de datos, en este caso la cantidad de veces que aparece cada número, sigue la distribución de probabilidad *Uniforme Discreta*, es decir

$$X_1, \dots, X_{90} \stackrel{\text{iid}}{\sim} \text{Uniforme}(1, 2, 3, 4, 5, 6)$$

ya que un *dado honesto* significa que cada número de este tiene la misma probabilidad de aparecer. Para esto se realiza una prueba de χ^2 de la siguiente manera.

Se crea una tabla como la siguiente

Categoría	Observado	Prob. teo. (p_i)	Esperado (np_i)	X^2
1	12	1/6	15	9/15
2	17	1/6	15	4/15
3	15	1/6	15	0
4	14	1/6	15	1/15
5	18	1/6	15	9/15
6	14	1/6	15	1/15
Total	$n = 90$	$p_T = 1$	$n = 90$	$X^2 = 1.6$

Cada columna de la tabla representa lo siguiente

- **Categoría:** O intervalos, en este ejemplo son los números correspondientes a cada cara del dado
- **Observado:** La cantidad de veces que apareció cada número de manera experimental
- **Prob. teo.:** Es la probabilidad de observar cada número de acuerdo a la distribución supuesta, como distribuye uniforme discreta entonces cada número tiene la misma probabilidad

- **Esperado:** Es la cantidad de veces que se espera observar cada número de manera teórica
- **X^2 :** Es el estadístico de prueba

De la tabla se obtiene que el estadístico de prueba, X^2 , es de $X^2 = 1.6 \sim \chi^2(6-1)$, ya que no se estimó ningún parámetro no se deben restar grados de libertad, por lo que el valor-p corresponde a

$$\text{valor-p} = P(X^2 > 1.6) = 0.9012$$

Se puede realizar este proceso de manera más rápida utilizando R como sigue

```
R: 0 = c(12,17,15,14,18,14)
p = rep(1/6,6)
k = length(0)

X2 = chisq.test(x=0,p=p)$statistic
valor.p = 1-pchisq(X2, k-1) # Valor-p = 0.9012493
```

Finalmente, se puede asumir un valor de significancia de hasta $\alpha = 25\%$, como $\text{valor-p} > \alpha$, no se rechaza la hipótesis nula concluyendo que los datos distribuyen Uniforme Discreta, es decir, el dado es honesto.

Comparación de Distribuciones

Muchas veces se tiene una gran variedad de distribuciones las cuales pueden ajustar los datos experimentales, para eso es necesario determinar cuál es la que presenta el mejor ajuste posible.

Lo que se explica a continuación es válido para el test KS y χ^2 .

Si se tienen k distribuciones a analizar, ya sea utilizando el test KS o χ^2 , entonces se tienen los siguientes criterios para determinar cual distribución presenta el mejor ajuste:

- **Comparando Estadísticos de Prueba:** Si una distribución que, después de realizados los test de bondad de ajuste, presenta un estadístico de prueba G_k , se concluye que ésta ajusta de mejor manera a los datos muestrales respecto a las demás distribuciones si:

$$G_k < G_1, \dots, G_n,$$

donde $G_1, \dots, G_n$ son los estadísticos de pruebas de las n distribuciones restantes.

- **Comparando valores-p:** Si una distribución que, después de realizados los test de bondad de ajuste, presenta un valor-p = $v\text{-}p_k$, se concluye que ésta ajusta de mejor manera a los datos muestrales respecto a las demás distribuciones si:

$$v\text{-}p_k > v\text{-}p_1, \dots, v\text{-}p_n$$

donde $v\text{-}p_1, \dots, v\text{-}p_n$ son los valores-p de las de las distribuciones restantes.

A continuación algunas observaciones respecto a la comparación de distribuciones.

Observación: Si se está utilizando el test χ^2 , **sólo** es posible comprar estadísticos de prueba con los mismos grados de libertad, a continuación un ejemplo con dos distribuciones:

$$X_1^2 \sim \chi^2(\gamma_1) <, >, = X_2^2 \sim \chi^2(\gamma_1) \quad (\text{Es posible realiza esta comparación})$$

$$X_1^2 \sim \chi^2(\gamma_1) <, >, = X_2^2 \sim \chi^2(\gamma_2) \quad (\text{No es posible realiza esta comparación})$$

Observación: Dependiendo el problema se tendrán que comparar los valores-p entre ellos o con el nivel de significancia α , por lo que se podrían llegar a las siguientes conclusiones, a continuación un ejemplo con dos distribuciones:

- Si $\text{valor-}p_1, \text{valor-}p_2 > \alpha$: Se concluye que ambas distribuciones tienen un buen ajuste bajo un nivel de significancia α .
- Si $\alpha < \text{valor-}p_1 < \text{valor-}p_2$: Se concluye que ambas distribuciones tienen un buen ajuste bajo α pero la distribución 2 tiene un mejor ajuste respecto a la primera.
- Si $\text{valor-}p_1 < \alpha < \text{valor-}p_2$: Se concluye que únicamente la distribución 2 tiene un buen ajuste bajo α .
- Si $\text{valor-}p_1, \text{valor-}p_2 < \alpha$: Se concluye que ninguna de las dos distribuciones presenta un buen ajuste bajo α .

Ejemplo: Comparación de distribuciones

Considere la siguiente tabla de frecuencia:

Intervalo	Frecuencia
≤ -10	6
$(-10; 0]$	13
$(0; +10]$	10
$> +10$	5

Los modelos disponibles a utilizar son la distribución Normal($\mu = 0.1, \sigma = 11.14$) y la distribución Gamma($k = 5, \nu = 0.2$) que está desplazada en $\alpha = -25$. Determine cuál de los dos modelos ajuste mejor a los datos muestrales.

Solución:

Test 1: Test para la distribución Normal, se tiene las siguiente dos hipótesis:

$$H_0 : X \sim \text{Normal} \quad \text{vs} \quad H_a : X \not\sim \text{Normal}$$

Recuerde que para calcular la probabilidad acumulada de una distribución normal de forma manual se utiliza $F_X(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$, y mediante R se utiliza `pnorm(x, mean=mu, sd=sigma)`. La tabla con la información para el test es la siguiente:

Intervalo	Observado	Prob. teo. (p_i)	Esperado (np_i)	X^2
≤ -10	6	0.1822	6.1948	0.006125628
$(-10, 0]$	13	0.3142	10.6828	0.502622518
$(0, +10]$	10	0.3166	10.7644	0.054281461
> 10	5	0.1870	6.3580	0.290054105
Total	$n = 34$	$p_T = 1$	$n = 34$	$X^2 = 0.853083713$

Como no se estimó ningún parámetro, se tiene que el valor del estadístico de prueba es:

$$X_N^2 = 0.8531 \sim \chi^2(4 - 1) = \chi^2(3)$$

El valor del valor-p es:

$$\text{valor-}p_N = P(C > 0.8531) = 0.8367285$$

Test 2: Test para la distribución Gamma desplazada, se tiene las siguientes dos hipótesis:

$$H_0 : X \sim \text{Gamma} \quad \text{vs} \quad H_a : X \not\sim \text{Gamma}$$

Como $k \in \mathbb{N}$ y la distribución es desplazada, para calcular probabilidades acumuladas se utiliza:

$$F_X(x) = P(X \leq x) = P(X - \alpha \leq x - \alpha) = 1 - \sum_{y=0}^{k-1} \frac{[v(x - \alpha)]^y e^{-y(x-\alpha)}}{y!}$$

La tabla queda de la siguiente forma:

Intervalo	Observado	Prob. teo. (p_i)	Esperado (np_i)	X^2
≤ -10	6	0.1868	6.3512	0.019420179
$(-10, 0]$	13	0.3762	12.7908	0.003421572
$(0, +10]$	10	0.2666	9.0644	0.096569807
> 10	5	0.1704	5.7936	0.108706324
Total	$n = 34$	$p_T = 1$	$n = 34$	$X^2 = 0.228117882$

Como no se estimó ningún parámetro, el estadístico de prueba es:

$$X_G^2 = 0.2281 \sim \chi^2(4 - 1) = \chi^2(3)$$

El valor-p es

$$\text{valor-p}_G = P(C > 0.2281) = 0.9729304$$

A continuación se realiza las conclusiones:

Comparación de Estadísticos de Prueba: Se puede comparar los estadísticos de prueba ya que tienen grados de libertad iguales, por lo tanto:

$$X_G^2 = 0.2281 < 0.8531 = X_N^2$$

Se concluye que la distribución Gamma desplazada tiene el mejor ajuste respecto a la distribución Normal.

Comparando Valores-p: Mediante los valores-p se tiene lo siguiente:

$$\text{valor-p}_G = 0.9729 > 0.8367 = \text{valor-p}_N$$

Se concluye que la distribución Gamma desplazada tiene el mejor ajuste respecto a la distribución Normal.

Capítulo 6

Regresión Lineal

Introducción

La inferencia vista anteriormente puede ser abordada desde el punto de vista de Modelos Estadísticos.

Sea $Y_1, \dots, Y_n$ variables aleatorias con alguna distribución asociada, el valor de cada Y_i se puede descomponer por la suma de la media y un factor de error:

$$Y_i = \mu_Y + \varepsilon_i, \quad i = 1, \dots, n$$

donde $\varepsilon_i \sim \text{Normal}(0, \sigma)$.

Si además se tiene otra muestra $X_1, \dots, X_n$ y se condiciona cada Y_i a la ocurrencia de cada X_i , entonces, el valor de cada $Y_i|X_i = Y_i(X_i)$ se puede descomponer de la misma forma antes mostrada:

$$Y_i(X_i) = \mu(X_i) + \varepsilon_i, \quad i = 1, \dots, n$$

donde $\mu_{Y_i|X_i} = \mu(X_i)$. Esto se conoce como **regresión simple**. Se llama a

$$y_i(x_i) = E(Y_i|X_i = x_i) = \mu(x_i)$$

a la curva de regresión de Y sobre x . Si $Y_1, \dots, Y_n \sim \text{Normal}(\mu_Y, \sigma_Y)$ y $X_1, \dots, X_n \sim \text{Normal}(\mu_X, \sigma_X)$ y cada X_i e Y_i distribuyen Normal Bivariada, entonces:

$$\mu(X_i) = \beta_0 + \beta_1 X_i$$

esto se conoce como modelo de **regresión lineal simple**, y la curva (o recta) de regresión está dada por $y_i = \beta_0 + \beta_1 x_i$.

En el caso que no exista Normalidad y la media condicionada sea de la forma:

$$\mu(X_i) = \beta_0 X_i^{\beta_1}$$

el modelo sería de **regresión No lineal simple**, y la curva de regresión esta dada por $y_i = \beta_0 x_i^{\beta_1}$.

Notación

En este capítulo se utilizará la siguiente notación:

- *Modelo de regresión simple:* $Y_i|X_i = Y_i(X_i) = Y_i$
- *Modelo de regresión múltiple:* $Y_i|X_1, \dots, X_n = Y_i(X_1, \dots, X_n) = Y_i$
- *Esperanzas de estimadores:* $E(\hat{\theta}|X_i = x_i) = E(\hat{\theta})$, $E(\hat{\theta}|X_1 = x_1, \dots, X_n = x_n) = E(\hat{\theta})$,
- *Varianzas de estimadores:* $\text{Var}(\hat{\theta}|X_i = x_i) = \text{Var}(\hat{\theta})$, $\text{Var}(\hat{\theta}|X_1 = x_1, \dots, X_n = x_n) = \text{Var}(\hat{\theta})$
- *Varianza Muestral de Y y de X :* $S_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$, $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$

Regresión Lineal Simple

Considerando el modelo de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$

Se tiene los siguientes supuestos:

1. **Linealidad:** La media condicional de Y sobre x es lineal

$$y = E(Y|X = x) = \beta_0 + \beta_1 x$$


2. **Homocedasticidad:** La varianza asociada a $f_{Y|x}(y)$ es la misma para todo x y es igual a:

$$\text{Var}(Y|X = x) = \sigma^2$$

3. **Independencia:** Las distribuciones condicionales son variables aleatorias independientes para todo x .

4. **Normalidad:** $f_{Y|x}(y)$ tiene distribución Normal para todo x .

La regresión lineal simple bajo los supuestos anteriores se ilustra en la siguiente figura



Interpretación de los parámetros del modelo:

- β_0 : Intercepto, $\beta_0 = E(Y | X = 0)$.
- β_1 : Pendiente, corresponde a la variación de $E(Y | X = x)$ cuando x aumenta en una unidad.

Estimación del modelo

Máxima Verosimilitud

Bajo los 4 supuestos se tiene que $Y_i | x_i$ tiene distribución Normal con media $E(Y_i | x_i) = \beta_0 + \beta_1 x_i$ y varianza σ^2 y además son independientes, entonces la función de verosimilitud de la muestra está dada por

$$L = \prod_{i=1}^n f_{Y|x_i}(y_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma} \right)^2 \right]$$
$$L = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right]$$

Los estimadores máximos verosímiles de los parámetros $\beta_0, \beta_1, \sigma^2$ están dados por

- **Estimador de β_0 :** $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

- **Estimador de β_1 :** $\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{y} \bar{x}}{\sum_{i=1}^n x_i^2 - n(\bar{x})^2}$

- **Estimador de σ^2 :** $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$

Mínimos Cuadrados

Bajo los 3 primeros supuestos, el método de mínimos cuadrados estimará los parámetros tales que minimicen la suma de la distancia al cuadrado entre los valores observados de y_i y los asumidos por el ajuste de regresión, es decir, minimizar la función Δ^2 dada por

$$\Delta^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Luego los EMCO (Estimadores de Mínimos Cuadrados Ordinarios) de β_0 y β_1 coinciden con los EMV.

Nota: El método de mínimos cuadrados no arroja estimación para σ^2 . Sin embargo, se estima a través de $S_{Y|x}^2$, que es un estimador insesgado de σ^2 dado por

$$S_{Y|x}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Propiedades de los estimadores

Bajo los 3 primeros supuestos los EMV y EMCO de β_0 y β_1 se tienen las siguientes propiedades:

1. Insesgamiento

$$E(\hat{\beta}_0) = \beta_0 \quad \text{y} \quad E(\hat{\beta}_1) = \beta_1$$

2. Varianza

$$\text{Var}(\hat{\beta}_0) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{y} \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Dado los primeros 3 supuestos los EMCO de β_0 y β_1 son los mejores estimadores lineales y con menor varianza entre los estimadores lineales e insesgados.

Si además se agrega el cuarto supuesto se tiene que $\hat{\beta}_0$ y $\hat{\beta}_1$ distribuyen Normal, por lo tanto

$$\hat{\beta}_0 \sim \text{Normal} \left(\beta_0, \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right)$$
$$\hat{\beta}_1 \sim \text{Normal} \left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Y además,

- $\hat{\beta}_1, \bar{Y}, \hat{\sigma}^2$ son mutuamente independientes.
- $\sum_{i=1}^n \left(\frac{y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i}{\sigma} \right)^2 = \frac{n\hat{\sigma}^2}{\sigma^2} = \frac{(n-2)S_{Y|x}^2}{\sigma^2} \sim \chi^2(n-2)$

Inferencia estadística del modelo

A partir de lo anterior se puede hacer inferencia sobre los parámetros del modelo, y poder construir intervalos de confianza o realizar test de hipótesis acerca de ellos.

Sea $E(Y|X = x) = \beta_0 + \beta_1 x$ la recta de regresión lineal simple, y $\hat{\beta}_0, \hat{\beta}_1$ los EMV de β_0, β_1 .

Entonces se tiene el siguiente estadístico de prueba para la pendiente β_1 :

$$T_0 = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{S_{Y|x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim \text{t-Student}(n-2)$$

Para la pendiente

Con $S_{Y|x}^2$ el estimador insesgado de σ^2 .

También se tiene el estadístico de prueba para el intercepto β_0 :

$$T_0 = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\frac{S_{Y|x}^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}}} \sim \text{t-Student}(n-2)$$

Para Intercepto

Por último, se tiene el estadístico de prueba para la varianza del modelo $S_{Y|x}^2$:

$$C_0 = \frac{(n-2)S_{Y|x}^2}{\sigma^2} \sim \chi^2(n-2)$$

Para la varianza

Análisis de Varianza

En un modelo de regresión existen 2 fuentes que explican la variación de los valores observados de Y (variación total)

- Una fuente es debido a la regresión, representada por la x

$$\text{SCR} = \sum_{i=1}^n (y(x_i) - \bar{y})^2$$

Suma de Cuadrados de la Regresión

- Otra fuente es la variación de y_i que no ha sido explicada en el modelo por las x_i

$$\text{SCE} = \sum_{i=1}^n (y_i - y(x_i))^2 = (n-2)S_{Y|x}^2$$

Suma de Cuadrados del Error

Para ambas fuentes de variación se tiene que $y(x_i)$ es el valor de Y dentro de la recta de regresión debido a un valor x_i , $y(x_i) = \hat{\beta}_0 + \hat{\beta}_1 x_i$, e y_i representa el valor de Y proveniente a los datos muestrales dado un cierto valor x_i . De esta manera, la variación total de Y , dada por la Suma de Cuadrados Totales (SCT), puede ser descrita como

$$\begin{aligned} \text{SCT} &= \text{SCR} + \text{SCE} \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (y(x_i) - \bar{y})^2 + \sum_{i=1}^n (y_i - y(x_i))^2 \end{aligned}$$

- Si $\text{SCR} \rightarrow 0$, entonces $y(x_i) = \bar{y}$ (Modelo pésimo)
- Si $\text{SCE} \rightarrow 0$, entonces $y(x_i) \neq \bar{y}$ y $y_i = y(x_i)$ (Modelo perfecto)

Observación: La suma de cuadrados totales (SCT) se relaciona con la varianza de la variable dependiente, en este caso Y , de la siguiente forma:

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2 = (n-1)S_Y^2$$

Los valores de SCT, SCR y SCE se pueden encontrar en una tabla llamada **tabla ANOVA**, ésta se muestra a continuación.

Tabla ANOVA

Fuente	Grados de libertad	SC	Cuadrados medios (MC)	F
Regresión	1	SCR	$\frac{SCR}{1}$	$\frac{MCR}{MCE}$
Error	$n-2$	$SCE = (n-2)S_{Y x}^2$	$\frac{SCE}{n-2} = S_{Y x}^2$	
Total	$n-1$	$SCT = (n-1)S_Y^2$		

El estadístico de prueba F_0 se muestra a continuación en diferentes formas:

$$F_0 = \frac{MCR}{MCE} = \frac{\frac{SCR}{1}}{\frac{SCE}{n-2}} = \frac{(n-2)SCT}{SCE} - (n-2) = \frac{(n-1)S_Y^2}{S_{Y|x}^2} - (n-2) \sim \text{Fisher}(1, n-2)$$

Para analizar la existencia de regresión es necesario plantear las siguientes dos hipótesis:

$$H_0 : \beta_1 = 0 \quad \text{vs} \quad H_a : \beta_1 \neq 0$$

Si se tiene un nivel de significancia α (generalmente es del 5%), entonces el valor-p y valor crítico a calcular son:

$$\begin{aligned} \text{Valor-p} &= P(F \geq F_0) \\ \text{Valor crítico} &= F_{1-\alpha}(1, n-2) \end{aligned}$$

En [R](#) el valor-p y el valor crítico se puede calcular de la siguiente forma:

```
R: Valor-p = 1-pf(F0,df1=1,df2=n-2)
Valor-crítico = qf(1-alpha,df1=1,df2=n-2)
```

Si el valor-p es menor que α , valor-p $< \alpha$, o el estadístico de prueba F_0 es mayor al valor crítico, $F_0 > F_{1-\alpha}(1, n-2)$, entonces se rechaza H_0 indicando que **si existe regresión**.

Otra opción para verificar si existe o no regresión bajo la hipótesis H_0 propuesta anteriormente es utilizar la estimación de la pendiente β_1 con el siguiente estadístico de prueba:

$$T_0 = \frac{\hat{\beta}_1}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_1)}} \sim \text{t-Student}(n-2)$$

El valor-p y el estadístico de prueba a calcular son:

$$\begin{aligned} \text{Valor-p} &= 2 \cdot P(T \geq |T_0|) \\ \text{Valor crítico} &= t_{1-\alpha/2}(n-2) \end{aligned}$$

En [R](#) el valor-p y el valor crítico se puede calcular de la siguiente forma:

```
R: Valor-p = 2*(1-pt(|T0|,df=n-2))
Valor-crítico = qt(1-alpha/2,df=n-2)
```

Si el valor-p es menor que α , valor-p $< \alpha$, o si el valor absoluto del estadístico de prueba T_0 es mayor al valor crítico, $|T_0| > t_{1-\alpha/2}(n-2)$, entonces se rechaza H_0 indicando la **existencia de regresión**.

Las conclusiones a las que se llegan ya sea utilizando el estadístico F o el estadístico T_0 para la pendiente son las mismas ya que se cumple la siguiente relación (Esto solo se cumple en regresión lineal simple):

$$\underbrace{T_0^2 = F_0}$$

Misma conclusión sobre la existencia de regresión lineal simple

El test de hipótesis para la pendiente antes mencionado se puede aplicar para el intercepto, es decir, se tiene la hipótesis nula $H_0 : \beta_0 = 0$ e hipótesis alternativa $H_a : \beta_0 \neq 0$, por lo que el estadístico de prueba para el intercepto es

$$T_0 = \frac{\hat{\beta}_0}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_0)}} \sim \text{t-Student}(n-2)$$

El valor-p y el valor crítico se pueden calcular de la misma forma que en el caso de la pendiente.

Observación: Mediante estos estadísticos de prueba, para pendiente e intercepto, es posible obtener tanto el valor del estadístico, el valor de los estimadores o el valor de las varianzas estimadas de cada estimador.

Coeficiente de Determinación

Una vez obtenida la recta de regresión lineal surge una pregunta a responder, ¿qué tan buena es la regresión?

Para constar esta pregunta se utiliza el coeficiente de determinación R^2

$$R^2 = \frac{\text{SCR}}{\text{SCT}} = \frac{\sum_{i=1}^n (y(x_i) - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{(n-2)}{(n-1)} \frac{S_{Y|x}^2}{S_Y^2}$$

También se tiene el coeficiente de determinación R^2 ajustado

$$r^2 = 1 - \frac{S_{Y|x}^2}{S_Y^2} = 1 - \frac{(n-1)\text{SCE}}{(n-2)\text{SCT}} = \bar{R}^2$$

Ambos se interpretan como la proporción o el porcentaje de variación total que es explicada por el modelo de regresión lineal.

El valor de R^2 y r^2 se relacionan mediante la siguiente ecuación

$$R^2 = 1 - (1 - r^2) \frac{n-2}{n-1}$$

Entre mayor sea el valor del coeficiente de determinación, mejor es el ajuste.

Uso de R para regresión lineal simple

Todo lo aprendido hasta ahora se puede aplicar en R para encontrar resultados rápidos.

Si se quiere ver si existe una relación entre dos variables provenientes de una base de datos se utiliza lo siguiente

```
modelo = lm(Y ~ X)
```

Este comando ajusta un modelo lineal a la variable Y en función de X .

La información que proporciona el modelo se obtiene utilizando el comando `summary()`

```
summary(modelo)
```

La información obtenida es la siguiente

```
Call
lm(formula = Y ~ X)

Residuals:
Min 1Q Median 3Q Max

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)
X
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: --- on -- degrees of freedom
Multiple R-squared: --- , Adjusted R-squared: ---
F-statistic: --- on -- and -- DF, p-value: ---
```

Lo importante de esto es la tabla de **Coefficients**, la información que contiene esta es la siguiente

- **(Intercept)**: Corresponde a la información de β_0 que es el intercepto
- **X**: Corresponde a la información de β_1 que es la pendiente
- **Estimate**: Corresponde a los valores estimado ya sea para el intercepto o la pendiente, o también mediante los estimadores EMV o EMCO.
- **std. Error**: Usa las formulas aprendidas para la desviación estándar, ya sea para el intercepto o la pendiente, $\sqrt{\widehat{\text{Var}}(\hat{\beta}_0)}$ o $\sqrt{\widehat{\text{Var}}(\hat{\beta}_1)}$.
- **t value**: Es el valor del estadístico T_0 y se calcula como $\text{Estimate}/(\text{Std. Error})$ ya sea para el intercepto o la pendiente
- **Pr(>|t|)**: Valor-p, ya sea para el intercepto o la pendiente, se calcula como `2*(1-pt(|t value|,n-2))`

Además, la parte final de la información que proporciona `summary()` corresponde a los siguiente

- **Residual standard error**: Es el estimador de la desviación estándar del modelo $S_{Y|x} = \sqrt{\text{SCE}/(n-2)}$
- **Multiple R-squared**: Es el coeficiente de determinación R^2
- **Adjusted R-squared**: Es el coeficiente de determinación ajustado r^2
- **F-statistic**: Es el estadístico $F = \text{MCR}/\text{MCE}$
- **p-value**: Es el valor-p del estadístico F , `1-pf(F-statistic,df1=1,df2=n-2)`

Nota: El valor de $(t \text{ value})^2$ para la pendiente es igual al valor de **F-statistic** y solo aplica al caso de regresión lineal simple.

La información mostrada anteriormente corresponde al modelo de regresión lineal simple:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

Para el análisis de la varianza se necesita obtener la tabla ANOVA, para esto se utiliza el siguiente comando:

`anova(modelo)`

La información que se muestra es la siguiente:

```
Analysis of Variance Table

Responce: Y

          Df Sum Sq Mean Sq F value Pr(>F)
X              1      0.001    0.001    0.01 0.917
Residuals      18      0.001    0.000    0.00 0.999
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

La información que contiene es la siguiente:

- **X**: Corresponde a la fuente de error debido a la regresión.
- **Residuals**: Corresponde a la fuente de error debido a la variabilidad del modelo.
- **Df**: Corresponde a los grados de libertad, para **X** es 1 y para **Residuals** es $n - 2$.
- **Sum Sq**: Corresponde a la suma de cuadrados, para **X** es la suma de cuadrados de la regresión SCT y para **Residuals** es la suma de cuadrados del error SCE.
- **Mean Sq**: Corresponde a los cuadrados medios, para **X** es $MCR = SCR/1$ y para **Residuals** es $MCE = SCE/(n - 2) = S_{Y|X}^2$.
- **F value**: Corresponde al valor del estadístico $F_0 = MCR/MCE$ y solo se muestra el valor para **X**.
- **Pr(>F)**: Es el valor-p asociado al valor F_0 , se calcula como `1-pf(F value, df1=1,df2=n-2)`, solo se muestra el valor para **X**.

Para comprobar los datos y el comportamiento del modelo de manera visual, se puede realizar un gráfico que contenga los datos muestrales y la recta de regresión ajustada a estas observaciones, para esto se utilizan los siguientes dos comandos:

`plot(X,Y,...)`: Gráfico de los datos muestrales de Y vs X .

`abline(modelo,...)`: Se añade al gráfico anterior la recta de regresión ajustada de Y vs X .

Regresión Lineal Múltiple

El modelo de regresión múltiple (MRLM) se define de la siguiente forma

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i, \quad i = 1, \dots, n$$

Donde Y es la variable dependiente, $X_j, j = 1, \dots, k$ son las covariables del modelo, y los β_j son coeficientes constantes del modelo, y las ε_i son variables aleatorias que corresponden a la varianza del modelo tales que cumplen con

$$E(\varepsilon_i) = 0$$

$$\text{Var}(\varepsilon_i) = \sigma^2$$

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$$

El objetivo es poder predecir $E(Y|X_1 = x_1, \dots, X_k = x_k)$ a partir de k variables independientes observadas: x_j

Observaciones

- El modelo tiene $k + 2$ parámetros a estimar: $\beta_0, \beta_1, \dots, \beta_k, \sigma^2$.
- El coeficiente β_j , con $j = 1, \dots, k$ corresponde a la variación de $E(Y|X_1 = x_1, \dots, X_k = x_k)$, cuando x_j aumenta en una unidad y el resto de las variables no cambian.
- β_0 : Corresponde al valor medio $E(Y|X_1 = 0, \dots, X_k = 0)$.
- Al igual que el caso MRLS, el MRLM debe ser lineal en los parámetros β_j , y no necesariamente en las variables X_j

Estimación del modelo

Dado el modelo de Regresión Lineal Múltiple, las estimaciones de mínimos cuadrados de los coeficientes $\beta_0, \dots, \beta_k$ son los valores $\hat{\beta}_0, \dots, \hat{\beta}_k$ para los que la suma de los cuadrados de las desviaciones entre el valor observado y_i y los asumidos por el ajuste de regresión es la menor posible

$$\text{SCE} = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_k x_{ik})^2$$

Para determinar los EMCOS de $\beta_0, \dots, \beta_k$, se deriva SCE parcialmente respecto a $\beta_0, \beta_1, \dots, \beta_k$ obteniendo las siguientes $(k + 1)$ ecuaciones normales que se deben resolver

$$\frac{\partial \text{SCE}}{\partial \beta_0} = 0, \quad \frac{\partial \text{SCE}}{\partial \beta_1} = 0, \quad \frac{\partial \text{SCE}}{\partial \beta_2} = 0 \quad \dots, \quad \frac{\partial \text{SCE}}{\partial \beta_k} = 0$$

La solución $(\hat{\beta}_0, \dots, \hat{\beta}_k)$ satisface el sistema lineal de $k + 1$ ecuaciones

$$\begin{aligned} n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_{1i} + \dots + \hat{\beta}_k \sum_{i=1}^n x_{ki} &= \sum_{i=1}^n y_i \\ \hat{\beta}_0 \sum_{i=1}^n x_{ji} + \hat{\beta}_1 \sum_{i=1}^n x_{1i} x_{ji} + \dots + \hat{\beta}_k \sum_{i=1}^n x_{ki} x_{ji} &= \sum_{i=1}^n y_i x_{ji} \end{aligned}$$

con $j = 1, \dots, k$

Si se considera una expresión matricial para el MRLM, entonces se puede obtener una expresión simple para los estimadores MCO.

Notación matricial del modelo

$$\begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & X_{11} & X_{21} & \dots & X_{k1} \\ 1 & X_{12} & X_{22} & \dots & X_{k2} \\ 1 & X_{13} & X_{23} & \dots & X_{k3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & X_{2n} & \dots & X_{kn} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$\vec{Y} = \mathbf{X}\vec{\beta} + \vec{\varepsilon}$$

Donde $\vec{\varepsilon}$ e $\vec{Y}$ son vectores de $n \times 1$, $\mathbf{X}$ es una matriz de $n \times (k + 1)$ y el Rango de $\mathbf{X}$ debe ser de rango columna completo $(k + 1)$.

Luego

$$\begin{aligned} \text{SCE} &= \sum_{i=1}^n (y_i - \beta_0 + \beta_1 x_{i1} - \dots - \beta_k x_{ik})^2 \\ \text{SCE} &= (\vec{Y} - \mathbf{X}\vec{\beta})^T (\vec{Y} - \mathbf{X}\vec{\beta}) \end{aligned}$$

Se debe derivar SCE parcialmente respecto a $\beta_0, \dots, \beta_k$ e igualar a cero, esto es

$$\mathbf{X}^T \mathbf{X} \vec{\beta} = \mathbf{X}^T \vec{Y} \Rightarrow \vec{\hat{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \vec{Y}$$

De esta manera, la regresión ajustada de Y sobre $X_1, \dots, X_k$ está dada por

$$y(x_{1i}, \dots, x_{ki}) = E(\widehat{Y | x_1, \dots, x_k}) = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki}$$

Estimación de σ^2

Dado el modelo de regresión poblacional múltiple

$$Y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \varepsilon_i$$

y los supuestos habituales de la regresión, sea σ^2 la varianza común de término de error, ε_i . Entonces, una estimación insesgada de esta varianza es

$$S_{Y|x}^2 = \frac{\text{SCE}}{n - k - 1}$$

donde k es el número de variables predictoras.

Los EMCOS de β tiene las siguientes propiedades

- $\hat{\beta}$ es insesgado, es decir, $E(\hat{\beta}) = \beta$
- $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$
- Si se asume Normalidad en ε se tiene que
 - $(n - k - 1) \frac{S_{Y|x}^2}{\sigma^2} \sim \chi^2(n - k - 1)$
 - $\hat{\beta} \sim \text{Normal}(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$

Luego, para cada i , $\hat{\beta}_i \sim \text{Normal}(\beta_i, \sigma^2 c_{ii})$, donde c_{ii} corresponde al elemento ii de la matriz $(\mathbf{X}^T \mathbf{X})^{-1}$

Inferencia en el modelo

La desviación estándar de $\hat{\beta}_i, \sigma \sqrt{c_{ii}}$, puede ser estimada por

$$\text{se}_{\hat{\beta}_i} = S_{Y|x} \sqrt{c_{ii}}$$

A partir de lo anterior, se pueden construir intervalos de confianza y test de hipótesis para β .

Bajo normalidad, se puede demostrar que

$$T_0 = \frac{\hat{\beta}_i - \beta_i}{\text{se}_{\hat{\beta}_i}} \sim \text{t-Student}(n - k - 1)$$

En base a este estadístico se puede analizar el grado de aporte de cada variable al modelo, para esto se plantean las siguientes dos hipótesis:

$$H_0 : \beta_i = 0 \text{ (La variable } X_i \text{ no es significativa)}$$

$$H_a : \beta_i \neq 0 \text{ (La variable } X_i \text{ si es significativa)}$$

con $i = 1, \dots, k$, se debe aplicar este test a los k regresores (variables dependientes), bajo un nivel de significancia de α , el valor-p y valor crítico que hay que calcular son:

$$\begin{aligned} \text{Valor-p} &= 2 \cdot P(T > |T_0|) \\ \text{Valor crítico} &= t_{1-\alpha/2}(n - k - 1) \end{aligned}$$

```
R: Valor-p = 2*(1-pt(|T0|, df=n-k-1))
Valor crítico = qt(1-alpha/2, df=n-k-1)
```

El criterio de rechazo es:

- $\text{Valor-p} < \alpha$: Se rechaza H_0 , por lo que la variable es significativa.
- $|T_0| > t_{1-\alpha/2}(n-k-1)$: Se rechaza H_0 , la variable es significativa.

Este test solo es válido para analizar el grado de aporte de cada variable al modelo de regresión múltiple, para determinar si puede existir regresión lineal o no se debe realizar un análisis de la varianza y determinar un estadístico de prueba F_0 , todo esto se desarrolla más adelante.

Coeficiente de Determinación y Análisis de Varianza

Al igual que en MRLS, la variabilidad del modelo puede dividirse en los componentes

$$\text{SCT} = \text{SCR} + \text{SCE}$$

las que se definen de la siguiente manera

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y(x_{1i}, \dots, x_{ki}) - \bar{y})^2 + \sum_{i=1}^n (y_i - y(x_{1i}, \dots, x_{ki}))^2$$

Esta descomposición puede interpretarse como

$$\text{Variabilidad Muestral total} = \text{Variabilidad Explicada} + \text{Variabilidad No Explicada}$$

Coeficiente de Determinación R^2

El coeficiente de determinación R^2 de la regresión ajustada es la proporción de la variabilidad muestral total explicada por la regresión

$$R^2 = \frac{\text{SCR}}{\text{SCT}} = 1 - \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{(n-k-1)}{(n-1)} \frac{S_{Y|x}^2}{S_Y^2}$$

y se deduce que

$$0 \leq R^2 \leq 1$$

Coeficiente de Determinación Ajustado $\bar{R}^2$

El coeficiente de determinación ajustado, $\bar{R}^2$, se define de la forma siguiente

$$r^2 = 1 - \frac{\text{SCE}/(n-k-1)}{\text{SCT}/(n-1)} = 1 - \frac{S_{Y|x}^2}{S_Y^2} = \bar{R}^2$$

Utilizamos esta medida para tener en cuenta el hecho de que las variables independientes irrelevantes provocan una pequeña reducción de la suma de los cuadrados de los error.

Por lo tanto, el r^2 ajustado permite comparar mejor los modelos de regresión múltiple que tiene diferentes número de variables independientes.

Coeficiente de Correlación Múltiple

El coeficiente de correlación múltiple es la correlación entre el valor predicho y el valor observado de la variable dependiente

$$R = \text{Cor}(y(x_{1i}, \dots, x_{ki}), y_i) = \sqrt{R^2}$$

y es igual a la raíz cuadrada del coeficiente múltiple de determinación. Se utiliza R como otra medida de la fuerza de la relación entre variable dependiente y las variables independientes.

Por lo tanto, es comparable a la correlación entre Y y X en la regresión simple.

Análisis de Varianza

Al igual que en el MRLS se puede contruir la Tabla de Análisis de la Varianza (ANOVA)

Tabla ANOVA

Fuente	Grados de libertad	SC	Cuadrados medios	F
Regresión	k	SCR	$\frac{SCR}{k}$	$\frac{MCR}{MCE}$
Error	$n - k - 1$	SCE	$\frac{SCE}{n - k - 1} = S_{Y x}^2$	
Total	$n - 1$	SCT		

Con el estadístico de prueba: $F_0 = \frac{MCR}{MCE} \sim \text{Fisher}(k, n - k - 1)$

¿Cómo se interpreta el F_0 ahora?, Es estadístico de prueba F_0 se utiliza para determinar la existencia o no de regresión lineal múltiple pero no determina cuales de las variables es mas o menos significativa al modelo.

Para analizar la existencia de regresión lineal múltiple se proponen las siguientes dos hipótesis:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \text{ (No hay regresión)}$$

$$H_a : \text{Al menos un } \beta_j \neq 0 \text{ (Existe regresión)}$$

Dado un nivel de significancia α , el valor-p y el valor crítico a calcular son:

$$\text{Valor-p} = P(F > F_0)$$

$$\text{Valor Crítico} = F_{1-\alpha}(k, n - k - 1)$$

En R, para calcular el valor-p y el valor crítico se utiliza:

```
R: Valor-p = 1-pf(F0, df1=k, df2=n-k-1)
Valor crítico = qf(1-alpha, df1=k, df2=n-k-1)
```

El criterio para determinar la existencia de regresión es el siguiente:

- Valor-p $< \alpha$: Se rechaza H_0 , hay regresión.
- $F_0 > F_{1-\alpha}(k, n - k - 1)$: Se rechaza H_0 , hay regresión

La conclusión de este test es que solo indica la existencia o no de regresión, pero no indica cual variable es la que más aporta o la que menos aporta, para esto es necesario hacer los test T mencionados anteriormente para cada variable.

Selección del Modelo

1. **Método jerárquico:** Se introducen unos predictores determinados en un orden determinado
2. **Método de entrada forzada:** Se introducen todos los predictores simultáneamente
3. **Método paso a paso (stepwise):** Emplea criterios matemáticos para predecir que predictores contribuyen significativamente al modelo y que orden de introducen.

Forward - Backward - Mixto

El método paso a paso requiere de algún criterio matemático para determinar si el modelo mejora o empeora con cada incorporación o extracción.

Existen varios parámetros empleados, de entre los que se destacan el Cp, AIC, BIC, test F y R^2 ajustado.

Análisis del Mejor Modelo de Regresión

Utilizando un ejemplo a modo de explicación, suponiendo que se tiene dos modelos de regresión en base a las variables X_1, X_2, X_3 de la siguiente forma:

- *Modelo 1:* $Y = \beta_0 + \beta_1 X_1$
- *Modelo 2:* $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$

Se quiere analizar cual es el mejor modelo entre estos dos (o que si la presencia de X_2 y X_3 llega a ser significativo para el modelo), para analizar esto se propone el siguiente estadístico de prueba en base a la suma cuadrática del error de ambos modelos:

$$F_0 = \frac{(\text{SCE}_1 - \text{SCE}_2)/r}{\text{SCE}_2/(n - (k + r) - 1)} \sim \text{Fisher}(r, n - (k + r) - 1)$$

donde:

- $\text{SCE}_1 > \text{SCE}_2$
- r : Cantidad de variables adicionales entre el modelo 1 y modelo 2.
- k : Cantidad de variables en común entre el modelo 1 y modelo 2.
- n : Cantidad de datos.

Mediante el estadístico F_0 se proponen las siguientes dos hipótesis:

$$H_0 : \beta_2 = \beta_3 = 0 \text{ } (\beta_2 \text{ y } \beta_3 \text{ no son significativos en el modelo})$$

$$H_a : \text{Al menos un } \beta_j \neq 0 \text{ } (\beta_2 \text{ y } \beta_3 \text{ si son significativos en el modelo})$$

Bajo un nivel de significancia de α , el valor-p y valor crítico a calcular son:

$$\text{Valor-p} = P(F > F_0)$$

$$\text{Valor crítico} = F_{1-\alpha}(r, n - (k + r) - 1)$$

en [R](#) esto se calcula como:

```
R: Valor-p = 1-pf(F0, df1=r, df2=n-(k+r)-1)
Valor crítico = qf(1-alpha, df1=r, df2=n-(k+r)-1)
```

El criterio de rechazo es el siguiente:

- $\text{Valor-p} < \alpha$: Se rechaza H_0 , las variables X_2 y X_3 si son de aporte al modelo.
- $F_0 > F_{1-\alpha}(r, n - (k + r) - 1)$: Se rechaza H_0 , las variables X_2 y X_3 si son de aporte al modelo.

Este test sirve para indicar si la presencia de un conjunto de variables es significativo al modelo completo o no, pero no indica cual de estas variables tiene mayor o menor aporte, así como tampoco indica cual de los dos modelos es mejor, para eso se calcula el coeficiente de determinación ajustado r^2 , el modelo que tenga mayor r^2 es el mejor.

El procedimiento es algo largo si se realiza de manera manual estos cálculos, pero utilizando [R](#) el problema se resume a una línea de código:

```
modelo1 = Y ~ X1
modelo2 = Y ~ X1+X2+X3
anova(modelo1, modelo2)
```

La información que se obtiene se muestra a continuación:

Analysis of Variance Table

Model 1: Y ~ X1

Model 2: Y ~ X1 + X2 + X3

	Res.Df	RSS	DF	Sum of Sq	F	Pr(>F)
1						
2						

La información importante se encuentra en la segunda fila de la tabla en el apartado de **F**, ahí se encontrará el valor del estadístico de prueba F_0 , a la derecha se encuentra el valor de **Pr(>F)** que corresponde al valor-p = $P(F > F_0)$, en base a estos dos valores se puede utilizar el criterio de rechazo mencionado anteriormente.

Observación: Si la cantidad de variables adicionales es uno, $r = 1$, entonces se cumple que el cuadrado del valor del estadístico de prueba T_0 de esa variable es igual al valor del estadístico F_0 , así como el valor-p de del test T y test F .

$$T_0^2 = F_0$$

$$P(F > F_0) = 2 \cdot P(T > |T_0|)$$

Multicolinealidad

Para determinar la existencia de colinealidad o multicolinealidad entre predictores de un modelo de regresión, se ha desarrollado numerosas reglas prácticas que tratan de determinar en que medida afecta a la estimación y contraste de un modelo

- Si es coeficiente de determinación R^2 es alto pero ninguno de los predictores resulta significativo, hay indicios de colinealidad
- Calcular una matriz de correlación en la que se estudia la relación lineal entre cada par de predictores
- Generar modelos de regresión lineal simple entre cada uno de los predictores frente al resto. Si en alguno de los modelos el coeficiente de determinación R^2 es alto, estaría señalando a una posible colinealidad
- tolerancia (TOL) y Factor de Inflación de la Varianza (VIF). Se trata de dos parámetros que viene a cuantificar lo mismo (uno es el inverso del otro)

El VIF de cada predictor se calcula según la siguiente formula

$$\text{VIF}_{\hat{\beta}_j} = \frac{1}{1 - R^2}$$

$$\text{Tolerancia}_{\hat{\beta}_j} = \frac{1}{\text{VIF}_{\hat{\beta}_j}}$$

donde R^2 se obtiene de la regresión del predictor X_j sobre los otros predictores

- VIF=1 (Ausencia total de colinealidad)
- $1 < \text{VIF} < 5$ (La regresión puede verse afectada por cierta colinealidad)
- $5 < \text{VIF} < 10$ (Causa de preocupación)
- El término tolerancia es $1/\text{VIF}$ por lo que los límites recomendables están entre 0.1 y 1

Independencia

Los valores de cada observación son independientes de los otros, esto es especialmente importante de comprobar cuando se trabaja con mediciones temporales.

Se recomienda representar los residuos ordenados acorde al tiempo de registro de las observaciones, si existe un cierto patrón hay indicios de auto-correlación. Función `acf()` de R.

También se puede emplear el test de hipótesis de Durbin-Watson y Box-Ljung.

Outliers, Leverage e Influyentes

- **Outlier:** Observaciones que no se ajustan bien al modelo. Residuo es excesivamente grande. En una representación bidimensional se corresponde con desviaciones en el eje Y.
- **Observación con alto Leverage:** Observación con un valor extremo para alguno de los predictores. En una representación bidimensional se corresponde con desviaciones en el eje X. Son potencialmente puntos influyentes.
- **Observación influyente:** Observación que influye sustancialmente en el modelo, su exclusión afecta al ajuste. No todos los outliers tienen por que ser influyentes.

En R se dispone de la función `outlierTest()` del paquete `car` y de las funciones `influence.measures()`, `influencePlot()` y `hatvalues()` para identificar las observaciones más influyentes en el modelo

- **Distancia de Cook:** Medida muy utilizada que combina, en un único valor, la magnitud del residuo y el grado de leverage. Valores de Cook mayores a 1 suelen considerarse como influyentes.
- **Cambio en los coeficientes de regresión:** Se trata de un proceso iterativo en el que cada vez se excluye una observación distinta y se reajusta el modelo. En cada iteración se registra la diferencia en los coeficientes de regresión con y sin la observación, dividida entre el SE del predictor en el modelo sin la observación.

$$Dfbetas_i = \frac{\hat{\beta} - \hat{\beta}_i}{SE_{\hat{\beta}_i}}$$

Al tratarse de un valor estandarizado, es sencillo identificar que observaciones influyen más y en que magnitud

$$|Dfbeta| > \frac{2}{\sqrt{n}}$$

La función `dfbeta()` realiza esta comparación.

Uso de R para modelos de regresión lineal múltiple

Si se quiere realizar un modelo de regresión lineal de una variable Y en función de otras variables $X_1, \dots, X_k$ se utiliza lo siguiente

```
modelo = lm(Y ~ X.1+X.2+X.3+...+X.k)
```

En el caso en que base de datos contiene un gran número de variables, es recomendable hacer lo siguiente

```
data=Base[,c(i:j)] # Contiene a todas las variables o las de interés
modelo = lm(Var.1 ~., data=data)
```

Con esto se está utilizando las demás variables escogidas en `data`, utilizando el comando `summary()` se obtiene lo siguiente

```
Call
lm(formula = Y ~ X.1+X.2+X.3+...+X.k)

Residuals:
Min 1Q Median 3Q Max

Coefficients:

                Estimate Std. Error t value Pr(>|t|)
(Intercept)
X.1
X.2
⋮
X.k
```

```

---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: ___ on __ degrees of freedom
Multiple R-squared: ___ , Adjusted R-squared: ___
F-statistic: ___ on __ and __ DF, p-value: ___

```

Todo es exactamente igual al modelo de regresión lineal simple pero con la característica que en la tabla de **Coefficients** aparece el intercepto ($Y|X_1 = 0, \dots, X_k = 0$) y las variables utilizadas ($X_1, \dots, X_k$), cada uno tiene su propio estimador, error estándar, estadístico de prueba T_0 y valor-p asociado al estadístico.

Para obtener la tabla ANOVA se utiliza el siguiente comando

`anova(modelo)`

La información obtenida es la siguiente

```

Analysis of Variance Table

Responce: Y

      Df Sum Sq Mean Sq F value Pr(>F)
X.1
X.2
:
X.k
Residuals
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Todo es exactamente igual al modelo de regresión lineal simple pero con la característica que ahora se muestran las demás variables utilizadas. Los grados de libertad de X.1,...,X.k son 1, cada uno de estos tiene asociada una suma cuadrática de regresión:

- X.1: $SCR.1 \sim \chi^2(1)$
- X.2: $SCR.2 \sim \chi^2(1)$
- $\vdots$
- X.k: $SCR.k \sim \chi^2(1)$

Al sumar todas las k sumas cuadráticas de regresión se obtiene la suma cuadrática de regresión total:

$$SCT.T = \sum_{i=1}^k SCR.i \sim \chi^2(k)$$

El cuadrado medio de la regresión es:

$$MCR = SCT.T/k$$

Finalmente, el valor del estadístico **F value** es:

$$F \text{ value} = MCR/MCE$$

donde MCE es el valor **Mean Sq** de **Residuals**. El valor de **F value** es igual al valor de **F-statistic** del comando `summary`.

- FIN -

Capítulo 7

Laboratorio: Uso de R

Operadores básicos

Se puede llevar a cabo distintas operaciones matemáticas y aritméticas usando operadores básicos

- Suma: +
- Resta: −
- Multiplicación: *
- División: /
- Exponentes: ** o ^

Funciones matemáticas

- Raíz cuadrada $\sqrt{}$: `sqrt()`
- Logaritmos $\ln()$: `log()`, `log2()`, `log10()`
- Exponencial e^a : `exp()`
- Valor absoluto $| \cdot |$: `abs()`
- Signo: `sign()`
- Funciones trigonométricas $\cos()$, $\sin()$, $\tan()$: `cos()`, `sin()`, `tan()`
- Funciones trigonométricas inversas $\cos^{-1}()$, $\sin^{-1}()$, $\tan^{-1}()$: `acos()`, `asin()`, `atan()`
- Resto de una división: `%%`
- factorial y su logaritmo $!$: `factorial`, `lfactorial`

Variables

Variables numéricas:

Números u operaciones numéricas a definir

```
a=3  
b=3+4/5
```

Variables booleanas:

Verdadero o Falso

```
d=TRUE  
e=FALSE
```

Variables de texto:

Strings o chat se escriben entre comillas

```
f="Hola mundo"
```

Vectores

Para saber la clase o tipo de objeto que se tiene guardado en una variable: `class()`.

Para crear vectores: `c()`

- `números=c(1,2,3,4,5)`
- `texto=c("a","hola","pelota","PC")`

Para nombrar elementos de un vector: `names()`

- `notas = c(3.5,4.1,5.5,6.0)`
- `nombres = c("I1","I2","I3","Ex")`
- `names(notas) = nombres`

Operaciones con vectores

Se pueden utilizar las operaciones básicas en vectores.

Algunas funciones de R para vectores son:

- `sum()`: Suma entre todos los componentes del vector
- `prod()`: Producto entre todos los componentes del vector
- `mean()`: Promedio entre todos los componentes del vector
- `sd()`: Desviación estándar entre todos los componentes del vector
- `min()`: Valor mínimo dentro del vector
- `max()`: Valor máximo dentro del vector

Operadores lógicos

- Menor: `<`
- Menor o igual: `<=`
- Mayor: `>`
- Mayor o igual: `>=`
- Igual: `==`
- Diferente: `!=`
- Y (and): `&`
- O (or): `|`
- No: `!`

Manipulación de vectores

Para conocer el largo de un vector: `length()`

Para acceder al i-ésimo componente del vector: `v[i]`

Para acceder a más de un componente de un vector: `v[c(i,j,k,...)]`

Para crear una secuencia de i hasta j: `i:j`

Para acceder a varios términos continuos: `v[i:j]`

Si cada componente tiene un nombre, para acceder a cada término: `v[c("nombre1", "nombre2",...)]`

Para manipular vectores con variable categórica es conveniente convertir a factor [`factor()`]. En el caso de ser nominal, no importa el orden.

En el caso en que la variable sea ordinal, con el comando `factor()` se puede indicar el orden de los niveles de la variable con el argumento `levels=`

- `opiniones = c("Bueno", "Malo", "Neutro", "Bueno", "Malo", "Malo", "Neutro", "Neutro")`
- `opiniones = factor(opiniones)`
- `opiniones = factor(opiniones, levels=c("Malo", "Neutro", "Bueno"))`

Ayuda en R

Para buscar ayuda para funciones: `?`

Matrices

Para definir una matriz: `matrix()`

Cantidad de filas: `nrow =`

Cantidad de columnas: `ncol =`

Rellenado por filas: `byrow = TRUE`

Rellenado por columnas: `byrow = FALSE`

R: Ejemplo: `matrix(v3,nrow=4,ncol=5,byrow=TRUE)`

Para acceder a un elemento de una matriz m: `m[i,j]`

Para acceder a una fila de m: `m[i,]`

Para acceder a una columna de m: `m[,j]`

Para acceder a un conjunto de filas de m: `m[c(a,b),]`

Para acceder a un conjunto de columnas de m: `m[,c(f,g)]`

Para acceder a un conjunto de filas y columnas de m: `m[c(a,b),c(f,g)]`

Para obtener m sin la fila i: `m[-i,]`

Para obtener m sin la columna j: `m[, -j]`

Para obtener m sin la fila i ni la columna j: `m[-i, -j]`

A partir de estos se pueden hacer diferentes combinaciones para obtener información de la matriz m.

Así como a los vectores se pueden asignar nombres a las filas y columnas de una matriz m mediante `rownames()` y `colnames()`

- `nombrefilas = c("f1", "f2", "f3", "f4")`
- `nombrescolumnas = c("c1", "c2", "c3", "c4", "c5")`
- `rownames(m) = nombrefilas`
- `colnames(m) = nombrescolumnas`

Se pueden utilizar las operaciones básicas, operadores lógicos en matrices.

Con los operadores lógicos se puede filtrar una matriz, por ejemplo:

- `m[m>5]`
- `m[m<=5]`
- `m[m>5 & m<5]`
- `m[m>15 | m<15]`

Funciones asociadas a matrices en R

- Diagonal: `diag()`
- Producto elemento a elemento: `*`
- Producto matricial: `%*%`
- Dimensiones: `dim()`
- Número de columnas: `ncol()`
- Número de filas: `nrow()`
- Transpuesta: `t()`
- Determinante: `det()`
- Inversa: `Solve()`
- Suma de filas: `rowSums()`
- Suma de columnas: `colSums()`
- Promedio simple de filas: `rowMeans()`
- Promedio simple de columnas: `colMeans()`
- Para unir filas a una matriz: `rbind()`
- Para unir columnas a una matriz: `cbind()`

Bases de datos

Para ver las primeras 6 observaciones de una base de datos: `head()`

Para ver las 6 últimas observaciones de una base de datos: `tail()`

Para obtener una breve descripción de la base de datos y el tipo de variables: `str()`

Para obtener estadísticas descriptivas de las variables de la base: `summary()`

Para crear una base de datos: `data.frame(variable1, variable2,...)`

Para definir nombres a las columnas: `data.frame(Nombre1=variable1,...)`

Para acceder a los subconjuntos de una base de datos se hace el mismo procedimiento que para una matriz. También se pueden acceder a columnas de una base de datos `bd` mediante `bd$Columna` o `bd$NombreColumna`

Para acceder a un subconjunto de datos con alguna restricción: `subset(Base de datos, subset=Restricción)`

Otra forma de filtrar es mediante el uso de corchetes: `Base[Base$Columna=Restricción,]`

- `Libreta[Libreta$Azul==TRUE,]`
- `Libreta[Libreta$Azul==TRUE & Libreta$Nota>5,]`

Para ordenar en orden creciente una base de datos: `order()`

Para ordenar en orden decreciente una base de datos: `order(-)`

Para agregar una nueva fila: `rbind()`

- `nuevafila = data.frame(Tipo="I4", Nota=4.5, Azul=TRUE)`

- `nuevaLibreta = rbind(Libreta, nuevafila)`

Para agregar una nueva columna:

- `nuevaLibreta$nuevacolumna = nuevaLibreta$Nota+1`

Para renombrar filas: `rownames()`

Para renombrar columna: `colnames()`

Para renombrar una fila en específico: `rownames()[i]`

Para renombrar una columna en específico: `colnames()[j]`

Listas

Para crear una lista: `list(variable1, variable2,...)`

Para asignar nombre a los componentes de la lista: `list(nombre1=variable1,...)`

Para acceder a los objetos de la lista: `lista[i]` o `lista$objeto`

Instalación de paquetes

Para obtener las aplicaciones que contiene el paquete base: `getOption(paquete)`

Para instalar un paquete: `install.packages("Nombre del paquete")`

Para cargar el paquete: `library("Nombre del paquete")`

Lectura de bases de datos

Para importar bases de datos en formato TXT, DAT y Excel, en R se utiliza las siguientes funciones:

- Importar bases de datos en formato TXT, DAT y CSV: `read.table()`
- Importar bases de datos en formato CSV: `read.csv()`
- Importar bases de datos en formato XLS y XLSX: `read:excel()`
- Importar un vector de datos: `scan()`
- Importar distintos tipos de datos: `import()` (Necesario el paquete rio)

Para obtener el nombre de las variables de la base: `names()`

Dos formas comunes para importar bases de datos:

- `data = import(file.choose())`
- `data = import("../base_de_datos.txt")`

Para seleccionar directamente un archivo: `file.choose()`

Sugerencia: Se sugiere utilizar el comando `import()` incluso para dos formatos mencionados

Nota: Para evitar problemas con números decimales con signo decimal la coma, se agrega un argumento adicional al comando `import()` de la siguiente manera

```
R: import(,dec=",")
```

Para saber el directorio actual: `getwd()`

Para cambiar de directorio: `setwd()`

Para conocer la dirección del directorio a cambiar: `choose.dir()`

(Para Mac) Para conocer la dirección del directorio a cambiar: `choose.sir()` (librería: easyscsv)

Para obtener la clase de cada columna con una estadística: `str()`

Para cambiar el tipo de variable en una base de datos: `as.TipoVariable()`

- `as.factor(data$Juego_tenis)`
- `as.numeric(Variable)`

Otras funciones útiles de R

- Combinatoria de n sobre r : `choose(n,r)`
- Muestra de tamaño n de un vector x : `sample(x,n,replace=)`
- Redondea el número x con n decimales: `round(x,n)`

Estadística descriptiva

Las medidas más comunes para variables numéricas se pueden clasificar de la siguiente manera

- **Tendencia Central:** Media, Moda, Mediana
- **Posición:** Percentil, Mínimo, Máximo
- **Dispersión:** Varianza, Desviación Estándar, c.o.v, Rango, Rango Intercuantil
- **Forma** Coeficiente de Asimetría, Kurtosis

Mientras que en las variables no numéricas solo se pueden trabajar como tabla de frecuencias

Funciones de R para estadística descriptiva

- Media: `mean()`
- Varianza: `var()`
- Desviación estándar: `sd()`
- Resumen de un vector numérico: `summary()`
- Cuantiles de una muestra: `quantile()`
- Mínimo de una muestra: `min()`
- Máximo de una muestra: `max()`
- Rango de una muestra: `range()`
- Mediana de una muestra: `median()`
- Tabla de conteo de una muestra: `table()`

Programación básica

if, else, else if

```
if(condición lógica){
  expresión...
} else if(condición){
  expresión...
} else{
  expresión...
}
```

for, while

```
while(condición lógica){
  expresión...
}

for(variable in vector){
  expresión...
```

```
}
```

ifelse

```
ifelse(text, A,B)
```

Donde **text** es una expresión lógica, **A** es lo que se ejecuta si la expresión lógica es verdadera y **B** es lo que se ejecuta si la expresión es falsa

Crear funciones

Para crear una función en R: **function**

```
function(argumentos){  
  expresión...  
  return(resultado) o list(resultado)  
}
```

Más funciones útiles

- Secuencia desde a hasta b cada d unidades: **seq(from=a,to=b,by=d)**
- Repite x , n veces: **rep(x,n)**
- Ordena el vector x de menor a mayor: **sort(x)**
- Da vuelta al vector x : **rev(x)**
- Mínimo de cada componente de los vectores: **pmin(x1,...,xn)**
- Máximo de cada componente de los vectores: **pmax(x1,...,xn)**

Funciones apply

- **Sapply**: **sapply(X,FUN,argumentos)** (Para vectores)
Calcula para cada elemento del vector X la función **FUN**. Si la función **FUN** tiene mas de un argumento, estos se los puede agregar en **argumentos** de la función **sapply**
- **Apply**: **apply(X, MARGIN, FUN, argumento)** (Para matrices)
Calcula para cada columna de la matriz X la función **FUN**. Si ésta tiene más de un argumento, se los agrega en **argumento** de la función **apply**.

El calculo es hecho por filas: **MARGIN=1**
El calculo es hecho por columnas: **MARGIN=2**
- **Tapply**: **tapply(X, INDEX, FUN, argumento)** (Para vectores)
Calcula la función **FUN** al vector X dependiendo de los valores del argumento **INDEX** que por defecto se asume categórico y es un vector del mismo largo de X . Si la función **FUN** tiene más de un argumentos, se los agrega a **argumento** de la función **tapply**
- **Lapply**: **lapply(X; FUN, argumento)** (Para bases de datos)
Opera para cada columna del **data.frame** X la función **FUN**. Si la función **FUN** tiene más de un argumento, se los agrega en **argumento** de la función **lapply**

Gráficos

Para graficar un vector x versus un vector y : `plot(x,y,...)`

Para agregar un punto (x_1, y_1) : `points(x1,y1,...)` (Usar despues de ejecutado `plot()`)

Para agregar una línea entre dos puntos (x_1, y_1) , (x_2, y_2) : `lines(c(x1,x2),c(y1,y2),...)`

Para agregar líneas horizontales y/o verticales: `abline(h= o v=)`

Para agregar línea con intercepto "a" y pendiente "b": `abline(a,b)`

Para dibujar un gráfico en blanco: `plot(x,y, type = "n",...)`

Para mostrar mas de un gráfico: `par(mfrow=c(1,n))`

Argumentos opcionales de plot()

Para agregar nombre en el eje X: `xlab="Nombre de eje"`

Para agregar nombre en el eje Y: `ylab="Nombre de eje"`

Para agregar título al gráfico: `main="Título"`

Para cambiar color: `col="Nombre del color"`

Para cambiar grosor: `lwd=`

Para agregar texto en un punto (x, y) : `text(x,y,label="texto")`

Para agregar un titulo a un gráfico ta ejecutado: `title("Título")`

Para agregar límites en el eje X: `xlim=c(a,b)`

Para agregar límites en el eje Y: `ylim=c(d,e)`

Para graficar la curva de una función respecto a x , `curve(f(x),a,b)`

Para rotar los números de los ejes: `las=`

- `las=0`: Paralelo a los ejes
- `las=1`: Orientación horizontal
- `las=2`: Perpendicular a los ejes
- `las=3`: Orientación vertical

Para cambiar el estilo de fuente del título: `font.main=`

Para escribir expresiones matemáticas en títulos, puntos ejes, etc: `expression()`

Para configurar el tipo de línea: `lty=`

Para seleccionar el tipo de dibujo para un punto: `pch=`

Comando boxplot()

Se utiliza para graficar diagramas de cajas.

El comando es:

```
R: boxplot(x=,main=,xlab=,ylab=,horizontal=,col=)
```

Donde:

- `x`: vector de datos
- `horizontal`: TRUE si se quiere en sentido horizontal y FALSE en sentido vertical

Ademas: `boxplot(x~y,...)`

A diferencia del anterior, éste lleva una variable y que puede asignar los datos de x en distinnros grupos.

Comando hist()

Se utiliza para graficar histogramas, el comando es el siguiente:

```
R: hist(x=,main=,breaks=,freq=,xlab=,ylab=,col=)
```

Donde:

- **x**: es el vector de datos
- **breaks**: número aproximado de clases o un vector donde se indican los puntos límites entre clases o intervalos
- **freq**: TRUE si el histograma representa las frecuencias absolutas o conteo de datos de cada clase, si FALSE el histograma representa las frecuencias relativas

Argumentos extras:

- **border**: Para definir el color de los bordes de las barras
- **plot**: Argumento lógico, si es TRUE, el resultado es el gráfico del histograma, si es FALSE el resultado es una lista de conteos por cada intervalo
- **labels**: Argumento lógico o carácter, si es TRUE coloca etiquetas arriba de cada barra
- **nclass**: `nclass=n` equivale a `breaks=n`

Comando `barplot()`

Permite representar para cada una de las modalidades definidas para una variable cualitativa o los valores de una variable discreta en términos de frecuencias relativas o absolutas, el comando es el siguiente:

```
R: barplot(height,legend.text=NULL,beside=FALSE,horizontal=FALSE,col=,...)
```

Donde:

- **height**: vector o matriz de valores que describen las barras., En el caso de variables categóricas, se entrega el `table` de la variable. Si es un vector, entonces el gráfico corresponde a una secuencia de barras rectangulares con alturas correspondientes a los valores del vector
- **beside**: FALSE gráfico de barras apilado, TRUE gráfico de barras agrupado
- **legend.text**: Es la leyenda del gráfico

Modelos de probabilidad

Cada comando de cada distribución se puede utilizar de 4 formas diferentes:

- `dDISTR(x,...)`: Para las discretas, entrega $P(X = x)$, para las continuas, entrega $f_X(x)$
- `pDISTR(q,...)`: Entrega $P(X \leq q)$
- `qDISTR(p,...)`: Entrega el valor de x tal que $P(X \leq x) = p$
- `rDISTR(n,...)`: Genera una muestra proveniente de un modelo de distribución

Semillas

Para fijar una semilla: `set.seed()`

Estas semillas establecen el número inicial utilizado para generar una secuencia de números aleatorios.

Medidas descriptivas Teóricas vs Empíricas

Para determinar las probabilidades empíricas se puede utilizar la función `prop.table()`, esta divide a la tabla hecha por `table()` por la suma total de ésta, por lo que `sum(prop.table())` de ser 1.

Para determinar la probabilidad

- **Probabilidad muestral**

```
R: #Probabilidad P(X >,>=,=,<=,< a)
mean(X >,>=,==,<=,< a)
```

■ Probabilidad teórica

Aquí se utiliza los comandos `dDISTR()` y/o `pDISTR()` correspondiente a la distribución utilizada

Para determinar la media

■ Media muestral

```
R: mean(X)
```

■ Media teórica

Aquí se utiliza la ecuación de la media de acuerdo a la distribución utilizada

Para determina la moda

■ Moda muestral

```
R: filtro=(table(X)==max(table(X)))
table(X)[filtro]
```

■ Moda teórica

```
R: filtro=dDIST(x,...)==max(dDIST(x,...))
x[filtro]
```

Para determinar la mediana

■ Mediana muestral

```
R: median(X)
```

■ Mediana teórica

```
R: qDIST(0.5,...)
```

Para determinar la esperanza matemática

■ Esperanza matemática

```
R: g=function(X){
# Función matemática a utilizar
}
mean(g(X))
```

Para determinar el percentil

■ Percentil muestral

```
R: quantile(X,seq(0,1,0.1))
```

■ Percentil teórico

```
R: qDISTR(seq(0,1,0.1),...)
```

Para calcular la varianza

■ Varianza muestral

```
R: var(X)
```

- **Varianza teórica**

Aquí se utiliza la ecuación de la varianza de acuerdo a la distribución utilizada

Para determinar la desviación estándar

- **Desviación estándar muestral**

```
R: sd(X)
```

- **Desviación estándar teórica**

Aquí se utiliza la ecuación de la desviación estándar de acuerdo a la distribución utilizada

Para determinar el rango

- **Rango muestral**

```
R: textttRango=function(X){  
  max(X)-min(X)  
}  
Rango(X)  
  
o también  
  
range(X)[2]-range(X)[1]
```

- **Rango teórico**

```
R: maximo-0
```

Para determinar el rango intercuartil

- **Rango intercuartilico muestral**

```
R: IQR=function(X){  
  quantile(X,0.75)-quantile(X,0.25)  
}  
IQR(X)
```

- **Rango intercuartilico teórico**

```
R: qDISTR(0.75,...)-qDISTR(0.25,...)
```

Para determinar la medida de asimetría

- **Skewness muestral**

```
R: install.packages("moments")  
library(moments)  
skewness(X)
```

Para determinar la kurtosis

- **Kurtosis muestral**

```
R: install.packages("moments")  
library(moments)  
kurtosis(X)-3
```

Para determinar la covarianza y correlación

- **Covarianza muestral**

```
R: cov(X,Y)
```

■ Correlación muestral

```
R: cor(X,Y)
```

Paquete dplyr

El paquete **dplyr** es principalmente un conjunto de funciones diseñadas para permitir la manipulación de macros de datos de una manera intuitiva y fácil de usar. Sirve para transformar conjuntos de datos existentes en un formato más adecuado para algún tipo particular de análisis o visualización de datos.

Para su instalación: `install.packages("dplyr")`

Para cargarlo: `library(dplyr)`

Funciones de dplyr

filter

Selecciona un subconjunto de filas aplicando ciertos filtros, su primer argumento es la base de datos, los siguientes argumentos son las condiciones para el filtro

```
R: filter(base, condicion1, condicion2,...)
```

slice

Selecciona un subconjunto de filas según la posición de las filas, el primer argumento es la base de datos, los siguientes argumentos son los índices de las filas a seleccionar

```
R: slice(base, fila i, fila j, fila k,...)
```

arrange

Permite ordenar los datos de ciertas columnas seleccionadas, para ordenarlas de menor a mayor:

```
R: arrange(base, columna i, columna j,...)
```

Para ordenarlos de forma descendiente se utiliza `desc()`

```
R: arrange(base, desc(columna i), ...)
```

select

Selecciona un subconjunto de columnas, el primero argumento es la base de datos, los siguientes argumentos son las columnas a seleccionar

```
R: select(base, columna i, columna k, ...)
```

rename

Permite renombrar columnas, el primer argumento es la base de datos, los siguientes argumentos son los nuevos nombres para las columnas

```
R: rename(base, nombre1=columna i, nombre2=columna j,...)
```

distinct

Permite obtener valores principales de una variable, el primer argumento es la base de datos, los siguientes argumentos son las variables (columnas) a seleccionar

```
R: distinct(selec(base de datos, variable1, variable2,...))
```

mutate

Permite agregar nuevas columnas que son funciones de las ya existentes, el primer argumento es la base de datos y los siguientes argumentos son las nuevas columnas a agregar

```
R: mutate(base de datos, NuevaColumna=f(ColumnaExistente))
```

transmute

Combinación de `mutate` y `select`, permite agregar nuevas columnas en función de las ya existentes pero no se muestra la columna agregada, el primer argumento es la base de datos y los siguientes son las nuevas columnas a agregar

```
R: transmute(base de datos, NuevaColumna=f(ColumnaExistente))
```

summarise

Permite obtener resúmenes de datos de la base de datos, el primer argumento es la base de datos y los siguientes son las medidas a resumir

```
R: summarise(base de datos, media_variable i=mean(variable i), sd_variable i=sd(variable i),...)
```

sample_n

Permite obtener un número n (con o sin remplazo) de filas aleatorias, el primer argumento es la base de datos y el segundo es el tamaño de la muestra a seleccionar y el tercer argumento es seleccionar con o sin remplazo

```
R: sample_n(base de datos,size=n,replace=F o T)
```

sample_frac

Permite obtener un porcentaje $p\%$ (con o sin remplazo) de filas aleatorias, el primer argumento es la base de datos, el segundo argumento es el tamaño porcentual y el tercer argumento es seleccionar con o sin remplazo

```
R: sample_frac(base de datos,size=p,replace=F o T)
```

Operador Pipe

El operador Pipe `%>%` permite realizar múltiples funciones y operaciones dentro de la base de datos, primero se escribe la base de datos, luego el operador Pipe y finalmente las operaciones a realizar

```
R: base de datos%>% operacion 1%>% operacion 2%>% ...
```

group_by

Permite agrupar y realizar resúmenes en grupos de la base de datos

```
R: base de datos %>% group_by(variable1, variable2,...) %>% summarise(dato1=fun1, dato2=fun2,...)
```

which

Sirve para obtener los índices de las filas de una base de datos que cumpla una condición dada

```
R: which(base de datos$variable1==condicion1,...)
```

Operador %in%

Indica si un valor o componentes de un vector se encuentran dentro de los valores de otro vector, esto retorna un valor o vector con valores booleanos para cada componente

```
R: base de datos$variable1 %in% c(valor 1, valor 2,...)
```

Múltiples variables aleatorias

Si se está trabajando con una tabla de base de datos, se puede obtener lo siguiente

■ Función de probabilidad conjunta

Sean X e Y dos variables aleatorias, su función de probabilidad conjunta se calcula como

```
R: tabla=table(base$X,base$Y)
función.probabilidad.conjunta = prop.table(tabla)
```

■ Función de probabilidad marginal de X

Para obtener $p_X(x)$ se utiliza

```
R: p.X = apply(X = función.probabilidad.conjunta, Margin=1, FUN=sum)
```

■ Función de probabilidad marginal de Y

Para obtener $p_Y(y)$ se utiliza

```
R: p.Y = apply(X = función.probabilidad.conjunta, Margin=2, FUN=sum)
```

■ Función de probabilidad condicional $Y|X$

Para encontrar $p_{Y|X=x}(y)$ se utiliza

```
R: p.Y.dado.X = prop.table(tabla,margin=1)
```

■ Independencia de variables

Para comprobar si dos variables aleatorias X e Y son independientes, se utiliza

```
R: función.probabilidad.conjunta["a","b"]
p.X["a"]
p.Y["b"]
función.probabilidad.conjunta["a","b"] == p.X["a"]*p.Y["b"]
```

Si resulta en ser **TRUE**, entonces las variables son independientes, si resulta en ser **FALSE**, las variables no son independientes

Función de probabilidad conjunta mediante condicionales

Si se tiene una variable $Y \sim \text{Distribución1}(\alpha_1, \alpha_2, \dots)$ y una variable condicional $X|Y = y \sim \text{Distribución2}(\beta_1, \beta_2, \dots)$, entonces su probabilidad conjunta se obtiene mediante los siguientes comandos

```
R: p.X.Y = function(x,y){
  p.conjunta = ifelse(condición, si condición es verdadera, 0 si es falsa)
}
```

Gráfica de función de probabilidad conjunta (Discreto)

Para hacer un gráfico en el espacio de la función de probabilidad conjunta de dos variables aleatorias se utiliza los siguientes comandos

```
R: x=seq(a,b)
y=seq(a,b)
z=outer(x,y,p.X.Y)
X=rep(x,times=length(y))
Y=rep(y,each=length(x))
Z=c(z)

install.packages("scatterplot3d") (Solo si no se instalo previamente)
library(scatterplot3d)

scatterplot3d(X,Y,Z,type="h",lwd=d,pch=,highlight.3d=TRUE,angle=alpha)
```

Nota: se pueden seguir agregando mas argumentos al gráfico

Gráfica de función de densidad conjunta (Continuo)

Para hacer un gráfico en el espacio de la función de densidad conjunta de dos variables aleatorias se utiliza los siguientes comandos

```
R: f.X.Y = function(x,y){
  densidad = ifelse(condición de x e y, f(x,y),0)
}

Gráfico
x=seq(a,b,by=d)
y=seq(a,b,by=d)
z=outer(x,y,f.X.Y)

install.packages("hola") (Solo si no se instalo previamente)
library(rgl)

rgl.surface(x=x,y=z,z=y,color="Color",back="lines")

X=rep(x,times=length(y))
Y=rep(y,each=length(x))
Z=c(z)

scatterplot3d(X,Y,Z,type="h",lwd=c,pch=,highlight.3d=TRUE,angle=phi)
```

Normal Bivariada

La distribución conjunta Normal Bivariada de dos variables aleatorias X e Y se representa mediante el siguiente código

```
R: install.packages("mvtnorm")
library(mvtnorm)
```

```

X=#Datos correspondientes a la variable X
Y=#Datos correspondientes a la variable Y

mu.X=mean(X)
mu.Y=mean(Y)
sigma.X=sd(X)
sigma.Y=sd(Y)
rho=cor(X,Y)

#Matriz Sigma
#Alternativa 1
Sigma=matrix(c(sigma.X**2,rho*sigma.X*sigma.Y,rho*sigma.X*sigma.Y,sigma.Y**2),
ncol=2,nrow=2,byrow=T)
#Alternativa 2
Sigma=cov(cbind(X,Y))

#Vector de medias
mu=c(mu.X,mu.Y)

#Calcular la probabilidad P(X<a,Y<b)
pmvnorm(lower=c(-Inf,-Inf),upper=c(a,b),mean=mu,sigma=Sigma)[1]
#Calcular la probabilidad P(X>a,Y>b)
pmvnorm(lower=c(a,b),upper=c(Inf,Inf),mean=mu,sigma=Sigma)[1]
#Calcular la probabilidad P(a<X<b,c<Y<d)
pmvnorm(lower=c(a,c),upper=c(b,d),mean=mu,sigma=Sigma)[1]

```

Para graficar la función de densidad conjunta teórica

```

R: library(rgl)
f.xy=funtion(x,y,mu.x=0,mu.y=0,s.x=1,s.y=1,rho=0){
n.r=length(x)
n.c=length(y)
M=matrix(NA,ncol=n.c,nrow=n.r)
for(i in 1:n.r){
M[i,]=dnorm(x[i],mean=mu.x,sd=s.x)*dnorm(y,mean=mu.y+rho*s.y*(x[i]-mu.x)/s.x,
sd=s.y*sqrt(1-rho**2))
}
M
}

x=seq(a,b,by=d)
y=seq(e,f,by=c)
z=f.xy(x,y,mu.x=h,mu.y=i,s.x=j,s.y=k,rho=m)

rgl.surface(x=x,y=z*t,z=y,color="Color",back="lines")

El valor t es para agrandar o disminuir la gráfica

```

Para graficar la función de densidad muestral

```

R: install.packages("MVN")
library(MVN)
Par=cbind(X,Y)

mvn(Par,multivariatePlot = "persp")
mvn(Par,multivariatePlot = "contour")

```

Filtrado de base de datos avanzado

A veces no solo es necesario filtrar una base de datos de acuerdo al valor de algunas variables, también es necesario saber filtrar una base de acuerdo a un subconjunto de datos y calcular resúmenes estadísticos en el proceso, en este apartado se mostrarán 3 maneras de realizar esto

Uso del comando `aggregate()`

La sintaxis de la función `aggregate()` dependerá de los datos de entrada, hay 3 entradas posibles, una base de datos, una fórmula o un objeto de clase serie temporal, solo se verán los 2 primeros casos

```
R: aggregate(x, by=list(), FUN,...) # Caso Base de datos
```

Donde

- **x**: Corresponde al objeto a utilizar, puede ser un vector o una variable numérica de una base de datos
- **by**: Corresponde a la lista de variables que conforman los grupos
- **FUN**: Corresponde a la función usada para el resumen estadístico, como `mean`, `sd`, `var`, etc

```
R: aggregate(formula, data, FUN,...) # Caso fórmula
```

Donde

- **fórmula**: Corresponde a la fórmula de entrada, generalmente es `formula = Variable.Numérica ~ Variable.Categórica`
- **data**: Corresponde a la base de datos donde se encuentran las variables
- **FUN**: Corresponde a la función usada para el resumen estadístico

Ejemplo: Uso de `aggregate()`

Si se desea conocer los promedios de la velocidad de los autos en ciertas ciudades, suponiendo que se tiene la base de datos que contiene esta información, para calcular lo pedido se puede utilizar la función `aggregate` como sigue

```
aggregate(x=Base$Velocidad, by=list(Base$Ciudad), mean)
aggregate(Velocidad ~ Ciudad, data=Base, mean)
```

Uso del comando `tapply()`

La sintaxis de la función es la siguiente

```
R: tapply(X, INDEX, FUN,...)
```

Donde

- **X**: Corresponde al objeto a utilizar, ya sea una matriz, un vector, una base de datos, etc.
- **INDEX**: Corresponde a una lista o listas de factores de la misma longitud de **X**, `INDEX=list(Variable1,...)`
- **FUN**: Corresponde a la función que se utiliza para el resumen estadístico.

Ejemplo: Uso de `tapply()`

Tomando el ejemplo anterior, si se quiere utilizar la función `tapply()` en esta situación, se escribe lo siguiente

```
tapply(X=Base$Velocidad, INDEX=list(Base$Ciudad), mean)
```

Uso del comando `group_by()` y `summarise()`

Para utilizar estas funciones es necesario tener instalado el paquete `dplyr`, la sintaxis del código a utilizar es

```
R: Y = Base %>% group_by(Var1,...) %>% summarise(dato1=FUN(Var.Num1),...)
X = data.frame(Y)
```

Donde

- **Base:** Corresponde a la base a utilizar
- **%>%:** Es el operador pipe
- **group_by():** Agrupa los datos en grupos correspondiente a cada variable
- **Var1,...:** Es la variables o las variables las cuales conforman los grupos
- **summarise():** Permite realizar resúmenes estadísticos
- **FUN:** Función a utilizar para el resumen estadístico
- **Var.Num1,...:** Variables numéricas utilizadas

Ejemplo: Uso de `group_by()` y `summarise()`

Finalizando con el ejemplo, para calcular lo pedido utilizando estos 2 comandos, se escribe lo siguiente

```
Y=Base %>% group_by(Ciudad) %>% summarise(medias=mean(Velocidad))
X=data.frame(Y)
```