
APUNTES DE SIMULACIÓN DE SISTEMAS

APUNTES DEL CURSO SIMULACIÓN DE SISTEMAS
CIND213, UNIVERSIDAD ANDRÉS BELLO

MARCEL FAVEREAU, PhD

*UNIVERSIDAD ANDRÉS BELLO,
CHILE*

$\boxed{\mathcal{MF}}$

2024

Índice general

1. Introducción a la Simulación	7
1.1. El proceso de simular	7
1.1.1. Diseño conceptual	10
1.1.2. Análisis del <i>input</i>	10
1.1.3. Desarrollo, verificación y validación del modelo . .	11
1.1.4. Análisis del <i>output</i> y experimentación	11
1.2. Habilidades exitosas para la simulación	12
1.2.1. Objetivos del proyecto	12
1.2.2. Especificación funcional	12
1.2.3. Iteraciones del proyecto	14
1.2.4. Gestión de proyectos y agilidad	15
1.3. Tipos de simulación	15
1.3.1. Modelos estáticos vs. dinámicos	15
1.3.2. Modelos dinámicos de cambio continuo vs. cambio discreto	16
1.3.3. Modelos determinísticos vs. estocásticos	16
1.3.4. Paradigmas de la simulación	17
1.4. Simulación manual	21
2. Repaso de Probabilidad y Estadística	33
2.1. Teoría de probabilidad	33
2.1.1. Medida de probabilidad	34
2.1.2. Probabilidad condicional	35
2.1.3. Independencia	35
2.1.4. Ley de probabilidad total	36
2.1.5. Regla de Bayes	36
2.2. Estadística descriptiva	37
2.2.1. Medidas de tendencia central	38
2.2.2. Medidas de dispersión	38
2.2.3. Medidas de dependencia	39

2.3. Variables aleatorias	40
2.3.1. Función de masa de probabilidad	40
2.3.2. Función de distribución acumulada discreta	41
2.3.3. Conexión entre pmf y cdf	41
2.3.4. Funciones de variables aleatorias continuas	42
2.3.5. Esperanza de una variable aleatoria	44
2.3.6. Varianza de una variable aleatoria	44
2.3.7. Variables aleatorias discretas: ejemplos	45
2.3.8. Variables aleatorias continuas: ejemplos	46
2.4. Inferencia estadística	47
2.4.1. Población y muestra	47
2.4.2. Ley de los grandes números	49
2.4.3. Teorema del límite central	50
2.4.4. Breve profundización: valor esperado de la media muestral	51
2.4.5. Breve profundización: varianza de la media muestral	52
2.4.6. Intervalos de confianza	52
2.4.7. Pruebas de hipótesis	54
3. Generación de Números Aleatorios	59
3.1. Introducción a la generación de números aleatorios	59
3.2. Método de los cuadrados medios	61
3.3. Generadores congruenciales lineales	62
3.3.1. Periodo de un generador	65
3.4. Otros generadores	67
3.4.1. Congruencias más generales	68
3.4.2. Generadores recursivos múltiples	68
3.4.3. Generadores compuestos	68
3.4.4. Generadores recursivos múltiples compuestos	70
3.4.5. Generadores de registros de desplazamiento con re- troalimentación	71
3.4.6. Generador Mersenne Twister	72
3.5. Pruebas estadísticas para generadores de números aleatorios	73
3.6. Pruebas estadísticas	76
3.6.1. Prueba de bondad de ajuste chi-cuadrado (χ^2)	77
3.6.2. Pruebas de independencia	78
4. Generación de Variables Aleatorias	82
4.1. Introducción a la generación de variables aleatorias	82
4.2. Método de la transformada inversa	83

4.2.1. Método de la transformada inversa para distribuciones continuas	84
4.2.2. Método de la transformada inversa para distribuciones discreta	87
4.2.3. Método de la transformada inversa para distribuciones continuas empíricas	90
4.3. Método de composición	94
4.4. Método de convolución	95
4.5. Método de aceptación y rechazo	97
4.6. Otros métodos	101
4.6.1. Método Box-Muller	101
4.6.2. Método polar	102
5. Análisis del Input	103
5.1. Hipotetización de la distribución	104
5.2. Estimación de parámetros de una distribución	107
5.2.1. Estimadores de máxima verosimilitud	110
5.2.2. Método de los momentos	115
5.3. Pruebas de bondad de ajuste	117
5.3.1. Prueba de bondad de ajuste chi-cuadrado (χ^2)	117
5.3.2. Prueba de bondad de ajuste Kolomgórov-Smirnov	121
5.4. Problemas comunes	125
6. Análisis del Output	130
6.1. Comportamiento transiente y de estado estable de un proceso estocástico	133
6.2. Tipos de simulación basados en análisis del <i>output</i>	135
6.3. Análisis estadístico para simulaciones terminales	138
6.4. Análisis estadístico para parámetros de estado estable	142
6.4.1. Método de Welch	144
6.4.2. Método de replicación/eliminación	146
7. Comparación de Sistemas	150
7.1. Introducción a la comparación de sistemas	150
7.2. Intervalos de confianza para comparar dos configuraciones alternativas de un sistema	154
7.2.1. Intervalo de confianza <i>t</i> -pareado	154
7.2.2. Intervalo de confianza modificado de dos muestras- <i>t</i>	157
7.3. Intervalos de confianza para comparar más de dos sistemas	159
7.3.1. Comparación con un estándar	160

7.3.2.	Todos los pares de comparaciones	163
7.3.3.	Comparaciones múltiples con el mejor	164
7.4.	Clasificación y selección	165
7.4.1.	Seleccionando el mejor de k sistemas	165
7.4.2.	Seleccionando los mejores m de k sistemas	167
7.4.3.	Procedimientos totalmente secuenciales	170
8.	Optimización Basada en Simulación	172
8.1.	Problema General	172
8.2.	Búsqueda tabú	175
8.3.	Búsqueda dispersa	179
8.4.	Redes neuronales	183
8.4.1.	Neuronas	183
8.4.2.	Red neuronal	184
8.4.3.	Funciones de activación	186
8.4.4.	Algoritmo de descenso de gradiente	187
8.4.5.	Algoritmo de retropropagación	188
8.5.	Paquete OptQuest	189
8.5.1.	Inicialización del algoritmo	191
8.5.2.	Proceso iterativo	192
8.5.3.	Uso de redes neuronales	192

Prefacio

Este libro se gestó con la intención de proporcionar a los estudiantes de pregrado y postgrado en ingeniería un recurso integral y detallado sobre los fundamentos y aplicaciones de la simulación de sistemas. Este texto se erige como una herramienta complementaria para aquellos que buscan profundizar sus conocimientos en esta disciplina, ya que abarca desde los conceptos básicos hasta temas especializados de simulación y toma de decisiones bajo incertidumbre.

Este libro no intenta proveer una presentación comprensiva de todos los aspectos de la simulación de sistemas, sino que se concentra en los fundamentos teóricos y básicos de ciertas áreas. El libro se organiza en ocho capítulos. El Capítulo 1 establece los cimientos de la simulación de sistemas, explorando desde el proceso de simular hasta las habilidades esenciales para llevar a cabo proyectos de simulación de manera exitosa. Se abordan temas como el diseño conceptual, la gestión de proyectos y la clasificación de modelos según su naturaleza.

En el Capítulo 2 se proporciona un repaso exhaustivo de los conceptos fundamentales de probabilidad y estadística que son esenciales para comprender y aplicar técnicas de simulación. Desde la teoría de probabilidad hasta la inferencia estadística, este capítulo establece la base matemática necesaria.

Los Capítulos 3 y 4 presentan en detalle métodos de generación de números aleatorios y realizaciones de variables aleatorias, respectivamente. El primero aborda métodos clásicos y modernos para generar secuencias aleatorias. Se exploran aspectos teóricos y prácticos, junto con pruebas estadísticas para evaluar la calidad de los generadores. En el segundo se detallan métodos para generar realizaciones de variables aleatorias, incluyendo transformada inversa, composición, convolución, aceptación y rechazo, entre otros. Cada método se ilustra con ejemplos prácticos y se discuten situaciones específicas de aplicación.

El Capítulo 5 se encarga del análisis del input, crucial para garan-

tizar que el modelo de simulación refleje de manera precisa el sistema real. Aquí, se examinan métodos para hipotetizar distribuciones, estimar parámetros y realizar pruebas de bondad de ajuste.

El capítulo 6 se centra en el análisis del output de simulaciones terminales y no terminales. Métodos estadísticos específicos para analizar los resultados de ambos tipos de simulación se presentan de manera detallada.

La comparación de sistemas es una parte integral de la simulación, y el Capítulo 7 explora la generación de intervalos de confianza para evaluar y comparar configuraciones alternativas de un sistema, junto con métodos de clasificación y selección de sistemas basada en los resultados de una simulación.

Finalmente, el Capítulo 8 introduce la aplicación de técnicas de optimización en el contexto de simulación de sistemas. El principal tópico de este capítulo es el paquete de optimización OptQuest, que considera desde métodos clásicos como la búsqueda tabú hasta el uso de redes neuronales. Esto proporciona al lector herramientas para mejorar la eficiencia y rendimiento de los sistemas simulados.

Este libro, con su enfoque teórico y práctico, se presenta como un recurso complementario para la formación académica y el desarrollo profesional en el ámbito de la simulación de sistemas. Está diseñado para satisfacer las necesidades de estudiantes de pregrado y postgrado, así como profesionales que buscan una comprensión profunda y aplicada de esta disciplina en constante evolución.

Los contenidos de este libro están fuertemente basados en textos como "Simulation modeling and analysis"(Law, 2014), "Discrete-event system simulation"(Banks & Nelson, 2014), "Introduction to probability models"(Ross, 2019), "Simulation modeling with SIMIO"(Smith et al., 2019), "The big book of simulation modeling"(Borshchev, 2013), y recursos disponibles públicamente como los apuntes del curso ISyE 6644 Simulation del profesor Dave Goldsman.

Capítulo 1

Introducción a la Simulación

En este capítulo nos adentraremos en un emocionante viaje que explora los fundamentos de la simulación como una herramienta esencial en la toma de decisiones, resolución de problemas y modelamiento de procesos. Comenzaremos por desglosar el proceso de simular, revelando cómo esta técnica permite representar situaciones reales de manera virtual, analizar resultados y evaluar diferentes escenarios sin incurrir en riesgos financieros o logísticos.

A lo largo de este capítulo, también exploraremos las habilidades clave que se requieren para llevar a cabo simulaciones exitosas, desde la formulación de modelos hasta la interpretación de resultados. Además, abordaremos los diversos tipos de simulación disponibles, lo que brindará un amplio espectro de herramientas para enfrentar problemas en campos tan variados como la ingeniería, la logística, la medicina y muchas otras disciplinas.

1.1. El proceso de simular

Comencemos con algunas definiciones básicas que nos permitirán avanzar de manera generalizada a lo largo de esta unidad.

Definición 1.1 (Sistema). Un sistema es una colección de entidades (personas, máquinas, etc.) que actúan e interactúan juntas en el cumplimiento de un objetivo

Definición 1.2 (Modelo). Un modelo es una representación abstracta de un sistema, usualmente conteniendo relaciones matemáticas o lógicas que describen el sistema en términos de estados, entidades, conjuntos, eventos, etc.

Definición 1.3 (Estado del sistema). Un conjunto de variables que contienen información suficiente para describir el sistema, que puede pensarse como una “foto” de éste. E.g., en la fila de un servidor, para describir su estado: $L_Q(t)$ = número de personas en la fila en el tiempo t , y $B(t) = 1$ [0] si el servidor está ocupado [disponible] en el tiempo t

Definición 1.4 (Lista). Una lista (o fila) es una lista ordenada de entidades (e.g., fila de personas)

Definición 1.5 (Entidades). Las entidades pueden ser permanentes (e.g., máquina) o temporales (e.g., clientes), y pueden tener varias propiedades o atributos (e.g., prioridad de cliente o velocidad media del servidor)

Definición 1.6 (Evento). Un evento es un punto en el tiempo en el cual el estado del sistema cambia (y que no puede ser predicho con certeza). E.g., una llegada, una salida o falla de máquina. “Evento” técnicamente significa el momento en que sucede la acción, pero vagamente se refiere a “qué” sucede (e.g., una llegada)

Definición 1.7 (Actividad). Una actividad es una duración de tiempo de un largo específico (*aka* una espera incondicional). E.g., un tiempo entre llegadas exponencial o tiempos de servicio constante (pues podemos generarlos explícitamente)

La mayoría de sistemas necesitan ser estudiados para intentar comprender su dinámica y relaciones, o para predecir su rendimiento bajo ciertas nuevas condiciones (*what if?*). La Figura 1.1 resume los enfoques clásicos de modelamiento de sistemas, donde destaca la simulación como modelo matemático que nos permite experimentar a través de ella (o de

un modelo de un sistema). Veremos los tipos de simulación un poco más adelante en este apunte.




Figura 1.1: Enfoques clásicos de modelamiento de sistemas

El proceso de simular un sistema típicamente es algo iterativo, no estrictamente secuencial. Está compuesto, de manera general, por 4 etapas (ver Figura 1.2): diseño conceptual, análisis del *input*, desarrollo, verificación y validación del modelo, y análisis del *output*. Revisaremos a continuación cada uno de ellos.




Figura 1.2: Esquema del proceso de simulación

1.1.1. Diseño conceptual

El diseño conceptual:

- Requiere una comprensión detallada del sistema en estudio, así como un enfoque de modelamiento básico.
- Este paso puede ser realizado con un lápiz y papel, en una pizarra o cualquier espacio de colaboración que promueva el pensamiento libre.
- Esto ayuda a pensar fuera de la caja, i.e., fuera de las restricciones de un *software* de simulación.
- Aunque una metodología bien definida sería ideal, no existe ninguna. En cambio, planificar el proyecto es un proceso informal que considera pensar y discutir sobre los detalles.
- Notar que los modelos de simulación son desarrollados para responder las preguntas levantadas en los objetivos específicos. En general, quienes recién comienzan en el mundo de la simulación invierten muy poco tiempo en la fase de diseño conceptual, y esto siempre aumenta el tiempo total requerido para completar el proyecto.

1.1.2. Análisis del *input*

En cuanto al análisis del *input*:

- Este paso considera la caracterización de los *input* del sistema, y luego desarrollar los algoritmos y códigos para generar observaciones.
- Virtualmente, todos los *software* de simulación comerciales (incluyendo Simio) tienen características integradas para generar observaciones del *input*.
- La tarea principal del análisis del *input* consiste en caracterizar las variables aleatorias de entrada y especificar las distribuciones correspondientes.
- A menudo tenemos observaciones de muestra de datos del mundo real, y un enfoque común es ajustar distribuciones estándar o empíricas.

- Si no tenemos datos del mundo real, podemos usar reglas prácticas generales y análisis de sensibilidad.

1.1.3. Desarrollo, verificación y validación del modelo

Con respecto al desarrollo, verificación y validación del modelo:

- El desarrollo de modelos es el proceso de “codificación” (programación) con el cual un modelo conceptual es convertido a un modelo de simulación “ejecutable”.
- Un desarrollo de modelo efectivo requiere una comprensión detallada de la metodología de simulación en general y cómo el *software* específico utilizado trabaja en particular.
- La verificación es el proceso de asegurar que el modelo se comporte como el modelador pretende.
- La validación asegura que el modelo es preciso en relación al sistema actual siendo modelado.
- Notar que no es posible probar que un modelo es correcto, ni en los modelos más simples. En cambio, nos enfocamos en recolectar evidencia hasta que nosotros (o nuestros clientes) estemos satisfechos.

1.1.4. Análisis del *output* y experimentación

Finalmente, el análisis del *output* y experimentación considera que:

- Una vez que el modelo ha sido verificado y validado, se debe experimentar con el modelo para obtener información acerca del sistema subyacente.
- Podría ser de interés evaluar métricas de rendimiento como el tiempo de espera promedio, el percentil 90 del número de personas esperando en una habitación, etc.
- También podría ser de interés tomar decisiones como el número de trabajadores requeridos para asegurar un cierto nivel de servicio para el cliente, la inversión que esto implica, etc.
- El análisis del *output* toma las observaciones individuales generadas por la simulación, caracteriza las variables aleatorias subyacentes (estadísticamente), y deduce inferencias acerca del sistema que está siendo modelado.

- La experimentación considera variar sistemáticamente los *input* y estructuras del modelo para investigar configuraciones alternativas del sistema.

1.2. Habilidades exitosas para la simulación

Aprender a utilizar una herramienta de simulación y comprender la tecnología subyacente no garantizará el éxito. Conducir proyectos de simulación exitosos requiere mucho más que eso.

Quienes se inician en el mundo de la simulación a menudo se preguntan cómo pueden ser exitosos. La respuesta es sencilla (y aplica para casi todo): trabajar duro y hacer las cosas correctas. Revisemos algunos de los temas más importante que deberían ser considerados para un proyecto de simulación exitoso

1.2.1. Objetivos del proyecto

Muchos proyectos comienzan con una fecha de entrega fija, pero a menudo sólo tienen una idea aproximada de lo que se entregará y una vaga idea de cómo se hará. La primera pregunta que aparece aquí es “¿cuáles son los objetivos del proyecto?”. Aunque puede parecer una pregunta obvia con una respuesta simple, a menudo ocurre que los *stakeholders* no conocen la respuesta.

Antes de definir objetivos, se necesita conocer a los *stakeholders*. Un *stakeholder* es alguien que comisiona, financia, usa o es afectado por el proyecto. Algunos *stakeholders* son obvios, pero a veces se deben identificar. ¿Por qué habría de interesar? En parte, porque los *stakeholders* a menudo tienen objetivos diferentes (contrapuestos).

1.2.2. Especificación funcional

Ahora que conocemos los objetivos del proyecto y a los *stakeholders*, podemos comenzar a construir el modelo, ¿cierto? ¡Incorrecto! En la mayoría de casos, los *stakeholders* buscarán algunos compromisos:

- ¿Cuándo estará listo?
- ¿Cuánto costará?
- ¿Qué tan comprensivo es el modelo?

- ¿Cuál será la calidad?

¿Estaremos preparados para entregar respuestas confiables a estas preguntas? Probablemente, no. Está bien para el cliente responder a dos (incluso tres) de estas preguntas. Pero, deben reservar su derecho a ajustar al menos una.

Si somos afortunados, los *stakeholders* permitirán que ustedes respondan las cuatro preguntas (obviamente, reservando su derecho de rechazar su propuesta). Pero, ¿cómo se entregan buenas respuestas? Creando una especificación funcional, que es un documento que describe exactamente qué se entregará, cuándo, cómo, y por quiénes. Mientras que los detalles requeridos en una especificación funcional varían según la aplicación y tamaño del proyecto, los componentes típicos podrían incluir:

1. Introducción.
 - Objetivos de la simulación.
 - Identificación de los *stakeholders*.
2. Descripción del sistema y enfoque de modelamiento.
 - Equipamiento.
 - Tipos de productos.
 - Operaciones.
 - Transporte.
3. Datos de *input*.
4. Datos de *output*.
5. Entregables.
 - Documentación.
 - *Software* y entrenamiento.
 - Animación.
6. Fases del proyecto.
7. Firmas.

Al comienzo de un proyecto existe una inclinación natural hacia comenzar rápidamente a modelar. El tiempo presiona. Las ideas fluyen. Hay emoción. Es difícil parar y hacer una especificación funcional, pero confíen en esto: hacer una especificación funcional vale la pena.

Observación 1.1. *Consejo del carpintero: “Mide dos veces. Corta una vez”.*

1.2.3. Iteraciones del proyecto

Los proyectos de simulación se realizan mejor como un proceso iterativo, incluso desde los primeros pasos. Un aprendiz de simulación a menudo tiene una idea y comienza modelándola, luego va añadiendo elementos al modelo hasta que esté completo (y recién ahí lo ejecuta). Pero, cuando el error (que siempre aparecen) está “en alguna parte del modelo” es muy difícil encontrarlo y corregirlo.

Los modeladores más experimentados típicamente construyen una pequeña pieza del modelo, luego lo ejecutan, lo prueban, lo corrigen, y verifican que haga lo que el modelador esperaba. Luego, repiten este proceso con otra pequeña pieza del modelo. Un beneficio extremadamente importante del enfoque iterativo es la habilidad de priorizar. Para cada iteración, se recomienda trabajar en la pequeña sección más importante del modelo que quede.

Aunque pueden variar según el proyecto y aplicación, los pasos generales en un estudio de simulación son:

1. Definir los objetivos generales e identificar a los *stakeholders*.
2. Definir la especificación funcional. Diseñar el reporte final.
3. Construir un prototipo. Actualizar pasos 1 y 2 si es necesario.
4. Modelar o mejorar una pieza de alta prioridad del sistema. Documentarla y verificarla. Iterar.
5. Recolectar e incorporar los datos de *input* del modelo.
6. Verificar y validar el modelo. Involucrar a *stakeholders*. Volver al paso 4 si es necesario.
7. Diseñar experimentos. Hacer corridas de producción. Involucrar *stakeholders*. Volver al paso 4 si es necesario.
8. Documentar los resultados y el modelo.
9. Presentar los resultados y recoger sus felicitaciones.

1.2.4. Gestión de proyectos y agilidad

- Cumplir los plazos es uno de los aspectos más obvios para un proyecto exitoso.
- Un proyecto que supere el presupuesto puede cancelarse antes de que se acerque a su finalización.
- Para guiar las decisiones, un proyecto bien gestionado comienza teniendo objetivos claros y una especificación funcional sólida.
- A través del desarrollo del proyecto, se tomarán decisiones grandes y pequeñas, como:
 - ¿Cuánto detalle debe ser modelado en una sección particular?
 - ¿Cuántos datos de *input* se necesita recolectar?
 - ¿Cuándo se considera que el modelo es válido?
 - ¿Cuánto tiempo se debe invertir en animación? Y, ¿en análisis?
- Una definición de agilidad es la habilidad de reacción rápida y apropiada a los cambios. La habilidad de ser ágil será un contribuyente significativo para el éxito de una simulación.

1.3. Tipos de simulación

1.3.1. Modelos estáticos vs. dinámicos

Definición 1.8 (Simulación estática). Un modelo de simulación estático es uno donde el paso del tiempo no juega un rol en la operación y ejecución del modelo. E.g., el uso de un generador de números aleatorios para simular la lotería, estimar el valor de una integral, etc.

Definición 1.9 (Simulación dinámica). En un modelo de simulación dinámica, el paso del tiempo (simulado) es una parte esencial de la estructura y operación del modelo. E.g., dinámica de inventarios, modelos de transporte y logística, etc.

El reloj de simulación, una variable (global) que representa el valor actual del tiempo simulado, es central en cualquier simulación dinámica.

Las simulaciones estáticas, donde no hay un reloj, usualmente son ejecutadas en una hoja de cálculo (@RISK o Crystal Ball), o en un lenguaje de programación de propósito general (Python, Julia, C++). Las simulaciones dinámicas, donde sí hay un reloj, generalmente requieren *software* más potentes creados específicamente para ellas.

1.3.2. Modelos dinámicos de cambio continuo vs. cambio discreto

En los modelos dinámicos, usualmente hay variables de estado que, colectivamente, describen el estado del sistema simulado en cualquier instante de tiempo (simulado).

Definición 1.10 (Modelo continuo). Si las variables de estado pueden cambiar continuamente en el tiempo, el modelo tiene aspectos de cambio continuo. E.g., el nivel de agua en un embalse (variable de estado) puede cambiar continuamente (incrementos/disminuciones infinitesimalmente pequeños). A menudo, tales modelos son descritos por ecuaciones diferenciales.

Definición 1.11 (Modelo discreto). Si las variables de estado pueden cambiar sólo en puntos instantáneos, separados y discretos en el eje del tiempo, luego el modelo dinámico es de cambios discretos. E.g., un modelo de simulación de filas, donde las variables de estado (como el largo de las filas) pueden cambiar sólo en los momentos de estos cambios discretos.

1.3.3. Modelos determinísticos vs. estocásticos

Definición 1.12 (Modelo determinístico). Si todos los datos de *input* de un modelo de simulación son fijos, constantes no aleatorias, entonces el modelo es determinístico. E.g., una línea de producción simple, representada por un sistema de filas, con tiempos de servicio fijos para cada parte, y tiempos fijos entre las llegada de las partes, sería determinístico.

Definición 1.13 (Modelo estocástico). El modelo anterior puede sonar un poco exagerado y, de hecho, lo es. Así que, la mayoría de los modelos de simulación son estocásticos, donde al menos algunos de los datos de *input* no son constantes fijas, sino que realizaciones aleatorias de distribuciones probabilística, quizás caracterizando la variación en tiempos de servicio y entre llegadas en esa línea de producción.

Recordar la importancia de modelar la incertidumbre... Nunca olvidar que ¡no se puede subestimar el riesgo ante la presencia de incertidumbre! Por lo tanto, confiar únicamente en promedios o estimaciones puntuales, nos puede llevar a subestimar el riesgo y la variabilidad en la dinámica de un sistema.

1.3.4. Paradigmas de la simulación

Por método nos referimos al marco general para mapear un sistema del mundo real a un modelo. A la fecha, existen tres métodos (paradigmas):

1. Dinámica de Sistemas - *System Dynamics* (SD).
2. Simulación de Eventos Discretos - *Discrete Event Simulation* (DES).
3. Simulación Basada en Agentes - *Agent-Based Simulation* (ABS).

Elegir el nivel de abstracción correcto es crítico para el éxito de un proyecto de simulación. En el proceso de desarrollo de un modelo es normal e incluso deseable reconsiderar periódicamente el nivel de abstracción. En la Figura 1.3 podemos analizar las diferencias entre los tres paradigmas, en base a sus niveles de abstracción.




Figura 1.3: Paradigmas de la simulación en base a niveles de abstracción

Dinámica de sistemas

La dinámica de sistemas (SD) es un método creado en la década de 1950 por el profesor del MIT Jay Forrester, cuya formación es en ciencia e ingeniería. La idea de Forrester fue utilizar las leyes de la física (circuitos eléctricos) para describir e investigar la dinámica de la economía y, luego, de sistemas sociales.

SD es un método de estudio de sistemas dinámicos. Aquí, se debe (Stermán, 2000):

- Tomar una visión endógena. Modelar el sistemas como una estructura causal cerrada que define su comportamiento por sí misma.
- Descubrir los bucles de retroalimentación del sistema (elemento principal de SD).
- Identificar acumulaciones y flujos. Las acumulaciones son la memoria del sistema, y fuentes de desequilibrio.
- Tomar una vista continua donde los eventos y decisiones son borrosas.

Para sentir el espíritu de SD, la Figura 1.4 presenta un típico ejemplo: difusión de nuevos productos. Este modelo es un enfoque que busca comprender cómo se propagan y adoptan nuevos productos o innovaciones en una población a lo largo del tiempo. Este modelo se basa en varios componentes clave: clientes potenciales, ventas, clientes, ventas por publicidad, ventas por boca a boca, efectividad de la publicidad, tasa de contacto de personas y fracción de ventas.




Figura 1.4: Modelo clásico de difusión de nuevos productos en dinámica de sistemas

Simulación de eventos discretos

El modelamiento de eventos discretos (DEM) es casi tan antiguo como SD. En 1961, Geoffrey Gordon (ingeniero IBM) introdujo la primera versión de GPSS (*General Purpose Simulation System*), considerado como el primer método de implementación de *software* de DEM.

La idea de DEM es: el modelador considera el sistema a modelar como un proceso, i.e., una secuencia de operaciones realizadas entre entidades. Las operaciones incluyen demoras (*delays*), atención por varios recursos, elección de procesos, fraccionamiento, combinación, entre otras. Siempre que las entidades compitan por los recursos y se puedan demorar, las filas están presentes en prácticamente cualquier DEM.

El modelo es planteado como un diagrama de flujo, donde los bloques representan operaciones. Este diagrama usualmente comienza con una “fuente” (*source*) y termina con un “sumidero” (*sink*). Típicos *output* de un DEM son: utilización de recursos, tiempo de permanencia en el sistema, tiempos de espera, largo de filas, cuellos de botella, costo de procesamiento de entidades, etc.

La Figura 1.5 presenta un ejemplo clásico de una simulación de eventos discretos: un banco. A él llegan clientes a una tasa de 0.75 personas por minutos, donde un 50 % de ellos pasa directamente con los (tres) cajeros, donde el tiempo de atención responde a una distribución triangular con mínimo, moda y máximo de 3, 5 y 20 minutos, respectivamente.

El otro 50 % pasa directamente al cajero automático (con un tiempo de atención que distribuye uniformemente entre 1 y 4 minutos), donde el 30 % de ellos pasa luego a atenderse con un cajero y el 70 % sale del sistema.




Figura 1.5: Modelo típico de simulación de eventos discretos de un banco

Simulación basada en agentes

El modelamiento basado en agentes (ABM) es un método mucho más reciente que SD o DEM. Hasta comienzos de los 2000, ABM era prácticamente un tópico académico. La adopción de ABM por el mundo de la simulación en 2002-2003 se debió a:

- El deseo de obtener una visión más profunda de los sistemas que no están bien capturados por los enfoques tradicionales.
- Los avances en *software*, *hardware* y tecnología de la informática.

Observación 1.2. Es posible que no sepa cómo se comporta el sistema como un todo, cuáles son las variables clave y las dependencias entre ellas, o simplemente que no se vea que hay un flujo de proceso, pero se puede tener una idea de cómo se comportan los objetos en el sistema individualmente. Por lo tanto, se puede comenzar a construir el modelo de abajo hacia arriba identificando esos objetos (agentes) y definiendo sus comportamientos.

La Figura 1.6 presenta un ejemplo clásico de una simulación basada en agentes: propagación de una enfermedad. Aquí, los agentes (individuos) transitan por los estados susceptible, expuesto, infectado o inmune. La transición entre estados responde a distintas variables aleatorias asociadas a la duración de cada estado. En los gráficos de la derecha es posible observar la dinámica de contagios a lo largo del tiempo, considerando una menor y mayor duración de la inmunidad.




Figura 1.6: Modelo clásico de propagación de nuevos productos en simulación basada en agentes

1.4. Simulación manual

En este ejemplo detallaremos cómo simular un sistema M/M/1 que representa una barbería con un operario. Aunque este sistema es muy simplificado en comparación a uno real, la simulación de éste será bastante representativa de una simulación de un sistema de alta complejidad. Analizaremos todos los eventos ocurridos durante la simulación para sentir la idea de la simulación de eventos discreto.

Definición del problema

El problema se puede resumir como (ver representación gráfica en Figura 1.7):

- Considerar un sistema de espera de único servidor (M/M/1) para el




Figura 1.7: Esquema de atención

cual los tiempos entre llegadas $A_1, A_2, \dots$ son variables aleatorias iid.

- Un cliente que llega y encuentra el servidor disponible comienza su atención inmediatamente.
- Los tiempos de atención $S_1, S_2, \dots$ de los clientes sucesivos son variables aleatorias iid (e independientes de los tiempos de llegada).
- Un cliente que llega y encuentra el servidor ocupado se une al final de una fila de espera.
- El sistema operará bajo la lógica FIFO (*first-in-first-out*).
- La simulación comenzará en un estado “*empty-and-idle*” (vacía y desocupada).
- En el tiempo 0 estaremos esperando la llegada del primer cliente, que ocurrirá luego del primer tiempo entre llegadas, A_1 , en lugar de en el tiempo 0 (aunque, eventualmente, esto podría suceder).

- Simularemos el sistema hasta que un número fijo (n) de clientes haya completado su espera en la fila. Notar que esto implica que la duración de la simulación es una variable aleatoria (lo profundizaremos en el Capítulo 6).
- Nuestras tres métricas de interés serán:
 1. Tiempo de espera promedio esperado de los n clientes, $d(n)$.
 2. Número promedio esperado de clientes en la fila, $q(n)$.
 3. Utilización esperada del servidor, $u(n)$.

Observaciones

Notar que la palabra “esperado” en la definición de $d(n)$ significa lo siguiente:

- En una réplica particular de la simulación, el tiempo de espera promedio real observado de los n clientes depende de las realizaciones de las variables aleatorias de los tiempos entre llegadas y de atención.
- En otra corrida probablemente habrán otras observaciones de esas variables aleatorias. Esto nos llevará a un tiempo de espera promedio real de los n clientes distintos.
- Por lo tanto, el tiempo de espera promedio en una cierta corrida es correctamente considerado como una variable aleatoria en sí misma.
- Lo que queremos estimar, $d(n)$, es el valor esperado de esta variable aleatoria. Una interpretación de esto es que $d(n)$ es el promedio de un gran número (de hecho, infinito) de tiempos de retraso promedio de n clientes.
- Si $D_1, D_2, \dots$ representan los retrasos de cada cliente en una corrida, un estimador obvio de $d(n)$ es

$$\hat{d}(n) = \bar{D}(n) = \frac{\sum_{i=1}^n D_i}{n}.$$

Notar que la palabra “promedio” en la definición de $q(n)$ es un poco distinta a la del tiempo de espera promedio ($d(n)$):

- Esto se debe a que $q(n)$ es tomado (continuamente) sobre el tiempo, en lugar de sobre los clientes (que es discreto).

- Necesitamos definir qué se entiende por este “promedio”. Para ello, definimos $Q(t)$ como el número de clientes en la fila en el tiempo $t \geq 0$, y $T(n)$ como el tiempo requerido para observar las n esperas en la fila.
- Para todo tiempo t entre 0 y $T(n)$, $Q(t)$ es un entero no negativo. Además, si definimos p_i como la proporción esperada (entre 0 y 1) de tiempo en que $Q(t)$ es igual a i , entonces una definición razonable de $q(n)$ sería

$$q(n) = \sum_{i=0}^{\infty} i p_i.$$

- Por lo tanto, $q(n)$ es un promedio ponderado de los posibles valores i para el largo de la fila $Q(t)$, con las ponderaciones siendo la proporción esperada de tiempo que la fila pasa en cada una de sus posibles longitudes.

Notar que la palabra “promedio” en la definición de $q(n)$ es un poco distinta a la del tiempo de espera promedio ($d(n)$):

- Para estimar $q(n)$ de una simulación, simplemente reemplazamos los p_i 's con estimaciones de ellos

$$\hat{q}(n) = \sum_{i=0}^{\infty} i \hat{p}_i,$$


donde $\hat{p}_i$ es la proporción de tiempo observada (en lugar de esperada) durante la simulación en que hubo i clientes en la fila.

- Computacionalmente, es más fácil reescribir $\hat{q}(n)$ en base a algunas consideraciones geométricas. Si definimos T_i como el tiempo total durante la simulación en que la cola fue de largo i , entonces $T(n) = T_0 + T_1 + T_2 + \dots$ y $\hat{p}_i = T_i/T(n)$. Luego, podemos reescribir $\hat{q}(n)$ como

$$\hat{q}(n) = \frac{\sum_{i=0}^{\infty} i T_i}{T(n)}.$$

La Figura 1.8 ilustra una posible realización de $Q(t)$ para $n = 6$. Notar que:

- Las llegadas ocurren en los tiempos 0.4, 1.6, 2.1, 3.8, 4.0, 5.6, 5.8 y 7.2
- Las salidas ocurren en los tiempos 2.4, 3.1, 3.3, 4.9 y 8.6

Figura 1.8: Posible realización de $Q(t)$ para $n = 6$

Para calcular $\hat{q}(n)$, primero calculamos los T_i 's que representan los intervalos sobre los cuales $Q(t)$ tomó valor 0,1,2 y así sucesivamente:

- $T_0 = (1,6 - 0,0) + (4,0 - 3,1) + (5,6 - 4,9) = 3,2$
- $T_1 = (2,1 - 1,6) + (3,1 - 2,4) + (4,9 - 4,0) + (5,8 - 5,6) = 2,3$
- $T_2 = (2,4 - 2,1) + (7,2 - 5,8) = 1,7$
- $T_3 = (8,6 - 7,2) = 1,4$
- $T_i = 0$ para $i \geq 4$, ya que la fila nunca creció hacia esos valores en esta realización.

Así,

$$\hat{q}(n) = \frac{\sum_{i=0}^{\infty} iT_i}{T(n)} = \frac{(0 \times 3,2) + (1 \times 2,3) + (2 \times 1,7) + (3 \times 1,4)}{8,6} = \frac{9,9}{8,6} = 1,15.$$

Notar que cada uno de los términos distintos de 0 en la segunda igualdad de la expresión anterior corresponden a una de las áreas sombreadas de la Figura 1.8:

- $1 \times 2,3$ es el área diagonalmente sombreada (cuatro piezas).
- $2 \times 1,7$ es el área sombreada con cruces (dos piezas).
- $3 \times 1,4$ es el área completamente sombreada (una pieza).

En otras palabras, $\sum_{i=0}^{\infty} iT_i$ es juntamente el área bajo la curva de $Q(t)$. Recordemos que el “área bajo la curva” es una integral, así

$$\sum_{i=0}^{\infty} iT_i = \int_0^{T(n)} Q(t)dt,$$

y el estimador de $q(n)$ puede ser expresado como

$$\hat{q}(n) = \frac{\int_0^{T(n)} Q(t)dt}{T(n)}.$$

Notar que:

- La utilización esperada del servidor es la proporción esperada del tiempo durante la simulación (desde 0 a $T(n)$) en que el servidor está ocupado (no disponible) y, por lo tanto, está entre 0 y 1.
- De una réplica particular, nuestra estimación de $u(n)$ es $\hat{u}(n) =$ la proporción observada de tiempo durante la simulación en que el servidor está ocupado.
- Podemos ver fácilmente esta cantidad como un promedio de tiempo continuo, similar a $q(n)$, al definir la “función de ocupación”.

$$B(t) = \begin{cases} 1 & \text{si el servidor está ocupado en el tiempo } t \\ 0 & \text{si el servidor está disponible en el tiempo } t \end{cases},$$

y, así, $\hat{u}(n)$ se puede expresar como la proporción de tiempo en que $B(t)$ es igual a 1.

La Figura 1.9 muestra $B(t)$ para la misma réplica del ejemplo utilizado para $Q(t)$.

En este caso, tenemos

$$\hat{u}(n) = \frac{(3,3 - 0,4) + (8,6 - 3,8)}{8,6} = \frac{7,7}{8,6} = 0,9.$$

Nuevamente, el numerador de la expresión de $\hat{u}(n)$ puede ser visto como el área bajo la función $B(t)$ durante el transcurso de la simulación, debido a que su altura siempre es 0 o 1. Por lo tanto,

$$\hat{u}(n) = \frac{\int_0^{T(n)} B(t)dt}{T(n)}.$$




Figura 1.9: Ejemplo de $B(t)$ para la misma réplica del ejemplo utilizado para $Q(t)$

Recapitulando, las tres medidas de rendimiento que analizaremos serán:

1. Tiempo de espera promedio de los n clientes, $\hat{d}(n)$.
2. Número promedio de clientes en la fila, $\hat{q}(n)$.
3. Utilización del servidor, $\hat{u}(n)$.

Explicación intuitiva

Comenzaremos la explicación de cómo simular un sistema M/M/1 mostrando cómo su modelo de simulación sería representado dentro de un computador en el tiempo $e_0 = 0$ y en los tiempos $e_1, e_2, \dots, e_{13}$ en los cuales ocurren los 13 eventos sucesivos que son necesarios para observar el número deseado, $n = 6$, de esperas en la fila.

Asumiremos que los tiempos entre llegadas y de atención son





$$A_1 = 0,4, A_2 = 1,2, A_3 = 0,5, A_4 = 1,7, A_5 = 0,2,$$




$$A_6 = 1,6, A_7 = 0,2, A_8 = 1,4, A_9 = 1,9 \dots$$


$$S_1 = 2,0, S_2 = 0,7, S_3 = 0,2, S_4 = 1,1, S_5 = 3,7, S_6 = 0,6 \dots$$

A continuación, veremos algunas “capturas” del sistema para los tiempos $e_0 = 0, e_1 = 0,4, \dots, e_{13} = 8,6$. Notar que:

- Los cuadrados representan el servidor y los círculos los clientes.
- Los números dentro de los círculos son los tiempos de llegada.
- Los valores de las variables que se muestran son después de que se haya completado todo el procesamiento en ese evento.







Contadores estadísticos

3

Número
en
espera

1.8

Espera
total


1.8

Área
bajo
 $Q(t)$

2.7

Área
bajo
 $B(t)$

Representación computacional



Contadores estadísticos

3

Número
en
espera

1.8

Espera
total


1.8

Área
bajo
 $Q(t)$

2.9

Área
bajo
 $B(t)$

Representación computacional



Contadores estadísticos

4

Número
en
espera

1.8

Espera
total




1.8




Área
bajo
 $Q(t)$

2.9

Área
bajo
 $B(t)$

Representación computacional





Capítulo 2

Repaso de Probabilidad y Estadística

2.1. Teoría de probabilidad

La teoría de la probabilidad comienza con tres componentes básicos. El conjunto de todos los posibles resultados (espacio muestral), Ω . Una colección de todos los conjuntos (eventos aleatorios), $\mathcal{F} \subseteq \Omega$. Y, una medida de probabilidad, $\mathbb{P}$.

La especificación del trío $(\Omega, \mathcal{F}, \mathbb{P})$ describe un espacio de probabilidad que modela una medida del mundo real. Por ejemplo:

$$\begin{aligned}\Omega &= \{\text{todos los resultados de lanzar un dado}\} \\ &= \{1, 2, 3, 4, 5, 6\}.\end{aligned}$$

$$\begin{aligned}\mathcal{F} &= \{\text{todos los posibles conjuntos de resultados}\} \\ &= \{\{1\}, \dots, \{6\}, \{1, 2\}, \dots, \{5, 6\}, \dots, \{1, 2, 3, 4, 5, 6\}\}.\end{aligned}$$

$$\mathbb{P} = \text{probabilidad de todos los conjuntos/eventos}.$$

Ejemplo 2.1. ¿Cuál es la probabilidad de $\omega \in \Omega$, e.g., $\omega = 5$? $\mathbb{P}(\omega) = 1/6$. Y, ¿de $\omega = \{1, 2, 3\}$? $\mathbb{P}(\omega) = 3/6$.

2.1.1. Medida de probabilidad

Definición 2.1 (Probabilidad). Una probabilidad es una medida de la posibilidad (*likelihood*) de que ocurra un evento. Este valor está dentro del intervalo $[0, 1]$, y $\mathbb{P}(F)$ denota el valor asignado a la probabilidad de ocurrencia del evento F

Las medidas de probabilidad deben satisfacer las siguientes propiedades (axiomas de Kolmogórov):

1. $0 \leq \mathbb{P}(F) \leq 1, \forall F \in \mathcal{F}$.
2. $\mathbb{P}(\Omega) = 1 \implies \mathbb{P}(\emptyset) = 1 - \mathbb{P}(\Omega) = 0$.
3. Para cada conjunto $F_1, F_2, \dots, F_n$ de eventos mutuamente disjuntos, i.e., conjuntos tales que $F_i \cap F_j = \emptyset$ para todo $i \neq j$, tenemos

$$\begin{aligned} \mathbb{P}\left(\bigcup_{i=1}^n F_i\right) &= \sum_{i=1}^n \mathbb{P}(F_i) \\ &= \mathbb{P}(F_1) + \mathbb{P}(F_2) + \dots + \mathbb{P}(F_n). \end{aligned}$$

Algunas propiedades básicas de las medidas de probabilidad son las siguientes:

- Probabilidad del complemento: sea F^c el complemento del evento F . Tenemos

$$\mathbb{P}(F) = 1 - \mathbb{P}(F^c).$$

- Probabilidad del conjunto vacío: notar que $\emptyset = \Omega^c$. Por tanto,

$$\mathbb{P}(\emptyset) = 1 - \mathbb{P}(\Omega) = 0.$$

- Probabilidad de la unión entre A y B :

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Si A y B son eventos mutuamente disjuntos tenemos

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

2.1.2. Probabilidad condicional

Consideremos dos eventos $A, B \in \mathcal{F}$. La probabilidad (condicional) de que ocurra A dado que B ocurre es

$$\mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Ejemplo 2.2. Sean $\Omega = \{1, 2, 3, 4, 5, 6\}$, $A = \{2, 3\}$, $B = \{3, 4\}$.

Recordar que decimos que A “ocurre” si el resultado es 2 o 3.

Ahora, suponer que se sabe que B ocurre. Entonces, parece más probable que A también haya ocurrido.

La probabilidad de que A ocurra, sin conocimiento de si B ha ocurrido, es $1/3$. Esto es $\mathbb{P}(A) = 1/3$. De la ecuación de arriba es fácil notar que

$$\mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\{3\}}{\{3, 4\}} = \frac{1/6}{1/3} = \frac{1}{2}.$$

Por lo tanto, vemos que el conocimiento de B provee información importante acerca de A .

2.1.3. Independencia

Se dice que dos eventos A y B son independientes si $\mathbb{P}(A|B) = \mathbb{P}(A)$. En otras palabras, B no provee información sobre si ha ocurrido A .

Ejemplo 2.3. Suponer que tenemos dos dados. Luego,

$$\begin{aligned} \Omega &= \{\text{todos los pares de resultados de lanzar dos dados}\} \\ &= \{(1, 1), (1, 2), \dots, (6, 6)\}. \end{aligned}$$

Sea $A = \{1^{\text{er}} \text{ dado es } 1\}$ y $B = \{2^{\text{do}} \text{ dado es } 1\}$. Luego,

$$\mathbb{P}(A|B) = \frac{\{(1, 1)\}}{\{1\}} = \frac{1/36}{1/6} = \frac{1}{6}.$$

Como sabemos, el valor de un dado no influencia al otro. Los dos resultados son independientes.

2.1.4. Ley de probabilidad total

Sean $F_1, F_2, \dots, F_n$ eventos mutuamente disjuntos para los cuales

$$\Omega = \bigcup_{i=1}^n F_i = F_1 \cup F_2 \cup \dots \cup F_n.$$

Luego, para cualquier conjunto E , lo siguiente es verdad

$$\mathbb{P}(E) = \sum_{i=1}^n \mathbb{P}(E \cap F_i) = \sum_{i=1}^n \mathbb{P}(E|F_i) \cdot \mathbb{P}(F_i).$$

2.1.5. Regla de Bayes

De nuevo, considerar dos eventos A y B . Recordar la probabilidad condicional $\mathbb{P}(A|B)$. La regla de Bayes es una fórmula para la probabilidad condicional “inversa”, $\mathbb{P}(B|A)$. La regla de Bayes es

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B)\mathbb{P}(B)}{\mathbb{P}(A)}.$$

Esto es fácil de verificar al recordar la definición de la probabilidad condicional. Previamente, teníamos $\mathbb{P}(A|B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$. Reordenando A y B , tenemos $\mathbb{P}(B|A) = \mathbb{P}(B \cap A)/\mathbb{P}(A)$. Notar que $\mathbb{P}(A \cap B) = \mathbb{P}(B \cap A)$. Por lo tanto,

$$\begin{aligned} \mathbb{P}(A|B) &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \\ &= \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(B)} \\ &= \frac{\mathbb{P}(B|A)\mathbb{P}(A)}{\mathbb{P}(B)}. \end{aligned}$$

Recordar la regla de Bayes (alternativamente, ley de Bayes o teorema de Bayes)

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(B|A)\mathbb{P}(A)}{\mathbb{P}(B)}.$$

Específicamente, los conceptos comprendidos aquí son los siguientes:

- *Posterior*: probabilidad de que A ocurra, dado que B ocurrió, $\mathbb{P}(A|B)$.
- *Likelihood*: probabilidad de que B ocurra, dado que A ocurrió, $\mathbb{P}(B|A)$.

- *Prior*: probabilidad de que A ocurra, $\mathbb{P}(A)$. Esto es el conocimiento previo.
- *Marginal*: probabilidad de que B ocurra, $\mathbb{P}(B)$.

La regla de Bayes también se puede definir como

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A, B)}{\mathbb{P}(B)},$$

dado que $\mathbb{P}(A, B) = \mathbb{P}(A \cap B) = \mathbb{P}(B \cap A) = \mathbb{P}(B|A)\mathbb{P}(A)$, donde $\mathbb{P}(A, B)$ es la distribución conjunta (*joint distribution*) y $\mathbb{P}(B)$ la distribución marginal (*marginal distribution*).

Ejemplo 2.4. Ciertos genetistas han determinado que un defecto genético (def) particular está relacionado con cierta enfermedad (enf). Muchas personas con la enfermedad también tienen este defecto, pero hay personas libres de enfermedad con el defecto. Los genetistas han encontrado que el 0.01 % de la población general tiene la enfermedad y que el defecto está presente en el 50 % de estos casos. También, saben que 0.1 % de la población tiene el defecto.

¿Cuál es la probabilidad de que una persona con el defecto tenga la enfermedad?

$$\mathbb{P}(\text{enf}|\text{def}) = \frac{\mathbb{P}(\text{def}|\text{enf})\mathbb{P}(\text{enf})}{\mathbb{P}(\text{def})} = \frac{0,5 \times 0,0001}{0,001} = 0,05.$$

2.2. Estadística descriptiva

La estadística descriptiva es la disciplina que cuantitativamente describe las principales características de una colección de datos. Se distingue de la inferencia estadística en que la estadística descriptiva busca resumir una muestra, en vez de usar estos datos para aprender acerca de la población. La inferencia estadística es el proceso de establecer conclusiones de datos sujetos a variaciones inciertas. En base a lo anterior, y a diferencia de la inferencia estadística, la estadística descriptiva no está desarrollada en base a la teoría de probabilidad.

Los tipos de datos de la estadística corresponden a (Figura 2.1):

- Continuos: datos que pueden tomar cualquier valor dentro de un rango ($x \in [0, 1]$).

- Discretos: datos que sólo pueden tomar ciertos valores dentro de un rango ($x \in \{0, 1\}$).
- Nominales: datos que tienen dos o más categorías, pero no hay un orden intrínseco ($x \in \{\text{hombre, mujer}\}$).
- Ordinales: datos que pueden tomar dos o más categorías, pero sí hay un orden claro ($x \in \{\text{bajo, medio, alto}\}$).




Figura 2.1: Tipos de datos en la estadística descriptiva

2.2.1. Medidas de tendencia central

Dentro de la estadística, existen las medidas de tendencia central, que buscan resumir un conjunto de valores a partir de un único valor (central). Suponer el conjunto de datos $\mathbf{d} = \{65, 55, 60, 65, 75, 85, 65\}$. Algunas medidas de tendencia central son:

- Media: corresponde a sumar todos los miembros y dividir por la cantidad de números ahí dentro. En particular,

$$\bar{d} = \frac{\sum_{i=1}^{|\mathbf{d}|} d_i}{|\mathbf{d}|} = \frac{65 + 55 + 60 + 65 + 75 + 85 + 65}{7} = 67,14.$$

- Mediana: es el número del medio. Se encuentra ordenando los números y tomando el valor del medio si es que hay uno, si no el promedio de los dos números del medio. En particular, $\hat{\mathbf{d}}_{0,5} = 65$.
- Moda: corresponde al número más frecuente. En particular, la moda de $\mathbf{d}$ es 65.

2.2.2. Medidas de dispersión

Así como existen medidas de tendencia central, también existen medidas de dispersión. Estas últimas buscan determinar el grado de variabilidad de un conjunto de datos $\mathbf{x}$. Algunas de ellas son:

- Varianza: corresponde a la media de la distancia cuadrada desde la media muestral, i.e.,

$$\sigma_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

- Desviación estándar: es la raíz cuadrada de la varianza, y tiene la propiedad de poseer la misma unidad de medida que los datos. La desviación estándar se calcula como

$$\sigma_x = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

- Rango: es la distancia entre el valor máximo y el mínimo, i.e., $\text{rango}(\mathbf{x}) = \mathbf{x}_{\text{máx}} - \mathbf{x}_{\text{mín}}$.

2.2.3. Medidas de dependencia

También, existen las medidas de dependencia, que buscan comprender la relación que existe entre dos o más variables. Las más comunes son:

- Covarianza: es la medida de la variabilidad conjunta de dos variables X e Y . Si los mayores (menores) valores de X corresponden principalmente con los más mayores (menores) de Y , la covarianza es positiva. En cambio, cuando los mayores (menores) valores de X corresponden principalmente con los menores (mayores) de Y , la covarianza es negativa. Para dos variables X e Y , la covarianza es

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

- Correlación: es cualquier relación estadística, sea causal o no, entre dos variables. En un sentido amplio, correlación es cualquier asociación estadística, aunque comúnmente se refiere al grado en que un par de variables están linealmente relacionadas. Para dos variables X e Y , ésta se define como

$$\rho_{X,Y} = \text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]}{\sigma_X \sigma_Y},$$

con $\rho_{X,Y} \in [-1, 1]$. Se dice que X e Y no están correlacionadas si $\rho_{X,Y} = 0$. $\rho_{X,Y} = 1$ indica correlación directa perfecta, y $\rho_{X,Y} = -1$ correlación inversa perfecta.

2.3. Variables aleatorias

Definición 2.2 (Variable aleatoria). Una variable aleatoria X es una función $X : \Omega \rightarrow \mathbb{R}$ que asocia un valor (número) a cada posible resultado. Puede tomar valores discretos o continuos.

Definición 2.3 (Variable aleatoria discreta). Una variable aleatoria X es discreta si el conjunto de todos los posibles valores de X (es decir, el rango de la función representada por X), denotado $\mathbb{X}$, es contable. O sea, $\mathbb{X} = \{x_1, x_2, \dots, x_n\}$ (finito) o $\mathbb{X} = \{x_1, x_2, \dots\}$ (infinito).

Definición 2.4 (Variable aleatoria continua). Una variable aleatoria X es continua si la función F_X definida en $\mathbb{R}$ por

$$F_X(x) = \mathbb{P}[X \leq x]$$

para $x \in \mathbb{R}$ es una función continua en $\mathbb{R}$. Esto es, para $x \in \mathbb{R}$

$$\lim_{h \rightarrow 0} F_X(x + h) = F_X(x).$$

2.3.1. Función de masa de probabilidad

La función f_X definida en $\mathbb{X}$ por

$$f_X(x) = \mathbb{P}(X = x), \quad x \in \mathbb{X}$$

que asigna probabilidad a cada $x \in \mathbb{X}$ es la función de masa de probabilidad (discreta) o pmf. Por completitud, definimos

$$f_X(x) = 0, \quad x \notin \mathbb{X}$$

tal que f_X está definida para todo $x \in \mathbb{R}$. Además, nos referiremos a $\mathbb{X}$ como el soporte de la variable aleatoria X . Esto es, el conjunto de $x \in \mathbb{R}$ tal que $f_X(x) > 0$.

Observación 2.1 (Propiedades de la función de masa). Una función f_X es una función de masa de probabilidad para una variable aleatoria discreta X con rango $\mathbb{X}$ de la forma $\{x_1, x_2, \dots\}$ si y sólo si

$$(i) f_X(x_i) \geq 0 \quad \forall i : x_i \in \mathbb{X}, \quad (ii) \sum_{i: x_i \in \mathbb{X}} f_X(x_i) = 1.$$

2.3.2. Función de distribución acumulada discreta

La función de distribución acumulada, o cdf, F_X , de una variable aleatoria discreta X está definida por

$$F_X(x) = \mathbb{P}(X \leq x), \quad \forall x \in \mathbb{R}.$$

Por tanto, $F_X(x)$ es la probabilidad de que, al realizar un experimento, la variable aleatoria X haya tomado un valor no mayor que el número x . Una cdf $F_X(x)$ tiene las siguientes propiedades:

1. $0 \leq F_X(x) \leq 1$ para todo x .
2. $F_X(x)$ es no-decreciente, i.e., si $x_1 < x_2$, entonces $F_X(x_1) \leq F_X(x_2)$.
3. $\lim_{x \rightarrow \infty} F_X(x) = 1$ y $\lim_{x \rightarrow -\infty} F_X(x) = 0$ (pues, X sólo toma valores finitos).

2.3.3. Conexión entre pmf y cdf

Sea X una variable aleatoria discreta con rango $\mathbb{X} = \{x_1, x_2, \dots\}$, donde $x_1 < x_2 < \dots$, y las pmf y cdf f_X y F_X . Por tanto, para cualquier valor real x , si $x < x_1$, entonces $F_X(x) = 0$, y para $x \geq x_1$,

$$F_X(x) = \sum_{x_i \leq x} f_X(x_i) \iff f_X(x_i) = F_X(x_i) - F_X(x_{i-1}) \quad \forall i \in \{2, 3, \dots\},$$

con, por completitud, $f_X(x_1) = F_X(x_1)$. La Figura 2.2 presenta la pmf de una variable aleatoria arbitraria (izquierda) y su correspondiente cdf (derecha).




Figura 2.2: Conexión entre pmf y cdf

2.3.4. Funciones de variables aleatorias continuas

Definición 2.5 (Función de distribución acumulada). La función de distribución acumulada, o cdf, F_X de una variable aleatoria continua X está definida por

$$F_X(x) = \mathbb{P}(X \leq x), \quad x \in \mathbb{R}.$$

Definición 2.6 (Función de densidad de probabilidad). Una variable aleatoria es absolutamente continua si la cdf F_X puede ser

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

para alguna función f_X , llamada función de densidad de probabilidad, o pdf, de X .

Observación 2.2. Desde ahora, cuando hablemos de una variable aleatoria continua, implícitamente asumiremos el caso absolutamente continuo, donde existe una pdf.

Por analogía con el caso discreto, sea $\mathbb{X}$ el rango de X , tal que $\mathbb{X} = \{x : f_X(x) > 0\}$:

1. Para la cdf de una variable aleatoria continua

$$\lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow \infty} F_X(x) = 1.$$

2. Directamente desde la definición, en valores de x donde F_X es diferenciable,

$$f_X(x) = \frac{d}{dt} \{F_X(t)\}_{t=x}.$$

3. Si X es continua,

$$\begin{aligned} f_X(x) &\neq \mathbb{P}(X = x) = \lim_{h \rightarrow 0^+} [\mathbb{P}(X \leq x) - \mathbb{P}(X \leq x - h)] \\ &= \lim_{h \rightarrow 0^+} [F_X(x) - F_X(x - h)] \\ &= 0. \end{aligned}$$

4. Para $a < b$

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= \mathbb{P}(a \leq X < b) = \mathbb{P}(a \leq X \leq b) \\ &= \mathbb{P}(a < X < b) \\ &= F_X(b) - F_X(a). \end{aligned}$$

Así, una función f_X es una pdf para la variable aleatoria continua X si y sólo si

$$(i) f_X(x) \geq 0, \quad (ii) \int_{-\infty}^{\infty} f_X(x) dx = 1.$$

La Figura 2.3 presenta la pdf de una variable aleatoria arbitraria (izquierda) y su correspondiente cdf (derecha).




Figura 2.3: Conexión entre pdf y cdf

2.3.5. Esperanza de una variable aleatoria

Definición 2.7 (Caso discreto). Para una variable aleatoria discreta X con rango $\mathbb{X}$ y pmf f_X , la esperanza o valor esperado de X con respecto a f_X es

$$\mathbb{E}_{f_X}[X] = \mu_X = \sum_{x=-\infty}^{\infty} x f_X(x) = \sum_{x \in \mathbb{X}} x f_X(x).$$

De manera más general,

$$\mathbb{E}_{f_X}[g(X)] = \sum_{x \in \mathbb{X}} g(x) f_X(x).$$

Definición 2.8 (Caso continuo). Para una variable aleatoria continua X con rango $\mathbb{X}$ y pdf f_X , la esperanza o valor esperado de X con respecto a f_X es

$$\mathbb{E}_{f_X}[X] = \mu_X = \int_{-\infty}^{\infty} x f_X(x) dx = \int_{\mathbb{X}} x f_X(x) dx.$$

De manera más general,

$$\mathbb{E}_{f_X}[g(X)] = \int_{x \in \mathbb{X}} g(x) f_X(x) dx.$$

2.3.6. Varianza de una variable aleatoria

Definición 2.9 (Caso discreto). Sea X una variable aleatoria discreta con pmf f_X , valor esperado μ_X y rango $\mathbb{X}$. La varianza de X es

$$\sigma_X^2 = \mathbb{V}_{f_X}[X] = \sum_{x \in \mathbb{X}} (x - \mu_X)^2 f_X(x) = \mathbb{E}_{f_X}[(X - \mu_X)^2].$$

Definición 2.10 (Caso continuo). La varianza de una variable aleatoria continua X con pdf f_X , valor esperado μ_X y rango $\mathbb{X}$ es

$$\sigma_X^2 = \mathbb{V}_{f_X}[X] = \int_{-\infty}^{\infty} (x - \mu_X)^2 f_X(x) dx = \mathbb{E}_{f_X}[(X - \mu_X)^2].$$

2.3.7. Variables aleatorias discretas: ejemplos

Ejemplo 2.5 (Distribución Bernoulli). Es una distribución de probabilidad discreta de una variable aleatoria que toma el valor 1 con probabilidad p y el valor 0 con probabilidad $q = 1 - p$. Menos formalmente, se puede considerar como un modelo para el conjunto de posibles resultados de un único experimento que hace una pregunta de “sí” o “no”.

Su pmf, sobre posibles resultados x , es

$$f_X(x|p) = f(x) = p^x(1-p)^{1-x} \quad \forall x \in \{0, 1\}.$$

Su primer y segundo momento corresponden a $\mathbb{E}[X] = p$ y $\mathbb{V}[X] = pq$, respectivamente.

Ejemplo 2.6 (Distribución binomial). Dada una secuencia Bernoulli, si n experimentos con probabilidad de éxito p son realizados, entonces la probabilidad de que exactamente x éxitos ocurran está representada por la distribución binomial

$$f_X(x|n, p) = f(x) = \binom{n}{x} p^x (1-p)^{n-x} \quad \forall x = \{0, 1, \dots, n\}.$$

Su primer y segundo momento corresponden a $\mathbb{E}[X] = np$ y $\mathbb{V}[X] = np(1-p)$, respectivamente.

Ejemplo 2.7 (Distribución geométrica). Dada una secuencia Bernoulli, el número de experimentos hasta la ocurrencia del primer evento exitoso (cada uno con probabilidad de éxito p) sigue una distribución geométrica. Si el primer éxito ocurre en el x -ésimo experimento, los primeros $x - 1$ experimentos fueron fracasos. Si X es la variable aleatoria que representa el número de experimentos hasta el primer éxito, entonces

$$f_X(x|p) = f(x) = p(1-p)^{x-1} \quad \forall x = \{1, 2, \dots\}.$$

Su primer y segundo momento corresponden a $\mathbb{E}[X] = \frac{1}{p}$ y $\mathbb{V}[X] = \frac{(1-p)}{p^2}$, respectivamente.

Ejemplo 2.8 (Distribución de Poisson). La distribución de Poisson es popular para modelar el número de veces que un evento ocurre en un intervalo de tiempo o espacio. Se dice que una variable aleatoria discreta X tiene una distribución de Poisson con parámetro $\lambda > 0$ si la función de masa de probabilidad de X está dada por

$$f_X(x|\lambda) = f(x) = \frac{e^{-\lambda} \lambda^x}{x!} \quad \forall x = \{0, 1, 2, \dots\}.$$

Su primer y segundo momento corresponden a $\mathbb{E}[X] = \lambda$ y $\mathbb{V}[X] = \lambda$, respectivamente.

2.3.8. Variables aleatorias continuas: ejemplos

Ejemplo 2.9 (Distribución exponencial). En un proceso de Poisson, el tiempo transcurrido entre la ocurrencia de dos eventos puede ser descrito a través de la distribución exponencial. Una variable aleatoria X de este tipo, con parámetro (tasa) $\lambda > 0$ tiene una función de densidad

$$f_X(x|\lambda) = f(x) = \begin{cases} e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}.$$

Su primer y segundo momento corresponden a $\mathbb{E}[X] = \frac{1}{\lambda}$ y $\mathbb{V}[X] = \frac{1}{\lambda^2}$, respectivamente.

Ejemplo 2.10 (Distribución uniforme). Esta distribución de probabilidad es utilizada para describir el fenómeno donde todos los posibles valores que la variable aleatoria puede tomar poseen igual probabilidad de ocurrencia. Suponer que una variable X puede tomar cualquier valor en el intervalo $[a, b]$. Luego, su comportamiento es directamente descrito por

$$f_X(x|a, b) = f(x) = \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & x < a \text{ o } x > b \end{cases}.$$

Su primer y segundo momento corresponden a $\mathbb{E}[X] = \frac{a+b}{2}$ y $\mathbb{V}[X] = \frac{(b-a)^2}{12}$, respectivamente.

Ejemplo 2.11 (Distribución normal). En estadística y probabilidad la distribución normal o gaussiana es una de las distribuciones de probabilidad más utilizadas porque aparece en varios fenómenos reales. La función de densidad de una variable aleatoria normal X con media $-\infty < \mu < \infty$ y desviación estándar $-\infty < \sigma < \infty$ es

$$f_X(x|\mu, \sigma) = f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad -\infty < x < \infty.$$

Su primer y segundo momento corresponden a $\mathbb{E}[X] = \mu$ y $\mathbb{V}[X] = \sigma^2$, respectivamente.

2.4. Inferencia estadística

2.4.1. Población y muestra

Supongamos que estamos interesados en la distribución de edades en Chile. Los residentes chilenos son la población; el parámetro μ es la edad promedio verdadera de los residentes chilenos, y σ^2 es la varianza verdadera.

Si fuéramos a medir la edad de todos los residentes chilenos deberíamos realizar un censo. Sin embargo, medir la edad de cada individuo es difícilmente factible, o sólo posible a un costo exorbitante. En cambio, podemos seleccionar aleatoriamente una muestra de la población y hacer inferencias sobre tal muestra.

En particular, podemos usar las estadísticas muestrales (e.g., media y varianza muestral) para hacer inferencias sobre los verdaderos, pero desconocidos, parámetros poblacionales (μ y σ^2). Aleatoriamente, seleccionamos una muestra de la población chilena y medimos la edad de los individuos en la muestra.

Definición 2.11 (Muestra aleatoria simple). Se da una muestra aleatoria si cada individuo de la población tiene la misma oportunidad de ser elegido.

Dado que las muestras son aleatorias, las edades del primero, segundo, tercero, $\dots$, y del n -ésimo individuo elegido también son aleatorias. Es decir, $x_1, x_2, \dots, x_n$ son variables aleatorias.

Definición 2.12 (Variables independiente e idénticamente distribuidas (iid)). Suponer que obtenemos aleatoriamente n elementos $(x_1, x_2, \dots, x_n)$ de la misma población. Dado que $x_1, x_2, \dots, x_n$ son obtenidas de los mismos residentes, ellos son idénticamente distribuidos. Además, debido a que la distribución de x_i no depende de la distribución de x_j para $i, j = 1, \dots, n$ tal que $i \neq j$, podemos decir que son independientemente distribuidos. Decimos que $x_1, x_2, \dots, x_n$ son iid.

Supongamos que obtenemos las siguientes edades ($n = 10$, en años):

$$\mathbf{x} = \{28, 33, 42, 56, 25, 27, 48, 67, 81, 13\}.$$

Dada esta muestra, ¿cuál es nuestra mejor suposición acerca de μ ? Simplemente la media muestral:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{10} (28 + \dots + 13) = 42.$$

La media muestral es un estimador insesgado (*unbiased*) y consistente (*consistent*) de la media poblacional desconocida μ .

Definición 2.13 (Estimador insesgado). Para entender qué es un estimador insesgado, notar que la distribución muestral de $\bar{x}$ está centrada en μ . Cuando muestreamos repetidamente, a veces $\bar{x}$ está por sobre el valor real del parámetro μ y otras veces por debajo de éste. Sin embargo, el aspecto clave es que no hay una tendencia sistemática a sobrestimar o subestimar el parámetro verdadero. Esto hace que $\bar{x}$ sea un estimador insesgado de μ .

Definición 2.14 (Estimador consistente). Un estimador es consistente si, en la medida que aumenta el tamaño de la muestra, el estimador se acerca cada vez más al verdadero valor del parámetro.

El estimador muestral $\bar{x}$ es una función de $x_1, \dots, x_n$,

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Por lo tanto, es una variable aleatoria, donde la media muestral de nuestra

muestra, $\bar{x} = 42$, es una realización.

Observación 2.3. Un estimador es una función de variables aleatorias que representan extracciones de una población. Por lo tanto, el estimador es una variable aleatoria. El estimador funciona como un método para “suponer” parámetros de una población. Una estimación es el valor numérico que se obtiene a partir de una muestra específica. Una estimación no es una variable aleatoria, es sólo un número.

Como cualquier variable aleatoria, $\bar{x}$ sigue una distribución. ¿Cómo es esta distribución? Para responderlo, consideraremos uno de los teoremas más importantes en estadística, el teorema del límite central (CLT, en inglés), pero antes debemos discutir acerca de la ley de los grandes números.

2.4.2. Ley de los grandes números

Aunque $\bar{x}$ es poco probable que sea exactamente correcto y varía de muestra en muestra, sigue siendo un estimador razonable de μ (de hecho, el mejor). Esto se debe a que está garantizado que se acerca cada vez más al parámetro poblacional μ en la medida que aumenta el tamaño muestral (consistencia). Por lo tanto, sabemos que si pudiéramos seguir tomando mediciones, eventualmente estimaríamos la verdadera media poblacional con mucha precisión. Este hecho es usualmente conocido como la ley de los grandes números. Es un hecho notable, pues vale para cualquier población.

Definición 2.15 (Ley de los grandes números - *Law of large numbers* (LLN)). Si extraemos aleatoriamente observaciones independientes de cualquier población con media finita μ , la media muestral, $\bar{x}$, de los valores observados se acerca a la media verdadera de la población, μ , cuando $n \rightarrow \infty$. Esto significa que $\bar{x} \rightarrow \mu$ cuando $n \rightarrow \infty$.

Suponer que extraemos $N = 5000$ muestras de $X \sim \mathcal{N}(\mu, \sigma^2)$, con $\mu = 100$ y $\sigma = 5$. Veamos la ley de los grandes números en acción a través de la Figura 2.4. En ella es posible ver que la estimación es consistente pues, a medida que aumenta el número de observaciones, la media de las observaciones tiende al valor buscado ($\mu = 100$). Por otra parte, no se

evidencia una tendencia sistemática a sobrestimar o subestimar el valor buscado, pues la media a veces está por sobre y a veces por debajo de éste.




Figura 2.4: Aplicación de la ley de los grandes números

2.4.3. Teorema del límite central

Introduciremos el teorema del límite central simulando. Asumamos que $X \sim U(80, 120)$. Procedemos de la siguiente forma:

1. Extraemos $n = 50$ observaciones $(x_1, \dots, x_{50})$ de nuestra “población” (nuestra distribución uniforme).
2. Obtenemos y escribimos la media muestral (i.e., $\bar{x}$).
3. Repetimos el paso (1) y (2) 100 000 veces.

Esto nos da 100 000 medias muestrales $(\bar{x}^{(1)}, \bar{x}^{(2)}, \dots, \bar{x}^{(100\,000)})$. Este gran conjunto de medias muestrales debería darnos una idea de cómo se ve la distribución teórica de $\bar{x}$. La Figura 2.5 presenta el histograma formado a partir de las primeras 100, 1000, 5000 y 100 000 medias muestrales. Es interesante notar que la media muestral de $\bar{x}^{(1)}, \bar{x}^{(2)}, \dots, \bar{x}^{(100\,000)}$ es 100,002 y la desviación estándar es 0,708. Además, en la medida que aumenta la cantidad de observaciones (medias muestrales), el histograma tiende a parecerse al de una distribución normal.

Si $\bar{x}$ es la media de una muestra de tamaño n , que es extraída aleatoriamente de una muestra grande de media μ y desviación estándar σ , entonces la media de la distribución muestral de $\bar{x}$ es μ y su desviación estándar es $\frac{\sigma}{\sqrt{n}}$. Más formalmente, el teorema del límite central puede ser descrito de la siguiente manera.




Figura 2.5: Histograma formado a partir de distintas cantidades de medias muestrales

Definición 2.16 (Teorema del límite central). Suponer que se extraen n números aleatorios de una distribución arbitraria (discreta o continua) con media μ y varianza σ^2 . Si n es suficientemente grande, entonces

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

donde $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.

2.4.4. Breve profundización: valor esperado de la media muestral

Teorema 2.1 (Linealidad de la esperanza). Para las variables aleatorias X e Y (que pueden ser dependientes),

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

Más general, para las variables aleatorias $X_1, X_2, \dots, X_n$ y constantes $c_1, c_2, \dots, c_n$

$$\mathbb{E}\left[\sum_{i=1}^n c_i X_i\right] = \sum_{i=1}^n (c_i \mathbb{E}[X_i]).$$

En base a la linealidad de la esperanza, tenemos

$$\begin{aligned}\mathbb{E}[\bar{X}] &= \mathbb{E}\left[\sum_{i=1}^n \frac{1}{n} X_i\right] = \mathbb{E}\left[\frac{1}{n} X_1\right] + \mathbb{E}\left[\frac{1}{n} X_2\right] + \cdots + \mathbb{E}\left[\frac{1}{n} X_n\right] \\ &= \frac{1}{n} \mathbb{E}[X_1] + \frac{1}{n} \mathbb{E}[X_2] + \cdots + \frac{1}{n} \mathbb{E}[X_n] \\ &= \frac{1}{n} \mu + \frac{1}{n} \mu + \cdots + \frac{1}{n} \mu = \mu.\end{aligned}$$

2.4.5. Breve profundización: varianza de la media muestral

En el caso de la varianza muestral, tenemos:

$$\begin{aligned}\mathbb{V}[\bar{X}] &= \mathbb{V}\left[\sum_{i=1}^n \frac{1}{n} X_i\right] = \mathbb{V}\left[\frac{1}{n} X_1 + \frac{1}{n} X_2 + \cdots + \frac{1}{n} X_n\right] \\ &= \frac{1}{n^2} \mathbb{V}[X_1] + \frac{1}{n^2} \mathbb{V}[X_2] + \cdots + \frac{1}{n^2} \mathbb{V}[X_n] \\ &= \frac{1}{n^2} \sigma^2 + \frac{1}{n^2} \sigma^2 + \cdots + \frac{1}{n^2} \sigma^2 \\ &= \frac{n}{n^2} \sigma^2 = \frac{1}{n} \sigma^2.\end{aligned}$$

Este resultado indica que la varianza muestral decrece cuando el tamaño muestral aumenta.

Observación 2.4 (Algunas propiedades de la varianza). Sean X e Y dos variables aleatorias con varianza finita y $a \in \mathbb{R}$

$$\begin{aligned}\mathbb{V}[X] &\geq 0, \quad \mathbb{V}[a] = 0, \quad \mathbb{V}[aX] = a^2 \mathbb{V}[X], \\ \mathbb{V}[X + Y] &= \mathbb{V}[X] + \mathbb{V}[Y] + 2\text{Cov}(X, Y).\end{aligned}$$

2.4.6. Intervalos de confianza

Considerar el siguiente diagrama (Figura 2.6), donde se indica que el 95 % de los valores de un conjunto de datos tiende a estar dentro de 2 desviaciones estándar (DS) de la media (para variables normalmente distribuidas).

Podemos utilizar la observación anterior para hacer inferencia estadística:

- Como se discutió anteriormente, la media muestral $\bar{x}$ es un estimador apropiado para la desconocida media poblacional μ debido a que es insesgado y consistente.




Figura 2.6: Intervalos de confianza para distribución normal

- También hemos comentado, sin embargo, que este estimador varía de muestra en muestra. Entonces, ¿cuán confiable es este estimador? Para responder esta pregunta también necesitamos considerar la variabilidad. Del CLT sabemos que si la media poblacional es μ y la desviación estándar σ , entonces varias muestras de n observaciones deberían producir una media muestral $\bar{x}$ con $\bar{X} \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$.

Definición 2.17 (Intervalo de confianza). Un intervalo de confianza (IC) con nivel de confianza C posee dos partes:

1. Un intervalo obtenido de los datos en la forma estimación $\pm$ margen de error.
2. Un nivel de confianza elegido, C , que entrega la probabilidad de que el intervalo calculado contenga el valor verdadero del parámetro.

Uno de los valores más populares para C es 95 %, lo que lleva a un intervalo de confianza del 95 % (lo que significa que hay un 95 % de probabilidad de que el parámetro poblacional real se encuentre dentro de ese IC).

Observación 2.5 (Intervalo de confianza al $100(1 - \alpha)\%$). Para tener un IC de $100(1 - \alpha)\%$ para una media poblacional (μ), simplemente necesitamos tener:

$$\bar{x} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}},$$

donde $z_{1-\alpha/2}$ es el valor crítico con área $100(1 - \alpha)$ entre $-z_{1-\alpha/2}$ y $z_{1-\alpha/2}$ bajo la curva normal estándar. La parte derecha de la expresión es conocida como margen de error.

Ejemplo 2.12. A una muestra de 50 estudiantes de una universidad se les preguntó cuántos años llevaban estudiando en la universidad. La muestra llevó a una media de 3,2 y una desviación estándar de 1,74. Estimar el verdadero promedio de años de estudio usando esta muestra.

El intervalo de confianza al 95 % se define como

$$\begin{aligned} \text{IC} &= \bar{x} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \\ &= 3,2 \pm 1,96 \cdot \frac{1,74}{\sqrt{50}} \\ &= (3,2 - 0,48; 3,2 + 0,48) \\ &= (2,72; 3,68) \end{aligned}$$

Estamos 95 % seguros de que los estudiantes de la universidad en promedio han estado estudiando en la universidad entre 2,72 y 3,68 años.

2.4.7. Pruebas de hipótesis

Comenzamos definiendo una hipótesis nula (H_0) que representa el *status quo*. Desarrollamos una hipótesis alternativa (H_a) que representa nuestra pregunta de investigación (qué estamos intentando probar). Realizaremos una prueba de hipótesis bajo el supuesto de que la hipótesis nula es verdadera, a través de simulación o métodos teóricos. Si los resultados sugieren que los datos no proveen evidencia convincente para la hipótesis alternativa, nos quedamos con la hipótesis nula. Si lo hacen, entonces rechazamos la hipótesis nula a favor de la alternativa.

Introduciremos formalmente el marco de prueba de hipótesis usando un ejemplo sobre la prueba de una afirmación acerca de la media de una

población.

Ejemplo 2.13. En el 2010 el PPA (promedio ponderado acumulado) promedio de los estudiantes de una universidad fue de 5,73. El semestre pasado, los estudiantes del curso de Simulación de Sistemas de la universidad fueron encuestados y se les preguntó su actual PPA. Esta encuesta tuvo 147 participantes y entregó un PPA promedio de 6,05 con una desviación estándar de 1,2. Asumiendo que esta muestra es aleatoria y representativa de todos los alumnos de la UNAB, ¿estos datos proveen evidencia convincente de que el PPA promedio de los alumnos de la UNAB ha cambiado (aumentado o disminuido) en el último tiempo?

En el Ejemplo 2.13:

- El parámetro de interés es el PPA promedio de los actuales alumnos de la universidad.
- Pueden existir dos explicaciones sobre por qué nuestra media muestral es mayor que el PPA promedio del 2010:
 - La verdadera media poblacional ha cambiado (aumentado o disminuido).
 - La verdadera media poblacional se mantuvo en 5,73, y la diferencia entre la verdadera media poblacional y la muestral es simplemente debido a la variabilidad natural del muestreo.
- Comenzaremos con el supuesto de que nada ha cambiado. Es decir,

$$H_0 : \mu = 5,73.$$

- Probamos la afirmación de que el PPA promedio ha cambiado. Es decir,

$$H_a : \mu \neq 5,73.$$

Nos gustaría tomar una decisión sobre si creemos que H_0 o H_a es correcta, para hacerlo de forma cuantitativa calculamos lo que se conoce como p -value. El p -value es la probabilidad de observar datos al menos tan favorables a la hipótesis alternativa como nuestro conjunto de datos actual, si la hipótesis nula fuera verdadera. Aquí, consideramos que:

- Si el p -value es bajo (menor al nivel de significancia, α , que usualmente es 5 %) decimos que sería muy poco probable observar los datos si la hipótesis nula fuera verdadera y, por tanto, rechazamos H_0 .
- Si el p -value es alto (mayor que α) decimos que es probable observar los datos incluso si la hipótesis nula fuera verdadera y, por tanto, no rechazamos H_0 .
- Nunca aceptamos H_0 , ya que no nos interesa probarlo. Simplemente queremos saber si los datos proveen evidencia convincente en contra de H_0 .

Para realizar inferencia a partir de este conjunto de datos, necesitamos usar el CLT y, luego, debemos asegurarnos de que las condiciones necesarias son satisfechas:

1. Independencia:

- Ya hemos asumido que la muestra es aleatoria.
- $147 < 10\%$ de los actuales alumnos universidad (no hay sobrerrepresentatividad).

Por lo tanto, estamos seguros asumiendo que el PPA de un estudiante en esta muestra es independiente de los otros.

2. Tamaño muestral / oblicuidad (*skewness*): la distribución aparece ligeramente torcida (pero no extremadamente) y $n > 30$, por lo que podemos asumir que la distribución de las medias muestrales es casi normal. La Figura 2.7 presenta el histograma y el *boxplot* de dos casos: una distribución torcida (gráficos inferiores) y una no torcida (gráficos superiores).

Volvamos con nuestro p -value. Recordemos que este representa la probabilidad de observar datos al menos tan favorables para H_a como nuestro actual conjunto de datos (una media muestral mayor que 6,05 o menor que 5,41)¹ si, de hecho, H_0 fuera verdadera (la verdadera media poblacional era 5,73). Tenemos:

$$\begin{aligned} & \mathbb{P}(\bar{x} > 6,05 \text{ ó } \bar{x} < 5,41 | \mu = 5,73) \\ &= \mathbb{P}(\bar{x} > 6,05 | \mu = 5,73) + \mathbb{P}(\bar{x} < 5,41 | \mu = 5,73) \end{aligned}$$

¹ $\mu \pm (\bar{x} - \mu) \implies 5,73 \pm (6,05 - 5,73) = 5,73 \pm 0,32 = [5,41; 6,05]$




Figura 2.7: Diferencia de oblicuidad en distribuciones de probabilidad

$$\begin{aligned}
 &= \mathbb{P}\left(Z > \frac{6,05 - 5,73}{1,2/\sqrt{147}}\right) + \mathbb{P}\left(Z < \frac{5,41 - 5,73}{1,2/\sqrt{147}}\right) \\
 &= \mathbb{P}(Z > 3,23) + \mathbb{P}(Z < -3,23) \\
 &= 1,2 \cdot 10^{-3} \approx 0.
 \end{aligned}$$

Ya que $H_a \neq \mu_0$ ($H_a > \mu_0 \vee H_a < \mu_0$), encontramos Z (3,23) en la tabla Z (distribución normal estándar) y lo multiplicamos por 2 (por simetría, es la misma probabilidad). Así, $p\text{-value} \approx 0,0012$. Luego:

- Si el verdadero PPA promedio de los alumnos de la universidad es 5,73, hay aproximadamente un 0,12 % de posibilidades de observar una muestra aleatoria de 147 alumnos de la universidad cuyo PPA promedio sea de 6,05.
- Esta es una probabilidad muy baja como para que pensemos que una media muestral de 6,05 suceda simplemente por el azar.
- Como el $p\text{-value}$ es bajo (menor al 5 %) rechazamos H_0 .
- Los datos proveen evidencia convincente de que los alumnos de la universidad han cambiado su PPA desde 2010.
- La diferencia entre el valor nulo de un PPA igual a 5,73 y la media muestral de 6,05 no se debe al azar o a la variabilidad del muestreo.

En resumen, el marco de las pruebas de hipótesis se resume como:

1. Establecer las hipótesis:

- $H_0: \mu = \text{valor nulo}$.

- H_a : $\mu < 0$ o $\mu > 0$ o $\mu \neq$ valor nulo.

2. Analizar supuestos y condiciones:

- Independencia: muestra aleatoria.
- Normalidad: población casi normal o $n \geq 30$, sin oblicuidad extrema.

3. Calcular un estadístico de prueba y un p -value mediante

$$Z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}.$$

4. Tomar una decisión e interpretarla en el contexto de la pregunta de investigación:

- Si $p\text{-value} < \alpha$, rechazar H_0 . Los datos proveen evidencia fuerte para H_a .
- Si $p\text{-value} > \alpha$, no rechazar H_0 .

Capítulo 3

Generación de Números Aleatorios

3.1. Introducción a la generación de números aleatorios

Una simulación de cualquier sistema en que haya componentes inherentemente aleatorios requiere un método de generación de números aleatorios. Pensar, por ejemplo, en tiempos entre llegadas, tiempos de servicio, tamaños de demanda, etc. En este capítulo discutiremos cómo obtener conveniente y eficientemente valores aleatorios a partir de una distribución de probabilidad deseada. Para evitar hablar de “generar variables aleatorias” (*random variables*), adoptaremos una terminología más precisa y hablaremos de “generar realizaciones de variables aleatorias” (*random variates*). En particular:

- Este capítulo está dedicado a métodos de generación de realizaciones de variables aleatorias con distribución uniforme en el intervalo $[0, 1]$.
- Esta distribución se denota como $U(0, 1)$. Las realizaciones de la distribución $U(0, 1)$ serán llamadas números aleatorios.
- Aunque esta es la distribución continua más simple de todas, es importante que seamos capaces de obtener tales números aleatorios independientes.

Observación 3.1. El rol prominente de la distribución $U(0, 1)$ se deriva del hecho de que las realizaciones de todas las otras distribuciones (normal, gamma, binomial, etc.) pueden ser obtenidas al transformar números aleatorios iid de alguna forma determinada por la distribución deseada.

Este capítulo discute formas de obtener números aleatorios independientes, y el Capítulo 4 se enfoca en métodos para transformarlos y así obtener realizaciones de otras distribuciones.

Los primeros métodos fueron esencialmente realizados a mano, como tirar dados, repartiendo cartas, etc. Al comienzo del siglo XX, los estadísticos se unieron a los jugadores (de apuestas) en su interés por los números aleatorios, y se construyeron dispositivos mecanizados para generar números aleatorios más rápidamente. Una máquina de números aleatorios, el *Electronic Random Number Indicator Equipment* (ERNIE), fue usado por la Oficina General de Correos británica para seleccionar a los ganadores de la Lotería de Bonos de Ahorro Premium. Otro dispositivo electrónico fue usado por la Corporación Rand (1955) para generar una tabla con un millón de dígitos aleatorios.

Muchos otros esquemas han sido ideados, tales como elegir números “aleatorios” de la guía telefónica o reportes censales, o usar dígitos en una expansión de π a 100 000 lugares decimales. A medida que los computadores (y la simulación) se usaron más ampliamente, se prestó mayor atención a los métodos de generación de números aleatorios compatibles con la forma en que funcionan los computadores.

¿Por qué no usar una máquina como ERNIE directamente en un computador? Porque tiene varias desventajas, principalmente que no podemos reproducir exactamente una cadena de números aleatorios previamente generada (veremos la importancia de esto). Y, ¿por qué no usar una tabla como la de la Corporación Rand? Porque esto implicaría grandes requisitos de memoria para operaciones relativamente lentas. Por lo tanto, la investigación en la década de 1940 y 1950 se volcó a formas numéricas o aritméticas de generar números “aleatorios”. Estos métodos son secuenciales y el primer generador aritmético es el método de los cuadrados medios (*midsquare method*) de Neumann & Metropolis en la década de 1940.

3.2. Método de los cuadrados medios

El método de los cuadrados medios se puede resumir de la siguiente manera:

1. Comenzar con un entero positivo de n dígitos, $Z_0 \in \mathbb{Z}_+$, y elevarlo al cuadrado para obtener un número de $2n$ dígitos. Si es necesario, agregar ceros a la izquierda para hacer que tenga exactamente $2n$ dígitos. Consideraremos $n = 4$ para los siguientes ejemplos. Tenemos,

$$Z_0 = 7182 \implies Z_0^2 = 51\,581\,124.$$

2. Tomar los n dígitos del medio de este número de $2n$ dígitos como el próximo número de n dígitos, Z_1 . Dividir el número Z_1 por 10^{n+1} para obtener el primer número aleatorio $U(0, 1)$. Por ejemplo,

$$Z_0 = 7182 \implies Z_0^2 = 51\,581\,124 \implies Z_1 = 5811 \implies U_1 = 0,5811.$$

3. Luego, hacer que Z_2 sea igual a los n dígitos del medio de Z_1^2 y hacer $U_2 = Z_2/10^{n+1}$, y así sucesivamente. La Tabla 3.1 continúa con algunas iteraciones del ejemplo anterior.

Tabla 3.1: Ejemplo de generación de números aleatorios con el método de los cuadrados medios

i	Z_i	U_i	Z_i^2
0	7182	—	51 581 124
1	5811	0,5811	33 767 721
2	7677	0,7677	58 936 329
3	9363	0,9363	87 665 769
4	6657	0,6657	44 315 649
5	3156	0,3156	09 960 336
$\vdots$	$\vdots$	$\vdots$	$\vdots$

Intuitivamente, el método de los cuadrados medios parece proveer una buena codificación de un número para obtener el siguiente. Pero, de hecho, no funciona del todo bien. Un problema serio (entre otros) es que tiene una fuerte tendencia a degenerarse con bastante rapidez a cero, donde permanecerá para siempre. Una objeción fundamental para este método es que no es del todo “aleatorio”, en el sentido de ser impredecible. De hecho, si conocemos Z_0 , se determina de antemano la secuencia completa de Z_i y U_i .

Observación 3.2 (Características de un generador de números aleatorios eficiente). En base a lo anterior, entonces es natural cuestionarse qué condiciones debería cumplir un generador de números aleatorios para decirse que sea eficiente.

1. Sobre todo, los números producidos deberían estar uniformemente distribuidos en $[0, 1]$ y no deberían exhibir correlación con ningún otro.
2. Naturalmente, queremos un generador rápido y que minimice el almacenamiento.
3. Nos gustaría ser capaces de reproducir de manera exacta una cadena de números aleatorios dada, por dos razones. Primero, facilita la depuración del programa informático. Segundo, podríamos querer usar números aleatorios idénticos al simular sistemas diferentes (por temas de comparación).
4. Debe haber una provisión en el generador para producir fácilmente “cadenas” separadas de números aleatorios. Usar cadenas separadas para propósitos distintos facilita la reproducibilidad y la comparabilidad de los resultados de la simulación.
5. Nos gustaría que el generador fuera portátil, i.e., que produzca la misma secuencia de números aleatorios en todos los computadores.

En resumen, los puntos 2-5 son cumplidos por la mayoría de generadores. Desafortunadamente, muchos métodos fallan en satisfacer el 1.

3.3. Generadores congruenciales lineales

Muchos generadores de números aleatorios usados actualmente son generadores congruenciales lineales (LCGs) introducidos por Lehmer (1951). Una secuencia de enteros $Z_1, Z_2, \dots$ es definida por la fórmula recursiva

$$Z_i = (\alpha Z_{i-1} + c) \pmod{m}, \quad (3.1)$$

donde m (el módulo), α (el multiplicador), c (el incremento) y Z_0 (la semilla) son enteros no negativos. Por tanto, (3.1) dice que para obtener Z_i se debe dividir $\alpha Z_{i-1} + c$ por m y hacer que Z_i sea el resto de esta división. Por lo tanto, $0 \leq Z_i \leq m - 1$, y para obtener los números aleatorios deseados U_i en $[0, 1]$, definimos $U_i = Z_i/m$.

Concentraremos nuestra mayor atención en la parte de los Z_i 's, aunque se debe prestar atención a la naturaleza precisa de la división de Z_i por m debido a las diferencias en la forma en que varios computadores manejan la aritmética de punto flotante. Los enteros m, α, c y Z_0 también deben satisfacer $0 < m, \alpha < m, c < m$, y $Z_0 < m$.

Inmediatamente, se pueden plantear dos objeciones contra los LCGs:

1. La primera es común a todos los generadores de números (pseudo) aleatorios. Es decir, que los Z_i 's de (3.1) no son del todo aleatorios. De hecho, se puede demostrar por inducción matemática que para $i = 1, 2, \dots$,

$$Z_i = \left[\alpha^i Z_0 + \frac{c(\alpha^i - 1)}{\alpha - 1} \right] (\text{mod } m),$$

así que, todo Z_i está completamente determinado por m, α, c y Z_0 .

2. Los U_i 's pueden tomar sólo valores racionales $0, 1/m, 2/m, \dots, (m-1)/m$. De hecho, los U_i 's podrían tomar sólo una fracción de estos valores dependiendo de la especificación de m, α, c y Z_0 , así como de la naturaleza de la división de punto flotante por m . Por tanto, no hay posibilidad de obtener un valor de U_i entre, digamos, $0,1/m$ y $0,9/m$, donde esto podría ocurrir con probabilidad $0,8/m > 0$. Veremos que usualmente se escoge un valor muy grande para el módulo m , digamos 10^9 o más, de modo que los puntos en $[0, 1]$ donde los U_i 's pueden caer sean bastante densos; para $m \geq 10^9$ hay al menos mil millones de posibles valores.

Ejemplo 3.1. Considerar el LCG definido por $m = 16$, $\alpha = 5$, $c = 3$, y $Z_0 = 7$. La siguiente tabla presenta Z_i y U_i (con hasta tres decimales) para $i = 1, 2, \dots, 19$. Notar que $Z_{17} = Z_1 = 6$, $Z_{18} = Z_2 = 1$ y así sucesivamente. Esto es, desde $i = 17$ hasta $i = 32$, obtendremos exactamente los mismos valores de Z_i (y de U_i) que desde $i = 1$ hasta $i = 16$, y en exactamente el mismo orden

i	Z_i	U_i	i	Z_i	U_i	i	Z_i	U_i	i	Z_i	U_i
0	7	—	5	10	0,625	10	9	0,563	15	4	0,250
1	6	0,375	6	5	0,313	11	0	0,000	16	7	0,438
2	1	0,063	7	12	0,750	12	3	0,188	17	6	0,375
3	8	0,500	8	15	0,938	13	2	0,125	18	1	0,063
4	11	0,688	9	14	0,875	14	13	0,813	19	8	0,500

El comportamiento de “bucle” del LCG del ejemplo es inevitable. Por la definición en (3.1), siempre que Z_i tome un valor que ya ha tenido previamente, exactamente la misma secuencia de valores será generada, y este ciclo se repite indefinidamente. El largo de un ciclo se conoce como el periodo del generador. Para el ejemplo anterior, ¡los números aleatorios aparecen principalmente en planos (Figura 3.1)!




Figura 3.1: Números aleatorios generados con un LCG de bajo periodo

3.3.1. Periodo de un generador

Definición 3.1. El periodo es el mínimo entero $\rho > 0$ tal que, para algún $\tau \geq 0$ y para todo $\eta \geq \tau$, tenemos $s_{\rho+\eta} = s_\eta$, donde

$$\underbrace{s_0, s_1, s_2, \dots, s_\tau}_{\text{periodo transiente}}, s_{\tau+1}, \dots, \underbrace{s_{\tau+\rho}}_{s_\tau} \rightarrow s_{\tau+1}, \dots, s_{\tau+\rho}.$$

Un buen método generador es aquel donde $\rho \rightarrow |S|$. En el LCG

$$Z_i = (\alpha Z_{i-1} + c) \pmod{m}$$

el periodo máximo es m . Para los LCGs, Z_i sólo depende del entero previo Z_{i-1} y, ya que $0 \leq Z_i \leq m-1$, es claro que el periodo es a lo más m . Si, de hecho, es m , se dice que el LCG posee periodo completo (*full period*). El LCG del Ejemplo 3.1 tiene periodo completo.

Si el generador es de periodo completo, cualquier elección de Z_0 (semilla inicial) de $\{0, 1, \dots, m-1\}$ producirá el ciclo completo en algún orden. Sin embargo, si un generador no tiene periodo completo, el largo del ciclo puede, de hecho, depender del valor de Z_0 elegido. Debido a que los proyectos de simulación de gran escala pueden usar millones de números aleatorios, es totalmente deseable tener LCGs con periodos largos. Más aún, los LCGs de periodo completo aseguran que cada entero entre 0 y $m-1$ ocurrirá exactamente una vez en cada ciclo, lo que debería contribuir a la uniformidad de los U_i 's.

Es útil saber cómo elegir m , α y c de tal forma que el LCG correspondiente tenga periodo completo. El siguiente teorema, probado por Hull & Dobell (1962), entrega tal caracterización (se puede probar con el ejemplo anterior)

Teorema 3.1. El LCG definido en (3.1) tiene periodo completo si y sólo si se cumplen las siguientes tres condiciones:

1. El único entero positivo que (exactamente) divide a m y c es 1. (Esto a menudo se establece como que “ c es primo relativo a m ”).
2. Todo número primo q (divisible por sí mismo y 1) que divida a m , debe dividir a $\alpha - 1$.
3. Si 4 divide a m , entonces 4 divide a $\alpha - 1$.

En lo que resta de esta sección consideraremos la elección de parámetros para obtener buenos LCGs e identificar algunos LCGs ineficientes que aún se utilizan. Debido a la condición 1 del Teorema 3.1, los LCGs tienden a comportarse diferente para $c > 0$ (LCGs mixtos) y para $c = 0$ (LCGs multiplicativos). Para $c > 0$, la condición 1 del Teorema 3.1 es posible, así que podríamos obtener un periodo completo m , como ahora analizamos:

- Para un periodo largo y alta densidad de los U_i en $[0, 1]$, queremos que m sea grande.
- Una buena elección de m es $m = 2^b$, donde b es el número de *bits* (dígitos binarios) de una palabra (en el computador siendo utilizado) que esté disponible para el almacenamiento de datos.
- Por ejemplo, la mayoría de computadores tienen palabras de 32 *bits*, con el bit de más a la izquierda siendo el signo, así que $b = 31$ y $m = 2^{31} > 2,1$ miles de millones. Elegir $m = 2^b$ permite evitar explícitamente la división por m al tomar ventaja del desbordamiento de enteros.
- El entero más grande que puede ser representado es $2^b - 1$, y cualquier intento de almacenar un valor entero más grande W (con $h > b$ *bits*) resultará en la pérdida de los $h - b$ *bits* más significativos de la izquierda de este entero de gran tamaño. Lo que queda en los b *bits* retenidos es precisamente $W \pmod{2^b}$.
- Eligiendo $m = 2^b$, el Teorema 3.1 dice que obtendríamos un periodo completo si c es impar y $\alpha - 1$ es divisible por 4. Más aún, Z_0 puede ser cualquier entero entre 0 y $m - 1$ sin afectar el periodo.

En cuanto a los LCGs multiplicativos, estos tienen la ventaja de que la suma de c no es necesaria, pero no pueden tener periodo completo ya que la condición 1 del Teorema 3.1 no se puede satisfacer (porque, e.g., m es positivo y divide a m y a $c = 0$). Veremos que es posible obtener un periodo $m - 1$ si m y α se eligen bien:

- Como con los mixtos, es computacionalmente eficiente elegir $m = 2^b$ y, por tanto, evitar divisiones explícitas. Sin embargo, se puede mostrar que en este caso el periodo es a lo más 2^{b-2} , es decir, sólo un cuarto de los enteros entre 0 y $m - 1$ pueden ser obtenidos como valores de los Z_i 's.

- De hecho, el periodo es 2^{b-2} si Z_0 es impar y α es de la forma $8k+3$ o $8k+5$ para algún $k = \{0, 1, \dots\}$.
- Si elegimos un α de la forma $2^l + j$, con $l, j \in \mathbb{Z}_+$, se pueden inducir propiedades estadísticas pobres. El generador usualmente conocido como RANDU es de esta forma ($m = 2^{31}$, $\alpha = 2^{16} + 3 = 65,539$, $c = 0$).
- Debido a estas dificultades asociadas con la elección de $m = 2^b$, se ha intentado buscar formas de especificar m . Un método, por ejemplo, puede ser el reportado por Hutchinson (1966) donde m puede ser el primo más grande menor que 2^b . En el caso de $b = 31$, $m = 2^{31} - 1 = 2\,147\,483\,647$.

Observación 3.3. Hasta el 2010, la función `=ALEATORIO()` de Excel utilizaba un LCG de la forma

$$Z_i = (\alpha Z_{i-1} + c)(\text{mod } m),$$

con

- $\alpha = 1\,103\,515\,245$
- $c = 12345$
- $m = 2^{31}$

Veremos más adelante cuál es el generador que utiliza actualmente.

3.4. Otros generadores

Aunque los LCGs son probablemente el tipo de generadores de números aleatorios más usados y mejor comprendidos, existen muchos tipos alternativos (como el método de los cuadrados medios, que no es recomendado). La mayoría de estos generadores han sido desarrollados en un intento de obtener periodos más largos y mejores propiedades estadísticas. La idea de esta sección no pretende ser un compendio exhaustivo de todo tipo de generadores, sino sólo indicar algunas de las principales alternativas a los LCGs.

3.4.1. Congruencias más generales

Los LCGs pueden considerarse como un caso especial de generadores definidos por

$$Z_i = g(Z_{i-1}, Z_{i-2}, \dots)(\text{mod } m), \quad (3.2)$$

donde $g(\cdot)$ es una función determinística fija de los Z_j 's anteriores. Al igual que con los LCGs, los Z_i 's definidos por (3.2) caen entre 0 y $m-1$, y los números aleatorios $U(0, 1)$ están dados por $U_i = Z_i/m$. (Para los LCGs, $g(\cdot)$ es $g(Z_{i-1}, Z_{i-2}, \dots) = \alpha Z_{i-1} + c$).

Una generalización obvia de los LCGs sería considerar

$$g(Z_{i-1}, Z_{i-2}, \dots) = \beta Z_{i-1}^2 + \alpha Z_{i-1} + c,$$

que produce un generador congruencial cuadrático (QCG). Un caso especial es cuando $\beta = \alpha = 1$, $c = 0$ y m es una potencia de 2. Aunque este generador resulta ser muy similar al método de los cuadrados medios, tiene mejores propiedades estadísticas. Puesto que Z_i sigue dependiendo de Z_{i-1} y, ya que $0 \leq Z_i \leq m-1$, el periodo de los QCGs es de a lo más m .

3.4.2. Generadores recursivos múltiples

Una elección diferente de $g(\cdot)$ es mantener la linealidad, pero usar Z_j 's anteriores; esto da lugar a los denominados generadores recursivos múltiples (MRGs) y se definen por

$$g(Z_{i-1}, Z_{i-2}, \dots) = \alpha_1 Z_{i-1} + \alpha_2 Z_{i-2} + \dots + \alpha_q Z_{i-q} \quad (3.3a)$$

$$= \sum_{k=1}^q \alpha_k Z_{i-k}, \quad (3.3b)$$

donde α es un vector de constantes. Un periodo tan grande como $m^q - 1$ se vuelve posible si los parámetros son elegidos correctamente.

3.4.3. Generadores compuestos

Varias investigaciones han desarrollado métodos que toman dos o más generadores separados y los combinan de alguna forma para generar los números aleatorios finales. Es esperable que estos generadores compuestos exhiban periodos más largos y mejores propiedades estadísticas. Obviamente, la desventaja es que el costo de obtener cada U_i es mayor que el de utilizar un único generador.

El quizás primer tipo de generadores compuestos usaba un segundo LCG para barajar los resultados del primero. El primer generador compuesto fue desarrollado por MacLaren & Marsaglia (1965) y extendido por varios autores en los años siguientes:

- Inicialmente, un vector $\mathbf{V} = (V_1, V_2, \dots, V_k)$ se llena secuencialmente con los k primeros U_i 's del primer LCG ($k = 128$ fue originalmente sugerido).
- El segundo LCG es usado para generar otro número en $[0, 1]$ para luego transformarlo en un entero aleatorio $I \sim U(1, k)$, y V_I es retornado como el primer número $U(0, 1)$. El primer LCG entonces reemplaza esta I -ésima ubicación en $\mathbf{V}$ con su próximo U_i , y el segundo LCG aleatoriamente elige el próximo número aleatorio retornado desde este $\mathbf{V}$ actualizado. Por ejemplo:
 - Para $k = 4$, suponer $\mathbf{V} = (0,15; 0,73; 0,92; 0,52)$. Luego, suponer que desde $I \sim U(1, 4)$ se muestrea $i = 2$. Entonces V_2 pasa a ser el primer número de $\mathbf{V}$, es decir, $\mathbf{V} = (0,73; 0,15; 0,92; 0,52)$.
 - El procedimiento puede continuar de manera análoga, muestreando otro entero desde $I \sim U(1, 4)$ y haciendo los cambios respectivos sobre el nuevo vector $\mathbf{V} = (0,73; 0,15; 0,92; 0,52)$.

Barajar tiene atractivo intuitivo natural, especialmente porque esperaríamos que rompa cualquier correlación y extienda mucho el periodo. Otra forma de combinar dos generadores es discutida en L'Ecuyer (1988). En forma simplificada, la idea es hacer que $\{Z_{1i}\}_{i \in \mathcal{I}}$ y $\{Z_{2i}\}_{i \in \mathcal{I}}$ denoten las secuencias de enteros (de largo $|\mathcal{I}|$) generadas por dos diferentes LCGs. Luego, definir

$$Z_i = (Z_{1i} - Z_{2i})(\text{mod } m) \quad \forall i \in \mathcal{I}$$

para algún entero m , y finalmente establecer

$$U_i = \frac{Z_i}{m} \quad \forall i \in \mathcal{I}.$$

Esta idea puede claramente ser extendida a más de dos generadores, y tiene varias ventajas:

- Periodos muy grandes (al menos 10^{18}).
- Los multiplicadores en cada uno de los componentes generadores puede ser pequeño. Esto promueve la portabilidad y usabilidad en

cualquier computador.

- El generador resultante es bastante rápido.
- Las propiedades estadísticas de estos generadores también tienden a ser muy buenas.

3.4.4. Generadores recursivos múltiples compuestos

Una clase muy atractiva de generadores se obtiene al combinar MRGs, y fue desarrollada por L'Ecuyer (1996, 1999):

- En general, J diferentes MRGs [usando la función $g(\cdot)$ de (3.3)] son implementados simultáneamente para formar las secuencias $\{Z_{1,i}\}, \{Z_{2,i}\}, \dots, \{Z_{J,i}\}$.
- Siendo m_1 el módulo m de (3.2) utilizado en el primero de estos MRGs, y $\delta_1, \delta_2, \dots, \delta_J$ constantes especificadas, definimos

$$Y_i = (\delta_1 Z_{1,i} + \delta_2 Z_{2,i} + \dots + \delta_J Z_{J,i}) \pmod{m_1} \quad (3.4a)$$

$$= \left(\sum_{j=1}^J \delta_j Z_{j,i} \right) \pmod{m_1} \quad \forall i \in \mathcal{I}, \quad (3.4b)$$

y finalmente, retornamos $U_i = Y_i/m_1$ como el i -ésimo número aleatorio para usar en la simulación.

- Aunque los parámetros para estos tipos de generadores deben ser elegidos muy cuidadosamente, periodos extremadamente largos y propiedades estadísticas excepcionalmente buenas son posibles.

L'Ecuyer (1999) llevó a cabo una búsqueda extensiva para encontrar una buena configuración de parámetros y suministró pequeños, portables y rápidos códigos en el lenguaje C para varios casos recomendados. El más simple, donde $J = 2$ MRGs son combinados, es definido para todo $i \in \mathcal{I}$ por

$$\begin{aligned} Z_{1,i} &= (1\,403\,580Z_{1,i-2} - 810\,728Z_{1,i-3}) \pmod{2^{32} - 209} \\ Z_{2,i} &= (527\,612Z_{2,i-1} - 1\,370\,589Z_{2,i-3}) \pmod{2^{32} - 22\,853} \\ Y_i &= (Z_{1,i} - Z_{2,i}) \pmod{2^{32} - 209} \\ U_i &= \frac{Y_i}{2^{32} - 209}, \end{aligned}$$

y posee un periodo de aproximadamente 2^{191} (sobre $3,1 \times 10^{57}$) además de excelentes propiedades estadísticas hasta la dimensión 45. Este

generador se denota como **MRG32k3a** en la literatura. También, este generador está implementado en los *software* de simulación Arena, AutoMod y WITNESS.

3.4.5. Generadores de registros de desplazamiento con retroalimentación

Varios tipos de generadores interesantes han sido desarrollados en base a Tausworthe (1965). Estos generadores, relacionados con métodos criptográficos, operan directamente en *bits* para formar números aleatorios:

- Definir una secuencia $b_1, b_2, \dots$, de dígitos binarios por

$$b_i = (c_1 b_{i-1} + c_2 b_{i-2} + \dots + c_q b_{i-q}) \pmod{2} \quad (3.6a)$$

$$= \left(\sum_{k=1}^q c_k b_{i-k} \right) \pmod{2} \quad (3.6b)$$

donde $\mathbf{c}$ es un vector de constantes que son iguales a 0 o 1 y $c_q = 1$.

Observación 3.4. Estos generadores se conocen en inglés como *feedback shift register generators*.

En la mayoría de aplicaciones de los generadores de Tausworthe, sólo dos coeficientes de $\mathbf{c}$ de (3.6) son distintos de 0 por simplicidad computacional, en cuyo caso (3.6) se convierte en

$$b_i = (b_{i-r} + b_{i-q}) \pmod{2} \quad (3.7)$$

para los enteros $0 < r < q$. La ecuación (3.7) se acelera observando que el módulo 2 es equivalente a la instrucción *exclusive-or* (XOR) en *bits*:

$$b_i = \begin{cases} 0 & b_{i-r} = b_{i-q} \\ 1 & b_{i-r} \neq b_{i-q} \end{cases},$$

que se denota por $b_i = b_{i-r} \oplus b_{i-q}$. Para inicializar la secuencia $\{b_i\}$, se debe especificar $b_1, b_2, \dots, b_q$ (como una semilla), con $i > q$.

Para formar una secuencia de enteros binarios $\{W_i\}$ encadenamos l b_i 's consecutivos y lo consideramos como un número en base 2. Esto es, $W_1 = b_1 b_2 \dots b_l$ y

$$W_i = b_{(i-1)l+1} b_{(i-1)l+2} \dots b_{il} \quad \forall i = 2, 3, \dots$$

Notar que la recurrencia para los W_i 's es análoga a la recurrencia para los b_i 's, es decir

$$W_i = W_{i-r} \oplus W_{i-q}.$$

Luego, el i -ésimo número aleatorio $U(0, 1)$ es definido por

$$U_i = \frac{W_i}{2^l} \quad \forall i = 1, 2, \dots$$

Sean $r = 3$, $q = 5$, $b_1 = b_2 = \dots = b_5 = 1$. Obtener $b_i = (b_{i-3} + b_{i-5})(\text{mod } 2) = b_{i-3} \oplus b_{i-5}$ para $i \geq 6$. Tenemos

$$\begin{aligned} b_6 &= b_3 \oplus b_1 = 0 \\ b_7 &= b_4 \oplus b_2 = 0 \\ b_8 &= b_5 \oplus b_3 = 0 \\ b_9 &= b_6 \oplus b_4 = 1 \\ &\dots \end{aligned}$$

que nos entrega la siguiente secuencia

$$1111 \ 1000 \ 1101 \ 1101 \ 0100 \ 0010 \ 0101 \ 1001 \ 1111.$$

El periodo de los *bits* 0-1 es siempre $2^q - 1 = 31$. Entonces, ¿cómo vamos de los b_i 's a los $U(0, 1)$'s? Fácil: usar $(l\text{-bits en base } 2)/2^l$ y convertirlo a base 10. Estableciendo, por ejemplo, $l = 4$:

$$1111_2, 1000_2, 1101_2, 1101_2, \dots \rightarrow \frac{15}{16}, \frac{8}{16}, \frac{13}{16}, \frac{13}{16}, \dots$$

Los generadores de Tausworthe exhiben buenas propiedades como periodos grandes y cálculos rápidos.

3.4.6. Generador Mersenne Twister

Matsumoto & Nishimura (1998) desarrollaron el generador Mersenne twister, que tiene las siguientes características:

- Su nombre proviene del número primo Mersenne ($2^{19937} - 1$).
- Posee un periodo de $2^{19937} - 1$ para la variante MT19937.
- Este generador es utilizado por Simio y por la librería `numpy.random`. Excel también lo utiliza en su función `=ALEATORIO.ENTRE()`.

- Es un generador muy rápido en arquitecturas modernas y con propiedades estadísticas muy buenas.
- En general, necesitaremos varios millones de números aleatorios en aplicaciones prácticas, pero 2^{191} (MRG32k3a) o $2^{19\,937}$ (MT19937) es como irse al extremo, ¿no?

3.5. Pruebas estadísticas para generadores de números aleatorios

A continuación hay algunos resultados útiles para determinar la calidad de generadores de números pseudo-aleatorios (PRN).

Teorema 3.2. El generador

$$X_i = (\alpha X_{i-1}) \pmod{2^n}$$

($n > 3$) puede tener largo de ciclo de a lo más 2^{n-2} . Este se alcanza cuando X_0 es impar y $\alpha = 8k + 3$ o $\alpha = 8k + 5$ para $k \in \mathbb{Z}_+$.

Ejemplo 3.2. Considerar el generador

$$X_i = (13X_{i-1}) \pmod{64}.$$

Tenemos

X_0	X_1	X_2	X_3	X_4	$\dots$	X_8	$\dots$	X_{16}
1	13	41	21	17	$\dots$	33	$\dots$	1
2	26	18	42	34	$\dots$	2		
3	39	56	63	51	$\dots$	35	$\dots$	3
4	52	36	20	4				

El periodo mínimo es 4... ¡Números aleatorios terribles!

Teorema 3.3. El generador

$$X_i = (\alpha X_{i-1} + c)(\text{mod } m)$$

(con $c > 0$) tiene ciclo completo si (i) c y m son primos relativos; (ii) $\alpha - 1$ es un múltiplo de cada primo que divide a m ; y (iii) $\alpha - 1$ es un múltiplo de 4 si 4 divide a m .

Observación 3.5. El generador

$$X_i = (\alpha X_{i-1} + c)(\text{mod } 2^n)$$

(con $c, n > 1$) tiene ciclo completo si c es impar y $\alpha = 4k + 1$ para $k \in \mathbb{Z}_+$.

Teorema 3.4. El generador multiplicativo

$$X_i = (\alpha X_{i-1})(\text{mod } m),$$



con m primo tiene periodo completo $(m - 1)$ si y sólo si (i) m divide a $\alpha^{m-1} - 1$; y (ii) para todo entero $i < m - 1$, m no divide a $\alpha^i - 1$.

Observación 3.6. Para $m = 2^{31} - 1$, 534 600 000 multiplicadores (α) producen periodo completo, de los cuales el “mejor” es $\alpha = 950\,706\,376$ (Fishman & Moore, 1986).

Ejemplo 3.3. Considerar el siguiente generador:

$$Z_i = (37Z_{i-1} + 1)(\text{mod } 64),$$



para 2 y 3 dimensiones.



Ejemplo 3.4. Considerar el siguiente generador:

$$Z_i = (21Z_{i-1} + 1)(\text{mod } 64),$$


para 2 y 3 dimensiones.




Ejemplo 3.5. Considerar el siguiente generador:

$$Z_i = ((2^{16} + 3)Z_{i-1} + 0)(\text{mod } 2^{31})$$

(RANDU), para 3 dimensiones.



Aquí se ve bien.



Pero, ¿aquí?.

3.6. Pruebas estadísticas

Veremos dos clases de pruebas:

1. Pruebas de bondad de ajuste (*goodness-of-fit*): ¿Son los PRNs aproximadamente $U(0, 1)$?
2. Pruebas de independencia: ¿Son los PRNs aproximadamente independientes?

Si un generador particular pasa ambos tipos de pruebas, estaremos felices de usar los PRNs que éste genere.

Todas las pruebas tienen la forma H_0 (nuestra hipótesis nula) vs H_a (la hipótesis alternativa). Recordemos de nuestro Capítulo 2, que sólo rechazaremos H_0 si tenemos evidencia “fuerte” para ello.

De hecho, queremos evitar rechazos incorrectos de la hipótesis nula. Por lo tanto, cuando diseñamos la prueba, estableceremos un nivel de significancia

$$\alpha \equiv \mathbb{P}(\text{rechazar } H_0 | H_0 \text{ verdadera}) = \mathbb{P}(\text{error tipo I}),$$

donde típicamente, $\alpha = 0,05$ o $\alpha = 0,1$. También, podemos definir

$$\beta \equiv \mathbb{P}(\text{fallar en rechazar } H_0 | H_0 \text{ falsa}) = \mathbb{P}(\text{error tipo II}),$$

pero no nos preocuparemos por el error tipo II en este punto.

3.6.1. Prueba de bondad de ajuste chi-cuadrado (χ^2)

Observación 3.7 (Objetivo). Probar $H_0: U_1, U_2, \dots, U_n \sim U(0, 1)$.

El procedimiento de una prueba de bondad de ajuste chi-cuadrado (χ^2):

1. Primero, se debe dividir el intervalo unitario en k celdas (subintervalos). Si se eligen celdas equiprobables

$$\left[0, \frac{1}{k}\right), \left[\frac{1}{k}, \frac{2}{k}\right), \dots, \left[\frac{k-1}{k}, 1\right],$$

entonces una observación particular U_j caerá en una celda particular con probabilidad $1/k$.

2. Contar cuántas de las n observaciones entran en cada una de las k celdas. Si $N_i \equiv \#$ de U_j 's en la celda i , entonces (ya que, los U_j 's son iid), podemos fácilmente ver que $N_i \sim \text{Bin}(n, 1/k)$ para $i = \{1, 2, \dots, k\}$.

3. Calcular el número esperado de U_j 's que se encuentran en la celda i , que será

$$E_i \equiv \mathbb{E}[N_i] = \frac{n}{k} \quad \forall i = \{1, 2, \dots, k\}.$$

4. Rechazamos H_0 si los N_i 's no coinciden con los E_i 's. El estadístico de bondad de ajuste χ^2 es

$$\chi_0^2 \equiv \sum_{i=1}^k \frac{(N_i - E_i)^2}{E_i}.$$

Un valor alto de este estadístico indica un mal ajuste. De hecho:

- Rechazamos la hipótesis nula H_0 (que las observaciones son uniformes) si $\chi_0^2 > \chi_{\alpha, k-1}^2$, donde $\chi_{\alpha, k-1}^2$ es el cuantil $(1 - \alpha)$ apropiado de una tabla χ^2 , i.e.,

$$\mathbb{P}(\chi_{k-1}^2 < \chi_{\alpha, k-1}^2) = 1 - \alpha.$$

- Si $\chi_0^2 \leq \chi_{\alpha, k-1}^2$, fallamos en rechazar H_0 .

Ejemplo 3.6. Considerar $n = 1000$ observaciones, $k = 5$ intervalos, que proporcionan los siguientes resultados

Intervalo	$[0,0; 0,2)$	$[0,2; 0,4)$	$[0,4; 0,6)$	$[0,6; 0,8)$	$[0,8; 1,0]$
E_i	200	200	200	200	200
N_i	179	208	222	199	192

Resulta que

$$\chi_0^2 \equiv \sum_{i=1}^k \frac{(N_i - E_i)^2}{E_i} = 5,27.$$

Tomemos $\alpha = 0,05$. Luego, de las tablas χ^2 , tenemos

$$\chi_{\alpha, k-1}^2 = \chi_{0,05,4}^2 = 9,49.$$

Ya que $\chi_0^2 < \chi_{\alpha, k-1}^2$, fallamos en rechazar H_0 , y así asumiremos que las observaciones son aproximadamente uniformes.

3.6.2. Pruebas de independencia

Observación 3.8. Ahora consideramos la hipótesis H_0 : $U_1, U_2, \dots, U_n$ son independientes

Para generar ciertas nociones, veamos tres casos de lanzamientos de monedas:

A : H, T, H, T, H, T, H, T, H, T, ... (correlación negativa)

B : H, H, H, H, H, T, T, T, T, T, ... (correlación positiva)

C : H, H, H, T, T, H, T, T, H, T, ... (“correcto”)

Definición 3.2. Una corrida es una serie de observaciones similares.

En base a lo anterior, tenemos:

- En A, las corridas son: “H”, “T”, “H”, “T”,... (muchas corridas).
- En B, las corridas son: “HHHHH”, “TTTTT”,... (muy pocas corridas).
- En C, las corridas son: “HHH”, “TT”, “H”, “TT”,... (número medio de corridas).

Una prueba de corridas rechazará H_0 si hay “muchas” o “pocas” corridas, sea lo que sea que esto signifique. Hay varios tipos de pruebas de corridas, y discutiremos tres de ellos.

Prueba de corridas “arriba y abajo”

Considerar la siguiente secuencia de números uniformes:

0,41 0,68 0,89 0,84 0,74 0,91 0,55 0,71 0,36 0,30 0,09 ...

Si el número incrementa en comparación al anterior, poner un +. Si disminuye, poner un − (como con los H’s y T’s). Se obtiene la secuencia

+ + − − + − + − − − ...

Aquí están las corridas asociadas:

++, −−, +, −, +, − − −, ...

Entonces, ¿tenemos muchas o pocas corridas? Sea A el número de corridas “arriba y abajo” a partir de n observaciones ($A = 6$ en el ejemplo anterior).

Observación 3.9. Hecho increíble: si n es grande (digamos, $n \geq 20$) y los U_j ’s son independientes, entonces

$$A \approx \mathcal{N}\left(\frac{2n-1}{3}, \frac{16n-29}{90}\right).$$

Rechazaremos H_0 si A es muy grande o pequeño. El estadístico de prueba es

$$Z_0 = \frac{A - \mathbb{E}[A]}{\sqrt{\mathbb{V}(A)}},$$

y rechazamos H_0 si $|Z_0| > z_{\alpha/2}$.

Ejemplo 3.7. Suponer que $n = 100$ y $A = 55$. Luego, $A \approx \mathcal{N}(66,33, 17,46)$, y así $Z_0 = -2,71$. Si $\alpha = 0,05$, luego $z_{\alpha/2} = 1,96$, y rechazamos la independencia.

Prueba de corridas “sobre y bajo la media”

Considerar nuevamente:

0,41 0,68 0,89 0,84 0,74 0,91 0,55 0,71 0,36 0,30 0,09 ...

Si $U_i \geq 0,5$, poner un +; si $U_i < 0,5$ poner un -. Se obtiene la secuencia

- + + + + + + - - ...

Aquí están las corridas asociadas, de las cuales hay $B = 3$:

-, + + + + + + +, - - - ...

Observación 3.10. Hecho: si n es grande y los U_j 's son independientes, entonces

$$B \approx \mathcal{N}\left(\frac{2n_1n_2}{n} + \frac{1}{2}, \frac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}\right)$$

donde n_1 es el número de observaciones $\geq 0,5$ (sobre y la media) y $n_2 = n - n_1$.

El estadístico de prueba es

$$Z_0 = \frac{B - \mathbb{E}[B]}{\sqrt{\mathbb{V}(B)}},$$

y rechazamos H_0 si $|Z_0| > z_{\alpha/2}$.

Ejemplo 3.8. Suponer que $n = 40$, con la siguiente secuencia +/−:

- + + + + + + - - - + + - + - - - -

- - + + - - - - + + - - + - + - - + + -

Luego, $n_1 = 18$, $n_2 = 22$ y $B = 17$. Esto implica que $\mathbb{E}[B] = 20,3$ y $\mathbb{V}(B) = 9,54$. Y, esto da $Z_0 = -1,07$.

Ya que $|Z_0| < z_{\alpha/2} = 1,96$, fallamos en rechazar la prueba; así que, podemos tratar las observaciones como independientes.

Prueba de correlación

Asumiendo que los U_j 's son todos $U(0,1)$, realicemos una prueba de correlación para H_0 : U_j 's independientes. Definimos la correlación de un retraso (*lag-1 correlation*) de los U_j 's como $\rho \equiv \text{Corr}(U_j, U_{j+1})$. Idealmente, ρ debe ser igual a 0. Un buen estimador para ρ está dado por

$$\hat{\rho} \equiv \frac{12}{n-1} \sum_{k=1}^{n-1} U_k U_{1+k} - 3.$$

Bajo H_0 , resulta que

$$\hat{\rho} \approx \mathcal{N}\left(0, \frac{13n-19}{(n-1)^2}\right).$$

El estadístico de prueba es $Z_0 = \hat{\rho}/\sqrt{\mathbb{V}(\hat{\rho})}$, y rechazamos si $|Z_0| > z_{\alpha/2}$.

Ejemplo 3.9. Considerar los siguientes $n = 30$ PRNs

| | | | | | | | | | |
|------|------|------|------|------|------|------|------|------|------|
| 0,29 | 0,38 | 0,46 | 0,29 | 0,69 | 0,73 | 0,80 | 0,74 | 0,99 | 0,75 |
| 0,88 | 0,66 | 0,56 | 0,41 | 0,35 | 0,22 | 0,18 | 0,05 | 0,25 | 0,36 |
| 0,39 | 0,45 | 0,50 | 0,62 | 0,76 | 0,81 | 0,97 | 0,72 | 0,11 | 0,55 |

Después de un poco de álgebra, tenemos

$$\hat{\rho} = 0,95 \quad \text{y} \quad \mathbb{V}(\hat{\rho}) = \frac{13n-19}{(n-1)^2} = 0,441.$$

Así, $Z_0 = 0,95/\sqrt{0,441} = 1,43$.

Ya que $|Z_0| < z_{\alpha/2} = 1,96$, fallamos en rechazar la prueba, lo que implica que podemos tratar los PRNs como independientes. (Obviamente, $n = 30$ es algo pequeño, y quizás esta decisión cambiaría si aumentamos n).

Capítulo 4

Generación de Variables Aleatorias

4.1. Introducción a la generación de variables aleatorias

Una simulación que tiene algún componente aleatorio debe incluir un procedimiento de muestreo, o generación, de realizaciones aleatorias a partir de distribuciones de probabilidad. Estas distribuciones a menudo son especificadas (a través de métodos estadísticos) y en este capítulo asumiremos que una distribución ha sido especificada de algún modo (incluyendo el valor de sus parámetros).

En este capítulo también abordaremos el tema de cómo generar realizaciones aleatorias con esta distribución, lo que desde ahora (por simplificación) denominaremos generación de (realizaciones de) variables aleatorias. Es importante recordar del Capítulo 3 que el ingrediente básico de cada método de muestreo de variables aleatorias de cualquier distribución es una fuente generadora de números aleatorios $U(0, 1)$ iid. Por esta razón, es esencial que esté disponible un generador de números aleatorios $U(0, 1)$ estadísticamente confiable.

Observación 4.1 (Objetivo). Usar números $U(0, 1)$ para generar realizaciones (observaciones) de otras distribuciones de probabilidad, e incluso procesos estocásticos. Intentar que sea rápido y reproducible.

En las siguientes secciones veremos algunos enfoques para generar realizaciones de variables aleatorias como el método de la transformada

inversa, de composición, de convolución, de aceptación y rechazo, y otros (Box-Muller y polar).

4.2. Método de la transformada inversa

Teorema 4.1. Sea X una variable aleatoria continua con cdf $F(x)$. Luego, $F(X) \sim U(0, 1)$.

Demostración. Sea $Y = F(X)$ y supongamos que Y tiene cdf $H(y)$. Luego,

$$\begin{aligned} H(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(F(X) \leq y) \\ &= \mathbb{P}(X \leq F^{-1}(y)) = F(F^{-1}(y)) = y, \end{aligned}$$

donde podemos definir la cdf inversa $F^{-1}(z)$ como

$$F^{-1}(z) = \min\{x : F(x) \geq z\} \quad z \in [0, 1].$$

□

La representación anterior puede ser aplicada a distribuciones continuas o discretas. En definitiva, la idea del método de la transformada inversa es generar x a partir de u . Veamos cómo funciona esto en la Figura 4.1 para una distribución normal estándar.




Figura 4.1: Método de la transformada inversa para distribución normal estándar

La pregunta ahora es cómo utilizamos este resultado. Para responderla, definamos $U \sim U(0, 1)$. Luego, $F(X) = U$ significa que la variable aleatoria $F^{-1}(U)$ tiene la misma distribución que X .

Observación 4.2. Método de la transformada inversa El método de la transformada inversa para generar una variable aleatoria X con cdf $F(x)$ es el siguiente:

1. Muestrear U desde $U(0, 1)$
2. Retornar $X = F^{-1}(U)$

4.2.1. Método de la transformada inversa para distribuciones continuas

Ejemplo 4.1 (Distribución uniforme). Considerar la distribución $U(a, b)$ para $a, b \in \mathbb{R}$, con $F(x) = \frac{x-a}{b-a}$, para $a \leq x \leq b$. Despejando X en $F(X) = (X - a)/(b - a) = U$, se obtiene

$$X = a + (b - a)U,$$

que corresponde a la transformada inversa de la distribución $U(a, b)$.

Ejemplo 4.2 (Distribución exponencial). Considerar la distribución $\text{Exp}(\lambda)$ para $\lambda > 0$, con $F(x) = 1 - e^{-\lambda x}$, para $x \in \mathbb{R}_+$. Despejando X en $F(X) = U$, se obtiene

$$X = -\frac{1}{\lambda} \ln(1 - U) \quad \text{o} \quad X = -\frac{1}{\lambda} \ln(U),$$

que corresponde a la transformada inversa de la distribución $\text{Exp}(\lambda)$.

Ejemplo 4.3 (Distribución de Weibull). Considerar la distribución $\text{Weib}(\lambda, \beta)$ para $\lambda, \beta > 0$, con $F(x) = 1 - e^{-(\lambda x)^\beta}$, para $x \in \mathbb{R}_+$. Despejando X en $F(X) = U$, se obtiene

$$X = \frac{1}{\lambda} (-\ln(1 - U))^{\frac{1}{\beta}} \quad \text{o} \quad X = \frac{1}{\lambda} (-\ln(U))^{\frac{1}{\beta}},$$

que corresponde a la transformada inversa de la distribución $\text{Weib}(\lambda, \beta)$.

Ejemplo 4.4 (Distribución triangular). Considerar la distribución $\text{Tria}(0, 1, 2)$ que tiene pdf

$$f(x) = \begin{cases} x & \text{si } 0 \leq x < 1 \\ 2 - x & \text{si } 1 \leq x \leq 2 \end{cases}.$$

Su cdf es

$$F(x) = \begin{cases} \frac{x^2}{2} & \text{si } 0 \leq x < 1 \\ 1 - \frac{(x-2)^2}{2} & \text{si } 1 \leq x \leq 2 \end{cases}.$$

Por lo tanto:

- Si $U < 1/2$, resolvemos $X^2/2 = U$ para obtener $X = \sqrt{2U}$.
- Si $U \geq 1/2$, la única raíz de $1 - (X - 2)^2/2 = U$ en $[1, 2]$ es $X = 2 - \sqrt{2(1 - U)}$.

Así, por ejemplo, si $U = 0,3$, tomamos $X = \sqrt{2 \cdot 0,3} = \sqrt{0,6}$.

Observación: ¡No reemplazar U por $1 - U$ aquí!

Ejemplo 4.5 (Distribución normal estándar). Desafortunadamente, la cdf inversa $\Phi^{-1}(\cdot)$ no tiene forma analítica. ¡Esto es a menudo un problema con el método de la transformada inversa!

- Solución fácil: Hacer una tabla de búsqueda (*lookup table*). E.g., si $U = 0,975$, entonces, a partir de una tabla normal estándar, $Z = \Phi^{-1}(U) = 1,96$.
- Aproximación portátil bruta: la siguiente aproximación da al menos un lugar decimal de precisión para $0,00134 \leq U \leq 0,98865$:

$$Z = \Phi^{-1}(U) \approx \frac{U^{0,135} - (1 - U)^{0,135}}{0,1975}.$$

Por ejemplo, si $U = 0,975$, usando la aproximación previa se obtiene $Z \approx 1,9688$.

Ejemplo 4.6 (Distribución normal estándar y general). Aquí hay una solución portátil mejor para la distribución normal estándar: la siguiente aproximación tiene un error absoluto $\leq 0,45 \cdot 10^{-3}$:

$$Z = \text{sign}(U - 1/2) \left(t - \frac{c_0 + c_1 t + c_2 t^2}{1 + d_1 t + d_2 t^2 + d_3 t^3} \right),$$

donde $\text{sign}(x) \in \{1, 0, -1\}$ si $x \in \mathbb{R}_+$, $x = 0$ o $x \in \mathbb{R}_-$, respectivamente,

$$t = \left\{ -\ln [\min(U, 1 - U)]^2 \right\}^{\frac{1}{2}},$$

y

$$\begin{aligned} c_0 &= 2,515517, & c_1 &= 0,802853, & c_2 &= 0,010328, \\ d_1 &= 1,432788, & d_2 &= 0,189269, & d_3 &= 0,001308. \end{aligned}$$

En cualquier caso, si $Z \sim \mathcal{N}(0, 1)$ y quisiéramos $X \sim \mathcal{N}(\mu, \sigma^2)$, sólo tomar $X \leftarrow \mu + \sigma Z$.

Veamos un ejemplo. Suponer que se quiere generar $X \sim \mathcal{N}(10, 9)$, y se comienza con $U = 0,85$. Luego,

$$\begin{aligned} X &= \mu + \sigma Z \\ &= 10 + 3\Phi^{-1}(0,85) \\ &= 10 + 3 \cdot (1,0364) \\ &= 13,1093. \end{aligned}$$

4.2.2. Método de la transformada inversa para distribuciones discreta

Para distribuciones discretas, a menudo es mejor construir una tabla. Esto es recomendable cuando el soporte de la variable aleatoria posee una cardinalidad suficientemente pequeña. En aquellos casos donde esto no ocurra, veremos que se puede incurrir a técnicas distintas. Veamos algunos ejemplos.

Ejemplo 4.7 (Distribución Bernoulli). Consideremos una variable aleatoria Bernoulli con probabilidad de éxito p . Sabemos que la variable aleatoria toma valor $x = 1$ con probabilidad p y toma valor $x = 0$ con probabilidad $q = 1 - p$. Luego, podemos definir la siguiente tabla.

| x | $\mathbb{P}(X = x)$ | $F(x)$ | $U(0, 1)$'s |
|-----|---------------------|---------|--------------|
| 0 | $1 - p$ | $1 - p$ | $[0, 1 - p]$ |
| 1 | p | 1 | $(1 - p, 1]$ |

De esta manera, si $U \leq 1 - p$, entonces tomar $X = 0$; en otro caso, $X = 1$. Por ejemplo, si $p = 0,75$ y generamos $U = 0,17$, obtenemos $X = 0$.

Ejemplo 4.8 (Distribución discreta general). Suponer que tenemos una pmf discreta un poco menos trivial, dada por

| x | $\mathbb{P}(X = x)$ | $F(x)$ | $U(0, 1)$'s |
|-----|---------------------|--------|----------------|
| -1 | 0,6 | 0,6 | $[0, 0, 0, 6]$ |
| 2,5 | 0,3 | 0,9 | $(0, 6, 0, 9]$ |
| 4 | 0,1 | 1,0 | $(0, 9, 1, 0]$ |

Por tanto, si $U = 0,63$, tomamos $X = 2,5$.

Ejemplo 4.9 (Distribución uniforme discreta). La distribución uniforme discreta en $k \in \{1, 2, \dots, n\}$ es representada como $\mathbb{P}(X = k) = 1/n$. Claramente, $X = \lceil nU \rceil$, donde $\lceil \cdot \rceil$ es la función techo (*ceiling*). Así que, si $n = 10$ y $U = 0,376$, entonces $X = \lceil 3,76 \rceil = 4$.

Ejemplo 4.10 (Distribución geométrica). La distribución geométrica con pmf

$$f(k) = q^{k-1}p,$$

y cdf

$$F(k) = 1 - q^k$$

para $k \in \{1, 2, \dots\}$, donde $q = 1 - p$. Por lo tanto, luego de un poco de álgebra

$$X = \min\{k : 1 - q^k \geq U\} = \left\lceil \frac{\ln(1 - U)}{\ln(1 - p)} \right\rceil \sim \left\lceil \frac{\ln(U)}{\ln(1 - p)} \right\rceil.$$

Por ejemplo, si $p = 0,3$ y $U = 0,72$, obtenemos

$$X = \left\lceil \frac{\ln(0,28)}{\ln(0,7)} \right\rceil = 4.$$

Observación 4.3. También podemos generar $\text{Geom}(p)$ contando experimentos $\text{Bern}(p)$ hasta obtener un éxito.

Suponer que queremos generar $X \sim \text{Geom}(1/6)$. Esto es lo mismo que contar el número de lanzamientos de dados hasta que aparezca un 3 (o cualquier número particular), donde los experimentos $\text{Bern}(1/6)$ son los lanzamientos iid de dados.

Por ejemplo, si se lanza 6, 2, 1, 4, 3, entonces se detienen los lanzamientos en el experimento Bernoulli $X = 5$, y esa es la respuesta.

Pero la vida no siempre consiste en lanzar un dado. Una forma general de generar una $\text{Geom}(p)$ es contar el número de experimentos hasta $U_i \leq p$. Por ejemplo, si $p = 0,3$, entonces $U_1 = 0,71$, $U_2 = 0,96$ y $U_3 = 0,12$ implican que $X = 3$.

Si se tiene una distribución discreta como la $\text{Pois}(\lambda)$ con un número infinito de valores, se pueden escribir las entradas de la tabla hasta que la cdf sea cercana a uno, generar exactamente un U , y luego buscar hasta encontrar $X = F^{-1}(U)$, i.e., x_i tal que $U \in (F(x_{i-1}), F(x_i)]$. Es decir,

| x | $\mathbb{P}(X = x)$ | $F(x)$ | $U(0, 1)$'s |
|----------|---------------------|----------|--------------------|
| x_1 | $f(x_1)$ | $F(x_1)$ | $[0, F(x_1)]$ |
| x_2 | $f(x_2)$ | $F(x_2)$ | $(F(x_1), F(x_2)]$ |
| x_3 | $f(x_3)$ | $F(x_3)$ | $(F(x_2), F(x_3)]$ |
| $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ |

Ejemplo 4.11 (Distribución de Poisson). Suponer $X \sim \text{Pois}(2)$, tal que $f(x) = \frac{e^{-2}2^x}{x!}$ para $x \in \{0, 1, 2, 3, \dots\}$

| x | $\mathbb{P}(X = x)$ | $F(x)$ | $U(0, 1)$'s |
|----------|---------------------|----------|--------------------|
| 0 | 0,1353 | 0,1353 | $[0, 0,1353]$ |
| 1 | 0,2707 | 0,4060 | $(0,1353, 0,4060]$ |
| 2 | 0,2707 | 0,6767 | $(0,4060, 0,6767]$ |
| 3 | 0,1804 | 0,8571 | $(0,6767, 0,8571]$ |
| $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ |

Por ejemplo, si $U = 0,581$, entonces $X = 2$.

4.2.3. Método de la transformada inversa para distribuciones continuas empíricas

Si no se puede encontrar una buena distribución teórica para modelar una cierta variable aleatoria, se podría utilizar la cdf empírica de los datos $\{X_i\}_{i \in [n]}$,

$$\hat{F}_n(x) \equiv \frac{Z(x)}{n},$$

donde $[n] = \{1, 2, \dots, n\}$ y $Z(x)$ representa el número de X_i 's $\leq x$. Notar que $\hat{F}_n(x)$ es una función escalonada con saltos de altura $1/n$ (cada vez que se produce una observación).

Una ventaja de este método es que incluso aunque X sea continua, el lema Glivenko-Cantelli dice que $\hat{F}_n(x) \rightarrow F(x)$ para todo x cuando $n \rightarrow \infty$. Así, $\hat{F}_n(x)$ es una buena aproximación a la verdadera cdf, $F(x)$.

El procedimiento es el siguiente. Primero, se definen los puntos ordenados, $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$. E.g., si las observaciones son $X_1 = 4$, $X_2 = 1$ y $X_3 = 6$, entonces los puntos ordenados son $X_{(1)} = 1$, $X_{(2)} = 4$ y $X_{(3)} = 6$, los que pueden representarse según la Figura 4.2.




Figura 4.2: Ejemplo de distribución empírica vs. teórica

Es importante considerar que, mientras mayor sea la cantidad de observaciones en una muestra, más clara debería ser la convergencia de la cdf empírica a la cdf teórica. La Figura 4.3 muestra este hecho a partir de 10, 50, 100, y 500 realizaciones generadas a partir de una distribución normal estándar. Aquí, claramente se aprecia que mientras mayor es la cantidad de observaciones, mayor va siendo la similitud entre ambas cdf's.




Figura 4.3: Comparación de distribución empírica y teórica para distintas cantidades de observaciones

Dado que sólo se tiene un número finito de n observaciones, podemos convertir la cdf empírica en una variable aleatoria continua usando una

interpolación lineal entre los $X_{(i)}$'s. Sea


$$F(x) = \begin{cases} 0 & x < X_{(1)} \\ \frac{i-1}{n-1} + \frac{x-X_{(i)}}{(n-1)(X_{(i+1)}-X_{(i)})} & X_{(i)} \leq x < X_{(i+1)}, \forall i \in [n-1], \\ 1 & x \geq X_{(n)} \end{cases}$$

y, luego,

1. Definir $F(X) = U \sim U(0, 1)$. Sea $P = (n-1)U$ y $I = \lceil P \rceil$.
2. Resolver para obtener $X = X_{(I)} + (P - I + 1)(X_{(I+1)} - X_{(I)})$.

Ejemplo 4.12. Suponer que se tienen las observaciones $X_{(1)} = 1$, $X_{(2)} = 4$ y $X_{(3)} = 6$. Si $U = 0,73$, entonces $P = (n-1)U = 1,46$ y $I = \lceil P \rceil = 2$. Así,

$$\begin{aligned} X &= X_{(I)} + (P - I + 1)(X_{(I+1)} - X_{(I)}) \\ &= X_{(2)} + (1,46 - 2 + 1)(X_{(3)} - X_{(2)}) \\ &= 4 + (0,46)(6 - 4) = 4,92. \end{aligned}$$



Ejemplo 4.13. Podemos usar una cdf empírica aproximada cuando se trabaja con datos agrupados. Veamos una muestra de 100 tiempos de reparación

| Intervalo | Frecuencia | Frecuencia relativa | $\hat{F}(x)$ aproximada |
|------------------------|------------|---------------------|-------------------------|
| $0,25 \leq x \leq 0,5$ | 31 | 0,31 | 0,31 |
| $0,5 < x \leq 1,0$ | 10 | 0,10 | 0,41 |
| $1,0 < x \leq 1,5$ | 25 | 0,25 | 0,66 |
| $1,5 < x \leq 2,0$ | 34 | 0,34 | 1,00 |

¿Cómo construir una realización X desde $\hat{F}(x)$? Usar el hecho de que $\hat{F}(X) \sim U(0,1)$ y aplicar la transformada inversa, i.e., $X = \hat{F}^{-1}(U)$.

Por ejemplo, si $U \in (0,66, 1,0]$ (las últimas dos entradas $\hat{F}(x)$ de la tabla), entonces

$$\begin{aligned}
 X &= \hat{F}^{-1}(0,66) + \left(\frac{\hat{F}^{-1}(1,0) - \hat{F}^{-1}(0,66)}{1,0 - 0,66} \right) (U - 0,66) \\
 &= 1,5 + \left(\frac{2,0 - 1,5}{1,0 - 0,66} \right) (U - 0,66) \\
 &= 1,5 + 1,471 \cdot (U - 0,66)
 \end{aligned}$$

Por lo tanto, e.g., si $U = 0,77$, entonces $X = 1,66181$.

Para generalizar el procedimiento del Ejemplo 4.13, se necesita:

1. Generar $U \sim U(0,1)$.
2. Encontrar el intervalo $\hat{F}(x)$ en el cual se encuentre U , i.e., i tal que $r_i < U \leq r_{i+1}$. En el ejemplo anterior,

| r_1 | r_2 | r_3 | r_4 | r_5 |
|-------|-------|-------|-------|-------|
| 0,0 | 0,31 | 0,41 | 0,66 | 1,0 |

3. Sea x_i el extremo izquierdo del i -ésimo intervalo X , y sea α_i el recíproco de la pendiente del i -ésimo intervalo, i.e., $\alpha_i = ((r_{i+1} - r_i)/(x_{i+1} - x_i))^{-1}$

| x_1 | x_2 | x_3 | x_4 | x_5 |
|-------|-------|-------|-------|-------|
| 0.25 | 0.50 | 1.0 | 1.5 | 2.0 |

| α_1 | α_2 | α_3 | α_4 | α_5 |
|------------|------------|------------|------------|------------|
| 0.81 | 5.0 | 2.0 | 1.47 | - |

4. Obtenemos $X = x_i + \alpha_i(U - r_i)$.

4.3. Método de composición

Suponer una variable aleatoria que proviene de dos variables aleatorias. Por ejemplo, un avión puede salir tarde por dos razones: retrasos en el tráfico aéreo y en el mantenimiento, que componen el tiempo total de retraso.

Observación 4.4 (Objetivo del método de composición). Generar una variable aleatoria con cdf

$$F(x) = \sum_{i=1}^{\infty} p_i F_i(x),$$

donde $p_i > 0$ para todo i , $\mathbb{1}^\top \mathbf{p} = 1$, y los $F_i(x)$'s son cdf's "fáciles" para generar realizaciones. Esto se hace de la siguiente manera:

1. Generar $I \in \mathbb{Z}_+$ tal que $\mathbb{P}(I = i) = p_i$ para todo i .
2. Retornar X de la cdf $F_I(x)$.

Demostración. Por la ley de probabilidad total (ver Capítulo 2), X tiene cdf $F(x)$:

$$\begin{aligned} \mathbb{P}(X \leq x) &= \sum_{i=1}^{\infty} \mathbb{P}(X \leq x | I = i) \mathbb{P}(I = i) \\ &= \sum_{i=1}^{\infty} F_i(x) p_i \\ &= F(x). \end{aligned}$$

□

Veamos como ejemplo el de la distribución exponencial doble (o Laplace), que es representada por

$$f(x) \equiv \begin{cases} 0,5e^x & x < 0 \\ 0,5e^{-x} & x > 0 \end{cases} \quad \text{y} \quad F(x) \equiv \begin{cases} 0,5e^x & x < 0 \\ 1 - 0,5e^{-x} & x > 0 \end{cases},$$

y cuya pdf y cdf pueden observarse en la Figura 4.4 a la izquierda y derecha, respectivamente.




Figura 4.4: Funciones de densidad de probabilidad (pdf) y probabilidad acumulada (cdf) de distribución Laplace

Ejemplo 4.14 (Distribución de Laplace). Por ahora, descompongamos X en distribuciones “exponenciales negativas” y exponenciales regulares

$$F_1(x) \equiv \begin{cases} e^x & x < 0 \\ 1 & x > 0 \end{cases} \quad \text{y} \quad F_2(x) \equiv \begin{cases} 0 & x < 0 \\ 1 - e^{-x} & x > 0 \end{cases}.$$

Luego, $F(X) = 0,5F_1(x) + 0,5F_2(x)$.

Usaremos la transformada inversa para resolver $F_1(X) = e^X = U$ en términos de X la mitad de las veces, y $F_2(X) = 1 - e^{-X} = U$ la otra mitad. Luego,

$$X \leftarrow \begin{cases} \ln(U) & \text{c.p. } 0,5 \\ -\ln(U) & \text{c.p. } 0,5 \end{cases}.$$

4.4. Método de convolución

Convolución, por definición, hace referencia a la suma de cosas. El método de convolución puede confundirse fácilmente con el de compo-


ción visto anteriormente. Sin embargo, el método de composición es una generalización del método de convolución. En este último, solo sumamos variables aleatorias, sin especificar una probabilidad a cada una de ellas. Dicho de otra manera, el método de convolución se puede considerar como uno de composición donde $p_i = 1/n$ para todo $i \in \{1, \dots, n\}$.

Ejemplo 4.15 (Distribución binomial). Si $\{X_i\}_{i \in [n]} \sim \text{Bern}(p)$ son iid, entonces $Y = \sum_{i=1}^n X_i \sim \text{Bin}(n, p)$.

Ya sabemos cómo obtener variables aleatorias Bernoulli a través de la transformada inversa: suponer que $\{U_i\}_{i \in [n]}$ son $U(0, 1)$ iid. Si $U_i \leq p$, definir $X_i = 1$; en otro caso, definir $X_i = 0$. Repetir para $i = 1, \dots, n$. Sumar hasta obtener Y .

Por ejemplo, si $Y \sim \text{Bin}(3, 0.4)$ y $U_1 = 0.63$, $U_2 = 0.17$ y $U_3 = 0.81$, entonces $Y = 0 + 1 + 0 = 1$.

Ejemplo 4.16 (Distribución triangular). Se puede mostrar que si U_1 y U_2 son $U(0, 1)$ iid, entonces $U_1 + U_2$ es $\text{Tria}(0, 1, 2)$. (Esto es más fácil—pero quizás no más rápido—que nuestro método de la transformada inversa).



Ejemplo 4.17 (Distribución de Erlang). Si $\{X_i\}_{i \in [n]} \sim \text{Exp}(\lambda)$ son iid, entonces $Y = \sum_{i=1}^n X_i \sim \text{Erlang}(\lambda)$. Por la transformada inversa, tenemos

$$\begin{aligned} Y &= \sum_{i=1}^n X_i \\ &= \sum_{i=1}^n \left[-\frac{1}{\lambda} \ln(U_i) \right] \\ &= -\frac{1}{\lambda} \ln \left(\prod_{i=1}^n U_i \right). \end{aligned}$$

Esto sólo toma una evaluación de logaritmo natural, por lo que es bastante eficiente.

4.5. Método de aceptación y rechazo

La mayoría de las cdf's no pueden ser invertidas fácilmente. Aceptación y rechazo (A-R) muestrea desde una distribución que es “casi” la que queremos, y luego lo ajusta al “aceptar” sólo una cierta proporción de estas muestras.

Ejemplo 4.18. Generar una variable aleatoria $U(2/3, 1)$. Aquí está el algoritmo A-R simplificado:

1. Generar $U \sim U(0, 1)$.
2. Si $U \geq 2/3$, se acepta $X \leftarrow U$. En otro caso, se rechaza y se vuelve al Paso 1.

Suponer que queremos simular una variable aleatoria continua X con pdf $f(x)$, pero que es difícil de generar directamente. También suponer que podemos fácilmente generar una variable aleatoria con pdf $h(x) \equiv t(x)/c$, donde $t(x)$ “mayoriza” (*majorizes*) $f(x)$, i.e.,

$$t(x) \geq f(x) \quad x \in \mathbb{R},$$

y

$$c \equiv \int_{\mathbb{R}} t(x) dx \geq \int_{\mathbb{R}} f(x) dx = 1,$$

donde asumimos que $c < \infty$. La Figura 4.5 resume esta idea.




Figura 4.5: Representación gráfica para un ejemplo del método de aceptación y rechazo

Usualmente, $f(x)$ y $t(x)$ son conocidas como las distribuciones obje-

tivo (*target*) y propuesta (*proposal*), respectivamente.

Teorema 4.2 (von Neumann 1951). Definir $g(x) \equiv f(x)/t(x)$ y notar que $0 \leq g(x) \leq 1$ para todo x . Sea $U \sim U(0, 1)$, y sea Y una variable aleatoria (independiente de U) con pdf $h(y) = t(y)/c$. Si $U \leq g(Y)$, entonces Y tiene pdf (condicional) $f(y)$.

Lo anterior, sugiere el siguiente algoritmo, que corresponde al método A-R:

Resultado: Muestra de $f(x)$ a partir de $h(y)$

repetir

Generar U desde $U(0, 1)$


Generar Y desde $h(y)$ (independiente de U)

$g(Y) = \frac{f(Y)}{t(Y)} = \frac{f(Y)}{c h(Y)}$

hasta que $U \leq g(Y)$;

devolver $X \leftarrow Y$

Ejemplo 4.19. Generar realizaciones de una variable aleatoria con pdf $f(x) = 60x^3(1-x)^2$ para $0 \leq x \leq 1$. Esta no se puede invertir analíticamente. Notar que el máximo ocurre en $x^* = 0,6$, y $f(x^*) = f(0,6) = 2,0736$.



Usando la *majorizing function* $t(x) = 2,0736$ para $0 \leq x \leq 1$ (que no es muy eficiente), obtenemos $c = \int_0^1 t(x)dx = 2,0736$, y así


$$h(y) = \frac{t(y)}{c} = 1,$$

con $0 \leq y \leq 1$ (i.e., una pdf $U(0,1)$), y

$$g(y) = \frac{f(y)}{t(y)} = \frac{60y^3(1-y)^2}{2,0736}.$$

Entonces, por ejemplo, si generamos $U = 0,13$ e $Y = 0,25$, entonces $U \leq g(0,25) \approx 0,254$, así tomamos $X \leftarrow 0,25$.

Ejemplo 4.20. Generar realizaciones de una variable aleatoria semi-normal estándar con pdf $f(x) = \frac{2}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$ para $x \in \mathbb{R}_+$.



Usando la *majorizing function*

$$t(x) = \sqrt{\frac{2e}{\pi}}e^{-x} \geq f(x) \quad \forall x \geq 0,$$

tenemos

$$c = \sqrt{\frac{2e}{\pi}} \int_0^\infty e^{-x} dx = \sqrt{\frac{2e}{\pi}} = 1,3155,$$

$$h(y) = \frac{t(y)}{c} = e^{-y},$$

y

$$g(y) = \frac{f(y)}{t(y)} = e^{-\frac{(y-1)^2}{2}}.$$

Podemos usar el resultado de la semi-normal del Ejemplo 4.20 para generar una realización $\mathcal{N}(0, 1)$ de la siguiente forma:

1. Generar U desde $U(0, 1)$.
2. Generar X desde la distribución semi-normal.
3. Retornar

$$Z = \begin{cases} -X & U \leq 0,5 \\ X & U > 0,5 \end{cases}.$$

Recordar que también podemos, entonces, generar una variable aleatoria $\mathcal{N}(\mu, \sigma^2)$ usando la transformación obvia $\mu + \sigma Z$.

4.6. Otros métodos

A continuación, serán revisados dos métodos para la generación de realizaciones de variables aleatorias normales estándar. Particularmente, los métodos Box-Muller y polar.


4.6.1. Método Box-Muller

El método Box-Muller es una forma sencilla para generar realizaciones de distribuciones normales estándar. La idea es que si U_1, U_2 son $U(0, 1)$ iid, entonces

$$Z_1 = \sqrt{-2 \ln(U_1)} \cos(2\pi U_2)$$

$$Z_2 = \sqrt{-2 \ln(U_1)} \sin(2\pi U_2)$$

son $\mathcal{N}(0, 1)$ iid. Notar que los cálculos trigonométricos deben realizarse en radianes.



Algunos corolarios interesantes siguen directamente de Box-Muller.

Ejemplo 4.21. Notar que

$$Z_1^2 + Z_2^2 \sim \chi^2(1) + \chi^2(1) \sim \chi^2(2).$$

Pero,

$$\begin{aligned} Z_1^2 + Z_2^2 &= -2 \ln(U_1) (\cos^2(2\pi U_2) + \sin^2(2\pi U_2)) \\ &= -2 \ln(U_1) \\ &= \text{Exp}(1/2). \end{aligned}$$

Por tanto, acabamos de demostrar que

$$\chi^2(2) \sim \text{Exp}(1/2).$$

4.6.2. Método polar


Este método es un poco más rápido que Box-Muller y tiene el mismo objetivo. Se puede resumir como:

1. Generar $U(0, 1)$ iid U_1, U_2 . Definimos $V_i = 2U_i - 1$ para $i = 1, 2$, y $W = V_1^2 + V_2^2$.
2. Si $W > 1$, rechazar y volver al Paso 1. En otro caso, definir

$$Y = \sqrt{-2 \ln(W)/W},$$

y aceptar $Z_i \leftarrow V_i Y$ para $i = 1, 2$.

Luego, Z_1 y Z_2 son $\mathcal{N}(0, 1)$ iid.



Capítulo 5

Análisis del Input

Una vez que el equipo ha definido y modelado de manera precisa el sistema real, surge una pregunta esencial: ¿Cómo especificar las distribuciones de probabilidad que gobiernan los parámetros inciertos de la simulación?

El proceso de especificar las distribuciones de probabilidad de los parámetros inciertos de la simulación es conocido como el análisis del *input*. Por ejemplo, pensar en los tiempos entre llegadas de los clientes a un banco. Las siguientes son preguntas naturales:

- ¿Los tiempos entre llegadas distribuyen exponencialmente? ¿Weibull? ¿Son estacionarios? ¿iid?
- ¿Son realmente inciertos? ¿Qué pasa si, de hecho, son constantes?
- ¿Es la tasa de llegadas constante a través del tiempo?
- ¿Qué pasa si modelamos correctamente los tiempos entre llegadas como exponenciales, pero están mal especificadas las tasas de llegada?

Observación 5.1 (Recordatorio). GIGO (*Garbage-In-Garbage-Out*) es nuestro peor enemigo. Un análisis del *input* adecuado puede evitar esto

Anteriormente, revisamos los principales temas del análisis del *input*. Pero, ¿qué debemos hacer en general para hacer este proceso correctamente? Además de recopilar (tantos) datos (como se pueda) para el análisis, debemos:

1. Hipotetizar la distribución subyacente.

2. Estimar los parámetros asociados a la distribución hipotetizada.
3. Realizar una prueba estadística para ver si la distribución anterior (junto con la estimación de sus parámetros) es “aproximadamente correcta”.

A continuación, estudiaremos detalladamente métodos para realizar estos tres pasos esenciales del análisis del *input*.

5.1. Hipotetización de la distribución

El primer paso en un proceso de análisis de datos es graficar los datos. Un tipo de gráfico muy útil es el histograma. En la Figura 5.1 podemos observar cuatro histogramas desarrollados en base al mismo conjunto de (1 000 000 de) datos. La única diferencia entre ellos es la cantidad de *bins* (barras) que los definen. Aunque cada software o paquete computacional aplica internamente distintas formas de determinar la cantidad de *bins* de un histograma, una alternativa clásica y comúnmente utilizada es la regla de Sturges. Esta señala que la cantidad de *bins* a considerar viene dada por la expresión $\lceil \log_2(n) + 1 \rceil$, donde n es la cantidad de observaciones y $\lceil \cdot \rceil$ corresponde a la función techo (que entrega el próximo valor entero de su argumento). Por ejemplo, si contamos con 31 datos, entonces la cantidad de bins a considerar según la regla de Sturges debería ser $\lceil \log_2(31) + 1 \rceil = \lceil 4,95 + 1 \rceil = \lceil 5,95 \rceil = 6$.




Figura 5.1: Histogramas del mismo conjunto de datos en base a diferentes cantidades de bins

Observación 5.2 (Hecho, LLN). Si se toman suficientes observaciones, el histograma eventualmente convergerá a la verdadera distribución

Ahora, la pregunta es cómo empezar la hipotetización. Antes de generar un histograma a partir de observaciones, algunas preguntas que pueden existir son:

- ¿La variable aleatoria es discreta o continua?
- ¿La variable aleatoria es univariada o multivariada?
- ¿Cuántos datos están disponibles?
- ¿Hay expertos cerca para preguntarles sobre la naturaleza de los datos?
- ¿Qué ocurre si no se tienen suficientes datos? ¿Se puede al menos suponer una distribución adecuada?

Supongamos que escogemos una distribución continua, pues notamos que la variable aleatoria a modelar es de naturaleza continua. La pregunta ahora es cuál podría ser una distribución tentativa:

- Uniforme, $\text{Unif}(a, b)$: no se sabe mucho de los datos, excepto los valores mínimos (a) y máximos (b) posibles.
- Triangular, $\text{Tria}(a, b, c)$: se conocen los valores mínimos (a), máximos (c) y “más probables” (b).
- Exponencial, $\text{Exp}(\lambda)$: tiempos entre llegadas de un proceso de Poisson con tasa λ .
- Normal, $\mathcal{N}(\mu, \sigma^2)$: buen modelo para alturas, pesos, medias muestrales, etc.
- Beta, $\text{Beta}(\alpha, \beta)$: buena para especificar datos delimitados.
- Gamma, $\text{Gamma}(\alpha, \lambda)$; Weibull, $\text{Weib}(\lambda, \alpha)$; Gumbel, $\text{Gumb}(\mu, \beta)$; lognormal, $\text{LN}(\mu, \sigma^2)$: datos de confiabilidad.
- Empírica: distribución “muestral”.

Y, ¿si la variable aleatoria es de naturaleza discreta en vez de continua? Algunas distribuciones clásicas que podríamos considerar serían las siguientes:

- Bernoulli, $\text{Ber}(p)$: probabilidad de éxito p en un experimento de resultado binario.
- Binomial, $\text{Bin}(n, p)$: número de éxitos en n experimentos $\text{Ber}(p)$.
- Geométrica, $\text{Geo}(p)$: número de experimentos $\text{Ber}(p)$ hasta el primer éxito.
- Binomial negativa, $\text{NBin}(r, p)$: número de éxitos en una secuencia iid $\text{Ber}(p)$ antes de que ocurran r fracasos.
- Poisson, $\text{Pois}(\lambda)$: número de eventos en un determinado espacio o tiempo.
- Empírica: distribución “muestral”.

En resumen, la idea es elegir una distribución aparentemente “razonable”, y luego probarla para ver que no sea tan insensata.

Ejemplo 5.1. Si se plantea la hipótesis de que ciertos datos son gaussianos, entonces los datos deberían caer aproximadamente en una línea recta de un gráfico Q-Q. En este gráfico se comparan los cuartiles teóricos (eje horizontal) con los muestrales (eje vertical). El gráfico izquierdo de la Figura 5.2 muestra un ejemplo de un correcto ajuste de una distribución normal estándar a los datos, mientras que el de la derecha muestra un ajuste incorrecto. El primero se debe al hecho de que existe una alineación casi perfecta entre ambos cuartiles, mientras que el segundo presenta una clara diferencia en los extremos (inferiores y superiores) de los cuartiles.




Figura 5.2: Ejemplo de gráfico Q-Q

5.2. Estimación de parámetros de una distribución

Una vez hipotetizada una distribución, el segundo paso consiste en estimar sus parámetros. Por supuesto, cada distribución necesita uno o más parámetros distintos entre sí. Por ejemplo, la distribución uniforme necesita el mínimo (a) y el máximo (b), la exponencial su tasa (λ), la normal la media (μ) y la varianza (σ^2), la Bernoulli la probabilidad de éxito (p), etc. Comenzaremos con algunas definiciones formales e importantes, para finalmente conocer el método de los estimadores de máxima verosimilitud y el método de los momentos.

Definición 5.1. Un estadístico es una función de las observaciones $\{X_i\}_{i \in [n]}$, y explícitamente independiente de cualquiera de los parámetros desconocidos.

Algunos ejemplos de estadísticos típicos son:

- Media muestral:

$$\bar{X} \equiv \frac{1}{n} \sum_{i=1}^n X_i.$$

- Varianza muestral:

$$S^2 \equiv \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Notar que los estadísticos son variables aleatorias. Son totalmente dependientes de las muestras, por lo que se esperaría que tomen diferentes valores para diferentes muestras.

Un estadístico es usualmente utilizado para estimar algunos parámetros inciertos de la distribución subyacente de las observaciones $\{X_i\}_{i \in [n]}$ que se tengan a disposición. Sean $\{X_i\}_{i \in [n]}$ variables aleatorias iid y sea $T(\mathbf{X}) \equiv T(X_1, \dots, X_n)$ un estadístico basado en los X_i 's. Suponer que usamos $T(\mathbf{X})$ para estimar algún parámetro desconocido θ . Luego, $T(\mathbf{X})$ se conoce como estimador puntual (*point estimator*) para θ . θ podría ser, por ejemplo, la tasa λ de una distribución exponencial, la media μ o la varianza σ^2 de una distribución normal, etc. Utilizamos θ solo para ge-

neralizar el nombre del parámetro a estimar.

Ejemplo 5.2. $\bar{X}$ es usualmente un estimador puntual para la media $\mu = \mathbb{E}[X]$, y S^2 es a menudo un estimador puntual para la varianza $\sigma^2 = \mathbb{V}[X]$.

Sería bueno que el estadístico $T(\mathbf{X})$ tuviera las siguientes propiedades:

- Su valor esperado debería ser igual al parámetro que se está intentando estimar. Es decir, debería ser insesgado.
- Debe tener baja varianza.

Definición 5.2. $T(\mathbf{X})$ es insesgado para θ si $\mathbb{E}[T(\mathbf{X})] = \theta$.

Ejemplo 5.3. Sean $\{X_1, \dots, X_n\}$ n observaciones iid de una población con media μ . Luego, $\bar{X}$ es siempre insesgado para μ ,

$$\mathbb{E}[\bar{X}] = \frac{1}{n} \mathbb{E}\left[\sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu.$$

Esta es la razón por la cual $\bar{X}$ se conoce como media muestral.

Ejemplo 5.4. Sean $\{X_1, \dots, X_n\}$ n observaciones iid de una población con media μ y varianza σ^2 . Luego, $\mathbb{E}[S^2] = \mathbb{V}[\mathbf{X}] = \sigma^2$, así que S^2 es siempre insesgado para σ^2 , y por ello la llamamos S^2 varianza muestral.

Observación: que S^2 sea insesgado para σ^2 no implica que S sea insesgado para la desviación estándar σ . Veamos la demostración a continuación.

Demostración. Sabemos que

$$\begin{aligned} S^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (X_i^2 - 2\bar{X}X_i + \bar{X}^2) \\ &= \frac{1}{n-1} \left[\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2 \right] \end{aligned}$$

$$\begin{aligned}
&= \frac{1}{n-1} \left[\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 \right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right]
\end{aligned}$$

Ya que, $\mathbb{E}[X_i] = \mathbb{E}[\bar{X}]$ y $\mathbb{V}[\bar{X}] = \mathbb{V}[X_i]/n = \sigma^2/n \ \forall i \in \{1, \dots, n\}$,

$$\begin{aligned}
\mathbb{E}[S^2] &= \frac{1}{n-1} \mathbb{E} \left[\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right] \\
&= \frac{1}{n-1} \left[\sum_{i=1}^n \mathbb{E}[X_i^2] - n\mathbb{E}[\bar{X}^2] \right] \\
&= \frac{n}{n-1} \left(\mathbb{E}[X_1^2] - \mathbb{E}[\bar{X}^2] \right) \\
&= \frac{n}{n-1} \left(\mathbb{V}[X_1] + (\mathbb{E}[X_1])^2 - \mathbb{V}(\bar{X}) - (\mathbb{E}[\bar{X}])^2 \right) \\
&= \frac{n}{n-1} \left(\sigma^2 - \frac{\sigma^2}{n} \right) = \sigma^2.
\end{aligned}$$

□

Una manera de evaluar la calidad de un estimador es mediante el error cuadrático medio (MSE, por sus siglas en inglés). El MSE de un estimador $T(\mathbf{X})$ de θ es

$$\text{MSE}(T(\mathbf{X})) \equiv \mathbb{E}[(T(\mathbf{X}) - \theta)^2].$$

Antes de entregar una interpretación más sencilla del MSE, definamos el sesgo (*bias*) como

$$\text{Bias}(T(\mathbf{X})) \equiv \mathbb{E}[T(\mathbf{X})] - \theta.$$

El MSE puede ser fácilmente interpretado como

$$\begin{aligned}
\text{MSE}(T(\mathbf{X})) &= \mathbb{E}[T^2] - 2\theta\mathbb{E}[T] + \theta^2 \\
&= \mathbb{E}[T^2] - (\mathbb{E}[T])^2 + (\mathbb{E}[T])^2 - 2\theta\mathbb{E}[T] + \theta^2 \\
&= \underbrace{\mathbb{V}(T)}_{\text{Varianza}} + \underbrace{(\mathbb{E}[T] - \theta)^2}_{\text{Sesgo}}.
\end{aligned}$$

Así, el MSE balancea el sesgo y la varianza de un estimador. Veremos este *trade-off* gráficamente a continuación. La Figura 5.3 presenta la denominada compensación sesgo-varianza (*bias-variance trade-off*), donde se refuerza la idea de que un buen estimador es aquel que posee una baja

varianza y un bajo sesgo.




Figura 5.3: Compensación sesgo-varianza

Como vimos, mientras menor es el MSE, mejor. Si $T_1(\mathbf{X})$ y $T_2(\mathbf{X})$ son dos estimadores de θ , por lo general, preferiríamos el que tiene el MSE más bajo, incluso si tiene un sesgo más alto. Ahora, en base a lo anterior, definiremos y presentaremos los estimadores de máxima verosimilitud como método para estimar los parámetros de una distribución. Primero, haremos algunas definiciones.

5.2.1. Estimadores de máxima verosimilitud

Considerar una muestra aleatoria iid $\{X_i\}_{i \in [n]}$, donde cada X_i está gobernada por nuestra pdf (o pmf) hipotetizada, $f(x)$. Además, suponer que θ es algún parámetro desconocido de X_i . La función *likelihood* es

$$\mathcal{L}(\theta|\mathbf{x}) \equiv \prod_{i=1}^n f(x_i|\theta)$$

que es equivalente a

$$\mathcal{L}(\theta) \equiv \prod_{i=1}^n f(x_i).$$

El estimador de máxima verosimilitud (*maximum likelihood estima-*

tor, MLE) de θ es el valor de θ que maximiza $\mathcal{L}(\theta)$. El MLE es una función de $\{X_i\}_{i \in [n]}$ y es, por lo tanto, una variable aleatoria. Veamos algunos ejemplos.

Ejemplo 5.5. Sean $X_1, \dots, X_n$ variables aleatorias iid $\text{Exp}(\lambda)$. Encontrar el MLE para λ . Primero, definimos la función likelihood,

$$\mathcal{L}(\lambda) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n \exp\left(-\lambda \sum_{i \in [n]} x_i\right).$$

Segundo, necesitamos maximizar $\mathcal{L}(\lambda)$ con respecto a λ . Esto podría ser algebraicamente tedioso, así que necesitamos algunos trucos.

Notar que el λ que maximiza $\mathcal{L}(\lambda)$ también maximiza $\ln(\mathcal{L}(\lambda))$. Así, aplicamos el logaritmo natural a la *likelihood* y definimos la función *log-likelihood*

$$\ln(\mathcal{L}(\lambda)) = \ln\left(\lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right)\right) = n \ln(\lambda) - \lambda \sum_{i=1}^n x_i.$$

Tercero, buscamos el punto (λ) que maximiza esta función. Para ello, derivamos la *log-likelihood* y la igualamos a 0. Es decir,

$$\frac{\partial}{\partial \lambda} \ln(\mathcal{L}(\lambda)) = \frac{\partial}{\partial \lambda} \left(n \ln(\lambda) - \lambda \sum_{i=1}^n x_i \right) = \frac{n}{\lambda} - \sum_{i=1}^n x_i \equiv 0.$$

Despejando, notamos que el MLE de λ es $\hat{\lambda} = n / \sum_{i=1}^n x_i = 1/\bar{X}$. Algunas observaciones son las siguientes:

1. $\hat{\lambda} = 1/\bar{X}$ hace sentido, pues $\mathbb{E}[X] = 1/\lambda$ en el caso exponencial.
2. Usamos un gorro ($\hat{\cdot}$) sobre λ para indicar que es el MLE.
3. Solo para tener cuidado, probablemente se debería realizar una prueba de segunda derivada.

Ejemplo 5.6. Sean $X_1, \dots, X_n$ variables aleatorias iid Bern(p). Encontrar el MLE para p .

$$\mathcal{L}(p) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}.$$

Ahora, maximizar $\mathcal{L}(\lambda)$ con respecto a λ podría ser algebraicamente tedioso, así que, al igual que antes, notar que el p que maximiza $\mathcal{L}(p)$ también maximiza $\ln(\mathcal{L}(p))$. Así

$$\ln(\mathcal{L}(p)) = \sum_{i=1}^n x_i \ln(p) + (n - \sum_{i=1}^n x_i) \ln(1-p).$$

Luego,

$$\frac{\partial}{\partial p} \ln(\mathcal{L}(p)) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} \equiv 0.$$

Esto implica que el MLE de p es $\hat{p} = \bar{X}$, lo cual es razonable, pues $\mathbb{E}[X] = p$.

Ejemplo 5.7. Suponer que $X_1, \dots, X_n$ son variables aleatorias iid $\mathcal{N}(\mu, \sigma^2)$. Encontrar los MLEs simultáneos para μ y σ^2 .

Solución:

$$\begin{aligned}\mathcal{L}(\mu, \sigma^2) &= \prod_{i=1}^n f(x_i) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2}\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}\right).\end{aligned}$$

Luego,

$$\ln(\mathcal{L}(\mu, \sigma^2)) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Por lo tanto,

$$\frac{\partial}{\partial \mu} \ln(\mathcal{L}(\mu, \sigma^2)) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) \equiv 0,$$

y así, $\hat{\mu} = \bar{X}$ (lo que hace sentido). Ahora, hacer lo mismo para σ^2 , y similarmente tomar la derivada parcial con respecto a σ^2 (no σ):

$$\frac{\partial}{\partial \sigma^2} \ln(\mathcal{L}(\mu, \sigma^2)) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \hat{\mu})^2 \equiv 0,$$

y eventualmente, obtener

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}.$$

Observación: notar qué tan cercano es $\hat{\sigma}^2$ de la varianza muestral (insesgada)

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1} = \frac{n}{n-1} \hat{\sigma}^2.$$

$\hat{\sigma}^2$ es un poco sesgado, pero tiene una varianza ligeramente menor que S^2 . De todos modos, cuando $n \rightarrow \infty$, S^2 y $\hat{\sigma}^2$ son iguales.

Ejemplo 5.8. Sean $X_1, \dots, X_n$ variables aleatorias iid $U(0, \theta)$. Encontrar el MLE para θ .

$$\mathcal{L}(\theta) = \prod_{i=1}^n f(x_i) = \begin{cases} \frac{1}{\theta^n} & 0 \leq x_i \leq \theta, \forall i \in \{1, \dots, n\} \\ 0 & \text{e.o.c.} \end{cases}.$$

Para asegurar que $\mathcal{L}(\theta) > 0$, debemos tener $0 \leq x_i \leq \theta$ para todo $i \in \{1, \dots, n\}$. En otras palabras, se debe tener $\theta \geq \max_i x_i$.

Considerando esta restricción, $\mathcal{L}(\theta) = 1/\theta^n$ se maximiza en el valor de θ más pequeño posible, i.e., $\hat{\theta} = \max_i X_i$.

Antes de continuar, veamos un hecho interesante, conocido como la propiedad de invarianza, junto con algunas de sus aplicaciones comunes.

Teorema 5.1 (Propiedad de invarianza). Si $\hat{\theta}$ es un MLE de θ y si $g(\cdot)$ es una función, entonces $g(\hat{\theta})$ es un MLE de $g(\theta)$.

Ejemplo 5.9. Suponer $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bern}(p)$. Considerar que el MLE de p es $\hat{p} = \bar{X}$ (que también es insesgado). Si consideramos la función $g(\theta) = \theta^2$ (para $\theta > 0$), entonces la propiedad de invarianza dice que el MLE de p^2 es $\bar{X}^2$.

Ejemplo 5.10. Sean $X_1, \dots, X_n$ variables aleatorias iid $\mathcal{N}(\mu, \sigma^2)$. Vimos que el MLE para σ^2 es

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

La buena noticia es que también podemos encontrar el MLE para σ . Si consideramos la función $g(\theta) = +\sqrt{\theta}$, entonces la propiedad de invarianza dice que el MLE de σ es

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

Ejemplo 5.11. Sean $X_1, \dots, X_n$ variables aleatorias iid $\text{Exp}(\lambda)$. Vimos que el MLE para λ es $\hat{\lambda} = 1/\bar{X}$. Mientras, definimos la función de supervivencia como

$$\bar{F}(x) = \mathbb{P}(X > x) = 1 - F(x) = e^{-\lambda x},$$

que representa la probabilidad de que un objeto sobreviva más allá de un cierto periodo (x). Luego, la propiedad de invarianza dice que el MLE de $\bar{F}(x)$ es

$$\hat{\bar{F}}(x) = e^{-\hat{\lambda}x} = e^{-x/\bar{X}}.$$

Este tipo de cosas es típicamente usado en la ciencia actuarial (disciplina que estudia matemática y estadísticamente el riesgo en seguros, inversiones, etc.).

5.2.2. Método de los momentos

Comencemos con un breve recordatorio. El k -ésimo momento de una variable aleatoria X se define como

$$\mathbb{E}[X^k] = \begin{cases} \sum_{x \in \mathbb{X}} x^k f(x) & \text{si } X \text{ es discreta} \\ \int_{x \in \mathbb{X}} x^k f(x) dx & \text{si } X \text{ es continua} \end{cases}.$$

Definición 5.3. Suponer que $\{X_i\}_{i \in [n]}$ son variables aleatorias iid de la pmf/pdf $f(x)$. Entonces, el estimador del método de los momentos (MOM) para $\mathbb{E}[X^k]$ es

$$m_k \equiv \frac{1}{n} \sum_{i=1}^n X_i^k.$$

Algunos ejemplos son los siguientes:

1. El estimador MOM para $\mu = \mathbb{E}[X_i]$ es

$$m_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

2. El estimador MOM para $\mathbb{E}[X_i^2]$ es

$$m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

3. El estimador MOM para $\mathbb{V}[X_i] = \mathbb{E}[X_i^2] - (\mathbb{E}[X_i])^2$ es

$$m_2 - m_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{n-1}{n} S^2.$$

Ejemplo 5.12. Suponer $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$. Los estimadores MOM para μ y σ^2 son $\bar{X}$ y $\frac{n-1}{n} S^2$, respectivamente. Para este ejemplo, estos estimadores son los mismos que los MLEs. Veamos a continuación un ejemplo menos trivial.

Ejemplo 5.13. Suponer $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Beta}(a, b)$. La pdf es

$$f(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, \quad 0 < x < 1.$$

Resulta (después de mucha álgebra) que

$$\begin{aligned} \mathbb{E}[X] &= \frac{a}{a+b} \\ \mathbb{V}[X] &= \frac{ab}{(a+b)^2(a+b+1)} = \frac{\mathbb{E}[X]b}{(a+b)(a+b+1)}. \end{aligned}$$

Estimemos a y b a través de MOM. Tenemos

$$\mathbb{E}[X] = \frac{a}{a+b} \implies a = \frac{b\mathbb{E}[X]}{1 - \mathbb{E}[X]} \approx \frac{b\bar{X}}{1 - \bar{X}}. \quad (\star)$$

Reemplazar lo siguiente en la ecuación anterior para $\mathbb{V}[X]$: $\bar{X}$ por $\mathbb{E}[X]$, S^2 por $\mathbb{V}[X]$, y $\frac{b\bar{X}}{1-\bar{X}}$ por a .

Después de harto álgebra, podemos resolver para b :

$$b \approx \frac{(1 - \bar{X})^2 \bar{X}}{S^2} - 1 + \bar{X}.$$

Para finalizar, reemplazar de vuelta en $(\star)$ para obtener el estimador MOM para a .

5.3. Pruebas de bondad de ajuste

Hasta el momento, hemos hipotetizado una distribución de probabilidad razonable y luego estimado sus parámetros asociados (con MLE o MOM). Ahora, realizaremos una prueba formal para ver cuán exitosos han sido nuestros esfuerzos.

Particularmente, nuestra prueba es

$$H_0 : X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} \text{pmf/pdf } f(x),$$

a un nivel de significancia

$$\alpha \equiv \mathbb{P}(\text{rechazar } H_0 | H_0 \text{ verdadera}) = \mathbb{P}(\text{error tipo I})$$

(usualmente, $\alpha = 0,05$ o $0,01$).

5.3.1. Prueba de bondad de ajuste chi-cuadrado (χ^2)

Un típico procedimiento de prueba de bondad de ajuste (GOF) es como sigue:

1. Dividir el dominio de $f(x)$ en k conjuntos, digamos $A_1, A_2, \dots, A_k$ (puntos distintos si X es discreta o intervalos si X es continua).
2. Contar el número de observaciones que entran en cada conjunto, digamos, O_i , $i = 1, 2, \dots, k$. Si $p_i \equiv \mathbb{P}(X \in A_i)$, entonces $O_i \sim \text{Bin}(n, p_i)$.
3. Determinar el número esperado de observaciones que habrían de entrar en cada conjunto si H_0 fuera verdadera, es decir, $E_i = \mathbb{E}[O_i] = np_i$, $i = 1, 2, \dots, k$.
4. Calcular un estadístico de prueba en base a las diferencias entre los E_i 's y O_i 's. El estadístico de prueba GOF chi-cuadrado corresponde a

$$\chi_0^2 \equiv \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}.$$

5. Un valor alto de χ_0^2 indica un mal ajuste. Así,

- Rechazamos H_0 si $\chi_0^2 > \chi_{\alpha, k-1-s}^2$, donde
 - s es el número de parámetros desconocidos de $f(x)$ que tienen que ser estimados. E.g., si $X \sim \mathcal{N}(\mu, \sigma^2)$, entonces $s = 2$.

- $\chi_{\alpha,\nu}^2$ es el cuantil $(1-\alpha)$ de la distribución χ_ν^2 , i.e., $\mathbb{P}(\chi_\nu^2 < \chi_{\alpha,\nu}^2) = 1 - \alpha$.
- Si $\chi_0^2 \leq \chi_{\alpha,k-1-s}^2$, fallamos en rechazar H_0 .

Observación 5.3. Algunas observaciones:

- Recomendación típica: para que funcione la prueba GOF χ^2 , elegir k , n tales que $E_i \geq 5$ y $n \geq 30$.
- Si los grados de libertad $\nu = k - 1 - s$ son muy grandes, entonces

$$\chi_{\alpha,\nu}^2 \approx \nu \left[1 - \frac{2}{9\nu} + z_\alpha \sqrt{\frac{2}{9\nu}} \right]^3,$$

donde z_α es el cuantil normal estándar apropiado.

- Otras pruebas GOF: Kolmogorov-Smirnov, Anderson-Darling, Shapiro-Wilk, etc.

Ejemplo 5.14. Probar H_0 : X_i 's son $U(0, 1)$. Suponer que tenemos $n = 1000$ observaciones divididas en $k = 5$ intervalos:

| Intervalo | $[0,0; 0,2)$ | $[0,2; 0,4)$ | $[0,4; 0,6)$ | $[0,6; 0,8)$ | $[0,8; 1,0]$ |
|-----------|--------------|--------------|--------------|--------------|--------------|
| E_i | 200 | 200 | 200 | 200 | 200 |
| O_i | 179 | 208 | 222 | 199 | 192 |

Resulta que $\chi_0^2 \equiv \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} = 5,27$.

Tomemos $\alpha = 0,05$. No hay parámetros inciertos, así que $s = 0$.

Luego, de las tablas χ^2 , tenemos

$$\chi_{\alpha,k-1-s}^2 = \chi_{0,05,4}^2 = 9,49.$$

Ya que $\chi_0^2 < \chi_{\alpha,k-1-s}^2$, fallamos en rechazar H_0 , y asumiremos que las observaciones son aproximadamente uniforme.

Veamos un ejemplo de una variable aleatoria discreta. Supongamos que el número de tiros libres que se necesitan hasta que se anote un gol sigue una distribución $\text{Geo}(p)$. Se ha recolectado una muestra aleatoria de $n = 70$ conjuntos de tiros libres intentados, y el número de tiros hasta anotar un gol se observa para cada uno de los 70 conjuntos

| Tiros hasta el gol (x_i) | Frecuencia (O_i) |
|------------------------------|----------------------|
| 1 | 34 |
| 2 | 18 |
| 3 | 2 |
| 4 | 9 |
| 5 | 7 |
| <hr/> | |
| | 70 |

Probaremos H_0 : las observaciones son $\text{Geom}(p)$. Comenzaremos estimando p a través de MLE. La función *likelihood* es

$$\begin{aligned}\mathcal{L}(p) &= \prod_{i=1}^n f(x_i) = \prod_{i=1}^n (1-p)^{x_i-1} p = (1-p)^{\sum_{i=1}^n x_i - n} p^n \\ \ln(\mathcal{L}(p)) &= \left(\sum_{i=1}^n x_i - n \right) \ln(1-p) + n \ln(p) \\ \frac{\partial \ln(\mathcal{L}(p))}{\partial p} &= \frac{-\sum_{i=1}^n x_i + n}{1-p} + \frac{n}{p} = 0.\end{aligned}$$

Resolviendo para p , se obtiene el MLE

$$\hat{p} = \frac{1}{\bar{X}} = \frac{1}{\sum_{i=1}^5 x_i \cdot (O_i/n)} \equiv \frac{1}{(1(34) + 2(18) + 3(2) + 4(9) + 5(7))/70} = 0,476.$$

Obtengamos el estadístico de prueba GOF, χ_0^2 . Crearemos una pequeña tabla, asumiendo que $\hat{p} = 0,476$ es correcto. Por la propiedad de invarianza de los MLEs, el número esperado de conjuntos de tiros que tienen un cierto valor x es $E_x = n\mathbb{P}(X = x) = n(1-\hat{p})^{x-1}\hat{p}$. Notar que combinaremos las entradas de la última fila (≥ 5) para que las probabilidades sumen uno

| x | $\mathbb{P}(X = x)$ | E_x | O_x |
|----------|---------------------|-------|-------|
| 1 | 0,4762 | 33,33 | 34 |
| 2 | 0,2494 | 17,46 | 18 |
| 3 | 0,1307 | 9,15 | 2 |
| 4 | 0,0684 | 4,79 | 9 |
| ≥ 5 | 0,0752 | 5,27 | 7 |
| <hr/> | | | |
| | 1,00 | 70 | 70 |

Realmente, deberíamos combinar las dos últimas celdas también, pues $E_4 = 4,79 < 5$ (recordar la recomendación de $E_i \geq 5$). Hagámoslo para obtener la siguiente tabla mejorada

| x | $\mathbb{P}(X = x)$ | E_x | O_x |
|----------|---------------------|-------|-------|
| 1 | 0,4762 | 33,33 | 34 |
| 2 | 0,2494 | 17,46 | 18 |
| 3 | 0,1307 | 9,15 | 2 |
| ≥ 4 | 0,1436 | 10,6 | 16 |
| | 1,00 | 70 | 70 |

Por lo tanto, el estadístico de prueba es

$$\chi_0^2 = \sum_{x=1}^4 \frac{(O_x - E_x)^2}{E_x} = \frac{(34 - 33,33)^2}{33,33} + \dots = 9,12.$$

Sea $k = 4$ el número de celdas (con las que terminamos), y sea $s = 1$ el número de parámetros que estimamos. Suponer el nivel $\alpha = 0,05$. Luego, comparamos χ_0^2 contra $\chi_{\alpha, k-1-s}^2 = \chi_{0,05,2}^2 = 5,99$. Ya que $\chi_0^2 > \chi_{\alpha, k-1-s}^2$, rechazamos H_0 . Esto significa que el número de tiros probablemente no es geométrico.

Observación 5.4 (Pruebas GOF para distribuciones continuas).

Para el caso continuo, denotemos los intervalos $A_i \equiv (a_{i-1}, a_i]$, $i = 1, 2, \dots, k$. Por conveniencia, elegimos los a_i 's para asegurar que tengan intervalos de igual probabilidad, i.e.,

$$p_i = \mathbb{P}(X \in A_i) = \mathbb{P}(a_{i-1} < X \leq a_i) = \frac{1}{k} \quad \forall i.$$

En este caso, inmediatamente tenemos $E_i = n/k$ para todo i . Luego,

$$\chi_0^2 = \sum_{i=1}^k \frac{(O_i - (n/k))^2}{n/k}.$$

El problema es que los a_i 's pueden depender de los parámetros desconocidos.

Veamos un ejemplo a partir de lo anterior. Suponer que estamos interesados en ajustar una distribución a una serie de tiempos entre llegadas. ¿Podrán ser exponenciales? Probaremos

$$H_0 : X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda).$$

Hagamos una prueba GOF χ^2 con intervalos equiprobables. Esto equivale

a elegir a_i 's tales que

$$F(a_i) = \mathbb{P}(X \leq a_i) = 1 - e^{-\lambda a_i} = \frac{i}{k}, \quad i = 1, 2, \dots, k.$$

Esto es,

$$a_i = -\frac{1}{\lambda} \ln \left(1 - \frac{i}{k} \right), \quad i = 1, 2, \dots, k.$$

Bien, pero λ es desconocido (así que, estimaremos $s = 1$ parámetros). Buenas noticias: sabemos que el MLE es $\hat{\lambda} = 1/\bar{X}$. Por lo tanto, por la propiedad de invarianza, los MLEs de los a_i 's son

$$\hat{a}_i = -\frac{1}{\hat{\lambda}} \ln \left(1 - \frac{i}{k} \right) = -\bar{X} \ln \left(1 - \frac{i}{k} \right), \quad i = 1, 2, \dots, k.$$

Suponer que tomamos $n = 100$ observaciones y las dividimos en $k = 5$ intervalos. Además, suponer que la media muestral basada en las 100 observaciones es $\bar{X} = 9$. Luego,

$$\hat{a}_i = -9 \ln(1 - 0,2i), \quad i = 1, 2, \dots, 5.$$

Suponer que determinamos a qué intervalo pertenece cada una de las 100 observaciones y las sumamos para obtener los O_i 's, obteniendo lo siguiente

| Intervalo $(\hat{a}_{i-1}, \hat{a}_i]$ | O_i | $E_i = n/k$ |
|--|-------|-------------|
| $(0; 2,01]$ | 25 | 20 |
| $(2,01; 4,60]$ | 27 | 20 |
| $(4,60; 8,25]$ | 23 | 20 |
| $(8,25; 14,48]$ | 13 | 20 |
| $(14,48; \infty]$ | 12 | 20 |
| | 100 | 100 |

Entonces, tenemos $\chi_0^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} = 9,8$ y $\chi_{\alpha, k-1-s}^2 = \chi_{0,05,3}^2 = 7,81$. Así que, rechazamos H_0 . Estas observaciones no son exponenciales.

5.3.2. Prueba de bondad de ajuste Kolmogórov-Smirnov

A continuación, detallaremos el procedimiento de la prueba de bondad de ajuste Kolmogórov-Smirnov (KS), que trabaja bien en situaciones de pocos datos. Por supuesto, la hipótesis nula corresponde a

$$H_0 : X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} \text{alguna distribución con cdf } F(x).$$

Recordar la definición de la cdf empírica de los datos $X_1, X_2, \dots, X_n$,

$$\hat{F}_n(x) \equiv \frac{\text{número de } X_i\text{'s } \leq x}{n}.$$

Notar que $\hat{F}_n(x)$ es una función escalonada con saltos de altura $1/n$ (cada vez que ocurre una observación). Por ejemplo, en la Figura 5.4 se presenta la cdf empírica de 10, 50, 100 y 500 observaciones $\mathcal{N}(0, 1)$ generadas aleatoriamente (junto con la cdf $\mathcal{N}(0, 1)$ teórica).




Figura 5.4: Comparación de distribución normal estándar teórica versus empírica en base a 10, 50, 100 y 500 observaciones

El lema Glivenko-Cantelli dice que $\hat{F}_n(x) \rightarrow F(x)$ para todo x cuando $n \rightarrow \infty$. Así que, si H_0 es verdadera, entonces $\hat{F}_n(x)$ debe ser una buena aproximación a la verdadera cdf, $F(x)$, para n grande. Principal pregunta: ¿La distribución empírica realmente respalda el supuesto de que H_0 es verdadera? La prueba K-S rechaza H_0 si

$$D \equiv \max_{x \in \mathbb{R}} |F(x) - \hat{F}_n(x)| > D_{\alpha, n},$$

donde α es el nivel de significancia, y $D_{\alpha, n}$ es un cuantil K-S que depende de la cdf hipotética $F(x)$. Veamos un ejemplo simplificado y explicativo de su aplicación.

Antes de dar un algoritmo sencillo para calcular D , primero definamos los puntos ordenados, $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$. Por ejemplo, si $X_1 = 4$, $X_2 = 1$ y $X_3 = 6$, entonces $X_{(1)} = 1$, $X_{(2)} = 4$ y $X_{(3)} = 6$. La Figura 5.5 presenta un ejemplo de cómo quedaría la distribución empírica en base a las tres observaciones anteriores, junto con la distribución teórica (desconocida, pero asumimos que la conocemos para este ejemplo).




Figura 5.5: Ejemplo de distribución empírica y teórica

Luego, calculamos

$$D^+ \equiv \max_{1 \leq i \leq n} \left\{ \frac{i}{n} - F(X_{(i)}) \right\}$$

$$D^- \equiv \max_{1 \leq i \leq n} \left\{ F(X_{(i)}) - \frac{i-1}{n} \right\},$$

y finalmente resulta que

$$D = \max(D^+, D^-).$$

Ahora, veamos un ejemplo numérico para complementar el anterior. Supongamos que contamos con cinco observaciones $\mathbf{X} = \{0,039, 0,706, 0,016, 0,198, 0,793\}$. Supongamos también que realizaremos la prueba KS para corroborar si estas observaciones provienen de una distribución uniforme $U(0, 1)$. Recordar que, en el caso de la distribución uniforme (con parámetros a y b , de manera general), la cdf viene dada por $F_X(x) = \frac{x-a}{b-a}$. Por lo tanto, para el caso $U(0, 1)$, la cdf se simplifica y corresponde a $F_X(x) = x$. A continuación, seguimos con el ejemplo.

Ejemplo 5.15. Considerando la descripción anterior, tenemos lo siguiente.

| | | | | | |
|------------------------------|-------|--------|--------|-------|--------|
| $F(X_i) = X_i$ | 0,039 | 0,706 | 0,016 | 0,198 | 0,793 |
| $F(X_{(i)}) = X_{(i)}$ | 0,016 | 0,039 | 0,198 | 0,706 | 0,793 |
| $\frac{i}{n}$ | 0,2 | 0,4 | 0,6 | 0,8 | 1,0 |
| $\frac{i-1}{n}$ | 0 | 0,2 | 0,4 | 0,6 | 0,8 |
| $\frac{i}{n} - F(X_{(i)})$ | 0,184 | 0,361 | 0,402 | 0,094 | 0,207 |
| $F(X_{(i)}) - \frac{i-1}{n}$ | 0,016 | -0,161 | -0,202 | 0,106 | -0,007 |

Por lo tanto, $D^+ = 0,402$, $D^- = 0,106$, y luego $D = 0,402$. Si vamos a una tabla KS para la distribución uniforme, tenemos $D_{\alpha;n} = D_{0,05;5} = 0,563$. Así que, fallamos en rechazar la uniformidad. Dicha tabla se puede observar a continuación.

| n | Nivel de significancia (α) | | | | | | |
|---------|-------------------------------------|----------------------------|----------------------------|----------------------------|----------------------------|----------------------------|----------------------------|
| | 0.001 | 0.01 | 0.02 | 0.05 | 0.1 | 0.15 | 0.2 |
| 1 | - | 0.99500 | 0.99000 | 0.97500 | 0.95000 | 0.92500 | 0.90000 |
| 2 | 0.97764 | 0.92930 | 0.90000 | 0.84189 | 0.77639 | 0.72614 | 0.68377 |
| 3 | 0.92063 | 0.82900 | 0.78456 | 0.70760 | 0.63604 | 0.59582 | 0.56481 |
| 4 | 0.85046 | 0.73421 | 0.68887 | 0.62394 | 0.56522 | 0.52476 | 0.49265 |
| 5 | 0.78137 | 0.66855 | 0.62718 | 0.56327 | 0.50945 | 0.47439 | 0.44697 |
| 6 | 0.72479 | 0.61660 | 0.57741 | 0.51926 | 0.46799 | 0.43526 | 0.41035 |
| 7 | 0.67930 | 0.57580 | 0.53844 | 0.48343 | 0.43607 | 0.40497 | 0.38145 |
| 8 | 0.64098 | 0.54180 | 0.50654 | 0.45427 | 0.40962 | 0.38062 | 0.35828 |
| 9 | 0.60846 | 0.51330 | 0.47960 | 0.43001 | 0.38746 | 0.36006 | 0.33907 |
| 10 | 0.58042 | 0.48895 | 0.45662 | 0.40925 | 0.36866 | 0.34250 | 0.32257 |
| 11 | 0.55588 | 0.46770 | 0.43670 | 0.39122 | 0.35242 | 0.32734 | 0.30826 |
| 12 | 0.53422 | 0.44905 | 0.41918 | 0.37543 | 0.33815 | 0.31408 | 0.29573 |
| 13 | 0.51490 | 0.43246 | 0.40362 | 0.36143 | 0.32548 | 0.30233 | 0.28466 |
| 14 | 0.49753 | 0.41760 | 0.38970 | 0.34890 | 0.31417 | 0.29181 | 0.27477 |
| 15 | 0.48182 | 0.40420 | 0.37713 | 0.33760 | 0.30397 | 0.28233 | 0.26585 |
| 16 | 0.46750 | 0.39200 | 0.36571 | 0.32733 | 0.29471 | 0.27372 | 0.25774 |
| 17 | 0.45440 | 0.38085 | 0.35528 | 0.31796 | 0.28627 | 0.26587 | 0.25035 |
| 18 | 0.44234 | 0.37063 | 0.34569 | 0.30936 | 0.27851 | 0.25867 | 0.24356 |
| 19 | 0.43119 | 0.36116 | 0.33685 | 0.30142 | 0.27135 | 0.25202 | 0.23731 |
| 20 | 0.42085 | 0.35240 | 0.32866 | 0.29407 | 0.26473 | 0.24587 | 0.23152 |
| 25 | 0.37843 | 0.31656 | 0.30349 | 0.26404 | 0.23767 | 0.22074 | 0.20786 |
| 30 | 0.34672 | 0.28988 | 0.27704 | 0.24170 | 0.21756 | 0.20207 | 0.19029 |
| 35 | 0.32187 | 0.26898 | 0.25649 | 0.22424 | 0.20184 | 0.18748 | 0.17655 |
| 40 | 0.30169 | 0.25188 | 0.23993 | 0.21017 | 0.18939 | 0.17610 | 0.16601 |
| 45 | 0.28482 | 0.23780 | 0.22621 | 0.19842 | 0.17881 | 0.16626 | 0.15673 |
| 50 | 0.27051 | 0.22585 | 0.21460 | 0.18845 | 0.16982 | 0.15790 | 0.14886 |
| OVER 50 | $\frac{1.94947}{\sqrt{n}}$ | $\frac{1.62762}{\sqrt{n}}$ | $\frac{1.51743}{\sqrt{n}}$ | $\frac{1.35810}{\sqrt{n}}$ | $\frac{1.22385}{\sqrt{n}}$ | $\frac{1.13795}{\sqrt{n}}$ | $\frac{1.07275}{\sqrt{n}}$ |

En definitiva, el estadístico D puede ser determinado al calcular

$$D^+ = \max_{1 \leq i \leq n} \left\{ \frac{i}{n} - F(X_{(i)}) \right\}, \quad D^- = \max_{1 \leq i \leq n} \left\{ F(X_{(i)}) - \frac{i-1}{n} \right\},$$

y definiendo $D = \max\{D^+, D^-\}$.

Observación 5.5. Algunas fórmulas incorrectas son a menudo propuestas para D . En particular, a veces se ve que

$$D' = \max_{1 \leq i \leq n} \left\{ \left| \frac{i}{n} - F(X_{(i)}) \right| \right\}$$

es propuesto para D . Hay veces en que efectivamente $D' = D$, pero no siempre es así, pues hay veces en que $D' \neq D$.

A continuación podemos ver un ejemplo a partir de la Observación 5.5 en la Figura 5.6. En el gráfico superior se puede ver la correcta aplicación de nuestro estadístico D , mientras que en el gráfico superior se observa claramente que D no es igual a D' .




Figura 5.6: Comparación de estadístico D y D'

5.4. Problemas comunes

Siempre existe algún problema del que nadie quiere hablar, pero cada proyecto de simulación los tiene. Uno pensaría que después de toda la teoría que hemos analizado, siempre podríamos encontrar buenas distribuciones que se ajuste a nuestros datos. Pero, ¡no exactamente! Aquí hay algunos casos con los cuales hay que tener cuidado:

1. Ausencia o insuficiencia de datos.
2. Datos que no se parecen a ninguna de las distribuciones usuales.
3. Datos no estacionarios (distribución que cambia dinámicamente).
4. Datos multivariados y correlacionados.

Este problema aparece más a menudo de lo que uno esperaría, ¡incluso en la era del *big data*! Literalmente, podría no haber datos disponibles, o los datos que se tienen son horribles. Entonces, ¿qué hacemos? Para ser honestos, no hay grandes opciones, pero aquí hay algunas de ellas:

1. Entrevistar a los denominados “expertos”:
 - Intentar de obtener al menos valores mínimos, máximos y “más probables” para luego probar distribuciones como la uniforme, triangular o Pert.
 - Obtener cuantiles.
 - Al menos discutir la naturaleza de las observaciones.
2. Si se tiene alguna idea acerca de la naturaleza de las variables aleatorias, tal vez se pueda hacer una buena estimación de la distribución:
 - ¿Discreta o continua?
 - ¿Las observaciones son éxitos/fallos?—Pensar en Bernoulli, binomial, geométrica, binomial negativa.
 - ¿Las observaciones adhieren a los supuestos de Poisson? Entonces, Poisson (si se están contando llegadas) o exponencial (tiempos entre llegadas).
 - ¿Las observaciones son promedios o sumas? Entonces, quizás normal.
 - ¿Las observaciones están acotadas? Entonces, pensar en beta.
 - ¿Confiabilidad o tiempos de trabajo? Quizás gamma, Weibull, lognormal, etc.
 - ¿Se puede pensar en algo más a partir de las características físicas subyacentes a la variable aleatoria?

En la Figura 5.7 se presenta una mezcla de gaussianas forzada (color *cyan*). La mayoría de *packages* no pueden ajustarlas correctamente, y hacen ajustes como el de la gaussiana magenta.




Figura 5.7: Ajuste incorrecto de una distribución normal a un conjunto de datos bimodal

Algunas alternativas para este caso podrían ser:

- Se puede intentar modelar como una mezcla de distribuciones razonables.
- Más fácil: se pueden tomar muestras de la distribución empírica o de una versión suavizada de la empírica. Esta es una forma de *bootstrapping*.

Por otra parte, pensar, por ejemplo, en tasas de llegada que cambian en el tiempo—pensar en restaurantes, bancos, tráfico en carreteras, *call centers*, demandas estacionales, etc. Esta variabilidad debe ser tomada en cuenta. ¡Recordar GIGO! Para ello:

- Sugerencia: proceso de Poisson no homogéneo. Algunos *software* como Simio puede fácilmente lidiar con esto.
- Se necesita modelar la tasa correctamente.
- En Simio se puede especificar una tasa de llegada constante distinta para cada periodo por separado.

Hasta ahora, hemos hablado de la importancia del supuesto iid. Pero, ¿todos los fenómenos tienen que ser iid? ¿Qué pasa si los datos poseen correlación temporal y/o espacial? O, ¿si los datos son multivariados? Un ejemplo clásico de datos altamente correlacionados espacio-temporalmente son los caudales afluentes de una red hidroeléctrica como muestra la Figura 5.8.




Figura 5.8: Ejemplo de datos correlacionados

Algunos otros ejemplos de datos multivariados o correlacionados podrían ser:

- Variable aleatoria multivariada: la edad y peso de una persona están correlacionadas.
- Ejemplos de correlación temporal:
 - Tasas de desempleo mensuales.
 - Entradas a un sitio web pueden estar correlacionadas si hay algo interesante ahí.
 - Una pieza muy dañada puede requerir más servicio de lo normal.
 - Si un servidor se cansa, sus tiempos de servicio pueden ser más largos.

Entonces, ¿qué necesitamos hacer?

- Identificar correlación serial o si los datos son multivariados.
- Proponer modelos apropiados. Algunos ejemplos:
 - Normal multivariada.
 - Modelos de mezcla de gaussianas (GMM).
 - Modelos de series de tiempo, e.g., $AR(p)$, $VAR(p)$, $ARMA(p, q)$, etc.
- Estimar parámetros relevantes (más fácil decir que hacer). Ejemplos:
 - Normal multivariada: medias y varianzas marginales, más covarianzas.

- Series de tiempo: para modelos $AR(p)$ estimar coeficientes autorregresivos es fácil. Para modelos más complicados deben estimarse utilizando técnicas más sofisticadas.
- Validar para ver si el modelo estimado es realmente bueno.
- Alternativa: muestrear desde distribución empírica (si hay datos suficientes).

Capítulo 6

Análisis del Output

En muchos estudios de simulación se invierte mucho tiempo y recursos en el desarrollo y programación de modelos, pero poco esfuerzo es puesto en analizar sus datos de *output* (salida) apropiadamente. Un modo común de operación es ejecutar una única y arbitraria corrida de la simulación para luego tratar los resultados como los “verdaderos” *outputs*. Una única corrida de la simulación sólo tiene una realización de las variables aleatorias involucradas, así que en tal caso ¡estamos ignorando los efectos deseados de la variabilidad!. No olvidar que un proyecto de simulación puede ser visto como un experimento de muestreo estadístico basado en computadores, así que apropiadas técnicas estadística deben ser usadas para diseñar y analizar los experimentos de la simulación.

Observación 6.1 (Principal preocupación). Virtualmente, todas las simulaciones son no estacionarias y autocorrelacionadas. Por lo tanto, las técnicas estadísticas clásicas basadas en supuestos iid no son directamente aplicables.

Definición 6.1. Un proceso estocástico es una colección de variables aleatorias “similares” ordenadas en el tiempo $\{Y_t, t \in \mathcal{T}\}$, definida sobre un espacio de probabilidad común $(\Omega, \mathcal{F}, \mathbb{P})$.

Sea $Y_1, Y_2, \dots$ el *output* de un proceso estocástico de una única corrida de la simulación. Por ejemplo, Y_i puede ser el número de clientes en un banco en la i -ésima hora. Los Y_i 's son variables aleatorias que no serán ni independientes ni idénticamente distribuidas.

Sea $y_{11}, y_{12}, \dots, y_{1m}$ una realización de las variables aleatorias $Y_1, Y_2, \dots, Y_m$ resultantes de una corrida de la simulación de largo m observacio-

nes usando los números aleatorios $u_{11}, u_{12}, \dots, u_{1m}$, donde u_{ji} representa el i -ésimo número aleatorio usado en la j -ésima corrida. Si corremos la simulación con diferentes números aleatorios $u_{21}, u_{22}, \dots, u_{2m}$, entonces obtendríamos una diferente realización $y_{21}, y_{22}, \dots, y_{2m}$. Las dos realizaciones no son iguales, ya que los diferentes números aleatorios usados en las dos corridas producen diferentes muestras de las distribuciones de probabilidad de *input*.

Suponer ahora que corremos n réplicas independientes de la simulación de largo m , resultando en las observaciones:

$$\begin{array}{ccccccc} y_{11}, & \dots, & y_{1i}, & \dots, & y_{1m} \\ y_{21}, & \dots, & y_{2i}, & \dots, & y_{2m} \\ \vdots & & \vdots & & \vdots \\ y_{n1}, & \dots, & y_{ni}, & \dots, & y_{nm} \end{array}$$

Las observaciones de una réplica (fila) particular claramente no son iid. Sin embargo, notar que $y_{1i}, y_{2i}, \dots, y_{ni}$ (la i -ésima columna) son observaciones iid de la variable aleatoria Y_i para todo $i = 1, 2, \dots, m$. Esta independencia a través de las corridas es la clave para los métodos de análisis del *output* relativamente simples que veremos en este capítulo.

Observación 6.2 (Objetivo del análisis del *output*). Más o menos, el objetivo del análisis del *output* es usar las observaciones y_{ji} para hacer inferencias sobre $\{Y_i\}_{i \in [m]}$. Por ejemplo, $\bar{y}_i(n) = \sum_{j=1}^n \frac{y_{ji}}{n}$ es una estimación insesgada de $\mathbb{E}(Y_i)$.

Ejemplo 6.1. Considerar un banco con cinco cajeros y una fila, que abre sus puertas a las 9:00, las cierra a las 17:00, pero se mantiene abierto hasta que todos los clientes en el banco han sido atendidos. Asumir que los tiempos entre llegadas de los clientes son variables aleatorias exponenciales iid con media 1 minuto, que los tiempos de servicio son variables aleatorias exponenciales iid con media 4 minutos, y que los clientes son atendidos FIFO. La siguiente tabla muestra estadísticas de *output* de 10 réplicas independientes, suponiendo que el banco comienza vacío. Considerar KPI_1 = clientes atendidos, KPI_2 = tiempo de cierre (horas), KPI_3 = retraso medio en la fila (minutos), KPI_4 = largo medio de la fila, y KPI_5 = proporción de clientes atendidos en menos de cinco minutos.

| Réplica | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|---------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| KPI_1 | 484 | 475 | 484 | 483 | 455 | 461 | 451 | 486 | 502 | 475 |
| KPI_2 | 8,12 | 8,14 | 8,19 | 8,03 | 8,03 | 8,32 | 8,09 | 8,19 | 8,15 | 8,24 |
| KPI_3 | 1,53 | 1,66 | 1,24 | 2,34 | 2,00 | 1,69 | 2,69 | 2,86 | 1,70 | 2,60 |
| KPI_4 | 1,52 | 1,62 | 1,23 | 2,34 | 1,89 | 1,56 | 2,50 | 2,83 | 1,74 | 2,50 |
| KPI_5 | 0,917 | 0,916 | 0,952 | 0,822 | 0,840 | 0,866 | 0,783 | 0,782 | 0,873 | 0,779 |

Notar que los resultados de varias réplicas pueden ser muy diferentes. Por lo tanto, una corrida claramente no produce “las respuestas”.

El objetivo de este capítulo es discutir métodos de análisis estadístico de los datos obtenidos a partir de una simulación. Discutiremos algunos métodos importantes para el análisis del *output*. Sin embargo, el énfasis estará en procedimientos estadísticos que son relativamente fáciles de implementar. Mostraremos cómo obtener un estimador puntual $\hat{\theta}$ y un intervalo de confianza para cada tipo de parámetro θ (como la media), con el intervalo de confianza típicamente requiriendo una estimación de $\mathbb{V}[\hat{\theta}]$. Cada método de análisis discutido puede sufrir uno o ambos de los siguientes problemas:

1. $\hat{\theta}$ no es un estimador insesgado de θ , es decir, $\mathbb{E}[\hat{\theta}] \neq \theta$.
2. $\hat{\mathbb{V}}[\hat{\theta}]$ no es un estimador insesgado de $\mathbb{V}[\hat{\theta}]$.

6.1. Comportamiento transiente y de estado estable de un proceso estocástico

Considerar el proceso estocástico de *output* $Y_1, Y_2, \dots$. Sea $F_i(y|I) = \mathbb{P}(Y_i \leq y|I)$ para $i = 1, 2, \dots$, donde $y \in \mathbb{R}$ e I representa las condiciones iniciales de la simulación. Por ejemplo, para un sistema de manufactura, I podría especificar el número de trabajadores presentes, y si cada máquina está libre u ocupada en el tiempo 0.

Observación 6.3 (Distribución transiente). Llamamos $F_i(y|I)$ a la distribución transiente del proceso de *output* en el punto (discreto) de tiempo i para las condiciones iniciales I .

Observación 6.4 (Distribución de estado estable). Para y e I fijos, las probabilidades $F_1(y|I), F_2(y|I), \dots$, son sólo una secuencia de números. Si $F_i(y|I) \rightarrow F(y)$ cuando $i \rightarrow \infty$ para todo y y para I , entonces $F(y)$ se denomina distribución de estado estable (estacionario) del proceso de *output* $Y_1, Y_2, \dots$.

La Figura 6.1 presenta un ejemplo de las distribuciones transientes y de estado estable de un proceso estocástico.




Figura 6.1: Comportamiento transiente y de estado estable de un proceso estocástico

Algunas observaciones son las siguientes:

- Estrictamente hablando, la distribución de estado estable $F(y)$ es

sólo obtenida en $i \rightarrow \infty$.

- En la práctica, siempre tenemos índices de tiempo finitos, digamos $k + 1$, tal que la distribución a partir de este punto será aproximadamente la misma que la otra.
- El estado estable no significa que las variables aleatorias $Y_{k+1}, Y_{k+2}, \dots$ tomarán todas el mismo valor en una corrida particular de la simulación. Más bien, significa que todas tendrán aproximadamente la misma distribución.

Ejemplo 6.2. Considerar el proceso estocástico $D_1, D_2, \dots$ para el sistema M/M/1 con $\rho = 0,9$ ($\lambda = 1$, $\mu = 10/9$ minutos), donde D_i es el retraso en la fila del i -ésimo cliente. La Figura 6.2 muestra la convergencia de la media transiente $\mathbb{E}[D_i]$ a la media de estado estable $d = \mathbb{E}[D] = W_q = \frac{\lambda}{\mu(\mu-\lambda)} = 8,1$ cuando i se hace grande para distintos valores del número en el sistema en $t = 0$.




Figura 6.2: Comportamiento de proceso estocástico en base a distintas condiciones iniciales

Observación 6.5. Hecho importante En el Ejemplo 6.2, se analizó la convergencia del valor esperado $\mathbb{E}[Y_i]$ a la media de estado estable $\mathbb{E}[Y]$. Se debe recordar, sin embargo, que la distribución entera de Y_i está también convergiendo a la distribución de Y cuando i se hace grande.

6.2. Tipos de simulación basados en análisis del *output*

Las opciones disponibles para diseñar y analizar experimentos de simulación dependen del tipo de simulación a la mano, como lo muestra la Figura 6.3. Aún más, las medidas de desempeño o parámetros para las simulaciones no terminales pueden ser de varios tipos.




Figura 6.3: Tipos de simulación en base al análisis del *output*

Una simulación terminal es aquella para la cual existe un evento “natural” E que especifica el largo de cada corrida (réplica). El evento E a menudo ocurre en un punto de tiempo donde el sistema se “limpia” (Ejemplo 6.3), en un punto de tiempo más allá del cual no se obtiene información útil (Ejemplo 6.4), o en un punto de tiempo especificado por un mandato de gestión (Ejemplo 6.5).

Ejemplo 6.3. Un establecimiento, por ejemplo, un banco, cierra cada tarde. Si el establecimiento está abierto de 9:00 a 17:00, el objetivo de una simulación podría ser estimar alguna medida de la calidad del servicio al cliente durante el periodo que comienza a las 9:00 y finaliza cuando se ha atendido al último cliente que ingresó antes de que se cerraran las puertas a las 17:00. En este caso, $E = \{\text{han transcurrido al menos 8 horas de tiempo simulado y el sistema está vacío}\}$.

Ejemplo 6.4. Considerar una confrontación militar terrestre entre una fuerza azul y una roja. En relación con algunos puntos fuertes iniciales de la fuerza, el objetivo de una simulación podría ser determinar los puntos fuertes (finales) de la fuerza cuando termina la batalla. En este caso, $E = \{\text{alguna de las fuerzas "ganó" la batalla}\}$. Un ejemplo de una condición que terminaría la batalla es que un bando pierda el 30 % de su fuerza, ya que este bando ya no se consideraría viable. La elección de las condiciones iniciales, e.g., el número de tropas y tanques para cada fuerza, para la simulación generalmente no es un problema aquí, ya que están especificadas por el escenario militar en consideración.

Ejemplo 6.5. A una compañía que vende un único producto le gustaría decidir cuántos elementos tener en inventario durante un horizonte de planificación de 120 meses. Dado cierto nivel inicial del inventario, el objetivo podría ser determinar cuánto ordenar en cada mes, de tal forma de minimizar el costo total esperado de la operación del sistema de inventario. En este caso, $E = \{120 \text{ meses han sido simulados}\}$, y la simulación es inicializada con el nivel de inventario actual.

Una simulación no terminal es aquella para la cual no existe un evento natural E que especifique el largo de una corrida. Esto a menudo ocurre cuando estamos diseñando un nuevo sistema o cambiando uno existente, y estamos interesados en el comportamiento del sistema en el largo plazo cuando éste está operando “normalmente”. Desafortunadamente, “en el largo plazo” no se traduce naturalmente en un evento de término E . Se dice que una medida de rendimiento para tal simulación es un parámetro de estado estable si ésta es una característica de la distribución de estado estable de algún proceso estocástico de salida $Y_1, Y_2, \dots$. En la Figura 6.1, si la variable aleatoria Y tiene distribución de estado estable, entonces podríamos estar interesados en estimar la media de estado estable $v = \mathbb{E}[Y]$ o una probabilidad $\mathbb{P}(Y \leq y)$ para algún $y \in \mathbb{R}$.

Ejemplo 6.6. Considerar una compañía que construirá un nuevo sistema de producción y le gustaría determinar el rendimiento medio por hora a largo plazo (estado estable) de su sistema después de haber estado funcionando el tiempo suficiente para que los trabajadores conozcan su trabajo y las dificultades mecánicas. Asumir que:

1. El sistema operará 16 horas diarias por 5 días a la semana.
2. Hay una pérdida insignificante de producción al final de un turno o al comienzo del siguiente.
3. No hay descansos (e.g., almuerzo) que detengan la producción en momentos específicos del día.

Este sistema podría ser simulado “pegando” días de 16 horas, ignorando así el tiempo de inactividad del sistema al final de cada día y durante el fin de semana. Sea N_i el número de partes producidas en la i -ésima hora. Si el proceso estocástico $N_1, N_2, \dots$ posee una distribución de estado estable con variable aleatoria correspondiente N , entonces nos interesa estimar la media $v = \mathbb{E}[N]$.

Considerar un proceso estocástico $Y_1, Y_2, \dots$ para una simulación no terminal que no tiene distribución de estado estable. Suponer que dividimos el eje del tiempo en intervalos contiguos de igual longitud llamados ciclos. (Por ejemplo, en un sistema de producción un ciclo podría ser un turno de 8 horas). Sea Y_i^C una variable aleatoria definida en el i -ésimo ciclo. Suponer que el proceso $Y_1^C, Y_2^C, \dots$ tiene distribución de estado estable F^C y que $Y^C \sim F^C$. Entonces, se dice que una medida de rendimiento es un parámetro de ciclo de estado estable si es una característica de Y^C tal que la media $v^C = \mathbb{E}[Y^C]$. Por lo tanto, un parámetro de ciclo de estado estable es sólo un parámetro de estado estable del proceso de ciclo apropiado $Y_1^C, Y_2^C, \dots$.

Ejemplo 6.7. Considerar el sistema de manufactura del Ejemplo 6.6. Había un programa de construcción de 3 meses disponible de marketing, que describía los tipos y la cantidad de computadores que se producirían cada semana. El horario cambiaba de una semana a otra debido a los cambios en las ventas y la introducción de nuevos computadores. En este caso, los rendimientos semanales o mensuales no tenían distribuciones de estado estable. Por lo tanto, realizamos una simulación de 3 meses de duración y estimamos el rendimiento medio por cada semana.

6.3. Análisis estadístico para simulaciones terminales

Suponer que corremos n réplicas independientes de una simulación terminal, donde cada una terminó por el evento E y comienza con las mismas condiciones iniciales:

- Al usar diferentes números aleatorios para cada réplica, aseguramos su independencia.
- Asumir por simplicidad que hay una única medida de rendimiento.
- Sea X_j una variable aleatoria definida en la j -ésima réplica, para $j = 1, 2, \dots, n$. Asumimos que son iid.
- A modo de ejemplo, X_j podría ser el retraso promedio $\sum_{i=1}^N D_i/N$ en un día de la j -ésima réplica, donde N es una variable aleatoria que cuenta el número de clientes atendidos en un día.

Suponer que queremos obtener una estimación puntual y un intervalo de confianza para la media $\mu = \mathbb{E}[X]$, donde X es una variable aleatoria definida en una réplica como se describió anteriormente. Hacer n réplicas independientes de la simulación y sea $\{X_i\}_{i \in [n]}$ las variables aleatorias resultantes. Tenemos:

- La media muestral $\bar{X}(n) = \sum_{i=1}^n X_i/n$ es un estimador puntual insesgado para μ .
- Un intervalo de confianza al $100(1 - \alpha)\%$ ($0 < \alpha < 1$) aproximado para μ está dado por la media muestral $\pm$ el *half-width* (ancho medio), i.e.,

$$\bar{X}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{n}}, \quad (6.1)$$

donde $S^2(n) = \sum_{i=1}^n (X_i - \bar{X}(n))^2 / (n - 1)$ es la varianza muestral. Llamaremos a este intervalo de confianza el procedimiento de tamaño de muestra fijo.

Ejemplo 6.8. Para el banco del Ejemplo 6.1, suponer que queremos obtener una estimación puntual y un intervalo de confianza al 90 % aproximado para la espera promedio esperada de un cliente durante un día, que está dada por

$$\mathbb{E}[X] = \mathbb{E}\left(\frac{\sum_{i=1}^N D_i}{N}\right).$$

Para las 10 réplicas dadas en la tabla del ejemplo, obtenemos: $\bar{X}(10) = 2,03$, $S^2(10) = 0,31$, y $\bar{X}(10) \pm t_{9,0,95} \sqrt{S^2(10)/10} = 2,03 \pm 0,32$. Por lo tanto, podemos afirmar con aproximadamente un 90 % de confianza que $\mathbb{E}[X]$ está contenido en el intervalo $[1,71; 2,35]$ minutos.

Una desventaja del procedimiento de tamaño de muestra fijo basado en n réplicas es que el analista no tiene control sobre el *half-width* del intervalo de confianza. Así:

- Para n fijo, el *half-width* dependerá de $\mathbb{V}[X]$, la varianza poblacional de los X_j 's.
- En lo que sigue, discutiremos procedimientos para determinar el número de réplicas necesarias para estimar la media $\mu = \mathbb{E}[X]$ con una precisión o error específico.

Comenzamos definiendo dos formas de medir el error en la estimación $\bar{X}$. (La dependencia de n es suprimida, pues el número de réplicas puede ser una variable aleatoria). Si la estimación $\bar{X}$ es tal que $|\bar{X} - \mu| = \beta$, entonces decimos que $\bar{X}$ tiene un error absoluto de $\beta > 0$. Si corremos réplicas de una simulación hasta que el *half-length* (largo medio) del intervalo de confianza al $100(1 - \alpha) \%$ sea menor o igual que β , entonces

$$\begin{aligned} 1 - \alpha &\approx \mathbb{P}(\bar{X} - \text{half length} \leq \mu \leq \bar{X} + \text{half length}) \\ &= \mathbb{P}(|\bar{X} - \mu| \leq \text{half-length}) \\ &\leq \mathbb{P}(|\bar{X} - \mu| \leq \beta). \end{aligned}$$

Si A y B son eventos con $A \subseteq B$, entonces $\mathbb{P}(A) \leq \mathbb{P}(B)$. Por lo tanto, $\bar{X}$ tiene un error absoluto de a lo más β con una probabilidad de apro-

ximadamente $1 - \alpha$. En otras palabras, si construimos 100 intervalos de confianza al 90 % usando la regla de parada anterior, esperaríamos que $\bar{X}$ tenga un error absoluto de a lo más β en alrededor de 90 de los 100 casos; en alrededor de 10 casos el error absoluto sería mayor que β .

Suponer que hemos construido un intervalo de confianza para μ basado en un número fijo de réplicas n . Si asumimos que nuestra estimación $S^2(n)$ de la varianza poblacional no cambiará (apreciablemente) en la medida que el número de réplicas aumenta, una expresión aproximada para el número total de réplicas, $n_a^*(\beta)$, requeridas para obtener un error absoluto de β es

$$n_a^*(\beta) = \min \left\{ i \geq n : t_{i-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{i}} \leq \beta \right\}.$$

Podemos determinar $n_a^*(\beta)$ al interativamente incrementar i de uno en uno hasta obtener un valor de i para el cual se satisface la restricción.

Ejemplo 6.9. Para el Ejemplo 6.1, suponer que queremos estimar el retraso promedio esperado con un error absoluto de 0,25 minutos y un nivel de confianza de 90 %. De las 10 réplicas disponibles, tenemos

$$n_a^*(0,25) = \min \left\{ i \geq 10 : t_{i-1, 0,95} \sqrt{\frac{0,31}{i}} \leq 0,25 \right\} = 16.$$

Ahora discutiremos otra forma de medir el error en $\bar{X}$. Asumir que ahora $\mu \neq 0$. Si la estimación $\bar{X}$ es tal que $|\bar{X} - \mu|/|\mu| = \gamma$, entonces decimos que $\bar{X}$ tiene un error relativo de γ , o que el error porcentual en $\bar{X}$ es 100γ %. Suponer que corremos réplicas de una simulación hasta que el *half-width* del intervalo de confianza dado por (6.1), dividido por $|\bar{X}|$, sea menor o igual que $0 < \gamma < 1$. Esta proporción es una estimación del error relativo real. Luego,

$$\begin{aligned} 1 - \alpha &\approx \mathbb{P}(|\bar{X} - \mu|/|\bar{X}| \leq \text{half-width}/|\bar{X}|) \\ &\leq \mathbb{P}(|\bar{X} - \mu| \leq \gamma|\bar{X}|) && (\text{half-width}/|\bar{X}| \leq \gamma) \\ &= \mathbb{P}(|\bar{X} - \mu| \leq \gamma|\bar{X} - \mu + \mu|) && (\text{sumar, restar } \mu) \\ &\leq \mathbb{P}(|\bar{X} - \mu| \leq \gamma(|\bar{X} - \mu| + |\mu|)) && (\text{desigualdad triangular}) \\ &= \mathbb{P}((1 - \gamma)|\bar{X} - \mu| \leq \gamma|\mu|) && (\text{álgebra}) \\ &= \mathbb{P}(|\bar{X} - \mu|/|\mu| \leq \gamma/(1 - \gamma)). && (\text{álgebra}) \end{aligned}$$

Por tanto, $\bar{X}$ tiene un error relativo de a lo más $\gamma/(1 - \gamma)$ con una probabilidad de aproximadamente $1 - \alpha$. Notar que obtenemos un error relativo de $\gamma/(1 - \gamma)$ en lugar de γ , pues estimamos $|\mu|$ con $|\bar{X}|$.

Suponer nuevamente que hemos construido un intervalo de confianza para μ en base a un número fijo de réplicas n . Si asumimos que nuestras estimaciones de la varianza y media poblacionales no cambiarán en la medida que aumenten o disminuyan las réplicas, una expresión aproximada para el número de réplicas, $n_r^*(\gamma)$, requeridas para obtener un error relativo de γ es

$$n_r^*(\gamma) = \min \left\{ i \geq n : \frac{t_{i-1, 1-\alpha/2} \sqrt{S^2(n)/i}}{|\bar{X}(n)|} \leq \gamma' \right\},$$

donde $\gamma' = \gamma/(1 + \gamma)$ es el error relativo “ajustado” necesario para tener un error relativo real de γ .

Ejemplo 6.10. Para el Ejemplo 6.1, suponer que queremos estimar el retraso promedio esperado con un error relativo de $\gamma = 0,1$ y un nivel de confianza de 90 %. De las 10 réplicas disponibles, tenemos

$$n_r^*(0,1) = \min \left\{ i \geq 10 : \frac{t_{i-1;0,95} \sqrt{0,31/i}}{2,03} \leq 0,09 \right\} = 27,$$

donde $\gamma' = 0,1/(1 + 0,1) = 0,09$.

La dificultad de usar esta segunda alternativa para obtener una estimación $\bar{X}$ con un error relativo de γ es que $\bar{X}(n)$ y $S^2(n)$ pueden no ser estimaciones precisas de sus respectivos parámetros poblacionales.

Ahora presentaremos un procedimiento secuencial (nuevas réplicas son añadidas de a una) para obtener una estimación de μ con un error relativo especificado que toma sólo tantas repeticiones como realmente se necesitan. Este nuevo procedimiento asume que $X_1, X_2, \dots$ es una secuencia de variables aleatorias iid que no necesitan ser normales.

El objetivo específico del procedimiento es obtener una estimación de μ con un error relativo de $0 < \gamma < 1$ y un nivel de confianza $100(1 - \alpha) \%$. Elegir un número inicial de réplicas $n_0 \geq 10$ y sea

$$\delta(n, \alpha) = t_{n-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{n}}$$

el *half-width* habitual del intervalo de confianza. Luego, el procedimiento

secuencial es como sigue:

1. Hacer n_0 réplicas de la simulación y definir $n = n_0$.
2. Calcular $\bar{X}(n)$ y $\delta(n, \alpha)$ desde $X_1, X_2, \dots, X_n$.
3. Si $\delta(n, \alpha)/|\bar{X}(n)| \leq \gamma'$, usar $\bar{X}(n)$ como estimación puntual para μ y parar. Equivalentemente,

$$I(\alpha, \gamma) = [\bar{X}(n) - \delta(n, \alpha), \bar{X}(n) + \delta(n, \alpha)]$$

es un intervalo de confianza aproximado del $100(1 - \alpha)\%$ para μ con la precisión deseada. En otro caso, reemplazar n por $n + 1$, hacer una réplica adicional de la simulación y volver al Paso 1.

Notar que el procedimiento calcula una nueva estimación de $\mathbb{V}[X]$ después de que cada réplica es ejecutada, y que el número total de réplicas requeridas por el procedimiento es una variable aleatoria.

Ejemplo 6.11. Para el Ejemplo 6.1, suponer que queremos estimar el retraso promedio esperado con un error relativo de $\gamma = 0,1$ y un nivel de confianza de 90 %. Usando las $n = 10$ réplicas como punto de partida, obtenemos

Número de réplicas al término = 74

$$\bar{X}(74) = 1,76, \quad S^2(74) = 0,67$$

intervalo de confianza al 90 %: $[1,60; 1,92]$.

Notar que el número de réplicas realmente requeridas, 74, es considerablemente más grande que las 27 predichas en el ejemplo previo, debido principalmente a la imprecisa estimación de la varianza basada en 10 réplicas.

6.4. Análisis estadístico para parámetros de estado estable

Sea $Y_1, Y_2, \dots$ un proceso estocástico de *output* de una única corrida de una simulación no terminal. Suponer que $\mathbb{P}(Y_i \leq y) = F_i(y) \rightarrow F(y) = \mathbb{P}(Y \leq y)$ cuando $i \rightarrow \infty$, donde Y es la variable aleatoria de estado estable de interés con función de distribución F . ϕ es un parámetro de

estado estable si éste es una característica de Y tal como $\mathbb{E}[Y]$, $\mathbb{P}(Y \leq y)$, o un cuantil de Y .

Una dificultad al estimar ϕ es que la función de distribución de Y_i es diferente a F , pues generalmente no será posible elegir I para que sea representativo del comportamiento de estado estable. Esto hace que un estimador de ϕ basado en $\{Y_i\}_{i \in [m]}$ no sea “representativo”. Este problema es conocido como el problema del transiente inicial o el problema de inicio (*startup problem*) en la literatura.

Suponer que queremos estimar la media de estado estable $v = \mathbb{E}[Y]$, que es también generalmente definido por

$$v = \lim_{i \rightarrow \infty} \mathbb{E}[Y_i].$$

Por lo tanto, las medias transientes convergen a la media de estado estable. La consecuencia más seria de este problema es probablemente que $\mathbb{E}[\bar{Y}(m)] \neq v$ para cualquier m . La técnica a menudo más sugerida para lidiar con esto es la denominada calentamiento del modelo (*warming up the model*) o eliminación de datos iniciales (*initial-data deletion*). La idea es eliminar algún número de observaciones desde el comienzo de una corrida, y usar las restantes para estimar v . E.g., dadas las observaciones $\{Y_i\}_{i \in [m]}$ es a menudo sugerido usar

$$\bar{Y}(m, l) = \frac{\sum_{i=l+1}^m Y_i}{m-l}$$

($1 \leq l \leq m-1$) en lugar de $\bar{Y}(m)$ como un estimador de v . Notar que uno esperaría que $\bar{Y}(m, l)$ fuera menos sesgado que $\bar{Y}(m)$.

La pregunta natural que surge es cómo elegir el periodo de calentamiento (*warmup period*) l :

- Nos gustaría elegir l (y m) tal que $\mathbb{E}[\bar{Y}(m, l)] \approx v$.
- Si se eligen l y m muy pequeños, entonces $\mathbb{E}[\bar{Y}(m, l)]$ puede ser significativamente diferente de v .
- Por otra parte, si son más grandes de lo necesario, entonces $\bar{Y}(m, l)$ probablemente tendrá una varianza innecesariamente grande.
- Discutiremos algunas de las técnicas comúnmente usadas para determinar l .

6.4.1. Método de Welch

Esta es una técnica simple y general para determinar l en un procedimiento gráfico. Su objetivo específico es determinar un índice de tiempo l tal que $\mathbb{E}[Y_i] \approx v$ para $i > l$, donde l es el *warmup period*. En general, es muy difícil determinar l de una única réplica debido a la variabilidad inherente del proceso $Y_1, Y_2, \dots$, como muestra la Figura 6.4.




Figura 6.4: Ejemplo de variabilidad inherente de un proceso estocástico

Como resultado, el procedimiento de Welch se basa en hacer n réplicas independientes de la simulación y emplear los siguientes cuatro pasos:

1. Hacer n réplicas de la simulación ($n \geq 5$), cada una de largo m . Sea Y_{ji} la i -ésima observación de la j -ésima réplica ($j = 1, 2, \dots, n$; $i = 1, 2, \dots, m$).
2. Sea $\bar{Y}_i = \sum_{j=1}^n Y_{ji}/n$ para $i = 1, 2, \dots, m$. El proceso promediado $\bar{Y}_1, \bar{Y}_2, \dots$ tiene medias $\mathbb{E}[\bar{Y}_i] = \mathbb{E}[Y_i]$ y varianzas $\mathbb{V}[\bar{Y}_i] = \mathbb{V}[Y_i]/n$. Por lo tanto, el proceso promediado tiene la misma curva media transiente que el proceso original, pero su gráfico sólo posee $(1/n)$ -ésimo de la varianza, tal como se ejemplifica en la Figura 6.5.




Figura 6.5: Ejemplo de proceso promediado

3. Para suavizar las oscilaciones de alta frecuencia en $\bar{Y}_1, \bar{Y}_2, \dots$ (pero dejar las de baja frecuencia o tendencias de largo plazo de interés), definimos la media móvil (*moving average*) $\bar{Y}_i(w)$ (donde w es la ventana y es un entero positivo tal que $w \leq \lfloor m/4 \rfloor$) como:

$$\bar{Y}_i(w) = \begin{cases} \frac{\sum_{s=-w}^w \bar{Y}_{i+s}}{2w+1} & i = w+1, \dots, m-w \\ \frac{\sum_{s=-(i-1)}^{i-1} \bar{Y}_{i+s}}{2i-1} & i = 1, \dots, w \end{cases}.$$

Por lo tanto, si i no está demasiado cerca del comienzo de las réplicas, entonces $\bar{Y}_i(w)$ es sólo el promedio muestral de $2w+1$ observaciones del proceso promediado centrado en la observación i .

4. Graficar $\bar{Y}_i(w)$ para $i = 1, 2, \dots, m-w$ y elegir l como aquel valor de i más allá del cual $\bar{Y}_1(w), \bar{Y}_2(w), \dots$ parece haber convergido.

En definitiva, la Figura 6.6 resume los tres primeros pasos del método de Welch, donde el cuarto consiste en graficar los valores obtenidos en el tercero.




Figura 6.6: Resumen esquemático del método de Welch

Ejemplo 6.12. Este ejemplo ilustra el cálculo de la media móvil. Por simplicidad, asumir que $m = 10$, $w = 2$, $\bar{Y}_i = i$ para $i = 1, 2, \dots, 5$ y $\bar{Y}_i = 6$ para $i = 6, 7, \dots, 10$. Luego,

$$\begin{aligned} \bar{Y}_1(2) &= 1 & \bar{Y}_2(2) &= 2 & \bar{Y}_3(2) &= 3 \\ \bar{Y}_4(2) &= 4 & \bar{Y}_5(2) &= 4,8 & \bar{Y}_6(2) &= 5,4 \\ \bar{Y}_7(2) &= 5,8 & \bar{Y}_8(2) &= 6 \end{aligned}$$

Algunas recomendaciones para elegir los parámetros n , m y w son:

- Correr $n = 5$ o 10 réplicas, con m tan grande como se pueda. m debe ser mucho más grande que el valor anticipado de l y también suficiente para permitir la ocurrencia eventos poco frecuentes (e.g., fallas de máquinas).
- Graficar $\bar{Y}_i(w)$ para varios valores de la ventana w y elegir el valor más pequeño de w para el cual el gráfico es “razonablemente suave”. Usar este gráfico para determinar el *warmup period* l .
- Si ningún valor de w es satisfactorio, hacer 5 o 10 réplicas adicionales de largo m . Repetir el Paso 2 usando todas las réplicas disponibles.

La mayor dificultad al aplicar el procedimiento de Welch en la práctica es que el número requerido de réplicas, n , puede ser relativamente grande si el proceso $Y_1, Y_2, \dots$ es altamente variable. También, la elección de l es algo subjetiva.

6.4.2. Método de replicación/eliminación

Suponer que queremos estimar la media de estado estable $v = \mathbb{E}[Y]$ del proceso $Y_1, Y_2, \dots$. El análisis es similar a aquel para simulaciones terminales excepto que ahora sólo aquellas observaciones más allá del *warmup period* l en cada réplica son utilizadas.

Específicamente, suponer que corremos n' réplicas de la simulación, cada una de largo m' observaciones, donde $m' \gg l$ (l determinado por el método de Welch). Sea Y_{ji} definido igualmente que antes y sea X_j dado por

$$X_j = \frac{\sum_{i=l+1}^{m'} Y_{ji}}{m' - l} \quad \text{para } j = 1, 2, \dots, n'.$$

Notar que X_j sólo usa aquellas observaciones de la j -ésima réplica correspondientes al estado estable, es decir, $Y_{j,l+1}, Y_{j,l+2}, \dots, Y_{j,m'}$. Luego, los X_j 's son variables aleatorias iid con $\mathbb{E}[X_j] \approx v$, $\bar{X}(n')$ es un estimador puntual aproximadamente insesgado para v , y un intervalo de confianza aproximado al $100(1 - \alpha)\%$ para v es

$$\bar{X}(n') \pm t_{n'-1, 1-\alpha/2} \sqrt{\frac{S^2(n')}{n'}}.$$

Ejemplo 6.13. Considerar un sistema de producción y suponer que queremos obtener una estimación puntual y un intervalo de confianza al 90 % para el rendimiento medio por hora en estado estable $v = \mathbb{E}[N]$. De $n = 10$ réplicas de largo $m = 160$ horas, especificamos un *warmup period* de $l = 24$. Ya que $m \gg l$, construiremos un intervalo de confianza como

$$X_j = \frac{\sum_{i=25}^{160} N_{ji}}{136}. \quad \text{para } j = 1, 2, \dots, 10.$$

Luego, una estimación puntual y un intervalo de confianza al 90 % para v están dados por

$$\hat{v} = \bar{X}(10) = 59,97,$$

y

$$\bar{X}(10) \pm t_{9;0,95} \sqrt{\frac{0,62}{10}} = 59,97 \pm 0,46.$$

Una crítica que a veces se hace sobre el enfoque de replicación/eliminación es que en realidad se está construyendo un intervalo de confianza al $100(1 - \alpha) \%$ para $\mathbb{E}[X_j]$ en lugar de para v (i.e., $\bar{X}(n')$ es un estimador sesgado de v).

Como resultado, si corremos un número grande de réplicas n' en un esfuerzo por hacer pequeño el *half-width* del intervalo de confianza, entonces la cobertura del intervalo de confianza podría ser mucho menor que el $1 - \alpha$ deseado.

Debido a que un modelo de simulación es sólo una aproximación al correspondiente sistema real, para muchos modelos, si no para la mayoría, es suficiente estimar $\mathbb{E}[X_j]$, siempre que sea “cercano” a v . Este debería ser el caso si elegimos el largo de la corrida m' suficientemente grande y usamos el procedimiento de Welch para elegir un *warm up period* conservador de l .

El método de medias por lotes (*batch means*, BM) es a menudo usado para estimar σ^2 y para calcular intervalos de confianza para μ .

Observación 6.6. Dividir una corrida larga en un número de lotes (*batches*) contiguos, y luego recurrir al CLT para asumir que las medias muestrales de los lotes resultantes son aproximadamente normales iid.

En particular, suponer que particionamos $Y_{l+1}, Y_{l+2}, \dots, Y_n$ en b lotes contiguos, no superpuestos, cada uno conteniendo $m = (n - l)/b$ observaciones (asumir que $(n - l) \% b = 0$):

$$\underbrace{Y_1, \dots, Y_l}_{\text{eliminados}}, \underbrace{Y_{l+1}, \dots, Y_{l+m}}_{\text{lote 1}}, \underbrace{Y_{l+m+1}, \dots, Y_{l+2m}}_{\text{lote 2}}, \dots, \underbrace{Y_{l+(b-1)m+1}, \dots, Y_{l+bm}}_{\text{lote } b}.$$

La media del i -ésimo lote es la media muestral de las m observaciones del lote $i = 1, 2, \dots, b$,

$$\bar{Y}_i \equiv \frac{1}{m} \sum_{j=(i-1)m+1}^{im} Y_{j+l}.$$

Las medias de los lotes están correlacionadas para pequeños m , pero para grandes m ,

$$\bar{Y}_1, \dots, \bar{Y}_b \approx \text{iid } \mathcal{N}(\mu, \mathbb{V}(\bar{Y}_i)) \approx \mathcal{N}(\mu, \sigma^2/m).$$

Ya que las medias por lotes $\bar{Y}_1, \dots, \bar{Y}_b \approx \text{iid } \mathcal{N}(\mu, \sigma^2/m)$ para m grande, tenemos el siguiente intervalo de confianza aproximado al $100(1 - \alpha)\%$ para μ .

$$\mu \in \bar{Y} \pm t_{b-1, 1-\alpha/2} \sqrt{\frac{\hat{V}_B}{b}},$$

donde $\bar{Y} = \frac{1}{b} \sum_{i=1}^b \bar{Y}_i$ y $\hat{V}_B := \frac{m}{b-1} \sum_{i=1}^b (\bar{Y}_i - \bar{Y})^2$ ($\hat{V}_B$ corresponde a un estimador de σ^2).

Observación 6.7. Infortunadamente, no existe un método relativamente simple y ampliamente aceptado para elegir un tamaño de m razonable (o, equivalentemente, la cantidad de lotes b). Sin embargo, en la Sección 5.5 de Banks (2014) se entregan algunas pautas basadas en la literatura (principalmente, basadas en correlaciones de los $\bar{Y}_i$).

Observación 6.8. El *half-width*, $t_{b-1, 1-\alpha/2} \sqrt{\hat{V}_B/n}$, disminuye en b , aunque se suaviza alrededor de $b = 30$. Una recomendación común es tomar $b = 30$ y concentrarse en incrementar el tamaño del lote m tanto como sea posible.

La técnica BM es intuitivamente atractiva y fácil de entender. Pero, algunos problemas pueden surgir si los Y_i 's son no estacionarios (i.e., si hay un sesgo de inicialización significativo), si las medias por lotes no son normales, o si las medias por lotes no son independientes.

Capítulo 7

Comparación de Sistemas

En el Capítulo 6 vimos la importancia de aplicar análisis estadísticos apropiados para los resultados de un modelo de simulación de un único sistema. En este capítulo discutiremos acerca de análisis estadísticos para los resultados de diferentes configuraciones de un modelo de simulación que pueden representar diseños de un sistema que compiten entre sí o políticas de operación alternativas.

7.1. Introducción a la comparación de sistemas

La comparación de sistemas es un tema muy importante, pues la real utilidad de la simulación consiste en comparar tales alternativas antes de la implementación real. Para introducirlo, consideremos el siguiente ejemplo:

- Un banco planea instalar una máquina de autoservicio y debe elegir entre una máquina Zippytel (enérgica) o dos Klunkytel (torpes).
- Una Zippy cuesta el doble de comprar, instalar y operar que una Klunky. La Zippy trabaja el doble de rápido.
- Por lo tanto, el costo total para el banco es el mismo, por lo que a los gerentes les gustaría instalar el sistema que brinde el mejor servicio.
- Los clientes llegan uno a la vez según un proceso de Poisson con tasa de 1 minuto.
- La Zippy puede proporcionar tiempos de servicio iid que son variables aleatorias exponenciales con una media de 0,9 minutos.

- Cada Klunky produce tiempos de servicio que son variables aleatorias exponenciales iid con una media de 1,8 minutos. En este caso, se formará una única fila FIFO (*first-in-first-out*) en lugar de dos filas separadas.
- La Figura 7.1 presenta gráficamente los esquemas propuestos.




Figura 7.1: Representación visual de esquema Zippy y Klunk

La métrica de rendimiento de interés es la demora promedio esperada en la cola de los primeros 100 clientes, asumiendo que el sistema comienza desocupado y vacío. Aquí:

- $d_Z(100)$ y $d_K(100)$ indican estas medidas para los casos de un Zippy y dos Klunky, respectivamente.
- El (intrépido) analista de sistemas del banco decidió realizar una simulación de 100 demoras de clientes para cada sistema (usando números aleatorios independientes) y usar el promedio de las 100 demoras en cada caso para inferir si $d_Z(100)$ o $d_K(100)$ es menor.
- ¿Qué tan probable es que el analista haga la recomendación correcta? Para averiguarlo, realizaremos 100 experimentos independientes del esquema completo del analista y observamos cuántas veces se habría recomendado el mejor sistema.
- El mejor sistema es en realidad la instalación de dos Klunky, ya que $d_Z(100) = 4,13$ y $d_K(100) = 3,70$. Estos valores se determinaron teóricamente a partir de los resultados de teoría de colas en Kelton & Law (1985).

- Por lo tanto, deberíamos realizar 100 pares independientes de simulaciones independientes de los dos sistemas y promediar las demoras en cada simulación para obtener $\hat{d}_Z(100)$ y $\hat{d}_K(100)$. Algunos resultados son los siguientes:

| Experimento | $\hat{d}_Z(100)$ | $\hat{d}_K(100)$ | Recomendación | |
|-------------|------------------|------------------|---------------|--------------|
| 1 | 3,80 | 4,60 | Zippy | (equivocada) |
| 2 | 3,17 | 8,37 | Zippy | (equivocada) |
| 3 | 3,96 | 4,18 | Zippy | (equivocada) |
| 4 | 1,91 | 5,77 | Zippy | (equivocada) |
| 5 | 1,71 | 2,23 | Zippy | (equivocada) |
| 6 | 6,16 | 4,72 | Klunky | (correcta) |
| 7 | 5,67 | 1,39 | Klunky | (correcta) |
| $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ | |
| 98 | 8,40 | 9,39 | Zippy | (equivocada) |
| 99 | 7,70 | 1,54 | Klunky | (correcta) |
| 100 | 4,64 | 1,17 | Klunky | (correcta) |

- En sólo 48 de los 100 experimentos se obtuvo $\hat{d}_K(100) < \hat{d}_Z(100)$, por lo que el analista realmente parece no tener una mejor alternativa que tomar la decisión equivocada.

Muchos estudios de simulación y de evaluación de diseño de procesos se llevan a cabo de manera similar a la descrita en el ejemplo ilustrativo. La dificultad es que los datos de salida de la simulación son estocásticos, por lo que comparar los dos sistemas sobre la base de una sola ejecución de cada uno es un enfoque muy poco confiable. El siguiente ejemplo indica cómo se podría mejorar el ejemplo ilustrativo:

- En la Figura 7.2 cada círculo representa el promedio de las 100 demoras en las n réplicas independientes.




Figura 7.2: Resultados de ejemplo mejorado

- Notar la superposición de círculos sobre los valores esperados.
- Sean X_{1j} y X_{2j} el promedio de las 100 demoras en los sistemas de un Zippy y dos Klunky en su j -ésima réplica, para $j = 1, 2, \dots, n$.
- $\bar{X}_1(n)$ y $\bar{X}_2(n)$ son las medias muestrales de los X_{1j} 's y X_{2j} 's. Los resultados son los siguientes:

| n | Proporción de experimentos que favorecen
el sistema uno-Zippy |
|-----|--|
| 1 | 0,52 |
| 5 | 0,43 |
| 10 | 0,38 |
| 20 | 0,34 |

De aquí se pueden establecer algunas observaciones:

- La posibilidad de cometer un error disminuye a medida que aumenta n , pero a un costo computacional correspondientemente más alto.
- A medida que aumenta n , las distribuciones de los promedios de la n -ésima réplica se ajustan en torno a sus valores esperados, pero aún existe una superposición considerable incluso para $n = 20$.

Ambos ejemplos ilustran la necesidad de un diseño y análisis cuidadoso de simulaciones comparativas. Incluso con $n = 20$ réplicas de cada diseño de sistema, el segundo ejemplo indica que existe un margen

considerable para el error. Notar que ambos ejemplos trataban con simulaciones terminales. Como veremos, un requisito básico para muchos métodos estadísticos de comparación de configuraciones alternativas o diseño de procesos se basa en la capacidad de recolectar observaciones iid con $\bar{X} = \mathbb{E}[X] = \mu$. Para simulaciones terminales, esto se logra de manera sencilla simplemente haciendo réplicas independientes.

7.2. Intervalos de confianza para comparar dos configuraciones alternativas de un sistema

Aquí consideramos el caso especial de comparar dos sistemas sobre la base de alguna medida de rendimiento, o respuesta esperada. Efectuamos esta comparación formando un intervalo de confianza para la diferencia de las dos esperanzas. Para $i = 1, 2$, sea $X_{i1}, X_{i2}, \dots, X_{in_i}$ una muestra de n_i observaciones iid del sistema i , y sea $\mu_i = \mathbb{E}[X_{ij}]$ la respuesta esperada de interés. Queremos construir un intervalo de confianza para $\zeta = \mu_1 - \mu_2$. Si X_{1j} y X_{2j} son o no independientes depende de cómo se ejecuten las simulaciones y podría determinar cuál de los siguientes dos enfoques de intervalo de confianza se utilizará:

- Intervalo de confianza t -pareado (*paired-t*).
- Intervalo de confianza modificado de dos muestras- t (*modified two-sample-t*).

Usar números aleatorios comunes (CRN, en inglés) significa usar los mismos números pseudo-aleatorios en exactamente la misma forma para las corridas correspondientes de cada uno de los sistemas competidores.

Ejemplo 7.1. Usar los mismos tiempos de llegada y atención del cliente al simular diferentes configuraciones propuestas de un banco

7.2.1. Intervalo de confianza t -pareado

Al someter a los sistemas competidores a condiciones experimentales idénticas, esperamos que sea más fácil distinguir qué sistemas son los mejores, incluso aunque los estimadores respectivos tengan un error de muestreo. Así:

- Si $n_1 = n_2 = n$, podemos emparejar (parear) X_{1j} con X_{2j} para definir $Z_j = X_{1j} - X_{2j}$, para $j = 1, 2, \dots, n$.

- Luego, los Z_j 's son variables aleatorias iid y $\mathbb{E}[Z_j] = \zeta$, la cantidad para la cual queremos construir un intervalo de confianza. Por lo tanto, podemos definir

$$\bar{Z}(n) = \frac{\sum_{j=1}^n Z_j}{n},$$


y

$$\hat{V}[\bar{Z}(n)] = \frac{\sum_{j=1}^n (Z_j - \bar{Z}(n))^2}{n(n-1)},$$

y formar el intervalo de confianza (aproximado) al $100(1 - \alpha) \%$

$$\bar{Z}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{\hat{V}[\bar{Z}(n)]}. \quad (7.1)$$

Aquí, el valor $t_{n-1, 1-\alpha/2}$ proviene de la tabla t -student de la Figura 7.3. Por ejemplo, si estamos construyendo un intervalo al 90 % (es decir, $\alpha = 0,1$) a partir de $n = 5$ réplicas, entonces tendremos $5 - 1 = 4$ grados de libertad y un valor $\alpha = 0,1$ (o $1 - \alpha = 0,9$), obteniendo un valor $t_{n-1, 1-\alpha/2} = 2,132$.

Figura 7.3: Tabla t -student

Si los Z_j 's distribuyen normal, este intervalo de confianza es exacto, es decir, cubre ζ con probabilidad $1 - \alpha$. En otro caso, en base al CLT, la probabilidad de cobertura será cercana a $1 - \alpha$ para n grande. Un punto importante es que no tuvimos que asumir que X_{1j} y X_{2j} son independientes; ni tuvimos que asumir que $\mathbb{V}[X_{1j}] = \mathbb{V}[X_{2j}]$. Permitir una correlación positiva entre X_{1j} y X_{2j} puede ser de gran importancia, ya que esto conduce a una reducción en $\mathbb{V}[Z_j]$ y, por lo tanto, a un intervalo de confianza más pequeño. Es importante tener en cuenta que X_{ij} son variables aleatorias definidas sobre una réplica completa. Por ejemplo, X_{1j} podría ser el promedio de las 100 demoras en la j -ésima réplica del sistema Zippytel; no es la demora de algún cliente individual. Veamos un ejemplo.

Ejemplo 7.2. Una política (s, S) es clásica en la gestión de inventarios. Es conocida como la política de mínimos y máximos, pues cada vez que el inventario alcanza s (o menos) unidades, se debe hacer un pedido para alcanzar un nuevo nivel de inventario de S unidades.

Suponer que queremos comparar dos políticas (s, S) diferentes en términos de su efecto sobre el costo total promedio esperado por mes durante los primeros 120 meses de operación, donde el nivel de inventario inicial es $I_0 = 60$. La primera política es $(s, S) = (20, 40)$, y la segunda política establece $(s, S) = (20, 80)$.

Aquí, X_{ij} es el costo total promedio por mes de la política i en la j -ésima réplica independiente. La siguiente tabla contiene los resultados de $n = n_1 = n_2 = 5$ réplicas independientes para cada política:

| j | X_{1j} | X_{2j} | Z_j |
|-----|----------|----------|-------|
| 1 | 126,97 | 118,21 | 8,76 |
| 2 | 124,31 | 120,22 | 4,09 |
| 3 | 126,68 | 122,45 | 4,23 |
| 4 | 122,66 | 122,68 | -0,02 |
| 5 | 127,23 | 119,40 | 7,83 |

Usando el enfoque t -pareado, obtenemos $\bar{Z}(5) = 4,98$ y $\hat{V}[\bar{Z}(5)] = 2,44$, llevando a un intervalo de confianza (aproximado) al 90 % de $[1,65; 8,31]$ para $\zeta = \mu_1 - \mu_2$. Así, con aproximadamente un 90 % de confianza, podemos decir que μ_1 difiere de μ_2 , y además parece que la política 2 es superior, ya que conduce a un menor costo operativo promedio (entre 1,65 y 8,31). Debemos usar la palabra “aproximado” para describir el nivel de confianza, ya que $n_1 = n_2 = n = 5$ puede no ser lo suficientemente “grande” para este modelo para que el CLT haya hecho efecto.

7.2.2. Intervalo de confianza modificado de dos muestras- t

Este segundo enfoque para formar un intervalo de confianza para ζ no necesita necesariamente que $n_1 = n_2$. Suponer que los X_{1j} 's distribuyen normalmente, los X_{2j} 's distribuyen normalmente y que los X_{1j} 's son independientes de los X_{2j} 's. Usaremos una solución aproximada antigua

pero confiable en esta situación (Welch, 1938). Como siempre, para $i = 1, 2$, sea

$$\bar{X}_i(n_i) = \frac{\sum_{j=1}^{n_i} X_{ij}}{n_i}$$

y

$$S_i^2(n_i) = \frac{\sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i(n_i))^2}{n_i - 1}.$$

Luego, calcular los grados de libertad estimados:

$$\hat{f} = \frac{(S_1^2(n_1)/n_1 + S_2^2(n_2)/n_2)^2}{(S_1^2(n_1)/n_1)^2/(n_1 - 1) + (S_2^2(n_2)/n_2)^2/(n_2 - 1)}$$

y usar

$$\bar{X}_1(n_1) - \bar{X}_2(n_2) \pm t_{\hat{f}, 1-\alpha/2} \sqrt{\frac{S_1^2(n_1)}{n_1} + \frac{S_2^2(n_2)}{n_2}} \quad (7.2)$$

como un intervalo de confianza aproximado al $100(1-\alpha)\%$ para ζ . Ya que $\hat{f}$ no será, en general, un entero, probablemente será necesario utilizar una interpolación en las tablas t -student. El intervalo de confianza está dado por (7.2), que llamaremos intervalo de confianza Welch, puede también ser usado para validar un modelo de simulación de un sistema existente.

Observación 7.1 (Interpolación en tabla t -student). Recordar que para todo $0 < \alpha \leq 1$, y para $f_1 = \lfloor \hat{f} \rfloor$, $f_2 = \lceil \hat{f} \rceil$, $t_{\hat{f}, 1-\alpha/2}$ viene dado por

$$t_{\hat{f}, 1-\alpha/2} = t_{f_1, 1-\alpha/2} + \frac{t_{f_2, 1-\alpha/2} - t_{f_1, 1-\alpha/2}}{f_2 - f_1} (\hat{f} - f_1).$$

Ejemplo 7.3. Dado que las corridas para las dos políticas de inventario diferentes del Ejemplo 7.2 se realizaron de forma independiente, podemos aplicar el enfoque de Welch para formar un intervalo de confianza aproximado del 90% para ζ . Usamos los mismos datos de X_{ij} que se dan en la tabla de ahí.

Tenemos $\bar{X}_1(5) = 125,57$, $\bar{X}_2(5) = 120,59$, $S_1^2(5) = 4,00$, $S_2^2(5) = 3,76$ y $\hat{f} = 7,99$. Interpolando en la tabla t -student, tenemos $t_{7,99; 0,95} = 1,86$. Por lo tanto, el intervalo de confianza Welch es $[2,66; 7,30]$.

Dado que los datos del Ejemplo 7.2 se recolectaron de modo que $n_1 = n_2$ y los X_{1j} fueran independientes de los X_{2j} 's, podríamos aplicar cualquiera de los dos métodos para construir un intervalo de confianza

para ζ . La elección del método generalmente se hará de acuerdo con la situación. Una consideración es que el uso de números aleatorios comunes para simular los dos sistemas a menudo puede llevar a una reducción considerable en $\mathbb{V}[Z_j]$ y, por lo tanto, a un intervalo de confianza mucho más acotado. Esto implica que $n_1 = n_2$ y que X_{1j} y X_{2j} no serán independientes, por lo que se requiere el enfoque t -pareado. Si $n_1 \neq n_2$ (y queremos usar todos los datos disponibles), se debe usar el enfoque de Welch. Esto requiere la independencia de los X_{1j} 's de X_{2j} 's, por lo que no se pueden usar números aleatorios comunes. Sin embargo, la configuración predeterminada en la mayoría de los *software* de simulación es que se utilizan las mismas cadenas y semillas de números aleatorios, aunque no necesariamente sincronizados correctamente, lo que hace que el enfoque de Welch sea inválido.

Observación 7.2 (Interpretación de resultados). Independiente de cuál de los dos métodos se utilice, la interpretación de resultados es la misma. Aquí, debemos analizar dos cosas:

1. Si el intervalo obtenido contiene al 0, entonces podemos inferir con un nivel de confianza de $100(1 - \alpha) \%$ que no existe una diferencia significativa entre ambas configuraciones alternativas.
2. Si el intervalo obtenido no contiene al 0, entonces sí existe una diferencia estadísticamente significativa. Luego:
 - Si el intervalo está contenido en los números reales no negativos (es decir, mayores que 0), entonces $\mu_1 > \mu_2$.
 - Si el intervalo está contenido en los números reales no positivos (es decir, menores que 0), entonces $\mu_2 > \mu_1$.

7.3. Intervalos de confianza para comparar más de dos sistemas

Ahora haremos varias declaraciones de intervalos de confianza simultáneamente, por lo que sus niveles individuales deberán ajustarse hacia arriba para que el nivel de confianza general de todos los intervalos que cubren sus objetivos respectivos esté en el nivel deseado $1 - \alpha$. Usaremos la desigualdad de Bonferroni para garantizar que el nivel de confianza general sea al menos $1 - \alpha$.

Observación 7.3 (Desigualdad de Bonferroni). Sea I_s un intervalo de confianza al $100(1 - \alpha_s)\%$ para la métrica de rendimiento μ_s , para $s = 1, 2, \dots, k$. Luego, la probabilidad de que todos los k intervalos de confianza contengan simultáneamente sus respectivas métricas verdaderas satisface

$$\mathbb{P}(\mu_s \in I_s \text{ para todo } s = 1, 2, \dots, k) = \mathbb{P}\left(\bigcap_{s=1}^k \mu_s \in I_s\right) \geq 1 - \sum_{s=1}^k \alpha_s,$$

sean o no independientes los I_s 's.

La desigualdad de Bonferroni implica que si queremos hacer un número c de declaraciones de intervalos de confianza, entonces deberíamos hacer cada intervalo separado en el nivel $1 - \alpha/c$, de modo que el nivel de confianza general asociado con todos los intervalos que cubren sus objetivos sea de al menos $1 - \alpha$.

Por ejemplo, si queremos hacer $c = 10$ intervalos y obtener un nivel de confianza general de $100(1 - \alpha)\% = 90\%$, debemos hacer cada intervalo individual a un nivel de 99% . Claramente, para c grande, esto implica que los intervalos individuales pueden volverse bastante amplios.

Aunque hay muchos objetivos que podrían formularse para comparar las medias de k sistemas, nos centraremos en dos problemas:

- Comparación con un “estándar”.
- Todos los pares de comparaciones.

7.3.1. Comparación con un estándar

Suponer que una de las variantes del modelo es un “estándar”, quizás representando un sistema o política existente. Luego:

- Si llamamos al sistema estándar 1 y a las otras variantes del sistema $2, 3, \dots, k$, el objetivo es construir $k - 1$ intervalos de confianza para las $k - 1$ diferencias $\{\mu_2 - \mu_1, \mu_3 - \mu_1, \dots, \mu_k - \mu_1\}$, con un nivel de confianza general $1 - \alpha$.
- Por lo tanto, estamos haciendo $c = k - 1$ intervalos individuales, por lo que cada uno debe construirse en el nivel $1 - \alpha/(k - 1)$.
- Entonces, podemos decir (con un nivel de confianza de al menos $1 - \alpha$) que para todo $i = 2, 3, \dots, k$, el sistema i difiere del estándar si el intervalo para $\mu_i - \mu_1$ no contiene al 0, y que ese sistema i no es

significativamente diferente del estándar si este intervalo contiene al 0.

Ejemplo 7.4. La siguiente tabla define $k = 5$ políticas (s, S) diferentes para un sistema de inventario. Las políticas 1 y 2 son las utilizadas en el Ejemplo 7.2. Suponga que la política 1 es la política actual y que las otras cuatro políticas se consideran como posibles alternativas

| Política (i) | s | S |
|------------------|-----|-----|
| 1 | 20 | 40 |
| 2 | 20 | 80 |
| 3 | 40 | 60 |
| 4 | 40 | 100 |
| 5 | 60 | 100 |

¿Cuáles de estas difieren del estándar? Para averiguarlo, tenemos el costo total promedio por mes para cinco réplicas independientes de cada política, siendo todas las políticas independientes.

| j | X_{1j} | X_{2j} | X_{3j} | X_{4j} | X_{5j} |
|----------|----------|----------|----------|----------|----------|
| 1 | 126,97 | 118,21 | 120,77 | 131,64 | 141,09 |
| 2 | 124,31 | 120,22 | 129,32 | 137,07 | 143,86 |
| 3 | 126,68 | 122,45 | 120,61 | 129,91 | 144,30 |
| 4 | 122,66 | 122,68 | 123,65 | 129,97 | 141,72 |
| 5 | 127,23 | 119,40 | 127,34 | 131,08 | 142,61 |
| Media | 125,57 | 120,59 | 124,34 | 131,93 | 142,72 |
| Varianza | 4,00 | 3,76 | 15,23 | 8,79 | 1,87 |

Dado que hay $k - 1 = 4$ intervalos para construir, haremos cada intervalo al nivel 97,5 % para producir un nivel de confianza general de al menos 90 %.

La siguiente tabla muestra las diferencias en las medias muestrales, así como los intervalos de confianza al 97,5 % para $\mu_i - \mu_1$ para $i = 2, 3, 4, 5$. Los asteriscos indican aquellos intervalos que no contienen al 0 (es decir, sistemas que difieren del sistema 1).

| i | $\bar{X}_i - \bar{X}_1$ | t -pareado | | Welch | |
|-----|-------------------------|--------------|-----------------|------------|-----------------|
| | | Half-width | Intervalo | Half-width | Intervalo |
| 2 | -4,98 | 5,45 | [-10,44; 0,48] | 3,54 | [-8,52; -1,44]* |
| 3 | -1,23 | 7,58 | [-8,80; 6,34] | 6,21 | [-7,44; 4,97] |
| 4 | 6,36 | 6,08 | [0,27; 12,46]* | 4,55 | [1,82; 10,91]* |
| 5 | 17,15 | 3,67 | [13,48; 20,81]* | 3,08 | [14,07; 20,22]* |

7.3.2. Todos los pares de comparaciones

¿Qué pasa si queremos comparar cada sistema con todos los demás sistemas para detectar y cuantificar cualquier diferencia significativa por pares?

- Por ejemplo, puede que no haya un sistema existente y todas las k alternativas representen posibles implementaciones.
- Un enfoque sería formar intervalos de confianza para las diferencias $\mu_{i_2} - \mu_{i_1}$, para todos los i_1 e i_2 entre 1 y k , con $i_1 < i_2$.
- Aquí habrán $k(k-1)/2$ intervalos individuales, por lo que cada uno debe hacerse al nivel

$$1 - \frac{\alpha}{(k(k-1)/2)}$$

para tener un nivel de confianza de al menos $1 - \alpha$ para todos los intervalos juntos.

Ejemplo 7.5. Suponer que las cinco políticas de inventario del Ejemplo 7.4 se van a comparar entre sí usando los datos del costo total promedio por mes. Como hay $5(5 - 1)/2 = 10$ pares posibles, debemos hacer cada intervalo individual al nivel 99 %. Los resultados son:

| | | <i>t</i> -pareado | | | |
|-----------------------|---|-----------------------|--------------|---------------|---------------|
| | | <i>i</i> ₂ | | | |
| | | 2 | 3 | 4 | 5 |
| <i>i</i> ₁ | 1 | -4,98 ± 7,18 | -1,23 ± 9,99 | 6,36 ± 8,01 | 17,15 ± 4,83* |
| | 2 | | 3,75 ± 9,58 | 11,34 ± 8,38* | 22,12 ± 3,80* |
| | 3 | | | 7,60 ± 5,66* | 18,38 ± 7,73* |
| | 4 | | | | 10,78 ± 5,85* |

| | | Welch | | | |
|-----------------------|---|-----------------------|--------------|---------------|---------------|
| | | <i>i</i> ₂ | | | |
| | | 2 | 3 | 4 | 5 |
| <i>i</i> ₁ | 1 | -4,98 ± 4,36* | -1,23 ± 7,91 | 6,36 ± 5,60* | 17,15 ± 3,80* |
| | 2 | | 3,75 ± 7,86 | 11,34 ± 5,88* | 22,12 ± 3,72* |
| | 3 | | | 7,60 ± 7,67 | 18,38 ± 8,51* |
| | 4 | | | | 10,78 ± 5,89* |

Una vez más, notar que los dos enfoques no siempre coinciden en términos de qué diferencias son significativas, y ninguno de los enfoques proporciona intervalos con *half-widths* uniformemente más pequeños.

Utilizando el enfoque de Welch podríamos concluir que ni μ_1 ni μ_2 difieren significativamente de μ_3 , es decir, " $\mu_1 = \mu_3 = \mu_2$ " y por tanto " $\mu_1 = \mu_2$ ". Pero, el intervalo de confianza para $\mu_2 - \mu_1$ no contiene al 0, por lo que no podemos considerar que μ_1 sea igual a μ_2 .

Observación: nunca interpretemos las declaraciones de intervalos de confianza como "demostraciones" de igualdad o desigualdad.

7.3.3. Comparaciones múltiples con el mejor

Finalmente, mencionaremos otro tipo de objetivo de comparación que forma intervalos de confianza simultáneos para las diferencias entre las

medias de cada una de las k alternativas y las de las mejores otras alternativas.

Esto se conoce como comparaciones múltiples con el mejor (MCB, en inglés), y tiene como objetivo formar k intervalos de confianza simultáneos en $\mu_i - \min_{l \neq i} \mu_l$ para $i = 1, 2, \dots, k$, asumiendo que los más pequeños son mejores (si los más grandes son mejores, entonces reemplazar “mín” por “máx”).

Si bien MCB es útil por sí mismo, también está íntimamente relacionado con los procedimientos de clasificación y selección que veremos a continuación.

7.4. Clasificación y selección

7.4.1. Seleccionando el mejor de k sistemas

Sea X_{ij} la variable aleatoria de interés de la j -ésima réplica del i -ésimo sistema, y $\mu_i = \mathbb{E}[X_{ij}]$. Se supone que los X_{ij} 's son independientes para diferentes réplicas del i -ésimo sistema. Sea μ_{i_l} el l -ésimo μ_i más pequeño, de modo que

$$\mu_{i_1} \leq \mu_{i_2} \leq \dots \leq \mu_{i_k}.$$

Nuestro objetivo es seleccionar un sistema con la respuesta esperada más pequeña, μ_{i_1} . Sea SC este evento de selección correcta. Debido a la aleatoriedad de los X_{ij} , nunca podemos estar absolutamente seguros de hacer la SC, pero nos gustaría poder especificar previamente la probabilidad de SC.

Si μ_{i_1} y μ_{i_2} están realmente muy juntos, es posible que no nos importe si elegimos erróneamente el sistema i_2 como el mejor. La formulación exacta del problema es que queremos $\mathbb{P}(\text{SC}) \geq P^*$ siempre que $\mu_{i_2} - \mu_{i_1} \geq d^*$, donde la probabilidad mínima SC $P^* > 1/k$ y la cantidad de indiferencia $d^* > 0$ son especificadas por el analista.

El siguiente procedimiento tiene la buena propiedad de que, con una probabilidad de al menos P^* , la respuesta esperada del sistema seleccionado no será mayor que $\mu_{i_1} + d^*$. Estamos protegidos con una probabilidad de al menos P^* contra seleccionar un sistema con una media que sea más de d^* peor que la del mejor sistema. El procedimiento estadístico, desarrollado por Dudewicz & Dalal (1975) y denominado $\mathcal{DD}$, para resolver este problema implica un muestreo en dos etapas de cada uno de los k sistemas:

1. Correr $n_0 \geq 2$ (típicamente, $n_0 \geq 20$) réplicas de cada uno de los k sistemas y definir las medias y varianzas muestrales de primera etapa para $i = 1, 2, \dots, k$

$$\bar{X}_i^{(1)}(n_0) = \frac{\sum_{j=1}^{n_0} X_{ij}}{n_0}$$

$$S_i^2(n_0) = \frac{\sum_{j=1}^{n_0} (X_{ij} - \bar{X}_i^{(1)}(n_0))^2}{n_0 - 1}.$$

Luego, calculamos el tamaño de muestra total N_i necesario para el sistema i como

$$N_i = \max \left\{ n_0 + 1, \left\lceil \frac{h_1^2 S_i^2(n_0)}{(d^*)^2} \right\rceil \right\}, \quad (7.3)$$

donde h_1 es una constante que se puede obtener de la Tabla 7.1.

| P^* | n_0 | $k = 2$ | $k = 3$ | $k = 4$ | $k = 5$ | $k = 6$ | $k = 7$ | $k = 8$ | $k = 9$ | $k = 10$ |
|-------|-------|---------|---------|---------|---------|---------|---------|---------|---------|----------|
| 0,90 | 20 | 1,896 | 2,342 | 2,583 | 2,747 | 2,870 | 2,969 | 3,051 | 3,121 | 3,182 |
| 0,90 | 40 | 1,852 | 2,283 | 2,514 | 2,669 | 2,785 | 2,878 | 2,954 | 3,019 | 3,076 |
| 0,95 | 20 | 2,453 | 2,872 | 3,101 | 3,258 | 3,377 | 3,472 | 3,551 | 3,619 | 3,679 |
| 0,95 | 40 | 2,386 | 2,786 | 3,003 | 3,150 | 3,260 | 3,349 | 3,422 | 3,484 | 3,539 |

Tabla 7.1: Constantes para procedimiento $\mathcal{DD}$

2. Correr $N_i - n_0$ réplicas más del sistema i y obtener las medias muestrales de segunda etapa

$$\bar{X}_i^{(2)}(N_i - n_0) = \frac{\sum_{j=n_0+1}^{N_i} X_{ij}}{N_i - n_0}.$$

Luego, definir los pesos

$$W_{i1} = \frac{n_0}{N_i} \left\{ 1 + \sqrt{1 - \frac{N_i}{n_0} \left[1 - \frac{(N_i - n_0)(d^*)^2}{h_1^2 S_i^2(n_0)} \right]} \right\},$$

y $W_{i2} = 1 - W_{i1}$, para $i = 1, 2, \dots, k$. Finalmente, definir las medias muestrales ponderadas

$$\tilde{X}_i(N_i) = W_{i1} \bar{X}_i^{(1)}(n_0) + W_{i2} \bar{X}_i^{(2)}(N_i - n_0)$$

y elegir el sistema con el $\tilde{X}_i(N_i)$ más pequeño.

Ejemplo 7.6. Para el modelo de inventario del Ejemplo 7.4 supongamos que queremos comparar las $k = 5$ políticas (s, S) diferentes, en base a sus correspondientes costos totales promedio esperados por mes (μ_i para la i -ésima política).

Nuestro objetivo es seleccionar un sistema con el μ_i más pequeño y estar $100P^* = 90\%$ seguros de que hemos hecho la selección correcta siempre que $\mu_{i_2} - \mu_{i_1} \geq d^* = 1$. Hicimos $n_0 = 20$ réplicas iniciales independientes de cada sistema, de manera que $h_1 = 2,747$.

Los resultados del muestreo de la primera etapa se presentan en las columnas $\bar{X}_i^{(1)}(20)$ y $S_i^2(20)$ de la siguiente tabla. En base a los $S_i^2(20)$'s, h_1 y d^* , luego calculamos N_i para todos los i .

Luego, hacemos $N_i - 20$ réplicas adicionales para cada política y calculamos las medias muestrales de segunda etapa $\bar{X}_i^{(2)}(N_i - 20)$. Finalmente, calculamos W_{i1} , W_{i2} y $\tilde{X}_i(N_i)$

| i | $\bar{X}_i^{(1)}(20)$ | $S_i^2(20)$ | N_i | $\bar{X}_i^{(2)}(N_i - 20)$ | W_{i1} | W_{i2} | $\tilde{X}_i(N_i)$ |
|-----|-----------------------|-------------|-------|-----------------------------|----------|----------|--------------------|
| 1 | 126,48 | 14,52 | 110 | 124,45 | 0,21 | 0,79 | 124,87 |
| 2 | 121,92 | 7,96 | 61 | 121,63 | 0,39 | 0,61 | 121,74 |
| 3 | 127,16 | 9,45 | 72 | 126,11 | 0,32 | 0,68 | 126,44 |
| 4 | 130,71 | 8,25 | 63 | 132,03 | 0,37 | 0,63 | 131,54 |
| 5 | 144,07 | 6,20 | 47 | 144,83 | 0,46 | 0,54 | 144,48 |

Dado que $\tilde{X}_2(N_2)$ es la media muestral ponderada más pequeña, seleccionamos la política 2 (20, 80) como la mejor.

7.4.2. Seleccionando los mejores m de k sistemas

Ahora consideremos que queremos seleccionar un subconjunto de m de los k sistemas para que, con una probabilidad de al menos P^* , el subconjunto seleccionado contenga un sistema con la respuesta media más pequeña μ_{i_1} .

Definimos X_{ij} , μ_i y μ_{i_1} como antes. Asumimos que todos los X_{ij} 's son independientes y normales, y para i fijo, $X_{i1}, X_{i2}, \dots$ son iid; los $\sigma_i^2 = \mathbb{V}[X_{ij}]$ son desconocidos y no necesitan ser iguales.

Se define una SC para pretender que el subconjunto de tamaño m que se selecciona contenga un sistema con media μ_{i_1} y queremos $\mathbb{P}(\text{SC}) \geq P^*$ siempre que $\mu_{i_2} - \mu_{i_1} \geq d^*$. Aquí, debemos tener $1 \leq m \leq k - 1$, $P^* >$

m/k , y $d^* > 0$.

El procedimiento es muy similar al procedimiento $\mathcal{DD}$ y ha sido derivado por Koenig & Law (1985) (y denominaremos $\mathcal{KL}$):

1. Tomamos una muestra de primera etapa de $n_0 \geq 2$ réplicas de cada sistema y definimos $\bar{X}_i^{(1)}(n_0)$ y $S_i^2(n_0)$ para $i = 1, 2, \dots, k$ exactamente como en $\mathcal{DD}$.
2. Calculamos el número total de réplicas, N_i , necesarias para el i -ésimo sistema exactamente como en (7.3), excepto que h_1 se reemplaza por h_2 dado por la Tabla 7.2.

| m | $k = 3$ | $k = 4$ | $k = 5$ | $k = 6$ | $k = 7$ | $k = 8$ | $k = 9$ | $k = 10$ |
|------------------------|---------|---------|---------|---------|---------|---------|---------|----------|
| $P^* = 0,9, n_0 = 20$ | | | | | | | | |
| 2 | 1,137 | 1,601 | 1,860 | 2,039 | 2,174 | 2,282 | 2,373 | 2,450 |
| 3 | | 0,782 | 1,243 | 1,507 | 1,690 | 1,830 | 1,943 | 2,038 |
| 4 | | | 0,556 | 1,012 | 1,276 | 1,461 | 1,603 | 1,718 |
| 5 | | | | 0,392 | 0,843 | 1,105 | 1,291 | 1,434 |
| 6 | | | | | 0,265 | 0,711 | 0,971 | 1,156 |
| 7 | | | | | | 0,162 | 0,603 | 0,861 |
| 8 | | | | | | | 0,075 | 0,512 |
| 9 | | | | | | | | † |
| $P^* = 0,9, n_0 = 40$ | | | | | | | | |
| 2 | 1,114 | 1,57 | 1,825 | 1,999 | 2,131 | 2,237 | 2,324 | 2,399 |
| 3 | | 0,763 | 1,219 | 1,479 | 1,660 | 1,798 | 1,909 | 2,002 |
| 4 | | | 0,541 | 0,991 | 1,251 | 1,434 | 1,575 | 1,688 |
| 5 | | | | 0,381 | 0,824 | 1,083 | 1,266 | 1,408 |
| 6 | | | | | 0,257 | 0,693 | 0,950 | 1,133 |
| 7 | | | | | | 0,156 | 0,587 | 0,841 |
| 8 | | | | | | | 0,072 | 0,497 |
| 9 | | | | | | | | † |
| $P^* = 0,95, n_0 = 20$ | | | | | | | | |
| 2 | 1,631 | 2,071 | 2,321 | 2,494 | 2,625 | 2,731 | 2,819 | 2,894 |
| 3 | | 1,256 | 1,697 | 1,952 | 2,131 | 2,267 | 2,378 | 2,470 |
| 4 | | | 1,021 | 1,458 | 1,714 | 1,894 | 2,033 | 2,146 |
| 5 | | | | 0,852 | 1,284 | 1,539 | 1,720 | 1,860 |
| 6 | | | | | 0,721 | 1,149 | 1,402 | 1,583 |
| 7 | | | | | | 0,615 | 1,038 | 1,290 |
| 8 | | | | | | | 0,526 | 0,945 |
| 9 | | | | | | | | 0,449 |
| $P^* = 0,95, n_0 = 40$ | | | | | | | | |
| 2 | 1,591 | 2,023 | 2,267 | 2,435 | 2,563 | 2,665 | 2,750 | 2,823 |
| 3 | | 1,222 | 1,656 | 1,907 | 2,082 | 2,217 | 2,325 | 2,415 |
| 4 | | | 0,990 | 1,420 | 1,672 | 1,850 | 1,987 | 2,098 |
| 5 | | | | 0,824 | 1,248 | 1,499 | 1,678 | 1,816 |
| 6 | | | | | 0,695 | 1,114 | 1,363 | 1,541 |
| 7 | | | | | | 0,591 | 1,004 | 1,252 |
| 8 | | | | | | | 0,505 | 0,913 |
| 9 | | | | | | | | 0,430 |

† Recordar que para este problema de selección debemos tener $P^* > m/k$. (Si $P^* = 0,9$, $m = 9$, $k = 10$, podemos obtener $\mathbb{P}(SC) = P^*$ seleccionando nueve sistemas al azar, sin ninguna recopilación de datos en absoluto)

Tabla 7.2: Constantes para procedimiento $\mathcal{KL}$

3. Correr $N_i - n_0$ réplicas más, formar las medias muestrales de segunda etapa $\bar{X}_i^{(2)}(N_i - n_0)$, pesos W_{i1} y W_{i2} , y la media muestral ponderada $\tilde{X}_i(N_i)$, como en el procedimiento $\mathcal{DD}$.
4. Finalmente, definir el subconjunto seleccionado para que consista en los m sistemas correspondientes a los m valores más pequeños de los $\tilde{X}_i(N_i)$'s.

Ejemplo 7.7. Considerar nuevamente los cinco sistemas de inventario del Ejemplo 7.4. Ahora, sin embargo, suponer que queremos seleccionar $m = 3$ de entre los sistemas $k = 5$ y estar seguros con un nivel de confianza de al menos $P^* = 0,9$ que el subconjunto seleccionado contiene el mejor sistema (de menor costo) siempre que $\mu_{i_2} - \mu_{i_1} \geq d^* = 1$.

Nuevamente, hacer $n_0 = 20$ réplicas iniciales de cada sistema. Los resultados completos para el procedimiento de selección de subconjuntos se presentan en la siguiente tabla:

| i | $\bar{X}_i^{(1)}(20)$ | $S_i^2(20)$ | N_i | $\bar{X}_i^{(2)}(N_i - 20)$ | W_{i1} | W_{i2} | $\tilde{X}_i(N_i)$ |
|-----|-----------------------|-------------|-------|-----------------------------|----------|----------|--------------------|
| 1 | 124,71 | 17,16 | 27 | 125,64 | 0,80 | 0,20 | 124,89 |
| 2 | 121,20 | 12,64 | 21 | 125,69 | 1,01 | -0,01 | 121,15 |
| 3 | 125,57 | 9,07 | 21 | 123,51 | 1,10 | -0,10 | 125,78 |
| 4 | 132,39 | 6,22 | 21 | 133,37 | 1,18 | -0,18 | 132,21 |
| 5 | 144,27 | 4,23 | 21 | 143,67 | 1,27 | -0,27 | 144,43 |

Notar que la subsección seleccionada consta de las políticas 1, 2 y 3, con $\tilde{X}_2(N_2) \leq \tilde{X}_1(N_1) \leq \tilde{X}_3(N_3)$.

7.4.3. Procedimientos totalmente secuenciales

Los procedimientos de clasificación y selección discutidos hasta ahora involucran un muestreo en dos etapas, donde se calcula una estimación de la varianza a partir de las observaciones de la primera etapa y se usan para determinar el número de observaciones adicionales requeridas en la segunda etapa.

Observación 7.4 (Desventaja). Si la estimación de la varianza de la primera etapa resulta ser mucho mayor que la varianza real, se prescribirá una cantidad de muestreo tal vez innecesariamente grande en la segunda etapa.

Se han propuesto procedimientos totalmente secuenciales, en los que se toma una sola “observación” (e.g., la respuesta promedio de una réplica completa) de cada sistema alternativo que todavía está en funcionamiento en la etapa actual de muestreo, y se eliminan los sistemas inferiores hasta que se identifique el mejor sistema.

Observación 7.5 (Objetivo). Reducir el número de observaciones necesarias para elegir el mejor sistema con una $\mathbb{P}(\text{SC})$ especificada.

Capítulo 8

Optimización Basada en Simulación

8.1. Problema General

Una característica importante del análisis de un modelo de simulación es encontrar una combinación de los factores (parámetros) de entrada que optimice alguna medida clave de rendimiento. A veces, el resultado principal puede ser, por ejemplo, minimizar algún costo sobre todos los valores posibles de los factores de entrada. En general, estos factores pueden incluir:

- El número de máquinas en una estación de trabajo en un sistema de producción (discreto).
- Variables como el tiempo medio de procesamiento de una máquina (continuo).
- Elección de una disciplina de fila (cualitativa).

Aunque sería posible buscar valores óptimos de factores de entrada tanto controlables como incontrolables, el enfoque principal en la mayoría de las aplicaciones está en los factores de entrada que son controlables (diseño de instalaciones o políticas operativas). Este objetivo de optimización puede parecer bastante similar a los objetivos de seleccionar el mejor sistema (Capítulo 7). Allí, sin embargo, asumimos que las configuraciones alternativas estaban dadas (conocidas de antemano).

Ahora tenemos una situación menos estructurada en la que tenemos que decidir qué configuración alternativa simular y cómo evaluar y comparar sus resultados. Dado que potencialmente estamos analizando todas

las combinaciones posibles de una gran cantidad de factores de entrada, la cantidad de configuraciones alternativas para simular y comparar podría ser literalmente bastante grande. Es útil pensar en este problema en términos de programación matemática (optimización) clásica.

En general, queremos resolver un problema de optimización como

$$\max_{\mathbf{x}} \quad \mathbb{E}[R(\mathbf{x})] \quad (8.1a)$$

$$\text{s.a.} \quad \mathbf{A}\mathbf{x} \leq \mathbf{b} \quad (8.1b)$$

$$\mathbf{l} \leq \mathbf{x} \leq \mathbf{u} \quad (8.1c)$$

$$\mathbf{x} \in \mathbb{Z}^n \times \mathbb{R}^{p-n}, \quad (8.1d)$$

donde:

- R representa una medida de rendimiento de salida de la simulación (por ejemplo, ganancias) que depende de $\mathbf{x}$.
- $\mathbf{x}$ es un vector de dimensión p de variables de decisión.
- $\mathbf{A}$ y $\mathbf{b}$ son una matriz y un vector de algunas constantes que relacionan las variables de decisión $\mathbf{x}$.
- $\mathbf{l}$ y $\mathbf{u}$ representan algunos límites inferiores y superiores sobre las variables de decisión $\mathbf{x}$.

Resolver un problema de optimización de este tipo en un contexto real de simulación puede ser muy desafiante:

1. Si p , el número de variables de decisión (factores de entrada en la simulación), es grande, estamos buscando un punto óptimo en un espacio p -dimensional (bastante grande).
2. En simulación no podemos evaluar la función objetivo simplemente conectando un conjunto de posibles valores de variables de decisión en una fórmula simple de forma cerrada. En este contexto, pensar en la simulación como una caja negra que devuelve el resultado una vez que se ha ejecutado una réplica.
3. En la simulación estocástica no podemos evaluar la función objetivo exactamente debido a la aleatoriedad en la salida.

Varias investigaciones han sido propuestas y desarrolladas con respecto a métodos que intentan optimizar una simulación buscando en el espacio de posibles combinaciones de factores de entrada. Estos procedimientos de búsqueda generalmente se pueden clasificar como:

- Metaheurísticas como algoritmos genéticos (*genetic algorithms*), recocido simulado (*simulated annealing*), búsqueda tabú (*tabu search*) y búsqueda de dispersión (*scatter search*).
- Metodología de superficie de respuesta (*response-surface*).
- Procedimientos basados en gradientes.
- Búsqueda aleatoria.
- Optimización *sample-path*.

En este capítulo nos centraremos en las metaheurísticas, que son métodos que guían otras heurísticas de búsqueda evitando quedar atrapados en óptimos locales. De esta manera, serán mezclados paquetes de optimización junto con modelos de simulación de acuerdo al diagrama de la Figura 8.1.




Figura 8.1: Diagrama de conexión optimización-simulación

Algunos paquetes de optimización que operan en ciertos *software* de simulación pueden ser los descritos en la Tabla 8.1. En particular, este capítulo se centrará en discutir acerca del paquete OptQuest y sus procedimientos de búsqueda como búsqueda tabú, búsqueda dispersa y redes neuronales.

| Paquete | Empresa desarrolladora | Software de simulación compatibles | Procedimientos de búsqueda utilizados |
|---------------------|------------------------|---|--|
| AutoStat | Applied Materials | AutoMod, AutoSched | Estrategias de evolución |
| ExtendSim Optimizer | Imagine That, Inc. | ExtendSim | Estrategias de evolución |
| OptQuest | OptTek Systems, Inc. | AnyLogic, Arena, FlexSim, Simio, SIMUL8 | Búsqueda dispersa, búsqueda tabú, redes neuronales |
| SimRunner | ProModel Corp. | MedModel, ProModel, ServiceModel | Estrategias de evolución, algoritmos genéticos |
| WITNESS Optimizer | Lanner Group, Inc. | WITNESS | Recocido simulado, búsqueda tabú |

Tabla 8.1: Paquetes de optimización en *software* de simulación

8.2. Búsqueda tabú

Las heurísticas están diseñadas para encontrar buenas soluciones aproximadas a problemas de optimización combinatorial difíciles como

$$\min_{\mathbf{x}} \quad \mathbf{c}^\top \mathbf{x} \quad (8.2a)$$

$$\text{s.a.} \quad \mathbf{Ax} \leq \mathbf{b} \quad (8.2b)$$

$$\mathbf{l} \leq \mathbf{x} \leq \mathbf{u} \quad (8.2c)$$

$$\mathbf{x} \in \mathbb{Z}^P. \quad (8.2d)$$

En alguna iteración k en una heurística, el procedimiento de búsqueda se mueve a un nuevo punto $\mathbf{x}_{k+1} \in \mathbf{N}(\mathbf{x}_k)$ si y sólo si el nuevo punto mejora el valor de la función objetivo $\mathbf{c}^\top \mathbf{x}$.

Las Metaheurísticas se pueden pensar como métodos que guían a las heurísticas para escapar del atrapamiento en óptimos locales, lo que permite movimientos inferiores (que empeoran el objetivo), si es necesario (Figura 8.2). Algunos ejemplos:

- Recocido simulado.
- Algoritmos genéticos.
- Búsqueda tabú.
- Búsqueda dispersa.

Cuando la búsqueda está atrapada en un óptimo local, la búsqueda tabú (TS, en inglés) selecciona el siguiente movimiento de búsqueda (posiblemente inferior) de una manera que temporalmente prohíbe volver a examinar soluciones anteriores.




Figura 8.2: Diferencia entre óptimo global y local

El instrumento principal para lograr este resultado es una lista tabú que “recuerda” los movimientos de búsqueda anteriores y los rechaza durante un período de permanencia especificado.


Cuando un movimiento tabú completa su permanencia, se elimina de la lista tabú y queda disponible para futuros movimientos. Así, para cada iteración k , tenemos:

- $\mathbf{x}_k$: solución de prueba actual.
- $N(\mathbf{x}_k)$: vecindario de $\mathbf{x}_k$.
- L_k : lista tabú de valores inadmisibles de $\mathbf{x}$ en la iteración k .
- τ : período de permanencia tabú expresado en número de iteraciones sucesivas.
- $\mathbf{x}^*$: mejor solución encontrada durante la búsqueda.

Ejemplo 8.1. Este ejemplo detalla la aplicación de TS al problema de optimización

$$\begin{array}{ll} \min_x & f(x) \\ \text{s.a.} & x \in S := \{1, 2, \dots, 8\}. \end{array}$$

La función $f(x)$ tiene un mínimo local en $x = 3$ y un mínimo global en $x = 7$, como la figura muestra



Para $\tau = 3$, $N(x_k) = \{x_k - 4, \dots, x_k - 1, x_k + 1, \dots, x_k + 4\} - L_k$, tenemos los siguientes resultados para 5 iteraciones:

| Iteración (k) | R_k | x_k | $f(x_k)$ | L_k | $N(x_k)$ |
|-------------------|--------|-------|----------|---------------|---------------------|
| (Inicio) 0 | 0,0935 | 1 | 90 | | $\{2, 3, 4, 5\}$ |
| 1 | 0,4128 | 3 | 50 | $\{1\}$ | $\{2, 4, 5, 6, 7\}$ |
| 2 | 0,2039 | 4 | 80 | $\{1, 3\}$ | $\{2, 5, 6, 7, 8\}$ |
| 3 | 0,0861 | 2 | 60 | $\{1, 3, 4\}$ | $\{5, 6\}$ |
| 4 | 0,3769 | 5 | 100 | $\{3, 4, 2\}$ | $\{1, 6, 7, 8\}$ |
| (Fin) 5 | 0,5712 | 7 | 20 | $\{4, 2, 5\}$ | $\{3, 6, 8\}$ |

Mejor solución heurística: $x = 7$, $f(x) = 20$, en iteración 5 (también sucede que es la óptima)

Observación 8.1. Algunas observaciones:

- En la iteración k , el conjunto vecindario de x_k puede definirse como $N(x_k) = \{x_k - q, \dots, x_k - 1, x_k + 1, \dots, x_k + q\} - L_k$, para $q \in \mathbb{Z}_+$.
 - La definición excluye implícitamente los puntos de solución no factibles. Un elemento tabú puede definir un próximo movimiento de búsqueda si cumple con el llamado Criterio de nivel de aspiración.
 - Por ejemplo, para $x_k = 3$, $q = 4$ y $L_k = \{6\}$, $N(x_k) = \{-1, 0, 1, 2, 4, 5, 6, 7\} - \{6\} = \{1, 2, 4, 5, 7\}$.
- El siguiente movimiento de búsqueda x_{k+1} se puede seleccionar como el mejor entre todas las soluciones en $N(x_k)$, o como un elemento aleatorio de la misma. Aquí usamos este último.
- Para ilustrar los cálculos, $N(x_0 = 1) = \{2, 3, 4, 5\}$. En $k = 1$, $L_1 = \{1\}$ y $R_1 = 0,4128$ seleccionar $x_1 = 3$ de $N(x_0)$, lo que produce $N(x_1) = \{1, 2, 4, 5, 6, 7\} - \{1\} = \{2, 4, 5, 6, 7\}$ y actualiza la lista tabú en la iteración 2 a $L_2 = \{1, 3\}$.
- Un elemento se elimina de la lista tabú en FIFO después del período de permanencia.
- En la iteración k , el siguiente movimiento x_{k+1} se selecciona de $N(x_k)$ con probabilidad $1/m$, donde $m = |N(x_k)|$ (heurística de paseo aleatorio, *random-walk*).

Observación 8.2. Los siguientes refinamientos pueden resultar efectivos para mejorar la calidad de la solución final:

- **Criterio de aspiración:** el diseño de TS no permite movimientos que están en la lista tabú. Se produce una excepción cuando un movimiento no permitido conduce a una solución mejorada.
- **Intensificación y diversificación:** la intensificación exige un examen más completo de los puntos de solución cercanos y la diversificación intenta trasladar la búsqueda a regiones de solución inexploradas. Una forma de implementar estas estrategias es controlar el tamaño de la lista tabú. Esto aumenta el tamaño del conjunto vecindario permisible y, por lo tanto, intensifica la búsqueda de puntos que se encuentran cerca de la mejor solución.

8.3. Búsqueda dispersa

La búsqueda dispersa es una metaheurística que también es un método evolutivo, i.e., opera sobre un conjunto de valores que cambian dinámicamente, el conjunto de referencia (RefSet). Su idea principal es que se puede obtener mejor información sobre las mejores soluciones del problema de optimización usando una combinación de “buenas soluciones”. El significado de buena solución no se refiere sólo a la calidad de la solución, sino también a la diversidad que esta aporta al RefSet. La búsqueda dispersa contiene 5 métodos:

1. Método de generación de diversificación: generar un conjunto $\mathcal{P}$ de soluciones diversas, del cual extraemos un subconjunto denominado RefSet.
2. Método de mejora: es un método de búsqueda local que busca mejorar las soluciones tanto en el RefSet como en las combinaciones.
3. Método de actualización del conjunto de referencia: del conjunto $\mathcal{P}$ se obtiene el RefSet según el criterio de contener soluciones de alta calidad y diferentes entre ellas (calidad y diversidad).
4. Método de generación de subconjuntos: este método especifica la forma en que se seleccionan los subconjuntos para aplicarles un método de combinación.




Figura 8.3: Esquema de resumen de funcionamiento de búsqueda dispersa

5. Método de combinación de soluciones: aquí se aplica un método de combinación a los subconjuntos obtenidos en el paso anterior. Estas soluciones pueden introducirse inmediatamente en el RefSet o almacenarse temporalmente en una lista hasta que se completen todas las combinaciones.

Finalmente, el algoritmo se detiene cuando no hay nuevos elementos para agregar al RefSet. La Figura 8.3 resume su idea principal de funcionamiento.

Para ilustrar el método de búsqueda dispersa, considerar el siguiente problema de mochila 0-1:

$$\begin{aligned}
 \text{máx} \quad & 11x_1 + 10x_2 + 9x_3 + 12x_4 + 10x_5 + 6x_6 + 7x_7 + 5x_8 + 3x_9 + 8x_{10} \\
 \text{s.a.} \quad & 33x_1 + 27x_2 + 16x_3 + 14x_4 + 29x_5 + 30x_6 + 31x_7 + 33x_8 + 14x_9 + 18x_{10} \leq 100 \\
 & x_i \in \{0, 1\}, \quad i = 1, \dots, 10
 \end{aligned}$$

1. Primero, construiremos el conjunto inicial $\mathcal{P}$ con 100 soluciones. La siguiente tabla muestra los primeros 10 con sus respectivos valores óptimos. Considerar que algunas soluciones son inviables, por lo que sus valores objetivo pueden ser mayores que el valor óptimo real.

| Solución | x_1 | x_2 | x_3 | x_4 | x_5 | x_6 | x_7 | x_8 | x_9 | x_{10} | $f(\mathbf{x})$ |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|-----------------|
| 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 2 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 81 |
| 3 | 0 | 1 | 0 | 1 | 0 | 1 | 0 | 1 | 0 | 1 | 41 |
| 4 | 1 | 0 | 1 | 0 | 1 | 0 | 1 | 0 | 1 | 0 | 40 |
| 5 | 0 | 1 | 1 | 0 | 1 | 1 | 0 | 1 | 1 | 0 | 43 |
| 6 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 38 |
| 7 | 1 | 0 | 1 | 1 | 0 | 1 | 1 | 0 | 1 | 1 | 56 |
| 8 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 25 |
| 9 | 1 | 1 | 0 | 1 | 1 | 0 | 1 | 1 | 0 | 1 | 63 |
| 10 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 18 |

2. Debido a que las soluciones anteriores pueden ser inviables, el método de mejora debe incorporar un mecanismo para asegurar la viabilidad de la solución final. Este mecanismo es el siguiente:

- Fase de factibilidad: para asegurar la factibilidad basta con cambiar el valor de algunas variables de 1 a 0. Podemos considerar las variables en orden creciente con respecto a la relación valor/peso, comenzando por la relación más baja. Una vez que la solución es factible (se cumple la restricción) pasamos a la siguiente fase.
- Fase de mejora: A diferencia de la fase anterior, ahora cambiaremos algunos valores de 0 a 1 para incrementar el valor óptimo. En este caso comenzaremos por la variable con mayor relación valor/peso y luego continuaremos en orden decreciente mientras la solución sea factible.
- Con ambas fases aplicadas, los resultados (conjunto $\mathcal{P}$) se muestran en la siguiente tabla.

| Solución | Solución factible | Valor | Solución mejorada | Valor |
|----------|-----------------------|-------|-----------------------|-------|
| 1 | (0,0,0,0,0,0,0,0,0,0) | 0 | (0,1,1,1,0,0,0,0,0,1) | 39 |
| 2 | (0,1,1,1,0,0,0,0,0,1) | 39 | (0,1,1,1,0,0,0,0,0,1) | 39 |
| 3 | (0,1,0,1,0,1,0,0,0,1) | 36 | (0,1,0,1,0,1,0,0,0,1) | 36 |
| 4 | (1,0,1,0,1,0,0,0,0,0) | 30 | (1,0,1,1,1,0,0,0,0,0) | 42 |
| 5 | (0,1,1,0,1,0,0,0,1,0) | 32 | (0,1,1,1,1,0,0,0,1,0) | 44 |
| 6 | (1,0,0,1,0,0,1,0,0,1) | 38 | (1,0,0,1,0,0,1,0,0,1) | 38 |
| 7 | (1,0,1,1,0,0,0,0,0,1) | 40 | (1,0,1,1,0,0,0,0,0,1) | 40 |
| 8 | (0,1,0,0,1,0,0,1,0,0) | 25 | (0,1,0,0,1,0,0,1,0,0) | 25 |
| 9 | (0,1,0,1,1,0,0,0,0,1) | 40 | (0,1,0,1,1,0,0,0,0,1) | 40 |
| 10 | (0,0,1,0,0,1,0,0,1,0) | 18 | (0,0,1,1,0,1,0,0,1,1) | 38 |

3. A partir de $\mathcal{P}$ construimos el RefSet con las 5 mejores soluciones. Para completar el RefSet con hasta 10 elementos añadimos los 5 más diversos respecto a los considerados anteriormente. Usamos un método aproximado que suma una a una las soluciones con una distancia máxima. La distancia de dos soluciones $\mathbf{x}$ y $\mathbf{y}$ se puede considerar como $d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^{10} |\mathbf{x}_i - \mathbf{y}_i|$.
4. Para la generación de subconjuntos, aplicamos la forma más sencilla que consiste en hacer únicamente combinaciones de dos elementos.
5. Una vez construido el RefSet combinamos sus elementos. En cada fase de combinación consideramos todos los pares de soluciones que no se han combinado antes. El método de combinación calcula una puntuación para cada variable. La puntuación (*score*) de la variable i al combinar las soluciones RefSet j y k es

$$score(i) = \frac{f(j)x_i^j + f(k)x_i^k}{f(j) + f(k)}.$$

Estas puntuaciones pueden interpretarse como $\mathbb{P}(x_i = 1) = score(i)$.

6. Esto es equivalente a generar un número aleatorio $r \in [0, 1]$ para cada variable y hacer:

$$x_i = \begin{cases} 1 & r \leq score(i) \\ 0 & r > score(i) \end{cases}.$$

Por ejemplo, suponer las soluciones RefSet 4 y 5, con $f(4) = 44$ y $f(5) = 43$. Tomando $r = 0,5$ para cada variable obtenemos una

nueva solución $(0, 1, 1, 1, 1, 0, 0, 0, 1, 0)$ con un valor de 44

| Solución | x_1 | x_2 | x_3 | x_4 | x_5 | x_6 | x_7 | x_8 | x_9 | x_{10} |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|
| 4 | 0 | 1 | 1 | 1 | 1 | 0 | 0 | 0 | 1 | 0 |
| 5 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 1 | 1 |
| Score | 0,49 | 0,51 | 1 | 1 | 0,51 | 0 | 0 | 0 | 1 | 0,49 |

7. Cuando se hacen todas las combinaciones, estudiamos la inclusión de cada solución del RefSet. Para eso comparamos cada solución con la peor del RefSet, y si es mejor, la reemplazamos. Una vez actualizado el RefSet, volvemos a la fase de combinación donde consideramos todos los pares de soluciones del RefSet no combinados previamente.

Este proceso de combinación/mejora/actualización del RefSet se repite hasta que, al intentar combinar soluciones, no encontramos un nuevo par. En este momento termina el algoritmo.

8.4. Redes neuronales

8.4.1. Neuronas

Corresponde a la unidad básica de procesamiento de una red neuronal. Son similares a una neurona biológica porque tienen conexiones de entrada con las que reciben estímulos externos ($\mathbf{x}$).

Con los valores de $\mathbf{x}$, la neurona realizará un cálculo interno (suma ponderada) para generar la salida ($\mathbf{y}$) en función de algunos pesos de entrada ($\mathbf{w}$) que tienen que ser ajustados de manera eficiente. La Figura 8.4 resume su estructura general.

Los pesos $\mathbf{w}$ son precisamente los parámetros del modelo que deben ser ajustados eficientemente. Se puede pensar en la neurona como una regresión lineal que determina los coeficientes de las variables endógenas. Así, la neurona también puede ser algo así como

$$y = w_1x_1 + w_2x_2 + w_3x_3 + b,$$

donde b se conoce como sesgo (*bias*). Para replicar una regresión lineal usando una red neuronal bastaría con agregar una nueva entrada $x_4 = 1$




Figura 8.4: Estructura general de una neurona en una red neuronal

cuyo peso sea b , haciendo que la suma interna de la neurona sea

$$y = w_1x_1 + w_2x_2 + w_3x_3 + bx_4.$$

8.4.2. Red neuronal

Una red neuronal es básicamente una mezcla de varias neuronas (Figura 8.5). Una alternativa para organizar las neuronas es juntarlas verticalmente, lo que se conoce como capa (*layer*). Las neuronas de una misma capa (n) recibirán como entrada la información de la capa anterior ($n - 1$), y los cálculos realizados pasarán a la siguiente capa ($n + 1$). La capa que contiene las variables de entrada se conoce como capa de entrada (*input layer*), y la capa que contiene las variables de salida es la capa de salida (*output layer*). Las capas intermedias se conocen como capas ocultas (*hidden layers*).

Cuando dos neuronas se colocan secuencialmente (Figura 8.6), una de ellas recibe la información procesada por la neurona anterior. Así, la red puede aprender conocimientos más básicos en las primeras capas para luego elaborar conocimientos más complejos en las capas siguientes.

Cuantas más capas se agreguen, más complejo puede ser el conocimiento elaborado. Esta profundidad en el número de capas es lo que le da su nombre a aprendizaje profundo (*deep learning*). Para lograr este aprendizaje profundo hemos buscado conectar múltiples neuronas de forma secuencial y, de lo anterior, recordar que lo que hace cada una de estas neuronas es una regresión lineal. Así, matemáticamente, estamos concatenando diferentes operaciones de regresión lineal. Se puede demostrar que la suma de múltiples regresiones colapsa en una sola regresión




Figura 8.5: Estructura general de red neuronal




Figura 8.6: Estructura general de red neuronal secuencial

h!




Figura 8.7: Colapso de múltiples regresiones lineales

(Figura 8.7).

8.4.3. Funciones de activación

Para asegurar que una red no colapse, es necesario que la suma de las regresiones lineales a la izquierda de la igualdad de la figura anterior resulte en algo diferente a una función lineal. En particular, es necesario que cada una de las regresiones del lado izquierdo sufra alguna manipulación no lineal que las distorsione. Esto se logra con las llamadas funciones de activación (*activation functions*).

Si el valor de salida de una neurona se calcula como $y = \mathbf{w}^\top \mathbf{x}$, ahora queremos usar este valor de salida y en una función de activación $f(\cdot)$. Esta función distorsionará el valor de salida agregando algunas no linealidades. Algunas funciones de activación clásicas son las que se observan en la Figura 8.8.




Figura 8.8: Funciones de activación clásicas

8.4.4. Algoritmo de descenso de gradiente

Considerar el problema de optimización convexa sin restricciones

$$\min_{\mathbf{x}} f(\mathbf{x})$$

donde, f es convexa y diferenciable con $\text{dom}(f) = \mathbb{R}^n$. Denotaremos el valor óptimo como $f^* = \min_{\mathbf{x}} f(\mathbf{x})$, y la solución óptima por $\mathbf{x}^*$.

Observación 8.3 (Descenso de gradiente). Elegir un punto inicial $\mathbf{x}^{(0)} \in \mathbb{R}^n$, y repetir:

$$\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} - t_k \cdot \nabla f(\mathbf{x}^{(k-1)}), \quad k = 1, 2, 3, \dots$$

donde t_k se conoce como el tamaño de paso. Parar si $\|\nabla f(\mathbf{x}^{(k-1)})\| \leq \epsilon$.

Simplemente tomando $t_k = t$ para todo $k = 1, 2, 3, \dots$, puede divergir si t es demasiado grande. Además, si t es demasiado pequeño, la convergencia del algoritmo puede ser muy lenta.

Dado que nuestro objetivo es minimizar $f(\mathbf{x})$, un enfoque razonable es elegir el tamaño de paso de manera que minimice el valor del nuevo punto, es decir, encontrar el tamaño de paso que minimice $f(\mathbf{x}^{(k)})$. Dado que $\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} - t \nabla f(\mathbf{x}^{(k-1)})$, el paso el tamaño t_k^* de este enfoque es

$$t_k^* = \arg \min_{t \in \mathbb{R}^+} f(\mathbf{x}^{(k-1)} - t \nabla f(\mathbf{x}^{(k-1)})).$$

Observación 8.4. Para obtener más información sobre este algoritmo, consultar el Capítulo 9 del libro *Convex Optimization* de Boyd & Vandenberghe.

La Figura 8.9 presenta dos ejemplos del funcionamiento gráfico del algoritmo de descenso de gradiente, para una y dos dimensiones.




Figura 8.9: Ejemplos de descenso de gradiente en una y dos dimensiones

8.4.5. Algoritmo de retropropagación

Retropropagación (*backpropagation*) es un algoritmo ampliamente utilizado para entrenar redes neuronales y se basa en el algoritmo de descenso de gradiente. Funciona calculando el gradiente de la función de pérdida (*loss function*) con respecto a cada peso mediante la regla de la cadena (*chain rule*), calculando el gradiente de una capa a la vez, iterando hacia atrás desde la última capa para evitar cálculos redundantes de términos intermedios en la regla de la cadena; este es un ejemplo de programación dinámica (*dynamic programming*).

Usaremos la misma neurona básica del principio (Figura 8.4) para explicar cómo funciona la retropropagación. Recordar que los términos importantes son $\mathbf{w}$ y b . Suponer que tenemos una red neuronal con L capas. Sean:

- $z^l = \mathbf{x}^\top \mathbf{w}^l + \mathbf{b}^l$, que luego pasará por la función de activación $a(z^l)$.

- C , una función de pérdida como el error cuadrático medio.

$$C(a_j^L) = \frac{1}{J} \sum_{j=1}^J (y_j - a_j^L)^2.$$

- El resultado de las activaciones de neuronas en la última capa constituiría el resultado de la red, que luego sería evaluado por la función de costo $C(a(z^L)) = \epsilon$.

El algoritmo de retropropagación funciona de la siguiente manera:

1. Calcular el error de la última capa:

$$\delta^L = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L}.$$

2. Propagar el error a la capa previa:

$$\delta^{l-1} = \mathbf{w}^l \delta^l \cdot \frac{\partial \mathbf{a}^{l-1}}{\partial \mathbf{z}^{l-1}}.$$

3. Calcular las derivadas de la capa usando el error:

$$\begin{aligned} \frac{\partial C}{\partial b^{l-1}} &= \delta^{l-1} \\ \frac{\partial C}{\partial \mathbf{w}^{l-1}} &= \delta^{l-1} \mathbf{a}^{l-2}. \end{aligned}$$

Como el objetivo del proceso de aprendizaje es minimizar ϵ , se debe tomar la dirección negativa del gradiente para obtener la mayor disminución en el error.

8.5. Paquete OptQuest

La Biblioteca Invocable de OptQuest (*OptQuest Callable Library*, OCL) es el motor de optimización del sistema OptQuest. El objetivo de OptQuest es optimizar sistemas complejos, que son aquellos que no pueden formularse fácilmente como modelos matemáticos y resolverse con herramientas clásicas de optimización.¹

Múltiples no linealidades, relaciones combinatoriales e incertidumbres a menudo hacen que los problemas prácticos desafiantes sean inaccesibles para el modelamiento, excepto recurriendo a herramientas más completas (como la simulación).

¹Esta sección se basa completamente en Laguna & Martí (2002)

Los avances en el campo de las metaheurísticas han llevado a la creación de motores de optimización que guían con éxito una serie de evaluaciones complejas con el objetivo de encontrar valores óptimos para las variables de decisión. Uno de esos motores es el algoritmo de búsqueda integrado en OCL.

OCL está diseñado para buscar soluciones óptimas a la siguiente clase de problemas de optimización

$$\begin{array}{lll}
 \min_{\mathbf{x}} & F(\mathbf{x}) & \\
 \text{s.t.} & \mathbf{Ax} \leq \mathbf{b} & \text{(Restricciones)} \\
 & \mathbf{g_l} \leq \mathbf{G}(\mathbf{x}) \leq \mathbf{g_u} & \text{(Requerimientos)} \\
 & \mathbf{l} \leq \mathbf{x} \leq \mathbf{u}, & \text{(Cotas)}
 \end{array}$$

donde $\mathbf{x}$ puede ser continuo o discreto, el conjunto de restricciones debe ser lineal y $\mathbf{A}$, $\mathbf{b}$, $\mathbf{g_l}$, $\mathbf{g_u}$, $\mathbf{l}$ y $\mathbf{u}$ deben conocerse de antemano.

En un optimizador de propósito general como OCL, es preferible separar el procedimiento de solución del sistema complejo a optimizar. Una desventaja de este enfoque tipo caja negra (*black box*) es que el procedimiento de optimización es genérico y no sabe nada sobre lo que sucede dentro de la caja. La clara ventaja es que el mismo optimizador se puede usar para muchos sistemas complejos

OCL es un optimizador genérico que supera la deficiencia de los sistemas de caja negra y encarna con éxito el principio de separar el método del modelo. En este contexto, el problema de optimización se define fuera del sistema complejo. Así, el evaluador puede cambiar o incorporar elementos adicionales del sistema complejo, manteniéndose el mismo procedimiento de optimización.

El funcionamiento de OptQuest se basa en la búsqueda dispersa, considerando algunos elementos de búsqueda tabú y redes neuronales. Debido a que OptQuest es un procedimiento comercial, se desconocen las etapas exactas de operación. La siguiente descripción del procedimiento se basa en Faundes & Gazmuri (2014), y se puede descomponer como:

1. Inicialización del algoritmo
2. Proceso iterativo
3. Estrategia de reinicio

8.5.1. Inicialización del algoritmo

En primer lugar, se define una población diversa de soluciones. Esta población siempre contiene las siguientes soluciones:

- Todas las variables toman los mínimos valores posibles ($\mathbf{x} = \mathbf{l}$).
- Todas las variables toman los máximos valores posibles ($\mathbf{x} = \mathbf{u}$).
- Todas las variables toman el valor medio ($\mathbf{x} = (\mathbf{l} + \mathbf{u})/2$).
- Adicionalmente, se incluyen las soluciones sugeridas por el usuario.

Para sumar diversidad a esta población, se agregan algunas soluciones basadas en la siguiente metodología:

1. El rango de cada variable se divide en 4 sub-rangos de igual tamaño.
2. Seleccionar aleatoriamente un sub-rango, donde la probabilidad de selección de un sub-rango es inversamente proporcional al número de veces que se ha seleccionado ese sub-rango.
3. Seleccione aleatoriamente un valor dentro del sub-rango.

Este método se basa en diseños avanzados de búsqueda dispersa. Opt-Quest determina automáticamente el tamaño de la población en función del tiempo necesario para evaluar la función objetivo

Después de la generación de la población inicial, se selecciona un subconjunto como primer conjunto de referencia (basado en un conjunto diverso como criterio). Las soluciones generadas se prueban en términos de factibilidad. Primero, se realiza el redondeo de variables si es necesario. Luego, se revisan las restricciones $\mathbf{Ax} \leq \mathbf{b}$. Si hay algunos $\mathbf{x}$ tales que $\mathbf{Ax} > \mathbf{b}$, se asignan a $\mathbf{x}^*$ (cerca de $\mathbf{x}$) tal que $\mathbf{Ax}^* \leq \mathbf{b}$. Esto se obtiene resolviendo el problema

$$\text{mín} \quad \mathbf{d}^- + \mathbf{d}^+ \quad (8.3a)$$

$$\text{s.t.} \quad \mathbf{Ax}^* \leq \mathbf{b} \quad (8.3b)$$

$$\mathbf{x} - \mathbf{x}^* - \mathbf{d}^- + \mathbf{d}^+ = \mathbf{0} \quad (8.3c)$$

$$\mathbf{l} \leq \mathbf{x}^* \leq \mathbf{u} \quad (8.3d)$$

$$\mathbf{d}^-, \mathbf{d}^+ \geq \mathbf{0}, \quad (8.3e)$$

donde $\mathbf{d}^-$ y $\mathbf{d}^+$ son las desviaciones negativas y positivas desde $\mathbf{x}$ a $\mathbf{x}^*$.

8.5.2. Proceso iterativo

Al igual que en la búsqueda dispersa, al comienzo de cada iteración se elige un subconjunto de soluciones para combinar de la siguiente manera:

- El algoritmo elige primero dos soluciones $\mathbf{x}_1$ y $\mathbf{x}_2$ en función de los valores de $G(\mathbf{x}_1)$ y $G(\mathbf{x}_2)$.
- Se consideran algunas nociones de búsqueda tabú para evitar soluciones elegidas recientemente.
- Cada solución en el RefSet tiene una edad que corresponde al número de iteraciones que lleva en el RefSet. Esta antigüedad se utiliza para determinar el atractivo de cada solución (se priorizan las que llevan más tiempo en el RefSet).

Luego, se generan 4 nuevas soluciones en base a $\mathbf{x}_1$ y $\mathbf{x}_2$ como:

$$\mathbf{y}_1 = \mathbf{x}_1 + \mathbf{e}$$

$$\mathbf{y}_2 = \mathbf{x}_1 - \mathbf{e}$$

$$\mathbf{y}_3 = \mathbf{x}_2 + \mathbf{e}$$

$$\mathbf{y}_4 = \mathbf{x}_2 - \mathbf{e},$$

donde $\mathbf{e} = (\mathbf{x}_1 - \mathbf{x}_2)/3$. Luego, estas soluciones son evaluadas en la prueba de factibilidad de (8.3).

Finalmente, el RefSet se actualiza reemplazando el peor valor entre $\mathbf{x}_1$ y $\mathbf{x}_2$ por el mejor entre $\mathbf{y}_1$, $\mathbf{y}_2$, $\mathbf{y}_3$ y $\mathbf{y}_4$. Al sobreviviente entre $\mathbf{x}_1$ y $\mathbf{x}_2$ se le asigna un estado tabú que evita que se elija para un cierto número de iteraciones.

En esta etapa son relevantes las restricciones $G(\mathbf{x})$. En el proceso de inicialización OptQuest no puede verificar si una solución es factible porque necesita que la simulación dé los valores de estas restricciones. Para lidiar con esto, OptQuest define una función de penalización $P(\mathbf{x})$ que se aplica a aquellas soluciones que no satisfacen estas restricciones, como se muestra de manera esquemática en la Figura 8.10.

8.5.3. Uso de redes neuronales

Uno de los principales desafíos de la optimización en simulación es que la simulación es computacionalmente costosa, por lo que la aplicación de algoritmos de optimización en simulación es bastante lenta. OptQuest se ocupa de esto utilizando redes neuronales que evitan la evaluación de




Figura 8.10: Aplicación de penalización de soluciones infactibles en Opt-Quest

soluciones de baja calidad. La idea principal es que una función $r(\mathbf{x}, \mathbf{w})$ estime el valor de $F(\mathbf{x})$ con algunos pesos $\mathbf{w}$. Los pesos se obtienen en un procedimiento de entrenamiento cuyo objetivo es

$$\min \frac{1}{|\mathcal{T}|} \sum_{\mathbf{x} \in \mathcal{T}} (F(\mathbf{x}) - \mathbf{r}(\mathbf{x}, \mathbf{w}))^2,$$

donde $\mathcal{T}$ es un subconjunto aleatorio de soluciones generadas durante la búsqueda.

Si $\mathbf{x}^*$ es la mejor solución encontrada y la red neuronal ya está entrenada, entonces se rechaza a priori una solución $\mathbf{x}$ (sin evaluarla) si se cumple la siguiente condición

$$r(\mathbf{x}, \mathbf{w}) > \mathbf{F}(\mathbf{x}^*) + 2\hat{\sigma}_{\mathbf{F}(\mathbf{x})},$$

siendo $\hat{\sigma}_{F(\mathbf{x})}$ la desviación estándar muestral de $F(\mathbf{x})$. Con esto se evitan soluciones que se espera que sean de muy baja calidad.

Finalmente, en la Figura 8.11 se puede observar cómo configurar Opt-Quest y sus elementos dentro del *software* de simulación Simio.




Figura 8.11: Configuración de OptQuest en *software* Simio

