

Resumen Modelos Estocásticos

Vicente Olea

17 de junio de 2025

Índice

1. Introducción	3
2. Repaso de Probabilidades	3
2.1. Conceptos Básicos	3
2.2. Definición de una probabilidad	3
2.3. Variables Aleatorias	4
3. Procesos Estocásticos	6
4. Proceso Poisson	6
4.1. Proceso de Conteo	6
4.2. Proceso de Poisson	7
4.3. Descomposición y Suma	8
4.4. Extensiones	8
5. Cadenas de Markov en Tiempo Discreto	9
5.1. Motivación	9
5.2. CMTD y sus propiedades	9
5.3. Visitas entre estados	11
5.4. Clasificación de estados	12
5.5. Largo plazo	13
5.6. Distribución Límite y Distribución Estacionaria	14
6. Cadenas de Markov en Tiempo Continuo	15
6.1. Definición	15
6.2. Probabilidades de Transición	16
7. Sistemas de Espera	20
7.1. Definición	20
7.2. Modelos Markovianos	21
7.3. Modelos no Markovianos	23

8. Simulación	24
8.0.1. Estructura de un modelo de simulación de eventos discretos	24
8.0.2. Generación de instancias de una variable aleatoria	26
8.1. Análisis de resultados	33
8.1.1. Réplicas independientes	33
8.1.2. Intervalos de Confianza para un parámetro	33

1 Introducción

El curso busca introducir al alumno en la problemática del modelamiento de sistemas estocásticos. Para esto, se enseñan las técnicas y conceptos básicos que sustentan los modelos analíticos más utilizados en investigación operacional para representar sistemas probabilísticos.

2 Repaso de Probabilidades

2.1. Conceptos Básicos

Experimento Aleatorio

Resultado cuyo desenlace no puede predecirse *a priori*.

Espacio Muestral Ω

Conjunto de todos los posibles resultados de un experimento aleatorio.

Evento

Cualquier subconjunto $E \subseteq \Omega$. Ocurre E si el resultado pertenece a E .

Operaciones con eventos

- **Unión:** $E \cup F$ — ocurre si ocurre al menos uno.
- **Intersección:** $E \cap F$ — ocurre si ocurren ambos simultáneamente.
- **Eventos disjuntos:** $E \cap F = \emptyset$.
- **Complemento:** $E^c = \Omega \setminus E$.
- **Diferencia:** $E \setminus F = \{\omega \in \Omega : \omega \in E, \omega \notin F\}$.

2.2. Definición de una probabilidad

Sea $(\Omega, \mathcal{S}_\Omega)$ un espacio muestral. Una **medida de probabilidad** es una función $P : \mathcal{S}_\Omega \rightarrow [0, 1]$ que satisface:

- (I) $0 \leq P(E) \leq 1$ para todo $E \in \mathcal{S}_\Omega$.
- (II) $P(\Omega) = 1$.
- (III) Para cualquier familia numerable de eventos disjuntos E_i :

$$P\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} P(E_i).$$

Propiedades básicas

- Complemento: $P(E^c) = 1 - P(E)$.
- Vacío: $P(\emptyset) = 0$.
- Unión de dos eventos:

$$P(E \cup F) = P(E) + P(F) - P(E \cap F).$$

Si E y F son disjuntos: $P(E \cup F) = P(E) + P(F)$.

- Monotonía: si $E \subset F$ entonces $P(E) \leq P(F)$.

Probabilidad condicional

Sea $P(F) > 0$.

$$P(E | F) = \frac{P(E \cap F)}{P(F)}.$$

Independencia E y F son independientes si $P(E \cap F) = P(E)P(F)$ (equivalentemente $P(E | F) = P(E)$).

Teorema de Probabilidades Totales

Si $\{E_i\}_{i=1}^n$ es una partición de Ω (eventos disjuntos con $\bigcup_i E_i = \Omega$), entonces para cualquier evento F :

$$P(F) = \sum_{i=1}^n P(F | E_i)P(E_i).$$

Teorema de Bayes

Con las hipótesis anteriores y $P(F) > 0$:

$$P(E_i | F) = \frac{P(F | E_i)P(E_i)}{\sum_{j=1}^n P(F | E_j)P(E_j)}.$$

2.3. Variables Aleatorias**Definición**

Una **variable aleatoria** es una función medible $X : \Omega \rightarrow \mathbb{R}$.

Tipos

- **Discreta**: toma valores en un conjunto finito o numerable.
- **Continua**: toma valores en un intervalo o conjunto no numerable.

Función de distribución acumulada

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Variable aleatoria discreta

- *Función de masa de probabilidad:* $p_X(k) = P(X = k)$.
- $\sum_k p_X(k) = 1$.

Variable aleatoria continua

- *Función de densidad:* $f_X : \mathbb{R} \rightarrow [0, \infty)$ con $\int_{-\infty}^{\infty} f_X(x) dx = 1$.
- $F_X(x) = \int_{-\infty}^x f_X(t) dt$.
- Probabilidad en un intervalo: $P(a \leq X \leq b) = \int_a^b f_X(x) dx = F_X(b) - F_X(a)$.

Distribuciones condicionales

Discreto–discreto: $P(X = x \mid Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)}$.

Continuo–continuo: $f_{X|Y}(x \mid y) = \frac{f_{XY}(x, y)}{f_Y(y)}$.

Esperanza y varianza

$$E[X] = \begin{cases} \sum k P(X = k), & \text{discreta,} \\ \int_{-\infty}^{\infty} x f_X(x) dx, & \text{continua;} \end{cases}$$

$$\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2.$$

Linealidad de la esperanza Para $Y = a + \sum_{i=1}^n b_i X_i$:

$$E[Y] = a + \sum_{i=1}^n b_i E[X_i].$$

Leyes de probabilidades totales**Distribución**

$$P(X = k) = \sum_i P(X = k \mid Y = i) P(Y = i) \quad (\text{discreto})$$

$$F_X(x) = \int P(X \leq x \mid Y = y) f_Y(y) dy \quad (\text{continuo})$$

Esperanza

$$E[X] = \sum_i E[X | Y = i] P(Y = i) \quad (\text{discreto})$$

$$E[X] = \int E[X | Y = y] f_Y(y) dy \quad (\text{continuo})$$

3 Procesos Estocásticos

Definición: Un **proceso estocástico** es una familia de variables aleatorias $\{X_t\}$ (o $X(t)$), en que t es un parámetro que varía según un índice en el conjunto T .

- Con frecuencia, t corresponde a unidades discretas de tiempo, por lo que $T = \{0, 1, 2, 3, \dots\}$.
- También puede representar tiempo u otra variable continua (p.ej., distancia desde el origen); en tal caso, $T = [0, \infty)$.

Entonces, en general:

$\{X_t, t = 0, 1, 2, \dots\}$ es un proceso estocástico en tiempo discreto,

$\{X(t), t \geq 0\}$ es un proceso estocástico en tiempo continuo.

Realización o instancia: La **realización** (o **instancia**) de un proceso estocástico es la sucesión de valores concretos que toman las variables aleatorias al ejecutar el proceso.

Estados transiente y de régimen

- En estado *transiente* la distribución de probabilidades de las variables aleatorias *varía* a lo largo del proceso.
- En estado *de régimen* (o estado estable) dicha distribución se mantiene *constante* a través del proceso.

4 Proceso Poisson

4.1. Proceso de Conteo

Definición Un *proceso de conteo* es una familia de v.a. $\{N(t), t \geq 0\}$ tal que $N(t)$ representa el número de eventos ocurridos en $[0, t]$.

Propiedades básicas

- (a) $N(t) \in \mathbb{N}_0$ y $N(0) = 0$.
- (b) Si $0 \leq s < t$, entonces $N(s) \leq N(t)$ (monótono no decreciente).
- (c) El número de eventos en $(s, t]$ es $N(t) - N(s)$.

Incrementos independientes $\{N(t), t \geq 0\}$ posee incrementos independientes (i.i.) si $N(t+s) - N(t)$ es independiente de $\{N(u), 0 \leq u \leq t\}$ para todo $s, t > 0$.

Incrementos estacionarios Tiene incrementos estacionarios (i.e.) si la distribución de $N(t+s) - N(t)$ depende solo de s , no de t .

Propiedad de orden Existe $\lambda > 0$ tal que, para $h \rightarrow 0$,

$$P(N(h) = 1) = \lambda h + o(h), \quad P(N(h) \geq 2) = o(h).$$

$$\text{Entonces } N(h) \approx \begin{cases} 0 & \text{con prob. } 1 - \lambda h, \\ 1 & \text{con prob. } \lambda h. \end{cases}$$

4.2. Proceso de Poisson

Definición Un proceso de conteo $\{N(t), t > 0\}$ es un **Proceso de Poisson** de tasa $\lambda > 0$ si:

- (I) posee incrementos independientes;
- (II) posee incrementos estacionarios;
- (III) cumple la propiedad de orden.

Distribución de estado

$$P(N(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \quad k = 0, 1, 2, \dots$$

Tiempos entre eventos Sea T_1 el tiempo hasta el primer evento y T_n ($n \geq 2$) el tiempo entre los eventos $n-1$ y n .

$$T_1, T_2, \dots \text{ son i.i.d. } \text{Exp}(\lambda).$$

Falta de memoria (exponencial) Para $x, y > 0$:

$$P(T_1 > x + y \mid T_1 > x) = e^{-\lambda y}.$$

Resultado inverso Si los tiempos $\{T_i\}$ de un proceso de conteo son i.i.d. exponenciales $\text{Exp}(\lambda)$, entonces el proceso resultante es de Poisson (tasa λ).

Instante del k -ésimo evento Sea $S_k = \sum_{i=1}^k T_i$. Entonces $S_k \sim \Gamma(k, \lambda)$ (Erlang de orden

$$k); F_{S_k}(x) = P(N(x) \geq k) = 1 - \sum_{j=0}^{k-1} \frac{e^{-\lambda x} (\lambda x)^j}{j!}.$$

Distribución condicional de los tiempos de evento Dados $N(t) = n$, los tiempos $(S_1, \dots, S_n)$ son los estadísticos de orden de n v.a. $\text{Unif}(0, t)$. En particular,

$$P(S_1 < x \mid N(t) = 1) = \frac{x}{t}$$

$$P(N(u) = k \mid N(t) = n) = \binom{n}{k} \left(\frac{u}{t}\right)^k \left(1 - \frac{u}{t}\right)^{n-k}$$

Por lo tanto, la distribución de $N(u)$ dado $N(t) = n$ distribuye $\text{Binomial}(n, \frac{u}{t})$. Este resultado también es válido para cualquier intervalo de largo t y sub-intervalo de largo u contenido en el primero.

4.3. Descomposición y Suma

Descomposición (adelgazamiento) Sea $\{N(t)\}$ un proceso de Poisson de tasa λ . Clasifique cada evento, independientemente, como tipo 1 con prob. p y tipo 2 con prob. $1 - p$. Entonces

$$N_1(t) \sim \text{Poisson}(\lambda p), \quad N_2(t) \sim \text{Poisson}(\lambda(1 - p)),$$

y $N_1(t)$ y $N_2(t)$ son procesos *independientes*.

Suma de procesos Poisson Si $N_i(t)$ ($i = 1, \dots, k$) son procesos de Poisson independientes con tasas λ_i , entonces

$$N(t) = \sum_{i=1}^k N_i(t) \sim \text{Poisson}(\lambda_1 + \dots + \lambda_k).$$

4.4. Extensiones

Proceso Poisson compuesto

$$X(t) = \sum_{i=1}^{N(t)} Y_i, \quad t \geq 0,$$

donde $N(t)$ es $\text{Poisson}(\lambda)$ y $\{Y_i\}$ son i.i.d. (indep. de N).

- Incrementos independientes y estacionarios.
- No satisface la propiedad de orden.
- $E[X(t)] = E[Y_1] E[N(t)] = E[Y_1] \lambda t$.

Proceso Poisson no-homogéneo

Definido por una tasa determinista $\lambda(t) > 0$:

$$\begin{aligned} P(N(t+h) - N(t) \geq 2) &= o(h), \\ P(N(t+h) - N(t) = 1) &= \lambda(t)h + o(h). \end{aligned}$$

Sea $m(t) = \int_0^t \lambda(s) ds$. Entonces

$$P(N(t+s) - N(t) = n) = \frac{[m(t+s) - m(t)]^n e^{-[m(t+s) - m(t)]}}{n!}.$$

El primer tiempo T_1 cumple $P(T_1 > t) = e^{-m(t)}$ (no es exponencial).

Proceso de Renovación

Definición Sea $\{N(t), t \geq 0\}$ un proceso de conteo y $\{T_i, i = 1, 2, \dots\}$ los tiempos entre eventos. Si $\{T_i\}$ son v.a. no negativas, independientes e idénticamente distribuidas con c.d.f. $F(\cdot)$, entonces $\{N(t)\}$ se denomina **Proceso de Renovación**. Cada vez que ocurre un evento el proceso “se renueva”, el tiempo al próximo evento posee nuevamente la distribución F .

Distribución de $N(t)$ Sea $S_n = \sum_{i=1}^n T_i$ la suma de los n primeros tiempos entre eventos (ésima convolución F^{*n}). Como $N(t) \geq n \iff S_n \leq t$,

$$P(N(t) = n) = F^{*n}(t) - F^{*(n+1)}(t), \quad n = 0, 1, 2, \dots$$

Función de renovación El número medio de eventos en $[0, t]$ se define como

$$m(t) = E[N(t)].$$

Condicionando en el primer tiempo T_1 y aplicando el argumento de renovación se obtiene la **ecuación de renovación** :

$$m(t) = F(t) + \int_0^t m(t-x) f_{T_1}(x) dx,$$

donde f_{T_1} es la densidad de T_1 .

Relación con el Proceso de Poisson El proceso de Poisson es un caso particular de proceso de renovación en el que $T_i \sim \text{Exp}(\lambda)$; en él, la renovación ocurre no sólo en cada evento sino “en todo instante”.

5 Cadenas de Markov en Tiempo Discreto

5.1. Motivación

Los procesos de decisión y planificación en contextos inciertos pueden modelarse mediante *procesos estocásticos*. Cuando el estado del sistema evoluciona en instantes discretos y el futuro depende del pasado únicamente a través del presente, el modelo apropiado es la **Cadena de Markov en Tiempo Discreto** (CMTD).

5.2. CMTD y sus propiedades

Propiedad markoviana

Un proceso estocástico $\{X_n, n = 0, 1, 2, \dots\}$ cumple la *propiedad markoviana* si

$$P(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = P(X_{n+1} = j \mid X_n = i),$$

para todo $j, i, i_{n-1}, \dots, i_0$ en el conjunto de estados posibles de X_n

Propiedad estacionaria

Un proceso estocástico $\{X_n, n = 0, 1, 2, \dots\}$ posee *incrementos estacionarios* cuando

$$P(X_{n+1} = j \mid X_n = i) = P_{ij}, \quad \text{independiente de } n.$$

Definición de CMTD

Un proceso estocástico es una *CMTD* si verifica simultáneamente la propiedad markoviana y la estacionaria. Trabajaremos con un espacio de estados numerable $S = \{0, 1, 2, \dots\}$.

Probabilidades de transición en una etapa

En una CMTD esta probabilidad se define como:

$$P_{ij} = P(X_{n+1} = j \mid X_n = i)$$

Se cumple también que:

$$P_{ij} \geq 0, \quad \sum_{j \in S} P_{ij} = 1.$$

Matriz de transición

Denominaremos P a la matriz de transición en una etapa.

$$P = \begin{pmatrix} P_{00} & P_{01} & \cdots & P_{0j} & \cdots \\ P_{10} & P_{11} & \cdots & P_{1j} & \cdots \\ \vdots & \vdots & \ddots & \vdots & \ddots \\ P_{i0} & P_{i1} & \cdots & P_{ij} & \cdots \\ \vdots & \vdots & \ddots & \vdots & \ddots \end{pmatrix}$$

- Para cada fila i de P , su suma debe ser igual a 1
- La suma de las columnas no necesariamente es igual a 1

Transición en n etapas

En una CMTD esta probabilidad esta dada por:

$$P_{ij}^{(n)} = P(X_{m+n} = j \mid X_m = i)$$

Para todo $m, n \geq 0$. Note que $P_{ij}^{(1)} = P_{ij}$.

Ecuación de Chapman–Kolmogórov

Se cumple que:

$$P_{ij}^{(n+m)} = \sum_{k \in S} P_{ik}^{(n)} P_{kj}^{(m)} \quad \forall m, n \geq 0, \forall i, j \in S$$

Lo que nos permite calcular probabilidades de transición en n etapas.

Matriz de transición en n etapas

Denominaremos $P^{(n)}$ a la matriz de transición en n etapas. Esta matriz está formada con los $P_{ij}^{(n)}$ de la CMTD.

Se tiene que:

$$P^{(n)} = P^n.$$

Distribución de probabilidades del proceso

Sea $\{X_n, n = 0, 1, 2, \dots\}$ una CMTD con un espacio de estados dados por $\{0, 1, 2, \dots, r\}$. Llamaremos al vector distribución de probabilidades del proceso en la etapa n, al vector $f^{(n)}$ tal que:

$$f^{(n)} = \begin{pmatrix} \mathbb{P}(X_n = 0) \\ \mathbb{P}(X_n = 1) \\ \vdots \\ \mathbb{P}(X_n = r) \end{pmatrix}$$

Si se conoce $f^{(0)}$, se puede calcular $f^{(n)}$ con la siguiente ecuación:

$$(f^{(n)})^\top = (f^{(0)})^\top P^n.$$

Representación gráfica

Cada estado se representa por un *nodo*. Existe una arista dirigida de i a j si $P_{ij} > 0$. El grafo facilita el estudio de comunicación, clases y periodicidad.

5.3. Visitas entre estados

Tiempo de primera visita

El tiempo (número de etapas) empleado para ir desde el estado i al estado j por primera vez está dado por:

$$T(i, j) = \inf \{n : X_n = j, n \geq 0\} \mid X_0 = i$$

Probabilidad de primera visita en k pasos

La probabilidad de ir del estado i al estado j en k etapas, sin haber pasado por j antes de la etapa k está dada por:

$$F_k(i, j) = P(T(i, j) = k)$$

Se tiene que:

$$F_k(i, j) = \sum_{r \neq j} P_{ir} F_{k-1}(r, j) \quad \forall k \geq 2$$

Probabilidad de visitar un estado en algún momento

La probabilidad de visitar eventualmente el estado j dado que al inicio el proceso está en el estado i se denotará $F(i, j)$ y corresponde a:

$$F(i, j) = \sum_{k=1}^{\infty} F_k(i, j) = P(T(i, j) < \infty).$$

Se tiene que:

$$F(i, j) = P_{ij} + \sum_{r \neq j} P_{ir} F(r, j).$$

Valor esperado del número de etapas para ir de i a j

Si $F(i, j) = 1$,

$$\mathbb{E}[T(i, j)] = \sum_{k=1}^{\infty} k F_k(i, j) = 1 + \sum_{l \neq j} P_{il} \mathbb{E}[T(l, j)].$$

Además, la probabilidad de retornar alguna vez al estado j esta dada por:

$$F(j, j)$$

5.4. Clasificación de estados

Estado recurrente

El estado i se denomina *recurrente* si:

$$F(i, i) = P(T(i, i) < \infty) = 1$$

Además se tiene que:

- Si $\mathbb{E}(T(i, i)) = \infty$, i se denomina *recurrente nulo*
- Si $\mathbb{E}(T(i, i)) < \infty$, i se denomina *recurrente positivo*

Estado transiente

El estado i se denomina *transiente* si:

$$F(i, i) = P(T(i, i) < \infty) < 1$$

Si una CMTD posee una cantidad de estados **finita**, luego:

- No pueden existir estados recurrentes nulos.
- No pueden ser todos los estados transientes.

Comunicación entre estados

Los estados i y j se *comunican* ($i \leftrightarrow j$) si hay camino de i a j y de j a i . La relación de comunicación satisface las siguientes tres propiedades:

- **Reflexión:** $i \leftrightarrow i$ para todo estado i
- **Simetría:** $i \leftrightarrow j$ si y solo si $j \leftrightarrow i$
- **Transitividad:** Si $i \leftrightarrow k$ y $k \leftrightarrow j$, entonces $i \leftrightarrow j$

Es decir, la relación de comunicación es una relación de equivalencia.

Clases

- La relación de comunicación define clases. Decimos que dos estados pertenecen a la misma clase si estos se comunican.
- Las clases constituyen una partición del conjunto de todos los estados.
- Todos los estados de una clase son del mismo tipo: transientes, recurrentes nulos o recurrentes positivos.
- Las clases de estados recurrentes son **cerradas**, es decir, si el sistema parte de un estado dentro de esa clase nunca sale.

Periodicidad

Un estado es periódico si partiendo desde ese estado solo es posible volver a él en un número de etapas que sea múltiplo de un número entero mayor a uno.

El período, d , de un estado j corresponde al máximo común divisor de los n para los que $P_{jj}^{(n)} > 0$.

- Si $d > 1$, diremos que el estado es periódico con período d .
- Si $d = 1$, diremos que el estado es aperiódico.

5.5. Largo plazo

Se estudia el límite $\lim_{n \rightarrow \infty} P_{ij}^{(n)}$.

Resultados clave

- Si j es transiente o recurrente nulo, $\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0$.
- Si j es recurrente positivo:

- Si j es aperiódico:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = \frac{F(i, j)}{\mathbb{E}(T(j, j))}$$

$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = \frac{1}{\mathbb{E}(T(j, j))}$$

- Si j es periódico con período d :

- Si $i = j$:

$$\lim_{n \rightarrow \infty} P_{ij}^{(nd)} = \frac{d}{\mathbb{E}(T(j, j))}$$

$$\lim_{n \rightarrow \infty} P_{ij}^{(nd+k)} = 0 \quad \forall k \in \{1, 2, \dots, d-1\}$$

- Si $i \neq j$ y pertenecen a la misma clase:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n_0+nd)} = \frac{d}{\mathbb{E}(T(j, j))}$$

$$\lim_{n \rightarrow \infty} P_{ij}^{(n_0+nd+k)} = 0 \quad \forall k \in \{1, 2, \dots, d-1\}$$

Donde n_0 es el mínimo de etapas para ir de i hasta j .

- Si $i \neq j$ e i pertenece a una clase recurrente distinta:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0$$

- Si $i \neq j$ e i pertenece a una clase transiente:

El límite depende de la estructura de la cadena

Existencia de los límites: Los límites $\lim_{n \rightarrow \infty} P_{ij}^{(n)}$ existen para todos i, j si y sólo si la cadena no contiene clases recurrentes positivas periódicas.

5.6. Distribución Límite y Distribución Estacionaria

Distribución límite:

Si existen todos los límites para las probabilidades de transición en n etapas y, en todos los casos, estos límites no dependen del estado inicial, diremos que el proceso tiene **distribución de probabilidades límite**. Es decir, en este caso se tiene que para todo j en el espacio de estados se cumple que para cualquier i :

$$\lim_{n \rightarrow \infty} P(X_n = j) = \lim_{n \rightarrow \infty} P_{ij}^{(n)}$$

Distribución estacionaria:

Por otra parte, la solución del siguiente sistema se denomina distribución de **probabilidades estacionaria**:

$$\begin{aligned}\pi^T &= \pi^T P \\ \sum_i \pi_i &= 1 \\ \pi_i &\geq 0 \quad \forall i\end{aligned}$$

Si una CMTD tiene distribución límite y distribución estacionaria, entonces ambas coinciden. Usaremos el vector π para denotar esta distribución. Con esto, en este caso podemos entonces escribir:

$$\pi_j = \lim_{n \rightarrow \infty} \mathbb{P}(X_n = j) = \lim_{n \rightarrow \infty} P_{ij}^{(n)}$$

Interpretación: La probabilidad límite de que el proceso se encuentre en el estado j en un tiempo n ($n \rightarrow \infty$) es igual a la proporción de tiempo, en el largo plazo, que el proceso estará en el estado j (probabilidad estacionaria).

Cadenas irreducibles

Diremos que una CMTD es **irreducible** cuando tiene finitos estados y todos sus estados se comunican.

Notemos que una CMTD irreducible consiste, por lo tanto, de una **única clase recurrente positiva**.

Si una CMTD es irreducible y aperiódica, entonces el proceso tiene distribución límite y distribución estacionaria (las cuales coinciden).

Cadenas con clases transientes

Consideremos una CMTD con espacio de estados $S = C \cup T$, en que C es una clase de estados recurrentes positivos aperiódicos y T es un conjunto de uno o más clases transientes. Si para cada estado i en T se cumple que:

$$\lim_{n \rightarrow \infty} P(X_n \in C \mid X_0 = i) = 1$$

entonces la cadena tiene una única distribución estacionaria. Además, se cumplirá que $\pi_j > 0$ para todo $j \in C$ y $\pi_j = 0$ para todo $j \in T$.

6 Cadenas de Markov en Tiempo Continuo

6.1. Definición

Supongamos que tenemos un proceso estocástico en tiempo continuo, $\{X(t), t \geq 0\}$, cuyo espacio de estados ϵ generalmente será el conjunto de enteros no negativos.

Propiedad Markoviana

$\{X(t), t \geq 0\}$ posee la propiedad markoviana si para todo $s, t \geq 0$, todo entero no negativo i, j , y para todo $x(u) \in \epsilon$, $0 \leq u \leq s$,

$$P(X(t+s) = j \mid X(s) = i, X(u) = x(u) \quad \forall u \in [0, s]) = P(X(t+s) = j \mid X(s) = i)$$

Propiedad Estacionaria

El proceso $\{X(t), t \geq 0\}$ posee la propiedad de estacionariedad si $P(X(t+s) = j | X(s) = i)$ no depende de s .

Notación: $P_{ij}(t) = P(X(t+s) = j | X(s) = i)$

CMTC

El proceso $\{X(t), t \geq 0\}$ es una CMTC si cumple la propiedad markoviana y con la propiedad estacionaria.

Consecuencias propiedad markoviana y estacionaria:

- No importa el tiempo que haya permanecido en un determinado estado.

$$P(T_i > s+t | T_i > s) = P(T_i > t) \quad \forall s, t \geq 0, \quad i \in \{0, 1, 2, \dots\}$$

- El tiempo de permanencia en un estado i (T_i) no tiene memoria, por lo que tiene que ser exponencial.

CMTC Definición alternativa

Una CMTC es un proceso $\{X(t), t \geq 0\}$ que tiene las siguientes propiedades:

- Cada vez que entra al estado i , el tiempo que permanece en ese estado antes de efectuar una transición a un estado diferente tiene distribución exponencial de parámetro $v_i \rightarrow$ tiene media $\frac{1}{v_i}$
- Cuando un proceso deja el estado i , a continuación entra al estado j con una probabilidad P_{ij} . Las probabilidades P_{ij} deben satisfacer:

$$P_{ii} = 0 \quad \forall i; \quad \sum_j P_{ij} = 1 \quad \forall i$$

Conclusiones importantes:

- Una CMTC es un proceso estocástico que se mueve de un estado a otro de acuerdo a una CMTD.
- Los P_{ij} corresponden a las componentes de la matriz P de transición de la CMTD asociada.
- Los tiempos de permanencia en un estado dado son iid con distribución exponencial (la media de los tiempos puede ser diferente para distintos estados).
- El tiempo que el proceso permanece en el estado i y el próximo estado a visitar son independientes.

6.2. Probabilidades de Transición

Considere una CMTC. Se llama **probabilidad de transición**, $P_{ij}(t)$, a la probabilidad de que el proceso, dado que ahora está en el estado i , en t unidades de tiempo más esté en el estado j .

$$P_{ij}(t) = P(X(t+s) = j | X(s) = i) \quad \forall i, j; \quad \forall s, t \geq 0$$

Ecuación Champan-Kolmogorov

Para todo $s, t \geq 0$ se tiene que:

$$P_{ij}(t+s) = \sum_{k=0}^{\infty} P_{ik}(t) \cdot P_{kj}(s)$$

Tasa de transición instantánea

Se denomina **tasa de transición instantánea**, q_{ij} , a la tasa a la cual el proceso realiza una transición del estado i al estado j . Esta tasa está dada por:

$$q_{ij} = v_i \cdot P_{ij}$$

Las tasas de transición instantáneas determinan los parámetros de una CMTC.

$$P_{ij} = \frac{q_{ij}}{v_i} = \frac{q_{ij}}{\sum_{j \in \epsilon} q_{ij}}$$

Probabilidades Límite

Probabilidad Límite

Considere la probabilidad de que una CMTC esté en el estado j después de un tiempo t , con $t \rightarrow \infty$. Si esta probabilidad existe y es independiente del estado inicial se llama probabilidad límite:

$$P_j = \lim_{t \rightarrow \infty} P_{ij}(t)$$

En este caso, se tiene que cumplir que:

$$\lim_{t \rightarrow \infty} \frac{d}{dt} P_{ij}(t) = 0$$

Esto es análogo a cuando en una CMTD se dice que « $f^{(n+1)} = f^{(n)}$ » cuando hay límite.

Ecuación de equilibrio

Es posible demostrar que se cumple lo siguiente, conocido como la ecuación de Kolmogorov:

$$\frac{d}{dt} P_{ij}(t) = \sum_{k \neq j} v_k P_{ik}(t) P_{kj} - v_j P_{ij}(t)$$

Tomando límite a ambos lados, obtenemos:

$$0 = \sum_{k \neq j} v_k P_k P_{kj} - v_j P_j$$

$$v_j P_j = \sum_{k \neq j} v_j P_k P_{kj}$$

Ecuación de equilibrio en el largo plazo

En una CMTC se cumple que, para cada estado $j \in \epsilon$, la tasa de salida de j en el largo plazo es igual a la suma de las tasas de entrada a j en el largo plazo. Es decir:

$$v_j \cdot P_j = \sum_{k \neq j} q_{kj} \cdot P_k \quad \forall j \in \epsilon$$

Interpretación:

- Si los P_j existen, se pueden interpretar como la proporción del tiempo que el proceso se encuentra en el estado j en el largo plazo.
- $v_j \cdot P_j$ corresponde a la tasa a la cual el proceso deja el estado j en el largo plazo.
- $\sum_{k \neq j} q_{kj} \cdot P_k$ corresponde a la tasa a la cual el proceso entra al estado j en el largo plazo.

Si a estas ecuaciones le agregamos la ecuación $\sum_{k=0}^{\infty} P_k = 1$, entonces tendremos un sistema de ecuaciones que permite obtener las probabilidades límite del proceso.

Procesos de Nacimiento y Muerte

Un proceso de nacimiento es una CMTC con estados $\{0, 1, 2, \dots\}$ para la cual las transiciones desde el estado i sólo pueden ser al estado $i - 1$ o al estado $i + 1$.

Probabilidades límites para Nacimiento y Muerte

Dado $X(t) = j$ tendremos:

- Tiempo hasta el siguiente nacimiento: $Exp(\lambda_j)$
- Tiempo hasta la siguiente muerte: $Exp(\mu_j)$

Luego,

$$\begin{aligned} v_0 &= \lambda_0 \\ v_j &= \lambda_j + \mu_j \quad \forall j \in \{0, 1, 2, \dots\} \\ P_{01} &= 1 \\ P_{j,j+1} &= \frac{\lambda_j}{\lambda_j + \mu_j} \quad \forall j \in \{1, 2, 3, \dots\} \\ P_{j,j-1} &= \frac{\mu_j}{\lambda_j + \mu_j} \quad \forall j \in \{1, 2, 3, \dots\} \end{aligned}$$

Reemplazando en las ecuaciones de equilibrio:

$$(\lambda_j + \mu_j)P_j = \lambda_{j-1}P_{j-1} + \mu_{j+1}P_{j+1}$$

Es decir, para cada j , esta ecuación sería:

$$\lambda_0 P_0 = \mu_1 P_1$$

$$(\lambda_1 + \mu_1)P_1 = \lambda_0 P_0 + \mu_2 P_2$$

$$(\lambda_2 + \mu_2)P_2 = \lambda_1 P_1 + \mu_3 P_3$$

...

$$(\lambda_n + \mu_n)P_n = \lambda_{n-1}P_{n-1} + \mu_{n+1}P_{n+1}$$

Sumando estas $n + 1$ ecuaciones:

$$\lambda_n P_n = \mu_{n+1} P_{n+1}$$

$$P_{n+1} = \frac{\lambda_n}{\mu_{n+1}} P_n$$

Realizando el mismo cálculo recursivo, podemos obtener la siguiente expresión:

$$P_n = \frac{\prod_{k=0}^{n-1} \lambda_k}{\prod_{k=1}^n \mu_k} P_0$$

Además se debe cumplir que:

$$\sum_{n=0}^{\infty} P_n = 1$$

$$\sum_{n=0}^{\infty} \frac{\prod_{k=0}^{n-1} \lambda_k}{\prod_{k=1}^n \mu_k} P_0 = 1$$

$$P_0 + P_0 \sum_{n=1}^{\infty} \frac{\prod_{k=0}^{n-1} \lambda_k}{\prod_{k=1}^n \mu_k} = 1$$

$$P_0 = \frac{1}{1 + \sum_{n=1}^{\infty} \frac{\prod_{k=0}^{n-1} \lambda_k}{\prod_{k=1}^n \mu_k}}$$

Estas probabilidades existen si y solo si:

$$\sum_{n=1}^{\infty} \frac{\prod_{k=0}^{n-1} \lambda_k}{\prod_{k=1}^n \mu_k} < \infty$$

7 Sistemas de Espera

7.1. Definición

Consideremos un sistema al cual clientes llegan de acuerdo a un proceso estocástico a requerir un servicio (o atención). Una vez que llegan, si no hay capacidad de atención disponible, deben esperar (en una cola) hasta que les toca el turno de ser atendidos. Una vez que termina la atención, los clientes dejan el sistema.

Modelos de este tipo son los que corresponden a sistemas de espera (o sistemas de servicio, o modelos de colas).

Notación de los modelos de lista de espera

Para representar estos modelos, se usará la notación **X1/X2/X3/X4**, en donde:

- **X1** corresponde a la distribución de los tiempos entre llegadas
- **X2** corresponde a la distribución de los tiempos de atención
- **X3** corresponde a la cantidad de servidores en paralelo (1,2,3,...)
- **X4** corresponde a la capacidad del sistema

En cual: Si se omite X4 y se escribe X1/X2/X3, se asume capacidad infinita para el sistema.

- Usaremos la letra **M** para representar que la distribución de tiempo correspondiente es exponencial (modelo Markoviano).
- Usaremos la letra **G** para representar que la distribución de tiempo correspondiente es una distribución general (no exponencial).

Medidas de desempeño

Las principales medidas de desempeño que nos interesará estudiar son:

- **L**: número medio de clientes en el sistema
- **Lq**: número medio de clientes en la cola
- **W**: tiempo medio de permanencia de un cliente en el sistema
- **Wq**: tiempo medio de permanencia de un cliente en la cola

Memotecnia:

- **L** referente a **long**, o sea, cantidad media de clientes.
- **W** referente a **weather**, o sea, tiempo medio de permanencia.
- Aquellas medidas que presentan una **q** hace referencia a **queue**, o sea, medidas relacionadas a la cola.

Ecuación de Little

Para un sistema de espera se cumple la siguiente relación entre el número medio de entidades en un sistema y el tiempo medio de permanencia de una entidad en el sistema.

$$L = \lambda_e \cdot W$$

Donde λ_e es la tasa media de entrada al sistema.

Cabe destacar que esta ecuación es válida:

- En estado estacionario (largo plazo cuando existe distribución límite).
- Independiente del tipo de proceso de llegada y de atención.
- Independiente de la disciplina de la cola (FIFO, LIFO, etc).
- Independiente de la cantidad de servidores.

Además, se tiene que la formalización de lo anterior sería:

$$L = \sum_{n=0}^{\infty} n \cdot P_n$$

$$L_q = \sum_{n=1}^{\infty} (n - c) \cdot P_n$$

7.2. Modelos Markovianos

Los modelos markovianos (o exponenciales) son aquellos sistemas de espera en que tanto los tiempos entre llegadas como los tiempos de atención son v.a. exponenciales (y por lo tanto, sin memoria o markovianos).

Los modelos que estudiaremos son:

- M/M/1
- M/M/1/K
- M/M/c
- M/M/c/K

Modelo 1: Sistema M/M/1

- Llegadas según un proceso de Poisson a tasa λ .
- Tiempos de atención exponenciales con parámetro μ .
- Un servidor.
- Capacidad infinita del sistema.

Se tiene que es un proceso de nacimiento y muerte, por lo que podemos obtener:

$$P_n = \frac{\lambda_{n-1}\lambda_{n-2}\dots\lambda_0}{\mu_n\mu_{n-1}\dots\mu_1}P_0 = \left(\frac{\lambda}{\mu}\right)^n P_0$$

con:

$$P_0 = 1 - \frac{\lambda}{\mu}$$

$$P_n = \left(\frac{\lambda}{\mu}\right)^n \left(1 - \frac{\lambda}{\mu}\right)$$

Obtenemos sus medidas de desempeño:

$$L = \sum_{n=0}^{\infty} n \cdot P_n = \sum_{n=0}^{\infty} n \left(\frac{\lambda}{\mu}\right)^n \left(1 - \frac{\lambda}{\mu}\right)$$

$$L = \frac{\lambda}{\mu - \lambda}$$

Se nos pide L_q :

$$L_q = \sum_{n=1}^{\infty} (n-1) \cdot P_n = \sum_{n=1}^{\infty} n \cdot P_n - \sum_{n=1}^{\infty} P_n$$

$$L_q = \sum_{n=0}^{\infty} n \cdot P_n - (1 - P_0)$$

$$L_q = \frac{\lambda}{\mu - \lambda} - \frac{\lambda}{\mu}$$

$$L_q = \frac{\lambda^2}{\mu(\mu - \lambda)}$$

Consideración: se podría calcular la cantidad de clientes en la fila, como cantidad de clientes medios totales - clientes medios en ser atendidos... Revisar si en realidad funciona.

$$W = \sum_{n=0}^{\infty} \frac{n+1}{\mu} P_n$$

$$W = \frac{1}{\mu} \cdot \left(\sum_{n=0}^{\infty} n P_n + \sum_{n=0}^{\infty} P_n \right)$$

$$W = \frac{1}{\mu} \cdot \left(\frac{\lambda}{\mu - \lambda} + 1 \right) = \frac{1}{\mu - \lambda}$$

Notar que, si consideramos la ecuación de Little, tendríamos:

$$W = \frac{L}{\lambda_e} = \frac{\lambda}{\mu - \lambda} \cdot \frac{1}{\lambda} = \frac{1}{\mu - \lambda}$$

¡Se llega al mismo resultado! Por lo tanto, usando la ecuación de Little se puede ahorrar bastante desarrollo, solo necesitamos obtener L (caso más sencillo) o W .

Consideración: se podría calcular el tiempo medio de clientes en la fila, como tiempo medio de clientes en el sistema - tiempo medios en ser atendidos.

Generalización:

Lo mencionado anteriormente se puede generalizar para el desarrollo de cada uno de los sistemas, repitiendo el procedimiento anterior y adaptando las tasas y probabilidades. Para generalizar lo anterior, a continuación, dejamos una tabla resumen con los resultados finales:

Sistema	P_0	P_n	$\mathbf{L}$	$\mathbf{L}_q$
M/M/1	$1 - \frac{\lambda}{\mu}$	$\left(\frac{\lambda}{\mu}\right)^n P_0 \quad \forall i \in \{1, 2, \dots\}$	$\frac{\lambda}{\mu - \lambda}$	$\frac{\lambda^2}{\mu(\mu - \lambda)}$
M/M/1/K	$\frac{1 - \left(\frac{\lambda}{\mu}\right)^{K+1}}{1 - \left(\frac{\lambda}{\mu}\right)^{K+1}}$	$\left(\frac{\lambda}{\mu}\right)^n P_0 \quad \forall i \in \{1, 2, \dots, K\}$	$\frac{\lambda}{\mu} \left(\frac{1 - \left(\frac{\lambda}{\mu}\right)^K - K \left(\frac{\lambda}{\mu}\right)^K + K \left(\frac{\lambda}{\mu}\right)^{K+1}}{\left(1 - \left(\frac{\lambda}{\mu}\right)\right) \left(1 - \left(\frac{\lambda}{\mu}\right)^{K+1}\right)} \right)$	$L - \frac{\lambda(1 - P_K)}{\mu}$
M/M/c	$\left[\sum_{n=0}^c \frac{\lambda^n}{n! \mu^n} + \frac{\lambda^c}{c! \mu^c} \cdot \frac{\frac{\lambda}{c\mu}}{1 - \frac{\lambda}{c\mu}} \right]^{-1}$	$\frac{\lambda^n}{n! \mu^n} P_0 \quad \forall i \in \{1, 2, \dots, c\}$ $\frac{\lambda^n}{c! c^{n-c} \mu^n} P_0 \quad \forall i \in \{c+1, \dots\}$	$\frac{\lambda}{\mu} + \frac{\left(\frac{\lambda}{\mu}\right)^c}{c! \left(1 - \frac{\lambda}{c\mu}\right)^2} \frac{\lambda}{\mu}$	$L - \frac{\lambda}{\mu}$
M/M/c/K	$\left[\sum_{n=0}^c \frac{\lambda^n}{n! \mu^n} + \frac{\lambda^c}{c! \mu^c} \cdot \frac{\lambda}{c\mu} \cdot \frac{1 - \left(\frac{\lambda}{c\mu}\right)^{K-c}}{1 - \frac{\lambda}{c\mu}} \right]^{-1}$	$\frac{\lambda^n}{n! \mu^n} P_0 \quad \forall i \in \{1, 2, \dots, c\}$ $\frac{\lambda^n}{c! c^{n-c} \mu^n} P_0 \quad \forall i \in \{c+1, \dots, K\}$	$\sum_{n=0}^K n P_n$	$L - \frac{\lambda(1 - P_K)}{\mu}$

Figura 1: Resultados generalizados de los sistema de espera.

7.3. Modelos no Markovianos

Los modelos no markovianos son aquellos sistemas de espera en que tanto los tiempos entre llegadas como los tiempos de atención **NO** son v.a. exponenciales, si no siguen otros tipos de distribución de tipo no markoviano.

Recordatorio: una distribución de tipo Markoviana es, en esencia, una distribución exponencial. Lo que la caracteriza es la propiedad de falta de memoria.

Ejemplo de modelo no Markoviano:

Sea $X(t)$ la cantidad de personas en el sistema en el instante t . $X(t)$ no es una CMTC, pero es posible modelarlo como un proceso de renovación:

- Sea X_n la cantidad de clientes que hay en el sistema justo en el instante de salida de la n -ésima persona.
- Sea Y_{n+1} la cantidad de personas que llegan durante el servicio del $(n+1)$ -ésimo cliente.

Entonces,

$$X_{n+1} = \begin{cases} X_n + Y_{n+1} - 1 & \text{si } X_n > 0 \\ Y_{n+1} & \text{si } X_n = 0 \end{cases}$$

¡ X_n es una CMTD! Sus cálculos son complejos, por lo que solamente usaremos su valor esperado.

Fórmula de Pollacsek-Khinchin

Sea S el tiempo de servicio. Entonces, la cantidad media de clientes en el sistema en el largo plazo está dada por:

$$\lim_{n \rightarrow \infty} E(X_n) = \lambda E(S) + \frac{\lambda^2 E(S^2)}{2(1 - \lambda E(S))}$$

8 Simulación

Técnica para estudiar sistemas dinámicos por medio de la representación de su comportamiento usando un modelo matemático del sistema, implementado en un computador. Una simulación puede ser:

- Estática o Dinámica
- Determinística o Estocástica
- Discreta o Continua

8.0.1. Estructura de un modelo de simulación de eventos discretos

Estudiaremos sistemas discretos, en que los cambios de las variables de estado se producen en instantes definidos, como por ejemplo:

- Llegada de un cliente
- Término de atención en la caja
- Momento en que falla un dispositivo

Componentes de un modelo de simulación

- **Variables de estado:** Son los elementos que describen el sistema en un instante dado. Por ejemplo, en una fila de supermercado, las variables de estado podrían ser: cuántas personas hay en la fila, si alguna caja está libre, o cuánto tiempo lleva esperando el primer cliente.
- **Reloj de la simulación:** Registra el tiempo real dentro del modelo. A medida que la simulación avanza, este reloj se mueve hacia adelante.
- **Conjunto de Eventos:** Son las ocurrencias que provocan cambios en el estado del sistema. Por ejemplo, la llegada de un nuevo cliente, que un cliente termine de pagar, o que una caja se abra o se cierre.
- **Agenda de eventos:** Un arreglo que incluye una posición para cada tipo de evento y que almacena el tiempo en que ocurrirá el siguiente evento de este tipo. Funciona como una lista de tareas pendientes que el programa revisa para saber qué "tarea" ejecutar a continuación.
- **Rutinas de actualización:** Son subrutinas que actualizan el estado del sistema para cada tipo de evento. Cuando un evento ocurre, esta rutina ajusta las variables de estado correspondientes (ej. si llega un cliente, se suma uno a la fila).

- **Programa principal:** Es el cerebro de la simulación. Determina el siguiente evento a ocurrir, avanza el reloj hasta ese momento y transfiere el control a la subrutina del evento correspondiente.
- **Indicadores / Estadísticas:** Elementos que van registrando datos de interés sobre el comportamiento del sistema, como el tiempo promedio de espera o la utilización de recursos.
- **Rutina de inicialización:** Una subrutina que establece las condiciones iniciales del sistema antes de que la simulación comience (ej. reloj en cero, filas vacías).
- **Medidas de desempeño:** Son las métricas que cuantifican el comportamiento del sistema, obtenidas de los indicadores (ej. tiempo promedio de espera, porcentaje de clientes atendidos).
- **Variables de entrada (input):** Datos con distribución de probabilidades conocida que alimentan la simulación. Por ejemplo, la tasa de llegada de clientes o los tiempos de servicio. Estas variables a menudo son aleatorias, reflejando la variabilidad del sistema real.

Aquí te presento un método de 3 pasos para definir las variables en cualquier problema de simulación:

Paso 1: Variables de Control de la Simulación Primero, olvídate del problema específico (la máquina, la cola, etc.) y pregúntate: ¿Qué necesito para que un motor de simulación de eventos discretos funcione?

- **El Reloj:** Necesitas saber en qué instante de tiempo estás.
 T : Tiempo actual de simulación.
- **La Condición de Parada:** ¿Cuándo termina la simulación?
 D : Duración total de la simulación.
- **La Agenda de Eventos Futuros:** La simulación salta de evento en evento. Debes saber cuándo ocurrirán los próximos eventos clave que cambian el estado del sistema. En sistemas de colas, los eventos fundamentales son las llegadas y las finalizaciones de servicio.
 TP : Tiempo de la Próxima llegada.
 TF : Tiempo de Finalización del servicio actual.

Estas variables son el esqueleto de casi cualquier simulación de eventos discretos.

Paso 2: Variables de Estado del Sistema Ahora, enfócate en el sistema físico que estás modelando. Pregúntate: Si pauso la simulación en un instante T , ¿qué información necesito para tener una "fotografía completa del estado actual del sistema?

- **El Servidor (La Máquina):** ¿Qué está haciendo? ¿Está disponible u ocupada?
 M : Estado de la Máquina (0 = libre, 1 = ocupada).
- **La Cola (Los Clientes en Espera):** ¿Hay gente esperando? ¿Cuánta? ¿Quiénes son y en qué orden están?
 N : Número de requerimientos en la cola. (Una visión simple).
 $Cola$: Un arreglo o lista que almacena a los clientes. (Una visión más detallada, necesaria para saber quién es el próximo y para manejar la lógica de "enviar al final de la cola").

Estas variables describen el estado físico y tangible del sistema en cualquier momento.

Paso 3: Variables de Recolección de Estadísticas Finalmente, mira el objetivo del problema. Pregúntate: ¿Qué datos debo acumular durante toda la simulación para poder calcular la medida de desempeño que me piden?

El objetivo es el "tiempo promedio de permanencia de una orden". La fórmula es:

$$\text{Tiempo Promedio} = \frac{\text{Suma de los tiempos de permanencia de TODAS las órdenes}}{\text{Número total de órdenes que TERMINARON}}$$

8.0.2. Generación de instancias de una variable aleatoria

Imagina que queremos simular eventos aleatorios, como el lanzamiento de un dado o el tiempo que tarda en llegar el próximo cliente a una tienda. Las computadoras, por su naturaleza, son máquinas que siguen instrucciones paso a paso, lo que significa que no pueden generar verdadera aleatoriedad por sí mismas. Entonces, ¿cómo crean esos "eventos random" que vemos en simulaciones o juegos?

El trasfondo de lo que viene a continuación es explicar distintos métodos para generar aleatoriedad o, más precisamente, aproximaciones analíticas que luego se usan de forma algorítmica. En pocas palabras, vamos a entender cómo la computadora crea "eventos aleatorios", incluso si en realidad solo sigue pasos definidos.

Método de la transformada inversa

El método que utilizaremos para generar instancias de una variable aleatoria X (denominado de la transformada inversa), opera de la siguiente manera:

1. Generar una instancia U_1 de U , en que $U \sim U(0, 1)$.
2. Sea $X_1 = F^{-1}(U_1)$. Entonces X_1 es una instancia de X .

Consideración: se debe usar $F^{-1}()$, o sea, la función acumulada inversa.

Nótese que $F^{-1}(U)$ es una v.a. distinta de X , pero que comparte su distribución de probabilidades. Por lo tanto, generar una instancia de $F^{-1}(U)$ es equivalente a generar una instancia de X .

Un ejemplo aplicado de lo anterior sería: Sea F la función de distribución acumulada. Sabemos que $F(x) = 1 - e^{-\lambda x}$. Por lo tanto, debemos calcular $F^{-1}(y)$.

$$\begin{aligned} y &= 1 - e^{-\lambda x} \\ 1 - y &= e^{-\lambda x} \\ \ln(1 - y) &= -\lambda x \\ x &= -\frac{1}{\lambda} \ln(1 - y) \end{aligned}$$

Por lo tanto, $F^{-1}(U) = -\frac{1}{\lambda} \ln(1 - U)$.

Generación de números aleatorios $U(0, 1)$

Método Congruencial Lineal El Método Congruencial Lineal (MCL) es la forma más común y clásica de generar **números pseudoaleatorios**. Como mencionamos antes, las computadoras no pueden generar verdadera aleatoriedad, así que usamos algoritmos como el MCL para producir secuencias de números que *parecen* aleatorios y se comportan como tales para propósitos de simulación.

¿Qué es el Método Congruencial Lineal? Es un algoritmo matemático que produce una secuencia de números enteros X_i que luego se transforman en números entre 0 y 1 (U_i), simulando una distribución uniforme. La clave está en una fórmula de recurrencia simple:

1. **Se elige un valor inicial X_0 (semilla):** Este es el punto de partida de toda la secuencia. Si inicias con la misma semilla, obtendrás exactamente la misma secuencia de números. Por eso se llaman "pseudoaleatorios": son determinísticos pero aparentan ser aleatorios.
2. **Se calcula el siguiente número X_i :** Se usa la siguiente fórmula:

$$X_i = (aX_{i-1} + c) \pmod{m}$$

Donde:

- X_i : Es el nuevo número entero generado.
- X_{i-1} : Es el número entero generado en el paso anterior.
- a : Es el **multiplicador**.
- c : Es el **incremento**.
- m : Es el **módulo**.
- $(\text{mód } m)$: Significa "módulo m ". Es el resto de la división de $(aX_{i-1} + c)$ entre m . Esto asegura que los números X_i siempre estén en el rango de 0 a $m - 1$.

3. **Se convierte X_i a un número U_i entre 0 y 1:**

$$U_i = \frac{X_i}{m}$$

Al dividir X_i (que va de 0 a $m - 1$) entre m , obtenemos un número U_i que cae en el rango $[0, 1)$, es decir, entre 0 y casi 1.

¿Por qué son útiles los U_i ? Los valores de U_i generados por este método aparentan tener una distribución uniforme entre 0 y 1 ($U(0, 1)$) y ser independientes entre sí. Esto es crucial porque, como vimos con el método de la transformada inversa, los números uniformes entre 0 y 1 son la base para generar instancias de cualquier otra distribución de probabilidad.

Importancia de las constantes a, c, m La calidad de los números pseudoaleatorios generados (qué tan "aleatorios" parecen, y qué tan larga es la secuencia antes de que se repita) depende críticamente de la elección de las constantes a , c y m . Si estas constantes no se eligen bien, la secuencia puede ser muy corta, mostrar patrones obvios, o no distribuir uniformemente, lo que arruinaría la simulación. Los generadores de números aleatorios modernos utilizan MCL o variaciones más sofisticadas con constantes probadas para asegurar una buena calidad.

Método de Aceptación y Rechazo

Imagina que quieres generar números aleatorios que sigan una distribución muy específica y complicada, pero el **método de la transformada inversa** (el que vimos antes) no funciona bien porque la función de distribución acumulada es muy difícil de invertir o calcular. Aquí es donde entra el **Método de Aceptación y Rechazo**.

¿Qué es el Método de Aceptación y Rechazo? La idea principal es sencilla: en lugar de generar directamente los números de nuestra distribución compleja ($f(x)$), vamos a generar números de una distribución "parecida" más simple ($h(x)$), y luego decidir si los **aceptamos o los rechazamos** basándonos en una regla.

Piénsalo como si estuvieras buscando manzanas rojas perfectas, pero solo tienes acceso a un montón mezclado de manzanas de distintos colores y tamaños. En lugar de buscar directamente las rojas perfectas, agarras cualquier manzana y luego decides si es lo suficientemente roja y perfecta para tu colección.

¿Cómo funciona? Encontrar una función "parecida" ($h(x)$): Necesitamos encontrar una función de densidad de probabilidad $h(x)$ de la cual sea fácil generar instancias aleatorias. Esta $h(x)$ se obtiene a partir de otra función $t(x)$, escalada por una constante c . Es decir:

$$h(x) \equiv \frac{t(x)}{c}$$

Algoritmo A-R:

1. Generar una instancia de $U \sim U(0, 1)$.
2. Generar una instancia de $Y \sim h(y)$ (independiente de U).
3. Si $U \leq g(Y)$, entonces hacer $X = Y$. Si no, volver al paso 1.

Condiciones clave: Para que el método funcione, $t(x)$ y c deben cumplir dos condiciones importantes:

- $f(x) \leq t(x)$ para todo x : Esto significa que la función "envolvente" $t(x)$ debe ser siempre igual o mayor que nuestra función de densidad objetivo $f(x)$ en todos los puntos. Gráficamente, $t(x)$ debe cubrir completamente a $f(x)$.
- $c = \int_{-\infty}^{\infty} t(x) dx > 1$: La constante c es el área total bajo la curva de $t(x)$. Esta área debe ser finita y mayor o igual que el área bajo $f(x)$ (que siempre es 1). Si $t(x)$ ya es una función de densidad válida y su área es 1, entonces c sería 1. Pero generalmente $t(x)$ será una función más "grande" que $f(x)$, por lo que c será mayor que 1.

¿Cuál es la lógica detrás de esto? Básicamente, $t(x)$ actúa como un "techo" o una "envolvente" para $f(x)$. Generamos un candidato de la distribución $h(x)$ (que es fácil de muestrear). Luego, con un segundo número aleatorio, decidimos si ese candidato está "debajo" de nuestra función $f(x)$ o no. Si está debajo, lo aceptamos; si no, lo rechazamos y lo intentamos de nuevo.

Este método es muy útil cuando el método de la transformada inversa es inviable. La eficiencia del método de Aceptación y Rechazo depende de qué tan bien $h(x)$ se "parezca" a $f(x)$. Cuanto más se parezcan, menos muestras tendremos que rechazar.

Creación y Desarrollo del Algoritmo de Aceptación y Rechazo

El algoritmo A-R es una herramienta ingeniosa para generar números aleatorios de una distribución compleja $f(x)$ cuando el método de la transformada inversa no es práctico. La idea central es usar una distribución "propuesta" más sencilla, y luego "filtrar" las muestras que no cumplen con los criterios de nuestra distribución deseada.

Paso 1: Identificar la Función de Densidad Deseada ($f(x)$)

Primero, define claramente la **función de densidad de probabilidad** $f(x)$ de la cual quieres generar muestras aleatorias. Esta es la distribución "objetivo" suele ser compleja o difícil de invertir.

Paso 2: Elegir una Función Envolvente ($t(x)$) y Calcular su Constante (c)

Este es el paso más crucial y a veces el más complicado. Necesitas encontrar una función $t(x)$ que cumpla dos condiciones vitales:

- **Que $t(x)$ sea fácil de muestrear:** Esto significa que $t(x)/c$ (donde c es su integral) debe ser una función de densidad de probabilidad de la que puedas generar números aleatorios fácilmente, quizás usando el método de la transformada inversa o simplemente una distribución conocida y sencilla (como la uniforme o la exponencial).
- **Que $f(x) \leq t(x)$ para todo x en el dominio de $f(x)$:** La función $t(x)$ debe "envolver" completamente a $f(x)$. Gráficamente, $t(x)$ siempre debe estar por encima de $f(x)$.

Una vez que tengas $t(x)$, debes calcular la constante c :

$$c = \int_{-\infty}^{\infty} t(x) dx$$

Esta constante es importante porque $t(x)/c$ será la función de densidad de probabilidad de la que realmente tomaremos las muestras "candidatas".

Paso 3: El Ciclo de Aceptación y Rechazo

Ahora, con $f(x)$, $t(x)$ y c definidos, puedes comenzar el proceso iterativo para generar tus muestras:

Generar un candidato X^* :

- Genera un número aleatorio $U_1 \sim U(0, 1)$ (usando, por ejemplo, un generador congruencial lineal).
- Usa U_1 para generar una instancia X^* de la distribución cuya densidad es $h(x) = t(x)/c$. Para esto, aplicarías el método de la transformada inversa a $h(x)$. Es decir, $X^* = h^{-1}(U_1)$.

Generar un número aleatorio para la decisión U_2 :

- Genera un segundo número aleatorio $U_2 \sim U(0, 1)$, independiente de U_1 .

Aplicar la Regla de Aceptación/Rechazo:

- Compara U_2 con la relación de las densidades en el punto X^* :

$$\text{Si } U_2 \leq \frac{f(X^*)}{t(X^*)}, \text{ entonces } \mathbf{Acepta } X^*$$

De lo contrario, **Rechaza** X^*

Repetir: Si X^* fue rechazado, vuelve al paso 1 y repite el proceso hasta que se acepte un valor. El valor X^* que sea aceptado es tu instancia de la variable aleatoria X con la distribución deseada $f(x)$.

Intuición Detrás de la Regla de Aceptación/Rechazo Piensa en una representación gráfica:

- Imagina que tienes la curva de $f(x)$ y la curva de $t(x)$ (que está por encima).
- Cuando generas X^* de $h(x) = t(x)/c$, estás eligiendo un punto aleatorio en el eje x según la distribución $h(x)$.
- Luego, al generar U_2 , lo multiplicamos por $t(X^*)$ para obtener un punto aleatorio vertical, $U_2 \cdot t(X^*)$, que está entre 0 y $t(X^*)$.
- La condición $U_2 \leq \frac{f(X^*)}{t(X^*)}$ es equivalente a $U_2 \cdot t(X^*) \leq f(X^*)$. Esto significa que estamos aceptando el X^* solo si el punto generado aleatoriamente $(X^*, U_2 \cdot t(X^*))$ cae **debajo de la curva** $f(x)$. Si cae entre $f(x)$ y $t(x)$, lo rechazamos.

Este proceso garantiza que los puntos aceptados realmente sigan la distribución $f(x)$, porque estamos recortando los puntos que están por encima de ella.

Ejemplo Aplicado del Método de Aceptación y Rechazo

Objetivo: Generar muestras aleatorias de la siguiente función de densidad de probabilidad $f(x)$:

$$\begin{aligned} f(x) &= 2x \quad \text{para } 0 \leq x \leq 1 \\ f(x) &= 0 \quad \text{en cualquier otro caso.} \end{aligned}$$

Esta es una distribución triangular simple.

Paso 1: Identificar la Función de Densidad Deseada ($f(x)$)

Nuestra función objetivo es $f(x) = 2x$ para $x \in [0, 1]$.

Paso 2: Elegir una Función Envolvente ($t(x)$) y Calcular su Constante (c)

La forma más sencilla de envolver una función en un intervalo finito es usar una distribución uniforme que cubra ese intervalo y que sea suficientemente alta.

Consideremos el intervalo $[0, 1]$. La función $f(x) = 2x$ va desde $f(0) = 0$ hasta $f(1) = 2$.

Vamos a elegir una función $t(x)$ que sea una constante. Para que $f(x) \leq t(x)$ para todo $x \in [0, 1]$, necesitamos que $t(x)$ sea al menos el valor máximo de $f(x)$ en ese intervalo. El valor máximo de $f(x) = 2x$ en $[0, 1]$ es $f(1) = 2$.

Entonces, podemos elegir $t(x) = 2$ para $x \in [0, 1]$, y $t(x) = 0$ en cualquier otro caso.

Ahora calculamos c :

$$c = \int_{-\infty}^{\infty} t(x) dx = \int_0^1 2 dx = [2x]_0^1 = 2(1) - 2(0) = 2.$$

Así, nuestra función de la que es fácil generar muestras es $h(x) = t(x)/c = 2/2 = 1$ para $x \in [0, 1]$. ¡Esta es simplemente una distribución uniforme $U(0, 1)$! Esto es perfecto porque sabemos cómo generar instancias de $U(0, 1)$ (usando un generador congruencial lineal, por ejemplo).

Resumen de funciones:

- $f(x) = 2x$ para $x \in [0, 1]$
- $t(x) = 2$ para $x \in [0, 1]$
- $c = 2$
- $h(x) = 1$ para $x \in [0, 1]$ (que es la densidad de una $U(0, 1)$)

Paso 3: El Ciclo de Aceptación y Rechazo (Generando una instancia de X)

Vamos a generar una sola instancia de X .

Generar un candidato X^* de $h(x)$:

- Generamos $U_1 \sim U(0, 1)$. Supongamos que nuestro generador de números aleatorios nos da $U_1 = 0,65$.
- Como $h(x)$ es la densidad de una $U(0, 1)$, una instancia de $h(x)$ es simplemente U_1 (o sea, $X^* = U_1$).
- Por lo tanto, nuestro candidato es $X^* = 0,65$.

Generar un número aleatorio para la decisión U_2 :

- Generamos un segundo número aleatorio $U_2 \sim U(0, 1)$. Supongamos que nuestro generador nos da $U_2 = 0,40$.

Aplicar la Regla de Aceptación/Rechazo:

- Necesitamos calcular el valor de la expresión $\frac{f(X^*)}{t(X^*)}$.
- $f(X^*) = f(0,65) = 2 \times 0,65 = 1,30$.
- $t(X^*) = t(0,65) = 2$ (ya que 0,65 está en el rango $[0, 1]$).
- La relación es $\frac{f(X^*)}{t(X^*)} = \frac{1,30}{2} = 0,65$.
- Ahora, comparamos U_2 con este valor:
 - ¿Es $U_2 \leq \frac{f(X^*)}{t(X^*)}$?
 - ¿Es $0,40 \leq 0,65$? **Sí.**
- Como la condición se cumple, **aceptamos** X^* .

Por lo tanto, la primera instancia de X generada usando el método de Aceptación y Rechazo es $X = 0,65$.

Ejemplo de una muestra rechazada (para ilustrar el proceso completo): Supongamos que volvemos a intentar generar otra instancia y obtenemos lo siguiente:

Generar X^* de $h(x)$:

- $U_1 = 0,80$ (del generador $U(0, 1)$).
- Candidato $X^* = 0,80$.

Generar U_2 :

- $U_2 = 0,90$ (del generador $U(0, 1)$).

Aplicar la Regla de Aceptación/Rechazo:

- $f(X^*) = f(0,80) = 2 \times 0,80 = 1,60$.
- $t(X^*) = t(0,80) = 2$.
- La relación es $\frac{f(X^*)}{t(X^*)} = \frac{1,60}{2} = 0,80$.
- Comparamos U_2 con este valor:
 - ¿Es $U_2 \leq \frac{f(X^*)}{t(X^*)}$?
 - ¿Es $0,90 \leq 0,80$? **No.**
- Como la condición no se cumple, **rechazamos** $X^* = 0,80$. Tendríamos que volver al paso 1 y generar nuevos U_1 y U_2 hasta encontrar un candidato aceptado.

Este proceso se repite hasta que obtienes la cantidad deseada de muestras de la distribución $f(x)$. A medida que generes muchas muestras, la distribución de los valores aceptados se aproximará a $f(x)$.

8.1. Análisis de resultados

Luego de generar una simulación, es importante validarla. Para analizar los resultados, existen dos tipos de simulación:

8.1.1. Réplicas independientes

Considere un modelo de simulación en que se desea estimar el valor esperado de X . El método consiste en hacer N corridas independientes (diferentes semillas) del modelo para obtener una muestra de X a partir de cada corrida, es decir, $\{X_1, X_2, \dots, X_n\}$. El estimador será:

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i$$

Además, se puede calcular la varianza del estimador y construir un intervalo de confianza sobre el valor esperado de X .

8.1.2. Intervalos de Confianza para un parámetro

Supongamos que tenemos una muestra de v.a. i.i.d. $X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 conocido, μ desconocido.

Estimador de μ :

$$\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}(n)$$

Además, sabemos que:

$$\frac{\bar{X}(n) - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Queremos construir un intervalo de confianza a nivel $1 - \alpha$.

$$\begin{aligned} 1 - \alpha &= P(\mu \in \text{intervalo}) = P\left(-Z_{1-\alpha/2} \leq \frac{\bar{X}(n) - \mu}{\sigma/\sqrt{n}} \leq Z_{1-\alpha/2}\right) \\ &= P\left(\bar{X}(n) - Z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}(n) + Z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right) \end{aligned}$$

Notar que μ no es una variable aleatoria. Usaremos dos métodos para construir un intervalo:

Método 1: Si $X_1, \dots, X_n$ son v.a. i.i.d., entonces cuando $n \rightarrow \infty$ se tiene que:

$$\frac{\bar{X}(n) - \mu}{\sqrt{S^2(n)/n}} \sim N(0, 1) \quad \text{por el Teorema Central del Límite}$$

Donde $S^2(n)$ es el estimador de $\text{Var}(X)$:

$$S^2(n) = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X}(n))^2$$

La desventaja de este método es que el intervalo solamente será válido para n grande.

Método 2: Si se asume que $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ entonces se puede demostrar que:

$$t^{(n)} = \frac{\bar{X}(n) - \mu}{\sqrt{S^2(n)/n}}$$

tiene distribución t de Student con $n - 1$ grados de libertad. Así, el intervalo de confianza a nivel $1 - \alpha$ sería:

$$\bar{X}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{S^2(n)/n}$$

—
Cuando hablamos de estadística, es crucial recordar por qué usamos la **distribución t de Student** y cómo se relaciona con la **distribución normal**.

La **distribución t de Student** es especialmente útil en estudios donde el **comportamiento humano** puede introducir sesgos o influir en los resultados. Piensa, por ejemplo, en encuestas de opinión, estudios de mercado o experimentos psicológicos; en estos casos, la variabilidad es a menudo mayor y la muestra suele ser pequeña. Por eso, su forma gráfica es muy **similar a la normal**, pero con colas "más pesadas", lo que significa que tiene más probabilidad en los extremos, reflejando una mayor incertidumbre.

Sin embargo, hay un límite práctico para su uso: se recomienda utilizar la distribución t de Student hasta **30 grados de libertad**. ¿Por qué 30? Después de este punto, la distribución t se vuelve **prácticamente indistinguible de la distribución normal**. Esto se debe al **Teorema del Límite Central**, que establece que, a medida que el tamaño de la muestra aumenta, la distribución de las medias muestrales se aproximará a una distribución normal, independientemente de la forma de la distribución original de la población.

Así que, si tienes más de 30 grados de libertad, es perfectamente válido y a menudo más sencillo usar la distribución normal para tus análisis.