



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería Industrial y Sistemas

Simulación

ICS2123 - Modelos Estocásticos

Prof. Maximiliano González R.

Outline

- 1 Conceptos básicos
- 2 Estructura de un modelo de simulación de eventos discretos
- 3 Generación de instancias de una variable aleatoria
- 4 Análisis de resultados



Outline

- 1 Conceptos básicos
- 2 Estructura de un modelo de simulación de eventos discretos
- 3 Generación de instancias de una variable aleatoria
- 4 Análisis de resultados



Modelos estocásticos

¿Cómo podemos estudiar un modelo con aleatoriedad?

Básicamente, de dos formas:

- Analíticamente: Proceso Poisson, Cadenas de Markov, Sistemas de espera
- Numéricamente: Simulación



Simulación

¿Qué es?

Podemos encontrar varias definiciones:

Definición (Thomas T. Goldsmith Jr. y Estle Ray Mann)

Simulación es una técnica numérica para conducir experimentos en una computadora digital. Estos experimentos comprenden ciertos tipos de relaciones matemáticas y lógicas, las cuales son necesarias para describir el comportamiento y la estructura de sistemas complejos del mundo real a través de largos períodos.

Definición (R. E. Shannon)

La **simulación** es el proceso de diseñar un modelo de un sistema real y llevar a término experiencias con él, con la finalidad de comprender el comportamiento del sistema o evaluar nuevas estrategias - dentro de los límites impuestos por un cierto criterio o un conjunto de ellos - para el funcionamiento del sistema.

Simulación

¿Qué es?

La definición que usaremos en el curso, más simple que las anteriores, es:

Definición

Técnica para estudiar sistemas dinámicos por medio de la representación de su comportamiento usando un modelo matemático del sistema, implementado en un computador.

Es decir, Simulación implica crear un modelo que aproxima ciertos aspectos de un sistema real y que puede ser usado para generar historias artificiales del sistema. Así, se puede predecir el comportamiento del sistema real.



Tipos de Simulación

Una simulación puede ser:

- Estática o Dinámica
- Determinística o Estocástica
- Discreta o Continua

Nos concentraremos en la simulación de eventos discretos (Dinámica, Estocástica, Discreta).



¿Cuándo usar simulación?

Razones para usar simulación:

- Experimentar con el sistema real es costoso, peligroso o puede causar desajustes importantes. Ej: sistema de transporte
- El sistema real no existe y la construcción de prototipos es muy costosa. Ej: reactor nuclear
- Necesidad de estudiar el pasado, presente o futuro del sistema en tiempo real. Ej: operación de 10 años de un puerto
- El sistema es tan complejo que su evaluación analítica es prohibitiva. Ej: colas en redes de espera



Ventajas y Desventajas

Ventajas:

- Permite una complejidad arbitraria en los modelos.
- Permite estudiar modelos que no son analíticamente tratables.
- Un modelo bien construido permite predecir el comportamiento de un sistema.

Desventajas:

- Validación de los modelos puede ser complicada.
- A veces, un proyecto de simulación toma mucho tiempo y capacidad computacional.
- No siempre es rentable realizar un modelo de simulación.



Outline

- 1 Conceptos básicos
- 2 Estructura de un modelo de simulación de eventos discretos
- 3 Generación de instancias de una variable aleatoria
- 4 Análisis de resultados



Modelo de Simulación de Eventos Discretos

Estudiaremos sistemas discretos, en que los cambios de las variables de estado se producen en instantes definidos, como por ejemplo:

- Llegada de un cliente
- Término de atención en la caja
- Momento en que falla un dispositivo

Analizaremos entonces cuáles son los componentes de un modelo de este tipo.



Componentes de un modelo de simulación

- Variables de estado que describen el sistema en un instante dado
- Reloj que registra el tiempo real de la simulación
- Conjunto de Eventos
- Un arreglo que incluye una posición para cada tipo de evento y que almacena el tiempo en que ocurrirá el siguiente evento de este tipo
- Una subrutina que actualiza el estado del sistema para cada tipo de evento
- Un programa principal que determina el siguiente evento a ocurrir y que transfiere el control a la subrutina del evento correspondiente
- Indicadores que van registrando estadísticas de interés
- Una subrutina de inicialización de variables
- Medidas de desempeño: medidas del comportamiento del sistema
- Variables de entrada (input), con distribución de probabilidades conocida



Diagrama de flujo

Definición

El **diagrama de flujo** o diagrama de actividades es la representación gráfica de algún algoritmo o proceso. Se utiliza en disciplinas como programación, economía, procesos industriales e incluso psicología cognitiva.

Nomenclatura básica:

- **Círculo:** Inicio y Término
- **Rectángulo:** Evento
- **Rombo:** Decisión



Ejemplo

Veamos un ejemplo para que quede más claro.

Consideremos una máquina que procesa trabajos, la llegada de éstos es aleatoria, como también su tiempo de procesamiento. Queremos estimar el tiempo de espera promedio en la cola de los trabajos. Supongamos que los tiempos de llegada y de atención son exponenciales.

¿Es necesario hacer simulación? **No!**

Conocemos métodos analíticos que nos permiten obtener estos resultados. Sin embargo, supongamos ahora que los tiempos de llegada siguen una distribución aleatoria F , mientras que los tiempos de atención siguen una distribución aleatoria G . Queremos obtener el tiempo de espera promedio en la cola de los primeros N trabajos, es decir:

$$W_q = \sum_{i=1}^N \frac{W_q(i)}{N}$$

Siendo $W_q(i)$ el tiempo de espera en la cola del i -ésimo cliente. No conocemos expresiones exactas que nos ayuden, por lo que plantearemos un modelo de simulación.




Eventos:

- Llegada de un trabajo al sistema.
- Salida de un trabajo del sistema.

Variables de estado:

- NCOL: cantidad de trabajos en la cola.
- STATUS: 1 si la máquina está ocupada, 0 si no.
- NCLIENTES: Número de trabajos que han completado su periodo de espera en la cola.
- ESTOT: Tiempo de espera total en la cola de los trabajos que han completado su periodo de espera.
- T: Reloj de la simulación.
- TPE(1): Instante en que ocurrirá la siguiente llegada de un trabajo (evento tipo 1).
- TPE(2): Instante en que ocurrirá la siguiente salida de un trabajo (evento tipo 2).
- TLLEG(i): Arreglo que en la posición i guarda el instante de llegada del trabajo que ocupa la posición i en la cola.





Ejemplo

El método anterior se puede extrapolar de forma general. La clave es mantener el reloj de la simulación y avanzar en el tiempo a medida que “pasan cosas”.

En algunos casos sencillos, esto se puede hacer de forma implícita pero avanzando el tiempo “cliente a cliente”.

Supongamos un ejemplo $G/G/1$, en que tenemos tiempos entre llegada de clientes aleatorio con alguna distribución genérica, tiempos de atención con alguna distribución genérica, un servidor, capacidad infinita del sistema y con regla de atención FIFO.

Queremos estimar el tiempo promedio esperado en la cola, el número de personas esperadas en el sistema y la utilización del servidor.



Ejemplo

Usaremos la siguiente notación:

- I_i (Interarrival time): Tiempo entre llegadas entre el cliente $i - 1$ y el cliente i .
- A_i (Arrival time): Instante de llegada del cliente i .

$$A_i = \sum_{j=1}^i I_j$$

- T_i (Starting service time): Instante en que empieza a atenderse el cliente i .

$$T_i = \max\{A_i, D_{i-1}\}$$

- W_i (Waiting time): Tiempo de espera en la cola.

$$W_i = T_i - A_i$$

- S_i (Service time): Tiempo de servicio.
- D_i (Departure time): Instante en que cliente i abandona el sistema.

$$D_i = T_i + S_i$$

Notemos que las únicas dos expresiones que no están en función de otras son I_i y S_i . Esto es porque ambas se deben generar como instancias de variables aleatorias.



Ejemplo

Supongamos entonces que se tiene el siguiente ejemplo: llegan seis clientes, y se cuenta con la información de tiempos entre llegada de cada uno y su tiempo de servicio.

i	I_i	A_i	T_i	W_i	S_i	D_i
1	3	3	3	0	7	10
2	1	4	10	6	6	16
3	2	6	16	10	4	20
4	4	10	20	10	6	26
5	5	15	26	11	1	27
6	5	20	27	7	2	29

El resto de los parámetros se calcula en función de I_i y S_i .



Así, tenemos que:


- Tiempo de espera promedio: $\sum_{i=1}^6 \frac{W_i}{6} = 7.33$
- Cantidad de personas promedio en el sistema:

Definamos $L(t)$ como la cantidad de gente en el instante t . Observemos que $L(t)$ solo depende de las llegadas y salidas del sistema.

t	Evento	$L(t)$
0	Simulación empieza	0
3	Llegada de cliente 1	1
4	Llegada de cliente 2	2
6	Llegada de cliente 3	3
10	Cliente 1 se va del sistema, Llegada de cliente 4	3
15	Llegada de cliente 5	4
16	Cliente 2 se va del sistema	3
20	Cliente 3 se va del sistema, Llegada de cliente 6	3
26	Cliente 4 se va del sistema	2
27	Cliente 5 se va del sistema	1
29	Cliente 6 se va del sistema	0



Gráficamente, sería:



Por lo tanto, la cantidad de personas promedio sería:

$$\bar{L} = \frac{1}{29} \int_0^{29} L(t) dt = \frac{70}{29} = 2.41$$

Otra forma de calcularlo sería sumando, para cada cliente, su tiempo de estadía, luego dividirlo por el tiempo total.

$$\bar{L} = \frac{\sum_{i=1}^6 (D_i - A_i)}{29} = \frac{7 + 12 + 14 + 16 + 12 + 9}{29} = \frac{70}{29}$$



- Utilización del servidor:

El servidor está ocupado cuando $L(t) > 0$. Eso ocurre en el intervalo $[3, 29]$. No está ocupado en el intervalo $[0, 3]$. Por lo tanto, su ocupación es de $\frac{26}{29} = 89.66\%$



Ahora, ¿Qué pasaría si el sistema de atención fuese LIFO? Se tendrían los siguientes valores:

i	I_i	A_i	T_i	W_i	S_i	D_i
1	3	3	3	0	7	10
2	1	4	23	19	6	29
3	2	6	17	11	4	21
4	4	10	10	0	6	16
5	5	15	16	1	1	17
6	5	20	21	1	2	23

Tiempo de espera promedio: $\frac{\sum_{i=1}^6 W_i}{6} = 5.33$

$$\bar{L} = \frac{58}{29} = 2.0$$

En este caso, una atención LIFO obtiene mejores resultados (“de pura suerte”).



Ejemplo en Julia

Considere un puesto de venta de helados en la playa donde atiende una persona. Los clientes llegan según un Proceso de Renovación donde los tiempos entre eventos corresponden a una v.a. uniforme entre 4 y 6 minutos, y las atenciones toman un tiempo que corresponde a una v.a. exponencial con una media de 4 minutos. El sistema tiene una capacidad de 6 personas (es decir, si la cola tiene 5 personas, los clientes no ingresan al sistema).

- 1 Desarrolle una simulación computacional de este puesto de helados para simular 8 horas de operación del sistema. Adjunte *screenshots* de su código (u otros desarrollos relevantes). Para una corrida de esta simulación, muestre lo siguiente:
 - (i) Cantidad total de clientes atendidos.
 - (ii) Tiempo promedio de los clientes en el sistema.
 - (iii) Tiempo en el sistema de aquel cliente que estuvo la mayor cantidad de tiempo en el sistema.
 - (iv) Estimación de la probabilidad de que el sistema se encuentre vacío en el largo plazo.
 - (v) Estimación de la proporción de demanda perdida (porcentaje de clientes que no ingresaron al sistema).



Ejemplo en Julia

Considere un puesto de venta de helados en la playa donde atiende una persona. Los clientes llegan según un Proceso de Renovación donde los tiempos entre eventos corresponden a una v.a. uniforme entre 4 y 6 minutos, y las atenciones toman un tiempo que corresponde a una v.a. exponencial con una media de 4 minutos. El sistema tiene una capacidad de 6 personas (es decir, si la cola tiene 5 personas, los clientes no ingresan al sistema).

- 2 Suponga ahora que los tiempos entre eventos para las llegadas de clientes corresponden a una v.a. uniforme entre 1 y 9 minutos, y que el sistema sigue teniendo una capacidad para 6 personas (es decir, si la cola tiene 5 personas, los clientes no ingresan al sistema). Simule 8 horas de operación del sistema y vuelva a calcular los mismos indicadores que en la parte anterior. Compare con los resultados obtenidos anteriormente y discuta lo que obtiene.
- 3 Suponga ahora que los tiempos entre eventos para las llegadas de clientes corresponden a una v.a. uniforme entre 1 y 9 minutos, y que el sistema tiene una capacidad para 3 personas (es decir, si la cola tiene 2 personas, los clientes no ingresan al sistema). Simule 8 horas de operación del sistema y vuelva a calcular los mismos indicadores que en la parte anterior. Compare con los resultados obtenidos anteriormente y discuta lo que obtiene.



Ejemplo en Julia

```

SimulacionPuestoDeHelados.jl X
C:\> Users > Alvaro > Desktop > SimulacionPuestoDeHelados.jl > ExponentialInstance
1  ### Ejemplo puesto de helados en Julia ###
2
3  # Documentación de distribución uniforme en Julia:
4  # https://juliastats.org/Distributions.jl/stable/univariate/#Distributions.Uniform
5
6  # Importamos paquetes necesarios
7
8  using Pkg; Pkg.add("Random"); Pkg.add("Distributions");
9
10 using Random, Distributions
11
12 # Definimos generadores de realizaciones de variables aleatorias exponencial y uniforme
13
14 function ExponentialInstance(lambda)
15     u = rand(Uniform(0, 1))
16     return -log(1 - u) / lambda
17 end
18
19 function UniformInstance(a, b)
20     u = rand(Uniform(0, 1))
21     return (b - a) * u + a
22 end
23
24 # Definimos los parametros a ocupar
25
26 a = 1                # Parametro de la uniforme
27 b = 9                # Parametro de la uniforme
28 lambda = 1/4         # Parametro de la exponencial
29 T = 0                # Reloj
30 Tfin = 4800          # Tiempo de la simulacion
31 NClientesAtendidos = 0 # Numeros de clientes atendidos
32 NClientesPerdidos = 0 # Numero de clientes perdidos
33 LargoCola = 0        # Clientes en la cola
34 Capacidad = 3        # Capacidad total del sistema
35 EstadoHeladero = 0   # vale 1 si el heladero esta atendiendo a alguien
36 TiempoProxllegada = UniformInstance(a, b) # Tiempo de llegada del proximo cliente
37 TiempoProxSalida = Inf # Tiempo de salida del cliente que esta siendo atendido
38 TiempoTotalPermanencia = 0 # Tiempo total de permanencia en el sistema de los clientes
39 Tiemposllegada = zeros(1, Capacidad) # Tiempos de llegada de los clientes en la cola
40 TiempoPermanenciaMaximo = 0 # Tiempo maximo de un cliente en el sistema
41 TiempoTotalSistemaVacio = 0 # Cantidad de tiempo del sistema vacio
42

```



Ejemplo en Julia

```

43 # Simulación
44
45 while (T < Tfin)
46     if TiempoProxLlegada < TiempoProxSalida
47         if LargoCola < Capacidad - 1
48             if EstadoHeladero == 0
49                 global EstadoHeladero = 1
50                 global TiempoTotalSistemaVacio += (TiempoProxLlegada - T)
51                 global T = TiempoProxLlegada
52                 global TiempoProxLlegada = T + UniformInstance(a, b)
53                 global TiempoProxSalida = (T + ExponentialInstance(lambda))
54                 setindex!(TiemposLlegada, T, 1)
55             else
56                 global T = TiempoProxLlegada
57                 global TiempoProxLlegada = T + UniformInstance(a, b)
58                 global LargoCola += 1
59                 setindex!(TiemposLlegada, T, LargoCola + 1)
60             end
61         else
62             global NClientesPerdidos += 1
63             global T = TiempoProxLlegada
64             global TiempoProxLlegada = T + UniformInstance(a, b)
65         end
66     else
67         global T = TiempoProxSalida
68         global NClientesAtendidos += 1
69         global TiempoTotalPermanencia += (T - TiemposLlegada[1])
70         global TiempoPermanenciaMaximo = max(TiempoPermanenciaMaximo, (T - TiemposLlegada[1]))
71         if LargoCola > 0
72             global LargoCola -= 1
73             global TiempoProxSalida = T + ExponentialInstance(lambda)
74             for i in 1:(Capacidad - 1)
75                 setindex!(TiemposLlegada, TiemposLlegada[i + 1], i)
76             end
77             setindex!(TiemposLlegada, 0, Capacidad)
78         else
79             global EstadoHeladero = 0
80             global TiempoProxSalida = Inf
81         end
82     end
83 end

```



Ejemplo en Julia

```

84
85 # Resultados
86
87 println("Simulation parameters: lambda = ", lambda, ", uniform(", a, ", ", b, "), Capacity = ", Capacidad)
88 println("RESULTADOS:")
89 println("Served clients: ", NClientesAtendidos)
90 println("Average time of clients in the system: ", TiempoTotalPermanencia/NClientesAtendidos)
91 println("Longest time in the system of a client: ", TiempoPermanenciaMaximo)
92 println("Estimation of the probability that the system is empty in the long-term: ", TiempoTotalSistemaVacio/Tfin)
93 println("Estimation of the proportion of unserved demand: ", NClientesPerdidos / (NClientesAtendidos + NClientesPerdidos))
94 println("\n\n\n")

```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL

Julia

```

Simulation parameters: lambda = 0.25, uniform(1,9), Capacity = 3
RESULTADOS:
Served clients: 886
Average time of clients in the system: 6.996625567618846
Longest time in the system of a client: 37.59654243852819
Estimation of the probability that the system is empty in the long-term: 0.26631731982675485
Estimation of the proportion of unserved demand: 0.0865979381443299

```

```

Simulation parameters: lambda = 0.25, uniform(1,9), Capacity = 3
RESULTADOS:
Served clients: 883
Average time of clients in the system: 6.809361402221988
Longest time in the system of a client: 42.588193739554754
Estimation of the probability that the system is empty in the long-term: 0.2614688225473983
Estimation of the proportion of unserved demand: 0.09342915811088295

```

```

Simulation parameters: lambda = 0.25, uniform(1,9), Capacity = 3
RESULTADOS:
Served clients: 836
Average time of clients in the system: 7.351703283249297
Longest time in the system of a client: 45.226765503410434
Estimation of the probability that the system is empty in the long-term: 0.27097132345975
Estimation of the proportion of unserved demand: 0.09816612729234088

```



Outline

- 1 Conceptos básicos
- 2 Estructura de un modelo de simulación de eventos discretos
- 3 Generación de instancias de una variable aleatoria**
- 4 Análisis de resultados



Generación de variables aleatorias

En los ejemplos anteriores se sabe cómo calcular cada valor...¿dónde está la aleatoriedad entonces?

Para el ejemplo 1: $TPE(1) = T + F$, $TPE(2) = T + G$

T es la "hora actual" de la simulación, pero ¿Qué es F ? ¿Qué es G ?
¿Cómo se calculan?

F representa una instancia de una v.a. de distribución $F(x)$, así como G representa una instancia de una v.a. de distribución $G(x)$.

Para el ejemplo 2, simplemente dimos las instancias, no se habló de cómo calcularlas.

Veremos los siguientes métodos para generar instancias de variables aleatorias:

- Método de la transformada inversa (para calcular instancias de una variable aleatoria con función distribución genérica)
- Generación de números aleatorios $U(0,1)$
- Método de aceptación y rechazo



Método de la transformada inversa

Supongamos que queremos generar instancias de una variable aleatoria continua X con distribución de probabilidades F . Entonces, sabemos que:

$$F(x) = \mathbb{P}(X \leq x)$$

Sea U una v.a. con distribución de probabilidad uniforme sobre $[0,1]$. Entonces:

$$\mathbb{P}(U \leq u) = u, \quad 0 \leq u \leq 1$$

Por lo tanto, como $0 \leq F(x) \leq 1$, podemos plantear la siguiente igualdad:


$$\mathbb{P}(U \leq F(x)) = F(x) = \mathbb{P}(X \leq x) \quad (1)$$



Método de la transformada inversa

Ahora bien, $F(\cdot)$ siempre es una función monótona no decreciente y, por lo tanto el evento $\{U \leq F(x)\}$ es equivalente al evento $\{F^{-1}(U) \leq x\}$.

Gráficamente, sería:



Método de la transformada inversa

La equivalencia de los dos eventos implica que:

$$\mathbb{P}(U \leq F(x)) = \mathbb{P}(F^{-1}(U) \leq x) \quad (2)$$

Obsérvese que $F^{-1}(U)$ es una función de una v.a. y , por lo tanto, es también aleatoria. Luego, las ecuaciones (1) y (2) implican que:

$$\mathbb{P}(X \leq x) = \mathbb{P}(F^{-1}(U) \leq x)$$

Por lo tanto, las variables aleatorias X y $F^{-1}(U)$ tienen la misma distribución de probabilidades.



Método de la transformada inversa

El método que utilizaremos para generar instancias de X (denominado de la transformada inversa), opera de la siguiente manera:

- 1 Generar una instancia U_1 de U , en que $U \sim U(0, 1)$
- 2 Sea $X_1 = F^{-1}(U_1)$. Entonces X_1 es una instancia de X .

Nótese que $F^{-1}(U)$ es una v.a. distinta de X , pero que comparte su distribución de probabilidades. Por lo tanto, generar una instancia de $F^{-1}(U)$ es equivalente a generar una instancia de X .

Para generar una secuencia $X_1, \dots, X_n$ de instancias de X , independientes entre sí, debemos generar una secuencia $U_1, \dots, U_n$ independientes entre sí.



Generación de números aleatorios $U(0,1)$

Características de un buen método de generación de números aleatorios:

- Que los números generados aparenten tener una distribución $U(0,1)$.
- Que los números generados aparenten ser independientes.
- Que el método sea rápido y no requiera mucha memoria.
- Que sea reproducible (que puedan repetir los números generados).



Generación de números aleatorios $U(0,1)$

Método congruencial lineal

Este es el método estándar.

- Se elige un valor inicial X_0 (semilla)
- $X_i = (aX_{i-1} + c) \bmod m$
- $U_i = \frac{X_i}{m}$

Los valores de U_i aparentan tener una distribución $U(0,1)$ y ser independientes entre sí!

Dependiendo de las constantes a, c y m el método puede tener mejores o peores propiedades.



Ejemplo

Ejercicio

Suponga que a través de un método congruencial se generaron dos instancias de una v.a. Uniforme(0,1): 0.2 y 0.8. A partir de ellas genere dos instancias de una v.a. con distribución Exponencial de media 3.

Solución:

Sea F la función distribución. Sabemos que $F(x) = 1 - e^{-\lambda x}$. Por lo tanto, debemos calcular F^{-1} .

$$\begin{aligned} y &= 1 - e^{-\lambda x} \\ 1 - y &= e^{-\lambda x} \\ -\frac{1}{\lambda} \ln(1 - y) &= x \end{aligned}$$

Por lo tanto, $F^{-1}(U) = -\frac{1}{\lambda} \ln(1 - U)$. Así, ocupando las dos instancias dadas en el enunciado, podemos obtener:

- $X_1 = -\frac{1}{1/3} \ln(1 - 0.2) = 0.669$
- $X_2 = -\frac{1}{1/3} \ln(1 - 0.8) = 4.828$




Histograma en Julia

```

Histograma.jl
C:\Users\Alvaro\Desktop> Histograma.jl
1  ### Histograma realizaciones variable aleatoria exponencial ###
2
3  # Importamos paquetes necesarios
4
5  # using Pkg; Pkg.add("Random"); Pkg.add("Distributions"); Pkg.add("Plots.jl"); Pkg.add("CSV"); Pkg.add("DataFrames");
6
7  using Random, Distributions, Plots, CSV, DataFrames
8
9  # Definimos generador de realizaciones de variable aleatoria exponencial
10
11 function ExponentialInstance(lambda)
12     u = rand(Uniform{0, 1})
13     return -log(1 - u) / lambda
14 end
15
16 # Generamos realizaciones
17
18 N = 100000
19 lambda = 1/4
20 X = zeros(N)
21
22 for i = 1:N
23     X[i] = ExponentialInstance(lambda)
24 end
25
26 println("Promedio realizaciones: ", sum(X)/N, "\n")
27
28 # Construimos histograma
29
30 df = DataFrame{Realizaciones=X[1:1]}
31 plot(df, x=Realizaciones, kind="histogram", bins=30)

```



Ejemplo

Ejercicio (Variable Aleatoria Discreta)

Suponga que a través de un método congruencial se generaron dos instancias de una v.a. Uniforme(0,1): 0.4 y 0.75. A partir de ellas genere dos v.a. con distribución Geométrica de parámetro 0,3.

Solución:

Sabemos que la distribución geométrica tiene probabilidad $\mathbb{P}(X = k) = (1 - p)^{k-1}p$. La función acumulada en este caso es $F(k) = 1 - (1 - p)^k$. Se puede deducir que:

$$F^{-1}(u) = \frac{\ln(1 - u)}{\ln(1 - p)}$$

Sin embargo, si usamos directamente la función, obtendríamos $X_1 = 1.43$, $X_2 = 3.88$.

No tiene sentido!

Esto se produce porque queremos generar instancias de una v.a. discreta.



Ejemplo

Se debe hacer:

$$X = \min\{k : F(k) \geq U\} = \lceil F^{-1}(U) \rceil$$

Es decir, se busca el menor k tal que la función distribución sea mayor o igual al número obtenido de $U(0,1)$. En este caso, debería ser:

$$X_i = \lceil \frac{\ln(1 - U_i)}{\ln(1 - p)} \rceil$$

Por lo tanto, $X_1 = 2$ y $X_2 = 4$.



Método de Aceptación y Rechazo

¿Qué pasa si la función de distribución no se puede invertir de forma eficiente?

La idea detrás del método de Aceptación y Rechazo es obtener muestras a partir de una función “parecida”, de las cuales se aceptarán solamente algunas de ellas.

Supongamos que queremos generar instancias de una v.a. X con función densidad $f(x)$, pero usar el método de la transformada inversa es complicado en este caso. Entonces, necesitamos encontrar una función

$h(x) \equiv \frac{t(x)}{c}$ con la cual ojalá sea fácil de generar instancias. En este caso, se debe cumplir que:

- $f(x) \leq t(x) \quad \forall x$
- $\infty > c = \int_{-\infty}^{\infty} t(x) \geq \int_{-\infty}^{\infty} f(x) = 1$

Es decir, $t(x)$ es mayor que $f(x)$ para todo x , y c es el “área bajo la curva” de $t(x)$.



Método de Aceptación y Rechazo

Teorema (von Neumann, 1951)

Sea la función $g(x) = \frac{f(x)}{t(x)}$ (notar que $0 \leq g(x) \leq 1$). Sean U, Y dos v.a. independientes tales que $U \sim U(0, 1)$, e Y posee función densidad $h(y)$. La variable aleatoria definida como Y condicionada a que $U \leq g(Y)$ distribuye según la función de densidad $f(y)$.

Por lo tanto, esto nos permite encontrar una expresión que posee la misma distribución que andamos buscando. Así, de este teorema se deriva el algoritmo de Aceptación-Rechazo

Algoritmo A-R:

- ➊ Generar una instancia de $U \sim U(0, 1)$.
- ➋ Generar una instancia de $Y \sim h(y)$ (independiente de U).
- ➌ Si $U \leq g(Y)$, entonces hacer $X = Y$. Si no, volver al paso 1.



Método de Aceptación y Rechazo

Hay dos factores a considerar al ocupar este método:

- Se debe poder generar fácilmente instancias a partir de $h(y)$. Si no, no ofrece ventaja con respecto al método anterior.
- El tamaño de c está directamente relacionado con qué tan cercana es la función $t(x)$ a la función $f(x)$. Por lo tanto, se desea que c sea pequeño, debido a que:

$$\mathbb{P}(U \leq g(Y)) = \frac{1}{c}$$

Entonces, el número esperado de iteraciones hasta obtener una instancia distribuye Geométrica($\frac{1}{c}$), por lo que el número esperado de iteraciones es c .



Método de Aceptación y Rechazo

Ejemplo

Considere una variable aleatoria continua X con la siguiente función de densidad: $f(x) = b(3 - x^2)(1 - x^2)$ para $x \in [-1, 1]$.

- (a) Encuentre el valor de b para que $f(x)$ efectivamente sea una función de densidad. Si lo necesita, utilice un método numérico para éste propósito.
- (b) Desarrolle un algoritmo de Aceptación y Rechazo para generar instancias de X .
- (c) Si se usa su algoritmo, ¿cuál es el valor esperado de la cantidad de rechazos necesarios para generar una instancia?
- (d) Utilice su algoritmo con los siguientes números aleatorios Uniforme(0,1): 0.672, 0.236, 0.464, 0.711, 0.283, 0.111.
- (e) Utilice algún método computacional para generar 1000 instancias de una v.a. Uniforme(0,1) y genere instancias de X a partir de estos números, utilizando el método desarrollado. ¿Cuántas instancias se

Método de Aceptación y Rechazo

(a) Buscamos resolver la siguiente ecuación para encontrar b :

$$\int_{-1}^1 b \cdot (3 - x^2) \cdot (1 - x^2) \cdot dx = 1$$

De donde, aplicando *Mathematica*, se obtiene que $b = 0.267857$.

(b) El algoritmo es el siguiente:

- Generamos una instancia $U \sim \text{Uniforme}(0,1)$.
- Sea $t(x) = 3b = 0.803$ y sea $c = \int_{-1}^1 3b \cdot dx = 1.606$.
- Sea $h(x) = \frac{t(x)}{c} = \frac{1}{2}$. Luego, $h(x) \sim \text{Uniforme}(-1,1)$.
- Sea $g(x) = \frac{f(x)}{t(x)} = \frac{(3-x^2) \cdot (1-x^2)}{3}$
- Sea W otra instancia $\text{Uniforme}(0,1)$, hacemos: $Y = 2W - 1$
- Si $U \leq g(y)$, entonces Y es una instancia de X .



Método de Aceptación y Rechazo

(c) El número esperado de iteraciones es c , por lo que los rechazos son $c - 1$. Es decir:

$$\text{Número esperado de rechazos} = c - 1 = 0.606$$

- (d)
- $U = 0.672$
 $W = 0.236$
 $Y = 2W - 1 = -0.528$
 $g(y) = 0.654195$
 Como $g(y) = 0.654195 \leq U = 0.672$, Y no es instancia de X .
 - $U = 0.464$
 $W = 0.711$
 $Y = 2W - 1 = 0.422$
 $g(y) = 0.773126$
 Como $g(y) = 0.773126 \geq U = 0.464$, Y es instancia de X .
 - $U = 0.283$
 $W = 0.111$
 $Y = 2W - 1 = -0.778$
 $g(y) = 0.315078$
 Como $g(y) = 0.315078 \geq U = 0.283$, Y es instancia de X .




Método de Aceptación y Rechazo

(e) El histograma es el siguiente:



Método de Aceptación y Rechazo

El gráfico es el siguiente:



Se puede apreciar que ambos gráficos son prácticamente idénticos.



Método de Aceptación y Rechazo

Demostración del Teorema

Sea A el evento de aceptar el valor de Y como instancia de X , i.e.

$$U \leq g(Y)$$

La función de distribución de X es:

$$F_x(X) = P(X \leq x) = P(Y \leq x|A) = \frac{P(A, Y \leq x)}{P(A)}$$

Ahora:

$$P(A, Y \leq x) = \int_{-\infty}^{\infty} P(A, Y \leq x|Y = y)h(y)dy \quad \text{Ley de probabilidades totales}$$

$$= \frac{1}{c} \int_{-\infty}^x P(A|Y = y)t(y)dy$$



Método de Aceptación y Rechazo

Tenemos:

$$P(A|Y = y) = P(U \leq g(Y)|Y = y) = P(U \leq g(y)|Y = y)$$

$$P(U \leq g(y)) = g(y) \quad U \text{ es uniforme}$$

Entonces:

$$\begin{aligned} P(A, Y \leq x) &= \frac{1}{c} \int_{-\infty}^x g(y)t(y)dy \\ &= \frac{1}{c} \int_{-\infty}^x f(y)dy \end{aligned}$$



Método de Aceptación y Rechazo

También necesitamos:

$$P(A) = P(A, y \leq \infty) = \frac{1}{c} \int_{-\infty}^{\infty} f(y) dy = \frac{1}{c}$$

Así:

$$F_x(X) = \frac{\frac{1}{c} \int_{-\infty}^x f(y) dy}{\frac{1}{c}} = \int_{-\infty}^x f(y) dy$$

Con esto queda demostrado que la función de densidad de probabilidades de X es $f(x)$



Método de Aceptación y Rechazo

¿Podemos utilizar Aceptación y Rechazo para generar instancias de una distribución normal?

Si queremos generar una instancia de $X \sim N(\mu, \sigma^2)$, podemos hacer $X = \sigma Z + \mu$, donde Z denota una v.a. con una distribución $N(0, 1)$.

Por lo tanto, es suficiente encontrar un algoritmo para generar $Z \sim N(0, 1)$.

Además, si podemos generar una instancia para el valor absoluto $|Z|$, luego por simetría podemos obtener una instancia para Z generando de forma independiente una v.a. S (para el signo) que es 1 con probabilidad $1/2$ y -1 con probabilidad $1/2$, para luego generar $Z = S|Z|$.



Método de Aceptación y Rechazo

Lo interesante es que $|Z|$ tiene la siguiente densidad:

$$f(x) = \frac{2}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad x \geq 0$$

¿Por qué?

Ahora, observamos que $t(x) = \sqrt{2e/\pi} e^{-x} \geq f(x) \quad \forall x \geq 0$
(¿cómo demostrarlo?)

Con esto, tomamos $h(x) = e^{-x}, x \geq 0$, la densidad exponencial con tasa 1, algo que ya sabemos cómo simular fácilmente (con el método de transformada inversa).

Y tenemos $c = \sqrt{2e/\pi} \approx 1.32$ (¿por qué?), y $g(y) = f(y)/t(y) = e^{-(y-1)}$



Método de Aceptación y Rechazo

Distribución Normal - Algoritmo

- 1 Genera U
- 2 Genera Y con una distribución exponencial a la tasa 1; es decir, genera U' y establece $Y = -\ln(1 - U')$.
- 3 Si $U \leq e^{-(Y-1)^2/2}$, sea $|Z| = Y$, en otro caso volver a 1.
- 4 Genera U'' . Sea $Z = |Z|$ si $U'' \leq 0.5$, sea $Z = -|Z|$ si $U'' > 0.5$



Outline

- 1 Conceptos básicos
- 2 Estructura de un modelo de simulación de eventos discretos
- 3 Generación de instancias de una variable aleatoria
- 4 Análisis de resultados**



Tipos de simulación

Para analizar los resultados, existen dos tipos de simulación:

- Simulación en Estado de Régimen (Largo plazo)
Interesa evaluar el desempeño del sistema después que ha pasado mucho tiempo, de modo que las condiciones iniciales del sistema dejan de tener efecto. Ejemplos:
 - Operación de una fábrica durante un año
 - Operación de un puerto durante un año
 - Tiempo promedio de espera de productos en cola considerando 10.000 productos
- Simulación terminal (Corto plazo)
Se simula un sistema hasta que ocurre un cierto evento terminal, habitualmente en el corto plazo. Ejemplos:
 - Operación de un banco entre 12:00 y 14:00
 - Simulación de la máquina hasta que se han atendido 100 productos
 - Operación de estación de metro Baquedano durante hora punta



Análisis de resultados

Réplicas independientes

Considere un modelo de simulación en que se desea estimar el valor esperado de X . El método consiste en hacer N corridas independientes (diferentes semillas) del modelo para obtener una muestra de X a partir de cada corrida, es decir, $\{X_1, X_2, \dots, X_n\}$. El estimador será:

$$\bar{X} = \sum_{i=1}^N \frac{X_i}{N}$$

Además, se puede sacar la varianza del estimador y construir un intervalo de confianza sobre el valor esperado de X .

Este es uno de los métodos más comunes para el análisis de output.



Intervalos de Confianza para un parámetro

Supongamos que tenemos una muestra de v.a. i.i.d

$X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 conocido, μ desconocido.

Estimador de μ :

$$\sum_{i=1}^n \frac{X_i}{n} = \bar{X}(n)$$

Además, sabemos que:

$$\frac{\bar{X}(n) - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

Queremos construir un intervalo de confianza a nivel $1 - \alpha$.

$$\begin{aligned} 1 - \alpha &= \mathbb{P}(\mu \in \text{intervalo}) = \mathbb{P}(-Z_{1-\alpha/2} \leq \frac{\bar{X}(n) - \mu}{\sigma/\sqrt{n}} \leq Z_{1-\alpha/2}) \\ &= \mathbb{P}(\bar{X}(n) - Z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}(n) + Z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}) \end{aligned}$$

Notar que μ no es una variable aleatoria.



Intervalos de Confianza para una Simulación Terminal

Se tiene lo siguiente:

- n réplicas independientes del modelo
- Largo de cada corrida queda determinado para un evento terminal E .
- Condiciones iniciales son las mismas para todas las corridas.

Sea X_j el valor del estimador de la medida de desempeño en la corrida número j . $X_1, \dots, X_n$ son v.a. i.i.d., pero no conocemos su distribución. Queremos construir un intervalo de confianza para $\mu = \mathbb{E}(X)$.

Usaremos dos métodos para construir un intervalo.



Intervalos de Confianza para una Simulación Terminal

Método 1:

Si $X_1, \dots, X_n$ son v.a. i.i.d., entonces cuando $n \rightarrow \infty$ se tiene que:

$$\frac{\bar{X}(n) - \mu}{\sqrt{S^2(n)/n}} \sim N(0, 1) \text{ por el Teorema Central del Límite}$$

$S^2(n)$ es el estimador de $\text{Var}(x)$:

$$S^2(n) = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X}(n))^2$$

La desventaja de este método es que el intervalo solamente será válido para n grande.



Intervalos de Confianza para una Simulación Terminal

Método 2:

Si se asume que $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ entonces se puede demostrar que:

$$t^{(n)} = \frac{\bar{X}(n) - \mu}{\sqrt{S^2(n)/n}}$$

tiene distribución de student con $n - 1$ grados de libertad.

Así, el intervalo de confianza a nivel $1 - \alpha$ sería:

$$\bar{X}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{S^2(n)/n}$$



Ejemplo

Supongamos que tenemos una sucursal de un banco con 5 cajeros, una sola cola de clientes, atiende de 9 am a 5 pm, pero permanece abierta hasta que todos los clientes que han llegado hasta las 5 pm han sido atendidos. Llegada de clientes es Poisson a tasa de 1 por minuto; tiempos de servicio exponenciales con media 4 minutos. Atención es FIFO. La siguiente tabla muestra los resultados de 10 réplicas del modelo de simulación:

Réplica	Nº atendidos	Demora promedio en cola	Largo promedio cola
1	484	1.53	1.52
2	475	1.66	1.62
3	484	1.24	1.23
4	483	2.34	2.34
5	455	2.00	1.89
6	461	1.69	1.56
7	451	2.69	2.50
8	486	2.86	2.82



Supongamos que queremos construir un intervalo de confianza al 90% para la demora promedio en la cola.

$$\mathbb{E}(X) = \mathbb{E}\left(\sum_{i=1}^N \frac{D_i}{N}\right)$$

De los datos podemos obtener entonces:

$$\bar{X}(10) = 2.03 \quad S^2(10) = 0.31$$

$$\Rightarrow \bar{X}(10) \pm t_{9,0.95} \sqrt{S^2(n)/n} = 2.03 \pm 0.32$$



Batch Means para Simulación de Largo Plazo

Motivación

Si tenemos una muestra del tiempo de espera en la cola de m clientes, no sería correcto que todos esos valores son independientes entre sí.

Claramente existe una correlación entre el valor del tiempo de un cliente y el del cliente anterior.

$$\underbrace{Y_1, Y_2, Y_3, Y_4}_{\text{Correlacionados}}$$

Sin embargo, sí se puede decir que esta muestra es estacionaria en el tiempo una vez que el sistema se encuentra en estado de régimen. Con esto, los m clientes los puedo separar en “grupos”, de tal manera que cada grupo es “aproximadamente independiente” entre sí. Por lo tanto, en vez de ver cada muestra, se ve el promedio de cada grupo, asumiendo que son independientes entre sí.

$$\underbrace{Y_1, Y_2, Y_3, Y_4, \dots, Y_{i+1}, Y_{i+2}, Y_{i+3}, Y_{i+4}}_{\bar{Y}_1} \quad \underbrace{\hspace{10em}}_{\bar{Y}_2}$$



Batch Means

La idea es particionar el output $Y_1, Y_2, \dots, Y_i, \dots$ en grupos aproximadamente independientes entre sí. Para esto, se realizará el siguiente supuesto: el proceso $Y_1, Y_2, \dots, Y_i, \dots$ es estacionario en covarianza, lo que es equivalente a:

- $\mathbb{E}(Y_i) = v$
- $\text{Var}(Y_i) = \sigma^2, \forall i$
- $\text{Cov}(Y_i, Y_{j+i}) = C_j$, independiente de i

(La dependencia es estable en el tiempo)

Las observaciones $Y_1, Y_2, \dots, Y_m$ se dividen en n grupos de tamaño l ($m = n \cdot l$):

$$Y_1, Y_2, \dots, Y_l, \quad Y_{l+1}, Y_{l+2}, \dots, Y_{2l}, \dots$$

$\bar{Y}_j(l)$ es la media muestral de las l observaciones del grupo j . Por lo tanto,

$$\bar{\bar{Y}}(n, l) = \sum_{j=1}^n \frac{\bar{Y}_j(l)}{n} = \sum_{i=1}^m \frac{Y_i}{m}$$



Batch Means

Si l es grande, los $\bar{Y}_j(l), j = 1, \dots, n$ serán aproximadamente no correlacionados. Además, si l es grande, $\bar{Y}_j(l) \sim \text{Normal (TCL)}$. Luego, se asume que:

$\bar{Y}_1(l), \bar{Y}_2(l), \dots, \bar{Y}_n(l)$ son v.a. i.i.d $\sim N(v, \sigma^2)$

$$\Rightarrow \frac{\bar{\bar{Y}}(n, l) - v}{\sqrt{S_{\bar{Y}}^2(n)/n}} \sim \text{Student con } n - 1 \text{ grados de libertad}$$

En donde
$$S_{\bar{Y}}^2(n) = \frac{1}{n-1} \sum_{j=1}^n (\bar{Y}_j(l) - \bar{\bar{Y}}(n, l))^2$$



Batch Means

Posibles fuentes de error del método:

- Es difícil que el proceso $Y_1, Y_2, \dots, Y_m$ sea estacionario en covarianza. Pero será aproximadamente estacionario para m grande.
- Si l no es grande, entonces $\bar{Y}_j(l)$ no será Normal.
- Si l no es grande, entonces los $\bar{Y}_j(l)$ pueden estar correlacionados.

