

Capítulo 3

Cadenas de Markov en Tiempo Discreto

3.1 Distribución de Probabilidades del Proceso y Tiempos entre Retornos a un Estado

Consideremos el caso de la evolución de una enfermedad infecciosa en la población, la que se transmite por el contacto de una persona infectada con una persona sana (denominada también susceptible); en ese contacto se produce el traspaso del agente infectante (una bacteria o un virus). A partir del momento que una persona se infecta, existe usualmente un **período de latencia** durante el cual la enfermedad se desarrolla en forma puramente interna, sin que el individuo emita agentes infectantes. Cuando este período termina, comienza el **período de infección** durante el cual la persona emite agentes infectantes que pueden ser traspasados a otros individuos susceptibles. En algún momento dentro de la evolución de la enfermedad del individuo **aparecerán** los **síntomas** de la infección, los que permiten reconocer la enfermedad en la persona infectada. Comúnmente, en ese momento se produce el aislamiento de la persona infectada, hasta que se recupera de la enfermedad (o eventualmente fallece). El tiempo que transcurre desde que un individuo se infecta hasta que aparecen en él los síntomas de la enfermedad se denomina **período de incubación**. En algunas enfermedades, este período se extiende bastante más allá del inicio del período de infección, lo que resulta extremadamente peligroso porque la persona infectada pasa inadvertida, y está en condiciones de contagiar a personas sanas.

La **transmisión de la enfermedad** desde un individuo infectado a uno susceptible es un **evento aleatorio**. Intentemos desarrollar un modelo estocástico que nos ayude a describir la evolución de la enfermedad en una población. Consideremos períodos de tiempo mensuales. Sea p la probabilidad que durante un mes cualquiera, un infectado le transmita la enfermedad a uno susceptible. Asumiremos que p es una constante, aunque en modelos más sofisticados esta probabilidad puede depender del número de infectados durante ese mes. Sea X_n el número de susceptibles de la población al final de mes n .

¿Cómo podemos obtener la distribución de X_{n+1} ? Es evidente que ésta es una variable aleatoria que, dado un valor inicial X_0 del tamaño de la población de susceptibles, dependerá de cuántos individuos sanos se hayan estado infectando en los meses $1, 2, \dots, n$. Asumiremos que un individuo permanece infectado durante los períodos definidos anteriormente (latencia, infección e incubación) y que una vez que el período de incubación termina, la persona es aislada y tratada de la enfermedad, después de lo cual permanece inmune.

Si conociéramos el valor de X_n (número de susceptibles al final del mes n), sabríamos cuántas personas son candidatos a enfermarse durante el mes $n + 1$. Si asumimos que la probabilidad p de infectarse es la misma para todas ellas, y que las personas se infectarán en forma independiente, entonces la distribución de X_{n+1} , condicionada a X_n corresponde a una binomial. Concretamente:

$$P(X_{n+1} = j | X_n = i) = \binom{i}{j} p^j (1-p)^{i-j} \quad \text{en que } j \leq i, \quad (3.1)$$

ya que si al final del mes n había i susceptibles y queremos que al final del mes $n + 1$ existan j susceptibles, entonces durante el mes $n + 1$ deben infectarse exactamente $i - j$ personas.

Vemos que para conocer la distribución de X_{n+1} necesitamos conocer a X_n . Pero ésta, a su vez, es una variable aleatoria. ¿Cómo obtenemos la distribución de X_n ? Razonando de un modo análogo, vemos que X_n depende a su vez de X_{n-1} . Además, X_{n-1} depende de X_{n-2} , etc. Luego, concluimos que X_{n+1} depende no sólo de X_n , sino que indirectamente depende también de X_{n-1} , X_{n-2} , $\dots$, X_1 , X_0 . El proceso estocástico $\{X_n, n = 0, 1, \dots\}$ está conformado por una familia de variables aleatorias dependientes entre sí (además, es fácil observar que estas variables no tienen la misma distribución de probabilidades). Sin embargo, la dependencia entre estas variables aleatorias es tal que, si yo conozco el valor de X_n los valores de X_0 , X_1 , X_2 , $\dots$, X_{n-1} son irrelevantes para estudiar el comportamiento de X_{n+1} . Obsérvese que esto **no** quiere decir que X_{n+1} sea independiente de X_0 , X_1 , X_2 , $\dots$, X_{n-1} , sino que lo que ocurre es que estas variables influyen en X_{n+1} **sólo a través de X_n** .

Si denominamos el período $n + 1$ como el futuro, el período n como el presente, y los períodos $0, 1, \dots, n - 1$ como el pasado, diremos entonces que **"el pasado influye sobre el futuro sólo a través del presente"**. Esta propiedad se denomina la **propiedad markoviana** de un proceso estocástico. A continuación entregaremos una definición formal.

Definición 3.1 (Propiedad markoviana) *Sea X_n una v.a. que toma valores enteros. Entonces se dice que el proceso $\{X_n, n = 0, 1, 2, \dots\}$ cumple con la propiedad markoviana si:*

$$\mathbb{P}(X_{n+1} = j | X_n = i, X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) = \mathbb{P}(X_{n+1} = j | X_n = i). \quad (3.2)$$

En el ejemplo que acabamos de analizar, nos interesará obtener la distribución de probabilidades del proceso, esto es, la distribución de X_n , para cualquier n . Este objetivo es análogo al que hemos estudiado en otros procesos anteriores (como por ejemplo en el Proceso de Poisson). Sin embargo, hay otras preguntas que, en este caso, puede ser de interés. Por ejemplo, a los epidemiólogos les puede interesar obtener información acerca de la duración de la epidemia o la velocidad a la que ésta se propaga. Si inicialmente hay N personas sanas ($X_0 = N$), ¿Cuánto tiempo pasará hasta que el número de susceptibles disminuya a la mitad? Claramente, este tiempo es una variable aleatoria. Denominemos T a esta variable. ¿Cómo podemos escribir una expresión para su distribución? Supongamos que N es par, y sea $k = \frac{N}{2}$. Entonces:

$$\mathbb{P}(T = m) = \mathbb{P}(X_m = k, X_{m-1} \neq k, X_{m-2} \neq k, \dots, X_1 \neq k | X_0 = N). \quad (3.3)$$

Más adelante analizaremos un método que nos permita obtener una expresión para (3.3).

Consideremos ahora otros ejemplos de sistemas que cumplen con la propiedad markoviana.

Ejemplo 3.1 *Una empresa mantiene en inventario un cierto producto para satisfacer la demanda de sus clientes. Sea X_n , el número de ítemes en inventario al principio del día n . Sean $Y_1, Y_2, \dots, Y_i, \dots$ las demandas sucesivas en los días $1, 2, \dots$. Asumamos que éstas corresponden a v.a. i.i.d. Suponemos que la función densidad de estas variables está dada por:*

$$\mathbb{P}(Y_i = k) = a_k, \quad k = 0, 1, 2, \dots \quad (3.4)$$

La política de inventario que se utiliza está determinada por dos parámetros, s y S , y opera de la siguiente manera: al final de cada día se revisa el nivel del inventario y si éste es menor que s , se pone una orden de stock para elevar el nivel de inventario hasta el valor S . Suponemos que esta orden llega al principio del día siguiente. La demanda que no puede ser satisfecha se pierde.

Desarrollo:

Para obtener la distribución de X_{n+1} observamos que se cumple la siguiente relación recursiva:

$$X_{n+1} = \begin{cases} X_n - Y_n & \text{si } X_n - Y_n \geq s, \\ S & \text{si } X_n - Y_n < s. \end{cases} \quad (3.5)$$

Esta expresión nos permite concluir que el proceso $\{X_n, n = 0, 1, 2, \dots\}$ también cumple con la propiedad markoviana (obsérvese que no existe una dependencia entre Y_n y $X_n, X_{n-1}, \dots, X_0$). Tanto este ejemplo como el anterior cumplen además con otra propiedad, que se describe en la Definición 3.2.

Definición 3.2 (Propiedad de Estacionaridad) *El proceso $\{X_n, n = 0, 1, 2, \dots\}$ cumple con la **propiedad de estacionaridad** si $\mathbb{P}(X_{n+1} = j | X_n = i)$ depende sólo de i y de j , pero no de n . En este caso, definimos como $P_{i,j}$ a esta probabilidad, y se denomina **probabilidad de transición en una etapa**.*

La propiedad de estacionaridad establece que los mecanismos probabilísticos que definen la evolución del proceso no cambian con el tiempo. En el caso de una enfermedad infecciosa, esto es cierto si la probabilidad de contagio es constante a lo largo del año. El modelo no será válido si, por ejemplo, esta probabilidad depende de la estación del año. En el caso de la fiebre tifoidea, se sabe que la probabilidad de infectarse es mucho más alta en los meses de temperaturas altas.

Las probabilidades $P_{i,j}$ pueden agruparse en una matrix P , denominada matriz de probabilidades de transición en una etapa, que tendrá tantas filas y columnas como estados tenga el proceso. En el modelo de inventario, los estados

posibles son $s, s+1, \dots, S$. En este caso, la matriz P tienen la siguiente forma:

$$P = \begin{array}{c|ccccccc|c} & s & s+1 & s+2 & \dots & \dots & \dots & S-1 & S \\ \hline s & a_0 & 0 & \dots & \dots & \dots & \dots & 0 & F^C(0) \\ s+1 & a_1 & a_0 & 0 & \dots & \dots & \dots & 0 & F^C(1) \\ s+2 & a_2 & a_1 & a_0 & 0 & \dots & \dots & 0 & F^C(2) \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ S-1 & a_{S-s-1} & a_{S-s-2} & a_{S-s-3} & \dots & \dots & \dots & a_0 & F^C(S-s-1) \\ S & a_{S-s} & a_{S-s-1} & a_{S-s-2} & \dots & \dots & \dots & a_1 & A \end{array}, \quad (3.6)$$

en que:

$$F^C(k) = \mathbb{P}(Y_n > k) = \sum_{j=k+1}^{\infty} a_j, \quad (3.7)$$

y

$$A = a_0 + F^C(S-s). \quad (3.8)$$

El modelo de inventario no cumplirá con la propiedad de estacionaridad si, por ejemplo, las demandas fueran estacionales (esto es, si la distribución de probabilidades de Y_n variara con n). ¿Se cumplirá esta propiedad si la empresa usara una política de descuentos cuando tiene mucho stock en inventario, de modo que la distribución de probabilidades de la demanda dependiera del nivel de stock? Obsérvese también que en este modelo podríamos haber definido la variable de estado X_n , como el nivel del inventario al final del día n . (Obtenga la matriz P para este caso).

Para este sistema, también interesará obtener información de la distribución X_n a lo largo del tiempo y de otras variables temporales. ¿Cómo podemos obtener la distribución de probabilidades del tamaño de la orden de reposición? ¿Con qué frecuencia el sistema enfrentará una demanda insatisfecha?

◇

Ejemplo 3.2 *Al patio de cargas de buques del Puerto de Valparaíso llegan, al principio del día, containers para ser almacenados. El número de containers que llega al principio de un día cualquiera tiene una distribución de probabilidades $\{q_k, k = 0, 1, 2, \dots\}$. El patio tiene una capacidad suficiente para acomodar todos los containers que puedan llegar. Cada container permanece en el patio, antes de ser cargado en un barco, un tiempo aleatorio con distribución exponencial con media de $\frac{1}{u}$ días. Sea Y_n el número de containers que llegará el día n y X_n el número de containers en el patio al principio del día n antes de que lleguen los nuevos containers.*

Desarrollo:

El modelo que describe la evolución de X_n es el siguiente:

$$X_{n+1} = Z_n + W_n, \quad (3.9)$$

en que Z_n corresponde al número de containers, de entre los X_n disponibles al principio del día n , que permanecerán al menos un día adicional en el patio, y W_n es el número de containers, de entre los que llegaron al principio el día n , cuya permanencia en el patio será superior a un día. Por la propiedad de falta de memoria de la distribución exponencial, sabemos que la probabilidad de que uno cualquiera de los X_n containers, permanezca al menos un día adicional es e^{-u} , independientemente de cuánto tiempo lleve en el patio. Por lo tanto,

$$\mathbb{P}(Z_n = k | X_n = i) = \binom{i}{k} (e^{-u})^k (1 - e^{-u})^{i-k}. \quad (3.10)$$

Respecto a W_n tenemos que:

$$\begin{aligned} \mathbb{P}(W_n = k) &= \sum_{m=1}^{\infty} \mathbb{P}(W_n = k | Y_n = m) \mathbb{P}(Y_n = m) \\ &= \sum_{m=1}^{\infty} \binom{m}{k} (e^{-u})^k (1 - e^{-u})^{m-k} q(m). \end{aligned} \quad (3.11)$$

Vemos que el Proceso $\{X_n, n = 0, 1, 2, \dots\}$ cumple con la propiedad markoviana y la propiedad de estacionariedad. ¿Cómo se modifica el modelo si el patio tiene una capacidad limitada de K containers, y todos los que llegan cuando el patio está copado son rechazados?

◇

Definición 3.3 (Cadena de Markov en tiempo discreto) *El proceso estocástico $\{X_n, n = 0, 1, 2, \dots\}$ se denomina una **Cadena de Markov en tiempo discreto** si cumple con la propiedad markoviana y la propiedad de estacionariedad.*

Nos interesa obtener la distribución de probabilidades del proceso estocástico $\{X_n, n = 0, 1, 2, \dots\}$ en que X_n es una variable aleatoria entera, que representa el estado del sistema y n es un parámetro entero no negativo que representa un tiempo discreto (días, meses, etc.). Estos instantes discretos de tiempo se denominan **etapas**. Así, si $X_n = i$, diremos que el estado del sistema en la etapa n es i . Es interesante notar que nuestro modelo es suficientemente general

para aceptar la posibilidad de que el tiempo físico transcurrido entre dos etapas no sea siempre el mismo. Supongamos, por ejemplo, que estamos en un sistema de atención de público y X_n representa el número de personas en el sistema a la llegada del cliente número n . Si estos clientes llegan de acuerdo a un proceso estocástico (como el de Poisson) los tiempos transcurridos entre etapas no son fijos (es más, en este caso son aleatorios). Más adelante analizaremos las condiciones que debe cumplir el proceso de llegada y de permanencia de los clientes en el sistema para que X_n corresponda a una Cadena de Markov.

Para una etapa n cualquiera, nos interesa conocer $\mathbb{P}(X_n = j)$ para todo valor de j . Sea $f^{(n)}$ un vector columna con tantas posiciones como estados, que representa la distribución del proceso en la etapa n , esto es:

$$f^{(n)} = \begin{bmatrix} f_0^{(n)} \\ f_1^{(n)} \\ \vdots \\ f_i^{(n)} \\ \vdots \end{bmatrix} \quad (3.12)$$

en que $f_j^{(n)} = \mathbb{P}(X_n = j)$.

Si $n = 0$, $f^{(0)}$ corresponde a la distribución de probabilidades del estado inicial del proceso. (Si el estado inicial es conocido con certeza, $f^{(0)}$ contiene un 1 en la posición correspondiente a ese estado y ceros en las restantes posiciones).

Ahora bien:

$$f_j^{(n)} = \mathbb{P}(X_n = j) = \sum_i \mathbb{P}(X_n = j | X_0 = i) \mathbb{P}(X_0 = i). \quad (3.13)$$

Sea:

$$P_{ij}^{(n)} = \mathbb{P}(X_n = j | X_0 = i), \quad (3.14)$$

diremos que ésta corresponde a una probabilidad de transición del proceso en n etapas. Observemos que por la probabilidad de estacionariedad de la Cadena de Markov se tiene que:

$$P_{ij}^{(n)} = \mathbb{P}(X_{m+n} = j | X_m = i), \quad (3.15)$$

para cualquier $m = 1, 2, \dots$

Sea $P^{(n)} = (P_{ij}^{(n)})$ la matriz de probabilidades de transición del proceso en n etapas.

Entonces:

$$f_j^{(n)} = \sum_i P_{ij}^{(n)} f_i^{(0)}. \quad (3.16)$$

La expresión vectorial de esta ecuación corresponde a:

$$f^{(n)} = \left[P^{(n)} \right]^T f^{(0)}, \quad (3.17)$$

en que $\left[P^{(n)} \right]^T$ corresponde a la matriz transpuesta de $P^{(n)}$.

Luego, para conocer $f^{(n)}$ sólo necesitamos conocer $f^{(0)}$ y la matriz $P^{(n)}$ de probabilidades de transición en n etapas.

Proposición 3.1 (Ecuación de Kolmogorov)

$$P^{(n)} = P^{(r)} P^{(n-r)} \quad \text{para cualquier } r = 1, 2, \dots, n-1. \quad (3.18)$$

Demostración:

Para calcular $P_{ij}^{(n)} = \mathbb{P}(X_{m+n} = j | X_m = i)$ consideramos la etapa intermedia $m+r$. Sabemos que existen muchas trayectorias del proceso que nos permiten ir del estado i en la etapa m al estado j en la etapa $n+m$. Sin embargo, en la etapa intermedia $m+r$ el proceso debe estar en algún estado.

Luego, podemos escribir:

$$\mathbb{P}(X_{m+n} = j | X_m = i) = \sum_k \mathbb{P}(X_{m+n} = j \text{ y } X_{m+r} = k | X_m = i). \quad (3.19)$$

(Aquí hemos usado solamente el teorema de probabilidades totales).

La probabilidad incluida en la sumatoria corresponde a la probabilidad conjunta de dos eventos. Para calcularla queremos usar la conocida fórmula de probabilidades condicionales:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \quad (3.20)$$

o bien:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A|B) \mathbb{P}(B), \quad (3.21)$$

en que, en nuestro caso, los eventos A y B ya están condicionados, previamente, al evento $\{X_m = i\}$. Esta condicionalidad debe mantenerse en cada una de las probabilidades del lado derecho de (3.21). Luego:

$$\frac{\mathbb{P}(X_{m+n} = j, X_{m+r} = k | X_m = i)}{\mathbb{P}(X_{m+n} = j | X_m = i, X_{m+r} = k) \mathbb{P}(X_{m+r} = k | X_m = i)} = \quad (3.22)$$

Sin embargo, la propiedad markoviana nos dice que:

$$\mathbb{P}(X_{m+n} = j | X_m = i, X_{m+r} = k) = \mathbb{P}(X_{m+n} = j | X_{m+r} = k), \quad (3.23)$$

(¿Por qué?).

Luego:

$$\frac{\mathbb{P}(X_{m+n} = j | X_m = i)}{\sum_k \mathbb{P}(X_{m+n} = j | X_{m+r} = k) \mathbb{P}(X_{m+r} = k | X_m = i)} = \quad (3.24)$$

Es decir:

$$\begin{aligned} P_{ij}^{(n)} &= \sum_k P_{kj}^{(n-r)} P_{ik}^{(r)} \\ &= \sum_k P_{ik}^{(r)} P_{kj}^{(n-r)} \end{aligned} \quad (3.25)$$

Matricialmente, la ecuación (3.25) equivale a:

$$P^{(n)} = P^{(r)} P^{(n-r)}. \quad (3.26)$$

Que corresponde a lo queríamos demostrar.

□

Si escogemos $r = 1$, se tiene que:

$$P^{(n)} = P^{(1)} P^{(n-1)} = P P^{(n-1)}. \quad (3.27)$$

Pero $P^{(n-1)}$ también puede ser descompuesto usando $r = 1$, con lo que obtenemos:

$$P^{(n)} = P P P^{(n-2)}. \quad (3.28)$$

Si continuamos este procedimiento, se tiene que:

$$P^{(n)} = P^n, \quad (3.29)$$

es decir, la matriz de probabilidad de transición en n etapas se obtiene como la potencia n –ésima de la matriz P de probabilidades de transición en una etapa.

Corolario 3.1

$$f^{(n)} = [P^n]^T f^{(0)}. \quad (3.30)$$

Por lo tanto, para la distribución de probabilidades del proceso en una etapa n cualquiera, debemos encontrar la potencia n –ésima de la matriz de probabilidades de transición P .

Ejemplo 3.3 (Sistema Productivo en Serie con Feedback) *Consideremos un sistema productivo de tres etapas en serie. El tiempo de proceso en cada etapa es fijo y vale h minutos. Cada etapa esta sujeta a posibles desperfectos, por lo que, cada vez que un producto completa su proceso en una etapa, es sometido a un control de calidad. Dependiendo del resultado de este control, el producto sigue a la siguiente etapa o debe volver a algunas de las etapas anteriores (para ser reprocesado). Cada una de estas alternativas tiene asociada probabilidades fijas, independientemente de cuantas veces haya pasado el producto por esa etapa. Supongamos, por el momento, que esta línea de producción va a procesar un sólo producto que llega al sistema en $t = 0$. Nos interesa estudiar la ubicación de este producto a medida que pasa el tiempo (así como también el tiempo en que eventualmente sale terminado). Las etapas del proceso corresponden a intervalos sucesivos de largo h . Sea X_n el número del proceso en que comenzará a ser procesado el producto al inicio de la etapa n (nh). Los estados del proceso serán 1, 2, 3, y 4, en que el estado 4 corresponde al caso en que el producto sale terminado exitosamente después del proceso 3.*

Desarrollo:

Supongamos que la matriz P de este proceso es la siguiente:

$$P = \begin{array}{c|cccc} & 1 & 2 & 3 & 4 \\ \hline 1 & \frac{1}{2} & \frac{1}{2} & 0 & 0 \\ 2 & \frac{1}{4} & \frac{1}{4} & \frac{1}{2} & 0 \\ 3 & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{2} \\ 4 & 0 & 0 & 0 & 1 \end{array}. \quad (3.31)$$

Para obtener la distribución de probabilidades de la ubicación del producto en un instante cualquiera, debemos calcular las potencias de la matriz P ; esto lo podemos hacer directamente, o bien usando la técnica denominada representación espectral de matrices. Esta técnica utiliza los valores y vectores propios de la matriz P para representar sus potencias; concretamente, si P es de $r \times r$, y $\lambda_1, \lambda_2, \dots, \lambda_r$

son sus valores propios, es posible escribir la matriz P^n como:

$$P^n = \lambda_1^n B_1 + \lambda_2^n B_2 + \dots + \lambda_r^n B_r, \quad (3.32)$$

en que $B_1, B_2, \dots, B_r$ son matrices de $r \times r$ que se obtienen a partir de los vectores propios fila y vectores propios columna asociados a los valores propios $\lambda_1, \lambda_2, \dots, \lambda_r$ (los detalles se pueden encontrar en (Cinlar, 2013)).

Para la matriz P de (3.31) se obtienen numéricamente los valores propios, cuyo código de programa está disponible en: https://github.com/facrespo/Modelos_Estocasticos:

Valor propio	
λ_1	1.1356
λ_2	0.8578
λ_3	0.4277
λ_4	0.0000

(3.33)

Las matrices respectivas son:

$$B_1 = \begin{bmatrix} 0.02 & 0.02 & 0.02 & 0.14 \\ 0.02 & 0.02 & 0.02 & 0.12 \\ 0.08 & 0.08 & 0.06 & 0.47 \\ 0.14 & 0.14 & 0.11 & 0.82 \end{bmatrix}, \quad (3.34)$$

$$B_2 = \begin{bmatrix} 0.46 & 0.46 & 0.27 & -0.19 \\ 0.37 & 0.37 & 0.22 & -0.15 \\ 0.10 & 0.10 & 0.06 & -0.04 \\ -0.19 & -0.19 & -0.11 & 0.08 \end{bmatrix}, \quad (3.35)$$

$$B_3 = \begin{bmatrix} 0.18 & 0.18 & -0.60 & 0.02 \\ -0.21 & -0.21 & 0.69 & -0.02 \\ -0.03 & -0.03 & 0.10 & 0.00 \\ 0.02 & 0.02 & -0.06 & 0.00 \end{bmatrix}, \quad (3.36)$$

$$B_4 = \begin{bmatrix} 0.10 & -0.10 & 0.00 & 0.00 \\ 0.20 & -0.20 & 0.00 & 0.00 \\ -0.60 & 0.60 & 0.00 & 0.00 \\ 0.30 & -0.30 & 0.00 & 0.00 \end{bmatrix}. \quad (3.37)$$

La cuarta matriz B_4 (3.37) es irrelevante considerando que $\lambda_4 = 0$.

Consideremos otro ejemplo, supongamos que P es:

$$\begin{bmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{bmatrix}. \quad (3.38)$$

es posible demostrar que:

$$P^n = (1.0)^n \begin{bmatrix} 0.60 & 0.40 \\ 0.60 & 0.40 \end{bmatrix} + (0.5)^n \begin{bmatrix} 0.40 & -0.40 \\ -0.60 & 0.60 \end{bmatrix}. \quad (3.39)$$

◇

También nos interesa conocer cuánto tiempo pasará hasta que el producto salga finalmente terminado (debido a las fallas del proceso, el producto puede eventualmente circular por la línea indefinidamente). Queremos conocer el tiempo que le toma al proceso ir desde el estado 1 al estado 4. Este tiempo es claramente una variable aleatoria. El estudio de este tipo de variables tiene aplicación también en otro tipo de problemas. Pensemos, por ejemplo, en el problema de inventario planteado previamente (Ejemplo 3.1); en ese caso nos puede interesar estudiar el tiempo que transcurre entre dos reposiciones del inventario. Supongamos, para simplificar el análisis, que la demanda es siempre positiva (esto es $a_0 = 0$). Si inicialmente, el inventario es S ($X_0 = S$), se produce una reposición cada vez que el sistema retorna al estado S . Nos interesa estudiar la variable aleatoria que representa el tiempo entre estos retornos.

Veamos un procedimiento para analizar la distribución de probabilidades de estos tiempos. Supongamos, en general, que el estado inicial del sistema es $X_0 = i$, y nos interesa el tiempo que le tomará al proceso entrar en el estado j por primera vez (éste corresponderá a la primera reposición de stock, en el caso del inventario). Sea $T(i, j)$ este tiempo y definamos su función densidad de probabilidades como:

$$\begin{aligned} F_k(i, j) &= \mathbb{P}(T(i, j) = k) \\ &= \mathbb{P}(\text{el sistema llegue al estado } j \\ &\quad \text{por primera vez en la etapa } k) \\ &= \mathbb{P}(X_1 \neq j, X_2 \neq j, \dots, X_{k-1} \neq j, X_k = j | X_0 = i) \end{aligned} \quad (3.40)$$

Podemos calcular estas probabilidades (3.40) en forma recursiva.

Para $k = 1$ se tiene que:

$$F_1(i, j) = \mathbb{P}(X_1 = j | X_0 = i) = P_{ij}. \quad (3.41)$$

$F_k(i, j)$ para $k > 1$ analizamos los posibles estados del sistema en la etapa 1:

$$\begin{aligned} F_k(i, j) &= \sum_{m \neq j} \mathbb{P}(X_2 \neq j, \dots, X_{k-1} \neq j, X_k = j | X_0 = i, X_1 = m) \cdot \\ &\quad \mathbb{P}(X_1 = m | X_0 = i). \end{aligned} \quad (3.42)$$

Por la Propiedad Markoviana se tiene que la probabilidad anterior corresponde a:

$$\begin{aligned}
 F_k(i, j) &= \sum_{m \neq j} \mathbb{P}(X_2 \neq j, \dots, X_{k-1} \neq j, X_k = j | X_1 = m) \cdot \\
 &\quad \mathbb{P}(X_1 = m | X_0 = i) \\
 &= \sum_{m \neq j} F_{k-1}(m, j) P_{im} \\
 &= \sum_{m \neq j} P_{im} F_{k-1}(m, j).
 \end{aligned} \tag{3.43}$$

De este modo hemos obtenido el siguiente sistema recursivo:

$$\begin{aligned}
 F_1(i, j) &= P_{ij} \\
 F_k(i, j) &= \sum_{m \neq j} P_{im} F_{k-1}(m, j), \quad k \geq 2.
 \end{aligned} \tag{3.44}$$

Este sistema puede escribirse también en forma matricial. Si definimos $F_k(\cdot, j)$ como un vector columna que contiene las probabilidades $F_k(i, j)$, $i = 1, 2, \dots$ entonces claramente este vector satisface la siguiente ecuación matricial:

$$F_k(\cdot, j) = Q_j F_{k-1}(\cdot, j), \tag{3.45}$$

en que Q_j se obtiene a partir de la matriz P reemplazando la columna j por una columna de ceros.

Con este sistema recursivo es posible obtener la distribución de probabilidades del tiempo requerido para ingresar al estado j por primera vez, desde cualquier otro estado inicial.

Nos interesa también obtener expresiones simples para el valor esperado de $T(i, j)$. Definimos:

$$\begin{aligned}
 t_{ij} &= \mathbb{E}[T(i, j)] \\
 &= \sum_{k=1}^{\infty} k F_k(i, j).
 \end{aligned} \tag{3.46}$$

Entonces:

$$\begin{aligned}
t_{ij} &= \sum_l \mathbb{E} [T(i, j) | X_1 = l] \mathbb{P} (X_1 = l | X_0 = i) \\
&= \mathbb{E} [T(i, j) | X_1 = j] \mathbb{P} (X_1 = j | X_0 = i) \\
&\quad + \sum_{l \neq j} \mathbb{E} [T(i, j) | X_1 = l] \mathbb{P} (X_1 = l | X_0 = i) \\
&= 1 \cdot P_{ij} + \sum_{l \neq j} (1 + \mathbb{E} [T(l, j)]) P_{il} \\
&= P_{ij} + \sum_{l \neq j} P_{il} + \sum_{l \neq j} \mathbb{E} [T(l, j)] P_{il} \\
&= 1 + \sum_{l \neq j} t_{lj} P_{il}.
\end{aligned} \tag{3.47}$$

Luego:

$$t_{ij} = 1 + \sum_{l \neq j} t_{lj} P_{il}. \tag{3.48}$$

La ecuación (3.48) constituye un sistema de ecuaciones lineales en la variable t_{ij} . Otra manera alternativa de calcular los valores t_{ij} es la siguiente:

El valor esperado de $T(i, j)$ es

$$\mathbb{E} (T(i, j)) = \sum_{k=1}^{\infty} k \cdot F_k(i, j). \tag{3.49}$$

Descomponiendo (3.49), usando (3.45), se tiene:

$$\mathbb{E} (T(\bullet, j)) = \sum_{k=1}^{\infty} k \cdot F_k(\bullet, j) = \sum_{k=1}^{\infty} k Q_j^{k-1} \cdot F_1(\bullet, j) = \sum_{k=1}^{\infty} k Q_j^{k-1} \cdot P_{\bullet j}. \tag{3.50}$$

Proposición 3.2 Si los valores propios de Q_j son todos ≤ 1 , y existe la inversa de $I - Q_j$ se tiene que:

$$\mathbb{E} (T(\bullet, j)) = \sum_{k=1}^{\infty} k Q_j^{k-1} \cdot P_{\bullet j} = (I - Q_j)^{-2} \cdot P_{\bullet j}. \tag{3.51}$$

También nos interesa analizar la probabilidad que si partimos en el estado i , el proceso ingrese al estado j alguna vez. Sea $F(i, j)$ esta probabilidad. Entonces:

$$F(i, j) = \sum_{k=1}^{\infty} F_k(i, j) = \mathbb{P}(T(i, j) < \infty). \tag{3.52}$$

Sumando las ecuaciones del sistema (3.44) obtenemos:

$$F(i, j) = P_{ij} + \sum_{m \neq j} P_{im} F(m, j). \quad (3.53)$$

Observemos que se puede obtener que $F(i, j) < 1$, con lo cual existe la probabilidad positiva que nunca ingresemos al estado j . En este caso, decimos que $\mathbb{P}(T(i, j) = \infty)$ es mayor que 0. En la expresión anterior, $T(i, j) = \infty$ quiere decir no ingresa nunca a ese estado, que es distinto al ingresar a un estado en una etapa arbitrariamente grande.

En el caso de sistemas simples, es posible obtener, por inspección directa, la distribución del tiempo entre retornos a un estado.

Ejemplo 3.4 Supongamos una Cadena de Markov con cuatro estados y con la siguiente matriz de probabilidades de transición:

$$P = \begin{bmatrix} \frac{1}{3} & \frac{2}{3} & 0 & 0 \\ 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & \frac{1}{4} & 0 & \frac{3}{4} \\ 0 & 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}. \quad (3.54)$$

Desarrollo:

Una forma de representar gráficamente una Cadena de Markov es mediante un grafo dirigido, en que existe un nodo para cada estado y un arco entre los nodos i y j si $P_{ij} > 0$. En este caso el grafo aparece en la Figura 3.1 (arriba de cada arco se anota la probabilidad correspondiente).




Figura 3.1: Gráfico representativo de una Cadena de Markov de cuatro estados y probabilidad de transición declarada en (3.54).

Analizando los retornos al estado 2. Tenemos que:

$$F_1(2, 2) = \mathbb{P}(\text{Retornar al estado 2 en una etapa}) = P_{2,2} = \frac{1}{2}. \quad (3.55)$$

$$F_2(2, 2) = P_{2,3}P_{3,2} = \frac{1}{2} \times \frac{1}{2} = \frac{1}{8}. \quad (3.56)$$

No es posible retornar al estado 2 en tres etapas. La probabilidad de retorno en cuatro etapas es:

$$F_4(2, 2) = P_{2,3}P_{3,4}P_{4,3}P_{3,2} = \frac{1}{2} \times \frac{3}{4} \times \frac{1}{2} \times \frac{1}{4} = \frac{3}{64}. \quad (3.57)$$

Por otra parte, para $k > 4$ debemos estudiar todas las trayectorias posibles que generan retornos al estado 2 en k etapas. Sabemos que por cada transición de 3 a 4 debe hacer la correspondiente transición de 4 a 3 que permite volver al estado 2. Para una trayectoria dada, sea m el número de transiciones de 3 a 4 (y las correspondientes transiciones de 4 a 3), y sea r el número de transiciones de 4 a sí mismo. Así, el número total k de transiciones puede escribirse como $k = 2 + 2m + r$ (el 2 inicial lleva cuenta de la primera transición de 2 a 3 y de la transición final de retorno 3 a 2). Sin embargo, el análisis es un poco más complejo por dos razones:

- a) Existen varias combinaciones de m y r que producen el mismo valor de k ,
- b) es necesario considerar el **orden** en que se producen las transiciones; así por ejemplo, la trayectoria o realización del proceso:

$$2 \rightarrow 3 \rightarrow 4 \rightarrow 4 \rightarrow 4 \rightarrow 3 \rightarrow 4 \rightarrow 3 \rightarrow 2$$

es distinta de la trayectoria:

$$2 \rightarrow 3 \rightarrow 4 \rightarrow 4 \rightarrow 3 \rightarrow 4 \rightarrow 4 \rightarrow 3 \rightarrow 2$$

aunque en ambos casos se tiene que $m = 2$, $r = 2$ y $k = 8$.

Si analizamos la secuencia de $2m + r$ transiciones, sabemos que la primera y la última deben ser de 3 a 4 y de 4 a 3 respectivamente. Denominamos como eventos tipo A a las transiciones de 3 a 4, como eventos tipo B las transiciones de 4 a 3 y como eventos tipo C las de 4 a sí mismo. Sabemos que al principio de la secuencia debe haber un evento tipo A y al final uno tipo B . Entre ambos, debemos distribuir $m - 1$ eventos tipo A , $m - 1$ eventos tipo B y r eventos tipo

C . En este grupo, sabemos que después de un B debe venir un A . Los eventos C pueden distribuirse arbitrariamente después de los eventos A . Luego el número de combinaciones o realizaciones posibles que pueden generarse corresponde al número de maneras de distribuirse los r eventos tipo C en m espacios posibles (el espacio entre el primer evento tipo A y la primera secuencia $B \rightarrow A$, el espacio entre la última secuencia $B \rightarrow A$ y el evento fijo B y los $m-2$ espacios intermedios entre secuencias $B \rightarrow A$). Esta cantidad corresponde al número de maneras de distribuir r objetos entre m cajas, los que equivale a $\binom{m+r-1}{r}$. (Una demostración de esta fórmula puede encontrarse en (Anderson, 1982), p. 38).

Por lo tanto, para valores fijos de $m+r$ (tales que $k = 2 + 2m + r$), la probabilidad asociada a la realización del proceso que lleva a retornar al estado 2 en k etapas es:

$$\binom{m+r-1}{r} \frac{1}{2} \times \left(\frac{3}{4}\right)^m \times \left(\frac{1}{2}\right)^r \times \left(\frac{1}{2}\right)^m \times \frac{1}{4} = \binom{m+r-1}{r} \frac{1}{8} \times \left(\frac{1}{2}\right)^r \times \left(\frac{3}{8}\right)^m. \quad (3.58)$$

Si k es par y de la forma $k = 2j$, entonces m puede tomar valores de 1 a $j-1$; para cada valor de m , el correspondiente valor de r es $r = k - 2m - 2 = 2j - 2m - 2$. Por lo tanto:

$$F_k(2, 2) = \sum_{m=1}^{j-1} \binom{m+r-1}{r} \frac{1}{8} \times \left(\frac{1}{2}\right)^{2j-2m-2} \times \left(\frac{3}{8}\right)^m. \quad (3.59)$$

Una forma análoga es válida para el caso k es impar (si es k de la forma $k = 2j + 1$, entonces $m = 1 \dots j - 1$ y $r = 2j - 1 - 2m$).

La probabilidad de **retornar alguna vez** al estado 2 se obtiene sumando las probabilidades asociadas a todos los posibles (retornar en una etapa, en dos etapas, ..., etc.). Si denominamos $F(2, 2)$ a esta probabilidad entonces:

$$F(2, 2) = \sum_{k=1}^{\infty} F_k(2, 2). \quad (3.60)$$

Para calcular este valor, podemos sumar sobre todas las combinaciones de m y r directamente, y así obtener las probabilidades de retornar en cuatro o más etapas (esto resulta más simple que sumar sobre k) Es decir:

$$F(2, 2) = F_1(2, 2) + F_2(2, 2) + \frac{1}{8} \sum_{m=1}^{\infty} \sum_{r=0}^{\infty} \binom{m+r-1}{r} \left(\frac{1}{2}\right)^r \left(\frac{3}{8}\right)^m. \quad (3.61)$$

Para obtener la doble sumatoria, definamos $N = m + r - 1$ y sumemos primero los pares (m, r) que producen un valor de N constante. Usando además la igualdad:

$$\binom{m+r-1}{r} = \binom{N+m-1}{r}, \quad (3.62)$$

obtenemos que la doble sumatoria de (3.61) equivale a:

$$\sum_{N=0}^{\infty} \sum_{m=1}^{N+1} \binom{N}{m-1} \left(\frac{1}{2}\right)^{N-m+1} \left(\frac{3}{8}\right)^m. \quad (3.63)$$

Haciendo el cambio de índice: $j = m - 1$, obtenemos:

$$\begin{aligned} \sum_{N=0}^{\infty} \sum_{j=0}^N \binom{N}{j} \left(\frac{1}{2}\right)^{N-j} \left(\frac{3}{8}\right)^{j+1} &= \frac{3}{8} \sum_{N=0}^{\infty} \sum_{j=0}^N \binom{N}{j} \left(\frac{1}{2}\right)^{N-j} \left(\frac{3}{8}\right)^j \\ &= \frac{3}{8} \sum_{N=0}^{\infty} \left(\frac{1}{2} + \frac{3}{8}\right)^N \\ &= \frac{3}{8} \sum_{N=0}^{\infty} \left(\frac{7}{8}\right)^N \\ &= \frac{3}{8} \times 8 = 3. \end{aligned} \quad (3.64)$$

Por lo tanto:

$$F(2, 2) = F_1(2, 2) + F_2(2, 2) + \frac{1}{8} \times 3 = \frac{1}{2} + \frac{1}{8} + \frac{3}{8} = 1. \quad (3.65)$$

Es decir, con probabilidad 1 el sistema retorna al estado 2 en alguna etapa. Esto no es cierto para todos los estados. Si consideramos el estado 1 en nuestro ejemplo, vemos que si el proceso parte en ese estado, vuelve a ese estado en una etapa, o bien no vuelve nunca, y en ese caso decimos que:

$$\mathbb{P}(T(1, 1) = \infty) = \frac{2}{3}. \quad (3.66)$$

En todo caso, el Ejemplo 3.4 sirve para percatarse que calcular directamente las probabilidades de retorno a un estado puede ser bastante complejo incluso en casos simples de cadenas de pocos estados. En este sentido, el sistema recursivo en (3.44) nos ofrece un procedimiento riguroso, simple de explicitar, y que además puede ser implementado en un computador, tal como hicimos con este capítulo, para ello revisar el código en https://github.com/facrespo/Modelos_

Estocásticos. Si definimos la matriz F_k como $F_k = (F_k(i, j))$, en nuestro ejemplo obtenemos:

$$F_1 = \begin{bmatrix} 0.33 & 0.67 & 0.00 & 0.00 \\ 0.00 & 0.50 & 0.50 & 0.00 \\ 0.00 & 0.25 & 0.00 & 0.75 \\ 0.00 & 0.00 & 0.50 & 0.50 \end{bmatrix}, \quad (3.67)$$

$$F_{10} = \begin{bmatrix} 0.00 & 0.00 & 0.00 & 0.03 \\ 0.00 & 0.02 & 0.00 & 0.01 \\ 0.00 & 0.03 & 0.00 & 0.01 \\ 0.00 & 0.04 & 0.00 & 0.00 \end{bmatrix}, \quad (3.68)$$

$$F_{20} = \begin{bmatrix} 0.00 & 0.00 & 0.00 & 0.00 \\ 0.00 & 0.01 & 0.00 & 0.00 \\ 0.00 & 0.01 & 0.00 & 0.00 \\ 0.00 & 0.02 & 0.00 & 0.00 \end{bmatrix}. \quad (3.69)$$

◇

3.2 Estado del Proceso en el Largo Plazo

Sabemos que la distribución de probabilidades (densidad) del proceso en la etapa n está dada por:

$$f^{(n)} = [P^n]^T f^{(0)}. \quad (3.70)$$

En términos escalares, esta ecuación corresponde a:

$$f^{(n)} = \mathbb{P}(X_n = j) = \sum_{i \in \text{Estados}} P_{ij}^{(n)} f_i^{(0)}. \quad (3.71)$$

Diremos que el proceso tiene **distribución límite**, si existe el límite $\lim_{n \rightarrow \infty} f^{(n)}$. En la medida en que esto ocurra, podemos concluir que, pasado mucho tiempo, la distribución de probabilidades del proceso no cambia de una etapa a otra (podremos hablar entonces de **la** distribución de probabilidades en el largo plazo).

El valor del límite puede o no depender del vector de probabilidades inicial $f^{(0)}$. En el caso de que el límite exista y su valor no dependa de $f^{(0)}$, diremos que el proceso tiene **distribución estacionaria**. Bajo esta situación, las condiciones iniciales son irrelevantes para efectos de su comportamiento en el largo plazo.

Un caso particular de $f^{(0)}$ ocurre cuando el estado inicial X_0 es conocido con certeza; si por ejemplo, $X_0 = i$, entonces $f_i^{(0)} = 1$ y $f_j^{(0)} = 0$ para todo $j \neq i$.

3.2.1 Condiciones para la Existencia de una Distribución Límite

En las secciones anteriores, estudiamos el comportamiento de la variable aleatoria $T(i, j)$, que representa el tiempo que le toma al proceso ir del estado i al estado j por primera vez. En el análisis del proceso en el largo plazo, veremos un aspecto fundamental que es la caracterización de los distintos estados del proceso en cuanto a los tiempos de retornos a un mismo estado, esto es, los tiempos $T(i, i)$.

La probabilidad de que si el sistema parte en el estado i retorne a ese estado **alguna vez** es $F(i, i)$, y la probabilidad de no retornar nunca es $1 - F(i, i)$.


Estas probabilidades permitirán clasificar los estados del proceso en distintos tipos.

Definición 3.4 (Tipo de Estados según su Probabilidad de Retorno)

- El estado i se denominará **transiente** si $F(i, i) < 1$.
- El estado i se denominará **recurrente** si $F(i, i) = 1$. Si $\mathbb{E}(T(i, i)) < \infty$ se denominará **recurrente positivo**; en caso contrario, se denominará **recurrente nulo**.

En el caso de un estado recurrente nulo, existe la seguridad de que si el proceso parte en el estado i , volverá a ese estado alguna vez; sin embargo, el tiempo de retorno será infinito.

Retomemos el Ejemplo 3.4 de la Sección 3.1, cuyo grafo aparece en la Figura 3.1.



En el estado 1, el proceso vuelve en una etapa o no vuelve nunca, es decir:

$$F_1(1, 1) = \frac{1}{3} \text{ y } \mathbb{P}(T(1, 1) = \infty) = \frac{2}{3}. \quad (3.72)$$

Para el estado 2 ya sabemos que $F(2, 2) = 1$. Además, en base a las expresiones anteriores podemos comprobar que $\mathbb{E}(T(2, 2)) < \infty$ y, por lo tanto, el estado 2 es recurrente positivo. En general, para una Cadena de Markov con un número finito de estados es posible demostrar que no pueden existir estados recurrentes nulos; además en este caso los estados no pueden ser todos transientes.

Definición 3.5 (Comunicación de Estados) *Se dice que los estados i y j se comunican si existe un camino para ir de i a j en un número finito de etapas, y viceversa (de j a i).*

En el Ejemplo 3.4, los estados 2, 3 y 4 se comunican entre sí, pero no así los estados 1 y 2.

Por convención diremos que un estado siempre se comunica consigo mismo, ya que:

$$P_{11}^{(0)} = \mathbb{P}(X_0 = i | X_0 = i) = 1. \quad (3.73)$$

Esto es, se comunica a través de un camino de largo 0.

Diremos que todos los estados que se comunican entre sí constituyen una clase de estados.

Estas clases de estados son disjuntas entre sí y cubren todo el conjunto de estados (es decir, generan una partición del conjunto). En el Ejemplo 3.4 el estado 1 constituye una clase y los estados 2, 3 y 4 otra. Si una Cadena de Markov contiene una sola clase de estados (i.e. todos los estados se comunican entre sí), se dirá que es **irreducible**.

La existencia de una distribución límite depende esencialmente del comportamiento en el largo plazo (n grande) de las probabilidades $P_{ij}^{(n)}$. Para analizar estas probabilidades necesitamos el concepto de estado periódico.


Definición 3.6 (Estados Periódicos) *Un estado es **periódico** si, partiendo de ese estado, sólo es posible volver a él en un número de etapas que sea múltiplo de un cierto número entero mayor que uno.*

En otras palabras, el estado j es periódico si existe un número entero $k \geq 1$ tal que $P_{jj}^{(n)}$ sólo para valores n en el conjunto $\{k, 2k, 3k, 4k, \dots\}$.

(Obsérvese que esto no quiere decir que necesariamente $P_{jj}^{(n)} > 0$ para todo n de la forma $n = rk$).


Definición 3.7 (Largo de un período de un estado) El **período** d del estado j corresponde al máximo común divisor de los n para los que $P_{jj}^{(n)} > 0$. Si $d > 1$, diremos que el estado es **periódico con período** d . Si $d = 1$ que el estado es **aperiódico**. Además diremos que el estado es aperiódico si no es posible volver a él (en este caso, el estado es aperiódico por la imposibilidad de chequear la condición de periodicidad).

Veamos el siguiente caso:



Los retornos al estado 2 se pueden producir en las etapas 2, 3, 4, 5, 6, 7, 8, 9, ... Luego $d = 1$ y el estado 2 es aperiódico.

Ejemplo 3.5 Se tiene el grafo:



Desarrollo:

Al estado 1 se puede volver en las etapas 2, 4, 6, 8, ... Luego, es periódico con período 2. Al estado 3 se puede retornar en las etapas 4, 6, 8, 10, ... Luego, el estado 3 también es periódico con período 2 (obsérvese, sin embargo, que al estado 3 no se puede volver en dos etapas; esto no contradice la definición de estado periódico).

◇

Es posible demostrar que todos los estados de una clase son del mismo tipo: transientes, recurrentes nulos o recurrentes positivos, y aperiódicos o periódicos con el mismo período (Verifique que esto es cierto para el ejemplo anterior).

Por otra parte, todas las clases recurrentes son cerradas, es decir, si partimos de un estado de esa clase, nunca saldremos de esa clase.


Ejemplo 3.6 Consideremos la siguiente matriz P de probabilidades de transición:

$$P = \begin{array}{c|ccc} & 0 & 1 & 2 \\ \hline 0 & 1 & 0 & 0 \\ 1 & \frac{1}{2} & \frac{1}{6} & \frac{1}{3} \\ 2 & \frac{1}{3} & \frac{3}{5} & \frac{1}{15} \end{array}. \quad (3.74)$$

Veremos el comportamiento de los estados.

Desarrollo:

Gráficamente:



El estado 0 es recurrente y los estados 1 y 2 forman una clase de estados transientes. Obtengamos la distribución de $T(1, 1)$:

$$\begin{aligned} P(T(1, 1) = 1) &= P_{1,1} = \frac{1}{6}, \\ P(T(1, 1) = 2) &= P_{1,2}P_{2,1} = \frac{1}{3} \times \frac{3}{5} = \frac{1}{5}. \end{aligned} \quad (3.75)$$

Para $k > 2$ se tiene:

$$\mathbb{P}(T(1, 1) = k) = P_{1,2}P_{2,2}^{k-2}P_{2,1} = \frac{1}{3}\left(\frac{1}{15}\right)^{k-2}\frac{3}{5} = \frac{1}{5}\left(\frac{1}{15}\right)^{k-2}. \quad (3.76)$$

$$\begin{aligned} F(1, 1) &= \mathbb{P}(T(1, 1) < \infty) \\ &= \sum_{k=1}^{\infty} \mathbb{P}(T(1, 1) = k) \\ &= \frac{1}{6} + \sum_{k=2}^{\infty} \frac{1}{5}\left(\frac{1}{15}\right)^{k-2} \\ &= \frac{1}{6} + \frac{1}{5} \sum_{n=0}^{\infty} \left(\frac{1}{15}\right)^n \\ &= \frac{8}{21}. \end{aligned} \quad (3.77)$$

Por lo tanto, la probabilidad de que, si partimos del estado 1, no volvamos nunca a ese estado es:

$$\mathbb{P}(T(1, 1) = \infty) = 1 - \mathbb{P}(T(1, 1) < \infty) = 1 - \frac{8}{21} = \frac{13}{21}. \quad (3.78)$$

Obsérvese que esta probabilidad es mayor que $P_{1,0} = \frac{1}{2}$.

◇


3.2.2 Análisis de las Probabilidades $P_{ij}^{(n)}$

Consideremos el caso en que $i = j$ y éste es un estado aperiódico.

Queremos calcular $\lim_{n \rightarrow \infty} P_{jj}^{(n)}$.

Podemos interpretar esta cantidad como la probabilidad de que, al observar el proceso en una etapa cualquiera, después que ha pasado mucho tiempo, éste se encuentre en el estado j (en este caso asumimos que el estado inicial es también el estado j).

Con esta idea en mente, elaboramos un argumento simple, aproximado, para obtener el límite: consideremos un horizonte largo de M etapas. A lo largo de este período ocurren un conjunto de transiciones, en las cuales se pasa por el estado j un cierto número de veces. Esta situación está representada en el siguiente diagrama:



Y_1 representa el tiempo hasta el primer retorno al estado j , Y_2 el tiempo entre el primer y segundo retorno, etc. Obsérvese que, por la propiedad markoviana, el conjunto de estas variables corresponde a variables i.i.d.

Además, la distribución de probabilidades de cualquiera de ellas corresponde a la distribución de la variable $T(j, j)$ mencionada en la sección anterior.

Si n es una etapa cualquiera dentro del horizonte de M etapas, la probabilidad $P_{ij}^{(n)}$ puede aproximarse como el número de veces que el proceso estuvo en el estado j dividido por el largo del horizonte, es decir:

$$P_{jj}^{(n)} = \frac{N(M)}{M}, \quad (3.79)$$

en que $N(M)$ representa el número de veces que el proceso retornó al estado j durante el horizonte de largo M .

a) Consideremos en primer lugar el caso en que j es un **estado recurrente**. A partir del diagrama de estados anterior, podemos concluir que el horizonte de tiempo puede describirse aproximadamente como:

$$M \equiv \sum_{i=1}^{N(M)} Y_i. \quad (3.80)$$

El error de esta aproximación será cada vez menos a medida que M crezca. (¿Es correcta esta aproximación para el caso en que j es un estado transiente?).

Utilizando esta aproximación en la expresión (3.79), obtenemos:

$$P_{jj}^{(n)} = \frac{N(M)}{\sum_{i=1}^{N(M)} Y_i}, \quad (3.81)$$

o bien:

$$P_{jj}^{(n)} = \left(\frac{\sum_{i=1}^{N(M)} Y_i}{N(M)} \right)^{-1}. \quad (3.82)$$

Ahora bien, cuando $M \rightarrow \infty$, $N(M)$ tiende al número total de veces que retorna al estado j durante **todo** el horizonte. Llamemos N_j a esta cantidad. Sabemos en general que, si el proceso parte del estado j , con probabilidad $F(j, j)$ retorna al estado j en alguna etapa posterior, y con probabilidad $1 - F(j, j)$ no retorna nunca a ese estado. Consideremos el evento de no retornar al estado j como un éxito. Entonces N_j corresponde al número de fracasos previos al primer éxito, en una secuencia de eventos independientes en que existe una probabilidad $p = 1 - F(j, j)$, de éxito y $q = F(j, j)$ de fracaso.

Luego:

$$P(N_j = m) = [F(j, j)]^m [1 - F(j, j)], \quad (3.83)$$

que corresponde a la distribución geométrica.

Además:

$$\mathbb{E}(N_j) = \frac{q}{p} = \frac{F(j, j)}{1 - F(j, j)}. \quad (3.84)$$

Ahora, en el caso específico que estamos considerando, en que j es recurrente, $F(j, j) = 1$ y luego: $P(N_j = m) = 0$ para todo m ; es decir, $N_j = \infty$ con probabilidad 1 (y $\mathbb{E}(N_j) = \infty$). Luego, observando de nuevo la expresión (3.82), concluimos que:

$$\lim_{M \rightarrow \infty} \frac{\sum_{i=1}^{N(M)} Y_i}{N(M)} = \frac{\sum_{i=1}^{N_j} Y_i}{N_j}, \quad (3.85)$$

que a su vez corresponde a:

$$\lim_{k \rightarrow \infty} \frac{\sum_{i=1}^k Y_i}{k}, \quad (3.86)$$

y por ley de los grandes números, este límite corresponde a $\mathbb{E}(Y_i)$, o bien $\mathbb{E}(T(j, j))$.

Concluimos entonces que si j es un estado recurrente aperiódico:

$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = \frac{1}{\mathbb{E}(T(j, j))}, \quad (3.87)$$

y este límite será positivo si j es recurrente positivo (ya que en este caso $\mathbb{E}(T(j, j)) < \infty$) y cero si j es recurrente nulo (en que $\mathbb{E}(T(j, j)) = \infty$).

- b) Consideremos ahora el caso en que j es un estado transiente aperiódico. En este caso $F(j, j) < 1$, es decir, existe una probabilidad positiva de no retornar nunca al estado j . Además:

$$P(N_j = m) = [F(j, j)]^m [1 - F(j, j)] > 0 \text{ para todo } m, \quad (3.88)$$

y:


$$\mathbb{E}(N_j) = \frac{1}{1 - F(j, j)} \text{ es un valor finito.} \quad (3.89)$$

También se cumple que: $\sum_{m=1}^{\infty} \mathbb{P}(N_j = m) = 1$, y luego N_j toma un valor finito con probabilidad 1 (esto es $\mathbb{P}(N_j = \infty) = 0$).

Si analizamos de nuevo nuestra representación inicial de la expresión (3.79), tenemos que $N(M) \rightarrow N_j$ cuando $M \rightarrow \infty$, pero ahora N_j es finito con probabilidad 1, luego: $P_{jj}^{(n)} \rightarrow 0$ cuando $M \rightarrow \infty$. Por lo tanto:


$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = 0. \quad (3.90)$$

Gráficamente, la evolución del proceso en este caso será la siguiente:



Después de un cierto número finito de retornos al estado j , existirá una de las variables Y_i que tomará un valor infinito, con lo que no se volverá a producir un retorno al estado j . Luego, a medida que M crezca, la proporción de las veces que el proceso está en el estado j será cada vez más despreciable.

- c) Consideremos ahora el caso que el estado inicial i es distinto del estado que nos interesa analizar en el largo plazo; esto es $i \neq j$ y j supongamos que j es **aperiódico**. Gráficamente, la evolución del proceso es del siguiente tipo:



Es decir, la situación es similar a la anterior excepto que debemos considerar un primer tiempo Z_1 de ingreso al estado j por primera vez (partiendo del estado i);

este tiempo puede ser finito con probabilidad 1 ó bien existir una probabilidad positiva de que sea ∞ . Es evidente que en el segundo caso, $P_{ij}^{(n)} = 0$. Luego podemos escribir, generalizando la expresión de la ecuación (3.81):

$$P_{jj}^{(n)} = \mathbb{P}(Z_1 < \infty) \frac{N(M)}{Z_1 + \sum_{i=1}^{N(M)-1} Y_i} + \mathbb{P}(Z_1 = \infty) \cdot 0. \quad (3.91)$$

Si Z_1 es finito, el comportamiento de la fracción que acompaña a $\mathbb{P}(Z_1 < \infty)$ en la expresión anterior se aproxima, cuando $M \rightarrow \infty$, a:

$$\frac{N(M)}{\sum_{i=1}^{N(M)} Y_i}. \quad (3.92)$$

Además, $\mathbb{P}(Z_1 < \infty) = F(i, j)$. Concluimos, usando argumentos similares al caso anterior, que:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = \frac{F(i, j)}{\mathbb{E}(T(j, j))}. \quad (3.93)$$

La ecuación (3.93) será igual a 0 si el estado j es transiente o recurrente nulo.

- d) Hasta ahora, hemos analizado sólo casos en que el estado j es aperiódico. Supongamos ahora que j es un estado **periódico** de período d . El caso $i = j$ es semejante a las situaciones planteadas en a) y b) excepto que el proceso pueda estar en el estado j sólo múltiplos de su período d . Luego, si j es recurrente, la expresión (3.87) se reemplaza por:

$$\lim_{n \rightarrow \infty} P_{jj}^{(nd)} = \frac{1}{\mathbb{E}(T(j, j))}. \quad (3.94)$$

Y si j es transiente o recurrente nulo, la expresión (3.94) se reemplaza por:

$$\lim_{n \rightarrow \infty} P_{jj}^{(nd)} = 0. \quad (3.95)$$

Obsérvese en este último caso que $P_{jj}^{(m)} = 0$ para todo $m \neq nd$. Luego, podemos definir el límite sin distinguir etapas y concluir que:

$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = 0. \quad (3.96)$$

Finalmente, consideremos el caso $i \neq j$ (j **periódico**). Este caso es mucho más complejo ya que, por ser j periódico, debemos llevar un recuento muy cuidadoso

de la etapa en que queremos analizar el proceso en el largo plazo. Este recuento se verá afectado por el número inicial de etapas requeridas para ir de i a j , ya que éste determinará la etapa a partir de la cual se empiezan a contabilizar los múltiplos de d .

Si i y j son estados recurrentes, sólo es posible llegar de uno al otro si pertenecen a la misma clase (las clases de estados recurrentes son cerradas, esto es, si el sistema parte en un estado de esa clase, nunca sale de esa clase, ya que de lo contrario, los estados de esa clase serían transientes). En este caso, el número de etapas requeridas para ir de i a j está determinado en forma única.

Si denominamos $n(i, j)$ a este número, tenemos:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n(i,j)+nd)} = \frac{1}{\mathbb{E}(T(j, j))}. \quad (3.97)$$

(Obsérvese que en este caso $F(i, j) = 1$). Si j es recurrente nulo, la ecuación (3.97) vale 0.

Si i es transiente y j es recurrente (nulo o positivo), y asumiendo que $F(i, j) > 0$ (en caso contrario el límite es trivialmente 0) los caminos que conducen de un estado al otro no son necesariamente del mismo largo. El análisis requiere por tanto estudiar todas estas alternativas, lo que resulta extremadamente complejo, por lo que lo omitimos. (Sin embargo, este análisis puede encontrarse en la referencia (Bailey, 1975) pag. 160 a 164).

Lo que si está claro es que si el estado j es transiente, se tiene que:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0. \quad (3.98)$$

Todos los resultados que hemos obtenido respecto de estas probabilidades en el límite aparecen resumidos en la Proposición 3.3.

Proposición 3.3 (Probabilidades límites)

a) Si j es un estado **recurrente positivo aperiódico** entonces:

$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = \frac{1}{\mathbb{E}(T(j, j))} > 0. \quad (3.99)$$

b) Si j es un estado **recurrente nulo o transiente (periódico o aperiódico)** entonces:

$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = 0. \quad (3.100)$$

c) Si j es un estado **recurrente positivo periódico**, de período d , entonces:

$$\lim_{n \rightarrow \infty} P_{jj}^{(nd)} = \frac{1}{\mathbb{E}(T(j, j))}. \quad (3.101)$$

d) Si $i \neq j$, y j es un estado **recurrente positivo aperiódico** entonces:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = \frac{F(i, j)}{\mathbb{E}(T(j, j))}. \quad (3.102)$$

El límite vale 0 si $F(i, j) = 0$.

e) Si $i \neq j$, y j es un **estado recurrente nulo o transiente (periódico o aperiódico)** entonces:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0, \quad (3.103)$$

cualquiera sea el estado i .

f) Si $i \neq j$, y si i y j son **estados recurrentes positivos periódicos pertenecientes a una misma clase**, de período d , entonces:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n(i, j) + nd)} = \frac{1}{\mathbb{E}(T(j, j))} > 0, \quad (3.104)$$

en que $n(i, j)$ es el número de etapas requeridas para ir de i a j (determinado en forma unívoca).

g) Si $i \neq j$, y j es un **estado recurrente positivo periódico** e i un **estado transiente**, el cálculo de $\lim_{n \rightarrow \infty} P_{ij}^{(n)}$ requiere analizar las trayectorias alternativas para ir de i a j .

Nótese que si j es recurrente positivo e i es recurrente nulo, $\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0$ ya que i y j pertenecen a dos clases recurrentes distintas, cada una de las cuales es cerrada y, por lo tanto, $P_{ij}^{(n)} = 0$ para todo n .

h) Si j es un **estado recurrente positivo periódico**, e i es un **estado recurrente nulo**, entonces i y j pertenecen a dos clases recurrentes distintas, cada una de las cuales es cerrada, luego $P_{ij}^{(n)} = 0 \forall n$, y por lo tanto:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0. \quad (3.105)$$

De todo lo anterior, es fácil concluir que lo único que puede atentar contra la existencia de una distribución límite es la existencia de estados periódicos.

La Proposición 3.3 c) en particular indica que el límite en cuestión existe sólo si se considera etapa múltiplo de nd (en que d es el período). Pero etapas n que son múltiplos de d se tiene que $P_{jj}^{(n)} = 0$.

Por último, hay que tener claro que puede haber ceros en que hay estados periódicos e igual hay distribución límite.

3.2.3 Condiciones para la Existencia de una Distribución Estacionaria

Si la distribución límite del proceso existe y es independiente de la distribución inicial de probabilidades (o del estado inicial), decimos que el proceso tiene distribución estacionaria y usaremos el vector π para denotar esta distribución, esto es:

$$\pi_j = \lim_{n \rightarrow \infty} \mathbb{P}(X_n = j) = \lim_{n \rightarrow \infty} P_{ij}^{(n)}, \text{ independiente de } i. \quad (3.106)$$

La Proposición 3.4 establece las condiciones necesarias y suficientes para que exista una distribución estacionaria con puros valores positivos.

Proposición 3.4 (Condiciones para existencia Distribución Estacionaria)

Existe una distribución estacionaria π tal que $\pi_j > 0$ para todo j si y sólo si la Cadena de Markov es irreductible, con estados recurrentes positivos aperiódicos.

Demostración:

- a) **Condición necesaria:** Supongamos que la cadena es irreductible aperiódica positiva. A partir de la Proposición 3.3 c), sabemos que si j es recurrente positivo aperiódico, entonces:

$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = \frac{F(i, j)}{\mathbb{E}(T(j, j))}. \quad (3.107)$$

Como la cadena es irreductible, los estados i y j pertenecen a la misma clase (recurrente positiva aperiódica); es fácil observar en este caso que $F(i, j) = 1$ (si partimos de i , con probabilidad 1 llegamos a j alguna vez). Además, $\mathbb{E}(T(j, j)) < \infty$ y luego:

$$\lim_{n \rightarrow \infty} P_{jj}^{(n)} = \frac{1}{\mathbb{E}(T(j, j))} > 0, \quad (3.108)$$

lo que indica que existe una distribución estacionaria y además todos sus elementos son positivos.

- b) **Condición suficiente:** Supongamos que existe una distribución estacionaria π con $\pi_j > 0$ para todo j . Si la cadena fuera reducible (dos ó más clases de estados) podríamos identificar dos estados i y j , pertenecientes a clases distintas, tal que uno de ellos (por ej. el estado j) no pudiera ser accesado desde el otro; por lo tanto $F(i, j) = 0$. Esto indicaría que necesariamente $\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0$.

Del mismo modo, si los estados son periódicos sabemos que la distribución límite no existe (y con mayor razón no existirá distribución estacionaria).

Finalmente, si los estados son transientes o recurrentes nulos, se tiene que:

$$\lim_{n \rightarrow \infty} P_{ij}^{(n)} = 0. \quad (3.109)$$

□

Es posible identificar otras situaciones en las que existe una distribución estacionaria, aunque no con todos los elementos positivos.

Proposición 3.5 (Límite con estados recurrentes positivos y transientes)

Consideremos una Cadena de Markov con un espacio de estados aperiódicos S tal que $S = C \cup T$, en que C es una clase de estados recurrentes positivos y T es un conjunto de una o más clases de estados transientes. Si para cada estado i en T se tiene que:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n \in C | X_0 = i) = 1, \quad (3.110)$$

entonces existe una distribución estacionaria π . Además $\pi_j > 0$ para todo $j \in C$ y $\pi_j = 0$ para todo $j \in T$. (La demostración de esta proposición puede encontrarse en (Gazmuri et al., 1987) pág. 241).

La condición establecida por la Proposición 3.5 exige que si el proceso parte en un estado transiente del conjunto T , con probabilidad 1 el proceso ingrese eventualmente al conjunto C de estados recurrentes positivos. En ese caso, sabemos que el proceso permanece en esa clase para siempre (las clases recurrentes son cerradas).

Con esta condición se elimina la única situación que podría atentar contra la existencia de una distribución estacionaria, ya que si, al iniciarse el proceso en un estado transiente, existiera una probabilidad positiva de no ingresar a C ,

la distribución límite dependería del estado inicial (al partir de un estado en C , sabemos que el proceso permanece en esa clase).

En general, si uno puede garantizar la existencia de la distribución estacionaria (con algún elemento positivo), su obtención puede lograrse por la vía de resolver un sistema simple de ecuaciones lineales, tal como se plantea en la Proposición 3.6.

Proposición 3.6 (Sistema Lineal para la Distribución Estacionaria) *Si una Cadena de Markov tiene una distribución estacionaria π en que $\pi_j > 0$ para algún j , entonces π corresponde a la única solución del sistema:*

$$\pi^T = \pi^T P \quad (3.111)$$

$$\sum_i \pi_i = 1 \quad (3.112)$$

$$\pi_i \geq 0, \forall i. \quad (3.113)$$

Demostración:

Supongamos que la Cadena de Markov tiene s estados (un número finito). Entonces:

$$P_{ij}^{(n+1)} = \sum_{k=1}^s P_{ik}^{(n)} P_{kj}. \quad (3.114)$$

Tomando límites sobre n a ambos lados de la ecuación se obtiene:

$$\pi_j = \sum_{k=1}^s \pi_k P_{kj}, \quad (3.115)$$

que corresponde a la ecuación (3.111).

El caso en que el sistema tiene un número infinito de estados puede ser analizado en forma análoga, excepto que hay que tener un cierto cuidado al tomar los límites sobre sumas infinitas.

En cuanto a que la distribución estacionaria π es la única solución al sistema, supongamos que existiera otra solución $V \neq \pi$. Supongamos que tomamos como distribución inicial del proceso el vector V ; esto es $f^{(0)} = V$.

Entonces:

$$f^{(1)} = P^T f^{(0)} = P^T V, \quad (3.116)$$

o bien:

$$\left[f^{(1)}\right]^T = V^T P. \quad (3.117)$$

Pero $V^T P = V^T$, ya que V es solución del sistema. Luego $f^{(1)} = V$, y en general $f^{(n)} = V$. Por lo tanto $\lim_{n \rightarrow \infty} f^{(n)} = V$.

Pero sabemos que existe una distribución estacionaria π que es independiente de la distribución inicial y es única (los límites son únicos), por lo tanto $\pi = V$.

□


En el sistema de ecuaciones (3.111) hay tantas ecuaciones como variables. Es posible demostrar que siempre una ecuación de ese sistema es linealmente dependiente de las otras. Por ello necesitamos la ecuación (3.112) para resolver el sistema.

Ejemplo 3.7 Sea:

$$P = \begin{matrix} & \begin{matrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \end{matrix} & \left| \begin{array}{ccccccc} \frac{1}{2} & 0 & \frac{1}{2} & 0 & 0 & 0 & 0 \\ \frac{1}{3} & 0 & 0 & \frac{2}{3} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{3} & 0 & \frac{2}{3} & 0 & 0 \\ \frac{1}{4} & \frac{1}{4} & 0 & \frac{1}{4} & 0 & \frac{1}{4} & 0 \\ \frac{1}{3} & 0 & \frac{1}{3} & 0 & \frac{1}{3} & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \frac{1}{3} & \frac{2}{3} \\ 0 & 0 & 0 & 0 & 0 & \frac{2}{3} & \frac{1}{3} \end{array} \right| \end{matrix}. \quad (3.118)$$

Desarrollo:

El grafo de la matriz de transición P de la ecuación (3.118):



Las clases en este caso son; $C_1 = \{2, 4\}$, $C_2 = \{1, 3, 5\}$ y $C_3 = \{6, 7\}$. La clase C_1 es transiente aperiódica y las clases C_2 y C_3 son recurrentes positivas aperiódicas.

Utilizando las ecuaciones del sistema (3.53), se obtiene que:

$$F(2, 1) = F(2, 3) = F(2, 5) = \frac{5}{7}, \quad (3.119)$$

$$F(2, 6) = F(2, 7) = \frac{2}{7}. \quad (3.120)$$

Además:

$$F(4, 1) = F(4, 3) = F(4, 5) = \frac{4}{7}, \quad (3.121)$$

$$F(4, 6) = F(4, 7) = \frac{3}{7}. \quad (3.122)$$

Respecto al comportamiento del sistema en el largo plazo, observamos que:

$$\begin{aligned} \lim_{n \rightarrow \infty} P_{2,1}^{(n)} &= \frac{F(2,1)}{\mathbb{E}(T(1,1))} = \frac{5}{7\mathbb{E}(T(1,1))}, \\ \lim_{n \rightarrow \infty} P_{2,3}^{(n)} &= \frac{F(2,3)}{\mathbb{E}(T(3,3))} = \frac{5}{7\mathbb{E}(T(3,3))}, \\ \lim_{n \rightarrow \infty} P_{2,5}^{(n)} &= \frac{F(2,5)}{\mathbb{E}(T(5,5))} = \frac{5}{7\mathbb{E}(T(5,5))}. \end{aligned} \quad (3.123)$$

Además:

$$\begin{aligned}\lim_{n \rightarrow \infty} P_{2,6}^{(n)} &= \frac{F(2,6)}{\mathbb{E}(T(6,6))} = \frac{2}{7\mathbb{E}(T(6,6))}, \\ \lim_{n \rightarrow \infty} P_{2,7}^{(n)} &= \frac{F(2,7)}{\mathbb{E}(T(7,7))} = \frac{2}{7\mathbb{E}(T(7,7))}.\end{aligned}\quad (3.124)$$

Por otra parte: $\lim_{n \rightarrow \infty} P_{2,2}^{(n)} = \lim_{n \rightarrow \infty} P_{2,4}^{(n)} = 0$.

De un modo análogo, podemos calcular las probabilidades límites cuando partimos del estado 4.

Ahora, si el sistema parte en alguno de los estados de la clase $C_2 = \{1, 3, 5\}$, permanece en esa clase para siempre (las clases recurrentes son cerradas). Por lo tanto, podemos analizar el comportamiento de esta sub-cadena formada por los estados 1, 3 y 5, utilizando como matriz de probabilidades de transición la submatriz P_I obtenida a partir de P escogiendo sólo las filas y columnas 1, 3 y 5. Es decir:

$$P_I = \begin{matrix} & \begin{matrix} 1 & 3 & 5 \end{matrix} \\ \begin{matrix} 1 \\ 3 \\ 5 \end{matrix} & \left| \begin{array}{ccc} \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & \frac{1}{3} & \frac{2}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \end{array} \right| \end{matrix}. \quad (3.125)$$

Esta sub-cadena es irreducible recurrente positiva aperiódica. Luego se pueden aplicar las Proposiciones 3.4 y 3.5 anteriores para concluir que existe un vector estacionario $\pi > 0$ que satisface:

$$\pi^T = \pi^T P_I, \quad (3.126)$$

en que $\pi^T = (\pi_1, \pi_3, \pi_5)$ y en que además se cumple: $\pi_1 + \pi_3 + \pi_5 = 1$ y $\pi_1, \pi_3, \pi_5 > 0$.

Resolviendo este sistema, podemos obtener valores de π_1 , π_3 y π_5 . Por otra parte, de la Proposición 3.1 obtenemos que:

$$\begin{aligned}\lim_{n \rightarrow \infty} P_{1,1}^{(n)} &= \frac{1}{\mathbb{E}(T(1,1))} = \pi_1, \\ \lim_{n \rightarrow \infty} P_{3,3}^{(n)} &= \frac{1}{\mathbb{E}(T(3,3))} = \pi_3, \\ \lim_{n \rightarrow \infty} P_{5,5}^{(n)} &= \frac{1}{\mathbb{E}(T(5,5))} = \pi_5.\end{aligned}\quad (3.127)$$

Luego, utilizando los valores π_1 , π_3 , π_5 podemos calcular $\mathbb{E}(T(1,1))$, $\mathbb{E}(T(3,3))$ y $\mathbb{E}(T(5,5))$, con lo que podemos obtener valores numéricos de los límites en las expresiones (3.123) y (3.124).

Un análisis semejante a este podemos efectuarlo para la clase $C_3 = \{6, 7\}$ de estados recurrentes positivos.

De todo el análisis anterior se deduce que en este ejemplo existen distribuciones límites, pero éstas dependen del estado inicial, por lo que no existe distribución estacionaria (por ejemplo, si el sistema parte en el estado 1, 3 ó 5, la probabilidad de que se encuentre en el estado 6 ó 7 en el futuro es 0; en cambio si parte de 6 ó 7 la probabilidad de estar en uno de estos estados en el largo plazo es positiva. Obsérvese que no es posible aplicar la Proposición 3.5 ya que existen **dos** clases recurrentes positivas).

La Figura 3.2 muestra gráficamente las convergencias de las distintas distribuciones en el largo plazo partiendo desde cada uno de los estados.




Figura 3.2: Gráfico de la distribución de convergencia donde se muestran las probabilidades partiendo del estado 1 al 7. Los segmentos muestran los estados de partida y los colores los estados de llegada.

◇

Pueden haber ceros en que el sistema (3.111), (3.112) y (3.113) tenga más de una solución (Por supuesto, no pueden ser ceros en que se cumplen los supuestos de la Proposición 3.6).


Consideremos el siguiente caso:

Ejemplo 3.8 (Caso con infinitas soluciones) *Imagine un caso con cuatro estados y la matriz de transición:*

$$P = \begin{array}{c|cccc} & 1 & 2 & 3 & 4 \\ \hline 1 & 0 & \frac{1}{2} & 0 & \frac{1}{2} \\ 2 & 0 & 0 & 1 & 0 \\ 3 & 0 & 1 & 0 & 0 \\ 4 & 0 & 0 & 0 & 1 \end{array}. \quad (3.128)$$

Desarrollo:

El grafo de la matriz de transición de (3.128), es:



Intentemos resolver el sistema (3.111):

$$\begin{aligned} \pi_1 &= 0 \\ \pi_2 &= \frac{1}{2}\pi_1 + \pi_3 \\ \pi_3 &= \pi_2 \\ \pi_4 &= \frac{1}{2}\pi_1 + \pi_4, \end{aligned} \quad (3.129)$$

desarrollando:

$$\begin{aligned} \pi_1 &= 0 \\ \pi_2 &= \pi_3 \\ \pi_3 &= \pi_2 \\ \pi_4 &= \pi_4. \end{aligned} \quad (3.130)$$

Las tres últimas ecuaciones de (3.130) no aportan ninguna información.

Utilizando la ecuación (3.112):

$$\pi_1 + \pi_2 + \pi_3 + \pi_4 = 1, \quad (3.131)$$

y la condición $\pi_1 = 0$ de (3.130), obtenemos en (3.131):

$$\begin{aligned} \pi_2 + \pi_2 + \pi_4 &= 1 \\ 2\pi_2 + \pi_4 &= 1. \end{aligned} \tag{3.132}$$

De (3.132) se deduce que hay infinitas soluciones para el sistema.

En este caso, existen tres distribuciones límites distintas:

1. Para el caso $X_0 = 1$, este se puede obtener por un procedimiento análogo al del ejemplo anterior.
2. Si $X_0 = 2$, $X_n = 3$ para todo $n > 1$, y luego $\pi_3 = 1$, $\pi_i = 0 \forall i \neq 3$.
3. Si $X_0 = 3$, el estado es del mismo tipo que el estado 2.
4. Por último si $X_0 = 4$, $X_n = 4$ para todo $n > 1$, y por lo tanto $\pi_4 = 1$, $\pi_i = 0 \forall i \neq 4$.

Todas estas distribuciones límites satisfacen el sistema lineal de ecuaciones descrito más arriba.

◇

Ejemplo 3.9 (Estados recurrentes nulos) *Considere un jugador que debe enfrentar una secuencia de apuestas. En cada una de ellas, con una cierta probabilidad gana una unidad monetaria y con otra probabilidad pierde todo su capital. Si el apostador lo pierde todo, con una probabilidad $1 - q_0$ le regalan una unidad monetaria, de modo de seguir jugando; con una probabilidad q_0 no le regalan esa unidad monetaria y el juego se acaba.*

Si al enfrentar una apuesta cualquiera, el capital del jugador corresponde a i unidades monetarias, con probabilidad q_i lo pierde todo y con probabilidad $1 - q_i$ gana una unidad adicional. Asuma que $q_i = \frac{1}{2+i}$.

Sea X_n el capital del jugador al momento de efectuar la apuesta n -ésima. Interesa analizar los tipos de estados de esta cadena.

Desarrollo:

La matriz P en este caso tiene la siguiente forma:

$$P = \begin{array}{c} \begin{array}{c} 0 \\ 1 \\ 2 \\ \vdots \end{array} \left| \begin{array}{cccccc} 0 & 1 & 2 & 3 & \dots \\ q_0 & 1 - q_0 & 0 & 0 & \dots & \dots \\ q_1 & 0 & 1 - q_1 & 0 & \dots & \dots \\ q_2 & 0 & 0 & 1 - q_2 & 0 & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots & \dots & \dots \end{array} \right. \end{array} \quad (3.133)$$

Es fácil observar que la cadena es irreducible, luego basta analizar un estado cualquiera. Consideremos el estado 0. Calculemos directamente la probabilidad $F(0,0)$ (en lugar de utilizar el sistema de ecuaciones (3.52) ó (3.53) anteriormente obtenido en esta Sección). Veamos todas las alternativas de retorno al estado 0:

N° de etapas	Trayectoria del retorno	Probabilidad asociada
1	$0 \rightarrow 0$	q_0
2	$0 \rightarrow 1 \rightarrow 0$	$(1 - q_0)q_1$
3	$0 \rightarrow 1 \rightarrow 2 \rightarrow 0$	$(1 - q_0)(1 - q_1)q_2$
$\vdots$	$\vdots$	$\vdots$
i	$0 \rightarrow 1 \dots \rightarrow i - 1 \rightarrow 0$	$\left(\prod_{j=0}^{i-2} (1 - q_j) \right) q_{i-1}$
$\vdots$	$\vdots$	$\vdots$

(3.134)

$F(0,0)$ corresponde a la suma de las probabilidades asociadas a todos los casos posibles; es decir, usando (3.134):

$$F(0,0) = q_0 + (1 - q_0)q_1 + (1 - q_0)(1 - q_1)q_2 + \dots \quad (3.135)$$

Reemplazando $q_i = \frac{1}{2+i}$ se obtiene en (3.135):

$$\begin{aligned} F(0,0) &= \frac{1}{2} + \frac{1}{2} \frac{1}{3} + \frac{1}{2} \frac{1}{3} \frac{1}{4} + \frac{1}{2} \frac{1}{3} \frac{1}{4} \frac{1}{5} \dots \\ &= \frac{1}{2} + \frac{1}{6} + \frac{1}{12} + \frac{1}{20} + \dots \end{aligned} \quad (3.136)$$

Es posible demostrar que esta suma es convergente e igual a 1. Luego el estado 0 (y por lo tanto todos los estados) son recurrentes.

Obtengamos el tiempo esperado de retornos. Éste es simplemente:

$$\begin{aligned} \mathbb{E}(T(0,0)) &= 1 - q_0 + 2(1 - q_0)q_1 + 3(1 - q_0)(1 - q_1)q_2 + \dots \\ &= \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5} + \dots \end{aligned} \quad (3.137)$$

3.3. ANÁLISIS DE MEDIDAS DE DESEMPEÑO EN EL LARGO PLAZO; VARIABLES DE ESTADO

Ésta es la conocida serie telescópica, que sabemos que diverge. Por lo tanto $E(T(0,0)) = \infty$, y los estados son recurrentes nulos.

◇

3.3 Análisis de Medidas de Desempeño en el Largo Plazo; Variables de Estado Multidimensionales

Consideremos de nuevo el modelo de inventario con política (s, S) (Ejemplo 3.1). En este caso, X_n representaba el número de ítems en inventario al principio del día n . Es fácil comprobar que en esta Cadena de Markov existe una sola clase de estados recurrentes positivos aperiódicos (están todos conectados), por lo que existe una sola distribución estacionaria π .

Analicemos los costos diarios de operación de este inventario en el largo plazo. Supongamos que existe un costo A asociado a poner una orden de reposición, un costo unitario h por unidad diaria mantenida en inventario, y un costo C por cada unidad de demanda perdida. Los costos incurridos en el largo plazo serán:

1. **Costo de reposición:** si asumimos que la demanda diaria es siempre positiva (i.e. $a_0 = 0$), entonces sabemos que cada vez que el estado del sistema es S , se ha producido una reposición (al final del día anterior). Luego, el costo esperado de reposición es $\pi_S A$.

Otra manera de obtener este costo es la siguiente: si al principio del día n el inventario es X_n , al final del día se pondrá una orden si la demanda Y_n durante el día es mayor que $X_n - s$. Luego, en el largo plazo, el costo esperado es:

$$C_R = A \sum_{i=s}^S \pi_i P(Y_n > i - s) = A \sum_{i=s}^S \pi_i \left(\sum_{k=i-s+1}^{\infty} a_k \right). \quad (3.138)$$

(Nótese que este método también puede usarse para el caso en que $a_0 > 0$).

2. **Costo de mantener inventario:** Si I_n el inventario al final del día n , entonces:

$$I_n = \begin{cases} X_n - Y_n & \text{si } X_n - Y_n \geq 0 \\ 0 & \text{si } X_n - Y_n < 0 \end{cases} \quad (3.139)$$

Una manera de estimar este costo es considerar el inventario promedio durante el día, esto es:

$$Z_n = \frac{X_n + I_n}{2}. \quad (3.140)$$

Luego, el costo esperado corresponde a:

$$h\mathbb{E}(Z_n) = h \left(\frac{\mathbb{E}(X_n) + \mathbb{E}(I_n)}{2} \right). \quad (3.141)$$

En el largo plazo, se tiene que:

$$\mathbb{E}(X_n) = \sum_{i=s}^S i\pi_i. \quad (3.142)$$

$$\mathbb{E}(I_n) = \sum_{i=s}^S \pi_i \mathbb{E}(I_n | X_n = i) = \sum_{i=s}^S \pi_i \left(\sum_{k=0}^i (i-k)a_k \right). \quad (3.143)$$

El costo esperado del inventario es entonces:

$$C_I = \frac{h}{2} \left(\sum_{i=s}^S i\pi_i + \sum_{i=s}^S \pi_i \left(\sum_{k=0}^i (i-k)a_k \right) \right). \quad (3.144)$$

3. **Costo de demanda perdida:** Si D_n es la demanda perdida durante el día n , entonces:

$$D_n = \begin{cases} Y_n - X_n & \text{si } Y_n - X_n \geq 0 \\ 0 & \text{si } Y_n - X_n < 0 \end{cases} \quad (3.145)$$

Luego, en el largo plazo, se tiene que el costo de demanda perdida es:

$$\begin{aligned} C_{DP} &= C\mathbb{E}(D_n) \\ &= C \sum_{i=s}^S \pi_i \mathbb{E}(D_n | X_n = i) \\ &= C \sum_{i=s}^S \pi_i \left(\sum_{k=i}^{\infty} (k-i)a_k \right). \end{aligned} \quad (3.146)$$

Por lo tanto, utilizando las expresiones (3.138), (3.144) y (3.146) se obtiene que el costo esperado diario de operación del inventario, en el largo plazo:

$$\begin{aligned} CE_I &= \sum_{i=s}^S \pi_i \left[A \left(\sum_{k=i-s+1}^{\infty} a_k \right) + \frac{h}{2}i + \frac{h}{2} \left(\sum_{k=0}^i (i-k)a_k \right) \right. \\ &\quad \left. + C \left(\sum_{k=i}^{\infty} (k-i)a_k \right) \right]. \end{aligned} \quad (3.147)$$

Evaluando esta expresión para distintos valores de s y S podemos encontrar los parámetros óptimos de esta política. (Obsérvese que al cambiar s y S , cambia la matriz P y los estados posibles del proceso, y por lo tanto, cambia el vector π).

Ejercicio 3.1 Encuentre el tamaño promedio, en el largo plazo, de una orden de reposición en el caso de demanda perdida y en el caso demanda pendiente.

Ejemplo 3.10 (Contratos de seguros para una flota de vehículos) Una empresa de transporte debe contratar un seguro para su flota de vehículos. Existen cuatro posible seguros con valores K_1 , K_2 , K_3 y K_4 , tales que:

$$K_1 > K_2 > K_3 > K_4. \quad (3.148)$$

El valor del seguro se paga a principio de año y depende del seguro contratado el año anterior, y de los accidentes cobrados (a la compañía de seguros) ese año. Si durante el año pasado, el seguro contratado costó K_i y no se cobraron daños, el seguro costará K_{i+1} ; en caso contrario (esto es, si se cobraron daños), el seguro costará K_1 . Si el año anterior el seguro costó K_4 y no hubo daños cobrados, el seguro este año costará también K_4 .

La empresa de transporte debe decidir, al final del año, si cobrará o no los daños acumulados por sus vehículos durante el año. Si la empresa decide cobrar los daños, la compañía de seguros se hace cargo de éstos, con excepción de un deducible r_i para el seguro K_i .

El monto monetario del daño total de la flota durante un año es un v.a. continua X con distribución $F(x)$ y densidad $f(x)$.

La empresa de transportes quiere usar la siguiente política: si el seguro contratado vale K_i , cobrar los daños al final del año si éstos son mayores que α_i , $i = 1, \dots, 4$. Estos α_i son parámetros de la política; interesa encontrar los valores óptimos de ellos.

Desarrollo:


Si definimos X_n como el tipo de seguro contratado durante el año n , entonces $\{X_n, n = 0, 1, 2, \dots\}$ es una Cadena de Markov discreta. Las probabilidades de transición en una etapa son:

$$\begin{aligned} P_{i,1} &= 1 - F(\alpha_i) & i = 1, 2, 3, 4. \\ P_{i,i+1} &= F(\alpha_i) & i = 1, 2, 3. \\ P_{4,4} &= F(\alpha_4) \end{aligned} \quad (3.149)$$

La matriz de transición, es:

$$P = \begin{bmatrix} 1 - F(\alpha_1) & F(\alpha_1) & 0 & 0 \\ 1 - F(\alpha_2) & 0 & F(\alpha_2) & 0 \\ 1 - F(\alpha_3) & 0 & 0 & F(\alpha_3) \\ 1 - F(\alpha_4) & 0 & 0 & F(\alpha_4) \end{bmatrix} \quad (3.150)$$

El grafo de la Cadena de Markov es:



Es fácil observar que esta cadena es irreducible, aperiódica recurrente positiva, y luego, para valores específicos de α_1 , α_2 , α_3 y α_4 , podemos encontrar la distribución estacionaria π .

Usando el sistema de ecuaciones (3.111), se obtiene que:

$$\begin{aligned} \pi_1 &= \frac{(1 - F(\alpha_4))}{(1 + F(\alpha_2) + F(\alpha_1)F(\alpha_2))(1 - F(\alpha_4)) + F(\alpha_3)F(\alpha_2)F(\alpha_1)}, \\ \pi_2 &= F(\alpha_1)\pi_1, \\ \pi_3 &= F(\alpha_2)F(\alpha_1)\pi_1, \\ \pi_4 &= \frac{F(\alpha_3)F(\alpha_2)F(\alpha_1)}{(1 - F(\alpha_4))}\pi_1. \end{aligned} \quad (3.151)$$

El valor de π_1 se obtiene de la condición de la ecuación (3.112).

Si en un año cualquiera en el largo plazo, estamos en el estado i , entonces el costo esperado para ese año es:

$$C(i) = K_i + \int_{x=0}^{\alpha_i} x f(x) dx + r_i \int_{x=\alpha_i}^{\infty} f(x) dx. \quad (3.152)$$

El segundo término corresponde al valor esperado de los daños, cuando éstos son inferiores a α_i (y por tanto deben ser pagados por la empresa de transportes); el tercer término corresponde al costo del deducible que la compañía debe pagar, cuando la compañía de seguros se hace cargo de los daños.

El costo esperado anual de la política es:

$$g(\alpha_1, \alpha_2, \alpha_3, \alpha_4) = \sum_{i=1}^4 \pi_i C(i). \quad (3.153)$$

Para obtener los parámetros, se puede optimizar la función que aparece en (3.153) respecto de $\alpha_1, \alpha_2, \alpha_3$ y α_4 .

◇

3.3.1 Variables de Estado Multidimensionales

En algunos casos, para especificar adecuadamente un proceso, es necesario utilizar más de una variable de estado. La propiedad markoviana puede seguir siendo válida en estas situaciones, con lo cual es posible utilizar todas las herramientas del modelo markoviano descrita en secciones anteriores.

Ejemplo 3.11 *Consideremos la siguiente extensión del sistema de inventario visto en el Ejemplo 3.1: $Y_1, Y_2, \dots, Y_n$ v.a. i.i.d. que representan las demandas por el ítem durante días sucesivos; las ordenes de reposición son de tamaño Q ; si el día n se pone una orden, ésta ingresará al sistema durante el día $n + m$ con probabilidad $q^{m-1}(1 - q)$, $m = 1, 2, \dots$ (es decir, existe un tiempo aleatorio desde que se coloca una orden hasta que ésta es recibida con los ítemes en la empresa). Sea I_n el número de ítemes de inventario al final del día n y O_n el número de órdenes de reposición solicitadas y aún no recibidas al final del día n . Para administrar este sistema se utiliza la siguiente política: al final del día n , se pone una nueva orden si:*

$$Y_n = I_n + QO_n \leq R, \quad (3.154)$$

en que R es un valor dado (un parámetro de la política). Y_n representa el inventario total que posee la empresa al final del día n ; de éste, I_n corresponde al inventario físico y QO_n a ítemes adquiridos pero aún no recibidos. Supongamos que el sistema opera con ventas perdidas. Analizaremos el costo diario de la política.

Desarrollo:

Para analizar el costo esperado de esta política, necesitamos definir como estado del sistema el vector X_n en que:

$$X_n = (I_n, O_n). \quad (3.155)$$

Observemos que el tiempo que demora en llegar una orden (O_n) tiene distribución geométrica (con falta de memoria); luego no es necesario conocer hace cuánto tiempo se puso cada una de las O_n órdenes (sólo es relevante conocer O_n).

La relación entre $X_{n+1} = (I_{n+1}, O_{n+1})$ y $X_n = (I_n, O_n)$ queda expresada en las siguientes ecuaciones:

$$I_{n+1} = \max \{I_n + Z_n Q - Y_n, 0\}, \quad (3.156)$$

$$O_{n+1} = \begin{cases} O_n - Z_n + 1 & \text{si } I_n + QO_n \leq R \\ O_n - Z_n & \text{si } I_n + QO_n > R, \end{cases} \quad (3.157)$$

en que Z_n es una v.a., con distribución binomial de parámetros (O_n, q) , que representa el número de órdenes, de entre las O_n pendientes al final del día n , que fueron recibidas durante el día $n + 1$. El parámetro q representa la probabilidad que durante el día $n + 1$ se reciba una orden que estaba pendiente al final del día n .

Las recurrencias anteriores permiten obtener una matriz de probabilidades de transición P , de un estado (i, j) a otro estado (k, l) .

Por ejemplo, si el estado inicial es (i, j) tal que $i + Qj > R$ entonces:

$$\mathbb{P}(O_{n+1} = r | I_n = i, O_n = j) = \binom{j}{r} (1 - q)^r q^{j-r}. \quad (3.158)$$

◇

3.4 Un Modelo de Programación Lineal de Optimización Markoviana

El modelo markoviano que formuláramos en el Ejemplo 3.1, para analizar la política de inventario (s, S) permite cuantificar diversas medidas de desempeño del sistema. Para ello es necesario especificar valores de los parámetros de la política. Para optimizar esta política deberíamos, en principio, formular el modelo

de Cadena de Markov para cada par de valores factibles de s y S , y posteriormente escoger aquéllos que resultaran más convenientes. Es obvio que este procedimiento puede ser muy engorroso.

En esta sección formularemos un modelo de optimización que considera simultáneamente todos los valores factibles de los parámetros y escoge automáticamente los valores óptimos.

Sea $\{X_n, n = 1, 2, \dots\}$ una Cadena de Markov discreta con un espacio de estados finito; supongamos que para cada estado del sistema existe un conjunto de acciones o decisiones posibles. Asumiremos que, para un estado determinado, estas acciones posibles son las mismas en cualquier etapa.

En cada etapa, el tomador de decisiones observa el estado i del sistema, y escoge una acción a (dentro de un conjunto A_i de acciones factibles definidas para ese estado). Después de ello, el sistema hace alguna transición a algún estado en la etapa siguiente. Sin embargo, ahora las probabilidades de transición dependen no sólo del estado actual, sino también de la acción escogida. De este modo, se definen las siguientes probabilidades de transición:

$$P_{ij}(a) = \mathbb{P}_{ij}(X_{n+1} = j | X_n = i, \text{ y se implementó la acción } a \text{ en la etapa } n). \quad (3.159)$$

Asumiremos que existe un beneficio neto por etapa $B(i, a)$ asociado a tomar la acción a cuando estamos en el estado i .

Por otra parte, al modelo le dejaremos abierta la posibilidad de no escoger siempre la misma acción, en un estado determinado; diremos que $P^{a,i}$ representa la probabilidad de escoger la acción a cuando estamos en el estado i . Nótese que esta probabilidad es desconocida para nosotros y constituye una variable de decisión del modelo. Si A_i corresponde al conjunto de acciones posibles asociadas al estado i , entonces obviamente debe cumplirse:

$$\sum_{a \in A_i} P^{a,i} = 1. \quad (3.160)$$

Nos interesa identificar las acciones (o más bien las probabilidades $P^{a,i}$) que maximicen los beneficios netos esperados por etapa en el largo plazo. Asumiremos que, para cualquier conjunto de decisiones, el proceso tiene una distribución estacionaria.

Si denominamos π a la distribución estacionaria, entonces el beneficio neto

esperado por etapa es:

$$\sum_i \sum_{a \in A_i} \pi_i P^{a,i} B(i, a), \quad (3.161)$$

ya que π representa la probabilidad de encontrarnos en el estado i en una etapa cualquiera, y $P^{a,i}$ es la probabilidad de que escogamos la acción a cuando estamos en ese estado. Sabemos que el vector π debe satisfacer las ecuaciones (3.111), (3.112) y (3.113):

$$\pi^T = \pi^T P \quad (3.162)$$

$$\sum_i \pi_i = 1 \quad (3.163)$$

$$\pi_i \geq 0, \forall i, \quad (3.164)$$

en que P es la matriz de probabilidades de transición del proceso, estas probabilidades son ahora más complejas, ya que las transiciones se ven influidas por las acciones. Específicamente, la probabilidad P_{ij} se obtiene como:

$$\begin{aligned} P_{ij} &= \mathbb{P}(X_{n+1} = j | X_n = i) \\ &= \sum_{a \in A_i} \mathbb{P}(X_{n+1} = j | X_n = i, \text{ y se escoge la acción } a \\ &\quad \text{en la etapa } n) \cdot \mathbb{P}(\text{tomar la acción } a \text{ en la etapa } n) \\ &= \sum_{a \in A_i} P_{ij}(a) P^{a,i}. \end{aligned} \quad (3.165)$$

Ahora bien, la ecuación i del sistema (3.162) corresponde a:

$$\begin{aligned} \pi_i &= \sum_j \pi_j P_{ji} \\ &= \sum_j \pi_j \sum_{a \in A_j} P_{ji}(a) P^{a,j}. \end{aligned} \quad (3.166)$$

Por lo tanto, nuestro modelo de optimización corresponde a:

$$\max \sum_i \sum_{a \in A_i} \pi_i P^{a,i} B(i, a) \quad (P)$$

s.a.

$$\pi_i = \sum_j \pi_j \sum_{a \in A_j} P_{ji}(a) P^{a,j} \quad \forall i \quad (3.167)$$

$$\sum_i \pi_i = 1 \quad (3.168)$$

$$\sum_{a \in A_i} P^{a,i} = 1 \quad \forall i \quad (3.169)$$

$$\pi_i \geq 0 \quad \forall i \quad (3.170)$$

$$P^{a,i} \geq 0 \quad \forall a \in A_i, \forall i. \quad (3.171)$$

Las variables del modelo son los π_i y las probabilidades $P^{a,i}$. Si observamos la estructura del modelo, vemos que estas variables aparecen multiplicadas en la función objetivo y en el primer conjunto de restricciones. Por lo tanto, el modelo es de optimización no lineal. Afortunadamente, es posible efectuar un cambio de variables de modo de transformarlo en un modelo estándar de Programación Lineal. Para ello, definimos la siguiente variable:

$$Z^{a,i} = \pi_i P^{a,i} = \text{Probabilidad de estar en } i \text{ y tomar la decisión } a. \quad (3.172)$$

Ahora bien:

$$\sum_{a \in A_i} Z^{a,i} = \pi_i \sum_{a \in A_i} P^{a,i} = \pi_i \cdot 1 = \pi_i. \quad (3.173)$$

Por lo tanto, las restricciones (3.167) pueden escribirse como:

$$\sum_{a \in A_i} Z^{a,i} = \sum_j \sum_{a \in A_j} \pi_j P_{ji}(a) P^{a,j} = \sum_j \sum_{a \in A_j} Z^{a,j} P_{ji}(a). \quad (3.174)$$

Por otra parte, usando la ecuación (3.173), podemos escribir la ecuación (3.168) de la siguiente manera:

$$\sum_i \sum_{a \in A_i} Z^{a,i} = 1. \quad (3.175)$$

Las variables de decisiones del modelo transformado son las $Z^{a,i}$. Por otra parte, es fácil demostrar que la restricción (3.169) del modelo (P) es innecesaria. De hecho, los valores $P^{a,i}$ se obtienen de la siguiente manera:

De la ecuación (3.172) obtenemos que:

$$P^{a,i} = \frac{Z^{a,i}}{\pi_i}. \quad (3.176)$$

Usando (3.173) en (3.176) se tiene que:

$$P^{a,i} = \frac{Z^{a,i}}{\sum_{a \in A_i} Z^{a,i}}, \quad (3.177)$$

de donde se desprende inmediatamente que:

$$\sum_{a \in A_i} P^{a,i} = \frac{\sum_{a \in A_i} Z^{a,i}}{\sum_{a \in A_i} Z^{a,i}} = 1. \quad (3.178)$$

Concluimos entonces que la forma final del modelo transformado es:

$$\max \sum_i \sum_{a \in A_i} Z^{a,i} B(i, a) \quad (ZP)$$

s.a.

$$\sum_{a \in A_i} Z^{a,i} = \sum_j \sum_{a \in A_j} Z^{a,j} P_{ji}(a) \quad \forall i \quad (3.179)$$

$$\sum_i \sum_{a \in A_i} Z^{a,i} = 1 \quad (3.180)$$

$$Z^{a,i} \geq 0 \quad \forall a \in A_i, \forall i. \quad (3.181)$$

Vemos que el modelo (ZP) es lineal en las variables $Z^{a,i}$. La solución óptima del modelo permitirá identificar las probabilidades óptimas $P^{a,i}$ asociadas a un cierto estado. Para implementar esta política óptima, se deberá hacer lo siguiente: después de cada transición del proceso, se observa el estado del sistema; si este estado es i , se escoge una acción a de acuerdo a las probabilidades óptimas $P^{a,i}$ (esto es equivalente a extraer el valor de una variable aleatoria con esa distribución).

Sin embargo, es posible demostrar que, en muchos casos, la estructura de la solución óptima es más simple.

Diremos que una política o conjunto de acciones es **determinística** si para cada estado, escoge con probabilidad 1, siempre la misma acción (en caso contrario, se dice que la política es **estocástica**). Es posible demostrar que, si para cualquier política determinística factible del sistema, la Cadena de Markov es irreducible (y por tanto, recurrente positiva, ya que el espacio de estados es finito), entonces, necesariamente existe una solución óptima al modelo (ZP) tal que, para cada estado i , $P^{a,i} = 1$ para algún a , y 0 para el resto (es decir, existe una política óptima determinística).

Por otra parte, existen situaciones en que es necesario incorporar restricciones adicionales al modelo (ZP); por ejemplo, en el modelo de inventario del Ejemplo 3.1, uno puede estar interesado en acotar la probabilidad que exista venta pendiente en un día cualquiera; usando la notación del modelo planteado en la Sección 3.3, esta probabilidad corresponde a:

$$\sum_{i=s}^S \pi_i \mathbb{P}(Y > i) = \sum_{i=s}^S \pi_i \sum_{k=i+1}^{\infty} a_k. \quad (3.182)$$

Si se desea que esta probabilidad sea menor que α , la restricción adicional sería entonces:

$$\sum_{i=s}^S \pi_i \sum_{k=i+1}^{\infty} a_k \sum_{a \in A_i} Z^{a,i} \leq \alpha. \quad (3.183)$$

En estos casos, no es posible asegurar una política óptima determinística.

Ejemplo 3.12 *Un canal de transmisión es utilizado para enviar señales de un punto a otro. El canal sólo puede transmitir una señal a la vez. Si la señal se transmite a una velocidad normal, el tiempo requerido para una transmisión es una constante; asuma que el horizonte de tiempo se divide en intervalos de largo igual a esa constante. Sin embargo, si se estima conveniente, el sistema puede hacerse operar a velocidad alta, con lo cual en un intervalo de tiempo se pueden transmitir dos señales. El número de señales que llega durante un intervalo cualquiera tiene distribución $q(k)$, $k \geq 1$. Las señales deben acumularse en un buffer de tamaño N . Las señales que al llegar encuentran lleno el buffer, se pierden.*

Existe un costo C_1 asociado a transmitir a velocidad normal y un costo C_2 asociado a transmitir en velocidad alta. Existe un costo h asociado a mantener un mensaje esperando en el buffer durante una unidad de tiempo.

Interesa formular un modelo que permita identificar las decisiones óptimas de modo de minimizar los costos esperados por unidad de tiempo, sujeto a la restricción que el número medio de señales que se pierden sea $\leq B$.

Desarrollo:

Sea X_n el número de señales en el buffer al final del intervalo n .

Asumimos que si $X_n = 0$, en el intervalo $n + 1$ no se transmiten señales, aunque éstas lleguen durante ese intervalo.

Sea a_n una acción que se toma al principio del intervalo n .

Los valores posibles para las acciones son:

- $a = 1$ se transmite una señal,
- $a = 2$ se transmiten dos señales,
- $a = 3$ no se hace nada.

Sea Z_n el número de señales recibidas durante el intervalo n .

Si $X_n = 0$, necesariamente $a_{n+1} = 3$ y luego $X_{n+1} = \min\{X_n + Z_{n+1}, N\}$.

Si $X_n = 1$, necesariamente $a_{n+1} = 3$ y luego $X_{n+1} = \min\{X_n + Z_{n+1} - 1, N\}$.

Si $X_n = i$, $1 < i \leq N$, entonces:

- si $a_{n+1} = 1$ $X_{n+1} = \min\{X_n + Z_{n+1} - 1, N\}$,
- si $a_{n+1} = 2$ $X_{n+1} = \min\{X_n + Z_{n+1} - 2, N\}$.

Luego las probabilidades de transición $P_{ij}(a)$ son:

- $i = 0$:

$$\begin{aligned} P_{0j}(3) &= \mathbb{P}(X_{n+1} = j | X_n = 0, a_n = 3) \\ &= \mathbb{P}(Z_{n+1} = j) = q(j) && \text{para } j < N. \\ &= \mathbb{P}(Z_{n+1} \geq N) = \sum_{k=N}^{\infty} q(k) && \text{para } j = N. \end{aligned}$$
- $i = 1$:

$$\begin{aligned} P_{1j}(1) &= \mathbb{P}(Z_{n+1} = j) = q(j) && \text{para } j < N, \\ &= \mathbb{P}(Z_{n+1} \geq N) = \sum_{k=N}^{\infty} q(k) && \text{para } j = N. \end{aligned}$$
- $1 < i \leq N$:

$$\begin{aligned}
P_{ij}(1) &= \mathbb{P}(X_{n+1} = j | X_n = i) = \\
&\quad \mathbb{P}(X_n + Z_{n+1} - 1 = j | X_n = i) \\
&= \mathbb{P}(Z_{n+1} = j - i + 1) = q(j - i + 2) \quad \text{para } j < N, \\
&\quad \text{en este caso debe cumplirse también} \\
&\quad \text{que } j - i + 1 \geq 1, \text{ es decir } j \geq i. \\
P_{iN}(1) &= \mathbb{P}(Z_{n+1} \leq N - i + 1) = \sum_{k=N-i+1}^{\infty} q(k) \quad \text{si } j = N. \\
P_{ij}(2) &= \mathbb{P}(Z_{n+1} = j - i + 2) = q(j - i + 2) \quad \text{para } j < N, \\
&\quad \text{en este caso debe cumplirse también} \\
&\quad \text{que } j - i + 2 \geq 1 \text{ o bien } j \geq i - 1. \\
P_{iN}(2) &= \mathbb{P}(Z_{n+1} = j - i + 2) = \sum_{k=N-i+2}^{\infty} q(k) \quad \text{para } j = N.
\end{aligned}$$

A continuación es necesario definir las variables y las restricciones estándares del modelo de Programación Lineal. En este ejercicio omitiremos estas definiciones. Lo que sí se hará es plantear la restricción adicional que el número medio de señales que se pierden por unidad de tiempo deben ser menor o igual a B .

Para ello observemos lo siguiente:

- Si $X_n = 0$ y $Z_{n+1} > N$ se pierden $Z_{n+1} - N$ señales.
- Si $X_n = 1$ y $Z_{n+1} > N$ se pierden $Z_{n+1} - N$ señales.
- Si $X_n = i > i$:
 - Si $a_{n+1} = 1$ y $i - 1 + Z_{n+1} > N$ se pierden $i - 1 + Z_{n+1} - N$ señales.
 - Si $a_{n+1} = 2$ y $i - 2 + Z_{n+1} > N$ se pierden $i - 2 + Z_{n+1} - N$ señales.

Luego, la restricción se representa de la siguiente manera:

$$\begin{aligned}
&\pi_0 \sum_{k=N}^{\infty} (k - N)q(k) + \pi_1 \sum_{k=N}^{\infty} (k - N)q(k) + \\
&+ \sum_{i=2}^N \pi_i \left(P^{1,i} \sum_{k=N-i+1}^{\infty} (i - 1 + k - N)q(k) + \right. \\
&\quad \left. P^{2,i} \sum_{k=N-i+2}^{\infty} (i - 2 + k - N)q(k) \right) \leq B. \tag{3.184}
\end{aligned}$$

Respecto a la función objetivo, ésta incluye los siguientes costos:

- **Costos de transmisión:**

$$\pi_1 c_1 + \sum_{i=2}^N \pi_i (P^{1,i} C_1 + P^{2,i} C_2). \quad (3.185)$$

- **Costos de mantención de inventario:**

Asumimos que el nivel promedio de inventario durante el período se obtiene como el promedio simple entre el inventario al final del período anterior y el inventario al final del período siguiente:

$$\begin{aligned} & \pi_0 \sum_{j=1}^N P_{0j}(3) \left(\frac{j}{2} \right) + \pi_1 \sum_{j=1}^N P_{1j}(1) \left(\frac{i+j}{2} \right) + \\ & \sum_{i=2}^N \pi_i (P^{1,i} P_{ij}(1) + P^{2,i} P_{ij}(2)) \left(\frac{i+j}{2} \right). \end{aligned} \quad (3.186)$$

Finalmente, sería necesario hacer la transformación de variables definidas anteriormente para obtener el modelo lineal respectivo.

◇

3.5 Ejercicios Resueltos

Ejercicio 3.1 Una máquina puede estar en tres estados posibles: funcionando bien, funcionando con defectos o fallada. El número de días que funciona bien tiene distribución $\mu^k(1-\mu)$, $k = 1, 2, \dots$. Cuando la máquina deja de funcionar bien, falla con probabilidad g y funciona con defectos con probabilidad $1-g$. El número de días que la máquina funciona con defectos tiene distribución $d^k(1-d)$, $k = 1, 2, \dots$ (después de lo cual falla). Cuando la máquina falla, se somete a una reparación que dura un tiempo con distribución $p^k(1-p)$, $k = 1, 2, \dots$. Una reparación produce una máquina que funciona bien con probabilidad ϕ y una máquina que funciona con defectos con probabilidad $1-\phi$.

Sea X_n el estado de la máquina al principio del día n . Obtenga la matriz de probabilidades de transición de la Cadena de Markov $\{X_n, n = 0, 1, 2, \dots\}$ (Asuma que el estado de la máquina permanece constante a lo largo del día; luego, si al principio funciona bien, seguirá funcionando bien durante el resto del día, pero podrá estar fallada o con defectos al principio del día siguiente).

Solución:

Lo primero es observar es que todos los tiempos mencionados tienen distribución geométrica, que es la equivalente discreta de la distribución exponencial, y como tal, tiene la propiedad de falta de memoria. Por ejemplo, sea T el tiempo que la máquina está funcionando bien al principio del día n , la probabilidad de que esté buena al principio del día $n + 1$ es:

$$\mathbb{P}(T \geq n + 1 | T \geq n) = \frac{\mathbb{P}(T \geq n + 1 \wedge T \geq n)}{\mathbb{P}(T \geq n)} = \frac{\mathbb{P}(T \geq n + 1)}{\mathbb{P}(T \geq n)}. \quad (3.187)$$

Ahora bien:

$$\mathbb{P}(T \geq n) = \sum_{k=n}^{\infty} \mu^{k-1}(1 - \mu) = \mu^{n-1}. \quad (3.188)$$

Luego, la probabilidad condicional anterior (3.187) vale:

$$\frac{\mu^n}{\mu^{n-1}} = \mu = \text{constante}. \quad (3.189)$$

Algo similar ocurre con los tiempos de funcionamiento defectuoso y con los tiempos de reparación.

Si definimos los estados posibles como 1 (funcionando bien), 2 (funcionando con defectos) y 3 (fallada), la matriz P está dada por (3.190).

$$P = \begin{array}{c|ccc} & 1 & 2 & 3 \\ \hline 1 & \mu & (1 - \mu)(1 - g) & (1 - \mu)g \\ 2 & 0 & d & 1 - d \\ 3 & \phi(1 - p) & (1 - \phi)(1 - p) & p \end{array}. \quad (3.190)$$

Ejercicio 3.2 Suponga que en el mercado de las AFP (Administradoras de Fondos de Pensiones) existen sólo dos de ellas: A_1 y A_2 . Sea N el número de afiliados atendidos por ambas AFP. La Superintendencia de las AFP está preocupada de que las cuentas individuales de los afiliados no siempre están al día. Por ello ha establecido un sistema de control basado en el siguiente proceso secuencial. Al final de cada mes, hace lo siguiente:

- Escoge un afiliado al azar (de entre los N disponibles).
- Si las AFP a la cual pertenece el afiliado escogido no tiene su cuenta al día, lo traspasa a la otra AFP. Si la cuenta está al día, lo deja donde estaba.

Suponga que la probabilidad de que un afiliado a A_1 tenga su cuenta al día es p_1 y que un afiliado a A_2 tenga su cuenta al día es p_2 . Si llamamos X_n el número de afiliados a la AFP A_2 al final del mes n , entonces $\{X_n, n \geq 0\}$ es una Cadena de Markov. Obtenga la matriz de probabilidades de transición en una etapa.

Solución:

Los valores posibles de X_n son: $0, 1, 2, \dots, N$. Supongamos que $X_n = i$. Las transiciones posibles a partir de ese estado son:

- $i \rightarrow i + 1$: si el afiliado es de A_1 y su cuenta no estaba al día. Luego:

$$P_{i,i+1} = \frac{N-i}{N}(1-p_1). \quad (3.191)$$

- $i \rightarrow i$: si el afiliado escogido es de A_1 y su cuenta estaba al día o bien el escogido es de A_2 y su cuenta estaba al día:

$$P_{i,i} = \frac{N-i}{N}(p_1) + \frac{i}{N}(p_2). \quad (3.192)$$

- $i \rightarrow i - 1$: si el afiliado escogido es de A_2 y su cuenta no está al día:

$$P_{i,i-1} = \frac{i}{N}(1-p_2). \quad (3.193)$$

Observe que $P_{i,i+1} + P_{i,i} + P_{i,i-1} = 1$.


Ejercicio 3.3 Considere una línea de producción que consiste en N máquinas en serie. El tiempo del proceso de la máquina i es constante y vale T_i . Sea T el tiempo de ciclo en la línea, esto es, el tiempo que demora el producto en salir terminado de la línea ($T = \sum_{i=1}^N T_i$). La materia prima requerida para producir este producto está disponible en cantidades ilimitadas y es utilizada como input de la máquina 1. Las N máquinas son operadas por un solo operario, de modo que sólo puede dedicarse a un solo proceso a la vez (el operario se va desplazando de una máquina a otra a medida que el producto avanza por la línea).

Al comienzo de cada ciclo se analiza el estado de cada máquina, la que se puede encontrar buena o fallada. Si existen una o más máquinas falladas, ese ciclo se pierde y esas T unidades de tiempo se utilizan en reparar las máquinas falladas. La probabilidad de que la máquina i se encuentre fallada al comienzo del

ciclo es P_i , $i = 1, 2, 3, \dots, N$ independientemente de si en el ciclo anterior estuvo funcionando o en reparación. Asuma que si al comienzo de un ciclo una máquina está funcionando, ésta no fallará durante el ciclo. Para aumentar la productividad de la línea de producción se desea estudiar la posibilidad de instalar una unidad de almacenamiento intermedio (buffer) de capacidad M entre dos máquinas de la línea. Supongamos, por ejemplo, que el buffer se ubica entre la máquina i e $i + 1$; entonces si al comienzo del ciclo alguna de las primeras i máquinas está fallada, pero las $i + 1, i + 2, \dots, N$ están buenas y existe al menos un producto en el buffer, ese producto puede ser procesado con lo cual ese ciclo es exitoso (se obtiene el producto terminado). Por otra parte, si alguna de las $i + 1, i + 2, \dots, N$ está mala, pero las $1, 2, 3, \dots, i$ están buenas y existe capacidad disponible en el buffer, entonces las primeras i máquinas pueden procesar una unidad de materia prima para incorporar durante ese ciclo un producto al buffer (en este caso el ciclo no es exitoso, pero produce un aumento en la cantidad de productos almacenados en el buffer, los que pueden usarse en ciclos futuros para producir productos terminados). Interesa poder formular un modelo que permita determinar la posición óptima del buffer de modo de maximizar la productividad media de la línea.

Analice el proceso $\{X_n, n \geq 0\}$ es que X_n corresponde a la cantidad de productos en el buffer al comienzo del ciclo n . Suponga que el buffer se ubica entre la posición i e $i + 1$. Obtenga la matriz de probabilidades de transición del proceso.

Solución:



Sea X_n la cantidad de productos en el buffer al comienzo del ciclo n . Supongamos que $X_n = k$, $0 < k < M$. Las transiciones posibles son a los estados $k - 1$, k y $k + 1$.

Analicemos todos los eventos (relevantes) posibles que pueden darse:

Evento	Máquinas $1, 2, \dots, i$	Máquinas $i + 1, i + 2, \dots, N$
1	Todas buenas	Al menos una mala
2	Al menos una mala	Todas buenas
3	Todas buenas	Todas buenas
4	Al menos una mala	Al menos una mala.

Obsérvese que estos eventos son disjuntos entre sí y cubren todos los casos posibles. Veamos ahora las probabilidades de transición.

$$\begin{aligned} \mathbb{P}(X_{n+1} = k+1 | X_n = k) &= \mathbb{P}(\text{Evento 1}) = \\ (1-P_1)(1-P_2)\dots(1-P_i)[1-(1-P_{i+1})(1-P_{i+2})\dots(1-P_N)] &= \\ \prod_{j=1}^i (1-P_j)[1-\prod_{j=i+1}^N (1-P_j)]. \end{aligned} \quad (3.194)$$

$$\begin{aligned} \mathbb{P}(X_{n+1} = k | X_n = k) &= \mathbb{P}(\text{Evento 3} \cup \text{Evento 4}) = \\ \mathbb{P}(\text{Evento 3}) + \mathbb{P}(\text{Evento 4}) &= \\ (1-P_1)(1-P_2)\dots(1-P_N) + [1-(1-P_1)(1-P_2)\dots(1-P_i)] \cdot \\ [1-(1-P_{i+1})(1-P_{i+2})\dots(1-P_N)] &= \\ \prod_{j=1}^N (1-P_j) + \prod_{j=1}^i (1-P_j)[1-\prod_{j=i+1}^N (1-P_j)]. \end{aligned} \quad (3.195)$$

$$\begin{aligned} \mathbb{P}(X_{n+1} = k-1 | X_n = k) &= \mathbb{P}(\text{Evento 2}) = \\ [1-(1-P_1)(1-P_2)\dots(1-P_i)](1-P_{i+1})(1-P_{i+2})\dots(1-P_N) &= \\ (1-\prod_{j=1}^i (1-P_j))(\prod_{j=i+1}^N (1-P_j)). \end{aligned} \quad (3.196)$$

Verifique que la suma de las probabilidades de transición (3.194), (3.195) y (3.196) vale 1. Obtenga además las probabilidades de transición para los estados límites $X_n = 0$ y $X_n = M$.

Ahora bien, la productividad media de la línea equivale a la probabilidad, en el largo plazo, de producir un producto terminado durante un ciclo. Supongamos que existe una distribución estacionaria π para este sistema (para una posición específica del buffer). Entonces esta probabilidad corresponde a:

$$\begin{aligned}
\text{Probabilidad de} &= \sum_{k=1}^M \mathbb{P}(\text{producir un producto terminado} \\
\text{terminar un producto} &|X_\infty = k) \mathbb{P}(X_\infty = k) \\
\text{en un ciclo} & \\
&= \pi_0 \mathbb{P}(E_3) + \sum_{k=1}^M (\mathbb{P}(E_2) + \mathbb{P}(E_3)) \pi_k \\
&= \prod_{j=1}^N (1 - P_j) \pi_0 + \\
&\quad \sum_{k=1}^M \left(\left(1 - \prod_{j=1}^i (1 - P_j)\right) \left(\prod_{j=i+1}^N (1 - P_j)\right) + \right. \\
&\quad \quad \left. \prod_{j=1}^N (1 - P_j) \right) \pi_k \\
&= \prod_{j=1}^N (1 - P_j) \pi_0 + (1 - \pi_0) \prod_{j=i+1}^N (1 - P_j).
\end{aligned} \tag{3.197}$$

Obsérvese que el vector π se obtiene de $\pi^T = \pi^T P$ y, por lo tanto, depende de P , la que a su vez, depende de la posición del buffer (i.e. del índice i).

Ejercicio 3.4 Consideremos una versión más sofisticada del problema presentado en el Ejercicio 3.1. En este caso, la máquina está constituida por una componente eléctrica y una componente mecánica. La componente mecánica funciona en forma análoga al Ejercicio 3.1. La componente eléctrica funciona durante un tiempo con distribución $a^k(1 - a)$, $k = 1, 2, \dots$, después de lo cual falla. Asuma que ambas componentes son independientes. El tiempo de reparación, de cualquiera de las dos componentes tiene distribución $p^k(1 - p)$, $k = 1, 2, \dots$. En este caso, una reparación siempre produce una componente buena (es decir $\phi = 1$).

Se ha establecido que la máquina funciona bien si ambas componentes funcionan bien; funciona con defectos si la componente eléctrica funciona bien y la componente mecánica funciona con defectos; y el sistema falla si cualquiera de las 2 componentes está fallada. X_n representa el estado de la máquina al principio del día n .

Solución:

Un análisis detallado de la lógica como funciona el sistema, permite concluir que, aunque éste presente tres estados posibles, se requiere definir una Cadena de Markov Y_n con más estados (5 específicamente) (La razón de ello radica en la forma como está definido el estado defectuoso).

La definición de los estados es la siguiente:

Estado	Componente eléctrica	Componente mecánica
0	funciona bien	funciona bien
1	funciona bien	con defectos
2	funciona bien	fallada (en reparación)
3	fallada (en reparación)	funciona bien
4	fallada (en reparación)	con defectos
5	fallada (en reparación)	fallada (en reparación)

La primera fila de la matriz P es la siguiente:

$$\begin{aligned}
 P_{0,0} &= \mu a \\
 P_{0,1} &= (1 - \mu)(1 - g)a \\
 P_{0,2} &= (1 - \mu)ga \\
 P_{0,3} &= \mu(1 - a) \\
 P_{0,4} &= (1 - \mu)(1 - g)(1 - a) \\
 P_{0,5} &= (1 - \mu)g(1 - a).
 \end{aligned} \tag{3.198}$$

Como ejercicio, obtenga el resto de los elementos de la matriz P .

El estado 0 de la cadena $\{Y_n, n \geq 0\}$ corresponde al estado 0 de la máquina (funcionando bien); lo mismo ocurre para el estado 1; los estados 2, 3, 4 y 5 corresponden al estado 2 de la máquina (fallada).

Ejercicio 3.5 *Existen situaciones en que la definición de los valores posibles de la variable de estado X_n puede no ser trivial. Consideremos el siguiente del ámbito computacional:*

En un disco de acceso directo se desean usar pistas de igual longitud para almacenar registros de información. Suponga que la longitud de las pistas es 1. Los registros no pueden particionarse, debiendo almacenarse íntegramente en una pista. Las pistas se van llenando en forma secuencial. Sean $R_1, R_2, R_3, \dots$ los registros que deben guardarse y $L_1, L_2, \dots$ las pistas disponibles. El tamaño (longitud) de los registros no se conoce a priori y deben considerarse como variables aleatorias independientes e idénticamente distribuidas (v.a.i.i.d.).

El procedimiento que se utiliza para llenar las pistas no permite utilizar espacios sobrantes de pistas previas. Así, por ejemplo, si la última pista utilizada es la 10 y el próximo registro que debe grabarse no cabe en esa pista, se debe utilizar la pista 11, aun cuando exista espacio en la pista 3 como para acomodar el registro en cuestión.

Suponga que la distribución de probabilidades de R_i es:

$$R_i = \begin{cases} \frac{1}{2} & \text{con probabilidad } \frac{1}{3}, \\ \frac{2}{3} & \text{con probabilidad } \frac{2}{3}. \end{cases} \quad (3.199)$$

Sea X_n el espacio total ocupado en la última pista utilizada, después de guardar el registro número n . (Para evitar inconvenientes innecesarios asumiremos que el proceso parte en la etapa 1 después de haber almacenado el primer registro).

Solución:

Es posible argumentar que el proceso $\{X_n, n = 1, 2, \dots\}$ es una Cadena de Markov discreta (desarrolle la argumentación).

Los valores posibles de X_n son: $\frac{1}{2}$, $\frac{2}{3}$, 1 y la matriz P corresponde a:

$$P = \begin{matrix} & \begin{matrix} \frac{1}{2} & \frac{2}{3} & 1 \end{matrix} \\ \begin{matrix} \frac{1}{2} \\ \frac{2}{3} \\ 1 \end{matrix} & \begin{vmatrix} 0 & \frac{2}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{2}{3} & 0 \\ \frac{1}{3} & \frac{2}{3} & 0 \end{vmatrix} \end{matrix}. \quad (3.200)$$

Podemos notar que un modelo como éste nos puede servir para estimar la frecuencia con que pasamos a utilizar una nueva pista y, por lo tanto, el número promedio de registro por pista que somos capaces de almacenar.

En el largo plazo, podemos obtener la distribución estacionaria del proceso resolviendo el sistema lineal (3.111), (3.112) y (3.113). Al hacerlo, obtenemos en este caso que: $\pi_1 = \frac{1}{4}$, $\pi_2 = \frac{2}{3}$ y $\pi_3 = \frac{1}{12}$.

(Obsérvese que el valor de π_2 era totalmente previsible, ya que cada vez que se recibe un registro de largo $\frac{2}{3}$, es necesario utilizar una nueva pista, independiente del último valor de Z_n).

Ahora bien, la probabilidad de que debamos utilizar una nueva pista para grabar un registro cualquiera en el largo plazo es:

$$\pi_1 P(R_1 = \frac{2}{3}) + \pi_2 + \pi_3 = \frac{11}{12}. \quad (3.201)$$

Luego, en promedio, podemos grabar $\frac{12}{11} = 1.1$ registros por pista.

Supongamos ahora que la distribución de probabilidades de R_i es:

$$R_i = \begin{cases} \frac{1}{3} & \text{con probabilidad 0.35,} \\ \frac{1}{2} & \text{con probabilidad 0.45,} \\ \frac{2}{3} & \text{con probabilidad 0.2.} \end{cases} \quad (3.202)$$

Los valores posibles de Z_n son ahora: $\frac{1}{3}$, $\frac{1}{2}$, $\frac{2}{3}$, $\frac{5}{6}$ y 1.

(Obtenga la matriz P en este caso). Vemos que a medida que aumenta el número de valores posibles de R_i , crece el número de valores posible de la variable de estado.

Ejercicio 3.6 (Duelos Markovianos) *Supongamos que existen dos enemigos A y B que se enfrentan (por ejemplo, dos tanques de países enemigos). Ambos cuentan con un abastecimiento ilimitado de municiones. El atacante A dispara municiones cada intervalos fijos de tiempo de largo a y el atacante B lo hace cada intervalos fijos de largo b .*

Después de cada disparo, el atacante A puede estar en m estados posibles $E_1, E_2, \dots, E_m$; existe además un estado inicial E_0 . Similarmente, el atacante A puede estar en n estados $F_1, F_2, \dots, F_n$ (su estado inicial es F_0).

En este caso, supongamos $n = m = 6$ estados posibles. Consideremos en particular el atacante A . Como resultado de un disparo, el atacante puede: golpear el contrincante y destruirlo, golpearlo pero no destruirlo, no golpearlo pero adquirir alguna información respecto de donde cayó el disparo en relación a su objetivo (ello le permitirá en principio corregir su próximo disparo y aumentar sus probabilidades del éxito), y finalmente no golpearlo ni adquirir información respecto del lugar en que cargó el disparo. Por lo tanto, existen cuatro resultados posibles.

Las transiciones entre estados dependen del resultado del disparo actual, pero también de cierta información de los disparos anteriores. Por ello, es necesario definir un número de estados mayor que 4. Después de un análisis cuidadoso de las leyes del combate, se ha concluido que los siguientes 6 estados son apropiados para describir la dinámica del proceso; esto es, el estado después del k -ésimo ataque de A :

<i>Estado</i>		<i>Descripción</i>
E_1	=	A logra golpear y destruir a B .
E_2	=	A logra golpear a B pero no destruirlo.
E_3	=	A no logra golpear a B , pero le ha pegado a B en un disparo anterior (sin destruirlo), y además ha logrado información de donde cayó su último disparo (en parte, esta información se logra en base al golpe anterior de A a B).
E_4	=	A no logra golpear a B , pero le ha pegado a B anteriormente, pero no logra obtener información de donde cayó el disparo.
E_5	=	A no logra golpear a B , no le ha pegado a B anteriormente, pero obtiene información de donde cayó el último disparo.
E_6	=	A no golpea a B , no le ha pegado a B previamente, ni tampoco obtuvo información del lugar donde cayó el último disparo.

Un ejemplo de la matriz P asociada a estos estados es la siguiente:

$$P = \begin{matrix} & \begin{matrix} E_0 & E_1 & E_2 & E_3 & E_4 & E_5 & E_6 \end{matrix} \\ \begin{matrix} E_0 \\ E_1 \\ E_2 \\ E_3 \\ E_4 \\ E_5 \\ E_6 \end{matrix} & \begin{vmatrix} 0 & 0.15 & 0.15 & 0 & 0 & 0.42 & 0.28 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.49 & 0.21 & 0.18 & 0.12 & 0 & 0 \\ 0 & 0.35 & 0.15 & 0.30 & 0.20 & 0 & 0 \\ 0 & 0.07 & 0.03 & 0.54 & 0.36 & 0 & 0 \\ 0 & 0.25 & 0.25 & 0 & 0 & 0.30 & 0.20 \\ 0 & 0.05 & 0.05 & 0 & 0 & 0.54 & 0.36 \end{vmatrix} \end{matrix} \quad (3.203)$$

De un modo análogo podemos definir la matriz P para los ataques de B a A .

Nuestro modelo asumirá que la matriz de probabilidades de transición de un atacante es independiente del estado de su adversario.

Supongamos que nos interesa obtener la probabilidad de que A gane el duelo.

Solución:

Sea:

$$\begin{aligned}
 \alpha_r &= \text{probabilidad de que } A \text{ destruya a } B \\
 &\quad \text{en el disparo número } r \text{ asumiendo que } B \\
 &\quad \text{está pasivo durante ese tiempo (esto es, sin disparar).} \\
 &= \text{probabilidad de que } A \\
 &\quad \text{haya fallado en los primeros } r-1 \\
 &\quad \text{disparos y destruya a } B \text{ en el disparo número } r. \\
 &= \text{probabilidad de que } A \text{ haya efectuado } r-1 \\
 &\quad \text{transiciones entre los estados (transientes) } E_1, \\
 &\quad E_2, \dots, E_m \text{ y la transición } r \text{ sea el estado } E_1. \\
 &= \sum_{j=2}^m P_{0j}^{(r-1)} P_{j1}.
 \end{aligned} \tag{3.204}$$

De igual forma, podemos definir B_r como la probabilidad de que B destruya a A en el disparo número r , asumiendo que A está pasivo.

Ahora sea:

$$\begin{aligned}
 \mathcal{P}(A, r) &= \text{probabilidad de que } A \text{ destruya a } B \\
 &\quad \text{en el disparo número } r \text{ asumiendo que } B \\
 &\quad \text{está activo (devolviendo fuego).} \\
 &= \text{probabilidad de que } A \\
 &\quad \text{esté vivo al momento del disparo número } r \\
 &\quad \text{y que con ese disparo destruya a } B.
 \end{aligned} \tag{3.205}$$

Ahora bien, hasta el disparo r de A han transcurrido $r \cdot a$ unidades de tiempo y en ese lapso B ha disparado:

$$s = \left\lceil \frac{ra}{b} \right\rceil \text{ veces.} \tag{3.206}$$

La probabilidad de que A esté vivo después de s disparos es:

$$1 - \sum_{j=1}^s B_j, \tag{3.207}$$

y por lo tanto:

$$\mathcal{P}(A, r) = \alpha_r \left(1 - \sum_{j=1}^s B_j \right). \tag{3.208}$$

Finalmente, la probabilidad de que A gane el duelo es:

$$\mathbb{P}(A) = \sum_{r=1}^{\infty} \mathbb{P}(A, r). \quad (3.209)$$

Ejercicio 3.7 Una institución dedicada al fomento del turismo está interesada en estudiar la forma como los automovilistas usan diariamente un parque de estacionamiento en un cierto lugar de recreo.

Suponga que cada día ha sido dividido en intervalos de tiempo de largo fijo ($\frac{1}{2}$ hora, por ejemplo). El proceso de llegada de autos en un intervalo corresponde a un Proceso de Poisson a tasa de λ autos por intervalo.

Un auto que está presente en el parque al principio del intervalo k y que llegó durante los primeros $k - 1$ intervalos, con probabilidad α abandona el parque durante el intervalo k (esta probabilidad es independiente del intervalo específico, dentro de los primeros $k - 1$, en que llegó el auto). Un auto que llega durante el intervalo k , con probabilidad β abandona el parque durante el intervalo k . Asuma que cada automovilista se comporta de forma independiente de los demás y que el parque tiene capacidad infinita.

Encuentre la matriz de probabilidades de transición del proceso que cuenta el número de autos relacionados en el parque al final de cada intervalo.

Solución:

Sea ΔT el largo del intervalo de tiempo escogido para el análisis y sea X_n el número de autos estacionados en el parque al final del intervalo n . Para desarrollar la solución, usaremos en varias oportunidades la distribución binomial. Para simplificar las ecuaciones, utilizaremos la siguiente convención: supongamos que Y es una variable con distribución binomial de parámetros (n, p) ; entonces:

$$B(n, p, k) = \mathbb{P}(Y = k) = \binom{n}{k} p^k (1 - p)^{n-k}. \quad (3.210)$$

Calculemos ahora P_{ij} para el caso $0 < i < j$:

$$\begin{aligned} P_{ij} &= \mathbb{P}(X_{n+1} = j | X_n = i) \\ &= \sum_{m=0}^{\infty} \mathbb{P}(X_{n+1} = j | X_n = i \wedge N(\Delta T) = m) \mathbb{P}(N(\Delta T) = m) \end{aligned} \quad (3.211)$$

en que $N(t)$ es el Proceso de Poisson asociado a la llegada de los automóviles.

Ahora bien, si había i autos al comienzo del intervalo, llegaron m y quedan j , entonces deben irse $i + m - j$ autos en total, obtenidos entre los que ya estaban en el parque al comienzo del intervalo n y los que llegaron durante ese intervalo (vemos que m debe cumplir la condición $m \leq j - 1$). Supongamos que k de éstos se obtienen de los que ya estaban y $i + m - j - k$ de los que llegaron durante el intervalo. Entonces:

$$\begin{aligned} \mathbb{P}(X_{n+1} = j | X_n = i \wedge N(\Delta T) = m) &= \\ \sum_{k=0}^{i+m-j} B(i, \alpha, k) B(m, \beta, i + m - j - k). \end{aligned} \quad (3.212)$$

Finalmente, P_{ij} se obtiene como:

$$P_{ij} = \sum_{m=j-i}^{\infty} \mathbb{P}(X_{n+1} = j | X_n = i \wedge N(\Delta T) = m) \frac{(\lambda \Delta T)^m e^{-\lambda \Delta T}}{m!}. \quad (3.213)$$

(Como ejercicio obtenga las probabilidades de transición de los demás casos posibles).

Formule ahora el mismo problema suponiendo que el tiempo que un auto cualquiera permanece en el parque tiene una distribución geométrica de parámetro p .

3.6 Extensiones y Referencias

La primera aplicación abordada aquí en el Capítulo 3, referida a la evolución estocástica de una enfermedad infecciosa, ha sido extensamente tratada en la literatura. Los modelos utilizados en la práctica son bastante más sofisticados que los que aquí comentamos, como los de la ecuación (3.1). Dos excelentes referencias generales sobre modelos estocásticos en epidemiología son los textos de (Bailey, 1975) y (Anderson, 1982).

El autor ha desarrollado aplicaciones de este tipo de modelos al análisis de la fiebre tifoidea y del HIV. En (Gazmuri et al., 1987) se plantea un modelo dinámico para analizar la primera enfermedad mencionada, en la Región Metropolitana. En (Gazmuri and Álvarez, 1987) se plantea una estrategia de agregación de este modelo y la aplicación de herramientas de programación dinámica para la selección óptima de estrategias de control de la enfermedad.

Alfaro (1993) contiene el detalle de un modelo de simulación estocástica, de estructura markoviana, para analizar la evolución del HIV en Chile.

Respecto de los textos de consulta para estudiar más detalles de Cadenas de Markov discretas, recomendamos los de (Bhat and Miller, 2002), (Cinlar, 2013), (Ross, 2013) y (Heyman and Sobel, 1982).

El modelo de programación lineal formulado en la Sección 3.4 es una de las posibles aproximaciones de optimización para procesos de Markov. Para el caso de un horizonte de decisiones de extensión finita, es posible desarrollar modelos de programación dinámica estocástica. Un texto clásico respecto de estos modelos es el de citepDerman1972.

Un aspecto no abordado en este Capítulo es el referente a métodos eficientes de cálculo numérico para obtener la distribución estacionaria π . En el caso que el número de estados del sistema sea moderado, se pueden usar los métodos tradicionales de eliminación gaussiana (Duff et al., 1989). Sin embargo, para sistemas con un gran número de estados, estos métodos resultan poco eficientes. En estos casos, resulta más efectivo el uso de métodos iterativos; entre éstos, los más efectivos son los de agregación-desagregación y los métodos proyectivos. En el primer caso, se explota el hecho que, habitualmente, los estados de una Cadena de Markov pueden ser particionados en clases de estados en las cuales hay una fuerte interacción entre los estados de una misma clase, y una interacción débil entre estados de clases distintas. De este modo, los estados del sistema pueden ser ordenados de manera que la matriz P de probabilidades de transición tenga una estructura cuasi-block-diagonal, en la que existen pocos elementos fuera de los bloques de la diagonal que son distintos de cero. Los métodos obtienen vectores π independientes para cada clase de estados y luego, definen procedimientos para construir a partir de ellos una aproximación al vector de toda la cadena.

Los métodos proyectivos se basan en una serie de aproximaciones sucesivas, en que, en cada aproximación, se busca la solución a un sistema de ecuaciones definido en un sub-espacio, de menor dimensión, del sistema original. A partir de estas soluciones parciales, se obtiene la solución al sistema original.

Una revisión exhaustiva de los métodos iterativos que han resultado más efectivos aparecen en la referencia (Philippe et al., 1992).

3.7 Problemas Propuestos

Ejercicio Propuesto 3.1 *3 bolitas blancas y 3 bolitas negras se distribuyen en 2 urnas de modo que cada una contiene 3 bolitas. Decimos que el sistema está en el estado i ($i = 0, 1, 2, 3$) si la primera urna contiene i bolitas blancas. En cada*

etapa, sacamos una bolita de cada urna y ponemos la bolita sacada de la primera urna, en la segunda, y recíprocamente.

Sea X_n el estado del sistema después de la etapa n . Explique por qué el proceso X_n , $n = 0, 1, 2, \dots$ es una Cadena de Markov.

- a) Calcule las probabilidades de transición en una etapa.
- b) Suponga que se han realizado un gran número de intercambios de bolitas. ¿Cuál es la probabilidad de que la primera urna contenga las tres bolitas blancas? ¿Depende esta probabilidad de la distribución inicial de las bolitas?

Ejercicio Propuesto 3.2 Considere un ratón ubicado en un tablero con nueve compartimentos dispuestos como en (3.214).

1	2	3
4	5	6
7	8	9

(3.214)

El ratón se mueve de un compartimento a otro en forma aleatoria (por ejemplo: si tiene k compartimentos contiguos, escoge uno de ellos con probabilidad $\frac{1}{k}$). Sea X_n el número del compartimento en que se encuentra el ratón después de la movida número n . Obtenga la matriz de probabilidades de transición.

Ejercicio Propuesto 3.3 Considere una Cadena de Markov con estados 1, 2 y 3 y con matriz de probabilidades de transición (3.215) en una etapa.

$$P = \begin{vmatrix} 0 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 0 & 1 \end{vmatrix} \quad (3.215)$$

La matriz P^n puede escribirse en este caso como:

$$P^n = 1.26^n \begin{vmatrix} 0.08 & 0.08 & 0.44 \\ 0.08 & 0.08 & 0.44 \\ 0.14 & 0.14 & 0.74 \end{vmatrix} + 0.5^n \begin{vmatrix} -0.50 & 0.50 & 0.00 \\ 0.50 & -0.50 & 0.00 \\ 0.00 & 0.00 & 0.00 \end{vmatrix} + 0.4^n \begin{vmatrix} 0.37 & 0.37 & -0.14 \\ 0.37 & 0.37 & -0.14 \\ -0.44 & -0.44 & 0.16 \end{vmatrix} \quad (3.216)$$

- a) Suponga que inicialmente el sistema tiene igual probabilidad de estar en cualquiera de los tres estados. ¿Cuál es la probabilidad de que en la etapa 5 el estado del sistema sea 3?

- b) ¿Qué sucede con la distribución del proceso en el largo plazo?
- c) Se sabe que el sistema en la etapa 5 estuvo en el estado 1 y en la etapa 7 también estuvo en el estado 1. ¿Cuál es la probabilidad de que en la etapa 11 el sistema esté en el estado 3?

Ejercicio Propuesto 3.4 Determine las clases de cada una de las siguientes Cadenas de Markov y determine si los estados son transientes o recurrentes:

$$A = \begin{vmatrix} 0 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & 0 & \frac{1}{2} \\ \frac{1}{2} & 0 & \frac{1}{2} \end{vmatrix} \quad (3.217)$$

$$B = \begin{vmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \end{vmatrix} \quad (3.218)$$

$$C = \begin{vmatrix} \frac{1}{2} & 0 & \frac{1}{2} & 0 & 0 \\ \frac{1}{4} & \frac{1}{2} & \frac{1}{4} & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} \\ 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} \end{vmatrix} \quad (3.219)$$

$$D = \begin{vmatrix} \frac{1}{3} & \frac{2}{3} & 0 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & \frac{1}{3} & \frac{2}{3} & 0 \\ 1 & 0 & 0 & 0 & 0 \end{vmatrix} \quad (3.220)$$

Ejercicio Propuesto 3.5 Suponga Juan y Pedro tienen 2 monedas cada uno. Se disponen a enfrentar un juego en que, en cada oportunidad, cada jugador lanza una de sus monedas. Si ambas coinciden, gana Juan y se queda con la moneda de Pedro. En caso contrario, gana Pedro. El juego termina cuando uno de los jugadores gana las 4 monedas.

- a) Obtenga la distribución de probabilidades del número de jugadas necesarias hasta que Juan logre tener 3 monedas por primera vez.
- b) Explique cómo obtendría la distribución de probabilidades del número de jugadas hasta que el juego termina.

Ejercicio Propuesto 3.6 Suponga que las ventas semanales de un cierto producto pueden ser descritas como una Cadena de Markov discreta. Suponga que estas ventas oscilan entre 2 y 8 unidades. La matriz de probabilidades de transición es (3.221).

$$\begin{array}{c|cccccccc}
 & 2 & 3 & 4 & 5 & 6 & 7 & 8 \\
 \hline
 2 & 0.6 & 0.4 & 0 & 0 & 0 & 0 & 0 \\
 3 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\
 4 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\
 5 & 0 & 0 & 0.8 & 0.2 & 0 & 0 & 0 \\
 6 & 0 & 0 & 0 & 0 & 0.4 & 0.6 & 0 \\
 7 & 0.5 & 0 & 0.3 & 0 & 0 & 0 & 0.2 \\
 8 & 0 & 0.4 & 0 & 0 & 0.6 & 0 & 0
 \end{array} \quad (3.221)$$

- a) ¿Existe la distribución límite? ¿Distribución estacionaria? Justifique.
- b) Suponga que las ventas semanales pueden clasificarse en Bajas (2, 3), Medias (4, 5) o Altas (6, 7, 8), y suponga que durante la primera semana se vendieron seis unidades. ¿Cuáles son las probabilidades, en el largo plazo, de que las ventas en una semana cualquiera sean Bajas, Medias, o Altas?
- c) ¿Cuánto tiempo transcurre, en promedio, entre dos semanas con ventas iguales a dos unidades? ¿Cuál es la distribución de probabilidades en ese tiempo?

Ejercicio Propuesto 3.7 Considere una Cadena de Markov con la matriz de probabilidades de transición de (3.222).

$$\begin{array}{c|ccccccc}
 & 1 & 2 & 3 & 4 & 5 & 6 & 7 \\
 \hline
 1 & \frac{1}{2} & 0 & \frac{1}{2} & 0 & 0 & 0 & 0 \\
 2 & \frac{1}{3} & 0 & 0 & \frac{2}{3} & 0 & 0 & 0 \\
 3 & 0 & 0 & \frac{1}{3} & 0 & \frac{2}{3} & 0 & 0 \\
 4 & \frac{1}{4} & \frac{1}{4} & 0 & \frac{1}{4} & 0 & \frac{1}{4} & 0 \\
 5 & \frac{1}{3} & 0 & \frac{1}{3} & 0 & \frac{1}{3} & 0 & 0 \\
 6 & 0 & 0 & 0 & 0 & 0 & \frac{1}{3} & \frac{2}{3} \\
 7 & 0 & 0 & 0 & 0 & 0 & \frac{2}{3} & \frac{1}{3}
 \end{array} \quad (3.222)$$

- a) Calcule $F(2, j)$ y $F(4, j)$; $j = 1, 3, 5, 6, 7$.
- b) Calcule $\lim_{n \rightarrow \infty} f^{(n)}$. ¿Depende de $f^{(0)}$?

Ejercicio Propuesto 3.8 Considere una Cadena de Markov con la matriz de probabilidades de transición de (3.223).

$$P = \begin{pmatrix} 0.8 & 0 & 0 & 0 & 0 & 0.2 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0.1 & 0 & 0.9 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.5 & 0 & 0 & 0.5 \\ 0 & 0.3 & 0 & 0 & 0.7 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0.5 & 0 & 0 & 0 & 0.5 & 0 \end{pmatrix} \quad (3.223)$$

- Determine las clases de estado y clasifique los estados en transientes, recurrentes nulos o positivos y determine si son aperiódicos o periódicos (y el período).
- Analice el problema de existencia de una distribución límite.
- ¿Cuál es la probabilidad de que, si el sistema parte en el estado 7, se llegue al estado 6 alguna vez? ¿Cuál es la probabilidad de que si parte en el estado 7 llegue alguna vez al estado 5?
- Suponga que el sistema parte en el estado 1. ¿Cuánto tiempo (etapas) toma en promedio retornar al estado 1?
- Suponga que el sistema parte en el estado 2. Obtenga la expresión para el tiempo promedio que le toma ingresar al estado 5 por primera vez.
- ¿Tiene este sistema distribución estacionaria? Justifique.
- Obtenga $F(6, 1)$ y $F(6, 3)$.
- Suponga que $\mathbb{P}(X_0 = 4) = \frac{1}{3}$, $\mathbb{P}(X_0 = 7) = \frac{2}{3}$. ¿Existe en este caso distribución límite? Si su respuesta es afirmativa, encuéntrala.

Ejercicio Propuesto 3.9 En un Estado socialista hay un economista matemático que está muy interesado en estudiar el siguiente mecanismo de redistribución del capital entre los habitantes. Cada habitante es visitado diariamente por un inspector del Ministerio. Si él descubre que su capital neto es cero, entonces con probabilidad $P_i > 0$ le entrega i unidades monetarias ($i = 1, 2, 3, \dots$). Por el contrario, si el inspector lo encuentra con un capital positivo j , se lo quita (para darlo, presumiblemente con probabilidad P_j a otro habitante que tiene capital cero).

Con este proceso, el economista asegura que, cualquiera sea la distribución inicial del capital, en el largo plazo, se obtendrá una distribución equitativa del capital diario para cada habitante. ¿Ud. qué opina?

Ejercicio Propuesto 3.10 *La Corporación de Educación Municipal de una cierta comuna está encargada de la gestión educacional de 100 colegios de enseñanza básica a su cargo. Esta corporación debe escoger una política de asignación de sus recursos a actividades de supervisión y apoyo pedagógico a los colegios. Para evaluar la efectividad de sus políticas, cuenta con los resultados del Sistema Integrado de Medición de la Calidad de la Educación (SIMCE) que anualmente aplica el Ministerio de Educación. Este programa mide, a través de la aplicación de una batería de pruebas, el grado de logro de los objetivos de los programas oficiales de estudio en los distintos niveles de la Educación Básica. En base a este programa es posible obtener un promedio de logro de objetivos a nivel de todo el colegio en todas las asignaturas evaluadas. Este promedio es un porcentaje que varía entre 0 y 100%. Suponga que el resultado obtenido por un colegio en el SIMCE puede clasificarse en cuatro categorías: Malo ($< 30\%$), Regular (entre 30 y 50%), Bueno (entre 50 y 70%) y Excelente (sobre 70%). Suponga que los resultados obtenidos por un colegio en el SIMCE del próximo año dependen sólo de los resultados del SIMCE obtenidos este año y de la supervisión que el colegio reciba de la Corporación Municipal. Si los colegios no reciben ninguna supervisión, sus resultados en el próximo año quedarán definidos por las matriz de probabilidades de transición de (3.224).*

<i>Este año</i>	<i>Próximo año</i>			
	<i>M</i>	<i>R</i>	<i>B</i>	<i>E</i>
<i>M</i>	0.6	0.3	0.1	0.0
<i>R</i>	0.3	0.4	0.2	0.1
<i>B</i>	0.1	0.3	0.4	0.2
<i>E</i>	0.1	0.2	0.4	0.3

(3.224)

Los porcentajes de colegios que obtuvieron resultados en el SIMCE de este año en cada una de las categorías, son los siguientes: *M* (30%), *R* (45%), *B* (12%) y *E* (13%).

La Corporación municipal dispone de \$70,000,000 para gastar en supervisión. El costo de dar supervisión a un colegio que obtuvo resultados malos en el SIMCE de este año es de \$3,000,000; para los otros colegios el costo es de \$2,000,000 por colegio.

Se desea determinar una política de asignación de los recursos de supervisión en la que se especifique el porcentaje de colegios de cada categoría que recibirá supervisión (una vez que estos porcentajes están determinados, los colegios específicos que reciben supervisión se escogen al azar dentro de cada categoría).

Si los colegios reciben supervisión, sus resultados en el SIMCE del próximo

año se determinarán por las probabilidades de (3.225).

Este año	Próximo año			
	M	R	B	E
M	0.4	0.5	0.1	0.0
R	0.2	0.4	0.3	0.1
B	0.1	0.3	0.3	0.3
E	0.0	0.3	0.3	0.4

(3.225)

- a) Formule un modelo que permita obtener la política que maximiza el número de colegios con resultados R o B en el SIMCE del próximo año. ¿Cómo cambia su modelo si se desea minimizar el número de colegios con resultados M el próximo año?
- b) Suponga que se desea escoger una política para ser utilizada todos los años dentro de un horizonte de tiempo largo. Formule un modelo que permita minimizar el número de colegios con resultados M o R en un año cualquiera en el largo plazo.

Ejercicio Propuesto 3.11 Una empresa debe decidir el tamaño de su aviso de publicidad en la edición dominical del diario EL Mercurio. Hay dos alternativas: un aviso pequeño (que cuesta \$100,000) y un aviso grande (que cuesta \$300,000). Las ventas semanales de la empresa pueden clasificarse en tres categorías: Altas, Medias o Bajas. El ingreso neto promedio en cada caso (sin considerar los costos de publicidad) es de \$1,000,000, \$800,000 y \$500,000, respectivamente.

Se sabe que las ventas de una semana dependen de las ventas de la semana anterior y del tamaño del aviso, en función de las probabilidades de (3.226).

Ventas semana pasada	Aviso Pequeño			Aviso Grande		
	Ventas esta semana			Ventas esta semana		
	A	N	B	A	N	B
A	0.2	0.5	0.3	0.6	0.3	0.1
N	0.1	0.5	0.4	0.4	0.5	0.1
B	0.1	0.3	0.6	0.2	0.7	0.1

(3.226)

Suponga que se desea analizar la siguiente política: si las ventas durante la semana pasada fueron bajas, publicar un aviso grande. Sea X_n el nivel de ventas en la semana n bajo esta política. ¿Es $\{X_n, n = 0, 1, 2, \dots\}$ una Cadena de Markov?. En caso afirmativo, obtenga la matriz P .

Formule ahora un modelo que permita escoger la política que maximice los beneficios netos de la empresa en el largo plazo.

Ejercicio Propuesto 3.12 *Considere de nuevo el sistema de producción en serie con buffer intermedio analizado en el Ejercicio Resuelto 3.3. Suponga que la línea de producción consta de 5 máquinas en serie y se dispone de un buffer de capacidad 4. Sea P_i la probabilidad de que la máquina i falle durante un ciclo. Suponga que:*

$$P_1 = 0.2 \quad P_2 = 0.1 \quad P_3 = 0.2 \quad P_4 = 0.2 \quad P_5 = 0.4.$$

Identifique la posición del buffer que permite maximizar, en el largo plazo, la probabilidad de producir un producto terminado durante un ciclo.

Ejercicio Propuesto 3.13 *Considere un cultivo que contiene inicialmente un solo glóbulo rojo. Después de una cantidad de tiempo el glóbulo rojo muere y es reemplazado por dos nuevos glóbulos rojos o bien por dos glóbulos blancos. Las probabilidades de estos eventos son $\frac{1}{4}$ y $\frac{3}{4}$ respectivamente. Subsecuentemente, cada glóbulo rojo se reproduce de la misma forma. Por otra parte, cada glóbulo blanco muere después de una unidad de tiempo sin reproducirse. Se desea calcular la probabilidad de que el cultivo se extinga en algún momento. Formule para tal efecto un modelo detallado e indique con precisión cómo lo utilizaría para obtener la probabilidad pedida.*

Ejercicio Propuesto 3.14 *Considere un sistema de atención al que llegan personas de acuerdo a un Proceso de Poisson a tasa λ . Los tiempos de atención de las personas en la caja son v.a.i.i.d con distribución de probabilidades F (continua). Suponga que observamos el proceso cada vez que sale un cliente del sistema. Sea X_n = Número de personas en el sistema a la salida del cliente n . ¿Es $\{X_n, n = 1, 2, 3, \dots\}$ una Cadena de Markov? ¿Qué sucede si observamos el sistema a la llegada de cada cliente?*

Suponga ahora que las personas llegan de acuerdo a un proceso de renovación en que los tiempos entre llegadas tienen distribución F , y que los tiempos de atención son v.a.i.i.d. con distribución exponencial a tasa λ . ¿Qué puede decir en este caso?

Ejercicio Propuesto 3.15 *La empresa CAR-RENTAL se dedica a arrendar autos para uso diario y tiene una oficina en Santiago y otra en Viña del Mar. Una de las secciones de la empresa está orientada exclusivamente a arrendar autos para*

viajes entre ambas ciudades. En este sentido, una persona que arrienda un auto en Santiago, y lo utiliza para viajar a Viña del Mar, debe devolverlo en la oficina de la empresa en esa ciudad. Similarmente, una persona que arrienda un auto en Viña del Mar lo devuelve en Santiago. Un auto que se arrienda hoy debe ser devuelto antes de las 8 A.M. del día siguiente.

Los clientes llegan diariamente a partir de las 8 A.M. a arrendar autos. Se sabe que el número de clientes que llega a la oficina de Santiago cada día es una v.a. con distribución de Poisson con media α . En Viña del Mar, el número de clientes que llega a arrendar autos tiene distribución de Poisson con media β .

Esta sección de la empresa tiene un total de N autos. Al principio de cada semana, éstos deben ser asignados de alguna manera a ambas oficinas. De ahí en adelante, la ubicación de estos autos al principio de cada día dependerá de los traslados entre ciudades que realicen los mismos usuarios (y por lo tanto, queda fuera del control de la empresa). Se desea formular un modelo que le permita a la empresa distribuir de manera óptima los autos entre las dos oficinas al principio de cada semana, de modo de minimizar el número esperado de clientes que se queda sin arrendar auto durante la semana. (Considere una semana de seis días hábiles).

Indique cómo podría utilizar un modelo de Cadena de Markov para estos efectos. Especifique la matriz de transición del modelo.

Ejercicio Propuesto 3.16 Considere un canal de comunicación que es compartido para transmitir señales de voz y señales de datos. El canal sólo puede transmitir un señal a la vez, el tiempo se divide en intervalos de largo igual al tiempo de transmisión. La transmisión de una señal sólo puede iniciarse al principio de un intervalo. En cada intervalo, las señales llegan de acuerdo a un proceso general de llegada en que $P(i_1, i_2)$ representa la probabilidad conjunta de que lleguen i_1 señales de voz e i_2 señales de datos. Las llegadas en intervalos sucesivos son independientes entre sí.

Las señales de voz y de datos deben esperar en un buffer de tamaños respectivos N_1 y N_2 . Una señal que al llegar encuentre lleno el buffer, se pierde.

El problema es cómo asignar las señales de voz y de datos al canal de comunicación; interesa que el largo promedio de la cola de señales de voz se mantenga bajo de modo que la conversación que representan estas señales no se transforme en algo incoherente. Se desea buscar una regla de asignación que minimice, en el largo plazo, el largo promedio de la cola de señales de datos, sujeto a la restricción que el largo promedio de la cola de señales de voz sea menor o igual a B .

Formule este problema como un modelo de optimización markoviana.

Ejercicio Propuesto 3.17 *Una unidad de disco de un computador va a ser llenada con cuatro grandes conjuntos de información: A, B, C y D. Se ha hecho un experimento obteniéndose los datos de (3.227).*

$F(i, j)$	A	B	C	D
A	130	50	0	100
B	160	50	40	45
C	60	0	40	50
D	55	70	80	70

(3.227)

donde $F(i, j)$ representa el número de veces, de un total de 1,000 observaciones, en que dos requerimientos sucesivos de información correspondieron a los conjuntos (i, j) .

El problema consiste en asignar óptimamente los conjuntos de información a las pistas (concéntricas) del disco (se asigna un solo conjunto de información por pista). Para ello, interesa minimizar el valor esperado del costo por requerimiento en el largo plazo. Asuma que el costo de un requerimiento es directamente proporcional a la distancia de la pista respectiva a la pista en la que se hizo el requerimiento anterior (esto es, donde se encuentra el cabezal del brazo lector). Un requerimiento hecho sobre la misma pista tiene costo 0.

- a) Encuentre la matriz de probabilidades de transición de los ordenamientos A, B, C y D y B, A, D, C, y obtenga en cada caso el costo esperado por requerimientos en el largo plazo.
- b) Suponga que Ud. quiere encontrar el ordenamiento óptimo. ¿Cómo lo haría? ¿Puede formularse este problema como el modelo de optimización markoviana discutido en la Sección 3.4?

Ejercicio Propuesto 3.18 *En un campus universitario existe un sistema interno de correo en el que un funcionario va recorriendo distintas oficinas, en las cuales retira y recibe correspondencia. Al inicio de la operación, el funcionario recorre en un cierto orden todas las oficinas y recoge la correspondencia que debe ser despachada. Al final del recorrido, el funcionario ordena la correspondencia e inicia un segundo ciclo en el que recorre las oficinas, entregando la correspondencia previa y recolectando la nueva, y así sucesivamente. Suponga que las oficinas están uniformemente distribuidas a lo largo del recorrido y que cada una genera al azar correspondencia para ser despachada, de modo que el total de correspondencia*

generada por el sistema en un intervalo de largo t corresponde a un Proceso de Poisson a la tasa λ .

El tiempo que le toma a un operario ordenar una carta es constante e igual a S , y el tiempo que le toma hacer todo el recorrido es también constante e igual a C .

Sea X_k el número de cartas que ha ordenado el funcionario al final del ciclo k . Desarrolle los argumentos para demostrar que $\{X_n, n = 1, 2, 3, \dots\}$ es una Cadena de Markov discreta. Obtenga la matriz P .

Ejercicio Propuesto 3.19 Sea X_n la posición de un caminante aleatorio que se mueve sobre una recta numerada. Las probabilidades de transición se calculan de acuerdo con (3.228).

$$\begin{aligned} P_{i,i+1} &= p, & P_{i,i-1} &= q & i &= 1, 2, \dots \\ P_{0,0} &= q, & P_{0,1} &= p & \text{en que } p + q &= 1. \end{aligned} \quad (3.228)$$

Demuestre que si $p > q$, la Cadena de Markov es irreductible aperiódica positiva.

Ejercicio Propuesto 3.20 Los árboles frutales tienen un rendimiento que es creciente en una primera etapa de su vida, y que luego comienza a decrecer. Por otra parte, estos árboles pueden morir antes que cumplan su edad máxima. Suponga que la edad máxima de un árbol es N años. Sea $P_{k,k+1}$ la probabilidad de que un árbol que está vivo al principio del año k , esté vivo al principio del año $k+1$, y sea $P_{k,0}$ la probabilidad de que ese árbol fallezca durante el año k . En una política sin intervención, asuma que cuando muere un árbol, se reemplaza inmediatamente por uno nuevo de edad 0. Asuma que se desea analizar el comportamiento de una gran plantación de estos árboles en un predio. Al principio del horizonte de análisis existe una distribución de probabilidades conocida que representa las edades iniciales de los distintos árboles de la plantación.

Un árbol que al principio del año k está vivo y permanece vivo durante ese año, genera una utilidad neta U_k para el predio; análogamente, un árbol que está vivo al principio del año k pero fallece durante ese año genera una utilidad neta V_k ($V_k < U_k$).

a) Desarrolle un modelo que permita calcular la utilidad promedio de un árbol de la plantación durante el primer año del horizonte de análisis.

- b) *Desarrolle ahora las expresiones necesarias para calcular la utilidad promedio anual de un árbol en el largo plazo.*
- c) *Para evitar la etapa de rendimiento decreciente de un árbol, se puede aplicar una política de corte artificial (política de intervención). Suponga que el agricultor a cargo del predio ha decidido cortar un árbol cuando cumple una edad T ($T < N$). Desarrolle un modelo que permita estimar la utilidad promedio anual de un árbol, bajo esta política, en el largo plazo.*