



Introducción a IA e IA en las organizaciones

Curso: Sistemas de información

Escuela de Ingeniería

Historia y origen de la Inteligencia Artificial

El término "inteligencia artificial" fue acuñado por John McCarthy en 1955.

McCarthy fue un pionero en el campo de la inteligencia artificial y organizó la famosa Conferencia de Dartmouth en verano de 1956, junto con Marvin Minsky, Nathaniel Rochester y Claude Shannon, donde se sentaron las bases para el campo de estudio que ahora conocemos como inteligencia artificial.

La conferencia se llevó a cabo en el Dartmouth College en Hanover, New Hampshire, Estados Unidos. En esta conferencia, **McCarthy propuso el término "inteligencia artificial" para describir el campo de estudio dedicado a la creación de máquinas y programas capaces de realizar tareas que, si fueran realizadas por humanos, requerirían inteligencia.**

A.I. TIMELINE

1950

TURING TEST

Computer scientist Alan Turing proposes a test for machine intelligence. If a machine can trick humans into thinking it is human, then it has intelligence

1955

A.I. BORN

Term 'artificial intelligence' is coined by computer scientist, John McCarthy to describe "the science and engineering of making intelligent machines"

1961

UNIMATE

First industrial robot, Unimate, goes to work at GM replacing humans on the assembly line

1964

ELIZA

Pioneering chatbot developed by Joseph Weizenbaum at MIT holds conversations with humans

1966

SHAKY

The 'first electronic person' from Stanford, Shakey is a general-purpose mobile robot that reasons about its own actions

A.I. WINTER

Many false starts and dead-ends leave A.I. out in the cold

1997

DEEP BLUE

Deep Blue, a chess-playing computer from IBM defeats world chess champion Garry Kasparov

1998

KISMET

Cynthia Breazeal at MIT introduces Kismet, an emotionally intelligent robot insofar as it detects and responds to people's feelings



1999

AIBO

Sony launches first consumer robot pet dog AiBO (AI robot) with skills and personality that develop over time



2002

ROOMBA

First mass produced autonomous robotic vacuum cleaner from iRobot learns to navigate and clean homes



2011

SIRI

Apple integrates Siri, an intelligent virtual assistant with a voice interface, into the iPhone 4S



2011

WATSON

IBM's question answering computer Watson wins first place on popular \$1M prize television quiz show Jeopardy



2014

EUGENE


Eugene Goostman, a chatbot passes the Turing Test with a third of judges believing Eugene is human



2014

ALEXA

Amazon launches Alexa, an intelligent virtual assistant with a voice interface that completes shopping tasks



2016

TAY

Microsoft's chatbot Tay goes rogue on social media making inflammatory and offensive racist comments



2017

ALPHAGO

Google's A.I. AlphaGo beats world champion Ke Jie in the complex board game of Go, notable for its vast number (2^{170}) of possible positions


¿Y entre 2017 y hoy?



Table Of Contents


- 1 How We Selected the Best AI Tools
- 2 Best AI Tools for Productivity in 2025
- 3 AI Writing Tools
 - 3.1 1. Jasper
 - 3.2 2. Writesonic
 - 3.3 3. Scalenut
 - 3.4 4. HubSpot AI Email Writer
- 4 AI Website Chatbots
 - 4.1 5. Tidio
 - 4.2 6. Botsonic
 - 4.3 7. Chatbase
- 5 AI Grammar Tools
 - 5.1 8. Grammarly
 - 5.2 9. Quillbot
 - 5.3 10. Wordtune
- 6 AI and Plagiarism Detectors
 - 6.1 11. Originality.ai
 - 6.2 12. Winston AI

120 MIND-BLOWING AI TOOLS




Principios fundamentales de la Inteligencia Artificial

AI Does Not Revolve Around GenAI




Source: Gartner
© 2024 Gartner, Inc. and/or its affiliates. All rights reserved. 2937191


Gartner



Aprendizaje: Proceso en la creación y entrenamiento del **modelo**



Tipos de algoritmos de aprendizaje supervisado



Regresión lineal


- La regresión lineal es un método estadístico que nos permite entender la relación entre dos variables.
- En su forma más sencilla, involucra dos variables: una independiente (o predictora) y una dependiente (o de respuesta).
- La idea básica es que la variable dependiente (y) puede ser expresada como una suma de los productos de las variables independientes (x) y sus correspondientes coeficientes (b), más un término de error (e).

Regresión lineal




$$y = w_0 + w_1x$$

Bias Coefficient / weight



$$y = w_0 + w_1x_1 + w_2x_2 + \dots + w_px_p$$



Regresión lineal


- Esto se puede expresar con la siguiente ecuación:

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n + e$$


b_0 es el término constante o intercepto, b_1 a b_n son los coeficientes de las variables independientes, y e es el error o residuo.

- El objetivo en la regresión lineal es encontrar los valores de los coeficientes que minimizan el error total (la diferencia entre los valores predichos por el modelo y los valores reales).

Problemas al clasificar con regresión lineal




$$\sigma(z) = \frac{1}{1 + e^{-z}}$$




El modelo versus “realidad”

Underfitting vs. Overfitting

Underfitting
Model is too simple



Good Fit
Model fits well,
with some error



Overfitting
Model is too
complex






Image source: Scikit Learn documentation


Subajuste y sobreajuste



Underfitted





Good Fit/Robust



Overfitted

Machine learning – Deep Learning




Regresión lineal en ML y clasificadores

- En Machine Learning, la regresión lineal es una herramienta para predecir valores continuos. *Por ejemplo, podríamos usar la regresión lineal para predecir el precio de una casa en función de su tamaño y ubicación.*
- También puede usarse para tareas de **clasificación**. En este caso, la variable de salida es categórica (categoría) no continua. Un algoritmo popular que usa la regresión lineal para la clasificación es la *Regresión Logística* (técnica de análisis de datos orientada a encontrar las relaciones entre dos factores de datos).

Machine Learning


- Aprendizaje a partir de datos en lugar de instrucciones programadas.
- Conceptos importantes:
 - Supervised Learning
 - Unsupervised Learning
 - Reinforcement Learning
 - Deep Learning



HOW TO CONFUSE MACHINE LEARNING




imgflip.com




Supervised Learning (SL)

- Es el entrenamiento de modelos con datos etiquetados (es decir, con respuestas conocidas) que luego predecirán comportamientos o resultados con datos reales.
- Se sustenta teóricamente en la inferencia estadística, y utiliza algoritmos de regresión y clasificación para encontrar patrones en los datos y hacer predicciones.



Classification




Regression

Unsupervised Learning


- El aprendizaje no supervisado son los modelos que aprenden de datos no etiquetados y descubren patrones ocultos sin intervención.
- Esta técnica se basa en métodos de agrupamiento y asociación para explorar y clasificar datos de manera autónoma.

Classification



Supervised learning


Clustering





Unsupervised learning

Unsupervised Learning

- Algoritmos Clave:
 - K-Means
 - Clustering Jerárquico
 - Density-Based Spatial Clustering of Applications with Noise(DBSCAN)
 - Algoritmos de Asociación (Apriori, Eclat)
- Aplicaciones




Regresión lineal en ML y clasificadores



Reinforced Learning (RL)


- El aprendizaje reforzado es un tipo de aprendizaje automático donde un agente aprende a comportarse en un entorno, al realizar ciertas acciones y observar las recompensas o penalidades de esas acciones.
- Algoritmos Clave: Q-Learning State-Action-Reward-State-Action (SARSA) Deep Deterministic Policy Gradient (DDPG)



Deep Learning (DL)

- Subcategoría de Machine Learning que se enfoca en el uso de Redes Neuronales Profundas.
- Inspirado por la estructura del cerebro humano y los principios de cómo aprenden las neuronas.
- No se trata de una categoría de aprendizaje sino una técnica que se puede aplicar en cada una de las categorías de aprendizaje: **supervisado, no supervisado y por refuerzo.**


Red neuronal



Perceptrón

- El perceptrón es el bloque de construcción más básico de una red neuronal. Es un algoritmo de aprendizaje supervisado de clasificadores binarios.
- Toma un vector de entrada, aplica una combinación lineal y luego aplica una función de activación para producir una salida. La salida puede ser 0 o 1, para clasificación binaria.
- El proceso de aprendizaje del perceptrón es ajustar los pesos de las entradas para mejorar la precisión de las predicciones.


Perceptrón



Red neuronal


- Una red neuronal es un modelo computacional inspirado en el cerebro humano. Está compuesto por una gran cantidad de neuronas (nodos) organizadas en capas.
- Cada neurona toma una serie de entradas, realiza una combinación lineal de ellas y luego aplica una función de activación a la salida.
- La “inteligencia” de la red proviene del aprendizaje de los mejores valores para los pesos y sesgos, utilizando técnicas como el Descenso del Gradiente.

Red neuronal



¿Cómo se relacionan?

- El Perceptrón es la unidad básica o neurona en una Red Neuronal.
- Las Redes Neuronales se construyen conectando múltiples perceptrones entre sí, creando capas de neuronas.
- El Descenso del Gradiente es el método de optimización que permite “entrenar” una Red Neuronal, es decir, aprender los pesos óptimos para los perceptrones en la red.




Estructura de una RN – Neuronas y Capas

Como vimos en la imagen anterior, una red neuronal (RN) se estructura de la siguiente forma:

- Múltiples capas de neuronas (perceptrones) conectadas. Se distribuyen de la siguiente forma:
 - Capa de entrada (Input layer)
 - Capa(s) oculta(s) (Hidden layers)
 - Capa de salida (Output layer)
- La cantidad de capas y neuronas en cada capa pueden afectar el rendimiento de la red. Por esto es fundamental entender bien el problema al que nos enfrentamos, para estimar (a priori) la estructura de nuestra red.

Parámetros de una red neuronal

- Los parámetros de una red neuronal son los pesos y sesgos (bias) asociados con cada neurona.
- La cantidad de parámetros puede afectar la capacidad de la red para modelar datos complejos.
- El cálculo del número total de parámetros depende del número de neuronas y sus conexiones.
- El cálculo del número total de parámetros total es una métrica importante y muy utilizada en el campo de la IA, ya que permite cuantificar la complejidad de una red.



Impacto de los parámetros en una RN

- La cantidad de parámetros de una red afecta su capacidad de aprendizaje.
- Más parámetros pueden permitir una mejor precisión, pero también pueden causar sobreajuste. Al contrario, muy pocos parámetros pueden causar un subajuste y un mal rendimiento.
- ¿Cómo determinar cual es la cantidad “correcta” de parámetros a estimar?

Elección de la cantidad de parámetros

1. El desafío de elegir la cantidad de parámetros.
2. Evitar el sobreajuste y el subajuste.
3. Consideraciones prácticas:
 1. Complejidad del modelo
 2. Capacidad de cómputo
 3. Cantidad de datos disponibles.


Cálculo de parámetros de una RN

- Veamos el ejemplo de una red con 784 entradas, dos capas ocultas de 16 neuronas y una salida de 10 neuronas.
 - El número de parámetros se calcula como la suma del número de pesos y sesgos.
 - El número de pesos es igual al número de conexiones entre las neuronas.
 - El número de sesgos es igual al número total de neuronas (excepto las de entrada).
- Con toda esta información es posible calcular el número total de parámetros.

- **Fórmula para el cálculo de parámetros por capa: $(N_i \times N_o) + N_o$, donde N_i es el número de entradas a una capa y N_o es el número de salidas (neuronas).**

Red Neuronal para resolver
la imagen de un dígito

784



Cálculo de parámetros de una RN

Para la capa de entrada, no se realiza ningún cálculo, ya que no recibe neuronas de entrada

1. Para la primera capa oculta (1), tenemos :

$$C_1 = (N_i \times N_o) + N_o = (784 \times 16) + 16 = 12.560$$

2. Para la segunda capa oculta (2):

$$C_2 = (N_i \times N_o) + N_o = (16 \times 16) + 16 = 272$$

3. Para la capa de salida (3):

$$C_3 = (N_i \times N_o) + N_o = (16 \times 10) + 10 = 170$$

4. Finalmente:

$$C = C_1 + C_2 + C_3 = 12.560 + 272 + 170 = 13.002$$

Cálculo de parámetros de una RN

- ¿Qué significa esto?


Si bien la red tiene 826 en neuronas, es posible modificar 13.002 parámetros diferentes para ajustar el modelo.

Taxonomías de la Inteligencia Artificial

Weak vs Strong AI


- Weak AI (IA Débil)
 - También conocida como IA estrecha.
 - Diseñada para realizar tareas específicas.
 - No comprende ni experimenta consciencia.
 - Ejemplos: Siri, Google Assistant, Alexa.
- Strong AI (IA Fuerte)
 - También conocida como IA general.
 - Puede entender, aprender, adaptarse y implementar la inteligencia en una amplia gama de tareas.
 - Teóricamente, tiene consciencia, sentimientos y deseos propios.
 - Aún no existe en la práctica.

Áreas de la Inteligencia Artificial



NLP : Natural Language Processing

LLM: Large Language Models



IA en las organizaciones

Inteligencia artificial

Sin datos NO hay IA

Hay que entender que BIG Data trata con **datos estructurados y datos no estructurados**

Por lo que vemos hay 3 V's:

Velocidad (mucho por segundo, pero mucho)

Variedad (muchas formas, todas las formas, estructurado y no estructurado)

Volumen (muchos datos)

Pero a lo tradicional, antes citado, agregamos 3 nuevas V's:


Variabilidad (la forma de generación varía, cambia y se expande)

Veracidad (Entre todos los datos, la cantidad de datos falsos se incrementa)



Valor (De todo lo generado, ¿todo tiene la misma valoración para la toma de decisiones?)

Big Data y las 3 V's


Se ha hablado de las 3 Vs del Big Data, veamos ahora sus dimensiones en expansión para comprender el fenómeno y cómo se relacionan



Working of HDFS




Esta es la arquitectura para una "ingesta" y su procesamiento desde BigData.
Sabían que algunos requerimientos, para plataformas, son de centenares de Gb de RAM?




Y no toda BigData es igual, se puede clasificar

Según su fuente, formato, tipo de almacenamiento, staging o procesamiento



AI para negocios (AI for business)

AI para negocios (AI for business)



Definición

Conjunto de aplicaciones y soluciones basadas en Inteligencia Artificial diseñadas específicamente para resolver problemas del entorno empresarial.

Estas tecnologías no solo promueven una mayor **eficiencia** y productividad, sino que también impulsan la competitividad de las organizaciones



Estrategia & Solución: AI for Business



Mejor Toma de Decisiones



Optimización de Procesos



Experiencia del Cliente Mejorada




Innovación en Productos y Servicios

IA para negocios (AI for business)




LAS EMPRESAS PUEDEN MEJORAR SIGNIFICATIVAMENTE LA **TOMA DE DECISIONES**. ANALIZANDO GRANDES VOLUMENES DE DATOS DE MANERA RÁPIDA Y PRECISA, LO QUE PERMITE EXTRAER CONOCIMIENTO (INSIGHTS) VALIOSOS Y GENERAR PREDICCIONES QUE GUÍEN LAS DECISIONES ESTRATÉGICAS Y OPERATIVAS.



ESTAS SOLUCIONES PERMITEN LA **OPTIMIZACIÓN DE PROCESOS**, RESULTANDO EN OPERACIONES MÁS ÁGILES, EFICIENTES, Y CON UNA REDUCCIÓN SIGNIFICATIVA EN LOS COSTOS OPERATIVOS.




OTRO BENEFICIO CLAVE ES LA **MEJORA EN LA EXPERIENCIA DEL CLIENTE**. LAS HERRAMIENTAS BASADAS EN IA PERMITEN PERSONALIZAR SERVICIOS Y PRODUCTOS, OFRECIENDO SOPORTE EFECTIVO Y RÁPIDO, LO QUE INCREMENTA LA SATISFACCIÓN Y LEALTAD DEL CLIENTE.




FINALMENTE, AI FOR BUSINESS **FOMENTA LA INNOVACIÓN EN PRODUCTOS Y SERVICIOS**, PERMITIENDO EL DESARROLLO DE NUEVAS OFERTAS Y MODELOS DE NEGOCIO RESPALDADOS POR CAPACIDADES AVANZADAS DE ANÁLISIS Y PROCESAMIENTO DE DATOS.

Y cuando decimos negocios, decimos *negocios*


Attractive Opportunities in the Artificial Intelligence Market



Source: Secondary Research, Expert Interviews, and MarketsandMarkets Analysis



Infraestructura para trabajo con datos





Toma de decisiones: *Spotify*

Utilizan algoritmos de **aprendizaje profundo**. Analizando patrones de escucha de usuarios, los algoritmos identifican preferencias y comportamientos específicos.

Este análisis se realiza mediante la consideración de múltiples variables: géneros musicales preferidos, duración de las sesiones de escucha, frecuencia de skips, entre otros. Estos datos procesados alimentan decisiones estratégicas, como lanzamientos de campañas de marketing y promociones específicas que responden a tendencias identificadas



Optimización de procesos: *FedEx*

Los **algoritmos de optimización** basados en IA son herramientas vitales. Estos algoritmos, diseñados para calcular rutas eficientes, consideran una serie de variables dinámicas en tiempo real. Desde condiciones de tráfico hasta patrones meteorológicos, cada factor se tiene en cuenta para determinar la ruta más rápida y segura, optimizando así las entregas y reduciendo tiempos

Experiencia del cliente: *American Express y Airbnb*



Con sistemas de **detección de fraude** impulsados por IA. Estos sistemas son complejos, utilizando técnicas avanzadas de análisis de anomalías y modelos de **clasificación predictiva** para evaluar transacciones y detectar comportamientos atípicos que podrían indicar fraude



Mediante **sistemas de recomendación** avanzados que utilizan filtrado colaborativo y técnicas de aprendizaje profundo para analizar preferencias de usuario, ofreciendo listados de propiedades que no solo coinciden con los criterios de búsqueda, sino que **anticipan** las expectativas del usuario

Innovación en Productos/Servicios: *Tesla e IBM WH*



Con vehículos equipados con tecnología IA avanzada. Utilizando **técnicas de percepción computacional y redes neuronales profundas**, los vehículos Tesla analizan datos de sensores en tiempo real para tomar decisiones autónomas de conducción, todo basado en el aprendizaje acumulativo de datos de conducción recopilados globalmente.




Mediante el uso de **procesamiento de lenguaje natural y algoritmos de aprendizaje automático**, Watson analiza registros médicos electrónicos, identificando patrones y correlaciones que facilitan diagnósticos precisos y permiten la administración de tratamientos más personalizados y efectivos.

Anexos

Historia y origen de la Inteligencia Artificial

Alan Turing | 1950 | Artículo "Computing Machinery and Intelligence"

"Una máquina puede ser considerada inteligente si su comportamiento es indistinguible del de un humano."
(El test de Turing) <https://www.techtarget.com/searchenterpriseai/definition/Turing-test>



Encontrar los valores óptimos de w

Definir la función de “costo” $J(w)$



Encontrar los valores de peso/coeficiente que minimicen la función de costo $J(w)$

moviéndonos pequeños intervalos (η)

Calcular la derivada (gradiente)

Igualar el conjunto gradiente a cero

Resolver los coeficientes usando el descenso gradiente




$$w_{t+1} = w_t - \eta * \nabla J(w_t)$$



Gradient Descent

- El Descenso del Gradiente es un **algoritmo de optimización** utilizado para **minimizar alguna función iterativamente**.
- En el contexto de las redes neuronales, el Descenso del Gradiente se utiliza para optimizar la **función de pérdida**, es decir, para encontrar los parámetros que reducen al mínimo la diferencia entre las predicciones del modelo y los valores reales.
- Básicamente, se trata de un método para moverse en la dirección de la pendiente más pronunciada de una función para encontrar su mínimo local.

Gradient Descent



Entrenamiento red neuronal



Complejidad, sesgo y varianza

Low bias



High bias




Low variance



High variance



● Target ● Predictions




Deep Learning (DL)

- Deep Learning en Supervised Learning: Redes Neuronales Convolucionales (CNN) para clasificación de imágenes.
- Deep Learning en Unsupervised Learning: Autoencoders para la reducción de dimensionalidad y la detección de anomalías.
- Deep Learning en Reinforcement Learning: Deep Q-Learning para aprender políticas eficientes en juegos y sistemas de control.

Deep Learning (DL)

- Una aplicación común del Deep Learning en el aprendizaje supervisado es la clasificación de imágenes. Las Redes Neuronales Convolucionales (CNN) se utilizan a menudo para este propósito. Por ejemplo, una CNN puede ser entrenada con imágenes de gatos y perros (datos de entrada) y sus correspondientes etiquetas ("gato" o "perro") para aprender a distinguir entre imágenes de gatos y perros.



Deep Learning (DL)

- Deep Learning en Unsupervised Learning: El Deep Learning también se utiliza en el aprendizaje no supervisado para descubrir patrones y estructuras en los datos de entrada sin la necesidad de etiquetas. Un ejemplo de esto son los Autoencoders, que se utilizan para aprender representaciones eficientes de los datos de entrada tratando de reconstruir los datos de entrada a partir de estas representaciones. Esto puede ser útil para tareas como la reducción de la dimensionalidad y la detección de anomalías.

Deep Learning (DL)

- Deep Learning en Reinforcement Learning: En el aprendizaje por refuerzo, las técnicas de Deep Learning se utilizan para aprender políticas eficientes a partir de la retroalimentación de recompensa. Por ejemplo, la técnica de Q-Learning Profundo (Deep Q-Learning) utiliza una red neuronal para aprender la función de valor Q , que es la expectativa de recompensa futura para una acción en un estado dado. Esto ha demostrado ser muy eficaz en tareas como la creación de agentes de juego autónomos y sistemas de control autónomos.