



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
ICS2121 – MÉTODOS DE OPTIMIZACIÓN

Apuntes de Métodos de Optimización

*Por Francisco García Aubert y Jorge Vera Andreo
Material en desarrollo. No compartir fuera del curso.
(versión 7, Agosto 2025)*



Índice general

5. Geometría de la Programación Lineal y Extensiones	3
5.1. Conceptos básicos de Geometría de Programación Lineal	3
5.1.1. Definiciones	3
5.1.2. Conceptos básicos aplicados a Programación Lineal	11
5.2. Algoritmo SIMPLEX	12
5.3. Dualidad	14
5.3.1. Problema primal y dual	14
5.3.2. Algunos ejemplos de formulaciones lineales y sus duales	15
5.3.3. Ejemplo: el dual aplicado al problema de planificación de proyectos	17
5.3.4. Condiciones alternativas y Lema de Farkas	18
5.3.5. Ejemplos de aplicación del Lema de Farkas	19
5.3.6. Demostración del Lema de Farkas	21
5.3.7. SIMPLEX Dual	22

Capítulo 5

Geometría de la Programación Lineal y Extensiones

Los problemas de Programación Lineal surgen en todas las aplicaciones y dan origen a problemas gigantes, tal como la coordinación de un sistema de energía eléctrica y problemas de planificación. En algunos casos, estos problemas llegan a ser tan grandes, que resultan inmanejable de resolver como un todo, por lo que generalmente se abordan con metodologías que buscan descomponer el problema en partes más “pequeñas” pero más manejables. Estos métodos de descomposición típicamente utilizan Programación Lineal. De este modo, la teoría que subyace en la Programación Lineal, junto con los conceptos de Geometría que esta involucra son fundamentales para entender la forma en que operan los problemas actuales de optimización.

En este capítulo, entonces, abordaremos algunos de esos temas. En particular, revisaremos algunas propiedades geométricas asociadas a la Programación Lineal, recordaremos el Algoritmo Simplex y también las fundamentos de la Teoría de Dualidad, así como algunas extensiones importantes que serán de utilidad en siguientes capítulos.

5.1. Conceptos básicos de Geometría de Programación Lineal

5.1.1. Definiciones

Conjuntos convexos

Sea un conjunto $S \subset \mathbb{R}^n$. S se dice convexo si:

$$x \in S, y \in S \Rightarrow \lambda x + (1 - \lambda)y \in S, \quad \forall \lambda \in [0, 1]$$

Vale decir, los puntos que están en la línea que une los puntos x y y pertenecen a S . El conjunto S puede ser abierto o cerrado. Particularmente, para una función de n variables, $f : \mathbb{D} \rightarrow \mathbb{R}$ es convexa si para todo $x_1, x_2 \in \mathbb{D}$ se cumple que:

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2), \quad \forall \lambda \in [0, 1]$$

La figura 5.1 ilustra la definición.

Envoltura convexa

Dados los puntos $x_1, \dots, x_p \in \mathbb{R}^n$, la envoltura convexa de esos puntos es el conjunto:

$$\text{conv}(x_1, \dots, x_p) = \left\{ \sum_{i=1}^p \lambda_i x_i : \sum_{i=1}^p \lambda_i = 1; 0 \leq \lambda_i \leq 1, i = 1, \dots, p \right\}$$

De este modo, la envoltura convexa se forma con los promedios ponderados de los puntos $\{x_1, \dots, x_p\} \in \mathbb{R}^n$, y corresponde al conjunto convexo más pequeño que contiene a los puntos $\{x_1, \dots, x_p\} \in \mathbb{R}^n$. Por ejemplo, en




Figura 5.1: Función convexa

$\mathbb{R}^2$, entre dos puntos corresponde a la recta que une dichos puntos; entre tres puntos no colineales corresponde al triángulo cuyos vértices son los puntos y el espacio dentro de este. En $\mathbb{R}^3$ puede corresponder a pirámides o cubos por ejemplo. La Figura 5.2 ilustra estos casos.




Figura 5.2: Ejemplos de Envoltura convexa

Notar en el último dibujo que si un punto x_i es combinación convexa de los otros puntos, entonces si se saca este punto del conjunto convexo, el conjunto convexo queda igual. De hecho, la envoltura convexa es única y corresponde al menor conjunto de puntos $\{x_1, \dots, x_p\} \in \mathbb{R}^n$ que conforman a S .

Conos convexos

Un conjunto $K \subset \mathbb{R}^n$ es un cono convexo si:

- i) K es convexo.
- ii) $x \in K \Rightarrow \lambda x \in K, \forall \lambda \geq 0$

La segunda condición, en el fondo, dice que si $x \in K$, entonces, si se multiplica por un escalar cualquiera $\lambda \geq 0$ (se escala), entonces el nuevo punto sigue perteneciendo al cono.

Ejemplos famosos son el singleton ($k = 0$, cono trivial), $\mathbb{R}^n$, o por ejemplo el subespacio $\mathbb{R}_0^2$ cumplen con la definición anterior, o sea, no todos los conos tienen “punta”. Los conos contienen al cero y parten desde el origen.

Envoltura cónica

Sean $y_1, \dots, y_r$ en $\mathbb{R}^n$. La envoltura cónica de esos puntos es el conjunto:

$$\text{cone}(y_1, \dots, y_r) = \left\{ \sum_{i=1}^r \mu_i y_i : \mu_i \geq 0, i = 1, \dots, r \right\}$$




Figura 5.3: Cono

Se le llama también el cono generado por los vectores $\{y_1, \dots, y_r\} \in \mathbb{R}^n$. Si el conjunto de vectores que definen al cono es finito, entonces el cono no puede tener una forma curva, sino que es un cono con “caras planas”, como ilustra la figura 5.4.




Figura 5.4: Rayos extremos que definen las caras de un Cono

Ejemplo de cono convexo

Consideremos el Cono de segundo orden o cono de Lorentz, definido como:

$$K = \{x \in \mathbb{R}^n : \|(x_1, x_2, \dots, x_{n-1})\|_2 \leq x_n\}$$

Se puede demostrar formalmente que K es un cono convexo. En primer lugar, demostraremos que K es cono. Consideremos $x \in K$, tal que: $\|(x_1, x_2, \dots, x_{n-1})\|_2 \leq x_n$. Multiplicando esta expresión por $\mu > 0$, obtenemos que:

$$\begin{aligned} \mu \|(x_1, x_2, \dots, x_{n-1})\|_2 &\leq \mu x_n \\ \|(\mu x_1, \mu x_2, \dots, \mu x_{n-1})\|_2 &\leq \mu x_n \end{aligned}$$

Por lo tanto, $\mu x \in K$. Para demostrar la convexidad, consideraremos $x, y \in K$. Como $x, y \in K$, se cumple que: $\|(x_1, x_2, \dots, x_{n-1})\|_2 \leq x_n$ y $\|(y_1, y_2, \dots, y_{n-1})\|_2 \leq y_n$. Si tomamos $\lambda \in [0, 1]$, obtenemos que:

$$\begin{aligned} \|\lambda(x_1, x_2, \dots, x_{n-1})\|_2 &\leq \lambda x_n \\ \|(1-\lambda)(y_1, y_2, \dots, y_{n-1})\|_2 &\leq (1-\lambda)y_n \\ \|\lambda(x_1, x_2, \dots, x_{n-1}) + (1-\lambda)(y_1, y_2, \dots, y_{n-1})\|_2 &\leq \lambda x_n + (1-\lambda)y_n \quad /(\star) \\ \|(\lambda x_1 + (1-\lambda)y_1, \dots, \lambda x_{n-1} + (1-\lambda)y_{n-1})\|_2 &\leq \lambda x_n + (1-\lambda)y_n \end{aligned}$$

Lo que implica que $\lambda x + (1-\lambda)y \in K$ y, por lo tanto, K es un cono convexo.


($\star$) Por desigualdad triangular y el principio de transitividad.

Cono Poliédrico

Como decíamos, el cono anterior posee caras, donde sus aristas corresponden a los “rayos extremos” $\{y_1, \dots, y_r\}$. Dado esto, un cono es poliédrico si es un cono y un poliedro a la vez, por lo cual también podría escribirse como el sistema homogéneo dado por:

$$\{x \in \mathbb{R}^n : Ax \leq 0\}$$

para alguna matriz $A \in \mathbb{R}^n$. Cada fila de A define un subespacio que corresponde a un hiperplano que pasa por 0. Ejemplo de esto es:



En la misma figura podemos ver también que ese poliedro (que es un cono) es generado por dos vectores:

$$y_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, y_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

Es decir, $\text{cone}\{y_1, y_2\} = \{x : Ax \leq 0\}$ y existen dos representaciones: una como envoltura cónica de un conjunto de rayos y otra como desigualdades que representan un poliedro. Esto es un resultado más general, como veremos a continuación.

Cápsula de video 5.1.1: Convexos y Conos

Profesor Jorge Vera explica en clases los conceptos de envolturas convexas y cónicas.
<https://youtu.be/bKf06b8Z00A>

Representación puntual y algebraica de un poliedro

Consideremos un Poliedro P , acotado (es lo que llamamos un polítopo) y dado por el sistema $Ax \leq b$. Este puede ser el dibujo del lado izquierdo de la figura 5.5. Si $v_1, \dots, v_p$ son los puntos extremos de P , entonces, se puede ver también en la figura, que tenemos **dos alternativas para describir al Poliedro**, a través de sus vértices o alternativamente las desigualdades que definen sus caras.




Figura 5.5: Dos formas de representar el mismo poliedro

En forma más general, es posible probar el siguiente teorema:

Teorema 5.1.1: Representación algebraica-puntual de un polítopo

Sean $\{x_1, \dots, x_p\} \in \mathbb{R}^n$, entonces existe una matriz $A \in \mathbb{R}^{m \times n}$, y un vector $b \in \mathbb{R}^m$, para algún m tales que:

$$\text{conv}(x_1, \dots, x_p) = \{x \in \mathbb{R}^n : Ax \leq b\}$$

De este modo, un poliedro P se puede expresar como $Ax \leq b$ algebraicamente o como la envoltura convexa de sus vértices $\{v_1, \dots, v_p\}$. Si P es acotado, se le llamo polítopo, el cual posee vértices o puntos extremos $\{v_1, \dots, v_p\}$, que son puntos de restricciones activas.

Por supuesto, no es fácil calcular A y b a partir de los vértices, ni los vértices a partir de A y b .

Como ilustración, supongamos que tenemos ciertos puntos $x^1, \dots, x^p \in \mathbb{R}^2$, como muestra la figura 5.6. La envoltura convexa de esos puntos es un poliedro y debe ser representable mediante desigualdades. Un algoritmo que puede determinar esas desigualdades puede ser uno que itere para todo par de puntos formando la línea que los une, si existen puntos a ambos lados de la línea, entonces esta línea no determina una cara del Poliedro, mientras que si todos los puntos se encuentran a un mismo lado (o sobre la línea), entonces si corresponde a una cara.




Figura 5.6: Planos que configuran caras del Poliedro de los puntos

Si tuviéramos puntos en $\mathbb{R}^3$, entonces tomaría de a tres puntos para definir un plano, pero el argumento sigue en forma similar. Más en general, en $\mathbb{R}^n$ tenemos que encontrar combinaciones entre n puntos y ver si están todos los restantes puntos a un solo lado de este hiperplano. Si se trabaja en $\mathbb{R}^n$ con k puntos, entonces, se deben probar:

$$\binom{k}{n} = \frac{k!}{(k-n)!n!}$$

posibles hiperplanos. Por ejemplo, si n es 3 y k es 50, entonces se deben estudiar 19.600 planos posibles que definan el conjunto pero es evidente que este número puede crecer enormemente al aumentar n y k .

Por otro lado, Si nos dan un sistema de desigualdades $Ax \leq b$ con m filas y n columnas, $m > n$, los vértices de ese poliedro se encuentran resolviendo subsistemas de igualdades de $n \times n$ extraídos de las m desigualdades. Existe una cantidad igual a

$$\binom{m}{n} = \frac{m!}{(m-n)!n!}$$

posibles sistemas de ecuaciones que habría que probar para determinar todos los vértices. Este también puede ser un número gigantesco.

En otras palabras, el resultado de la construcción equivalente entre desigualdades y vértices suena poco práctico debido al esfuerzo computacional involucrado en pasar de uno a otro. Sin embargo, y esto es lo importante: si estamos optimizando sobre el poliedro no necesitamos todos los vértices, sólo uno: el óptimo. Eso es lo que resuelve de manera muy eficiente el Algoritmo Simplex. Al revés, muchas veces los vértices existen pero no necesitamos todas las desigualdades, sólo unas pocas. Esto será muy relevante más adelante cuando estudiemos técnicas de descomposición avanzadas como la Descomposición de Benders.

Cápsula de video 5.1.2: Representación puntual y algebraica

Profesor Jorge Vera explica en clases la construcción de la representación puntual y de la representación algebraica de un polítopo.

<https://youtu.be/BpKy6tXIC6o>

Teorema de Minkowski-Weil-Motzkin

El resultado anterior tiene una limitante: asume que el poliedro está acotado y eso no tiene por qué ser así. En este caso, la envoltura convexa de los vértices no conforma al poliedro completo, le falta algo para poder describir la parte no acotada del conjunto. Esto se puede solucionar si el poliedro no se define solo en términos de vértices, sino que también de rayos de un cono, como especifica el siguiente teorema:

Teorema 5.1.2: Minkowski-Weil-Motzkin

P es un poliedro, acotado o no, y se escribe como $\{x : Ax \leq b\}$, con $A \in \mathbb{R}^{m \times n}$, y $b \in \mathbb{R}^m$ si y solo si existen $x_1, \dots, x_p$ e $y_1, \dots, y_r$, tales que:

$$P = C + K$$

donde:

- $C = \text{conv}(x_1, \dots, x_p)$
- $K = \text{cone}(y_1, \dots, y_r)$

En el fondo, esto quiere decir que puedo tener dos representaciones totalmente equivalentes, una por vectores (representación puntual) y otra por desigualdades (representación algebraica). Al cono K se le llama “cono de recesión” de P y se denota como $\text{Recc}(P)$. Se puede probar que si P está dado por el sistema $Ax \leq b$ $\text{Recc}(P) = \{y : Ay \leq b_0\}$ y en caso que sea $Ax = b, x \geq 0$, entonces $\text{Recc}(P) = \{y : Ay = 0, y \geq 0\}$.




Figura 5.7: Un Poliedro no acotado P se puede formar mediante la suma de un Poliedro acotado C y un cono K

En forma alternativa, cualquier vector del poliedro P se puede representar por la suma de un vector que en C más un vector que sea un rayo del cono de recesión K .




Figura 5.8: Poliedro acotado C más los rayos de K forman al poliedro P

De manera más explícita, el punto $x \in P$ si:

$$x = \sum_{i=1}^p v_i x_i + \sum_{i=1}^r h_i y_i : \sum_{i=1}^p \lambda_i = 1; 0 \leq \lambda_i \leq 1, i = 1, \dots, p, \mu_i \geq 0, i = 1, \dots, r$$

Donde los v_i corresponden a los vértices del poliedro y los h_i corresponden a los rayos. Las figuras 5.7 y 5.8 ilustran la construcción.

Cápsula de video 5.1.3: Teorema de Minkowski-Weil-Motzkin

Profesor Jorge Vera explica en clases la representación puntual-algebraica general de un poliedro.
<https://youtu.be/BpKy6tXIC6o>


Ejemplo 1

Consideremos el poliedro definido por las siguientes desigualdades:


$$\begin{array}{rcl} x_1 & -2x_2 & \leq 0 \\ 2x_1 & +2x_2 & \leq 3 \\ x_2 & & \leq 1 \end{array}$$

Vamos a determinar explícitamente la descomposición de P en puntos extremos y rayos del cono de recesión (en caso que exista). Es decir, identifique esos puntos extremos y rayos.

El siguiente diagrama muestra el poliedro y sus puntos extremos (notar que no hay restricciones de signo en las variables):



En el siguiente diagrama se muestra el cono de recesión:



Los puntos extremos son:

$$A = \begin{pmatrix} 1 \\ 1/2 \end{pmatrix}, B = \begin{pmatrix} 1/2 \\ 1 \end{pmatrix}$$

y los rayos son:

$$y_1 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, y_2 = \begin{pmatrix} -2 \\ -1 \end{pmatrix}$$

o múltiplos de estos, por supuesto.

Ahora, consideremos el punto $(\frac{1}{2}, \frac{1}{2})$. Este punto se escribe de la siguiente manera usando la descomposición anterior:

$$\begin{pmatrix} 1/2 \\ 1/2 \end{pmatrix} = \lambda_1 \begin{pmatrix} 1 \\ 1/2 \end{pmatrix} + \lambda_2 \begin{pmatrix} 1/2 \\ 1 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} -2 \\ -1 \end{pmatrix}$$

y, adicionalmente:

$$\lambda_1 + \lambda_2 = 1, \lambda_i \geq 0, \mu_i \geq 0$$


Esto se resuelve con $\lambda_1 = 1, \lambda_2 = 0, \mu_1 = 1/2, \mu_2 = 0$.

Ejemplo 2:

Consideremos el conjunto en $\mathbb{R}^3$ definido por las siguientes desigualdades lineales:

$$\begin{aligned} x_1 + x_2 + x_3 &\geq 2 \\ -x_1 - x_2 + x_3 &\leq 2 \\ x_3 &\geq 1 \\ x_1, x_2, x_3 &\geq 0 \end{aligned}$$

La siguiente figura muestra, aproximadamente la forma del conjunto. Esto está “visto” desde el interior del ortante ≥ 0 mirando hacia el origen:



Los vértices (o puntos extremos) son:

$$v^1 = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, v^2 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, v^3 = \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix}$$

Los rayos son:

$$y^1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, y^2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, y^3 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, y^4 = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

Usando los elementos anteriores, el punto $(5, 5, 3)$ se escribe de la siguiente forma:

$$\begin{pmatrix} 5 \\ 5 \\ 3 \end{pmatrix} = \lambda_1 \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} + \lambda_2 \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} + \lambda_3 \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix} + \mu_1 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} + \mu_3 \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} + \mu_4 \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

con las condiciones adicionales que:

$$\lambda_1 + \lambda_2 + \lambda_3 = 1, \lambda_i \geq 0, \mu_i \geq 0$$

5.1.2. Conceptos básicos aplicados a Programación Lineal

Tomemos un problema de Programación Lineal en forma estándar: $\min \{c^T x : Ax = b, x \geq 0\}$ donde A es de m filas y n columnas, $m \leq n$. Recordemos que cuando este problema alcanza el óptimo, lo hace en un punto extremo, eso es lo que se llama una solución básica factible. Una solución básica viene de que en el sistema $Ax = b, x \geq 0$, la matriz A se puede descomponer en dos partes, una básica B y una no básica N : $A = [B \mid N]$. Si $A \in \mathbb{R}^{m \times n}$ con $m \leq n$, entonces $B \in \mathbb{R}^{m \times m}$ es una matriz invertible y es la dimensión fila (el número de restricciones) la que define el tamaño de la base. El vector x se descompone siguiendo una estructura análoga, en coordenadas básicas y no básicas: $x = \begin{bmatrix} x_B \\ x_N \end{bmatrix}$, lo mismo el vector c de costos: $c = \begin{bmatrix} c_B \\ c_N \end{bmatrix}$. Con esto, una solución básica factible es tal que:

$$\begin{aligned} Ax &= b \\ [B \mid N] \cdot \begin{bmatrix} x_B \\ x_N \end{bmatrix} &= b \\ Bx_B + Nx_N &= b \end{aligned}$$

Como $x_N = 0$, entonces se cumple que $x_B = B^{-1}b \geq 0$. Uno de los resultados fundamentales de Programación Lineal es que esta solución básica factible identifica a uno de los vértices del Poliedro. Más aún, el óptimo se alcanza en uno de esos vértices, es decir, en una solución básica factible.

No acotamiento e infactibilidad

Por otro lado, el problema $\min \{c^T x, \text{ s.a. } Ax = b, x \geq 0\}$ puede ser “no acotado”, lo que se traduce en que existe un rayo $h \in \text{Recc}(P)$, tal que $c^T h < 0$. La prueba de esto es la siguiente: Sea $\bar{x}$ una solución factible:

$$A\bar{x} = b, \quad \bar{x} \geq 0$$

Luego, el punto $A(\bar{x} + \delta h)$, $\delta \geq 0$ también es factible pues es mayor que el vector 0: $\bar{x} + \delta h \geq 0$ y además cumple con:

$$A(\bar{x} + \delta h) = A\bar{x} + \delta Ah = A\bar{x} = b, \quad \text{pues como } h \in \text{Recc}(P), \text{ entonces : } Ah = 0$$

Luego, si se evalúa este punto factible en la función objetivo, tomando el límite cuando δ tiende a infinito y el rayo $h \in \text{Recc}(P)$ tal que $c^T h \leq 0$, entonces se tiene que:

$$\lim_{\delta \rightarrow \infty} c^T(\bar{x} + \delta h) = \lim_{\delta \rightarrow \infty} (c^T \bar{x} + \delta c^T h) = c^T \bar{x} + \lim_{\delta \rightarrow \infty} (\delta c^T h) = -\infty$$

Entonces, si existe un rayo $h \in \text{Recc}(P)$, tal que $c^T h < 0$, es un certificado de no acotamiento. El algoritmo Simplex detecta esto precisamente en su “test de no acotamiento”.

Por otro lado, para certificar infactibilidad, se hace Simplex Fase I con variables artificiales, si se llegaba a una solución donde todas las variables artificiales son nulas, entonces el problema era factible.

5.2. Algoritmo SIMPLEX

El problema en forma estándar: $\min \{c^T x : Ax = b, x \geq 0\}$ puede ser replanteado en la forma canónica o reducida mediante la “separación” de los vectores y matrices en una parte básica y no básica. En primer lugar, $Ax = b$, se puede plantear como:

$$\begin{aligned} A_B x_B + A_R x_R &= b, \quad /A_B^{-1} \\ x_B + \underbrace{A_B^{-1} A_R}_{\bar{A}_R} x_R &= \underbrace{A_B^{-1} b}_{\bar{b}} \end{aligned}$$

Donde x_R corresponde a las variables no básicas ($\therefore x_R = 0$), por lo que las variables básicas corresponden a $x_B = \bar{b} - \bar{A}_R x_R = \bar{b}$. La función objetivo, $\min c^T x$, se puede plantear del siguiente modo en términos de sus coordenadas básicas y no básicas:

$$\begin{aligned} c^T x &= c^T (x_B + x_R) \\ &= c_B^T x_B + c_R^T x_R \\ &= c_B^T (\bar{b} - \bar{A}_R x_R) + c_R^T x_R \\ &= c_B^T \bar{b} + \underbrace{(c_R^T - c_B^T \bar{A}_R)}_{\text{costos reducidos}} x_R \end{aligned}$$

Con todo esto, el problema de optimización se puede escribir como:

$$\begin{aligned} \min \quad & c_B^T \bar{b} + (c_R^T - c_B^T \bar{A}_R) x_R \\ \text{s.a.} \quad & x_B + \bar{A}_R x_R = \bar{b} \\ & x_B \geq 0 \\ & x_R = 0 \end{aligned}$$

En el fondo, los costos reducidos de la variable j r_j corresponden a la tasa de cambio del valor objetivo por aumentos unitarios de x_j manteniendo constante la base B :

$$r_j = \frac{dz}{dx_j} = \frac{d}{dx_j} (c_B^T \bar{b} + (c_R^T - c_B^T \bar{A}_R) x_R) = c_j - c_B^T \bar{A}_j$$

El algoritmo desarrollado por Dantzig, se inspira en el hecho de que los costos se pueden expresar como $c_B^T \bar{b} + (c_R^T - c_B^T \bar{A}_R) x_R$, entonces si $[(c_R^T - c_B^T \bar{A}_R) x_R]_j$, que corresponde a la variable j dentro de los costos reducidos, es negativa, sucede que conviene hacer que variable sea distinta de cero, es decir entrar a la base a dicha variable.

El valor de esta variable se puede hacer crecer hasta el punto en que se pueda. Para ver cuánto es la capacidad máxima, se puede ver que como:

$$x_B = A_B^{-1} b - \bar{A}_R x_R = \bar{b} - \bar{A}_R x_R$$

y como x_B debe no puede ser negativa, entonces el valor de $\bar{b} - \bar{A}_R x_R$ debe ser mayor que cero, pero precisamente, al aumentar el valor de la variable $j \in x_R$, sucederá que algún variable en el vector x_B disminuirá hasta hacerse cero. La primera variable de la base tal que pasé esto, la sacamos de la base, tal que:

$$\bar{\delta} = \min \left\{ \frac{\bar{b}_i}{[\bar{A}_j]_i}, i : [\bar{A}_j]_i > 0 \right\} = \min \left\{ \frac{\bar{b}_i}{\bar{a}_{ij}}, i : \bar{a}_{ij} > 0 \right\}$$

Es i el índice donde el mínimo se alcanza.

Por otro lado, se define el vector de precios sombra $\pi \in \mathbb{R}^m$ asociado a una base B se define como:

$$\pi = (A_B^{-1})^T c_B$$

Cada π_i indica tasa de cambio del valor objetivo al haber un aumento unitario del recurso b_i (manteniendo la base). Para ver porqué sucede esto, consideremos la variable de holgura x_h de la i -ésima restricción: $a_i^T x + x_h = b_j$. Si $\bar{A}_h$ es la componente i de $\bar{A}_R$, entonces su costo reducido es:

$$\begin{aligned} r_h &= c_h - c_B^T \bar{A}_h \\ &= c_h - c_B^T A_B^{-1} A_h \\ &= c_h - \pi^T A_h \quad / c_h = 0 \\ &= -\pi_i \end{aligned}$$

Notar que $c_h = 0$ debido a que las variables de holgura al ser artificiales no tienen costo y $\pi^T A_h = -\pi_i$ debido a que A_h corresponde a un vector de puros ceros, salvo en la coordenada i . Luego, $\frac{dz}{db_i} = -r_h = \pi_i$. Esto sucede en esencia ya que un cambio marginal de la f.o. respecto a la restricción de recurso i es precisamente el negativo del costo de que la variable de holgura pudiera crecer marginalmente. Notar que es muy brillante, dado que tenemos la forma de calcular la variación marginal respecto a las variables y las variables de holgura, si bien no tienen costo, sus cambios igual afectan el valor de la función objetivo, y sus cambios son precisamente aumentar la “holgura” que le impone la barrera del b , por lo que su beneficio marginal también es el beneficio marginal de aumentar b .

Toda esta idea se implementa en el algoritmo SIMPLEX que se muestra a continuación:

Algoritmo SIMPLEX

Data: A , b , c y una base factible inicial $B = [A_{j(1)}, \dots, A_{j(m)}]$
 Las variables básicas actuales son $x_B = \bar{b} = B^{-1}b$ y el valor objetivo es $z = c_B^T \bar{b}$.;
 Calcular π de $B\pi = c_B$ y $\bar{c}_j = c_j - \pi^T R_j, \forall j \in I_R$ (índices de variables no básicas).;
while $\bar{c}_j$ no sea ≥ 0 para todo $j \in I_R$ **do**
 Elegir $j_0 \in I_R$ tal que $\bar{c}_{j_0} < 0$.;
 Calcular $\bar{R}_{j_0} = B^{-1}R_{j_0}$
 if $\bar{R}_{j_0} \leq 0$ **then**
 el problema es no acotado, STOP;
 else
 $\bar{\delta} = \min \left\{ \frac{\bar{b}_i}{\bar{a}_{ij_0}}, i : \bar{a}_{ij_0} > 0 \right\}$ y sea s el índice donde mín se alcanza. ;
 Formar una nueva base reemplazando la columna A_s por la columna A_{j_0} .;
 end
end
end

En el fondo, el algoritmo SIMPLEX ve todas las contribuciones de cada una de las variables no básicas a la función objetivo, esto corresponde al costo reducido $\bar{c}_j$. Si uno de estos es negativo, entonces conviene aumentar la variable x_j hasta donde se pueda, según lo que indique el test del mínimo cociente. Posteriormente se hace el cambio de base, haciendo entrar la columna j de A y sacando la asociada a la variable que sale. Cada vez que se hace esto, se pasa de un vértice a otro.

SIMPLEX tiene una ventaja computacional, es muy eficiente, gracias a que el costo por iteración es muy bajo. Las etapas computacionales fundamentales son resolver los sistemas:

$$B\pi = c_B, \quad Bx_B = b, \quad B\bar{R}_j = R_j$$

Esto implica resolver sistemas lineales, y por lo tanto invertir matrices (B^{-1}). Además B cambia de iteración a iteración, por lo que se podría pensar que es muy lento, pero la verdad es que B cambia, en cada iteración, en solo una columna. Se puede aprovechar eso de manera muy eficiente para recalculer la inversa de la base, cosa que llega a tener una complejidad de orden $\mathcal{O}(m)$ y no $\mathcal{O}(m^3)$ como sucede con invertir matrices. Esto se hace utilizando la descomposición LU , donde L es una matriz triangular inferior y U triangular superior

$$B = LU$$

Las matrices L y U se ven aproximadamente de esta forma, donde $\bullet$ implica de que ahí hay números que no necesariamente son 0:

$$L = \begin{bmatrix} \bullet & 0 & 0 & \dots & 0 \\ \bullet & \bullet & 0 & \dots & 0 \\ \bullet & \bullet & \bullet & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \bullet & \bullet & \bullet & \dots & \bullet \end{bmatrix} \quad U = \begin{bmatrix} 0 & \bullet & \bullet & \dots & \bullet \\ 0 & 0 & \bullet & \dots & \bullet \\ 0 & 0 & 0 & \dots & \bullet \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{bmatrix}$$

$$Bx = b \longrightarrow LUx = b \longrightarrow Ux = L^{-1}b \longrightarrow x = U^{-1}L^{-1}b$$

Esto es fácil de invertir, pues son matrices triangulares. Además cuando B cambia a B' ($B \longrightarrow B'$), llamamos C a la matriz que tiene sólo ceros y una sola columna distinta de cero, entonces se tiene que

$$B' = B + C \longrightarrow L^{-1}B' = L^{-1}B + L^{-1}C = U + L^{-1}C$$

$L^{-1}C$ corresponde a una matriz que también tiene todas sus entradas igual a cero, salvo una columna. Como esta matriz se le suma a U , entonces va a quedar una matriz V con la siguiente forma:

$$U + L^{-1}C = V = \begin{bmatrix} 0 & \bullet & \bullet & \dots & \bullet \\ 0 & 0 & \bullet & \dots & \bullet \\ 0 & 0 & \bullet & \dots & \bullet \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \bullet & \dots & 0 \end{bmatrix}$$

Para transformar estas matrices diagonales superiores e inferiores tan solo debo pivotar, cosa que en el peor de los casos es de orden $\mathcal{O}(m)$, con lo que se pasa de la matriz V a la matriz U' que es diagonal superior. Luego se multiplica $L^{-1}B' = U'$ por L y así se obtiene $B' = LU'$, y debido a que son diagonales resultan simples de invertir.

Cápsula de video 5.2.1: Eficiencia del cambio de base del Simplex

Profesor Jorge Vera explica en clase el cambio de base del Simplex usando la descomposición LU .
<https://youtu.be/J-GnXtqqSgQ>

5.3. Dualidad

5.3.1. Problema primal y dual

En programación Lineal, la Dualidad da una visión alternativa del problema que se está planteando, de modo que se tiene un problema equivalente pero con una visión alternativa. Si el siguiente es el Problema primal (en forma estándar):

$$\begin{aligned} P) \quad & z^* = \min c^T x \\ & \text{s.a. } Ax = b \\ & x \geq 0 \end{aligned}$$

Entonces, el dual de P) es:

$$\begin{aligned} D) \quad & w^* = \max b^T u \\ & \text{s.a. } A^T u \leq c \end{aligned}$$

Si x es factible en P) y n es factible en D , entonces se cumple que el que minimiza acota por arriba al que maximiza:

$$c^T x \geq b^T u, \quad (\text{dualidad débil})$$

Y si son óptimos:

$$z^* = w^*, \quad (\text{dualidad fuerte})$$

Otros formatos de Programación dual tienen sus correspondientes duales. Por ejemplo si

$$\begin{aligned} z^* &= \min c^T x \\ P) \quad &\text{s.a. } Ax \geq b \\ &x \geq 0 \end{aligned}$$

Entonces, el dual de P) es:

$$\begin{aligned} w^* &= \max b^T u \\ D) \quad &\text{s.a. } A^T u \leq c \\ &u \geq 0 \end{aligned}$$

Cualquier combinación de desigualdades e igualdades lleva a un correspondiente dual y ese se obtiene haciendo transformaciones equivalentes. A veces es útil tener esta tabla, que recuerda las transformaciones:

Minimización	Maximización
Variables	Restricciones
≥ 0	$\leq$
≤ 0	$\geq$
irrestringida	$=$
Restricciones	Variables
$\leq$	≤ 0
$\geq$	≥ 0
$=$	irrestringida

Por Dualidad Débil, sabemos que: $b^T \bar{u} \leq c^T \bar{x}$ cuando $\bar{x}$ e $\bar{y}$ son soluciones factibles. Y por Dualidad Fuerte, se sabe que si x^* e y^* son soluciones óptimas, entonces: $b^T u^* = c^T x^*$

Esto mismo lleva a la conclusión que si P) es infactible y si D es factible entonces D tiene que ser no acotado. Más en específico:

- Si el primal es no acotado, entonces su dual será infactible.
- Si el primal es infactible, entonces su dual puede ser infactible o no acotado.
- Si el primal es degenerado (posee una restricción de más), entonces su dual posee infinitas soluciones.

5.3.2. Algunos ejemplos de formulaciones lineales y sus duales

$$\begin{aligned} \min \sum_{t=1}^T \{c_t x_t + h_t I_t\} \\ \text{s.a. } \sum_{t=1}^T a_t x_t \leq K \\ I_{t-1} - I_t + x_t \geq d_t, \quad t = 1, \dots, T \\ x_t \geq 0, \quad t = 1, \dots, T \end{aligned} \quad (\pi) \quad \longrightarrow \quad \begin{aligned} \max \quad &\pi \cdot K + \sum_{t=1}^T u_t \cdot d_t \\ \text{s.a. } \quad &a_t \cdot \pi + u_t \leq c_t, \quad t = 1, \dots, T \\ &-u_t + u_{t+1} = h_t, \quad t = 1, \dots, T-1 \\ &-u_T = h_T \\ &u_t \geq 0, \quad t = 1, \dots, T \\ &\pi \leq 0 \end{aligned} \quad (u_t)$$

$$\begin{array}{ll}
\min \sum_{t=1}^T \sum_{i=1}^m (e_{it} - p_i) z_{it} & \\
\text{s.a. } \sum_{i=1}^m z_{it} = \sum_{j=1}^n x_{jt}, & t = 1, \dots, T \quad (\pi_t) \\
\sum_{t=1}^T z_{it} \leq K_i, & i = 1, \dots, m \quad (s_i) \\
z_{it} \geq 0, & t = 1, \dots, T \\
& i = 1, \dots, m
\end{array} \longrightarrow \begin{array}{ll}
\max \sum_{t=1}^T \sum_{j=1}^n x_{jt} \pi_t + \sum_{i=1}^m K_i s_i & \\
\text{s.a. } \pi_t + s_i \leq e_{it} - p_i, & t = 1, \dots, T \\
& i = 1, \dots, m \\
s_i \leq 0, & i = 1, \dots, m
\end{array}$$

$$\begin{array}{ll}
\min \sum_{j=1}^N c_j t_j & \\
\text{s.a. } t_j \geq \sum_{i=1}^P w_i x_{ij} - T y_j, & j = 1, \dots, N \quad (\pi_j) \\
\sum_{j=1}^N t_j \leq Q & (\alpha) \\
t_j \geq 0, & j = 1, \dots, N
\end{array} \longrightarrow \begin{array}{ll}
\max \sum_{j=1}^N \pi_j \left(\sum_{i=1}^P w_i x_{ij} - T y_j \right) + Q \alpha & \\
\text{s.a. } \pi_j + \alpha \leq c_j & j = 1, \dots, N \\
\pi_j \geq 0, \alpha \leq 0 & j = 1, \dots, N
\end{array}$$

$$\begin{array}{ll}
\min e^T v & \\
\text{s.a. } Ax + Iv = b \quad (\pi) & \longrightarrow \\
(x, v) \geq 0 & \begin{array}{ll} \max b^T \pi \\ \text{s.a. } A^T \pi \leq 0 \\ I\pi \leq e \end{array}
\end{array}$$

$$\begin{array}{ll}
\min \sum_{(i,j) \in A} c_{ij} x_{ij} & \\
\text{s.a. } \sum_{(i,j) \in A} x_{ij} - \sum_{(k,i) \in A} x_{ki} = d_i, & i \in N \quad (\pi_i) \\
x_{ij} \leq U_{ij} y_{ij}, & (i,j) \in A \quad (W_{ij}) \\
x_{ij} \geq 0 & (i,j) \in A
\end{array} \longrightarrow \begin{array}{ll}
\max \sum_{i \in N} \pi_i d_i + \sum_{(i,j) \in A} W_{ij} U_{ij} y_{ij} & \\
\text{s.a. } \pi_i - \pi_j + W_{ij} \leq c_{ij} & (i,j) \in A \\
W_{ij} \geq 0 & (i,j) \in A
\end{array}$$


$$\begin{array}{ll}
\min \gamma & \\
\text{s.a. } 1 + v_i^T x \leq \gamma, i = 1, \dots, r \quad (y_i) & \longrightarrow \\
& \begin{array}{ll} \max \sum_{i=1}^r y_i \\ \text{s.a. } \sum_{i=1}^r y_i v_i = 0 \\ \sum_{i=1}^r y_i = 1 \\ y_i \geq 0, & i = 1, \dots, r \end{array}
\end{array}$$

$$\begin{aligned}
& \text{máx } 0 \times \pi + \sum_{k=1}^N q_k c_k^T x \\
& \text{s.a. } \sum_{k=1}^N \sum_{s=1}^N \pi_{ks} d_{ks} \leq r \quad (\rho) \\
& \sum_{k=1}^N \pi_{ks} = p_s, \quad s = 1, \dots, N \quad (\alpha_s) \\
& \sum_{s=1}^N \pi_{ks} - q_k = 0, \quad k = 1, \dots, N \quad (\beta_k) \\
& \pi \geq 0, \quad q \in \mathbb{R}^N
\end{aligned}
\longrightarrow
\begin{aligned}
& \text{mín } r\rho + \sum_{s=1}^N p_s \alpha_s \\
& \text{s.a. } \rho d_{ks} + \alpha_s + \beta_k \geq 0 \quad k, s = 1, \dots, N \\
& \quad -\beta_k = c_k^T x \quad k = 1, \dots, N \\
& \quad \rho \geq 0
\end{aligned}$$

$$\begin{aligned}
& \text{mín } \sum_{(i,j) \in A} c_{ij} x_{ij} \\
& \text{s.a. } \sum_{j: (i,j) \in A} x_{ij} - \sum_{p: (p,i) \in A} x_{pi} = d_i, i \in N \longrightarrow \text{s.a. } \pi_i - \pi_j \leq c_{ij}, \forall (i,j) \in A \\
& x_{ij} \geq 0, \forall (i,j) \in A
\end{aligned}$$

5.3.3. Ejemplo: el dual aplicado al problema de planificación de proyectos

Un proyecto se ha dividido en actividades que deben ser realizadas respetando relaciones de precedencia entre ellas. Se ha decidido utilizar una red dirigida para representar estas relaciones, en la cual cada arco está asociado a una actividad, y cada nodo representa el término o inicio de las actividades que llegan o salen de él, respectivamente. Por ejemplo, en la red de figura, las actividades (1,2) y (1,3) son las que se deben realizar al inicio del proyecto. El nodo 1 representa el evento o “hito” de inicio. Por otro lado, el nodo 5 representa el término de las actividades (3,5) y (2,5), y el comienzo de las actividades (5,6) y (5,7). Estas dos últimas no se pueden realizar mientras no se hayan completado las actividades (2,5) y (3,5). Se ha estimado la duración de cada actividad, denotado por d_{ij} y este dato se muestra igualmente en la figura:



Más formalmente y en general, un proyecto se puede, entonces, representar con un grafo dirigido $G = (N, A)$ donde un nodo r representa el inicio y un nodo s representa el final del proyecto. Los arcos son las actividades y los nodos son inicios y términos de conjuntos de actividades, d_{ij} es la duración de la actividad (i, j) .

Denotemos por t_i la variable de decisión que representa el instante de tiempo en que pueden comenzar las actividades cuyos arcos salen del nodo i . Ahora notemos que la duración total del proyecto (y por ende la función cuyo objetivo es minimizar) es $t_s - t_r$, donde r representa el punto de partida del proyecto y s el término de este. Para las restricciones, lo importante es considerar la precedencia de las actividades, lo que puede ser representado por cada arco en la red. De esta manera, lo anterior se puede expresar matemáticamente como $t_j \geq t_i + d_{ij} \forall (i, j) \in A$. Por lo tanto, el modelo de programación lineal asociado a la minimización de la duración del proyecto es:

$$\begin{aligned}
& \text{mín } t_s - t_r \\
& \text{s.a. } t_j - t_i \geq d_{ij} \quad \forall (i, j) \in A \\
& \quad t_i \in \mathbb{R} \quad \forall i \in N
\end{aligned}$$

Escribamos ahora el problema dual a este. Llamemos x_{ij} a la variable dual asociada a cada arco $(i, j) \in A$. Notemos que los coeficientes de las variables t_i valen 0 excepto para r y s , cuyos coeficientes son -1 y 1 respectivamente. Estos coeficientes equivalen a los valores del lado derecho de las restricciones en el dual.

Del mismo modo, notemos que en el dual hay una restricción por cada nodo y el número de términos en la función objetivo está limitado a la cantidad de arcos existentes en la red. Por lo tanto, el problema dual es el siguiente:

$$\begin{aligned} & \text{máx} \quad \sum_{(i,j) \in A} d_{ij} x_{ij} \\ & \text{s.a.} \quad \sum_{(i,j) \in A} x_{ij} - \sum_{(j,k) \in A} x_{jk} = \begin{cases} -1 & j = r \\ 0 & j \neq r, s \\ 1 & j = s \end{cases} \quad \forall j \in N \\ & \quad x_{ij} \geq 0 \quad \forall (i,j) \in A \end{aligned}$$

Esta formulación corresponde a un problema de flujo en el que se busca maximizar el costo de la ruta, es decir, obtener la ruta más larga (lo que se consigue en el óptimo). Por otro lado, en la formulación inicial del problema, se buscaba minimizar la duración del proyecto, es decir, obtener la duración mínima (lo cual se consigue en el óptimo). Luego, por el Teorema de Dualidad Fuerte, la ruta más larga coincide con la duración mínima del proyecto. En el área de “Programación de proyectos” esa ruta más larga es la que se conoce como “Ruta Crítica”. Su determinación es fundamental ya que atrasos en las actividades de la ruta crítica implican atrasos en todo el proyecto.

5.3.4. Condiciones alternativas y Lema de Farkas

El siguiente resultado es muy importante y establece una especie de “condición alternativa” con respecto a la existencia de soluciones de dos sistemas de ecuaciones y desigualdades relacionados. Esto es el:

Teorema 5.3.1: Lema de Farkas

Una y solo una de las siguientes afirmaciones es cierta:

- (I) El sistema $Ax \leq b$ es factible
- (II) Existe $u \geq 0$ tal que $A^T u = 0$, $b^T u < 0$

La demostración de que ambas no pueden ser verdaderas simultáneamente se puede dar por contradicción: supongamos que ambas condiciones son verdaderas al mismo tiempo, entonces, si multiplicamos (I) por $u \geq 0$, entonces se mantiene la desigualdad: $u^T Ax \leq u^T b$, por (II) el lado derecho de la desigualdad es nulo, pues $A^T u = 0$, entonces se llega a que $0 \leq u^T b$, lo que es una clara contradicción con la condición de (II) $b^T u < 0$. El resto del argumento muestra que una de ellas tiene que ser verdadera (es decir, no pueden ser ambas falsas) pero eso requiere argumentos más avanzados de análisis convexo y no lo mostraremos ahora.

Lo que subyace a este teorema está relacionado con dualidad. Sea el primal estándar (con $c = 0$) y el dual respectivamente como:

$$\begin{array}{ll} \text{máx} & 0^T x \\ P) \quad \text{s.a.} & Ax \leq b \end{array} \quad \begin{array}{ll} \text{mín} & b^T u \\ D) \quad \text{s.a.} & A^T u = 0 \\ & u \geq 0 \end{array}$$

Notar que el dual es factible ($u = 0$ cumple). Entonces se tiene que si o si se debe cumplir una, y solo una de las siguientes opciones para un $u > 0$:

- Si el dual es factible no acotado, tal que para un $u > 0$ se cumple que $A^T u = 0$ y $b^T u < 0$, entonces su primal será infactible (no se cumple que $Ax \leq b$).
- Si el dual es acotado, tal que $b^T u \geq 0$, entonces su primal es factible, tal que se cumple que $Ax \leq b$ con valor óptimo $0^T x = 0$.

Notar que $A^T u = 0$ es un cono.

Cápsula de video 5.3.1: Dualidad y Lema de Farkas

Profesor Jorge Vera repasa en clases los conceptos de dualidad de Programación Lineal e introduce el Lema de Farkas.

<https://youtu.be/St9-jCUpGrE>

5.3.5. Ejemplos de aplicación del Lema de Farkas**Otros formatos alternativos**

Considere un sistema de la forma $Ax \leq b, Bx = d, x \geq 0$. El sistema de desigualdades e igualdades alternativo según el Lema de Farkas se puede obtener de dos formas. Primero, el Lemma de Farkas dice que el sistema $Ax \leq b, x \geq 0$ es infactible si y sólo si el sistema $A^T u \geq 0, b^T u < 0$ es factible. Para el sistema propuesto, podemos escribirlo como:

$$Ax \leq b, Bx \leq d, -Bx \leq -d, x \geq 0$$

y aplicar la formulación básica del lema, de donde se deduce que el sistema alternativo es:

$$A^T u + B^T z - B^T w \geq 0, b^T u + d^T z - d^T w < 0, u \geq 0, z \geq 0, w \geq 0$$

que es lo mismo que:

$$A^T u + B^T(z - w) \geq 0, b^T u + d^T(z - w) < 0, u \geq 0, z \geq 0, w \geq 0$$

Llamando $v = z - w$, como $z \geq 0, w \geq 0$, se tiene que v no tiene restricción de signo alguna y de ahí se sigue que el resultado alternativo es:

$$A^T u + B^T v \geq 0, b^T u + d^T v < 0, u \geq 0$$

Otra forma de obtener el resultado es mediante dualidad. Si el problema de optimización lineal

$$\begin{array}{ll} \text{máx} & c^T x \\ \text{s.a.} & Ax \leq b \\ & Bx = d \\ & x \geq 0 \end{array}$$

es infactible, entonces su dual:

$$\begin{array}{ll} \text{mín} & b^T u + d^T v \\ \text{s.a.} & A^T u + B^T v \geq c \\ & u \geq 0 \end{array}$$

es no acotado. Esto significa que existe (u, v) tales que $A^T u + B^T v \geq 0, b^T u + d^T v < 0, u \geq 0$, que es lo pedido.

Fase I del Simplex

Para la Fase I del Simplex, se resuelve el problema con las holguras y se busca que estas sean nulas, por lo que si el valor del siguiente problema es cero, entonces se está en un vértice que es solución factible:

$$\begin{array}{ll} \text{mín} & e^T v \\ \text{s.a.} & Ax + Iv = b \quad (\pi) \\ & (x, v) \geq 0 \end{array}$$

El dual de este problema corresponde a:

$$\begin{array}{ll} \text{máx} & b^T \pi \\ \text{s.a.} & A^T \pi \leq 0 \\ & I\pi \leq e \end{array}$$

Si el óptimo de este problema es estrictamente positivo ($e^T v^* > 0$), entonces por dualidad fuerte, se tiene que $b^T \pi > 0$. De esto se sigue que existe π tal que $A^T \pi \leq 0$, $b^T \pi > 0$. Por el Lema de Farkas, se tiene que el sistema $Ax = b, x \geq 0$ no puede ser factible, que es lo mismo que postula la Fase I.

Problema de inversiones

Suponga que dispone de n instrumentos de inversión (bonos, por ejemplo). Sean $p_1, \dots, p_n$ los precios de estos bonos al comienzo del periodo de inversión. Al final del horizonte, el valor de los bonos es $v_1, \dots, v_n$. Supongamos que se invierte $x_1, \dots, x_n$ en cada uno de los bonos (se puede tener $x_j < 0$, es lo que en finanzas se llama una “posición corta”). Entonces el valor de la inversión inicial es $p^T x$ y el retorno final es $v^T x$. Dado que el retorno real es incierto, es habitual asumir algunos escenarios futuros. Específicamente, supongamos que se asume que puede ocurrir cualesquiera de m escenarios de retornos, $v^1, \dots, v^m$, donde $v^i \in \mathbb{R}^n$. Si ocurre el escenario i , el retorno será $(v^i)^T x$. Si existe un vector de inversiones x tal que $p^T x < 0$ y $(v^i)^T x \geq 0$, para todos escenarios $i = 1, \dots, m$, se dice que hay una “oportunidad de arbitraje”, que significa que hay una garantía de obtener utilidades en la inversión, libre de riesgos. La teoría económica-financiera impone habitualmente la condición de que no exista arbitraje. Sea V la matriz cuyas filas son los vectores $v^1, \dots, v^m$ (puestos como filas). Vamos a demostrar que para que no exista arbitraje, entonces debe existir $y \in \mathbb{R}^m$ tal que $p = V^T y, y \geq 0$.

Para argumentar esto, necesitamos la siguiente versión del Lema de Farkas (demostrarla):

Uno y exactamente uno de los siguientes sistemas es factible:

1. $Ax = b, x \geq 0$.
2. $A^T y \geq 0, b^T y < 0$.

Ahora, sobre la base de este resultado, podemos ver que para que no haya arbitraje, no debe existir x tal que $p^T x < 0$ y $Vx \geq 0$. Esto es equivalente a que exista $y \in \mathbb{R}^m$ tal que $p = V^T y, y \geq 0$.

Demostración de los teoremas de dualidad a partir del Lema de Farkas

Vamos a usar el Lema de Farkas para demostrar los teoremas de dualidad. Para esto (y para simplificar) vamos a considerar el problema

$$P) \quad \begin{array}{ll} z^* = \text{mín} & c^T x \\ \text{s.a.} & Ax \geq b \\ & x \geq 0 \end{array}$$

cuyo dual es

$$D) \quad \begin{array}{ll} w^* = \text{máx} & b^T u \\ \text{s.a.} & A^T u \leq c \\ & u \geq 0 \end{array}$$

Primero vamos a probar el Teorema Débil de Dualidad. Sea x un punto factible para el problema primal P) y sea u un punto factible para el problema dual D). Como $x \geq 0$ y $A^T u \leq c$, tenemos que $x^T A^T u \leq x^T c = c^T x$. Pero $x^T A^T u = b^T u$. Luego, $b^T u \leq c^T x$, como se quería demostrar.

Ahora vamos a mostrar el Teorema Fuerte, que dice que si los óptimos se alcanzan, entonces $z^* = w^*$. Por el Teorema Débil, ya sabemos que $z^* \geq w^*$. Supongamos que $z^* > w^*$. Entonces, el sistema

$$\begin{array}{rcl} c^T x & -b^T u & > 0 \\ Ax & & \geq b \\ & A^T u & \leq c \\ x & & \geq 0 \\ & u & \geq 0 \end{array}$$

es factible (las respectivas soluciones óptimas de P) y D) lo cumplen). En forma alternativa, podemos asegurar, bajo la hipótesis que estamos adoptando, que el sistema

$$\begin{array}{rcl} c^T x & -b^T u & = 0 \\ Ax & & \geq b \\ & -A^T u & \geq -c \\ x \geq 0 & u \geq 0 & \end{array}$$

es infactible. Esto implica que un sistema alternativo, dado por el Lema de Farkas, adecuado debe ser factible.

El sistema planteado acá es similar a la forma $By \geq d, y \geq 0$, cuyo sistema alternativo es $B^T w \leq 0, d^T w > 0, w \geq 0$, con la modificación de que la primera relación del sistema es de igualdad y no $\geq$. Esto significa que la variable alternativa (la primera componente de w) no tiene restricción de signo. Vamos, entonces, a definir variables (w^1, w^2, w^3) para el sistema alternativo. Asumiendo que $A \in \mathbb{R}^{m \times n}$, tendremos que $w^1 \in \mathbb{R}$, $w^2 \in \mathbb{R}^m$, $w^3 \in \mathbb{R}^n$. El sistema alternativo es, entonces:

$$\begin{array}{rclcl} w^1 c & + A^T w^2 & & \leq 0 \\ -w^1 b & & - A w^3 & \leq 0 \\ & b^T w^2 & - c^T w^3 & > 0 \\ & w^2 \geq 0 & w^3 \geq 0 & \end{array}$$

Este sistema, entonces, es factible. Notemos que, como w^1 no tiene restricción de signo, si es > 0 , podemos dejarlo en su valor y dividir por w^1 . En caso que sea < 0 , lo redefinimos a $-w^1$ y hacemos lo mismo. Esto significa, entonces, que el sistema

$$\begin{array}{rcl} A^T w^2 & \leq & c \\ A w^3 & \geq & b \\ b^T w^2 & > & c^T w^3 \\ w^2 \geq 0, w^3 \geq 0 & \end{array}$$

es factible. Pero esto significa que tendríamos un problema primal y un problema dual, ambos factibles, tales que $b^T w^2 > c^T w^3$, lo que contradice la dualidad débil. En consecuencia, nuestro supuesto inicial debe ser falso y esto muestra el resultado.

5.3.6. Demostración del Lema de Farkas


En esta subsección presentamos una demostración del Lema de Farkas, basada en conceptos geométricos. Vamos a considerar la siguiente forma del Lema de Farkas:

Lema de Farkas: Dados $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^n$, una y sólo una de las siguientes afirmaciones es verdadera:

- (I) El sistema $Ax = b, x \geq 0$ es factible
- (II) Existe u tal que $A^T u \leq 0, b^T u > 0$.

Suponga que I) es verdadero, vamos a mostrar que II) debe ser falsa. Vamos a proceder por contradicción, suponiendo que II) también es verdadera. Entonces, existe u tal que $A^T u \leq 0, b^T u > 0$. Como I) es verdadera, también existen $x \geq 0$ tal que $Ax = b$. Entonces, $x^T A^T u \leq 0$ (ya que el multiplicar por ≥ 0 no cambia la desigualdad). Pero $x^T A^T u = b^T u$, así que se tiene que $b^T u \leq 0$ lo que se contradice con el supuesto de que $b^T u > 0$. Se concluye, entonces, que el supuesto inicial no puede ser correcto y debe tenerse que II) es falsa.

Ahora asumamos que I) es falsa, vamos a deducir que II) debe ser verdadera. Para esto, vamos a usar un resultado fundamental en análisis convexo (y muy intuitivo, aunque no lo demostraremos ya que escapa de los alcances del curso) que dice lo siguiente: Sean K_1 y K_2 dos conjuntos convexos cerrados en $\mathbb{R}^n$. Supongamos que $K_1 \cap K_2 = \emptyset$. Entonces, existe un vector $u \in \mathbb{R}^n$ y un escalar α tales que $u^T x \leq \alpha, \forall x \in K_1$ y $u^T x > \alpha, \forall x \in K_2$. El conjunto $\{x : u^T x = \alpha\}$ se llama un “hiperplano separador”. En otras palabras, dos convexos que no se intersectan pueden ser separados por un hiperplano, como ilustran las figuras:



Acá se muestra un hiperplano que separa estrictamente ambos conjuntos

Acá la separación no es estricta, el hiperplano es “de apoyo” de uno de los conjuntos, pero igual es un “hiperplano separador”

(Nota: este es uno de los varios teoremas de separación que son corolario del Teorema de Hahn-Banach, un resultado fundamental en análisis funcional)

Ahora, volviendo a nuestra demostración del Lema de Farkas, estamos asumiendo que I) es falsa. Denotemos por $\beta_1, \beta_2, \dots, \beta_m$ los vectores correspondientes a las columnas de la matriz A . Sea $K_1 = \{y \in \mathbb{R}^m : y = Ax, x \geq 0\}$. Entonces, K_1 es un cono convexo generado por las columnas de A , es decir, $K_1 = \text{cone}(\beta_1, \beta_2, \dots, \beta_n)$. Esto se sigue del hecho que $Ax = \sum_{j=1}^n \beta_j x_j$ y de que $x_j \geq 0$. Entonces, K_1 es la envoltura cónica de los vectores $\beta_1, \dots, \beta_n$.

Ahora, sea $K_2 = \{b\}$, que es, obviamente un conjunto convexo. Tenemos que si I) es falsa, entonces $K_1 \cap K_2 = \emptyset$. Esto también es directo ya que si I) es falsa, entonces $Ax = b, x \geq 0$ es infactible. Es decir, $b \neq Ax = \sum_{j=1}^n \beta_j x_j$, para todo $x \geq 0$. Esto es lo mismo que decir que b no está contenido en K_1 . Luego $K_1 \cap K_2 = \emptyset$.

Finalmente, vamos a deducir que debe existir $u \in \mathbb{R}^m$ tal que $A^T u \leq 0, b^T u > 0$. En efecto, siguiendo con lo mostrado antes, tenemos que $K_1 \cap K_2 = \emptyset$. Como ambos son conjuntos convexos cerrados, tenemos, por el Teorema de Separación de Convexos, que existe un vector u tal que $u^T y \leq 0$, para todo $y \in K_1$ y $u^T y > 0$, para todo $y \in K_2$, pero esto último es simplemente $u^T b > 0$. En particular, como $y \in K_1$ tomemos los vectores $\beta_1, \dots, \beta_n$. Entonces, $u^T \beta_j \leq 0, j = 1, \dots, n$. Pero como los β_j son las columnas de A , esto no es más que decir que $u^T A \leq 0$. Entonces tenemos que existe u tal que $A^T u \leq 0, b^T u > 0$, que es, precisamente la afirmación II).

5.3.7. SIMPLEX Dual

A veces, el problema dual es tal que resulta más rápido de resolver que el primal, es por eso que algunos *softwares* como *Gurobi*, cuando el computador tiene más de un núcleo, lo que hacen es que en un núcleo ejecutan el primal y en el otro el dual, de modo que el que termine primero arroja el resultado final.

Sea el primal estándar y el dual respectivamente como:

$$\begin{array}{ll} \text{mín } c^T x & \text{máx } b^T u \\ P) \quad \text{s.a. } Ax = b & D) \quad \text{s.a. } A^T u \leq c \\ & x \geq 0 \end{array}$$

El dual se puede escribir en forma estándar añadiéndole las holguras:

$$\begin{aligned}
w^* &= \text{máx } b^T u \\
\text{s.a. } &A^T u + s = c \\
&s \geq 0
\end{aligned}$$

Si la matriz A es de $m \times n$, con $n > m$, entonces, en el problema dual, cuando se transpone la matriz A y se le añaden las holguras (matriz diagonal de $n \times n$), se pasa a tener una matriz al lado izquierdo con n filas y $m+n$ columnas (m de A^T y otras n de las holguras), de modo que queda una matriz de tamaño $n \times (m+n)$, lo que es mucho más grande y por lo tanto se podría pensar que es peor. Sin embargo, esta matriz es fácil de tratar en el SIMPLEX Dual con relativa facilidad como si fuera una matriz de $m \times m$.

Suponer una base no factible del primal ($x_B = B^{-1}b < 0$), pero con costos reducidos $\bar{c}_R \geq 0$, tal que:

$$\begin{aligned}
z &= \text{mín } c^T x \\
\text{s.a. } &Ax = b \\
&x \geq 0
\end{aligned}$$

Dado lo anterior, entonces en el dual la solución es factible:

$$\begin{aligned}
w &= \text{máx } b^T y \\
\text{s.a. } &A^T y \leq c \\
&y \quad \text{irrestric}ta
\end{aligned}$$

Y el dual con variables de holgura, queda:

$$\begin{aligned}
w &= \text{máx } b^T y + 0^T z \\
\text{s.a. } &A^T y + z = c \\
&y \quad \text{irrestric}ta \\
&z \geq 0
\end{aligned}$$

Donde, por el algoritmo SIMPLEX Dual, cuando agrego una columna en el dual, esta es no básica, por lo que su base sigue siendo factible ($z_B = 0$, pero $z_R = \bar{c}_R$). Es decir, busca primero la factibilidad en el dual (condición óptimalidad), para luego encontrarla en el primal.