



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
ICS2121 – MÉTODOS DE OPTIMIZACIÓN

Apuntes de Métodos de Optimización

*Por Francisco García Aubert y Jorge Vera Andreo
Material en desarrollo. No compartir fuera del curso.
(versión 7, Agosto 2025)*



Índice general

6. Optimización de gran tamaño	3
6.1. Generación de columnas	3
6.1.1. El algoritmo general	5
6.1.2. Multiple Pricing	7
6.1.3. Ejemplos	7
6.2. Descomposición de Dantzig-Wolfe	14
6.2.1. Ejemplo	19
6.3. Identificando Estructuras Complicantes	22
6.4. Descomposición de Benders	24
6.4.1. Ejemplos adicionales	29
6.5. Relación entre el método de Dantzig-Wolfe y Benders	44

Capítulo 6

Optimización de gran tamaño

En las aplicaciones reales de optimización muchas veces se presentan problemas con millones de variables y restricciones. Tal es el caso de modelos del área de la energía, especialmente si son bajo incertidumbre, en logística y otros, por ejemplo. Estos son los que llamaremos problemas de “gran tamaño”.

La existencia de problemas grandes no es nueva, por supuesto, lo que se entiende por “grande” es en relación a la capacidad de cómputo y almacenamiento. Antiguamente era especialmente más difícil el manejo de problemas de optimización con miles de variables, no era ni siquiera posible guardarlo en la memoria de los computadores. Tales problemas fueron formulados en la década de 1960, por ejemplo, para la industria petrolera y también en otras aplicaciones. Los expertos de esas épocas diseñaron enfoques para lidiar con esto y una idea que sirvió fue el usar la información del problema en forma “parcial pero inteligente”, lo que llevó al enfoque de Generación de Columnas. Otra idea fue descomponer un problema grande en partes más pequeñas y más manejables que luego se pudieran unir (en algún sentido), lo que lleva a los enfoques de descomposición de Dantzig-Wolfe y Benders. Posteriormente aparecieron enfoques de descomposición mediante dualidad.

Pero hoy un problema con varios millones de variables y restricciones requiere igual de estos enfoques especiales, con las modernizaciones adecuadas y ese será el tema de este capítulo.

6.1. Generación de columnas

El primer enfoque que estudiaremos busca utilizar de forma inteligente los datos del problema. Específicamente, si pensamos en un problema de Programación Lineal, habitualmente consideramos que tenemos “a la vista” los datos de las restricciones y la función objetivo. Veremos en esta sección que basta usar sólo los que se necesitan.

Motivación: problema de Cutting Stock (o corte de piezas)

Una compañía forestal tiene troncos de largo L que se deben cortar para obtener “trozas” de largos específicos. Hay m de largos $l_1, \dots, l_m$ y hay demandas por cada tipo de troza, $d_1, \dots, d_m$ para los distintos productos. Cada tronco es cortado de acuerdo a un “patrón de corte.”^{el} cual especifica el número de piezas de cada tipo que se cortan del tronco de largo L . Cada patrón de corte define una forma única de cortar el tronco y para el patrón de corte j vamos a llamar a_{ij} la cantidad de piezas (trozas) de tipo i que se obtienen usando ese patrón. Como los patrones se aplican a un tronco de largo L fijo, la cantidad de piezas debe ser tal que los largos combinados no superen L . Es decir:

$$\sum_{i=1}^m a_{ij} l_i \leq L, \quad \forall j = 1, \dots, n$$

Se busca determinar cuántos troncos usar con cada patrón de corte de modo tal de satisfacer la demanda, pero usando la menor cantidad de troncos posibles. Lo que se busca aquí es ser eficientes minimizando las pérdidas por recorte o “trim”. Sea x_j la cantidad de troncos cortados con el patrón de corte j . El modelo, para patrones a_{ij} válidos, consiste en minimizar la cantidad de troncos utilizados para satisfacer la demanda. Esto es:

$$\begin{aligned}
& \text{mín} \quad \sum_{j=1}^n x_j \\
& \text{s.a.} \quad \sum_{j=1}^n a_{ij} x_j \geq d_i, \quad \forall i = 1, \dots, m \\
& \quad \quad x_j \in \mathbb{Z}_0^+, \quad \forall j = 1, \dots, n
\end{aligned}$$

Para simplificar la complejidad que involucra el problema, al ser de programación entera, se puede aprovechar el hecho que los números son grandes y así relajar la restricción de integralidad, por lo que la restricción de que $x_j \in \mathbb{Z}_0^+$ se cambia por $x_j \geq 0, x_j \in \mathbb{R}$, convirtiéndose en un problema de programación Lineal que no es más que la relajación lineal del problema entero original. Si el problema es de tamaño muy grande, es muy marginal lo que si pierde de optimalidad haciendo esto. Además, dada cualquier solución con parte fraccionaria en una variables x_j , siempre podemos redondear al entero superior y obtendremos una solución factible. Tenemos, entonces, el siguiente problema:

$$\begin{aligned}
& \text{mín} \quad \sum_{j=1}^n x_j \\
& \text{s.a.} \quad \sum_{j=1}^n a_{ij} x_j \geq d_i, \quad \forall i = 1, \dots, m \\
& \quad \quad x_j \geq 0, \quad \forall j = 1, \dots, n
\end{aligned}$$

Sin embargo, es fácil darse cuenta que hay una cantidad combinatorialmente grande de posibles patrones de corte, lo que se podría traducir, en un caso real, que el problema tenga una cantidad enorme de variables, aunque el número de restricciones será pequeño. Lo que argumentaremos ahora es que no es necesario conocer en detalle todos los patrones de corte.

Para esto, necesitamos recordar lo que sucede en el algoritmo Simplex: Si conociéramos todas las columnas $A_1, \dots, A_n$ y estamos en una iteración de Simplex donde $B \in \mathbb{R}^{m \times m}$ es la base actual y π los multiplicadores actuales, luego para elegir que variable entra a la base, se deben calcular los costos reducidos de todas las $n - m$ columnas que no están en la base, para así encontrar el índice de la columna no básica con menor costo reducido $\bar{c}_j = c_j - \pi^T A_j < 0$ con $j \in I_N$ (donde I_N es el conjunto de índices no básicos.) Para el problema en cuestión, como $c_j = 1$, entonces lo que se busca es:

$$\text{mín}_{j \in I_N} \{1 - \pi^T A_j\} = 1 - \max_{j \in I_N} \left\{ \sum_{i=1}^m \pi_i a_{ij} \right\}$$

Recordemos que los número a_{ij} son los que describen el patrón y que puede ser una cantidad muy grande. Sin embargo, esos no son números cualquiera ya que cumplen ciertas condiciones, notablemente la relación

$$\sum_{i=1}^m a_{ij} l_i \leq L, \quad \forall j = 1, \dots, n$$

Consideremos, entonces, el siguiente problema de optimización:

$$\begin{aligned}
& \eta = \text{máx} \quad \sum_{i=1}^m \pi_i u_i \\
& \text{s.a.} \quad \sum_{i=1}^m u_i l_i \leq L \\
& \quad \quad u_i \in \mathbb{Z}_0^+, \quad \forall i = 1, \dots, m
\end{aligned}$$

Notemos que cualquier solución factible de este problema es una combinación de valores que define un patrón de corte válido y que la función objetivo es precisamente la parte del costo reducido que queremos maximizar. De este modo, si $1 - \eta < 0$, entonces entonces los números $u_1, \dots, u_m$ pueden usarse para definir

un patrón de corte, es decir, una de las columnas formadas por los coeficientes a_{ij} del problema, para algún j . Más aún, esa columna j entrega el menor costo reducido e identifica una nueva variable que puede entrar a la base de Programación Lineal. Pero, si $1 - \eta \geq 0$, se satisface el criterio de optimalidad de Simplex, pues no existen combinaciones de valores a_{ij} que definan patrones de cortes válidos y que, a su vez, identifiquen una columna para entrar a la base.

De este modo, se van generando las columnas a medida que se necesitan, y no es necesario conocer explícitamente todas las columnas o patrones de corte con anticipación ni guardarlas en memoria.

Desde una perspectiva económica, el problema satélite busca el patrón con mayor beneficio marginal para el problema maestro (reducción de costos, en este caso), usando para esto el valor que las distintas piezas aportan al objetivo final, información que está contenida en los π , que son los valores óptimos de las variables duales del problema considerando las columnas que existen hasta el momento. El patrón con mayor beneficio marginal es, entonces, el que se debe ingresar.

Cápsula de video 6.1.1: El problema de corte de piezas

Profesor Jorge Vera explica en clases el problema de corte de piezas o *Cutting Stock*, para introducir la técnica de Generación de Columnas
<https://youtu.be/hY05ktYyYEg>

Recapitulando

Todos esto es lo que se conoce como el método de “Generación de columnas” y fue desarrollado por Gilmore & Gomory en 1961. Este método se suele aplicar en problemas de gran tamaño (en el número de variables), como por ejemplo donde se tiene que encontrar la ruta más corta entre dos puntos y existen millones de rutas que los unan. El método es aplicable siempre que haya un “generador”, es decir, la estructura del problema permita caracterizar de alguna forma matemática las relaciones que existen entre los coeficientes de las columnas.

6.1.1. El algoritmo general

Comenzamos con un problema mín $\{c^T x : Ax = b, x \geq 0\}$, sin conocer explícitamente todas las columnas, pero sí sabemos que los coeficientes (c_j, A_j) pertenecen a un conjunto $D \subset \mathbb{R}^{m+1}$, cuya estructura conocemos (típicamente D corresponde a un conjunto de restricciones matemáticas). Notemos que acá estamos incluyendo los coeficientes de la función objetivo y, efectivamente, estos entran dentro de la generación, en general. En el ejemplo de motivación del problema de corte de piezas, esos coeficientes eran siempre igual a 1, pero eso no tiene que ser así, en general.

Si hemos generado una cantidad de columnas, digamos k , tenemos que hacer la operación de cálculo de los costos reducidos para las restantes columnas (las que están contenidas en D). Ahora bien, podemos considerar el problema:

$$\begin{aligned} \text{mín} \quad & \sum_{j \in J} c_j x_j \\ \text{s.a.} \quad & \sum_{j=1}^k A_j x_j = b \\ & x \geq 0 \end{aligned}$$

Este es el problema con las columnas generadas hasta el momento. Si se resuelve este problema con el Simplex, las variables duales π_i , $i = 1, \dots, m$ que se obtienen como solución dual óptima son precisamente los multiplicadores del Simplex que necesitamos para hacer el análisis de introducir una nueva columna A_{k+1} con costo reducido negativo (si existe). Al problema parcial, formado por las columnas generadas hasta el momento, lo llamaremos el Problema Maestro. La generación de la nueva columna se hace en el Problema Satélite.

Ahora presentamos el algoritmo general. Llamemos, J al conjunto de índices de las columnas que se van generando.

Algoritmo de Generación de columnas

Data: Comenzamos con unas pocas columnas $\{(c_j, A_j), j \in J\}$.

while *Criterio de parada no se satisface* **do:**

Resolvemos el “**Problema Maestro**” (master):

$$\begin{aligned} \text{mín} \quad & \sum_{j \in J} c_j x_j \\ \text{s.a.} \quad & \sum_{j \in J} A_j x_j = b \\ & x \geq 0 \end{aligned}$$

Sean π las variables duales óptimas del maestro (los multiplicadores del SIMPLEX).

Se hace el “pricing” de las demás columnas, para lo que se resuelve el “**Problema Satélite**”, que evalúa el costo reducido ($\bar{c}_j = c_j - \pi^T A_j$), y se quiere encontrar un coeficiente c_j y una columna A_j , contenidas en el conjunto D y tales que el costo reducido sea mínimo, para lo que se explora el conjunto D con el escalar u_0 (que juega el papel de c_j) y el vector u (que juega el papel de A_j):


$$\begin{aligned} \rho = \text{mín} \quad & u_0 - \pi^T u \\ \text{s.a.} \quad & (u_0, u) \in D \end{aligned}$$

Si $\rho \geq 0$, se ha llegado al óptimo, en caso contrario, la solución del satélite entrega una columna para agregar al maestro y el conjunto J crece en uno:

$$\begin{bmatrix} u_0 \\ u_1 \\ \vdots \\ u_m \end{bmatrix} = \begin{bmatrix} u_0 \\ u \end{bmatrix} \quad \text{que en el fondo corresponde a:} \quad \begin{bmatrix} c_j \\ A_{1j} \\ \vdots \\ A_{mj} \end{bmatrix}$$

end

Podemos interpretar esto como un *diálogo* entre el Maestro y el Satélite: el maestro envía información π al satélite, que indica “cuánto está dispuesto a pagar por algo nuevo” y este devuelve una columna, que sería “lo nuevo que se puede usar que más contribuye a mejorar la función objetivo”. Con esta nueva actividad, el maestro vuelva a evaluar los π y así sucesivamente. La figura ilustra este diálogo.



6.1.2. Multiple Pricing

En muchos casos, el problema satélite puede tener una estructura combinatorial compleja lo que hace lento resolverlo hasta el óptimo. Para solucionar este problema, se puede resolver de forma aproximada, basta con $(u_0, u) \in D$ cumplan que $u_0 - \pi^T u < 0$, es decir, que el costo reducido sea negativo, no necesariamente el más negativo. Si se implementa esto en forma eficiente es posible encontrar varias soluciones factibles al satélite y que tengan costo reducido negativo. Entonces, se agregan al maestro todas las columnas generadas con costos reducidos negativos y se resuelve ese maestro. Hacer esto es lo que se conoce como “Multiple Pricing” y es habitualmente muy usado en problemas de Generación de Columnas.

Cápsula de video 6.1.2: Generación de Columnas: el algoritmo general y un ejemplo computacional

Profesor Jorge Vera explica en clases el algoritmo general de Generación de Columnas y muestra un ejemplo computacional del problema de corte de piezas.
<https://youtu.be/YIENq5jweuQ>

6.1.3. Ejemplos

Problema de corte de piezas más general

Consideremos nuevamente el problema de corte de piezas pero al que hemos agregado algunas condiciones adicionales respecto a la forma en que se hacen los cortes, motivadas por la tecnología de corte. Estas son:

1. Existe un costo α por cada corte que se haga al tronco. Esto significa que si el tronco se corta 4 veces (para obtener 5 piezas), entonces hay un costo $c_j = 4\alpha$ asociado al patrón. Vamos a suponer que las piezas de sobre también se consideran útiles ya que pueden ser procesadas para generación de energía.
2. No es posible obtener más de 3 piezas de cada tipo cuando se ejecuta un patrón de corte.

Luego, se tiene que decidir cuántos troncos usar con cada patrón de corte de modo de *minimizar el costo total* (en vez de minimizar el número de troncos usados, como en el ejemplo inicial). Veamos cómo se desarrolla la Generación de Columnas.

El problema maestro es de la forma

$$\begin{aligned} \text{mín} \quad & \sum_{j \in J} c_j x_j \\ \text{s.a.} \quad & \sum_{j \in J} a_{ij} x_j \geq d_i, i = 1, \dots, m \\ & x_j \geq 0, j \in J \end{aligned}$$

donde J es el conjunto de índices de los patrones activos en este momento. Este problema viene de la relajación lineal del problema original, tal como se hizo en clases.

Este problema se resuelve y se obtienen las variables duales π . El satélite tiene que buscar un nuevo patrón de corte con menor costo reducido, que es

$$\bar{c}_j = c_j - \sum_{i=1}^m a_{ij}\pi_i$$

En este caso, el costo del patrón también tiene que ser generado ya que depende de cómo se corta el tronco.

bajo el supuesto de que todas las piezas se consideran útiles, podemos decir que el costo del corte es $c_j = \alpha(\sum_i a_{ij} - 1)$. Entonces, el satélite es de la forma:

$$\begin{aligned} \eta = \min \quad & \left\{ \alpha \left(\sum_{i=1}^m u_i - 1 \right) - \sum_{i=1}^m \pi_i u_i \right\} \\ \text{s.a.} \quad & \sum_{i=1}^m u_i l_i \leq L \\ & u_i \leq 3, i = 1, \dots, m \\ & u_i \geq 0, \text{ entero} \end{aligned}$$

(el término $-\alpha$ puede quedar fuera del problema, obviamente). Si $\eta < 0$, eso genera una columna que entra al problema y se agrega al maestro, y el método lo resuelve nuevamente. Y así sucesivamente.

Problema de la p-mediana

En este ejemplo consideramos el problema de “p-median”, que es una forma de problema de localización de instalaciones y asignación de clientes. Tenemos un conjunto de n entidades las cuales deben ser asignadas a una o más entidades especiales de entre ellas, llamadas “medianas” (“median”, en Inglés). Más específicamente, asumiremos que se conoce un costo d_{ij} que corresponde al costo de asignar la entidad i a la entidad j , la cual actúa como mediana. d_{jj} corresponde al costo de usar j como mediana. Cualquier entidad puede tomar el lugar de mediana y algunas de las otras deberán ser asociadas con ella, pero se debe hacer de modo que sea “costo eficiente”. Una condición del problema es que deben elegirse exactamente p entidades como medianas. Usemos la variable binaria $x_{ij} = 1$ si la entidad i es asociada a la mediana j , en particular $x_{jj} = 1$ significa que j es elegida como mediana. Hay una demanda (o carga de trabajo) q_i en la entidad i , y cada entidad, si es elegida como mediana, puede manejar una demanda total no mayor a Q (incluyendo la propia). El siguiente modelo encuentra la asignación de menor costo total:

$$\begin{aligned} \min \quad & \sum_{i \in N} \sum_{j \in N} d_{ij} x_{ij} \\ \text{s.a.} \quad & \sum_{j \in N} x_{ij} = 1, i \in N \\ & \sum_{j \in N} x_{jj} = p \\ & \sum_{i \in N} q_i x_{ij} \leq Q x_{jj}, j \in N \\ & x_{ij} \in \{0, 1\}, i \in N, j \in N \end{aligned}$$

Lo primero que observaremos es que este modelo efectivamente selecciona p entidades como medianas y asigna el total de las $n - p$ restantes a estas, excluyendo la posibilidad de que alguna entidad juegue el papel de mediana y cliente al mismo tiempo y, de este modo, el resultado es particionar $N = \{1, \dots, n\}$ en p subconjuntos, cada uno de los cuales tiene una entidad que hace el papel de mediana.

En efecto, las variables x_{jj} seleccionan la mediana y las otras asignan las restantes. Las primeras restricciones garantizan que cada entidad sólo puede jugar un papel, mediana o cliente. Las segundas restricciones garantizan que haya exactamente p medianas y las últimas restricciones garantizan el cumplimiento de la capacidad.

Las primeras restricciones, a su vez, dado que $\sum_{j \in N} x_{ij} = 1$, impiden que una misma entidad sea asignada a más de una mediana. De este modo, el conjunto de todas las entidades queda particionado en subconjuntos los cuales tienen una mediana y otras entidades asignadas a ella. La partición es en conjuntos disjuntos.

Pero ahora vamos a considerar la siguiente formulación alternativa al problema. Sean $S_1, S_2, \dots, S_K$ todos los subconjuntos de $N = \{1, \dots, n\}$ con dos o más elementos. Sea $A_k \in \mathbb{R}^n$ dado por

$$a_{ik} = \begin{cases} 1 & i \in S_k \\ 0 & \text{si no} \end{cases}$$

y sea

$$c_k = \min_{j \in S_k} \left(\sum_{i \in S_k} d_{ij} \right)$$

Usemos variables binarias $x_k = 1$ si se elige el conjunto k , y 0 si no, y consideremos el siguiente modelo de optimización:

$$\begin{aligned} \text{mín} \quad & \sum_{k=1}^K c_k x_k \\ \text{s.a.} \quad & \sum_{k=1}^K A_k x_k = 1 \\ & \sum_{k=1}^K x_k = p \\ & x_k \in \{0, 1\}, \quad k = 1, \dots, K \end{aligned}$$

Vamos a argumentar que este problema resuelve el problema de p-median en forma totalmente equivalente. Este último problema es una forma de “set partitioning”, como se conoce en optimización combinatorial. En efecto, Cada A_k es, simplemente, un vector indicador de los elementos del conjunto k . La estructura de esos conjuntos, y su correspondiente vector indicador, debe ser compatible con la descripción original del problema, es decir, deben cumplir con la capacidad. Esto significa que, si a_{ik} son los coeficientes de la columna k , entonces S_k debe ser tal que un índice de de S_k toma el papel de la mediana, digamos i_0 y los otros son los clientes asiados, y deberá cumplirse que

$$\sum_{i \in S} q_i \leq Q$$

De esta manera, las columnas A_k describen conjuntos válidos de entre todos los posibles subconjuntos de N . La primera restricción del modelo garantiza que toda entidad sea usada (de alguna forma, como cliente o como mediana) y la segunda restricción garantiza que p subconjuntos sean seleccionados, induciendo p medianas. Notemos también que el costo propuesto,

$$c_k = \min_{j \in S_k} \left(\sum_{i \in S_k} d_{ij} \right)$$

corresponde a seleccionar, de todas las posibles combinaciones en S_k , en donde una entidad toma el papel de mediana y las otras de clientes, la más barata.

Ahora bien, la formulación anterior podría tener un número exponencialmente grande de columnas, lo que lo hace un excelente candidato a ser abordado mediante Generación de Columnas. La generación de Columnas se aplica a la relajación lineal del problema:

$$\begin{aligned} \text{mín} \quad & \sum_{k=1}^K c_k x_k \\ \text{s.a.} \quad & \sum_{k=1}^K A_k x_k = 1 \\ & \sum_{k=1}^K x_k = p \\ & 0 \leq x_k \leq 1, \quad k = 1, \dots, K \end{aligned}$$

En una etapa cualquiera de la generación, tendremos el siguiente problema maestro:

$$\begin{aligned} \text{mín} \quad & \sum_{k \in J} c_k x_k \\ \text{s.a.} \quad & \sum_{k \in J} A_k x_k = 1 \\ & \sum_{k \in J} x_k = p \\ & 0 \leq x_k \leq 1, \quad k \in J \end{aligned}$$

donde J es una manera de denotar los conjuntos que han sido generados hasta el momento. Sea $\pi = (v, t)$, con $v \in \mathbb{R}^n$ y t escalar, el vector de variables duales óptimas en esta iteración del problema maestro. Estas variables las usaremos para el problema satélite, el cual debe generar un nuevo conjunto asociado a una columna de costo reducido negativo y que cumple con la estructura de tener una mediana y otras entidades asociadas respetando la capacidad. Consideremos el siguiente problema, inspirado en el problema original:

$$\begin{aligned} \text{mín} \quad & \sum_{i \in N} \sum_{j \in N} d_{ij} u_{ij} - \sum_{i \in N} \sum_{j \in N} v_i u_{ij} \\ \text{s.a.} \quad & \sum_{j \in N} u_{ij} \leq 1, \quad i \in N \\ & \sum_{j \in N} u_{jj} = 1 \\ & \sum_{i \in N} q_i u_{ij} \leq Q u_{jj}, \quad j \in N \\ & u_{ij} \in \{0, 1\}, \quad i \in N, j \in N \end{aligned}$$

Este problema determina la asignación, de entre las n entidades, de una como mediana (la que asigne la variables u_{jj} activada), y de algunas otras entidades de modo que el costo (notar que no pedimos que todas sean asignadas), que corresponde al balance entre el costo de asignación y el inducido por las variables duales, sea mínimo. Si $\eta - t$ es ≤ 0 , eso define una columna para agregar al maestro. Sea $\bar{u}$ la solución óptima de este problema. La nueva columna tiene un costo igual a

$$\sum_{i \in N} \sum_{j \in N} d_{ij} \bar{u}_{ij}$$

y el correspondiente conjunto S , que define los coeficientes de la columna A_k , quedan definidos por las variables $\bar{u}_{ij}$ activadas. Nótese que solo para un único índice i las variables u_{ij} se activarán en 1.

“Crew Scheduling” o Programación de Tripulaciones

Este es un problema clásico al cual se puede aplicar generación de columnas. Lo ilustramos aquí considerando la situación de una empresa del sector de los ferrocarriles de alta velocidad la que tiene trenes que conectan distintas ciudades. Cada tren tiene que tener asignada una tripulación de comando y control, las cuales deben cubrir los tramos y pernoctar en las ciudades de un día para otro. La empresa quiere determinar un esquema de asignación de tripulaciones a segmentos de viaje para una semana. Más en específico, supondremos que la empresa atiende un conjunto N de ciudades las cuales está conectadas por líneas de alta velocidad. Los viajes de trenes están descritos, entonces, por un conjunto de arcos dirigidos $A \subset N \times N$. Entonces, la red de viajes es el grafo (N, A) en donde cada arco es un segmento de viaje entre dos ciudades. Suponemos, para simplificar, que se hace sólo un viaje al día en un segmento y se repite todos los 7 días de la semana. Cada segmento debe estar cubierto por alguna tripulación en cada uno de los días de la semana.

Vamos a suponer que hay M tripulaciones disponibles en la empresa. Para cada tripulación podemos definir una serie de alternativas de “turno” o itinerario, que son opciones con las cuales pueden cubrir distintos segmentos de viaje. La forma en que se definen estas opciones de las tripulaciones debe seguir las siguientes reglas:

1. Cada tripulación, al inicio de la semana, parte en una ciudad conocida, denotamos esa ciudad por $s_k \in N$, para la tripulación $k = 1, \dots, M$. El itinerario de la tripulación puede terminar en una ciudad diferente.
2. Los segmentos que cubra una tripulación deben ser consecutivos en la red en días consecutivos y en cada día la tripulación debe estar asignada a un único segmento. De este modo, debe ocupar los 7 días de la semana en 7 segmentos (supondremos que hay muchos segmentos).
3. El costo de una opción específica de itinerario para la tripulación k se calcula en función de lo siguiente: si la tripulación es asignada al segmento $(i, j) \in A$, hay un costo c_{ij}^k . Notar que pueden repetirse ciudades.

Por ejemplo, sólo para ilustrar, una tripulación podría tener la siguiente secuencia de segmentos partiendo de la ciudad 3: (3, 1), (1, 2), (2, 4), (4, 5), (5, 8), (8, 11), (11, 4). Cada uno de esos siete segmentos se cubren desde el día 1 al día 7 y el costo total de esta opción es la suma de los costos de cada uno de esos 7 segmentos.

Vamos primero a formular el problema de optimización de “crew scheduling”, que encuentra la mezcla de opciones de itinerarios de tripulaciones de menor costo, tratando que cada segmento de viaje esté cubierto por una opción de tripulación en cada uno de los días. Adicionalmente, vamos a considerar la posibilidad de que algún segmento no logre ser cubierto en algún día y asuma que si el segmento (i, j) no puede recibir una opción de tripulación en algún día, entonces se incurre en un costo g_{ij} .

Para construir el modelo vamos a pensar que existen una cantidad de “segmentos” de viaje, que corresponden a un tramo de itinerario en un día específico de la semana. A cada uno de esos tramos y días (los segmentos) se deben, entonces, asignar las tripulaciones. Entonces, podemos pensar en las posibles formas que las tripulaciones podrían ser asignadas a lo largo de la semana, generando un gran conjunto de “opciones” las cuales pueden quedar, simplemente, caracterizadas por el siguiente coeficiente:

$$a_{ij} = \begin{cases} 1 & \text{si opción de tripulación } j \text{ puede cubrir segmento } i \\ 0 & \text{en caso contrario} \end{cases}$$

Sea c_j es el costo asociado a la opción j . Entonces, necesitamos definir variables de decisión binarias x_j , que valen 1 si la opción de tripulación j es elegida y 0 si no.

Ahora, es necesario tratar de cubrir los segmentos pero dejamos abierta la posibilidad de que no sea así, con el costo indicado. Para esto vamos a definir otra variable binaria, v_i , que vale 1 si el segmento no es cubierto, y 0 si lo es.

Con esto, el modelo que determina qué opciones seleccionar es el siguiente:

$$\begin{aligned} \text{mín} \quad & \sum_{j=1}^n c_j x_j + \sum_{i=1}^m g_i v_i \\ \text{s.a.} \quad & \sum_{j=1}^n a_{ij} x_j + v_i = 1, i = 1, \dots, m \\ & x_j \in \{0, 1\}, v_i \in \{0, 1\}, j = 1, \dots, n; i = 1, \dots, m \end{aligned}$$

Ahora explicamos cómo se desarrolla una procedimiento de Generación de Columnas para este problema.

El problema maestro corresponde a la relajación lineal de modelo que hemos planteado, pero en el que no se conocen todas las columnas. Así, las variables x serán continuas y tendremos un conjunto $J \subset \{1, \dots, n\}$ de columnas ya generadas. El problema es:

$$\begin{aligned} \text{mín} \quad & \sum_{j \in J} c_j x_j + \sum_{i=1}^m g_i v_i \\ \text{s.a.} \quad & \sum_{j \in J} a_{ij} x_j + v_i = 1, i = 1, \dots, m \\ & x_j \in \{0, 1\}, v_i \in \{0, 1\}, j \in J \end{aligned}$$

Para la construcción del problema satélite consideraremos las variables duales provenientes del maestro, $\pi_i, i = 1, \dots, m$. Acá recordemos que los segmentos corresponden a un viaje por el arco (p, q) en un día específico t , así que es conveniente aquí descomponer los bloques de las variables π según el índice (p, q) y el índice del tiempo, t . Entonces, tenemos las variables duales $\pi_{pq}^t, (p, q) \in A, t = 1, \dots, 7$.

El problema satélite debe, entonces, construir una opción de tripulación que respete las restricciones establecidas. Para esto, planteamos un problema de optimización entera, usando variables u_{pq}^t . Esta vale 1 si una tripulación va de la ciudad p a la ciudad q en el día t . En el problema satélite debemos evaluar el costo reducido del problema maestro. Vamos a plantear este problema satélite para cada una de las M tripulaciones. De este modo, el satélite determinará la opción de tripulación más conveniente para cada una de las tripulaciones y tendremos que seleccionar la de menor costo reducido. El problema es el siguiente:

$$\begin{aligned}
\eta^k &= \min \sum_{(p,q) \in A} c_{pq}^k u_{pq}^t - \sum_{(p,q)} \sum_{t=1}^t \pi_{p,q}^t \\
s.a. \quad &\sum_{q:(s_k,q) \in A} u_{(s_k,q)}^t = 1 \\
(1) \quad &u_{(p,q)}^t = \sum_{r:(q,r) \in A} u_{(q,r)}^{t+1} \quad (p,q) \in A, t = 1, \dots, 6 \\
(2) \quad &u_{(p,q)}^t \in \{0, 1\} \quad (p,q) \in A, t = 1, \dots, 7 \\
(3) \quad &
\end{aligned}$$

La función objetivo determina el costo reducido. El primer sumando es el costo de una ruta específica para la tripulación, la cual estará definida por las variables $u_{(p,1)}^t$, el segundo término corresponde a “ $\pi^T A_j$ ”, es decir, el “precio” de la columna que será generada. La restricción (1) establece que se comienza en el nodo s_k , la restricción (2) establece que la ruta que se construye avanza de un día a otro a un nodo diferente.

De este modo, si $\eta^k < 0$ para alguna de las tripulaciones, entonces los valores óptimos de las variables, llamémoslos $\hat{u}_{(p,q)}^t$ definen coeficientes a_{ij} adecuados para una nueva columna a agregar al problema maestro. Por otro lado, el costo de la nueva columna j es igual a $\sum_{(p,q) \in A} c_{pq}^k \hat{u}_{pq}^t$.

Asignación de trabajos a máquinas

En este ejemplo abordamos la siguiente situación, que se presenta frecuentemente en programación de operaciones en los más diversos ámbitos industriales. Tenemos que realizar n trabajos, los cuales se pueden hacer en cualesquiera de m máquinas. El trabajo j requiere de t_j horas para ser realizado (independientemente de la máquina en que se haga). Si se asignan algunos trabajos a una máquina, esta terminará de trabajar en un tiempo igual a la suma de los tiempos de los trabajos que se asignaron. Ese tiempo, que denotaremos γ_i , para la máquina i , se llama “tardanza” (tardiness, es el término que se usa en Inglés). Existen pesos $w_i > 0$ asociados a cada máquina y queremos encontrar una forma de asignar los trabajos a las distintas máquinas de modo tal que se minimice la “tardanza ponderada total” (total weighted tardiness), dada por $\sum_{i=1}^m w_i \gamma_i$. Adicionalmente, existe el requisito de que cada máquina debe trabajar un tiempo total mínimo de R_{min} horas. Notemos que, una vez asignados algunos trabajos a una máquina, da lo mismo el orden en que se hagan, la tardanza de esa máquina es la misma y la asignación es válida, mientras cumpla el mínimo de horas.

La siguiente figura muestra un ejemplo de 5 trabajos asignados a 2 máquinas (llamadas M1 y M2), con un tiempo mínimo de trabajo $R_{min} = 5$ horas, y con una tardanza ponderada total igual a 69.

$M_1, w_1 = 5$	$t_1 = 2,5$	$t_4 = 8,5$			$\gamma_1 = 11$
$M_2, w_2 = 2$	$t_2 = 2,0$	$t_3 = 2,0$	$t_5 = 3,0$		$\gamma_2 = 7$

Simplemente “a ojo” se puede ver que esa asignación se puede mejorar: basta cambiar el trabajo 1 a la máquina 2 y se tiene una nueva asignación que sigue cumpliendo el trabajo mínimo, y la tardanza ponderada disminuye a 61,5.

Podemos pensar este problema de la siguiente manera, en forma general: existen “opciones de asignación” de trabajos, las que identifican los trabajos que se le asignan a una máquina. Estas opciones, para cada máquina, las podemos describir con un coeficiente asociado a la opción k para la máquina i :

$$a_{jk}^i = \begin{cases} 1 & \text{si en la opción } k \text{ de la máquina } i \text{ el trabajo } j \text{ se asigna a la máquina} \\ 0 & \text{si no} \end{cases}$$

Asumiendo que la opción cumpla con el requisito de tiempo mínimo, estos coeficientes describen completamente las posibles opciones válidas de asignar trabajos a las máquinas. En el ejemplo, digamos que la opción 1 es la

que se está usando en la máquina 1 y, entonces, estará dada por $a_{11}^1 = 1, a_{21}^1 = 0, a_{31}^1 = 0, a_{41}^1 = 1, a_{51}^1 = 0$, indicando que, para la máquina 1, opción 1, los trabajos 1 y 4 se asignan a esa máquina y los otros no. Otras opciones tendrán valores diferentes, pero todas deben cumplir con el tiempo mínimo de trabajo.

De este modo, podemos ahora definir la “tardanza de la opción k para la máquina i ”, y que denotaremos por γ_{ki} , como $\gamma_{ki} = \sum_{j=1}^n a_{jk}^i t_j$.

Notemos también que la cantidad posible de opciones para una máquina particular puede ser muy grande (a lo más, pueden llegar a ser 2^n). Llamaremos r al número total de opciones válidas posibles para una máquina. Como las máquinas son idénticas, hay la misma cantidad de opciones para cada máquina.

Podemos formular el problema de decidir qué opción de asignación usar para cada máquina de modo tal de minimizar la tardanza ponderada total y garantizar que todos los trabajos son realizados, como un problema de Programación Lineal Entera. Sea y_{ki} es una variable binaria que vale 1 si se usa la opción k de la máquina i , y 0 si no. El siguiente modelo representa la situación:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m \sum_{k=1}^r w_i \gamma_{ki} y_{ki} \\ & \sum_{i=1}^m \sum_{k=1}^r a_{jk}^i y_{ki} = 1, \quad j = 1, \dots, n \quad (1) \\ & \sum_{k=1}^r y_{ki} = 1, \quad i = 1, \dots, m \quad (2) \\ & y_{ki} \in \{0, 1\}, \quad i = 1, \dots, m; k = 1, \dots, r \end{aligned}$$

En efecto, en primer lugar, la función objetivo minimiza la tardanza ponderada total. A continuación, la restricción (1) asegura que cada trabajo sea realizado por una única máquina. Finalmente, la restricción (2) asegura que en cada máquina se utilice una única opción. De esta manera, el problema minimiza la tardanza ponderada total garantizando que todos los trabajos sean realizados.

Por otro lado, notemos que para que una opción k sea válida, se debe cumplir que todas las máquinas bajo la opción k cumplan con el tiempo de trabajo total mínimo R_{min} . Para ello, los coeficientes a_{jk}^i deben cumplir con la siguiente condición:

$$\gamma_{ki} = \sum_{j=1}^n a_{jk}^i t_j \geq R_{min}, \quad \forall i = 1, \dots, m; \quad \forall k = 1, \dots, r$$

Ahora mostramos cómo abordar el problema anterior mediante Generación de Columnas. El problema maestro es:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m \sum_{k \in \bar{R}_i} w_i \gamma_{ki} y_{ki} \\ & \sum_{i=1}^m \sum_{k \in \bar{R}_i} a_{jk}^i y_{ki} = 1, \quad j = 1, \dots, n \quad (\pi_j) \\ & \sum_{k \in \bar{R}_i} y_{ki} = 1, \quad i = 1, \dots, m \quad (\nu_i) \\ & 0 \leq y_{ki} \leq 1, \quad i = 1, \dots, m; \quad k \in \bar{R}_i \end{aligned}$$

Donde $\bar{R}_i \subseteq \{1, \dots, r\}$ para todo $i \in \{1, \dots, m\}$ (lo anterior es equivalente a tomar subconjuntos $i' = \{1, \dots, m'\}$ y $k' = \{1, \dots, r'\}$). A partir del problema maestro se obtienen los costos reducidos, y con estos se construye el problema satélite:

$$\begin{aligned} \bar{C}_{ki} &= w_i \gamma_{ki} - \sum_{j=1}^n \pi_j a_{jk}^i - \nu_i \\ &= \sum_{j=1}^n w_i a_{jk}^i t_j - \sum_{j=1}^n \pi_j a_{jk}^i - \nu_i \end{aligned}$$

Podemos definir el siguiente problema satélite:

$$\begin{aligned} \eta_i = \min \quad & \sum_{j=1}^n w_i u_j t_j - \sum_{j=1}^n \pi_j u_j - \nu_i \\ & \sum_{j=1}^n u_j t_j \geq R_{min} \\ & u_j \in \{0, 1\}, \quad j = 1, \dots, n \end{aligned}$$

La interacción entre el problema maestro y el problema satélite se da de la siguiente manera: se resuelve el problema maestro, el cual envía información (π, ν) al problema satélite. Sea $\bar{\eta} = \min_{i=1, \dots, m} \{\eta_i\}$ el problema satélite con el menor costo reducido dado (π, ν) , entonces:

- si $\bar{\eta} \geq 0 \rightarrow$ se ha llegado al óptimo
- si $\bar{\eta} < 0 \rightarrow$ la solución del problema satélite entrega una nueva columna para agregar al problema maestro

Si el problema maestro recibe una nueva columna, entonces este se vuelve a resolver y así sucesivamente. Finalmente, observando la forma del problema satélite, se concluye que es un problema de la mochila, el cual es medianamente fácil de resolver con programación dinámica.

Notemos, también, que en la implementación de Generación de Columnas para este problema, hay una forma natural de hacer “Multiple Pricing”. En efecto, notemos que se debe resolver el problema maestro y tomar la información (π, ν) enviada, la cual debe ser evaluada en todos los problemas satélites $i = 1, \dots, m$. Una vez evaluados todos los problemas satélites, se deben tomar todos aquellos en que $\eta_i < 0$, obteniendo así todas las columnas generadas con costos reducidos negativos, para posteriormente agregarlas al problema maestro y volver a resolverlo, repitiendo el proceso sucesivamente.

6.2. Descomposición de Dantzig-Wolfe

Muchos problemas de optimización son de gran tamaño, con muchas variables y restricciones. La generación de Columnas, como hemos visto, permite abordar un problema con muchas columnas pero hay otros que presentan gran tamaño por todas partes. Sin embargo, a veces esos problemas tienen una estructura muy especial. Identificar esa estructura para desarrollar una forma de resolver el problema es lo que ilustraremos ahora con una técnica que fue originalmente desarrollada en los años 1960, pero que sigue 100 % vigente hoy. Más aún, el desarrollo que mostraremos es una buena aplicación de los conceptos de geometría poliedral y hace uso de la técnica de Generación de Columnas de la sección anterior. Vamos a partir, eso sí, motivando la estructura que consideraremos y luego iremos a los detalles.

Motivación: problema de flujos multiproducto (multicommodity flow problem)

Consideremos la situación de una red logística en donde hay una cantidad de bodegas que manejan distintos productos. Para cada producto existen ofertas y demandas en cada una de las bodegas y existen costos de transporte. Esto es como un problema de optimización de flujos entre distintos lugares y a costo mínimo, pero hay una condición adicional: existe un límite de capacidad total a lo que se puede transportar entre un lugar y otro. Este es el problema que queremos modelar.

El problema se puede representar mediante un grafo dirigido $G = (N, A)$, con N el conjunto de nodos y A el conjunto de arcos. Sea el conjunto K los pares de nodos de origen-destino: $\{o_k = (r_k, s_k) : r_k \in N, s_k \in N, \forall k \in K\}$, donde cada par $k \in K$ posee una demanda de flujo d_k . Por otro lado, cada arco $(i, j) \in A$ posee una capacidad u_{ij} , un costo de $c_{ij}^k, k \in K$. Sea x_{ij}^k la variable de la cantidad transportada entre el arco (i, j) para el par $k \in K$. Ver Figura 6.1.

El modelo de optimización que minimiza los costos para este problema es:




Figura 6.1: Grafo multicommodity

$$\begin{aligned}
 \text{mín} \quad & \sum_{k \in K} \sum_{(i,j) \in A} c_{ij}^k x_{ij}^k \\
 \text{s.a.} \quad & \sum_{j: (i,j) \in A} x_{ij}^k - \sum_{p: (p,i) \in A} x_{pi}^k = b_i^k, \quad \forall i \in N, k \in K \quad (1) \\
 & \sum_{k \in K} x_{ij}^k \leq u_{ij}, \quad \forall (i,j) \in A \quad (2) \\
 & x_{ij}^k \geq 0, \quad \forall (i,j) \in A, k \in K \quad (3)
 \end{aligned}$$

Donde (1), que va para cada par origen-destino k , dice que lo que sale de un nodo i , menos lo que entra es igual a su balance b_i^k (que es nulo cuando no es de origen ni de destino) de ese nodo:

$$b_i^k = \begin{cases} d_k, & i = r_k \\ -d_k, & i = s_k \\ 0, & \text{e.o.c.} \end{cases}$$

(2) dice que en cada arco, la suma de los flujos para cada par origen-destino k , debe respetar su capacidad máxima. El modelo se puede reescribir de forma alternativa, pasando (2) para arriba y expandiendo la sumatoria para el índice k . Además se ordena (1) de tal modo que **cada columna que se visualiza está asociada a un índice de un par $k \in K$** :

$$\begin{aligned}
\text{mín} \quad & \sum_{(i,j) \in A} c_{ij}^1 x_{ij}^1 + \sum_{(i,j) \in A} c_{ij}^2 x_{ij}^2 + \dots + \sum_{(i,j) \in A} c_{ij}^K x_{ij}^K \\
\text{s.a.} \quad & x_{ij}^1 + x_{ij}^2 + \dots + x_{ij}^K \leq u_{ij}, \forall (i,j) \in A \\
& \sum_{j:(i,j) \in A} x_{ij}^1 - \sum_{p:(p,i) \in A} x_{pi}^1 = b_i^1, \forall i \in N \\
& \sum_{j:(i,j) \in A} x_{ij}^2 - \sum_{p:(p,i) \in A} x_{pi}^2 = b_i^2, \forall i \in N \\
& \vdots \\
& \sum_{j:(i,j) \in A} x_{ij}^K - \sum_{p:(p,i) \in A} x_{pi}^K = b_i^K, \forall i \in N \\
& \underbrace{x_{ij}^1 \geq 0, \forall (i,j) \in A,}_{\text{columnas para } k=1} \quad \underbrace{x_{ij}^2 \geq 0, \forall (i,j) \in A,}_{\text{columnas para } k=2} \quad \dots \quad \underbrace{x_{ij}^K \geq 0, \forall (i,j) \in A}_{\text{columnas para } k=K}
\end{aligned}$$

En este modelo, se puede visualizar claramente una estructura muy especial. En la primera fila de la matriz que se ve, todos los pares de orígenes destinos están mezclados (restricciones comunes para todos los pares origen destino), mientras que en las otras restricciones, cada par $k \in K$ va en un bloque, de modo que no hay interacciones entre dos pares distintos (actúan como independientes). Llevando esto mismo a una estructura más genérica, con K bloques independientes y otra parte de restricciones comunes, tenemos un problema lineal con la siguiente estructura (Problema Dantzig-Wolfe):

$$\begin{aligned}
\text{mín} \quad & c_1^T x^1 + \dots + c_K^T x^K \\
\text{s.a.} \quad & A_1 x^1 + \dots + A_K x^K = b \\
& D_1 x^1 = d_1 \\
& \vdots \quad \ddots \quad \vdots \quad \vdots \\
& D_K x^K = d_K \\
& x_1 \geq 0, \quad \dots, \quad x_K \geq 0
\end{aligned}$$

donde $A_k \in R^{m \times n_k}$, $b \in R^m$, $D_k \in R^{p_k \times n_k}$, $d_k \in R^{p_k}$ y $\{c_k, x_k\} \in R^{n_k}$, $k \in K$.

En forma más gráfica, la forma en que se distribuyen los coeficientes del problema puede ser vista como esto:




Figura 6.2: Estructura de Problema para Descomposición de Dantzig-Wolfe

El gran problema aquí son las restricciones comunes, que impiden que se pueda tratar el problema multiproducto como K problemas de flujo a costo mínimo por separado. La capacidad en los arcos, que es común a todos

los flujos de todos los pares origen-destino es lo que genera el problema. A estas restricciones comunes está asociada la matriz A corresponde a las denominadas “restricciones complicantes”.

Vamos a abordar este problema transformándolo en otro equivalente mediante un **cambio de variable**. Esto lo vamos a hacer representando los poliedros asociados a cada bloque de una forma alternativa: no vamos a usar las desigualdades, es decir la representación algebraica, sino que la representación puntual.

Consideremos los poliedros $P_k = \{x \in \mathbb{R}^{n_k} : D_k x = d_k, x \geq 0\}$, que son los poliedros asociados a las restricciones de los bloques. Como sabemos, el poliedro P_k tiene puntos extremos $v^{k1}, \dots, v^{kr_k}$ y rayos extremos $u^{k1}, \dots, u^{kp_k}$. Entonces por el teorema de representación de Minkowski-Weil-Motzkin, si $x \in P_k$, entonces existen $\lambda_{k1}, \dots, \lambda_{kr_k}$ y $\mu_{k1}, \dots, \mu_{kp_k}$, tales que $0 \leq \lambda_{ki} \leq 1, \forall i = 1, \dots, r_k, \mu_{kj} \geq 0, j = 1, \dots, p_k$ y que x se puede escribir la combinación convexa de los vértices del polígono más la combinación cónica de los rayos:

$$x = \sum_{i=1}^{r_k} \lambda_{ki} v^{ki} + \sum_{j=1}^{p_k} \mu_{kj} u^{kj}, \quad \sum_{i=1}^{r_k} \lambda_{ki} = 1$$

Para simplificar el resto de la presentación, vamos a asumir que los poliedros P_k son acotados. De este modo, no hay que considerar los rayos. Entonces, si $x^k \in P_k$, tenemos que:

$$x^k = \sum_{i=1}^{r_k} \lambda_{ki} v^{ki}, \quad \sum_{i=1}^{r_k} \lambda_{ki} = 1$$

Ahora vamos a reemplazar esta escritura de x^k en el problema de optimización, de modo que ya no se trabaje con las variables x , sino las λ_{ki} :

$$\begin{aligned} A_k x^k &= A_k \sum_{i=1}^{r_k} \lambda_{ki} v^{ki} = \sum_{i=1}^{r_k} \lambda_{ki} (A_k v^{ki}), \quad \sum_{i=1}^{r_k} \lambda_{ki} = 1 \\ c_k^T x^k &= c_k^T \sum_{i=1}^{r_k} \lambda_{ki} v^{ki} = \sum_{i=1}^{r_k} \lambda_{ki} (c_k^T v^{ki}), \quad \sum_{i=1}^{r_k} \lambda_{ki} = 1 \end{aligned}$$

De este modo, el problema de optimización queda así (con las variables duales de cada conjunto de restricciones, o multiplicadores del Simplex, a la derecha):

$$\begin{array}{llllllll} \text{mín} & \sum_{i=1}^{r_1} \lambda_{1i} (c_1^1 v^{1i}) & + & \sum_{i=1}^{r_2} \lambda_{2i} (c_2^1 v^{12}) & + \dots + & \sum_{i=1}^{r_K} \lambda_{Ki} (c_K^T v^{Ki}) & & \\ \text{s.a.} & \sum_{i=1}^{r_1} \lambda_{1i} (A_1 v^{1i}) & + & \sum_{i=1}^{r_2} \lambda_{2i} (A_2 v^{12}) & + \dots + & \sum_{i=1}^{r_K} \lambda_{Ki} (A_K v^{Ki}) & = & b \quad (\pi) \\ & \sum_{i=1}^{r_1} \lambda_{1i} & & & & & = & 1 \quad (t_1) \\ & & & \sum_{i=1}^{r_2} \lambda_{2i} & & & = & 1 \quad (t_2) \\ & & & & & \ddots & & \vdots \\ & & & & & & \sum_{i=1}^{r_K} \lambda_{Ki} & = & 1 \quad (t_K) \\ & 0 \leq \lambda_{1i} \leq 1, i = 1, \dots, r_1, & & 0 \leq \lambda_{2i} \leq 1, i = 1, \dots, r_2, & \dots, & 0 \leq \lambda_{Ki} \leq 1, i = 1, \dots, r_K & & \end{array}$$

Notemos que este problema ahora está escrito en las variables λ . Si bien sigue teniendo la misma estructura de bloques que el problema original, hay una gran diferencia: cada bloque k tiene solo una restricción. Las restricciones comunes sí siguen siendo la misma cantidad inicial. Escrito en forma más compacta, el problema es:

$$\begin{aligned}
\text{mín} \quad & \sum_{k=1}^K \left\{ \sum_{i=1}^{r_k} \lambda_{ki} (c_k^T v^{ki}) \right\} \\
\text{s.a.} \quad & \sum_{k=1}^K \left\{ \sum_{i=1}^{r_k} \lambda_{ki} (A_k v^{ki}) \right\} = b \quad (\pi) \\
& \sum_{i=1}^{r_k} \lambda_{ki} = 1 \quad \forall k = 1, \dots, K \quad (t_k) \\
& \lambda_{ki} \geq 0 \quad \forall k = 1, \dots, K; i = 1, \dots, r_k
\end{aligned}$$

Este problema de optimización tiene $m+K$ restricciones o filas (pocas) y $\sum_k r_k$ variables o columnas, que son muchísimas dado que hay una por cada vértice de cada poliedro P_k . Desde luego, no conocemos esos vértices pero sí conocemos su estructura: son vértices de un poliedro cuyas restricciones lineales conocemos. Esto sugiere que deberíamos poder usar el enfoque de Generación de Columnas de la sección anterior. Generar columnas para este problema equivale a encontrar los vértices que generaron las columnas de este problema (recordemos que cada columna tiene una parte que es de la forma $A_k v^{ki}$).

Para las primeras m restricciones se tiene asociada una variable dual π , y para las siguientes $k \in K$ una variable t_k para cada una de ellas. La operación de Pricing calcula el vector de costos reducidos de la columna del punto extremo (k, i) como:

$$\bar{c}_{ik} = (c_k^T v^{ki}) - \pi^T (A_k v^{ki}) - t_k$$

Para encontrar un candidato a entrar a la base se resuelven los K problemas (uno por bloque) de Pricing buscando el valor objetivo más negativo por bloque $k = 1, \dots, K$ de los siguientes problemas:

$$\begin{aligned}
\eta_k = \text{mín} \quad & (c_k^T u) - \pi^T (A_k u) \\
\text{s.a.} \quad & u \text{ punto extremo de } P_k
\end{aligned}$$

Notemos que la función objetivo se puede reescribir como $(c_k - A_k^T \pi)^T u$. Entonces, el problema consiste en encontrar un punto extremo de un poliedro que alcance el mejor valor de una función lineal. Eso no es más que un problema de Programación Lineal sobre las restricciones que definen el poliedro, que son $D_k u = d_k, u \geq 0$. De este modo, lo que queremos resolver son los problemas:

$$\begin{aligned}
\eta_k = \text{mín} \quad & c_k^T u - \pi^T A_k u \\
\text{s.a.} \quad & D_k u = d_k \\
& u \geq 0
\end{aligned}
\quad \Longleftrightarrow \quad
\begin{aligned}
\eta_k = \text{mín} \quad & (c_k - A_k^T \pi)^T u \\
\text{s.a.} \quad & D_k u = d_k \\
& u \geq 0
\end{aligned}$$

Entonces, si para algún k tenemos que $\eta_k - t_k < 0$ y este problema alcanza el óptimo en el vértice v^{kj} , entonces ese vértice v^{kj} permite reconstruir una columna para el problema maestro que conviene hacer entrar a la base. Esa columna es de la forma:

$$\begin{bmatrix} A_k v^{kj} \\ 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix}$$

donde el 1 va en la posición k del vector de K componentes que va debajo de $A_k v^{kj}$. En coeficiente en la función objetivo de esta columna es, por otro lado, $c_k^T v^{kj}$. Notar, entonces, que buscar columnas para entrar a la base es lo mismo que buscar vértices que engendren columnas para entrar a la base.

También podemos notar que esta descomposición es especialmente apropiada para usar “Multiple Pricing”. En efecto, podemos tomar todas las columnas que resulten con costo reducido negativo mínimo de cada bloque y agregarlas todas al problema maestro.

Es posible dar una interpretación económica interesante a la forma en que la Descomposición de Dantzig-Wolfe aborda el problema. En efecto, si miramos nuevamente el problema satélite:

$$\begin{aligned} \eta_k = \min \quad & (c_k - A_k^T \pi)^T u \\ \text{s.a.} \quad & D_k u = d_k \\ & u \geq 0 \end{aligned}$$

notamos que es “casi” lo mismo que haber resuelto en forma independiente cada problema de cada bloque, sólo que la función objetivo es diferente: si cada bloque actuara en forma independiente, sin tomar en cuenta las restricciones comunes, la función objetivo a considerar sería simplemente $c_k^T u$. Si embargo, la que se está usando en cada iteración de la descomposición es $(c_k - A_k^T \pi)^T u$. El término adicional, que involucra las variables duales, está entregando información del “costo” que el problema del bloque debe compensar para el problema completo, si se toman en cuenta las restricciones comunes.

Cápsula de video 6.2.1: Descomposición de Dantzig-Wolfe

Profesor Jorge Vera explica en clases la Descomposición de Dantzig-Wolfe
<https://youtu.be/t94XbRBvox8>

6.2.1. Ejemplo

En este problema consideramos una variante del problema de flujo multiproducto que fue presentado antes, al motivar la descomposición de Dantzig-Wolfe. La variación es que existen dos alternativas tecnológicas diferentes para el transporte (por ejemplo, camiones normales o camiones eléctricos autónomos) y hay que decidir el número de unidades de cada una de esas tecnologías a usar.

Como en el problema original, tenemos una red dirigida (N, A) para representar el problema. Hay K pares de nodos que representan distintos orígenes-destinos y sea $o_k = (r_k, s_k)$ el par origen-destino k , $r_k \in N, s_k \in N$. Para cada par k hay una demanda de flujo, d_k que requiere ser transportada de r_k a s_k . Un vehículo de la tecnología de transporte t , $t = 1, 2$, tiene una capacidad igual a C_t . Por otro lado, cada arco (i, j) puede aceptar un máximo de U_{ijt} unidades de la tecnología t , pero no pueden mezclarse distintas tecnologías de transporte en un mismo arco. Para cada arco (i, j) hay un costo unitario c_{ijt}^k para el flujo correspondiente al par k con la tecnología t . Tenemos, también, un costo f_{ijt} por cada unidad de la tecnología t que se use en el arco (i, j) .

Para el modelo se usa una variable x_{ijt}^k , correspondiente al flujo en (i, j) asociado al par k y con la tecnología t , una variable y_{ijt} correspondiente al número de unidades de la tecnología t asignadas al arco (i, j) , y una variable auxiliar z_{ijt} que vale 1 si la tecnología t es usada en el arco (i, j) . El modelo es el siguiente:

$$\begin{aligned} \min \quad & \sum_{t=1}^2 \sum_{(i,j) \in A} \left(f_{ijt} y_{ijt} + \sum_{k \in K} c_{ijt}^k x_{ijt}^k \right) \\ \text{s.a.} \quad & \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k, i \in N, k = 1, \dots, K \\ & \sum_{k=1}^K x_{ijt}^k \leq C_t y_{ijt}, \forall (i, j) \in A, t = 1, 2 \\ & y_{ijt} \leq U_{ijt} z_{ijt}, \forall (i, j) \in A, t = 1, 2 \\ & z_{ij1} + z_{ij2} \leq 1, \forall (i, j) \in A \\ & x_{ijt}^k \geq 0, y_{ijt} \in \mathbb{Z}, z_{ijt} \in \{0, 1\}, \forall (i, j) \in A, k = 1, \dots, K, t = 1, 2 \end{aligned}$$

donde

$$b_i^k = \begin{cases} d_k, & i = r_k \\ -d_k, & i = s_k \\ 0 & \text{si no} \end{cases}$$

En primer lugar, dado que el problema es de Programación Entera Mixta, vamos a considerar la relajación

lineal para aplicar la descomposición. Entonces, el problema a considerar es:

$$\begin{aligned}
& \min \sum_{t=1}^2 \sum_{(i,j) \in A} \left(f_{ijt} y_{ijt} + \sum_{k \in K} c_{ijt}^k x_{ijt}^k \right) \\
& s.a. \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k, i \in N, k = 1, \dots, K \\
& \sum_{k=1}^K x_{ijt}^k \leq C_t y_{ijt}, \forall (i,j) \in A, t = 1, 2 \\
& y_{ijt} \leq U_{ijt} z_{ijt}, \forall (i,j) \in A, t = 1, 2 \\
& z_{ij1} + z_{ij2} \leq 1, \forall (i,j) \in A \\
& x_{ijt}^k \geq 0, y_{ijt} \geq 0, 0 \leq z_{ijt} \leq 1, \forall (i,j) \in A, k = 1, \dots, K, t = 1, 2
\end{aligned}$$

Podemos ver que las restricciones

$$\sum_{k=1}^K x_{ijt}^k \leq C_t y_{ijt}$$

“complican” la estructura. De hecho, si no existieran, permitirían que el problema se separara en K problemas por bloques y, además, otro problema independiente para las variables z e y . Vamos a escribir el problema en forma reordenada:

$$\begin{aligned}
& \min \sum_{t=1}^2 \sum_{(i,j) \in A} f_{ijt} y_{ijt} + \sum_{k \in K} \sum_{t=1}^2 \sum_{(i,j) \in A} c_{ijt}^k x_{ijt}^k \\
& s.a. \sum_{k=1}^K x_{ijt}^k \leq C_t y_{ijt} \quad \forall (i,j) \in A, t = 1, 2 \\
& y_{ijt} \leq U_{ijt} z_{ijt} \quad \forall (i,j) \in A, t = 1, 2 \\
& z_{ij1} + z_{ij2} \leq 1 \quad \forall (i,j) \in A \\
& \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k \quad i \in N, k = 1, \dots, K \\
& y_{ijt} \geq 0, 0 \leq z_{ijt} \leq 1 \quad x_{ijt}^k \geq 0 \quad \forall (i,j) \in A, k = 1, \dots, K, t = 1, 2
\end{aligned}$$

Y ahora hacemos más explícita la suma en K , descartando las especificaciones de los rangos de los índices, por razones de espacio:

$$\begin{aligned}
& \min \sum_{t=1}^2 \sum_{(i,j) \in A} f_{ijt} y_{ijt} + \sum_{t=1}^2 \sum_{(i,j) \in A} c_{ijt}^1 x_{ijt}^1 + \dots + \sum_{t=1}^2 \sum_{(i,j) \in A} c_{ijt}^K x_{ijt}^K \\
& s.a. -C_t y_{ijt} + x_{ijt}^1 + \dots + x_{ijt}^K \leq 0 \\
& y_{ijt} - U_{ijt} z_{ijt} \leq 0 \\
& z_{ij1} + z_{ij2} \leq 1 \\
& \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k \\
& \vdots \\
& \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k \\
& y_{ijt} \geq 0, 0 \leq z_{ijt} \leq 1 \quad x_{ijt}^k \geq 0
\end{aligned}$$

Acá se puede ver claramente la estructura de bloques, la que destacamos en el siguiente diagrama:

y los $t_1, \dots, t_K$ son las variables duales de las restricciones

$$\sum_{l=1}^{r_k} \lambda_{lk} = 1$$

para cada bloque. El problema satélite del bloque k es, entonces:

$$\begin{aligned} \min \quad & \sum_{t=1}^2 \sum_{(i,j) \in A} (c_{ijt}^k - \pi_{ijt}) x_{ijt}^k \\ \text{s.a.} \quad & \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k, \quad i \in N, k = 1, \dots, K \\ & x_{ijt}^k \geq 0, \quad \forall (i,j) \in A, k = 1, \dots, K, t = 1, 2 \end{aligned}$$

Notar que aquí los coeficientes de la columna a considerar del problema maestro tienen coeficientes = 1, por la estructura, así que basta seguir el orden de los índices (i, j, t) .

6.3. Identificando Estructuras Complicantes

Uno de los temas centrales en los enfoques de descomposición es la identificación de estructuras complicantes. En el caso del problema de Flujo Multiproducto de la sección anterior, con el que motivamos la Descomposición de Dantzig-Wolfe, las restricciones de capacidad en los arcos son “complicantes”: impiden que el problema sea más fácil. En efecto, si no existieran, podríamos resolver cada problema de flujo, para cada par origen-destino, por separado. Lo mismo ocurriría en el ejemplo detallado de la sección anterior. Pero hay otras formas en que pueden presentarse estructuras complicantes y ese es el tema de esta sección, que nos llevará a otro método de descomposición, también muy importante en Optimización de gran tamaño.

Tomemos otro ejemplo, para ilustrar esto. Consideremos una empresa del sector forestal la que posee n bosques (rodales, en la jerga del sector) que pueden ser cosechados lo largo de T periodos (meses, por ejemplo). Llamemos B_i la cantidad de madera disponible en el bosque $i = 1, \dots, n$. Vamos a suponer que existen m puntos de destino con demanda d_{jt} en el periodo t , para el punto de demanda j y que hay costos variables, pero también hay costos fijos cada vez que se cosecha. Denotemos por α_{it} el costo unitario de cosecha en el rodal i en el periodo t y por β_{it} el costo fijo de cosechar el rodal i en el periodo t . También llamaremos c_{ij} al costo unitario de transporte entre el rodal i y el destino j . Para construir un modelo definiremos las siguientes variables:

- x_{it} : cantidad de madera cosechada en el rodal i en el período t .
- z_{it} : variable binaria que indica si un rodal es cosechado o no.
- y_{ijt} cantidad de madera enviada desde el rodal i al destino j en el período t .

El siguiente modelo de optimización busca la forma de cosechar los bosques de modo de cumplir con la demanda y hacerlo al menor costo combinado de cosecha y transporte:

$$\begin{aligned} \min \quad & \sum_{t=1}^T \left\{ \left(\sum_{i=1}^n \alpha_{it} x_{it} + \beta_{it} z_{it} \right) + \sum_{i=1}^n \sum_{j=1}^m c_{ij} y_{ijt} \right\} \\ \text{s.a.} \quad & x_{it} = \sum_{j=1}^m y_{ijt} \quad \forall i; \forall t \quad (1) \\ & \sum_{i=1}^n y_{ijt} \geq d_{jt} \quad \forall j; \forall t \quad (2) \\ & x_{it} \leq B_i - \sum_{k=1}^{t-1} x_{ik} \quad \forall i; \forall t \geq 2 \quad (3) \\ & x_{i1} \leq B_i \quad \forall i \quad (4) \\ & x_{it} \leq M z_{it} \quad \forall i, \forall t \quad (5) \\ & x_{it} \geq 0, y_{ijt} \geq 0, z_{it} \in \{0, 1\} \quad \forall i; \forall t; \forall j \quad (6) \end{aligned}$$

Queremos analizar la estructura del problema. Esto es, de qué forma se relacionan entre sí los elementos y cómo se distribuyen. Esto es muy importante para establecer el método de resolución correcto ya que, como ya hemos visto, estos hacen uso de esa estructura especial.

En esto, podemos notar que todas las restricciones, con la excepción de las (3) se pueden separar en el índice de tiempo, t (tienen un $\forall t$), mientras que la (3) suma sobre el índice de tiempo. De esta forma, se puede apreciar que (3) es una restricción “complicante”: impide que el problema se separe en problemas más pequeños para cada periodo de tiempo. Una forma de visualizar mejor esto es dejar (3) arriba, todas las que sean separables del tiempo abajo (que son la (1), (2), (5) y (6)) y las variables al lado izquierdo:

$$\begin{aligned}
 \text{mín} \quad & \sum_{t=1}^T \left\{ \left(\sum_{i=1}^n \alpha_{it} x_{it} + \beta_{it} z_{it} \right) + \sum_{i=1}^n \sum_{j=1}^m c_{ij} y_{ijt} \right\} \\
 \text{s.a.} \quad & x_{it} + \sum_{k=1}^{t-1} x_{ik} \leq B_i & \forall i; \forall t \geq 2 \quad (3) \\
 & x_{i1} \leq B_i & \forall i \quad (4) \\
 & x_{it} - \sum_{j=1}^m y_{ijt} = 0 & \forall i; \forall t \quad (1) \\
 & \sum_{i=1}^n y_{ijt} \geq d_{jt} & \forall j; \forall t \quad (2) \\
 & x_{it} - M z_{it} \leq 0 & \forall i, \forall t \quad (5) \\
 & x_{it} \geq 0, y_{ijt} \geq 0, z_{it} \in \{0, 1\} & \forall i; \forall t; \forall j \quad (6)
 \end{aligned}$$

Esto permite ver “restricciones complicantes” con mayor facilidad. De este modo, la estructura que se forma es tal que solo (3) es complicante, ya que liga las variables entre sí por sumar sobre t , (4) solo va asociada al tiempo $t = 1$ y para las restricciones (1), (2), (5) y (6) se arman bloques, uno para cada periodo de tiempo:

$$\begin{aligned}
 \text{mín} \quad & \left(\sum_{i=1}^n \alpha_{i1} x_{i1} + \beta_{i1} z_{i1} \right) + \sum_{i=1}^n \sum_{j=1}^m c_{ij} y_{ij1} \quad + \dots + \quad \left(\sum_{i=1}^n \alpha_{iT} x_{iT} + \beta_{iT} z_{iT} \right) + \sum_{i=1}^n \sum_{j=1}^m c_{ij} y_{iT} \\
 \text{s.a.} \quad & x_{it} + \sum_{k=1}^{t-1} x_{ik} \leq B_i, \quad \forall i, t \geq 2 \\
 & x_{i1} \leq B_i, \quad \forall i \\
 & x_{i1} - \sum_{j=1}^m y_{ij1} = 0, \quad \forall i \\
 & \sum_{i=1}^n y_{ij1} \geq d_{j1}, \quad \forall j \\
 & x_{i1} - M z_{i1} \leq 0, \quad \forall i \\
 & \vdots \\
 & x_{iT} - \sum_{j=1}^m y_{ijT} = 0, \quad \forall i \\
 & \sum_{i=1}^n y_{ijT} \geq d_{jT}, \quad \forall j \\
 & x_{iT} - M z_{iT} \leq 0, \quad \forall i \\
 & x_{it} \geq 0, y_{ijt} \geq 0, z_{it} \in \{0, 1\} \quad \forall i, j, t
 \end{aligned}$$

Esta forma de plantear el problema permite “ver”, entonces, una estructura apropiada de ser abordada mediante descomposición de Dantzig - Wolfe.

Sin embargo, también existen otra forma de estructurar el problema en bloques, observando la naturaleza de las variables y cómo se relacionan a las restricciones. Hagamos lo siguiente: formemos 2 bloques de variables: las x con las z (que corresponden a la cosecha) se dejan en el primer bloque y las y (que corresponde al transporte) en el segundo. Esto se hace para separar el problema en las dos partes presentes en la estructura general: la cosecha primero y después el transporte. Sin embargo, notemos que no se puede separar completamente, pues existe una restricción que relaciona las variables de cosecha y de transporte. Esta sería la forma de reordenar el modelo:

$$\begin{aligned}
 \text{mín} \quad & \sum_{t=1}^T \left\{ \left(\sum_{i=1}^n \alpha_{it} x_{it} + \beta_{it} z_{it} \right) + \sum_{i=1}^n \sum_{j=1}^m c_{ij} y_{ijt} \right\} \\
 \text{s.a.} \quad & x_{it} - \sum_{k=1}^{t-1} x_{ik} \leq B_i, \quad \forall i; \forall t \geq 2 \quad (3) \\
 & x_{i1} \leq B_i, \quad \forall i \quad (4) \\
 & x_{it} - M z_{it} = 0, \quad \forall i; \forall t \quad (1) \\
 & x_{it} - \sum_{j=1}^m y_{ijt} = 0, \quad \forall i; \forall t \quad (2) \\
 & \sum_{i=1}^n y_{ijt} \geq d_{jt}, \quad \forall j; \forall t \quad (5) \\
 & x_{it} \geq 0, z_{it} \in \{0, 1\}, \quad y_{ijt} \geq 0, \quad \forall i; \forall t; \forall j
 \end{aligned}$$

Si se fijan las variables x y z en valores específicos, estas quedan como constantes para el segundo bloque. Con eso, las variables y forman su propio problema de optimización. Esto en el fondo quiere decir que las variables son casi separables, pero están ligadas por uno de los tres bloques en que se puede separar estas restricciones.

Acá, las variables x y z “complican”, implican resolver un problema de programación entera, mientras que en el problema de las variables y , se tiene un problema más simple de programación lineal.

También es interesante pensar que las decisiones representadas por las variables y , el transporte, están supeditadas a las decisiones de (x, z) , que corresponden a la cosecha. Esto es muy razonable desde un punto de vista práctico ya que primero se cosecha y después se transporta, pero para ser eficientes, ambas decisiones deben estar coordinadas. Esto es lo que motiva el tema de la siguiente sección.

Cápsula de video 6.3.1: Estructuras complicantes

Profesor Jorge Vera explica en clases la importancia de identificar estructuras complicantes.
<https://youtu.be/SuhdnqyuytY>

6.4. Descomposición de Benders

Este es un enfoque de descomposición que fue propuesto por Benders en 1962, pero hasta el día de hoy es muy usado en algunos problemas gigantes en diversas áreas, como la planificación de sistemas eléctricos y otros.

El método se aplica a un problema con la siguiente estructura (**Problema Original**):

$$\begin{aligned}
 \text{mín} \quad & c^T x + d^T y \\
 \text{s.a.} \quad & Ax = b \\
 & Ex + Dy = e \\
 & x \in C, \quad y \geq 0
 \end{aligned}$$

Donde $A \in \mathbb{R}^{m \times n}$, $E \in \mathbb{R}^{p \times n}$, $D \in \mathbb{R}^{p \times r}$, $b \in \mathbb{R}^m$ y $e \in \mathbb{R}^p$. Las variables y son continuas y C es algún conjunto de restricciones adicionales (integralidad, por ejemplo, y podemos asumir eso como modelo de ejemplo) para las variables x . El tema es que puede ser conveniente separar la parte entera de la continua. Para hacer esto, hay que pensar en la idea de separar en dos etapas: primero se toman decisiones con los x fijos y con eso los y “viven” en un problema de programación lineal (y están subordinadas a las x). El problema anterior se puede reescribir como:

$$\begin{array}{llll} \text{mín} & c^T x & + & d^T y \\ \text{s.a.} & Ax & & = b \\ & & + & Dy = e - Ex \\ & x \in C & & y \geq 0 \end{array}$$

Pensemos en que la optimización en y está subordinada a la optimización en x , por lo que minimizar $(c^T x + d^T y)$ equivale a minimizar $c^T x$ y $d^T y$ por separado, pero donde y necesita un determinado valor de x . Esto es un problema de minimización que está dentro de otro:

$$\text{mín}_{Ax=b, x \in C} \{c^T x + \text{mín} \{d^T y : Dy = e - Ex, y \geq 0\}\}$$

Para el problema de adentro, se tiene por dualidad fuerte que:

$$\text{mín} \{d^T y : Dy = e - Ex, y \geq 0\} = \text{máx} \{(e - Ex)^T u : D^T u \leq d\}$$

Luego, el problema original también se puede plantear como:

$$\text{mín}_{Ax=b, x \in C} \{c^T x + \text{máx} \{(e - Ex)^T u : D^T u \leq d\}\}$$

Sea P el poliedro de la restricción del dual. Vamos a suponer, de momento, que este poliedro es acotado y, por lo tanto, puede ser generado por la envoltura convexa de sus puntos extremos, que llamaremos $v^1 \dots v^q$. Es decir, $P_D = \{u : D^T u \leq d\} = \text{conv} \{v^1 \dots v^q\}$. Entonces, resolver un problema de programación lineal sobre P_D es lo mismo que buscar el vértice con mayor función objetivo. Por lo tanto, el problema puede escribirse como:

$$\text{mín}_{Ax=b, x \in C} \{c^T x + \text{máx} \{(e - Ex)^T v^i : i = 1, \dots, q\}\}$$

Este es un problema “min-max”, minimizar el máximo de un número finito de expresiones, que se puede tratar utilizando una variable auxiliar γ que sea cota superior de todos los valores objetivos del problema de maximización (y por lo tanto también es cota superior del mayor), de modo que baste con minimizar γ .

Con esto, se puede expresar el problema original de manera equivalente a:

$$\begin{array}{ll} \text{mín} & c^T x + \gamma \\ \text{s.a.} & Ax = b \quad (1) \\ & (e - Ex)^T v^i \leq \gamma \quad \forall i = 1, \dots, q \quad (2) \\ & x \in C, \gamma \in \mathbb{R} \end{array}$$

En el conjunto de restricciones (2) hay una restricción por cada vértice v^i . Además, podemos aún reescribirlo de otra manera para dejar claro que las variables son el x y el γ , mientras que los vértices v^i son parámetros:

$$\begin{array}{ll} z^* = \text{mín} & c^T x + \gamma \\ \text{s.a.} & Ax = b \\ & - (v^i)^T Ex - \gamma \leq -e^T v^i, \quad \forall i = 1 \dots q \\ & x \in C, \gamma \in \mathbb{R} \end{array}$$

En este problema ya no aparece y , pues con todas las transformaciones ahora está representada por los vértices v^i . Ahora solo están las variables x (y γ). Este problema tiene una gran cantidad de restricciones


o filas (asociadas a todos los puntos extremos del poliedro). Vamos a resolverlo usando un enfoque que es análogo al de generación de columnas, pero aplicado a las “filas”, es decir las restricciones. Esto es un método de “generación de restricciones” o de “planos cortantes”. La idea es partir con unas pocas restricciones e ir agregando otras a medida que se necesiten.

Supongamos que inicialmente conocemos los primeros k vértices extremos $\{v^1, \dots, v^k\}$, o sea, k restricciones. Por lo tanto, resolvemos el **Problema Maestro**:

$$P_k) \quad \begin{aligned} z^k &= \min && c^T x + \gamma \\ &\text{s.a.} && Ax = b \\ &&& (e - Ex)^T v^i \leq \gamma \quad \forall i = 1, \dots, k \end{aligned} \quad (1)$$

$$x \in C, \gamma \in \mathbb{R} \quad (2)$$

Sea (x^k, γ^k) solución óptima del problema P_k , el que posee menor o igual cantidad de restricciones que el problema original, lo que implica que $z^k \leq z^*$ (es una relajación). Le geometría de lo que se está haciendo acá se muestra en la siguiente imagen:



donde el poliedro original es el que está en azul, pero solo las restricciones rojas representan al poliedro original, pues se parte con un conjunto menor de restricciones. Con estas primeras restricciones se encuentra que el “pseudo óptimo” (llamémoslo incumbente) está en x^1 . La idea es llamar a un generador de restricciones que genere una restricción que sea de utilidad (un plano cortante), es decir, que genere una restricción tal que se encuentre un nuevo incumbente x^2 más cerca del poliedro original. El gran desafío es cómo implementamos algo que sea capaz de generar estas restricciones.

Lo que necesitamos es encontrar (generar) una restricción $((e - Ex)^T v^i \leq \gamma)$, asociada a un v^i que no sea de los que ya han sido encontrados. Esta nueva restricción debe dejar afuera al actual incumbente (lo “corta”), por lo que si el incumbente es (x^k, γ^k) , entonces el nuevo vértice que se busca v^i debe cumplir con que: $(e - Ex^k)^T v^i > \gamma^k$. Todo esto motiva al siguiente

Problema Satélite:

$$\begin{aligned} w^k &= \max (e - Ex^k)^T u \\ &\text{s.a. } D^T u \leq d \end{aligned}$$

Este problema de Programación Lineal encontrará una solución en un vértice del poliedro P_D . Si $w^k > \gamma^k$, entonces una solución óptima v^{k+1} nos permite generar una nueva restricción que es agregada al problema maestro, la cual es:

$$(e - Ex)^T v^{k+1} \leq \gamma$$

Si $w^k \leq \gamma^k$, significa que (x^k, γ^k) satisface todas las restricciones (sin necesidad de haberlas escrito), entonces nos encontramos en el óptimo final.

Notemos que el maestro es una relajación del problema original. Esto implica que $z^1 \leq z^2 \leq \dots \leq z^k \leq z^*$, es decir, el maestro entrega siempre una cota inferior. Por otro lado, w^k , el óptimo del satélite, es igual al óptimo del problema “interior”:

$$w^k = \min \{d^T y : Dy = e - Ex^k, y \geq 0\}$$

Sea y^k solución óptima de este problema. Entonces, (x^k, y^k) es factible (aunque no necesariamente óptima) para el problema original, lo que significa que $c^T x^k + w^k$ es una cota superior a z^* . De este modo, se tiene una cota superior y una inferior al valor óptimo:

$$\underbrace{z^k}_{\text{maestro}} \leq z^* \leq \underbrace{w^* + c^T x^k}_{\text{satélite}}$$

Esto puede ser muy útil para saber a cuánto se está del óptimo, si la diferencia entre z^k y $w^k + c^T x^k$ es suficientemente pequeña, o aceptable, podríamos detener las iteraciones y tendremos, al menos, una solución factible (x^k, y^k) .

Veamos ahora qué hacer si se considera la posibilidad de que $P_D = \{u : D^T u \leq d\}$ sea no acotado. En este caso, van a existir los rayos del cono de recesión de P_D , llamémoslos $h^1, h^2, \dots, h^r$. Recordemos el problema:

$$\min_{Ax=b, x \in C} \{c^T x + \max \{(e - Ex)^T u : D^T u \leq d\}\}$$

Entonces, para los x posibles solución óptima, el problema interior debe tener un valor finito, de otro modo el valor para ese x sería $+\infty$. Por esa razón, queremos imponer que los x a considerar generen el problema interior un problema acotado. Esto se logra pidiendo que $(e - Ex)^T h^i \leq 0$, para todos los rayos extremos del cono de recesión.

Entonces, el problema maestro completo es:

$$\begin{array}{ll} z^k = \min & c^T x + \gamma \\ \text{s.a.} & Ax = b \\ P_k) & (e - Ex)^T v^i \leq \gamma \quad \forall i = 1, \dots, q \\ & (e - Ex)^T h^j \leq 0, \quad \forall j = 1, \dots, r \\ & x \in C, \gamma \in \mathbb{R} \end{array}$$

Entonces, al resolver el satélite:

$$\begin{array}{ll} w^k = \max & (e - Ex^k)^T u \\ \text{s.a.} & D^T u \leq d \end{array}$$

este puede alcanzar óptimo en un vértice v^{k+1} , como explicábamos antes, y en entonces se agrega la restricción $(e - Ex)^T v^{k+1} \leq \gamma$ al maestro (“corte de optimalidad”). Pero puede resultar que sea no acotado, y en ese caso se detecta un rayo h^{k+1} tal que $(e - Ex)^T h^{k+1} > 0$ y se agrega la restricción $(e - Ex)^T h^{k+1} \leq 0$ (“corte de factibilidad”).

El algoritmo completo es el siguiente:

Algoritmo de Descomposición de Benders

Data: Sea $k = 0$.

while *Criterio de parada no se satisface* **do:**

Resolver el “**Problema Maestro**”:

$$\begin{aligned} \text{mín} \quad & c^T x + \gamma \\ \text{s.a.} \quad & Ax = b \\ & (e - Ex)^T v^i \leq \gamma \quad \forall i = 1, \dots, q \\ & (e - Ex)^T h^j \leq 0, \quad \forall j = 1, \dots, r \\ & x \in C, \gamma \in \mathbb{R} \end{aligned}$$

obteniendo un vector solución x^k y se entrega esta solución al “**Problema Satélite**”.

Resolver el “**Problema Satélite**” con el vector x^k .

$$\begin{aligned} w^k = \text{máx} \quad & (e - Ex^k)^T u \\ \text{s.a.} \quad & D^T u \leq d \end{aligned}$$

Existen tres casos posibles:

- El problema satélite es no acotado con rayo de escape h^k , que se asocia con u . Se agrega un corte de factibilidad al problema maestro del tipo:

$$(e - Ex^k)^T h^k \leq 0$$

- El problema satélite es acotado y se obtiene el valor óptimo w^k . Sea v^{k+1} el vector dual. Si $w^k > \gamma^k$ entonces con la solución agregamos un corte de optimalidad al problema maestro del tipo:


$$(e - Ex^k)^T v^{k+1} \leq \gamma$$

- El problema satélite es acotado y se obtiene el valor óptimo w^k . Si $w^k \leq \gamma^k$, entonces hemos llegado al óptimo y termina el algoritmo con solución óptima (x^k, y^k) .

Actualizar el “**Problema Maestro**”, $k = k + 1$

end

La siguiente figura ilustra el diálogo entre el Problema Maestro y el problema Satélite.



Cápsula de video 6.4.1: Descomposición de Benders

Profesor Jorge Vera explica en clases el algoritmo de descomposición de Benders
<https://youtu.be/gXzp1CZPNKE>

6.4.1. Ejemplos adicionales

Flujos Multiproducto via Generación de Columnas

Consideremos el problema de flujo multiproducto que ya hemos introducido en la sección 6.2. Vamos a presentar una forma alternativa de abordar este problema.

Es posible demostrar que la solución óptima del problema de flujo multiproducto consiste en un conjunto de caminos dirigidos que conectan cada uno de los pares origen-destino $o_k = (r_k, s_k)$, transportando una cantidad de producto. Basado en esto, vamos a denotar por $\mathcal{P}_k$ al conjunto de todos los caminos dirigidos que conectan el par k , es decir, que conectan el nodo r_k con el nodo s_k . Denotemos también por $\mathcal{P} = \cup_k \mathcal{P}_k$ al conjunto de todos los caminos en el grafo. Vamos a denotar por $\mathcal{P}_{ij}$ al conjunto de todos los caminos que pasan por el arco (i, j) y por A_p el conjunto de todos los arcos que forman el camino A . Si f_p denota el flujo del camino p , entonces el problema puede ser reescrito de la siguiente forma:

$$\begin{aligned} \text{mín} \quad & \sum_{p \in \mathcal{P}} c_p f_p \\ \text{s.a.} \quad & \sum_{p \in \mathcal{P}_k} f_p = d_k \quad k = 1, \dots, K \\ & \sum_{p \in \mathcal{P}_{ij}} f_p \leq u_{ij} \quad (i, j) \in A \\ & f_p \geq 0 \quad p \in \mathcal{P} \end{aligned}$$

En este modelo, c_p denota el costo del camino p , el cual corresponde a la suma de los costos c_{ij}^k sobre todos los $(i, j) \in A_p$ (recuerde aquí que cada camino p está asociado a forma única a un par origen-destino k).

Este problema de optimización, reformulación del original, tiene un gran número de variables y, por esa razón, es adecuado para ser abordado mediante Generación de Columnas. Mostramos ahora ese desarrollo. Primero, vamos a reescribir el problema de una forma equivalente que lo hace más manejable para efectos de la formulación de Generación de Columnas. Para esto vamos a definir los siguientes parámetros, los cuales pueden ser construidos sin problemas a partir de la definición del problema dado que esta asume que “se conocen” todos los caminos que conectan cada par origen destino. Sean:

$$\alpha_{pk} = \begin{cases} 1 & \text{si el camino } p \text{ conecta el par origen destino } k \\ 0 & \text{en caso contrario,} \end{cases}$$

y

$$\beta_{pij} = \begin{cases} 1 & \text{si el camino } p \text{ pasa por el arco } (i, j) \\ 0 & \text{en caso contrario,} \end{cases}$$

El problema reformulado es, entonces:

$$\begin{aligned} \min \quad & \sum_{p \in \mathcal{P}} c_p f_p \\ \text{s.a.} \quad & \sum_{p \in \mathcal{P}} \alpha_{pk} f_p = d_k \quad k = 1, \dots, K \\ & \sum_{p \in \mathcal{P}} \beta_{pij} f_p \leq u_{ij} \quad (i, j) \in A \\ & f_p \geq 0 \quad p \in \mathcal{P} \end{aligned}$$

Notemos que el introducir los parámetros α y β , que describen la topología de la red, podemos reescribir el problema con sumas completas sobre $\mathcal{P}$. También es más directo ver la generación de columnas ya que esta tiene que generar las columnas y estas están formadas por los coeficientes α_{pk} y β_{pij} para un $p \in \mathcal{P}$. Es decir, las columnas son los caminos.

En una iteración de la generación de columnas tendremos, entonces, que se ha generado un conjunto de columnas (caminos) $\bar{\mathcal{P}}$. El problema maestro es:

$$\begin{aligned} \min \quad & \sum_{p \in \bar{\mathcal{P}}} c_p f_p \\ \text{s.a.} \quad & \sum_{p \in \bar{\mathcal{P}}} \alpha_{pk} f_p = d_k \quad k = 1, \dots, K \\ & \sum_{p \in \bar{\mathcal{P}}} \beta_{pij} f_p \leq u_{ij} \quad (i, j) \in A \\ & f_p \geq 0 \quad p \in \bar{\mathcal{P}} \end{aligned}$$

Ahora, una vez resuelto este problema maestro, se obtienen variables duales π_k , correspondientes al primer conjunto de restricciones, y variables duales w_{ij} correspondientes al segundo conjunto de restricciones. El costo reducido de una columna cualquiera es, entonces:

$$\bar{c}_p = c_p - \sum_{k=1}^K \pi_k \alpha_{kp} - \sum_{(i,j) \in A} w_{ij} \beta_{pij}$$

Ahora, recordemos que el costo de un camino específico es igual a la suma de los costos de los arcos que lo conforman. Entonces,

$$\bar{c}_p = \sum_{k=1}^K \sum_{(i,j) \in A} c_{ij}^k \beta_{pij} - \sum_{k=1}^K \pi_k \alpha_{kp} - \sum_{(i,j) \in A} w_{ij} \beta_{pij}$$

Notemos ahora que, por la estructura del problema, cada camino está asociado de forma única a un par origen destino. Esto significa que, en esa suma, el índice k activo es el que corresponde al camino y ningún otro aparece en la suma. Entonces, podemos fijar un par origen destino específico, digamos el k , y queremos buscar un camino con costo reducido igual a:

$$\bar{c}_p = \sum_{(i,j) \in A} c_{ij}^k - \sum_{(i,j) \in A} w_{ij} \beta_{pij} - \pi_k$$

y que sea mínimo. Esto se logra resolviendo el siguiente problema de optimización:

$$\begin{aligned} \eta = \min \quad & \sum_{(i,j) \in A} c_{ij}^k - \sum_{(i,j) \in A} w_{ij} \beta_{pij} \\ \text{s.a.} \quad & \beta_{pij} \text{ describe un camino válido para el par origen destino } k \end{aligned}$$

Si $\eta - \pi_k < 0$ eso determina una columna que puede entrar a la base.

Ahora bien, el problema de optimización anterior lo que busca es un camino para el par k de mínimo costo. Es decir, este camino se puede encontrar resolviendo un problema de ruta más corta donde los costos de los arcos son $(c_{ij}^k - w_{ij})$. Para abordar este problema se puede usar, entre otros, el algoritmo de Dijkstra.

Planificación de comunicaciones mediante Generación de Columnas

Consideramos el siguiente problema de una empresa del área de comunicaciones y transmisión de datos. Existen una serie de requerimientos por parte de distintos clientes, que necesitan transmitir datos en la red de esta empresa. Estos requerimientos pueden o no ser asignados y el problema es que la asignación consume ancho de banda, el cual es limitado. Se quiere asignar la mayor cantidad de requerimientos que resulten rentables.

Para modelar este problema, consideramos que todo ocurre en una red $G = (N, A)$, donde N son los nodos y A es el conjunto de arcos, que son pares (i, j) . Hay n requerimientos de comunicación y cada requerimiento k tiene origen en algún nodo o_k y termina en algún nodo d_k . La transmisión puede ocurrir, a través de la red, de muchas formas distintas, por muchos caminos diferentes, mientras se inicie y termine donde corresponde. Entonces, vamos a denotar por P_k el conjunto de todos los caminos que son factibles para el requerimiento k . Sea r_k la utilidad del requerimiento k , d_k el ancho de banda que se necesita usar para el requerimiento k . Denotemos, también, por u_{ij} la capacidad de ancho de banda del arco (i, j) y por c_{ij} el costo de uso del arco (i, j) . El problema puede ser modelado usando las siguientes variables:

x_{kl} : igual a 1 si el requerimiento k usa el camino l , 0 en caso contrario.

y_k : igual a 1 si el requerimiento k NO es asignado, 0 en caso contrario.

Para describir mejor los caminos, vamos a usar un parámetro $\delta_{(i,j)l}$ que toma valor 1 si el arco (i, j) pertenece al camino l . Con esto, se formula el siguiente modelo:

$$\begin{aligned}
 \text{mín} \quad & \sum_{k=1}^n \sum_{l \in P_k} \sum_{(i,j) \in A} c_{ij} \delta_{(i,j)l} d_k x_{kl} + \sum_{k=1}^n r_k y_k \\
 \text{s.a.} \quad & \sum_{l \in P_k} x_{kl} + y_k = 1 & k = 1, \dots, n \\
 & \sum_{k=1}^n \sum_{l \in P_k} \delta_{(i,j)l} d_k x_{kl} \leq u_{ij} & (i, j) \in A \\
 & x_{kl} \in \{0, 1\}, y_k \in \{0, 1\} & (i, j) \in A, k = 1, \dots, n; l \in P_k
 \end{aligned}$$

Si bien este es un problema de Programación Entera (y difícil), la relajación lineal puede ser abordada mediante Generación de Columnas, como mostramos a continuación.

Primero, reescribamos el modelo de esta forma:

$$\begin{aligned}
 \text{mín} \quad & \sum_{k=1}^n \sum_{l \in P_k} x_{kl} \left(\sum_{(i,j) \in A} c_{ij} \delta_{(i,j)l} d_k \right) + \sum_{k=1}^n r_k y_k \\
 \text{s.a.} \quad & \sum_{l \in P_k} x_{kl} + y_k = 1 & k = 1, \dots, n \\
 & \sum_{k=1}^n \sum_{l \in P_k} \delta_{(i,j)l} d_k x_{kl} \leq u_{ij} & (i, j) \in A \\
 & x_{kl} \in \{0, 1\}, y_k \in \{0, 1\} & (i, j) \in A, k = 1, \dots, n; l \in P_k
 \end{aligned}$$

Cada columna del problema está indexada por (k, l) en las variables x y por k en las variables y . El coeficiente en la función objetivo de x_{kl} es igual a $\left(\sum_{(i,j) \in A} c_{ij} \delta_{(i,j)l} d_k \right)$. Las variables x_{kl} son las que pueden ser muchas (una por cada requerimiento y por cada camino factible que atiende el requerimiento y puede haber muchos de esos caminos) y para ellas se debería aplicar la Generación de Columnas. Las variables y no participarán en esto y pueden permanecer en el problema. Para la generación de columnas, resolveremos la relajación lineal del problema, es decir, el problema:

$$\begin{aligned}
& \min \sum_{k=1}^n \sum_{l \in P_k} x_{kl} \left(\sum_{(i,j) \in A} c_{ij} \delta_{(i,j)l} d_k \right) + \sum_{k=1}^n r_k y_k \\
& \text{s.a.} \\
& \quad \sum_{l \in P_k} x_{kl} + y_k = 1 \quad k = 1, \dots, n \\
& \quad \sum_{k=1}^n \sum_{l \in P_k} \delta_{(i,j)l} d_k x_{kl} \leq u_{ij} \quad (i,j) \in A \\
& \quad x_{kl} \geq 0, y_k \in \{0, 1\} \quad (i,j) \in A, k = 1, \dots, n; l \in P_k
\end{aligned}$$

Notar que relajamos a $x_{kl} \geq 0$ ya que las primeras restricciones garantizan que $x_{kl} \leq 1$.

Entonces, en una iteración específica de la generación de columnas, para cada requerimiento k se habrán generado ya algunos caminos, los que denotaremos como el conjunto $\bar{P}_k \subset P_k$. El problema maestro es, entonces:

$$\begin{aligned}
& \min \sum_{k=1}^n \sum_{l \in \bar{P}_k} x_{kl} \left(\sum_{(i,j) \in A} c_{ij} \delta_{(i,j)l} d_k \right) + \sum_{k=1}^n r_k y_k \\
& \text{s.a.} \\
& \quad \sum_{l \in \bar{P}_k} x_{kl} + y_k = 1 \quad (1) \quad k = 1, \dots, n \\
& \quad \sum_{k=1}^n \sum_{l \in \bar{P}_k} \delta_{(i,j)l} d_k x_{kl} \leq u_{ij} \quad (2) \quad (i,j) \in A \\
& \quad x_{kl} \geq 0, y_k \in \{0, 1\} \quad (3) \quad (i,j) \in A, k = 1, \dots, n; l \in \bar{P}_k
\end{aligned}$$

Se resuelve este problema y se obtienen las variables duales óptimas. Llamemos u_k las duales de las restricciones (1) y v_{ij} las duales de las restricciones (2). El problema satélite busca encontrar un costo reducido negativo, o el más negativo. El costo reducido de la columna (k, l) es:

$$\bar{c}_{kl} = \left(\sum_{(i,j) \in A} c_{ij} \delta_{(i,j)l} d_k \right) - \sum_{(i,j) \in A} \delta_{(i,j)l} d_k v_{ij} - u_k$$

que se reescribe como:

$$\bar{c}_{kl} = d_k \sum_{(i,j) \in A} \delta_{(i,j)l} (c_{ij} - v_{ij}) - u_k$$

Acá tenemos que recordar que los coeficientes $\delta_{(i,j)l}$ describen un camino que conecta el origen y destino del requerimiento k . Planteemos, entonces, el siguiente problema:

$$\begin{aligned}
& \eta_k = \min \sum_{(i,j) \in A} \delta_{(i,j)l} (c_{ij} - v_{ij}) \\
& \text{s.a.} \quad \text{delta}_{(i,j)l} \text{ describe un camino conectando el origen y destino del requerimiento } k
\end{aligned}$$

Esto no es más que un problema de ruta más corta. Este lo podemos formular como sigue, denotando o_k el nodo origen del requerimiento, y s_k el nodo de destino para el requerimiento k . La formulación es un problema de flujo a costo mínimo. Definamos variables $f : ij$ como el flujo entre el nodo i y el nodo j . La formulación que deberíamos usar es:

$$\begin{aligned}
& \eta_k = \min \sum_{(i,j) \in A} f_{ij} (c_{ij} - v_{ij}) \\
& \text{s.a.} \\
& \quad \sum_{(i,j) \in A} f_{ij} - \sum_{(j,i) \in A} f_{ji} = 0, \quad i \neq o_k, s_k \\
& \quad \sum_{(o_k, j) \in A} f_{o_k j} - \sum_{(j, o_k) \in A} f_{j o_k} = 1, \\
& \quad \sum_{(s_k, j) \in A} f_{s_k j} - \sum_{(j, s_k) \in A} f_{j s_k} = -1, \\
& \quad f_{ij} \geq 0, \quad (i,j) \in A
\end{aligned}$$

Este problema de flujo a costo mínimo identificará, en las variables f_{ij} , el camino óptimo. Con esos valores, se pueden definir los coeficientes $\delta_{(i,j)l}$ que definen la estructura del camino que generará la nueva columna para el problema.


Entonces, si se resuelve el problema anterior, se obtiene η_k y si $d_k \eta_k - u_k < 0$, hemos identificado, para el requerimiento k , una columna (un camino) que puede ser considerado para incorporarse al problema maestro. Con eso se actualiza el conjunto $\bar{P}_k$. Si no es posible identificar ningún nuevo camino, deberíamos estar en el óptimo.

Acá debe comentarse qué papel deben jugar las variables y . Bueno, estas son parte del maestro y se resuelven en sus valores cuando el maestro alcanza el óptimo. El satélite genera columnas de las variables x_{kl} solamente pero eso no importa. Al llegar al óptimo el maestro, tiene que haber agotado las columnas tanto de los conjuntos $\bar{P}_k$ como de las variables y así que si el satélite no genera nuevos caminos, tampoco debería haber variables y que puedan entrar a la base.

Otra observación que vale la pena hacer es que este problema es, en realidad, una forma alternativa de problema de flujo multiproducto (que estudiamos en clases para la Descomposición de Dantzig-Wolfe). Cada requerimiento corresponde a un par origen-destino que tiene una demanda. El problema presenta la reformulación por caminos del problema de flujo multiproducto y desarrollo de la generación de columnas es totalmente análogo a haber aplicado la Descomposición de Dantzig-Wolfe al problema de flujo multiproducto. Los satélites que habrían resultado en DW corresponderían, precisamente, a problemas de ruta más corta.

Problema de corte de piezas en dos dimensiones

El problema de corte de piezas que hemos revisado antes es en una dimensión. Veremos ahora una primera extensión a dos dimensiones y para eso consideramos la situación de una fábrica de muebles que necesita disponer de una gran cantidad de piezas rectangulares de tablero de madera de distintas dimensiones. Para simplificar, vamos a asumir que todas las piezas son de ancho a (todas las unidades son centímetros) pero hay distintos largos: existen r largos distintos, $l_1, l_2, \dots, l_r$. Todas las piezas son cortadas de tableros de ancho A y largo $L \geq A$, y los cortes son todos de la siguiente forma: se hacen primero cortes de ancho a en el tablero, en el sentido largo, y luego esos se dividen en pedazos de distintos tamaños. La figura muestra un típico corte de un tablero:



Vamos a asumir que el proceso de corte funciona de la siguiente forma: se cortan primero en dirección vertical, dos “tiras” de ancho a , las que después se dividen, en dirección horizontal, en varios otros tableros. Las partes en gris son sobras perdidas.

La empresa necesita ciertas cantidades de piezas de cada tipo. Específicamente, se necesitan d_i piezas de medidas $a \times l_i$, para $i = 1, \dots, r$. Interesa calcular la cantidad mínima de tableros que deben usarse para cumplir con esta demanda y cómo se deberán cortar los tableros elegidos.

Este problema puede ser abordado mediante generación de columnas. De hecho, es una extensión del modelo de corte en una dimensión, gracias a que las piezas verticales son todas del mismo ancho. Vamos a suponer que tenemos definidos todos los posibles patrones de corte. Un patrón consiste en cortar $K = \lceil A/a \rceil$ tiras verticales de largo L y cada una de ellas cortarla de distintas formas. Consideremos un patrón de corte cualquiera, j . Sea a_{ij} el número de piezas de largo l_i que se generan del patrón. Aquí observemos que el número a_{ij} debe obtenerse de las formas posibles de cortar la tabla. Usemos el índice k para las piezas verticales, entonces sea b_{ki}^j el número de piezas de largo l_i que se obtienen de esa pieza vertical. Tenemos,

entonces, que se debe cumplir:

$$\begin{aligned} \sum_{i=1}^r b_{ki}^j l_i &\leq L, k = 1, \dots, K \\ \sum_{k=1}^K b_{ki}^j &= a_{ij}, i = 1, \dots, r \end{aligned}$$

El modelo, entonces, es similar al de corte unidimensional. Sea x_j el número de tablas cortadas con el patrón j . Supongamos que hay, potencialmente, J patrones. Tenemos que resolver:

$$\begin{aligned} \text{mín} \quad & \sum_{j=1}^J x_j \\ \text{s.a.} \quad & \sum_{j=1}^J a_{ij} x_j \geq d_i, i = 1, \dots, r \\ & x_j \geq 0, \text{ entero} \end{aligned}$$

Ahora, detallemos la forma en que funcionaría la generación de columnas. Primero, usaremos un maestro con cierta cantidad de columnas ya generadas, digamos hasta p :

$$\begin{aligned} \text{mín} \quad & \sum_{j=1}^p x_j \\ \text{s.a.} \quad & \sum_{j=1}^p a_{ij} x_j \geq d_i, i = 1, \dots, r \\ & x_j \geq 0, \text{ entero} \end{aligned}$$

Se resuelve este problema y se obtienen precios duales π . Ahora tenemos que encontrar una columna que tenga la propiedad de que

$$1 - \sum_{i=1}^r \pi_i a_{ij} \leq 0$$

que corresponde a identificar un costo reducido negativo para ingresar a la base. Esto es lo mismo que encontrar números a_{ij} , consistentes con un patrón de corte válido, que maximicen $\sum_{i=1}^r \pi_i a_{ij}$. Para esto, hay que resolver el siguiente problema satélite:

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^r \pi_i u_i \\ \text{s.a.} \quad & \sum_{k=1}^K v_{ki} = u_i, i = 1, \dots, r \\ & \sum_{i=1}^r v_{ki} l_i \leq L, k = 1, \dots, K \\ & v_{ki}, u_i \geq 0, \text{ enteros} \end{aligned}$$

En este problema, las variables u_i representan el número total de piezas del tipo i a seleccionar, y las variables v_{ki} indican el número de piezas del tipo i que se cortan de la “tira” k . Este problema es uno de programación entera (es un “multiknapsack”) y, por lo tanto, debe resolverse con técnicas como Ramificación y Acotamiento.

Entonces, el problema satélite determina, en función de la información de precios duales, π , que viene del problema maestro, el nuevo patrón de corte que resulte más conveniente para ingresar al problema.

Programación de operaciones en quirófanos

Un problema muy importante en el ámbito de la gestión hospitalaria es la programación eficiente de las salas de operaciones. Esto es lo que abordamos, en forma simplificada, en este ejemplo. Queremos resolver la programación de las operaciones durante un período dado, para lo cual debe determinarse qué quirófanos serán usados y qué operaciones se realizarán en qué quirófano. Tenemos N quirófanos y cada quirófano está disponible T horas, en tiempo normal, en el período. Se deben organizar un total de P operaciones y la

duración de la operación i es de w_i horas. De ser eventualmente necesario, un quirófano puede funcionar tiempo extra, pero existen restricciones a esto: el tiempo extra total que se use sobre todo el horizonte de planificación no puede superar Q horas. Existe un costo fijo K_j por usar el quirófano j en el período, un costo e_{ij} por realizar la operación i en el quirófano j y un costo adicional c_j por hora de sobretiempo que se asigne al quirófano j . La programación debe ser tal que las operaciones se realicen en los quirófanos, pero de no ser posible (por falta de tiempo), algunas operaciones deberán ser “derivadas” a otra red hospitalaria. Esto no es deseable, así que se asigna una penalidad por esta ocurrencia, β , ya que deteriora la calidad de atención a los pacientes. El siguiente modelo de optimización determina qué quirófanos usar, cuánto sobretiempo asignar de modo de cumplir con la mayor cantidad posible de cirugías y minimizar los costos, que consideran los directos y la penalidad por derivación (note que aquí hay un balance entre objetivos de costos y uno de calidad de atención, que no es necesariamente un costo monetario). La variables y_j indica si un quirófano se usa o no, la variables x_{ij} indica si la operación i se hace en el quirófano j , t_j es la cantidad de sobretiempo asignado al quirófano j y la variable z_i indica si una operación es derivada o no:

$$\begin{aligned}
\text{mín} \quad & \sum_{j=1}^N \{K_j y_j + c_j t_j\} + \beta \sum_{i=1}^P z_i + \sum_{i=1}^P \sum_{j=1}^N e_{ij} x_{ij} \\
\text{s.a.} \quad & \sum_{j=1}^N x_{ij} + z_i = 1, & i = 1, \dots, P & \quad (1) \\
& \sum_{i=1}^P x_{ij} \leq P y_j & j = 1, \dots, N & \quad (2) \\
& \sum_{i=1}^P w_i x_{ij} \leq T + t_j, & j = 1, \dots, N & \quad (3) \\
& \sum_{j=1}^N t_j \leq Q & & \quad (4) \\
& x_{ij}, y_j, z_i \in \{0, 1\}, t_j \geq 0, & i = 1, \dots, P; j = 1, \dots, N. & \quad (5)
\end{aligned}$$

En este modelo, la función objetivo suma todos los costos relevantes, las restricciones (1) especifican que todas las operaciones deben ser realizadas o derivadas, (2) establece que si un quirófano no es habilitado, no se le pueden asignar operaciones, (3) calcula el tiempo usado y establece el eventual sobretiempo, (4) define el límite total al sobretiempo y, finalmente, (5) define la naturaleza de las variables.

Primero, visualicemos una estructura adecuada para utilizar la descomposición de Benders. Reescribiremos el problema de modo que tenga la estructura básica requerida (obviamos los rangos para simplificar la escritura):

$$\begin{aligned}
\text{mín} \quad & \sum_{i=1}^P \sum_{j=1}^N e_{ij} x_{ij} + \sum_{j=1}^N \{K_j y_j\} + \beta \sum_{i=1}^P z_i + \sum_{j=1}^N \{c_j t_j\} \\
\text{s.a.} \quad & \sum_{j=1}^N x_{ij} + z_i = 1 \quad \forall i \\
& \sum_{i=1}^P x_{ij} - P y_j \leq 0 \quad \forall j \\
& \sum_{i=1}^P w_i x_{ij} - t_j \leq T \quad \forall j \\
& \sum_{j=1}^N t_j \leq Q \\
& x_{ij} \in \{0, 1\} \quad y_j \in \{0, 1\} \quad z_i \in \{0, 1\} \quad t_j \geq 0
\end{aligned}$$

Primero se identifica el problema interior de la Descomposición de Benders:

$$\begin{aligned}
& \text{mín} \quad \sum_{j=1}^N \{c_j t_j\} \\
& \text{s.a.} \\
& \quad t_j \geq \sum_{i=1}^P w_i x_{ij} - T \quad \forall j \quad (\pi_j) \\
& \quad \sum_{j=1}^N t_j \leq Q \quad (u) \\
& \quad t_j \geq 0
\end{aligned}$$

Luego, se determina el problema dual del problema interior. Para esto se utilizan variables duales π_j para la primera restricción y u para la segunda (obviamos los rangos para simplificar la escritura):

$$\begin{aligned}
& \text{máx} \quad \sum_{j=1}^N \pi_j \left(\sum_{i=1}^P w_i x_{ij} - T \right) + uQ \\
& \text{s.a.} \\
& \quad \pi_j + u \leq c_j \quad \forall j \\
& \quad \pi_j \geq 0 \\
& \quad u \leq 0
\end{aligned}$$

Luego el problema maestro queda:

$$\begin{aligned}
& \text{mín} \quad \sum_{i=1}^P \sum_{j=1}^N e_{ij} x_{ij} + \sum_{j=1}^N \{K_j y_j\} + \beta \sum_{i=1}^P z_i + \gamma \\
& \text{s.a.} \\
& \quad \sum_{j=1}^N x_{ij} + z_i = 1 \quad \forall i \\
& \quad \sum_{i=1}^P x_{ij} - P y_j \leq 0 \quad \forall j \\
& \quad \sum_{j=1}^N \pi_j \left(\sum_{i=1}^P w_i x_{ij} - T \right) + uQ \leq \gamma \\
& \quad \sum_{j=1}^N \pi'_j \left(\sum_{i=1}^P w_i x_{ij} - T \right) + u'Q \leq 0 \\
& \quad x_{ij}, y_j, z_i \in \{0, 1\} \quad t_j \geq 0 \quad \forall i, j
\end{aligned}$$

Donde π_j y u son cortes de optimalidad dados por el problema satélite y π'_j y u' son cortes de factibilidad dados por el satélite. Finalmente, el problema satélite, es el mismo dual del problema interior, pero para la solución del problema maestro. Denotemos por $(\bar{x}, \bar{y}, \bar{z}, \bar{\gamma})$ la solución óptima del problema maestro en esta etapa, entonces el satélite es:

$$\begin{aligned}
& \text{máx} \quad \sum_{j=1}^N \pi_j \left(\sum_{i=1}^P w_i \bar{x}_{ij} - T \right) + uQ \\
& \text{s.a.} \\
& \quad \pi_j + u \leq c_j \quad \forall j \\
& \quad \pi_j \geq 0 \\
& \quad u \leq 0
\end{aligned}$$

Flujo multiproducto

Consideramos en este ejemplo el mismo problema, generalización del problema de flujo multiproducto, de la sección 5.2.1.

Para visualizar una estructura adecuada para Benders, vamos a tomar la reescritura inicial del problema:

$$\begin{aligned}
 \min \quad & \sum_{t=1}^2 \sum_{(i,j) \in A} f_{ijt} y_{ijt} + \sum_{k \in K} \sum_{t=1}^2 \sum_{(i,j) \in A} c_{ijt}^k x_{ijt}^k \\
 \text{s.a.} \quad & y_{ijt} - U_{ijt} z_{ijt} \leq 0 \quad \forall (i,j), t \\
 & z_{ij1} + z_{ij2} \leq 1 \quad \forall (i,j) \\
 & -C_t y_{ijt} + \sum_{k=1}^K x_{ijt}^k \leq 0 \quad \forall (i,j), t \\
 & \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k \quad \forall i, k \\
 & y_{ijt} \in \mathbb{N}, z_{ijt} \in \{0, 1\} \quad x_{ijt}^k \geq 0 \quad \forall (i,j), k, t
 \end{aligned}$$

Acá se ve claramente que las variables (z, y) son complicantes, además de ser enteras. Es útil visualizar los bloques de la siguiente forma:

$$\begin{aligned}
 \min \quad & \sum_{t=1}^2 \sum_{(i,j) \in A} f_{ijt} y_{ijt} + \sum_{k \in K} \sum_{t=1}^2 \sum_{(i,j) \in A} c_{ijt}^k x_{ijt}^k \\
 \text{s.a.} \quad & \boxed{\begin{array}{l} y_{ijt} - U_{ijt} z_{ijt} \\ z_{ij1} + z_{ij2} \end{array}} \quad \text{A} \quad \begin{array}{l} \leq 0 \\ \leq 1 \end{array} \quad \forall (i,j), t \\
 & \boxed{\begin{array}{l} -C_t y_{ijt} + \\ \sum_{k=1}^K x_{ijt}^k \end{array}} \quad \text{D} \quad \begin{array}{l} \leq 0 \\ \end{array} \quad \forall (i,j), t \\
 & \boxed{\begin{array}{l} \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) \end{array}} \quad \text{E} \quad \begin{array}{l} = b_i^k \\ \end{array} \quad \forall i, k = 1 \\
 & y_{ijt} \in \mathbb{N}, z_{ijt} \in \{0, 1\} \quad x_{ijt}^k \geq 0 \quad \forall (i,j), k, t
 \end{aligned}$$

Ahora desarrollamos los detalles de la Descomposición de Benders. El problema interior es:

$$\begin{aligned}
 \min \quad & \sum_{k \in K} \sum_{t=1}^2 \sum_{(i,j) \in A} c_{ijt}^k x_{ijt}^k \\
 \text{s.a.} \quad & \sum_{k=1}^K x_{ijt}^k \leq C_t y_{ijt} \quad \forall (i,j), t \\
 & \sum_{t=1}^2 \left(\sum_{j:(i,j) \in A} x_{ijt}^k - \sum_{p:(p,i) \in A} x_{pit}^k \right) = b_i^k \quad \forall i, k \\
 & x_{ijt}^k \geq 0 \quad \forall (i,j), k, t
 \end{aligned}$$

Para determinar su dual usamos variables duales π_{ijt} para las primeras restricciones y variables duales t_{ik} para el conjunto de restricciones de los bloques de pares origen-destino. El dual es (obviamos los rangos para simplificar la escritura):

$$\begin{aligned}
 w = \max \quad & \sum_{i,j,t} (-C_t y_{ijt}) \pi_{ijt} + \sum_{i,k} b_{ik} t_{ik} \\
 & t_{ik} - t_{jk} - \pi_{ijt} \leq c_{ijt}^k, \quad \forall i, j, t, k \\
 & \pi_{ijt} \geq 0, \quad \forall i, j, t
 \end{aligned}$$

El problema maestro es:

$$\begin{aligned}
 \min \quad & \sum_{t=1}^2 \sum_{(i,j) \in A} f_{ijt} y_{ijt} + \gamma \\
 \text{s.a.} \quad & y_{ijt} - U_{ijt} z_{ijt} \leq 0, \quad \forall (i,j), t \\
 & z_{ij1} + z_{ij2} \leq 1, \quad \forall (i,j) \\
 & \sum_{i,j,t} (-C_t y_{ijt}) \pi_{ijt}^l + \sum_{i,k} b_{ik} t_{ik}^l \leq \gamma, \quad l = 1, \dots, L \\
 & \sum_{i,j,t} (-C_t y_{ijt}) h_{ijt}^l + \sum_{i,k} b_{ik} g_{ik}^l \leq 0, \quad l = 1, \dots, M \\
 & y_{ijt} \in \mathbb{N}, z_{ijt} \in \{0, 1\}
 \end{aligned}$$

donde (π_{ijt}^l, t_{ik}^l) son los vértices de la región factible del dual y (h_{ijt}^l, g_{ik}^l) son los rayos de esa misma región factible. El problema satélite, es el mismo dual del problema interior, pero para la solución del problema maestro. Denotemos por $(\bar{y}, \bar{\gamma})$ la solución óptima de problema maestro en esta etapa, entonces el satélite es:

$$w = \max \quad \sum_{i,j,t} (-C_t \bar{y}_{ijt}) \pi_{ijt} + \sum_{i,k} b_{ik} t_{ik}$$

$$t_{ik} - t_{jk} - \pi_{ijt} \leq c_{ijt}^k, \quad \forall i, j, t, k$$

$$\pi_{ijt} \geq 0, \quad \forall i, j, t$$

Entonces, si el problema alcanza su óptimo y $w > \bar{\gamma}$, se ha generado un corte con puntos extremos. Si ese problema satélite es no acotado, entonces el correspondiente rayo genera un corte de factibilidad.

Transporte con costos fijos via Descomposición de Benders

Una empresa posee un conjunto de bodegas entre las cuales se generan necesidades de transporte. Esto se puede representar por una red con un conjunto de nodos, N , que corresponden a las bodegas, y un conjunto de arcos, A , formado por pares (i, j) que representan la posibilidad de viajar entre la bodega i y la j . Existe una oferta/demanda d_i en cada nodo $i \in N$ (la convención habitual, si $d_i > 0$ es oferta, si es < 0 es demanda y si es $= 0$ es un nodo de paso), y existe un costo variables c_{ij} por el transporte entre i y j . Sin embargo, también existe un costo fijo, F_{ij} por efectuar transporte entre i y j . Adicionalmente, si se hace uso de la posibilidad de transportar entre i y j , se produce una externalidad ambiental negativa igual a β_{ij} (en unidades adecuadas) y la externalidad total no puede superar un valor B . Además, la cantidad que se puede transportar por (i, j) no puede ser mayor a u_{ij} . La empresa quiere determinar de qué forma realizar el transporte y para eso formula un modelo de optimización con variables x_{ij} que corresponden a la cantidad que se transporte entre i y j y variables binarias z_{ij} que indican si se usa o no la posibilidad de transportar entre i y j . El modelo es el siguiente, que corresponde a un modelo de “diseño de red” con restricciones adicionales:

$$\begin{aligned} \min \quad & \sum_{(i,j) \in A} c_{ij} x_{ij} + \sum_{(i,j) \in A} F_{ij} z_{ij} \\ \text{s.a.} \quad & \sum_{j:(i,j) \in A} x_{ij} - \sum_{k:(k,i) \in A} x_{ki} = d_i \quad i \in N \quad (1) \\ & x_{ij} \leq u_{ij} z_{ij} \quad (i, j) \in A \quad (2) \\ & \sum_{(i,j) \in A} \beta_{ij} z_{ij} \leq B \quad (3) \\ & x_{ij} \geq 0, z_{ij} \in \{0, 1\} \quad (i, j) \in A \quad (4) \end{aligned}$$

Vamos a desarrollar una Descomposición de Benders para este problema. Primero, podemos notar que las variables z son complicantes debido a la naturaleza de estas variables y que al fijar las aristas que se van a utilizar, resolver las cantidades a transportar es más fácil ya que el problema se transforma en un problema de optimización lineal con variables continuas.

Luego, podemos definir la estructura de bloques de la siguiente forma:

$$\begin{array}{ll} \min & \boxed{\sum_{(i,j) \in A} F_{ij} z_{ij}} \quad \boxed{+ \sum_{(i,j)} c_{ij} x_{ij}} \\ \text{s.a.} & \boxed{\sum_{(i,j) \in A} \beta_{ij} z_{ij}} \leq \boxed{B} \\ & \boxed{\sum_{j:(i,j) \in A} x_{ij} - \sum_{k:(k,i) \in A} x_{ki}} = \boxed{d_i} \quad i \in N \\ & \boxed{-u_{ij} z_{ij}} \quad \boxed{\sum_{j:(i,j) \in A} x_{ij} - \sum_{k:(k,i) \in A} x_{ki}} \leq \boxed{0} \quad (i, j) \in A \\ & \boxed{z_{ij} \in \{0, 1\}} \quad \boxed{x_{ij} \geq 0} \quad (i, j) \in A \end{array}$$

Ahora identificamos el problema interior:

$$\begin{aligned}
 & \min \sum_{(i,j)} c_{ij} x_{ij} \\
 & \text{s.a} \\
 & \sum_{j:(i,j) \in A} x_{ij} - \sum_{k:(k,i) \in A} x_{ik} = d_i \quad i \in N \quad (\pi_i) \\
 & x_{ij} \leq u_{ij} z_{ij} \quad (i,j) \in A \quad (\theta_{ij}) \\
 & x_{ij} \geq 0 \quad (i,j) \in A
 \end{aligned}$$

El problema satélite se obtiene del dual de este problema:

$$\begin{aligned}
 & \max \sum_{i \in N} d_i \pi_i + \sum_{(i,j) \in A} u_{ij} z_{ij} \theta_{ij} \\
 & \text{s.a} \\
 & \pi_i - \pi_j + \theta_{ij} \leq c_{ij} \quad (i,j) \in A \\
 & \pi_i \in \mathbb{R} \quad i \in N \quad \theta_{ij} \leq 0 \quad (i,j) \in A
 \end{aligned}$$

Ahora, el Problema Maestro de la Descomposición de Benders es:

$$\begin{aligned}
 & \min \sum_{(i,j)} F_{ij} z_{ij} + \gamma \\
 & \text{s.a} \\
 & \sum_{(i,j) \in A} \beta_{ij} z_{ij} \leq B \\
 & \sum_{i \in N} d_i \hat{\pi}_i + \sum_{(i,j) \in A} u_{ij} z_{ij} \hat{\theta}_{ij} \leq \gamma \quad (\hat{\pi}, \hat{\theta}) \in V \\
 & \sum_{i \in N} d_i \tilde{\pi}_i + \sum_{(i,j) \in A} u_{ij} z_{ij} \tilde{\theta}_{ij} \leq 0 \quad (\tilde{\pi}, \tilde{\theta}) \in H \\
 & z_{ij} \in \{0, 1\} \quad (i,j) \in A
 \end{aligned}$$

Donde V es un conjunto de vértices del problema satélite y H es un conjunto de rayos de recesión del satélite

Una vez descompuesto el problema, este se puede resolver iterando, podemos partir resolviendo el problema maestro con los conjuntos V y H vacíos. Sea (z, γ) la solución del maestro, reemplazamos este z en la función objetivo del satélite y lo resolvemos, si el satélite es no acotado, agregamos el rayo de recesión $(\tilde{\pi}, \tilde{\theta})$ a H y volvemos a resolver el maestro. Si el satélite es acotado, agregamos el vértice solución $(\hat{\pi}, \hat{\theta})$ a V y si el valor objetivo del satélite es mayor que γ entonces volvemos a resolver el maestro. En caso contrario, tenemos que la solución actual es óptima.

Un problema de planificación agrícola con Dantzig-Wolfe

Un empresa del sector agropecuario necesita planificar sus actividades de cosecha y procesamiento de frutas sobre un horizonte de T períodos de tiempo (días, para fijar ideas). Existen n parcelas que pueden ser cosechadas, y la disponibilidad de fruta en la parcela j es L_j (kilos). Hay un costo por kilo cosechado en cada período, c_{jt} y también un costo fijo cada vez que se decide cosechar una parcela, f_{jt} . Además, hay personal empleado en la cosecha y α_{jt} es el requerimiento unitario de mano de obra (en horas) en la parcela j en el periodo t , y el total disponible en el periodo t es igual a B_t . Además, una parcela sólo se puede cosechar una vez en todo el horizonte, aunque sea parcialmente. Una vez cosechada la fruta, debe ser procesada en una de m plantas de procesamiento, para lo cual la fruta cosechada en un día es acumulada y enviada a alguna de las plantas (todo está cerca, así que el transporte lo consideraremos despreciable). La planta de procesamiento i puede recibir un máximo de K_i kilos sobre todo el horizonte de tiempo. La empresa vende la fruta procesada de la planta i a un precio p_i . El costo de procesamiento es e_{it} para la planta i en el día t .

La empresa ha construido el siguiente modelo de optimización para encontrar la planificación más rentable, el que usa las siguientes variables:

x_{jt} : kilos cosechados en la parcela j el día t .

y_{jt} : vale 1 si se cosecha la parcela j en t , 0 en caso contrario.

z_{it} : kilos procesados en la planta i en t .

El modelo es:

$$\begin{aligned}
 \text{máx} \quad & \sum_{t=1}^T \sum_{i=1}^m p_i z_{it} - \sum_{t=1}^T \left\{ \sum_{j=1}^n c_{jt} x_{jt} + \sum_{j=1}^n f_{jt} y_{jt} + \sum_{i=1}^m e_{it} z_{it} \right\} \\
 \text{s.a.} \quad & \sum_{j=1}^n \alpha_{jt} x_{jt} \leq B_t, \quad t = 1, \dots, T \quad (1) \\
 & x_{jt} \leq L_j y_{jt}, \quad j = 1, \dots, n; t = 1, \dots, T \quad (2) \\
 & \sum_{t=1}^T y_{jt} \leq 1, \quad j = 1, \dots, n \quad (3) \\
 & \sum_{j=1}^n x_{jt} = \sum_{i=1}^m z_{it}, \quad t = 1, \dots, T \quad (4) \\
 & \sum_{t=1}^T z_{it} \leq K_i, \quad i = 1, \dots, m \quad (5) \\
 & x_{jt} \geq 0, z_{it} \geq 0, y_{jt} \in \{0, 1\}, j = 1, \dots, n; t = 1, \dots, T; i = 1, \dots, m \quad (6)
 \end{aligned}$$

Lo primero que haremos será identificar en el problema una estructura que permita aplicar la descomposición de Dantzig-Wolfe al problema.

Las restricciones (3) y (5) pueden ser consideradas complicantes en el sentido que ligan las decisiones con respecto al índice t , del tiempo. Si no estuvieran, el problema se separa por periodos de tiempo independientes en las otras variables. Vamos a reordenar el problema:

$$\begin{aligned}
 \text{máx} \quad & \sum_{t=1}^T \left\{ - \sum_{j=1}^n c_{jt} x_{jt} - \sum_{j=1}^n f_{jt} y_{jt} + \sum_{i=1}^m (p_i - e_{it}) z_{it} \right\} \\
 \text{s.a.} \quad & \sum_{t=1}^T y_{jt} \leq 1, \quad j = 1, \dots, n \quad (3) \\
 & \sum_{t=1}^T z_{it} \leq K_i, \quad i = 1, \dots, m \quad (5) \\
 & \sum_{j=1}^n \alpha_{jt} x_{jt} \leq B_t, \quad t = 1, \dots, T \quad (1) \\
 & x_{jt} - L_j y_{jt} \leq 0, \quad j = 1, \dots, n; t = 1, \dots, T \quad (2) \\
 & \sum_{j=1}^n x_{jt} - \sum_{i=1}^m z_{it} = 0, \quad t = 1, \dots, T \quad (4) \\
 & x_{jt} \geq 0, z_{it} \geq 0, y_{jt} \in \{0, 1\}, \quad j = 1, \dots, n; t = 1, \dots, T; i = 1, \dots, m \quad (6)
 \end{aligned}$$

El cual podemos hacer más explícito, en forma “estirada”, para hacer más visible la estructura de D-W:

$$\begin{array}{llll}
\text{máx} & \sum_{j=1}^n (-c_{j1}x_{j1} - f_{j1}y_{j1}) + \sum_{i=1}^m (p_i - e_{i1})z_{i1} & + \cdots + & \sum_{j=1}^n (-c_{jT}x_{jT} - f_{jT}y_{jT}) + \sum_{i=1}^m (p_i - e_{iT})z_{iT} \\
s.a. & & & \\
& y_{j1} & + \cdots + & y_{jT} & \leq 1, \forall j \\
& z_{i1} & + \cdots + & z_{iT} & \leq K_i, \forall i \\
& \sum_{j=1}^n \alpha_{j1}x_{j1} & & & \leq B_1 \\
& x_{j1} - L_j y_{j1} & & & \leq 0, \forall j \\
& \sum_{j=1}^n x_{j1} - \sum_{i=1}^m z_{i1} & & & = 0 \\
& \vdots & \ddots & & \vdots \\
& & & \sum_{j=1}^n \alpha_{jT}x_{jT} & \leq B_T \\
& & & x_{jT} - L_j y_{jT} & \leq 0, \forall j \\
& & & \sum_{j=1}^n x_{jT} - \sum_{i=1}^m z_{iT} & = 0, \forall t \\
& x_{jt} \geq 0, z_{it} \geq 0, y_{jt} \in \{0, 1\}, & & & \forall i, j, t
\end{array}$$

Notemos que en el bloque común, las variables x no aparecen, sólo lo hacen las variables y y z .

Ahora vamos a desarrollar los elementos de la Descomposición de Dantzig-Wolfe para el problema, usando la estructura identificada anteriormente.

Desarrollar la descomposición es un ejercicio de entender la forma como esta se desarrolla y, también, poder adaptar la notación ya que hay que hacerlo para este problema particular. Primero, la descomposición resuelve la relajación lineal del problema, es decir, el problema:

$$\begin{array}{llll}
\text{máx} & \sum_{j=1}^n (-c_{j1}x_{j1} - f_{j1}y_{j1}) + \sum_{i=1}^m (p_i - e_{i1})z_{i1} & + \cdots + & \sum_{j=1}^n (-c_{jT}x_{jT} - f_{jT}y_{jT}) + \sum_{i=1}^m (p_i - e_{iT})z_{iT} \\
s.a. & & & \\
& y_{j1} & + \cdots + & y_{jT} & \leq 1, \forall j \\
& z_{i1} & + \cdots + & z_{iT} & \leq K_i, \forall i \\
& \sum_{j=1}^n \alpha_{j1}x_{j1} & & & \leq B_1 \\
& x_{j1} - L_j y_{j1} & & & \leq 0, \forall j \\
& \sum_{j=1}^n x_{j1} - \sum_{i=1}^m z_{i1} & & & = 0 \\
& \vdots & \ddots & & \vdots \\
& & & \sum_{j=1}^n \alpha_{jT}x_{jT} & \leq B_T \\
& & & x_{jT} - L_j y_{jT} & \leq 0, \forall j \\
& & & \sum_{j=1}^n x_{jT} - \sum_{i=1}^m z_{iT} & = 0, \forall t \\
& x_{jt} \geq 0, z_{it} \geq 0, 0 \leq y_{jt} \leq 1, & & & \forall i, j, t
\end{array}$$

Los poliedros asociados a los T bloques del problema están descritos por las siguientes restricciones:

$$\begin{array}{ll}
\sum_{j=1}^n \alpha_{jt}x_{jt} & \leq B_t \\
x_{jt} - L_j y_{jt} & \leq 0, \forall j \\
\sum_{j=1}^n x_{jt} - \sum_{i=1}^m z_{it} & = 0 \\
x_{jt} \geq 0, z_{it} \geq 0, 0 \leq y_{jt} \leq 1, & \forall i, j
\end{array}$$

Notemos que las variables x están acotadas, lo que implica que las z también lo están, y las y también lo están de manera natural. Esto significa que sólo hay que considerar vértices de estos poliedros al desarrollar la Descomposición de DW. Ahora, es útil tratar de reconocer la estructura algebraica de DW, la cual es:

$$\begin{array}{llll} \text{mín} & c_1^T x^1 & + \cdots + & c_T^T x^T \\ \text{s.a.} & A_1 x^1 & + \cdots + & A_T x^T = b \\ & D_1 x^1 & & = d_1 \\ & \vdots & \ddots & \vdots \\ & & & D_T x^T = d_T \\ & x_1 \geq 0 & & x_T \geq 0 \end{array}$$

Acá, cada vector x^i corresponde al vector concatenado de las variables x_{jt} , y_{jt} , z_{it} , y vamos a denotarlo (x^t, y^t, z^t) , donde estaremos poniendo el índice del bloque, t , como superíndice. Las matrices D_t son, precisamente, las de las restricciones de cada bloque, y eso ya lo tenemos bien identificado. Las matrices A_t , por otro lado tienen la siguiente estructura, en términos de las variables (x^t, y^t, z^t) (la primera fila de la matriz sólo es un encabezado indicando el orden de las variables):

$$A_t = \begin{bmatrix} x^t & y^t & z^t \\ 0 & I & 0 \\ 0 & 0 & I \end{bmatrix}$$

Entonces, siguiendo la lógica de la descomposición de DW, supongamos que $(\bar{x}^{tk}, \bar{y}^{tk}, \bar{z}^{tk})$ es uno de los puntos extremos del poliedro del bloque t . La columna en el problema maestro es:

$$A_t \times \begin{bmatrix} \bar{x}^{tk} \\ \bar{y}^{tk} \\ \bar{z}^{tk} \end{bmatrix} = \begin{bmatrix} \bar{y}^{tk} \\ \bar{z}^{tk} \end{bmatrix}$$

y el coeficiente de la función objetivo es:

$$\sum_{j=1}^n (-c_{jt} \bar{x}_{jt}^k - f_{jt} \bar{y}_{jt}^k) + \sum_{i=1}^m (p_i - e_{it}) \bar{z}_{it}^k$$

Todo lo que hemos desarrollado hasta ahora es para la columna (t, k) del problema transformado de DW, que da origen al problema maestro. Entonces, suponemos que hasta ahora, por cada bloque t se han generado r_t vértices. Denotemos por λ_{tk} los ponderadores de la descomposición de los puntos extremos del poliedro del bloque k . El problema maestro es:

$$\begin{array}{ll} \text{máx} & \sum_{t=1}^T \sum_{k=1}^{r_t} \lambda_{tk} \left\{ \sum_{j=1}^n (-c_{jt} \bar{x}_{jt}^k - f_{jt} \bar{y}_{jt}^k) + \sum_{i=1}^m (p_i - e_{it}) \bar{z}_{it}^k \right\} \\ \text{s.a.} & \sum_{t=1}^T \sum_{k=1}^{r_t} \lambda_{tk} \bar{y}_{jt}^k \leq 1, \quad j = 1, \dots, n \quad (a) \\ & \sum_{t=1}^T \sum_{k=1}^{r_t} \lambda_{tk} \bar{z}_{it}^k \leq K_i, \quad i = 1, \dots, m \quad (b) \\ & \sum_{k=1}^{r_t} \lambda_{tk} = 1, \quad t = 1, \dots, T \quad (c) \\ & \lambda_{tk} \geq 0, \quad t = 1, \dots, T; k = 1, \dots, r_t \quad (d) \end{array}$$

Sean u_j las variables duales de las restricciones (a), v_i las variables duales de las restricciones (b), y s_t las variables duales de las restricciones (c). El costo reducido que se debe buscar, para un vértice k en el bloque t , es:

$$\bar{c}_{tk} = \left\{ \sum_{j=1}^n (-c_{jt} \bar{x}_{jt}^k - f_{jt} \bar{y}_{jt}^k) + \sum_{i=1}^m (p_i - e_{it}) \bar{z}_{it}^k \right\} - \sum_{j=1}^n u_j \bar{y}_{jt}^k - \sum_{i=1}^m v_i \bar{z}_{it}^k - s_t$$

Luego, el problema satélite busca resolver, para cada bloque t :

$$\begin{aligned}
\eta_t = \max \quad & \sum_{j=1}^n (-c_{jt}x_{jt} - (f_{jt} + u_j)y_{jt}) + \sum_{i=1}^m (p_i - e_{it} - v_i)z_{it} \\
s.a. \quad & \sum_{j=1}^n \alpha_{jt}x_{jt} \leq B_t \\
& x_{jt} - L_j y_{jt} \leq 0, \forall j \\
& \sum_{j=1}^n x_{jt} - \sum_{i=1}^m z_{it} = 0 \\
& x_{jt} \geq 0, z_{it} \geq 0, 0 \leq y_{jt} \leq 1, \quad \forall i, j
\end{aligned}$$

Si $\eta_t - s_t > 0$, entonces de la solución óptima de este problema se obtiene un nuevo vértice $(\bar{x}^{tk}, \bar{y}^{tk}, \bar{z}^{tk})$ que puede ser agregado al problema maestro. Nótese que, como este se hace para todos los bloques t , si hay candidatos a entrar a la base en los distintos bloques, pueden todos esos ser agregados al problema maestro en un formato de “multiple pricing”, tal como se explicó en clases. La descomposición de DW está muy bien configurada para funcionar de esa forma y, también, de usar computación paralela ya que los t satélites de cada bloque podrían ser resueltos en forma paralela.

El mismo problema anterior, pero via Descomposición de Benders

Podemos ver que son variables complicantes en este problema las y , por ser enteras, y las x . De este modo, las (y, x) representan la parte del problema que representa la cosecha y las z representa el procesamiento, decisiones que dependen de las anteriores. El siguiente es el problema reordenado:

$$\begin{aligned}
\max \quad & \sum_{t=1}^T \left\{ - \sum_{j=1}^n c_{jt}x_{jt} - \sum_{j=1}^n f_{jt}y_{jt} \right\} + \sum_{t=1}^T \sum_{i=1}^m (p_i - e_{it})z_{it} \\
s.a. \quad & \sum_{j=1}^n \alpha_{jt}x_{jt} \leq B_t, \quad t = 1, \dots, T \quad (1) \\
& x_{jt} - L_j y_{jt} \leq 0, \quad j = 1, \dots, n; t = 1, \dots, T \quad (2) \\
& \sum_{t=1}^T y_{jt} \leq 1, \quad j = 1, \dots, n \quad (3) \\
& \sum_{j=1}^n x_{jt} - \sum_{i=1}^m z_{it} = 0, \quad t = 1, \dots, T \quad (4) \\
& \sum_{t=1}^T z_{it} \leq K_i, \quad i = 1, \dots, m \quad (5) \\
& x_{jt} \geq 0, y_{jt} \in \{0, 1\}, \quad z_{it} \geq 0, \quad j = 1, \dots, n; t = 1, \dots, T; i = 1, \dots, m \quad (6)
\end{aligned}$$

Para desarrollar la descomposición, tenemos que identificar el problema interior, que es el de las variables z . El problema, dadas las variables x , es:

$$\begin{aligned}
\max \quad & \sum_{t=1}^T \sum_{i=1}^m (p_i - e_{it})z_{it} \\
s.a. \quad & \sum_{i=1}^m z_{it} = \sum_{j=1}^n x_{jt}, \quad t = 1, \dots, T \\
& \sum_{t=1}^T z_{it} \leq K_i, \quad i = 1, \dots, m \\
& z_{it} \geq 0, j = 1, \dots, n; t = 1, \dots, T; i = 1, \dots, m
\end{aligned}$$

Vamos a necesitar el dual de este problema ya que es la base del problema satélite. Definamos variables duales u_t para las primeras T restricciones y variables duales v_i para las siguientes m . El dual es:

$$\begin{array}{llllll}
\text{máx} & b^T \pi & + d_1^T s^1 & + \cdots + & d_K^T s^K & \\
\text{s.a.} & & & & & \\
& A_1^T \pi & + D_1^T s^1 & + \cdots + & \cdots & \leq c_1 \\
& A_1^T \pi & + \cdots & + D_2^T s^2 & + \cdots & \leq c_2 \\
& \vdots & \ddots & \vdots & \vdots & \vdots \\
& A_K^T \pi & + \cdots & \cdots & + D_K^T s^K & \leq c_K
\end{array}$$

Se puede ver claramente que las variables π son complicantes. Notemos que no existen restricciones exclusivas para estas variables, pero el esquema de Benders se puede aplicar igual, de hecho.

A continuación se muestra el esquema de Benders, básicamente el maestro y el satélite, primero usando los símbolos generales de los bloques. Notemos, en primer lugar, que el problema es:

$$\begin{array}{ll}
\text{máx} & c^T \pi + d^T s \\
\text{s.a.} & E\pi + Ds \leq e
\end{array}$$

que se lleva a dos etapas de la siguiente forma:

$$\text{máx } c^T \pi + \text{máx } \{d^T s : Ds \leq e - E\pi\}$$

y que es lo mismo que:

$$\text{máx } c^T \pi + \text{mín } \{(e - E\pi)^T u : D^T u = d, u \geq 0\}$$

Esto lleva al siguiente maestro:

$$\begin{array}{ll}
\text{máx} & c^T \pi + \gamma \\
\text{s.a.} & \gamma \leq (e - E\pi)^T v^i, i = 1, \dots, t
\end{array}$$

donde v^i son vértices del poliedro definido por las restricciones $D^T u = d, u \geq 0$. Cuando se resuelve el maestro en esta iteración de índice t , se obtiene una solución π^t , la que es alimentada al satélite, el que es:

$$\begin{array}{ll}
\text{mín} & (e - E\pi^t)^T u \\
\text{s.a.} & D^T u = d \\
& u \geq 0
\end{array}$$

Ahora es el momento de recordar qué es lo que realmente son E, e y D , según el diagrama de más arriba. El u va por bloques de las matrices originales D_k , entre otras. Esto hace que el problema satélite anterior sea:

$$\begin{array}{ll}
\text{mín} & \sum_{k=1}^K (c_k - A_k^T \pi^t)^T u^k \\
\text{s.a.} & D_k^T u^k = d_k, k = 1, \dots, K \\
& u^k > 0, k = 1, \text{ dots }, K
\end{array}$$

y esto se descompone en K problemas independientes de la forma:

$$\begin{array}{ll}
\text{mín} & (c_k - A_k^T \pi^t)^T u^k \\
\text{s.a.} & D_k^T u^k = d_k
\end{array}$$

Estos satélites son exactamente el mismo problema satélite que aparecía en Dantzig-Wolfe. De hecho, es también el mismo problema satélite que aparecía en la aplicación de Relajación lagrangeana al problema original. Esto muestra cómo las distintas técnicas están relacionadas. De hecho, se dice a veces, que Bender es “dual” a Dantzig-Wolfe o, alternativamente, a Generación de Columnas.