



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
ESCUELA DE INGENIERÍA  
ICS2121 – MÉTODOS DE OPTIMIZACIÓN

---

# Apuntes de Métodos de Optimización

---

*Por Francisco García Aubert y Jorge Vera Andreo  
Material en desarrollo. No compartir fuera del curso.  
(versión 7, Agosto 2025)*



# Índice general

|                                                                               |          |
|-------------------------------------------------------------------------------|----------|
| <b>7. El Enfoque Dual para Problemas de Gran Tamaño</b>                       | <b>3</b> |
| 7.1. Dualidad Lagrangeana . . . . .                                           | 3        |
| 7.1.1. El Primal y el Dual . . . . .                                          | 3        |
| 7.1.2. Teorema débil y fuerte de dualidad . . . . .                           | 6        |
| 7.1.3. Múltiples duales . . . . .                                             | 6        |
| 7.2. Relajación Lagrangeana . . . . .                                         | 7        |
| 7.2.1. Ejemplos de Relajaciones Lagrangeanas . . . . .                        | 8        |
| 7.3. Resolviendo el Problema Dual: Método del Supgradiente . . . . .          | 11       |
| 7.4. Visión alternativa del dual y el algoritmo de planos cortantes . . . . . | 13       |
| 7.4.1. El Método de Planos Cortantes para el dual . . . . .                   | 14       |
| 7.4.2. Diferencias en las relajaciones (material avanzado) . . . . .          | 15       |
| 7.5. Ejemplos . . . . .                                                       | 17       |

## Capítulo 7

# El Enfoque Dual para Problemas de Gran Tamaño

Muchos problemas de gran tamaño son difíciles porque tienen restricciones complicantes. Como ya hemos visto, una forma de manejar esto es mediante la Descomposición de Dantzig-Wolfe, si es que la estructura puede ser descompuesta en bloques. Sin embargo, las estructuras de restricciones complicantes pueden ser más generales y necesitamos técnicas que permitan abordarlas. En este capítulo estudiaremos cómo la Dualidad Lagrangeana entrega las herramientas para abordar estos problemas. Para esto, introducimos primero algunos elementos de la teoría general de Dualidad Lagrangeana para luego aplicarlos para abordar problemas de gran tamaño.

### 7.1. Dualidad Lagrangeana

Vamos a introducir aquí las nociones generales de dualidad Lagrangeana que necesitamos. Este es un concepto mucho más amplio de dualidad que el que se ha estudiado en Programación Lineal, pero mostraremos que los resultados que ya conocemos se rescatan como casos particulares.

#### 7.1.1. El Primal y el Dual

Consideremos el siguiente problema general de optimización:

$$\begin{array}{ll} \text{mín} & f(x) \\ \text{s.a.} & g_i(x) \leq b_i, \quad i = 1, \dots, m \\ & x \in C \end{array}$$

Con  $x \in \mathbb{R}^n$ ,  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $i = 1, \dots, m$ , con  $C$  cerrado y no vacío. Luego, el Lagrangeano  $\mathcal{L} : \mathbb{R}^n \times \mathbb{R}_+^m \rightarrow \mathbb{R}$  se define como :

$$\mathcal{L}(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i (g_i(x) - b_i)$$

Donde  $x \in \mathbb{R}^n$  y  $\lambda \in \mathbb{R}_+^m$  son los multiplicadores de Lagrange. Notar que el Lagrangeano combina la función objetivo con las restricciones.

Ahora se define el **Problema Primal** como:

$$\text{mín}_{x \in C} \text{máx}_{\lambda \geq 0} \mathcal{L}(x, \lambda)$$

Este es un problema en dos niveles. La maximización sobre las variables  $\lambda$ , es el problema que está dentro del de minimización que controla un  $x$  que pertenece al conjunto  $C$ . Podemos pensar que para el problema interior, el  $x$  está fijo.

Por otro lado, se define el **Problema Dual** como:

$$\max_{\lambda \geq 0} \min_{x \in C} \mathcal{L}(x, \lambda)$$

En este, la minimización está dentro del problema de maximización y “ve” un  $\lambda$  fijo. Si alguna restricción  $i$  es de igualdad, entonces su respectivo  $\lambda_i$  es irrestricto. Notemos que este problema “invierte” el mín con el máx con respecto al Primal.

Se define también la **Función Dual** como:

$$\theta(\lambda) = \min_{x \in C} \mathcal{L}(x, \lambda), \quad \lambda \geq 0$$

Luego, el problema dual es maximizar la función dual:

$$\max_{\lambda \geq 0} \theta(\lambda)$$

Estos dos problemas que hemos definido se ven “extraños” y no parecen estar relacionados con lo que se entiende por primal y dual en Programación Lineal. Sin embargo, partamos por hacer notar algo sutil: el primal  $\min_{x \in C} \max_{\lambda \geq 0} \mathcal{L}(x, \lambda)$  coincide con el problema original. Para ver esto, se puede explicitar  $\mathcal{L}(x, \lambda)$  en el primal:

$$\min_{x \in C} \left\{ \max_{\lambda \geq 0} \left\{ f(x) + \sum_{i=1}^m \lambda_i (g_i(x) - b_i) \right\} \right\}$$

Notar que como el problema de adentro funciona para un  $x$  fijo, y  $f(x)$  no depende de  $\lambda$ , entonces el primal también puede escribirse como:

$$\min_{x \in C} \left\{ f(x) + \max_{\lambda \geq 0} \left\{ \sum_{i=1}^m \lambda_i (g_i(x) - b_i) \right\} \right\}$$

El problema interior de maximización opera con  $\lambda \geq 0$  como variable. Sucederá que si  $g_i(x) - b_i > 0$  para algún  $x$  y algún  $i$ , entonces óptimo para  $\lambda$  será tender a  $+\infty$ , por lo que se vuelve no acotado, ya que la maximización también se va a  $+\infty$ , valor que claramente no nos interesa, pues a final de cuenta queremos minimizar toda la expresión. Por este mismo hecho ( $g_i(x) - b_i > 0$ ), es a su vez una violación de la restricción del problema original. De este modo, para que el problema de minimización tenga sentido en el problema primal (no tiene sentido minimizar  $\{f(x) + \infty\}$ ) sobre  $x$ , debe cumplirse que  $g_i(x) - b_i \leq 0$ . De este modo, para que el problema de maximización que está dentro del primal no diverja, solo puede ser cero, que sería el óptimo del problema de maximización para que la cuestión tenga sentido. Así, el problema primal es:

$$\min_{\substack{x \in C \\ g_i(x) \leq b_i, \forall i}} \{f(x) + 0\} \quad \longrightarrow \quad \begin{array}{l} \text{es equivalente al} \\ \text{problema original} \end{array} \quad \longrightarrow \quad \begin{array}{ll} \min & f(x) \\ \text{s.a.} & g_i(x) \leq b_i, \quad \forall i \\ & x \in C \end{array}$$

Análogamente, se puede mostrar que, en el caso de Programación Lineal, el Problema Dual es igual al dual ya conocido del problema original. Para esto considérese que en el problema original  $f(x) = c^T x$  y que  $g_i(x) \leq b_i$  que eran las restricciones del problema, se escriben como  $\alpha_i^T x \leq b_i$  y el conjunto  $C$  al que pertenecen las  $x$  corresponde a  $x \geq 0$ , por lo que el problema original queda de la siguiente forma ( $\star$  Nota: ver este caso nuevamente considerando que  $x \in \mathbb{Z}_0^+$  después de ver dualidad fuerte  $\star$ ):

$$\begin{array}{ll} \min & c^T x \\ \text{s.a.} & Ax \leq b \\ & x \geq 0 \end{array}$$

El Lagrangeano de este problema es:

$$\mathcal{L}(x, \lambda) = c^T x + \sum_{i=1}^m \lambda_i (b_i - \alpha_i^T x)$$

Y el Problema Dual es  $\max_{\lambda \geq 0} \theta(\lambda)$ , con  $\theta(\lambda)$ , el problema de optimización sobre la variable  $x$  para un valor de  $\lambda$ , tal que:

$$\begin{aligned} \theta(\lambda) &= \min_{x \geq 0} \left\{ c^T x + \sum_{i=1}^m \lambda_i (b_i - \alpha_i^T x) \right\} \\ &= \min_{x \geq 0} \left\{ \sum_{j=1}^n x_j \left( c_j - \sum_{i=1}^m \alpha_{ij} \lambda_i \right) + \sum_{i=1}^m \lambda_i b_i \right\} \\ &= b^T \lambda + \min_{x \geq 0} \left\{ \sum_{j=1}^n x_j \left( c_j - \sum_{i=1}^m \alpha_{ij} \lambda_i \right) \right\} \end{aligned}$$

Del mismo modo que se hizo anteriormente, se debe observar que si  $c_j < \sum_{i=1}^m \alpha_{ij} \lambda_i$  para un determinado índice  $j$ , entonces el problema de minimización  $\theta(\lambda)$  va a tener por solución en la componente  $j$ ,  $x_j$ , un valor que tiende a  $+\infty$ , cosa que el valor objetivo tienda a  $-\infty$  y el problema de  $\max_{\lambda \geq 0} \theta(\lambda)$  no tenga sentido (es análogo al caso anterior donde se maximizaba y se iba a  $+\infty$ ). De este modo, el problema dual es tal que se busca maximizar  $\{b^T \lambda + 0\}$  sujeto a que  $\theta(\lambda)$  no diverga, por lo que el problema dual es:

$$\max_{A^T \lambda \leq c, \lambda \geq 0} \{b^T \lambda + 0\} \longrightarrow \text{es equivalente al dual} \longrightarrow \begin{array}{ll} \max & b^T \lambda \\ \text{s.a.} & A^T \lambda \leq c, \lambda \geq 0 \end{array}$$

De este modo, el problema original equivale al problema primal y el dual del original equivale al problema dual, por lo menos para Programación Lineal, por lo que hay consistencia.

Notemos también que si hemos llegado al óptimo en  $x^*$  con variables duales  $\lambda^*$ . Entonces:

$$z^* = f(x^*) = L(x^*, \lambda^*) = f(x^*) + \sum_{i=1}^m \lambda_i^* (g_i(x^*) - b_i)$$

Luego, se debe tener que:

$$\sum_{i=1}^m \lambda_i^* (g_i(x^*) - b_i) = 0$$

Estas son las holguras complementarias.

Cabe decir que detrás de todo este concepto de dualidad lagrangiana existe una interpretación económica como un equilibrio “mín máx” sobre la equivalencia entre:

$$P) \min_{x \in C} \max_{\lambda \geq 0} \mathcal{L}(x, \lambda) \quad \text{y} \quad D) \max_{\lambda \geq 0} \min_{x \in C} \mathcal{L}(x, \lambda)$$

Si uno es un comprador y tiene poder de decisión sobre  $x$  y el vendedor tiene poder de decisión sobre las variables  $\lambda$ , y la función lagrangeana representa el pago entre los dos, la estrategia óptima que puede adoptar el comprador es minimizar sobre las variables  $x$  la función lagrangiana que el vendedor intentará maximizar sobre  $\lambda$ . Esto es  $P$ ). Por otro lado, la estrategia que debe adoptar el vendedor es maximizar sobre su variable de decisión  $\lambda$  la función lagrangiana que el comprador está intentando minimizar sobre las variables  $x$ . Esto es  $D$ ). Bajo ciertas condiciones (lo que viene a continuación) estos dos problemas entregan el mismo valor óptimo. Esto está muy relacionado con el tema de Teoría de Juegos, que es uno de los elementos fundamentales sobre los que descansa la teoría de equilibrio económico.

### 7.1.2. Teorema débil y fuerte de dualidad

Para enunciar estos dos teoremas de dualidad, primero se precisa un concepto importante:

**Condición de Slater:** Esta condición se puede cumplir de cualquiera de las siguientes forma:

1. El problema es lineal puro
2. El problema es no lineal y la región factible tiene interior no vacío, es decir,  $\exists \bar{x} \in \mathbb{R}^n : g_i(\bar{x}) < b_i, \quad \forall i = 1 \dots m$ .

#### Teorema 7.1.1: Teorema débil de dualidad

*El dual (que maximiza) acota por abajo al primal, y este a su vez, acota al dual por arriba:*

$$w^* = \max_{\lambda \geq 0} \min_{x \in C} \mathcal{L}(x, \lambda) \leq \min_{x \in C} \max_{\lambda \geq 0} \mathcal{L}(x, \lambda) = z^*$$

Sabemos, por supuesto, que esto se cumple con igualdad en el caso de Programación Lineal. Eso es lo que dice el siguiente resultado:

#### Teorema 7.1.2: Teorema fuerte de dualidad

*Si el problema es convexo, o sea,  $f$  y  $g_i$  son funciones convexas,  $C$  es un conjunto convexo, y además se cumple la condición de Slater, entonces*

$$w^* = z^*$$

Como decíamos, Programación Lineal cumple dualidad fuerte. Pero, si el problema no es convexo, podría ocurrir que  $w^* < z^*$  y en ese caso hay un “salto de dualidad” (duality gap).

Un caso donde no se cumplen las condiciones de Slater es cuando las variables del problema son enteras ya que la restricción de integralidad rompe con la convexidad que pudiera tener el problema. Ahora, si se vuelve a revisar la construcción del dual del problema de Programación Lineal pero imponiendo que  $x \in \mathbb{Z}_0^+$ , puede verse que en ningún momento del desarrollo esta restricción de integralidad es un problema para llegar a exactamente a la misma conclusión que se llegó considerando que  $x \in \mathbb{R}_0^+$ . En otras palabras, el dual de un problema de Programación Lineal Entera es el dual de la relajación lineal del problema, y el valor óptimo de ese problema no es igual (necesariamente) al valor óptimo del problema original. Es por esto que, si bien el dual del problema con variables enteras cumple con el teorema fuerte para el problema de programación lineal (el relajado del entero), suele estar muy por abajo del óptimo del problema de programación entera, entonces típicamente  $w^* < z^*$ .

#### Cápsula de video 7.1.1: Programación Entera no tiene dualidad fuerte

*Profesor Jorge Vera muestra en clases el dual del problema de Programación entera, concluyendo que no existe, en general, dualidad fuerte en este caso:*  
<https://youtu.be/48imlaGWkOg>

### 7.1.3. Múltiples duales

Consideremos el siguiente ejemplo de problema de optimización:

$$\begin{aligned} z^* = \min \quad & x + 3(y - 4)^2 \\ \text{s.a.} \quad & x^2 + y^2 \leq 4 \\ & x + y \leq 3 \\ & x, y \in \mathbb{Z}_0^+ \end{aligned}$$

Una observación importante es que tenemos un grado de libertad para definir “un” dual para este problema. En efecto, qué restricciones serán elegidas para formar el lagrangiano y cuáles permanecen como definición del conjunto  $C$  puede ser una decisión importante. Para este problema, mostramos a continuación dos posibles definiciones de Lagrangianos y conjuntos  $C$ :

$$\begin{aligned} \mathcal{L}_1(x, \lambda_1, \lambda_2) &= x + 3(y - 4)^2 + \lambda_1(x^2 + y^2) + \lambda_2(x + y - 3) & \text{y} & \quad \mathcal{L}_2(x, \lambda) = x + 3(y - 4)^2 + \lambda(x^2 + y^2) \\ C_1 &= \{x, y : x, y \in \mathbb{Z}_0^+\} & & \quad C_2 = \{x, y : x + y \leq 3, x, y \in \mathbb{Z}_0^+\} \end{aligned}$$

Cada uno de estos dos Lagrangeanos da origen a dos duales diferentes que darán origen a valores duales,  $w^1$  y  $w^2$  potencialmente diferentes. Si las restricciones de integralidad,  $x, y \in \mathbb{Z}_0^+$  no existieran, entonces el problema original sería convexo, cumpliría la condición de Slater y, en ese caso,  $w^1 = w^2 = z^*$ . Sin embargo, la restricción de integralidad hace que se rompa la convexidad y, por lo tanto, no hay dualidad fuerte, es decir,  $w^1 < z^*$ ,  $w^2 < z^*$ . Sin embargo, uno de los dos duales será “mejor” que el otro: aquel que aporte el valor dual más cercano a  $z^*$ .

En un problema de optimización que posea, en general,  $m$  restricciones, existirán, entonces, potencialmente  $O(2^m)$  posibles duales y todos podrían dar valores diferentes (asumiendo que no haya dualidad fuerte). En problema de alta dificultad, podría ser imposible (o muy costoso) resolver el primal y ahí es donde adquiere relevancia considerar el dual. Nos gustaría mucho poder “descubrir” el dual que nos entregue el mejor valor, que será, entonces, la mejor cota inferior disponible al valor (desconocido)  $z^*$ . Encontrar ese “mejor” dual puede ser un problema muy complejo, pero podríamos guiarnos por buenos criterios y construir un buen dual. Esto es lo que motiva el enfoque de Relajación Lagrangeana, que se explica en la siguiente sección.

## 7.2. Relajación Lagrangeana

En lo que sigue, vamos a considerar, en forma más específica, un problema de Programación Lineal Entera de la siguiente forma:

$$\begin{aligned} \text{mín} \quad & c^T x \\ \text{s.a.} \quad & \alpha_i^T x \leq b_i, i = 1, \dots, p \\ & \beta_i^T x \leq d_i, i = 1, \dots, q \\ & x \geq 0, \text{ entero} \end{aligned}$$

donde  $\alpha_i \in \mathbb{R}^n$ ,  $\beta_i \in \mathbb{R}^n$ ,  $c \in \mathbb{R}^n$  y los  $b_i$  son escalares.

Supongamos que las primeras  $p$  restricciones son “complicantes”. Podemos interpretar esto en el sentido que si esas restricciones no estuvieran presentes, el problema que queda sería más abordable que el problema original. Formemos el siguiente Lagrangeano, solo con las restricciones “complicantes”:

$$L(x, \lambda) = c^T x + \sum_{i=1}^p \lambda_i(\alpha_i^T x - b_i)$$

Y sea

$$C = \{x : x \geq 0, \text{ entero}, \beta_i^T x \leq d_i, i = 1, \dots, q\}$$

De este modo, al problema original se le “quitan” restricciones complicantes y se le “pasan” al Lagrangeano, de modo que las restricciones que quedan en  $C$  son menos que las que habían en el problema original. Por esta razón, al problema resultante se le llama “problema relajado”. La función dual asociada a ese Lagrangeano es:

$$\theta(\lambda) = \min_{x \in C} \{c^T x + \sum_{i=1}^p \lambda_i(\alpha_i^T x - b_i)\}$$

o, en forma más explícita:

$$\begin{aligned} \theta(\lambda) &= \min_{\text{s.a.}} \quad c^T x + \sum_{i=1}^p \lambda_i(\alpha_i^T x - b_i) \\ & \quad \beta_i^T x \leq d_i, i = 1, \dots, q \\ & \quad x \geq 0, \text{ entero} \end{aligned}$$


NO dejemos de observar que, si bien la función objetivo se ve más compleja, es lineal en  $x$ , los valores  $\lambda_i$  son fijos para efectos de este problema relajado.

Entonces, el problema dual consiste en obtener:

$$w^* = \max_{\lambda \geq 0} \theta(\lambda)$$

La propuesta es, entonces, resolver este dual y esperar que el valor de  $w^*$  no sea muy diferente del problema original. Debido al uso del Lagrangeano y al hecho que se está pasando a un problema con menos restricciones, al enfoque resultante se le conoce como “**Relajación Lagrangeana**”.

Se puede demostrar que la función dual es una función cóncava en las variables  $\lambda$ . Luego, el problema dual consiste en maximizar una función cóncava, lo que debería ser “fácil” (es equivalente a minimizar una convexa). Si se visualizara esta función se vería un gráfico del siguiente tipo:



Tal como se puede ver, este es un problema no diferenciable, el cual puede ser abordado mediante el Método del Subgradiente, como se explica más adelante.

### 7.2.1. Ejemplos de Relajaciones Lagrangeanas

#### Problema con estructura de bloques

Consideremos un problema estándar de Programación lineal similar al que se usó para desarrollar la Descomposición de Dantzig-Wolfe:

$$\begin{array}{llll} \text{mín} & c_1^T x_1 & + \cdots + & c_K^T x_K \\ \text{s.a.} & A_1 x_1 & + \cdots + & A_K x_K = b \\ & D_1 x_1 & & = d_1 \\ & \vdots & \ddots & \vdots \\ & & & D_K x_K = d_K \\ & x_1 \geq 0, & \dots & x_K \geq 0 \end{array}$$

Como discutimos antes, las restricciones comunes son complicantes y las vamos a usar para formar un dual.

El lagrangeano se puede expresar como:

$$\mathcal{L}(x, \lambda) = c_1^T x_1 + \cdots + c_K^T x_K + \lambda^T (A_1 x_1 + \cdots + A_K x_K - b)$$

Con

$$C = \{(x_1, \dots, x_K) \geq 0 : D_k x_k = d_k, x_k \geq 0, k = 1 \dots K\}$$

La función dual, con  $\lambda$  irrestricta es:

$$\theta(\lambda) = \min_{x \in S} \left\{ \sum_{k=1}^K c_k x_k + \lambda^T \left( \sum_{k=1}^K A_k x_k - b \right) \right\}$$

Reordenando los términos queda:

$$\theta(\lambda) = \min_{x \in S} \left\{ \sum_{k=1}^K (c_k + A_k^T \lambda)^T x_k - \lambda^T b \right\}$$

De modo que lo que se minimiza tiene la siguiente estructura:

$$\theta(\lambda) = \sum_{k=1}^K \theta^k(\lambda) - \lambda^T b$$

Donde cada  $\theta^k(\lambda)$  es:

$$\begin{array}{ll} \min & (c_k + A_k^T \lambda)^T u \\ \text{s.a.} & D_k u = d_k \\ & u \geq 0 \end{array}$$

Estos problemas tienen la misma forma que tenían los problemas satélite de la descomposición de Dantzig-Wolfe. La diferencia aquí es el origen de los  $\lambda$  ya que en el caso de la descomposición, vienen de las variables duales del problema maestro, que es una construcción parcial del problema que se está resolviendo, mientras que acá vienen de la solución parcial de un dual lagrangiano. La interpretación de la descomposición, sin embargo, es similar: aquí los  $\lambda$  son “precios duales” que penalizan a los satélites por no cumplir con las restricciones comunes. Esos precios se deberían ir ajustando hasta alcanzar el balance óptimo.

### Problema de Asignación Generalizada

Consideremos un problema donde hay entidades que se quieren asignar a trabajos, de modo que se utilizan variables binarias  $x_{ij}$  que valen 1 cuando las entidades  $i$  son asignadas al trabajo  $j$ . Pero, existen, además, restricciones que deben cumplirse con valores mínimos:

$$\begin{array}{ll} \min & \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s.a.} & \sum_{j=1}^n x_{ij} = 1, \quad i = 1, \dots, m \quad (1) \\ & \sum_{i=1}^m a_{ij} x_{ij} \geq b_j, \quad j = 1, \dots, n \quad (2) \\ & x_{ij} \in \{0, 1\}, \quad \forall (i, j) \end{array}$$

Este es un problema de programación entera, y no convexo. (1) dice que toda entidad es asignada a un trabajo y (2) dice que existe un requisito mínimo  $b_j$  para cada trabajo  $j$ , que se satisface con la contribución de ciertos pesos  $a_{ij}$  cuando la entidad  $i$  trabaja en  $j$ . En este problema hay  $n + m$  restricciones. La idea es relajar la familia de restricciones “complicantes”. Sin embargo, acá no es tan obvio cuáles restricciones son las complicantes. Es por esto que se proponen ver los dos tipos de relajaciones generales que se puede hacer en este problema.

### Relajación 1

Relajamos las restricciones (1), por lo que se van a necesitar  $m$  variables duales:  $\lambda_i$ ,  $i = 1, \dots, m$  que son irrestrictas (por los “=”). De este modo, el problema relajado de la función dual es:

$$\begin{array}{ll} \theta_1(\lambda) = \min & \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} + \sum_{i=1}^m \lambda_i \left( \sum_{j=1}^n x_{ij} - 1 \right) \\ \text{s.a.} & \sum_{i=1}^m a_{ij} x_{ij} \geq b_j, \quad j = 1 \dots n \\ & x_{ij} \in \{0, 1\}, \quad \forall (i, j) \end{array}$$

Este problema sigue siendo de programación entera. Se reorganiza la función objetivo y se tiene:

$$\begin{aligned}\theta_1(\lambda) = \min \quad & \sum_{j=1}^n \sum_{i=1}^m (c_{ij} + \lambda_i) x_{ij} - \sum_{i=1}^m \lambda_i \\ \text{s.a.} \quad & \sum_{i=1}^m a_{ij} x_{ij} \geq b_j, \quad j = 1, \dots, n \\ & x_{ij} \in \{0, 1\}, \quad \forall (i, j)\end{aligned}$$

La suma de los  $\lambda_i$  en el último sumando, para efectos de la función dual es constante, por lo que no entra en la minimización, solo entran los  $x_{ij}$ . Nótese que en la familia de restricciones que quedó, no hay ninguna que combine distintos  $j$ , por lo que este problema de asignación se puede separar en  $n$  subproblemas más pequeños:

$$\theta_1(\lambda) = \sum_{j=1}^n z_j(\lambda) - \sum_{i=1}^m \lambda_i$$

Donde se define la función  $z_j(\lambda)$  para un  $j$  fijo como:

$$\begin{aligned}z_j(\lambda) = \min \quad & \sum_{i=1}^m (c_{ij} + \lambda_i) x_{ij} \\ \text{s.a.} \quad & \sum_{i=1}^m a_{ij} x_{ij} \geq b_j \\ & x_{ij} \in \{0, 1\}, \quad \forall i\end{aligned}$$

Este es un problema de minimización con solo una restricción, e integralidad. Este es un problema de mochila, que puede ser resuelto mediante programación dinámica, entre otras alternativas. En resumen, para resolver el problema relajado o calcular el valor de la función dual para un  $\lambda$  específico se deben resolver  $n$  problemas de mochila, obtener los valores óptimos y sumarlos en  $\theta_1(\lambda)$ .

## Relajación 2

Relajamos las restricciones (2), por lo que se van a necesitar  $n$  variables duales:  $\mu_i$ ,  $i = 1, \dots, n$  que son no negativas,  $\mu_i \geq 0$ ,  $i = 1, \dots, n$ . De este modo, el problema relajado es:

$$\begin{aligned}\theta_2(\lambda) = \min \quad & \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} + \sum_{j=1}^n \mu_j \left( b_j - \sum_{i=1}^m a_{ij} x_{ij} \right) \\ \text{s.a.} \quad & \sum_{j=1}^n x_{ij} = 1, \quad i = 1, \dots, m \\ & x_{ij} \in \{0, 1\}, \quad \forall (i, j)\end{aligned}$$

Este problema sigue siendo de programación entera. Se reorganiza la función objetivo y se obtiene:

$$\begin{aligned}\theta_2(\lambda) = \min \quad & \sum_{i=1}^m \sum_{j=1}^n (c_{ij} + \mu_i a_{ij}) x_{ij} + \sum_{j=1}^n \mu_j b_j \\ \text{s.a.} \quad & \sum_{j=1}^n x_{ij} = 1, \quad i = 1, \dots, m \\ & x_{ij} \in \{0, 1\}, \quad \forall (i, j)\end{aligned}$$

La suma de los  $\mu_i b_j$  al lado derecho, para efectos de la función dual es constante, por lo que no entra en la minimización, solo entran los  $x_{ij}$ . Nótese que en la familia de restricciones que quedó, no hay ninguna que combine distintos  $i$ , por lo que este problema de asignación se puede separar en  $m$  subproblemas más chicos:

$$\theta_2(\lambda) = \sum_{i=1}^m v_i(\mu) + \sum_{j=1}^n \mu_j b_j$$

Donde se define la función  $v_i(\mu)$  para un  $i$  fijo como:

$$\begin{aligned} v_i(\mu) = \min \quad & \sum_{j=1}^n (c_{ij} + \mu_i a_{ij}) x_{ij} \\ \text{s.a.} \quad & \sum_{j=1}^n x_{ij} = 1 \\ & x_{ij} \in \{0, 1\}, \quad \forall (i, j) \end{aligned}$$

Este es un problema de minimización con solo una restricción e integralidad. Este es un problema de la mochila, pero que tiene una estructura tal que se puede resolver de manera muy fácil. Por la restricción, se sabe que para un determinado  $i$ , entre todos los  $x_{ij}$  para distintos valores de  $j$ , solo uno vale 1, por lo que se debe probar para los  $n$  posibles números de la función objetivo, buscar el más pequeño y así se llega al óptimo, en orden de  $n$  cálculos  $\mathcal{O}(n)$ , lo que es mucho más rápido que en el caso del problema de mochila de la Relajación 1.

En conclusión, la evaluación de la función dual (o resolver el problema relajado) en esta Relajación 2 podría llegar a ser mucho más fácil que en el caso de la Relajación 1. Se puede demostrar, sin embargo, que el valor dual que se obtenga de la Relajación 2 puede ser más malo que el de la Relajación 1. Esto se explica por el hecho que el problema relajado de la segunda relajación tiene la “propiedad de integralidad”, que significa que si se resuelve como problema de Programación Lineal, las variables tomarán valores enteros en forma natural. En forma intuitiva, lo que ha pasado es que el problema fue “excesivamente relajado”, perdiendo buena parte de la estructura que aporta al problema. Esa misma estructura aporta, igualmente, complejidad, pero esa complejidad del problema no puede ser eliminada completamente. Si lo hacemos, pagaremos el precio de una mala cota.

### 7.3. Resolviendo el Problema Dual: Método del Supgradiente

Como ya hemos comentado, la función dual es cóncava y el problema dual busca maximizar dicha función:

$$w^* = \max_{\lambda \geq 0} \theta(\lambda)$$

Este problema es, evidentemente, equivalente a

$$\min_{\lambda \geq 0} -\theta(\lambda)$$

que es un problema de minimización con una función objetivo convexa no diferenciable. Como ya sabemos, este puede ser abordado por el Método del Subgradiente que estudiamos en el Capítulo 2. Eso es lo que haremos ahora, aunque reescribiremos el método directamente para abordar el problema de maximización. Por esa razón hablaremos del método de “supgradiente” en vez de “subgradiente”, haciendo alusión al hecho que, para una función cóncava, los supgradienates definen los hiperplanos tangentes que están por arriba del grafo de la función.

El algoritmo es el siguiente:

**Algoritmo del supgradiente para el problema dual****Data:** Sea  $\lambda^0 \in \mathbb{R}^m$ ,  $k = 0$ **while** Criterio de parada no se satisface **do:** $h^k = -u$ , donde  $u \in \partial(-\theta(\lambda^k))$ 

resolver:

$$\lambda^{k+1} = \lambda^k + t_k h^k$$

(Atención si se requiere que  $\lambda \in \mathbb{R}_+^m$ )**end**

En el algoritmo,  $t_k$  es el paso de avance y explicaremos esto en breve. Notemos también que, como  $\theta(\lambda^k)$  es cóncava, entonces  $-\theta(\lambda^k)$  es convexa, y  $u \in \partial(-\theta(\lambda^k))$ ,  $u$  es un subgradiente, pero si  $h^k = -u$ , entonces  $h^k$  es un supgradiente.

Para usar el algoritmo necesitamos identificar un subgradiente y, afortunadamente, eso no es difícil.

**Proposición:** Dado  $\lambda^k$ , sea  $\bar{x}^k$  solución óptima del problema que calcula  $\theta(\lambda^k)$  para la iteración  $k$ . Sea  $h_i = g_i(\bar{x}^k) - b_i$ . Entonces,  $h \in \partial(-\theta(\lambda^k))$

Para dar una justificación intuitiva de este resultado, notemos que

$$\theta(\lambda^k) = \min_{x \in C} \left\{ f(x_k) + \sum_{i=1}^m \lambda_i^k (g_i(x_k) - b_i) \right\} = f(\bar{x}_k) + \sum_{i=1}^m \lambda_i^k (g_i(\bar{x}_k) - b_i),$$

donde se tiene que  $h_i = g_i(\bar{x}^k) - b_i$ . Ahora, si derivamos este valor óptimo en función de lambda se tendría algo así:

$$\frac{\partial}{\partial \lambda} \theta(\lambda^k) = \frac{\partial}{\partial \lambda} \left( f(\bar{x}_k) + \sum_{i=1}^m \lambda_i^k (h_i^k) \right) = h$$

Igualmente, se puede justificar el resultado en forma rigurosa directamente de la definición de subgradiente. De este modo, el subgradiente se obtiene como “subproducto” del proceso de evaluar la función dual y resolver el problema relajado.

Un tema que debe abordarse en el algoritmo es qué hacer si se requiere que  $\lambda \geq 0$ . En este caso, y siguiendo las ideas del Capítulo 2, basta con proyectar sobre esas restricciones. Es decir, calcularemos la siguiente iteración de esta forma:

$$\lambda^{k+1} = \max \{0, \lambda^k + t^k h^k\}$$

Una pregunta importante es el paso elegir. Esto es método de subgradiente y podríamos usar algo como  $1/\sqrt{k}$ , donde  $k$  es el número de iteración, como se sugería en el Capítulo 2. Esto se puede utilizar, pero en Relajación Lagrangeana se hace algo diferente que es mejor, i que se inspira en la aplicación específica a Programación Lineal Entera. Sea  $U^k$  una cota superior a  $z^*$ . Además, sea  $h^k$  la dirección de avance y  $\theta(\lambda^k)$  el valor actual de la función dual en la iteración  $k$ . Se propone el siguiente paso en la iteración  $k$ :

$$t_k = \rho \cdot \frac{U^k - \theta(\lambda^k)}{\|h^k\|_2^2}$$

Donde  $\rho \in [1/2, 2]$  es un factor de control que se ajusta “a mano”.

Cómo obtener esa cota superior es una gran pregunta. Veremos que eso se puede hacer mediante un procedimiento de aproximación que llamaremos una “Heurística Lagrangeana”. Los pasos son las siguientes:

- En la iteración  $k$  resolvemos  $\theta(\lambda^k)$  y obtenemos una solución  $\bar{x}^k$ .

- Esta solución **no cumple** las restricciones relajadas, pero sí las restricciones del conjunto  $C$  y que se usaron en el problema relajado.
- La idea es aplicar algún procedimiento computacional a  $\bar{x}^k$  para transformarlo en una nueva solución  $\tilde{x}^k$  que sí cumpla, además, las restricciones relajadas y por lo tanto sea factible al problema original.
- Entonces podríamos utilizar  $U^k = f(\tilde{x}^k)$ .

De este modo, la iteración  $k$  del algoritmo tendremos dos valores que cumplen:

$$\theta(\lambda^k) \leq z^* \leq U^k$$

De hecho, dado que la evolución de los valores no es necesariamente monótona, deberíamos tomar el mejor valor dual hasta la iteración  $k$  así como la mejor cota superior hasta esa iteración:

$$\max_{i=1,\dots,k} \theta(\lambda^i) = \bar{w}^k \leq z^* \leq \bar{U}^k = \min_{i=1,\dots,k} U^i$$

De este modo, podemos juzgar el avance de las iteraciones y tomar una decisión de cuándo detenernos. Debe recordarse que este procedimiento se aplicará a problemas difíciles en los que, generalmente, existirá salto de dualidad, por lo tanto no vamos a obtener  $\bar{U}^k - \bar{w}^k = 0$ . Sin embargo, podremos detener las iteraciones cuando esta diferencia ya no disminuya en forma significativa. En ese momento tendremos una solución factible al problema (obtenida por la heurística lagrangeana) y una estimación del error de esa solución con respecto al óptimo.

#### Cápsula de video 7.3.1: Relajación Lagrangiana: ejemplo computacional

Profesor Jorge Vera desarrolla en clases un ejemplo computacional de Relajación Lagrangiana usando Gurobi en Python:  
<https://youtu.be/KRtjT6yOvUQ>

## 7.4. Visión alternativa del dual y el algoritmo de planos cortantes

Vamos a introducir en esta parte una forma alternativa de escribir el problema dual. Esta forma nos dará, también, la posibilidad de un algoritmo alternativo al Método de Subgradiente.

Para esto consideremos el siguiente problema:

$$\begin{aligned} P) \quad z^* = \min \quad & c^T x \\ \text{s.t.} \quad & Ax \geq b \\ & Dx \geq d \\ & x \text{ entero} \end{aligned}$$

Sea  $C = \{x : Dx \geq d, x \text{ entero}\}$ . Supongamos, para simplificar, que  $C$  es un conjunto acotado (será el caso si la integralidad es binaria). Entonces  $C$  es un conjunto finito (aunque eventualmente muy grande). Sean  $x^1, x^2, \dots, x^p$  los elementos de  $C$ . Nuestro problema es:

$$\begin{aligned} P) \quad z^* = \min \quad & c^T x \\ \text{s.t.} \quad & Ax \geq b \\ & x \in C \end{aligned}$$

cuyo dual Lagrangeano es:

$$\max_{\lambda \geq 0} \min_{x \in C} \{c^T x + \lambda^T (b - Ax)\}$$

Pero como  $C$  es un conjunto finito, el problema

$$\min_{x \in C} \{c^T x + \lambda^T (b - Ax)\}$$

es lo mismo que

$$\min_{i=1,\dots,p} \{c^T x^i + \lambda^T (b - Ax^i)\}.$$

Luego, el dual es:

$$w^* = \max_{\lambda \geq 0} \left\{ \min_{i=1, \dots, p} \{c^T x^i + \lambda^T (b - Ax^i)\} \right\},$$

que es lo mismo que:

$$PD_{PC}) \quad \begin{array}{ll} w^* = \max & \gamma \\ \text{s.a.} & \gamma \leq c^T x^i + \lambda^T (b - Ax^i), i = 1, \dots, p \\ & \lambda \geq 0. \end{array}$$

Esta forma alternativa de escribir el dual nos puede llevar a pensar que es poco práctica, ya que tiene una cantidad enorme de restricciones (asociadas a los vértices del poliedro). Sin embargo, podemos desarrollar un procedimiento análogo al usado para la Descomposición de Benders del capítulo 5, un esquema de “planos cortantes”, como mostramos a continuación.

### 7.4.1. El Método de Planos Cortantes para el dual

Un procedimiento alternativo surge de la escritura “puntual” del dual que desarrollamos recién:

$$PD_{PC}) \quad \begin{array}{ll} w^* = \max & \gamma \\ \text{s.a.} & \gamma - \lambda^T (b - Ax^i) \leq c^T x^i, i = 1, \dots, p \\ & \lambda \geq 0 \end{array}$$

donde  $x^1, \dots, x^p$  son los elementos del conjunto  $C = \{x : Dx \geq d, x \text{ entero}\}$ . La idea es ir generando las restricciones de  $PD_{PC}$  a medida que las necesitemos, en un esquema de “planos cortantes”.

Supongamos que conocemos hasta el momento  $k$  puntos del conjunto  $C$ . Consideremos el problema “maestro” con sólo las restricciones asociadas a esos  $k$  puntos:

$$PM_k) \quad \begin{array}{ll} w^k = \max & \gamma \\ \text{s.a.} & \gamma - \lambda^T (b - Ax^i) \leq c^T x^i, i = 1, \dots, k \\ & \lambda \geq 0 \end{array}$$

Como  $PM_k$  es una relajación de  $PD_{PC}$  se tiene que  $w^k \geq w^*$ . Sea  $(\gamma^k, \lambda^k)$  solución óptima de  $PM_k$ . Ahora tenemos que encontrar una restricción de la forma

$$\gamma - \lambda^T (b - Au) \leq c^T u$$

para algún  $u \in C$  tal que  $(\gamma^k, \lambda^k)$  no la cumpla, es decir:

$$\gamma^k - (\lambda^k)^T (b - Au) > c^T u$$

¿Cómo encontramos ese  $u$ ? La condición anterior se puede escribir:

$$\gamma^k - (\lambda^k)^T b > (c - A^T \lambda^k)^T u$$

Resolvamos el siguiente problema:

$$\eta^k = \min_{\text{s.a. } u \in C} (c - A^T \lambda^k)^T u \quad \Leftrightarrow \quad \begin{array}{ll} \eta^k = \min & (c - A^T \lambda^k)^T u \\ \text{s.a.} & Du \geq d \\ & u \text{ entero} \end{array}$$

Entonces, si

$$\eta^k < \gamma^k - (\lambda^k)^T b$$

el punto solución de este problema define un punto  $x^{k+1} \in C$  que sirve para construir una nueva restricción:

$$\gamma - \lambda^T (b - Ax^{k+1}) \leq c^T x^{k+1}$$

que puede ser agregada al problema maestro para crear el problema  $PM_{k+1}$ ). Si el valor  $\eta^k$  es tal que

$$\eta^k \geq \gamma^k - (\lambda^k)^T b$$

entonces no podemos encontrar otra restricción y hemos llegado al óptimo del dual. Nótese que el problema “satélite” para calcular  $\eta^k$ :

$$\begin{aligned} \eta^k = \min \quad & (c - A^T \lambda^k)^T u \\ \text{s.a.} \quad & Du \geq d \\ & u \text{ entero} \end{aligned}$$

es exactamente el mismo usado para calcular  $\theta(\lambda^k)$ . Esto significa que la solución  $u = x^{k+1}$  que se obtiene de ese problema también puede usarse para calcular una solución primal factible usando una heurística lagrangeana.

### 7.4.2. Diferencias en las relajaciones (material avanzado)

Como indicamos en el ejemplo del problema de Asignación Generalizado, algunos duales son mejores que otros. La escritura del dual en forma de planos cortantes nos permite entender mejor lo que está pasando. Para esto, retomemos otra vez más la forma de planos cortantes del dual:

$$\begin{aligned} PD_{PC}) \quad w^* = \max \quad & \gamma \\ \text{s.a.} \quad & \gamma \leq c^T x^i + \lambda^T (b - Ax^i), i = 1, \dots, p \\ & \lambda \geq 0. \end{aligned}$$

A partir de esta escritura del dual es posible demostrar el siguiente resultado:

#### Proposición:

$$\begin{aligned} w^* = \min \quad & c^T x \\ \text{s.a.} \quad & Ax \geq b \\ & x \in \text{conv}(C) \end{aligned}$$

#### Demostración:

Reorganicemos el problema dual  $PD_{PC}$  de la siguiente forma:

$$\begin{aligned} PD_{PC}) \quad w^* = \max \quad & \gamma \\ \text{s.a.} \quad & \gamma - \lambda^T (b - Ax^i) \leq c^T x^i, i = 1, \dots, p \\ & \lambda \geq 0 \end{aligned}$$

Este es un problema de programación lineal que tiene su propio dual como tal. Sean  $\pi_1, \dots, \pi_p$  las variables duales. El dual de  $PD_{PC}$  es entonces:

$$\begin{aligned} \min \quad & \sum_{j=1}^p \pi_j c^T x^j \\ \text{s.a.} \quad & \sum_{j=1}^p \pi_j (b - Ax^j) \leq 0 \\ & \sum_{j=1}^p \pi_j = 1 \\ & \pi_i \geq 0, i = 1, \dots, p. \end{aligned}$$

Reorganizando queda:

$$\begin{aligned} \min \quad & c^T \left( \sum_{j=1}^p \pi_j x^j \right) \\ \text{s.a.} \quad & A \left( \sum_{j=1}^p \pi_j x^j \right) \geq b \\ & \sum_{j=1}^p \pi_j = 1 \\ & \pi_i \geq 0, i = 1, \dots, p. \end{aligned}$$

Pero notemos que  $\sum_{j=1}^p \pi_j x^j$  es un punto en la envoltura convexa de  $C$ . Luego, tenemos que:

$$\begin{aligned} w^* = \min \quad & c^T x \\ \text{s.a.} \quad & Ax \geq b \\ & x \in \text{conv}(C) \end{aligned}$$

como queríamos demostrar. QED.

Comparemos bien ahora los distintos problemas que tenemos disponibles. El problema entero original es:

$$\begin{aligned} z^* = \min \quad & c^T x \\ \text{s.a.} \quad & Ax \geq b \\ & Dx \geq d, x \text{ entero} \end{aligned}$$

Mientras que el problema dual es:

$$\begin{aligned} w^* = \min \quad & c^T x \\ \text{s.a.} \quad & Ax \geq b \\ & x \in \text{conv}(\{x : Dx \geq d, x \text{ entero}\}) \end{aligned}$$

Por otra parte, la relajación lineal del problema entero original es:


$$\begin{aligned} z^0 = \min \quad & c^T x \\ \text{s.a.} \quad & Ax \geq b \\ & Dx \geq d \end{aligned}$$

Tenemos entonces que:

**Proposición:**

Si  $\text{conv}(\{x : Dx \geq d, x \text{ entero}\}) = \{x : Dx \geq d\}$  entonces  $w^* = z^0$ .

Es decir, en ese caso el valor del dual es igual al de la relajación lineal original del problema y la cota dual no será ninguna mejora con respecto a la relajación lineal. La siguiente figura ilustra en forma comparativa los conjuntos factibles de los distintos problemas y sus respectivas envolturas convexas.



La figura muestra las regiones lineales de los dos conjuntos de restricciones del problema:  $Ax \geq b$  y  $Dx \geq d$ . En línea punteada se muestra la envoltura convexa de los puntos enteros, y el correspondiente óptimo del problema, así como la relajación lineal. El valor de la Relajación Lagrangeana se alcanza la intersección de la región  $Ax \geq b$  con  $\text{conv}(C)$ . Puede verse claramente que si la región  $Dx \geq d$  coincide con  $\text{conv}(C)$  entonces los valores óptimos de la Relajación Lineal y el de la Relajación Lagrangeana coinciden.

En nuestro ejemplo del Problema de Asignación Generalizado, en la relajación 2, el conjunto  $C$  estaba dado por la región factible de los problemas:

$$\begin{aligned} v_i(\mu) = \min \quad & \sum_{j=1}^n (c_{ij} - \mu_j a_{ij}) x_{ij} \\ \text{s.a.} \quad & \sum_{j=1}^n x_{ij} = 1 \\ & x_{ij} \in \{0, 1\} \forall (i, j) \end{aligned}$$

Y en este caso  $\text{conv}(C)$  corresponde a la región factible de:

$$\begin{aligned} \min \quad & \sum_{j=1}^n (c_{ij} - \mu_j a_{ij}) x_{ij} \\ \text{s.a.} \quad & \sum_{j=1}^n x_{ij} = 1 \\ & 0 \leq x_{ij} \leq 1 \forall (i, j) \end{aligned}$$

Se dice que el subproblema que resulta de la relajación tiene “la propiedad de integralidad” y entonces el valor dual no mejorará la relajación lineal. Esto no ocurre, de hecho, en la Relajación 1.

De todo este análisis se deduce que la descomposición del problema debe ser tal que el valor dual obtenido sea efectivamente mejor cota que la de la relajación lineal. Para esto debe evitarse que el problema dual relajado sea demasiado “fácil”. ¿Cómo saber esto a priori? Depende de la estructura del problema y del “arte” del que está resolviendo el problema.

## 7.5. Ejemplos

### Logística de vacunas

Considere la siguiente situación: una autoridad de salud debe organizar el proceso de vacunación de  $n$  comunidades, para lo cual debe habilitar centros de vacunación en  $m$  posibles lugares. La comunidad  $j$  tiene una población total a vacunar igual a  $d_j$  y cada persona a vacunar hará uso de recursos de capacidad de un centro de vacunación. Denotaremos por  $\alpha_j$  la capacidad usada por una persona de la comunidad  $j$ . La capacidad total de un centro de vacunación es  $C$  (es la misma para todos). Idealmente queremos vacunar a todas las personas de todas las comunidades en los centros que se abran, pero si no se puede, se tendrá que proceder a hacer vacunación a domicilio, y eso tiene un costo  $f_j$  por persona de la comunidad  $j$ . Por otro lado, abrir el centro de vacunación  $i$  tiene un costo fijo  $G_i$ . Por razones de disponibilidad de personal, a lo más  $M$  centros pueden ser habilitados. La autoridad de salud ha formulado el siguiente modelo de optimización entera mixta para decidir qué centros abrir y cuántas personas de cada comunidad asignar a cada centro, de modo de lograr el mejor balance entre costos y cantidad de personas vacunadas en los centros:

$$\begin{aligned} \max \quad & \beta \sum_{i=1}^m \sum_{j=1}^n x_{ij} - \sum_{i=1}^m G_i y_i - \sum_{j=1}^n f_j z_j \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} + z_j = d_j, \quad j = 1, \dots, n \end{aligned} \quad (1)$$

$$\sum_{j=1}^n \alpha_j x_{ij} \leq C y_i, \quad i = 1, \dots, m \quad (2)$$

$$\sum_{i=1}^m y_i \leq M, \quad (3)$$

$$x_{ij} \geq 0, z_j \geq 0, y_i \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n \quad (4)$$

La variable  $y_i$  vale 1 si se habilita el centro de vacunación  $i$ , 0 en caso contrario,  $x_{ij}$  es la cantidad de personas de la comunidad  $j$  vacunadas en el centro  $i$  (pensemos en que son números grandes, por eso consideramos la variable como continua),  $z_j$  denota las personas de la comunidad  $j$  no vacunadas en centros de vacunación (y, por lo tanto, vacunadas a domicilio). La función objetivo combina el objetivo de maximizar la cantidad de personas vacunadas contra los costos asociados (usando un parámetro  $\beta > 0$  para darle más o menos importancia a la cantidad de personas vacunadas), las restricciones (1) definen que los vacunados y no vacunados corresponden, en total, a la población de  $j$ , las restricciones (2) establecen el límite de capacidad de los centros y, además, que si el centro  $i$  no se abre, entonces no se le pueden asignar personas, la restricción (3) es el límite a la cantidad de centros, y (4) define la naturaleza de las variables.

El problema tiene una estructura compleja debido a que mezcla restricciones “de carga fija” (las 2) y también de “mochila” (la 3) y, seguramente, puede ser difícil de resolver para cantidades grandes de centros de vacunación y de comunidades. Vamos a visualizar posibles construcciones de duales en este problema y desarrollar una de ellas.

Lo más razonable es formar un dual relajando las restricciones (1) o la (3). Esto hace que el problema relajado tenga suficiente estructura. Si se relaja las restricciones (2) el problema se separa en uno lineal puro y en uno entero en las variables  $y$  pero de solución trivial, así que seguramente, la cota dual en ese caso no será buena. Mostramos acá la relajación con las restricciones (3). Para esto introducimos una sola variables dual  $\lambda \geq 0$ . El problema relajado de la función dual es:

$$\begin{aligned} \theta(\lambda) = \text{máx} \quad & \beta \sum_{i=1}^m \sum_{j=1}^n x_{ij} - \sum_{i=1}^m G_i y_i - \sum_{j=1}^n f_j z_j + \lambda \left( \sum_{i=1}^m y_i - M \right) \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} + z_j = d_j, & j = 1, \dots, n & \quad (1) \\ & \sum_{j=1}^n \alpha_j x_{ij} \leq C y_i, & i = 1, \dots, m & \quad (2) \\ & x_{ij} \geq 0, z_j \geq 0, y_i \in \{0, 1\} & i = 1, \dots, m; j = 1, \dots, n & \quad (4) \end{aligned}$$

que se reordena a:

$$\begin{aligned} \theta(\lambda) = \text{máx} \quad & \beta \sum_{i=1}^m \sum_{j=1}^n x_{ij} - \sum_{i=1}^m (G_i - \lambda) y_i - \sum_{j=1}^n f_j z_j - \lambda \times M \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} + z_j = d_j, & j = 1, \dots, n & \quad (1) \\ & \sum_{j=1}^n \alpha_j x_{ij} \leq C y_i, & i = 1, \dots, m & \quad (2) \\ & x_{ij} \geq 0, z_j \geq 0, y_i \in \{0, 1\} & i = 1, \dots, m; j = 1, \dots, n & \quad (4) \end{aligned}$$

El problema dual es:

$$\min_{\lambda \geq 0} \theta(\lambda)$$

### Localización y Asignación de Clientes

Consideramos aquí un problema en el que se deben instalar centros de distribución y asignar clientes a ellos. Tenemos que hay  $m$  posibles puntos donde se pueden instalar centros de distribución y un total de  $n$  clientes deben ser atendidos desde un único centro de distribución. Sea  $f_i$  el costo de abrir un centro de distribución en  $i$  y sea  $c_{ij}$  el costo de asignar al cliente  $j$  al centro en  $i$ . Lo que el problema básico busca es determinar en qué lugares se deben abrir centros de distribución y qué clientes asignar a cada uno de ellos, pero además existen externalidades negativas de tipo ambiental. Esto significa que si un cliente  $j$  se asigna a un centro de distribución  $i$ , entonces se produce una huella de carbono igual a  $h_{ij}$  (en unidades adecuadas). Para cada lugar donde puede haber un centro de distribución, se ha definido una huella total máxima que no se puede superar, dada por  $H_i$ , para el lugar  $i$ .

El problema se modela con dos variables:

- $y_i$ , binaria que indica si se abre el centro en  $i$ .
- $x_{ij}$ , binaria que indica si el cliente  $j$  se asigna al centro  $i$ .

El modelo es:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} = 1, & j = 1, \dots, n & \quad (1) \\ P_1) \quad & \sum_{j=1}^n x_{ij} \leq n y_i, & i = 1, \dots, m & \quad (2) \\ & \sum_{j=1}^n h_{ij} x_{ij} \leq H_i, & i = 1, \dots, m & \quad (3) \\ & y_i, x_{ij} \in \{0, 1\} & i = 1, \dots, m; j = 1, \dots, n & \end{aligned}$$

Es interesante notar, también, que las restricciones (2) y (3) podrían ser combinadas en una sola, que tendrá el mismo efecto:

$$\begin{aligned}
P_2) \quad & \min \quad \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\
& s.a. \quad \sum_{i=1}^m x_{ij} = 1, \quad j = 1, \dots, n \quad (1) \\
& \quad \sum_{j=1}^n h_{ij} x_{ij} \leq H_i y_i, \quad i = 1, \dots, m \quad (2') \\
& \quad y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n
\end{aligned}$$

Incluso es válida la siguiente formulación:

$$\begin{aligned}
& \min \quad \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\
& s.a. \quad \sum_{i=1}^m x_{ij} = 1, \quad j = 1, \dots, n \quad (1) \\
P_3) \quad & \quad \sum_{j=1}^n x_{ij} \leq n y_i, \quad i = 1, \dots, m \quad (2) \\
& \quad \sum_{j=1}^n h_{ij} x_{ij} \leq H_i y_i, \quad i = 1, \dots, m \quad (3) \\
& \quad y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n
\end{aligned}$$

aunque el poner  $y_i$  en la restricción (3) es redundante, para efectos de la instalación de centros de distribución. Se debe mencionar que, aunque las tres formulaciones son equivalentes, dan resultados distintos en términos de dificultad de resolución. La formulación (3) puede resultar algo más “fuerte” que las otras y dar un valor relajado lineal menos malo.

Ahora queremos resolver el problema usando Relajación lagrangeana. Vamos a detallar el análisis para las formulaciones anteriores, comentando las propiedades que tendrán los correspondientes problemas relajados.

Partamos por la formulación  $P_1$ ). Lo primero que podría considerarse es imitar lo que se hizo en clases con un problema similar, y relajar las restricciones (1). Si hacemos esto, el problema relajado es:

$$\begin{aligned}
PR_1) \quad & \theta_1(\lambda) = \min \quad \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} + \sum_{j=1}^n \lambda_j \left( \sum_{i=1}^m x_{ij} - 1 \right) \\
& s.a. \quad \sum_{j=1}^n x_{ij} \leq n y_i, \quad i = 1, \dots, m \quad (2) \\
& \quad \sum_{j=1}^n h_{ij} x_{ij} \leq H_i, \quad i = 1, \dots, m \quad (3) \\
& \quad y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n
\end{aligned}$$

que es lo mismo que:

$$\begin{aligned}
PR_1) \quad & \theta_1(\lambda) = \min \quad \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n (c_{ij} + \lambda_j) x_{ij} - \sum_{j=1}^n \lambda_j \\
& s.a. \quad \sum_{j=1}^n x_{ij} \leq n y_i, \quad i = 1, \dots, m \quad (2) \\
& \quad \sum_{j=1}^n h_{ij} x_{ij} \leq H_i, \quad i = 1, \dots, m \quad (3) \\
& \quad y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n
\end{aligned}$$

El dual correspondiente es  $\max_{\lambda} \theta_1(\lambda)$ .

Este problema relajado posee una estructura combinatorial razonablemente compleja, las variables  $x$  e  $y$  siguen interactuando y seguramente dará origen a una buena cota. En el desarrollo de la RL deberá abordarse el problema de una heurística lagrangiana. Discutamos eso ahora. Una primera idea suponer que estamos en la iteración  $k$  de la RL, tenemos variables duales  $\lambda^k$  y hemos resuelto el problema  $\theta_1(\lambda^k)$ . Esto nos ha dado una solución  $(y^k, x^k)$  que no cumple las restricciones (1), que han sido relajadas. Entonces, podríamos

construir un problema sólo en la variables  $x$ , fijando los  $y$  en los valores  $y^k$ . Esto nos llevará a resolver, en cada iteración de la RL, el problema:

$$PH_1) \quad \begin{aligned} \theta_1(\lambda) = \min \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n (c_{ij} + \lambda_j) x_{ij} - \sum_{j=1}^n \lambda_j \\ \text{s.a.} \quad & \sum_{j=1}^n x_{ij} \leq n y_i^k, \quad i = 1, \dots, m \end{aligned} \quad (2)$$

$$\begin{aligned} & \sum_{j=1}^n h_{ij} x_{ij} \leq H_i, \quad i = 1, \dots, m \\ & x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n \end{aligned} \quad (3)$$

Con esto, las restricciones (2) tienen lado derecho constante, no variable. El problema que tiene este enfoque ) es que el problema en las variables  $x$  ya no es tan fácil de resolver, las restricciones (3) complican todo y hacen que el problema pierda su estructura de redes, que lo hacía tan simple. Esto significa que, si bien es válido hacer esto, puede no dar una heurística muy eficiente. Hay que recordar que queremos una solución heurística que se pueda calcular con rapidez.

Existen varias otras alternativas, una es la siguiente:

1. Tomar la solución  $(x^k, y^k)$  y evaluar si se cumple la restricción (1). Si se cumple, estamos listos.
2. Si no se cumple, es porque hay clientes asignados a más de un lugar o no asignados.
3. Si un cliente está asignado a más de un lugar, sacarlo de los lugares más caros. Esto no afectará las restricciones (3).
4. Si un cliente no está asignado, buscar un centro  $i$  donde haya holgura suficiente en las restricciones (3), y asignarlo ahí.
5. Si no se puede encontrar una asignación, abrir un centro  $i$  que esté actualmente cerrado y comenzar a agregar ahí los clientes no asignados.

Con algo de suerte, este proceso heurístico podría generar una solución factible.

Sigamos con la formulación  $P_1$ ) y consideremos otros RL, relajando las restricciones (3) más bien. El problema relajado es:

$$PR_2) \quad \begin{aligned} \min \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} + \sum_{i=1}^m \lambda_i \left( \sum_{j=1}^n h_{ij} x_{ij} - H_i \right) \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} = 1, \quad j = 1, \dots, n \quad (1) \\ & \sum_{j=1}^n x_{ij} \leq n y_i, \quad i = 1, \dots, m \quad (2) \\ & y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n \end{aligned}$$

que es lo mismo que:

$$PR_2) \quad \begin{aligned} \theta_2(\lambda) = \min \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n (c_{ij} + \lambda_i) x_{ij} - \sum_{i=1}^m \lambda_i H_i \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} = 1, \quad j = 1, \dots, n \quad (1) \\ & \sum_{j=1}^n x_{ij} \leq n y_i, \quad i = 1, \dots, m \quad (2) \\ & y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n \end{aligned}$$

El correspondiente problema dual es  $\max_{\lambda \geq 0} \theta_2(\lambda)$ . El problema relajado que resulta no es más que un problema de localización-asignación típico. Lo único es que los costos son variables. Resolver este problema en cada iteración puede resultar bastante complejo, pero suponiendo que lo hacemos, igual tenemos que pensar en una heurística lagrangeana. Supongamos, entonces, que estamos en la iteración  $k$  de la RL, tenemos variables duales  $\lambda^k$  y hemos resuelto el problema  $\theta_2(\lambda^k)$ . Esto nos ha dado una solución  $(y^k, x^k)$  que no cumple necesariamente las restricciones (3). Ahora, se puede hacer el siguiente procedimiento heurístico:

1. Verificar la solución  $(y^k, x^k)$  en las restricciones (3), si se cumplen, estamos listos.
2. Si no se cumplen, identificar los centros  $i$  abiertos donde se excede contaminantes. Identificar también los centros abiertos donde hay holgura en las restricciones (3).
3. Remover, en orden de costos (por ejemplo) los clientes de los centros saturados (donde se viola (3)) y agregarlos a los centros con holgura.
4. Cuando ya no se puedan mover más clientes, comenzar a abrir centros cerrados (en orden de costos) y colocar ahí los clientes agregados, hasta saturar las restricciones (3).
5. Continuar hasta obtener una solución factible.

En forma alternativa, tanto para la relajación (1), como la (2), se podría considerar como heurística el ejecutar un procedimiento de tipo metaheurístico en las variables  $x$ . Eso igual estaría usando parte de la solución relajada.

Consideremos ahora la formulación  $P_2$ ) del problema. Esta tiene la ventaja de que las restricciones originales (2) y (3) se manejan en conjunto. Aquí relajaremos las restricciones (1) para obtener:

$$\begin{aligned}
 PR_3) \quad \theta_3(\lambda) = \min \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} + \sum_{j=1}^n \lambda_j \left( \sum_{i=1}^m x_{ij} - 1 \right) \\
 \text{s.a.} \quad & \sum_{j=1}^n h_{ij} x_{ij} \leq H_i y_i, & i = 1, \dots, m \\
 & y_i, x_{ij} \in \{0, 1\} & i = 1, \dots, m; j = 1, \dots, n
 \end{aligned} \tag{2'}$$

que es lo mismo que:

$$\begin{aligned}
 PR_3) \quad \theta_3(\lambda) = \min \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n (c_{ij} + \lambda_j) x_{ij} - \sum_{j=1}^n \lambda_j \\
 \text{s.a.} \quad & \sum_{j=1}^n h_{ij} x_{ij} \leq H_i y_i, & i = 1, \dots, m \\
 & y_i, x_{ij} \in \{0, 1\} & i = 1, \dots, m; j = 1, \dots, n
 \end{aligned} \tag{2'}$$

Este problema tiene la característica de que las restricciones (2') generan problemas de mochila algo más complejos, pero podría resolverse en forma más o menos eficiente, en todo caso. Ahora, nuevamente tenemos el problema de considerar una heurística lagrangeana para este caso, y el procedimiento descrito para la relajación (1) anterior puede servir aquí sin problemas.

## Planificación de Producción

Una empresa fabrica  $J$  productos diferentes, los cuales tiene demandas sobre  $T$  periodos de tiempo. La demanda por el ítem  $j$  en el periodo  $t$  es  $d_{jt}$ . La empresa tiene  $K$  fábricas diferentes que pueden fabricar los productos, pero hay un costo fijo si se asigna la producción de un producto a una fábrica en algún periodo de tiempo. En cada periodo, sólo una de las fábricas producirá de un mismo producto. Además, hay costo variables de producción y hay capacidades de producción. Adicionalmente, el uso de alguna de las fábricas para un producto genera el uso de un recurso productivo, que se requiere en una cantidad fija (independientemente de cuánto se fabrica de los productos), y del cual hay disponibilidad limitada. Más en específico, sea  $c_{jtk}$  el costo unitario de producción para el producto  $j$  en la fábrica  $k$  en  $t$ ,  $F_{jkt}$  el costo fijo de producir el producto  $j$  en la fábrica  $k$  en  $t$ ,  $\beta_{jk}$  la cantidad del recurso escaso que se requerirá para el producto  $j$  en la fábrica  $k$ , y cuyo total disponible es  $P$ , para todo el problema. La fábrica  $k$  tiene una capacidad total de  $H_{kt}$  horas en el periodo  $t$  y producir producto  $j$  en  $k$  consume  $\alpha_{jk}$  horas. Adicionalmente, el producto se puede guardar en inventario de un periodo al siguiente, pero eso tiene un costo  $h_{jt}$ . Asumimos aquí que todo lo producido se almacena en una bodega central y los costos de transportarlo a esa bodega son despreciables.

La empresa ha postulado un modelo de optimización en el cual usa las variables  $x_{jtk}$  para indicar la cantidad del producto  $j$  a fabricar en la fábrica  $k$  en el periodo  $t$ ,  $y_{jkt}$ , una variable binaria que indica si hay producción de  $j$  en la fábrica  $k$  en  $t$  e  $I_{jt}$  como el inventario del producto  $j$  al final del periodo  $t$  (asumiremos que los inventarios iniciales,  $I_{j0}$ , son conocidos). El modelo es el siguiente:

$$\begin{aligned}
\min \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt} \right\} \\
s.a. \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
& \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} & k = 1, \dots, K; t = 1, \dots, T & (2) \\
& x_{jkt} \leq My_{jkt} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (3) \\
& \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (4) \\
& \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk}y_{jkt} \leq P & & (5) \\
& x_{jkt} \geq 0, I_{jt} \geq 0, y_{jkt} \in \{0, 1\} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (6)
\end{aligned}$$

Las restricciones (1) son el flujo de inventarios y satisfacción de demanda (y, se entiende,  $I_{j0}$  es un dato), las (2) establecen el límite a la capacidad de producción, las (3) definen la “carga fija”, las (4) establecen que sólo una fábrica se encarga de cada producto en cada periodo, las (5) determinan que se cumpla la disponibilidad del recurso escaso, y las (6) definen la naturaleza de las variables.

Vamos a abordar este problema mediante Relajación Lagrangeana pero primero discutamos la existencia de restricciones complicantes. Por ejemplo, las restricciones (3) son complicantes, ya que relaciona las variables  $x$  con las  $y$ . Las restricciones (2), junto con la restricción (5), también son complicantes, ya que relacionan las variables  $x$  y las  $y$  según el índice  $j$  de los productos. El resto de las restricciones forma problemas independientes en el índice  $j$ .

Se planteará ahora una relajación Lagrangeana relajando las restricciones (3). Para esto, se tiene que definir variables duales  $\lambda_{jkt} \geq 0$ . El problema relajado de la función dual es:

$$\begin{aligned}
\theta(\lambda) = \min \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt} \right\} + \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J \lambda_{jkt} \{x_{jkt} - My_{jkt}\} \\
s.a. \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
& \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} & k = 1, \dots, K; t = 1, \dots, T & (2) \\
& \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (4) \\
& \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk}y_{jkt} \leq P & & (5) \\
& x_{jkt} \geq 0, I_{jt} \geq 0, y_{jkt} \in \{0, 1\} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (6)
\end{aligned}$$

Reordenado queda:

$$\begin{aligned}
\theta(\lambda) = \min \quad & \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J x_{jkt} \{c_{jkt} + \lambda_{jkt}\} + \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J y_{jkt} \{F_{jkt} - \lambda_{jkt}M\} + \sum_{t=1}^T \sum_{j=1}^J h_{jt}I_{jt} \\
s.a. \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
& \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} & k = 1, \dots, K; t = 1, \dots, T & (2) \\
& \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (4) \\
& \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk}y_{jkt} \leq P & & (5) \\
& x_{jkt} \geq 0, I_{jt} \geq 0, y_{jkt} \in \{0, 1\} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (6)
\end{aligned}$$

El problema dual es  $\max_{\lambda_{jkt} \geq 0} \theta(\lambda)$

También, se pudo haber descompuesto el problema relajado de la función dual en dos problemas, uno para las  $x$  y otro para las  $y$ , es decir:

$$\theta(\lambda) = \theta_1(\lambda) + \theta_2(\lambda)$$

donde:

$$\begin{aligned}
\theta_1(\lambda) = \min \quad & \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J x_{jkt} \{c_{jkt} + \lambda_{jkt}\} + \sum_{t=1}^T \sum_{j=1}^J h_{jt} I_{jt} \\
s.a. \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} \quad j = 1, \dots, J; t = 1, \dots, T \quad (1) \\
& \sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt} \quad k = 1, \dots, K; t = 1, \dots, T \quad (2) \\
& x_{jkt} \geq 0, I_{jt} \geq 0 \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (6)
\end{aligned}$$

$$\begin{aligned}
\theta_2(\lambda) = \min \quad & \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J y_{jkt} \{F_{jkt} - \lambda_{jkt} M\} \\
& \sum_{k=1}^K y_{jkt} = 1 \quad j = 1, \dots, J; t = 1, \dots, T \quad (4) \\
& \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} \leq P \quad (5) \\
& y_{jkt} \in \{0, 1\} \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (6)
\end{aligned}$$

Discutamos ahora cuál puede ser una buena heurística Lagrangeana para usar en la relajación anterior. La heurística busca encontrar una solución factible a un problema, aunque esa solución no sea necesariamente óptima. Supongamos, que estamos en la iteración  $n$  de la RL, se ha resuelto el problema  $\theta(\lambda)$ , tenemos variables duales  $\lambda^n$  y llegamos a una solución  $(x^n, y^n)$  que puede no cumplir con las restricciones (3). Una posible heurística sería la siguiente:

1. Si  $(x^n, y^n)$  cumple con las restricciones (3), se ha llegado a la solución.
2. Si no cumple, es porque hay asignado a fabricar una cantidad de producto  $j$  en el tiempo  $t$  a una fábrica que no produce ese producto en ese tiempo.
3. Si pasa lo anterior, asignar la fabricación de la cantidad  $x_{jkt}$  de un producto a una fábrica que se encuentre produciendo ese producto en ese tiempo, ya que como dice el enunciado, sólo una fábrica puede producir de un mismo producto. Además, se debe correr el subproblema de las  $x$ , para asegurar que se cumplan las restricciones de capacidad.
4. Si no hay ninguna fábrica abierta que fabrique el producto en cuestión, se debe abrir una fábrica para la producción del producto, eligiendo la que tenga menor costo fijo.

### Planificación de una flota de transporte marítimo

Una empresa de transporte marítimo tiene que planificar su flota para operar entre distintos puertos entre los que debe transportar carga de un total de  $K$  distintos tipos de productos. Según las necesidades de transporte, debe asignar un número de barcos adecuado en cada ruta. En forma más general, supongamos que la red de transporte se puede representar por un grafo  $G = (N, A)$ , donde  $N$  es un conjunto de nodos (puertos) y  $A$  son los arcos (vías marítimas). En el nodo  $i$  existe una oferta (demanda)  $d_{ik}$  para el producto  $k$  (aquí seguimos la convención de que valor positivo es oferta y negativo es demanda). Existe un costo unitario de transporte  $c_{ij}^k$  para el producto  $k$  por la ruta  $(i, j)$ . Los productos son organizados en contenedores y el volumen unitario del producto  $k$  es  $v_k$ , medido en unidades de contenedor (TEU, se llaman). La compañía tiene una flota muy estandarizada y cada barco tiene una capacidad de transporte de  $C$  TEUs, y hay un total de  $M$  barcos. Hay un costo fijo  $g_{ij}$  por usar un barco en la ruta  $(i, j)$ . Si no fueran suficientes los barcos de la compañía, se puede aumentar la flota con barcos arrendados de la misma capacidad, y cada uno tiene un costo igual a  $\beta$ . Adicionalmente, cada barco genera emisiones de efecto invernadero iguales a  $F_{ij}$  (millones de toneladas) en la ruta  $(i, j)$  y la compañía ha comprometido no generar más de  $D$  en total.

La compañía usa el siguiente modelo de optimización para determinar cuántos barcos usar en cada ruta, de modo de minimizar costos. Aquí  $x_{ij}^k$  es la cantidad transportada de producto  $k$  en la ruta  $(i, j)$ ,  $y_{ij}$  es la cantidad de barcos a usar en la ruta  $(i, j)$ , y  $w$  es el número de barcos adicionales arrendados:

$$\begin{aligned}
\text{mín} \quad & \sum_{(i,j) \in A} \sum_{k=1}^K c_{ij}^k x_{ij}^k + \sum_{(i,j) \in A} g_{ij} y_{ij} + \beta w \\
\text{s.a.} \quad & \sum_{(i,j) \in A} x_{ij}^k - \sum_{(l,i) \in A} x_{li}^k = d_{ik} \quad i \in N; k = 1, \dots, K \quad (1) \\
& \sum_{k=1}^K x_{ij}^k v_k \leq C y_{ij} \quad (i, j) \in A \quad (2) \\
& \sum_{(i,j) \in A} y_{ij} \leq M + w \quad (3) \\
& \sum_{(i,j) \in A} F_{ij} y_{ij} \leq D \quad (4) \\
& y_{ij} \geq 0 \text{ entero}, w \geq 0 \text{ entero}, x_{ij}^k \geq 0, \quad (i, j) \in A, k = 1, \dots, K \quad (5)
\end{aligned}$$

Queremos abordar este problema mediante Relajación Lagrangiana y primero vamos a identificar algún conjunto de restricciones complicantes en este problema y posteriormente desarrollaremos los detalles de todo el procedimiento.

Las restricciones (2) son candidato a complicantes. Una razón es que conectan las variables de las decisiones de transporte,  $x$ , con las decisiones de diseño de la flota, las  $y$  con la  $w$ . Entonces, vamos a usar estas para relajar. Dado que las restricciones son  $\leq 0$ , se requieren variables duales  $\lambda_{ij} \geq 0, (i, j) \in A$ . El problema de la función dual es:

$$\begin{aligned}
\theta(\lambda) = \text{mín} \quad & \sum_{(i,j) \in A} \sum_{k=1}^K c_{ij}^k x_{ij}^k + \sum_{(i,j) \in A} g_{ij} y_{ij} + \beta w + \sum_{(i,j) \in A} \left( \sum_{k=1}^K x_{ij}^k v_k - y_{ij} \right) \\
\text{s.a.} \quad & \sum_{(i,j) \in A} x_{ij}^k - \sum_{(l,i) \in A} x_{li}^k = d_{ik} \quad i \in N; k = 1, \dots, K \quad (1) \\
& \sum_{(i,j) \in A} y_{ij} \leq M + w \quad (3) \\
& \sum_{(i,j) \in A} F_{ij} y_{ij} \leq D \quad (4) \\
& y_{ij} \geq 0 \text{ entero}, w \text{ entero}, x_{ij}^k \geq 0, \quad (i, j) \in A, k = 1, \dots, K \quad (5)
\end{aligned}$$

Este problema se separa en dos problemas:

$$\theta(\lambda) = \theta_1(\lambda) + \theta_2(\lambda)$$

donde

$$\begin{aligned}
\theta_1(\lambda) = \text{mín} \quad & \sum_{(i,j) \in A} \sum_{k=1}^K (c_{ij}^k + \lambda_{ij} v_k) x_{ij}^k \\
\text{s.a.} \quad & \sum_{(i,j) \in A} x_{ij}^k - \sum_{(l,i) \in A} x_{li}^k = d_{ik} \quad i \in N; k = 1, \dots, K \quad (1) \\
& x_{ij}^k \geq 0, \quad (i, j) \in A, k = 1, \dots, K \quad (5')
\end{aligned}$$

y

$$\begin{aligned}
\theta_2(\lambda) = \text{mín} \quad & \sum_{(i,j) \in A} (g_{ij} - C) y_{ij} + \beta w \\
\text{s.a.} \quad & \sum_{(i,j) \in A} y_{ij} \leq M + w \quad (3) \\
& \sum_{(i,j) \in A} F_{ij} y_{ij} \leq D \quad (4) \\
& y_{ij} \geq 0 \text{ entero}, w \text{ entero}, \quad (i, j) \in A, k = 1, \dots, K \quad (5'')
\end{aligned}$$

El problema de  $\theta_1$  es un problema de Programación Lineal, específicamente, de Flujo a Costo Mínimo, y es fácil de resolver. El problema de  $\theta_2$  es un problema de programación entera con dos restricciones. No es necesariamente trivial de resolver, dado que las variables enteras van multiplicadas por coeficientes diversos en las restricciones (4). Todo esto indica que la cota dual que se obtendrá con esta relajación podría no ser necesariamente mala.

El algoritmo de subgradiente hace uso de un vector subgradiente. En este caso, el subgradiente que se debe usar en una iteración, en la cual se ha obtenido la solución  $(\bar{x}, \bar{y}, \bar{w})$  es un vector  $h(\bar{x}, \bar{y}, \bar{w})$  dado por:

$$h_{ij}(\bar{x}, \bar{y}, \bar{w}) = \sum_{k=1}^K \bar{x}_{ij}^k v_k - \bar{y}_{ij}, \quad (i, j) \in A$$

Otro de los elementos importantes es la creación de una heurística lagrangiana. La siguiente es una posible alternativa de heurística lagrangiana, puede haber varias otras. Asumimos que tenemos la solución del problema de la función dual,  $(\bar{x}, \bar{y}, \bar{w})$ . Como hemos relajado las restricciones (2), estas no necesariamente se cumplen. Entonces, podemos revisar, para cada  $(i, j) \in A$ :

1. Si (2) se cumple, no hay problemas.
2. Si (2) no se cumple y  $\sum_{k=1}^K \bar{x}_{ij}^k v_k > \bar{y}_{ij}$ , entonces significa que no hay suficientes barcos en la ruta  $(i, j)$ . Debemos incrementar  $y_{ij}$ , de a una unidad, hasta que la restricción calce o se alcance el límite total de barcos de las restricciones (3) o (4).
3. Si se alcanza el límite de la restricción (3), incrementar  $w$  hasta que se pueda alcanzar el nuevo valor de  $y$  que cumple la restricción.
4. Si se alcanza el límite de la restricción (4), se pueden dejar los  $y$  en ese límite y resolver, con los  $y$  fijos, el problema para los  $x$  (que es de programación lineal), para obtener, finalmente, una solución factible.
5. Si no se obtiene una solución factible, no queda más que descartar la posibilidad de cota para esa iteración y continuar adelante.