



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
ICS2121 – MÉTODOS DE OPTIMIZACIÓN

Apuntes de Métodos de Optimización

*Por Francisco García Aubert y Jorge Vera Andreo
Material en desarrollo. No compartir fuera del curso.
(versión 7, Agosto 2025)*



Índice general

10.Optimización Bajo Incertidumbre	3
10.1. La necesidad de considerar la incertidumbre	3
10.1.1. Análisis de Sensibilidad para entender incertidumbre	4
10.2. Simulando la incertidumbre	5
10.3. Optimización con Restricciones Probabilísticas	6
10.3.1. Ejemplos	8
10.4. Modelando la Dinámica de la Incertidumbre	10
10.4.1. Ejemplo introductorio	10
10.4.2. Modelo Estocástico de 2 etapas: formulación general	12
10.5. Cómo resolver el problema	12
10.5.1. Ejemplos	14
10.5.2. Decisiones en etapas: comentarios	33

Capítulo 10

Optimización Bajo Incertidumbre

Desde los comienzos de la Investigación de Operaciones como disciplina científica, es decir, hacia fines de la década de 1940, los modelos de Optimización han sido usados en los más diversos ámbitos, apoyando distintos procesos de toma de decisiones. Pero también, desde los comienzos de la disciplina, los académicos y profesionales prácticos se han preguntado algo fundamental: ¿Qué hacemos frente al hecho que, muchas veces, enfrentamos situaciones de incertidumbre?

Esta incertidumbre tiene distintos orígenes pero es una realidad: muchos parámetros de nuestros modelos vienen de estimaciones y, por lo tanto, tiene errores. Podríamos argumentar que es tema de tomar más mediciones y mejorar la estimaciones (es lo que nos enseña la estadística básica) pero, además, hay parámetros de modelos que corresponden a situaciones que no ha ocurrido aún y ahí necesitamos predicciones (que, sutilmente, no es lo mismo) y para eso tenemos que vivir con los datos que tenemos. Esto ilustra la complejidad que hay en la existencia de incertidumbre, pero algo es claro: muchas veces no puede ser ignorada.

Desde la década de 1950 se han venido desarrollando metodologías que buscan lidiar con la incertidumbre, pero en nuestros tiempos esto ha adquirido más relevancia que nunca. Hay, al menos, dos temas que intervienen aquí: Por un lado, hoy existen problemas de gestión cada vez más complejos en ambientes altamente inciertos. Ejemplos de esto es la gestión de sistemas de energía, la gestión de sistemas hospitalarios, y otros. Por otro lado, vivimos en una época en la cual hay una gran abundancia de datos, lo que abre una promesa de tener mejores estimaciones que podrían ayudar a lidiar mejor con la incertidumbre.

En este capítulo exploraremos, en forma muy introductoria, algunas de las metodologías que se usan en el ámbito de la Optimización bajo Incertidumbre, un tema de gran relevancia hoy en día.

10.1. La necesidad de considerar la incertidumbre

A modo de motivación e introducción de la consideración de la incertidumbre, vamos a tomar como ejemplo el famoso “Problema del Granjero”, que está desarrollado en el conocido libro de John Birge y François Louvaux, *Introduction to Stochastic Optimization*.

Consideremos la situación de un granjero que cultiva trigo, maíz y remolacha. Est agricultor debe sembrar su granja, que tiene un total de 500 acres, con estos tres cultivos en alguna proporción. Después del crecimiento vendrá la cosecha y en ese momento deberá cumplir tener un stock mínimo de maíz y trigo (que debe entregar a una cooperativa de la cual es socio). En caso de no poder cumplir ese mínimo, deberá comprar producto al precio de ese momento. Por otro lado, si le sobra cultivo, puede venderlo en el mercado. Debe cumplir con un inventario mínimo de trigo y maíz y vende lo que sobre, pero si falta, debe comprar lo que falte. Respecto a la remolacha, esta es 100 % del granjero y la venderá una vez cultiva, aunque el precio al cual se le pagará depende la de cantidad cosechada. Hay costos, obviamente, por sembrar. Se conoce, también, el rendimiento de la tierra en cada uno de los cultivos.

La siguiente tabla (tomada del libro de Birge y Louvaux) muestra los datos del problema:

	Trigo	Maíz	Remolacha
Rendimiento (T/acre)	2,5	3	20
Costo plantar (\$/acre)	150	230	260
Precio venta (\$/T)	170	150	36 bajo 6000 T 10 sobre 6000 T
Precio compra (\$/T)	238	210	—
Requisito mínimo (T)	200	240	—
Superficie disponible: 500 acres			

Construir un modelo para este problema es simple. Usemos las siguientes variables:

x_j : superficie dedicada al cultivo j .

w_j : cantidad de cultivo j vendida, para trigo y maíz.

y_j : cantidad de cultivo j comprada, para trigo y maíz.

w_3 : cantidad de remolacha vendida a precio alto.

w_4 : cantidad de remolacha vendida a precio bajo.

- El modelo maximiza utilidades y es (adaptado de B&L):

$$\begin{aligned}
 \text{máx} \quad & 170w_1 + 150w_2 + 36w_3 + 10w_4 - 150x_1 - 230x_2 - 260x_3 - 238y_1 - 210y_2 \\
 \text{s.a.} \quad & x_1 + x_2 + x_3 \leq 500 \\
 & (2,5)x_1 + y_1 - w_1 \geq 200 \\
 & (3,0)x_2 + y_2 - w_2 \geq 240 \\
 & w_3 + w_4 \leq 20x_3 \\
 & w_3 \leq 6000 \\
 & x_1, x_2, x_3, y_1, y_2, w_1, w_2, w_3, w_4 \geq 0
 \end{aligned}$$

Si se resuelve este problema se obtiene la siguiente solución:

Cultivo	Trigo	Maíz	Remolacha
Superficie (acres)	120	80	300
Rendimiento (T)	300	240	6000
Venta (T)	100	—	6000
Compra (T)	—	—	—
Ganancia total: \$118,600			

Si bien esta solución se ve bastante “normal”, cuando nos damos cuenta de las facetas de incertidumbre que existen podríamos entrar a cuestionar su validez. Por ejemplo, los precios de venta de los cultivos corresponden a un dato que estima algo que solo ocurrirá muchos meses más adelante, el valor real puede ser diferente. Esto es crítico si se considera la volatilidad de los mercados agrícolas en el mundo. Con un valor muy diferente, la actual solución podría ser muy mala. Por otro lado, el rendimiento de los cultivos es variable ya que depende de factores incontrolables como el clima. Podría ocurrir que uno de los cultivos rinda mucho menos y termina teniendo un precio de venta atractivo. En esa circunstancia podríamos haber dicho “debía haber sembrado más...”. Es fácil visualizar el problema que aquí se presenta.

Vamos a comentar a continuación algunas primeras aproximaciones a la consideración de incertidumbre.

10.1.1. Análisis de Sensibilidad para entender incertidumbre

El Análisis de Sensibilidad es una de las herramientas importantes para estudiar las propiedades de una solución óptima una vez resuelto un problema. Por ejemplo, en nuestro problema podríamos preguntarnos por la sensibilidad a los precios de venta del trigo y maíz. El análisis de sensibilidad de la solución óptima indica que el precio de venta del trigo (original en \$170) puede variar entre \$148 y \$220 y eso conserva la optimalidad de la solución actual. Esto podría usarse para tener un rango inicial de “tolerancia a la incertidumbre”. Por ejemplo, si el precio terminara siendo \$ 150 en vez de 170, sabemos que la solución calculada aún es óptima.

Sin embargo, hay otras preguntas que el Análisis de Sensibilidad no responde con facilidad. Por ejemplo, cómo evaluar variaciones en los rendimientos de los cultivos. Estos son coeficientes de las restricciones y el análisis convencional se hace sobre el lado derecho y la función objetivo. Más aún, el análisis se hace a

posteriori, cuando ya hemos hecho un supuesto determinista sobre los parámetros inciertos. El Análisis de Sensibilidad, entonces, parece tener varias limitantes, aunque pueda dar una idea preliminar de los efectos de la incertidumbre.

10.2. Simulando la incertidumbre

Sigamos suponiendo que el rendimiento del trigo varía, específicamente entre rangos de un 20% del valor entregado, es decir, en el intervalo $[2, 3]$ (el valor “medio” es 2,5). Supongamos que somos capaces de conocer el comportamiento estocástico del rendimiento del trigo en ese intervalo. Esto último es equivalente a conocer la distribución de probabilidad de la variable aleatoria que nos entrega el rendimiento del trigo. Asumamos, a modo de ilustración, que el rendimiento sigue una distribución Uniforme en el intervalo $[2, 3]$.

La propuesta ahora es ponernos en distintos escenarios. Para eso podríamos generar aleatoriamente distintos escenarios de rendimiento según una distribución uniforme y resolver el problema correspondiente a cada uno de ellos y analizar los resultados. Hacer esto es lo que se llama Simulación de Montecarlo.

Supongamos que nuestro problema original se formula como un problema de programación lineal de la forma:

$$\begin{aligned} z_s &= \text{mín} c^T x \\ \text{s.a. } Ax &= b \\ x &\geq 0 \end{aligned}$$

Supongamos que generamos P escenarios de los datos contenidos en la matriz A (podría ser en los otros elementos también). Específicamente, para el escenario s generamos la matriz A_s $s = 1, \dots, P$. Específicamente, esto significa que para cada coeficiente a_{ij} generaremos escenarios con las correspondientes distribuciones (O solo para los que nos interesen, como se rá el caso del rendimiento del trigo en nuestro ejemplo). Entonces, tendremos que resolver cada uno de los problemas:

$$\begin{aligned} z_s &= \text{mín} c^T x \\ \text{s.a. } A_s x &= b \\ x &\geq 0 \end{aligned}$$

para $s = 1, \dots, P$. El valor óptimo promedio se puede estimar como:

$$\bar{z} = \frac{1}{P} \sum_{s=1}^P z_s$$

Incluso, a partir de las estadísticas, podemos estimar un intervalo de confianza para el valor óptimo.

Ahora bien, ¿cuál es “la” solución? Para cada problema s , sea x_s^* la correspondiente solución óptima. Si seguimos la misma lógica que aplicamos al valor óptimo, podríamos pensar en promediar los vectores de las soluciones. Si aplicamos este enfoque al Problema del Granjero, con 100 escenarios, asumiendo lo indicado antes para el rendimiento del trigo, se obtienen las siguientes soluciones “promedio”:

Cultivo	Área	Venta	Compra
Trigo	104,11	66,35	1,18
Maíz	79,74	21,52	15,12
Remolacha	316,16	5,976,21	0,0

Pero recordemos ahora que se debe cumplir un mínimo de cantidad cosechada de trigo, restricción que, para el valor medio del rendimiento, es:

$$(2,5)x_1 + y_1 - w_1 \geq 200$$

Al evaluar en los resultados de la simulación se tiene:

$$2,5 \times 104,11 + 1,18 - 66,35 = 195,10$$

que no es mayor a 200, como se requiere. Es decir que, con la solución promedio, la restricción, con el rendimiento medio, no se cumple. Obviamente podría argumentarse que si el rendimiento fuera 3.0 entonces seguramente la restricción sí se cumple, pero eso no lo sabemos a priori. Complementariamente, si el rendimiento termina siendo 2.1, la situación es aún peor. Esto ilustra nuevamente la complejidad del tema: cada escenario tiene una solución óptima, pero no estamos siendo capaces de construir una solución que funcione “bien” para todos los escenarios, o la mayor parte de ellos.

Podríamos sí construir una solución que sirviera siempre: asumir que el rendimiento será 2.0, es decir, el peor caso. Pero esto generará una solución extremadamente conservadora que nos puede llevar a tener un exceso de trigo en desmedro de los otros cultivos.

Como vemos de toda esta discusión, necesitamos mejores enfoques para abordar la incertidumbre, enfoques que incorporen las características de esta incertidumbre en el momento que tomamos las decisiones. En las próximas secciones describiremos, en forma simple, algunos de estos enfoques.

Cápsula de video 10.2.1: Introduciendo la incertidumbre en Optimización

Profesor Jorge Vera explica en clases las motivaciones y desafíos de considerar la incertidumbre en Optimización.

<https://youtu.be/GG3bPPtG3tI>

10.3. Optimización con Restricciones Probabilísticas

Supongamos que en un modelo de optimización tenemos una restricción lineal de la forma:

$$\sum_{j=1}^n a_j x_j \leq b$$

Vamos a suponer que los coeficientes a_j no se conocen con precisión pues son aleatorios. En ese contexto, el lado izquierdo de la restricción es un valor aleatorio (una variable aleatoria, que depende de los valores de x , que son las variables de decisión del problema) y, por lo tanto, no podemos tener certeza respecto a cómo se compara con el lado derecho. Por esa razón, lo que vamos a hacer es pedir que la solución se cumpla con al menos una cierta probabilidad α , por ejemplo, que se cumpla con 90 %, 95 % o 99 %, es decir:

$$\mathbf{Prob} \left\{ \sum_{j=1}^n a_j x_j \leq b \right\} \geq \alpha$$

donde $0 < \alpha < 1$ está dado exógenamente. Esto se conoce como una Restricción Probabilística o “Chance Constraint”. Este enfoque fue desarrollado por Charnes y Cooper en 1959 y ha sido ampliamente estudiado, aunque presenta desafíos computacionales importantes ya que la expresión probabilística suele ser extremadamente difícil de tratar, salvo que se den ciertas condiciones. Una de estas condiciones es que los coeficientes a_j sigan una distribución **Normal** con media $\bar{a}_j$ y varianza σ_j^2 (en forma independiente de los otros). Entonces,

$$\sum_{j=1}^n a_j x_j$$

es una variable aleatoria Normal con media $\sum_{j=1}^n \bar{a}_j x_j$ y varianza $\sum_{j=1}^n \sigma_j^2 x_j^2$ (bajo la hipótesis de independencia). Luego

$$T = \frac{\sum_{j=1}^n a_j x_j - \left(\sum_{j=1}^n \bar{a}_j x_j \right)}{\sqrt{\sum_{j=1}^n \sigma_j^2 x_j^2}}$$

es una variable aleatoria normal con media 0 varianza 1 $N(0, 1)$. Tenemos, entonces que:




Figura 10.1: Fuente: allaboutlean.com

$$\mathbf{Prob} \left\{ \sum_{j=1}^n a_j x_j \leq b \right\} = \mathbf{Prob} \left\{ T \leq \frac{b - \left(\sum_{j=1}^n \bar{a}_j x_j \right)}{\sqrt{\sum_{j=1}^n \sigma_j^2 x_j^2}} \right\}$$

donde T sigue una distribución $N(0, 1)$. Tal como se recordará, la probabilidad de una normal $P(T \leq t)$ se ve como muestra la figura:

El valor que cubre un determinado percentil, z_α , corresponde al área acumulada de la densidad y esa es la probabilidad de que $T \leq z_\alpha$. Por lo que para que se cumpla la restricción con probabilidad α , debe tenerse que

$$\frac{b - \left(\sum_{j=1}^n \bar{a}_j x_j \right)}{\sqrt{\sum_{j=1}^n \sigma_j^2 x_j^2}} \geq z_\alpha$$

donde z_α es el percentil α de la distribución Normal.

De esta forma la expresión probabilística con la que partimos queda transformada en su “equivalente determinístico”:

$$\sum_{j=1}^n \bar{a}_j x_j + z_\alpha \sqrt{\sum_{j=1}^n \sigma_j^2 x_j^2} \leq b$$

Esta expresión no ha hecho desaparecer el aspecto probabilístico, pues el valor de esta restricción depende del valor de α que se quiera. Por ejemplo, para $\alpha = 0,95$, $z_\alpha = 1,65$.

La mala noticia del enfoque es que la transformación anterior se puede hacer con la distribución Normal y “casi nada más”, pero aún así es una idea potente, pues la distribución Normal es muy típica en todo tipo de fenómenos. Más aún, por el Teorema Central del Límite, muchos fenómenos pueden ser aproximados por la distribución Normal y una restricción lineal cualquiera, aún si sus sumandos tienen distribuciones “exóticas”, la suma total tenderá a un comportamiento normal cuando n es relativamente grande.

La buena noticia es que las restricciones como la anterior, en el caso normal, se pueden manejar de manera eficiente. Notemos que la restricción

$$\sum_{j=1}^n \bar{a}_j x_j + (1,65) \sqrt{\sum_{j=1}^n \sigma_j^2 x_j^2} \leq b$$

Es lo mismo que

$$\sqrt{\sum_{j=1}^n \sigma_j^2 x_j^2} \leq \frac{1}{1,65} \left(b - \sum_{j=1}^n \bar{a}_j x_j \right)$$

Lo que lleva a una estructura de un cono de segundo orden. Definamos el siguiente cambio de variables:

$$t = \frac{1}{1,65} \left(b - \sum_{j=1}^n \bar{a}_j x_j \right), \quad u_j = s_j x_j, j = 1, \dots, n.$$

Entonces, la restricción queda:

$$\sqrt{\sum_j u_j^2} \leq t$$

Como ya sabemos, esta estructura puede ser manejada con algoritmos de punto interior de manera muy eficiente.

Cápsula de video 10.3.1: Restricciones Probabilísticas

Profesor Jorge Vera explica en clases el enfoque de restricciones probabilísticas y su manejo mediante modelación SOCP.

<https://youtu.be/LDh14mHykEg>

10.3.1. Ejemplos

Problema de Cosechas

Una empresa del sector agropecuario necesita planificar sus actividades de cosecha de cereales sobre un horizonte de T períodos de tiempo (días, para fijar ideas). Existen n campos, con superficies conocidas, que pueden ser cosechados total o parcialmente. La superficie del campo j es S_j . Las labores de cosecha en el campo j tienen un rendimiento de α_{jt} kilos por hectárea cosechada en el período t . Esto varía de período a período debido a las condiciones operacionales a medida que avanza la temporada. Hay un costo por hectárea cosechada en cada período, c_{jt} . Existe un requerimiento mínimo diario de cereal cosechado que la empresa debe cumplir, que es igual a d_t kilos en el día t . Para resolver la planificación de cosecha, la empresa ha formulado un modelo de optimización que usa las variables x_{jt} que corresponden a la superficie cosechada en el campo j el día t .

El modelo es:

$$\begin{aligned} \min \quad & \sum_{t=1}^T \sum_{j=1}^n c_{jt} x_{jt} \\ \text{s.a.} \quad & x_{jt} \leq S_j - \sum_{l=1}^{t-1} x_{jl}, \quad t = 2, \dots, T; j = 1, \dots, n \quad (1) \\ & x_{j1} \leq S_j, \quad j = 1, \dots, n \quad (2) \\ & \sum_{j=1}^n \alpha_{jt} x_{jt} \geq d_t, \quad t = 1, \dots, T \quad (3) \\ & x_{jt} \geq 0, \quad j = 1, \dots, n; t = 1, \dots, T \quad (4) \end{aligned}$$

Supongamos que los rendimientos de cosecha pueden sufrir variaciones, pero se sabe que se comportan según una distribución conocida. Más específicamente, se sabe que α_{jt} sigue una distribución Normal con media $\bar{\alpha}_{jt}$ y desviación estándar s_{jt} , siendo todos esos rendimientos independientes entre sí.

Se quiere imponer un cumplimiento probabilístico para las restricciones de requerimiento mínimo (3), a un nivel de un 95 %. Vamos a desarrollar el correspondiente problema con restricciones probabilísticas.

Las restricciones a considerar son las (3):

$$\sum_{j=1}^n \alpha_{jt} x_{jt} \geq d_t, t = 1, \dots, T$$

Entonces, queremos pedir que

$$\text{Prob}\left(\sum_{j=1}^n \alpha_{jt} x_{jt} \geq d_t\right) \geq 0,95, t = 1, \dots, T$$

Siguiendo el desarrollo que ya hemos presentado (notar el sentido de la desigualdad) se obtiene la siguiente restricción determinista equivalente:

$$\sum_{j=1}^n \bar{\alpha}_{jt} x_{jt} - (1,64) \sqrt{\sum_{j=1}^n s_{jt}^2 (x_{jt})^2} \geq d_t, t = 1, \dots, T$$

Luego, el problema completo es:

$$\begin{aligned} \min \quad & \sum_{t=1}^T \sum_{j=1}^n c_{jt} x_{jt} \\ \text{s.a.} \quad & x_{jt} \leq S_j - \sum_{l=1}^{t-1} x_{jl}, & t = 2, \dots, T; j = 1, \dots, n \quad (1) \\ & x_{j1} \leq S_j, & j = 1, \dots, n \quad (2) \\ & \sum_{j=1}^n \bar{\alpha}_{jt} x_{jt} - (1,64) \sqrt{\sum_{j=1}^n s_{jt}^2 (x_{jt})^2} \geq d_t, & t = 1, \dots, T \quad (3) \\ & x_{jt} \geq 0, & j = 1, \dots, n; t = 1, \dots, T \quad (4) \end{aligned}$$

Si queremos resolver este problema mediante el uso de algoritmos de punto interior, debemos considerar la correspondiente función de barrera. En particular, el problema penalizado de la etapa k del algoritmo de punto interior general deben considerar la función de barrera de todas las desigualdades y conos. Para esto, vamos a reescribir el problema en la forma:

$$\begin{aligned} \min \quad & \sum_{t=1}^T \sum_{j=1}^n c_{jt} x_{jt} \\ \text{s.a.} \quad & x_{jt} \leq S_j - \sum_{l=1}^{t-1} x_{jl}, & t = 2, \dots, T; j = 1, \dots, n \quad (1) \\ & x_{j1} \leq S_j, & j = 1, \dots, n \quad (2) \\ & (1,64) \sqrt{\sum_{j=1}^n s_{jt}^2 (x_{jt})^2} \leq \sum_{j=1}^n \bar{\alpha}_{jt} x_{jt} - d_t, & t = 1, \dots, T \quad (3) \\ & x_{jt} \geq 0, & j = 1, \dots, n; t = 1, \dots, T \quad (4) \end{aligned}$$

Introduciendo variables auxiliares, lo reescribimos:

$$\begin{aligned} \min \quad & \sum_{t=1}^T \sum_{j=1}^n c_{jt} x_{jt} \\ \text{s.a.} \quad & x_{jt} \leq S_j - \sum_{l=1}^{t-1} x_{jl}, & t = 2, \dots, T; j = 1, \dots, n \quad (1) \\ & x_{j1} \leq S_j, & j = 1, \dots, n \quad (2) \\ & \sqrt{\sum_{j=1}^n v_{jt}^2} \leq w, & t = 1, \dots, T \quad (3) \\ & w = \frac{1}{1,64} \left(\sum_{j=1}^n \bar{\alpha}_{jt} x_{jt} - d_t \right), & t = 1, \dots, T \quad (3,1) \\ & v_{jt} = s_{jt} x_{jt}, & t = 1, \dots, T; j = 1, \dots, n \quad (3,2) \\ & x_{jt} \geq 0, & j = 1, \dots, n; t = 1, \dots, T \quad (4) \end{aligned}$$

La función de barrera que se debe usar es:

$$\Phi(x) = - \left\{ \sum_{t=2}^T \sum_{j=1}^n \log(S_j - \sum_{l=1}^{t-1} x_{jl} - x_{jt}) + \sum_{j=1}^n \log(S_j - x_{j1}) + \log(w^2 - \sum_{j=1}^n v_{jt}^2) + \sum_{t=1}^T \sum_{j=1}^n \log(x_{jt}) \right\}$$

y el problema penalizado es:

$$\begin{aligned}
& \min \sum_{t=1}^T \sum_{j=1}^n c_{jt} x_{jt} + \mu \Phi(x) \\
& \text{s.a.} \\
& w = \frac{1}{1,64} \left(\sum_{j=1}^n \bar{\alpha}_{jt} x_{jt} - d_t \right), \quad t = 1, \dots, T \quad (3,1) \\
& v_{jt} = s_{jt} x_{jt}, \quad t = 1, \dots, T; j = 1, \dots, n \quad (3,2)
\end{aligned}$$

10.4. Modelando la Dinámica de la Incertidumbre

Muchas veces, la forma en que se toman las decisiones es frente a un evento incierto que ocurrirá en algún futuro, pero las decisiones deben ser tomadas en el presente. Reconocer esta dinámica es importante para un mejor tratamiento de la incertidumbre y es el tema de esta sección.

Vamos a introducir una forma de pensar que consisten en dos etapas: En una **primera etapa**, se toman decisiones x específicas (ej. decidimos la producción). En una **segunda etapa**, se manifiesta el fenómeno aleatorio (ej. la demanda). Recién en ese entonces es posible ver qué consecuencias tuvo la decisión, como que podría haber habido demanda insatisfecha, por ejemplo. En ese momento, también, se tendrán que evaluar los costos involucrados.

10.4.1. Ejemplo introductorio

Vamos a ilustrar esta forma de pensar con un ejemplo en el que vamos a considerar un problema de planificar la asignación de quirófanos a operaciones en un hospital. Este es un problema muy importante y mostraremos aquí una situación simplificada. En esta situación tenemos varios quirófanos que pueden operar o no y una serie de operaciones que deben ser asignadas a los quirófanos. Cada operación tiene un tiempo de duración pero los quirófanos tienen un tiempo limitado de operación, el cual puede ser extendido con algún sobretiempo. Algunas operaciones puede que no se logren programar y, en ese caso, se incurrirá un costo por eso. Más en específico, tenemos los siguientes parámetros:

- N quirófanos y cada quirófano está disponible T horas.
- P operaciones y la duración de la operación i es de w_i horas.
- Si es necesario, un quirófano puede funcionar tiempo extra, pero hay un total de Q horas máximo disponible para todos los quirófanos.
- Costo fijo K_j por usar el quirófano j en el período.
- Costo adicional c_j por hora de sobretiempo que se asigne al quirófano j .
- Costo β por operación no realizada ya que implica reasignar al paciente a otro centro asistencial.

El problema se puede modelar con las siguientes variables de decisión:

- x_{ij} indica si la operación i se hace en el quirófano j .
- y_j indica si el quirófano j se usa o no.
- z_i indica si la operación no pudo ser programada.
- t_j es la cantidad de sobretiempo asignado al quirófano j .

El modelo para este problema es:

$$\begin{aligned}
& \text{mín} \quad \sum_{j=1}^N \{K_j y_j + c_j t_j\} + \sum_{i=1}^P \beta z_i \\
& \text{s.a.} \quad \sum_{j=1}^N x_{ij} + z_i = 1, & i = 1, \dots, P \\
& \quad \sum_{i=1}^P x_{ij} \leq P y_j, & j = 1, \dots, N \\
& \quad \sum_{i=1}^P w_i x_{ij} \leq T + t_j, & j = 1, \dots, N \\
& \quad \sum_{j=1}^N t_j \leq Q, \\
& \quad x_{ij}, y_j, z_i \in \{0, 1\}, t_j \geq 0, \quad i = 1, \dots, P; j = 1, \dots, N
\end{aligned}$$

Las decisiones principales que se deben tomar aquí son la asignación de las operaciones, junto con asignar sobretiempo si es necesario. Acá aparece, de forma natural, la perspectiva que proponemos: las operaciones se planifican por anticipado pero se hacen en el futuro. El tema es que la duración de las operaciones es, en realidad, aleatoria y varía, lo que puede llevar a tener que usar sobretiempo distinto al que se podría haber planificado si no se toma esa incertidumbre en cuenta.

Vamos a construir un solo modelo que separa la primera etapa de decisiones (“here and now”), y considera, además, una estimación del costo que generarían esas decisiones una vez que la incertidumbre se manifieste.

Vamos a suponer ahora que la duración de las operaciones se comporta según una distribución de probabilidades ξ . En este caso, la decisión t es la que pertenece al futuro. Entonces, cada decisión de asignación de operaciones a quirófanos, (y, x, z) genera una posibilidad en el futuro.

Queremos tomar hoy decisiones (y, x, z) de modo tal que el costo incurrido ahora más el costo esperado del futuro sea mínimo. Para esto, planteamos el siguiente problema:

$$\begin{aligned}
& \text{mín} \quad \sum_{j=1}^N K_j y_j + \sum_{i=1}^P \beta z_i + \mathbb{E}_\xi(F(y, x, z)) \\
& \text{s.a.} \quad \sum_{j=1}^N x_{ij} + z_i = 1, & i = 1, \dots, P \\
& \quad \sum_{i=1}^P x_{ij} \leq P y_j, & j = 1, \dots, N \\
& \quad x_{ij}, y_j, z_i \in \{0, 1\} & i = 1, \dots, P; j = 1, \dots, N
\end{aligned}$$

Este problema optimiza sobre las decisiones de asignación de las operaciones a los quirófanos, minimizando el costo específico de esa asignación (incluyendo el costo de dejar operaciones sin asignar) más el costo que esas decisiones generarán en el futuro. Como el futuro es aleatorio, específicamente la duración de las operaciones, y el sobretiempo real en que se incurra dependerá de esa duración, lo que se hace es considerar el costo esperado de ese futuro. En el modelo, $F(y, x, z)$ es el costo, en el futuro, de las decisiones (y, x, z) , y como es aleatorio, lo tomamos en valor esperado.

$F(y, x, z)$ es el resultado de optimizar el sobretiempo, dada la asignación de operaciones, y se calcula como:

$$\begin{aligned}
F(y, x, z) = \min & \sum_{j=1}^N c_j t_j \\
\text{s.a.} & \sum_{i=1}^P w_i x_{ij} \leq T + t_j, \quad j = 1, \dots, N \\
& \sum_{j=1}^N t_j \leq Q, \quad i = 1, \dots, P; j = 1, \dots, N. \\
& t_j \geq 0,
\end{aligned}$$

Este es el que llamaremos el problema “de segunda etapa”. Acá x_{ij} (notar que y no se hace explícita aquí, tampoco z) son las decisiones de la primera etapa y el sobretiempo, t_j , son las variables de segunda etapa, es la variable que se “ajusta en el futuro”. Como los w_i son variables aleatorias, $F(y, x, z)$ es también una variable aleatoria y por eso tomamos su valor esperado.

Este problema que acabamos de formular se conoce como un modelo de optimización estocástica de 2 etapas con “recurso” (2 stage stochastic model with recourse). El costo de segunda etapa es, entonces, una estimación de lo que podría pasar en el futuro pero la decisión de primera etapa tiene que servir para cualquier cosa que pase en el futuro.

Las decisiones “de primera etapa” (x , en el modelo) se suelen llamar decisiones “here and now”. Estas tienen sus propias restricciones y costo. Las decisiones de “segunda etapa” (los t en nuestro caso) se suelen llamar decisiones “wait and see” y también tienen sus propios costos y restricciones, pero estos dependen de las decisiones de primera etapa.

Cápsula de video 10.4.1: Motivando decisiones de 2 etapas

Profesor Jorge Vera explica en clases el esquema de decisiones de 2 etapas para considerar incertidumbre.

<https://youtu.be/KBnecox6rUg>

10.4.2. Modelo Estocástico de 2 etapas: formulación general

Consideramos un problema de optimización en el que queremos minimizar el costo de primera etapa, en el que decidimos x , **más el valor esperado del costo que generan las decisiones x en la segunda etapa**. Es decir:

$$\begin{aligned}
\min & c^T x + \mathbb{E}(Q(x)) \\
\text{s.a.} & Ax = b \\
& x \geq 0
\end{aligned}$$

Donde el problema de segunda etapa es:

$$\begin{aligned}
Q(x) = \min & d^T y \\
\text{s.a.} & Dx + Ty = e \\
& y \geq 0
\end{aligned}$$

Generalmente e (y/o D) es aleatorio y las variables y se “ajustan” o “adaptan”, al evento incierto, son variables “wait and see”. Cuando esto ocurre se dice que se trata de un modelo con “recurso fijo” (fixed recourse).

10.5. Cómo resolver el problema

No existe una manera analítica simple de caracterizar la optimalidad de un problema como el anterior. Para comenzar, la función $c^T x + \mathbb{E}(Q(x))$ no es diferenciable. Un enfoque, posiblemente el más usado, se basa

en **aproximar** $\mathbb{E}(Q(x))$ por escenarios finitos. Esto se conoce como **Sample Average Approximation** (SAA) y lo explicamos a continuación. Tenemos el siguiente problema:

$$\begin{array}{ll} \text{mín} & c^T x + \mathbb{E}(Q(x)) \\ \text{s.a.} & Ax = b \\ & x \geq 0 \end{array}$$

donde

$$Q(x) = \begin{array}{ll} \text{mín} & d^T y \\ \text{s.a.} & Dx + Ty = e \\ & y \geq 0 \end{array}$$

Asumiremos que e y/o D son aleatorios y siguen una distribución de probabilidad ξ conocida (muchas veces sólo e es el aleatorio, o D solo). La idea es aproximar $\mathbb{E}(Q(x))$ por un promedio sobre un número finito de ocurrencias de los eventos aleatorios. Más específicamente, supongamos que se generan K escenarios de e y D , a partir de la distribución $\xi : e^1, \dots, e^K, D^1, \dots, D^K$

Dadas decisiones x , por cada escenario de (D, e) , hay un problema de segunda etapa, que determina **variables y para ese escenario** (por eso son y^k , pues corresponden al escenario k):

$$Q_k(x) = \begin{array}{ll} \text{mín} & d^T y^k \\ \text{s.a.} & D^k x + Ty^k = e^k \\ & y^k \geq 0 \end{array}$$

y esto para $k = 1, \dots, K$. Podemos, entonces, aproximar $\mathbb{E}(Q(x))$ por

$$\frac{1}{K} \sum_{k=1}^K Q_k(x)$$

(Notar que x es el mismo para todos los escenarios: viene de la primera etapa). Reemplazando esto en el problema de la primera etapa, obtenemos el siguiente problema:

$$\begin{array}{llll} \text{SAA) } \text{mín} & c^T x & + \frac{1}{K} \sum_{k=1}^K d^T y^k & \\ \text{s.a.} & Ax & & \\ & D^k x & + Ty^k & = b \\ & x \geq 0, & y^k \geq 0 & = e^k, k = 1, \dots, K \end{array}$$

Este se conoce como el problema de Sample Average Approximation (SAA). Nótese como la formulación considera las decisiones x como comunes y se pone en diversos escenarios de la aleatoriedad, cada uno de los cuales genera una respuesta y según cada uno de los escenarios. Por eso, hay un solo conjunto de variables x pero distintos y según el escenario. Esto refuerza la idea del enfoque general: las decisiones que tomemos, x , deben ser “buenas” para cada posible futuro.

Aquí está el mismo problema, en forma estructurada:

$$\begin{array}{llllll} \text{SAA) } \text{mín} & c^T x & + \frac{1}{K} (d^T y^1 + d^T y^2 & \dots + d^T y^K) & & \\ \text{s.a.} & Ax & & & & = b \\ & D^1 x & + Ty^1 & & & = e^1 \\ & D^2 x & & + Ty^2 & & = e^2 \\ & \vdots & & & \ddots & \vdots \\ & D^K x & & & Ty^K & = e^K \\ & x \geq 0, & y^1 \geq 0 & y^2 \geq 0 & \dots & y^K \geq 0, k = 1, \dots, K \end{array}$$

Podemos ver que este es, claramente, un problema de gran tamaño. Si A es de $m \times n$, D es de $p \times n$ y hay r variables y , el problema SAA tiene: $m + Kp$ restricciones y $n + Kr$ variables. Podemos ver, de inmediato, que la estructura es muy adecuada para ser abordada mediante el enfoque de Descomposición de Benders. De hecho, la adaptación de la Descomposición de Benders a esta estructura es el método "L-shaped".

Entonces, la solución óptima del problema es un vector de la forma $(\bar{x}, \bar{y}^1, \bar{y}^2, \dots, \bar{y}^K)$. La forma de usar, en la práctica, esta solución sería la siguiente: se implementa x ahora y el tiempo pasará hasta que se tenga que cosechar. Entonces, ahí se observará lo que ocurrió con el fenómeno aleatorio: si se dio algo parecido al escenario k , entonces y^k es la política "de ajuste" que se debe seguir.

Cápsula de video 10.5.1: El problema de 2 etapas general y SAA

Profesor Jorge Vera explica en clases el problema general de 2 etapas y su resolución aproximada mediante Sample Average Approximation.

<https://youtu.be/2rRigALTQjw>

10.5.1. Ejemplos

Problema del Granjero como problema de 2 etapas

Consideremos nuevamente el problema inicial del granjero. Asumiremos incertidumbre en los rendimientos. Esto es, en lo que correspondería a la matriz $D \dots$ en la formulación general.

El problema del granjero tenía las siguientes variables:

- x_j : superficie dedicada al cultivo j .
- w_j : cantidad de cultivo j vendida, para wheat y corn.
- y_j : cantidad de cultivo j comprada, para wheat y corn.
- w_3 : cantidad de remolacha vendida a precio alto.
- w_4 : cantidad de remolacha vendida a precio bajo.

Las decisiones de primera etapa son, evidentemente, las decisiones de siembra, es decir, las x . Las otras variables son "wait and see". Podemos ver ahora cómo el enfoque de 2 etapas se adapta a la situación del problema del granjero: sus decisiones de ahora son las decisiones de siembra, pero cuando llegue la cosecha, ahí tendrá que decidir si tiene que comprar producto o, más bien, tiene producto de sobra y puede vender.

Vamos a denotar por α_t , α_m y α_r los rendimientos del trigo, maíz y remolacha respectivamente. El problema del granjero modelado como problema estocástico en 2 etapas es:

$$\begin{aligned} \text{máx} \quad & -150x_1 - 230x_2 - 260x_3 + \mathbb{E}(Q(x)) \\ \text{s.a.} \quad & x_1 + x_2 + x_3 \leq 500 \\ & x_1, x_2, x_3 \geq 0 \end{aligned}$$

donde:

$$\begin{aligned} Q(x) = \text{máx} \quad & +170w_1 + 150w_2 + 36w_3 + 10w_4 - 238y_1 - 210y_2 \\ \text{s.a.} \quad & \alpha_t x_1 + y_1 - w_1 \geq 200 \\ & \alpha_m x_2 + y_2 - w_2 \geq 240 \\ & w_3 + w_4 \leq \alpha_r x_3 \\ & w_3 \leq 6000 \\ & y_1, y_2, w_1, w_2, w_3, w_4 \geq 0 \end{aligned}$$

Problema de Planificación de Producción

Vamos a considerar el "clásico" problema de planificación de producción en el que se fabrican n productos haciendo uso de m recursos, en un horizonte de T meses. Supondremos que hay disponibilidades máximas de los recursos y se debe satisfacer demanda. Los siguientes son los parámetros disponibles:

d_{jt} : demanda por producto j en periodo t , $j = 1, \dots, n, t = 1, \dots, T$.

b_{it} : Disponibilidad del recurso i en periodo t , $i = 1, \dots, m, t = 1, \dots, T$.

c_{jt} : Costo unitario de producción de j en t , $j = 1, \dots, n, t = 1, \dots, T$.

a_{ij} : Cantidad de recurso i usado en producir una unidad de producto j , $i = 1, \dots, m, j = 1, \dots, n$.

h_j : Costo de dejar una unidad de producto j en inventario de un periodo al siguiente, $j = 1, \dots, n$.

Este problema se modela con las variables x_{jt} , producción de j en t , y se usa otra variable I_{jt} para registrar el inventario. El modelo es:

$$\begin{aligned} \text{mín} \quad & \sum_{t=1}^T \sum_{j=1}^n \{c_{jt}x_{jt} + h_j I_{jt}\} \\ \text{s.t.} \quad & I_{jt} = I_{jt-1} + x_{jt} - d_{jt}, t = 1, \dots, T; j = 1, \dots, n \\ & \sum_{j=1}^n a_{ij}x_{jt} \leq b_{it}, i = 1, \dots, m; t = 1, \dots, T \\ & x_{jt} \geq 0, I_{jt} \geq 0, t = 1, \dots, T; j = 1, \dots, n \end{aligned}$$

Este modelo requiere cumplimiento de demanda, pero si esta es aleatoria, podríamos no cumplir. Vamos a modificar el modelo para poder tomar en cuenta el posible incumplimiento de demanda. Para esto, notemos que si no se cumple la demanda en algún periodo, la restricción de inventario sólo se podrá cumplir si permitimos “inventario negativo”, que representa demanda insatisfecha. Vamos a considerar, entonces, I_{jt} sin restricción de signo y vamos a reemplazar:

$$I_{jt} = I_{jt}^+ - I_{jt}^-, \quad I_{jt}^+ \geq 0, I_{jt}^- \geq 0.$$

Supongamos ahora que existe un costo por unidad no satisfecha de demanda y es π_j . Entonces, el modelo modificado sería:

$$\begin{aligned} \text{mín} \quad & \sum_{t=1}^T \sum_{j=1}^n \{c_{jt}x_{jt} + h_j I_{jt}^+ + \pi_j I_{jt}^-\} \\ \text{s.t.} \quad & I_{jt} = I_{jt-1} + x_{jt} - d_{jt}, t = 1, \dots, T; j = 1, \dots, n \\ & I_{jt} = I_{jt}^+ - I_{jt}^-, t = 1, \dots, T; j = 1, \dots, n \\ & \sum_{j=1}^n a_{ij}x_{jt} \leq b_{it}, i = 1, \dots, m; t = 1, \dots, T \\ & x_{jt} \geq 0, I_{jt}^+ \geq 0, I_{jt}^- \geq 0, t = 1, \dots, T; j = 1, \dots, n \end{aligned}$$

Ahora vamos a suponer ahora que la demanda sigue una distribución de probabilidad ξ . Planteamos el siguiente problema:

$$\begin{aligned} \text{mín} \quad & \sum_{t=1}^T \sum_{j=1}^n \{c_{jt}x_{jt}\} + \mathbb{E}_{\xi}(Q(x)) \\ \text{s.t.} \quad & \sum_{j=1}^n a_{ij}x_{jt} \leq b_{it}, i = 1, \dots, m; t = 1, \dots, T \\ & x_{jt} \geq 0, t = 1, \dots, T; j = 1, \dots, n \end{aligned}$$

donde Q es la consecuencia, en el futuro, de las decisiones x . El problema de segunda etapa es:

$$\begin{aligned} Q(x) = \text{mín} \quad & \sum_{t=1}^T \sum_{j=1}^n \{h_j I_{jt}^+ + \pi_j I_{jt}^-\} \\ \text{s.t.} \quad & I_{jt} = I_{jt-1} + x_{jt} - d_{jt}, t = 1, \dots, T; j = 1, \dots, n \\ & I_{jt} = I_{jt}^+ - I_{jt}^-, t = 1, \dots, T; j = 1, \dots, n \\ & I_{jt}^+ \geq 0, I_{jt}^- \geq 0, t = 1, \dots, T; j = 1, \dots, n \end{aligned}$$

Entonces acá: x_{jt} son las decisiones de la primera etapa y los inventarios y faltantes son las variables de ajuste, “wait and see”.

Para plantear la formulación SAA de este problema, asumamos que se han generado K escenarios de la demanda, $d_{jt}^k, k = 1, \dots, K$. El problema SAA es:

$$\begin{aligned}
\min \quad & \sum_{t=1}^T \sum_{j=1}^n c_{jt} x_{jt} + \frac{1}{K} \sum_{k=1}^K \sum_{t=1}^T \sum_{j=1}^n \{h_j I_{jt}^{+k} + \pi_j I_{jt}^{-k}\} \\
\text{s.t.} \quad & I_{jt}^k = I_{jt-1}^k + x_{jt} - d_{jt}^k, t = 1, \dots, T; j = 1, \dots, n; k = 1, \dots, K \\
& I_{jt}^k = I_{jt}^{+k} - I_{jt}^{-k}, t = 1, \dots, T; j = 1, \dots, n; k = 1, \dots, K \\
& \sum_{j=1}^n a_{ij} x_{jt} \leq b_{it}, i = 1, \dots, m; t = 1, \dots, T \\
& x_{jt} \geq 0, I_{jt}^{+k} \geq 0, I_{jt}^{-k} \geq 0, t = 1, \dots, T; j = 1, \dots, n; k = 1, \dots, K
\end{aligned}$$

Destaquemos nuevamente la lógica al identificar las variables de primera y segunda etapa: el contexto del problema es muy importante, aquí estamos planificando producción, es decir, planificando cuánto producir y cuándo de cada producto. Por eso las variables x_{jt} son las de primera etapa. Los inventarios se ajustan una vez que se manifiesta la incertidumbre, es decir, cuando se observa la verdadera demanda.

También destaquemos por qué el modelo tuvo que ser modificado. En el modelo original de producción todo es determinístico, ese modelo no se pone en la situación de no cumplir la demanda ya que esta es perfectamente conocida. Por otro lado, en el modelo bajo incertidumbre no podemos estar seguros que podremos cumplir con la demanda y por esa razón debemos considerar la posibilidad de dejar demanda insatisfecha, pero eso debe tener un costo. En efecto, si no existiera el costo por demanda insatisfecha, lo óptimo es no hacer nada y no incurrir en los costos de producción, lo que no tiene sentido desde el punto de vista de gestión. Por eso es necesario considerar inventarios positivos y negativos (real inventario y demanda insatisfecha). Notemos que esas variables son totalmente análogas a las de compra y venta del problema del granjero.

Admisión de pacientes en salas de hospitalización

Consideramos aquí el problema de asignar un conjunto de paciente a salas de hospitalización de cuidados intermedios en un hospital. Este problema está basado en Managing the unknown: A distributionally robust model for the admission planning problem under uncertain length of stay, de A. Batista, D. Pozo y J. Vera, publicado en Computers & Industrial Engineering 154 (2021).

Vamos a considerar que existe un conjunto de I de pacientes que deben ser asignados a alguna de R salas a lo largo de un horizonte de T días. Cada paciente tendrá un tiempo de estadía en el hospital igual a ξ_i , para el paciente i y existe un “beneficio” η_i de atender al paciente i (no es necesariamente un beneficio económico, puede estar relacionado a la gravedad del paciente, el tiempo que lleva esperando, etc.) Cada sala r tiene un límite a la cantidad de paciente que puede acomodar por día t . Ese límite es C_{rt} . Adicionalmente, cada vez que un paciente está hospitalizado en alguna sala, requiere de atenciones diversas que consumen un total de α_i horas por día del personal del hospital. En cada sala, existe un límite Q_{rt}^{max} de horas disponible por día en la sala r . El hospital quiere atender pacientes de modo de obtener el mayor “beneficio” total posible, así que necesita asignar estos a las distintas salas, para lo cual ha formulado un modelo de optimización que usa las siguientes variables:

y_{irt} : igual a 1 si el paciente i ocupa la sala r en el día t , 0 en caso contrario.

x_{irt} : igual a 1 si el paciente i ocupa la sala r a partir del día t , 0 en caso contrario.

z_{ir} : igual a 1 si el paciente i es asignado a la sala r , 0 en caso contrario.

El modelo es:

$$\begin{aligned}
\text{máx} \quad & \sum_{r=1}^R \sum_{i=1}^I \eta_i z_{ir} \\
\text{s.a.} \quad & \sum_{i=1}^I y_{irt} \leq C_{rt} \quad r = 1, \dots, R; t = 1, \dots, T \quad (1) \\
& x_{irt} \geq y_{irt} - y_{ir(t-1)} \quad i = 1, \dots, I; r = 1, \dots, R; t = 2, \dots, T \quad (2) \\
& \sum_{r=1}^R y_{irt} \leq 1 \quad i = 1, \dots, I; t = 1, \dots, T \quad (3) \\
& z_{ir} = \sum_{t=1}^T x_{irt} \quad i = 1, \dots, I; r = 1, \dots, R \quad (4) \\
& \sum_{t=1}^T y_{irt} \geq z_{ir} \xi_i \quad i = 1, \dots, I; r = 1, \dots, R \quad (5) \\
& \sum_{i=1}^I \alpha_i y_{irt} \leq Q_{rt}^{max} \quad r = 1, \dots, R; t = 1, \dots, T \quad (6) \\
& x_{irt}, y_{irt}, z_{ir} \in \{0, 1\} \quad i = 1, \dots, I; r = 1, \dots, R; t = 1, \dots, T \quad (7)
\end{aligned}$$

La función objetivo maximiza el beneficio por atención de pacientes. Las restricciones (1) corresponden a la capacidad de cada sala, las restricciones (2) y (3) aseguran que cada paciente sea atendido en periodos consecutivos de tiempo, las restricciones (4) activan la variable z_{ir} cuando el paciente i es asignado a la sala r en algún momento de tiempo, las restricciones (5) establecen que si el paciente i es asignado a la sala r , debe serlo por una cantidad de días al menos igual al tiempo de estadía que necesita, las restricciones (6) establecen el límite de recursos por sala por día, y, finalmente, las restricciones (7) establecen la naturaleza de las variables.

El problema que se presenta aquí es que el uso de recursos hospitalarios, representado por los parámetros α_i , es variable y eso puede provocar que, según lo que se planifique, estos no sean suficientes para cumplir adecuadamente. El hospital decide enfrentar esto con la posibilidad de incorporar recursos adicionales, a un costo. Vamos a suponer que el comportamiento de α_i puede estimarse muy bien que siguen una distribución normal de media $\bar{\alpha}_i$ y desviación estándar σ_i .

Suponga, entonces, que el límite de recursos, Q_{rt}^{max} puede aumentar en alguna cantidad, pero ese adicional sale de un límite total para todas las salas del hospital sobre todos los períodos de tiempo, igual a $\bar{Q}$. Además, por cada unidad de aumento, en alguna sala en algún periodo, el hospital incurre en un “costo” igual a β (tampoco tiene que ser monetario, asuma que es compatible, en unidades, al “beneficio” de atender pacientes).

Basado en la nueva situación, vamos a formular un modelo estocástico de 2 etapas. Primero, hay que modificar el modelo para considerar el uso de recursos adicionales. Para esto, vamos a definir nuevas variables v_{rt} que corresponden a la cantidad de recurso adicional que se agrega en la sala r en el periodo t . El modelo extendido es:

$$\begin{aligned}
\text{máx} \quad & \sum_{r=1}^R \sum_{i=1}^I \eta_i z_{ir} - \sum_{r=1}^R \sum_{t=1}^T \beta v_{rt} \\
\text{s.a.} \quad & \sum_{i=1}^I y_{irt} \leq C_{rt} \quad r = 1, \dots, R; t = 1, \dots, T \quad (1) \\
& x_{irt} \geq y_{irt} - y_{ir(t-1)} \quad i = 1, \dots, I; r = 1, \dots, R; t = 2, \dots, T \quad (2) \\
& \sum_{r=1}^R y_{irt} \leq 1 \quad i = 1, \dots, I; t = 1, \dots, T \quad (3) \\
& z_{ir} = \sum_{t=1}^T x_{irt} \quad i = 1, \dots, I; r = 1, \dots, R \quad (4) \\
& \sum_{t=1}^T y_{irt} \geq z_{ir} \xi_i \quad i = 1, \dots, I; r = 1, \dots, R \quad (5) \\
& \sum_{i=1}^I \alpha_i y_{irt} \leq Q_{rt}^{max} + v_{rt} \quad r = 1, \dots, R; t = 1, \dots, T \quad (6') \\
& \sum_{r=1}^R \sum_{t=1}^T v_{rt} \leq \bar{Q} \quad (6'') \\
& x_{irt}, y_{irt}, z_{ir} \in \{0, 1\}, v_{rt} \geq 0 \quad i = 1, \dots, I; r = 1, \dots, R; t = 1, \dots, T \quad (7)
\end{aligned}$$

ahora, podemos pensar en un modelo de 2 etapas. Las variables “here and now” corresponde a las de

asignación y planificación, es decir, las (x, y, z) . Las variables “wait and see” corresponden a los ajustes de recursos, es decir, las v_{rt} , las que actuarán cuando se revele la incertidumbre.

El problema de 2 etapas es (tener cuidado con que el problema original es “max”):

$$\begin{aligned}
 \text{máx} \quad & \sum_{r=1}^R \sum_{i=1}^I \eta_i z_{ir} - E(Q(x, y, z)) \\
 \text{s.a.} \quad & \sum_{i=1}^I y_{irt} \leq C_{rt} & r = 1, \dots, R; t = 1, \dots, T & (1) \\
 & x_{irt} \geq y_{irt} - y_{ir(t-1)} & i = 1, \dots, I; r = 1, \dots, R; t = 2, \dots, T & (2) \\
 & \sum_{r=1}^R y_{irt} \leq 1 & i = 1, \dots, I; t = 1, \dots, T & (3) \\
 & z_{ir} = \sum_{t=1}^T x_{irt} & i = 1, \dots, I; r = 1, \dots, R & (4) \\
 & \sum_{t=1}^T y_{irt} \geq z_{ir} \xi_i & i = 1, \dots, I; r = 1, \dots, R & (5) \\
 & x_{irt}, y_{irt}, z_{ir} \in \{0, 1\} & i = 1, \dots, I; r = 1, \dots, R; t = 1, \dots, T & (7)
 \end{aligned}$$

donde

$$\begin{aligned}
 Q(x, y, z) = \text{mín} \quad & \sum_{r=1}^R \sum_{t=1}^T \beta v_{rt} \\
 \text{s.a.} \quad & \sum_{i=1}^I \alpha_i y_{irt} \leq Q_{rt}^{max} + v_{rt} & r = 1, \dots, R; t = 1, \dots, T & (6') \\
 & \sum_{r=1}^R \sum_{t=1}^T v_{rt} \leq \bar{Q} & & (6'') \\
 & v_{rt} \geq 0 & r = 1, \dots, R; t = 1, \dots, T & (7')
 \end{aligned}$$

Para la formulación SAA vamos a asumir que, a partir del conocimiento de las distribuciones de los parámetros α_i , se han generado K escenarios, $\alpha^1, \alpha^2, \dots, \alpha^K$. Siguiendo la construcción del modelo SAA, tenemos que est sería:

$$\begin{aligned}
 \text{máx} \quad & \sum_{r=1}^R \sum_{i=1}^I \eta_i z_{ir} - \frac{1}{K} \sum_{k=1}^K \sum_{r=1}^R \sum_{t=1}^T \beta v_{rt}^k \\
 \text{s.a.} \quad & \sum_{i=1}^I y_{irt} \leq C_{rt} & r = 1, \dots, R; t = 1, \dots, T & (1) \\
 & x_{irt} \geq y_{irt} - y_{ir(t-1)} & i = 1, \dots, I; r = 1, \dots, R; t = 2, \dots, T & (2) \\
 & \sum_{r=1}^R y_{irt} \leq 1 & i = 1, \dots, I; t = 1, \dots, T & (3) \\
 & z_{ir} = \sum_{t=1}^T x_{irt} & i = 1, \dots, I; r = 1, \dots, R & (4) \\
 & \sum_{t=1}^T y_{irt} \geq z_{ir} \xi_i & i = 1, \dots, I; r = 1, \dots, R & (5) \\
 & \sum_{i=1}^I \alpha_i y_{irt} \leq Q_{rt}^{max} + v_{rt}^k & r = 1, \dots, R; t = 1, \dots, T; k = 1, \dots, K & (6') \\
 & \sum_{r=1}^R \sum_{t=1}^T v_{rt}^k \leq \bar{Q} & k = 1, \dots, K & (6'') \\
 & x_{irt}, y_{irt}, z_{ir} \in \{0, 1\}, v_{rt}^k \geq 0 & i = 1, \dots, I; r = 1, \dots, R; t = 1, \dots, T; k = 1, \dots, K & (7)
 \end{aligned}$$

Planificación de flota de empresa de arriendo de autos

Vamos a considerar, en forma muy simplificada, la situación de una empresa de arriendo de automóviles, que tiene que planificar sus operaciones sobre un horizonte de tiempo (una semana dividida en 7 días, para fijar ideas). La empresa posee una cantidad de sucursales en las que arrienda vehículos de diversas categorías (compacto, económico, mediano, híbridos, etc.) y hay una demanda por vehículos de cada categoría. En cada día, cada sucursal recibe devueltos a primera hora una cantidad de vehículos de cada categoría. Vamos a asumir que los arriendos son semanales (una simplificación), es decir, los vehículos devueltos

fueron arrendados la semana anterior y los que se arrienden esta semana serán devueltos en la siguiente. La demanda diaria se satisface con los vehículos que sobraron del día anterior (quedaron en inventario), los devueltos de ese día y, además, es posible trasladar autos entre sucursales muy temprano en la mañana para que se sumen a los que quedaron disponibles, para satisfacer la demanda del día. Esto, eso sí, tiene costos, tanto variables como fijos y la cantidad total de vehículos que se pueden mover entre sucursales está acotada. Además, el inventario de vehículos que quede de un día para otro en cada sucursal está acotado.

La empresa quiere planificar su flota para la semana, en el sentido de decidir qué vehículos trasladar entre sucursales día a día, de modo disponer del inventario necesario para cumplir con la demanda en cada categoría, y que el costo sea mínimo. Esta planificación debe hacerse al comienzo de la semana (ya que se debe contratar el transporte), para todos los días de la semana y para esto, ha desarrollado un modelo de optimización cuya descripción es la siguiente:

Parámetros y conjuntos:

T : Conjunto de períodos de tiempo (los días de la semana)

S : Conjunto de sucursales

K : Conjunto de las categorías de vehículos.

d_{jkt} : Demanda por vehículos de la categoría k en la sucursal j , para el día t .

f_{jkt} : Vehículos de categoría k devueltos a la sucursal j al comienzo del día t .

α_{ij} : Costo de mover un vehículo desde la sucursal i a la sucursal j .

β_{ij} : Costo fijo de mover vehículos desde la sucursal i a la sucursal j .

C_{kt} : Número máximo de vehículos de la categoría k que pueden moverse en el día t .

G_j : Capacidad máxima de vehículos que pueden quedar de un día para otro de la sucursal j .

M : Un número suficientemente grande.

variables:

x_{ijkt} : Vehículos de la categoría k movidos desde la sucursal i a la sucursal j al comienzo del día t .

v_{ijkt} : Variable binaria que vale 1 si algún vehículo de la categoría k es movido desde la sucursal i a la sucursal j en t .

z_{jkt} : Vehículos de la categoría k efectivamente disponibles para ser arrendados en la sucursal j en t .

I_{jkt} : Inventario de vehículos de categoría k en la sucursal j que quedan al final del día t .

El modelo es el siguiente:

$$\begin{aligned}
 \text{mín} \quad & \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \sum_{i \in S, i \neq j} \{\alpha_{ij} x_{ijkt} + \beta_{ij} v_{ijkt}\} \\
 \text{s.a.} \quad & I_{jkt} = I_{jk,t-1} + f_{jkt} - \sum_{i \in S, i \neq j} x_{ijkt} + \sum_{l \in S, l \neq j} x_{ljkt} - z_{jkt} \quad j \in S, k \in K, t \in T \quad (1) \\
 & z_{jkt} \geq d_{jkt}, \quad j \in S, k \in K, t \in T \quad (2) \\
 & x_{ijkt} \leq M v_{ijkt} \quad i, j \in S, i \neq j, k \in K, t \in T \quad (3) \\
 & \sum_{j \in S} \sum_{i \in S, i \neq j} x_{ijkt} \leq C_{kt} \quad k \in K, t \in T \quad (4) \\
 & \sum_{k \in K} I_{jkt} \leq G_j \quad j \in S, t \in T \quad (5) \\
 & I_{jkt} \geq 0, x_{ijkt} \geq 0, z_{jkt} \geq 0, v_{ijkt} \in \{0, 1\} \quad i, j \in S, k \in K, t \in T \quad (6)
 \end{aligned}$$

La función objetivo suma los costo de trasladar vehículos entre sucursales (fijo y variable), las restricciones (1) son el balance de inventarios de vehículos de una categoría específica y considera los que sobraron del día anterior más los que se devuelven y los que se reciben de otras sucursales, menos los que se envían a otras, dando como resultado los que están disponibles para arrendar en el día. Como se explicó, asumimos que estos movimientos y las devoluciones ocurren todas al comienzo del día. Las restricciones (2) establecen el cumplimiento de la demanda. Las restricciones (3) activan las variables binarias para cobrar el costo fijo.

Las restricciones (4) establecen los límites a la cantidad de vehículos que se pueden mover entre sucursales mientras que (5) establece el límite de capacidad de inventario de la sucursal. Finalmente, (6) establece la naturaleza de las variables. Suponemos conocido el inventario de vehículos al comienzo de la semana, I_{jk0} .

Una característica de situaciones como esta es la existencia de diversas incertidumbre. En particular, la demanda d_{jkt} es incierta. Vamos a mostrar cómo incorporar los efectos esta incertidumbre usando un modelo estocástico de 2 etapas. Por supuesto, debido a la aleatoriedad de la demanda, podría, incluso, pasar que no sea posible cumplir completamente la demanda, aún moviendo vehículos de otras sucursales. Cuando eso ocurre es habitual que el cliente deba ser indemnizado y, además, se le entregará un auto de otra compañía (esto pasa, de hecho, si la agencia está en un aeropuerto, hay varias empresas de arriendo de autos ahí mismo). Supongamos que si esto ocurre, se incurre en un costo δ_{jkt} por vehículo. Esto implica modificar el modelo introduciendo una variables $u_{jkt} \geq 0$ que es la demanda no cubierta en el día.

Entonces, las restricciones (2) se transforman en

$$z_{jkt} + u_{jkt} \geq d_{jkt} \quad j \in S, k \in K, t \in T \quad (2')$$

y a la función objetivo se agrega el término:

$$\sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \delta_{jkt} u_{jkt}$$

Con esto, el problema completo es:

$$\begin{aligned} \text{mín} \quad & \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \sum_{i \in S, i \neq j} \{\alpha_{ij} x_{ijkt} + \beta_{ij} v_{ijkt}\} + \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \delta_{jkt} u_{jkt} \\ \text{s.a.} \quad & I_{jkt} = I_{jk,t-1} + f_{jkt} - \sum_{i \in S, i \neq j} x_{jik} + \sum_{l \in S, l \neq j} x_{ljk} - z_{jkt} \quad j \in S, k \in K, t \in T \quad (1) \\ & z_{jkt} + u_{jkt} \geq d_{jkt}, \quad j \in S, k \in K, t \in T \quad (2) \\ & x_{ijkt} \leq M v_{ijkt} \quad i, j \in S, i \neq j, k \in K, t \in T \quad (3) \\ & \sum_{j \in S} \sum_{i \in S, i \neq j} x_{ijkt} \leq C_{kt} \quad k \in K, t \in T \quad (4) \\ & \sum_{k \in K} I_{jkt} \leq G_j \quad j \in S, t \in T \quad (5) \\ & I_{jkt} \geq 0, x_{ijkt} \geq 0, z_{jkt} \geq 0, u_{jkt} \geq 0, v_{ijkt} \in \{0, 1\} \quad i, j \in S, k \in K, t \in T \quad (6) \end{aligned}$$

Ahora procedemos a construir el modelo de 2 etapas. Primero, observemos que, como se debe planificar el movimiento de autos de todos los días de la semana por anticipado al comienzo de semana, podemos decir que los movimientos corresponde a la primera etapa. Las variables “here and now” son, entonces, las x y las v . Las variables de inventario, I , las de oferta, z , y las de incumplimiento de demanda, u son las que se ajustan, las “wait and see”. Entonces, el problema estocástico de dos etapas es:

$$\begin{aligned} \text{mín} \quad & \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \sum_{i \in S, i \neq j} \{\alpha_{ij} x_{ijkt} + \beta_{ij} v_{ijkt}\} + \mathbb{E}(Q(x, v)) \\ \text{s.a.} \quad & x_{ijkt} \leq M v_{ijkt} \quad i, j \in S, i \neq j, k \in K, t \in T \quad (3) \\ & \sum_{j \in S} \sum_{i \in S, i \neq j} x_{ijkt} \leq C_{kt} \quad k \in K, t \in T \quad (4) \\ & x_{ijkt} \geq 0, v_{ijkt} \in \{0, 1\} \quad i, j \in S, k \in K, t \in T \quad (6') \end{aligned}$$

donde $Q(x, v)$ es el problema de segunda etapa:

$$\begin{aligned} Q(x, v) = \text{mín} \quad & \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \delta_{jkt} u_{jkt} \\ \text{s.a.} \quad & I_{jkt} = I_{jk,t-1} + f_{jkt} - \sum_{i \in S, i \neq j} x_{jik} + \sum_{l \in S, l \neq j} x_{ljk} - z_{jkt} \quad j \in S, k \in K, t \in T \quad (1) \\ & z_{jkt} + u_{jkt} \geq d_{jkt}, \quad j \in S, k \in K, t \in T \quad (2) \\ & \sum_{k \in K} I_{jkt} \leq G_j \quad j \in S, t \in T \quad (5) \\ & I_{jkt} \geq 0, z_{jkt} \geq 0, u_{jkt} \geq 0 \quad i, j \in S, k \in K, t \in T \quad (6) \end{aligned}$$

Como ya sabemos, este problema puede ser resuelto, en forma aproximada, mediante Sample Average Approximation. Para el problema SAA vamos a asumir que se han generado P escenarios de la demanda. Vamos a usar un superíndice r (¡se están acabando las letras!) para eso. Entonces, d_{jkt}^r denota los valores de la demanda en el escenario r , $r = 1, \dots, P$. El problema SAA es (simplificamos los índices de las restricciones para que quepa todo):

$$\begin{aligned}
& \text{mín} && \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \sum_{i \in S, i \neq j} \{\alpha_{ij} x_{ijkt} + \beta_{ij} v_{ijkt}\} + \frac{1}{P} \sum_{r=1}^P \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \delta_{jkt} u_{jkt}^r \\
& \text{s.a.} && \\
& && I_{jkt}^r = I_{jk,t-1}^r + f_{jkt} - \sum_{i \in S, i \neq j} x_{ijkt} + \sum_{l \in S, l \neq j} x_{ljkt} - z_{jkt}^r && \forall j, k, t, r \\
& && z_{jkt}^r + u_{jkt}^r \geq d_{jkt}^r, && \forall j, k, t, r \\
& && x_{ijkt} \leq M v_{ijkt} && i, j \in S, \forall i \neq j, k, t \\
& && \sum_{j \in S} \sum_{i \in S, i \neq j} x_{ijkt} \leq C_{kt} && \forall k, t \\
& && \sum_{k \in K} I_{jkt}^r \leq G_j && \forall j, t, r \\
& && I_{jkt}^r \geq 0, x_{ijkt} \geq 0, z_{jkt}^r \geq 0, u_{jkt}^r \geq 0, v_{ijkt} \in \{0, 1\} && \forall i, j, k, t, r
\end{aligned}$$

Este problema puede llegar a ser muy grande y complejo y, como sabemos, podría ser abordado con técnicas de descomposición como la Descomposición de Benders. Vamos a detallar acá cómo sería ese planteamiento. Para la Descomposición de Benders, tenemos que, claramente, las variables de primera etapa son las complicantes, es decir, las (x, v) . Siguiendo la lógica de la descomposición, vamos a partir por identificar el “problema interior”. Este es:

$$\begin{aligned}
& \text{mín} && \frac{1}{P} \sum_{r=1}^P \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \delta_{jkt} u_{jkt}^r \\
& \text{s.a.} && \\
& && I_{jkt}^r = I_{jk,t-1}^r + f_{jkt} - \sum_{i \in S, i \neq j} x_{ijkt} + \sum_{l \in S, l \neq j} x_{ljkt} - z_{jkt}^r && \forall j, k, t, r \\
& && z_{jkt}^r + u_{jkt}^r \geq d_{jkt}^r, && \forall j, k, t, r \\
& && \sum_{k \in K} I_{jkt}^r \leq G_j && \forall j, t, r \\
& && I_{jkt}^r \geq 0, z_{jkt}^r \geq 0, u_{jkt}^r \geq 0 && \forall i, j, k, t, r
\end{aligned}$$

Este es el problema al que habría que calcular el dual. La función objetivo de ese dual es, además, la que se usa para la definición de las restricciones del maestro. Construir ese dual se ve algo intimidante, pero aquí hay que hacer una observación crítica: el problema interior es siempre factible ya que las variables u permiten ajustar el cumplimiento de demanda, sin importar si hay o no inventario de autos para arrendar. Entonces, no necesitamos determinar ese dual completo, solo su función objetivo usando las variables duales.

Vamos a escribir nuevamente el problema interior, en forma más ordenada, e indicando a la derecha las variables duales de cada restricción:

$$\begin{aligned}
& \text{mín} && \frac{1}{P} \sum_{r=1}^P \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \delta_{jkt} u_{jkt}^r \\
& \text{s.a.} && \\
& && I_{jkt}^r - I_{jk,t-1}^r + \sum_{i \in S, i \neq j} x_{ijkt} - \sum_{l \in S, l \neq j} x_{ljkt} + z_{jkt}^r = f_{jkt} && \forall j, k, t, r && \pi_{jktr} \\
& && z_{jkt}^r + u_{jkt}^r \geq d_{jkt}^r, && \forall j, k, t, r && w_{jktr} \\
& && \sum_{k \in K} I_{jkt}^r \leq G_j && \forall j, t, r && q_{jtr} \\
& && I_{jkt}^r \geq 0, z_{jkt}^r \geq 0, u_{jkt}^r \geq 0 && \forall i, j, k, t, r
\end{aligned}$$

La función objetivo del dual es:

$$\sum_{j \in S} \sum_{k \in K} \sum_{t \in T} \sum_{r=1}^P f_{jkt} \pi_{jktr} + \sum_{j \in S} \sum_{k \in K} \sum_{t \in T} \sum_{r=1}^P d_{jkt}^r w_{jktr} + \sum_{j \in S} \sum_{t \in T} \sum_{r=1}^P G_j q_{jtr}$$

Entonces, denotemos por (π^m, w^m, q^m) , los vértices del poliedro del problema dual al problema interior, donde usamos el superíndice m para identificarlos. Suponiendo que estamos en la iteración n de la descomposición, el problema maestro será:

$$\begin{aligned}
 \text{mín} \quad & \sum_{k \in K} \sum_{t \in T} \sum_{j \in S} \sum_{i \in S, i \neq j} \{\alpha_{ij} x_{ijkt} + \beta_{ij} v_{ijkt}\} + \gamma \\
 \text{s.a.} \quad & x_{ijkt} \leq M v_{ijkt} & i, j \in S, i \neq j, k \in K, t \in T \\
 & \sum_{j \in S} \sum_{i \in S, i \neq j} x_{ijkt} \leq C_{kt} & k \in K, t \in T \\
 & \sum_{j \in S} \sum_{k \in K} \sum_{t \in T} \sum_{r=1}^P f_{jkt} \pi_{jkt}^m + \sum_{j \in S} \sum_{k \in K} \sum_{t \in T} \sum_{r=1}^P d_{jkt}^r w_{jkt}^m + \sum_{j \in S} \sum_{t \in T} \sum_{r=1}^P G_j q_{jtr}^m \leq \gamma & m = 1, \dots, n \\
 & x_{ijkt} \geq 0, v_{ijkt} \in \{0, 1\}, \gamma \in \mathbb{R} & i, j \in S, k \in K, t \in T
 \end{aligned}$$

El problema satélite es el mismo problema interior, para valores fijos de (x, v) que vienen del maestro.

La notación en todo esto es bastante pesada, es aceptable escribir las cosas en forma más compacta. Por ejemplo, las restricciones de los cortes de optimalidad se podrían escribir:

$$\sum_{j,k,t,r} f_{jkt} \pi_{jkt}^m + \sum_{j,k,t,r} w_{jkt}^m + \sum_{j,t,r} G_j q_{jtr}^m \leq \gamma, \quad m = 1, \dots, n$$

ya que es claro del contexto cuáles son los conjuntos de los índices.

Un problema en agricultura bajo incertidumbre

Vamos a presentar un ejemplo de problema en agricultura, con bastante más complejidad que el ejemplo del granjero que hemos mostrado en clases. El problema está inspirado en una investigación real y considera una cooperativa formada por familias de pequeños agricultores los cuales deben planificar sus cultivos con el objetivo de tener suficientes productos cultivados para su propio sustento, y también poder venderlo en el mercado y obtener ingresos. Adicionalmente, consideraremos ahora algunos aspectos de aporte nutricional de los cultivos, además de diversas incertidumbres. La cooperativa quiere planificar los cultivos de cada familia y también da la posibilidad de que estas familias intercambien cultivos.

Más en concreto, hay m familias de agricultores, cada una de las cuales puede plantar n cultivos diferentes. La familia i dispone de una superficie de S_i [m^2]. Cada cultivo tiene un rendimiento específico, el cultivo j rinde r_j kilos de producto final por m^2 sembrado. El costo de siembra del cultivo j es c_j por m^2 y hay un costo fijo F_j si se siembra del cultivo j . Por otro lado, el costo de cosecha es d_j por m^2 , para el cultivo j . El producto cosechado del cultivo j se puede vender en el mercado a p_j por kilo cosechado. Por otro lado, la familia i debe procurar tener una cantidad mínima igual a f_{ij} del cultivo j después de cosechar. Esto es para garantizar su propio sustento. Los agricultores pueden intercambiar productos cosechados entre ellos, de modo que eso les ayuda a cumplir con los mínimos especificados, pero sólo venden de la cosecha propia. Adicionalmente, por razones de salud del suelo, para cada cultivo j , existe un conjunto de otros cultivos, que denotaremos R_j que son “incompatibles” con j , es decir, si se siembra j , no puede sembrarse ninguno de los otros cultivos identificados en el conjunto R_j .

Por otro lado, se debe considerar también el aporte nutricional que generan los distintos cultivos, ya que un objetivo de la cooperativa es garantizar seguridad alimentaria de sus socios. Para esto se consideran r diferentes nutrientes (proteínas, minerales, vitaminas de distintos tipos, etc.). Sabemos que el cultivo j aporta a_{js} unidades del nutriente s . Para la familia i , se debe cumplir con cantidades mínimas iguales a e_{is} unidades del nutriente s en lo disponible para esa familia, $s = 1, \dots, r$.

La cooperativa ha construido el siguiente modelo de optimización para determinar su política de siembra de modo de cumplir con los mínimos de cada familia, cumplir requerimientos nutricionales y, además, ganar la mayor cantidad de dinero posible. En este modelo, x_{ij} corresponde a la superficie sembrada del cultivo j por la familia i , z_{ij} es una variable binaria que indica si se sembró del cultivo j por la familia i o no, y_{ilj} indica la cantidad de cultivo j que la familia i le traspasa a la familia l . También se usa la variable v_{ij} que representa la cantidad del cultivo j vendida en el mercado por la familia i , y las variables w_{ij} que indican la cantidad cosechada del cultivo j que la familia i conserva para sí misma:

$$\begin{aligned}
& \text{máx} \quad \sum_{i=1}^m \sum_{j=1}^n p_j v_{ij} - \sum_{i=1}^m \sum_{j=1}^n \{c_j x_{ij} + d_j x_{ij} + F_j z_{ij}\} \\
& \text{s.a.} \\
& r_j x_{ij} = v_{ij} + w_{ij} + \sum_{l=1, l \neq i}^m y_{ilj} \quad i = 1, \dots, m; j = 1, \dots, n \quad (1) \\
& \sum_{j=1}^n x_{ij} \leq S_i \quad i = 1, \dots, m \quad (2) \\
& w_{ij} + \sum_{l=1, l \neq i}^m y_{lij} \geq f_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (3) \\
& \sum_{j=1}^n a_{js} w_{ij} \geq e_{is} \quad s = 1, \dots, r; i = 1, \dots, m \quad (4) \\
& x_{ij} \leq S_i z_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (5) \\
& \sum_{k \in R_j} z_{ik} \leq n(1 - z_{ij}) \quad i = 1, \dots, m; j = 1, \dots, n \quad (6) \\
& x_{ij} \geq 0, y_{ilj} \geq 0, v_{ij} \geq 0, w_{ij} \geq 0, z_{ij} \in \{0, 1\} \quad i, l = 1, \dots, m; j = 1, \dots, n \quad (7)
\end{aligned}$$

La función objetivo hace el balance de utilidades para la cooperativa completa, las restricciones (1) establecen la división de lo cosechado entre lo que se vende, lo que se queda en la familia y lo que se envía a otros, las (2) establecen el límite de superficie a sembrar, las (3) hacen el balance para cumplir con los mínimos, las (4) establecen los mínimos nutricionales aportados por las cantidades que se quedan en la familia, las (5) activan las variables binarias para el costo fijo, las (6) establecen las exclusiones de cultivos. Finalmente, (7) define la naturaleza de las variables.

Una característica de este problema es que, como es agricultura, hay todo tipo de incertidumbres. Eso es lo que abordamos a continuación.

Primero, suponga que le indican que los aportes de nutrientes de los distintos cultivos están sujetos a incertidumbre, pero esta ha sido estudiada. Específicamente, le dicen que los coeficientes a_{js} se pueden modelar según una distribución normal con medias $\bar{a}_{js}$ y desviación estándar σ_{js} , independientes entre sí. A usted se le ocurre que una forma de manejar esta incertidumbre es mediante un modelo con restricciones probabilísticas. Vamos a escribir un modelo con restricciones probabilísticas, pidiendo que cada restricción (4) se cumpla con una probabilidad de, al menos 0,95. Las restricciones que se deben escribir son:

$$\sum_{j=1}^n \bar{a}_{js} w_{ij} - (1,65) \sqrt{\sum_{j=1}^n \sigma_{js}^2 w_{ij}^2} \geq e_{is}, s = 1, \dots, r; i = 1, \dots, m$$

y el modelo con restricciones probabilísticas es:

$$\begin{aligned}
& \text{máx} \quad \sum_{i=1}^m \sum_{j=1}^n p_j v_{ij} - \sum_{i=1}^m \sum_{j=1}^n \{c_j x_{ij} + d_j x_{ij} + F_j z_{ij}\} \\
& \text{s.a.} \\
& r_j x_{ij} = v_{ij} + w_{ij} + \sum_{l=1, l \neq i}^m y_{ilj} \quad i = 1, \dots, m; j = 1, \dots, n \quad (1) \\
& \sum_{j=1}^n x_{ij} \leq S_i \quad i = 1, \dots, m \quad (2) \\
& w_{ij} + \sum_{l=1, l \neq i}^m y_{lij} \geq f_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (3) \\
& \sum_{j=1}^n \bar{a}_{js} w_{ij} - (1,65) \sqrt{\sum_{j=1}^n \sigma_{js}^2 w_{ij}^2} \geq e_{is}, s = 1, \dots, r; i = 1, \dots, m \quad (4') \\
& x_{ij} \leq S_i z_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (5) \\
& \sum_{k \in R_j} z_{ik} \leq n(1 - z_{ij}) \quad i = 1, \dots, m; j = 1, \dots, n \quad (6) \\
& x_{ij} \geq 0, y_{ilj} \geq 0, v_{ij} \geq 0, w_{ij} \geq 0, z_{ij} \in \{0, 1\} \quad i, l = 1, \dots, m; j = 1, \dots, n \quad (7)
\end{aligned}$$

Supongamos ahora que los coeficientes a_{js} son completamente conocidos y no varían, pero ahora sí hay incertidumbre en los rendimientos de los cultivos, los coeficientes r_j . Más específicamente, esos rendimientos se pueden modelar según una distribución de probabilidad conocida, que denotaremos por ξ . Se le ocurre,

entonces, dado que el problema tiene una clara separación de decisiones en el tiempo, que lo mejor es modelar la situación como un problema de estocástico de 2 etapas. Vamos a desarrollar un modelo estocástico de 2 etapas.

Por la estructura y la historia contada, lo más natural es que las decisiones de siembra firmen la primera etapa del problema y las restantes se ajuste una vez que la incertidumbre se hace presente en los rendimientos. Entonces, el problema estocástico de 2 etapas es el siguiente:

$$\begin{aligned}
 \text{máx} \quad & - \sum_{i=1}^m \sum_{j=1}^n (c_j x_{ij} + d_j x_{ij}) - \sum_{i=1}^m \sum_{j=1}^n F_j z_{ij} + \mathbb{E}(Q(x, z)) \\
 \text{s.a.} \quad & \sum_{j=1}^n x_{ij} \leq S_i \quad i = 1, \dots, m \quad (2) \\
 & x_{ij} \leq S_i z_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (5) \\
 & \sum_{k \in R_j} z_{ik} \leq n(1 - z_{ij}) \quad i = 1, \dots, m; j = 1, \dots, n \quad (6) \\
 & x_{ij} \geq 0, z_{ij} \in \{0, 1\} \quad i, l = 1, \dots, m; j = 1, \dots, n \quad (7')
 \end{aligned}$$

donde Q es la consecuencia en el futuro de las decisiones de primera etapa y está dado por:

$$\begin{aligned}
 Q(x, z) = \text{máx} \quad & \sum_{i=1}^m \sum_{j=1}^n p_j v_{ij} \\
 \text{s.a.} \quad & r_j x_{ij} = v_{ij} + w_{ij} + \sum_{l=1, l \neq i}^m y_{ilj} \quad i = 1, \dots, m; j = 1, \dots, n \quad (1) \\
 & w_{ij} + \sum_{l=1, l \neq i}^m y_{lij} \geq f_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (3) \\
 & \sum_{j=1}^n a_{js} w_{ij} \geq e_{is} \quad s = 1, \dots, r; i = 1, \dots, m \quad (4) \\
 & y_{ilj} \geq 0, v_{ij} \geq 0, w_{ij} \geq 0, \quad i, l = 1, \dots, m; j = 1, \dots, n \quad (7'')
 \end{aligned}$$

Ahora vamos a escribir el problema de Sample Average Approximation (SAA) que se puede usar para resolver aproximadamente el problema anterior. Para el problema SAA, generaremos escenarios aleatorios a partir de la distribución ξ , para los parámetros r_j . Vamos a suponer, entonces, que se generan R escenarios, de todos estos parámetros, que denotamos r_j^t , para $j = 1, \dots, n, t = 1, \dots, R$. Todas las variables de segunda etapa se deben superindexar según el escenario. El problema SAA es:

$$\begin{aligned}
 \text{máx} \quad & - \sum_{i=1}^m \sum_{j=1}^n (c_j x_{ij} + d_j x_{ij}) - \sum_{i=1}^m \sum_{j=1}^n F_j z_{ij} + \frac{1}{R} \sum_{t=1}^R \sum_{i=1}^m \sum_{j=1}^n p_j v_{ij} \\
 \text{s.a.} \quad & \sum_{j=1}^n x_{ij} \leq S_i \quad i = 1, \dots, m \quad (2) \\
 & x_{ij} \leq S_i z_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (5) \\
 & \sum_{k \in R_j} z_{ik} \leq n(1 - z_{ij}) \quad i = 1, \dots, m; j = 1, \dots, n \quad (6) \\
 & v_{ij}^t + w_{ij}^t + \sum_{l=1, l \neq i}^m y_{ilj}^t = r_j^t x_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (1') \\
 & w_{ij}^t + \sum_{l=1, l \neq i}^m y_{lij}^t \geq f_{ij} \quad i = 1, \dots, m; j = 1, \dots, n \quad (3') \\
 & \sum_{j=1}^n a_{js} w_{ij}^t \geq e_{is} \quad s = 1, \dots, r; i = 1, \dots, m \quad (4') \\
 & x_{ij} \geq 0, y_{ilj}^t \geq 0, v_{ij}^t \geq 0, w_{ij}^t \geq 0, z_{ij} \in \{0, 1\} \quad i, l = 1, \dots, m; j = 1, \dots, n \quad (7''')
 \end{aligned}$$

(notar que los números de restricciones son otros ya que las que corresponden a los escenarios no son las mismas del problema original).

Como ya sabemos, el problema SAA debería poder ser resuelto mediante Descomposición de Benders. Veamos cómo funcionaría esto, es decir, cuál es la estructura correspondiente.

Acá se muestra el problema SAA reescrito en forma ordenada para que se vea la estructura de Benders. Las variables complicantes son las mismas de la primera etapa, es decir, (x, z) (se han simplificado los rangos de los índices y se eliminan los números de restricciones, pero razones de espacio). Para que todo quepa en el espacio vamos a definir:

$$g(x, z) = - \sum_{i=1}^m \sum_{j=1}^n (c_j x_{ij} + d_j x_{ij}) - \sum_{i=1}^m \sum_{j=1}^n F_j z_{ij}$$

El problema SAA es:

$$\begin{aligned} \text{máx} \quad & g(x, z) + \frac{1}{R} \sum_{t=1}^R \sum_{i=1}^m \sum_{j=1}^n p_j v_{ij}^t \\ \text{s.a.} \quad & \sum_{j=1}^n x_{ij} \leq S_i & \forall i \\ & x_{ij} \leq S_i z_{ij} & \forall i, j \\ & \sum_{k \in R_j} z_{ik} \leq n(1 - z_{ij}) & \forall i, j \\ & r_j x_{ij} = v_{ij}^t + w_{ij}^t + \sum_{l=1, l \neq i}^m y_{ilj}^t & \forall i, j, t \\ & w_{ij}^t + \sum_{l=1, l \neq i}^m y_{lij}^t \geq f_{ij} & \forall i, j, t \\ & \sum_{j=1}^n a_{js} w_{ij}^t \geq e_{is} & \forall i, t, s \\ & x_{ij} \geq 0, z_{ij} \in \{0, 1\}, \quad y_{ilj}^t \geq 0, v_{ij}^t \geq 0, w_{ij}^t \geq 0, & \forall i, j, l, t \end{aligned}$$

No vamos a desarrollar completamente la descomposición de Benders pero sí vamos a notar lo siguiente: el problema interior de la estructura es:

$$\begin{aligned} \text{máx} \quad & \frac{1}{R} \sum_{t=1}^R \sum_{i=1}^m \sum_{j=1}^n p_j v_{ij}^t \\ \text{s.a.} \quad & v_{ij}^t + w_{ij}^t + \sum_{l=1, l \neq i}^m y_{ilj}^t = r_j x_{ij} & \forall i, j, t \\ & w_{ij}^t + \sum_{l=1, l \neq i}^m y_{lij}^t \geq f_{ij} & \forall i, j, t \\ & \sum_{j=1}^n a_{js} w_{ij}^t \geq e_{is} & \forall i, t, s \\ & y_{ilj}^t \geq 0, v_{ij}^t \geq 0, w_{ij}^t \geq 0, & \forall i, j, l, t \end{aligned}$$

A este problema habría que calcularle el dual, lo que suena bastante complicado. Sin embargo, podemos observar que el problema se descompone por bloques según el índice t :

Una característica de este problema es que hay todo tipo de incertidumbres y abordaremos esto en lo que sigue.

Supongamos primero que le indican que la duración de las operaciones, w_i , son inciertas, pero se sabe que los w_i se pueden modelar según una distribución normal con media $\bar{w}_i$ y desviación estándar σ_i , en forma independiente entre sí. A usted se le ocurre que una forma de manejar esta incertidumbre es mediante un modelo con restricciones probabilísticas. Vamos a desarrollar el modelo con restricciones probabilísticas, pidiendo que cada restricción afectada por incertidumbre se cumpla con una probabilidad de al menos 0,95.

Esto se hace con la construcción estándar del equivalente determinístico de restricciones probabilísticas. Las restricciones afectadas por esta incertidumbre son las (2), así que pedimos que:

$$Prob\left(\sum_{i=1}^P w_i x_{ijt} \leq T + \delta_{jt}\right), \quad j = 1, \dots, N; t = 1, \dots, 7$$

cuyo equivalente determinístico es:

$$\sum_{i=1}^P \bar{w}_i x_{ijt} - \delta_{jt} + (1,65) \sqrt{\sum_{i=1}^P (\sigma_i x_{ijt})^2} \leq T, \quad j = 1, \dots, N; t = 1, \dots, 7$$

(donde vaya δ_{jt} es irrelevante, lo que importa es que no entra en la raíz cuadrada ya que su coeficiente es constante).

Entonces, el modelo con restricciones probabilísticas es:

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 d_{ijt} x_{ijt} - \sum_{j=1}^N \sum_{t=1}^7 c_{jt} \delta_{jt} - \beta \sum_{i=1}^P z_i \\ \text{s.a.} \quad & \sum_{j=1}^N \sum_{t=1}^7 x_{ijt} + z_i = 1, \quad i = 1, \dots, P \end{aligned} \quad (1)$$

$$\sum_{i=1}^P \bar{w}_i x_{ijt} - \delta_{jt} + (1,65) \sqrt{\sum_{i=1}^P (\sigma_i x_{ijt})^2} \leq T, \quad j = 1, \dots, N; t = 1, \dots, 7 \quad (2')$$

$$\sum_{j=1}^N \delta_{jt} \leq Q_t \quad t = 1, \dots, 7 \quad (3)$$

$$x_{ijt}, z_i \in \{0, 1\}, \delta_{jt} \geq 0, \quad i = 1, \dots, P; j = 1, \dots, N; t = 1, \dots, 7 \quad (4)$$

Ahora le proponen que resuelva la relajación lineal del problema planteado por usted en a) mediante un algoritmo de punto interior. Desarrollemos ese problema. La relajación lineal es:

$$\begin{aligned} \text{máx} \quad & \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 d_{ijt} x_{ijt} - \sum_{j=1}^N \sum_{t=1}^7 c_{jt} \delta_{jt} - \beta \sum_{i=1}^P z_i \\ \text{s.a.} \quad & \sum_{j=1}^N \sum_{t=1}^7 x_{ijt} + z_i = 1, \quad i = 1, \dots, P \end{aligned} \quad (1)$$

$$\sum_{i=1}^P \bar{w}_i x_{ijt} - \delta_{jt} + (1,65) \sqrt{\sum_{i=1}^P (\sigma_i x_{ijt})^2} \leq T, \quad j = 1, \dots, N; t = 1, \dots, 7 \quad (2')$$

$$\sum_{j=1}^N \delta_{jt} \leq Q_t \quad t = 1, \dots, 7 \quad (3)$$

$$0 \leq x_{ijt} \leq 1, 0 \leq z_i \leq 1, \delta_{jt} \geq 0, \quad i = 1, \dots, P; j = 1, \dots, N; t = 1, \dots, 7 \quad (4')$$

El que podemos escribir, usando variables auxiliares y_{jt} , como

$$\begin{aligned}
\text{máx} \quad & \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 d_{ijt} x_{ijt} - \sum_{j=1}^N \sum_{t=1}^7 c_{jt} \delta_{jt} - \beta \sum_{i=1}^P z_i \\
\text{s.a.} \quad & \sum_{j=1}^N \sum_{t=1}^7 x_{ijt} + z_i = 1, & i = 1, \dots, P & \quad (1) \\
& T - \sum_{i=1}^P \bar{w}_i x_{ijt} + \delta_{jt} = (1, 65) y_{jt}, & j = 1, \dots, N; t = 1, \dots, 7 & \quad (1,5) \\
& \sqrt{\sum_{i=1}^P (\sigma_i x_{ijt})^2} \leq y_{jt}, & j = 1, \dots, N; t = 1, \dots, 7 & \quad (2'') \\
& \sum_{j=1}^N \delta_{jt} \leq Q_t & t = 1, \dots, 7 & \quad (3) \\
& 0 \leq x_{ijt} \leq 1, 0 \leq z_i \leq 1, \delta_{jt} \geq 0, & i = 1, \dots, P; j = 1, \dots, N; t = 1, \dots, 7 & \quad (4')
\end{aligned}$$

La función de barrera debe incluir todas las desigualdades lineales y las restricciones cónicas. Es:

$$\begin{aligned}
\Phi(x, y, z) = & - \sum_{(i,j) \in A} \log \left(y_{jt}^2 - \sum_{i=1}^P (\sigma_i x_{ijt})^2 \right) - \sum_{t=1}^7 \log \left(Q_t - \sum_{j=1}^N \delta_{jt} \right) \\
& - \sum_{j=1}^N \sum_{t=1}^7 \log \delta_{jt} - \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 \log x_{ijt} - \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 \log (1 - x_{ijt}) \\
& - \sum_{i=1}^P \log z_i - \sum_{i=1}^P \log (1 - z_i)
\end{aligned}$$

El problema penalizado usa un parámetro de penalización $\mu > 0$ y es:

$$\begin{aligned}
\text{máx} \quad & \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 d_{ijt} x_{ijt} - \sum_{j=1}^N \sum_{t=1}^7 c_{jt} \delta_{jt} - \beta \sum_{i=1}^P z_i + \mu \Phi(x, y, z) \\
\text{s.a.} \quad & \sum_{j=1}^N \sum_{t=1}^7 x_{ijt} + z_i = 1, & i = 1, \dots, P & \quad (1) \\
& T - \sum_{i=1}^P \bar{w}_i x_{ijt} + \delta_{jt} = (1, 65) y_{jt}, & j = 1, \dots, N; t = 1, \dots, 7 & \quad (1,5)
\end{aligned}$$

Siguiendo con el manejo de la incertidumbre, supongamos ahora que decide descartar el enfoque de restricciones probabilísticas anterior pero observa que, dado que el problema tiene una clara separación de decisiones en el tiempo, lo mejor es modelar la situación como un problema de estocástico de 2 etapas. Vamos a desarrollar este modelo.

Dada la forma como está formulada la historia, las decisiones de asignación de las operaciones deben tomarse antes de que estas se hagan, así que (x, z) son las variables de primera etapa, “hear and now”. Por otro lado, las variables δ son las “wait and see”. El problema de 2 etapas se formula como sigue:

$$\begin{aligned}
\text{máx} \quad & \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 d_{ijt} x_{ijt} - \beta \sum_{i=1}^P z_i + \mathbb{E}(F(x, z)) \\
\text{s.a.} \quad & \sum_{j=1}^N \sum_{t=1}^7 x_{ijt} + z_i = 1, & i = 1, \dots, P & \quad (1) \\
& x_{ijt}, z_i \in \{0, 1\}, & i = 1, \dots, P; j = 1, \dots, N; t = 1, \dots, 7 & \quad (4'')
\end{aligned}$$

donde

$$\begin{aligned}
F(x, z) = \text{máx} \quad & - \sum_{j=1}^N \sum_{t=1}^7 c_{jt} \delta_{jt} \\
\text{s.a.} \quad & \sum_{i=1}^P w_i x_{ijt} \leq T + \delta_{jt}, & j = 1, \dots, N; t = 1, \dots, 7 & \quad (2') \\
& \sum_{j=1}^N \delta_{jt} \leq Q_t & t = 1, \dots, 7 & \quad (3) \\
& \delta_{jt} \geq 0, & j = 1, \dots, N; t = 1, \dots, 7 & \quad (4'')
\end{aligned}$$

Escribamos ahora el problema de Sample Average Approximation (SAA) que se puede usar para resolver aproximadamente el problema anterior. Para formular el problema de SAA asumiremos que disponemos de S escenarios de los parámetros inciertos w_i . Estos escenarios se generan en forma aleatoria a partir de la distribución de probabilidad normal que nos dicen que siguen esos parámetros. Denotemos, entonces, por $w_i^s, i = 1, \dots, P, s = 1, \dots, S$ es escenarios generados. También definimos por δ_{jt}^s las variables de segunda etapa asociadas a cada escenario. El problema SAA es:

$$\begin{aligned}
 \text{máx} \quad & \sum_{i=1}^P \sum_{j=1}^N \sum_{t=1}^7 d_{ijt} x_{ijt} - \beta \sum_{i=1}^P z_i - \frac{1}{S} \sum_{s=1}^S \sum_{j=1}^N \sum_{t=1}^7 c_{jt} \delta_{jt}^s \\
 \text{s.a.} \quad & \sum_{j=1}^N \sum_{t=1}^7 x_{ijt} + z_i = 1, & i = 1, \dots, P \\
 & \sum_{i=1}^P w_i^s x_{ijt} \leq T + \delta_{jt}^s, & j = 1, \dots, N; t = 1, \dots, 7; s = 1, \dots, S \\
 & \sum_{j=1}^N \delta_{jt}^s \leq Q_t & t = 1, \dots, 7; s = 1, \dots, S \\
 & x_{ijt}, z_i \in \{0, 1\}, \delta_{jt}^s \geq 0, & i = 1, \dots, P; j = 1, \dots, N; t = 1, \dots, 7; s = 1, \dots, S
 \end{aligned} \tag{1}$$

Supongamos ahora que alguien le ofrece una consultoría para mejorar la estimación de la duración de las operaciones, los parámetros w_i . Específicamente, le dice que por un valor de M (unidades monetarias) puede reducir las desviaciones estándar estimada de cada parámetro w_i en un 50 %. Veamos cómo pueden usarse los modelos anteriores para evaluar si acaso vale la pena contratar la consultoría.

Una forma de hacer este análisis es el siguiente: Llamemos z^1 el valor óptimo alcanzado por el problema SAA con los datos originales. La consultora promete reducir los valores de los σ_i en un 50 %, así que podríamos generar un nuevo conjunto de escenarios, $\bar{w}_i^s$, pero con las distribuciones normales con esas nuevas desviaciones estándar. Usando esos escenarios, resolvemos el nuevo SAA. Llamemos z^2 el valor óptimo alcanzado. Tanto z^1 como z^2 son estimaciones de los valores óptimos de los problemas de 2 etapas, sin consultora y con consultora. Sabemos que, típicamente, $z^2 \geq z^1$ (porque en el segundo caso hay mejor información, se pierde menos y, recordemos, estamos maximizando). Entonces, $z^2 - z^1$ es el valor estimado de la información adicional. Si $z^2 - z^1 > M$, definitivamente estamos ganando más que el costo de la consultoría y, definitivamente vale la pena contratarla.

Un problema de planificación de tareas forestales

Una empresa del sector forestal debe tomar una serie de decisiones relativas a la cosecha de sus bosques a lo largo de un cierto horizonte de mediano plazo. Vamos a suponer que esta compañía dispone de n bosques (o “rodal”, en la jerga del área), los cuales pueden ser cosechados en cualquier momento que se considere adecuado dentro de un horizonte que se extiende desde ahora hasta T periodos de tiempo (meses). Cada rodal tiene una cantidad B_i de madera, $i = 1, \dots, n$ (medido en metros cúbicos). En cada periodo de tiempo se puede cosechar todo o sólo una parte de cada rodal. Existen m puntos de destino a los cuales se puede enviar la madera cosechada en cada periodo. Cada uno de estos puntos de destino paga un precio p_j por metro cúbico en el destino j . La empresa debe decidir sobre la instalación de faenas en los rodales que se vayan a cosechar, al comienzo de todo el horizonte de planificación, y esta instalación (maquinarias, campamentos, etc.) involucra costos fijos, independientemente de las cantidades cosechadas después. Esta decisión es importante ya que los costos de instalación de faenas son muy significativos. Igualmente, si se traslada madera desde el rodal i hacia el punto de destino j , debe habilitarse, en ese momento, infraestructura de transporte y esto tiene costos fijos asociados. Sean: β_i , el costo fijo de instalación de faenas en el rodal i , α_{it} el costo unitario de cosecha en el rodal i en el periodo t , c_{ij} el costo unitario de transporte entre el rodal i y el destino j , y f_{ijt} el costo fijo de habilitación de transporte entre i y j en el periodo t . Adicionalmente, la actividad de cosecha es también usada para la generación de biomasa (ramas, residuos) y se debe cumplir una meta mínima de generación de biomasa por periodo (para uso, por ejemplo, en generación eléctrica). Se sabe que si se cosecha el bosque i en t , se puede generar g_{it} toneladas de biomasa y se ha establecido una cuota mínima G_t por periodo. La empresa usa el siguiente modelo para determinar el plan óptimo de

cosecha sobre el horizonte, y que maximiza la utilidad de la compañía:

$$\begin{aligned} \text{máx} \quad & \sum_{t=1}^T \left\{ \sum_{j=1}^m p_j v_{jt} - \sum_{i=1}^n \alpha_{it} x_{it} - \sum_{i=1}^n \sum_{j=1}^m (c_{ij} y_{ijt} + f_{ijt} w_{ijt}) \right\} - \sum_{i=1}^n \beta_i z_i \\ \text{s.a.} \quad & \sum_{j=1}^m y_{ijt} = x_{it} \quad i = 1, \dots, n; t = 1, \dots, T \end{aligned} \quad (1)$$

$$\sum_{i=1}^n y_{ijt} = v_{jt} \quad j = 1, \dots, m; t = 1, \dots, T \quad (2)$$

$$x_{it} \leq B_i - \sum_{k=1}^{t-1} x_{ik} \quad i = 1, \dots, n; t = 2, \dots, T \quad (3)$$

$$x_{i1} \leq B_i \quad i = 1, \dots, n \quad (4)$$

$$x_{it} \leq B_i z_i \quad i = 1, \dots, n; t = 1, \dots, T \quad (5)$$

$$y_{ijt} \leq M w_{ijt} \quad i = 1, \dots, n; j = 1, \dots, m; t = 1, \dots, T \quad (6)$$

$$\sum_{i=1}^n g_{it} z_i \geq G_t \quad t = 1, \dots, T \quad (7)$$

$$x_{it} \geq 0, y_{ijt} \geq 0, v_{jt} \geq 0, z_i \in \{0, 1\}, w_{ijt} \in \{0, 1\} \quad i = 1, \dots, n; t = 1, \dots, T; j = 1, \dots, m \quad (8)$$

donde M es “suficientemente grande”. En este modelo, las variables x corresponden a la cosecha y las z son binarias que indican si se instala faena en algún rodal, las variables y corresponden al transporte desde los rodales a los puntos de demanda, las variables v acumulan la cantidad que se envía a un punto de destino, y las variables w indican si se activa el transporte entre i y j o no. Las restricciones (1) asignan lo cosechado a transporte, las (2) acumulan lo que se vende en destinos, las (3) y (4) acotan lo que se puede cosechar a lo disponible a medida que avanza el tiempo, las (5) activan el costo fijo de faenas, las (6) activan el costo fijo de transporte, las (7) establecen el mínimo de remoción de especies parásitas y, finalmente, las (8) definen la naturaleza de las variables.

Este problema puede presentar diversas fuentes de incertidumbre y veremos cómo modelar algunas de estas.

Suponga que le indican que los coeficientes de generación de biomasa, g_{it} , son inciertos, pero se sabe que se pueden modelar según una distribución normal con media $\bar{g}_{it}$ y desviación estándar σ_{it} , independientes entre sí. A usted se le ocurre que una forma de manejar esta incertidumbre es mediante un modelo con restricciones probabilísticas. Vamos a escribir el modelo con restricciones probabilísticas, pidiendo que cada restricción afectada por incertidumbre se cumpla con una probabilidad de al menos 0,95.

La restricción probabilística es:

$$\sum_{i=1}^n \bar{g}_{it} z_i - (1,65) \sqrt{\sum_{i=1}^n \sigma_{it}^2 z_i^2} \geq G_t, t = 1, \dots, T$$

y el modelo es, ahora:

$$\begin{aligned} \text{máx} \quad & \sum_{t=1}^T \left\{ \sum_{j=1}^m p_j v_{jt} - \sum_{i=1}^n \alpha_{it} x_{it} - \sum_{i=1}^n \sum_{j=1}^m (c_{ij} y_{ijt} + f_{ijt} w_{ijt}) \right\} - \sum_{i=1}^n \beta_i z_i \\ \text{s.a.} \quad & \sum_{j=1}^m y_{ijt} = x_{it} \quad i = 1, \dots, n; t = 1, \dots, T \end{aligned} \quad (1)$$

$$\sum_{i=1}^n y_{ijt} = v_{jt} \quad j = 1, \dots, m; t = 1, \dots, T \quad (2)$$

$$x_{it} \leq B_i - \sum_{k=1}^{t-1} x_{ik} \quad i = 1, \dots, n; t = 2, \dots, T \quad (3)$$

$$x_{i1} \leq B_i \quad i = 1, \dots, n \quad (4)$$

$$x_{it} \leq B_i z_i \quad i = 1, \dots, n; t = 1, \dots, T \quad (5)$$

$$y_{ijt} \leq M w_{ijt} \quad i = 1, \dots, n; j = 1, \dots, m; t = 1, \dots, T \quad (6)$$

$$\sum_{i=1}^n \bar{g}_{it} z_i - (1,65) \sqrt{\sum_{i=1}^n \sigma_{it}^2 z_i^2} \geq G_t, \quad t = 1, \dots, T \quad (7')$$

$$x_{it} \geq 0, y_{ijt} \geq 0, v_{jt} \geq 0, z_i \in \{0, 1\}, w_{ijt} \in \{0, 1\} \quad i = 1, \dots, n; t = 1, \dots, T; j = 1, \dots, m \quad (8)$$

Volviendo a la situación anterior, supongamos que, en realidad, nadie sabe cómo se distribuyen los coeficientes de generación de biomasa. Sin embargo, a partir de mediciones empíricas, lo indican que se conocen valores

estimados $\bar{g}_{it}$ y que el verdadero valor puede llegar a variar hasta un 20% con respecto a ese valor nominal. En este caso, usted se da cuenta que sólo un modelo de Optimización Robusta puede usarse. Veamos cómo modelar eso.

En este caso, estamos diciendo que $g_{it} \in [\bar{g}_{it} - s_{it}, \bar{g}_{it} + s_{it}]$, donde $s_{it} = 0,2 \times \bar{g}_{it}$. Si usamos el enfoque de Soyster, la contraparte robusta de la restricción es:

$$\sum_{i=1}^n (\bar{g}_{it} - s_{it}) z_i \geq G_t, t = 1, \dots, T$$

Ahora, volviendo al problema con restricciones probabilísticas, le proponen que resuelva *la relajación lineal* del problema planteado por usted en a) mediante un algoritmo de punto interior. Veamos cómo se haría eso.

Primero, los algoritmos de punto interior se usan en problemas continuos, lineales o lineales cónicos (al menos, como hemos visto en el curso), así que el problema debe ser relajado y escrito en el formato cónico más detallado, primero. Para esto, vamos a definir variables auxiliares s_t y el modelo es:

$$\begin{aligned} \text{máx} \quad & \sum_{t=1}^T \left\{ \sum_{j=1}^m p_j v_{jt} - \sum_{i=1}^n \alpha_{it} x_{it} - \sum_{i=1}^n \sum_{j=1}^m (c_{ij} y_{ijt} + f_{ijt} w_{ijt}) \right\} - \sum_{i=1}^n \beta_i z_i \\ \text{s.a.} \quad & \sum_{j=1}^m y_{ijt} = x_{it} & i = 1, \dots, n; t = 1, \dots, T & (1) \\ & \sum_{i=1}^n y_{ijt} = v_{jt} & j = 1, \dots, m; t = 1, \dots, T & (2) \\ & x_{it} \leq B_i - \sum_{k=1}^{t-1} x_{ik} & i = 1, \dots, n; t = 2, \dots, T & (3) \\ & x_{i1} \leq B_i & i = 1, \dots, n & (4) \\ & x_{it} \leq B_i z_i & i = 1, \dots, n; t = 1, \dots, T & (5) \\ & y_{ijt} \leq M w_{ijt} & i = 1, \dots, n; j = 1, \dots, m; t = 1, \dots, T & (6) \\ & \sqrt{\sum_{i=1}^n \sigma_{it}^2 z_i^2} \leq s_t, & t = 1, \dots, T & (7'') \\ & (1,65) s_t = \sum_{i=1}^n \bar{g}_{it} z_i - G_t & t = 1, \dots, T & (7''') \\ & x_{it} \geq 0, y_{ijt} \geq 0, v_{jt} \geq 0, 0 \leq z_i \leq 1, 0 \leq w_{ijt} \leq 1 & i = 1, \dots, n; t = 1, \dots, T; j = 1, \dots, m & (8) \end{aligned}$$

Todas las desigualdades (si, son muchas) e inclusiones cónicas deben ir en la función de barrera, así que esta es:

$$\begin{aligned} \Phi(x, y, v, z, w) = & -\log(s_t^2 - \sum_{i=1}^n \sigma_{it}^2 z_i^2) - \sum_{i=1}^n \sum_{t=1}^T \log(B_i - \sum_{k=1}^{t-1} x_{ik} - x_{it}) - \sum_{i=1}^n \log(B_i - x_{i1}) - \sum_{i=1}^n \sum_{t=1}^T \log(B_i z_i - x_{it}) \\ & - \sum_{i=1}^n \sum_{j=1}^m \sum_{t=1}^T \log(M w_{ijt} - y_{ijt}) - \sum_{i=1}^n \sum_{t=1}^T \log(x_{it}) - \sum_{i=1}^n \sum_{j=1}^m \sum_{t=1}^T \log(y_{ijt}) - \sum_{j=1}^m \sum_{t=1}^T \log(v_{jt}) \\ & - \sum_{i=1}^n \sum_{j=1}^m \sum_{t=1}^T \log(w_{ijt}) - \sum_{i=1}^n \sum_{j=1}^m \sum_{t=1}^T \log(1 - w_{ijt}) \\ & - \sum_{i=1}^n \log(z_i) - \sum_{i=1}^n \log(1 - z_i) \end{aligned}$$

Ahora, el problema penalizado que usa el algoritmo de punto interior se construye con esa función de barrera y un parámetro de penalización $\mu > 0$. El problema es:

$$\begin{aligned}
\text{máx} \quad & \sum_{t=1}^T \left\{ \sum_{j=1}^m p_j v_{jt} - \sum_{i=1}^n \alpha_{it} x_{it} - \sum_{i=1}^n \sum_{j=1}^m (c_{ij} y_{ijt} + f_{ijt} w_{ijt}) \right\} - \sum_{i=1}^n \beta_i z_i && -\mu \Phi(x, y, v, z, w) \\
\text{s.a.} \quad & \sum_{j=1}^m y_{ijt} = x_{it} && i = 1, \dots, n; t = 1, \dots, T \quad (1) \\
& \sum_{i=1}^n y_{ijt} = v_{jt} && j = 1, \dots, m; t = 1, \dots, T \quad (2) \\
& (1,65)s_t = \sum_{i=1}^n \bar{g}_{it} z_i - G_t && t = 1, \dots, T \quad (7''')
\end{aligned}$$

Nótese la forma en que se escribió la función objetivo, con la función de barrera restada. Esto es porque el problema original es de maximización.

Ahora le dicen que no hay incertidumbre en los coeficientes g_{it} (y ya no son necesarias las restricciones probabilísticas), pero que sí hay incertidumbre en la disponibilidad de madera B_i , y que esta ha sido modelada con una distribución de probabilidades conocida. Entonces, usted observa que, dado que el problema tiene una clara separación de decisiones en el tiempo, lo mejor es modelar la situación como un problema estocástico de 2 etapas. Veamos cómo modelar esto.

En este caso, las variables de primera etapa son, naturalmente, las z , que se refieren a la instalación de faenas. Esto debe hacerse antes de todo, según indica la historia. Todas las demás decisiones son de segunda etapa y dependen de cuando se manifiesta la incertidumbre. Entonces, el modelo de 2 etapas es:

$$\begin{aligned}
\text{máx} \quad & - \sum_{i=1}^n \beta_i z_i + \mathbb{E}(Q(z)) \\
\text{s.a.} \quad & \sum_{i=1}^n g_{it} z_i \geq G_t && t = 1, \dots, T \quad (7) \\
& z_i \in \{0, 1\} && i = 1, \dots, n
\end{aligned}$$

donde

$$\begin{aligned}
Q(z) = \text{máx} \quad & \sum_{t=1}^T \left\{ \sum_{j=1}^m p_j v_{jt} - \sum_{i=1}^n \alpha_{it} x_{it} - \sum_{i=1}^n \sum_{j=1}^m (c_{ij} y_{ijt} + f_{ijt} w_{ijt}) \right\} \\
\text{s.a.} \quad & \sum_{j=1}^m y_{ijt} = x_{it} && i = 1, \dots, n; t = 1, \dots, T \quad (1) \\
& \sum_{i=1}^n y_{ijt} = v_{jt} && j = 1, \dots, m; t = 1, \dots, T \quad (2) \\
& x_{it} \leq B_i - \sum_{k=1}^{t-1} x_{ik} && i = 1, \dots, n; t = 2, \dots, T \quad (3) \\
& x_{i1} \leq B_i && i = 1, \dots, n \quad (4) \\
& x_{it} \leq B_i z_i && i = 1, \dots, n; t = 1, \dots, T \quad (5) \\
& y_{ijt} \leq M w_{ijt} && i = 1, \dots, n; j = 1, \dots, m; t = 1, \dots, T \quad (6) \\
& x_{it} \geq 0, y_{ijt} \geq 0, v_{jt} \geq 0, w_{ijt} \in \{0, 1\} && i = 1, \dots, n; t = 1, \dots, T; j = 1, \dots, m \quad (8)
\end{aligned}$$

Ahora escribimos el problema de Sample Average Approximation (SAA) que se puede usar para resolver aproximadamente el problema anterior.

Acá vamos a asumir que se han generado K escenarios de los parámetros inciertos, $B_i^1, \dots, B_i^K, i = 1, \dots, n$. Todas las variables de segunda etapa llevarán un superíndice k asociado al respectivo escenario. El modelo de SAA es:

$$\begin{aligned}
\text{máx} \quad & - \sum_{i=1}^n \beta_i z_i + \frac{1}{K} \sum_{k=1}^K \sum_{t=1}^T \left\{ \sum_{j=1}^m p_j v_{jt}^k - \sum_{i=1}^n \alpha_{it} x_{it}^k - \sum_{i=1}^n \sum_{j=1}^m (c_{ij} y_{ijt}^k + f_{ijt} w_{ijt}^k) \right\} \\
\text{s.a.} \quad & \sum_{i=1}^n g_{it} z_i \geq G_t & \forall t \\
& \sum_{j=1}^m y_{ijt}^k = x_{it}^k & \forall i, t \\
& \sum_{i=1}^n y_{ijt}^k = v_{jt}^k & \forall j, t \\
& x_{it}^k \leq B_i^k - \sum_{k=1}^{t-1} x_{ik}^k & \forall i, t \\
& x_{i1}^k \leq B_i^k & \forall i \\
& x_{it}^k \leq B_i^k z_i & \forall i, t \\
& y_{ijt}^k \leq M w_{ijt}^k & \forall i, j, t \\
& x_{it}^k \geq 0, y_{ijt}^k \geq 0, v_{jt}^k \geq 0, z_i \in \{0, 1\}, w_{ijt}^k \in \{0, 1\} & \forall i, j, t
\end{aligned}$$

Finalmente, comentemos que uno podría preguntarse si acaso se puede usar o no la Descomposición de Benders (de la forma en que la vimos en clases) para abordar este problema SAA. La respuesta es, definitivamente no, Benders aplicado al problema anterior identifica a las z como variables complicantes y todas las demás están en el problema interior, incluyendo variables enteras. Benders (como lo vimos en clases) debe tener un problema interior con variables continuas. En Optimización bajo Incertidumbre, se usa un método inspirado en la descomposición de Benders, conocido como el “L-shape method”, que permite aproximar la solución del problema, pero su descripción escapa de los objetivos de este curso.

10.5.2. Decisiones en etapas: comentarios

La modelación “con recurso” ha sido de gran utilidad en diversas áreas de aplicación. Una de las más antiguas es la Planificación de Sistemas Eléctricos y también los problemas de Planificación de Producción.

El proceso puede extenderse a más de una etapa, es lo que se conoce como un “Multistage Stochastic Problem”. En este caso la complejidad aumenta en forma significativa debido a que cada escenario de una etapa genera otros escenarios en la etapa siguiente. Se han desarrollado, eso sí, técnicas de aproximación que permiten abordar estos problemas, especialmente apoyados en los recursos computacionales existentes hoy. En ese sentido, estos problemas son buenos ejemplos de los niveles de complejidad que puede alcanzar la optimización, muchas veces alcanzan decenas de millones de variables y restricciones, pero con las “viejas” técnicas que hemos estudiado pueden ser abordados en forma aproximada, algo que no se podía hacer hace un par de décadas.

En forma alternativa a la aproximación por SAA, el problema de 2 etapas puede ser abordado mediante una técnica de subgradientes ya que la función objetivo es convexa. Eso lleva a otro método, que también tiene propiedades atractivas para algunos problemas.