

- La clase anterior presentamos una introducción al curso, ilustrando la relevancia de algunos de los temas que estudiaremos.
- Hoy entraremos en materia:
- Revisión del problema general y notación.
- Breve repaso de conceptos de optimización y algoritmos.
- Revisaremos los métodos de Gradiente y Newton

El problema general de Optimización:

- El problema:

$$P) \quad \min_{x \in S} f(x)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $S \subset \mathbb{R}^n$.

- Muchas veces haremos S explícito a través de restricciones algebraicas:

$$P) \quad \begin{array}{ll} \min & f(x) \\ \text{s.a.} & g_i(x) \leq b_i, i = 1, \dots, m \end{array}$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$.

El problema general: queremos calcular una solución

- ¿Qué posibilidades tenemos, en general, de poder encontrar una solución a P)?
- Encontremos el mínimo de $f(x) = x^2 + e^{-x}$.
- Veamos que nos dice un chat de IA
- ¿Y si más bien tratamos con una solución “**aproximada**”?
- Por ejemplo, $\bar{x} = 0,351732281$ es tal que $f'(\bar{x}) = -3,86 \times 10^{-6}$.

El problema general: definiciones básicas

- Sea x^* solución óptima de P).
- Sea $\epsilon > 0$.
- Decimos que $\bar{x} \in S$ es una solución ϵ -**óptima** de P) si

$$|f(\bar{x}) - f(x^*)| \leq \epsilon$$

- Decimos que $\bar{x} \in S$ es una ϵ -aproximación a la solución óptima de P) (o solución ϵ -**aproximada**) si

$$\|\bar{x} - x^*\| \leq \epsilon$$

- ($\|\cdot\|$ denota una norma en el espacio euclideo $\mathbb{R}^n$)

- Pregunta: ¿son equivalentes las dos nociones?

Cómo podemos calcular

- Para resolver el problema usaremos un “algoritmo” que genera una sucesión de puntos, partiendo de x^0 :

$$x^0, x^1, x^2, \dots$$

- El algoritmo usa las iteraciones anteriores y una subrutina a la que se le “preguntan” características de f .
- Esa subrutina es lo que se suele llamar un “oráculo”.

Cómo podemos calcular



(Fuente: historia.nationalgeographic.com.es)

Cómo podemos calcular

- El oráculo puede darnos distintos niveles de información.
 - ▶ **Oráculo de orden cero:** valores de la función.
 - ▶ **Oráculo de primer orden:** valores y derivadas (o algo parecido).
 - ▶ **Oráculo de segundo orden:** valores, derivadas y segundas derivadas.
- Una de las preguntas fundamentales en el curso: ¿Qué tan **eficiente** es el algoritmo?:
- Dado un error aceptable $\epsilon > 0$, ¿cuánto tiempo necesitamos para obtener una solución que cumpla con ese error (en alguna medida de aproximación)?
- Analizar esto es determinar la “complejidad del algoritmo”.

Qué podemos calcular

- Supongamos primero que nuestro algoritmo usa un oráculo de orden cero (sólo valores de la función).
- Tomemos, para simplificar, una función en una variable, y supongámosla continua.
- Veamos si podemos encontrar una solución aproximada para este problema:

$$P) \quad \min_{a \leq x \leq b} f(x)$$

Qué podemos calcular

- Sigamos con un oráculo de orden cero.
- Supongamos ahora que ponemos límites a la variación de f .

Definición

Decimos que $f : \mathbb{R} \rightarrow \mathbb{R}$ satisface una **condición de Lipschitz**, con constante L , si

$$|f(x) - f(y)| \leq L|x - y|, \quad \forall x, y$$

- Suponiendo ahora la hipótesis de Lipschitz, ¿Qué podemos hacer ahora con el problema:

$$P) \quad \min_{a \leq x \leq b} f(x) \quad ?$$

Qué podemos calcular

- Solo con un oráculo de orden cero no vamos a llegar muy lejos...
- Por esa razón tendremos que ir pidiendo más propiedades a la función y/o al conjunto de restricciones:
 - ▶ Usar oráculos de mayor orden
 - ▶ Pedir estructura más fuerte, como por ejemplo, convexidad.
- Y esas propiedades adicionales permitirán mejorar la eficiencia.

- Vamos a revisar ahora los algoritmos más básicos (y famosos) para un problema no lineal sin restricciones:
- Método del Gradiente y el Método de Newton
- Después avanzaremos más allá.
- El problema a estudiar:

$$P) \min_{x \in \mathbb{R}^n} f(x)$$

donde f es, al menos, continuamente diferenciable.

La idea del Algoritmo de Descenso

- Muchos algoritmos se basan en la idea de “descender” hacia el mínimo...

Definición

$d \neq 0$ se dice una **dirección de descenso** de f en x si existe $r > 0$ tal que $f(x + \lambda d) < f(x), \forall \lambda \geq 0, \lambda \leq r$.


- Las direcciones de descenso se relacionan a las derivadas de la función
- Tenemos:

Proposición

Si d es tal que $d^T \nabla f(x) < 0$, entonces d es una dirección de descenso.

- Entonces: queremos minimizar y nos dan una dirección de descenso...
- ¿Qué deberíamos hacer?

Dirección de descenso:



La idea del Algoritmo de Descenso

Data: $x^0 \in \mathbb{R}^n$, f , $k = 0$.

while *Criterio de parada no se satisface* **do**

 Sea d^k una dirección de descenso en x^k ;

 Resolver

$$\min_{\lambda \geq 0} f(x^k + \lambda d^k) \quad (\text{etapa de "linesearch"})$$

 Sea λ^k solución óptima de ese problema;

 Sea $x^{k+1} = x^k + \lambda^k d^k$;

$k = k + 1$;

end

- Hay que especificar todos los detalles...

La idea del Algoritmo de Descenso

- **La más simple dirección de descenso:**

$$h^k = -\nabla f(x^k)$$

- Da origen al Método del Gradiente o de Cauchy, un método de “primer orden”

- **Y la otra dirección famosa:**

$$h^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

- Esta es la Dirección de Newton y da origen al Método de Newton, un método de “segundo orden”.

¿De donde viene la Dirección de Newton?

- Supongamos estamos en un punto x .
- Aproximemos f mediante su desarrollo de Taylor de orden 2...
- (hagámoslo primero en 1 variable, es decir $n = 1$)
- Ahora recordemos nuestro problema “imposible” del comienzo:

$$\text{mín } x^2 + e^{-x}$$

¿Cómo se hace Newton aquí?

¿De donde viene la Dirección de Newton?

- Ahora expliquemos Newton en varias variables.
- Primero, recordemos que toda función tiene un Desarrollo de Taylor...
- Definamos la aproximación cuadrática a f en x :

$$q(y) = f(x) + \nabla f(x)^T(y - x) + \frac{1}{2}(y - x)^T \nabla^2 f(x)(y - x)$$

- Entonces, aproximamos f localmente por q .
- Determinemos el mínimo de esta aproximación cuadrática...

Método de Newton para minimizar

- Momento: ¿Cómo podemos estar seguros que d^k sea dirección de descenso?
- La dirección: $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$.
- Necesitamos que

$$\nabla f(x^k)^T d^k < 0$$

Ejemplo:

- Consideremos la función de n variables:

$$f(x) = \frac{1}{2}x^T Qx + c^T x + \alpha(5 - x_n)^4$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, $c \in \mathbb{R}^n$, α es constante.

- Veamos los métodos de Gradiente y Newton funcionando en un par de casos particulares del problema.
- Mostraremos una implementación computacional en Python.
- Necesitamos el gradiente y hessiano de la función...