

ICS2121, Métodos de Optimización

Una introducción a los Métodos de Primer Orden modernos

Motivación

- Recordemos el ejemplo de la introducción: estimar los parámetros de una red neuronal.
- Eso llevaba a un problema de optimización no restringida, que se podría abordar con los métodos del capítulo anterior...
- Pero, el número de variables (parámetros a estimar) puede ser muy, muy grande.
- Entonces, Newton está fuera de consideración...
- Sólo nos queda el Método del Gradiente...

El problema general:

- El problema a estudiar es el mismo de antes:

$$P) \quad \min_{x \in \mathbb{R}^n} f(x)$$

- Pero, agregamos desde el comienzo la hipótesis de que f **es convexa**.
- Supondremos, inicialmente, que f es continua y diferenciable (después cambiaremos esto).
- Vamos a repensar el Método del Gradiente...

Gradiente, pero sin linesearch

- Recordemos el **Algoritmo de Gradiente**:

Data: Sea $x^0 \in \mathbb{R}^n$, $k = 0$, $d^0 = -\nabla f(x^0)$, $\epsilon > 0$.

while $\|d^k\|_2 > \epsilon$ **do**

 sea λ^k una solución aproximada (que cumple condiciones de Wolfe-Armijo) de

$$\min_{\lambda \geq 0} f(x^k + \lambda d^k)$$

$$x^{k+1} = x^k + \lambda^k d^k;$$

$$d^{k+1} = -\nabla f(x^{k+1});$$

$$k = k + 1;$$

end

- Recordemos: λ^k , el paso de avance, es resultado de un proceso iterativo y **eso igual introduce costos**.
- Lo que buscamos:** queremos que λ^k esté **definido a priori** y no requiera cálculos iterativos de ningún tipo.

La convexidad entra en juego:

- El siguiente es un resultado conocido:

Teorema

Si f es convexa y continuamente diferenciable, se tiene:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x), \quad \forall x, y \in \mathbb{R}^n$$

- Interpretémoslo en 1 variable...

La convexidad entra en juego:

- Ahora agregaremos otro supuesto al problema:

- Pediremos que $\nabla f(x)$ sea **Lipschitziana** de parámetro $L > 0$, es decir:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2, \quad \forall x, y \in \mathbb{R}^n$$

(acotamos la variación de las primeras derivadas)

- Entonces, se puede probar el siguiente resultado:

Proposición

Si f cumple las hipótesis anteriores, entonces se tiene:

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2, \quad \forall x, y \in \mathbb{R}^n$$

Lo que la convexidad nos da

- Tenemos que f está “estimada por arriba y por abajo”:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x), \quad \forall x, y \in \mathbb{R}^n$$

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2, \quad \forall x, y \in \mathbb{R}^n$$

Gradiente, pero sin linesearch: el paso

- La aproximación superior, en un x fijo, como función de y :

$$q(y) = f(x) + \nabla f(x)^T (y - x) + \frac{L}{2} \|y - x\|_2^2$$

- Sigamos con la lógica de usar las aproximaciones en vez de la función en sí.
- Supongamos que x está fijo. ¿Qué valor de y minimiza esa aproximación superior?

Gradiente, pero sin linesearch

- Lo anterior nos lleva al siguiente método:

- Método Simple de Primer Orden:**

Data: Sea $x^0 \in \mathbb{R}^n$, $k = 0$, $d^0 = -\nabla f(x^0)$, $\epsilon > 0$.

while $\|d^k\| > \epsilon$ **do**

$x^{k+1} = x^k + \frac{1}{L}d^k$;
 $d^{k+1} = -\nabla f(x^{k+1})$;
 $k = k + 1$;

end

- Este será nuestro primer método de Primer Orden “moderno”.
- Para implementarlo **necesitamos conocer L** , pero, según el problema, eso se puede hacer o aproximar (veremos un ejemplo).
- El análisis original de esta idea y las otras que veremos, es antiguo: **Arkadi Nemirovsky** en los 70's, y complementada por **Yuri Nesterov** en los 80's, con mucho desarrollo adicional en este siglo.

Ejemplo Computacional

- Vamos a considerar un problema de “mínimos cuadrados”: queremos resolver el sistema

$$Ax = b$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$

- En el área de estimaciones estadísticas usando Modelos Lineales (regresión lineal), muchas veces $m > n$
- Entonces, se busca el mejor ajuste resolviendo el problema de mínimos cuadrados:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2$$

- Desarrollemos todo: necesitamos $\nabla f(x)$ y la constante L de $\nabla f(x)$.
- Y después veamos una implementación en Python.

Convergencia del Método Simple

- Sea x^* solución óptima. Es posible probar el siguiente resultado:

Teorema

Si f es convexa y continuamente diferenciable, ∇f es L -Lipschitz, y x^ es óptimo, entonces, después de k iteraciones del algoritmo, se tiene:*

$$f(x^k) - f(x^*) \leq \frac{L\|x^0 - x^*\|_2^2}{2k}$$

- Supongamos que buscamos una solución con error $\epsilon > 0$ (ϵ -óptima). Entonces, ¿cuántas iteraciones necesitamos?

Aceleración

- El método simple igual es bastante lento...
- Pero volvamos a los códigos y veamos otra corrida.
- El algoritmo que acabo de mostrar implementa una idea que se conoce como “aceleración”.
- Este concepto fue desarrollado por diversas personas a comienzos de los 2000 pero sus reales raíces están en un método que fue desarrollado por Yuri Nesterov en 1983 en la Unión Soviética de entonces.
- Pero no fue muy conocido en occidente debido a la Guerra Fría.

Aceleración

- El método usa dos sucesiones de puntos en vez de una...
- (explora el espacio en forma dinámica usando dos dimensiones)
- Sea $x^0 \in \mathbb{R}^n$ y sea $z^0 = x^0$.
- En la iteración k tenemos x^k y z^k y calculamos:

$$\begin{aligned} z^{k+1} &\leftarrow z^k - \frac{1}{\theta_k L} \nabla f(\theta_k z^k + (1 - \theta_k)x^k). \\ x^{k+1} &\leftarrow (1 - \theta_k)x^k + \theta_k z^{k+1}. \end{aligned}$$

donde θ_k es una sucesión convergente a 0 que se elige de una manera “adecuada”.

- Tratemos de “interpretar” cómo funciona...

Aceleración

- La propiedad de aceleración se refleja en el siguiente resultado:

Teorema

Sea f convexa, y con $\nabla f(x)$ L -Lipschitz. Supongamos que $\theta_k = \frac{2}{2+k}$. Después de k iteraciones se tiene:

$$\min_{0 \leq i \leq k} f(x^i) \leq f(x^*) + \frac{2L\|x^0 - x^*\|_2}{(k+1)^2}$$

- El resultado se garantiza **para el mejor valor encontrado hasta la iteración k** ya que no necesariamente se tiene monotonía de las iteraciones.
- ¿Cuántas iteraciones necesito para alcanzar error ϵ ?

¿Y si f realmente tiene muy buenas propiedades?

- A f sólo le hemos pedido, hasta ahora, ser convexa y que ∇f tenga la propiedad de Lipschitz.
- ¡Eso es pedir muy poco!
- ¡Si pedimos a f *propiedades fuertes de convexidad*, obtendremos que el método del gradiente, con un paso igual a $1/L$ tiene convergencia lineal!
- Es decir, para llegar a una solución ϵ -aproximada, bastan

$$O\left(\log \frac{1}{\epsilon}\right)$$

iteraciones.

- El detalle de esto quedará en un video complementario.