

Métodos para problema no diferenciables

- El verdadero poder de los Métodos de Primer Orden se ve cuando se enfrentan problemas con enorme cantidad de variables...
- Pero en donde, además, “no podemos calcular derivadas”

Motivación

- Una investigación médica ha estudiado a un total de m pacientes que sufren una enfermedad.
- El “grado” de la enfermedad está registrado en $b_1, \dots, b_m$, observaciones de una variable médica.
- Por otro lado, para esos pacientes se dispone de mediciones del grado de “expresión” de una gran cantidad de genes, n en total.



OPEN

Gene Expression Predicts Histological Severity and Reveals Distinct Molecular Profiles of Nonalcoholic Fatty Liver Disease

Received: 11 December 2018
Accepted: 29 July 2019
Published online: 29 August 2019

Stephen A. Hoang¹, Abdul Oseini², Ryan E. Feaver¹, Banumathi K. Cole¹, Amon Asgharpour³, Robert Vincent², Mohammad Siddiqui², Mark J. Lawson¹, Nathan C. Day¹, Justin M. Taylor¹, Brian R. Wamhoff¹, Faridoddin Mirshahi², Melissa J. Contos², Michael Idowu² & Arun J. Sanyal²

The heterogeneity of biological processes driving the severity of nonalcoholic fatty liver disease (NAFLD) as reflected in the transcriptome and the relationship between the pathways involved are not well established. Well-defined associations between gene expression profiles and disease progression would benefit efforts to develop novel therapies and to understand disease heterogeneity. We analyzed hepatic gene expression in controls and a cohort with the full histological spectrum of NAFLD. Protein-protein interaction and gene set variation analysis revealed distinct sets of coordinately regulated genes and pathways whose expression progressively change over the course of the disease. The progressive nature of these changes enabled us to develop a framework for calculating a disease progression score for individual genes. We show that, in aggregate, these scores correlate strongly with histological measures of disease progression and can thus themselves serve as a proxy for severity. Furthermore, we demonstrate that the expression levels of a small number of genes (~20) can be used to infer disease severity. Finally, we show that patient subgroups can be distinguished by the relative distribution of gene-level scores in specific gene sets. While future work is required to identify the specific disease characteristics that correspond to patient clusters identified on this basis, this work provides a general framework for the use of high-content molecular profiling to identify NAFLD patient subgroups.

Motivación

- Supongamos que a_{ij} es el “grado” de expresión del gen j en el paciente i .
- Queremos saber qué genes mejor explican la enfermedad.
- Se plantea, nuevamente, un “modelo lineal”, donde x_j es el “peso” del gen j :

$$b_i = \sum_{j=1}^n a_{ij}x_j, i = 1, \dots, m$$

- El problema acá es que la cantidad de genes es enorme, $n > m$, y queremos identificar los genes que “mejor” explican...

Motivación

- Tenemos, nuevamente, un problema de regresión de la forma $Ax = b$, pero donde hay más incógnitas que ecuaciones ($m < n$).
- Luego, hay infinitas soluciones...
- Entonces, ¿cuál de todas es la solución “correcta”?

- Queremos identificar **unos pocos** factores explicativos.

- Es decir, queremos una solución con la menor cantidad de componentes $x_j \neq 0$

- Esto lleva al problema:

$$\begin{array}{ll} \text{mín} & \text{card}\{j : x_j \neq 0\} \\ \text{s.a.} & Ax = b \end{array}$$

- Esto es un problema de naturaleza combinatorial, pero se puede modelar mediante programación entera...

Motivación

- Pero n puede ser “miles” (o más) y el problema entero puede ser intratable.

- Consideremos la siguiente idea: aproximar $\text{card}\{j : x_j \neq 0\}$ por $\|x\|_1$

$$\|x\|_1 = \sum_{j=1}^n |x_j|$$

- Entonces, el problema lo cambiamos a:

$$\begin{array}{ll} \text{mín} & \|x\|_1 = \sum_{j=1}^n |x_j| \\ \text{s.a.} & Ax = b \end{array}$$

El problema de “Regularización L1”

- Pero si n son “millones”, ese problema aún es difícil.
- Una forma indirecta de aproximadamente forzar lo mismo es resolver el siguiente problema no restringido:

$$\min_{x \in \mathbb{R}^n} \tau \|x\|_1 + \|Ax - b\|_2^2$$

- donde $\tau > 0$ es un parámetro de “balance” entre dos objetivos...
- Entendamos este problema...

En resumen:

- Queremos resolver un sistema de ecuaciones $Ax = b$ pero donde hay más incógnitas que ecuaciones...
- Entonces, se plantea encontrar una solución que tenga muchas componentes $= 0$:

$$\begin{array}{ll} \text{mín} & \text{card}\{j : x_j \neq 0\} \\ \text{s.a.} & Ax = b \end{array}$$

- Este problema es difícil de abordar en forma exacta y se propone usar $\|x\|_1$ como aproximación a $\text{card}\{j : x_j \neq 0\}$
- Y esto lleva a formular un problema **aproximado** para lograr eso:

$$\text{mín}_{x \in \mathbb{R}^n} \tau \|x\|_1 + \|Ax - b\|_2^2$$

- donde $\tau > 0$ es un parámetro de “balance” entre dos objetivos.
- El término $\|x\|_1$ es una “regularización”.

El problema de “Regularización L1”

- Hacer regresión de la forma que lo estamos planteando se conoce como la técnica LASSO (Least Absolute Shrinkage and Selection Operator)
- Problemas con la misma estructura que el anterior aparecen en:
 - ▶ Reconstrucción de imágenes (Compressed Sensing)
 - ▶ Reconstrucción de información (Sistemas recomendadores y Componentes Principales)
 - ▶ En “Machine Learning”, en general
 - ▶ Y otros temas de “Ciencia de Datos”

El problema de “Regularización L1”

- Tenemos que resolver, entonces, el problema:

$$\min_{x \in \mathbb{R}^n} \tau \|x\|_1 + \|Ax - b\|_2^2$$

- ¿Qué método podríamos usar?
- Pero hay un problema...

Paréntesis: subdiferenciabilidad

- Necesitamos definir un concepto que juega el mismo papel que las derivadas.

Definición

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Un vector $h \in \mathbb{R}^n$ es un **subgradiente** de f en x si

$$f(y) \geq f(x) + h^T(y - x), \forall y$$

- Estamos rescatando la propiedad del hiperplano por abajo.

Definición

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. El conjunto

$$\partial f(x) = \{h \in \mathbb{R}^n : f(y) \geq f(x) + h^T(y - x), \forall y\}$$

se llama **subdiferencial** de f en x .

- ¿Qué pasa si la función **es** diferenciable en x ?
- ¿Cómo es la condición de optimalidad “de primer orden”?

El Método del Subgradiente

- **Método Simple de Primer Orden no diferenciable:**

```
Data: Sea  $x^0 \in \mathbb{R}^n, k = 0, -d^0 \in \partial f(x^0), \epsilon > 0$ .  
while Criterio de parada no se satisface do  
     $x^{k+1} = x^k + \lambda^k d^k;$   
     $-d^{k+1} \in \partial f(x^{k+1});$   
     $k = k + 1;$   
end
```

- Este es el método más básico basado en subgradientes...
- Pero para implementarlo necesitamos poder calcular subgradientes.
- Y el paso λ_k debe ser elegido correctamente.

Ejemplo

- Usaremos el problema:

$$\min_{x \in \mathbb{R}^n} \tau \|x\|_1 + \|Ax - b\|_2^2$$

con una matriz de 50×300 .

- Veamos cómo funcionan el Método de Subgradiente en algunos casos.
- Vamos a calcular un subgradiente
- Después correremos casos ajustando τ , viendo la solución.
- Recordar: buscamos una solución con “pocas” coordenadas $\neq 0$.

Convergencia del Método del Subgradiente

- El análisis de convergencia es más complejo y requiere elementos adicionales.
- Vamos a tener que asumir algo adicional sobre el problema:
- Primero, supondremos que se conoce un $R > 0$ **tal que f cumple una propiedad de Lipschitz con constante L (es L -Lipschitz) en una vecindad de radio R de x^*** , es decir:

$$|f(x) - f(y)| \leq L\|x - y\|, \quad \forall x, y : \|x - x^*\| \leq R, \|y - x^*\| \leq R$$

- (notemos que esto no es lo mismo que en el caso del método con gradientes)
- Supongamos, además, que podemos elegir el punto inicial x^0 tal que $\|x^* - x^0\| \leq R$.

Convergencia del Método del Subgradiente

- Se puede demostrar que si se elige:

$$\lambda_k = \frac{a}{\sqrt{k+1}}$$

donde $a > 0$ es una constante elegida “juiciosamente”, entonces:

$$\min_{i=1,\dots,k} f(x^i) \leq f(x^*) + \frac{R^2 + a \ln(k+1)}{2a\sqrt{k+1}}$$

- Con otras reglas de paso de avance más complejas se puede probar que

$$\min_{i=1,\dots,k} f(x^i) \leq f(x^*) + \frac{RL}{\sqrt{k+1}}$$

- ¿Cuántas iteraciones se necesitan para alcanzar error ϵ ?

Convergencia del Método del Subgradiente

- Este resultado corresponde, de hecho, al mejor comportamiento que puede tener el Método del Subgradiente simple (resultado de A. Nemirovski).
- El manejo de funciones no diferenciables es más complejo pero muchos problemas reales presentan función objetivo no diferenciable
- (LASSO es sólo un ejemplo)
- El método del subgradiente puede ser acelerado, el algoritmo que logra eso se llama FISTA y lo revisaremos a continuación...