

Ejemplo: compra de acciones

- Consideremos un horizonte de T periodos en los que podemos comprar acciones.
- Disponemos de un capital total K sobre todo el horizonte.
- Sea p_t el precio de la acción en el periodo t .
- Sea e_t el rendimiento que la acción tendrá al final del horizonte, si se compra en el periodo t .
- La pregunta es cuántas acciones comprar en cada periodo para maximizar el rendimiento al final del horizonte.
- Sea x_t la cantidad a comprar.
- El problema base es:

$$\begin{aligned} \text{máx} \quad & \sum_{t=1}^T e_t x_t \\ \text{s.a.} \quad & \sum_{t=1}^T p_t x_t \leq K \\ & x_t \geq 0, \text{ entero}, t = 1, \dots, T. \end{aligned}$$

Ejemplo: compra de acciones

- El problema anterior sería un problema de mochila de no ser por el hecho que queremos incorporar la evolución del precio.
- Esto le da una dinámica natural al problema.
- El precio de un periodo a otro se ve modificado según lo que se haya transado.
- Supongamos que $p_{t+1} = p_t + \alpha_t x_t$, donde α_t es “conocido”.
- El problema ahora es:

$$\begin{aligned} & \text{máx} \quad \left(\sum_{t=1}^T e_t x_t \right) \\ & s.a. \quad \sum_{t=1}^T p_t x_t \leq K \\ & \quad p_{t+1} = p_t + \alpha_t x_t, t = 1, \dots, T-1 \\ & \quad x_t \geq 0, \text{ entero}, t = 1, \dots, T. \end{aligned}$$

(y asumimos como dato un p_1 inicial).

- Esto se puede llevar a una formulación de PD.

El caso estocástico

- La PD se hace especialmente importante cuando se consideran problemas bajo incertidumbre, ya que en muchas aplicaciones hay elementos estocásticos que afectan el comportamiento del sistema.
- Formalmente, sea $w_k \in W_k$ un vector de parámetros aleatorio.

- La función de transición se ve afectada por la aleatoriedad y es, en este caso:

$$s_{k+1} = f_k(s_k, x_k, w_k)$$

- La aleatoriedad puede afectar también a los costos g_k y a las restricciones.
- Se define, entonces, la función de valor del problema, escrita en forma dinámica (Ecuación de Bellman):

$$J_k(s_k) = \min_{x_k \in U_k(s_k, w_k)} \mathbb{E} \{g_k(s_k, x_k, w_k) + J_{k+1}(f_k(s_k, x_k, w_k))\}$$

donde $\mathbb{E}$ denota valor esperado...

El caso estocástico

- Un caso muy relevante es el siguiente:
- El sistema puede estar en un estado $i \in \{1, \dots, N\}$ y el pasar de un estado a otro de una etapa a la siguiente, depende de una probabilidad de transición y de la acción que se tome en la etapa:

$$p^k(x_k, i, j) = \text{Prob}(s_{k+1} = j / s_k = i, \text{acción} = x_k)$$

- Un sistema de este tipo se dice “Markoviano”

El caso estocástico

- Supongamos que los costos de la etapa, g_k , no tienen incertidumbre una vez definido el estado y la acción.
- Entonces, el problema puede escribirse, en forma dinámica:

$$J_k(i) = \min_{x_k \in U_k(i)} \{g_k(i, x_k) + \mathbb{E}(J_{k+1}(i))\}$$

- Que es lo mismo que:

$$J_k(i) = \min_{x_k \in U_k(i)} \left\{ g_k(i, x_k) + \sum_{j=1}^N p^k(x_k, i, j) J_{k+1}(j) \right\}$$

- y nos interesa $J_1(i_0)$, donde i_0 es el estado inicial del sistema.
- Este problema se conoce como un “Problema de Decisión Markoviano” (MDP, Markovian Decision Process).

El caso estocástico

- Muchas veces las decisiones, o políticas, son además discretas...
- y esto conecta el problema con la Programación Entera.
- La PD Estocástica tiene amplias aplicaciones:
 - ▶ Finanzas
 - ▶ “Pricing” y “Revenue Management”
 - ▶ Planificación bajo incertidumbre en, por ejemplo, el sector eléctrico.
 - ▶ Decisiones dinámicas en logística.
 - ▶ Y muchas otras...
- Hoy el tema de PD se estudia en conexión a la retroalimentación en tiempo real, o mediante simulación computacional o estimaciones basadas en herramientas de Machine Learning, de las decisiones con los datos del sistema.

Ejemplo: Un MDP en salud

- Un área de un hospital dispone de un cierto número de camas, digamos $P = 9$.
- Llegan pacientes que pueden pertenecer a alguna de 4 categorías: A, B, C, D, en orden de “gravedad”.
- Cada paciente, si es admitido, estará en el hospital un tiempo aleatorio (LOS, “length of stay”).
- El problema diario de decisión, que enfrenta el hospital, es a quién admitir:
 - Por ejemplo, llegan 3 pacientes A, 3 pacientes B y 3 pacientes C. ¿A quién admito?
 - (No admitir a alguien implica redirigirlo a otro lugar, con el consiguiente costo y problemas, siendo más complejo redirigir a los A que a los B y C)

Ejemplo: Un MDP en salud

- El estado del sistema corresponde al número de pacientes A, B y C actualmente hospitalizados.
 - La decisión, o política, es cuántos admitir de los que llegan.
 - Dado el estado del sistema, y las admisiones, más datos probabilísticos de duración de estadías (LOS), pueden construirse las transiciones posibles de un día al siguiente, y sus probabilidades.
 - ¡El problema se puede modelar como un MDP!
-
- Pero ahora viene lo complicado:
 - En situaciones reales, la cantidad de estados y políticas puede generar una combinación total de miles de millones de transiciones y el problema es imposible de resolver...
 - Esto se llama la **maldición de la dimensión**, o explosión dimensional (“curse of dimensionality”).

Ejemplo: Un MDP en salud

- En PD hay técnicas que permiten simplificar estados y otras cosas: Programación Dinámica Aproximada.
- Desarrollos de épocas más recientes avanzan hacia técnicas que permitan estimar el costo del futuro:
- Recordemos la Ecuación de Bellman en este caso:

$$J_k(i) = \min_{x_k \in U_k(i)} \left\{ g_k(i, x_k) + \sum_{j=1}^N p^k(x_k, i, j) J_{k+1}(j) \right\}$$

- Esto se transforma en:

$$J_k(i) = \min_{x_k \in U_k(i)} \{ g_k(i, x_k) + Q(x_k, i) \}$$

donde $Q(x_k, i)$ es una **aproximación** a $\sum_{j=1}^N p^k(x_k, i, j) J_{k+1}(j)$.

Ejemplo: Un MDP en salud

- ¿Cómo estimamos $Q(x_k, i)$?
- Por ejemplo: usando Simulación Computacional en conjunto con las técnicas de Programación Dinámica:
- En vez de conocer a priori las probabilidades de transición, se simula el sistema y se itera “al estilo programación dinámica” para “aprender” el comportamiento del sistema y aproximar una política óptima.
- Se puede también usar un método de Redes Neuronales para “aprender” Q , y eso se incorpora en el modelo (Q-learning).
- Eso hace el *Reinforcement Learning*, metodología que se ha hecho clave en la Inteligencia Artificial moderna...