

Cómo resolver el dual:

- El dual es maximizar la función dual
- La función dual, $\theta(\lambda)$, es una función cóncava
- El problema dual busca maximizar una función cóncava...
- (O, minimizar una función convexa, que es el negativo de la original)
- Pero la función dual es no diferenciable...
- Vamos a usar el Método del Subgradiente para minimizar $f(\theta) = -\theta(\lambda)$

Cómo resolver el dual:

- **El método de subgradiente para el problema dual:**

Data: Sea $\lambda^0 \in \mathbb{R}^m$, $k = 0$, $h^0 = -u$, donde $u \in \partial f(\lambda^0)$.

while *Criterio de parada no se satisface* **do**

$\lambda^{k+1} = \lambda^k + t_k h^k$ (cuidado si $\lambda \geq 0$);
 $h^k = -u$, donde $u \in \partial(f(\lambda^k))$;
 $k = k + 1$;

end

- ¿De dónde sacamos un subgradiente de $f(\lambda^k) = -\theta(\lambda^k)$ (que es convexa)?
- ¿Cuánto debe ser el paso t_k ?
- ¿Y el criterio de parada?
- ¿Y eso del cuidado si se debe tener $\lambda \geq 0$?

Cómo resolver el dual:

- Obtener un subgradiente, afortunadamente, no es difícil.
- Supongamos que estamos en la iteración k del método:

Proposición

Dado λ^k , sea $\bar{x}^k$ solución óptima del problema que calcula $\theta(\lambda^k)$ para la iteración k . Sea $h_i = \alpha_i^T \bar{x}^k - b_i$. Entonces, $h \in \partial(-\theta(\lambda^k))$.

- Es decir, el subgradiente sale de las holguras de las restricciones relajadas.
- Ya veremos cómo se determina el paso de avance...
- El criterio de parada está relacionado con la determinación del paso.

Cómo resolver el dual:

- Supongamos que el problema requiere que $\lambda \geq 0$.
- Entonces, el avance:

$$\lambda^{k+1} = \lambda^k + t_k h^k$$

podría producir componentes negativas.

- Esto se maneja proyectando:

$$\lambda_i^{k+1} = \max\{0, \lambda_i^k + t_k h_i^k\}$$

Cómo resolver el dual:

- Una pregunta importante es el paso a elegir.
- Esto es método de subgradiente y podríamos usar algo como $1/\sqrt{k}$, donde k es el número de iteración...
- En Relajación Lagrangeana se hace algo diferente:
- Sea U^k una cota superior a z^* en la iteración k (luego discutiremos cómo obtenerla).
- Sea h^k la dirección de avance en la iteración k .
- Sea $\theta(\lambda^k)$ el valor actual de la función dual en la iteración k
- Se propone el siguiente paso en la iteración k :

$$t_k = \rho \times \frac{U^k - \theta(\lambda^k)}{\|h^k\|_2^2}$$

donde $\rho \in [1/2, 2]$ es un factor de control que se ajusta “de forma criteriosa”

La importancia de la cota superior

- ¿De dónde sacamos la cota superior?
- Un desarrollo importante en este tema es estimar un U^k mediante una **Heurística Lagrangeana**:
 - ▶ En la iteración k resolvemos $\theta(\lambda^k)$ y obtenemos una solución $\bar{x}^k$.
 - ▶ Esta solución NO CUMPLE las restricciones relajadas.
 - ▶ Idea: aplicar algún procedimiento computacional a $\bar{x}^k$ para transformarlo en una nueva solución $\tilde{x}^k$ que sí cumpla las restricciones relajadas (factible al problema original).
 - ▶ Entonces, podemos tomar $U^k = f(\tilde{x}^k)$.
- Con esto, en la iteración k se cumple:

$$\theta(\lambda^k) \leq z^* \leq U^k$$

y esto sirve de criterio de parada...

Ejemplo computacional

- Revisaremos ahora un ejemplo completo de implementación de Relajación Lagrangeana aplicado a un problema de inspiración real.
- **Problema de localización de instalaciones y asignación de clientes:**
- Hay m posibles puntos donde se pueden instalar centros de distribución
- Hay n clientes que deben ser atendidos desde un único centro de distribución.
- Sea f_i el costo de abrir un centro en i .
- Sea c_{ij} el costo de asignar al cliente j al centro en i .
- Pregunta: ¿en qué lugares abrir centros de distribución y a cuáles asignar los clientes?

Un problema difícil

- Esto se modela con dos variables:
- y_i , binaria que indica si se abre el centro en i .
- x_{ij} , binaria que indica si el cliente j se asigna al centro i .
- El modelo típico es el siguiente:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} = 1, & j = 1, \dots, n \end{aligned} \tag{1}$$

$$\begin{aligned} & \sum_{j=1}^m x_{ij} \leq n y_i, & i = 1, \dots, m \end{aligned} \tag{2}$$
$$y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n$$

- Este es un problema conocido como difícil (es NP-completo).
- Mostremos primero una instancia de este problema y resolvámoslo en Gurobi-Python.
- Mostraremos el óptimo y también el óptimo de la relajación lineal.

La Relajación Lagrangeana

- Este es nuestro modelo:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s.a.} \quad & \sum_{i=1}^m x_{ij} = 1, & j = 1, \dots, n & \quad (1) \end{aligned}$$

$$\sum_{j=1}^m x_{ij} \leq n y_i, \quad i = 1, \dots, m \quad (2)$$

$$y_i, x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n$$

- Construiremos un dual relajando las restricciones (1).

La Relajación Lagrangeana

- El problema relajado (la función dual) es:

$$\begin{aligned} \theta(\mu) = \min \quad & \sum_{i=1}^m f_i y_i + \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} + \sum_{j=1}^n \mu_j \left(\sum_{i=1}^m x_{ij} - 1 \right) \\ \text{s.a.} \quad & \sum_{j=1}^m x_{ij} \leq n y_i, & i = 1, \dots, m \\ & y_i, x_{ij} \in \{0, 1\} & i = 1, \dots, m; j = 1, \dots, n \end{aligned} \quad (2)$$

- Y el dual a resolver:

$$\max_{\mu} \theta(\mu)$$

- Mostraremos una implementación en Python
- También comentaremos algunos detalles....

El ejemplo computacional

- El código que mostraré hace lo siguiente:
 - ▶ Primero resuelve el problema original completo y su relajación lineal
 - ▶ Usa las variables duales del relajado lineal para los valores iniciales de μ .
 - ▶ Luego ejecuta la Relajación Lagrangeana una cierta cantidad de iteraciones.
- También mostraremos cómo implementar una heurística lagrangiana para la cota superior U^k .

El ejemplo computacional

- Para el paso de la iteración k usaremos:

$$\rho \times \frac{U^k - \theta(\lambda^k)}{\|h^k\|_2^2}$$

donde $\rho \in [1/2, 2]$, y donde:

- Recordemos: U^k debe ser una cota superior a z^* , es decir, $U^k \geq z^*$.
- h^k la dirección de avance en la iteración k .
- La pregunta es de dónde sacamos U^k ...
- Primero vamos a implementar esto haciendo “trampa”:
- En esta ocasión, conocemos el óptimo y podemos tomar $U^k = z^*$.
- También podemos tomar un valor más grande.
- Veamos qué resulta...

Obteniendo una cota superior

- En un problema real no conocemos z^* y no podemos hacer trampa.
- Si tuviéramos una solución factible al problema original, $(\bar{y}, \bar{x})$, podríamos poner U^k igual al valor de esa solución.
- Esto la vamos a hacer mediante una **Heurística Lagrangeana**:
- En la iteración k resolvemos $\theta(\mu^k)$ y obtenemos una solución (y^k, x^k) .
- Esta solución NO cumple las restricciones

$$\sum_{i=1}^m x_{ij} = 1, \quad j = 1, \dots, n$$

- Esto significa que pueden haber:
 - ▶ Clientes asignados más de una vez
 - ▶ Clientes no asignados
- Veamos qué pasa en la solución del problema...

Obteniendo una cota superior

- Pensemos: ¿cómo podemos, a partir de (y^k, x^k) , construir una solución factible al problema original?

Comentarios

- Esto es hacer Relajación Lagrangiana...
- La via del dual provee una buena forma de aproximarse a una solución óptima del problema.
- Pero, es muy importante elegir correctamente el dual a usar.
- Es decir, elegir “bien” las restricciones a relajar.
- De hecho, muchas veces, aún habiendo “gap” es posible obtener heurísticamente una solución primal factible.
- Las heurísticas son muy importantes en optimización y las estudiaremos pronto.