

Elementos (muy) básicos de Optimización Cónica

- El siguiente es un problema “lineal cónico” (en forma estándar):

$$\begin{array}{ll}\text{mín} & c^T x \\ \text{s.a.} & Ax = b \\ & x \in K\end{array}$$

donde K es un cono convexo.

- Recordemos: K es cono convexo si es convexo y $x \in K \Rightarrow \lambda x \in K, \lambda \geq 0$

Elementos de Optimización Cónica

- Ejemplos de conos convexos:
- $\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x \geq 0\}$
- $Q^{n+1} = \{(x, t) : x \in \mathbb{R}^n, t \in \mathbb{R} \text{ y } \|x\|_2 \leq t\}$, el Cono de Segundo Orden o Cono de Lorenz en $n + 1$ dimensiones.
- $S_+^{n \times n} = \{X \in \mathbb{R}^{n \times n} : X \text{ es simétrica y semidefinida positiva}\}.$
- Para cada uno de esos conos hay una función de barrera con buenas propiedades.
- Pero, lo interesante es que hay problemas relevantes que se pueden formatear como problemas de Optimización Cónica.

Ejemplos de problemas cónicos

- Tenemos el poliedro $P = \{x \in \mathbb{R}^n : Ax \leq b\}$
- Sea $u \in \mathbb{R}^n$ dado.
- Queremos encontrar el punto en P más cercano a u .

- Esto se hace resolviendo:

$$\begin{array}{ll} \text{mín} & \|x - u\|_2 \\ \text{s.a.} & Ax \leq b \end{array}$$

Ejemplos de problemas cónicos

- Y lo anterior es equivalente a:

$$\begin{array}{ll}\text{mín} & t \\ \text{s.a.} & Ax \leq b \\ & \|x - u\|_2 \leq t\end{array}$$

- que equivale a:

$$\begin{array}{ll}\text{mín} & t \\ \text{s.a.} & Ax \leq b \\ & v = x - u \\ & \|v\|_2 \leq t\end{array}$$

- Que es lo mismo que:

$$\begin{array}{ll}\text{mín} & t \\ \text{s.a.} & Ax \leq b \\ & v = x - u \\ & (v, t) \in Q^{n+1}\end{array}$$

- Y este es un problema lineal con restricciones cónicas: restricciones de Cono de Segundo Orden.
Se conoce como SOCP: "Second Order Cone Problem"

Ejemplos de problemas cónicos

- El problema anterior se resuelve con un algoritmo de punto interior usando la siguiente función de barrera para el cono:

$$\Phi(x, t) = -\log(t^2 - \|v\|_2^2)$$

- Y el problema penalizado es:

$$\begin{aligned} \text{mín} \quad & t - \mu \left(\log(t^2 - \|v\|_2^2) + \sum_{i=1}^m \log(b_i - \alpha_i^T x) \right) \\ \text{s.a.} \quad & v = x - u \end{aligned}$$

donde $\alpha_1, \dots, \alpha_m$ son las filas de A .

- Gurobi y otros pueden resolver un problema de esta forma, al igual que otros sistemas de software que implementan punto interior para problemas cónicos.

Otro ejemplo

- Un problema importante en Machine Learning es el de poder distinguir comportamientos de observaciones.
- Por ejemplo, supongamos que en un hospital hemos estudiado a personas que llegan al servicio de urgencias y que tienen una serie de síntomas y características, que se miden al ingresar (como “Triage” se conoce esto).
- Algunas de esas personas han sido atendidas y dadas de alta inmediatamente después, pero otras tuvieron que ser admitidas al hospital después de urgencia.
- Nos interesa anticipar si alguien tendrá que ser hospitalizado, para poder preparar unidades médicas, camas, etc.
- Objetivo: a partir de la información anterior, inferir una “fórmula” que permita anticipar si los nuevos pacientes que llegan a urgencia y sean posteriormente evaluados, requerirán o no hospitalización.

Otro ejemplo

- Más en específico, tenemos n variables que puedo observar y medir.
- Hay una propiedad que quiero discriminar (por ejemplo, “alta” u “hospitalización”).
- Tenemos r observaciones de esas n variables y que corresponden a “alta”.
- Tenemos q observaciones de esas n variables y que corresponden a “hospitalización”.
- Sean $u^1, \dots, u^r$ vectores en $\mathbb{R}^n$ que corresponden a “alta”.
- Sean $v^1, \dots, v^q$ vectores en $\mathbb{R}^n$ que corresponden a “hospitalización”.
- Y supongamos que podemos visualizarlos en el espacio de n dimensiones...

Otro ejemplo

- El objetivo, entonces, es encontrar un hiperplano que separe ambas nubes de puntos en forma lo más “equidistante” posible.
- Recordemos: un hiperplano tiene esta forma:

$$H_{\alpha,\beta} = \{x \in \mathbb{R}^n : \alpha^T x = \beta\}$$

donde $\alpha \in \mathbb{R}^n$, $\beta \in \mathbb{R}$.

- Necesitamos también la distancia de un punto al hiperplano.
- Si $\bar{x} \in \mathbb{R}^n$, la distancia hasta el hiperplano es:

$$\text{dist}(\bar{x}, H_{\alpha,\beta}) = \frac{|\alpha^T \bar{x} - \beta|}{\|\alpha\|_2}$$

Otro ejemplo

- Entonces, buscamos un hiperplano $H_{\alpha,\beta}$ que maximice la menor distancia a ambas nubes de puntos.
- Es decir, queremos resolver el siguiente problema (α y β son las incógnitas):

$$\begin{aligned} \text{máx} \quad & \gamma \\ \text{s.a.} \quad & \text{dist}(u^i, H_{\alpha,\beta}) \geq \gamma, \quad i = 1, \dots, r \\ & \text{dist}(v^j, H_{\alpha,\beta}) \geq \gamma, \quad j = 1, \dots, q \\ & \alpha \in \mathbb{R}^n, \beta \in \mathbb{R} \end{aligned}$$

- Que equivale a:

$$\begin{aligned} \text{máx} \quad & \gamma \\ \text{s.a.} \quad & \frac{|\alpha^T u^i - \beta|}{\|\alpha\|_2} \geq \gamma, \quad i = 1, \dots, r \\ & \frac{|\alpha^T v^j - \beta|}{\|\alpha\|_2} \geq \gamma, \quad j = 1, \dots, q \\ & \alpha \in \mathbb{R}^n, \beta \in \mathbb{R} \end{aligned}$$

- Podemos imponer $\|\alpha\|_2 = 1$ para normalizar...

Otro ejemplo

- Con esto, el problema es:

$$\begin{array}{ll} \text{máx} & \gamma \\ \text{s.a.} & \alpha^T u^i - \beta \geq \gamma, \quad i = 1, \dots, r \end{array}$$

$$\beta - \alpha^T v^j \geq \gamma, \quad j = 1, \dots, q$$

$$\|\alpha\|_2 = 1$$

- (hemos impuesto arbitrariamente un “lado” al hiperplano)
- Este problema NO es convexo, debido a la restricción $\|\alpha\|_2 = 1$.
- Pero se puede hacer una transformación “ingeniosa”: si dividimos por γ y reemplazamos

$$z = \frac{\alpha}{\gamma}, \quad \delta = \frac{\beta}{\gamma}$$

obtenemos un nuevo problema...

Otro ejemplo

- El problema equivalente es:

$$\text{mín} \quad \|z\|_2$$

$$s.a. \quad z^T u^i - \delta \geq 1, \quad i = 1, \dots, r$$

$$\delta - z^T v^j \geq 1, \quad j = 1, \dots, q$$

$$z \in \mathbb{R}^n, \delta \in \mathbb{R}$$

- Y este problema ¡SI es convexo!
- Y puede adaptarse al formato de Cono de Segundo Orden

Otro ejemplo

- El problema se transforma en:

$$\begin{array}{ll}\text{mín} & t \\ \text{s.a.} & z^T u^i - \delta \geq 1, \quad i = 1, \dots, r \\ & \delta - z^T v^j \geq 1, \quad j = 1, \dots, q \\ & \|z\|_2 \leq t \\ & z \in \mathbb{R}^n, \delta \in \mathbb{R}, t \geq 0\end{array}$$

- Que es lo mismo que:

$$\begin{array}{ll}\text{mín} & t \\ \text{s.a.} & z^T u^i - \delta \geq 1, \quad i = 1, \dots, r \\ & \delta - z^T v^j \geq 1, \quad j = 1, \dots, q \\ & (z, t) \in Q^{n+1} \\ & z \in \mathbb{R}^n, \delta \in \mathbb{R}, t \geq 0\end{array}$$

donde hemos hecho explícita la restricción cónica.

- Este es el problema de “**Support Vector Machine**” (**SVM**), de gran importancia en Machine Learning, y que habíamos ya mencionado.
- Se usa ampliamente en análisis de datos de gran tamaño.

Otro ejemplo: Cono de matrices semidefinidas positivas

- Tengo m puntos en $\mathbb{R}^n$, $c^1, \dots, c^m$.
- Estos pueden ser el resultado de muchas observaciones de n variables que interesa estudiar.
- Queremos saber si hay “tendencias” en los datos: encontrar lo que se conoce como las “Componentes Principales”.
- Entonces, el problema que queremos resolver es encontrar un elipsoide de mínimo volumen que contenga todos los puntos.
- Elipsoide:

$$Ell(R, z) = \{x \in \mathbb{R}^n : (x - z)^T R (x - z) \leq 1\}$$

queda determinada por el centro z y la matriz R , que tiene que ser **simétrica y definida positiva**.

Otro ejemplo: Cono de matrices s.d.p

- El problema es:

$$\begin{array}{ll} \min_{(R,z)} & Vol(Ell(R, z)) \\ \text{s.a.} & c^i \in Ell(R, z), \quad i = 1, \dots, m \\ & R \in S_+^{n \times n}, z \in \mathbb{R}^n \end{array}$$

- Que es lo mismo que:

$$\begin{array}{ll} \min_{(R,z)} & Vol(Ell(R, z)) \\ \text{s.a.} & (c^i - z)^T R (c^i - z) \leq 1, \quad i = 1, \dots, m \\ & R \in S_+^{n \times n}, z \in \mathbb{R}^n \end{array}$$

- Por otro lado,

$$Vol(Ell(R, z)) = \frac{\pi^{n/2}}{\Gamma\left(\frac{n}{2} + 1\right)} \det(R)^{-1/2}$$

- Entonces, minimizar $Vol(Ell(R, z))$ es lo mismo que minimizar $-\log(\det(R))$ y esa función es fácil de manejar (aunque no lo crean).

Otro ejemplo: Cono de matrices s.d.p

- El problema es, entonces:

$$\begin{aligned} \min_{(R,z)} \quad & -\log(\det(R)) \\ \text{s.a.} \quad & (c^i - z)^T R (c^i - z) \leq 1, \quad i = 1, \dots, m \\ & R \in S_+^{n \times n}, z \in \mathbb{R}^n \end{aligned}$$

- (las restricciones $(c^i - z)^T R (c^i - z) \leq 1$ se pueden transformar en cónicas más lineales)
- Esto es lo que se conoce como un problema de Programación Semi-definida o SDP (Semi-definite Programming)
- ¡Puede ser abordado con algoritmos de punto interior!

Otro ejemplo: Cono de matrices s.d.p

- La pregunta acá es cuál es la barrera que se debe usar para el cono $S_+^{n \times n}$ de matrices simétricas y definidas positivas.
- Sean $\lambda_1, \dots, \lambda_n$ los valores propios de R .
- R es d.p. si y sólo si $\lambda_i > 0, i = 1, \dots, n$.
- Entonces, la barrera “natural” es:

$$\Phi(R) = - \sum_{i=1}^n \log \lambda_i = - \log \det(R)$$

- Se puede mostrar que esta función Φ es estrictamente convexa y se conocen su gradiente y Hessiano!

Palabras al Cierre

- Hemos presentado las ideas principales de los Algoritmos de Punto Interior en Optimización.
- Son una herramienta algorítmica muy poderosa...
- Especialmente por su potencial en el caso no lineal.
- Problemas que antes no se podían abordar, ahora pueden ser resueltos en forma eficiente.