

- La clase pasada:
- Introdujimos la necesidad de considerar incertidumbre al resolver un problema de optimización.
- Ilustramos la Simulación de Montecarlo pero también mostramos sus debilidades.
- Mostramos el enfoque de Restricciones Probabilísticas, cómo se reduce a SOCP (en el caso Normal) y vimos un ejemplo computacional.
- Hoy estudiaremos cómo incorporar los efectos de la incertidumbre según las decisiones que tomemos.

Modelando la Dinámica de la Incertidumbre

- Muchas veces, la forma en que se toman las decisiones es frente a un evento incierto que ocurrirá en algún futuro.
- En la realidad las cosas suelen pasar en dos etapas (al menos):
 - ▶ En una **primera etapa**, se toman decisiones específicas (por ejemplo, decidimos la siembra).
 - ▶ Después, **en una segunda etapa**, se manifiesta el fenómeno aleatorio (los rendimientos de los cultivos, por ejemplo).
 - ▶ Recién ahí se ve qué consecuencias tuvo la decisión.
 - ▶ Por ejemplo: los rendimientos podrían haber variado y lo vendido no fue lo esperado, y eso tiene un costo.
- Pero las decisiones las tenemos que tomar ahora, antes del futuro...

Ejemplo

- Vamos a considerar un problema en el área de salud: planificar la asignación de quirófanos a operaciones en un hospital.
 - ▶ N quirófanos y cada quirófano está disponible T horas en el periodo de planificación.
 - ▶ P operaciones y la duración de la operación i es de w_i horas.
 - ▶ Si es necesario, un quirófano puede funcionar tiempo extra, pero hay un total de Q horas máximo disponible para todos los quirófanos.
 - ▶ Costo fijo K_j por usar el quirófano j en el período.
 - ▶ Costo adicional c_j por hora de sobretiempo que se asigne al quirófano j .
 - ▶ Costo β por operación no realizada ya que implica reasignar al paciente a otro centro asistencial.

Ejemplo

- x_{ij} indica si la operación i se hace en el quirófano j .
- y_j indica si el quirófano j se usa o no.
- z_i indica si la operación no pudo ser programada.
- t_j es la cantidad de sobretiempo asignado al quirófano j .

$$\text{mín} \quad \sum_{j=1}^N \{K_j y_j + c_j t_j\} + \sum_{i=1}^P \beta z_i$$

$$s.a. \quad \sum_{j=1}^N x_{ij} + z_i = 1, \quad i = 1, \dots, P \quad (1)$$

$$\sum_{i=1}^P x_{ij} \leq P y_j, \quad j = 1, \dots, N \quad (2)$$

$$\sum_{i=1}^P w_i x_{ij} \leq T + t_j, \quad j = 1, \dots, N \quad (3)$$

$$\sum_{j=1}^N t_j \leq Q, \quad (4)$$

$$x_{ij}, y_j, z_i \in \{0, 1\}, t_j \geq 0, \quad i = 1, \dots, P; j = 1, \dots, N. \quad (5)$$

Ejemplo

- En la realidad, las operaciones se planifican por anticipado pero se hacen en el futuro.
- Pero la duración de las operaciones es, en realidad, aleatoria y varía, y eso puede llevar a tener que usar sobretiempo.
- Pero esto lo sabríamos sólo cuando la incertidumbre se manifieste...
- Vamos a construir un solo modelo, pero que separa la primera etapa de decisiones (“here and now”), y considera, además, una estimación del costo que generarían, en el futuro, esas decisiones una vez que la incertidumbre se manifieste (“wait and see”)...

Ejemplo

- Vamos a suponer que la duración de las operaciones se comporta según una distribución de probabilidades ξ “conocida”.
- Entonces, cada decisión de asignación de operaciones a quirófanos, (y, x, z) genera una posibilidad hacia el futuro...
- Queremos ver y analizar “todos” los futuros posibles...

Ejemplo

- Planteamos el siguiente problema principal:

$$\text{mín} \quad \sum_{j=1}^N K_j y_j + \sum_{i=1}^P \beta z_i + \mathbb{E}_{\xi}(F(y, x, z))$$

$$\text{s.a.} \quad \sum_{j=1}^N x_{ij} + z_i = 1, \quad i = 1, \dots, P \quad (1)$$

$$\sum_{i=1}^P x_{ij} \leq P y_j, \quad j = 1, \dots, N \quad (2)$$

$$x_{ij}, y_j, z_i \in \{0, 1\} \quad i = 1, \dots, P; j = 1, \dots, N. \quad (5)$$

- donde $F(y, x, z)$ es la consecuencia (costo en este caso), en el futuro, de las decisiones (y, x, z) , lo que llamaremos el **problema de segunda etapa**.

Ejemplo

- El problema de segunda etapa es:

$$F(y, x, z) = \min \sum_{j=1}^N c_j t_j$$
$$s.a. \sum_{i=1}^P w_i x_{ij} \leq T + t_j, \quad j = 1, \dots, N \quad (3)$$

$$\sum_{j=1}^N t_j \leq Q, \quad (4)$$

$$t_j \geq 0, \quad i = 1, \dots, P; j = 1, \dots, N. \quad (5)$$

- Entonces acá: x_{ij} (notar que y no se necesita aquí, tampoco z) son las decisiones de la primera etapa y el sobretiempo, t_j , son las variables de segunda etapa, es la variable que se “ajusta en el futuro”.
- Recordemos que los w_i son variables aleatorias, así que ¡ $F(y, x, z)$ es aleatorio!

Comentarios

- Acabamos de formular lo que se conoce como un “modelo de optimización estocástica de 2 etapas con *recurso*” (2 stage stochastic model with recourse)
- No confundirse: todas las decisiones se toman ahora.
- El costo de segunda etapa es, entonces, una estimación de lo que podría pasar en el futuro pero la decisión de primera etapa tiene que servir para cualquier cosa que pase en el futuro...

Modelo lineal con recurso: formulación general (con notación típica)

- Tenemos decisiones “de primera etapa”, x , que llamamos “here and now”. Estas tienen sus propias restricciones ($Ax = b, x \geq 0$) y costos ($c^T x$).
- Queremos minimizar el costo de primera etapa **más el valor esperado del costo que generan las decisiones x en la segunda etapa.**

- Es decir:

$$\begin{array}{ll} \text{mín} & c^T x + \mathbb{E}(Q(x)) \\ \text{s.a.} & Ax = b \\ & x \geq 0 \end{array}$$

- donde la segunda etapa es:

$$\begin{array}{ll} Q(x) = \text{mín} & d^T y \\ & \text{s.a. } Dx + Ty = e \\ & y \geq 0 \end{array}$$

- Generalmente e (y/o D) es aleatorio y las variables y se “ajustan” o “adaptan”, al evento incierto, son variables “wait and see”, esto se llama un modelo con “recurso fijo” (fixed recourse).
- Tanto x como y podrían tener restricciones de integralidad adicionales.

Cómo resolver el problema

- No existe una manera analítica simple de caracterizar la optimalidad de un problema como el anterior.
- Para comenzar, la función $c^T x + \mathbb{E}(Q(x))$ no es diferenciable.
- Vamos a ver como abordar este problema.
- Un enfoque se basa en aproximar $\mathbb{E}(Q(x))$ por escenarios finitos.
- Esto se conoce como **Sample Average Approximation (SAA)**.

Resolviendo el problema: SAA

- Supongamos que e y/o D son aleatorios y siguen una distribución de probabilidad ξ “conocida”.
- Supongamos que se generan K escenarios de e y D , a partir de la distribución ξ : $e^1, \dots, e^K, D^1, \dots, D^K$.
- Dadas decisiones x , por cada escenario de (D, e) , hay un problema de segunda etapa, que determina variables y para ese escenario,
- donde

$$Q_k(x) = \begin{array}{ll} \text{mín} & d^T y^k \\ \text{s.a.} & D^k x + T y^k = e^k \\ & y^k \geq 0 \end{array}$$

y esto para $k = 1, \dots, K$.

Resolviendo el problema: SAA

- Podemos, entonces, aproximar $\mathbb{E}(Q(x))$ por

$$\frac{1}{K} \sum_{k=1}^K Q_k(x)$$

- (Notar que x es el mismo para todos los escenarios: viene de la primera etapa)

Resolviendo el problema: SAA

- Reemplazando esto en el problema de la primera etapa, obtenemos el siguiente problema:

$$\begin{aligned} SAA) \quad & \text{mín} \quad c^T x \quad + \quad \frac{1}{K} \sum_{k=1}^K d^T y^k \\ & s.a. \quad Ax \quad = b \\ & \quad D^k x \quad + \quad T y^k \quad = e^k, k = 1, \dots, K \\ & \quad x \geq 0, \quad y^k \geq 0 \end{aligned}$$

- Este se conoce como el problema SAA: Sample Average Approximation.

Resolviendo el problema: SAA

- Aquí está, en forma estructurada:

$$\begin{array}{llllll}
 \text{mín} & c^T x & + \frac{1}{K} (d^T y^1 + d^T y^2 & \dots & + d^T y^K) & \\
 \text{s.a.} & Ax & & & & = b \\
 & D^1 x & + T y^1 & & & = e^1 \\
 \text{SAA)} & D^2 x & & + T y^2 & & = e^2 \\
 & \vdots & \vdots & \vdots & \ddots & = \vdots \\
 & D^K x & \dots & \dots & \dots & T y^K = e^K \\
 & x \geq 0, & y^1 \geq 0 & y^2 \geq 0 & \dots & y^K \geq 0, k = 1, \dots, K
 \end{array}$$

- ¿Cómo se podrá resolver este problema?

Ejemplo de SAA

- Retomemos el ejemplo de granjero...
- Asumiremos incertidumbre en los rendimientos
- Esto es, en la matriz D ...

- Vamos a mostrar una implementación de SAA para este problema en Gurobi-Python y la vamos a ejecutar.
- En este caso lo resolvemos directo, sin descomposición ya que el problema es muy chico.

Ejemplo de SAA

- El problema del granjero:

x_j : superficie dedicada al cultivo j .

w_j : cantidad de cultivo j vendida, para wheat y corn.

y_j : cantidad de cultivo j comprada, para wheat y corn.

w_3 : cantidad de remolacha vendida a precio alto.

w_4 : cantidad de remolacha vendida a precio bajo.

- El modelo:

$$\begin{aligned} \text{máx} \quad & +170w_1 + 150w_2 + 36w_3 + 10w_4 \\ & -150x_1 - 230x_2 - 260x_3 - 238y_1 - 210y_2 \\ \text{s.a.} \quad & x_1 + x_2 + x_3 \leq 500 \\ & 2,5x_1 + y_1 - w_1 \geq 200 \\ & 3,0x_2 + y_2 - w_2 \geq 240 \\ & w_3 + w_4 \leq 20x_3 \\ & w_3 \leq 6000 \\ & x_1, x_2, x_3, y_1, y_2, w_1, w_2, w_3, w_4 \geq 0 \end{aligned}$$

- ¿Cuáles son decisiones de primera etapa y cuáles de ajuste?

Ejemplo de SAA

- Vamos a denotar por α_t , α_m y α_r los rendimientos del trigo, maíz y remolacha respectivamente.
- El problema del granjero modelado como problema estocástico en 2 etapas:

$$\begin{aligned} \text{máx} \quad & -150x_1 - 230x_2 - 260x_3 + \mathbb{E}(Q(x)) \\ \text{s.a.} \quad & x_1 + x_2 + x_3 \leq 500 \\ & x_1, x_2, x_3 \geq 0 \end{aligned}$$

- donde:

$$\begin{aligned} Q(x) = \text{máx} \quad & +170w_1 + 150w_2 + 36w_3 + 10w_4 - 238y_1 - 210y_2 \\ \text{s.a.} \quad & \alpha_t x_1 + y_1 - w_1 \geq 200 \\ & \alpha_m x_2 + y_2 - w_2 \geq 240 \\ & w_3 + w_4 \leq \alpha_r x_3 \\ & w_3 \leq 6000 \\ & y_1, y_2, w_1, w_2, w_3, w_4 \geq 0 \end{aligned}$$

- Veamos esto funcionando...

Decisiones en etapas: comentarios

- La modelación “con recurso” ha sido de gran utilidad en diversas áreas de aplicación.
- Una de las más antiguas es la Planificación de Sistemas Eléctricos.
- También en Planificación de Producción.

- El proceso puede extenderse a más de una etapa: “Multistage Stochastic Problem”
- En este caso la complejidad aumenta pero sí se pueden abordar.
- Algunos de los problemas de optimización más grandes que existen son de este tipo: decenas de millones de variables y restricciones...
- Y se abordan con nuestras viejas ideas de descomposición...

- Existe también una forma alternativa de abordar el problema de 2-etapas:
- La función objetivo es no diferenciable, pero se puede probar que es convexa, ¿qué método servirá?