

¿Realmente conocemos cómo varían los datos?

- En los enfoques anteriores se ha supuesto que “conocemos” la distribución de probabilidad de los datos y esto es un supuesto bastante fuerte y en la realidad no siempre se puede tener.
- Enfoques recientes tratan de buscar soluciones que no necesiten conocimiento detallado de la incertidumbre.
- Uno de ellos es la **Optimización Robusta**, que presentaremos ahora.

La idea de una solución robusta


- Consideremos el siguiente problema base:

$$\begin{array}{ll} \min & c^T x \\ \text{s.a.} & Ax \leq b \\ & x \geq 0 \end{array} \Leftrightarrow \begin{array}{ll} \min & c^T x \\ \text{s.a.} & \alpha_i^T x \leq b_i \quad i = 1, \dots, m \\ & x \geq 0 \end{array}$$

- Aquí $\alpha_1, \dots, \alpha_m$ son las filas de la matriz A de las restricciones.
- Una solución del problema es robusta si sigue siendo válida aún si hay un cambio en los datos, al menos dentro de cierto rango.
- “Válida”: factible y con buen valor de función objetivo.


La idea de una solución robusta

- Aquí está gráficamente:




La idea de una solución robusta

- Aquí está gráficamente:




La idea de una solución robusta

- Aquí está gráficamente:



La idea de una solución robusta

- Aquí está gráficamente:



La idea de una solución robusta

- La variación de los datos NO la conocemos como fenómeno estocástico.
- Supongamos, para simplificar, que sólo A es el que varía.
- Asumimos que, para cada restricción, $\alpha_i = \bar{\alpha}_i + u_i$, $u_i \in D_i(\Gamma)$, donde $D_i(\Gamma)$ es un “conjunto de incertidumbre”.
- Γ es una medida del grado de incertidumbre.
- El problema robusto es entonces:

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a.} & (\bar{\alpha}_i + u_i)^T x \leq b_i, \forall u_i \in D_i(\Gamma), i = 1, \dots, m \\ & x \geq 0 \end{array}$$

La idea de una solución robusta

- Definamos, para cada $i = 1, \dots, m$,

$$\begin{aligned}\beta_i(x, \Gamma) &= \max x^T u_i \\ \text{s.t. } &u_i \in \mathcal{D}_i(\Gamma) .\end{aligned}$$

- Estas son las “funciones de protección” asociadas a las restricciones y miden cuánta holgura extra se necesita debido a la variación.
- El problema queda transformado en:

$$\begin{aligned}\text{mín } &c^T x \\ \text{s.a. } &\bar{\alpha}_i^T x + \beta_i(x, \Gamma) \leq b_i \quad i = 1, \dots, m \\ &x \geq 0 ,\end{aligned}$$

- Y este puede ser llevado a la “contraparte robusta” que es un problema más manejable dependiendo de los conjuntos D_i .

Diferentes Enfoques

- Diferentes modelos robustos se obtienen según la especificación de los conjuntos $D_i(\Gamma)$:
- **Incertidumbre por intervalos:** coeficiente $a_{ij} \in [\bar{a}_{ij} - s_{ij}, \bar{a}_{ij} + s_{ij}]$, donde $s_{ij} = \Gamma \times \bar{a}_{ij}$.
- Entonces, Γ grande genera un intervalo grande.
- La contraparte robusta, en este caso, es simple:

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a.} & \tilde{\alpha}_i^T x \leq b_i \quad i = 1, \dots, m \\ & x \geq 0, \end{array}$$

donde $\tilde{a}_{ij} = \bar{a}_{ij} + s_{ij}$, para todo i, j .

- Estamos tomando el escenario de “peor caso” y obteniendo la solución más conservadora.
- Esta idea fue desarrollada por Soyster[1972].

Diferentes Enfoques

- **Incertidumbre elipsoidal** : como lo anterior es muy “conservador”, se pueden considerar conjuntos que no sean producto de intervalos:

- Para cada restricción, sea:

$$D_i(\Gamma) = \{u \in \mathbb{R}^n : u^T Q_i u \leq \Gamma^2\}$$

donde Q_i es una matriz de $n \times n$ definida positiva.

- La contraparte robusta es:

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a.} & \bar{\alpha}_i^T x + \Gamma \sqrt{x^T Q_i^{-1} x} \leq b_i \quad i = 1, \dots, m \\ & x \geq 0, \end{array}$$

- Esto genera un problema de Cono de Segundo Orden.
- Esta idea fue propuesta por Ben-Tal y Nemirovski[desde 1998]

Diferentes Enfoques

- Otro enfoque muy popular es usar un modelo de **Incertidumbre poliedral**
- Supongamos que $a_{ij} \in [\bar{a}_{ij} - s_{ij}, \bar{a}_{ij} + s_{ij}]$, pero que, además, deben cumplir que:

$$\sum_{j=1}^n \frac{1}{s_{ij}} |a_{ij} - \bar{a}_{ij}| \leq \Gamma$$

- Esto acota la variación simultánea de los coeficientes inciertos, a lo más Γ varían.
- Se puede probar que la contraparte es:

$$\begin{aligned} \text{mín} \quad & c^T x \\ \text{s.a.} \quad & \bar{\alpha}_i^T x + z_i \Gamma + \sum_{j=1}^n p_{ij} \leq b_i, \quad i = 1, \dots, m \\ & z_i + p_{ij} \geq s_{ij} y_{ij}, \quad j = 1, \dots, n; i = 1, \dots, m \\ & -y_{ij} \leq x_j \leq y_{ij}, \quad j = 1, \dots, n; i = 1, \dots, m \\ & z_i \geq 0; p_{ij}, y_{ij} \geq 0, x \geq 0, \quad j = 1, \dots, n; i = 1, \dots, m. \end{aligned}$$

- Esta idea fue propuesta por Bertsimas y Sim[2004] y preserva la linealidad del problema original.

Optimización Robusta en la Práctica


- La Optimización Robusta ha encontrado aplicaciones en diferentes áreas
- Ingeniería civil, mecánica y electrónica:
 - ▶ Diseño estructural
 - ▶ Diseño mecánico
 - ▶ Diseño de sistemas electrónicos
- Finanzas
 - ▶ “Robust asset allocation”
 - ▶ “Robust portfolio optimization”
- Problemas de planificación y transporte
 - ▶ Ruteo robusto
 - ▶ Diseño robusto de redes
 - ▶ Revenue Management
- Gestión de la Cadena de Abastecimientos (SCM)
- Gestión de Sistemas de Salud.

Ejemplo de aplicación: Planificación en la Industria Forestal:

- La industria forestal requiere planificar complejas operaciones con altos costos de capital.
- También está sujeta a variabilidades e incertidumbres, no sólo las habituales, sino que otras que se originan en la naturaleza biológica de la materia prima.
- Mostraremos un ejemplo de uso de Optimización Robusta en la planificaciones de operaciones industriales forestales.
- Este trabajo fue parte de la tesis doctoral de Pamela Álvarez (actualmente académica de la UNAB).

Planificación de operaciones de aserraderos:

- Un aserradero transforma troncos, que son “cilindros” en tablas que son paralelógramos.
- Hay troncos de varias dimensiones (diámetros).
- Las tablas demandadas pueden tener muchas dimensiones.
- Existe demanda por los productos a lo largo del tiempo.
- El problema es asignar trabajo a los aserraderos, proveer los troncos adecuados y hacer todo en forma “óptima”.
- Los troncos se cortan según un “patrón de corte”



- Algunos patrones son más adecuados que otros dependiendo del diámetro y características de los troncos
- La calidad de la madera también cambia.

El modelo (sin mucha explicación)

- Esta es la función objetivo:

$$Max\ z = \sum_t \delta_t \left[\begin{aligned} & \sum_j \sum_m PR_m \cdot VV_{jmt} - \sum_j \sum_k CPT_{jk} \cdot DT_{jkt} - \sum_j \sum_k CT_j \cdot IT_{jkt} - \\ & \sum_j \sum_m CP_j \cdot IP_{jmt} - \sum_m \sum_j CO \cdot OT_{jmt} - \sum_j \sum_m F \cdot CR_j \cdot PT_{jmt} - \\ & \sum_j \sum_m CS_j \cdot PT_{jmt} - \sum_j \sum_k \sum_e CA_j \cdot AT_{jek} \end{aligned} \right]$$

- Calcula el ingreso que se obtiene de venta de tablas, menos los costos:
 - ▶ Compra de troncos
 - ▶ Costos de aserrío
 - ▶ Costos de inventario y almacenamiento
 - ▶ Costos de secado
 - ▶ Costos de reprocesamiento y subcontratación.

Planificación de operaciones de aserraderos: El modelo

- Estas son las restricciones:

$$\begin{aligned}
 IT_{jkt-1} + DT_{jkt} &= IT_{jkt} + \sum_c AT_{jckk} \\
 IP_{jwt-1} + PT_{jwt} &= IP_{jwt} + VV_{jwt} \\
 IB_{jwt-1} + PT_{jwt} + OT_{jwt} &= IB_{jwt} + VV_{jwt} \\
 \sum_c \sum_k AT_{jckk} \text{RM}_{ckw} &= PT_{jwt} \\
 \sum_c \sum_k AT_{jckk} &\leq CAPA_j \\
 \sum_k IT_{jkt} &\leq CAPC_j \\
 \sum_{w \in TV} IP_{jwt} &\leq CAPP_j \\
 \sum_{w \in TS} PT_{jwt} &\leq CAPS_j \\
 \sum_{w \in TS} IB_{jwt} &\leq CAPB_j \\
 0.2 \sum_{w \in TS} PT_{jwt} + \sum_{w \in TV} PT_{jwt} &\leq CAPR_j \\
 \sum_j VV_{jwt} &\geq DD_{wt} \\
 IT_{jkt}, IP_{jwt}, IB_{jwt}, AT_{jckk}, PT_{jwt}, OT_{jwt}, VV_{jwt}, DT_{jkt} &\geq 0
 \end{aligned}$$

Yield coefficient

Inventory constraints


Transformation constraint

Capacity constraints

Demand constraint

Planificación de operaciones de aserraderos: Consideraciones


- Una compañía en Chile usaba, en 2007, un modelo de este tipo para asignar 4 aserraderos sobre un periodo de tres meses y tardaba varias horas en cada ejecución.
- Pero... el modelo no capturaba las variabilidades en los procesos y estas debían ser corregidas “a ojo” al llevar adelante la producción.
- La variabilidad está en el rendimiento de los patrones de corte porque los troncos no son cilindros perfectos.



- No existían estudios sobre la variabilidad de los procesos productivos: no habían distribuciones de probabilidad disponibles.
- Entonces, la Optimización Robusta era el camino a seguir...
- Se construyó la contraparte robusta del modelo.

Planificación de Aserraderos: resultados



- Se probó el modelo robusto para diferentes grados de variabilidad en los coeficientes de rendimiento (5 %, 10 %, 15 %, 20 %), y para diferentes valores de Γ .
- Este es el cambio en la función objetivo:



- Puede verse claramente el “tradeoff” entre deterioro de la función objetivo y el grado de robustez en el modelo: el “precio de la robustez”.

Planificación de Aserraderos: resultados

- ¿Qué tan buena es la solución obtenida para un valor de Γ dado?
- Si Γ tiene valor intermedio, podría haber infactibilidad...
- Se simularon 2.000 escenarios con distribución uniforme y con distribución normal y se evaluó factibilidad de las soluciones calculadas.



- Podemos usar estos resultados para decidir qué valor de Γ usar para lograr un nivel “aceptable” de factibilidad.
- Por ejemplo, si creemos que los datos distribuyen en forma uniforme y la variabilidad es de un 15 %, una solución obtenida con $\Gamma = 80$ es factible con una probabilidad estimada de alrededor de 0.95.

Optimización Robusta: comentarios

- Construir un modelo robusto a partir de uno ya existente no es particularmente complicado.
- Si se usa la formulación de Bertsimas y Sim, se mantiene la linealidad y se pueden usar variables enteras “sin problemas”!
- Incluso hay implementaciones de software que construyen “automáticamente” las formulaciones robustas: JuMPeR en Julia.
- La idea de soluciones robustas se puede combinar con la toma de decisiones en dos etapas: tomamos decisiones hoy considerando un escenario conservador sobre lo que puede pasar en el futuro (Optimización Robusta “Ajustable”)

Otros conceptos y hacia el futuro

- Lo que presentamos son las ideas básicas de modelación bajo incertidumbre.
- Pero es un campo enorme de desarrollo con múltiples aplicaciones
- Comentaremos algunos temas más recientes.

Combinando Optimización y Simulación

- Consideremos un problema general bajo incertidumbre de la siguiente forma:

$$\begin{array}{ll} \text{mín} & \mathbb{E}(f(x, \omega)) \\ \text{s.a.} & g_i(x) \leq b_i, i = 1, \dots, m \\ & x \in C \end{array}$$

- donde ω son parámetros aleatorios.
- Si tuviéramos una fórmula simple para $f(x, \omega)$, tal vez podríamos calcular $\mathbb{E}(f(x, \omega))$
- Pero muchas veces no es así...

Combinando Optimización y Simulación

- Por ejemplo:
 - Un hospital debe planificar la asignación de camas a distintas áreas de atención (cirugía, maternidad, etc.)
 - Las camas son el “recurso” fundamental del hospital, si no son suficientes, no se puede atender a los pacientes, y estos deben esperar.
 - El problema es que los pacientes llegan en forma aleatoria y con condición de salud aleatoria, y podrían seguir rutas aleatorias dentro del hospital.
 - Luego, no siempre sabemos con certeza qué camas necesitan.
-
- Podemos visualizar el hospital como una red donde los nodos representan las unidades.
 - Y en esta red se genera una espera total de los pacientes para poder ser atendidos.
 - Problema: determinar la asignación de camas a las unidades de modo tal que la espera de los pacientes sea mínima...

Combinando Optimización y Simulación

- Aquí $f(x, \omega)$ es el tiempo de espera de los pacientes, que depende de las decisiones de asignación, x , y de los eventos aleatorios relacionados a los pacientes.
- Las restricciones limitan el total de camas e imponen otras restricciones técnicas.
- ¿Cómo es la función $f(x, \omega)$?
- Esto está en el contexto de una red de sistemas de espera.
- La Teoría de Colas no ayuda mucho aquí...
- La solución: aproximar f mediante simulación computacional.

Combinando Optimización, Simulación y Machine Learning

- La Optimización y la Simulación muchas veces no conversan.
- Desde hace tiempo existen enfoques para “optimizar” usando simulación...
- Pero los grandes requerimientos computacionales los hacían poco prácticos.
- ¡Pero hoy se puede hacer!

- Por ejemplo, podríamos usar el Simulated Annealing para minimizar $\mathbb{E}(f(x, \omega))$.
- Y $\mathbb{E}(f(x, \omega))$ se estima mediante la simulación:
- Se corren n simulaciones, con escenarios $\omega_1, \dots, \omega_n$ y

$$\mathbb{E}(f(x, \omega)) \approx \frac{1}{n} \sum_{i=1}^n f(x, \omega_i)$$

- Y podemos repetir esto para muchos escenarios diferentes y hacer que una Red Neuronal “aprenda” las soluciones...

El poder (y necesidad) de la Optimización bajo Incertidumbre

- El objetivo fue dar una visión muy resumida de la Optimización bajo Incertidumbre
- Es una herramienta de modelación potente y que hoy tiene 100 % de relevancia en problemas reales.
- Además, esto se une la capacidad cada vez mayor de analizar grandes cantidades de datos ya que esos análisis pueden permitir mejores estimaciones de las características de los fenómenos aleatorios.
- Mejores estimaciones ayudan a reducir la complejidad de la incertidumbre.