


Interrogación 1. Solución

Pregunta 1 (14 puntos):


- a) (3 pts) Haga un dibujo que muestre con claridad la forma de las trayectorias de avance de las iteraciones, tanto del Método del Gradiente como del Método Simple de Primer Orden, para minimizar una función f , que cumpla con las hipótesis de cada método. Use como base el dibujo siguiente, que muestra curvas de nivel de la función y el punto de partida x^0 :



Se entiende que el centro de las curvas de nivel es el punto mínimo (puede hacer ambas trayectorias en un mismo dibujo, bien diferenciadas, o hacer dos dibujos).

Solución: Por un lado, en el Método del Gradiente, los pasos de avance son en dirección ortogonal a las curvas de nivel hasta encontrar un mínimo en esa dirección (Linesearch), esto es, lo que genera trayectorias en zig-zag hasta llegar al mínimo de la función.

Mientras que, en el Método Simple de Primer Orden, la trayectoria parece más directa hacia el mínimo, ya que en cada iteración se da un paso fijo, de $1/L$, en la dirección del negativo del gradiente (perpendicular a la curva de nivel en el punto considerado, ya que el gradiente tiene esa propiedad). A diferencia del método del gradiente con linesearch, aquí no se llega hasta el mínimo en cada dirección, sino que se avanza un poco y se vuelve a iterar en la dirección del negativo del gradiente.



- (1.5 puntos) Dibujo correcto de la trayectoria del Método del Gradiente.
- (1.5 puntos) Dibujo correcto de la trayectoria del Método Simple de Primer Orden.

- b) (3 pts) Comente si acaso la siguiente afirmación es correcta o no: “Para el problema no restringido $\min f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es 2 veces continuamente diferenciable, el método de Newton converge siempre a velocidad cuadrática, para cualquier función de ese tipo, siempre y cuando el punto de partida esté suficientemente cerca de una solución óptima.” Justifique con precisión su respuesta en función de los contenidos del curso.

Solución: La afirmación es falsa, se necesita que el Hessiano sea definido positivo en el mínimo de la función como indica el teorema de convergencia de Newton.

También se puede usar un contraejemplo, como lo sería la función $f(t) = t^4$. Su primera derivada es $f'(t) = 4t^3$ y su segunda derivada es $f''(t) = 12t^2$. En el mínimo, $t = 0$, se cumple que $f''(0) = 0$, lo que implica que el Hessiano es semidefinido positivo. En consecuencia, el método de Newton aplicado a esta función presenta sólo convergencia lineal y no cuadrática. En efecto, la iteración general (esto se hizo en clases) sería de la forma $x^{k+1} = x^k - f'(x^k)/f''(x^k)$. Reemplazando resulta:

$$x^{k+1} = x^k - \frac{4(x^k)^3}{12(x^k)^2} = x^k - \frac{1}{3}(x^k) = \frac{2}{3}(x^k)$$

y esto representa convergencia lineal y no cuadrática.

- (3 puntos) Argumentar que afirmación es FALSA o usar un contraejemplo.
- Nota: Si se responde que afirmación es falsa pero justificación es incorrecta no se asigna puntaje.
- Nota: Argumentar únicamente que función es convexa no es respuesta válida.

c) (4 pts) Suponga que se está aplicando el Método de Gradiente para resolver el problema de mínimos cuadrados

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, y $m > n$. Suponga que quiere resolver este problema con el Método del Gradiente y se le ocurre calcular los valores propios de la matriz $A^T A$. El despliegue de los valores propios, en orden decreciente es el siguiente:


[118.30, 32.10, 22.40, 21.60, , 7.43, 6.20, 0.0, 0.0]

(se entiende que los puntos representan muchas coordenadas que no vamos a mostrar). ¿Cómo considera usted que será la convergencia del Método del Gradiente para este problema? Y si usara el Método Simple de Primer Orden, ¿podría tener complejidad $O(\log \frac{1}{\epsilon})$? Explique con precisión su respuesta.

Solución: Para el Método del Gradiente, la convergencia será muy lenta debido al mal condicionamiento de la matriz $A^T A$, siendo esta matriz el Hessiano de la función objetivo. Dentro de los valores propios se encuentra el 0.0, lo que implica que el Hessiano es semidefinido positivo, por lo que la convergencia no será lineal y/o incluso puede no converger. En cuanto al Método Simple de Primer Orden, no puede alcanzar complejidad $O(\log \frac{1}{\epsilon})$, ya que dicha tasa requiere la propiedad de convexidad fuerte (es decir, que todos los valores propios estén acotados inferiormente por un número positivo fijo).



- (2 puntos) Explicar que el Método del Gradiente funcionaría mal debido al mal condicionamiento.
- (2 puntos) Justificar que, al no cumplirse la propiedad fuerte de convexidad, el Método Simple de Primer Orden no tendría convergencia lineal.

d) (4 pts) Suponga que está comparando el comportamiento de algoritmos para abordar el problema $\min_{x \in \mathbb{R}^n} f(x)$ para una función convexa, dos veces continuamente diferenciable, con ∇f cumpliendo propiedad de Lipschitz, y todas las otras hipótesis necesarias para ambos métodos. El problema viene de una aplicación en astronomía y usted usa el Método de Newton y el Método Simple de Primer Orden para una función con $n = 10^{12}$ variables. Dibuje dos gráficos que muestren, en forma comparativa: i) el primero, la forma más probable de las curvas de evolución para el valor de función objetivo en función del número de iteraciones de los algoritmos, y ii) el segundo, la forma más probable de las curvas de evolución para el valor de función objetivo en función del tiempo de CPU de ejecución transcurrido. Justifique el por qué de las diferencias de comportamiento que está mostrando en sus gráficos. No olvide identificar bien qué curva corresponde a qué método. Use como base las siguientes recomendaciones de gráficos (se muestran los ejes solamente):



Solución: En relación con el número de iteraciones, el Método de Newton presenta una complejidad de $O(\log \log \frac{1}{\epsilon})$ (convergencia cuadrática), mientras que el Método de Primer Orden tiene complejidad $O(\frac{1}{\epsilon})$ (también llamado sublineal), o en el mejor de los casos $O(\log \frac{1}{\epsilon})$ (convergencia lineal). Por lo tanto, al comparar únicamente la cantidad de iteraciones, Newton requiere considerablemente menos pasos para alcanzar una solución óptima.

Sin embargo, si se compara el costo por iteración, cada paso realizado por el Método de Newton requiere operaciones de orden $O(n^3)$, lo que implica un esfuerzo total de $O(n^3 \log \log \frac{1}{\epsilon})$. Mientras que, cada iteración del Método de Primer Orden cuesta $O(n)$, es decir, requiere un esfuerzo total de $O(n \log \frac{1}{\epsilon})$. Por lo que, dado que $n = 10^{12}$, que se entiende que es un n muy grande, el costo total de Newton resulta mucho mayor que el del Método de Primer Orden.



- (1 punto) Gráfico correcto del valor de la función objetivo en función del número de iteraciones, mostrando que Newton desciende más rápido que el Método de Primer Orden.
- (1 punto) Gráfico correcto del valor de la función objetivo en función del tiempo, mostrando que el Método de Primer Orden resulta más eficiente que Newton.
- (1 punto) Explicación de las diferencias en términos de número de iteraciones. Nota: si la explicación no tiene fundamento teórico asignar 0.5 puntos.
- (1 punto) Explicación de las diferencias en términos de costo computacional. Nota: si la explicación no tiene fundamento teórico asignar 0.5 puntos.

Pregunta 2 (14 puntos)

Consideremos el siguiente problema, que se conoce como “basis pursuit”, en inglés, y que tiene diversas aplicaciones en estimaciones estadísticas y análisis de señales. Vamos a suponer que se conocen funciones $g_1, \dots, g_n$. Otra función h puede escribirse de la forma

$$h = \sum_{j=1}^n x_j g_j$$

donde los x_j son escalares que corresponden a pesos o ponderadores. Se dice que las funciones g_j son una “base” y la función h es generada como combinación de estas. Por ejemplo, las funciones g_i podrían representar toda una cantidad de modos de vibración naturales de algún fenómeno y f está relacionada a una onda o señal que se descompone, en alguna proporción, en esos modos básicos o naturales.

Entonces, se ha observado el fenómeno y se dispone de m observaciones y sus valores en la función h . Es decir, conocemos valores u_i y valores y_i , $i = 1, \dots, m$ tales que $h(u_i) = y_i$. Queremos, entonces, determinar la función h en términos de la base de funciones g_j , $j = 1, \dots, n$, de modo que, al menos para los valores u_i la estimación sea correcta. Entonces, postulamos una expresión de la forma:

$$\sum_{j=1}^n x_j g_j(u_i) = y_i, \quad i = 1, \dots, m$$

y queremos encontrar pesos x_j que cumplan con esto. En el caso bajo estudio, la base de funciones corresponde a un número enorme, es decir, n es muy grande comparado con m y el problema anterior está sobredeterminado. Se propone, entonces, encontrar una solución x usando la menor cantidad posible de funciones básicas y para eso se postula un problema de la forma:

$$\min_{x \in \mathbb{R}^n} \tau \|x\|_1 + \sum_{i=1}^m \left(\sum_{j=1}^n g_j(u_i) x_j - y_i \right)^2$$

donde $\tau > 0$ es un parámetro de balance elegido adecuadamente. (recuerde que $\|x\|_1 = \sum_{j=1}^n |x_j|$)

- a) (3 pts) Argumente que el resolver ese problema puede, efectivamente, generar una solución x que pudiera aproximarse a la estructura que buscamos y que, además, logre un buen ajuste del problema de estimación.

Solución: El problema presentado genera una solución aproximada a la buscada en la estimación debido a los siguientes motivos (en realidad, no es más que un problema de estimación tipo LASSO):

- En primer lugar, la minimización del error cuadrático de las predicciones respecto a los valores observados, que corresponde al segundo término de la función objetivo.
- Adicionalmente, ya que el problema está sobredeterminado ($m \gg n$), habrán variables libres, por lo que podrían tomar cualquier valor. Para evitar esto, la norma 1 busca penalizar las componentes no nulas de x , como se vio en clases. Por ende, este problema de minimización permitirá encontrar una solución con la menor cantidad de "pesos" posibles (componentes no nulas de x).

Otra forma de argumentarlo por medio de reconocer que corresponde al problema de LASSO visto en clases, en particular

notando que $\sum_{i=1}^m \left(\sum_{j=1}^n g_j(u_i) x_j - y_i \right)^2 = \|Ax - y\|_2^2$ con $A_{ij} := g_j(u_i)$.

- (2 puntos) Explicar error cuadrático.
- (1 punto) Explicar penalización de norma 1.
- Alternativamente, si se argumenta justificadamente con problema de LASSO asignar (3 puntos).

- b) (4 pts) El problema planteado aquí es no diferenciable y se puede abordar con el Método del Subgradiente. Determine una expresión general para $\partial f(x)$, donde f es la función objetivo del problema. Justifique con precisión todo lo que haga.

Solución: Sea $f(x) = \tau \|x\|_1 + \sum_{i=1}^m \left(\sum_{j=1}^n g_j(u_i) x_j - y_i \right)^2$.

Obtenemos que $\partial f(x) = \tau \cdot \partial \|x\|_1 + \partial \sum_{i=1}^m \left(\sum_{j=1}^n g_j(u_i) x_j - y_i \right)^2$. Dicho cálculo presenta una parte diferenciable y una parte no diferenciable.

$$\text{Parte diferenciable: } \partial \sum_{i=1}^m \left(\sum_{j=1}^n g_j(u_i) x_j - y_i \right)^2 = \begin{pmatrix} \sum_{i=1}^m \left(2 \sum_{j=1}^n g_j(u_i) x_j - y_i \right) g_1(u_i) \\ \sum_{i=1}^m \left(2 \sum_{j=1}^n g_j(u_i) x_j - y_i \right) g_2(u_i) \\ \vdots \\ \sum_{i=1}^m \left(2 \sum_{j=1}^n g_j(u_i) x_j - y_i \right) g_n(u_i) \end{pmatrix}$$

(Es equivalente a $2A^T(Ax - y)$ con $A_{ij} = g_j(u_i)$)

Parte no diferenciable: llamaremos $p(x) \in \mathbb{R}^n$ tal que $p_k(x) = \begin{cases} 1 & \text{si } x_k > 0 \\ -1 & \text{si } x_k < 0 \\ \in [-1, 1] & \text{si } x_k = 0 \end{cases}$

$$\text{Por ende: } \partial f(x) = \tau p(x) + \begin{pmatrix} \sum_{i=1}^m \left(2 \sum_{j=1}^n g_j(u_i) x_j - y_i \right) g_1(u_i) \\ \sum_{i=1}^m \left(2 \sum_{j=1}^n g_j(u_i) x_j - y_i \right) g_2(u_i) \\ \vdots \\ \sum_{i=1}^m \left(2 \sum_{j=1}^n g_j(u_i) x_j - y_i \right) g_n(u_i) \end{pmatrix}$$

- (1.5 puntos) Cálculo correcto de parte diferenciable
- (1.5 puntos) Cálculo correcto de parte no diferenciable

- (1 punto) Especificar que subgradiente es un vector

c) (3 pts) Suponga que se imponen ahora condiciones adicionales al problema y le indican que los pesos x deben tener valores que cumplan con la condición $|x_j| \leq 1, j = 1, \dots, n$ y se postula el problema:

$$\begin{aligned} \min \quad & \tau \|x\|_1 + \sum_{i=1}^m \left(\sum_{j=1}^n g_j(u_i) x_j - y_i \right)^2 \\ \text{s.a.} \quad & |x_j| \leq 1, j = 1, \dots, n \end{aligned}$$

Explique con claridad cómo manejaría las restricciones que aparecen ahora en el problema cuando aplique el Método del Subgradiente.

Solución: Se debe proyectar x en cada iteración del algoritmo sobre el conjunto $D = \{x : -1 \leq x_k \leq 1 \quad \forall k\}$. Se debe revisar que cada coordenada de x se encuentra en D , si esta cumple, se mantiene sin cambios, si es que no cumple, se le debe reasignar el valor de la variables x_k al valor más cercano en D , es decir, si $x_k < -1$ entonces x_k será -1 , si es que $x_k > 1$ entonces x_k será 1 . Esto se puede generalizar mediante la función:

$$\Pi D(x)_k = \begin{cases} x_k & \text{si } -1 \leq x_k \leq 1 \\ -1 & \text{si } x_k < -1 \\ 1 & \text{si } x_k > 1 \end{cases}$$

- (1 punto) Explicar que procedimiento se realiza en cada iteración
- (2 puntos) Explicación correcta del método de proyección

d) (4 pts) Suponga que otro equipo de investigación ha decidido abordar el problema de forma diferente y han planteado el siguiente problema:

$$\min_{x \in \mathbb{R}^n} \tau \sum_{j=1}^n x_j^4 + \sum_{i=1}^m \left(\sum_{j=1}^n g_j(u_i) x_j - y_i \right)^2$$

donde se ha usado una potencia 4 para castigar fuertemente a los $x_j \neq 0$. El equipo pregunta a un Chat de Inteligencia Artificial si acaso se puede usar un Método Simple de Primer Orden para este problema y la respuesta es:

“Sí, puedes usar un método simple o acelerado, la función objetivo es convexa y ∇F , donde F es la función objetivo, tiene propiedad de Lipschitz”

¿Está correcta la afirmación del chat? Discuta y Justifique con precisión sobre la base de los contenidos del curso.

Solución: La afirmación es falsa, si bien la función objetivo si es diferenciable, el gradiente no cumple con la propiedad de Lipschitz, ya que el hessiano de la función objetivo tendrá términos de orden x_k^2 y dado que este no es acotado superiormente en $\mathbb{R}^n$, el hessiano no será acotado y por ende no existirá la constante de Lipschitz L . También es posible argumentar directamente con la definición de Lipschitz, tal como está desarrollado en uno de los problemas de la tarea 1 o como se revisó en el taller.

- (1 punto) Mencionar que afirmación es FALSA
- (3 puntos) Argumentación correcta

Pregunta 3 (12 puntos + 3 de bono):

Como sabemos, una de las etapas complejas en los algoritmos de descenso es el “linesearch”, la búsqueda aproximada de un mínimo en la dirección de descenso. Esta es una etapa que consume recursos y querríamos simplificarla (o eliminarla, como en los métodos de primer orden), pero igual puede ser bueno conservar algo de las propiedades de un linesearch.

Supongamos, entonces, que estamos abordando el problema $\min_{x \in \mathbb{R}^n} f(x)$, para $f : \mathbb{R}^n \rightarrow \mathbb{R}$ función dos veces continuamente diferenciable y fuertemente convexa. Supongamos que estamos en la iteración k de un método de descenso y estamos en el punto x^k , y hemos determinado una dirección de descenso d^k (puede ser la del gradiente o la de Newton, no importa). Como usted sabe, el problema de linesearch es

$$PL) \quad \min_{\lambda \geq 0} f(x^k + \lambda d^k)$$

Se propone, entonces, reemplazar este problema de linesearch por un problema “sustituto” de la siguiente forma:

$$PS) \quad \min_{0 \leq \lambda \leq r} g_k(x^k + \lambda d^k)$$

donde

$$g_k(y) = f(x^k) + \nabla f(x^k)^T (y - x^k) + \frac{1}{2} (y - x^k)^T \nabla^2 f(x^k) (y - x^k)$$


y $r > 0$ es un parámetro determinado adecuadamente.

a) (3 pts) Explique qué es lo que hace el problema PS). Puede dar su explicación “en palabras”, apoyarse con un dibujo, pero no use más de cuatro líneas.

Solución:

El problema PS) consiste en encontrar un problema sustituto para PL), al aproximar la función f a una función cuadrática mediante su polinomio de Taylor de segundo orden, restringido en un intervalo $[0, r]$. Así, mediante este proceso se simplifica el cálculo al encontrar una función más sencilla de trabajar.

A continuación se muestra un ejemplo gráfico: Sea $f(x) = x^2 + e^x - 1$ y $g(x) = x + \frac{3}{2}x^2$ su expansión de Taylor de segundo orden en torno a $x^k = 0$ (nótese que f cumple con las hipótesis del enunciado):



Se logra apreciar una aproximación decente en torno a $x^k = 0$, sin embargo esta empeora a medida que nos alejamos del 0. Por esto nos restringimos a un intervalo acotado.

- (0.5 puntos) Reconocer que se sustituye el problema de linesearch por uno más sencillo.
- (2 puntos) Mencionar que se aproxima la función por una cuadrática usando el polinomio de Taylor de segundo orden.
- (0.5 puntos) Indicar que la minimización se restringe al intervalo $[0, r]$.

b) (3 pts) Demuestre que la solución óptima del problema PS) está dada por

$$\lambda^k = \min \left\{ -\frac{\nabla f(x^k)^T d^k}{(d^k)^T \nabla^2 f(x^k) d^k}, r \right\},$$

Justifique con claridad. (Note que la expresión es un mínimo de dos cosas).

Solución:

En primer lugar, desarrollamos la expresión de la función objetivo

$$\begin{aligned} g_k(x^k + \lambda d^k) &= f(x^k) + \nabla f(x^k)^T (x^k + \lambda d^k - x^k) + \frac{1}{2} (x^k + \lambda d^k - x^k)^T \nabla^2 f(x^k) (x^k + \lambda d^k - x^k) \\ &= f(x^k) + \nabla f(x^k)^T (\lambda d^k) + \frac{1}{2} (\lambda d^k)^T \nabla^2 f(x^k) (\lambda d^k) \\ &= f(x^k) + \lambda \nabla f(x^k)^T (d^k) + \frac{\lambda^2}{2} (d^k)^T \nabla^2 f(x^k) (d^k) \end{aligned}$$

Luego, notar que como la función g es fuertemente convexa (debido a que su Hessiano coincide con el de f), el mínimo se alcanza al derivar e igualar a 0.

Así, primero se calcula la derivada:

$$\frac{d}{d\lambda} g_k(x^k + \lambda d^k) = \nabla f(x^k)^T d^k + \lambda (d^k)^T \nabla^2 f(x^k) d^k$$

Imponiendo que esta sea igual a 0:

$$\begin{aligned} \nabla f(x^k)^T d^k + \lambda (d^k)^T \nabla^2 f(x^k) d^k &= 0 \\ \lambda (d^k)^T \nabla^2 f(x^k) d^k &= -\nabla f(x^k)^T d^k \\ \therefore \lambda^* &= -\frac{\nabla f(x^k)^T d^k}{(d^k)^T \nabla^2 f(x^k) d^k} \end{aligned}$$

Luego, notar que $0 \leq \lambda \leq r$, por lo que

$$\lambda^k = \min \left\{ -\frac{\nabla f(x^k)^T d^k}{(d^k)^T \nabla^2 f(x^k) d^k}, r \right\}$$

- (1 punto) Encontrar la expresión para g y su derivada.
- (1 punto) Despejar correctamente la expresión para encontrar λ^* .
- (1 punto) Mencionar que debido a como está acotado λ , el óptimo es el mínimo entre ambas expresiones.

c) (3 pts) Argumente que $(d^k)^T \nabla^2 f(x^k) d^k > 0$ y que λ^k dado por la expresión anterior, efectivamente es > 0 . Justifique con precisión y no use más de 5 líneas para su respuesta.

Solución:

Notar que, f es una función dos veces continuamente diferenciable y **fuertemente convexa**, por lo que su Hessiano es una matriz definida positiva. Esto quiere decir que para $d^k \neq 0$ se cumple, en particular que $(d^k)^\top \nabla^2 f(x^k) d^k > 0$.

Note que este hecho hace que el desarrollo del inciso anterior sea válido. Además, se tiene que d^k es dirección de descenso, luego por la Proposición de descenso para funciones diferenciables (visto en clases) se tiene que $\nabla f(x^k)^\top d^k < 0$.

Por lo tanto

$$\lambda^* = -\frac{\nabla f(x^k)^\top d^k}{(d^k)^\top \nabla^2 f(x^k) d^k} > 0.$$

Finalmente, dado que $r > 0$, $\lambda^k = \min\{\lambda^*, r\} > 0$.

- (1.5 puntos) Argumentar que, por la fuerte convexidad, el Hessiano es definido positivo.
- (1.5 puntos) Señalar que, como d^k es dirección de descenso, se cumple $\nabla f(x^k)^\top d^k < 0$.

d) (3 pts) Suponiendo que sabemos que calcular $\nabla f(x)$ requiere $O(n)$ flops y calcular $\nabla^2 f(x)$ requiere $O(n^2)$ flops, determine el esfuerzo computacional, en flops, en el que se debe incurrir para obtener λ^k . Sea claro con todas sus estimaciones y justifique con claridad.

Solución:

Para calcular

$$\lambda^k = -\frac{\nabla f(x^k)^T d^k}{(d^k)^T \nabla^2 f(x^k) d^k}$$

se desglosa el número de flops de cada operación:

- Calcular $\nabla f(x^k)$: $O(n)$
- Calcular $\nabla^2 f(x^k)$: $O(n^2)$
- $u = \nabla^2 f(x^k) d^k$: $O(n^2)$
- $s = (d^k)^\top u$: $O(n)$
- $m = \nabla f(x^k)^\top d^k$: $O(n)$.

- $\frac{m}{s} = \lambda^k : O(1)$.

El término dominante es la multiplicación matriz-vector $\nabla^2 f(x^k)d^k$, por lo que el esfuerzo total es $O(n^2)$.

- (1.5 puntos) Justificar mediante el cálculo del número de flops de cada término relevante (u, s, m) ; (0.5 c/u).
- (1.5 puntos) Concluir que el costo total es $O(n^2)$.

e) (3 pts de bono) El esquema presentado acá se conoce como “enfoque de región de confianza”. Explique bajo qué condiciones esto, efectivamente puede ser competitivo frente a hacer un linesearch tradicional. ¿En qué será que se “confía” y que da el nombre al enfoque?

Solución:

Este enfoque es competitivo frente a hacer un linesearch tradicional cuando el cálculo del modelo, para obtener el Hessiano de la función y por lo tanto λ^k requiere menos flops que evaluar repetidamente $f(x^k + \lambda d^k)$ en un linesearch. En particular, el Linesearch en general tiene un esfuerzo computacional de $O(kn)$ flops, donde k es el número de iteraciones. Luego si $k \gg n$ (ignorando constantes desconocidas) este enfoque es competitivo en términos del esfuerzo computacional.

Así, en este modelo se confía en que la aproximación es válida dentro de esta vecindad limitada alrededor del punto actual, dado el comportamiento de la función original. Esta confianza se controla mediante el parámetro r , donde si es muy pequeño, se “confía poco” en la aproximación y se toman pasos conservadores, mientras que si es muy grande se “confía mucho” en la aproximación y se permiten pasos más grandes. Iniciar cerca del óptimo no tiene relación con la confianza del modelo.

- (2 puntos) Mencionar que es competitivo cuando se reduce el número de flops respecto al linesearch tradicional.
- (1 punto) Explicar de dónde proviene el nombre, en que se “confía” en el modelo, mencionando la importancia del parámetro r .