



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025- 2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 1

Repaso de Conceptos Previos

07 de agosto de 2025

Resumen

Matriz transpuesta

Sea A una matriz de $\mathbb{R}^{m \times n}$ se define su matriz transpuesta $A^\top \in \mathbb{R}^{n \times m}$ como sigue:

$$A_{i,j}^\top = A_{j,i}$$

$\forall i \in \{1, 2, \dots, n\}$ y $\forall j \in \{1, 2, \dots, m\}$

Propiedades de la matriz transpuesta

$(A^\top)^\top = A$ para toda matriz $A \in \mathbb{R}^{m \times n}$.

$(A + B)^\top = A^\top + B^\top$ para toda matriz $A, B \in \mathbb{R}^{m \times n}$.

$(c \cdot A)^\top = c \cdot A^\top$ para todo numero $c \in \mathbb{R}$ y para toda matriz $A \in \mathbb{R}^{m \times n}$.

$(A \cdot B)^\top = B^\top \cdot A^\top$ para toda matriz $A \in \mathbb{R}^{m \times n}$ y para toda matriz $B \in \mathbb{R}^{n \times k}$.

$(Ax)^\top = x^\top A^\top$ para toda matriz $A \in \mathbb{R}^{m \times n}$ y para todo $x \in \mathbb{R}^n$.

Matriz simétrica

Sea $A \in \mathbb{R}^{n \times n}$ una matriz cualquiera. Se dice que es simétrica si:

$$A^\top = A$$

Norma euclidea

La norma euclidea de un vector $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ denotada por $\|x\|_2$ o simplemente por $\|x\|$ se define como sigue:

$$\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

Propiedades

- 1) $\|x\| = 0 \Leftrightarrow x = 0$
- 2) $\|x + y\| \leq \|x\| + \|y\| \forall x, y \in \mathbb{R}^n$
- 3) $\|\alpha \cdot x\| = |\alpha| \cdot \|x\| \forall \alpha \in \mathbb{R}, \forall x \in \mathbb{R}^n$

Un vector se dice unitario cuando su norma es 1.

Producto punto

Sea $u = (u_1, u_2, \dots, u_n) \in \mathbb{R}^n$ y $v = (v_1, v_2, \dots, v_n) \in \mathbb{R}^n$. Se define el producto punto entre u y v como sigue:

$$\langle u, v \rangle = u \cdot v = u^\top v = \sum_i^n u_i \cdot v_i$$

Propiedades del producto punto

- 1) $u \cdot v = v \cdot u \quad \forall u, v \in \mathbb{R}^n$.
- 2) $u \cdot (v_1 + v_2) = u \cdot v_1 + u \cdot v_2 \quad \forall u, v_1, v_2 \in \mathbb{R}^n$.
- 3) $\alpha(u \cdot v) = (\alpha u) \cdot v = u \cdot (\alpha v) \quad \forall u, v \in \mathbb{R}^n, \forall \alpha \in \mathbb{R}$.

Relación del producto punto con la norma

$$\|x\|_2 = \sqrt{x \cdot x} \quad \forall x \in \mathbb{R}^n$$

Desigualdad de Cauchy-Schwarz

$$|x \cdot y| \leq \|x\| \|y\| \quad \forall x, y \in \mathbb{R}^n$$

Matriz definida positiva

Sea A una matriz en $\mathbb{R}^{n \times n}$. Se dice que la matriz es definida positiva cuando $\forall u \in \mathbb{R}^n$ tal que $u \neq 0$:

$$u^\top A u > 0$$

Si el producto anterior es < 0 , entonces la matriz es definida negativa.

Matriz semi-definida positiva

Sea A una matriz en $\mathbb{R}^{n \times n}$. Se dice que la matriz es semi-definida positiva cuando $\forall u \in \mathbb{R}^n$:

$$u^\top A u \geq 0$$

Si el producto anterior es ≤ 0 , entonces la matriz es semi definida negativa.

Determinante de una matriz

Sea A una matriz en $\mathbb{R}^{n \times n}$. El determinante se puede calcular a través de una expansión por filas y columnas.

Primero, definiremos a $A^{i,j}$ como la matriz de $\mathbb{R}^{(n-1) \times (n-1)}$ que resulta al eliminar la fila i y la columna j de la matriz A .

La expansión por filas se calcula de la siguiente manera:

$$\det(A) = \sum_{k=1}^n (-1)^{i+k} a_{i,k} \cdot \det(A^{i,k}) \quad \forall i \in \{1, 2, \dots, n\}$$

Y la expansión por columnas se calcula de la siguiente manera:

$$\det(A) = \sum_{k=1}^n (-1)^{k+j} a_{k,j} \cdot \det(A^{k,j}) \quad \forall j \in \{1, 2, \dots, n\}$$

Propiedades del determinante

$\det(A) = \det(A^\top)$ para toda matriz $A \in \mathbb{R}^{n \times n}$.

$\det(A \cdot B) = \det(A) \cdot \det(B)$ para toda matriz $A, B \in \mathbb{R}^{n \times n}$.

Matriz Invertible

Una matriz invertible, es una matriz $A \in \mathbb{R}^{n \times n}$ (Matriz cuadrada), tal que existe una matriz $B \in \mathbb{R}^{n \times n}$ la cual cumpla que:

$$A \cdot B = I_n$$

Con I_n la matriz identidad que pertenece a $\mathbb{R}^{n \times n}$. La matriz B se escribe como A^{-1} y de denomina matriz inversa de A . Una matriz es inversa si y solo si su determinante es distinto de cero.

Propiedades

$(A^{-1})^\top = (A^\top)^{-1}$ para toda matriz $A \in \mathbb{R}^{m \times n}$ invertible.

$(A \cdot B)^{-1} = B^{-1}A$ para toda matriz $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{m \times n}$ invertibles.

$(A^{-1})^{-1} = A$ para toda matriz $A \in \mathbb{R}^{m \times n}$ invertible.

Derivada parcial

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Su derivada parcial en la variable i - esima se define como sigue:

$$\frac{\partial f(x)}{\partial x_i} = \frac{\partial f(x_1, \dots, x_n)}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) - f(x_1, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_n)}{h}$$

para todo $i \in \{1, 2, \dots, n\}$.

Gradiente

El gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

Matriz Hessiana

Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

Regla de la cadena

Consideremos un función $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

Sea $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ tal que: $x_1 = x_1(\lambda), x_2 = x_2(\lambda), \dots, x_n = x_n(\lambda)$, entonces tenemos que:

$$\begin{aligned} \frac{\partial f(x)}{\partial \lambda} &= \left(\frac{\partial f(x)}{\partial x_1} \right) \cdot \left(\frac{\partial x_1}{\partial \lambda} \right) + \left(\frac{\partial f(x)}{\partial x_2} \right) \cdot \left(\frac{\partial x_2}{\partial \lambda} \right) + \dots + \left(\frac{\partial f(x)}{\partial x_n} \right) \cdot \left(\frac{\partial x_n}{\partial \lambda} \right) \\ &= \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right) \begin{pmatrix} \frac{\partial x_1}{\partial \lambda} \\ \frac{\partial x_2}{\partial \lambda} \\ \vdots \\ \frac{\partial x_n}{\partial \lambda} \end{pmatrix} = [\nabla f(x)]^\top \left(\frac{\partial x}{\partial \lambda} \right) = \nabla f(x) \cdot \left(\frac{\partial x}{\partial \lambda} \right) \end{aligned}$$

De manera más compacta podemos decir que:

$$\frac{\partial f(x)}{\partial \lambda} = [\nabla f(x)]^\top \left(\frac{\partial x}{\partial \lambda} \right)$$

Máximos y mínimos

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función. Un punto crítico x_0 de f cumple que f no es diferenciable en x_0 o bien:

$$\nabla f(x_0) = 0.$$

La naturaleza del punto crítico x_0 depende de la matriz hessiana $\nabla^2 f(x_0)$:

- x_0 es un **mínimo local** si $\nabla^2 f(x_0)$ es definida positiva.
- x_0 es un **máximo local** si $\nabla^2 f(x_0)$ es definida negativa.
- x_0 es un **punto de silla** en caso contrario.

Multiplicadores de Lagrange

Los multiplicadores de Lagrange se utilizan para resolver problemas de optimización con restricciones.

Con una restricción

Consideremos el problema:

$$\text{mín / máx } f(x) \quad \text{s.a.} \quad g_1(x) = \alpha_1,$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g_1 : \mathbb{R}^n \rightarrow \mathbb{R}$.

Se define la función:

$$h(x, \lambda_1) = f(x) - \lambda_1[\alpha_1 - g_1(x)].$$

Los valores extremos del problema cumplen:

$$\nabla_x h(x, \lambda_1) = 0, \quad g_1(x) = \alpha_1.$$

Resolviendo este sistema se obtiene el punto crítico x y el multiplicador λ_1 .

Con m restricciones

Consideremos ahora el problema:

$$\text{mín / máx } f(x) \quad \text{s.a.} \quad g_i(x) = \alpha_i, \quad \forall i \in \{1, 2, \dots, m\},$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$ para todo i .

Esto se puede escribir en forma vectorial:

$$\text{mín / máx } f(x) \quad \text{s.a.} \quad A(x) = \alpha,$$

donde:

$$A(x) = \begin{pmatrix} g_1(x) \\ \vdots \\ g_m(x) \end{pmatrix} \in \mathbb{R}^m, \quad \alpha = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix} \in \mathbb{R}^m.$$

Se define la función de Lagrange como:

$$h(x, \lambda) = f(x) - \sum_{i=1}^m \lambda_i [\alpha_i - g_i(x)] = f(x) - \lambda^\top (A(x) - \alpha),$$

con $\lambda \in \mathbb{R}^m$.

Los puntos extremos satisfacen:

$$\nabla_x h(x, \lambda) = 0, \quad \nabla_\lambda h(x, \lambda) = 0.$$

Dado que:

$$\nabla_\lambda h(x, \lambda) = -[A(x) - \alpha],$$

la segunda condición implica:

$$A(x) = \alpha.$$

Vectores y valores propios

Definición de vector y valor propio

Un vector propio v y su respectivo valor propio λ de una matriz $A \in \mathbb{R}^{n \times n}$ satisfacen:

$$Av = \lambda v.$$

¿Cómo determinar un valor propio?

Se resuelve la ecuación característica:

$$\det(A - \lambda I) = 0.$$

¿Cómo determinar un vector propio?

Una vez encontrado un valor propio λ , se resuelve el sistema:

$$(A - \lambda I)v = 0.$$

Relación entre valores propios y la naturaleza de la matriz

Sean $\lambda_1, \lambda_2, \dots, \lambda_n$ los valores propios de A , entonces:

- Si $\lambda_i > 0$ para todo i , entonces A es **definida positiva**.
- Si $\lambda_i \geq 0$ para todo i , entonces A es **semidefinida positiva**.
- Si $\lambda_i < 0$ para todo i , entonces A es **definida negativa**.
- Si $\lambda_i \leq 0$ para todo i , entonces A es **semidefinida negativa**.

Singularidad e invertibilidad de una matriz

Sean $\lambda_1, \lambda_2, \dots, \lambda_n$ los valores propios de A . Entonces:

- Si existe i tal que $\lambda_i = 0$, entonces A es **singular**, es decir, A **no es invertible**.

Modelos de Optimización: Estructura Básica

La optimización busca la mejor solución entre varias alternativas. Los modelos matemáticos de optimización buscan maximizar o minimizar una función objetivo sujeta a restricciones.

Elementos Clave:

1. **Función Objetivo:** Define la medida de desempeño a optimizar y es una expresión matemática de las variables de decisión.
2. **Variables de Decisión:** Son las incógnitas a determinar para optimizar la función objetivo, pueden ser continuas, enteras o binarias.
3. **Conjuntos:** Definen los conjuntos a los que pertenecen las variables y parámetros.
4. **Parámetros:** Constantes que afectan la función objetivo o las restricciones, representando costos, ingresos, tiempos, etc.
5. **Restricciones:** Limitan las soluciones al sistema, pueden ser igualdades o desigualdades, representando limitaciones en recursos, capacidades, relación entre variables, etc.

Formulación Matemática:

El modelo de optimización se expresa en nivel general como:

$$\begin{aligned} & \max/\min f(x) \\ & \text{s.a } g_i(x) \leq b_i, \quad i = 1, 2, \dots, m \\ & x_j \in X_j, \quad j = 1, 2, \dots, n \end{aligned}$$

Donde:

$f(x)$ es la función objetivo.

$g_i(x)$ son las restricciones.

b_i es el coeficiente (parámetro) asociado a la restricción

X_j es el conjunto de la variable x_j .

Se busca un conjunto de valores para las variables de decisión que optimicen la función objetivo, cumpliendo con todas las restricciones.

Ejercicio 1

Considere $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica, c un vector en $\mathbb{R}^n$ y $d \in \mathbb{R}$ una constante. Sea la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ la cual se define como sigue:

$$f(x) = x^\top Q x + c^\top x + d$$

- (a) Utilice sumatorias para expresar la función $f(x)$.

Solución: Veamos la expresión por partes.

Sea

$$Q = \begin{bmatrix} Q_{1,1} & Q_{1,2} & \cdots & Q_{1,n} \\ Q_{2,1} & Q_{2,2} & \cdots & Q_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ Q_{n,1} & Q_{n,2} & \cdots & Q_{n,n} \end{bmatrix}$$

Definimos los siguientes vectores fila:

$$Q_i = \begin{bmatrix} Q_{i,1} \\ Q_{i,2} \\ \vdots \\ Q_{i,n} \end{bmatrix} \quad \forall i \in \{1, 2, \dots, n\}$$

Así tenemos que:

$$Q = \begin{bmatrix} Q_1^\top \\ Q_2^\top \\ \vdots \\ Q_n^\top \end{bmatrix}$$

De este modo:

$$Qx = \begin{bmatrix} Q_1^\top x \\ Q_2^\top x \\ \vdots \\ Q_n^\top x \end{bmatrix}$$

Así tenemos que la i -ésima fila de Qx es:

$$(Qx)_i = Q_i^\top x = \sum_{j=1}^n Q_{j,i} \cdot x_j$$

Como Qx es un vector y $(Qx)_i$ es la i -ésima fila de Qx , entonces:

$$x^\top Qx = \sum_{i=1}^n x_i (Qx)_i = \sum_{i=1}^n x_i \sum_{j=1}^n Q_{j,i} \cdot x_j$$

Como x_i no depende de j , entonces x_i puede pasar multiplicando a la sumatoria que toma j . Así tenemos que:

$$x^\top Qx = \sum_{i=1}^n x_i \sum_{j=1}^n Q_{j,i} \cdot x_j = \sum_{i=1}^n \sum_{j=1}^n x_i \cdot Q_{j,i} \cdot x_j$$

Finalmente, tenemos que:

$$x^\top Qx = \sum_{i=1}^n \sum_{j=1}^n x_i \cdot Q_{j,i} \cdot x_j$$

Por otra parte tenemos que:

$$c^\top x = \sum_{i=1}^n c_i x_i$$

Con lo que:

$$f(x) = x^\top Qx + c^\top x + d = \sum_{i=1}^n \sum_{j=1}^n x_i \cdot Q_{j,i} \cdot x_j + \sum_{i=1}^n c_i x_i + d$$

(b) Calcule el gradiente de $f(x)$.

Solución: Calcularemos la k -ésima derivada parcial de $f(x)$ para un $k \in \{1, 2, \dots, n\}$.

Del ejercicio anterior tenemos que:

$$\begin{aligned} x^\top Qx &= \sum_{i=1}^n \sum_{j=1}^n x_i \cdot Q_{j,i} \cdot x_j = \sum_{i=1}^n \left(\sum_{j=1}^n x_i \cdot Q_{j,i} \cdot x_j \right) \\ &= \sum_{i=1}^n \left(\sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + x_i \cdot Q_{k,i} \cdot x_k \right) \\ &= \sum_{i=1:i \neq k}^n \left(\sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + x_i \cdot Q_{k,i} \cdot x_k \right) + \left(\sum_{j=1:j \neq k}^n x_k \cdot Q_{j,k} \cdot x_j + x_k \cdot Q_{k,k} \cdot x_k \right) \\ &= \sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k + \sum_{j=1:j \neq k}^n x_k \cdot Q_{j,k} \cdot x_j + x_k \cdot Q_{k,k} \cdot x_k \end{aligned}$$

De forma análoga, podemos llegar a que:

$$\begin{aligned}
f(x) &= x^\top Qx + c^\top x + d \\
&= \sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k + \sum_{j=1:j \neq k}^n x_k \cdot Q_{j,k} \cdot x_j + x_k \cdot Q_{k,k} \cdot x_k \\
&\quad + \sum_{i=1:i \neq k}^n c_i x_i + c_k x_k + d
\end{aligned}$$

Como Q es simétrica, entonces: $Q_{j,k} = Q_{k,j}$. De este modo:

$$\sum_{j=1:j \neq k}^n x_k \cdot Q_{j,k} \cdot x_j = \sum_{j=1:j \neq k}^n x_k \cdot Q_{k,j} \cdot x_j = \sum_{i=1:i \neq k}^n x_k \cdot Q_{k,i} \cdot x_i$$

Así tenemos que:

$$\begin{aligned}
f(x) &= \sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k + \sum_{j=1:j \neq k}^n x_k \cdot Q_{j,k} \cdot x_j + x_k \cdot Q_{k,k} \cdot x_k \\
&\quad + \sum_{i=1:i \neq k}^n c_i x_i + c_k x_k + d \\
&= \sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k + \sum_{i=1:i \neq k}^n x_k \cdot Q_{k,i} \cdot x_i + x_k \cdot Q_{k,k} \cdot x_k \\
&\quad + \sum_{i=1:i \neq k}^n c_i x_i + c_k x_k + d \\
&= \sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + 2 \cdot \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k + x_k \cdot Q_{k,k} \cdot x_k + \sum_{i=1:i \neq k}^n c_i x_i + c_k x_k + d
\end{aligned}$$

Así llegamos a que:

$$f(x) = \sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + 2 \cdot \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k + Q_{k,k} \cdot (x_k)^2 + \sum_{i=1:i \neq k}^n c_i x_i + c_k x_k + d$$

Ahora, calcularemos la k -ésima derivada parcial:

$$\begin{aligned}
\frac{\partial f(x)}{\partial x_k} &= \frac{\partial}{\partial x_k} \left(\sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j + 2 \cdot \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k + Q_{k,k} \cdot (x_k)^2 + \sum_{i=1:i \neq k}^n c_i x_i + c_k x_k \right) \\
&= \frac{\partial}{\partial x_k} \left(\sum_{i=1:i \neq k}^n \sum_{j=1:j \neq k}^n x_i \cdot Q_{j,i} \cdot x_j \right) + 2 \cdot \frac{\partial}{\partial x_k} \left(\sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} \cdot x_k \right) + \frac{\partial}{\partial x_k} (Q_{k,k} \cdot (x_k)^2) \\
&\quad + \frac{\partial}{\partial x_k} \left(\sum_{i=1:i \neq k}^n c_i x_i \right) + \frac{\partial}{\partial x_k} (c_k x_k) + \frac{\partial}{\partial x_k} (d) \\
&= 2 \cdot \sum_{i=1:i \neq k}^n x_i \cdot Q_{k,i} + 2 \cdot Q_{k,k} \cdot x_k + c_k = 2 \cdot \sum_{i=1}^n x_i \cdot Q_{k,i} + c_k = 2 \cdot (Q_k)^\top x + c_k
\end{aligned}$$

Así tenemos que:

$$\frac{\partial f}{\partial x_k} = 2 \cdot (Q_k)^\top x + c_k$$

De este manera, tenemos que:

$$\begin{aligned}
\nabla f(x) &= \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix} = \begin{bmatrix} 2 \cdot (Q_1)^\top x \\ 2 \cdot (Q_2)^\top x \\ \vdots \\ 2 \cdot (Q_n)^\top x \end{bmatrix} + \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} = 2 \cdot \begin{bmatrix} (Q_1)^\top x \\ (Q_2)^\top x \\ \vdots \\ (Q_n)^\top x \end{bmatrix} + c \\
&= 2 \cdot \begin{bmatrix} (Q_1)^\top \\ (Q_2)^\top \\ \vdots \\ (Q_n)^\top \end{bmatrix} x + c = 2Qx + c
\end{aligned}$$

Finalmente llegamos a que:

$$\nabla f(x) = 2Qx + c$$

(c) Calcule la matriz Hessiana de $f(x)$.

Solución: Del ejercicio anterior tenemos que:

$$\frac{\partial f}{\partial x_k} = 2 \cdot (Q_k)^\top x + c_k = 2 \cdot \sum_{i=1}^n Q_{k,i} x_i = 2 \cdot \sum_{i=1:i \neq h}^n Q_{k,i} x_i + 2Q_{k,h} x_h + c_k$$

Ahora calcularemos el elemento en la fila h y en la columna k de la matriz hessiana. Es decir:

$$\begin{aligned}\frac{\partial^2 f(x)}{\partial x_h \partial x_k} &= \frac{\partial}{\partial x_h} \left(\frac{\partial f(x)}{\partial x_k} \right) = \frac{\partial}{\partial x_h} \left(2 \cdot \sum_{i=1:i \neq h}^n Q_{k,i} x_i + 2Q_{k,h} x_h + c_k \right) \\ &= \frac{\partial}{\partial x_h} \left(2 \cdot \sum_{i=1:i \neq h}^n Q_{k,i} x_i \right) + \frac{\partial}{\partial x_h} (2Q_{k,h} x_h) + \frac{\partial}{\partial x_h} (c_k) = \frac{\partial}{\partial x_h} (2Q_{k,h} x_h) = 2Q_{k,h}\end{aligned}$$

De este modo, tenemos que $[\nabla^2 f(x)]_{h,k} = 2Q_{k,h}$. Pero como Q es simétrica, entonces $Q_{k,h} = Q_{h,k}$. Así obtenemos que $[\nabla^2 f(x)]_{h,k} = 2Q_{h,k}$. De este forma, la matriz hessiana es la siguiente:

$$\nabla^2 f(x) = \begin{bmatrix} 2Q_{1,1} & 2Q_{1,2} & \cdots & 2Q_{1,n} \\ 2Q_{2,1} & 2Q_{2,2} & \cdots & 2Q_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ 2Q_{n,1} & 2Q_{n,2} & \cdots & 2Q_{n,n} \end{bmatrix} = 2 \begin{bmatrix} Q_{1,1} & Q_{1,2} & \cdots & Q_{1,n} \\ Q_{2,1} & Q_{2,2} & \cdots & Q_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ Q_{n,1} & Q_{n,2} & \cdots & Q_{n,n} \end{bmatrix} = 2Q$$

Así finalmente obtuvimos que:

$$\nabla^2 f(x) = 2Q$$

Ejercicio 2

En estadística, se utiliza un modelo matemático para explicar la relación entre una variable dependiente y y un conjunto de n variables independientes $X_1, X_2, \dots, X_n$, junto con un término de error ε que captura las discrepancias no explicadas por el modelo. La forma general del modelo lineal es:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon$$

Cuando se dispone de m observaciones, el modelo para cada observación $i \in \{1, 2, \dots, m\}$ se expresa como:

$$y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_n x_{i,n} + \varepsilon_i$$

Este sistema puede escribirse de manera compacta en notación matricial:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & x_{1,2} & \cdots & x_{1,n} \\ 1 & x_{2,1} & x_{2,2} & \cdots & x_{2,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m,1} & x_{m,2} & \cdots & x_{m,n} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_n \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_m \end{bmatrix}$$

Definimos:

$$Y \in \mathbb{R}^m, \quad X \in \mathbb{R}^{m \times (n+1)}, \quad \beta \in \mathbb{R}^{n+1}, \quad \varepsilon \in \mathbb{R}^m$$

De modo que el modelo puede resumirse como:

$$Y = X\beta + \varepsilon$$

El objetivo fundamental en este contexto consiste en estimar los coeficientes $\beta_0, \beta_1, \dots, \beta_n$ de forma tal que el error total del modelo, representado por ε , sea lo más pequeño posible. Es decir, se busca encontrar el vector β que minimice una medida del error, como por ejemplo, la suma de los errores cuadráticos:

$$\min_{\beta} \|Y - X\beta\|^2$$

Esta formulación corresponde al método de los mínimos cuadrados ordinarios, ampliamente utilizado para ajustar modelos lineales a los datos observados.

- (a) **(Propuesto)** ¿Es equivalente minimizar la norma de ε a minimizar la norma al cuadrado de ε ? Justifique.

Solución: Sea $f(x) = x^2$ y $g(x) = x$. Decimos que minimizar ambas funciones es equivalente si:

$$f(x_1) < f(x_2) \Leftrightarrow g(x_1) < g(x_2)$$

Como $g(x) = x$, entonces:

$$f(x_1) < f(x_2) \Leftrightarrow x_1 < x_2$$

Esto es cierto cuando $f(x)$ es creciente. Como $f'(x) = 2x$, entonces $f(x)$ es creciente cuando $x > 0$. Como:

$$\varepsilon = Y - X\beta$$

Y no existe β tal que $\varepsilon = 0$, entonces $\|\varepsilon\| > 0$. Por lo tanto, minimizar $\|\varepsilon\|$ es equivalente a minimizar $\|\varepsilon\|^2$.

- (b) Dé una expresión para la norma al cuadrado de ε en función de X, Y y β . ¿Qué tipo de función es? ¿Cuál es la variable?

Solución: Notemos que

$$\|\varepsilon\|^2 = \varepsilon^\top \varepsilon = (Y - X\beta)^\top (Y - X\beta)$$

Expandiendo:

$$\|\varepsilon\|^2 = Y^\top Y - 2Y^\top X\beta + \beta^\top X^\top X\beta$$

Esto es una función cuadrática en β , de la forma:

$$f(\beta) = \beta^\top Q\beta + c^\top \beta + d$$

con:

$$Q = X^\top X, \quad c = -2X^\top Y, \quad d = Y^\top Y$$

y Q es simétrica, ya que $Q^\top = (X^\top X)^\top = X^\top X$. Esta forma es tal cómo la que se revisó en el Ejercicio 1.

- (c) Calcule el gradiente y la matriz hessiana de la función anterior (con β como variable).

Solución: La función es:

$$f(\beta) = \beta^\top X^\top X\beta - 2Y^\top X\beta + Y^\top Y$$

Entonces:

$$\nabla f(\beta) = 2X^\top X\beta - 2X^\top Y$$

Y la matriz hessiana es:

$$\nabla^2 f(\beta) = 2X^\top X$$

(d) ¿Cuál es la naturaleza de la matriz hessiana?

Solución: La matriz hessiana es:

$$\nabla^2 f(\beta) = 2X^\top X$$

Como se asume que las columnas de X son linealmente independientes, entonces $X^\top X$ es definida positiva. Por lo tanto:

$$\nabla^2 f(\beta)$$

es definida positiva.

(e) Calcule la solución óptima (con β como variable).

Solución: Buscamos minimizar $\|\varepsilon\|^2$. Como:

$$\nabla f(\beta) = 2X^\top X\beta - 2X^\top Y$$

El punto crítico se obtiene igualando el gradiente a cero:

$$0 = 2X^\top X\beta - 2X^\top Y \Rightarrow X^\top X\beta = X^\top Y$$

Como $X^\top X$ es invertible:

$$\beta = (X^\top X)^{-1} X^\top Y$$

Y dado que la hessiana es definida positiva, este punto crítico es un mínimo. Por lo tanto:

$$\beta^* = (X^\top X)^{-1} X^\top Y$$

Ejercicios Propuestos

Ejercicio 1

Consideremos el siguiente problema de optimización:

$$\max c^\top x \quad \text{s.a.} \quad x^\top Qx \leq 1,$$

donde $c \in \mathbb{R}^n$ y $Q \in \mathbb{R}^{n \times n}$ es simétrica definida positiva.

- (a) Calcule la función lagrangiana asociada.

Solución: La función lagrangiana se define como:

$$f(x, \lambda) = c^\top x - \lambda(x^\top Qx - 1) = c^\top x - \lambda x^\top Qx + \lambda.$$

- (b) Plantee las condiciones que deben cumplir los puntos críticos.

Solución: Calculamos el gradiente respecto de x :

$$\nabla_x f(x, \lambda) = \nabla_x (c^\top x - \lambda x^\top Qx + \lambda) = c - 2\lambda Qx.$$

Derivando respecto de λ :

$$\frac{\partial f(x, \lambda)}{\partial \lambda} = -x^\top Qx + 1.$$

Entonces las condiciones de punto crítico son:

$$\begin{cases} c = 2\lambda Qx, \\ x^\top Qx = 1. \end{cases}$$

- (c) Calcule los puntos críticos.

Solución: De la primera ecuación: $c = 2\lambda Qx \Rightarrow x = \frac{1}{2\lambda} Q^{-1}c$.

Reemplazamos en la segunda ecuación:

$$1 = \left(\frac{1}{2\lambda} Q^{-1}c \right)^\top Q \left(\frac{1}{2\lambda} Q^{-1}c \right) = \frac{1}{4\lambda^2} c^\top Q^{-1} Q Q^{-1} c = \frac{1}{4\lambda^2} c^\top Q^{-1} c.$$

Multiplicando ambos lados por $4\lambda^2$:

$$4\lambda^2 = c^\top Q^{-1}c \Rightarrow \lambda = \pm \frac{\sqrt{c^\top Q^{-1}c}}{2}.$$

Entonces hay dos posibles puntos críticos:

- Para $\lambda_1 = \frac{\sqrt{c^\top Q^{-1}c}}{2}$:

$$x_1 = \frac{1}{2\lambda_1}Q^{-1}c = \frac{Q^{-1}c}{\sqrt{c^\top Q^{-1}c}}.$$

- Para $\lambda_2 = -\frac{\sqrt{c^\top Q^{-1}c}}{2}$:

$$x_2 = \frac{1}{2\lambda_2}Q^{-1}c = -\frac{Q^{-1}c}{\sqrt{c^\top Q^{-1}c}}.$$

(d) Calcule la solución óptima.

Solución: Buscamos maximizar $c^\top x$. Evaluamos en ambos puntos:

- Para x_1 :

$$c^\top x_1 = c^\top \left(\frac{Q^{-1}c}{\sqrt{c^\top Q^{-1}c}} \right) = \frac{c^\top Q^{-1}c}{\sqrt{c^\top Q^{-1}c}} = \sqrt{c^\top Q^{-1}c}.$$

- Para x_2 :

$$c^\top x_2 = -\sqrt{c^\top Q^{-1}c}.$$

Por lo tanto, el máximo se alcanza en x_1 y la solución óptima es:

$$x^* = \frac{Q^{-1}c}{\sqrt{c^\top Q^{-1}c}}.$$

Ejercicio 2

- (a) Considere la siguiente descripción de un problema que se presenta frecuentemente en programación de operaciones en los más diversos ámbitos industriales:

Tenemos que realizar n trabajos, los cuales se pueden hacer en cualesquiera de m máquinas. El trabajo j requiere de t_j horas para ser realizado (independientemente de la máquina en que se haga). Si se asignan algunos trabajos a una máquina, esta terminará de trabajar en un tiempo igual a la suma de los tiempos de los trabajos que se asignaron. Ese tiempo, que denotaremos γ_i , para la máquina i , se llama “tardanza” (tardiness, es el término que se usa en Inglés). Existen pesos $w_i > 0$ asociados a cada máquina y queremos encontrar una forma de asignar los trabajos a las distintas máquinas de modo tal que se minimice la “tardanza ponderada total” (total weighted tardiness), dada por $\sum_{i=1}^m w_i \gamma_i$. Adicionalmente, existe el requisito de que cada máquina debe trabajar un tiempo total mínimo de R_{min} horas. Notemos que, una vez asignados algunos trabajos a una máquina, da lo mismo el orden en que se hagan, la tardanza de esa máquina es la misma y la asignación es válida, mientras cumpla el mínimo de horas.

La siguiente figura muestra un ejemplo de 5 trabajos asignados a 2 máquinas (llamadas M1 y M2), con un tiempo mínimo de trabajo $R_{min} = 5$ horas, y con una tardanza ponderada total igual a 69.

$M_1, w_1 = 5$	$t_1 = 2,5$	$t_4 = 8,5$			$\gamma_1 = 11$
$M_2, w_2 = 2$	$t_2 = 2,0$	$t_3 = 2,0$	$t_5 = 3,0$		$\gamma_2 = 7$

Se le solicita confeccionar un modelo de programación lineal que permita minimizar la tardanza ponderada.

Solución: Para construir el modelo, definamos variables x_{ij} que valen 1 si el trabajo j es asignado a la máquina i . Se propone el siguiente modelo:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m w_i \sum_{j=1}^n t_j x_{ij} \\ \text{s. a.} \quad & \sum_{j=1}^n t_j x_{ij} \geq R_{min} \quad i = 1, \dots, m \end{aligned} \quad (1)$$

$$\sum_{i=1}^m x_{ij} = 1 \quad j = 1, \dots, n \quad (2)$$

$$x_{ij} \in \{0, 1\} \quad i = 1, \dots, m; j = 1, \dots, n \quad (3)$$

La función objetivo minimiza la tardanza ponderada ya que γ_i es, precisamente, igual a $\sum_{j=1}^n t_j x_{ij}$ y no es necesario usar explícitamente las variables γ_i . La restricción (1)

asegura el cumplimiento de tiempo mínimo de trabajo en cada máquina, la (2) obliga a que cada trabajo sea realizado por exactamente una máquina y (3) es la naturaleza de variables.

- (b) Vamos a considerar la situación de una compañía de transportes del tipo “ridesharing” (como las que operan a través de plataformas de Internet), la que quiere planificar la cantidad de conductores que debe tener en cada zona para satisfacer la demanda. Vamos a suponer que hay n zonas y existe una demanda estimada de viajes igual a $d_j^\top$ en la zona j en el periodo t . Los conductores (en sus autos) operan en ciertas zonas pero pueden ser movidos de una zona a otra (reposicionamiento, se llama esto) y esto tiene un costo de $c_{ij}^\top$ por conductor que se mueve entre la zona i y la zona j en el periodo t . Existe un beneficio $\alpha_j^\top$ por conductor, por cubrir viajes en la zona j en el periodo t . Además, cada vez que se reposicionan conductores desde la zona j , se incurre en un costo fijo igual a $f_j^\top$ en el periodo t , independientemente de la cantidad de conductores reposicionados e independientemente de su destino. Suponemos que cada conductor atiende un solo viaje. El contrato con los conductores de los autos especifica ciertos límites a la cantidad de reposicionamientos que se pueden hacer por periodo de tiempo, siendo igual a $G^\top$ para el periodo t . Igualmente, en cada periodo existen ciertas zonas en las que no puede haber reposicionamiento de conductores si los hay en otra. Esto se describe con un conjunto $E_j^\top$ para la zona j en el periodo t .

La empresa quiere determinar las cantidades de conductores a reposicionar entre las zonas de modo de maximizar la utilidad neta y para esto, ha construido el siguiente modelo:

El modelo empleado es el siguiente:

$$\begin{aligned}
 \text{máx} \quad & \sum_{t=1}^T \sum_{j=1}^n \alpha_j^\top u_j^\top - \sum_{t=1}^T \sum_{j=1}^n \sum_{i=1, i \neq j}^n c_{ij}^\top x_{ij}^\top - \sum_{t=1}^T \sum_{j=1}^n f_j^\top z_j^\top \\
 \text{s. a.} \quad & u_j^\top = u_j^{t-1} + \sum_{i=1, i \neq j}^n x_{ij}^\top - \sum_{i=1, i \neq j}^n x_{ji}^\top & j = 1, \dots, n; t = 1, \dots, T \quad (1) \\
 & u_j^\top \leq d_j^\top & j = 1, \dots, n; t = 1, \dots, T \quad (2) \\
 & \sum_{i=1, i \neq j}^n x_{ji}^\top \leq M z_j^\top & j = 1, \dots, n; t = 1, \dots, T \quad (3) \\
 & \sum_{j=1}^n z_j^\top \leq G^\top & t = 1, \dots, T \quad (4) \\
 & \sum_{i \in E_j^\top} z_i^\top \leq n(1 - z_j^\top) & j = 1, \dots, n; t = 1, \dots, T \quad (5) \\
 & z_j^\top \in \{0, 1\}, x_{ij}^\top \geq 0, u_j^\top \geq 0 & j = 1, \dots, n; t = 1, \dots, T \quad (6)
 \end{aligned}$$

donde las cantidades u_j^0 corresponden al número de conductores iniciales en cada zona y los asumimos conocidos (no son igual a cero, si no, no habría conductores para atender a los pasajeros). El número M es una constante “suficientemente grande”.

Interprete claramente el significado de las variables, función objetivo y restricciones del modelo.

Solución: Las variables corresponden a:

$x_{ij}^\top$: cantidad de conductores reposicionados desde la zona i a la zona j en el periodo t .

$u_j^\top$: cantidad de conductores disponibles en la zona j en el periodo t .

$z_j^\top$: variable binaria que vale 1 si se reposicionan conductores de la zona j en t .

En cuanto a la función objetivo, maximiza el beneficio total en las zonas y periodos de tiempo por cubrimiento de los conductores, menos los costos de movimiento de los conductores y el costo fijo por reposición.

Las restricciones (1) hacen el balance de conductores disponibles en una zona, considerando los que han llegado de otras zonas y los que van a otras zonas (suponemos que los reposicionamientos se hacen al comienzo del periodo); las restricciones (2) establecen que el número de conductores en la zona no debe ser mayor a la demanda (notar que no necesariamente cumplimos demanda, todo es un tema de maximizar utilidades); las (3) activan las variables binarias si hay reposicionamientos a otras zonas; las (4) imponen el límite de veces que se pueden hacer reposicionamientos y, las (5), establecen que si la zona j hace reposicionamientos, las zonas en el conjunto $E_j^\top$ no pueden. Finalmente, (6) establece la naturaleza de las variables.

Ejercicio 3

- (a) Sea $f(x) = x^\top Qx$, con $Q \in \mathbb{R}^{n \times n}$ matriz simétrica semidefinida positiva. Muestre que $f(x)$ es una función convexa.

Solución: Queremos mostrar que:

$$\alpha f(x) + (1 - \alpha)f(y) \geq f(\alpha x + (1 - \alpha)y), 0 \leq \alpha \leq 1$$

Una aproximación a la función, centrada en x , es:

$$\sum_{n=0}^{\infty} \frac{1}{n!} \frac{\partial^n f(x)}{\partial x^n} \Delta x^n, \quad \text{Expansión o Serie de Taylor}$$

con n multi-índice.

Para este caso particular, tenemos que,

$$f(x + \Delta x) = f(x) + \Delta x^\top \nabla f(x) + \frac{1}{2} \Delta x^\top \nabla^2 f(x) \Delta x,$$

dado que,

$$\frac{\partial^n f(x)}{\partial x^n} = 0, \forall n \geq 3$$

Reemplazando,

$$f(y) = f(x) + 2(y - x)^\top Qx + (y - x)^\top Q(y - x)$$

Evaluable el lado izquierdo de la desigualdad, obtenemos,

$$\alpha f(y) + (1 - \alpha)f(x) = f(x) + 2\alpha(y - x)^\top Qx + \alpha(y - x)^\top Q(y - x)$$

Evaluable el lado derecho, logramos,

$$f(\alpha y + (1 - \alpha)x) = f(x) + 2\alpha(y - x)^\top Qx + \alpha^2(y - x)^\top Q(y - x)$$

Dado que $0 \leq \alpha \leq 1$, resulta evidente que,

$$\alpha f(y) + (1 - \alpha)f(x) - f(\alpha y + (1 - \alpha)x) = \alpha(y - x)^\top Q(y - x) - \alpha^2(y - x)^\top Q(y - x) \geq 0$$

Así,

$$\alpha f(x) + (1 - \alpha)f(y) \geq f(\alpha x + (1 - \alpha)y), 0 \leq \alpha \leq 1$$

Por lo que se prueba que la función es convexa.

(b) Sean $A, B \in \mathbb{R}^{n \times n}$ matrices. Demuestre que:

$$\|AB\|_F \leq \|A\|_F \cdot \|B\|_F,$$

donde $\|M\|_F$ denota la norma de Frobenius de la matriz M .

Solución: Recordemos que, para una matriz $M \in \mathbb{R}^{m \times n}$, la norma de Frobenius está dada por:

$$\|M\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n M_{ij}^2}.$$

Entonces, para el producto $AB \in \mathbb{R}^{n \times n}$, tenemos:

$$\|AB\|_F^2 = \sum_{i=1}^n \sum_{j=1}^n \left(\sum_{k=1}^n A_{ik} B_{kj} \right)^2.$$

Aplicamos la desigualdad de Cauchy-Bunyakovsky-Schwarz (Cauchy-Schwarz) a cada término del doble sumatorio:

$$\left(\sum_{k=1}^n A_{ik} B_{kj} \right)^2 \leq \left(\sum_{k=1}^n A_{ik}^2 \right) \left(\sum_{k=1}^n B_{kj}^2 \right).$$

Entonces,

$$\|AB\|_F^2 \leq \sum_{i=1}^n \sum_{j=1}^n \left(\sum_{k=1}^n A_{ik}^2 \right) \left(\sum_{k=1}^n B_{kj}^2 \right).$$

Notamos que $\sum_{k=1}^n A_{ik}^2$ no depende de j , y $\sum_{k=1}^n B_{kj}^2$ no depende de i . Entonces podemos reordenar la suma:

$$\|AB\|_F^2 \leq \left(\sum_{i=1}^n \sum_{k=1}^n A_{ik}^2 \right) \left(\sum_{j=1}^n \sum_{k=1}^n B_{kj}^2 \right) = \|A\|_F^2 \cdot \|B\|_F^2.$$

Tomando raíz cuadrada en ambos lados:

$$\|AB\|_F \leq \|A\|_F \cdot \|B\|_F.$$

Esto completa la demostración.

Ejercicio 4

Considere el siguiente problema de optimización cuadrática:

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} x^\top Q x + c^\top x, a$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y $c \in \mathbb{R}^n$. Se sabe que si Q es definida positiva, entonces el problema tiene solución única. (¿Por qué?)

Suponga ahora que Q no es definida positiva, sino que posee al menos un valor propio negativo. Construya explícitamente un vector $d \in \mathbb{R}^n$ que permita demostrar que el problema no tiene solución, es decir, un vector d tal que:

$$f(\bar{x} + \lambda d) \rightarrow -\infty \quad \text{cuando} \quad \lambda \rightarrow \infty.$$

En su construcción debe demostrar que efectivamente el vector seleccionado cumple con esa propiedad.

Solución: Sabemos que el gradiente de f es:

$$\nabla f(x) = Qx + c,$$

y la matriz hessiana es:

$$\nabla^2 f(x) = Q.$$

Si Q es definida positiva, entonces $\nabla^2 f(x)$ también lo es. Esto implica que la función f es estrictamente convexa y, por lo tanto, existe un único mínimo global x^* , el cual satisface:

$$\nabla f(x^*) = 0.$$

Ahora, consideramos el desarrollo de Taylor de segundo orden en la dirección $d \in \mathbb{R}^n$:

$$f(x^* + \lambda d) = f(x^*) + \lambda d^\top \nabla f(x^*) + \frac{1}{2} \lambda^2 d^\top Q d.$$

Como $\nabla f(x^*) = 0$, esto se reduce a:

$$f(x^* + \lambda d) = f(x^*) + \frac{1}{2} \lambda^2 d^\top Q d.$$

Para que x^* sea un mínimo, se requiere que $d^\top Qd > 0$ para todo $d \neq 0$. Esto se cumple si Q es definida positiva.

Supongamos ahora que Q no es definida positiva, sino que posee al menos un valor propio negativo. Como Q es simétrica, puede ser diagonalizada: existe una matriz ortogonal P y una matriz diagonal D tal que:

$$Q = PDP^\top,$$

donde los elementos de D son los valores propios de Q . Supongamos que $\alpha < 0$ es uno de esos valores propios, con vector propio asociado $w \neq 0$, tal que:

$$Qw = \alpha w.$$

Entonces:

$$w^\top Qw = w^\top (\alpha w) = \alpha \|w\|^2 < 0.$$

Si elegimos $d = w$, entonces:

$$f(x^* + \lambda d) = f(x^*) + \frac{1}{2} \lambda^2 d^\top Qd = f(x^*) + \frac{1}{2} \lambda^2 \alpha \|w\|^2.$$

Dado que $\alpha < 0$, se tiene que:

$$\lim_{\lambda \rightarrow \infty} f(x^* + \lambda d) = -\infty.$$

El problema no tiene solución cuando Q posee al menos un valor propio negativo, ya que la función puede decrecer sin cota inferior en una dirección d asociada a un vector propio de un valor propio negativo.

Ejercicio 5

Consideremos el siguiente problema de optimización:

$$\min \|x - u\| \quad \text{s.a.} \quad Ax = 0,$$

donde $x, u \in \mathbb{R}^n$ y $A \in \mathbb{R}^{m \times n}$.

- (a) Transforme el problema en uno equivalente.

Solución: El problema original puede escribirse de forma equivalente como:

$$\min \|x - u\|^2 \quad \text{s.a.} \quad Ax = 0.$$

La función objetivo queda:

$$\begin{aligned} f(x) &= \|x - u\|^2 = (x - u)^\top (x - u) \\ &= x^\top x - 2x^\top u + u^\top u. \end{aligned}$$

Por lo tanto, el problema se transforma en:

$$\min f(x) = x^\top x - 2x^\top u + u^\top u \quad \text{s.a.} \quad Ax = 0.$$

- (b) Calcule la función lagrangiana asociada.

Solución: La función lagrangiana para este problema es:

$$\begin{aligned} L(x, \lambda) &= f(x) + \lambda^\top (Ax - 0) \\ &= x^\top x - 2x^\top u + u^\top u + \lambda^\top Ax \\ &= x^\top x - 2x^\top u + u^\top u + (A^\top \lambda)^\top x. \end{aligned}$$

- (c) Plantee las condiciones que deben cumplir los puntos críticos.

Solución: Primero calculamos el gradiente de L respecto a x :

$$\begin{aligned} \nabla_x L(x, \lambda) &= \nabla_x (x^\top x - 2x^\top u + u^\top u + (A^\top \lambda)^\top x) \\ &= 2x - 2u + A^\top \lambda. \end{aligned}$$

La primera condición de punto crítico es entonces:

$$2x - 2u + A^\top \lambda = 0.$$

Luego, derivamos respecto a λ :

$$\nabla_\lambda L(x, \lambda) = Ax.$$

La segunda condición de punto crítico es:

$$Ax = 0.$$

(d) Calcule los puntos críticos y determine cuál es la solución óptima.

Solución: A partir de la primera condición:

$$2x = 2u - A^\top \lambda \Rightarrow x = u - \frac{1}{2} A^\top \lambda.$$

Reemplazamos en la segunda condición:

$$A \left(u - \frac{1}{2} A^\top \lambda \right) = 0 \Rightarrow Au - \frac{1}{2} AA^\top \lambda = 0.$$

Multiplicando por 2:

$$2Au = AA^\top \lambda \Rightarrow \lambda = 2(AA^\top)^{-1} Au.$$

Sustituyendo de vuelta en x :

$$\begin{aligned} x &= u - \frac{1}{2} A^\top \lambda = u - \frac{1}{2} A^\top [2(AA^\top)^{-1} Au] \\ &= u - A^\top (AA^\top)^{-1} Au = [I - A^\top (AA^\top)^{-1} A] u. \end{aligned}$$

Por lo tanto, el único punto crítico (y solución óptima del problema) es:

$$x^* = [I - A^\top (AA^\top)^{-1} A] u.$$