



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025- 2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 1

Repaso de Conceptos Previos

07 de agosto de 2025

Resumen

Matriz transpuesta

Sea A una matriz de $\mathbb{R}^{m \times n}$ se define su matriz transpuesta $A^\top \in \mathbb{R}^{n \times m}$ como sigue:

$$A_{i,j}^\top = A_{j,i}$$

$\forall i \in \{1, 2, \dots, n\}$ y $\forall j \in \{1, 2, \dots, m\}$

Propiedades de la matriz transpuesta

$(A^\top)^\top = A$ para toda matriz $A \in \mathbb{R}^{m \times n}$.

$(A + B)^\top = A^\top + B^\top$ para toda matriz $A, B \in \mathbb{R}^{m \times n}$.

$(c \cdot A)^\top = c \cdot A^\top$ para todo numero $c \in \mathbb{R}$ y para toda matriz $A \in \mathbb{R}^{m \times n}$.

$(A \cdot B)^\top = B^\top \cdot A^\top$ para toda matriz $A \in \mathbb{R}^{m \times n}$ y para toda matriz $B \in \mathbb{R}^{n \times k}$.

$(Ax)^\top = x^\top A^\top$ para toda matriz $A \in \mathbb{R}^{m \times n}$ y para todo $x \in \mathbb{R}^n$.

Matriz simétrica

Sea $A \in \mathbb{R}^{n \times n}$ una matriz cualquiera. Se dice que es simétrica si:

$$A^\top = A$$

Norma euclidea

La norma euclidea de un vector $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ denotada por $\|x\|_2$ o simplemente por $\|x\|$ se define como sigue:

$$\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

Propiedades

- 1) $\|x\| = 0 \Leftrightarrow x = 0$
- 2) $\|x + y\| \leq \|x\| + \|y\| \forall x, y \in \mathbb{R}^n$
- 3) $\|\alpha \cdot x\| = |\alpha| \cdot \|x\| \forall \alpha \in \mathbb{R}, \forall x \in \mathbb{R}^n$

Un vector se dice unitario cuando su norma es 1.

Producto punto

Sea $u = (u_1, u_2, \dots, u_n) \in \mathbb{R}^n$ y $v = (v_1, v_2, \dots, v_n) \in \mathbb{R}^n$. Se define el producto punto entre u y v como sigue:

$$\langle u, v \rangle = u \cdot v = u^\top v = \sum_i^n u_i \cdot v_i$$

Propiedades del producto punto

- 1) $u \cdot v = v \cdot u \quad \forall u, v \in \mathbb{R}^n$.
- 2) $u \cdot (v_1 + v_2) = u \cdot v_1 + u \cdot v_2 \quad \forall u, v_1, v_2 \in \mathbb{R}^n$.
- 3) $\alpha(u \cdot v) = (\alpha u) \cdot v = u \cdot (\alpha v) \quad \forall u, v \in \mathbb{R}^n, \forall \alpha \in \mathbb{R}$.

Relación del producto punto con la norma

$$\|x\|_2 = \sqrt{x \cdot x} \quad \forall x \in \mathbb{R}^n$$

Desigualdad de Cauchy-Schwarz

$$|x \cdot y| \leq \|x\| \|y\| \quad \forall x, y \in \mathbb{R}^n$$

Matriz definida positiva

Sea A una matriz en $\mathbb{R}^{n \times n}$. Se dice que la matriz es definida positiva cuando $\forall u \in \mathbb{R}^n$ tal que $u \neq 0$:

$$u^\top A u > 0$$

Si el producto anterior es < 0 , entonces la matriz es definida negativa.

Matriz semi-definida positiva

Sea A una matriz en $\mathbb{R}^{n \times n}$. Se dice que la matriz es semi-definida positiva cuando $\forall u \in \mathbb{R}^n$:

$$u^\top A u \geq 0$$

Si el producto anterior es ≤ 0 , entonces la matriz es semi definida negativa.

Determinante de una matriz

Sea A una matriz en $\mathbb{R}^{n \times n}$. El determinante se puede calcular a través de una expansión por filas y columnas.

Primero, definiremos a $A^{i,j}$ como la matriz de $\mathbb{R}^{(n-1) \times (n-1)}$ que resulta al eliminar la fila i y la columna j de la matriz A .

La expansión por filas se calcula de la siguiente manera:

$$\det(A) = \sum_{k=1}^n (-1)^{i+k} a_{i,k} \cdot \det(A^{i,k}) \quad \forall i \in \{1, 2, \dots, n\}$$

Y la expansión por columnas se calcula de la siguiente manera:

$$\det(A) = \sum_{k=1}^n (-1)^{k+j} a_{k,j} \cdot \det(A^{k,j}) \quad \forall j \in \{1, 2, \dots, n\}$$

Propiedades del determinante

$\det(A) = \det(A^\top)$ para toda matriz $A \in \mathbb{R}^{n \times n}$.

$\det(A \cdot B) = \det(A) \cdot \det(B)$ para toda matriz $A, B \in \mathbb{R}^{n \times n}$.

Matriz Invertible

Una matriz invertible, es una matriz $A \in \mathbb{R}^{n \times n}$ (Matriz cuadrada), tal que existe una matriz $B \in \mathbb{R}^{n \times n}$ la cual cumpla que:

$$A \cdot B = I_n$$

Con I_n la matriz identidad que pertenece a $\mathbb{R}^{n \times n}$. La matriz B se escribe como A^{-1} y se denomina matriz inversa de A . Una matriz es inversa si y solo si su determinante es distinto de cero.

Propiedades

$(A^{-1})^\top = (A^\top)^{-1}$ para toda matriz $A \in \mathbb{R}^{m \times n}$ invertible.

$(A \cdot B)^{-1} = B^{-1}A$ para toda matriz $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{m \times n}$ invertibles.

$(A^{-1})^{-1} = A$ para toda matriz $A \in \mathbb{R}^{m \times n}$ invertible.

Derivada parcial

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Su derivada parcial en la variable i -ésima se define como sigue:

$$\frac{\partial f(x)}{\partial x_i} = \frac{\partial f(x_1, \dots, x_n)}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) - f(x_1, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_n)}{h}$$

para todo $i \in \{1, 2, \dots, n\}$.

Gradiente

El gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

Matriz Hessiana

Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

Regla de la cadena

Consideremos un función $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

Sea $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ tal que: $x_1 = x_1(\lambda), x_2 = x_2(\lambda), \dots, x_n = x_n(\lambda)$, entonces tenemos que:

$$\begin{aligned} \frac{\partial f(x)}{\partial \lambda} &= \left(\frac{\partial f(x)}{\partial x_1} \right) \cdot \left(\frac{\partial x_1}{\partial \lambda} \right) + \left(\frac{\partial f(x)}{\partial x_2} \right) \cdot \left(\frac{\partial x_2}{\partial \lambda} \right) + \dots + \left(\frac{\partial f(x)}{\partial x_n} \right) \cdot \left(\frac{\partial x_n}{\partial \lambda} \right) \\ &= \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right) \begin{pmatrix} \frac{\partial x_1}{\partial \lambda} \\ \frac{\partial x_2}{\partial \lambda} \\ \vdots \\ \frac{\partial x_n}{\partial \lambda} \end{pmatrix} = [\nabla f(x)]^\top \left(\frac{\partial x}{\partial \lambda} \right) = \nabla f(x) \cdot \left(\frac{\partial x}{\partial \lambda} \right) \end{aligned}$$

De manera más compacta podemos decir que:

$$\frac{\partial f(x)}{\partial \lambda} = [\nabla f(x)]^\top \left(\frac{\partial x}{\partial \lambda} \right)$$

Máximos y mínimos

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función. Un punto crítico x_0 de f cumple que f no es diferenciable en x_0 o bien:

$$\nabla f(x_0) = 0.$$

La naturaleza del punto crítico x_0 depende de la matriz hessiana $\nabla^2 f(x_0)$:

- x_0 es un **mínimo local** si $\nabla^2 f(x_0)$ es definida positiva.
- x_0 es un **máximo local** si $\nabla^2 f(x_0)$ es definida negativa.
- x_0 es un **punto de silla** en caso contrario.

Multiplicadores de Lagrange

Los multiplicadores de Lagrange se utilizan para resolver problemas de optimización con restricciones.

Con una restricción

Consideremos el problema:

$$\text{mín / máx } f(x) \quad \text{s.a.} \quad g_1(x) = \alpha_1,$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g_1 : \mathbb{R}^n \rightarrow \mathbb{R}$.

Se define la función:

$$h(x, \lambda_1) = f(x) - \lambda_1[\alpha_1 - g_1(x)].$$

Los valores extremos del problema cumplen:

$$\nabla_x h(x, \lambda_1) = 0, \quad g_1(x) = \alpha_1.$$

Resolviendo este sistema se obtiene el punto crítico x y el multiplicador λ_1 .

Con m restricciones

Consideremos ahora el problema:

$$\text{mín / máx } f(x) \quad \text{s.a.} \quad g_i(x) = \alpha_i, \quad \forall i \in \{1, 2, \dots, m\},$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$ para todo i .

Esto se puede escribir en forma vectorial:

$$\text{mín / máx } f(x) \quad \text{s.a.} \quad A(x) = \alpha,$$

donde:

$$A(x) = \begin{pmatrix} g_1(x) \\ \vdots \\ g_m(x) \end{pmatrix} \in \mathbb{R}^m, \quad \alpha = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix} \in \mathbb{R}^m.$$

Se define la función de Lagrange como:

$$h(x, \lambda) = f(x) - \sum_{i=1}^m \lambda_i [\alpha_i - g_i(x)] = f(x) - \lambda^\top (A(x) - \alpha),$$

con $\lambda \in \mathbb{R}^m$.

Los puntos extremos satisfacen:

$$\nabla_x h(x, \lambda) = 0, \quad \nabla_\lambda h(x, \lambda) = 0.$$

Dado que:

$$\nabla_\lambda h(x, \lambda) = -[A(x) - \alpha],$$

la segunda condición implica:

$$A(x) = \alpha.$$

Vectores y valores propios

Definición de vector y valor propio

Un vector propio v y su respectivo valor propio λ de una matriz $A \in \mathbb{R}^{n \times n}$ satisfacen:

$$Av = \lambda v.$$

¿Cómo determinar un valor propio?

Se resuelve la ecuación característica:

$$\det(A - \lambda I) = 0.$$

¿Cómo determinar un vector propio?

Una vez encontrado un valor propio λ , se resuelve el sistema:

$$(A - \lambda I)v = 0.$$

Relación entre valores propios y la naturaleza de la matriz

Sean $\lambda_1, \lambda_2, \dots, \lambda_n$ los valores propios de A , entonces:

- Si $\lambda_i > 0$ para todo i , entonces A es **definida positiva**.
- Si $\lambda_i \geq 0$ para todo i , entonces A es **semidefinida positiva**.
- Si $\lambda_i < 0$ para todo i , entonces A es **definida negativa**.
- Si $\lambda_i \leq 0$ para todo i , entonces A es **semidefinida negativa**.

Singularidad e invertibilidad de una matriz

Sean $\lambda_1, \lambda_2, \dots, \lambda_n$ los valores propios de A . Entonces:

- Si existe i tal que $\lambda_i = 0$, entonces A es **singular**, es decir, A **no es invertible**.

Modelos de Optimización: Estructura Básica

La optimización busca la mejor solución entre varias alternativas. Los modelos matemáticos de optimización buscan maximizar o minimizar una función objetivo sujeta a restricciones.

Elementos Clave:

1. **Función Objetivo:** Define la medida de desempeño a optimizar y es una expresión matemática de las variables de decisión.
2. **Variables de Decisión:** Son las incógnitas a determinar para optimizar la función objetivo, pueden ser continuas, enteras o binarias.
3. **Conjuntos:** Definen los conjuntos a los que pertenecen las variables y parámetros.
4. **Parámetros:** Constantes que afectan la función objetivo o las restricciones, representando costos, ingresos, tiempos, etc.
5. **Restricciones:** Limitan las soluciones al sistema, pueden ser igualdades o desigualdades, representando limitaciones en recursos, capacidades, relación entre variables, etc.

Formulación Matemática:

El modelo de optimización se expresa en nivel general como:

$$\begin{aligned} & \max/\min f(x) \\ & \text{s.a } g_i(x) \leq b_i, \quad i = 1, 2, \dots, m \\ & x_j \in X_j, \quad j = 1, 2, \dots, n \end{aligned}$$

Donde:

$f(x)$ es la función objetivo.

$g_i(x)$ son las restricciones.

b_i es el coeficiente (parámetro) asociado a la restricción

X_j es el conjunto de la variable x_j .

Se busca un conjunto de valores para las variables de decisión que optimicen la función objetivo, cumpliendo con todas las restricciones.

Ejercicio 1

Considere $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica, c un vector en $\mathbb{R}^n$ y $d \in \mathbb{R}$ una constante. Sea la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ la cual se define como sigue:

$$f(x) = x^\top Qx + c^\top x + d$$

- (a) Utilice sumatorias para expresar la función $f(x)$.
- (b) Calcule el gradiente de $f(x)$.
- (c) Calcule la matriz Hessiana de $f(x)$.

Ejercicio 2

En estadística, se utiliza un modelo matemático para explicar la relación entre una variable dependiente y y un conjunto de n variables independientes $X_1, X_2, \dots, X_n$, junto con un término de error ε que captura las discrepancias no explicadas por el modelo. La forma general del modelo lineal es:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon$$

Cuando se dispone de m observaciones, el modelo para cada observación $i \in \{1, 2, \dots, m\}$ se expresa como:

$$y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_n x_{i,n} + \varepsilon_i$$

Este sistema puede escribirse de manera compacta en notación matricial:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & x_{1,2} & \cdots & x_{1,n} \\ 1 & x_{2,1} & x_{2,2} & \cdots & x_{2,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m,1} & x_{m,2} & \cdots & x_{m,n} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_n \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_m \end{bmatrix}$$

Definimos:

$$Y \in \mathbb{R}^m, \quad X \in \mathbb{R}^{m \times (n+1)}, \quad \beta \in \mathbb{R}^{n+1}, \quad \varepsilon \in \mathbb{R}^m$$

De modo que el modelo puede resumirse como:

$$Y = X\beta + \varepsilon$$

El objetivo fundamental en este contexto consiste en estimar los coeficientes $\beta_0, \beta_1, \dots, \beta_n$ de forma tal que el error total del modelo, representado por ε , sea lo más pequeño posible. Es decir, se busca encontrar el vector β que minimice una medida del error, como por ejemplo, la suma de los errores cuadráticos:

$$\min_{\beta} \|Y - X\beta\|^2$$

Esta formulación corresponde al método de los mínimos cuadrados ordinarios, ampliamente utilizado para ajustar modelos lineales a los datos observados.

- (a) **(Propuesto)** ¿Es equivalente minimizar la norma de ε a minimizar la norma al cuadrado de ε ? Justifique.

-
- (b) Dé una expresión para la norma al cuadrado de ε en función de X, Y y β . ¿Qué tipo de función es? ¿Cuál es la variable?
 - (c) Calcule el gradiente y la matriz hessiana de la función anterior (con β como variable).
 - (d) ¿Cuál es la naturaleza de la matriz hessiana?
 - (e) Calcule la solución óptima (con β como variable).

Ejercicios Propuestos

Ejercicio 1

Consideremos el siguiente problema de optimización:

$$\max c^\top x \quad \text{s.a.} \quad x^\top Q x \leq 1,$$

donde $c \in \mathbb{R}^n$ y $Q \in \mathbb{R}^{n \times n}$ es simétrica definida positiva.

- (a) Calcule la función lagrangiana asociada.
- (b) Plantee las condiciones que deben cumplir los puntos críticos.
- (c) Calcule los puntos críticos.
- (d) Calcule la solución óptima.

Ejercicio 2

- (a) Considere la siguiente descripción de un problema que se presenta frecuentemente en programación de operaciones en los más diversos ámbitos industriales:

Tenemos que realizar n trabajos, los cuales se pueden hacer en cualesquiera de m máquinas. El trabajo j requiere de t_j horas para ser realizado (independientemente de la máquina en que se haga). Si se asignan algunos trabajos a una máquina, esta terminará de trabajar en un tiempo igual a la suma de los tiempos de los trabajos que se asignaron. Ese tiempo, que denotaremos γ_i , para la máquina i , se llama “tardanza” (tardiness, es el término que se usa en Inglés). Existen pesos $w_i > 0$ asociados a cada máquina y queremos encontrar una forma de asignar los trabajos a las distintas máquinas de modo tal que se minimice la “tardanza ponderada total” (total weighted tardiness), dada por $\sum_{i=1}^m w_i \gamma_i$. Adicionalmente, existe el requisito de que cada máquina debe trabajar un tiempo total mínimo de R_{min} horas. Notemos que, una vez asignados algunos trabajos a una máquina, da lo mismo el orden en que se hagan, la tardanza de esa máquina es la misma y la asignación es válida, mientras cumpla el mínimo de horas.

La siguiente figura muestra un ejemplo de 5 trabajos asignados a 2 máquinas (llamadas M1 y M2), con un tiempo mínimo de trabajo $R_{min} = 5$ horas, y con una tardanza ponderada total igual a 69.

$M_1, w_1 = 5$	$t_1 = 2,5$	$t_4 = 8,5$		$\gamma_1 = 11$
$M_2, w_2 = 2$	$t_2 = 2,0$	$t_3 = 2,0$	$t_5 = 3,0$	$\gamma_2 = 7$

Se le solicita confeccionar un modelo de programación lineal que permita minimizar la tardanza ponderada.

- (b) Vamos a considerar la situación de una compañía de transportes del tipo “ridesharing” (como las que operan a través de plataformas de Internet), la que quiere planificar la cantidad de conductores que debe tener en cada zona para satisfacer la demanda. Vamos a suponer que hay n zonas y existe una demanda estimada de viajes igual a d_j^T en la zona j en el periodo t . Los conductores (en sus autos) operan en ciertas zonas pero pueden ser movidos de una zona a otra (reposicionamiento, se llama esto) y esto tiene un costo de c_{ij}^T por conductor que se mueve entre la zona i y la zona j en el periodo t . Existe un beneficio α_j^T por conductor, por cubrir viajes en la zona j en el periodo t . Además, cada vez que se reposicionan conductores desde la zona j , se incurre en un costo fijo igual a f_j^T en el periodo t , independientemente de la cantidad de conductores reposicionados e independientemente de su destino. Suponemos que cada conductor atiende un solo viaje. El contrato con los conductores de los autos especifica ciertos límites a la cantidad de reposicionamientos que se pueden hacer por periodo de tiempo,

siendo igual a $G^\top$ para el periodo t . Igualmente, en cada periodo existen ciertas zonas en las que no puede haber reposicionamiento de conductores si los hay en otra. Esto se describe con un conjunto $E_j^\top$ para la zona j en el periodo t .

La empresa quiere determinar las cantidades de conductores a reposicionar entre las zonas de modo de maximizar la utilidad neta y para esto, ha construido el siguiente modelo:

El modelo empleado es el siguiente:

$$\begin{aligned}
& \text{máx} \quad \sum_{t=1}^T \sum_{j=1}^n \alpha_j^\top u_j^\top - \sum_{t=1}^T \sum_{j=1}^n \sum_{i=1, i \neq j}^n c_{ij}^\top x_{ij}^\top - \sum_{t=1}^T \sum_{j=1}^n f_j^\top z_j^\top \\
& \text{s. a.} \quad u_j^\top = u_j^{t-1} + \sum_{i=1, i \neq j}^n x_{ij}^\top - \sum_{i=1, i \neq j}^n x_{ji}^\top \quad j = 1, \dots, n; t = 1, \dots, T \quad (1) \\
& \quad u_j^\top \leq d_j^\top \quad j = 1, \dots, n; t = 1, \dots, T \quad (2) \\
& \quad \sum_{i=1, i \neq j}^n x_{ji}^\top \leq M z_j^\top \quad j = 1, \dots, n; t = 1, \dots, T \quad (3) \\
& \quad \sum_{j=1}^n z_j^\top \leq G^\top \quad t = 1, \dots, T \quad (4) \\
& \quad \sum_{i \in E_j^\top} z_i^\top \leq n(1 - z_j^\top) \quad j = 1, \dots, n; t = 1, \dots, T \quad (5) \\
& \quad z_j^\top \in \{0, 1\}, x_{ij}^\top \geq 0, u_j^\top \geq 0 \quad j = 1, \dots, n; t = 1, \dots, T \quad (6)
\end{aligned}$$

donde las cantidades u_j^0 corresponden al número de conductores iniciales en cada zona y los asumimos conocidos (no son igual a cero, si no, no habría conductores para atender a los pasajeros). El número M es una constante “suficientemente grande”.

Interprete claramente el significado de las variables, función objetivo y restricciones del modelo.

Ejercicio 3

- (a) Sea $f(x) = x^\top Qx$, con $Q \in \mathbb{R}^{n \times n}$ matriz simétrica semidefinida positiva. Muestre que $f(x)$ es una función convexa.
- (b) Sean $A, B \in \mathbb{R}^{n \times n}$ matrices. Demuestre que:

$$\|AB\|_F \leq \|A\|_F \cdot \|B\|_F,$$

donde $\|M\|_F$ denota la norma de Frobenius de la matriz M .

Ejercicio 4

Considere el siguiente problema de optimización cuadrática:

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} x^\top Q x + c^\top x, a$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y $c \in \mathbb{R}^n$. Se sabe que si Q es definida positiva, entonces el problema tiene solución única. (¿Por qué?)

Suponga ahora que Q no es definida positiva, sino que posee al menos un valor propio negativo. Construya explícitamente un vector $d \in \mathbb{R}^n$ que permita demostrar que el problema no tiene solución, es decir, un vector d tal que:

$$f(\bar{x} + \lambda d) \rightarrow -\infty \quad \text{cuando} \quad \lambda \rightarrow \infty.$$

En su construcción debe demostrar que efectivamente el vector seleccionado cumple con esa propiedad.

Ejercicio 5

Consideremos el siguiente problema de optimización:

$$\text{mín } \|x - u\| \quad \text{s.a.} \quad Ax = 0,$$

donde $x, u \in \mathbb{R}^n$ y $A \in \mathbb{R}^{m \times n}$.

- (a) Transforme el problema en uno equivalente.
- (b) Calcule la función lagrangiana asociada.
- (c) Plantee las condiciones que deben cumplir los puntos críticos.
- (d) Calcule los puntos críticos y determine cuál es la solución óptima.