



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025-2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 2

Método del Gradiente y Newton

14 de agosto de 2025

Resumen

■ Gradiente

El Gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

■ Matriz Hessiana

Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- **Dirección de descenso:** d es dirección de descenso si cumple que $d^T \nabla f(x) < 0$

■ **Método de Gradiente (Convergencia lineal):**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
2. Sea $d^k = -\nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.

■ **Método de Newton (Convergencia cuadrática):**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
2. Sea $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.

Ejercicio 1

Se está realizando una investigación sobre los factores que influyen en qué personas de una cierta población adquieran una enfermedad. Lo que se busca es relacionar la propensión al contagio con algunos factores como peso, edad, presión arterial y otros que podrían ser explicativos. Para esto, se dispone de datos de m personas y se ha definido un indicador y donde $y_i = 1$ si la persona contrajo la enfermedad e $y_i = 0$ en caso contrario. Además, se dispone de mediciones de n variables (edad, peso, etc.) para esas m personas, donde u_{ij} es el valor de la variable j para la persona i . Se tiene que $m > n$. Además, en el grupo bajo estudio hay q personas contagiadas y $m - q$ no contagiadas y los datos están ordenados de modo que los contagiados corresponden a las personas $i = 1, \dots, q$ y los no contagiados corresponden a las personas $i = q + 1, \dots, m$. Para este tipo de estudios se puede usar un “modelo logístico”, en el cual se modela la probabilidad de adquirir la enfermedad, p , de la siguiente forma:

$$p = \frac{e^{\alpha^T u}}{1 + e^{\alpha^T u}}$$

donde $\alpha \in \mathbb{R}^n$ corresponde a los parámetros del modelo (a veces hay, además, un término constante pero acá lo estamos obviando para simplificar). Entonces, para la persona i , se estima una probabilidad dada por

$$p_i = \frac{e^{\alpha^T u^i}}{1 + e^{\alpha^T u^i}}, \quad i = 1, \dots, m$$

donde $u^i \in \mathbb{R}^n$ corresponde al vector de las observaciones para la persona i . Es decir, las componentes de u^i son $u_{i1}, u_{i2}, \dots, u_{in}$.

Este problema se aborda buscando los estimadores de “máxima verosimilitud” del modelo, es decir, los valores de los parámetros α que maximizan la probabilidad conjunta de contagio y no contagio en el grupo observado, que es:

$$\prod_{i=1}^q p_i \prod_{i=q+1}^m (1 - p_i)$$

Como esta expresión es compleja, lo que se hace, en forma equivalente, es maximizar la log-verosimilitud (con logaritmo natural) dada por:

$$l(\alpha) = \sum_{i=1}^q \alpha^T u^i - \sum_{i=1}^m \log(1 + e^{\alpha^T u^i}) = \sum_{i=1}^q \sum_{j=1}^n \alpha_j u_{ij} - \sum_{i=1}^m \log(1 + e^{\sum_{j=1}^n \alpha_j u_{ij}})$$

(la última fórmula está bien, la primera suma sí es desde 1 a q .) Esta es la función de n variables con la que trabajamos y lo que queremos hacer es resolver el siguiente problema de optimización:

$$\max_{\alpha \in \mathbb{R}^n} l(\alpha)$$

-
- (a) Determine $\nabla l(\alpha)$
 - (b) Determine $\nabla^2 l(\alpha)$
 - (c) Supongamos que queremos llegar a una solución con un error $\epsilon > 0$. Estime el esfuerzo computacional total (en flops) para llegar a esa meta. (Aquí puede asumir conocidas las constantes “escondidas” en algunas expresiones, denótelas como algún valor constante). Explique con claridad cualquier supuesto adicional o estimación que haga.
 - (d) Considere que un amigo que ya dio el ramo le dice que siempre es conveniente usar el método de Newton para encontrar una solución ϵ –óptima. Argumente si lo mencionado por su amigo es correcto.
 - (e) Suponga que le dicen que $n \gg m$, encuentre a partir de cual n es más conveniente usar Gradiente sobre Newton para la obtención de una solución ϵ –óptima (en términos de tiempo total de cómputo). Para esto puede asumir que $\mathcal{O}(X) = X$, es decir, todas las constantes ocultas son 1.

Ejercicio 2

Considere la siguiente función de máxima verosimilitud para un problema de estimación estadística:

$$g(v_1, \dots, v_k) = \sum_{i=1}^m \left(y_i \log \left(\sum_{j=1}^k v_j u_j^i \right) - \sum_{j=1}^k v_j u_j^i \right)$$



donde los y_i son datos diarios de accidentes de tránsito y los u_j^i son valores de varios factores explicativos que se postulan. El problema consiste en determinar v de modo que se maximice $g(v)$.

El Gradiente y el Hessiano de esa función en un punto arbitrario x se puede calcular sin mucha dificultad. Las fórmulas son las siguientes:

$$\nabla g(v) = \sum_{i=1}^m \left(y_i \frac{u^i}{v^T u^i} - u^i \right), \quad \nabla^2 g(v) = \sum_{i=1}^m \left(-y_i \frac{u^i (u^i)^T}{(v^T u^i)^2} \right)$$

Donde llamamos U a la matriz de los datos de los factores explicativos, siendo u^i el vector de la fila i de la matriz de datos de los factores explicativos.

- Determine el orden de número de operaciones aritméticas (flops) que se tienen que realizar para evaluar el Gradiente, en función del número de factores explicativos k , y del número de observaciones m .
- Sobre la base de lo anterior, determine el orden del costo por iteración para el método del Gradiente.
- Ahora determine el orden de número de operaciones aritméticas (flops) que se tienen que realizar para evaluar el hessiano, en función del número de factores explicativos k y del número de observaciones m .
- Sobre la base de lo anterior, determine el orden del costo por iteración para el método de Newton.
- Determine, basado en sus respuestas anteriores, un criterio que permita decir a partir de qué cantidad de factores (k) o de observaciones (m) conviene más usar el Método del Gradiente que el Método de Newton para llegar en menos tiempo a una solución ϵ -aproximada. Para hacer su estimación asuma, en forma simplificada, que las constantes “ocultas” en las expresiones $\mathcal{O}(\cdot)$ son todas iguales a 1. Justifique con precisión todo supuesto adicional que haga para su análisis (Nota: en su análisis tendrá que ver si sus criterios se aplican sólo a k o sólo a m o a ambos).
- (Propuesto)** Ahora queremos usar el Método del Gradiente para abordar el problema. Las siguientes figuras muestran (en dos dimensiones) dos posibles poliedros en los que se querría resolver el problema: el poliedro (A) y el poliedro (B).



¿En cuál de los dos casos espera que el método del Gradiente converja en menos iteraciones? (suponiendo que parten de un punto más o menos alejado del centro). Justifique con precisión su respuesta sobre la base de los contenidos del curso.

Ejercicios Propuestos

Ejercicio 1

Vamos a considerar el siguiente problema, que es relevante en diversas aplicaciones en geometría computacional. Tenemos un poliedro definido por un conjunto de desigualdades lineales, de la forma

$$P = \{x \in \mathbb{R}^n : a_i^T x \leq b_i, i = 1, \dots, m\}$$

donde $a_i \in \mathbb{R}^n$, $b_i \in \mathbb{R}$, para $i = 1, \dots, m$, $m > n$. Vamos a asumir, también, que P tiene interior no vacío, es decir, existe un punto $x^0 \in \mathbb{R}^n$ tal que $a_i^T x^0 < b_i, i = 1, \dots, m$. Interesa encontrar un punto en el interior de este conjunto, que esté separado de las hiperplanos definidos por las restricciones. Para esto, se plantea la siguiente función, definida en el interior del conjunto P :

$$f(x) = \sum_{i=1}^m \frac{1}{b_i - a_i^T x}$$

Note que cuando x se acerca a alguno de los hiperplanos de la frontera de P , los que están definidos por $a_i^T x = b_i$, entonces alguno de los términos $b_i - a_i^T x$ se hace chico, con lo cual su recíproco se hace grande y el valor de $f(x)$ se hace grande. Por lo tanto, cuando x se acerca a la frontera de P desde adentro, f aumenta de valor y se va a ∞ a medida que x se acerca más y más al borde, y no está definida en la frontera. Se propone, entonces, resolver el siguiente problema de optimización para encontrar el punto “más al centro” de P : $\min f(x)$. Si bien es verdad que el problema debería restringirse al interior de P , no es realmente necesario ya que, en la medida que los algoritmos que conocemos partan desde un punto en el interior (por ejemplo, x^0), los puntos generados por las iteraciones deberían permanecer dentro de P ya que la función objetivo crece al acercarse a la frontera. Le comentamos también que la función f es convexa, si se considera solamente dentro del interior del conjunto P .

- (a) Desarrolle fórmulas explícitas para el Gradiente y el Hessiano de la función f .
- (b) Estime el esfuerzo computacional, en flops, para evaluar el Gradiente y Hessiano de la función f en algún punto de x , en función de m y n . Debe hacer las estimaciones considerando una evaluación eficiente de las fórmulas que desarrolle en la parte a).
- (c) Supongamos que decidimos usar el Método de Newton para este problema y queremos llegar a una solución con un error $\epsilon > 0$. Estime el esfuerzo computacional total (en flops) para llegar a esa meta, en función de m y n . Asuma que la etapa de Linesearch requiere un esfuerzo fijo de $p < m$ iteraciones en las que se debe evaluar el Gradiente de f en distintos puntos. Su expresión final puede quedar en términos de m , n , p , y ϵ , además de constantes. (Aquí puede asumir conocidas las constantes “escondidas” en algunas expresiones, denótelas con un símbolo adecuado). Explique con claridad cualquier supuesto adicional o estimación que haga.

Ejercicio 2

Nos interesa encontrar una solución al sistema de ecuaciones $Ax = b$, donde $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, con $m < n$. También asumiremos que las filas de A son linealmente independientes. Como sabemos, un sistema de este tipo tiene muchas soluciones posibles. Una forma de “regularizar” el problema, diferente a lo que vimos en clases, es pedir que la solución x que se encuentre tenga “poca variación”. Esto se usa, por ejemplo, en aplicaciones de análisis de señales. Explicamos esto a continuación:

Sea $x \in \mathbb{R}^n$. Se define la “variación” del vector $x \in \mathbb{R}^n$ como el siguiente vector $\Delta(x) \in \mathbb{R}^{n-1}$ dado por:

$$\Delta(x)_j = x_{j+1} - x_j, j = 1, \dots, n-1$$

Entonces, vamos a plantear resolver el siguiente problema de optimización:

$$\min_{x \in \mathbb{R}^n} \tau \|\Delta(x)\|_2^2 + \|Ax - b\|_2^2$$

donde τ es un parámetro que busca un balance entre las dos partes de la función objetivo.

- (a) Muestre que $\Delta(x)$ se puede escribir de la forma $\Delta(x) = Bx$ donde $B \in \mathbb{R}^{(n-1) \times n}$ y determine explícitamente esa matriz B .
- (b) Según a), entonces, la función objetivo del problema es de la forma $f(x) = \tau \|Bx\|_2^2 + \|Ax - b\|_2^2$. También es fácil ver que esta función es convexa (es suma de términos cuadráticos convexos). Determine el Gradiente y el Hessiano de f .
- (c) Determine explícitamente la solución óptima del problema $\min f(x)$. ¿Cuánto es el esfuerzo computacional (en “flops”) para encontrar esta solución?
- (d) En forma alternativa a hacer lo de (c), se propone usar el Método del Gradiente para abordar el problema. Si el algoritmo se implementa de forma eficiente, ¿Cuál es el esfuerzo computacional (en flops) de una iteración del Método del Gradiente? (Piense bien esto, fíjese en cosas que se deben hacer en cada iteración, que es lo que estamos preguntando, frente a otras que pueden hacerse una sola vez al comienzo y que no las incluimos en el costo por iteración).
- (e) Discuta bajo qué circunstancias puede ser conveniente igual usar el Método del Gradiente en vez de calcular explícitamente la solución óptima determinada en (c). Su discusión se debe basar en las propiedades del Método del Gradiente. Puede usar la versión del método que le resulte más adecuada (el “clásico” o el presentado como Método de Primer Orden). Justifique con precisión todo lo que argumente y explicita cualquier supuesto adicional que haga.

Ejercicio 3

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa sobre $x \geq 0$, con $n \approx 40$, f queda definida de la siguiente forma:

$$f(x) = \frac{c}{\sum_{i=1}^n a_i x_i^2} + \sum_{j=1}^m \left(\sum_{i=1}^n b_{i,j} x_i - d_j \right)^2$$

Donde tanto como c , a_i , $b_{i,j}$, d_j son constantes positivas: Suponga que se quiere resolver el siguiente problema:


$$\min_{x \geq 0} f(x)$$

A partir de esta información, calcule $\nabla f(x)$ y $\nabla^2 f(x)$. Luego indique qué método elegiría para obtener el mínimo de la función, calculando además el esfuerzo computacional de dicho método (en notación asintótica $\mathcal{O}(\cdot)$).

Ejercicio 4

Suponga que se desea minimizar una cierta función (no importa cuál) y usted “sabe” que esa función es convexa y diferenciable hasta el orden que uno quiera. Un grupo de ingenieros se pone a trabajar con los métodos de Gradiente y Newton en esta función, eligen puntos de partida, etc., lo típico que seguramente usted habría hecho.

El grupo le presenta a usted los resultados de la evolución del Método del Gradiente. Estos se muestran en el siguiente gráfico de la función objetivo a medida que avanzan las iteraciones:



¿Qué opinión le despiertan esos resultados? ¿Los consideraría correctos? Justifique con precisión su respuesta sobre la base de contenidos del curso.

Ejercicio 5

Queremos resolver el problema de minimización restringido $\min_{x \in \mathbb{R}^n} f(x)$, para una función f dos veces continuamente diferenciable. No asumiremos más hipótesis sobre f . Sabemos que podríamos usar el Método de Newton para esto pero, debe recordarse, para que este método funcione correctamente es necesario asegurarse de que en cualquier iteración k , la matriz $\nabla^2 f(x^k)$ sea definida positiva (para que la dirección de avance sea de descenso). Como f no es necesariamente convexa, eso no tendría necesariamente que cumplirse.

Antes de seguir, definiremos un concepto importante: Sea $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica. Denotamos por q_{ij} el elemento fila i , columna j de Q . Decimos que Q es **diagonal dominante** si para cada fila i se tiene que $\sum_{j=1, j \neq i}^n |q_{ij}| < |q_{ii}|$.

Teorema: Si $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica diagonal dominante, entonces Q es definida positiva.

(**Nota:** La propiedad es sólo suficiente, hay matrices definidas positivas que no son diagonal dominantes.)

Proponemos el siguiente algoritmo, algo como una variante del Método de Newton:

Algoritmo de Newtoncito (para minimizar):

Data: $x^0 \in \mathbb{R}^n$, f , $k = 0$, $\epsilon > 0$.

```
while  $\|\nabla f(x^k)\|_2 > \epsilon$  do
  if  $\nabla^2 f(x^k)$  no es definida positiva then
    Sea  $B = \nabla^2 f(x^k)$ 
    for  $i = 1, \dots, n$  do
       $a_i = \sum_{j=1, j \neq i}^n |b_{ij}|$ 
      if  $a_i > |b_{ii}|$  then
         $b_{ii} = a_i + \eta$ 
      end
    end
  else
     $B = \nabla^2 f(x^k)$ 
  end
  Sea  $d^k = -B^{-1}\nabla f(x^k)$ 
  Resolver aproximadamente
      
$$\min_{\lambda \geq 0} f(x^k + \lambda d^k) \quad (\text{etapa de "linesearch"})$$

  Sea  $\lambda^k$  solución óptima de ese problema
  Sea  $x^{k+1} = x^k + \lambda^k d^k$ 
   $k = k + 1$ 
end
```

En este algoritmo, $\eta > 0$ es un número dado, y b_{ij} es el elemento fila i , columna j de la matriz B .

- (a) Explique qué es lo que hace este algoritmo y por qué podría ser buena idea hacer lo que ahí se propone. Justifique con precisión su respuesta y no se extienda en más de 5-6 líneas.
- (b) ¿Qué cree usted que podría pasar con las propiedades de convergencia del algoritmo, incluyendo la complejidad (es decir, el orden del número de iteraciones necesarias para llegar a un error dado), comparadas con la del Método de Newton? Justifique con precisión su respuesta y no se extienda en más de 5-6 líneas.
- (c) Aún suponiendo que en una iteración k , la matriz $\nabla^2 f(x^k)$ no sea definida positiva, ¿Qué característica cree usted que debería tener $\nabla^2 f(x^k)$ para que la convergencia del algoritmo Newtoncito sea prácticamente igual a la del Método de Newton original (es decir, que hagan, aproximadamente, el mismo número de iteraciones para un mismo caso de problema.)? Justifique con precisión su argumento.
- (d) Supongamos que el algoritmo Newtoncito tiene éxito y eventualmente comienza a

converger a un mínimo local de la función f . Argumente que, eventualmente, el algoritmo usará una etapa normal de Newton y no será necesario hacer la corrección de las líneas 3 a 8 del pseudocódigo de arriba.