



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025-2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 3

Método Simple de Primer Orden

21 de agosto de 2025

Resumen

■ **Condición de Lipschitz:** $|f(x) - f(y)| \leq L |x - y| \quad \forall x, y.$

■ **Método de Gradiente (Convergencia lineal):**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0.$
2. Sea $d^k = -\nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.

■ **Método de Newton (Convergencia cuadrática):**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0.$
2. Sea $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.

■ **Método Simple de Primer Orden:**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, d^0 = -\nabla f(x^0), \epsilon > 0.$
2. Sea $d^k = -\nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea $x^{k+1} = x^k + \frac{1}{L} d^k, k \leftarrow k + 1$, go to 2.

- **Gradiente**

El Gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

- **Matriz Hessiana**

Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- **Dirección de descenso:** d es dirección de descenso si cumple que $d^T \nabla f(x) < 0$

Ejercicio 1

Considere un problema de la forma

$$\min_{x \in \mathbb{R}^n} \left\{ \|x - \bar{x}\|_2^2 + \tau \sum_{j=1}^{n-1} (x_{j+1} - x_j)^4 \right\}$$

donde $\bar{x}$ corresponde a mediciones ruidosas de una señal y $\tau > 0$ es dado. Recuerde que el problema busca encontrar un estimador “suavizado” de $\bar{x}$. En esta pregunta vamos a considerar que ahora queremos usar métodos de primer orden para abordar el problema. Como ya sabemos, la función objetivo es convexa y le recordamos que esta función se puede escribir, equivalentemente, como $f(x) = \|x - \bar{x}\|_2^2 + \tau g(\Delta x)$, donde $g(u) = \sum_{j=1}^{n-1} u_j^4$ y $\Delta \in \mathbb{R}^{(n-1) \times n}$ está dada por

$$\Delta = \begin{bmatrix} -1 & 1 & 0 & \dots & 0 & 0 \\ 0 & -1 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & -1 & 1 \end{bmatrix}.$$

Además, el gradiente y Hessiano de esta función objetivo están dados por

$$\nabla f(x) = 2(x - \bar{x}) + \tau \Delta^\top \nabla g(\Delta x), \quad \nabla^2 f(x) = 2I + \tau \Delta^\top \nabla^2 g(\Delta x) \Delta.$$

donde el gradiente y Hessiano de $g(u)$ se escriben explícitamente como

$$\nabla g(u) = \begin{bmatrix} 4u_1^3 \\ 4u_2^3 \\ \vdots \\ 4u_{n-1}^3 \end{bmatrix}, \quad \nabla^2 g(u) = \begin{bmatrix} 12u_1^2 & 0 & \dots & 0 \\ 0 & 12u_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 12u_{n-1}^2 \end{bmatrix}.$$

- (a) **(Propuesto)** La forma que hemos usado para estimar una constante de Lipschitz para $\nabla f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función continua y 2 veces diferenciable, ha sido buscar una cota superior a $\max_x \|\nabla^2 f(x)\|_2$. Explique en qué se basa esta estimación.

Solución: Esta estimación se basa en el Teorema del Valor Medio, según el cual la variación de los gradientes entre dos puntos es acotada por el valor del Hessiano. Repetimos el argumento informal que se presentó en clases. Bajo el supuesto de que $\nabla f(x)$ es L -Lipschitziana con parámetro $L > 0$, se tiene lo siguiente:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \quad \forall x, y \in \mathbb{R}^n$$

Reordenando,

$$\frac{\|\nabla f(x) - \nabla f(y)\|}{\|x - y\|} \leq L \quad \forall x, y \in \mathbb{R}^n$$

Luego, tomando el límite cuando los valores de x e y están muy cerca,

$$\lim_{y \rightarrow x} \frac{\|\nabla f(x) - \nabla f(y)\|}{\|x - y\|} \leq L \quad \forall x \in \mathbb{R}^n$$

El valor de la izquierda se ve “como una derivada” y eso es lo que lleva a que

$$\|\nabla^2 f(x)\| \leq L \quad \forall x \in \mathbb{R}^n$$

De esta manera, la constante de Lipschitz se puede estimar como

$$\max_x \|\nabla^2 f(x)\|_2$$

- (b) Argumente que, globalmente, $\nabla f(x)$ no cumple la propiedad de Lipschitz.

Solución: Esta demostración se podía realizar de dos maneras distintas. La primera manera es probando que la propiedad de Lipschitz no se cumple al menos para un par de puntos x e y , es decir,

$$\|\nabla f(x) - \nabla f(y)\|_2 > L\|x - y\|_2$$

para cualquier valor de L . Tomando $x = x^*$, se tiene que $\nabla f(x) = 0$. De esta manera, necesitamos encontrar un valor de y tal que

$$\|\nabla f(y)\|_2 > L\|x^* - y\|_2$$

Ahora bien, en el lado izquierdo de esta desigualdad se tiene que $\nabla f(y)$ depende del vector $\nabla g(\Delta y)$, el cual tiene la siguiente forma:

$$\nabla g(\Delta y) = \begin{bmatrix} 4(y_2 - y_1)^3 \\ 4(y_3 - y_2)^3 \\ \vdots \\ 4(y_n - y_{n-1})^3 \end{bmatrix}$$

Como se puede observar, los elementos de este vector crecen de forma cúbica, aunque hay que tener cuidado con el hecho que lo que está al cubo en el vector son las diferencias de valores de y , no los valores de y en sí. Entonces, se puede elegir un y de la siguiente forma:

$$\begin{aligned}
y_1 &= v \\
y_2 &= 2v \\
y_3 &= 3v \\
&\vdots \\
y_n &= nv
\end{aligned}$$

donde v es una variable arbitraria. Entonces, $y_{j+1} - y_j = v$ para todo $j = 1, \dots, n-1$, quedando v^3 en los elementos del vector. Lo anterior provoca que el lado izquierdo de la desigualdad crezca sin control y de forma mucho más rápida que el lado derecho de la desigualdad. De esta manera, el lado izquierdo será imposible de acotar con algún valor constante de L , por ende, no se cumplirá con la propiedad de Lipschitz.

La segunda manera de argumentarlo es demostrando que la norma del Hessiano de la función $f(x)$ no se encuentra acotada. Para ello, observamos que $\|\nabla^2 f(x)\|_2$ depende de la matriz diagonal $\nabla^2 g(\Delta x)$, la cual tiene la siguiente forma:

$$\nabla^2 g(\Delta x) = \begin{bmatrix} 12(x_2 - x_1)^2 & 0 & \dots & 0 \\ 0 & 12(x_3 - x_2)^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 12(x_n - x_{n-1})^2 \end{bmatrix}$$

Como se puede observar, la norma del Hessiano terminará dependiendo de x , el cual es irrestricto. El punto es que se pueda elegir un x de modo tal que la norma pueda crecer sin límite. Para ello, hay que tener cuidado con el hecho que lo que está al cuadrado en la diagonal de $\nabla^2 g(\Delta x)$ son las diferencias de valores de x , no los valores de x en sí. Entonces, se puede elegir un x de la siguiente forma:

$$\begin{aligned}
x_1 &= v \\
x_2 &= 2v \\
x_3 &= 3v \\
&\vdots \\
x_n &= nv
\end{aligned}$$

donde v es una variable arbitraria. Entonces, $x_{j+1} - x_j = v$ para todo $j = 1, \dots, n-1$, quedando v^2 en los términos diagonales, lo cual puede crecer sin límite. De esta manera, la norma del Hessiano de la función no se encuentra acotada, imposibilitando así poder cumplir con la propiedad de Lipschitz.

- (c) **(Propuesto)** Por otro lado, argumente que, para el contexto de este problema, podríamos definir un valor M tal que para cualquier solución x relevante del problema se cumple $|x_j| \leq M$. Lo que le pedimos aquí es que considere el verdadero contexto del problema y argumente de dónde podría obtenerse un valor de M .

Solución: Considerando el contexto del problema, este busca encontrar un estimador suavizado de los datos observados en el vector $\bar{x}$, provenientes de las mediciones ruidosas de una señal. De esta manera, al tratarse de una estimación, es de suponer que los valores de la solución no debieran apartarse mucho de $\bar{x}$. Así, la constante M se puede obtener a través de un valor suficientemente más grande que la mayor desviación que puede ser observada a partir de los datos.

- (d) Asumiendo la existencia de ese valor de M , determine un valor de constante de Lipschitz, L , restringido al conjunto $\{x \in \mathbb{R}^n : \|x\|_1 \leq M\}$, que se pueda usar en el Método Simple de Primer Orden. Explique todos sus supuestos y estimaciones.

Solución: Llamemos D al conjunto $\{x \in \mathbb{R}^n : \|x\|_1 \leq M\}$. Como D es un conjunto cerrado y acotado, podemos estimar la constante de Lipschitz como

$$L = \max_{x \in D} \|\nabla^2 f(x)\|_2$$

Luego,

$$\begin{aligned} \|\nabla^2 f(x)\|_2 &= \|2I + \tau \Delta^\top \nabla^2 g(\Delta x) \Delta\|_2 \\ &\leq \|2I\|_2 + \|\tau \Delta^\top \nabla^2 g(\Delta x) \Delta\|_2 \\ &\leq 2\|I\|_2 + \tau \|\Delta^\top\|_2 \|\nabla^2 g(\Delta x)\|_2 \|\Delta\|_2 \\ &\leq 2 + \tau \|\Delta^\top\|_2 \|\nabla^2 g(\Delta x)\|_2 \|\Delta\|_2 \end{aligned}$$

En este punto, observamos que tenemos al lado derecho de la desigualdad el valor $\|\nabla^2 g(\Delta x)\|_2$, correspondiente a la norma del Hessiano de la función $g(\Delta x)$. Contextualizando, el Hessiano de esta función es una matriz diagonal de la forma

$$\nabla^2 g(\Delta x) = \begin{bmatrix} 12(x_2 - x_1)^2 & 0 & \dots & 0 \\ 0 & 12(x_3 - x_2)^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 12(x_n - x_{n-1})^2 \end{bmatrix}$$

Por ende, la norma 2 de este Hessiano corresponde al máximo valor propio de la matriz. De esta manera, busquemos una cota superior:

$$\begin{aligned} \|\nabla^2 g(\Delta x)\|_2 &\leq 12(\max_j \{|x_{j+1} - x_j|\})^2 \\ &\leq 12(\max_j \{|x_{j+1}| + |x_j|\})^2 \\ &\leq 12(2 \max_i \{|x_i|\})^2 \\ &\leq 12(2M)^2 \\ &\leq 12(4M^2) \\ &\leq 48M^2 \end{aligned}$$

Reemplazando,

$$\begin{aligned}\|\nabla^2 f(x)\|_2 &\leq 2 + \tau\|\Delta^\top\|_2\|\nabla^2 g(\Delta x)\|_2\|\Delta\|_2 \\ &\leq 2 + \tau\|\Delta^\top\|_2 48M^2\|\Delta\|_2\end{aligned}$$

De esta manera, una constante de Lipschitz estimada es

$$L = 2 + 48M^2\tau\|\Delta^\top\|_2\|\Delta\|_2$$

- (e) Muestre que la función objetivo de este problema es fuertemente convexa. Justifique bien sus argumentos.

Solución: En primer lugar, debemos mostrar que el Hessiano $\nabla^2 f(x)$ es definido positivo para todo x . El Hessiano de la función es $2I + \tau\Delta^\top\nabla^2 g(\Delta x)\Delta$ y es la suma de dos matrices. La primera, $2I$, es definida positiva. La segunda es una matriz que corresponde a una forma general del tipo $Q = B^\top DB$, donde D es una matriz diagonal cuyos elementos son ≥ 0 y B puede ser cualquier matriz de dimensiones compatibles. Vamos a mostrar que esta matriz es siempre semidefinida positiva. En efecto, tenemos que probar que $x^\top Qx \geq 0, \forall x$. Tenemos que $x^\top Qx = x^\top B^\top DBx$. Llamemos $v = Bx$. Entonces, tenemos el producto $v^\top Dv = \sum_{j=1}^n v_j^2 d_j$ y esto es siempre ≥ 0 si $d_j \geq 0$. En el caso de nuestro problema, los elementos d_j son los términos $12(x_{j+1} - x_j)^2$, que son ≥ 0 . En consecuencia, la matriz Hessiana es suma de una matriz definida positiva y otra semidefinida positiva, lo que es siempre definida positiva.

Una vez que se ha demostrado que el Hessiano es definido positivo, es necesario encontrar una constante que sea una cota inferior para los valores propios del Hessiano. Para este caso, una cota inferior válida es el 2 que multiplica a la matriz identidad en el primer término de $\nabla^2 f(x)$ (ya que la otra matriz sumada sólo aumenta la magnitud de los valores propios). De esta manera, queda demostrado que la función objetivo es fuertemente convexa.

Ejercicio 2

Considere el problema de encontrar el centro analítico de un poliedro dado por

$$P = \{x \in \mathbb{R}^n : \alpha_i^\top x \leq b_i, i = 1, \dots, m\}$$

donde $\alpha_i \in \mathbb{R}^n, i = 1, \dots, m$, y los b_i son números reales. Como recordará, se asume que el poliedro es acotado y lo que se intenta resolver es el problema

$$\begin{array}{ll} \text{mín} & \Phi(x) \\ \text{s. a.} & x \in \text{int}(P) \end{array}$$

donde

$$\Phi(x) = - \sum_{i=1}^m \log(b_i - a_i^\top x)$$

Como debería saber, la forma de la función Φ garantiza estar siempre estrictamente dentro del poliedro ya que esta función no está definida en el exterior (ni siquiera en la frontera) y, de ese modo, el problema lo consideramos no restringido. Se quiere aplicar el método Simple de Primer Orden, es decir, del Método del Gradiente usando paso fijo. Como recordará, ese paso fijo depende de la constante de Lipschitz de los gradiente de la función que estamos tratando de minimizar.

- (a) Argumente que la función Φ es tal que $\nabla\Phi(x)$ NO cumple propiedad de Lipschitz en el dominio en que la función está definida, es decir, $\text{int}(P)$.

(**Indicación:** Hay más de una forma de abordar esto, por ejemplo, puede basarse en la definición de la condición de Lipschitz o también podría serle útil el siguiente resultado, que es una adaptación de una de las Desigualdades de Horn: Para una matriz de la forma $B^\top EB$, donde E es un matriz diagonal de $n \times n$ y B es otra matriz, todas con dimensiones compatibles, si σ es un valor propio de $B^\top EB$ y $\gamma_1, \dots, \gamma_n$ son los elementos diagonales de E , se tiene que $\sigma \geq C \times \max\{\gamma_1, \dots, \gamma_n\}$, donde C es una constante escalar).

Solución: Hay 2 posibles formas de abordar la pregunta, ambas se consideran correctas.

Alternativa 1: Aplicando la propiedad Lipschitz al gradiente de $\nabla\Phi(x)$ considerando un punto $x = x^*$ (el óptimo) y un punto $y = y$ cualquiera $x \in \text{int}(P)$, se tiene:

$$\begin{aligned} \nabla\Phi(x) &= \sum_{i=1}^m \frac{a_{ik}}{b_i - a_i^\top x} = A^\top D(x)^{-1} e \\ \|A^\top D(x^*)^{-1} e - A^\top D(y)^{-1} e\|_2 &\leq L \|x^* - y\| \end{aligned}$$

Pero en el óptimo el gradiente es 0, por lo que:

$$A^\top D(x^*)^{-1} e = 0$$

Entonces, la desigualdad de Lipschitz resulta:

$$\|A^T D(y)^{-1} e\|_2 \leq L \|x^* - y\|$$

L debe ser una constante para cumplir la propiedad, sin embargo como se tiene $y \in \text{int}(P)$, la norma $\|A^T D(y)^{-1} e\|_2$ al acercarse a la frontera, crece mucho y tiende a infinito, por lo que la función $\nabla \Phi(x)$ no cumple la propiedad de Lipschitz.

Alternativa 2: Para utilizar las desigualdades de Horn, es necesario ver los mayores valores propios de $\nabla^2 \Phi(x)$, lo cual está dado por:

$$\max_x \|\nabla^2 \Phi(x)\|_2$$

con:

$$\nabla^2 \Phi(x) = A^T D^{-2}(x) A$$

Ahora, para cumplir la propiedad de Lipschitz se necesita que:

$$A^T D^{-2}(x) A \geq L * \|D^{-2}(x)\|_2$$

Pero $D^{-2}(x) = (\frac{1}{b_i - a_i^T x})^2$ tiende al infinito en la frontera, por lo que no se puede estimar una constante L y así la función $\nabla^2 \Phi(x)$ no cumple la propiedad de Lipschitz.

- (b) Lo anterior parecería indicar que no podremos usar el Método Simple de Primer Orden, pero acá proponemos una posible salida. Recuerde que vamos a partir de x^0 usando el Método Simple de Primer Orden, es decir, Método del Gradiente con paso fijo. Sea $S = \{x : \Phi(x) \leq \Phi(x^0)\}$ el correspondiente conjunto de nivel para la función Φ en el valor $\Phi(x^0)$, argumente que todas las iteraciones posteriores del método, $x^1, x^2, \dots$ estarán todas contenidas en el conjunto S .

Solución: Basta con indicar que el método del gradiente es un método con dirección de descenso por lo que a medida que x crece, todas las iteraciones futuras $x^1, x^2, \dots$ estarán contenidas en $S = \{x : \Phi(x) \leq \Phi(x^0)\}$.

- (c) Basado en lo anterior, argumente que SÍ es posible determinar una constante de Lipschitz de $\nabla \Phi(x)$ que sí se puede usar en el Método Simple de Primer Orden. Proponga una forma de determinar esa constante (esto es, un problema auxiliar que deba resolver, algún cálculo basado en álgebra lineal, etc.) y comente sobre la dificultad que podrían encontrar en su propuesta.

Solución: Dado que el conjunto $S = \{x : \Phi(x) \leq \Phi(x^0)\}$ es cerrado y acotado, dentro de este se pueden tomar como máximo valores propios del Hessiano.

Es decir, basta con acotar a L con:

$$L = \max_{x \in S} \|\Delta^2 \nabla \Phi(x)\|_2$$

Sobre la dificultad, puede no ser simple obtener el valor de $\|\Delta^2 \nabla \Phi(x)\|_2$, pues se está buscando el mayor valor propio del máximo punto $x \in S$.

Ejercicios Propuestos

Ejercicio 1

Considere la función Banana de Rosenbrock, la que está dada por:

$$f(x) = \sum_{i=1}^{n-1} b(x_{i+1} - x_i^2)^2 + (a - x_i)^2$$

- (a) Determine si acaso el gradiente $\nabla f(x)$ de la función Banana, para una dimensión específica n , puede cumplir o no la propiedad de Lipschitz.

Solución: Recordemos, primero, lo que necesitaríamos: debe existir una constante $L > 0$ tal que

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad x, y \in \mathbb{R}^n$$

En nuestro caso, f es la función Banana. Tomemos $y = x^*$, el punto donde la función Banana alcanza un mínimo. Tenemos que $\nabla f(x^*) = 0$. Entonces, se cumpliría que:

$$\|\nabla f(x)\| \leq L\|x - x^*\|, \quad x, y \in \mathbb{R}^n$$

Ahora bien, volvamos a las expresiones para las derivadas parciales de f . Acá las repetimos:

$$\frac{\partial f(x)}{\partial x_k} = \begin{cases} 2b(x_k - x_{k-1}^2) - 4b(x_{k+1} - x_k^2)x_k - 2(a - x_k) & k = 2, \dots, n-1 \\ -4b(x_2 - x_1^2)x_1 - 2(a - x_1) & k = 1 \end{cases}$$

Podemos ver que se puede elegir un vector de forma adecuada de manera tal que $\|\nabla f(x)\|$ crezca de manera muy fuerte. De hecho, seleccionemos x de la siguiente forma, dependiendo de un parámetro t :

$$x_1(t) = t, x_i(t) = 0, i = 2, \dots, n$$

Entonces, tenemos que:

$$\begin{aligned} \frac{\partial f(x)}{\partial x_1} &= 4bt^3 - 2(a - t) \\ \frac{\partial f(x)}{\partial x_2} &= -2bt^2 \end{aligned}$$

y todas las demás son idénticamente cero. Entonces, para este gradiente evaluado en este punto especial $x(t)$, tenemos:

$$\|\nabla f(x(t))\| = \sqrt{(4bt^3 - 2(a - t))^2 + 4b^2t^4}$$

Para t grande, este número es del orden de t^2 . Por otro lado, $\|x(t) - x^*\|$ es del orden de t . Con eso, se concluye que no puede nunca cumplirse lo que buscamos ya que $\|\nabla f(x(t))\|$ puede crecer mucho más rápido que $\|x(t) - x^*\|$ y no podrá estar nunca acotado por $L\|x(t) - x^*\|$, para ningún L . La conclusión final es que ∇f no puede cumplir la condición de Lipschitz que buscamos.

-
- (b) Notemos que en los experimentos computacionales se observa que los puntos de las iteraciones de los métodos de Gradiente y Newton tienden a concentrarse en, digamos, una región de radio 100 del espacio $\mathbb{R}^n$. Vamos a remitirnos, entonces, a la región $R = \{x \in \mathbb{R}^n : \|x\|_2 \leq 100\}$. Argumente que en esa región R , sí se puede argumentar que $\nabla f(x)$ cumple una condición de Lipschitz, restringida a R . Estime el valor que podría tener esa constante de Lipschitz. Explique todos los supuestos que haga para hacer su estimación (Indicación: para esto pueden serle útiles algunas relaciones entre distintas “normas de matrices”, la de los valores propios no es la única).

Solución: Para este argumento vamos a reconstruir lo presentado en clases para estimar una constante de Lipschitz de $\nabla f(x)$. Nuevamente, para que se cumpla la condición buscada debe pasar que

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad x, y \in \mathbb{R}^n$$

lo que equivale a que

$$\frac{\|\nabla f(x) - \nabla f(y)\|}{\|x - y\|} \leq L, \quad x, y \in \mathbb{R}^n$$

Como argumentamos en clases, el lado izquierdo de esta desigualdad, cuando x está muy cercano a y , “parece” una derivada. Más específicamente, elijamos $x = y + th$, donde h es algún vector con $\|h\| = 1$. Entonces, el lado izquierdo es:

$$\frac{\|\nabla f(y + th) - \nabla f(y)\|}{t}$$

y aquí se ve mucho más claro la forma de derivada. Se puede argumentar, entonces, que, cambiando h por los distintos vectores canónicos, que

$$\|\nabla^2 f(x)\| \leq C(n)L$$

donde $C(n)$ es una constante que depende de n . Para efectos de simplificar, vamos a suponer que $C(n) = 1$ (lo que se puede hacer, cambiando de forma adecuada la norma). Entonces, podemos hacer la siguiente estimación para L :

$$L = \sup_{x \in \mathbb{R}^n} \|\nabla^2 f(x)\|$$

Ya sabemos, por la parte anterior, que ese supremo no existe. Basta ver las fórmulas de las segundas derivadas y darse cuenta que la matriz puede terminar teniendo números muy grande que harán que $\|\nabla f(x)\|$ crezca sin límite si x tiene ciertas componentes suficientemente grandes. Ahora bien, sin nos reducen el “universo de interés” a $R = \{x \in \mathbb{R}^n : \|x\|_2 \leq 100\}$, las componentes de x no podrán crecer arbitrariamente. Más aún, para este problema $\|\nabla f(x)\|$ es una función continua en x y se sabe que toda función continua alcanza sus valores extremos en un conjunto cerrado y acotado (compacto). Entonces, sí podemos estimar:

$$L = \max_{x \in R} \|\nabla^2 f(x)\|$$

Esa será la constante de Lipschitz que podríamos querer usar.

-
- (c) Si se va a usar un Método Simple de Primer Orden, el paso debe ser $1/L$. Con la estimación de la parte 2), ¿qué tan rápido cree usted que, realmente, funcionará ese algoritmo? Discuta sobre la base de los contenidos de clases.

Solución: En primer lugar, podríamos cuestionarnos si acaso corresponde usar un método de primer orden ya que la función Banana no es convexa. Eso invalida todo desarrollo. Sin embargo, siempre podríamos asumir que partimos de un punto inicial “suficientemente cerca” del óptimo, y, en esa zona, la función puede ser considerada convexa. Ahora bien, como no sabemos eso, lo único que podríamos usar es el radio igual a 100 que nos han dado y con eso hacer la estimación de la constante de Lipschitz. Veamos nuevamente las fórmulas para las segundas derivadas:

$$\frac{\partial^2 f(x)}{\partial x_{k+1} \partial x_k} = -4b$$

$$\frac{\partial^2 f(x)}{\partial x_{k-1} \partial x_k} = -4bx_{k-1}$$

$$\frac{\partial^2 f(x)}{\partial x_k^2} = -4bx_{k+1} - 12bx_k^2 + 2$$

$$\frac{\partial^2 f(x)}{\partial x_l \partial x_k} = -0, |l - k| > 2$$

Estimativamente, la norma del Hessiano podría ser del orden de los elementos diagonales, para x con coordenadas relativamente grandes. Ese orden es cuadrático en x_k . Esto significa que si nos ubicamos en los límites de la región R , tendríamos números del orden de 10^4 . Si la constante L es de ese orden, el paso es $1/L$ y podría ser del orden 10^{-4} , bastante chico. Este es un argumento bastante informal pero busca hacer una estimación rápida.

Ejercicio 2

(a) Considere la función de n variables dada por:

$$f(x) = \frac{1}{2}x^\top Qx + \sum_{j=1}^{n-1} (x_{j+1} - x_j)^2$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva. ¿Cumple $\nabla f(x)$ una propiedad de Lipschitz en todo el espacio $\mathbb{R}^n$? Si su respuesta es afirmativa, construya una estimación al valor de esa constante y si su respuesta es negativa justifique por qué no. Sea claro en todas sus explicaciones y desarrollo matemático, y supuestos que haga.

Solución: Se pide demostrar

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2$$

que es equivalente a

$$\|\nabla^2 f(x)\|_2 \leq L$$

Definiendo

$$f(x) = \underbrace{\frac{1}{2}x^\top Qx}_{h(x)} + \underbrace{\sum_{j=1}^{n-1} (x_{j+1} - x_j)^2}_{g(x)}$$

Se tiene que

$$\begin{aligned} f(x) &= h(x) + g(x) \\ \nabla f(x) &= \nabla h(x) + \nabla g(x) \end{aligned}$$

Notar que $\nabla h(x) = Qx$. Por otro lado, se deduce que

$$\frac{\partial g(x)}{\partial x_k} = \begin{cases} 2(x_k - x_{k-1}) & k = n \\ 2(x_k - x_{k-1}) - 2(x_{k+1} - x_k) & k = 2, \dots, n-1 \\ -2(x_{k+1} - x_k) & k = 1 \end{cases}$$

Se tiene además

$$\nabla^2 f(x) = \nabla^2 h(x) + \nabla^2 g(x)$$

Se tiene que $\nabla^2 h(x) = Q$ y para obtener $\nabla^2 g(x)$ se tienen las siguientes derivadas parciales

$$\begin{aligned}\frac{\partial^2 g(x)}{\partial x_{k+1} \partial x_k} &= -2 \\ \frac{\partial^2 g(x)}{\partial x_{k-1} \partial x_k} &= -2 \\ \frac{\partial^2 g(x)}{\partial x_k^2} &= \begin{cases} 2 & k \in \{1, n\} \\ 4 & k = 2, \dots, n-1 \end{cases} \\ \frac{\partial^2 g(x)}{\partial x_l \partial x_k} &= 0 \quad |l - k| > 2\end{aligned}$$

Por tanto, como el Hessiano queda en términos de constantes, se puede obtener una constante L-Lipschitz la cual corresponde a la norma del Hessiano.

- (b) Siguiendo con la misma función de la parte (a), determine el esfuerzo computacional que requiere evaluar el gradiente de f en un punto x cualquiera. Justifique con precisión.

Solución: El esfuerzo de calcular $\nabla f(x) = Qx + \nabla g(x)$ se separa en calcular el esfuerzo de Qx que es $\mathcal{O}(n^2)$ y el esfuerzo de evaluar $\nabla g(x)$ es $\mathcal{O}(n)$. Por tanto, el esfuerzo de evaluar $\nabla f(x)$ es $\mathcal{O}(n^2)$.

- (c) Considere un problema de la forma $\min_{x \in \mathbb{R}^n} f(x)$, donde f es una función convexa dos veces continuamente diferenciable y con hipótesis suficientes para garantizar que cualquier algoritmo de los que conocemos funcionará correctamente. También asuma que se sabe que el cálculo del gradiente requiere $\mathcal{O}(n)$ flops, el cálculo del Hessiano $\mathcal{O}(n^2)$ flops y que, eventualmente, se puede usar un método de Linesearch que hace un máximo de p iteraciones usando gradientes. Explique cómo estimaría a partir de qué dimensión n será más conveniente usar el Método Simple de Primer Orden en vez del Método de Newton para llegar a una solución ϵ -aproximada, para $0 < \epsilon < 1$ dado. Sea claro en su explicación, explicitando relaciones matemáticas adecuadas y justifique según los contenidos del curso, explicando cualquier supuesto que tenga que hacer.

Solución: Se sabe que el tiempo total del Método Simple de Primer Orden y del Método de Newton son $c_1 \cdot k_1 \cdot n \cdot \frac{1}{\epsilon}$ y $c_2 \cdot k_2 \cdot n^3 \log(\log(\frac{1}{\epsilon}))$ respectivamente, con c_1 y c_2 constantes. Asumiendo $c_1 = c_2 = c$ se debe cumplir la siguiente relación

$$\text{Tiempo total Método Simple de Primer Orden} \leq \text{Tiempo total Método de Newton}$$

que se traduce en

$$c_1 \cdot k_1 \cdot \frac{1}{\epsilon} \leq c \cdot k_2 \cdot n^3 \cdot \log \left(\log \left(\frac{1}{\epsilon} \right) \right)$$

despejando se obtiene

$$\sqrt{\frac{k_1}{k_2} \cdot \frac{\frac{1}{\epsilon}}{\log(\log(\frac{1}{\epsilon}))}} \leq n$$

Ejercicio 3

Nos interesa resolver el problema $\min_{x \in \mathbb{R}^n} f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces continuamente diferenciable. Para encontrar una solución aproximada de este problema se propone el siguiente algoritmo:

Algoritmo 1:

```
Data:  $x^0 \in \mathbb{R}^n$ ,  $k = 0$ .  
while Criterio de parada no se satisface do  
    Sea  $\alpha = \max_{l=1,\dots,n} \left\{ \left| \frac{\partial f}{\partial x_l}(x^k) \right| \right\}$     if  $\alpha = 0$  then  
        | STOP  
    end  
    Sea  $j$  tal que  $\left| \frac{\partial f}{\partial x_j}(x^k) \right| = \alpha$  (si hay empate, se elije cualquiera)  
    if  $\frac{\partial f}{\partial x_j}(x^k) < 0$  then  
        |  $d^k = e^j$   
    else  
        |  $d^k = -e^j$   
    end  
    Resolver aproximadamente (hasta cumplir condición de Wolf-Armijo):  
  
        
$$\min_{t \geq 0} f(x^k + td^k)$$
  
  
        Sea  $t^k$  la solución elegida del problema anterior  
        Sea  $x^{k+1} = x^k + t^k d^k$   
         $k = k + 1$   
end
```

En este pseudo-código, e^j denota el j -ésimo vector canónico en $\mathbb{R}^n$ (el vector de n componentes, todas nulas, excepto la j -ésima que vale 1). No especificamos explícitamente el criterio de parada y no se preocupe de eso. Si quiere, piense en que es número de iteraciones.

- (a) Describa qué es lo que hace este algoritmo y por qué le parece que debería, efectivamente, servir para encontrar un mínimo local de la función. Su respuesta debe basarse en los contenidos del curso y su interpretación del pseudo-código, puede apoyarse también en representaciones gráficas, pero todo muy justificado.

Solución: Este algoritmo escoge en cada iteración la mayor derivada parcial en valor absoluto de la función objetivo con respecto a x en una dimensión en específico y lo llama α .

Si α es igual a cero, significa que se está en un mínimo local y se para de iterar (es equivalente a decir que el gradiente es igual a cero).

En el caso de que α sea distinto de cero, la derivada parcial de $f(x^k)$ con respecto a x_j , con $j \in 1, \dots, n$, que maximiza a α puede ser negativa o positiva. Si esta es menor que cero, se escoge como dirección de descenso el vector canónico positivo con un uno en la posición j de este (todas las demás posiciones con un cero). Si $\frac{\partial f(x^k)}{\partial x_j}$ es mayor que cero, para que disminuya el valor de la función objetivo se debe utilizar el negativo del mismo vector canónico descrito anteriormente.

Al final de la iteración, se resuelve aproximadamente el problema de minimizar la función evaluada en la suma de la solución actual más el paso de descenso ponderado. Se escoge el ponderador t del problema anterior, se define la solución x^{k+1} y se vuelve a iterar.

Este método encontraría un mínimo local, ya que para cada punto en cada iteración, decide moverse en la dirección de la variable que más hace decrecer el valor de la función objetivo, y se detendría cuando se encuentre en un mínimo.

- (b) ¿Qué ventajas o desventajas considera usted que este algoritmo tiene frente al Método del gradiente, que hemos estudiado en clases? En particular, ¿puede estimarse el orden de “flops” que este método necesita por iteración? De ser así, de una estimación y no olvide justificar y explicar bien sus supuestos.

Solución: La principal ventaja se basa en un caso de “suerte”, ya que el mayor problema del método del gradiente es que su dirección de descenso es muy local. Este algoritmo propuesto navega por distintas coordenadas, es decir, en distintas direcciones según iteración, las cuales detecta que disminuyen rápidamente el valor de la función objetivo. Así, dadas unas condiciones favorables, este algoritmo podría ser más eficiente que el método del gradiente, si es que lograr capturar mejor la curvatura.

Por otra parte, una desventaja que tiene es que la dirección de descenso de este mismo algoritmo solo tiene elementos no nulos en una dimensión. El método del gradiente tiene la mejor dirección de descenso localmente. Así, la mayor parte del tiempo, el gradiente entregaría una menor cantidad de iteraciones hacia el mínimo (salvo que se de el caso “de suerte” anterior).

Al igual que el método del gradiente, requiere $\mathcal{O}(n)$ flops. La razón es que, aunque se utiliza solo un elemento del gradiente, en cada iteración se debe calcular alfa, valor que implica resolver n derivadas parciales y encontrar la más grande en valor absoluto.

- (c) Considere ahora la siguiente modificación que introduciremos al método. Suponiendo que vamos a partir del punto x^0 , consideramos la matriz Hessiana de f en x^0 , $H = \nabla^2 f(x^0)$. Supongamos que determinamos que H es simétrica y definida positiva. Por lo tanto, es diagonalizable. Sean $v^1, v^2, \dots, v^n$ los vectores propios que se obtienen de la diagonalización y vamos a asumir que se han normalizados, es decir, $\|v^j\|_2 = 1, j = 1, \dots, n$. Proponemos el siguiente algoritmo, modificado, que usa las direcciones v^j en vez de los vectores canónicos e^j :

Algoritmo 2:

Data: $x^0 \in \mathbb{R}^n$, $k = 0$.

while *Criterio de parada no se satisface* **do**

 Sea $\alpha = \max_{l=1,\dots,n} \{|\nabla f(x^k)^\top v^l|\}$ **if** $\alpha = 0$ **then**
 | STOP

end

 Sea j tal que $|\nabla f(x^k)^\top v^j| = \alpha$ (si hay empate, se elije cualquiera)

if $\nabla f(x^k)^\top v^j < 0$ **then**

 | $d^k = v^j$

else

 | $d^k = -v^j$

end

 Resolver aproximadamente (hasta cumplir condición de Wolf-Armijo):

$$\min_{t \geq 0} f(x^k + td^k)$$

 Sea t^k la solución elegida del problema anterior

 Sea $x^{k+1} = x^k + t^k d^k$

$k = k + 1$

end

Explique por qué este algoritmo podría ser mejor que el algoritmo 1 presentado antes, en términos de número de iteraciones para llegar a una meta de error. ¿Qué desventajas podría tener, sin embargo, frente el método original? ¿Qué condición debería cumplir x^0 para que esta idea funcione bien, y por qué? Nuevamente, debe justificar en función de los contenidos del curso.

Solución: Este algoritmo tiene potencial de ser mejor que el anterior debido a que la dirección de descenso contiene información del Hessiano de la función, es decir, información de segundo orden. Podría decirse que sigue un “estilo Newtoniano”. La información de segundo orden que podemos extraer de este algoritmos involucra a los vectores propios, los cuales son utilizados como dirección de descenso. Estos determinan los ejes coordinados en que se mueven las direcciones de descenso, los que corresponderían a los ejes principales de la elipse de las curvas de nivel de la función objetivo. De esta manera, el algoritmo podría adaptarse a las características de la función en específico y eventualmente generar una menor cantidad de iteraciones.

Entre las desventajas que tiene este algoritmo, se encuentran el elevado costo computacional, y por consecuencia, un mayor tiempo de ejecución con respecto al primer algoritmo visto. Esto debido principalmente a que para comenzar a iterar, se deben hacer cálculos de gran magnitud, ya que se debe diagonalizar la matriz Hessiana para calcular sus vectores propios. Es importante notar que este cálculo se realiza una vez para todo el

uso del algoritmo. Además, cada iteración es un poco más costosa debido a que *alpha* implica calcular el gradiente de la función en x^k y multiplicarlo por cada vector propio calculado.

De esta manera, si la función no es bien comportada o posee un gran número de variables, puede que el método inicial fuese una mejor opción. Debe considerarse el balance entre número de iteraciones y el costo por iteración.

Por otro lado, sin el supuesto de que la función es estrictamente convexa y bien definida, se debe escoger cuidadosamente el punto de partida. Específicamente, suficientemente cerca del óptimo, donde sea localmente convexa la función objetivo. De no ser así, puede ocurrir que la sucesión contruida sea divergente o caiga en soluciones locales.

Ejercicio 4

Interesa resolver el siguiente problema de minimización en n variables:

$$\min f(x) = \frac{1}{2}x^\top Qx + c^\top x + \sum_{j=1}^n a_j x_j^4$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, $c \in \mathbb{R}^n$, $a_j > 0$, $j = 1, \dots, n$. Queremos estudiar la aplicación del Método Simple de Primer Orden a este problema, para llegar a una solución aproximada con error $\epsilon > 0$.

- (a) Determine explícitamente el gradiente y el Hessiano de f y argumente que esta función es convexa (utilice cualquier caracterización que conozca de la convexidad y que sea adecuada).

Solución: El gradiente de la función es:

$$\nabla f(x) = Qx + c + \begin{bmatrix} 4a_1 x_1^3 \\ \vdots \\ 4a_n x_n^3 \end{bmatrix}$$

El Hessiano de la función es:

$$\nabla^2 f(x) = Q + \begin{bmatrix} 12a_1 x_1^2 & 0 & \cdots & 0 \\ 0 & 12a_2 x_2^2 & \cdots & 0 \\ \vdots & 0 & \ddots & 0 \\ 0 & 0 & 0 & 12a_n x_n^2 \end{bmatrix}$$

Debido a que Q es una matriz definida positiva y se le suma una matriz con elementos positivos (dado que $x_j^2 \geq 0$ y $a_j \geq 0$ por enunciado), se tiene que el Hessiano de f es una matriz definida positiva y, por lo tanto, f es convexa. (también es válido argumentar que la función tiene componentes convexas vistas en clase y se le suma una función algebraica de grado 4)

- (b) En clases argumentamos que uno podía tratar de estimar una constante de Lipschitz, L , para ∇f tratando de buscar una cota superior a la norma de la matriz Hessiana de f (así se hizo para el ejemplo de función cuadrática). Argumente que eso aquí no va a funcionar, es decir, no hay cota a la norma del Hessiano (no necesita ponerse a calcular la norma exacta del Hessiano ni nada de eso, de un argumento simple pero sólido y basado en el problema).

Solución: El problema de optimización consta de una variable no restringida, que puede tomar todos los valores en $\mathbb{R}^n$, por lo que la norma de la matriz $\text{diag}(12a_1 x_1^2, \dots, 12a_n x_n^2)$ es no acotada. luego la norma del Hessiano no es acotada.

- (c) Lo anterior sugiere que no se podría usar el Método Simple de Primer Orden, pero, suponga que tenemos un punto x^0 como punto inicial. Argumente que, dado que el método es de descenso y la función f es convexa, en la medida que el paso cumpla con las condiciones de Wolf-Armijo, cualquier punto x^k generado por el método estará contenido en el conjunto de nivel $S_0 = \{x : f(x) \leq f(x^0)\}$. Justifique con precisión su argumento en función de los contenidos del curso


(**Hint:** piense en cómo se ven las curvas de nivel de una función convexa y piense cómo se movería un método de descenso).

Solución: Sea x_0 el punto de inicio, todo otro punto $k + 1$ generado por el método de primer orden será de la forma $x^{k+1} = x^k + \lambda d^k$, con d^k una dirección de descenso. Dado que el paso de avance λ cumple con las condiciones de Wolfe-Armijo, se nos asegura que:

$$f(x^k + \lambda d^k) \leq f(x^k) + c_1 \lambda \nabla f(x^k)^\top$$

cuya interpretación es: *Pedir que f descienda lo suficiente, haciendo que x^{k+1} permanezca en el conjunto $\{x : f(x) \leq f(x^{k+1})\}$ asegurándonos que $f(x^{k+1}) \leq f(x^k)$.*

Esto se puede sintetizar en la siguiente curva de nivel:



- (d) Sobre la base de la conclusión de la pregunta anterior argumente que sí se podría estimar una constante de Lipschitz L que pueda ser usada en el Método Simple de Primer Orden, partiendo del x^0 mencionado en la parte c) y que las iteraciones son válidas para cualquier punto que el método requiera evaluar.

Solución: Dado que la sucesión de puntos x^k generados a partir de la iteración del Método Simple de Primer Orden pertenecen al conjunto $S_0 = \{x : f(x) \leq f(x_0)\}$ (demostrado en la pregunta anterior) se puede determinar una cota máxima para el Hessiano, la cual corresponde a $\max(\|H(x)\| : x \in S_0)$, y se alcanza dado que el conjunto es cerrado y acotado (compacto). Luego, podemos utilizar $\max(\|H(x)\| : x \in S_0)$ como constante de Lipschitz.

-
- (e) Determine si acaso se podría obtener con certeza una velocidad de convergencia del método simple de primer orden, tipo $\mathcal{O}(\log \frac{1}{\epsilon})$ para este problema. Justifique con precisión su argumento.

Solución: Como $f(x)$ es continua, diferenciable, con Hessiano definido positivo (por punto 2), se tiene que $f(x)$ es fuertemente convexa, con $\nabla f(x)$ lipschitziana, se tiene que el Método de Primer Orden ejecuta en orden $\mathcal{O}(\log \frac{1}{\epsilon})$

Ejercicio 5

- (a) Supongamos que se quiere resolver el problema $\min_{x \in \mathbb{R}^n} f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es 2 veces continuamente diferenciable, fuertemente convexa, y tal que ∇f es L -Lipschitz. Se considera usar el Método de Primer Orden acelerado de Nesterov o el Método de Newton para este problema. Es fácil darse cuenta que el esfuerzo computacional por iteración del método acelerado de Nesterov es $\mathcal{O}(n)$ flops, y usted conoce cuál es el esfuerzo, en flops, por iteración del Método de Newton. Además, usted conoce el orden de número de iteraciones de ambos métodos para llegar a un error $\epsilon > 0$. Llamemos C el tiempo efectivo de reloj que requiere un computador específico para realizar un flop (una operación de punto flotante). Para efectos de lo que sigue, asuma que el tiempo adicional que involucra calcular gradientes y Hessianos es despreciable (puede no ser verdad, pero lo tomaremos así para simplificar).

Determine, estimativamente, sobre la base de las propiedades de convergencia de cada método, a partir de qué valor de n conviene usar el método acelerado de Nesterov en vez del método de Newton para llegar en el menor tiempo posible a una solución ϵ -óptima del problema, todo esto para un $0 < \epsilon < 1$ dado. (En este problema tendrá que asumir, tal vez, algunas constantes como conocidas o cosas así, y eso está bien, pero deberá explicar con claridad todos los supuestos que haga para llegar a una respuesta).

Solución: Calcular el tiempo del método de Newton:

- Esfuerzo por iteración: $\mathcal{O}(n^3)$ “flops”.
- Error: ϵ
- N° de iteraciones: $\mathcal{O}(\log(\log(\frac{1}{\epsilon})))$
- Tiempo en una iteración $\approx C \cdot (k_1 n^3)$
- Tiempo total $\approx \log(\log(\frac{1}{\epsilon})) \cdot C \cdot (k_1 n^3)$

Calcular el tiempo del método de Nesterov:

- Esfuerzo por iteración: $\mathcal{O}(n)$ “flops”.
- Error: ϵ
- N° de iteraciones: $\mathcal{O}(\log(\frac{1}{\epsilon}))$
- Tiempo en una iteración $\approx C \cdot (k_2 n)$
- Tiempo total $\approx \log(\frac{1}{\epsilon}) \cdot C \cdot (k_2 n)$

Comparar ambos tiempos. Será conveniente usar el método de Nesterov cuando:

$$\text{Tiempo de Nesterov} \leq \text{Tiempo de Newton}$$

$$\log\left(\frac{1}{\epsilon}\right) \cdot C \cdot (k_2 n) \leq \log\left(\log\left(\frac{1}{\epsilon}\right)\right) \cdot C \cdot (k_1 n^3) / \cdot \frac{1}{C}$$

$$\log\left(\frac{1}{\epsilon}\right) \cdot (k_2 n) \leq \log\left(\log\left(\frac{1}{\epsilon}\right)\right) \cdot (k_1 n^3) / \cdot \frac{1}{n}$$

$$\log\left(\frac{1}{\epsilon}\right) \cdot k_2 \leq \log\left(\log\left(\frac{1}{\epsilon}\right)\right) \cdot (k_1 n^2)$$

$$\frac{\log\left(\frac{1}{\epsilon}\right) \cdot k_2}{\log\left(\log\left(\frac{1}{\epsilon}\right)\right) \cdot k_1} \leq n^2$$

$$\sqrt{\frac{\log\left(\frac{1}{\epsilon}\right) \cdot k_2}{\log\left(\log\left(\frac{1}{\epsilon}\right)\right) \cdot k_1}} \leq n$$

- (b) Considere la siguiente función de máxima verosimilitud para un problema de estimación estadística:

$$g(v_1, \dots, v_k) = \sum_{i=1}^m \left(y_i \log\left(\sum_{j=1}^k v_j u_j^i\right) - \sum_{j=1}^k v_j u_j^i \right)$$

donde los y_i son los datos diarios de accidentes de tránsito y los u_j^i eran los valores de varios factores explicativos que se postulan. El problema consistía en determinar v de modo que se maximice $g(v)$.

Para un punto arbitrario, las fórmulas para el gradiente y Hessianos son:

$$\nabla g(v) = \sum_{i=1}^m \left(y_i \frac{u^i}{v^\top u^i} - u^i \right), \quad \nabla^2 g(v) = \sum_{i=1}^m \left(-y_i \frac{u^i (u^i)^\top}{(v^\top u^i)^2} \right)$$

Donde llamamos U a la matriz de los datos de los factores explicativos, siendo u^i el vector de la fila i de la matriz de datos de los factores explicativos.

Se propone usar el Método Simple de Primer Orden. Determine si acaso se podrá o no usar el método. Más en específico, usted sabe que el método requiere una constante L adecuada, así que lo que le pedimos es que discuta si acaso puede determinarse un L adecuado para este problema. Si su respuesta es afirmativa, especifique cómo haría esa estimación y en caso de ser negativa, justifíquelo con precisión.

Solución: Para poder determinar si es posible utilizar el Método Simple de Primer Orden, se debe tener que la función sea convexa, continuamente diferenciable y $\nabla g(v)$ L -lipschitz.

Sabemos que el problema se puede escribir de forma convexa, donde $\max g(v) = \min -g(v)$. Además, sabemos que es continuamente diferenciable. Falta demostrar que

$\nabla g(v)$ sea L -lipschitz. Para que se cumpla esto debemos ver que la variación del gradiente esté acotada por la constante L . Esto significa que el módulo del hessiano esté acotado por algún valor.

Por lo tanto, es correcto decir que $L = \max\{\|\nabla^2(g(v))\|\}$. Sin embargo, al estudiar el hessiano en detalle notamos que depende del vector v , que es variable. Por lo que no podemos afirmar que esté acotado. Tomando todo esto en consideración, no es posible usar el Método Simple de Primer Orden para resolver este problema.

Otra respuesta podría ser que sí es posible usar este método, siempre y cuando el vector v esté acotado a alguna región identificable y acotada del espacio, ya que se puede tomar el mayor valor de la norma del hessiano. Para que esté correcta esta solución debe proponerse una cota adecuada para v .