



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025-2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 3

Método Simple de Primer Orden

21 de agosto de 2025

Resumen

■ **Condición de Lipschitz:** $|f(x) - f(y)| \leq L |x - y| \quad \forall x, y.$

■ **Método de Gradiente (Convergencia lineal):**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0.$
2. Sea $d^k = -\nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.

■ **Método de Newton (Convergencia cuadrática):**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0.$
2. Sea $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.

■ **Método Simple de Primer Orden:**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, d^0 = -\nabla f(x^0), \epsilon > 0.$
2. Sea $d^k = -\nabla f(x^k)$
3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
4. Sea $x^{k+1} = x^k + \frac{1}{L} d^k, k \leftarrow k + 1$, go to 2.

- **Gradiente**

El Gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

- **Matriz Hessiana**

Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- **Dirección de descenso:** d es dirección de descenso si cumple que $d^T \nabla f(x) < 0$

Ejercicio 1

Considere un problema de la forma

$$\min_{x \in \mathbb{R}^n} \left\{ \|x - \bar{x}\|_2^2 + \tau \sum_{j=1}^{n-1} (x_{j+1} - x_j)^4 \right\}$$

donde $\bar{x}$ corresponde a mediciones ruidosas de una señal y $\tau > 0$ es dado. Recuerde que el problema busca encontrar un estimador “suavizado” de $\bar{x}$. En esta pregunta vamos a considerar que ahora queremos usar métodos de primer orden para abordar el problema. Como ya sabemos, la función objetivo es convexa y le recordamos que esta función se puede escribir, equivalentemente, como $f(x) = \|x - \bar{x}\|_2^2 + \tau g(\Delta x)$, donde $g(u) = \sum_{j=1}^{n-1} u_j^4$ y $\Delta \in \mathbb{R}^{(n-1) \times n}$ está dada por

$$\Delta = \begin{bmatrix} -1 & 1 & 0 & \dots & 0 & 0 \\ 0 & -1 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & -1 & 1 \end{bmatrix}.$$

Además, el gradiente y Hessiano de esta función objetivo están dados por

$$\nabla f(x) = 2(x - \bar{x}) + \tau \Delta^\top \nabla g(\Delta x), \quad \nabla^2 f(x) = 2I + \tau \Delta^\top \nabla^2 g(\Delta x) \Delta.$$

donde el gradiente y Hessiano de $g(u)$ se escriben explícitamente como

$$\nabla g(u) = \begin{bmatrix} 4u_1^3 \\ 4u_2^3 \\ \vdots \\ 4u_{n-1}^3 \end{bmatrix}, \quad \nabla^2 g(u) = \begin{bmatrix} 12u_1^2 & 0 & \dots & 0 \\ 0 & 12u_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 12u_{n-1}^2 \end{bmatrix}.$$

- (Propuesto)** La forma que hemos usado para estimar una constante de Lipschitz para $\nabla f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función continua y 2 veces diferenciable, ha sido buscar una cota superior a $\max_x \|\nabla^2 f(x)\|_2$. Explique en qué se basa esta estimación.
- Argumente que, globalmente, $\nabla f(x)$ no cumple la propiedad de Lipschitz.
- (Propuesto)** Por otro lado, argumente que, para el contexto de este problema, podríamos definir un valor M tal que para cualquier solución x relevante del problema se cumple $|x_j| \leq M$. Lo que le pedimos aquí es que considere el verdadero contexto del problema y argumente de dónde podría obtenerse un valor de M .
- Asumiendo la existencia de ese valor de M , determine un valor de constante de Lipschitz, L , restringido al conjunto $\{x \in \mathbb{R}^n : \|x\|_1 \leq M\}$, que se pueda usar en el Método Simple de Primer Orden. Explique todos sus supuestos y estimaciones.
- Muestre que la función objetivo de este problema es fuertemente convexa. Justifique bien sus argumentos.

Ejercicio 2

Considere el problema de encontrar el centro analítico de un poliedro dado por

$$P = \{x \in \mathbb{R}^n : \alpha_i^\top x \leq b_i, i = 1, \dots, m\}$$

donde $\alpha_i \in \mathbb{R}^n, i = 1, \dots, m$, y los b_i son números reales. Como recordará, se asume que el poliedro es acotado y lo que se intenta resolver es el problema

$$\begin{array}{ll} \text{mín} & \Phi(x) \\ \text{s. a.} & x \in \text{int}(P) \end{array}$$

donde

$$\Phi(x) = - \sum_{i=1}^m \log(b_i - \alpha_i^\top x)$$

Como debería saber, la forma de la función Φ garantiza estar siempre estrictamente dentro del poliedro ya que esta función no está definida en el exterior (ni siquiera en la frontera) y, de ese modo, el problema lo consideramos no restringido. Se quiere aplicar el método Simple de Primer Orden, es decir, del Método del Gradiente usando paso fijo. Como recordará, ese paso fijo depende de la constante de Lipschitz de los gradiente de la función que estamos tratando de minimizar.

- (a) Argumente que la función Φ es tal que $\nabla\Phi(x)$ NO cumple propiedad de Lipschitz en el dominio en que la función está definida, es decir, $\text{int}(P)$.

(Indicación: Hay más de una forma de abordar esto, por ejemplo, puede basarse en la definición de la condición de Lipschitz o también podría serle útil el siguiente resultado, que es una adaptación de una de las Desigualdades de Horn: Para una matriz de la forma $B^\top EB$, donde E es un matriz diagonal de $n \times n$ y B es otra matriz, todas con dimensiones compatibles, si σ es un valor propio de $B^\top EB$ y $\gamma_1, \dots, \gamma_n$ son los elementos diagonales de E , se tiene que $\sigma \geq C \times \max\{\gamma_1, \dots, \gamma_n\}$, donde C es una constante escalar).

- (b) Lo anterior parecería indicar que no podremos usar el Método Simple de Primer Orden, pero acá proponemos una posible salida. Recuerde que vamos a partir de x^0 usando el Método Simple de Primero Orden, es decir, Método del Gradiente con paso fijo. Sea $S = \{x : \Phi(x) \leq \Phi(x^0)\}$ el correspondiente conjunto de nivel para la función Φ en el valor $\Phi(x^0)$, argumente que todas las iteraciones posteriores del método, $x^1, x^2, \dots$ estarán todas contenidas en el conjunto S .
- (c) Basado en lo anterior, argumente que SÍ es posible determinar una constante de Lipschitz de $\nabla\Phi(x)$ que sí se puede usar en el Método Simple de Primer Orden. Proponga una forma de determinar esa constante (esto es, un problema auxiliar que deba resolver, algún cálculo basado en álgebra lineal, etc.) y comente sobre la dificultad que podrían encontrar en su propuesta.

Ejercicios Propuestos

Ejercicio 1

Considere la función Banana de Rosenbrock, la que está dada por:

$$f(x) = \sum_{i=1}^{n-1} b(x_{i+1} - x_i^2)^2 + (a - x_i)^2$$

- (a) Determine si acaso el gradiente $\nabla f(x)$ de la función Banana, para una dimensión específica n , puede cumplir o no la propiedad de Lipschitz.
- (b) Notemos que en los experimentos computacionales se observa que los puntos de las iteraciones de los métodos de Gradiente y Newton tienden a concentrarse en, digamos, una región de radio 100 del espacio $\mathbb{R}^n$. Vamos a remitirnos, entonces, a la región $R = \{x \in \mathbb{R}^n : \|x\|_2 \leq 100\}$. Argumente que en esa región R , sí se puede argumentar que $\nabla f(x)$ cumple una condición de Lipschitz, restringida a R . Estime el valor que podría tener esa constante de Lipschitz. Explique todos los supuestos que haga para hacer su estimación (Indicación: para esto pueden serle útiles algunas relaciones entre distintas “normas de matrices”, la de los valores propios no es la única).
- (c) Si se va a usar un Método Simple de Primer Orden, el paso debe ser $1/L$. Con la estimación de la parte 2), ¿qué tan rápido cree usted que, realmente, funcionará ese algoritmo? Discuta sobre la base de los contenidos de clases.

Ejercicio 2

- (a) Considere la función de n variables dada por:

$$f(x) = \frac{1}{2}x^\top Qx + \sum_{j=1}^{n-1} (x_{j+1} - x_j)^2$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva. ¿Cumple $\nabla f(x)$ una propiedad de Lipschitz en todo el espacio $\mathbb{R}^n$? Si su respuesta es afirmativa, construya una estimación al valor de esa constante y si su respuesta es negativa justifique por qué no. Sea claro en todas sus explicaciones y desarrollo matemático, y supuestos que haga.

- (b) Siguiendo con la misma función de la parte (a), determine el esfuerzo computacional que requiere evaluar el gradiente de f en un punto x cualquiera. Justifique con precisión.
- (c) Considere un problema de la forma $\min_{x \in \mathbb{R}^n} f(x)$, donde f es una función convexa dos veces continuamente diferenciable y con hipótesis suficientes para garantizar que cualquier algoritmo de los que conocemos funcionará correctamente. También asuma que se sabe que el cálculo del gradiente requiere $\mathcal{O}(n)$ flops, el cálculo del Hessiano $\mathcal{O}(n^2)$ flops y que, eventualmente, se puede usar un método de Linesearch que hace un máximo de p iteraciones usando gradientes. Explique cómo estimaría a partir de qué dimensión n será más conveniente usar el Método Simple de Primer Orden en vez del Método de Newton para llegar a una solución ϵ -aproximada, para $0 < \epsilon < 1$ dado. Sea claro en su explicación, explicitando relaciones matemáticas adecuadas y justifique según los contenidos del curso, explicando cualquier supuesto que tenga que hacer.

Ejercicio 3

Nos interesa resolver el problema $\min_{x \in \mathbb{R}^n} f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces continuamente diferenciable. Para encontrar una solución aproximada de este problema se propone el siguiente algoritmo:

Algoritmo 1:

```
Data:  $x^0 \in \mathbb{R}^n$ ,  $k = 0$ .  
while Criterio de parada no se satisface do  
    Sea  $\alpha = \max_{l=1,\dots,n} \left\{ \left| \frac{\partial f}{\partial x_l}(x^k) \right| \right\}$  if  $\alpha = 0$  then  
        | STOP  
    end  
    Sea  $j$  tal que  $\left| \frac{\partial f}{\partial x_j}(x^k) \right| = \alpha$  (si hay empate, se elije cualquiera)  
    if  $\frac{\partial f}{\partial x_j}(x^k) < 0$  then  
        |  $d^k = e^j$   
    else  
        |  $d^k = -e^j$   
    end  
    Resolver aproximadamente (hasta cumplir condición de Wolf-Armijo):  
  
        
$$\min_{t \geq 0} f(x^k + td^k)$$
  
  
        Sea  $t^k$  la solución elegida del problema anterior  
        Sea  $x^{k+1} = x^k + t^k d^k$   
         $k = k + 1$   
end
```

En este pseudo-código, e^j denota el j -ésimo vector canónico en $\mathbb{R}^n$ (el vector de n componentes, todas nulas, excepto la j -ésima que vale 1). No especificamos explícitamente el criterio de parada y no se preocupe de eso. Si quiere, piense en que es número de iteraciones.

- Describa qué es lo que hace este algoritmo y por qué le parece que debería, efectivamente, servir para encontrar un mínimo local de la función. Su respuesta debe basarse en los contenidos del curso y su interpretación del pseudo-código, puede apoyarse también en representaciones gráficas, pero todo muy justificado.
- ¿Qué ventajas o desventajas considera usted que este algoritmo tiene frente al Método del gradiente, que hemos estudiado en clases? En particular, ¿puede estimarse el orden de “flops” que este método necesita por iteración? De ser así, de una estimación y no olvide justificar y explicar bien sus supuestos.
- Considere ahora la siguiente modificación que introduciremos al método. Suponiendo

que vamos a partir del punto x^0 , consideramos la matriz Hessiana de f en x^0 , $H = \nabla^2 f(x^0)$. Supongamos que determinamos que H es simétrica y definida positiva. Por lo tanto, es diagonalizable. Sean $v^1, v^2, \dots, v^n$ los vectores propios que se obtienen de la diagonalización y vamos a asumir que se han normalizados, es decir, $\|v^j\|_2 = 1, j = 1, \dots, n$. Proponemos el siguiente algoritmo, modificado, que usa las direcciones v^j en vez de los vectores canónicos e^j :

Algoritmo 2:

```

Data:  $x^0 \in \mathbb{R}^n, k = 0$ .
while Criterio de parada no se satisface do
    Sea  $\alpha = \max_{l=1, \dots, n} \{|\nabla f(x^k)^\top v^l|\}$    if  $\alpha = 0$  then
        | STOP
    end
    Sea  $j$  tal que  $|\nabla f(x^k)^\top v^j| = \alpha$  (si hay empate, se elije cualquiera)
    if  $\nabla f(x^k)^\top v^j < 0$  then
        |  $d^k = v^j$ 
    else
        |  $d^k = -v^j$ 
    end
    Resolver aproximadamente (hasta cumplir condición de Wolf-Armijo):

        
$$\min_{t \geq 0} f(x^k + td^k)$$


    Sea  $t^k$  la solución elegida del problema anterior
    Sea  $x^{k+1} = x^k + t^k d^k$ 
     $k = k + 1$ 
end

```

Explique por qué este algoritmo podría ser mejor que el algoritmo 1 presentado antes, en términos de número de iteraciones para llegar a una meta de error. ¿Qué desventajas podría tener, sin embargo, frente el método original? ¿Qué condición debería cumplir x^0 para que esta idea funcione bien, y por qué? Nuevamente, debe justificar en función de los contenidos del curso.

Ejercicio 4

Interesa resolver el siguiente problema de minimización en n variables:

$$\min f(x) = \frac{1}{2}x^\top Qx + c^\top x + \sum_{j=1}^n a_j x_j^4$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, $c \in \mathbb{R}^n$, $a_j > 0$, $j = 1, \dots, n$. Queremos estudiar la aplicación del Método Simple de Primer Orden a este problema, para llegar a una solución aproximada con error $\epsilon > 0$.

- (a) Determine explícitamente el gradiente y el Hessiano de f y argumente que esta función es convexa (utilice cualquier caracterización que conozca de la convexidad y que sea adecuada).
- (b) En clases argumentamos que uno podía tratar de estimar una constante de Lipschitz, L , para ∇f tratando de buscar una cota superior a la norma de la matriz Hessiana de f (así se hizo para el ejemplo de función cuadrática). Argumente que eso aquí no va a funcionar, es decir, no hay cota a la norma del Hessiano (no necesita ponerse a calcular la norma exacta del Hessiano ni nada de eso, de un argumento simple pero sólido y basado en el problema).
- (c) Lo anterior sugiere que no se podría usar el Método Simple de Primer Orden, pero, suponga que tenemos un punto x^0 como punto inicial. Argumente que, dado que el método es de descenso y la función f es convexa, en la medida que el paso cumpla con las condiciones de Wolf-Armijo, cualquier punto x^k generado por el método estará contenido en el conjunto de nivel $S_0 = \{x : f(x) \leq f(x^0)\}$. Justifique con precisión su argumento en función de los contenidos del curso

(**Hint:** piense en cómo se ven las curvas de nivel de una función convexa y piense cómo se movería un método de descenso).
- (d) Sobre la base de la conclusión de la pregunta anterior argumente que sí se podría estimar una constante de Lipschitz L que pueda ser usada en el Método Simple de Primer Orden, partiendo del x^0 mencionado en la parte c) y que las iteraciones son válidas para cualquier punto que el método requiera evaluar.
- (e) Determine si acaso se podría obtener con certeza una velocidad de convergencia del método simple de primer orden, tipo $\mathcal{O}(\log \frac{1}{\epsilon})$ para este problema. Justifique con precisión su argumento.

Ejercicio 5

- (a) Supongamos que se quiere resolver el problema $\min_{x \in \mathbb{R}^n} f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es 2 veces continuamente diferenciable, fuertemente convexa, y tal que ∇f es L -Lipschitz. Se considera usar el Método de Primer Orden acelerado de Nesterov o el Método de Newton para este problema. Es fácil darse cuenta que el esfuerzo computacional por iteración del método acelerado de Nesterov es $\mathcal{O}(n)$ flops, y usted conoce cuál es el esfuerzo, en flops, por iteración del Método de Newton. Además, usted conoce el orden de número de iteraciones de ambos métodos para llegar a un error $\epsilon > 0$. Llamemos C el tiempo efectivo de reloj que requiere un computador específico para realizar un flop (una operación de punto flotante). Para efectos de lo que sigue, asuma que el tiempo adicional que involucra calcular gradientes y Hessianos es despreciable (puede no ser verdad, pero lo tomaremos así para simplificar).

Determine, estimativamente, sobre la base de las propiedades de convergencia de cada método, a partir de qué valor de n conviene usar el método acelerado de Nesterov en vez del método de Newton para llegar en el menor tiempo posible a una solución ϵ -óptima del problema, todo esto para un $0 < \epsilon < 1$ dado. (En este problema tendrá que asumir, tal vez, algunas constantes como conocidas o cosas así, y eso está bien, pero deberá explicar con claridad todos los supuestos que haga para llegar a una respuesta).

- (b) Considere la siguiente función de máxima verosimilitud para un problema de estimación estadística:

$$g(v_1, \dots, v_k) = \sum_{i=1}^m \left(y_i \log \left(\sum_{j=1}^k v_j u_j^i \right) - \sum_{j=1}^k v_j u_j^i \right)$$

donde los y_i son los datos diarios de accidentes de tránsito y los u_j^i eran los valores de varios factores explicativos que se postulan. El problema consistía en determinar v de modo que se maximice $g(v)$.

Para un punto arbitrario, las fórmulas para el gradiente y Hessianos son:

$$\nabla g(v) = \sum_{i=1}^m \left(y_i \frac{u^i}{v^\top u^i} - u^i \right), \quad \nabla^2 g(v) = \sum_{i=1}^m \left(-y_i \frac{u^i (u^i)^\top}{(v^\top u^i)^2} \right)$$

Donde llamamos U a la matriz de los datos de los factores explicativos, siendo u^i el vector de la fila i de la matriz de datos de los factores explicativos.

Se propone usar el Método Simple de Primer Orden. Determine si acaso se podrá o no usar el método. Más en específico, usted sabe que el método requiere una constante L adecuada, así que lo que le pedimos es que discuta si acaso puede determinarse un L adecuado para este problema. Si su respuesta es afirmativa, especifique cómo haría esa estimación y en caso de ser negativa, justifíquelo con precisión.