



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025-2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 4

Método del Subgradiente

21 de agosto de 2025

Resumen

- **Condición de Lipschitz:** $|f(x) - f(y)| \leq L |x - y| \quad \forall x, y$
- **Método de Gradiente (Convergencia lineal):**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
 2. Sea $d^k = -\nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
 5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.
- **Método de Newton (Convergencia cuadrática):**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
 2. Sea $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
 5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.
- **Método simple de primer orden:**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, d^0 = -\nabla f(x^0), \epsilon > 0$.
 2. Sea $d^k = -\nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea $x^{k+1} = x^k + \frac{1}{L} d^k, k \leftarrow k + 1$, go to 2.

■ **Método del subgradiente:**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, -d^0 \in \partial f(x^0), \epsilon > 0$.
2. Sea $-d^k \in \partial f(x^k)$
3. Si el criterio de parada se satisface, entonces STOP. En caso contrario, continuar con el paso siguiente.
4. Sea $x^{k+1} = x^k + \lambda_k d^k, k \leftarrow k + 1$, go to 2.

■ **Gradiente**

El Gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

■ **Matriz Hessiana**


Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- **Dirección de descenso:** d es dirección de descenso si cumple que $d^\top \nabla f(x) < 0$

Ejercicio 1

- (a) **(Propuesto)** Explique, basado en las características de los gráficos, cuál método que, probablemente, mostrará mayores diferencias en número de iteraciones cuando se aplica a f_1 y a f_2 y justifique por qué.



Solución: El Método del Gradiente posiblemente mostrará mayores diferencias entre f_1 y f_2 , ya que sus características de convergencia dependen del condicionamiento de la matriz $\nabla^2 f(x^*)$. Por las figuras se deduce que es mucho mayor en el caso de f_1 que en f_2 . Si bien, el Método de Newton también se ve afectado por el condicionamiento de $\nabla^2 f(x^*)$, este efecto es menor y se ve compensado por la reducción cuadrática del error.

- (b) Considere la siguiente función, que está definida en $\mathbb{R}^n$:

$$f(x) = x^\top Qx + \|Ax\|_2^2 + \sum_{j=1}^n \max\{\alpha_j, x_j^4\}$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, $\alpha_j > 0, j = 1, \dots, n$, $A \in \mathbb{R}^{n \times n}$.

- (i) Argumente que esta función es convexa y determine $\partial f(x)$ en un punto $x \in \mathbb{R}^n$ cualquiera.

Solución: Para determinar la convexidad de la función dada podemos analizar su convexidad término a término (dividir la función en varias funciones).

- $x^\top Qx \rightarrow$ Como la matriz Q es definida positiva, entonces se puede afirmar que esta parte de la función es convexa.
- $\|Ax\|_2^2 \rightarrow$ Por lo visto en clase podemos asumir que esta parte de la función también es convexa (basta con analizar la naturaleza del Hessiano de esta función).
- $\sum_{j=1}^n \max\{\alpha_j, x_j^4\} \rightarrow$ Por enunciado sabemos que α_j es positivo para cualquier j y como el máximo es una función convexa y la suma también, esta parte

también es convexa. Una representación gráfica argumentada también es válida.

Finalmente como $f(x)$ es la suma de estas funciones que son convexas, se puede afirmar que es convexa.

Ahora para determinar $\partial f(x)$ debemos notar que $\sum_{j=1}^n \max\{\alpha_j, x_j^4\}$ no es diferenciable mientras que los demás términos si lo son.

- $\nabla x^\top Q x = 2Qx$ debido a que Q es simétrica.
- $\nabla \|Ax\|_2^2 = 2A^\top(Ax)$.
- Definimos un subdiferencial h para $\sum_{j=1}^n \max\{\alpha_j, x_j^4\}$ por lo que tenemos lo siguiente:

$$\nabla h(x) = \begin{cases} 4x_j^3 & \text{si } x_j < -\sqrt[4]{\alpha_j} \\ 4x_j^3 & \text{si } x_j > \sqrt[4]{\alpha_j} \\ 0 & \text{si } -\sqrt[4]{\alpha_j} < x_j < \sqrt[4]{\alpha_j} \\ \mu : \mu \in [4(-\sqrt[4]{\alpha_j})^3, 0] & \text{si } x_j = -\sqrt[4]{\alpha_j} \\ \nu : \nu \in [0, 4(\sqrt[4]{\alpha_j})^3] & \text{si } x_j = \sqrt[4]{\alpha_j} \end{cases}$$

Este ultimo se podría escribir de forma mas compacta, lo importante es que sea claro el argumento.

- (ii) Suponga que sabemos que cualquier valor x que podamos encontrar en los algoritmos cumplirá con que $\|x\|_2 \leq R$. Estime un valor para una constante de Lipschitz de f que sea válida en una región del espacio $\mathbb{R}^n$ de a lo más radio R desde el origen, es decir, en $B(0, R) = \{y : \|y\|_2 \leq R\}$.

Solución: Para este inciso, lo más sencillo será descomponer por partes el gradiente

y usar la propiedad de desigualdad triangular. Tomando $\|\nabla f(x)\|_2 \leq L$ se tiene:

$$\nabla f(x) = 2Qx + 2A^\top(Ax) + \begin{cases} 4x_j^3 & \text{si } x_j < -\sqrt[4]{\alpha_j} \\ 4x_j^3 & \text{si } x_j > \sqrt[4]{\alpha_j} \\ 0 & \text{si } -\sqrt[4]{\alpha_j} < x_j < \sqrt[4]{\alpha_j} \\ \mu : \mu \in [4(-\sqrt[4]{\alpha_j})^3, 0] & \text{si } x_j = -\sqrt[4]{\alpha_j} \\ \nu : \nu \in [0, 4(\sqrt[4]{\alpha_j})^3] & \text{si } x_j = \sqrt[4]{\alpha_j} \end{cases}$$

Se define

$$\nabla g(x) = 2Qx$$

$$\nabla p(x) = 2A^\top(Ax)$$

$$\nabla h(x) = \begin{cases} 4x_j^3 & \text{si } x_j < -\sqrt[4]{\alpha_j} \\ 4x_j^3 & \text{si } x_j > \sqrt[4]{\alpha_j} \\ 0 & \text{si } -\sqrt[4]{\alpha_j} < x_j < \sqrt[4]{\alpha_j} \\ \mu : \mu \in [4(-\sqrt[4]{\alpha_j})^3, 0] & \text{si } x_j = -\sqrt[4]{\alpha_j} \\ \nu : \nu \in [0, 4(\sqrt[4]{\alpha_j})^3] & \text{si } x_j = \sqrt[4]{\alpha_j} \end{cases}$$

Por lo tanto para cada gradiente tenemos:

$$\nabla g(x) \rightarrow \|2Qx\|_2 \leq 2\|Q\|_2 \cdot \|x\|_2 = 2\|Q\|_2 \cdot R$$

$$\nabla p(x) \rightarrow \|2A^\top(Ax)\|_2 \leq 2\|A^\top A\|_2 \cdot \|x\|_2 = 2\|A^\top A\|_2 \cdot R$$

$$\nabla h(x) \rightarrow \sqrt{n} \cdot 4 \cdot R^3$$

Por lo tanto el L nos da:

$$L = 2\|Q\|_2 \cdot R + 2\|A^\top A\|_2 \cdot R + \sqrt{n} \cdot 4 \cdot R^3$$

-
- (iii) Estime el esfuerzo computacional, en flops, de calcular un subgradiente de f , según lo que desarrolló en la parte (i).

Solución: Para estimar el esfuerzo computacional que se requiere para calcular el subgradiente de (i), es necesario analizar cada una de las componentes por separado:

- $2Qx \rightarrow$ Es una matriz por un vector, así que por lo aprendido en el curso sabemos que el orden es $\mathcal{O}(n^2)$.
- $2A^\top(Ax) \rightarrow (Ax)$ es una matriz por un vector, que queda como un vector (μ), y luego tenemos $A^\top\mu$, lo que es una matriz por vector de nuevo y nos da un orden final de $\mathcal{O}(n^2)$. Alternativamente podemos tener una matriz $A' = A^\top A$ entonces $A'x$ constituye a una matriz por vector que corresponde a un orden de $\mathcal{O}(n^2)$.
- Finalmente se tiene

$$\nabla h(x) = \begin{cases} 4x_j^3 & \text{si } x_j < -\sqrt[4]{\alpha_j} \\ 4x_j^3 & \text{si } x_j > \sqrt[4]{\alpha_j} \\ 0 & \text{si } -\sqrt[4]{\alpha_j} < x_j < \sqrt[4]{\alpha_j} \\ \mu : \mu \in [4(-\sqrt[4]{\alpha_j})^3, 0] & \text{si } x_j = -\sqrt[4]{\alpha_j} \\ \nu : \nu \in [0, 4(\sqrt[4]{\alpha_j})^3] & \text{si } x_j = \sqrt[4]{\alpha_j} \end{cases}$$

En el peor de los casos, es $\mathcal{O}(n)$.

Por lo tanto, se concluye que el esfuerzo computacional máximo, en flops, es de $\mathcal{O}(n^2)$.

Ejercicio 2

En este problema consideramos una función de n variables dada por:

$$f(x) = \tau \sum_{j=1}^n \max\{(\alpha_j - x_j), 0\} + \|Ax\|_2^2$$

donde $\tau > 0$ es dado, los α_j **son escalares positivos**, y $A \in \mathbb{R}^{m \times n}$ con $n > m$.

- (a) **(Propuesto)** Determine el subdiferencial de f en cualquier punto x del dominio.

Solución: Tenemos:

$$\partial(\tau \sum_{j=1}^n \max\{(\alpha_j - x_j), 0\} + \|Ax\|_2^2) = \tau \cdot \partial(\sum_{j=1}^n \max\{(\alpha_j - x_j), 0\}) + 2A^\top Ax$$

Acá estamos abusando notación con ∂ pero es análogo a lo hecho en clases.

Tenemos que calcular, entonces, $\partial(\sum_{j=1}^n \max\{(\alpha_j - x_j), 0\})$. Esto se calcula en forma análoga a otros subgradientes que vimos en clases. Denotemos por $p(x)$ ese subgradiente, que es un vector de n componentes. Tenemos:

$$p(x)_j = \begin{cases} -1 & x_j < \alpha_j \\ 0 & x_j > \alpha_j \\ t \in [-1, 0] & x_j = \alpha_j \end{cases}$$

Entonces, si denotamos por $h(x)$ un subgradiente de la función objetivo en x , tenemos que

$$h(x) = \tau p(x) + 2A^\top Ax$$

En lo que sigue, considere $h(x)$ como el vector que representa el subgradiente de $f(x)$:

$$h(x) = \tau p(x) + 2A^\top Ax,$$

donde se tiene que:

$$p(x)_j = \begin{cases} -1 & x_j < \alpha_j \\ 0 & x_j > \alpha_j \\ t \in [-1, 0] & x_j = \alpha_j \end{cases}$$

A partir de lo anterior, responda:

- (b) Suponga que le dicen que se sabe que cualquier x relevante para el problema cumple con $\|x\|_2 \leq R$, donde R es una constante positiva. ¿Cumple la función f una condición de Lipschitz en el conjunto $\{x \in \mathbb{R}^n : \|x\|_2 \leq R\}$? En caso de ser así, estime esa

constante (Para esto le puede ser útil el siguiente resultado: si p es un subgradiente de f , entonces la constante de Lipschitz de f cumple $\|p\|_2 \leq L$), y en caso contrario, justifique por qué no.

Solución: Tenemos que $h(x) \in \partial f(x)$. Veamos qué pasa con $\|h(x)\|$:

$$\|\tau p(x) + 2A^\top Ax\|_2 \leq \tau\|p(x)\|_2 + 2\|A^\top Ax\|_2 \leq \tau\|p(x)\|_2 + 2\|A^\top A\| \cdot \|x\|_2$$

Pero sabemos que $\|x\|_2 \leq R$. Además, si $p(x)_j = 1$ para todo $j = 1, \dots, n$, tenemos la cota $\|p(x)\| \leq \sqrt{n}$. Juntando esto, tenemos

$$\|\tau p(x) + 2A^\top Ax\|_2 \leq \tau\sqrt{n} + 2\|A^\top A\|R$$

Esto no depende de x (debido a que acotamos la norma de x , al estar restringido a una región acotada) por lo que obtenemos una cota (y valor adecuado) para L .

(c) Ahora queremos resolver el siguiente problema de optimización:

$$\begin{array}{ll} \text{mín} & f(x) \\ \text{s. a.} & 0 \leq x_j \leq 1, j = 1, \dots, n \end{array}$$

Especifique los pasos del método del subgradiente para este problema siendo explícito en la forma de resolver cualquier subproblema adicional que se presente.

Solución: Tenemos un problema del estilo

$$\begin{array}{ll} \text{mín} & f(x) \\ \text{s. a.} & x \in S \end{array}$$

con $S = \{x \in \mathbb{R}^n : 0 \leq x_j \leq 1 \ \forall j \in \{1, \dots, n\}\}$ convexo. Luego, el algoritmo es:

Data: Sea $x^0 \in \mathbb{R}^n, k = 0, -h^0 \in \partial f(x^0), \epsilon > 0$.

while *Criterio de parada no se satisface* **do**

$x^{k+1} = \text{Proy}_S(x^k + \lambda^k h^k)$
 $-h^{k+1} \in \partial f(x^{k+1})$
 $k = k + 1$

end

Aquí $\text{Proy}_S(x^k + \lambda^k d^k)$ denota la proyección sobre S . El problema de proyección es:

$$\begin{array}{ll} \text{mín} & \|y - (x^k + \lambda^k d^k)\|_2 \\ \text{s. a.} & y \in S \end{array}$$

lo que simplemente se reduce a

$$\text{Proy}_S(u)_j = \begin{cases} u_j & 0 \leq u_j \leq 1 \\ 0 & u_j < 0 \\ 1 & u_j > 1 \end{cases}$$

- (d) Suponga que queremos aplicar FISTA a este problema. Explique cómo se debe escribir el problema para usarlo con FISTA y determine la constante de Lipschitz que tendría que usar en el método. Explique y justifique con precisión.

Solución: Podemos reescribir cada término de la parte no diferenciable de la función objetivo como

$$\max\{(\alpha_j - x_j), 0\} = \frac{|\alpha_j - x_j|}{2} + \frac{\alpha_j - x_j}{2}$$

Con esto, sumamos todos los términos y obtenemos

$$\sum_{j=1}^n \max\{(\alpha_j - x_j), 0\} = \sum_{j=1}^n \frac{|\alpha_j - x_j|}{2} + \frac{\alpha_j - x_j}{2} = \frac{1}{2} \|\alpha - x\|_1 + \frac{1}{2} (\alpha - x)^\top e$$

La función objetivo se vuelve

$$f(x) = \frac{\tau}{2} \|\alpha - x\|_1 + \frac{\tau}{2} (\alpha - x)^\top e + \|Ax\|_2^2$$

Es decir, tenemos que la parte diferenciable de la función es

$$h(x) = \frac{\tau}{2} (\alpha - x)^\top e + \|Ax\|_2^2$$

y su gradiente es

$$\nabla h(x) = -\frac{\tau}{2} e + 2A^\top Ax$$

Luego, veamos qué pasa con $\|\nabla h(x) - \nabla h(y)\|_2$:

$$\|\nabla h(x) - \nabla h(y)\|_2 = \left\| -\frac{\tau}{2} e + 2A^\top Ax + \frac{\tau}{2} e - 2A^\top Ay \right\|_2 = \|2A^\top A(x - y)\|_2 \leq 2\|A^\top A\| \cdot \|x - y\|_2$$

Lo que quiere decir que $L = 2\|A^\top A\|$ y así obtenemos la desigualdad

$$\|\nabla h(x) - \nabla h(y)\|_2 \leq 2\|A^\top A\| \cdot \|x - y\|_2$$

Ejercicios Propuestos

Ejercicio 1


Considere la siguiente función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ dada como $f(x) = \sum_{j=1}^n g_j(x_j) + \|Ax - b\|_2^2$, donde las funciones de una variable g_j están dadas por:

$$g_j(t) = \begin{cases} \gamma_j + \beta_j t^2 & \text{si } t > \alpha_j \\ 0 & \text{si } t \leq \alpha_j \end{cases}$$

donde $\beta_j > 0, \gamma_j < 0, \alpha_j = \sqrt{-\gamma_j/\beta_j}$ (tome la raíz > 0), para cada $j = 1, \dots, n$. La matriz A es de $m \times n$ y $b \in \mathbb{R}^m$.

- (a) Haga un gráfico de una función g_j y de ahí, más otros argumentos adicionales, muestre que la función f es convexa, y determine una expresión general para $\partial f(x)$ en cualquier punto $x \in \mathbb{R}^n$.

Solución: El gráfico de g_j es el siguiente:



De aquí se deduce que las funciones g_j son convexas. Además $\|Ax - b\|_2^2$ es evidentemente convexa (se puede asumir lo que se sabe de las clases). Luego, la suma total, que es $f(x)$, es convexa. Ahora, para determinar $\partial f(x)$, debemos determinar la forma general de un subgradiente. Cualquier subgradiente será de la forma:

$$p = u(x) + 2A^\top(Ax - b)$$

donde $u(x)$ es un subgradiente de $\sum_{j=1}^n g_j(x_j)$. Para $u(x)$ tenemos la siguiente expresión:

$$u(x)_j = \begin{cases} 2\beta_j x_j, & x_j > \alpha_j \\ 0, & x_j < \alpha_j \\ \text{cualquier } s \in [0, 2\beta_j \alpha_j], & x_j = \alpha_j \end{cases}$$

-
- (b) Ahora queremos encontrar un mínimo de f y para eso vamos a usar el método del subgradiente, tal como fue presentado en clases. Vamos a suponer que, a partir de información del problema subyacente, se sabe que los puntos de interés (los puntos que evaluará el algoritmo) incluyendo el óptimo, tienen la propiedad de que $|x_j| \leq M, j = 1, \dots, n$, donde M es conocido. Explique los pasos del método y determine valores adecuados para los parámetros que se usan en el algoritmo (incluyendo el paso de avance). Le puede ser útil aquí un resultado que mostramos en clases: para una función convexa f que cumple propiedad de Lipschitz con constante L , si $p \in \partial f(x)$, entonces $\|p\|_2 \leq L$.

Solución: El Método del subgradiente funcionará de la siguiente manera:

0. Sea $x^0 \in \mathbb{R}^n, k = 0$.
1. Sea $d^k = -u$, donde $u \in \partial f(x^k)$
2. Si se satisface un criterio de parada, STOP.
3. Si no, $x^{k+1} = x^k + \lambda_k d^k, k = k + 1$, Go to 1 .

en donde, si decidimos hacer K iteraciones, $\lambda_i = \frac{R}{L\sqrt{K+1}}$. Luego, se necesita R y L , donde R es tal que $\|x\| \leq R$, para cualquier punto relevante del método, y L es la constante de Lipschitz de f . Para R podemos usar el que $|x_j| \leq M, j = 1, \dots, n$. Luego, $\|x\| \leq \sqrt{n}M$ y podemos tomar $R = \sqrt{n}M$. Para L basta (por el resultado que nos dan) que acotemos $\|p\|_2$ para cualquier subgradiente p de f .

Por la expresión para un subgradiente p que tenemos de la parte anterior, podemos acotar:

$$\|p\|_2 \leq \|u(x)\|_2 + 2 \|A^\top A\| \|x\| + 2 \|A^\top b\|$$

Por otro lado, si vemos la expresión para $u(x)$, podemos ver que

$$\|u(x)\| \leq \sqrt{2n \max_{j=1, \dots, n} \{\beta_j\} M}$$

Luego,

$$\|p\|_2 \leq \sqrt{2n \max_{j=1, \dots, n} \{\beta_j\} M} + 2 \|A^\top A\| \sqrt{n}M + 2 \|A^\top b\| = L$$

Estos son los valores que se debieran usar para el paso.

Ejercicio 2

- (a) En algunas aplicaciones de Machine Learning es necesario resolver un problema de la siguiente forma:

$$\begin{aligned} \min \quad & \|x - u\|_2^2 + \tau \sum_{j=1}^n \max\{\gamma_j, \beta_j x_j\} \\ \text{s.a} \quad & \sum_{j=1}^n x_j \leq 1 \\ & x_j \geq 0, j = 1, \dots, n \end{aligned}$$

donde $u \in \mathbb{R}^n$ es fijo y conocido, al igual que $\tau > 0$. Los γ_j, β_j también son escalares positivos conocidos.

Indique con cuál algoritmo se podrá abordar este problema, de todos los que han visto en el curso, para encontrar una solución ϵ -óptima. Detalle los pasos principales del algoritmo seleccionado por usted aplicado al problema, mostrando todo elemento que deba calcular en forma específica a este problema para que funcione el algoritmo.

Solución: Un algoritmo que se puede usar es el Método de Subgradiente Proyectado. El algoritmo necesita, para funcionar, un subgradiente de la función objetivo. Para esto hagamos:

$$\partial(\|x - u\|_2^2 + \tau \sum_{j=1}^n \max\{\gamma_j, \beta_j x_j\}) = 2(x - u) + \tau \partial(\sum_{j=1}^n \max\{\gamma_j, \beta_j x_j\})$$

(Acá estamos abusando notación con ∂ pero es análogo a lo hecho en clases).

Tenemos que calcular, entonces, $\partial(\sum_{j=1}^n \max\{\gamma_j, \beta_j x_j\})$. Esto se calcula en forma análoga a otros subgradientes. Denotemos por $p(x)$ ese subgradiente, que es un vector de n componentes. Tenemos:

$$p(x)_j = \begin{cases} 0 & x_j < \gamma_j/\beta_j \\ \beta_j & x_j \geq \gamma_j/\beta_j \\ t \in [0, \beta_j] & x_j = \gamma_j/\beta_j \end{cases}$$

Entonces, si denotamos por $h(x)$ un subgradiente de la función objetivo en x , tenemos que

$$h(x) = 2(x - u) + \tau p(x)$$

El algoritmo es, entonces:

Data: Sea $x^0 \in \mathbb{R}^n$, $k = 0$, $-h^0 \in \partial f(x^0)$, $\epsilon > 0$.

while *Criterio de parada no se satisface* **do**

$x^{k+1} = \text{Proy}_S(x^k + \lambda^k h^k)$
 $-h^{k+1} \in \partial f(x^{k+1})$
 $k = k + 1$

end

Aquí $\text{Proy}_S(x^k + \lambda^k h^k)$ denota la proyección sobre S , que en este caso es $S = \{x : \sum_{j=1}^n x_j \leq 1, x_j \geq 0, j = 1, \dots, n\}$. El problema de proyección es:

$$\begin{array}{ll} \text{mín} & \|y - (x^k + \lambda^k h^k)\|_2 \\ \text{s. a.} & y \in S \end{array}$$

(b) Considere la siguiente función definida en $\mathbb{R}^n$:

$$g(x) = x^\top Mx + \|Ax + b\|_2^2 + \sum_{j=1}^n \max\{\beta_j, |x_j|^3\}$$

donde $M \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$ es un vector, y $\beta_j > 0$ para $j = 1, \dots, n$.

- (i) Argumente que esta función es convexa y determine $\partial f(x)$ en un punto $x \in \mathbb{R}^n$ cualquiera. Para responder sobre la convexidad puede usar conocimiento previo sobre determinadas funciones, y propiedades conocidas de las funciones convexas.

Solución: Al igual que en el taller anterior, para determinar la convexidad de $g(x)$, analizamos la convexidad de cada uno de sus términos:

- $x^\top Mx$: Sabemos que la función cuadrática $x^\top Mx$ es convexa si y solo si la matriz M es semidefinida positiva ($M \succeq 0$). En este caso, se nos da que M es definida positiva ($M \succ 0$), lo que implica que es semidefinida positiva y, por lo tanto, la función $x^\top Mx$ es convexa.
- $\|Ax + b\|_2^2$: Dado que su Hessiano ($2A^\top A$) es semidefinido positivo (ya que $B^\top B$ es semidefinida positiva para cualquier matriz B), concluimos que $\|Ax + b\|_2^2$ es una función convexa.
- $\sum_{j=1}^n \max\{\beta_j, |x_j|^3\}$: El máximo de funciones convexas es convexa (su segunda derivada siempre es no negativa), y dado que $|x_j|^3$ es convexa en $\mathbb{R}$ y β_j es constante, esta parte también es convexa.

Dado que la suma de funciones convexas es convexa, concluimos que $g(x)$ es convexa.

Calculamos el subgradiente para cada término:

- $\nabla(x^\top Mx) = 2Mx$.
- $\nabla\|Ax + b\|_2^2 = 2A^\top(Ax + b)$.
- Definiendo $h_j(x) = \max\{\beta_j, |x_j|^3\}$, su subgradiente en la componente $j \in \{1, \dots, n\}$ es:

$$\nabla h_j(x_j) = \begin{cases} 3x_j^2, & \text{si } |x_j| > \sqrt[3]{\beta_j}, \\ 0, & \text{si } |x_j| < \sqrt[3]{\beta_j}, \\ \mu_j : \mu_j \in [0, 3(\sqrt[3]{\beta_j})^2], & \text{si } |x_j| = \sqrt[3]{\beta_j}. \end{cases}$$

Por lo tanto, el subgradiente de $g(x)$ está dado por:

$$\partial g(x) = 2Mx + 2A^\top(Ax + b) + \sum_{j=1}^n \partial h_j(x_j).$$

- (ii) Suponga que sabemos que cualquier valor x que podamos encontrar en los algoritmos cumplirá con que $\|x\|_2 \leq R$, y que $|x_j| \leq K$. Estime un valor para una constante de Lipschitz de f que sea válida en una región del espacio $\mathbb{R}^n$ de a lo más radio R desde el origen, es decir, en $B(0, R) = \{y : \|y\|_2 \leq R, |y_j| \leq K \ \forall j\}$.

Solución: Dado que $\|x\|_2 \leq R$, usamos las siguientes desigualdades:

- $\|2Mx\|_2 \leq 2\|M\|_2 R$.
- $\|2A^\top(Ax + b)\|_2 \leq 2\|A^\top A\|_2 R + 2\|A^\top b\|_2$.
- $\nabla h_j(x) \leq 3K^2$ en el peor caso, así que $\|\nabla h(x)\|_2 \leq 3\sqrt{n}K^2$.

Por lo tanto, una cota válida para la constante de Lipschitz de $g(x)$ en $B(0, R)$ es:

$$L = 2\|M\|_2 R + 2\|A^\top A\|_2 R + 2\|A^\top b\|_2 + 3\sqrt{n}K^2.$$

- (iii) Estime el esfuerzo computacional, en flops, de calcular un subgradiente de f , según lo que desarrolló en la parte a).

Solución: El costo en flops de calcular un subgradiente es:

- $2Mx$: $\mathcal{O}(n^2)$.

-
- $2A^\top(Ax + b)$: $\mathcal{O}(n^2)$.
 - Evaluación de $\partial h_j(x_j)$: $\mathcal{O}(n)$.

La complejidad total es $\mathcal{O}(n^2)$.

(c) Considere la siguiente función de n variables:

$$f(x) = \|Ax - b\|_2^2 + \sum_{j=1}^n \max\{0, (e^{-x_j} - 1)\}$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Muestre que f es convexa y determine una expresión para $\partial f(x)$ para todo x . En otras palabras, determine expresiones generales para los subgradiientes de f .

Solución: Para demostrar la convexidad de f se puede probar la convexidad de cada uno de sus elementos, así, para (1) $\|Ax - b\|_2^2$, tenemos que su hessiano cumple con $\nabla^2 f(x) = 2A^\top A \succeq 0$, luego (1) es convexa. Por otra parte, para (2) $\sum_{j=1}^n \max\{0, e^{-x_j} - 1\}$ analizando de adentro hacia afuera, tenemos que 0 es una función lineal y por tanto convexa, mientras que,

$$\frac{\partial^2 e^{-x_j}}{\partial x_j^2} = e^{-x_j} > 0 \quad \forall x \in \text{dom } f$$

luego $e^{-x_j} - 1$ es convexa en x_j . Concluyendo, como el máximo de funciones convexas es convexo, y la suma de funciones convexas es convexa, tenemos que f es convexa.

Para encontrar el subdiferencial de f , tenemos:

$$\begin{aligned} \partial f(x) &= \partial \|Ax - b\|_2^2 + \partial \sum_{j=1}^n \max\{0, e^{-x_j} - 1\} \\ &= \partial \|Ax - b\|_2^2 + \sum_{j=1}^n \partial \max\{0, e^{-x_j} - 1\} \\ &= 2A^\top(Ax - b) + \sum_{j=1}^n \partial \max\{0, e^{-x_j} - 1\} \end{aligned}$$

donde

$$\partial \max\{0, e^{-x_j} - 1\} = p(x_j) = \begin{cases} 0 & x_j > 0 \\ -e^{-x_j} & x_j < 0 \\ [-1, 0] & x_j = 0 \end{cases}$$

Finalmente el diferencial queda:

$$\partial f(x) = 2A^\top(Ax - b) + \sum_{j=1}^n p(x_j)$$

Ejercicio 3

Vamos a considerar el siguiente problema de estimación estadística. Tenemos m observaciones de un cierto fenómeno, $b_1, \dots, b_m$ y queremos explicarlo en función de n factores, para los cuales también existen valores conocidos a_{ij} , que es el valor del factor j para la observación i . Entonces, se postula un modelo lineal de la forma:

$$\sum_{j=1}^n a_{ij}x_j = b_i, \quad i = 1, \dots, m$$

en donde los x_j son los pesos de los factores. Entonces, queremos encontrar la mejor solución posible al sistema de ecuaciones $Ax = b$. Este problema lo hemos planteado ya en el curso, usando mínimos cuadrados pero acá usaremos un criterio distinto, el error en valor absoluto. Adicionalmente, por propiedades del problema subyacente, se sabe que los coeficientes de la estimación, las variables x , deben estar dentro de ciertos rangos específicos y conocidos. Entonces, se plantea resolver el siguiente problema de optimización:

$$\begin{aligned} \text{mín} \quad & \|Ax - b\|_1 \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y los l_j, u_j son todos escalares conocidos. Como usted debe observar, la función objetivo de este problema es no diferenciable.

- (a) Determine un subgradiente de la función objetivo del problema en un punto x factible. (Indicación: le recordamos una relación que se ha usado ya en el curso, para hacer “regla de la cadena no diferenciable”, sea f una función convexa, si $p \in \partial f(x)$ y $g(x) = f(Bx)$, donde B es alguna matriz de dimensiones adecuadas, entonces $B^\top p \in \partial g(x)$.)

Solución: Sea $f(x) = \|Ax - b\|_1 = \sum_{i=1}^m |\alpha_i^\top x - b_i|$

Luego, se deriva usando la regla de la cadena:

$$\partial f(x) = \sum_{i=1}^m \partial |\alpha_i^\top x - b_i| = \sum_{i=1}^m \alpha_i \cdot p_i(x)$$

Donde definimos $p(x) \in \mathbb{R}^m$ como

$$p_i(x) = \begin{cases} 1 & \text{si } \alpha_i^\top x - b_i > 0 \\ -1 & \text{si } \alpha_i^\top x - b_i < 0 \\ u \in [-1, 1] & \text{si } \alpha_i^\top x - b_i = 0 \end{cases}$$

Finalmente, denotamos $h(x) \in \partial f(x)$ tal que:

$$h(x) = \sum_{i=1}^m \alpha_i p_i(x)$$

Una forma alternativa es derivando utilizando la indicación del enunciado:

$$\partial f(x) = \partial \|Ax - b\|_1 = A^\top \partial \|Ax - b\|_1 = A^\top p(x)$$

Con $p(x)$ definido anteriormente.

- (b) Explique, en forma detallada y con el desarrollo matemático correspondiente, cómo manejar las restricciones $l_j \leq x_j \leq u_j, j = 1, \dots, n$ del problema, si se usa el método de subgradiente para el problema.

Solución: Para poder manejar las restricciones, es necesario utilizar el Método del Subgradiente Proyectado. Para esto, se debe proyectar x en cada iteración del algoritmo, sobre el conjunto $D = \{x : \forall j \ l_j \leq x_j \leq u_j\}$.

Lo que se debe hacer es revisar cada cordenada x_j y determinar si es que está se encuentra dentro del conjunto D. Si $l_j \leq x_j \leq u_j$, entonces esta coordenada queda igual. Por otro lado, si $x_j < l_j$, esta coordenada se debe poner en l_j y si $x_j > u_j$, se debe llevar a u_j . Esto es:

$$\Pi_D(x)_j = \begin{cases} x_j & \text{si } l_j \leq x_j \leq u_j \\ l_j & \text{si } x_j < l_j \\ u_j & \text{si } x_j > u_j \end{cases}$$

Se puede apoyar la respuesta con un dibujo.

- (c) Ahora le proponen hacer una transformación al problema y poder resolverlo con algún algoritmo, ojalá, más eficiente que el método de subgradiente. Para esto, considere la función $g : \mathbb{R} \rightarrow \mathbb{R}$ dada por $g(u) = \sqrt{u^2 + \mu}$ donde $\mu > 0$ es un parámetro dado. Muestre que $g(u) \approx |u|$, es decir, se puede usar para aproximar el valor absoluto, y que esa aproximación se hace cada vez mejor mientras más chico sea μ (puede dar un argumento simple, basado en aproximaciones matemáticas y apoyarse, también, en un gráfico, si lo desea).

Solución:

Se tiene que

$$g(u) = \sqrt{u^2 + \mu} = \sqrt{u^2(1 + \frac{\mu}{u^2})} = |u| \sqrt{1 + \frac{\mu}{u^2}}$$

Para valores de u muy grandes, $\frac{\mu}{u^2} \rightarrow 0$, por lo que $\sqrt{1 + \frac{\mu}{u^2}} \approx \sqrt{1} = 1$. Luego

$$g(u) \approx |u| \cdot 1 = |u|$$

Por otro lado, para valores de u más pequeños, la aproximación no sería tan buena. Ahora bien, si $\mu \rightarrow 0 \Rightarrow \frac{\mu}{u^2} \rightarrow 0$, por lo que a través del mismo razonamiento anterior se concluye que $g(u) \approx |u|$.

- (d) Dado lo anterior, se propone ahora resolver, alternativamente, el problema:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m g(\alpha_i^\top x - b_i) \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $\alpha_1, \dots, \alpha_m$ son las filas de la matriz A , usando un algoritmo basado en el Método Acelerado de Nesterov (no es necesario recordar todo el detalle). ¿Puede usarse el Método Acelerado de Nesterov, con alguna etapa adicional, para este problema? Justifique con precisión sobre la base de las hipótesis necesarias para que funcione el algoritmo y otras propiedades que hemos visto en el curso, no tiene que describir el detalle del algoritmo.

Solución: La respuesta es sí. En primer lugar, es importante identificar que se debe usar el Método Acelerado de Nesterov Proyectado, ya que el problema incluye restricciones acotadas en x , lo que requiere proyectar las soluciones propuestas en cada iteración sobre el conjunto factible $[l, u]$. Esta etapa se incorpora en el algoritmo y se maneja de la misma manera que se menciona en el inciso b).

En segundo lugar, definimos

$$f(x) = \sum_{i=1}^m g(\alpha_i^\top x - b_i)$$

Luego, se observa que se cumplen los supuestos necesarios para poder utilizar este algoritmo. Estos son:

- Función convexa.

Esto se puede ver ya que la función $(\cdot)^2$ es convexa y la función $\sqrt{\cdot}$ es no decreciente. Se puede argumentar a través de un gráfico.

- Función doblemente diferenciable.

Como se aproxima la función valor absoluto mediante $g(u)$, la función ahora es diferenciable, ya que se suaviza su comportamiento para valores de u pequeños, mediante el parámetro μ .

- $\nabla f(x)$ L -Lipschitz.

Dado que la solución se busca en un conjunto acotado, luego se sabe que la norma del Hessiano alcanzará su máximo dentro de este, por lo que es posible acotarlo.

Ejercicio 4

Consideremos el siguiente problema de optimización, que surge en algunas variantes de problemas de estimación estadística. Queremos resolver un problema de estimar un vector $b \in \mathbb{R}^m$ a partir de observaciones de otros n factores, las cuales están tabuladas en una matriz $A \in \mathbb{R}^{m \times n}$, pero donde n es mayor que m . Entonces, queremos encontrar una solución al sistema $Ax = b$. Ahora, en el curso hemos tratado de imponer una condición de que x tenga el menor número de elementos no nulos. Acá haremos algo un poco diferente: queremos minimizar el “largo” del vector x , que se define por $l(x) = \min\{k : x_j = 0, j > k\}$. Esto corresponde al menor índice de coordenadas a partir de la cual todas las otras son nulas. Es como buscar un vector x con la menor cantidad de coordenadas no nulas, pero que estén al comienzo del vector. Por ejemplo, con $n = 10$:

$$\begin{aligned}x &= (1, 2, 4, 0, 0, 0, 0, 0, 0, 0), l(x) = 3, \\y &= (1, 0, 0, 0, 0, 0, 0, 0, 8, 0), l(y) = 9.\end{aligned}$$

Podemos ver que y , pese a que tiene menos coordenadas no nulas, tiene largo 9 ya que $y_9 \neq 0$. Entonces, x es preferible a y pese a que tiene más coordenadas no nulas. Entonces, queremos resolver el problema:

$$\begin{aligned}\text{mín} \quad & l(x) \\ \text{s. a.} \quad & Ax = b\end{aligned}$$

Inspirados en lo que hicimos para el modelo LASSO, postulamos el siguiente problema aproximado, con la intención de obtener alguna solución que vaya en la dirección de nuestro objetivo:

$$\min_{x \in \mathbb{R}^n} \tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2$$

donde los números β_j son todos positivos y tales que $\beta_{j+1} > \beta_j$, y $\tau > 0$ es un parámetro de balance. Específicamente, tomemos la siguiente definición para estos números: $\beta_j = 2^j, j = 1, \dots, n$ (es decir, $\beta_1 = 2, \beta_2 = 4$, etc.).

- (a) Argumente que el resolver ese problema puede, efectivamente, generar una solución x que pudiera aproximarse a la estructura que buscamos, es decir, componentes x_j tales que $|x_j|$ sea bastante pequeño cuando j sea grande (y pueda ser redondeado a 0, como se hizo en clases).

Solución: Al analizar el comportamiento de la función objetivo, notamos que cada componente $|x_j|$ está penalizada con un peso $\beta_j = 2^j$, el cual crece exponencialmente con j . Esto implica que, para minimizar la función objetivo, se vuelve cada vez más costoso mantener valores distintos de cero en las posiciones con índices altos. Como resultado, el modelo tenderá a asignar valores más pequeños a los x_j con índices grandes, mientras que permitirá valores más grandes en las primeras coordenadas. Esta estructura incentiva soluciones donde los valores no nulos de x se concentren al

comienzo del vector, lo que está alineado con el objetivo de minimizar el largo $l(x)$. Por lo tanto, esta formulación aproximada puede efectivamente conducir a soluciones con la estructura deseada.

- (b) El problema planteado aquí es no diferenciable. Determine una fórmula general para $\partial f(x)$, donde f es la función objetivo del problema. Justifique con precisión todo lo que haga.

Solución: Sea $f(x) = \tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2$

Luego, obtenemos $\partial f(x)$ de la función:

$$\partial f(x) = \partial \left(\tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2 \right) = \left(\tau \cdot \partial \left(\sum_{j=1}^n \beta_j |x_j| \right) + \partial (\|Ax - b\|_2^2) \right)$$

Se puede observar que la función posee una parte diferenciable y una parte no diferenciable.

Para la parte diferenciable: $\partial (\|Ax - b\|_2^2) = 2A^\top (Ax - b)$

Para la parte no diferenciable: Definimos $p(x) \in \mathbb{R}^n$ como

$$p_j(x) = \begin{cases} \beta_j & \text{si } x_j > 0 \\ -\beta_j & \text{si } x_j < 0 \\ \mu \in [-\beta_j, \beta_j] & \text{si } x_j = 0 \end{cases}$$

Finalmente, denotamos $p(x) \in \partial f(x)$ tal que:

$$\partial f(x) = \tau \cdot p(x) + 2A^\top (Ax - b)$$

Una forma alternativa es derivando utilizando la función signo:

$$\partial f(x) = \tau \cdot \beta_j \cdot \text{sgn}(x) + 2A^\top (Ax - b)$$

- (c) Supongamos que queremos resolver este problema con el algoritmo FISTA. Justifique, según los contenidos del curso, que el problema efectivamente tiene el formato de problema que puede ser resuelto con FISTA. Y en este caso, ¿cuál sería la complejidad del algoritmo, en orden de número de iteraciones para llegar a una solución ϵ -óptima? (no use más de 5-6 líneas para responder esta pregunta).

Solución: El problema puede resolverse con el algoritmo FISTA debido a que su función objetivo se puede descomponer en la suma de dos términos: uno diferenciable y convexo, $\|Ax - b\|_2^2$, que además tiene gradiente L -Lipschitz; y otro no diferenciable pero convexo, $\sum_{j=1}^n \beta_j |x_j|$, que corresponde a una penalización ponderada tipo LASSO.

La complejidad del algoritmo en términos del número de iteraciones para alcanzar una solución ϵ -óptima es $\mathcal{O}(1/\sqrt{\epsilon})$.

-
- (d) Suponga que ahora se quiere resolver una variante restringida del problema, de la forma:

$$\begin{aligned} \text{mín} \quad & \tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2 \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $l_j < u_j, j = 1, \dots, n$. Si se usa ahora una versión proyectada del algoritmo FISTA, explique cómo se resuelve la etapa de proyección que debe incorporar en el algoritmo.

Solución: Para esto, se debe proyectar x en cada iteración del algoritmo, sobre el conjunto $D = \{x : l_j \leq x_j \leq u_j \forall j\}$.

Lo que se debe hacer es revisar cada cordenada x_j y determinar si es que está se encuentra dentro del conjunto D. Si $l_j \leq x_j \leq u_j$, entonces esta coordenada queda igual. Por otro lado, si $x_j < l_j$, esta coordenada se debe poner en l_j y si $x_j > u_j$, se debe llevar a u_j . Esto es:

$$\Pi_D(x)_j = \begin{cases} x_j & \text{si } l_j \leq x_j \leq u_j \\ l_j & \text{si } x_j < l_j \\ u_j & \text{si } x_j > u_j \end{cases}$$

Se puede apoyar la respuesta con un dibujo, pero este debe ser explicado adecuadamente.

Ejercicio 5

Suponga que dada una muestra de puntos en $\mathbb{R}^n$, usted ha podido agruparlos en m clusters.

El cluster i ha sido aproximado por la bola $B_i = B(c_i, r_i) = \{z \in \mathbb{R}^n : \|z - c_i\|_2 \leq r_i\}$, donde $c_i \in \mathbb{R}^n$ es el centro y $r_i > 0$ es el radio. Lo que le interesa determinar ahora es un punto $x^* \in \mathbb{R}^n$ que esté razonablemente cerca de todos los clusters a la vez. Para ello, sea $g_i(x) = d(x, B_i) = \min\{\|x - z\|_2 : z \in B_i\}$ la distancia de $x \in \mathbb{R}^n$ a B_i . Sea $f(x) = \sum_{i=1}^m g_i(x)$ la función que desea minimizar.

- (a) Muestre que $g_i(x) = \max\{\|x - c_i\|_2 - r_i, 0\}$ y concluya que g_i es convexa.

Solución: Si $x \in B_i$, entonces $d(x, B_i) = 0$. Si $x \notin B_i$, entonces $d(x, B_i) = \|x - c_i\|_2 - r_i > 0$. Luego, $g_i(x) = \max\{\|x - c_i\|_2 - r_i, 0\}$. Además, las funciones $x \mapsto \|x - c_i\|_2 - r_i$ y $x \mapsto 0$ son convexas, por lo que el máximo entre ellas también lo es.

- (b) Muestre que si $\|x - c_i\|_2 \leq r_i$, entonces $h = 0 \in \partial g_i(x)$.

Solución: Tenemos $g_i(x) = 0$, por lo que

$$g_i(x) + h^\top(y - x) = 0 + 0^\top(y - x) = 0 \leq g_i(y).$$

- (c) Muestre que si $\|x - c_i\|_2 \geq r_i$, entonces $h = \frac{1}{\|x - c_i\|_2}(x - c_i) \in \partial g_i(x)$.

Solución: Tenemos $g_i(x) = \|x - c_i\|_2 - r_i$, por lo que

$$\begin{aligned} g_i(x) + h^\top(y - x) &= \|x - c_i\|_2 - r_i + \frac{1}{\|x - c_i\|_2}(x - c_i)^\top(y - x) \\ &= \|x - c_i\|_2 - r_i + \frac{1}{\|x - c_i\|_2}(x - c_i)^\top(y - c_i) + \frac{1}{\|x - c_i\|_2}(x - c_i)^\top(c_i - x) \\ &\leq \|x - c_i\|_2 - r_i + \frac{1}{\|x - c_i\|_2}\|x - c_i\|_2\|y - c_i\|_2 - \frac{1}{\|x - c_i\|_2}\|x - c_i\|_2^2 \\ &= \|y - c_i\|_2 - r_i = g_i(y). \end{aligned}$$

- (d) ¿Es f de clase C^1 ? Justifique claramente.

Solución: Si $\|x - c_i\|_2 = r_i$, entonces $\frac{1}{\|x - c_i\|_2}(x - c_i) \neq 0$ y estos dos vectores pertenecen a $\partial g_i(x)$. Luego, g_i no es de clase C^1 .

-
- (e) Asuma que f es L -Lipschitz y que existen $d \in \mathbb{R}^n$ y $R > 0$ tales que $B(d, R)$ contiene un minimizador de f . Suponga, sin embargo, que solamente ha podido determinar que f es L_0 -Lipschitz y que $B(d, R_0)$ contiene un minimizador de f , donde $L_0 \geq L$ y $R_0 \geq R$. Si su objetivo es encontrar una solución ϵ -óptima para f , ¿cómo afecta esta falta de precisión a la eficiencia del método del subgradiente?

Solución: Para alcanzar un error no superior a $\epsilon > 0$, con las estimaciones L_0 y R_0 obtenemos

$$k + 1 \geq \frac{R_0 L_0}{\epsilon^2} = \frac{R_0 L_0}{RL} \frac{RL}{\epsilon^2}.$$

Luego, la cantidad de iteraciones aumenta en un factor $\frac{R_0 L_0}{RL} \geq 1$ comparado con el número de iteraciones obtenido si utilizáramos L y R .