



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025-2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 4

Método del Subgradiente

21 de agosto de 2025

Resumen

- **Condición de Lipschitz:** $|f(x) - f(y)| \leq L |x - y| \quad \forall x, y$
- **Método de Gradiente (Convergencia lineal):**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
 2. Sea $d^k = -\nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
 5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.
- **Método de Newton (Convergencia cuadrática):**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
 2. Sea $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
 5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.
- **Método simple de primer orden:**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, d^0 = -\nabla f(x^0), \epsilon > 0$.
 2. Sea $d^k = -\nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea $x^{k+1} = x^k + \frac{1}{L} d^k, k \leftarrow k + 1$, go to 2.

■ **Método del subgradiente:**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, -d^0 \in \partial f(x^0), \epsilon > 0$.
2. Sea $-d^k \in \partial f(x^k)$
3. Si el criterio de parada se satisface, entonces STOP. En caso contrario, continuar con el paso siguiente.
4. Sea $x^{k+1} = x^k + \lambda_k d^k, k \leftarrow k + 1$, go to 2.

■ **Gradiente**

El Gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

■ **Matriz Hessiana**


Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- **Dirección de descenso:** d es dirección de descenso si cumple que $d^\top \nabla f(x) < 0$

Ejercicio 1

- (a) **(Propuesto)** Explique, basado en las características de los gráficos, cuál método que, probablemente, mostrará mayores diferencias en número de iteraciones cuando se aplica a f_1 y a f_2 y justifique por qué.



- (b) Considere la siguiente función, que está definida en $\mathbb{R}^n$:

$$f(x) = x^\top Qx + \|Ax\|_2^2 + \sum_{j=1}^n \max\{\alpha_j, x_j^4\}$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, $\alpha_j > 0, j = 1, \dots, n$, $A \in \mathbb{R}^{n \times n}$.

- (i) Argumente que esta función es convexa y determine $\partial f(x)$ en un punto $x \in \mathbb{R}^n$ cualquiera.
- (ii) Suponga que sabemos que cualquier valor x que podamos encontrar en los algoritmos cumplirá con que $\|x\|_2 \leq R$. Estime un valor para una constante de Lipschitz de f que sea válida en una región del espacio $\mathbb{R}^n$ de a lo más radio R desde el origen, es decir, en $B(0, R) = \{y : \|y\|_2 \leq R\}$.
- (iii) Estime el esfuerzo computacional, en flops, de calcular un subgradiente de f , según lo que desarrolló en la parte (i).

Ejercicio 2

En este problema consideramos una función de n variables dada por:

$$f(x) = \tau \sum_{j=1}^n \max\{(\alpha_j - x_j), 0\} + \|Ax\|_2^2$$

donde $\tau > 0$ es dado, los α_j **son escalares positivos**, y $A \in \mathbb{R}^{m \times n}$ con $n > m$.

(a) **(Propuesto)** Determine el subdiferencial de f en cualquier punto x del dominio.

En lo que sigue, considere $h(x)$ como el vector que representa el subgradiente de $f(x)$:

$$h(x) = \tau p(x) + 2A^\top Ax,$$

donde se tiene que:

$$p(x)_j = \begin{cases} -1 & x_j < \alpha_j \\ 0 & x_j > \alpha_j \\ t \in [-1, 0] & x_j = \alpha_j \end{cases}$$

A partir de lo anterior, responda:

- (b) Suponga que le dicen que se sabe que cualquier x relevante para el problema cumple con $\|x\|_2 \leq R$, donde R es una constante positiva. ¿Cumple la función f una condición de Lipschitz en el conjunto $\{x \in \mathbb{R}^n : \|x\|_2 \leq R\}$? En caso de ser así, estime esa constante (Para esto le puede ser útil el siguiente resultado: si p es un subgradiente de f , entonces la constante de Lipschitz de f cumple $\|p\|_2 \leq L$), y en caso contrario, justifique por qué no.
- (c) Ahora queremos resolver el siguiente problema de optimización:

$$\begin{array}{ll} \text{mín} & f(x) \\ \text{s. a.} & 0 \leq x_j \leq 1, j = 1, \dots, n \end{array}$$

Especifique los pasos del método del subgradiente para este problema siendo explícito en la forma de resolver cualquier subproblema adicional que se presente.

- (d) Suponga que queremos aplicar FISTA a este problema. Explique cómo se debe escribir el problema para usarlo con FISTA y determine la constante de Lipschitz que tendría que usar en el método. Explique y justifique con precisión.

Ejercicios Propuestos

Ejercicio 1

Considere la siguiente función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ dada como $f(x) = \sum_{j=1}^n g_j(x_j) + \|Ax - b\|_2^2$, donde las funciones de una variable g_j están dadas por:

$$g_j(t) = \begin{cases} \gamma_j + \beta_j t^2 & \text{si } t > \alpha_j \\ 0 & \text{si } t \leq \alpha_j \end{cases}$$

donde $\beta_j > 0, \gamma_j < 0, \alpha_j = \sqrt{-\gamma_j/\beta_j}$ (tome la raíz > 0), para cada $j = 1, \dots, n$. La matriz A es de $m \times n$ y $b \in \mathbb{R}^m$.

- (a) Haga un gráfico de una función g_j y de ahí, más otros argumentos adicionales, muestre que la función f es convexa, y determine una expresión general para $\partial f(x)$ en cualquier punto $x \in \mathbb{R}^n$.
- (b) Ahora queremos encontrar un mínimo de f y para eso vamos a usar el método del subgradiente, tal como fue presentado en clases. Vamos a suponer que, a partir de información del problema subyacente, se sabe que los puntos de interés (los puntos que evaluará el algoritmo) incluyendo el óptimo, tienen la propiedad de que $|x_j| \leq M, j = 1, \dots, n$, donde M es conocido. Explique los pasos del método y determine valores adecuados para los parámetros que se usan en el algoritmo (incluyendo el paso de avance). Le puede ser útil aquí un resultado que mostramos en clases: para una función convexa f que cumple propiedad de Lipschitz con constante L , si $p \in \partial f(x)$, entonces $\|p\|_2 \leq L$.

Ejercicio 2

- (a) En algunas aplicaciones de Machine Learning es necesario resolver un problema de la siguiente forma:

$$\begin{aligned} \min \quad & \|x - u\|_2^2 + \tau \sum_{j=1}^n \max\{\gamma_j, \beta_j x_j\} \\ \text{s.a} \quad & \sum_{j=1}^n x_j \leq 1 \\ & x_j \geq 0, j = 1, \dots, n \end{aligned}$$

donde $u \in \mathbb{R}^n$ es fijo y conocido, al igual que $\tau > 0$. Los γ_j, β_j también son escalares positivos conocidos.

Indique con cuál algoritmo se podrá abordar este problema, de todos los que han visto en el curso, para encontrar una solución ϵ -óptima. Detalle los pasos principales del algoritmo seleccionado por usted aplicado al problema, mostrando todo elemento que deba calcular en forma específica a este problema para que funcione el algoritmo.

- (b) Considere la siguiente función definida en $\mathbb{R}^n$:

$$g(x) = x^\top Mx + \|Ax + b\|_2^2 + \sum_{j=1}^n \max\{\beta_j, |x_j|^3\}$$

donde $M \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$ es un vector, y $\beta_j > 0$ para $j = 1, \dots, n$.

- (i) Argumente que esta función es convexa y determine $\partial f(x)$ en un punto $x \in \mathbb{R}^n$ cualquiera. Para responder sobre la convexidad puede usar conocimiento previo sobre determinadas funciones, y propiedades conocidas de las funciones convexas.
 - (ii) Suponga que sabemos que cualquier valor x que podamos encontrar en los algoritmos cumplirá con que $\|x\|_2 \leq R$, y que $|x_j| \leq K$. Estime un valor para una constante de Lipschitz de f que sea válida en una región del espacio $\mathbb{R}^n$ de a lo más radio R desde el origen, es decir, en $B(0, R) = \{y : \|y\|_2 \leq R, |y_j| \leq K \quad \forall j\}$.
 - (iii) Estime el esfuerzo computacional, en flops, de calcular un subgradiente de f , según lo que desarrolló en la parte a).
- (c) Considere la siguiente función de n variables:

$$f(x) = \|Ax - b\|_2^2 + \sum_{j=1}^n \max\{0, (e^{-x_j} - 1)\}$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Muestre que f es convexa y determine una expresión para $\partial f(x)$ para todo x . En otras palabras, determine expresiones generales para los subgradientes de f .

Ejercicio 3

Vamos a considerar el siguiente problema de estimación estadística. Tenemos m observaciones de un cierto fenómeno, $b_1, \dots, b_m$ y queremos explicarlo en función de n factores, para los cuales también existen valores conocidos a_{ij} , que es el valor del factor j para la observación i . Entonces, se postula un modelo lineal de la forma:

$$\sum_{j=1}^n a_{ij}x_j = b_i, \quad i = 1, \dots, m$$

en donde los x_j son los pesos de los factores. Entonces, queremos encontrar la mejor solución posible al sistema de ecuaciones $Ax = b$. Este problema lo hemos planteado ya en el curso, usando mínimos cuadrados pero acá usaremos un criterio distinto, el error en valor absoluto. Adicionalmente, por propiedades del problema subyacente, se sabe que los coeficientes de la estimación, las variables x , deben estar dentro de ciertos rangos específicos y conocidos. Entonces, se plantea resolver el siguiente problema de optimización:

$$\begin{aligned} \text{mín} \quad & \|Ax - b\|_1 \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y los l_j, u_j son todos escalares conocidos. Como usted debe observar, la función objetivo de este problema es no diferenciable.

- (a) Determine un subgradiente de la función objetivo del problema en un punto x factible. (Indicación: le recordamos una relación que se ha usado ya en el curso, para hacer “regla de la cadena no diferenciable”, sea f una función convexa, si $p \in \partial f(x)$ y $g(x) = f(Bx)$, donde B es alguna matriz de dimensiones adecuadas, entonces $B^\top p \in \partial g(x)$.)
- (b) Explique, en forma detallada y con el desarrollo matemático correspondiente, cómo manejar las restricciones $l_j \leq x_j \leq u_j, j = 1, \dots, n$ del problema, si se usa el método de subgradiente para el problema.
- (c) Ahora le proponen hacer una transformación al problema y poder resolverlo con algún algoritmo, ojalá, más eficiente que el método de subgradiente. Para esto, considere la función $g : \mathbb{R} \rightarrow \mathbb{R}$ dada por $g(u) = \sqrt{u^2 + \mu}$ donde $\mu > 0$ es un parámetro dado. Muestre que $g(u) \approx |u|$, es decir, se puede usar para aproximar el valor absoluto, y que esa aproximación se hace cada vez mejor mientras más chico sea μ (puede dar un argumento simple, basado en aproximaciones matemáticas y apoyarse, también, en un gráfico, si lo desea).
- (d) Dado lo anterior, se propone ahora resolver, alternativamente, el problema:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m g(\alpha_i^\top x - b_i) \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $\alpha_1, \dots, \alpha_m$ son las filas de la matriz A , usando un algoritmo basado en el Método Acelerado de Nesterov (no es necesario recordar todo el detalle). ¿Puede usarse

el Método Acelerado de Nesterov, con alguna etapa adicional, para este problema? Justifique con precisión sobre la base de las hipótesis necesarias para que funcione el algoritmo y otras propiedades que hemos visto en el curso, no tiene que describir el detalle del algoritmo.

Ejercicio 4

Consideremos el siguiente problema de optimización, que surge en algunas variantes de problemas de estimación estadística. Queremos resolver un problema de estimar un vector $b \in \mathbb{R}^m$ a partir de observaciones de otros n factores, las cuales están tabuladas en una matriz $A \in \mathbb{R}^{m \times n}$, pero donde n es mayor que m . Entonces, queremos encontrar una solución al sistema $Ax = b$. Ahora, en el curso hemos tratado de imponer una condición de que x tenga el menor número de elementos no nulos. Acá haremos algo un poco diferente: queremos minimizar el “largo” del vector x , que se define por $l(x) = \min\{k : x_j = 0, j > k\}$. Esto corresponde al menor índice de coordenadas a partir de la cual todas las otras son nulas. Es como buscar un vector x con la menor cantidad de coordenadas no nulas, pero que estén al comienzo del vector. Por ejemplo, con $n = 10$:

$$\begin{aligned}x &= (1, 2, 4, 0, 0, 0, 0, 0, 0, 0), l(x) = 3, \\y &= (1, 0, 0, 0, 0, 0, 0, 0, 8, 0), l(y) = 9.\end{aligned}$$

Podemos ver que y , pese a que tiene menos coordenadas no nulas, tiene largo 9 ya que $y_9 \neq 0$. Entonces, x es preferible a y pese a que tiene más coordenadas no nulas. Entonces, queremos resolver el problema:

$$\begin{aligned}\text{mín} \quad & l(x) \\ \text{s. a.} \quad & Ax = b\end{aligned}$$

Inspirados en lo que hicimos para el modelo LASSO, postulamos el siguiente problema aproximado, con la intención de obtener alguna solución que vaya en la dirección de nuestro objetivo:

$$\min_{x \in \mathbb{R}^n} \tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2$$

donde los números β_j son todos positivos y tales que $\beta_{j+1} > \beta_j$, y $\tau > 0$ es un parámetro de balance. Específicamente, tomemos la siguiente definición para estos números: $\beta_j = 2^j, j = 1, \dots, n$ (es decir, $\beta_1 = 2, \beta_2 = 4$, etc.).

- Argúente que el resolver ese problema puede, efectivamente, generar una solución x que pudiera aproximarse a la estructura que buscamos, es decir, componentes x_j tales que $|x_j|$ sea bastante pequeño cuando j sea grande (y pueda ser redondeado a 0, como se hizo en clases).
- El problema planteado aquí es no diferenciable. Determine una fórmula general para $\partial f(x)$, donde f es la función objetivo del problema. Justifique con precisión todo lo que haga.
- Supongamos que queremos resolver este problema con el algoritmo FISTA. Justifique, según los contenidos del curso, que el problema efectivamente tiene el formato de problema que puede ser resuelto con FISTA. Y en este caso, ¿cuál sería la complejidad

del algoritmo, en orden de número de iteraciones para llegar a una solución ϵ -óptima? (no use más de 5-6 líneas para responder esta pregunta).

- (d) Suponga que ahora se quiere resolver una variante restringida del problema, de la forma:

$$\begin{aligned} \text{mín} \quad & \tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2 \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $l_j < u_j, j = 1, \dots, n$. Si se usa ahora una versión proyectada del algoritmo FISTA, explique cómo se resuelve la etapa de proyección que debe incorporar en el algoritmo.

Ejercicio 5

Suponga que dada una muestra de puntos en $\mathbb{R}^n$, usted ha podido agruparlos en m clusters.

El cluster i ha sido aproximado por la bola $B_i = B(c_i, r_i) = \{z \in \mathbb{R}^n : \|z - c_i\|_2 \leq r_i\}$, donde $c_i \in \mathbb{R}^n$ es el centro y $r_i > 0$ es el radio. Lo que le interesa determinar ahora es un punto $x^* \in \mathbb{R}^n$ que esté razonablemente cerca de todos los clusters a la vez. Para ello, sea $g_i(x) = d(x, B_i) = \min\{\|x - z\|_2 : z \in B_i\}$ la distancia de $x \in \mathbb{R}^n$ a B_i . Sea $f(x) = \sum_{i=1}^m g_i(x)$ la función que desea minimizar.

- (a) Muestre que $g_i(x) = \max\{\|x - c_i\|_2 - r_i, 0\}$ y concluya que g_i es convexa.
- (b) Muestre que si $\|x - c_i\|_2 \leq r_i$, entonces $h = 0 \in \partial g_i(x)$.
- (c) Muestre que si $\|x - c_i\|_2 \geq r_i$, entonces $h = \frac{1}{\|x - c_i\|_2}(x - c_i) \in \partial g_i(x)$.
- (d) ¿Es f de clase C^1 ? Justifique claramente.
- (e) Asuma que f es L -Lipschitz y que existen $d \in \mathbb{R}^n$ y $R > 0$ tales que $B(d, R)$ contiene un minimizador de f . Suponga, sin embargo, que solamente ha podido determinar que f es L_0 -Lipschitz y que $B(d, R_0)$ contiene un minimizador de f , donde $L_0 \geq L$ y $R_0 \geq R$. Si su objetivo es encontrar una solución ϵ -óptima para f , ¿cómo afecta esta falta de precisión a la eficiencia del método del subgradiente?