



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2121 - MÉTODOS DE OPTIMIZACIÓN - 2025-2

Profesor: JORGE VERA

Ayudantes: - CHRISTOPH BÜRGER (CHRISTOPH.BUERGER@UC.CL)
- FRANCISCO TAMARÍN (FTAMARIN@UC.CL)
- ALBERTO URETA (ALBERTO.URETA@UC.CL)

Taller 5

Repaso I1

4 de septiembre de 2025

Resumen

- **Condición de Lipschitz:** $|f(x) - f(y)| \leq L |x - y| \quad \forall x, y$
- **Método de Gradiente (Convergencia lineal):**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
 2. Sea $d^k = -\nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
 5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.
- **Método de Newton (Convergencia cuadrática):**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, \epsilon > 0$.
 2. Sea $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea λ^k solución de $\min_{\lambda \geq 0} f(x^k + \lambda d^k)$
 5. Sea $x^{k+1} = x^k + \lambda^k d^k, k \leftarrow k + 1$, go to 2.
- **Método simple de primer orden:**
 1. Sea $x^0 \in \mathbb{R}^n, k = 0, d^0 = -\nabla f(x^0), \epsilon > 0$.
 2. Sea $d^k = -\nabla f(x^k)$
 3. Si $\|\nabla f(x^k)\| \leq \epsilon$, entonces STOP.
 4. Sea $x^{k+1} = x^k + \frac{1}{L} d^k, k \leftarrow k + 1$, go to 2.

■ **Método del subgradiente:**

1. Sea $x^0 \in \mathbb{R}^n, k = 0, -d^0 \in \partial f(x^0), \epsilon > 0$.
2. Sea $-d^k \in \partial f(x^k)$
3. Si el criterio de parada se satisface, entonces STOP. En caso contrario, continuar con el paso siguiente.
4. Sea $x^{k+1} = x^k + \lambda_k d^k, k \leftarrow k + 1$, go to 2.

■ **Gradiente**

El Gradiente de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como sigue:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

■ **Matriz Hessiana**

Sea una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Se define la matriz hessiana como sigue:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- **Dirección de descenso:** d es dirección de descenso si cumple que $d^\top \nabla f(x) < 0$

Ejercicio 1

- (a) Supongamos que queremos resolver el problema $\min_{x \in \mathbb{R}^n} f(x)$, donde f es una función fuertemente convexa y tal que ∇f cumple una propiedad de Lipschitz. Nos proponen usar el Algoritmo de Primer Orden Acelerado de Nesterov o el Método Simple de Primer Orden (con paso fijo). En términos del orden de número iteraciones necesario para llegar a una solución ϵ -óptima, cuál de los dos algoritmos tiene mejor complejidad? ¿Cuál es esa complejidad? Justifique. No use más de 4-5 líneas para responder esta pregunta.
- (b) Indique, en forma justificada, sobre la base de los contenidos del curso, si la siguiente afirmación es correcta o no: “Para el problema no restringido $\min_{x \in \mathbb{R}^n} f(x)$, el método de Newton converge siempre a velocidad cuadrática, para cualquier tipo de función dos veces continuamente diferenciable, siempre y cuando el punto de partida esté suficientemente cerca de una solución óptima”. No use más de 4-5 líneas para responder esta pregunta.
- (c) Considere el problema

$$\begin{array}{ll} \min & f(x) \\ \text{s. a.} & 0 \leq x_j \leq a_j, j = 1, \dots, n \end{array}$$

donde los a_j son escalares positivos y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función dos veces continuamente diferenciable y convexa, pero no necesariamente se cumple que ∇f tenga una propiedad de Lipschitz en todo el espacio $\mathbb{R}^n$. Argumente que, sin embargo, sí es posible asumir la existencia de una constante de Lipschitz “local” para ∇f en el conjunto definido por las restricciones del problema. Explique cómo podría calcular esa constante de Lipschitz si le dieran una función f explícitamente.

- (d) Considere la función de n variables dada por:

$$f(x) = \frac{1}{2}x^\top Qx + \sum_{j=1}^n e^{-x_j^2}$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva.. ¿Cumple $\nabla f(x)$ una propiedad de Lipschitz en todo el espacio $\mathbb{R}^n$? Si su respuesta es afirmativa, determine una estimación al valor de esa constante y si su respuesta es negativa justifique por qué no. Sea claro en todas sus explicaciones y desarrollo matemático, y supuestos que haga.

Ejercicio 2

Consideremos el siguiente problema de optimización, que surge en algunas variantes de problemas de estimación estadística. Queremos resolver un problema de estimar un vector $b \in \mathbb{R}^m$ a partir de observaciones de otros n factores, las cuales están tabuladas en una matriz $A \in \mathbb{R}^{m \times n}$, pero donde n es mayor que m . Entonces, queremos encontrar una solución al sistema $Ax = b$. Ahora, en el curso hemos tratado de imponer una condición de que x tenga el menor número de elementos no nulos. Acá haremos algo un poco diferente: queremos minimizar el “largo” del vector x , que se define por $l(x) = \min\{k : x_j = 0, j > k\}$. Esto corresponde al menor índice de coordenadas a partir de la cual todas las otras son nulas. Es como buscar un vector x con la menor cantidad de coordenadas no nulas, pero que estén al comienzo del vector. Por ejemplo, con $n = 10$:

$$\begin{aligned}x &= (1, 2, 4, 0, 0, 0, 0, 0, 0, 0), l(x) = 3, \\y &= (1, 0, 0, 0, 0, 0, 0, 0, 8, 0), l(y) = 9.\end{aligned}$$

Podemos ver que y , pese a que tiene menos coordenadas no nulas, tiene largo 9 ya que $y_9 \neq 0$. Entonces, x es preferible a y pese a que tiene más coordenadas no nulas. Entonces, queremos resolver el problema:

$$\begin{aligned}\min \quad & l(x) \\ \text{s. a.} \quad & Ax = b\end{aligned}$$

Inspirados en lo que hicimos para el modelo LASSO, postulamos el siguiente problema aproximado, con la intención de obtener alguna solución que vaya en la dirección de nuestro objetivo:

$$\min_{x \in \mathbb{R}^n} \tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2$$

donde los números β_j son todos positivos y tales que $\beta_{j+1} > \beta_j$, y $\tau > 0$ es un parámetro de balance. Específicamente, tomemos la siguiente definición para estos números: $\beta_j = 2^j, j = 1, \dots, n$ (es decir, $\beta_1 = 2, \beta_2 = 4$, etc.).

- Argumente que el resolver ese problema puede, efectivamente, generar una solución x que pudiera aproximarse a la estructura que buscamos, es decir, componentes x_j tales que $|x_j|$ sea bastante pequeño cuando j sea grande (y pueda ser redondeado a 0, como se hizo en clases).
- El problema planteado aquí es no diferenciable. Determine una fórmula general para $\partial f(x)$, donde f es la función objetivo del problema. Justifique con precisión todo lo que haga.
- Supongamos que queremos resolver este problema con el algoritmo FISTA. Justifique, según los contenidos del curso, que el problema efectivamente tiene el formato de problema que puede ser resuelto con FISTA. Y en este caso, ¿cuál sería la complejidad

del algoritmo, en orden de número de iteraciones para llegar a una solución ϵ -óptima? (no use más de 5-6 líneas para responder esta pregunta).

- (d) Suponga que ahora se quiere resolver una variante restringida del problema, de la forma:

$$\begin{aligned} \text{mín} \quad & \tau \sum_{j=1}^n \beta_j |x_j| + \|Ax - b\|_2^2 \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $l_j < u_j, j = 1, \dots, n$. Si se usa ahora una versión proyectada del algoritmo FISTA, explique cómo se resuelve la etapa de proyección que debe incorporar en el algoritmo.

Ejercicios Propuestos

Ejercicio 1

- (a) Considere la función de n variables dada por:

$$f(x) = \frac{1}{2}x^\top Qx + \sum_{j=1}^{n-1} (x_{j+1} - x_j)^2$$

donde $Q \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva. ¿Cumple $\nabla f(x)$ una propiedad de Lipschitz en todo el espacio $\mathbb{R}^n$? Si su respuesta es afirmativa, construya una estimación al valor de esa constante y si su respuesta es negativa justifique por qué no. Sea claro en todas sus explicaciones y desarrollo matemático, y supuestos que haga.

- (b) Siguiendo con la misma función de la parte (a), determine el esfuerzo computacional que requiere evaluar el gradiente de f en un punto x cualquiera. Justifique con precisión.
- (c) Considere el siguiente problema de optimización:

$$\min_{x \in \mathbb{R}^n} \left\{ \left(\sum_{j=1}^n \max\{0, x_j\} \right) + f(x) \right\}$$

donde f es la función de la parte a). ¿Puede el algoritmo FISTA aplicarse a este problema? Justifique con precisión su respuesta de acuerdo a las características del algoritmo FISTA presentadas en el curso y de otros contenidos que necesite. Sea preciso en su justificación.

- (d) Considere un problema de la forma $\min_{x \in \mathbb{R}^n} f(x)$, donde f es una función convexa dos veces continuamente diferenciable y con hipótesis suficientes para garantizar que cualquier algoritmo de los que conocemos funcionará correctamente. También asuma que se sabe que el cálculo del gradiente requiere $O(n)$ flops, el cálculo del Hessiano $O(n^2)$ flops y que, eventualmente, se puede usar un método de Linesearch que hace un máximo de p iteraciones usando gradientes. Explique cómo estimaría a partir de qué dimensión n será más conveniente usar el Método Simple de Primer Orden en vez del Método de Newton para llegar a una solución ϵ -aproximada, para $0 < \epsilon < 1$ dado. Sea claro en su explicación, explicitando relaciones matemáticas adecuadas y justifique según los contenidos del curso, explicando cualquier supuesto que tenga que hacer.

Ejercicio 2

(a) Considere la función de n variables dada por:

$$f(x) = \tau \sum_{j=1}^n \max\{\alpha_j + x_j^2, 0\} + \|Ax - b\|_2^2$$


donde $\tau > 0$ es dado, los α_j son escalares no nulos (de cualquier signo), $A \in \mathbb{R}^{m \times n}$ con $n > m$, y $b \in \mathbb{R}^m$. Determine el subdiferencial de f en cualquier punto x del dominio.

(b) Considere, alternatively, la función:

$$f(x) = \tau \sum_{j=1}^n (\alpha_j + x_j^2) + \|Ax - b\|_2^2$$

donde $\tau > 0$ es dado, los α_j son escalares no nulos, $A \in \mathbb{R}^{m \times n}$, $n > m$, y $b \in \mathbb{R}^m$. Determine si $\nabla f(x)$ cumple una propiedad de Lipschitz en todo $\mathbb{R}^n$ y estime la constante o justifique si no la cumple.

(c) El siguiente gráfico muestra, de forma conjunta, cómo evolucionan las iteraciones del Método Simple de Primer Orden aplicado a dos funciones, f_1 y f_2 , para buscar el mínimo de estas, hasta llegar a un error $\epsilon > 0$. Ambas funciones son de n variables, son convexas, sus gradientes cumplen condición de Lipschitz y no necesariamente son fuertemente convexas:



Si en ambos casos, el algoritmo parte de un mismo punto inicial y las correspondientes soluciones óptimas son cercanas, ¿para cuál de las dos funciones la constante de Lipschitz L debería ser mayor? Justifique con precisión su respuesta sobre la base de los contenidos del curso y en no más de 4 líneas.

Ejercicio 3

Queremos resolver el problema $\min_{x \in \mathbb{R}^n} f(x)$, donde f es continuamente diferenciable y convexa, y tenemos que n es muy grande. Como se comentó en clases, en esos casos no se puede calcular explícitamente el vector $\nabla f(x)$ así que se recurre a algunas aproximaciones. Consideremos el algoritmo descrito por el siguiente pseudo-código, y que llamaremos “Algoritmo Misterioso”:

Algoritmo Misterioso (para minimizar):

Data: $x^0 \in \mathbb{R}^n$, f , $k = 0$, $LIMITE$, un escalar > 0 .


while $k < LIMITE$ **do**

- Seleccionar $j_0 \in \{1, \dots, n\}$ en forma aleatoria. Si j_0 es igual al de la selección anterior, repetir.
- Sea $d_{j_0}^k = -\frac{\partial f}{\partial x_{j_0}}(x^k)$ Sea $d_j^k = 0, j = 1, \dots, n, j \neq j_0$
- Resolver aproximadamente
$$\min_{\lambda \geq 0} f(x^k + \lambda d^k) \quad (\text{etapa de “linesearch”})$$
- Sea λ^k solución de ese problema
- Sea $x^{k+1} = x^k + \lambda^k d^k$
- $k = k + 1$

end

Respecto a la etapa 2 del método, hay una probabilidad de que se repita el índice seleccionado pero, dado que estamos diciendo que n es muy grande, realmente la probabilidad de eso es muy baja y no hay problemas si asumimos que no se repite.

- (a) ¿Es d^k , calculada por el algoritmo, una dirección de descenso? Justifique con precisión.
- (b) Explique qué es lo que hace este “Algoritmo Misterioso”. Haga un dibujo simple (en dos variables, sí, pese a que n es grande, pero eso lo que se puede dibujar) mostrando las curvas de nivel de alguna función (cuadrática si quiere), mostrando cómo sería la trayectoria del algoritmo. Justifique con precisión su respuesta y no se extienda en más de 5-6 líneas (sin incluir el dibujo). Puede usar, como referencia, un dibujo de curvas de nivel como el siguiente:



- (c) Para este “**Algoritmo Misterioso**”, ¿hay alguna forma especial de la función objetivo que favorezca en forma significativa la convergencia? Puede apoyarse en un dibujo, pero igual debe dar un argumento basado en los contenidos del curso, y explicar con claridad.
- (d) ¿Qué tan buena cree usted que será la velocidad de convergencia de este algoritmo, comparada con la de los métodos clásicos que hemos estudiado, como el método de Gradiente o el Método de Newton? Justifique su discusión en función de los contenidos del curso (Esta pregunta puede admitir diversos argumentos, pero queremos que se comprometa con algún juicio basado en lo que hemos estudiado sobre lo que favorece, o desfavorece, la convergencia de diversos algoritmos).
- (e) Ahora se propone la modificación que viene en el siguiente pseudo-código, y a este segundo algoritmo lo llamaremos “**Algoritmo Mas-Misterioso**”:

Algoritmo Más-Misterioso (para minimizar):

Data: $x^0 \in \mathbb{R}^n$, f , $k = 0$, $LIMITE$, un entero > 0 , p , un entero entre 2 y n

while $k < LIMITE$ **do**

$y^1 = x^k$

for $i = 1, \dots, p - 1$ **do**

Seleccionar $j_0 \in \{1, \dots, n\}$ en forma aleatoria. Si j_0 es igual al de la selección anterior, repetir.

Sea $h_{j_0}^i = -\frac{\partial f}{\partial x_{j_0}}(y^i)$ Sea $h_j^i = 0, j = 1, \dots, n, j \neq j_0$

Resolver aproximadamente

$$\min_{\mu \geq 0} f(y^i + \mu h^i) \quad (\text{etapa de "linesearch"})$$

Sea μ^i solución de ese problema

Sea $y^{i+1} = y^i + \mu^i h^i$

$i = i + 1$

end

Sea $d^k = \frac{y^p - x^k}{\|y^p - x^k\|_2}$

Resolver aproximadamente

$$\min_{\lambda \geq 0} f(x^k + \lambda d^k) \quad (\text{etapa de "linesearch"})$$

Sea λ^k solución de ese problema

Sea $x^{k+1} = x^k + \lambda^k d^k$

$k = k + 1$

end

Explique qué hace esta modificación del algoritmo y haga un dibujo, similar al que hizo en la parte (b), mostrando la forma en que avanza este método. Explique qué ventaja considera usted que tiene este algoritmo comparado con la versión original (esto en el sentido de que pueda, por ejemplo, tener mejor convergencia). Justifique con precisión.

Ejercicio 4

Nos interesa resolver el problema $\min_{x \in \mathbb{R}^n} f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces continuamente diferenciable. Para encontrar una solución aproximada de este problema se propone el siguiente algoritmo:

Algoritmo 1:

```
Data:  $x^0 \in \mathbb{R}^n$ ,  $k = 0$ .  
while Criterio de parada no se satisface do  
    Sea  $\alpha = \max_{l=1,\dots,n} \left\{ \left| \frac{\partial f}{\partial x_l}(x^k) \right| \right\}$  if  $\alpha = 0$  then  
        | STOP  
    end  
    Sea  $j$  tal que  $\left| \frac{\partial f}{\partial x_j}(x^k) \right| = \alpha$  (si hay empate, se elije cualquiera)  
    if  $\frac{\partial f}{\partial x_j}(x^k) < 0$  then  
        |  $d^k = e^j$   
    else  
        |  $d^k = -e^j$   
    end  
    Resolver aproximadamente (hasta cumplir condición de Wolf-Armijo):  
  
        
$$\min_{t \geq 0} f(x^k + td^k)$$
  
  
        Sea  $t^k$  la solución elegida del problema anterior  
        Sea  $x^{k+1} = x^k + t^k d^k$   
         $k = k + 1$   
end
```

En este pseudo-código, e^j denota el j -ésimo vector canónico en $\mathbb{R}^n$ (el vector de n componentes, todas nulas, excepto la j -ésima que vale 1). No especificamos explícitamente el criterio de parada y no se preocupe de eso. Si quiere, piense en que es número de iteraciones.

- Describa qué es lo que hace este algoritmo y por qué le parece que debería, efectivamente, servir para encontrar un mínimo local de la función. Su respuesta debe basarse en los contenidos del curso y su interpretación del pseudo-código, puede apoyarse también en representaciones gráficas, pero todo muy justificado.
- ¿Qué ventajas o desventajas considera usted que este algoritmo tiene frente al Método del gradiente, que hemos estudiado en clases? En particular, ¿puede estimarse el orden de “flops” que este método necesita por iteración? De ser así, de una estimación y no olvide justificar y explicar bien sus supuestos.
- Considere ahora la siguiente modificación que introduciremos al método. Suponiendo

que vamos a partir del punto x^0 , consideramos la matriz Hessiana de f en x^0 , $H = \nabla^2 f(x^0)$. Supongamos que determinamos que H es simétrica y definida positiva. Por lo tanto, es diagonalizable. Sean $v^1, v^2, \dots, v^n$ los vectores propios que se obtienen de la diagonalización y vamos a asumir que se han normalizados, es decir, $\|v^j\|_2 = 1, j = 1, \dots, n$. Proponemos el siguiente algoritmo, modificado, que usa las direcciones v^j en vez de los vectores canónicos e^j :

Algoritmo 2:

```

Data:  $x^0 \in \mathbb{R}^n, k = 0$ .
while Criterio de parada no se satisface do
    Sea  $\alpha = \max_{l=1, \dots, n} \{|\nabla f(x^k)^\top v^l|\}$  if  $\alpha = 0$  then
        | STOP
    end
    Sea  $j$  tal que  $|\nabla f(x^k)^\top v^j| = \alpha$  (si hay empate, se elije cualquiera)
    if  $\nabla f(x^k)^\top v^j < 0$  then
        |  $d^k = v^j$ 
    else
        |  $d^k = -v^j$ 
    end
    Resolver aproximadamente (hasta cumplir condición de Wolf-Armijo):

        
$$\min_{t \geq 0} f(x^k + td^k)$$


    Sea  $t^k$  la solución elegida del problema anterior
    Sea  $x^{k+1} = x^k + t^k d^k$ 
     $k = k + 1$ 
end

```

Explique por qué este algoritmo podría ser mejor que el algoritmo 1 presentado antes, en términos de número de iteraciones para llegar a una meta de error. ¿Qué desventajas podría tener, sin embargo, frente el método original? ¿Qué condición debería cumplir x^0 para que esta idea funcione bien, y por qué? Nuevamente, debe justificar en función de los contenidos del curso.

Ejercicio 5

Vamos a considerar el siguiente problema de estimación estadística. Tenemos m observaciones de un cierto fenómeno, $b_1, \dots, b_m$ y queremos explicarlo en función de n factores, para los cuales también existen valores conocidos a_{ij} , que es el valor del factor j para la observación i . Entonces, se postula un modelo lineal de la forma:

$$\sum_{j=1}^n a_{ij}x_j = b_i, \quad i = 1, \dots, m$$

en donde los x_j son los pesos de los factores. Entonces, queremos encontrar la mejor solución posible al sistema de ecuaciones $Ax = b$. Este problema lo hemos planteado ya en el curso, usando mínimos cuadrados pero acá usaremos un criterio distinto, el error en valor absoluto. Adicionalmente, por propiedades del problema subyacente, se sabe que los coeficientes de la estimación, las variables x , deben estar dentro de ciertos rangos específicos y conocidos. Entonces, se plantea resolver el siguiente problema de optimización:

$$\begin{aligned} \text{mín} \quad & \|Ax - b\|_1 \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y los l_j, u_j son todos escalares conocidos. Como usted debe observar, la función objetivo de este problema es no diferenciable.

- (a) Determine un subgradiente de la función objetivo del problema en un punto x factible. (Indicación: le recordamos una relación que se ha usado ya en el curso, para hacer “regla de la cadena no diferenciable”, sea f una función convexa, si $p \in \partial f(x)$ y $g(x) = f(Bx)$, donde B es alguna matriz de dimensiones adecuadas, entonces $B^\top p \in \partial g(x)$.)
- (b) Explique, en forma detallada y con el desarrollo matemático correspondiente, cómo manejar las restricciones $l_j \leq x_j \leq u_j, j = 1, \dots, n$ del problema, si se usa el método de subgradiente para el problema.
- (c) Ahora le proponen hacer una transformación al problema y poder resolverlo con algún algoritmo, ojalá, más eficiente que el método de subgradiente. Para esto, considere la función $g : \mathbb{R} \rightarrow \mathbb{R}$ dada por $g(u) = \sqrt{u^2 + \mu}$ donde $\mu > 0$ es un parámetro dado. Muestre que $g(u) \approx |u|$, es decir, se puede usar para aproximar el valor absoluto, y que esa aproximación se hace cada vez mejor mientras más chico sea μ (puede dar un argumento simple, basado en aproximaciones matemáticas y apoyarse, también, en un gráfico, si lo desea).
- (d) Dado lo anterior, se propone ahora resolver, alternativamente, el problema:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^m g(\alpha_i^\top x - b_i) \\ \text{s. a.} \quad & l_j \leq x_j \leq u_j, j = 1, \dots, n \end{aligned}$$

donde $\alpha_1, \dots, \alpha_m$ son las filas de la matriz A , usando un algoritmo basado en el Método Acelerado de Nesterov (no es necesario recordar todo el detalle). ¿Puede usarse

el Método Acelerado de Nesterov, con alguna etapa adicional, para este problema? Justifique con precisión sobre la base de las hipótesis necesarias para que funcione el algoritmo y otras propiedades que hemos visto en el curso, no tiene que describir el detalle del algoritmo.