



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería Industrial y de Sistemas

ICS2121 Métodos de Optimización

Tarea 3 - Grupo 21

Integrantes:

- Francisca Isidora Ortiz Rojo
- Vicente Renato Jorge Olea Concha
- Santiago Ignacio García Lozano
- Franco Nicolai Corvalán Mansourova

Fecha de entrega: 4 de diciembre de 2025

Índice de contenido

1 Problema 1	3
2 Problema 2	6
2.1 Ítem a.	6
2.2 Ítem b.	7
2.3 Ítem c.	8
3 Problema 3	9
3.1 Ítem a.	9
3.2 Ítem b.	10
4 Problema 4	11
4.1 Ítem a.	11
4.2 Ítem b.	11
5 Problema 5	13
5.1 Ítem a.	13
5.2 Ítem b.	14
5.3 Ítem c.	14
6 Problema 6	16
6.1 Ítem a.	16
6.2 Ítem b.	16
6.3 Ítem c.	17
7 Problema 7	18
7.1 Ítem a.	18
7.2 Ítem b.	19

8 Problema 8	21
9 Problema 9	26
9.1 Ítem a.	26
9.2 Ítem b.	27
9.3 Ítem c.	28
9.4 ítem d.	29
10 Referencias bibliográficas	30

1. Problema 1

a)

Para mostrar que la solución cumple con todas las restricciones (1), identificaremos a cada nodo con un número del 1 al 11 como se muestra en la siguiente figura:




Imagen 1

Numeración de nodos.

Ahora, podemos escribir las restricciones (1) para cada nodo y verificar que estas se cumplan:

- $\sum_{e \in \delta(1)} x_e = 0 + 1/2 + 1/2 + 1 = 2$
- $\sum_{e \in \delta(2)} x_e = 0 + 1/2 + 1/2 + 1 = 2$
- $\sum_{e \in \delta(3)} x_e = 0 + 1 + 1 = 2$
- $\sum_{e \in \delta(4)} x_e = 0 + 1/2 + 1/2 + 1 = 2$
- $\sum_{e \in \delta(5)} x_e = 0 + 0 + 1 + 1 = 2$
- $\sum_{e \in \delta(6)} x_e = 0 + 0 + 1/2 + 1/2 + 1 = 2$

- $\sum_{e \in \delta(7)} x_e = 0 + 1 + 1 = 2$
- $\sum_{e \in \delta(8)} x_e = 1/2 + 1/2 + 1 = 2$
- $\sum_{e \in \delta(9)} x_e = 1/2 + 1/2 + 1 = 2$
- $\sum_{e \in \delta(10)} x_e = 0 + 1/2 + 1/2 + 1 = 2$
- $\sum_{e \in \delta(11)} x_e = 1/2 + 1/2 + 1 = 2$

b)

Utilizando los mismos números para identificar a los nodos que los utilizados en el inciso a), se puede determinar por "inspección", que los siguientes conjuntos de nodos no cumplen las restricciones (2):

- $K_1 = \{3, 4, 8, 9, 10\}$: $\sum_{e \in \delta(K_1)} x_e = 0 + 0 + 0 + 1/2 + 1/2 = 1 < 2$
- $K_2 = \{2, 7, 11\}$: $\sum_{e \in \delta(K_2)} x_e = 1/2 + 0 + 0 + 1/2 = 1 < 2$
- $K_3 = \{1, 5, 6\}$: $\sum_{e \in \delta(K_3)} x_e = 0 + 1/2 + 0 + 0 + 1/2 + 0 + 0 = 1 < 2$

c)

El problema general de encontrar una restricción de eliminación de subcircuitos violada formulado como el problema de encontrar un corte de mínima capacidad en la red es el siguiente:

$$Q(x^*) = \min_{S \subset N, S \neq \emptyset} \sum_{e \in A(S)} x_e^* \quad (1)$$

En el cual x^* es una solución de una iteración del algoritmo de planos cortantes (será un parámetro en este subproblema).

Si es que $Q(x^*) < 2$, entonces debemos añadir la siguiente restricción en el modelo:

$$\sum_{e \in \delta(S^*)} x_e \geq 2 \quad (2)$$

En la cual S^* es la solución del problema resuelto anteriormente.

d)

El problema de separación de desigualdades de eliminación de subcircuitos puede reformularse como un problema de corte mínimo en una red dirigida, donde la capacidad de cada arco (i, j) se define como

$$u_{ij} = x_{ij}^*, \quad (3)$$

siendo x^* la solución fraccional obtenida al resolver la relajación lineal del Problema del Vendedor Viajero.

Según el Teorema de Ford y Fulkerson, el valor del flujo máximo entre un nodo origen r y un nodo destino s es igual a la capacidad mínima entre todos los cortes (S, T) que separan dichos nodos. Al resolver el problema de Flujo Máximo mediante su formulación de Programación Lineal, los arcos en los cuales el flujo alcanza y satura su capacidad ($x_{ij} = u_{ij}$) permiten identificar explícitamente el corte (r, s) de capacidad mínima, ya que estos arcos saturados determinan la frontera entre los conjuntos S y T asociados al corte mínimo.

De este modo, al resolver un problema de Flujo Máximo entre r y cada uno de los otros nodos s , es posible identificar cortes cuya capacidad sea estrictamente menor que 2. Cada uno de estos cortes define un subconjunto S tal que:

$$\sum_{e \in \delta(S)} x_e^* < 2, \quad (4)$$

lo que corresponde exactamente a una restricción de eliminación de subcircuitos violada.

Dado que este procedimiento debe realizarse considerando un número lineal de nodos como posibles destinos s , se requiere resolver $O(|N|)$ problemas de Flujo Máximo, cada uno de los cuales es un problema de Programación Lineal resoluble en tiempo polinomial. Por tanto, se concluye que el problema de separación de desigualdades de eliminación de subcircuitos para la relajación lineal del Problema del Vendedor Viajero puede resolverse en tiempo polinomial.

2. Problema 2

2.1. Ítem a.

Sea el siguiente modelo:

$$\min P \sum_{t=1}^T \sum_{j=1}^n \{c_{jt}x_{jt} + h_{jt}I_{jt}\} + \sum_{t=1}^T g_t z_t \quad (1)$$

$$\text{s.t. } I_{jt} = I_{jt-1} + x_{jt} - d_{jt}, \quad t = 1, \dots, T; j = 1, \dots, n \quad (2)$$

$$\sum_{j=1}^n a_j x_{jt} \leq b_t, \quad t = 1, \dots, T \quad (3)$$

$$x_{jt} \leq M z_t, \quad t = 1, \dots, T; j = 1, \dots, n \quad (4)$$

$$x_{jt} \geq 0, I_{jt} \geq 0, z_t \in \{0, 1\}, \quad t = 1, \dots, T; j = 1, \dots, n \quad (5)$$

La restricción (4) utiliza el conocido método "Big M" para vincular una variable continua de producción (x_{jt}) a una variable binaria de decisión (z_t) que indica si la producción ocurre en el periodo t . El objetivo es encontrar el valor más pequeño y ajustado para M (o M_{jt}) que garantice la lógica del modelo, o sea, si $z_t = 0 \implies x_{jt} = 0$, entonces:

$$z_t = 1 \implies x_{jt} \leq M \text{ (no restrictiva)}$$

Para encontrar un M_{jt} "ajustado", debemos analizar x_{jt} :

- La restricción de capacidad:

$$\sum_{j=1}^n a_j x_{jt} \leq b_t$$

Como todos los términos $a_j x_{jt}$ y b_t son no negativos ($a_j \geq 0, x_{jt} \geq 0, b_t \geq 0$), si tomamos el supuesto de producción de un solo producto, obtenemos:

$$\bar{x}_{jt} = \frac{b_t}{a_j}$$

- La restricción de balance de inventario:

$$I_{jt} = I_{jt-1} + x_{jt} - d_{jt}$$

Despejando x_{jt} y utilizando la condición de no negatividad para el inventario, $I_{jt} \geq 0$:

$$x_{jt} = d_{jt} - I_{jt-1} + I_{jt}$$

Como buscamos una cota superior para x_{jt} , debemos considerar el escenario pesimista donde

el inventario inicial es el mínimo ($I_{j0} = 0$) y además, producimos lo justo y necesario. Obtenemos:

$$I_{jT} = I_{j0} + \sum_{t=1}^T x_{jt} - \sum_{t=1}^T d_{jt}$$

Dado al supuesto de no inventario, obtenemos:

$$\bar{x}_{jt} = \sum_{t=1}^T d_{jt}$$

Por último, el valor de M_{jt} debe ser un valor tal que $x_{jt} \leq M_{jt}$ no sea restrictivo cuando $z_t = 1$. Esto se logra eligiendo la cota superior más pequeña entre las posibles para garantizar que se cumpla la restricción. Por lo tanto, el valor ajustado para M_{jt} es

$$M_{jt} = \min \left(\frac{b_t}{a_j}, \sum_{k=t}^T d_{jk} \right)$$

2.2. Ítem b.

Podemos observar que de las formulaciones propuestas, la única diferencia se origina en las restricciones 3 y 4, en particular podemos destacar lo siguiente:

$$\sum_{j=1}^n a_j x_{jt} \leq b_t$$

$$x_{jt} \leq M_{jt} z_t, \quad \text{para } j = 1, \dots, n$$

$$0 \leq z_t \leq 1$$

$$\sum_{j=1}^n a_j x_{jt} \leq b_t z_t$$

$$0 \leq z_t \leq 1$$

Formulación 1

Formulación 2

Podemos observar que la formulación (2) es como un estilo de unión de la restricción 3 y 4 originales. En particular, si analizamos cómo afecta este cambio en la resolución, la formulación (2) es significativamente mejor (más fuerte) que la formulación (1), y por lo tanto, más fácil de resolver. Esto se debe a que la formulación (2) es más estricta que la (1) al no usar el método *Big-M*. Esto genera que esté más cerca de una formulación ideal, o sea, que una formulación se considera "ideal" si el poliedro (la región factible) de su relajación lineal tiene solo vértices enteros; en la práctica, esto significaría que al resolver la relajación lineal (un problema "fácil"), la solución óptima obtenida ya es entera ($z_t = 0$ o $z_t = 1$) y es, por tanto, la solución óptima del problema mixto-entero original, eliminando la necesidad del costoso proceso de *Branch & Bound*. Para ejemplificar esto, si reemplazáramos valores, o sea, instanciamos dicho problema, podríamos encontrar un caso donde sea factible para la formulación (1) pero no para la (2), por lo que es una estructura más fuerte y cercana a la ideal.

2.3. Ítem c.

Sea que estamos en un tiempo t específico y la demanda para los periodos anteriores ya está satisfecha, tenemos el siguiente modelo:

$$\min \sum_{t=1}^T \sum_{j=1}^n \{c_{jt}x_{jt} + h_{jt}I_{jt}\} + \sum_{t=1}^T g_t z_t \quad (1)$$

$$\text{s.t. } I_{jt} = I_{j,t-1} + x_{jt} - d_{jt}, \quad t = 1, \dots, T; j = 1, \dots, n \quad (2)$$

$$\sum_{j=1}^n a_j x_{jt} \leq b_t, \quad t = 1, \dots, T \quad (3)$$

$$x_{jt} \leq M z_t, \quad t = 1, \dots, T; j = 1, \dots, n \quad (4)$$

$$x_{jt} \geq 0, I_{jt} \geq 0, z_t \in \{0, 1\}, \quad t = 1, \dots, T; j = 1, \dots, n \quad (5)$$

Para construir el "trigger", primero debemos calcular la demanda neta total de recursos (medida en horas) que el sistema debe satisfacer durante todo el horizonte T .

Para un producto j , la demanda total es $\sum_{i=1}^T d_{ji}$. Dado que tenemos un inventario inicial I_{j0} , la demanda neta que debemos producir es $\max(0, \sum_{i=1}^T d_{ji} - I_{j0})$. Para convertir esta demanda neta de unidades a horas de producción, la multiplicamos por a_j . La capacidad total de recursos necesaria para satisfacer toda la demanda neta de todos los productos es:

$$R^{\text{TOTAL_NET}} = \sum_{j=1}^n a_j \cdot \max(0, \sum_{i=1}^T d_{ji} - I_{j0})$$

Donde dicha variable $R^{\text{TOTAL_NET}}$ es una constante conocida. Luego, podemos construir la siguiente restricción que agregaremos, basándonos en el ítem anterior:

$$\sum_{k=1}^T b_k z_k \geq R^{\text{TOTAL_NET}}$$

Esta restricción es una desigualdad válida global que debe cumplirse en cualquier solución factible. La explicación de porque esto hace sentido, es la siguiente:

- El término de la derecha, $R^{\text{TOTAL_NET}}$, es la *mínima cantidad de horas-máquina* (recursos) que se necesitan para satisfacer la demanda neta total de todo el horizonte.
- El término de la izquierda, $\sum_{k=1}^T b_k z_k$, representa la capacidad máxima total de producción (en horas) que "activamos" o "encendemos" a lo largo de todo el horizonte.

3. Problema 3

3.1. Ítem a.

El artículo describe cómo JD.com, la empresa de comercio electrónico B2C más grande de China, mejoró sus redes de entrega mediante el desarrollo de un modelo de optimización para la planificación anual de sus estaciones de entrega (DSs). Este modelo utiliza un enfoque de programación lineal entera mixta para minimizar los costos operativos y mejorar las distancias de entrega en comparación con la planificación manual. Aunque existen muchos algoritmos para estos problemas, pocos modelos multiperíodo existentes integraban todas las restricciones prácticas que enfrentaba JD.com, lo que motivó a la empresa a proponer un nuevo modelo. Además, estas restricciones, combinadas con el gran tamaño de las redes de entrega, conducían a un número masivo de variables y restricciones.

Los cambios en la red de Centros de Distribución (DS) están sujetos a varias restricciones operativas y logísticas, como límites en la frecuencia de aperturas y cierres para mantener una tendencia estable a lo largo del tiempo, términos de los contratos de arrendamiento, y límites en la expansión o reducción de capacidad de cada DS individual. Además, se establecen topes en la reasignación de bloques de demanda entre DSs para minimizar la reubicación de personal, y se exige que todos los bloques asignados a una misma DS estén geográficamente conectados para optimizar la flexibilidad operativa y el apoyo mutuo entre los repartidores.

El objetivo del modelo se formuló como minimizar el costo total de la red (costos fijos de las DSs y costos de entrega de DSs a bloques). Las variables de decisión incluyeron la ubicación y el tamaño de cada DS y la asignación mensual de cada bloque a una DS. Las restricciones prácticas, especialmente la de conectividad, hicieron que el modelo fuera difícil de resolver directamente. Para abordar esto, los autores propusieron dos estrategias: emplearon una formulación alternativa para las restricciones de conectividad (basada en flujos "agregados") para reducir el número de variables y restricciones; y desarrollaron una heurística basada en vecindarios que utiliza un algoritmo de "arranque en caliente anidado" (nested warm-start) para mejorar la eficiencia computacional.

Se utilizó la planificación anual en Qingdao como ejemplo para demostrar la efectividad del modelo. El modelo logró un ahorro del 8.08 % en el costo total en Qingdao. La mayor parte de este ahorro provino de la reducción de costos fijos, reduciendo el número de DSs casi a la mitad. A su vez, aumentó la tasa de uso de la capacidad promedio de las DS en 11.56 puntos porcentuales, se acortó la distancia media de entrega en un 3.61 %, mejorando la experiencia del cliente y los planes generados por el modelo para las 16 ciudades piloto en 2018 resultaron en un ahorro estimado de más de 82 millones de yuanes (un 4.2 % del costo total). Además de los impactos económicos, se mejoró la experiencia del cliente (reducción del 20.9 % en la distancia de entrega promedio) y se disparó la eficiencia de los empleados, reduciendo el tiempo de planificación de meses a solo horas.

3.2. Ítem b.

Podemos ver que lo planteado en el artículo es un caso aplicado de los casos que se han visto en clases, un problema de ubicación de instalaciones y la asignación de demandas. Esto nos hace dar cuenta que lo visto en clases nos da las herramientas para poder modelar un proceso real complejo. Además, es un problema de gran tamaño, lo que se relaciona fuertemente con los contenidos del curso, y las técnicas dadas para trabajar con problemas de este tipo. A su vez, se puede ver una aplicación en la vida real de trabajar con heurísticas, es decir, aceptar soluciones casi óptimas, para acortar el espacio de búsqueda.

Por último, el hecho que sea un problema multiperíodo nos indica que estamos tratando con un problema dinámico, que por la complejidad de estados, no se puede trabajar directamente. Es ahí donde entra lo previamente mencionado, técnicas para poder acercarnos lo más posible a una solución que satisfaga las restricciones de nuestro problema y que nos de el mejor valor objetivo posible.

Para concluir, el artículo nos muestra un caso real de cómo poder implementar la materia vista en el curso, desde el momento que modelamos un problema dinámico, con diversos períodos involucrados, entender la complejidad de este, y ver que herramientas o formas de trabajar el problema convienen en cada caso para obtener la mejor solución posible.

4. Problema 4

4.1. Ítem a.

Sea $V(c) = \arg \min_{x \in \mathbb{R}^n} f(x, c)$, con f convexa en x y dos veces continuamente diferenciable. Por optimalidad de primer orden se cumple

$$\frac{d}{dx} f(V(c), c) = 0$$

Derivando respecto de c . En este problema el x óptimo es $V(c)$, entonces x depende de c . Usando la técnica vista en el material complementario Mandi et als aplicamos la regla de la cadena al término $\frac{\partial f}{\partial x}(V(c), c)$ obteniendo el factor $\frac{\partial^2 f}{\partial x^2}(V(c), c) \frac{dV(c)}{dc}$, y el segundo término aparece por la regla de la derivada total respecto de c . Así:

$$\frac{d}{dc} \left[\frac{\partial f}{\partial x}(V(c), c) \right] = \frac{\partial^2 f}{\partial x^2}(V(c), c) \frac{dV(c)}{dc} + \frac{\partial^2 f}{\partial x \partial c}(V(c), c) = 0.$$

Despejando,

$$\frac{dV(c)}{dc} = - \frac{\frac{\partial^2 f}{\partial x \partial c}(V(c), c)}{\frac{\partial^2 f}{\partial x^2}(V(c), c)}.$$

En conclusión, se demostró la igualdad. Además, cabe notar que como f es 2 veces continuamente diferenciable, el orden de las derivadas parciales no importa, es decir,

$$\frac{\partial^2 f}{\partial x \partial c}(x, c) = \frac{\partial^2 f}{\partial c \partial x}(x, c).$$

4.2. Ítem b.

Partimos definiendo la función $f(x, c)$ a minimizar respecto de x :

$$\min_{x \in \mathbb{R}^n} f(x, c) \quad \text{con} \quad f(x, c) = \frac{1}{2} x^\top Q(c) x + b(c)^\top x,$$

donde

$$Q(c) = A_0 + \sum_{i=1}^p c_i A_i, \quad b(c) = d_0 + \sum_{i=1}^p c_i d_i,$$

con A_i simétricas definidas positivas. Al derivar respecto a x se resuelve de la típica forma vista en clases y talleres:

$$\nabla_x f(x, c) = Q(c)x + b(c) = 0 \implies V(c) = -Q(c)^{-1} b(c).$$

Donde $V(c)$ es el minimizador de $f(x, c)$ respecto de x . Ahora definimos la función $F(c)$ como el minimo de $f(x, c)$ respecto de x :

$$F(c) = f(V(c), c) = \frac{1}{2}V(c)^\top Q(c)V(c) + b(c)^\top V(c) = -\frac{1}{2}b(c)^\top Q(c)^{-1}b(c).$$

Derivando F respecto de c_j (para derivar la matriz inversa se usó el método de PlanetMath para la derivada inversa) y usando

$$\frac{\partial b}{\partial c_j} = d_j, \quad \frac{\partial Q}{\partial c_j} = A_j, \quad \frac{\partial Q^{-1}}{\partial c_j} = -Q^{-1} \left(\frac{\partial Q}{\partial c_j} \right) Q^{-1} = -Q^{-1} A_j Q^{-1},$$

Ademas, como b y Q dependen de c , al derivar el termino se deriva cada componente y se suma a la derivada del otro:

$$\frac{\partial}{\partial c_j} [b^\top Q^{-1} b] = \underbrace{\frac{\partial b^\top}{\partial c_j} Q^{-1} b}_{(1)} + \underbrace{b^\top \frac{\partial Q^{-1}}{\partial c_j} b}_{(2)} + \underbrace{b^\top Q^{-1} \frac{\partial b}{\partial c_j}}_{(3)}.$$

Sustituyendo cada derivada:

$$(1) = d_j^\top Q^{-1} b, \quad (2) = b^\top (-Q^{-1} A_j Q^{-1}) b = -b^\top Q^{-1} A_j Q^{-1} b, \quad (3) = b^\top Q^{-1} d_j.$$

Por tanto

$$\frac{\partial}{\partial c_j} [b^\top Q^{-1} b] = d_j^\top Q^{-1} b + b^\top Q^{-1} d_j - b^\top Q^{-1} A_j Q^{-1} b.$$

Como Q^{-1} es simétrica y $d_j^\top Q^{-1} b$ es escalar, $d_j^\top Q^{-1} b = b^\top Q^{-1} d_j$, luego

$$\frac{\partial}{\partial c_j} [b^\top Q^{-1} b] = 2d_j^\top Q^{-1} b - b^\top Q^{-1} A_j Q^{-1} b.$$

Finalmente,

$$\frac{\partial F}{\partial c_j} = -\frac{1}{2} \left(2d_j^\top Q^{-1} b - b^\top Q^{-1} A_j Q^{-1} b \right) = d_j^\top V(c) + \frac{1}{2} V(c)^\top A_j V(c),$$

donde usamos $Q^{-1} b = -V(c)$. Por lo tanto, el gradiente pedido es

$$\nabla F(c) = \begin{pmatrix} d_1^\top V(c) + \frac{1}{2} V(c)^\top A_1 V(c) \\ \vdots \\ d_p^\top V(c) + \frac{1}{2} V(c)^\top A_p V(c) \end{pmatrix}.$$

5. Problema 5

5.1. Ítem a.

El prompt utilizado fue:

Hola! te entregué un modelo matemático de optimización, el contexto del problema y el modelo están adjuntos en las imágenes. Tu tarea es la siguiente: A partir del modelo anterior, ¿cuál es la mejor forma de hacer relajación Lagrangiana a este problema?

Se adjuntaron imágenes con el modelo y el contexto. El enlace a la conversación completa es:

<https://chatgpt.com/share/692861ca-4a70-8011-ad1b-5fc1a49d4b89>

Respuesta obtenida (resumen). La recomendación central es relajar la restricción (4) entre cosecha y procesamiento (denotada como (4): $\sum_j x_{jt} = \sum_i z_{it}$ para cada t), porque es la que enlaza las decisiones discretas de cosecha (x_{jt}, y_{jt}) con las continuas de procesamiento/compra (z_{it}, v_t) . Al dualizarla con multiplicadores $\lambda_t \in \mathbb{R}$ se obtiene:

- **Subproblema de cosecha (A)** en (x_{jt}, y_{jt}) , sujeto a las restricciones locales (p.ej. $x_{jt} \leq L_j y_{jt}$ y $\sum_t y_{jt} \leq 1$). Este subproblema se separa por parcela j y puede resolverse en tiempo $O(T)$ por parcela, eligiendo periodos con señal de $(c_{jt} + \lambda_t)$.
- **Subproblema de procesamiento/compra (B)** en (z_{it}, v_t) , que resulta ser un LP por plantas y periodos con las capacidades, demanda y límites agregados. Si además se relaja la capacidad por periodo (opcional), se descompone aún más, aunque con una cota dual generalmente más débil.

La **dual Lagrangiana** es $\max_{\lambda} \mathcal{L}(\lambda)$ y se sugiere resolverla mediante subgradientes, bundle u otros métodos para funciones no diferenciables. El subgradiente en cada periodo es la violación de (4): $g_t = \sum_j x_{jt} - \sum_i z_{it}$. Se recomienda además usar heurísticas para construir soluciones factibles a partir de las soluciones de los subproblemas.

Algoritmo práctico sugerido.

1. Inicializar λ_t (por ejemplo en cero).
2. Iterar: resolver (A) por parcela, resolver (B) como LP, calcular g_t , actualizar $\lambda_t = \lambda_t + \alpha_k g_t$, mantener la mejor cota dual y una solución primal factible por heurística.
3. Parar al converger o alcanzar el máximo de iteraciones.

Conclusión. Relajar (4) es la mejor primera elección: separa decisiones discretas de continuas, produce subproblemas simples y suele dar una cota dual fuerte. Relajar adicionalmente la capacidad por periodo puede aumentar el paralelismo a costa de la calidad de la cota.

5.2. Ítem b.

El prompt utilizado fue:

Ahora, evalúa si acaso la cota dual que se obtendría de la relajación que propones es buena.

El enlace al chat es el mismo que en el ítem a.

Respuesta obtenida (resumen). La cota dual al relajar la restricción de balance (4) suele ser *fuerte* cuando:

- (i) esa igualdad es el principal acoplamiento del modelo,
- (ii) los subproblemas resultantes (cosecha discreta y procesamiento LP) se resuelven exactamente,
- (iii) capacidades y costos son vinculantes y de magnitud comparable.

Puede ser *débil* si:

- (i) la compra externa es muy barata,
- (ii) las capacidades no son vinculantes,
- (iii) la componente binaria genera saltos que un único multiplicador por periodo no penaliza bien.

Conclusión del chat. En síntesis, la cota dual al dualizar la restricción de balance (4) suele ser útil y cercana al óptimo cuando el acoplamiento cosecha procesamiento es la dificultad dominante y las capacidades/costos son vinculantes; puede ser débil si comprar externo es barato, las capacidades no son activas o la parte entera introduce saltos no bien penalizados. La respuesta completa está en el mismo enlace del ítem a. En general, la calidad de la cota depende de esos factores, pero según el chat, para el caso típico del problema debería ser buena.

5.3. Ítem c.

La relajación propuesta por el chat es correcta (la misma de la respuesta de la I2): relaja la igualdad de balance (4) con multiplicadores libres $\lambda_t \in \mathbb{R}$, separa en dos subproblemas (cosecha y procesamiento/compra) y define la dual como $\max_{\lambda} \mathcal{L}(\lambda)$.

Evaluación crítica y ambigüedades. Si bien la respuesta es adecuada, hay aspectos a considerar:

- El chat menciona que el subproblema de cosecha es un pequeño problema combinatorio. Sin embargo, este es un problema de programación mixta no trivial, que se debería resolver con Branch and Bound.
- En el otro subproblema, el chat acierta al mencionar que es programación lineal, dice que es sencillo de resolver, pero no menciona cómo, solo que se use un solver. Podría haber mencionado que se puede usar simplex.
- Faltó también mencionar otras opciones de relajación.

Opciones de relajación que no se mencionaron. El chat no consideró explícitamente otras restricciones candidatas a relajar que también acoplan decisiones y pueden dar descomposiciones útiles:

- **Restricción (2):** $x_{jt} \leq L_j y_{jt}$. Es un acoplamiento continuo-binario por parcela/período. Relajarla con multiplicadores $\mu_{jt} \geq 0$ separa x de y , pudiendo resolver x continuo por señales de costo y y como selección binaria independiente.
- **Restricciones (3) y (6):** capacidades/demandas por período que impiden separar completamente en el tiempo. Relajarlas con multiplicadores por período puede aumentar la descomposición temporal y el paralelismo, aunque típicamente debilita la cota dual.

Conclusión. La opción de relajar (4) es una buena primera elección por fuerza de acoplamiento y simplicidad de los subproblemas, pero faltó mencionar considerar también relajar (2) y, según el caso, (3) y (6) para explorar mejores descomposiciones o cotas alternativas.

6. Problema 6

6.1. Ítem a.

Viendo la estructura y naturaleza de las variables del problema, el espacio de búsqueda puede tomarse como el definido por las variables binarias y , que será discreto. Se elige esta variable precisamente por dicha razón, ya que es una variable entera que si la tomamos como un valor dado, deja el problema como uno de programación lineal con sólo variables continuas. Además, la variable y es la variable de "decisión" de la cosecha (si se realiza o no), por lo que es más fácil resolver el problema de optimización de variables continuas relacionado a cantidades de cosecha.

El espacio de búsqueda sería:

$$Y = \{y \in \{0, 1\}^{nT} : \sum_{t=1}^T y_{jt} = 1, \quad j = 1, \dots, n\} \quad (5)$$

6.2. Ítem b.

Si tomamos una realización particular de $\hat{y} \in Y$, la función objetivo y el problema quedarían de la siguiente manera (considerando $g(\hat{y})$ como el valor del problema):

$$g(\hat{y}) = \min \sum_{t=1}^T \left(\sum_{j=1}^n c_{jt} x_{jt} + \sum_{j=1}^n f_{jt} \hat{y}_{jt} + \sum_{i=1}^m e_{it} z_{it} + \beta_t v_t \right) \quad (6)$$

$$\text{s.a.} \quad \sum_{j=1}^n \alpha_{jt} x_{jt} \leq B_t, \quad t = 1, \dots, T \quad (1)$$

$$x_{jt} \leq L_j \hat{y}_{jt}, \quad j = 1, \dots, n; \quad t = 1, \dots, T \quad (2)$$

$$\sum_{j=1}^n x_{jt} = \sum_{i=1}^m z_{it}, \quad t = 1, \dots, T \quad (3)$$

$$\sum_{i=1}^m z_{it} \geq d_t - v_t, \quad t = 1, \dots, T \quad (4)$$

$$\sum_{t=1}^T z_{it} \leq K_i, \quad i = 1, \dots, m \quad (5)$$

$$x_{jt} \geq 0, z_{it} \geq 0, v_t \geq 0, \quad j = 1, \dots, n; \quad t = 1, \dots, T; \quad i = 1, \dots, m \quad (6)$$

Por lo tanto, el problema que la heurística trata de resolver es

$$\min \quad g(y) \quad (7)$$

$$\text{s.a.} \quad y \in Y \quad (8)$$

La complejidad de este problema está relacionado a la cantidad de variables y restricciones de este. En particular, hay nT variables x , mT variables z y T variables v . Por otro lado, las restricciones (1), (3) y (4) tienen T ecuaciones cada una; la restricción (2), nT ecuaciones y la restricción (5), m . Por lo tanto, la resolución del problema con $\hat{y}$ fijo se resuelve con tiempo polinomial dependiendo de la cantidad de variables y restricciones.

6.3. Ítem c.

Sea $\hat{y} \in Y$ una solución factible actual. Definimos su vecindad $V(\hat{y})$ como el conjunto de soluciones factibles obtenidas mediante modificaciones elementales sobre $\hat{y}$. A continuación se presenta un posible procedimiento:

Algorithm 1 Generación de vecindad $V(\hat{y})$

Require: Solución actual $\hat{y} \in Y$, número de vecinos a generar $N \in \mathbb{N}$

Ensure: Vecindad $V(\hat{y}) \subseteq Y$

```

1: Inicializar  $V(\hat{y}) \leftarrow \emptyset$ 
2: while  $|V(\hat{y})| < N$  do
3:   Crear copia  $y' \leftarrow \hat{y}$ 
4:   Elegir aleatoriamente una parcela  $j \in \{1, \dots, n\}$ 
5:   if  $\exists t \in \{1, \dots, T\} : y_{jt} = 1$  then
6:     Elegir aleatoriamente una de las dos operaciones siguientes:
     (a) Elegir no cosechar ese día  $t$  en la parcela  $j$ :
          $y'_{jt} \leftarrow 0$ 
     (b) Cambiar el día de la cosecha:
         Elegir  $t' \in \{1, \dots, T\}$  al azar, con  $t' \neq t$ 
          $y'_{jt'} \leftarrow 1, y'_{jt} \leftarrow 0$ 
7:   else if  $\sum_{t=1}^T y_{jt} = 0$  then
8:     Elegir un día  $t \in \{1, \dots, T\}$  al azar para que ese día se coseche en la parcela  $j$ :
9:      $y'_{jt} \leftarrow 1$ 
10:   end if
11:   if  $y' \in Y$  then
12:     Agregar  $y'$  a  $V(\hat{y})$ 
13:   end if
14: end while
15: return  $V(\hat{y})$ 

```

7. Problema 7

7.1. Ítem a.

Para encontrar el Lagrangeano de algún problema, se tenía que:

$$\min f(x) \quad (9)$$

$$\text{s.a } g_i(x) \leq b_i \quad (10)$$

$$x \in C \quad (11)$$

Donde el Lagrangeano estaba dado por:

$$L(x, \lambda) = f(x) + \sum \lambda (g_i(x) - b_i) \quad (12)$$

Y el problema dual estaba dado por:

$$\max_{\lambda \geq 0} \min_{x \in C} L(x, \lambda) \quad (13)$$

Siguiendo este mismo enfoque, podemos evidenciar lo pedido en la pregunta. En primer lugar, definimos el Lagrangeano del problema P), que corresponde a:

$$\begin{aligned} L(x, u) &= c^T x + u^T (b - Ax) \\ &= b^T u + c^T x - (A^T u)^T x \\ &= b^T u + (c - A^T u)^T x \end{aligned}$$

Por lo tanto, la función dual estaría dada por:

$$\begin{aligned} \theta(u) &= \min_{x \in C} L(x, u) \\ &= \min_{x \in C} b^T u + (c - A^T u)^T x \\ &= b^T u + \min_{x \in C} (c - A^T u)^T x \end{aligned}$$

Por lo tanto, el problema dual sería:

$$\max_{u \geq 0} \theta(u) = \max_{u \geq 0} b^T u + \min_{x \in C} (c - A^T u)^T x$$

Ahora, si se tiene que $(c - A^T u) < 0$, el problema de minimización $\theta(u)$ va a tener como solución que x tienda a ∞ , para que así el valor objetivo tienda a $-\infty$, lo que haría que el problema $\max \theta(u)$ no tenga sentido (se va a estar maximizando $-\infty$).

Por lo tanto, se requiere que $(c - A^T u) \leq 0$, que si nos damos cuenta, calza perfectamente con la definición de K^* , ya que se tiene $(c - A^T u) \in \mathbb{R}^n$, tal que $(c - A^T u)^T x, \forall x \in K$.

Si definimos que $s = c - A^T u$, se puede plantear el problema dual como:

$$\text{máx } b^T u \quad (14)$$

$$\text{s.a } A^T u + s = c \quad (15)$$

$$s \in K^* \quad (16)$$

Por lo que queda demostrado lo pedido.

7.2. Ítem b.

En primer lugar, reescribimos la primera restricción, es decir

$$(x - z)^T Q(x - z) \leq r \quad (17)$$

Donde Q es simétrica y definida positiva. Esto implica que $\exists R : Q = R^T R$. Entonces, se tiene que:

$$(x - z)^T Q(x - z) = (x - z)^T R^T R(x - z) = \|R(x - z)\|_2^2 \quad (18)$$

Por lo tanto, la restricción queda como:

$$\|R(x - z)\|_2^2 \leq r = \|R(x - z)\|_2 \leq \sqrt{r} \quad (19)$$

Si definimos $u = R(x - z)$ y $t = \sqrt{r}$, se tiene que $\|u\|_2 \leq \sqrt{r}$, por lo que, por definición, se cumple que $(u, t) \in Q^{n+1}$.

Por lo tanto, el problema queda como:

$$\text{mín } c^T x \quad (20)$$

$$\text{s.a } Ax = b \quad (21)$$

$$u = R(x - z) \quad (22)$$

$$t = \sqrt{r} \quad (23)$$

$$x \geq 0 \quad (24)$$

$$(u, t) \in Q^{n+1} \quad (25)$$

Escribiremos el problema de forma matricial para dejarlo con la misma estructura que el problema P) del ítem a.

$$\text{Definimos: } y = \begin{bmatrix} x \\ u \\ t \end{bmatrix}, d = \begin{bmatrix} c \\ 0 \\ 0 \end{bmatrix}, E = \begin{bmatrix} A & 0 & 0 \\ -R & I & 0 \\ 0 & 0 & 1 \end{bmatrix} \text{ y } f = \begin{bmatrix} b \\ -Rz \\ \sqrt{r} \end{bmatrix}.$$

Donde el conjunto K sería el producto de los conos a los cuales pertenecen las variables x, u y t . En este caso, $K = \mathbb{R}_+^n \times Q^{n+1}$.

De esta manera, se tiene que el problema quedaría como:

$$\text{mín } d^T y \quad (26)$$

$$\text{s.a } Ey = f \quad (27)$$

$$y \in K \quad (28)$$

Ahora podemos realizar un proceso análogo al del inciso anterior, donde el problema dual terminaría siendo:

$$\text{máx } f^T w \quad (29)$$

$$\text{s.a } E^T w + l = d \quad (30)$$

$$l \in K^* \quad (31)$$

Donde el conjunto K^* está dado por el producto de los conos duales de $\mathbb{R}_+^n \times \mathcal{Q}^{n+1}$ en este caso, ya que son los que componen el conjunto K . Los duales de dichos conos son estos mismos, por lo que $K^* = \mathbb{R}_+^n \times \mathcal{Q}^{n+1}$.

8. Problema 8

El modelo inicial es el siguiente:

$$\min \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J (c_{jkt} x_{jkt} + F_{jkt} y_{jkt}) + \sum_{j=1}^J h_{jt} I_{jt} \right\} \quad (32)$$

$$\text{s.a. } I_{jt} = I_{j,t-1} + \sum_{k=1}^K x_{jkt} - d_{jt}, \quad j = 1, \dots, J; t = 1, \dots, T \quad (1)$$

$$\sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt}, \quad k = 1, \dots, K; t = 1, \dots, T \quad (2)$$

$$x_{jkt} \leq M y_{jkt}, \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (3)$$

$$\sum_{k=1}^K y_{jkt} = 1, \quad j = 1, \dots, J; t = 1, \dots, T \quad (4)$$

$$\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} \leq P, \quad (5)$$

$$x_{jkt} \geq 0, \quad I_{jt} \geq 0, \quad y_{jkt} \in \{0, 1\}, \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (6)$$

a)

Los parámetros β_{jk} y H_{kt} se pueden modelar con un comportamiento normal, con media y desviación estándar de $(\bar{\beta}_{jk}, \sigma_{jk})$ y $(\bar{H}_{kt}, \eta_{kt})$ respectivamente.

Para que nuestro modelo considere la incertidumbre asociada al parámetro β_{jk} , buscaremos reformular la restricción (5) para que esta sea equivalente a que esta se cumpla con una cierta probabilidad ε .

Buscamos entonces que se cumpla $\mathbb{P}(\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} \leq P) = \varepsilon$.

Ya que $\beta_{jk} \sim \mathbb{N}(\bar{\beta}_{jk}, \sigma_{jk}^2)$, entonces $\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} \sim \mathbb{N}(\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt}, \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2)$

Por lo tanto, tenemos que:

$$T = \frac{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} - (\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt})}{\sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2}} \sim \mathbb{N}(0, 1) \quad (33)$$

Entonces, tenemos que:

$$\mathbb{P}\left(\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} \leq P\right) = \mathbb{P}\left(T \leq \frac{P - \left(\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt}\right)}{\sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2}}\right) \quad (34)$$

Por ende, que se cumpla $\mathbb{P}\left(\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} \leq P\right) = \varepsilon$ será equivalente a que se cumpla la siguiente ecuación:

$$\frac{P - \left(\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt}\right)}{\sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2}} \geq z_\varepsilon \quad (35)$$

en la cual z_ε es el percentil ε de la distribución $Normal(0, 1)$.

Para $\varepsilon = 0.95$, $z_\varepsilon = 1.65$, entonces, para que la restricción (5) se cumpla con un 95 % de probabilidad, necesitamos añadir la siguiente restricción al modelo:

$$\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt} + (1.65) \cdot \sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2} \leq P \quad (36)$$

Por otra parte, para incorporar la incertidumbre asociada al parámetro H_{kt} al modelo, deseamos que la restricción (2) se cumpla con un 95 % de probabilidades. Por lo tanto, buscamos calcular:

$$\mathbb{P}\left(\sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt}\right) \Leftrightarrow \mathbb{P}\left(H_{kt} \geq \sum_{j=1}^J \alpha_{jk} x_{jkt}\right) \Leftrightarrow \mathbb{P}\left(-H_{kt} \leq -\sum_{j=1}^J \alpha_{jk} x_{jkt}\right) \quad (37)$$

Tenemos que:

$$T = \frac{-H_{kt} - (-\bar{H}_{kt})}{\sqrt{\eta_{kt}^2}} = \frac{\bar{H}_{kt} - H_{kt}}{\eta_{kt}} \sim \mathbb{N}(0, 1) \quad (38)$$

Entonces,

$$\mathbb{P}\left(-H_{kt} \leq -\sum_{j=1}^J \alpha_{jk} x_{jkt}\right) = \mathbb{P}\left(T \leq \frac{-\sum_{j=1}^J \alpha_{jk} x_{jkt} - (-\bar{H}_{kt})}{\eta_{kt}}\right) \quad (39)$$

Por ende, para que se cumpla $\mathbb{P}\left(\sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt}\right) = \varepsilon$, es equivalente a que se cumpla la siguiente

ecuación:

$$\frac{\bar{H}_{kt} - \sum_{j=1}^J \alpha_{jk} x_{jkt}}{\eta_{kt}} \geq z_{\varepsilon} \quad (40)$$

en la cual z_{ε} es el percentil ε de la distribución $Normal(0, 1)$.

Para $\varepsilon = 0.95$, $z_{\varepsilon} = 1.65$, entonces, para que la restricción (5) se cumpla con un 95 % de probabilidad, necesitamos añadir la siguiente restricción al modelo:

$$\sum_{j=1}^J \alpha_{jk} x_{jkt} + (1.65) \cdot \eta_{kt} \leq \bar{H}_{kt} \quad (41)$$

Finalmente, podemos crear el problema inicial reformulado en una forma determinística que permitirá que las restricciones con incertidumbre se cumplan con probabilidad 0,95. El modelo es el siguiente (Debido a que $y_{jkt} \in \{0, 1\}$, tenemos que $y_{jkt}^2 = y_{jkt}$):

$$\min \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J (c_{jkt} x_{jkt} + F_{jkt} y_{jkt}) + \sum_{j=1}^J h_{jt} I_{jt} \right\} \quad (42)$$

$$\text{s.a. } I_{jt} = I_{j,t-1} + \sum_{k=1}^K x_{jkt} - d_{jt}, \quad j = 1, \dots, J; t = 1, \dots, T \quad (1)$$

$$\sum_{j=1}^J \alpha_{jk} x_{jkt} + (1.65) \cdot \eta_{kt} \leq \bar{H}_{kt}, \quad k = 1, \dots, K; t = 1, \dots, T \quad (2)$$

$$x_{jkt} \leq M y_{jkt}, \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (3)$$

$$\sum_{k=1}^K y_{jkt} = 1, \quad j = 1, \dots, J; t = 1, \dots, T \quad (4)$$

$$\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt} + (1.65) \cdot \sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}} \leq P, \quad (5)$$

$$x_{jkt} \geq 0, \quad I_{jt} \geq 0, \quad y_{jkt} \in \{0, 1\}, \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (6)$$

b)

La restricción (5) de la formulación determinística obtenida en (a) puede escribirse como

$$\sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2} \leq \frac{1}{z_{0.95}} \left(P - \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt} \right), \quad (43)$$

donde ($z_{0,95}$ es el percentil 0,95 de la $N(0, 1)$ app 1.65. Definiendo las variables

$$\tau = \frac{1}{1.65} \left(P - \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt} \right), \quad v_{jkt} = \sigma_{jk} y_{jkt}, \quad (44)$$

la restricción (5) es equivalente a

$$\|v\|_2 \leq \tau, \quad (45)$$

es decir, (v, τ) pertenece al cono de segundo orden de dimensión adecuada. Para este cono, una función de barrera logarítmica estándar es

$$\Phi_{\text{cono}}(v, \tau) = -\log \left(\tau^2 - \|v\|_2^2 \right), \quad (46)$$

definida en el interior del cono $\{(v, \tau) : \tau^2 > \|v\|_2^2\}$.

De forma análoga, las restricciones determinísticas de capacidad y de enlace quedan:

$$\sum_{j=1}^J \alpha_{jk} x_{jkt} + 1.65 \eta_{kt} \leq \bar{H}_{kt}, \quad k = 1, \dots, K; t = 1, \dots, T, \quad (2)$$

$$x_{jkt} \leq M y_{jkt}, \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T, \quad (3)$$

dando lugar a las siguientes funciones de barrera asociadas:

$$\Phi_2(x) = - \sum_{k=1}^K \sum_{t=1}^T \log \left(\bar{H}_{kt} - \sum_{j=1}^J \alpha_{jk} x_{jkt} - 0.65 \eta_{kt} \right), \quad (47)$$

$$\Phi_3(x, y) = - \sum_{j=1}^J \sum_{k=1}^K \sum_{t=1}^T \log \left(M y_{jkt} - x_{jkt} \right). \quad (48)$$

Para la relajación lineal del modelo, se consideran además las restricciones de naturaleza de variables:

$$x_{jkt} \geq 0, \quad I_{jt} \geq 0, \quad 0 \leq y_{jkt} \leq 1, \quad (49)$$

lo que induce las siguientes funciones de barrera:

$$\Phi_x(x) = - \sum_{j=1}^J \sum_{k=1}^K \sum_{t=1}^T \log(x_{jkt}), \quad (50)$$

$$\Phi_I(I) = - \sum_{j=1}^J \sum_{t=1}^T \log(I_{jt}), \quad (51)$$

$$\Phi_y(y) = - \sum_{j=1}^J \sum_{k=1}^K \sum_{t=1}^T \left(\log(y_{jkt}) + \log(1 - y_{jkt}) \right). \quad (52)$$

Agrupando todas las funciones de barrera, definimos

$$\Phi(x, I, y, v, \tau) = \Phi_{\text{cono}}(v, \tau) + \Phi_2(x) + \Phi_3(x, y) + \Phi_x(x) + \Phi_I(I) + \Phi_y(y). \quad (53)$$

El problema penalizado que se resuelve en un algoritmo de punto interior para la relajación lineal cónica del modelo de la parte (a) es entonces:

$$\min_{x, I, y, v, \tau} \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \left(c_{jkt} x_{jkt} + F_{jkt} y_{jkt} \right) + \sum_{j=1}^J h_{jt} I_{jt} \right\} + \mu \Phi(x, I, y, v, \tau) \quad (54)$$

$$\text{s.a. } I_{jt} = I_{j,t-1} + \sum_{k=1}^K x_{jkt} - d_{jt}, \quad j = 1, \dots, J; t = 1, \dots, T, \quad (1)$$

$$\sum_{k=1}^K y_{jkt} = 1, \quad j = 1, \dots, J; t = 1, \dots, T, \quad (4)$$

$$\tau = \frac{1}{z_{0.95}} \left(P - \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk} y_{jkt} \right), \quad (5a)$$

$$v_{jkt} = \sigma_{jk} y_{jkt}, \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T, \quad (5b)$$

donde $\mu > 0$ es el parámetro de penalización del método de punto interior.

9. Problema 9

Sea el siguiente problema:

$$\min \sum_{t=1}^T \left(\sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt} \right) \quad (55)$$

$$\text{s.a. } I_{jt} = I_{j,t-1} + \sum_{k=1}^K x_{jkt} - d_{jt}, \quad \forall j = 1, \dots, J; t = 1, \dots, T \quad (1)$$

$$\sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt}, \quad \forall k = 1, \dots, K; t = 1, \dots, T \quad (2)$$

$$x_{jkt} \leq My_{jkt}, \quad \forall j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (3)$$

$$\sum_{k=1}^K y_{jkt} = 1, \quad \forall j = 1, \dots, J; t = 1, \dots, T \quad (4)$$

$$\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk}y_{jkt} \leq P \quad (5)$$

$$x_{jkt} \geq 0, I_{jt} \geq 0, y_{jkt} \in \{0, 1\}, \quad \forall j, k, t \quad (6)$$

9.1. Ítem a.

Para reformular el problema considerando el efecto de la demanda no satisfecha y su costo asociado, es necesario relajar la restricción de balance de inventario original (Restricción 1). Dicha restricción, en su forma original, forzaba el cumplimiento estricto de la demanda:

$$I_{jt} = I_{j,t-1} + \sum_{k=1}^K x_{jtk} - d_{jt}$$

Para permitir el faltante, introducimos la variable de decisión no negativa S_{jt} , que representa la demanda insatisfecha del producto j en el periodo t . De esta forma, la ecuación de balance se transforma para permitir que la demanda supere a la oferta disponible:

$$I_{jt} - S_{jt} = I_{j,t-1} + \sum_{k=1}^K x_{jtk} - d_{jt}, \quad \forall j, t \quad (1 \text{ transformada})$$

Esta modificación implica que si la demanda d_{jt} es mayor que el inventario disponible más la producción, la variable S_{jt} tomará un valor positivo para equilibrar la ecuación.

Consecuentemente, la función objetivo debe ser penalizada por este incumplimiento. Dado que la empresa incurre en un costo ρ_{jt} por cada unidad de demanda no satisfecha, la nueva función objetivo que minimiza los costos totales queda expresada como:

$$\min Z = \sum_{t=1}^T \left[\sum_{j=1}^J \sum_{k=1}^K (c_{jtk}x_{jtk} + F_{jtk}y_{jtk}) + \sum_{j=1}^J (h_{jt}I_{jt} + \rho_{jt}S_{jt}) \right]$$

Sujeto a:

$$I_{jt} - S_{jt} = I_{j,t-1} + \sum_{k=1}^K x_{jtk} - d_{jt}, \quad \forall j, t \quad (1 \text{ transformada})$$

$$S_{jt} \geq 0, \quad \forall j, t$$

Las restricciones (2), (3), (4), (5) y (6) se mantienen inalteradas con respecto al modelo original.

9.2. Ítem b.

Para modelar el problema bajo incertidumbre como un problema de optimización estocástica de dos etapas con recurso, debemos identificar las variables de primera etapa (decisiones "*here and now*") y las variables de ajuste o segunda etapa (decisiones "*wait and see*").

■ Primera Etapa (Here and Now):

- y_{jkt} : Variable binaria de asignación.
- x_{jkt} : Cantidad a producir del producto j en la línea k durante el periodo t .

■ Segunda Etapa (Wait and See):

- I_{jt}^ω : Inventario final del producto j en el periodo t bajo el escenario ω .
- S_{jt}^ω : Demanda insatisfecha del producto j en el periodo t bajo el escenario ω .

Con esto definido, el problema maestro (Primera Etapa) es:

$$\begin{aligned} \min \quad & \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J (c_{jtk}x_{jtk} + F_{jtk}y_{jtk}) + \mathbb{E}_\xi [Q(x, y, \xi)] \\ \text{s.a.} \quad & \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt}, \quad \forall k, t \\ & x_{jkt} \leq M y_{jkt}, \quad \forall j, k, t \\ & \sum_{k=1}^K y_{jkt} = 1, \quad \forall j, t \\ & \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk}y_{jkt} \leq P \\ & x_{jkt} \geq 0, y_{jkt} \in \{0, 1\}, \quad \forall j, k, t \end{aligned}$$

Donde la función de recurso $Q(\hat{x}, \hat{y}, \omega)$, que representa el costo mínimo futuro dado un escenario ω , corresponde al problema de segunda etap:

$$\begin{aligned} Q(\hat{x}, \hat{y}, \omega) = \min \quad & \sum_{t=1}^T \sum_{j=1}^J (h_{jt} I_{jt}^{\omega} + \rho_{jt} S_{jt}^{\omega}) \\ \text{s.a.} \quad & I_{jt}^{\omega} - S_{jt}^{\omega} = I_{j,t-1}^{\omega} + \sum_{k=1}^K \hat{x}_{jkt} - d_{jt}^{\omega}, \quad \forall j, t \\ & I_{jt}^{\omega}, S_{jt}^{\omega} \geq 0, \quad \forall j, t \end{aligned}$$

9.3. Ítem c.

El método de Aproximación por Promedio Muestral (SAA, por sus siglas en inglés) permite aproximar el valor esperado $\mathbb{E}[\cdot]$ de la función objetivo utilizando el promedio empírico de una muestra de tamaño N . Esta técnica transforma el problema estocástico original en un problema determinista equivalente de mayor tamaño, lo cual nos permite aprovechar los algoritmos de optimización estándar para obtener soluciones factibles y eficientes.

Dado que la demanda es una variable aleatoria con distribución $d_{jt} \sim \text{Beta}(\gamma_{jt}, \delta_{jt})$, generamos N escenarios independientes idénticamente distribuidos (i.i.d.). Para cada escenario $n = 1, \dots, N$, obtenemos una realización de la demanda denotada como d_{jt}^n .

El modelo SAA resultante ("Equivalente Determinista") es:

$$\begin{aligned} \min \quad & \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J (c_{jkt} x_{jkt} + F_{jkt} y_{jkt}) + \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^T \sum_{j=1}^J (h_{jt} I_{jt}^n + \rho_{jt} S_{jt}^n) \\ \text{s.a.} \quad & \sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt}, \quad \forall k, t \\ & x_{jkt} \leq M y_{jkt}, \quad \forall j, k, t \\ & \sum_{k=1}^K y_{jkt} = 1, \quad \forall j, t \\ & \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk} y_{jkt} \leq P \\ & I_{jt}^n - S_{jt}^n = I_{j,t-1}^n + \sum_{k=1}^K x_{jkt} - d_{jt}^n, \quad \forall j, t, n \\ & x_{jkt}, I_{jt}^n, S_{jt}^n \geq 0, \quad y_{jkt} \in \{0, 1\}, \quad \forall j, k, t, n \end{aligned}$$

En esta formulación, el factor estocástico queda capturado por el parámetro d_{jt}^n . Al simular estos valores previamente utilizando la distribución Beta especificada, d_{jt}^n se convierte en un vector de demanda determinista conocido para cada escenario n dentro del modelo de optimización.

9.4. ítem d.

El problema propuesto en el ítem anterior presenta una estructura favorable al uso de la descomposición de Benders. Se muestra a continuación la estructura de bloques al desplegar el modelo:

$$\begin{aligned}
 \text{mín} \quad Z &= \sum_{t,k,j} (c_{jkt}x_{jkt} + F_{jkt}y_{jkt}) + \frac{1}{N} \sum_{t,j} (h_{jt}I_{jt}^1 + \rho_{jt}S_{jt}^1) + \cdots + \frac{1}{N} \sum_{t,j} (h_{jt}I_{jt}^N + \rho_{jt}S_{jt}^N) \\
 \text{s.a.} \quad &\sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} && \forall k,t \\
 &x_{jkt} - My_{jkt} \leq 0 && \forall j,k,t \\
 &\sum_{k=1}^K y_{jkt} = 1 && \forall j,t \\
 &\sum_{k,j,t} \beta_{jk}y_{jkt} \leq P \\
 &-\sum_{k=1}^K x_{jkt} + (I_{jt}^1 - S_{jt}^1 - I_{j,t-1}^1) = -d_{jt}^1 && \forall j,t \\
 &\vdots && \ddots && \vdots \\
 &-\sum_{k=1}^K x_{jkt} + (I_{jt}^N - S_{jt}^N - I_{j,t-1}^N) = -d_{jt}^N && \forall j,t \\
 &x, y \in \Omega_1 && I^1, S^1 \geq 0 && I^N, S^N \geq 0
 \end{aligned}$$

10. Referencias bibliográficas

- Kang, Ningxuan & Shen, Hao & Xu, Ye, 2022. "JD.com Improves Delivery Networks by a Multiperiod Facility Location Model," *INFORMS Journal on Applied Analytics*, INFORMS, vol. 52(2), pages 119-130.
- Wikipedia contributors. (s. f.). Total derivative. En Wikipedia. Recuperado el 26 de noviembre de 2025, de https://en.wikipedia.org/wiki/Total_derivative
- Mandi, et al. (2024). Decision-focused learning review. *Journal of Artificial Intelligence Research*. Recuperado el 26 de noviembre de 2025, de https://cursos.canvas.uc.cl/courses/90425/files/13815698/module_item_id=2830369
- Mosek. (5 de noviembre de 2025). 8 Duality in conic optimization. <https://docs.mosek.com/modeling-cookbook/duality.html>
- Mosek. (17 de noviembre de 2025). 12.2 Conic Optimization. <https://docs.mosek.com/11.0/capi/prob-def-conic.html>
- PlanetMath contributors. (s. f.). Derivative of inverse matrix. PlanetMath. Recuperado el 26 de noviembre de 2025, de <https://planetmath.org/derivativeofinversematrix>