

### Tarea 3. Solución


#### Pregunta 1 (12 pts):

Mostraremos en este problema como la idea de planos cortantes, que revisamos en clases, puede usarse a partir de la estructura del problema para ayudar a resolver problemas muy difíciles, como es el Problema del Vendedor Viajero (PVV).

Necesitamos, primero, introducir algo de notación que nos hará más cómodo el manejo de la formulación. Vamos a suponer que tenemos una red no dirigida  $(N, A)$ , donde  $N$  es el conjunto de nodos y  $A$  es el conjunto de arcos. El usar una red no dirigida es perfectamente válido para este problema ya que lo asumimos “simétrico”: ir del origen al destino es la misma distancia que del destino al origen. Es decir, no nos preocupamos de sentido de los arcos. Vamos a denotar por  $e \in A$  un arco cualquiera, y para un nodo  $v$ ,  $\delta(v) \subset A$  denota el conjunto de arcos incidentes a  $v$ , es decir, arcos tales que uno de sus extremos es el vértice  $v$ . Si  $K \subset N$ ,  $\delta(K)$  es el conjunto de arcos incidentes a  $K$  (arcos con un extremo en algún nodo de  $K$ ). Entonces, usaremos la siguiente formulación del Problema del Vendedor Viajero:

$$\begin{aligned} \text{mín} \quad & \sum_{e \in A} d_e x_e \\ \text{s.t.} \quad & \sum_{e \in \delta(v)} x_e = 2, v \in N \quad (1) \\ & \sum_{e \in \delta(K)} x_e \geq 2, \forall K \subsetneq N \quad (2) \\ & x_e \in \{0, 1\}, e \in A \end{aligned}$$

donde  $d_e$  es el largo del arco  $e$ . Las restricciones (1) piden que cada nodo de la red debe tener exactamente 2 arcos que inciden con él. Esto es natural ya que un camino que corresponda a un circuito de vendedor viajero debe entrar y salir siempre de cada nodo. Las restricciones (2) se conocen como “restricciones de eliminación de subcircuitos y funcionan de la siguiente forma: piden que para cualquier subconjunto de nodos de la red, debe haber al menos un arco que entre y otro que salga de ese conjunto. La siguiente figura muestra una solución (los arcos en azul tienen  $x_e = 1$ ) que cumple con las restricciones (1) ya que cada nodo tiene dos arcos que conectan con él, pero que presenta dos subcircuitos:



Esta solución no es un circuito de vendedor viajero. Si tomamos  $K = \{1, 2, 3\}$  en la figura, tenemos que  $\sum_{e \in \delta(K)} x_e = 0$ . Es en ese sentido que las restricciones (2) eliminan subcircuitos.

Para abordar este problema (que es muy difícil), intentaremos primero resolver la relajación lineal de la formulación:


$$\begin{aligned} \text{mín} \quad & \sum_{e \in A} d_e x_e \\ \text{s.t.} \quad & \sum_{e \in \delta(v)} x_e = 2, v \in N \quad (1) \\ & \sum_{e \in \delta(K)} x_e \geq 2, \forall K \subsetneq N \quad (2) \\ & 0 \leq x_e \leq 1, e \in A \end{aligned}$$

Como esta formulación tiene un número exponencial de restricciones, esto no se puede resolver directamente. Una idea puede ser partir sin las restricciones de eliminación de subcircuitos y comenzar a agregarlas de a una, en un esquema de planos cortantes. Más específicamente, si una solución  $\{\bar{x}_e\}_{e \in A}$  viola una restricción de eliminación de subcircuitos, entonces tiene que existir un subconjunto  $\bar{K}$  propio de los nodos tal que


$$\sum_{e \in \delta(\bar{K})} \bar{x}_e < 2$$

La pregunta que surge de inmediato es cómo encontrar tal conjunto  $\bar{K}$ , para poder agregar, entonces, la restricción  $\sum_{e \in \delta(\bar{K})} \bar{x}_e \geq 2$ . Exploraremos eso en este problema.

**a) (2 pts)** Considere la red no dirigida  $(N, A)$  que se muestra en la figura:



Suponga que en una cierta iteración del algoritmo de planos cortantes, se tiene la siguiente solución en las variables de los arcos:



Muestre que esta solución cumple las restricciones (1) de la formulación del problema del vendedor viajero (las restricciones de “asignación”).


**Solución:** Esto es simple verificación de que en cada nodo la suma de los valores es exactamente 2. Por ejemplo, en el nodo inferior izquierdo, la suma es  $1 + \frac{1}{2} + \frac{1}{2} = 2$ . Lo mismo pasa en todos los demás, acá no se muestra todo el desarrollo.

**b) (3 pts)** Ahora, “por inspección”, determine al menos dos restricciones de eliminación de subcircuitos que no sean cumplidas por la solución de la parte a).

**Solución:** Debe buscarse un “corte” de la red tal que la suma de los valores de los arcos que conectan el corte sea menor a 2, es decir, determinar  $\bar{K}$  tal que

$$\sum_{e \in \delta(\bar{K})} \bar{x}_e < 2$$

Las siguientes figuras muestran dos maneras de hacer esos cortes:



Con esto, las restricciones se definen con los siguientes conjuntos:

$$\bar{K}_1 = \{1, 2, 3, 4\}, \quad \bar{K}_2 = \{9, 10, 11\}$$

y las restricciones son:

$$\sum_{e \in \delta(\bar{K}_1)} \bar{x}_e \geq 2$$

$$\sum_{e \in \delta(\bar{K}_2)} \bar{x}_e \geq 2$$

- c) (3 pts) Vamos ahora a generalizar la forma de buscar restricciones de subcircuito violadas. Primero, dada una red  $(N, A)$ , en donde cada arco  $e \in A$  tiene asignado un número,  $u_e$ , que llamaremos capacidad del arco. Definimos un “corte” en la red como una partición de los nodos definida por un subconjunto  $S \subset N$ , con su complemento siendo  $N - S$ . Denotemos por  $\bar{A}(S) \subset A$  el conjunto de todos los arcos que tienen un extremo en  $S$  y el otro en  $N - S$  (van de un lado al otro del corte). Se define la “capacidad del corte” como

$$\sum_{e \in \bar{A}(S)} u_e$$

El *problema del corte mínimo en una red* no dirigida  $(N, A)$  consiste en encontrar una partición  $(S, N - S)$  que defina un corte y que tenga la mínima capacidad posible.

Formule el problema general de encontrar una restricción de eliminación de subcircuitos violada como el problema de encontrar un corte de mínima capacidad en la red, donde se definen las capacidades de los arcos de manera adecuada.

**Solución:** A partir de la intuición de la pregunta anterior, lo que hay que hacer es construir la red definiendo la capacidad de los arcos como  $u_e = \bar{x}_e$ , donde  $x$  es la solución relajada actual. Entonces, planteamos el problema de encontrar el corte de capacidad mínima:

$$\begin{aligned} \text{mín}_S \quad & \sum_{e \in \bar{A}(S)} u_e \\ \text{s.a.} \quad & S \subset N \\ & S \neq N \end{aligned}$$

Ahora, este mismo problema se puede escribir de manera más “manejable” como problema de Programación Entera. Para esto, vamos a usar variables  $y_i$  para seleccionar los nodos y consideramos el siguiente problema:

$$\begin{aligned} \text{mín}_S \quad & \sum_{e \in \bar{A}(S)} u_e \\ \text{s.a.} \quad & S = \{i : y_i = 1\} \\ & \sum_{i \in N} y_i \leq |N| - 1 \\ & y_i \in \{0, 1\}, i \in N \end{aligned}$$

- d) (4 pts) Usted debería recordar, del curso de Optimización, el problema de Flujo Máximo en una red **dirigida**. Supongamos tenemos un grafo, o red, dirigido  $(N, A)$ . Cada arco  $(i, j) \in A$  tiene capacidad  $u_{ij}$  (eventualmente  $+\infty$ .) Hay dos nodos particulares: nodo  $r$ , el “origen”, y nodo  $s$ , el “destino”. El problema consiste en enviar el mayor flujo posible de  $r$  a  $s$  sin exceder la capacidad en ningún arco. El problema puede formularse como uno de programación lineal: Sea  $x_{ij}$  el flujo en el arco  $(i, j)$ . Sea  $F$  el flujo que se envía desde el nodo  $r$ .

$$\begin{aligned} \text{máx} \quad & F \\ \text{s.a.} \quad & \sum_{j \in \delta^+(i)} x_{ij} - \sum_{k \in \delta^-(i)} x_{ki} = \begin{cases} F & i = r \\ 0 & i \neq r, s \\ -F & i = s \end{cases} \\ & 0 \leq x_{ij} \leq u_{ij}, \forall (i, j) \in A \end{aligned}$$

Vamos a definir un concepto de corte similar al que ya hemos mencionado, con algunas particularidades (la notación acá ha cambiado un poco, así que no se confunda).

**Definición:** Un corte- $(r, s)$  en una red dirigida  $(N, A)$  es una partición de  $N$  en dos subconjuntos disjuntos,  $S$  y  $T = N - S$  tales  $r \in S$ ,  $s \in T$ . Denotamos el corte por  $(S, T)$ .

**Definición:** La capacidad de un corte  $(S, T)$  es

$$\sum_{(i,j) \in A: i \in S, j \in T} u_{ij}$$

Un resultado muy famoso es el siguiente:

**Teorema de Ford y Fulkerson:** El máximo valor de flujo (si existe) que se puede enviar desde el origen  $r$  al destino  $s$  es igual a la menor capacidad de entre todos los cortes- $(r, s)$ .

Cuando se resuelve el problema de Flujo Máximo, resolviendo el problema de programación lineal mostrado más arriba, los arcos en los cuales el flujo satura la capacidad, permiten identificar el corte- $(r, s)$  de capacidad mínima.

Entonces, muestre, usando el concepto anterior, y el Teorema de Ford y Fulkerson, de qué forma el problema de separación de desigualdades de eliminación de subcircuitos, que desarrolló en c), podría ser abordado mediante la resolución de una cantidad (¿cuántos?) de problemas de Programación Lineal. Concluya que el problema de separación de desigualdades de eliminación de subcircuitos para el Problema del Vendedor Viajero, puede ser resuelto en tiempo polinomial.

**Solución:** En términos intuitivos, como hay que buscar un corte de capacidad mínima, eso debe poder hacerse buscando flujo máximo. El problema es que el problema de Flujo Máximo es dirigido y tiene origen y destino perfectamente definidos, así que se requieren algunas transformaciones de la red original no dirigida  $(N, A)$ . Asumimos que tenemos la solución relajada actual  $\bar{x}$ .

Vamos definir la red para problemas de Flujo Máximo, que denotaremos por  $(\tilde{N}, \tilde{A})$ . Primero, los nodos son los mismos, así que  $\tilde{N} = N$ . para los arcos, sea  $e \in A$ . Sean  $i \in N$  y  $j \in N$  los extremos de  $e$  (recordemos que, como es no dirigido, ninguno es especial). Definimos dos arcos *dirigidos* en  $\tilde{A}$  de la siguiente forma: el arco  $(i, j)$  y el arco  $(j, i)$ . A estos arcos asignamos una capacidad como  $u_{ij} = \bar{x}_e$ ,  $u_{ji} = \bar{x}_e$ . En otras palabras, por cada arco no dirigido creamos dos arcos en sentidos opuestos y con la misma capacidad. Ahora tenemos una red dirigida y con capacidades.

Sean  $r \in \tilde{N}$  y  $s \in \tilde{N}$  dos nodos de la red. Podemos formular el problema de encontrar el máximo flujo de  $r$  a  $s$  y con eso determinaremos un corte- $(r, s)$  mínimo. Pero este no es necesariamente el corte que buscamos ya que este específicamente separa  $r$  y  $s$ . Para garantizar encontrar el mínimo corte

cualquiera en la red  $(\tilde{N}, \tilde{A})$ , debemos enumerar todos los pares  $(r, s)$ , con  $r \neq s$  en la red y resolver el problema de Flujo Máximo para todos ellos, determinado también los correspondientes cortes mínimos. El más mínimo de los mínimos será el corte que buscamos.

hacer todo esto requiere resolver  $O(|N|^2)$  problemas de Flujo a Costo Mínimo, cada uno de los cuales, por ser un problema de Programación Lineal, se resuelve en tiempo polinomial. Luego, encontrar el mínimo corte se puede hacer en tiempo polinomial. Esto suena bastante ineficiente (por muy “polinomial” que sea) y hay formas más elaboradas de hacerlo, en realidad.

Esto que hemos desarrollado acá permite resolver aproximadamente la relajación lineal de la formulación del Problema del Vendedor Viajero, pero no necesariamente el problema en sí, ya que necesitamos valores enteros en las variables. Sin embargo, en muchos casos (aunque no garantizadamente en todos), al avanzar el método de planos cortantes, comienzan a obtenerse valores enteros. Algunos de los primeros problemas de Vendedor Viajero fueron resueltos de esta forma, pero problema más grandes requieren de otras desigualdades válidas adicionales.

### Pregunta 2 (10 pts):

Una empresa fabrica  $n$  productos haciendo uso de ciertos recursos productivos que entregan una capacidad máxima agregada mes a mes medida en horas. Además, se debe satisfacer una cierta demanda a lo largo de un horizonte de  $T$  meses. Además, cada vez que hay producción de cualquier producto en un mes, se debe incurrir en un costo fijo (set-up y otros costos de “arranque”. Los siguientes son los parámetros y datos que conocemos:

$d_{jt}$ : demanda por producto  $j$  en  $t$ ,  $j = 1, \dots, n, t = 1, \dots, T$ .

$b_t$ : Disponibilidad total de tiempo de producción en  $t$ ,  $t = 1, \dots, T$ .

$c_{jt}$ : Costo unitario de producción de  $j$  en  $t$ ,  $j = 1, \dots, n, t = 1, \dots, T$ .

$a_j$ : Cantidad de horas usadas en producir una unidad de producto  $j$ ,  $j = 1, \dots, n$ .

$h_{jt}$ : Costo de dejar una unidad de producto  $j$  en inventario en el mes  $t$ ,  $j = 1, \dots, n; t = 1, \dots, T$

$g_t$ : Costo fijo en que se incurre si se produce algún producto en  $t$ ,  $t = 1, \dots, T$ .

El modelo se construye con una decisión principal que es cuánto producir de cada producto en cada periodo,  $x_{jt}$ , el inventario de producto  $j$  en  $t$ ,  $I_{jt}$ , y una variable binaria  $z_t$  que vale 1 si se produce algún producto en  $t$ , y 0 en caso contrario. El modelo es:

$$(1) \quad \begin{aligned} \min \quad & \sum_{t=1}^T \sum_{j=1}^n \{c_{jt}x_{jt} + h_{jt}I_{jt}\} + \sum_{t=1}^T g_t z_t \\ \text{s.t.} \quad & I_{jt} = I_{j,t-1} + x_{jt} - d_{jt}, t = 1, \dots, T; j = 1, \dots, n \\ & \sum_{j=1}^n a_j x_{jt} \leq b_t, t = 1, \dots, T \\ & x_{jt} \leq M z_t, t = 1, \dots, T; j = 1, \dots, n \\ & x_{jt} \geq 0, I_{jt} \geq 0, z_t \in \{0, 1\}, t = 1, \dots, T; j = 1, \dots, n \end{aligned}$$

donde el valor de  $I_{j0}$  es constante y conocido.

a) (3 pts) ¿Cuál podría ser un buen valor para  $M$ ? (recuerde que tener un  $M$  “ajustado” favorece a la formulación). Su nuevo  $M$  puede depender de los índices de las restricciones, si es necesario.

### Solución

Consideremos las restricciones

$$\sum_{j=1}^n a_j x_{jt} \leq b_t, t = 1, \dots, T$$

De aquí se deduce que  $a_j x_{jt} \leq b_t$ . Por tanto, un nuevo valor para  $M$  es  $M_{jt} = \frac{b_t}{a_j}$ .

**b) (3 pts)** Es fácil ver que podemos escribir el modelo en forma totalmente equivalente como:

$$(2) \quad \begin{aligned} \min \quad & \sum_{t=1}^T \sum_{j=1}^n \{c_{jt}x_{jt} + h_{jt}I_{jt}\} + \sum_{t=1}^T g_t z_t \\ \text{s.t.} \quad & I_{jt} = I_{j,t-1} + x_{jt} - d_{jt}, t = 1, \dots, T; j = 1, \dots, n \\ & \sum_{j=1}^n a_j x_{jt} \leq z_t b_t, t = 1, \dots, T \\ & x_{jt} \geq 0, I_{jt} \geq 0, z_t \in \{0, 1\}, t = 1, \dots, T; j = 1, \dots, n \end{aligned}$$

Explique qué ventajas o desventajas puede tener la formulación (2) con respecto a la formulación (1), desde el punto de vista de la facilidad o dificultad para resolver el problema. Justifique con precisión.

### Solución

Una de las ventajas, es que en la segunda formulación uno tiene menos restricciones, por lo que en términos de uso de memoria, uno puede suponer que este es menor. En cuanto a las desventajas, es que si por ejemplo uno utiliza algún algoritmo de planos cortantes, en la función objetivo se van a tener menos términos, por lo que los cortes obtenidos pueden ser más débiles. Desde el punto de vista de la “fortaleza” de las dos formulaciones, podemos hacer el siguiente análisis, siempre pensando en la relajación lineal. Alguna de las restricciones  $x_{jt} \leq M z_t$  se deberá satisfacer con igualdad, digamos la  $(t', j')$ , entonces se tendrá que  $\frac{x_{j't'}}{M} = z_{t'}$ . Si usamos el valor de  $M$  propuesto en la parte anterior, tenemos que

$$z_{t'} = \frac{a_j x_{j't'}}{b_{t'}}$$

En la segunda formulación, se tendrá que

$$z_{t'} = \frac{1}{b_{t'}} \sum_{j=1}^n a_j x_{jt}$$

Esto indica que, potencialmente, el valor (relajado) de  $z_t$  puede ser más grande que en la primera formulación. Es decir, podría haber menos fraccionamiento de parte de las variables  $z$  y eso puede favorecer la resolución del Branch and Bound.

**c) (4 pts)** Piense en lo siguiente: si estamos ya en un tiempo  $t$  específico y la demanda para los periodos anteriores ya está satisfecha, ¿cuánto es la capacidad de producción que se necesita para terminar el plan? Utilice lo anterior para construir algún “trigger” que pueda ser agregado a la formulación (1) para hacerla “más fuerte”. Justifique con precisión.

### Solución

Suponiendo que estamos parados en un período  $t$  y toda la demanda hasta antes ya fue satisfecha (tal como obliga el modelo), la cantidad necesaria a producir para un período en específico va a estar dado por  $\max\{d_{jt} - I_{j,t-1}, 0\}$  y por tanto, al multiplicar eso por  $a_j$  obtenemos las cantidades de horas para producir en ese período. Se define una variable auxiliar, que indica la cantidad de horas de producción necesarias para lo que resta del período  $t$  hasta un período  $\tau$  específico (que se define arbitrariamente, mientras sea mayor a  $t$ , puede ser  $T$ , incluso):

$$H_{t\tau} = \sum_{j=1}^n \sum_{t'=t}^{\tau} a_{js} \max\{d_{jt} - I_{j,t-1}, 0\}$$

Luego, habría que forzar que exista una cantidad mínima de trabajo a realizar en una ventana de tiempo determinada, para garantizar que se puede elaborar a lo menos la cantidad de productos que se necesitan, lo cual se puede hacer con

$$\sum_{t'=t}^{\tau} z_{t'} b_{t'} \geq H_{t\tau} \quad \forall t, \forall \tau > t$$

**Pregunta 3 (10 pts):**

En esta pregunta deberán leer el siguiente artículo, que está disponible junto con este enunciado: *JD.com Improves Delivery Networks by a Multiperiod Facility Location Model*, por Ningxuan Kang, Hao Shen, b, Ye Xu, publicado en el *INFORMS Journal on Applied Analytics*, vol. 52, No. 2, marzo-abril de 2022. **El contenido de esto y lo que usted rescate será evaluado en el examen.**

a) (5 pts) Deben leer el artículo y preparar un resumen de máximo una página.

**Solución**

El paper describe una implementación de solución por parte de JD.com, que corresponde a la empresa de e-commerce más grande del tipo business-to-customer en China, para poder implementar un modelo de optimización que les permita hacer planes anuales de las estaciones de delivery que deben tener, de manera de minimizar los costos operacionales. Para lo anterior, adaptaron un modelo multiperíodo de facility location a la situación a la que se enfrenta la empresa. Dado el tamaño del modelo y la complejidad inherente de este es que desarrollaron diversas estrategias de acelerar y hacer factible la resolución del modelo en un tiempo acotado, por ejemplo con reformulación de restricciones, añadir desigualdades para fortalecer la formulación, warm-starts y la utilización de heurísticas.

b) (5 pts) Analice y reflexione sobre las conexiones de las metodologías mostradas en el artículo, para lo solución de problema, con los temas que se han estudiando en el curso.

**Solución**

En el paper se puede observar como tienen una situación a la que se enfrentan, y antes de partir de cero, buscan problemas similares al suyo y logran encontrar uno relativamente parecido. De ahí con ese problema, lo toman como base y modifican de acuerdo a sus necesidades. En una primera pasada, logran observar que el modelo es muy grande y difícil de resolver, por lo que empiezan a investigar y a aplicar de a poco distintas técnicas de resolución y fortalecimiento de la formulación con la que están trabajando. Tiene mucha relación con lo que se ve en el curso, que uno dependiendo del problema y según a lo que se va enfrentando, va eligiendo sobre que herramientas utilizar para poder resolver el problema al que nos enfrentamos. Ocupan en específico heurísticas, y fortalecimiento de la formulación mediante restricción, añadir desigualdades válidas, entre otros, cosas que se ven en el curso.

**Pregunta 4 (10 pts):**

En este problema abordaremos un caso particular de manejo de la diferenciación de la solución de un problema de optimización, en función de los parámetros del problema y cómo usar eso para construir un gradiente que pueda usarse para entrenar un algoritmo de ML en el esquema de Decision Focused Learning que se revisó en clases.

Más en específico, consideraremos un problema convexo pero no restringido, mín  $f(x, c)$ , donde  $f : \mathbf{R}^n \rightarrow \mathbf{R}$  es convexa y dos veces continuamente diferenciable. Aquí,  $c$  es un vector de parámetros del modelo. Sea  $V(c) = \operatorname{argmin}_{x \in \mathbf{R}^n} f(x, c)$  la función que define la solución óptima, como función de los parámetros  $c$ .

a) (4 pts) Muestre que

$$\frac{dV(c)}{dc} = - \frac{\frac{\partial^2 f(V(c), c)}{\partial x \partial c}}{\frac{\partial^2 f(V(c), c)}{\partial^2 x}}$$

Indicación: Use el hecho que, por optimalidad de primer orden,

$$\frac{d}{dx} f(V(c), c) = 0$$

y derive esta expresión usando derivación implícita.

### Solución

Sea

$$g(c) = \frac{\partial f}{\partial x}(V(c), c)$$

Se tiene

$$\begin{aligned} \frac{\partial g}{\partial c} &= \frac{\partial^2 f}{\partial^2 x}(V(c), c) \cdot \frac{dV}{dc} + \frac{\partial^2 f}{\partial x \partial c}(V(c), c) = 0 \\ &= \frac{dV}{dc} = \frac{-\frac{\partial^2 f(V(c), c)}{\partial x \partial c}}{\frac{\partial^2 f(V(c), c)}{\partial^2 x}} \end{aligned}$$

en donde  $\frac{\partial^2 f}{\partial c \partial x}$  se reemplaza por  $\frac{\partial^2 f}{\partial x \partial c}$  ya que  $f$  es dos veces continuamente diferenciable.

**b) (6 pts)** Suponga que el problema concreto que enfrentamos es:

$$P) \quad \min_{x \in \mathbf{R}^n} \frac{1}{2} x^T Q(c) x + b(c)^T x$$

donde  $c \in \mathbf{R}^p$  es el vector de parámetros del problema. Acá,  $Q(c)$  y  $b(c)$  vienen dados por

$$Q(c) = A_0 + \sum_{i=1}^p c_i A_i, \quad b(c) = d_0 + \sum_{i=1}^p c_i d_i$$

donde los  $A_i$  son matrices simétricas y definidas positivas. Asumiremos que los  $c$  son tales que garantizan que  $Q(c)$  sea siempre simétrica y definida positiva. De este modo, el problema P) cumple los supuestos que hemos establecido.

Suponiendo que queremos aplicar un Método de gradiente para resolver el problema de aprendizaje, tal como se mostró en clases, desarrolle una expresión para el gradiente del problema de ajuste (el que busca encontrar los mejores parámetros  $\omega$ ).

### Solución

Acá nos basamos en lo que indicamos en clases y en el desarrollo más detallado que está en el artículo de Mandi et al., Decision Focused Learning, Journal of AI Research, 2024. Ahí se presenta el problema que se mostró en clases:

$$\begin{aligned} \min_w \quad & \mathcal{L}(x^*(\hat{c}), c) = \frac{1}{N} \sum_{i=1}^N \|x^*(\hat{c}_i) - x^*(c_i)\|_2^2 \\ \text{s.a.} \quad & \hat{c}_i = m_w(z_i) \quad i = 1, \dots, N \\ & x^*(\hat{c}_i) = \operatorname{argmin}\{f(x, \hat{c}_i) : g(x, \hat{c}_i) \leq 0, x \text{ entero}\} \quad i = 1, \dots, N \end{aligned}$$

También en el mismo artículo se menciona que, para aplicar un método “tipo gradiente” se debe considerar la derivada de la función de pérdida en términos de los parámetros del modelo predictor, que son los  $\omega$ . Esta derivada es (aquí cambiamos ligeramente la notación de las derivadas, respecto al paper):

$$\frac{\partial \mathcal{L}(x^*(\hat{c}), c)}{\partial \omega} = \frac{\partial \mathcal{L}(x^*(\hat{c}), c)}{\partial x^*(\hat{c})} \times \frac{\partial x^*(\hat{c})}{\partial \hat{c}} \times \frac{\partial \hat{c}}{\partial \omega}$$

Ahora, tenemos que calcular cada una de estas derivadas parciales para los elementos del problema, pero con la función específica que nos dan en el enunciado. La función es

$$f(x) = \frac{1}{2} x^T Q(c) x + b(c)^T x$$

Primero, notemos que la solución del mínimo de  $f(x)$  es

$$x^*(c) = -(Q(c)^{-1})b(c)$$

ahora veamos los elementos del gradiente. Hay que notar que estamos haciendo algo de uso abusivo de la notación acá ya que ponemos “derivadas” con objetos que son funciones reales, otras vectoriales y los resultados son, en unos casos, matrices, en otros vectores. Ahora especificaremos mejor todo esto. Para fijar ideas, asumiremos que el vector  $\omega$  tiene  $p$  componentes. Entonces,  $\frac{\partial \mathcal{L}(x^*(\hat{c}), c)}{\partial \omega}$  es un vector gradiente con  $p$  componentes.

Tomemos el primer término de la expresión del gradiente,  $\frac{\partial \mathcal{L}(x^*(\hat{c}), c)}{\partial x^*(\hat{c})}$ .  $\mathcal{L}$  es una función real que tenemos que visualizarla como función de  $x^*(\hat{c})$ , pero acá hay que notar que  $\hat{c}$  no es un único vector, hay uno para cada caso de los  $c_i$ .

Más en específico, siguiendo la notación del artículo “Decision-Focused Learning: Foundations, State of the Art, Benchmark and Future Opportunities”, de Mandi et al., tenemos que  $c \in \mathbb{R}^p$  (según el enunciado), y hay  $N$  sets the “features” o características disponibles para el entrenamiento. Entonces, tenemos que

$$x^*(\hat{c}) = \begin{bmatrix} x^*(\hat{c}_1) \\ x^*(\hat{c}_2) \\ \vdots \\ x^*(\hat{c}_i) \\ \vdots \\ x^*(\hat{c}_N) \end{bmatrix} \in \mathbb{R}^{p \times N}$$

Entonces, el término  $\frac{\partial \mathcal{L}(x^*(\hat{c}), c)}{\partial x^*(\hat{c})}$  nos conviene visualizarlo como un vector en  $\mathbb{R}^{m \times N}$  por bloques de componentes, donde cada componente es el gradiente respecto a cada  $\hat{c}_i$ . Es decir,

$$\nabla_{x^*(\hat{c})} \mathcal{L}(x^*(\hat{c})) = \begin{bmatrix} \nabla_{x^*(\hat{c}_1)} \mathcal{L}(x^*(\hat{c})) \\ \nabla_{x^*(\hat{c}_2)} \mathcal{L}(x^*(\hat{c})) \\ \vdots \\ \nabla_{x^*(\hat{c}_i)} \mathcal{L}(x^*(\hat{c})) \\ \vdots \\ \nabla_{x^*(\hat{c}_N)} \mathcal{L}(x^*(\hat{c})) \end{bmatrix}$$

Entonces, podemos obtener una expresión para cada término a partir de la formulación. tenemos:

$$\nabla_{x^*(\hat{c}_i)} \mathcal{L}(x^*(\hat{c})) = \frac{2}{N} (x^*(\hat{c}_i) - x^*(c_i))$$

Ahora analizamos el término central,  $\frac{\partial x^*(\hat{c})}{\partial \hat{c}}$ . Como  $x^*(\hat{c})$  es una función vectorial, esta derivada es, en realidad, un Jacobiano, una matriz. Cada bloque fila de esa matriz es el Jacobiano de cada término  $x^*(\hat{c}_i)$ . Tenemos que  $x^*(\hat{c}_i) = -(Q(\hat{c}_i)^{-1})b(\hat{c}_i)$ . Entonces:

$$\frac{\partial x^*(c_i)}{\partial \hat{c}_i} = - \left( \frac{\partial}{\partial \hat{c}_i} Q^{-1}(\hat{c}_i) \right) b(\hat{c}_i) - Q^{-1}(\hat{c}_i) \frac{\partial b}{\partial \hat{c}_i} \in \mathbb{R}^{n \times p}$$

Para la deriva de la inversa de una matriz como función, podemos recurrir a las expresiones que están en la literatura, o buscar en la web, por ejemplo, acá hay una explicación: <https://planetmath.org/derivativeofinversematrix>. Entonces, tenemos:

$$\left( \frac{\partial}{\partial \hat{c}_i} Q^{-1}(\hat{c}_i) \right) = Q^{-1}(\hat{c}_i) \left( \frac{\partial}{\partial \hat{c}_i} Q(\hat{c}_i) \right) Q^{-1}(\hat{c}_i)$$

Finalmente, hemos llegado al término central, que sí se puede calcular en función de las expresiones para  $Q(c)$ . Lo mismo podemos hacer con el término  $b(c)$ . Recordemos que:

$$Q(c) = A_0 + \sum_{i=1}^p c_i A_i, \quad b(c) = d_0 + \sum_{i=1}^p c_i d_i$$

Luego,

$$\frac{\partial}{\partial \hat{c}_i} Q(\hat{c}_i) = A_i$$

y

$$\frac{\partial b}{\partial \hat{c}_i} = d_i$$

Combinando todos los términos, tenemos la expresión que se busca. Respecto al último término,  $\frac{\partial \hat{c}}{\partial \omega}$ , aplicamos lo que se dice en el artículo, en el sentido de que depende específicamente del modelo de Machine Learning que se esté usando y es posible obtener las derivadas por diferenciación numérica aproximada. En todo caso, pueden ver el ejemplo 2.7.1 en los apuntes del curso, en el que se desarrolla explícitamente las derivadas del modelo de cálculo para una red neuronal simple (y es bastante enredado).

Para las preguntas 5, 6 y 7 usaremos el problema 8 de la Tarea 2, lo repetimos por claridad:

Una empresa del sector agropecuario necesita planificar sus actividades de cosecha y procesamiento de frutas sobre un horizonte de  $T$  períodos de tiempo (días, para fijar ideas). Existen  $n$  parcelas que pueden ser cosechadas, y la disponibilidad de fruta en la parcela  $j$  es  $L_j$  (kilos). Hay un costo por kilo cosechado en cada período,  $c_{jt}$  y también un costo fijo cada vez que se decide cosechar una parcela,  $f_{jt}$ . Además, hay personal empleado en la cosecha y  $\alpha_{jt}$  es el requerimiento unitario de mano de obra (en horas) en la parcela  $j$  en el período  $t$ , y el total disponible en el período  $t$  es igual a  $B_t$ . Además, una parcela sólo se puede cosechar una vez en todo el horizonte, aunque sea parcialmente. Una vez cosechada la fruta, debe ser procesada en una de  $m$  plantas de procesamiento, para lo cual la fruta cosechada en un día es acumulada y enviada a alguna de las plantas (todo está cerca, así que el transporte lo consideraremos despreciable). La planta de procesamiento  $i$  puede recibir un máximo de  $K_i$  kilos sobre todo el horizonte de tiempo. La empresa debe planificar la producción de modo tal que se cumpla con una demanda mensual  $d_t$  por fruta procesada. En caso de no poder cumplir completamente esa demanda, la empresa debe comprar producto procesado en el mercado “spot”, lo que tiene un costo  $\beta_t$  por kilo. El costo de procesamiento es  $e_{it}$  para la planta  $i$  en el día  $t$ . La empresa ha construido el siguiente modelo de optimización para encontrar la planificación que minimiza los costos incurridos, el que usa las siguientes variables:

$x_{jt}$ : kilos cosechados en la parcela  $j$  el día  $t$ .

$y_{jt}$ : vale 1 si se cosecha la parcela  $j$  en  $t$ , 0 en caso contrario.

$z_{it}$ : kilos procesados en la planta  $i$  en  $t$ .

$v_t$ : kilos de fruta procesada que deben comprarse externamente para cubrir la demanda.

El modelo es:

$$\begin{aligned}
& \min \sum_{t=1}^T \left\{ \sum_{j=1}^n c_{jt} x_{jt} + \sum_{j=1}^n f_{jt} y_{jt} + \sum_{i=1}^m e_{it} z_{it} + \beta_t v_t \right\} \\
& \text{s.a.} \\
& \sum_{j=1}^n \alpha_{jt} x_{jt} \leq B_t, \quad t = 1, \dots, T \quad (1) \\
& x_{jt} \leq L_j y_{jt}, \quad j = 1, \dots, n; t = 1, \dots, T \quad (2) \\
& \sum_{t=1}^T y_{jt} \leq 1, \quad j = 1, \dots, n \quad (3) \\
& \sum_{j=1}^n x_{jt} = \sum_{i=1}^m z_{it}, \quad t = 1, \dots, T \quad (4) \\
& \sum_{i=1}^m z_{it} \geq d_t - v_t, \quad t = 1, \dots, T \quad (5) \\
& \sum_{t=1}^T z_{it} \leq K_i, \quad i = 1, \dots, m \quad (6) \\
& x_{jt} \geq 0, z_{it} \geq 0, y_{jt} \in \{0, 1\}, v_t \geq 0, j = 1, \dots, n; t = 1, \dots, T; i = 1, \dots, m \quad (7)
\end{aligned}$$

### Pregunta 5 (8 pts):

Este problema fue abordado en la I2 mediante Relajación Lagrangiana y ya sabemos qué habría que hacer. Acá vamos a ver si una IA es capaz de dar una respuesta razonable. Para esto,

- a) (2 pts) Prepare una consulta para un chat de IA, que puede ser ChatGPT o Copilot, preguntando cuál es la mejor forma de hacer Relajación Lagrangiana a este problema. Reporte las respuestas del chat y comparta en su solución un enlace al diálogo completo.

### Solución

ChatGPT-5 entrega la siguiente respuesta

### Relajación Lagrangeana

Observamos que la restricción

$$\sum_{j=1}^n x_{jt} = \sum_{i=1}^m z_{it}, \quad t = 1, \dots, T \quad (4)$$

acopla las decisiones de cosecha con las de procesamiento. Por lo tanto, una relajación natural es relajar esta restricción mediante multiplicadores lagrangeanos  $\lambda_t \in \mathbb{R}$  (irrestringidos, pues la restricción es de igualdad).

El problema original es

$$\min_{x,y,z,v} \sum_{t=1}^T \left( \sum_{j=1}^n c_{jt} x_{jt} + \sum_{j=1}^n f_{jt} y_{jt} + \sum_{i=1}^m e_{it} z_{it} + \beta_t v_t \right) \quad \text{s.a. (1), (2), (3), (4), (5), (6), (7)}.$$

Relajando (4), el Lagrangiano queda:

$$\mathcal{L}(x, y, z, v; \lambda) = \sum_{t=1}^T \left[ \sum_{j=1}^n (c_{jt} + \lambda_t) x_{jt} + \sum_{j=1}^n f_{jt} y_{jt} + \sum_{i=1}^m (e_{it} - \lambda_t) z_{it} + \beta_t v_t \right].$$

sujeto solamente a las restricciones:

$$(1), (2), (3), (5), (6), (7).$$

### Descomposición del Lagrangiano

El problema se separa en dos subproblemas independientes:

### Subproblema de Cosecha

$$\min_{x,y} \sum_{t=1}^T \sum_{j=1}^n (c_{jt} + \lambda_t) x_{jt} + \sum_{t=1}^T \sum_{j=1}^n f_{jt} y_{jt}$$

s.a.

$$\sum_{j=1}^n \alpha_{jt} x_{jt} \leq B_t \quad (1)$$

$$x_{jt} \leq L_j y_{jt} \quad \forall j, t \quad (2)$$

$$\sum_{t=1}^T y_{jt} \leq 1 \quad \forall j \quad (3)$$

$$x_{jt} \geq 0, \quad y_{jt} \in \{0, 1\}.$$

### Subproblema de Procesamiento

$$\min_{z,v} \sum_{t=1}^T \sum_{i=1}^m (e_{it} - \lambda_t) z_{it} + \sum_{t=1}^T \beta_t v_t$$

s.a.

$$\sum_{i=1}^m z_{it} \geq d_t - v_t \quad \forall t \quad (5)$$

$$\sum_{t=1}^T z_{it} \leq K_i \quad \forall i \quad (6)$$

$$z_{it} \geq 0, \quad v_t \geq 0.$$

### Dual Lagrangeano

Definimos la función:

$$\theta(\lambda) = \min_{x,y,z,v \text{ factibles sin (4)}} \mathcal{L}(x, y, z, v; \lambda) = \theta^{\text{cosecha}}(\lambda) + \theta^{\text{proc}}(\lambda).$$

y el problema dual lagrangeano será:

$$\max_{\lambda \in \mathbb{R}^T} \theta(\lambda).$$

El subgradiente para cada  $t$  está dado por:

$$g_t = \sum_{j=1}^n x_{jt}^* - \sum_{i=1}^m z_{it}^*,$$

donde  $(x^*, y^*, z^*, v^*)$  es la solución óptima de los subproblemas para el vector  $\lambda$  actual.

**b) (2 pts)** Pídale al chat evaluar si acaso la cota dual que se obtendría de la o las relajaciones que le proponga son buenas o no.

### Solución

## ¿La cota dual obtenida es buena o no?

En esta relajación solo se relaja la restricción de balance entre cosecha y procesamiento:

$$\sum_{j=1}^n x_{jt} = \sum_{i=1}^m z_{it}, \quad t = 1, \dots, T.$$

Esta restricción es justamente la que *acopla* las decisiones de cosecha con las de procesamiento. El resto de las restricciones importantes se mantiene “duras”, esto es:

- la capacidad de mano de obra en cada período: (1),
- que cada parcela se coseche a lo más una vez en todo el horizonte: (3),
- las capacidades máximas de procesamiento en planta: (6),
- cumplimiento de la demanda mediante producción más compras externas: (5).

Esto implica que el único “error” que podría cometer una solución del problema relajado es un *desbalance* entre lo cosechado y lo procesado en un período dado. Dicho desbalance se penaliza a través de los multiplicadores  $\lambda_t$ , por lo que en general la cota dual que se obtiene suele ser **razonablemente buena**, es decir, cercana al óptimo primal.

En particular:

- Es **mucho mejor** que relajar restricciones como (1), (3) o (6), pues eso permitiría usar trabajo ilimitado, cosechar varias veces una parcela, o procesar más que la capacidad de planta, deteriorando la cota dual.
- La relajación mantiene la binariedad de  $y_{jt}$ , por lo que suele entregar una cota **mejor que la relajación lineal continua** típica (donde se relaja la integralidad).
- Al descomponer el problema en subproblemas de cosecha y de procesamiento, se obtiene una estructura útil para heurísticas tipo *lagrangeano + subgradientes*.

Sin embargo, puede existir brecha de dualidad (no siempre es cota exacta). Esto se debe a:

- la presencia de variables binarias  $y_{jt}$ ,
- el hecho de que el balance entre cosecha y procesamiento solo se aplica mediante penalizaciones lagrangeanas.

**Conclusión:** La cota dual resultante de esta relajación es considerada **buena** en la práctica: es fuerte, tiene interpretación natural y permite construir heurísticas efectivas. No obstante, puede presentar brecha y no necesariamente coincide con el óptimo primal.

**b) (4 pts)** Evalúe en forma crítica la respuesta entregada por el Chat. ¿Son correctas? ¿Hay ambigüedades en las respuestas?

### Solución

Las respuestas del Chat tienen bastante consistencia, es capaz de identificar las restricciones complicantes y separar los problemas de tal forma que puedan ser paralelizables y también es capaz de indicar que tan buena es una cierta cota y el porque tomó la decisión de relajar una cierta restricción y no otra.

### Pregunta 6 (10 pts):

El problema ha sido abordado con distintas técnicas de descomposición y también computacionalmente usando Benders, en la Tarea 2. Acá vamos a hacerlo mediante una heurística de tipo Simulated Annealing.

a) (3 pts) Elija variables que formarán su espacio de búsqueda. Justifique su selección.

**Solución**

El espacio de búsqueda se hará sobre las variables  $y$ . Así el espacio de búsqueda es

$$Z = \left\{ y \in \{0, 1\}^{|n| \times |T|} : \sum_{t=1}^T y_{jt} \leq 1 \quad \forall j \right\}$$

b) (3 pts) Defina la función objetivo que usará y explique cómo se evalúa y la complejidad o dificultad de esto.

**Solución**

Se definen las funciones

$$g(y) = \min \sum_{t=1}^T \left\{ \sum_{j=1}^n c_{jt} x_{jt} + \sum_{i=1}^m e_{it} z_{it} + \beta_t v_t \right\}$$

s.a. (1), (2), (4), (5), (6), (7)

y la función  $f(\hat{y}) = \sum_{t=1}^T \sum_{j=1}^n f_{jt} \hat{y}_{jt} + g(y)$ . Evaluar la función  $f(\hat{y})$  sólo involucra resolver un problema de programación lineal por cada ocasión que se altere la vecindad.

c) (4 pts) Ahora defina un mecanismo para seleccionar soluciones vecinas. Sea claro en todos sus pasos.

Para la selección de soluciones vecinas, se podría por ejemplo:

1. Se selecciona aleatoriamente una parcela  $j$
2. Se verifica el estado actual de la parcela  $j$  y se aplica una de las siguientes operaciones:
  - Caso 1: La parcela ya está programada para cosechar ( $y_{jt} = 1$ ).
    - Cambiar día de cosecha: Seleccionar un nuevo día  $t' \neq t$  aleatoriamente. Hacer  $y_{jt} = 0$  y  $y_{jt'} = 1$ .
    - Eliminar cosecha: Decidir no cosechar la parcela. Hacer  $y_{jt} = 0$ .
  - Caso 2: La parcela no se cosecha actualmente ( $\sum_t y_{jt} = 0$ ).
    - Agregar cosecha: Elegir un día aleatorio  $t$  y establecer  $y_{jt} = 1$ .

**Pregunta 7 (10 pts):**

Considere un problema de optimización lineal cónica de la forma:

$$P) \quad \begin{array}{ll} \min & c^T x \\ \text{s.a.} & Ax = b \\ & x \in K \end{array}$$

donde  $K$  es un cono convexo con interior no vacío,  $A \in \mathbf{R}^{m \times n}$ ,  $b \in \mathbf{R}^m$ ,  $c \in \mathbf{R}^n$ .

a) (6 pts) Usando los conceptos de dualidad lagrangiana, demuestre que el dual lagrangiano del problema P) está dado por

$$D) \quad \begin{array}{ll} \max & b^T u \\ \text{s.a.} & A^T u + s = c \\ & s \in K^* \end{array}$$

donde  $K^*$  es el cono “dual” a  $K$  y está dado por:

$$K^* = \{y \in \mathbf{R}^n : y^T x \geq 0, \forall x \in K\}$$

(Ind: escriba el lagrangiano de la manera obvia y siga un argumento similar al usado en clases cuando mostramos el dual lagrangiano de programación lineal).

### Solución

Se define la función Lagrangeana como

$$L(x, \lambda) = c^T x + \sum_{i=1}^m \lambda_i (b_i - \alpha_i^T x)$$

entonces el problema dual es

$$\max_{\lambda \in \mathbf{R}} \min_{x \in K} c^T x + \sum_{i=1}^m \lambda_i (b_i - \alpha_i^T x)$$

se define la función dual como

$$\begin{aligned} \theta(\lambda) &= \min_{x \in K} c^T x + \sum_{i=1}^m \lambda_i (b_i - \alpha_i^T x) \\ &= \min_{x \in K} \sum_{j=1}^n c_j x_j + \sum_{i=1}^m \lambda_i (b_i - \alpha_i^T x) \\ &= b^T \lambda + \min_{x \in K} \left\{ \sum_{j=1}^n x_j \left( c_j - \sum_{i=1}^m \alpha_{ij} \lambda_i \right) \right\} \end{aligned}$$

Ahora bien, analicemos por separado la expresión

$$\min_{x \in K} \left\{ \sum_{j=1}^n x_j \left( c_j - \sum_{i=1}^m \alpha_{ij} \lambda_i \right) \right\}$$

Notemos que la expresión es, en realidad, igual a

$$x^T (c - A^T \lambda)$$

Supongamos que el  $\lambda$  que estamos considerando es tal que, para algún  $x$  se tiene  $x^T (c - A^T \lambda) < 0$ . Entonces, podemos tomar cualquier múltiplo  $tx$ , con  $t > 0$  y  $t$  muy grande, y como  $x \in K$ , que es un cono,  $tx$  también estará en  $K$  y el valor de  $tx^T (c - A^T \lambda)$  puede ser arbitrariamente negativo. En ese caso, se tendría  $\theta(\lambda) = -\infty$ .

Entonces, tenemos que excluir esos valores de  $\lambda$  y eso lo podemos hacer pidiendo que cualquier  $\lambda$  cumpla con  $x^T (c - A^T \lambda) \geq 0$ , para cualquier  $x \in K$ . Lo anterior significa que  $(c - A^T \lambda) \in K^*$ . Luego, el problema dual es:

$$\begin{aligned} &\max b^T \lambda \\ &s.a. \ c - A^T \lambda \in K^* \end{aligned}$$

Si ponemos  $s = c - A^T \lambda$ , podemos reescribir el problema como

$$\begin{aligned} &\max b^T \lambda \\ &s.a. \ c - A^T \lambda \in K^* \end{aligned}$$

b) (4 pts.) Considere ahora el siguiente problema de optimización:

$$P) \quad \begin{array}{ll} \text{mín} & c^T x \\ \text{s.a.} & (x - z)^T Q(x - z) \leq r \\ & Ax = b \\ & x \geq 0 \end{array}$$

donde  $Q$  es simétrica y definida positiva,  $A \in \mathbf{R}^{m \times n}$ ,  $b \in \mathbf{R}^m$ ,  $c \in \mathbf{R}^n$ ,  $z \in \mathbf{R}^n$  y  $r > 0$ . Reescriba este problema en formato línea cónica y determine su dual. Para esto último, debería usar lo de la parte a) pero con las generalizaciones naturales de los distintos formatos de duales.

### Solución

Como  $Q$  es simétrica y definida positiva, es válido asumir que existe una matriz  $M$  tal que  $Q = M^T M$ , por lo que la restricción primera se puede escribir como  $(x - z)^T M^T M(x - z) = \|M(x - z)\|_2^2$ . Así el problema queda

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a.} & \|M(x - z)\|_2 \leq \sqrt{r} \\ & Ax = b \\ & x \geq 0 \end{array}$$

Reescribiendo

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a.} & \|v\|_2 \leq \sqrt{r} \\ & Ax = b \\ & v = M(x - z) \\ & x \geq 0 \end{array}$$

que es equivalente a

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a} & Ax = b \\ & v = M(x - z) \\ & (v, \sqrt{r}) \in Q^{n+1} \\ & x \geq 0 \end{array}$$

Para construir el dual hay que pensar en forma intuitiva y ver cómo se generaliza la construcción de la parte a). Es mejor reescribir el problema de la siguiente forma:

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a} & Ax = b \\ & -Mx + v = -Mz \\ & t = \sqrt{r} \\ & (v, t) \in Q^{n+1} \\ & x \geq 0 \end{array} \quad \begin{array}{l} (1) \\ (2) \\ (3) \end{array}$$

Definamos variables duales  $\pi$  para las restricciones (1), variables duales  $w$  para las restricciones (2), y variable dual  $s$  para la restricción (3). Entonces, el dual es:

$$\begin{aligned} \text{máx} \quad & b^T \pi - (Mz)^T w + s\sqrt{r} \\ \text{s.a.} \quad & A^T \pi - M^T w \leq c \\ & (w, s) \in (Q^{n+1})^* \end{aligned}$$

Notar que las  $x$  están restringidas al cono  $\geq 0$ , luego “la columna” de las  $x$  al construir el dual debe quedar restringida a dual  $\geq 0$ , que es lo mismo. Pero, las  $v$  están restringidas al cono, así que  $(w, s)$  queda restringida al cono dual.

Ahora, hay que saber cuál es el cono dual a  $Q^{n+1}$ . Esto no es muy difícil de deducir en forma geométrica a partir de la forma del cono de segundo orden. Se tiene que  $(Q^{n+1})^* = Q^{n+1}$  (se dice que el cono de segundo orden es “auto-dual” o “self-dual”, en inglés).

Entonces, el problema dual es:

$$\begin{aligned} \text{máx} \quad & b^T \pi - (Mz)^T w + s\sqrt{r} \\ \text{s.a.} \quad & A^T \pi - M^T w \leq c \\ & (w, s) \in (Q^{n+1})^* \end{aligned}$$

Para las siguientes preguntas, usaremos el problema de planificación de producción que se describe a continuación. Este es una variante del que está, como ejemplo, en el capítulo 7 de los apuntes de clases.

Una empresa fabrica  $J$  productos diferentes, los cuales tiene demandas sobre  $T$  periodos de tiempo. La demanda por el ítem  $j$  en el periodo  $t$  es  $d_{jt}$ . La empresa tiene  $K$  fábricas diferentes que pueden fabricar los productos, pero hay un costo fijo si se asigna la producción de un producto a una fábrica en algún periodo de tiempo. En cada periodo, sólo una de las fábricas producirá de un mismo producto. Además, hay costo variables de producción y hay capacidades de producción. Adicionalmente, el uso de alguna de las fábricas para un producto genera el uso de un recurso productivo, que se requiere en una cantidad fija (independientemente de cuánto se fabrica de los productos), y del cual hay disponibilidad limitada. Más en específico, sea  $c_{jtk}$  el costo unitario de producción para el producto  $j$  en la fábrica  $k$  en  $t$ ,  $F_{jkt}$  el costo fijo de producir el producto  $j$  en la fábrica  $k$  en  $t$ ,  $\beta_{jk}$  la cantidad del recurso escaso que se requerirá para el producto  $j$  en la fábrica  $k$ , y cuyo total disponible es  $P$ , para todo el problema. La fábrica  $k$  tiene una capacidad total de  $H_{kt}$  horas en el periodo  $t$  y producir producto  $j$  en  $k$  consume  $\alpha_{jk}$  horas. Adicionalmente, el producto se puede guardar en inventario de un periodo al siguiente, pero eso tiene un costo  $h_{jt}$ . Asumimos aquí que todo lo producido se almacena en una bodega central y los costos de transportarlo a esa bodega son despreciables.

La empresa ha postulado un modelo de optimización en el cual usa las variables  $x_{jtk}$  para indicar la cantidad del producto  $j$  a fabricar en la fábrica  $k$  en el periodo  $t$ ,  $y_{jkt}$ , una variable binaria que indica si hay producción de  $j$  en la fábrica  $k$  en  $t$  e  $I_{jt}$  como el inventario del producto  $j$  al final del periodo  $t$  (asumiremos que los inventarios iniciales,  $I_{j0}$ , son conocidos). El modelo es el siguiente:

$$\begin{aligned}
\min \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt} \right\} \\
s.a. \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
& \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} & k = 1, \dots, K; t = 1, \dots, T & (2) \\
& x_{jkt} \leq M y_{jkt} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (3) \\
& \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (4) \\
& \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk}y_{jkt} \leq P & & (5) \\
& x_{jkt} \geq 0, I_{jt} \geq 0, y_{jkt} \in \{0, 1\} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (6)
\end{aligned}$$

Las restricciones (1) son el flujo de inventarios y satisfacción de demanda (y, se entiende,  $I_{j0}$  es un dato), las (2) establecen el límite a la capacidad de producción, las (3) definen la “carga fija”, las (4) establecen que sólo una fábrica se encarga de cada producto en cada periodo, las (5) determinan que se cumpla la disponibilidad del recurso escaso, y las (6) definen la naturaleza de las variables.

#### Pregunta 8 (10 pts):

Supongamos que le indican que la cantidad de recurso escaso presenta incertidumbres, al igual que la disponibilidad de horas para funcionar. Sin embargo, se conocen bien las características de esta incertidumbre. Específicamente, se sabe que los coeficientes  $\beta_{jk}$  se pueden modelar como un comportamiento normal, con media  $\bar{\beta}_{jk}$  y desviación estándar  $\sigma_{jk}$ . Por otro lado, la disponibilidad de horas,  $H_{kt}$ , se puede modelar como normal, con media  $\bar{H}_{kt}$  y desviación estándar  $\eta_{kt}$ .

- a) (4 pts) La empresa ha decidido que le basta cumplir las restricciones afectadas por incertidumbre con probabilidad 0,95. Reescriba el problema representando las restricciones probabilísticas correspondientes cuando corresponda. Su modelo debe quedar en forma determinística equivalente.

#### Solución

$$\begin{aligned}
& \text{Prob} \left( \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jk}y_{jkt} \leq P \right) \geq 0,95 \\
& \iff \text{Prob} \left( T \leq \frac{P - \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk}y_{jkt}}{\sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2}} \right) \geq 0,95 \\
& \iff \frac{P - \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk}y_{jkt}}{\sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2}} \geq 1,65 \\
& \iff \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk}y_{jkt} + 1,65 \sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2} \leq P
\end{aligned}$$

que es la restricción “típica” que vimos en clases.

Para la otra restricción, notemos que el coeficiente con incertidumbre es el del lado derecho solamente. Se tiene

$$\begin{aligned}
& \mathbf{Prob} \left( \sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt} \right) \geq 0,95 \\
& \iff \mathbf{Prob} \left( \frac{\sum_{j=1}^J \alpha_{jk} x_{jkt} - \bar{H}_{kt}}{\eta_{kt}} \leq T \right) \geq 0,95 \\
& \iff 1 - \mathbf{Prob} \left( \frac{\sum_{j=1}^J \alpha_{jk} x_{jkt} - \bar{H}_{kt}}{\eta_{kt}} \leq T \right) \leq 1 - 0,95 = 0,05 \\
& \iff \mathbf{Prob} \left( \frac{\sum_{j=1}^J \alpha_{jk} x_{jkt} - \bar{H}_{kt}}{\eta_{kt}} > T \right) \leq 0,05
\end{aligned}$$

donde  $T$  denota una variable aleatoria  $N(0,1)$ . Ahora, acá hay que ver la cola izquierda de la distribución normal y se deduce que se tiene que cumplir:

$$\frac{\sum_{j=1}^J \alpha_{jk} x_{jkt} - \bar{H}_{kt}}{\eta_{kt}} \leq -1,64$$

Luego, la restricción determinista equivalente es:

$$\sum_{j=1}^J \alpha_{jk} x_{jkt} \leq \bar{H}_{kt} - 1,64 \times \eta_{kt}$$

Notar que lo que la restricción hace, al considerar la incertidumbre, es disminuir el lado derecho, la restricción se pone “más estricta”.

- b) (6 pts) La formulación a la que llegó en la parte a) es lineal entera cónica. Escriba el problema penalizado que deberá usarse en un algoritmo de punto interior para resolver la relajación lineal de ese problema.

### Solución:

Reescribimos acá el problema completo:

$$\begin{aligned}
\text{mín} \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt} x_{jkt} + F_{jkt} y_{jkt}\} + \sum_{j=1}^J h_{jt} I_{jt} \right\}
\end{aligned}$$

$$s.a. \quad I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} \quad j = 1, \dots, J; t = 1, \dots, T \quad (1)$$

$$\sum_{j=1}^J \alpha_{jk} x_{jkt} \leq \bar{H}_{kt} - 1,64 \times \eta_{kt} \quad k = 1, \dots, K; t = 1, \dots, T \quad (2)$$

$$x_{jkt} \leq M y_{jkt} \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (3)$$

$$\sum_{k=1}^K y_{jkt} = 1 \quad j = 1, \dots, J; t = 1, \dots, T \quad (4)$$

$$\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jkt} y_{jkt} \leq P \quad (5)$$

$$x_{jkt} \geq 0, I_{jt} \geq 0, y_{jkt} \in \{0,1\} \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \quad (6)$$

**Pregunta 9 (14 pts):**

Seguimos acá con el mismo problema de la pregunta anterior, supongamos que la empresa contrata una consultoría de ciencias de datos y con eso obtiene mucho mejores estimaciones de los parámetros inciertos mencionados en la pregunta 8, así que esa incertidumbre ya no es relevante y no se considera más.

Sin embargo, pronto se dan cuenta de que la demanda presenta incertidumbres importantes. La misma consultora les indica que  $d_{jt}$  distribuye Beta con parámetros  $\gamma_{jt} > 0$  y  $\delta_{jt} > 0$ . Adicionalmente, dada la incertidumbre, podría haber demanda que no se cumpla, así que la empresa debe pagar una cantidad  $\rho_{jt}$  por cada unidad de demanda no cumplida.

a) (3 pts) Reformule el problema para considerar el efecto de demanda no satisfecha y su costo.

**Solución**

Para lo anterior, es necesario redefinir  $I_{jt} = I_{jt}^+ - I_{jt}^-$ , donde  $I_{jt}^+, I_{jt}^- \geq 0$ . Por tanto, se reformula el modelo como

$$\begin{aligned}
 \text{mín} \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt}^+ + \sum_{j=1}^J \rho_{jt}I_{jt}^- \right\} \\
 \text{s.a.} \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
 & I_{jt} = I_{jt}^+ - I_{jt}^- & j = 1, \dots, J; t = 1, \dots, T & (2) \\
 & \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} & k = 1, \dots, K; t = 1, \dots, T & (3') \\
 & x_{jkt} \leq My_{jkt} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (4) \\
 & \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (5) \\
 & \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk}y_{jkt} + 1,65\sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2} \leq P & & (6') \\
 & x_{jkt} \geq 0, I_{jt}^+ \geq 0, I_{jt}^- \geq 0, y_{jkt} \in \{0, 1\} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (7)
 \end{aligned}$$

Vamos a definir una variable auxiliar,  $w$ , para transformar la restricción cónica. El modelo queda:

$$\begin{aligned}
 \text{mín} \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt}^+ + \sum_{j=1}^J \rho_{jt}I_{jt}^- \right\} \\
 \text{s.a.} \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
 & I_{jt} = I_{jt}^+ - I_{jt}^- & j = 1, \dots, J; t = 1, \dots, T & (2) \\
 & \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} & k = 1, \dots, K; t = 1, \dots, T & (3') \\
 & x_{jkt} \leq My_{jkt} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (4) \\
 & \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (5) \\
 & P - \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk}y_{jkt} = (1,65)w & & (6'') \\
 & \sqrt{\sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2} \leq w & & (6''') \\
 & x_{jkt} \geq 0, I_{jt}^+ \geq 0, I_{jt}^- \geq 0, y_{jkt} \in \{0, 1\} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (7)
 \end{aligned}$$

Y de este problema, vamos a resolver la relajación lineal:

$$\begin{aligned}
\min \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt}^+ + \sum_{j=1}^J \rho_{jt}I_{jt}^- \right\} \\
s.a. \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
& I_{jt} = I_{jt}^+ - I_{jt}^- & j = 1, \dots, J; t = 1, \dots, T & (2) \\
& \sum_{j=1}^J \alpha_{jk}x_{jkt} \leq H_{kt} & k = 1, \dots, K; t = 1, \dots, T & (3') \\
& x_{jkt} \leq My_{jkt} & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (4) \\
& \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (5) \\
& P - \sum_{k=1}^k \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk}y_{jkt} = (1,65)w & & (6'') \\
& \sqrt{\sum_{k=1}^k \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2} \leq w & & (6''') \\
& x_{jkt} \geq 0, I_{jt}^+ \geq 0, I_{jt}^- \geq 0, 0 \leq y_{jkt} \leq 1 & j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T & (7)
\end{aligned}$$

Vamos a plantear la función de barrera. Todas las restricciones que involucren desigualdades o conos deben llevar barrera. Estas son las (3'), (4), (6'') y las desigualdades de la naturaleza de las variables. La barrera es:

$$\begin{aligned}
\Phi(x, y, I^+, I^-, w) = & - \sum_{t=1}^T \sum_{k=1}^K \log(H_{kt} - \sum_{j=1}^J \alpha_{jk}x_{jkt}) - \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^K \log(My_{jkt} - x_{jkt}) \\
& - \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^K (\log(x_{jkt}) + \log(y_{jkt}) + \log(1 - y_{jkt})) \\
& - \sum_{t=1}^T \sum_{j=1}^J (\log(I_{jt}^+) + \log(I_{jt}^-)) \\
& - \log(w^2 - \sum_{k=1}^k \sum_{j=1}^J \sum_{t=1}^T \sigma_{jk}^2 y_{jkt}^2)
\end{aligned}$$

Entonces, el problema penalizado es:

$$\begin{aligned}
\min \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J \{c_{jkt}x_{jkt} + F_{jkt}y_{jkt}\} + \sum_{j=1}^J h_{jt}I_{jt}^+ + \sum_{j=1}^J \rho_{jt}I_{jt}^- \right\} + \mu\Phi(x, y, I^+, I^-, w) \\
s.a. \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} & j = 1, \dots, J; t = 1, \dots, T & (1) \\
& I_{jt} = I_{jt}^+ - I_{jt}^- & j = 1, \dots, J; t = 1, \dots, T & (2) \\
& \sum_{k=1}^K y_{jkt} = 1 & j = 1, \dots, J; t = 1, \dots, T & (5) \\
& P - \sum_{k=1}^k \sum_{j=1}^J \sum_{t=1}^T \bar{\beta}_{jk}y_{jkt} = (1,65)w & & (6'')
\end{aligned}$$

**b) (4 pts)** Modele el problema bajo incertidumbre como un problema de 2 etapas con recursos. Para esto, identifique bien las variables de primera etapa (“here and now”) y las de ajuste o segunda etapa (“wait and see”), y escriba los modelos correspondientes.

La variable de primera etapa corresponde a  $y_{jkt}$  y las de segunda etapa corresponden a  $x_{jkt}, I_{jt}^+, I_{jt}^-, I_{jt}$ . Así el problema de primera etapa queda como

$$\begin{aligned} \min \quad & \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J F_{jkt} y_{jkt} + \mathbb{E}_{\xi}[Q(y, \xi)] \\ \text{s.a.} \quad & \sum_{k=1}^K y_{jkt} = 1 \quad j = 1, \dots, J; t = 1, \dots, T \\ & \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jkt} y_{jkt} \leq P \\ & y_{jkt} \in \{0, 1\} \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \end{aligned}$$

y el modelo de segunda etapa es

$$\begin{aligned} Q(y, \xi) = \min \quad & \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J c_{jkt} x_{jkt} + \sum_{j=1}^J h_{jt} I_{jt}^+ + \sum_{j=1}^J \rho_{jt} I_{jt}^- \right\} \\ \text{s.a.} \quad & I_{jt} = I_{jt-1} + \sum_{k=1}^K x_{jtk} - d_{jt} \quad j = 1, \dots, J; t = 1, \dots, T \\ & I_{jt} = I_{jt}^+ - I_{jt}^- \quad j = 1, \dots, J; t = 1, \dots, T \\ & \sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt} \quad k = 1, \dots, K; t = 1, \dots, T \\ & x_{jkt} \leq M y_{jkt} \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \\ & x_{jkt} \geq 0, I_{jt}^+ \geq 0, I_{jt}^- \geq 0 \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T \end{aligned}$$

**c) (4 pts)** Escriba el problema de SAA que deberá usarse para aproximar la solución del modelo de 2 etapas de la parte a). Sea claro en cómo se generarán los escenarios a usar en el problema.

Se indexan las variables de la segunda etapa por un nuevo índice, sea  $s$  el índice que hace referencia a un escenario en específico, el modelo SAA quedaría como

$$\begin{aligned}
& \min \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J F_{jkt} y_{jkt} + \frac{1}{|S|} \sum_{s=1}^S \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J c_{jkt} x_{jkt} + \sum_{j=1}^J h_{jt} I_{jts}^+ + \sum_{j=1}^J \rho_{jt} I_{jts}^- \right\} \\
& s.a. \sum_{k=1}^K y_{jkt} = 1 \quad j = 1, \dots, J; t = 1, \dots, T \\
& \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jkt} y_{jkt} \leq P \\
& I_{jts} = I_{jt-1s} + \sum_{k=1}^K x_{jtk} - d_{jts} \quad j = 1, \dots, J; t = 1, \dots, T; s = 1, \dots, S \\
& I_{jts} = I_{jts}^+ - I_{jts}^- \quad j = 1, \dots, J; t = 1, \dots, T; s = 1, \dots, S \\
& \sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt} \quad k = 1, \dots, K; t = 1, \dots, T; s = 1, \dots, S \\
& x_{jkt} \leq M y_{jkt} \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T; s = 1, \dots, S \\
& x_{jkt} \geq 0, I_{jts}^+ \geq 0, I_{jts}^- \geq 0, y_{jkt} \in \{0, 1\} \quad j = 1, \dots, J; k = 1, \dots, K; t = 1, \dots, T; s = 1, \dots, S
\end{aligned}$$

**d) (3 pts)** ¿Posee el problema de la parte c) una estructura favorable al uso de la descomposición de Benders? En caso de ser así, reescriba en forma ordenada el problema explicitando la estructura. En caso contrario, diga por qué no.

El problema si posee una estructura favorable, la cual corresponde a

$$\begin{aligned}
& \min \sum_{t=1}^T \sum_{k=1}^K \sum_{j=1}^J F_{jkt} y_{jkt} + \frac{1}{|S|} \sum_{s=1}^S \sum_{t=1}^T \left\{ \sum_{k=1}^K \sum_{j=1}^J c_{jkt} x_{jkt} + \sum_{j=1}^J h_{jt} I_{jts}^+ + \sum_{j=1}^J \rho_{jt} I_{jts}^- \right\} \\
& s.a. \sum_{k=1}^K y_{jkt} = 1 \quad j = 1, \dots, J; t = 1, \dots, T \\
& \sum_{k=1}^K \sum_{j=1}^J \sum_{t=1}^T \beta_{jkt} y_{jkt} \leq P \\
& y_{jkt} \in \{0, 1\}, \\
& \sum_{k=1}^K x_{jtk} + I_{jt-1s} - I_{jts} = d_{jts} \quad \forall j, t, s \\
& I_{jts}^+ - I_{jts}^- - I_{jts} = 0 \quad j = 1, \dots, J; t = 1, \dots, T; s = 1, \dots, S \\
& \sum_{j=1}^J \alpha_{jk} x_{jkt} \leq H_{kt} \quad k = 1, \dots, K; t = 1, \dots, T; s = 1, \dots, S \\
& x_{jkt} \leq M y_{jkt} \quad \forall j, k, t, s \\
& x_{jkt} \geq 0, I_{jts}^+ \geq 0, I_{jts}^- \geq 0 \quad \forall j, k, t, s
\end{aligned}$$