

Diferencias en Diferencias y Datos de Panel: Fundamentos y Aplicaciones

Vicente Olea

Notas basadas en diapositivas del profesor Gonzalo Gaete del curso ICS2563 - Econometría Aplicada

Resumen

Este documento presenta una síntesis estructurada de los fundamentos teóricos y aplicaciones empíricas del método de Diferencias en Diferencias (DD) y su conexión con los modelos lineales de datos de panel y estimadores de efectos fijos. Se discute la motivación económica, el álgebra del estimador, el supuesto de tendencia común, la implementación mediante regresión y su formulación como modelo de efectos fijos. Posteriormente se introducen los datos de panel, los estimadores *within* y de primeras diferencias, y se describen extensiones como las Triples Diferencias (DDD) y los estudios de eventos. Finalmente se revisan aplicaciones empíricas relevantes en la literatura reciente.

Índice

1. Motivación y fundamentos de Diferencias en Diferencias (DD)	2
1.1. Motivación: salario mínimo y empleo	2
1.2. El diseño de Card y Krueger (1994, AER)	2
1.3. Variable de resultado: empleo FTE	3
2. Álgebra y supuesto de identificación de DD	3
2.1. El estimador de diferencias en diferencias en el caso 2x2	3
2.2. Tabla de doble entrada (2 x 2)	4
2.3. Modelo en ausencia de intervención y tendencia común	4
2.4. Efecto causal y expectativas en el grupo tratado	5
2.5. Demostración de que $DD = \delta$	5
2.6. Supuesto de tendencia común (tendencias paralelas)	5
3. Implementación de DD mediante regresión lineal y efectos fijos	6
3.1. Modelo lineal 2x2	6
3.2. DD como modelo de efectos fijos	6
4. Datos de panel y estimadores de efectos fijos (FE)	7
4.1. Estructuras de datos: sección cruzada, serie de tiempo y panel	7
4.2. Panel balanceado y no balanceado	7
4.3. Modelo general y soluciones estadísticas	7
4.4. Estimador <i>within</i> (de efectos fijos)	8
4.5. Estimador de primeras diferencias (FD)	9

5. Extensiones de DD: Triples Diferencias (DDD) y estudios de eventos	9
5.1. Triples diferencias (DDD)	9
5.2. Aplicación: robos a choferes de buses	10
5.3. Estudios de eventos	10
6. Aplicaciones y casos de estudio relevantes	11
6.1. Duflo (2001, AER): construcción de escuelas en Indonesia	11
6.1.1. Efecto en educación (global)	11
6.1.2. Efecto en educación por cohorte	11
6.2. IVA francés: Benzarti y Carloni (2020)	12
6.3. Kleven et al. (2019, AEJ): penalidad por hijos/as	12
6.3.1. Regresión base	12
6.3.2. Cálculo de la penalidad de género	13
7. Conclusiones	13
8. Cheat Sheet: Diferencias en Diferencias, DDD y Datos de Panel	14
8.1. Fórmulas fundamentales	14

1. Motivación y fundamentos de Diferencias en Diferencias (DD)

1.1. Motivación: salario mínimo y empleo

Una pregunta clásica en economía laboral es:

¿Cuál es el efecto de aumentar el salario mínimo (MW) sobre el empleo (L)?

El modelo neoclásico estándar de oferta y demanda de trabajo predice que, en un mercado competitivo, un aumento exógeno del salario mínimo por sobre el salario de equilibrio reduce el nivel de empleo de equilibrio. Sin embargo, la pregunta empírica es si esa predicción se verifica en los datos y *cómo* medir el efecto causal de una política de aumento del salario mínimo.

En términos de diseño empírico, uno querría comparar la trayectoria del empleo en un grupo afectado por el cambio de política (grupo tratado) con la trayectoria en un grupo similar que no se ve afectado (grupo de control), antes y después de la intervención.

1.2. El diseño de Card y Krueger (1994, AER)

Card y Krueger (1994) estudian un experimento natural asociado al aumento del salario mínimo en el estado de Nueva Jersey (NJ) y utilizan como grupo de comparación al estado vecino de Pennsylvania (PA). El contexto es el siguiente:

- **Tratamiento:** Nueva Jersey (NJ) aumenta el salario mínimo el 1 de abril de 1992.
- **Control:** Pennsylvania (PA) no cambia su salario mínimo en esa fecha.
- **Diseño:** antes–después con grupo de comparación geográficamente cercano.

Las unidades observadas son **locales de comida rápida** pertenecientes principalmente a las cadenas Burger King, KFC, Wendy's y Roy Rogers, encuestadas mediante levantamiento propio (principalmente telefónico). McDonald's fue excluida tras un piloto con baja tasa de respuesta. El marco muestral se construyó a partir de guías telefónicas (*white pages*) de Nueva Jersey y Pennsylvania oriental, identificando los locales con teléfono.

Unidad de observación y cobertura geográfica.

- **Unidad de observación:** restaurante o tienda individual.
- **Cobertura geográfica:** Nueva Jersey y Pennsylvania oriental, que comparten mercados laborales comparables.
- **Homogeneidad de medición:** mismo cuestionario, definiciones y cadenas en ambos estados, lo que facilita la comparabilidad entre tratados y controles.

Cronograma de levantamiento. El diseño empírico contempla dos olas de encuesta:

- **Ola 1 (pre-tratamiento):** febrero–marzo de 1992, pocas semanas antes del alza del salario mínimo en NJ.
- **Ola 2 (post-tratamiento):** noviembre–diciembre de 1992, aproximadamente ocho meses después de la reforma.

Se recontacta a los mismos locales de comida rápida para construir un panel de establecimientos. Cuando fue necesario, se verificó in situ el cierre de locales para depurar correctamente el panel.

1.3. Variable de resultado: empleo FTE

La variable central de resultado es el empleo medido en *full-time equivalents* (FTE), definida como:

$$FTE = FT + 0,5 \times PT,$$

donde:

- *FT*: número de trabajadores de jornada completa.
- *PT*: número de trabajadores de jornada parcial.

Esta definición permite agregar trabajadores de jornada completa y parcial a un mismo denominador de “equivalentes tiempo completo”, mejorando la comparabilidad del nivel de empleo entre establecimientos y en el tiempo.

Además, el cuestionario recoge información sobre salarios de entrada, cumplimiento del mínimo, precios (por ejemplo, precios de combos), horas de operación y características del local (franquicia versus empresa, políticas de contratación y bonos), utilizando exactamente las mismas definiciones en ambas olas para asegurar comparabilidad antes y después de la política.

2. Álgebra y supuesto de identificación de DD

2.1. El estimador de diferencias en diferencias en el caso 2x2

Considérese un diseño con dos grupos:

- Tratados ($D = 1$): unidades expuestas a la política.
- No tratados o controles ($D = 0$): unidades no expuestas.

y dos períodos:

- Pre-intervención ($t = 1$).
- Post-intervención ($t = 2$).

Denotemos por $\bar{Y}_{\text{pre}}^{\text{trat}}$ el promedio del resultado en el grupo tratado antes de la intervención, por $\bar{Y}_{\text{post}}^{\text{trat}}$ el promedio en tratados después, y análogamente para el grupo de control. El estimador de diferencias en diferencias se define como:

$$DD = (\bar{Y}_{\text{post}}^{\text{trat}} - \bar{Y}_{\text{pre}}^{\text{trat}}) - (\bar{Y}_{\text{post}}^{\text{ctrl}} - \bar{Y}_{\text{pre}}^{\text{ctrl}}). \quad (1)$$

En notación de esperanza, el estimador poblacional que se desea identificar es:

$$\tau_{DD} = \mathbb{E}[(Y_{11} - Y_{10}) - (Y_{01} - Y_{00})],$$

donde Y_{dt} denota el resultado promedio en el grupo con indicador $D = d$ en el período t .

2.2. Tabla de doble entrada (2 x 2)

La situación se resume en una tabla 2x2:

	Tratados ($D = 1$)	No tratados ($D = 0$)
Pre-intervención	$\bar{Y}_{\text{pre}}^{\text{trat}}$	$\bar{Y}_{\text{pre}}^{\text{ctrl}}$
Post-intervención	$\bar{Y}_{\text{post}}^{\text{trat}}$	$\bar{Y}_{\text{post}}^{\text{ctrl}}$

Solo en una de las cuatro celdas (Tratados $\times$ Post) las unidades han sido efectivamente tratadas. La idea de DD es usar la evolución del grupo de control como aproximación de la contrafactual para el grupo tratado.

2.3. Modelo en ausencia de intervención y tendencia común

Supongamos que, en ausencia de intervención, el resultado de la unidad i en el período T está dado por:

$$\mathbb{E}[Y_i(0) \mid D_i = 0, t = T] = \gamma_i + \lambda_T, \quad (2)$$

donde:

- γ_i captura características inobservadas fijas de la unidad (sesgo de selección basado en variables inmutables en el tiempo).
- λ_T captura la tendencia común en el tiempo que afecta por igual a todas las unidades.

En la notación de las diapositivas, para el grupo no tratado:

$$\mathbb{E}[\bar{Y}_{\text{pre}}^{\text{ctrl}}] = \mathbb{E}[Y_{0i} \mid D_i = 0, t = 1] = \mathbb{E}[\gamma_i \mid D_i = 0] + \lambda_1, \quad (3)$$

$$\mathbb{E}[\bar{Y}_{\text{post}}^{\text{ctrl}}] = \mathbb{E}[Y_{0i} \mid D_i = 0, t = 2] = \mathbb{E}[\gamma_i \mid D_i = 0] + \lambda_2. \quad (4)$$

Por lo tanto, la diferencia temporal en el grupo de control identifica la tendencia común:

$$\mathbb{E}[\bar{Y}_{\text{post}}^{\text{ctrl}} - \bar{Y}_{\text{pre}}^{\text{ctrl}}] = \lambda_2 - \lambda_1. \quad (5)$$

2.4. Efecto causal y expectativas en el grupo tratado

Sea δ el efecto real del programa en el resultado de interés:

$$\delta = \mathbb{E}[Y_{1i} \mid D_i = 1, t = T] - \mathbb{E}[Y_{0i} \mid D_i = 1, t = T]. \quad (6)$$

En observables, para las unidades tratadas:

$$\mathbb{E}[\bar{Y}_{\text{pre}}^{\text{trat}}] = \mathbb{E}[Y_{0i} \mid D_i = 1, t = 1] = \mathbb{E}[\gamma_i \mid D_i = 1] + \lambda_1, \quad (7)$$

$$\mathbb{E}[\bar{Y}_{\text{post}}^{\text{trat}}] = \mathbb{E}[Y_{1i} \mid D_i = 1, t = 2] = \mathbb{E}[\gamma_i \mid D_i = 1] + \delta + \lambda_2. \quad (8)$$

La diferencia temporal en el grupo tratado es:

$$\mathbb{E}[\bar{Y}_{\text{post}}^{\text{trat}} - \bar{Y}_{\text{pre}}^{\text{trat}}] = \delta + (\lambda_2 - \lambda_1). \quad (9)$$

Asimismo, si comparamos tratados versus no tratados en el período post:

$$\mathbb{E}[\bar{Y}_{\text{post}}^{\text{trat}} - \bar{Y}_{\text{post}}^{\text{ctrl}}] = \delta + \left(\mathbb{E}[\gamma_i \mid D_i = 1] - \mathbb{E}[\gamma_i \mid D_i = 0] \right), \quad (10)$$

donde el segundo término corresponde al sesgo de selección asociado a diferencias en características fijas entre tratados y controles.

2.5. Demostración de que $DD = \delta$

Proposición 1 (Identificación de δ mediante DD). *Bajo el supuesto de tendencia común, el estimador de diferencias en diferencias definido en (1) identifica el efecto causal δ .*

Demostración. Por (9):

$$\mathbb{E}[\bar{Y}_{\text{post}}^{\text{trat}} - \bar{Y}_{\text{pre}}^{\text{trat}}] = \delta + (\lambda_2 - \lambda_1).$$

Para el grupo no tratado:

$$\mathbb{E}[\bar{Y}_{\text{post}}^{\text{ctrl}} - \bar{Y}_{\text{pre}}^{\text{ctrl}}] = \lambda_2 - \lambda_1.$$

Restando ambas expresiones se obtiene:

$$\begin{aligned} \mathbb{E}[DD] &= \mathbb{E}[\bar{Y}_{\text{post}}^{\text{trat}} - \bar{Y}_{\text{pre}}^{\text{trat}}] - \mathbb{E}[\bar{Y}_{\text{post}}^{\text{ctrl}} - \bar{Y}_{\text{pre}}^{\text{ctrl}}] \\ &= (\delta + \lambda_2 - \lambda_1) - (\lambda_2 - \lambda_1) \\ &= \delta. \end{aligned}$$

Es decir, el estimador de DD neutraliza tanto la tendencia temporal común como el sesgo de selección basado en componentes fijas γ_i . $\square$

2.6. Supuesto de tendencia común (tendencias paralelas)

Definición 1 (Supuesto de tendencia común). *El supuesto de tendencia común establece que, en ausencia de tratamiento, la trayectoria temporal (en valor esperado) del resultado para el grupo tratado habría sido igual a la trayectoria del grupo de control. Formalmente:*

$$\mathbb{E}[Y_{0i} \mid D_i = 1, t = 2] - \mathbb{E}[Y_{0i} \mid D_i = 1, t = 1] = \mathbb{E}[Y_{0i} \mid D_i = 0, t = 2] - \mathbb{E}[Y_{0i} \mid D_i = 0, t = 1].$$

Este supuesto no exige que los niveles de Y sean similares entre tratados y controles; solo exige que las *tendencias* condicionales sean las mismas. Cualquier factor fijo en el tiempo que diferencie a los grupos queda absorbido por γ_i , mientras que shocks comunes se recogen en λ_t .

La validez de este supuesto es una cuestión sustantiva: en aplicaciones empíricas se suele inspeccionar la evolución previa (*pre-trends*) de tratados y controles para evaluar si las trayectorias eran razonablemente paralelas antes de la intervención.

3. Implementación de DD mediante regresión lineal y efectos fijos

3.1. Modelo lineal 2x2

El diseño 2x2 puede implementarse mediante la siguiente regresión lineal:

$$Y_{it} = \alpha + \beta D_i + \eta Post_t + \delta(D_i \times Post_t) + \varepsilon_{it}, \quad (11)$$

donde:

- D_i es un indicador de pertenencia al grupo tratado.
- $Post_t$ es un indicador de período post-intervención.
- $D_i \times Post_t$ es la interacción tratamiento $\times$ período post.

En este modelo:

- α capta el nivel medio en el grupo de control en el período pre.
- β capta la diferencia en niveles (fija en el tiempo) entre tratados y controles.
- η capta el cambio temporal común entre períodos pre y post en el grupo de control.
- δ es el coeficiente de la interacción y representa precisamente el estimador de DD, δ_{DD} .

La interpretación de δ es el *cambio adicional* en el resultado del grupo tratado, más allá del cambio observado en el grupo de control.

3.2. DD como modelo de efectos fijos

El estimador de DD se puede ver como un caso especial de un modelo de efectos fijos (FE). Consideremos el modelo:

$$Y_{ist} = \alpha + \delta D_{st} + \gamma_s + \lambda_t + \varepsilon_{ist}, \quad (12)$$

donde:

- Y_{ist} es el resultado para el individuo i , en la región o estado s , en el período t .
- D_{st} indica si la célula (s, t) está tratada (por ejemplo, NJ en el período post).
- γ_s son efectos fijos específicos del lugar (capturan γ_i a nivel de s).
- λ_t son efectos fijos de tiempo comunes a todos los lugares.

En el caso concreto de Card y Krueger, con dos estados ($s \in \{NJ, PA\}$) y dos períodos (pre y post), la diferencia en diferencias puede expresarse como:

$$\begin{aligned} \mathbb{E}[Y_{ist} \mid s = PA, t = \text{Nov}] - \mathbb{E}[Y_{ist} \mid s = PA, t = \text{Feb}] &= \lambda_{\text{Nov}} - \lambda_{\text{Feb}}, \\ \mathbb{E}[Y_{ist} \mid s = NJ, t = \text{Nov}] - \mathbb{E}[Y_{ist} \mid s = NJ, t = \text{Feb}] &= \lambda_{\text{Nov}} - \lambda_{\text{Feb}} + \delta. \end{aligned}$$

Por lo tanto, la diferencia de diferencias vuelve a ser δ , y el modelo (12) implementa DD como un caso particular de estimador de efectos fijos de dos vías (lugar y tiempo).

4. Datos de panel y estimadores de efectos fijos (FE)

4.1. Estructuras de datos: sección cruzada, serie de tiempo y panel

Existen tres estructuras de datos básicas:

- (I) **Sección cruzada (corte transversal)**: se observan N unidades en un solo período. Número de observaciones: N .
- (II) **Serie de tiempo**: se observa una unidad en T períodos. Número de observaciones: T .
- (III) **Datos de panel**: se observan N unidades en T períodos. Número de observaciones: $N \times T$.

Un caso intermedio son los *datos de sección cruzada agrupados*, como en Card y Krueger, donde se observa una misma muestra en dos momentos, formando un panel de establecimientos de pequeña dimensión temporal.

4.2. Panel balanceado y no balanceado

En un panel balanceado se observa cada unidad i en todos los períodos $t = 1, \dots, T$, de modo que:

$$\{y_{it}, x_{it}\} : i = 1, \dots, N; t = 1, \dots, T.$$

En un panel no balanceado, el número de períodos T_i puede diferir entre unidades, y la muestra se describe como:

$$\{y_{it}, x_{it}\} : i = 1, \dots, N; t = t_i, \dots, \bar{t}_i,$$

donde el conjunto de períodos observados para cada i puede variar. En este caso, el número total de observaciones es $\sum_{i=1}^N T_i$.

4.3. Modelo general y soluciones estadísticas

Consideremos el modelo lineal con término inobservable específico de la unidad:

$$Y_{it} = \beta_0 + \beta_1 D_{it} + c_i + u_{it}, \quad (13)$$

donde c_i recoge factores inobservados fijos en el tiempo para la unidad i .

En este contexto, las observaciones ya no son i.i.d., pues existe correlación serial en Y_{it} incluso después de controlar por X_{it} , debido a c_i . Se utilizan dos enfoques estándar:

- (a) **Efectos aleatorios (RE)**: se asume que

$$\mathbb{E}[c_i | X_{i1}, \dots, X_{iT}] = 0.$$

Bajo este supuesto, c_i es independiente de las covariables y puede modelarse como un componente aleatorio adicional.

- (b) **Efectos fijos (FE)**: se permite correlación entre c_i y las covariables; se requiere solo

$$\mathbb{E}[u_{it} | X_{i1}, \dots, X_{iT}, c_i] = 0.$$

El componente c_i se elimina mediante transformaciones como el estimador *within* o de primeras diferencias.

En estas notas el énfasis está puesto en el enfoque de efectos fijos.

4.4. Estimador *within* (de efectos fijos)

Partiendo del modelo:

$$y_{it} = \beta x_{it} + a_i + u_{it}, \quad t = 1, \dots, T, \quad (14)$$

se define, para cada unidad i , el promedio temporal:

$$\bar{y}_i = \frac{1}{T} \sum_{t=1}^T y_{it}, \quad (15)$$

$$\bar{x}_i = \frac{1}{T} \sum_{t=1}^T x_{it}, \quad (16)$$

$$\bar{u}_i = \frac{1}{T} \sum_{t=1}^T u_{it}. \quad (17)$$

Promediando (14) sobre t , se obtiene:

$$\bar{y}_i = \beta \bar{x}_i + a_i + \bar{u}_i. \quad (18)$$

Restando (18) de (14) se eliminan los efectos fijos a_i :

$$\begin{aligned} y_{it} - \bar{y}_i &= \beta(x_{it} - \bar{x}_i) + (u_{it} - \bar{u}_i) \\ \tilde{y}_{it} &= \beta \tilde{x}_{it} + \tilde{u}_{it}, \quad t = 1, \dots, T, \end{aligned} \quad (19)$$

donde:

$$\tilde{y}_{it} = y_{it} - \bar{y}_i, \quad \tilde{x}_{it} = x_{it} - \bar{x}_i, \quad \tilde{u}_{it} = u_{it} - \bar{u}_i.$$

La regresión en desviaciones respecto del promedio específico de cada unidad,

$$\tilde{y}_{it} = \beta \tilde{x}_{it} + \tilde{u}_{it}, \quad (20)$$

es precisamente la ecuación (8) y produce el estimador *within* de efectos fijos.

Conexión con el teorema de Frisch–Waugh–Lovell (FWL)

En notación matricial, para cada unidad i :

$$y_i = X_i \beta + d_i a_i + \varepsilon_i,$$

donde d_i es un vector de unos que multiplica el efecto fijo a_i .

Apilando todas las unidades:

$$y = [X, D] \begin{bmatrix} \beta \\ a \end{bmatrix} + \varepsilon = Z\delta + \varepsilon.$$

El teorema de FWL establece que el estimador de β puede escribirse como:

$$\hat{\beta} = (X' M_D X)^{-1} (X' M_D y), \quad (21)$$

donde:

$$M_D = I - D(D'D)^{-1}D'$$

es la matriz de proyección ortogonal al espacio generado por D .

En el caso de paneles con dummies de unidad, la estructura de D es especialmente conveniente: sus columnas son ortogonales y D_i es un vector de unos de dimensión T_i , de modo que para cada i :

$$M_D^{(i)} X_i = x_i - d_i \bar{x}_i,$$

lo que muestra que M_D implementa, precisamente, la transformación de desviaciones respecto del promedio de cada unidad. El estimador *within* es entonces la aplicación de FWL al conjunto de dummies de efectos fijos.

4.5. Estimador de primeras diferencias (FD)

Una alternativa para eliminar c_i es trabajar con primeras diferencias:

$$\Delta Y_{it} = Y_{it} - Y_{i,t-1}, \quad \Delta X_{it} = X_{it} - X_{i,t-1}, \quad \Delta \varepsilon_{it} = \varepsilon_{it} - \varepsilon_{i,t-1}.$$

Aplicando diferencias al modelo (13) se obtiene:

$$\Delta Y_{it} = \Delta X'_{it} \beta + \Delta \varepsilon_{it}, \quad t = 2, \dots, T, \quad (22)$$

que corresponde a la ecuación (9).

Comentario 1 (Equivalencia FE–FD cuando $T = 2$). *Cuando solo hay dos períodos ($T = 2$), el estimador de efectos fijos (within) y el estimador de primeras diferencias coinciden:*

$$\hat{\beta}_{FE} = \hat{\beta}_{\Delta}.$$

El resultado se verifica algebraicamente, observando que, con $T = 2$, restar el promedio de la unidad es proporcional a tomar la diferencia entre los dos períodos.

5. Extensiones de DD: Triples Diferencias (DDD) y estudios de eventos

5.1. Triples diferencias (DDD)

En algunos contextos es posible fortalecer la identificación de DD agregando una tercera dimensión de comparación (por ejemplo, un grupo etario cercano). Supongamos una política que afecta a una región $i = 1$ en un momento $t = 1$ y a un grupo etario $a = 1$ (por ejemplo, mayores de 65 años). Sea Y_{iat} el resultado promedio para la celda (i, a, t) .

El estimador de *triples diferencias* se puede escribir como:

$$\begin{aligned} DDD = & [(Y_{111} - Y_{110}) - (Y_{101} - Y_{100})] \\ & - [(Y_{011} - Y_{010}) - (Y_{001} - Y_{000})], \end{aligned} \quad (23)$$

donde los subíndices representan región ($i = 0, 1$), grupo ($a = 0, 1$) y período ($t = 0, 1$).

La regresión lineal asociada puede escribirse como:

$$\begin{aligned} Y_{iat} = & \alpha + \gamma_1 \mathbf{1}\{i = 1\} + \gamma_2 \mathbf{1}\{t = 1\} + \gamma_3 \mathbf{1}\{a = 1\} \\ & + \gamma_4 \mathbf{1}\{i = 1\} \mathbf{1}\{t = 1\} + \gamma_5 \mathbf{1}\{i = 1\} \mathbf{1}\{a = 1\} + \gamma_6 \mathbf{1}\{t = 1\} \mathbf{1}\{a = 1\} \\ & + \gamma_7 \mathbf{1}\{i = 1\} \mathbf{1}\{t = 1\} \mathbf{1}\{a = 1\} + u_{iat}. \end{aligned} \quad (24)$$

En este modelo, γ_7 captura la trayectoria diferencial específica del grupo ($i = 1, a = 1$) en el período post, por encima de todas las dobles interacciones. Bajo el supuesto de identificación apropiado, γ_7 es el parámetro de interés.

Comentario 2 (Supuesto de identificación en DDD). *DDD relaja el supuesto de DD en el sentido de que ya no se requiere que la trayectoria (en valor esperado) sea igual entre $s = 1$ y $s = 0$ para todos los grupos, sino que, si existe una diferencia de tendencia entre ambas regiones, esta debe afectar del mismo modo a los grupos $a = 1$ y $a = 0$. La tercera dimensión permite descontar diferencias en tendencia comunes a ambos grupos etarios.*

5.2. Aplicación: robos a choferes de buses

En una aplicación al contexto de robos a choferes de buses, se estudia la introducción de un sistema de pago electrónico que elimina el manejo de efectivo por parte del conductor. El diseño empírico utiliza tanto DD como DDD.

Modelo DD:

$$\begin{aligned} Crime_{it} = & \alpha + \beta_1 Treat_i + \beta_2 Post_t + \beta_3 Cash_i \\ & + \beta_4 (Cash_i \times Treat_i) + \beta_5 (Cash_i \times Post_t) + \omega_{m(t)} + \varepsilon_{it}, \end{aligned} \quad (25)$$

donde $Crime_{it}$ es el número de incidentes de robo, $Treat_i$ indica exposición al nuevo sistema, $Post_t$ es el período post-reforma, $Cash_i$ indica manejo de efectivo y $\omega_{m(t)}$ captura efectos fijos de mes o patrones estacionales.

Modelo DDD:

$$\begin{aligned} Crime_{ijt} = & \alpha + \beta_1 Treat_i + \beta_2 Post_t + \beta_3 Cash_i + \beta_4 (Cash_i \times Treat_i) \\ & + \beta_5 (Cash_i \times Post_t) + \beta_6 Bus_j + \beta_7 (Bus_j \times Treat_i) \\ & + \beta_8 (Bus_j \times Post_t) + \beta_9 (Bus_j \times Cash_i) \\ & + \beta_{10} (Treat_i \times Cash_i \times Bus_j) \\ & + \beta_{11} (Post_t \times Cash_i \times Bus_j) + \omega_{m(t)} + \varepsilon_{ijt}, \end{aligned} \quad (26)$$

donde Bus_j identifica un tercer margen de heterogeneidad (por ejemplo, tipo de bus o ruta), y las interacciones triples permiten aislar la variación específica combinada de tratamiento, efectivo y tipo de bus.

5.3. Estudios de eventos

En muchos casos interesa describir no solo un “efecto medio post”, sino la evolución del resultado en torno al momento en que la política entra en vigor. Para ello se utilizan *estudios de eventos*, que generalizan DD permitiendo múltiples períodos pre y post.

Supóngase información de individuos y varios períodos alrededor del evento, $t \in \{-T, \dots, T\}$. Un modelo típico es:

$$Y_{ist} = \gamma_s + \lambda_t + \sum_{k=-T}^T \delta_k D_{s,k} + X'_{ist} \beta + \varepsilon_{ist}, \quad (27)$$

donde:

- γ_s son efectos fijos de lugar.
- λ_t son efectos fijos de tiempo.
- $D_{s,k}$ indica que la observación está k períodos antes o después del evento en la unidad s .

- δ_k mide el efecto relativo en el período k respecto de un período base (típicamente normalizado a cero).

Los estudios de eventos permiten inspeccionar *pre-trends* (coeficientes δ_k para $k < 0$) y la dinámica del efecto post-política.

6. Aplicaciones y casos de estudio relevantes

6.1. Duflo (2001, AER): construcción de escuelas en Indonesia

Duflo (2001) estudia los retornos económicos de la educación a partir de un gran programa de construcción de escuelas en Indonesia entre 1973 y 1978, que construyó aproximadamente 61.000 escuelas en cinco años. La estrategia de identificación explota la variación en la *intensidad del programa* por región de nacimiento y cohorte.

La exposición al programa se mide por el número de escuelas construidas por cada 1.000 niños en la región de nacimiento. Se utilizan datos de encuestas (SUPAS) para hombres nacidos entre 1950 y 1972.

6.1.1. Efecto en educación (global)

La ecuación básica para educación es:

$$S_{ijk} = c_1 + \alpha_{1j} + \beta_{1k} + (P_j T_i) \gamma_1 + (C_j T_i) \delta_1 + \varepsilon_{ijk}, \quad (28)$$

donde:

- S_{ijk} : años de educación del individuo i , nacido en región j , cohorte k .
- T_i : indicador de pertenencia a una cohorte joven.
- α_{1j} : efecto fijo de distrito de nacimiento.
- β_{1k} : efecto fijo de cohorte de nacimiento.
- P_j : intensidad del programa (número de escuelas por 1.000 niños) en la región de nacimiento.
- C_j : vector de variables específicas de la región (por ejemplo, tasa de matrícula inicial, saneamiento).

6.1.2. Efecto en educación por cohorte

Para estudiar la heterogeneidad por edad al momento de la reforma, se especifica:

$$S_{ijk} = c_1 + \alpha_{1j} + \beta_{1k} + \sum_{\ell=2}^{23} (P_j d_{i\ell}) \gamma_{1\ell} + \sum_{\ell=2}^{23} (C_j d_{i\ell}) \delta_{1\ell} + \varepsilon_{ijk}, \quad (29)$$

donde:

- $d_{i\ell}$: indicador de que el individuo i tenía ℓ años en 1974.
- Los demás términos se definen como en (28).

Supuesto de identificación. La identificación descansa en que no existan efectos omitidos tiempo-variables y región-específicos correlacionados con la intensidad del programa. En particular, la asignación de escuelas a cada región fue función explícita de la matrícula en 1972, lo que permite tratar P_j como exógeno condicional a efectos fijos de región y cohorte.

6.2. IVA francés: Benzarti y Carloni (2020)

En 2009 Francia redujo el IVA de 19,6 % a 5 % en el sector restaurantes, con el objetivo de estimular esa industria. La pregunta de interés es cómo se reparte el beneficio de la rebaja entre consumidores (precios), trabajadores, dueños de firmas y proveedores.

Benzarti y Carloni (2020) estiman modelos de DD a nivel de firma utilizando un diseño de estudio de eventos. Una especificación típica es:

$$\log Y_{idt} = \sum_{v=-k}^q \eta_v \mathbf{1}\{i \in T\} \times \mathbf{1}\{t = v\} + \lambda_t + \omega_i + \varepsilon_{idt}, \quad (30)$$

donde:

- Y_{idt} es el resultado de interés (por ejemplo, ventas o empleo) de la firma i en el departamento d y año t .
- $\mathbf{1}\{i \in T\}$ indica que la firma pertenece al sector tratado (restaurantes).
- η_v mide la variación porcentual del resultado en el año v relativo al año base.
- λ_t son efectos fijos de año.
- ω_i son efectos fijos de firma.

Al normalizar el coeficiente para 2008 a cero, cada η_v se interpreta como la variación porcentual relativa a 2008. La presencia de efectos fijos de firma implica que la identificación proviene de variación intra-firma a lo largo del tiempo.

6.3. Kleven et al. (2019, AEJ): penalidad por hijos/as

Kleven et al. (2019) estudian el impacto del nacimiento del primer hijo en la desigualdad de género en el mercado laboral, usando datos administrativos de Dinamarca para toda la población entre 1980 y 2013. La estrategia es un estudio de eventos alrededor del nacimiento del primer hijo.

6.3.1. Regresión base

Para cada padre y madre se estima, relativo al año del nacimiento ($t = 0$), la siguiente especificación:

$$Y_{ist}^g = \sum_{j \neq -1} \alpha_j^g \mathbf{1}[j = t] + \sum_k \beta_k^g \mathbf{1}[k = age_{is}] + \sum_y \gamma_y^g \mathbf{1}[y = s] + v_{ist}^g, \quad (31)$$

donde:

- Y_{ist}^g es el resultado (por ejemplo, ingreso laboral) del individuo i , de género $g \in \{m, w\}$, en año calendario s , y tiempo relativo al evento t .
- α_j^g son efectos de tiempo de evento.

- β_k^g son efectos fijos de edad.
- γ_y^g son efectos fijos de año calendario.

Se utiliza un panel balanceado que cubre desde 5 años antes hasta 10–20 años después del nacimiento del primer hijo.

6.3.2. Cálculo de la penalidad de género

La penalidad por hijos sobre las mujeres se mide como:

$$P_t = \frac{\hat{\alpha}_t^m - \hat{\alpha}_t^w}{\mathbb{E}[\tilde{Y}_{ist}^w | t]}, \quad (32)$$

donde el numerador mide la diferencia en el efecto de evento entre hombres y mujeres, y el denominador normaliza por el nivel esperado de Y para las mujeres, interpretando P_t como una penalidad relativa en porcentaje.

El resultado central es que la penalidad de largo plazo en ingresos alcanza aproximadamente 20 %, reflejando cambios en participación, horas y salarios, y está asociada a cambios hacia empleos más “*family friendly*”.

7. Conclusiones

El diseño de Diferencias en Diferencias y sus extensiones basadas en datos de panel constituyen herramientas fundamentales para la evaluación de políticas públicas y el análisis causal en econometría aplicada. La clave de identificación en DD descansa en el **supuesto de tendencia común**: en ausencia de tratamiento, la trayectoria del resultado para el grupo tratado habría sido paralela a la del grupo de control. Bajo este supuesto, el estimador de DD elimina tanto la tendencia temporal común como el sesgo de selección basado en características fijas.

Sin embargo, la validez de la tendencia común es *intesteable*. El análisis de *pre-trends* y la inspección de la dinámica en estudios de eventos entregan evidencia indirecta, pero no garantizan plenamente el supuesto. Por ello, el uso riguroso de DD requiere una cuidadosa elección de grupos de control comparables, la posibilidad de extender el diseño mediante triples diferencias cuando la estructura de datos lo permite, y una discusión crítica de posibles comportamientos estratégicos o fuentes de endogeneidad residual que puedan invalidar la interpretación causal de los coeficientes estimados.

8. Cheat Sheet: Diferencias en Diferencias, DDD y Datos de Panel

Esta sección resume fórmulas, supuestos, pasos de resolución y mini-ejemplos basados en ejercicios como los de la *Guía DD [Pauta]* y la *Ayudantía Repaso I2*. El objetivo es dejar un formulario completo para resolver cualquier ejercicio típico.

8.1. Fórmulas fundamentales

Diferencias en Diferencias (DD)

$$DD = (\bar{Y}_{post}^T - \bar{Y}_{pre}^T) - (\bar{Y}_{post}^C - \bar{Y}_{pre}^C)$$

$$\tau_{DD} = (Y_{11} - Y_{10}) - (Y_{01} - Y_{00})$$

Modelo equivalente:

$$Y_{it} = \alpha + \beta D_i + \eta Post_t + \delta(D_i \times Post_t) + \varepsilon_{it}$$

$$\boxed{\hat{\delta} = DD}$$

Efectos Fijos (FE)

Modelo base:

$$Y_{it} = X'_{it}\beta + a_i + u_{it}$$

Transformación dentro de unidad:

$$\tilde{Y}_{it} = Y_{it} - \bar{Y}_i, \quad \tilde{X}_{it} = X_{it} - \bar{X}_i$$

Regresión:

$$\tilde{Y}_{it} = \tilde{X}'_{it}\beta + \tilde{u}_{it}$$

Propiedad clave:

$$T = 2 \Rightarrow \hat{\beta}_{FE} = \hat{\beta}_{FD}$$

Primeras Diferencias (FD)

$$\Delta Y_{it} = Y_{it} - Y_{i,t-1}$$

$$\Delta Y_{it} = \Delta X'_{it}\beta + \Delta u_{it}$$

Triples Diferencias (DDD)

$$DDD = [(Y_{111} - Y_{110}) - (Y_{101} - Y_{100})] - [(Y_{011} - Y_{010}) - (Y_{001} - Y_{000})]$$

Regresión:

$$Y_{iat} = \dots + \gamma_7 1\{i = 1\}1\{t = 1\}1\{a = 1\} + u_{iat}$$

$$\boxed{\hat{\gamma}_7 = DDD}$$

Estudios de Evento

$$Y_{ist} = \gamma_s + \lambda_t + \sum_{k=-K}^K \delta_k D_{s,k} + X' \beta + \varepsilon_{ist}$$

Interpretación: - δ_k con $k < 0$: pre-trends - δ_k con $k > 0$: dinámica del efecto post

Supuestos esenciales

DD: Tendencias paralelas

$$E[Y_{0i}(2) - Y_{0i}(1) \mid D = 1] = E[Y_{0i}(2) - Y_{0i}(1) \mid D = 0]$$

No exige niveles iguales, solo *trayectorias* iguales.

FE: Exogeneidad condicional

$$E[u_{it} \mid X_{i1}, \dots, X_{iT}, a_i] = 0$$

RE: Exogeneidad fuerte

$$E[a_i \mid X_{i1}, \dots, X_{iT}] = 0$$

FD: Exogeneidad sobre diferencias

$$E[\Delta u_{it} \mid \Delta X_{it}] = 0$$

DDD: Tendencias paralelas diferenciadas

Las tendencias entre grupos $a = 0$ y $a = 1$ deben ser iguales en ausencia del tratamiento.

Cómo resolver un ejercicio de DD

1. Identificar dimensiones - Tratado vs. Control - Pre vs. Post
2. Construir tabla 2×2
3. Calcular las diferencias

$$\Delta Y^T = Y_{post}^T - Y_{pre}^T$$

$$\Delta Y^C = Y_{post}^C - Y_{pre}^C$$

4. Aplicar fórmula

$$DD = \Delta Y^T - \Delta Y^C$$

5. Interpretar signo, magnitud y unidades
6. Evaluar supuestos

Mini-ejemplo DD

Datos:

$$Y_{pre}^T = 10, Y_{post}^T = 14, \quad Y_{pre}^C = 12, Y_{post}^C = 15$$

$$\Delta Y^T = 4, \quad \Delta Y^C = 3$$

$$DD = 4 - 3 = 1$$

Interpretación: El tratamiento aumenta Y en 1 unidad adicional.

Cómo resolver un ejercicio de DDD

1. Identificar las tres dimensiones i (grupo), t (tiempo), a (subgrupo)
2. Construir tabla $2 \times 2 \times 2$
3. Calcular dos DD:

$$DD_1 = (Y_{111} - Y_{110}) - (Y_{101} - Y_{100})$$

$$DD_0 = (Y_{011} - Y_{010}) - (Y_{001} - Y_{000})$$

4. Restar:

$$DDD = DD_1 - DD_0$$

5. Interpretar

Mini-ejemplo DDD

$$DD_1 = 5, \quad DD_0 = 2$$

$$DDD = 5 - 2 = 3$$

Interpretación: El efecto adicional para el subgrupo $a = 1$ es 3 unidades.

Cómo resolver ejercicios FE (within)

1. Calcular promedios por unidad

$$\bar{Y}_i, \quad \bar{X}_i$$

2. Transformar

$$\tilde{Y}_{it} = Y_{it} - \bar{Y}_i$$

$$\tilde{X}_{it} = X_{it} - \bar{X}_i$$

3. Regresión within

$$\tilde{Y}_{it} = \tilde{X}_{it}'\beta + \tilde{u}_{it}$$

4. Interpretar coeficientes

Mini-ejemplo FE

Datos:

$$Y_{i1} = 8, Y_{i2} = 12, \quad X_{i1} = 1, X_{i2} = 3$$

$$\bar{Y}_i = 10, \quad \bar{X}_i = 2$$

Desviaciones:

$$\tilde{Y}_1 = -2, \tilde{Y}_2 = 2$$

$$\tilde{X}_1 = -1, \tilde{X}_2 = 1$$

Estimación:

$$\hat{\beta} = \frac{4}{2} = 2$$

Interpretación: Cada incremento de 1 unidad en X dentro de la unidad aumenta Y en 2.

Estimador Between (Entre-Unidades)

El estimador *between* utiliza únicamente la variación **entre** unidades, es decir, compara promedios temporales de cada unidad. A diferencia del estimador Within (FE), que elimina la heterogeneidad inobservable c_i restando promedios, el estimador Between explota la variación *entre individuos*, por lo cual requiere un supuesto más fuerte:

$$E[c_i \mid \bar{X}_i] = 0.$$

Dado el modelo:

$$Y_{it} = X_{it}'\beta + c_i + u_{it},$$

primero se toman promedios temporales:

$$\bar{Y}_i = \frac{1}{T_i} \sum_t Y_{it}, \quad \bar{X}_i = \frac{1}{T_i} \sum_t X_{it}, \quad \bar{u}_i = \frac{1}{T_i} \sum_t u_{it}.$$

Al promediar en el tiempo se obtiene:

$$\bar{Y}_i = \bar{X}_i' \beta + c_i + \bar{u}_i.$$

El estimador Between se obtiene por MCO sobre esta regresión de promedios:

$$\hat{\beta}_{BE} = \left(\sum_{i=1}^N (\bar{X}_i - \bar{\bar{X}})' (\bar{X}_i - \bar{\bar{X}}) \right)^{-1} \left(\sum_{i=1}^N (\bar{X}_i - \bar{\bar{X}})' (\bar{Y}_i - \bar{\bar{Y}}) \right),$$

donde:

$$\bar{\bar{X}} = \frac{1}{N} \sum_{i=1}^N \bar{X}_i, \quad \bar{\bar{Y}} = \frac{1}{N} \sum_{i=1}^N \bar{Y}_i.$$

Interpretación: El estimador Between mide cómo varía Y entre unidades con distintos valores promedio de X en el tiempo. Es “corte transversal sobre promedios”.

Condición clave:

$$E[c_i | \bar{X}_i] = 0 \quad (\text{mucho más fuerte que FE}).$$

Si este supuesto falla, el estimador Between será sesgado incluso si FE es consistente.

Mini-ejemplo del estimador Between

Suponga tres unidades observadas en dos períodos, con los siguientes datos:

Unidad	Y_{i1}	Y_{i2}	X_{i1}	X_{i2}
1	8	12	1	3
2	4	10	0	2
3	15	18	4	5

1. Calcular promedios por unidad

$$\bar{Y}_1 = 10, \quad \bar{X}_1 = 2$$

$$\bar{Y}_2 = 7, \quad \bar{X}_2 = 1$$

$$\bar{Y}_3 = 16,5, \quad \bar{X}_3 = 4,5$$

2. Calcular promedios generales

$$\bar{\bar{Y}} = \frac{10 + 7 + 16,5}{3} = 11,17, \quad \bar{\bar{X}} = \frac{2 + 1 + 4,5}{3} = 2,5.$$

3. Regresión entre promedios

Construimos:

$$(\bar{X}_i - \bar{\bar{X}}) = [-0,5, -1,5, 2].$$

$$(\bar{Y}_i - \bar{\bar{Y}}) = [-1,17, -4,17, 5,33].$$

El coeficiente entre unidades:

$$\hat{\beta}_{BE} = \frac{(-0,5)(-1,17) + (-1,5)(-4,17) + (2)(5,33)}{(-0,5)^2 + (-1,5)^2 + (2)^2}.$$

$$\hat{\beta}_{BE} = \frac{0,585 + 6,255 + 10,66}{0,25 + 2,25 + 4} = \frac{17,5}{6,5} = 2,692.$$

Interpretación: Entre unidades, un incremento de 1 unidad en el valor promedio de X se asocia con un incremento de aproximadamente 2.69 unidades en el valor promedio de Y .

Comentario práctico: En ejercicios de panel, este valor suele diferir considerablemente del estimador Within, ya que incluyen heterogeneidad inobservable c_i , generando sesgo si c_i está correlacionado con $\bar{X}_i$.

Checklist para cualquier ejercicio

- ¿Identifiqué tratamiento y control?
- ¿Separé pre y post correctamente?
- ¿Construí la tabla adecuada (2×2 o $2 \times 2 \times 2$)?
- ¿Aplicué la fórmula de DD o DDD correspondiente?
- ¿Identifiqué la interacción en la regresión?
- ¿Interpreté signo, magnitud y unidades?
- ¿Comenté el supuesto de tendencia paralela?