

Econometría Aplicada: Análisis Profundo de Mínimos Cuadrados Ordinarios (MCO) y sus Fundamentos

Vicente Olea

Contenido basado en diapositivas del profesor Gonzalo Gaete del curso ICS2563 - Econometría Aplicada

Índice

1. El Modelo de Regresión Lineal (MRL) – Fundamentos	4
1.1. Introducción y objetivos	4
1.2. Definiciones y notación	4
2. Estimación del Modelo Simple (MRLS) – Tres vías	5
2.1. Vía 1: Esperanza de una Función Condicional Lineal (CEF)	5
2.2. Vía 2: Predicción insesgada	7
2.3. Vía 3: Mínimos Cuadrados Ordinarios (MCO)	8
2.4. Consideraciones clave: suma de residuos y ortogonalidad	9
2.5. Ejemplo numérico: “Temperature – Ice Sales”	9
3. Variables Binarias en MRLS y Derivaciones Alternativas	10
3.1. Regresión con variable explicativa binaria	10
3.2. Método de Momentos (MoM)	11
3.3. Máxima Verosimilitud (MV) y equivalencia con MCO	12
4. El MRLM y Álgebra Matricial	12
4.1. Notación y forma matricial	12
4.2. Residuos y suma de cuadrados de residuos (RSS)	13
4.3. Derivación matricial del estimador MCO	13
4.4. Condiciones de segundo orden	14
5. Interpretación de Coeficientes y Formas Funcionales	14
5.1. Interpretación ceteris paribus	14
5.2. Ejemplo aplicado (tratamiento contra el cáncer)	14

5.3. Modelos logarítmicos	14
5.4. No linealidad en variables, linealidad en parámetros	15
6. Variables Binarias (Dummies) e Interacciones	16
6.1. Variables binarias como regresores	16
6.2. Trampa de variables binarias (Dummy variable trap)	16
6.3. Múltiples dummies e interacciones entre dummies	16
6.4. Interacción con variables continuas	17
7. Supuestos y Álgebra de MCO	18
7.1. Supuestos clásicos del MRL	18
7.2. Matrices de proyección y aniquiladora	18
7.3. Teorema de Frisch–Waugh–Lovell (FWL)	19
8. Bondad de Ajuste: R^2 y $\bar{R}^2$	19
8.1. Descomposición $TSS = ESS + RSS$	19
8.2. Definición de R^2	20
8.3. R^2 ajustado	20
9. Propiedades del Estimador MCO y Gauss–Markov	20
9.1. Insesgadez (P1)	20
9.2. Consistencia	21
9.3. Matriz de varianzas-covarianzas (P2)	21
9.4. Teorema de Gauss–Markov (P3)	22
9.5. Estimación insesgada de σ^2 (P4)	22
10. Inferencia Estadística y Test de Hipótesis	23
10.1. Distribuciones χ^2 y t de Student	23
10.2. Distribución de $\hat{\beta}_j$ y estadístico t	23
10.3. Test de hipótesis	24
10.4. Ejemplo aplicado: retorno a la educación	24
10.5. Valor-p e intervalos de confianza	25
11. Problemas de Especificación y Endogeneidad	25
11.1. Inclusión de variable irrelevante	25
11.2. Omisión de variable relevante (OVR)	25
11.3. Error clásico de medida (ECM)	26
11.4. Simultaneidad (endogeneidad por determinación conjunta)	27

12.Problemas adicionales de datos (ejemplos aplicados)	27
12.1. Falacia ecológica y paradoja de Simpson	27
12.2. Sesgo de selección muestral posterior al tratamiento	27
13.Resumen y temas avanzados no cubiertos	28
13.1. Resumen	28
13.2. Temas avanzados no cubiertos	29

1. El Modelo de Regresión Lineal (MRL) – Fundamentos

1.1. Introducción y objetivos

El punto de partida de la econometría aplicada es el *modelo de regresión lineal* (MRL). En términos muy generales, la regresión lineal consiste en relacionar una variable de interés (variable dependiente, Y) con una o más variables explicativas o regresores ($X_1, \dots, X_k$), mediante una función lineal en los parámetros más un término de error.

En la práctica, el MRL suele utilizarse con tres objetivos principales:

1. **Resumir información compleja:** condensar la relación entre muchas variables en pocos parámetros (las β), permitiendo describir patrones y asociaciones.
2. **Predecir el futuro:** usar la relación estimada para pronosticar el valor de Y para nuevas observaciones de X (predicción fuera de la muestra).
3. **Analizar efectos causales de intervenciones:** estudiar qué le ocurre a Y cuando se modifica exógenamente X (por ejemplo, un programa, un tratamiento, una política).

Los dos primeros objetivos pueden lograrse bajo supuestos relativamente débiles (estabilidad temporal, regularidad estadística). El tercero, en cambio, requiere condiciones mucho más exigentes: en particular, que el mecanismo que genera los datos permita interpretar las diferencias en X como variación exógena (aleatoria o asimilable a tal). Toda la discusión sobre exogeneidad, sesgos de especificación, endogeneidad y validez de instrumentos apunta, precisamente, a legitimar esa interpretación causal.

1.2. Definiciones y notación

Sea $i = 1, \dots, N$ el índice de observación (individuos, firmas, comunas, etc.). Definimos:

- Variable dependiente: Y_i .
- Regresores o covariables: $X_{i1}, \dots, X_{ik}$.
- Vector de parámetros: $\beta = (\beta_1, \dots, \beta_k)'$.
- Término de error: ε_i , que recoge todos los factores no observados que afectan a Y_i y que no están explícitos en X_i .

Tres notaciones son útiles:

a) Notación por observación

$$y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \cdots + x_{ik}\beta_k + \varepsilon_i, \quad i = 1, \dots, N. \quad (1)$$

Si incluimos una constante, escribimos $x_{i1} = 1$ y β_1 representa el intercepto.

b) Notación vectorial (por fila)

Definimos el vector fila $x_i = (x_{i1}, \dots, x_{ik})$ y el vector columna de parámetros $\beta = (\beta_1, \dots, \beta_k)'$. Entonces:

$$y_i = x_i\beta + \varepsilon_i. \quad (2)$$

c) Notación matricial (MRLM)

Apilando las N observaciones en vectores y matrices:

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}_{N \times 1}, \quad X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1k} \\ x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Nk} \end{pmatrix}_{N \times k}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_N \end{pmatrix}_{N \times 1}. \quad (3)$$

La forma matricial compacta del modelo de regresión lineal múltiple es:

$$y = X\beta + \varepsilon. \quad (4)$$

Esta notación es clave para la derivación matricial de MCO, para el análisis de supuestos y para establecer propiedades asintóticas y de óptimo (Gauss–Markov).

2. Estimación del Modelo Simple (MRLS) – Tres vías

En el caso bivariado (un regresor y una constante) veremos tres caminos que conducen al mismo estimador MCO:

$$y_i = \beta_1 + \beta_2 x_i + u_i. \quad (5)$$

2.1. Vía 1: Esperanza de una Función Condicional Lineal (CEF)

Supondremos que la función de esperanza condicional poblacional de Y dado X es lineal:

$$m(x) := E[Y|X = x] = \beta_1 + \beta_2 x. \quad (6)$$

Esta es una afirmación sobre la población: en promedio, el valor esperado de Y para individuos con $X = x$ es una recta en x .

Tomando esperanza incondicional en ambos lados:

$$E[Y] = E[E(Y|X)] = E[\beta_1 + \beta_2 X] = \beta_1 + \beta_2 E[X]. \quad (7)$$

Definimos:

$$\mu_Y = E[Y], \quad \mu_X = E[X].$$

Entonces:

$$\mu_Y = \beta_1 + \beta_2 \mu_X. \quad (8)$$

Restando μ_Y a ambos lados de la CEF:

$$Y - \mu_Y = (\beta_1 + \beta_2 X + u) - \mu_Y \quad (9)$$

$$= \beta_2(X - \mu_X) + u. \quad (10)$$

Multiplicando por $(X - \mu_X)$ y tomando esperanza:

$$E[(Y - \mu_Y)(X - \mu_X)] = E[\beta_2(X - \mu_X)^2] + E[u(X - \mu_X)]. \quad (11)$$

Si definimos el error poblacional como

$$u = Y - E[Y|X],$$

entonces se cumple por construcción $E[u|X] = 0$ y, en particular, $E[u(X - \mu_X)] = 0$. De aquí:

$$\text{Cov}(Y, X) = \beta_2 \text{Var}(X). \quad (12)$$

Por lo tanto, el parámetro de pendiente poblacional es:

$$\boxed{\beta_2 = \frac{\text{Cov}(Y, X)}{\text{Var}(X)}}. \quad (13)$$

Este es exactamente el valor al cual convergen los estimadores de MCO cuando $N \rightarrow \infty$ bajo los supuestos clásicos.

2.2. Vía 2: Predicción insesgada

Partimos del modelo:

$$Y_i = \beta_1 + \beta_2 X_i + u_i,$$

y de un predictor lineal:

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i.$$

Queremos que el error de predicción promedio sea cero y que, además, el error sea ortogonal al regresor. A nivel poblacional:

$$E[Y - \hat{Y}] = 0, \quad (14)$$

$$E[(Y - \hat{Y})X] = 0. \quad (15)$$

En la muestra, reemplazamos expectativas por promedios:

$$\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i) = 0, \quad (16)$$

$$\frac{1}{N} \sum_{i=1}^N x_i (y_i - \hat{y}_i) = 0. \quad (17)$$

Multiplicando por N , obtenemos las condiciones de primer orden (CPOs) muestrales:

$$\sum_{i=1}^N (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i) = 0, \quad (18)$$

$$\sum_{i=1}^N x_i (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i) = 0. \quad (19)$$

La primera condición implica:

$$\sum y_i - N\hat{\beta}_1 - \hat{\beta}_2 \sum x_i = 0 \quad (20)$$

$$\Rightarrow \hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}. \quad (21)$$

Usando esto en (19):

$$\sum x_i(y_i - \bar{y} + \hat{\beta}_2\bar{x} - \hat{\beta}_2x_i) = 0 \quad (22)$$

$$\sum x_i(y_i - \bar{y}) + \hat{\beta}_2 \sum x_i(\bar{x} - x_i) = 0. \quad (23)$$

Nótese que:

$$\sum x_i(\bar{x} - x_i) = \bar{x} \sum x_i - \sum x_i^2 = N\bar{x}^2 - \sum x_i^2 = -\sum (x_i - \bar{x})^2.$$

También,

$$\sum x_i(y_i - \bar{y}) = \sum (x_i - \bar{x})(y_i - \bar{y}).$$

Sustituyendo:

$$\sum (x_i - \bar{x})(y_i - \bar{y}) - \hat{\beta}_2 \sum (x_i - \bar{x})^2 = 0. \quad (24)$$

Entonces:

$$\boxed{\hat{\beta}_2 = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2}} \quad (25)$$

y

$$\boxed{\hat{\beta}_1 = \bar{y} - \hat{\beta}_2\bar{x}.} \quad (26)$$

Estas dos ecuaciones son equivalentes a las obtenidas por MCO y garantizan que los errores muestrales cumplan:

$$\sum \hat{u}_i = 0, \quad \sum x_i \hat{u}_i = 0.$$

2.3. Vía 3: Mínimos Cuadrados Ordinarios (MCO)

El criterio de MCO define los estimadores como los valores de (β_1, β_2) que minimizan la suma de cuadrados de los residuos:

$$S(\beta_1, \beta_2) = \sum_{i=1}^N (y_i - \beta_1 - \beta_2 x_i)^2. \quad (27)$$

Tomamos derivadas parciales y las igualamos a cero:

Derivada respecto de β_1 :

$$\frac{\partial S}{\partial \beta_1} = \sum 2(y_i - \beta_1 - \beta_2 x_i)(-1) = -2 \sum (y_i - \beta_1 - \beta_2 x_i). \quad (28)$$

Igualando a cero:

$$\sum_{i=1}^N (y_i - \beta_1 - \beta_2 x_i) = 0. \quad (29)$$

Derivada respecto de β_2 :

$$\frac{\partial S}{\partial \beta_2} = \sum 2(y_i - \beta_1 - \beta_2 x_i)(-x_i) = -2 \sum x_i (y_i - \beta_1 - \beta_2 x_i). \quad (30)$$

Igualando a cero:

$$\sum_{i=1}^N x_i (y_i - \beta_1 - \beta_2 x_i) = 0. \quad (31)$$

Como se ve, las CPOs de MCO coinciden con las de predicción insesgada. Repitiendo el álgebra anterior llegamos a las mismas expresiones para $\hat{\beta}_1$ y $\hat{\beta}_2$.

2.4. Consideraciones clave: suma de residuos y ortogonalidad

Dos propiedades esenciales del estimador MCO bivariado son:

$$\sum_{i=1}^N \hat{u}_i = 0, \quad (32)$$

$$\sum_{i=1}^N x_i \hat{u}_i = 0. \quad (33)$$

La primera implica que la línea de regresión pasa por el punto $(\bar{x}, \bar{y})$; la segunda implica ortogonalidad muestral entre regresor y residuo, lo que en la práctica significa que no queda “información lineal” en X que permita predecir Y más allá de $\hat{y}$.

2.5. Ejemplo numérico: “Temperature – Ice Sales”

Consideremos el ejemplo en que y_i es el número de helados vendidos y x_i es la temperatura diaria. A partir de la tabla con sumas $\sum x_i$, $\sum y_i$, $\sum x_i^2$, $\sum x_i y_i$, se calculan:

$$\hat{\beta}_2 \approx 0,70, \quad \hat{\beta}_1 \approx -38,45.$$

La recta estimada es:

$$\widehat{\text{Ventas}} = -38,45 + 0,70 \text{ Temperatura.} \quad (34)$$

Interpretación: un aumento de un grado en la temperatura se asocia, en promedio, con un aumento de 0,70 unidades en las ventas de helados. El intercepto se interpreta como las ventas esperadas cuando la temperatura es cero (aquí no tiene necesariamente interpretación práctica, pero es requerido por la forma lineal).

3. Variables Binarias en MRLS y Derivaciones Alternativas

3.1. Regresión con variable explicativa binaria

Sea $T \in \{0, 1\}$ un indicador de tratamiento o pertenencia a un grupo (por ejemplo, tratado vs. control). Consideremos el modelo:

$$Y_i = \beta_0 + \beta_1 T_i + u_i. \quad (35)$$

Notemos que:

$$E[Y|T = 0] = \beta_0, \quad (36)$$

$$E[Y|T = 1] = \beta_0 + \beta_1. \quad (37)$$

Por lo tanto:

$$\beta_1 = E[Y|T = 1] - E[Y|T = 0], \quad \beta_0 = E[Y|T = 0]. \quad (38)$$

Es decir, en el caso con dummy, la regresión lineal simple está *exactamente* replicando la diferencia de medias entre tratados y no tratados.

Además, utilizando la varianza de una variable Bernoulli ($T \in \{0, 1\}$):

$$\text{Var}(T) = E[T](1 - E[T]) = p(1 - p), \quad (39)$$

y la covarianza $\text{Cov}(T, Y)$ se puede escribir como:

$$\text{Cov}(T, Y) = E[T](1 - E[T])\{E[Y|T = 1] - E[Y|T = 0]\}.$$

Por tanto:

$$\beta_1 = \frac{\text{Cov}(T, Y)}{\text{Var}(T)} = E[Y|T = 1] - E[Y|T = 0]. \quad (40)$$

3.2. Método de Momentos (MoM)

Partimos del modelo poblacional:

$$Y_i = X_i' \beta + u_i, \quad (41)$$

con $E[u_i|X_i] = 0$. Esto implica dos condiciones de momento poblacionales:

$$E[u_i] = 0, \quad (42)$$

$$E[X_i u_i] = 0. \quad (43)$$

Sustituyendo $u_i = Y_i - X_i' \beta$:

$$E[Y_i - X_i' \beta] = 0, \quad (44)$$

$$E[X_i(Y_i - X_i' \beta)] = 0. \quad (45)$$

Apilando en forma matricial, estas condiciones implican:

$$E[X'Y] = E[X'X]\beta. \quad (46)$$

El método de momentos consiste en reemplazar estas expectativas por sus análogos muestrales:

$$\frac{1}{N} X'Y \approx E[X'Y], \quad \frac{1}{N} X'X \approx E[X'X]. \quad (47)$$

De este modo, la ecuación de momentos muestral queda:

$$\frac{1}{N} X'Y = \frac{1}{N} X'X \hat{\beta} \Rightarrow X'X \hat{\beta} = X'Y. \quad (48)$$

Resolviendo:

$$\hat{\beta} = (X'X)^{-1} X'Y, \quad (49)$$

que coincide exactamente con el estimador MCO.

3.3. Máxima Verosimilitud (MV) y equivalencia con MCO

Suponemos ahora que el término de error cumple:

$$\varepsilon_i|X_i \sim N(0, \sigma^2) \quad \text{i.i.d.} \quad (50)$$

Entonces, condicional en X , Y es multivariadamente normal:

$$y|X \sim N(X\beta, \sigma^2 I_N). \quad (51)$$

La función de verosimilitud (condicional en X) es:

$$L(\beta, \sigma^2|y, X) = (2\pi\sigma^2)^{-N/2} \exp \left\{ -\frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta) \right\}. \quad (52)$$

La log-verosimilitud es:

$$\ell(\beta, \sigma^2) = -\frac{N}{2} \log(2\pi) - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta). \quad (53)$$

Maximizamos con respecto a β y σ^2 . Derivando respecto a β :

$$\frac{\partial \ell}{\partial \beta} = -\frac{1}{2\sigma^2} \cdot 2X'(y - X\beta) = -\frac{1}{\sigma^2} X'(y - X\beta). \quad (54)$$

Igualando a cero:

$$X'(y - X\beta) = 0 \quad \Rightarrow \quad X'X\beta = X'y. \quad (55)$$

Por tanto:

$$\hat{\beta}_{MV} = (X'X)^{-1}X'y = \hat{\beta}_{MCO}. \quad (56)$$

Es decir, con normalidad e independencia, MCO coincide con el estimador de máxima verosimilitud para β .

4. El MRLM y Álgebra Matricial

4.1. Notación y forma matricial

Reescribimos:

$$y = X\beta + \varepsilon, \quad (57)$$

con X de dimensión $N \times k$, usualmente con una primera columna de unos (intercepto) y las columnas restantes correspondientes a los regresores.

4.2. Residuos y suma de cuadrados de residuos (RSS)

Definimos la predicción lineal:

$$\hat{y} = X\hat{\beta}, \quad (58)$$

y el vector de residuos:

$$\hat{\varepsilon} = y - \hat{y} = y - X\hat{\beta}. \quad (59)$$

La suma de cuadrados de residuos es:

$$RSS(\beta) = \hat{\varepsilon}'\hat{\varepsilon} = (y - X\beta)'(y - X\beta). \quad (60)$$

4.3. Derivación matricial del estimador MCO

El problema es:

$$\min_{\beta} Q(\beta), \quad Q(\beta) := (y - X\beta)'(y - X\beta). \quad (61)$$

Expandiendo:

$$Q(\beta) = y'y - 2\beta'X'y + \beta'X'X\beta. \quad (62)$$

Derivamos con respecto a β :

$$\frac{\partial Q}{\partial \beta} = -2X'y + 2X'X\beta. \quad (63)$$

Igualando a cero:

$$X'X\beta = X'y. \quad (64)$$

Suponiendo que X tiene rango completo ($\text{rango}(X) = k$), entonces $X'X$ es invertible y obtenemos:

$$\boxed{\hat{\beta} = (X'X)^{-1}X'y.} \quad (65)$$

4.4. Condiciones de segundo orden

El hessiano de Q respecto de β es:

$$H = \frac{\partial^2 Q}{\partial \beta \partial \beta'} = 2X'X. \quad (66)$$

Si $X'X$ es definida positiva (lo que requiere que no haya colinealidad perfecta), entonces Q es estrictamente convexa y la solución de las CPOs es el mínimo global.

5. Interpretación de Coeficientes y Formas Funcionales

5.1. Interpretación ceteris paribus

En el modelo múltiple:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + u_i, \quad (67)$$

la interpretación *ceteris paribus* de β_j es:

$$\beta_j = \frac{\partial E[y_i | x_{i1}, \dots, x_{ik}]}{\partial x_{ij}} \quad (68)$$

si la relación poblacional es lineal. Es decir, β_j mide cuánto cambia el valor esperado de y cuando x_{ij} aumenta en una unidad, manteniendo fijas las demás covariables.

5.2. Ejemplo aplicado (tratamiento contra el cáncer)

Supongamos un modelo donde Y_i es un indicador de mejoría o supervivencia, y T_i es una variable de tratamiento (placebo vs. nuevo fármaco), junto con covariables como edad, sexo, etc. En una regresión simple Y sobre T , el coeficiente de T mide la diferencia de medias bruta entre tratados y controles.

En una regresión múltiple Y sobre T y edad, el coeficiente de T controla por edad. La interpretación *ceteris paribus* es: diferencia de supervivencia entre quienes reciben tratamiento y quienes no, *manteniendo constante* la edad. Si, además, se cumple exogeneidad, podemos darle interpretación causal.

5.3. Modelos logarítmicos

Modelo log-log

$$\ln Y = \beta_0 + \beta_1 \ln X + u. \quad (69)$$

En este caso, β_1 es una elasticidad: una variación de 1 % en X se asocia, aproximadamente, a una variación de β_1 % en Y .

Modelo log–nivel

$$\ln Y = \beta_0 + \beta_1 X + u. \quad (70)$$

Ante un cambio $\Delta X = 1$, el efecto en $\ln Y$ es β_1 . Como para cambios pequeños:

$$\Delta \ln Y \approx \frac{\Delta Y}{Y},$$

se interpreta que un incremento de una unidad en X está asociado a un cambio aproximado de $100\beta_1$ % en Y .

Ejemplo (CAsEN): si $\beta_1 = 0,054$ en la regresión $\ln(\text{salario})$ sobre años de escolaridad, entonces un año adicional de educación se asocia, en promedio, con un aumento de 5,4 % en el salario.

5.4. No linealidad en variables, linealidad en parámetros

La linealidad del MRL se refiere a los parámetros, no necesariamente a las variables. Por ejemplo:

$$\ln(\text{salario}_i) = \beta_0 + \beta_1 \text{edad}_i + \beta_2 \text{edad}_i^2 + u_i. \quad (71)$$

Este modelo es lineal en $\beta_0, \beta_1, \beta_2$, pese a ser no lineal en la variable edad. El efecto marginal de la edad sobre el log-salario es:

$$\frac{\partial \ln(\text{salario})}{\partial \text{edad}} = \beta_1 + 2\beta_2 \cdot \text{edad}. \quad (72)$$

Interpretado en porcentaje (para cambios pequeños en edad), el efecto en el salario es aproximadamente:

$$100(\beta_1 + 2\beta_2 \cdot \text{edad}) \%$$

por año adicional de edad. Por ejemplo, para una persona de 40 años, el efecto puede ser del orden de 1,68 % si los coeficientes estimados así lo indican.

6. Variables Binarias (Dummies) e Interacciones

6.1. Variables binarias como regresores

Considere una dummy D_i que vale 1 si la observación i pertenece a un grupo (por ejemplo, mujer) y 0 en caso contrario (hombre). El modelo:

$$Y_i = \beta_0 + \beta_1 D_i + u_i \quad (73)$$

genera dos rectas:

$$E[Y|D = 0] = \beta_0, \quad (74)$$

$$E[Y|D = 1] = \beta_0 + \beta_1. \quad (75)$$

Es decir, la dummy desplaza el intercepto, manteniendo constante la pendiente respecto de otros regresores.

6.2. Trampa de variables binarias (Dummy variable trap)

Si junto con una dummy D_i incluimos una constante, no podemos incluir la dummy complementaria $1 - D_i$ porque:

$$1 = D_i + (1 - D_i), \quad (76)$$

lo que implica colinealidad perfecta entre las columnas de la matriz X . En tal caso, $X'X$ no es invertible y el estimador MCO no está bien definido. La regla práctica es: con una variable categórica con g categorías, incluimos sólo $g - 1$ dummies (más la constante).

6.3. Múltiples dummies e interacciones entre dummies

Supongamos dos dummies: F_i (mujer) y C_i (casado). El modelo sin interacción:

$$Y_i = \beta_0 + \beta_1 F_i + \beta_2 C_i + u_i. \quad (77)$$

Genera cuatro medias condicionadas según las combinaciones (F, C) :

$$E[Y|F = 0, C = 0] = \beta_0, \quad (78)$$

$$E[Y|F = 1, C = 0] = \beta_0 + \beta_1, \quad (79)$$

$$E[Y|F = 0, C = 1] = \beta_0 + \beta_2, \quad (80)$$

$$E[Y|F = 1, C = 1] = \beta_0 + \beta_1 + \beta_2. \quad (81)$$

Si queremos permitir que el efecto de ser casado difiera entre hombres y mujeres, introducimos la interacción:

$$Y_i = \beta_0 + \beta_1 F_i + \beta_2 C_i + \beta_3 (F_i C_i) + u_i. \quad (82)$$

Ahora:

$$E[Y|F = 0, C = 0] = \beta_0, \quad (83)$$

$$E[Y|F = 1, C = 0] = \beta_0 + \beta_1, \quad (84)$$

$$E[Y|F = 0, C = 1] = \beta_0 + \beta_2, \quad (85)$$

$$E[Y|F = 1, C = 1] = \beta_0 + \beta_1 + \beta_2 + \beta_3. \quad (86)$$

El parámetro β_3 mide la diferencia en el efecto de casarse entre hombres y mujeres (una “doble diferencia”).

6.4. Interacción con variables continuas

Supongamos el modelo:

$$\ln(\text{salario}_i) = \beta_0 + \beta_1 \text{esc}_i + \beta_2 F_i + \beta_3 (\text{esc}_i \cdot F_i) + u_i, \quad (87)$$

donde esc_i es años de escolaridad y F_i es dummy mujer. Para hombres ($F_i = 0$):

$$\ln(\text{salario}|F = 0) = \beta_0 + \beta_1 \text{esc}. \quad (88)$$

Para mujeres ($F_i = 1$):

$$\ln(\text{salario}|F = 1) = (\beta_0 + \beta_2) + (\beta_1 + \beta_3) \text{esc}. \quad (89)$$

La interacción permite tanto interceptos como pendientes diferenciados por género.

7. Supuestos y Álgebra de MCO

7.1. Supuestos clásicos del MRL

Consideramos el modelo $y = X\beta + \varepsilon$ con N observaciones y k regresores. Los supuestos estándar (en la versión utilizada en el curso) son:

- S1 **Linealidad en parámetros:** el modelo puede escribirse como $y = X\beta + \varepsilon$.
- S2 **Rango completo (no colinealidad perfecta):** las columnas de X son linealmente independientes, lo que implica que $X'X$ es invertible.
- S3 **Exogeneidad estricta:** $E[\varepsilon|X] = 0$.
- S4 **Homoscedasticidad e incorrelación:** $E[\varepsilon\varepsilon'|X] = \sigma^2 I_N$ (errores esféricos).
- S6 **Normalidad:** $\varepsilon|X \sim N(0, \sigma^2 I_N)$.

S3 asegura insesgadez, S3–S4 características de varianza mínima (Gauss–Markov), y S6 entrega exactitud finita de la inferencia basada en distribución t y χ^2 .

7.2. Matrices de proyección y aniquiladora

Definimos:

$$P = X(X'X)^{-1}X' \quad (\text{matriz de proyección sobre el espacio columna de } X), \quad (90)$$

$$M = I_N - P \quad (\text{matriz aniquiladora o residual maker}). \quad (91)$$

Propiedades clave:

- $P^2 = P$ e $M^2 = M$ (idempotencia).
- $P' = P$ y $M' = M$ (simetría).
- $PX = X$ y $MX = 0$.
- $\hat{y} = Py$ y $\hat{\varepsilon} = My$.
- y se descompone como $y = \hat{y} + \hat{\varepsilon} = Py + My$ en componentes ortogonales.

De estas propiedades se desprende la descomposición de sumas de cuadrados que da origen al R^2 .

7.3. Teorema de Frisch–Waugh–Lovell (FWL)

Supongamos que $X = [X_1 \ X_2]$, donde X_1 es un conjunto de control y X_2 la variable de interés. El modelo es:

$$y = X_1\beta_1 + X_2\beta_2 + \varepsilon. \quad (92)$$

El teorema de FWL afirma que el estimador de β_2 que se obtiene de la regresión conjunta es igual al estimador obtenido en dos pasos:

1. Regresar y sobre X_1 y guardar los residuos y^* .
2. Regresar cada columna de X_2 sobre X_1 y guardar los residuos X_2^* .
3. Regresar y^* sobre X_2^* por MCO; los coeficientes son exactamente $\hat{\beta}_2$ de la regresión original.

En forma matricial:

$$\hat{\beta}_2 = (X_2^{*'} X_2^*)^{-1} X_2^{*'} y^*, \quad (93)$$

donde $y^* = M_1 y$ y $X_2^* = M_1 X_2$, con $M_1 = I - X_1(X_1' X_1)^{-1} X_1'$.

Interpretación: el efecto parcial de X_2 sobre y (controlando por X_1) es el efecto de la parte de X_2 no explicable por X_1 sobre la parte de y no explicable por X_1 .

8. Bondad de Ajuste: R^2 y $\bar{R}^2$

8.1. Descomposición $TSS = ESS + RSS$

Sea $\bar{y}$ el promedio muestral de y . Definimos:

$$TSS = \sum_{i=1}^N (y_i - \bar{y})^2, \quad (94)$$

$$RSS = \sum_{i=1}^N \hat{\varepsilon}_i^2 = (y - X\hat{\beta})'(y - X\hat{\beta}), \quad (95)$$

$$ESS = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2. \quad (96)$$

En notación matricial, usando la matriz de proyección asociada sólo a la constante se puede mostrar:

$$TSS = ESS + RSS. \quad (97)$$

8.2. Definición de R^2

El coeficiente de determinación es:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}. \quad (98)$$

Mide la proporción de la variabilidad total de y alrededor de su media que es explicada (en el sentido de cuadrados) por el modelo. Sin embargo, R^2 *nunca disminuye* cuando se agregan regresores, incluso si son irrelevantes.

8.3. R^2 ajustado

El R^2 ajustado corrige por el número de regresores. Se define como:

$$\bar{R}^2 = 1 - \frac{RSS/(N - k)}{TSS/(N - 1)}. \quad (99)$$

Aquí $N - k$ es el número de grados de libertad en la regresión (errores) y $N - 1$ el de la variación total. A diferencia de R^2 , el R^2 ajustado puede disminuir al agregar regresores que no aportan suficiente reducción en el RSS.

9. Propiedades del Estimador MCO y Gauss–Markov

9.1. Insensatez (P1)

Recordemos:

$$\hat{\beta} = (X'X)^{-1}X'y. \quad (100)$$

Sustituyendo $y = X\beta + \varepsilon$:

$$\hat{\beta} = (X'X)^{-1}X'(X\beta + \varepsilon) \quad (101)$$

$$= (X'X)^{-1}X'X\beta + (X'X)^{-1}X'\varepsilon \quad (102)$$

$$= \beta + (X'X)^{-1}X'\varepsilon. \quad (103)$$

Tomamos esperanza condicional en X :

$$E[\hat{\beta}|X] = \beta + (X'X)^{-1}X'E[\varepsilon|X]. \quad (104)$$

Bajo el supuesto S3 ($E[\varepsilon|X] = 0$):

$$E[\hat{\beta}|X] = \beta. \quad (105)$$

Por lo tanto, $\hat{\beta}$ es un estimador insesgado de β .

9.2. Consistencia

De la expresión anterior:

$$\hat{\beta} - \beta = (X'X)^{-1}X'\varepsilon. \quad (106)$$

Dividiendo y multiplicando por N :

$$\hat{\beta} - \beta = \left(\frac{X'X}{N}\right)^{-1} \left(\frac{X'\varepsilon}{N}\right). \quad (107)$$

Si se cumple que:

$$\frac{X'X}{N} \xrightarrow{p} Q_{xx}, \quad \text{positiva definida,} \quad (108)$$

$$\frac{X'\varepsilon}{N} \xrightarrow{p} 0, \quad (109)$$

por Ley de los Grandes Números, entonces por el Teorema de Slutsky:

$$\hat{\beta} \xrightarrow{p} \beta. \quad (110)$$

Es decir, MCO es un estimador consistente bajo las condiciones usuales (exogeneidad, momentos finitos, estabilidad en la matriz de momentos de X).

9.3. Matriz de varianzas-covarianzas (P2)

Consideramos:

$$\hat{\beta} - \beta = (X'X)^{-1}X'\varepsilon. \quad (111)$$

Tomando varianza condicional en X :

$$\text{Var}(\hat{\beta}|X) = (X'X)^{-1}X'\text{Var}(\varepsilon|X)X(X'X)^{-1}. \quad (112)$$

Bajo S4 ($\text{Var}(\varepsilon|X) = \sigma^2 I_N$):

$$\boxed{\text{Var}(\hat{\beta}|X) = \sigma^2(X'X)^{-1}.} \quad (113)$$

9.4. Teorema de Gauss–Markov (P3)

Sea $\hat{\beta}$ el estimador MCO y $\tilde{\beta}$ un estimador lineal e insesgado:

$$\tilde{\beta} = Ay, \quad \text{con } A \in \mathbb{R}^{k \times N},$$

tal que $E[\tilde{\beta}|X] = \beta$.

La linealidad en y implica linealidad en ε :

$$\tilde{\beta} - \beta = A\varepsilon.$$

La insesgadez implica:

$$E[\tilde{\beta}|X] = A(X\beta) = \beta \quad \Rightarrow \quad AX = I_k.$$

El estimador MCO puede escribirse como:

$$\hat{\beta} = (X'X)^{-1}X'y = A_{\text{MCO}}y, \quad \text{con } A_{\text{MCO}} = (X'X)^{-1}X'.$$

Se puede mostrar que para cualquier A tal que $AX = I_k$, se cumple:

$$A = A_{\text{MCO}} + C,$$

donde $CX = 0$. Para la varianza:

$$\text{Var}(\tilde{\beta}|X) = \sigma^2 AA' \tag{114}$$

$$= \sigma^2(A_{\text{MCO}} + C)(A_{\text{MCO}} + C)' \tag{115}$$

$$= \sigma^2 A_{\text{MCO}} A_{\text{MCO}}' + \sigma^2 CC' + 2\sigma^2 A_{\text{MCO}} C'. \tag{116}$$

Utilizando las restricciones $CX = 0$ y $AX = I_k$ se puede ver que el término cruzado desaparece, y queda:

$$\text{Var}(\tilde{\beta}|X) - \text{Var}(\hat{\beta}|X) = \sigma^2 CC' \tag{117}$$

que es una matriz semidefinida positiva. Por tanto, ningún otro estimador lineal insesgado tiene varianza menor que MCO en el sentido de matrices (orden de Loewner). MCO es el *Mejor Estimador Lineal Insesgado* (MELI o BLUE).

9.5. Estimación insesgada de σ^2 (P4)

Recordemos que:

$$RSS = \hat{\varepsilon}'\hat{\varepsilon} = (My)'(My) = y'My.$$

Tomando esperanza condicional en X :

$$E[RSS|X] = E[\varepsilon' M \varepsilon | X] \quad (118)$$

$$= \text{tr}(M E[\varepsilon \varepsilon' | X]) \quad (119)$$

$$= \text{tr}(M \sigma^2 I_N) = \sigma^2 \text{tr}(M). \quad (120)$$

La traza de M es igual al número de grados de libertad de los errores: $N - k$, donde k es el número de regresores (incluida la constante). Por tanto:

$$E[RSS|X] = \sigma^2(N - k). \quad (121)$$

El estimador:

$$\boxed{\hat{\sigma}^2 = \frac{RSS}{N - k}} \quad (122)$$

es insesgado para σ^2 .

10. Inferencia Estadística y Test de Hipótesis

10.1. Distribuciones χ^2 y t de Student

Si $Z \sim N(0, 1)$, entonces Z^2 tiene distribución χ^2 con 1 grado de libertad. Más generalmente, si $Z_1, \dots, Z_m$ son i.i.d. $N(0, 1)$, entonces:

$$\sum_{j=1}^m Z_j^2 \sim \chi_m^2. \quad (123)$$

La distribución t surge como el cociente entre una normal y la raíz de un χ^2 independiente:

$$T = \frac{Z}{\sqrt{V/m}}, \quad Z \sim N(0, 1), \quad V \sim \chi_m^2, \quad Z \perp V \quad \Rightarrow \quad T \sim t_m. \quad (124)$$

10.2. Distribución de $\hat{\beta}_j$ y estadístico t

Bajo S3, S4 y S6, se tiene:

$$\hat{\beta} | X \sim N(\beta, \sigma^2(X'X)^{-1}). \quad (125)$$

El elemento j -ésimo de $\hat{\beta}$ cumple:

$$\hat{\beta}_j | X \sim N(\beta_j, \sigma^2 v_{jj}), \quad (126)$$

donde v_{jj} es la componente (j, j) de $(X'X)^{-1}$.

Si reemplazamos σ^2 por su estimador $\hat{\sigma}^2$ (independiente de $\hat{\beta}$ bajo normalidad), el estadístico:

$$t_j = \frac{\hat{\beta}_j - \beta_{j,0}}{\sqrt{\hat{\sigma}^2 v_{jj}}} \quad (127)$$

sigue una distribución t con $N - k$ grados de libertad, bajo la hipótesis nula $H_0 : \beta_j = \beta_{j,0}$.

10.3. Test de hipótesis

Queremos contrastar:

$$H_0 : \beta_j = \beta_{j,0}, \quad (128)$$

$$H_1 : \begin{cases} \beta_j > \beta_{j,0} & (\text{test unilateral derecha}), \\ \beta_j < \beta_{j,0} & (\text{test unilateral izquierda}), \\ \beta_j \neq \beta_{j,0} & (\text{test bilateral}). \end{cases} \quad (129)$$

La regla de rechazo se basa en el valor crítico de la distribución t o en el valor-p asociado a t_j .

10.4. Ejemplo aplicado: retorno a la educación

Supongamos que en CASEN 2017 se estima:

$$\ln(\text{salario}) = \beta_0 + \beta_1 \text{escolaridad} + u,$$

y se quiere testear:

$$H_0 : \beta_1 = 0,045, \quad (130)$$

$$H_1 : \beta_1 > 0,045. \quad (131)$$

Se calcula:

$$t_1 = \frac{\hat{\beta}_1 - 0,045}{\sqrt{\hat{\sigma}^2 v_{11}}}.$$

Si, por ejemplo, $t_1 = 3,72$ y el valor crítico al 5 % para un test unilateral es aproximadamente 1,64, se rechaza H_0 y se concluye que el retorno es mayor a 4.5 %.

10.5. Valor-p e intervalos de confianza

El *valor-p* es la probabilidad, bajo H_0 , de obtener un valor del estadístico tan extremo o más extremo que el observado. Para un test bilateral:

$$p\text{-value} = 2P(|T_{N-k}| \geq |t_j|).$$

Un intervalo de confianza $(1 - \alpha) \times 100\%$ para β_j se obtiene de:

$$\hat{\beta}_j \pm t_{1-\alpha/2, N-k} \sqrt{\hat{\sigma}^2 v_{jj}}.$$

11. Problemas de Especificación y Endogeneidad

11.1. Inclusión de variable irrelevante

Modelo verdadero (restringido):

$$Y_i = \beta_0 + \beta_1 X_{1i} + u_i.$$

Modelo estimado (completo) con variable irrelevante X_{2i} (verdaderamente $\beta_2 = 0$):

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i.$$

Se puede mostrar que $\hat{\beta}_1$ sigue siendo insesgado para β_1 , pero su varianza es mayor que la del modelo restringido. Intuitivamente, se han usado grados de libertad para estimar un parámetro que es en realidad cero (ruido puro), lo que disminuye precisión.

11.2. Omisión de variable relevante (OVR)

Modelo verdadero:

$$Y_i = \beta_0 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i. \tag{132}$$

Modelo estimado (que omite X_3):

$$Y_i = \alpha_0 + \alpha_2 X_{2i} + v_i, \tag{133}$$

donde $v_i = \beta_3 X_{3i} + u_i$. El estimador MCO de α_2 satisface:

$$\hat{\alpha}_2 \approx \beta_2 + \beta_3 \frac{\text{Cov}(X_2, X_3)}{\text{Var}(X_2)}. \quad (134)$$

Por tanto:

$$E[\hat{\alpha}_2 | X_2, X_3] = \beta_2 + \beta_3 \frac{\text{Cov}(X_2, X_3)}{\text{Var}(X_2)}. \quad (135)$$

El sesgo es cero sólo si $\beta_3 = 0$ (la variable omitida no tiene efecto) o si $\text{Cov}(X_2, X_3) = 0$ (no hay correlación entre el regresor incluido y el omitido). El signo del sesgo depende del signo de β_3 y de la correlación entre X_2 y X_3 .

Ejemplo clásico: retorno a la educación, donde se omite la *habilidad*. Si la habilidad aumenta tanto la educación como el salario, se induce un sesgo positivo en el estimador de la educación.

11.3. Error clásico de medida (ECM)

Error en la variable dependiente

Supongamos que observamos $Y_i^* = Y_i + \nu_i$, donde ν_i es error de medida clásico (independiente de X y de u_i). Reemplazar Y por Y^* en la regresión genera:

$$Y_i^* = X_i' \beta + (u_i + \nu_i).$$

El estimador de β sigue siendo insesgado, pero la varianza del error aumenta, lo que genera pérdida de precisión (intervalos más anchos).

Error en los regresores

Si X_i está medido con error: $X_i^* = Z_i + w_i$ donde Z_i es la verdadera variable y w_i el error de medición clásico, y el modelo verdadero es:

$$Y_i = \alpha + \beta Z_i + v_i, \quad (136)$$

pero estimamos:

$$Y_i = \alpha^* + \beta^* X_i^* + \text{error}, \quad (137)$$

se puede demostrar que:

$$\text{plim } \hat{\beta}^* = \beta \left(\frac{\sigma_Z^2}{\sigma_Z^2 + \sigma_w^2} \right), \quad (138)$$

donde σ_Z^2 es la varianza de Z y σ_w^2 la del error de medida. El factor multiplicativo está

entre 0 y 1, de modo que el sesgo es hacia cero (sesgo de atenuación). Este problema es grave en variables como ingreso, patrimonio o capital humano medidas con error.

11.4. Simultaneidad (endogeneidad por determinación conjunta)

Considere dos ecuaciones estructurales simples:

$$Y_1 = \alpha_1 + \gamma Y_2 + \delta' Z_1 + u_1, \quad (139)$$

$$Y_2 = \alpha_2 + \pi Y_1 + \theta' Z_2 + u_2, \quad (140)$$

donde Z_1, Z_2 son variables exógenas. Aquí Y_1 y Y_2 se determinan simultáneamente. Si se intenta estimar la ecuación de Y_1 por MCO usando Y_2 como regresor, Y_2 estará correlacionado con u_1 (porque Y_2 depende de u_2 , que a su vez está correlacionado con u_1 a través del sistema).

Puede demostrarse que:

$$\text{plim } \hat{\gamma} = \gamma + \frac{\text{Cov}(Y_2, u_1)}{\text{Var}(Y_2)}.$$

Si $\text{Cov}(Y_2, u_1) \neq 0$, el estimador es inconsistente. Este es el problema clásico de simultaneidad (por ejemplo, crimen y policía, oferta y demanda, etc.) y motiva el uso de variables instrumentales.

12. Problemas adicionales de datos (ejemplos aplicados)

12.1. Falacia ecológica y paradoja de Simpson

La falacia ecológica ocurre cuando se infieren conclusiones a nivel individual usando datos agregados. La paradoja de Simpson muestra que una relación que aparece en datos agregados puede invertirse al desagregar por grupos relevantes.

Ejemplo típico: admisiones en una universidad por género. A nivel total puede parecer que hay discriminación contra las mujeres (menor tasa de admisión), pero al separar por facultad se observa que las mujeres postulan más a programas altamente competitivos y son aceptadas en mayor proporción dentro de cada facultad. El error es interpretar la asociación agregada como evidencia de discriminación sin controlar por la composición de las postulaciones (dificultad del programa).

12.2. Sesgo de selección muestral posterior al tratamiento

Este sesgo aparece cuando la muestra utilizada para estimar el efecto de un tratamiento está condicionada por una variable que es resultado (directo o indirecto) del tratamiento.

Ejemplo: discriminación racial en detenciones policiales. Si sólo observamos a quienes fueron controlados (y, dentro de ellos, quién fue multado), los coeficientes de una regresión de multa sobre raza y otras variables pueden estar sesgados, porque la muestra de “controlados” ya refleja decisiones previas de la policía que pueden ser discriminatorias. Es decir, el proceso de selección en la muestra ya incorpora el sesgo que queremos estudiar.

13. Resumen y temas avanzados no cubiertos

13.1. Resumen

En este capítulo hemos:

- Presentado el modelo de regresión lineal (simple y múltiple) en notación escalar, vectorial y matricial.
- Derivado el estimador de MCO por tres vías (CEF, predicción insesgada y minimización de la suma de cuadrados).
- Analizado el caso de variables binarias, mostrando su equivalencia con diferencias de medias y su relación con covarianza y varianza.
- Mostrado el vínculo entre MCO, métodos de momentos y máxima verosimilitud (bajo normalidad).
- Introducido el MRLM, la notación matricial, las matrices de proyección y aniquiladora, y el teorema de Frisch–Waugh–Lovell.
- Definido medidas de bondad de ajuste (R^2 , $\bar{R}^2$) y su interpretación.
- Demostrado las propiedades clave del estimador MCO: insesgadez, consistencia, varianza, y óptimo de Gauss–Markov, así como la estimación insesgada de σ^2 .
- Desarrollado la inferencia estadística basada en las distribuciones t y χ^2 , incluyendo tests de hipótesis e intervalos de confianza.
- Discutido problemas de especificación (inclusión de variables irrelevantes, omisión de variables relevantes) y formas de endogeneidad (error de medida, simultaneidad).
- Ilustrado problemas adicionales de datos, como la falacia ecológica y el sesgo de selección post tratamiento.

13.2. Temas avanzados no cubiertos

Más allá del MRL y MCO, la econometría moderna trabaja con extensiones y generalizaciones que requieren técnicas adicionales:

- Relajación de los supuestos clásicos (heteroscedasticidad, autocorrelación, formas generales de dependencia).
- Teoría asintótica avanzada y estimadores robustos.
- Métodos de Momentos Generalizados (GMM).
- Modelos de elección discreta (logit, probit, multinomial).
- Modelos de conteo, duración y censura.
- Series de tiempo (ARMA, VAR, cointegración).
- Modelos de datos de panel con efectos fijos y aleatorios.

Estos temas se apoyan en los fundamentos establecidos aquí: notación matricial, MCO, supuestos, propiedades y problemas de especificación, que constituyen la base de la econometría aplicada moderna.