

Econometría Aplicada: Causalidad, Sesgo y Diseños de Investigación

Vicente Olea

Contenido basado en diapositivas del profesor Gonzalo Gaete del curso ICS2563 - Econometría Aplicada

Índice

1. Repaso: Sesgo de Variable Omitida (OVB)	3
1.1. Modelo poblacional y modelo estimado	3
1.2. Derivación matricial del sesgo por omisión	3
1.3. Interpretación vía Frisch–Waugh–Lovell	4
1.4. Sesgo en términos de covarianza y varianza parcial	4
2. El Problema de la Endogeneidad	5
2.1. Definición general	5
2.2. Canales clásicos de endogeneidad	5
2.3. Ejemplo: Crimen y encarcelamiento	6
2.3.1. Forma reducida de $prison_t$ y covarianza crítica	6
2.3.2. Sesgo del estimador MCO de α_1	7
3. Marco de Resultados Potenciales (Neyman–Rubin)	8
3.1. Notación básica de resultados potenciales	8
3.2. Problema Fundamental de la Inferencia Causal	8
3.3. ATE y TOT	9
3.4. Descomposición de la diferencia de medias observada	9
4. Experimentos Aleatorios Controlados (RCT)	10
4.1. Aleatorización y contrafactual válido	10
4.2. Estimación del ATE mediante MCO	10

4.2.1.	Mejora de precisión con controles	11
4.3.	Supuesto SUTVA	11
4.4.	TOT (Treatment on the Treated) en RCT	12
4.5.	Consideraciones éticas: Informe Belmont y límites	12
5.	Diseño Observacional y Función Condicional Esperada (CEF)	13
5.1.	Diseños basados en observables y no observables	13
5.2.	Selección en observables: supuestos clave	13
5.3.	Función Condicional Esperada (CEF)	14
5.4.	Tres razones para usar regresión lineal (Angrist)	14
5.5.	Anatomía de una regresión multivariable	15
6.	Ejemplos de Diseño de Investigación y Aplicaciones	16
6.1.	Experimentos naturales: John Snow y el cólera en Londres	16
6.1.1.	Contexto histórico e hipótesis causales	16
6.1.2.	Evidencia cuantitativa: Tabla IX de Snow	17
6.1.3.	Interpretación causal	17
6.2.	Ejemplo de discriminación en orquestas (Amaral et al., 2022)	18
6.2.1.	Modelo lineal con efectos fijos	18
6.2.2.	Efectos fijos individuales y comparación dentro de persona	19
6.2.3.	Interpretación causal en términos de diseño	19

1. Repaso: Sesgo de Variable Omitida (OVV)

1.1. Modelo poblacional y modelo estimado

Considere el modelo de datos generador (DGP) lineal:

$$y = X\beta + z\gamma + \epsilon, \quad (1)$$

donde:

- y es un vector $n \times 1$ de resultados observados.
- X es una matriz $n \times k$ de regresores incluidos en la regresión.
- z es una variable (o vector columna) $n \times 1$ relevante para explicar y , que en el DGP aparece con parámetro estructural γ .
- ϵ es el término de error estructural, con $E[\epsilon|X, z] = 0$.

En la práctica, el investigador omite z y estima el modelo simplificado:

$$y = X\beta + \varphi, \quad (2)$$

donde $\varphi = z\gamma + \epsilon$ agrupa tanto la parte omitida como el error idiosincrático original.

1.2. Derivación matricial del sesgo por omisión

El estimador MCO de β en el modelo (2) es:

$$\hat{\beta} = (X'X)^{-1}X'y. \quad (3)$$

Sustituyendo la verdadera ecuación (1) en y :

$$\hat{\beta} = (X'X)^{-1}X'(X\beta + z\gamma + \epsilon) \quad (4)$$

$$= (X'X)^{-1}(X'X)\beta + (X'X)^{-1}X'(z\gamma) + (X'X)^{-1}X'\epsilon \quad (5)$$

$$= \beta + (X'X)^{-1}X'z\gamma + (X'X)^{-1}X'\epsilon. \quad (6)$$

Por lo tanto, el valor esperado condicional en (X, z) es:

$$E[\hat{\beta} | X, z] = \beta + (X'X)^{-1}X'z\gamma + (X'X)^{-1}X'E[\epsilon | X, z] \quad (7)$$

$$= \beta + (X'X)^{-1}X'z\gamma, \quad (8)$$

ya que $E[\epsilon \mid X, z] = 0$ por definición del DGP.

Definimos:

$$p_{X,z} := (X'X)^{-1}X'z, \quad (9)$$

de modo que:

$$E[\hat{\beta} \mid X, z] = \beta + p_{X,z} \gamma. \quad (10)$$

1.3. Interpretación vía Frisch–Waugh–Lovell

El vector $p_{X,z}$ corresponde al vector de coeficientes de la regresión de z sobre X :

$$z = Xp_{X,z} + u_z, \quad E[u_z \mid X] = 0. \quad (11)$$

Esto es una aplicación directa del Teorema de Frisch–Waugh–Lovell (FWL): proyectar z en el espacio generado por X produce la mejor aproximación lineal $Xp_{X,z}$.

La ecuación (10) nos dice que el sesgo en $\hat{\beta}$ depende de:

- el efecto causal de z sobre y , dado por γ , y
- la manera en que z se correlaciona con los regresores incluidos X , capturada por $p_{X,z}$.

1.4. Sesgo en términos de covarianza y varianza parcial

Para entender el sesgo en el k -ésimo coeficiente, β_k , consideremos el caso en que X contiene la constante y $k - 1$ regresores adicionales. Sea x_k la columna de X asociada al parámetro de interés β_k .

El resultado estándar de anatomía de la regresión (derivado también de FWL) establece que el estimador parcial para β_k puede escribirse como:

$$\hat{\beta}_k = \beta_k + \gamma \frac{\text{Cov}(z, x_k \mid \text{todos los otros } x)}{\text{Var}(x_k \mid \text{todos los otros } x)} + \text{error de muestreo}. \quad (12)$$

Tomando esperanza condicional se obtiene:

$$E[\hat{\beta}_k \mid X, z] = \beta_k + \gamma \frac{\text{Cov}(z, x_k \mid \text{todos los otros } x)}{\text{Var}(x_k \mid \text{todos los otros } x)}. \quad (13)$$

La fracción

$$\frac{\text{Cov}(z, x_k \mid \text{otros } x)}{\text{Var}(x_k \mid \text{otros } x)}$$

corresponde a la pendiente de la regresión de z sobre el residuo de x_k una vez eliminado el efecto lineal del resto de regresores. La intuición clave es:

- Si z y x_k están correlacionados condicionalmente a los demás regresores, entonces omitir z desplaza el coeficiente de x_k en la dirección del efecto de z sobre y (signo de γ).
- El sesgo será mayor cuanto más fuerte sea la correlación parcial entre z y x_k .
- Si z es irrelevante ($\gamma = 0$) o si z es ortogonal a x_k condicionalmente a los demás regresores, el sesgo desaparece.

2. El Problema de la Endogeneidad

2.1. Definición general

Llamamos *sesgo de endogeneidad* a todos los problemas en los que el término de error estimado en el modelo de regresión captura parte del DGP que no está incluida explícita y correctamente en el conjunto de regresores. En notación:

$$y_i = x_i' \beta + u_i, \quad E[u_i | x_i] \neq 0. \quad (14)$$

En estos casos, Mínimos Cuadrados Ordinarios (MCO) deja de estimar sin sesgo el parámetro estructural β : la condición clave de exogeneidad $E[u_i | x_i] = 0$ se viola. En otras palabras:

- MCO entrega una interpretación causal válida sólo para variables *exógenas*, es decir, regresores cuya variación no está determinada, directa ni indirectamente, por el término de error.
- Siempre que una parte del mecanismo causal relevante quede absorbida por el error y se correlacione con los regresores, aparece endogeneidad.

2.2. Canales clásicos de endogeneidad

Los principales canales pueden escribirse como casos particulares de variable omitida:

1. Variable omitida relevante:

- Existe un factor z que afecta y (con parámetro $\gamma \neq 0$) y que está correlacionado con x_k .

- Omitir z induce sesgo según (13).

2. Causalidad reversa:

- La variable explicativa x es a su vez afectada por el resultado y .
- En un modelo reducido $y = \beta x + u$, el componente “ $y \rightarrow x$ ” queda escondido dentro de u , generando correlación entre x y u .
- Se puede reinterpretar como un problema de omisión de las ecuaciones que determinan x .

3. Simultaneidad:

- y y x son variables jointly determinadas por un sistema de ecuaciones estructurales.
- La observación de equilibrio mezcla las direcciones causales, de modo que una regresión reducida de y en x recoge efectos en ambas direcciones.

En todos los casos, la esencia es que el regresor x contiene, directa o indirectamente, información sobre el término de error estructural.

2.3. Ejemplo: Crimen y encarcelamiento

Considere el problema de estimar el efecto de la tasa de encarcelamiento ($prison_t$) sobre la tasa de crimen ($crime_t$):

$$crime_t = \alpha_0 + \alpha_1 prison_t + \epsilon_t, \quad (15)$$

$$prison_t = \beta_0 + \beta_1 crime_t + \beta_2 X_t + \nu_t, \quad (16)$$

donde X_t es un conjunto de variables exógenas (por ejemplo, condiciones socioeconómicas o reglas de política).

El parámetro de interés es α_1 , que recoge el efecto causal de la tasa de encarcelamiento sobre el crimen (efecto de incapacitación y/o disuasión). Sin embargo, la ecuación (16) muestra que $prison_t$ es *endógeno*: depende a su vez de $crime_t$.

2.3.1. Forma reducida de $prison_t$ y covarianza crítica

Sustituyendo (15) en (16):

$$prison_t = \beta_0 + \beta_1(\alpha_0 + \alpha_1 prison_t + \epsilon_t) + \beta_2 X_t + \nu_t \quad (17)$$

$$= \beta_0 + \beta_1 \alpha_0 + \beta_1 \alpha_1 prison_t + \beta_1 \epsilon_t + \beta_2 X_t + \nu_t. \quad (18)$$

Reordenando términos en $prison_t$:

$$prison_t(1 - \beta_1 \alpha_1) = \beta_0 + \beta_1 \alpha_0 + \beta_1 \epsilon_t + \beta_2 X_t + \nu_t. \quad (19)$$

Por tanto,

$$prison_t = \frac{\beta_0 + \beta_1 \alpha_0 + \beta_2 X_t + \nu_t}{1 - \beta_1 \alpha_1} + \frac{\beta_1}{1 - \beta_1 \alpha_1} \epsilon_t. \quad (20)$$

La segunda parte de (20) muestra claramente la fuente del problema: $prison_t$ contiene una componente proporcional a ϵ_t . Por tanto:

$$\text{Cov}(prison_t, \epsilon_t) = \frac{\beta_1}{1 - \beta_1 \alpha_1} \text{Var}[\epsilon]. \quad (21)$$

2.3.2. Sesgo del estimador MCO de α_1

Si estimamos (15) por MCO, el estimador es:

$$\hat{\alpha}_1 = \frac{\text{Cov}(prison_t, crime_t)}{\text{Var}[prison_t]}. \quad (22)$$

Usando que $crime_t = \alpha_0 + \alpha_1 prison_t + \epsilon_t$,

$$\hat{\alpha}_1 = \frac{\text{Cov}(prison_t, \alpha_0 + \alpha_1 prison_t + \epsilon_t)}{\text{Var}[prison_t]} \quad (23)$$

$$= \alpha_1 + \frac{\text{Cov}(prison_t, \epsilon_t)}{\text{Var}[prison_t]} \quad (24)$$

$$= \alpha_1 + \frac{\beta_1 \text{Var}[\epsilon]}{(1 - \beta_1 \alpha_1) \text{Var}[prison_t]}. \quad (25)$$

Si $\beta_1 > 0$ (más crimen genera políticas más duras y mayor encarcelamiento) y $\alpha_1 < 0$ (más encarcelamiento reduce crimen por incapacitación/disuasión), entonces el denominador $1 - \beta_1 \alpha_1 > 1$, y el numerador $\beta_1 \text{Var}[\epsilon]$ es positivo. El sesgo es positivo:

$$\hat{\alpha}_1 > \alpha_1,$$

es decir, la regresión ingenua subestima en magnitud (hace menos negativo) el verdadero

efecto disuasivo del encarcelamiento sobre el crimen.

La intuición económica es que se confunden dos fuerzas:

- el efecto causal de aumentar encarcelamiento sobre crimen (potencialmente negativo),
- y la respuesta de las políticas de encarcelamiento frente a un aumento del crimen (positiva).

3. Marco de Resultados Potenciales (Neyman–Rubin)

3.1. Notación básica de resultados potenciales

Sea $D_i \in \{0, 1\}$ una variable de tratamiento:

- $D_i = 1$ si la unidad i recibe el tratamiento,
- $D_i = 0$ si no lo recibe (control).

Para cada unidad i definimos dos *resultados potenciales*:

$$Y_{1i} = Y_i(1) \quad \text{resultado potencial si } D_i = 1, \quad (26)$$

$$Y_{0i} = Y_i(0) \quad \text{resultado potencial si } D_i = 0. \quad (27)$$

Definición 1 (Efecto del tratamiento a nivel individual). *El efecto causal individual del tratamiento es*

$$\tau_i = Y_{1i} - Y_{0i}. \quad (28)$$

El resultado observado Y_i puede expresarse como:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i = Y_{0i} + \tau_i D_i. \quad (29)$$

3.2. Problema Fundamental de la Inferencia Causal

El punto central del marco Neyman–Rubin es:

Definición 2 (Problema fundamental). *Es imposible observar simultáneamente $Y_i(1)$ y $Y_i(0)$ para la misma unidad i . Por lo tanto, nunca observamos directamente τ_i .*

Sólo observamos:

$$Y_i = \begin{cases} Y_i(1) & \text{si } D_i = 1, \\ Y_i(0) & \text{si } D_i = 0. \end{cases}$$

El resultado potencial correspondiente al estado no observado es un *contrafactual*.

Nuestro objetivo es típicamente un parámetro promedio de la distribución de τ_i en una población.

3.3. ATE y TOT

Definición 3 (Efecto Promedio del Tratamiento (ATE)).

$$ATE := E[\tau_i] = E[Y_i(1) - Y_i(0)] = E[Y_i(1)] - E[Y_i(0)]. \quad (30)$$

Definición 4 (Efecto del Tratamiento sobre los Tratados (TOT o ATT)).

$$\tau_{TOT} = E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 1]. \quad (31)$$

Mientras el ATE describe el efecto promedio sobre una población (o sobre la muestra completa), el TOT se enfoca en el efecto entre quienes efectivamente reciben el tratamiento.

3.4. Descomposición de la diferencia de medias observada

Considere la diferencia de medias observada entre tratados y controles:

$$\Delta := E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0]. \quad (32)$$

Usando la notación de resultados potenciales:

$$E[Y_i \mid D_i = 1] = E[Y_i(1) \mid D_i = 1], \quad (33)$$

$$E[Y_i \mid D_i = 0] = E[Y_i(0) \mid D_i = 0]. \quad (34)$$

Por lo tanto:

$$\Delta = E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0] \quad (35)$$

$$= \underbrace{E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 1]}_{\text{Efecto promedio en tratados}} + \underbrace{E[Y_i(0) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0]}_{\text{Sesgo de selección}}. \quad (36)$$

Es decir:

$$E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0] = \underbrace{E[Y_{1i} - Y_{0i} \mid D_i = 1]}_{\text{Efecto promedio en tratados}} + \underbrace{E[Y_{0i} \mid D_i = 1] - E[Y_{0i} \mid D_i = 0]}_{\text{Sesgo de selección}}. \quad (37)$$

La segunda parte es precisamente el sesgo de selección: diferencia en el estado basal Y_0 entre quienes se tratan y quienes no. Sólo bajo condiciones fuertes (por ejemplo, tratamiento asignado al azar) esta diferencia desaparece.

4. Experimentos Aleatorios Controlados (RCT)

4.1. Aleatorización y contrafactual válido

Suponga que el tratamiento D_i se asigna aleatoriamente, de manera que:

$$D_i \perp (Y_i(0), Y_i(1)). \quad (38)$$

Esto implica que la distribución condicional de los resultados potenciales dado D_i coincide con la distribución incondicional:

$$E[Y_i(0) \mid D_i = 1] = E[Y_i(0) \mid D_i = 0] = E[Y_i(0)], \quad (39)$$

$$E[Y_i(1) \mid D_i = 1] = E[Y_i(1) \mid D_i = 0] = E[Y_i(1)]. \quad (40)$$

Por lo tanto:

$$\Delta = E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0] \quad (41)$$

$$= E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 0] \quad (42)$$

$$= E[Y_i(1)] - E[Y_i(0)] \quad (43)$$

$$= ATE. \quad (44)$$

Es decir, en un RCT simple, la diferencia de medias observada entre grupo tratado y de control es un estimador insesgado del ATE.

4.2. Estimación del ATE mediante MCO

En un experimento simple (sin covariables), el modelo lineal es:

$$Y_i = \alpha + \beta D_i + \epsilon_i, \quad (45)$$

donde:

- β representa el efecto causal del tratamiento (ATE bajo efectos constantes),
- ϵ_i recoge las diferencias idiosincráticas no explicadas.

El estimador MCO de β es:

$$\hat{\beta} = \bar{Y}_1 - \bar{Y}_0, \quad (46)$$

la diferencia de medias entre tratados y controles. Bajo asignación aleatoria,

$$E[\hat{\beta}] = ATE.$$

4.2.1. Mejora de precisión con controles

Si se dispone de covariables X_i que predican Y_i pero que no están afectadas por el tratamiento, se puede estimar:

$$Y_i = \alpha + \beta D_i + \delta h(X_i) + \epsilon_i, \quad (47)$$

donde $h(X_i)$ es una función (posiblemente no lineal) de los regresores pretratamiento.

Bajo aleatorización, la inclusión de $h(X_i)$:

- no altera la interpretación causal de β (sigue estimando el ATE),
- reduce la varianza de $\hat{\beta}$ al explicar parte de la variación de Y_i .

4.3. Supuesto SUTVA

Sea D el vector de asignaciones $(D_1, \dots, D_N)$. Denotemos $Y_i(D)$ al resultado potencial de la unidad i cuando el *perfil completo* de tratamientos es D .

Definición 5 (SUTVA: Stable Unit Value Treatment Assumption). *Se dice que SUTVA se cumple si, para todo i y para cualquier par de vectores D y D' tales que $D_i = D'_i$, se tiene:*

$$Y_i(D) = Y_i(D').$$

SUTVA implica dos condiciones conceptuales:

1. **No interferencia:** el resultado potencial de la unidad i depende sólo de su propio tratamiento D_i , no de los tratamientos asignados a otras unidades.
2. **Consistencia del tratamiento:** cada nivel de tratamiento corresponde a una intervención bien definida y estable; cualquier unidad con $D_i = 1$ recibe la misma “versión” del tratamiento.

La violación de SUTVA (por ejemplo, cuando el tratamiento de un alumno afecta el resultado de sus compañeros) puede invalidar la interpretación causal estándar del estimador de diferencia de medias.

4.4. TOT (Treatment on the Treated) en RCT

En un RCT simple sin incumplimiento de asignación, la diferencia de medias estima el ATE. El TOT se define como:

$$\tau_{TOT} = E[Y_i(1) \mid D_i = 1] - E[Y_i(0) \mid D_i = 1]. \quad (48)$$

En presencia de cumplimiento perfecto, la aleatorización garantiza que:

$$E[Y_i(0) \mid D_i = 1] = E[Y_i(0) \mid D_i = 0],$$

de modo que el TOT coincide con el ATE. Cuando hay incumplimiento (por ejemplo, individuos asignados a tratamiento que no reciben efectivamente el programa), ATE y TOT difieren, y se requiere un análisis adicional (p. ej. variables instrumentales) para identificarlos.

4.5. Consideraciones éticas: Informe Belmont y límites

Los RCT involucran intervención deliberada sobre personas, por lo que surgen cuestiones éticas centrales. El *Informe Belmont* (1979) en Estados Unidos estableció tres principios fundamentales:

1. Respeto por las personas:

- Requiere consentimiento informado.
- Exige especial protección para grupos vulnerables (niños, presos, personas con capacidades reducidas).

2. Beneficio:

- Los riesgos esperados de la investigación deben ser razonables en relación con los beneficios potenciales.
- Implica evitar exponer sujetos a tratamientos con alta probabilidad de daño cuando existen alternativas conocidas mejores.

3. Justicia:

- La carga de los riesgos y la distribución de beneficios deben ser equitativas.
- Por ejemplo, sería injusto probar un medicamento sólo en presos pobres si luego su comercialización beneficia predominantemente a personas de altos ingresos.

Un caso clásico de violación de estos principios es el experimento de la prisión de Stanford (Zimbardo, 1971), en el cual estudiantes universitarios fueron asignados aleatoriamente a roles de prisioneros y guardias, generando rápidamente episodios de abuso psicológico y físico que obligaron a detener el experimento a los pocos días. Este caso ilustra la importancia de lineamientos éticos claros y supervisión independiente en el diseño experimental.

5. Diseño Observacional y Función Condicional Esperada (CEF)

5.1. Diseños basados en observables y no observables

Cuando no es posible realizar un RCT, el investigador recurre a *diseños observacionales*. Dos grandes familias son:

1. Selección en observables:

- Supone que, condicional en un conjunto suficiente de covariables observadas X_i , la asignación al tratamiento es “como aleatoria”.
- Métodos típicos: regresión lineal con controles, matching, ponderación por puntaje de propensión, estratificación.

2. Selección en no observables:

- Acepta que existen factores no observados que afectan tanto el tratamiento como el resultado.
- Requiere estructuras adicionales de datos o de diseño: datos de panel con efectos fijos, diferencias en diferencias, variables instrumentales, regresión discontinua, entre otros.

5.2. Selección en observables: supuestos clave

En el marco de resultados potenciales, la identificación causal con observables descansa en dos supuestos centrales.

Definición 6 (Independencia condicional (unconfoundedness)).

$$(Y_i(1), Y_i(0)) \perp D_i \mid X_i. \quad (49)$$

Interpretación: una vez que controlamos por X_i , la asignación al tratamiento se comporta como si fuera aleatoria; no quedan factores no observados que influyan simultáneamente en D_i y en los resultados potenciales.

Definición 7 (Soporte común (overlap)).

$$0 < P(D_i = 1 \mid X_i) < 1 \quad \forall X_i. \quad (50)$$

Interpretación: para cada valor de X_i relevante en la población, existe probabilidad positiva de observar unidades tratadas y no tratadas. Esto garantiza la posibilidad de construir contrafactuales observacionales válidos; evita extrapolar efectos estimados en regiones sin comparables.

Cuando ambos supuestos se satisfacen, se puede identificar el ATE mediante:

$$ATE = E_X \left[E[Y_i \mid D_i = 1, X_i] - E[Y_i \mid D_i = 0, X_i] \right]. \quad (51)$$

5.3. Función Condicional Esperada (CEF)

Definición 8 (Función Condicional Esperada). *La CEF de y_i dado X_i se define como*

$$E[y_i \mid X_i] = h(X_i), \quad (52)$$

para alguna función (posiblemente no lineal) $h(\cdot)$.

Definimos el residuo asociado:

$$\epsilon_i = y_i - h(X_i). \quad (53)$$

Por construcción de la CEF se cumple:

$$E[\epsilon_i \mid X_i] = 0. \quad (54)$$

En el caso particular de un solo regresor binario D_i , $h(D_i)$ describe la diferencia de medias entre tratados y controles.

5.4. Tres razones para usar regresión lineal (Angrist)

Sea x_i el vector de regresores (incluyendo constante) y considérese el modelo lineal poblacional

$$E[y_i \mid x_i] = x_i' \beta. \quad (55)$$

Razón 1: si la CEF es lineal, la regresión estima la CEF

Teorema 1 (Regresión-CEF). *Si la CEF es lineal, $E[y_i | x_i] = x_i'\beta$, entonces*

$$\beta = E[x_i x_i']^{-1} E[x_i y_i]. \quad (56)$$

En este caso, la regresión lineal reproduce exactamente la CEF.

Razón 2: Teorema BLP (Best Linear Predictor)

Teorema 2 (BLP). *Entre todas las funciones lineales $x_i'b$ del vector x_i , la función*

$$x_i'\beta, \quad \beta = E[x_i x_i']^{-1} E[x_i y_i], \quad (57)$$

es el mejor predictor lineal de y_i en el sentido de minimizar el error cuadrático medio:

$$\beta = \arg \min_b E[(y_i - x_i'b)^2]. \quad (58)$$

Aunque la CEF no sea lineal, si el objetivo es predecir y_i mediante una función lineal de x_i , la regresión MCO es óptima dentro de la clase lineal.

Razón 3: mejor aproximación lineal de la CEF

Teorema 3 (Aproximación de la regresión). *Sea $h(x_i) = E[y_i | x_i]$ la CEF (posiblemente no lineal). Entonces el vector*

$$\beta = E[x_i x_i']^{-1} E[x_i y_i] \quad (59)$$

minimiza el error cuadrático de aproximación de la CEF por una función lineal:

$$\beta = \arg \min_b E[(h(x_i) - x_i'b)^2]. \quad (60)$$

La regresión lineal proporciona la mejor aproximación lineal de la CEF, siempre que no se extrapole lejos de la región de soporte de los datos.

5.5. Anatomía de una regresión multivariable

Considere el modelo:

$$y_i = \alpha + x_{1i}\beta_1 + \cdots + x_{Ki}\beta_K + u_i. \quad (61)$$

Con un solo regresor (más constante), el coeficiente de pendiente puede escribirse como:

$$\hat{\beta}_1 = \frac{\text{Cov}(y_i, x_{1i})}{\text{Var}[x_{1i}]}.$$
 (62)

Con múltiples regresores, el resultado FWL implica que el estimador parcial para el regresor k se puede escribir como:

$$\hat{\beta}_k = \frac{\text{Cov}(y_i, \tilde{x}_{ki})}{\text{Var}[\tilde{x}_{ki}]},$$
 (63)

donde $\tilde{x}_{ki}$ es el residuo de la regresión de x_{ki} sobre *todos los demás* regresores (incluida la constante). De este modo:

- $\tilde{x}_{ki}$ representa la parte de x_{ki} que no se explica por el resto de covariables.
- $\hat{\beta}_k$ compara cómo cambia y_i cuando se varía $\tilde{x}_{ki}$ manteniendo constante el resto de la información contenida en X .

En forma matricial, el vector completo de coeficientes se escribe como:

$$\hat{\beta} = (X'X)^{-1}X'y,$$
 (64)

y su interpretación causal dependerá de que el vector de regresores X cumpla exogeneidad condicional en el contexto del diseño de investigación.

6. Ejemplos de Diseño de Investigación y Aplicaciones

6.1. Experimentos naturales: John Snow y el cólera en Londres

6.1.1. Contexto histórico e hipótesis causales

Durante la epidemia de cólera en Londres (1849–1854), la teoría dominante sostenía que la enfermedad se transmitía por “miasmas” en el aire. John Snow formuló una hipótesis alternativa: el cólera se transmitía a través del agua contaminada.

Snow explotó una variación cuasi-experimental en el suministro de agua de la ciudad:

- La compañía *Southwark and Vauxhall* extraía agua del río Támesis en una sección contaminada por aguas servidas.
- La compañía *Lambeth* había movido su toma de agua río arriba, a una sección relativamente limpia.

Ambas compañías servían vecindarios geográficamente entremezclados, lo que generaba una asignación de “tratamiento” (agua contaminada vs limpia) aproximadamente exógena respecto de las características socioeconómicas de los hogares.

6.1.2. Evidencia cuantitativa: Tabla IX de Snow

La tabla siguiente resume la tasa de mortalidad por cólera según fuente de agua durante la epidemia de 1854:

Cuadro 1: Tasas de muerte por cólera según fuente de agua, Londres 1854			
Fuente de agua	N° casas	Muertes por cólera	Tasa por 10,000
Southwark and Vauxhall	40,046	1,263	315
Lambeth	26,107	98	37
Resto de Londres	256,423	1,422	59

La comparación de tasas (315 vs 37 por 10,000) indica un contraste dramático asociado únicamente a la fuente de agua. Bajo la hipótesis de miasmas, no existiría razón para observar diferencias tan marcadas entre clientes de distintas compañías dentro de los mismos barrios.

6.1.3. Interpretación causal

El diseño de John Snow es un *experimento natural*:

- La “asignación al tratamiento” (tipo de agua) no fue manipulada por el investigador, pero presenta una variación exógena explotable.
- La comparación de tasas de mortalidad entre compañías es análoga a comparar resultados entre grupos tratado/control.

Dentro del lenguaje de resultados potenciales:

- El tratamiento $D_i = 1$ puede interpretarse como recibir agua contaminada.
- El contrafactual se aproxima con hogares similares que reciben agua limpia.

El análisis de Snow refutó la teoría de miasmas y entregó evidencia contundente a favor de la transmisión hídrica, influyendo en políticas de saneamiento urbano y en la posterior aceptación de la teoría de los gérmenes.

6.2. Ejemplo de discriminación en orquestas (Amaral et al., 2022)

Considere un diseño de audiciones para orquestas donde:

- Los músicos realizan audiciones por rondas (preliminar, semifinal, final).
- Algunas rondas se realizan con una pantalla o cortina que impide identificar visualmente al músico (*audición ciega*).
- El objetivo es medir si la implementación de audiciones ciegas afecta la probabilidad de avance/selección de mujeres.

6.2.1. Modelo lineal con efectos fijos

Sea A_{ijts} el indicador de resultado para individuo i en la orquesta j , en el año t y ronda s (por ejemplo, $A_{ijts} = 1$ si avanza a la siguiente ronda o es contratado, 0 en caso contrario). Sea:

- F_i indicador de que el músico es mujer.
- B_{jts} indicador de que la ronda se realiza con pantalla (audición ciega).
- X_{it} características del postulante (experiencia, edad, etc.).
- Z_{jtr} características de la orquesta o de la vacante (tipo de instrumento, año, nivel del cargo).

Un modelo lineal típico es:

$$A_{ijts} = \alpha + \beta F_i + \gamma B_{jts} + \delta(F_i \times B_{jts}) + X_{it}\theta_1 + Z_{jtr}\theta_2 + FE_{instr} + FE_t + FE_j + \epsilon_{ijts}. \quad (65)$$

Interpretación de los parámetros clave:

- β : brecha promedio mujer–hombre en la probabilidad de éxito *sin* pantalla.
- γ : efecto promedio de tener pantalla (audición ciega) sobre el éxito, para postulantes hombres.
- δ : cambio diferencial en la probabilidad de éxito para mujeres cuando hay pantalla. Captura si la pantalla reduce o aumenta la brecha de género.

Los efectos fijos:

- FE_{instr} controla por el instrumento (diferencias sistemáticas entre instrumentos).

- FE_t controla por shocks comunes al año (ciclos, políticas generales).
- FE_j controla por heterogeneidad entre orquestas (criterios de selección, tamaño, reputación).

6.2.2. Efectos fijos individuales y comparación dentro de persona

Cuando existen múltiples audiciones por el mismo individuo (en distintas orquestas, años o rondas) se puede especificar:

$$A_{ijts} = \alpha + \gamma B_{jts} + \delta(F_i \times B_{jts}) + X_{it}\theta_1 + Z_{jtr}\theta_2 + FE_i + FE_{instr} + FE_t + FE_j + \epsilon_{ijts}. \quad (66)$$

Aquí, FE_i son efectos fijos individuales:

- Capturan la calidad promedio del músico, su historial de entrenamiento, talento, etc., tanto observables como no observables pero constantes en el tiempo.
- Permiten comparar al mismo postulante en situaciones con y sin pantalla, eliminando el sesgo de selección asociado a que músicos de distinta calidad se presenten a distintos concursos.

En este diseño, la variación relevante para identificar γ y δ proviene de cambios en B_{jts} a través de orquestas, años y rondas, manteniendo constante la identidad del músico (vía FE_i), lo que se aproxima a un experimento cuasi-aleatorio sobre el uso de pantalla.

6.2.3. Interpretación causal en términos de diseño

La unidad de tratamiento es la *ronda de audición* y el tratamiento B_{jts} (uso de pantalla) no es elegido por el postulante; está determinado por reglas internas de la orquesta. En la medida en que estas reglas sean exógenas al talento individual no observado, el coeficiente δ puede interpretarse como el efecto causal de introducir audiciones ciegas sobre la brecha de género en la probabilidad de avanzar.

En resumen:

- La combinación de efectos fijos y variación en B_{jts} entrega un diseño de investigación robusto frente a selección en covariables observadas y parte de la selección en no observables.
- El diseño imita, en espíritu, un experimento donde se asigna aleatoriamente el uso de pantalla a distintas rondas e individuos.