

Análisis Exhaustivo de la Regresión Discontinua (RD)

Vicente Olea

Contenido basado en las diapositivas del profesor Gonzalo Gaete del curso ICS2563 - Econometría Aplicada

Índice

1. Introducción y fundamentos de la Regresión Discontinua	3
1.1. Motivación general	3
1.2. Ejemplos de aplicación	3
1.3. Tipos de diseños de Regresión Discontinua	3
1.4. Interpretación causal de RD	4
1.4.1. RD como RCT local	4
1.4.2. RD como caso particular de CIA	4
1.4.3. Limitación: extrapolación local	4
2. Regresión Discontinua Nítida (SRD)	5
2.1. Mecanismo de asignación	5
2.2. Efecto causal local en SRD	5
2.3. Supuesto clave de identificación	5
2.4. Modelo lineal básico	6
2.5. Estimación localizada: ajuste lineal a ambos lados	6
2.6. Modelos no lineales y aproximaciones polinomiales	7
2.7. Polinomios diferentes a ambos lados del umbral	7
2.8. Validez interna y forma funcional	8
3. Regresión Discontinua Difusa (FRD)	8
3.1. Definición y diferencia clave respecto de SRD	8
3.2. Parámetro FRD y razón de saltos	8
3.3. La discontinuidad como variable instrumental	8
3.4. Modelos 2SLS con polinomios diferentes a cada lado	9
3.5. Supuestos clave e interpretación LATE	9
4. Análisis gráfico y testeo de validez	10
4.1. Rol del análisis gráfico en RD	10
4.2. Resultado vs. variable de asignación	10
4.3. Probabilidad de tratamiento condicional a X_i (FRD)	11
4.4. Covariables vs. variable de asignación	12
4.5. Densidad de la variable de asignación	13
4.6. Pruebas de especificación	13
4.6.1. Prueba de continuidad de la densidad (McCrary, 2008)	13

4.6.2.	Pruebas placebo en covariables	14
4.6.3.	Pruebas con puntos de corte falsos	14
5.	Ejemplo de aplicación: Angrist y Lavy (1999)	15
5.1.	Contexto y objetivo	15
5.2.	Regla de Maimónides	15
5.3.	Modelo causal y fuentes de endogeneidad	15
5.4.	Estrategia FRD y variables clave	16
5.5.	Resultados empíricos: MCO vs 2SLS	16
6.	Cheat Sheet Completo de Regresión Discontinua (Sharp y Fuzzy)	17
6.1.	1. Parámetros Clave	17
6.1.1.	Sharp RD (SRD)	17
6.1.2.	Fuzzy RD (FRD)	17
6.2.	2. Supuestos de Identificación	17
6.2.1.	Para SRD	17
6.2.2.	Para FRD	17
6.3.	3. Plantilla para Resolver Ejercicios Sharp RD	18
6.3.1.	Paso 1: Identificar el umbral	18
6.3.2.	Paso 2: Verificar SRD	18
6.3.3.	Paso 3: Escribir el modelo	18
6.3.4.	Paso 4: Interpretación del coeficiente clave	18
6.3.5.	Paso 5: Conclusión	18
6.4.	4. Plantilla para Resolver Ejercicios Fuzzy RD	18
6.4.1.	Paso 1: Determinar si es FRD	18
6.4.2.	Paso 2: Construcción del instrumento	18
6.4.3.	Paso 3: Primera etapa	18
6.4.4.	Paso 4: Forma reducida	18
6.4.5.	Paso 5: Segunda etapa / estimador FRD	19
6.5.	5. Cómo Resolver los Tipos de Ejercicios de la Guía y Ayudantía	19
6.5.1.	Caso 1: Ejercicios con cambio de pendiente	19
6.5.2.	Caso 2: Ejercicios de interpretación de gráficos	19
6.5.3.	Caso 3: Ejercicios tipo “edad de jubilación” (FRD)	19
6.5.4.	Caso 4: Subsidios agrícolas (FRD)	19
6.5.5.	Caso 5: Reforzamiento académico obligatorio (SRD)	20
6.6.	6. Checklist Gráfico para Validar un Diseño RD	20
6.7.	7. Cómo Reconocer Si un Ejercicio es Sharp o Fuzzy	20
6.7.1.	Es SRD si:	20
6.7.2.	Es FRD si:	20
6.8.	8. Fórmulas Esenciales para Polinomios Locales	20
6.9.	9. Interpretación de un Ejercicio Completo (Plantilla General)	21

1. Introducción y fundamentos de la Regresión Discontinua

1.1. Motivación general

En numerosos contextos de política pública y evaluación de programas, la asignación del tratamiento está gobernada por reglas administrativas que dependen de una variable continua de elegibilidad. Por ejemplo, un puntaje en una prueba estandarizada, un índice de focalización social o una fecha de nacimiento pueden determinar el acceso a un programa o beneficio. Cuando la regla presenta un *punto de corte* (clásicamente un umbral escalar x_0) que induce una *discontinuidad* en la probabilidad de recibir el tratamiento, se puede explotar dicha regla para construir un *cuasi-experimento*.

Definición 1 (Diseño de regresión discontinua). *Un diseño de regresión discontinua (RD) es un esquema de asignación al tratamiento en que existe una variable de asignación continua X_i (también llamada running variable o forcing variable) y un umbral conocido x_0 tal que la probabilidad de recibir el tratamiento D_i presenta un salto en $X_i = x_0$. Más precisamente, existe x_0 tal que*

$$\lim_{x \rightarrow x_0^+} \mathbb{P}(D_i = 1 \mid X_i = x) \neq \lim_{x \rightarrow x_0^-} \mathbb{P}(D_i = 1 \mid X_i = x).$$

La idea fundamental es comparar unidades ubicadas *justo a la derecha* del umbral con unidades *justo a la izquierda*. Si las demás determinantes no observadas del resultado son suaves en X_i alrededor de x_0 , entonces la discontinuidad en la probabilidad de tratamiento permite identificar un efecto causal del tratamiento.

1.2. Ejemplos de aplicación

La RD se apoya en reglas que suelen ser relativamente rígidas y, en muchos casos, administrativamente arbitrarias. Algunos ejemplos típicos son:

- **Educación:** resultados en pruebas estandarizadas como la PAES, donde un puntaje mínimo determina la elegibilidad a becas o a programas remediales.
- **Focalización social:** instrumentos como el Registro Social de Hogares (RSH) o el decil de ingreso, que definen umbrales para acceder a transferencias o subsidios.
- **Fechas específicas:** políticas que se aplican a cohortes nacidas antes o después de una fecha determinada (por ejemplo, reformas educacionales con cortes por año de nacimiento).

En todos estos casos, la *regla de asignación* genera discontinuidades aprovechables para inferencia causal.

1.3. Tipos de diseños de Regresión Discontinua

Definición 2 (Regresión Discontinua Nítida (Sharp RD, SRD)). *Existe un diseño de RD nítida cuando el estado de tratamiento D_i es una función determinista de la variable de asignación X_i y del umbral x_0 , de modo que*

$$D_i = \begin{cases} 1, & \text{si } X_i \geq x_0, \\ 0, & \text{si } X_i < x_0. \end{cases}$$

Es decir, conocer X_i determina completamente el tratamiento.

Definición 3 (Regresión Discontinua Difusa (Fuzzy RD, FRD)). *Existe un diseño de RD difusa cuando el tratamiento D_i ya no es determinista en X_i , pero la probabilidad de tratamiento presenta una discontinuidad en el umbral:*

$$\mathbb{P}(D_i = 1 \mid X_i = x) = \begin{cases} g_1(x), & x \geq x_0, \\ g_0(x), & x < x_0, \end{cases}$$

donde $g_1(x_0) \neq g_0(x_0)$. La discontinuidad en la probabilidad de tratamiento se utiliza como una variable instrumental para D_i .

En la práctica, los diseños difusos son sumamente frecuentes, por ejemplo, cuando las reglas administrativas se aplican con cierto grado de discrecionalidad, existen excepciones o la implementación es imperfecta.

1.4. Interpretación causal de RD

1.4.1. RD como RCT local

Comentario 1 (RD como experimento aleatorio local). *Para unidades situadas muy cerca del umbral x_0 , el hecho de caer justo a la izquierda o a la derecha del corte puede considerarse “casi aleatorio” desde el punto de vista de los determinantes no observados del resultado. Por ello, la RD puede interpretarse como un experimento aleatorio controlado (RCT) local: la asignación al tratamiento está casi “randomizada” en una vecindad pequeña del umbral.*

Esta intuición sugiere por qué la RD se considera un diseño con un estándar creíble de causalidad: la comparación se realiza entre unidades que son, en promedio, muy similares salvo por el valor de la variable de asignación alrededor de x_0 .

1.4.2. RD como caso particular de CIA

Sea $Y_i(1)$ el resultado potencial bajo tratamiento y $Y_i(0)$ el resultado potencial sin tratamiento. El supuesto de independencia condicional (CIA, por sus siglas en inglés) establece que

$$(Y_i(1), Y_i(0)) \perp D_i \mid X_i.$$

En un diseño de RD nítida, dado que el tratamiento es una función determinista de X_i , no hay variación residual en D_i condicional en X_i . La identificación no se basa en el ajuste por múltiples covariables, sino en la *continuidad* de los resultados potenciales en la variable de asignación. El papel de X_i es doble: fija el tratamiento y permite extrapolar localmente los resultados potenciales.

1.4.3. Limitación: extrapolación local

Un rasgo distintivo de la RD es que el efecto causal identificado es *local* en torno al umbral. Más específicamente:

- En SRD, el parámetro identificado corresponde al efecto promedio del tratamiento para las unidades con X_i en una vecindad de x_0 .
- En FRD, además de ser local en X_i , el parámetro es un efecto LATE (*Local Average Treatment Effect*) para los *compliers* que modifican su probabilidad de tratamiento al cruzar el umbral.

Por ello, la RD *no* entrega, en general, un efecto causal global sobre toda la población, sino un efecto local que debe interpretarse con cuidado al extrapolar a otros niveles de la variable de asignación.

2. Regresión Discontinua Nítida (SRD)

2.1. Mecanismo de asignación

En una RD nítida, el mecanismo de asignación se describe como:

$$D_i = \begin{cases} 1, & \text{si } X_i \geq x_0, \\ 0, & \text{si } X_i < x_0. \end{cases} \quad (1)$$

Conocido X_i , se conoce exactamente el estado de tratamiento. No existe valor de X_i donde coexistan observaciones tratadas y de control; la identificación se logra *extrapolando* las funciones de regresión de los resultados potenciales a través de x_0 .

2.2. Efecto causal local en SRD

Sea $Y_i(1)$ y $Y_i(0)$ los resultados potenciales. Definimos la función de regresión observada

$$m(x) = \mathbb{E}[Y_i \mid X_i = x].$$

Definición 4 (Parámetro SRD). *El efecto causal local en un diseño de RD nítida se define como*

$$\rho_{SRD} = \lim_{x \rightarrow x_0^+} \mathbb{E}[Y_i \mid X_i = x] - \lim_{x \rightarrow x_0^-} \mathbb{E}[Y_i \mid X_i = x] = \mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x_0]. \quad (2)$$

Este parámetro corresponde al efecto promedio del tratamiento en la población de unidades con valor de la variable de asignación igual (o muy cercano) al umbral x_0 .

Obsérvese que la última igualdad requiere supuestos de continuidad sobre las funciones de regresión de los resultados potenciales, que explicitamos a continuación.

2.3. Supuesto clave de identificación

Supuesto 1 (Continuidad de los resultados potenciales en X_i). *Las funciones de regresión de los resultados potenciales son continuas en x_0 , es decir,*

$$\lim_{x \rightarrow x_0^-} \mathbb{E}[Y_i(0) \mid X_i = x] = \lim_{x \rightarrow x_0^+} \mathbb{E}[Y_i(0) \mid X_i = x],$$

y

$$\lim_{x \rightarrow x_0^-} \mathbb{E}[Y_i(1) \mid X_i = x] = \lim_{x \rightarrow x_0^+} \mathbb{E}[Y_i(1) \mid X_i = x].$$

El supuesto establece que todos los demás determinantes (observados y no observados) del resultado varían de forma suave con X_i y, por tanto, no generan saltos en el resultado en x_0 en ausencia de tratamiento.

Proposición 1 (Identificación en SRD). *Bajo el Supuesto 1, el parámetro ρ_{SRD} definido en (2) identifica el efecto causal promedio del tratamiento en el umbral:*

$$\rho_{SRD} = \mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x_0].$$

La idea es que las unidades justo por debajo de x_0 proveen un *contrafactual válido* para las unidades justo por encima del umbral. En la práctica, este supuesto no se puede verificar directamente (pues no observamos ambos resultados potenciales), pero se puede respaldar mediante análisis gráfico y pruebas placebo en covariables, descritas más adelante.

2.4. Modelo lineal básico

Como punto de partida, supongamos que los resultados potenciales están dados por un modelo de efectos constantes:

$$\begin{aligned}\mathbb{E}[Y_i(0) \mid X_i] &= \alpha + \beta X_i, \\ Y_i(1) &= Y_i(0) + \rho.\end{aligned}$$

Entonces el modelo observable es

$$Y_i = \alpha + \beta X_i + \rho D_i + \eta_i, \quad (3)$$

donde η_i es un término de error con media condicional cero dado X_i .

La particularidad de este modelo respecto de una regresión lineal estándar es que D_i es una función determinista de X_i , de acuerdo con (1). Por lo tanto, la estimación ignora observaciones lejos del umbral o utiliza especificaciones polinomiales para capturar adecuadamente la relación entre Y_i y X_i .

2.5. Estimación localizada: ajuste lineal a ambos lados

Una especificación muy utilizada es la regresión local lineal alrededor del umbral. Sea $h > 0$ un parámetro de ancho de banda que define la vecindad en la cual se usan observaciones:

$$x_0 - h < X_i < x_0 + h.$$

Definamos la variable de tratamiento

$$D_i = \mathbf{1}\{X_i > x_0\}$$

y centremos la variable de asignación,

$$\tilde{X}_i = X_i - x_0.$$

El modelo local lineal de SRD se escribe como

$$Y_i = \beta_0 + \beta_1 \tilde{X}_i + \beta_2 \tilde{X}_i D_i + \rho_{SRD} D_i + \varepsilon_i. \quad (4)$$

En esta especificación:

- β_0 y β_1 describen la función de regresión de Y_i para unidades con $X_i < x_0$.
- La interacción $\beta_2 \tilde{X}_i D_i$ permite que la pendiente de la regresión sea distinta a la derecha del umbral.
- El coeficiente ρ_{SRD} mide el *salto* en el nivel de la función de regresión al pasar de X_i justo por debajo a justo por encima de x_0 .

La especificación (4) puede ser estimada mediante MCO ponderados localmente (por ejemplo, usando kernels) o mediante MCO sobre la submuestra restringida a la vecindad definida por h .

2.6. Modelos no lineales y aproximaciones polinomiales

En muchos contextos, la relación $\mathbb{E}[Y_i(0) \mid X_i = x]$ es notablemente no lineal. Sea $f(x)$ una función suave tal que

$$\mathbb{E}[Y_i(0) \mid X_i = x] = f(x).$$

El modelo estructural con tratamiento constante se puede escribir como

$$Y_i = f(X_i) + \rho D_i + \eta_i. \quad (5)$$

Existen dos enfoques frecuentes para aproximar $f(x)$:

1. **Métodos no paramétricos tipo kernel:** estiman $f(x)$ por regresión local (por ejemplo, local lineal o local polinomial) usando pesos que decrecen con la distancia entre X_i y el punto de interés.
2. **Polinomios de orden p :** se aproxima $f(x)$ mediante un polinomio global en X_i :

$$Y_i = \alpha + \beta_1 X_i + \beta_2 X_i^2 + \cdots + \beta_p X_i^p + \rho D_i + \eta_i. \quad (6)$$

La especificación (6) impone que la función de regresión en X_i sea la misma a ambos lados del umbral, excepto por el salto de nivel ρ en D_i .

2.7. Polinomios diferentes a ambos lados del umbral

En muchos trabajos empíricos se prefiere permitir que la forma funcional de la regresión difiera a ambos lados del umbral. Sea

$$\tilde{X}_i = X_i - x_0,$$

de modo que el umbral queda centrado en cero.

Consideremos las funciones de regresión de los resultados potenciales:

$$\mathbb{E}[Y_i(0) \mid X_i] = \alpha + \beta_{01} \tilde{X}_i + \beta_{02} \tilde{X}_i^2 + \cdots + \beta_{0p} \tilde{X}_i^p, \quad (7)$$

$$\mathbb{E}[Y_i(1) \mid X_i] = \alpha + \rho + \beta_{11} \tilde{X}_i + \beta_{12} \tilde{X}_i^2 + \cdots + \beta_{1p} \tilde{X}_i^p. \quad (8)$$

Usando que D_i es determinista en X_i , podemos escribir la función de regresión observada como

$$\mathbb{E}[Y_i \mid X_i] = \mathbb{E}[Y_i(0) \mid X_i] + (\mathbb{E}[Y_i(1) \mid X_i] - \mathbb{E}[Y_i(0) \mid X_i]) D_i.$$

El modelo de regresión resultante es

$$Y_i = \alpha + \beta_{01} \tilde{X}_i + \beta_{02} \tilde{X}_i^2 + \cdots + \beta_{0p} \tilde{X}_i^p + \rho D_i + \beta_1^* D_i \tilde{X}_i + \beta_2^* D_i \tilde{X}_i^2 + \cdots + \beta_p^* D_i \tilde{X}_i^p + \eta_i, \quad (9)$$

donde

$$\beta_j^* = \beta_{1j} - \beta_{0j}, \quad j = 1, \dots, p.$$

En este modelo:

- ρ representa el efecto del tratamiento en el umbral $X_i = x_0$.
- Para un valor $\tilde{X}_i = c > 0$, el efecto del tratamiento es

$$\rho + \beta_1^* c + \beta_2^* c^2 + \cdots + \beta_p^* c^p,$$

lo que permite capturar efectos heterogéneos a lo largo de la variable de asignación.

La especificación (9) generaliza (6): esta última se obtiene cuando todos los coeficientes de interacción β_j^* son cero.

2.8. Validez interna y forma funcional

La validez de las estimaciones de RD depende crucialmente de que la especificación para la función de regresión de $Y_i(0)$ sea suficientemente flexible. En particular, si se impone una forma funcional demasiado rígida, una *no linealidad* en $f(x)$ puede ser erróneamente interpretada como un salto en el resultado, generando una falsa discontinuidad. Gráficos de diagnóstico que comparen ajustes polinomiales y datos binned a lo largo de X_i son fundamentales para detectar este problema.

3. Regresión Discontinua Difusa (FRD)

3.1. Definición y diferencia clave respecto de SRD

En una RD difusa, el estado de tratamiento D_i ya no está perfectamente determinado por X_i , sino que la probabilidad de tratamiento cambia discontinuamente en el umbral. Formalmente, existe x_0 tal que

$$0 < \lim_{x \rightarrow x_0^+} \mathbb{P}(D_i = 1 \mid X_i = x) - \lim_{x \rightarrow x_0^-} \mathbb{P}(D_i = 1 \mid X_i = x) < 1. \quad (10)$$

Una parametrización conveniente es

$$\mathbb{P}(D_i = 1 \mid X_i) = \begin{cases} g_1(X_i), & X_i \geq x_0, \\ g_0(X_i), & X_i < x_0, \end{cases} \quad (11)$$

donde $g_1(x_0) \neq g_0(x_0)$. Podemos reescribir (11) como

$$\mathbb{P}(D_i = 1 \mid X_i) = g_0(X_i) + [g_1(X_i) - g_0(X_i)]T_i,$$

donde

$$T_i = \mathbf{1}\{X_i \geq x_0\}$$

es un indicador de estar sobre el umbral.

3.2. Parámetro FRD y razón de saltos

En la versión difusa, el parámetro de interés se define como la razón entre el salto en el resultado y el salto en la probabilidad de tratamiento:

$$\rho_{FRD} = \frac{\lim_{x \rightarrow x_0^+} \mathbb{E}[Y_i \mid X_i = x] - \lim_{x \rightarrow x_0^-} \mathbb{E}[Y_i \mid X_i = x]}{\lim_{x \rightarrow x_0^+} \mathbb{E}[D_i \mid X_i = x] - \lim_{x \rightarrow x_0^-} \mathbb{E}[D_i \mid X_i = x]}. \quad (12)$$

La expresión (12) es análoga al cociente de coeficientes en un modelo de variables instrumentales: el numerador capta la discontinuidad en la función de regresión de Y_i (forma reducida) y el denominador, la discontinuidad en la probabilidad de tratamiento (primera etapa).

3.3. La discontinuidad como variable instrumental

La variable

$$T_i = \mathbf{1}\{X_i \geq x_0\}$$

es una candidata natural a instrumento para D_i , pues:

- Está correlacionada con D_i vía la discontinuidad en $\mathbb{P}(D_i = 1 \mid X_i)$ en x_0 (relevancia).
- Bajo los supuestos de continuidad de los resultados potenciales en X_i , el cruce del umbral no afecta Y_i sino a través del tratamiento (exclusión).

Podemos escribir una ecuación de primera etapa polinomial:

$$\mathbb{E}[D_i \mid X_i] = \gamma_{00} + \gamma_{01}X_i + \gamma_{02}X_i^2 + \cdots + \gamma_{0p}X_i^p + \pi T_i + \gamma_1^* X_i T_i + \gamma_2^* X_i^2 T_i + \cdots + \gamma_p^* X_i^p T_i. \quad (13)$$

En la práctica, es común utilizar una especificación justamente identificada empleando como instrumento solo T_i (sin interacciones), lo que puede tener mejores propiedades en muestras finitas. En ese caso, la primera etapa estimada puede escribirse como:

$$D_i = \gamma_0 + \gamma_1 X_i + \gamma_2 X_i^2 + \cdots + \gamma_p X_i^p + \pi T_i + \varepsilon_i. \quad (14)$$

La forma reducida asociada es

$$Y_i = \mu + \kappa_1 X_i + \kappa_2 X_i^2 + \cdots + \kappa_p X_i^p + \tau T_i + \xi_i. \quad (15)$$

En este marco, el estimador 2SLS de ρ coincide con el cociente τ/π en modelos lineales simples; en las especificaciones polinomiales se preserva la lógica de ratio de límites descrita en (12).

3.4. Modelos 2SLS con polinomios diferentes a cada lado

Al igual que en SRD, podemos permitir que la función de regresión de Y_i difiera a ambos lados del umbral. Para ello, centramos la variable de asignación en x_0 , $\tilde{X}_i = X_i - x_0$, y escribimos la segunda etapa como

$$Y_i = \alpha + \beta_{01}\tilde{X}_i + \beta_{02}\tilde{X}_i^2 + \cdots + \beta_{0p}\tilde{X}_i^p + \rho D_i + \beta_1^* D_i \tilde{X}_i + \beta_2^* D_i \tilde{X}_i^2 + \cdots + \beta_p^* D_i \tilde{X}_i^p + \eta_i. \quad (16)$$

Aquí, D_i y los términos de interacción $D_i \tilde{X}_i^j$ se reemplazan por sus valores ajustados provenientes de las respectivas primeras etapas, que pueden escribirse, por ejemplo, como

$$D_i = \gamma_{00} + \gamma_{01}\tilde{X}_i + \gamma_{02}\tilde{X}_i^2 + \cdots + \gamma_{0p}\tilde{X}_i^p + \pi T_i + \gamma_1^* \tilde{X}_i T_i + \cdots + \gamma_p^* \tilde{X}_i^p T_i + \xi_{1i}, \quad (17)$$

y, análogamente, primeras etapas para $D_i \tilde{X}_i$, $D_i \tilde{X}_i^2$, etc.

3.5. Supuestos clave e interpretación LATE

Supuesto 2 (Supuestos estándar de VI en FRD). *El diseño FRD requiere los mismos supuestos básicos que el marco estándar de variables instrumentales:*

1. Relevancia: $\mathbb{P}(D_i = 1 \mid X_i)$ presenta un salto en x_0 , es decir, el instrumento T_i afecta al tratamiento.
2. Exogeneidad condicional: condicional en X_i , el cruce del umbral no afecta directamente al resultado potencial.
3. Monotonicidad: no existen unidades cuyo tratamiento se mueva en dirección opuesta a la inducida por el instrumento (defiers).

La monotonicidad se puede expresar de la siguiente forma. Sea x^* un valor potencial del umbral y $D_i(x^*)$ el estado de tratamiento que recibiría el individuo si el umbral fuera x^* . Entonces, alrededor de x_0 se requiere que $D_i(x^*)$ sea no decreciente (o no creciente, según el contexto) en x^* .

Bajo estos supuestos, el parámetro ρ_{FRD} en (12) se interpreta como un *LATE local*:

Proposición 2 (Interpretación LATE en FRD). *En un diseño FRD, bajo los supuestos de continuidad y monotonicidad, ρ_{FRD} identifica el efecto promedio del tratamiento para la subpoblación de compliers cuya probabilidad de tratamiento cambia al cruzar el umbral $X_i = x_0$.*

Nótese que la localización es doble: el efecto es local en la variable de asignación (vecindad de x_0) y local en el tipo de unidad (compliers).

4. Análisis gráfico y testeo de validez

4.1. Rol del análisis gráfico en RD

El análisis gráfico es parte esencial de cualquier estudio de RD. Los gráficos permiten:

- Visualizar la presencia (o ausencia) de discontinuidades en el resultado y en la probabilidad de tratamiento.
- Evaluar la plausibilidad de la continuidad de covariables observables en X_i en el umbral.
- Detectar posibles manipulaciones de la variable de asignación (agentes que se auto-posicionan respecto del umbral).

A continuación se describen los gráficos más importantes.

4.2. Resultado vs. variable de asignación

El primer gráfico clave representa la variable de resultado promedio en función de la variable de asignación X_i . El procedimiento estándar es:

1. Dividir el soporte de X_i en intervalos (bins).
2. Calcular, para cada bin, el promedio de Y_i .
3. Graficar los puntos medios de los bins en el eje horizontal y los promedios de Y_i en el eje vertical.
4. Ajustar sobre estos puntos una función de regresión flexible (por ejemplo, local polinomial) a ambos lados del umbral.




Figura 1: Variable de resultado promedio en función de la variable de asignación. Ejemplo inspirado en Lee y Lemieux (2010).




Figura 2: Variable de resultado promedio en función de la variable de asignación. Ejemplo inspirado en Lee y Lemieux (2010).

El gráfico permite inspeccionar si existe un salto en x_0 y, además, si aparecen otras discontinuidades inesperadas en otros puntos del soporte.

4.3. Probabilidad de tratamiento condicional a X_i (FRD)

En diseños FRD, es imprescindible verificar que la probabilidad de tratamiento presenta un salto en el umbral. El gráfico se construye análogamente:

1. Para cada bin en X_i , calcular la proporción de unidades tratadas ($\mathbb{P}(D_i = 1)$) dentro del bin.
2. Graficar estas proporciones contra el valor medio de X_i en el bin.

3. Ajustar una curva suave a ambos lados del umbral.




Figura 3: Probabilidad de tratamiento condicional a la variable de asignación en un diseño FRD. Ejemplo inspirado en Araya y Gaete (2022).

La presencia de un salto claro en este gráfico confirma la existencia de una *primera etapa fuerte*, condición necesaria para que el instrumento sea relevante.

4.4. Covariables vs. variable de asignación

Un requisito clave para la validez de la RD es que (condicional en X_i) los determinantes observables del resultado sean continuos en el umbral. Esto se evalúa mediante gráficos de “balance” en covariables:

1. Repetir el procedimiento de binned scatter, pero usando una covariable W_i como variable de resultado.
2. Verificar gráficamente que no existe un salto en x_0 .




Figura 4: Covariables promedio en función de la variable de asignación. Ejemplo inspirado en Araya y Gaete (2022).

Salto significativo en covariables ponen en duda el supuesto de identificación, pues sugieren que factores observables (y posiblemente no observables) también cambian de forma discreta en el umbral.

4.5. Densidad de la variable de asignación

El cuarto gráfico central se concentra en la densidad de la variable de asignación. El objetivo es detectar posibles manipulaciones:

1. Dividir el soporte de X_i en bins y contar el número de observaciones en cada uno.
2. Graficar el conteo (o la densidad estimada) contra el valor medio de X_i en el bin.
3. Ajustar una curva suave a ambos lados del umbral.




Figura 5: Densidad de la variable de asignación alrededor del umbral. Ejemplo inspirado en Lee y Lemieux (2010).

Una discontinuidad marcada en la densidad alrededor de x_0 sugiere que los individuos pueden manipular la variable de asignación, por ejemplo, estratégicamente situándose justo encima del umbral para acceder al tratamiento. Esto vulnera la suposición de que el cruce del umbral es esencialmente exógeno.

4.6. Pruebas de especificación

4.6.1. Prueba de continuidad de la densidad (McCrary, 2008)

McCrary (2008) propone un test formal para contrastar la hipótesis nula de continuidad de la densidad de X_i en x_0 . El procedimiento es:

1. Dividir el soporte de X_i en bins y computar las frecuencias (conteos) en cada bin.
2. Tratar el logaritmo de la densidad estimada como variable dependiente en una regresión local no paramétrica a la izquierda y derecha del umbral.

3. Estimar el tamaño del salto en la densidad en x_0 y su error estándar.

Un salto significativo en la densidad es evidencia de manipulación de la variable de asignación y, por tanto, amenaza la validez del diseño RD (sobre todo en el plano interno).




Figura 6: Ejemplo de test de McCrary para la densidad de la variable de asignación.

4.6.2. Pruebas placebo en covariables

Una estrategia complementaria consiste en estimar el modelo RD utilizando como variable dependiente una covariable W_i que debería ser independiente del tratamiento condicional en X_i . Bajo la validez del diseño, el salto estimado en W_i en el umbral debería ser estadísticamente indistinguible de cero.

Formalmente, se estima una regresión de la forma

$$W_i = g(X_i) + \delta D_i + u_i,$$

o la versión FRD instrumentando D_i con T_i . Un $\hat{\delta}$ pequeño y no significativo refuerza la idea de que las covariables son continuas en x_0 .

4.6.3. Pruebas con puntos de corte falsos

Imbens y Lemieux (2008) proponen evaluar la presencia de discontinuidades en puntos del soporte donde no debería existir salto alguno. Una versión sencilla es:

1. Tomar solamente observaciones a un lado del umbral verdadero.
2. Calcular la mediana (u otro cuantíl) de X_i en esa submuestra.
3. Tratar dicha mediana como un “pseudo-umbral” y aplicar el mismo procedimiento RD.

Si se detectan discontinuidades significativas en estos puntos de corte falsos, puede ser indicio de especificaciones funcionales inadecuadas.

5. Ejemplo de aplicación: Angrist y Lavy (1999)

5.1. Contexto y objetivo

Angrist y Lavy (1999) estudian el efecto del tamaño de la clase sobre el desempeño académico en Israel, explotando una regla administrativa conocida como *Regla de Maimónides*. El resultado de interés Y_{isc} es la puntuación de las pruebas de lenguaje y matemáticas del estudiante i en la escuela s y clase c .

El objetivo es estimar el efecto causal del tamaño de la clase sobre los puntajes de las pruebas, corrigiendo la endogeneidad inherente a la forma en que se asignan los estudiantes a clases.

5.2. Regla de Maimónides

La Regla de Maimónides establece que las clases deben dividirse cuando la matrícula excede 40 alumnos. De forma simplificada:

- Si una escuela tiene exactamente 40 estudiantes en un nivel, se forma una sola clase de 40 alumnos.
- Si una escuela tiene 41 estudiantes, se forman dos clases, por ejemplo, de 21 y 20 estudiantes.

Sea e_s la matrícula total en el curso de la escuela s . El tamaño de clase *predicho* por una aplicación estricta de la regla es

$$m_{sc} = \frac{e_s}{\text{int} \left[\frac{(e_s - 1)}{40} \right] + 1}, \quad (18)$$

donde $\text{int}[a]$ denota la parte entera de a .

En la práctica, la regla no se cumple de forma perfecta: directores y administradores pueden apartarse parcialmente de ella, generando un diseño de RD *difusa* con múltiples discontinuidades (en 40, 80, 120, etc.).

5.3. Modelo causal y fuentes de endogeneidad

El modelo de interés puede escribirse como

$$Y_{isc} = \alpha_0 + \rho n_{sc} + \eta_{isc}, \quad (19)$$

donde n_{sc} es el tamaño de la clase c en la escuela s .

La estimación por MCO de (19) está potencialmente sesgada, pues es plausible que n_{sc} esté correlacionado con el término de error η_{isc} . Dos mecanismos centrales son:

1. **Selección de padres:** familias con nivel socioeconómico más alto podrían preferir y lograr matricular a sus hijos en escuelas con clases más pequeñas.
2. **Asignación discrecional:** directores pueden asignar a estudiantes con menor rendimiento a clases de menor tamaño, para brindarles más atención.

Ambos fenómenos inducen correlación entre n_{sc} y determinantes no observados del rendimiento académico.

5.4. Estrategia FRD y variables clave

Angrist y Lavy utilizan la Regla de Maimónides como fuente de variación exógena en el tamaño de la clase, implementando un diseño de RD difusa (FRD) con múltiples puntos de corte.

La relación con la notación de FRD es la siguiente:

- El tamaño de clase observado n_{sc} juega el rol de D_i (tratamiento).
- La matrícula e_s juega el rol de X_i (variable de asignación).
- El tamaño de clase predicho m_{sc} , definido en (18), juega el rol de instrumento T_i .

Una especificación extendida, que incorpora covariables y términos polinomiales en e_s , es:

$$Y_{isc} = \alpha_0 + \alpha_1 d_s + \rho n_{sc} + \beta_1 e_s + \beta_2 e_s^2 + \eta_{isc}, \quad (20)$$

donde d_s es el porcentaje de alumnos en desventaja en la escuela s .

La ecuación de primera etapa correspondiente es

$$n_{sc} = \gamma_0 + \gamma_1 d_s + \pi m_{sc} + \delta_1 e_s + \delta_2 e_s^2 + \xi_{isc}, \quad (21)$$

donde:

- m_{sc} refleja los saltos inducidos por la Regla de Maimónides.
- π mide la fuerza de la relación entre el tamaño predicho y el tamaño efectivo de la clase.

La estimación por 2SLS utiliza (21) como primera etapa, sustituyendo n_{sc} en (20) por su valor ajustado $\hat{n}_{sc}$.

5.5. Resultados empíricos: MCO vs 2SLS

De acuerdo con Angrist y Lavy:

- Las estimaciones por MCO sugieren una relación positiva o ligeramente negativa (no significativa) entre tamaño de clase y rendimiento académico: clases más grandes no parecen perjudicar significativamente el desempeño.
- En cambio, las estimaciones 2SLS, que explotan la variación exógena generada por la Regla de Maimónides, encuentran un efecto *significativamente negativo* del tamaño de la clase sobre los puntajes: clases más pequeñas mejoran los resultados académicos.

Este contraste ilustra el valor de la RD (y FRD en particular) para aislar variación exógena y corregir por la endogeneidad de la asignación de estudiantes a clases.

Conclusiones

La regresión discontinua es una herramienta poderosa para la evaluación causal cuando la asignación al tratamiento está gobernada por reglas de elegibilidad con umbrales. Los diseños SRD explotan la determinación exacta del tratamiento, mientras que los diseños FRD convierten la discontinuidad en la probabilidad de tratamiento en una variable instrumental.

La validez de las inferencias descansa en supuestos de continuidad de las funciones de regresión de los resultados potenciales y, en el caso de FRD, en los supuestos estándar de variables instrumentales, incluyendo monotonicidad. Los análisis gráficos y las pruebas de especificación (gráficos de resultado, primera etapa, covariables, densidad y tests tipo McCrary) son imprescindibles para respaldar empíricamente estos supuestos.

Finalmente, el ejemplo de Angrist y Lavy (1999) muestra cómo la combinación de una regla administrativa (Regla de Maimónides) con técnicas de FRD y 2SLS permite estimar de forma convincente el efecto del tamaño de la clase sobre el rendimiento académico, revelando que la asignación endógena puede ocultar relaciones causales de gran relevancia para la política educativa.

6. Cheat Sheet Completo de Regresión Discontinua (Sharp y Fuzzy)

Esta sección sintetiza todas las fórmulas, supuestos, procedimientos y plantillas necesarias para resolver cualquier ejercicio de RD, tanto SRD como FRD, basándose en los contenidos trabajados en *Guía RDD [Pauta]* y en la *Ayudantía Examen*.

6.1. 1. Parámetros Clave

6.1.1. Sharp RD (SRD)

$$D_i = \mathbf{1}(X_i \geq c),$$

$$\rho_{SRD} = \lim_{x \rightarrow c^+} \mathbb{E}[Y_i | X_i = x] - \lim_{x \rightarrow c^-} \mathbb{E}[Y_i | X_i = x].$$

Interpretación: efecto causal local para unidades con $X_i = c$.

6.1.2. Fuzzy RD (FRD)

$$\rho_{FRD} = \frac{\lim_{x \rightarrow c^+} \mathbb{E}[Y_i | X_i = x] - \lim_{x \rightarrow c^-} \mathbb{E}[Y_i | X_i = x]}{\lim_{x \rightarrow c^+} \mathbb{E}[D_i | X_i = x] - \lim_{x \rightarrow c^-} \mathbb{E}[D_i | X_i = x]}.$$

Interpretación: LATE para los compliers locales.

6.2. 2. Supuestos de Identificación

6.2.1. Para SRD

- Continuidad de $Y_i(0)$ y $Y_i(1)$ en $X = c$.
- No manipulación del running variable cerca del umbral.
- Funciones $f_0(x)$ y $f_1(x)$ suficientemente suaves.

6.2.2. Para FRD

- Continuidad de los resultados potenciales.
- Relevancia: salto en $\mathbb{E}[D_i | X_i = x]$.
- Exclusión: $T_i = \mathbf{1}(X \geq c)$ afecta a Y_i solo vía D_i .
- Monotonicidad: no existen defiers.

6.3. 3. Plantilla para Resolver Ejercicios Sharp RD

6.3.1. Paso 1: Identificar el umbral

Identificar c tal como en los ejercicios de la guía (por ejemplo, score de focalización, puntaje de pruebas, edad de jubilación).

6.3.2. Paso 2: Verificar SRD

Confirmar que la asignación es determinista:

$$P(D_i = 1 \mid X_i) \in \{0, 1\}.$$

6.3.3. Paso 3: Escribir el modelo

Modelo lineal local:

$$Y_i = \alpha + \beta(X_i - c) + \rho D_i + \eta_i.$$

Modelo con pendientes distintas:

$$Y_i = \beta_0 + \beta_1(X_i - c) + \beta_2 D_i + \beta_3 D_i(X_i - c) + \epsilon_i.$$

6.3.4. Paso 4: Interpretación del coeficiente clave

$$\rho = \text{salto en el nivel de } Y_i \text{ en } X = c.$$

6.3.5. Paso 5: Conclusión

Siempre limitar la inferencia a unidades cercanas al umbral.

6.4. 4. Plantilla para Resolver Ejercicios Fuzzy RD

6.4.1. Paso 1: Determinar si es FRD

Existe salto en la probabilidad de tratamiento:

$$0 < \Delta D < 1.$$

6.4.2. Paso 2: Construcción del instrumento

$$T_i = \mathbf{1}(X_i \geq c).$$

6.4.3. Paso 3: Primera etapa

$$D_i = \gamma_0 + \gamma_1(X_i - c) + \pi T_i + \xi_i.$$

Interpretación: π = salto en probabilidad de tratamiento.

6.4.4. Paso 4: Forma reducida

$$Y_i = \mu_0 + \mu_1(X_i - c) + \tau T_i + \nu_i.$$

6.4.5. Paso 5: Segunda etapa / estimador FRD

$$\rho_{FRD} = \frac{\tau}{\pi}.$$

Interpretación: efecto causal para los compliers.

6.5. 5. Cómo Resolver los Tipos de Ejercicios de la Guía y Ayudantía

6.5.1. Caso 1: Ejercicios con cambio de pendiente

Los ejercicios que presentan modelos como:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 (X_i - c) D_i + \epsilon_i$$

requieren:

- Evaluar el salto en $X = c$: $\rho = \beta_2$.
- Evaluar cambios en pendiente: $\Delta \text{slope} = \beta_3$.

6.5.2. Caso 2: Ejercicios de interpretación de gráficos

De acuerdo a la guía:

- Identificar el salto en el gráfico binned.
- Comparar ajuste paramétrico vs. no paramétrico.
- Señalar si la forma funcional parece adecuada.

6.5.3. Caso 3: Ejercicios tipo “edad de jubilación” (FRD)

Tal como en la ayudantía:

- El running variable es la edad.
- El tratamiento es recibir pensión.
- El instrumento es cruzar el umbral de edad.

Primera etapa:

$$P(\text{recibe pensión}) = \gamma_0 + \gamma_1 \text{Age} + \pi T + u.$$

Segunda etapa:

$$\text{Salud} = \mu_0 + \mu_1 \text{Age} + \rho \widehat{P(\text{pensión})} + v.$$

6.5.4. Caso 4: Subsidios agrícolas (FRD)

Plantilla basada en la Ayudantía:

- Running variable: tamaño productivo.
- Tratamiento: recibir subsidio.
- Instrumento: pasar el umbral del programa.

6.5.5. Caso 5: Reforzamiento académico obligatorio (SRD)

$$D_i = \mathbf{1}(\text{puntaje} < c).$$

Efecto del reforzamiento:

$$\rho = \lim_{x \rightarrow c^-} \mathbb{E}[Y | x] - \lim_{x \rightarrow c^+} \mathbb{E}[Y | x].$$

6.6. 6. Checklist Gráfico para Validar un Diseño RD

- ¿Hay salto visible en Y_i ?
- ¿Hay salto en D_i (solo en FRD)?
- ¿Las covariables son continuas en c ?
- ¿La densidad de X_i es continua (test tipo McCrary)?
- ¿El ajuste polinomial parece razonable?
- ¿Los resultados son robustos a BW y especificación?

6.7. 7. Cómo Reconocer Si un Ejercicio es Sharp o Fuzzy

6.7.1. Es SRD si:

- El tratamiento cambia de 0 a 1 exactamente en c .
- La regla administrativa se cumple al 100 %.

6.7.2. Es FRD si:

- El tratamiento no es completamente determinado por X_i .
- El gráfico de primera etapa muestra un salto < 1 .

6.8. 8. Fórmulas Esenciales para Polinomios Locales

$$Y_i = \alpha + \sum_{j=1}^p \beta_{0j} \tilde{X}_i^j + \rho D_i + \sum_{j=1}^p \beta_{1j} \tilde{X}_i^j D_i + \epsilon_i.$$

Efecto en el umbral:

$$\rho = \text{intercepto derecho} - \text{intercepto izquierdo}.$$

6.9. 9. Interpretación de un Ejercicio Completo (Plantilla General)

1. Identificar X , D , c , Y .
2. Determinar si es SRD o FRD.
3. Graficar:
 - Y vs. X
 - D vs. X (FRD)
 - Covariables vs. X
 - Densidad de X
4. Elegir especificación (polinomios o local linear).
5. Estimar:
 - Sharp: $\rho_{SRD} = \Delta Y$
 - Fuzzy: $\rho_{FRD} = \Delta Y / \Delta D$
6. Presentar interpretación causal localizada.