



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería Industrial y de Sistemas

ICS2563 Econometría aplicada

Apunte de clases

Autor:

- Franco Nicolai Corvalán Mansourova

Fecha de entrega: 21 de noviembre de 2025

Índice de contenido

1 Capítulo 1	4
1.1 El problema fundamental	4
1.2 Tres tipos de preguntas (Cunningham, 2021)	5
1.3 Clasificación de métodos de diseño de investigación	6
1.3.1 Selección sobre observables (SOO - Selection On Observables)	6
1.3.2 Selección sobre no observables (SOU - Selection On Unobservables)	7
2 Capítulo 2:	8
2.1 El modelo de regresión lineal simple (Bivariado)	8
2.1.1 Método 1: esperanza de una Función Condicional (CEF) Lineal	9
2.1.2 Método 2: Predicción Insesgada	10
2.1.3 Método 3: Mínimos Cuadrados Ordinarios (MCO)	11
2.1.4 Caso Especial: Regresor Binario (Discreto)	13
2.2 Métodos de estimación alternativos	13
2.2.1 Método de Momentos (MoM)	14
2.2.2 Máxima Verosimilitud (MLE)	15
2.3 Álgebra Matricial de MCO	17
2.3.1 Interpretación Geométrica: Matrices de Proyección (P) y Residuos (M)	19
2.3.2 Teorema de Frisch-Waugh-Lovell (FWL) - Regresiones Particionadas	22
2.4 Supuestos y Propiedades (Gauss-Markov Profundo)	24
2.4.1 Los Supuestos Clásicos (Explicación Detallada)	24
2.4.2 El Teorema de Gauss-Markov	25
2.5 Test de Hipótesis	26
2.5.1 El problema Epistemológico:	26
2.5.2 La Lógica de la Falsación (Karl Popper)	26
2.5.3 El Estadístico t como medida de distancia	27
2.5.4 ¿Por qué aprendemos esto en Econometría?	27
2.5.5 Insesgamiento de la Varianza del Error (s^2)	28
2.6 Descomposición de la Varianza y Bondad de Ajuste (R^2)	29
2.6.1 El Coeficiente de Determinación (R^2)	31
3 Capítulo 3:	32
3.0.1 El sesgo de la endogeneidad	32

3.1 El Marco de resultados potenciales (POF) o notación Neyman-Rubin	33
3.2 El teorema fundamental de la inferencia causal y sus implicaciones	33
3.3 Diseños de investigación y el modelo experimental	38
3.4 Modelo experimental: el ensayo controlado aleatorizado (RCT)	38
3.5 Modelo experimental SOO vs. SOU: muestra no aleatorizada	41
3.5.1 Modelo 1: Selección en observables (SOO)	42
3.5.2 Modelo 2: Selección en no-observables (SOU)	42
4 Capítulo 4:	44
4.1 Modelo SOU: El Estimador de diferencias en diferencias (2×2)	44
4.2 Modelo SOU: Efectos fijos	48
4.3 Modelo SOU: Triples diferencias (DDD)	49
4.4 Modelo SOU: Estudios de eventos (Event Studies)	50
5 Capítulo 5	51
5.1 Metodo SOU: Variables Instrumentales (IV)	51
5.1.1 Condiciones	52
5.1.2 Deducción del estimador	52
5.1.3 El estimador de Wald	54
5.2 Mínimos Cuadrados en Dos Etapas (2SLS)	55
5.2.1 Generalización	56
5.3 IV con resultados potenciales heterogéneos (LATE)	57
5.3.1 El Teorema LATE	58
5.3.2 Diferencias entre LATE, ATE y TOT	59
5.3.3 Ponderación Kappa (Abadie, 2003)	60
5.4 Diseños Populares de Variables Instrumentales (IV)	61
5.5 Detalles Críticos de IV	61
5.5.1 A. El Sesgo y los Instrumentos Débiles (La "Palanca Rota")	61
5.5.2 B. Regresiones Prohibidas (Forbidden Regressions)	62
5.5.3 C. Tests de Diagnóstico	63
6 Capítulo 6	64

6.1	Regresión discontinua nítida (Sharp RD)	64
6.1.1	Modelos de estimación paramétrica	66
6.1.2	Validez del RD (Pruebas de Robustez)	66
6.2	2. Regresión discontinua borrosa (Fuzzy RD)	67
6.2.1	Estimador Fuzzy RD (Analogía con IV/Wald)	67

1. Capítulo 1

Este capítulo establece los cimientos del curso, definiendo el objetivo central de la econometría moderna: la búsqueda de la causalidad.

1.1. El problema fundamental

Al trabajar con datos, nos enfrentamos a una limitación ontológica similar a la descrita en la alegoría de la caverna de Platón. En el día a día, al muestrear datos, lo que observamos son solo "sombras" de la realidad (los datos observados de los reales), pero nuestro objetivo es entender el objeto real que proyecta esa sombra: la realidad. Nuestro fin último es estimar un efecto causal. Para ello, necesitamos comparar lo que ocurrió con lo que hubiera ocurrido en un mundo alternativo. A este escenario hipotético lo llamamos Contrafactual.



Imagen 1

Alegoría de la caverna de Platón.

El problema es que el contrafactual es inobservable, o sea, nunca podemos ver simultáneamente a la misma persona "tomando" y "no tomando" un medicamento al mismo tiempo. Debido a esto y a que solo vemos "sombras" (datos observacionales), corremos el riesgo de confundir correlación con causalidad. Un ejemplo de esto es el siguiente:

- En verano, se observa una alta correlación positiva entre el consumo de helado y los ataques de tiburones.
- La falacia: ¿Comer helado provoca que los tiburones ataquen? No.

- La realidad (Sesgo): Existe una variable omitida (el calor/verano) que aumenta ambas cosas. Si basáramos políticas públicas solo en datos brutos, prohibiríamos el helado para salvar nadadores, lo cual sería un error desastroso.

Un ejemplo aun más visual de lo anterior es el siguiente que la interpretación se deja al ejercicio del lector:



Imagen 2

Ejemplo de diferencia entre causalidad y correlación.

Nuestra misión es eliminar ese sesgo de selección para acercarnos al verdadero efecto causal, teniendo en cuenta que los datos muestrados no siempre son la mejor sombra de la realidad.

1.2. Tres tipos de preguntas (Cunningham, 2021)

¿En que contexto la econometría aplicada moderna se coloca? Pues esta se distingue por ir más allá de la descripción. Podemos clasificar los distintos movimientos actuales a través de las siguientes preguntas analíticas:

1. Identificación de Patrones (Descripción):

- Pregunta: "¿Tiene cáncer este paciente?" o "¿Quiénes son mis clientes?"
- Objetivo: Clasificar o describir el estado actual basándose en características observables. No busca el "por qué".
- Herramienta: sistemas clasificadores o minería de datos.

2. Predicción:

- Pregunta: "¿Cuántos libros venderé el próximo mes?"
- Objetivo: Estimar valores futuros ($\hat{y}$) basándose en correlaciones históricas.
- Herramientas: Aquí es donde brillan el Machine Learning y el Big Data. Se enfocan en $\hat{y}$, sin necesariamente entender el mecanismo (β).

3. Inferencia Causal (Estimación de Efectos):

- Pregunta: "¿Si subo los precios un 50 %, cuánto bajarán las ventas?"
- Objetivo: Entender el efecto de una intervención (D) sobre un resultado (Y). Requiere construir un contrafactual creíble (el "qué pasaría si").
- Herramienta: la econometría.

Tener más datos (Big Data) es excelente para describir (1) y predecir (2), pero no resuelve por sí solo el problema causal (3). Un millón de datos correlacionados siguen siendo correlación, no causalidad. Para responder preguntas causales, necesitamos un diseño de investigación.

1.3. Clasificación de métodos de diseño de investigación

Para limpiar el sesgo de selección y recuperar el efecto causal, utilizamos dos grandes familias de diseños:

1.3.1. Selección sobre observables (SOO - Selection On Observables)

Intentamos cerrar la puerta trasera controlando por variables visibles.

- Lógica: Asumimos que podemos medir y "controlar" por todas las variables que confunden la relación. Si dos personas tienen la misma edad, educación y experiencia (observables), asumimos que son comparables, o sea, entre ellos son contrafactuales.
- Supuesto clave (CIA): Independencia Condicional ($Y_i(1), Y_i(0) \perp D_i \mid X_i$), o sea, una vez que controlamos por variables observables, la variable de interés es independiente de los factores no observados.
- Métodos: Regresión Lineal Multivariada (OLS con controles), Matching, Propensity Score Matching.
- Filosofía: "I know everything about everything" (Asumo que observo todo lo relevante que afecta el resultado).

1.3.2. Selección sobre no observables (SOU - Selection On Unobservables)

Reconocemos que hay cosas que no podemos medir (habilidad innata, motivación) y que causan sesgo. Buscamos "experimentos naturales" o trucos en el diseño para aislar variación limpia.

- Lógica: No necesito verlo todo; solo necesito encontrar una pequeña parte de la variación en D que sea exógena (Una variable es exógena cuando su valor está determinado por factores externos al modelo y, crucialmente, no tiene correlación con el término de error (no depende de las variables omitidas)).
- Métodos: Variables Instrumentales (IV), Regresión Discontinua (RD), Diferencias en Diferencias (DiD), Efectos Fijos.
- Filosofía: "I know a little bit about a little bit" (Admito mi ignorancia sobre el todo, pero conozco muy bien esta pequeña parte de la variación que es limpia).

2. Capítulo 2:

La regresión lineal es la herramienta más importante para el econometrista. Al imponer una serie de supuestos, nos permite extraer información útil sobre la realidad. Sus tres usos principales son:

1. Resumir información compleja (multivariable).
2. Predecir el futuro de una variable.
3. Inferencia Causal: Analizar el resultado de una intervención (*ceteris paribus*).

2.1. El modelo de regresión lineal simple (Bivariado)

El modelo busca estimar la relación entre una variable dependiente Y y una variable independiente X , denotada como:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

Donde:

- Y : Variable dependiente (outcome).
- X : Variable independiente (regresor, covariable).
- u : Término de error (factores no observados).




Imagen 3

Ilustración de una regresión lineal simple.

Existen tres maneras conceptuales de llegar a los estimadores de Mínimos Cuadrados Ordinarios (MCO). A continuación, desarrollamos matemáticamente cada una.

2.1.1. Método 1: esperanza de una Función Condicional (CEF) Lineal

Si asumimos que la media condicional de Y dado X es lineal en X , podemos recuperar los parámetros poblacionales usando las propiedades de la esperanza y la covarianza.

Supuesto: $\mathbb{E}[Y|X] = \beta_0 + \beta_1 X$

Desarrollo:

1. Esperanza Incondicional (β_0): Usamos la Ley de Esperanzas Iteradas: $\mathbb{E}[Y] = \mathbb{E}_X[\mathbb{E}[Y|X]]$.

$$\mathbb{E}[Y] = \mathbb{E}[\beta_0 + \beta_1 X] = \beta_0 + \beta_1 \mathbb{E}[X]$$

Despejando β_0 :

$$\beta_0 = \mathbb{E}[Y] - \beta_1 \mathbb{E}[X]$$

2. Covarianza (β_1): Partimos de la definición de covarianza:

$$\text{Cov}(Y, X) = \mathbb{E}[YX] - \mathbb{E}[Y]\mathbb{E}[X]$$

Calculamos el término $\mathbb{E}[YX]$ usando esperanzas iteradas:

$$\mathbb{E}[YX] = \mathbb{E}[\mathbb{E}[YX|X]] = \mathbb{E}[X \cdot \mathbb{E}[Y|X]]$$

(Como X es constante dada X , sale de la esperanza condicional).

Sustituimos el supuesto de linealidad:

$$\mathbb{E}[YX] = \mathbb{E}[X(\beta_0 + \beta_1 X)] = \mathbb{E}[\beta_0 X + \beta_1 X^2] = \beta_0 \mathbb{E}[X] + \beta_1 \mathbb{E}[X^2]$$

Sustituimos este resultado en la fórmula de covarianza:

$$\text{Cov}(Y, X) = (\beta_0 \mathbb{E}[X] + \beta_1 \mathbb{E}[X^2]) - (\beta_0 + \beta_1 \mathbb{E}[X])\mathbb{E}[X]$$

$$\text{Cov}(Y, X) = \beta_0 \mathbb{E}[X] + \beta_1 \mathbb{E}[X^2] - \beta_0 \mathbb{E}[X] - \beta_1 (\mathbb{E}[X])^2$$

$$\text{Cov}(Y, X) = \beta_1 (\mathbb{E}[X^2] - (\mathbb{E}[X])^2)$$

Dado que $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$:

$$\text{Cov}(Y, X) = \beta_1 \text{Var}(X)$$

Resultado:

$$\beta_1 = \frac{\text{Cov}(Y, X)}{\text{Var}(X)}$$

2.1.2. Método 2: Predicción Insesgada

Buscamos un predictor lineal $\hat{Y} = a + bX$ que cumpla dos propiedades deseables sobre el error de predicción $e = Y - \hat{Y}$:

1. El error es cero en promedio (Insesgadez).
2. El error no está correlacionado con la variable predictora X .

Desarrollo:

1. Condición 1: $\mathbb{E}[Y - \hat{Y}] = 0$

$$\mathbb{E}[Y - (a + bX)] = 0$$

$$\mathbb{E}[Y] - a - b\mathbb{E}[X] = 0 \implies a = \mathbb{E}[Y] - b\mathbb{E}[X]$$

(Esto nos da la fórmula para el intercepto, igual que antes).

2. Condición 2: $\mathbb{E}[X(Y - \hat{Y})] = 0$ (Esto equivale a decir que la covarianza entre X y el error es cero).

$$\mathbb{E}[X(Y - a - bX)] = 0$$

Sustituimos $a = \mathbb{E}[Y] - b\mathbb{E}[X]$ en la ecuación:

$$\mathbb{E}[X(Y - (\mathbb{E}[Y] - b\mathbb{E}[X]) - bX)] = 0$$

$$\mathbb{E}[XY - X\mathbb{E}[Y] + bX\mathbb{E}[X] - bX^2] = 0$$

Aplicamos esperanza:

$$\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] + b(\mathbb{E}[X])^2 - b\mathbb{E}[X^2] = 0$$

Reordenamos los términos:

$$(\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]) - b(\mathbb{E}[X^2] - (\mathbb{E}[X])^2) = 0$$

Reconocemos las definiciones de Covarianza y Varianza:

$$\text{Cov}(X, Y) - b \cdot \text{Var}(X) = 0$$

Resultado:

$$b = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

2.1.3. Método 3: Mínimos Cuadrados Ordinarios (MCO)

Este es el enfoque algebraico/geométrico. Buscamos los estimadores muestrales $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan la Suma de los Residuos al Cuadrado (SSR), en palabras simples buscaremos resolver un problema de optimización sin restricciones.

Función Objetivo a Minimizar (es prácticamente definición):

$$S(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Desarrollo (Condiciones de Primer Orden):

1. Derivada respecto a $\hat{\beta}_0$:

$$\frac{\partial S}{\partial \hat{\beta}_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

Dividiendo por -2 y sumando:

$$\sum y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum x_i = 0$$

Dividiendo por n :

$$\bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0 \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

2. Derivada respecto a $\hat{\beta}_1$:

$$\frac{\partial S}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

Expandiendo:

$$\sum x_i y_i - \hat{\beta}_0 \sum x_i - \hat{\beta}_1 \sum x_i^2 = 0$$

Sustituimos $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ en esta ecuación:

$$\sum x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \sum x_i - \hat{\beta}_1 \sum x_i^2 = 0$$

$$\sum x_i y_i - \bar{y} \sum x_i + \hat{\beta}_1 \bar{x} \sum x_i - \hat{\beta}_1 \sum x_i^2 = 0$$

Recordemos que $\sum x_i = n\bar{x}$ y $\sum y_i = n\bar{y}$:

$$\sum x_i y_i - n\bar{y}\bar{x} + \hat{\beta}_1 n\bar{x}^2 - \hat{\beta}_1 \sum x_i^2 = 0$$

$$\sum x_i y_i - n\bar{y}\bar{x} = \hat{\beta}_1 (\sum x_i^2 - n\bar{x}^2)$$

Usando la identidad algebraica $\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y}$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{Cov(x, y)}{Var(x)}$$

Resultado (Estimadores Muestrales):

$$\hat{\beta}_1 = \frac{Cov(x, y)}{Var(x)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

2.1.4. Caso Especial: Regresor Binario (Discreto)

Supongamos que la variable independiente T_i es binaria (toma valores 0 o 1).

$$Y_i = \beta_0 + \beta_1 T_i + u_i$$

Podemos calcular la esperanza condicional de Y para cada grupo:

1. Grupo Control ($T_i = 0$):

$$\mathbb{E}[Y|T = 0] = \beta_0 + \beta_1(0) + \mathbb{E}[u|T = 0] = \beta_0$$

(Asumiendo exogeneidad $\mathbb{E}[u|T] = 0$).

2. Grupo Tratamiento ($T_i = 1$):

$$\mathbb{E}[Y|T = 1] = \beta_0 + \beta_1(1) + \mathbb{E}[u|T = 1] = \beta_0 + \beta_1$$

Interpretación de β_1 : Si restamos ambas esperanzas:

$$\mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0] = (\beta_0 + \beta_1) - \beta_0 = \beta_1$$

Por lo tanto, en el caso de un regresor binario, el estimador MCO de la pendiente es simplemente la diferencia de medias entre el grupo tratado y el grupo control.

$$\hat{\beta}_1 = \mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]$$

2.2. Métodos de estimación alternativos

Hasta ahora hemos visto una forma intuitiva y geométrica de ajustar una línea a una nube de datos. Sin embargo, en la estadística y la econometría avanzada, existen principios más generales para construir estimadores. Dos de los más importantes son el Método de Momentos (MoM) y la Máxima Verosimilitud (MLE).

Entender estos métodos es crucial porque nos permiten estimar modelos cuando MCO no es aplicable (por ejemplo, en modelos no lineales o con variables endógenas). Lo importante aclarar es que en el día a día podríamos hacer estos métodos de forma manual pero en la realidad usamos funciones ya

creadas nativas de algunos lenguajes de programación.

2.2.1. Método de Momentos (MoM)

El Método de Momentos es quizás el enfoque más antiguo y "natural" para la estimación. La intuición es simple: Si el modelo teórico impone ciertas condiciones sobre los momentos poblacionales (ej. esperanzas), debemos imponer las mismas condiciones a los momentos muestrales (ej. promedios).

Supongamos que tenemos una población caracterizada por k parámetros desconocidos $\theta_1, \dots, \theta_k$. Si podemos escribir k ecuaciones que relacionen los momentos de la población (como la media μ , la varianza σ^2 , o covarianzas) con estos parámetros, entonces podemos estimar los parámetros reemplazando los momentos poblacionales teóricos ($\mathbb{E}[\cdot]$) con sus contrapartes muestrales ($\frac{1}{n} \sum \cdot$).

Desarrollo en el Modelo de Regresión Lineal:

En el contexto de la regresión lineal $y = X\beta + u$, el modelo poblacional asume ortogonalidad entre los regresores y el error (Exogeneidad Estricta).

Condiciones de Momentos Poblacionales:

1. La media del error es cero:

$$\mathbb{E}[u] = 0$$

2. La covarianza entre los regresores x y el error u es cero (ortogonalidad):

$$\mathbb{E}[x'u] = 0$$

Donde x' es una fila de la matriz X .

El principio de analogía del MoM nos dice que reemplacemos el operador esperanza $\mathbb{E}[\cdot]$ por el promedio muestral $\frac{1}{n} \sum_{i=1}^n$.

Sustituyendo $u_i = y_i - x_i\beta$:

1. $\frac{1}{n} \sum_{i=1}^n (y_i - x_i\hat{\beta}) = 0$
2. $\frac{1}{n} \sum_{i=1}^n x'_i (y_i - x_i\hat{\beta}) = 0$

Si observamos la segunda ecuación (que es vectorial e incluye a la primera si x tiene una constante), podemos reescribirla matricialmente:

$$\frac{1}{n}X'(y - X\hat{\beta}) = 0$$

Multiplicando por n :

$$X'y - X'X\hat{\beta} = 0$$

$$X'X\hat{\beta} = X'y$$

Conclusión:

$$\hat{\beta}_{MOM} = (X'X)^{-1}X'y$$

¡El estimador del Método de Momentos para la regresión lineal es idéntico al estimador MCO (Todavía no lo hemos definido pero es un spoiler)! Esto valida a MCO desde una perspectiva estadística diferente: MCO es el estimador que cumple con las condiciones de momentos poblacionales de exogeneidad.

2.2.2. Máxima Verosimilitud (MLE)

La estimación por Máxima Verosimilitud (Maximum Likelihood Estimation) es un enfoque paramétrico. A diferencia de MCO o MoM (que son semiparamétricos porque solo usan momentos), MLE requiere que asumamos una distribución de probabilidad específica para los datos (usualmente para los errores). Importante aclarar que para dicho método generalmente se espera una comprensión conceptual más allá del desarrollo matemático.

La pregunta que hace MLE es: "Dados los datos que ya observé, ¿cuáles son los valores de los parámetros (β, σ^2) que hacen que estos datos sean lo más probables posible?"

Desarrollo Matemático (Bajo Normalidad):

Asumimos que el proceso generador de datos es:

$$y = X\beta + \varepsilon, \quad \text{donde } \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$$

Esto implica que, condicional a X , la variable y distribuye normal:

$$y_i|x_i \sim \mathcal{N}(x_i\beta, \sigma^2)$$

1. La Función de Densidad (PDF) para una observación:

$$f(y_i|x_i; \beta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y_i - x_i\beta)^2}{2\sigma^2} \right\}$$

2. La Función de Verosimilitud (Likelihood): Como asumimos muestreo aleatorio (independencia), la probabilidad conjunta de observar toda la muestra $(y_1, \dots, y_n)$ es el producto de las probabilidades individuales:

$$L(\beta, \sigma^2|y, X) = \prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y_i - x_i\beta)^2}{2\sigma^2} \right\} \right)$$

3. La Log-Verosimilitud (Log-Likelihood): Es difícil maximizar un producto. Como el logaritmo es una función monótona creciente, maximizar el logaritmo de L es equivalente a maximizar L , pero mucho más fácil matemáticamente (convierte productos en sumas).

$$\mathcal{L}(\beta, \sigma^2) = \ln L = \sum_{i=1}^n \left[\ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) - \frac{(y_i - x_i\beta)^2}{2\sigma^2} \right]$$

Simplificando constantes:

$$\mathcal{L}(\beta, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i\beta)^2$$

4. Maximización respecto a β : Para encontrar el β que maximiza $\mathcal{L}$, derivamos e igualamos a cero. Observa que los dos primeros términos no dependen de β . Maximizar $\mathcal{L}$ respecto a β equivale a minimizar el término negativo final, que es... ¡la Suma de Residuos al Cuadrado!

$$\frac{\partial \mathcal{L}}{\partial \beta} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i'(y_i - x_i\beta) = 0$$

Esto nos lleva nuevamente a las ecuaciones normales:

$$\sum x_i'(y_i - x_i\beta) = 0 \implies \hat{\beta}_{MLE} = (X'X)^{-1}X'y$$

Resultado: Bajo el supuesto de normalidad, $\hat{\beta}_{MLE} = \hat{\beta}_{MCO}$.

5. Maximización respecto a σ^2 : Aquí surge una diferencia importante. Derivando respecto a σ^2 (tratándolo como una variable):

$$\frac{\partial \mathcal{L}}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum (y_i - x_i\beta)^2 = 0$$

Despejando σ^2 :

$$\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - x_i\hat{\beta})^2 = \frac{e'e}{n}$$

¡Ojo! El estimador MLE de la varianza divide por n , no por $n - k$. Esto significa que el estimador MLE de la varianza es sesgado en muestras pequeñas (subestima la varianza), aunque es consistente (el sesgo desaparece cuando $n \rightarrow \infty$).

2.3. Álgebra Matricial de MCO

Cuando pasamos de una variable X (como hemos estado viendo, aunque hemos hecho algunos spoilers) a múltiples variables $(X_1, X_2, \dots, X_k)$, las sumatorias se vuelven inmanejables, por lo que la herramienta necesaria es el Álgebra Matricial.

El modelo general para n observaciones y k variables de ahora en adelante es:

$$y = X\beta + \varepsilon$$

Definición de las matrices:

- y (Vector de Respuesta): Dimensión $n \times 1$. Contiene las observaciones de la variable dependiente.
- X (Matriz de Diseño): Dimensión $n \times k$. La primera columna suele ser de "unos" para el intercepto. Cada fila es un individuo; cada columna es una variable.
- β (Vector de Parámetros): Dimensión $k \times 1$. Los coeficientes que queremos estimar.
- ε (Vector de Errores): Dimensión $n \times 1$.

Queremos encontrar el vector $\mathbf{b}$ (estimador de β) que minimice la Suma de Residuos al Cuadrado (SSR), para ello usaremos el desarrollo de optimización planteado en el método 3 pero ahora de

forma matricial.

Definimos el vector de residuos como $e = y - Xb$. En notación matricial, la suma de cuadrados se expresa como el producto interno del vector de residuos consigo mismo ($e'e$), es por lo tanto la función objetivo que buscamos minimizar:

$$S(b) = e'e = (y - Xb)'(y - Xb)$$

Paso 1: Expansión de la Función. Expandimos el producto utilizando la propiedad de la transpuesta de una suma/resta $(A - B)' = A' - B'$ y la transpuesta de un producto $(AB)' = B'A'$.

$$S(b) = (y' - (Xb)')(y - Xb) = (y' - b'X')(y - Xb)$$

Ahora multiplicamos término a término (propiedad distributiva):

$$S(b) = y'y - y'Xb - b'X'y + b'X'Xb$$

Importante! Observa los términos del medio: $y'Xb$ y $b'X'y$.

- y' es $(1 \times n)$, X es $(n \times k)$, b es $(k \times 1)$. El resultado $y'Xb$ es (1×1) (un escalar).
- La transpuesta de un escalar es el mismo escalar ($a' = a$).
- Tomemos la transpuesta de $y'Xb$:

$$(y'Xb)' = b'X'(y')' = b'X'y$$

- ¡Es exactamente el tercer término! Por lo tanto, $y'Xb = b'X'y$. Podemos sumarlos y obtener:

$$S(b) = y'y - 2b'X'y + b'X'Xb$$

Paso 2: Derivación Matricial (CPO). Para minimizar, derivamos $S(b)$ respecto al vector b e igualamos a cero. Necesitamos dos reglas de cálculo matricial:

1. Derivada de una función lineal: $\frac{\partial(a'b)}{\partial b} = a$. (Aquí $a = X'y$).
2. Derivada de una forma cuadrática: $\frac{\partial(b'Ab)}{\partial b} = 2Ab$ (siempre que A sea simétrica, como lo es $X'X$).

Aplicamos estas reglas a nuestra función:

- La derivada de $y'y$ respecto a b es 0 (no contiene b).

- La derivada de $-2b'X'y$ es $-2X'y$.
- La derivada de $b'X'Xb$ es $2X'Xb$.

$$\frac{\partial S(b)}{\partial b} = -2X'y + 2X'Xb = 0$$

Paso 3: Solución (Ecuaciones Normales). Dividimos por 2 y reordenamos:

$$X'Xb = X'y$$

Estas son las famosas Ecuaciones Normales. Para despejar b , necesitamos "pasar dividiendo" la matriz $X'X$. En matrices, esto significa multiplicar por la inversa.

- Supuesto S2 (Rango Completo): Asumimos que las columnas de X son linealmente independientes. Esto garantiza que $X'X$ es invertible.

Premultiplicamos por $(X'X)^{-1}$:

$$\begin{aligned}(X'X)^{-1}(X'X)b &= (X'X)^{-1}X'y \\ I \cdot b &= (X'X)^{-1}X'y\end{aligned}$$

Resultado Final (Estimador MCO):

$$b = (X'X)^{-1}X'y$$

2.3.1. Interpretación Geométrica: Matrices de Proyección (P) y Residuos (M)

Una vez que tenemos b , podemos calcular los valores predichos ($\hat{y}$) y los residuos (e). Aquí es donde entra la geometría del álgebra lineal.

Aclaración: en un principio no es tan claro por que haremos esto, y razón por la cual la definición de las matrices proyección y residuos son las que definiremos, pero les pedimos que confíen en el proceso.

1. La Matriz de Proyección (P):

Los valores predichos $\hat{y}$ son simplemente X multiplicado por los coeficientes b :

$$\hat{y} = Xb$$

Sustituimos la fórmula de b que acabamos de encontrar:

$$\hat{y} = X[(X'X)^{-1}X'y]$$

$$\hat{y} = [X(X'X)^{-1}X']y$$

Definimos la matriz P como:

$$P \equiv X(X'X)^{-1}X'$$

Entonces:

$$\hat{y} = Py$$

¿Qué significa esto? Geométricamente, el vector y vive en un espacio de n dimensiones. Las columnas de la matriz X generan un "subespacio" (como un plano dentro de una habitación 3D). Generalmente, y no está exactamente en ese plano (por eso hay error). La matriz P toma el vector y y lo proyecta ortogonalmente sobre el plano generado por X . Es como si una linterna brillara desde arriba sobre y : $\hat{y}$ es la "sombra" de y sobre el plano de las variables explicativas. Es la mejor aproximación de y que podemos construir usando solo combinaciones lineales de X .

2. La Matriz de Residuos o Aniquiladora (M):

Los residuos son la diferencia entre lo observado y lo proyectado:

$$e = y - \hat{y}$$

$$e = y - Py = I_n y - Py = (I - P)y$$

Definimos la matriz M como:

$$M \equiv I - P = I - X(X'X)^{-1}X'$$

Entonces:

$$e = My$$

¿Qué significa esto? La matriz M crea los residuos. Se le llama Matriz Aniquiladora porque si la multiplicas por X , el resultado es cero:

$$MX = (I - P)X = X - PX = X - X(X'X)^{-1}X'X = X - XI = 0$$

¡Aniquila a las X ! Esto tiene todo el sentido del mundo: los residuos son, por definición, la parte de y que no tiene nada que ver con X . M extrae la parte de y que es ortogonal (perpendicular) al espacio de X .

Propiedades de P y M :

Ambas matrices son "especiales" en álgebra lineal. Cumplen dos propiedades mágicas:

1. Simetría ($A = A'$):

- $P' = (X(X'X)^{-1}X')' = X((X'X)^{-1})'X' = X(X'X)^{-1}X' = P$.
- $M' = (I - P)' = I' - P' = I - P = M$.

2. Idempotencia ($A^2 = A$): "Aplicarla dos veces es lo mismo que una vez".

- $P^2 = P \cdot P = X(X'X)^{-1}X' \cdot X(X'X)^{-1}X' = P$. (Nota: $X'X(X'X)^{-1} = I$). Intuición: Si ya proyectaste la sombra sobre el piso, volver a proyectar la sombra no la cambia. Ya está en el piso.
- $M^2 = M \cdot M = (I - P)(I - P) = I - P - P + P^2 = I - 2P + P = I - P = M$.

3. Ortogonalidad ($PM = 0$):

- $PM = P(I - P) = P - P^2 = P - P = 0$. La predicción y los residuos son ortogonales entre sí.

Gracias a estas matrices, podemos descomponer cualquier vector y en dos componentes perpendiculares:

$$y = Py + My$$

Y debido al Teorema de Pitágoras (versión matricial), la variación total se descompone perfectamente:

$$y'y = \hat{y}'\hat{y} + e'e$$

2.3.2. Teorema de Frisch-Waugh-Lovell (FWL) - Regresiones Particionadas

El Teorema de Frisch-Waugh-Lovell (FWL) es fundamental en econometría porque nos permite entender cómo funcionan los controles en una regresión múltiple. Nos da una interpretación precisa y paso a paso de qué significa "ceteris paribus" en la práctica estadística.

Imagina que quieres estimar el efecto de una variable X_1 sobre y , pero necesitas controlar por otra variable (o conjunto de variables) X_2 . El modelo completo es:

$$y = X_1\beta_1 + X_2\beta_2 + \varepsilon$$

¿Cómo podemos obtener el estimador β_1 "limpio" del efecto de X_2 ? ¿Es necesario correr la regresión múltiple completa, o podemos hacerlo por partes? Para responder esas preguntas haremos el procedimiento paso a paso de la descomposición FWL.

Importante, este contenido es explicativo, o sea, busca ilustrar lo mencionado previamente, pero en el día a día este ya se encuentra integrado en los software. En el caso hipotético que quisiera encontrar el estimador a mano pues simplemente usa el resultado final. Continuemos con el desarrollo.

El teorema establece que el estimador de β_1 obtenido de la regresión múltiple es numéricamente idéntico al obtenido mediante el siguiente proceso de tres pasos:

1. Paso 1: Limpiar y de X_2 (Residuos de y). Regresamos y sobre X_2 . Obtenemos los residuos, que llamaremos y^* .

$$y^* = M_2y = (I - X_2(X_2'X_2)^{-1}X_2')y$$

Interpretación: y^* es la parte de y que no puede ser explicada por X_2 . Es la variación de y "libre" de la influencia de X_2 .

2. Paso 2: Limpiar X_1 de X_2 (Residuos de X_1). Regresamos X_1 sobre X_2 . Obtenemos los residuos, que llamaremos X_1^* .

$$X_1^* = M_2X_1 = (I - X_2(X_2'X_2)^{-1}X_2')X_1$$

Interpretación: X_1^* es la parte de X_1 que no está correlacionada con X_2 . Es la variación "neta" o "exclusiva" de X_1 .

3. Paso 3: Regresión de Residuos sobre Residuos. Regresamos y^* sobre X_1^* . El estimador resultante

es exactamente igual al $\hat{\beta}_1$ de la regresión múltiple original.

$$\hat{\beta}_1 = (X_1^{*'} X_1^*)^{-1} X_1^{*'} y^*$$

Demostración Matemática:

Partimos del sistema de ecuaciones normales para el modelo completo:

$$\begin{bmatrix} X_1' X_1 & X_1' X_2 \\ X_2' X_1 & X_2' X_2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} X_1' y \\ X_2' y \end{bmatrix}$$

Queremos aislar $\hat{\beta}_1$. De la segunda fila del sistema:

$$X_2' X_1 \hat{\beta}_1 + X_2' X_2 \hat{\beta}_2 = X_2' y$$

Despejamos $\hat{\beta}_2$:

$$\hat{\beta}_2 = (X_2' X_2)^{-1} X_2' y - (X_2' X_2)^{-1} X_2' X_1 \hat{\beta}_1$$

Sustituimos este $\hat{\beta}_2$ en la primera fila del sistema:

$$X_1' X_1 \hat{\beta}_1 + X_1' X_2 [(X_2' X_2)^{-1} X_2' y - (X_2' X_2)^{-1} X_2' X_1 \hat{\beta}_1] = X_1' y$$

Reagrupamos los términos con $\hat{\beta}_1$ y los términos con y :

$$X_1' [I - X_2 (X_2' X_2)^{-1} X_2'] X_1 \hat{\beta}_1 = X_1' [I - X_2 (X_2' X_2)^{-1} X_2'] y$$

Reconocemos la matriz aniquiladora $M_2 = I - X_2 (X_2' X_2)^{-1} X_2'$:

$$X_1' M_2 X_1 \hat{\beta}_1 = X_1' M_2 y$$

Como M_2 es simétrica ($M_2' = M_2$) e idempotente ($M_2^2 = M_2$), podemos escribir $M_2 = M_2' M_2$. Insertamos esto en la ecuación:

$$(M_2 X_1)' (M_2 X_1) \hat{\beta}_1 = (M_2 X_1)' (M_2 y)$$

Recordando que $X_1^* = M_2 X_1$ y $y^* = M_2 y$:

$$(X_1^*)' X_1^* \hat{\beta}_1 = (X_1^*)' y^*$$

Despejamos $\hat{\beta}_1$:

$$\hat{\beta}_1 = (X_1^{*'} X_1^*)^{-1} X_1^{*'} y^*$$

¿Por qué hacemos esto?

- Intuición de "Controlar Por": El teorema nos muestra que el coeficiente β_1 captura el efecto de X_1 sobre y usando solo la variación de X_1 que es independiente de X_2 . Si X_1 y X_2 están muy correlacionados, X_1^* tendrá muy poca varianza, lo que hace que la estimación de β_1 sea imprecisa (aumenta el error estándar).
- Eficiencia Computacional: Históricamente (y en problemas de Big Data hoy), invertir matrices gigantescas es costoso. FWL permite resolver problemas grandes partiendo las variables en bloques.
- Derivación de Sesgo de Variable Omitida: Es la base para demostrar la fórmula de sesgo, mostrando exactamente qué parte de la correlación se atribuye erróneamente a X_1 si omitimos X_2 .

2.4. Supuestos y Propiedades (Gauss-Markov Profundo)

El Teorema de Gauss-Markov es la "joya de la corona" de la econometría clásica. No solo nos da una fórmula para estimar, sino que nos garantiza que, bajo ciertas condiciones, no existe ninguna otra fórmula lineal que sea mejor (más precisa).

2.4.1. Los Supuestos Clásicos (Explicación Detallada)

Para que la magia ocurra, necesitamos que el mundo se comporte de cierta manera:

1. Linealidad en Parámetros: El modelo poblacional verdadero es $y = X\beta + \varepsilon$.
 - Profundidad: Esto no significa que la relación entre Y y X sea una línea recta. Podemos tener X^2 , $\ln(X)$, etc. Lo que debe ser lineal son los β .
 - Riesgo: Si el modelo verdadero es $y = \beta_1/(\beta_2 + X) + \varepsilon$, MCO no sirve directamente.
2. Muestreo Aleatorio: Tenemos una muestra aleatoria de tamaño n del proceso poblacional.
 - Profundidad: Esto garantiza que nuestras observaciones (y_i, x_i) sean independientes e idénticamente distribuidas (i.i.d.). Sin esto, la inferencia se complica (ej. series de tiempo).
3. No Colinealidad Perfecta (Rango Completo): La matriz X tiene rango columna completo (k).

- Profundidad: Matemáticamente, esto permite que $(X'X)^{-1}$ exista. Intuitivamente, significa que cada variable aporta información "nueva". Si $X_1 = 2X_2$, no podemos separar el efecto de X_1 del de X_2 .
4. Exogeneidad Estricta (Media Condicional Cero): $\mathbb{E}[\varepsilon|X] = 0$.
- Profundidad: Este es el supuesto crucial para causalidad. Significa que el error ε (todo lo que no observamos) no tiene un patrón sistemático relacionado con X . Si conocemos X , nuestra mejor predicción para el error sigue siendo 0.
 - Consecuencia Directa: Insensamiento. $\mathbb{E}[b] = \beta$.
5. Homocedasticidad (Varianza Constante): $\text{Var}(\varepsilon|X) = \sigma^2 I$.
- Profundidad: La dispersión de los errores es la misma para todos los valores de X . La "nube" de puntos no se abre como un abanico.
 - Consecuencia: Si esto se cumple, MCO es el estimador más eficiente. Si no, MCO sigue siendo insensado, pero sus errores estándar están mal calculados y ya no es el mejor (BLUE).

2.4.2. El Teorema de Gauss-Markov

Bajo los supuestos 1 al 5 (Linealidad a Homocedasticidad), el estimador de Mínimos Cuadrados Ordinarios (b) es el Mejor Estimador Lineal Insensado (MELI o BLUE en inglés).

Vamos a desglosar qué significa cada letra de MELI/BLUE:

- Estimador: Es una regla o fórmula para calcular una estimación a partir de los datos.
- Lineal: El estimador b puede escribirse como una combinación lineal de los datos observados y .

$$b = (X'X)^{-1}X'y = Ay$$

Donde A es una matriz de "pesos" que solo depende de X .

- Insensado: En promedio, si repitiéramos el muestreo muchas veces, el estimador le "pegaría" al verdadero valor β .

$$\mathbb{E}[b] = \beta$$

- Mejor (Eficiente): Aquí está la potencia del teorema. "Mejor" significa que tiene la Mínima Varianza. Si tomas cualquier otro estimador $\tilde{b}$ que también sea Lineal e Insensado, la varianza de MCO será menor o igual.

$$\text{Var}(b) \leq \text{Var}(\tilde{b})$$

¿Por qué nos importa? Nos dice que no necesitamos buscar algoritmos más complicados. Si los supuestos se cumplen, MCO es imbatible en precisión dentro de su clase. Hemos agotado toda la información disponible en los datos.

2.5. Test de Hipótesis

Llegamos al corazón de la práctica econométrica. ¿Por qué no nos basta con decir "el efecto estimado es $\beta = 0.5$ "?

2.5.1. El problema Epistemológico:

La econometría opera casi siempre con muestras, no con poblaciones enteras. Además, podemos trabajar con datos generados por procesos estocásticos (aleatorios). Si estimas un $\hat{\beta} = 0.5$, hay dos posibilidades ontológicas sobre la realidad:

1. La Señal: Existe un efecto real en la población ($\beta \neq 0$), y tu dato lo capturó.
2. El Ruido: El efecto real es nulo ($\beta = 0$), pero por pura casualidad del muestreo (suerte, azar, error muestral), obtuviste un 0.5.

El Test de Hipótesis es la herramienta metodológica diseñada para disciplinar nuestra inferencia y distinguir sistemáticamente entre señal y ruido. Es un mecanismo de defensa contra el auto-engañó de encontrar patrones donde solo hay azar.

2.5.2. La Lógica de la Falsación (Karl Popper)

En ciencia, rara vez podemos "probar" que algo es verdadero definitivamente. Sin embargo, podemos probar que algo es falso (o altamente improbable).

- Hipótesis Nula (H_0): Es la postura escéptica. Asumimos que "no pasa nada", que el efecto es cero ($\beta = 0$). Es el "abogado del diablo".
- Hipótesis Alternativa (H_a): Es nuestra teoría, lo que queremos demostrar ($\beta \neq 0$).

La econometría no busca confirmar H_a directamente. Busca ver si los datos son tan extraños, tan incompatibles con H_0 , que nos vemos obligados a rechazar el escepticismo.

2.5.3. El Estadístico t como medida de distancia

La esencia del Test de Hipótesis es pasar de la postura filosófica del escepticismo, la Hipótesis Nula ($H_0 : \beta = 0$) que asume que el efecto es nulo, a una decisión metodológica. Si el Test de Hipótesis nos exige rechazar H_0 solo cuando la evidencia de la muestra es demasiado extrema para ser explicada por el puro azar (el Ruido), necesitamos una métrica precisa para definir qué tan "extrema" es nuestra estimación $\hat{\beta}$. Aquí es donde entra el Estadístico t : es la herramienta diseñada para cuantificar esa distancia. Nos da una medida estandarizada, expresada en errores estándar ($se(\hat{\beta})$), de cuánto se aleja nuestra estimación de lo que esperaríamos si el mundo realmente fuera aquel de la H_0 (donde $\beta = 0$). Un valor alto de t indica una gran distancia y, por lo tanto, una baja probabilidad de que el resultado sea Ruido, obligándonos a considerar que hemos capturado una Señal.

$$t = \frac{\hat{\beta} - \beta_{H0}}{se(\hat{\beta})}$$

Nos dice: "¿A cuántas desviaciones estándar del cero (el mundo donde no pasa nada) está nuestra estimación?"

- Si t es bajo (ej. 0.5): Estamos cerca del cero. Es fácil obtener este dato por puro azar. No rechazamos H_0 .
- Si t es alto (ej. 5.0): Estamos lejísimos del cero. Es extremadamente improbable obtener este dato si el verdadero efecto fuera nulo. Rechazamos H_0 .

El valor-p responde a la pregunta: En un mundo donde la hipótesis nula es cierta, ¿cuál es la probabilidad de ver una muestra tan extrema como la que tengo?

- Un valor-p de 0.001 significa que si el efecto fuera cero, solo 1 de cada 1000 veces veríamos datos como estos. Como eso es muy raro, concluimos que probablemente el efecto no sea cero.

2.5.4. ¿Por qué aprendemos esto en Econometría?

En economía y políticas públicas, las decisiones tienen costos.

- Decir que un programa social funciona cuando no lo hace (Error Tipo I) implica gastar millones en algo inútil.
- Decir que no funciona cuando sí lo hace (Error Tipo II) implica privar a la sociedad de un beneficio.

Aprendemos test de hipótesis para cuantificar nuestra incertidumbre. No se trata de buscar la "verdad absoluta", sino de tomar decisiones bajo incertidumbre con un nivel de riesgo controlado (α , usualmente 5%).

En el contexto de inferencia causal (SOU), el test de hipótesis adquiere una capa adicional: no solo preguntamos si la correlación es real, sino si la estrategia de identificación (IV, RD, DiD) ha logrado aislar la señal causal del ruido de la selección. Un coeficiente significativo en una regresión mal especificada (con endogeneidad) es una "señal falsa" muy precisa, lo cual es el peligro más grande en econometría aplicada: estar precisamente equivocados.

2.5.5. Inesgamiento de la Varianza del Error (s^2)

Para hacer pruebas de hipótesis (test-t), necesitamos conocer la varianza del error σ^2 . Como no la observamos, la estimamos usando los residuos e .

El estimador natural sería el promedio de los residuos al cuadrado: $\frac{e'e}{n}$. ¡Pero este está sesgado! Subestima la verdadera varianza. ¿Por qué? Los residuos e se calculan usando b (estimado), no β (verdadero). El método MCO "fuerza" a los residuos a ser lo más pequeños posible para esta muestra específica. Esto hace que $e'e$ sea sistemáticamente menor que $\varepsilon'\varepsilon$.

Para corregirlo, dividimos por los grados de libertad ($n - k$), no por el tamaño de la muestra (n).

$$s^2 = \frac{e'e}{n - k}$$

Demostración Matemática (Usando la Matriz M):

1. Sabemos que $e = M\varepsilon$ (La matriz M crea los residuos a partir del error verdadero).
2. La suma de residuos al cuadrado es:

$$e'e = (M\varepsilon)'(M\varepsilon) = \varepsilon'M'M\varepsilon$$

3. Como M es simétrica e idempotente ($M'M = M$):

$$e'e = \varepsilon'M\varepsilon$$

4. Queremos la esperanza $\mathbb{E}[e'e]$. Usamos el truco de la traza (la traza de un escalar es el mismo escalar):

$$\mathbb{E}[e'e] = \mathbb{E}[\text{tr}(\varepsilon'M\varepsilon)] = \mathbb{E}[\text{tr}(M\varepsilon\varepsilon')]$$

(Propiedad de la traza: $\text{tr}(ABC) = \text{tr}(BCA)$).

5. Sacamos M de la esperanza (es fija condicional a X):

$$\mathbb{E}[e'e] = \text{tr}(M \cdot \mathbb{E}[\varepsilon\varepsilon'])$$

6. Por el supuesto de Homocedasticidad, $\mathbb{E}[\varepsilon\varepsilon'] = \sigma^2 I$:

$$\mathbb{E}[e'e] = \text{tr}(M \cdot \sigma^2 I) = \sigma^2 \text{tr}(M)$$

7. ¿Cuál es la traza de M ?

$$\text{tr}(M) = \text{tr}(I_n - P) = \text{tr}(I_n) - \text{tr}(P) = n - \text{tr}(P)$$

$$\text{tr}(P) = \text{tr}(X(X'X)^{-1}X') = \text{tr}((X'X)^{-1}X'X) = \text{tr}(I_k) = k$$

(Donde k es el número de regresores).

$$\text{tr}(M) = n - k$$

8. Sustituyendo de vuelta:

$$\mathbb{E}[e'e] = \sigma^2(n - k)$$

Por lo tanto, para obtener un estimador insesgado de σ^2 , debemos dividir por $(n - k)$:

$$\mathbb{E}\left[\frac{e'e}{n - k}\right] = \frac{\sigma^2(n - k)}{n - k} = \sigma^2$$

2.6. Descomposición de la Varianza y Bondad de Ajuste (R^2)

Una vez que hemos estimado el modelo, queremos saber qué tan bien "ajusta" los datos. Para esto, descomponemos la variación total de y . Partimos de la identidad fundamental de los datos observados:

$$y_i = \hat{y}_i + e_i$$

(Dato Real = Predicción + Error Residual).

Si restamos la media $\bar{y}$ a ambos lados:

$$(y_i - \bar{y}) = (\hat{y}_i - \bar{y}) + e_i$$

Elevamos al cuadrado y sumamos para todos los individuos:

$$\begin{aligned}\sum (y_i - \bar{y})^2 &= \sum [(\hat{y}_i - \bar{y}) + e_i]^2 \\ \sum (y_i - \bar{y})^2 &= \sum (\hat{y}_i - \bar{y})^2 + \sum e_i^2 + 2 \sum (\hat{y}_i - \bar{y})e_i\end{aligned}$$

El término cruzado es CERO: Gracias a las propiedades de MCO (ortogonalidad), los residuos e_i no tienen correlación con las predicciones $\hat{y}_i$. Por tanto, $2 \sum (\hat{y}_i - \bar{y})e_i = 0$. Esto nos deja con la Ecuación

de Análisis de Varianza (ANOVA):

$$SCT = SCE + SCR$$

Donde:

■ **Suma de Cuadrados Total (SCT):**

- Definición:

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2$$

- Concepto: Representa la variabilidad total de los datos observados. Es lo que queremos explicar.
- Notación matricial (centrada):

$$SCT = \mathbf{y}'\mathbf{A}\mathbf{y}$$

donde $\mathbf{A}$ es la matriz generadora de desviaciones.

■ **Suma de Cuadrados Explicada (SCE):**

- Definición:

$$SCE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- Concepto: Representa la variabilidad capturada por nuestro modelo (la "señal").
- Notación matricial:

$$SCE = \hat{\mathbf{y}}'\mathbf{A}\hat{\mathbf{y}}$$

■ **Suma de Cuadrados de Residuos (SCR):**

- Definición:

$$SCR = \sum_{i=1}^n e_i^2$$

- Concepto: Representa la variabilidad no explicada o residual (el "ruido"). Es lo que minimizamos con MCO.
- Notación matricial:

$$SCR = \mathbf{e}'\mathbf{e}$$

2.6.1. El Coeficiente de Determinación (R^2)

El R^2 es simplemente la proporción de la variabilidad total que nuestro modelo logró explicar.

$$R^2 = \frac{\text{Variabilidad Explicada}}{\text{Variabilidad Total}} = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

- R^2 puede tomar valores de: $0 \leq R^2 \leq 1$.
- Interpretación: Un $R^2 = 0.65$ significa que el 65 % de la variación en Y es explicada por las variables X incluidas en el modelo.
- Conexión con P : El R^2 mide qué tan "cerca" está el vector y de su proyección Py . Si y cae exactamente en el plano (error cero), $y = Py$, $SCR = 0$ y $R^2 = 1$.
- Importante: tener un R^2 más grande no implica que el modelo sea más explicativo, pues se puede demostrar que existe una relación directa entre la cantidad de variables que tiene un modelo vs. R^2 , o sea, entre más variables, más grande será R^2 .

3. Capítulo 3:

Una vez que hemos definido la herramienta (la regresión lineal) para estimar el efecto causal, surge una pregunta clave sobre su aplicabilidad real. Sabemos que el estimador de Mínimos Cuadrados Ordinarios (MCO) es BLUE (Best Linear Unbiased Estimator) bajo los supuestos de Gauss-Markov. Esto implica que, en un escenario ideal, MCO es la mejor herramienta posible.

Sin embargo, el principio fundamental sigue siendo: "Garbage In, Garbage Out."

Aunque MCO sea una excelente herramienta estadística, su validez causal se derrumba si los datos de entrada están contaminados o si los supuestos cruciales (como la exogeneidad o ausencia de endogeneidad) son violados.

Por lo tanto, nuestro siguiente paso en econometría aplicada es doble:

- Identificar y entender todas las amenazas que pueden contaminar nuestro análisis causal (como la variable omitida, la simultaneidad o el error de medición).
- Desarrollar y proponer estrategias de identificación robustas (o "experimentos naturales") que permitan atacar estas amenazas y aislar el verdadero efecto causal, distinguiendo la correlación de la causalidad.

3.0.1. El sesgo de la endogeneidad

El sesgo de endogeneidad es el fallo más crítico en la regresión de mínimos cuadrados ordinarios (MCO) para la inferencia causal y ocurre cuando la variable de tratamiento (D) está correlacionada con el término de error (ε):

$$\text{Cov}(D, \varepsilon) \neq 0$$

Esta correlación espuria significa que el término de error está capturando información relevante para la variable D (variable independiente en teoría). Dicha información suele ser una variable omitida que afecta tanto al tratamiento como al resultado, o bien se debe a la causalidad inversa (donde Y afecta a D). La consecuencia directa de esta violación es que los estimadores MCO ($\hat{\beta}$) son sesgados ($\mathbb{E}[\hat{\beta}] \neq \beta$) e inconsistentes (el sesgo no desaparece incluso con una muestra muy grande). Por lo tanto, el modelo no logra aislar el efecto causal puro de D sobre Y , llevando a conclusiones erróneas.

Fuentes principales de endogeneidad:

- **Variables Omitidas (OVB, Omitted-Variable Bias):** Una variable crucial no incluida en el modelo (Z) afecta al resultado (Y) y, a su vez, está correlacionada con el tratamiento (D). Esta

variable Z es absorbida por el término de error (ε), creando la correlación $\text{Cov}(D, \varepsilon) \neq 0$. El sesgo resultante en el estimador $\hat{\beta}$ es:

$$\mathbb{E}[\hat{\beta} \mid D, Z] = \beta + \underbrace{\rho_{D,Z}\gamma}_{\text{Sesgo OVB}}$$

Donde $\rho_{D,Z}$ es la correlación entre D y Z , y γ es el efecto real de Z sobre Y .

- **Causalidad Inversa:** El resultado (Y) influye en la asignación del tratamiento (D), creando un bucle de retroalimentación (e.g., las personas más saludables se inscriben en el gimnasio).

3.1. El Marco de resultados potenciales (POF) o notación Neyman-Rubin

Las Fuentes de Endogeneidad (como el Sesgo por Variable Omitida, OVB) son la manifestación empírica del fracaso en aislar el efecto causal verdadero. Para combatir estos sesgos de manera rigurosa, no podemos limitarnos a la estadística; primero debemos definir qué es el efecto causal que estamos tratando de estimar. El Marco de Resultados Potenciales (POF), o Notación Neyman-Rubin, sirve precisamente como el lenguaje fundacional y matemático que define el efecto causal individual.

A continuación se detallan los componentes principales de este modelo propuesto:

- $Y_i(1)$: Resultado potencial (Tratado), es el valor del resultado (Y) que el individuo i observaría teóricamente si recibiera el tratamiento ($D_i = 1$).
- $Y_i(0)$: Resultado potencial (Control), es el valor del resultado (Y) que el individuo i observaría teóricamente si no recibiera el tratamiento ($D_i = 0$).
- τ_i : Efecto causal individual, es la diferencia entre los dos resultados potenciales para un mismo individuo. Se define matemáticamente como:

$$\tau_i = Y_i(1) - Y_i(0)$$

3.2. El teorema fundamental de la inferencia causal y sus implicaciones

El Teorema fundamental de la inferencia causal es una declaración concisa sobre la imposibilidad de observar el efecto causal en un solo individuo. En términos simples, establece lo siguiente:

Es imposible observar simultáneamente los dos resultados potenciales, $Y_i(1)$ (el resultado con tratamiento) y $Y_i(0)$ (el resultado sin tratamiento), para una misma unidad i (persona) en un mismo punto en el tiempo.

Esta limitación implica que, para cualquier individuo i , una de las dos cantidades ($Y_i(1)$ o $Y_i(0)$) será siempre desconocida (un contrafactual no observable). Esto hace que sea imposible calcular el efecto causal individual (τ_i) con certeza directa. La Solución, el diseño de investigación. Dado que no podemos observar los dos estados en la misma persona simultáneamente, utilizamos el diseño de investigación (como experimentos aleatorios) para resolver este problema a nivel grupal. En palabras simples: aunque no podemos ver qué le habría pasado a un individuo tratado si no hubiera recibido el tratamiento, podemos buscar a otro individuo (o grupo) muy similar que no recibió el tratamiento. Si logramos que ambos individuos sean comparables (bajo condiciones ceteris paribus), asumimos que el resultado del individuo no tratado sirve como el sustituto del contrafactual del individuo tratado. De esta forma, ya no comparamos al individuo consigo mismo, sino que comparamos promedios entre grupos equivalentes para estimar el efecto causal.

Con lo anterior explicado, y de forma más precisa, buscaremos por lo tanto que el grupo de control ofrece un válido contrafactual del grupo de tratamiento de no haber sido tratado, y el grupo de tratamiento ofrece un válido contrafactual del grupo de control de haber sido tratado. Esto se traduce usando la notación Neyman-Rubin:

$$\mathbb{E}[Y_i(1)|T_i = 1] - \mathbb{E}[Y_i(0)|T_i = 0] = \underbrace{\mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)]}_{\text{Si el grupo de control fuera un contrafactual válido}}$$

Para que la comparación entre grupos observados tenga una interpretación causal, debemos garantizar que los grupos sean intercambiables. Esto se formaliza mediante el **Supuesto de Independencia** (o ignorabilidad).

Para que el grupo de control sirva como un contrafactual válido del grupo de tratamiento, la asignación del tratamiento D_i debe ser independiente de los resultados potenciales. Matemáticamente:

$$\{Y_i(0), Y_i(1)\} \perp D_i$$

Esto implica que el hecho de recibir el tratamiento no está correlacionado con las características inherentes (observables o no) de los individuos. Bajo este supuesto, los promedios condicionales se igualan a los poblacionales:

$$\mathbb{E}[Y_i(0) | D_i = 1] = \mathbb{E}[Y_i(0) | D_i = 0] = \mathbb{E}[Y_i(0)] \quad (1)$$

En palabras simples, el resultado base de los tratados sería idéntico, en promedio, al de los no tratados si no hubieran recibido el tratamiento).

El objetivo es estimar el ATE (Average Treatment Effect). Si se cumple la aleatorización (o independencia), la "Diferencia de Medias Observada" se convierte en el efecto causal:

$$\begin{aligned}
\text{Diferencia Observada} &= \mathbb{E}[Y_i | D_i = 1] - \mathbb{E}[Y_i | D_i = 0] \\
&= \mathbb{E}[Y_i(1) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 0] \quad (\text{por consistencia}) \\
&= \mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)] \quad (\text{por independencia}) \\
&= \mathbb{E}[Y_i(1) - Y_i(0)] \\
&= \text{ATE}
\end{aligned}$$

O sea:

$$\mathbb{E}[Y_i(1) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 0] = \text{ATE}$$

Por lo tanto, bajo aleatorización, la simple resta de promedios es un estimador insesgado del ATE.

En ocasiones, el interés de la investigación no recae en el efecto poblacional (ATE), sino específicamente en el impacto sobre aquellos que efectivamente participaron en el programa. Definimos el ATT (*Average Treatment Effect on the Treated*) como:

$$\tau_{ATT} = \mathbb{E}[Y_i(1) - Y_i(0) | D_i = 1]$$

Sin embargo, al intentar estimar este efecto mediante una comparación simple de medias entre el grupo tratado y el no tratado, nos enfrentamos al problema de identificación.

Para comprender por qué la correlación no implica causalidad, descomponemos analíticamente la diferencia de medias observada. Partimos de la diferencia simple:

$$\Delta_{\text{obs}} = \mathbb{E}[Y_i | D_i = 1] - \mathbb{E}[Y_i | D_i = 0]$$

Sumamos y restamos el término contrafactual fundamental $\mathbb{E}[Y_i(0) | D_i = 1]$ (el resultado de los tratados si no hubieran sido tratados) dentro de la ecuación:

$$\begin{aligned}
\Delta_{\text{obs}} &= \mathbb{E}[Y_i(1) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 0] \\
&= \mathbb{E}[Y_i(1) | D_i = 1] - \underbrace{\mathbb{E}[Y_i(0) | D_i = 1] + \mathbb{E}[Y_i(0) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 0]}_{\text{Sumamos y restamos 0}}
\end{aligned}$$

Reagrupando los términos, obtenemos la ecuación del sesgo de selección:

$$\Delta_{\text{obs}} = \underbrace{\{\mathbb{E}[Y_i(1) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 1]\}}_{\text{ATT}} + \underbrace{\{\mathbb{E}[Y_i(0) | D_i = 1] - \mathbb{E}[Y_i(0) | D_i = 0]\}}_{\text{Sesgo de Selección}} \quad (2)$$

Interpretación de los componentes:

- ATT (Efecto Causal): Es la parte de la diferencia que se debe puramente al tratamiento. Representa el cambio en el resultado de los tratados comparado con su propio contrafactual.

- **Sesgo de selección:** Es la diferencia preexistente entre los grupos. Representa cómo se comparan los resultados basales (sin tratamiento) de los tratados frente a los no tratados. Si $\text{Sesgo} \neq 0$, los grupos no son comparables estructuralmente (ej. los tratados eran más ricos, más hábiles o más enfermos antes del tratamiento).

En un experimento aleatorio ideal, la asignación D_i es independiente de los resultados potenciales ($Y_i(0) \perp D_i$). Esto implica que:

$$\mathbb{E}[Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(0) \mid D_i = 0]$$

Esto hace que el término de Sesgo de Selección sea igual a cero, permitiendo que la diferencia observada recupere el efecto causal verdadero. Sin embargo, aunque los supuestos mencionados son convenientes por su capacidad de inferencia estadística sin necesidad de mayores supuestos, existen amenazas a su validez interna:

1. **Attrition (Atrición o Desgaste de Muestra):** Ocurre cuando los individuos abandonan el estudio o se pierden datos de seguimiento. Esto genera un problema de datos faltantes no aleatorios.

Si $S_i = 1$ indica que el individuo permanece en la muestra, el estimador disponible es:

$$\widehat{\text{ATE}}_{\text{obs}} = \mathbb{E}[Y_i \mid D_i = 1, S_i = 1] - \mathbb{E}[Y_i \mid D_i = 0, S_i = 1]$$

Para que esto no genere sesgo, la atrición debe ser aleatoria (MCAR). Si la probabilidad de abandonar ($S_i = 0$) depende de los resultados potenciales $Y_i(1)$ o $Y_i(0)$ (ej. los más enfermos abandonan el tratamiento médico), el estimador estará sesgado y la comparabilidad de los grupos se rompe.

2. **Imperfect Compliance (Cumplimiento Imperfecto):** Sucede cuando la asignación aleatoria no coincide con el tratamiento recibido.

- Z_i : Asignación (Intención).
- D_i : Tratamiento recibido (Realidad).

Si hay non-compliance (asignados que no se tratan) o take-up de controles (no asignados que consiguen el tratamiento), comparar según D_i reintroduce el sesgo de selección. La solución es estimar la Intención de Tratar (ITT):

$$\text{ITT} = \mathbb{E}[Y_i \mid Z_i = 1] - \mathbb{E}[Y_i \mid Z_i = 0]$$

El ITT estima el efecto de la oferta del programa, no del programa en sí. Mantiene la validez de la aleatorización porque Z_i es aleatorio, aunque D_i no lo sea.

Si $D_i = Z_i$ para todos (Cumplimiento Perfecto) $\implies$ ITT = ATE

3. **SUTVA (Stable Unit Treatment Value Assumption):** Es el supuesto fundamental para definir los resultados potenciales. Se compone de dos partes:

- a. **No Interferencia (No Spillovers):** El resultado potencial del individuo i depende solo de su propio tratamiento y no de la asignación de tratamiento de otros individuos ($j \neq i$).

$$Y_i(\mathbf{D}) = Y_i(D_i)$$

Violación común: Efectos de contagio (vacunas) o efectos de equilibrio general (mercado laboral).

- b. **Consistencia (No Hidden Variations):** Solo existe una versión del tratamiento. Si $D_i = 1$, el resultado observado es $Y_i(1)$ sin ambigüedad. No importa "cómo" recibió el tratamiento, sino "que" lo recibió.

Formalmente, SUTVA implica que podemos escribir $Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$ de forma única.

Por lo tanto, cada uno de los puntos anteriores deben tomarse en cuenta al momento de desarrollar un modelo experimental.

Tabla 1*Términos Clave de la Inferencia Causal*

Nombre	Explicación Breve	Fórmula
ATE	El Efecto de Tratamiento Promedio a nivel poblacional. Es el verdadero parámetro que se busca identificar.	$ATE = \mathbb{E}[Y_i(1) - Y_i(0)]$
$\widehat{ATE}$	El Estimador del ATE de la muestra. Es la Diferencia de Medias Observadas entre grupos.	$\widehat{ATE} = \bar{Y}_{Tratado} - \bar{Y}_{Control}$
ITT	El Efecto de Intención de Tratar . Mide el impacto de la asignación (Z), no del tratamiento efectivo (D).	$ITT = \mathbb{E}[Y_i Z_i = 1] - \mathbb{E}[Y_i Z_i = 0]$
ATT o TOT	El Efecto del Tratamiento en los Tratados . Efecto causal promedio solo en el subgrupo que recibió el tratamiento ($D = 1$).	$ATT \equiv \tau_{TOT} = \mathbb{E}[Y_i(1) - Y_i(0) D = 1]$
Sesgo de Selección	Diferencia en el resultado contra-factual sin tratamiento (Y_0) entre el grupo tratado ($D = 1$) y el de control ($D = 0$).	$Sesgo = \mathbb{E}(Y_0 D = 1) - \mathbb{E}(Y_0 D = 0)$

3.3. Diseños de investigación y el modelo experimental

Una vez definidas las herramientas del marco Neyman-Rubin, analizaremos su aplicación en distintos escenarios. La distinción fundamental para elegir la metodología correcta radica en el mecanismo de asignación del tratamiento, lo que divide a los estudios en dos grandes categorías:

- **Estudios Observacionales:** Son aquellos donde el investigador actúa como un espectador pasivo. Registra datos sin influir en la asignación del tratamiento (D_i), la cual es determinada por los propios participantes, por políticas administrativas o por la naturaleza. Esto suele introducir sesgos, ya que la asignación no es aleatoria.
- **Estudios Experimentales:** Son aquellos donde el investigador interviene activamente manipulando el entorno. El mecanismo de asignación del tratamiento está bajo control del diseño de investigación, lo que permite buscar la exogeneidad.

3.4. Modelo experimental: el ensayo controlado aleatorizado (RCT)

Dentro de los modelos experimentales, el "Gold Standard" es el **Ensayo Controlado Aleatorizado** (RCT). En este diseño, la asignación del tratamiento (D_i) se determina puramente por azar (lotería, generador de números aleatorios).

Esta aleatorización garantiza matemáticamente que la asignación es independiente de las características de los participantes y de sus resultados potenciales:

$$\{Y_i(0), Y_i(1)\} \perp D_i$$

El cumplimiento de esta independencia asegura tres consecuencias fundamentales que resuelven el problema de identificación:

1. **Eliminación del Sesgo de Selección:** Al ser independientes, los grupos de tratamiento y control son estadísticamente equivalentes en sus resultados potenciales (intercambiables).

$$\mathbb{E}[Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(0) \mid D_i = 0]$$

2. **El Grupo de Control como Contrafactual Válido:** Podemos usar con confianza el resultado promedio del grupo de control para estimar qué le habría pasado al grupo de tratamiento de no haber sido tratado.
3. **Identificación del ATE:** La simple diferencia de medias observada se convierte en un estimador insesgado del efecto causal:

$$\widehat{ATE} = \underbrace{\mathbb{E}[Y_i \mid D_i = 1]}_{\text{Observado en Tratados}} - \underbrace{\mathbb{E}[Y_i \mid D_i = 0]}_{\text{Observado en Control}}$$

$$(Y_i(1), Y_i(0)) \perp D_i$$

Gracias a la aleatorización, el grupo de control proporciona una estimación insesgada del contrafactual:

$$E[Y(0) \mid D = 1] = E[Y(0) \mid D = 0]$$

Lo que afecta directamente en:

$$E[Y \mid D = 1] - E[Y \mid D = 0] = ATT + \underbrace{(E[Y(0) \mid D = 1] - E[Y(0) \mid D = 0])}_{\text{Sesgo de Selección}} = ATT$$

Esto permite identificar el ATE simplemente tomando la diferencia de medias observadas.

Implementación de un modelo de regresión lineal:

Al asegurar que la asignación al tratamiento (D_i) es completamente aleatoria y, por lo tanto, independiente de los resultados potenciales ($\mathbf{Y}_i(1), \mathbf{Y}_i(0)$), se satisface automáticamente el supuesto de no-correlación entre la variable de tratamiento y el término de error ($\text{Cov}(D_i, \varepsilon_i) = 0$).

- **El Modelo observado (MCO):** Dado que D_i es exógeno por diseño, el Efecto de Tratamiento Promedio (ATE) puede estimarse directamente usando la regresión lineal más simple. El

coeficiente $\hat{\beta}$ capta la diferencia de medias observadas, que es igual al ATE insesgado:

$$Y_i = \alpha + \beta D_i + \varepsilon_i$$

El estimador MCO $\hat{\beta}$ en este modelo es $\hat{\beta} = \mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0] = \text{ATE}$.

- **Aumento de precisión con controladores ($\mathbf{X}_i$):** La inclusión de variables de control ($\mathbf{X}_i$) que afectan el resultado (Y_i) no se realiza para corregir el sesgo (pues ya es insesgado), sino para reducir la varianza del estimador $\hat{\beta}$ y hacer la prueba de hipótesis más potente. Al "explicar" una parte de la variación en Y_i con $\mathbf{X}_i$, se reduce el tamaño del término de error ε_i , lo que se traduce en un error estándar más pequeño para $\hat{\beta}$ (mayor precisión):

$$Y_i = \alpha + \beta D_i + \delta h(\mathbf{X}_i) + \varepsilon_i$$

En resumen, la aleatorización transforma el problema de inferencia causal en un simple problema de regresión MCO, donde el coeficiente $\hat{\beta}$ ya tiene una interpretación causal directa.

Aunque la aleatorización garantiza teóricamente la independencia, en la práctica es fundamental verificar que los grupos sean efectivamente comparables en sus características observables.

- **Objetivo:** Demostrar que el grupo de tratamiento y el de control son estadísticamente indistinguibles antes de la intervención.
- **Implementación:** Se debe presentar una tabla de estadísticas descriptivas (conocida como *Balance Table*, ver ejemplo en Amaral et al., 2022) que compare las medias de las variables covariables (X_i) entre ambos grupos.
- **Criterio:** Si la aleatorización funcionó correctamente, la diferencia de medias entre grupos para las variables pre-tratamiento debería ser cercana a cero y no significativa estadísticamente. Esto sustenta la validez de asumir que también son iguales en lo *no observado*.

Adicionalmente a los supuestos de SUTVA, Holland (1986) introduce una distinción crucial para la inferencia causal: "**No causation without manipulation**". Es necesario distinguir entre los efectos de una causa y las causas de un efecto. Para que un tratamiento sea válido en este marco, debe ser manipulable.

- **Atributo (No manipulable):** "El estudiante obtuvo buena nota porque es mujer". El género es un atributo intrínseco, no un tratamiento que podamos asignar o retirar ceteris paribus.
- **Causa (Manipulable):** "El estudiante obtuvo buena nota porque estudió". Estudiar es una acción/tratamiento que puede ser modificada experimentalmente.

Con lo anterior definimos lo modelo experimental que puede ser bastante eficiente, lo relevante es que ningún método es perfecto, por lo que a continuación mencionamos las ventajas y desventajas de RCT:

Tabla 2*Ventajas y desventajas del RCT*

Aspecto	Consideración
Ventaja Principal	Es la forma más transparente y limpia de eliminar el sesgo de selección, ya que la asignación aleatoria garantiza la exogeneidad de D .
Desventaja 1: Costo/Práctica	El diseño, la recolección de datos y la implementación de la aleatorización son costosos y difíciles de gestionar en la práctica.
Desventaja 2: Generabilidad	Los RCTs responden a una pregunta concreta en un contexto específico. Su validez externa (extrapolar resultados a otras poblaciones o contextos) es limitada.
Desventaja 3: Macro/Equilibrio	No son adecuados para abordar preguntas de nivel macro o medir efectos de equilibrio general (a menos que la aleatorización se realice a nivel del sistema).
Ética	Existen consideraciones éticas cruciales, especialmente al denegar un tratamiento potencialmente beneficioso a un grupo de control.

3.5. Modelo experimental SOO vs. SOU: muestra no aleatorizada

Sea un modelo experimental donde la asignación del tratamiento (D) no es aleatoria, lo que inevitablemente genera un Sesgo de Selección. La diferencia de medias observadas es:

$$E[Y | D = 1] - E[Y | D = 0] = \text{ATT} + \underbrace{(E[Y(0) | D = 1] - E[Y(0) | D = 0])}_{\text{Sesgo de Selección}}$$

Por lo que necesitaremos tomar otra estrategia para controlar el sesgo de selección. En particular usaremos el supuesto de Independencia Condicional (CIA), que se define como:

$$(Y_i(1), Y_i(0)) \perp D_i | \mathbf{X}_i$$

Esto significa que podemos si separamos a las personas en grupos con las mismas características previas (e.g., todos con un promedio de 8.5), dentro de ese grupo homogéneo, la decisión efecto es independiente de cualidades intrínsecas de las personas, o variables no controladas; dicho de otra forma, si la asignación no es realmente aleatoria, al menos lo es condicional en las variables que podemos observar y medir.

Los resultados potenciales son independientes de la asignación del tratamiento, una vez que se ha condicionado en el conjunto de covariables $\mathbf{X}_i$. Esto significa que, dentro de cada estrato definido por $\mathbf{X}_i$, la asignación es "como si fuera aleatoria".

3.5.1. Modelo 1: Selección en observables (SOO)

Se asume que la regla de asignación a tratamiento es perfectamente conocida y observable. El problema causal se reduce a controlar por todos aquellos factores ($\mathbf{X}_i$) que definen la asignación al tratamiento (D_i) y que afectan el resultado de interés (Y_i).

Implementación

En la regresión lineal, la implementación de **SOO** (Supuesto de Independencia Condicional o de Resultados Observables) es directa: se incluye la variable de tratamiento (D_i) y todos los controles relevantes (X_i) en el modelo.

$$Y_i = \alpha + \beta D_i + \delta h(X_i) + \varepsilon_i$$

Al incluir las variables X_i , se elimina la correlación entre el tratamiento (D_i) y el término de error (ε_i). Es decir, el sesgo por Variables Omitidas (OVV) es removido. El término $\delta h(X_i)$ captura la parte de la variación que antes estaba sesgando a $\hat{\beta}$, permitiendo que el estimador $\hat{\beta}$ restante sea una estimación insesgada del ATE (o ATT, si el efecto no es constante) para el grupo que se está comparando (el ATE condicional a X_i).

3.5.2. Modelo 2: Selección en no-observables (SOU)

Se utiliza cuando la CIA no se cumple porque existen variables no observadas relevantes (no-observables). El objetivo es buscar una fuente de variación exógena (Z) en D que sea independiente del error (ε). Se busca una variación en D que sea "as good as randomly assigned."

Implementación

Se utiliza el método de Mínimos Cuadrados en Dos Etapas (2SLS), que es una aplicación del concepto de Variables Instrumentales (IV), que es una herramienta que estudiaremos más adelante.

El proceso se implementa en dos regresiones de MCO:

- **Primera Etapa (Modelo de la Variable Endógena):** Se utiliza el instrumento (Z_i) para predecir la parte de la variación en el tratamiento (D_i) que es verdaderamente exógena. El valor predicho, $\hat{D}_i$, se convierte en el tratamiento "limpio" o purgado del error ε_i .

$$D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2 h(X_i) + u_i$$

Donde $\hat{D}_i$ es el valor predicho de D_i a partir de esta regresión.

- **Segunda Etapa (Modelo de Resultado):** Se reemplaza la variable de tratamiento original (D_i) por su versión predicha y limpia ($\hat{D}_i$) en el modelo de resultado. El estimador $\hat{\beta}$ resultante es un estimador IV insesgado (o consistente, bajo ciertas condiciones):

$$Y_i = \alpha + \beta \hat{D}_i + \delta h(X_i) + v_i$$

4. Capítulo 4:

El método de Diferencias en Diferencias (DiD) es una de las estrategias de identificación más populares en la econometría aplicada para estimar efectos causales cuando no es posible realizar un experimento aleatorio (RCT). Pertenecce a la familia de diseños "cuasi-experimentales" que utilizan datos observacionales longitudinales (o datos de panel).

Supongamos que queremos medir el efecto de una política pública (ej. aumentar el salario mínimo) sobre una variable de resultado (ej. el empleo).

- **Problema de la comparación transversal (Cross-section):** Si comparamos una región que aplicó la política (Tratamiento) con una que no (Control) solo en el periodo post-política, el resultado estará sesgado por diferencias estructurales permanentes entre las regiones (ej. una región es naturalmente más industrial que la otra).
- **Problema de la comparación temporal (Before-After):** Si comparamos a la misma región antes y después de la política, el resultado estará sesgado por factores temporales que habrían ocurrido de todos modos (ej. inflación, ciclos económicos, cambios estacionales).

La solución, combinar ambas dimensiones. Comparamos el cambio en el tiempo del grupo de tratamiento con el cambio en el tiempo del grupo de control. Un ejemplo más gráfico de esto sería analizar el impacto de una política pública en dos regiones distintas:




Imagen 4

Ejemplo de combinar dimensiones.

4.1. Modelo SOU: El Estimador de diferencias en diferencias (2×2)

El diseño canónico involucra dos grupos y dos periodos:

- **Grupos:** Tratamiento ($D = 1$) y Control ($D = 0$).
- **Tiempo:** Pre-intervención ($t = 0$) y Post-intervención ($t = 1$).

De una forma más gráfica lo que haremos es:

	Tratados	No Tratados
Pre- Intervención	$\bar{Y}_{pre}^{tratadas}$	$\bar{Y}_{pre}^{no\ tratados}$
Post - Intervención	$\bar{Y}_{post}^{tratadas}$	$\bar{Y}_{post}^{no\ tratados}$

Imagen 5

Tabla de diferencias 2x2

Definimos el modelo lineal para el resultado potencial Y_{ist} (individuo i , estado s , tiempo t) de la siguiente manera:

$$Y_{ist} = \gamma_s + \lambda_t + \tau D_{st} + \varepsilon_{ist}$$

Donde:

- γ_s : Efecto fijo de grupo (captura características no observadas que no cambian en el tiempo).
- λ_t : Efecto fijo de tiempo (captura shocks temporales comunes a ambos grupos).
- τ : El parámetro de interés (Efecto Causal del Tratamiento).
- D_{st} : Dummy que toma valor 1 si es el grupo tratado en el periodo post.

Calculamos las Esperanzas Condicionales ($\mathbb{E}[Y]$) para cada una de las 4 celdas posibles, asumiendo $\mathbb{E}[\varepsilon] = 0$:

1. Grupo Control, Periodo Pre ($D = 0, t = 0$):

$$\mathbb{E}[Y_{C,pre}] = \gamma_C + \lambda_{pre}$$

(No hay τ porque no es tratado).

2. Grupo Control, Periodo Post ($D = 0, t = 1$):

$$\mathbb{E}[Y_{C,post}] = \gamma_C + \lambda_{post}$$

(La tendencia temporal λ cambia, pero γ se mantiene).

3. Grupo Tratado, Periodo Pre ($D = 1, t = 0$):

$$\mathbb{E}[Y_{T,pre}] = \gamma_T + \lambda_{pre}$$

(Difiere del control en γ_T , pero comparte el mismo tiempo λ_{pre}).

4. Grupo Tratado, Periodo Post ($D = 1, t = 1$):

$$\mathbb{E}[Y_{T,post}] = \gamma_T + \lambda_{post} + \tau$$

(Aquí aparece el efecto causal τ).

Ahora realizamos la doble diferencia:

Paso 1: Primera Diferencia (Temporal) Restamos Post menos Pre para cada grupo para eliminar los efectos fijos de grupo (γ):

$$\Delta Y_C = \mathbb{E}[Y_{C,post}] - \mathbb{E}[Y_{C,pre}] = (\gamma_C + \lambda_{post}) - (\gamma_C + \lambda_{pre}) = \lambda_{post} - \lambda_{pre}$$

$$\Delta Y_T = \mathbb{E}[Y_{T,post}] - \mathbb{E}[Y_{T,pre}] = (\gamma_T + \lambda_{post} + \tau) - (\gamma_T + \lambda_{pre}) = (\lambda_{post} - \lambda_{pre}) + \tau$$

Paso 2: Segunda Diferencia (Entre Grupos) Restamos el cambio del control al cambio del tratamiento para eliminar la tendencia temporal común ($\lambda_{post} - \lambda_{pre}$):

$$DD = \Delta Y_T - \Delta Y_C$$

$$DD = [(\lambda_{post} - \lambda_{pre}) + \tau] - [\lambda_{post} - \lambda_{pre}]$$

$$DD = \tau$$

El estimador DiD aísla matemáticamente el efecto causal τ eliminando tanto los sesgos por características fijas de grupo como los sesgos por tendencias temporales comunes.

Para que la derivación anterior sea válida, asumimos implícitamente que el término $\lambda_{post} - \lambda_{pre}$ es idéntico para ambos grupos. Este es el supuesto fundamental de DiD. O sea, en ausencia de tratamiento, el resultado promedio del grupo de tratamiento habría seguido la misma trayectoria temporal que el grupo de control.

$$\mathbb{E}[Y_{0i}|T = 1, t = 1] - \mathbb{E}[Y_{0i}|T = 1, t = 0] = \mathbb{E}[Y_{0i}|T = 0, t = 1] - \mathbb{E}[Y_{0i}|T = 0, t = 0]$$

Si este supuesto no se cumple (por ejemplo, si el grupo de tratamiento ya venía creciendo más rápido antes de la política), el estimador τ estará sesgado, capturando esa diferencia de tendencias preexistente.


**Imagen 6**

Gráfico clave: Muestra las líneas de tendencia. La línea punteada representa el contrafactual (qué habría pasado al grupo tratado sin tratamiento). Esta debe ser paralela a la línea del grupo de control.

En la práctica, estimamos DiD usando regresión lineal por Mínimos Cuadrados Ordinarios (MCO). Esto nos permite obtener errores estándar y controlar por otras covariables.

La ecuación de regresión es:

$$Y_{it} = \beta_0 + \beta_1 \text{Tratado}_i + \beta_2 \text{Post}_t + \beta_3 (\text{Tratado}_i \times \text{Post}_t) + \varepsilon_{it}$$

Demostremos qué captura cada coeficiente β :

- $\mathbb{E}[Y|C, Pre] = \beta_0$ (Intercepto, base del grupo control).
- $\mathbb{E}[Y|C, Post] = \beta_0 + \beta_2$ (El grupo control suma la tendencia temporal β_2).
- $\mathbb{E}[Y|T, Pre] = \beta_0 + \beta_1$ (El grupo tratado difiere del control en la base por β_1).
- $\mathbb{E}[Y|T, Post] = \beta_0 + \beta_1 + \beta_2 + \beta_3$ (Suma base, tendencia y efecto extra).

Calculamos el DiD usando los coeficientes β :

$$\Delta Y_C = (\beta_0 + \beta_2) - \beta_0 = \beta_2$$

$$\Delta Y_T = (\beta_0 + \beta_1 + \beta_2 + \beta_3) - (\beta_0 + \beta_1) = \beta_2 + \beta_3$$

$$DD = (\beta_2 + \beta_3) - \beta_2 = \beta_3$$

Por lo tanto, el coeficiente de la interacción (β_3) es el estimador del efecto causal τ .

4.2. Modelo SOU: Efectos fijos

El método DiD es un caso particular de los modelos de Efectos Fijos (Fixed Effects) con datos de panel (N individuos, T periodos).

Consideremos el modelo:

$$Y_{it} = \beta X_{it} + c_i + u_{it}$$

Donde c_i es el efecto fijo individual no observado (ej. habilidad, cultura institucional) que podría estar correlacionado con X .

Derivación del Estimador "Within" (Transformación de Medias): Para eliminar c_i sin sesgar β , utilizamos la transformación "Within".

Paso 1: Promediar en el tiempo para cada individuo Calculamos el promedio temporal para el individuo i :

$$\bar{Y}_i = \beta \bar{X}_i + c_i + \bar{u}_i$$

(Nota importante: Como c_i es constante en el tiempo, su promedio $\bar{c}_i$ es simplemente c_i).

Paso 2: Restar la media a la ecuación original Restamos la ecuación promediada a la ecuación original:

$$\begin{aligned} (Y_{it} - \bar{Y}_i) &= \beta (X_{it} - \bar{X}_i) + (c_i - c_i) + (u_{it} - \bar{u}_i) \\ \ddot{Y}_{it} &= \beta \ddot{X}_{it} + \ddot{u}_{it} \end{aligned}$$

Resultado: El término c_i desaparece matemáticamente. Al correr MCO sobre los datos transformados $(\ddot{Y}, \ddot{X})$, obtenemos un estimador insesgado de β .

Además de la transformación de medias, el estimador de efectos fijos se puede explicar mediante el Teorema Frisch-Waugh-Lovell (FWL). Si escribimos el modelo matricialmente como $y = Z\delta + \varepsilon$, donde $Z = [X, D]$ incluye las variables de interés y las dummies de los individuos⁴. La solución se puede obtener utilizando una matriz de proyección M_D que "limpia" el efecto de las variables dummy (los efectos fijos):

$$b = (X' M_D X)^{-1} (X' M_D Y)$$

Donde $M_D = I - D(D'D)^{-1}D'$. Esta matriz transforma las variables X e Y en sus desviaciones respecto a la media, llegando al mismo resultado que el cálculo escalar "Within", pero demostrando que solo necesitamos la variación ortogonal a los efectos fijos para identificar β .

Otra forma de eliminar el efecto fijo c_i (en lugar de restar el promedio) es restar el valor del periodo anterior. Si definimos $\Delta Y_{it} = Y_{it} - Y_{it-1}$, podemos estimar la regresión:

$$\Delta Y_{it} = \Delta X'_{it} \beta + \Delta \varepsilon_{it}$$

Esto se conoce como el estimador de Primeras Diferencias. ¡Ojo! Cuando $T = 2$ (solo dos periodos),

el estimador de Efectos Fijos (Within) y el de Primeras Diferencias entregan numéricamente el mismo coeficiente β . Si $T > 2$, no necesariamente coinciden.

4.3. Modelo SOU: Triples diferencias (DDD)

A veces, el supuesto de tendencias paralelas es débil. Puede existir un shock específico que afecte solo a la región tratada en el momento del tratamiento, confundiendo nuestro estimador τ con el efecto de ese shock (violación de la exclusión).

Para solucionar esto, usamos un tercer grupo de comparación (ej. un grupo etario o sectorial no afectado por la política, pero que reside dentro de la misma región y que, por tanto, estaría expuesto al mismo shock regional).

La intuición es restar una "doble diferencia falsa" (placebo) a nuestra "doble diferencia original":

$$DDD = \underbrace{[\Delta Y_T^{Afectado} - \Delta Y_C^{Afectado}]}_{DD_{original}} - \underbrace{[\Delta Y_T^{NoAfectado} - \Delta Y_C^{NoAfectado}]}_{DD_{falso}}$$

Si existe un shock regional, este aparecerá en el DD_{falso} . Al restarlo, limpiamos el estimador y aislamos el efecto real de la política.

Para implementar mediante una triple interacción en la regresión lineal. Definimos las variables dummy:

- T : Tratamiento (Región tratada).
- P : Post (Periodo después de la política).
- A : Afectado (Grupo objetivo de la política, ej. jóvenes).

La ecuación completa de regresión incluye todos los efectos principales, todas las interacciones dobles y la triple interacción:

$$\begin{aligned} Y_{ist} = & \alpha + \beta_1 T + \beta_2 P + \beta_3 A \\ & + \beta_4 (T \times P) + \beta_5 (T \times A) + \beta_6 (P \times A) \\ & + \delta_{DDD} (T \times P \times A) + \varepsilon_{ist} \end{aligned}$$

Donde:

- $\beta_4 (T \times P)$: Captura cualquier shock que afecte a *toda* la región tratada en el periodo post (el sesgo que queremos eliminar).
- δ_{DDD} : Es el estimador de Triples Diferencias. Captura el efecto diferencial sobre el grupo afectado, en la región tratada, en el periodo post, *neto* de todos los otros cambios.

4.4. Modelo SOU: Estudios de eventos (Event Studies)

En lugar de agrupar todo el periodo posterior en una sola variable dummy "Post" (lo cual asume un efecto constante e inmediato), analizamos el efecto periodo a periodo relativo al momento del evento ($t = 0$). Esto permite flexibilizar el modelo y observar la dinámica temporal.

El modelo de regresión se especifica reemplazando la dummy de "Post" por una serie de dummies para cada periodo relativo al tratamiento (lags y leads):

$$Y_{ist} = \gamma_s + \lambda_t + \sum_{k \neq -1} \delta_k D_{s,t-k} + \varepsilon_{ist}$$

Donde:

- $D_{s,t-k}$: Es una dummy igual a 1 si el estado s fue tratado y el periodo actual es k periodos después del tratamiento (si $k > 0$) o antes del tratamiento (si $k < 0$).
- $k = -1$: Se omite usualmente como categoría base (normalización a cero) para evitar multicolinealidad perfecta.

Este enfoque sirve para dos propósitos claves:

1. **Validar tendencias paralelas (Pre-trends):** Los coeficientes previos al tratamiento ($\delta_{-1}, \delta_{-2}, \dots$) deberían ser estadísticamente no significativos (cerca de cero). Si son distintos de cero, indica que los grupos ya divergían antes de la política (violación del supuesto).
2. **Ver dinámica del efecto:** Permite ver si el efecto de la política es inmediato (un salto en δ_0), creciente (efecto acumulativo) o transitorio (desaparece con el tiempo).




Imagen 7

Este gráfico es el estándar de oro para mostrar resultados DiD. Muestra que hombres y mujeres siguen trayectorias idénticas antes del nacimiento del hijo (validación) y divergen drásticamente justo después (efecto causal).

5. Capítulo 5

La disciplina de la Econometría se distingue de la Estadística por dos aspectos principales: una aproximación sin timidez a la inferencia causal y un arsenal de herramientas estadísticas desarrolladas para abordar problemas complejos. La más potente de estas herramientas es el método de Variables Instrumentales (IV).

En particular las variables instrumentales (IV), originalmente ideado por Wright and Wright (1928) y continuado por Tinbergen y Haavelmo en los 1930s y 1940s, se basa en un diseño en lo no-observable, que tiene como principal objetivo identificar causalidad.

5.1. Metodo SOU: Variables Instrumentales (IV)

Comenzamos con el modelo causal lineal de efectos constantes. Supongamos que el resultado potencial y_{si} (salario) para un individuo i con nivel de escolaridad s se puede escribir como:

$$y_{si} = \alpha + \beta s + \varepsilon_i$$

Donde ε_i representa los determinantes no observados (como la *habilidad* A_i). El problema de sesgo por variables omitidas ocurre si existen habilidades que se correlaciona con la escolaridad s_i . O sea, el factor de error absorbe dichas variables no observadas:

$$\varepsilon_i = A_i' \gamma + v_i$$

Con v_i factor de error. El modelo de regresión "largo," que considera todas aquellas variables omitidas (que produciría un coeficiente β insesgado si A_i fuera observable) es:

$$y_i = \alpha + \beta s_i + A_i' \gamma + v_i$$

La hipótesis de un modelo causal es que $E[s_i v_i] = 0$, que de forma simple menciona que no existe relación entre la escolaridad y los errores medidos. Ahora, estamos seguros que condición se cumple? Podría estar sesgada nuestra estimación del efecto de escolaridad sobre salarios? La alternativa que proponemos en el presente capítulo es usar una variable instrumental. O sea, identificar parte de la variación de s_i , que llamaremos z_i , que no está correlacionada con e_i . En palabras más simples, buscamos una fuerza externa (z_i) que mueva a nuestra variable de interés (s_i), asegurándonos de que este movimiento no tenga ninguna relación con los errores (e_i) que suelen confundir los resultados.

Siguiendo con nuestro ejemplo sobre el efecto de la educación (s_i) en el salario, una variable de control fundamental sería la experiencia laboral. Aunque usemos la cercanía a la universidad (z_i) como instrumento para resolver el problema de la 'habilidad oculta', sabemos que el sueldo también sube simplemente por llevar más años trabajando. Al agregar la experiencia laboral como variable de control, lo que hacemos es comparar a personas que tienen la misma antigüedad en el trabajo; de esta forma, nos aseguramos de que cualquier diferencia salarial que encontremos se deba al efecto 'limpio' de la educación identificado por nuestro instrumento, y no simplemente a que unos llevan más tiempo trabajando que otros.

Si eso se cumple, podemos decir que es "tan buena como si hubiera sido aleatoria". Entonces, tenemos como meta encontrar un instrumento z_i que cumpla con lo siguiente puntos.

5.1.1. Condiciones

Buscamos una Variable Instrumental (VI), z_i , que cumpla dos condiciones críticas:

1. *Relevancia del Instrumento (First Stage)*: La variable instrumental z_i debe estar correlacionada con la variable causal de interés s_i . Se conoce como que sea relevante.

$$\text{Cov}(s_i, z_i) \neq 0$$

2. *Restricción de Exclusión (Exclusion Restriction)*: El instrumento z_i solo puede afectar la variable dependiente y_i a través de s_i . Es decir, debe ser no correlacionado con cualquier otro determinante de y_i , incluyendo ε_i (variables omitidas). Se conoce como que sea exógeno.

$$\text{Cov}(\varepsilon_i, z_i) = 0$$

Dado esto, el estimador obtenido de IV (β) es el cociente de las covarianzas entre z_i y y_i y entre z_i y s_i . Demostremos dicho resultado:

5.1.2. Deducción del estimador

Sea:

$$\text{Cov}(y_i, z_i) = \text{Cov}(\alpha + \beta s_i + A_i' \gamma + v_i, z_i)$$

Dado que α es una constante y por la linealidad de la covarianza:

$$\text{Cov}(y_i, z_i) = \beta \text{Cov}(s_i, z_i) + \text{Cov}(A_i' \gamma, z_i) + \text{Cov}(v_i, z_i)$$

Por la restricción de exclusión $\text{Cov}(\varepsilon_i, z_i) = 0$, y como $\varepsilon_i = A_i'\gamma + v_i$, se cumple que z_i no está correlacionada ni con $A_i'\gamma$ ni con v_i , lo que implica:

$$\text{Cov}(A_i'\gamma, z_i) = 0 \quad \text{y} \quad \text{Cov}(v_i, z_i) = 0$$

Simplificando, obtenemos:

$$\text{Cov}(y_i, z_i) = \beta \text{Cov}(s_i, z_i)$$

Despejando β , el estimador poblacional de IV queda:

$$\beta = \frac{\text{Cov}(y_i, z_i)}{\text{Cov}(s_i, z_i)} = \frac{\text{Cov}(y_i, z_i)/V(z_i)}{\text{Cov}(s_i, z_i)/V(z_i)}$$

$$\beta = \frac{\text{Coeficiente de la Regresión de } y_i \text{ sobre } z_i \text{ (Forma Reducida)}}{\text{Coeficiente de la Regresión de } s_i \text{ sobre } z_i \text{ (Primera Etapa)}}$$

Con $V(z_i)$ correspondiente a la varianza de z_i . En términos más generales el estimador IV se escribe como:

$$\hat{\beta}_{IV} = (Z'D)^{-1}(Z'Y)$$

Z (matriz) puede incluir las covariables predeterminadas x_i que afectan y_i . Además, el estimador encontrado es consistente, o sea, entre más datos, disminuye la varianza.

Es importante demostrar formalmente que, aunque IV tiene sesgo en muestras pequeñas, converge al valor verdadero β cuando la muestra es grande ($N \rightarrow \infty$). Usando límites de probabilidad ($plim$):

$$\begin{aligned} plim(\hat{\beta}_{IV}) &= plim[(Z'D)^{-1}(Z'Y)] \\ &= plim[(Z'D)^{-1}(Z'D\beta + Z'\varepsilon)] \\ &= \beta + \frac{plim(Z'\varepsilon)}{plim(Z'D)} \end{aligned}$$

Dado que por la restricción de exclusión $\text{Cov}(z, \varepsilon) = 0$ (el numerador es 0) y por relevancia $\text{Cov}(z, d) \neq 0$ (el denominador no es 0), el término de error desaparece y $plim(\hat{\beta}_{IV}) = \beta$.

A menudo es útil analizar la Forma Reducida (RF), que es la regresión directa del resultado Y sobre

el instrumento Z (sin pasar por el tratamiento). Ecuación RF:

$$Y_i = \delta_0 + \rho_{RF} Z_i + v_i$$

El estimador de IV es simplemente la razón entre el coeficiente de la forma reducida y el coeficiente de la primera etapa (FS):

$$\hat{\beta}_{IV} = \frac{\text{Efecto de } Z \text{ sobre } Y \text{ (RF)}}{\text{Efecto de } Z \text{ sobre } D \text{ (FS)}}$$

Esto nos dice que IV es simplemente re-escalar el efecto del instrumento sobre el resultado, ajustándolo por cuánta gente realmente cambió su comportamiento gracias al instrumento.

5.1.3. El estimador de Wald

El Estimador de Wald es el caso más simple de IV. Sea un instrumento binario ($z_i \in \{0, 1\}$) y sin covariables. La fórmula es la diferencia de medias del resultado y_i dividida por la diferencia de medias de la variable endógena s_i , condicionada al instrumento. Generemos dicha expresión.

Podemos encontrar ρ usando r.e: $\text{Cov}(Z_i, e_i) = 0$:

$$\text{Cov}(Y_i, Z_i) = \text{Cov}(\alpha + \rho S_i + e_i, Z_i) = \rho \text{Cov}(S_i, Z_i)$$

Luego, la covarianza de una variable binaria (invocando ley de esperanzas iteradas):

$$\begin{aligned} \text{Cov}(Y_i, Z_i) &= E[Y_i Z_i] - E[Y_i] E[Z_i] \\ &= p E[Y_i | Z_i = 1] - [p E[Y_i | Z_i = 1] + (1 - p) E[Y_i | Z_i = 0]] p \\ &= p(1 - p) [E[Y_i | Z_i = 1] - E[Y_i | Z_i = 0]] \end{aligned}$$

Lo mismo para: $\text{Cov}(S_i, Z_i) = [E[S_i | Z_i = 1] - E[S_i | Z_i = 0]] p(1 - p)$, que nos lleva a:

$$\rho = \frac{\text{Cov}(Y_i, Z_i)}{\text{Cov}(S_i, Z_i)} = \frac{E[Y_i | Z_i = 1] - E[Y_i | Z_i = 0]}{E[S_i | Z_i = 1] - E[S_i | Z_i = 0]}$$

Por lo tanto:

$$\beta = \frac{E[y_i | z_i = 1] - E[y_i | z_i = 0]}{E[s_i | z_i = 1] - E[s_i | z_i = 0]}$$

5.2. Mínimos Cuadrados en Dos Etapas (2SLS)

Dicho estimador mencionado anteriormente se podrías calcularlo a mano en el caso más simple (1 instrumento para 1 variable), pero se vuelve matemáticamente infernal e impreciso cuando agregas más instrumentos o controles. Es por ello que introducimos el método de 2SLS (Two-Stage Least Squares) que es la forma práctica de calcular la estimación IV, especialmente con múltiples instrumentos y covariables.

En palabras simples lo que buscaremos hacer es reemplazar tu variable problemática (s_i) por un "clon limpio" ($\hat{s}_i$). O sea, no podemos usar la variable original (s_i) porque está contaminada (correlacionada con el error). Entonces, en lugar de usar los datos reales de s_i , vamos a construir una predicción de s_i basada únicamente en información "segura" (nuestro instrumento).

Etapas 1: Fabricar la variable "limpia" ($\hat{s}_i$)

En esta etapa *nos olvidamos por un momento del resultado final (y)*. Nuestro único objetivo es entender cómo funciona la variable problemática (s_i) usando solo el instrumento (Z) y los controles (X).

- *¿Qué hacemos?* Hacemos una regresión donde s_i es la variable a explicar (dependiente).
- *La ecuación:* $s_i = \text{Instrumentos} + \text{Controles} + \text{error}$.
- *El resultado clave:* Obtenemos los *valores ajustados* (o predichos), que llamamos $\hat{s}_i$. $\hat{s}_i$ es el "clon limpio". Representa la parte de la educación (u otra variable) que fue *provocada exclusivamente* por el instrumento. Aquí ya no hay "contaminación" de factores ocultos.

Etapas 2: Calcular el efecto causal real

Ahora volvemos a nuestra ecuación principal para ver qué afecta a y_i (el resultado final, como el salario).

- *¿Qué hacemos?* Hacemos una regresión normal (OLS), pero *hacemos un cambio clave*:
 - Quitamos la variable original "sucia" (s_i).
 - Ponemos la variable "limpia" que fabricamos en la etapa 1 ($\hat{s}_i$).
- *La ecuación:* $y_i = \beta(\text{Variable Limpia } \hat{s}_i) + \text{Controles} + \text{error}$.
- *El resultado clave:* El coeficiente β que obtengas aquí será tu *efecto causal real* ($\hat{\beta}_{2SLS}$).

5.2.1. Generalización

Generalicemos lo anterior. Sea la ecuación estructural causal:

$$y_i = X_i' \gamma + \beta s_i + \varepsilon_i$$

Sustituimos esta ecuación por el resultado de la regresión de la Primera Etapa. Para ello, descomponemos el error asumiendo que:

$$\varepsilon_i = v_{1i} \beta + v_{2i}$$

(donde v_{1i} es el error de la Primera Etapa y v_{2i} es el error residual estructural).

La forma reducida se puede expresar como una función de los valores ajustados poblacionales de la Primera Etapa, definidos como $\mathbb{E}[s_i | X_i, z_i] = X_i' \pi_{10} + \pi_{11} z_i$. Esto nos lleva a:

$$y_i = X_i' \gamma + \beta \mathbb{E}[s_i | X_i, z_i] + v_{2i}$$

Explicación Simple: Lo que nos dice esta ecuación es que, en teoría, β (nuestro efecto causal) se puede encontrar si ignoramos el s_i real (que está sucio) y en su lugar usamos su "predicción ideal" o esperanza matemática ($\mathbb{E}[s_i | \dots]$), la cual está limpia de factores ocultos.

Como no conocemos la esperanza poblacional, $\mathbb{E}[s_i | X_i, z_i]$ se debe estimar con los datos muestrales a través de dos pasos secuenciales:

Etapas 1 (Estimación de los valores ajustados - "La Limpieza")

Se estima por OLS la regresión de la variable endógena s_i sobre todas las covariables X_i y todos los instrumentos Z_i . El objetivo es obtener los valores ajustados (predichos) $\hat{s}_i$:

$$\hat{s}_i = X_i' \hat{\pi}_{10} + Z_i' \hat{\pi}_{11}$$

¿Qué ocurre aquí?: Estamos construyendo un "clon limpio" de nuestra variable problemática. $\hat{s}_i$ representa la variación de la educación (o la variable de interés) que es explicada *exclusivamente* por el instrumento y los controles, eliminando la parte "contaminada" por los errores.

Etapas 2 (Estimación del parámetro causal)

Se estima por OLS la regresión de la variable dependiente y_i sobre las covariables X_i y, crucialmente, sobre los valores ajustados $\hat{s}_i$ obtenidos en el paso anterior (en lugar de usar el s_i original):

$$y_i = X_i' \hat{\gamma} + \hat{\beta}_{2SLS} \hat{s}_i + \text{Error Residual}$$

¿Qué ocurre aquí?: Al usar la variable "clonada y limpia" ($\hat{s}_i$), nos aseguramos de que el coeficiente $\hat{\beta}_{2SLS}$ capture solamente el efecto causal real, sin la interferencia de factores ocultos.

Así, podemos escribir matricialmente nuestro estimador de forma compacta como:

$$\hat{\beta}_{2SLS} = (D' P_Z D)^{-1} (D' P_Z Y), \quad \text{donde } P_Z = Z(Z'Z)^{-1}Z'$$

(Donde P_Z actúa matemáticamente como el "filtro" que proyecta los datos sobre el espacio limpio generado por los instrumentos).

Nota importante sobre los errores estándar: Si se realiza el 2SLS "manualmente" (calculando dos regresiones OLS separadas en un software), los errores estándar calculados en la segunda etapa serán *incorrectos*. Porque al hacerlo manualmente, el software trata a $\hat{s}_i$ como si fuera un dato real recolectado perfectamente, ignorando que en realidad es una estimación que proviene de una etapa previa (y que, por tanto, trae su propia incertidumbre o ruido).

El software especializado (como Stata o SAS, usando comandos como `ivregress`) ajusta la varianza residual automáticamente para usar la varianza del error estructural original ε_i , reconociendo correctamente la naturaleza estimada de la primera etapa.

5.3. IV con resultados potenciales heterogéneos (LATE)

En el mundo real, no todos reaccionan igual a un tratamiento (heterogeneidad). Si damos una medicina, a algunos les cura mucho, a otros poco y a otros nada. Cuando usamos Variables Instrumentales (IV), surge una pregunta crítica: ¿El efecto que calculamos representa a toda la población o solo a un grupo específico?

La respuesta es: solo a un grupo específico. A esto le llamamos Efecto de Tratamiento Promedio Local (LATE). La Intuición clave detrás de esto es que el estimador de IV solo mide el efecto en las personas que cambiaron su comportamiento gracias al instrumento. Si el instrumento no te hizo cambiar de opinión, el método IV te ignora.

Para entender el LATE, debemos clasificar a las personas según cómo reaccionan a nuestro instrumento (z , por ejemplo, recibir un cupón de descuento) frente al tratamiento real (d , por ejemplo, comprar el producto).

Existen 4 grupos teóricos, aunque asumimos que el último no existe:

- *Cumplidores (Compliers) - Los "Obedientes"*: Si reciben el cupón, compran. Si no lo reciben, no compran. *SÍ lo captura IV (Son el LATE)*.
- *Siempre Tomadores (Always-takers) - Los "Decididos"*: Compran con o sin cupón. El instrumento no les afecta. *NO lo captura IV*.
- *Nunca Tomadores (Never-takers) - Los "Negados"*: No compran nunca, tengan cupón o no. El instrumento no les afecta. *NO lo captura IV*.
- *Desafiantes (Defiers) - Los "Contreras"*: Si les das cupón, no compran. Si NO les das, compran. (Hacen lo opuesto). *Asumimos que no existen*.

El LATE es el efecto promedio EXCLUSIVAMENTE sobre los cumplidores.

5.3.1. El Teorema LATE

Para que las matemáticas funcionen e identifiquen a estos "Cumplidores", necesitamos 4 supuestos clave. Sea d_i una variable de tratamiento binaria. Definimos los resultados potenciales y_{1i}, y_{0i} (con o sin tratamiento) y las asignaciones de tratamiento potenciales d_{1i}, d_{0i} (con $z_i = 1$ o $z_i = 0$).

Teorema 4.4.1 (El Teorema LATE): Suponiendo:

1. *Independencia*: $\{y_{1i}, y_{0i}, d_{1i}, d_{0i}\} \perp z_i$. O sea, El instrumento (z) es asignado al azar (como una lotería), no depende de características ocultas de la persona.
2. *Exclusión*: $y_i(d, 0) = y_i(d, 1) \equiv y_{di}$ para $d = 0, 1$. O sea, el instrumento solo afecta el resultado final a través del tratamiento. (El cupón no te hace más saludable mágicamente; solo te ayuda si te lleva a comprar la medicina).
3. *Relevancia*: $E[d_{1i} - d_{0i}] \neq 0$. El instrumento realmente funciona. Debe haber gente que cambie su comportamiento por él.
4. *Monotonicidad*: $d_{1i} \geq d_{0i}$ para todo i (o viceversa). Este es crucial. Asumimos que nadie actúa como un "Desafiante". Es decir, el instrumento no hace que nadie haga lo contrario a lo que se pretende. Sin este supuesto, el LATE no se puede calcular.

Entonces, el estimador de Wald identifica el efecto promedio del tratamiento en la subpoblación de compliers (Cumplidores) es:

$$\tau_{LATE} = \frac{E[y_i|z_i = 1] - E[y_i|z_i = 0]}{E[d_i|z_i = 1] - E[d_i|z_i = 0]} = E[y_{1i} - y_{0i}|d_{1i} > d_{0i}] = E[y_{1i} - y_{0i}|C_i = 1]$$

En español simple:

$$\text{Efecto LATE} = \frac{\text{Cambio en el Resultado Final (Y)}}{\text{Porcentaje de gente que cambió su comportamiento (D)}}$$

Lo que hace esta división es "inflar" el efecto reducido que vemos en la población general para ajustarlo al tamaño del grupo que realmente obedeció (los Cumplidores).

5.3.2. Diferencias entre LATE, ATE y TOT

Recordatorio de las definiciones:

$$ATE = E[Y_{1i} - Y_{0i}]$$

$$TOT = E[Y_{1i} - Y_{0i}|D_i = 1]$$

$$TONT = E[Y_{1i} - Y_{0i}|D_i = 0]$$

$$LATE = E[Y_{1i} - Y_{0i}|D_{1i} > D_{0i}]$$

Con eso recordado, es vital entender que el número que nos da el IV (LATE) suele ser distinto al promedio de la población (ATE) o al promedio de los tratados (TOT).

- *ATE (Average Treatment Effect)*: El efecto si obligáramos a *toda* la población a tratarse. (Incluye a los que nunca querrían tratarse).
- *TOT (Treatment on the Treated)*: El efecto promedio en los que *realmente se trataron*.
 - *Ojo*: El grupo "Tratados" incluye a dos tipos de personas: los *Cumplidores* (que se trataron por el instrumento) + los *Siempre Tomadores* (que se habrían tratado igual).
- *LATE*: El efecto solo en los *Cumplidores*.

¿Cuándo son iguales? (Casos Especiales): El texto menciona el caso de *Bloom (1984)* o "One-sided non-compliance". Imagina un experimento clínico donde: al grupo de control *se le prohíbe* acceder a la medicina (No hay "Siempre Tomadores" en el control) y al grupo de tratamiento se le ofrece, pero algunos dicen que no (Hay "Nunca Tomadores"). En este escenario específico, como eliminaste a los

"Siempre Tomadores", el grupo de tratados está compuesto *únicamente* por Cumplidores. Por tanto: $LATE = TOT$. (Lo que mide el IV es exactamente el efecto en los tratados, porque no hay nadie más que se haya tratado "por su cuenta").

Resumen visual de las diferencias:

- TOT es un promedio ponderado entre *Siempre Tomadores* y *Cumplidores*.
- $TONT$ es un promedio ponderado entre *Nunca Tomadores* y *Cumplidores*.
- $IV (LATE)$ aísla quirúrgicamente a los *Cumplidores*.

5.3.3. Ponderación Kappa (Abadie, 2003)

Ya sabemos que el IV estima el efecto sobre los *Cumplidores* (los que obedecen al instrumento). Pero surge un problema: *No podemos señalar con el dedo quién es un cumplidor y quién no*. Solo vemos quién recibió el tratamiento y quién no, pero no sabemos sus motivos internos.

Cuando agregamos variables de control (X_i) al modelo, la cosa se complica. Aquí entra Abadie (2003) con la *Ponderación Kappa*.

Imagina que Kappa (κ) es un *detector de probabilidad*. Como no podemos filtrar los datos eliminando a los "Siempre Tomadores" o "Nunca Tomadores" (porque no sabemos quiénes son), usamos κ para dar *pesos matemáticos* a las personas.

- El peso κ_i será *alto* para las personas que tienen características (X) que las hacen muy propensas a ser Cumplidores.
- El peso será bajo (o cero) para quienes probablemente sean Siempre/Nunca Tomadores.

El peso *Kappa* κ_i se define como:

$$\kappa_i = \frac{d_i(1 - z_i)}{P(z_i = 0|X_i)} + \frac{(1 - d_i)z_i}{P(z_i = 1|X_i)} = 1 - \frac{D_i(1 - z_i)}{1 - P(z_i = 1|X_i)} - \frac{(1 - D_i)z_i}{P(z_i = 1|X_i)}$$

Entonces:

$$E[g(Y_i, D_i, X_i)|D_{1i} > D_{0i}] = \frac{E[\kappa_i g(Y_i, D_i, X_i)]}{E[\kappa_i]}$$

5.4. Diseños Populares de Variables Instrumentales (IV)

Más allá de las loterías simples, existen estrategias sofisticadas para construir instrumentos:

A. Diseños de Severidad de Jueces (*Judge Leniency Designs*)

- Se utiliza para medir el efecto del encarcelamiento o decisiones judiciales.
- **Lógica:** Los casos se asignan aleatoriamente a jueces, pero los jueces tienen diferentes niveles de severidad (algunos encarcelan mucho, otros poco).
- **El Instrumento:** Se construye el instrumento como la tasa de encarcelamiento promedio del juez asignado (excluyendo el caso propio, conocido como *leave-out mean*).
- **Identificación:** Comparamos acusados similares asignados a jueces "duros" vs. "blandos".

B. Instrumentos de Bartik (*Shift-Share IV*)

- Se utiliza en economía laboral para medir *shocks* locales.
- **Lógica:** El crecimiento de una región depende de qué industrias tiene (*share* inicial) y cómo les va a esas industrias a nivel nacional (*shift* nacional).
- **El Instrumento** (B_{lt}): Interactúa la composición industrial inicial de una ciudad (exógeno por estar predeterminado) con la tasa de crecimiento nacional de esas industrias (exógeno a la ciudad).
- **Fórmula:**

$$B_{lt} = \sum_k z_{lk} g_{kt}$$

Donde z es la participación histórica (*share*) y g es el crecimiento nacional (*shift*).

5.5. Detalles Críticos de IV

Entremos en las advertencias de seguridad. El método de Variables Instrumentales es poderoso, pero frágil.

5.5.1. A. El Sesgo y los Instrumentos Débiles (La "Palanca Rota")

A diferencia de una regresión normal (OLS), que si cumple sus supuestos es perfecta (insesgada), el método de IV *siempre tiene un poco de sesgo* en muestras finitas (datos reales), aunque se arregla si tienes datos infinitos (consistencia).

El peligro: Si tu instrumento es *débil* (es decir, apenas logra mover a la variable s_i), el método de IV colapsa.

Mira la fórmula del sesgo traducida:

$$\text{Sesgo IV} \approx \text{Sesgo OLS} \times \frac{1}{F+1}$$

- *F (Fuerza del instrumento)*: Imagina que es la fuerza de tu palanca.
- *Si F es gigante*: El término $\frac{1}{F+1}$ se vuelve casi cero. El sesgo desaparece. ¡Bien!
- *Si F es pequeño (cerca de 0)*: El término se vuelve 1. Entonces: *Sesgo IV* $\approx$ *Sesgo OLS*.
 - *Consecuencia*: Si tu instrumento es malo, hiciste todo este trabajo matemático complejo para terminar con el mismo resultado erróneo que tenías al principio.

La Regla de Oro (Stock, Yogo, et al.): Mira el Estadístico F de la primera etapa.

- *F > 10*: Estás en zona segura. El instrumento es fuerte.
- *F < 10*: ¡Alerta roja! Tu instrumento es débil y tus resultados no son confiables.

Solución rápida: Si tienes instrumentos débiles, considera usar *LIML* (Limited Information Maximum Likelihood) en lugar de 2SLS, ya que aguanta mejor la debilidad de los instrumentos.

5.5.2. B. Regresiones Prohibidas (Forbidden Regressions)

Esto es un error de novato muy común pero fatal. Ocurre cuando intentas mezclar modelos no lineales (como Probit o Logit) con 2SLS "a mano".

El escenario del crimen: Tienes una variable endógena binaria (ej. tener o no tener hijos).

1. *Lo que NO debes hacer*: Correr un Probit en la primera etapa para predecir "tener hijos", guardar esos valores predichos, y meterlos directamente como regresor en la segunda etapa OLS.
 - *¿Por qué está mal?* Porque las matemáticas del Probit no garantizan que los errores se comporten bien (ortogonalidad) en la segunda etapa. Ensucia el modelo.
2. *Lo que SÍ debes hacer (La Alternativa Correcta)*:
 - Corre el Probit en la primera etapa y obtén la probabilidad predicha ($\hat{d}$).
 - Usa esa probabilidad *como instrumento* (no como regresor) en un 2SLS lineal estándar.
 - O simplemente usa un Modelo Lineal de Probabilidad (OLS) en la primera etapa. A menudo es más robusto y menos riesgoso.

5.5.3. C. Tests de Diagnóstico

Además de verificar la fuerza del instrumento ($F > 10$), existen tests para validar el modelo y los instrumentos:

Test de Hausman (Endogeneidad) Este test compara las estimaciones obtenidas por Mínimos Cuadrados Ordinarios (OLS) y por Variables Instrumentales (IV).

- **Hipótesis Nula (H_0):** OLS e IV son similares (La variable no es endógena, OLS es preferible por eficiencia).
- **Hipótesis Alternativa (H_1):** OLS e IV son distintos (Existe endogeneidad, IV es necesario por consistencia).

Test de Sobreidentificación (Sargan-Hansen J) Este test solo se puede usar si tienes más instrumentos que variables endógenas (es decir, el modelo está **sobreidentificado**).

- **Hipótesis Nula (H_0):** Todos los instrumentos son válidos (exógenos).
- **Hipótesis Alternativa (H_1):** Al menos un instrumento no es válido (está correlacionado con el error).

Si tienes varios instrumentos, todos deberían apuntar al mismo β . Si las estimaciones varían significativamente entre sí, es un indicio de que al menos uno de ellos está fallando en el supuesto de exclusión.

6. Capítulo 6

El Diseño de Regresión Discontinua (RD) es, posiblemente, el método cuasi-experimental más creíble que existe. Su lógica es hermosa por su simplicidad: explotamos la arbitrariedad de las reglas burocráticas.

Imagina un examen donde se aprueba con 50 puntos.

- Un estudiante con 49.9 puntos reprueba.
- Un estudiante con 50.0 puntos aprueba.
- ¿Es el estudiante de 50.0 significativamente más inteligente que el de 49.9? Probablemente no. Son prácticamente idénticos (intercambiables), pero el destino (tratamiento) los separó drásticamente.

Por eso decimos que es un método de Selección sobre no observables: asumimos que cerca del corte, la asignación es "como si fuera aleatoria".

6.1. Regresión discontinua nítida (Sharp RD)

El diseño de RD Nítida se aplica cuando el estatus de tratamiento (D_i) es una función determinística y discontinua de una variable de asignación (o running variable), X_i , en un umbral conocido c :

$$D_i = \begin{cases} 1 & \text{si } X_i \geq c \\ 0 & \text{si } X_i < c \end{cases}$$

Este es el caso donde la regla se cumple a rajatabla:

- Si cruzas el umbral (c), recibes el tratamiento ($D = 1$) *sí o sí*.
- Si no lo cruzas, no lo recibes ($D = 0$) *bajo ninguna circunstancia*.

El supuesto clave para la validez del RD es que los resultados potenciales cambian de forma suave y continua alrededor del umbral c , es decir, que no hay saltos en la variable dependiente Y_i causados por factores distintos al tratamiento D_i .

Si se cumple la continuidad de las funciones de medias condicionales contrafactuales:

$$\mathbb{E}[Y_i(0)|X_i = x] \quad \text{y} \quad \mathbb{E}[Y_i(1)|X_i = x]$$

son continuas en x en una vecindad de c .

El efecto causal local τ_{SRD} se define como la discontinuidad o el salto en la función de media condicional observada $\mathbb{E}[Y_i|X_i = x]$ justo en el umbral c :

$$\tau_{\text{SRD}} = \lim_{x \rightarrow c^+} \mathbb{E}[Y_i|X_i = x] - \lim_{x \rightarrow c^-} \mathbb{E}[Y_i|X_i = x]$$

Deducción del efecto causal local:

Sabemos que el resultado observado Y_i es una función del estatus de tratamiento D_i y los resultados potenciales $Y_i(1)$ (con tratamiento) y $Y_i(0)$ (sin tratamiento):

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$$

Tomando la esperanza condicional en la running variable X_i :

$$\mathbb{E}[Y_i|X_i = x] = \mathbb{E}[Y_i(1)|X_i = x]\mathbb{E}[D_i|X_i = x] + \mathbb{E}[Y_i(0)|X_i = x](1 - \mathbb{E}[D_i|X_i = x])$$

Para el caso Nítido, $\mathbb{E}[D_i|X_i = x]$ es la función determinística $\mathbf{1}(X_i \geq c)$.

1. *Límite por la derecha* ($x \rightarrow c^+$): $D_i = 1$, por lo que $\mathbb{E}[D_i|X_i = c^+] = 1$.

$$\lim_{x \rightarrow c^+} \mathbb{E}[Y_i|X_i = x] = \lim_{x \rightarrow c^+} \mathbb{E}[Y_i(1)|X_i = x] = \mathbb{E}[Y_i(1)|X_i = c]$$

(Por la suposición de continuidad de $\mathbb{E}[Y_i(1)|X_i = x]$).

2. *Límite por la izquierda* ($x \rightarrow c^-$): $D_i = 0$, por lo que $\mathbb{E}[D_i|X_i = c^-] = 0$.

$$\lim_{x \rightarrow c^-} \mathbb{E}[Y_i|X_i = x] = \lim_{x \rightarrow c^-} \mathbb{E}[Y_i(0)|X_i = x] = \mathbb{E}[Y_i(0)|X_i = c]$$

(Por la suposición de continuidad de $\mathbb{E}[Y_i(0)|X_i = x]$).

Sustituyendo estos límites en la definición de τ_{SRD} :

$$\tau_{\text{SRD}} = \mathbb{E}[Y_i(1)|X_i = c] - \mathbb{E}[Y_i(0)|X_i = c] = \mathbb{E}[Y_i(1) - Y_i(0)|X_i = c]$$

El estimador τ_{SRD} identifica el efecto de tratamiento promedio local (LATE) para los individuos justo en el umbral $X_i = c$.

6.1.1. Modelos de estimación paramétrica

En la práctica, τ_{SRD} se estima utilizando regresión. Pero no podemos calcular "límites" con datos reales, así que usamos regresiones. Dibujamos una línea (o curva) a la izquierda del corte y otra a la derecha.

$$Y_i = \beta_0 + \beta_1(X_i - c) + \beta_2(X_i - c) \cdot D_i + \tau_{\text{SRD}}D_i + \varepsilon_i$$

Donde:

- Y_i : Es la variable de resultado para la unidad i .
- X_i : Es la variable de asignación (o variable de *running*) para la unidad i .
- c : Es el valor del umbral o corte (cutoff) usado para la asignación al tratamiento.
- D_i : Es una variable dummy de tratamiento, que toma el valor 1 si $X_i \geq c$ (grupo de tratamiento) y 0 si $X_i < c$ (grupo de control).
- ε_i : Es el término de error.

Interpretación de los coeficientes

- β_0 : Es el valor esperado de Y justo a la izquierda del corte (es decir, en $X_i = c$ para el grupo de control).
- β_1 : Es la pendiente de la recta para el grupo de **control** (cuando $D_i = 0$, a la izquierda del corte).
- β_2 : Captura el cambio en la pendiente para el grupo de tratamiento. La pendiente para el grupo de tratamiento es, por lo tanto, $(\beta_1 + \beta_2)$.
- τ_{SRD} : Es el salto en el intercepto en el umbral. Este coeficiente es la estimación del efecto causal del tratamiento en el corte.

Si se omite el término de interacción $(X_i - c) \cdot D_i$, se asume incorrectamente que el efecto del tratamiento es solo un salto constante y que la relación entre X e Y es paralela a ambos lados del umbral. Esta omisión puede sesgar la estimación de τ_{SRD} .

6.1.2. Validez del RD (Pruebas de Robustez)

La credibilidad del RD depende de que la continuidad se cumpla para los resultados potenciales. Esto se testea con:

- Continuidad de Covariables (Balance): Si miramos otras características (edad, ingresos previos), no debería haber saltos en el umbral. Si los que tienen 50 puntos son mágicamente más ricos que los que tienen 49.9, entonces el corte no fue aleatorio.

- Prueba de McCrary (¿Manipularon la nota?): Miramos la densidad de personas. Si hay un "bulto" sospechoso de gente justo en 50.0 y un vacío en 49.9, significa que la gente manipuló su puntaje para cruzar la meta. Eso invalida el supuesto de aleatoriedad.

6.2. 2. Regresión discontinua borrosa (Fuzzy RD)

El diseño de RD Borrosa es más común y se aplica cuando el cruce del umbral c ya no determina el tratamiento de forma determinística (D_i no salta de 0 a 1), sino que solo provoca una discontinuidad en la probabilidad de recibir el tratamiento. O sea, en la vida real, las reglas se rompen. A veces cruzas el umbral y no tomas el tratamiento, o no lo cruzas y sí lo tomas.

$$0 < \lim_{x \rightarrow c^+} \mathbb{E}[D_i|X_i = x] - \lim_{x \rightarrow c^-} \mathbb{E}[D_i|X_i = x] < 1$$

Aquí, la asignación (T_i , cruzar la meta) se convierte en un instrumento para el tratamiento real (D_i).

6.2.1. Estimador Fuzzy RD (Analogía con IV/Wald)

Como el cumplimiento no es perfecto, no podemos atribuir todo el cambio en Y al tratamiento directamente. Tenemos que ajustar por "cuánta gente realmente obedeció a la regla". El estimador τ_{FRD} se calcula como el cociente de dos saltos:

1. **Salto en el Resultado (Y_i):** El efecto de la "intención de tratar" (forma reducida).
2. **Salto en el Tratamiento (D_i):** El efecto de la "asignación" sobre el tratamiento real (primera etapa).

$$\tau_{\text{FRD}} = \frac{\lim_{x \rightarrow c^+} \mathbb{E}[Y_i|X_i = x] - \lim_{x \rightarrow c^-} \mathbb{E}[Y_i|X_i = x]}{\lim_{x \rightarrow c^+} \mathbb{E}[D_i|X_i = x] - \lim_{x \rightarrow c^-} \mathbb{E}[D_i|X_i = x]}$$

De forma más sencilla:

$$\tau_{\text{FRD}} = \frac{\text{Salto en el Resultado (Y)}}{\text{Salto en la Probabilidad de Tratamiento (D)}}$$

Interpretación Causal:

Bajo las condiciones de IV (Restricción de Exclusión, Relevancia y Monotonicidad), el estimador τ_{FRD} identifica el Efecto de Tratamiento Promedio Local (LATE) para la subpoblación de Cumplidores (Compliers), aquellos cuya probabilidad de tratamiento cambió debido al cruce del umbral.

$$\tau_{\text{FRD}} = \mathbb{E}[Y_i(1) - Y_i(0)|D_{1i} > D_{0i}, X_i = c]$$

Donde D_{1i} es el estatus de tratamiento potencial si $X_i \geq c$, y D_{0i} es el estatus si $X_i < c$.