



PONTIFICIA UNIVERSIDAD CATOLICA DE CHILE

ESCUELA DE INGENIERÍA

DEPARTAMENTO DE INGENIERÍA DE TRANSPORTE Y LOGÍSTICA

ICT-2950 Tópicos de Econometría

Profesor: Louis de Grange C.

APUNTES DE CLASES

ICT-2950 TÓPICOS DE ECONOMETRÍA

(VERSIÓN 1er SEMESTRE 2014)

ÍNDICE

	Pág.
1 REPASO DE MATRICES Y ANÁLISIS DE DATOS	1-1
1.1 Operaciones con Matrices.....	1-1
1.1.1 Matrices Especiales	1-1
1.1.2 Suma	1-2
1.1.3 Multiplicación.....	1-2
1.1.4 Operador de Kronecker.....	1-2
1.1.5 Matrices Particionadas	1-3
1.1.6 Matriz Inversa	1-3
1.1.7 Matriz Traspuesta	1-3
1.1.8 Traza de una Matriz.....	1-4
1.1.9 Matrices Ortogonales	1-5
1.1.10 Vectores Característicos y Valores Propios.....	1-5
1.1.11 Rango de una Matriz	1-7
1.1.12 Formas Cuadráticas de una Matriz.....	1-7
1.1.13 Diferenciación de Matrices	1-8
1.1.14 Series de Taylor	1-9
1.2 Análisis de Datos.....	1-9
1.2.1 Tipos de Variables	1-10
1.2.2 Media, Varianza, Covarianza y Correlación.....	1-10
1.2.3 Medidas de Dependencia Lineal de los Datos	1-12
1.2.4 Datos Atípicos (Outliers).....	1-12
2 REGRESIÓN LINEAL MÚLTIPLE	2-15
2.1 Supuestos del Modelo.....	2-17
2.1.1 Supuestos Sobre la Perturbación.....	2-17
2.1.2 Supuestos sobre las Variables Explicativas	2-18
2.1.3 Supuestos sobre los Parámetros del Modelo	2-18
2.2 Estimación por Mínimos Cuadrados Ordinarios (MCO) ..	2-18
2.2.1 Vector de Parámetros	2-21
2.2.2 Aspectos Algebraicos y Propiedades de los Estimadores (Muestras Finitas y Muestras Grandes)	2-23
2.2.3 Teorema Central del Límite.....	2-28

	2.2.4	Indicadores de Bondad de Ajuste	2-30
	2.2.5	MCO vs Máxima Verosimilitud	2-33
	2.2.6	Interpretación Económica.....	2-35
	2.2.7	Diagrama de Venn	2-36
	2.2.8	Interpretación Geométrica de los MCO.....	2-38
3		INFERENCIA Y PRECICCIÓN.....	3-43
	3.1	Contraste de Restricciones	3-43
	3.1.1	Contraste de una Restricción Lineal.....	3-43
	3.1.2	Contraste de Restricciones Lineales Conjuntas.....	3-44
	3.1.3	Contraste Basado en una Región de Confianza	3-45
	3.1.4	Mínimos Cuadrados Restringidos.....	3-48
	3.1.5	Contraste de Restricciones No Lineales	3-49
	3.2	Predicción	3-50
	3.3	Estimación por Mínimos Cuadrados Generales (MCG) ..	3-53
4		ESPECIFICACIÓN	4-56
	4.1	Variables Ficticias	4-56
	4.1.1	Cambio Estructural en el Intercepto	4-58
	4.1.2	Cambio Estructural en la Pendiente.....	4-59
	4.1.3	Cambio Estructural en el Intercepto y la Pendiente	4-59
	4.2	Variables No Lineales.....	4-60
	4.2.1	Transformaciones Generales	4-60
	4.2.2	Transformación Box - Tidwell	4-61
	4.2.3	Transformación Box - Cox.....	4-62
	4.3	Modelos No Lineales	4-65
	4.3.1	Modelo de Regresión Linealizado en Parámetros	4-66
	4.3.2	Modelo de Regresión Linealizado en Variables.....	4-67
	4.4	Especificación de Variables	4-68
	4.4.1	Selección de Variables.....	4-68
	4.4.2	Variables Omitidas	4-69
	4.4.3	Variables Superfluas.....	4-71

4.5	Contraste de Subespecificación de Modelos (Test J)	4-72
5	TEMAS ESPECÍFICOS.....	5-74
5.1	Ortogonalidad	5-74
5.2	Multicolinealidad	5-76
5.2.1	Definición de Multicolinealidad.....	5-76
5.2.2	Causas de la Multicolinealidad.....	5-77
5.2.3	Efectos de la Multicolinealidad	5-77
5.2.4	Detección de la Multicolinealidad y su Magnitud.....	5-84
5.2.5	Corrección de la Multicolinealidad.....	5-87
5.2.6	Método de Componentes Principales.....	5-88
5.2.7	Regresión Cresta (Ridge Regression).....	5-94
5.3	Heterocedasticidad.....	5-97
5.3.1	Definición de Heterocedasticidad	5-97
5.3.2	Causas de la Heterocedasticidad	5-99
5.3.3	Efectos de la Heterocedasticidad.....	5-101
5.3.4	Detección de la Heterocedasticidad.....	5-104
5.3.5	Corrección de la Heterocedasticidad	5-111
5.4	Autocorrelación.....	5-114
5.4.1	Definición de Autocorrelación	5-114
5.4.2	Causas de la Autocorrelación	5-115
5.4.3	Efectos de la Autocorrelación.....	5-116
5.4.4	Detección de la Autocorrelación.....	5-118
5.4.5	Estimación bajo Autocorrelación.....	5-122
5.5	Endogeneidad.....	5-124
5.5.1	Definición de Endogeneidad	5-124
5.5.2	Causas de la Endogeneidad	5-125
5.5.3	Efectos de la Endogeneidad.....	5-126
5.5.4	Detección de la Endogeneidad.....	5-127
5.5.5	Estimación bajo Endogeneidad.....	5-128
5.6	Asimetría, Curtosis y Normalidad.....	5-130
5.6.1	Asimetría.....	5-130
5.6.2	Curtosis	5-131
5.6.3	Estadístico Jarque-Bera de Normalidad.....	5-132

5.7	Contrastes de Datos Atípicos	5-132
6	INTRODUCCIÓN A LAS SERIES DE TIEMPO.....	6-134
6.1	Extrapolación de Series de Tiempo	6-134
6.1.1	Modelos de Extrapolación Simple	6-134
6.1.2	Modelos de Promedio Móvil	6-135
6.2	Suavizamiento de Series de Tiempo	6-136
6.3	Estimación y Pronóstico de Modelos de Tendencia.....	6-137
6.4	Procesos Estocásticos.....	6-137
6.5	Estacionariedad	6-138
6.5.1	Estacionariedad Estricta	6-138
6.5.2	Estacionariedad Débil	6-139
6.5.3	Función de Autocorrelación Simple (FAS)	6-140
6.5.4	Función de Autocorrelación Parcial (FAP)	6-142
6.5.5	Proceso Ruido Blanco.....	6-143
6.6	Ergodicidad	6-145
6.7	Teorema de Wold.....	6-146
6.8	Retardos y Diferencias.....	6-147
6.8.1	Operador de Retardos	6-147
6.8.2	Operador de Diferencias	6-148
6.9	Ecuaciones de Diferencias	6-148
6.9.1	Definición.....	6-148
6.9.2	Solución Recursiva.....	6-149
6.9.3	Solución Analítica	6-149

	6.10 Círculo Unitario.....	6-156
7	PROCESOS MEDIA MÓVIL.....	7-159
	7.1 Procesos MA(1)	7-159
	7.2 Procesos MA(2)	7-162
	7.3 Procesos MA(q).....	7-163
	7.4 Invertibilidad de los Procesos MA(q)	7-164
	7.5 Estimación de Procesos MA(q)	7-165
	7.6 Pronósticos con Procesos MA(q)	7-168
8	PROCESOS AUTORREGRESIVOS	8-172
	8.1 Procesos AR(1).....	8-172
	8.1.1 Media	8-172
	8.1.2 Varianza	8-173
	8.1.3 Autocovarianza.....	8-173
	8.1.4 Autocorrelación.....	8-174
	8.2 Procesos AR(2).....	8-177
	8.2.1 Media	8-177
	8.2.2 Varianza	8-177
	8.2.3 Autocovarianza.....	8-178
	8.2.4 Autocorrelación.....	8-178
	8.3 Procesos AR(p)	8-180
	8.4 Estimación de Procesos AR(p).....	8-183
	8.5 Pronósticos con Procesos AR(p).....	8-183
	8.6 Regla de la Cadena Para Pronosticar AR(p)	8-185
	8.7 Dualidad entre Procesos AR y MA	8-186
	8.8 Procesos ARMA(p,q)	8-187
	8.9 Pronósticos de Modelos ARMA(p,q).....	8-189
	8.10 Procesos ARIMA(p,i,q).....	8-191
	8.11 Procesos Estacionales	8-192
	8.11.1 Estacionalidad Mediante Variables Dicotómicas.....	8-193
	8.11.2 Procesos Autorregresivos Estacionales.....	8-194
	8.11.3 Estacionariedad del AR(p) Estacional	8-194
	8.11.4 Procesos Medias Móviles Estacionales.....	8-195
	8.11.5 Identificación de s	8-196

9	PROCESOS ESTOCÁSTICOS NO ESTACIONARIOS	9-197
9.1	Paseo Aleatorio.....	9-197
9.2	Procesos ARIMA	9-201
9.2.1	Identificación de Procesos ARIMA.....	9-202
9.2.2	Estimación de Procesos ARIMA.....	9-206
9.2.3	Inicialización de la Serie.....	9-207
9.2.4	Validación de Procesos ARIMA.....	9-209
9.2.5	Predicción con Procesos ARIMA	9-215
9.3	Orden de Integración de una Serie: Métodos No Paramétricos	9-219
9.3.1	Análisis de la Función de Autocorrelación	9-219
9.3.2	Sobrediferenciación.....	9-221
9.3.3	Análisis de la Varianza.....	9-222
10	RAÍCES UNITARIAS Y COINTEGRACIÓN	10-223
10.1	Tendencias Determinísticas y Estocásticas	10-224
10.1.1	Tendencia Determinística.....	10-224
10.1.2	Tendencia Estocástica.....	10-225
10.2	Regresión Espuria.....	10-228
10.3	Detección de Raíces Unitarias	10-230
10.3.1	Análisis Gráfico de la Serie	10-230
10.3.2	Análisis del Correlograma Simple de la Serie.....	10-231
10.3.3	Utilización del Estadístico de Durbin - Watson.....	10-233
10.4	Contraste de Estacionariedad y de Raíz Unitaria	10-234
10.4.1	Contraste de Dickey - Fuller (DF)	10-234
10.4.2	Contraste de Dickey - Fuller Aumentado (DFA)	10-240
10.4.3	Contraste de Phillips - Perron (PP)	10-241
10.5	Cointegración.....	10-242
10.6	Detección de Cointegración	10-244
10.6.1	Engle y Granger	10-244
10.6.2	Durbin y Watson.....	10-245
10.6.3	Modelo de Corrección de Errores (MCE)	10-245

10.7	Causalidad	10-247
11	ANÁLISIS FACTORIAL.....	11-248
11.1	Comparación Entre FA y MCP	11-252
11.2	El Modelo de Análisis Factorial	11-252
11.2.1	Hipótesis del FA	11-252
11.2.2	Forma Matricial del FA.....	11-253
11.3	Ecuaciones del FA.....	11-254
11.3.1	No Unicidad de los Factores	11-255
11.3.2	Normalización del Modelo Factorial.....	11-255
11.4	Resolución de las Ecuaciones del FA	11-256
11.4.1	Número de Factores.....	11-256
11.4.2	Método del Factor Principal	11-257
11.5	Determinación de la Cantidad Apropia de Factores.....	11-262
11.5.1	Criterios Subjetivos	11-263
11.5.2	Criterios Objetivos	11-263
11.6	Rotación de Factores	11-264
11.6.1	Rotación VARIMAX.....	11-266
11.6.2	Rotación Oblicua	11-267
11.7	Cuantificación de Factores.....	11-268
11.7.1	Método de Barlett.....	11-269
11.7.2	Método de Thompson	11-269
11.7.3	Otros Métodos.....	11-270
12	ANÁLISIS DE CONGLOMERADOS (CLUSTER).....	12-271
12.1	Medidas de Semejanza y Desemejanza	12-271
12.1.1	Distancia Métrica	12-271
12.1.2	Distancia de Mahalanobis.....	12-271
12.2	Análisis Gráficos	12-272
12.2.1	Gráficos de Dispersión (Bidimensionales)	12-272
12.2.2	Gráficos de Dispersión (Tridimensionales).....	12-273
12.2.3	Gráficos de Andrews.....	12-274
12.2.4	Gráficos de Estrellas	12-276
12.2.5	Gráficos de Caras de Chernoff	12-279

12.3	Métodos de Agrupación	12-280
12.3.1	Método del Vecino Más Cercano	12-280
12.3.2	Diagrama de Árbol.....	12-283
12.3.3	Estadístico F de Beale	12-286
12.4	Reducción de la Escala Multidimensional	12-287

1 REPASO DE MATRICES Y ANÁLISIS DE DATOS

1.1 Operaciones con Matrices

Sea la matriz $A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & & a_{2n} \\ \dots & & \ddots & \dots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}$ donde $A^T = \begin{bmatrix} a_{11} & a_{21} & \dots & a_{m1} \\ a_{12} & a_{22} & & a_{m2} \\ \dots & & \ddots & \dots \\ a_{1n} & a_{2n} & \dots & a_{mn} \end{bmatrix}$.

1.1.1 Matrices Especiales

$D = \text{diag}(A)$ es la diagonal de la matriz A de dimensión $n \times n$:

$$D = \begin{bmatrix} a_{11} & 0 & \dots & 0 \\ 0 & a_{22} & & 0 \\ \dots & & \ddots & \dots \\ 0 & 0 & \dots & a_{nn} \end{bmatrix} = D^T \quad (1.1)$$

T se denomina triangular superior de la matriz A:

$$T = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ 0 & a_{22} & & a_{2n} \\ \dots & & \ddots & \dots \\ 0 & 0 & \dots & a_{nn} \end{bmatrix} \quad (1.2)$$

I_n se denomina matriz identidad de dimensión $n \times n$:

$$I = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & & 0 \\ \dots & & \ddots & \dots \\ 0 & 0 & \dots & 1 \end{bmatrix} \quad (1.3)$$

1.1.2 Suma

$C = A \pm B$ es definido como $c_{ij} = a_{ij} \pm b_{ij}$ dado que A y B tienen el mismo número de filas y de columnas. Es fácil demostrar que: $(A \pm B) \pm C = A \pm (B \pm C)$ y también que $A + B = B + A$.

1.1.3 Multiplicación

$C = A \cdot B$ es definido como $c_{ij} = \sum_{k=1}^n (a_{ik} \cdot b_{kj})$ dado que A y B son matrices conformables, es decir, A es de $r \times n$ y B es de $n \times p$. Debe notarse que:

- $A \cdot B$ y $B \cdot A$ no son necesariamente iguales.
- Se cumple que $A \cdot (B \pm C) = A \cdot B \pm A \cdot C$
- En general, $A \cdot B \neq B \cdot A$
- Dos vectores $a \in A$ y $b \in B$ son ortogonales ($a \perp b$) si $a^T \cdot b = \sum_{i=1}^n (a_i \cdot b_i) = 0$
- $\|a\| = (a^T a)^{1/2} = \sqrt{\sum_{i=1}^n a_i^2}$
- Si $A \cdot A = A$ se dice que A es idempotente, y en general $(A)^p = A, \forall p > 1$.

1.1.4 Operador de Kronecker

Si A es de $m \times n$ y B es de $s \times t$, el operador de Kronecker de A y B , denotado por $A \otimes B$, es una matriz de $ms \times nt$ dada por:

$$A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & & a_{2n}B \\ \dots & & \ddots & \dots \\ a_{n1}B & a_{n2}B & \dots & a_{nn}B \end{bmatrix} \quad (1.4)$$

Se cumplen las siguientes propiedades:

- $(A \otimes B)(C \otimes D) = (AC \otimes BD)$
- $(A + B) \otimes (C + D) = (A \otimes C) + (A \otimes D) + (B \otimes C) + (B \otimes D)$
- $(A \otimes B) \otimes C = A \otimes (B \otimes C)$

1.1.5 Matrices Particionadas

La matriz A de $m \times n$ puede ser particionada en 4 sub-matrices de la forma:

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \quad (1.5)$$

Luego, si B es también particionada se puede obtener la siguiente expresión:

$$A \cdot B = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix} \quad (1.6)$$

1.1.6 Matriz Inversa

Dada la matriz A de $n \times n$, si existe una matriz B que satisface $AB = BA = I_n$, esta matriz B se denomina inversa de A , y se denota $B = A^{-1}$. Se cumplen las siguientes propiedades:

- $(AB)^{-1} = B^{-1}A^{-1}$
- $(A + B)^{-1} = A^{-1}(A^{-1} + B^{-1})^{-1}B^{-1}$

1.1.7 Matriz Traspuesta

Se cumplen las siguientes propiedades:

- $(A^T)^T = A$
- $(A \pm B)^T = A^T \pm B^T$

- $(A \cdot B)^T = B^T A^T$
- $(A^{-1})^T = (A^T)^{-1}$
- Si $A = A^T$ se dice que A es simétrica
- $A \cdot A^T$ y $A^T \cdot A$ son simétricas
- $(A \otimes B)^T = (A^T \otimes B^T)$

1.1.8 Trazo de una Matriz

La traza de una matriz cuadrada conformable A de $n \times n$ se define como la suma de los elementos de su diagonal: $tr(A) = \sum_{i=1}^n a_{ii}$. Debe notarse que:

- $tr(A^T) = tr(A)$
- $tr(A \pm B) = tr(A) \pm tr(B)$
- $tr(A \cdot B) = tr(B \cdot A)$
- $tr(k \cdot A) = k \cdot tr(A)$
- $tr(A \otimes B) = tr(A) \cdot tr(B)$

Debe notarse que para un producto de matrices cuyo resultado es un escalar, dicho valor también corresponde a la traza del producto original de las matrices. Es decir, el valor de un escalar es igual a su traza.

1.1.9 Matrices Ortogonales

Las matrices ortogonales son matrices cuadradas que pueden representar un giro en el espacio respecto a un plano (o hiperplano). Para caracterizar estas matrices, supongamos que, dado un vector X , lo ponderamos por una matriz no singular C , y obtenemos un nuevo vector Y :

$$Y = C \cdot X \quad (1.7)$$

Si la operación realizada es sólo un giro, entonces el módulo o norma de Y debe ser idéntica a la de X , y por lo tanto se cumple:

$$Y^T Y = X^T C^T C X = X^T X \quad (1.8)$$

Por lo tanto, debe cumplirse que:

$$C^T C = I \quad (1.9)$$

La condición de ortogonalidad es la que se obtiene de (1.9), de donde se deduce que la matriz traspuesta debe ser igual a su inversa:

$$C^T = C^{-1} \quad (1.10)$$

Luego, una matriz ortogonal debe tener filas (o columnas) que son ortogonales entre sí, y de longitud igual a la unidad.

1.1.10 Vectores Característicos y Valores Propios

Dada una matriz cuadrada, existen determinadas propiedades de dicha matriz que son invariantes ante transformaciones lineales de dicha matriz de tal forma que se mantiene la información existente en la matriz. Algunos ejemplos pueden ser trasponer la matriz o girarla.

Los valores propios son las medidas básicas de tamaño de una matriz. Dichas medidas básicas, como la traza o el determinante, son función de los valores propios, y serán por lo tanto invariantes ante transformaciones lineales que preserven los valores propios.

Llamaremos vectores propios de una matriz cuadrada de orden n a aquellos vectores cuya dirección no se modifica al aplicar una transformación lineal a la matriz. Sea A una matriz de $n \times n$. Existe entonces un vector propio $\vec{c}$ que satisface:

$$A \cdot \vec{c} = \lambda \cdot \vec{c} \quad (1.11)$$

para determinados valores constantes de λ , que es un escalar, y que se denomina valor propio.

Si $\vec{c}$ es un vector propio de A , y si multiplicamos (1.11) por cualquier $\alpha \neq 0$, entonces $\alpha \cdot \vec{c}$ también será un vector propio de A . Para evitar esta indeterminación, supondremos que $\|\vec{c}\| = 1$.

Luego, existe una solución no nula (para $\vec{c} \neq 0$) que verifica:

$$\det|A - \lambda \cdot I| = 0 \quad (1.12)$$

La expresión (1.12) es un sistema de ecuaciones lineal homogéneo que tiene una solución no nula sólo si la matriz $(A - \lambda \cdot I)$ es no singular. El polinomio que se obtiene de (1.12) en función de λ se denomina ecuación característica.

Las soluciones de (1.11) son los vectores característicos, y los distintos valores de λ en (1.12) son las raíces características, que son número reales si la matriz es simétrica. En general, una matriz tiene $h \leq n$ valores propios. A cada valor propio de la matriz podemos asignarle un único vector propio que satisface (1.11).

Debe destacarse que:

- Si λ es un valor propio de A , entonces λ^r es un valor propio de A^r
- Los valores propios de una matriz y su traspuesta son los mismos
- $tr(A) = \sum_{i=1}^n \lambda_i$
- $tr(A^r) = \sum_{i=1}^n \lambda_i^r$
- $tr(A^{-1}) = \sum_{i=1}^n \lambda_i^{-1}$

- $\|A\| = \prod_{i=1}^n \lambda_i$
- Los vectores característicos de una matriz simétrica son ortogonales
- Las matrices A y $(A + I)$ tienen los mismos vectores propios, y si λ es un valor propio de A , $\lambda + 1$ es un valor propio de $(A + I)$
- Las matrices ABC , ACB y CAB tienen los mismos valores propios no nulos
- Si A es triangular, los valores propios son los elementos de la diagonal
- En una matriz simétrica, los valores propios son números reales y los vectores son ortogonales

1.1.11 Rango de una Matriz

Supongamos una matriz A de $m \times n$ con m filas $(a_1, a_2, \dots, a_m)$. El rango de la matriz A corresponde al número de filas linealmente independientes. Si el rango es m , se dice que la matriz es de rango completo.

- $\text{rango}(A^T) = \text{rango}(A) = \text{rango}(A^T A)$
- $\text{rango}(A \cdot B) \leq \min \{ \text{rango}(A); \text{rango}(B) \}$
- El rango también corresponde al número de raíces características λ distintas de cero en $(A^T A)$. Si la matriz es simétrica, corresponde al número de raíces características λ distintas de cero en A .

1.1.12 Formas Cuadráticas de una Matriz

Sea una matriz A de $n \times n$ simétrica, y $x = (x_1, x_2, \dots, x_n)$ un vector. Entonces la expresión $q = x^T A x = \sum_{i=1}^n \sum_{j=1}^n (x_i x_j a_{ij})$ se denomina forma cuadrática, que es un polinomio de segundo grado en x .

- Si $x^T A x > 0$ entonces A es definida positiva.
- Si $x^T A x < 0$ entonces A es definida negativa.

- Si $x^T A x \geq 0$ entonces A es semi-definida positiva.
- Si $x^T A x \leq 0$ entonces A es semi-definida negativa.

1.1.13 Diferenciación de Matrices

Sea una matriz X de $n \times m$ con elementos x_{ij} , y $f = f(X)$ una función que depende de los elementos de X . Entonces:

$$\frac{df}{dX} = \left[\left(\frac{df}{dx_{ij}} \right) \right] \quad (1.13)$$

Como ejemplo, supongamos que $f = 5X_1 + 2X_2 + 3X_3$. Luego:

$$\frac{df}{dX} = \begin{bmatrix} 5 \\ 2 \\ 3 \end{bmatrix} \quad (1.14)$$

Además, es fácil obtener los siguientes resultados:

- $\frac{d(\beta^T X)}{d\beta} = X, \quad \frac{d(\beta^T X)}{dX} = \beta$
- Si X simétrica entonces $\frac{d(\beta^T X \beta)}{d\beta} = 2X\beta$
- Si $f(X) = a^T X b$ entonces $\frac{df}{dX} = b^T a$
- Si $f(X) = (A \cdot X \cdot B)$ entonces $\frac{df}{dX} = A^T B^T$
- Si X es de $n \times n$ y $f(X) = (X)$ entonces $\frac{df}{dX} = I_n$
- Si X es de $n \times n$ y $f(X) = (X^T A X)$ entonces $\frac{df}{dX} = (A + A^T)X$

Definiendo $Y^T = (f_1(X); f_2(X); \dots; f_n(X))$, entonces:

$$\bullet \quad \frac{dY}{dX} = \left[\frac{df_1}{dX}, \frac{df_2}{dX}, \dots, \frac{df_n}{dX} \right] = \begin{bmatrix} \frac{df_1}{dx_1} & \frac{df_2}{dx_1} & \dots & \frac{df_n}{dx_1} \\ \frac{df_1}{dx_2} & \frac{df_2}{dx_2} & \dots & \frac{df_n}{dx_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{df_1}{dx_n} & \frac{df_2}{dx_n} & \dots & \frac{df_n}{dx_n} \end{bmatrix}$$

$$\bullet \quad \text{Si } Y = AX \text{ entonces } \frac{dY}{dX} = A^T$$

1.1.14 Series de Taylor

Para una función vectorial $f = f(\vec{x})$ la expansión en series de Taylor es la siguiente:

$$f(\vec{x}) \approx f(\vec{x}_0) + \nabla f(\vec{x}_0) \cdot (\vec{x} - \vec{x}_0) + \frac{\nabla^2 f(\vec{x}_0) \cdot (\vec{x} - \vec{x}_0)^T \cdot (\vec{x} - \vec{x}_0)}{2} + \dots \quad (1.15)$$

$$f(\vec{x}) \approx \beta_0 + \beta_1 \cdot \vec{x} + \beta_2 \cdot \vec{x}^T \vec{x} + \dots \quad (1.16)$$

1.2 Análisis de Datos

En general, consideraremos un total de n datos u observaciones o unidades experimentales, y un total de p variables. Es decir, cada una de las n observaciones considera p variables. Esta información puede ser representada como una matriz de $p \times n$.

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & & x_{2p} \\ \dots & & \ddots & \dots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix} \quad (1.17)$$

1.2.1 Tipos de Variables

Las variables pueden ser básicamente de dos tipos: **cuantitativas o cualitativas**. Las cuantitativas se caracterizan porque su valor puede ser expresado numéricamente, como por ejemplo la edad de una persona, su peso, la población de un país, el ingreso monetario de un individuo, etc. Las variables cualitativas se caracterizan porque su valor corresponde a un atributo o categoría, como por ejemplo el sexo, su país de nacimiento, temporada del año, etc.

Las variables cuantitativas pueden a su vez en **continuas o discretas**. Las variables cualitativas por su parte pueden clasificarse en binarias (sólo 2 valores) o múltiples (muchos valores).

1.2.2 Media, Varianza, Covarianza y Correlación

Estas variables representan un resumen de la información existente en los datos. En términos probabilísticos, estas variables están asociadas a los momentos de la función de densidad.

Para una determinada variable k en particular, su media se representa como:

$$\bar{x}_k = \frac{1}{n} \sum_{i=1}^n x_{ik} \quad (1.18)$$

La varianza de esta variable k está relacionada conceptualmente con la distorsión promedio de cada observación de la variable respecto a la media de dicha variable, y se expresa de la siguiente forma:

$$V(x_k) = \frac{1}{n-1} \sum_{i=1}^n (x_{ik} - \bar{x}_k)^2 \quad (1.19)$$

Por otra parte, **el grado de relación lineal entre dos variables** se mide por la covarianza. La covarianza entre las variables x_k y x_j se calcula como:

$$\text{cov}(x_k, x_j) = \frac{1}{n-1} \left[\sum_{i=1}^n (x_{ik} - \bar{x}_k)(x_{ij} - \bar{x}_j) \right] \quad (1.20)$$

Notar que la covarianza puede ser positiva o negativa. El signo de la covarianza indica el signo de la variación conjunta de las variables x_k y x_j . Su magnitud, sin embargo, depende de la escala en que fueron medidas las variables.

A partir de las expresiones obtenidas de (1.20), se puede generar la matriz de varianzas y covarianzas del conjunto de datos X . En la diagonal irán los términos asociados a la varianza de cada una de las p variables, y fuera de la diagonal irán los términos asociados a la covarianza entre las distintas variables. Luego, la matriz de varianzas y covarianzas es de $(p \times p)$.

Una característica importante de la matriz de varianzas y covarianzas es que es siempre **simétrica y positiva-definida** (excepto que existan filas/columnas dependientes).

La simetría se debe a que $\text{cov}(x_k, x_j) = \text{cov}(x_j, x_k)$; lo de positiva definida es una extensión del hecho que la varianza es siempre positiva por definición, ya que es una suma de elementos al cuadrado.

Adicionalmente, la traza, el determinante y los valores propios de la matriz de varianzas y covarianzas son siempre no negativos.

Como se mencionó anteriormente, la magnitud de las varianzas y covarianzas depende de la escala en que se han medido las variables x_k y x_j . Ello implica que valores altos de la covarianza no implica necesariamente altos grados de relación lineal entre las variables. Análogamente, valores bajos no implica ausencia de relación entre ellas.

Una alternativa que mitiga este problema es la matriz de correlaciones, que se obtiene de la siguiente expresión:

$$r_{kj} = \frac{\text{cov}(x_k, x_j)}{\sqrt{V(x_k)} \cdot \sqrt{V(x_j)}} \quad (1.21)$$

Las propiedades de la matriz de correlaciones son las mismas que las de la matriz de varianzas y covarianzas: simétrica, semidefinida positiva, y con traza, determinante y valores propios no nulos. Sin embargo, los valores de la matriz de correlaciones van entre -1 y 1 , y los elementos de la diagonal son siempre 1 .

1.2.3 Medidas de Dependencia Lineal de los Datos

Interesa analizar la estructura de dependencia entre las variables. Estas dependencias pueden estudiarse como:

- Dependencia entre pares de variables (correlación)
- Dependencia entre pares de variables pero eliminando el efecto del resto (correlación parcial)
- **Dependencia entre una variable y un conjunto de variables (regresión lineal múltiple)**

1.2.4 Datos Atípicos (Outliers)

a) Definición

Datos atípicos o Outliers son aquellas observaciones que al parecer han sido generados de manera distinta al resto de los datos. Pueden ser causados por ejemplo por errores de medición o digitación de los datos, cambios en los instrumentos de medición o simplemente representan una heterogeneidad intrínseca de los elementos observados.

La caracterización de un único dato atípico es simple, ya que por definición debe estar alejado del resto. Luego, la distancia entre dicha observación y el resto debe ser alta. Alternativamente, podemos definir como dato atípico aquella observación que se encuentra alejada del centro o de la media de los datos.

Una observación puede considerarse atípica si la distancia métrica entre dicha observación y la media de los datos es grande:

$$d(x_i, \bar{x}) = \left[(x_i - \bar{x})^T (x_i - \bar{x}) \right]^{1/2} \quad (1.22)$$

Para identificar las observaciones atípicas, podríamos construir un histograma de estas distancias y determinar si existen puntos muy alejados respecto a los demás.

Sin embargo, esta medida de distancia no es correcta cuando existe dependencia entre observaciones (relación lineal). Ello se debe a que la distancia euclidiana no considera la estructura de correlaciones entre los datos; una alternativa es estandarizar previamente los datos en forma multivariante. La estandarización típicamente utilizada es la siguiente:

$$z_{ki} = \frac{x_{ki} - \bar{x}_k}{\sqrt{V(x_k)}} \quad (1.23)$$

Luego, se puede construir la distancia euclidiana pero con las variables estandarizadas:

$$d(z_i, \bar{z}) = \left[(z_i - \bar{z})^T (z_i - \bar{z}) \right]^{1/2} \quad (1.24)$$

b) Efectos de los Datos Atípicos

Las consecuencias incluso de una única observación atípica pueden ser graves: distorsionar las medias y desviaciones típicas de las variables y destruir eventuales relaciones existentes entre ellas.

Consideremos que tenemos una muestra de tamaño n con observaciones de un vector p -dimensional x . Supongamos ahora que introducimos una observación atípica a , que corresponde también a un vector de p variables. Sea $\bar{x}$ el vector de medias de las p variables y V la matriz de varianzas y covarianzas sin el dato atípico; sea $\bar{x}_a$ el vector de medias de las p variables y V_a la matriz de varianzas y covarianzas con el dato atípico. Se comprueba fácilmente que:

$$\bar{x}_a = \bar{x} + \left(\frac{a - \bar{x}}{n+1} \right) \quad (1.25)$$

$$V_a = \left(\frac{n}{n+1} \right) V + \left(\frac{(a - \bar{x})(a - \bar{x})^T}{n+1} \right) \left(\frac{n}{n+1} \right) \quad (1.26)$$

Las expresiones anteriores indican que un solo dato atípico puede afectar de manera importante el vector de medias y la matriz de varianzas y covarianzas.

El efecto del dato atípico depende, además de su magnitud, de su ubicación, particularmente la matriz de varianzas y covarianzas.

c) Identificación de Datos Atípicos

Una regla simple y automática para detectar datos atípicos es la siguiente:

$$\frac{|x_{ki} - \text{mediana}(x_k)|}{MEDA(x_k)} > 4,5 \quad \forall k = 1, 2, \dots, p \quad (1.27)$$

$MEDA(x_k)$ es la mediana de las desviaciones absolutas $|x_{ki} - \text{mediana}(x_k)|$, que es una medida robusta de las dispersión.

Por otra parte, si el número de datos no es muy grande, los diagramas de dispersión pueden ayudar a detectar datos atípicos.

Otra alternativa corresponde a escoger el intervalo que albergue a un 88,88% de las observaciones. El intervalo será el siguiente:

$$\left(\bar{x}_k - \delta \sqrt{V(x_k)}; \bar{x}_k + \delta \sqrt{V(x_k)} \right) \quad \forall k = 1, 2, \dots, p \quad (1.28)$$

Se suele considerar $\delta = 3$. Esta expresión proviene de la desigualdad de Chebychev, ya que en el intervalo definido se encuentra una proporción $1 - \frac{1}{\delta^2}$ de las observaciones. Si $\delta = 4$, se albergan el 93,5% de las observaciones.

2 REGRESIÓN LINEAL MÚLTIPLE

La econometría es la aplicación de métodos estadísticos y matemáticos al análisis de datos, generalmente económicos, biológicos y sociológicos, a fin de otorgar un contenido empírico sobre diferentes teorías, y así verificarlas o refutarlas.

El modelo de regresión lineal es el único escenario en econometría en el que es factible contrastar fehacientemente la capacidad de predicción de los modelos ajustados, mediante la aplicación de diversos test específicos. Otros modelos econométricos, como por ejemplo modelos de elección discreta (Logit, Probit) o de variable dependiente limitada (Tobit, Selección Muestral), si bien pueden estimarse mediante técnicas econométricas, no existe un indicador de bondad de ajuste tan preciso como en el caso de la regresión lineal.

Mediante un modelo de regresión lineal múltiple (RLM) tratamos de explicar el comportamiento de una determinada variable, que denominaremos variable a explicar, variable endógena o variable dependiente, (y representaremos con la letra Y) en función de un conjunto de k variables explicativas $x_1, x_2, \dots, x_k$ mediante una relación de dependencia.

$$Y = f(\beta; X) + \varepsilon \quad (2.1)$$

En el caso del modelo de RLM, la forma funcional es la siguiente:

$$Y = X\beta + \varepsilon \quad (2.2)$$

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_k \end{pmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{bmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_n \end{pmatrix}$$

- Y es el vector de variables dependientes ($n \times 1$)
- β es el vector de parámetros o coeficientes de calibración ($k + 1 \times 1$). Normalmente, se considera que hay k variables explicativas más un término constante o intercepto (representado por la columna de unos en la matriz X).

- X es la matriz de variables independientes o explicativas; observaciones conocidas que incluye una columna con unos ($n \times k + 1$). También se les denomina regresores.
- ε es el vector de errores o residuos no observados ($n \times 1$); también se le denomina perturbación, término aleatorio o estocástico (para el caso de series de tiempo).

Los parámetros β miden la intensidad media de los efectos de las variables explicativas sobre la variable a explicar y se obtienen al tomar las derivadas parciales de la variable a explicar respecto a cada una de las variables explicativas: $\beta_j = \frac{\partial Y}{\partial x_j}$.

El error ε , por su parte, aparece por varias razones. Las tres principales razones son las siguientes:

- i. Muchas veces no es posible captar la totalidad de variables que explican un determinado fenómeno. Es decir, se omiten algunas variables que pueden ser más o menos relevantes en la especificación del modelo. Esto implica que la naturaleza de la relación económica no está correctamente especificada. Evidentemente se espera que en un modelo se especifiquen todas las variables relevantes. Sin embargo, muchas de las variables omitidas pueden incluso tener una influencia suave o irregular, por lo que la perturbación busca representar la influencia neta de la suma de un gran número de variables de tamaños y efectos independientes.
- ii. Mediciones con Error de las variables explicativas o en la variable explicada. Muchas veces no es posible obtener un valor preciso para las variables que se desea estudiar o incorporar en los modelos. Por ejemplo, cuando se miden tiempos de viaje en transporte público o consumo de combustible de los automóviles. Sin embargo, y como veremos más adelante, si las variables explicativas son medidas con error, se obtienen estimaciones sesgadas en la regresión lineal, y si la variable explicada es medida con error, se produce ineficiencia en la estimación (aumento de la varianza).
- iii. Indeterminación humana, es decir, las personas o individuos se comportan de manera diferente frente a los mismos estímulos. El error busca por lo tanto representar esta aleatoriedad inherente al comportamiento humano.

2.1 Supuestos del Modelo

Trataremos de estimar el modelo de manera que, los valores ajustados de la variable endógena o explicada, resulten tan próximos a los valores realmente observados como sea posible. Debe notarse que el modelo corresponde a una esperanza condicionada:

$$E(Y / X) = X\beta \quad (2.3)$$

A fin de poder determinar las propiedades de los estimadores obtenidos al aplicar distintos métodos de estimación y realizar diferentes contrastes, hemos de especificar un conjunto de supuestos sobre la RLM que hemos formulado. Existen tres grupos de supuestos: los supuestos sobre el **término de perturbación**, los supuestos sobre las **variables explicativas**, y los supuestos sobre los **parámetros del modelo**.

2.1.1 Supuestos Sobre la Perturbación

- Valor esperado de la perturbación es cero: $E(\varepsilon_j) = 0, \forall j$.
- Homocedasticidad: todos los términos de perturbación tienen la misma varianza (varianza constante): $V(\varepsilon_i) = V(\varepsilon_j) = \sigma^2, \forall i \neq j$. Por tanto, todos los términos de la diagonal principal de la matriz de varianzas y covarianzas serán iguales.
- No Autocorrelación: los errores son independientes unos de otros, por lo que la matriz de varianzas y covarianzas es una matriz diagonal (fuera de la diagonal principal todo son ceros): $E(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$. Luego, considerando las hipótesis de homocedasticidad y ausencia de autocorrelación, la matriz de varianzas y covarianzas tiene la siguiente estructura:

$$V(\varepsilon) = \begin{bmatrix} \sigma^2 & 0 & 0 & \dots & 0 \\ 0 & \sigma^2 & 0 & \dots & 0 \\ \dots & & & & \dots \\ 0 & 0 & 0 & \dots & \sigma^2 \end{bmatrix} = \sigma^2 \cdot I \quad (2.4)$$

- La perturbación o error presenta una distribución normal: $\varepsilon \sim N(0; \sigma^2 I)$.

En síntesis, en un modelo bueno el error es impronosticable.

2.1.2 Supuestos sobre las Variables Explicativas

- Las variables explicativas son fijas o determinísticas.
- Las variables explicativas no están correlacionadas con el término de error o perturbación: $E(x_i, \varepsilon_i) = 0, \forall i$.
- Las variables explicativas no presentan relación lineal exacta entre si (no existe multicolinealidad perfecta).
- Las variables explicativas son medidas sin error.
- En el modelo no se excluyen las variables relevantes y tampoco se incluyen las variables irrelevantes, a la hora de explicar el comportamiento de la variable endógena.


2.1.3 Supuestos sobre los Parámetros del Modelo

- La única hipótesis que haremos acerca de los parámetros del modelo es la hipótesis de permanencia estructural, lo que significa que los parámetros poblacionales β_j se mantienen constantes a lo largo de toda la muestra.

2.2 Estimación por Mínimos Cuadrados Ordinarios (MCO)

El método de estimación de modelos de regresión lineal más famoso en el mundo entero para efectuar investigación empírica es el de mínimos cuadrados ordinarios (MCO). Este método intenta obtener estimadores de los parámetros de tal forma que la variable predicha $\hat{Y}$ se parezca lo más posible a la variable observada (Y), es decir, se busca minimizar la diferencia $(\hat{Y} - Y)$. Sin embargo, no basta sólo con minimizar esta diferencia, como se observa en la siguiente Figura:


Figura 2.1
Ajuste Según Minimización del Error



En la Figura 2.1 se observa claramente que si el criterio de ajuste fuera simplemente minimizar la diferencia entre los valores observados de las Y (puntos) y los valores modelados (línea recta azul), los dos conjuntos de datos representados por los puntos negros y rojos tendrían el mismo ajuste. Evidentemente, es mejor el ajuste de los puntos rojos. Por lo tanto, minimizar las diferencias entre valores observados y modelados no es un buen criterio.

Una segunda alternativa podría ser minimizar el valor absoluto de las diferencias entre los valores observados y modelados, mitigando el problema expuesto en el párrafo anterior. Sin embargo, este segundo criterio también tiene sus detractores, como se observa en la siguiente Figura:

Figura 2.2
Ajuste Según Minimización del Valor Absoluto del Error



En la Figura 2.2 se observa los puntos negros presentan tres casos en que el ajuste es exacto y otros tres casos en que el ajuste es malo. En el caso de los puntos rojos, se observa que el ajuste en todos los casos es relativamente bueno. Para muchos modeladores, el ajuste de los puntos rojos es preferible al de los puntos negros. Sin embargo, la opinión en este segundo caso es dividida, ya que en determinadas situaciones puede ser preferible predecir exactamente un número pequeño de casos a cambio de fallar groseramente en otros, en lugar de estar cerca en todos, pero sin apuntar exactamente a ninguno. Suponga por ejemplo que usted tiene un modelo que predice los números del Loto; qué preferiría usted si jugara 6 veces, apuntarle al total de los números 3 veces y a ningún número las otras tres veces, o fallar por poco las 6 veces. Evidentemente, en este ejemplo es preferible el primer modelo.

Una tercera alternativa de criterio es minimizar el cuadrado de las diferencias entre los valores observados y los modelados. Esto permite, por una parte, penalizar los errores y, por otra parte, castigar a aquellos puntos que se alejen mucho del valor observado. Por lo tanto, este criterio penaliza más fuertemente a aquellos errores grandes en magnitud que aquellos errores pequeños. A este criterio se le denomina Mínimos Cuadrados Ordinarios o simplemente MCO (los mínimos cuadrados generales, que es un criterio adicional que otorga un peso relativo a cada observación, se presenta en los próximos Capítulos).

Sin embargo, la principal razón del éxito de la estimación por MCO no se debe a la minimización de la suma de errores al cuadrado, ya que ello poco nos dice respecto de la real capacidad explicativa de las variables. La razón de su éxito se debe a que sus resultados superan al de otros criterios (como los dos anteriores), y además a su gran simplicidad en términos computacionales.

2.2.1 Vector de Parámetros

La estimación de MCO se realiza con el criterio de minimizar los cuadrados de los errores inducidos por el modelo poblacional. Luego, debe resolverse el siguiente problema de optimización:

$$\min_{\{\beta\}} Q = \underbrace{(Y - X\beta)^T (Y - X\beta)}_{\varepsilon^T \varepsilon} \quad (2.5)$$

$$\min_{\{\beta\}} Q = Y^T Y - \beta^T X^T Y - Y^T X \beta + \beta^T X^T X \beta = 0 \quad (2.6)$$

y dado que $(X\beta)^T = \beta^T X^T$ se obtiene:

$$\min_{\{\beta\}} Q = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta \quad (2.7)$$

$$\frac{\partial Q}{\partial \beta} = -2X^T Y + 2X^T X \beta = 0 \rightarrow X^T Y = X^T X \beta \quad (2.8)$$

Si X tiene rango $(k + 1)$ de la ecuación normal (2.8) se obtiene entonces la siguiente solución única:

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad (2.9)$$

Debe notarse que la expresión (2.9) corresponde a la razón entre la covarianza de X e Y y la varianza de X . Si X tiene rango menor que $(k + 1)$, es decir, existe dependencia lineal en las observaciones, de la ecuación normal (2.8) deja de obtenerse una única solución. Por otra parte, si X tiene rango mayor que $(k + 1)$, el problema queda indeterminado (más parámetros que ecuaciones).

Por otra parte, la estimación de la varianza de $\hat{\beta}$ se obtiene de la siguiente manera:

$$V(\hat{\beta}) = E\left[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T\right] \quad (2.10)$$

$$E\left[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T\right] = E\left\{\left[(X^T X)^{-1}(X^T \varepsilon)\right]\left[(X^T X)^{-1}(X^T \varepsilon)\right]^T\right\} \quad (2.11)$$

$$V(\hat{\beta}) = E\left[(X^T X)^{-1}(X^T \varepsilon \varepsilon^T X)(X^T X)^{-1}\right] \quad (2.12)$$

$$V(\hat{\beta}) = (X^T X)^{-1} E[X^T \varepsilon \varepsilon^T X] (X^T X)^{-1} \quad (2.13)$$

$$V(\hat{\beta}) = (X^T X)^{-1} X^T E[\varepsilon \varepsilon^T] X (X^T X)^{-1} \quad (2.14)$$

$$V(\hat{\beta}) = (X^T X)^{-1} X^T (\sigma^2 I) X (X^T X)^{-1} \quad (2.15)$$

$$V(\hat{\beta}) = \sigma^2 (X^T X)^{-1} \quad (2.16)$$

Sin embargo, es necesario un estimador de σ^2 . Es directo demostrar a partir de (2.9) y (2.2) que:

$$\hat{\varepsilon} = MY = M(X\beta + \varepsilon) = MX\beta + M\varepsilon = M\varepsilon \quad (2.17)$$

donde $M = (I - X(X^T X)^{-1} X^T)$ es una matriz de $n \times n$ simétrica ($M = M^T$) e idempotente ($M = M^T M$). Luego, de (2.17) se obtiene:

$$\hat{\varepsilon}^T \hat{\varepsilon} = \varepsilon^T M \varepsilon \quad (2.18)$$

$$E(\hat{\varepsilon}^T \hat{\varepsilon} / X) = E(\varepsilon^T M \varepsilon / X) \quad (2.19)$$

$$E\left[tr(\hat{\varepsilon}^T \hat{\varepsilon} / X)\right] = E\left[tr(\varepsilon^T M \varepsilon / X)\right] \quad (2.20)$$

$$tr\left[ME(\varepsilon \varepsilon^T / X)\right] = tr\left[M\sigma^2 I\right] = \sigma^2 tr(M) \quad (2.21)$$

$$\sigma^2 \text{tr}(M) = \sigma^2 \text{tr}\left(I - X(X^T X)^{-1} X^T\right) = \sigma^2 \left[\text{tr}(I_n) - \text{tr}\left(X(X^T X)^{-1} X^T\right) \right] \quad (2.22)$$

$$\sigma^2 \left[\text{tr}(I_n) - \text{tr}(I_k) \right] = \sigma^2 (n - k) \quad (2.23)$$

Por lo tanto se obtiene:

$$E(\hat{\varepsilon}^T \hat{\varepsilon} / X) = \sigma^2 (n - k) \quad (2.24)$$

$$\hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{(n - k)} \quad (2.25)$$

Finalmente, de (2.16) y de (2.25) resulta:

$$\hat{V}(\hat{\beta}) = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{(n - k)} (X^T X)^{-1} \quad (2.26)$$

2.2.2 Aspectos Algebraicos y Propiedades de los Estimadores (Muestras Finitas y Muestras Grandes)

i. El estimador MCO es insesgado y eficiente:

$$\hat{\beta} = (X^T X)^{-1} (X^T (\beta X + \varepsilon)) \quad (2.27)$$

$$\hat{\beta} = (X^T X)^{-1} (X^T X) \beta + (X^T X)^{-1} (X^T \varepsilon) \quad (2.28)$$

$$\hat{\beta} = \beta + (X^T X)^{-1} (X^T \varepsilon) \rightarrow (\hat{\beta} - \beta) = (X^T X)^{-1} (X^T \varepsilon) \quad (2.29)$$


$$E(\hat{\beta}) = \beta + E\left[(X^T X)^{-1} (X^T \varepsilon)\right] \quad (2.30)$$

$$E(\hat{\beta}) = \beta + E\left[(X^T X)^{-1} (X^T \varepsilon)\right] = \beta + (X^T X)^{-1} E(X^T \varepsilon) \quad (2.31)$$

$$E(\hat{\beta}) = \beta + (X^T X)^{-1} E(X^T) E(\varepsilon) \quad (2.32)$$

$$E(\hat{\beta}) = \beta \quad (2.33)$$

Figura 2.3
Ilustración del Sesgo en la Estimación MCO de β



Para demostrar que $\hat{\beta}$ presenta la mínima varianza:

$$b = \left((X^T X)^{-1} X^T + C \right) Y = \hat{\beta} + CY \quad (2.34)$$

$$E(b) = \left((X^T X)^{-1} X^T + C \right) X \beta = (I + CX) \beta = \beta \quad (2.35)$$

$$V(b) = E \left\{ \left((X^T X)^{-1} X^T + C \right) \varepsilon \varepsilon^T \left((X^T X)^{-1} X^T + C \right)^T \right\} \quad (2.36)$$


$$V(b) = \left((X^T X)^{-1} X^T + C \right) E(\varepsilon \varepsilon^T) \left((X^T X)^{-1} X^T + C \right)^T \quad (2.37)$$

$$V(b) = \left((X^T X)^{-1} X^T + C \right) \sigma^2 I \left((X^T X)^{-1} X^T + C \right)^T \quad (2.38)$$

$$V(b) = \sigma^2 \left((X^T X)^{-1} + CC^T \right) = V(\hat{\beta}) + \sigma^2 (CC^T) > V(\hat{\beta}) \quad (2.39)$$

$$\hat{\beta} \sim N \left[\beta; \sigma^2 (X^T X)^{-1} \right] \quad (2.40)$$

Figura 2.4
Ilustración de la Eficiencia en la Estimación MCO de β



A partir de las dos Figuras anteriores surge la siguiente pregunta: ¿qué es preferible, un estimador insesgado o uno eficiente? Surge entonces el concepto de Error Cuadrático Medio (ECM):


$$ECM(\hat{\beta}) = [\text{sesgo}(\hat{\beta})]^2 + V(\hat{\beta}) \quad (2.41)$$

También es posible dar un peso relativo al cuadrado del sesgo y a la varianza, dependiendo lo que el modelador valore más:

$$ECMP(\hat{\beta}) = \alpha [\text{sesgo}(\hat{\beta})]^2 + (1 - \alpha) V(\hat{\beta}) \quad (2.42)$$


La varianza mide la dispersión en torno a la media del parámetro estimado, mientras que el ECM mide la dispersión en torno al verdadero parámetro poblacional. Si el estimador es insesgado, ambos coinciden. El concepto del ECM se aprecia en la siguiente Figura:

Figura 2.5
Ilustración del Error Cuadrático Medio (ECM) de β



- ii. El estimador MCO es consistente: $\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta$ (sin sesgo ni varianza)

Figura 2.6
Ilustración de la Consistencia en la Estimación MCO de β



iii. Otras Propiedades:

- **El valor medio de los residuos es nulo**, lo cual implica que la suma de los residuos es igual a cero. Esta característica es bastante trivial pues se deduce de la misma metodología de los mínimos cuadrados, la cual impone a través de su primera ecuación normal que esta suma sea cero (columna de unos en matriz X).

Si el modelo de regresión posee una constante entonces la primera derivada parcial del lagrangeano (ver (2.8)), o primera expresión de ecuación normal, indicará que la suma de los residuos muestrales es cero.


Sin embargo, si el modelo no posee una constante en su formulación, esta condición no necesariamente se cumplirá pues nunca surge como condición necesaria de primer orden al no tener nunca que derivar con respecto a este parámetro.

Puede sin embargo darse el caso que la representación de los datos haga que este parámetro sea efectivamente cero, por ejemplo si las series Y, X se entregan en forma de desviación de sus propias medias, lo cual implicaría que la suma de estos residuos también lo será (por construcción el intercepto es cero). De (2.8) se obtiene:

$$-2X^T Y + 2X^T X \beta = 0 \rightarrow X^T (Y - X \beta) = X^T \varepsilon = 0 \quad (2.43)$$

- **Los datos muestrales y modelados de Y tienen igual media**. Esta característica se deduce de la noción que el valor actual de la variable dependiente se puede descomponer en lo que estima el modelo y el residuo. Una implicancia de esta condición es que la metodología de los mínimos cuadrados hace que la recta de regresión que pasa a través de la nube de puntos pase justo por el punto que representa a la media de X y la media de Y . Es decir, el hiperplano de la regresión pasa por el punto de las medias de los datos, puesto que la primera ecuación normal implica $\bar{Y} = \bar{X} \beta$.
- La media de los valores estimados por la regresión es igual a la media de los valores actuales; ello se deduce de (2.8) ya que $\hat{Y} = X \beta$.

Figura 2.7
Hiperplano de la Regresión y Medias de las Variables



- Los residuos no se correlacionan con la variable independiente (ver (2.43)).
- Los residuos no se correlacionan con la variable dependiente estimada.

Todos los resultados anteriores requieren que la regresión tenga un término constante.

2.2.3 Teorema Central del Límite

- **Caso univariante:** una sola muestra de tamaño n con media μ y varianza σ^2 .

$$\sqrt{n}(\bar{x}_n - \mu) \xrightarrow{d} N[0; \sigma^2] \quad (2.44)$$

- **Caso univariante con desigualdad de varianzas:** varias muestra con medias μ_r y varianzas σ_i^2 .

$$\sqrt{n}(\bar{x}_n - \bar{\mu}_n) \xrightarrow{d} N[0; \bar{\sigma}^2] \quad (2.45)$$

donde: $\bar{\sigma}^2 = \frac{1}{n}(\sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2)$ y $\bar{\mu}_n = \frac{1}{n}(\mu_1 + \mu_2 + \dots + \mu_n)$

- **Caso multivariante:** un vector de muestras de tamaño n con media $\bar{\mu}$ y matriz de varianzas y covarianzas Q .

$$\sqrt{n}(\bar{X}_n - \bar{\mu}) \xrightarrow{d} N[0; Q] \quad (2.46)$$

- **Caso multivariante con desigualdad de varianzas:** varias muestra con media $\bar{\mu}_i$ y matriz de varianzas y covarianzas Q_i .

$$\sqrt{n}(\bar{X}_n - \bar{\bar{\mu}}_n) \xrightarrow{d} N[0; Q] \quad (2.47)$$

donde: $Q = \lim_{n \rightarrow \infty} \frac{1}{n}(Q_1 + Q_2 + \dots + Q_n)$ y $\bar{\bar{\mu}}_n = \frac{1}{n}(\bar{\mu}_1 + \bar{\mu}_2 + \dots + \bar{\mu}_n)$.

- **Distribución de una función** $g(x_n)$:

$$\sqrt{n}(g(x_n) - g(\mu)) \xrightarrow{d} N\left[0; \left[\frac{\partial g(\mu)}{\partial x}\right]^2 \cdot \sigma^2\right] \quad (2.48)$$

Lo anterior se obtiene de estimar la media y la varianza de las extensiones en Series de Taylor de la función $g(x_n)$:

$$g(x_n) \approx g(\mu) + \frac{\partial g(\mu)}{\partial x}(x_n - \mu) \quad (2.49)$$

Para un conjunto de funciones, el resultados es:

$$\sqrt{n}(\bar{g}(\bar{x}_n) - \bar{g}(\bar{\mu})) \xrightarrow{d} N[0; \nabla g^T \cdot Q \cdot \nabla g] \quad (2.50)$$

2.2.4 Indicadores de Bondad de Ajuste

Lo que se intenta es determinar objetivamente cuán bueno es el modelo que se ha ajustado:

$$Y = \underbrace{X\beta}_{\text{porción explicada}} + \underbrace{\varepsilon}_{\text{porción no explicada}} \quad (2.51)$$

$$Y^T Y = (X\hat{\beta} + \hat{\varepsilon})^T (X\hat{\beta} + \hat{\varepsilon}) \quad (2.52)$$

$$Y^T Y = \hat{\beta}^T X^T X \hat{\beta} + \hat{\varepsilon}^T \hat{\varepsilon} \quad (2.53)$$

$$1 = \frac{\hat{\beta}^T X^T X \hat{\beta}}{Y^T Y} + \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{Y^T Y} \rightarrow \frac{\hat{\beta}^T X^T X \hat{\beta}}{Y^T Y} = 1 - \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{Y^T Y} \quad (2.54)$$

$$R^2 = 1 - \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{Y^T Y} \quad (2.55)$$

Una expresión análoga para R^2 pero más general es la siguiente:

$$R^2 = 1 - \frac{\sum_i (\hat{\varepsilon}_i)^2}{\sum_i (Y_i - \bar{Y})^2} \quad (2.56)$$

Las expresiones (2.55) y (2.56) son idénticas entre sí sólo si la variable Y tiene media cero. La expresión (2.56) es la correlación al cuadrado entre los valores observados de Y y las predicciones calculadas por la ecuación de regresión estimada $\hat{Y}$. El valor de R^2 indica el porcentaje de la varianza de Y que es explicada por las variables X . Dicho de otra forma, R^2 mide el éxito de la ecuación de regresión, dentro de la muestra, para predecir Y .

Notar que el valor de R^2 no guarda relación con la calidad del estimador de β , ya que uno puede tener un buen estimador de β y un bajo R^2 producto simplemente de una alta varianza del error. Por otra parte, es interesante notar que, en presencia del intercepto (término constante de la regresión), el valor del R^2 se ubica siempre entre 0 y 1.

El uso del R^2 debe ser cuidadoso, ya que dependerá de la escala de las variables explicativas y de la variable explicada; por ejemplo usar valores en niveles, en logaritmos o en porcentajes para el mismo fenómeno entrega normalmente diferentes valores de R^2 . tampoco es razonable comparar R^2 entre distintas muestras.

Sin embargo, la utilización de (2.56) como indicador general de bondad de ajuste, si bien es teóricamente robusta, presenta algunos problemas, razón por la cual muchos econométricos no le dan una gran importancia. El principal de ellos hace referencia al número de grados de libertad utilizados en la estimación de los parámetros.

De hecho, R^2 **nunca decrecerá** si se añaden nuevas variables a la ecuación de regresión. Es relativamente trivial demostrar que al agregar una variable adicional (y su respectivo parámetro) al modelo de regresión, se obtiene un nuevo R^2 mayor o al menos igual que el original, incluso si la variable adicional es superflua (no aporta información).

No obstante, adicionar variables tiene un costo en términos de grados de libertad, lo que se traduce en una reducción en la significancia de los parámetros de las variables originales. Es por ello que se considera un valor ajustado como el siguiente:

$$\bar{R}^2 = 1 - (1 - R^2) \frac{(n-1)}{(n-k)} = 1 - \frac{\frac{1}{(n-k)} \sum_i (\tilde{\varepsilon}_i)^2}{\frac{1}{(n-1)} \sum_i (Y_i - \bar{Y})^2} = 1 - \frac{\hat{V}(\tilde{\varepsilon})}{\hat{V}(Y)} \quad (2.57)$$

La expresión (2.57) tiene la ventaja de que podría reducirse si se añade una variable poco importante dentro del conjunto de variables explicativas. Incluso, este valor ajustado podría ser negativo en algunos casos extremos, particularmente cuando el ajuste es deficiente. En el límite, si Y y X tienen un ajuste cercano a cero ($R^2 \approx 0$), se tendría un valor de $\bar{R}^2 \approx \frac{-k+1}{n-k}$. Por otra parte, si hay más de una variable explicativa, $\bar{R}^2 < R^2$.

Finalmente, un contraste de significancia de la regresión como un todo, corresponde a analizar si la totalidad de los coeficientes, a excepción del intercepto, son distintos de cero. Si todas las pendientes son cero, el coeficiente de correlación múltiple R^2 también lo será; luego, es posible basarse en el valor de R^2 para contrastar esta hipótesis. El contraste es el siguiente:

$$F_{(k-1;n-k)} = \frac{R^2}{(1-R^2)} \frac{(n-k)}{(k-1)} \quad (2.58)$$

Valores grandes para la expresión (2.58) dan evidencia en contra de la hipótesis nula (parámetros iguales a cero).

Debe considerarse que cualquier muestra que presente la misma media y misma varianza, presentará por lo tanto los mismos valores estimados para los parámetros (ver el cuarteto de Anscombe).

Figura 2.8
Cuarteto de Anscombe




Figura 2.9
Estimación del Cuarteto de Anscombe

	β_1	β_0
β	0,50	3,00
$se(\beta)$	0,12	1,12
R²-se(y)	0,67	1,24
F(k; n-k+1); (n-k)	17,99	9,00
Var Mod; Var Error	27,51	13,76
t-student	4,24	2,67

2.2.5 MCO vs Máxima Verosimilitud

El método de estimación por MCO consiste en asignar valores numéricos a los parámetros desconocidos de manera que la suma cuadrática de errores sea mínima y sólo requiere que la matriz $X^T X$ sea invertible. A continuación veremos un método de estimación alternativo, el método de máxima verosimilitud.

El método de máxima verosimilitud (MV), un método de estimación alternativo, propone en cambio como un estimador el valor que maximiza la probabilidad de obtener la muestra ya disponible. El método MV se basa, principalmente, en la distribución que sigue el término de error. A tales efectos, se suele suponer que las perturbaciones aleatorias se distribuyen con una distribución Normal que, además de cumplir las propiedades de una muestra grande, es una aproximación cómoda y fácil de tratar.

Suponiendo que el término de error sigue una distribución normal, y dado que la media del error cero, se tiene que:

$$f(\varepsilon_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{\varepsilon_i^2}{2\sigma^2}\right), \quad \forall i = 1, \dots, n \quad (2.59)$$

Maximizar la probabilidad de obtener la muestra ya disponible equivale maximizar la función de densidad conjunta del vector aleatorio ε . Para ello, hemos de suponer homoscedasticidad y ausencia de autocorrelación. Luego, la expresión de la función de densidad conjunta es la siguiente:

$$\prod_{i=1}^n f(\varepsilon_i) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left(-\frac{\sum_i (\varepsilon_i)^2}{2\sigma^2} \right) \quad (2.60)$$

Dado que ε sigue una distribución Normal Multivariante de orden k , la variable Y , al ser una combinación lineal de las perturbaciones aleatorias, también se distribuirá con una distribución Normal Multivariante. Así, para que la función de densidad conjunta sea una función de verosimilitud, el vector aleatorio ε ha de expresarse en función del vector Y , es decir:

$$L(Y; \beta, \sigma^2) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left(-\frac{(Y - X\beta)^T (Y - X\beta)}{2\sigma^2} \right) \quad (2.61)$$

Maximizar la función de verosimilitud (2.61) equivale a maximizar la probabilidad que los datos (X) provengan de la distribución considerada. Luego, el estimador de máxima verosimilitud maximiza por lo tanto dicha probabilidad.

Dado que (2.61) es una función estricta creciente y monótona, maximizarla equivale a maximizar una transformación monótona, como por ejemplo logaritmo natural:

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(2\sigma^2) - \frac{1}{2\sigma^2} (Y - X\beta)^T (Y - X\beta) \quad (2.62)$$

Derivando (2.62) respecto a β y a σ^2 , se obtienen los siguientes resultados:

$$\hat{\beta}_{MV} = (X^T X)^{-1} X^T Y = \hat{\beta}_{MCO} \quad (2.63)$$

$$\hat{\sigma}_{MV}^2 = \frac{(\hat{\varepsilon}^T \hat{\varepsilon})}{n} < \hat{\sigma}_{MCO}^2 = \frac{(\hat{\varepsilon}^T \hat{\varepsilon})}{n - k} \quad (2.64)$$

Observamos que el estimador de MV de β coincide con el MCO, con lo que tendrá las mismas propiedades: será lineal, insesgado, óptimo y consistente. Es fácil ver que el estimador de MV de σ^2 , en cambio, resulta diferente del MCO y es sesgado a la baja aunque asintóticamente insesgado (cuando $n \rightarrow \infty$).

El estimador de MV es consistente, asintóticamente normal, asintóticamente eficiente e invariante. La matriz de varianzas y covarianzas asintótica del estimador de MV corresponde al negativo de la inversa de la **matriz informacional** $I(\theta)$:

$$I(\theta) = E \left[\frac{\partial^2 \ln L}{\partial \theta^T \partial \theta} \right] \quad (2.65)$$

$$[-I(\theta)]^{-1} = \left(-E \left[\frac{\partial^2 \ln L}{\partial \theta^T \partial \theta} \right] \right)^{-1} \quad (2.66)$$

Notar que en el caso de la distribución normal, $\theta = (\mu, \sigma^2)$.

2.2.6 Interpretación Económica

La interpretación económica nos permite comprobar si las estimaciones obtenidas son coherentes con la teoría económica. Según la especificación del modelo, la interpretación y significación de los parámetros puede variar. Si el modelo está especificado en niveles, el parámetro refleja el efecto medio que tiene una variación unitaria de la variable explicativa sobre la variable endógena:

$$\beta_j = \frac{\partial Y}{\partial x_j} \quad (2.67)$$

En cambio, si el modelo está especificado en logaritmos, los parámetros pueden interpretarse como una elasticidad, como es el caso de la función de producción de Cobb-Douglas:


$$\beta_j = \frac{\partial \ln Y}{\partial \ln x_j} \quad (2.68)$$

Recordar que la elasticidad precio-demanda es $\eta = \frac{\partial Q}{\partial P} \frac{P}{Q} = \frac{\partial \ln Q}{\partial \ln P}$.

2.2.7 Diagrama de Venn


Considere una variable Y que la deseamos regresionar con una variable X , obteniendo un término de error ε . La variabilidad de la variable dependiente Y está representada por el círculo amarillo de la Figura 2.10. La variabilidad de la variable independiente X está representada por el círculo blanco. La superposición de ambos círculos, representada por el área azul, representa la variación que tienen en común ambas variables. Mientras mayor sea el área azul, mayor será la correlación entre ambas variables, por lo que la información utilizada para estimar el parámetro β_x es mayor. La parte del círculo amarillo que no se superpone al círculo blanco corresponde a la variación en Y que no es explicada por X , y por lo tanto se traspasa al error ε . El R^2 puede en este caso interpretarse como la razón entre el área azul y el círculo amarillo.

Figura 2.10
Diagrama de Venn Para Una Variable Explicativa



Consideremos ahora la Figura 2.11 siguiente, que representa un diagrama de Venn para 2 variables explicativas:


Figura 2.11
Diagrama de Venn Para Dos Variables Explicativas



El área naranja más el área roja representa la correlación conjunta (grado de colinealidad) que tienen las variables X y Z .

Si regresionamos Y sólo sobre X , se utilizaría el área azul más la roja. Si regresionamos Y sólo sobre Z , usaríamos el área verde más la roja. Luego, el área roja representa aquella variación en Y que es explicada tanto por X como por Z , debido a que estas dos variables explicativas están correlacionadas.


Por lo tanto, se observa claramente que regresionar Y sobre X y Z simultáneamente, genera resultados diferentes que regresionar Y sobre X o Y sobre Z separadamente. Pero, ¿qué pasaría si X y Z están incorrelacionadas?

Figura 2.12**Diagrama de Venn Para Dos Variables Explicativas Incorrelacionadas**


Si X y Z están incorrelacionadas, estimar separadamente Y sobre cada regresor X y Z entregará los mismos resultados que regresionar Y sobre los dos regresores. Sin embargo, se observa claramente que incluir ambas variables aumenta la proporción explicada de la variación de Y (excepto que el área azul o el área verde fueran cero, es decir, que no haya intercección entre Y y X o entre Y y Z). El R^2 en este caso puede interpretarse como la razón entre la suma de las áreas azul más la verde y el círculo amarillo.

2.2.8 Interpretación Geométrica de los MCO

Considere el modelo $Y = \beta_1 X_1 + \beta_2 X_2 + \varepsilon$. Considerando las variables como vectores, se puede generar la siguiente Figura:



La regresión de Y sobre X_1 y X_2 corresponde a la proyección de dicho vector sobre el hiperplano generado por las variables independientes, en este caso el plano formado por X_1 y X_2 :




Luego, el valor de los parámetros estimados es necesario descomponer el vector proyectado $\hat{Y}$ sobre las distintas variables X , obteniendo en este caso los trazos definidos por OF_1 y OF_2 , por lo que se obtiene las siguientes estimaciones MCO:

$$\hat{\beta}_1 = \frac{OF_1}{OB} \quad , \quad \hat{\beta}_2 = \frac{OF_2}{OC} \quad (2.69)$$

Es interesante notar que los estimadores de los parámetros pueden ser mayor o menor que uno, y también positivos o negativos, dependiendo de la estructura de los vectores considerados.

Notar también que $\hat{\varepsilon} = Y - \hat{Y} = AD$.



Por otra parte, teniendo en cuenta que las variables están medidas en desviaciones respecto a sus medias (estandarizadas), el coeficiente de determinación puede escribirse como:

$$R = \frac{\hat{Y}^T \hat{Y}}{Y^T Y} \quad (2.70)$$


Dado que $\hat{Y}^T \hat{Y} = \hat{Y}^T (Y - \hat{\varepsilon}) = \hat{Y}^T Y - \hat{Y}^T \hat{\varepsilon} = \hat{Y}^T Y$ se obtiene:

$$R^2 = \frac{\hat{Y}^T \hat{Y} \times \hat{Y}^T \hat{Y}}{Y^T Y \times \hat{Y}^T \hat{Y}} = \frac{\hat{Y}^T Y \times \hat{Y}^T Y}{Y^T Y \times \hat{Y}^T \hat{Y}} \rightarrow R = \frac{\hat{Y}^T Y}{\sqrt{Y^T Y} \times \sqrt{\hat{Y}^T \hat{Y}}} \quad (2.71)$$

La expresión anterior es el coeficiente de correlación simple entre $\hat{Y}$ e Y .

Por otra parte, se tiene que:


$$\cos \theta = \frac{OD}{OA} = \frac{\sqrt{\hat{Y}^T \hat{Y}}}{\sqrt{Y^T Y}} = \frac{\hat{Y}^T Y}{\sqrt{Y^T Y} \times \sqrt{\hat{Y}^T \hat{Y}}} \quad (2.72)$$



Por lo tanto, el coeficiente de correlación múltiple o R^2 es igual al coseno del ángulo que forma el vector Y con el plan formado por X_1 y X_2 .

El coeficiente de correlación parcial entre Y y X_2 , dado X_1 , corresponde al coeficiente de correlación simple entre los residuos de la regresión de Y y X_2 ambas sobre X_1 por separado. Luego, este coeficiente será igual al coseno del ángulo (θ_1) que forman ambos vectores de residuos:

$$\cos \theta_1 = \frac{AG_1}{CG_2} \quad (2.73)$$



El contraste F en este caso se forma a partir de un cuociente. En el numerador es la diferencia de la suma de los cuadrados de los residuos con y sin restricciones; en el denominador la suma de los cuadrados de los residuos sin restricciones.

$$\frac{(\hat{\varepsilon}_R^T \hat{\varepsilon}_R - \hat{\varepsilon}^T \hat{\varepsilon})/p}{\hat{\varepsilon}^T \hat{\varepsilon}/(n-k)} \sim F_{[p; n-k]} \quad (2.74)$$

Luego, si se desea contrastar la hipótesis $\hat{\beta}_2 = 0$ (por lo que no existiría correlación entre Y y la variable X_2), el vector de residuos con restricciones ($\hat{\varepsilon}_R$) será la diferencia entre el vector Y y el vector que resulta de proyectar Y sobre X_1 , al que denominaremos $\hat{Y}_1$, y se tendrá que $|\hat{Y}_1| = OG_1$. En consecuencia: $\hat{\varepsilon}_R = Y - \hat{Y}_1 = AG_1$. Análogamente, el vector de errores sin restricción es $\hat{\varepsilon} = Y - \hat{Y} = AD$

Finalmente, se tendrá la siguiente expresión:

$$\frac{((AG_1)^2 - (AD)^2)/1}{(AD)^2/(n-2)} \sim F_{[1; n-2]} \quad (2.75)$$

3 INFERENCIA Y PRECICCIÓN

3.1 Contraste de Restricciones

3.1.1 Contraste de una Restricción Lineal

Dado que la distribución de los coeficientes de regresión pueden ser caracterizados a partir de $\hat{\beta} \sim N\left[\beta; \sigma^2 (X^T X)^{-1}\right]$, y dado que se ha supuesto independencia estadística entre los parámetros y el vector de residuos, entonces el estadístico:

$$\frac{(\hat{\beta}_i - \beta_i)}{se(\hat{\beta}_i)} \sim t_{(n-k)} \quad (3.1)$$

sigue una distribución t con $(n - k)$ grados de libertad. Notar que al ser un análisis asintótico (n grande), la distribución t converge a una distribución normal. Notar además que el término $se(\hat{\beta}_i) = \sqrt{\sigma^2 S^{ii}}$, donde S^{ii} es el i -ésimo elemento de la diagonal de $(X^T X)^{-1}$.

Para llevar a cabo hipótesis sobre el valor de un coeficiente puede emplearse un estadístico de la t tradicional. Si el valor del parámetro calibrado $\hat{\beta}$ difiere significativamente del verdadero valor de β , deducimos entonces que los datos muestrales no son consistentes con la hipótesis nula.

Un contraste común consiste en si un parámetro $\hat{\beta}$ es significativamente distinto de cero. En tal caso, el estadístico es:

$$t = \frac{\hat{\beta}_i}{se(\hat{\beta}_i)} \quad (3.2)$$

En general, si $|\hat{\beta}_i - \beta_i| / se(\hat{\beta}_i) > t_{\lambda/2}$, donde $\lambda/2$ define el grado de confiabilidad exigido de la distribución t con $(n - k)$ grados de libertad, entonces la hipótesis se rechaza y se dice que el coeficiente es estadísticamente significativo; es decir, la variable asociada a dicho componente ayuda a describir el fenómeno estudiado.

En otras palabras, t es una medida de la diferencia entre la función hipotética de los verdaderos coeficientes y la misma función de las estimaciones de dichos coeficientes. Si la hipótesis es verdadera, las estimaciones deberían reflejarlo al menos dentro de los rangos de variabilidad muestral. El valor $t = 1,96$ (correspondiente a un grado de significatividad del 95% en muestras grandes) normalmente es el utilizado como valor de referencia.

Un intervalo de confianza para β_i estaría dado por:

$$P\left(\hat{\beta}_i - t_{\lambda/2} se(\hat{\beta}_i) < \beta_i < \hat{\beta}_i + t_{\lambda/2} se(\hat{\beta}_i)\right) = 1 - \lambda \quad (3.3)$$

3.1.2 Contraste de Restricciones Lineales Conjuntas

Consideremos las siguientes restricciones lineales del modelo de RLM:

$$\left. \begin{array}{l} R_{11}\beta_1 + R_{12}\beta_2 + \dots + R_{1k}\beta_k = q_1 \\ R_{21}\beta_1 + R_{22}\beta_2 + \dots + R_{2k}\beta_k = q_2 \\ \dots \\ R_{p1}\beta_1 + R_{p2}\beta_2 + \dots + R_{pk}\beta_k = q_p \end{array} \right\} R\beta = q \quad (3.4)$$

La matriz R tiene k columnas y p filas (restricciones); con las restricciones hay por lo tanto sólo $k - p$ parámetros libres.

La hipótesis nula corresponde en este caso a $R\beta = q$. A partir del valor numérico que tome el estadístico de contraste es posible determinar si la diferencia entre $R\beta$ y q es estadísticamente significativa o no lo es. La regla de decisión es la siguiente:

$$\frac{(R\hat{\beta} - q)^T \left[R(X^T X)^{-1} R^T \right]^{-1} (R\hat{\beta} - q) / p}{\hat{\varepsilon}^T \hat{\varepsilon} / (n - k)} \sim F_{[p; n-k]} \quad (3.5)$$

donde $\hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - k} \rightarrow \hat{\varepsilon}^T \hat{\varepsilon} = \hat{\sigma}^2 (n - k)$.

- Si $F \geq F_{[p; n-k]}$ el estadístico de contraste se encuentra fuera de la región de aceptación, lo cual nos lleva a rechazar la hipótesis nula. Por tanto, las restricciones lineales no son ciertas en el ámbito de la población.

- Si $F < F_{[p;n-k]}$ el estadístico de contraste cae dentro de la región de aceptación, con lo cual no podemos rechazar la hipótesis nula. En consecuencia, podemos afirmar que las restricciones son ciertas en el ámbito de la población.

En el caso particular que se desee testear que todos los k parámetros de la regresión, excepto la constante o intercepto, son significativamente distintos de cero, se tendrá que $R = I_{k-1}$ y $q = (0, 0, \dots, 0)$. Luego, de (3.5) se obtiene:

$$\frac{\hat{\beta}^T (X^T X) \hat{\beta} / (k-1)}{\hat{\varepsilon}^T \hat{\varepsilon} / (n-k)} \sim F_{[k-1; n-k]} \quad (3.6)$$

y dado que $\hat{\beta} = (X^T X)^{-1} X^T Y$ se obtiene finalmente:

$$\frac{R^2}{(1-R^2)} \frac{(n-k)}{(k-1)} \sim F_{[k-1; n-k]} \quad (3.7)$$

Esta última expresión (3.7) nos indica que aquellas regresiones que tienen bajo coeficiente de ajuste, es decir un bajo R^2 , tienen a su vez un test F también muy bajo, lo cual permitiría decir que la probabilidad de rechazar la hipótesis es muy baja.


3.1.3 Contraste Basado en una Región de Confianza

En el modelo de RLM, una región de confianza para un conjunto de coeficientes sería el conjunto de valores para los cuales la hipótesis de que el conjunto de coeficientes verdaderos iguala a estos valores no sería rechazada. El contraste en este caso es:

$$\frac{1}{2} (\hat{\beta} - \beta)^T \left[R^T \left(\frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n-k} \right) (X^T X)^{-1} R \right]^{-1} (\hat{\beta} - \beta) \sim F_{[p; n-k]} \quad (3.8)$$

En el caso de 2 parámetros $(\hat{\beta}_1, \hat{\beta}_2)$, cuyos estimadores presenten distintas varianzas, la región de confianza está dada por una elipse en el plano $(\hat{\beta}_1, \hat{\beta}_2)$. Para entender este contraste, consideremos la siguiente Figura:

Figura 3.1
Región de Confianza Para Variables Incorrelacionadas




Considerando una significancia del 95% para cada parámetro en forma independiente, el área del rectángulo de la Figura 3.1 sería $0,95 \times 0,95 = 0,9025$. Por lo tanto, el rectángulo no es lo suficientemente grande, y un contraste de cada parámetro por separado podría no ser adecuado. La elipse representa un corte de la campana de Gauss a una "altura" que representa el 95%. Luego, si se exigiera un 99%, el área de la elipse crecería, y si se exigiera un 90%, el área sería menor.

¿Por qué se produce esta diferencia entre el rectángulo y la elipse? La respuesta es simple: las áreas en las cuatro puntas del rectángulo, que están fuera de la elipse, son muy poco probables, es decir, es muy difícil que en una distribución conjunta los 2 parámetros estimados tengan valores que caigan en dichas áreas. Por otra parte, las áreas de la elipse que caen fuera del rectángulo pasan a ser más probables, ya que representan probabilidades condicionales. Es decir, dado que existe una distribución divariada en el ejemplo de la Figura 3.1, es más probable obtener dos estimadores de β_1 y β_2 representados en el punto A que en el punto B.

Considerando que existe correlación (colinealidad) entre las variables explicativas, el análisis es similar. Sin embargo, y como se aprecia en la Figura 3.2, los errores que se pueden cometer son mucho mayores.

Figura 3.2
Región de Confianza Para Variables Correlacionadas



3.1.4 Mínimos Cuadrados Restringidos

De manera análoga al estimador de MCO, en el caso restringido se resuelve el siguiente problema de optimización:

$$\min_{\{\beta\}} Q = \underbrace{(Y - X\beta)^T (Y - X\beta)}_{\varepsilon^T \varepsilon} \quad (3.9)$$

$$s.a.: \quad R\beta = q \quad (2\lambda) \quad (3.10)$$

Sin pérdida de generalidad, el lagrangeano del problema anterior es:

$$L(\beta, \lambda) = (Y - X\beta)^T (Y - X\beta) + 2\lambda (R\beta - q) \quad (3.11)$$

$$\frac{\partial L}{\partial \beta} = -2X^T (Y - X\hat{\beta}_R) + 2R^T \lambda = 0 \quad (3.12)$$

$$\frac{\partial L}{\partial \lambda} = 2(R^T \hat{\beta}_R - q) = 0 \quad (3.13)$$

Dividiendo por 2 y desarrollando se obtiene la siguiente matriz particionada:

$$\begin{bmatrix} X^T X & R^T \\ R & 0 \end{bmatrix} \begin{bmatrix} \hat{\beta}_R \\ \lambda \end{bmatrix} = \begin{bmatrix} X^T Y \\ q \end{bmatrix} \quad (3.14)$$

Si $X^T X$ es no singular, se obtiene entonces:

$$\hat{\beta}_R = \hat{\beta} + (X^T X)^{-1} R^T \left[R (X^T X)^{-1} R^T \right]^{-1} (R\hat{\beta} - q) \quad (3.15)$$

$$\lambda = \left[R (X^T X)^{-1} R^T \right]^{-1} (R\hat{\beta} - q) \quad (3.16)$$

De la expresión (2.9) se observa que, si la restricción es correcta, es decir, efectivamente $(R\hat{\beta} - q)$, el estimador restringido corresponde al estimador de MCO $(\hat{\beta}_R = \hat{\beta})$. Del mismo modo, el parámetro λ valdría cero.

Adicionalmente, se tiene que:

$$V(\hat{\beta}_R) = \sigma^2 (X^T X)^{-1} - \underbrace{\sigma^2 (X^T X)^{-1} R^T \left[R (X^T X)^{-1} R^T \right] R (X^T X)^{-1}}_{\text{Matriz Positiva Definida}} \quad (3.17)$$

Luego, el estimador restringido presenta menor varianza que el estimador MCO. Ello se explica por el valor de la información contenida en las restricciones, lo que reduce la incertidumbre en la estimación (más grados de libertad).

3.1.5 Contraste de Restricciones No Lineales

El problema general consiste en el contraste de la hipótesis que implica una función no lineal de los coeficiente de la regresión:

$$g(\beta) = q \quad (3.18)$$

Analizando el caso de una única restricción resulta:

$$\frac{g(\hat{\beta}) - q}{se(g(\hat{\beta}))} \sim t_{(n-k)} \quad (3.19)$$

La aproximación lineal en series de Taylor para $g(\hat{\beta}_i)$ implica lo siguiente:

$$g(\hat{\beta}) \approx g(\beta) + \left[\frac{\partial g(\beta)}{\partial \beta} \right]^T (\hat{\beta} - \beta) \quad (3.20)$$

$$V[g(\hat{\beta})] \approx \left[\frac{\partial g(\beta)}{\partial \beta} \right]^T V(\hat{\beta}) \left[\frac{\partial g(\beta)}{\partial \beta} \right] \quad (3.21)$$

$$V[g(\hat{\beta})] \approx \left[\frac{\partial g(\beta)}{\partial \beta} \right]^T \left[\frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n-k} (X^T X)^{-1} \right] \left[\frac{\partial g(\beta)}{\partial \beta} \right] \quad (3.22)$$

De la expresión (3.21) se obtiene el valor requerido:

$$se[g(\hat{\beta})] = \left(V[g(\hat{\beta})] \right)^{1/2} \quad (3.23)$$

3.2 Predicción

Junto con la estimación de parámetros y la inferencia, el uso más habitual de la regresión es la predicción.

La predicción del conjunto de regresores X^0 es la siguiente:

$$Y^0 = X^0 \beta + \varepsilon^0 \quad (3.24)$$

Sin embargo, usando el modelo estimado tendríamos:

$$\hat{Y}^0 = X^0 \hat{\beta} \quad (3.25)$$

que corresponde al estimador de $E(Y^0)$. Luego, el error de predicción en este caso está dado por:

$$e^0 = Y^0 - \hat{Y}^0 = X^0 (\beta - \hat{\beta}) + \varepsilon^0 \quad (3.26)$$

La varianza de este error es:

$$V(e^0) = \sigma^2 + V[X^0 (\beta - \hat{\beta})] = \sigma^2 + X^{0T} V[(\beta - \hat{\beta})] X^0 \quad (3.27)$$

$$V(e^0) = \sigma^2 + X^{0T} [\sigma^2 (X^T X)^{-1}] X^0 \quad (3.28)$$

$$V(e^0) = \sigma^2 \left(1 + X^{0T} (X^T X)^{-1} X^0 \right) \quad (3.29)$$

La expresión (3.29) representa la distancia de los elementos de X^0 respecto a la media de los datos. Esto implica que mientras más lejos estén los datos X^0 de la media, mayor será el grado de incertidumbre. El intervalo de confianza para la predicción es por lo tanto:

$$\hat{Y}^0 \pm t_{\lambda/2} \cdot \left[\sigma^2 \left(1 + X^{0T} (X^T X)^{-1} X^0 \right) \right]^{1/2} \quad (3.30)$$

Es interesante determinar cuál es el valor de X^0 que minimiza la varianza de la predicción. Para ello, se puede resolver el siguiente problema de minimización:

$$\min_{\{X\}} X^{0T} (X^T X)^{-1} X^0 \quad (3.31)$$

$$s.a.: X_1^0 = 1 \quad (\lambda) \quad (3.32)$$

La restricción $X_1^0 = 1$ se refiere al hecho de que el primer elemento de X^0 es el intercepto de la ecuación de regresión.

El lagrangeano y condiciones de primer orden son:

$$L = X^{0T} (X^T X)^{-1} X^0 - \lambda (X_1^0 - 1) \quad (3.33)$$

$$\frac{\partial L}{\partial X^0} = 2(X^T X)^{-1} X^0 - \lambda \begin{pmatrix} 1 \\ 0 \\ \dots \\ 0 \end{pmatrix} = 0 \quad (3.34)$$

$$X^0 = \frac{\lambda}{2} (X^T X)^{-1} \begin{pmatrix} 1 \\ 0 \\ \dots \\ 0 \end{pmatrix} \quad (3.35)$$

La expresión (3.35) indica que X^0 es proporcional a la primera columna de $X^T X$, por lo que se obtiene:

$$X^0 = \frac{\lambda}{2} \begin{pmatrix} n \\ \sum_{i=1}^n x_{i2} \\ \dots \\ \sum_{i=1}^n x_{ik} \end{pmatrix} \quad (3.36)$$

De la primera fila de (3.36) se deduce que $1 = \frac{\lambda}{2} n \rightarrow \lambda = \frac{2}{n}$. En consecuencia, podemos escribir (3.36) como:

$$X^0 = \begin{pmatrix} 1 \\ \sum_{i=1}^n x_{i2} / n \\ \dots \\ \sum_{i=1}^n x_{ik} / n \end{pmatrix} \quad (3.37)$$


El lado derecho de (3.37) corresponde al vector de medias de las observaciones. En consecuencia, la varianza del error de pronóstico es minimizada cuando todas las nuevas observaciones de las variables independientes son iguales a sus valores medios. A partir de (3.37), para luego sustituir en (3.29), se obtiene:

$$X^0 = \frac{1}{n} X^T X \begin{pmatrix} 1 \\ 0 \\ \dots \\ 0 \end{pmatrix} \quad (3.38)$$

$$V(e^0) = \sigma^2 \left(1 + \frac{1}{n} \right) \quad (3.39)$$

En consecuencia, el intervalo de confianza será menor en los valores medios de las variables de X .

Figura 3.3
Intervalo de Confianza Para las Predicciones



Finalmente, la predicción se puede medir de acuerdo a diversos criterios. Sin embargo, todos estos criterios se basan en evaluaciones ex-post, es decir, predicciones para las que las variables exógenas no tienen que ser predichas en los n^0 períodos siguientes. Dos de estos criterios son la raíz del error cuadrático medio (*RECM*) y el error absoluto medio (*EAM*):

$$RECM = \sqrt{\frac{1}{n^0} \sum_i (Y_i - \hat{Y}_i)^2} \quad (3.40)$$

$$EAM = \frac{1}{n^0} \sum_i |Y_i - \hat{Y}_i| \quad (3.41)$$

Los dos criterios anteriores presentan evidentemente un problema de escala. Criterios alternativos son:

$$U = \sqrt{\frac{\frac{1}{n^0} \sum_i (Y_i - \hat{Y}_i)^2}{\frac{1}{n^0} \sum_i (Y_i)^2}} \quad (3.42)$$

$$\Delta U = \sqrt{\frac{\frac{1}{n^0} \sum_i (\Delta Y_i - \Delta \hat{Y}_i)^2}{\frac{1}{n^0} \sum_i (\Delta Y_i)^2}} \quad (3.43)$$

donde $\Delta Y_i = (Y_i - Y_{i-1})$ y $\Delta \hat{Y}_i = (\hat{Y}_i - \hat{Y}_{i-1})$. Este último es válido sólo en series de tiempo.

3.3 Estimación por Mínimos Cuadrados Generales (MCG)

En este caso asumimos que $V(\varepsilon) \neq \sigma^2 I$, por lo que podemos expresar la matriz de varianzas y covarianzas de la perturbación como $V(\varepsilon) = \sigma^2 \Omega$, donde Ω es una matriz de $n \times n$ positiva definida:

$$V(\varepsilon) = \begin{bmatrix} \sigma_{11}^2 & \sigma_{12}^2 & \sigma_{13}^2 & \dots & \sigma_{1n}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \sigma_{23}^2 & \dots & \sigma_{2n}^2 \\ \dots & \dots & \dots & \dots & \dots \\ \sigma_{n1}^2 & \sigma_{n2}^2 & \sigma_{n3}^2 & \dots & \sigma_{nn}^2 \end{bmatrix} = \sigma^2 \cdot \Omega \quad (3.44)$$

Esta matriz Ω la podemos descomponer de la siguiente manera:

$$\Omega = PP^T \rightarrow \Omega^{-1} = (P^{-1})(P^{-1})^T \quad (3.45)$$

con lo que se obtiene el siguiente modelo:

$$P^{-1}Y = P^{-1}X\beta + P^{-1}\varepsilon \rightarrow Y^* = X^*\beta + \varepsilon^* \quad (3.46)$$

Por tanto, se ha conseguido una transformación del modelo de forma que las perturbaciones cumplen las hipótesis habituales. Al estimador de β por MCO en el modelo transformado se le denomina estimador de Mínimos Cuadrados Generalizados (MCG):

$$\hat{\beta}_{MCG} = (X^{*T}X^*)^{-1}X^{*T}Y^* = (X^T\Omega^{-1}X)^{-1}X^T\Omega^{-1}Y \quad (3.47)$$

$$V(\hat{\beta}_{MCG}) = \sigma^2(X^{*T}X^*)^{-1} = \sigma^2(X^T\Omega^{-1}X)^{-1} \quad (3.48)$$

siendo el siguiente un estimador insesgado de la varianza de las perturbaciones:

$$\hat{\sigma}^2 = \frac{\overbrace{(Y - X\hat{\beta}_{MCG})^T}^{\hat{\varepsilon}^T} (\Omega^{-1}) \overbrace{(Y - X\hat{\beta}_{MCG})}^{\varepsilon}}{n - k} \quad (3.49)$$

Es decir, el estimador MCG minimiza la suma de cuadrados de residuos ponderada por la inversa de su matriz de covarianzas.

No hay una contrapartida precisa del R^2 del modelo ordinario con el R^2 del modelo generalizado. Una elección sería usar el R^2 del modelo transformado $Y^* = X^* + \varepsilon^*$, pero esta regresión no tiene por qué tener término constante el coeficiente de determinación no estaría acotado entre cero y uno.

Pero incluso si existe término constante, el modelo transformado no es más que un instrumento computacional, no el modelo de interés. El hecho de que se obtenga una mejora o un empeoramiento en el ajuste del modelo transformado puede no tener ningún interés, ya que la variable dependiente Y^* es diferente de la original.

Por otra parte, el estimador de MCG es en presencia de autocorrelación y/o heterocedasticidad más eficiente que el de MCO, aunque ambos son insesgados, consistentes y asintóticamente normales.

Para usar MCG es necesario sin embargo obtener un estimador consistente de Ω . Debido a que Ω es una matriz de $n \times n$ con $\frac{n(n+1)}{2}$ elementos, es imposible con las n observaciones estimar todos los elementos. Considerando $\hat{\Omega}$ como estimador de Ω , se obtendría:

$$\hat{\beta}_{MCG} = \left(X^T \hat{\Omega}^{-1} X \right)^{-1} X^T \hat{\Omega}^{-1} Y \quad (3.50)$$

$$V\left(\hat{\beta}_{MCG}\right) = \frac{\hat{\varepsilon}^T \hat{\Omega}^{-1} \hat{\varepsilon}}{n-k} \left(X^T \hat{\Omega}^{-1} X \right)^{-1} \quad (3.51)$$

En el caso de heterocedasticidad, se tendrá que:

$$P = \begin{bmatrix} \frac{1}{\sigma_1} & 0 & \dots & 0 \\ 0 & \frac{1}{\sigma_2} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \frac{1}{\sigma_n} \end{bmatrix} \quad (3.52)$$

Por su parte, en el caso de correlación serial (autocorrelación), se tendrá que:

$$P = (1 - \rho^2)^{-1/2} \begin{bmatrix} \sqrt{1 - \rho^2} & 0 & \dots & 0 \\ -\rho & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & \dots & -\rho & 1 \end{bmatrix} \quad (3.53)$$

4 ESPECIFICACIÓN

La especificación de los modelos es un tema que no es tratado en detalle en los libros de econometría, ya que estos se centran principalmente en los procesos de estimación e inferencia, para un modelo conocido. La razón de ello es que la especificación correcta para obtener un buen modelo es normalmente difícil.

En este capítulo estudiaremos técnicas que nos permiten definir la forma funcional de un modelo de regresión lineal, a fin de obtener mejores resultados. Sin embargo, nunca debemos dejar de considerar las siguientes aseveraciones:

“Los modelos son para ser usados, no para creer en ellos” (Henry Theil, 1971).

“Todos los modelos son incorrectos, pero algunos son útiles” (George E. Box, 1987).

“Los modelos son sólo metáforas, una pequeña ventana para ver el resto del mundo” (Peter Kennedy, 2005).

4.1 Variables Ficticias

Si es posible definir con certeza el momento del eventual quiebre estructural ya sea en un parámetro como en una combinación de parámetros entonces podemos aplicar lo que se conoce como variables mudas.

Las variables ficticias recogen los efectos diferenciales que se producen en el comportamiento de los agentes económicos debido a diferentes causas como las siguientes:

- **De tipo temporal:** Para recoger efectos diferentes en función del tiempo en que se producen las observaciones de las variables (por ejemplo, consumo en periodos de guerra o paz).
- **De carácter espacial:** Para tener en cuenta la pertenencia o no de la observación a una determinada zona (por ejemplo, consumo en zonas rurales o urbanas).

- **De tipo cualitativo:** Para recoger los efectos de variables cualitativas como el género, el estado civil, tener o no cargas familiares, nivel de educación, etc. sobre el comportamiento de los agentes económicos en decisiones de consumo, de oferta de trabajo, etc.
- **Otras causas:** Para conocer los efectos que las variables cuantitativas tienen sobre la variable endógena, distinguiendo por submuestras (por ejemplo, la propensión marginal al consumo de individuos de rentas altas o bajas).

Una variable muda o ficticia generalmente se asocia a una función indicadora de un evento determinado. Esta nueva variable artificial tomará valor unitario si el evento está presente y cero si no es así. Ejemplos de este tipo de funciones son muchos, por ejemplo:

- Guerra - Paz
- Hombre - Mujer
- Profesional - Técnico
- Gobierno A - Gobierno B
- Crisis Bancaria - Normalidad
- Tipo de Cambio Fijo - Tipo de Cambio Flexible

Si estas variables no son directamente cuantificables entonces surge la alternativa de utilizar variables dicotómicas mudas. Volvamos al modelo de regresión simple para entender cómo contrastar cambios estructurales en algún o algunos parámetros utilizando esta variable. Supongamos que el modelo a estimar es:

$$Y^i = \beta_0 + \beta_1 x_1^i + \varepsilon^i \quad (4.1)$$

Sin embargo, se ha identificado que para cierto grupo de observaciones existen cambios estructurales. Para incorporar este hecho econométricamente, creamos una nueva serie artificial (muda) D^i que tomará valores de cero y uno. La siguiente Tabla ayuda a comprender esta representación:

Tabla 4.1
Variables Ficticias

Observación (<i>i</i>)	Y^i	X^i	D^i
1	Y^1	X^1	0
2	Y^2	X^2	0
.....			
$j - 1$	Y^{j-1}	X^{j-1}	0
j	Y^j	X^j	1
$j + 1$	Y^{j+1}	X^{j+1}	1
.....			
n	Y^n	X^n	1

Con esta nueva variable podemos contrastar cambios tanto en el coeficiente de intercepto β_0 como en el de la pendiente β_1 .

4.1.1 Cambio Estructural en el Intercepto

La especificación del modelo es en este caso la siguiente:

$$\begin{aligned} Y^i &= \beta_0 + \beta_1 x_1^i + \varepsilon^i & \forall i = 1, 2, \dots, j-1 \\ Y^i &= \beta_0 + \beta_1 x_1^i + \beta_2 D^i + \varepsilon^i & \forall i = j, j+1, \dots, n \end{aligned} \quad (4.2)$$

La hipótesis está representada por :

$$\begin{aligned} H_0 : \beta_2 &= 0 \\ H_1 : \beta_2 &\neq 0 \end{aligned} \quad (4.3)$$

El contraste consiste en evaluar si el parámetro $\hat{\beta}_2$ es significativamente distinto de cero o no. Para esto generamos un test t :

$$t_c = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\hat{V}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2}{\sqrt{\hat{V}(\hat{\beta}_2)}} \quad (4.4)$$

Si t_c (en valor absoluto) es menor al valor tabulado de t_{n-k} para cierto nivel de precisión, no rechazamos la hipótesis de que el parámetro es cero, no habiendo por lo tanto indicios de quiebre estructural en el parámetro del intercepto.

4.1.2 Cambio Estructural en la Pendiente

La especificación del modelo es en este caso la siguiente:

$$\begin{aligned} Y^i &= \beta_0 + \beta_1 x_1^i + \varepsilon^i & \forall i = 1, 2, \dots, j-1 \\ Y^i &= \beta_0 + (\beta_1 + \beta_2 D^j) x_1^i + \varepsilon^i & \forall i = j, j+1, \dots, n \end{aligned} \quad (4.5)$$

La hipótesis está representada por :

$$\begin{aligned} H_0 : \beta_2 &= 0 \\ H_1 : \beta_2 &\neq 0 \end{aligned} \quad (4.6)$$

El contraste es análogo al caso anterior:

$$t_c = \frac{\hat{\beta}_2 - \beta_2}{\sqrt{\hat{V}(\hat{\beta}_2)}} = \frac{\hat{\beta}_2}{\sqrt{\hat{V}(\hat{\beta}_2)}} \quad (4.7)$$

4.1.3 Cambio Estructural en el Intercepto y la Pendiente

La especificación del modelo es en este tercer caso la siguiente:

$$\begin{aligned} Y^i &= \beta_0 + \beta_1 x_1^i + \varepsilon^i & \forall i = 1, 2, \dots, j-1 \\ Y^i &= \beta_0 + (\beta_1 + \beta_2 D^j) x_1^i + \beta_3 D^j + \varepsilon^i & \forall i = j, j+1, \dots, n \end{aligned} \quad (4.8)$$

La hipótesis está representada por :

$$H_0 : \beta_2 = \beta_3 = 0 \quad (4.9)$$

El contraste es el siguiente:

$$F_c = \frac{(R\hat{\beta} - q)^T \left[R(X^T X)^{-1} R^T \right]^{-1} (R\hat{\beta} - q) / p}{\varepsilon^T \varepsilon / (n - k)} \sim F_{[p; n-k]} \quad (4.10)$$

donde p es el número de restricciones que estamos imponiendo en la hipótesis nula. En nuestro caso se tendría que buscar el valor tabulado de $F_{[2;n-4]}$.

Si F_c es menor al valor tabulado de $F_{[p;n-k]}$, no rechazamos la hipótesis de que ambos parámetros son cero, no habiendo indicios de quiebre estructural en los parámetros de la pendiente y el intercepto.

4.2 Variables No Lineales

Un típico error de especificación ocurre cuando se utiliza un modelo lineal en variables explicativas cuando realmente no lo es.

Supongamos que uno tiene una variable de respuesta Y y varias variables predictoras X y desea hacer transformaciones en las variables de respuesta para mejorar la medida de ajuste del modelo. Lo primero que uno intenta es hacer un gráfico matricial y de éste extraer las relaciones de X con cada una de las variables predictoras.

Pero estas transformaciones se pueden ver afectadas por la colinealidad (dependencia lineal) existente entre las variables predictoras.

4.2.1 Transformaciones Generales

Consideremos por ahora solo modelos con una variable independiente. La idea es tratar de aumentar la medida de ajuste R^2 del modelo, sin incluir variables adicionales. Lo primero que hay que hacer es un gráfico para observar el tipo de tendencia.

La siguiente tabla muestra las transformaciones de las variables dependiente e independiente que se requieren para linealizar varios modelos:

Tabla 4.2
Transformación de Variables

Nombre del Modelo	Ecuación Original	Transformación	Modelo Linealizado
Exponencial	$Y = \alpha \exp(\beta X)$	$Z = \ln Y; X = X$	$Z = \ln \alpha + \beta X$
Logarítmico	$Y = \alpha + \beta \ln(X)$	$Y = Y; W = \ln X$	$Y = \alpha + \beta W$
Potencial	$Y = \alpha X^\beta$	$Z = \ln Y; W = \ln X$	$Z = \ln \alpha + \beta W$
Hiperbólico	$Y = \alpha + \frac{\beta}{X}$	$Y = Y; W = \frac{1}{X}$	$Y = \alpha + \beta W$
Doblemente Inverso	$Y = \frac{1}{\alpha + \beta X}$	$Z = \frac{1}{Y}; X = X$	$Z = \alpha + \beta X$

El primer y tercer modelo son válidos bajo la suposición de que los errores son multiplicativos y habría que cotejar haciendo análisis de residuales si el logaritmo de los errores tiene una media de cero y varianza constante. Si los errores no son multiplicativos entonces deberían aplicarse técnicas de regresión no lineal que son expuestas más adelante.

4.2.2 Transformación Box - Tidwell

En 1962, Box y Tidwell, propusieron un método para transformar las variables predictoras pero solo usando potencia de ellas. Más específicamente, ellos consideraron el modelo:

$$Y = \beta_0 + \sum_{i=1}^k \beta_i w_i + \varepsilon \quad (4.11)$$

donde $w_i = (x_i)^{\alpha_i}$ si $\alpha_i \neq 0$ y $w_i = \ln(x_i)$ si $\alpha_i = 0$. El método está basado en el desarrollo en series de Taylor del modelo anterior con respecto a $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_k)$.

Haciendo las derivaciones respectivas, el modelo (4.11) se reduce a:

$$Y \approx \beta_0 + \sum_{i=1}^k \beta_i x_i + \sum_{i=1}^k \gamma_i z_i + \varepsilon \quad (4.12)$$

donde $\gamma_i = (\alpha_i - 1)\beta_i$ y $z_i = x_i \ln(x_i) \quad \forall i = 1, 2, \dots, k$.

El procedimiento para la estimación de los $\hat{\alpha}_i$ se puede resumir como sigue:

- Hacer la regresión lineal múltiple considerando las variables predictoras originales x_i y denotar los estimados de los coeficientes por $\hat{\beta}_i$.
- Hacer una regresión lineal múltiple de Y respecto a las variables predictoras originales x_i mas las variables $z_i = x_i \ln(x_i)$ y denotar los estimados de los coeficientes de z_i por $\hat{\gamma}_i$.
- Estimar $\hat{\alpha}_i = \frac{\hat{\gamma}_i}{\hat{\beta}_i} + 1$.

El procedimiento se puede repetir varias veces usando en cada etapa las nuevas variables transformadas y la siguiente relación de recurrencia:

$$\hat{\alpha}_i^{n+1} = \left(\frac{\hat{\gamma}_i^n}{\hat{\beta}_i^n} + 1 \right) \hat{\alpha}_i^n \quad (4.13)$$

El proceso termina cuando $|\hat{\alpha}_i^{n+1} - \hat{\alpha}_i^n| < \delta$. Sin embargo, es común que con una iteración sea suficiente.

4.2.3 Transformación Box - Cox

En 1964, Box y Cox introdujeron una transformación de la variable de respuesta con el objetivo de satisfacer la suposición de normalidad del modelo de regresión. La transformación es de la forma Y^λ (transformación potencia), donde λ es estimada con los datos tomados. Más específicamente, la transformación está definida,

para todo x mayor que cero, por $x_i(\lambda) = \frac{(x_i)^\lambda - 1}{\lambda}$ si $\lambda \neq 0$ y $x_i(\lambda) = \ln(x_i)$ si

$\lambda = 0$. Por la regla de L'Hopital se puede demostrar que $\lim_{\lambda \rightarrow 0} \frac{(x_i)^\lambda - 1}{\lambda} = \ln(x_i)$. Notar

que si $\lambda = 1$ se obtiene el modelo lineal, y si $\lambda = 0$ se obtiene un modelo logarítmico. Luego, el modelo Box-Cox es una especificación no lineal generalizada.

El parámetro λ se estima usando el método de Máxima verosimilitud, conjuntamente con los coeficientes del modelo de regresión lineal múltiple:

$$Y(\lambda) = \beta_0 + \sum_{i=1}^k \beta_i x_i(\lambda) + \varepsilon = \beta^T X(\lambda) + \varepsilon \quad (4.14)$$

Escribiendo la función de verosimilitud se tiene que:

$$L(Y; \beta, \sigma^2) = \left(\frac{1}{\sigma \sqrt{2\pi}} \right)^n \exp \left(-\frac{1}{2\sigma^2} (\varepsilon^T \varepsilon) \right) \quad (4.15)$$

Luego se puede establecer que el logaritmo de la función de verosimilitud está dado por:

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} (\varepsilon^T \varepsilon) \quad (4.16)$$

Debe recordarse que si una variable z distribuye $f(z)$, y existe otra variable u tal que $u = \phi(z)$ (ó $z = \psi(u)$), se tiene que u distribuye de la forma $f(z) \cdot \left| \frac{\partial z}{\partial u} \right| = f(\psi(u)) \cdot \psi'(u)$. Dado que $\varepsilon = Y(\lambda) - \beta^T X(\lambda) = \varepsilon(Y)$ se obtiene que $\frac{\partial \varepsilon_i}{\partial y_i} = \frac{\partial (y_i(\lambda))}{\partial y_i} = y_i^{\lambda-1}$ y por lo tanto $\ln \left(\frac{\partial \varepsilon_i}{\partial y_i} \right) = (\lambda-1) y_i$. Finalmente, el logaritmo de la

función de verosimilitud en este caso es el siguiente:

$$\begin{aligned} \ln L = & -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(2\sigma^2) + (\lambda-1) \sum_{i=1}^n \ln y_i \\ & - \frac{1}{2\sigma^2} \left((Y(\lambda) - \beta^T X(\lambda))^T (Y(\lambda) - \beta^T X(\lambda)) \right) \end{aligned} \quad (4.17)$$

El término $(\lambda-1) \sum_{i=1}^n \ln y_i$ aparece debido justamente al cambio de variables al moverse de la función de distribución de ε a la función de distribución de Y . Una comparación de (4.17) entre los valores de $\lambda=1$ y $\lambda=0$ nos permite elegir entre un modelo lineal y uno logarítmico.

Sin embargo, si se desea aplicar técnicas de MCO en lugar de MV, es factible **normalizar las observaciones por su media geométrica**:

$$\ln y_g = \frac{\sum_{i=1}^n \ln y_i}{n} \rightarrow y_g = \exp\left(\frac{\sum_{i=1}^n \ln y_i}{n}\right) \quad (4.18)$$

Las variables normalizadas son ahora $y_i^* = \frac{y_i}{y_g}$. Luego, podemos calcular el ajuste de los siguientes modelos lineal y log-lineal en forma directa (suponiendo que las perturbaciones son normal):

$$Y^* = \tilde{\beta} X^* + \tilde{\varepsilon} \quad (4.19)$$

$$\ln Y^* = \beta \ln X^* + \varepsilon \quad (4.20)$$

Notar que en (4.19) tanto la endógena como las exógenas han sido normalizadas por su media geométrica.

La comparación directa (MV vs MCO) es posible debido a que:

$$\ln y_i^* = \ln y_i - \ln y_g \quad (4.21)$$

$$\sum_{i=1}^n \ln y_g = \sum_{i=1}^n \left(\frac{\sum_{i=1}^n \ln y_i}{n} \right) = n \left(\frac{\sum_{i=1}^n \ln y_i}{n} \right) \quad (4.22)$$

$$\sum_{i=1}^n \ln y_i^* = \sum_{i=1}^n \ln y_i - \sum_{i=1}^n \ln e^{\sum_{i=1}^n \ln y_i / n} = 0 \quad (4.23)$$

De este modo, el término $(\lambda - 1) \sum_{i=1}^n \ln y_i^*$ de la expresión (4.17) es igual a cero para la versión log-lineal del modelo, pero también es cero para la versión lineal, ya que $\lambda = 1$. En consecuencia, la estimación MV y MCO produjeron los mismos resultados cuando los datos son normalizados. En el caso de MCO, se escogerá el λ que entregue un mayor valor de R^2 .

4.3 Modelos No Lineales

Lo que caracteriza a un modelo de regresión no lineal es el método utilizado para estimar sus parámetros. La forma general del modelo de regresión es:

$$Y = f(\beta; X) + \varepsilon \quad (4.24)$$

Considerando el mismo argumento que MCO se obtiene:

$$\min_{\{\beta\}} Q = \frac{1}{2} \sum_{i=1}^n \underbrace{(Y_i - f(\beta; X_i))^2}_{\varepsilon_i^2} \quad (4.25)$$

$$\frac{\partial Q}{\partial \beta} = \sum_{i=1}^n (Y_i - f(\beta; X_i)) \frac{\partial f(\beta; X_i)}{\partial \beta} = 0 \quad (4.26)$$

$$\frac{\partial^2 Q}{\partial \beta \partial \beta^T} = 2 \left[\frac{\partial f(\beta; X_i)}{\partial \beta} \frac{\partial f(\beta; X_i)}{\partial \beta^T} - \sum_{i=1}^n (Y_i - f(\beta; X_i)) \frac{\partial^2 f(\beta; X_i)}{\partial \beta \partial \beta^T} \right] \quad (4.27)$$

La matriz (4.27) debe ser positiva definida. Por otra parte, la distribución asintótica del estimador de mínimos cuadrados no lineal viene dada por:

$$\sqrt{n}(\hat{\beta}_{NL} - \beta) \xrightarrow{d} N(0; \sigma^2 \Omega^{-1}) \quad (4.28)$$

donde:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - f(\hat{\beta}; X_i))^2 \xrightarrow{p} \sigma^2 \quad (4.29)$$

$$\hat{\Omega} \approx \left(\frac{X^T X}{n} \right) = \frac{1}{n} \sum_{i=1}^n \frac{\partial f(\hat{\beta}; X_i)}{\partial \beta} \frac{\partial f(\hat{\beta}; X_i)}{\partial \beta^T} \quad (4.30)$$

4.3.1 Modelo de Regresión Linealizado en Parámetros

Los resultados en este caso se basan en aproximaciones de series de Taylor en torno a un determinado vector de parámetros β^0 :

$$f(\beta; X) \approx f(\beta^0; X) + \sum_{k=1}^K \frac{\partial f(\beta^0; X)}{\partial \beta_k^0} (\beta_k - \beta_k^0) \quad (4.31)$$

Haciendo $\frac{\partial f(\beta^0; X)}{\partial \beta_k^0} = Z_k$ y reagrupando términos se obtiene:

$$f(\beta; X) \approx f(\beta^0; X) - \sum_{k=1}^K Z_k \beta_k^0 + \sum_{k=1}^K Z_k \beta_k \quad (4.32)$$

Reemplazando luego en (4.24):

$$Y \approx f(\beta^0; X) - \sum_{k=1}^K Z_k \beta_k^0 + \sum_{k=1}^K Z_k \beta_k + \varepsilon \quad (4.33)$$

$$\underbrace{Y - f(\beta^0; X) + \sum_{k=1}^K Z_k \beta_k^0}_{\tilde{Y}} \approx \sum_{k=1}^K Z_k \beta_k + \varepsilon \quad (4.34)$$

$$\tilde{Y} \approx \sum_{k=1}^K Z_k \beta_k + \varepsilon \quad (4.35)$$

Por lo tanto, para un determinado valor de β^0 se estiman $\tilde{Y}$ y Z_k , para luego determinar los parámetros $\hat{\beta}_k$ de (4.35) utilizando MCO. Estos parámetros $\hat{\beta}_k$ deben ser utilizados como nuevo valor de β^0 , y repetir el proceso hasta que converja $|\hat{\beta}_k - \beta^0| < \delta$.

Sin embargo, si bien es posible aplicar los contrastes de hipótesis y procedimientos de inferencia de los MCO, no está garantizado que el R^2 esté entre 0 y 1.

4.3.2 Modelo de Regresión Linealizado en Variables

Un caso más general se obtiene si se consideran una mayor cantidad de términos en la expansión en series de Taylor en torno a X :

$$f(\beta; X) \approx f(\beta; X^0) + \sum_{i=1}^K \frac{\partial f(\beta; X^0)}{\partial x_i} (x_i - x_i^0) + \frac{1}{2} \sum_{i=1}^K \sum_{j=1}^K \frac{\partial^2 f(\beta; X^0)}{\partial x_i \partial x_j} (x_i - x_i^0)(x_j - x_j^0) + \dots \quad (4.36)$$

En el caso de que exista sólo una variable explicativa, se obtendría:

$$f(\beta; x) \approx f(\beta; x^0) + \frac{\partial f(\beta; x^0)}{\partial x} (x - x^0) + \frac{1}{2} \frac{\partial^2 f(\beta; x^0)}{\partial x^2} (x - x^0)^2 + \frac{1}{3!} \frac{\partial^3 f(\beta; x^0)}{\partial x^3} (x - x^0)^3 + \dots \quad (4.37)$$

y reagrupando términos:

$$f(\beta; x) \approx \gamma_0 + \gamma_1 x + \gamma_2 x^2 + \gamma_3 x^3 + \dots \quad (4.38)$$

Luego, se debe calibrar el siguiente modelo lineal:

$$Y \approx \gamma_0 + \gamma_1 x + \gamma_2 x^2 + \gamma_3 x^3 + \dots + \varepsilon \quad (4.39)$$

La elección del número de parámetros se puede obtener a partir de la significancia estadística de sus respectivos parámetros. Sin embargo, estos parámetros $\hat{\gamma}_i$ no tienen una interpretación económica clara.

4.4 Especificación de Variables

Existen numerosos errores que pueden cometerse producto de una mala especificación de la ecuación estimada, ya sea por omisión de variables relevantes o por inclusión de variables irrelevantes o superfluas.

4.4.1 Selección de Variables

Como se vio anteriormente, el valor del R^2 **nunca decrecerá** si se añaden nuevas variables a la ecuación de regresión, aun cuando dichas variables no aporten a la explicación del fenómeno estudiado. Para evitar ello, se considera el R^2 ajustado:

$$\bar{R}_j^2 = 1 - (1 - R_j^2) \frac{(n-1)}{(n-k)} \quad (4.40)$$

Dado que el $\bar{R}^2$ incorpora penalización por los grados de libertad, y a la vez revela un incremento en el ajuste, una alternativa es elegir la especificación que maximiza el valor del $\bar{R}^2$. Puede demostrarse que esto último equivale a minimizar el estimador de varianza $\hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{(n-k)}$.

Sin embargo, se ha sugerido que el $\bar{R}^2$ no penaliza suficientemente la pérdida de grados de libertad. Tres alternativas que se han propuesto para la **comparación de modelos** son las siguientes:

$$\bar{R}_j^2 = \frac{(n+k_j)}{(n-k_j)} (1 - R_j^2) \quad (4.41)$$

$$AIC_j = \ln \left(\frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n} \right) + 2 \left(\frac{k_j}{n} \right) \quad (4.42)$$

$$SIC_j = \ln \left(\frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n} \right) + \left(\frac{k_j \ln(n)}{n} \right) \quad (4.43)$$

En el caso de la expresión (4.41), obtenido de Amemiya (1985), el criterio consiste escoger el modelo con las variables que presenten el mayor $\bar{R}_j^2$.

Análogamente, en el caso de la expresión (4.42), el criterio es escoger el modelo que presente el mínimo valor de AIC_j . Lo mismo con SIC_j en (4.43).

Es interesante notar que las expresiones para AIC_j y SIC_j provienen de ponderar el error cuadrático medio $\left(\frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n}\right)$ del modelo calibrado. De hecho, el valor del $\bar{R}^2$ se puede describir como:

$$\bar{R}_j^2 = 1 - (1 - R_j^2) \frac{(n-1)}{(n-k)} = 1 - \frac{\frac{1}{(n-k_j)} \sum_i (\varepsilon_i)^2}{\frac{1}{(n-1)} \sum_i (Y_i - \bar{Y})^2} \quad (4.44)$$

Luego, en este caso el error cuadrático medio se corrige por los grados de libertad: $\left(\frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n-k}\right)$. Sin embargo, en los otros 2 criterios, el error cuadrático medio se corrige de la siguiente manera:

$$AIC_j = \underbrace{e^{(2k_j/n)}}_{\text{penalización}} \cdot \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n} \quad (4.45)$$

$$SIC_j = \underbrace{n^{(k_j/n)}}_{\text{penalización}} \cdot \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n} \quad (4.46)$$

Al aplicar logaritmo natural a las expresiones (4.45) y (4.46) se obtienen directamente las expresiones (4.42) y (4.43), respectivamente.

4.4.2 Variables Omitidas

Supongamos que el modelo especificado correctamente es el siguiente:

$$Y = X_1 \beta_1 + X_2 \beta_2 + \varepsilon \quad (4.47)$$

Si realizamos una regresión de Y sobre X_1 , sin incluir X_2 , el estimador es:

$$\hat{\beta}_1 = (X_1^T X_1)^{-1} X_1^T Y = (X_1^T X_1)^{-1} X_1^T \underbrace{(X_1 \beta_1 + X_2 \beta_2 + \varepsilon)}_Y \quad (4.48)$$

$$\hat{\beta}_1 = \beta_1 + (X_1^T X_1)^{-1} X_1^T X_2 \beta_2 + (X_1^T X_1)^{-1} X_1^T \varepsilon \quad (4.49)$$

$$E(\hat{\beta}_1) = \beta_1 + (X_1^T X_1)^{-1} X_1^T X_2 \beta_2 \neq \beta_1 \quad (4.50)$$

Si existe una única variable incluida y una única variable omitida, el signo del sesgo en el estimador es evidente. Sin embargo, si existen varias variables, no es posible.

La varianza de $\hat{\beta}_1$ es:

$$V(\hat{\beta}_1) = \sigma^2 (X_1^T X_1)^{-1} \quad (4.51)$$

Sin embargo, si hubiéramos especificado correctamente el modelo, incluyendo las variables X_2 se tendría:

$$V(\hat{\beta}_{1,2}) = \sigma^2 \left(X_1^T X_1 - X_1^T X_2 (X_2^T X_2)^{-1} X_2^T X_1 \right)^{-1} \quad (4.52)$$


Luego, a partir de (4.51) y (4.52), se deduce:

$$\left[V(\hat{\beta}_1)^{-1} - V(\hat{\beta}_{1,2})^{-1} \right] = \frac{1}{\sigma^2} X_1^T X_2 (X_2^T X_2)^{-1} X_2^T X_1 \quad (4.53)$$

La expresión (4.53) es siempre positiva. En consecuencia, si bien $\hat{\beta}_1$ es sesgado, tiene menor varianza que $\hat{\beta}_{1,2}$. Es interesante también notar que mientras mayor sea la correlación entre X_1 y X_2 , más grande será la varianza de $\hat{\beta}_{1,2}$ respecto a la de $\hat{\beta}_1$. Esto último equivale a resolver el problema con una restricción del tipo $\beta_2 = 0$.

Este sesgo no desaparecerá si aumenta el tamaño muestral, por lo que el estimador es también inconsistente (excepto si $X_1^T X_2 = 0$). Al mismo tiempo, una varianza muy alta en la variable X_2 reducirá el sesgo, aunque no lo eliminará. Notar que el intercepto también será sesgado, excepto que la variable omitida tenga media cero.

Por otra parte, se puede demostrar también que el estimador $\hat{\sigma}^2$ está sesgado hacia arriba (aún cuando X_1 y X_2 sean ortogonales); sin embargo, para estimar ese sesgo debiéramos estimar $\hat{\beta}_2$. Esto último implica que existirán problemas al contrastar hipótesis sobre $\hat{\beta}_1$.

Figura 4.1**Diagrama de Venn Para Una Analizar Omisión de Variables Relevantes**

Al regresionar Y sólo sobre X , la proporción de la variación de Y no explicada es mayor que al regresionar Y sobre X y Z , es decir, el σ^2 es mayor. Sin embargo, al regresionar Y sólo sobre X , la información usada para obtener β_x es mayor que al regresionar sobre las dos variables, ya que el área roja se usa tanto para estimar β_x como β_z . Esto último implica que omitir Z aumenta la información para estimar β_x , aumentando por lo tanto la significancia de β_x ; lo contrario ocurre si se incluye Z .

4.4.3 Variables Superfluas

Supongamos que el modelo especificado correctamente es el siguiente:

$$Y = X_1\beta_1 + \varepsilon \quad (4.54)$$

Sin embargo, la estimación se realiza a partir del siguiente modelo:


$$Y = X_1\beta_1 + X_2\beta_2 + \varepsilon \quad (4.55)$$

En este caso, se puede demostrar que tanto $\hat{\beta}_1$ como $\hat{\sigma}^2$ son insesgados. Sin embargo, la varianza del estimador $\hat{\beta}_1$ será mayor. Esto se explica por la pérdida de grados de libertad producto de la presencia de más parámetros en la estimación. Luego, los estimadores si bien son insesgados y consistentes, son ineficientes. Esta pérdida de

eficiencia hace más difícil rechazar la hipótesis nula de que un determinado parámetro vale cero.

Figura 4.2

Diagrama de Venn Para Una Analizar Inclusión de Variables Irrelevantes



Al agregar Z , la información usada para obtener β_x claramente se reduce (ineficiencia), y el σ^2 no se reduce de manera importante.

4.5 Contraste de Subespecificación de Modelos (Test J)

Este test nos permite comparar dos especificaciones alternativas de modelos, a partir de un único modelo artificial anidado. Suponga que usted está haciendo competir dos especificaciones diferentes para un fenómeno, las que pueden ser representadas de la siguiente forma:

$$\begin{aligned} H_0 : Y &= X\beta + \varepsilon \\ H_1 : Y &= Z\gamma + \eta \end{aligned} \tag{4.56}$$

El modelo anidado artificial es el siguiente:

$$Y = (1 - \lambda) \cdot X\beta + \lambda \cdot Z\gamma + v \tag{4.57}$$

Bajo la hipótesis nula de que H_0 es la correcta especificación, se tendrá entonces que $\lambda = 0$. La regresión (4.57) permite obtener estimadores para $(1 - \lambda)\beta$ y $\lambda\gamma$, pero no para λ (problema de identificabilidad de parámetros). Notar que X y Z no deben tener variables en común.

El procedimiento es el siguiente:

- i. Regresionar Y sobre Z y obtener $\hat{\gamma}$, y calcular $\hat{Y}_1 = Z\hat{\gamma}$
- ii. Regresionar Y sobre X y sobre $\hat{Y}_1$, $Y = X\delta + \lambda\hat{Y}_1 + \xi$, y obtener la significancia estadística de $\hat{\lambda}$.

Luego, si el test t de $\hat{\lambda}$ es chico, entonces no se rechaza H_0 , y si es grande, se rechaza H_0 a favor de H_1 .

5 TEMAS ESPECÍFICOS

5.1 Ortogonalidad

La Ortogonalidad entre los regresores de un modelo econométrico implica incorrelación entre dichos regresores, mientras que la Multicolinealidad implica dependencia o correlación entre esas variables.

Se dice que dos regresores son ortogonales cuando están linealmente incorrelacionados, es decir, su coeficiente de correlación lineal o su covarianza es cero. Así, x_i y x_j son ortogonales si $r_{ij} = 0$.

Dos grupos de regresores son ortogonales si $(X_1^T X_2) = 0$, lo que significa que cada regresor del primer bloque está incorrelacionado con cada regresor del segundo bloque.

Sea el modelo particionado:

$$Y = X_1\beta_1 + X_2\beta_2 + \varepsilon \quad (5.1)$$

Los estimadores MCO de los vectores de parámetros β_1 y β_2 de este modelo coinciden con los que obtendríamos efectuando la regresión individual de Y sobre cada uno de los bloques:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} X_1^T X_1 & X_1^T X_2 \\ X_2^T X_1 & X_2^T X_2 \end{pmatrix}^{-1} \begin{pmatrix} X_1^T Y \\ X_2^T Y \end{pmatrix} \quad (5.2)$$

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} X_1^T X_1 & 0 \\ 0 & X_2^T X_2 \end{pmatrix}^{-1} \begin{pmatrix} X_1^T Y \\ X_2^T Y \end{pmatrix} = \begin{pmatrix} (X_1^T X_1)^{-1} X_1^T Y \\ (X_2^T X_2)^{-1} X_2^T Y \end{pmatrix} \quad (5.3)$$

Las varianzas de los estimadores también coinciden con las calculadas al hacer las regresiones individuales pero no así con los estimadores de las varianzas:

$$V(\hat{\beta}) = \sigma^2 \begin{pmatrix} X_1^T X_1 & 0 \\ 0 & X_2^T X_2 \end{pmatrix}^{-1} = \begin{pmatrix} \sigma^2 (X_1^T X_1)^{-1} \\ \sigma^2 (X_2^T X_2)^{-1} \end{pmatrix} \quad (5.4)$$

$$\hat{V}(\hat{\beta}) = \hat{\sigma}^2 \begin{pmatrix} X_1^T X_1 & 0 \\ 0 & X_2^T X_2 \end{pmatrix}^{-1} = \begin{pmatrix} \hat{\sigma}^2 (X_1^T X_1)^{-1} \\ \hat{\sigma}^2 (X_2^T X_2)^{-1} \end{pmatrix} \quad (5.5)$$

siendo $\hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n-k}$.

Sin embargo, en las regresiones individuales se tendría:

$$\hat{V}(\hat{\beta}_1) = \hat{\sigma}_1^2 (X_1^T X_1)^{-1} \rightarrow \hat{\sigma}_1^2 = \frac{\hat{u}^T \hat{u}}{n-k_1} \quad (5.6)$$

$$\hat{V}(\hat{\beta}_2) = \hat{\sigma}_2^2 (X_2^T X_2)^{-1} \rightarrow \hat{\sigma}_2^2 = \frac{\hat{v}^T \hat{v}}{n-k_2} \quad (5.7)$$

Por otra parte, si no existe ortogonalidad, se tendría que:

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} (X_1^T X_1)^{-1} X_1^T Y - (X_1^T X_1)^{-1} X_1^T X_2 \hat{\beta}_2 \\ (X_2^T X_2)^{-1} X_2^T Y - (X_2^T X_2)^{-1} X_2^T X_1 \hat{\beta}_1 \end{pmatrix} \quad (5.8)$$

La solución (5.8) indica que $\hat{\beta}_1$ es el conjunto de coeficientes o parámetros de la regresión de Y sobre X_1 menos un **vector de corrección**. De hecho, manipulando (5.8) resulta:

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} (X_1^T X_1)^{-1} X_1^T (Y - X_2 \hat{\beta}_2) \\ (X_2^T X_2)^{-1} X_2^T (Y - X_1 \hat{\beta}_1) \end{pmatrix} \quad (5.9)$$

El teorema de Frisch-Waugh establece que el vector $\hat{\beta}_2$ es el conjunto de parámetros que se obtiene de realizar una regresión de los residuos de la regresión de Y sobre X_1 , sobre el conjunto de residuos obtenidos de la regresión de X_2 sobre X_1 . Esto es lo que normalmente se conoce como extraer el efecto de X_1 .

Suponiendo una regresión de Y sobre $W = (X_1, X_2)$, el coeficiente $\hat{\beta}_2$ de X_2 se calcula como:

$$\hat{\beta}_2 = (X_2^T M X_2)^{-1} (X_2^T M Y) \quad (5.10)$$

donde $M = (I - X_1 (X_1^T X_1)^{-1} X_1^T)$ es una matriz de $n \times n$ simétrica ($M = M^T$) e idempotente ($M = M^T M$).

Esta matriz M genera el vector de residuos de la regresión de mínimos cuadrados de Y sobre X_1 cuando pre-multiplica al vector Y , por lo que:

$$\hat{\varepsilon} = MY \rightarrow MX_1 = 0 \quad (5.11)$$

Una manera de interpretar el resultado $MX_1 = 0$ es que la realización de una regresión de X_1 en X_1 se obtendrá un ajuste perfecto, por lo que los residuos serán cero.

Finalmente, dado que en general $Y = X\beta + \varepsilon$, se obtiene:

$$\hat{Y} = Y - \hat{\varepsilon} = (I - M)Y = PY \quad (5.12)$$

La matriz P , simétrica e idempotente, se denomina **matriz de proyección**. Esta matriz se genera a partir de X tal que cuando el vector Y se pre-multiplica por P , se obtiene como resultados los valores calculados de la regresión por MCO de Y sobre X .

5.2 Multicolinealidad

5.2.1 Definición de Multicolinealidad

El término multicolinealidad (o colinealidad) en Econometría se refiere a una situación en la que dos o más variables explicativas están fuertemente interrelacionadas y, por tanto, **resulta difícil cuantificar sus efectos individuales sobre la variable explicada**.

Este problema reside, por tanto, en la muestra utilizada y/o de la especificación del modelo, y no tiene causas interpretables. Sí existen, en cambio, una serie de situaciones en que la multicolinealidad resulta habitual.

En principio, cabe distinguir dos casos:

- a) Multicolinealidad Perfecta**, que se presenta cuando $\det(X^T X) = 0$. En este caso existen infinitas soluciones para el sistema $(X^T X)\hat{\beta} = X^T Y$. Este caso se presenta usualmente cuando el modelador construye artificialmente ciertas variables explicativas, como por ejemplo variables dummy.
- b) Multicolinealidad Fuerte**, cuando la relación entre las variables es muy fuerte pero no perfecta; es decir, los coeficientes de correlación lineal no serán próximos a 1 pero se le aproximarán bastante. En este caso $\det(X^T X) \neq 0$ y por lo tanto no existen razones a priori para no poder estimar el modelo. Esto ocurre frecuentemente en datos económicos de series de tiempo.

5.2.2 Causas de la Multicolinealidad

- Existencia de alguna relación causal entre 2 variables explicativas (o más). Es decir, una tercera variable exógena se relaciona muy fuertemente con las otras 2.
- En economía, la mayoría de las variables explicativas están, de alguna manera, correlacionadas. Cuando trabajamos con series temporales, la mayoría de las variables económicas tienen una tendencia creciente; Granger y Newbold demostraron que basta con introducir una tendencia lineal en dos series temporales independientes para que su correlación aumente considerablemente, y por lo tanto, la existencia de esa tendencia puede ser la causa de un problema de multicolinealidad.
- Existencia de una variable explicativa con escasa variabilidad en su serie, por lo que su presencia puede confundirse con la del intercepto.

5.2.3 Efectos de la Multicolinealidad

En el caso de multicolinealidad extrema o perfecta, resulta claro que el problema fundamental es que es imposible resolver de forma única el sistema de ecuaciones normales: $(X^T X)\hat{\beta} = X^T Y$.

La multicolinealidad de grado o fuerte da lugar a distintos efectos, que veremos en más detalle a continuación. Sin embargo, es importante mencionar que no produce sesgo en la estimación, y que el R^2 tampoco se ve afectado. Es decir, la multicolinealidad induce problemas en la inferencia de los modelos (interpretación de los parámetros) pero no en la predicción.

Algunos efectos son los siguientes:

- Las estimaciones individuales de los parámetros están mal identificadas, esto es, el valor estimado de un parámetro puede depender crucialmente del(los) valor(es) estimado(s) de otro(s). Esto significa que, dependiendo de la muestra, puede no ser correcto al análisis del impacto que cada variable correlacionada genera sobre la variable explicada. Es decir, se pueden confundir los efectos marginales.
- Se genera una inflación artificial de la varianza de los parámetros estimados. Luego, efectuar inferencia puede ser riesgoso y conducir a conclusiones incorrectas. Este fenómeno se explica claramente si analizamos el siguiente ejemplo simple:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \varepsilon_t \quad (5.13)$$

La estimación por MCO del modelo (5.13) nos proporciona los siguientes resultados:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2, \quad \hat{\beta}_1 = \frac{\hat{\sigma}_{33}\hat{\sigma}_{12} - \hat{\sigma}_{23}\hat{\sigma}_{13}}{\hat{\sigma}_{22}\hat{\sigma}_{33} - \hat{\sigma}_{23}^2}, \quad \hat{\beta}_2 = \frac{\hat{\sigma}_{22}\hat{\sigma}_{13} - \hat{\sigma}_{23}\hat{\sigma}_{12}}{\hat{\sigma}_{22}\hat{\sigma}_{33} - \hat{\sigma}_{23}^2} \quad (5.14)$$

donde:

$$\sigma_{ij} = \frac{1}{N} \left(\sum_{t=1}^N (z_{it} - \bar{z}_i)(z_{jt} - \bar{z}_j) \right); \quad i, j = 1, 2, 3, \dots \quad (5.15)$$

$$z_{1t} = y_t; \quad z_{2t} = x_{1t}; \quad z_{3t} = x_{2t}$$

Las varianzas de los estimadores son:

$$\begin{aligned} \text{var}(\hat{\beta}_1) &= \frac{N \cdot \hat{\sigma}^2}{(1 - \hat{\rho}^2) \hat{\sigma}_{22}}; \quad \text{var}(\hat{\beta}_2) = \frac{N \cdot \hat{\sigma}^2}{(1 - \hat{\rho}^2) \hat{\sigma}_{33}} \\ \hat{\sigma}^2 &= \frac{\sum_{t=1}^T \hat{\varepsilon}_t^2}{T-3}; \quad \hat{\rho}^2 = \frac{\hat{\sigma}_{23}^2}{\hat{\sigma}_{22} \hat{\sigma}_{33}} \end{aligned} \quad (5.16)$$

Los test- t para ambos estimadores los escribimos como:

$$t_1 = \frac{\hat{\beta}_1}{\hat{\sigma} \sqrt{N}} \sqrt{(1 - \hat{\rho}^2) \hat{\sigma}_{22}}; \quad t_2 = \frac{\hat{\beta}_2}{\hat{\sigma} \sqrt{N}} \sqrt{(1 - \hat{\rho}^2) \hat{\sigma}_{33}} \quad (5.17)$$

Analizando (5.17), se desprende que cuando la colinealidad es perfecta ($\hat{\rho}^2 = 1$) las varianzas tienden a infinito. Además, se aprecia que los test t son función decreciente del $\hat{\rho}^2$.

Por otra parte, cuando hay colinealidad fuerte ($\hat{\rho}^2 \approx 1$) se produce que $\hat{\sigma}_{23}^2 \approx \hat{\sigma}_{22} \hat{\sigma}_{33}$. Luego, los denominadores de (5.14) toman valores cercanos a cero, generando estimaciones poco confiables en magnitud e incluso en signo:

$$\hat{\beta}_1 = \frac{\hat{\sigma}_{33} \hat{\sigma}_{12} - \hat{\sigma}_{23} \hat{\sigma}_{13}}{\hat{\sigma}_{22} \hat{\sigma}_{33} - \hat{\sigma}_{23}^2} = \frac{\hat{\sigma}_{33} \hat{\sigma}_{12} - \hat{\rho} \hat{\sigma}_{13} \sqrt{\hat{\sigma}_{22} \hat{\sigma}_{33}}}{\hat{\sigma}_{22} \hat{\sigma}_{33} (1 - \hat{\rho}^2)} \quad (5.18)$$


$$\hat{\beta}_2 = \frac{\hat{\sigma}_{22} \hat{\sigma}_{13} - \hat{\sigma}_{23} \hat{\sigma}_{12}}{\hat{\sigma}_{22} \hat{\sigma}_{33} - \hat{\sigma}_{23}^2} = \frac{\hat{\sigma}_{22} \hat{\sigma}_{13} - \hat{\rho} \hat{\sigma}_{12} \sqrt{\hat{\sigma}_{22} \hat{\sigma}_{33}}}{\hat{\sigma}_{22} \hat{\sigma}_{33} (1 - \hat{\rho}^2)} \quad (5.19)$$

Por simplicidad supongamos que todas las variables tienen varianza unitaria, es decir, supongamos que $\hat{\sigma}_{11}^2 = \hat{\sigma}_{22}^2 = \hat{\sigma}_{33}^2 = 1$. En este caso tendríamos:

$$\hat{\beta}_1 = \frac{\hat{\sigma}_{12} - \hat{\rho} \hat{\sigma}_{13}}{(1 - \hat{\rho}^2)} \quad \hat{\beta}_2 = \frac{\hat{\sigma}_{13} - \hat{\rho} \hat{\sigma}_{12}}{(1 - \hat{\rho}^2)} \quad (5.20)$$

En consecuencia, si $\hat{\rho}^2 \approx 1$ se cumpliría que $\hat{\beta}_1 \approx -\hat{\beta}_2$.

- Las estimaciones resultan sensibles con respecto a la muestra utilizada lo que supone que si, por ejemplo, se amplía la muestra con una nueva observación, las estimaciones obtenidas pueden variar sustancialmente.

Figura 5.1**Diagrama de Venn Para Dos Variables Fuertemente Colineales**

En la Figura 5.1 se observan dos variables fuertemente colineales. El área azul es utilizada para estimar ambos parámetros. Luego, dicha área no permite distinguir claramente entre ambos parámetros. El área verde es usada para estimar β_x y el área fucsia para estimar β_z .

i) Problemas de Identificación

No se puede aislar el efecto individual de un regresor sobre el regresando ya que no se puede mantener la cláusula del "ceteris paribus".

En Econometría tradicional, el término identificación alude a la posibilidad de obtener estimaciones independientes para los parámetros de un modelo.

Se dice que un modelo está mal identificado cuando el valor estimado de un(os) parámetro(s) depende crucialmente del(los) valor(es) de otro(s). En este sentido, puede decirse que la colinealidad da lugar a un problema de identificación paramétrica.

Para aclarar esta idea, utilizaremos un ejemplo correspondiente al caso de multicolinealidad extrema. Sea el modelo:

$$Y = X_1\beta_1 + X_2\beta_2 + \varepsilon \quad (5.21)$$

Supongamos que la segunda variable explicativa puede generarse a partir de una transformación lineal de la primera, esto es: $X_2 = \gamma_1 + \gamma_2 X_1$. Si sustituimos esta igualdad en la ecuación (2.9) se obtiene, tras realizar algunas operaciones algebraicas elementales, la siguiente expresión:

$$Y = \underbrace{\beta_2\gamma_1}_{\phi_0} + X_1 \underbrace{(\beta_1 + \beta_2\gamma_2)}_{\phi_1} + \varepsilon \quad (5.22)$$

En (5.22) queda clara la imposibilidad de obtener estimaciones independientes de β_1 y β_2 sin más que aplicar MCO.

Este problema también se produce en el caso de multicolinealidad de grado. Para verlo, basta suponer que la relación entre las variables explicativas fuera $X_2 = \gamma_1 + \gamma_2 X_1 + u$, entonces el modelo (5.22) podría expresarse como:

$$Y = \beta_2\gamma_1 + X_1(\beta_1 + \beta_2\gamma_2) + \beta_2u + \varepsilon \quad (5.23)$$

ii) Inflación de las Estimaciones

Si el determinante de $(X^T X)$ es aproximadamente igual a cero (columnas LD), tanto las estimaciones de parámetros, como las de sus correspondientes varianzas, tenderán a ser sensibles y, en general, serán mayores que las que se obtendrían si no existiera multicolinealidad. Por esta razón, se dice que la multicolinealidad causa un problema de "inflación de algunos parámetros estimados y de sus varianzas".

En general, esta inflación distorsionará los resultados de los procesos de inferencia estadística que se desarrollen a partir de los resultados de la estimación. Concretamente, puesto que las varianzas de los parámetros estimados están distorsionadas al alza, el estadístico t de significación individual de los parámetros:

$$t = \frac{\hat{\beta}_i}{\hat{\sigma}_{\beta_i}} \sim t_{(n-k)} \quad (5.24)$$


tenderá a no rechazar la hipótesis nula $\beta_i = 0$ más frecuentemente que si no existiese multicolinealidad. Es decir, **el estadístico t tendrá un menor valor** que el real.

Por otra parte, dado que la multicolinealidad no hace variar la bondad del ajuste, si contrastamos la significancia conjunta de los parámetros a través del R^2 del modelo, podemos *concluir* que los parámetros conjuntamente son significativos e individualmente no. Este hecho puede sugerir la existencia de multicolinealidad de grado.

En síntesis:

- Intervalos de confianza grandes
- Valores muestrales de los estadísticos t pequeños, lo que implica que es muy difícil no rechazar cualquier contraste de no significación de las variables
- Los 2 puntos anteriores nos pueden llevar a no rechazar la significación individual de todos los regresores y sin embargo rechazar la significación conjunta de todos ellos (test F).

Figura 5.2
Región de Confianza Para Variables Colineales



- No afecta al R^2 ya que éste mide el efecto conjunto de todos los regresores sobre el regresando y la multicolinealidad afecta a los valores individuales de los regresores. Por lo tanto, la regresión podrá ser significativa a pesar de la existencia de multicolinealidad.
- No afecta a las predicciones de la variable Y .

iii) Sensibilidad de las Estimaciones con Respecto a los Datos

Cuando existe un problema de multicolinealidad, ligeros cambios en la matriz X y el vector Y (por ejemplo, si añadimos o suprimimos algún dato) pueden llevar a grandes cambios en los coeficientes estimados.

Este hecho puede llevar erróneamente a considerar la posibilidad de cambio estructural, cuando en realidad se trata de un problema de multicolinealidad.

5.2.4 Detección de la Multicolinealidad y su Magnitud

Resulta frecuente que exista un problema de multicolinealidad en los siguientes casos:

- a) Cuando se emplean variables explicativas no estacionarias en media. Es decir, si dos variables explicativas tienen una tendencia común, esto puede causar multicolinealidad. Como veremos más adelante, transformar las variables para que sean estacionarias, puede resolver el problema, salvo cuando la multicolinealidad sea estricta. Esta causa es muy común en la práctica econométrica.
- b) Cuando se consideran muchas variables explicativas. Lógicamente, a medida que aumenta el número de variables explicativas, es más fácil que aparezca una pauta de relación entre ellas que de lugar a un problema de colinealidad.
- c) Cuando la métrica de las variables da lugar a datos de un orden de magnitud muy diferente. Puesto que el valor numérico del determinante de $(X^T X)$ depende de las unidades de medida de las variables contenidas en X , si dichas variables estén medidas en unidades de un orden de magnitud muy diferente (por ejemplo kilómetros y centímetros) esto puede dar lugar a una aparente multicolinealidad, debida a la acumulación de errores de redondeo. Este problema se resolvería transformando adecuadamente la métrica de los datos.
- d) Cuando se incluyen como variables explicativas retardos sucesivos de la variable endógena o de alguna de las variables explicativas. Esto puede provocar multicolinealidad porque los valores de una variable económica en distintos instantes de tiempo suelen estar correlacionados entre sí.

Para decidir si la colinealidad de grado o fuerte supone un problema para nuestro análisis concreto, en primer lugar tendremos que definir claramente cuáles son los objetivos últimos del mismo. Por ejemplo, si nuestra finalidad es predecir la evolución futura de una variable, la posible multicolinealidad no nos causa ningún problema. Sin embargo, si el énfasis está en obtener estimaciones de los parámetros lo más precisas posibles, la colinealidad sería un problema muy grave ya que, como hemos visto, da lugar a un alto grado de imprecisión en las estimaciones individuales.

Evidentemente, caracterizar el problema de colinealidad de grado como $\det(X^T X) = 0$ no es suficiente para la práctica econométrica ya que: 1) el valor de $\det(X^T X)$ depende de las unidades de medida y 2) no sabemos en qué grado de proximidad a cero comienzan a hacerse relevantes los problemas que acabamos de señalar.

Para detectar el posible problema de multicolinealidad estudiaremos dos tipos de métodos: métodos basados en la correlación entre variables explicativas y métodos basados en el tamaño de la matriz $(X^T X)$.

i) **Métodos Basados en la Correlación Entre Variables Explicativas.**

Para detectar la multicolinealidad se podría calcular la correlación simple existente entre pares de las variables exógenas (X) . Denotaremos como r_{ij} al coeficiente de correlación simple entre la variable x_i y x_j ($r_{ij} = r_{ji}, \forall i \neq j$). Al calcular estos coeficientes simples de correlación para todos los pares de variables, se tendría una matriz R_x definida como:

$$R_x = \begin{pmatrix} 1 & r_{12} & \dots & r_{1k} \\ r_{21} & 1 & \dots & r_{2k} \\ \dots & \dots & \dots & \dots \\ r_{k1} & r_{k2} & \dots & 1 \end{pmatrix} \quad (5.25)$$

Si r_{ij} es cercano a la unidad, detectaríamos multicolinealidad por la alta correlación muestral entre x_i y x_j . Para ver si la correlación es cercana a 1, podemos realizar el siguiente test:

$$\frac{(r_{ij}\sqrt{n-2}-1)}{\sqrt{1-r_{ij}^2}} \sim t_{n-2} \quad (5.26)$$

El problema de este método es que sólo puede detectar correlación entre pares de variables explicativas de la forma $x_i = \lambda x_j$. Sin embargo, es posible que existan relaciones de dependencia lineal más complejas como, por ejemplo $x_i = \lambda x_j + \alpha x_k$, que no detectaríamos calculando sólo los coeficientes de correlación muestral entre pares de variables. En este caso, lo que se puede hacer es un conjunto de regresiones de cada variable exógena con respecto a las $k - 1$ restantes.

ii) Métodos Basados en el Tamaño de la Matriz.

Como sabemos, la multicolinealidad es un problema numérico ya que el determinante de la matriz $(X^T X)$ es muy pequeño. Entonces, podemos pensar que sería útil medir el "tamaño" de $(X^T X)$.

Una primera solución sería calcular el valor numérico del determinante de $(X^T X)$. El problema es que el determinante de esta matriz depende de las unidades de medida de las variables explicativas. Otra posibilidad se basa en el hecho de que el determinante de $(X^T X)$ es igual al producto de sus valores propios. Entonces, podemos calcular los valores propios y comprobar si alguno es muy cercano a cero ya que, en este caso, el determinante también tendría un valor próximo a cero. El problema es que el tamaño de los valores propios también depende de las unidades de medida de las variables explicativas. El último método consiste en medir el tamaño relativo de los valores propios de la matriz $(X^T X)$. De este modo, eliminamos el problema de las unidades de medida. Es decir, calculamos los valores propios, los ordenamos de menor a mayor, y obtenemos el ratio entre el valor propio máximo y el mínimo. Si este cociente es muy grande, existiría un problema de multicolinealidad porque el valor propio mínimo es muy pequeño en relación con el más grande. A la raíz cuadrada de este cociente se le llama número de condición de la matriz X :

$$\text{Número de Condición} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} \quad (5.27)$$

5.2.5 Corrección de la Multicolinealidad

Existen diversas soluciones, aunque ninguna resulta plenamente satisfactoria.

- **No Hacer Nada.** Sólo tenerlo presente y ser cuidadoso.
- **Suprimir Variables.** La idea consiste en que, si se suprimen variables que estén altamente correlacionadas con otras, la pérdida de capacidad explicativa del modelo será pequeña, mientras que la multicolinealidad se reducirá. Existe, sin embargo, el riesgo de eliminar variables que debieran mantenerse en el modelo ya que, como hemos visto, en situaciones de multicolinealidad las varianzas de los parámetros están infladas y muchos parámetros serán formalmente no significativos.
- **Utilización de Estimaciones Externas.** Por ejemplo, sea una función de demanda donde el consumo de un país (C_t) depende, a lo largo del tiempo, de las variables renta (Y_t) y precios (P_t):

$$C_t = \beta_0 + \beta_1 Y_t + \beta_2 P_t + \varepsilon_t \quad (5.28)$$

y se sabe que las variables de renta y precios están altamente correlacionadas. En este caso, una posible solución al problema de multicolinealidad sería estimar el parámetro β_1 en una función de consumo con datos de sección cruzada definida como:

$$C_t = \beta_1 Y_t + v_t \quad (5.29)$$

De esta forma, se puede plantear el nuevo modelo de regresión con datos temporales:

$$(C_t - \hat{\beta}_1 Y_t) = \beta_0 + \beta_2 P_t + \varepsilon_t \quad (5.30)$$

en donde la variable a explicar ha cambiado con respecto al modelo original. Sin embargo, esta solución a la multicolinealidad tiene varios problemas:

- a) Para que la solución fuese correcta tendríamos que tener como nueva variable dependiente $(C_t - \hat{\beta}_1 Y_t)$, pero no disponemos del valor del verdadero parámetro β_1 sino sólo de una estimación $\hat{\beta}_1$.
- b) El parámetro β_1 en una regresión con datos de sección cruzada tiene una interpretación distinta que cuando se estima con datos de series temporales (Largo Plazo vs Corto Plazo).
- **Incorporar Nuevas Observaciones.** Algunas veces, aumentando el tamaño muestral con el que trabajamos podemos reducir el problema de multicolinealidad; esta podría ser una solución siempre que la multicolinealidad fuera un problema muestral. Por supuesto, si existe una relación lineal exacta entre algunas variables explicativas (multicolinealidad estricta) por mucho que aumentemos el número de observaciones, no va a desaparecer el problema.
- **Imponer Restricciones Sobre los Parámetros.** Evidentemente, si la Teoría Económica o la experiencia empírica sugieren algunas restricciones razonables sobre los parámetros del modelo más afectados por la colinealidad, imponerlas permitirá reducir el problema. El riesgo que se corre es, obviamente, imponer restricciones que no son ciertas.
- **Transformación de Variables.** Muchas veces el problema de multicolinealidad surge al trabajar con variables no estacionarias en media o con una tendencia creciente en el tiempo. En este caso, la transformación adecuada para hacer estacionarias las variables sería diferenciar.

5.2.6 Método de Componentes Principales

El Método de Componentes Principales (MCP) es una técnica estadística de síntesis de la información, o reducción de la dimensión (número de variables); ante un banco de datos con muchas variables, el objetivo será reducirlas a un menor número perdiendo la menor cantidad de información posible.

Es decir, el MCP transforma un conjunto de variables predictoras correlacionadas en un conjunto menor de variables no correlacionadas, a las que se les denomina componentes principales.

Los nuevos componentes principales o factores serán una combinación lineal de las variables originales, y además serán independientes entre sí. Un aspecto clave en MCP es la interpretación de los factores, ya que ésta no viene dada a priori, sino que será deducida tras observar la relación de los factores con las variables iniciales (habrá que estudiar tanto el signo como la magnitud de las correlaciones).

Esto no siempre es fácil, y será de gran importancia el conocimiento que se tenga sobre la materia de investigación. Para el análisis resulta fundamental el concepto de vectores y valores propios de una matriz.

Las fases del Análisis de Componentes Principales son las siguientes:

- **Análisis de la Matriz de Correlaciones:** Un análisis de componentes principales tiene sentido si existen altas correlaciones entre las variables, ya que esto es indicativo de que existe información redundante y, por tanto, pocos factores explicarían gran parte de la variabilidad total.
- **Selección de los Componentes:** La elección de los factores se realiza de tal forma que el primero recoja la mayor proporción posible de la variabilidad original; el segundo factor debe recoger la máxima variabilidad posible no recogida por el primero, y así sucesivamente. Del total de factores se elegirán aquellos que recojan el porcentaje de variabilidad que se considere suficiente. A éstos se les denominará componentes principales
- **Análisis de la Matriz de Componentes:** Una vez seleccionados los componentes principales, se representan en forma de matriz. La matriz tendrá tantas columnas como componentes principales y tantas filas como variables.
- **Interpretación de los Componentes:** Para que un componente sea fácilmente interpretable debe tener las siguientes características:

- o Los coeficientes de los componentes deben ser próximos a 1.
- o Una variable debe tener coeficientes elevados sólo con un factor.
- o No deben existir componentes con coeficientes similares.

Estimación de los Componentes: Son los valores que tienen los componentes principales para cada caso, que nos permitirán su representación gráfica. Supongamos que tenemos un vector p -dimensional $X = (x_1, x_2, \dots, x_p)$ que presenta una matriz de varianzas y covarianzas Σ . El método de basa en encontrar un nuevo vector q -dimensional $Z = (z_1, z_2, \dots, z_q)$ con $q < p$ que cumpla:

$$z_i = \sum_{j=1}^p (a_{ij} \cdot x_j) \quad \forall i = 1, \dots, q \quad (5.31)$$

$$Z = AX \quad (5.32)$$

Además debe cumplirse para $a_i^T = (a_{i1}, a_{i2}, \dots, a_{ip})$ que:

- o $\text{var}(z_i) = a_i^T \Sigma a_i$
- o $\text{cov}(z_i, z_k) = a_i^T \Sigma a_k$
- o $\text{var}(z_1) \geq \text{var}(z_2) \geq \dots \geq \text{var}(z_q)$

El objetivo del análisis de componentes principales es el de maximizar la suma de cuadrados $Z^T Z = A^T X^T X A = A^T \Sigma A$, la cual representa la variancia de Z , sujeta a que la suma de cuadrados de los coeficientes a sea igual a 1 (condición de identificabilidad).

Este proceso de maximización con restricción conduce a una solución de orden de la forma:

$$(X^T X) \cdot a_i = \lambda_i \cdot a_i \quad (5.33)$$

donde λ es el multiplicador de Lagrange, asociado con el problema de maximización, y a la vez es la raíz característica de la matriz $\Sigma = (X^T X)$.

La matriz Σ tiene asociados valores y vectores propios (λ_i, a_i) donde $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$. Luego, el i -ésimo componente principal está dado por:

$$z_i = \sum_{j=1}^p (a_{ij} \cdot x_j) = a_{i1}x_1 + a_{i2}x_2 + \dots + a_{ip}x_p \quad (5.34)$$

donde $\text{var}(z_i) = \lambda_i$ ($\forall i = 1, \dots, p$), $\text{cov}(z_i, z_k) = a_i^T \Sigma a_k = 0$ ($\forall i \neq k$).

Notar que los valores propios (λ_i) son únicos, no así los vectores propios (y por lo tanto los vectores z_i).

La traza de la matriz Σ se obtiene como la suma de los valores propios $\left(\text{tr}(\Sigma) = \sum_{i=1}^p \lambda_i \right)$. Por lo tanto, la proporción de la varianza explicada por

el k -ésimo componente principal es $\frac{\lambda_k}{\sum_{i=1}^p \lambda_i}$

Si la matriz X está centrada y escalada tal que Σ corresponda a la matriz de correlaciones, se cumple que $\sum_{i=1}^p \lambda_i = p$. En otras palabras, los elementos

λ_i proporcionan la ponderación que tienen los componentes principales en la varianza total de $X^T X$ de forma tal que $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$.

Además de reducir los efectos de la Multicolinealidad, la técnica de Componentes Principales se utiliza para:

- Detectar la presencia de **Datos Outliers**.
- Revisar la hipótesis de **Distribución Normal Multivariada** de las variables predictoras.
- Agrupar elementos de la muestra en subgrupos semejantes (Análisis Cluster).
- Reducción de la dimensión en Análisis Discriminante.

Para entender de mejor manera los conceptos recién expuestos, consideremos la siguiente muestra de las variables x_1 y x_2 , obtenidas de una distribución normal bi-variada:

Figura 5.3
Distribución Normal Bivariada: x_1 vs x_2





Figura 5.4
Componentes Principales



Respecto a la Figura 5.4, es interesante notar que:

- La ecuación de la elipse es: $\frac{\tilde{x}_1^2}{\lambda_1} + \frac{\tilde{x}_2^2}{\lambda_2} = c$, donde $\tilde{x}_1$ y $\tilde{x}_2$ corresponden a los ejes rotados y c es la distancia entre el plano de corte de la distribución normal bivariada (campana) y el plano definido por $f(x_1, x_2) = 0$.
- Los vectores propios son paralelos a los ejes rotados de la elipse.
- $\text{cov}(\tilde{x}_1, \tilde{x}_2) = 0$
- Si x_1 y x_2 no están correlacionados ($\sigma_{1,2} = 0$), se tendrá que $\lambda_1 = \sigma_1^2$ y $\lambda_2 = \sigma_2^2$. Luego, no es necesario rotar la elipse.
- Si $\lambda_2 = 0$, los puntos caerían en la recta de $\tilde{x}_1$, y viceversa. Esto indica que la correlación entre ambas variables es uno.

- Si $\lambda_1 = \lambda_2$ a elipse colapsará a una circunferencia, y los valores propios quedarán indeterminados (se podrá determinar sólo uno), ya que la variabilidad de los datos es la misma en todas las direcciones.

Sin embargo, **si las variables x no están correlacionadas, no tiene sentido aplicar el MCP**. Luego, es necesario determinar si las variables de respuesta x están o no correlacionadas antes de aplicar el MCP.

Esto se puede llevar a cabo probando si la matriz Σ es diagonal o no. Si es diagonal, las variables de respuesta son independientes y no tiene sentido aplicar MCP.

Definiendo la hipótesis nula de que Σ es diagonal, o que es análogo a decir que la matriz de correlaciones R es la identidad I , se tiene el siguiente contraste para muestras grandes:

$$-\left(n-1-\left(\frac{2p+5}{6}\right)\right)\ln|R| \sim \chi^2_{p(p-1)/2} \quad (5.35)$$

Si el valor estimado es mayor que el valor crítico tabulado, se rechaza entonces la hipótesis nula de no correlación entre las variables de respuesta, por lo que es factible aplicar el MCP. Notar que $\ln|R| = \sum_i \hat{\lambda}_i - \sum_i \hat{\sigma}_{i,i}$.

5.2.7 Regresión Cresta (Ridge Regression)

Fue propuesta por Hoerl y Kennard (1970) y se basa en perturbar la matriz $(X^T X)$ en otra parecida $(X^T X + \lambda I)$, donde lo que hacemos es sumar a la diagonal principal de $(X^T X)$ una constante λ . La idea es perturbar lo mínimo posible la matriz $(X^T X)$ para que cambie su tamaño y su determinante sea distinto de cero. El problema de estos regresores es la elección de la constante k que ha de sumarse a la diagonal principal de $(X^T X)$, además de que dichos estimadores no conservan la propiedad de insesgadez de los MCO. Es decir:

$$\hat{\beta}_C = (X^T X + \lambda I)^{-1} X^T Y = (X^T X + \lambda I)^{-1} X^T (X\beta + \varepsilon) \quad (5.36)$$

y bajo las hipótesis habituales sobre el término de perturbación, se tiene que:

$$E(\hat{\beta}_C) = (X^T X + \lambda I)^{-1} X^T X \beta \neq \beta \quad (5.37)$$


$$\text{sesgo}(\hat{\beta}_C) = -\lambda (X^T X + \lambda I)^{-1} \beta \quad (5.38)$$

El estimador Cresta o Ridge se obtiene de resolver el siguiente problema de optimización:

$$\begin{aligned} \min_{\{\beta\}} \quad & Q = (Y - X\beta)^T (Y - X\beta) = \varepsilon^T \varepsilon \\ \text{s.a.:} \quad & \beta^T \beta \leq r \quad (\lambda) \end{aligned} \quad (5.39)$$

Gráficamente, la solución del problema (5.39) se muestra en la siguiente Figura:

Figura 5.5
Estimador MCO vs Estimados Cresta



El valor de r no se conoce, y debe ser definido por el modelador, lo que equivale a definir un determinado valor para λ en la ecuación (5.36). Existen múltiples recomendaciones para estimar λ , entre las que se pueden mencionar:

$$\lambda_k = \frac{\hat{\sigma}^2}{\left(\hat{\theta}_{MAX}\right)^2} \quad (5.40)$$

donde $\hat{\sigma}^2$ se obtiene directamente de la estimación de MCO y $\hat{\theta}_{MAX}$ es el máximo parámetro estimado del siguiente modelo:

$$Y = Z\theta + \varepsilon \quad (5.41)$$

En el modelo (5.41) se construye a partir de la siguiente definición: sea $\Sigma = X^T X$ y definamos también $Z = XA$, $\theta = A^T \beta$, $A^T \Sigma A = \Lambda$, donde A es una matriz ortogonal y Λ es la matriz diagonal cuyos elementos son los valores propios de Σ .


Pese a ser sesgado, el estimador cresta tiene menor varianza que el clásico estimador de MCO:

$$V(\hat{\beta}_C) = \sigma^2 (X^T X + \lambda I)^{-1} X^T X (X^T X + \lambda I)^{-1} < V(\hat{\beta}_{MCO}) \quad (5.42)$$

Además, es posible demostrar que siempre existe un valor de λ tal que el Error Cuadrático Medio (ECM, que es la suma de la varianza del estimador más el cuadrado del sesgo) del estimador Cresta es menor que el de MCO.

Además del problema de elegir el escalar λ óptimo para cada problema en concreto, esta solución no tiene **ninguna interpretación económica**. Es decir, resolvemos el problema numérico, pero perturbamos la matriz $(X^T X)$, lo cual supone cambiar la información muestral sobre las variables explicativas. Este remedio a la multicolinealidad no es muy utilizado en la práctica.

Figura 5.6
Error Cuadrático Medio Estimador MCO vs Estimados Cresta




5.3 Heterocedasticidad

5.3.1 Definición de Heterocedasticidad

La heterocedasticidad es la existencia de una varianza no constante en las perturbaciones aleatorias de un modelo econométrico. Es decir, cada individuo u observación de la muestra tiene una varianza propia diferente del resto. En ese caso, la matriz de varianzas y covarianzas de las perturbaciones se representaría del siguiente modo:

$$V(\varepsilon) = \begin{bmatrix} \sigma_1^2 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & \sigma_n^2 \end{bmatrix} = \sigma^2 \Omega \quad (5.43)$$

Figura 5.7
Perturbaciones Heterocedásticas



Producto de la presencia de una matriz de varianzas y covarianzas no escalar de las perturbaciones aleatorias, la estimación correcta de los parámetros del modelo se realiza mediante MCG:

$$\hat{\beta}_{MCG} = (X^T \Omega^{-1} X)^{-1} (X^T \Omega^{-1} Y) \quad (5.44)$$

Sin embargo, para la aplicación de (5.44) en un modelo con n observaciones y k variables explicativas, sería necesario estimar $k + 1$ parámetros (considerando el intercepto) y n varianzas para las perturbaciones. Luego, hay más incógnitas que ecuaciones independientes que se puedan construir con las n observaciones.

Por ello, habrá que hacer algún supuesto simplificador sobre la causa de la heterocedasticidad, una vez que esta sea detectada. Evidentemente, encontrar una simplificación correcta dotará de plena utilidad (eficiencia) a la estimación con MCG y, a en caso contrario, un mal diseño de la causa de la heterocedasticidad (de la matriz Ω) producirá un valor ineficiente de dichos parámetros. Lamentablemente, muy rara vez de puede inferir una forma funcional adecuada de Ω , por lo que la única alternativa puede ser estimar dicha matriz o simplemente usar MCO.

5.3.2 Causas de la Heterocedasticidad

La heterocedasticidad es un problema que surge en muchas aplicaciones, sobre todo trabajando con datos de sección cruzada (corte transversal). Por ejemplo, en una relación que explica los beneficios de un conjunto de empresas, es lógico pensar que existe una mayor variación en los beneficios de las empresas grandes que en los beneficios de las pequeñas. Pero incluso después de descontar las diferencias de tamaños, puede seguir existiendo heterocedasticidad.

Así, la varianza de los beneficios puede depender también de la diversificación del producto, de los gastos en investigación y desarrollo, de las características de cada empresa y además, podrían variar los beneficios dentro de empresas de un mismo tamaño debido a diferencias en la rotación de personal. Todas estas variables, que afectan a la variable dependiente, difícilmente pueden ser incorporadas correctamente en un modelo, ya que no existe información fidedigna al respecto.

Si bien las causas que se citan a continuación no son las únicas posibilidades que dan lugar a un modelo heterocedástico, sí son las más frecuentes. Notar que en la mayoría de los casos, la heterocedasticidad es se debe a la presencia de una variable heterocedástica.

a. Variables explicativas cuyo recorrido tenga una gran dispersión respecto a su propia media.

En esta situación, los modelos de corte transversal son especialmente susceptibles a registrar heterocedasticidad. La disposición arbitraria de las observaciones en este caso (puede responder, por ejemplo al orden alfabético de las observaciones de la endógena o al modo en que se han obtenido los datos o a cualquier otra razón) pueden agrupar, casualmente, observaciones que presenten valores grandes en una determinada variable explicativa y lo mismo con valores pequeños de esta misma variable.

Si esta variable es la que está produciendo la distorsión en el modelo de heterocedasticidad, dicha distorsión será probablemente mayor en aquellas observaciones que contengan una mayor carga de ésta y menor en las que su peso

sea más pequeño. Por ello, la varianza de las perturbaciones aleatorias estimada por sub-períodos distintos de una muestra sería diferente; es decir, habría heterocedasticidad. La misma situación se puede dar en modelos de corte temporal en los que la evolución histórica haya marcado diferentes períodos en cuanto a los valores de una variable en relación a su media, agrupando en algún sub-período valores altos y en otros valores pequeños, como por ejemplo en períodos de inestabilidad en el precio del petróleo.

b. Omisión de variables relevantes en el modelo especificado.

Evidentemente, cuando se ha omitido una variable en la especificación, dicha variable quedará parcialmente recogida en el comportamiento de las perturbaciones aleatorias, pudiendo introducir en éstas su propia variación, no necesariamente fija. Recuérdese que la hipótesis inicial del MRL de homocedasticidad hacía referencia a la varianza constante de las perturbaciones aleatorias, pero no obligaba a que las variables explicativas tuvieran también varianza constante, hecho que, además, sería una restricción muy poco plausible.

c. Cambio de estructura.

El hecho de que se produzca un cambio de estructura determina un mal ajuste de los parámetros al conjunto de los datos muestrales. Este no tiene porque influir del mismo modo en todo el recorrido de la muestra, pudiendo producir cuantías de desajuste del modelo diferentes y, por tanto, varianza no constante por sub-períodos.

Al fin y al cabo, el fenómeno del cambio de estructura es equiparable a una especificación incorrecta por omisión de variables relevantes: precisamente faltaría la variable ficticia que distingue entre las dos situaciones o estructuras distintas que conviven en el período muestral elegido en el modelo. Un caso típico es ver el nivel de ingreso entre profesionales con y sin post grado, o entre hombres y mujeres, o entre jóvenes y adultos mayores jubilados.

d. Empleo de variables no relativizadas.

De un modo similar al comentado en el caso (a), aquellas observaciones que contengan un valor mayor de una variable explicativa concreta (sospechosa de ser la que produce la heterocedasticidad) pueden originar valores del error diferentes.

Observadas las causas frecuentes de heterocedasticidad, es fácil deducir que la varianza no constante de las perturbaciones aleatorias viene casi siempre inducida por alguna variable, presente o no en el modelo, por lo que se podrían distinguir dos componentes en la varianza heterocedástica resultante del modelo: una cambiante, proveniente de esa variable que induce el problema, y una constante, que sería la que se daría si el modelo hubiera sido bien planteado. Matemáticamente podríamos escribir esto del siguiente modo:

$$\sigma_i^2 = f(\sigma^2 Z_i) \quad (5.45)$$

donde σ^2 sería el parámetro fijo o parte fija de la varianza, y Z_i sería la matriz de variable o variables que está produciendo ese comportamiento no constante de la varianza de las perturbaciones aleatorias. Esta función podría ser empleada precisamente como el “supuesto simplificador” al que anteriormente se hacía referencia para posibilitar la estimación mediante MCG de Ω sin encontrarnos con más incógnitas que observaciones.

5.3.3 Efectos de la Heterocedasticidad

El gran efecto de la heterocedasticidad es que los estimadores de los parámetros de varianza (no los β), son incorrectos. Luego, la eficiencia de los restantes estimadores es menor y la inferencia estadística que se realice es incorrecta.

a. Cálculo incorrecto de varianzas y parámetros ineficientes.

En el caso de obviar la heterocedasticidad para la estimación de los parámetros, es decir, seguir empleando la expresión MCO, caben dos opciones:

- Estimar los parámetros y también la varianza como si hubiera homocedasticidad en el modelo; esto es, usar simplemente MCO.
- Estimar los parámetros β con MCO, pero luego calcular la verdadera varianza que les correspondería a estos estimadores cuando la matriz de varianzas y covarianzas de la perturbación aleatoria es no escalar.

Sobre esta reflexión es interesante notar el experimento realizado por Goldfeldt y Quandt (1972) en el que pretendían analizar la ganancia en eficiencia (menor varianza) en los siguientes tres casos:

- Estimación de los parámetros con la expresión de MCG y cálculo correcto de sus varianzas correspondientes:

$$\hat{\beta}_{MCG} = (X^T \Omega^{-1} X)^{-1} (X^T \Omega^{-1} Y) \text{ y } V(\hat{\beta}_{MCG}) = \sigma^2 (X^T \Omega^{-1} X)^{-1}$$

- Estimación de los parámetros con la expresión MCO y cálculo de las varianzas con la expresión que correspondería a un supuesto de homocedasticidad:

$$\hat{\beta}_{MCO} = (X^T X)^{-1} X^T Y \text{ y } V(\hat{\beta}_{MCO}) = \sigma^2 (X^T X)^{-1}$$

- Estimación de los parámetros con la expresión MCO y cálculo de las varianzas con la expresión que correspondería a un supuesto de heterocedasticidad:

$$\hat{\beta}_{MCO} = (X^T X)^{-1} X^T Y \text{ y } V(\hat{\beta}_{MCO}) = \sigma^2 (X^T X)^{-1} (X^T \Omega^{-1} X) (X^T X)^{-1}$$

Sobre un experimento controlado de generación de la varianza heterocedástica se llegaba a las siguientes conclusiones:

1. La mayor varianza de MCO en vez de MCG puede producir un incremento de más de 10 veces en la varianza estimada del parámetro constante y valores hasta 4 veces mayores en las varianzas de los parámetros que acompañan a variables explicativas.
2. Calcular la varianza de los estimadores ignorando la heterocedasticidad, produce un sesgo por infravaloración de la real del orden del doble.

b. Invalidez de los contrastes de significancia.

Los contrastes que emplean para su cálculo estimaciones de la varianza o de su raíz cuadrada (desviación típica), sufrirán un claro sesgo deducible de lo dicho anteriormente:


- Si se confirma el problema de la heterocedasticidad y se siguen empleando MCO, calculando erróneamente la varianza que correspondería a estos en el caso de que hubiera homocedasticidad $\sigma^2 (X^T X)^{-1}$, ya se ha comentado que se estaría infravalorando la varianza real, por lo que contrastes de significatividad de los parámetros como la t -estadística o la F rechazarían la hipótesis nula con mayor frecuencia de la debida; es decir, aceptarían la validez de determinadas variables para explicar la endógena en casos en los que esto realmente es falso ($\hat{t} > t$).
- Si se emplearan MCO en la estimación, calculando correctamente su varianza en caso de heterocedasticidad $\sigma^2 (X^T X)^{-1} (X^T \Omega^{-1} X) (X^T X)^{-1}$ ya se ha comentado que estos parámetros arrojarían una importante ineficiencia respecto al empleo de MCG, por lo que, al contrario que en el caso anterior, se aceptaría la hipótesis nula de los contrastes de significatividad más veces de las reales ($\hat{t} < t$).

En síntesis, en presencia de heterocedasticidad, $\hat{\beta}$ será insesgado pero ineficiente, mientras que $\hat{\sigma}^2$ será sesgado. No obstante, si la heterocedasticidad no se debe a alguna variable X , la estimación MCO será asintóticamente correcta.

En la Figura 5.8 5.4 se observa claramente que la muestra de color fucsia genera un estimador MCO muy diferente a la muestra de color naranja, y a su vez ambos son diferentes al verdadero estimador (pendiente de la línea recta de color negro).

Sin embargo, se aprecia que el promedio de las pendientes de las línea fucsia y naranja tiende a parecerse a la pendiente de la línea negra. Esto refleja por lo tanto la ineficiencia que genera la heterocedasticidad al usar MCO.

Figura 5.8
Ejemplo del Efecto de la Heterocedasticidad



5.3.4 Detección de la Heterocedasticidad

a. Contrastes gráficos.

- **Gráfica del error a través de las distintas observaciones del modelo:** Dado que las series económicas presentan casi siempre una tendencia definida (positiva o negativa), la simple gráfica de error puede servir para conocer intuitivamente si el mero transcurso del tiempo da lugar a un incremento/decremento continuado del error, lo que sería significativo de una relación entre la evolución de las variables del modelo y los valores cada vez mayores o cada vez menores de éste.

En ambos, la mera evolución del tiempo podría estar correlacionada con valores cada vez mayores (izquierda) del error o cada vez menores (derecha), con lo que el cálculo de la varianza por sub-períodos arrojaría valores significativamente diferentes; es decir la serie del error sería heterocedástica.

- **Gráfica del valor absoluto del error en función de una explicativa sospechosa de producir la heterocedasticidad en el modelo:** Si se ordena de menor a mayor la variable sobre la que se quiere investigar si produce o no heterocedasticidad y, con ella, los valores absolutos del error estimado, el hecho de que la nube de puntos obtenida en su gráfica conjunta se pudiera aproximar correctamente con una regresión lineal significaría que el incremento de la variable explicativa da lugar a un incremento de las perturbaciones aleatorias, lo que sería causa de heterocedasticidad en éstas.

b. Contrastes paramétricos.

Varios de los contrastes que se desarrollan en este apartado tendrán un método para dirimir la significatividad de los valores obtenidos a partir de las tablas estadísticas de las funciones de densidad conocidas según la cual se distribuyen en cada caso los ratios propuestos. Es por esta razón por la que se llaman "paramétricos".

- **Contraste de Breusch-Pagan:** La idea del contraste es comprobar si se puede encontrar un conjunto de variables Z que sirvan para explicar la evolución de la varianza de las perturbaciones aleatorias, estimada ésta a partir del cuadrado de los errores del modelo inicial sobre el que se pretende comprobar si existe o no heterocedasticidad. El proceso a seguir para llevar a cabo este contraste es el siguiente:

- i) Estimar el modelo inicial, sobre el que se pretende saber si hay o no heterocedasticidad, empleando MCO y determinando los errores:

$$Y = X\beta + \varepsilon, \hat{\beta}_{MCO} = (X^T X)^{-1} X^T Y, \hat{\varepsilon}_i = Y_i - \hat{Y}_i \rightarrow \hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n-k}$$

- ii) Calcular una serie con los errores del modelo anterior al cuadrado estandarizados:

$$\hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n-k} \rightarrow \tilde{\varepsilon}_i^2 = \frac{\hat{\varepsilon}_i^2}{\hat{\sigma}^2} \quad (5.46)$$

Este valor al cuadrado nos elimina problemas de interpretación sobre la evolución media del error en el tiempo debidos a la compensación de signos que se produciría en cualquier cálculo agregado (valores positivos y negativos). Por otra parte, la estandarización elimina distorsiones debidas a las posibles distintas dimensiones de los errores originales.

iii) Se estima una regresión del error $\tilde{\varepsilon}_i^2 = \frac{\hat{\varepsilon}_i^2}{\hat{\sigma}^2}$ calculado en el paso (ii)

explicado por una constante α_0 y el conjunto de las variables Z que se pretende saber si producen o no heterocedasticidad en el modelo; notar que las variables Z pueden ser todas o un subconjunto de las variables X originales. Luego se obtiene el coeficiente de determinación de este modelo y la varianza de la estimada:

$$\tilde{\varepsilon}_i^2 = \alpha_0 + \alpha_1 Z_1^i + \alpha_2 Z_2^i + \dots + \alpha_p Z_p^i + v_i \rightarrow R_{\tilde{\varepsilon}}^2 \quad (5.47)$$

iv) En principio, dado que el modelo tiene término constante, se cumple la regla general de las regresiones en que la varianza de la variable dependiente real es igual a la suma de la varianza de la dependiente estimada más la varianza del error obtenido en el modelo. Por ello, si el modelo es "malo" la varianza de la endógena estimada será pequeña (es lo mismo que decir que la varianza del error estimado es grande o que el "modelo tiene mucho error").

En definitiva, y siguiendo el interés que aquí buscamos, si la varianza de la variable dependiente estimada en este segundo modelo es muy pequeña, estaremos afirmando que el poder explicativo del conjunto de variables Z sobre la representación de la varianza de las perturbaciones aleatorias es escaso.

A partir de esta afirmación, podríamos generar un contraste calculado con esta varianza, sabiendo que cuanto más cerca de cero se encuentre, más probabilidades de homocedasticidad habrá en el modelo. El contraste propuesto es:

$$n \cdot R_{\varepsilon}^2 \sim \chi_{p-1}^2 \quad (5.48)$$

Si el valor estimado de $n \cdot R_{\varepsilon}^2$ supera al valor de tablas e χ_{p-1}^2 , se rechaza la hipótesis nula; es decir, se acepta que el conjunto de variables Z está produciendo heterocedasticidad en el modelo original. En caso contrario, se acepta la homocedasticidad.

El contraste de Breusch - Pagan efectivamente nos servirá para aceptar o descartar la presencia de heterocedasticidad debida a ese conjunto de variables Z citado, pero su operatividad es limitada. Si el conjunto de las variables Z contiene variables no incluidas en el modelo original, parece difícil no haberlas tenido en cuenta antes para realizar una buena especificación y sí tenerlas en cuenta ahora para la contrastación. Por otro lado, la lista de variables Z debe ser necesariamente pequeña para poder realizarse el contraste.

- **Contraste de Glesjer:** De forma similar al caso anterior, Glesjer propone descartar la variación del error en función de una variable Z , que ahora pueden estar elevadas a una potencia " h " que estaría comprendida entre -1 y 1. El método que se propone es:

- i) Estimar el modelo inicial, sobre el que se pretende saber si hay o no heterocedasticidad, empleando MCO y determinando los errores:

$$Y = X\beta + \varepsilon, \quad \hat{\beta}_{MCO} = (X^T X)^{-1} X^T Y, \quad \hat{\varepsilon}_i = Y_i - \hat{Y}_i \rightarrow \hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - k}$$

- ii) Estimar cuatro regresiones para los valores absolutos del error del modelo anterior en función de una variable elevada consecutivamente a " h ", que para cada modelo tomaría los valores -1, -0,5, 0,5 y 1:

$$|\hat{\varepsilon}_i| = \alpha_0 + \alpha_1 Z^h + u_i \quad (5.49)$$

Se escogerá la regresión de las cuatro con parámetros significativos y con mayor R^2 .

iii) Se entiende que, si el valor de esta R^2 es suficientemente grande, se estará confirmando que existe heterocedasticidad producida por la variable Z , ya que esta es capaz de explicar la evolución de la evolución del error como estimada de la evolución de las perturbaciones aleatorias. Se puede usar el test expuesto en (5.48).

- **Contraste de White:** En este contraste la idea subyacente es determinar si las variables explicativas del modelo, sus cuadrados y todos sus cruces posibles no repetidos, sirven para determinar la evolución del error al cuadrado.

Es decir, si la evolución de las variables explicativas y de sus varianzas y covarianzas son significativas para determinar el valor de la varianza muestral de los errores, entendida ésta como una estimación de las varianzas de las perturbaciones aleatorias. El proceso a seguir para realizar este contraste sería el siguiente:

- Estimar el modelo original por MCO, determinando la serie de los errores. Escrito esto en forma matricial para un modelo con n observaciones y k variables explicativas:

$$Y = X\beta + \varepsilon, \quad \hat{\beta}_{MCO} = (X^T X)^{-1} X^T Y, \quad \hat{\varepsilon}_i = Y_i - \hat{Y}_i \rightarrow \hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - k}$$

- Estimar un modelo en el que la endógena sería los valores al cuadrado de los errores obtenidos previamente (paso i) con todas las variables explicativas del modelo inicial, sus cuadrados y sus combinaciones no repetidas.

$$\left. \begin{aligned} \hat{\varepsilon}_i^2 = & \alpha_0 + \alpha_1 X_1^i + \dots + \alpha_k X_k^i + \\ & \alpha_{k+1} (X_1^i)^2 + \dots + \alpha_{k+k} (X_k^i)^2 + \\ & \alpha_{k+k+1} (X_1^i \cdot X_2^i) + \dots + \alpha_{k+k+k} (X_1^i \cdot X_k^i) + \\ & \alpha_{3k+1} (X_2^i \cdot X_3^i) + \dots + \alpha_{4k-1} (X_2^i \cdot X_k^i) + \dots + \eta_i \end{aligned} \right\} \rightarrow R_{\varepsilon}^2 \quad (5.50)$$

El valor de la R_{ε}^2 de este segundo modelo (paso ii) nos dirá si las variables elegidas sirven o no para estimar la evolución variante del error al cuadrado, representativo de la varianza estimada de las perturbaciones aleatorias.

Evidentemente, si la varianza de éstas fuera constante (homocedasticidad), el carácter no constante de las variables explicativas implicadas en el modelo no serviría para explicar la endógena, luego la R_{ε}^2 debiera ser muy pequeña.

En principio, la R_{ε}^2 , como proporción de la varianza de la endógena real que queda explicada por la estimada, debiera ser muy pequeña si la capacidad explicativa de los regresores considerados también es muy pequeña, siendo estos regresores, por su construcción, representativos de varianzas y covarianzas de todas las explicativas del modelo original.

Dicho esto, evidentemente un valor de la R_{ε}^2 suficientemente pequeño servirá para concluir que no existe heterocedasticidad en el modelo producida por los valores de las explicativas consideradas en el modelo inicial.

Para encontrar el valor crítico en esa consideración de “suficientemente pequeño” se emplea la expresión deducida por Breusch y Pagan como producto del coeficiente R^2 por el número de datos del modelo, que se distribuiría del siguiente modo:

$$n \cdot R_{\varepsilon}^2 \sim \chi_{p-1}^2 \quad (5.51)$$

En definitiva, si obtenemos un valor del producto $n \cdot R_{\varepsilon}^2$ mayor que el reflejado por las tablas de χ_{p-1}^2 , afirmaremos que existe heterocedasticidad, y viceversa.

Otro modo de contrastar la existencia de heterocedasticidad en el modelo a partir de la validez o no de los parámetros incluidos en la regresión propuesta por White vendría dado por el valor del contraste de significación conjunta F .

Si dicho contraste afirmara que, en conjunto, las variables explicitadas tienen capacidad explicativa sobre la endógena, estaríamos afirmando la presencia de heterocedasticidad en el modelo.

- **Contraste de Spearman:** La filosofía de este contraste reside en que la variable sospechosa de producir heterocedasticidad debería provocar un crecimiento del residuo estimado al mismo ritmo que ella va creciendo. Por ello, si ordenáramos de menor a mayor tanto la variable “sospechosa”, por ejemplo x_{ki} , como el valor absoluto del residuo $|\hat{\varepsilon}_i|$, el cambio de puesto en ambas, y para cada una de las observaciones, debiera ser del mismo número de puestos respecto al orden original de las series.

En la medida en la que este cambio de puesto respecto al original no sea el mismo para las dos (una vez ordenadas) se podría hablar de movimientos no correlacionados.

Dado que la correlación se mide entre uno y menos uno, Spearman propone determinar un grado de correlación en ese “cambio de puesto respecto al inicial” de cada una de las variables a partir de la diferencia (d_i) entre el nuevo puesto y el inicial:

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (5.52)$$

En esta expresión, una coincidencia máxima (todas las distancias son igual a cero), daría lugar a una correlación de Spearman igual a uno; mientras que una distancia máxima, provocaría un valor cero de dicho coeficiente de correlación.

Para valorar la significatividad o no de esta correlación, se conoce la función de distribución del siguiente ratio bajo la hipótesis nula de no significatividad, demostrado por el autor:

$$\frac{r_s \sqrt{n-2}}{\sqrt{1-r_s^2}} \sim t_{n-2} \quad (5.53)$$

Con ello, si el resultado del ratio es superior al valor de tablas, podremos afirmar que la correlación es significativa o, de cara a nuestro interés en este caso, que hay indicios de heterocedasticidad en el modelo provocada por la variable x_{ki} .

5.3.5 Corrección de la Heterocedasticidad

Como hemos venido viendo repetidas veces a lo largo del tema, la heterocedasticidad viene producida por la dependencia de la varianza de las perturbaciones aleatorias de una o más variables que, a su vez, pueden estar presentes en el modelo o no.

Los distintos métodos para detectar este problema servían para probar, en el caso en el que ésta realmente se diese, la dependencia de la varianza de la perturbación aleatoria de un conjunto de variables, a partir de lo que hemos llamado un supuesto simplificador:

$$\sigma_i^2 = f(\sigma^2 Z_i) \quad (5.54)$$

Por lógica, el modo de subsanar el problema detectado será operar convenientemente las variables del modelo precisamente eliminando la fuente de heterocedasticidad que habremos podido definir cuando detectamos la misma.

Como veremos a continuación, si el conjunto total de las variables del modelo (endógena incluida) es dividido por la forma estimada de esta función de la raíz de la varianza heterocedástica (una vez algún método de detección nos haya confirmado que efectivamente el comportamiento de esta varianza se puede seguir convenientemente con dicha función) estaremos corrigiendo el modelo.

Para comprobar esto, podemos volver a la forma matricial de varianzas covarianzas no escalar:

$$V(\varepsilon) = \begin{bmatrix} \sigma_1^2 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & 0 & \dots & 0 \\ \dots & & & & \\ 0 & 0 & 0 & \dots & \sigma_n^2 \end{bmatrix} = \sigma^2 \Omega \quad (5.55)$$

En esta matriz, si dividimos por la raíz de $\sigma_i^2 = f(\sigma^2 Z_i)$, obtendremos una diagonal principal de unos; es decir, volveríamos al caso de una matriz de varianzas y covarianzas escalar tal y como la que se supone en el modelo básico de regresión lineal.

Formalmente, para probar esto seguimos los siguientes pasos. Dado que la matriz Ω es una matriz semidefinida positiva (todos los elementos de su diagonal principal son necesariamente positivos), siempre podremos descomponerla en dos matrices de la forma:

$$\Omega = PP^T \rightarrow \Omega^{-1} = (P^{-1})(P^{-1})^T \quad (5.56)$$

Volviendo a la matriz de varianzas y covarianzas no escalar, y uniendo esto a la función que hemos comprobado sirve para definir esta varianza no constante $\sigma_i^2 = f(\sigma^2 Z_i)$, es fácil llegar a que la descomposición $\Omega = PP^T \rightarrow \Omega^{-1} = (P^{-1})(P^{-1})^T$ es:

$$\begin{bmatrix} \sigma_1 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & 0 & \dots & 0 \\ \dots & & & & \\ 0 & 0 & 0 & \dots & \sigma_n \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & 0 & \dots & 0 \\ \dots & & & & \\ 0 & 0 & 0 & \dots & \sigma_n \end{bmatrix} = \sigma^2 PP^T \quad (5.57)$$

Si multiplicamos cada variable del modelo por esta matriz P , tal y como se ha sugerido, obtenemos unas nuevas variables del siguiente tipo:

$$P^{-1}Y = P^{-1}X\beta + P^{-1}\varepsilon \rightarrow Y^* = X^*\beta + \varepsilon^* \quad (5.58)$$

donde:

$$V(\varepsilon^*) = E(\varepsilon^* \varepsilon^{*T}) = E\left((P^{-1})\varepsilon^* \varepsilon^{*T}(P^{-1})^T\right) = (P^{-1})(P^{-1})^T E(\varepsilon^* \varepsilon^{*T}) \quad (5.59)$$

$$V(\varepsilon^*) = \Omega^{-1} E(\varepsilon^* \varepsilon^{*T}) = \Omega^{-1} \sigma^2 \Omega = \sigma^2 I_n \quad (5.60)$$

Luego, podemos afirmar que el modelo transformado (aquel por el que se han dividido todas las variables por la desviación típica estimada de las perturbaciones aleatorias) soporta una matriz de varianzas covarianzas de las perturbaciones aleatorias escalar, con lo que se puede estimar con toda garantía por MCO.

En síntesis, los pasos para corregir la heterocedasticidad son los siguientes:

- a) Se estiman los parámetros del modelo por MCO, ignorando por el momento el problema de la heterocedasticidad de las perturbaciones aleatorias
- b) Se establece un supuesto acerca de la formación de σ_i^2 y se emplean los residuos de la regresión por MCO para estimar la forma funcional supuesta.
- c) Se divide cada observación por $\sqrt{\sigma_i^2}$ según el paso anterior (según el valor de esa heterocedasticidad supuesta estimada, siempre y cuando un contraste nos haya confirmado que el "modelo simplificador" es bueno).
- d) Se estima el modelo original ahora con todas las variables transformadas según el paso (c).

5.4 Autocorrelación


5.4.1 Definición de Autocorrelación

Usando datos de series temporales es un problema común la presencia de autocorrelación o correlación serial de las perturbaciones. Sin embargo, con datos de sección cruzada o de panel, es más habitual encontrar un problema de heterocedasticidad. En ese caso, la matriz de varianzas y covarianzas de las perturbaciones se representaría del siguiente modo:

$$V(\varepsilon) = \frac{\sigma^2}{1-\rho^2} \begin{bmatrix} 1 & \rho & \rho^2 & \dots & \rho^{n-1} \\ \rho & 1 & \rho & \dots & \rho^{n-2} \\ \dots & \dots & \dots & \dots & \dots \\ \rho^{n-1} & \rho^{n-2} & \rho^{n-3} & \dots & 1 \end{bmatrix} = \sigma^2 \Omega \quad (5.61)$$

Supongamos que se ha estimado un modelo por MCO y representamos gráficamente los residuos resultantes:

Figura 5.9
Perturbaciones Autocorrelacionadas



El patrón de estos residuos nos muestra que el conocimiento del signo de un residuo es un buen indicador del signo del residuo en el período siguiente y esto es autocorrelación. Luego, si se pueden predecir los errores cometidos por un modelo, se puede por lo tanto mejorar el modelo al pronosticar dichos errores.

5.4.2 Causas de la Autocorrelación

- a) Una explicación al problema de autocorrelación son los factores omitidos en la regresión que están correlacionados a través del tiempo. El análisis univariante de series temporales nos sugiere que las variables económicas siguen distintas estructuras de autocorrelación.
- b) Otra causa común de la autocorrelación es la existencia de tendencias (inercias) y ciclos en los datos. Es decir, la mayoría de las variables económicas no son estacionarias en media. Esto significa que si la variable endógena del modelo tiene una tendencia creciente o presenta un comportamiento cíclico que no es explicado por las exógenas, el término de error recogerá ese ciclo o tendencia.
- c) Si se omite una variable explicativa no estacionaria en media, esto también provocará autocorrelación en el término de error. Por ejemplo, si el modelo correcto es:

$$Y^t = X_1^t \beta_1 + X_2^t \beta_2 + \varepsilon^t \quad (5.62)$$

y se trabaja con el modelo $Y^t = X_1^t \beta_1 + u^t$ donde $u^t = X_2^t \beta_2 + \varepsilon^t$, entonces presentará autocorrelación aunque ε^t sea un proceso de ruido blanco. Sabemos además que la omisión de variables relevantes provoca sesgos en el estimador MCO.

- d) Otra fuente de autocorrelación es especificar una relación lineal entre las variables cuando la verdadera relación es no lineal. En este caso, lo habitual es tener una racha de residuos positivos (o negativos) seguida de otra racha de residuos negativos (o positivos) y así sucesivamente. Aquí la causa del problema en los residuos es un error de especificación en la forma funcional.

- e) La autocorrelación puede provenir del hecho de que la relación entre las variables económicas es dinámica y no estática. Por ejemplo, trabajamos con el modelo:

$$Y^t = \beta_0 + X^t \beta_1 + u^t \quad (5.63)$$

cuando la verdadera relación es $Y^t = \beta_0 + X^t \beta_1 + Y^{t-1} \beta_2 + e^t$. Por tanto, $u^t = Y^{t-1} \beta_2 + e^t$, pero Y^{t-1} es una función de u^{t-1} y por ello, u^t será una función de u^{t-1} .

- c) Efectos de shocks con influencia prolongada en la economía, por ejemplo un terremoto o una guerra:

5.4.3 Efectos de la Autocorrelación

La consecuencia más grave de la autocorrelación de las perturbaciones es que la estimación MCO deja de ser eficiente y la inferencia estadística también se verá afectada. Con datos de series temporales, suponer que las perturbaciones son homocedásticas pero están correlacionadas equivale a escribir su matriz de covarianzas como:

$$V(\varepsilon) = \sigma^2 \Omega \quad (5.64)$$

donde Ω es una matriz definida positiva y simétrica, pero no diagonal. El estimador MCO de los parámetros β puede escribirse como:

$$\hat{\beta} = \beta + (X^T X)^{-1} X^T \varepsilon \quad (5.65)$$

Si la $E(\varepsilon) = 0$ y los regresores no están correlacionados con las perturbaciones, sigue siendo un estimador insesgado, ya que $E(\hat{\beta}) = \beta$.

Con respecto a la eficiencia del estimador, ahora $E(\hat{\beta})$ se tiene que:

$$V(\hat{\beta}) = E\left((\hat{\beta} - \beta)(\hat{\beta} - \beta)^T\right) = E\left((X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1}\right) \quad (5.66)$$


$$V(\hat{\beta}) = \sigma^2 \left[(X^T X)^{-1} (X^T \Omega X)^{-1} (X^T X)^{-1} \right] \quad (5.67)$$

y si $\varepsilon \sim N(0; \sigma^2 \Omega)$ entonces:

$$\hat{\beta} \sim N\left(\beta; \sigma^2 \left[(X^T X)^{-1} (X^T \Omega X)^{-1} (X^T X)^{-1} \right] \right) \quad (5.68)$$

Puesto que la matriz de covarianzas del estimador MCO no es $\sigma^2 (X^T X)^{-1}$, cualquier inferencia basada en el estimador será errónea. Además, no sólo es incorrecta la $\hat{\sigma}^2 (X^T X)^{-1}$ expresión de la matriz de covarianzas, sino que el estimador habitual de σ^2 será ahora sesgado.

Figura 5.10
Ejemplo del Efecto de la Autocorrelación



En la Figura 5.10 se observa claramente que la muestra de color fucsia genera un estimador MCO muy diferente a la muestra de color verde, y a su vez ambos son diferentes al verdadero estimador (pendiente de la línea recta de color negro). Además, claramente en los casos de las líneas verde y fucsia se sobrestima el R^2 , y al mismo tiempo subestima el σ^2 . Al igual que en la heterocedasticidad, se aprecia que el promedio de las pendientes de las línea fucsia y verde tiende a parecerse a la pendiente

de la línea negra. Esto refleja por lo tanto la ineficiencia que genera la autocorrelación al usar MCO.

5.4.4 Detección de la Autocorrelación

Existen distintos procedimientos de detección de la autocorrelación. Básicamente son instrumentos estadísticos y gráficos.

- **Contraste de Durbin-Watson:** En la práctica, no se sabe a priori si existe autocorrelación y cuál puede ser el proceso más adecuado para modelizarla.

Existen varios contrastes de autocorrelación que se construyen usando los residuos MCO del modelo original. El más antiguo y conocido es el estadístico de Durbin y Watson (1950, 1951) para detectar la presencia de un AR(1).

La hipótesis nula es que en el modelo $\varepsilon_t = \phi\varepsilon_{t-1} + v_t$, se cumple $\phi = 0$, donde además v_t es ruido blanco. El estadístico de contraste es:

$$DW = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=1}^n (\hat{\varepsilon}_t^2)} \approx 2(1 - \hat{\phi}) \quad (5.69)$$

Esta última aproximación es buena si n es suficientemente grande. El parámetro $\hat{\phi}$ es el estimador MCO de ϕ en la siguiente regresión:

$$\hat{\varepsilon}_t = \phi\hat{\varepsilon}_{t-1} + v_t \quad (5.70)$$

donde $\hat{\varepsilon}_t$ es el residuo resultante de la estimación MCO del modelo original, ignorando la presencia de autocorrelación.

La solución MCO es:

$$\hat{\phi} = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t \hat{\varepsilon}_{t-1})}{\sum_{t=2}^n (\hat{\varepsilon}_{t-1}^2)} \quad (5.71)$$

El rango de valores que puede tomar el estadístico DW es el siguiente:

- o $DW = 2$ si $\hat{\phi} = 0$.
- o $DW \in (2, 4)$ si $-1 < \hat{\phi} < 0$.
- o $DW \in (0, 2)$ si $0 < \hat{\phi} < 1$.

La distribución del estadístico DW bajo la hipótesis nula no es conocida. De hecho, el DW depende de los residuos MCO, $\hat{\varepsilon}_{MCO} = M\varepsilon$, y la matriz M depende de la matriz X , luego la distribución del estadístico depende de la matriz de datos y los valores críticos del contraste serán diferentes para cada posible matriz X .

Durbin y Watson tabularon los valores máximo ($d_{\max}$) y mínimo ($d_{\min}$) que pueden tomar dichos valores críticos cuando la $H_1: \phi > 0$, los regresores son fijos y existe término constante en el modelo.

Con este estadístico:

- o Si $H_0: \phi = 0$ frente a $H_1: \phi > 0$
 - i) se rechaza H_0 si $DW < d_{\min}$
 - ii) no se rechaza H_0 si $DW > d_{\max}$
 - iii) se cae en zona de incertidumbre si $d_{\min} < DW < d_{\max}$
- o Si la hipótesis a contrastar es $H_0: \phi = 0$ frente a $H_1: \phi < 0$, puesto que el estadístico toma valores comprendidos entre 2 y 4, los valores tabulados $d_{\min}$ y $d_{\max}$ se comparan con $(4 - DW)$ en lugar de DW .

Este contraste se puede considerar como un contraste de mala especificación del modelo. La omisión de variables relevantes, una forma funcional no apropiada, cambios estructurales no tenidos en cuenta, etc., pueden llevar a un valor del estadístico significativo.

Con este estadístico no se puede concluir nada si se cae en una zona de indeterminación y tampoco sirve si en el modelo aparecen regresores estocásticos (como, por ejemplo, algún retardo de la endógena). En este último caso, el valor del estadístico DW está sesgado hacia el 2, por lo que se tendería a no rechazar la hipótesis nula de no autocorrelación. Finalmente, si la estructura de autocorrelación existente en los residuos es de tipo estacional, el contraste de Durbin - Watson, en general, no detecta este tipo de autocorrelación.

Si la estructura de autocorrelación existente es de orden 2 o superior, en general, el valor del DW nos llevará a rechazar la nula, pero también a trabajar con una estructura de autocorrelación de orden 1.

Una alternativa propuesta por DW , cuando $Y^t = \beta_0 + Y^{t-1}\beta_1 + X^t\beta_2 + u^t$, corresponde a la siguiente:

$$h = \hat{\phi} \sqrt{\frac{n-1}{1-(n-1) \cdot V(\hat{\beta}_1)}} \sim N(0;1) \quad (5.72)$$

donde $\hat{\beta}_1$ es el estimador del coeficiente asociado a la variable endógena rezagada y n es el tamaño muestral. Luego, si el valor estimado de h es mayor al tabulado para un determinado nivel de confiabilidad, no se rechaza la hipótesis de ausencia de autocorrelación, es decir, es altamente probable que exista autocorrelación.

- **Contraste de Breusch y Godfrey:** Un procedimiento alternativo de detección es el contraste de Breusch y Godfrey donde en la hipótesis nula se tiene ausencia de autocorrelación, pero en la hipótesis alternativa se presenta $H_1 : \varepsilon_t > AR(p)$ ó $H_1 : \varepsilon_t > MA(q)$.

Operacionalmente, el test puede llevarse a cabo regresando los residuos MCO $\hat{\varepsilon}_t$, sobre las $X_t, \varepsilon_{t-1}, \dots, \varepsilon_{t-p}$ y comparando $n \cdot R^2$ con χ_p^2 . Dado que $X^T \hat{\varepsilon} = 0$, el contraste es equivalente a regresionar $\hat{\varepsilon}_t$ sobre la parte de los residuos no explicada por las X_t .

Si se encuentra algún ajuste, éste es debido a la correlación entre los residuos presentes y los residuos retardados.

Este estadístico es muy sencillo de calcular y resuelve los problemas del contraste de Durbin-Watson.

- **Contraste de Box y Pierce:** Otro estadístico es la Q de Box-Pierce definido como $Q = n \sum_{j=1}^L r_j^2$ donde:

$$r_j = \frac{\sum_t (\hat{\varepsilon}_t \hat{\varepsilon}_{t-j})}{\sum_t (\hat{\varepsilon}_t^2)} \quad (5.73)$$

Los valores resultantes se comparan con una distribución χ_L^2 . La principal diferencia entre el test de Breusch-Godfrey y el de Box-Pierce es el uso de correlaciones parciales entre los residuos en el primero y el de correlaciones simples en el segundo. Bajo la hipótesis nula de ausencia de autocorrelación, ambos contrastes son asintóticamente equivalentes.

- **Contrastes gráficos:** La autocorrelación residual puede detectarse mediante instrumentos gráficos, como por ejemplo, el gráfico estandarizado de los residuos MCO resultantes de la estimación del modelo original, la función de autocorrelación simple y la función de autocorrelación parcial. El uso de estas funciones permite no sólo detectar la presencia de autocorrelación en los residuos, sino también identificar la estructura concreta que siguen los mismos (de tipo AR, MA o ARMA).

5.4.5 Estimación bajo Autocorrelación

Para describir los procedimientos de estimación más habituales trabajaremos con un modelo concreto y un esquema de autocorrelación de tipo AR(1). Como ejemplo, supongamos que:

$$Y^t = \beta_0 + X^t \beta_1 + \varepsilon^t \quad (5.74)$$

$$\varepsilon^t = \phi \varepsilon^{t-1} + u^t \quad (5.75)$$

donde u^t es un proceso de ruido blanco. El modelo transformado donde el término de error no presenta autocorrelación es el siguiente:

$$\underbrace{Y^t - \phi Y^{t-1}}_{\tilde{Y}^t} = \underbrace{\beta_0 (1 - \phi)}_{\tilde{\beta}_0} + \underbrace{(X^t - \phi X^{t-1})}_{\tilde{X}^t} \beta_1 + u^t \quad (5.76)$$

$$\tilde{Y}^t = \tilde{\beta}_0 + \tilde{X}^t \beta_1 + u^t \quad (5.77)$$

Los procedimientos para estimar β_0, β_1 y ϕ son los siguientes:

- **Procedimiento iterativo de Cochrane-Orcutt:** Las etapas de este método son las siguientes:

- o Aplicar MCO al modelo original (5.74) ignorando la presencia de autocorrelación y recuperar los residuos. A partir de ellos, obtener una estimación preliminar de ϕ como:

$$\hat{\phi} = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t \hat{\varepsilon}_{t-1})}{\sum_{t=2}^n (\hat{\varepsilon}_{t-1}^2)} \quad (5.78)$$

- o Con la estimación $\hat{\phi}$ de la etapa anterior se calculan las variables transformadas:

$$\tilde{Y}^t = Y^t - \hat{\phi} Y^{t-1} \quad , \quad \tilde{X}^t = X^t - \hat{\phi} X^{t-1} \quad (5.79)$$

- o Luego se estima por MCO el modelo (5.77) y se recupera la estimación del término constante $\hat{\beta}_0$, a través de la relación $\tilde{\beta}_0 = \beta_0(1 - \hat{\phi})$. Con las estimaciones β_0, β_1 se vuelve al modelo original (5.74) y se recuperan los nuevos residuos y una nueva estimación de $\hat{\phi}$, usando de nuevo (5.78).
- o Se repite la segunda etapa hasta alcanzar la convergencia. Un criterio de convergencia puede ser parar cuando se cumple que:

$$\left| \frac{\hat{\phi}_t - \hat{\phi}_{t-1}}{\hat{\phi}_t} \right| < \delta \quad (5.80)$$

- **Procedimiento iterativo de Hildreth-Hu:** Este método calcula el estadístico de Durbin - Watson del modelo original y obtiene una estimación inicial $\hat{\phi}_t$.

A partir de esta estimación, se construye una malla de valores $\hat{\phi}_1, \hat{\phi}_2, \dots, \hat{\phi}_t, \dots, \hat{\phi}_n$ y se realizan tantas regresiones en el modelo transformado como valores tenga la malla. A continuación, se selecciona la regresión que genere la menor suma residual que se habrá obtenido con un valor $\hat{\phi}_m$.

A partir de este valor, se vuelve a construir una malla más fina de valores y se vuelve a repetir el proceso hasta alcanzar convergencia.

- **Método de diferencias:** la idea es tratar el problema no lineal directamente planteando como función objetivo:

$$\min \sum_{t=2}^n (\hat{\varepsilon}_t^2) = \sum_{t=2}^n \left[Y^t - \phi Y^{t-1} - \beta_0(1 - \phi) - (X^t - \phi X^{t-1})\beta_1 \right]^2 \quad (5.81)$$

para obtener simultáneamente una estimación de β_0, β_1 y ϕ . Una solución válida sólo cuando $\phi = 1$, es eliminar la autocorrelación tomando primeras diferencias a las variables. Es decir, si ε_t no sigue un proceso AR(1) sino un camino aleatorio, de forma que $\Delta \varepsilon_t = u_t$ y u_t es ruido blanco, el modelo transformado adecuado sería:

$$\Delta Y' = \Delta X' \beta_1 + u' \quad (5.82)$$

donde ha desaparecido el término constante del modelo original. Por esta razón, trabajar con variables temporales estacionarias en media, en muchas ocasiones resuelve el problema de correlación serial de los residuos.

5.5 Endogeneidad

5.5.1 Definición de Endogeneidad

Endógeno significa, literalmente, “determinado dentro del sistema,” es decir, una variable que se determina conjuntamente con Y , o bien que está sujeta a causalidad simultánea (X causa a Y e Y causa a X , simultáneamente).

La endogeneidad se define, en términos analíticos en el contexto de modelos de regresión lineal, como la correlación entre una (o varias) variable(s) explicativa(s) y el término de error. Esto implica que $E(X^T \varepsilon) \neq 0$. Luego, y como se observa a continuación, el estimador MCO de β será sesgado:

$$\hat{\beta} = (X^T X)^{-1} X^T Y = (X^T X)^{-1} (X^T (\beta X + \varepsilon)) \quad (5.83)$$


$$\hat{\beta} = \beta + (X^T X)^{-1} (X^T \varepsilon) \quad (5.84)$$

$$E(\hat{\beta}) = \beta + E\left[(X^T X)^{-1} (X^T \varepsilon)\right] \quad (5.85)$$


$$E(\hat{\beta}) = \beta + E\left[(X^T X)^{-1} (X^T \varepsilon)\right] = \beta + \underbrace{(X^T X)^{-1} E(X^T \varepsilon)}_{\substack{\neq 0 \\ \text{sesgo}}} \quad (5.86)$$

$$E(\hat{\beta}) \neq \beta \quad (5.87)$$

Por lo tanto, cuando existe endogeneidad, la estimación de parámetros puede ser sesgada e inconsistente, incluso con signos cambiados, y las conclusiones del proceso de inferencia pueden ser absolutamente incorrectas. Además, si $\hat{\beta}$ está sesgado, también estará sesgado $\hat{\varepsilon}$.

**Sin Endogeneidad**

$$\frac{\partial Y}{\partial X} = \beta$$

**Con Endogeneidad**

$$\frac{\partial Y}{\partial X} = \beta + \frac{\partial \varepsilon}{\partial X}$$

5.5.2 Causas de la Endogeneidad

- a) Una primera causa de endogeneidad puede ser la omisión de variables relevantes. Al omitir dichas variables, se traspasan al término de error. Si las variables omitidas están correlacionadas con algunas variables no omitidas, entonces el error del modelo también estará correlacionado con algunas de las variables no omitidas, y por lo tanto se cumplirá que $E(X^T \varepsilon) \neq 0$.
- b) Otra causa común de endogeneidad es la simultaneidad. Es decir, cuando la variable X causa a la variable Y , pero al mismo tiempo la variable Y causa a la variable X . Por ejemplo, supongamos la demanda por usar una autopista depende del precio de la autopista y también del nivel de servicio o velocidad. Conforme aumente la demanda de la autopista, también se reducirá su velocidad, lo que a su vez redundará en un nuevo nivel de demanda hasta llegar a un equilibrio.

$$Y_i = \beta X_i(Y_i) + \varepsilon_i \quad (5.88)$$

Luego, la estimación de los efectos marginales con y sin endogeneidad pueden ser muy distintos. Esto se da comúnmente en sistemas de ecuaciones simultáneas (por ejemplo, oferta y demanda).

- c) Una tercera causa de endogeneidad es la medición de la variable X con error. Supongamos que el modelo verdadero es $Y_i = \beta X_i + \varepsilon_i$, pero no observamos correctamente X_i , sino una aproximación de ella, que la definimos como $X_i = X_i^* + u_i$, con $u_i \sim N(0; \sigma_u^2)$.

Luego, el modelo que se estimará será:

$$Y_i = \beta X_i + \varepsilon_i = \beta X_i^* + \underbrace{\beta u_i + \varepsilon_i}_{v_i} = \beta X_i^* + v_i \quad (5.89)$$

El estimador MCO de (5.89) es el siguiente:

$$\hat{\beta} = \frac{\sum_i X_i^* Y_i}{\sum_i (X_i^*)^2} = \frac{\sum_i X_i^* (\beta X_i^* + v_i)}{\sum_i (X_i^*)^2} = \beta + \frac{\sum_i X_i^* v_i}{\sum_i (X_i^*)^2} \quad (5.90)$$

$$E(\hat{\beta}) = \beta + \frac{E\left(\sum_i X_i^* v_i\right)}{E\left(\sum_i (X_i^*)^2\right)} = \beta + \frac{E\left(\sum_i (X_i - u_i)(\beta u_i + \varepsilon_i)\right)}{E\left(\sum_i (X_i + u_i)^2\right)} \quad (5.91)$$

$$E(\hat{\beta}) = \beta - \frac{\beta \sigma_u^2}{\sigma_x^2 + \sigma_u^2} = \beta \left(1 - \frac{\sigma_u^2}{\sigma_x^2 + \sigma_u^2}\right) = \beta \left(\frac{\sigma_x^2}{\sigma_x^2 + \sigma_u^2}\right) < \beta \quad (5.92)$$


- d) Una cuarta fuente de endogeneidad se produce por el denominado sesgo de selección. Es decir, cuando la muestra no representa adecuadamente a la población, y está sesgada hacia una proporción específica del universo total. Por ejemplo, las encuestas de participación voluntaria.

5.5.3 Efectos de la Endogeneidad

La consecuencia más grave de la endogeneidad es el sesgo en la estimación de los parámetros y de las conclusiones que se obtengan del proceso de inferencia.

En la siguiente Figura se aprecia claramente los efectos que pueden generar la omisión de variables en el contexto de endogeneidad:

Figura 5.11
Ejemplo del Efecto de la Autocorrelación



En la Figura 5.11 se observa claramente que la pendiente de la recta azul es diferente a la pendiente de las rectas rojas; estas últimas, corrigen el efecto de la endogeneidad, mientras que la recta azul no lo hace.

5.5.4 Detección de la Endogeneidad

Lamentablemente, no existe un contraste o metodología que permita determinar la presencia de endogeneidad de manera infalible, y dependerá fuertemente de las habilidades del modelador y su comprensión del problema estudiado a fin de identificar potenciales fuentes de endogeneidad.

Sin embargo, mediante el test de Hausman, es posible comparar un estimador sesgado (en presencia de endogeneidad) con un estimador insesgado (estimado corrigiendo la endogeneidad). El test de Hausman es el siguiente:

$$(\hat{\beta}_c - \hat{\beta}_s)^T [\text{var}(\hat{\beta}_c) - \text{var}(\hat{\beta}_s)]^{-1} (\hat{\beta}_c - \hat{\beta}_s) \sim \chi_m^2 \quad (93)$$

donde $\hat{\beta}_c$ es el vector de parámetros estimados del modelo (de rango m) corrigiendo la endogeneidad (estimador consistente), y $\hat{\beta}_s$ es el vector de parámetros estimados del modelo usando las variables originales (estimador eficiente).


Otro método que se utiliza normalmente para detectar una potencial fuente de endogeneidad producto de la omisión de variables relevantes o de la mala especificación del modelo es el test de Ramsey para el siguiente modelo:

$$Y_i = \beta X_i + \delta_1 \hat{Y}_i^2 + \delta_2 \hat{Y}_i^3 + u_i \quad (5.94)$$

La hipótesis nula es $H_0 : \delta_1 = \delta_2 = 0$. Para testear esta hipótesis se usa el clásico test F . Si se rechaza la hipótesis nula, se concluye que habría endogeneidad por omisión de variables relevantes o por mala especificación del modelo.

5.5.5 Estimación bajo Endogeneidad

La forma más común de corregir el problema de endogeneidad es mediante el uso de variables instrumentales (VI). Una variable instrumental (o simplemente instrumento) es una variable que está altamente correlacionada con la variable X que presenta endogeneidad, pero incorrelacionada con el término de error.



Es importante notar que el estimador VI corrige el sesgo de endogeneidad, pero tiene mayor varianza. Luego, es un estimador consistente pero más ineficiente respecto a MCO.

Recordemos que el estimador de MCO es:

$$\hat{\beta} = (X^T X)^{-1} X^T Y = \beta + (X^T X)^{-1} X^T \varepsilon \quad (5.95)$$

Luego, si $X^T \varepsilon \neq 0$, el estimador MCO será sesgado. Definamos ahora a Z como un instrumento de X . Normalmente el rango de Z es igual al de X , aunque como veremos más adelante puede ser mayor, pero nunca menor. Es decir, el número de instrumentos debe ser igual o mayor al número de variables con endogeneidad.

El estimador de variables instrumentales (cuando el número de instrumentos es igual al número de variables con endogeneidad) se define como:

$$\hat{\beta}_{VI} = (Z^T X)^{-1} Z^T Y \quad (5.96)$$

Cuando una variable es exógena, se define como instrumento a la misma variable. De esta forma se asegura que el rango de las variables originales X y de las variables instrumentales Z sea al menos el mismo.

En este estimador se cumple:

$$\hat{\beta}_{VI} = (Z^T X)^{-1} Z^T Y = (Z^T X)^{-1} Z^T (X\beta + \varepsilon) \quad (5.97)$$

$$\hat{\beta}_{VI} = \beta + (Z^T X)^{-1} Z^T \varepsilon \quad (5.98)$$

De (5.98) se aprecia claramente que si Z es ortogonal a ε , el estimador $\hat{\beta}_{VI}$ será consistente. También se observa que mientras mayor sea la correlación entre Z y X , más rápido convergerá el estimador $\hat{\beta}_{VI}$ al parámetro poblacional β .

Un instrumento Z débil será aquel que presente una baja correlación con la variable X instrumentada.

Es interesante notar la siguiente relación:

$$\hat{\beta}_{VI} = \frac{\partial Y / \partial Z}{\partial Y / \partial X} = \frac{(Z^T Z)^{-1} Z^T Y}{(Z^T Z)^{-1} Z^T X} = (Z^T X)^{-1} Z^T Y \quad (5.99)$$

Cuando el rango de Z es mayor al de X (es decir, cuando hay más instrumentos que variables con endogeneidad), el instrumento se puede definir como:

$$\hat{\beta}_{VI} = (\hat{X}^T \hat{X})^{-1} \hat{X}^T Y \quad (5.100)$$

donde $\hat{X} = Z(Z^T Z)^{-1} Z^T X$ es la predicción de X usando como variables explicativas los instrumentos Z . Es decir, $\hat{X}$ se obtiene de resolver el siguiente modelo de regresión múltiple:

$$X = Z\theta + v \rightarrow \hat{\theta} = (Z^T Z)^{-1} Z^T X \rightarrow \hat{X} = Z\hat{\theta} \quad (5.101)$$

Este método se conoce con Mínimos Cuadrados en 2 Etapas: primero se estima $\hat{X}$, y luego se estima $\hat{\beta}_{VI}$.

Un instrumento se puede definir como débil si el R^2 obtenido del modelo (5.101) es estadísticamente pequeño, o si el test F de significancia conjunta de todos los parámetros θ es estadísticamente bajo.

De hecho, si el instrumento es muy débil, el método de VI puede generar estimadores incluso más inconsistentes que MCO.

5.6 Asimetría, Curtosis y Normalidad

5.6.1 Asimetría

Si una distribución es simétrica, el sesgo vale cero. Cuanto mayor es el valor absoluto del estadístico de asimetría, más sesgada es la distribución. Un valor positivo grande indica que la cola de la derecha de la distribución es "larga", y un valor negativo grande indica una cola izquierda "larga". La asimetría o sesgo poblacional se define como:

$$A = \frac{E(Y - \bar{Y})^3}{\sigma^3} \quad (5.102)$$

donde $\sigma = \sqrt{E(Y - \bar{Y})^2}$ e $\bar{Y} = E(Y)$. A partir de la muestra, la asimetría se estima de la siguiente manera:

$$\hat{A} = \frac{\frac{1}{N} \sum_{i=1}^N (Y_i - \bar{Y})^3}{\hat{\sigma}^3} \quad (5.103)$$

donde $\hat{\sigma} = \sqrt{\frac{1}{N} \sum_{i=1}^N (Y_i - \bar{Y})^2}$ e $\bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i$.

La distribución de este estimador es $\hat{A} \sim N\left(0; \frac{6}{N}\right)$, por lo que es factible construir el siguiente contraste:

$$\frac{\hat{A}}{\sqrt{6/N}} \sim N(0;1) \quad (5.104)$$

5.6.2 Curtosis

Es una variable aleatoria que mide el espesor de las colas de la curva de distribución, en relación con la distribución normal. La curtosis de una variable aleatoria normal es 3. Si la curtosis es mayor que 3, significa que las colas de la distribución son "gordas"; cuando ello ocurre, se dice que la distribución es **leptocúrtica**, e indica que la distribución tiene mayor masa de probabilidad en los extremos que la distribución normal. La distribución es **mesocúrtica**, se corresponde a una normal, y **platocúrtica** si las colas son "flacas". La curtosis poblacional se define como:

$$K = \frac{E(Y - \bar{Y})^4}{\sigma^4} \quad (5.105)$$

A partir de la muestra, la curtosis se estima de la siguiente manera:

$$\hat{K} = \frac{\frac{1}{N} \sum_{i=1}^N (Y_i - \bar{Y})^4}{\hat{\sigma}^4} \quad (5.106)$$

donde $\hat{\sigma} = \sqrt{\frac{1}{N} \sum_{i=1}^N (Y_i - \bar{Y})^2}$ e $\bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i$.

La distribución de este estimador es $\hat{K} \sim N\left(3; \frac{24}{N}\right)$, por lo que es factible construir el siguiente contraste:

$$\frac{\hat{K} - 3}{\sqrt{24/N}} \sim N(0;1) \quad (5.107)$$

5.6.3 Estadístico Jarque-Bera de Normalidad

Combina información sobre asimetría y curtosis para producir una prueba más general de normalidad:

$$JB = \frac{N-k}{6} \left(\hat{A}^2 + \frac{1}{4} (\hat{K} - 3)^2 \right) \sim \chi^2_{(2)} \quad (5.108)$$

De acuerdo a la hipótesis nula, que las observaciones son independientes y normalmente distribuidas, el estadístico JB sigue una distribución χ^2 con 2 grados de libertad (en muestras grandes).

5.7 Contrastes de Datos Atípicos

La hipótesis nula en este caso será que todos los datos provienen de la misma función de distribución multivariante.

Consideremos que existe una observación sospechosa de ser atípica x_i . La hipótesis nula será $H_0 : E(x_i) = \mu$, mientras que la alternativa será $H_1 : E(x_i) \neq \mu$.

Bajo H_1 , como la estimación de μ_i es x_i , la estimación de la varianza será:

$$V_i = \frac{1}{n-1} W_i \quad (5.109)$$

donde:

$$W_i = \sum_{j=1, (j \neq i)}^n \left[(x_j - \bar{x}_i)(x_j - \bar{x}_i)^T \right] \quad (5.110)$$

es la estimación de la suma de los cuadrados de los residuos, y $\bar{x}_i$ es la media de las observaciones, **en ambos casos eliminando la observación x_i** .

El contraste finalmente es el siguiente:

$$(x_j - \bar{x}_i)^T V_i^{-1} (x_j - \bar{x}_i) \sim \chi^2_p \quad (5.111)$$

Lo anterior implica que si la observación x_i está muy lejos de la media de las observaciones $\bar{x}_i$, que no consideran x_i , se rechaza la hipótesis nula de que la esperanza de x_i es igual a la media de los datos. En tal caso, x_i sí es una observación atípica que puede ser eliminada del proceso de estimación.

El problema de este método se da cuando existe más de una observación atípica, lo que genera una potencia muy baja del contraste. Una alternativa en tal caso puede ser identificar a priori las observaciones sospechosas, e ir incorporando de a una según el contraste (5.111). Evidentemente, se comenzará por aquella observación que presente el menor valor calculado de $(x_j - \bar{x}_i)^T V_i^{-1} (x_j - \bar{x}_i)$, y así sucesivamente.

6 INTRODUCCIÓN A LAS SERIES DE TIEMPO

Una serie de tiempo es una secuencia de observaciones o datos numéricos **ordenadas y equidistantes cronológicamente** sobre una característica de una unidad observable en diferentes períodos. La característica específica de una serie temporal es, por lo tanto, que las observaciones están ordenadas en el tiempo.

Hay casos en los que la variable observada tiene un patrón de comportamiento fijo; en términos estadísticos estamos ante una serie determinista. Por el contrario, hay otras series que resultan impredecibles. Su pauta de comportamiento no responde a un patrón fijo, por lo que son puramente aleatorias. Un ejemplo típico es la sucesión de números premiados en un sorteo de loterías. En general, las series económicas contienen una componente determinista y una componente aleatoria. La muestra está definida en este caso por un tamaño o longitud de N componentes consecutivos de Y_t .

6.1 Extrapolación de Series de Tiempo

Un modelo de series de tiempo es un método complejo de extrapolación de datos. Sin embargo, en determinadas ocasiones, debido a urgencias o poca disponibilidad de recursos, es factible utilizar métodos menos complejos. Estos son los denominados modelos deterministas.

En estos modelos no se hace referencia a la naturaleza aleatoria o estocástica de la serie. Proporcionan por lo tanto una alternativa simple, económica y en algunos casos aceptable de pronóstico.

6.1.1 Modelos de Extrapolación Simple

El modelo de extrapolación más simple es el modelo de tendencia lineal:

$$Y_t = a_1 + a_2 t \quad (6.1)$$

donde t es el tiempo y (a_1, a_2) son parámetros de calibración. El pronóstico para el período $t + l$ es $\hat{Y}_{t+l} = a_1 + a_2 (t + l)$.

Una segunda alternativa corresponde a una de crecimiento exponencial:

$$Y_t = c \cdot e^{rt} \quad (6.2)$$

donde (c, r) son parámetros de calibración. El pronóstico para el período $t + l$ es $\hat{Y}_{t+l} = c \cdot e^{r(t+l)}$. Los parámetros en este caso pueden estimarse aplicando logaritmos naturales a la expresión (6.2): $\ln Y_t = \ln c + rt \rightarrow \tilde{Y}_t = \tilde{c} + rt$.

Un tercer método de extrapolación es el de tendencia autoregresiva y su variación logarítmica:

$$Y_t = a_1 + a_2 Y_{t-1} \quad (6.3)$$

$$\ln Y_t = b_1 + b_2 \ln Y_{t-1} \quad (6.4)$$

Una cuarta alternativa corresponde al modelo con tendencia cuadrática:

$$Y_t = a_1 + a_2 t + a_3 t^2 \quad (6.5)$$

Modelos un poco más complejos corresponden a aquellos que presentan curvas logísticas:

$$Y_t = \frac{1}{c + ab^t} \quad (6.6)$$

donde (a, b, c) son parámetros de calibración. Al ser un modelo no lineal, debe estimarse con métodos no lineales.

Una curva logística alternativa más simple de estimar es la siguiente:

$$Y_t = e^{c_1 - (c_2/t)} \quad (6.7)$$

La estimación en este último caso se obtiene aplicando logaritmos de tal forma de obtener $\ln Y_t = c_1 - \frac{c_2}{t} \rightarrow \tilde{Y}_t = c_1 - c_2 \tilde{t}$.

6.1.2 Modelos de Promedio Móvil

Este modelo es útil cuando creemos que los valores probables a futuro son promedios de sus valores anteriores. A menudo es razonable suponer que los valores más recientes de la serie tienen un mayor impacto que los valores anteriores.

$$Y_t = \alpha \sum_{i=0}^{\infty} (1-\alpha)^i Y_{t-i} \quad (6.8)$$

En este caso se debe cumplir que $0 < \alpha \leq 1$. Si $\alpha = 1$ el pronóstico se vuelve $\hat{Y}_{T+1} = Y_T$, y nos olvidamos de los valores anteriores. A medida que α tome un menor valor, consideramos en mayor medida el impacto de valores anteriores. Debe notarse que $\alpha \sum_{i=0}^{\infty} (1-\alpha)^i = \frac{\alpha}{1-(1-\alpha)} = 1$, por lo que las ponderaciones suman uno.

Es importante notar que si la serie tiene una tendencia creciente, el modelo (6.8) subpredecirá los valores (y viceversa). Esto recomienda eliminar la tendencia antes de ajustar el modelo.

6.2 Suavizamiento de Series de Tiempo

Estas técnicas proporcionan un medio para reducir las fluctuaciones volátiles de las series de tiempo en el corto plazo. Una de las técnicas más simples de suavizamiento corresponde a considerar el promedio móvil de período n :

$$\tilde{Y}_t = \frac{1}{n} \sum_{i=0}^{n-1} Y_{t-i} \quad (6.9)$$

Entre mayor sea n , más suave será $\tilde{Y}_t$.

El suavizamiento exponencial corresponde a un promedio móvil ponderado exponencialmente para el suavizamiento:

$$\tilde{Y}_t = \alpha \sum_{i=0}^{\infty} (1-\alpha)^i Y_{t-i} \quad (6.10)$$

Si escribimos $(1-\alpha)\tilde{Y}_{t-1} = \alpha \sum_{i=1}^{\infty} (1-\alpha)^i Y_{t-i}$, y restamos esta expresión de la ecuación (6.10), se obtiene la siguiente fórmula recurrente:

$$\tilde{Y}_t = \alpha Y_t + (1-\alpha)\tilde{Y}_{t-1} \quad (6.11)$$

Notar que mientras más cerca está α de 1, mayor peso tiene la ponderación actual de Y_t al generar $\tilde{Y}_t$; valores pequeños de α , implican en cambio una serie más suavizada.

6.3 Estimación y Pronóstico de Modelos de Tendencia

Para ajustar los diversos modelos de tendencia de datos a una serie temporal, se usa la técnica de MCO:

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \sum_{t=1}^T (Y_t - T_t(\beta))^2 \quad (6.12)$$

donde β es el conjunto de parámetros a calibrar en el modelo y $T_t(\beta)$ es la tendencia que presenta la serie. El pronóstico de la serie, por su parte, se obtiene directamente del modelo calibrado:

$$\hat{Y}_{T+l} = T_{T+l}(\hat{\beta}) \quad (6.13)$$

Es interesante notar que la estimación correcta de MCO requiere que la media del error de pronóstico sea cero. El intervalo de confianza del pronóstico es en este caso, para un 95% de confiabilidad, el siguiente:

$$\hat{Y}_{T+l} \pm 1,96 \cdot \hat{\sigma}^2 \quad (6.14)$$

donde $\hat{\sigma}^2$ es la estimación de la desviación estándar de la perturbación de la tendencia. Luego, la densidad pronosticada es $\hat{Y}_{T+l} \sim N(Y_{T+l}; \hat{\sigma}^2)$.

6.4 Procesos Estocásticos

Un proceso estocástico es un conjunto de variables aleatorias correspondientes a distintos instantes de tiempo. Consecuentemente, una serie temporal puede considerarse como una realización muestral de las n variables aleatorias que forman su proceso estocástico generador. Es decir, la serie se forma a partir de un proceso estocástico.

La estructura probabilística de un proceso estocástico queda completamente definida por la distribución conjunta de las variables del mismo (por ejemplo una normal multivariada $f(Y_1, Y_2, \dots, Y_N)$). Evidentemente, para caracterizar empíricamente esta distribución conjunta, es necesario observar un cierto número de realizaciones del proceso. Este proceso de observación repetida **no siempre es posible**, por lo que suelen utilizarse hipótesis simplificadoras del proceso estocástico:

- Linealidad
- Estacionariedad
- Normalidad (Gaussiano)

El término gaussiano quiere decir que la distribución conjunta de las variables que forman el proceso estocástico es una normal multivariante, que puede ser caracterizada por sus correspondientes vectores de medias y matrices de varianzas-covarianzas (primeros y segundos momentos).

La caracterización de un proceso estocástico lineal gaussiano n -variante definido en estos términos aún requiere conocer o estimar el valor de n medias, n varianzas y $\frac{n \cdot (n-1)}{2}$ covarianzas, por lo que en la mayor parte de los casos prácticos es necesario recurrir a un supuesto simplificador adicional: el de estacionariedad.

6.5 Estacionariedad

6.5.1 Estacionariedad Estricta

Se dice que un proceso estocástico es estrictamente estacionario si la distribución conjunta de las variables que lo forman es función únicamente de los intervalos temporales que las separan. Así, el proceso Y_t es estrictamente estacionario para todo t si la función de distribución conjunta de (Y_i, Y_{i+k}) es la misma que la de (Y_j, Y_{j+k}) . Luego, **todos los momentos de la función de densidad** de la variable (de cualquier orden) son **constantes** en el tiempo.

6.5.2 Estacionariedad Débil

Un proceso es débilmente estacionario si su media es constante e independiente del tiempo, su varianza es finita y constante, y el valor de la covarianza entre dos periodos no depende del tiempo en el cual se ha calculado, sino de la distancia o desfase entre aquellos.

Luego, en una serie estacionaria se cumple:

$$E(Y_t) = \mu \quad (6.15)$$

$$V(Y_t) = \sigma^2 = \gamma_0 \quad (6.16)$$

$$\text{cov}(Y_t, Y_{t+k}) = \gamma_k, \quad \forall k \quad (6.17)$$

$$\rho_k = \frac{\text{cov}(Y_t, Y_{t+k})}{\sqrt{V(Y_t)}\sqrt{V(Y_{t+k})}} = \frac{\gamma_k}{\sqrt{\gamma_0}\sqrt{\gamma_0}} = \frac{\gamma_k}{\gamma_0}, \quad \forall k \quad (6.18)$$

Los modelos de predicción de series temporales están diseñados para procesos estacionarios. Si las características del proceso cambian a lo largo del tiempo, resultará difícil representar la serie para intervalos de tiempo pasados y futuros mediante un modelo lineal sencillo.

Sin embargo, por regla general, las series económicas no son series que proceden de procesos estacionarios, sino que suelen tener una tendencia creciente o decreciente, y variabilidad no constante.

Esta limitación no es tan importante porque, en la práctica, se pueden transformar las series no estacionarias en otras que sí lo son.

Un tipo de proceso estacionario particular es el denominado **ruido blanco**, formado por una **sucesión de variables aleatorias con distribución normal, esperanza cero, varianza constante e incorrelacionadas** entre sí. La variable aleatoria ε_t es ruido blanco para cualquier t si $\varepsilon_t \sim N(0, \sigma^2)$ y además $\text{cov}(\varepsilon_t, \varepsilon_{t+k}) = 0, \quad \forall k \neq 0$.

Luego, en un proceso ruido blanco se cumple $\gamma_k = 0$ y $\gamma_k = 0 \forall k \geq 1$. El interés de este de proceso radica en que, si sólo se cuenta con información muestral acerca de su propio pasado, no puede realizarse ninguna previsión mejor que su esperanza incondicional.

Por lo tanto, los procesos de ruido blanco de esperanza nula resultan útiles para caracterizar las propiedades ideales del término de error de un modelo estocástico dinámico.

6.5.3 Función de Autocorrelación Simple (FAS)

En la práctica se dispone de una muestra de un proceso estocástico, $Y_1, Y_2, \dots, Y_n$. Se pueden obtener los coeficientes de autocorrelación y, a partir de ellos, la función de autocorrelación:

$$\hat{\mu} = \frac{1}{n} \sum_{t=1}^n Y_t \quad (6.19)$$

$$\hat{\gamma}_0 = \frac{1}{n-1} \sum_{t=1}^n (Y_t - \hat{\mu})^2 \quad (6.20)$$

$$\hat{\gamma}_k = \frac{\sum_{t=1}^{n-k} (Y_t - \hat{\mu})(Y_{t+k} - \hat{\mu})}{n-k} \quad (6.21)$$

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}, \quad \forall k \quad (6.22)$$

La expresión $\hat{\rho}_k$ corresponde entonces a la **función de autocorrelación**.

Como medida de precisión de $\hat{\mu}$ se tiene que:

$$V(\hat{\mu}) = \frac{\gamma_0}{n} \left(1 + 2 \sum_{k=1}^{n-1} \left(1 - \frac{k}{n} \right) \rho_k \right) \quad (6.23)$$

Si el tamaño de la muestra es grande con respecto a k , dividir por n o por $n-k$ es prácticamente lo mismo, así como el cálculo de la media con n o con $n-k$ observaciones:

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} = \frac{\frac{\sum_{t=1}^{n-k} (Y_t - \hat{\mu})(Y_{t+k} - \hat{\mu})}{n-k}}{\frac{1}{n-1} \sum_{t=1}^n (Y_t - \hat{\mu})^2} \approx \frac{\sum_{t=1}^{n-k} (Y_t - \hat{\mu})(Y_{t+k} - \hat{\mu})}{\sum_{t=1}^n (Y_t - \hat{\mu})^2} \quad (6.24)$$

$$V(\hat{\rho}_k) \approx \frac{1}{n} \left(1 + 2 \sum_{i=1}^{k-1} \rho_i^2 \right) \quad (6.25)$$

La expresión (6.25) corresponde a la varianza aproximada bajo la hipótesis de normalidad del proceso generador de datos.

El estadístico Q de Box-Ljung permite contrastar la significancia conjunta de los coeficientes de autocorrelación muestral. Se define como:

$$Q(m) = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k} \sim \chi_{m-p-q}^2 \quad (6.26)$$

siendo m un número arbitrario utilizado en el cálculo.

Bajo la hipótesis nula de que la muestra haya sido generada por un proceso de ruido blanco, este estadístico se distribuye aproximadamente como una χ_{m-p-q}^2 .

El valor de m suele fijarse en tres veces la longitud del período estacional más tres retardos. De esta manera, para series trimestrales tendríamos $m = 15$ y para series mensuales $m = 39$. En el caso de datos que carecen de un período estacional definido, m se fija en un número "razonable", en función de la longitud de la muestra ($m = n/4$).

A veces resulta interesante contrastar individualmente la significación de los coeficientes de la FAS muestral. Para ello pueden compararse éstos con los valores $\pm \frac{2}{\sqrt{n}}$ que, aproximadamente, son los límites de un intervalo de confianza al 95% bajo la hipótesis nula de que el verdadero valor del coeficiente es cero. Luego, si un coeficiente está fuera del intervalo de confianza, se rechaza (aproximadamente) que su verdadero valor sea cero.

El interés de la FAS consiste en que sus coeficientes pueden interpretarse como una estimación del k -ésimo coeficiente de un modelo $MA(k)$. Si los datos han sido generados por un modelo $MA(q)$, sólo los primeros q coeficientes de autocorrelación simple serán distintos de cero, mientras que si los datos han sido generados por un modelo $AR(p)$, la FAS será infinita y tenderá a aproximarse a cero asintóticamente.

6.5.4 Función de Autocorrelación Parcial (FAP)

El coeficiente de autocorrelación parcial k -ésimo ϕ_k de la serie Y_t se define como el último coeficiente de una autorregresión de la variable centrada sobre sus últimos k valores. Es decir, corresponden a los parámetros del modelo de regresión lineal definido por $Y_t = \phi_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_k Y_{t-k} + \varepsilon_t$.

Puede demostrarse que los coeficientes teóricos de autocorrelación parcial pueden calcularse a partir de los coeficientes de autocorrelación simple resolviendo las ecuaciones de Yule-Walker expuestas en (6.27):

$$\phi_k = \frac{\det \begin{bmatrix} 1 & \rho_1 & \rho_2 & \dots & \rho_{k-2} & \rho_1 \\ \rho_1 & 1 & \rho_1 & \dots & \rho_{k-3} & \rho_2 \\ \rho_2 & \rho_1 & 1 & \dots & \rho_{k-4} & \rho_3 \\ \dots & & & & \dots & \dots \\ \rho_{k-2} & \rho_{k-3} & & & 1 & \rho_{k-1} \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \dots & \rho_1 & \rho_k \end{bmatrix}}{\det \begin{bmatrix} 1 & \rho_1 & \rho_2 & \dots & \rho_{k-2} & \rho_{k-1} \\ \rho_1 & 1 & \rho_1 & \dots & \rho_{k-3} & \rho_{k-2} \\ \rho_2 & \rho_1 & 1 & \dots & \rho_{k-4} & \rho_{k-3} \\ \dots & & & & \dots & \dots \\ \rho_{k-2} & \rho_{k-3} & & & 1 & \rho_1 \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \dots & \rho_1 & 1 \end{bmatrix}} \quad (6.27)$$

El interés de la FAP consiste en que sus coeficientes pueden interpretarse como una estimación del k -ésimo coeficiente de un modelo $AR(k)$. Consecuentemente, si los datos han sido generados por un modelo $AR(p)$, sólo los primeros p coeficientes de autocorrelación parcial serán distintos de cero. Por otra parte, si los datos han sido generados por un modelo $MA(q)$, la FAP será infinita y tenderá a aproximarse a cero asintóticamente.

6.5.5 Proceso Ruido Blanco

Se dice que un proceso Y_t es un proceso de ruido blanco si es estacionario en sentido débil y, además, $\gamma_k = 0 \quad \forall k \geq 1$. Corresponde al más simple de los procesos estacionarios.


El interés de este de proceso radica en que, si sólo se cuenta con información muestral acerca de su propio pasado, no puede realizarse ninguna previsión mejor que su esperanza incondicional.

Por tanto, los procesos de ruido blanco de esperanza nula resultan útiles para caracterizar las propiedades ideales del término de error de un modelo estocástico dinámico. Si Y_t es independiente e idénticamente distribuido con media cero y varianza constante, decimos entonces que es un ruido blanco gaussiano:

$$Y_t = \varepsilon_t \sim N(0, \sigma^2) \quad (6.28)$$

Tanto Y_t como ε_t no están correlacionados en el tiempo. Supondremos además que $\sigma^2 < \infty$. Un ejemplo de ruido blanco se presenta en la Figura 6.1:

Figura 6.1
Proceso Ruido Blanco $\sigma^2 = 2,3$



A continuación vamos a caracterizar este proceso estacionario, particularmente su estructura dinámica.

La media incondicional de Y_t es la siguiente:

$$E(Y_t) = E(\varepsilon_t) = 0 \quad (6.29)$$

y la varianza incondicional de Y_t es:

$$V(Y_t) = V(\varepsilon_t) = \sigma^2 = \gamma_0 \quad (6.30)$$

Dada la característica de estacionariedad, y que la función de autocovarianzas depende del espaciamiento y no del tiempo, se tendrá que:

$$\gamma_k = \begin{cases} \sigma^2, & \text{si } k = 0 \\ 0, & \forall k \geq 1 \end{cases} \quad (6.31)$$

Recordar que la varianza corresponde a la autocovarianza de orden cero. Además, dado que el ruido blanco es incorrelacionado en el tiempo, todas las autocovarianzas de orden superior a cero valen cero, como se expuso en (6.31). La función de autocorrelación es en este caso la siguiente:

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \begin{cases} 1, & \text{si } k = 0 \\ 0, & \forall k \geq 1 \end{cases} \quad (6.32)$$

Luego, la FAS y FAP valen cero siempre, excepto en $k = 0$. Este es un caso particular en que la FAS y la FAP coinciden.

En consecuencia, **pronosticar un proceso RB es imposible**. Sin embargo, es deseable que procesos que sí sean pronosticables, presenten un error RB.

Otra caracterización dinámica de los procesos puede realizarse a partir de sus momentos condicionados (en el pasado). Los momentos incondicionales requerían ser constantes para que el proceso sea estacionario; sin embargo, los momentos condicionales pueden que no lo sean.

En el caso del RB gaussiano, **los momentos incondicionales son idénticos a los condicionales**. Esto es consistente con que no nos sirve de nada la información pasado y presente para pronosticar en el futuro.

Para determinar si una serie es RB, podemos contrastar si todas sus autocorrelaciones de manera conjunta son cero. A partir de la ecuación:

$$\hat{\phi}_k \sim N\left(0; \frac{1}{n}\right) \quad (6.33)$$

se obtiene

$$\sqrt{n}\hat{\phi}_k \sim N(0;1) \quad (6.34)$$

$$n(\hat{\phi}_k)^2 \sim \chi_1^2 \quad (6.35)$$

Luego, recordando que suma de m variables χ_1^2 distribuyen χ_m^2 , bajo la hipótesis nula de que Y_t es RB se tendrá el estadístico de Box-Pierce:

$$Q_{BP} = n \sum_{k=1}^m \hat{\phi}_k^2 \sim \chi_m^2 \quad (6.36)$$

Notar que el estadístico de Box-Pierce (6.36) es igual al de Box-Liung (6.26), con la diferencia de que en este último la suma de las autocorrelaciones al cuadrado se reemplaza por una suma ponderada de las mismas autocorrelaciones. Cuando n es grande, ambos estadísticos difieren muy poco.

6.6 Ergodicidad

Diremos que un proceso es ergódico si **sus promedios estadísticos se pueden calcular a partir de una realización**; es decir, si sus promedios estadísticos coinciden con sus promedios temporales. Lo anterior implica que en un proceso ergódico, una única realización de Y_t nos provee información suficiente para estimar su media y sus autocovarianzas.

En un proceso estocástico **ergódico en varianza** los valores de la serie alejados en el tiempo están poco correlacionados, por lo que ρ_k decrece al aumentar el retardo k . Es decir, cuando la dependencia entre observaciones tiende a cero al aumentar el retardo, diremos que el proceso es ergódico en varianza.

El hecho de decir que el límite de una variable aleatoria coincide con una constante, se representa analíticamente así: sea $E(Y_t) = \frac{1}{2N} \int_{-N}^N Y(t) dt$; un proceso será ergódico en media si, con probabilidad 1, se cumple:

$$\lim_{N \rightarrow \infty} (E(Y_t)) = \mu \quad (6.37)$$

donde $E(Y_t)$ es una variable aleatoria con media $E(E(Y_t)) = \frac{1}{2N} \int_{-N}^N E[Y(t)] dt = \mu$ y por lo tanto:

$$\lim_{N \rightarrow \infty} (E(Y_t)) = \mu \Leftrightarrow \lim_{N \rightarrow \infty} (\sigma_t^2) = 0 \Leftrightarrow \lim_{N \rightarrow \infty} E[(E(Y_t) - \mu)^2] = 0 \quad (6.38)$$

Lo anterior implica que cuando la dependencia entre observaciones tiende a cero al aumentar el retardo, diremos que el proceso es ergódico. En adelante supondremos que los procesos estacionarios son ergódicos.

En el caso de variables discretas, la ergodicidad implica que:

$$\frac{1}{N} \sum_{t=1}^N Y_t \rightarrow E(Y_t) \quad (6.39)$$

$$\frac{1}{N-1} \sum_{t=1}^N (Y_t - E(Y_t))^2 \rightarrow V(Y_t) \quad (6.40)$$

6.7 Teorema de Wold

Si una serie es estacionaria en covarianza, no queda claro qué modelo debemos ajustarle para describir su evolución. El teorema de representación de Wold (1938) determina cuál es el proceso adecuado. Sea Y_t cualquier proceso estacionario en covarianza con media cero. Este proceso se puede representar como sigue:

$$Y_t = \sum_{i=0}^{\infty} \theta_i \varepsilon_{t-i} \quad (6.41)$$

Donde $\theta_0 = 1$ y $\sum_{i=0}^{\infty} \theta_i^2 < \infty$.

El teorema de Wold establece que cualquier proceso estacionario se puede representar como una suma ponderada de los residuos pasados. La expresión (6.41) se denomina **proceso lineal general**. Si un proceso estacionario no presenta media cero, simplemente se analiza la variable desviada respecto a su media: $y_t = Y_t - \bar{Y}$.

La media y varianza incondicional de (6.41) son las siguientes:

$$E(Y_t) = E\left(\sum_{i=0}^{\infty} \theta_i \varepsilon_{t-i}\right) = \sum_{i=0}^{\infty} \theta_i E(\varepsilon_{t-i}) = \sum_{i=0}^{\infty} \theta_i \cdot 0 = 0 \quad (6.42)$$

$$V(Y_t) = V\left(\sum_{i=0}^{\infty} \theta_i \varepsilon_{t-i}\right) = \left(\sum_{i=0}^{\infty} \theta_i^2 V(\varepsilon_{t-i})\right) = \sigma^2 \sum_{i=0}^{\infty} \theta_i^2 \quad (6.43)$$

A partir de (6.43) podríamos describir las funciones de autocovarianzas y autocorrelación, pero dicho cálculo es bastante tedioso y no muy revelador.

La media y varianza condicional de (6.41) son las siguientes, donde el conjunto de información disponible es $\Omega_{t-1} = (Y_{t-1}, Y_{t-2}, \dots, Y_0, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_0)$:

$$\begin{aligned} E(Y_t / \Omega_{t-1}) &= E(\varepsilon_t / \Omega_{t-1}) + \theta_1 E(\varepsilon_{t-1} / \Omega_{t-1}) + \theta_2 E(\varepsilon_{t-2} / \Omega_{t-1}) + \dots \\ E(Y_t / \Omega_{t-1}) &= 0 + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots = \sum_{i=1}^{\infty} \theta_i \varepsilon_{t-i} \end{aligned} \quad (6.44)$$

$$V(Y_t / \Omega_{t-1}) = E\left\{\left(Y_t - E(Y_t / \Omega_{t-1})\right)^2\right\} = E\left\{\left(\varepsilon_t / \Omega_{t-1}\right)^2\right\} = E(\varepsilon_t^2) = \sigma^2 \quad (6.45)$$

6.8 Retardos y Diferencias

6.8.1 Operador de Retardos

El operador de retardos L es un operador lineal tal que $L^i Y_t = Y_{t-i}$. Sus propiedades son las siguientes:

- $Lc = c$
- $(L^i + L^j)Y_t = L^i Y_t + L^j Y_t = Y_{t-i} + Y_{t-j}$
- $(L^i \cdot L^j)Y_t = L^i (L^j Y_t) = L^i Y_{t-j} = Y_{t-i-j}$
- $L^{-i}Y_t = Y_{t+i}$
- Para $|a| < 1$, $(1 + aL + a^2L^2 + \dots)Y_t = \sum_{i=0}^{\infty} a^i L^i Y_t = \frac{1}{1-aL} Y_t$

6.8.2 Operador de Diferencias

El operador de diferencias Δ es un operador tal que $\Delta Y_t = Y_t - Y_{t-1}$. Notar además que:

- $\Delta Y_t = (1 - L)Y_t$
- $\Delta^2 Y_t = Y_t - 2Y_{t-1} + Y_{t-2}$

6.9 Ecuaciones de Diferencias

6.9.1 Definición

Una ecuación de diferencias (en nuestro caso lineal y finita) se puede definir como una expresión que relaciona el valor de una variable en el momento presente (Y_t) con momentos pasados de la misma:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} \quad (6.46)$$

Notar que la relación entre la variable y sus retardos es lineal. Las ecuaciones de diferencia pueden presentar términos adicionales:

$$Y_t = f(t) + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} \quad (6.47)$$

Posibles expresiones de la función "forzadora" $f(t)$ son:

- $f(t) = \mu$

- $f(t) = \mu + \beta t$
- $f(t) = \varepsilon_t$
- $f(t) = \mu + \beta t + \theta(L)\varepsilon_t$

Las dos primeras expresiones son determinísticas, y las dos segundas son estocásticas. Las ecuaciones de diferencias finitas pueden ser resueltas mediante forma recursiva o mediante resoluciones analíticas más complejas.

6.9.2 Solución Recursiva

La solución consiste en sustituir de manera recursiva los valores pasados de la variable por otros valores (también pasados) de tal forma de expresar la variable en función de las condiciones iniciales del proceso y de la función $f(t)$. Por ejemplo:

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t \quad (6.48)$$

$$Y_t = \phi_1^2 Y_{t-2} + \varepsilon_t + \phi_1 \varepsilon_{t-1} \quad (6.49)$$

$$Y_t = \phi_1^3 Y_{t-3} + \varepsilon_t + \phi_1 \varepsilon_{t-1} + \phi_1^2 \varepsilon_{t-2} \quad (6.50)$$

.....

$$Y_t = \phi_1^t Y_0 + \sum_{i=0}^{t-1} \phi_1^i \varepsilon_{t-i} \quad (6.51)$$

Luego, conocidos los valores de ϕ_1^i , Y_0 y ε_{t-i} , podremos determinar el valor de Y_t . Sin embargo, este método no siempre resulta ser el más conveniente, y es aplicable a pocos casos.

6.9.3 Solución Analítica

Una segunda alternativa corresponde a encontrar la solución general de la ecuación, que denominaremos Y_t^g . La solución general está definida como la suma de la solución homogénea Y_t^h y de la solución particular Y_t^p :

$$Y_t^g = Y_t^h + Y_t^p \quad (6.52)$$

La solución homogénea Y_t^h no es única, pero la solución particular Y_t^p sí.

a) Solución Homogénea

La solución homogénea se obtiene a partir del planteamiento de la ecuación de diferencias y resolviendo la denominada ecuación característica. El sistema homogéneo considera únicamente los retardos, y no la función $f(t)$.

Sin pérdida de generalidad, vamos a proponer una sencilla transformación que permite obtener la llamada solución general para el sistema homogéneo de cualquier ecuación en diferencias ordinaria, lineal, de diferencias finitas y de coeficientes constantes.

Supongamos el caso más sencillo de todos, una ecuación genérica de primer orden del tipo:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \varepsilon_t \quad (6.53)$$

El sistema homogéneo es en este caso el siguiente:

$$Y_t - \phi_1 Y_{t-1} = 0 \quad (6.54)$$

Aplicando el operador de rezagos se puede obtener el polinomio característico:

$$(1 - \phi_1 L) Y_t = 0 \rightarrow \lambda - \phi_1 = 0 \quad (6.55)$$

Esta ecuación (6.55) se denomina ecuación característica y a sus soluciones raíces características. Realizando el cambio de variable $Y_t = \lambda^t$, la solución (raíz característica) de esta ecuación será $\lambda = \phi_1$.

La solución homogénea se define como la función suma de las raíces del polinomio característico elevadas a t ; en este caso es:

$$Y_t^h = A \phi_1^t \quad (6.56)$$

siendo A una constante ($A \in \mathbb{R}^2$). Notar que $A \phi_1^t$ es solución de la homogénea.

En el caso de segundo orden se obtiene:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t \quad (6.57)$$

$$Y_t - \phi_1 Y_{t-1} - \phi_2 Y_{t-2} = 0 \quad (6.58)$$

$$\lambda^2 - \phi_1 \lambda - \phi_2 = 0 \quad (6.59)$$

$$\lambda^* = \begin{cases} \frac{\phi_1 + \sqrt{\phi_1^2 + 4\phi_2}}{2} \\ \frac{\phi_1 - \sqrt{\phi_1^2 + 4\phi_2}}{2} \end{cases} \quad (6.60)$$

Si todas las raíces son diferentes, la solución homogénea será:

$$Y_t^h = A_1 \lambda_1^t + A_2 \lambda_2^t \quad (6.61)$$

No obstante, si las raíces del polinomio característico presentan multiplicidad (raíces iguales), la solución homogénea habrá que buscarla como:

$$Y_t^h = A_1 \lambda^t + A_2 \lambda^t t + \underbrace{\left(A_3 \lambda^t t^2 + \dots + A_{m+1} \lambda^t t^m \right)}_{\text{caso general con } (m+1) \text{ soluciones iguales}} \quad (6.62)$$

Los valores de los coeficientes A_i se pueden obtener directamente si se dispone de las condiciones iniciales de Y_t y resolviendo luego un sistema lineal de ecuaciones.

Supongamos por ejemplo la siguiente ecuación de diferencias finita:

$$Y_t = 0,6 Y_{t-1} - 0,08 Y_{t-2} \quad (6.63)$$

El polinomio característico es:

$$\lambda^2 - 0,6\lambda + 0,08 = 0 \quad (6.64)$$

Luego, las raíces características son $\lambda_1 = 0,2$ y $\lambda_2 = 0,4$, con multiplicidad igual a 1. La solución homogénea es:

$$Y_t^h = A_1 (0,2)^t + A_2 (0,4)^t \quad (6.65)$$

Considerando como segundo ejemplo la siguiente ecuación de diferencias:

$$Y_t = 4Y_{t-1} - 4Y_{t-2} \quad (6.66)$$

El polinomio característico es:

$$\lambda^2 - 4\lambda + 4 = 0 \quad (6.67)$$

Luego, las raíces características son $\lambda_1 = 2 = \lambda_2$, por lo que se tiene multiplicidad igual a 2. La solución homogénea es en este segundo caso:

$$Y_t^h = A_1 (2)^t + A_2 (2)^t \cdot t \quad (6.68)$$

Si por ejemplo $Y_0 = 1$ e $Y_{-1} = 3$, se puede plantear el siguiente sistema de ecuaciones:

$$1 = A_1 (2)^0 + A_2 (2)^0 \cdot 0 \quad (6.69)$$

$$3 = A_1 (2)^{-1} + A_2 (2)^{-1} \cdot (-1) \quad (6.70)$$

de donde finalmente se obtiene $A_1 = 1$ y $A_2 = -5$. Notar que es factible obtener soluciones complejas para las raíces características.

b) Solución Particular

La solución particular atenderá a la porción de la ecuación no considerada en el sistema homogéneo. Luego, depende de la función forzadora $f(t)$.

Vamos a considerar primero el caso en el que el sistema NO contiene componentes estocásticos. La forma de encontrar con rapidez la solución particular es asumir que Y_t **se comporta de forma análoga a la parte no homogénea de la ecuación original**, parte no homogénea que denominaremos $g(t)$. Existen varios casos, como se presenta a continuación:

- **Caso 1:** $g(t) = \phi_0$

El caso ilustrado anteriormente con el ejemplo numérico es una situación particular de un caso genérico del tipo:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} \quad (6.71)$$

Si asumimos que Y_t se comportará como la parte no homogénea $g(t)$ estamos asumiendo la constancia de Y_t , es decir:

$$Y_t = g(t) \rightarrow Y_t = Y \quad (6.72)$$

Si sustituimos $Y_t = Y$ en la ecuación original (6.71) obtenemos la solución particular que, en este caso, será igual a una constante:

$$Y = \phi_0 + \phi_1 Y + \phi_2 Y + \dots + \phi_p Y \rightarrow Y_t^p = \frac{\phi_0}{1 - \phi_1 - \phi_2 - \dots - \phi_p} \quad (6.73)$$

Esta solución representa precisamente el valor de convergencia de Y_t para infinitas observaciones, siempre y cuando estemos hablando de un proceso Y_t estacionario. Es por eso por lo que, a veces, se define la solución particular como el punto de equilibrio del proceso a largo plazo. Notar que el resultado anterior no es válido si $\sum_{i=1}^p \phi_i = 1$.

- **Caso 2:** $g(t) = b \cdot t$

La ecuación genérica sería ahora:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + b \cdot t \quad (6.74)$$

lo que equivale a introducir en el proceso estocástico una **tendencia determinística**.

En este caso, asumiendo de nuevo que Y_t se comporta como $g(t)$ debemos considerar que Y_t será también una función del tiempo:

$$g(t) = \phi_0 + b \cdot t \rightarrow Y_t = \alpha + \beta \cdot t \quad (6.75)$$

Sustituyendo Y_t y $g(t)$ en (6.74) obtenemos:

$$(\alpha + \beta t) - \phi_1 (\alpha + \beta(t-1)) - \phi_2 (\alpha + \beta(t-2)) - \dots - \phi_p (\alpha + \beta(t-p)) = \phi_0 + b \cdot t \quad (6.76)$$

$$\alpha^* = \frac{\phi_0 - \beta(\phi_1 + 2\phi_2 + \dots + p\phi_p)}{1 - \phi_1 - \phi_2 - \dots - \phi_p} \quad (6.77)$$

$$\beta^* = \frac{b}{1 - \phi_1 - \phi_2 - \dots - \phi_p} \quad (6.78)$$

$$Y_t^p = \alpha^* + \beta^* \cdot t \quad (6.79)$$

- **Caso 3:** $g(t) = b \cdot d^t$

La ecuación genérica sería ahora:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + b \cdot d^t \quad (6.80)$$

El patrón será ahora:

$$Y_t = \alpha \cdot d^t \quad (6.81)$$

Resolviendo obtenemos:

$$\alpha^* = \frac{b}{1 - \phi_1 d^{-1} - \phi_2 d^{-2} - \dots - \phi_p d^{-p}} \quad (6.82)$$

$$Y_t^p = \alpha^* d^t \quad (6.83)$$

Ahora consideraremos el caso en que la función forzadora $f(t)$ es estocástica:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} \quad (6.84)$$

$$\phi_p(L)Y_t = \theta_q(L)\varepsilon_t \rightarrow Y_t = \frac{\theta_q(L)}{\phi_p(L)}\varepsilon_t \quad (6.85)$$

En el caso de un proceso AR(1) se tendrá:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \varepsilon_t \quad (6.86)$$

La solución homogénea ya es conocida: $Y_t^h = A_1 (\phi_1)^t$. La solución particular en este caso es de la forma: $Y_t^p = b_0 + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i} \rightarrow Y_t^p = \frac{\phi_0}{1 - \phi_1} + \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i}$.

Luego, la solución general es:

$$Y_t^g = A_1 (\phi_1)^t + \frac{\phi_0}{1 - \phi_1} + \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i} \quad (6.87)$$

Dado que $Y_0 = A_1 + \frac{\phi_0}{1-\phi_1} + \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i}$, se tendrá $A_1 = Y_0 - \frac{\phi_0}{1-\phi_1} - \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i}$.

Luego, resulta entonces:

$$Y_t^g = \underbrace{\left[Y_0 - \frac{\phi_0}{1-\phi_1} - \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i} \right]}_{\text{Sol-Homog}} (\phi_1)^t + \underbrace{\left(\frac{\phi_0}{1-\phi_1} + \sum_{i=0}^{\infty} \phi_1^i \varepsilon_{t-i} \right)}_{\text{Sol-Part}} \quad (6.88)$$

Notar que esta solución es válida sólo si $\phi_1 \neq 1$, es decir, no existe raíz unitaria (proceso no estacionario). En tal caso, la solución particular sería:

$$Y_t^p = Y_0 + \phi_0 \cdot t + \sum_{i=0}^{\infty} \varepsilon_{t-i} \quad (6.89)$$

Se observa que la presencia de la tendencia determinista $\phi_0 \cdot t$ domina el proceso de evolución del proceso a lo largo del tiempo.

En general, para cualquier proceso lineal con variables y errores rezagados (6.84), la solución particular se puede obtener de la proposición:

$$Y_t^p = b_0 + b_1 \cdot t + \sum_{i=0}^{\infty} \psi_i^t \varepsilon_{t-i} \quad (6.90)$$

Luego, sustituyendo los valores de (6.90) en (6.84) se obtienen los valores de los parámetros β_0 , β_1 y ψ_i .

6.10 Círculo Unitario

Un proceso autorregresivo será estacionario (convergente en términos de su solución analítica) si sus raíces caen dentro del círculo unitario, o si las raíces de su polinomio de retardos caen fuera del mismo.

Efectivamente, en un proceso autoregresivo de orden 2, la solución homogénea tiene la forma general:

$$Y_t^h = A_1 (\lambda_1)^t + A_2 (\lambda_2)^t \xrightarrow{\text{(Teorema de Moivre)}} Y_t^h = A \cdot r^t \cdot \text{sen}(wt + \alpha) \quad (6.91)$$

donde A_1 y A_2 son las constantes arbitrarias habituales que dependen de las condiciones de borde (iniciales en nuestro caso), y λ_1 y λ_2 son las raíces características.

El parámetro “ r ” es lo que se denomina módulo o valor absoluto del número complejo, y “ w ” representa lo que se denomina frecuencia angular y define el número de ciclos por unidad de tiempo, es decir, la inversa del período. La frecuencia se mide en radianes e indica el número de ciclos que hay por unidad de tiempo, y está elegida de forma que satisfaga simultáneamente la expresión:

$$\cos(w) = \frac{\phi_1}{2\sqrt{-\phi_2}} \quad (6.92)$$

El parámetro α representa lo que se denomina fase, que viene a indicar la situación del ciclo en cada momento del tiempo.

Sin entrar en el desarrollo completo, esta transformación parte de la expresión de las raíces características en forma polar. Para ello deben realizarse las siguiente transformaciones:

$$\lambda = r \cdot \cos(w); \theta = r \cdot \text{sen}(w) \rightarrow \lambda^2 + \theta^2 = r^2 \quad (6.93)$$

$$\text{Luego, } r^2 = -\phi_1 \rightarrow r = \sqrt{-\phi_1}.$$

Continuando con el análisis, y dada la forma general (7.78), está claro que la convergencia (estacionariedad) de la ecuación en diferencias (proceso autorregresivo) pasa por que λ_1 y λ_2 sean menores que la unidad, o más estrictamente, que λ_1 y λ_2 deben caer dentro de un círculo unitario (y no simplemente que deben ser menores que 1).

La razón es que cuando λ_1 y λ_2 son enteras, bastaría una recta para representarlas, por lo que el "círculo", es decir las dos dimensiones, serían innecesarias; pero cuando λ_1 y λ_2 son imaginarias, necesitamos una representación en dos ejes, uno real y otro imaginario, para representar raíces imaginarias del tipo:


$$\lambda^* = \begin{cases} \frac{\phi_1 + \sqrt{\phi_1^2 + 4\phi_2}}{2} = \frac{\phi_1 + i\sqrt{-d}}{2} \\ \frac{\phi_1 - \sqrt{\phi_1^2 + 4\phi_2}}{2} = \frac{\phi_1 - i\sqrt{-d}}{2} \end{cases} \quad (6.94)$$

Si usamos la representación real/imaginaria, cada una de las raíces características vendrá representada por una coordenada del tipo:

$$\lambda^* = \begin{cases} \left(\frac{\phi_1}{2}, +\frac{i\sqrt{-d}}{2} \right) \\ \left(\frac{\phi_1}{2}, -\frac{i\sqrt{-d}}{2} \right) \end{cases} \quad (6.95)$$

Es decir, una será la conjugada de la otra. La condición de convergencia en el caso de raíces imaginarias obliga a que el parámetro r de amplitud sea menor que la unidad en valor absoluto. Este parámetro es precisamente la distancia que separará las soluciones λ_1 y λ_2 del origen del plano real/imaginario sean cuales sean estas.

Luego, necesariamente el par de soluciones λ_1 y λ_2 deberá estar dentro de un círculo unitario como en el que se muestra en la ilustración presentada a continuación.



Cuando las soluciones son reales, basta el eje horizontal (real) para representarlas; cuando son imaginarias, deben "caer dentro del círculo unitario" ya que de otra forma el radio " r " sería superior a 1 y la solución no sería convergente.

7 PROCESOS MEDIA MÓVIL

En los procesos de media móvil de orden q , cada observación Y_t es generada por una media ponderada de perturbaciones aleatorias, con un retardo de q periodos. Se simboliza por $MA(q)$:

$$Y_t = \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (7.1)$$

donde δ es un término constante y ε_t es una variable ruido blanco.

El proceso de media móvil de orden finito es una aproximación natural y obvia de la representación de Wold.

7.1 Procesos MA(1)


El proceso de media móvil de primer orden o $MA(1)$ es:

$$Y_t = \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} = \delta + (1 + \theta_1 L) \varepsilon_t \quad (7.2)$$

donde ε_t es una variable ruido blanco: $\varepsilon_t \sim N(0; \sigma_\varepsilon^2)$.

La característica que describe al proceso MA y en particular al $MA(1)$ es que el valor actual de la serie observada se expresa como función de choques actuales y rezagados inobservables.

Dependiendo del signo de θ_1 , los choques anteriores alimentarán positiva o negativamente el valor actual de la serie. Sin embargo, un mayor valor de θ_1 no se traduce en una mayor persistencia de los choques pasados, como podría pensarse. El proceso $MA(1)$ tiene muy poca memoria, independiente del valor del parámetro θ_1 .

Figura 7.1**Relación de 2 Procesos MA(1): $\theta_1 = 0,4$ vs $\theta_1 = 0,9$ y $\varepsilon_t \sim N(0;1)$** 

Cuando θ_1 tiene un mayor valor, la varianza incondicional aumenta; sin embargo, la dinámica del proceso es la misma en ambos casos (poca memoria).

Los momentos incondicionales de un proceso MA(1) son los siguientes:

$$E(Y_t) = E(\delta) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1}) = \delta \quad (7.3)$$

$$V(Y_t) = V(\delta) + V(\varepsilon_t) + \theta_1^2 V(\varepsilon_{t-1}) = \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 = \sigma_\varepsilon^2 (1 + \theta_1^2) = \gamma_0 \quad (7.4)$$

$$\text{cov}(Y_t, Y_{t-1}) = E[(Y_{t-1} - \delta)(Y_t - \delta)] = E[(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2})(\varepsilon_t + \theta_1 \varepsilon_{t-1})] \quad (7.5)$$

$$\text{cov}(Y_t, Y_{t-1}) = \gamma_1 = \theta_1 \sigma_\varepsilon^2 \quad (7.6)$$

$$\text{cov}(Y_t, Y_{t-2}) = \gamma_2 = 0 \quad (7.7)$$

En general, $\gamma_k = 0$ para $k > 1$. Se dice que el proceso tiene una memoria de sólo un período.

Cualquier valor de Y_t está correlacionado con Y_{t-1} e Y_{t+1} , pero con ningún otro valor de la serie.

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1 \quad (7.8)$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{\theta_1}{1 + \theta_1^2} \quad (7.9)$$

$$\rho_k = \frac{\gamma_k}{\gamma_0} = 0, \quad \forall k > 1 \quad (7.10)$$

Un modelo MA(1) siempre es **estacionario** independiente del valor de θ_1 .

Por otra parte, los momentos condicionales de un proceso MA(1) son los siguientes ($\Omega_{t-1} = (\varepsilon_{t-1}, \varepsilon_{t-2}, \dots)$):

$$E(Y_t / \Omega_{t-1}) = E(\delta) + E(\varepsilon_t / \Omega_{t-1}) - \theta_1 E(\varepsilon_{t-1} / \Omega_{t-1}) = \delta + \theta_1 \varepsilon_{t-1} \quad (7.11)$$

$$V(Y_t / \Omega_{t-1}) = E[Y_t - E(Y_t / \Omega_{t-1})]^2 = E(\varepsilon_t^2 / \Omega_{t-1}) = \sigma_\varepsilon^2 \quad (7.12)$$

Se observa que la media condicional se adapta en forma explícita al conjunto de información, a diferencia de la media incondicional (8.3) que es constante. El hecho de que la media condicional considere sólo el primer rezago del choque, es indicativo de la memoria del proceso, que también está caracterizada por la función de autocorrelación.

Figura 7.2
Correlograma Simple $\theta_1 > 0$





Figura 7.3
Correlograma Simple $\theta_1 < 0$



Si además $|\theta_1| < 1$, se dice que el proceso es invertible. En dicho caso, podemos expresar el proceso en términos de un choque actual y valores rezagados de la serie en lugar de un choque actual y uno rezagado. A esto se le denomina representación autoregresiva (ver sección 8.4)

7.2 Procesos MA(2)

En este caso, la representación de momentos no condicionales es la siguiente:

$$Y_t = \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} \quad (7.13)$$

$$E(Y_t) = \delta \quad (7.14)$$

$$V(Y_t) = \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 + \theta_2^2 \sigma_\varepsilon^2 = \sigma_\varepsilon^2 (1 + \theta_1^2 + \theta_2^2) = \gamma_0 \quad (7.15)$$

$$\text{cov}(Y_t, Y_{t-1}) = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \theta_2 \varepsilon_{t-3})] \quad (7.16)$$

$$\text{cov}(Y_t, Y_{t-1}) = \gamma_1 = \sigma_\varepsilon^2 (\theta_1 + \theta_1 \theta_2) \quad (7.17)$$

$$\text{cov}(Y_t, Y_{t-2}) = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3} + \theta_2 \varepsilon_{t-4})] \quad (7.18)$$

$$\text{cov}(Y_t, Y_{t-2}) = \gamma_2 = \theta_2 \sigma_\varepsilon^2 \quad (7.19)$$

$$\text{cov}(Y_t, Y_{t-3}) = \gamma_3 = 0 \quad (7.20)$$

En general, $\gamma_k = 0$ para $k > 2$.

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1 \quad (7.21)$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{\theta_1 + \theta_1 \theta_2}{1 + \theta_1^2 + \theta_2^2} \quad (7.22)$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{\theta_2}{1 + \theta_1^2 + \theta_2^2} \quad (7.23)$$

$$\rho_k = \frac{\gamma_k}{\gamma_0} = 0, \quad \forall k \geq 3 \quad (7.24)$$

Un modelo MA(2) siempre es estacionario con independencia del valor de sus parámetros, y su memoria es de dos periodos.

7.3 Procesos MA(q)

En este caso, la representación es la siguiente:

$$Y_t = \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (7.25)$$

$$E(Y_t) = \delta \quad (7.26)$$

$$V(Y_t) = \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 + \dots + \theta_q^2 \sigma_\varepsilon^2 = \sigma_\varepsilon^2 (1 + \theta_1^2 + \dots + \theta_q^2) = \gamma_0 \quad (7.27)$$

$$\text{cov}(Y_t, Y_{t-1}) = \gamma_1 = \sigma_\varepsilon^2 (\theta_1 + \theta_1 \theta_2 + \theta_2 \theta_3 + \dots + \theta_{q-1} \theta_q) \quad (7.28)$$

$$\text{cov}(Y_t, Y_{t-2}) = \gamma_2 = \sigma_\varepsilon^2 (\theta_2 + \theta_1 \theta_3 + \theta_2 \theta_4 + \dots + \theta_{q-2} \theta_q) \quad (7.29)$$

.....

$$\text{cov}(Y_t, Y_{t-q}) = \gamma_q = \theta_q \sigma_\varepsilon^2 \quad (7.30)$$

En general, $\gamma_k = 0$ para $k > q$. Los coeficientes de autocorrelación pueden ser obtenidos a partir de las autocovarianzas. Todos los procesos MA de orden finito son estacionarios.

7.4 Invertibilidad de los Procesos MA(q)

Cualquier proceso MA(q) puede expresarse como un AR(∞). Un modelo MA(1):

$$Y_t = \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (7.31)$$

$$Y_{t-1} = \delta + \varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} \quad (7.32)$$

$$Y_{t-2} = \delta + \varepsilon_{t-2} + \theta_1 \varepsilon_{t-3} \quad (7.33)$$

.....

Despejando ε_t , ε_{t-1} , ε_{t-2} , etc. se obtiene:

$$\varepsilon_t = -\delta + Y_t - \theta_1 \varepsilon_{t-1} \quad (7.34)$$

$$\varepsilon_t = -\delta + Y_t - \theta_1 (-\delta + Y_{t-1} - \theta_1 (\varepsilon_{t-2})) = -\delta + Y_t - \theta_1 Y_{t-1} + \delta \theta_1 + \theta_1^2 (\varepsilon_{t-2}) \quad (7.35)$$

$$\varepsilon_t = -\delta + Y_t - \theta_1 Y_{t-1} + \delta \theta_1 + \theta_1^2 (-\delta + Y_{t-2} - \theta_1 \varepsilon_{t-3}) \quad (7.36)$$

etc.

Si continuamos eliminando ε_{t-3} y siguientes, el procedimiento continuará hasta el infinito. Esto lleva a expresar Y_t como función de sus valores retardados más una constante y un término de error:

$$Y_t = \mu + \varepsilon_t - \theta_1 Y_{t-1} + \theta_1^2 Y_{t-2} - \theta_1^3 Y_{t-3} + \dots \quad (7.37)$$

$$Y_t = \mu + \varepsilon_t + \sum_{i=1}^{\infty} (-1)^i \theta_1^i Y_{t-i} \quad (7.38)$$

Esto tiene sentido si $|\theta_1| < 1$, ya que, de otro modo, el efecto del pasado sería más importante para explicar el comportamiento actual. Lo más lógico es pensar que el efecto del pasado va siendo cada vez menor y el proceso es invertible.

Si $|\theta_1| = 1$, es un caso límite de invertibilidad, en el que el efecto se mantiene constante con el retardo.

Para un modelo MA(2), la condición de invertibilidad es $|L| > 1$ en el polinomio $1 - \theta_1 L - \theta_2 L^2 = 0$. Para un modelo MA(q), la condición de invertibilidad es $|L| > 1$ en el polinomio $1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q = 0$. Considerar el módulo es importante, ya que pueden generarse raíces complejas.

Debido a que el proceso MA(q) se puede expresar como un AR(∞), consta de infinitos coeficientes de autocorrelación parcial distintos de cero, aunque a partir del valor q decaerán rápidamente. Así, la FAP de un proceso MA se comporta de manera análoga a como lo hace la FAS en un AR.

7.5 Estimación de Procesos MA(q)

En este caso, debido a que los errores no son función lineal de los parámetros (no se cumple el supuesto de linealidad requerido para utilizar MCO), la estimación se resuelve mediante métodos numéricos.

Analicemos el caso de un MA(1):

$$Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} \rightarrow \varepsilon_t = Y_t - \theta_1 \varepsilon_{t-1} \quad (7.39)$$

$$\hat{\varepsilon}_t = Y_t - \hat{Y}_t = Y_t - \hat{\theta}_1 \varepsilon_{t-1} \quad (7.40)$$

En forma recursiva se obtiene:

$$\varepsilon_1 = Y_1 - \theta_1 \varepsilon_0 \quad (7.41)$$

$$\varepsilon_2 = Y_2 - \theta_1 \varepsilon_1 = Y_2 - \theta_1 (Y_1 - \theta_1 \varepsilon_0) = Y_2 - \theta_1 Y_1 + \theta_1^2 \varepsilon_0 \quad (7.42)$$

$$\varepsilon_3 = Y_3 - \theta_1 \varepsilon_2 = Y_3 - \theta_1 (Y_2 - \theta_1 Y_1 + \theta_1^2 \varepsilon_0) = Y_3 - \theta_1 Y_2 + \theta_1^2 Y_1 - \theta_1^3 \varepsilon_0 \quad (7.43)$$

.....

$$\varepsilon_n = \sum_{i=0}^{n-1} (-1)^i \theta_1^i Y_{n-i} + (-1)^n \theta_1^n \varepsilon_0 \quad (7.44)$$

El término de error no es función lineal del parámetro a diferencia de lo que sucede con los modelos autorregresivos. El modelo se puede estimar a través de un proceso iterativo de estimación no lineal, que utiliza los dos primeros términos de la aproximación de ε_t a través del desarrollo en serie de Taylor (se consideran despreciables los términos de segundo orden y superior).

$$\varepsilon_t \approx \varepsilon_t^0 + \frac{\partial \varepsilon_t(\theta_1^0)}{\partial \theta_1}(\theta_1 - \theta_1^0) \quad (7.45)$$

El parámetro ε_t^0 es el valor que toma el residuo después de sustituir θ_1 por el valor inicial θ_1^0 en (7.44). Esto implica que se requiere un valor inicial de este parámetro.

En este caso se tiene que $\frac{\partial \varepsilon_t}{\partial \theta_1} = -\varepsilon_{t-1}$, por lo que se cumple:

$$\varepsilon_t \approx \varepsilon_t^0 - (\theta_1 - \theta_1^0) \varepsilon_{t-1}^0 \quad (7.46)$$

Luego, reemplazando $x_t = -\varepsilon_{t-1}^0$ y $z_t = \varepsilon_t^0 + \theta_1^0 \varepsilon_{t-1}^0$ se obtiene:

$$z_t = \theta_1 x_t + \varepsilon_t \quad (7.47)$$

La expresión (7.47) es una ecuación de regresión lineal que se puede estimar directamente mediante MCO. Luego, la estimación $\hat{\theta}_1$ constituye la primera iteración del proceso. Este valor se utiliza para realizar una segunda iteración, como valor inicial, y así sucesivamente hasta que $|\hat{\theta}_1^h - \hat{\theta}_1^{h-1}| < \alpha$.

En el caso de un MA(2) la aproximación en series de Taylor sería:

$$\varepsilon_t \approx \varepsilon_t^0 + \frac{\partial \varepsilon_t(\theta_1^0, \theta_2^0)}{\partial \theta_1}(\theta_1 - \theta_1^0) + \frac{\partial \varepsilon_t(\theta_1^0, \theta_2^0)}{\partial \theta_2}(\theta_2 - \theta_2^0) \quad (7.48)$$

donde $\frac{\partial \varepsilon_t}{\partial \theta_1} = \varepsilon_{t-1}$ y $\frac{\partial \varepsilon_t}{\partial \theta_2} = \varepsilon_{t-2}$. Luego se obtiene:

$$\varepsilon_t \approx \varepsilon_t^0 + \varepsilon_{t-1}^0(\theta_1 - \theta_1^0) + \varepsilon_{t-2}^0(\theta_2 - \theta_2^0) \quad (7.49)$$

Reemplazando $x_t^1 = -\varepsilon_{t-1}^0$, $x_t^2 = -\varepsilon_{t-2}^0$ y $z_t = \varepsilon_t^0 + \theta_1^0 \varepsilon_{t-1}^0 + \theta_2^0 \varepsilon_{t-2}^0$ se obtiene:

$$z_t = \theta_1 x_t^1 + \theta_2 x_t^2 + \varepsilon_t \quad (7.50)$$

Este método se puede extender para cualquier proceso MA(q) y ARMA(p, q):

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} - \dots - \phi_p Y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q} \quad (7.51)$$

Suponiendo que $\delta = 0$ se obtiene:

$$\varepsilon_t \approx \varepsilon_t^0 + \sum_{i=1}^p \frac{\partial \varepsilon_t(\phi^0, \theta^0)}{\partial \phi_i} (\phi_i - \phi_i^0) + \sum_{j=1}^q \frac{\partial \varepsilon_t(\phi^0, \theta^0)}{\partial \theta_j} (\theta_j - \theta_j^0) \quad (7.52)$$

En este caso habrá que estimar un total de $p + q$ parámetros, para lo cual se aplican los procedimientos ya expuestos.

Para efectuar contrastes estadísticos, en la iteración final se calcula la estimación de la matriz de varianzas y covarianzas de los estimadores mediante la expresión:

$$V(\phi, \theta) = \frac{\hat{\varepsilon}_t^T \hat{\varepsilon}_t}{(T - p - q)} (X^T X)^{-1} \quad (7.53)$$

El procedimiento iterativo no siempre es convergente. Si se produce divergencia el modelo se puede volver a estimar una o más veces, utilizando diferentes pronósticos iniciales, con la esperanza de obtener convergencia.

Puede también producirse por una mala especificación del modelo, es decir, que no sea el que mejor representa la estructura del proceso estocástico que generó la serie temporal objeto de análisis.

En este caso, habría que elegir una nueva especificación. La convergencia del proceso de estimación puede que sea más rápida si el pronóstico inicial es bueno. Para obtener valores iniciales de los parámetros (ϕ, θ) pueden utilizarse las estimaciones realizadas para la FAS y FAP.

7.6 Pronósticos con Procesos MA(q)

Mientras Y_t sea estacionario en covarianzas, podemos expresar la información disponible en el tiempo en función de valores y choques presentes y pasados:

$$\Omega_T = (Y_T; Y_{T-1}; Y_{T-2}; \dots; \varepsilon_T; \varepsilon_{T-1}; \varepsilon_{T-2}; \dots) \quad (7.54)$$

A partir de la información Ω_T , se desea estimar el pronóstico óptimo de Y en algún instante de tiempo futuro $T + h$. El pronóstico óptimo es aquel que minimiza la pérdida esperada.

El pronóstico óptimo, bajo estacionariedad débil, es la esperanza condicional $E(Y_{T+h}/\Omega_T)$, es decir, el valor esperado del valor futuro de la serie que se pronostica, condicionado a la información disponible.

Supongamos un modelo MA(2):

$$Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} \quad (7.55)$$

con $\varepsilon_t \sim N(0; \sigma^2)$; nos encontramos en T y queremos pronosticar para $T + 1$. Primero, formulamos el proceso para $T + 1$:

$$Y_{T+1} = \varepsilon_{T+1} + \theta_1 \varepsilon_T + \theta_2 \varepsilon_{T-1} \quad (7.56)$$

Luego, proyectamos sobre el conjunto de información en el tiempo T , lo cual implica reemplazar todas las innovaciones futuras por cero:

$$\hat{Y}_{T+1/T} = \theta_1 \varepsilon_T + \theta_2 \varepsilon_{T-1} \quad (7.57)$$

Para pronosticar dos etapas futuras observamos que:

$$Y_{T+2} = \varepsilon_{T+2} + \theta_1 \varepsilon_{T+1} + \theta_2 \varepsilon_T \quad (7.58)$$

$$\hat{Y}_{T+2/T} = \theta_2 \varepsilon_T \quad (7.59)$$

Al continuar de esta forma vemos que:

$$\hat{Y}_{T+h/T} = 0 \quad \forall h > 2 \quad (7.60)$$

Ahora calculemos los errores de pronóstico correspondientes. Para ello, se debe recordar que el error de pronóstico es simplemente la diferencia entre el valor real y el pronosticado, es decir, $\hat{\varepsilon}_{T+h/T} = Y_{T+h} - \hat{Y}_{T+h/T}$. Por lo tanto:

$$\hat{\varepsilon}_{T+1/T} = \varepsilon_{T+1} \quad \text{RB} \quad (7.61)$$

$$\hat{\varepsilon}_{T+2/T} = \varepsilon_{T+2} + \theta_1 \varepsilon_{T+1} \quad \text{MA(1)} \quad (7.62)$$

$$\hat{\varepsilon}_{T+h/T} = \varepsilon_{T+h} + \theta_1 \varepsilon_{T+h-1} + \theta_2 \varepsilon_{T+h-2} \quad \forall h > 2 \quad \text{MA(2)} \quad (7.63)$$

Finalmente, la varianza del error de pronóstico es:

$$V(\hat{\varepsilon}_{T+1/T}) = \sigma^2 \quad (7.64)$$

$$V(\hat{\varepsilon}_{T+2/T}) = \sigma^2 (1 + \theta_1^2) \quad (7.65)$$

$$V(\hat{\varepsilon}_{T+h/T}) = \sigma^2 (1 + \theta_1^2 + \theta_2^2) \quad \forall h > 2 \quad (7.66)$$

Notar que en $h > 2$ la varianza del error es la varianza no condicional de Y_t .

Analicemos ahora el caso general del modelo MA(q). El modelo es:

$$Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (7.67)$$

Si $h \leq q$, el pronóstico tiene la forma (análogo al caso MA(2)):

$$\hat{Y}_{T+h/T} = 0 + \text{"ajuste"} \quad (7.68)$$

Si $h > q$, el pronóstico tiene la forma:

$$\hat{Y}_{T+h/T} = 0 \quad (7.69)$$

De esta forma, un proceso MA(q) no es pronosticable más de q períodos adelante. Toda la dinámica del proceso MA(q), que se aprovecha para pronosticar, se desvanece cuando llegamos al horizonte q .

Ello es un reflejo del comportamiento de la función de autocorrelación de un MA(q), la cual se va a cero después del rezago q .

Por otra parte, los errores de pronóstico son los siguientes:

$$\hat{\varepsilon}_{T+h/T} = MA(h-1) \quad h \leq q \quad (7.70)$$

$$\hat{\varepsilon}_{T+h/T} = MA(q) \quad h > q \quad (7.71)$$

Luego, el error de pronóstico a h etapas, cuando $h > q$, es justamente el mismo proceso menos su media.

Finalmente, veamos la varianza del error de pronóstico:

$$V(\hat{\varepsilon}_{T+h/T}) < V(Y_t) \quad h \leq q \quad (7.72)$$

$$V(\hat{\varepsilon}_{T+h/T}) = V(Y_t) \quad h > q \quad (7.73)$$

Notar que la varianza del error de pronóstico cuando $h \leq q$ dependerá del número de períodos h a futuro que queramos predecir.

Ahora construiremos los intervalos de confianza. Dado que $\hat{\varepsilon}_{T+h/T} = Y_{T+h} - \hat{Y}_{T+h/T}$, el valor futuro será entonces el pronóstico más el error:

$$Y_{T+h} = \hat{Y}_{T+h/T} + \hat{\varepsilon}_{T+h/T} \quad (7.74)$$

Si las innovaciones se distribuyen en forma normal, el valor futuro de la serie también tiene forma normal, condicional al conjunto de información disponible en el período en el cual se emitió la información disponible.


Luego, el intervalo del pronóstico a un 95% de confiabilidad es:

$$\hat{Y}_{T+h/T} \pm 1,96 \sqrt{V(\hat{\varepsilon}_{T+h/T})} \quad (7.75)$$

Por lo tanto, se obtiene la siguiente función de densidad de pronóstico a h etapas futuras:

$$\hat{Y}_{T+h} \sim N(\hat{Y}_{T+h/T}; V(\hat{\varepsilon}_{T+h/T})) \quad (7.76)$$

Figura 7.4
Pronóstico de un MA(1)



Sin embargo, hasta ahora se han considerado conocidos los valores de los parámetros y de las innovaciones. En la práctica se deben estimar (ver sección 8.5), y luego utilizar las mismas ecuaciones pero con los estimadores de los parámetros y los residuos. Este procedimiento es válido para estimar pronósticos, errores, varianzas e intervalos.

8 PROCESOS AUTORREGRESIVOS

Representan los valores de una variable durante un instante del tiempo en función de sus valores precedentes. Un modelo autorregresivo de orden p o $AR(p)$ tiene la forma siguiente:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t \quad (8.1)$$

donde δ es un término constante y ε_t es una variable ruido blanco, que representa los errores del ajuste y otorga el carácter aleatorio a la misma.

8.1 Procesos AR(1)

En este caso, la representación es la siguiente:

$$Y_t = \delta + \phi_1 Y_{t-1} + \varepsilon_t \quad (8.2)$$

Si el proceso es estacionario, entonces $E(Y_t) = E(Y_{t-1})$ y $V(Y_t) = V(Y_{t-1})$.

8.1.1 Media

La media incondicional es:

$$E(Y_t) = E(Y_{t-1}) = \mu \quad (8.3)$$

$$\mu = \delta + \phi_1 \mu \rightarrow \mu = \frac{\delta}{1 - \phi_1} \quad (8.4)$$

La media condicional es:

$$E(Y_t/Y_{t-1}) = E(\mu + \phi_1 Y_{t-1}/Y_{t-1}) = \delta + \phi_1 Y_{t-1} \quad (8.5)$$

8.1.2 Varianza

La varianza incondicional es:

$$V(Y_t) = V(Y_{t-1}) = \gamma_0 \quad (8.6)$$

$$\gamma_0 = \phi_1^2 \gamma_0 + \sigma_\varepsilon^2 \rightarrow \gamma_0 = \frac{\sigma_\varepsilon^2}{1 - \phi_1^2} \quad (8.7)$$

La varianza condicional es:

$$V(Y_t/Y_{t-1}) = V(\mu + \phi_1 Y_{t-1} + \varepsilon_t/Y_{t-1}) = 0 + \phi_1^2 V(Y_{t-1}/Y_{t-1}) + V(\varepsilon_t/Y_{t-1}) \quad (8.8)$$

$$V(Y_t/Y_{t-1}) = 0 + \sigma_\varepsilon^2 = \sigma_\varepsilon^2 \quad (8.9)$$

La condición a cumplir para que γ_0 sea positiva y finita es que $|\phi_1| < 1$. En ese caso el modelo es estacionario en media y varianza.

8.1.3 Autocovarianza

$$\text{cov}(Y_t, Y_{t-1}) = \text{cov}(Y_{t-1}, Y_t) = \gamma_1 \quad (8.10)$$

$$\text{cov}(Y_t, Y_{t-1}) = E[(Y_{t-1} - \mu)(Y_t - \mu)] = E[y_{t-1} \cdot y_t] \quad (8.11)$$

$$Y_t = \delta + \phi_1 Y_{t-1} + \varepsilon_t = \mu(1 - \phi_1) + \phi_1 Y_{t-1} + \varepsilon_t \quad (8.12)$$

$$Y_t - \mu = \phi_1 (Y_{t-1} - \mu) + \varepsilon_t \rightarrow y_t = \phi_1 y_{t-1} + \varepsilon_t \quad (8.13)$$

$$\gamma_1 = E[y_{t-1} \cdot y_t] = E[y_{t-1} \cdot (\phi_1 y_{t-1} + \varepsilon_t)] = \phi_1 E(y_{t-1}^2) + E(y_{t-1} \varepsilon_t) = \phi_1 \gamma_0 \quad (8.14)$$

La variable y_{t-1} está correlacionada con ε_{t-1} pero no con ε_t , debido a que ésta es una variable ruido blanco y no presenta autocorrelación. Por otra parte:

$$\gamma_2 = E[y_{t-2} \cdot y_t] = E[y_{t-2} \cdot (\phi_1 y_{t-1} + \varepsilon_t)] \quad (8.15)$$

$$\gamma_2 = \phi_1 E(y_{t-1} y_t) + E(y_{t-2} \varepsilon_t) = \phi_1 \gamma_1 = \phi_1^2 \gamma_0 \quad (8.16)$$

En general, se tendrá que $\gamma_k = \phi_1^k \gamma_0$.

8.1.4 Autocorrelación

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1 \quad (8.17)$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \phi_1 \quad (8.18)$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \phi_1^2 \quad (8.19)$$

En general, se tendrá que $\rho_k = \frac{\gamma_k}{\gamma_0} = \phi_1^k$. Los valores de la función de autocorrelación son las sucesivas potencias de ϕ_1 .

La condición $|\phi_1| < 1$ garantiza que los sucesivos valores ρ_k converjan a cero, por lo que la función de autocorrelación o correlograma puede tener dos aspectos distintos, dependiendo del signo de ϕ_1 .

Utilizando el operador de retardos L , podemos establecer de otro modo la condición de estacionariedad:

$$Y_t = \delta + \phi_1 L Y_t + \varepsilon_t \rightarrow Y_t \underbrace{(1 - \phi_1 L)}_{\phi(L)} = \delta + \varepsilon_t \quad (8.20)$$

Para que el proceso AR(1) sea estacionario, $|\phi_1| < 1$ y es equivalente a la condición de que la raíz del operador polinomial $\phi(L)$ debe caer fuera del círculo unitario, es decir:

$$(1 - \phi_1 L) = 0 \rightarrow |L| > 1 \rightarrow \frac{1}{\phi_1} > 1 \rightarrow \phi_1 < 1 \quad (8.21)$$

Figura 8.1
Correlograma Simple $\phi_1 > 0$




Figura 8.2
Correlograma Simple $\phi_1 < 0$




Figura 8.3
Correlograma Parcial $\phi_1 > 0$




Figura 8.4
Correlograma Parcial $\phi_1 < 0$





Figura 8.5
Relación de 2 Procesos AR(1): $\phi_1 = 0,4$ vs $\phi_1 = 0,9$



Se observa que las fluctuaciones del proceso AR(1) con $\phi = 0,9$ son más persistentes que con $\phi = 0,4$, a diferencia del MA(1), que tiene poca memoria.

8.2 Procesos AR(2)

En este caso, la representación es la siguiente:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t \quad (8.22)$$

8.2.1 Media

$$E(Y_t) = E(Y_{t-1}) = E(Y_{t-2}) = \mu \quad (8.23)$$

$$\mu = \delta + \phi_1 \mu + \phi_2 \mu \rightarrow \mu = \frac{\delta}{1 - \phi_1 - \phi_2} \quad (8.24)$$

8.2.2 Varianza

$$V(Y_t) = V(Y_{t-1}) = V(Y_{t-2}) = \gamma_0 \quad (8.25)$$

$$\gamma_0 = V[y_t] = E[y_t^2] = E[y_t \cdot (\phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t)] = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \sigma_\varepsilon^2 \quad (8.26)$$

8.2.3 Autocovarianza

$$\text{cov}(Y_t, Y_{t-1}) = \text{cov}(Y_{t-1}, Y_t) = \gamma_1 \quad (8.27)$$

$$\gamma_1 = \text{cov}(Y_t, Y_{t-1}) = E[y_{t-1} \cdot (\phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t)] = \phi_1 \gamma_0 + \phi_2 \gamma_1 \quad (8.28)$$

$$\gamma_2 = \text{cov}(Y_t, Y_{t-2}) = E[y_{t-2} \cdot (\phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t)] = \phi_1 \gamma_1 + \phi_2 \gamma_0 \quad (8.29)$$

En general, se tendrá que $\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}$.

8.2.4 Autocorrelación

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1 \quad (8.30)$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \phi_1 + \phi_1 \rho_1 \quad (8.31)$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \phi_1 \rho_1 + \phi_2 \quad (8.32)$$

En general, se tendrá que $\rho_k = \frac{\gamma_k}{\gamma_0} = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$.

Utilizando el operador de retardos L , podemos establecer de otro modo la condición de estacionariedad:

$$Y_t = \delta + \phi_1 L Y_t + \phi_2 L^2 Y_t + \varepsilon_t \rightarrow Y_t \underbrace{(1 - \phi_1 L - \phi_2 L^2)}_{\phi(L)} = \delta + \varepsilon_t \quad (8.33)$$

Para que el proceso AR(2) sea estacionario la raíz del operador polinomial $\phi(L)$ debe caer fuera del círculo unitario, es decir:

$$(1 - \phi_1 L - \phi_2 L^2) = 0 \rightarrow |L| > 1 \quad (8.34)$$

$$L^* = \begin{cases} \frac{\phi_1 + \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2} \\ \frac{\phi_1 - \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2} \end{cases} \quad (8.35)$$

Sea $G_1 = \frac{1}{L_1}$ y $G_2 = \frac{1}{L_2}$. Si $|G_1| < 1$ y $|G_2| < 1$ entonces $|G_1 \cdot G_2| = |G_1| \cdot |G_2| < 1$ y además $|G_1 + G_2| \leq |G_1| + |G_2| < 2$.

Como $G_1 \cdot G_2 = \phi_2$ y $G_1 + G_2 = \phi_1$, para que un proceso AR(2) sea estacionario es necesario (aunque no siempre suficiente) que $|\phi_2| < 1$ y $|\phi_1| < 2$.

Las raíces serán iguales sólo si $\phi_1^2 + 4\phi_2 = 0 \rightarrow \phi_2 = -\frac{\phi_1^2}{4}$. En este caso, $|G_1| = |G_2| = \frac{|\phi_1|}{2}$. Luego, si $|\phi_1| < 2$, dado que $\phi_2 = -\frac{\phi_1^2}{4}$, el modelo resultante es estacionario puesto con $-1 < \phi_2 < 0$.

Por otro lado, las raíces serán reales y diferentes si $\phi_1^2 + 4\phi_2 > 0 \rightarrow \phi_2 > -\frac{\phi_1^2}{4}$.


Puede demostrarse que si $|G_1| < 1$ y $|G_2| < 1$ entonces:

$$\phi_2 + \phi_1 < 1 \quad (8.36)$$

$$\phi_2 - \phi_1 < 1 \quad (8.37)$$

$$-1 < \phi_2 < 1 \quad (8.38)$$

Estas tres últimas condiciones son necesarias y suficientes para que el proceso AR(2) sea estacionario, incluso cuando las soluciones sean complejas conjugadas.



8.3 Procesos AR(p)

En este caso, la representación es la siguiente:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t \quad (8.39)$$

Si el proceso es estacionario, entonces $E(Y_t) = E(Y_{t-1}) = \dots = E(Y_{t-p})$ y $V(Y_t) = V(Y_{t-1}) = \dots = V(Y_{t-p})$. Luego:

$$E(Y_t) = E(Y_{t-1}) = \dots = E(Y_{t-p}) = \mu \quad (8.40)$$

$$\mu = \delta + \phi_1 \mu + \phi_2 \mu + \dots + \phi_p \mu \rightarrow \mu = \frac{\delta}{1 - \phi_1 - \phi_2 - \dots - \phi_p} \quad (8.41)$$

La condición de estacionariedad es que las raíces de la ecuación polinomial $\phi(L)$ estén fuera del círculo unidad:

$$\underbrace{(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)}_{\phi(L)} = 0 \quad (8.42)$$

Si L_i es una raíz de la ecuación polinomial se demuestra que $\frac{1}{L_i} = \lambda_i$, donde

λ_i son las raíces de la denominada ecuación característica:

$$\lambda^p - \phi_1 \lambda^{p-1} - \phi_2 \lambda^{p-2} - \dots - \phi_{p-1} \lambda - \phi_p = 0 \quad (8.43)$$

Por tanto, la condición de invertibilidad se puede obtener de forma alternativa y es que las raíces de la ecuación característica deben ser menores a la unidad en valor absoluto.

Luego, generalizando:

$$\gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \dots + \phi_p \gamma_p + \sigma_\varepsilon^2 \quad (8.44)$$

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \dots + \phi_p \gamma_{k-p} \quad , \quad \forall k \geq 1 \quad (8.45)$$

El sistema de ecuaciones (8.45) para $k = 1...p$, relaciona las p primeras autocovarianzas con los parámetros del proceso. Se denominan ecuaciones de Yule-Walker:

$$\gamma_1 = \phi_1 \gamma_0 + \phi_2 \gamma_1 + \dots + \phi_p \gamma_{p-1} \quad (8.46)$$

$$\gamma_2 = \phi_1 \gamma_1 + \phi_2 \gamma_0 + \dots + \phi_p \gamma_{p-2} \quad (8.47)$$

.....

$$\gamma_p = \phi_1 \gamma_{p-1} + \phi_2 \gamma_{p-2} + \dots + \phi_p \gamma_0 \quad (8.48)$$

Las ecuaciones de Yule-Walker se pueden expresar en términos de los coeficientes de autocorrelación dividiendo por γ_0 ambos miembros:

$$\rho_1 = \phi_1 \rho_0 + \phi_2 \rho_1 + \dots + \phi_p \rho_{p-1} \quad (8.49)$$

$$\rho_2 = \phi_1 \rho_1 + \phi_2 \rho_0 + \dots + \phi_p \rho_{p-2} \quad (8.50)$$

.....

$$\rho_p = \phi_1 \rho_{p-1} + \phi_2 \rho_{p-2} + \dots + \phi_p \rho_0 \quad (8.51)$$

Mediante estas ecuaciones se pueden obtener los coeficientes o parámetros del proceso AR(p) con los datos de los coeficientes de autocorrelación o autocovarianzas.

Si se resuelve sucesivamente el sistema de Yule-Walker bajo la hipótesis de la serie es un AR(1), AR(2), AR(3), etc., y se toma el último coeficiente de cada uno de los procesos que corresponde a la función de autocorrelación parcial. Bajo el supuesto de que p es el orden del proceso autorregresivo, se obtiene que los coeficientes de autocorrelación parcial serán distintos de cero para retardos iguales o inferiores a p .

En términos matriciales, y considerando que $\rho_0 = 1$, $\rho_k = \rho_{-k}$, las ecuaciones de Y-W pueden escribirse de la siguiente manera:

$$\begin{pmatrix} \rho_1 \\ \rho_2 \\ \dots \\ \rho_p \end{pmatrix} = \begin{bmatrix} 1 & \rho_1 & \dots & \rho_{p-1} \\ \rho_1 & 1 & & \rho_{p-2} \\ & & \ddots & \\ \rho_{p-1} & \rho_{p-2} & \dots & 1 \end{bmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \dots \\ \phi_p \end{pmatrix} \quad (8.52)$$

Figura 8.6
Correlograma Parcial $\phi > 0$





Figura 8.7
Correlograma Parcial $\phi < 0$



Los procesos AR son siempre invertibles, pero deben cumplir ciertas condiciones para que sean estacionarios; notar la dualidad con los procesos MA.

8.4 Estimación de Procesos AR(p)

Un proceso autorregresivo no cumple la hipótesis del modelo clásico de regresión basada en regresores fijos. Son variables aleatorias puesto que son retardos de la variable Y_t que es aleatoria (ó $w_t = \Delta Y_t$ si corresponde). Sin embargo, en presencia de errores que no presentan autocorrelación, los estimadores MCO tienen buenas propiedades (consistencia).

Por el contrario, si el término de error estuviese correlacionado (no fuese ruido blanco), estos estimadores serían inconsistentes. En este caso, el modelo estaría mal especificado, puesto que una especificación correcta debe provocar un término de error con estructura de ruido blanco.

La especificación es la siguiente:

$$w_t = \delta + \phi_1 w_{t-1} + \phi_2 w_{t-2} + \dots + \phi_k w_{t-k} + \varepsilon_t \quad (8.53)$$

$$w = W\Phi + \varepsilon \quad (8.54)$$

$$w = \begin{pmatrix} w_1 \\ w_2 \\ \dots \\ w_T \end{pmatrix}, \quad \Phi = \begin{pmatrix} \delta \\ \phi_1 \\ \dots \\ \phi_k \end{pmatrix}, \quad W = \begin{bmatrix} 1 & w_0 & w_{-1} & \dots & w_{1-p} \\ 1 & w_1 & w_0 & \dots & w_{2-p} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & w_{T-1} & w_{T-2} & \dots & w_{T-p} \end{bmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_T \end{pmatrix}$$

Luego, el estimador MCO es simplemente $\hat{\Phi} = (W^T W)^{-1} W^T w$. Si no se incluye la media δ , simplemente se suprime la columna de unos en W .

8.5 Pronósticos con Procesos AR(p)

Considere un modelo AR(1):

$$Y_t = \delta + \phi Y_{t-1} + \varepsilon_t \rightarrow \varepsilon_t \sim N(0; \sigma^2) \quad (8.55)$$

El proceso a una etapa más es:

$$Y_{T+1} = \delta + \phi Y_T + \varepsilon_{T+1} \quad (8.56)$$

La proyección por su parte es:

$$\hat{Y}_{T+1/T} = \delta + \phi Y_T \quad (8.57)$$

El proceso y la proyección en $T + 2$ son:

$$Y_{T+2} = \delta + \phi Y_{T+1} + \varepsilon_{T+2} \quad (8.58)$$

$$\hat{Y}_{T+2/T} = \delta + \phi Y_{T+1/T} = \phi^2 Y_T + \delta(1 + \phi) \quad (8.59)$$

El proceso y la proyección en $T + h$ son:

$$Y_{T+h} = \delta + \phi Y_{T+h-1} + \varepsilon_{T+h} \quad (8.60)$$

$$\hat{Y}_{T+h/T} = \phi^h Y_T + \delta(1 + \phi + \phi^2 + \dots + \phi^{h-1}) \quad (8.61)$$

Notar que el pronóstico tiende a la media conforme aumente h :

$$\lim_{h \rightarrow \infty} (\hat{Y}_{T+h/T}) = \frac{\delta}{1 - \phi} = \mu \quad (8.62)$$

Luego, no existe información útil del pasado, ni siquiera reciente, a medida que aumenta el tamaño muestral.

El error de pronóstico, por su parte:

$$\hat{\varepsilon}_{T+h} = Y_{T+h} - \hat{Y}_{T+h/T} = \delta + \phi Y_{T+h-1} + \varepsilon_{T+h} - \hat{Y}_{T+h/T} \quad (8.63)$$

$$\hat{\varepsilon}_{T+h} = \phi^2 Y_{T+h-2} + \delta(1 + \phi) + \varepsilon_{T+h} + \phi \varepsilon_{T+h-1} - \hat{Y}_{T+h/T} \quad (8.64)$$

$$\begin{aligned} \hat{\varepsilon}_{T+h} &= \phi^h Y_T + \delta(1 + \phi + \phi^2 + \dots + \phi^{h-1}) \\ &\quad + \varepsilon_{T+h} + \phi \varepsilon_{T+h-1} + \phi^2 \varepsilon_{T+h-2} + \dots + \phi^{2h-1} \varepsilon_{T+1} - \hat{Y}_{T+h/T} \end{aligned} \quad (8.65)$$


$$\hat{\varepsilon}_{T+h} = \varepsilon_{T+h} + \phi \varepsilon_{T+h-1} + \phi^2 \varepsilon_{T+h-2} + \dots + \phi^{2h-1} \varepsilon_{T+1} \quad (8.66)$$

y su varianza:

$$V(\hat{\varepsilon}_{T+h}) = \sigma_\varepsilon^2 (1 + \phi^2 + \phi^4 + \dots + \phi^{2h-2}) \quad (8.67)$$

Notar que la varianza se incrementa conforme aumenta h , pero converge.

Figura 8.8
Pronóstico de un AR(1)



8.6 Regla de la Cadena Para Pronosticar AR(p)

Dado que cualquier proceso AR(p) estacionario en covarianza puede ser expresado como un MA de orden infinito, no hay necesidad de técnicas especiales para pronósticos autorregresivos.

Sin embargo, existe un método muy sencillo para calcular el pronóstico óptimo de modelos autorregresivos, conocido como regla de la cadena para pronosticar.

Primero se construye el pronóstico óptimo a una etapa, y luego se construye el óptimo a dos etapas, que depende del óptimo a una etapa ya calculado. Después se estima el pronóstico a tres etapas, el que depende del pronóstico a dos etapas ya calculado, y así sucesivamente.

El proceso a una etapa más es:

$$Y_{T+1} = \phi Y_T + \varepsilon_{T+1} \quad (8.68)$$

La proyección por su parte es:

$$\hat{Y}_{T+1/T} = \phi Y_T \quad (8.69)$$

El proceso y la proyección en $T + 2$ son:

$$Y_{T+2} = \phi Y_{T+1} + \varepsilon_{T+2} \quad (8.70)$$

$$\hat{Y}_{T+2/T} = \phi Y_{T+1/T} \quad (8.71)$$

El proceso y la proyección en $T + 3$ son:

$$Y_{T+3} = \phi Y_{T+2} + \varepsilon_{T+3} \quad (8.72)$$

$$\hat{Y}_{T+3/T} = \phi Y_{T+2/T} \quad (8.73)$$

Continuando de esta forma, se pueden formular pronósticos para todos y cada uno de los períodos futuros. Notar que para un AR(1) se necesita el valor más reciente de Y_t , mientras que para un proceso general AR(p) se necesitan los p valores más recientes.

8.7 Dualidad entre Procesos AR y MA

- En un modelo AR(p) el término ε_t puede representarse como una combinación finita de $Y_t, Y_{t-1}, \dots, Y_{t-p}$. Análogamente, Y_t puede expresarse como una combinación infinita de $\varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots$.

En un modelo MA(q) Y_t puede expresarse como una combinación finita de $\varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_{t-q}$ y el término ε_t puede representarse como una combinación infinita de $Y_t, Y_{t-1}, Y_{t-2}, \dots$.

- En un modelo AR(p) no se requiere ninguna condición sobre los parámetros ϕ_i para que el proceso sea invertible; sin embargo, cada raíz L del polinomio $\phi(L)$ debe estar fuera del círculo unitario para que el proceso sea estacionario.

En un modelo MA(q) no se requiere ninguna condición sobre los parámetros θ_i para que el proceso sea estacionario; sin embargo, cada raíz L del polinomio $\theta(L)$ debe estar fuera del círculo unitario para que el proceso sea invertible.

- La FAS de un proceso $MA(q)$ se anula para retardos superiores a q ; sin embargo, la FAP es infinita y está dominada por una combinación lineal de oscilaciones armónicas, exponenciales amortiguadas y productos de dichos términos por potencias de k .

Recíprocamente, la FAP de un proceso $AR(p)$ se anula para retardos superiores a p , sin embargo, la FAS es infinita y está dominada por una combinación lineal de oscilaciones armónicas, exponenciales amortiguadas y productos de dichos términos por potencias de k .

8.8 Procesos ARMA(p,q)

Un modelo mixto con componente autorregresiva y con componente de medias móviles se denomina ARMA (p,q), donde p es el orden de la parte autorregresiva y q el de la parte de medias móviles:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (8.74)$$

$$\Phi(L)Y_t = \Theta(L)\varepsilon_t \rightarrow Y_t = \frac{\Theta(L)}{\Phi(L)}\varepsilon_t \quad (8.75)$$

La condición de estacionariedad es que las raíces de la ecuación característica $\phi(L) = 0$ estén fuera del círculo unidad. La condición de invertibilidad es que las raíces de la ecuación $\theta(L) = 0$ estén fuera del círculo unidad.

Lógicamente, en un proceso ARMA (p,q) tanto la FAS como la FAP tienen infinitos elementos distintos de cero.

Para estimar modelos ARMA se utiliza el criterio de máxima verosimilitud. La función de verosimilitud se obtiene de la siguiente forma. Supongamos que Y_t evoluciona en el tiempo de acuerdo con un proceso estocástico ARMA gaussiano cuya esperanza incondicional es nula para todo t ; esto implica que la función de verosimilitud de la muestra condicionada a los valores de los parámetros del modelo es:

$$f(Y, \phi, \theta, \sigma^2) = (2\pi)^{-n/2} |\Omega|^{-1/2} \exp\left(-\frac{1}{2} Y^T \Omega^{-1} Y\right) \quad (8.76)$$

donde:

- ϕ : Vector de dimensión $p \times 1$ que contiene todos los parámetros de la parte autorregresiva del modelo.
- θ : Vector de dimensión $q \times 1$ que contiene todos los parámetros de la parte media móvil del modelo.
- Ω : Matriz de varianzas-covarianzas de Y_t , de dimensión $n \times n$. En general, los elementos de esta matriz serán función de los parámetros ϕ , θ y σ^2 del modelo.

Transformando logarítmicamente la expresión anterior, tras simplificaciones algebraicas, se obtiene la función:

$$L(Y, \phi, \theta, \sigma^2) = -\ln |\Omega| - Y^T \Omega^{-1} Y \quad (8.77)$$

Consecuentemente, el problema de estimación por máxima verosimilitud queda reducido a buscar los valores de ϕ , θ y σ^2 que minimizan la función anterior, sustituyendo en cada caso la matriz Ω por su expresión analítica correcta.

Supongamos, por ejemplo, que Y_t evoluciona en el tiempo de acuerdo con un modelo invertible de medias móviles de orden 1: $Y_t = \varepsilon_t + \theta \varepsilon_{t-1}$, $|\theta| < 1$ y $\varepsilon_t \sim N(0, \sigma^2)$.

Por los resultados anteriores, sabemos que la matriz Ω tendrá la forma:

$$\Omega = \sigma^2 \begin{bmatrix} 1+\theta^2 & -\theta & \dots & 0 \\ -\theta & 1+\theta^2 & & 0 \\ \dots & & \ddots & \dots \\ 0 & 0 & \dots & 1+\theta^2 \end{bmatrix} \quad (8.78)$$

Por otra parte, si Y_t evoluciona en el tiempo de acuerdo con un modelo AR(1) estacionario $Y_t = \phi Y_{t-1} + \varepsilon_t$, $|\phi| < 1$ y $\varepsilon_t \sim N(0, \sigma^2)$, por resultados anteriores, sabemos que:

$$\Omega = \frac{\sigma^2}{1-\phi} \begin{bmatrix} 1 & \phi & \dots & \phi^{n-1} \\ \phi & 1 & & \phi^{n-2} \\ \dots & & \ddots & \dots \\ \phi^{n-1} & \phi^{n-2} & \dots & 1 \end{bmatrix} \quad (8.79)$$

En el contexto de modelos ARMA, las condiciones de primer orden del problema de optimización dan lugar a un sistema de ecuaciones no lineales. Por ello, es

necesario recurrir a técnicas numéricas para resolverlas de forma aproximada, lo que provoca una serie de problemas:

- **Soluciones no exactas:** Los procedimientos que se utilizan para resolver estos problemas generan una secuencia de soluciones tentativas que, idealmente, deben converger a la solución óptima. En la práctica, el proceso se interrumpe cuando la solución obtenida es "suficientemente buena", lo cual introduce un cierto grado de arbitrariedad en el proceso de estimación.
- **Posibilidad de convergencia fuera del óptimo global:** El proceso iterativo de búsqueda puede converger a un óptimo local o, incluso, a una región "plana" de la función de verosimilitud, creada por un problema de identificación paramétrica análogo al de colinealidad.
- **Posibilidad de acumulación de errores de redondeo:** Puesto que los procesos de cálculo se desarrollan con una precisión finita, es posible cometer errores de redondeo capaces de abortar la secuencia de cálculos (provocando, por ejemplo, una división por cero) o dar lugar a una convergencia alejada del óptimo.

8.9 Pronósticos de Modelos ARMA(p, q)

Consideremos un proceso ARMA estacionario en covarianza. Como en el caso de los procesos AR(p), siempre se puede convertir un proceso ARMA en uno de medias móviles de orden infinito, y luego utilizar las técnicas de dichos procesos para pronosticar (ver Capítulo 8).

Sin embargo, se dispone de un método más sencillo que combina las metodologías consideradas para los MA y los AR.

El proceso en el futuro es:

$$Y_{T+h} = \phi_1 Y_{T+h-1} + \phi_2 Y_{T+h-2} + \dots + \phi_p Y_{T+h-p} + \varepsilon_{T+h} + \theta_1 \varepsilon_{T+h-1} + \theta_2 \varepsilon_{T+h-2} + \dots + \theta_q \varepsilon_{T+h-q} \quad (8.80)$$

En el lado derecho hay varios valores futuros de Y y de ε , y quizás también algunos valores pasado (depende de los valores de h , p y q).

Se debe reemplazar todo el lado derecho por su proyección sobre el conjunto de información en el tiempo T . Es decir, se sustituyen todos los valores futuros de Y por sus pronósticos (obtenidos recursivamente por regla de la cadena) y todos los ε , también por sus pronósticos óptimos.

$$\begin{aligned}\hat{Y}_{T+h/T} = & \phi_1 \hat{Y}_{T+h-1/T} + \phi_2 \hat{Y}_{T+h-2/T} + \dots + \phi_p \hat{Y}_{T+h-p/T} + \hat{\varepsilon}_{T+h/T} \\ & + \theta_1 \hat{\varepsilon}_{T+h-1/T} + \theta_2 \hat{\varepsilon}_{T+h-2/T} + \dots + \theta_q \hat{\varepsilon}_{T+h-q/T}\end{aligned}\quad (8.81)$$

Por ejemplo, para una ARMA(1,1):

$$Y_t = \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} \quad (8.82)$$

El proceso en el tiempo $T+1$ es:

$$Y_{T+1} = \phi Y_T + \varepsilon_{T+1} + \theta \varepsilon_T \quad (8.83)$$

Al proyectar el lado derecho sobre Ω_T se obtiene:

$$\hat{Y}_{T+1/T} = \phi Y_T + \theta \varepsilon_T \quad (8.84)$$

El proceso en el tiempo $T+2$ es:

$$Y_{T+2} = \phi Y_{T+1} + \varepsilon_{T+2} + \theta \varepsilon_{T+1} \quad (8.85)$$

Al proyectar el lado derecho sobre Ω_T se obtiene:

$$\hat{Y}_{T+2/T} = \phi \hat{Y}_{T+1/T} \quad (8.86)$$

Sustituyendo el pronóstico a una etapa ya calculado se obtiene:

$$\hat{Y}_{T+2/T} = \phi^2 Y_T + \phi \theta \varepsilon_T \quad (8.87)$$

8.10 Procesos ARIMA(p,i,q)

Hasta este momento se han tratado procesos estacionarios. Sin embargo, las series de datos económicos suelen caracterizarse por ser no estacionarias: nótese la simple observación de una tendencia creciente en el tiempo o de unas fluctuaciones que crecen en tamaño con el paso del tiempo, como, por ejemplo, puede ocurrir con el precio de algunos activos financieros.

Muchas series económicas se convierten en aproximadamente estacionarias después de aplicar diferencias en una ó más etapas. Lo que se hace en tales situaciones es trabajar con la serie en diferencias especificando y estimando un modelo para ellas.

Una predicción con estas series hay que traducirla a una predicción para la serie origen, en cuyo análisis está interesado el investigador.

- Diferencias de orden uno o de primer orden o primeras diferencias:

$$\Delta Y_t = Y_t - Y_{t-1} \quad (8.88)$$

- Diferencias de orden dos o segundas diferencias: se aplican primeras diferencias a la serie ya diferenciada una vez.

$$\Delta(\Delta Y_t) = \Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1} = Y_t - 2Y_{t-1} - Y_{t-2} \quad (8.89)$$

Un ejemplo de proceso estocástico o aleatorio no estacionario es el denominado paseo o camino aleatorio:

$$Y_t = Y_{t-1} + \varepsilon_t \quad (8.90)$$

$$Y_t = \delta + Y_{t-1} + \varepsilon_t \quad (8.91)$$

donde ε_t es ruido blanco. Este es un proceso no estacionario en varianza, ya que:

$$Y_t = Y_{t-1} + \varepsilon_t = Y_{t-2} + \varepsilon_{t-1} + \varepsilon_t = Y_{t-3} + \varepsilon_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \dots \quad (8.92)$$

$$Y_t = \sum_{i=0}^N \varepsilon_{t-i} \quad (8.93)$$

$$V(Y_t) = N\sigma_\varepsilon^2 \quad (8.94)$$

La transformación consiste en tomar primeras diferencias de la variable, con lo que se produce una nueva serie claramente estacionaria: $\Delta Y_t = Y_t - Y_{t-1} = \varepsilon_t$, variable que sigue un proceso ruido blanco, estacionario.

La serie Y_t es no estacionaria homogénea de orden d , si la serie $w_t = \Delta^d Y_t$ es estacionaria. Entonces, Y_t es un proceso autorregresivo integrado de media móvil de orden (p, d, q) y se denomina ARIMA (p, d, q) . Si se aplican diferencias de orden d a Y_t se obtiene un proceso estacionario w_t del tipo ARMA (p, q) .

8.11 Procesos Estacionales

Hasta el momento solamente hemos considerado procesos estocásticos que no contenía un componente estacional. Sin embargo, es posible que las variables sometidas a análisis se hayan medido como datos de **frecuencia inferior al año** y, en consecuencia, son susceptibles de presentar un componente estacional que tenga un comportamiento propio.

En este apartado vamos a analizar este tipo de modelos considerando que el proceso contiene solamente componente estacional. No es el caso más habitual desde el punto de vista empírico, pero sí que tiene interés desde el punto de vista teórico, en especial de cara a ofrecer una mejor comprensión de aquellos procesos que combinan un comportamiento estacional con otro no estacional.

Vamos a comenzar analizando el caso autorregresivo para, a continuación, estudiar los procesos de medias móviles y, finalmente, los procesos mixtos. A lo largo de las subsiguientes secciones consideraremos que disponemos de datos de frecuencia inferior al año, en general s , tal que $s = 2, 4, 12$ se interpreta como datos de frecuencia bi-mensual, trimestral o mensuales, respectivamente.

La principal ventaja de utilizar modelos estacionales, es que mejora el nivel de predicción y además permite aumentar el número de datos utilizados en el proceso de calibración.

8.11.1 Estacionalidad Mediante Variables Dicotómicas

La utilización de variables Dicotómicas, Dummies o Ficticias, es típicamente utilizada en la modelación de procesos estacionales. Para cada estación diferentes, que puede ser un mes, trimestre, semestre, estación del año, e incluso semana, se considera una variable ficticia. Así, si por ejemplo interesa diferenciar entre meses del año, deben considerarse 12 variables ficticias; si el análisis fuera a partir de trimestres, debieran considerarse 4 variables ficticias, etc.

Si el análisis fuera, por ejemplo, considerando las 4 estaciones del año, tendríamos que definir cuatro variables ficticias: D_1 , D_2 , D_3 y D_4 . Así, para la primera temporada (verano por ejemplo), la variable D_1 toma el valor 1, mientras que el resto de las variables toma el valor cero. Para la segunda temporada, la variable D_2 toma el valor 1, y el resto toma el valor cero; análogo para las otras dos temporadas.

De esta forma, el modelo estacional puro considerando s estaciones dentro del año, es el siguiente:

$$Y_t = \sum_{i=1}^s \gamma_i D_{it} + \varepsilon_t \quad (8.95)$$

Esta última expresión corresponde al modelo más básico, definido únicamente por una constante, que representa la ordenada en el origen. Sin embargo, cada estación tiene su propia ordenada en el origen γ_i . Cuando no hay estacionalidad, las γ_i son iguales, y se pueden eliminar todas las variables ficticias estacionales, para dejar sólo el intercepto acostumbrado.

Luego, en lugar de incorporar un conjunto de s variables ficticias estacionales, podríamos incluir sólo $(s - 1)$ variables ficticias y una ordenada en el origen (intercepto). Entonces, **el intercepto representa la variable ficticia de la estación omitida**, y los parámetros γ_i representan el aumento o la reducción en relación a la estación omitida. Sin embargo, **por ningún motivo deben incluirse s variables ficticias estacionales y también el intercepto**. Recordar que incluir el intercepto equivale a incorporar una variable que siempre toma el valor 1. Si analizamos, la suma de las variables ficticias por estación también es 1.

Luego, si se incluye el intercepto y todo el conjunto de s variables ficticias, **se produce multicolinealidad perfecta**, y los parámetros no son estimables.

El modelo también puede incorporar un término de tendencia determinista de la siguiente forma:

$$Y_t = \beta t + \sum_{i=1}^s \gamma_i D_{it} + \varepsilon_t \quad (8.96)$$

El pronóstico y la varianza del error de predicción se construyen de manera análoga a los casos anteriores en que no se consideró estacionalidad.

8.11.2 Procesos Autorregresivos Estacionales

Un proceso autorregresivo estacional de orden p es:

$$Y_t = \delta + \phi_1 Y_{t-s} + \phi_2 Y_{t-2s} + \dots + \phi_p Y_{t-ps} + \varepsilon_t \quad (8.97)$$

Este proceso lo podemos expresar en función de un polinomio autorregresivo de retardos de la siguiente manera:

$$(1 + \phi_1 L^s + \phi_2 L^{2s} + \dots + \phi_p L^{ps}) Y_t = \delta + \varepsilon_t \quad (8.98)$$

$$\Phi_p(L^s) Y_t = \delta + \varepsilon_t \quad (8.99)$$

Se observa que existen grandes similitudes entre un autorregresivo estacional y los modelos autorregresivos comunes. La diferencia principal reside en el hecho de que aquí **las correlaciones no se presentan entre un periodo y el inmediatamente anterior, sino entre un periodo y s periodos atrás**.

8.11.3 Estacionariedad del AR(p) Estacional

Dadas estas semejanzas, los resultados van a ser similares entre sí. Por ejemplo, la primera cuestión que debemos dilucidar es si el proceso autorregresivo estacional es estacionario o no. Tomando como referencia un proceso autorregresivo regular, podemos decir que un proceso autorregresivo estacional será estacionario siempre que las raíces del polinomio de retardos $\Phi_p(L^s)$ estén todas fuera del círculo unidad.

Una vez impuesta la condición de estacionariedad, el cálculo de los momentos del proceso es similar a lo que hicimos con anterioridad para el proceso AR(p). Así la media poblacional del proceso es:

$$E(Y_t) = E(Y_{t-s}) = \dots = E(Y_{t-ps}) = \mu \quad (8.100)$$

$$\mu = \delta + \phi_1\mu + \phi_2\mu + \dots + \phi_p\mu \rightarrow \mu = \frac{\delta}{1 - \phi_1 - \phi_2 - \dots - \phi_p} \quad (8.101)$$

Resultado es cualitativamente similar al expuesto para un autorregresivo de orden p no estacional.

Por otra parte, la función de autocovarianzas tiene características similares a la de un autorregresivo regular. Primero, tiene infinitos valores distintos de 0, no se anula nunca. Además, los coeficientes son decrecientes, en valor absoluto.

8.11.4 Procesos Medias Móviles Estacionales

Un proceso media móvil estacional de orden q es:

$$Y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-s} + \theta_2\varepsilon_{t-2s} + \dots + \theta_q\varepsilon_{t-qs} \quad (8.102)$$

Este proceso lo podemos expresar en función de un polinomio autorregresivo de retardos de la siguiente manera:

$$Y_t = \mu + (1 + \theta_1L^s + \theta_2L^{2s} + \dots + \theta_qL^{qs})\varepsilon_t \quad (8.103)$$

$$Y_t = \mu + \Theta_q(L^s)\varepsilon_t \quad (8.104)$$

Como todo proceso que solamente tiene parte de medias móviles, este proceso será siempre estacionario. No será, por el contrario, siempre invertible. Para que cumpla esta característica es necesario imponerle una condición similar a la de los procesos de medias móviles regulares. Así, un proceso estacional de medias móviles será invertible cuando las raíces del polinomio autorregresivo de retardos estén todas fuera del círculo unidad.

El análisis de los momentos de este proceso se hace de forma similar a como lo hemos venido realizando. En primer lugar, la media poblacional del proceso se obtiene como:

$$E(Y_t) = \mu \quad (8.105)$$

La función de autocorrelación de un proceso estacional de medias móviles tiene un comportamiento similar al de un proceso regular de medias móviles, pero con la particularidad de que **esta función muestra valores distintos de 0 sólo en las frecuencias estacionales, esto es, para $s = 1, 2, \dots, q$** . El resto de los coeficientes de la función se anulan.

8.11.5 Identificación de s

La existencia de un componente estacional en la serie puede deducirse del contraste de Kruskal - Wallis por:

- a.) El gráfico de la serie (la serie presenta valores superiores o inferiores al valor medio anual, los cuales se repiten frecuentemente para determinar periodos al año).
- b.) Correlograma muestral de dicha serie (FAM presenta valores elevados en los retardos correspondientes a los periodos estacionales).

9 PROCESOS ESTOCÁSTICOS NO ESTACIONARIOS

En este Capítulo comenzamos el estudio de los procesos no estacionarios. Un proceso puede ser no estacionario en la media, en la varianza, en las covarianzas o en otras características de la distribución de las variables a lo largo del tiempo.

Será no estacionario en la media si el nivel de la serie no es estable en el tiempo, pudiendo en particular tener tendencia creciente o decreciente. Será no estacionario en la varianza o en las covarianzas si estas varían con el tiempo.

Vamos a considerar la clase de procesos no estacionarios integrados, que son procesos no estacionarios en la media, pero que pueden convertirse en estacionarios tomando diferencias.

9.1 Paseo Aleatorio

Hemos visto que los procesos MA finitos son siempre estacionarios y que los AR lo son si las raíces de $\phi(B) = 0$ están fuera del círculo unidad. Consideremos el AR(1):

$$Y_t = \delta + \phi Y_{t-1} + \varepsilon_t \quad (9.1)$$

Si $\phi > 1$ el proceso es explosivo; si $\phi = 1$ el proceso es no estacionario y tampoco es explosivo, y pertenece a la clase de procesos integrados de orden uno (ya que su primera diferencia, $Y_t - Y_{t-1} = \varepsilon_t$, sí es un proceso estacionario). Este proceso se denomina paseo aleatorio, y corresponde al más simple de los procesos no estacionarios.

Para calcular la función de autocorrelación de este proceso supondremos que comienza en $t = 0$. Entonces, sustituyendo sucesivamente Y_t por Y_{t-1} tendremos:

$$Y_t = t\delta + Y_0 + \varepsilon_t + \varepsilon_{t-1} + \varepsilon_{t-2} + \dots + \varepsilon_1 \quad (9.2)$$

De (9.2) se observa que el impacto de los choques no se disipa con el tiempo, a diferencia del caso estacionario. Procesos de memoria corta suelen ser estacionarios, mientras que procesos de memoria larga pueden ser no estacionarios.

La media y varianza del proceso (9.2) son:

$$E(Y_t) = \delta \cdot t + Y_0 \quad (9.3)$$

$$V(Y_t) = \sigma^2 t \rightarrow V(Y_{t+k}) = \sigma^2 (t+k) \quad (9.4)$$

Se observa que la varianza aumenta con el tiempo, lo mismo con la media cuando $\delta > 0$. Además se tiene:

$$\text{cov}(Y_t, Y_{t+k}) = \sigma^2 t \quad (9.5)$$

Luego, la función de autocorrelación es:

$$\rho_k = \frac{\text{cov}(Y_t, Y_{t+k})}{\sqrt{V(Y_{t+k})}\sqrt{V(Y_t)}} = \frac{\sigma^2 t}{[\sigma\sqrt{(t+k)}][\sigma\sqrt{t}]} = \sqrt{\frac{t}{(t+k)}} \quad (9.6)$$

Si t es grande, los coeficientes de la función de autocorrelación serán próximos a uno y decrecerán muy lentamente con k .

Este proceso puede ser representado por lanzamientos sucesivos de una moneda, donde la cara recibe el valor +1 y el sello recibe el valor -1.

El pronóstico en este caso (considerando $\delta = 0$) para un período más adelante está dado por:

$$\hat{Y}_{T+1} = E(Y_{T+1}/\Omega_T) = Y_T + E(\varepsilon_{T+1}/\Omega_T) = Y_T \quad (9.7)$$

Para dos períodos más adelante es:

$$\hat{Y}_{T+2} = E(Y_{T+2}/\Omega_T) = E(Y_{T+1} + \varepsilon_{T+2}) \quad (9.8)$$

$$\hat{Y}_{T+2} = E(Y_T + \varepsilon_{T+1} + \varepsilon_{T+2}) = Y_T \quad (9.9)$$

Del mismo modo, el pronóstico para h períodos más adelante es también Y_T . Sin embargo, aunque el pronóstico $\hat{Y}_{T+h}$ será el mismo independiente de h , la varianza del pronóstico crecerá conforme h se haga mayor.

Para un período, el error de pronóstico es:

$$\hat{\varepsilon}_{T+1} = Y_{T+1} - \hat{Y}_{T+1} = \underbrace{Y_T + \varepsilon_{T+1}}_{Y_{T+1}} - \underbrace{Y_T}_{\hat{Y}_{T+1}} = \varepsilon_{T+1} \quad (9.10)$$

y su varianza:

$$V(\hat{\varepsilon}_{T+1}) = \sigma_{\varepsilon}^2 \quad (9.11)$$

El error de pronóstico y su varianza para dos períodos es:

$$\hat{\varepsilon}_{T+2} = Y_{T+2} - \hat{Y}_{T+2} = Y_{T+1} + \varepsilon_{T+2} - Y_T = Y_T + \varepsilon_{T+1} + \varepsilon_{T+2} - Y_T = \varepsilon_{T+1} + \varepsilon_{T+2} \quad (9.12)$$

$$V(\hat{\varepsilon}_{T+2}) = E\left[(\varepsilon_{T+1} + \varepsilon_{T+2})^2\right] = E(\varepsilon_{T+1}^2) + 2E(\cancel{\varepsilon_{T+1}\varepsilon_{T+2}}) + E(\varepsilon_{T+2}^2) \quad (9.13)$$

$$V(\hat{\varepsilon}_{T+2}) = 2\sigma_{\varepsilon}^2 \quad (9.14)$$

Sucesivamente, la varianza del error de pronóstico para h períodos más es:

$$V(\hat{\varepsilon}_{T+h}) = h\sigma_{\varepsilon}^2 \quad (9.15)$$

De esta forma, el error estándar del pronóstico se incrementa con la raíz cuadrada de h . Por lo tanto, se pueden obtener intervalos de confianza para los pronósticos, los que se volverán más amplios conforme aumente el horizonte del pronóstico.

Un extensión simple de este proceso consiste en agregar una tendencia en la serie, de tal forma de agregar también una tendencia al pronóstico:

$$Y_t = \delta + Y_{t-1} + \varepsilon_t \quad (9.16)$$

$$\hat{Y}_{T+1} = E(Y_{T+1}/\Omega_T) = Y_T + \delta + E(\varepsilon_{T+1}/\Omega_T) = Y_T + \delta \quad (9.17)$$

Para h períodos más adelante es:

$$\hat{Y}_{T+h} = Y_T + h \cdot \delta \quad (9.18)$$

Sin embargo, el error de pronóstico y su respectiva varianza será igual que el caso sin tendencia.

Figura 9.1
Pronóstico de un Paseo Aleatorio Sin Tendencia





Figura 9.2
Pronóstico de un Paseo Aleatorio Con Tendencia



9.2 Procesos ARIMA

El paseo aleatorio expuesto anteriormente ha sido obtenido admitiendo que la raíz de la parte AR de los procesos AR(1) es unitaria, con lo que se convierte en no estacionario.

Esta idea puede generalizarse para cualquier proceso ARMA, permitiendo una o varias raíces unitarias en el operador AR. Se obtienen entonces procesos del tipo:

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)(1 - L)^d Y_t = (1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q) \varepsilon_t \quad (9.19)$$

$$\phi(L) \Delta^d Y_t = \theta(L) \varepsilon_t \quad (9.20)$$

$$\phi(L) w_t = \theta(L) \varepsilon_t \quad (9.21)$$

La serie Y_t es no estacionaria homogénea de orden d , si la serie $w_t = \Delta^d Y_t$ es estacionaria. Entonces, Y_t es un proceso autorregresivo integrado de media móvil de orden (p, d, q) y se denomina ARIMA (p, d, q) . Si se aplican diferencias de orden d a Y_t se obtiene un proceso estacionario w_t del tipo ARMA (p, q) .

En esta notación p es el orden de la parte autorregresiva estacionaria, d es el número de raíces unitarias (orden de integración del proceso) y q es el orden de la parte media móvil.

El paseo aleatorio es el modelo ARIMA $(0, 1, 0)$ que se caracteriza porque su función de autocorrelación simple tiene coeficientes que decrecen lentamente. Todos los procesos ARIMA no estacionarios tienen esta propiedad general.

En consecuencia, la FAS tendrá coeficientes positivos que se amortiguarán linealmente y pueden ser distintos de cero incluso para valores altos de k . Esta propiedad de persistencia de valores positivos en el correlograma (aunque sean pequeños) y de decrecimiento lineal caracteriza a los procesos no estacionarios.

Sin embargo, la diferenciación de una serie para convertirla en estacionaria sólo es adecuado cuando nos encontramos ante tendencias estocásticas, nunca cuando estamos ante tendencias deterministas.

En el caso de tendencia determinista, el procedimiento habitual es de aplicar sobre la serie original un filtro sencillo: se estima la regresión de la serie no estacionaria Y_t sobre un término de tendencia determinista obteniéndose una estimación de la serie original $Y_t : \hat{Y}_t = \hat{\beta}_0 + \hat{\beta}_1 t$

Luego, es suficiente trabajar con la expresión:

$$\tilde{Y}_t = Y_t - \hat{Y}_t = Y_t - (\hat{\beta}_0 + \hat{\beta}_1 t) \quad (9.22)$$

9.2.1 Identificación de Procesos ARIMA

El objetivo de esta etapa es buscar un proceso ARMA que haya podido generar la serie temporal, es decir, que se adapte lo mejor posible a las características de dicha serie. Pero esos procesos son estacionarios, por lo que habrá que efectuar un análisis de la estacionariedad de los datos.

Para analizar la estacionariedad de una serie, se utilizan los siguientes instrumentos:

- **Representación Gráfica.** Si el gráfico de la serie temporal presenta fluctuaciones cuya amplitud cambia para distintos intervalos del período muestral, se pensará que el proceso que genera la serie es no estacionario. Lo mismo sucede cuando la tendencia es creciente o decreciente con el tiempo.
- **El Correlograma.** El hecho de que la función de autocorrelación simple decrece muy lentamente al aumentar el retardo, ha demostrado ser una señal de tendencia no estacionaria. Puesto que en la práctica se dispone de una realización de un proceso estocástico, podemos obtener los coeficientes de autocorrelación muestral y, a partir de ellos, el correlograma muestral. Una vez representado el correlograma muestral, se conoce si la serie es o no estacionaria.
- **Mediante Contrastes de Raíces Unitarias.** Son válidos para determinar si existe tendencia determinística o estocástica; se verán más adelante.

- **Gráfico Desviación Típica de la Media.** Si conforme crece la media, la desviación típica aumenta, la varianza del proceso es creciente.

Si la serie temporal no es estacionaria se aplican las transformaciones adecuadas con objeto de convertirla en estacionaria.

Cuando la serie presente **no estacionariedad en media**, se suele aplicar el proceso de diferenciación. Pero, a veces, la toma de diferencias no es suficiente para obtener series estacionarias en media y en varianza.

Una solución consiste en fijar logaritmos de la serie, teniendo en cuenta que posteriormente hay que deshacer el cambio de variable. En series económicas que están afectadas por una fuerte tendencia, suele ser necesario efectuar alguna transformación del tipo Box-Cox, para obtener **una serie estacionaria en varianza**.

Una vez estacionaria, se determinará el orden de la parte autorregresiva (p) y el de la parte de medias móviles (q) del proceso ARMA, que se considere haya podido generar la serie estacionaria.

Para tal fin se utilizan el correlograma estimado y la función de autocorrelación parcial estimada. Esta última puede obtenerse de dos formas alternativas, prácticamente equivalentes: mediante el sistema de Yule-Walker, y mediante el método de regresión (MCO o MV).

Se puede utilizar el sistema de Yule-Walker para estimar los coeficientes de autocorrelación parcial a partir de los simples estimados:

$$\hat{\phi}_{11} = \hat{\rho}_1 = \frac{\hat{\gamma}_1}{\hat{\gamma}_1} \quad (9.23)$$

$$\begin{pmatrix} \hat{\phi}_{21} \\ \hat{\phi}_{22} \end{pmatrix} = \begin{pmatrix} 1 & \hat{\rho}_1 \\ \hat{\rho}_1 & 1 \end{pmatrix} \begin{pmatrix} \hat{\rho}_1 \\ \hat{\rho}_2 \end{pmatrix} \quad (9.24)$$

$$\begin{pmatrix} \hat{\phi}_{31} \\ \hat{\phi}_{32} \\ \hat{\phi}_{33} \end{pmatrix} = \begin{pmatrix} 1 & \hat{\rho}_1 & \hat{\rho}_2 \\ \hat{\rho}_1 & 1 & \hat{\rho}_1 \\ \hat{\rho}_2 & \hat{\rho}_1 & 1 \end{pmatrix} \begin{pmatrix} \hat{\rho}_1 \\ \hat{\rho}_2 \\ \hat{\rho}_3 \end{pmatrix} \quad (\text{etc.}) \quad (9.25)$$

Luego, los valores de $(\hat{\phi}_{11}, \hat{\phi}_{22}, \hat{\phi}_{33}, \dots, \hat{\phi}_{kk})$ se usan para construir la FAP.

La otra opción para el cálculo de la FAP, consiste en obtener los coeficientes mediante las siguientes regresiones sucesivas:

$$Y_t = \phi_{11}Y_{t-1} + \varepsilon_t \quad (9.26)$$

$$Y_t = \phi_{21}Y_{t-1} + \phi_{22}Y_{t-2} + \varepsilon_t \quad (9.27)$$

$$Y_t = \phi_{k1}Y_{t-1} + \phi_{k2}Y_{t-2} + \dots + \phi_{kk}Y_{t-k} + \varepsilon_t \quad (9.28)$$

Las estimaciones $\hat{\phi}_{kk}$ son la correlación estimada existente entre Y_t e Y_{t-k} , después de eliminar el efecto de $Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}$.

En los modelos $AR(p)$, la FAP presenta los p primeros coeficientes distintos de cero y el resto nulos. La FAS presenta un decrecimiento rápido de tipo exponencial, sinusoidal o ambos. En los modelos $MA(q)$, sucede el patrón opuesto: la FAS se anula para retardos superiores a q y la FAP decrece exponencial o sinusoidalmente.

Sin embargo, la especificación de los modelos ARMA no se ajusta a unas normas tan bien definidas. Por ejemplo, en un modelo $AR(1)$, la FAP es cero para $k > 1$, pero esto no ocurre en un $ARMA(1,1)$, pues a la componente $AR(1)$ hay que superponer la $MA(1)$ cuya FAP converge exponencialmente a cero.

En la práctica, se puede especificar una de las componentes y analizar sus residuos. Si el modelo considerado es un ARMA (2,1) se especifica inicialmente la componente AR(2). Se analizarán estos residuos a través del correlograma y si siguen un MA (1), el proceso completo será un ARMA (2,1).

Para que una serie sea fácilmente identificable hay que considerar un tamaño mayor a 50.

El estimador $\hat{\rho}_k$ de la FAS es una variable aleatoria cuya varianza se estima de forma aproximada (Barlett, 1946) por:

$$V(\hat{\rho}_k) = \frac{1}{T} \left(1 + 2 \sum_{i=1}^{k-1} \hat{\rho}_i^2 \right) \quad (9.29)$$

Con un tamaño muestral suficientemente grande, $\hat{\rho}_k$ se aproxima a una distribución normal. Se puede, por lo tanto, construir un intervalo de confianza al 95%, para contrastar la hipótesis nula de que $\rho_k = 0$ definido por $\pm 1,96\sqrt{V(\hat{\rho}_k)}$.

Si los coeficientes muestrales caen dentro del intervalo, se concluye que los coeficientes de autocorrelación no son significativamente distintos de cero. En la práctica, esta fórmula permite identificar procesos de media móvil, para los cuales ρ_k se anula a partir de algún $k > q$.

Para la FAP, se ha demostrado (Quenouille, 1949) que, en un proceso $AR(p)$:

$$V(\hat{\phi}_{kk}) = \frac{1}{T}, \quad \forall k > p \quad (9.30)$$

por lo que el intervalo de confianza, al 95%, para contrastar $\hat{\phi}_{kk} = 0$ es igual a $\pm 1,96 \frac{1}{\sqrt{T}}$.

Es posible verificar si una muestra procede de un proceso autorregresivo de un orden p^* dado, comprobando si $\hat{\phi}_{kk}$ cae dentro del intervalo para todo $k > p^*$ (es significativamente igual a cero).

En la práctica, se utilizan estas técnicas para calcular intervalos de confianza para todos los coeficientes de autocorrelación parcial estimados, con independencia de cuál sea el tipo de proceso, que se desconoce de antemano.

También hay que identificar la inclusión o no de término independiente (constante). La media del proceso está ligada al mismo, por lo tanto, si la media observada se considera significativamente igual a cero, no se introducirá término independiente en el modelo.

Esta etapa suele plantear ciertas dificultades y su objetivo consiste, en general, en la especificación tentativa de unos pocos modelos con estructuras sencillas. La etapa de estimación y la posterior validación de los resultados confirmarán los indicios o, por el contrario, servirán de fundamento para la reformulación de los modelos propuestos.

9.2.2 Estimación de Procesos ARIMA

Dado que $w_t = \Delta^d Y_t \rightarrow w_t = (1-L)^d Y_t$ se puede construir el siguiente modelo ARMA(p, q):

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) w_t = (1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q) \varepsilon_t \quad (9.31)$$

El objetivo es la estimación de los parámetros ϕ_i y θ_j , para lo cual se dispone de una muestra de tamaño T de la variable Y . Sin embargo, al tomar las diferencias de orden d , quedarán sólo $(T - d)$ datos $(w_1, w_2, \dots, w_{T-d})$.

Es importante insistir en que las hipótesis que se consideran en el proceso de estimación son:

- El error es ruido blanco gaussiano: $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$.
- El proceso es estacionario.
- El proceso es invertible.

Debemos obtener estimaciones de los p parámetros autorregresivos y los q parámetros media móvil. La metodología consiste en elegir los valores de parámetros que minimizan la suma de diferencias al cuadrado entre la serie de tiempo real $w_t = \Delta^d Y_t$ y la ajustada $\hat{w}_t$.

De otra forma, podemos escribir la expresión (9.31) en función de los términos del error gaussiano, considerando eso sí que la parte media móvil es invertible:

$$\Phi(L) w_t = \Theta(L) \varepsilon_t \rightarrow \varepsilon_t = \frac{\Phi(L)}{\Theta(L)} w_t \quad (9.32)$$

Considerando los estimadores $\hat{\phi}$ y $\hat{\theta}$, la expresión sería:

$$\hat{\varepsilon}_t = \frac{\hat{\Phi}(L)}{\hat{\Theta}(L)} w_t \quad (9.33)$$

Luego, se debe minimizar la expresión $\sum_t \hat{\varepsilon}_t^2$.

Si están presentes los términos de media móvil, esta expresión es no lineal, por lo que deben utilizarse métodos de estimación no lineales. Adicionalmente, debe emplearse algún criterio para inicializar la serie (elegir números para los valores iniciales no observada).

Supongamos que un total de $T + d$ observaciones están disponibles para la serie estacionaria homogénea de orden d ; denotamos esta observaciones como $(Y_{-d+1}, \dots, Y_0; Y_1, \dots, Y_T)$. Después de diferenciar la serie d veces, obtenemos la serie estacionaria con T observaciones $(w_1, \dots, w_T)$. El problema consiste ahora en estimar el modelo ARMA(p, q) que se ha especificado para la serie w_t .

Dado que $\hat{\varepsilon}_t$ es un proceso rudo blanco, la **función de log-verosimilitud condicional** asociada al vector de parámetros a estimar es la siguiente:

$$\ell = -T \ln \sigma_\varepsilon - \frac{\sum_t \varepsilon_t^2}{2\sigma_\varepsilon^2} \quad (9.34)$$

Dado que los parámetros a estimar están dentro del segundo término de la derecha, se obtiene que la estimación por máxima verosimilitud condicionada y mínimos cuadrados es la misma.

9.2.3 Inicialización de la Serie

Dado que la expresión $\sum_t \hat{\varepsilon}_t^2$ depende de los valores pasados (está condicionada) la estimación dependerá por lo tanto de la elección de los valores iniciales de la serie.

La solución más común para escoger los valores iniciales de la serie corresponde a establecer que dichos valores iniciales son iguales a sus medias no condicionales.

Las medias no condicionales de los errores ε_t son cero siempre, mientras que si no existe tendencia, la media no condicional de los w_t iniciales también será cero. Esto proporcionará una **aproximación inicial adecuada si los valores reales de ϕ_i no son cercanos a 1 y si T es grande respecto a p y q .**

Un método alternativo es inicializar la serie con las medias condicionales. Sin embargo, este procedimiento es técnicamente difícil y los beneficios poco importantes. Por lo tanto, **se recomienda inicializar las series en cero**. Luego, dado que se consideraron los valores no condicionales para inicializar la serie, los intervalos van de 1 hasta T : $\sum_{t=1}^T \hat{\varepsilon}_t^2$.

Sin embargo, es importante hacer notar que la estimación no lineal de los parámetros, producto de la existencia de media móvil, dependerá de manera importante de los valores con los que se inicialice el proceso iterativo.

Si los valores iniciales están cerca de los verdaderos parámetros, la estimación será más rápida, pero si los valores iniciales son muy diferentes de los reales, puede que incluso el **procedimiento iterativo de calibración no converja**. Para ello, es factible utilizar la función de autocorrelación muestral. De hecho, pueden **utilizarse las ecuaciones de Yule-Walker como estimaciones iniciales**.

Si el modelo contiene una parte MA, se tendrá que las ecuaciones de Yule-Walker que relacionan la función de autocorrelación con los valores de los parámetros no será lineal. Ello implica que se pueden obtener soluciones múltiples para un determinado estimador de la parte MA.

Esto se hace más problemático a medida que aumente q . De hecho, para obtener estimaciones iniciales para la parte $MA(q)$ es necesario resolver q ecuaciones no lineales simultáneas.

Notar que los valores de los parámetros estimados con las ecuaciones de Yule-Walker corresponden a la función de autocorrelación muestral, y son por lo tanto una estimación de la función de correlación real.

De hecho, para muestras pequeñas la función de autocorrelación muestral estará sesgada en forma descendente en relación a la función de autocorrelación real.

Después que se ha estimado el modelo, se utiliza algún procedimiento de verificación diagnóstica para determinar si fue correcta o no la especificación inicial del modelo calibrado. Para ello, esperaríamos que los residuos $\hat{\varepsilon}_t$ se parezcan a los errores verdaderos ε_t , los cuales por suposición no están correlacionados (ruido blanco).

Una vez que el modelo ha pasado la etapa de verificación diagnóstica, puede entonces utilizarse para predicción.

9.2.4 Validación de Procesos ARIMA

Por otra parte, es interesante comprobar la capacidad de ajuste a los datos del modelo propuesto y estimado. Si éste no supera satisfactoriamente este paso, es necesario reformularlo. Cabe decir que los resultados de la comprobación de la validez del modelo suelen dar insinuaciones para proceder a la especificación de uno diferente.

Algunos análisis de validación del modelo son los siguientes:

a) **Análisis de los residuos:**

Se parte de la hipótesis de que el término de error de un modelo ARIMA es ruido blanco. Estos errores son inobservables, pero no ocurre lo mismo con los residuos. Cualquier contraste sobre la perturbación aleatoria debe basarse en los residuos del modelo, los cuales deben seguir el comportamiento de un proceso puramente aleatorio normal. En caso contrario, contendrían información relevante para la predicción.

Con el objeto de estudiar si los residuos se aproximan al comportamiento de un proceso ruido blanco, se disponen de las siguientes herramientas:

b) **Contraste independencia de Box-Pierce y Ljung-Box**

Está destinado a contrastar la independencia o no autocorrelación de los residuos. La autocorrelación se mide por los coeficientes de autocorrelación de los residuos r_k .

Notar que ρ_k corresponde a las autocorrelaciones de Y_t , mientras que r_k está relacionado a las de ε_t .

Es un contraste global acerca de la no autocorrelación de los residuos de las observaciones separadas un número determinado de periodos:
 $H_0 : r_1 = r_2 = \dots = r_k = 0$.

Se utiliza el siguiente estadístico propuesto por Box y Pierce (1970):

$$Q(m) = T \sum_{t=1}^m \hat{r}_t^2 \sim \chi_{m-p-q}^2 \quad (9.35)$$

La elección de m es arbitraria ($m = T/4$). Cuanto mayor sea m el contraste se extenderá a desfases mayores, pero la precisión en la estimación de los r_k es menor y disminuye la potencia del contraste, es decir, aumenta la probabilidad de no rechazar la hipótesis nula cuando es falsa (error tipo 2).

Se rechazará la hipótesis nula si el valor de Q experimental es superior que el teórico o tabulado de la distribución a un nivel de significación dado.

El estadístico de Ljung-Box es:

$$Q(m) = T(T+2) \sum_{t=1}^m \frac{\hat{r}_t^2}{T-t} \sim \chi_{m-p-q}^2 \quad (9.36)$$

Cuanto mayor sea el nivel de significación crítico mayor confianza podemos tener para aceptar la hipótesis nula y viceversa: si toma el valor cero, podemos rechazar la hipótesis nula al 100% de confianza.

c) Representación de la FAS y FAP de los residuos

La serie de residuos es aleatoria si los coeficientes de autocorrelación simple y parcial son significativamente cero. Anderson (1942) ha demostrado que los coeficientes de autocorrelación simples muestrales procedentes de un proceso ruido blanco, siguen asintóticamente la siguiente distribución:

$$\hat{r}_k \sim N\left(0, \frac{1}{T}\right), \quad \forall k \quad (9.37)$$

En consecuencia, bajo la hipótesis de que $r_k = 0$, se construye un intervalo de confianza al 95% de la forma $\pm \frac{1,96}{\sqrt{T}}$. Si algún $\hat{r}_k$ cae fuera de los límites, se rechaza la hipótesis de no autocorrelación. En este caso hay evidencia de no aleatoriedad de la serie.

Además, los errores deberán alternar el signo de su coeficiente de autocorrelación sin ningún criterio obvio.

También, los coeficientes de la FAP deben ser significativamente cero. En la práctica se construyen bandas de confianza utilizando la distribución de una variable ruido blanco cuya varianza es $\frac{1}{T}$ según se ha visto anteriormente.

Hay que tener en cuenta que esta aproximación realizada sobre la varianza no es muy adecuada tanto para la FAS como para la FAP, especialmente en los retardos bajos. Se podría concluir que un coeficiente es estadísticamente no significativo cuando en realidad lo es.

La FAS y la FAP de los residuos del modelo estimado son instrumentos valiosos a la hora de reformular el modelo, en caso de que no se comporten como un proceso ruido blanco.

Supongamos que se ha estimado un AR(1):

$$\hat{Y}_t = \hat{\phi}_1 Y_{t-1} \rightarrow \hat{\varepsilon}_t = Y_t - \hat{\phi}_1 Y_{t-1} \quad (9.38)$$

Después de examinar la FAS y la FAP de la serie $\hat{\varepsilon}_t$, se llega a la conclusión de que sigue un modelo MA(1), no un proceso ruido blanco: $\hat{\varepsilon}_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$.

Sustituyendo en el modelo AR (1):

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1} \quad (9.39)$$

se puede concluir que Y_t es un ARMA(1,1).

d) Representación Gráfica de los residuos

La representación de los residuos en el tiempo permite observar si la varianza es constante y si la media está próxima a cero. Además, se puede verificar si se ajustan a una distribución normal y la existencia de residuos atípicos. Un residuo se considera atípico si el valor absoluto excede en tres o cuatro veces su desviación típica (siendo su media cero).

Para contrastar la existencia de heteroscedasticidad se puede realizar el contraste de White (1980). Su hipótesis nula es que el término de perturbación es homocedástico e independiente de los regresores y que la especificación lineal es correcta. Para contrastar la normalidad se utiliza el contraste de Jarque-Bera (1987).

e) Análisis de los Parámetros Estimados

Primero hay que verificar si los parámetros o coeficientes son significativos. El estadístico de contraste está construido bajo la hipótesis nula de que el coeficiente es cero y sigue una distribución t -student con $T - k$ grados de libertad, con k igual al número de parámetros incluidos.

Si concluimos que alguno no es significativo se puede suprimir.

$$H_0 : \phi_i = 0 \rightarrow \frac{\hat{\phi}_i - \phi_i}{\sqrt{V(\hat{\phi}_i)}} \sim t_{T-k} \quad (9.40)$$

$$H_0 : \theta_j = 0 \rightarrow \frac{\hat{\theta}_j - \theta_j}{\sqrt{V(\hat{\theta}_j)}} \sim t_{T-k} \quad (9.41)$$

$$H_0 : \delta = 0 \rightarrow \frac{\hat{\delta} - \delta}{\sqrt{V(\hat{\delta})}} \sim t_{T-k} \quad (9.42)$$

La aplicación del contraste anterior requiere un contraste de dos colas, pues la hipótesis alternativa considera que puede tomar el coeficiente cualquier valor distinto de cero. Si el valor obtenido es mayor que el teórico tabulado, se rechaza la hipótesis nula y el parámetro es significativo.

Otro aspecto importante es el examen del cumplimiento de las condiciones de estacionariedad e invertibilidad. Si alguna de las raíces (L^*) de:

$$1 - \hat{\phi}_1 L - \hat{\phi}_2 L^2 - \dots - \hat{\phi}_p L^p = 0 \quad (9.43)$$

$$1 - \hat{\theta}_1 L - \hat{\theta}_2 L^2 - \dots - \hat{\theta}_q L^q = 0 \quad (9.44)$$

fuesen inferior a la unidad, **el modelo se rechazaría**.

Si alguna de las raíces de $1 - \hat{\phi}_1 L - \hat{\phi}_2 L^2 - \dots - \hat{\phi}_p L^p = 0$ estuviese próxima a uno, es posible que la serie original esté sub-diferenciada, por lo que puede que precise alguna diferenciación adicional (raíz unitario, no estacionariedad).

Si alguna de las raíces de $1 - \hat{\theta}_1 L - \hat{\theta}_2 L^2 - \dots - \hat{\theta}_q L^q = 0$ está próxima a uno, es posible que el modelo esté sobre-diferenciado.

Si existen raíces comunes $(L_i^* = L_j^*)$, se podría utilizar para las predicciones un modelo con dos parámetros menos, y el modelo sería un ARMA($p-1, q-1$).

Es conveniente también examinar la matriz de correlación entre los coeficientes estimados. Cuando la correlación entre dos coeficientes es próxima a uno, los coeficientes estimados son muy inestables, con lo que podrían cambiar bastante de una muestra a otra.

El modelo estimado para el período muestral puede diferir del que se obtendría para los períodos de predicción. Puede existir este problema siempre que alguna de las correlaciones entre estimadores tome un valor superior a 0,6.

Para evitar este problema, puede ser eficaz eliminar algún parámetro aún a costa de que el grado de ajuste sea más pequeño. No obstante, si todos los coeficientes son significativos no sería aconsejable eliminar coeficientes del modelo.

f) **Análisis de Bondad de Ajuste**

Es factible usar el R^2 y el R^2 ajustado ($\bar{R}^2$). El coeficiente de determinación ajustado penaliza la introducción de parámetros adicionales en el modelo. Si se introducen parámetros adicionales, aunque no sean apropiados, pueden incrementar el R^2 . Para evitar este problema se suele utilizar el coeficiente ajustado.

El modelo se ajusta en mayor medida a los datos cuanto más próximos a la unidad estén los coeficientes de determinación. Pero **sólo son comparables en modelos en los que se hayan tomado idéntico número de diferencias**, debido a que, para que este sea un elemento de comparación directa, la varianza de la variable debe ser la misma.

Si se calcula el coeficiente de determinación R^2 con la varianza de la variable diferenciada una vez, el resultado no será comparable con el calculado a partir del ajuste a un modelo sobre la variable original.

Para paliar el anterior inconveniente, se han propuesto medidas alternativas destacando el estadístico AIC (Akaike Information Criterion), formulado por Akaike (1974). Consiste en seleccionar aquél modelo para el que se obtenga un AIC más bajo. Otra medida es SC (Schwarz Criterion) y cuanto menor sea éste, mejor es el ajuste.

g) **Análisis de Estabilidad**

La construcción de un modelo ARIMA está justificada por su utilización para la predicción. Conviene saber entonces si el modelo estimado para el período muestral sigue siendo válido para períodos futuros.

Se pretende contrastar si el último tramo muestral ha estado generado por la misma estructura que el resto de las observaciones.

Para esta finalidad se puede aplicar el contraste de estabilidad estructural de Chow:

$$F = \frac{\left[\sum_{t=1}^T \hat{\varepsilon}_t^2 - \left(\sum_{t=1}^{T_1} \hat{\varepsilon}_{1t}^2 + \sum_{t=1}^{T_2} \hat{\varepsilon}_{2t}^2 \right) \right] / k}{\left(\sum_{t=1}^{T_1} \hat{\varepsilon}_{1t}^2 + \sum_{t=1}^{T_2} \hat{\varepsilon}_{2t}^2 \right) / (T - 2k)} \sim F_{(k, T-2k)} \quad (9.45)$$

donde k es el número de parámetros a estimar, $T = T_1 + T_2$, $\hat{\varepsilon}_t$ es el residuo del modelo utilizando todo el período muestral, $\hat{\varepsilon}_{1t}$ es el residuo utilizando los T_1 primeros datos, y $\hat{\varepsilon}_{2t}$ es el residuo utilizando los T_2 últimos datos.

Algunos autores aconsejan tomar como segundo tramo muestral un tercio o un cuarto de la muestra. Si la F calculada o experimental es mayor que la tabulada o teórica a un determinado nivel de significación, se rechaza la hipótesis de estabilidad estructural.

9.2.5 Predicción con Procesos ARIMA

Una vez que el modelo ha sido estimado y sometido a la fase de diagnosis, se convierte en un instrumento útil para la predicción. Sea el modelo estimado $\text{ARMA}(p, q)$, para la serie w_t , siendo la serie original Y_t un proceso $\text{ARIMA}(p, d, q)$. Se trata de predecir los valores para la serie no estacionaria Y_t , una vez se haya realizado para la serie w_t estacionaria.

Por ejemplo, si $w_t = Y_t - Y_{t-1}$, donde w_t es estacionaria, la estimación de esta serie para el período $T + 1$ es $\hat{w}_{T+1}$. Luego, la correspondiente predicción de $\hat{Y}_{T+1}$ está dada por $\hat{Y}_{T+1} = \hat{w}_{T+1} + Y_T$. Si hubiera sido una aplicación de segundo orden ($w_t = Y_t - 2Y_{t-1} + Y_{t-2}$), la predicción sería entonces $\hat{Y}_{T+1} = \hat{w}_{T+1} + 2Y_T - Y_{T-1}$.

La mejor predicción puntual es aquella que se obtiene mediante la esperanza matemática condicional a toda la información disponible hasta el período de predicción. La expresión de este predictor es la siguiente:

$$\hat{Y}_{T+1} = E(Y_{T+1} / Y_T, Y_{T-1}, \dots, Y_0) \quad (9.46)$$

$$Y_{T+1} = \delta + \phi_1 Y_T + \phi_2 Y_{T-1} + \dots + \phi_p Y_{T-p+1} + \varepsilon_{T+1} - \theta_1 \varepsilon_T - \theta_2 \varepsilon_{T-1} - \dots - \theta_q \varepsilon_{T-q+1} \quad (9.47)$$

Tomando esperanzas condicionadas, se obtiene:

$$\hat{Y}_{T+1} = \delta + \phi_1 Y_T + \phi_2 Y_{T-1} + \dots + \phi_p Y_{T-p+1} - \theta_1 \varepsilon_T - \theta_2 \varepsilon_{T-1} - \dots - \theta_q \varepsilon_{T-q+1} \quad (9.48)$$

donde todas las variables con subíndices inferiores a $T+1$, dejan de ser aleatorias, por lo que sus esperanzas matemáticas coinciden con sus realizaciones y $E(\varepsilon_{T+1}) = 0$, por hipótesis.

Después de obtener $\hat{Y}_{T+1}$ se calcula $\hat{Y}_{T+2}$, y así sucesivamente. Los ε_t son inobservables, por lo que hay que sustituirlos por sus estimaciones, que se obtienen a través de los sucesivos residuos del modelo.

Si algún residuo no es posible obtenerlo, se considera igual a su media teórica: cero. Esta solución es aceptable si el proceso es invertible, dado que, en ese caso, la importancia de los valores iniciales tiende a desaparecer a medida que aumenta el tamaño muestral.

Cuando dispongamos de los valores observados, se utilizan para efectuar la predicción; si no se conocen, se utilizan sus estimaciones en períodos anteriores. A medida que el horizonte de la predicción crece, la predicción por puntos de un modelo ARMA tiende a la media.

a) Error de Predicción

La predicción de una variable aleatoria como es Y_t conlleva incertidumbre, pues depende de la muestra considerada; entonces aparece un error de predicción.

Si se conociesen los valores exactos de los coeficientes, cosa imposible en la mayoría de los casos, sería posible obtener una expresión del error de predicción como sigue:

$$\hat{\varepsilon}_{t+s} = Y_{t+s} - \hat{Y}_{t+s} \quad (9.49)$$

Escribamos el proceso ARMA, como un proceso de medias móviles de infinitos términos, mediante sustituciones sucesivas:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_{t+1} - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q} \quad (9.50)$$

$$Y_t = \tilde{\delta} + \varepsilon_t + \psi_1 \varepsilon_{t-1} + \psi_2 \varepsilon_{t-2} + \psi_3 \varepsilon_{t-3} + \dots \quad (9.51)$$

$$Y_{t+s} = \tilde{\delta} + \varepsilon_{t+s} + \psi_1 \varepsilon_{t+s-1} + \psi_2 \varepsilon_{t+s-2} + \dots + \psi_{s-1} \varepsilon_{t+s-s-1} + \sum_{j=0}^{\infty} \psi_{s+j} \varepsilon_{t-j} \quad (9.52)$$

La predicción $\hat{Y}_{t+s}$ se puede basar únicamente en la información disponible hasta el período t .

Escribimos la predicción como una suma ponderada de los términos de error que podemos estimar:

$$\hat{Y}_{t+s} = \tilde{\delta} + \sum_{j=0}^{\infty} \hat{\psi}_{s+j} \varepsilon_{t-j} \quad (9.53)$$

donde las ponderaciones $\hat{\psi}_{s+j}$ se elegirán de manera que minimicen el Error Cuadrático Medio de predicción. Luego, y considerando (9.52) y (9.53), el error de predicción es:

$$\hat{\varepsilon}_{t+s} = Y_{t+s} - \hat{Y}_{t+s} \quad (9.54)$$

$$\hat{\varepsilon}_{t+s} = \varepsilon_{t+s} + \psi_1 \varepsilon_{t+s-1} + \psi_2 \varepsilon_{t+s-2} + \dots + \psi_{s-1} \varepsilon_{t+s-s-1} + \sum_{j=0}^{\infty} (\psi_{s+j} - \hat{\psi}_{s+j}) \varepsilon_{t-j} \quad (9.55)$$

El error cuadrático medio de predicción, considerando que $E(\varepsilon_i, \varepsilon_j) = 0$ es de la forma:

$$E\left[(\hat{\varepsilon}_{t+s})^2\right] = \sigma_{\varepsilon}^2 (1 + \psi_1^2 + \psi_2^2 + \dots + \psi_{s-1}^2) + \sigma_{\varepsilon}^2 \sum_{j=0}^{\infty} (\psi_{s+j} - \hat{\psi}_{s+j})^2 \quad (9.56)$$

Dado que el error cuadrático medio se minimiza cuando $\psi_{s+j} = \hat{\psi}_{s+j}$, finalmente se obtiene:

$$\hat{\varepsilon}_{t+s} = \varepsilon_{t+s} + \psi_1 \varepsilon_{t+s-1} + \psi_2 \varepsilon_{t+s-2} + \dots + \psi_{s-1} \varepsilon_{t+s-s-1} \quad (9.57)$$

$$V(\hat{\varepsilon}_{t+s}) = E\left[(\hat{\varepsilon}_{t+s})^2\right] = \sigma_\varepsilon^2 (1 + \psi_1^2 + \psi_2^2 + \dots + \psi_{s-1}^2) \quad (9.58)$$

El uso más importante de los errores de predicción es la construcción de intervalos de confianza para la predicción. El intervalo de predicción para el pronóstico de Y_{t+s} es, al 95%, $\hat{Y}_{t+s} \pm 1,96\sigma_\varepsilon \sqrt{(1 + \psi_1^2 + \psi_2^2 + \dots + \psi_{s-1}^2)}$.

El cálculo de los parámetros ψ_i se obtiene a partir de las siguientes relaciones:

$$\phi(L)Y_t = \theta(L)\varepsilon_t \rightarrow Y_t = \underbrace{\phi(L)^{-1}\theta(L)}_{\psi(L)}\varepsilon_t = \psi(L)\varepsilon_t \quad (9.59)$$

b) Capacidad de Predicción

Podemos verificar si el modelo sigue siendo válido para los períodos de predicción, una vez se ha comprobado su validez para el periodo muestral.

Para ello, se utiliza el siguiente estadístico:

$$\frac{\sum_{s=0}^h \hat{\varepsilon}_{t+s+1/t+s}^2}{\hat{\sigma}_\varepsilon^2} \sim \chi_h^2 \quad (9.60)$$

Donde $\hat{\varepsilon}_{t+s+1/t+s}^2$ es el error de predicción de Y_{t+s+1} utilizando la información disponible en el momento $(t + s)$ y $\hat{\sigma}_\varepsilon^2 = \frac{\sum \hat{\varepsilon}_t^2}{T-k}$, con k el número de parámetros del modelo ($k = p + q$).

Si el valor calculado en **¡Error! No se encuentra el origen de la referencia.** supera al tabulado, habrá diferencias significativas entre los verdaderos valores y los estimados, por lo que se rechazará la hipótesis nula de estabilidad.

9.3 Orden de Integración de una Serie: Métodos No Paramétricos

El orden de integración se puede determinar de diversas formas. Una de ellas es el uso de métodos no paramétricos.

Estos métodos tienen la ventaja de que no es necesario formular ninguna hipótesis ni calcular la distribución de un estadístico bajo dicha hipótesis. Por contra, suelen ser bastante subjetivos y no tan fiables como los métodos paramétricos. En cualquier caso, siempre pueden darnos pistas sobre el orden de integración de la variable.

Es recomendable considerar estos métodos no paramétricos antes de calibrar los modelos.

En esta sección vamos a considerar tres métodos alternativos: **estudio de la función de autocorrelación, sobrediferenciación de la serie y estudio de la varianza para diversos órdenes de integración**. No es conveniente utilizarlos de forma separada, sino que lo más habitual es usarlos conjuntamente.

9.3.1 Análisis de la Función de Autocorrelación


Supongamos que tenemos un proceso autorregresivo de orden 1. Su función de autocorrelación es igual a $\rho_k = \phi_1^k$. Esta función de autocorrelación decae hacia 0, pero sólo se anula en el infinito.

Entonces, el decaimiento que se observa en la función de autocorrelación de la variable depende del valor del parámetro ϕ_1 . Si este toma, por ejemplo, un valor igual a 0.5, entonces para $k = 5$ el coeficiente de la función de autocorrelación es igual a 0.03. Si $\phi_1 = 0.8$, entonces $\rho_5 = 0.33$, mientras que la función de autocorrelación toma el valor 0.03 cuando $k = 16$.

Esto conlleva que **cuanto mayor es el valor del parámetro autorregresivo más lenta es la convergencia** hacia 0 de la función de autocorrelación.

Si consideramos el caso límite, $\phi_1 = 1$, en el que el proceso no es estacionario, la función de autocorrelación debería expresar un decaimiento muy lento hacia 0, con abundantes valores distintos de 0.

Figura 9.3
Correlogramas Para Distintos Procesos



El problema que presenta este procedimiento es su subjetividad. No queda claro cuándo podemos considerar que el primer valor del coeficiente de autocorrelación está suficientemente próximo a la unidad, ¿basta con 0,7 o tiene que ser igual a 0,9999?;

Tampoco queda claro cuándo el valor está próximo a 0, ni cuánto valores de la función de autocorrelación deben ser distintos de 0 para considerar que el decaimiento hacia 0 es lento.

9.3.2 Sobrediferenciación

La justificación de este método es la siguiente. Supongamos que tenemos un proceso estacionario, un ruido blanco por ejemplo: $Y_t = \varepsilon_t$. Si tomamos primeras diferencias, entonces el modelo se convierte en:

$$Y_t - Y_{t-1} = \varepsilon_t - \varepsilon_{t-1} \rightarrow (1-L)Y_t = (1-L)\varepsilon_t \quad (9.61)$$

y que es igual a:

$$\Delta Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad (9.62)$$

Esto lo podemos interpretar diciendo que la variable ΔY_t sigue un proceso MA(1) no invertible con parámetro $\theta_1 = -1$. Esta no invertibilidad nos está indicado que el proceso está sobre diferenciado.

Si tomamos en consideración ahora la forma que adopta la función de autocorrelación de un MA(1), es directo comprobar que el primer valor de esta función será igual a:

$$\rho_1 = \frac{\theta_1}{1 + \theta_1^2} = \frac{-1}{1 + 1} = -0,5 \quad (9.63)$$

y el resto de los valores serán iguales a 0.

A partir de este resultado particular, podemos sacar la conclusión para el caso general y decir que **si la serie que estamos analizando está sobrediferenciada, su función de autocorrelación exhibe un comportamiento de medias móviles con primer valor de la función de autocorrelación próximo a -0,5.**

Entonces, el proceso a seguir es el siguiente.

- En primer lugar debemos estudiar la función de autocorrelación simple (FAS) de la serie en niveles (Y_t).
- Si tenemos dudas sobre el decaimiento lento hacia 0, entonces debemos calcular la FAS para la variable diferenciada (ΔY_t).

- Si ésta presenta un comportamiento similar al de un MA(1), con su primer coeficiente próximo a $-0,5$ podemos concluir que está sobrediferenciada y concluir que la variable es estacionaria en niveles (valores originales de la serie sin diferenciar). En caso contrario, es posible concluir que la serie es integrada.

9.3.3 Análisis de la Varianza

Un método asociado al caso anterior es el estudio de la varianza de la variable para diversos órdenes de integración. La justificación del método es la siguiente. Supongamos que la variable está generada por un paseo aleatorio $Y_t = Y_{t-1} + \varepsilon_t$. La varianza de la variable Y_t es igual a $V(Y_t) = t\sigma^2$.

Por tanto, es una varianza que tiene hacia infinito. Si tomamos primeras diferencias, el modelo anterior nos queda de la siguiente manera:

$$\Delta Y_t = \varepsilon_t \quad (9.64)$$

Por tanto, es inmediato comprobar que la varianza de la variable en primeras diferencias es $V(\Delta Y_t) = \sigma^2$.

Por último, si sobrediferenciamos la variable anterior, el modelo queda así:

$$\Delta^2 Y_t = \Delta^2 \varepsilon_t = \varepsilon_t - \varepsilon_{t-1} \quad (9.65)$$

de lo que se desprende que $V(\Delta Y_t) = V(\varepsilon_t - \varepsilon_{t-1}) = V(\varepsilon_t) + V(\varepsilon_{t-1}) = 2\sigma^2$.

En virtud de estos resultados, el procedimiento a seguir sería obtener la varianza de la variable que estamos analizando para diversos valores del parámetro de diferenciación d . **El orden de integración seleccionado sería aquel para el que la varianza de la variable se minimiza.**

10 RAÍCES UNITARIAS Y COINTEGRACIÓN

Los métodos de estimación que se usan habitualmente en los trabajos económicos aplicados suponen que las medias y varianzas de las variables son constantes, bien definidas e independientes del tiempo. Sin embargo, estas suposiciones no son satisfechas por un gran número de series temporales de tipo económico. Las variables cuyas medias y varianzas cambian a lo largo del tiempo se dicen no estacionarias o con raíces unitarias. **Utilizar métodos clásicos de estimación como MCO para estimar relaciones con variables no estacionarias produce inferencias erróneas.**

Si las medias y varianzas de las variables “raíz unitaria” cambian a lo largo del tiempo, **todos los estadísticos computados en un modelo de regresión, que usa estas medias y varianzas, también dependen del tiempo y no convergen a su verdadero valor cuando el tamaño muestral aumenta.** Incluso los contrastes convencionales de hipótesis estarán muy sesgados hacia el rechazo de la hipótesis nula de no relación entre las variables dependiente e independiente.

La aplicación de técnicas de cointegración y raíces unitarias son fundamentales para entender los siguientes aspectos:

- Determinar si las variables en una regresión son o no estacionarias.
- Estimar si las variables satisfacen ciertas condiciones. Estas regresiones de cointegración son las relaciones de equilibrio o a largo plazo entre esas variables.

10.1 Tendencias Determinísticas y Estocásticas

10.1.1 Tendencia Determinística

En un gran número de ocasiones, las series pueden no presentar componente tendencial alguno, como es el caso de un proceso autorregresivo puro AR(1) en el que los coeficientes cumplan las condiciones de estacionariedad:


$$Y_t = \delta + \phi_1 Y_{t-1} + \varepsilon_t \quad (10.1)$$

Definir una tendencia en una serie temporal Y_t es extremadamente sencillo. Por ejemplo, la serie:

$$Y_t = \delta + \beta t + \varepsilon_t \quad (10.2)$$

La serie (10.2) presenta obviamente un patrón dominado fundamentalmente por una **tendencia lineal**. Este tipo de proceso, se clasifica dentro de aquellos que vienen definidos por lo que se denomina una **tendencia determinista**.

Figura 10.1
Proceso con Tendencia Determinista



Esta tendencia de tipo determinista puede combinarse con el proceso autorregresivo presentado en (10.2), para generar otra variedad de proceso con tendencia determinista que se denomina **proceso estacionario sobre una tendencia**. Su expresión sería la siguiente:

$$Y_t = \delta + \beta t + \phi_1 Y_{t-1} + \varepsilon_t \quad (10.3)$$

En este caso, el proceso es dominado por la componente tendencial (para un valor razonable de la varianza de ε_t) por lo que distinguir gráficamente su evolución temporal de un modelo tendencial determinista puro resulta casi imposible; es decir, diferenciar (10.2) de (10.3) es muy difícil.

10.1.2 Tendencia Estocástica

Si observamos algunas series en economía, podríamos caer en la tentación de calificarlas entre aquellas con tendencias deterministas como las observadas hasta aquí. Sin embargo, desde la teoría económica sería muy difícil justificar una tendencia determinista de este tipo en cualquiera de las series representadas en el acápite anterior. **Aún a pesar de existir componentes tendenciales importantes desde el punto de vista teórico, seguramente estos no serían de naturaleza determinista.**

Por ejemplo, es muy posible que la productividad tienda a crecer de forma “natural” en la medida en que, con el paso del tiempo, se va produciendo la mejora tecnológica de los procesos productivos. También es “natural” que el valor añadido nominal en determinados productos (como los servicios) tienda a crecer incluso de forma ligeramente exponencial a medida que una economía va alcanzando ciertos niveles de desarrollo.

Sin embargo, ambos procesos teóricos no se producirán, con total seguridad, de una manera invariable, constante, predecible y determinista, con el paso del tiempo.


Frente a la tendencia determinista surge por tanto la necesidad de definir un componente tendencial, con **efectos permanentes** en la evolución de la serie analizada, pero de **naturaleza estocástica**. El caso más común es el paseo aleatorio con deriva:

$$Y_t = \delta + Y_{t-1} + \varepsilon_t \rightarrow E(Y_t) = \delta \cdot t + Y_0 \quad (10.4)$$

En cualquier caso, es evidente que el paseo aleatorio con deriva resulta gráficamente muy similar al presentado en (10.2) o en (10.3). Esto explica que, frecuentemente, se califiquen como deterministas series que, probablemente, presenten un componente tendencial estocástico.

Solamente para **muestras grandes un proceso podrá ser distinguido del otro** en la medida en que, aunque el paseo aleatorio con deriva presentará una marcada evolución tendencial, **tenderá a fluctuar de forma algo más visible sobre la línea tendencial** de lo que lo haría un modelo determinista puro.

Figura 10.2
Proceso con Tendencia Estocástica



Debe tenerse especial cuidado para no confundir la tendencia determinista y estocástica, ya que entonces tanto uno como otro método resultarían incorrectos de aplicar. Por ejemplo, si estamos ante un proceso del tipo:

$$\phi(L)Y_t = \beta_0 + \beta_1 t + \theta(L)\varepsilon_t \quad (10.5)$$

en el que tenemos tendencia determinista pero no estocástica, si tomamos una primera diferencia la anterior expresión quedaría:

$$\phi(L)\Delta Y_t = \beta_1 + (1-L)\theta(L)\varepsilon_t \quad (10.6)$$

Luego, **habríamos eliminado la tendencia temporal pero habríamos introducido una raíz unitaria en el proceso MA, que ahora sería no invertible**. Debe notarse que este problema también se planteará, por las mismas razones, en el caso en el que **sobrediferenciamos una serie** más allá de su orden de integración.

Análogamente, cometemos un error aún más importante si intentamos transformar un modelo con tendencia estocástica aplicando el filtro para la eliminación de la tendencia determinista:

- En primer lugar, el estadístico “ t ” de significación individual **tiende a infinito para la variable de tendencia determinista introducida en el filtro**. Además es inconsistente, por lo que resulta fácil rechazar erróneamente la hipótesis de nulidad del parámetro de tendencia.
- El R^2 converge a una distribución no degenerada, es decir, a medida que el tamaño de la muestra se incrementa no convergen hacia un escalar, sino hacia una variable aleatoria.

Un efecto adicional comentado por Durlauf y Phillips (1988) es que, en estos casos, **el estadístico DW de la errónea regresión de la serie sobre una tendencia temporal tiende a acercarse a cero**.

10.2 Regresión Espuria

El problema de las regresiones espurias es que tienden a admitirse como buenas, **relaciones económicas que, en realidad, sólo se deben a aspectos casuales.**

Por regresión espuria entendemos técnicamente aquellas ecuaciones de regresión que presentan una **elevada significatividad conjunta**, medida en términos del coeficiente de determinación R^2 o $\bar{R}^2$ y, sin embargo, **fuertes problemas de autocorrelación positiva** (reflejados en bajos valores del estadístico Durbin – Watson).

La presencia de un término de error fuertemente autocorrelacionado impide efectuar un proceso de inferencia con mínimas garantías. La probabilidad de un error en el cálculo y en la aplicación de los test de significancia individual convencionales es muy importante, sin contar los problemas de ineficiencia en la estimación propios de una situación de matriz de varianzas y covarianzas no escalar para la perturbación aleatoria.

Este tipo de regresiones aparecen **cuando se relacionan series temporales no estacionarias** y se agudizan más cuando estas estén más cercanas a la forma de un **paseo aleatorio**, es decir, cuanto más evidente sea la presencia de tendencias estocásticas en las series.

Supongamos dos variables Y_t y X_t independientemente generadas por paseos aleatorios:

$$\begin{aligned} Y_t &= Y_{t-1} + u_t \\ X_t &= X_{t-1} + v_t \end{aligned} \tag{10.7}$$

donde u_t y v_t son variables aleatorias normales estándar independientes entre sí con media cero y varianza unitaria (ruidos blancos). Dado que Y_t y X_t están generadas de forma independiente, deberíamos esperar que no existiera ninguna relación significativa entre ambas.

Sin embargo, sobre un conjunto de 1.000 muestras de Y_t y X_t con 50 observaciones, alrededor de un 65% de las regresiones de Y_t sobre X_t presentan contrastes “t” significativos a un nivel de significatividad del 5%, generando un resultado absurdo.

Efectivamente, en la regresión:

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t \quad (10.8)$$

es claro que, prescindiendo de la constante β_0 , se obtiene:

$$\varepsilon_t = Y_t - \beta_1 X_t \quad (10.9)$$

por lo que imponiendo las restricciones iniciales $Y_0 = X_0 = 0$ tenemos que:

$$\varepsilon_t = \sum_{i=0}^T u_i - \beta_1 \sum_{i=0}^T v_i \quad (10.10)$$

Por tanto, es obvio que estamos ante una **secuencia ε_t no estacionaria en varianza**. Si esto es así, $\hat{\varepsilon}_t$ presenta una tendencia estocástica, lo que quiere decir que el error cometido en “ t ” no se diluye en $t + 1$, $t + 2$, ..., $t + s$; es imposible por lo tanto que una regresión en la que los errores se acumulan de forma permanente pueda tener algún interés.

Nótese que en esta situación **se violan algunas hipótesis básicas** asumidas en los procesos de inferencia habituales en el contexto del Modelo Básico de Regresión Lineal (MCO):

- **La varianza de ε_t ya hemos dicho que no es constante.** En la expresión (10.10) anterior puede comprobarse con sencillez cómo se incrementa **hacia el infinito a medida que t crece**.
- **No existe incorrelación serial.** La misma expresión para (10.10) puede utilizarse para comprobar cómo la correlación entre ε_t y ε_{t+1} tiende a uno a medida que t se incrementa.

Dada esta acumulación de errores de base, **ningún test de significancia puede ser usado con garantías** y, por ello, ninguna inferencia será fiable.

10.3 Detección de Raíces Unitarias

10.3.1 Análisis Gráfico de la Serie

Uno de los métodos que suelen proponerse como suficientes para la detección de la no estacionariedad de una serie es, erróneamente, el del análisis de representaciones gráficas de la misma.

Así, se dice que la simple contemplación del gráfico de evolución temporal de la serie permite decidir si la serie es o no estacionaria en virtud, por ejemplo, de la pendiente que presente.

Efectivamente, pueden confundirse con facilidad representaciones gráficas de procesos con tendencias estocásticas con procesos con tendencias deterministas.

Por otro lado, incluso con procedimientos técnicamente elaborados, resulta aún más complejo diferenciar, por ejemplo, un proceso con una raíz unitaria de otro con una raíz autorregresiva elevada.

No obstante, **a pesar de que el análisis gráfico no puede considerarse una herramienta suficiente para el análisis de la estacionariedad de una serie, si ha de servir como etapa previa a la aplicación de contrastes más avanzados.**

Efectivamente, observar la evolución gráfica de la serie puede permitir localizar cambios de estructura, comportamientos estacionales o medias y tendencias de tipo determinista, lo que permitirá aplicar, con mayor porcentaje de éxito, los test clásicos de raíces unitarias.

10.3.2 Análisis del Correlograma Simple de la Serie

Un procedimiento sencillo que no requiere la aplicación de ningún contraste para determinar la presencia de raíces unitarias en las series, es el de observar el correlograma de la misma, es decir, **la representación gráfica de su función de autocorrelación simple** (FAS).

Distintos trabajos, pero en especial los presentados por Hoskin (1989), Diebold y Rudebusch y Lo (1991), se han centrado en analizar las variaciones de la autocorrelación en función del orden de integración “ d ” de una serie.

En general, la regla a aplicar será sencilla: **los valores de la FAS de una serie con raíces unitarias descienden muy suavemente hacia el cero mientras que cuando no hay presencia de raíces unitarias el descenso es exponencial.**

La serie integrada es una serie de memoria ilimitada (precisamente por presentar un componente tendencial), la serie no integrada guarda sólo memoria de los “shocks” más recientes.

De esta forma, si la serie no estacionaria guarda memoria de los shocks pasados y recientes, la relación entre dos valores separados por un lapso de tiempo “ s ” presentarán necesariamente algún tipo de relación, o sea, **los coeficientes de correlación entre Y_t e Y_{t-s} tenderán a mantenerse elevados.**

Efectivamente, la expresión genérica de la solución de una ecuación en diferencias de primer orden puede expresarse como:

$$Y_t = \phi_1' Y_0 + \sum_{i=0}^{t-1} \phi_1^i \varepsilon_{t-i} \quad (10.11)$$

$$\phi_1 = 1 \rightarrow Y_t = Y_0 + \sum_{i=0}^{t-1} \varepsilon_{t-i} \quad (10.12)$$

A partir de las expresiones (10.11) y (10.12) puede calcularse el coeficiente de autocorrelación entre Y_t e Y_{t-s} para cada caso.

Cuando no existe raíz unitaria, el término ϕ_1 (menor que la unidad) fuerza a los coeficientes de autocorrelación a descender rápidamente hacia el cero en una progresión geométrica de razón ϕ_1 ; recordemos que, efectivamente, la expresión de la serie de coeficientes de autocorrelación es $\rho_k = \phi_1^k$ para un AR(1).

En el segundo caso (10.12), sin embargo, la varianza del proceso contiene un término lineal $(t - s)$, el que define más lento la progresión hacia el cero de los coeficientes de autocorrelación. La expresión de los coeficientes de correlación es ahora $\rho_k = \sqrt{\frac{t-s}{t}}$.

Debe recordarse en este punto que la simple observación del gráfico de la función de autocorrelación puede completarse con el cálculo de algunos conocidos contrastes Q como los propuestos por Box y Pierce (1970) o Ljung y Box (1978):

$$Q_{BP} = T \sum_{k=1}^K \hat{\rho}_k^2 \sim \chi_{T-K}^2 \quad (10.13)$$

$$Q_{LB} = T(T+2) \sum_{k=1}^K \frac{\hat{\rho}_k^2}{T-k} \sim \chi_{T-K}^2 \quad (10.14)$$

Recordemos que, en ambos casos, la hipótesis a contrastar es que los “ p ” primeros coeficientes de correlación calculados $\hat{\rho}_k$ son iguales a cero ($k = 1, 2, \dots, p$). El escalar T será igual al número total de coeficientes de correlación representados en el correlograma.

Estos contrastes se distribuyen como una χ^2 con $(T - k)$ grados de libertad. Dado que lo habitual es aplicarlos sobre los residuos de un modelo ARIMA previamente estimado, para saber si estamos o no ante un ruido blanco, **el parámetro k toma el valor del número de coeficientes estimados de ese modelo ARIMA.**

En cambio, si estamos observando los test directamente sobre una serie, y no sobre los residuos de un modelo, los grados de libertad de la χ^2 serán entonces “ p ”. Si el estadístico supera el valor de tablas rechazaremos la hipótesis nula de que los “ p ” primeros coeficientes son significativamente nulos.

10.3.3 Utilización del Estadístico de Durbin - Watson

El estadístico Durbin Watson (1950), tradicionalmente utilizado para detectar la presencia de autocorrelación de primer orden en los residuos de un modelo estimado por MCO, puede utilizarse según la propuesta de Sargan y Bhargava (1983) para detectar la presencia de una raíz unitaria en una serie temporal Y_t .

El estadístico es de la forma:

$$DW = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=2}^n (\hat{\varepsilon}_t^2)} \quad (10.15)$$

Asumiendo que el residuo, de estar autocorrelacionado, seguiría un modelo simple AR(1), el valor del estadístico fluctuará entre 0 y 4. El límite inferior (0) correspondería a una situación de autocorrelación perfecta positiva, el límite superior (4), a una situación de autocorrelación perfecta negativa y el valor medio (2), mostraría ausencia de autocorrelación.

A fin de utilizar este contraste para la detección de raíces unitarias, la idea es aplicar la expresión (10.15) sobre los residuos del siguiente modelo:

$$Y_t = \beta_0 + \varepsilon_t \quad (10.16)$$

Si los residuos de este modelo están correlacionados de forma perfecta siguiendo un paseo aleatorio, es decir, presentan una raíz unitaria ($\varepsilon_t = \varepsilon_{t-1} + u_t$), también podremos decir que Y_t es integrada de orden 1 ya que podríamos expresar el estadístico DW como:

$$DW = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=2}^n (\hat{\varepsilon}_t^2)} = \frac{\sum_{t=2}^n (Y_t - Y_{t-1})^2}{\sum_{t=2}^n (Y_t - \bar{Y}_t)^2} \quad (10.17)$$

Si esto es así, el estadístico DW tomará el valor 0. Por tanto, la hipótesis a contrastar es si el estadístico DW toma un valor significativamente distinto de cero.

10.4 Contraste de Estacionariedad y de Raíz Unitaria

10.4.1 Contraste de Dickey – Fuller (DF)

Sin duda alguna, el test más habitual a la hora de determinar la estacionariedad de una serie temporal, consiste en la aplicación del test conocido como de Dickey–Fuller (Test DF).

Este es un contraste de **No Estacionariedad** ya que la hipótesis nula es precisamente la presencia de una raíz unitaria en el proceso generador de datos de la serie analizada.

Vamos a suponer inicialmente, como modelo de partida para el análisis de una determinada serie Y_t , el de un proceso estacionario autorregresivo de orden uno sin constante:

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t \quad (10.18)$$

Frente a este modelo se plantea, como hipótesis nula (H_0), el modelo alternativo de un paseo aleatorio no estacionario del tipo:

$$Y_t = Y_{t-1} + \varepsilon_t \quad (10.19)$$

Sin embargo, para contrastar la nulidad del coeficiente ϕ_1 , no podemos utilizar el contraste “t” habitual sobre la estimación por MCO del modelo (10.18).

La razón de ello es que la hipótesis nula que habitualmente se contrasta y, a partir de la cual se deriva la expresión y propiedades del test “t”, es la de nulidad del parámetro ($\phi_1 = 0$) de (10.18); sin embargo, en nuestro caso, necesitaríamos contrastar $H_0 : \phi_1 = 1$.

Si la hipótesis nula fuera cierta ($H_0 : \phi_1 = 1$), la varianza de Y_t no sería estacionaria sino que crecería con los valores de “t” según la expresión de la varianza de un paseo aleatorio con deriva: $V(Y_t) = t\sigma^2$.

En estas condiciones, la estimación del parámetro ϕ_1 sería una estimación consistente pero sesgada a la baja (función de densidad asimétrica) con relación al verdadero valor del parámetro y el uso de la distribución “t” estándar sería incorrecto.

Si $|\phi_1| < 1$, la distribución del estimador es **asintóticamente Normal**, o lo que es lo mismo, el estadístico “t” de Student converge hacia una $N(0,1)$ cuando los grados de libertad tienden a infinito.

En el caso de que $|\phi_1| > 1$, también puede caracterizarse la distribución del estimador del parámetro y de su razón “t”, si bien la convergencia en el límite no se produce hacia una Normal sino a una **Cauchy**.

El problema surge precisamente cuando $|\phi_1| = 1$, ya que en este caso, la distribución del parámetro no puede caracterizarse adecuadamente.

Por tanto, la distribución de probabilidad asintótica del estimador de MCO del modelo AR(1) presenta una “discontinuidad” cuando $|\phi_1| = 1$ y, como sustituto, deberán utilizarse las **distribuciones derivadas de forma empírica mediante un procedimiento de Montecarlo** realizado por Dickey (1976).

En este experimento se generaron un elevado número de series ruido blanco ε_t para construir el mismo número de **paseos aleatorios con término constante**. La estimación de los parámetros de interés en cada uno de esos modelos “controlados” arrojó las siguientes conclusiones:

- El 90% de los valores estimados del parámetro ϕ_1 estaban menos alejados de 2.58 errores estándar del verdadero valor (la unidad).
- El 95% de los valores estimados del parámetro ϕ_1 estaban menos alejados de 2.89 errores estándar del verdadero valor (la unidad).
- El 99% de los valores estimados del parámetro ϕ_1 estaban menos alejados de 3.51 errores estándar del verdadero valor (la unidad).

Tras este experimento de Dickey, fue Fuller (1976) quien obtuvo la distribución límite apropiada y publicó, tabulados, toda una batería de valores críticos, dado que **el valor empírico del contraste varía en función del tamaño muestral**.

En la práctica, por cuestiones de sencillez operativa, el modelo utilizado para el contraste DF no es el expuesto al comienzo del epígrafe (10.18) sino otro, equivalente al anterior, que se obtiene restando a uno y otro lado el término Y_{t-1} :

$$\begin{aligned} Y_t - Y_{t-1} &= \phi_0 + \phi_1 Y_{t-1} - Y_{t-1} + \varepsilon_t \\ \Delta Y_t &= \phi_0 + \underbrace{(\phi_1 - 1)}_{\gamma} Y_{t-1} + \varepsilon_t = \phi_0 + \gamma Y_{t-1} + \varepsilon_t \end{aligned} \quad (10.20)$$

Por lo tanto, la hipótesis nula inicial para (10.18), se transforma ahora en $H_0 : \gamma = 0$ frente a $H_1 : \gamma < 0$.

Decir que γ es nulo es lo mismo que decir que $\phi_1 = 1$, es decir, que existe una raíz unitaria; decir que γ es menor que cero equivale a decir que $\phi_1 < 1$ (proceso autorregresivo estacionario).

El procedimiento básico para la aplicación simple del test DF es, a partir de aquí, aparentemente sencillo:

- Se estima el modelo propuesto y se calcula el valor estimado de la "t" del parámetro analizado
- Una vez calculado se compara con el valor empírico de referencia obtenido con las tablas de Dickey y Fuller
- Si el valor t estimado para el parámetro γ es inferior al tabulado (dado un determinado nivel de confianza), admitiremos la hipótesis nula, o sea, la presencia de una raíz unitaria.

Sin embargo, los valores críticos t de referencia para el contraste DF no sólo dependerán del tamaño muestral, sino también del tipo de modelo estimado (proceso generador de datos supuesto).

Por lo tanto, antes de estimar los parámetros del modelo, hay que decidir si el proceso generador de datos será el simple, como el expuesto anteriormente (10.18), ó contendrá una constante (ϕ_0), un término tendencial determinista (βt), o ambas cosas simultáneamente.

Los tres modelos propuestos por Dickey-Fuller son:

$$\Delta Y_t = \gamma Y_{t-1} + \varepsilon_t \quad (10.21)$$

$$\Delta Y_t = \phi_0 + \gamma Y_{t-1} + \varepsilon_t \quad (10.22)$$

$$\Delta Y_t = \phi_0 + \beta t + \gamma Y_{t-1} + \varepsilon_t \quad (10.23)$$

El contraste simple de DF consiste en determinar el valor del parámetro γ , para lo cual se utilizará su estimador $\hat{\gamma}$. Dicho estimador puede ser obtenido mediante MCO:

Una vez decidido el modelo, el estadístico de referencia para el contraste será diferente, notándose generalmente por las letras t para el caso más simple, t_δ para el caso del modelo con constante y t_t para el caso del modelo con tendencia determinista.

Consultar correctamente el estadístico de referencia es fundamental dado que las diferencias entre los distintos valores de t , t_δ y t_t son importantes. Por ejemplo, para un nivel de significación del 95% y 100 observaciones los valores críticos serían -1.95 para t , -2.89 para t_δ y -3.45 para t_t .

Tal y como describen de forma muy clara Suriñach et al. (1995), los modelos (10.22) y (10.23) presentados por Dickey y Fuller son en realidad formas reducidas de determinados modelos estructurales.

Así, el modelo (10.22), que contrasta la hipótesis nula de paseo aleatorio con deriva (ϕ_0) frente a una alternativa de esquema AR(1) estacionario, es la forma reducida del modelo VAR siguiente:

$$\left. \begin{array}{l} Y_t = \delta + u_t \\ u_t = \phi_1 u_{t-1} + \varepsilon_t \end{array} \right\} \rightarrow \left. \begin{array}{l} u_{t-1} = Y_{t-1} - \delta \\ Y_t = \delta + \phi_1 u_{t-1} + \varepsilon_t \end{array} \right\} \rightarrow Y_t = \underbrace{\delta(1-\phi_1)}_{\phi_0} + \phi_1 Y_{t-1} + \varepsilon_t \quad (10.24)$$

$$\Delta Y_t = \underbrace{\delta(1-\phi_1)}_{\phi_0} + \underbrace{(\phi_1-1)}_{\gamma} Y_{t-1} + \varepsilon_t \quad (10.25)$$

Bajo la hipótesis nula $\phi_1 = 1$ el término constante sería nulo ($\phi_0 = 0$); luego, su presencia en el modelo a estimar es irrelevante y sólo se justificaría para garantizar que, en el caso de que fuera cierta la hipótesis alternativa $H_1: \gamma < 0$, el proceso autorregresivo tenga media no nula.

El modelo (10.23), que contrasta la hipótesis nula de un paseo aleatorio con deriva frente a la alternativa de un proceso AR(1) estacionario sobre una tendencia determinista (βt), sería la forma reducida del siguiente modelo VAR:

$$\begin{aligned} Y_t &= \delta + \alpha t + u_t \\ u_t &= \phi_1 u_{t-1} + \varepsilon_t \end{aligned} \quad (10.26)$$

en que $\phi_0 = \delta(1 - \phi_1) + \alpha\phi_1$ y $\beta = \alpha(1 - \phi_1)$.

Bajo la hipótesis de raíz unitaria $\phi_1 = 1$ tendríamos que $\phi_0 = \alpha$ y $\beta = 0$. Luego, como en el caso anterior, **la presencia en este caso del parámetro β es irrelevante en el caso de raíz unitaria**, y su presencia intenta sólo garantizar la consistencia del contraste en una situación de hipótesis alternativa (proceso estacionario sobre tendencia determinista).

Tabla 12.3
Valores Críticos de D-F al 95%

MODELO	Hipótesis Nula	Estadístico	Valor Crítico
$\Delta Y_t = \gamma Y_{t-1} + \varepsilon_t$	$\gamma = 0$	t	-1,95
$\Delta Y_t = \phi_0 + \gamma Y_{t-1} + \varepsilon_t$	$\gamma = 0$	t_μ	-2,89
	$\phi_0 = 0 / \gamma = 0$	$t_{\mu/\gamma}$	-2,54
	$\phi_0 = \gamma = 0$	$F_{\mu,\gamma}$	-4,71
$\Delta Y_t = \phi_0 + \beta t + \gamma Y_{t-1} + \varepsilon_t$	$\gamma = 0$	t_t	-3,45
	$\phi_0 = 0 / \gamma = 0$	$t_{t/\gamma}$	-3,11
	$\beta = 0 / \gamma = 0$	$t_{\beta/\gamma}$	-2,79
	$\beta = \gamma = 0$	$F_{\beta,\gamma}$	-6,49
	$\phi_0 = \beta = \gamma = 0$	$F_{\mu,\beta,\gamma}$	-4,88

Dolado et al. (1990) y Perron (1990) propusieron, entre otros autores, seguir un proceso en etapas a fin de aumentar la probabilidad de éxito en la elección del modelo de referencia:

- En primer lugar se estimaría el **modelo menos restringido** (con término constante y tendencia determinista).
- Dado que el principal error de esta táctica inicial consistiría en la escasa potencia del contraste para el rechazo de la hipótesis nula por inclusión de variables irrelevantes, **si los valores críticos indican rechazo (ausencia de raíz unitaria), terminaríamos el procedimiento.**
- En el caso de no rechazarse la hipótesis nula de presencia de una raíz unitaria, es decir, en el caso en que admitamos la presencia de una raíz unitaria ($H_0 : \gamma = 0$), pasaríamos ahora a examinar la significancia del parámetro tendencial determinista β .

Dado que, en este punto, estaríamos bajo la hipótesis ya admitida de que $\gamma = 0$, utilizaríamos el valor de referencia $t_{\beta/\gamma}$ de la Tabla 12.1 y, para mayor seguridad, también el contraste conjunto $F_{\beta,\gamma}$.

- Si el término tendencial resulta significativo ($\beta \neq 0$) contrastaremos de nuevo la presencia de una raíz unitaria $H_0 : \gamma = 0$ pero utilizando entonces las tablas de una normal estandarizada. Sea cual sea el resultado del test, con las nuevas tablas finalizaríamos aquí el contraste admitiendo o rechazando la presencia de una raíz unitaria.
- Si el término tendencial es no significativo ($\beta = 0$), deberá replantearse el modelo inicialmente estimado pasándose a examinar otro con término constante pero sin esta tendencia determinista. Con este modelo se vuelve a analizar la presencia de una raíz unitaria ($H_0 : \gamma = 0$).
- En el caso en que, nuevamente, se sostenga la presencia de una raíz unitaria, se contrastará entonces la adecuación del término independiente ϕ_0 con el contraste $t_{\mu/\gamma}$ o bien con $F_{\mu,\gamma}$.

- Si el término independiente resulta significativo, usamos de nuevo las tablas de una normal para contrastar la presencia de la raíz unitaria, concluyendo de nuevo aquí el contraste.
- Sólo si la constante ϕ_0 es no significativa se utiliza el modelo más simple como modelo de referencia contrastándose, de nuevo, la presencia de raíz unitaria. En este caso, no tiene cabida el uso de la distribución normal estandarizada.

10.4.2 Contraste de Dickey – Fuller Aumentado (DFA)

Está claro que lo expuesto hasta este momento permite contrastar la presencia de una o más raíces unitarias en **una determinada serie temporal para la que se supone un proceso AR(1)**.

Sin embargo, muchas serie temporales se ajustan más adecuadamente a **procesos autorregresivos de orden superior AR(2) o AR(3)**. No parece, por lo tanto, muy correcto contrastar la presencia de una o más raíces unitarias utilizando siempre la estructura de un modelo AR(1) ya que las raíces unitarias pueden aparecer también en estructuras más complejas.

Este problema da lugar a lo que se conoce como test de raíces unitarias de Dickey-Fuller Ampliado (DFA). El contraste de DF aumentado (DFA) considera la siguiente forma reducida:

$$\Delta Y_t = \phi_0 + \beta t + \gamma Y_{t-1} + \sum_{i=2}^p \beta_i \Delta Y_{t-i+1} + \varepsilon_t \quad (10.27)$$

donde $\gamma = -\left(1 - \sum_{i=1}^p \phi_i\right)$ y $\beta_i = \sum_{j=1}^p \phi_j$.

El procedimiento es análogo al expuesto en el test de DF simple; sin embargo, los estimadores $\hat{\beta}_i$ distribuyen asintóticamente como una normal estandarizada.

Para determinar el número de rezagos p del modelo (10.27) es posible considerar criterios alternativos, por ejemplo el criterio de Akaike.

El criterio de Akaike (AIC) considera la siguiente expresión:

$$AIC = \frac{2k}{n} + \log \left(\frac{\sum_i \hat{\varepsilon}_i^2}{n} \right) \quad (10.28)$$

donde n es el número de observaciones, k es el número de parámetros estimados, y $\hat{\varepsilon}$ es la serie de residuos obtenidos en la estimación.

Luego, interesa introducir un a variable adicional (rezago adicional en nuestra caso) a un modelo con k variables explicativas si $AIC_{k+1} < AIC_k$.

De manera complementaria, se puede emplear el criterio modificado de Akaike (MAIC):

$$MAIC = \frac{2(k + \tau)}{T - k} + \log \left(\sum_i e_i^2 / n \right) \quad (10.29)$$

donde $\tau = \hat{\gamma}^2 \left(\sum_i e_i^2 / n \right)^{-1} \sum_{t=k+1}^T Y_{t-1}^2$

10.4.3 Contraste de Phillips - Perron (PP)

El contraste Phillips-Perron (1988) es una corrección no paramétrica del DFA en el que se elimina el problema de correlación serial de los residuos. Se ha indicado por parte de los investigadores que **el contraste Phillips - Perron (PP) tiene mayor potencia que el DFA** de forma que en caso de duda parece adecuado atender a sus resultados.

La diferencia fundamental entre ambos está en que mientras la validez del procedimiento DF está basada en que los términos de error son ruido blanco, el procedimiento de PP modifica los estadísticos después de la regresión para tener en cuenta el efecto de los errores autocorrelacionados que aparecen en los resultados.

De esa forma, asintóticamente, el estadístico se corrige en la forma apropiada y se aplica la misma distribución límite (DF).

10.5 Cointegración

Las regresiones que incluyen series temporales pueden ocasionar coeficientes de determinación muy altos pero sin reflejar el verdadero grado de asociación entre las dos variables, sino que es la tendencia común presente en ellas (regresión espuria).

Cuando se lleva a cabo la regresión estática entre variables $I(1)$ afectadas por tendencias comunes, se encuentra un valor de R^2 elevado sin que exista una relación de causalidad. Además **el valor del estadístico de Durbin - Watson (DW) es muy pequeño** lo que indica que los errores de la ecuación están autocorrelacionados positivamente.

Este es el problema de las regresiones espurias que implica no sólo que los estimadores MCO de los coeficientes son ineficientes sino que los estimadores de los errores estándar son inconsistentes.

En general, la integrabilidad es una propiedad dominante en las series, de manera que para cualquier combinación lineal de dos procesos integrados, **el proceso resultante tendrá el orden mayor de las variables integradas**. Pero, en ocasiones, la combinación lineal de dos procesos $I(1)$ es estacionaria.

Si la combinación lineal de dos variables o procesos no estacionarios es estacionaria, se dice que las variables están cointegradas, es decir, las tendencias se contrarrestan o se cancelan.

Es decir, si Y_t es un vector de N series temporales, sus componentes son cointegradas de orden d, b , que se define como $Y_t \sim CI(d, b)$ si:

- Todas las componentes de Y_t son $I(d)$.
- Existe un vector $\alpha \neq 0$ tal que $Z_t = \alpha Y_t \sim I(d - b)$, con $b > 0$.

La relación $Z_t = \alpha Y_t$ se denomina relación de cointegración, y el vector α , vector de cointegración.

Sean dos variables X_t e Y_t tales que la **teoría económica sugiere una relación de equilibrio a largo plazo entre ellas.**

Supongamos que las series de datos X_t e Y_t son $I(1)$. En la relación $Z_t = \alpha_1 Y_t + \alpha_2 X_t$, lo normal es que Z_t sea $I(1)$. Sin embargo, es posible que exista un valor particular de $\alpha = (\alpha_1, \alpha_2)$, tal que Z_t sea $I(0)$, es decir, estacionaria. En este caso las series serían $CI(1,1)$, o cointegradas de orden 1.

Sea $Y_t^* = \alpha_0 + \alpha_1 X_t$, donde Y_t^* es el valor de equilibrio a largo plazo correspondiente a X_t . Si hay equilibrio en t , $(Y_t^* - Y_t) = 0$, entonces $Y_t - \alpha_0 - \alpha_1 X_t = 0$.

Como Y_t , en general, será distinto de Y_t^* , podemos escribir $Y_t - \alpha_0 - \alpha_1 X_t = u_t$, donde u_t puede interpretarse como el error o desviación entre Y_t y su correspondiente valor de equilibrio en el período t .

Esta última ecuación es equivalente a $Y_t - \alpha_1 X_t = \alpha_0 + u_t$. Luego, la relación de cointegración será:

$$Z_t = \alpha Y_t \rightarrow \alpha = (1 - \alpha_1), \quad Y_t = \begin{pmatrix} Y \\ X \end{pmatrix}, \quad Z_t = \alpha_0 + u_t \quad (10.30)$$

Si las series son $CI(1,1)$, Z_t es estacionaria, por lo que **el error será una serie estacionaria.**

La cointegración de dos o más series temporales apunta a la existencia de una relación de largo plazo o de equilibrio entre ellas, es decir, que las desviaciones de la situación de equilibrio no tienden, en promedio, a ampliarse con el paso del tiempo.

Por el contrario, si X_t e Y_t son ambas $I(1)$ pero no son cointegradas, Z_t no es estacionaria, es decir, las dos variables se alejarán una de otra con el paso del tiempo.

Así, si X_t e Y_t son integradas del mismo orden, y si haciendo la regresión $Y_t = \alpha_0 + \alpha_1 X_t + u_t$ obtenemos los **residuos estacionarios**, hay evidencia de que las dos series son cointegradas, lo cual implicaría que la relación a largo plazo que supone la teoría económica viene apoyada por la evidencia empírica, y que la regresión efectuada está libre de resultados espurios.

A la regresión anterior se le conoce como regresión de cointegración, siendo el vector $\alpha = (\alpha_0, \alpha_1)$ el vector de cointegración.

El análisis de la cointegración permite detectar si existe la posibilidad de obtener estimaciones libres de resultados espurios de los parámetros que definen las relaciones entre dos o más series tanto a corto como a largo plazo. Las pruebas t y F usuales serían válidas.

En general, si consideramos m variables integradas del mismo orden, el número máximo de vectores de cointegración es $m - 1$. Al número de vectores de cointegración linealmente independientes se le denomina **rango de cointegración**.

Una implicancia del concepto de cointegración es que si X_t e Y_t cointegran, también lo harán X_t e Y_{t-k} , puesto que las variables Y_t e Y_{t-k} lo hacen.

10.6 Detección de Cointegración

10.6.1 Engle y Granger

El primer conjunto de contrastes fue considerado por Engle y Granger (1987). Supongamos un vector $(Y_t^1, Y_t^2, \dots, Y_t^k)$ y regresionamos $Y_t^1 = \alpha_2 Y_t^2 + \alpha_3 Y_t^3 + \dots + \alpha_k Y_t^k + u_t$, que puede ser estimada por MCO y a la que se denomina "regresión de cointegración".

Se contrasta la hipótesis nula de que los residuos u_t tienen una raíz unitaria contra la alternativa de que son $I(0)$. De esa forma, **la hipótesis nula es la no cointegración y la alternativa la cointegración**. Podemos aplicar la prueba DF o ADF. Engle y Granger consideran que existe una relación de cointegración entre las variables si los residuos u_t son $I(0)$.

Los valores críticos son distintos de los del contraste de raíces unitarias, pues la u_t estimada está basada en los parámetros de cointegración estimados. Engle y Granger han calculado estos valores, los cuales pueden encontrarse en Engle y Granger (1987), Engle y Yoo (1987), Phillips y Outlaris (1990) y Mackinnon (1991). En este contexto, las pruebas DF y ADF se conocen como EG y AEG, respectivamente. **En valor absoluto, los valores críticos de EG y AEG son mayores a los de DF y ADF, respectivamente.**

10.6.2 Durbin y Watson

Un método alternativo para contrastar la cointegración es el contraste Durbin-Watson de la regresión de cointegración (CRDW). Se considera el estadístico DW de la regresión de cointegración $Y_t = \alpha_0 + \alpha_1 X_t + u_t$ y **se contrasta la hipótesis nula de que el estadístico DW es cero para ver si los residuos son estacionarios**. Si no son estacionarios el estadístico DW tenderá a cero.

Así, cuando el valor DW calculado es menor que el tabulado para cierto nivel de significación, se acepta la hipótesis nula de no cointegración. Si es mayor, se acepta la hipótesis de cointegración. Los valores críticos de este contraste están tabulados y pueden verse en Sargan-Bhargava (1983).

Una regla práctica muy útil es que si $DW < R^2$ las series no están cointegradas.

10.6.3 Modelo de Corrección de Errores (MCE)

En el caso de que el vector de variables del modelo esté constituido por dos variables, Y_t y X_t , la relación a largo plazo entre ambas variables puede expresarse como:

$$Y_t^* = \alpha + \beta X_t + \varepsilon_t \quad (10.31)$$

Por otra parte, su relación a corto plazo puede expresarse, de acuerdo con el MCE, de forma que las desviaciones respecto a la tendencia a largo plazo tienden a corregirse.

Si en un período el valor observado de Y_t es superior al de su tendencia, $E(Y_t^*/X_t)$, se supone que se producirá en el período siguiente una disminución en Y_t que amortigüe esa diferencia, y si Y_t es inferior a Y_t^* , se supone que en el período siguiente se producirá un aumento de Y_t que lo acerque a su tendencia, de forma que las relación a corto plazo puede expresarse mediante las dos expresiones siguientes:

$$Y_t = Y_t^* + g \cdot \underbrace{(Y_{t-1} - \alpha - \beta X_{t-1})}_{\hat{\varepsilon}_{t-1}} \quad (10.32)$$

donde g es un parámetro cuyo valor es menor que cero (para compensar la diferencia generada en el período anterior).

Si aplicamos primeras diferencias a (10.32), sustituimos Y_t^* por su valor estimado en la relación (10.31), y añadimos una perturbación aleatoria v_t obtenemos:

$$\Delta Y_t = \beta \cdot \Delta X_t + g \cdot \hat{\varepsilon}_{t-1} + v_t \quad (10.33)$$

La relación (10.31) se denomina regresión de cointegración, y la (10.33) MCE con relación contemporánea.

De forma similar se procede en el caso de varias variables explicativas, en cuyo caso aparecerían los términos correspondientes a cada una de dichas variables explicativas, y la perturbación retardada estimada ($\hat{\varepsilon}_{t-1}$) incluiría la diferencia entre el valor retardado de Y_t y una combinación lineal de los valores retardados de todas las variables explicativas.

Así, en el caso de k variables explicativas, tendríamos:

$$Y_t^* = \alpha + \beta_1 X_t^1 + \beta_2 X_t^2 + \dots + \beta_k X_t^k + \varepsilon_t \quad (10.34)$$

$$\Delta Y_t = \beta_1 \Delta X_t^1 + \beta_2 \Delta X_t^2 + \dots + \beta_k \Delta X_t^k + g \cdot \hat{\varepsilon}_{t-1} + v_t \quad (10.35)$$

Engle y Granger proponen estimar la relación (10.34), MCE, en dos etapas, estimando en la primera etapa por MCO la relación (10.35), o regresión de cointegración para calcular $\hat{\varepsilon}_{t-1}$ y, en una segunda etapa estimar los parámetros de (10.34).

El modelo CE con causalidad contemporánea presenta en general buenos resultados, tanto si las variables están cointegradas como si no, ya que permite tener en cuenta la relación causal a largo plazo y las desviaciones a corto plazo.

10.7 Causalidad

Aunque la causalidad es de naturaleza extra-estadística, es decir, que en un modelo econométrico viene determinada por antecedentes económicos, a veces no es fácil determinar si X_t influye sobre Y_t o si es Y_t la causa de las variaciones de X_t .

El test de Granger surge como elemento de ayuda para determinar el sentido de una relación causal entre dos variables. El contraste de Granger se basa en estimar los dos modelos siguientes:

$$Y_t = \alpha_0 + \sum_{i=1}^r \alpha_i Y_{t-i} + \sum_{j=0}^r \beta_j X_{t-j} + \varepsilon_t \quad (10.36)$$

$$X_t = \tilde{\alpha}_0 + \sum_{i=1}^r \tilde{\alpha}_i X_{t-i} + \sum_{j=0}^r \tilde{\beta}_j Y_{t-j} + \tilde{\varepsilon}_t \quad (10.37)$$

Las hipótesis a contrastar son las siguientes:

$$\begin{aligned} H_0 : \beta_i = 0, \tilde{\beta}_i \neq 0; \forall i = 1, \dots, r \\ \tilde{H}_0 : \tilde{\beta}_i = 0, \beta_i \neq 0; \forall i = 1, \dots, r \end{aligned} \quad (10.38)$$

Si no se rechaza H_0 se concluye que Y_t causa las variaciones de X_t . Si se no rechaza $\tilde{H}_0$ se concluye que X_t causa las variaciones de Y_t . Si ninguna de las dos hipótesis se puede rechazar, entonces ambas variables son independientes. Si se rechazan ambas, se produce entonces un **feedback**.

Para ello se aplica un test F de manera complementaria con los test- t ; las restricciones del test F en este caso corresponden a los valores de los parámetros según las hipótesis nulas.

11 ANÁLISIS FACTORIAL

El método de Análisis Factorial (FA) es una técnica que se utiliza frecuentemente para **crear nuevas variables que resuman toda la información disponible contenida en las variables originales**. También se utiliza para estudiar la posible relación existente entre variables medidas en un conjunto de datos.

Un objetivo básico del FA es determinar si las variables de respuesta (X) exhiben patrones de **relaciones entre sí**, de tal forma de agrupar dichas variables en subconjuntos de variables correlacionadas, pero no correlacionadas con las de los otros subconjuntos. Luego, el FA se utiliza para estudiar la estructura de correlación entre variables dentro de un determinado conjunto de datos.

En resumen, el FA tiene por objetivo:

- Determinar si existe un conjunto más pequeño de variables no correlacionadas que expliquen las relaciones existentes entre las variables originales.
- Determinar el número de variables subyacentes (Factores).
- Interpretar estas nuevas variables.
- Evaluar las unidades experimentales (o individuos) del conjunto de datos (muestra) sobre estas nuevas variables.
- Utilizar estas nuevas variables en otros análisis estadístico de los datos, por ejemplo para predicción.

Sin embargo, se debe tener especial cuidado con el método de FA, particularmente en lo que respecta a la **subjetividad que representa su utilización** en numerosos aspectos. Esta subjetividad está asociada, por ejemplo, al número de factores que considere el investigador y a la interpretación de los factores, entre otros. De hecho, algunos autores sugieren que es posible demostrarse mediante FA cualquier cosa que se desee.

El modelo matemático para el análisis factorial parece ser similar a la ecuación de regresión múltiple, pero se debe recordar que en el caso de la regresión múltiple, ésta considera variables simples que son predictoras de la variable dependiente (criterio). En cambio, **en el caso del análisis factorial, la variable dependiente se expresa en términos de una combinación lineal de grupos de variables** que caracterizan un concepto en particular (factores).

Los factores no son variables independientes simples sino que cada uno está constituido por un grupo de variables que caracterizan el concepto que representa el factor.

Es por esta causa que se clasifica esta técnica entre las técnicas de interdependencia. (Tanto las variables a un lado de la ecuación como en el otro están interactuando como criterios y predictoras).

Por lo general, los factores que pueden caracterizar a un grupo de variables no se conocen con anticipación, sino que llegan a ser determinados por medio del análisis factorial. Estos factores se llama factores comunes, dado que todas las variables en observación se llegan a expresar como funciones de ellos.

Cuando no se conoce con anticipación los factores que constituyen las variables, se dice que procede un **análisis exploratorio**. Pero en cambio, si el investigador ha elaborado el análisis anticipando (posiblemente apoyado en la teoría) la existencia de cierto número de factores en particular y anticipando qué variables conforman cada uno de los factores, se trata de un **análisis confirmatorio**.

Para efectos del presente tema vamos a proseguir según un análisis exploratorio de factores.

Corresponde al investigador determinar lo que representa o constituye cada uno de estos factores, para lo cual deberá considerar la información existente (marco teórico).

EJEMPLO DE MODELO FACTORIAL EXPLORATORIO

Se desea extrapolar, de una provincia un municipio, un modelo de regresión explicativo del nivel de renta disponible en función de una serie de manifestaciones de esa renta. Para ello, se parte de un amplio conjunto de variables provinciales para 8.000 municipios:

- Recaudación de los distintos impuestos directos e indirectos
- Tasa de paro y actividad
- Generación neta de empleo
- Kilómetros de carreteras de cada tipo en servicio
- Kilómetros de línea férrea en servicio
- Número de vehículos de distintos tipos por habitante
- Líneas telefónicas por cada 100 habitantes
- Camas hospitalarias por cada 1000 habitantes
- Empresas creadas y cerradas en el año
- Índice de precios al consumo
- Índice de precios industriales
- Índice de comercio al por menor
- Licencias fiscales concedidas

Con el fin de poder abordar con grados de libertad suficiente la estimación del modelo de renta, se intenta resumir en tres factores, sin perder excesiva información y logrando una incorrelación muy conveniente. El factorial arrojó tres factores cuyos significados se asociaron a:

Factor 1: renta y riqueza personal - familiar

Factor 2: salud y desarrollo del mercado laboral

Factor 3: desarrollo infraestructural

EJEMPLO DE MODELO FACTORIAL CONFIRMATORIO

Se desea medir la capacidad de abstracción, analítica y memoria de los alumnos. Se observaron 10 notas de cada alumno de un determinado grupo de estudiantes universitarios. Entre estas notas, o al menos entre algunas de ellas, se observan correlaciones elevadas que, en cierta medida, provienen de aptitudes globales del alumno que no se observan directamente:

- Nota en álgebra
- Nota en cálculo
- Nota en estadística
- Nota en derecho comercial
- Nota en derecho laboral
- Nota en contabilidad financiera y de sociedades
- Nota en análisis de costos
- Nota en comunicación comercial
- Nota en administración
- Nota en econometría

Un análisis factorial permitió que la información relativa a estas variables se resumiese en tres únicos factores de fondo, sin pérdida excesiva de información y logrando, de nuevo, una incorrelación muy conveniente. Cada uno de estos tres factores se interpretó como:

Factor 1: capacidad de abstracción

Factor 2: memoria

Factor 3: capacidad analítica

Independientemente de estos tres factores relacionados con grupos de variables (notas) se identificó un factor común que podríamos llamar inteligencia en general y un factor específico para cada asignatura (su propia dificultad y componentes de tipo aleatorio relativos a las distintas formas de evaluación).

11.1 Comparación Entre FA y MCP

- Al igual que el método de Componentes Principales (MCP), el FA es una técnica dirigida a las variables.
- Una ventaja que presenta el FA respecto al MCP, es que las nuevas variables creadas (denominadas factores) son en general mucho más fácil de interpretar. Recordemos que el MCP genera una transformación ortogonal de las variables y no depende de un modelo subyacente. El FA, en cambio, sí depende de un modelo estadístico razonable. Por lo tanto, el MCP es descriptivo y el FA tiene un modelo estadístico formal.
- En el MCP el interés se centra en la explicación de la variabilidad de las variables (varianzas), mientras que en el FA el interés se centra en la estructura de la matriz de varianzas y covarianzas (correlaciones).
- Si las variables originales no están correlacionadas, tal como ocurre con el MCP, no tiene sentido aplicar FA.
- En ambos casos pueden existir problemas con la escala de los valores de las variables.

11.2 El Modelo de Análisis Factorial

11.2.1 Hipótesis del FA

Suponga que se observa un vector de respuestas p -variado X , de una población que tiene media μ y matriz de varianzas y covarianzas Σ . En el modelo general de FA se supone que se tienen m factores subyacentes ($m < p$) denotados por $f_1, \dots, f_m$, tales que:

$$x_j = \mu_j + \lambda_{j1}f_1 + \lambda_{j2}f_2 + \dots + \lambda_{jm}f_m + \eta_j \quad \forall j=1,2,\dots,p \quad (11.1)$$

En el modelo anterior se supone que:

- $f_k \stackrel{iid}{\sim} N(0;1), \forall k=1,2,\dots,m$
- $\eta_j \stackrel{iid}{\sim} N(0;\psi_j), \forall j=1,2,\dots,p$

- $\text{cov}(f_k; \eta_j) = 0, \forall j, k$

Sin pérdida de generalidad, se puede suponer que $\mu_j = 0$ y que $\text{var}(x_j) = 1$.

Este siempre puede ser el caso, si se estandarizan las variables medidas antes de aplicar el método de FA. Sin embargo, no es necesario estandarizar.

11.2.2 Forma Matricial del FA

En forma matricial, el modelo resulta:

$$X = \Lambda F + \eta \quad (11.2)$$

donde:

$$X = (x_1, x_2, \dots, x_p)^T \quad (11.3)$$

$$F = (f_1, f_2, \dots, f_m)^T \quad (11.4)$$

$$\eta = (\eta_1, \eta_2, \dots, \eta_p)^T \quad (11.5)$$

$$\Lambda = \begin{bmatrix} \lambda_{11} & \lambda_{12} & \dots & \lambda_{1m} \\ \lambda_{21} & \lambda_{22} & \dots & \lambda_{2m} \\ \dots & \dots & \dots & \dots \\ \lambda_{p1} & \lambda_{p2} & \dots & \lambda_{pm} \end{bmatrix} \quad (11.6)$$

Luego, en forma matricial, la hipótesis del modelo de FA es la siguiente:

- $F \sim N(0; I)$

- $\eta \sim N(0; \Psi) \rightarrow \Psi = \begin{bmatrix} \psi_1 & 0 & \dots & 0 \\ 0 & \psi_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \psi_p \end{bmatrix}$

- $F^T \eta = 0$

11.3 Ecuaciones del FA

De las expresiones anteriores, debe notarse que:

$$X = \Lambda F + \eta \quad (11.7)$$

$$\Sigma = V(X) \quad (11.8)$$

$$\Sigma = V(\Lambda F + \eta) \quad (11.9)$$

$$\Sigma = \Lambda V(F) \Lambda^T + V(\eta) \quad (11.10)$$

$$\Sigma = \Lambda \Lambda^T + \Psi \quad (11.11)$$

Luego, para determinar si existen F , Λ y η tales que $X = \Lambda F + \eta$, en lugar de ello se intenta encontrar Λ y Ψ de modo que $\Sigma = \Lambda \Lambda^T + \Psi$, lo que es equivalente a:

$$\sigma_{jj} = \sum_{k=1}^m \lambda_{jk}^2 + \psi_j \quad (11.12)$$

Debe notarse lo siguiente:

- Si existen Λ y Ψ de modo que $\Sigma = \Lambda \Lambda^T + \Psi$, entonces los factores comunes explican con exactitud las covarianzas entre las variables de respuesta, lo que se concluye dado que Ψ es una matriz diagonal.
- La varianza de x_j se puede dividir como $\sigma_{jj} = \sum_{k=1}^m \lambda_{jk}^2 + \psi_j$, y la proporción de la varianza de x_j que se explica por los factores es $\sum_{k=1}^m \lambda_{jk}^2 / \sigma_{jj}$. A esta última expresión se le denomina **comunidad** de la j -ésima variable de respuesta.
- $\text{cov}(x_i; x_j) = \sum_{k=1}^m \lambda_{ik} \lambda_{jk}$ (recordar que $\psi_{ij} = 0$)
- $\text{cov}(f_k; x_j) = \lambda_{jk}$, y se denomina **carga** de la j -ésima variable de respuesta sobre el k -ésimo factor (ver (11.1)).

Si bien los desarrollos hasta ahora expuestos se han basado en la matriz de varianzas y covarianzas Σ , los procedimientos casi siempre se realizan en torno a la matriz de correlaciones, matriz que definiremos como P .

Si el FA se ha aplicado a la matriz P , entonces Λ es la matriz de correlaciones entre las z_j y las f_k ; es decir, $\text{corr}(f_k; z_j) = \lambda_{jk}$.

Del mismo modo, se tendrá que $\sum_{k=1}^m \lambda_{jk}^2 + \psi_j = 1$, por lo que la comunidad de la j -ésima variable es simplemente $\sum_{k=1}^m \lambda_{jk}^2$.

En el resto del Capítulo, supondremos que el FA se aplica a la matriz P .

11.3.1 No Unicidad de los Factores

Si el número de factores es mayor que uno ($m > 1$) la matriz de cargas Λ de los factores **no es única**. Es decir, si existen Λ y Ψ de modo que $P = \Lambda\Lambda^T + \Psi$, entonces, para toda matriz ortogonal T tal que $TT^T = I$, se cumplirá:

$$P = \Lambda TT^T \Lambda^T + \Psi \quad (11.13)$$

Luego, si Λ es una matriz de cargas, entonces ΛT también. Esto representa un grave dilema para muchos investigadores, mientras que otros lo ven como una ventaja.

Estos últimos creen que si no son interpretables un determinado conjunto de factores, entonces puede existir otra solución que sí lo sea.

A esta multiplicación por la matriz T se le denomina **rotación de factores**.

11.3.2 Normalización del Modelo Factorial

El análisis expuesto en la sección anterior implica que, aunque observemos toda la población, y los valores de μ y Σ sean conocidos, no podemos determinar Λ de manera única.

La solución para poder estimar esta matriz es imponer restricciones adicionales sobre sus términos. Dos criterios alternativos son:

$$1) \quad A^T A = \text{Diag}$$

Con esta normalización, los vectores que definen el efecto de cada factor sobre las p variables observadas son ortogonales. De esta manera, los factores, además de estar incorrelacionados, producen efectos lo más distinto posible sobre las variables. Por otra parte, esta normalización asegura una matriz de cargas A única.

$$2) \quad A^T \Psi^{-1} A = \text{Diag}$$

Con esta normalización, los efectos de los factores sobre las variables, ponderados por las varianzas de las perturbaciones de cada observación, se hacen incorrelacionados. También se define una matriz de cargas única.

11.4 Resolución de las Ecuaciones del FA

11.4.1 Número de Factores

Si bien se presentan los desarrollos a base de la matriz de correlaciones P , las técnicas descritas también pueden aplicarse sobre la matriz de varianzas y covarianzas Σ .

Para determinar si existe un conjunto de m factores subyacentes, se determina si sería posible la existencia de A y Ψ tales que $P = AA^T + \Psi$.

El número de parámetros desconocidos en A y Ψ es $pm + p$; el número de parámetros en P es $p(p+1)/2$. Luego, las ecuaciones del FA dan origen a $p(p+1)/2$ ecuaciones en $p(m+1)$ incógnitas. Recordar que p es el número de unidades experimentales y m es el número de factores.

Si por ejemplo $p = 20$ y $m = 5$, se tendrían 210 ecuaciones y 120 incógnitas por resolverse.

Si $p(m+1) > p(p+1)/2 \rightarrow m > (p-1)/2$, se tendría más incógnitas que ecuaciones, por lo que la solución no sería única. Sin embargo, incluso cuando $m \leq (p-1)/2$, no existe solución única cuando $m \geq 2$, ya que a cualquier solución se le pueden aplicar **rotaciones** hacia una cantidad infinita de soluciones.

Sin embargo, es factible que existan soluciones diferentes entre sí sin la necesidad de aplicar rotaciones, ya que ΛF puede ser formado de múltiples maneras.

Por otra parte, dado que deben respetarse ciertas restricciones respecto de los valores que pueden tomar las cargas λ_{jk} y las varianzas ψ_j , directamente se rechazan todas aquellas soluciones absurdas (por ejemplo con valores negativos para ψ_j o valores mayores que uno para λ_{jk}). Adicionalmente, puede exigirse que $\Lambda\Lambda^T = \text{Diag}$ o $\Lambda\Psi^{-1}\Lambda^T = \text{Diag}$.

Luego, considerando un número elevado de ecuaciones e incógnitas, resulta bastante difícil resolver el sistema $P = \Lambda\Lambda^T + \Psi$. No obstante, existen varios programas computacionales que resuelven adecuadamente las ecuaciones del FA.

11.4.2 Método del Factor Principal

Este es un método para estimar la matriz de cargas que se basa en los componentes principales.

Supongamos que podemos obtener una estimación inicial de la matriz Ψ ; entonces, podemos escribir:

$$(\Sigma - \hat{\Psi}) = \Lambda\Lambda^T \quad (11.14)$$

Dado que $(\Sigma - \hat{\Psi})$ es simétrica, puede descomponerse como:

$$(\Sigma - \hat{\Psi}) = HGH^T = (HG^{1/2})(HG^{1/2})^T \quad (11.15)$$

donde H es cuadrada de orden p y ortogonal; G es también de orden p pero diagonal y contiene las raíces características de $(\Sigma - \hat{\Psi})$. El modelo factorial (11.11) establece que, dado que $(\Sigma - \hat{\Psi})$ es de rango m , la matriz G debe ser diagonal del tipo:

$$G = \begin{bmatrix} G_{(m \times m)}^1 & 0_{m \times (p-m)} \\ 0_{(p-m) \times m} & 0_{(p-m) \times (p-m)} \end{bmatrix} \quad (11.16)$$

Si llamamos H^1 a la matriz $(p \times m)$ que contiene los vectores propios asociados a los valores propios no nulos de G^1 , podemos entonces tomar como estimador de A la siguiente matriz de $(p \times m)$:

$$\hat{A} = H^1 [G^1]^{1/2} \quad (11.17)$$

Es interesante notar la normalización resultante de este proceso:

$$\hat{A}^T \hat{A} = [G^1]^{1/2} \underbrace{[H^1]^T H^1}_{I_m} [G^1]^{1/2} = G^1 = \text{Diag} \quad (11.18)$$

En la práctica, este método se desarrolla de forma iterativa de la siguiente manera:

- 1) Partir de una estimación inicial de $\hat{A}_i$ o de $\hat{\Psi}_i$ mediante $\hat{\Psi}_i = \text{Diag}(\Sigma - \hat{A} \hat{A}^T)$
- 2) Calcular la matriz cuadrada y simétrica $Q_i = (\Sigma - \Psi_i)$
- 3) Obtener la descomposición espectral de Q_i de la forma:

$$Q_i = H_i^1 G_i^1 [H_i^1]^T + H_i^2 G_i^2 [H_i^2]^T \quad (11.19)$$

donde G_i^1 contiene los m mayores valores propios de Q_i , y H_i^1 sus vectores propios. Elegiremos m de manera que los restantes valores propios contenidos en G_i^2 sean todos pequeños y en magnitud similar.

- 4) Tomar $\hat{A}_{i+1} = H_i^1 [G_i^1]^{1/2}$ y volver al paso (1).

Los estimadores obtenidos mediante este método iterativo son consistentes pero ineficientes. Además, no son invariantes ante transformaciones lineales.

Para poder llevar a cabo este procedimiento, necesitamos obtener estimadores iniciales de $\hat{\Psi}$ (iteración cero). Es decir, deben estimarse los elementos de la diagonal $(\hat{\psi}_{jj})$, para luego estimar $h_j^2 = s_j^2 - \hat{\psi}_{jj}$. Existen las siguientes alternativas:

- i. Tomar $\hat{\psi}_{jj} = 0$. Esto equivale a extraer los componentes principales de Σ . Supone tomar $\hat{h}_j^2 = s_j^2$ (en el caso de correlaciones $h_j^2 = 1$), que es claramente su valor máximo, por lo que podemos comenzar con un sesgo importante.
- ii. Tomar $\hat{\psi}_{jj} = \frac{1}{s_{jj}}$, donde s_{ii} es el elemento diagonal i -ésimo de la matriz de precisión Σ^{-1} . Esto equivale a tomar $\hat{h}_j^2 = s_j^2 R_j^2$, donde R_j^2 es el coeficiente de correlación múltiple entre x_j y el resto de las variables. Mientras mayor sea el valor de R_j^2 , mayor será la comunidad de $\hat{h}_j^2$. Notar también que el término s_j^2 representa la j -ésima columna de valores de la matriz Σ .

A fin de entender el procedimiento descrito, consideremos un conjunto de observaciones de 3 variables: x_1 , x_2 y x_3 . Su matriz de varianzas y covarianzas es la siguiente:

$$\Sigma = \begin{bmatrix} 0,35 & 0,15 & -0,19 \\ 0,15 & 0,13 & -0,03 \\ -0,19 & -0,03 & 0,16 \end{bmatrix} \quad (11.20)$$

Paso 1 (iteración 0): considerando $\hat{\psi}_{jj} = \frac{1}{s_{jj}}$, se obtiene:

$$\Sigma^{-1} = \begin{bmatrix} 52,09 & -47,91 & 52,88 \\ -47,91 & 52,09 & -47,12 \\ 52,88 & -47,12 & 60,21 \end{bmatrix} \quad (11.21)$$

$$\hat{\Psi}_0 = \begin{bmatrix} \frac{1}{52,09} & 0 & 0 \\ 0 & \frac{1}{52,09} & 0 \\ 0 & 0 & \frac{1}{60,21} \end{bmatrix} = \begin{bmatrix} 0,019 & 0 & 0 \\ 0 & 0,019 & 0 \\ 0 & 0 & 0,017 \end{bmatrix} \quad (11.22)$$

Paso 2: calculamos la matriz cuadrada y simétrica $Q_0 = (\Sigma - \Psi_0)$:

$$Q_0 = \begin{bmatrix} 0,35 & 0,15 & -0,19 \\ 0,15 & 0,13 & -0,03 \\ -0,19 & -0,03 & 0,16 \end{bmatrix} - \begin{bmatrix} 0,019 & 0 & 0 \\ 0 & 0,019 & 0 \\ 0 & 0 & 0,017 \end{bmatrix} \quad (11.23)$$

$$Q_0 = \begin{bmatrix} 0,331 & 0,15 & -0,19 \\ 0,15 & 0,11 & -0,03 \\ -0,19 & -0,03 & 0,143 \end{bmatrix} \quad (11.24)$$

Paso 3: realizamos la descomposición espectral $Q_0 = H_0^1 G_0^1 [H_0^1]^T + H_0^2 G_0^2 [H_0^2]^T$. Sin embargo, para ello necesitamos previamente los valores propios de la matriz Q_0 . A partir de (11.24) se deduce directamente que los valores propios de la matriz Q_0 son 0.379, 0.094 y -0.108. Dado que uno de ellos es negativo, la matriz no es positiva definida.

Como hay un valor propio mucho mayor que los demás (0.379) consideraremos sólo un factor. En consecuencia, la descomposición es la siguiente:

$$\begin{aligned} \begin{bmatrix} 0,331 & 0,15 & -0,19 \\ 0,15 & 0,11 & -0,03 \\ -0,19 & -0,03 & 0,143 \end{bmatrix} &= \overbrace{\begin{bmatrix} -0,670 \\ -0,442 \\ 0,596 \end{bmatrix}}^{\text{vector propio para } 0,379} \times 0,379 \times \begin{bmatrix} -0,670 \\ -0,442 \\ 0,596 \end{bmatrix}^T + \\ &+ \underbrace{\begin{bmatrix} -0,036 & 0,741 \\ -0,783 & -0,438 \\ 0,621 & 0,508 \end{bmatrix}}_{\text{vectores propios para } 0,094 \text{ y } -0,108} \begin{bmatrix} 0,094 & 0 \\ 0 & -0,108 \end{bmatrix} \begin{bmatrix} -0,036 & 0,741 \\ -0,783 & -0,438 \\ 0,621 & 0,508 \end{bmatrix}^T \end{aligned} \quad (11.25)$$

Paso 4: calculamos $\hat{A}_1 = H_0^1 [G_0^1]^{1/2}$:

$$\hat{A}_1 = \begin{bmatrix} -0,670 \\ -0,442 \\ 0,596 \end{bmatrix} \times \sqrt{0,379} = \begin{bmatrix} -0,412 \\ -0,272 \\ 0,367 \end{bmatrix} \quad (11.26)$$

La expresión (11.26) es la primera estimación de la matriz de cargas. Vamos a volver al paso 1 para iterar.

Paso 1: Estimamos $\hat{\Psi}_1 = \text{Diag}(\Sigma - \hat{A}_1 \hat{A}_1^T)$:

$$\hat{\Psi}_1 = \text{Diag} \left\{ \begin{bmatrix} 0,331 & 0,15 & -0,19 \\ 0,15 & 0,11 & -0,03 \\ -0,19 & -0,03 & 0,143 \end{bmatrix} - \begin{bmatrix} -0,412 \\ -0,272 \\ 0,367 \end{bmatrix} \begin{bmatrix} -0,412 & -0,272 & 0,367 \end{bmatrix} \right\} \quad (11.27)$$

$$\hat{\Psi}_1 = \begin{bmatrix} 0,180 & 0 & 0 \\ 0 & 0,056 & 0 \\ 0 & 0 & 0,025 \end{bmatrix} \quad (11.28)$$

Paso 2: calculamos la matriz cuadrada y simétrica $Q_1 = (\Sigma - \hat{\Psi}_1)$:

$$Q_1 = \begin{bmatrix} 0,35 & 0,15 & -0,19 \\ 0,15 & 0,13 & -0,03 \\ -0,19 & -0,03 & 0,16 \end{bmatrix} - \begin{bmatrix} 0,180 & 0 & 0 \\ 0 & 0,056 & 0 \\ 0 & 0 & 0,025 \end{bmatrix} \quad (11.29)$$

$$Q_1 = \begin{bmatrix} -0,05 & 0,15 & -0,19 \\ 0,15 & 0,074 & -0,03 \\ -0,19 & -0,03 & 0,135 \end{bmatrix} \quad (11.30)$$

Paso 3: realizamos la descomposición espectral $Q_1 = H_1^1 G_1^1 [H_1^1]^T + H_1^2 G_1^2 [H_1^2]^T$. A partir de (11.30) se deduce directamente que los valores propios de la matriz Q_1 son 0.307, 0.067 y -0.215. En consecuencia, la descomposición es la siguiente:

$$\begin{aligned} \begin{bmatrix} -0,05 & 0,15 & -0,19 \\ 0,15 & 0,074 & -0,03 \\ -0,19 & -0,03 & 0,135 \end{bmatrix} &= \begin{bmatrix} -0,559 \\ -0,450 \\ 0,696 \end{bmatrix} \times 0,307 \times \begin{bmatrix} -0,559 \\ -0,450 \\ 0,696 \end{bmatrix}^T + \\ &+ \begin{bmatrix} 0,081 & 0,825 \\ 0,806 & -0,385 \\ 0,586 & 0,414 \end{bmatrix} \begin{bmatrix} 0,067 & 0 \\ 0 & -0,215 \end{bmatrix} \begin{bmatrix} 0,081 & 0,825 \\ 0,806 & -0,385 \\ 0,586 & 0,414 \end{bmatrix}^T \end{aligned} \quad (11.31)$$

Paso 4: calculamos $\hat{A}_2 = H_1^1 [G_1^1]^{1/2}$:

$$\hat{A}_2 = \begin{bmatrix} -0,559 \\ -0,450 \\ 0,696 \end{bmatrix} \times \sqrt{0,307} = \begin{bmatrix} -0,310 \\ -0,249 \\ 0,386 \end{bmatrix} \quad (11.32)$$

Realizando una tercera iteración se obtiene:

$$\hat{A}_3 = \begin{bmatrix} -0,269 \\ -0,229 \\ 0,407 \end{bmatrix} \quad (11.33)$$

Finalmente, el modelo con los nuevos parámetros es el siguiente:

$$X = \underbrace{\hat{A}_3}_{\begin{bmatrix} -0,269 \\ -0,229 \\ 0,407 \end{bmatrix}} F + \begin{bmatrix} \eta_1 \\ \eta_2 \\ \eta_3 \end{bmatrix} \quad (11.34)$$

$$\begin{bmatrix} \eta_1 \\ \eta_2 \\ \eta_3 \end{bmatrix} \sim N \left(\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}; \underbrace{\begin{bmatrix} 0,254 & 0 & 0 \\ 0 & 0,068 & 0 \\ 0 & 0 & 0,011 \end{bmatrix}}_{\hat{\Psi}_3} \right) \quad (11.35)$$

11.5 Determinación de la Cantidad Apropia de Factores

Antes de iniciarse un FA, debe inferirse el valor de m . Una conjetura inicial adecuada puede ser determinar el número de componentes principales, y considerar dicho número como cantidad de factores. No obstante, el número inicial no necesariamente corresponderá con el definitivo.

Se recomienda que el número máximo de factores no sea superior a la mitad del número de variables menos uno: $m \leq \frac{p}{2} - 1$.

11.5.1 Criterios Subjetivos

- **No Incluir Factores Triviales:** los factores triviales son aquellos que tienen sólo una variable original cargando sobre el factor. Ello implica que dicha variable no se correlaciona con el resto, y es por sí misma un factor subyacente. En tal caso, se elimina dicha variable antes del FA.

Esto no significa que la variable no sea importante, sino que sus características son independientes de las otras variables. En síntesis, no tiene sentido construir factores si se pueden emplear ellas mismas.

- **No Eliminar Necesariamente Factores con Valores Pequeños de η_j o ψ_j** (ver (11.1)): Esto hace tender el método de FA a un MCP. Análogamente, no es necesario que las comunidades tiendan a uno. Recordar que en el FA interesa las correlaciones entre las variables, y no su variabilidad individual como en el MCP.
- Si las diferencias entre la matriz de correlaciones observada (P) y la generada por la solución de FA (Λ) es grande ($P > \Lambda\Lambda^T$), puede ser necesario aumentar el número de factores. Análogamente, si la diferencia es muy pequeña, puede reducirse el número de factores.
- Si, después de realizado el ajuste respecto a los factores comunes, se presentan correlaciones altas entre variables, es factible considerarse el incremento en el número de factores. Por el contrario, si las correlaciones son pequeñas, podría reducirse el número de factores.

11.5.2 Criterios Objetivos

El criterio objetivo más utilizado corresponde al denominado **enfoque de posibilidad máxima**, basado en los datos con distribución normal multivariada.

Este método permite considerar que si por ejemplo, 6 factores son adecuados, eventualmente pueden ser adecuados también 5 ó 4. Pero si 6 factores son inadecuados, es necesario incrementar el número de factores.

Otro criterio utilizado comúnmente es el de Akaike (AIC). La cantidad de factores que presentan el menor valor del estadístico AIC se considera como la mejor selección. Ello requiere evidentemente varias selecciones diferentes de m . También es factible considerar el criterio de Schwartz (SIC).

Sin embargo, estos métodos tienden a producir factores triviales, los que deben eliminarse.



11.6 Rotación de Factores

Como se mencionó antes, un conjunto de factores no siempre se interpreta con facilidad. De hecho, no es recomendable intentar interpretar los factores sin realizar una rotación.

Los procedimientos de rotación intentan que la mayor cantidad posible de cargas de los factores (λ_{jk}) estén cercanas a cero, mientras se maximicen la mayor cantidad posible de las restantes.

Además, dado que los factores son independientes, sería bueno (pero no fundamental) que las variables de respuesta no se carguen mucho sobre distintos factores.

Por lo tanto, los factores que afectan a una determinadas variables no afectan al resto, y viceversa.



11.6.1 Rotación VARIMAX

La interpretación de los factores se facilita si los factores que afectan a unas variables no lo hacen al resto, y viceversa. Luego, se desea maximizar la varianza de los coeficientes que definen los efectos de cada factor sobre las variables observadas.

Definamos $B = AT \rightarrow b_{ij}$. En 1958, Kaiser propuso como medida de estructura simple la suma de las varianzas de las cargas elevadas al cuadrado dentro de cada columna de la matriz de los factores. Se eleva al cuadrado para prescindir de los signos.

Su criterio por lo tanto es maximizar la varianza de los coeficientes que definen los efectos de cada factor sobre las variables observadas; es decir, maximizar la expresión:

$$V_{\{t_{ij}\}}^* = \frac{1}{p} \sum_{q=1}^m \left[\sum_{j=1}^p b_{jq}^2 - \left(\sum_{j=1}^p b_{jq}^2 / p \right) \right]^2 = \sum_{q=1}^m \left[\frac{\sum_{j=1}^p b_{jq}^4 - \left(\sum_{j=1}^p b_{jq}^2 \right)^2 / p}{p} \right] \quad (11.36)$$

La cantidad dentro de los paréntesis $\left(\sum_{j=1}^p b_{jq}^2 \right)^2$ en esta expresión es la varianza de las cargas elevada al cuadrado, dentro de la q -ésima columna de B .

Dado que las cargas elevadas al cuadrado se encuentran entre 0 y 1, intentar maximizar la varianza de las cargas elevadas al cuadrado (dentro de una columna) equivale a dispersar las cargas elevadas al cuadrado dentro de una columna. Es decir, forzar la mayor cantidad de cargas hacia 0 y forzar las demás hacia 1. Esto permite una **mejor interpretación de los factores**, ya que existirá una correlación alta para ciertas variables y una correlación baja para el resto.

Kaiser suma las varianzas de las cargas elevadas al cuadrado que están dentro de una columna, a través de las distintas columnas (q). La matriz ortogonal T que produce un máximo para esta suma de varianzas de las columnas da como resultado la rotación VARIMAX de Kaiser de la matriz A de carga de los factores $t_{ij} = b_{ij} / \lambda_{ij}$.

Notar que el criterio recién expuesto da igual peso a las variables de respuesta que tengan tanto comunidades grandes como pequeñas.

Debido a ello, Kaiser sugirió que sería mejor dividir las cargas de los factores para cada variable, por la comunidad propia de la variable, y luego maximizar la suma de las varianzas de las razones elevadas al cuadrado dentro de una columna.

En consecuencia, Kaiser maximizaría realmente la expresión:

$$V_{\{t_{ij}\}} = \frac{1}{p^2} \sum_{q=1}^m \left(p \sum_{j=1}^p \frac{b_{jq}^4}{h_j^4} - \left(\sum_{j=1}^p \frac{b_{jq}^2}{h_j^2} \right)^2 \right) \quad (11.37)$$

donde h_j^2 es la comunidad de la j -ésima variable de respuesta ($j = 1, 2, \dots, p$)

La matriz T que maximiza la suma precedente produce la rotación VARIMAX de la matriz de cargas de los factores. Este ajuste da más peso a las variables que tienen las comunidades más grandes y menor a las que tienen comunidades pequeñas; es decir, menos peso a las variables que tienen menos en común con las demás.

Notar que:


$$h_j^2 = \lambda_{j1}^2 + \lambda_{j2}^2 + \dots + \lambda_{jm}^2 = b_{j1}^2 + b_{j2}^2 + \dots + b_{jm}^2 \quad (11.38)$$

Es decir, **la rotación no cambia las comunidades** (permanecen constantes). Toda rotación ortogonal tiene esta propiedad, ya que las rotaciones ortogonales de las matrices de cargas de los factores no afectan las comunidades de las variables de respuesta. En consecuencia, **las rotaciones ortogonales no afectan las varianzas específicas de las variables**.

11.6.2 Rotación Oblicua

En la práctica, las rotaciones oblicuas se pueden lograr multiplicando la matriz A por una matriz Q no ortogonal ($Q^T Q \neq I$). Las rotaciones oblicuas no producen nuevos factores que permanecen no correlacionados, lo cual es una contradicción de las hipótesis iniciales del FA. Luego, este tipo de rotaciones no tiene mucho sentido.

En el desarrollo inicial de un proceso de FA se supone que existe un conjunto no correlacionado de factores subyacentes que dirigen o controlan las variables que se están midiendo. Luego, permitir rotaciones oblicuas implica por lo tanto desconocer esta hipótesis. Si bien existen paquetes computacionales que permiten realizar rotaciones oblicuas, ellas no son recomendables.



11.7 Cuantificación de Factores

La cuantificación de factores corresponde a asignarle valores a los factores para cada unidad experimental del conjunto de datos.

La cuantificación de los factores no es sencilla, pues el modelo para cada unidad experimental es $X = \Lambda F + \eta$ donde η no se conoce y Λ se estima. En consecuencia, para un determinado vector de observaciones X , no se puede determinar F en forma explícita.

A continuación se presentan algunos métodos para estimar F .

11.7.1 Método de Barlett

Después de resolver el modelo de FA, se tiene $Z = \Lambda F + \eta$ donde $\eta \sim N(0; \Psi)$ y Z es la variable de respuesta estandarizada. El paso siguiente es hallar F que minimice:

$$(Z_r - \hat{\Lambda}F)^T \Psi^{-1} (Z_r - \hat{\Lambda}F) \quad (11.39)$$

donde Z_r es el vector de datos estandarizados para el r -ésimo individuo. Para un Z_r dado, la expresión anterior se minimiza cuando:

$$\hat{F}_r = (\hat{\Lambda}^T \hat{\Psi}^{-1} \hat{\Lambda})^{-1} \hat{\Lambda}^T \hat{\Psi}^{-1} Z_r \quad (11.40)$$

Luego, se forma F_r como el vector de las cuantificaciones estimadas de los factores para el r -ésimo individuo ($r = 1, 2, \dots, N$).

11.7.2 Método de Thompson

Thompson notó que, para datos normalmente distribuidos, la distribución conjunta de Z y F era:

$$\begin{pmatrix} Z \\ F \end{pmatrix} \sim N \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}; \begin{bmatrix} P & \Lambda \\ \Lambda^T & I \end{bmatrix} \right) \quad (11.41)$$

Esto implica que la esperanza condicional de F dado $Z = Z^*$ es:

$$E(F/Z = Z^*) = \Lambda^T P^{-1} Z^* \quad (11.42)$$

Por lo tanto, en el método de Thompson se estima el vector de valores para los factores del r -ésimo individuo de la forma:

$$\hat{F}_r = \hat{\Lambda}^T (\hat{\Lambda} \hat{\Lambda}^T + \hat{\Psi})^{-1} Z_r \quad (11.43)$$

11.7.3 Otros Métodos

Dado que para cuantificar un factor se requiere únicamente que una determinada variable esté altamente correlacionada con un factor y poco correlacionada con los demás factores, cualquier procedimiento que cumpla estas dos condiciones se considera aceptable.

Una alternativa puede ser por ejemplo considerar el valor promedio de todas aquellas variables que tengan correlación elevada con un determinado factor.

Una segunda alternativa puede ser considerar aquella variable que presenta una mayor correlación con el factor como cuantificación de este mismo.

12 ANÁLISIS DE CONGLOMERADOS (CLUSTER)

El análisis cluster consiste en definir esquemas de agrupación que permita dividir un gran número de unidades experimentales (observaciones) en clases o grupos que sean semejantes entre sí.

Luego, se realizan clasificaciones a partir de datos que no están inicialmente clasificados. Por ejemplo, podría interesar analizar la semejanza de clientes de una determinada tienda comercial. Las variables medidas podrían incluir aspectos como la edad, el nivel educativo, nivel de ingresos, estado civil, número de hijos, etc.

Para determinar la semejanza de los grupos dentro de la muestra total, deben definirse criterios que indiquen cuán semejante son las unidades experimentales dentro de un determinado grupo y cuán distintas son del resto.

12.1 Medidas de Semejanza y Desemejanza

12.1.1 Distancia Métrica

Corresponde a la distancia euclidiana entre valores de dos observaciones:

$$d_{rs} = \left[(x_r - x_s)^T (x_r - x_s) \right]^{1/2} \quad (12.1)$$

Como alternativa, que es en la mayoría de los casos recomendable, se puede usar la distancia métrica estandarizada:

$$d_{rs} = \left[(z_r - z_s)^T (z_r - z_s) \right]^{1/2} \quad (12.2)$$

12.1.2 Distancia de Mahalanobis

A diferencia de las anteriores, esta distancia requiere de la matriz de varianzas y covarianzas (Σ):

$$d_{rs} = \left[(x_r - x_s)^T \Sigma^{-1} (x_r - x_s) \right]^{1/2} \quad (12.3)$$

12.2 Análisis Gráficos

Es importante hacer notar que diferentes técnicas de agrupación pueden generar resultados completamente distintos. La razón de ello es que cada algoritmo de agrupación impone una determinada estructura en la muestra.


Por otra parte, es probable que determinadas técnicas de agrupación identifiquen agrupamientos que en realidad pueden no existir.

Para mitigar estos problemas algorítmicos, se pueden utilizar diferentes técnicas gráficas que permitan validar los resultados de los algoritmos utilizados.

12.2.1 Gráficos de Dispersión (Bidimensionales)

Este tipo de gráfico es útil cuando la dimensionalidad de los datos es $p = 2$. De hecho, es probablemente el mejor método para identificar agrupamientos:

Figura 12.1
Gráfico de Dispersión Bidimensional



12.2.2 Gráficos de Dispersión (Tridimensionales)

Son similares a los gráficos bidimensionales, aunque en determinados casos, por su representación gráfica, puede no identificarse de manera adecuada la agrupación adecuada de los distintos conjuntos de datos. Ello se debe a que si bien son una representación de tres dimensiones, siguen graficándose sólo en dos dimensiones.

Figura 12.2
Gráfico de Dispersión Tridimensional





Figura 12.3
Gráfico de Dispersión de Esferas



12.2.3 Gráficos de Andrews

En 1972, Andrews sugirió que la observación p -variada para la r -ésima observación experimental, esto es $x_r = (x_{r1}, x_{r2}, \dots, x_{rp})^T$, podría representarse por la función:


$$f_r(t) = \frac{x_{r1}}{\sqrt{2}} + x_{r2} \sin(t) + x_{r3} \cos(t) + x_{r4} \sin(2t) + x_{r5} \cos(2t) + \dots \quad (12.4)$$

De este modo, los datos correspondientes a un individuo (o unidad experimental en general) dan lugar a una función única para dicho individuo.

Las curvas resultantes no sólo representan la imagen de relaciones entre las variables, sino que son útiles para hallar o validar agrupamientos que podrían existir en los datos. También son útiles para localizar datos outliers.

Para construir las curvas de Andrews, es importante que las variables de respuesta se midan en unidades semejantes, por lo que es recomendable estandarizar los datos antes de construir las gráficas.

Figura 12.4
Gráficos de Andrews



Notar que **las interpretaciones gráficas resultantes son afectadas por el ordenamiento de las variables**. Si se cree que ciertas variables son más importantes que otras, la más importante debe tomarse como x_1 , la segunda en importancia debe tomarse como x_2 , y así sucesivamente.


En los casos donde se tienen grandes números de variables de respuesta, los gráficos de Andrews pueden construirse luego de un análisis de MCP. En dicho caso, x_1 debe tomarse como la primera calificación de una componente principal, x_2 como la segunda, etc.

12.2.4 Gráficos de Estrellas

Cada dato se representará mediante una estrella que contendrá tantos rayos o puntas como variables se deseen representar. Luego, existirá una estrella para cada unidad experimental.

La longitud del j -ésimo rayo en la estrella de la i -ésima unidad experimental (x_{ij}) dependerá del valor de la variable j en dicho dato.

Figura 12.5
Gráficos de Estrellas



Se utilizan los siguientes criterios para calcular la longitud del rayo:

- Construir la variable z a partir de la estandarización de x . En cada eje se marca el cero y los valores de la variable z se representan sobre los ejes en unidades de desviación estándar.
- Se construye la variable $z = (z_1, z_2, \dots, z_p)^T$ de manera que la variable z_j vale 1 cuando x_j es máxima y 0 cuando x_j es mínima, de acuerdo a la siguiente expresión:

$$z_{ij} = \frac{x_{ij} - \min_i \{x_{ij}\}}{\max_i \{x_{ij}\} - \min_i \{x_{ij}\}} \quad (12.5)$$

- c) Se construye la variable $z = (z_1, z_2, \dots, z_p)^T$ de manera que se cumpla $0 \leq z_j \leq 1$ mediante la siguiente expresión:


$$z_{ij} = \frac{x_{ij} - \min_i \{x_{ij}\}}{\max_i \{x_{ij}\} - \min_i \{x_{ij}\}} \quad (12.6)$$

Ejemplo (The World Competitiveness Yearbook 1999):

- x : ocho índices socioeconómicos de un país
- x_1 : Economía interna: inversiones, ahorro, consumo
- x_2 : Economía internacional: inversiones en extranjero, importación, exportación
- x_3 : Gobierno: Política fiscal, justicia, seguridad, deuda externa
- x_4 : Finanzas, sector bancario
- x_5 : Ciencia y tecnología: Inversión en I+D, propiedad intelectual, capacidad tecnológica
- x_6 : Organización empresarial
- x_7 : Infraestructura, energía y medio ambiente
- x_8 : Sociedad: Recursos humanos, desempleo, calidad de vida, educación


Tabla 12.1
Datos Económicos de Países del Mundo

Observación (i)	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8
Canadá	61.0	51.5	64.5	67.0	61.0	68.5	69.0	68.0
Australia	60.0	49.5	67.5	67.0	60.0	64.0	73.0	67.0
Noruega	62.5	50.5	57.5	61.0	59.0	60.5	76.0	70.0
Venezuela	30.0	42.0	44.0	35.5	41.0	37.0	42.0	40.5
P. Bajos	64.5	72.0	61.5	72.5	63.0	73.0	69.5	65.0
Hungría	59.5	58.0	51.5	51.5	49.5	51.0	50.5	57.0
Portugal	58.0	54.5	52.0	59.5	42.0	48.0	49.0	57.5
España	57.5	59.0	63.5	64.5	49.5	57.5	55.0	59.0
China	66.5	54.5	62.0	40.5	49.5	42.5	39.0	57.0
Thailandia	44.5	45.5	62.0	39.0	38.0	38.0	39.0	49.5
Brasil	52.0	44.5	50.5	39.0	41.0	48.5	41.0	39.5
México	53.5	40.5	50.5	36.5	39.0	48.5	42.0	43.0



12.2.5 Gráficos de Caras de Chernoff

Representan observación p -dimensional mediante cara bidimensional. Forma de cabeza, curvatura de boca, tamaño de ojo y de nariz, posición de cejas etc., determinados por valores observados de las p variables.



12.3 Métodos de Agrupación

12.3.1 Método del Vecino Más Cercano

En este método se empieza con un número de agrupamientos igual al total de observaciones o unidades experimentales que se disponga. Luego, dependiendo de las distancias entre puntos, se van agrupando hasta que finalmente se dispone de un único grupo que contiene a las N unidades experimentales o individuos:

- Empiece con N agrupamientos, en que cada uno de ellos contiene exactamente una unidad experimental
- Enlace los dos puntos más cercanos, de acuerdo a una de las medidas de distancia definidas anteriormente (ver punto 14.1)
- Defina la desemejanza entre este nuevo agrupamiento y cualquier otro punto como la distancia mínima entre cualquiera de estos dos puntos agrupados y el otro punto
- Continúe combinando los agrupamientos que sean los más cercanos entre sí de modo que, en cada etapa, la cantidad de agrupamientos se reduzca en uno, y la desemejanza entre cualquier par de éstos siempre se defina como la distancia entre sus miembros más cercanos

El número apropiado de agrupamientos se encuentra en algún punto intermedio entre el principio y el final de este proceso.

Para ilustrar este método, consideremos un ejemplo. Las distancias métricas para un grupo de 6 individuos se presenta en la siguiente Tabla:

	1	2	3	4	5	6
1	-	0,31	0,23	0,32	0,26	0,25
2		-	0,34	0,21	0,36	0,28
3			-	0,31	0,04	0,07
4				-	0,31	0,28
5					-	0,09
6						-

La agrupación inicial se denota como $G_0 = \{[1], [2], [3], [4], [5], [6]\}$. Analizando la matriz de desemejanza anterior, se observa que los dos puntos más cercanos entre sí son el 3 y el 5, con una distancia métrica de 0,04. Luego, se define una nueva agrupación de la forma $G_1 = \{[1], [2], [3-5], [4], [6]\}$.

Posteriormente, debe calcularse una nueva matriz de desemejanza o de distancias métricas.

- La distancia métrica entre el grupo $[1]$ y el $[3-5]$ corresponde al mínimo entre **0,23** y 0,26.
- La distancia métrica entre el grupo $[2]$ y el $[3-5]$ corresponde al mínimo entre **0,34** y 0,36.
- La distancia métrica entre el grupo $[4]$ y el $[3-5]$ corresponde al mínimo entre **0,31** y **0,31**.
- La distancia métrica entre el grupo $[6]$ y el $[3-5]$ corresponde al mínimo entre **0,07** y 0,09.
- El resto de las distancias se mantiene igual

La nueva matriz de desemejanza es la siguiente:

	1	2	3-5	4	6
1	-	0,31	0,23	0,32	0,25
2		-	0,34	0,21	0,28
3-5			-	0,31	0,07
4				-	0,28
6					-

La menor distancia métrica corresponde ahora a la existente entre los grupos $[6]$ y $[3-5]$, que es igual a 0,07. Luego, se define una nueva agrupación de la forma $G_2 = \{[1], [2], [3-5-6], [4]\}$.

- La distancia métrica entre el grupo $[1]$ y el $[3-5-6]$ corresponde al mínimo entre **0,23** y 0,25.

- La distancia métrica entre el grupo $[2]$ y el $[3-5-6]$ corresponde al mínimo entre 0,34 y **0,28**.
- La distancia métrica entre el grupo $[4]$ y el $[3-5-6]$ corresponde al mínimo entre 0,31 y **0,28**.
- El resto de las distancias se mantiene igual

	1	2	3-5-6	4
1	-	0,31	0,23	0,32
2		-	0,28	0,21
3-5-6			-	0,28
4				-

La menor distancia métrica corresponde ahora a la existente entre los grupos $[2]$ y $[4]$, que es igual a 0,21. Luego, se define una nueva agrupación de la forma $G_3 = \{[1], [2-4], [3-5-6]\}$.

- La distancia métrica entre el grupo $[1]$ y el $[2-4]$ corresponde al mínimo entre **0,31** y 0,32.
- La distancia métrica entre el grupo $[3-5-6]$ y el $[2-4]$ corresponde al mínimo entre **0,28** y **0,28**.
- El resto de las distancias se mantiene igual

	1	2-4	3-5-6
1	-	0,31	0,23
2-4		-	0,28
3-5-6			-

La menor distancia métrica corresponde ahora a la existente entre los grupos $[1]$ y $[3-5-6]$, que es igual a 0,23. Luego, se define una nueva agrupación de la forma $G_4 = \{[2-4], [1-3-5-6]\}$.

- La distancia métrica entre el grupo $[2-4]$ y el $[1-3-5-6]$ corresponde al mínimo entre 0,31 y **0,28**.

	1-3-5-6	2-4
1-3-5-6	-	0,28
2-4		-

Finalmente, se obtiene el grupo $G_5 = \{[1-2-3-4-5-6]\}$ con todos los individuos.


12.3.2 Diagrama de Árbol

Una manera de decidir cuándo detener el proceso de agrupación es construir un diagrama de árbol jerárquico.

Este tipo de diagrama contiene ramas que une individuos y muestra el orden en que se asignan los individuos a los agrupamientos. Las longitudes de las ramas son proporcionales a las distancias métricas entre los individuos (o grupos de individuos).

Para el ejemplo anterior, en la siguiente Figura se presenta el árbol jerárquico que se ha obtenido:

Figura 12.6
Diagrama de Árbol Jerárquico




Para determinar la cantidad de agrupaciones a conformar, es factible realizar una **inspección visual** del árbol jerárquico que se ha construido.

Por ejemplo, con el diagrama de árbol expuesto en la Figura 14.6 no es tan claro el número de agrupaciones que es posible definir. Una alternativa adecuada podría ser por ejemplo considerar 4 agrupaciones: $G_2 = \{[1], [2], [3-5-6], [4]\}$.

Sin embargo, en un diagrama como el que se muestra en la siguiente Figura 14.7, se podrían definir claramente 3 agrupaciones:

Figura 12.7
Diagrama de Árbol Jerárquico con 3 Agrupaciones



12.3.3 Estadístico F de Beale

Otro procedimiento para determinar el número de agrupaciones a considerar corresponde al propuesto por Beale.

Suponga que se tienen 2 agrupaciones posibles; la primera tiene a su vez C_1 agrupaciones y la segunda tiene C_2 agrupaciones, tal que $C_2 < C_1$.

Sean W_1 y W_2 las sumas de cuadrados correspondientes a las distancias métricas dentro de cada una de las 2 agrupaciones, calculadas desde las medias de éstos. Es decir, suponga que se tienen n_r individuos en el r -ésimo agrupamiento: $r = 1, 2, \dots, C_1$ y $r = 1, 2, \dots, C_2$.

Si X_{rq} representa el q -ésimo vector de observaciones en el r -ésimo agrupamiento, entonces:

$$W_1 = \sum_{r=1}^{C_1} \sum_{q=1}^{n_r \in C_1} \left[(X_{rq} - \bar{X}_r)^T (X_{rq} - \bar{X}_r) \right] \quad (12.7)$$

$$W_2 = \sum_{r=1}^{C_2} \sum_{q=1}^{n_r \in C_2} \left[(X_{rq} - \bar{X}_r)^T (X_{rq} - \bar{X}_r) \right] \quad (12.8)$$

Para determinar si la primera agrupación es mejor que la segunda, Beale sugirió calcular una pseudo-estadística tipo F por medio de:

$$F^* = \frac{(W_2 - W_1)}{W_1} \frac{(N - C_1)k_1}{(N - C_2)k_2 - (N - C_1)k_1} \quad (12.9)$$

donde $k_1 = C_1^{-2/p}$ y $k_2 = C_2^{-2/p}$; N es el número total de individuos (unidades experimentales) y p es el número de variables exógenas.

Si F^* es mayor que el valor tabulado de F con $(N - C_1)k_1$ grados de libertad en el denominador y $[(N - C_2)k_2 - (N - C_1)k_1]$ en el numerador (a la inversa de la expresión (12.9)), entonces se elegiría la primera agrupación (aquella con más agrupamientos) sobre la segunda (aquella con menos agrupamientos).

Notar que eventualmente pueden subdividirse las dos agrupaciones iniciales y repetir el mismo análisis para determinar finalmente cuáles serían consideradas semejantes y cuáles no.

12.4 Reducción de la Escala Multidimensional

La reducción de la escala multidimensional es una técnica matemática que permite mapear en un espacio de menos dimensiones las distancias métricas entre los individuos (unidades experimentales) que se encuentran en un espacio de muchas dimensiones (muchas variables exógenas).

Resulta útil, por ejemplo, mapear distancias desde un espacio multidimensional hacia uno bidimensional, para luego construir y analizar un gráfico de dispersión.

Para aplicar esta técnica, en primer lugar deben calcularse las distancias métricas entre todas las parejas de individuos; es razonable antes estandarizar los datos.

Supongamos que D_{rs} representa la distancia métrica entre el r -ésimo individuo y el s -ésimo individuo, dentro de un espacio muestral p -dimensional: $r = 1, 2, \dots, N$, $s = 1, 2, \dots, N$; N es el número total de individuos.

Si se representan respectivamente por Z_r y Z_s los vectores de valores (estandarizados) del r -ésimo y s -ésimo individuo, la distancia métrica estandarizada entre estos dos individuos se expresa como:

$$D_{rs} = \left[(Z_r - Z_s)^T (Z_r - Z_s) \right]^{1/2} \quad (12.10)$$

Estas distancias se pueden ordenar desde la más pequeña hasta la más grande.

Sean $D_{r_1 s_1}$ la distancia entre los dos individuos más cercanos; $D_{r_2 s_2}$ la distancia entre los siguientes dos individuos más cercanos, y así sucesivamente hasta llegar a $D_{r_{N(N-1)/2} s_{N(N-1)/2}}$, que es la distancia entre los individuos más lejanos. Note que el número de parejas distintas de individuos es $\frac{N(N-1)}{2}$.

Considere a continuación la representación gráfica de N individuos en el espacio bidimensional y denote por d_{rs} la distancia entre el r -ésimo individuo y el s -ésimo individuo, dentro del espacio bidimensional.

En este mismo espacio, sean $d_{r_1s_1}$ la distancia entre los dos individuos más cercanos; $d_{r_2s_2}$ la distancia entre los siguientes dos individuos más cercanos, y así sucesivamente hasta llegar a $d_{r_{N(N-1)/2}s_{N(N-1)/2}}$, que es la distancia entre los individuos más alejados.

La reducción de escala multidimensional intenta localizar N puntos en un espacio bidimensional de modo que las distancias entre las parejas de puntos en este espacio corresponda tanto como pueda con las distancias verdaderas ordenadas entre los puntos observados:

$$D_{r_1s_1} < D_{r_2s_2} < \dots < D_{r_{N(N-1)/2}s_{N(N-1)/2}} \quad (12.11)$$

La localización de los puntos observados en un espacio reducido se realiza de tal forma que se minimice la expresión:

$$E = \frac{\sum_{r=1}^N \sum_{s=1}^{r-1} (D_{rs} - d_{rs})^2 / D_{rs}}{\sum_{r=1}^N \sum_{s=1}^{r-1} D_{rs}} \quad (12.12)$$

sujeto a (12.11).

Para evaluar la calidad del ajuste, se acostumbra **comparar gráficamente las diferencias reales entre las parejas de puntos contra sus distancia modeladas**. Si la representación gráfica de estas parejas de distancias revela una tendencia monótona creciente, entonces se puede deducir que la gráfica bidimensional ilustra con exactitud la cercanía de las parejas de puntos.

Evidentemente, para determinar las distancias d_{rs} es necesario utilizar programas computacionales específicos. Notar también que es altamente probable la inexistencia de soluciones factibles, por lo que resulta necesario relajar algunas de las restricciones, o incluso todas.

