

Microeconometría Aplicada

Javiera Vásquez Núñez¹

Mayo 2012

¹Agradezco a José Manuel Eguiguren la revisión y comentarios de este apunte. Cualquier comentario o sugerencia enviar correo electrónico a jvasquez@fen.uchile.cl

Índice general

1. Introducción	8
1.1. Algunas preguntas económicas	8
1.2. Preguntas sobre <i>Preguntas</i>	9
1.3. El Ideal de lo Experimental	11
1.3.1. El Problema de Selección	11
1.3.2. La asignación aleatoria resuelve el problema de selección .	13
1.3.3. Análisis de Regresión para experimentos	13
1.4. Tipos de datos	14
1.4.1. Corte Transversal	14
1.4.2. Series de tiempo	15
1.4.3. Datos de Panel o Longitudinales	15
2. Modelo de Regresión Lineal	18
2.1. Análisis de Regresión	18
2.1.1. ¿Qué es una regresión?	18
2.1.2. Relaciones estadísticas versus relaciones determinísticas . .	21
2.1.3. Regresión versus Causalidad	21
2.1.4. Regresión versus Correlación	22

2.2.	Análisis de regresión con dos variables	25
2.2.1.	Función de regresión poblacional (FRP)	27
2.2.2.	Especificación estocástica de la función de regresión pobla- cional	28
2.2.3.	Función de regresión muestral	30
2.2.4.	Propiedades de un Estimador	33
2.3.	Modelo de regresión con dos variables	36
2.3.1.	Método de Mínimos Cuadrados Ordinarios	36
2.3.2.	Ejemplo Estimación MCO	39
2.3.3.	Supuestos detrás del método MCO	40
2.3.4.	Errores estándar de los Estimadores Mínimos Cuadrados Ordinarios	44
2.3.5.	Estimador Mínimo Cuadrado Ordinario de σ^2	45
2.4.	Modelo de Regresión con k variables	47
2.4.1.	Representación Matricial del Modelo de Regresión Lineal .	47
2.4.2.	Estimador Mínimo Cuadrados Ordinarios	48
2.5.	Propiedades del estimador MCO	50
2.5.1.	Propiedad de mejor estimador lineal insesgado	51
2.5.2.	Teorema de Gauss-Markov	51
3.	Modelo de Regresión Lineal: Inferencia y Bondad de Ajuste	53
3.1.	Bondad de Ajuste y Análisis de Varianza	53
3.1.1.	Modelo de Regresión Lineal en Desvíos	54
3.1.2.	Análisis de Varianza	55
3.1.3.	Bondad de Ajuste: R^2 y $\tilde{R}^2$	56

3.2. Inferencia	58
3.2.1. Test t (Una hipótesis lineal)	61
3.2.2. Test F (Conjunto de hipótesis lineales)	70
3.2.3. Intervalos de Confianza	70
3.2.4. Test de Normalidad (Test de Jarque-Bera)	72
3.3. Bondad de Ajuste e Inferencia en STATA	73
4. Modelo de Regresión Lineal: Especificación y Problemas	78
4.1. Omisión de Variables Relevantes	80
4.2. Inclusión de Variables Irrelevantes	83
4.3. Multicolinealidad	83
4.4. Variables Categóricas o Cualitativas como Regresores	86
4.5. Test de No Linealidades Omitidas	100
4.6. Heterocedasticidad	102
4.7. Selección de Modelos	106
4.7.1. Selección entre modelos anidados	106
4.7.2. Selección de modelos no anidados	108
5. Estimador de Variables Instrumentales	111
5.1. Introducción	111
5.2. Simultaneidad	113
5.3. Error de Medición	114
5.4. Estimador de Variables Instrumentales	115
5.4.1. Estimador de Mínimos Cuadrados Ordinarios en dos etapas	116
5.5. Ejemplos de Variables Instrumentales	117

5.5.1.	¿Afecta la obligatoriedad de educación a la escolaridad e ingresos?, Angrist y Krueger (1991)	117
5.5.2.	Using Geographic Variation in College Proximity to Estimate the Return to Schooling, Card (1993)	118
5.5.3.	Estimating the payoff to schooling using the Vietnam-era Daft lottery, Angrist y Krueger (1992)	119
5.6.	Aplicación I: Determinantes de los gastos médicos	120
6.	Estimador Máximo Verosímil	126
6.1.	Propiedades de los estimadores MV	127
6.2.	Estimación MV	128
6.3.	Inferencia en el contexto MV	132
6.3.1.	Test de Razón de Verosimilitud (LR)	132
6.3.2.	Test de Wald (W)	133
6.3.3.	Test del Multiplicador de Lagrange (LM)	133
6.4.	Algunas acotaciones respecto a la estimación y la inferencia MV .	137
7.	Variable Dependiente Discreta	139
7.1.	Modelo de Probabilidad Lineal	140
7.2.	Modelo de Elección Discreta	144
7.3.	Variable Dependiente Latente	145
7.4.	Estimación	146
7.5.	Medidas de Bondad de Ajuste	151
7.6.	Aplicación	156
8.	Modelos de Respuesta Múltiple	162
8.1.	Modelos de Respuesta Múltiple Ordenada	162

8.2. Modelos Multinomiales	169
8.2.1. Conditional Logit	170
8.2.2. Multinomial Logit	175
8.2.3. Mixed Logit	177
8.2.4. Independencia de Alternativas Irrelevantes	180
8.2.5. Modelo Nested Logit	182
8.2.6. Multinomial Probit	186
9. Variable Dependiente Limitada	188
9.1. Introducción	188
9.2. Modelos Censurados y Truncados	189
9.2.1. Estimación por Máxima Verosimilitud	193
9.2.2. Modelo Tobit	194
9.2.3. Media condicional truncada y censurada	195
9.2.4. Efectos Marginales	197
9.2.5. Estimación de Modelos Censurados y Truncados en STATA	197
9.2.6. Test de Normalidad y Homocedasticidad	204
9.3. Modelos de Selección	208
9.3.1. Modelo de Selección Bivariado (Tobit Tipo II)	208
9.3.2. Medias Condicionales en Modelo Tobit Tipo II	209
9.3.3. Estimador Heckman Dos Etapas (Heckit)	210
9.3.4. Identificación	211
9.3.5. Efectos Marginales	211
9.3.6. Estimación Modelo Tobit Tipo II en STATA	212
9.4. Modelo de Probabilidad con Selección	215

10.Datos de Panel	220
10.1. Modelos de Datos de Panel	221
10.1.1. Modelo Pooled	221
10.1.2. Dummies Individuales y de Tiempo	221
10.1.3. Modelos de Efecto Fijo y Efecto Aleatorio	222
10.2. Estimadores de Datos de Panel	222
10.2.1. MCO Pooled	222
10.2.2. Estimador Between	223
10.2.3. Estimador de Efectos Fijos o Within	223
10.2.4. Estimador de Primeras Diferencias	224
10.2.5. Estimador de Efectos Aleatorios	225
10.3. Test de Hausman	225
10.4. Estimación de Datos de Panel en STATA	226
10.4.1. Formato de la base de datos	226
10.4.2. Descripción de los datos	227
11.Regresión de Mediana y Cuantiles	237
11.1. Regresión de Mediana y Cuantiles en STATA	238
12.Modelos de Datos de Conteo	244
12.1. Modelo de Regresión Poisson	245
12.2. Estimación de Modelo Poisson en STATA	246
12.3. Modelo Binomial Negativo	251
12.4. Estimación Modelo Binomial Negativo en STATA	252
13.Métodos No Paramétricos y Semi-paramétricos	256

13.1. Estimación No Paramétrica de Funciones de Densidad	256
13.2. Estimación No Paramétrica de la Relación Entre Dos Variables . .	260
14.Evaluación de Tratamiento	263
14.1. El Problema de Sesgo de Selección	264
14.2. Metodologías para Evaluación de Impacto	265
14.2.1. Propensity Score Matching	266
14.2.2. Diferencias en Diferencias	275
14.2.3. Regresión Discontinua	277
15.Modelos de Duración	284
15.1. Introducción	284
15.2. Modelos de Duración	285

Capítulo 1

Introducción

En este curso estudiaremos diferentes técnicas econométricas aplicadas a datos a nivel micro (o individual) que nos permitirán responder a preguntas económicas y de políticas públicas de interés.

Primero comencemos por definir qué se entiende por Econometría, pero esta definición no es única:

- Ciencia que testea la teoría económica
- Herramientas utilizadas para predecir los valores de variables económicas
- Proceso mediante el cual se ajusta un modelo económico matemático a datos reales
- Ciencia y arte de usar datos históricos para hacer recomendaciones de política cuantitativas

Todas estas definiciones son correctas, pero siendo más general la Econometría se puede definir como la ciencia y arte de usar la teoría económica y técnica estadísticas para analizar datos económicos.

1.1. Algunas preguntas económicas

Las decisiones en el gobierno y mundo privado (negocios) dependen del correcto entendimiento de la relación entre las variables claves que afectan estas

decisiones, de esta forma se puede decir que estas decisiones requieren de respuestas cuantitativas a preguntas cuantitativas.

Algunos ejemplos de preguntas que podemos responder son los siguientes:

- ¿Aumentar la cantidad de alumnos por profesor mejora el rendimiento de los alumnos?
- ¿Los impuestos a los cigarros reducen la cantidad de cigarros fumados?
- ¿Cuál será la tasa de inflación el próximo año?
- ¿Cuánto disminuye el consumo por energía eléctrica al aumentar el precio?
- ¿Existen diferencias salariales entre hombres y mujeres?
- ¿Cómo se ve afectada participación previsional al incrementar los beneficios sociales no contributivos?

Cada una de estas preguntas requiere una respuesta cuantitativa, por ejemplo, necesitamos determinar en cuantos puntos porcentuales se reduce la tasa de participación previsional por un incremento en 30 mil pesos en la pensión no contributiva, este número debe ser determinado de manera empírica mediante los datos disponibles. De esta forma, al utilizar una base de datos para responder nuestras preguntas de manera cuantitativa siempre existirá incertidumbre en nuestra respuesta, por lo cual no basta con encontrar la respuesta cuantitativa a la pregunta sino que además determinar la precisión de esta.

Una herramienta matemática que nos permite responder esta pregunta es el análisis de regresión, el que mide numéricamente cuanto cambia una variable (variable de interés) al cambiar otra variable, manteniendo todo lo demás constante.

1.2. Preguntas sobre *Preguntas*

Al estudiar y aprender las técnicas econométricas se tiene la tentación a tratar de ocuparlas sin pensar mucho en la agenda de investigación o las preguntas relevantes que quiero responder. Una agenda de investigación coherente, interesante, y factible constituye la base sobre la cual se construyen las metodologías estadísticas y econométricas útiles. Así, una muy buena econometría no puede salvar una agenda de investigación débil, pero por el contrario el uso promiscuo de técnicas

econométricas sofisticadas a veces puede derrumbar una buena idea.

A continuación se presenta lo que Angrist y Pischke en su libro “Mostly Harmless Econometrics: An Empiricist’s Companion” definen como la base para un proyecto de investigación exitoso. Una agenda de investigación puede ser organizada en torno a cuatro preguntas (Frequently Asked Questions, FAQs), las cuales preguntan sobre:

- Relación de interés
- El experimento ideal
- La estrategia de identificación
- EL modo de hacer inferencia

Así, para comenzar deberíamos preguntarnos *¿Cuál es la relación causal que nos interesa?*, a pesar de que la investigación puramente descriptiva tiene un rol importante que jugar, la investigación más interesante en ciencias sociales tiene que ver con *causa y efecto*, como por ejemplo el efecto del tamaño de la clase sobre el rendimiento de los alumnos. Una relación causal es útil para hacer predicciones sobre las consecuencias de hacer cambios o políticas, nos dice que pasaría en un mundo alternativo (o contrafactual). Por ejemplo, como parte de la agenda que investiga la productividad de la capacidad humana o capital humano se ha investigado el efecto causal de escolaridad sobre salarios. El efecto causal de escolaridad sobre salarios es el incremento en salarios que un individuo recibiría al incrementar su escolaridad.

La segunda pregunta tiene que ver con el experimento que idealmente nos permitiría capturar el efecto causal de interés. Por ejemplo, en el caso que nos interesa el efecto causal de escolaridad sobre ingresos podríamos pensar en ofrecer una compensación a las personas que dejan el colegio para que no lo hagan y ver cuáles son las consecuencias. Los experimentos ideales generalmente son hipotéticos.

La tercera y cuarta pregunta tienen que ver con los elementos para generar un estudio específico. Angrist y Krueger (1999) utilizan el término “estrategia de identificación” para describir la forma en que los investigadores utilizan los datos observados (no experimental) para aproximar un experimento real. Con respecto a la cuarta FAQs tiene que ver con la mejor forma de hacer inferencia en el contexto de los datos utilizados, así el modelo de hacer inferencia dependerá de la población bajo estudio, los datos disponibles, y los supuestos utilizados para obtener los errores estándar.

1.3. El Ideal de lo Experimental

Las investigaciones con un diseño experimental han sido las más creíbles e influyentes. Un ejemplo es el *Proyecto Perry Preschool*, donde se intervinieron de manera aleatoria 123 niños pre-escolares de raza negra en Ypsilanti (Michigan) en el año 1962. El grupo de tratamiento de este programa fue seleccionado de manera aleatoria para recibir una intervención intensiva que incluye educación pre-escolar y visitas a la casa. Este programa fue de gran impacto en los estudios realizados, ya que siguió a los niños hasta la edad de 27 años, además este programa dio el pie de partida para un programa pre-escolar masivo.

Otro ejemplo es el programa PROGRESA en México....

1.3.1. El Problema de Selección

Suponga que estamos en una pregunta causal (supuestamente), por ejemplo “¿*Los hospitales hacen a las personas más saludables?*”, para algunos esta pregunta puede parecer metafórica, pero es la clase de pregunta que le interesa a los economistas en el área de la salud, para hacerla más realista imagine que estamos estudiando a la población de adultos mayores pobres (que no tienen seguro de salud) que usan las atenciones de urgencia como cuidados primarios de salud, y algunos de estos pacientes son hospitalizados recibiendo los cuidados de salud que necesitan. Esta manera de obtener los cuidados de salud es costosa, satura las instalaciones de urgencia de los hospitales, y probablemente no es eficiente. Además de que esta población vulnerable se expone a otro tipo de enfermedades al ingresar al hospital mediante esta vía.

Luego, podríamos comparar el estatus de las personas que ingresan al hospital con el estatus de las personas que no ingresan al hospital, la encuesta National Health Interview Survey (NHIS) de Estados Unidos contiene la información necesaria para hacer esta comparación. Específicamente, contiene las preguntas:

- Durante los últimos 12 meses, ¿Estuvo hospitalizado?
- ¿Ud. diría que en general su salud es excelente, muy buena, buena, regular, o mala?, la respuesta a esta pregunta toma valores de 1 a 5, donde 1 es excelente y 5 es mala.

Tabla 1.1
Estatus de salud promedio hospitalizados y no hospitalizados

Grupo	Tamaño Muestra	Promedio Estatus Salud	Error Estándar
Hospitalizados	7774	2.79	0.014
No Hospitalizados	90049	2.07	0.003

La diferencia en medias es 0.71 en favor de las personas no hospitalizadas, esta diferencia es significativa con un estadístico t de 58.9. Tomando este resultado de manera literal sugiere que los hospitales “enferman” a las personas. Sin embargo, es fácil notar que esta comparación no puede ser tomada de manera literal, ya que las personas que van a los hospitales probablemente son menos saludables desde un principio.

Para ver este problema de manera más precisa, pensemos la variable de haber asistido a un hospital como un tratamiento binario $D_i = \{0, 1\}$. La variable de interés o resultados (outcome), en este caso el estatus de salud, es denotada por Y_i . La pregunta es como Y_i es *afectada* por el cuidado del hospital. Para responder esta pregunta, debemos imaginarnos que hubiera pasado con el estado de salud de una persona que fue al hospital si no hubiera ido y viceversa. Así, para cada uno de los individuos existen dos potenciales variables:

$$\text{Resultado Potencial} = \begin{cases} Y_{1i}, & \text{si } D_i = 1 \\ Y_{0i}, & \text{si } D_i = 0 \end{cases}$$

Es decir, Y_{0i} es el estado de salud del individuo i de no haber ido al hospital independiente si fue o no, e Y_{1i} el estado de salud de haber ido al hospital. Nos gustaría saber la diferencia entre Y_{1i} e Y_{0i} lo que podría ser interpretado como el efecto causal de que el individuo i vaya al hospital.

El resultado observado Y_i puede ser escrito en función de los resultados potenciales de la siguiente manera:

$$\begin{aligned} Y_i &= \begin{cases} Y_{1i}, & \text{si } D_i = 1 \\ Y_{0i}, & \text{si } D_i = 0 \end{cases} \\ (1.1) \quad &= Y_{0i} + (Y_{1i} - Y_{0i})D_i \end{aligned}$$

Esta notación es útil ya que $(Y_{1i} - Y_{0i})$ mide el efecto causal de hospitalización para un individuo. En general, es probable que exista una distribución en la población de Y_{1i} e Y_{0i} , de esta forma el efecto tratamiento puede ser diferente para diferentes personas, el problema es que nunca observamos ambos resultados potenciales para una misma persona, por lo cual debemos obtener el efecto de la

hospitalización comparando el estado de salud promedio de los que estuvieron hospitalizados con el estado de salud promedio de los que no estuvieron hospitalizados.

Así, la comparación de los promedios por estatus de hospitalización nos dice algo sobre los resultados potenciales, pero no necesariamente lo que queremos determinar. Formalmente:

$$\underbrace{E[Y_i|D_i = 1] - E[Y_i|D_i = 0]}_{\text{Diferencia observada}} = \underbrace{E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 1]}_{\text{Efecto tratamiento sobre tratados}} + \underbrace{E[Y_{0i}|D_i = 1] - E[Y_{0i}|D_i = 0]}_{\text{Sesgo de selección}}$$

EL sesgo de selección muestra la diferencia en la condición inicial o sin tratamiento entre el grupo de tratados y no tratados, en este caso como se espera que el estado de salud de los hospitalizados sea peor que el de los no hospitalizados, el sesgo de selección es positivo en este caso.

1.3.2. La asignación aleatoria resuelve el problema de selección

La asignación aleatoria de D_i resuelve el problema de selección ya que la asignación aleatoria hace que D_i sea independiente de los resultados potenciales. Notemos que:

$$\begin{aligned} E[Y_i|D_i = 1] - E[Y_i|D_i = 0] &= E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 0] \\ &= E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 1] \end{aligned}$$

dado la independencia entre Y_{0i} y D_i , el sesgo de selección se elimina.

1.3.3. Análisis de Regresión para experimentos

El análisis de regresión es una herramienta útil para estudiar preguntas de causalidad, incluyendo datos experimentales. Supongamos que el efecto tratamiento es constante para todos los individuos $\rho = Y_{1i} - Y_{0i}$. Luego, podemos escribir la ecuación (1.1) de la siguiente manera:

$$Y_i = \underbrace{\alpha}_{E[Y_{0i}]} + \underbrace{\rho}_{(Y_{1i}-Y_{0i})} D_i + \underbrace{\eta_i}_{Y_{0i}-E[Y_{0i}]}$$

Obteniendo la esperanza condicional de la variable de resultado observada en el estatus de tratamiento se tiene:

$$\begin{aligned} E[Y_i|D_i = 1] &= \alpha + \rho + E[\eta_i|D_i = 1] \\ E[Y_i|D_i = 0] &= \alpha + E[\eta_i|D_i = 0] \end{aligned}$$

De esta forma:

$$E[Y_i|D_i = 1] - E[Y_i|D_i = 0] = \underbrace{\rho}_{\text{efecto tratamiento}} + \underbrace{E[\eta_i|D_i = 1] - E[\eta_i|D_i = 0]}_{\text{Sesgo de selección}}$$

El sesgo de selección refleja la correlación entre η_i y el regresor D_i , y dado que:

$$E[\eta_i|D_i = 1] - E[\eta_i|D_i = 0] = E[Y_{0i}|D_i = 1] - E[Y_{0i}|D_i = 0]$$

refleja las diferencias en el resultado potencial (de no ser tratado) entre tratados y no tratados

1.4. Tipos de datos

Los datos que disponemos para trabajar pueden tener tres formatos: corte transversal, Series de Tiempo, y Datos de Panel (o Longitudinales).

1.4.1. Corte Transversal

Los datos de corte transversal se caracterizan por recopilar información para varias unidades en un momento del tiempo, las unidades pueden ser individuos, hogares, comunas, colegios, empresas, regiones, etc.

Un ejemplo de datos de corte transversal en Chile es la Encuesta CASEN.

La Figura 1.1 muestra un ejemplo de una base de corte transversal de países, que muestra la tasa de mortalidad, expectativa de vida, y otras variables para el año 2005.

Figura 1.1
Datos de tipo Corte Transversal

	countries	mort_m	lhyb_m	lexb_m	lexb_pop	govexp	health_cap-a	intdollar	percentGDP
1	AFG	527	10	41.1	42.3	52.6	8	34	5.2
2	ALB	177	10.4	66.3	69.5	64.6	48	150	3.7
3	DZA	164	11.9	67.7	69.4	75	73	169	4.1
4	AND	113	7.4	76.2	79.6	71	1233	1821	5.7
5	AGO	660	8.4	34.1	36.1	63.1	31	70	4.4
6	ATG	197	11.8	68.7	71	60.9	531	614	5.6
7	ARG	183	9.5	70.1	73.9	53.4	679	1130	9.5
8	ARM	216	10.8	66.2	69.7	41.2	54	273	7.8
9	AUS	94	7.3	77.4	80	67.9	1741	2532	9.2
10	AUT	119	7	75.9	79	69.3	1866	2259	8
11	AZE	253	10.4	60.7	63.6	66.9	11	48	1.6
12	BHS	249	14.1	68.8	71.9	57	864	1220	5.7
13	BHR	123	9.9	72.2	72.7	69	500	664	4.1
14	BGD	251	10.2	61.9	61.8	44.2	12	58	3.5
15	BRB	192	9.5	70.5	74.4	66.3	613	940	6.5
16	BLR	368	9	62.9	68.5	86.7	68	464	5.6
17	BEL	128	7.1	74.8	78	71.7	1983	2481	8.9
18	BLZ	191	11.4	67.7	70	45.1	167	278	5.2
19	BEN	407	10.9	51	52.1	46.9	16	39	4.4
20	BTN	270	10.5	60.5	61.6	90.6	9	64	3.9
21	BOL	266	13.1	61.1	62.7	66.3	49	125	5.3
22	BIH	194	9.3	69.3	72.8	36.8	85	268	7.5
23	BWA	797	6.4	39.3	39.1	66.2	190	381	6.6
24	BRA	247	13.3	65.5	68.7	41.6	222	573	7.6

1.4.2. Series de tiempo

Las series de tiempo representan observaciones para una sola unidad en varios momentos del tiempo, la frecuencia de los datos puede ser diaria, semanal, trimestral, anual, etc.

Por ejemplo, del Banco Central de Chile podemos obtener las series de tiempo del Producto Interno Bruto (PIB), Índice de Precios al Consumidor (IPC), fuerza de trabajo, ocupados, etc. Ver Figura 1.2.

1.4.3. Datos de Panel o Longitudinales

Los datos longitudinales corresponden a observaciones de varias unidades en distintos momentos del tiempo, por ejemplo puedo tener los puntajes en SIMCE, PSU, número de alumnos, número de profesores, para varios colegios entre los años 2000 y 2008.

La ventaja de los datos de panel es que observamos la misma unidad en diferentes momentos del tiempo lo que nos permite estudiar la dinámica en el comportamiento de diversas variables.

La Figura 1.3 muestra un ejemplo de datos de panel, con observaciones de varios países entre el año 2004 y 2009.

Figura 1.2
Datos de tipo Series de Tiempo

	año	ftrabajo	ocupados	desocupa	remu	ipc	dlar	pib
1	1990	4824.34	4450.04	373.45	.	25.9	304.9	25142431
2	1991	4919.2	4518.02	402.8	.	22	349.22	27136665
3	1992	5061.2	4723.77	336.91	.	15.6	362.58	30438176
4	1993	5342.24	4992.29	345.83	.	12.7	404.17	32559292
5	1994	5463.22	5036.22	425.1	47.44	11.5	420.18	34416723
6	1995	5497.09	5095.32	405.15	53.83	8.2	396.77	38028591
7	1996	5532.02	5182.08	357.87	60.17	7.4	412.27	40831597
8	1997	5625.4	5281.26	343.8	65.39	6.2	419.31	43526546
9	1998	5763.47	5393.91	357.36	70.55	5.1	460.29	44944340
10	1999	5915.32	5315.45	591.25	74.67	3.4	508.78	44616348
11	2000	5993.55	5414.07	581.79	78.62	3.8	539.49	46605199
12	2001	6065.83	5468.07	597.83	82.74	3.6	634.94	48165625
13	2002	6175.81	5570.5	605	86.51	2.5	688.94	49209330
14	2003	6398.81	5788.52	608.39	89.77	2.8	691.4	51156415
15	2004	6607.65	5946.43	659.42	92.37	1.1	609.53	54246819
16	2005	6798.41	6170.34	632.2	96.97	3.1	559.77	57262645
17	2006	6802.75	6271.85	541.18	102.22	3.4	530.28	59890971
18	2007	6944.39	6448.86	485.92	109.72	4.4	522.47	62694083
19	2008	7203	6641.43	557.02	119.02	8.7	522.46	64677016
20	2009	7299.83	6592.59	702.91	.	1.6	559.61	.

Figura 1.3
Datos de tipo Longitudinal

	country	agno	gdpcons	gdpcorr	inversion	inflacion	desempleo	ccorriente
1	Austria	2004	2.545	289.419	.	1.95	4.792	2.081
2	Austria	2005	2.46	303.447	.	2.108	5.2	2.017
3	Austria	2006	3.46	321.649	.	1.686	4.8	2.833
4	Austria	2007	3.547	371.144	.	2.203	4.4	3.107
5	Austria	2008	2.048	414.828	.	3.223	3.9	3.484
6	Austria	2009	-3.824	374.417	.	.47	5.267	2.109
7	Chile	2004	6.041	95.653	.	1.055	.	2.169
8	Chile	2005	5.559	118.25	.	3.053	.	1.225
9	Chile	2006	4.59	146.774	.	3.392	.	4.874
10	Chile	2007	4.68	163.878	.	4.408	.	4.387
11	Chile	2008	3.163	169.458	.	8.717	.	-2.029
12	Chile	2009	-1.735	150.361	.	2.043	.	.702
13	Costa Rica	2004	4.259	18.598	.	12.315	.	-4.287
14	Costa Rica	2005	5.886	19.967	.	13.798	.	-4.917
15	Costa Rica	2006	8.78	22.528	.	11.471	.	-5.11
16	Costa Rica	2007	7.795	26.269	.	9.357	.	-6.269
17	Costa Rica	2008	2.609	29.664	.	13.426	.	-9.197
18	Costa Rica	2009	-1.5	29.291	.	8.368	.	-3.607
19	Germany	2004	1.176	2,748.82	17.143	1.79	9.775	4.654
20	Germany	2005	.732	2,793.23	16.873	1.92	10.617	5.149
21	Germany	2006	3.176	2,919.51	17.639	1.784	9.833	6.126
22	Germany	2007	2.516	3,328.18	18.349	2.276	8.375	7.52
23	Germany	2008	1.248	3,673.11	19.177	2.754	7.404	6.405
24	Germany	2009	-5.297	3,235.46	16.905	.135	8.015	2.913

Capítulo 2

Modelo de Regresión Lineal

2.1. Análisis de Regresión

2.1.1. ¿Qué es una regresión?

En la mayoría de los problemas económicos y de evaluación de políticas públicas el interés está en estudiar el efecto causal que tiene una o más variables sobre alguna variable de interés (variable de resultado).

El concepto *ceteris paribus* (todo lo demás constante) juega un rol fundamental en determinar el efecto causal, ya que generalmente habrá una serie de variables que afectan el comportamiento de nuestra variable de interés y debemos ser capaces de controlar por todas ellas para poder aislar e identificar de manera correcta el efecto de una o más variables particulares que nos interesen sobre la variable de interés.

Por ejemplo, si estamos interesados en determinar el efecto de una semana adicional de capacitación sobre la productividad de los trabajadores (lo que se verá reflejado en su salario) debemos considerar los otros factores que pueden afectar la productividad del trabajador como educación y experiencia, es decir, debemos preguntarnos cuál es el efecto de una semana adicional de capacitación dado un nivel de escolaridad y un nivel de experiencia.

Suponga que nos interesa estudiar el efecto sobre el rendimiento de los alumnos, medido a través del puntaje SIMCE, de reducir el tamaño del curso (o alumnos

por profesor) en 2. Luego queremos encontrar una relación entre Simce y TamañoCurso, donde significa cambio. Lo que queremos determinar es cuánto cambia el puntaje de Simce en relación a cuanto está cambiando el tamaño del curso, vale decir:

$$\beta = \frac{\Delta Simce}{\Delta \text{Tamaño Curso}}$$

β mide cuanto cambia el puntaje del Simce por cada cambio en tamaño de curso, por ejemplo, si beta es -5.7 se puede interpretar que un aumento en 1 alumno el tamaño del curso disminuye el puntaje de SIMCE en 5.7 puntos:

$$\begin{aligned}\Delta Simce &= \beta \cdot \Delta \text{Tamaño Curso} \\ &= -5,7 \cdot 1\end{aligned}$$

Notemos que β corresponde a la pendiente de una recta que relaciona el puntaje en el SIMCE con el tamaño del curso:

$$Simce = \beta_0 + \beta_1 \cdot \text{Tamaño Curso}$$

donde β_0 es el intercepto de la recta, y β_1 la pendiente.

Así, la regresión, elemento fundamental en la Econometría, corresponde a un estudio de dependencia entre una *variable dependiente* y una o más *variables explicativas*. El análisis de regresión tiene como objeto estimar y/o predecir el promedio poblacional de la variable dependiente para valores fijos de la(s) variable(s) explicativa(s).

Por ejemplo, observemos la Figura 2.1, en el eje de las abscisas tenemos nuestra variable explicativa (X): número de alumnos por profesor, y en el eje de las ordenadas tenemos nuestra variable dependiente (Y): puntaje en prueba estandarizada. Podemos observar dos cosas: primero, para cada valor posible de Tamaño Curso tenemos un rango o distribución de valores de rendimiento; y segundo, el promedio de rendimiento es menor mientras mayor es el tamaño de curso. Esto último se puede apreciar al trazar una recta que una los valores promedios de rendimiento para cada valor de tamaño de curso (línea negra de la Figura 2.2), la que corresponde a la **recta de regresión**. Luego, si de alguna forma podemos determinar el valor del intercepto de esta recta así como de su pendiente, podríamos predecir cuál es el rendimiento promedio esperado de un curso dependiente de la cantidad de alumnos que tenga por profesor.

Figura 2.1
Relación entre rendimiento y tamaño de curso





Figura 2.2
Recta de regresión entre rendimiento y tamaño de curso



2.1.2. Relaciones estadísticas versus relaciones determinísticas

La calidad de un producto, por ejemplo el vino, dependerá de como fue su cosecha y por lo tanto, de variables como la temperatura al que estuvo expuesta la uva, la cantidad de lluvia, sol y los fertilizantes. La relación entre estas variables explicativas y la calidad del vino tiene una naturaleza estadística, ya que si bien estas variables ayudan al productor de vino a saber más o menos como será la cosecha, no podrá predecir en forma exacta la calidad del producto debido a los errores involucrados en estas variables y porque pueden haber otros factores difíciles de medir que estén afectando la calidad del vino.

La variable dependiente, en este caso la calidad del vino, tiene una variabilidad aleatoria, ya que no puede ser explicada en su totalidad por las variables explicativas.

En la econometría nos interesa la dependencia estadística entre variables, donde tratamos con **variables aleatorias**, es decir, variables que tienen una distribución de probabilidad. La dependencia determinística, por el contrario, trata relaciones como la ley de gravedad de Newton¹, las que son exactas (no tienen naturaleza aleatoria).

2.1.3. Regresión versus Causalidad

Es importante tener claro que la regresión es una relación estadística, que no implica causalidad a priori. En el ejemplo del vino, no hay una razón estadística para suponer que la lluvia no depende de la calidad del vino. Pero nuestro sentido común nos hace considerar como variable dependiente la calidad del vino y no la lluvia. Es importante recordar de aquí en adelante que *una relación estadística no puede por sí misma implicar en forma lógica una causalidad*. El que podamos o no determinar y estimar una relación causal va a depender de si estamos o no utilizando una correcta estrategia de identificación en nuestro modelo.

¹La ley de gravedad de Newton plantea que toda partícula en el universo atrae a cualquier otra partícula con una fuerza directamente proporcional al producto de sus masas e inversamente proporcional al cuadrado de la distancia entre ellas: $F=k(\frac{m_1m_2}{r^2})$, donde F=fuerza, m_1 y m_2 son la masa de las dos partículas, r es la distancia y k una constante de proporcionalidad. Esta es una relación determinística, ya que para valores de masas, distancia y constante sabemos exactamente a la fuerza que se atraen estas partículas. Si alguna de las variables estuviera medida con error, la ley de Newton pasa a ser una relación estadística, y F se convierte en una variable aleatoria.

2.1.4. Regresión versus Correlación

El **Análisis de Correlación** está estrechamente relacionado con el de regresión aunque conceptualmente son dos cosas muy diferentes. El análisis de correlación tiene como objetivo medir el grado de asociación lineal entre dos variables, medida a través del **coeficiente de correlación**. Por ejemplo, se puede estar interesado en medir el grado de correlación entre años de educación y salario. En cambio, el análisis de regresión trata de estimar o predecir el valor promedio de salario para un nivel dado de educación.

Las diferencias fundamentales son que, en el análisis de regresión, tenemos una variable dependiente y una o más explicativas, la que son tratadas en forma asimétrica: la variable dependiente es aleatoria, tiene una distribución de probabilidad, en cambio las variables explicativas toman valores fijos. En el análisis de correlación las variables son tratadas de forma simétrica: la correlación entre educación y salario es igual a la correlación entre salario y educación. Además ambas variables son aleatorias. Así, si x e y son dos variables aleatorias, el coeficiente de correlación se define de la siguiente manera:

$$\rho_{yx} = \frac{E\{[x - E(x)][y - E(y)]\}}{\sqrt{\text{var}(x)\text{var}(y)}} = \frac{\sigma_{xy}}{\sqrt{\sigma_x^2\sigma_y^2}}$$

Lo que se calcula para una muestra de la siguiente forma:

$$\hat{\rho}_{yx} = \frac{\sum_{i=1}^n [x_i - \bar{X}][y_i - \bar{Y}]}{\sqrt{\sum_{i=1}^n [x_i - \bar{X}]^2} \sqrt{\sum_{i=1}^n [y_i - \bar{Y}]^2}}$$

con $\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$ e $\bar{Y} = \frac{1}{n} \sum_{i=1}^n y_i$.

De ahora en adelante denotaremos con un $\hat{\cdot}$ a los estimadores de un estadístico obtenidos a partir de información muestral.

Algunas precauciones con el coeficiente de correlación:

- Cuidado cuando el grado de correlación muestral depende de solo unas pocas observaciones.
- El coeficiente de correlación mide una relación lineal. Por lo tanto, una variable puede depender de otra aún cuando la correlación sea cero si la relación es no lineal.

- Correlación no implica causalidad económica, es sólo una relación estadística.
- Correlación puede indicar relación espuria.
- No olvidar que la correlación muestral es una variable aleatoria y que por lo tanto, el coeficiente por si sólo no garantiza la existencia de una relación estadística entre las series.

A continuación las figuras 2.3, 2.4, 2.5 y 2.6 muestran algunos ejemplos de correlaciones entre variables.

Figura 2.3

Portales de Internet, correlación entre número de visitas y valor de la empresa




Figura 2.4
Correlación entre Empleo y Producto (serie de tiempo)




Figura 2.5
Correlación entre Producto per-capita y ranking fútbol





Figura 2.6*Correlación entre temperatura media del día y estudiantes ausentes a clases*

2.2. Análisis de regresión con dos variables

Para esta sección asumiremos que existe una variable dependiente (Y) que es explicada por sólo una variable (X).

Consideremos el siguiente ejemplo. En la Tabla 2.1 se presentan datos de salarios y nivel de educación para una población de 60 individuos ²

Tabla 2.1: Salarios y Años de Educación

Salario (Y)	Años de Educación (X)									
	8	9	10	11	12	13	14	15	16	17
	16000	18260	15000	15000	20000	20000	21912	35000	40000	60000
	32868	36520	40000	40000	50000	54780	60000	73040	90000	120000
	50000	54780	58000	60000	73040	80000	89000	100000	105000	165784
	80000	82170	90000	90000	100000	100500	120000	140000	180000	250000
	100000	109560	120000	120000	140000	160000	200000	230000	280000	365200
	150000	170000	182600	188973	219120	257880	300000	400000	434686	600000
	219120	273900	280000	328680	365200	400000	500000	600000	730400	1095600
	300000	365200	380000	434120	500000	550000	650000	883085	1000000	1643400
	547800	730400	913000	821700	1064558	1460800	1500000	1826000	2487041	4000000
E(Y X)	166199	204532	230956	233164	281324	342662	382324	476347	594125	922220

La población tiene 10 niveles distintos de educación, que van desde 8 a 17. Para cada uno de estos niveles tenemos 9 individuos con distintos salarios. A pesar de la variabilidad en los salarios para cada nivel educacional considerado, en promedio el salario se incrementa a medida que los años de educación aumentan. Esto último se puede verificar al calcular el promedio para cada nivel de educación, lo

²Una población de 60 individuos puede parecer un poco pequeña, pero por el momento consideremos que estas familias son el total existente

que se presenta en la última línea de la Tabla 2.1, estos corresponden a los **valores esperados condicionales**, ya que dependen de los valores dados de la variable X .

En la Figura 2.7, los valores medios condicionales están marcados con una cruz. La unión de estos valores representa la **Recta de regresión poblacional**, donde el término poblacional se refiere a que estamos trabajando con el total de la población.

Definición: La *curva de regresión poblacional* es simplemente el lugar geométrico de las medias condicionales de la variable dependiente para los valores fijos de la(s) variable(s) explicativa(s).

En el ejemplo anterior los valores de Y (salario) no estaban distribuidos de forma simétrica en torno al valor promedio para cada valor X , desde ahora asumiremos que esto **si** se cumple, tal como lo podemos apreciar en la Figura 2.8.

Figura 2.7
Recta de regresión salarios y educación




Figura 2.8
Recta de regresión entre consumo e ingreso




Figura 3: Ingreso semanal y Gasto semanal. Distribución simétrica

En este ejemplo, se ve la relación entre ingreso semanal y gasto en consumo semanal, para cada nivel de ingreso se tiene un rango de gasto que se distribuye en forma simétrica entorno al valor promedio condicional de gasto.

2.2.1. Función de regresión poblacional (FRP)

De lo anterior es claro que la media condicional $E(Y|X_i)$ es función de X_i , donde X_i es un valor dado de X :

$$(2.1) \quad E(Y|X_i) = f(X_i)$$

donde $f(\cdot)$ es una función cualquiera, en el ejemplo anterior era una función lineal. La ecuación (2.1) se denomina **Regresión Poblacional**.

Que forma tiene $f(\cdot)$ es una pregunta empírica, aunque muchas veces la teoría nos puede ayudar bastante. Supongamos que en nuestro ejemplo anterior el salario está relacionado linealmente con la educación, así podemos suponer que la función de regresión poblacional $E(Y|X_i)$ es una función lineal de X_i , es decir:

$$(2.2) \quad E(Y|X_i) = \beta_0 + \beta_1 X_i$$

donde β_0 y β_1 se denominan **coeficientes de regresión**. Así el objetivo es estimar β_0 y β_1 a partir de datos de X e Y .

2.2.2. Especificación estocástica de la función de regresión poblacional

En los dos ejemplos anteriores veíamos que a medida que se incrementa la variable explicativa (educación o ingreso), el valor promedio de la variable dependiente (salario o gasto) también se incrementaba. Sin embargo, este patrón se da solo a nivel de promedios. A nivel individual esto no es necesariamente cierto. En la Tabla 2.1 podemos ver que el individuo que gana menos ingreso con 9 años de educación, gana menos que el individuo con 8 años de educación con mayor salario.

Existe una dispersión de los valores individuales de Y_i en torno al promedio condicional de esta variable. De esta forma, podemos definir:

$$u_i = Y_i - E(Y|X_i)$$

o

$$(2.3) \quad Y_i = E(Y|X_i) + u_i$$


donde u_i es una variable aleatoria no observable que toma valores positivos o negativos. Este término surge pues no se puede esperar que todas las observaciones Y_i sean igual al promedio condicional a X_i . (Ver Figura 2.9).

Recordemos que la regresión es una relación estadística, a pesar de conocer los valores de X_i , esto no nos permite predecir en forma exacta Y_i . Lo que no podemos explicar debido a que tiene naturaleza aleatoria se representa a través de u_i , denominado **término de error estocástico**.

Entonces siguiendo el ejemplo de la Figura 2.8, podemos decir que el gasto de una familia individual (Y_i) corresponde a la suma de dos componentes:

- $E(Y|X_i)$, que corresponde a la media de gasto de todas las familias con el mismo nivel de ingresos → **Componente Determinístico**
- u_i → **Componente Aleatorio**

Figura 2.9
Término de error estocástico



Si $E(Y|X_i)$ es lineal en X_i , podemos escribir la ecuación (2.3) de la siguiente forma:

$$\begin{aligned} Y_i &= E(Y|X_i) + u_i \\ (2.4) \quad &= \beta_0 + \beta_1 X_i + u_i \end{aligned}$$

Tomando el valor esperado condicional en X_i a la ecuación (2.4):

$$\begin{aligned} E(Y_i|X_i) &= E[E(Y|X_i)|X_i] + E(u_i|X_i) \\ (2.5) \quad &= E(Y|X_i) + E(u_i|X_i) \end{aligned}$$

Debido a que $E(Y_i|X_i) = E(Y|X_i)$, implica que:

$$(2.6) \quad E(u_i|X_i) = 0$$

Así, el supuesto de que la recta de regresión pasa a través de las medias condicionales de Y , implica que la media condicional de u_i es cero.

2.2.3. Función de regresión muestral

En la mayoría de los fenómenos económicos a estudiar, no disponemos de las observaciones totales de la población, como hemos supuesto hasta ahora. En la práctica se tiene alcance nada más que a una **muestra** de los valores de Y que corresponden a unos valores fijos de X . En este caso tenemos que estimar la función de regresión poblacional en base a información muestral.

Los datos poblacionales asociados a la Figura 2.8 son los siguientes:

Tabla 2.2. Ingreso familiar (X) y Gasto en consumo (Y).

$Y X$	80	100	120	140	160	180	200	220	240	260
Gasto en	55	65	79	80	102	110	120	135	137	150
consumo	60	70	84	93	107	115	136	137	145	152
familiar	65	74	90	95	110	120	140	140	155	175
semanal	70	80	94	103	116	130	144	152	165	178
(Y)	75	85	98	108	118	135	145	157	175	180
	-	88	-	113	125	140	-	160	189	185
	-	-	-	115	-	-	-	162	-	191
Media Condicional	65	77	89	101	113	125	137	149	161	173

Supongamos que nosotros no conocemos estos datos, es decir, no tenemos acceso a las observaciones correspondientes a la población total. Tenemos a nuestra disposición sólo una muestra (Tabla 2.3), la que ha sido obtenida de forma aleatoria de la población.

Es importante notar que a partir de una población podemos sacar una gran cantidad de muestras en forma aleatoria y en la realidad nosotros observamos solo una de ellas. Debido a esta variabilidad en las muestras podremos estimar la FRP pero no de manera precisa. Para ejemplificar esto supongamos que además de la muestra en la Tabla 2.3 se sacó otra muestra (Tabla 2.4) a partir de la información poblacional.

Tabla 2.3. Muestra aleatoria de la población en tabla 2.

Y	X
70	80
65	100
90	120
95	140
110	160
115	180
120	200
140	220
155	240
150	260

Tabla 2.4. Muestra aleatoria de la población en tabla 2.

Y	X
55	80
88	100
90	120
80	140
118	160
120	180
145	200
135	220
145	240
175	260

Al graficar los datos de las Tablas 2.3 y 2.4 obtenemos los diagramas de dispersión en la Figura 2.10. En este diagrama se han trazado dos **rectas de regresión muestral**: FRM₁ corresponde a la primera muestra y FRM₂ corresponde a la segunda. Como vemos, no es posible asegurar cual de las dos rectas muestrales representa mejor la recta de regresión poblacional.

Entonces es importante tener en mente que las rectas de regresión muestral representan la recta de regresión poblacional, pero debido a fluctuaciones muestrales pueden ser consideradas sólo como una aproximación.

Como contraparte muestral la **función de regresión muestral** puede escribirse como:

$$(2.7) \quad \hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

donde $\hat{Y}_i$ es el estimador de $E(Y|X_i)$, $\hat{\beta}_1$ es el estimador de β_1 y $\hat{\beta}_2$ es el estimador de β_2 .




Figura 4: Rectas de Regresión basadas en dos muestras distintas

Definición: Un *estimador* es una regla, fórmula o método que dice cómo determinar el parámetro poblacional a partir de la información suministrada por la muestra disponible.

De igual manera que para el caso poblacional la función de regresión muestral también tiene una representación estocástica:

$$(2.8) \quad Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{u}_i$$

Entonces, el objetivo del Análisis de Regresión es estimar la Función de regresión poblacional:

$$(2.9) \quad Y_i = \beta_0 + \beta_1 X_i + u_i$$

con base en la Función de regresión muestral:

$$(2.10) \quad Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{u}_i$$

Esta aproximación se puede ver en la Figura 2.11:

Figura 2.11

Función de regresión muestral y poblacional




Figura 5: Rectas de Regresión muestral y poblacional

En términos de la función de regresión muestral, la Y_i observada puede ser expresada como:

$$(2.11) \quad Y_i = \hat{Y}_i + \hat{u}_i$$

y en términos de la función de regresión poblacional puede ser expresada como:

$$(2.12) \quad Y_i = E(Y|X_i) + u_i$$

En la Figura 2.11 podemos notar que para todo X_i a la derecha del punto A, $\hat{Y}_i$ sobreestima $E(Y|X_i)$. De igual manera, para cualquier punto a la izquierda de A, $\hat{Y}_i$ subestima $E(Y|X_i)$. Esta sobreestimación y subestimación del modelo poblacional es inevitable debido a las fluctuaciones muestrales.

¿Cómo se puede construir la función de regresión muestral para $\hat{\beta}_0$ y $\hat{\beta}_1$ que este lo más cerca de los valores verdaderos (poblacionales) de β_0 y β_1 ?

2.2.4. Propiedades de un Estimador

Un estimador, siendo función de la muestra, es una variable aleatoria y tiene su propia distribución de probabilidad.

Las propiedades de los estimadores son las siguientes:

1. Se denomina *sesgo* a la diferencia entre el valor esperado del estimador y su verdadero valor: $E(\hat{\beta}) - \beta$. De esta forma, se dice que $\hat{\beta}$ es un estimador *insesgado* si $E(\hat{\beta}) = \beta$.
2. El estimador es *eficiente* o de *mínima varianza* si no hay ningún otro estimador insesgado que tenga una varianza menor que $\hat{\beta}$. En general se trata de utilizar estimadores de varianza pequeña, pues de este modo la estimación es más precisa.
3. El *Error Cuadrático Medio (ECM)* es una propiedad de los estimadores que mezcla los conceptos de eficiencia e insesgamiento. El ECM de $\hat{\beta}$ se define como:

$$ECM(\hat{\beta}) = E[(\hat{\beta} - \beta)^2]$$

Lo que se puede expresar equivalentemente de la siguiente manera:

$$ECM(\hat{\beta}) = Var(\hat{\beta}) + [Sesgo(\hat{\beta})]^2$$

4. La última propiedad de un estimador es la *consistencia*. El estimador $\hat{\beta}$ es consistente si converge (en el límite) al verdadero valor del parámetro.


Se dice que la sucesión de variables aleatorias $X_1, X_2, \dots, X_n$ *converge en probabilidad* a la variable aleatoria (o constante) X si:

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} \Pr[|X_n - X| < \varepsilon] = 1$$

Esto se denota $\text{plim } X_n = X$. Dos reglas útiles al respecto son:

- $\text{plim} \left(\frac{X}{Y} \right) = \frac{\text{plim} X}{\text{plim} Y}$
- $\text{plim} (X \cdot Y) = \text{plim} X \cdot \text{plim} Y$

Figura 2.12
Convergencia asintótica



Ejemplo: Tenemos una variable y_i que esta compuesta por la suma de un componente fijo o determinístico (c) y un componente aleatorio(u_i):

$$y_i = \underbrace{c}_{\text{componente fijo}} + \underbrace{u_i}_{\text{componente aleatorio}}$$

Si $u_i \sim N(0, \sigma_u^2)$, entonces:

$$\begin{aligned} \mu = E(y_i) &= c \\ V(y_i) &= E[(y_i - E(y_i))^2] = E[u_i^2] = \sigma_u^2 \end{aligned}$$

Ahora consideremos el siguiente estimador de la esperanza de y_i , la media muestral:

$$\hat{\mu} = \bar{Y} = \frac{1}{n}(y_1 + y_2 + \dots + y_n) = \frac{1}{n} \sum_{i=1}^n y_i$$

Veamos que propiedades tiene este estimador:

- **Insesgamiento:** $E(\hat{\mu}) = \mu$

$$\begin{aligned} E(\hat{\mu}) &= E(\bar{Y}) \\ &= E\left(\frac{1}{n}(y_1 + y_2 + \dots + y_n)\right) \\ &= \frac{1}{n}(E(y_1) + E(y_2) + \dots + E(y_n)) \end{aligned}$$

dado que $E(y_i) = E(c) + \underbrace{E(u_i)}_0 = c$,

$$E(\hat{\mu}) = c = \mu$$

- **Eficiencia:** $Var(\hat{\mu}) < Var(\hat{\mu}_1)$

Comparemos el estimador promedio muestral con un estimador que es simplemente cualquier valor de y_i :

$\hat{\mu} = \bar{Y}$	$E(\bar{Y}) = c$	$Var(\bar{Y}) = \frac{\sigma_u^2}{n}$
$\hat{\mu}_1 = y_i$	$E(y_i) = c$	$Var(y_i) = \sigma_u^2$

Entonces para $n > 1$ siempre se cumple que $\hat{\mu}$ es más eficiente (menor varianza) que $\hat{\mu}_1$.

- **Error Cuadrático Medio:** Como $\hat{\mu}$ es un estimador insesgado de μ al igual que $\hat{\mu}_1$, el error cuadrático medio de ambos estimadores es igual a la varianza del estimador, de esta forma $\hat{\mu}$ tiene menor error cuadrático medio que $\hat{\mu}_1$.

- **Consistencia:** $\hat{\mu}$ es un estimador consistente dado que:

$$plim(\hat{\mu}) = plim(\bar{Y}) = c$$

Ya que si $\lim_{n \rightarrow \infty} Var(\bar{Y}) = 0 \Rightarrow plim(\bar{Y}) = c$.

2.3. Modelo de regresión con dos variables

2.3.1. Método de Mínimos Cuadrados Ordinarios

De la sección anterior teníamos que el error estimado era:

$$\begin{aligned} \hat{u}_i &= Y_i - \hat{Y}_i \\ (2.13) \quad &= Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i \end{aligned}$$

es decir, los residuos son simplemente la diferencia entre los valores verdaderos y estimados de Y .

Si queremos que la función de regresión muestral sea lo más cercana posible a la poblacional, debemos tratar de escoger los coeficientes de regresión (los β 's) de forma tal que los errores sean lo más pequeños posible. De acuerdo a esto un criterio para escoger la función de regresión muestral podría ser minimizar la suma de los errores: $\sum \hat{u}_i = \sum (Y_i - \hat{Y}_i)$, sin embargo este criterio no es muy bueno. Observemos la Figura 2.13, existe una gran diferencia en la magnitud de los errores, sin embargo en la suma de los errores todos reciben el mismo peso. Debido a esto es posible que la suma de los errores sea muy pequeña cercana a cero, incluso cuando la dispersión de los errores en torno a la función de regresión muestral es alta.

Este problema puede ser solucionado al considerar la suma de los errores al cuadrado como criterio a minimizar, en este caso los errores más lejos reciben un mayor peso:

$$\begin{aligned} \sum \hat{u}_i^2 &= \sum (Y_i - \hat{Y}_i)^2 \\ (2.14) \quad &= \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2 \end{aligned}$$

Figura 2.13
Función de regresión muestral




Figura 6: Mínimos Cuadrados Ordinarios

El **Método de Mínimos Cuadrados Ordinarios (MCO)** escoge $\hat{\beta}_0$ y $\hat{\beta}_1$ de forma tal que para una muestra dada, $\sum \hat{u}_i^2$ sea lo más pequeño posible.

Entonces el problema que este método propone resolver es el siguiente:

$$(2.15) \quad \min_{\hat{\beta}_0, \hat{\beta}_1} \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

las condiciones de primer orden de este problema son:

$$(2.16) \quad \frac{\partial \sum \hat{u}_i^2}{\partial \hat{\beta}_0} = -2 \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = -2 \sum \hat{u}_i = 0$$

$$(2.17) \quad \frac{\partial \sum \hat{u}_i^2}{\partial \hat{\beta}_1} = -2 \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) X_i = -2 \sum \hat{u}_i X_i = 0$$

Simplificando (2.16) y (2.17) obtenemos las **ecuaciones normales**:

$$(2.18) \quad \sum Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum X_i$$

$$(2.19) \quad \sum Y_i X_i = \hat{\beta}_0 \sum X_i + \hat{\beta}_1 \sum X_i^2$$

Debemos resolver un sistema con dos ecuaciones y dos incógnitas. De la ecuación (2.18) podemos despejar $\hat{\beta}_0$:

$$(2.20) \quad \hat{\beta}_0 = \frac{\sum Y_i - \hat{\beta}_1 \sum X_i}{n}$$

reemplazando (2.20) en (2.19):

$$(2.21) \quad \sum Y_i X_i = \left(\frac{\sum Y_i - \hat{\beta}_1 \sum X_i}{n} \right) \cdot \sum X_i + \hat{\beta}_1 \sum X_i^2$$

De esta forma, el estimador de β_1 es:

$$(2.22) \quad \hat{\beta}_1 = \frac{n \cdot \sum Y_i X_i - \sum X_i \sum Y_i}{n \cdot \sum X_i^2 - (\sum X_i)^2}$$

El que puede ser escrito de la siguiente forma (hacerlo):

$$(2.23) \quad \hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2}$$

donde $x_i = X_i - \bar{X}$ e $y_i = Y_i - \bar{Y}$, con $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ e $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$

Reemplazando (2.22) en (2.20):

$$(2.24) \quad \hat{\beta}_0 = \frac{\sum X_i^2 \sum Y_i - \sum X_i \sum X_i Y_i}{n \cdot \sum X_i^2 - (\sum X_i)^2}$$

$$(2.25) \quad = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Los resultados (2.23) y (2.25) podrían haber sido obtenidos de igual forma, expresando inicialmente el modelo de regresión en desviaciones con respecto a la media.

El modelo de regresión original es:

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{u}_i$$

si le restamos el promedio de esta:

$$(2.26) \quad \bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X} + \bar{\hat{u}}_i$$

y recordando que el valor esperado del término de error es 0, tenemos el siguiente modelo de regresión lineal expresado en desviaciones con respecto a la media:

$$(Y_i - \bar{Y}) = \hat{\beta}_1 (X_i - \bar{X}) + \hat{u}_i$$

$$y_i = \hat{\beta}_1 x_i + \hat{u}_i$$

Así el problema de Mínimos Cuadrados Ordinarios es:

$$\min_{\hat{\beta}_1} \sum (y_i - \hat{\beta}_1 x_i)^2$$

La condición de primer orden de este problema es:

$$\frac{\partial \sum \hat{u}_i^2}{\partial \hat{\beta}_1} = -2 \sum (y_i - \hat{\beta}_1 x_i) x_i = 0$$

Así obtenemos el mismo estimador de β_1 , encontrado en (2.23), y β_0 se obtiene simplemente despejando la ecuación (2.26):

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

que corresponde a lo mismo en la ecuación (2.25).


Una vez estimados los coeficientes de regresión mediante MCO y utilizando la información muestral, la recta de regresión muestral ($\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$) puede ser obtenida fácilmente.

2.3.2. Ejemplo Estimación MCO

La Encuesta Longitudinal de la Primera Infancia (ELPI) recoge información sobre habilidades cognitivas y no cognitivas de niños menores de 5 años de edad, en particular en este ejemplo estamos interesados en estudiar como el peso al nacer del menor afecta su desarrollo cognitivo medido a través del Test TEPSI, este es un test de tamizaje, es decir, es una evaluación gruesa que permite conocer el nivel de rendimiento en cuanto al desarrollo psicomotor de niños entre 2 y 5 años de edad. El puntaje del test está estandarizado de acuerdo a la edad del niño en una media de 50 puntos y con una desviación estándar de 10 puntos. La Figura 2.14 muestra el gráfico que relaciona ambas variables así como la recta de regresión lineal.

Para obtener los coeficientes estimados del intercepto y la pendiente de la recta de regresión, podemos utilizar el comando `regress` de STATA que realiza la estimación el modelo de regresión lineal por MCO. El Cuadro 2.1 muestra los resultados, obteniendo que cada 100 gramos adicionales de peso de menor al nacer, el puntaje Tepsí estandarizado aumenta en 0.067 puntos.

Figura 2.14



Cuadro 2.1

Estimación MCO Puntaje Tepsi y Peso al Nacer

. reg tepsi_t_s peso100						
Source	SS	df	MS			
Model	1121.49072	1	1121.49072	Number of obs = 8915		
Residual	1363158.35	8913	152.940464	F(1, 8913) = 7.33		
				Prob > F = 0.0068		
				R-squared = 0.0008		
				Adj R-squared = 0.0007		
				Root MSE = 12.367		
Total	1364279.85	8914	153.049119			
tepsi_t_s	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
peso100	.0675061	.0249291	2.71	0.007	.0186394	.1163729
_cons	51.64347	.8447839	61.13	0.000	49.9875	53.29944

2.3.3. Supuestos detrás del método MCO

En el análisis de regresión nuestro objetivo no es sólo obtener los valores de $\hat{\beta}_1$ y $\hat{\beta}_2$ sino también hacer inferencia sobre los verdaderos β_1 y β_2 . Nos interesa saber

que tan cerca están $\hat{\beta}_1$ y $\hat{\beta}_2$ de sus contraparte poblacional o que tan cerca esta $\hat{Y}_i$ de la verdadera $E(Y|X_i)$. La Función de regresión poblacional: $Y_i = \beta_1 + \beta_2 X_i + u_i$, nos muestra que Y_i depende de X_i y u_i . Así, los supuestos hechos para estas dos variables son fundamentales para lograr una interpretación válida de los valores estimados de la regresión. Mientras no se especifique la forma como se generan X_i y u_i , no hay forma de hacer inferencia estadística sobre Y_i ni sobre β_1 y β_2 .

Supuesto 1: Modelo de regresión lineal, el modelo de regresión es lineal en parámetros:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

Supuesto 2: Los valores de X son fijos, X se supone no estocástica. Esto implica que el análisis de regresión es un **análisis de regresión condicional**, condicionado a los valores dados del regresor X.

Supuesto 3: El valor medio del error u_i es igual a cero. Dado el valor de X, el valor esperado del término de error u_i es cero:

$$E(u_i|X_i) = 0$$

Lo que nos dice este supuesto es que los factores que no están considerados en el modelo y que están representados a través de u_i , no afectan sistemáticamente el valor de la media de Y. Es decir, los valores positivos de u_i se cancelan con los valores negativos de u_i . De esta forma, el efecto promedio de u_i sobre Y es cero. Ver Figura 2.15.

Figura 2.15




Figura 7: Distribución condicional del término de error u_i

Supuesto 4: Homocedasticidad o igual varianza de u_i . Dado el valor de X , la varianza de u_i es la misma para todas las observaciones:

$$\begin{aligned} \text{var}(u_i|X_i) &= E[u_i - E(u_i)|X_i]^2 \\ &= E(u_i^2|X_i) \text{ por supuesto 3} \\ &= \sigma^2 \end{aligned}$$

En la Figura 2.16 podemos apreciar el significado del supuesto de homocedasticidad, la variación alrededor de la recta de regresión es la misma para todos los valores de X . Esto implica que la función de densidad del término de error u_i es la misma.

Figura 2.16




Figura 8: Homocedasticidad

Por el contrario, en la Figura 9 observamos el caso cuando la varianza del término de error varía para cada X_i , en este caso particular la varianza del error aumenta en la medida que X_i crece.

Figura 2.17




Figura 9: Heterocedasticidad

Esto se conoce como **Heterocedasticidad** o varianza desigual, lo que se expresa de la siguiente manera:

$$(2.27) \quad \text{var}(u_i|X_i) = \sigma_i^2$$

Supuesto 5: No existe autocorrelación entre los errores. Dado dos valores de X , X_i y X_j , con $i \neq j$, la correlación entre u_i y u_j es cero:

$$\begin{aligned} cov(u_i, u_j | X_i, X_j) &= E\{[u_i - E(u_i)] | X_i\} \{[u_j - E(u_j)] | X_j\} \\ &= E(u_i | X_i)(u_j | X_j) \\ &= 0 \end{aligned}$$

Si en la Función de regresión poblacional $Y_i = \beta_1 + \beta_2 X_i + u_i$, u_i esta correlacionado con u_j , entonces Y_i no depende solamente de X_i sino también de u_j . Al imponer le supuesto 5 estamos diciendo que solo se considerará el efecto sistemático de X_i sobre Y_i sin preocuparse de otros factores que pueden estar afectando a Y , como la correlación entre los u 's.

Supuesto 6: La covarianza entre u_i y X_i es cero $E(u_i X_i) = 0$:

$$\begin{aligned} cov(u_i, X_i) &= E[u_i - E(u_i)][X_i - E(X_i)] \\ &= E[u_i(X_i - E(X_i))] \text{ por supuesto } E(u_i) = 0 \\ &= E(u_i X_i) - E(u_i)E(X_i) \text{ por supuesto } E(X_i) \text{ no estocastica} \\ &= E(u_i X_i) \text{ por supuesto } E(u_i) = 0 \\ &= 0 \end{aligned}$$

Como mencionamos en la sección 2.2.2 se supone que X y u tienen una influencia separada sobre Y (determinística y estocástica, respectivamente), ahora si X y u están correlacionadas, no es posible determinar los efectos individuales sobre Y .

Este supuesto se cumple automáticamente si X es no estocástica y el supuesto 3 se cumple.

Supuesto 7: El número de observaciones n debe ser mayor que el número de parámetros por estimar. El número de observaciones tiene que ser mayor que el número de variables explicativas, de otra forma no se puede resolver el sistema de ecuaciones. Supongamos que tenemos una sola observación para nuestra variable dependiente y nuestra variable explicativa (Y_1 y X_1), el modelo de regresión es tal que tiene intercepto, es decir:

$$Y_1 = \beta_1 + \beta_2 X_1 + u_1$$

el estimador MCO de β_2 es :

$$\beta_2 = \frac{\sum x_i y_i}{\sum x_i^2}$$

donde $x_i = X_i - \bar{X}$ e $y_i = Y_i - \bar{Y}$, sin embargo con una observación $X_1 = \bar{X}$ e $Y_1 = \bar{Y}$, así β_2 no esta determinado y así tampoco podemos determinar β_1 .

Supuesto 8: Variabilidad en los valores de X. No todos los valores de X en una muestra deben ser iguales, $\text{var}(X)$ debe ser un número finito positivo. Si las X son las mismas $\Rightarrow X_i = \bar{X}$, de esta forma ni β_2 ni β_1 pueden ser estimados.

Supuesto 9: El modelo de regresión esta correctamente especificado. Esto es muy importante, ya que por ejemplo la omisión de variables importantes en el modelo, o la elección de la forma funcional inadecuada, o la consideración de supuestos estocásticos equivocados sobre las variables del modelo, harán cuestionable la validez de la interpretación de la regresión estimada. (Aspectos que veremos más adelante).

2.3.4. Errores estándar de los Estimadores Mínimos Cuadrados Ordinarios

Como vimos en la sección 2.3.1, los valores estimados para β_1 y β_2 dependen de los datos muestrales, sin embargo, los datos cambian de una muestra a otra y así los valores estimados también, por eso es necesario tener una medida que nos permita decir que tan cercano son los valores estimados a los valores poblacionales de los parámetros.

La medida que utilizaremos para medir la precisión del estimador es el **error estándar**, que es la desviación estándar de la distribución muestral del estimador, la que a su vez es la distribución del conjunto de valores del estimador obtenidos de todas las muestras posibles de igual tamaño de una población dada.

Recordemos el estimador MCO de β_2 :

$$\hat{\beta}_2 = \frac{\sum x_i y_i}{\sum x_i^2}$$

donde $y_i = \beta_2 x_i + u_i$ (modelo poblacional en desviaciones con respecto a la media). De esta forma reemplazando y_i en el estimador de β_2 :

$$\begin{aligned} \hat{\beta}_2 &= \frac{\sum x_i (\beta_2 x_i + u_i)}{\sum x_i^2} \\ &= \beta_2 \frac{\sum x_i^2}{\sum x_i^2} + \frac{\sum u_i x_i}{\sum x_i^2} \\ &= \beta_2 + \frac{\sum u_i x_i}{\sum x_i^2} \end{aligned}$$

Aplicando valor esperado a la expresión anterior:

$$\begin{aligned}
 E(\hat{\beta}_2) &= \beta_2 + E\left(\frac{\sum u_i x_i}{\sum x_i^2}\right) \\
 &= \beta_2 + \left(\frac{\sum E(u_i) x_i}{\sum x_i^2}\right) \quad \text{por supuesto 2} \\
 (2.28) \quad &= \beta_2 \quad \text{por supuesto 3}
 \end{aligned}$$

La ecuación (2.28) nos dice que en valor esperado el estimador MCO de $\hat{\beta}_2$ es igual a su verdadero valor. Esta propiedad del estimador MCO se conoce como **insesgamiento**.

Ahora procedamos a calcular la varianza de el estimador MCO de β_2 :

$$\begin{aligned}
 var(\hat{\beta}_2) &= E[\hat{\beta}_2 - E(\hat{\beta}_2)]^2 \\
 &= E(\hat{\beta}_2 - \beta_2)^2 \\
 &= E\left(\frac{[\sum x_i u_i]^2}{[\sum x_i^2]^2}\right)
 \end{aligned}$$

Por supuesto 4 $E(u_i^2) = \sigma^2$ y por supuesto 6 $E(u_i u_j) = 0$, esto implica que:

$$(2.29) \quad var(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_i^2}$$

2.3.5. Estimador Mínimo Cuadrado Ordinario de σ^2

Ahora debemos estimar el parámetro poblacional σ^2 , como este corresponde al valor esperado de u_i^2 y $\hat{u}_i$ es una estimación de u_i , por analogía:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n}$$

pareciera ser un estimador razonable. Pero los errores de MCO, están estimados imperfectamente si los comparamos con los errores poblacionales, ya que dependen de una estimación de β_1 y β_2 . Veamos esto con más detalle:

Partiendo del Regresión poblacional expresado en desviaciones con respecto a la media:

$$(2.30) \quad y_i = \beta_2 x_i + (u_i - \bar{u})$$

y recordando también que:

$$(2.31) \quad \hat{u}_i = y_i - \hat{\beta}_2 x_i$$

Al sustituir (2.30) en (2.31), se obtiene:

$$\hat{u}_i = \beta_2 x_i + (u_i - \bar{u}) - \hat{\beta}_2 x_i$$

Elevando al cuadrado la expresión anterior, aplicando sumatoria y tomando valor esperado:

$$\begin{aligned} E\left(\sum \hat{u}_i^2\right) &= E(\hat{\beta}_2 - \beta_2)^2 \sum x_i^2 + \underbrace{E\left[\sum (u_i - \bar{u})^2\right]}_{(i)} - 2 \underbrace{E\left[(\hat{\beta}_2 - \beta_2) \sum x_i(u_i - \bar{u})\right]}_{(ii)} \\ &= \text{var}(\hat{\beta}_2) \sum x_i^2 + (n-1)\text{var}(u_i) - 2E\left[\frac{\sum x_i u_i}{\sum x_i^2} \sum x_i(u_i - \bar{u})\right] \\ &= \sigma^2 + (n-1)\sigma^2 - 2\sigma^2 \\ &= (n-2)\sigma^2 \end{aligned}$$

$$\begin{aligned} (i) \quad E\left[\sum (u_i - \bar{u})^2\right] &= E\left[\sum (u_i^2 - 2u_i\bar{u} + \bar{u}^2)\right] \\ &= E\left[\sum u_i^2 - 2\bar{u} \sum u_i + n\bar{u}^2\right] \\ &= E\left[\sum u_i^2 - 2\bar{u} \frac{n}{n} \sum u_i + n\bar{u}^2\right] \\ &= E\left[\sum u_i^2 - 2n\bar{u}^2 + n\bar{u}^2\right] \\ &= E\left[\sum u_i^2 - n\bar{u}^2\right] \\ &= E\left[\sum u_i^2 - n\left(\frac{\sum u_i}{n}\right)^2\right] \\ &= n\sigma^2 - \frac{n}{n}\sigma^2 \\ &= (n-1)\sigma^2 \end{aligned}$$

$$\begin{aligned} (ii) \quad E\left[(\hat{\beta}_2 - \beta_2) \sum x_i(u_i - \bar{u})\right] &= E\left[(\hat{\beta}_2 - \beta_2) \sum x_i(u_i - \bar{u})\right] \\ &= E\left[\frac{\sum x_i u_i}{\sum x_i^2} \sum x_i(u_i - \bar{u})\right] \\ &= E\left[\frac{(\sum x_i u_i)^2}{\sum x_i^2} - \bar{u} \frac{\sum x_i u_i \sum x_i}{\sum x_i^2}\right] \\ &= \sigma^2 \end{aligned}$$

Por lo tanto se define el estimador de la varianza $\tilde{\sigma}^2$ como:

$$(2.32) \quad \tilde{\sigma}^2 = \frac{\sum \hat{u}_i^2}{n-2}$$

De forma tal que, $\tilde{\sigma}^2$ es un estimador insesgado de σ^2 :

$$\tilde{\sigma}^2 = \frac{1}{n-2} E \left(\sum \hat{u}_i^2 \right) = \sigma^2$$

2.4. Modelo de Regresión con k variables

Ahora abandonemos la simplificación de solo usar dos variables, de ahora en adelante generalizaremos el modelo de regresión lineal para que pueda tener hasta k variables explicativas.

Aclaración: haremos un cambio de notación, cada observación i de la variable dependiente será denotada por y_i y cada observación i de una variable explicativa, por ejemplo X_1 , será denotada por x_{1i} . Ahora las variables en minúscula no significa que estén en desvíos.

El Modelo de Regresión Poblacional en este caso es:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + \dots + \beta_k x_{ki} + u_i \quad i = 1, \dots, n$$

2.4.1. Representación Matricial del Modelo de Regresión Lineal

El modelo con k variables explicativas puede ser expresado en notación matricial. En efecto, cada variable explicativa x_j , con $j=1, \dots, k$, es un vector columna de dimensión n, al igual que la variable dependiente y el término de error. De este modo, el modelo puede ser reescrito de la siguiente forma:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \beta_1 + \begin{bmatrix} x_{21} \\ x_{22} \\ \vdots \\ x_{2n} \end{bmatrix} \beta_2 + \begin{bmatrix} x_{31} \\ x_{32} \\ \vdots \\ x_{3n} \end{bmatrix} \beta_3 + \dots + \begin{bmatrix} x_{k1} \\ x_{k2} \\ \vdots \\ x_{kn} \end{bmatrix} \beta_k + \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}$$

Donde las variables explicativas se pueden agrupar en una sola matriz de dimensión $n \times k$, que denotaremos simplemente como X, de esta manera el modelo se

expresa de la siguiente forma:

$$(2.33) \quad \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{21} & x_{31} & \cdots & x_{k1} \\ 1 & x_{22} & x_{32} & \cdots & x_{k2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{2n} & x_{3n} & \cdots & x_{kn} \end{bmatrix} \cdot \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix} \Rightarrow Y = X\beta + u$$

donde Y es un vector de dimensión $n \times 1$, X es la matriz de variables explicativas de dimensión $n \times k$ y u es un vector correspondiente al término de error con dimensión $n \times 1$.

Ahora debemos expresar la distribución del término de error en términos matriciales:

$$E(u) = \begin{bmatrix} E(u_1) \\ E(u_2) \\ \vdots \\ E(u_n) \end{bmatrix} = \mathbf{0}_{n \times 1}$$

$$E(uu') = \begin{bmatrix} E(u_1^2) & E(u_1u_2) & \cdots & E(u_1u_n) \\ E(u_2u_1) & E(u_2^2) & \cdots & E(u_2u_n) \\ \vdots & \vdots & \ddots & \vdots \\ E(u_nu_1) & E(u_nu_2) & \cdots & E(u_n^2) \end{bmatrix} = \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{bmatrix} = \sigma^2 I_{n \times n}$$

De los supuestos 3, 4 y 5, tenemos entonces que el término de error tiene la siguiente distribución:

$$(2.34) \quad u \sim \left(\mathbf{0}_{n \times 1}, \sigma^2 I_{n \times n} \right)$$

2.4.2. Estimador Mínimo Cuadrados Ordinarios

El método de MCO, plantea que los parámetros del modelo pueden ser estimados minimizando la suma de los errores al cuadrado ($S_E(\hat{\beta})$), la que en términos matriciales equivale a:

$$S_E(\hat{\beta}) = \sum_{i=1}^n \hat{u}_i^2 = \hat{u}'\hat{u}$$

donde $\hat{u} = Y - X\hat{\beta}$. Entonces el problema de minimizar la suma de los errores al cuadrado se expresa de la siguiente forma:

$$\begin{aligned} \min_{\hat{\beta}} S_E(\hat{\beta}) &= \min_{\hat{\beta}} \left[(Y - X\hat{\beta})'(Y - X\hat{\beta}) \right] \\ &= \min_{\hat{\beta}} \left[Y'Y - 2\hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta} \right] \\ \frac{\partial S_E(\hat{\beta})}{\partial \hat{\beta}'} &= -2X'Y + 2X'X\hat{\beta} = 0 \\ (2.35) \quad &\Rightarrow \hat{\beta} = (X'X)^{-1}X'Y \end{aligned}$$

De (2.35) tenemos:

$$(2.36) \quad X'(Y - X\hat{\beta}) = 0 \Rightarrow X'\hat{u} = 0$$

(2.36) es la condición de ortogonalidad.

De esta forma, el vector de parámetros estimados $\hat{\beta}$ se obtiene de resolver el siguiente sistema de ecuaciones normales:

$$\begin{aligned} X'X\hat{\beta} &= X'Y \Leftrightarrow \\ \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ x_{2,1} & x_{2,2} & x_{2,3} & \cdots & x_{2,n} \\ x_{3,1} & x_{3,2} & x_{3,3} & \cdots & x_{3,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{k,1} & x_{k,2} & x_{k,3} & \cdots & x_{k,n} \end{bmatrix} \begin{bmatrix} 1 & x_{2,1} & x_{3,1} & \cdots & x_{k,1} \\ 1 & x_{2,2} & x_{3,2} & \cdots & x_{k,2} \\ 1 & x_{2,3} & x_{3,3} & \cdots & x_{k,3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{2,n} & x_{3,n} & \cdots & x_{k,n} \end{bmatrix} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} \\ &= \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ x_{2,1} & x_{2,2} & x_{2,3} & \cdots & x_{2,n} \\ x_{3,1} & x_{3,2} & x_{3,3} & \cdots & x_{3,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{k,1} & x_{k,2} & x_{k,3} & \cdots & x_{k,n} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix} \\ \Leftrightarrow \begin{bmatrix} n & \sum_{i=1}^n x_{2,i} & \sum_{i=1}^n x_{3,i} & \cdots & \sum_{i=1}^n x_{k,i} \\ \sum_{i=1}^n x_{2,i} & \sum_{i=1}^n x_{2,i}^2 & \sum_{i=1}^n x_{2,i}x_{3,i} & \cdots & \sum_{i=1}^n x_{2,i}x_{k,i} \\ \sum_{i=1}^n x_{3,i} & \sum_{i=1}^n x_{3,i}x_{2,i} & \sum_{i=1}^n x_{3,i}^2 & \cdots & \sum_{i=1}^n x_{3,i}x_{k,i} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{k,i} & \sum_{i=1}^n x_{k,i}x_{2,i} & \sum_{i=1}^n x_{k,i}x_{3,i} & \cdots & \sum_{i=1}^n x_{k,i}^2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i x_{2,i} \\ \sum_{i=1}^n y_i x_{3,i} \\ \vdots \\ \sum_{i=1}^n y_i x_{k,i} \end{bmatrix} \end{aligned}$$

Es importante recordar que el estimador MCO está definido solo cuando la matriz $(X'X)$ es invertible, lo que ocurre siempre y cuando:

1. Las k columnas de la matriz X sean linealmente independientes.
2. Se disponga al menos de tantas observaciones como variables explicativas, es decir: $n \geq k$. (Supuesto 7)

Pongamos atención en el segundo supuesto, cuando $n=k$ la matriz X tiene dimensión $k \times k$, por lo tanto salvo que no se cumpla el supuesto 8, X es invertible, y de esta forma $(X'X)^{-1} = X^{-1}(X')^{-1}$ y por lo tanto:

$$(2.37) \quad \hat{\beta} = (X'X)^{-1}X'Y = X^{-1}(X')^{-1}X'Y = X^{-1}Y$$

el vector de residuos $\hat{u} = Y - X\hat{\beta} = Y - X(X^{-1}Y) = Y - Y = 0_n$, de esta forma el ajuste es perfecto, ya que todos los residuos son cero, la suma residual de igual forma toma el mínimo valor posible, cero.

Sin embargo, esta no es una característica deseable, el ajuste perfecto ocurre porque tenemos una muestra muy reducida. Esto trae como consecuencia poco robustez e imprecisión en las estimaciones. Si escogemos una nueva muestra, del mismo tamaño que la anterior, obtendremos otro estimador $\hat{\beta}$ con suma residual 0, que puede diferir en forma arbitraria del anterior.

Para lograr estimaciones precisas de los parámetros, es necesario tener un número de observaciones notablemente superior al de las variables explicativas. La diferencia $n-k$ se conoce como el número de *grados de libertad* de la estimación.

2.5. Propiedades del estimador MCO

Notemos que el vector $\hat{\beta}$ es un vector aleatorio, ya que depende del vector de errores:

$$(2.38) \quad \hat{\beta} = (X'X)^{-1}X'Y = (X'X)^{-1}X'(X\beta + u) = \beta + (X'X)^{-1}X'u$$

$$\begin{aligned} E(\hat{\beta}) &= E(\beta) + E[(X'X)^{-1}X'u] \\ &= \beta + (X'X)^{-1}X'E(u) \end{aligned}$$

La esperanza de β es el mismo parámetro, ya que este es un constante (valor poblacional), y por supuestos 2 y 3 el segundo término de la expresión anterior es cero,

$$(2.39) \quad \Rightarrow E(\hat{\beta}) = \beta$$

Es decir, el estimador MCO es **insesgado**, tal como lo habíamos mostrado en la ecuación (2.28).

De (2.38) podemos definir el *error de estimación o sesgo* como:

$$\hat{\beta} - \beta = (X'X)^{-1}X'u$$

Ahora calculemos la varianza de $\hat{\beta}$:

$$\begin{aligned} \text{var}(\hat{\beta}) &= E[(\hat{\beta} - E(\hat{\beta})) \cdot (\hat{\beta} - E(\hat{\beta}))'] \\ &= E[(\hat{\beta} - \beta) \cdot (\hat{\beta} - \beta)'] \\ &= E[(X'X)^{-1}X'uu'X(X'X)^{-1}] \\ &= (X'X)^{-1}X'E(uu')X(X'X)^{-1} \\ &= (X'X)^{-1}X'(\sigma^2 I_n)X(X'X)^{-1} \\ (2.40) \quad &= \sigma^2(X'X)^{-1} \end{aligned}$$

Para poder estimar la varianza de $\hat{\beta}$ necesitamos reemplazar σ^2 en (2.40) por su estimador insesgado:

$$\tilde{\sigma}^2 = \frac{u'u}{n - k}$$

2.5.1. Propiedad de mejor estimador lineal insesgado

Se dice que $\hat{\beta}$, es el mejor estimador lineal insesgado (MELI) de β si se cumple lo siguiente:

1. El **lineal**, es decir, es una función lineal de una variable aleatoria, como la variable y en el modelo de regresión.
2. Es **insesgado**, es decir, su valor esperado, $E(\hat{\beta})$, es igual a el verdadero valor, β .
3. Tiene varianza mínima dentro de la clase de todos los estimadores lineales insesgados; un estimador insesgado como varianza mínima es conocido como un **estimador eficiente**.

2.5.2. Teorema de Gauss-Markov

Proposición: El estimador MCO es el estimador lineal insesgado óptimo, en el sentido de que cualquier otro estimador lineal e insesgado tiene una matriz de covarianza *mayor* que la del estimador MCO. Es decir, el estimador MCO es MELI.

Demostración: Sea $\tilde{\beta} = \tilde{A}y$ un estimador lineal de β , donde $\tilde{A}$ es una matriz $k \times n$. Denotemos $A = \tilde{A} - (X'X)^{-1}X'$, de modo que:

$$\begin{aligned}\tilde{\beta} &= [A + (X'X)^{-1}X']Y \\ &= [A + (X'X)^{-1}X'](X\beta + u) \\ &= AX\beta + \beta + [A + (X'X)^{-1}X']u\end{aligned}$$

Aplicando esperanza a la expresión anterior:

$$\begin{aligned}E(\tilde{\beta}) &= AX\beta + \beta + [A + (X'X)^{-1}X']E(u) \\ &= AX\beta + \beta\end{aligned}$$

El estimador $\tilde{\beta}$ será insesgado solo si la matriz A es tal que $AX=0_{k \times k}$. De esta forma:

$$\tilde{\beta} = \beta + [A + (X'X)^{-1}X']u$$

y su matriz de covarianza será:

$$\begin{aligned}\text{cov}(\tilde{\beta}) &= E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)'] \\ &= E\{([A + (X'X)^{-1}X']u)([A + (X'X)^{-1}X']u)'\} \\ &= \sigma^2 AA' + \underbrace{\sigma^2 (X'X)^{-1}}_{\text{cov}(\hat{\beta})}\end{aligned}$$

Como la matriz AA' es semidefinida positiva, se concluye la diferencia entre la covarianza de $\tilde{\beta}$ y $\hat{\beta}$ es una matriz semidefinida positiva, con lo que la covarianza de $\tilde{\beta}$ es mayor o igual a la covarianza de $\hat{\beta}$

Capítulo 3

Modelo de Regresión Lineal: Inferencia y Bondad de Ajuste

3.1. Bondad de Ajuste y Análisis de Varianza

El objetivo de esta sección es introducir un criterio de ajuste de nuestra regresión, es decir, un criterio que nos indique cuan bien se ajusta nuestro modelo a la muestra.

En principio, podríamos pensar que la suma de los residuos cuadrados, es decir, nuestro criterio original de ajuste, es una buena opción: a menor sea éste, mejor es nuestro ajuste. Sin embargo, la suma de los residuos cuadrados puede ser arbitrariamente escalada al multiplicar la variable dependiente (Y) por el factor de escala deseado, lo cual invalida su uso como criterio de ajuste.

Por ello, se ha desarrollado un criterio que elimine el problema anterior. Dicho estadístico ya no se basará en la *magnitud* de un valor (como la suma de los cuadrados de los residuos), sino que intentará preguntarse si la *variación* de las variables independientes (X) explica la *variación* de la variable dependiente, como veremos más adelante. Para ello analizaremos con un poco más de profundidad el modelo de regresión lineal en desvíos con respecto a la media y presentaremos la llamada descomposición de varianza (o análisis de varianza), ambos, insumos fundamentales para obtener nuestro estadístico de bondad de ajuste.

3.1.1. Modelo de Regresión Lineal en Desvíos

Sea el modelo poblacional usual con k variables:

$$(3.1) \quad y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + \cdots + \beta_k x_{ki} + u_i$$

donde $i = 1 \dots n$ y cuya contraparte estimada es:

$$(3.2) \quad y_i = \hat{\beta}_1 + \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i} + \cdots + \hat{\beta}_k x_{ki} + \hat{u}_i$$

Luego, si sumamos para todas las observaciones y dividimos a ambos lados por el tamaño muestral n , tenemos:

$$(3.3) \quad \bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{x}_2 + \hat{\beta}_3 \bar{x}_3 + \cdots + \hat{\beta}_k \bar{x}_k$$

por lo cual:

$$(3.4) \quad \hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{x}_2 + \hat{\beta}_3 \bar{x}_3 + \cdots + \hat{\beta}_k \bar{x}_k$$

La ecuación (3.4) muestra que la constante de una regresión queda determinado por el resto de los $k-1$ coeficientes involucrados. Finalmente, note que restando las ecuaciones (3.2) y (3.3) obtenemos:

$$(3.5) \quad y_i - \bar{Y} = \hat{\beta}_2(x_{2i} - \bar{x}_2) + \hat{\beta}_3(x_{3i} - \bar{x}_3) + \cdots + \hat{\beta}_k(x_{ki} - \bar{x}_k) + \hat{u}_i$$

la cual es una expresión similar a (3.2), excepto por dos importantes diferencias. Primero, el modelo no posee constante y segundo, las variables se encuentran expresadas en desvíos con respecto a la media. A pesar de ello, note que los coeficientes y los residuos son los mismos en ambos modelos.

De lo anterior surge un importante corolario respecto del término constante de nuestro modelo. En general, el interés del investigador se centra en el impacto de los regresores sobre la variable dependiente, por lo cual, el término constante no es más que una *corrección* que garantiza que los promedios muestrales de ambos miembros del modelo econométrico coincidan.

Para transformar en desvíos con respecto a la media un modelo en términos matriciales, introduciremos una matriz fundamental para el análisis de esta sección. Denotaremos por M^0 una matriz de $n \times n$, definida como:

$$M^0 = I_{n \times n} - \frac{ii'}{n} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} - \frac{1}{n} \begin{bmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{bmatrix} = \begin{bmatrix} 1 - \frac{1}{n} & -\frac{1}{n} & \cdots & -\frac{1}{n} \\ -\frac{1}{n} & 1 - \frac{1}{n} & \cdots & -\frac{1}{n} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{1}{n} & -\frac{1}{n} & \cdots & 1 - \frac{1}{n} \end{bmatrix}$$

donde I es la identidad ($n \times n$) e i corresponde al vector unitario de dimensión n . Dicha matriz es singular, simétrica ($M^0 = M^{0'}$) e idempotente ($M^0 M^0 = M^0$). En general, M^0 es conocida como *matriz de desvíos*, ya que resta a cada columna de la matriz involucrada, su media aritmética. Por ejemplo, es fácil comprobar que:

$$M^0 Y = Y - \frac{1}{n} i i' Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} - \frac{1}{n} \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i \\ \vdots \\ \sum_{i=1}^n y_i \end{bmatrix} = \begin{bmatrix} y_1 - \bar{Y} \\ y_2 - \bar{Y} \\ \vdots \\ y_n - \bar{Y} \end{bmatrix}$$

Por lo tanto, nuestro modelo expresado en matrices, puede ser expresado en términos de desvío con respecto a la media como:

$$(3.6) \quad M^0 Y = M^0 X \beta + M^0 u$$

3.1.2. Análisis de Varianza

Suponga entonces el siguiente modelo poblacional:

$$Y = X\beta + u$$

donde Y corresponde a una vector $n \times 1$, X corresponde a nuestra matriz de regresores que incluye un término constante, tal que X es de $n \times k$ y u corresponde a nuestro vector de errores de $n \times 1$.

Buscamos entonces definir la variación de la variable dependiente (Suma de los cuadrados totales = TSS) como¹:

$$(3.7) \quad TSS = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Para encontrar entonces una expresión para (2.48), de la ecuación (2.47) tenemos que nuestro modelo estimado en desvíos con respecto a la media es:

$$M^0 Y = M^0 X \hat{\beta} + M^0 \hat{u}$$

con lo cual, al particionar nuestra matriz X en $X = [i \quad X_2]$, nuestro vector de parámetros en $\beta' = [\beta_1 \quad \beta_2]$ y considerando que $M^0 i = 0$ y que $M^0 \hat{u} = \hat{u}$, tenemos que:

$$(3.8) \quad \begin{aligned} M^0 Y &= M^0 i \hat{\beta}_1 + M^0 X_2 \hat{\beta}_2 + M^0 \hat{u} \\ &= M^0 X_2 \hat{\beta}_2 + \hat{u} \end{aligned}$$

¹Note que para dicha definición utilizamos los cuadrados de la desviaciones, ya que la suma de las desviaciones es siempre cero.

Luego, para formar la TSS (suma de los cuadrados totales o la suma de los cuadrados de las desviaciones de Y con respecto a su media), de la ecuación (2.48), multiplicamos por Y' la ecuación (2.49):

$$\begin{aligned}
 Y'M^0Y &= Y'(M^0X_2\hat{\beta}_2 + \hat{u}) \\
 &= (X\hat{\beta} + \hat{u})'(M^0X_2\hat{\beta}_2 + \hat{u}) \\
 &= \hat{\beta}'X'M^0X_2\hat{\beta}_2 + \hat{\beta}'X'\hat{u} + \hat{u}'M^0X_2\hat{\beta}_2 + \hat{u}'\hat{u} \\
 (3.9) \quad Y'M^0Y &= \hat{\beta}_2'X_2'M^0X_2\hat{\beta}_2 + \hat{u}'\hat{u} \\
 (3.10) \quad TSS &= ESS + RSS
 \end{aligned}$$

donde el segundo y el tercer término desaparecen gracias a que los residuos estimados son, por construcción, ortogonales a las variables explicativas². La igualdad anterior es conocida como la **descomposición de varianza**. El término de la izquierda corresponde a TSS o la suma de los cuadrados de las desviaciones de la variable dependiente. En otras palabras, la variabilidad de Y. En la derecha se encuentra la variabilidad de las variables independientes o regresores y la variabilidad de los errores. ¿Cuál es entonces el objetivo?: descomponer la varianza de la variable dependiente aquella parte que es explicada por la regresión (ESS) de aquella parte explicada por los residuos (RSS). ¿Por qué?: porque intuitivamente, la regresión se ajusta mejor si las desviaciones de Y se explican en su mayor parte por desviaciones de X y no por desviaciones de los residuos.

3.1.3. Bondad de Ajuste: R^2 y $\tilde{R}^2$

Definimos entonces la bondad de ajuste del modelo a través del siguiente estadígrafo llamado también coeficiente de determinación:

$$(3.11) \quad R^2 = \frac{ESS}{TSS}$$

es decir, como la proporción de la varianza de Y que es explicada por la varianza de la regresión. Alternativamente:

$$(3.12) \quad R^2 = 1 - \frac{RSS}{TSS}$$

Note que:

1. El coeficiente de determinación es siempre menor a 1. Ello porque $RSS \leq TSS$ y por lo tanto $\frac{RSS}{TSS} \leq 1$.

²Ya que $X'\hat{u} = X'(Y - X\hat{\beta}) = X'Y - X'X\hat{\beta} = 0$.

2. El análisis de varianza anterior fue derivado bajo el supuesto que el modelo incluía una constante (por ello utilizábamos la matriz M^0). En dicho caso, necesariamente $R^2 \geq 0$. En caso de que el modelo no incluya una constante, se debe utilizar la fórmula (2.5.2) utilizando $TSS=Y'Y$ (sin desvíos).
3. Al agregar regresores al modelo, el R^2 nunca decrecerá (se mantendrá constante o aumentará)
4. No es claro cuan bueno sea como predictor de ajuste.

Para ver este último punto, suponga que usted posee el siguiente modelo poblacional:

$$Y = \beta_1 + \beta_2 X + u$$

donde X es un vector ($n \times 1$). Suponga ahora que restamos X a ambos lados de nuestro modelo. Obtenemos entonces:

$$Y - X = \beta_1 + \gamma X + u$$

Si $\beta_2 \approx 1$, entonces es fácil verificar que el R^2 del primer modelo será cercano a 1, mientras que el del segundo será cercano a cero, a pesar de que los modelos son matemáticamente equivalentes. A pesar de lo anterior, en trabajos aplicados, el R^2 es ampliamente utilizado, por lo cual se recomienda su publicación.

Retrocedamos ahora al punto tres. El nos dice que el coeficiente de determinación probablemente crecerá al incluir regresores. Ello plantea incentivos a incluir regresores no relevantes para nuestro modelo, con el fin de obtener un mejor ajuste. ¿Porqué sucede esto?, ya que al incluir regresores, la RSS necesariamente decrece (o en el mejor de los casos se mantiene), mientras que la TSS permanece constante.

Por esta razón se creó el coeficiente de determinación ajustado, el cual corrige el R^2 original por los grados de libertad del numerador y el denominador. Entonces, definimos el R^2 ajustado ($\tilde{R}^2$) como:

$$(3.13) \quad \tilde{R}^2 = 1 - \frac{\hat{u}'\hat{u}/(n-k)}{Y'MY/(n-1)}$$

o equivalentemente:

$$(3.14) \quad \tilde{R}^2 = 1 - (1 - R^2) \frac{(n-1)}{(n-k)}$$

3.2. Inferencia

Una vez que hemos estimado nuestra regresión muestral, es necesario preguntarse cuan buena aproximación es dicha regresión de la poblacional. Para que la aproximación sea cercana, es condición necesaria que los parámetros incluidos en la regresión muestral sea estadísticamente distintos de cero (en caso contrario, no pertenecen a la regresión poblacional). Así, uno de nuestros objetivos puede ser el testear la significancia individual de los parámetros.

Pero lo anterior es sólo una de las preguntas que como investigadores podemos estar interesados en responder. Por ejemplo, en la estimación de la función de producción de una firma, que asumimos Cobb Douglas ($Y = AK^\alpha L^\beta e^u$ o en logaritmo $\ln Y = \ln A + \alpha \ln K + \beta \ln L + u$), podemos estar interesados en descubrir si la firma presenta rendimientos constantes, crecientes o decrecientes a la escala, lo cual se reflejará en que $\alpha + \beta > 0 \leq 1$. Por lo tanto, ello podría ser otra hipótesis interesante de plantearse. También podría ser interesante descubrir si todos los parámetros a la vez son distintos de cero, o de algún valor determinado.

La gama de preguntas posibles respecto del valor de los parámetros es sólo acotada por la pregunta que el investigador desee responder. Nuestro objetivo es, por lo tanto, desarrollar los métodos de inferencia y contraste de hipótesis que nos permitan responder, en el contexto de una regresión muestral particular, las preguntas anteriores.

Dos notas precautorias. En esta sección nos ocuparemos de restricciones o hipótesis **lineales** sobre los coeficientes. Restricciones no lineales son más escasas en econometría aplicada y se desarrollan en contexto de un modelo particular. Segundo, en todo lo que se refiere a este apartado, asumiremos que los errores de nuestra regresión muestral siguen una distribución normal (ya veremos porqué).

Entonces, sea nuestro modelo poblacional

$$Y = X\beta + u$$

donde X es una matriz de $(n \times k)$, u e Y son vectores $(n \times 1)$ y β es vector de $(k \times 1)$.

Sean entonces las siguientes hipótesis:

1. $H_0: \beta_i = 0 \Rightarrow$ Plantea que el regresor X_i no posee influencia alguna sobre Y . Este es el test más común y nos referiremos a él como *test de significancia*.

2. $H_0: \beta_i = \beta_{i0} \Rightarrow$ Plantea que el regresor X_i posee un impacto determinado por β_{i0} sobre Y .
3. $H_0: \beta_i + \beta_j = 1 \Rightarrow$ Plantea que la suma de los regresores X_i y X_j poseen un impacto conjunto de magnitud 1.
4. $H_0: \beta_i = \beta_j \Rightarrow$ Plantea que los regresores X_i y X_j poseen el mismo impacto sobre Y .
5. $H_0: \beta_i = 0 \forall i = 2 \dots k \Rightarrow$ Plantea que todos los regresores conjuntamente, excepto la constante, son cero.
6. $H_0: \beta_l = 0$ donde el vector β ha sido particionado en dos (β_l y β_p) con dimensiones $(k_l \times 1)$ y $(k_p \times 1)$ respectivamente, tal que $k_l + k_p = k$. Plantea entonces que un *subconjunto* de parámetros son estadísticamente no significativos.

Todas las hipótesis anteriores pueden ser resumidas en la siguiente expresión:

$$R\beta = r$$

donde R es una matriz de $(q \times k)$ constantes conocidas (ceros o unos), cuyo objetivo será *seleccionar* los parámetros a testear, cuyo número de filas, q , representa el número de restricciones. A su vez, r es un vector de dimensión q y contiene el real al cual es restringido cada parámetro. Veamos como serán las matrices R y r en cada una de nuestras hipótesis:

1. $R = [0 \dots 010 \dots 0]$; $r = 0$; $q = 1$
donde 1 se encuentra en la i -ésima posición
2. $R = [0 \dots 010 \dots 0]$; $r = \beta_{i0}$; $q = 1$
donde 1 se encuentra en la i -ésima posición
3. $R = [0 \dots 010 \dots 010 \dots 0]$; $r = 1$; $q = 1$
donde 1 se encuentra en la i -ésima posición y en la j -ésima posición.
4. $R = [0 \dots 010 \dots 0-10 \dots 0]$; $r = 0$; $q = 1$
donde 1 se encuentra en la i -ésima posición y en la j -ésima posición.
5. $R = [0_{q \times 1} \ I_{k-1}]$; $r = 0$; $q = k - 1$
6. $R = [0_{k_i \times k_j} \ I_{k_i}]$; $r = 0$; $q = k_i$

Entonces, nuestra hipótesis nula corresponde a:

$$(3.15) \quad H_0 : R\beta = r$$

con lo cual, sólo nos resta derivar el test que nos permita rechazar o no rechazar nuestra nula. La construcción del estadígrafo es como sigue. Dado que MCO (bajo los supuestos relevantes) es insesgado, tenemos que $E(\hat{\beta}) = \beta$, por lo tanto, $E(R\hat{\beta}) = R\beta$, mientras que la varianza de $R\hat{\beta}$ corresponde a

$$\begin{aligned} V[R\hat{\beta}] &= E[R(\hat{\beta} - \beta)(\hat{\beta} - \beta)'R'] \\ &= RVar(\hat{\beta})R' \\ &= \sigma^2 R(X'X)^{-1}R' \end{aligned}$$

Necesitamos aún un supuesto más para determinar la distribución muestral de nuestra nula. Dado que $\hat{\beta}$ es función de u y $u \sim N(0, \sigma^2)$, entonces $\hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$ y por lo tanto $R\hat{\beta} \sim N(r, \sigma^2 R(X'X)^{-1}R')$, entonces:

$$(3.16) \quad \hat{\beta} \sim N[\beta, \sigma^2(X'X)^{-1}]$$

y

$$(3.17) \quad R\hat{\beta} \sim N[R\beta, \sigma^2 R(X'X)^{-1}R']$$

y si la nula $R\beta = r$ es cierta:

$$(3.18) \quad \therefore (R\hat{\beta} - r) \sim N[0, \sigma^2 R(X'X)^{-1}R']$$

luego estandarizamos, con lo cual:

$$(3.19) \quad \frac{(R\hat{\beta} - r)}{\sqrt{\sigma^2 R(X'X)^{-1}R'}} \sim N[0, 1]$$

Además, se puede demostrar que (hacerlo)³:

$$(3.20) \quad \frac{\hat{u}'\hat{u}}{\sigma^2} \sim \chi^2_{(n-k)}$$

Luego, se puede demostrar que (hacerlo)⁴:

$$(3.21) \quad (R\hat{\beta} - r)'[\sigma^2 R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r) \sim \chi^2_q$$

³Basta con recordar que si x corresponde a un vector de realizaciones normales $(0,1)$, por lo cual $x \sim N(0, \sigma^2 I)$ y A corresponde a una matriz simétrica e idempotente de rango n , entonces $\frac{1}{\sigma^2} x'Ax \sim \chi^2_n$. Finalmente, recuerde que $\hat{u} = MY = Mu$ y que el rango de una matriz simétrica e idempotente es su traza.

⁴Basta con recordar que si el vector x , de dimensión n , es tal que $x \sim N(0, \Sigma)$, entonces, $x'\Sigma^{-1}x \sim \chi^2_n$.

luego, combinando los dos resultados anteriores, se puede demostrar que (hacerlo)⁵:

$$(3.22) \quad \frac{[(R\hat{\beta} - r)'[R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r)]/q}{\hat{u}'\hat{u}/(n-k)} \sim F_{(q, n-k)}$$

El test expuesto en (2.63) corresponde a la forma general del test F. Dicho test es de utilidad para testear cualquier hipótesis de la forma expuesta en (2.56). A continuación veremos subcasos de dicho test general.

3.2.1. Test t (Una hipótesis lineal)

Reescribiendo el test F como:

$$[(R\hat{\beta} - r)'[\widehat{RVar}(\hat{\beta})R']^{-1}(R\hat{\beta} - r)] \sim F_{(q, n-k)}$$

y haciendo el reemplazo respectivo de R y r correspondientes a las hipótesis 1 o 2 ($H_0: \beta_i = 0 = \beta_{i0}$), llegaremos a:

$$(3.23) \quad F = \frac{(\hat{\beta} - \beta_{i0})^2}{\widehat{Var}(\beta_i)} \sim F(1, n-k)$$

Recordando que t^2 es una caso particular de una F con un grado de libertad en el numerador, tenemos que:

$$(3.24) \quad t = \frac{\hat{\beta} - \beta_{i0}}{\sqrt{\widehat{Var}(\beta_i)}} \sim t_{n-k}$$

Lo anterior es conocido como el **test t** (test de significancia) y en su versión más utilizada corresponde a $t = \frac{\hat{\beta}}{\sqrt{\widehat{Var}(\beta_i)}}$, donde se busca testear la hipótesis nula de que el parámetro es cero.


El test t también cubre los casos 3. y 4.. En el caso 3. por ejemplo ($H_0: \beta_i + \beta_j = 1$), el estadígrafo corresponderá a:

$$(3.25) \quad t = \frac{\hat{\beta}_i + \hat{\beta}_j - 1}{\sqrt{\widehat{Var}(\hat{\beta}_i) + 2\widehat{Cov}(\hat{\beta}_i, \hat{\beta}_j) + \widehat{Var}(\hat{\beta}_j)}} \sim t_{n-k}$$

La distribución t es simétrica y se aproxima a la normal para tamaños de muestras

⁵Sólo un poquito de álgebra y recordar como se construye una distribución F(q, n-k) a partir de la división de dos χ^2 con grados de libertad q en el numerador y n-k en el denominador.

grandes, sin embargo, la t posee colas más gruesas que la normal (lo cual es más pronunciado en muestras pequeñas: $n \leq 30$). La siguiente figura expone la relación entre la distribución t y la normal:



Nota precautoria:

Toda la derivación anterior se basa en el estricto supuesto de normalidad de los errores. En caso de que los mismos no distribuyan normal, la distribución del test F (y por lo tanto el del t) es *desconocida* en muestras finitas. Sin embargo, es posible demostrar que $t \stackrel{a}{\sim} N(0, 1)$, es decir, que el test t distribuye asintóticamente normal. Luego, los valores críticos de t y Φ (normal estándar) se encuentran sumamente cerca si $n-k \geq 30$, por lo cual, en términos prácticos no importa mucho cual de ellas escojamos para los valores críticos (a menos que la muestra sea especialmente pequeña).

Finalmente, nos queda examinar los criterios de rechazo del test y los niveles de confianza. Como usted recordará de sus clases de estadística, lo anterior depende de como especifiquemos la hipótesis alternativa. A continuación, pasamos a revisar este punto.

Criterio de Rechazo y Nivel de Confianza

Una vez que hemos calculado el valor del test para nuestra nula particular (o *valor calculado*), resta calcular el *valor crítico* o el valor que nos indica la tabla t. Dicho valor crítico nos dirá si nuestra nula es falsa o si no podemos afirmar que lo es. La elección de dicho valor crítico se toma desde la tabla de distribución t y el número debe ser escogido tomado en cuenta el **nivel de significancia** escogido (1 %, 5 % o 10 %), el cual a su vez determina el **nivel de confianza** del test (99 %, 95 % o 90 %, respectivamente). El nivel de confianza posee una explicación intuitiva: Nuestro estadígrafo es función de la muestra con lo que estamos trabajando, por lo cual, si contáramos con una gran número de ellas y con cada una pudiésemos calcular nuestro estadígrafo, el nivel de confianza indica el porcentaje de veces que calculamos nuestro estadígrafo en que realmente no rechazamos lo cierto o rechazamos correctamente lo falso. La forma en que se distribuya la probabilidad de rechazo, es decir, el nivel de significancia, depende de nuestra hipótesis alternativa. A continuación revisamos dicho asunto. *Test de una cola*

Supongamos que nuestra hipótesis es:

$$H_0 : \beta_i = \beta_{io}$$

$$H_1 : \beta_i > \beta_{io}$$

donde $\beta_{io} \in \mathbb{R}$. En dicho caso, el estadígrafo es calculado según lo propuesto en la sección anterior. El punto está en como acumulamos la probabilidad de rechazo. En este caso, el total de la probabilidad de rechazo se acumula en la cola derecha de la distribución, como lo muestra la siguiente figura⁶:

⁶¿Por qué en la cola derecha? Porque la probabilidad de rechazo, es decir, el nivel de significancia, nos indica hasta donde puedo tolerar un valor mayor a β_{io} , por lo cual, carecería de sentido que la zona de rechazo se encuentre en la cola izquierda de la distribución. Por ejemplo, si $\beta_{io}=0$, la distribución de nuestro estadígrafo se centra en cero (vea la fórmula), por lo cual la hipótesis alternativa correspondería a que el parámetro es positivo. el punto es ¿cuán positivo puedo aceptar que sea?.

Figura 3.2
Zona de rechazo test de una cola



por lo tanto, rechazaremos nuestra hipótesis nula de que el coeficiente es cero contra la hipótesis alternativa que el parámetro es *mayor* que β_{io} , si el valor calculado del test es *mayor* al valor crítico de la tabla t. En el caso que H_1 sea que el parámetro es menor a β_{io} , entonces la probabilidad de rechazo se concentra en la cola izquierda y se rechaza la nula en el caso que el valor calculado sea menor que el valor crítico de la tabla t.

Test de dos colas

Supongamos que nuestra hipótesis es:

$$H_0 : \beta_i = \beta_{io}$$

$$H_1 : \beta_i \neq \beta_{io}$$

En este caso estamos repartiendo uniformemente la probabilidad de rechazo en ambas colas de la distribución como lo muestra la siguiente figura (al 95 % de confianza):

Figura 3.3
Zona de rechazo test de dos colas



Por lo tanto, rechazaremos la nula si el valor calculado es en *módulo mayor* que el valor crítico de tabla. Note que en este caso, la probabilidad de rechazo se reparte en partes iguales en ambas colas. Ello se justifica en que la distribución t corresponde a una distribución simétrica.

Error de Tipo I, Error de Tipo II, Tamaño y Potencia de un test

Antes de continuar, veremos cuatro conceptos estadísticos importantes que nos indican características de nuestro test.

1. **Error de Tipo I (ETI):** Corresponde a la probabilidad de rechazar la nula cuando es cierta.
2. **Error de Tipo II (ETII):** Corresponde a la probabilidad de aceptar la nula cuando es falsa.
3. **Tamaño del Test:** Corresponde a la probabilidad de cometer ETI. Se define como el nivel de significancia del test (α).
4. **Potencia del Test:** Corresponde a la probabilidad de rechazar la nula cuando es falsa. Se define como $\text{Potencia} = 1 - \text{ETII}$.

El óptimo para el investigador sería minimizar ambos tipos de errores y tener un test con un menor tamaño y mayor potencia posibles, sin embargo, note que el tamaño del test y por lo tanto, el ETI, es una variable endógena al investigador, en tanto que él decide con que nivel de confianza trabajar. Luego, el objetivo se transforma en, dado un nivel de confianza, minimizar la ocurrencia de ETII.

Intuitivamente, si usted escoge un nivel de significancia pequeño (1 %, por ejemplo), sus zonas de rechazo serán pequeñas, con lo cual, inevitablemente, la zona de no rechazo crece, lo cual implica que por minimizar el ETI, ha aumentado el ETII.

P-value

Otra forma alternativa al valor crítico de tabla para rechazar o no rechazar nuestra nula, corresponde al uso de los llamados p-values, los cuales son reportados en cualquier paquete estadístico. El p-value (p) se define como:

$$(3.26) \quad p = p(t^{\text{calculado}}) = P(|Z| \geq |t^{\text{calculado}}|) = 2(1 - \Phi(|t^{\text{calculado}}|))$$

es decir, el p-value representa la probabilidad de que el valor crítico (t de tabla, en nuestro caso), sea mayor al valor t calculado, es decir, describe el nivel de significancia exacto asociado a un resultado econométrico en particular. Por ejemplo, un p-value de 0.07 indica que un coeficiente es estadísticamente significativo en un nivel de 0.07 (o con un 93 % de confianza).

Ejemplo:

Suponga el siguiente Modelo de Regresión Lineal Simple:

$$Y_i = \beta_1 + \beta_2 X_i + u_i \quad \text{para } i = 1, \dots, N$$

Además posee la siguiente información muestral de X e Y:

Y	2	5	6	7
X	0	10	18	20

El estimador MCO de β_1 y β_2 es el siguiente:

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 4 & 48 \\ 48 & 824 \end{bmatrix}^{-1} \begin{bmatrix} 20 \\ 298 \end{bmatrix} = \begin{bmatrix} 2,1935 \\ 0,2338 \end{bmatrix}$$

La matriz de varianzas y covarianzas de $\hat{\beta}$ es:

$$\begin{aligned} \hat{V}(\hat{\beta}) &= \hat{\sigma}_u^2 (X'X)^{-1} \\ &= \frac{0,436}{2} \begin{bmatrix} 4 & 48 \\ 48 & 824 \end{bmatrix}^{-1} = \begin{bmatrix} 0,180866 & -0,010536 \\ -0,010536 & 0,000878 \end{bmatrix} \end{aligned}$$

Primero veamos el ajuste de este modelo, es decir, en que grado la variable x explica a la variable y , para lo cual calculemos el R^2 y $\bar{R}^2$:

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum_{i=1}^4 \hat{u}_i^2}{\sum_{i=1}^4 (Y_i - \bar{Y})^2} = 1 - \frac{0,436}{14} = 0,969$$

$$\bar{R}^2 = 1 - \frac{RSS/2}{TSS/3} = 1 - \frac{\sum_{i=1}^4 \hat{u}_i^2/2}{\sum_{i=1}^4 (Y_i - \bar{Y})^2/3} = 0,953$$

Como podemos ver, el grado de ajuste del modelo es bastante bueno, como el modelo incluye constante, el R^2 se puede interpretar como la proporción de la variabilidad de la variable independiente que es explicada por la variabilidad de la variable dependiente, la que en este caso alcanza un 97 %.

Ahora veamos si estos parámetros estimados son significativos a un 95 % de confianza, para lo cual realizaremos un test t de significancia a cada uno de ellos:

1. Test de significancia de $\hat{\beta}_1$:

$$H_0 : \hat{\beta}_1 = 0$$

$$H_1 : \hat{\beta}_1 \neq 0$$


$$t = \frac{\hat{\beta}_1}{Var(\hat{\beta}_1)} \sim t_2$$

De esta forma, el valor calculado para el estadístico t es:

$$t^c = \frac{2,193548387}{\sqrt{0,180866}} = 5,157850523$$

El valor de tabla del estadístico t a un 95 % de confianza y con dos grados de libertad es 4,303.

Figura 3.4
Inferencia Estadística



De esta forma, se rechaza la hipótesis nula de que $\hat{\beta}_1=0$, y por lo tanto el parámetro estimado resulta ser estadísticamente significativo.

2. Test de significancia de $\hat{\beta}_2$:

$$H_0 : \hat{\beta}_2 = 0$$

$$H_1 : \hat{\beta}_2 \neq 0$$


$$t = \frac{\hat{\beta}_2}{\text{Var}(\hat{\beta}_2)} \sim t_2$$

De esta forma, el valor calculado para el estadístico t es:

$$t^c = \frac{0,233870968}{\sqrt{0,000878}} = 7,892762865$$

El valor de tabla del estadístico t a un 95 % de confianza y con dos grados de libertad es 4,303.

Figura 3.5
Inferencia Estadística



De esta forma, se rechaza la hipótesis nula de que $\hat{\beta}_2=0$, y por lo tanto el parámetro estimado resulta ser estadísticamente significativo.

3. TAREA: Testee la siguiente hipótesis nula:

$$H_0 : \hat{\beta}_1 - \hat{\beta}_2 = 2$$

$$H_1 : \hat{\beta}_1 - \hat{\beta}_2 \neq 2$$

3.2.2. Test F (Conjunto de hipótesis lineales)

Los casos 6. y 5. corresponden a un *conjunto* de hipótesis a testear. En el caso 5. correspondía a un subconjunto particular de parámetros, mientras que el caso 6. correspondía a la nula de que todos ellos eran cero, menos la constante. En dichos casos se aplica la fórmula del test F según la ecuación (2.63) y los criterios de rechazo siguen lo expuesto en la sección anterior.

Sin embargo, en ambos casos podemos derivar expresiones alternativas para nuestro test.

- **Todas las pendientes del modelo son cero:** En este caso, se puede demostrar que el test F puede expresarse como:

$$(3.27) \quad F = \frac{ESS/(k-1)}{RSS/(n-k)} \sim F_{(k-1, n-k)}$$

o alternativamente, utilizando la definición del R^2 :

$$(3.28) \quad F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \sim F_{(k-1, n-k)}$$

- **Un subconjunto de las pendientes del modelo son cero:** En este caso, se puede demostrar que el test F puede expresarse como:

$$(3.29) \quad F = \frac{(\hat{u}'_*\hat{u}_* - \hat{u}'\hat{u})/k_2}{\hat{u}'\hat{u}/(n-k)} \sim F_{(k_2, n-k)}$$

donde $\hat{u}_*$ denotan los residuos MCO restringidos (donde k_2 representa el número de regresores que han sido restringidos a cero), mientras que $\hat{u}$ representan los residuos del modelo MCO original.

3.2.3. Intervalos de Confianza

Una forma alternativa (o mejor dicho complementaria) de examinar la significancia estadística de un parámetro (o un conjunto de ellos) es a través de intervalos de confianza (IC). Ellos nos indican, dado un nivel de confianza, el **rango de valores admisibles** del coeficiente que se estima. Los niveles de confianza generalmente utilizados son 99 %, 95 % y 90 % (al igual que en los test de hipótesis),

donde el tamaño de los mismos es necesariamente decreciente⁷.

Una manera natural de obtener el IC asociado a $\hat{\beta}_i$ es a través del test t asociado. Vimos entonces que él corresponde a:

$$\frac{\hat{\beta}_i - \beta_{i0}}{\sqrt{Var(\hat{\beta}_i)}} \sim t_{n-k}$$

entonces, si deseamos un IC del $(1-\alpha)\%$ de confianza (es decir, de $\alpha\%$ de significancia) para el parámetro $\hat{\beta}_i$, basta obtener de las tablas de distribución el valor λ_α correspondiente, es decir:

$$\begin{aligned} 1 - \alpha &= Pr \left[Z_{\alpha/2} \leq \frac{\hat{\beta}_i - \beta_{i0}}{\sqrt{Var(\hat{\beta}_i)}} \leq Z_{1-\alpha/2} \right] \\ &= Pr \left[-Z_{1-\alpha/2} \leq \frac{\hat{\beta}_i - \beta_{i0}}{\sqrt{Var(\hat{\beta}_i)}} \leq Z_{1-\alpha/2} \right] \\ &= Pr \left[\hat{\beta}_i - Z_{1-\alpha/2} \sqrt{Var(\hat{\beta}_i)} \leq \beta_{i0} \leq \hat{\beta}_i + Z_{1-\alpha/2} \sqrt{Var(\hat{\beta}_i)} \right] \end{aligned}$$

donde la tercera expresión se obtiene de despejar β_{i0} de la segunda. Note que el intervalo ha sido construido en base a una distribución simétrica (como la t o la normal), por lo cual el valor de tabla a escoger debe corresponder a $\alpha/2$.

Note además que dicho intervalo está construido sólo en base a constantes conocidas. Una vez construido, se puede contrastar la nula ($H_0: \beta_i = \beta_{i0}$) al nivel de significancia α sencillamente observando si β_{i0} pertenece al intervalo (en cuyo caso no rechazamos la nula) o se encuentra fuera de él (en cuyo caso rechazamos la nula)⁸. Nuevamente, la validez de dicho intervalo de confianza depende críticamente del supuesto de distribución de los errores. En el caso que el valor Z_α se obtenga de la tabla t, como ya sabemos, estamos suponiendo que los errores siguen una distribución normal. Un caso más general es utilizar los valores críticos de la distribución normal estándar.

También es posible derivar *regiones de confianza*, es decir, IC de confianza simultáneos para una conjunto de parámetros, sin embargo, su utilización es escasa en

⁷Intuitivamente, ya que a más exacta es mi estimación del rango posible, con menos confianza puedo afirmar estar en lo correcto.

⁸Una forma fácil de verlo es pensando en $\beta_{i0}=0$, es decir, que la variable x_i no ayuda a explicar y .

econometría aplicada (¡a menos que su pregunta puntual lo requiera!).

Finalmente derivaremos el intervalo de confianza para la varianza de los errores. Sabemos de la ecuación (2.61) que:

$$\frac{\hat{u}'\hat{u}}{\sigma^2} \sim \chi_{n-k}^2$$

$\therefore$

$$(3.30) \quad \frac{(n-k)\tilde{\sigma}^2}{\sigma^2} \sim \chi_{n-k}^2$$

Utilizando la misma lógica que utilizamos para el IC de un parámetro $\hat{\beta}$, tenemos que el IC para σ^2 corresponde a:

$$(3.31) \quad \left[\frac{(n-k)\tilde{\sigma}^2}{\chi_{n-k,\alpha}^2} \leq \sigma^2 \leq \frac{(n-k)\tilde{\sigma}^2}{\chi_{n-k,1-\alpha}^2} \right] = (1-\alpha)$$

Note que los valores críticos utilizados corresponden a $\chi_{n-k,1-\alpha}^2$ y $\chi_{n-k,\alpha}^2$, ya que la distribución χ^2 es una distribución asimétrica.

3.2.4. Test de Normalidad (Test de Jarque-Bera)

Consideramos ahora el problema de utilizar los momentos de los residuos MCO para hacer inferencia sobre la distribución de los errores poblacionales. Dado que algunas de las propiedades de MCO y de la inferencia dependen del supuesto de normalidad en los errores, es importante poseer un contraste para dicho supuesto. Como es sabido, la distribución normal es simétrica y mesocúrtica. La simetría implica que el tercer momento poblacional $E(u^3)$ en torno a la media, es cero. El hecho que sea mesocúrtica implica que la kurtosis es 3 (es decir, el ancho de las colas de la distribución, el cual se mide utilizando el cuarto momento en torno a la media). Recordemos entonces que el coeficiente de simetría poblacional se define como:

$$\sqrt{S} = \frac{E(u^3)}{(\sigma^2)^{\frac{3}{2}}}$$

mientras que la kurtosis (o coeficiente de):

$$K = \frac{E(u^4)}{(\sigma^2)^2}$$

En base a los anteriores, Bera y Jarke (1981), propusieron el siguiente estadígrafo, construido **bajo la nula de normalidad**:

$$JB = n \left[\frac{\hat{S}}{6} + \frac{(\hat{K} - 3)^2}{24} \right] \stackrel{a}{\sim} \chi^2_{(2)}$$

Donde los estimadores muestrales del coeficiente de asimetría y kurtosis se obtienen al considerar que un estimador natural de:

$$\mu_r = E[\hat{u}^r]$$

corresponde a:

$$m_r = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^r$$

Note que el estadígrafo está definido en términos del exceso de kurtosis, por lo cual, a menor sea el valor, menor es la probabilidad de rechazar la nula de normalidad. Note además que el estadístico es esencialmente no constructivo, en términos de que no nos indica que camino seguir en caso de rechazar la nula, además de que no rechazar normalidad no implica confirmar su existencia. Sin embargo, en la práctica corresponde al test más utilizado.

3.3. Bondad de Ajuste e Inferencia en STATA

Volvamos al ejemplo del capítulo 2 donde se ha estimado el efecto del peso al nacer del menor sobre los resultados estandarizados de la prueba cognitiva Tepsi. Los resultados, presentados nuevamente en el Cuadro 3.1, nos mostraban un efecto positivo del peso al nacer sobre el puntaje de esta prueba, cada 100 gramos adicionales de peso al nacer el puntaje del menor se incrementa en 0.067 puntos, recordemos que el puntaje está estandarizado en una media de 50 puntos con desviación estándar de 10 puntos.

El cuadro en STATA también nos muestra el error estándar del coeficiente estimado, y el correspondiente valor del estadístico t para la hipótesis nula de que este coeficiente es igual a cero. Podemos notar que:

$$t = \frac{0,0675061}{0,0249291} = 2,71$$

La comparar el valor calculado para el estadístico con la información de la estimación (2.71) con el valor crítico de una distribución t que acumula un 5% en

la cola derecha e izquierda (1.96) podemos concluir que a un 5 % de significancia se rechaza la hipótesis nula que el coeficiente de peso al nacer sea igual a cero, concluyendo que el coeficiente es estadísticamente significativo. La cuarta columna del output de STATA nos muestra el p-value, el cual corresponde al nivel de significancia asociado al valor calculado del estadístico, este es 0.7 %. Como este valor del p-value es menor al 5 % de error tipo 1 que se está dispuesto a cometer (nivel de significancia) también podemos concluir que se rechaza la hipótesis nula. Finalmente, las últimas dos columnas muestran el intervalo de confianza calculado al 95 % de confianza, este intervalo nos indica que con un 95 % de seguridad el valor poblacional del coeficiente de peso sobre puntaje Tepsi está entre 0.019 y 0.116, al no pertenecer el cero al intervalo de confianza también podemos concluir que el coeficiente es estadísticamente significativo. El cuadro 3.2 nos muestra la misma estimación pero utilizando un 1 % de significancia (o 99 % de confianza).

Adicionalmente el resultado de STATA nos muestra la descomposición de varianza y el coeficiente de determinación R^2 y R^2 ajustado estimado, en este ejemplo el porcentaje de la varianza de la variable dependiente que está siendo explicada por el modelo es muy baja sólo 0.007 %, porque a este modelo le falta incorporar variables explicativas. En el Cuadro 3.3 se estima el modelo pero incorporando algunas otras variables como: años de escolaridad de la madre, test cognitivo e la madre (números y lenguaje), y meses de lactancia materna, en este caso el R^2 ajustado es de un 8.4 %, todas las variables son estadísticamente significativas a excepción de los meses de lactancia materna.

Cuadro 3.1

*Estimación MCO Puntaje Tepsi y Peso al Nacer
Inferencia al 95 %*

. reg tepsi_t_s peso100						
Source	SS	df	MS		Number of obs = 8915	
Model	1121.49072	1	1121.49072		F(1, 8913) =	7.33
Residual	1363158.35	8913	152.940464		Prob > F =	0.0068
					R-squared =	0.0008
					Adj R-squared =	0.0007
Total	1364279.85	8914	153.049119		Root MSE =	12.367
tepsi_t_s	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
peso100	.0675061	.0249291	2.71	0.007	.0186394	.1163729
_cons	51.64347	.8447839	61.13	0.000	49.9875	53.29944

Cuadro 3.2
Estimación MCO Puntaje Tepsi y Peso al Nacer
Inferencia al 99 %

. reg tepsi_t_s peso100, level(99)						
Source	SS	df	MS			
Model	1121.49072	1	1121.49072	Number of obs = 8915		
Residual	1363158.35	8913	152.940464	F(1, 8913) = 7.33		
Total	1364279.85	8914	153.049119	Prob > F = 0.0068		
				R-squared = 0.0008		
				Adj R-squared = 0.0007		
				Root MSE = 12.367		
tepsi_t_s	Coef.	Std. Err.	t	P> t	[99% Conf. Interval]	
peso100	.0675061	.0249291	2.71	0.007	.0032793	.131733
_cons	51.64347	.8447839	61.13	0.000	49.46699	53.81996

Cuadro 3.3
Estimación MCO Puntaje Tepsi y Peso al Nacer
Inferencia al 95 %, incluyendo más controles

. reg tepsi_t_s peso100 esc_madre wais* meses_lechem						
Source	SS	df	MS			
Model	113277.091	5	22655.4182	Number of obs = 8752		
Residual	1222603.19	8746	139.789983	F(5, 8746) = 162.07		
Total	1335880.28	8751	152.654586	Prob > F = 0.0000		
				R-squared = 0.0848		
				Adj R-squared = 0.0843		
				Root MSE = 11.823		
tepsi_t_s	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
peso100	.100206	.0243658	4.11	0.000	.0524433	.1479687
esc_madre	.6346425	.0482998	13.14	0.000	.5399635	.7293215
wais_num_st	.4089277	.0492641	8.30	0.000	.3123585	.5054968
wais_vo_st	.3922531	.0410636	9.55	0.000	.3117588	.4727474
meses_lechem	.0128574	.0124263	1.03	0.301	-.0115011	.0372159
_cons	37.17019	.9906579	37.52	0.000	35.22827	39.11211

Una vez estimado el modelo es posible testear si los errores cumplen con el supuesto de normalidad, para esto primero debemos obtener los errores predichos del modelo a través del siguiente comando:

```
predict errores, resid
```

El Cuadro 3.4 nos muestra la asimetría y kurtosis de los errores predichos, podemos ver que la kurtosis es muy cercana a 3, pero la asimetría se aleja de cero. El Cuadro 3.5 muestra el test de normalidad de los errores, que testea conjuntamente kurtosis igual a 3 y asimetría igual a cero, la hipótesis nula conjunta es rechazada, por lo cual el modelo no cumple con el supuesto de normalidad de los errores.

Cuadro 3.4*Coefficiente de asimetría y kurtosis errores del modelo*

```
. tabstat errores, stats(kurtosis skewness)
```

variable	kurtosis	skewness
errores	2.945956	-.2310341

Cuadro 3.5*Test de Normalidad de los errores del modelo*

```
. sktest errores
```

Skewness/Kurtosis tests for Normality					
variable	obs	Pr(Skewness)	Pr(Kurtosis)	adj chi2(2)	joint Prob>chi2
errores	8.8e+03	0.0000	0.3064	67.58	0.0000

Como los errores del modelo no cumplen con el supuesto de normalidad de los errores, se puede utilizar el método de simulación de Bootstrap para obtener los intervalos de confianza de cada uno de los coeficientes, el comando para esto es:

```
bootstrap _b, reps(500): reg tepsi_t_s peso100 esc_madre wais* meses_lechem
```

Cuadro 3.6
Intervalos de confianza mediante Bootstrap

. estat bootstrap, all						
Linear regression			Number of obs	=	8752	
			Replications	=	500	
tepsi_t_s	Observed Coef.	Bias	Bootstrap Std. Err.	[95% Conf. Interval]		
peso100	.100206	-.0006524	.02506282	.0510838	.1493282	(N)
				.0473988	.1508733	(P)
				.049779	.1550461	(BC)
esc_madre	.6346425	.0028542	.04815708	.5402564	.7290287	(N)
				.549747	.7308265	(P)
				.5487492	.7283936	(BC)
wais_num_st	.40892767	-.0010131	.05293731	.3051725	.5126829	(N)
				.3082435	.5087942	(P)
				.3088819	.5089437	(BC)
wais_vo_st	.39225311	-.0020424	.03977151	.3143024	.4702038	(N)
				.313166	.4702752	(P)
				.3152159	.4729657	(BC)
meses_lechem	.01285744	.0008675	.0126198	-.0118769	.0375918	(N)
				-.0116534	.0373735	(P)
				-.0130734	.0360172	(BC)
_cons	37.17019	-.0023034	1.0513932	35.1095	39.23088	(N)
				35.06607	39.33858	(P)
				35.0638	39.15738	(BC)
(N)	normal confidence interval					
(P)	percentile confidence interval					
(BC)	bias-corrected confidence interval					

Capítulo 4

Modelo de Regresión Lineal: Especificación y Problemas

En el capítulo anterior se revisó el estimador de Mínimos Cuadrados Ordinarios (MCO) en el contexto de un modelo de regresión simple (solo una variable explicativa) y un modelo de regresión múltiple (más de una variable explicativa). Si los supuestos del estimador MCO se cumplen, este es el mejor estimador lineal insesgado. También se abordaron los test de hipótesis lineal simple y conjunto, y los intervalos de confianza tanto de los parámetros. En ambos casos, tanto para realizar inferencias como para computar los intervalos de confianza, el supuesto de normalidad del término de error es fundamental. Si este supuesto no se cumple, la inferencia realizada no es válida. En este caso, se deben utilizar métodos de simulaciones para obtener los intervalos de confianza correctos y realizar la inferencia en forma apropiada.

Para que el estimador MCO sea el mejor estimador lineal insesgado se requieren de los siguientes supuestos:

1. El modelo de regresión es lineal
2. Los errores del modelo son independiente entre ellos
3. Los errores del modelo tienen media cero
4. Los errores del modelo tienen varianza constante
5. Las variables explicativas son exógenas, o no están correlacionadas con el error del modelo

6. El modelo debe estar especificado de manera correcta

El primer supuesto habla de que la relación estimada entre la variable dependiente y la variable explicativas será lineal, sin embargo, para capturar relaciones no lineales entre la variable dependiente y las variables explicativas se pueden utilizar como variables explicativas transformaciones no lineales, por ejemplo, potencias, logaritmo, etc.

Los supuestos 2, 3 y 4 se traducen en que:

$$u_i \stackrel{iid}{\sim} (0, \sigma^2)$$

Los errores del modelo son independiente e idénticamente distribuidos con media cero y varianza constante. El supuesto de homocedasticidad del término de error, es un supuesto que raramente se cumple cuando se trabaja con datos de corte transversal. La ruptura de este supuesto no genera problema de sesgo, pero si de ineficiencia. Veremos cómo detectar y abordar el problema de heterocedasticidad (varianza del error no es constante).

El supuesto 5 es clave para la identificación del modelo, si las variables explicativas son endógenas, es decir, están correlacionadas con el error, el efecto marginal de la variable explicativa sobre la variable dependiente se estima de manera sesgada.

El último supuesto enunciado habla de que el modelo debe estar especificado de manera correcta, esto significa que debemos hacer todos los esfuerzos (considerando la disponibilidad de datos) para incorporar todas las variables relevantes para explicar el comportamiento de la variable de interés (variable dependiente), y de la mejor forma posible. Algunas de las variables claves para explicar el comportamiento de la variable dependiente pueden ser discretas, no continuas; estas generalmente son variables de carácter cualitativo: género, zona geográfica, estatus laboral, etc. Es importante incorporar la información que aportan estas variables en forma correcta en la especificación para obtener una estimación adecuada de los impactos. En el caso de no tener acceso a algunas variables, las variables quedaran como *variables relevantes omitidas*, cuando una variable es omitida esta forma parte del término de error. Si la variable omitida tiene correlación con una o más de las variables explicativas del modelo, la estimación MCO será sesgada ya que se rompe el supuesto de exogeneidad de las variables explicativas.

Por otra parte, con el objetivo de evitar el problema de omisión de variables,

se pueden incluir variables irrelevantes. En este caso no se genera sesgo en la estimación MCO, pero se pierde eficiencia (el estimador tiene mayor varianza, es menos preciso). Un tipo de variable omitida son aquellas que ayudan a explicar un comportamiento no lineal de la variable dependiente, en estos casos las variables omitidas son potencias de las mismas variables explicativas ya incluidas en el modelo.

Otros supuesto, para la correcta especificación del modelo, es que las variables explicativas no sean colineales entre ellas. Es decir, se deben incluir variables explicativas que no sean muy parecidas o que no expliquen de igual forma el comportamiento de la variable dependiente. Cuando las variables explicativas son muy parecidas, se habla del problema de multicolinealidad. Este problema, se detecta por “síntomas” que se observan en la estimación. No genera sesgo en la estimación, pero el problema es que la estimación es muy “volátil”, poco robusta.

Por último, una vez incorporadas todas las variables relevantes de la mejor forma, en forma binaria o considerando no linealidades, y habiendo detectado y abordado los problemas de multicolinealidad o heterocedasticidad presentes, es posible tener más de un modelo que explique el comportamiento de la variable de interés y que cumple con todos los requisitos de especificación. Entonces, ¿con cuál de los modelos quedarse?. Existen test de modelos anidados y no anidados que lo ayudarán a tomar la decisión en estos casos.

4.1. Omisión de Variables Relevantes

Supongamos que la especificación correcta del modelo es la siguiente:

$$\ln y_{ph_i} = \beta_0 + \beta_1 \cdot esc_i + \beta_2 \cdot exp_i + v_i$$

Sin embargo, el modelo estimado es el siguiente:

$$\ln y_{ph_i} = \beta_0 + \beta_1 \cdot esc_i + u_i$$

es decir, se ha omitido la variable correspondiente a la experiencia laboral (exp), por lo cual el error del modelo estimado es el siguiente:

$$u_i = v_i + \beta_2 \cdot exp_i$$

Entonces, en el modelo estimado se genera un problema de endogeneidad entre la variable explicativa (esc) y el error (u) siempre que la variable correspondiente a los años de escolaridad esta correlacionada con la variable relevante omitida,

experiencia.

Este problema de endogeneidad hace que el coeficiente estimado por MCO para la variable escolaridad sea sesgado e inconsistente:

$$E[\hat{\beta}_1|esc] = \beta_1 + \underbrace{\frac{cov(esc, exp)}{V(esc)}}_{sesgo} \cdot \beta_2$$

Así, podemos notar que el sesgo por omisión de variable relevantes será distinto de cero en la medida que la variable omitida este correlacionada con las variables incluidas en el modelo. El signo de sesgo depende de la correlación entre la variable omitida e incluida, y el signo esperado para el coeficiente de la variable omitida en el modelo.

Veamos el siguiente ejemplo, el Cuadro 4.1 muestra la estimación de un modelo para el logaritmo de salario por hora (*lyph*) en función de los años de escolaridad y la experiencia laboral a partir una muestra de 4,740 personas entrevistadas en la Encuesta de Protección Social (EPS), que en el año 2004 tenían entre 18 y 41 años y se encontraban trabajando. Se tomo este universo de personas ya que en la encuesta se pregunta por la historia laboral de las personas desde 1980. De esta forma, las personas mayores de 41 años en el año 2004 reportan una historia laboral censurada, la cual no nos permite obtener una medida apropiada de los años trabajados.

Cuadro 4.1
Estimación Logaritmo Salarios

<pre>. reg lyph esc04 experiencia [pw=factor] (sum of wgt is 2.9721e+06)</pre>						
Linear regression				Number of obs = 4727 F(2, 4724) = 407.72 Prob > F = 0.0000 R-squared = 0.2586 Root MSE = .5862		
lyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
esc04	.112605	.0039438	28.55	0.000	.1048732	.1203367
experiencia	.0011489	.0001376	8.35	0.000	.0008791	.0014187
_cons	5.417344	.0534188	101.41	0.000	5.312619	5.52207

Ahora suponga que por error la variable experiencia es omitida del modelo, el Cuadro 4.2 muestra la estimación del modelo con la variable omitida.

Cuadro 4.2*Estimación Logaritmo Salarios omitiendo experiencia*

<pre>. reg lypn esc04 [pw=factor] (sum of wgt is 2.9721e+06)</pre>					
Linear regression			Number of obs = 4727 F(1, 4725) = 795.10 Prob > F = 0.0000 R-squared = 0.2427 Root MSE = .59241		
lyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]
esc04	.1060137	.0037597	28.20	0.000	.098643 .1133844
_cons	5.644588	.0433197	130.30	0.000	5.559661 5.729515

Podemos ver que el coeficiente estimador para el retorno a la educación en el modelo que omite experiencia es 10.6 % menor al coeficiente en el modelo que no omite esta variable. Es decir, omitir la variable relevante experiencia genera un sesgo negativo en el retorno a la educación. El sesgo negativo se debe a que existe una correlación negativa entre los años de escolaridad y experiencia, tal como lo muestra el cuadro 4.3, y el coeficiente de experiencia sobre logaritmo del salario es positivo.

Cuadro 4.3*Correlación entre escolaridad y experiencia*

<pre>. corr esc experiencia (obs=7430)</pre>		
	esc04	experiencia
esc04	1.0000	
experiencia	-.01307	1.0000

En resumen, el problema de omisión de variables relevantes genera sesgo en la estimación MCO pero no problemas de eficiencia, por el contrario el error estándar es menor dado que se están estimando menos coeficientes en el modelo. No existe un test para detectar la omisión de variables relevantes, es algo que el investigador debe tener presente de acuerdo a su conocimiento sobre la especificación del modelo.

4.2. Inclusión de Variables Irrelevantes

Con el objetivo de eliminar el potencial problema de omisión de variables relevantes, siempre existe la tentación de incluir la mayor cantidad de variables explicativas posibles. Esto nos puede llevar a incluir variables irrelevantes.

La inclusión de variables irrelevantes no genera problemas de sesgo en la estimación, ya que el error sigue teniendo media cero y no está correlacionado con las variables explicativas del modelo. Sin embargo, incluir variables irrelevantes genera un problema de ineficiencia, la varianza del estimador será mayor, provocando que la estimación sean menos precisa.

4.3. Multicolinealidad

El problema de multicolinealidad surge cuando se incluyen variables explicativas similares. Una de las dos variables es irrelevante, ya que no aporta información adicional con respecto a la otra.

Algunas fuentes de la multicolinealidad son:

- El método de recolección de información empleado
- Restricción de la población objeto de muestreo
- Especificación del modelo

La multicolinealidad, al igual que la inclusión de variables relevantes, genera problemas de eficiencia. La estimación MCO en presencia de variables colineales es imprecisa o ineficiente, pero sigue siendo insesgada.

El problema de multicolinealidad es fácil de detectar, pero no tiene más solución que eliminar la variable que no está aportando información distinta de las otras.

Síntomas de la estimación en presencia de multicolinealidad:

1. El modelo tiene un ajuste bueno (R^2 alto), pero los parámetros resultan ser estadísticamente no significativos.

2. Pequeños cambios en los datos producen importantes cambios en las estimaciones.
3. Los coeficientes pueden tener signos opuestos a los esperados o una magnitud poco creíble.

Cuando existe multicolinealidad perfecta STATA automáticamente borra una de las dos variables.

El comando `estat vif` (post estimación) reporta el factor de inflación de varianza (VIF) de cada variable explicativa del modelo, y el promedio del modelo. Este factor mide el grado en que la varianza del coeficiente estimado para la variable ha sido inflada, como producto de que esta variable no es ortogonal (no es independiente) de las restantes variables del modelo.

$$VIF_k = \frac{1}{1 - R_k^2}$$

donde R_k^2 representa el coeficiente de determinación (R^2) de la regresión de la variable explicativa k sobre las restantes variables explicativas del modelo. Si R_k^2 es grande significa que el comportamiento de la variable independiente k se puede explicar en gran medida con el comportamiento de las restantes variables de modelo, con lo cual esta variable no entrega información diferente a la que están entregando las restantes variables del modelo. La regla sobre este factor, es que existe multicolinealidad si el VIF es mayor a 10.

Volvamos al modelo donde el logaritmo del salario por hora es estimado en función de los años de escolaridad y la experiencia, pero además se le incorporan tres variables explicativas: el índice de masa corporal (peso/estatura²), estatura y peso. Estas variables busca determinar si las características físicas de la persona tienen influencia sobre el salario por hora, dado un nivel de escolaridad y experiencia constante.

El Cuadro 4.4 muestra el modelo estimado. Luego de la estimación podemos obtener el factor de inflación de varianza de cada una de las variables incluidas en la especificación, el que se obtiene haciendo una regresión de cada variable explicativa contra las restantes. Se reporta un VIF para cada variable, y el promedio de ellos, los resultados de aplicar el comando `estat vif` luego de la estimación del modelo se muestran en el Cuadro 4.5. Podemos notar que las variables explicativas incorporadas al modelo tienen problema de multicolinealidad, lo que es natural ya que el índice de masa corporal es calculado en función de las variables peso y estatura.

Cuadro 4.4
Estimación Logaritmo Salarios

<pre>. reg lyph esc04 experiencia imc estatura peso [pw=factor] (sum of wgt is 2.8761e+06)</pre>					
Linear regression			Number of obs = 4578 F(5, 4572) = 168.82 Prob > F = 0.0000 R-squared = 0.2800 Root MSE = .57843		
lyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]
esc04	.1115549	.0039289	28.39	0.000	.1038523 .1192575
experiencia	.0011325	.0001394	8.12	0.000	.0008592 .0014058
imc	.0144427	.0075481	1.91	0.056	-.0003553 .0292406
estatura	.0158268	.0032813	4.82	0.000	.0093939 .0222596
peso	-.0055681	.003221	-1.73	0.084	-.0118828 .0007465
_cons	2.822478	.5230056	5.40	0.000	1.797134 3.847821

Cuadro 4.5
Factor de Inflación de la Varianza

. estat vif		
variable	VIF	1/VIF
peso	31.20	0.032050
imc	25.05	0.039919
estatura	14.72	0.067946
experiencia	1.06	0.940563
esc04	1.06	0.941571
Mean VIF	14.62	

De los anterior se concluye que a pesar de que las variables resultan ser medianamente significativas (al 10 %), están no pueden ser incluidas en forma conjunta en la especificación, ya que generan multicolinealidad. La escolaridad y experiencia, no tienen problema de colinealidad, un muy bajo porcentaje de su comportamiento se explica por el de las restantes variables explicativas, un 6 % aproximadamente. Luego, la única solución es eliminar alguna(s) de la(s) variable(s) que generan multicolinealidad, a continuación se estiman diferentes versiones del modelo y en el Cuadro 4.6 se muestra la comparación de ellos:

```
reg lyph esc04 experiencia [pw=factor]
estimates store modelo1
reg lyph esc04 experiencia imc [pw=factor]
```

```

estimates store modelo2
reg lyph esc04 experiencia estatura [pw=factor]
estimates store modelo3
reg lyph esc04 experiencia peso [pw=factor]
estimates store modelo4
reg lyph esc04 experiencia estatura peso [pw=factor]
estimates store modelo5
estimates table modelo1 modelo2 modelo3 modelo4 modelo5,
  stat(r2_a, rmse) b(%7.3g) p(%4.3f)

```

Cuadro 4.6
Comparación de Modelos

variable	modelo1	modelo2	modelo3	modelo4	modelo5
esc04	.113 0.000	.114 0.000	.112 0.000	.112 0.000	.111 0.000
experiencia	.00115 0.000	.00122 0.000	.00112 0.000	.00103 0.000	.00113 0.000
imc		-.0035 0.109			
estatura			.0108 0.000		.0108 0.000
peso				.00407 0.000	-7.7e-05 0.935
_cons	5.42 0.000	5.49 0.000	3.63 0.000	5.16 0.000	3.63 0.000
r2_a	.258	.258	.28	.262	.279
rmse	.586	.587	.577	.585	.579

legend: b/p

De acuerdo a la información presentada en el Cuadro 4.6 deberíamos quedarnos con el modelo que sólo incluye la estatura, ya que tiene el mayor R^2 ajustado y menor error cuadrático medio.

4.4. Variables Categóricas o Cualitativas como Regresores

En gran parte de los modelos de regresión lineal las variables cualitativas son fundamentales para una correcta especificación. Hasta ahora hemos visto la incorporación de una o más variables explicativas, esencialmente cuantitativas y

continuas.

Las variables cualitativas indican la presencia o ausencia de cierta cualidad, pueden tener dos o más categorías. Para la incorporación de variables cualitativas en el modelo de regresión esto siempre se debe hacer en forma de variable Dummy. Las variables Dummies (ficticias, dicotómicas, etc.) toman sólo valores 1 y 0, donde 1 indica la presencia de cierta característica y 0 que la característica no esta presente.

Por ejemplo, en la base de datos contamos con la variable género:

Cuadro 4.7
Variable Categórica Género

```
. d genero
```

variable name	storage type	display format	value label	variable label
genero	float	%9.0g	sexolbl	

```
. tab genero
```

genero	Freq.	Percent	Cum.
Hombre	3,744	50.26	50.26
Mujer	3,705	49.74	100.00
Total	7,449	100.00	

```
. label list sexolbl
sexolbl:
    1 Hombre
    2 Mujer
```

Esta variable toma valor 1 cuando la persona es hombre y 2 cuando es mujer. La variable así definida no es una variable Dummy, la inclusión de la variable genero en el modelo, definida de esta forma, es incorrecta.

Debemos redefinir la variable para que la cualidad “Hombre” o, indistintamente, la cualidad “Mujer” tome el valor 1 y los restantes cero. De esta forma, se pueden definir dos variables dummies, pero una de ellas es redundante. En términos generales, si una variable tiene n categorías debo definir al menos $n - 1$ dummies para ser incluidas en el modelo, una de ellas debe ser excluida la cuál es denominada categoría base.

Siguiendo con el ejemplo de la variable género podemos definir una dummy de la siguiente forma:

```
g sexo=1 if genero==1
replace sexo=0 if genero==2
```

Pero podría haber definido de la variable de esta otra forma:

```
g sexo_2=1 if genero==2
replace sexo_2=0 if genero==1
```

Supongamos que el modelo del logaritmo del salario por hora además de incorporar los años de escolaridad y experiencia, queremos incorporar la cualidad género en la regresión. Como la cualidad género puede tomar dos valores posibles, sólo una dummy (correspondiente a una de estas cualidades) debe ser incorporada en el modelo. Suponga que estimamos el siguiente modelo:

$$\ln yph = \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_4 \cdot sexo + u$$

Según el modelo planteado, el valor esperado del logaritmo del salario por hora para un hombre es:

$$E[\ln yph | hombre, esc, experiencia] = \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_4$$

Y el valor esperado del logaritmo del salario por hora para una mujer es:

$$E[\ln yph | mujer, esc, experiencia] = \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia$$

De esta forma, todo lo demás constante la diferencia en salario promedio de ser hombre versus mujer es:

$$E[\ln yph | hombre, esc, experiencia] - E[\ln yph | mujer, esc, experiencia] = \beta_4$$

El Cuadro 4.8 muestra la estimación del modelo plantado con los datos de la EPS 2004. El resultado nos muestra que dado un nivel de escolaridad y un nivel de experiencia los hombres tienen un salario por hora que en promedio es 17.5 % superior al salario promedio de las mujeres.

Se podría haber estimado el mismo modelo incluyendo la dummy correspondiente a mujer (*sexo_2*), el resultado se muestra en el Cuadro 4.9 obteniendo exactamente el mismo resultado, en promedio las mujeres tienen un salario por hora 17.5 % inferior al de los hombres.

Cuadro 4.8*Estimación Logaritmo Salario por Hora incluyendo dummy Hombre*

<pre>. reg ltyph esc experiencia sexo [pw=factor]</pre> (sum of wgt is 2.9721e+06) Linear regression						
				Number of obs = 4727 F(3, 4723) = 284.34 Prob > F = 0.0000 R-squared = 0.2736 Root MSE = .58029		
ltyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
esc04	.11531	.0039659	29.08	0.000	.107535	.123085
experiencia	.0009495	.0001377	6.90	0.000	.0006796	.0012194
sexo	.175023	.0206795	8.46	0.000	.1344816	.2155644
_cons	5.305846	.0560166	94.72	0.000	5.196027	5.415665

Cuadro 4.9*Estimación Logaritmo Salario por Hora incluyendo dummy Mujer*

<pre>. reg ltyph esc experiencia sexo_2 [pw=factor]</pre> (sum of wgt is 2.9721e+06) Linear regression						
				Number of obs = 4727 F(3, 4723) = 284.34 Prob > F = 0.0000 R-squared = 0.2736 Root MSE = .58029		
ltyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
esc04	.11531	.0039659	29.08	0.000	.107535	.123085
experiencia	.0009495	.0001377	6.90	0.000	.0006796	.0012194
sexo_2	-.175023	.0206795	-8.46	0.000	-.2155644	-.1344816
_cons	5.480869	.0525935	104.21	0.000	5.377761	5.583977

Notemos que la interpretación del coeficiente depende de cuál sea la categoría base, en la primera regresión donde se incluye la dummy correspondiente a la categoría hombre, la categoría base es mujer, por lo cual el coeficiente que acompaña a la dummy hombre se interpreta como el efecto marginal sobre la variable dependiente de pasar de ser mujer (categoría base) a ser hombre.

Una vez estimado el modelo podemos graficar la relación entre el logaritmo del salario por hora y escolaridad estimada según el modelo, separando entre hombres y mujeres:


```

sum experiencia if e(sample)
scalar mexp=r(mean)
g pred_mujer=_b[_cons]+_b[esc04]*esc04+_b[experiencia]*mexp
g pred_hombre=_b[_cons]+_b[esc04]*esc04+_b[experiencia]*mexp+_b[sexo]

twoway (connected pred_hombre esc04 if sexo==1, msize(small)),
      title(Relación entre escolaridad y valor predicho del salario por hora)
      subtitle(Diferencias por género) ||
      (connected pred_mujer esc04 if sexo==0, msize(small))

```

Gráfico 4.1



Supongamos otro ejemplo donde el logaritmo del salario por hora se estima en función de los años de escolaridad, experiencia, y se quiere introducir la categoría ocupacional del trabajador, para esto se dispone de una variable con tres categorías: independiente, dependiente sin contrato, y dependiente con contrato. Como la variable tiene tres categorías, se deben definir dos variables dummies que serán introducidas en el modelo las cuales se interpretaran en función de la categoría base. Se pueden definir las siguientes dummies:

$$DC = \begin{cases} 1 & \text{Dependiente con contrato} \\ 0 & \text{sino} \end{cases} \quad DSC = \begin{cases} 1 & \text{Dependiente sin contrato} \\ 0 & \text{sino} \end{cases}$$

De esta forma, la categoría base son los cuenta propia. Así, el modelo estimado sería el siguiente:

$$lyph = \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_4 \cdot DC + \beta_5 DSC + u$$

El coeficiente β_4 corresponde a la diferencia en el valor esperado del logaritmo del salario por hora entre los dependientes con contrato y los trabajadores por cuenta propia, y el coeficiente β_5 a la diferencia entre los dependientes sin contrato y los trabajadores por cuenta propia, esto se puede notar al tomar valor esperado del modelo condicional en las tres categorías de la variable explicativa:

$$\begin{aligned} E[lyph|cuentapropia, esc, experiencia] &= \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia \\ E[lyph|dependienteconcontrato, esc, experiencia] &= \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_4 \\ E[lyph|dependientesincontrato, esc, experiencia] &= \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_5 \end{aligned}$$

Por otra parte, las variables dummies también pueden ser interactuadas con variables continuas, esta interacción permite estimar un efecto marginal de la variable explicativa continua sobre la variable dependiente diferente para la categorías de la variable dummy. Por ejemplo, podríamos estimar el siguiente modelo para obtener una estimación del retorno a la educación diferenciado entre hombres y mujeres:

$$lyph = \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_4 \cdot sexo + \beta_5 \cdot sexo \cdot esc$$

En este modelo el salario esperado para los hombres es:

$$E[lyph|hombre, esc, experiencia] = \beta_1 + \beta_4 + (\beta_2 + \beta_5) \cdot esc + \beta_3 \cdot experiencia$$

En este modelo el salario esperado para las mujeres es:

$$E[lyph|mujer, esc, experiencia] = \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia$$

Notemos que existe una diferencia en intercepto, pero también existe una diferencia en el efecto marginal de los años de escolaridad sobre el logaritmo del salario por hora, es decir, en el retorno a la educación.

El retorno a la educación para los hombres según el modelo es:

$$\frac{\partial E[lyph|hombre, esc, experiencia]}{\partial esc} = \beta_2 + \beta_5$$

El retorno a la educación para las mujeres según el modelo es:

$$\frac{\partial E[lyph|mujer, esc, experiencia]}{\partial esc} = \beta_2$$

Así, en este modelo β_2 (coeficiente que acompaña a la variable escolaridad sin interacción) corresponde al retorno a la educación de las mujeres (categoría base) y β_5 corresponde a la **diferencia** en retorno a la educación de los hombres con respecto a las mujeres.

El Cuadro 4.10 se muestra la estimación del modelo con retornos a la educación diferenciados entre hombres y mujeres, primero debemos generar la variables interactuadas:

```
g sexo_esc=sexo*esc04
```

Cuadro 4.10

Estimación Retorno a la Educación diferenciado por género


<pre>. reg lph esc experiencia sexo sexo_esc [pw=factor] (sum of wgt is 2.9721e+06)</pre>						
Linear regression				Number of obs = 4727 F(4, 4722) = 214.92 Prob > F = 0.0000 R-squared = 0.2758 Root MSE = .5795		
lph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
esc04	.1290327	.0065549	19.68	0.000	.1161821	.1418833
experiencia	.0008964	.0001387	6.46	0.000	.0006244	.0011684
sexo	.4326887	.0977668	4.43	0.000	.2410202	.6243573
sexo_esc	-.0213026	.0081509	-2.61	0.009	-.0372821	-.005323
_cons	5.142357	.0835223	61.57	0.000	4.978614	5.3061

La estimación del modelo nos muestra que el retorno a la educación de las mujeres es 12.9 % y el de los hombres 2.13 % menor. A partir del modelo estimado podemos graficar la relación entre logaritmo del salario por hora y escolaridad manteniendo constante el nivel de experiencia y separando por género:

```
g pred_hombre2=_b[_cons]+(_b[esc04]+_b[sexo_esc])*esc04+_b[experiencia]*mexp+_b[sexo]
g pred_mujer2=_b[_cons]+_b[esc04]*esc04+_b[experiencia]*mexp
twoway (connected pred_hombre2 esc04 if sexo==1, msize(small)),
  title(Relación entre escolaridad y valor predicho del salario por hora)
  subtitle(Diferencias por género)
|| (connected pred_mujer2 esc04 if sexo==0, msize(small))
```

Gráfico 4.2

Relación entre escolaridad y valor predicho del salario por hora
Diferencias por género



Es importante aclarar que al incluir una variable continua interactuada con una variable dummy se deben incluir siempre las variables involucradas sin interactuar.

EL Cuadro 4.11 muestra la comparación del modelo de retornos a la educación sin controlar por género, el modelo controlando por un efecto nivel en género, y el modelo controlando por un efecto nivel y retorno a la educación diferenciado por género. Este cuadro se obtiene a través de los siguientes comandos:

```
reg lyph esc experiencia sexo [pw=factor]
estimates store modelo6
reg lyph esc experiencia sexo sexo_esc [pw=factor]
estimates store modelo7
estimates table modelo1 modelo6 modelo7, stat(r2_a, rmse) b(%7.3g) p(%4.3f)
```

Cuadro 4.11
Estimación Retorno a la Educación diferenciado por género

variable	modelo1	modelo6	modelo7
esc04	.113 0.000	.115 0.000	.129 0.000
experiencia	.00115 0.000	.00095 0.000	.0009 0.000
sexo		.175 0.000	.433 0.000
sexo_esc			-.0213 0.009
_cons	5.42 0.000	5.31 0.000	5.14 0.000
r2_a	.258	.273	.275
rmse	.586	.58	.58
Legend: b/p			

Las variables dummies también nos permiten estimar efectos umbrales, por ejemplo, en el caso de educación puede ser más interesantes ver el efecto sobre salarios de completar cada nivel educacional que un efecto promedio por cada año de escolaridad adicional. Para esto primero definamos una variable categórica con el nivel educacional logrado por cada persona:

```
g nivel=1 if esc04<8
replace nivel=2 if esc04>=8 & esc04<12
replace nivel=3 if esc04>=12 & esc04<17
replace nivel=4 if esc04>=17

label define nivellbl 1 "Ninguna" 2 "Básica Completa"
3 "Media Completa" 4 "Universitaria Completa"
label values nivel nivellbl
```

La variable `nivel` recién creada tiene 4 categorías de nivel educacional, por lo cuál a partir de ella se pueden generar 4 variables dummies, una para cada nivel educacional pero una de ellas debe ser excluida del modelo la que será la categoría base y la interpretación de los coeficientes que acompañan a las dummies incluidas en el modelo será en función de esta categoría base. El comando `tabulate` de STATA con la opción `generate` generan automáticamente las variables dummies:

```
tab nivel, generate(DE_)
```

Este comando genera automáticamente 4 variables binarias definidas de la siguiente forma:

$$DE_1 = \begin{cases} 1 & \text{si nivel=ninguna} \\ 0 & \text{sino} \end{cases} \quad DE_2 = \begin{cases} 1 & \text{si nivel=Básica} \\ 0 & \text{sino} \end{cases}$$

$$DE_3 = \begin{cases} 1 & \text{si nivel=Media} \\ 0 & \text{sino} \end{cases} \quad DE_4 = \begin{cases} 1 & \text{si nivel=Universitaria} \\ 0 & \text{sino} \end{cases}$$

Así, para estimar el efecto umbral sobre salarios se debe estimar el siguiente modelo:

$$lyph = \beta_1 + \beta_2 \cdot experiencia + \beta_3 \cdot sexo + \beta_4 \cdot DE_2 + \beta_5 \cdot DE_3 + \beta_6 \cdot DE_4 + u$$

El Cuadro 4.12 muestra la estimación de este modelo, se obtiene que completar la educación básica aumenta en promedio 17 % el salario, completar educación media versus no tener educación incrementa el salario en 58.2 %, y completar educación universitaria versus no tener educación incrementa el salario en promedio un 150,7 %. La diferencia entre β_5 y β_4 corresponde al retorno de tener educación media completa versus básica completa, y la diferencia entre β_6 y β_7 corresponde al retorno de tener educación media completa versus educación media completa.

Cuadro 4.12

Estimación Efectos Umbrales Educación sobre Salarios

<pre>. reg lyph experiencia sexo DE_2-DE_4 [pw=factor] (sum of wgt is 2.9792e+06)</pre>						
Linear regression			Number of obs = 4740 F(5, 4734) = 176.50 Prob > F = 0.0000 R-squared = 0.2276 Root MSE = .59813			
lyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
experiencia	.0007516	.0001369	5.49	0.000	.0004833	.0010199
sexo	.1671182	.0215284	7.76	0.000	.1249124	.2093239
DE_2	.1696814	.0378266	4.49	0.000	.0955237	.2438392
DE_3	.5822595	.0325504	17.89	0.000	.5184456	.6460733
DE_4	1.507881	.0578608	26.06	0.000	1.394447	1.621316
_cons	6.158615	.0382947	160.82	0.000	6.08354	6.23369

Esta misma estimación se puede utilizar a través del siguiente comando que crea automáticamente las variables dummies en la regresión:

Cuadro 4.13
Estimación Efectos Umbrales Educación sobre Salarios



<pre>. xi: reg ltyph experiencia sexo i.nivel [pw=factor] i.nivel _Inivel_1-4 (naturally coded; _Inivel_1 omitted) (sum of wgt is 2.9792e+06)</pre>						
Linear regression			Number of obs = 4740 F(5, 4734) = 176.50 Prob > F = 0.0000 R-squared = 0.2276 Root MSE = .59813			
typh	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
experiencia	.0007516	.0001369	5.49	0.000	.0004833	.0010199
sexo	.1671182	.0215284	7.76	0.000	.1249124	.2093239
_Inivel_2	.1696814	.0378266	4.49	0.000	.0955237	.2438392
_Inivel_3	.5822595	.0325504	17.89	0.000	.5184456	.6460733
_Inivel_4	1.507881	.0578608	26.06	0.000	1.394447	1.621316
_cons	6.158615	.0382947	160.82	0.000	6.08354	6.23369

Una vez estimado el modelo podemos graficar la relación entre escolaridad y salarios de acuerdo al modelo estimado, para esto debemos generar las siguientes variables con la predicción del modelo:

```
sum experiencia if e(sample)
scalar mexp=r(mean)
g pred_ningunaH=_b[_cons]+_b[experiencia]*mexp+_b[sexo]
g pred_ningunaM=_b[_cons]+_b[experiencia]*mexp
g pred_basicaH=_b[_cons]+_b[experiencia]*mexp+_b[sexo]+_b[DE_2]
g pred_basicaM=_b[_cons]+_b[experiencia]*mexp+_b[DE_2]
g pred_mediaH=_b[_cons]+_b[experiencia]*mexp+_b[sexo]+_b[DE_3]
g pred_mediaM=_b[_cons]+_b[experiencia]*mexp+_b[DE_3]
g pred_univH=_b[_cons]+_b[experiencia]*mexp+_b[sexo]+_b[DE_4]
g pred_univM=_b[_cons]+_b[experiencia]*mexp+_b[DE_4]

twoway (connected pred_ningunaH esc04 if sexo==1 & nivel==1, msize(small)),
       title(Relación entre escolaridad y valor predicho del salario por hora)
       subtitle(Efectos Umbrales Hombres) ||
       (connected pred_basicaH esc04 if sexo==1 & nivel==2, msize(small)) ||
       (connected pred_mediaH esc04 if sexo==1 & nivel==3, msize(small)) ||
       (connected pred_univH esc04 if sexo==1 & nivel==4, msize(small))
```

El Gráfico 4.3 muestra el resultado para los hombres y el gráfico 4.4 para las mujeres.



El modelo anterior tiene como hipótesis que sólo entrega retorno, en términos de salario por hora, completar los diferentes niveles educativos, pero que al inte-

rior de cada nivel avanzar en años de escolaridad no significa un retorno adicional. Para poder estimar retornos a la educación diferenciados entre los niveles educacionales se deben interactuar las dummies de nivel educacional con la variable años de escolaridad. Para esto primero generamos las variables con las interacciones entre las dummies de nivel educacional y la variable de años de escolaridad, recuerde que en el modelo se deben incluir además las variables sin interactuar:

```
g DE2_esc=DE_2*esc04
g DE3_esc=DE_3*esc04
g DE4_esc=DE_4*esc04
```

El Cuadro 4.14 muestra la estimación de este modelo, y el Gráfico 4.5 la relación estimada entre años de escolaridad y logaritmo del salario por hora para los hombres.

Cuadro 4.14

Estimación retorno a la educación diferenciado por nivel educacional

. reg lyp ^h experiencia sexo esc DE_2-DE_4 DE2_esc- DE4_esc [pw=factor] (sum of wgt is 2.9721e+06)						
Linear regression				Number of obs = 4727		
				F(9, 4717) = 137.05		
				Prob > F = 0.0000		
				R-squared = 0.3304		
				Root MSE = .55753		
lyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
experiencia	.0009688	.0001314	7.37	0.000	.0007112	.0012265
sexo	.1738134	.0197108	8.82	0.000	.1351709	.2124558
esc04	.0358678	.021469	1.67	0.095	-.0062215	.0779572
DE_2	-.4999872	.2348012	-2.13	0.033	-.9603072	-.0396672
DE_3	-1.578178	.1759646	-8.97	0.000	-1.923151	-1.233205
DE_4	-1.621478	1.213839	-1.34	0.182	-4.00117	.758214
DE2_esc	.0636711	.0316845	2.01	0.045	.0015546	.1257876
DE3_esc	.1480502	.0238169	6.22	0.000	.101358	.1947424
DE4_esc	.1592897	.0734456	2.17	0.030	.015302	.3032774
_cons	5.938939	.1221939	48.60	0.000	5.699382	6.178496


La estimación del modelo nos muestra que el retorno a los años de escolaridad para las personas con un nivel educación inferior a básica completa es 3.6 %, el retorno a la educación para las personas con educación básica completa pero media incompleta es un 10 % (3.6 % +6.4 %), el retorno a la educación para las personas con educación media completa pero sin educación superior completa es 18.4 %

(3.6 % + 14.8 %), y el retorno a la educación de las personas con educación universitaria completa es 19.5 % (3.6 % + 15.9 %).

Para obtener el gráfico con la relación entre escolaridad y logaritmo del salario por hora estimada según el modelo se deben ejecutar los siguientes comandos:

```
g pred_ningunaH_esc=_b[_cons]+_b[experiencia]*mexp+_b[sexo]+_b[esc]
g pred_basicaH_esc=_b[_cons]+_b[experiencia]*mexp+_b[sexo]+_b[esc04]*esc04
+_b[DE_2]+_b[DE2_esc]*esc04
g pred_mediaH_esc=_b[_cons]+_b[experiencia]*mexp+_b[sexo]+_b[esc04]*esc04
+_b[DE_3]+_b[DE3_esc]*esc04
g pred_univH_esc=_b[_cons]+_b[experiencia]*mexp+_b[sexo]+_b[esc04]*esc04
+_b[DE_4]+_b[DE4_esc]*esc04
twoway (connected pred_ningunaH_esc esc04 if sexo==1 & nivel==1, msize(small)),
title(Relación entre escolaridad y valor predicho del salario por hora)
subtitle(Efectos Umbrales Hombres) ||
(connected pred_basicaH_esc esc04 if sexo==1 & nivel==2, msize(small)) ||
(connected pred_mediaH_esc esc04 if sexo==1 & nivel==3, msize(small)) ||
(connected pred_univH_esc esc04 if sexo==1 & nivel==4, msize(small))
```

Gráfico 4.5



4.5. Test de No Linealidades Omitidas

El estimador MCO asume que la relación entre la variable dependiente y la(s) variable(s) explicativa(s) es lineal. Sin embargo, en algunos casos esta relación es no lineal, y la estimación lineal se comportará relativamente bien para ciertos valores de las variables pero para otros no. La omisión de no linealidades genera un problema de especificación equivalente a la omisión variables relevantes, que se puede solucionar incorporando potencias de las variables explicativas al modelo de regresión lineal.

El comando post-estimación `estat ovtest` computa el test RESET de omisión de no linealidades. La idea de este test es bastante simple, el test RESET hace una nueva regresión aumentada donde incluye los regresores originales y además potencias de los valores predichos a través de la especificación original:

$$Y_i = X\beta + \varphi_1 \cdot \hat{Y}_i^2 + \varphi_2 \cdot \hat{Y}_i^3 + \varphi_3 \cdot \hat{Y}_i^4 + \varepsilon$$

La hipótesis nula es que no existen problemas de especificación, es decir, que no existen no linealidades omitidas. Para testear esta hipótesis se hace un test de hipótesis conjunta de que todos los coeficientes de las potencias del valor predicho de la variable dependiente son cero. Si no se puede rechazar la hipótesis nula, los coeficientes asociados a las potencias incluidas en la especificación aumentada son iguales a cero. El Cuadro 4.15 muestra como obtener el test de no linealidad omitidas para el modelo donde se incluyen la variable años de escolaridad sin distinguir entre los niveles educacionales, y el Cuadro 4.16 el test aplicado al modelo que estima retornos a la educación diferenciados por nivel educacional, en el primer caso se rechaza la hipótesis nula de que el modelo no tiene no linealidades omitidas, y en el segundo caso no se puede rechazar la hipótesis nula, es decir, la incorporación de la interacción entre dummies y escolaridad permite capturar la no linealidad.

Cuadro 4.15
Test de No Linealidades Omitidas

```
. reg lyph experiencia sexo esc[pw=factor]
(sum of wgt is 2.9721e+06)
```

Linear regression

	Number of obs = 4727
	F(3, 4723) = 284.34
	Prob > F = 0.0000
	R-squared = 0.2736
	Root MSE = .58029

lyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]
experiencia	.0009495	.0001377	6.90	0.000	.0006796 .0012194
sexo	.175023	.0206795	8.46	0.000	.1344816 .2155644
esc04	.11531	.0039659	29.08	0.000	.107535 .123085
_cons	5.305846	.0560166	94.72	0.000	5.196027 5.415665

```
. estat ovtest
```

Ramsey RESET test using powers of the fitted values of lyph
Ho: model has no omitted variables
F(3, 4720) = **62.12**
Prob > F = **0.0000**

Cuadro 4.16
Test de No Linealidades Omitidas

<pre>. reg lypb experiencia sexo esc DE_2-DE_4 DE2_esc- DE4_esc [pw=factor] (sum of wgt is 2.9721e+06)</pre>						
Linear regression			Number of obs = 4727 F(9, 4717) = 137.05 Prob > F = 0.0000 R-squared = 0.3304 Root MSE = .55753			
lypb	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
experiencia	.0009688	.0001314	7.37	0.000	.0007112	.0012265
sexo	.1738134	.0197108	8.82	0.000	.1351709	.2124558
esc04	.0358678	.021469	1.67	0.095	-.0062215	.0779572
DE_2	-.4999872	.2348012	-2.13	0.033	-.9603072	-.0396672
DE_3	-1.578178	.1759646	-8.97	0.000	-1.923151	-1.233205
DE_4	-1.621478	1.213839	-1.34	0.182	-4.00117	.758214
DE2_esc	.0636711	.0316845	2.01	0.045	.0015546	.1257876
DE3_esc	.1480502	.0238169	6.22	0.000	.101358	.1947424
DE4_esc	.1592897	.0734456	2.17	0.030	.015302	.3032774
_cons	5.938939	.1221939	48.60	0.000	5.699382	6.178496
<pre>. estat ovtest</pre>						
Ramsey RESET test using powers of the fitted values of lypb Ho: model has no omitted variables F(3, 4714) = 1.26 Prob > F = 0.2881						


4.6. Heterocedasticidad

En datos de corte transversal el problema de heterocedasticidad es bastante común. La heterocedasticidad se produce cuando la varianza del error difiere para distintos valores de la(s) variable(s) explicativa(s). Por ejemplo, para niveles bajos de escolaridad la varianza en el logaritmo del salario por hora es más baja que para niveles de escolaridad más elevados.

La presencia de heterocedasticidad no genera problemas de sesgo en el estimador MCO, es decir, se sigue cumpliendo la propiedad de insesgamiento de este estimador:

$$E[\hat{\beta}] = \beta$$

Gráfico 4.6



Pero, al tener los errores una varianza no constante, la matriz de varianzas y covarianzas del estimar MCO deja de ser la mínima o la más eficiente. La varianza de los coeficientes estimados es mayor, por lo cual toda inferencia basada en la varianza MCO es incorrecta, los estadísticos t se están computando con una varianza menor a la que se debería, por lo tanto son mayores y existe mayor probabilidad de rechazar la hipótesis nula cuando esta no debería ser rechazada. Es decir, la significancia de los parámetros se puede ver afectada, mostrando significancia cuando en realidad no la hay.

Para solucionar el problema de heterocedasticidad se debe conocer el patrón de heterocedasticidad o que variables generan el problema, ya que el estimar MCG o MCF tienen como espíritu “quitar” la heterocedasticidad de las variables explicativas y dependiente, mediante una transformación que consiste en dividir cada observación de la variable dependiente y las variables explicativas por la desviación estándar del error asociado a esa observación. Y luego aplicando MCO a este modelo transformado se obtiene una estimación insesgada y eficiente que cumple con la propiedad MELI (Mejor Estimador Lineal e Insesgado).

La transformación de las variables es la siguiente:

$$\begin{array}{c} \frac{y_1}{\sigma_1}, \frac{x_{11}}{\sigma_1}, \dots, \frac{x_{k1}}{\sigma_1} \\ \frac{y_2}{\sigma_2}, \frac{x_{12}}{\sigma_2}, \dots, \frac{x_{k2}}{\sigma_2} \\ \vdots \\ \frac{y_N}{\sigma_N}, \frac{x_{1N}}{\sigma_N}, \dots, \frac{x_{kN}}{\sigma_N} \end{array}$$

Después de realizar la estimación del modelo en STATA el comando `estat hettest` permite testear la presencia de heterocedasticidad. La hipótesis nula de este test es la homocedasticidad del error. Este comando computa el test de heterocedasticidad de Breusch-Pagan (BP) el que consiste en un test de Wald a la hipótesis nula de que las variables explicativas del modelo original no son significativas en explicar el comportamiento del término de error estimado al cuadrado, para esto se estima una regresión auxiliar del error estimado al cuadrado en función de las variables explicativas originales del modelo. El Cuadro 4.17 muestra la aplicación de este test al modelo de retorno a la educación.

Cuadro 4.17
Test de Heterocedasticidad

. reg lypb experiencia sexo esc						
Source	SS	df	MS			
Model	521.242942	3	173.747647	Number of obs = 4727		
Residual	1469.03962	4723	.311039513	F(3, 4723) = 558.60		
Total	1990.28256	4726	.421134694	Prob > F = 0.0000		
				R-squared = 0.2619		
				Adj R-squared = 0.2614		
				Root MSE = .55771		
lypb	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
experiencia	.0009296	.0001107	8.40	0.000	.0007126	.0011465
sexo	.1705728	.0171898	9.92	0.000	.1368727	.2042728
esc04	.1072802	.002648	40.51	0.000	.1020889	.1124714
_cons	5.386591	.0391023	137.76	0.000	5.309932	5.463249
. estat hettest						
Breusch-Pagan / Cook-Weisberg test for heteroskedasticity						
Ho: Constant variance						
Variables: fitted values of lypb						
chi2(1)	=	34.31				
Prob > chi2	=	0.0000				

De este test podemos concluir que se rechaza la hipótesis nula de homocedasticidad.

Para poder solucionar el problema y obtener una estimación insesgada y eficiente a través de la metodología de Mínimos Cuadrados Generalizados (MCG) o Mínimos Cuadrados Factibles (MCF) es necesario conocer el patrón de Heterocedasticidad, es decir, conocer la verdadera matriz de varianzas y covarianzas del término de error, conocer las desviaciones estándar de cada error para poder realizar la transformación. Esto en la práctica es poco probable.

La solución más sensata es la planteada por White, que consiste en quedarse con la estimación menos eficiente pero insesgada de MCO, pero estimar el forma correcta la matriz de varianzas y covarianzas de los coeficientes estimados, de forma tal de que los test de hipótesis y la inferencia este realizada en forma apropiada. Esto se hace en STATA simplemente introduciendo la opción **robust** al comando `regress`.

A continuación vemos las diferencias entre la estimación del modelo de retorno a la educación sin corregir por heterocedasticidad y utilizando la opción **robust** que estima la matriz correcta de varianzas y covarianzas del estimador MCO en presencia de heterocedasticidad:

```
reg lyph experiencia sexo esc
estimates store modelosr
reg lyph experiencia sexo esc, r
estimates store modelocr
estimates table modelosr modelocr, stat(r2_a, rmse) b(%7.3g) se(%7.4f)
```

El Cuadro 4.18 presenta la comparación de ambos modelos, de la cual podemos notar lo siguiente:

- Los coeficientes estimados son exactamente iguales.
- La bondad de ajuste del modelo tampoco se ve afectada
- Las varianzas estimadas de los coeficientes son mayores en el modelo que incorpora la presencia de heteroscedasticidad, confirmando lo que los test estadísticos BP y White indicaban sobre la presencia de este problema.

En resumen, siempre utilice la opción **robust** del comando `regress` de stata. Si existe el problema de Heterocedasticidad, con esta opción Ud. estará seguro de

que los test estadísticos son correctos y así las conclusiones sobre la significancia de los parámetros. Si es que no hay Heterocedasticidad, obtendrá exactamente el mismo resultado que sin ocupar esta opción, ya que sin Heterocedasticidad la matriz de varianzas y covarianzas robusta (o de White), en este caso, sería la misma que la del estimador MCO.

Cuadro 4.18
Estimación Retorno a la Educación Robusta

variable	model~r	model~r
experiencia	.00093 0.0001	.00093 0.0001
sexo	.171 0.0172	.171 0.0171
esc04	.107 0.0026	.107 0.0031
_cons	5.39 0.0391	5.39 0.0439
r2_a	.261	.261
rmse	.558	.558
Legend: b/se		

4.7. Selección de Modelos

Al final de día puede que más de un modelo satisfaga todos los requerimientos teóricos y econométricos, pero Ud. deberá escoger sólo uno de estos modelos para poder concluir, hacer predicciones y tomar decisiones de política.

Los modelos sobre los cuales tiene que elegir pueden estar anidados o no. Se dice que dos modelos están anidados cuando uno de ellos corresponde al anterior imponiendo cierta restricciones sobre los parámetros.

4.7.1. Selección entre modelos anidados

Los criterios de información de Akaike (AIC) y Schwarz (BIC) son medidas consistentes para ver el mejor modelo. El mejor modelo es aquel que tiene menor valor del criterio de información.

Volvamos al modelo de retornos a la educación diferenciados por nivel educacional, y suponga que queremos ver si este modelo es mejor que uno exactamente igual pero incluyendo la variable estatura que en especificaciones anteriores había resultado estadísticamente significativa. El modelo más grande (en cuanto a variables incluidas) es el siguiente:

Cuadro 4.19
Estimación Retorno a la Educación por Nivel

<pre>. reg lphph experiencia sexo esc DE_2-DE_4 DE2_esc- DE4_esc estatura [pw=factor] (sum of wgt is 2.9240e+06)</pre>						
Linear regression			Number of obs = 4649 F(10, 4638) = 124.55 Prob > F = 0.0000 R-squared = 0.3376 Root MSE = .55441			
lphph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
experiencia	.0010616	.000132	8.04	0.000	.0008027	.0013204
sexo	.0822528	.0251359	3.27	0.001	.0329746	.1315311
esc04	.038609	.0215929	1.79	0.074	-.0037234	.0809414
DE_2	-.4919427	.2392868	-2.06	0.040	-.9610586	-.0228268
DE_3	-1.53227	.1749792	-8.76	0.000	-1.875312	-1.189227
DE_4	-2.115875	1.308886	-1.62	0.106	-4.681915	.4501641
DE2_esc	.0601242	.032204	1.87	0.062	-.0030109	.1232594
DE3_esc	.1409689	.0238407	5.91	0.000	.0942299	.187708
DE4_esc	.1841626	.0788796	2.33	0.020	.0295212	.3388041
estatura	.0077458	.0013685	5.66	0.000	.0050628	.0104288
_cons	4.699682	.2542921	18.48	0.000	4.201148	5.198215
. estimates stats						
Model	obs	ll(null)	ll(model)	df	AIC	BIC
.	4649	-4806.205	-3848.927	11	7719.854	7790.742
Note: N=Obs used in calculating BIC; see [R] BIC note						

Vemos que al aplicar el comando post-estimación `estimates stats` luego de estimar el modelo, podemos obtener los criterios de información. Estos números por si mismos no tienen ninguna interpretación ni relevancia sólo sirven para comparar dos o más modelos anidados. El Cuadro 4.20 muestra la estimación del modelo anterior excluyendo la variable estatura y sus respectivos criterios de información. El modelo con estatura tienen menor criterio de información por lo cual este modelo es mejor para explicar el logaritmo del salario por hora.

Los criterios combinan el ajuste del modelo con lo parsimonioso del mismo, es decir, dos modelos con igual poder explicativo pero uno con menos variables que

el otro, el criterio nos va indicar que escojamos el modelo con menos variables. Los criterios de información son medidas de selección de modelos más consistentes que el R^2 y R^2 ajustado, y entre los dos criterios el Bayesiano (BIC) es más consistente.

Cuadro 4.20
Estimación Retorno a la Educación por Nivel

<pre>. reg lyph experiencia sexo esc DE_2-DE_4 DE2_esc- DE4_esc [pw=factor] (sum of wgt is 2.9721e+06)</pre>						
Linear regression				Number of obs = 4727 F(9, 4717) = 137.05 Prob > F = 0.0000 R-squared = 0.3304 Root MSE = .55753		
lyph	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
experiencia	.0009688	.0001314	7.37	0.000	.0007112	.0012265
sexo	.1738134	.0197108	8.82	0.000	.1351709	.2124558
esc04	.0358678	.021469	1.67	0.095	-.0062215	.0779572
DE_2	-.4999872	.2348012	-2.13	0.033	-.9603072	-.0396672
DE_3	-1.578178	.1759646	-8.97	0.000	-1.923151	-1.233205
DE_4	-1.621478	1.213839	-1.34	0.182	-4.00117	.758214
DE2_esc	.0636711	.0316845	2.01	0.045	.0015546	.1257876
DE3_esc	.1480502	.0238169	6.22	0.000	.101358	.1947424
DE4_esc	.1592897	.0734456	2.17	0.030	.015302	.3032774
_cons	5.938939	.1221939	48.60	0.000	5.699382	6.178496
. estimates stats						
Model	obs	ll(null)	ll(model)	df	AIC	BIC
.	4727	-4888.381	-3940.605	10	7901.21	7965.82
Note: N=Obs used in calculating BIC; see [R] BIC note						

4.7.2. Selección de modelos no anidados

Cuando estamos interesados en comparar modelos que son diferentes en cuanto a las variables que incluyen, es decir, modelos que no están anidados, no se pueden utilizar los criterios de información. Suponga que estamos interesados en evaluar cual de los siguientes dos modelos es mejor para explicar el comportamiento del logaritmo del salario por hora:

$$\begin{aligned}
 lyph &= \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_4 \cdot sexo + \beta_5 \cdot sexo \cdot esc + u \\
 lyph &= \beta_1 + \beta_2 \cdot esc + \beta_3 \cdot experiencia + \beta_4 \cdot sexo + \beta_5 \cdot DE_2 + \beta_6 \cdot DE_3 \\
 &+ \beta_7 \cdot DE_4 + \beta_8 \cdot DE_2 \cdot esc + \beta_9 \cdot DE_3 \cdot esc + \beta_{10} \cdot DE_4 \cdot esc + u
 \end{aligned}$$

¿Cómo escogemos entre el modelo (1), que estima un retorno a la educación diferenciado por sexo pero igual para todos los niveles educacionales, y el modelo (2) que estima un retorno diferenciado por nivel educacional?

Davidson y MacKinnon (1981) propusieron el test J para poder seleccionar entre modelos no anidados. Este test consiste definir uno de los modelos como aquel bajo la hipótesis nula y el otro como bajo la alternativa, se estiman ambos modelos y se obtiene el valor predicho de la variable dependiente, luego el valor predicho con el modelo de la hipótesis alternativa se incluye como variable explicativa del modelo bajo la hipótesis nula, y se testea la significancia estadística de esta nueva variable, si es estadísticamente significativa se rechaza el modelo de la hipótesis nula. Luego se invierten los modelos definidos bajo la hipótesis nula y se repite el procedimiento. Se pueden dar cuatro soluciones:

1. Se rechaza el modelo (1) y no el modelo (2)
2. Se rechaza el modelo (2) y no el modelo (1)
3. Se rechazan ambos modelos
4. No se puede rechazar ninguno de los dos modelos

Sólo en los primeros dos casos el test J nos permite concluir sobre el modelo que debemos preferir.

El comando para realizar este test no viene en STATA pero puede ser instalado ejecutando el siguiente comando: `ssc install nnest`. La ejecución de este comando sobre los dos modelos anteriores se debe realizar de la siguiente forma:

```
reg lyph experiencia sexo esc DE_2-DE_4 DE2_esc- DE4_esc estatura [pw=factor]
nnest lyph esc04 experiencia estatura sexo sexo_esc
```

El comando nos entrega dos resultados, el del test J de Davidson y MacKinnon y el del test de Cox-Pearson, que es bastante similar. El resultado se presenta a continuación:

Cuadro 4.21
Test J de modelos no anidados

Competing Models			

M1 : Y =	[lyph]		
X =	[experiencia sexo esc04 DE_2 DE_3 DE_4 DE2_esc DE3_esc DE4_esc]		
M2 : Y =	[lyph]		
Z =	[lyph esc04 experiencia sexo sexo_esc]		

J test for non-nested models			

	Dist	Stat	P> Stat
H0:M1 / H1:M2	t(4716)	7.4e+15	0.000
H0:M2 / H1:M1	t(4720)	-13.51	0.000

Cox-Pesaran test for non-nested models			

	Dist	Stat	P> Stat
H0:M1 / H1:M2	N(0,1)	.	.
H0:M2 / H1:M1	N(0,1)	.	.

En este caso el test no nos permite concluir sobre ninguno de los modelos.

Capítulo 5

Estimador de Variables Instrumentales

5.1. Introducción

Uno de los supuestos claves para que el estimador MCO sea insesgado es que el término de error no debe estar correlacionado con las variables explicativas o regresores del modelo:

$$\text{cov}(u_i, X_i) = 0$$

Existen tres situaciones en la que se puede invalidar este supuesto:


- Omisión de variables relevantes
- Simultaneidad o doble causalidad
- Error de medición

A pesar de que estos problemas son generados por diferentes razones, el problema es el mismo: endogeneidad; y la solución se llama **Estimador de Variables Instrumentales (IV)**.


Supongamos el siguiente modelo de regresión lineal simple:

$$y = \beta x + u$$

Donde por ejemplo, y mide el ingreso, x los años de escolaridad, y u representa el término de error del modelo. El estimador MCO asume que x no está correlacionado con u , luego mide el único efecto marginal que tiene x sobre y , y el estimador MCO es consistente.




Recordemos que el término de error captura todas las otras variables (no observables) que afectan los ingresos, en este ejemplo, una de estas variables es la habilidad. Entonces, en la medida que exista correlación entre habilidad ya años de escolaridad, el error del modelo no será exógeno a la variable explicativa.



Luego, el estimador MCO de β será inconsistente ya que combina el efecto directo de años de escolaridad sobre ingresos y el efecto indirecto de años de escolaridad sobre habilidad y luego sobre ingresos. En este caso la variable explicativa se dice que es endógena.

Una solución obvia al problema de endogeneidad es incluir variables explicativas que controlen por la habilidad de la persona, esta metodología se llama **control-function**. Pero muchas veces esas variables no estarán disponibles, en estos casos el **estimador de variables instrumentales** ofrece una solución para obtener un estimador consistente, este estimador técnicamente muy fácil de implementar pero conceptualmente es bastante complejo.

Para poder aplicar este método se requiere de una variable adicional, denominada **instrumento** y que denotaremos por z . Esta variable tiene la característica de estar muy relacionada con la variable endógena (x), pero no está correlacionada con el error.



Para entender cómo funciona el estimador IV, pensemos que una de las variables explicativas está compuesta por una parte que está correlacionada con el error (por cualquiera de las tres razones antes mencionadas), y otra parte que no está correlacionada con el error. Si se tiene información suficiente para aislar la segunda parte de la variable, luego nos podemos enfocar en cómo la variación en esta parte de la variable explicativa afecta la variación de la variable dependiente. De esta forma, se elimina el sesgo en la estimación MCO considerando sólo la parte de la variable explicativa que no está correlacionada con el error. Esto es exactamente lo que hace el estimador de variables instrumentales. La información sobre los movimientos de la variable explicativa que no están correlacionados con el término de error se captura a través de una o más variables instrumentales.

En resumen, la regresión por variables instrumentales usa estas variables como herramientas o “instrumentos” para aislar del comportamiento de la variable explicativa la parte no correlacionada con el término de error, lo que permite una estimación consistente de los coeficientes de regresión.

5.2. Simultaneidad

El estimador MCO asume que la causalidad es en un sentido, de la variable explicativa a la variable dependiente. Pero la causalidad podría, en algunos casos, también funcionar en ambos sentidos. Por ejemplo, generalmente en el modelo de la ecuación de Mincer se asume que la escolaridad afecta el nivel de ingresos, pero la relación entre estas variables también podría ser inversa, el nivel de ingresos determina el nivel de educación. Otro ejemplo es el relacionado con el tamaño de los cursos (o número de alumnos por profesor) y los resultados académicos (prueba SIMCE), en general, se asume que la causalidad es en el sentido de que cursos más pequeños tienen mejores logros educativos, pero se podría esperar también una relación inversa, mientras menores son los logros el gobierno entrega mayores recursos y menor es el número de alumnos por profesor. En ambos casos se dice que la variable explicativa, años de escolaridad o número de alumnos por

profesor, es endógena.

$$\begin{aligned} Y_i &= \beta X_i + u_i \\ X_i &= \varphi Y_i + v_i \end{aligned}$$

Veamos que sucede cuando hay simultaneidad de la variable explicativa. Supongamos que para un individuo cualquiera el término de error es negativo, es decir, el valor puntual de la variable dependiente está por debajo del valor estimado, es decir, un valor negativo de u_i disminuye el valor de Y_i . En la segunda ecuación si φ fuese negativo podemos ver que mientras menor es Y_i mayor es X_i , con lo cual podemos apreciar que existe una correlación negativa entre u_i y X_i . De esta forma, la simultaneidad en la variable explicativa rompe con el supuesto de no correlación entre el término de error y las variables explicativas.

5.3. Error de Medición

El error de medición es un problema con la recolección de los datos, el error de medición sólo genera problemas de sesgo e inconsistencia cuando las variables explicativas están medidas con error, cuando la variable dependiente es la que esta medida con error no se genera problema de sesgo.

A continuación podemos apreciar que cuando la variable explicativa esta medida con error, el término de error del modelo esta correlacionado con la variable explicativa incluida (variable con error), lo que invalida, nuevamente, el supuesto del estimador MCO sobre la no correlación entre el error y las variables explicativas.

Supongamos que en el siguiente modelo no observamos la variable explicativa X_i que debiésemos, sino una que esta medida con error, que llamaremos X_i^* . De esta forma:

$$X_i^* = X_i + \varepsilon_i$$

donde ε_i es el error de medición.

El modelo verdadero que debería ser estimado es:

$$Y_i = X_i \beta + v_i$$

Sin embargo, se estima el siguiente modelo:

$$Y_i = X_i^* \beta + u_i$$

donde $u_i = v_i - \beta\varepsilon_i$.

El modelo estimado no cumple con los supuestos MCO, ya que existe correlación distinta de cero entre el término de error compuesto u_i y la variable medida con error X_i^* . El estimador MCO será sesgado e inconsistente.

5.4. Estimador de Variables Instrumentales

Supongamos el modelo básico de la ecuación de Mincer para estimar retornos a la educación:

$$\ln y_{ph_i} = \beta_0 + \beta_1 \cdot \text{esc}_i + u_i$$

Si la correlación entre el término de error y la variable años de escolaridad es distinta de cero (por cualquiera de las tres razones antes mencionada), la estimación del retorno a la educación será sesgada e inconsistente.

La idea del estimador IV es buscar una variable z , denominada **instrumento**, que permita aislar o separar la parte de los años de escolaridad que esta correlacionada con el error de la que no está correlacionada con el error. Y luego utilizar sólo la parte de los años de escolaridad no correlacionada con el error para estimar correctamente el parámetro de interés a través de MCO.

El instrumento debe satisfacer dos condiciones para que sea un instrumento válido:

- Condición de relevancia:

$$\text{cov}(\text{esc}_i, z_i) \neq 0$$

- Condición de exogeneidad:

$$\text{cov}(u_i, z_i) = 0$$

Si el instrumento es relevante, entonces la variación del instrumento está relacionada con la variación en la variable años de escolaridad. Adicionalmente, si el instrumento es exógeno, la parte de años de escolaridad que está siendo capturada por el instrumento es justamente la parte exógena (o no correlacionada con el error) de años de escolaridad. De esta forma, un instrumento que es relevante

y exógeno puede capturar el comportamiento de años de escolaridad que es exógeno, y esto puede ser utilizando para estimar consistentemente el retorno a la educación.

En el modelo de regresión simple (una variable explicativa) con un instrumento, se dice que el modelo está exactamente identificado, y el estimador de variables instrumentales es:

$$\hat{\beta}_{VI} = \frac{\sum z_i x_i}{\sum z_i y_i}$$

El que se obtiene de la condición de momento $E[zu] = 0$ en términos muestrales:

$$\sum_{i=1}^N z_i (y_i - \beta x_i) = 0$$

Notemos que el estimador de variables instrumentales puede ser escrito de la siguiente manera:

$$\hat{\beta}_{VI} = \frac{\sum z_i x_i}{\sum z_i y_i} \cdot \frac{\sum z_i^2}{\sum z_i^2} = \frac{\hat{\beta}_{yz}}{\hat{\beta}_{xz}}$$

Por ejemplo, si un incremento en una unidad de z aumenta en 0.2 los años de escolaridad y en \$300 el salario por hora, luego el estimador de variables instrumentales para el efecto de un año más de escolaridad sobre ingresos es \$1500.

5.4.1. Estimador de Mínimos Cuadrados Ordinarios en dos etapas

Cuando se dispone de más instrumentos que variables explicativas endógenas (sobreidentificado) se utiliza el estimador MCO2E, tal como su nombre sugiere, es un estimador que consta de dos etapas. En la primera etapa se descompone la variable que tiene el problema de endogeneidad en dos partes, la que no está correlacionada con el término de error y la que esta correlacionada con el término de error. De esta forma, la primera etapa consiste en hacer una regresión de la variable con problemas, en este caso años de escolaridad, con el instrumento:

- Primera etapa:

$$esc_i = \pi_0 + \pi_1 z_i + \nu_i$$

Esta regresión permite hacer la descomposición de la variable escolaridad de la forma que necesitamos: una parte exógena ($\pi_0 + \pi_1 z_i$), que es la parte predicha por z_i , si el instrumento cumple la condición de exogeneidad esta predicción será justamente la parte exógena de la variable escolaridad, y otra parte que esta correlacionada con el error y es la que genera el problema de endogeneidad.

- Segunda etapa: la segunda etapa consiste en estimar el modelo original, pero en vez de utilizar la variable escolaridad con problema, se utiliza la predicción del modelo de la primera etapa, a la cual se le ha "quitado" la parte que esta correlacionada con el término de error:

$$\ln y_{ph_i} = \beta_0 + \beta_1 \cdot \hat{e}sc_i + u_i$$

5.5. Ejemplos de Variables Instrumentales

5.5.1. ¿Afecta la obligatoriedad de educación a la escolaridad e ingresos?, Angrist y Krueger (1991)

El artículo publicado en el año 1991 por Angrist y Krueger estima retornos a la educación a través de variables instrumentales. Como se explico anteriormente, la escolaridad e ingresos pueden tener un problema de endogeneidad. Además existe un problema potencial de omisión de variables relevante, habilidad, ambos aspectos genera que la escolaridad en el modelo de regresión este correlacionada con le término de error, lo que provoca sesgo e inconsistencia en el estimado MCO.

Este artículo explota la característica de experimento natural de la fecha de nacimiento, y como esto determina los años de escolaridad logrados, para estimar correctamente el retorno a la educación mediante variables instrumentales.

El instrumento utilizado en este caso para separar la parte de escolaridad exógena de la endógena, consiste en el trimestre de nacimiento de la persona.

¿Por qué el trimestre de nacimiento se puede utilizar como instrumento de los años de escolaridad?

La ley educacional en EEUU obliga a los estudiantes a permanecer en el colegio hasta la edad de 16 años, en el minuto que estos alumnos cumplen esta edad pueden abandonar el colegio. Sin embargo, para ingresar al colegio deben tener

los seis años cumplidos al 1 de Enero del año de ingreso al colegio.

De esta forma, si comparamos dos niños uno nacido el 15 de Diciembre y otro el 15 de Enero del siguiente año, a pesar de que la diferencia en edad es sólo un mes, el segundo de ellos deberá esperar un año completo para poder ingresar al colegio, ingresando cuando tenga 7 años de edad y no a los 6 años de edad como el primero de los niños. Sin embargo, la ley permite que ambos abandonen el colegio a los 16 años, si ambos decidieran abandonar el colegio a los 16 años, el primero tendrá un año de educación más que el segundo de ellos.

Así, a priori, el trimestre de nacimiento es un instrumento que cumple con la condición de relevancia, y la condición de exogeneidad, debido a que el cumpleaños es poco probable que este correlacionado con otros atributos personales que puedan determinar el ingreso de la persona, sólo tiene influencia a través de su impacto en el nivel educacional logrado.

El modelo estimado por los autores tiene como variable dependiente el logaritmo del salario por hora, y como variables explicativas los años de escolaridad, dummy de raza, variable dummy de área metropolitana, variable dummy si esta casado, 9 dummies para año de nacimiento, 8 dummies para región de residencia, 49 dummies de estado, edad y edad al cuadrado.

La estimación por MCO entrega un retorno a la educación de 5.7%. Cuando se realiza la estimación MCO2E, en la primera etapa se hace una regresión de los años de escolaridad (variable endógena) contra raza, área, y todas las variables explicativas incluidas en el modelo original distintas de la escolaridad, más tres dummies correspondientes al trimestre de nacimiento 1, 2 y 3, dummies que corresponden a los instrumentos de los años de escolaridad. El retorno a la educación estimado por esta metodología es de 3.9%.

5.5.2. Using Geographic Variation in College Proximity to Estimate the Return to Schooling, Card (1993)

Este artículo tiene como objetivo estimar el retorno a la educación, sin embargo, como ya mencionamos antes el nivel educacional y los ingresos presentan endogeneidad, el nivel educacional no es entregado aleatoriamente en la población, sino que depende de las decisiones tomadas sobre invertir o no en educación, las que dependen en parte del nivel de ingresos. De esta forma, para identificar correctamente el impacto que tiene la escolaridad sobre los ingresos se requiere una variación exógena en los años de escolaridad, es decir, requiere una variable

instrumental que permita descomponer la escolaridad en la parte correlacionada con el término de error (endógena), y la parte no correlacionada con el error (exógena). Este artículo utiliza como variable instrumental en la estimación de retornos a la educación una variable la presencia de una universidad en el área de residencia de la persona. Los estudiantes que crecieron en áreas donde no existen universidades presentan mayores costos de educación, ya que no tienen la posibilidad de seguir viviendo en sus casas. De esta forma, se espera que estos costos reduzcan la inversión en educación, al menos en las familias de menores ingresos.

En este artículo se estima la siguiente ecuación de salarios por hora:

$$\ln y_{ph_i} = \beta_0 + \beta_1 \cdot esc_i + \beta_2 \cdot exp_i + \beta_3 \cdot exp_i^2 + X_k \beta_k + u_i$$

donde X_k incluye una serie de controles como: raza, área geográfica, educación de los padres, y estructura familiar.

La estimación por MCO del modelo anterior estima un retorno a la educación de 7.3 %.

El estimador MCO2E utiliza como instrumento para la escolaridad una variable que indica que existe una universidad en el área donde vive la persona. El retorno a la educación estimado en este caso es de 13.2 %.

5.5.3. Estimating the payoff to schooling using the Vietnamese Daft lottery, Angrist y Krueger (1992)

Estos autores, nuevamente con el objetivo de estimar el retorno a la educación en forma correcta eliminando el problema de endogeneidad utilizan la metodología de variables instrumentales. Entre 1970 y 1973 la prioridad para servicio militar fue seleccionada aleatoriamente mediante una lotería. Muchos de los hombres que estimaban que podían ser seleccionados para el servicio militar se matricularon en los colegios para evadir el servicio militar, generando un mayor nivel educacional. Este artículo ocupa esta lotería como experimento natural para estimar el retorno a la educación.

El modelo estimado tiene como variable dependiente el logaritmo del salario por hora y como variable explicativa la escolaridad más un conjunto de regresores como estatus de veterano, raza, ciudad metropolitana, estado civil, dummies de año de nacimiento, y dummies de regiones. La estimación MCO de este modelo entrega un valor estimado del retorno a la educación de 5.9 %. Luego para solucionar el problema de endogeneidad de los años de escolaridad, se estima primero

un modelo de regresión entre los años de escolaridad como variable dependiente, y 130 dummies con la fecha de nacimiento para la lotería. Luego incorporando la predicción de escolaridad a partir de esta primera etapa, se obtiene un estimar del retorno a la educación de 6.5 %.

5.6. Aplicación I: Determinantes de los gastos médicos

Para esta aplicación se utilizarán los datos de Medical Expenditure Panel Survey (MEPS), esta encuesta se realiza a individuos de 65 años o más. En particular se estimará un modelo de regresión que tiene como variable dependiente el logaritmo del gasto en medicinas recetadas (`ldrugexp`), y las variables explicativas son: una variable binaria que toma valor 1 si el individuo tiene seguro médico del empleador o sindicato (`hi_empunion`), número de enfermedades crónicas (`totchr`), edad (`age`), dummy mujer (`female`), dummy hispano o negro (`blhisp`), y el logaritmo natural del ingreso del hogar (`linc`).

El Cuadro 5.1 muestra las estadísticas descriptivas de estas variables:

Cuadro 5.1
Estadísticas Descriptivas Gastos Médicos

. sum ldrugexp hi_empunion totchr age female blhisp linc						
Variable	Obs	Mean	Std. Dev.	Min	Max	
ldrugexp	10391	6.479668	1.363395	0	10.18017	
hi_empunion	10391	.3796555	.4853245	0	1	
totchr	10391	1.860745	1.290131	0	9	
age	10391	75.04639	6.69368	65	91	
female	10391	.5797325	.4936256	0	1	
blhisp	10391	.1703397	.3759491	0	1	
linc	10089	2.743275	.9131433	-6.907755	5.744476	

El estimador MCO del modelo propuesto se presenta en el Cuadro 5.2, se obtiene que las personas con seguro médico gastan en promedio un 7.4 % más en medicamentos, y que cada enfermedad crónica incrementa el gasto en medicamentos en 44 %, ambas variables son significativas al 1 %. Por otra parte se obtiene que la edad tiene un efecto negativo pero significativo solo al 10 %, las mujeres en promedio gastan un 5.8 % más que los hombres en medicamentos (significativo al

5 %), y ser de un grupo minoritario (hispano o negro) reduce el gasto promedio en medicamentos en 15.1 %. El ingreso del hogar no tiene un efecto significativo.

Cuadro 5.2
Estimador MCO Gastos Médicos

<pre>. global x2list totchr age female blhisp linc . reg ldrugexp hi_empunion \$x2list, r</pre>						
Linear regression			Number of obs = 10089 F(6, 10082) = 376.85 Prob > F = 0.0000 R-squared = 0.1770 Root MSE = 1.236			
ldrugexp	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
hi_empunion	.0738788	.0259848	2.84	0.004	.0229435	.1248141
totchr	.4403807	.0093633	47.03	0.000	.4220268	.4587346
age	-.0035295	.001937	-1.82	0.068	-.0073264	.0002675
female	.0578055	.0253651	2.28	0.023	.0080848	.1075262
blhisp	-.1513068	.0341264	-4.43	0.000	-.2182013	-.0844122
linc	.0104815	.0137126	0.76	0.445	-.0163979	.037361
_cons	5.861131	.1571037	37.31	0.000	5.553176	6.169085

Sin embargo, es probable que la variable explicativa que indica si la persona tiene seguro de salud sea endógena ya que personas con mayor gasto esperado en salud tienen mayor probabilidad de tomar un seguro.

En la base de datos existen cuatro potenciales instrumentos:

- **ssiratio**: corresponde al ratio entre el ingreso el ingreso del trabajo y el ingreso total del individuo, mientras mayor es el valor mayor es la restricción de ingreso del individuo.
- **lowincome**: variable cualitativa que toma valor 1 si la persona es de bajos ingresos.
- **firmsz**: número de empleados de la firma
- **multc**: indica que la firma tiene múltiples locaciones.

EL Cuadro 5.3 muestra la matriz de correlaciones con la variable explicativa endógena, los dos primeros instrumentos están correlacionados de manera negativa con tener seguro médico, y los dos últimos de manera positiva.

Cuadro 5.3
Correlación Variable Endógena e Instrumentos

. correlate hi_empunion ssiratio lowincome firmsz multlc (obs=10391)					
	hi_emp~n	ssiratio	lowinc~e	firmsz	multlc
hi_empunion	1.0000				
ssiratio	-0.1963	1.0000			
lowincome	-0.1144	0.2498	1.0000		
firmsz	0.0372	-0.0405	-0.0078	1.0000	
multlc	0.1191	-0.1744	-0.0607	0.1874	1.0000

El Cuadro 5.4 muestra el estimador de variables instrumentales (MCO2E) utilizando como único instrumento para la única variable endógena el ratio de ingresos (ssiratio), es decir, un modelo exactamente identificado. Se encuentra un coeficiente negativo y estadísticamente significativo de la variable de seguro complementario de salud, indicando que las personas con seguro complementario tienen un gasto promedio en medicamentos 90 % menor a los que no tienen seguro complementario en salud. El Cuadro 5.5 muestra la estimación del modelo pero adicionando el instrumento multlc. En este caso, se estima que las personas con seguro complementario de salud tienen un gasto promedio en medicamentos 98 % menor que las personas que no poseen de este seguro.

Para que el estimador de variables instrumentales sea válido se deben cumplir los dos supuestos de relevancia y exogeneidad del instrumento.

Para testear la exogeneidad de los instrumentos se realiza un test de sobreidentificación del modelo, claramente no se puede testear la exogeneidad del instrumento cuando el modelo está exactamente identificado.

Cuadro 5.4
Estimador de Variables Instrumentales
Instrumento: ssiratio

. ivregress 2sls ldrugexp (hi_empunion=ssiratio) \$x2list, vce(robust) first						
First-stage regressions						
				Number of obs	=	10089
				F(6, 10082)	=	119.18
				Prob > F	=	0.0000
				R-squared	=	0.0761
				Adj R-squared	=	0.0755
				Root MSE	=	0.4672
hi_empunion	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
totchr	.0127865	.0036655	3.49	0.000	.0056015	.0199716
age	-.0086323	.0007087	-12.18	0.000	-.0100216	-.0072431
female	-.07345	.0096392	-7.62	0.000	-.0923448	-.0545552
blhisp	-.06268	.0122742	-5.11	0.000	-.08674	-.0386201
linc	.0483937	.0066075	7.32	0.000	.0354417	.0613456
ssiratio	-.1916432	.0236326	-8.11	0.000	-.2379678	-.1453186
_cons	1.028981	.0581387	17.70	0.000	.9150172	1.142944
Instrumental variables (2SLS) regression						
				Number of obs	=	10089
				wald chi2(6)	=	2000.86
				Prob > chi2	=	0.0000
				R-squared	=	0.0640
				Root MSE	=	1.3177
ldrugexp	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
hi_empunion	-.8975913	.2211268	-4.06	0.000	-1.330992	-.4641908
totchr	.4502655	.0101969	44.16	0.000	.43028	.470251
age	-.0132176	.0029977	-4.41	0.000	-.0190931	-.0073421
female	-.020406	.0326114	-0.63	0.531	-.0843232	.0435113
blhisp	-.2174244	.0394944	-5.51	0.000	-.294832	-.1400167
linc	.0870018	.0226356	3.84	0.000	.0426368	.1313668
_cons	6.78717	.2688453	25.25	0.000	6.260243	7.314097
Instrumented:	hi_empunion					
Instruments:	totchr age female blhisp linc ssiratio					

Cuadro 5.5
Estimador de Variables Instrumentales
Instrumento: ssiratio, multlc

. ivregress 2sls ldrugexp (hi_empunion=ssiratio multlc) \$x2list, vce(robust)						
Instrumental variables (2SLS) regression				Number of obs = 10089		
				wald chi2(6) = 1955.36		
				Prob > chi2 = 0.0000		
				R-squared = 0.0414		
				Root MSE = 1.3335		
ldrugexp	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
hi_empunion	-.9899269	.2045907	-4.84	0.000	-1.390917	-.5889365
totchr	.4512051	.0103088	43.77	0.000	.4310001	.47141
age	-.0141384	.0029	-4.88	0.000	-.0198223	-.0084546
female	-.0278398	.0321743	-0.87	0.387	-.0909002	.0352207
blhisp	-.2237087	.0395848	-5.65	0.000	-.3012934	-.1461239
linc	.0942748	.0218841	4.31	0.000	.0513828	.1371668
_cons	6.875188	.2578855	26.66	0.000	6.369741	7.380634
Instrumented: hi_empunion						
Instruments: totchr age female blhisp linc ssiratio multlc						

Para realizar el Test de Exogeneidad se debe utilizar el comando post-estimación de STATA `estat overid`. La hipótesis nula de este test es que los instrumentos son exógenos (o que se cumplen las restricciones de sobreidentificación), en este caso no se puede rechazar la hipótesis nula de que los instrumentos sean exógenos. El Cuadro 5.6 muestra los resultados del test de exogeneidad para el modelo estimado, en este caso no se puede rechazar la hipótesis nula de que los instrumentos son exógenos.

Cuadro 5.6
Test de Exogeneidad

```
. estat overid
Test of overidentifying restrictions:
Score chi2(1)          =  1.04754  (p = 0.3061)
```

Para testear la relevancia de los instrumentos Stock y Yogo (2005) proponen utilizar el estadístico F de la significancia conjunta de los instrumentos en la primera etapa, los estadísticos de la primera etapa se obtienen de la siguiente manera:

Cuadro 5.7*Estadísticos Primera Etapa Variables Instrumentales*

estat firststage, forcenonrobust					
First-stage regression summary statistics					
variable	R-sq.	Adjusted R-sq.	Partial R-sq.	Robust F(2,10081)	Prob > F
hi_empunion	0.0794	0.0788	0.0215	58.6119	0.0000
Minimum eigenvalue statistic = 110.613					
Critical values			# of endogenous regressors:		1
Ho: Instruments are weak			# of excluded instruments:		2
2SLS relative bias	5%	10%	20%	30%	
		(not available)			
2SLS size of nominal 5% wald test	10%	15%	20%	25%	
LIML size of nominal 5% wald test	19.93	11.59	8.75	7.25	
	8.68	5.33	4.42	3.92	

Se rechaza la hipótesis nula de que los instrumentos son débiles.

De esta forma, el modelo estimado por variables instrumentales debería ser consistente ya que se han utilizado instrumentos correctos.

Una vez validado el estimador se puede testear si efectivamente la variable seguro médico es endógena, si la variable sugerida como endógena no resulta serlo es mejor (consistente y eficiente) el estimador de MCO por sobre el de VI. El test de endogeneidad se realiza mediante el siguiente comando:

Cuadro 5.8*Test de Endogeneidad*

estat endogenous			
Tests of endogeneity			
Ho: variables are exogenous			
Robust score chi2(1)	=	35.4571	(p = 0.0000)
Robust regression F(1,10081)	=	37.0514	(p = 0.0000)

La hipótesis nula es que la variable es exógena, por lo cual sería mejor el estimador de MCO, en este caso se rechaza la hipótesis nula validando la utilización del estimador de variables instrumentales por sobre el estimador MCO.

Capítulo 6

Estimador Máximo Verosímil

Hasta el momento hemos adoptado el criterio de estimación consistente con escoger los valores de los parámetros $(\hat{\beta}, \hat{\sigma}^2)$ de modo de minimizar la suma de los residuos al cuadrado. A continuación, expondremos otra forma de obtener los parámetros de interés, el cual, a diferencia de MCO, descansa en un determinado supuesto respecto de la distribución del término de error, teniendo por objetivo, como veremos más adelante, determinar los parámetros que *maximicen la probabilidad de ocurrencia de la muestra observada*. La ventaja de MV es que puede producir estimadores consistentes y asintóticamente eficientes cuando MCO falla.

Sea $Y' = [y_1, y_2, \dots, y_n]$ un vector $n \times 1$ de valores muestrales para la variable dependiente, los cuales dependen de un vector $k \times 1$ $\theta' = [\theta_1, \theta_2, \dots, \theta_k]$. Sea $f(y; \theta)$ la densidad conjunta asociada. A dicha probabilidad conjunta se le llama *función de Verosimilitud* y se denota por $L(\cdot)$:

$$L(\theta; y) = f(y; \theta)$$

Note que hemos invertido la notación entre L y la densidad. Ello porque la densidad describe los valores probables de Y *dado* un vector θ determinado, sin embargo, en nuestro caso el sentido es inverso: estamos interesados en el vector θ *dado* un vector Y determinado.

Al maximizar $L(\theta; Y)$ respecto de θ se obtienen los estimadores máximo verosímiles ($\hat{\theta}_{MV}$), los cuales *maximizan la probabilidad de ocurrencia de la muestra observada*, es decir:

$$\hat{\theta}_{MV} = \max_{\theta} L(\theta; Y)$$

o equivalentemente¹

$$\hat{\theta}_{MV} = \max_{\theta} \ln(L(\theta; Y)) = \max_{\theta} l(\theta; Y)$$

Luego, si asumimos que las observaciones de Y son independientes, entonces ²:

$$l(\theta; Y) = \ln\left(\prod_{i=1}^n L_i(\theta; y_i)\right) = \sum_{i=1}^n l_i(\theta; y_i)$$

La primera derivada de L es generalmente conocida como **Score**, $s = (\theta; Y)$, por lo cual $\hat{\theta}_{MV}$ se obtienen al igualar el score a cero.

6.1. Propiedades de los estimadores MV

Las propiedades de los estimadores ML se derivan en grandes muestras, por lo cual hablaremos de las propiedades *asintóticas* de los mismos. Ellas son:

1. Consistencia:

$$plim(\hat{\theta}_{MV}) = \theta$$

es decir, asintóticamente, el parámetro estimado corresponde al parámetro poblacional.

2. **Eficiencia Asintótica:** La varianza del estimador ML alcanza la llamada **Cota Inferior de Cramer Rao**, es decir $I(\theta)^{-1}$. Esta propiedad asintótica es la principal virtud de los estimadores ML. La cota inferior de Cramer Rao corresponde al inverso de la matriz de información (que definiremos a continuación), la cual corresponde a la mínima varianza que puede poseer un estimador insesgado.

3. Normalidad Asintótica:

$$\hat{\theta}_{MV} \sim^a N(\theta, I(\theta)^{-1})$$

¹En general se utiliza el logaritmo de la función de verosimilitud, denotado como $l = \ln(L)$ como función objetivo. Note que dicha transformación es inocua, en términos de que el vector de parámetros que maximice l será el que a su vez maximice L , ya que: $\frac{\partial l}{\partial \theta} = \frac{1}{L} \frac{\partial L}{\partial \theta}$

²Bajo independencia, la función de distribución conjunta de una muestra corresponde a la multiplicación de las funciones de densidad individuales.

es decir, el estimador ML distribuye asintóticamente normal, con media θ y varianza igual al inverso de la llamada **matriz de información** ($I(\theta)$). Esta última se define como:

$$I(\theta) = E \left[\frac{\partial l}{\partial \theta} \frac{\partial l'}{\partial \theta} \right] = -E \left[\frac{\partial^2 l}{\partial \theta \partial \theta'} \right]$$

donde note que la matriz hessiana de segundas derivadas de L es una matriz cuadrada y simétrica de orden $k \times k$.

4. **Invarianza:** Si $\hat{\theta}$ es el estimador ML de θ y $g(\theta)$ es una función continua de θ , entonces $g(\hat{\theta})$ es el estimador ML de $g(\theta)$.

6.2. Estimación MV

Como ya es usual, sea el siguiente modelo poblacional:

$$Y = X\beta + u$$

donde las matrices poseen los tamaños usuales y $u \stackrel{iid}{\sim} N(0, \sigma^2 I)$. Entonces:

$$f(u_1, u_2, \dots, u_n; \sigma^2 I) = f(u_1) * f(u_2) * \dots * f(u_n) = \prod_{i=1}^n f(u_i)$$

y asumiendo una distribución normal para los errores, tenemos que la función de verosimilitud corresponde a:

$$\begin{aligned} f(u_1, u_2, \dots, u_n; \sigma^2 I) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp^{-\frac{u_i^2}{2\sigma^2}} \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp^{-\frac{u'u}{2\sigma^2}} \end{aligned}$$

luego, dado nuestro modelo poblacional, tenemos que:

$$L = f(y_1, y_2, \dots, y_n; X, \sigma^2, \beta) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp^{-\frac{(Y-X\beta)'(Y-X\beta)}{2\sigma^2}}$$

con lo cual, nuestros estimadores $\hat{\theta}_{MV} = [\hat{\beta}_{MV} \quad \hat{\sigma}_{MV}^2]'$ se obtienen siguiendo la regla expuesta en (2.74):

$$\begin{aligned} \max_{\beta, \sigma^2} \ln(L) &= \max_{\beta, \sigma^2} \ln \left(\frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp^{-\frac{(Y-X\beta)'(Y-X\beta)}{2\sigma^2}} \right) \\ &= \max_{\beta, \sigma^2} \left(-\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{(Y-X\beta)'(Y-X\beta)}{2\sigma^2} \right) \end{aligned}$$

con lo cual, las CPO:

$$\frac{\partial \ln L}{\partial \beta} = \frac{1}{\hat{\sigma}^2} X'(Y - X\hat{\beta}) = 0$$

$$\Rightarrow \hat{\beta}_{MV} = (X'X)^{-1}X'Y$$

$$\frac{\partial \ln L}{\partial \sigma} = -\frac{n}{2\hat{\sigma}^2} + \frac{1}{2\hat{\sigma}^4} (Y - X\hat{\beta})'(Y - X\hat{\beta}) = 0$$

$$\Rightarrow \hat{\sigma}_{MV}^2 = \frac{(Y - X\hat{\beta}_{MV})'(Y - X\hat{\beta}_{MV})}{n}$$

Entonces, bajo normalidad de los errores, el estimador $\hat{\beta}_{MV}$ es equivalente al estimador MCO. Sin embargo, note que el estimador de la varianza de los errores ($\hat{\sigma}_{MV}$) da lugar al estimador sesgado.

Nos queda entonces derivar la varianza de los estimadores MV. Vimos que la matriz de varianzas correspondía al inverso de la matriz de información ($I(\theta)$). Por facilidad de cálculo, generalmente se utiliza la segunda definición de $I(\theta)$, es decir, la de las segundas derivadas de la función de verosimilitud. Entonces:

$$\frac{\partial^2 l}{\partial \beta \partial \beta'} = -\frac{X'X}{\sigma^2}$$

$\therefore$

$$-E \left[\frac{\partial^2 l}{\partial \beta \partial \beta'} \right] = \frac{X'X}{\sigma^2}$$

$$\frac{\partial^2 l}{\partial \beta \partial \sigma^2} = -\frac{X'u}{\sigma^4}$$

$\therefore$

$$-E \left[\frac{\partial^2 l}{\partial \beta \partial \sigma^2} \right] = 0$$

$$\frac{\partial^2 l}{\partial (\sigma^2)^2} = \frac{n}{2\sigma^4} - \frac{u'u}{\sigma^6}$$

$\therefore$

$$-E \left[\frac{\partial^2 l}{\partial (\sigma^2)^2} \right] = \frac{n}{2\sigma^4}$$

donde esta última esperanza se deriva del hecho que $E(u'u) = n\sigma^2$. Entonces, la matriz de información corresponde a:

$$I(\beta, \sigma) = \begin{pmatrix} \frac{X'X}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{pmatrix}$$

mientras que su inversa:

$$I(\beta, \sigma)^{-1} = \begin{pmatrix} (X'X)^{-1}\sigma^2 & 0 \\ 0 & \frac{2\sigma^4}{n} \end{pmatrix}$$

Note que el hecho que la matriz de información (y por lo tanto su inversa) sea una matriz diagonal, refleja que X y u se distribuyen independientemente (de otra forma $E(X'u) \neq 0$).

Ejemplo: Considere la siguiente función de densidad condicional:

$$f(y|x) = \frac{\lambda e^{-\lambda y} (\lambda y)^x}{x!} \quad y \geq 0, \quad \lambda \geq 0$$

Obtenga el estimador de máxima verosimilitud de λ .

Primero debemos recordar que cada observación i de la variable dependiente y tiene la siguiente densidad condicional a la variable explicativa x :

$$f(y_i|x_i, \lambda) = \frac{\lambda e^{-\lambda y_i} (\lambda y_i)^{x_i}}{x_i!}$$

El logaritmo de la función de verosimilitud asociada a cada observación i es:

$$\begin{aligned} l_i(\lambda|y_i, x_i) &= \ln \left(\frac{\lambda e^{-\lambda y_i} (\lambda y_i)^{x_i}}{x_i!} \right) \\ &= \ln \lambda - \lambda y_i + x_i(\ln \lambda + \ln y_i) - \ln(x_i!) \end{aligned}$$

De esta forma, aplicando sumatoria a la ecuación anterior obtengo la verosimilitud conjunta:

$$L(\lambda|\mathbf{y}, \mathbf{x}) = n \ln \lambda - \lambda \sum_{i=1}^n y_i + \ln \lambda \sum_{i=1}^n x_i + \sum_{i=1}^n x_i \ln y_i - \sum_{i=1}^n \ln(x_i!)$$

Maximizando la expresión anterior con respecto a λ obtenemos el estimador Máximo Verosímil:

$$\begin{aligned}\frac{\partial L}{\partial \lambda} &= \frac{n}{\hat{\lambda}} - \sum_{i=1}^n y_i + \frac{\sum_{i=1}^n x_i}{\hat{\lambda}} = 0 \\ n - \hat{\lambda} \sum_{i=1}^n y_i + \sum_{i=1}^n x_i &= 0 \\ \hat{\lambda} &= \frac{n + \sum_{i=1}^n x_i}{\sum_{i=1}^n y_i} \\ \hat{\lambda} &= \frac{1 + \bar{x}}{\bar{y}}\end{aligned}$$

Ahora suponga que disponemos de los siguientes datos de la variable x e y :

y	2	5	6	7
x	4	10	18	20

En este caso el estimador Máximo Verosímil de λ es:

$$\begin{aligned}\hat{\lambda} &= \frac{1 + \bar{x}}{\bar{y}} \\ &= \frac{1 + 13}{5} = 2,8\end{aligned}$$

6.3. Inferencia en el contexto MV

6.3.1. Test de Razón de Verosimilitud (LR)

El valor de la función de verosimilitud, $L(\hat{\beta}, \hat{\sigma}^2)$, corresponde al valor de la verosimilitud **irrestringida**, es decir, sin imponer ninguna restricción sobre los parámetros del modelo. Suponiendo entonces que nuestro interés se centra en una serie de restricciones lineales del tipo $R\beta = r$ (donde R y r se definen como en la sección 2.8), entonces el modelo original es estimable en su versión restringida, al maximizar la función de verosimilitud sujeta a $R\beta = r$, cuyo resultado son los estimadores $\tilde{\beta}$ y $\tilde{\sigma}^2$. Luego $L(\tilde{\beta}, \tilde{\sigma}^2)$ corresponde al valor de la verosimilitud **restringida**.

El valor de la verosimilitud restringida no puede ser superior al de la no restringida, sin embargo, podría esperarse que si las restricciones impuestas son correctas, el valor de la primera esté cerca del de la segunda. Entonces, definimos la *razón de verosimilitud* (λ) como:

$$\lambda = \frac{L(\tilde{\beta}, \tilde{\sigma}^2)}{L(\hat{\beta}, \hat{\sigma}^2)}$$

El test LR se define entonces como:

$$LR = -2 \ln \lambda = 2[\ln L(\hat{\beta}, \hat{\sigma}^2) - \ln L(\tilde{\beta}, \tilde{\sigma}^2)] \sim^a \chi^2(q)$$

donde q corresponde al número de restricciones impuestas (es decir, el número de filas de R).

Intuitivamente, el valor del estadígrafo crecerá a mayor sea la discrepancia entre los valores de la verosimilitud restringida y la no restringida, lo cual nos aleja de la posibilidad que las restricciones impuestas sea válidas (no rechazo de la nula).

En el caso que los errores distribuyan normal, es posible derivar una versión alternativa del estadígrafo utilizando los residuos. Reemplazando $\hat{\beta}_{MV}$ y $\hat{\sigma}_{MV}^2$ en l es posible demostrar:

$$L(\hat{\beta}, \hat{\sigma}^2) = (2\pi e)^{-\frac{n}{2}} (\hat{\sigma}^2)^{-\frac{n}{2}} = \left(\frac{2\pi e}{n} \right)^{-\frac{n}{2}} (\hat{u}'\hat{u})^{-\frac{n}{2}}$$

Luego, si definimos como $\hat{u}_{NR}$ los residuos del modelo irrestricto y como $\hat{u}_R$, reemplazando en la definición del test, obtenemos:

$$LR = n(\ln \hat{u}_R' \hat{u}_R - \ln \hat{u}_{NR}' \hat{u}_{NR})$$

6.3.2. Test de Wald (W)

Un segundo test asintótico en el contexto MV corresponde al llamado Test de Wald. Dicho test se basa en evaluar la hipótesis nula en los coeficientes estimados y evaluar cuan cercano es el resultado comprado a lo propuesto por la nula. Una de las ventajas del test de Wald es que sólo necesita de la estimación no restringida. Así, una vez obtenido $\hat{\beta}$, un vector $(R\hat{\beta} - r)$ cercano a cero tendería a apoyar la hipótesis nula.

Siguiendo la misma lógica de la demostración del test F, si:

$$\hat{\beta} \stackrel{a}{\sim} (\beta, I(\beta)^{-1})$$

entonces, bajo la hipótesis nula:

$$(R\hat{\beta} - r) \stackrel{a}{\sim} (0, RI(\beta)^{-1}R')$$

entonces, se puede demostrar que:

$$(R\hat{\beta} - r)'[RI(\beta)^{-1}R']^{-1}(R\hat{\beta} - r) \stackrel{a}{\sim} \chi_q^2$$

donde q es el número de filas de R y por lo tanto, el número de restricciones (según la definimos en la sección 2.8). Luego, como los estimadores MV distribuyen asintóticamente normales, entonces la matriz de información expuesta en la ecuación (2.88) es válida en muestras grandes, tenemos que el estadístico de Wald se define como³:

$$W = \frac{(R\hat{\beta} - r)'[R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r)}{\hat{\sigma}^2} \stackrel{a}{\sim} \chi_q^2$$

Una nota: Dijimos que el test era válido asintóticamente, donde hemos utilizado el resultado de normalidad asintótica de MV. En caso de que los errores efectivamente distribuyan normal en muestra finita, el test (lógicamente) mantiene su distribución.

6.3.3. Test del Multiplicador de Lagrange (LM)

Un tercer test corresponde al test LM, el cual también es conocido como el test del Score. recordemos que el Score corresponde a la matriz de primeras derivadas

³Note que hemos utilizado sólo el bloque superior izquierdo de la inversa de la matriz de información. Ello porque el test corresponde a los parámetros asociados a los coeficientes de la regresión. Además, ello es posible porque la matriz es diagonal, lo cual implica que no existe correlación entre los errores y los regresores.

de la función de Verosimilitud:

$$\begin{aligned}s(\theta) &= \frac{\partial \ln L}{\partial \theta} \\ &= \frac{\partial l}{\partial \theta}\end{aligned}$$

Como vimos en la introducción, $s(\hat{\theta}) = 0$, por lo cual, al evaluar el score en el estimador restringido bajo la nula $R\beta - r = 0$ ($\tilde{\beta}$), generalmente obtendremos un vector diferente de cero, sin embargo, si la nula no se puede rechazar, esperaríamos obtener un vector cercano a cero.

Se puede demostrar que el score posee media cero y varianza igual a la matriz de información ($I(\theta)$). Por lo tanto, tenemos que la forma cuadrática:

$$s'(\theta)I(\theta)^{-1}s(\theta) \stackrel{a}{\sim} \chi^2$$

con lo cual, al evaluar en el vector de parámetros restringido tenemos que bajo la nula, el test LM se define y distribuye como:

$$LM = s'(\tilde{\theta})I(\tilde{\theta})^{-1}s(\tilde{\theta}) \sim^a \chi_q^2$$

Note que contraposición al test de Wald, sólo necesitamos calcular el estimador restringido. De hecho, su popularidad reside en que muchas veces es más fácil calcular el estimador restringido que el no restringido.

Dada la normalidad asintótica de los estimadores MV, podemos reducir el estadígrafo a una forma mucho más simple. Para ver lo anterior, considere una notación matricial del score:

$$s(\theta) = \begin{bmatrix} \frac{\partial l}{\partial \beta} \\ \frac{\partial l}{\partial \sigma^2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sigma^2} X'u \\ -\frac{n}{2\sigma^2} + \frac{u'u}{2\sigma^4} \end{bmatrix}$$

entonces, para evaluar el score en la estimación restringida, utilizamos los residuos restringidos, los cuales denotaremos por:

$$u_* = Y - X\tilde{\beta}$$

y por lo tanto:

$$\hat{\sigma}^{2*} = \frac{u'_* u_*}{n}$$

con lo cual:

$$s(\tilde{\theta}) = \begin{bmatrix} \frac{1}{\hat{\sigma}^{2*}} X'u_* \\ 0 \end{bmatrix}$$

Entonces, tomado en cuenta la definición de $I(\theta)^{-1}$ dada en (2.87) y evaluándola en el estimador restringido, tenemos que nuestro test en (2.96) queda como:

$$\begin{aligned}
 LM &= \begin{bmatrix} \frac{1}{\tilde{\sigma}^2} u'_* X & 0 \end{bmatrix} \begin{bmatrix} \tilde{\sigma}^2 (X'X)^{-1} & 0 \\ 0 & \frac{2\tilde{\sigma}^4}{n} \end{bmatrix} \begin{bmatrix} \frac{1}{\tilde{\sigma}^2} u'_* X \\ 0 \end{bmatrix} \\
 &= \frac{u'_* X (X'X)^{-1} X' u_*}{\tilde{\sigma}^2} \\
 &= n \frac{u'_* X (X'X)^{-1} X' u_*}{u'_* u_*} \\
 &= n R^2 \sim^a \chi_q^2
 \end{aligned}$$

donde el R^2 corresponde a la bondad de ajuste de la regresión auxiliar entre u_* y X .

Resumiendo, el test se implementa en tres simples pasos:

1. Estimar el modelo restringido y obtener sus residuos
2. Con ellos correr una regresión de ellos contra X . Obtener el R^2
3. Construir el estadístico

Ejemplo: Siguiendo con el ejemplo anterior, testee la hipótesis nula de que $\lambda = 5$.

(i) Test de Razón de Verosimilitud: recordemos que el estadístico de este test es:

$$LR = 2[\ln L(\hat{\lambda}) - \ln L(\tilde{\lambda})] \sim^a \chi^2(q)$$

Primero debemos evaluar el logaritmo de la verosimilitud en el parámetro no restringido (estimado):

$$\begin{aligned}
 L(\hat{\lambda}|\mathbf{y}, \mathbf{x}) &= n \ln \hat{\lambda} - \hat{\lambda} \sum_{i=1}^n y_i + \ln \hat{\lambda} \sum_{i=1}^n x_i + \sum_{i=1}^n x_i \ln y_i - \sum_{i=1}^n \ln(x_i!) \\
 &= 4 \cdot \ln(2,8) - 2,8 \cdot 20 + \ln(2,8) \cdot 52 + 90,04 - 97,014 \\
 &= -5,317999436
 \end{aligned}$$

El siguiente paso es computar el logaritmo de la función de verosimilitud restringida, es decir, evaluada en el valor del λ bajo la hipótesis nula ($\tilde{\lambda} = 5$):

$$\begin{aligned}
 L(\tilde{\lambda}|\mathbf{y}, \mathbf{x}) &= n \ln \tilde{\lambda} - \tilde{\lambda} \sum_{i=1}^n y_i + \ln \tilde{\lambda} \sum_{i=1}^n x_i + \sum_{i=1}^n x_i \ln y_i - \sum_{i=1}^n \ln(x_i!) \\
 &= 4 \cdot \ln(5) - 5 \cdot 20 + \ln(5) \cdot 52 + 90,04 - 97,014 \\
 &= -16,8481637
 \end{aligned}$$

Luego debemos computar el estadístico restando ambas verosimilitudes en logaritmos y multiplicar esta diferencia por 2:

$$\begin{aligned} LR &= 2[\ln L(\hat{\lambda}) - \ln L(\tilde{\lambda})] \\ &= 2[-5,317999436 + -16,8481637] = 23,06032853 \end{aligned}$$

Finalmente, debemos comparar el valor de este estadístico con el valor de tabla de una χ^2 con 1 grado de libertad (sólo estamos testeando una hipótesis). El valor de la χ^2 con un grado de libertad a un 5% de significancia es de 3.84, por lo tanto se rechaza la hipótesis nula de que λ sea igual a 5.

- (ii) Test de Wald: para poder realizar este test primero necesitamos computar la matriz de varianzas y covarianzas del estimador, el inverso de la matriz de información. Recordemos la forma de esta matriz:

$$I(\theta) = E \left[\frac{\partial l}{\partial \theta} \frac{\partial l'}{\partial \theta} \right] = -E \left[\frac{\partial^2 l}{\partial \theta \partial \theta'} \right]$$

El score (o primera derivada de el logaritmo de la función de verosimilitud era:

$$\frac{\partial \ln L}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n y_i + \frac{\sum_{i=1}^n x_i}{\lambda}$$

Ahora, la segunda derivada (o Hessiano) es:

$$\begin{aligned} \frac{\partial^2 \ln L}{\partial \lambda \partial \lambda'} &= -\frac{n}{\lambda^2} - \frac{\sum_{i=1}^n x_i}{\lambda^2} \\ \frac{\partial^2 \ln L}{\partial \lambda \partial \lambda'} &= -\frac{(n + \sum_{i=1}^n x_i)}{\lambda^2} \end{aligned}$$

Como la variable x es fija el valor esperado del hessiano corresponde a la misma expresión, luego el negativo de esto constituye la matriz de información:

$$\begin{aligned} I(\lambda) &= \frac{(n + \sum_{i=1}^n x_i)}{\lambda^2} \\ I(\lambda) &= \frac{(4 + 52)}{\lambda^2} \\ I(\lambda) &= \frac{56}{\lambda^2} \end{aligned}$$

Ahora el estadístico de Wald se construye de la siguiente forma:

$$W = (\hat{\lambda} - 5)' I(\hat{\lambda}) (\hat{\lambda} - 5) \sim \chi_1^2$$

Reemplazando $\hat{\lambda}$ por 2,8:

$$\begin{aligned} W^c &= (2,8 - 5)' \left(\frac{56}{(2,8)^2} \right) (2,8 - 5) \\ W^c &= 34,6 \end{aligned}$$

Como el valor calculado del estadístico de Wald resulta ser mayor al valor de tabla de una χ^2 con un grado de libertad, se rechaza la hipótesis nula de que $\hat{\lambda} = 5$.

- (iii) Test de multiplicador de Lagrange: para construir este estadístico necesitamos evaluar el score y la matriz de información en el estimador restringido ($\tilde{\lambda}$), que en este caso es igual a 5:

$$\begin{aligned} s(\tilde{\lambda}) &= \frac{n}{\tilde{\lambda}} - \sum_{i=1}^n y_i + \frac{\sum_{i=1}^n y_i}{\tilde{\lambda}} = \frac{4}{5} - 20 + \frac{52}{5} = -8,8 \\ I(\tilde{\lambda}) &= \frac{56}{(5)^2} = 2,24 \end{aligned}$$

Reemplazando en el estadístico:

$$\begin{aligned} LM &= s(\tilde{\lambda})' I(\tilde{\lambda})^{-1} s(\tilde{\lambda}) \\ LM &= (-8,8)(2,24)^{-1}(-8,8) = 34,6 \end{aligned}$$

Con lo cual se rechaza la hipótesis nula de que $\hat{\lambda} = 5$.

6.4. Algunas acotaciones respecto a la estimación y la inferencia MV

1. La sección 2.10.2 asume que la distribución de los errores sigue una distribución normal. Sin embargo, suponer errores normales es sólo uno de los posibles supuestos respecto a la distribución de los errores. Existe una gran cantidad de posibilidades al respecto, utilizándose otras como la distribución logística y la exponencial, muy regularmente en otros tópicos econométricos. Lo anterior es una ventaja de la estimación MV, dado que sus propiedades asintóticas se mantienen independientemente de la distribución utilizada.
2. Otra ventaja corresponde a la posibilidad de utilizar modelos no lineales. MCO (tal y como lo hemos estudiado) sólo permite estimar modelos lineales en parámetros, mientras que MV permite no linealidades (aunque ello

implique la imposibilidad de obtener formas funcionales cerradas para nuestros estimadores, lo cual implica necesariamente utilizar métodos numéricos para optimizar la función objetivo).

3. Otra ventaja reside en la inferencia. Toda la inferencia vista en MCO poseía distribución exacta bajo el supuesto de normalidad. Los test asintóticos visto en la inferencia MV son válidos bajo cualquier distribución supuesta (aunque asintóticamente).
4. Adicionalmente, los tres test vistos son capaces de lidiar con restricciones no lineales. ¿Por qué? Porque MV es capaz de lidiar con modelos no lineales⁴
5. Es posible demostrar que $W \geq LR \geq LM$ al ser aplicados a un modelo lineal. Los tres son asintóticamente equivalentes, sin embargo, en muestras finitas arrojarán resultados diferentes.
6. ¿Cuándo es recomendable utilizar un test t o un test F por sobre un test asintótico?
7. Todos los paquetes estadísticos reportan el valor de la función de verosimilitud (es decir, la función evaluada en los parámetros estimados). Ello, muchas veces es utilizado como un criterio de selección entre modelos (recuerde que nuestro objetivo es maximizar la función de verosimilitud).

⁴Un ejemplo de restricción no lineal corresponde a $H_0 : \ln(\beta_3^2) = -0,1 + \ln(\beta_2)$. Para estimar el modelo restringido basta con aislar β_2 e introducirlo en la función de verosimilitud que será maximizada por métodos numéricos.

Capítulo 7

Variable Dependiente Discreta

En los problemas empíricos es bastante común encontrarse con análisis donde la variable de interés no es continua, por ejemplo, si estamos interesados en estudiar los factores que determinan que una mujer casada trabaje o no, esta variable es binaria:

$$Trabaja = \begin{cases} 1 & \text{trabaja;} \\ 0 & \text{no trabaja.} \end{cases}$$

Cuando la variable dependiente tiene esta característica usualmente el modelo de regresión lineal no es apropiado.

Algunos ejemplos de modelos de variable dependiente discreta son:

- Decisión de estudiar en colegios privados versus públicos
- Decisión de otorgar o no un crédito a una empresa
- Decisión de las personas de capacitarse o no
- Decisión de las personas de ahorrar o no (o de endeudarse o no)
- Factores asociados a la depresión
- Decisión de contribuir o no al sistema de pensiones
- Decisión de tener o no un seguro

7.1. Modelo de Probabilidad Lineal

Suponga que estamos interesados en estudiar como el nivel de ingresos afecta la decisión de un hogar de tener auto o no. Para esto se disponen de N familias ($i = 1, 2, \dots, N$), la variable ingresos la denotamos por x_2 , y la variable dependiente correspondiente a la tenencia o no auto es binaria, y se define de la siguiente manera:

$$y_i = \begin{cases} 1 & \text{si el hogar } i \text{ posee auto;} \\ 0 & \text{si el hogar } i \text{ no posee auto.} \end{cases}$$

Suponga que realizamos una regresión lineal para este modelo:

$$y_i = \beta_1 + \beta_2 x_{i2} + u_i$$

o de manera equivalente y más general:

$$y_i = x_i' \beta + u_i$$

donde $x_i = (1, x_{i2})'$. Bajo los supuestos estándar de que la esperanza condicional del error es cero, $E[u_i|x_i] = 0$, se tiene que $E[y_i|x_i] = x_i' \beta$.

Pero dado que la variable dependiente y es binaria, la esperanza condicional de la variable dependiente es equivalente a:

$$\begin{aligned} E[y_i|x_i] &= 1 \cdot Pr[y_i = 1|x_i] + 0 \cdot Pr[y_i = 0|x_i] \\ &= Pr[y_i = 1|x_i] \end{aligned}$$

Por lo cual, el supuesto de un modelo lineal cuando la variable dependiente es binaria implica que $x' \beta$ es una probabilidad, y por lo tanto debería estar entre 0 y 1, lo cual se cumplirá acotando los valores que pueden tomar x y β .

Adicionalmente, el término de error del modelo no tendrá una distribución normal y tendrá heterocedasticidad, esto se debe a que como la variable y sólo puede tomar dos valores, el término de error (dado un valor de x) también puede tomar dos valores. En particular tenemos que cuando $y = 1$ el término de error es $1 - x' \beta$ y cuando $y = 0$ el término de error es $-x' \beta$, y la distribución de u_i se puede resumir de la siguiente manera:

$$\begin{aligned} Pr[u_i = 1 - x_i' \beta | x_i] &= Pr[y_i = 1 | x_i] = x_i' \beta \\ Pr[u_i = -x_i' \beta | x_i] &= Pr[y_i = 0 | x_i] = 1 - x_i' \beta \end{aligned}$$

La varianza del error entonces es:

$$\begin{aligned}
 V[u_i|x_i] &= (1 - x'_i\beta)^2 \cdot Pr[u_i = 1 - x'_i\beta] + (-x'_i\beta)^2 \cdot Pr[u_i = -x'_i\beta] \\
 &= (1 - x'_i\beta)^2 \cdot (x'_i\beta) + (x'_i\beta)^2 \cdot (1 - x'_i\beta) \\
 &= (1 - x'_i\beta)(x'_i\beta)[1 - x'_i\beta + x'_i\beta] \\
 &= (1 - x'_i\beta)(x'_i\beta)
 \end{aligned}$$

Así, podemos notar que la varianza del error no es constante sino que depende de los valores de x_i y además depende de β que es un parámetro desconocido.

Suponga que estamos interesados en estudiar como la alimentación por leche materna afecta los niveles de obesidad en niños entre 2 y 5 años de edad¹, para cual además de considerar la variable correspondiente a la cantidad de meses que el niño fue alimentado con leche materna se incorporan las variables años de escolaridad de la madre, la que usualmente es utilizada como educación en salud de la madre, una dummy que indica si la madre sufrió de diabetes gestacional, y una dummy que indica si la madre tuvo algún trastorno psicológico (depresión, fobia, pánico, etc.) durante el embarazo. El siguiente cuadro muestra la estimación por MCO de este modelo, donde la variable dependiente es binaria y toma valor 1 si el menor es obeso (su índice de masa corporal está por sobre el percentil 95 de los niños de su mismo sexo y edad) y cero si el niño no es obeso.

Cuadro 7.1

Modelo de Regresión Lineal: Variable Dependiente Obeso

. reg obeso esc_madre meses_lechem diabetes trastorno, robust						
Linear regression				Number of obs = 9015		
				F(4, 9010) = 6.60		
				Prob > F = 0.0000		
				R-squared = 0.0031		
				Root MSE = .42976		
obeso	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
esc_madre	-.0047688	.0015277	-3.12	0.002	-.0077635	-.0017742
meses_lechem	-.0012044	.0004423	-2.72	0.006	-.0020714	-.0003375
diabetes	.0604884	.018171	3.33	0.001	.0248691	.0961077
trastorno	.0067431	.0136633	0.49	0.622	-.0200401	.0335263
_cons	.3108055	.0205943	15.09	0.000	.2704361	.3511749

La estimación anterior nos muestra que la cantidad de meses que el menor fue alimentado con leche materna tiene un efecto negativo sobre la probabilidad de

¹Datos obtenidos de la Encuesta Longitudinal de la Primera Infancia

ser obeso, en particular un mes mas de alimentación materna disminuye en 0.12 puntos porcentuales la probabilidad de que el menor sea obeso, también podemos ver que por cada año adicional de educación de la madre la probabilidad de ser obeso se reduce en 0.48 puntos porcentuales, si la madre tuvo diabetes gestacional se incrementa la probabilidad de ser obeso en 6 puntos porcentuales, y si la madre tuvo algún trastorno psicológico durante el embarazo no tiene efecto significativo sobre la probabilidad de que el menor sea obeso.

El siguiente cuadro muestra el valor predicho de la probabilidad de ser obeso ($\hat{P}[y = 1|x] = x'\hat{\beta}$) según este modelo lineal:

Cuadro 7.2

Predicción Obesidad según Modelo de Regresión Lineal

```
. predict prob_lineal if e(sample), xb
(294 missing values generated)

. sum prob_lineal
```

Variable	Obs	Mean	Std. Dev.	Min	Max
prob_lineal	9015	.2453688	.0240005	.172216	.3652717

En este caso puntual no se producen predicciones fuera del rango $[0, 1]$, sin embargo, la estimación del modelo sigue siendo ineficiente por la heterocedasticidad del modelo, y restringida al asumir que la función de probabilidad es lineal.

Una vez estimado el modelo podemos utilizar los valores estimados para los coeficientes para graficar la relación entre la probabilidad de ser obeso (según el modelo) y los meses de lactancia materna, esto asumiendo todas las demás variables constantes y fijas en algún valor (generalmente se ocupa el promedio), el siguiente cuadro nos muestra los comando necesarios para poder realizar este gráfico.

Cuadro 7.3
Predicción Lineal Obesidad y Lactancia Materna

```
. sum esc_madre
```

Variable	obs	Mean	Std. Dev.	Min	Max
esc_madre	9175	11.45079	3.064091	0	23

```
. scalar escm=r(mean)
```

```
. sum diabetes
```

Variable	obs	Mean	Std. Dev.	Min	Max
diabetes	9309	.0748738	.2632017	0	1

```
. scalar diabm=r(mean)
```

```
. sum trastorno
```

Variable	obs	Mean	Std. Dev.	Min	Max
trastorno	9171	.1310653	.3374902	0	1


```
. scalar trasm=r(mean)
```

```
. g lineal_lechem=_b[_cons]+_b[esc_madre]*escm+_b[meses_lechem]*meses_lechem+_b[diabetes]*diabm+_b[trastorno]*trasm
```

(31 missing values generated)

```
. twoway (scatter lineal_lechem meses_lechem), ytitle(Probabilidad Predicha obesidad) xtitle(Meses de lactancia materna)
```

Gráfico 7.1
Predicción Lineal Obesidad y Lactancia Materna



7.2. Modelo de Elección Discreta

Los modelos de elección discreta están diseñados para abordar el problema de que la variable dependiente corresponde al resultado de una elección entre dos alternativas. Estos modelos describen directamente la probabilidad de que $y_i = 1$ como una función no lineal de $x'_i\beta$:

$$Pr[y_i = 1|x_i] = G(x'_i\beta)$$

La elección natural para esta función $G(\cdot)$ es una función de distribución de probabilidad acumulada, por ejemplo la distribución normal estándar:

$$F(\omega) = \Phi(\omega) = \int_{-\infty}^{\omega} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}t^2\right\} dt$$

En este caso el modelo de elección discreta es conocido como [Modelo Probit](#).

También se puede asumir una función de probabilidad logística:

$$F(\omega) = \Lambda(\omega) = \frac{e^{\omega}}{1 + e^{\omega}}$$

En este caso el modelo de elección discreta es conocido como [Modelo Logit](#).

Estas dos distribuciones son bastante similares, la única diferencia es que la distribución logística tiene las colas un poco más anchas, por lo cual los resultados entregados por ambos modelos en la práctica son bastante similares.

Notemos que en estos modelos los coeficientes β no representan los efectos marginales de la variable x sobre la probabilidad de que $y = 1$, ya que esta la función de probabilidad de por medio. En estos modelos la interpretación de los efectos marginales no es directa. Si x_k es una variable continua, el [efecto marginal](#) de esta variable sobre $Pr[y = 1]$ corresponde a:

$$\begin{aligned} \frac{\partial Pr[y_i = 1]}{\partial x_{ik}} &= \frac{\partial F(x'_i\beta)}{\partial x_{ik}} \cdot \beta_k \\ &= f(x'_i\beta)\beta_k \end{aligned}$$

donde $f(\cdot)$ corresponde a la función de densidad.

De esta forma, el efecto marginal no es constante para todas las observaciones sino por el contrario cada individuo tienen un valor distinto del efecto marginal, en la práctica se obtiene el valor del efecto marginal evaluando las variables

explicativas en el promedio:

$$\left. \frac{\partial Pr[y_i = 1]}{\partial x_{ik}} \right|_{x_i = \bar{x}} = f(\bar{x}'\beta)\beta_k$$

Otra alternativa, menos utilizada en la práctica, es calcular el promedio de los efectos marginales.

Cuando la variable explicativa x_k es discreta, el efecto marginal corresponde a:

$$F(x'_i\beta) \Big|_{x_{-k}=\bar{x}, x_k=1} - F(x'_i\beta) \Big|_{x_{-k}=\bar{x}, x_k=0}$$

Esto es, la probabilidad evaluada en el promedio para todas las variables explicativas excepto para la variable binaria para la cual estamos calculando el efecto marginal, la cual se evalúa en 1 y se le resta la evaluada en 0.

En el caso del modelo Logit:

$$Pr[y_i = 1|x_i] = \frac{e^{x'_i\beta}}{1 + e^{x'_i\beta}}$$

Denotando $Pr[y_i = 1|x_i]$ por p_i , el modelo Logit puede ser expresado de la siguiente manera:

$$\frac{p_i}{1 - p_i} = e^{x'_i\beta}$$

$$\ln \left[\frac{p_i}{1 - p_i} \right] = x'_i\beta$$

donde el lado izquierdo de esta ecuación corresponde al logaritmo natural del **odds ratio**, este se define como el ratio de las posibilidades, por ejemplo un odd ratio de 3 indica que las posibilidades de que $y = 1$ son tres veces las posibilidades de que $y = 0$. En este modelo el coeficiente β estimado representa los efectos marginales sobre el logaritmo del odd ratio, entonces si por ejemplo β_k es 0.12 significa que un cambio en una unidad de x_k aumenta en un 12% las posibilidades de que $y = 1$ sobre las posibilidades de que $y = 0$.

7.3. Variable Dependiente Latente

Es posible (pero no necesario) derivar el modelo de elección discreta de un modelo de comportamiento, lo que lleva a una representación del modelo mediante

una variable latente. Por ejemplo, suponga que nuestra variable de interés es si una mujer casada trabaja o no trabaja condicional en ciertas características, la variable dependiente en este caso es binaria y toma valor 1 si la mujer trabaja y 0 sino trabaja. Sin embargo, la decisión de trabajar o no de la mujer fue tomada en función de evaluar la utilidad de trabajar versus la utilidad de no trabajar, esta diferencia en las utilidades depende del salario que reciba, algunas características de la mujer, educación, si tiene hijos pequeños o no, entre otras variables. Así, para cada persona i se puede escribir la diferencia de utilidades de tener o no tener trabajo (y_i^*) como una función de características observadas (x_i), y características no observadas (u_i):

$$y_i^* = x_i'\beta + u_i$$

dado que en realidad y_i^* no se observa nos referimos a ella como **variable latente**. Suponiendo, sin pérdida de generalidad, que la persona decide trabajar cuando la diferencia de utilidades es mayor a cero, y no trabaja si es mejor o igual a cero, tenemos que la variable observada y tiene la siguiente característica:

$$y = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* \leq 0 \end{cases}$$

De esta forma, se tiene que:

$$\begin{aligned} Pr[y_i = 1] &= Pr[y_i^* > 0] \\ &= Pr[x_i'\beta + u_i > 0] \\ &= Pr[-u_i \leq x_i'\beta] \\ &= F(x_i'\beta) \end{aligned}$$

Es equivalente al modelo de elección discreta antes mostrado, si se asume que el error del modelo latente u_i es normal estamos hablando del modelo Probit y si se asume que es logístico estamos hablando del modelo Logit.

7.4. Estimación

La estimación de este modelo es por Máxima Verosimilitud, primero notemos que la función de verosimilitud es:

$$L(\beta) = \prod_{i=1}^N P[y_i = 1|x_i, \beta]^{y_i} P[y_i = 0|x_i, \beta]^{1-y_i}$$

Tomando logaritmo de la función de verosimilitud, se tiene que la log-likelihood de este modelo es:

$$\ln L(\beta) = \sum_{i=1}^N y_i \ln F(x_i'\beta) + \sum_{i=1}^N (1 - y_i) \ln [1 - F(x_i'\beta)]$$

donde $F(\cdot)$ es la función de probabilidad acumulada la que puede ser normal o logística.

Tomando la derivada de log-likelihood con respecto a β e igualando a cero se obtiene la condición de primer orden:

$$\frac{\partial \ln L(\beta)}{\partial \beta} = \sum_{i=1}^N \left[\frac{y_i - F(x'_i \beta)}{F(x'_i \beta)[1 - F(x'_i \beta)]} f(x'_i \beta) \right] x_i = 0$$

El término entre paréntesis cuadrado recibe el nombre de residuo generalizado. Este residuo generalizado (ε_i) tiene las siguientes características:

$$\varepsilon_i = \begin{cases} \frac{f(x'_i \beta)}{F(x'_i \beta)} & \text{si } y_i = 1 \\ \frac{-f(x'_i \beta)}{1 - F(x'_i \beta)} & \text{si } y_i = 0 \end{cases}$$

La condición de primer orden nos indica que los residuos generalizados son ortogonales a las variables explicativas del modelo, similar a la condición de primer orden de MCO.

La condición de primer orden de este problema no tiene una solución cerrada para β por lo cual se resuelve mediante métodos de optimización.

El Cuadro 7.4 muestra la estimación de la probabilidad de que el menor sea obeso en función de la educación de la madre, meses de lactancia materna, una dummy si la madre tuvo diabetes gestacional, y una dummy si la madre tuvo un trastorno psicológico durante el embarazo, asumiendo una distribución normal estándar para el término de error del modelo latente. Sin embargo, los resultados presentados corresponden a la estimación de los coeficientes β los que no tienen una interpretación de efectos marginales en este tipo de modelos. Para poder interpretar los efectos marginales de las variables explicativas sobre la probabilidad de obesidad del menor, debemos computar los efectos marginales. El Cuadro 7.5 muestra el cálculo de los efectos marginales para el modelo probit estimado evaluados en el promedio de las variables explicativas.

Los resultados encontrados son bastante similares a la estimación por MCO, un aumento en un mes de lactancia materna reduce la probabilidad de obesidad del niño en 0.12 puntos porcentuales, un año más de escolaridad de la madre reduce la probabilidad de obesidad del niño en 0.48 puntos porcentuales, si la madre tuvo diabetes gestacional la probabilidad de obesidad es 6 puntos porcentuales mayor que en niños con madres sin diabetes gestacional, y los trastornos psicológicos no tienen efectos significativos sobre la probabilidad de obesidad.

Cuadro 7.4
Estimación Probit Probabilidad de Obesidad

```
. probit obeso esc_madre meses_lechem diabetes trastorno, robust
```

Iteration 0: log pseudolikelihood = -5023.0665
 Iteration 1: log pseudolikelihood = -5009.3366
 Iteration 2: log pseudolikelihood = -5009.332
 Iteration 3: log pseudolikelihood = -5009.332

Probit regression

Log pseudolikelihood = -5009.332

		Number of obs	=	9015
		wald chi2(4)	=	27.42
		Prob > chi2	=	0.0000
		Pseudo R2	=	0.0027

obeso	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
esc_madre	-.0150623	.0048288	-3.12	0.002	-.0245265	-.0055981
meses_lechem	-.00383	.0014293	-2.68	0.007	-.0066314	-.0010286
diabetes	.1832067	.0525854	3.48	0.000	.0801412	.2862722
trastorno	.0220451	.0427933	0.52	0.606	-.0618283	.1059185
_cons	-.4834822	.0641241	-7.54	0.000	-.6091632	-.3578013

Cuadro 7.5
Efectos Marginales Probit sobre Probabilidad de Obesidad

```
. mfx
```

Marginal effects after probit
 y = Pr(obeso) (predict)
 = .24478049

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]		x
esc_ma~e	-.0047328	.00152	-3.12	0.002	-.007706	-.00176	11.4937
meses_~m	-.0012034	.00045	-2.68	0.007	-.002083	-.000323	13.3648
diabetes*	.0605047	.01816	3.33	0.001	.024916	.096093	.075984
trasto~0*	.0069657	.0136	0.51	0.608	-.019683	.033615	.129895

(*) dy/dx is for discrete change of dummy variable from 0 to 1

El Cuadro 7.6 muestra los comandos necesarios para guardar la información de los efectos marginales de las estimaciones por MCO, Probit y Logit, para luego poder mostrar en una sola tabla la comparación de los tres modelos. El Cuadro 7.7 muestra la tabla con los resultados.

Cuadro 7.6
Efectos Marginales Probabilidad de Obesidad
Comparación MCO, Probit y Logit

```
. quietly reg obeso esc_madre meses_lechem diabetes trastorno, robust
. qui mfx
. estimates store lineal
. quietly probit obeso esc_madre meses_lechem diabetes trastorno, robust
. qui mfx
. estimates store probit
. quietly logit obeso esc_madre meses_lechem diabetes trastorno, robust
. qui mfx
. estimates store logit
. outreg2 [lineal probit logit] using "C:\Users\Javiera\Dropbox\Microeconometria Aplicada 2012\Material
> \Clases\Clase3\tabla", replace see mfx
. tit Enter to continue.
```

Cuadro 7.7
Efectos Marginales Probabilidad de Obesidad
Comparación MCO, Probit y Logit

	(1)	(2)	(3)	
	lineal	probit	logit	Robust standard errors in parentheses
VARIABLES	obeso	obeso	obeso	*** p<0.01, ** p<0.05, * p<0.1
esc_madre	-0.00477*** (0.00153)	-0.00473*** (0.00152)	-0.00474*** (0.00151)	
meses_lechem	-0.00120*** (0.000442)	-0.00120*** (0.000449)	-0.00121*** (0.000451)	
diabetes	0.0605*** (0.0182)	0.0605*** (0.0182)	0.0604*** (0.0182)	
trastorno	0.00674 (0.0137)	0.00697 (0.0136)	0.00667 (0.0136)	
Observations	9,015	9,015	9,015	
R-squared	0.003			

De manera alternativa se puede utilizar el comando:

```
outreg2 [lineal probit logit] using javiera, replace word excel mfx
```

Generando archivos excel y word con la tabla de comparación de los tres modelos.


Al igual que en el modelo lineal podemos graficar la relación entre la probabilidad de obesidad predicha por el modelo y los meses de lactancia dejando constante las demás variables. Para lograr este gráfico debemos ejecutar los siguientes comandos:

Cuadro 7.8
Probabilidad de Obesidad y Lactancia Materna

```
. qui probit obeso esc_madre meses_lechem diabetes trastorno, robust
. g probit_lechem=_b[_cons]+_b[esc_madre]*11.5+_b[meses_lechem]*meses_lechem+_b[d
> iabetes]*0.075+_b[trastorno]*0.13
(31 missing values generated)
. g prob_probit_lechem=normal(probit_lechem)
(31 missing values generated)
. qui logit obeso esc_madre meses_lechem diabetes trastorno, robust
. g logit_lechem=_b[_cons]+_b[esc_madre]*11.5+_b[meses_lechem]*meses_lechem+_b[d
> iabetes]*0.075+_b[trastorno]*0.13
(31 missing values generated)
. g prob_logit_lechem=exp(logit_lechem)/(1+exp(logit_lechem))
(31 missing values generated)
. twoway (scatter lineal_lechem meses_lechem, msize(small)) (scatter prob_probit_
> lechem meses_lechem, msize(small)) (scatter prob_logit_lechem meses_lechem, msi
> ze(small)), ytitle(Probabilidad predicha obesidad) xtitle(Meses de lactancia ma
> terna) legend(order(1 "Lineal" 2 "Probit" 3 "Logit"))
```

Podemos notar que no existen grandes diferencias en la relación probabilidad de obesidad y lactancia materna estimadas por los diferentes modelos, lo que ya habíamos adelantando comparando los efectos marginales de los tres modelos estimados.

Gráfico 7.2
Probabilidad de Obesidad y Lactancia Materna



7.5. Medidas de Bondad de Ajuste

Las medidas de Bondad de Ajuste representan estadísticas indicando el grado de precisión con la cual el modelo se aproxima a los datos observados, en el modelo de regresión lineal se utiliza el R^2 o $R^2 - \text{ajustado}$. En los modelos de variable dependiente binaria el modelo puede ser juzgado tanto en términos del ajuste entre las probabilidades calculadas y las frecuencias observadas como en términos de la habilidad de predecir las respuestas observadas.

Sea $\ln L_1$ el valor de la función de verosimilitud para el modelo estimado (máximo valor), y sea $\ln L_0$ el valor de la función de verosimilitud donde todos los coeficientes excepto la constante son reemplazados por cero. Claramente, $\ln L_1 > \ln L_0$ y la diferencia entre las dos funciones es mayor mientras mayor sea el valor de las variables explicativas del modelo en explicar la variable dependiente. De esta manera, se puede utilizar la siguiente medida, denominada *pseudo- R^2* para estudiar el ajuste del modelo:

$$\text{pseudo-}R^2 = 1 - \frac{1}{1 + 2(\ln L_1 - \ln L_0)/N}$$

donde N denota el número de observaciones.

Una medida alternativa es sugerida por McFadden (1974):

$$McFaddenR^2 = 1 - \frac{\ln L_1}{\ln L_0}$$

Se podría pensar que una manera razonable de estudiar el ajuste del modelo es comparar el valor promedio de las probabilidades predichas:

$$\frac{1}{N} \sum_{i=1}^N \hat{p}_i$$

con el promedio de la variable binaria observada $\bar{y}$, o la frecuencia muestral de observaciones con valor de y igual a 1. Sin embargo, esta medida no es útil ya que por supuesto de estimación (condición de primer orden) la igualdad de estos dos indicadores es impuesta. De esta forma, Hosmer-Lemeshow sugieren un test que consiste en comparar la frecuencia muestral ($\bar{y}$) con el promedio de las probabilidades predichas por el modelo en subgrupos de observaciones, donde la hipótesis nula del test es que los dos grupos son iguales. La cantidad de grupos es definida de manera arbitraria por el investigador. Sea $\hat{p}_g$ el promedio de las probabilidades predichas del grupo g e $\bar{y}_g$ la frecuencia muestral del grupo g , el estadístico de este test es:

$$\sum_{g=1}^G \frac{(\hat{p}_g - \bar{y}_g)^2}{\bar{y}_g(1 - \bar{y}_g)}$$

los grupos se basan en los cuantiles de las probabilidades predichas. Bajo la hipótesis nula el estadístico se distribuye $\chi^2_{(G-2)}$.

El Cuadro 7.9 muestra este test para la estimación probit del modelo de probabilidad de obesidad. En este caso no se puede rechazar la hipótesis nula de que el promedio de las probabilidades estimadas son iguales a las frecuencias muestrales para todos los grupos cuando utilizamos 5 grupos, se rechaza al 10 % cuando utilizamos 6 grupos.

Cuadro 7.9
Test Hosmer-Lemeshow

```
. estat gof, group(5)

Probit model for obeso, goodness-of-fit test

(Table collapsed on quantiles of estimated probabilities)

      number of observations =      9015
      number of groups      =         5
Hosmer-Lemeshow chi2(3)    =      3.00
      Prob > chi2          =      0.3921

. estat gof, group(6)

Probit model for obeso, goodness-of-fit test

(Table collapsed on quantiles of estimated probabilities)

      number of observations =      9015
      number of groups      =         6
Hosmer-Lemeshow chi2(4)    =      8.70
      Prob > chi2          =      0.0690
```

Justamente uno de los problemas de este test es que es muy sensible al número de grupos que se utilicen.

Otra forma de estudiar la bondad de ajuste del modelo es comparar los resultados predichos con los resultados efectivos. Para obtener los resultados predichos por el modelo primero debemos computar la probabilidad predicha por el modelo, y luego definimos la variable de resultado predicha de la siguiente manera:

$$\hat{y} = \begin{cases} 1 & \text{si } \hat{p} \geq 0,5 \\ 0 & \text{si } \hat{p} < 0,5 \end{cases}$$

Luego al comparar $\hat{y}$ con y podemos computar una medida de bondad de ajuste que indique el porcentaje de las observaciones clasificadas de manera correcta. Para calcular esta medida de bondad de ajuste luego de estimar un modelo de elección binaria debemos ejecutar el comando `estat classification`, el cuadro 6.10 nos muestra el resultado para el modelo probit de la probabilidad de obesidad, un 75.5 % de las observaciones son clasificadas de manera correcta.

Cuadro 7.10
Observaciones predichas correctamente

```
. estat classification
```

Probit model for obeso

Classified	True		Total
	D	~D	
+	0	0	0
-	2212	6803	9015
Total	2212	6803	9015


Classified + if predicted $\Pr(D) \geq .5$
True D defined as obeso != 0

Sensitivity	$\Pr(+ D)$	0.00%
Specificity	$\Pr(- \sim D)$	100.00%
Positive predictive value	$\Pr(D +)$	.%
Negative predictive value	$\Pr(\sim D -)$	75.46%

False + rate for true ~D	$\Pr(+ \sim D)$	0.00%
False - rate for true D	$\Pr(- D)$	100.00%
False + rate for classified +	$\Pr(\sim D +)$	.%
False - rate for classified -	$\Pr(D -)$	24.54%

Correctly classified	75.46%
----------------------	--------

Cuando la variable no tienen una distribución proporcional en la muestra, se puede cambiar el corte de clasificación de la variable predicha de acuerdo a la probabilidad estimada, para esto primero se puede utilizar el comando `lsens` para determinar este corte:



En este caso se puede utilizar el corte en 0.25:

```
. estat classification, cut(0.25)
```

Probit model for obeso

Classified	True		Total
	D	~D	
+	826	2138	2964
-	1386	4665	6051
Total	2212	6803	9015

Classified + if predicted $\Pr(D) \geq .25$
True D defined as obeso != 0

Sensitivity	$\Pr(+ D)$	37.34%
Specificity	$\Pr(- \sim D)$	68.57%
Positive predictive value	$\Pr(D +)$	27.87%
Negative predictive value	$\Pr(\sim D -)$	77.09%
False + rate for true ~D	$\Pr(+ \sim D)$	31.43%
False - rate for true D	$\Pr(- D)$	62.66%
False + rate for classified +	$\Pr(\sim D +)$	72.13%
False - rate for classified -	$\Pr(D -)$	22.91%
Correctly classified		60.91%

7.6. Aplicación

se utilizará la encuesta CASEN 2009 para estudiar los determinantes de que una persona realice o no una capacitación laboral. En esta encuesta se pregunta a las personas han asistido a algún curso de capacitación laboral en el último año. Plantearemos un modelo simple para analizar la relación entre la realización de capacitación laboral y un conjunto de variables demográficas y características del empleo de los ocupados, por lo cual sólo se tomará como muestra de análisis los ocupados como asalariados. Según los datos de la Encuesta CASEN 2009, un 47,1 % de los mayores de 15 años (población en edad de trabajar) se encuentran ocupados. Del total de personas ocupadas, un 70.6 % trabaja como asalariado, y de los asalariados un 19.6 % ha realizado algún curso de capacitación en el último año. Las características individuales que se utilizarán en la estimación son: género, edad, escolaridad, estado civil, y condición de jefe de hogar. Además se utilizarán algunas características del empleo como: ingreso laboral por hora, tamaño de la empresa y rama de actividad económica.

A través de los siguientes comandos se construyen las variables necesarias para la estimación:

```
g ocupado=1 if o1==1
replace ocupado=0 if o1==2

replace ocupado=1 if o2==1
replace ocupado=1 if o3==1

g asalariado=1 if o23>=3 & o23<=5 & o23!=.
replace asalariado=0 if asalariado==. & ocupado==1

g capacitado=1 if o33>=1 & o33<=7
replace capacitado=0 if o33==8
replace capacitado=. if asalariado==0
replace capacitado=. if ocupado==0

g casado=1 if ecivil==1 | ecivil==2
replace casado=0 if casado==.
replace casado=. if ecivil==.

g jefe=1 if pc01==1
replace jefe=0 if pc01!=1
```

```
replace jefe=. if pco1==.

g genero=1 if sexo==1
replace genero=0 if sexo==2

replace o16=. if o16==999
g horas=o16/7*30
g yph=yopraj/horas
g lyph=ln(yph)

g Emediana=1 if o14=='D'
replace Emediana=0 if o14=='A' | o14=='B' | o14=='C' | o14=='E'
| o14=='F'
g Egrande=1 if o14=='E' | o14=='F'
replace Egrande=0 if o14=='A' | o14=='B' | o14=='C' | o14=='D'

g actividad=int(c_o12/1000)
replace actividad=. if actividad==0

tab rama, generate(act_)
rename act_3 mineria
rename act_4 industria
rename act_5 electr
rename act_6 construccion
rename act_7 comercio
rename act_8 transporte
rename act_9 servicios
rename act_10 servcomu
```

Una vez generadas las variables para estimar el modelo, se puede estimar el modelo de elección discreta para la probabilidad de realizar una capacitación mediante un modelo Probit:

```
. probit capacitado esc edad casado jefe genero lyph Egrande Emediana mineria indus
> tria electr construccion comercio transporte servicios servcomu, robust
```

```
Iteration 0:  log pseudolikelihood = -22340.419
Iteration 1:  log pseudolikelihood = -20234.183
Iteration 2:  log pseudolikelihood = -20194.365
Iteration 3:  log pseudolikelihood = -20194.35
Iteration 4:  log pseudolikelihood = -20194.35
```

```
Probit regression                                Number of obs   =      49225
                                                wald chi2(16)   =      3849.93
                                                Prob > chi2     =      0.0000
Log pseudolikelihood = -20194.35                Pseudo R2      =      0.0961
```

capitadado	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
esc	.0457907	.0025329	18.08	0.000	.0408263	.0507551
edad	-.0010397	.0006782	-1.53	0.125	-.002369	.0002896
casado	.1274817	.0162719	7.83	0.000	.0955893	.1593741
jefe	.1959335	.0173368	11.30	0.000	.161954	.2299131
genero	-.1312429	.0170645	-7.69	0.000	-.1646886	-.0977971
lyph	.1818271	.012615	14.41	0.000	.1571021	.2065521
Egrande	.521641	.0198386	26.29	0.000	.482758	.560524
Emediana	.2738703	.021787	12.57	0.000	.2311685	.3165721
mineria	.4802994	.0380363	12.63	0.000	.4057495	.5548492
industria	.1328683	.027192	4.89	0.000	.0795729	.1861637
electr	.3376599	.062704	5.38	0.000	.2147623	.4605575
construccion	-.0878618	.0322859	-2.72	0.007	-.151141	-.0245826
comercio	.067855	.0250117	2.71	0.007	.018833	.116877
transporte	.0944057	.0316434	2.98	0.003	.0323857	.1564257
servicios	.1695077	.0343502	4.93	0.000	.1021826	.2368328
servcomu	.3073982	.0228524	13.45	0.000	.2626082	.3521882
_cons	-3.309148	.080411	-41.15	0.000	-3.466751	-3.151545

La medida de bondad de ajuste *pseudo*– R^2 nos indica que estas variables son capaces de explicar un 9.6 %. La siguiente tabla muestra que el porcentaje predicho correctamente es 83 %.

```
. estat classification
```

Probit model for capacitado

Classified	True		Total
	D	~D	
+	215	262	477
-	8090	40658	48748
Total	8305	40920	49225

Classified + if predicted $\Pr(D) \geq .5$
True D defined as capacitado != 0

Sensitivity	$\Pr(+ D)$	2.59%
Specificity	$\Pr(- \sim D)$	99.36%
Positive predictive value	$\Pr(D +)$	45.07%
Negative predictive value	$\Pr(\sim D -)$	83.40%
False + rate for true ~D	$\Pr(+ \sim D)$	0.64%
False - rate for true D	$\Pr(- D)$	97.41%
False + rate for classified +	$\Pr(\sim D +)$	54.93%
False - rate for classified -	$\Pr(D -)$	16.60%
Correctly classified		83.03%

Para interpretar el efecto de las variables explicativas sobre la probabilidad de realizar una capacitación se deben computar los efectos marginales:

```
. mfx
```

Marginal effects after probit
y = Pr(capacitado) (predict)
= .14475227

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	x
esc	.0104247	.00057	18.16	0.000	.0093 .01155	10.5291
edad	-.0002367	.00015	-1.53	0.125	-.000539 .000066	39.0403
casado*	.0286164	.0036	7.95	0.000	.021565 .035667	.604449
jefe*	.0447562	.00396	11.29	0.000	.036988 .052524	.484693
genero*	-.0305946	.00407	-7.52	0.000	-.038571 -.022618	.671752
lyph	.0413948	.00288	14.36	0.000	.035745 .047044	7.09285
Egrande*	.1218583	.00465	26.18	0.000	.112735 .130981	.454139
Emediana*	.0663394	.00555	11.96	0.000	.055471 .077208	.279858
mineria*	.1348909	.01257	10.73	0.000	.110263 .159519	.031813
indust~a*	.0319621	.00688	4.64	0.000	.018469 .045455	.098487
electr*	.0902289	.01916	4.71	0.000	.052667 .127791	.011295
constr~n*	-.0192218	.00678	-2.84	0.005	-.032505 -.005938	.078801
comercio*	.0158321	.00597	2.65	0.008	.004123 .027541	.154596
transp~e*	.0224273	.00783	2.87	0.004	.007089 .037766	.065922
servic~s*	.0416959	.00907	4.60	0.000	.023918 .059474	.052636
servcomu*	.0761559	.0061	12.49	0.000	.064204 .088108	.229111

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Podemos concluir que:

- Todas las variables excepto edad resultan ser estadísticamente significativas
- Aumentar la escolaridad en un año aumenta la probabilidad de haber realizado una capacitación en 1 punto porcentual.
- Estar casado aumenta la probabilidad en 2.8 puntos porcentuales
- Ser jefe de hogar también aumenta la probabilidad de realizar capacitación en 4.5 puntos porcentuales.
- Ser hombre disminuye la probabilidad en 3 puntos porcentuales.
- Un 1 % más de salario por hora aumenta la probabilidad de capacitarse en 4.2 puntos porcentuales.
- Trabajar en una empresa grande versus una empresa pequeña aumenta la probabilidad de capacitarse en 12.2 puntos porcentuales.
- Trabajar en una empresa mediana versus una empresa pequeña aumenta la probabilidad de capacitarse en 6.6 puntos porcentuales.

- Con respecto a los sectores económicos (todos evaluados versus el sector agricultura) se concluye que: minería aumenta la probabilidad en 13.5 puntos porcentuales, industria aumenta la probabilidad en 3.2 puntos porcentuales, electricidad la aumenta en 9 puntos porcentuales, construcción disminuye la probabilidad en 1.9 puntos porcentuales, comercio aumenta la probabilidad en 1.6 puntos porcentuales, transporte aumenta la probabilidad en 2.2 puntos porcentuales, servicios financieros aumenta la probabilidad en 4.2 puntos porcentuales, y servicios comunales aumenta la probabilidad en 7.6 puntos porcentuales.

Capítulo 8

Modelos de Respuesta Múltiple

Existen diversas aplicaciones donde la variable dependiente es categórica, es decir, la variable de interés sólo toma valores discretos. En el capítulo anterior revisamos el caso cuando la variable dependiente es binaria, en este capítulo nos centraremos en el caso que la variable dependiente puede tomar más de dos valores discretos. Por ejemplo, nuestra variable de interés podría ser la jornada de trabajo de una persona (tiempo completo, medio tiempo o no trabaja), o la elección de donde invertir de una empresa (Europa, Asia, Estados Unidos o América Latina), etc. También tendremos que utilizar estos modelos cuando a pesar de que la variable de interés es continua, por ejemplo ingreso, la manera en que se reporta la información es discreta, por ejemplo en algunas encuestas las personas responden en que tramo de ingresos se ubica su salario.

Los modelos de elección múltiple tienen como objetivo explicar la probabilidad de cada una de las alternativas como función de características de las propias alternativas o como función de características de el individuo que esta escogiendo entre las diversas alternativas. Una distinción metodológica importante surge dependiendo si la variable categórica es ordenada o no ordenada.

8.1. Modelos de Respuesta Múltiple Ordenada

Consideremos que nuestra variable dependiente es categórica y representa el resultado de una elección entre M alternativas, numeradas de 1 a M . Si existe un orden lógico entre estas alternativas (por ejemplo, no tiene auto, tiene 1 auto, tiene 2 autos, y tiene más de 2 autos), el modelo se denomina [Modelo de Respuesta](#)

Ordenada. Este modelos se basa en la existencia de una variable latente, sea y_i^* la variable latente e y_i la variable categórica ordenada observada, el modelo se puede expresar de la siguiente manera:

$$\begin{aligned} y_i^* &= x_i' \beta + u_i \\ y_i &= j \quad \text{si} \quad \gamma_{j-1} < y_i^* \leq \gamma_j \end{aligned}$$

Los parámetros γ_j son desconocidos, con $\gamma_0 = -\infty$ y $\gamma_M = +\infty$.

De esta forma, la probabilidad de que la alternativa j sea escogida corresponde a la probabilidad de que la variable latente este entre γ_{j-1} y γ_j . Bajo el supuesto de que el error del modelo latente u_i es independiente e idénticamente distribuido normal estándar el modelo se denomina **Probit Ordenado**, y bajo el supuesto de que la distribución es logística el modelo se denomina **Logit Ordenado**.

Independiente del función de distribución de probabilidad escogida para el error el modelo se estima por Máxima Verosimilitud, para plantear la función de verosimilitud debemos notar que la función de probabilidad de las observaciones depende del valor que tome la variable dependiente categórica ordenada:

$$\begin{aligned} Pr[y_i = 1|x_i] &= Pr[-\infty < x_i' \beta + u_i \leq \gamma_1] \\ &= F(\gamma_1 - x_i' \beta) - F(-\infty - x_i' \beta) \\ &= F(\gamma_1 - x_i' \beta) \\ Pr[y_i = 2|x_i] &= Pr[\gamma_1 < x_i' \beta + u_i \leq \gamma_2] \\ &= F(\gamma_2 - x_i' \beta) - F(\gamma_1 - x_i' \beta) \\ &\vdots \\ Pr[y_i = M|x_i] &= Pr[\gamma_{M-1} < x_i' \beta + u_i \leq +\infty] \\ &= F(+\infty - x_i' \beta) - F(\gamma_{M-1} - x_i' \beta) \\ &= 1 - F(\gamma_{M-1} - x_i' \beta) \end{aligned}$$

De esta forma, la log-likelihood de este modelo es:

$$\ln L(\beta, \gamma) = \sum_{j=1}^M \sum_{Y_i=j} \ln [F(\gamma_j - x_i' \beta) - F(\gamma_{j-1} - x_i' \beta)]$$

la que debe ser maximizada con respecto a β y γ .

Al igual que en los modelos de elección discreta, los coeficientes β estimados no representan los efectos marginales de las variables explicativas sobre la probabilidad de elegir la alternativa j , una vez estimado el modelo se deben computar

los efectos marginales:

$$\frac{\partial Pr[y_i = j]}{\partial x_{ik}} = [f(\gamma_{j-1} - x'_i \beta) - f(\gamma_j - x'_i \beta)] \beta_k$$

Para ejemplificar la estimación de un modelo de elección múltiple ordenado utilizaremos la Encuesta Casen 2009, específicamente la variable que pregunta sobre la cantidad de personas que trabajan en la empresa de la persona entrevistada. El Cuadro 8.1 muestra la distribución de frecuencia de esta variable, un 24.9 % de las personas trabajan por cuenta propia (1 persona), y un 18.4 % trabaja en empresas grandes.

Cuadro 8.1
Distribución de Frecuencia Tamaño de Empresa

. tab tamaño_empresa			
tamaño_empresa	Freq.	Percent	Cum.
1 persona	19,314	24.90	24.90
2 a 5 personas	14,687	18.94	43.84
6 a 9 personas	4,969	6.41	50.25
10 a 49 personas	14,655	18.90	69.15
50 a 199 personas	9,626	12.41	81.56
200 y más personas	14,301	18.44	100.00
Total	77,552	100.00	

Mediante la estimación de un modelo probit/logit ordenado se puede estudiar como diferentes características de las personas como sexo, edad, escolaridad y calificación del oficio de la persona, afectan la probabilidad de trabajar en cada una de estas categorías de tamaño de empresa.

EL Cuadro 8.2 muestra la estimación de un modelo probit ordenado para esta variable, notemos que además de mostrar la estimación de los coeficientes β y sus respectivas desviación estándar, muestra la estimación de los parámetros γ y su desviación estándar, los que son llamados por el programa como `\cut_1-``\cut_5`. Para poder interpretar los resultados del modelo debemos calcular los efectos marginales con el comando `mfx` pero a diferencia del modelo de elección binaria donde se estimaba una sola probabilidad, en este caso debemos indicar además sobre que probabilidad queremos calcular el efecto marginal.

Cuadro 8.2
Probit Ordenado Tamaño de Empresa

. oprobit tamaño_empresa dhombre esc edad calificado						
Iteration 0: log likelihood = -132985.01						
Iteration 1: log likelihood = -127832.01						
Iteration 2: log likelihood = -127829.9						
Iteration 3: log likelihood = -127829.9						
Ordered probit regression						
				Number of obs	=	77178
				LR chi2(4)	=	10310.21
				Prob > chi2	=	0.0000
				Pseudo R2	=	0.0388
Log likelihood = -127829.9						
tamaño_emp~a	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
dhombre	.2799434	.0081588	34.31	0.000	.2639523	.2959344
esc	.0479334	.0011865	40.40	0.000	.045608	.0502588
edad	-.0157927	.0003079	-51.30	0.000	-.0163961	-.0151893
calificado	.3628996	.0124827	29.07	0.000	.3384339	.3873653
/cut1	-.6794782	.0212113			-.7210517	-.6379047
/cut2	-.1069903	.021057			-.1482613	-.0657192
/cut3	.0698495	.0210461			.0285999	.1110992
/cut4	.6030554	.0211297			.561642	.6444689
/cut5	1.027698	.0213285			.9858954	1.069501

El Cuadro 8.3 muestra los efectos marginales (evaluados en el promedio) de las variables explicativas sobre la probabilidad de trabajar en una empresa unipersonal (o por cuenta propia), los hombres tienen 8.7 puntos porcentuales menos de probabilidad de trabajar por cuenta propia que las mujeres, cada año adicional de escolaridad disminuye en 1.5 puntos porcentuales la probabilidad de trabajar por cuenta propia, cada año adicional de edad aumenta en 0.5 puntos porcentuales la probabilidad de trabajar por cuenta propia, y tener un oficio calificado disminuye en 10 puntos porcentuales la probabilidad de trabajar por cuenta propia, todos los efectos marginales son estadísticamente significativos. El Cuadro 8.4 muestra los efectos marginales sobre la probabilidad de trabajar en una empresa grande, los hombres tienen 6.7 puntos porcentuales más de probabilidad de trabajar en una empresa grande que las mujeres, cada año de escolaridad aumenta en 1.2 puntos porcentuales la probabilidad de trabajar en una empresa grande, cada año adicional de edad disminuye en 0.4 puntos porcentuales la probabilidad de trabajar en empresa grande, y tener un oficio calificado aumenta en los puntos porcentuales la probabilidad de trabajar en una empresa grande.

Cuadro 8.3
Efectos Marginales Probit Ordenado Tamaño de Empresa
Pr[Tamaño empresa=1]

```
. mfx, predict(outcome(1))
```

Marginal effects after oprobit
y = Pr(tamaño_empresa==1) (predict, outcome(1))
= .23253887

variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]	x
dhombre*	-.0877832	.00263	-33.41	0.000	-.092933	-.082634		.639418
esc	-.0146443	.00036	-40.18	0.000	-.015359	-.01393		9.95658
edad	.0048249	.00009	50.87	0.000	.004639	.005011		41.7025
califi~o*	-.099998	.00307	-32.58	0.000	-.106013	-.093983		.147076

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Cuadro 8.4
Efectos Marginales Probit Ordenado Tamaño de Empresa
Pr[Tamaño empresa=200 y más]

```
. mfx, predict(outcome(6))
```

Marginal effects after oprobit
y = Pr(tamaño_empresa==6) (predict, outcome(6))
= .16436743

variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]	x
dhombre*	.0666815	.00189	35.33	0.000	.062982	.070381		.639418
esc	.0118691	.0003	39.98	0.000	.011287	.012451		9.95658
edad	-.0039105	.00008	-50.37	0.000	-.004063	-.003758		41.7025
califi~o*	.1008457	.00384	26.24	0.000	.093312	.108379		.147076

(*) dy/dx is for discrete change of dummy variable from 0 to 1

El modelo puede ser estimado también bajo el supuesto de distribución logística del error utilizando el comando `ologit`, ejecutando los siguientes comandos podemos comparar los efectos marginales sobre la probabilidad de trabajar por cuenta propia de la estimación `oprobit` y `ologit` en el Cuadro 8.5:

```
qui oprobit tamaño_empresa dhombre esc edad calificado
qui mfx, predict(outcome(1))
estimates store oprobit1
```

```

qui ologit tamaño_empresa dhombre esc edad calificado
qui mfx, predict(outcome(1))
estimates store ologit1
outreg2 [oprobit1 ologit1] using order, replace mfx see

```

Cuadro 8.5
Efectos Marginales Probit Ordenado Tamaño de Empresa
Pr[Tamaño empresa=1]
Comparación oprobit y ologit

		(1)	(2)	
		oprobit1	ologit1	Standard errors in parentheses
EQUATION	VARIABLES	tamaño_empresa	tamaño_empresa	*** p<0.01, ** p<0.05, * p<0.1
tamaño_empresa	dhombre	-0.0878***	-0.0875***	
		(0.00263)	(0.00262)	
	esc	-0.0146***	-0.0141***	
		(0.000364)	(0.000359)	
	edad	0.00482***	0.00464***	
		(9.48e-05)	(9.26e-05)	
	calificado	-0.1000***	-0.0952***	
		(0.00307)	(0.00289)	
	Observations	77,178	77,178	

Una vez estimado el modelo podemos utilizar el comando predict para obtener la probabilidad predicha de cada una de las alternativas de la variable dependiente condicional en las características del individuo:

```
predict categ1 categ2 categ3 categ4 categ5 categ6 if e(sample), pr
```

El Cuadro 8.6 muestra el promedio, mínimo y máximo de las probabilidades predichas para cada una de las categorías de la variable dependiente ordenada, la probabilidad predicha para trabajar como cuenta propia toma como mínimo 0.045 y como máximo 0.77, el valor promedio es 0.25. Con respecto a la probabilidad predicha de trabajar en empresa grande el valor mínimo es 0.018 y máximo 0.56 con un valor promedio de 0.18.


Cuadro 8.6
Predicción Probit Ordenado Tamaño de Empresa

. sum categ1- categ6					
Variable	Obs	Mean	Std. Dev.	Min	Max
categ1	77178	.2506796	.1194149	.0446465	.7669665
categ2	77178	.1928858	.0380243	.0631451	.2330869
categ3	77178	.0650852	.0078017	.0241893	.0718866
categ4	77178	.1881605	.030214	.0455408	.2152678
categ5	77178	.1219126	.0378241	.0179893	.1797676
categ6	77178	.1812763	.0944363	.0174496	.5557

Ahora si queremos graficar la relación entre la probabilidad de trabajar en empresa grande (según el modelo) y la edad de la persona, debemos realizar lo siguiente:

```
oprobit tamaño_empresa dhombre esc edad calificado
sum dhombre esc edad calificado if e(sample)
g xb_oprobit=_b[dhombre]*0.64+_b[esc]*9.96+_b[edad]*edad
+_b[calificado]*0.147
g prob_oprobit1=1-normal(_b[/cut5]-xb_oprobit)
twoway (scatter prob_oprobit1 edad) if e(sample),
yttitle(Probabilidad de Trabajar en Empresa Grande) xtitle(Edad)
```

Gráfico 8.1
Probabilidad de Trabajar en Empresa Grande versus Edad



8.2. Modelos Multinomiales

En la mayoría de los casos de modelos donde la variable dependiente es categórica no existe un orden natural de las alternativas, y por lo tanto, no es realista asumir que existe una relación monótona entre una variable latente y los resultados categóricos observados, por ejemplo si nuestra variable de interés es el medio de transporte usado por las personas para ir al trabajo, donde las alternativas son auto, micro, metro, bicicleta y caminando. En estos casos se plantea una metodología distinta para darle una estructura a las probabilidades de cada una de las alternativas.

Suponga que nuestra variable dependiente corresponde al resultado de la elección entre M alternativas, indexadas a través de $j = 1, \dots, M$, pero no existe un orden entre las alternativas. La utilidad que obtiene el individuo i de la alternativa j es U_{ij} , y la alternativa j será escogida por el individuo i si esta le entrega la mayor utilidad, es decir, $U_{ij} = \max\{U_{i1}, \dots, U_{iM}\}$.

Sin embargo, U_{ij} para $j = 1, \dots, M$ no son observadas por lo cuál es necesario darme mayor estructura al modelo, específicamente se asume que la utilidad que obtienen el individuo i de la alternativa j es una función de variables observables y de factores no observables:

$$U_{ij} = x'_{ij}\beta_j + u_{ij}$$

Luego la probabilidad de elegir la alternativa j es:

$$\begin{aligned} Pr[y_i = j] &= Pr[U_{ij} = \max\{U_{i1}, \dots, U_{iM}\}] \\ &= Pr \left[x'_{ij}\beta_j + u_{ij} > \max_{k=1, \dots, M, k \neq j} \{x'_{ik}\beta_k + u_{ik}\} \right] \end{aligned}$$

Bajo el supuesto de que u_{ij} son independientes y con función de distribución de probabilidad Weibull (o Extreme Value Tipo I), es decir, la función de distribución de probabilidad de cada u_{ij} es:

$$F(t) = \exp\{-e^{-t}\}$$

Así, bajo estos supuestos se tiene que la probabilidad de cada alternativa:

$$p_j = Pr[y_i = j] = \frac{\exp(x'_{ij}\beta_j)}{\exp(x'_{i1}\beta_1) + \dots + \exp(x'_{iM}\beta_M)}$$

Una vez definida la probabilidad de cada una de las alternativas se puede estimar el modelo por Máxima Verosimilitud, para esto definamos y_{ij} de la siguiente

manera:

$$y_{ij} = \begin{cases} 1 & \text{si } y = j \\ 0 & \text{si } y \neq j \end{cases}$$

Luego la función de verosimilitud de este modelo es:

$$L = \prod_{i=1}^N \prod_{j=1}^M p_{ij}^{y_{ij}}$$

o la función log-likelihood:

$$\ln L = \sum_{i=1}^N \sum_{j=1}^M y_{ij} \ln(p_{ij})$$

Maximizando esta función con respecto a β se obtiene el estimador Máximo Verosímil de los coeficientes del modelo, sin embargo, estos coeficientes no representan los efectos marginales de las variables explicativas sobre la probabilidad de escoger la alternativa j .

En el modelo planteado podemos notar que tanto las variables explicativas como los coeficientes varían con las alternativas, sin embargo, en la práctica un modelo así planteado no está identificado y no se puede estimar. Cuando el modelo es tal que los regresores varían entre alternativas, por lo tanto los coeficientes son constantes para todas las alternativas, el modelo es denominado **Conditional Logit**. Por el contrario, cuando los regresores no varían entre alternativas pero sí los coeficientes, el modelo se denomina **Multinomial Logit**. Los dos modelos pueden ser combinados en un modelo denominado **Mixed Logit**, donde un conjunto de variables explicativas varían entre alternativas y las restantes variables explicativas no varían entre alternativas.

8.2.1. Conditional Logit

En el modelo Conditional Logit las probabilidades de cada una de las alternativas se expresan de la siguiente manera:

$$p_{ij} = \frac{\exp(x'_{ij}\beta)}{\sum_{k=1}^M \exp(x'_{ik}\beta)}$$

Definidas estas probabilidades se puede construir la función de verosimilitud y estimar β , sin embargo, para interpretar el modelo se deben computar los efectos

marginales:

$$\frac{\partial p_{ij}}{\partial x_{il}} = p_{ij}(\delta_{ijl} - p_{il})\beta$$

donde δ_{ijl} es una variable binaria que toma valor 1 cuando $j = l$ y 0 cuando $j \neq l$.

Consideremos el siguiente ejemplo de Herriges y Kling (1999) donde se analizan los distintos modos de pesca en función de algunas características de los individuos como el ingreso y otras características específicas de las alternativas como precio y tasa de captura. En el Cuadro 8.7 se muestra la descripción de las variables contenidas en la base de datos.

Cuadro 8.7
Descripción Base de Datos Modos de Pesca

obs:	1,182			
vars:	16			26 Nov 2008 17:16
size:	80,376	(99.8% of memory free)		
variable name	storage type	display format	value label	variable label
mode	float	%9.0g	modetype	Fishing mode
price	float	%9.0g		price for chosen alternative
crate	float	%9.0g		catch rate for chosen alternative
dbeach	float	%9.0g		1 if beach mode chosen
dpier	float	%9.0g		1 if pier mode chosen
dprivate	float	%9.0g		1 if private boat mode chosen
dcharter	float	%9.0g		1 if charter boat mode chosen
pbeach	float	%9.0g		price for beach mode
ppier	float	%9.0g		price for pier mode
pprivate	float	%9.0g		price for private boat mode
pcharter	float	%9.0g		price for charter boat mode
qbeach	float	%9.0g		catch rate for beach mode
qpier	float	%9.0g		catch rate for pier mode
qprivate	float	%9.0g		catch rate for private boat mode
qcharter	float	%9.0g		catch rate for charter boat mode
income	float	%9.0g		monthly income in thousands \$

El Cuadro 8.8 muestra la distribución de frecuencia de la variable de interés, modelo de pesca, un 11.3 % de las personas escogen pescar en la playa, un 15.1 % en un muelle, un 35.4 % en un bote privado, y un 38.2 % en un bote compartido.

En el modelos Conditional Logit sólo se pueden utilizar variables que varían entre alternativas, en este ejemplo serían el precio y tasa de captura. En el Cuadro 8.9 podemos notar que el formato de la base de datos es *wide*, para poder estimar el modelo primero necesitamos cambiar el formato de la base de datos a formato *long*.

Cuadro 8.8
Distribución de Frecuencia Modo de Pesca

. tab mode			
Fishing mode	Freq.	Percent	Cum.
beach	134	11.34	11.34
pier	178	15.06	26.40
private	418	35.36	61.76
charter	452	38.24	100.00
Total	1,182	100.00	

Cuadro 8.9
Datos Modo de Pesca

mode	price	crate	pbeach	ppier	pprivate	pcharter	qbeach	qpier	qprivate	qcharter
charter	182.93	.5391	157.93	157.93	157.93	182.93	.0678	.0503	.2601	.5391
charter	34.534	.4671	15.114	15.114	10.534	34.534	.1049	.0451	.1574	.4671
private	24.334	.2413	161.874	161.874	24.334	59.334	.5333	.4522	.2413	1.0266
pier	15.134	.0789	15.134	15.134	55.93	84.93	.0678	.0789	.1643	.5391
private	41.514	.1082	106.93	106.93	41.514	71.014	.0678	.0503	.1082	.324
charter	63.934	.3975	192.474	192.474	28.934	63.934	.5333	.4522	.1665	.3975
beach	51.934	.0678	51.934	51.934	191.93	220.93	.0678	.0789	.1643	.5391
charter	56.714	.0209	15.134	15.134	21.714	56.714	.0678	.0789	.0102	.0209
private	34.914	.0233	34.914	34.914	34.914	53.414	.2537	.1498	.0233	.0219
private	28.314	.0233	28.314	28.314	28.314	46.814	.2537	.1498	.0233	.0219
pier	34.914	.0451	34.914	34.914	24.334	48.334	.1049	.0451	.1574	.4671
private	16.722	.2413	312.144	312.144	16.722	51.722	.5333	.4522	.2413	1.0266
pier	17.862	.0451	17.862	17.862	4.122	28.122	.1049	.0451	.0023	.0046
pier	15.134	.0789	15.134	15.134	55.93	84.93	.0678	.0789	.0014	.0029
beach	74.514	.2537	74.514	74.514	74.514	93.014	.2537	.1498	.2339	.6288
pier	33.534	.0789	33.534	33.534	123.93	152.93	.0678	.0789	.1643	.5391

El Cuadro 8.10 muestra el comando ejecutado para cambiar el formato de la base de datos, y el Cuadro 8.11 el resultado donde cada observación corresponde a los datos de un individuo i para la alternativa j .

Cuadro 8.10
Cambio Formato Base de Datos

```
. g id=_n
. reshape long d p q, i(id) j(fishmode beach pier private charter) string
```

Data	wide	->	long
Number of obs.	1182	->	4728
Number of variables	17	->	9
j variable (4 values)		->	fishmode
xij variables:			
	dbeach dpier ... dcharter	->	d
	pbeach ppier ... pcharter	->	p
	qbeach qpier ... qcharter	->	q

Cuadro 8.11
Datos Modo de Pesca en Formato Long

	id	fishmode	mode	price	crate	d	p	q	income
1	1	beach	charter	182.93	.5391	0	157.93	.0678	7.083332
2	1	charter	charter	182.93	.5391	1	182.93	.5391	7.083332
3	1	pier	charter	182.93	.5391	0	157.93	.0503	7.083332
4	1	private	charter	182.93	.5391	0	157.93	.2601	7.083332
5	2	beach	charter	34.534	.4671	0	15.114	.1049	1.25
6	2	charter	charter	34.534	.4671	1	34.534	.4671	1.25
7	2	pier	charter	34.534	.4671	0	15.114	.0451	1.25
8	2	private	charter	34.534	.4671	0	10.534	.1574	1.25
9	3	beach	private	24.334	.2413	0	161.874	.5333	3.75
10	3	charter	private	24.334	.2413	0	59.334	1.0266	3.75
11	3	pier	private	24.334	.2413	0	161.874	.4522	3.75
12	3	private	private	24.334	.2413	1	24.334	.2413	3.75

El Cuadro 8.12 muestra la estimación del modelo Conditional Logit para la elección de modo de pesca en función del precio de cada alternativa y de la tasa de captura de cada alternativa, el modelo muestra un ajuste medido a través del pseudo- R^2 de 0.20. Sin embargo, la información presentada en este cuadro no tiene interpretación como efectos marginales de las variables explicativas sobre la probabilidad de elegir cada una de las alternativas de modos de pesca.

Cuadro 8.12
Conditional Logit Modo de Pesca

```
. clogit d p q, group(id)
```

Iteration 0: log likelihood = **-1360.1218**
Iteration 1: log likelihood = **-1312.5912**
Iteration 2: log likelihood = **-1311.981**
Iteration 3: log likelihood = **-1311.9796**
Iteration 4: log likelihood = **-1311.9796**

Conditional (fixed-effects) logistic regression Number of obs = **4728**
LR chi2(2) = **653.24**
Prob > chi2 = **0.0000**
Pseudo R2 = **0.1993**

Log likelihood = **-1311.9796**

	d	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
	p	-.0204765	.0012231	-16.74	0.000	-.0228737 -0.0180794
	q	.9530985	.0894134	10.66	0.000	.7778514 1.128346

Para obtener los efectos marginales debemos ejecutar el comando `estat mfx`, este comando entrega como resultado los efectos marginales de los precios de cada alternativa y tasa de captura de cada alternativa sobre las probabilidades de escoger cada una de las alternativas, el Cuadro 8.13 muestra parte del resultado de este comando, el que corresponde a los efectos marginales sobre la probabilidad de escoger la alternativa barco privado.

Cuadro 8.13
Efectos Marginales Conditional Logit
Probabilidad escoger barco privado

Pr(choice = private|1 selected) = **.41956284**

variable	dp/dx	Std. Err.	z	P> z	[	95% C.I.	]	x
P								
beach	.000568	.000056	10.16	0.000	.000458	.000677		103.42
charter	.00472	.000437	10.80	0.000	.003863	.005576		84.379
pier	.000749	.000066	11.30	0.000	.000619	.000879		103.42
private	-.006037	.000437	-13.82	0.000	-.006893	-.005181		55.257
q								
beach	-.008641	.002758	-3.13	0.002	-.014047	-.003235		.24101
charter	-.071807	.020968	-3.42	0.001	-.112904	-.030711		.62937
pier	-.011403	.003586	-3.18	0.001	-.018432	-.004375		.16222
private	.091852	.026806	3.43	0.001	.039314	.14439		.17121

Los resultados nos muestra que cada dólar adicional de costo de la alternativa playa aumenta en 0.06 puntos porcentuales la probabilidad de escoger barco privado, cada dólar adicional de costo de la alternativa barco compartido aumenta en 0.47 puntos porcentuales la probabilidad de escoger la alternativa barco privado, cada dólar adicional de la alternativa muelle aumenta en 0.075 puntos porcentuales la probabilidad de escoger barco privado, y cada dólar adicional de costo de la alternativa barco privado disminuye en 0.6 puntos porcentuales la probabilidad de escoger esta alternativa. Por otra parte, un aumento en un punto en la tasa de captura en la alternativa playa disminuye en 0.0086 puntos porcentuales la probabilidad de escoger la alternativa barco privado, un aumento en un punto en la tasa de captura de barco compartido disminuye en 0.072 puntos porcentuales la probabilidad de escoger barco privado, un aumento en un punto en la tasa de captura de la alternativa muelle disminuye en 0.011 puntos porcentuales la probabilidad de escoger barco privado, y un aumento en un punto en la tasa de captura de la alternativa barco privado aumenta en 0.092 puntos porcentuales la probabilidad de escoger esta alternativa.

8.2.2. Multinomial Logit

Muchos de las aplicaciones de modelos multinomiales están basados en base de datos con información de variables que no varían entre alternativas sino sólo entre individuos. En este caso los modelos son estimados mediante la metodología Multinomial Logit.

En este modelo la probabilidad de cada una de las alternativas es igual a:

$$p_{ij} = \frac{\exp(x'_i \beta_j)}{\sum_{l=1}^M \exp(x'_i \beta_l)}$$

La estimación de este tipo de modelos requiere que los coeficientes de una de las alternativas (usualmente la primera) sean normalizados a cero, es decir, $\beta_1 = 0$. Notemos que con esta normalización, la probabilidad de la alternativa j condicional en que se escoge la alternativa 1 (normalizada) o la alternativa j es:

$$Pr[y_i = j | y_i = j \text{ o } y_i = 1] = \frac{\exp(x'_i \beta_j)}{1 + \exp(x'_i \beta_j)}$$

lo que corresponde a estimar un modelo Logit de la alternativa j contra la alternativa base o normalizada.

Nuevamente los coeficientes estimados no son de interés para el análisis sino los

efectos marginales, los que se pueden computar una vez estimado el modelo de la siguiente forma:

$$\frac{\partial p_{ij}}{\partial x_i} = p_{ij}(\beta_j - \bar{\beta}_i)$$

donde $\bar{\beta}_i = \sum_l p_{il}\beta_l$.

El Cuadro 8.14 muestra la estimación del modelo Multinomial Logit utilizando el comando `mlogit`, en este caso la elección de modo de pesca es explicada por una única variable correspondiente al ingreso de la persona, esta variable es constante para un individuo entre las distintas alternativas. Para aplicar este comando el formato de la base de datos debe ser *wide*, es decir, una sola observación por individuo donde aparezca el modelo de pesca escogido y el ingreso.

Cuadro 8.14
Multinomial Logit Modo de Pesca

```
. mlogit mode income, baseoutcome(1)
```

Iteration 0: log likelihood = **-1497.7229**
Iteration 1: log likelihood = **-1477.5265**
Iteration 2: log likelihood = **-1477.1514**
Iteration 3: log likelihood = **-1477.1506**
Iteration 4: log likelihood = **-1477.1506**

Multinomial logistic regression

Log likelihood = **-1477.1506**

	Number of obs	=	1182
	LR chi2(3)	=	41.14
	Prob > chi2	=	0.0000
	Pseudo R2	=	0.0137

mode	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
beach	(base outcome)					
pier						
income	-.1434029	.0532884	-2.69	0.007	-.2478463	-.0389595
_cons	.8141503	.228632	3.56	0.000	.3660399	1.262261
private						
income	.0919064	.0406637	2.26	0.024	.0122069	.1716058
_cons	.7389208	.1967309	3.76	0.000	.3533352	1.124506
charter						
income	-.0316399	.0418463	-0.76	0.450	-.1136571	.0503774
_cons	1.341291	.1945167	6.90	0.000	.9600457	1.722537

Sin embargo, el cuadro anterior no nos entrega información interesante para interpretar los resultados, analizar el modelo debemos computar los efectos marginales lo que se hace con el comando `mfx, predict(pr outcome(j))`. Por ejemplo, el

Cuadro 8.15 muestra los efectos marginales de ingreso sobre la probabilidad de escoger la alternativa barco privado.

Cuadro 8.15
Efectos Marginales Multinomial Logit
Probabilidad escoger barco privado

<pre>. mfx, predict(pr outcome(3)) Marginal effects after mlogit y = Pr(mode==private) (predict, pr outcome(3)) = .35220366</pre>							
variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]
income	.0325985	.00569	5.73	0.000	.021442	.043755	4.09934

Un aumento en mil dólares de ingreso aumenta en 3.3 puntos porcentuales la probabilidad de escoger la alternativa barco privado para ir a pescar. El Cuadro 8.16 muestra que cambiar la categoría base cambia los coeficientes estimados, pero no así los efectos marginales.

8.2.3. Mixed Logit

En este caso se combina la utilización de variables explicativas que varían entre alternativas con variables explicativas que no varían entre alternativas. En este caso la probabilidad de la alternativa j es:

$$p_{ij} = \frac{\exp(x'_{ij}\beta + z'_i\gamma_j)}{\sum_{l=1}^M \exp(x'_{il}\beta + z'_i\gamma_l)}$$

donde x_{ij} son las variables explicativas que varían entre alternativas y z_i son las variables que no varían entre alternativas.

Definidas las probabilidades de cada alternativa se construye la función de verosimilitud la cual es maximizada con respecto a β y γ para obtener los coeficientes estimados, nuevamente estos coeficientes no representan los efectos marginales de las variables explicativas sobre la probabilidad de escoger la alternativa j , los efectos marginales deben ser computados luego de estimar el modelo.

Cuadro 8.16
Efectos Marginales Multinomial Logit
Probabilidad escoger barco privado

. mlogit mode income, baseoutcome(3) nolog						
Multinomial logistic regression			Number of obs =		1182	
			LR chi2(3) =		41.14	
			Prob > chi2 =		0.0000	
Log likelihood = -1477.1506			Pseudo R2 =		0.0137	
mode	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
beach						
income	-.0919064	.0406637	-2.26	0.024	-.1716058	-.0122069
_cons	-.7389208	.1967309	-3.76	0.000	-1.124506	-.3533352
pier						
income	-.2353093	.0436681	-5.39	0.000	-.3208971	-.1497214
_cons	.0752295	.1832396	0.41	0.681	-.2839134	.4343724
private	(base outcome)					
charter						
income	-.1235462	.0279106	-4.43	0.000	-.17825	-.0688425
_cons	.6023707	.1360964	4.43	0.000	.3356267	.8691147
. mfx, predict(pr outcome(3))						
Marginal effects after mlogit						
y = Pr(mode==private) (predict, pr outcome(3))						
= .35220366						
variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	
income	.0325985	.00569	5.73	0.000	.021442	.043755
						4.09934

El comando `asclogit` permite estimar modelos de variable dependiente categórica no ordinal cuando hay variables explicativas que varían entre alternativas y otras que no varían entre alternativas, la base de datos debe estar en formato `long`:

```
use "mus15data.dta", clear
g id=_n
reshape long d p q, i(id) j(fishmode beach pier private charter) string
```

El Cuadro 8.17 muestra el resultado de la estimación de un modelo mixed logit donde la variable dependiente es el modo de pesca y las variables explicativas son el ingreso (no varía entre alternativas), el precio (si varía entre alternativas) y la tasa de captura (si varía entre alternativas). Luego mediante el comando `estat mfx` podemos obtener los efectos marginales para cada una de las alternativas, el Cuadro 8.18 muestra parte del resultado de este comando, lo que corresponde a los efectos marginales sobre la alternativa barco privado.

Cuadro 8.17
Mixed Logit Modo de Pesca

. asclogit d p q, case(id) alternatives(fishmode) casevars(income) basealternative(beach) nolog						
Alternative-specific conditional logit			Number of obs	=	4728	
Case variable: id			Number of cases	=	1182	
Alternative variable: fishmode			Alts per case: min	=	4	
			avg	=	4.0	
			max	=	4	
Log likelihood = -1215.1376			wald chi2(5)	=	252.98	
			Prob > chi2	=	0.0000	
d		Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
fishmode						
	p	-.0251166	.0017317	-14.50	0.000	-.0285106 -.0217225
	q	.357782	.1097733	3.26	0.001	.1426302 .5729337
beach		(base alternative)				
charter						
	income	-.0332917	.0503409	-0.66	0.508	-.131958 .0653745
	_cons	1.694366	.2240506	7.56	0.000	1.255235 2.133497
pier						
	income	-.1275771	.0506395	-2.52	0.012	-.2268288 -.0283255
	_cons	.7779593	.2204939	3.53	0.000	.3457992 1.210119
private						
	income	.0894398	.0500671	1.79	0.074	-.0086898 .1875694
	_cons	.5272788	.2227927	2.37	0.018	.0906132 .9639444

Cuadro 8.18
Efectos Marginales Mixed Logit Modo de Pesca
Probabilidad de escoger barco privado

Pr(choice = private 1 selected) = .41959373							
variable		dp/dx	Std. Err.	z	P> z	[95% C.I.]	x
p	beach	.000553	.000056	9.88	0.000	.000443 .000663	103.42
	charter	.00487	.000452	10.77	0.000	.003983 .005756	84.379
	pier	.000694	.000066	10.58	0.000	.000565 .000822	103.42
	private	-.006117	.000444	-13.77	0.000	-.006987 -.005246	55.257
q	beach	-.00788	.002647	-2.98	0.003	-.013068 -.002691	.24101
	charter	-.069367	.021306	-3.26	0.001	-.111125 -.027609	.62937
	pier	-.009886	.003283	-3.01	0.003	-.016321 -.00345	.16222
	private	.087132	.026755	3.26	0.001	.034693 .139571	.17121
casevars							
	income	.031761	.006554	4.85	0.000	.018915 .044608	4.0993

8.2.4. Independencia de Alternativas Irrelevantes

Una limitación de los modelos Conditional Logit y Multinomial Logit es que la comparación de las M alternativas se reduce a una serie de comparaciones entre pares de alternativas, ya habíamos mostrado que en estos modelos se obtiene un resultado equivalente estimado modelos logit de una alternativa contra la alternativa base. Es así, como bajo este tipo de modelos sacar una de las alternativas no debería afectar los resultados obtenidos, si por el contrario al sacar una de las alternativas en la variable dependiente las estimaciones cambian, los supuestos detrás de estos modelos no se están cumpliendo, por lo cual no tienen una forma funcional que caracterice bien los datos. La Independencia de Alternativas Irrelevantes (IIA) se puede testear a través de un test de Hausman, este test consiste en comparar los coeficientes del modelo con todas las alternativas versus la estimación del modelo donde una de las alternativas es eliminada.

Volvamos a nuestro ejemplo de los modos de pesca, específicamente el modelo donde esta variable es función del ingreso y la estimación corresponde a un Multinomial Logit, primero debemos estimar el modelo y guardar los resultados:

```
mlogit mode income, baseoutcome(4)
estimates store completa
```

Luego estimamos el modelo sin considerar la primera alternativa:

```
mlogit mode income if mode!=1, baseoutcome(4)
estimates store sin1
```

Con los resultados de las dos estimaciones podemos utilizar el comando **hausman** para testear la hipótesis nula de que los coeficientes de los dos modelos son iguales, si no se puede rechazar la hipótesis nula la metodología Multinomial Logit es validada. El Cuadro 8.19 muestra el resultado del test de hausman para la categoría 1 (playa), el resultado nos muestra que no se puede rechazar la hipótesis nula de que los coeficiente son iguales, en este caso se cumple el supuesto de IIA. El test se debe realizar para cada una de las alternativas.

Cuadro 8.19
Test de Hausman: Alternativa Playa

```
. hausman sin1 completa, alleqs constant
```

		Coefficients			
		(b) sin1	(B) completa	(b-B) Difference	sqrt(diag(v_b-v_B)) S.E.
pier	income	-.1140713	-.111763	-.0023083	.0069276
	_cons	-.5188148	-.5271412	.0083263	.0241913
private	income	.1250193	.1235462	.001473	.0038754
	_cons	-.6085431	-.6023707	-.0061724	.016031

b = consistent under Ho and Ha; obtained from mlogit
 B = inconsistent under Ha, efficient under Ho; obtained from mlogit
 Test: Ho: difference in coefficients not systematic
 $\chi^2(4) = (b-B)'[(v_b-v_B)^{-1}](b-B)$
 $= 0.70$
 Prob>chi2 = 0.9519

Existe el comando `mlogtest`, `hausman` que entrega el resultado para todas las alternativas, el Cuadro 8.20 muestra los resultados. En este caso se rechaza la estimación Multinomial Logit para este modelo ya que al sacar la alternativa barco privado se rechaza la hipótesis nula de que los coeficientes con la alternativa sean iguales a los coeficientes sin la alternativa.

Cuadro 8.20
Test de Hausman

```
. mlogtest, hausman
```

Problem determining number of categories.

**** Hausman tests of IIA assumption

Ho: Odds(Outcome-J vs Outcome-K) are independent of other alternatives.
You used the old syntax of **hausman**. click [here](#) to learn about the new syntax.

(storing estimation results as _HAUSMAN)

Omitted	chi2	df	P>chi2	evidence
beach	0.706	4	0.951	for Ho
pier	4.619	4	0.329	for Ho
private	0.091	4	0.999	for Ho
charter	34.474	4	0.000	against Ho

8.2.5. Modelo Nested Logit


Los modelos Multinomial Logit y Conditional Logit asumen que los errores en la función de utilidad:

$$U_{ij} = x'_{ij}\beta_j + u_{ij}$$

son independientes e idénticamente distribuidos extreme value tipo I, por lo cuál las alternativas no están relacionadas entre ellas, y el modelo es equivalente a estimar un modelo logit de una alternativa contra otra.

Este modelo puede ser generalizado permitiendo algún tipo de correlación entre los errores, una forma de permitir correlación es a través del [Modelo Nested Logit](#) donde las alternativas de la variable dependiente son divididas en dos grupos, dentro de cada grupo los errores pueden estar correlacionados pero no existe correlación entre grupos. Este tipo de modelo requiere una estructura secuencial en la elección de alternativas, por ejemplo, en la elección del modo de pesca se puede suponer que primero la persona decide si pescar en la orilla de la playa o en bote, luego condicional en que elige la orilla de la playa debe elegir si pesca en la playa o en un muelle, y condicional a que escoge pescar en bote debe escoger si en uno privado o uno público. La Figura 8.1 muestra el diagrama de estas decisiones.

Figura 8.1
Decisión Anidada de Modo de Pesca



Denotaremos el conjunto de alternativas en el primer nivel por el subíndice j y las del segundo nivel por k . Así, en este modelo la utilidad de la alternativa (j, k) es:

$$U_{jk} = z'_j\alpha + x'_{jk}\beta_j + u_{jk}$$

donde z_j varían entre las alternativas del primer nivel, y x_{jk} varían entre las alternativas del primer nivel y segundo nivel. El Modelo Nested Logit asume que $(u_{j1}, u_{j2}, \dots, u_{jK})$ se distribuyen con distribución multivariada extreme value Gumbel, y bajo este supuesto la probabilidad que la alternativa (j, k) sea escogida es:

$$p_{jk} = p_j \times p_{k|j} \\ = \frac{\exp(z'_j \alpha + \tau_j I_j)}{\sum_{m=1}^J \exp(z'_m \alpha + \tau_m I_m)} \times \frac{\exp(x'_{jk} \beta_j / \tau_j)}{\sum_{l=1}^{K_j} \exp(x'_{jl} \beta_j / \tau_j)}$$

donde $I_j = \ln \left[\sum_{l=1}^{K_j} \exp(x'_{jl} \beta_j / \tau_j) \right]$. El parámetro τ_j es llamado *dissimilarity parameter*, para que el modelo sea consistente se requiere que $0 \leq \tau_j \leq 1$, si este parámetro es igual a 1 el modelo converge a un Conditional Logit.

El comando para estimar este tipo de modelos es `nlogit`, sin embargo antes de utilizar este comando se debe construir una variable que especifique la estructura del árbol de decisiones con el comando `nlogitgen`. El Cuadro 8.21 muestra la definición de la variable con el árbol de decisión diagramado en la Figura 8.1. Primero debemos transformar la base de datos en formato long:

```
use mus15data.dta, clear
g id=_n
reshape long d p q, i(id) j(fishmode beach pier private charter) string
```

Luego utilizamos el comando `nlogitgen`:

Cuadro 8.21

Definición Árbol de Decisiones Modo de Pesca

```
. nlogitgen type=fishmode(shore: pier | beach, boat: private | charter)
new variable type is generated with 2 groups
label list lb_type
lb_type:
      1 shore
      2 boat
```

Para verificar el árbol de decisiones se puede utilizar el comando `nlogittree`, tal como muestra el Cuadro 8.22. El primer nivel quedo definido como shore (orilla) o boat (barco), de la opción shore del primer nivel se desprenden dos alternativas beach (playa) o muelle (pier), y de la opción boat las alternativas private (privado) o charter (compartido). En la columna k se indica la cantidad de observaciones que eligen cada una de las alternativas.

Cuadro 8.22
Árbol de Decisiones Modo de Pesca

```
. nlogittree fishmode type, choice(d)
```

tree structure specified for the nested logit model

type	N	fishmode	N	k
shore	2364	beach	1182	134
		pier	1182	178
boat	2364	charter	1182	452
		private	1182	418
		total	4728	1182

k = number of times alternative is chosen
N = number of observations at each level

El Cuadro 8.23 muestra la estimación del modelo de elección de modo de pesca en función de las variables precio, tasa de captura, e ingreso. Al igual que en los otros modelos los coeficientes estimados no tienen interpretación de efectos marginales, pero lamentablemente el comando `mfxx` (efectos marginales en el promedio) o `margeff` (efectos marginales promedio) no se pueden aplicar para este comando. La última parte del resultado del comando `nlogit` muestra el test de razón de verosimilitud para la hipótesis nula conjunta de que $\tau = 1$ o de que el modelo Conditional Logit es apropiado (las alternativas son independientes), la cual es rechazada. Sin embargo, ambos parámetros son mayores a 1 por lo cual tampoco es un modelo consistente el Nested Logit.

Si el modelo fuese válido los efectos marginales (promedios) podrían ser calculados manualmente siguiendo los siguientes pasos:

1. Obtener las probabilidades predichas según el modelo para todas las observaciones
2. Cambiar uno de los regresores en un valor pequeño (delta)
3. Volver a obtener las probabilidades predichas por el modelo con este cambio en uno de los regresores
4. Restar los dos valores predichos y dividir delta.
5. El efecto marginal promedio corresponde al promedio de lo calculado en el paso anterior.

Cuadro 8.23
Estimación Nested Logit Modo de Pesca

. nlogit d p q type:, base(shore) fishmode: income, case(id) notree nolog						
RUM-consistent nested logit regression			Number of obs	=	4728	
Case variable: id			Number of cases	=	1182	
Alternative variable: fishmode			Alts per case: min	=	4	
			avg	=	4.0	
			max	=	4	
Log likelihood = -1192.4236			wald chi2(5)	=	212.37	
			Prob > chi2	=	0.0000	
d	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
fishmode						
p	-.0267625	.0018937	-14.13	0.000	-.0304741	-.023051
q	1.340078	.3080391	4.35	0.000	.7363329	1.943824
fishmode equations						
beach						
income	(base)					
_cons	(base)					
charter						
income	-8.402969	78.34197	-0.11	0.915	-161.9504	145.1445
_cons	69.96747	558.6645	0.13	0.900	-1024.995	1164.93
pier						
income	-9.458769	80.28494	-0.12	0.906	-166.8144	147.8968
_cons	58.94565	500.589	0.12	0.906	-922.1908	1040.082
private						
income	-1.634704	8.583156	-0.19	0.849	-18.45738	15.18797
_cons	37.51814	230.7252	0.16	0.871	-414.695	489.7313
dissimilarity parameters						
type						
/shore_tau	83.46671	718.2333			-1324.245	1491.178
/boat_tau	52.56573	542.7797			-1011.263	1116.394
LR test for IIA (tau = 1):			chi2(2) =	45.43	Prob > chi2 = 0.0000	

Para obtener los efectos marginales promedios del modelo estimado debemos ejecutar los siguientes comandos:

```
predict plevel1 plevel2, pr
qui sum p
g delta=r(sd)/1000
qui replace p=p+delta if fishmode=="beach"
predict pnew1 pnew2, pr
g dpdbeach=(pnew2-plevel2)/delta
```

El Cuadro 8.24 muestra entonces el efecto marginal promedio del precio de la alternativa beach.

Cuadro 8.24
Efectos Marginales Nested Logit Modo de Pesca

. tab fishmode, sum(dpdbeach)			
fishmode	Summary of dpdbeach		Freq.
	Mean	Std. Dev.	
beach	-.00053325	.00047922	1182
charter	.00063588	.00054939	1182
pier	-.00065946	.00057603	1182
private	.00055682	.00051133	1182
Total	-2.363e-09	.00079968	4728
. restore			

8.2.6. Multinomial Probit

Un modelo más general es el [Multinomial Probit](#), donde los errores se asumen que tienen una distribución normal conjunta. Es decir, si la utilidad de la alternativa j es:

$$U_{ij} = x'_{ij}\beta + z'_i\gamma_j + u_{ij}$$

los errores de las alternativas no son independientes sino que tienen una distribución normal conjunta $(u_{i1}, u_{i2}, \dots, u_{iM}) \sim \mathcal{N}(0, \Sigma)$. De esta forma, la probabilidad de escoger la alternativa j es:

$$p_{ij} = Pr[y_i = j] = Pr[u_{ik} - u_{ij} \leq (x_{ij} - x_{ik})'\beta + z'_i(\gamma_j - \gamma_k)], \quad \forall k$$

Esta probabilidad corresponde a una integral de dimensión $(m - 1)$.

El comando `mprobit` es análogo al comando `mlogit`, es decir, sólo se puede aplicar cuando las variables explicativas no varían entre alternativas. El Cuadro 8.25 nos muestra la estimación del modelo de elección de modo de pesca en función del ingreso, que es una variable que no varía entre alternativas. Para poder interpretar el modelo debemos computar los efectos marginales, en el Cuadro 8.26 se presentan los efectos marginales para las alternativas beach y charter, en el caso de la alternativa beach el ingreso no tiene un efecto significativa sobre la probabilidad de escoger esta alternativa, y en el caso de charter se estima que 1000 dólares más de ingreso disminuyen en 1.3 puntos porcentuales la probabilidad de escoger esta alternativa.

Cuadro 8.25
Multinomial Probit Modo de Pesca

```
. mprobit mode income
```

Iteration 0: log likelihood = **-1479.5592**
 Iteration 1: log likelihood = **-1477.7997**
 Iteration 2: log likelihood = **-1477.7976**
 Iteration 3: log likelihood = **-1477.7976**

Multinomial probit regression

Log likelihood = **-1477.7976**

Number of obs	=	1182
Wald chi2(3)	=	37.94
Prob > chi2	=	0.0000

mode	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
beach					
income	.0264354	.0278632	0.95	0.343	-.0281755 .0810462
_cons	-.967472	.1302516	-7.43	0.000	-1.22276 -.7121836
pier					
income	-.0570537	.0282839	-2.02	0.044	-.1124891 -.0016183
_cons	-.4695829	.1232788	-3.81	0.000	-.7112048 -.2279609
private					
income	.1001853	.0225904	4.43	0.000	.0559088 .1444618
_cons	-.4828754	.108252	-4.46	0.000	-.6950455 -.2707054
charter	(base outcome)				

Cuadro 8.26
Efectos Marginales Multinomial Probit Modo de Pesca

```
. mfx, predict(pr outcome(1))
```

Marginal effects after mprobit
 y = Pr(mode==beach) (predict, pr outcome(1))
 = **.11511718**

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	x
income	-.0001255	.00386	-0.03	0.974	-.007681 .007431	4.09934

```
. mfx, predict(pr outcome(4))
```

Marginal effects after mprobit
 y = Pr(mode==charter) (predict, pr outcome(4))
 = **.38569951**

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	x
income	-.0132486	.00605	-2.19	0.028	-.0251 -.001397	4.09934

Capítulo 9

Variable Dependiente Limitada

9.1. Introducción

En este capítulo estudiaremos modelos donde la variable dependiente es continua, sin embargo puede presentar uno de los siguientes problemas:

- La variable de interés se observa de manera incompleta
- La variable de interés se observa de manera completa pero para una muestra seleccionada que no es representativa de la población

Por eso se dice que la variable dependiente es limitada. En este caso, aún cuando se cumplan todos los supuestos que requiere el estimador MCO para ser insesgado y consistente, MCO será inconsistente porque la muestra que se está utilizando para la estimación no es representativa de la población. De esta forma, se requerirá de una metodología alternativa de estimación, con supuestos de distribución mucho más fuerte, para obtener coeficientes estimados de manera consistente.

El primer caso de variable dependiente limitada, donde se observa una muestra incompleta, se puede dar debido al problema de [censura](#) o [truncamiento](#). Una muestra esta truncada cuando no existen datos para algunas observaciones de la variable dependiente y variables explicativas, por ejemplo, si el ingreso es la variable dependiente y sólo se han incluido en la muestra a las personas de bajos ingresos (bajo cierto umbral). Por otra parte, una muestra esta censurada cuando no existen datos de la variable dependiente para ciertas observaciones pero si existen datos para las variables explicativas, por ejemplo, se incluye a personas

de todos los niveles de ingresos en la muestra, pero las personas de altos ingresos son todas codificadas en cierto nivel.

Para los modelos truncados y censurados Tobin (1958) propone un método de estimación consistente de los coeficientes en el contexto de un modelo de regresión lineal con errores normales, conocido como el [Modelo Tobit](#).

El segundo caso de variable dependiente limitada es conocido como [Modelo de Selección](#) (Sample Selection Models), estos modelos son utilizados cuando la muestra no es aleatoria sino que de manera intencional o no intencional esta basada sólo en una parte de los valores que puede tomar la variable dependiente, los parámetros serán inconsistentes a menos que se corrija la estimación. Por ejemplo, se ha observado que el rendimiento de los alumnos en la PSU ha ido empeorando en el tiempo, ya que es menor el porcentaje de alumnos que postulan a una carrera, menor el porcentaje de alumnos seleccionados, y el porcentaje de alumnos bajo 500 puntos (media) en lenguaje y matemáticas se ha incrementado, pero se ha visto que la cantidad de estudiantes que rinden la PSU se ha incrementando en un 63 % desde el año 2003 al 2010, por cual este resultado se puede deber a un incremento en los alumnos de bajo rendimiento que rinden la PSU. En estos modelos la selección puede venir de una auto-selección, la variable de interés dependen de una decisión previa que tomo el individuo de participar o no en cierta actividad de interés, o puede ser resultado de una selección muestral donde los individuos que participan en esta actividad están sobre muestreados o en un caso extremos sólo incluye a los individuos que participan.

9.2. Modelos Censurados y Truncados

Sea y^* la variable de interés que es observada de manera incompleta (variable latente). En el caso de que existe truncamiento por abajo se observa y^* cuando excede cierto valor (umbral), por ejemplo podemos asumir que ese valor es cero. Es decir:

$$y = y^* \quad \text{si} \quad y^* > 0$$

Dado que los valores negativos de la variable de interés no aparecen en la muestra, la media de la variable truncada observada y será mayor a la media de y^* .

En el caso de censura por debajo, y^* no se observa completamente cuando $y^* \leq 0$

pero se sabe que $y^* < 0$ pero se observa $y = 0$, es decir:

$$\begin{aligned} y &= y^* & \text{si } y^* > 0 \\ y &= 0 & \text{si } y^* \leq 0 \end{aligned}$$

Dado que los valores negativos son reemplazados por cero, la media de la variable observada censurada será mayor a la media de la variable y^* . Así, podemos notar claramente que las medias muestrales truncadas y censuradas no pueden ser utilizadas sin ningún tipo de ajuste para estimar la media poblacional.

Consideremos la siguiente ilustración, suponga que las horas trabajadas se determinan según la siguiente relación con el salario por hora:

$$\begin{aligned} y^* &= -25 + 10 \cdot \ln w + u \\ u &\sim N(0, 10^2) \\ \ln w &\sim N(2,75, 0,6^2) \end{aligned}$$

Luego, podemos generar 200 observaciones artificiales de la variable latente y^* :

```
set obs 200

g u=rnormal(0,10)
g lnw=rnormal(2.75,0.6)

g ystar=-25+10*lnw+u

g ytrunc=ystar
replace ytrunc=. if ystar<0

g ycens=ystar
replace ycens=0 if ystar<0
```

Luego podemos notar la diferencia en las medias de las tres variables tal como lo habíamos anticipado:

Cuadro 9.1*Diferencia en medias variable latente, truncada y censurada*

. sum y*					
variable	obs	Mean	Std. Dev.	Min	Max
ystar	200	2.340769	11.63541	-26.58702	33.60682
ytrunc	116	10.26564	7.086578	.3806939	33.60682
ycens	200	5.95407	7.404171	0	33.60682

De esto podemos concluir que al menos se producirá un sesgo en el intercepto de la regresión lineal que relaciona horas trabajadas con salario por hora en logaritmo, ya que hay diferencia en medias entre las tres variables, el problema es que no sólo se genera el sesgo en el intercepto sino también en la pendiente o efecto marginal del modelo. A través de los siguientes comandos realizamos las regresiones con la variable latente, censurada y truncada:

```
reg ystar lnw
estimates store ystar
```

```
reg ycens lnw
estimates store ycens
```

```
reg ytrunc lnw
estimates store ytrunc
```

El siguiente cuadro resume los resultados:

Cuadro 9.2*Diferencia en efectos marginales variable latente, truncada y censurada*


. estimates table ystar ycens ytrunc, b(%7.4f) p(%7.4f)			
variable	ystar	ycens	ytrunc
lnw	8.8190 0.0000	5.7923 0.0000	4.9424 0.0000
_cons	-21.6443 0.0000	-9.7992 0.0000	-3.9404 0.2102
Legend: b/p			

Gráficamente también podemos notar las diferencias:

```
twoway (scatter ystar lnw) (lfit ystar lnw) (lfit ycens lnw)
(lfit ytrunc lnw), legend(order(1 "lnw observado"
2 "Media no censurada" 3 "Media censurada" 4 "Media truncada"))
```

Gráfico 9.1

Diferencia en efectos marginales e intercepto variable latente, truncada y censurada



En términos más generales, hablaremos de **censura por abajo** cuando la variable observada y cumple con:

$$y = \begin{cases} y^* & \text{si } y^* > L \\ L & \text{si } y^* \leq L \end{cases}$$

De manera análoga hablaremos de **censura por arriba** cuando:

$$y = \begin{cases} y^* & \text{si } y^* < U \\ U & \text{si } y^* \geq U \end{cases}$$

Por otra parte, cuando la variable de interés se encuentra **truncada por abajo** se observa y tal que:

$$y = y^* \quad \text{si} \quad y^* > L$$

y si esta **truncada por arriba** se tiene que:

$$y = y^* \quad \text{si} \quad y^* < U$$

9.2.1. Estimación por Máxima Verosimilitud

Si la distribución de y^* condicional en las variables explicativas x es conocida o asumida, los parámetros pueden ser estimados de manera eficiente y consistente por Máxima Verosimilitud, a través de la función de distribución condicional truncada y censurada de la variable observada y .

Sean $f(y^*|x)$ y $F(y^*|x)$ la función de densidad y de probabilidad acumulada de y^* , luego podemos obtener $f(y|x)$ y $F(y|x)$ para la variable observada como una función de las funciones de la variable latente, y así podemos determinar la función de verosimilitud en el caso de censura y truncamiento.

Cuando la variable y es censurada por abajo, se tiene la siguiente función de densidad condicional para la variable y :

$$f(y|x) = \begin{cases} f(y^*|x) & \text{si } y > L \\ F(L|x) & \text{si } y = L \end{cases}$$

Notemos que cuando $y = L$ la densidad es discreta e igual a la probabilidad de que $y \leq L$. De esta forma, la función de densidad condicional de y es una mezcla de la función de densidad y de probabilidad acumulada de y^* .

Definamos la siguiente variable binaria:

$$d = \begin{cases} 1 & \text{si } y > L \\ 0 & \text{si } y = L \end{cases}$$

Luego, la función de densidad condicional de la variable y censurada por abajo en L se puede escribir de la siguiente manera:

$$f(y|x) = f^*(y|x)^d F^*(L|x)^{1-d}$$

Entonces la función de verosimilitud de las N observaciones en la muestra es:

$$\ln L(\theta) = \sum_{i=1}^N [d_i \ln f^*(y_i|x_i, \theta) + (1 - d_i) \ln F^*(L|x_i, \theta)]$$

Ahora, cuando la variable está truncada por abajo en L , la función de densidad de la variable observada y es:

$$\begin{aligned} f(y|x) &= f^*(y|y > L, x) \\ &= \frac{f^*(y|x)}{\Pr[y > L|x]} \\ &= \frac{f^*(y|x)}{1 - F^*(L|x)} \end{aligned}$$

Luego, la función de verosimilitud para la variable dependiente truncada es:

$$\ln L(\theta) = \sum_{i=1}^N \{\ln f^*(y_i|x_i, \theta) - \ln[1 - F^*(L|x_i, \theta)]\}$$

9.2.2. Modelo Tobit

En un contexto de un modelo de regresión lineal con errores normales y homocedásticos donde sólo se observa la variable dependiente para valores positivos, Tobin (1958) desarrolla un modelo para la estimación que es conocido como Modelo Tobit.

Es decir,

$$y^* = x'\beta + u \quad \text{con} \quad u \sim N(0, \sigma^2)$$

De esta forma, y^* se distribuye normal con media $x'\beta$ y varianza σ^2 .

Sin embargo, y^* no es observada sino y :

$$y = \begin{cases} y^* & \text{si } y^* > 0 \\ - & \text{si } y^* \leq 0 \end{cases}$$

Esto indica que no se observa la variable cuando toma valores negativos, cuando realmente sólo hay observaciones positivas es porque la muestra está truncada, cuando observamos ceros la muestra esta censurada.

Entonces, bajo estos supuestos:

$$f^*(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left\{-\frac{(y - x'\beta)^2}{2\sigma^2}\right\}$$

y

$$\begin{aligned}
 F^*(0) &= Pr[y^* \leq 0] \\
 &= Pr[x'\beta + u \leq 0] \\
 &= \Phi\left(\frac{-x'\beta}{\sigma}\right) \\
 &= 1 - \Phi\left(\frac{x'\beta}{\sigma}\right)
 \end{aligned}$$

donde $\Phi(\cdot)$ es la función de probabilidad acumulada normal estándar.

Luego, la función de densidad de la variable censurada observada:

$$f(y) = \left[\frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left\{-\frac{(y - x'\beta)^2}{2\sigma^2}\right\} \right]^d \left[1 - \Phi\left(\frac{x'\beta}{\sigma}\right) \right]^{1-d}$$

Luego, la función de verosimilitud que debe ser optimizada con respecto a β y σ^2 para obtener los estimadores Máximo Verosímil de estos coeficientes es:

$$\ln L(\beta, \sigma^2) = \sum_{i=1}^N \left\{ d_i \left(-\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (y_i - x'_i \beta)^2 \right) + (1 - d_i) \ln \left(1 - \Phi\left(\frac{x'_i \beta}{\sigma}\right) \right) \right\}$$

Cuando los datos están truncados en vez de censurados la función de verosimilitud es:

$$\ln L(\beta, \sigma^2) = \sum_{i=1}^N \left\{ -\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (y_i - x'_i \beta)^2 - \ln \Phi\left(\frac{x'_i \beta}{\sigma}\right) \right\}$$

El estimador Tobit será consistente en la medida que se cumplan los supuestos de homocedasticidad y normalidad del error.

9.2.3. Media condicional truncada y censurada

Cuando estimamos un modelo de regresión lineal estamos interesados en la media de la variable dependiente condicional en las variables explicativas $E[y|x]$ ya veíamos a través de un ejemplo simulado que la media condicional truncada o censurada se ve alterada con respecto a la media condicional poblacional.

Si la variable está **truncada por abajo**:

$$\begin{aligned}
 E[y] &= E[y^* | y^* > 0] \\
 &= E[x'\beta + u | x'\beta + u > 0] \\
 &= E[x'\beta | x'\beta + u > 0] + E[u | x'\beta + u > 0] \\
 &= x'\beta + \underbrace{E[u | u > -x'\beta]}_{>0}
 \end{aligned}$$

de esta forma $E[y] > x'\beta$. En caso de truncamiento por arriba se obtendrá de manera análoga que $E[y] < x'\beta$.

Cuando la variable está **censurada por abajo**:

$$\begin{aligned}
 E[y] &= E_d[E_{y|d}[y|d]] \\
 &= Pr[d = 0] \cdot E[y|d = 0] + Pr[d = 1] \cdot E[y|d = 1] \\
 &= Pr[y^* \leq 0] \cdot 0 + Pr[y^* > 0] \cdot E[y^* | y^* > 0] \\
 &= Pr[y^* > 0] \cdot E[y^* | y^* > 0] \\
 &= Pr[u > -x'\beta] \cdot \underbrace{E[y^* | y^* > 0]}_{truncada}
 \end{aligned}$$

En resumen, en un modelo de regresión lineal con censura o truncamiento bajo cero las medias condicionales están dadas por:

$$\begin{aligned}
 \text{Variable Latente:} & \quad E[y^* | x] = x'\beta \\
 \text{Truncada por abajo en 0:} & \quad E[y | x, y > 0] = x'\beta + E[u | u > -x'\beta] \\
 \text{Censurada por abajo en 0:} & \quad E[y | x] = Pr[u > -x'\beta] [x'\beta + E[u | u > -x'\beta]]
 \end{aligned}$$

Bajo el supuesto de normalidad del error se tiene que la media truncada del error es de la forma:

$$\begin{aligned}
 E[u | u > -x'\beta] &= \sigma E \left[\frac{u}{\sigma} \middle| \frac{u}{\sigma} > \frac{-x'\beta}{\sigma} \right] \\
 &= \sigma \frac{\phi \left(-\frac{x'\beta}{\sigma} \right)}{\left[1 - \Phi \left(-\frac{x'\beta}{\sigma} \right) \right]} \\
 &= \sigma \frac{\phi \left(\frac{x'\beta}{\sigma} \right)}{\Phi \left(\frac{x'\beta}{\sigma} \right)} \\
 &= \sigma \lambda \left(\frac{x'\beta}{\sigma} \right) \\
 &= \sigma \lambda(z)
 \end{aligned}$$

donde $\lambda(\cdot)$ es conocido como el [inverse Mills ratio](#). Luego, las medias condicionales truncada y censurada en este caso son:

$$\begin{aligned} \text{Variable Latente:} & E[y^*|x] = x'\beta \\ \text{Truncada por abajo en 0:} & E[y|x, y > 0] = x'\beta + \sigma\lambda(z) \\ \text{Censurada por abajo en 0:} & E[y|x] = \Phi(z)x'\beta + \sigma\phi(z) \end{aligned}$$

9.2.4. Efectos Marginales

Notemos que en estos modelos estamos interesados en el efecto marginal que tiene la variable explicativa sobre la variable dependiente latente, estos efectos marginales son capturados directamente por los coeficientes estimados (β). Ahora, también podemos querer estudiar los efectos marginales sobre la variable truncada y sobre la variable censurada los cuales no son exactamente igual a los coeficientes:

$$\begin{aligned} \text{Variable Latente:} & \frac{\partial E[y^*|x]}{\partial x} = \beta \\ \text{Truncada por abajo en 0:} & \frac{\partial E[y|x, y > 0]}{\partial x} = [1 - z\lambda(z) - \lambda(z)^2]\beta \\ \text{Censurada por abajo en 0:} & \frac{\partial E[y|x]}{\partial x} = \Phi(z)\beta \end{aligned}$$

9.2.5. Estimación de Modelos Censurados y Truncados en STATA

En esta sección estudiaremos los determinantes de las horas trabajadas de las mujeres casadas. En este caso la variable dependiente consiste en las horas trabajadas, la cuál toma sólo valores positivos. Cuando no tenemos en la muestra mujeres que no trabajan la muestra esta truncada, cuando en la muestra tenemos las mujeres que no trabajan tomando valor cero la variable dependiente, la muestra esta censurada.

Para esta aplicación utilizaremos los datos de la Encuesta Casen 2009, las variables explicativas serán: número de hijos entre 0 y 2 años, número de hijos entre 2 y 6 años, número de hijos entre 6 y 18 años, edad de la mujer, y los años de escolaridad. Primero generemos las variables explicativas que nos interesan:

```
use casen2009.dta, clear

g hijos0_2=1 if pco2==3 & edad>=0 & edad<=2
g hijos2_6=1 if pco2==3 & edad>2 & edad<=6
g hijos6_18=1 if pco2==3 & edad>6 & edad<=18
```

```

egen nucl=group(region provincia comuna zona segmento folio nucleo)

replace hijos0_2=0 if hijos0_2==.
replace hijos2_6=0 if hijos2_6==.
replace hijos6_18=0 if hijos6_18==.

egen t_hijos0_2=sum(hijos0_2), by(nucl)
egen t_hijos2_6=sum(hijos2_6), by(nucl)
egen t_hijos6_18=sum(hijos6_18), by(nucl)

keep if pco2==1 | pco2==2
keep if sexo==2 & ecivil==1

replace o16=0 if o16==.
replace o16=. if o16==999

g o16_horas=o16/7*30

```

Primero veamos las estadísticas descriptivas de las variables para la muestra censurada:

Cuadro 9.3
Estadísticas Descriptivas Muestra Censurada

. sum o16_horas t_hijos0_2 t_hijos2_6 t_hijos6_18 edad esc					
variable	Obs	Mean	Std. Dev.	Min	Max
o16_horas	38676	49.24848	86.86332	0	540
t_hijos0_2	38904	.0794006	.2855332	0	3
t_hijos2_6	38904	.1402684	.3802016	0	3
t_hijos6_18	38904	.6230208	.8624857	0	8
edad	38904	49.54326	14.15669	16	105
esc	38904	8.456817	4.285308	0	20

Y para la muestra truncada:

Cuadro 9.4
Estadísticas Descriptivas Muestra Truncada

. sum o16_horas t_hijos0_2 t_hijos2_6 t_hijos6_18 edad esc if o16_horas>0					
Variable	Obs	Mean	Std. Dev.	Min	Max
o16_horas	10916	174.4901	69.85354	4.285714	540
t_hijos0_2	11144	.0802225	.2858161	0	3
t_hijos2_6	11144	.161163	.4026466	0	3
t_hijos6_18	11144	.745603	.8803388	0	6
edad	11144	44.57107	10.66948	18	91
esc	11144	10.53302	4.126705	0	20

Comenzaremos con la estimación para la muestra censurada, en este caso un 65.2% de las observaciones están censuradas, es decir, un 65.2% de las mujeres casadas no trabaja. Primero estimaremos el modelo por MCO olvidándonos del problema de censura de la variable dependiente:

Cuadro 9.5
Estimación MCO Muestra Censurada

. reg o16_horas t_hijos0_2 t_hijos2_6 t_hijos6_18 edad esc [pw=expr], robust (sum of wgt is 2.5610e+06)						
Linear regression			Number of obs = 38676 F(5, 38670) = 348.75 Prob > F = 0.0000 R-squared = 0.1163 Root MSE = 85.361			
o16_horas	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
t_hijos0_2	-30.7215	3.139034	-9.79	0.000	-36.87409	-24.56892
t_hijos2_6	-15.46713	2.635962	-5.87	0.000	-20.63369	-10.30058
t_hijos6_18	-4.395111	1.090798	-4.03	0.000	-6.533103	-2.25712
edad	-1.475508	.0773754	-19.07	0.000	-1.627165	-1.32385
esc	5.02032	.2348151	21.38	0.000	4.560076	5.480563
_cons	89.47918	5.652529	15.83	0.000	78.40008	100.5583

Recordemos que la estimación MCO de los coeficientes es una estimación inconsistente, esto porque la media condicional debe ser corregida para representar

una media condicional de una muestra censurada y estimar los coeficientes bajo el modelo apropiado que será no lineal en β . El comando en STATA que nos permite estimar modelos censurados es el comando Tobit:

```
tobit depvar [indepvars] [if] [in] [weight] , ll[(#)] ul[(#)]
```

donde ll(#) corresponde al punto de censura por abajo y ul(#) corresponde al punto de censura por arriba.

En el Cuadro 9.6 se presenta la estimación del modelo Tobit para nuestra variable de interés. Recordemos que lo que hace este modelo es incorporar la corrección a la estimación de la media condicional por tener una parte de las observaciones de la variable dependiente censurada, por lo cual los coeficientes presentados representan directamente los efectos marginales de las variables explicativas sobre la media condicional de la variable latente. Al respecto se obtiene, por cada hijo menor de 2 años las mujeres trabajan en promedio 90.7 horas mensuales menos, por cada hijo entre 2 y 6 años las mujeres trabajan en promedio 47.7 horas mensuales menos, por cada hijo entre 6 y 18 años las mujeres trabajan en promedio 9.4 horas mensuales menos, la edad tiene un efecto negativo sobre las horas trabajadas por cada año se reduce en 5 en promedio las horas trabajadas al mes, y la escolaridad tiene un efecto positivo sobre las horas trabajadas, un aumento en un año de escolaridad aumenta en promedio 15.2 las horas trabajadas al mes. Podemos notar que los coeficientes estimados por MCO están siendo subestimados (en valor absoluto) o sesgados hacia el origen.

Cuadro 9.6
Estimación Tobit Muestra Censurada

. tobit o16_horas t_hijos0_2 t_hijos2_6 t_hijos6_18 edad esc [pw=expr], ll(0)						
Tobit regression			Number of obs = 38676			
			F(5, 38671) = 458.71			
			Prob > F = 0.0000			
Log pseudolikelihood = -6794571			Pseudo R2 = 0.0274			
o16_horas	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
t_hijos0_2	-90.65917	8.330026	-10.88	0.000	-106.9862	-74.33211
t_hijos2_6	-47.72682	6.392643	-7.47	0.000	-60.25656	-35.19708
t_hijos6_18	-9.414291	2.638724	-3.57	0.000	-14.58626	-4.242325
edad	-4.978344	.2238158	-22.24	0.000	-5.417028	-4.539659
esc	15.2377	.6086838	25.03	0.000	14.04467	16.43074
_cons	38.45905	15.44302	2.49	0.013	8.190328	68.72777
/sigma	194.3233	2.059226			190.2871	198.3594
obs. summary: 27760 left-censored observations at o16_horas<=0						
10916 uncensored observations						
0 right-censored observations						

Existen otros efectos marginales de interés que pueden ser obtenidos a través de la opción postestimación `mf`. Por ejemplo el Cuadro 7.7 muestra los efectos marginales sobre la media de la variable truncada $E[y^*|y^* > 0]$, la opción `e(0,.)` indica que calcule $E[x'\beta + u|x'\beta + u > 0]$

Cuadro 9.7
Efecto Marginal sobre Media Truncada

. mfx, predict(e(0,.))							
Marginal effects after tobit							
y = E(o16_horas o16_horas>0) (predict, e(0,.))							
= 131.21663							
variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]
t_hijo~2	-26.21894	2.3949	-10.95	0.000	-30.9129	-21.525	.086209
t_hijo~6	-13.80276	1.84017	-7.50	0.000	-17.4094	-10.1961	.153202
t_hijo~18	-2.722645	.76424	-3.56	0.000	-4.22053	-1.22476	.6365
edad	-1.439754	.06239	-23.08	0.000	-1.56203	-1.31748	48.8309
esc	4.406796	.18113	24.33	0.000	4.0518	4.7618	10.0029

Podemos interpretar estos efectos marginales de la siguiente manera: por cada hijo entre 0 y 2 años se reducen las horas trabajadas en 26.2 horas promedio mensual para la mujeres que trabajan, por cada hijo entre 2 y 6 años las horas trabajadas se reducen en promedio 13.8 horas mensuales, y por cada hijo entre 6 y 18 años en 2.7 horas mensuales. El efecto de la edad sobre las horas trabajadas de las mujeres que trabajan es de reducir en 1.4 horas mensuales las horas trabajadas por cada año adicional de edad, y el efecto marginal de los años de escolaridad es aumentar 4.4 las horas promedio trabajadas al mes por cada año de escolaridad adicional.

Para obtener los efectos marginales sobre la media censurada $E[y|x]$ debemos utilizar la siguiente opción `ystar(0,.)`, la cual indica que calcule $E(y)$ donde $y = 0$ si $y^* \leq 0$.¹

¹Note que en STATA la variable y^* es la variable observada y la variable y es la latente.

Cuadro 9.8
Efecto Marginal sobre Media Censurada

```
. mfx, predict(ystar(0,.))
```

Marginal effects after tobit
 $y = E(o16_horas * | o16_horas > 0) \text{ (predict, ystar(0,.))}$
= **46.311652**

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	x
t_hijo~2	-31.99728	2.92634	-10.93	0.000	-37.7328 -26.2618	.086209
t_hijo~6	-16.84472	2.2439	-7.51	0.000	-21.2427 -12.4468	.153202
t_hij~18	-3.322684	.93422	-3.56	0.000	-5.15373 -1.49164	.6365
edad	-1.757059	.07589	-23.15	0.000	-1.9058 -1.60832	48.8309
esc	5.378001	.23141	23.24	0.000	4.92445 5.83156	10.0029

Finalmente, podemos calcular también los efectos marginales sobre la probabilidad de estar censurado:

Cuadro 9.9
Efecto Marginal sobre Probabilidad de estar Censurado

```
. mfx, predict(p(.,0))
```

Marginal effects after tobit
 $y = \Pr(o16_horas < 0) \text{ (predict, p(.,0))}$
= **.64705959**

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	x
t_hijo~2	.1733283	.01602	10.82	0.000	.141928 .204729	.086209
t_hijo~6	.0912474	.01224	7.46	0.000	.067258 .115236	.153202
t_hij~18	.0179989	.00506	3.56	0.000	.008087 .027911	.6365
edad	.0095179	.00043	22.31	0.000	.008682 .010354	48.8309
esc	-.0291325	.00132	-22.05	0.000	-.031722 -.026543	10.0029

Cada hijo menor de dos años aumenta en 17.3 puntos porcentuales la probabilidad de no trabajar, los hijos entre 2 y 6 años la aumentan en 9.1 puntos porcentuales, y los hijos entre 6 y 18 años aumentan en 1.8 puntos porcentuales la probabilidad de que la mujer casada no trabaje. Cada año de edad aumenta en 0.95 puntos porcentuales de que la mujer casada no trabaje, y cada año de escolaridad disminuye en 2.9 puntos porcentuales la probabilidad de que la mujer casada no trabaje.

Ahora estimaremos el modelo para la muestra truncada, el comando en STATA para hacer una regresión truncada es:

```
truncreg depvar [indepvars] [if] [in] [weight] [, options]
```

El Cuadro 9.10 muestra los resultados de la estimación, los coeficientes se pueden interpretar directamente como los efectos marginales sobre la variable dependiente latente.

Cuadro 9.10
Estimación Muestra Truncada

```
. truncreg o16_horas t_hijos0_2 t_hijos2_6 t_hijos6_18 edad esc [pw=expr], ll(0)
(note: 27760 obs. truncated)
```

Fitting full model:

```
Iteration 0: log pseudolikelihood = -4992155.5
Iteration 1: log pseudolikelihood = -4991722.1
Iteration 2: log pseudolikelihood = -4991721
Iteration 3: log pseudolikelihood = -4991721
```

Truncated regression

Limit:	lower =	0	Number of obs =	10916
	upper =	+inf	wald chi2(5) =	23.71
Log pseudolikelihood =	-4991721		Prob > chi2 =	0.0002

o16_horas	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]
t_hijos0_2	-9.256082	3.803218	-2.43	0.015	-16.71025 -1.801912
t_hijos2_6	-5.383333	3.174873	-1.70	0.090	-11.60597 .8393039
t_hijos6_18	-2.219142	1.2724	-1.74	0.081	-4.713001 .2747166
edad	-.3595417	.1324362	-2.71	0.007	-.619112 -.0999715
esc	.7936111	.2936566	2.70	0.007	.2180549 1.369167
_cons	180.8229	7.770249	23.27	0.000	165.5935 196.0523
/sigma	67.57379	1.177385	57.39	0.000	65.26616 69.88142

Y el cuadro 9.11 los efectos marginales sobre la media condicional de la variable truncada:

Cuadro 9.11
Efectos Marginales Variable Truncada

```
. mfx, predict(e(0,.))
```

Marginal effects after truncreg

```
y = E(o16_horas|o16_horas>0) (predict, e(0,.))
= 172.04555
```

variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]	x
t_hijo~2	-8.870511	3.64527	-2.43	0.015	-16.0151	-1.72592		.091729
t_hijo~6	-5.159085	3.04066	-1.70	0.090	-11.1187	.800497		.181972
t_hij~18	-2.126702	1.21954	-1.74	0.081	-4.51696	.263552		.740064
edad	-.3445647	.12687	-2.72	0.007	-.593232	-.095897		44.0039
esc	.7605525	.28169	2.70	0.007	.208459	1.31265		11.8563

9.2.6. Test de Normalidad y Homocedasticidad

Los supuestos claves del Modelo Tobit son la normalidad y homocedasticidad, por lo cual es clave testear estos supuestos y validar la utilización de este modelo. En el contexto del modelo de regresión lineal sin censura, los residuos al cuadrado son utilizados para testear homocedasticidad y la tercera y cuarta potencia de los residuos para testear normalidad (ya que se relacionan con los momentos de kurtosis y asimetría). Para testear homocedasticidad y normalidad en este contexto se construirán los residuos para utilizar las potencias de ellos en la formulación de los tests. Los residuos (normalizados) $\hat{\epsilon}_i$ tendrán la siguiente forma para las variables no censuradas:

$$\hat{\epsilon}_i = \frac{y_i - x_i' \hat{\beta}}{\hat{\sigma}}$$

Para las variables censuradas por la izquierda en L , el primer, segundo, tercer y cuarto momento de los errores normalizados son:

Momentos	Expresión
$E[\epsilon_i d_i = 0]$	$-\lambda_i$
$E[\epsilon_i^2 d_i = 0]$	$1 - z_i \lambda_i$
$E[\epsilon_i^3 d_i = 0]$	$-(2 + z_i^2) \lambda_i$
$E[\epsilon_i^4 d_i = 0]$	$3 - (3z_i + z_i^3) \lambda_i$
donde	
$\lambda_i = \frac{\phi(x_i' \beta / \sigma)}{1 - \Phi(x_i' \beta / \sigma)}$	$z_i = \frac{L - x_i' \beta}{\sigma}$

El comando `bctobit` de STATA realiza este test, la hipótesis nula es que el Modelo Tobit es válido, es decir, cumple con los supuestos de normalidad y homocedasticidad:

```
. bctobit
Bootstrap replications (499)
-----|----- 1 -----|----- 2 -----|----- 3 -----|----- 4 -----|----- 5
.....
..... 50
..... 100
..... 150
..... 200
..... 250
..... 300
..... 350
..... 400
..... 450
.....
LM test of Tobit specification
Bootstrap critical values
lm      %10      %5      %1
11933   2.55083   3.4572232  7.2489443
```

En este caso, el Modelo Tobit es rechazado fuertemente. Se pueden utilizar alternativas no paramétricas o semi-paramétricas para la estimación.

El Test de Normalidad puede ser realizado de manera independiente a través de los siguientes comandos:

1- Se estima el modelo tobit:

```
global xlist t_hijos0_2 t_hijos2_6 t_hijos6_18 edad esc
tobit o16_horas $xlist, ll(0)
```

2- Se genera una variable binaria que toma valor 1 para las observaciones no censuradas y cero para las observaciones censuradas:

```
g dy=1 if o16_horas>0
replace dy=0 if o16_horas<=0
replace dy=. if o16_horas==.
```

3- Con el modelo tobit estimado se obtiene la predicción lineal $x'\beta$:

```
predict xb, xb
```

4- Se rescata el vector de coeficientes estimados:

```
matrix btobit=e(b)
```

Notemos la estructura de esta matriz:

```
. matrix list btobit
btobit[1,7]
      model:      model:      model:      model:      model:      model:      sigma:
      t_hijos0_2  t_hijos2_6  t_hijos6_18  edad      esc      _cons      _cons
y1      -90.65917  -47.726821  -9.4142906  -4.9783437  15.237704  38.459048  194.32325
```

5- Con el nombre `e(df_m)` se guarda la información sobre el número de variables explicativas excepto la constante, por lo cuál podemos rescatar la estimación de sigma de la siguiente manera:

```
scalar sigma=btobit[1,e(df_m)+2]
```

6- Se define el punto de censura, en este caso es cero:

```
scalar gamma=0
```

y se estandariza con la media y desviación estándar:

```
generate threshold=(gamma-xb)/sigma
```

7- Se genera el inverso de mills (λ_i):

```
generate lambda=normalden(threshold)/normal(threshold)
```

8- Se calculan los residuos normalizados para las observaciones no censuradas:

```
generate uifdyeq1=(o16_horas-xb)/sigma if dy==1
```

```
generate gres1=uifdyeq1
```

9- Se calculan los residuos normalizados para las observaciones censuradas:

```
replace gres1=-lambda if dy==0
```

10- Luego se calcula el segundo momento de los residuos normalizados:

```
generate gres2=uifdyeq1^2-1
```

```
replace gres2=-threshold*lambda if dy==0
```

11- El tercer momento de los residuos normalizados será:

```
generate gres3=uifdyeq1^3
```

```
replace gres3=-(2+threshold^2)*lambda if dy==0
```

12- Y el cuarto momento de los residuos normalizados es:

```
generate gres4=uifdyeq1^4-3
```

```
replace gres4=-(3*threshold+threshold^3)*lambda if dy==0
```

13- Para aplicar el test de normalidad se debe hacer una regresión de unos como variable dependiente contra los scores (primera derivada de la función de verosimilitud) de cada uno de los parámetros del modelo. En este modelo los score

corresponde a $\hat{\lambda}_i x_i$, los que pueden ser calculados de la siguiente manera para cada una de las variables explicativas del modelo:

```
foreach var in $xlist {
generate score'var'=gres1*'var'
}
```

El score de la constante del modelo es **gres1** y de la desviación estándar es **gres2**.

14- Se hace la regresión auxiliar, N veces el R^2 de esta regresión corresponde al estadístico LM para la hipótesis nula de normalidad:

```
global scores score* gres1 gres2

generate one=1

reg one gres3 gres4 $scores, nocon
```

```
. display "N R2=" e(N)*e(r2) "con p-value=" chi2tail(9,e(N)*e(r2))
N R2=2197.2271con p-value=0
```

Se rechaza la hipótesis nula de normalidad.

Por otra parte, el test de homocedasticidad se puede realizar mediante los siguientes comandos:

```
foreach var in $xlist {

generate score2'var'=gres2*'var'

}

global scores2 score* score2* gres1 gres2

reg one gres3 gres4 $scores2, nocon
```

```
. display "N R2=" e(N)*e(r2) "con p-value=" chi2tail(14,e(N)*e(r2))
N R2=8257.1336con p-value=0
```

Se rechaza la hipótesis nula de homocedasticidad.

9.3. Modelos de Selección

Cuando la muestra de la que disponemos no es aleatoria en el sentido que de manera intencional o no intencional nos hemos quedado con una parte de la población que no es representativa del resto, hablamos de que existe un problema de selección en la muestra.

9.3.1. Modelo de Selección Bivariado (Tobit Tipo II)

Este modelo generaliza el modelo Tobit Tipo I mostrado en la sección anterior introduciendo una variable latente que determina la censura, y que es diferente a la variable latente de interés. En definitiva la probabilidad de estar censurado es modelado a través de otra variable.

Sea y_2^* la variable latente de interés. En el Modelo Tobit Tipo I la variable era observada sólo si $y_2^* > 0$. En este modelo, llamado Tobit Tipo II o Modelo de Heckman, se introduce la variable latente y_1^* y la variable de interés es observada sólo si $y_1^* > 0$. Por ejemplo, en la aplicación de la sección anterior podemos pensar en y_1^* como la variable que determina que la mujer casada trabaje o no, y la variable y_2^* cuantas horas trabajar, en principio estas dos variables no tienen porque ser iguales ya que hay factores o variables que son relevantes para explicar la decisión de participar o no, pero que una vez que la mujer está trabajando no son relevantes para explicar la cantidad de horas que decide trabajar.

La [ecuación de participación](#) en el Modelo Tobit Tipo II es:

$$y_1 = \begin{cases} 1 & \text{si } y_1^* > 0 \\ 0 & \text{si } y_1^* \leq 0 \end{cases}$$

y la **ecuación de resultado (outcome)** es la siguiente:

$$y_2 = \begin{cases} y_2^* & \text{si } y_1^* > 0 \\ - & \text{si } y_1^* \leq 0 \end{cases}$$

Luego, cada una de las variables latentes es función lineal de las variables explicativas y de un término de error:

$$\begin{aligned} y_1^* &= x_1' \beta_1 + u_1 \\ y_2^* &= x_2' \beta_2 + u_2 \end{aligned}$$

El problema consiste en estimar β_2 cuando los errores de ambas ecuaciones están correlacionados, ya que un shock en u_1 genera cambios en u_2 e y_1^* lo que a su vez cambia y_2 , de esta forma se nos hace imposible identificar correctamente β_2 . Notemos que el Modelo Tobit Tipo I es un caso especial cuando $y_1^* = y_2^*$.

El modelo puede ser estimado de manera consistente realizando supuestos adicionales sobre la distribución conjunta de los errores, en particular el Modelo Tobit Tipo II o Heckman asume que los errores son homocedásticos y se distribuyen conjuntamente normal:

$$\begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \sim \mathcal{N} \left[\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right]$$

Al igual que en el Modelo Probit σ_1 es normalizada en 1 dado que sólo se observa el signo de y_1^* (observamos y_1 igual a 1 si es positiva e y_1 igual a cero si es negativo).

La función de densidad de y_2 que nos permite construir la función de verosimilitud y estimar los coeficientes β_1 y β_2 es:

$$f(y_2) = \begin{cases} f^*(y_2^*|y_1^* > 0) \cdot Pr[y_1^* > 0] & \text{si } y_1^* > 0 \\ Pr[y_1^* \leq 0] & \text{si } y_1^* \leq 0 \end{cases}$$

Luego, la función de verosimilitud es:

$$L = \prod_{i=1}^N \{Pr[y_1^* \leq 0]\}^{1-y_{1i}} \{f(y_{2i}|y_1^* > 0) \cdot Pr[y_1^* > 0]\}^{y_{1i}}$$

9.3.2. Medias Condicionales en Modelo Tobit Tipo II

En este modelo tenemos que la variable y_2 está truncada para los valores de $y_1^* > 0$, de esta forma la media condicional de la variable de interés truncada es:

$$\begin{aligned} E[y_2|x, y_1^* > 0] &= E[x_2' \beta_2 + u_2 | x_1' \beta_1 + u_1 > 0] \\ &= x_2' \beta_2 + E[u_2 | u_1 > -x_1' \beta_1] \end{aligned}$$

En la medida que los errores no estén correlacionados el segundo término es igual a $E[u_2] = 0$, y la estimación por MCO del modelo de interés nos lleva a una estimación consistente de β_2 , sin embargo si la correlación existe la media truncada no es igual a $x'_2\beta_2$ y necesitamos considerar el problema de selección en la estimación.

Heckman (1979) notó que bajo los supuestos de normalidad conjunta de los errores se puede determinar la siguiente relación entre ellos:

$$u_2 = \sigma_{12}u_1 + \varepsilon$$

donde ε es independiente de u_1 .

Utilizando este resultado:

$$\begin{aligned} E[y_2|x, y_1^* > 0] &= x'_2\beta_2 + E[(\sigma_{12}u_1 + \varepsilon)|u_1 > -x'_1\beta_1] \\ &= x'_2\beta_2 + \sigma_{12}E[u_1|u_1 > -x'_1\beta_1] \\ &= x'_2\beta_2 + \sigma_{12}\lambda(x'_1\beta_1) \end{aligned}$$

Luego, la esperanza incondicional (censurada) de y_2 se obtiene de la siguiente manera:

$$\begin{aligned} E[y_2|x] &= E_{y_1^*}[E[y_2|x, y_1^*]] \\ &= Pr[y_1^* \leq 0|x] \cdot 0 + Pr[y_1^* > 0|x] \cdot E[y_2|x, y_1^* > 0] \\ &= \Phi(x'_1\beta_1)x'_2\beta_2 + \sigma_{12}\phi(x'_1\beta_1) \end{aligned}$$

9.3.3. Estimador Heckman Dos Etapas (Heckit)

Como notamos en la sección anterior, la media condicional de la variable de interés truncada no es igual a $x'_2\beta_2$ a menos que $\sigma_{12} = 0$. Si existe correlación entre los errores se debe incluir el término correspondiente al inverso de Mill. De esta forma, el procedimiento de Heckman en dos etapas consiste en estimar el modelo por MCO pero incluyendo la “variable omitida” correspondiente a $\lambda(x'_1\beta_1)$, lo que requiere de un paso previo consistente en estimar β_1 mediante un modelo probit de y_1 sobre x_1 , con lo cual se puede construir el inverso de Mill:

$$\lambda(x'_1\hat{\beta}_1) = \frac{\phi(x'_1\hat{\beta}_1)}{\Phi(x'_1\hat{\beta}_1)}$$

Así, usando sólo los valores positivos de y_2 se estima el siguiente modelo por MCO:

$$y_{2i} = x'_{2i}\beta_2 + \sigma_{12}\lambda(x'_1\hat{\beta}_1) + \nu_i$$

Notemos que σ_{12} será estimada como el coeficiente que acompaña al inverso de Mill, luego se puede testear si este coeficiente es cero, en caso de no poder rechazar la hipótesis nula no es necesaria la corrección por selección, ya que los errores no están correlacionados entre ellos.

Esta estimación será consistente pero menos eficiente que la estimación por Máxima Verosimilitud.

9.3.4. Identificación

Dado que el inverso de Mill es una función *casi* lineal del argumento si se ocupan exactamente las mismas variables en x_2 y x_1 se genera un problema de multicolinealidad, es por eso que la estimación del Modelo Tobit Tipo II requiere de una **variable de exclusión**, es decir, de una variable que este en la ecuación de participación (y_1^*) pero no la en la ecuación de resultado (y_2^*). Por ejemplo, en el modelo de horas trabajadas los costos fijos de participar puede ser la variable de exclusión.

9.3.5. Efectos Marginales

Simplemente para mejorar la notación agruparemos las variables x_1 y x_2 en un sólo conjunto de variables llamado x , luego $x_1'\beta_1$ puede ser escrito como $x'\gamma_1$ y $x_2'\beta_1$ como $x'\gamma_2$, donde γ_1 tiene ceros para las variables x_2 y γ_2 tiene ceros para las variables x_1 .

Luego, diferenciando con respecto a x la media condicional de interés (latente o truncada en cero) se obtienen los efectos marginales:

Media Condicional Latente:

$$E[y_2^*|x] = x'\gamma_2$$

El efecto marginal esta dado por γ_2 .

Media Condicional Truncada:

$$E[y_2|x, y_1 = 1] = x'\gamma_2 + \sigma_{12}\lambda(x'\gamma_1)$$

El efecto marginal esta dado por:

$$\frac{\partial E[y_2|x, y_1 = 1]}{\partial x} = \gamma_2 - \sigma_{12}\lambda(x'\gamma_1)[x'\gamma_1 + \lambda(x'\gamma_1)]\gamma_1$$

9.3.6. Estimación Modelo Tobit Tipo II en STATA

Utilizaremos los datos de la Encuesta Casen 2009 para estimar una ecuación de salarios de las mujeres, en función de la escolaridad, la edad, y el número de hijos que la mujer tiene en diferentes edades. En este caso la variable dependiente logaritmo del salario por hora (lyph) está truncada, sólo observamos valores positivos de salarios para las mujeres que trabajan, y no hay información para las mujeres que no trabajan. La decisión de trabajar, no es exógena sino que depende de un proceso de decisión de la mujer, esta ecuación de participación depende de no observables que con alta probabilidad están correlacionados con los no observables de la ecuación de salarios. De esta forma, nos encontramos en un contexto de un modelo de selección, la variable de exclusión utilizada será una dummy que indica si la mujer está casada o no.

Primero generamos las variables de interés:

```
use casen2009.dta, clear

g hijos0_2=1 if pco2==3 & edad>=0 & edad<=2
g hijos2_6=1 if pco2==3 & edad>2 & edad<=6
g hijos6_18=1 if pco2==3 & edad>6 & edad<=18

egen nucl=group(region provincia comuna zona segmento folio nucleo)

replace hijos0_2=0 if hijos0_2==.
replace hijos2_6=0 if hijos2_6==.
replace hijos6_18=0 if hijos6_18==.

egen t_hijos0_2=sum(hijos0_2), by(nucl)
egen t_hijos2_6=sum(hijos2_6), by(nucl)
egen t_hijos6_18=sum(hijos6_18), by(nucl)

g casada=1 if ecivil==1
replace casada=0 if ecivil!=1

keep if pco2==1 | pco2==2
keep if sexo==2

g o16_horas=o16/7*30

g yph=yopraj/o16_horas
```

```
g lyph=ln(yph)
```

El comando en STATA que nos permite estimar un Modelo Tobit Tipo II es:

```
heckman depvar [indepvars], select(varlist_s) [twostep]
```

Las variables explicativas comunes de la ecuación de participación (o selección) y de la ecuación de resultados son agrupadas a través de la siguiente macro:

```
global xlist esc edad t_hijos0_2 t_hijos2_6 t_hijos6_18
```

El Cuadro 9.12 se presenta la estimación del modelo de interés, se utilizan 75330 observaciones de mujeres en la estimación, de las cuales 51161 están truncadas o son mujeres que no tienen observaciones de salarios porque no trabajan. Se puede notar que el test de correlación cero entre los errores de la ecuación de selección y de resultados rechaza fuertemente la hipótesis nula de que no existe correlación, validando la corrección por selección que realiza esta metodología en la estimación de la media condicional. Podemos notar que todas las variables resultan ser significativas excepto la cantidad de hijos entre 6 y 18 años en la ecuación de interés. Los coeficientes estimados para la variable de interés (o la ecuación de resultados) se pueden interpretar directamente como los efectos marginales sobre la variable de interés latente, sin embargo, los coeficientes estimados en la ecuación de selección (o participación) no pueden ser interpretados como los efectos marginales sobre la probabilidad de participar, por las mismas razones que se dieron en la estimación de los modelos probit, debemos solicitar el cálculo de estos efectos marginales a través del comando `mf`, lo mismo si queremos estudiar los efectos marginales sobre la media condicional de la variable truncada.

Primero interpretemos los resultados obtenidos sobre la variable de interés latente. Se obtiene un retorno a la educación de las mujeres de 9.3 %, cada año adicional de edad aumenta el salario por hora en aproximadamente 0.9 %, tener hijos más pequeños tiene un impacto positivo sobre salarios por hora.

Cuadro 9.12
Modelo Heckman por Máxima Verosimilitud

. heckman lyph \$xlist, select(\$xlist casada) no log						
Heckman selection model (regression model with sample selection)			Number of obs	=	75330	
			Censored obs	=	51161	
			Uncensored obs	=	24169	
Log likelihood = -71908.93			wald chi2(5)	=	2722.74	
			Prob > chi2	=	0.0000	
lyph	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
lyph						
esc	.0931094	.0022773	40.89	0.000	.0886459	.0975729
edad	.0093755	.0006116	15.33	0.000	.0081769	.0105741
t_hijos0_2	.0689478	.0258295	2.67	0.008	.0183228	.1195728
t_hijos2_6	.0318699	.0181557	1.76	0.079	-.0037147	.0674544
t_hijos6_18	.0019273	.0076056	0.25	0.800	-.0129794	.0168339
_cons	5.518481	.0432727	127.53	0.000	5.433668	5.603294
select						
esc	.0884671	.0013718	64.49	0.000	.0857785	.0911557
edad	-.0144597	.0003925	-36.84	0.000	-.0152289	-.0136905
t_hijos0_2	-.6018367	.0187674	-32.07	0.000	-.6386201	-.5650533
t_hijos2_6	-.2763876	.0152071	-18.17	0.000	-.306193	-.2465821
t_hijos6_18	-.0198275	.0073142	-2.71	0.007	-.034163	-.005492
casada	-.2400566	.0110201	-21.78	0.000	-.2616557	-.2184576
_cons	-.3849199	.0265599	-14.49	0.000	-.4369764	-.3328635
/athrho	.1542556	.0353208	4.37	0.000	.0850281	.2234832
/lnsigma	-.1631192	.0058501	-27.88	0.000	-.1745852	-.1516532
rho	.1530437	.0344935			.0848238	.2198354
sigma	.84949	.0049696			.8398053	.8592863
lambda	.1300091	.0297862			.0716291	.188389
LR test of indep. eqns. (rho = 0): chi2(1) = 16.48 Prob > chi2 = 0.0000						

El Cuadro 9.13 muestra los efectos marginales de las variables explicativas sobre la probabilidad de participación o selección. Cada año de escolaridad aumenta en 3 puntos porcentuales la probabilidad de que una mujer trabaje, cada año de edad disminuye en 0.5 puntos porcentuales la probabilidad, por cada hijo entre 0 y 2 años se reduce la probabilidad de que una mujer participe en 20.8 puntos porcentuales, cada hijo entre 2 y 6 años la reduce en 9.6 puntos porcentuales, y cada hijo entre 6 y 18 años la reduce en 0.7 puntos porcentuales. Finalmente, estar casada reduce en 8.3 puntos porcentuales la probabilidad de que una mujer trabaje.

Cuadro 9.13
Efectos Marginales sobre Probabilidad de Participación

```
. mfx, predict(psel)
```

Marginal effects after heckman
y = Pr(select) (predict, psel)
= .29617458

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	x
esc	.03058	.00047	64.96	0.000	.029657 .031503	8.53114
edad	-.0049982	.00013	-37.04	0.000	-.005263 -.004734	48.0322
t_hijo~2	-.2080342	.00648	-32.11	0.000	-.220732 -.195336	.080008
t_hijo~6	-.0955376	.00525	-18.18	0.000	-.105837 -.085238	.111403
t_hij~18	-.0068537	.00253	-2.71	0.007	-.01181 -.001898	.393017
casada*	-.0830112	.00381	-21.81	0.000	-.09047 -.075552	.516448

(*) dy/dx is for discrete change of dummy variable from 0 to 1

El Cuadro 9.14 muestra los efectos marginales sobre la media condicional truncada si es que este análisis fuese de interés:

Cuadro 9.14
Efectos Marginales sobre Media Condicional Truncada

```
. mfx, predict(ycond)
```

Marginal effects after heckman
y = E(lyph|zg>0) (predict, ycond)
= 6.924694

variable	dy/dx	Std. Err.	z	P> z	[95% C.I.]	x
esc	.0846303	.00146	58.13	0.000	.081777 .087484	8.53114
edad	.0107614	.0005	21.49	0.000	.00978 .011743	48.0322
t_hijo~2	.1266308	.02206	5.74	0.000	.083399 .169863	.080008
t_hijo~6	.0583602	.01686	3.46	0.001	.025314 .091407	.111403
t_hij~18	.0038276	.00751	0.51	0.610	-.010883 .018538	.393017
casada*	.022981	.00535	4.29	0.000	.012488 .033474	.516448

(*) dy/dx is for discrete change of dummy variable from 0 to 1

9.4. Modelo de Probabilidad con Selección

También es posible estimar modelos donde la variable dependiente de interés es binaria y existe selección en la muestra, conocidos como Modelos Probit Bivariados con Selección. Este caso es bastante similar al Modelo Tobit Tipo II, sólo observamos y_1 si es que $y_2 = 1$, la diferencia es que y_1 es una variable binaria. Existen tres posibles resultados observados en la muestra con sus respectivas

probabilidades:

$$\begin{aligned} y_1 = 0 & \quad Pr(y_1 = 0) = \Phi(-x'\gamma_1) \\ y_1 = 1, y_2 = 0 & \quad Pr(y_1 = 1, y_2 = 0) = \Phi(x'\gamma_1) - \Phi_2(x'\gamma_1, x'\gamma_2, \rho) \\ y_1 = 1, y_2 = 1 & \quad Pr(y_1 = 1, y_2 = 1) = \Phi_2(x'\gamma_1, x'\gamma_2, \rho) \end{aligned}$$

Por lo cual la función de verosimilitud en este contexto es:

$$\ln L = \sum_{i=1}^N \{y_{1i} \cdot y_{2i} \ln \Phi(x'\gamma_1, x'\gamma_2, \rho) + y_{1i}(1 - y_{2i}) \ln [\Phi(x'\gamma_1) - \Phi_2(x'\gamma_1, x'\gamma_2, \rho)] + (1 - y_{1i}) \cdot y_{2i} \ln \Phi(-x'\gamma_1)\}$$

En STATA podemos estimar este tipo de modelo a través del siguiente comando:

```
heckprob depvar indepvars [if] [in] [weight] , select(varlist_s)
```

Utilizando los datos de la EPS 2006 se estima un modelo para la probabilidad de que un trabajador independiente (empleador o cuenta propia) cotice para el sistema de pensiones. Así, la variable de interés es binaria ya que toma valor 1 si la persona cotiza y cero sino cotiza, pero al estar estimando el modelo sólo para los trabajadores independientes existe una selección en la muestra que debe ser corregida para estimar de manera consistente los parámetros. El Cuadro 9.15 muestra los resultados de estimar el modelo de interés a través del siguiente comando:

```
heckprob cotiza edad06 empleador dcasado06 cashom06 dumjefe06
jefehombre06 part_time tfirma_2 tfirma_3 tran_indep seguro_vida
ting_2 -ting_5 d_ahorro d_progreso hpobre corto_plazo,
select(indep=edad06 dumjefe06 dhombre averso) nolog
```

Podemos notar que del total de 9766 observaciones 8309 están censuradas, es decir, no son trabajadores independientes, la hipótesis nula de no correlación entre los errores es rechazada, lo que valida la corrección a las estimaciones que realiza esta metodología. No es posible interpretar los efectos marginales a través de estos resultados ya que son modelos de probabilidad donde los coeficientes estimados no representan los efectos marginales. Para obtener los efectos marginales debemos utilizar la función `mf` de STATA, donde podemos pedir los efectos marginales sobre la probabilidad incondicional de que la variable de interés sea igual a 1, la probabilidad condicionada (truncada) de que la variable de interés sea igual a 1, y sobre la probabilidad de selección. Los resultados se presentan en los Cuadros 9.16, 9.17, y 9.18.

Cuadro 9.15
Estimación Probit Bivariado con Selección

Probit model with sample selection				Number of obs	=	9766
				Censored obs	=	8309
				Uncensored obs	=	1457
Log likelihood = -4762.553				Wald chi2(19)	=	295.65
				Prob > chi2	=	0.0000
	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
cotiza						
edad06	.0125326	.002086	6.01	0.000	.0084441	.016621
empleador	.3747334	.0394336	9.50	0.000	.297445	.4520218
dcasado06	-.2011582	.0590888	-3.40	0.001	-.3169701	-.0853463
cashom06	.215086	.0769398	2.80	0.005	.0642867	.3658852
dumjefe06	.2205141	.0687367	3.21	0.001	.0857926	.3552357
jefehombre06	.0396447	.0804762	0.49	0.622	-.1180858	.1973751
part_time	-.1863886	.0584746	-3.19	0.001	-.3009968	-.0717804
tfirma_2	.0886249	.0412042	2.15	0.031	.0078661	.1693837
tfirma_3	.2999618	.0507744	5.91	0.000	.2004458	.3994778
tran_indep	.0310478	.0473388	0.66	0.512	-.0617345	.12383
seguro_vida	.1249344	.0434193	2.88	0.004	.0398341	.2100348
ting_2	.2246309	.0629309	3.57	0.000	.1012887	.3479731
ting_3	.3065874	.0680148	4.51	0.000	.1732808	.439894
ting_4	.2908734	.0777372	3.74	0.000	.1385112	.4432356
ting_5	.1627619	.0708132	2.30	0.022	.0239705	.3015533
d_ahorro	.0868919	.0369965	2.35	0.019	.01438	.1594037
d_progreso	.0833605	.0380446	2.19	0.028	.0087945	.1579265
hpobre	-.1046117	.0382814	-2.73	0.006	-.1796419	-.0295814
corto_plazo	-.1298652	.038688	-3.36	0.001	-.2056924	-.0540381
_cons	-2.585186	.1325795	-19.50	0.000	-2.845038	-2.325335
indep						
edad06	.0152559	.0014103	10.82	0.000	.0124918	.0180201
dumjefe06	.1511318	.0391266	3.86	0.000	.0744451	.2278185
dhombre	.2228062	.0346377	6.43	0.000	.1549175	.2906949
averso	-.0985219	.0274797	-3.59	0.000	-.1523812	-.0446627
_cons	-1.878559	.0648675	-28.96	0.000	-2.005697	-1.751421
/athrho	2.337859	.3008411	7.77	0.000	1.748221	2.927497
rho	.9815344	.0110078			.9411728	.9942853
LR test of indep. eqns. (rho = 0):				chi2(1) =	16.31	Prob > chi2 = 0.0001

Cuadro 9.16
Efectos Marginales sobre Probabilidad Incondicional

. mfx, predict(pm)

Marginal effects after heckprob
y = Pr(cotiza=1) (predict, pm)
= .07490965

variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]	x
edad06	.0017724	.00029	6.10	0.000	.001203	.002342		42.2567
emplea~r	.0529968	.00637	8.31	0.000	.040505	.065489		.328811
dcasa~06	-.0284489	.00853	-3.34	0.001	-.045161	-.011737		.742319
cashom06	.0304186	.01103	2.76	0.006	.00881	.052028		.462106
dumje~06*	.030126	.00926	3.25	0.001	.011981	.048271		.615196
jefeh~06*	.0056187	.01141	0.49	0.623	-.01675	.027988		.463854
part_t~e	-.0263601	.00844	-3.12	0.002	-.04291	-.00981		.100941
tfirma_2	.0125338	.00588	2.13	0.033	.001005	.024063		.212892
tfirma_3	.0424222	.00868	4.89	0.000	.025416	.059428		.646553
tran_i~p	.0043909	.00668	0.66	0.511	-.008701	.017483		.908966
seguro~a	.0176689	.00636	2.78	0.005	.005198	.030139		.24915
ting_2	.0317685	.0088	3.61	0.000	.01453	.049007		.379527
ting_3	.0433592	.00968	4.48	0.000	.024384	.062334		.184704
ting_4	.0411369	.01117	3.68	0.000	.019242	.063032		.096932
ting_5	.0230187	.00997	2.31	0.021	.003474	.042563		.163507
d_ahorro*	.0126516	.00563	2.25	0.025	.001627	.023677		.26838
d_prog~o	.0117893	.0055	2.14	0.032	.00101	.022569		.589646
hpobre	-.0147947	.0056	-2.64	0.008	-.025761	-.003828		.40924
corto~o	-.0183662	.00575	-3.19	0.001	-.029641	-.007091		.705323
dhombre*	0	0	.	.	0	0		.59318
dhombre*	0	0	.	.	0	0		.681241

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Cuadro 9.17
Efectos Marginales sobre Probabilidad Condicional (Truncada)

. mfx, predict(pcond)

Marginal effects after heckprob
y = Pr(cotiza=1|indep=1) (predict, pcond)
= .52855302

variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]	x
edad06	-.000167	.00169	-0.10	0.921	-.003473	.003139		42.2567
emplea~r	.3613207	.03269	11.05	0.000	.297248	.425393		.328811
dcasa~06	-.1939582	.05643	-3.44	0.001	-.304561	-.083356		.742319
cashom06	.2073874	.07336	2.83	0.005	.063599	.351176		.462106
dumje~06*	.0907617	.05613	1.62	0.106	-.019255	.200778		.615196
jefeh~06*	.038269	.0779	0.49	0.623	-.114404	.190942		.463854
part_t~e	-.1797172	.05696	-3.16	0.002	-.291347	-.068087		.100941
tfirma_2	.0854528	.04038	2.12	0.034	.006315	.164591		.212892
tfirma_3	.2892253	.04978	5.81	0.000	.191663	.386788		.646553
tran_i~p	.0299365	.04587	0.65	0.514	-.05997	.119843		.908966
seguro~a	.1204627	.04053	2.97	0.003	.04103	.199896		.24915
ting_2	.2165907	.06008	3.61	0.000	.098839	.334342		.379527
ting_3	.2956138	.0645	4.58	0.000	.169193	.422034		.184704
ting_4	.2804622	.07227	3.88	0.000	.138812	.422112		.096932
ting_5	.1569362	.06736	2.33	0.020	.024919	.288953		.163507
d_ahorro*	.0852385	.03673	2.32	0.020	.013255	.157222		.26838
d_prog~o	.0803768	.03618	2.22	0.026	.009473	.15128		.589646
hpobre	-.1008673	.03625	-2.78	0.005	-.171918	-.029816		.40924
corto~o	-.125217	.03589	-3.49	0.000	-.195559	-.054875		.705323
dhombre*	-.1834234	.03027	-6.06	0.000	-.242755	-.124092		.59318
dhombre*	.0768577	.02038	3.77	0.000	.03692	.116796		.681241

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Cuadro 9.18
Efectos Marginales sobre Probabilidad de Selección

. mfx, predict(psel)							
Marginal effects after heckprob							
y = Pr(indep) (predict, psel)							
= .14099247							
variable	dy/dx	std. Err.	z	P> z	[	95% C.I.	]
edad06	.0034119	.00031	10.90	0.000	.002798	.004026	42.2567
emplea~r	0	0	.	.	0	0	.328811
dcasa~06	0	0	.	.	0	0	.742319
cashom06	0	0	.	.	0	0	.462106
dumje~06*	.033174	.00841	3.94	0.000	.016687	.049661	.615196
jefeh~06*	0	0	.	.	0	0	.463854
part_t~e	0	0	.	.	0	0	.100941
tfirma_2	0	0	.	.	0	0	.212892
tfirma_3	0	0	.	.	0	0	.646553
tran_i~p	0	0	.	.	0	0	.908966
seguro~a	0	0	.	.	0	0	.24915
ting_2	0	0	.	.	0	0	.379527
ting_3	0	0	.	.	0	0	.184704
ting_4	0	0	.	.	0	0	.096932
ting_5	0	0	.	.	0	0	.163507
d_ahorro*	0	0	.	.	0	0	.26838
d_prog~o	0	0	.	.	0	0	.589646
hpobre	0	0	.	.	0	0	.40924
corto~o	0	0	.	.	0	0	.705323
dhombre*	.0487389	.0074	6.59	0.000	.034236	.063242	.59318
averso*	-.022459	.00639	-3.52	0.000	-.034976	-.009942	.681241
(*) dy/dx is for discrete change of dummy variable from 0 to 1							

Capítulo 10

Datos de Panel

Los **Datos de Panel** consisten en observaciones repetidas del mismo corte transversal, típicamente individuos, empresas, colegios, etc. Otra forma de llamar estos tipos de datos es **Datos Longitudinales**. En estudios a nivel microeconómico generalmente los paneles son cortos, es decir, el corte transversal de individuos es observado un número reducido de periodos.

La mayor ventaja de los Datos de Panel es incrementar la precisión de las estimaciones, debido al incremento en el número de observaciones al combinar (pooling) varios periodos de tiempo para cada individuo. Sin embargo, hay que tener presente para la realización de inferencia estadística que en estos datos existirá correlación en los errores en el tiempo para los mismos individuos, y esta correlación debe ser considerada al momento de computar los errores estándar, si esto no es considerado los errores estándar serán subestimados y los estadísticos t inflados.

La segunda ventaja de los Datos de Panel es que permite estimar de manera consistente **efectos fijos** en el modelo, lo que permite controlar por no observables heterogéneos entre los individuos y que puedan estar correlacionados con las otras variables explicativas. Es decir, nos permite corregir el sesgo por omisión de variables relevantes sin necesidad de usar variables instrumentales. Este efecto individual también se puede suponer como una variable aleatoria distribuida de manera independiente de las variables explicativas, en este caso el efecto individual se llama **efecto aleatorio**, tienes supuestos más fuerte pero permite incluir variables explicativas que no varían en el tiempo como regresores y estimar de manera consistente sus coeficientes.

10.1. Modelos de Datos de Panel

Los modelos de Datos de Panel entregan información sobre el comportamiento individual a través del tiempo y a través de los individuos. El modelo de Datos de Panel más general donde el intercepto y coeficientes varían entre individuos y en el tiempo es:

$$y_{it} = \alpha_{it} + x'_{it}\beta_{it} + u_{it} \quad i = 1, \dots, N. \quad t = 1, \dots, T.$$

Sin embargo, este modelo no es estimable ya que posee mayor cantidad de parámetros que observaciones, se requieren hacer supuestos adicionales para estimar este modelo, lo que deriva a los diferentes modelos de datos de panel.

10.1.1. Modelo Pooled

Este es el modelo mas restrictivo donde se asume que todos los coeficientes son constantes (supuesto de los modelos de corte transversal):

$$y_{it} = \alpha + x'_{it}\beta + u_{it}$$

Si la especificación es correcta y los regresores no están correlacionados con el término de error, los coeficientes pueden ser estimados de manera consistente por [pooled-MCO](#). Pero hay que tener cuidado con el cálculo de los errores estándar por la presencia de correlación entre los errores.

10.1.2. Dummies Individuales y de Tiempo

En este modelo se permite que el intercepto varía entre individuos y en el tiempo, pero los coeficientes que acompañan a las variables explicativas siguen siendo constantes:

$$y_{it} = \alpha_i + \gamma_t + x'_{it}\beta + u_{it}$$

el que también puede ser especificado de la siguiente manera:

$$y_{it} = \sum_{j=1}^N \alpha_j \cdot d_{j,it} + \sum_{s=2}^T \gamma_s \cdot d_{s,it} + x'_{it}\beta + u_{it}$$

con N dummies individuales $d_{j,it}$ que toman valor 1 si $i=j$ y cero en otro caso, y $(T-1)$ dummies de tiempo $d_{s,it}$ que toman valor 1 si $t=s$ y cero en otro caso. El modelo no incluye intercepto. El problema es cuando N es muy grande.

10.1.3. Modelos de Efecto Fijo y Efecto Aleatorio

Estos modelos se conocen como modelo de efectos individuales:

$$y_{it} = \alpha_i + x'_{it}\beta + \varepsilon_{it}$$

donde ε_{it} son independientes sobre i y t . Las dummies de tiempo pueden ser incluidas dentro de los regresores. Los efectos individuales α_i son variables aleatorias que capturan la heterogeneidad no observable.

La primera variante de este modelo asume que los α_i están correlacionados con las variables explicativas del modelo x_{it} , este modelo es llamado de efecto fijo, y los efectos individuales son parámetros a estimar. La segunda variante de este modelo asume que los efectos individuales son variables aleatorias no correlacionadas con las restantes variables del modelo, es llamado modelo de efectos aleatorios.

10.2. Estimadores de Datos de Panel

A continuación se introducirán algunos estimadores para los coeficientes β . Las variables explicativas pueden ser invariantes en el tiempo x_i y variantes en el tiempo e individuos x_{it} , pero algunos estimadores serán capaz de identificar los coeficientes que acompañan a las variables que varían en el tiempo solamente.

10.2.1. MCO Pooled

Este estimador consiste en aplicar MCO al modelo:

$$y_{it} = \alpha + x'_{it}\beta + u_{it}$$

con NT observaciones. Este estimador será consistente en la medida que $Cov(u_{it}, x_{it}) = 0$, y $N \rightarrow \infty$ o $T \rightarrow \infty$, y el modelo especificado (intercepto y coeficientes constantes) sea el correcto. Sin embargo, las varianzas del estimador MCO no serán apropiadas ya que los errores están correlacionados, estos deben ser calculados de manera robusta. Si el modelo correcto es el de efecto fijo, este estimador no será consistente:

$$y_{it} = \alpha + \beta x'_{it}\beta + (\alpha_i - \alpha + \varepsilon_{it})$$

ya que los efectos fijos (α_i) están correlacionados con las variables explicativas, por lo cuál el error del modelo donde se omiten los efectos individuales ($\alpha_i - \alpha + \varepsilon_{it}$)

estarán correlacionados con las variables explicativas.

En resumen, el estimador MCO Pooled será consistente si el modelo correcto es de coeficientes constantes o de efectos aleatorios, sin embargo, el cálculo de las varianzas debe ser corregido para la realización correcta de la inferencia. Si el modelo correcto es el de efecto fijo, el estimador será inconsistente.

10.2.2. Estimador Between

El Estimador Between se utiliza en paneles cortos, utiliza la variación del corte transversal para estimar β . Partiendo del modelo de efectos individuales:

$$y_{it} = \alpha_i + x'_{it}\beta + \varepsilon_{it}$$

se toma el promedio de las T observaciones para cada i :

$$\bar{y}_i = \alpha + \bar{x}'_i\beta + (\alpha_i - \alpha + \bar{\varepsilon}_i) \quad i = 1, \dots, N.$$

donde $\bar{y}_i = \frac{\sum_{t=1}^T y_{it}}{T}$, $\bar{\varepsilon}_i = \frac{\sum_{t=1}^T \varepsilon_{it}}{T}$, y $\bar{x}_i = \frac{\sum_{t=1}^T x_{it}}{T}$.

De esta forma, el Estimador Between utiliza la variación entre individuos para estimar β , y consiste en hacer una regresión por MCO de $\bar{y}_i$ sobre una constante y $\bar{x}_i$. Este estimador será consistente si el modelo de coeficientes constantes o de efectos aleatorios es el correcto, por el contrario si el modelo de efectos fijos es el correcto el estimador será inconsistente ya que existe correlación entre $\bar{x}_i$ y $(\alpha_i - \alpha + \bar{\varepsilon}_i)$.

10.2.3. Estimador de Efectos Fijos o Within

Al contrario del estimador MCO-Pooled o el estimador Between, el estimador Within utiliza la característica de panel de los datos. Esto lo hace midiendo la asociación entre las variaciones específicas del individuo de sus variables explicativas con respecto al promedio individual en el tiempo y las variaciones de la variable dependiente con respecto a su promedio. Es decir, partiendo del modelo de efectos individuales:

$$y_{it} = \alpha_i + x'_{it}\beta + \varepsilon_{it}$$

Se toman los promedios individuales a través del tiempo:

$$\bar{y}_i = \alpha_i + \bar{x}'_i\beta + \bar{\varepsilon}_i$$

Y al modelo se le restan los promedios, obteniendo el modelo en desvíos:

$$y_{it} - \bar{y}_i = (x_{it} - \bar{x}_i)' \beta + \varepsilon_{it}$$

El estimador Within consiste en estimar por MCO el modelo anterior, y se obtiene un estimador consistente de β cuando el modelo de efectos fijos es el correcto.

Si existe interés en estimar los efectos fijos y la muestra de individuos no es muy grande, se puede realizar el estimador de variables dummies por MCO incorporando al modelo N variables dummies, una para cada individuo.

La mayor limitación del estimador Within es que los coeficientes de los regresores que no varían en el tiempo no están identificados, razón por la cuál muchos estudios prefieren usar el estimador de efectos aleatorios, sin embargo este estimador será inconsistente si el verdadero modelo es de efecto fijo.

10.2.4. Estimador de Primeras Diferencias

El estimador de diferencias también explota la característica de panel de los datos, este tipo de estimador mide la relación entre la variación individual de las variables explicativas y la variación individual de la variable dependiente. Partiendo del modelo con efectos individuales:

$$y_{it} = \alpha_i + x'_{it} \beta + \varepsilon_{it}$$

y tomando restando el primer rezago del modelo:

$$y_{i,t-1} = \alpha_i + x'_{i,t-1} \beta + \varepsilon_{i,t-1}$$

se obtiene el modelo en primeras diferencias:

$$\Delta y_{it} = \Delta x'_{it} \beta + \Delta \varepsilon_{it}$$

El estimador de primeras diferencias consiste en estimar por MCO el modelo anterior, el que entrega una estimación consistente de β si el modelo de efecto fijo es el correcto pero al igual que el estimador Within los coeficientes de los regresores que no varían en el tiempo no están identificados. Este estimador es menos eficiente que el estimador Within para $T > 2$.

10.2.5. Estimador de Efectos Aleatorios

El estimador de efectos aleatorios también explota la característica de panel de los datos. Comenzando con el modelo de efectos individuales:

$$y_{it} = \alpha_i + x'_{it}\beta + \varepsilon_{it}$$

el estimador de efectos aleatorios asume que α_i y ε_i son iid. El estimador MCO-Pooled es consistente en este contexto pero el estimador MCG-Pooled es más eficiente. El estimador MCG factibles del modelo de efectos aleatorios es conocido como el estimador de efectos aleatorios el que se obtiene al estimar por MCO el siguiente modelo transformado:

$$y_{it} - \hat{\theta}\bar{y}_i = (1 - \hat{\theta})\mu + (x_{it} - \hat{\theta}\bar{x}_i)'\beta + \nu_{it}$$

donde $\nu_{it} = (1 - \hat{\theta})\alpha_i + (\varepsilon_{it} - \hat{\theta}\bar{\varepsilon}_i)$ es asintóticamente iid, y $\hat{\theta}$ es la estimación consistente de:

$$\theta = 1 - \frac{\sigma_\varepsilon}{\sqrt{\sigma_\varepsilon^2 + T\sigma_\alpha^2}}$$

Si el modelo de efectos aleatorios es el correcto este estimador es consistente y eficiente, sin embargo, si el estimador de efectos fijos es el correcto el estimador es inconsistente.

10.3. Test de Hausman

En el modelo de efectos individuales presentado en las secciones anteriores, los principales estimadores utilizados son el estimador de Efectos Fijos (Within) y el estimador de Efectos Aleatorios. El estimador de Efectos Fijos es consistente cuando existe correlación entre los efectos individuales y las variables explicativas, sin embargo, no permite identificar los coeficientes de las variables explicativas que son constantes en el tiempo para cada individuo. El estimador de Efectos Aleatorios es inconsistente si existe correlación entre las variables explicativas del modelo y el efecto individual, asume que los efectos individuales son iid, pero bajo este supuesto es el estimador más eficiente.

El Teste de Hausman nos permite testear si el estimador de Efectos Aleatorios es válido en el modelo y datos estimado. La hipótesis nula de este test es que los efectos individuales no están correlacionados con las variables explicativas, es decir, que el estimador de Efectos Aleatorios es válido. En particular la hipótesis nula es que el estimador de Efectos Fijos y de Efectos Aleatorios son iguales, ya que bajo el modelo de Efectos Aleatorios ambos estimadores son consistentes.

10.4. Estimación de Datos de Panel en STATA

Para esta sección se utilizará una muestra de 595 individuos del Panel Study of Income Dynamics (PSID) observada durante 7 años 1976-1982 para estudiar los determinantes de los salarios.

10.4.1. Formato de la base de datos


Para trabajar con Datos de Panel en STATA los datos deben ser organizados en formato “long”, es decir, cada observación en la base de datos corresponde a un individuo en un año puntual.

Primero abramos la base de datos:

```
use mus08psidextract.dta, clear
```

Luego veamos el formato en que debe estar la base de datos:

Cuadro 10.1
Orden Base de Datos Panel



```
. list id t exp wks occ in 1/3, clean
```

	id	t	exp	wks	occ
1.	1	1	3	32	0
2.	1	2	4	43	0
3.	1	3	5	40	0

La primera observación corresponde al individuo 1 en el primer año, la segunda observación corresponde al mismo individuo 1 pero en el segundo año, etc.

Para utilizar los comandos de panel de STATA, los que son identificados por comenzar con las letras **xt**, primero es necesario indicar al programa que se dispone de ese formato de datos a través del comando **xtset**:

Cuadro 10.2
Formato Datos de Panel STATA

```
. xtset id t
      panel variable:  id (strongly balanced)
      time variable:  t, 1 to 7
      delta: 1 unit
```

10.4.2. Descripción de los datos

Las variables dependientes y explicativas podrían variar en el tiempo y entre individuos. La variación en el tiempo o a nivel individual se denomina Within, y la variación entre individuos se denomina Between. Esto es importante ya que nos ayuda a determinar que tipo de estimador será el más apropiado.

La varianza total de una variable en torno a su media puede ser descompuesta en la variación de los individuos en el tiempo (within) y la variación entre individuos. Mediante el comando `xtsum` podemos obtener esta descomposición de varianza para cada una de las variables que nos interese en la base de datos, tal como se muestra en el Cuadro 10.3

Las variables explicativas que no varían en el tiempo tienen 0 variación Within, como la variable `id` (identificador individual) y `ed` (años de educación), y las variables que no varían entre individuos tienen 0 varianza Between como por ejemplo `t` (identificador del año). Para todas las demás variables excepto `wks` (semanas trabajadas) la varianza Between es mayor a la varianza Within.

Cuadro 10.3
Summarize Within y Between en STATA

. xtsum id t lwage ed exp exp2 wks south tdum1						
Variable		Mean	Std. Dev.	Min	Max	Observations
id	overall	298	171.7821	1	595	N = 4165
	between		171.906	1	595	n = 595
	within		0	298	298	T = 7
t	overall	4	2.00024	1	7	N = 4165
	between		0	4	4	n = 595
	within		2.00024	1	7	T = 7
lwage	overall	6.676346	.4615122	4.60517	8.537	N = 4165
	between		.3942387	5.3364	7.813596	n = 595
	within		.2404023	4.781808	8.621092	T = 7
ed	overall	12.84538	2.787995	4	17	N = 4165
	between		2.790006	4	17	n = 595
	within		0	12.84538	12.84538	T = 7
exp	overall	19.85378	10.96637	1	51	N = 4165
	between		10.79018	4	48	n = 595
	within		2.00024	16.85378	22.85378	T = 7
exp2	overall	514.405	496.9962	1	2601	N = 4165
	between		489.0495	20	2308	n = 595
	within		90.44581	231.405	807.405	T = 7
wks	overall	46.81152	5.129098	5	52	N = 4165
	between		3.284016	31.57143	51.57143	n = 595
	within		3.941881	12.2401	63.66867	T = 7
south	overall	.2902761	.4539442	0	1	N = 4165
	between		.4489462	0	1	n = 595
	within		.0693042	-.5668667	1.147419	T = 7
tdum1	overall	.1428571	.3499691	0	1	N = 4165
	between		0	.1428571	.1428571	n = 595
	within		.3499691	0	1	T = 7

El comando `xttab` entrega una manera adicional de analizar la variación Between y Within de las variables, por ejemplo:

Cuadro 10.4
Tabulate Within y Between en STATA

. xttab south					
south	Overall		Between		within
	Freq.	Percent	Freq.	Percent	Percent
0	2956	70.97	428	71.93	98.66
1	1209	29.03	182	30.59	94.90
Total	4165	100.00	610	102.52	97.54
			(n = 595)		

La tabulación “Overall” indica que un 71 % de las 4165 observaciones (año-individuo) tienen la variable `south=0`, y el restante 29 % tienen `south=1`. La parte “Between” de la tabla nos indica que un 72 % de los 595 individuos tiene `south` igual a 0 al menos una vez y un 31 % tiene `south` igual a 1 al menos una vez, el porcentaje total de esta tabla es 102.52 % ya que un 2.52 % de los individuos (15 individuos) vivieron un tiempo en el sur y un tiempo no en el sur, por lo cual están contabilizados dos veces. Finalmente, la parte “within” de la tabla indica que un 95 % de los individuos siempre vivieron en el sur, y un 99 % nunca vivió en el sur, en el periodo de tiempo considerado. La variable `south` casi no tiene variación en el tiempo.

Pooled-MCO con errores estándar robustos

A continuación estimaremos un modelo para explicar el logaritmo del salario en función de la educación, las semanas trabajadas, experiencia y experiencia al cuadrado. Primero este modelo será estimado por Pooled-MCO, es decir, modelo que considera intercepto y coeficientes constantes, pero se corrige la opción de cálculo de varianzas para que estas sean robustas. El Cuadro 8.5 muestra los resultados de la estimación de este modelo.

Cuadro 10.5

Estimación Pooled-MCO

```
. regress lwage exp exp2 wks ed, vce(cluster id)
```

Linear regression

Number of obs = 4165
F(4, 594) = 72.58
Prob > F = 0.0000
R-squared = 0.2836
Root MSE = .39082

(Std. Err. adjusted for 595 clusters in id)

lwage	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
exp	.044675	.0054385	8.21	0.000	.0339941	.055356
exp2	-.0007156	.0001285	-5.57	0.000	-.0009679	-.0004633
wks	.005827	.0019284	3.02	0.003	.0020396	.0096144
ed	.0760407	.0052122	14.59	0.000	.0658042	.0862772
_cons	4.907961	.1399887	35.06	0.000	4.633028	5.182894

Los resultados nos muestran que el salario se incrementa con la experiencia hasta los 31 años ($0,044675/(2 \times 0,0007156)$) y luego disminuye. Los salarios se incrementan en un 0.6 % por cada semana adicional trabajada, y el retorno a la educación es de 7.6 %.

Este estimador será consistente si el modelo verdadero es de coeficientes constantes o de efectos aleatorios, pero inconsistente si el modelo es de efectos fijos.

Estimación Within

El estimador Within se obtiene a través del comando `xtreg` con la opción `fe`. El default del modelo asume que los errores ε_{it} son iid, pero se puede utilizar la opción `vce(robust)` relaja este supuesto y computa las varianzas robustas ante problema de autocorrelación o heterocedasticidad. El Cuadro 10.6 muestra los resultados de la estimación por efectos fijos.

Cuadro 10.6
Estimación Within

```
. xtreg lwage exp exp2 wks ed, fe vce(robust)
note: ed omitted because of collinearity
```

Fixed-effects (within) regression		Number of obs	=	4165
Group variable: id		Number of groups	=	595
R-sq: within	= 0.6566	Obs per group: min	=	7
between	= 0.0276	avg	=	7.0
overall	= 0.0476	max	=	7
corr(u_i, Xb) = -0.9107		F(3,594)	=	1059.72
		Prob > F	=	0.0000
(Std. Err. adjusted for 595 clusters in id)				

lwage	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
exp	.1137879	.0040289	28.24	0.000	.1058753	.1217004
exp2	-.0004244	.0000822	-5.16	0.000	-.0005858	-.0002629
wks	.0008359	.0008697	0.96	0.337	-.0008721	.0025439
ed	(omitted)					
_cons	4.596396	.0600887	76.49	0.000	4.478384	4.714408
sigma_u	1.0362039					
sigma_e	.15220316					
rho	.97888036	(fraction of variance due to u_i)				

Recordemos que este estimador es consistente cuando el modelo es de efecto fijo, y existe correlación entre los efectos individuales y las variables explicativas del modelo. Notemos que el coeficiente de los años de escolaridad no está identificado, esto porque la variable no tiene variación en el tiempo para cada individuo. Todas las variables que son constantes en el tiempo quedan controladas por el efecto individual. `sigma_u` entrega la estimación de la desviación estándar de los efectos

individuales α_i y `sigma_e` entrega la desviación estándar de ε_{it} . En este caso, la desviación estándar de los efectos individuales es bastante superior a la del error del modelo. El output nos presenta el cálculo de tres R^2 : Within, Between, y Overall (o Pooled). Dado que estamos estimando el estimador Within debemos tomar en cuenta el primero de ellos, teniendo que $R_w^2 = 0,66$. Notemos además que se nos entrega la correlación entre los efectos individuales y las variables explicativas $\text{corr}(u_i, Xb) = -0,9107$ la cuál es bastante elevada. Con respecto a la estimación de los coeficientes se obtiene que la experiencia aumenta el salario pero a tasas decrecientes, y las semanas trabajadas no resultan ser estadísticamente significativas.

Estimación de Variables Dummies

El estimador Within de β también es llamado estimador de Efecto Fijo ya que se puede mostrar que este estimador es equivalente a la estimación por MCO de un modelo que incluye los coeficientes $\alpha_1, \alpha_2, \dots, \alpha_N$ y β en el modelo de efectos individuales. La estimación de los efectos fijos es igual a $\hat{\alpha}_i = \bar{y}_i - \bar{x}_i \hat{\beta}$. En paneles cortos esta estimación de los efectos individuales no es consistente ya que depende sólo de las T_i observaciones disponibles para calcular los promedios. Sin embargo, $\hat{\beta}$ es estimado de manera consistente.

Cuadro 10.7
Estimación de Variables Dummies

<pre>. areg lwage exp exp2 wks ed, absorb(id) vce(cluster id) note: ed omitted because of collinearity</pre>						
Linear regression, absorbing indicators				Number of obs = 4165 F(3, 594) = 908.44 Prob > F = 0.0000 R-squared = 0.9068 Adj R-squared = 0.8912 Root MSE = .1522		
(Std. Err. adjusted for 595 clusters in id)						
lwage	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
exp	.1137879	.0043514	26.15	0.000	.1052418	.1223339
exp2	-.0004244	.0000888	-4.78	0.000	-.0005988	-.00025
wks	.0008359	.0009393	0.89	0.374	-.0010089	.0026806
ed	(omitted)					
_cons	4.596396	.0648993	70.82	0.000	4.468936	4.723856
id	absorbed		(595 categories)			

Otro nombre del estimador Within es estimador de variables dummies, ya que se puede mostrar que es equivalente a estimar un modelo de la variable dependiente contra las variables explicativas y N variables dummies individuales.

El Cuadro 10.7 nos muestra la estimación del modelo de variables dummies. Los coeficientes obtenidos son exactamente iguales, pero las desviaciones estándar levemente superior.

Estimación Between

El estimador Between sólo utiliza la variación entre individuos para estimar los coeficientes que acompañan a las variables explicativas, por lo cual los coeficientes de las variables que son comunes a los individuos y sólo varían en el tiempo no estarán identificados.

Esta estimación se obtiene aplicando el comando `xtreg` con la opción `be`, la cual no posee una opción para obtener los errores estándar robustos, pero se puede utilizar bootstrap `vce(bootstrap)`. El Cuadro 8.8 muestra la estimación Between del modelo.

El R^2 Between es el pertinente en este caso, el cual indica que el modelo es capaz de explicar un 33 % de las variaciones de corte transversal de la variable dependiente. Los coeficientes estimados son muy similares a los del modelo Pooled y muy diferentes a los del modelo Within, recordemos que este estimador es inconsistente si el modelo de efectos fijos es el correcto, es decir, existe correlación entre las variables explicativas del modelo y los efectos individuales.

Estimación por Efectos Aleatorios

El estimador de Efectos Aleatorios corresponden a la estimación Mínimos Cuadrados Generalizados Factibles (MCO de un modelo transformado) bajo los supuestos que el efecto individual es iid y el error del modelo también es iid. Esta estimación será consistente y eficiente bajo estos supuestos, pero inconsistente si el modelo correcto es de efectos fijos. El modelo debe ser transformado por una estimación consistente de θ :

$$\theta_i = 1 - \sqrt{\frac{\sigma_\varepsilon^2}{T_i \sigma_\alpha^2} + \sigma_\varepsilon^2}$$

Cuadro 10.8
Estimación Between

El estimador de efectos aleatorios ocupa la variación between y within de los datos, e incluye los casos particulares de Pooled cuando $\theta = 0$ y Within cuando $\theta = 1$.

Luego podemos comparar el modelo de efectos fijos y el modelo de efectos aleatorios:

233

```
xtreg lwage exp exp2 wks ed, re vce(robust)
estimates store re
```

El Cuadro 10.10 muestra la comparación de ambos modelos.

Cuadro 10.9
Estimación por Efectos Aleatorios

```
. xtreg lwage exp exp2 wks ed, re vce(cluster id) theta
```

```
Random-effects GLS regression              Number of obs      =       4165
Group variable: id                        Number of groups   =        595

R-sq:  within = 0.6340                    Obs per group: min =         7
       between = 0.1716                               avg   =        7.0
       overall  = 0.1830                               max   =         7

Random effects u_i ~ Gaussian              Wald chi2(4)        =    1598.50
corr(u_i, X) = 0 (assumed)                Prob > chi2         =         0.0000
theta = .82280511
```

(Std. Err. adjusted for 595 clusters in id)

lwage	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
exp	.0888609	.0039992	22.22	0.000	.0810227	.0966992
exp2	-.0007726	.0000896	-8.62	0.000	-.0009481	-.000597
wks	.0009658	.0009259	1.04	0.297	-.000849	.0027806
ed	.1117099	.0083954	13.31	0.000	.0952552	.1281647
_cons	3.829366	.1333931	28.71	0.000	3.567921	4.090812
sigma_u	.31951859					
sigma_e	.15220316					
rho	.81505521	(fraction of variance due to u_i)				

Podemos notar que existen algunas diferencias en los coeficientes estimados, dado que el estimador de efecto fijo siempre es **consistente** y el estimador de efectos aleatorios sólo es consistente bajo el supuesto de que no existe correlación entre los efectos individuales y las variables explicativas, si existe una diferencia significativa es porque el estimador de efectos aleatorios no es apropiado. El estimador de efectos aleatorios siempre será más eficiente. Además, la ventaja del estimador de efectos aleatorios por sobre el de efectos fijos es que el primero permite identificar los coeficientes de las variables que no varían en el tiempo.

Para testear si el estimador de efectos aleatorios es apropiado, o en otras palabras se cumple el supuesto de no correlación entre los efectos individuales y las variables explicativas se debe realizar un test de Hausman.

Cuadro 10.10
Comparación Efectos Aleatorios y Efectos Fijos

```
. estimates table fe re, b se stats(N r2_o r2_b r2_w) b(%7.4f)
```

variable	fe	re
exp	0.1138 0.0040	0.0889 0.0040
exp2	-0.0004 0.0001	-0.0008 0.0001
wks	0.0008 0.0009	0.0010 0.0009
ed	(omitted)	0.1117 0.0084
_cons	4.5964 0.0601	3.8294 0.1334
N	4165	4165
r2_o	0.0476	0.1830
r2_b	0.0276	0.1716
r2_w	0.6566	0.6340

Legend: b/se

Test de Hausman

A través del comando `hausman` de STATA podemos realizar el test sobre la hipótesis nula de que el estimador de efectos aleatorios es apropiado. Para esto se estima el modelo por efectos fijos y efectos aleatorios guardando los resultados a través del comando `estimates store`, luego se ejecuta el comando:

```
xtreg lwage exp exp2 wks ed, re
estimates store re
```

```
xtreg lwage exp exp2 wks ed, fe
estimates store fe
```

Cuadro 10.11
Test de Hausman

```
. hausman fe re, sigmamore
```

	Coefficients			
	(b) fe	(B) re	(b-B) Difference	sqrt(diag(V_b-V_B)) S.E.
exp	.1137879	.0888609	.0249269	.0012778
exp2	-.0004244	-.0007726	.0003482	.0000285
wks	.0008359	.0009658	-.0001299	.0001108

b = consistent under Ho and Ha; obtained from xtreg
 B = inconsistent under Ha, efficient under Ho; obtained from xtreg
 Test: Ho: difference in coefficients not systematic
 $\chi^2(3) = (b-B)'[(V_b-V_B)^{-1}](b-B)$
 = 1513.02
 Prob>chi2 = 0.0000

En este caso se rechaza la hipótesis nula de efectos aleatorios.

Capítulo 11

Regresión de Mediana y Cuantiles

Cuando estimamos la relación entre una variable de interés, la que hemos llamado variable dependiente, y una o más variables explicativas, por el método de MCO, lo que estamos estimando es la media condicional de la variable dependiente:

$$E[\widehat{Y_i|X_i}] = \hat{\alpha} + x'_i \hat{\beta}$$

Sin embargo, en muchos casos puede que nuestro interés no sea solamente la media de la variable dependiente, sino por ejemplo la mediana o cuantiles de la misma.

En MCO la función que se minimiza es la suma de los errores al cuadrado. En la [regresión de mediana](#):

$$Med[\widehat{Y_i|X_i}] = \hat{\alpha}_{med} + x'_i \hat{\beta}_{med}$$

se minimiza es la suma de los valores absolutos del error:

$$\min_{\alpha, \beta} \sum_{i=1}^N |u_i| \Leftrightarrow \min_{\alpha, \beta} |Y_i - \alpha - x'_i \beta|$$

En la [regresión de cuantiles](#):

$$q_\tau[\widehat{Y_i|X_i}] = \hat{\alpha}_\tau + x'_i \hat{\beta}_\tau$$

se minimiza la siguiente función objetivo:

$$\min_{\alpha_\tau, \beta_\tau} \left[\sum_{i: Y_i \geq \alpha_\tau + x'_i \beta_\tau} \tau |Y_i - \alpha_\tau - x'_i \beta_\tau| + \sum_{i: Y_i < \alpha_\tau + x'_i \beta_\tau} (1 - \tau) |Y_i - \alpha_\tau - x'_i \beta_\tau| \right]$$

Notar que la regresión de mediana es un caso especial de la regresión de cuantiles cuando τ es 0.5.

La ventaja de la regresión de cuantiles es que permite caracterizar de mejor forma los datos, y la regresión de mediana, comparado con de la media, es más robusta frente a la presencia de outliers.

11.1. Regresión de Mediana y Cuantiles en STATA

Para la aplicación de los modelos de regresión de cuantiles se utilizarán datos del logaritmo del gasto médicos y el logaritmo de gastos totales del hogar, los datos fueron obtenidos de la encuesta Vietnam Living Standards del Banco Mundial (1997), y consiste en una muestra de 5.006 hogares.

Cuando realizamos la estimación por mínimos cuadrados ordinarios de un modelo de regresión simple entre el logaritmo del gasto médico y el logaritmo del gasto total del hogar, obtenemos el siguiente resultado:

Cuadro 11.1
Estimación MCO

```
. reg lnmed lntotal, robust
```

Linear regression					Number of obs =	5006
					F(1, 5004) =	318.05
					Prob > F =	0.0000
					R-squared =	0.0587
					Root MSE =	1.5458

lnmed	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
lntotal	.5736545	.0321665	17.83	0.000	.510594	.636715
_cons	.9352117	.298119	3.14	0.002	.3507677	1.519656

```
. predict predmco
(option xb assumed; fitted values)
```

Podemos apreciar que la estimación MCO de este modelo entrega una elasticidad del gasto médico con respecto al gasto total del hogar de un 0.57. Es decir, un aumento de un 1 % en el gasto total del hogar aumenta en un 0.57 % el gasto en medicamentos del hogar. Esta estimación anterior no considera la heterogeneidad

en estas elasticidades que pueden existir en diferentes niveles de ingresos o de gasto total del hogar.

El comando `qreg` de STATA nos permite realizar estimaciones por cuantiles, por ejemplo, a través del siguiente comando podemos estimar una regresión de mediana:

Cuadro 11.2
Estimación de Mediana

```
. qreg lnmed lntotal, quantile(50)
Iteration 1: WLS sum of weighted deviations = 6108.5829
Iteration 1: sum of abs. weighted deviations = 6109.4048
Iteration 2: sum of abs. weighted deviations = 6101.0453
Iteration 3: sum of abs. weighted deviations = 6098.2687
Iteration 4: sum of abs. weighted deviations = 6097.1907
Iteration 5: sum of abs. weighted deviations = 6097.161
Iteration 6: sum of abs. weighted deviations = 6097.158
Iteration 7: sum of abs. weighted deviations = 6097.158
Iteration 8: sum of abs. weighted deviations = 6097.1564

Median regression
Raw sum of deviations 6324.265 (about 6.3716121)
Min sum of deviations 6097.156
Number of obs = 5006
Pseudo R2 = 0.0359
```

	lnmed	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
	lntotal	.6210917	.0388194	16.00	0.000	.5449886 .6971948
	_cons	.5921626	.3646869	1.62	0.104	-.1227836 1.307109

```
. predict predp50
(option xb assumed; fitted values)
```

Se obtiene que en la mediana de la población un aumento de un 1% en el gasto total del hogar incrementa en 0.62% el gasto medico del hogar. La inferencia no se puede realizar directamente a través del output de esta regresión, sino que debemos realizar bootstrap, con lo cual podemos concluir que la elasticidad de 0.62 sobre la media es estadísticamente significativa.

Cuadro 11.3
Bootstrap Estimación de Mediana

```
. bs "qreg lnmed lntotal, quantile(50)" "_b[lntotal]", reps(100)
```

```
command:      qreg lnmed lntotal , quantile(50)
statistic:    _bs_1      = _b[lntotal]
```

Bootstrap statistics

Number of obs	=	5006
Replications	=	100

Variable	Reps	Observed	Bias	Std. Err.	[95% Conf. Interval]
_bs_1	100	.6210917	.0152198	.0418308	.5380903 .7040931 (N) .5672665 .7341737 (P) .5604197 .7133538 (BC)

Note: N = normal
P = percentile
BC = bias-corrected

También podemos obtener la elasticidad de los gastos médicos al gasto total del hogar para el percentil 25:

Cuadro 11.4
Estimación de Percentil 25

```
. qreg lnmed lntotal, quantile(25)
```

Iteration 1: WLS sum of weighted deviations = 5875.156

Iteration 1: sum of abs. weighted deviations = 5877.8326
Iteration 2: sum of abs. weighted deviations = 5232.7371
Iteration 3: sum of abs. weighted deviations = 5096.2454
Iteration 4: sum of abs. weighted deviations = 5086.316
Iteration 5: sum of abs. weighted deviations = 5085.6278
Iteration 6: sum of abs. weighted deviations = 5085.3827
Iteration 7: sum of abs. weighted deviations = 5085.3128
Iteration 8: sum of abs. weighted deviations = 5085.3107
Iteration 9: sum of abs. weighted deviations = 5085.3097
Iteration 10: sum of abs. weighted deviations = 5085.3096

.25 Quantile regression

Raw sum of deviations	5162.186 (about 5.2729998)	Number of obs	=	5006
Min sum of deviations	5085.31	Pseudo R2	=	0.0149

lnmed	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
lntotal	.4034632	.0454632	8.87	0.000	.3143353 .492591
_cons	1.567055	.4271577	3.67	0.000	.7296387 2.404471

```
. predict predp25
(option xb assumed; fitted values)
```

Y para el percentil 90:

Cuadro 11.5
Estimación de Percentil 90

```
. qreg lnmed lntotal, quantile(90)
Iteration 1: WLS sum of weighted deviations = 5224.714
Iteration 1: sum of abs. weighted deviations = 5230.4682
Iteration 2: sum of abs. weighted deviations = 5074.7346
Iteration 3: sum of abs. weighted deviations = 3451.0598
Iteration 4: sum of abs. weighted deviations = 2652.288
Iteration 5: sum of abs. weighted deviations = 2505.1313

. 9 Quantile regression
Raw sum of deviations 2687.692 (about 8.2789364)
Min sum of deviations 2505.131
Number of obs = 5006
Pseudo R2 = 0.0679
```


lnmed	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
lntotal	.8003569	.0517226	15.47	0.000	.698958	.9017558
_cons	.6750967	.4857565	1.39	0.165	-.277199	1.627392

```
. predict predp90
(option xb assumed; fitted values)
```

El siguiente gráfico muestra la relación lineal estimada entre el logaritmo de gasto médico y el logaritmo del gasto total del hogar, para la media, mediana, cuantil 25 y cuantil 90:

```
twoway (scatter lnmed lntotal) (lfit predmco lntotal, lcolor(blue))
(lfit predp50 lntotal, lcolor(red)) (lfit predp25 lntotal, lcolor(green))
(lfit predp90 lntotal, lcolor(purple)),
title(Logaritmo gasto médico y logaritmo gasto total del hogar)
```

Gráfico 11.1
Estimación de Mediana y Cuantiles



Se podría estimar una elasticidad del gasto médico al gasto total para cada cuantil:

```
matrix Q=J(99,2,0)

local i=0.01
while 'i'<1{


qui qreg lnmed lntotal, quantile('i')
matrix Q['i'*100,1]=e(q)
matrix Q['i'*100,2]=_b[lntotal]

local i='i'+0.01
}

svmat Q, name(quantile)

rename quantile1 quantile
rename quantile2 beta
```

```
twoway (line beta quantile, msize(vtiny) mstyle(p1) clstyle(p1)),  
       yline(.5736545, lcolor(red)) title(Beta estimado para cada quantil)
```

Gráfico 11.2*Elasticidad para cada Cuantil*

Podemos apreciar que mientras menor es el nivel de gasto en médico del hogar (cuantiles más bajos), menor es la elasticidad del gasto en médico con respecto al gasto total del hogar. La línea roja del gráfico representa la estimación MCO del coeficiente de interés.

Capítulo 12

Modelos de Datos de Conteo

En muchos contextos económicos la variable dependiente toma sólo valores enteros positivos, es decir, corresponde a una cuanta o conteo de algo y esto es lo que queremos explicar en función de algunas variables explicativas. Cuando la variable dependiente tiene estas características no es apropiado utilizar el modelo de regresión lineal (MCO), este tipo de modelo, al igual que los modelos probit y logit, son no lineales, por lo cual la forma correcta de estimar este tipo de modelos es por Máxima Verosimilitud.

Algunos ejemplos de modelo de conteo son:

- Estudios de fertilidad: se estudia el número de nacimientos y como estos varían en función de la escolaridad de la madre, la edad, y el ingreso del hogar.
- Estudio del número de accidentes de una aerolínea como medida de seguridad de la aerolínea, que puede ser explicado por los beneficios de la empresa y la salud financiera de la misma.
- Estudios de demanda recreacional, que modelan el número de viajes a lugares recreacionales.
- Estudios de demanda por salud, donde se trata de modelar el número de veces que los individuos demandan servicios de salud como número de visitas al doctor o número de días en el hospital.

12.1. Modelo de Regresión Poisson

La distribución Poisson es para variables discretas no negativas, de esta forma, podemos asumir que la variable dependiente tiene este tipo de distribución para plantear la función de verosimilitud. Entonces la variable dependiente tiene distribución Poisson, podemos escribir su función de masa de probabilidad como:

$$Pr[Y = y] = \frac{e^{-\mu} \mu^y}{y!} \quad y = 0, 1, 2, \dots$$

donde μ es lo que se denomina intensidad. Notemos además que $E[Y] = \mu$ y $V[Y] = \mu$, es decir, se tiene equidispersión o igual media y varianza.

Luego, el [Modelo de Regresión Poisson](#) es derivado de la distribución Poisson parametrizando la relación entre el parámetro μ y las variables explicativas:

$$E[y_i|x_i] = \mu_i = \exp(x_i'\beta)$$

dado que la varianza de esta variable será igual a la media, el modelo por construcción será heterocedástico:

$$V[y_i|x_i] = \mu_i = \exp(x_i'\beta)$$

La función de verosimilitud para este modelo es:

$$\ln L = \sum_{i=1}^N \{y_i x_i' \beta - \exp(x_i' \beta) - \ln(y_i!)\}$$

Los coeficientes estimados de este modelo no representan los efectos marginales de las variables explicativas sobre la media condicional de la variable dependiente, los efectos marginales se obtienen de la siguiente manera:

$$\frac{\partial E[y_i|x_i]}{\partial x_k} = \exp(x_i' \beta) \beta_k$$

El modelo de regresión poisson usualmente será muy restrictivo para los datos de conteo, el problema fundamental es que la distribución es parametrizada en términos de un sólo parámetro μ , la media y la varianza son iguales a este parámetro. Usualmente, la varianza excede a la media lo que se conoce como [sobredispersión](#).

Una vez estimado el modelo poisson se puede realizar un test de sobredispersión. Para realizar este test se asume que la varianza de la variable dependiente es de la forma:

$$V[y_i|x_i] = \mu_i + \alpha g(\mu_i)$$

donde α es un parámetro desconocido y $g(\cdot)$ es una función desconocida, pero generalmente se asume $g(\mu) = \mu$ o $g(\mu) = \mu^2$, luego se testea la hipótesis nula de que $\alpha = 0$.

Para aplicar este test se estima el modelo poisson, se construye el valor estimado de la media $\hat{\mu}_i = \exp(x_i' \hat{\beta})$, y se realiza la siguiente regresión auxiliar (sin constante):

$$\frac{(y_i - \hat{\mu}_i)^2 - y_i}{\hat{\mu}_i} = \alpha \frac{g(\hat{\mu}_i)}{\hat{\mu}_i} + u_i$$

donde u_i es un término de error. Luego se realiza un test t sobre la hipótesis nula de que $\alpha = 0$.

12.2. Estimación de Modelo Poisson en STATA


El comando en STATA para estimar este tipo de modelos es el siguiente:

```
poisson depvar [indepvars] [if] [in] [weight] [, options]
```

Recordemos que por construcción el modelo es heterocedástico por lo cual se deben calcular las varianzas de manera robusta, para esto se puede utilizar la opción `vce(robust)`.

Para esta aplicación se utiliza la base de datos del RAND Experimento de Seguros de Salud (RAND Health Insurance Experiment) utilizada por Deb y Trivendi (2002). El experimento conducido por la Coporación RAND entre los años 1974 y 1982, ha sido el experimento social controlado más grande en el área de la investigación en seguros de salud. El objetivo principal del experimento era evaluar como el uso de los servicios de salud por parte de los pacientes se ve afectado por los tipos de seguros medicos, los cuales fueron asignados aleatoriamente. En el experimento los datos fueron recolectados para cerca de 8.000 personas en 2.823 familias. Cada familia fue suscrita a uno de los 14 diferentes planes de salud por 3 o 5 años. Los planes van desde servicio libre hasta 95 % de cobertura bajo cierto nivel de gasto (con un tope).

El siguiente gráfico muestra un histograma con el número de visitas al médico, podemos ver que poco más del 30 % realiza cero visitas al año al médico, y cerca de un 18 % realiza una visita al año.

Gráfico 12.1*Distribución Número de Visitas*

La siguiente tabla muestra las principales estadísticas de cada una de las variables que serán utilizadas como factores determinantes en la cantidad de visitas al médico realizadas al año. La variable BLACK toma valor 1 si el jefe de hogar es de raza negra, la variable AGE corresponde a la edad en años, FEMALE toma valor 1 si la persona es mujer, EDUCDEC representa los años de educación del jefe de hogar, MDU es la variable que queremos explicar (variable dependiente) que mide el número de visitas ambulatorias a un médico, NDISEASE es el número de enfermedades crónicas, PHYSLIM toma valor 1 si la persona tiene limitaciones físicas, CHILD toma valor 1 si la persona tiene menos de 18 años, FEMCHILD corresponde a la interacción de la Dummy FEMALE y la Dummy CHILD, LFAM es el logaritmo del tamaño familiar, LPI es el logaritmo del pago anual de incentivo por participación, IDP si el plan tiene deducible, LC es el logaritmo del copago, FMDE es el logaritmo del tope de cobertura sobre 0.01 el copago, HLTHG es 1 si declara que su estado de salud es bueno, HLTHF es 1 si declara su estado de salud regular, HLTHP si declara estado de salud malo, y LINC es el logaritmo del ingreso familiar.

Cuadro 12.1
Estadísticas Descriptivas Variables Explicativas

. Sum					
Variable	Obs	Mean	Std. Dev.	Min	Max
BLACK	20186	.1815343	.3827365	0	1
AGE	20186	25.71844	16.76759	0	64.27515
FEMALE	20186	.5169424	.4997252	0	1
EDUCDEC	20186	11.96681	2.806255	0	25
MDU	20186	2.860696	4.504765	0	77
NDISEASE	20186	11.2445	6.741647	0	58.6
PHYSLIM	20186	.1235247	.3220437	0	1
CHILD	20186	.4014168	.4901972	0	1
FEMCHILD	20186	.1937481	.3952436	0	1
LFAM	20186	1.248404	.5390681	0	2.639057
LPI	20186	4.708827	2.697293	0	7.163699
IDP	20186	.2599822	.4386354	0	1
LC	20186	2.383588	2.041713	0	4.564348
FMDE	20186	4.030322	3.471234	0	8.294049
HLTHG	20186	.3620826	.4806144	0	1
HLTHF	20186	.0772813	.2670439	0	1
HLTHP	20186	.0149609	.1213992	0	1
LINC	20186	8.708167	1.22841	0	10.28324

El siguiente cuadro muestra el resultado de estimar un modelo poisson para explicar el número de veces que la persona va al médico al año en función de las características de los planes de salud y características familiares.

Los coeficientes estimados no representan los efectos marginales, estos deben ser computados con el comando `mfx`. El Cuadro 12.3 muestra la estimación de los efectos marginales del modelo. Se encuentra que un incremento de un 1 % en el copago disminuye en 0.11 las visitas promedio al año, si el plan tiene deducible disminuye en 0.4 las visitas promedio al año, un incremento de un 1 % en el ingreso familiar aumenta en 0.21 las visitas promedio al año, las mujeres en promedio van 0.9 veces más al médico que los hombres, al igual que las personas menores de 18 años de edad. Las personas de raza negra van en promedio al médico 1.7 veces menos.

Cuadro 12.2
Estimación Modelo Poisson

```
. poisson MDU LC IDP LPI FMDE LINC LFAM AGE FEMALE CHILD FEMCHILD BLACK EDUCDEC PHY
> SLIM NDISEASE HLTHG HLTHF HLTHP
```

```
Iteration 0: log likelihood = -60097.599
Iteration 1: log likelihood = -60087.636
Iteration 2: log likelihood = -60087.622
Iteration 3: log likelihood = -60087.622
```

```
Poisson regression
```

```
Number of obs = 20186
LR chi2(17) = 13106.07
Prob > chi2 = 0.0000
Pseudo R2 = 0.0983
```

```
Log likelihood = -60087.622
```

MDU	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
LC	-.0427332	.0060785	-7.03	0.000	-.0546469	-.0308195
IDP	-.1613169	.0116218	-13.88	0.000	-.1840952	-.1385385
LPI	.0128511	.0018362	7.00	0.000	.0092523	.0164499
FMDE	-.020613	.0035521	-5.80	0.000	-.027575	-.0136511
LINC	.0834099	.0051656	16.15	0.000	.0732854	.0935343
LFAM	-.1296626	.0089603	-14.47	0.000	-.1472245	-.1121008
AGE	.0023756	.0004311	5.51	0.000	.0015306	.0032206
FEMALE	.3487667	.0113504	30.73	0.000	.3265203	.371013
CHILD	.3361904	.0178194	18.87	0.000	.3012649	.3711158
FEMCHILD	-.3625218	.0179396	-20.21	0.000	-.3976827	-.3273608
BLACK	-.6800518	.0155484	-43.74	0.000	-.7105262	-.6495775
EDUCDEC	.0176149	.0016387	10.75	0.000	.0144031	.0208268
PHYSLIM	.2684048	.0123624	21.71	0.000	.2441749	.2926347
NDISEASE	.023183	.0006081	38.12	0.000	.0219912	.0243749
HLTHG	.0394004	.0095884	4.11	0.000	.0206074	.0581934
HLTHF	.2531119	.016212	15.61	0.000	.2213369	.2848869
HLTHP	.5216034	.0272382	19.15	0.000	.4682176	.5749892
_cons	-.1898766	.0491731	-3.86	0.000	-.2862541	-.093499

Un supuesto implícito en la distribución poisson es que la varianza es igual a la media, es decir, que existe equidispersión, este supuesto es testeable para esto después de haber estimado el modelo generamos el valor predicho de la media ($\hat{\mu}_i$):

```
predict mugorro, n
```

Luego generamos la variable dependiente de la regresión auxiliar:

```
g yaux=((MDU-mugorro)^2-MDU)/mugorro
```

y se hace una regresión de esta variable contra $\hat{\mu}_i$. Los resultados se presentan en el Cuadro 12.4. AL rechazar la hipótesis nula de que el coeficiente que acompaña a $\hat{\mu}$ es igual a cero, se rechaza la hipótesis nula de equidispersión.

Cuadro 12.3
Efectos Marginales

. mfx							
Marginal effects after poisson							
y = Predicted number of events (predict)							
= 2.5526948							
variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]
LC	-.1090849	.01551	-7.03	0.000	-.139482	-.078688	2.38359
IDP*	-.396583	.02749	-14.43	0.000	-.45046	-.342706	.259982
LPI	.0328049	.00469	7.00	0.000	.02362	.04199	4.70883
FMDE	-.0526187	.00907	-5.80	0.000	-.070389	-.034848	4.03032
LINC	.2129199	.01313	16.22	0.000	.187188	.238652	8.70817
LFAM	-.3309892	.02283	-14.50	0.000	-.375737	-.286241	1.2484
AGE	.0060642	.0011	5.51	0.000	.003907	.008221	25.7184
FEMALE*	.8895421	.02887	30.81	0.000	.832963	.946121	.516942
CHILD*	.8912944	.04911	18.15	0.000	.795039	.98755	.401417
FEMCHILD*	-.8327063	.03698	-22.52	0.000	-.90519	-.760223	.193748
BLACK	-1.735965	.03863	-44.94	0.000	-1.81168	-1.66025	.181534
EDUCDEC	.0449655	.00418	10.76	0.000	.036773	.053158	11.9668
PHYSLIM	.6851555	.03153	21.73	0.000	.623364	.746947	.123525
NDISEASE	.0591792	.00155	38.26	0.000	.056148	.062211	11.2445
HLTHG*	.1011317	.02474	4.09	0.000	.052633	.14963	.362083
HLTHF*	.7210038	.05129	14.06	0.000	.620471	.821537	.077281
HLTHP*	1.734312	.11537	15.03	0.000	1.50819	1.96044	.014961
(*) dy/dx is for discrete change of dummy variable from 0 to 1							

Cuadro 12.4
Test de sobredispersión

. reg yaux mugorro, nocon noheader						
yaux	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
mugorro	1.488852	.0830523	17.93	0.000	1.326063	1.651642

Una vez estimado el modelo este puede ser utilizado para comprar las frecuencias muestrales con las frecuencias ajustadas para los valores de la variable dependiente (discreta). Las frecuencias ajustadas se obtienen promediando las probabilidades predichas según el modelo de que cada individuo tenga un valor de la variable dependiente 0, 1, 2, etc..Para esto se utiliza el comando `countfit` (descargar los ado necesarios en http://www.indiana.edu/~jslsoc/stata/spost9_ado/, `countfit`, `fitstat` y `prcounts`).

El Cuadro 12.5 muestra la comparación de la proporción muestral y predicha según el modelo de regresión poisson, podemos notar las dificultades del modelo poisson para predecir las frecuencias muestrales observadas, por ejemplo, en los

datos efectivos de la variable se observa que un 31.2% no ha ido al médico, sin embargo, el modelo predice que un 10.7% no ha ido al médico.

Cuadro 12.5
Comparación Frecuencia Observada y Predicha

```
. countfit MDU LC IDP LPI FMDE LINC LFAM AGE FEMALE CHILD FEMCHILD BLACK EDUCDEC PHY
> SLIM NDISEASE HLTHG HLTHF HLTHP, maxcount(5) prn noestimates nofit
Comparison of Mean Observed and Predicted Count
```

Model	Maximum Difference	At Value	Mean Diff
PRM	0.206	0	0.076

PRM: Predicted and actual probabilities

Count	Actual	Predicted	Diff	Pearson
0	0.312	0.107	0.206	8002.381
1	0.189	0.192	0.003	1.111
2	0.138	0.209	0.071	483.374
3	0.093	0.176	0.083	788.603
4	0.067	0.126	0.059	562.277
5	0.048	0.080	0.032	258.557
Sum	0.848	0.890	0.454	1.0e+04

12.3. Modelo Binomial Negativo

Cuando la varianza de la variable dependiente no es igual a la media el modelo de regresión poisson no es apropiado, una forma de modelar este problema es asumir que el parámetro de la distribución poisson (que corresponde a la media y a la varianza) corresponde al producto de una función determinística de x y una variable aleatoria. Así, sea y una variable con distribución poisson condicional en el parámetros λ :

$$f(y|\lambda) = \frac{\exp(-\lambda)\lambda^y}{y!}$$

donde $\lambda = \mu\nu$, donde μ es una función de determinística de x , $\exp(x'_i\beta)$, y $\nu > 0$ es iid con función de densidad $g(\nu|\alpha)$, cuando esta función de densidad es gamma se obtiene el [modelo binomial negativo](#). Cuando $\alpha = 0$ se converge al modelo poisson.

La media y la varianza de la distribución binomial negativa son:

$$\begin{aligned} E[y|\mu, \alpha] &= \mu \\ V[y|\mu, \alpha] &= \mu(1 + \alpha\mu) \end{aligned}$$

la varianza excede la media ya que $\alpha > 0$ y $\mu > 0$.

12.4. Estimación Modelo Binomial Negativo en STATA

Para estimar el modelo de número de visitas al médico utilizando el supuesto de distribución binomial negativa con varianza cuadrática, se debe utilizar el comando `nbreg` de STATA. El Cuadro 12.6 muestra el resultado de la estimación de este modelo. Los coeficientes estimados, al igual que en el modelo poisson, no pueden ser interpretados como efectos marginales, por lo cuál debemos preocuparnos de calcular los efectos marginales con el comando `mfxx` luego de estimar el modelo. Al final del output de la regresión se muestra el test sobre la hipótesis nula de que α es igual a cero, lo que es consistente con un modelo poisson, sin embargo, en este caso se rechaza la hipótesis nula.

Cuadro 12.6

Modelo Binomial Negativo: visitas médico

```
. nbreg MDU LC IDP LPI FMDE LINC LFAM AGE FEMALE CHILD FEMCHILD BLACK EDUCDEC PHYSLI
> M NDISEASE HLTHG HLTHF HLTHP, noolog
```

Negative binomial regression

Dispersion = mean

Log likelihood = -42777.611

Number of obs = 20186

LR chi2(17) = 2828.01

Prob > chi2 = 0.0000

Pseudo R2 = 0.0320

	MDU	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
LC		-.0504405	.0128694	-3.92	0.000	-.0756641 -.0252169
IDP		-.1475976	.0254099	-5.81	0.000	-.1974001 -.0977951
LPI		.0158351	.0040586	3.90	0.000	.0078805 .0237898
FMDE		-.021335	.0075119	-2.84	0.005	-.036058 -.0066119
LINC		.0845165	.0085659	9.87	0.000	.0677277 .1013053
LFAM		-.1226764	.019308	-6.35	0.000	-.1605195 -.0848333
AGE		.0025943	.0009433	2.75	0.006	.0007455 .0044432
FEMALE		.3672884	.024005	15.30	0.000	.3202395 .4143373
CHILD		.3060317	.0385618	7.94	0.000	.230452 .3816115
FEMCHILD		-.3755503	.0371392	-10.11	0.000	-.4483418 -.3027587
BLACK		-.7104372	.0274929	-25.84	0.000	-.7643223 -.6565521
EDUCDEC		.0162582	.0034846	4.67	0.000	.0094285 .0230879
PHYSLIM		.2751715	.0295572	9.31	0.000	.2172404 .3331026
NDISEASE		.0259352	.0014827	17.49	0.000	.0230292 .0288412
HLTHG		.0065371	.0202235	0.32	0.747	-.0331002 .0461744
HLTHF		.2368643	.0374086	6.33	0.000	.1635448 .3101837
HLTHP		.4256563	.0741812	5.74	0.000	.2802638 .5710488
_cons		-.2069298	.0899431	-2.30	0.021	-.3832151 -.0306445
/lnalpha		.1674206	.0147901			.1384326 .1964087
alpha		1.182251	.0174856			1.148472 1.217024

Likelihood-ratio test of alpha=0: **chibar2(01) = 3.5e+04 Prob>=chibar2 = 0.000**

El Cuadro 12.7 muestra los efectos marginales sobre el número de visitas al médico estimados mediante el modelo binomial negativo, se encuentra que un incremento de un 1 % en el copago disminuye en 0.13 las visitas promedio al año, si el plan tiene deducible disminuye en 0.36 las visitas promedio al año, un incremento de un 1 % en el ingreso familiar aumenta en 0.21 las visitas promedio al año, las mujeres en promedio van 0.93 veces más al médico que los hombres, al igual que las personas menores de 18 años de edad. Las personas de raza negra van en promedio al médico 1.8 veces menos.

Cuadro 12.7

Efectos Marginales Binomial Negativo: visitas médico

```
. mfx
```

Marginal effects after nbreg
y = Predicted number of events (predict)
= 2.5365441

variable	dy/dx	Std. Err.	z	P> z	[	95% C.I.	]	x
LC	-.1279445	.03265	-3.92	0.000	-.191944	-.063945		2.38359
IDP*	-.361685	.06021	-6.01	0.000	-.479698	-.243672		.259982
LPI	.0401665	.0103	3.90	0.000	.019983	.06035		4.70883
FMDE	-.0541171	.01906	-2.84	0.005	-.091469	-.016765		4.03032
LINC	.2143799	.02174	9.86	0.000	.171764	.256996		8.70817
LFAM	-.3111741	.04901	-6.35	0.000	-.407226	-.215122		1.2484
AGE	.0065806	.00239	2.75	0.006	.00189	.011271		25.7184
FEMALE*	.9310767	.06143	15.16	0.000	.81067	1.05148		.516942
CHILD*	.803165	.10516	7.64	0.000	.597064	1.00927		.401417
FEMCHILD*	-.8541029	.07596	-11.24	0.000	-1.00298	-.705228		.193748
BLACK	-1.802055	.07036	-25.61	0.000	-1.93996	-1.66415		.181534
EDUCDEC	.0412396	.00884	4.66	0.000	.023908	.058571		11.9668
PHYSLIM	.6979846	.07514	9.29	0.000	.550716	.845253		.123525
NDISEASE	.0657858	.00379	17.37	0.000	.058363	.073209		11.2445
HLTHG*	.0165967	.05139	0.32	0.747	-.084128	.117321		.362083
HLTHF*	.6656429	.11621	5.73	0.000	.437882	.893404		.077281
HLTHP*	1.337333	.28482	4.70	0.000	.77909	1.89558		.014961

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Al igual que en el modelo de regresión poisson podemos comparar las frecuencias muestrales para los número de visitas con las frecuencias estimadas según el modelo, el Cuadro 12.8 muestra que este modelo logra predecir bastante mejor que el modelo poisson.

Cuadro 12.8
Comparación Frecuencia Observada y Predicha

```
. countfit MDU LC IDP LPI FMDE LINC LFAM AGE FEMALE CHILD FEMCHILD BLACK EDUCDEC PHY
> SLIM NDISEASE HLTHG HLTHF HLTHP, maxcount(5) nbreg noestimates nofit
```

Comparison of Mean observed and Predicted Count

Model	Maximum Difference	At Value	Mean Diff
NBRM	0.011	2	0.004

NBRM: Predicted and actual probabilities

Count	Actual	Predicted	Diff	Pearson
0	0.312	0.318	0.006	2.115
1	0.189	0.191	0.002	0.316
2	0.138	0.128	0.011	18.819
3	0.093	0.089	0.004	3.684
4	0.067	0.064	0.002	1.695
5	0.048	0.047	0.001	0.200
Sum	0.848	0.837	0.025	26.829

Capítulo 13

Métodos No Paramétricos y Semi-paramétricos

En esta sección presentaremos métodos para el análisis de datos que buscan realizar la menor cantidad de supuestos sobre el proceso que genera los datos. Los primeros son los métodos no paramétricos, los que nos permitirán estimar la densidad de una variable. También se verá la regresión no paramétrica, la que sólo se puede realizar en función de una variable explicativa, aunque teóricamente la regresión no paramétrica se puede realizar en función de más de una variable explicativa, en la práctica esto no es factible. Es por esta razón que surgen los métodos semi-paramétricos, en los que por ejemplo no se supone una forma funcional específica para la relación entre la variable dependiente y explicativa (media, mediana, etcÉ) sino que se deja que los datos revelen esta función, estimando los parámetros beta que forman parte del argumento de esta relación.


13.1. Estimación No Paramétrica de Funciones de Densidad

La primera aproximación para estimar la densidad de una variable es mediante el histograma de la misma, el [histograma](#) divide el espacio posible de los valores de la variable en intervalos de igual distancia y calculando la fracción de las observaciones en cada uno de estos intervalos se aproxima la distribución empírica de la variable. Sin embargo, el histograma es una estimación tosca o no suave de la densidad. El siguiente gráfico muestra el histograma del logaritmo del ingreso

de la ocupación principal, obtenido de la encuesta Casen 2009:

Gráfico 13.1

Histograma



Para obtener una estimación más suave de la función de densidad en vez de tomar intervalos de valores de la variable, se podría tomar cada observación puntual de la variable y darle un peso de $\frac{1}{N}$ a cada una de estas observaciones, el problema de esta metodología es que no se le asigna probabilidad a los valores de x que no son observados en la muestra. Entonces la alternativa que surge a esto es no darle el peso o probabilidad $\frac{1}{N}$ al punto x_i sino a la densidad de la variable entorno a x_i . Esto es justamente lo que hace la estimación **KERNEL**, obtiene la densidad empírica de la variable tomando una combinación de densidades entorno a los puntos observados de la variable:

$$\hat{f}(x_0) = \frac{1}{Nh} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right)$$

Donde $K(\cdot)$ es la llamado función Kernel, y h es el llamado bandwidth. Dentro de las funciones kernel se encuentra el Gaussiano, Epanechnikov, uniforme, entre otros. Se ha demostrado que la función Kernel óptima es la Epanechnikov. Con respecto al parámetro de suavización h , existe una elección óptima que corresponden a aquel que minimiza el error cuadrático medio integrado de la función de densidad.

El comando que en STATA permite estimar la densidad utilizando la función Kernel es `kdensity`:

```
kdensity varname [if] [in] [weight] [, options]
```

Por ejemplo, el Gráfico 11.2 muestra la estimación con Kernel Gaussiano de la función de densidad del logaritmo del ingreso de la ocupación principal:


```
kdensity lny, gaussian generate(estim den)
```



La opción `generate`, genera dos variables `estim` que contiene los puntos de estimación de la densidad kernel y `den` que contiene la densidad estimada para cada uno de estos puntos. En esta estimación se ha utilizado el bandwidth óptimo, que corresponde al default de STATA.

El siguiente gráfico muestra la estimación kernel utilizando la función gaussiana y `epanechnikov`, en ambas utilizando el bandwidth óptimo que mínimo el error cuadrático medio integrado.


```
twoway (kdensity lny, gaussian) (kdensity lny),  
legend(on order(1 "Gaussian" 2 "Epanechnikov"))
```

Gráfico 13.3*Kernel Gaussiano y Epanechnikov*

Las diferencias entre ambas estimaciones son mínimas. Se menciona que se ha demostrado que el Kernel Epanechnikov ha demostrado ser óptimo pero en la práctica las ventajas son mínimas. Lo que sí puede generar grandes diferencias es la elección del parámetro de suavización, bandwidth. El Gráfico 11.4 muestra cuatro funciones kernel utilizando el kernel Epanechnikov con 4 bandwidths distintos, incluyendo el valor óptimo.

```
twoway (kdensity lny) (kdensity lny, width(1)) (kdensity lny, width(0.5))
(kdensity lny, width(0.05)), legend(on order(1 "h óptimo" 2 "h=1"
3 "h=0.5" 4 "h=0.0"))
```

Gráfico 13.4
Kernel Epanechnikov



Mientras mayor el bandwidth asumido más se suaviza la función de densidad. Este parámetro representa una especie de desviación estándar de cada una de las densidades que estoy combinando, mientras mayor es el parámetro más desviación estándar tienen las densidades ponderadas lo que suaviza la función de densidad final obtenida.

13.2. Estimación No Paramétrica de la Relación Entre Dos Variables

Consideremos la regresión entre la variable dependiente y sobre la variable explicativa x . El modelo de regresión, sin asumir una forma funcional específica para la relación entre ambas variables, es el siguiente:

$$y_i = m(x_i) + \varepsilon_i \quad i = 1, \dots, N.$$

$$\varepsilon_i \sim iid(0, \sigma_\varepsilon^2)$$

Donde la forma funcional $m(\cdot)$ no ha sido especificada.

El método general denominado **Local Weighted Average Estimator** toma la siguiente forma:

$$\hat{m}(x_0) = \sum_{i=1}^N \omega_{i0,h} y_i$$


donde $\omega_{i0,h} = \omega(x_i, x_0, h)$ y $\sum_{i=1}^N \omega_{i0,h} = 1$.

De esta forma, para cada punto x_0 que observamos se obtiene la relación estimada con la variable dependiente como el promedio ponderado de la variable dependiente, donde el ponderador depende de cuan cerca esta la observación de x_i a x_0 . El estimador **Lowess** utiliza la función kernel como ponderador. De esta forma, el Lowess Estimator minimiza la siguiente función objetivo:

$$\min_{m_0} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right) (y_i - m_0)^2$$

El comando en STATA que permite realizar esta estimación es **lowess**, el Gráfico 11.5 muestra la estimación no paramétrica de la relación entre logaritmo del ingreso de la ocupación principal y los años de escolaridad, y la estimación paramétrica MCO de la misma relación.

Gráfico 13.5
Estimación Lowess



Otros estimadores no paramétricos son el estimador de Nadaraya-Watson (**kernreg**) y el estimador del vecino más cercano (**knnreg**), lo que cambia son las definiciones del ponderador.

Capítulo 14

Evaluación de Tratamiento

La Evaluación de Tratamiento consiste en medir el impacto de intervenciones o tratamientos en variables de resultados de interés. Algunos ejemplos de tratamientos en el contexto económico son:

- Programa de Capacitación Laboral
- Pertenecer a un sindicato de trabajadores
- Ser beneficiario de un programa social
- Cambios en las políticas que definen los beneficiarios de un programa social
- Cambios en incentivos económicos

El mayor desafío en la evaluación de impacto es determinar que habría pasado con los beneficiarios si el programa o intervención no hubiese existido, el resultado del beneficiario en ausencia del programa es su **contrafactual**. Entonces el problema para medir el impacto (independiente de otros factores) sólo puede ser obtenido comparando el resultado efectivo y el resultado contrafactual. Sin embargo, el resultado contrafactual no es observado. Así, el desafío es crear un grupo de comparación razonable y convincente para los beneficiarios.

14.1. El Problema de Sesgo de Selección

La siguiente ecuación presenta el problema básico que surge de comparar la variable de resultado Y entre los individuos tratados y no tratados:

$$Y_i = X_i\beta + \gamma T_i + u_i$$

donde T_i es una variable dummy que toma valor 1 para aquellos que participan en el programa y cero para quienes no participan. Además se incluyen variables explicativas X_i que caracterizan al individuo y que afectan Y , finalmente u corresponden a los factores no observables que afectan Y . El problema en estimar el efecto del tratamiento a través de γ es que generalmente el tratamiento no ha sido asignado de manera aleatoria, de esta forma puede ser el caso en que los no observables estén relacionados con la probabilidad de recibir el tratamiento, generando un problema de endogeneidad en la ecuación antes planteada.

De manera alternativa, podemos definir la variable de resultado para los tratados como $Y_i(1)$ y para los no participantes $Y_i(0)$. Si $Y_i(0)$ se utiliza como comparación del resultado de los participantes $Y_i(1)$ el efecto promedio del programa puede ser representado de la siguiente forma:

$$D = E[Y_i(1)|T_i = 1] - E[Y_i(0)|T_i = 0]$$

El problema es que el grupo de los tratados y no tratados pueden ser diferentes previo al tratamiento (no han sido asignados aleatoriamente), de esta forma la simple diferencia en las medias no representa el efecto puro del tratamiento. Sumando y restando el resultado de los no participantes si hubiesen participado:

$$\begin{aligned} D &= E[Y_i(1)|T_i = 1] - E[Y_i(0)|T_i = 0] + E[Y_i(0)|T_i = 1] - E[Y_i(0)|T_i = 1] \\ &= E[Y_i(1)|T_i = 1] - E[Y_i(0)|T_i = 1] + E[Y_i(0)|T_i = 1] - E[Y_i(0)|T_i = 0] \\ &= ATT + B \end{aligned}$$

donde ATT es el **Efecto Tratamientos sobre los Tratados** (Average Treatment Effect on Treated) que representa la ganancia promedio en la variable de resultado de los participantes relativo a los no participantes si los no participantes también hubiesen sido tratados. B representa el sesgo de selección que se genera al utilizar D como una medida del ATT .

Luego, los objetivos para poder estimar de manera apropiada el Efecto Promedio del Tratamiento es tratar de eliminar B o encontrar una manera de contabilizar este sesgo.

El problema de sesgo de selección desaparece si se asume que el recibir o no el tratamiento (condicional en una serie de variables explicativas X) es independiente de los resultados que ellos obtienen, lo que se conoce como el supuesto de independencia condicional:

$$(Y_i(1), Y_i(0)) \perp T_i | X_i$$

Cuando el programa es aplicable a todos la población se está interesado en medir el efecto tratamiento promedio (ATE):

$$ATE = E[Y_i(1) - Y_i(0)]$$

14.2. Metodologías para Evaluación de Impacto

Existen diversas metodologías para abordar el problema de no existencia de contrafactual. Cada una de estas metodologías hace diferentes supuestos sobre la naturaleza del problema de sesgo de selección en la participación en el programa. Estas metodologías son:

1. Propensity Score Matching (PSM): esta metodología asume que el sesgo de selección es en variables observables, luego estas pueden ser utilizadas para determinar un grupo de no participantes con características similares a las de los no participantes como si hubiesen sido seleccionados de manera aleatoria.
2. Doble Diferencias (DD): esta metodología asume que existe selección en no observables pero que esta no varía en el tiempo por lo cuál este sesgo se elimina al tomar diferencias en el tiempo. Así, el efecto del tratamiento se obtiene tomando la diferencia en la variable de resultado entre tratados y no tratados antes y después del programa.
3. Variables Instrumentales: con esta metodología se busca corregir el problema de endogeneidad que genera el sesgo de selección, para esto requiere de una variable o instrumento que se correlacione con la participación en el programa pero no con las características no observables que afectan la variable de resultado.
4. Regresión en la Discontinuidad (RD): esta metodología es una extensión del estimador de variables instrumentales, explota las reglas exógenas de selección para el programa para comparar participantes y no participantes en una vecindad de la regla que determina la selección, en esta vecindad se puede argumentar que no existe sesgo de selección.

14.2.1. Propensity Score Matching

Esta metodología construye un grupo de comparación o de control basado en un modelo de probabilidad de participación en el programa utilizando características observadas, luego se hace un matching de los participantes con este grupo de participación en base a esta probabilidad o [propensity](#).

El efecto tratamiento promedio del programa se obtiene de la diferencia en los resultados de estos dos grupos. La validez de esta metodología se sustenta en dos condiciones:

- Independencia Condicional (factores no observables no afectan la participación)
- Soporte Común en el propensity score entre participantes y no participantes

La Figura 12.1 muestra un ejemplo de soporte común aceptable entre tratados y no tratados, mientras que la Figura 12.2 muestra un ejemplo de soporte débil.

Figura 14.1
Soporte Común





Figura 14.2
Soporte Común Débil



Diferentes metodologías pueden ser utilizadas para hacer el matching entre tratados y no tratados de acuerdo al propensity score: vecino más cercano, matching de radio, matching estratificado o intervalo, y Kernel Matching. Pero la estimación del modelo usando tratados y no tratados ponderando de acuerdo al propensity score permite obtener estimaciones más eficientes.

Las condiciones de independencia condicional y soporte común requieren supuestos menos fuerte cuando se calcula el ATT, razón por la cuál la mayoría de las investigaciones que utilizan esta metodología se concentran en el cálculo de este indicador para evaluar el impacto del programa.

Utilizando datos de corte transversal, y dentro del soporte común, el efecto tratamiento sobre los tratados se puede obtener de la siguiente manera:

$$ATT_{PSM} = \frac{1}{N_T} \sum_{i \in T} \left[Y_i^T - \sum_{j \in C} \omega(i, j) Y_j^C \right]$$

donde N_T corresponde al número de participantes, y $\omega(i, j)$ son los ponderadores que determinan que tan parecido es el individuo i a cada uno de los individuos j .

A continuación se detallan los pasos necesarios para la aplicación de esta metodología:

Estimación del Modelo de Participación

Tomando los datos de participantes y no participantes se debe estimar un modelo de probabilidad donde la variable dependiente es T y se deben considerar todas las variables explicativas X que determinen la probabilidad de recibir tratamiento. Una vez estimado el modelo se obtiene el valor predicho para la probabilidad de recibir tratamiento o el propensity score $\hat{P}(X|T = 1) = \hat{P}(X)$, se deben incluir todas las variables que se piensen puedan tener alguna relación con el tratamiento, no es necesario fijarse en los estadísticos t y R^2 ya que no se está buscando un modelo causal, sino una herramienta estadística para buscar similitud entre grupos de personas. Idealmente se debe trabajar con la misma base de datos que contiene participantes y no participantes.

Definición del Soporte Común y Test de Balanceo

Se debe determinar la región donde la densidad del propensity score de los tratados y no tratados se superponen, las observaciones que no están en el soporte común deben ser eliminadas. Adicionalmente se deben realizar test de balanceo, lo que significa chequear para cada cuantil en la distribución del propensity score que el promedio del propensity score y de las variables explicativas son iguales.

Matching entre Participantes y No Participantes

Existen diferentes criterios para hacer el matching entre participantes y no participantes:

1. Vecino más cercano: cada tratado es asignado a una unidad del grupo de control, la que tenga el valor del propensity score más cercano
2. Radio: cuando las diferencias en propensity score entre tratados y no tratados son altas, el matching por vecino más cercano puede ser pobre. Esta metodología para hacer matching acepta hasta cierta distancia en cuanto a propensity score para realizar el matching.
3. Estratificado: se parte la muestra en el soporte común en estratos, y en cada estrato se calcula la diferencia promedio entre el resultado de los tratados y no tratados. Luego, el promedio ponderado de estos estratos corresponde al efecto del tratamiento.

4. Kernel: los riesgos de las metodologías anteriores es que el grupo de no participantes comparable sea muy pequeño. Este estimador utiliza toda la muestra de no participantes en el soporte común ponderados de acuerdo a su distancia en el propensity. En particular el ponderador de este estimador es:

$$\omega(i, j)_K = \frac{K\left(\frac{P_j - P_i}{h}\right)}{\sum_{k \in C} K\left(\frac{P_k - P_i}{h}\right)}$$

Dehejia (1997) plantea la siguiente manera alternativa de obtener el efecto tratamiento promedio y sobre los tratados:

$$\begin{aligned} \hat{ATE} &= \frac{1}{N} \sum_{i=1}^N \left[\frac{(D_i - \hat{p}(x_i))y_i}{\hat{p}(x_i)(1 - \hat{p}(x_i))} \right] \\ \hat{ATT} &= \left(\frac{1}{N} \sum_{i=1}^N D_i \right)^{-1} \sum_{i=1}^N \left[\frac{1}{N} \frac{(D_i - \hat{p}(x_i))y_i}{(1 - \hat{p}(x_i))} \right] \end{aligned}$$

Hirano, Imbens, y Ridder (2003) proponen utilizar el propensity score para estimar el efecto del tratamiento de manera eficiente utilizando el enfoque de regresión lineal. Es decir, se debe estimar la siguiente regresión lineal:

$$Y_i = \alpha + \gamma T_i + X_i \beta + u_i$$

Para obtener el ATT las observaciones de los no participantes deben ser ponderadas por $\hat{p}(x)/(1 - \hat{p}(x))$ y las de los participantes por 1. Para obtener el ATE las observaciones de los no participantes deben ser ponderadas por $1/(1 - \hat{p}(x))$ y las de los participantes por $1/\hat{p}(x)$

Propensity Score Matching en STATA

El comando en STATA para la estimación del propensity score es `pscore`:

```
pscore treatment varlist [weight] [if exp] [in range],
pscore(newvar) [blockid(newvar) detail logit comsup level(#) numblo(#)]
```

Se utilizará una muestra de 185 hombres que recibieron una capacitación durante 1976 y 1977 para evaluar el impacto de capacitación laboral sobre ingresos. El grupo de control se obtiene de una muestra de 2.490 hombres jefes de hogar menores de 55 años y que no se encuentran pensionados, muestra que fue obtenida del PSID. La variable TREAT indica si la persona ha sido tratada o no. El

Cuadro 12.1 presenta el promedio de algunas de las variables claves, mostrando la diferencia entre tratados y grupo de control.

Cuadro 14.1
Variables y Estadísticas

		TRATADOS	CONTROL
AGE	Edad	25.8	34.9
EDUC	Años de escolaridad	10.3	12.1
NODEGREE	1 si educ<12	0.71	0.31
BLACK	1 si es negro	0.84	0.25
HISP	1 si es hispano	0.06	0.03
MARR	1 si es casado	0.19	0.87
U74	1 si estaba desempleado 1n 1974	0.71	0.09
U75	1 si estaba desempleado 1n 1975	0.60	0.10
RE74	Ingreso real en 1974	2096	19429
RE75	Ingreso real en 1975	1532	19063
RE78	Ingreso real en 1978	6349	21554

A continuación se presenta la estimación del propensity score para el problema y datos presentados:

```
pscore TREAT AGE AGESQ EDUC EDUCSQ NODEGREE BLACK HISP MARR RE74 RE75
RE74SQ RE75SQ U74BLACK, pscore(propensity) blockid(estratos)
logit comsup numblo(8)
```

Luego de ejecutar el comando se genera una variable llamada propensity que contiene el propensity score estimado, otra variable estratos que contiene el número de bloques en que se ha dividido la muestra según el propensity score, el número de bloques por default es 5 en este caso hemos solicitado que fueran 8. La opción comsup es para que se genere una variable que indique si se cumple la condición de soporte común que requiere el matching. El output de este comando es el siguiente:

Cuadro 14.2
Estimación Propensity Score

Algorithm to estimate the propensity score

The treatment is TREAT

TREAT	Freq.	Percent	Cum.
0	2,490	93.08	93.08
1	185	6.92	100.00
Total	2,675	100.00	

Logistic regression

Number of obs = 2675

LR chi2(13) = 935.44

Prob > chi2 = 0.0000

Pseudo R2 = 0.6953

Log likelihood = -204.9295

TREAT	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
AGE	.3305734	.1203353	2.75	0.006	.0947206	.5664262
AGESQ	-.0063429	.0018561	-3.42	0.001	-.0099808	-.0027049
EDUC	.8247711	.3534216	2.33	0.020	.1320775	1.517465
EDUCSQ	-.0483153	.0186057	-2.60	0.009	-.0847819	-.0118488
NODEGREE	.1299868	.4284278	0.30	0.762	-.7097163	.96969
BLACK	1.132961	.352088	3.22	0.001	.4428814	1.823041
HISP	1.962762	.5673735	3.46	0.001	.8507302	3.074793
MARR	-1.884062	.2994614	-6.29	0.000	-2.470996	-1.297129
RE74	-.0001047	.0000355	-2.95	0.003	-.0001743	-.0000351
RE75	-.0002172	.0000415	-5.23	0.000	-.0002986	-.0001357
RE74SQ	2.36e-09	6.57e-10	3.59	0.000	1.07e-09	3.65e-09
RE75SQ	1.58e-10	6.68e-10	0.24	0.813	-1.15e-09	1.47e-09
U74BLACK	2.137042	.4273667	5.00	0.000	1.299419	2.974665
_cons	-7.552458	2.451721	-3.08	0.002	-12.35774	-2.747173

Note: 19 failures and 0 successes completely determined.

Note: the common support option has been selected

The region of common support is [.00065257, .97487544]

Description of the estimated propensity score

in region of common support

Estimated propensity score

Percentiles	Smallest		
1%	.0006813	.0006526	
5%	.0008363	.0006581	
10%	.0011416	.0006593	Obs 1331
25%	.0024351	.0006598	Sum of Wgt. 1331
50%	.0111854		Mean .1388772
		Largest	Std. Dev. .275571
75%	.0779976	.9744237	
90%	.6200607	.9747552	Variance .0759394
95%	.9494181	.9747918	Skewness 2.17177
99%	.970738	.9748754	Kurtosis 6.296349

Cuadro 14.3

```

*****
Step 1: Identification of the optimal number of blocks
Use option detail if you want more detailed output
*****

The final number of blocks is 8

This number of blocks ensures that the mean propensity score
is not different for treated and controls in each blocks

*****
Step 2: Test of balancing property of the propensity score
Use option detail if you want more detailed output
*****

The balancing property is satisfied

This table shows the inferior bound, the number of treated
and the number of controls for each block

```

Inferior of block of pscore	TREAT 0	1	Total
.0006526	1,043	11	1,054
.125	43	13	56
.25	22	13	35
.375	12	13	25
.5	7	21	28
.625	11	10	21
.75	1	18	19
.875	7	86	93
Total	1,146	185	1,331

Cuando estamos interesados en el efecto causal de un programa de aplicabilidad universal, la medida apropiada es el ATE, esta medida consiste en un promedio de los efectos causales individuales, donde se requiere comparar cada individuo del grupo de tratamiento con su contrafactual en el grupo de control. En la práctica, lo que se ha realizado es buscar el número óptimo de estratos o grupos donde el propensity score es similar entre grupo de tratamiento y grupo de control, lo que garantiza la similitud entre ambos grupos, luego tomando el promedio de la variable de resultado al interior de cada estrato y para cada grupo, y luego sacando un

promedio ponderado de estas diferencias, se obtiene finalmente el estimador ATE.

En este ejemplo en particular la medida ATE será obtenida tomando el promedio de la variable de resultado, en este caso el ingreso real post capacitación (1978), en cada estrato tanto para el grupo de tratamiento como para el grupo de control, calcular la diferencia de los promedios de ambos grupos y ponderar esta diferencia por la fracción de individuos tratados en el estrato:

$$ATE = \sum_{s=1}^8 \omega_s (\overline{RE78}_{s,T=1} - \overline{RE78}_{s,T=0})$$

La información para construir este estimador se obtiene de las tablas en los Cuadros 12.4 y 12.5.

Cuadro 14.4

Número de Observaciones por Estrato y Grupo

```
. tab estratos TREAT
```

Number of block	TREAT		Total
	0	1	
1	1,043	11	1,054
2	43	13	56
3	22	13	35
4	12	13	25
5	7	21	28
6	11	10	21
7	1	18	19
8	7	86	93
Total	1,146	185	1,331

Cuadro 14.5

Promedio Variable Resultado por Estrato y Grupo

```
. tab estratos TREAT, summarize(RE78) means
```

Means of RE78			
Number of block	TREAT		Total
	0	1	
1	13768.653	9541.4008	13724.536
2	9278.8254	6028.3812	8524.258
3	9008.1485	5720.2962	7786.9462
4	3859.3258	4948.4329	4425.6615
5	6824.7656	5072.4689	5510.5431
6	4173.6352	8235.7418	6107.9717
7	16809.1	6709.9257	7241.4612
8	1563.8577	6312.9782	5955.5175
Total	13198.626	6349.1454	12246.594

El valor estimado del tratamiento es 6009.

Recuerde que el estimador ATE tiene validez cuando se supone una universalidad en el tratamiento, es decir, es razonable considerar una ganancia hipotética de asignar el tratamiento aleatoriamente a miembros de la población.

Por otra parte, cuando el interés se centra en las ganancias en el grupo de tratamiento, el estimador pertinente es ATT:

$$ATT = \frac{1}{N_T} \sum_{i \in T} \left[Y_{1,i} - \sum_{j \in C} \omega(i, j) Y_{0,j} \right]$$

Notar la diferencia importante con el estimador ATE el que al evaluar los efectos sobre el total de la población, utiliza directamente el grupo de control para la obtención del efecto causal, mediante el propensity score lo que hace es considerar la heterogeneidad en el efecto causal y agrupar tratamiento y control en estratos similares según el vector de variables X . Sin embargo, el estimador ATT sólo se concentra en los efectos sobre los tratados, pero como los tratados no pueden a la vez no recibir el tratamiento busca un contrafactual en el grupo de control, es decir, busca su *clon* en el grupo de control. Esto se hace mediante las técnicas de matching. Existen distintos tipos de matching: vecino más cercano, kernel, y usando la metodología de radios.

El Cuadro 12.6 muestra la estimación del ATT mediante Kernel:

```
attk RE78 TREAT , pscore(propensity) logit comsup epan boot reps(100)
```

Cuadro 14.6
ATT con Kernel Matching

ATT estimation with the kernel Matching method Bootstrapped standard errors				
n. treat.	n. contr.	ATT	Std. Err.	t
185	1146	1246.556	906.179	1.376

El coeficiente ATT estimado utilizando la metodología kernel para el matching entrega un impacto sobre el ingreso de participar en programa de capacitación dentro de los tratados de 1.247, pero el valor no resulta ser estadísticamente

significativo, no se puede rechazar la hipótesis nula de que sea igual a cero, el estadístico t calculado es menor al valor de tabla.

El Cuadro 12.7 muestra la estimación del ATT utilizando el vecino más cercano:

```
attnd RE78 TREAT , pscore(propensity) logit comsup boot reps(100)
```

Cuadro 14.7
ATT con vecino más cercano

ATT estimation with Nearest Neighbor Matching method (random draw version) Bootstrapped standard errors				
n. treat.	n. contr.	ATT	Std. Err.	t
185	57	560.287	913.938	0.613
Note: the numbers of treated and controls refer to actual nearest neighbour matches				

El coeficiente ATT estimado utilizando la metodología del vecino más cercano entrega un impacto sobre el ingreso de participar en programa de capacitación de 560, pero el valor no resulta ser estadísticamente significativo, no se puede rechazar la hipótesis nula de que sea igual a cero, el estadístico t calculado es menor al valor de tabla.

14.2.2. Diferencias en Diferencias

El estimador DD hace la comparación entre participantes y no participantes antes y después del programa. Para eliminar el sesgo de selección se asume que este no varía en el tiempo y no correlacionado con la variable de tratamiento en el tiempo. Bajo estos supuestos el impacto del tratamiento se obtiene tomando la diferencia en el promedio de la variable de resultado entre tratados y no tratados, antes y después del programa. Para esto se necesita tener datos de panel.

El estimador de diferencias en diferencias también puede ser obtenido mediante un modelo de regresión lineal:

$$Y_{it} = \alpha + \gamma T_{it} \cdot t + \rho T_{it} + \lambda t + u_{it}$$

Si se disponen más de dos periodos de tiempo, el efecto del tratamiento se puede estimar mediante un modelo de efecto fijo:

$$Y_{it} = \phi T_{it} + \delta X_{it} + \eta_i + u_{it}$$

Se puede mejorar la estimación Diferencia en Diferencias utilizando PSM para controlar de mejor manera por las características de los individuos antes del programa, además con esta metodología se puede obtener el estimador de Diferencias en Diferencias en cortes transversales repetidos. El estimador DD utilizando PSM y cuando se disponen de datos de panel es:

$$DD_{PSM} = \frac{1}{N} \sum_{i=1}^N \left[(Y_{i,2}^T - Y_{i,1}^T) - \sum_{j \in C} \omega(i, j) (Y_{j,2}^C - Y_{j,1}^C) \right]$$

Sin embargo, cuando se disponen de cortes transversales se debe hacer matching sobre *tres grupos de control*: tratados y no tratados en $t=1$, y no tratados en $t=2$, y el estimador de Diferencias en Diferencias será igual a:

$$DD_{PSM} = \frac{1}{N} \sum_{i=1}^N \left[\left\{ Y_{i,2}^T - \sum_{j \in T_1} \omega(i, j) Y_{j,1}^T \right\} - \left\{ \sum_{j \in C_2} \omega(i, j) Y_{j,2}^C - \sum_{j \in C_1} \omega(i, j) Y_{j,1}^C \right\} \right]$$

También se puede utilizar la metodología de Hirano, Imbens, y Ridder (2003) mediante Mínimos Cuadrados Ponderados para obtener una estimación más eficiente del estimador de diferencias en diferencias:

$$Y_{it} = \alpha + \gamma T_{it} \cdot t + \rho T_{it} + \lambda t + X_i \beta + u_{it}$$

donde los tratados son ponderados por 1, y los no tratados ponderados por $\hat{p}(x)/(1 - \hat{p}(x))$.

El estimador de DD se puede obtener mediante una regresión MCO o una estimador de efectos fijos. Por ejemplo, utilizando los datos de la Encuesta de Protección Social 2006-2009 se intenta medir el impacto en horas trabajadas de la población adulta mayor luego de la introducción de la Pensión Básica Solidaria (PBS). El Cuadro 12.8 muestra la estimación por MCO, se estima un impacto de la PBS en las horas trabajadas de los adultos mayores de 6.9 horas semanales.

Cuadro 14.8
Estimador MCO Diferencias en Diferencias

. reg horas treat time timetreat if edad>=50						
Source	SS	df	MS		Number of obs = 5470	
Model	54285.4805	3	18095.1602		F(3, 5466) = 38.31	
Residual	2581804.09	5466	472.338838		Prob > F = 0.0000	
					R-squared = 0.0206	
					Adj R-squared = 0.0201	
Total	2636089.57	5469	482.005772		Root MSE = 21.733	
horas	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
treat	-8.234842	2.228552	-3.70	0.000	-12.60369	-3.865994
time	-4.092886	.6008958	-6.81	0.000	-5.270881	-2.914891
timetreat	-6.893385	3.117369	-2.21	0.027	-13.00467	-.7821006
_cons	38.88131	.441976	87.97	0.000	38.01486	39.74776

14.2.3. Regresión Discontinua

Esta metodología explota las reglas de decisión de participación en el programa exógenas, estas reglas crean un quasi-experimento para un conjunto de observaciones en donde se produce una discontinuidad en la probabilidad de recibir el tratamiento en función de esta regla. Por ejemplo, Angrist y Lavy (1999) estudian el efecto del tamaño de clase sobre el rendimiento de los alumnos, tomando ventaja de los datos generados por la *Maimonides Rule* que indica que los cursos deben ser divididos si la cantidad de alumnos por curso supera cierto umbral. Otro ejemplo es el estudio de Van der Klaauw (2003) que analiza los efectos de la oferta de ayuda financiera en la decisión de ir a la universidad, explotando la regla de elegibilidad de ayuda financiera en función del puntaje en la prueba SAT y las notas del colegio. De esta forma, la metodología de regresión discontinua es bastante similar a la de variables instrumentales en el sentido que se introduce una variable exógena altamente correlacionada con la participación en el programa pero no con los resultados. La Figura 12.3 muestra como la variable que determina la regla de decisión produce una discontinuidad en los valores observados de la variable de resultado, en la vecindad de esta discontinuidad se espera que los individuos sean muy similares en sus observables y no observables eliminando el sesgo de selección al comparar simplemente el promedio de la variable de resultado entre tratados y no tratados.


Entonces, existe una variable S_i que determina la probabilidad de participación en el programa de acuerdo a un valor umbral de esta variable s^* . Asumiendo que existe el límite a ambos lados del umbral s^* , el impacto estimado para un valor

arbitrario y pequeño de $\varepsilon > 0$ entorno al umbral es:

$$E[Y_i|s^* - \varepsilon] - E[Y_i|s^* + \varepsilon]$$

donde $Y_i = \beta S_i + \epsilon_i$.

Figura 14.3
Regresión Discontinua



Tomando límite a la ecuación anterior cuando $\varepsilon \rightarrow 0$ se puede identificar β de la siguiente manera:


$$\beta = \frac{Y^- - Y^+}{S^- - S^+}$$

Lo anterior asume que la regla de decisión es **Sharp**, es decir, depende directamente de la variable S . Sin embargo, puede ser que esta variable S determine la probabilidad de participar, en tal caso la regla es **Fuzzy**. La Figura 12.4 muestra gráficamente la diferencia entre estos dos enfoques.

Para estimar el efecto tratamiento se deben estimar modelos no paramétricos de la variable de resultado bajo el umbral y sobre el umbral, luego tomando la diferencia en los valores predichos según el modelo de la esperanza condicional de la variable de resultado, en la vecindad del umbral, se obtiene el efecto del tratamiento:

$$y^- - y^* = \lim_{S_i \uparrow s^*} E[Y_i|S_i = s^*] - \lim_{S_i \downarrow s^*} E[Y_i|S_i = s^*]$$

Figura 14.4
Sharp versus Fuzzy



La estimación Fuzzy requiere hacer una regresión no paramétrica tanto para la variable de resultado como para la variable que indica la participación en el programa.

A continuación utilizaremos los datos de la Encuesta a Hogares de Bangladesh 1998/99 para mostrar un ejemplo de como estimar una regresión discontinua Sharp y Fuzzy para analizar como el nivel de los gastos de los hogares se ve afectado por un programa de microcréditos. La variable `exptot` corresponde al gasto total per-cápita del hogar, `hhland` corresponde al valor de las tierras que tiene el hogar, y es utilizado como regla para poder acceder al programa de microcréditos, los hogares son elegibles para el programa si `hhland < 50`. Primero vamos a crear las variables de interés:

```
use hh_98.dta
gen lexptot=ln(1+exptot)
gen lnland=ln(1+hhland/100)
```

El siguiente programa nos permite estimar el efecto de participar en el programa de microcréditos sobre el gasto del hogar basado en la metodología de regresión discontinua Sharp:

```
capture prog drop rd_sharp
prog rd_sharp, rclass
```

```

version 8.2
args outcome
confirm var `outcome'
tempname outrd1 outrd0 outcome1 outcome0
locpoly `outcome' lnland if hhland<50, gen(`outrd1')
    at(lnland) nogr tri w(3) d(1)
locpoly `outcome' lnland if hhland>=50, gen(`outrd0')
    at(lnland) nogr tri w(3) d(1)
sum `outrd1' if hhland>=45 & hhland<50, meanonly
scalar `outcome1'=r(mean)
sum `outrd0' if hhland>=50 & hhland<55, meanonly
scalar `outcome0'=r(mean)
return scalar diff_outcome=`outcome1'-'outcome0'
end

```

Con esta serie de comandos hemos creado un comando en STATA llamado `rd_sharp` el cuál hará la regresión no paramétrica mediante polinomios (`locpoly`), podríamos utilizar otras opciones antes vistas, entre la variable de resultado que definamos (`outcome`) y el logaritmo del valor de la tierra del hogar, bajo el umbral y sobre el umbral. Luego se toma el valor predicho del `outcome` en una vecindad de este umbral.

Luego aplicamos el comando para obtener el efecto tratamiento estimado, y su intervalo de confianza:

```

set seed 12345
bootstrap ``rd_sharp lexptot'' impact_sharp=r(diff_outcome),
    reps(100) nowarn
gen t_impact_sharp=_b[impact_sharp]/_se[impact_sharp]
sum t_impact_sharp

```

El Cuadro 14.9 muestra los resultados de la estimación del impacto sobre el gasto del hogar de participar en el programa de microcréditos, se encuentra que el participar en el programa reduce el gasto promedio en un 12.6 %, sin embargo, este impacto no resulta ser estadísticamente significativo.

Cuadro 14.9
Resultado Estimación RD Sharp

```
. bootstrap "rd_sharp lexptot" impact_sharp=r(diff_outcome), reps(100) nowarn
```

```
command:      rd_sharp lexptot
statistic:    impact_s~p = r(diff_outcome)
```

Bootstrap statistics		Number of obs	=	243
		Replications	=	100

Variable	Reps	Observed	Bias	Std. Err.	[95% Conf. Interval]		
impact_sharp	92	-.1264224	.0023491	.1116639	-.3482292	.0953843	(N)
					-.3132059	.0937947	(P)
					-.3132059	.125849	(BC)

Note: N = normal
P = percentile
BC = bias-corrected

```
. gen t_impact_sharp=_b[impact_sharp]/_se[impact_sharp]
. sum t_impact_sharp
```

Variable	Obs	Mean	Std. Dev.	Min	Max
t_impact_s~p	243	-1.132169	0	-1.132169	-1.132169

En este caso particular, la regla de decisión en el umbral de 50 no es tan clara, por lo cuál es mejor utilizar la metodología Fuzzy siguiendo el siguiente procedimiento:

```
capture prog drop rd_fuzzy
prog rd_fuzzy, rclass
version 8.2
args treatment outcome
confirm var `treatment'
confirm var `outcome'
tempname treatrd1 treatrd0 outrd1 outrd0 treat1 treat0 outcome1 outcome0
locpoly `treatment' lnland if hhland<50, gen(`treatrd1')
  at(lnland) nogr tri w(3) d(1)
locpoly `treatment' lnland if hhland>=50, gen(`treatrd0')
  at(lnland) nogr tri w(3) d(1)
locpoly `outcome' lnland if hhland<50, gen(`outrd1')
  at(lnland) nogr tri w(3) d(1)
locpoly `outcome' lnland if hhland>=50, gen(`outrd0')
  at(lnland) nogr tri w(3) d(1)
sum `treatrd1' if hhland>=45 & hhland<=55, meanonly
scalar `treat1'=r(mean)
sum `treatrd0' if hhland>=45 & hhland<=55, meanonly
```

```

scalar 'treat0'=r(mean)
sum 'outrd1' if hhland>=45 & hhland<=55, meanonly
scalar 'outcome1'=r(mean)
sum 'outrd0' if hhland>=45 & hhland<=55, meanonly
scalar 'outcome0'=r(mean)

return scalar impact=('outcome1'-'outcome0')/('treat1'-'treat0')
end

```

Es bastante similar al procedimiento que definimos para la estimación Sharp, pero en este caso también debemos estimar los modelos no paramétricos sobre la variable de tratamiento. A continuación se obtiene la estimación Fuzzy, mostrando los resultados en los Cuadros 12.10 y 12.11

```

***Male participation
set seed 12345
bootstrap 'rd_fuzzy dmmfd lexptot' impact_fuzzy_m=r(impact), reps(100) nowarn
gen t_impact_fuzzy_m=_b[impact_fuzzy_m]/_se[impact_fuzzy_m]
sum t_impact_fuzzy_m

```

Cuadro 14.10
Resultado Estimación RD Fuzzy (Hombres)

```
. ***Male participation
. set seed 12345

. bootstrap "rd_fuzzy dmmfd lexptot" impact_fuzzy_m=r(impact), reps(100) nowarn

command:      rd_fuzzy dmmfd lexptot
statistic:    impact_f~m = r(impact)

Bootstrap statistics                                Number of obs    =      243
                                                    Replications    =      100
```

Variable	Reps	Observed	Bias	Std. Err.	[95% Conf. Interval]		
impact_fuz~m	100	-.1234946	.0101017	.1192884	-.3601886	.1131994	(N)
					-.3220172	.1357002	(P)
					-.3220172	.1357002	(BC)

```
Note:  N   = normal
       P   = percentile
       BC  = bias-corrected

. gen t_impact_fuzzy_m=_b[impact_fuzzy_m]/_se[impact_fuzzy_m]

. sum t_impact_fuzzy_m
```

Variable	Obs	Mean	Std. Dev.	Min	Max
t_impact_f~m	243	-1.035261	0	-1.035261	-1.035261

```

***Female participation
set seed 123
bootstrap "rd_fuzzy dfmfd lexptot" impact_fuzzy_f=r(impact), reps(100) nowarn
gen t_impact_fuzzy_f=_b[impact_fuzzy_f]/_se[impact_fuzzy_f]
sum t_impact_fuzzy_f

```

Cuadro 14.11
Resultado Estimación RD Fuzzy (Mujeres)

```

. ***Female participation
. set seed 123
. bootstrap "rd_fuzzy dfmfd lexptot" impact_fuzzy_f=r(impact), reps(100) nowarn
command:      rd_fuzzy dfmfd lexptot
statistic:    impact_f~f = r(impact)

Bootstrap statistics                                Number of obs   =      243
                                                    Replications   =      100

```

Variable	Reps	Observed	Bias	Std. Err.	[95% Conf. Interval]		
impact_fuz~f	100	-.1234946	.004899	.1211266	-.3638361	.116847	(N)
					-.3258091	.10984	(P)
					-.3879352	.0611647	(BC)

Note: N = normal
P = percentile
BC = bias-corrected

```

. gen t_impact_fuzzy_f=_b[impact_fuzzy_f]/_se[impact_fuzzy_f]
. sum t_impact_fuzzy_f

```

Variable	Obs	Mean	Std. Dev.	Min	Max
t_impact_f~f	243	-1.019549	0	-1.019549	-1.019549

Capítulo 15

Modelos de Duración

15.1. Introducción

Cuando una persona esta desempleada, o cuando los trabajadores de una empresa están en huelga, podríamos esperar que mientras más tiempo se ha permanecido en ese “estado” mayor es la probabilidad de que la persona encuentre un trabajo o de que la huelga termine en las próximas semanas. Pero también podríamos pensar que mientras más tiempo ha durado este estado las características que provocaron este estado son más fuertes y por lo tanto es poco probable salir de este estado. En este tipo de problemas no sólo interesa el tiempo transcurrido en cierto estado, sino además interesa la probabilidad de transición a otro estado.

En la clase de hoy se estudiarán los **Modelos de duración**, en estos modelos la variable de interés es el tiempo transcurrido desde el inicio de cierto evento hasta el término de este o hasta que donde se tiene acceso a la información (fecha de medición). En los modelos de duración la censura en los datos es un problema inherente a la forma de obtener los datos, la estimación de estos modelos debe considerar el problema de censura presente en los datos.

Para efectos del análisis de los modelos de duración, se definirá **estado** como la clasificación de un individuo o unidad en un momento del tiempo, **transición** es el movimiento de un estado a otro, y **duración (spell)** corresponde al tiempo transcurrido en cierto estado.

15.2. Modelos de Duración

La variable de interés en los modelos de duración corresponde al tiempo transcurrido entre el inicio de cierto estado hasta que termina o hasta cuando la medición fue realizada. Los datos que debemos poseer para hacer un análisis de duración consiste en tiempos de duración de un estado: $t_1, t_2, \dots, t_N$.