



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2
Profesor: PATRICIO DOMÍNGUEZ
Ayudante: GONZALO AGUILAR (GONZALO.AGUILAR@UC.CL)

Ayudantía 1

Repaso probabilidades e Introducción MCO

8 de agosto de 2025

Repaso Probabilidad y Estadística

- **Valor Esperado** $\mathbb{E}(X)$: Esperanza, valor esperado o media poblacional es la suma ponderada de los valores posibles que una variable puede tomar, ponderada por la probabilidad de ocurrencia de cada evento posible. Sea X una variable aleatoria con soporte θ_X ,

Si X es discreta, luego:

$$\mathbb{E}(X) = \sum_{x \in \theta_X} x \mathbb{P}(X = x)$$

Si X es continua, luego:

$$\mathbb{E}(X) = \int_{\theta_X} x f(x) dx$$

donde $f(x)$ es la función de densidad de la distribución asociada a la variable aleatoria X .

Sea Y una variable aleatoria con soporte θ_Y . Podemos definir la media condicional:

$$\mathbb{E}(Y | X = x) = \sum_{y \in \theta_Y} y \mathbb{P}(Y = y | X = x) \quad (\text{Si } Y \text{ es discreta})$$

$$\mathbb{E}(Y | X = x) = \int_{\theta_Y} y f(y | X = x) dy \quad (\text{Si } Y \text{ es continua})$$

A partir de ello, se puede definir la ley de esperanzas iteradas:

$$\mathbb{E}(Y) = \mathbb{E}(\mathbb{E}(Y | X))$$

Y si la anterior se extiende a más variables:

$$\mathbb{E}(Y | X_1) = \mathbb{E}(\mathbb{E}(Y | X_1, X_2) | X_2)$$

Además, el operador esperanza es lineal. Sea $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$,

1. $\mathbb{E}(\alpha_1 X) = \alpha_1 \mathbb{E}(X)$
 2. $\mathbb{E}(\alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_n X_n) = \alpha_1 \mathbb{E}(X_1) + \alpha_2 \mathbb{E}(X_2) + \dots + \alpha_n \mathbb{E}(X_n)$
- **Varianza y Covarianza:** La varianza es el segundo momento central de la función de densidad/probabilidad de una variable aleatoria X . Sea μ la media poblacional y σ^2 la varianza poblacional,

$$\text{Var}(X) = \sigma^2 = \mathbb{E}((X - \mu)^2) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

La varianza de la suma de dos variables aleatorias X e Y corresponde a:

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$$

Donde $\text{Cov}(X, Y)$ corresponde a la covarianza entre X e Y y a, b son constantes reales.

Ahora, la covarianza se define como:

$$\text{Cov}(X, Y) = \sigma_{X,Y} = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

La covarianza y varianza tienen algunas propiedades interesantes:

1. $\text{Var}(\alpha_1 X) = \alpha_1^2 \text{Var}(X)$
 2. $\text{Cov}(X, Y) = 0$, si, y sólo si, X e Y son independientes y ambas variables aleatorias son Gaussianas.
 3. $\text{Var}(\alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_n X_n) = \alpha_1^2 \text{Var}(X_1) + \alpha_2^2 \text{Var}(X_2) + \dots + \alpha_n^2 \text{Var}(X_n)$ si $X_1, \dots, X_n$ son variables aleatorias independientes entre sí.
- **Correlación:** Corresponde simplemente a una estandarización de la covarianza.

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\sigma_{X,Y}}{\sigma_X \sigma_Y}$$

- **Propiedades de Distribuciones:**

Sean $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, y sean $\alpha_i, \beta \in \mathbb{R}, \forall i \in \{1, \dots, n\}$

1. $\sum_{i=1}^n \alpha_i X_i \sim \mathcal{N}\left(\sum_{i=1}^n \alpha_i \mu_i, \sum_{i=1}^n \alpha_i^2 \sigma_i^2\right)$

-
2. $X \sim \mathcal{N}(\mu, \sigma^2) \rightarrow Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$
 3. $Z \sim \mathcal{N}(0, 1) \rightarrow \alpha + \beta Z \sim \mathcal{N}(\alpha, \beta^2)$

Introducción MCO

- **Modelo de regresión lineal:** El modelo de regresión lineal se usa para estudiar la relación de dependencia entre una variable dependiente (Y) y una o más variables independientes o covariables. Existen distintas formas de representar el modelo, entre las cuales están:

- Observaciones: $y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{ik}\beta_k + \epsilon_i$
- Vectores columna ($n \times 1$): $y = x_1\beta_1 + x_2\beta_2 + \dots + x_k\beta_k + \epsilon$
- Matrices: $y = X\beta + \epsilon$, con y de $(n \times 1)$, X de $(n \times k)$, β de $(k \times 1)$ y ϵ de $(n \times 1)$.

El término ϵ es el "vector de errores" de la regresión, y β son los parámetros que se buscan estimar (lo que no se conoce).

- **Modelo de regresión simple:** Un modelo de regresión lineal se dice simple si posee únicamente un intercepto y un coeficiente (parámetro del modelo), siendo éstos β_0 y β_1 respectivamente en la siguiente ecuación de regresión:

$$y = \beta_0 + \beta_1 x_1 + \epsilon$$

Notar que en este caso, x , ϵ e y son vectores de dimensión $(n \times 1)$.

- **Mínimos cuadrados ordinarios (MCO):**

Una de las formas de estimar β es por medio del método de mínimos cuadrados ordinarios, el cual consiste en minimizar el error $\mathbb{E}(y - X\beta)^2$ (la notación en este caso es matricial). Al estimador del parámetro β se le denota por $\hat{\beta}$.

- Si se tiene una regresión simple, por MCO se llega a

$$\hat{\beta}_1 = \frac{\text{Cov}(x_i, y_i)}{\text{Var}(x_i)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- Si se habla de la forma matricial, se encuentra la solución

$$\hat{\beta} = (X'X)^{-1}X'y$$

Pregunta 1: Probabilidad y Estadística, el regreso

- a) Demuestre que

$$\text{Cov}(X, Y)^2 \leq \text{Var}(X)\text{Var}(Y)$$

Además, utilizando este resultado, demuestre que el coeficiente de correlación entre X y Y satisface $\rho_{X,Y} \leq 1$.

- b) Sea $\mathbf{x} \in \mathbb{R}^3$ un vector de variables aleatorias, donde cada componente x_i tiene una varianza σ_i^2 para $i = 1, 2, 3$. Además, se conoce la matriz de correlación entre las componentes de $\mathbf{x}$:

$$\rho = \begin{bmatrix} 1 & \rho_{12} & \rho_{13} \\ \rho_{21} & 1 & \rho_{23} \\ \rho_{31} & \rho_{32} & 1 \end{bmatrix}$$

Calcule la matriz de covarianza Σ correspondiente al vector $\mathbf{x}$.

- c) **PROPUESTO:** Sean $y_1, y_2, \dots, y_n$ variables aleatorias independientes con distribución $\mathcal{N}_n(\mu, I_n\sigma^2)$ donde I_n es la matriz identidad en $\mathbb{R}^n$. Defina

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

¿Son las variables aleatorias independientes entre sí? Verifique si S^2 es insesgado.

$$\text{Hint: } \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \mu)^2 - n(\bar{y} - \mu)^2$$

Pregunta 2: CASEN

se cuenta con una submuestra aleatoria equivalente al 10 % de la Encuesta CASEN 2022. En esta pregunta, el análisis se enfocará exclusivamente en trabajadores (`o1==1`) de entre 25 y 65 años con ingreso per cápita positivo (`ypc >0`), considerando únicamente las variables `ypc` (ingreso per cápita), `esc` (años de escolaridad) y `sexo` (0 = hombre, 1 = mujer).

- Elabore un *scatterplot* del logaritmo del salario y de los años de escolaridad. ¿Qué patrón se observa?
- Plantee un modelo que permita estimar la relación entre el logaritmo del salario y los años de escolaridad.
- Cree una función que estime los parámetros de una regresión lineal simple.
- Estime los coeficientes del modelo planteado en b). ¿Qué interpretación tienen los coeficientes en su modelo? ¿Y sin el logaritmo?

-
- e) Separe los datos de acuerdo al **sexo** y estime el mismo modelo previamente utilizado. Discuta.
 - f) Agrupe la muestra de hombres por años de escolaridad y calcule, para cada nivel, el logaritmo del salario promedio. Grafique la relación entre años de escolaridad y logaritmo del salario promedio para hombres, e incluya la recta estimada por MCO. Interprete la pendiente de la recta.
 - g) Suponga ahora que desea entender qué tan confiable es el estimador de MCO en muestras pequeñas, y cómo mejora a medida que aumentamos el número de observaciones. Para ello, siga los siguientes pasos:
 - i) Utilice los datos originales para generar 1000 muestras aleatorias de tamaño 100, con reemplazo.
 - ii) Para cada muestra, estime el modelo de regresión lineal simple planteado en b) (sin separar por grupo) y guarde el valor del coeficiente estimado.
 - iii) Grafique la evolución del promedio acumulado del coeficiente estimado a medida que se agregan más simulaciones.
 - iv) Compare este valor promedio con el coeficiente estimado usando toda la base original.

Grafique la distribución del coeficiente de interés. ¿Qué patrón observa en la evolución del estimador? ¿Qué ocurre con su varianza a medida que aumentamos el número de simulaciones? ¿Qué nos dice esto sobre la estabilidad de los estimadores MCO?