

Ayudantía 1

Repaso probabilidades e Introducción MCO

8 de agosto de 2025

Repaso Probabilidad y Estadística

- **Valor Esperado** $\mathbb{E}(X)$: Esperanza, valor esperado o media poblacional es la suma ponderada de los valores posibles que una variable puede tomar, ponderada por la probabilidad de ocurrencia de cada evento posible. Sea X una variable aleatoria con soporte θ_X ,

Si X es discreta, luego:

$$\mathbb{E}(X) = \sum_{x \in \theta_X} x \mathbb{P}(X = x)$$

Si X es continua, luego:

$$\mathbb{E}(X) = \int_{\theta_X} x f(x) dx$$

donde $f(x)$ es la función de densidad de la distribución asociada a la variable aleatoria X .

Sea Y una variable aleatoria con soporte θ_Y . Podemos definir la media condicional:

$$\mathbb{E}(Y | X = x) = \sum_{y \in \theta_Y} y \mathbb{P}(Y = y | X = x) \quad (\text{Si } Y \text{ es discreta})$$

$$\mathbb{E}(Y | X = x) = \int_{\theta_Y} y f(y | X = x) dy \quad (\text{Si } Y \text{ es continua})$$

A partir de ello, se puede definir la ley de esperanzas iteradas:

$$\mathbb{E}(Y) = \mathbb{E}(\mathbb{E}(Y | X))$$

Y si la anterior se extiende a más variables:

$$\mathbb{E}(Y | X_1) = \mathbb{E}(\mathbb{E}(Y | X_1, X_2) | X_2)$$

Además, el operador esperanza es lineal. Sea $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$,

1. $\mathbb{E}(\alpha_1 X) = \alpha_1 \mathbb{E}(X)$

2. $\mathbb{E}(\alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_n X_n) = \alpha_1 \mathbb{E}(X_1) + \alpha_2 \mathbb{E}(X_2) + \dots + \alpha_n \mathbb{E}(X_n)$

- **Varianza y Covarianza:** La varianza es el segundo momento central de la función de densidad/probabilidad de una variable aleatoria X . Sea μ la media poblacional y σ^2 la varianza poblacional,

$$\text{Var}(X) = \sigma^2 = \mathbb{E}((X - \mu)^2) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

La varianza de la suma de dos variables aleatorias X e Y corresponde a:

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$$

Donde $\text{Cov}(X, Y)$ corresponde a la covarianza entre X e Y y a, b son constantes reales.

Ahora, la covarianza se define como:

$$\text{Cov}(X, Y) = \sigma_{X,Y} = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

La covarianza y varianza tienen algunas propiedades interesantes:

1. $\text{Var}(\alpha_1 X) = \alpha_1^2 \text{Var}(X)$
2. $\text{Cov}(X, Y) = 0$, si, y sólo si, X e Y son independientes y ambas variables aleatorias son Gaussianas.
3. $\text{Var}(\alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_n X_n) = \alpha_1^2 \text{Var}(X_1) + \alpha_2^2 \text{Var}(X_2) + \dots + \alpha_n^2 \text{Var}(X_n)$ si $X_1, \dots, X_n$ son variables aleatorias independientes entre sí.

- **Correlación:** Corresponde simplemente a una estandarización de la covarianza.

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\sigma_{X,Y}}{\sigma_X \sigma_Y}$$

- **Propiedades de Distribuciones:**

Sean $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, y sean $\alpha_i, \beta \in \mathbb{R}, \forall i \in \{1, \dots, n\}$

1. $\sum_{i=1}^n \alpha_i X_i \sim \mathcal{N}\left(\sum_{i=1}^n \alpha_i \mu_i, \sum_{i=1}^n \alpha_i^2 \sigma_i^2\right)$

2. $X \sim \mathcal{N}(\mu, \sigma^2) \rightarrow Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$

3. $Z \sim \mathcal{N}(0, 1) \rightarrow \alpha + \beta Z \sim \mathcal{N}(\alpha, \beta^2)$

Introducción MCO

- **Modelo de regresión lineal:** El modelo de regresión lineal se usa para estudiar la relación de dependencia entre una variable dependiente (Y) y una o más variables independientes o covariables. Existen distintas formas de representar el modelo, entre las cuales están:

- Observaciones: $y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{ik}\beta_k + \epsilon_i$
- Vectores columna ($n \times 1$): $y = x_1\beta_1 + x_2\beta_2 + \dots + x_k\beta_k + \epsilon$
- Matrices: $y = X\beta + \epsilon$, con y de $(n \times 1)$, X de $(n \times k)$, β de $(k \times 1)$ y ϵ de $(n \times 1)$.

El término ϵ es el "vector de errores" de la regresión, y β son los parámetros que se buscan estimar (lo que no se conoce).

- **Modelo de regresión simple:** Un modelo de regresión lineal se dice simple si posee únicamente un intercepto y un coeficiente (parámetro del modelo), siendo éstos β_0 y β_1 respectivamente en la siguiente ecuación de regresión:

$$y = \beta_0 + \beta_1 x_1 + \epsilon$$

Notar que en este caso, x , ϵ e y son vectores de dimensión $(n \times 1)$.

- **Mínimos cuadrados ordinarios (MCO):**

Una de las formas de estimar β es por medio del método de mínimos cuadrados ordinarios, el cual consiste en minimizar el error $\mathbb{E}(y - X\beta)^2$ (la notación en este caso es matricial). Al estimador del parámetro β se le denota por $\hat{\beta}$.

- Si se tiene una regresión simple, por MCO se llega a

$$\hat{\beta}_1 = \frac{\text{Cov}(x_i, y_i)}{\text{Var}(x_i)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- Si se habla de la forma matricial, se encuentra la solución

$$\hat{\beta} = (X'X)^{-1}X'y$$

Pregunta 1: Probabilidad y Estadística return

a) Demuestre que

$$\text{Cov}(X, Y)^2 \leq \text{Var}(X)\text{Var}(Y)$$

Además, utilizando este resultado, demuestre que el coeficiente de correlación entre X y Y satisface $\rho_{X,Y} \leq 1$.

Solución: Consideremos un vector $u = (a, b)' \in \mathbb{R}^2$ y la matriz varianza-covarianza de $\gamma = (X, Y)$

$$\text{Var}(\gamma) = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix}.$$

El producto cuadrático asociado es

$$u' \text{Var}(\gamma) u = \begin{pmatrix} a & b \end{pmatrix} \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = a^2 \text{Var}(X) + 2ab \text{Cov}(X, Y) + b^2 \text{Var}(Y).$$

¿Por qué escribimos esto? Porque $u' \text{Var}(\gamma) u$ es exactamente la varianza de la combinación lineal $aX + bY$:

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + 2ab \text{Cov}(X, Y) + b^2 \text{Var}(Y) = u' \text{Var}(\gamma) u.$$

Y por definición de varianza, $\text{Var}(aX + bY) \geq 0$ para todo (a, b) . Es decir, $u' \text{Var}(\gamma) u \geq 0$ para todo u , lo que implica que $\text{Var}(\gamma)$ es *semidefinida positiva*.

Una matriz simétrica 2×2 es semidefinida positiva si y solo si (criterio de Sylvester) todos los determinantes de sus submatrices son no negativos. En nuestro caso:

$$\text{Var}(X) \geq 0, \quad \text{Var}(Y) \geq 0, \quad |\text{Var}(\gamma)| = \text{Var}(X)\text{Var}(Y) - \text{Cov}(X, Y)^2 \geq 0.$$

De la última desigualdad se obtiene, reordenando,

$$\text{Cov}(X, Y)^2 \leq \text{Var}(X)\text{Var}(Y).$$

Ahora bien, el coeficiente de correlación es

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}.$$

Utilizando el resultado anterior, dividiendo por $\text{Var}(X)\text{Var}(Y)$, obtenemos que

$$\rho_{X,Y}^2 = \frac{\text{Cov}(X, Y)^2}{\text{Var}(X)\text{Var}(Y)} \leq 1 \Rightarrow -1 \leq \rho_{X,Y} \leq 1.$$

En particular, $\rho_{X,Y} \leq 1$.

- b) Sea $\mathbf{x} \in \mathbb{R}^3$ un vector de variables aleatorias, donde cada componente x_i tiene una varianza σ_i^2 para $i = 1, 2, 3$. Además, se conoce la matriz de correlación entre las componentes de $\mathbf{x}$:

$$\rho = \begin{bmatrix} 1 & \rho_{12} & \rho_{13} \\ \rho_{21} & 1 & \rho_{23} \\ \rho_{31} & \rho_{32} & 1 \end{bmatrix}$$

Calcule la matriz de covarianza Σ correspondiente al vector $\mathbf{x}$.

Solución: Dado que cada elemento de la matriz de correlación ρ se denota como ρ_{ij} y cada varianza como σ_i^2 , la matriz de covarianza Σ se puede calcular utilizando la relación:

$$\Sigma_{ij} = \sigma_i \sigma_j \rho_{ij}$$

donde ρ_{ij} es el coeficiente de correlación entre las variables x_i y x_j .

Para calcular Σ , se debe tener en cuenta que

1. La varianza de x_i es σ_i^2 , por lo que la covarianza $\Sigma_{ii} = \sigma_i^2$.
2. La covarianza entre x_i y x_j se calcula mediante $\Sigma_{ij} = \sigma_i \sigma_j \rho_{ij}$.

Entonces, la matriz de covarianza Σ es:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_1 \sigma_2 \rho_{12} & \sigma_1 \sigma_3 \rho_{13} \\ \sigma_2 \sigma_1 \rho_{21} & \sigma_2^2 & \sigma_2 \sigma_3 \rho_{23} \\ \sigma_3 \sigma_1 \rho_{31} & \sigma_3 \sigma_2 \rho_{32} & \sigma_3^2 \end{bmatrix}$$

NOTA: También se puede calcular la matriz de covarianza mediante matrices utilizando la siguiente igualdad: $\Sigma = D\rho D$, con D como la matriz diagonal de las varianzas.

- c) **PROPUESTO:** Sean $y_1, y_2, \dots, y_n$ variables aleatorias independientes con distribución $\mathcal{N}_n(\mu, I_n \sigma^2)$ donde I_n es la matriz identidad en $\mathbb{R}^n$. Defina

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

¿Son las variables aleatorias independientes entre sí? Verifique si S^2 es insesgado.

Hint: $\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \mu)^2 - n(\bar{y} - \mu)^2$

Solución: Sustituyendo el *hint* en la definición de S^2 :

$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n (y_i - \mu)^2 - n(\bar{y} - \mu)^2 \right)$$

Para analizar si S^2 es insesgado, calculemos su esperanza:

$$\mathbb{E}[S^2] = \mathbb{E} \left[\frac{1}{n-1} \left(\sum_{i=1}^n (y_i - \mu)^2 - n(\bar{y} - \mu)^2 \right) \right]$$

Dado que la esperanza es un operador lineal:

$$\mathbb{E}[S^2] = \frac{1}{n-1} \left(\mathbb{E} \left[\sum_{i=1}^n (y_i - \mu)^2 \right] - n\mathbb{E}[(\bar{y} - \mu)^2] \right)$$

La varianza de cada y_i es σ^2 , y dado que y_i son independientes, se tiene:

$$\mathbb{E} \left[\sum_{i=1}^n (y_i - \mu)^2 \right] = \sum_{i=1}^n \mathbb{E}[(y_i - \mu)^2] = n\sigma^2$$

Además, sabemos que $\bar{y}$ es el promedio de n variables normales independientes y, por tanto, $\bar{y} \sim \mathcal{N} \left(\mu, \frac{\sigma^2}{n} \right)$. Entonces:

$$\mathbb{E}[(\bar{y} - \mu)^2] = \text{Var}(\bar{y}) = \frac{\sigma^2}{n}$$

Sustituyendo estos resultados en la expresión de $\mathbb{E}[S^2]$:

$$\mathbb{E}[S^2] = \frac{1}{n-1} \left(n\sigma^2 - n\frac{\sigma^2}{n} \right) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{n\sigma^2 - \sigma^2}{n-1} = \sigma^2$$

Por lo tanto, S^2 es un estimador insesgado de σ^2 .

Pregunta 2: CASEN

Se cuenta con una submuestra aleatoria equivalente al 10 % de la Encuesta CASEN 2022. En esta pregunta, el análisis se enfocará exclusivamente en trabajadores ($o1=1$) de entre 25 y 65 años con ingreso per cápita positivo ($ypc > 0$), considerando únicamente las variables ypc (ingreso per cápita), esc (años de escolaridad) y $sexo$ (0 = hombre, 1 = mujer).

Responda:

- a) Elabore un *scatterplot* del logaritmo del salario y de los años de escolaridad. ¿Qué patrón se observa?

Solución: A continuación se muestra el gráfico pedido:




Figura 1: Scatterplot de la relación del logaritmo del ingreso per cápita con la escolaridad

El gráfico de dispersión entre el logaritmo del ingreso per cápita ($\log(ypc)$) y los años de escolaridad (esc) muestra un patrón claramente creciente, lo que indica que, en promedio, a mayor nivel educativo, mayor es el ingreso per cápita de los trabajadores. La nube de puntos sugiere una relación positiva, aunque no perfectamente lineal, y con cierta dispersión alrededor de la tendencia, lo que refleja que existen otros factores (observables o no) que también influyen en el ingreso.

- b) Plantee un modelo que permita estimar la relación entre el logaritmo del salario y los años de escolaridad.

Un modelo que permite estimar la relación pedida es

$$\log(\text{ypc}_i) = \beta_0 + \beta_1 \text{esc}_i + \varepsilon_i \quad (1)$$

Donde β_0 es el intercepto del modelo, β_1 : cambio promedio en el logaritmo del ingreso per cápita asociado a un año adicional de escolaridad y ε_i : término de error aleatorio.

- c) Cree una función que estime los parámetros de una regresión lineal simple.

Solución Ver Script de R.

- d) Estime los coeficientes del modelo planteado en b). ¿Qué interpretación tienen los coeficientes en su modelo? ¿Y sin el logaritmo?

Solución A partir de la estimación del modelo (1) con logaritmo del ingreso per cápita se obtiene:

$$\log(\text{ypc}_i) = 11,96481 + 0,08294 \text{esc}_i$$

- $\beta_0 = 11,96481$: valor esperado del logaritmo del ingreso per cápita para un trabajador con 0 años de escolaridad.
- $\beta_1 = 0,08294$: un año adicional de escolaridad se asocia, en promedio, con un aumento de aproximadamente 8,29 % en el ingreso per cápita, manteniendo todo lo demás constante.

Por otro lado, al estimar el modelo sin logaritmo:

$$\text{ypc}_i = -200,406,9 + 62,917,19 \text{esc}_i$$

- $\alpha_0 = -200,406,9$: ingreso per cápita esperado para un trabajador con 0 años de escolaridad. El valor negativo carece de sentido económico, reflejando que este parámetro fuera del rango observado no es directamente interpretable.
- $\alpha_1 = 62,917,19$: un año adicional de escolaridad se asocia, en promedio, con un aumento de \$62,917 CLP en el ingreso per cápita, manteniendo todo lo demás constante.

En resumen, el modelo con logaritmo permite interpretar la pendiente como un cambio porcentual en el ingreso, mientras que el modelo sin logaritmo mide cambios absolutos en pesos chilenos.

- e) Separe los datos de acuerdo al sexo y estime el mismo modelo previamente utilizado. Discuta.

Solución: Separando la muestra por sexo, se estiman los siguientes modelos:

$$\log(\text{ypc}_i) = \begin{cases} 11,9767 + 0,08278 \text{esc}_i, & \text{Hombres} \\ 11,9401 + 0,08387 \text{esc}_i, & \text{Mujeres} \end{cases}$$

- Para los hombres, un año adicional de escolaridad se asocia con un aumento promedio de 8,28 % en el ingreso per cápita.
- Para las mujeres, el efecto estimado es de 8,39 % por año adicional de escolaridad.

La brecha en intercepto ($\alpha_{\text{gap}} = -0,0366$) sugiere que, a igual escolaridad, el logaritmo del ingreso per cápita de las mujeres es, en promedio, ligeramente menor que el de los hombres.

La brecha en pendiente ($\beta_{\text{gap}} = 0,00109$) indica que el retorno estimado a la escolaridad es levemente mayor para las mujeres que para los hombres.

- f) Agrupe la muestra de hombres por años de escolaridad y calcule, para cada nivel, el logaritmo del salario promedio. Grafique la relación entre años de escolaridad y logaritmo del salario promedio para hombres, e incluya la recta estimada por MCO. Interprete la pendiente de la recta.

Solución: A continuación se tiene el gráfico pedido:




Figura 2: Scatterplot de la relación del logaritmo del ingreso per cápita promedio con la escolaridad

Según el gráfico, al agrupar la muestra de hombres por años de escolaridad y calcular

para cada nivel el logaritmo del salario promedio, se observa una clara relación creciente: a mayor escolaridad, mayor es el logaritmo del ingreso promedio.

La recta estimada por MCO, superpuesta a los puntos promedio, presenta una pendiente aproximada de 0.08278, lo que significa que cada año adicional de escolaridad se asocia con un incremento promedio cercano al 8,28 % en el salario.

Es importante destacar que este promedio se calcula sobre datos agrupados por años de escolaridad, lo que implica menos observaciones que en las estimaciones de las preguntas anteriores, donde se utilizaban todos los datos individuales. Esto hace que la pendiente siga reflejando la relación general, pero la precisión de la estimación puede ser menor debido al menor número de puntos en el ajuste.

- g) Suponga ahora que desea entender qué tan confiable es el estimador de MCO en muestras pequeñas, y cómo mejora a medida que aumentamos el número de observaciones. Para ello, siga los siguientes pasos:
- I) Utilice los datos originales para generar 1000 muestras aleatorias de tamaño 100, con reemplazo.
 - II) Para cada muestra, estime un modelo de regresión lineal simple (sin separar por grupo) y guarde el valor del coeficiente estimado.
 - III) Grafique la evolución del promedio acumulado del coeficiente estimado a medida que se agregan más simulaciones.
 - IV) Compare este valor promedio con el coeficiente estimado usando toda la base original.

Grafique la distribución del coeficiente de interés. ¿Qué patrón observa en la evolución del estimador? ¿Qué ocurre con su varianza a medida que aumentamos el número de simulaciones? ¿Qué nos dice esto sobre la estabilidad de los estimadores MCO?

Solución: En primer lugar, se tiene la evolución del promedio acumulado:




Figura 3: Evolución del promedio acumulado de los β_1 estimados en el bootstrap.

- Al inicio, con pocas simulaciones, el promedio acumulado del coeficiente estimado (β_1) presenta alta variabilidad.
- A medida que se incrementa el número de simulaciones, el promedio acumulado converge rápidamente y se estabiliza cerca del valor estimado del valor original de $\hat{\beta}_1$, mostrando que el estimador de MCO es consistente.
- La línea azul (media bootstrap) y la línea roja (valor original de $\hat{\beta}_1$) prácticamente coinciden, lo que indica ausencia de sesgo relevante en el estimador.

Por otro lado, la distribución del coeficiente estimado:




Figura 4: Distribución del coeficiente estimado.

- La distribución es aproximadamente simétrica y centrada en torno al valor del valor original de $\hat{\beta}_1$.
- La dispersión de los valores estimados (varianza) es consecuencia del tamaño de muestra reducido ($n = 100$) en cada remuestreo.
- A medida que aumentamos el número de simulaciones, la varianza de la media bootstrap disminuye, lo que refleja mayor estabilidad en la estimación del promedio.

En conclusión, esto confirma que, aunque en muestras pequeñas la estimación de β_1 presenta mayor variabilidad, el uso de muchas simulaciones (bootstrap) permite aproximar bien el valor verdadero y estabilizar la estimación. Esto respalda la estabilidad y consistencia del estimador MCO en la medida que crece el número de observaciones o simulaciones.