



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2
Profesor: PATRICIO DOMÍNGUEZ
Ayudante: CATALINA ALEGRÍA (CALEGRIAK@UC.CL)

Ayudantía 2

MCO Simple y Multivariado

18 de agosto de 2025

Introducción MCO

- **Modelo de regresión Lineal:** El modelo de regresión lineal se usa para estudiar la relación de dependencia entre una variable dependiente (Y) y una o más variables independientes o covariables. Existen distintas formas de representar el modelo, entre las cuales están:

- Observaciones: $y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{ik}\beta_k + \epsilon_i$
- Vectores columna ($n \times 1$): $y = x_1\beta_1 + x_2\beta_2 + \dots + x_k\beta_k + \epsilon$
- Matrices: $y = X\beta + \epsilon$, con y de $(n \times 1)$, X de $(n \times k)$, β de $(k \times 1)$ y ϵ de $(n \times 1)$.

El término ϵ es el "vector de errores" de la regresión, y β son los parámetros que se buscan estimar (lo que no se conoce).

- **Modelo de regresión simple:** Un modelo de regresión lineal se dice simple si posee únicamente un intercepto y un coeficiente (parámetro del modelo), siendo éstos β_0 y β_1 respectivamente en la siguiente ecuación de regresión:

$$y = \beta_0 + \beta_1 x_1 + \epsilon$$

Notar que en este caso, x , ϵ e y son vectores de dimensión $(n \times 1)$.

- **Mínimos cuadrados ordinarios (MCO):**

Una de las formas de estimar β es por medio del método de mínimos cuadrados ordinarios, el cual consiste en minimizar el error $\mathbb{E}(y - X\beta)^2$ (la notación en este caso es matricial). Al estimador del parámetro β se le denota por $\hat{\beta}$.

- Si se tiene una regresión simple, por MCO se llega a

$$\hat{\beta}_1 = \frac{\text{Cov}(x_i, y_i)}{\text{Var}(x_i)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- Si se habla de la forma matricial, se encuentra la solución

$$\hat{\beta} = (X'X)^{-1}X'y$$

Supuestos del modelo lineal

Para que el modelo lineal quede definido correctamente como un modelo estadístico, deben realizarse supuestos (principalmente sobre vectores aleatorios). A continuación se presentan los supuestos que tiene el modelo de regresión lineal:

1. **Linealidad:** La variable de interés corresponde a una combinación lineal de los parámetros β_j , con pesos x_j , $j \in \{1, \dots, p\}$. En palabras sencillas, esto quiere decir que la regresión es lineal únicamente en los parámetros β_j , es decir, para cada parámetro j el exponente asociado al parámetro no puede ser distinto de 1¹.
2. **Rango completo:** La matriz de diseño X tiene rango columna completo, es decir, $\text{ran}(X) = p$, $n \geq p$.
3. **Exogeneidad estricta:** La matriz X no aporta información a la esperanza de los errores, es decir, para todo $i \in \{1, \dots, n\}$, se tiene $\mathbb{E}[\epsilon_i | X] = 0$. De este punto se desprende también que la esperanza de los errores es 0, es decir, $\mathbb{E}[\epsilon_i] = 0$. Esta última conclusión es quizás más importante al momento de sacar conclusiones respecto al vector de errores, pues sabemos que, en promedio, la variable de interés puede ser explicada completamente por la matriz de diseño.
4. **Varianza de errores esférica:** El vector de errores tiene matriz de covarianza diagonal y constante, es decir, $\text{Cov}[\epsilon | X] = \sigma^2 I_n$, donde I_n corresponde a la matriz identidad de dimensión $(n \times n)$. Debemos notar que como la matriz de covarianza es diagonal, luego para todo $i \neq j \in \{1, \dots, n\}$ se tiene $\text{Cov}[\epsilon_i, \epsilon_j] = 0$. Lo anterior implica a su vez, por definición de la covarianza, que los errores son todos independientes entre sí.
5. **Normalidad en los errores:** Este supuesto muchas veces puede no ser utilizado (principalmente en regresiones no normales), pero para el curso es fundamental definirlo, dado que sin él no se tendría la linealidad de la regresión ni tampoco todas las conclusiones importantes que se pueden obtener debido al amplio estudio de la distribución normal. Todo se puede resumir en lo siguiente: **Suponemos que los errores distribuyen normal n -variados**. Por supuestos anteriores conocemos la media y varianza de los errores, luego tenemos:

$$\epsilon \sim \mathcal{N}_n(0, \sigma^2 I_n)$$

¹Como dato curioso, la linealidad en los parámetros es una consecuencia del supuesto de normalidad en los errores, y en muchos textos no es considerada un supuesto (dado que puede ser derivado por otros medios). En el caso de este curso, la linealidad corresponde a un supuesto.

Por propiedades de la distribución normal multivariada, tenemos que cada error por sí solo distribuye normal, con media 0 y varianza σ^2 , es decir, $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ para $i \in \{1, \dots, n\}$.

Pregunta 1: Wooldrige 2.3 Modificado

En la tabla siguiente se presentan las puntuaciones obtenidas en el examen de ingreso a la universidad en Estados Unidos, ACT (American College Test), y en el GPA (promedio) por ocho estudiantes universitarios. El GPA está medido en una escala de cuatro puntos y se ha redondeado a un dígito después del punto decimal.

Estudiante	GPA	ACT
1	2.8	21
2	3.4	24
3	3.0	26
4	3.5	27
5	3.6	29
6	3.0	25
7	2.7	25
8	3.7	30

Cuadro 1: Datos de GPA y ACT por estudiante.

- a) Estime la relación entre GPA y ACT empleando las definiciones de varianza y covarianza; es decir, obtenga las estimaciones para la pendiente y para el intercepto de la regresión. Comente la dirección de la relación ¿tiene, en este caso, el intercepto una interpretación útil? Explique, ¿qué tanto más alto será el GPA predicho si ACT aumenta cinco puntos?
- b) Estime los coeficientes utilizando álgebra matricial
- c) Calcule los valores ajustados y los residuales para cada observación y verifique que los residuales (aproximadamente) sumen cero.

Por otro lado, se incorpora una nueva variable a la tabla que indica el nivel de excelencia académica de la ciudad en la que se encontraba la escuela a la que asistió cada estudiante universitario. Esta medición se realiza en una escala de 1 a 5 puntos, donde un valor de 1 corresponde a una ciudad con muy baja excelencia académica y un valor de 5 corresponde a una ciudad con alta excelencia académica.

Estudiante	GPA	ACT	Nivel EA
1	2.8	21	1
2	3.4	24	1
3	3.0	26	3
4	3.5	27	2
5	3.6	29	5
6	3.0	25	4
7	2.7	25	3
8	3.7	30	5

Cuadro 2: Datos de GPA, ACT y nivel de excelencia académica por estudiante.

-
- d) Estime los coeficientes de forma matricial e interprete los coeficientes. ¿Tiene sentido la dirección de los signos?

Pregunta 2: Propiedades Estimación MCO

Consideremos la siguiente regresión lineal y su escalamiento por una constante k :

$$y_i = \alpha + \beta x_i + \epsilon_i$$
$$z_i = ky_i = \alpha_k + \beta_k x_i + \epsilon_{ki}$$

Además, consideremos la estimación de z_i ocupando mínimos cuadrados:

$$\hat{z}_i = \hat{\alpha}_k + \hat{\beta}_k x_i$$

- a) Muestre que $E[z - \hat{z}] = 0$ y $E[(z - \hat{z})x] = 0$.

Ahora veremos cómo cambia la estimación de MCO si forzamos a que el intercepto pase por un punto en particular. Arbitrariamente, impongamos que $\alpha = 10$:

$$y_i = 10 + \beta x_i + \epsilon_i$$

- b) Obtenga una expresión para $\hat{\beta}$.
- c) Demuestre que la suma de residuos no es igual a 0.
- d) Demuestre que la recta no cruza los puntos promedios.

Pregunta 3: ¿Cómo el índice de vulnerabilidad de los colegios afecta en los puntajes Simce?

En Chile, la Subvención Escolar Preferencial (SEP) entrega recursos adicionales del Estado a establecimientos educacionales subvencionados con el objetivo de mejorar la calidad y equidad de la educación, especialmente para estudiantes prioritarios. A partir de esta condición, es posible calcular el índice de vulnerabilidad de un colegio, definido como el porcentaje que resulta de dividir el número total de estudiantes beneficiados con la SEP entre el total de estudiantes matriculados en el establecimiento en un año determinado. Este indicador permite aproximarse a la composición socioeconómica del alumnado y su potencial relación con el rendimiento académico.

El Sistema de Medición de la Calidad de la Educación (SIMCE) es una evaluación estandarizada aplicada a nivel nacional que mide el desempeño de los estudiantes en diversas áreas, como

Lenguaje, Matemática, Ciencias e Historia, proporcionando información clave para diagnosticar y mejorar la calidad de la educación.

En este estudio, se busca analizar los puntajes SIMCE de Matemática correspondientes al año 2019 para los cursos de octavo básico, con el fin de explorar posibles relaciones entre estos resultados y el índice de vulnerabilidad de los establecimientos. En la base de datos [Simce 2019 8°básico](#) se encontrará información de los resultados de las pruebas por colegio, específicamente se encuentra "simce8b2019rbd.dta". Para encontrar la cantidad de matriculas de cada colegio está en la base de datos [Resumen de matricula EE 2019](#). Finalmente, para hallar quienes reciben los beneficios del SEP por colegio está en la base de datos [Resumen Prioritarios y Beneficiarios SEP 2019](#).

- a) Realice un histograma que relaciona a los establecimientos que rindieron el SIMCE de 8° básico el año 2019 según la proporción de estudiantes prioritarios. Además, estandarice los puntajes de matemática.
- b) Plantee una regresión que permita calcular el efecto del índice de vulnerabilidad en los resultados de los puntajes de matemática. Estime el coeficiente de interés e interprete. Muestre sus resultados también en un scatterplot.
- c) Seleccione una muestra aleatoria de 10 establecimientos y estime los nuevos valores de beta, haga 10000 simulaciones. Posteriormente, haga lo mismo, pero con una muestra aleatoria de 100 establecimientos. Finalmente compare y analice los resultados.