



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2
Profesor: PATRICIO DOMÍNGUEZ
Ayudante: CATALINA ALEGRÍA (CALEGRIAK@UC.CL)

Ayudantía 3

Propiedades de MCO y FWL

29 de agosto de 2025

Introducción MCO

- **Modelo de regresión Lineal:** El modelo de regresión lineal se usa para estudiar la relación de dependencia entre una variable dependiente (Y) y una o más variables independientes o covariables. Existen distintas formas de representar el modelo, entre las cuales están:

- Observaciones: $y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{ik}\beta_k + \epsilon_i$
- Vectores columna ($n \times 1$): $y = x_1\beta_1 + x_2\beta_2 + \dots + x_k\beta_k + \epsilon$
- Matrices: $y = X\beta + \epsilon$, con y de $(n \times 1)$, X de $(n \times k)$, β de $(k \times 1)$ y ϵ de $(n \times 1)$.

El término ϵ es el "vector de errores" de la regresión, y β son los parámetros que se buscan estimar (lo que no se conoce).

- **Modelo de regresión simple:** Un modelo de regresión lineal se dice simple si posee únicamente un intercepto y un coeficiente (parámetro del modelo), siendo éstos β_0 y β_1 respectivamente en la siguiente ecuación de regresión:

$$y = \beta_0 + \beta_1 x_1 + \epsilon$$

Notar que en este caso, x , ϵ y y son vectores de dimensión $(n \times 1)$.

- **Mínimos cuadrados ordinarios (MCO):**

Una de las formas de estimar β es por medio del método de mínimos cuadrados ordinarios, el cual consiste en minimizar el error $\mathbb{E}(y - X\beta)^2$ (la notación en este caso es matricial). Al estimador del parámetro β se le denota por $\hat{\beta}$.

- Si se tiene una regresión simple, por MCO se llega a

$$\hat{\beta}_1 = \frac{\text{Cov}(x_i, y_i)}{\text{Var}(x_i)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- Si se habla de la forma matricial, se encuentra la solución

$$\hat{\beta} = (X'X)^{-1}X'y$$

Supuestos del modelo lineal

Para que el modelo lineal quede definido correctamente como un modelo estadístico, deben realizarse supuestos (principalmente sobre vectores aleatorios). A continuación se presentan los supuestos que tiene el modelo de regresión lineal:

1. **Linealidad:** La variable de interés corresponde a una combinación lineal de los parámetros β_j , con pesos x_j , $j \in \{1, \dots, p\}$. En palabras sencillas, esto quiere decir que la regresión es lineal únicamente en los parámetros β_j , es decir, para cada parámetro j el exponente asociado al parámetro no puede ser distinto de 1¹.
2. **Rango completo:** La matriz de diseño X tiene rango columna completo, es decir, $\text{ran}(X) = p$, $n \geq p$.
3. **Exogeneidad estricta:** La matriz X no aporta información a la esperanza de los errores, es decir, para todo $i \in \{1, \dots, n\}$, se tiene $\mathbb{E}[\epsilon_i | X] = 0$. De este punto se desprende también que la esperanza de los errores es 0, es decir, $\mathbb{E}[\epsilon_i] = 0$. Esta última conclusión es quizás más importante al momento de sacar conclusiones respecto al vector de errores, pues sabemos que, en promedio, la variable de interés puede ser explicada completamente por la matriz de diseño.
4. **Varianza de errores esférica:** El vector de errores tiene matriz de covarianza diagonal y constante, es decir, $\text{Cov}[\epsilon | X] = \sigma^2 I_n$, donde I_n corresponde a la matriz identidad de dimensión $(n \times n)$. Debemos notar que como la matriz de covarianza es diagonal, luego para todo $i \neq j \in \{1, \dots, n\}$ se tiene $\text{Cov}[\epsilon_i, \epsilon_j] = 0$. Lo anterior implica a su vez, por definición de la covarianza, que los errores son todos independientes entre sí.
5. **Normalidad en los errores:** Este supuesto muchas veces puede no ser utilizado (principalmente en regresiones no normales), pero para el curso es fundamental definirlo, dado que sin él no se tendría la linealidad de la regresión ni tampoco todas las conclusiones importantes que se pueden obtener debido al amplio estudio de la distribución normal. Todo se puede resumir en lo siguiente: **Suponemos que los errores distribuyen normal n -variados**. Por supuestos anteriores conocemos la media y varianza de los errores, luego tenemos:

$$\epsilon \sim \mathcal{N}_n(0, \sigma^2 I_n)$$

¹Como dato curioso, la linealidad en los parámetros es una consecuencia del supuesto de normalidad en los errores, y en muchos textos no es considerada un supuesto (dado que puede ser derivado por otros medios). En el caso de este curso, la linealidad corresponde a un supuesto.

Por propiedades de la distribución normal multivariada, tenemos que cada error por sí solo distribuye normal, con media 0 y varianza σ^2 , es decir, $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ para $i \in \{1, \dots, n\}$.

Teorema de Frisch-Waugh-Lovell (FWL)

Este teorema permite dividir la matriz de diseño en dos, y recuperar los coeficientes de la regresión asociados a una sola parte de la matriz. En palabras matemáticas, sea y la variable dependiente de una regresión, con una matriz de diseño X . Consideremos dividir la matriz X en dos, X_1 y X_2 :

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nn} \end{bmatrix} \text{ la separamos en } X_1 = \begin{bmatrix} x_{11} \\ x_{21} \\ \vdots \\ x_{n1} \end{bmatrix}, \quad X_2 = \begin{bmatrix} x_{12} & \dots & x_{1n} \\ x_{22} & \dots & x_{2n} \\ \vdots & \ddots & \vdots \\ x_{n2} & \dots & x_{nn} \end{bmatrix}$$

luego, el teorema nos dice lo siguiente: Si queremos obtener la estimación del coeficiente β de la siguiente regresión:

$$y = X_1\beta + X_2\gamma + \epsilon$$

entonces podemos realizar el siguiente procedimiento:

1. Realizar una regresión donde X_1 sea la variable dependiente y X_2 sea la variable independiente, es decir, considerar la siguiente regresión: $X_1 = \lambda_1 X_2 + \mu_1$. De la regresión anterior, obtener los residuos μ_1 .
2. Realizar una regresión donde y sea la variable dependiente y X_2 sea la variable independiente, es decir, considerar la siguiente regresión: $y = \lambda_2 X_2 + \mu_2$. De la regresión anterior, obtener los residuos μ_2 .
3. Una vez obtenidos los residuos μ_1 y μ_2 , realizar una regresión donde μ_2 sea la variable dependiente y μ_1 sea la variable independiente, es decir, $\mu_2 = \eta\mu_1 + \nu$.

de tal manera, se tiene que $\hat{\beta} = \hat{\eta}$, es decir, el coeficiente estimado asociado a X_1 obtenido por MCO es exactamente el mismo que el coeficiente estimado utilizando una división de la matriz de diseño (FWL).

Pregunta 1: FWL (Adaptado Wooldridge 3.10)

Suponga que desea estudiar la relación entre y y x_1 . Para eso, se pueden incluir dos variables de control, x_2 y x_3 . Sea $\tilde{\beta}_1$ y $\hat{\beta}_1$ estimadores de dos regresiones tal que:

$$y = \tilde{\alpha}_0 + \tilde{\alpha}_1 x_1 = X_1 \tilde{\beta}_1$$
$$y = \hat{\alpha}_0 + \hat{\alpha}_1 x_1 + \hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 = \hat{\beta}_1 X_1 + X_2 \hat{\beta}_2$$

Con

$$X_1 = \begin{bmatrix} 1 & x_{11} \\ 1 & x_{21} \\ 1 & x_{31} \\ \vdots & \vdots \\ 1 & x_{n1} \end{bmatrix}, \quad X_2 = \begin{bmatrix} x_{12} & x_{13} \\ x_{22} & x_{23} \\ x_{32} & x_{33} \\ \vdots & \vdots \\ x_{n2} & x_{n3} \end{bmatrix}, \quad \tilde{\beta}_1 = \begin{bmatrix} \tilde{\alpha}_0 \\ \tilde{\alpha}_1 \end{bmatrix}, \quad \hat{\beta}_1 = \begin{bmatrix} \hat{\alpha}_0 \\ \hat{\alpha}_1 \end{bmatrix} \quad \text{y} \quad \hat{\beta}_2 = \begin{bmatrix} \hat{\alpha}_2 \\ \hat{\alpha}_3 \end{bmatrix}$$

Por FWL sabemos que

$$\hat{\beta}_1 = \tilde{\beta}_1 - (X_1' X_1)^{-1} X_1' X_2 \hat{\beta}_2 \quad (1)$$

a) Demuestre que $\hat{\beta}_1$ se puede reescribir como

$$\hat{\beta}_1 = (X_1' M_2 X_1)^{-1} X_1' M_2 y$$

con $M_2 = I - X_2 (X_2' X_2)^{-1} X_2'$

b) Encuentre expresiones para $\text{Var}(\hat{\beta}_1)$ y $\text{Var}(\tilde{\beta}_1)$.

c) Con ayuda de las expresiones obtenidas anteriormente responda:

- I) Si x_1 está altamente correlacionada con x_2 y x_3 , y x_2 y x_3 tienen efectos parciales grandes sobre y , ¿esperaría que $\tilde{\beta}_1$ y $\hat{\beta}_1$ sean similares o muy diferentes?
- II) Si x_1 casi no está correlacionada con x_2 y x_3 , pero x_2 y x_3 están fuertemente correlacionadas, ¿esperaría que $\tilde{\beta}_1$ y $\hat{\beta}_1$ sean similares o muy diferentes?
- III) Si x_1 está altamente correlacionada con x_2 y x_3 , y x_2 y x_3 tienen efectos parciales pequeños sobre y , ¿esperaría que $\text{Var}(\tilde{\beta}_1)$ o $\text{Var}(\hat{\beta}_1)$ fuera pequeña?
- IV) Si x_1 casi no está correlacionada con x_2 y x_3 , y x_2 y x_3 tienen efectos parciales grandes sobre y , ¿esperaría que $\text{Var}(\tilde{\beta}_1)$ o $\text{Var}(\hat{\beta}_1)$ fuera pequeña?

Pregunta 2: FWL, pero en R

En Macroeconomía, la inversión agregada real $rInvest$ se suele explicar en términos del producto agregado real $rGNP$ y otros determinantes. En particular, considere los datos

del archivo *datos4.csv* que contienen observaciones de inversión, tasa de interés y GNP nominales, y de un indicador de precios al consumidor para ajustar la siguiente especificación:

$$rInvest = \beta_0 + \beta_1 Trend + \beta_2 GNP + \beta_3 Interest + \beta_4 Inflation + \mu$$

Donde Trend es una tendencia (1, 2, 3, ...), y μ es el error de pronóstico. Construya el modelo de regresión lineal y calculelo utilizando FWL en R.

Pregunta 3: R^2 (Propuesto)

Consideremos que para una regresión

$$Y = X\beta + \epsilon$$

Y sus errores de la estimación

$$e = Y - X\hat{\beta}$$

Se puede calcular R^2 como:

$$R^2 = 1 - \frac{e'e}{Y'MY}$$

Muestre que el R^2 crece a medida que se le añaden variables, aún cuando éstas no sean relevantes.