



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2
Profesor: PATRICIO DOMÍNGUEZ
Ayudantes: GONZALO AGUILAR (GONZALO.AGUILAR@UC.CL)
ANTONIO LÓPEZ (ANTONIO.LOPEZ.MAS@UC.CL)

Ayudantía 4

Repaso I1

3 de septiembre de 2025

Pregunta 1

Un investigador está interesado en estudiar qué factores afectan el desempeño de los pilotos de Fórmula 1. Para ello, recopiló información de 8 carreras recientes para un mismo grupo de pilotos. La variable dependiente es la **Posición Final** (número entero, donde 1 es el mejor puesto).

Se dispone de las siguientes variables explicativas:

- **Clasificación:** posición de largada (número entero, donde 1 es el mejor puesto).
- **Lluvia:** vale 1 si la carrera se corrió con lluvia, 0 en caso contrario.
- **Inglés:** vale 1 si el piloto tiene nacionalidad británica, 0 en otro caso.
- **HomeGP:** vale 1 si el piloto corre en su país de origen, 0 en caso contrario.
- **Edad:** edad del piloto (en años).

La tabla con los datos es la siguiente:

PosiciónFinal	Clasificación	Lluvia	Inglés	HomeGP	Edad
2	1	0	0	1	24
15	13	1	0	0	29
9	7	0	1	1	22
8	6	0	0	0	31
3	4	1	0	1	27
6	5	0	0	0	26
4	2	1	0	0	23
7	7	1	1	0	35

Responda:

-
- a) Plantee un modelo para predecir el efecto de *HomeGP*. Explique variables, índices y coeficientes.

Para medir el efecto de *HomeGP* en el resultado de la carrera, se podría utilizar el siguiente modelo:

$$PosicionFinal_i = \alpha + \beta \cdot HomeGP_i + e_i$$

Donde *PosicionFinal_i* es el outcome que queremos medir y *HomeGP_i* es una variable que vale 1 cuando la carrera i fue corrida en el país de origen.

En este caso el coeficiente de interés es β , ya que nos dirá cuantas posiciones mejor o peor tienen en promedio los corredores cuando están de local.

- b) Estime el coeficiente de interés y comente sus resultados.

Como *HomeGP* es una variable binaria:

$$\begin{aligned}\hat{\beta} &= \mathbb{E}(\text{PosicionFinal} \mid HomeGP = 1) - \mathbb{E}(\text{PosicionFinal} \mid HomeGP = 0) \\ &= \frac{2 + 9 + 3}{3} - \frac{15 + 8 + 6 + 4 + 7}{5} \\ &= 4,67 - 8,00 \\ &= -3,33\end{aligned}$$

Esto se interpreta como que al correr en un circuito de su propio país, se espera que el corredor termine en promedio 3,3 posiciones más adelante en la carrera (recordemos que un número menor corresponde a un mejor puesto). Esto tiene sentido, ya que los pilotos podrían conocer mejor su circuito local y además contar con el apoyo de la hinchada.

- c) Plantee un modelo que permita predecir el resultado de la carrera, conociendo el lugar de clasificación del piloto

Para predecir la posición final se puede utilizar:

$$PosicionFinal_i = \alpha + \beta \cdot Clasificación_i + e_i$$

Donde *PosicionFinal_i* es el outcome que queremos medir y *Clasificación_i* representa la posición obtenida en la *qualy* del piloto i.

En este caso el coeficiente de interés es β , ya que nos entrega las posiciones que aumentan (o disminuyen) por cada puesto que aumente en la clasificación.

- d) Estime los coeficientes de forma manual-matricial e interprete

Para estimar el modelo se utiliza la fórmula

$$\hat{\beta} = (X'X)^{-1}X'Y$$

Donde:

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 13 \\ 1 & 7 \\ 1 & 6 \\ 1 & 4 \\ 1 & 5 \\ 1 & 2 \\ 1 & 7 \end{bmatrix}, \quad Y = \begin{bmatrix} 2 \\ 15 \\ 9 \\ 8 \\ 3 \\ 6 \\ 4 \\ 7 \end{bmatrix}$$

Resolviendo primero:

$$X'X = \begin{bmatrix} 8 & 45 \\ 45 & 349 \end{bmatrix}$$

Ahora podemos invertir la matriz:

$$(X'X)^{-1} = \frac{1}{8 \cdot 349 - 45 \cdot 45} \begin{bmatrix} 349 & -45 \\ -45 & 8 \end{bmatrix} = \frac{1}{767} \begin{bmatrix} 349 & -45 \\ -45 & 8 \end{bmatrix} = \begin{bmatrix} 0,4550 & -0,05867 \\ -0,05867 & 0,01043 \end{bmatrix}$$

A su vez:

$$X'Y = \begin{bmatrix} 54 \\ 407 \end{bmatrix}$$

Por último,

$$(X'X)^{-1}X'Y = \begin{bmatrix} 0,4550 & -0,05867 \\ -0,05867 & 0,01043 \end{bmatrix} \begin{bmatrix} 54 \\ 407 \end{bmatrix} = \begin{bmatrix} 0,6923 \\ 1,0769 \end{bmatrix}$$

Un $\hat{\beta} = 1,0769$ se interpreta como que cada puesto adicional (o más atrás en la clasificación) implica, en promedio, 1,0769 puestos más atrás en el resultado de la carrera.

Pregunta 2

Sea el modelo lineal

$$Y = X\beta + u,$$

con $X \in \mathbb{R}^{n \times k}$ de rango completo. Fijado un índice j y un escalar $c > 0$, sea la matriz diagonal

$$S = \text{diag}(1, \dots, 1, \underbrace{c}_j, 1, \dots, 1), \quad \tilde{X} := XS.$$

Denote por $\hat{\beta}$ el estimador de MCO asociado a X y por $\tilde{\beta}$ el estimador de MCO asociado a $\tilde{X}$. Demuestre y/o responda lo siguiente:

a) Pruebe que $\tilde{\beta} = S^{-1}\hat{\beta}$.

Solución: Recordemos que el estimador de MCO asociado a X es

$$\hat{\beta} = (X'X)^{-1}X'Y.$$

De manera análoga, el estimador asociado a $\tilde{X} = XS$ es

$$\tilde{\beta} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'Y.$$

Sustituyendo $\tilde{X} = XS$ en la expresión anterior:

$$\tilde{\beta} = (S'X'XS)^{-1}S'X'Y.$$

Dado que S es diagonal con entradas positivas ($c > 0$), es simétrica e invertible, por lo que $S' = S$. Así,

$$\begin{aligned}\tilde{\beta} &= (SX'XS)^{-1}SX'Y \\ &= S^{-1}(X'X)^{-1}S^{-1}SX'Y \\ &= S^{-1}(X'X)^{-1}X'Y\end{aligned}$$

Finalmente,

$$\tilde{\beta} = S^{-1}\hat{\beta}.$$

Con esto, los componentes del vector $\tilde{\beta}$ son $\tilde{\beta}_j = \hat{\beta}_j/c$ y $\tilde{\beta}_\ell = \hat{\beta}_\ell$ para $\ell \neq j$.

Observación: También se puede hacer con las ecuaciones normales de X y $\tilde{X}$.

b) Pruebe que los valores ajustados y los residuos permanecen invariantes.

Solución: Del inciso anterior, se tiene $\tilde{\beta} = S^{-1}\hat{\beta}$. Luego, para los valores ajustados:

$$\begin{aligned}\tilde{Y} &= \tilde{X}\tilde{\beta} \\ &= XS S^{-1}\hat{\beta} \\ &= X\hat{\beta} \\ &= \hat{Y},\end{aligned}$$

y para los residuos:

$$\begin{aligned}\tilde{e} &= Y - \tilde{Y} \\ &= Y - \hat{Y} \\ &= \hat{e}\end{aligned}$$

Por lo tanto, el reescalamiento de una columna de X no altera la proyección de Y sobre el espacio columna del diseño, de modo que los valores ajustados y los residuos permanecen invariantes.

Observación: También se puede hacer con las proyecciones de X y $\tilde{X}$.

-
- c) Analice la estimación de la varianza del error, $\hat{\sigma}^2$, y el coeficiente de determinación, R^2 . Muestre qué implica esto respecto a la matriz de varianza-covarianza y al estadístico asociado a $\tilde{\beta}_j$.

Solución: Para la estimación de la varianza del error, como $\tilde{e} = e$, el $SCR = \sum_i (y - \hat{y})^2 = \sum_i (y - \tilde{y})^2$ no cambia. Por tanto,

$$\hat{\sigma}^2 = \frac{SCR}{n - k} \quad \text{y} \quad \tilde{\sigma}^2 = \frac{SCR}{n - k}$$

coinciden:

$$\hat{\sigma}^2 = \tilde{\sigma}^2.$$

Por otro lado, para el coeficiente de determinación, como $\tilde{Y} = \hat{Y}$ y Y no cambia, ni la $STC = \sum_i (y_i - \bar{y})$ ni la SCR cambian; en consecuencia,

$$\tilde{R}^2 = \hat{R}^2.$$

Para la matriz de varianza-covarianza de los estimadores, bajo homocedasticidad,

$$\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2 (X'X)^{-1}.$$

Para el modelo reescalado $\tilde{X} = XS$,

$$\widehat{\text{Var}}(\tilde{\beta}) = \hat{\sigma}^2 (\tilde{X}'\tilde{X})^{-1} = \hat{\sigma}^2 (S'X'XS)^{-1} = \hat{\sigma}^2 S^{-1}(X'X)^{-1}S^{-1}.$$

Lo que implica para cada componente que:

$$\text{Var}(\tilde{\beta}_j) = \frac{1}{c^2} \text{Var}(\hat{\beta}_j), \quad \text{se}(\tilde{\beta}_j) = \frac{1}{c} \text{se}(\hat{\beta}_j),$$

$$\text{Cov}(\tilde{\beta}_j, \tilde{\beta}_\ell) = \frac{1}{c} \text{Cov}(\hat{\beta}_j, \hat{\beta}_\ell) \quad (\ell \neq j), \quad \text{Var}(\tilde{\beta}_\ell) = \text{Var}(\hat{\beta}_\ell) \quad (\ell \neq j).$$

Y por último, el estadístico t de $\tilde{\beta}_j$. Del inciso (a), $\tilde{\beta}_j = \hat{\beta}_j/c$, y por lo anterior $\text{se}(\tilde{\beta}_j) = \text{se}(\hat{\beta}_j)/c$. Luego,

$$t_j^{(\tilde{X})} = \frac{\tilde{\beta}_j}{\text{se}(\tilde{\beta}_j)} = \frac{\hat{\beta}_j/c}{\text{se}(\hat{\beta}_j)/c} = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)} = t_j^{(X)}.$$

Por consiguiente, el valor t , su p -valor y los intervalos de confianza (expresados en la escala correspondiente) son invariantes en términos de significancia: los límites del IC para β_j se reescalan por $1/c$, pero la evidencia estadística (razón t) no cambia. De forma análoga.

d) Interprete este efecto en términos prácticos.

Solución: Reescalar la j -ésima columna de X por un factor $c > 0$ (reemplazar x_j por $\tilde{x}_j = c x_j$) únicamente cambia la unidad de medida de esa regresora. En consecuencia, el coeficiente correspondiente se reexpresa como $\tilde{\beta}_j = \hat{\beta}_j/c$, de modo que el “efecto por una unidad” pasa a estar definido en la nueva unidad (p. ej., si el ingreso se mide en miles de pesos, $c = \frac{1}{1000}$ y $\tilde{\beta}_j = 1000 \hat{\beta}_j$, que es el efecto por mil pesos). El producto columna-coeficiente se preserva ($x_j \hat{\beta}_j = \tilde{x}_j \tilde{\beta}_j$), por lo que no cambian los valores ajustados ni los residuos, ni tampoco métricas de ajuste como $\hat{\sigma}^2$ y R^2 . En inferencia, el error estándar se reescala como $\text{se}(\tilde{\beta}_j) = \text{se}(\hat{\beta}_j)/c$, lo que deja invariante el estadístico t y, por ende, p -values y decisiones de test; los intervalos de confianza simplemente se expresan en las nuevas unidades. La matriz de varianzas-covarianzas se transforma como $\widehat{\text{Var}}(\tilde{\beta}) = S^{-1} \widehat{\text{Var}}(\hat{\beta}) S^{-1}$, por lo que las correlaciones entre coeficientes no se ven afectadas. En la práctica, elegir c sirve para mejorar la legibilidad de los coeficientes (edad en décadas, ingreso en miles) y, a veces, la estabilidad numérica al trabajar con magnitudes muy grandes o muy pequeñas, sin alterar el contenido económico o estadístico del modelo.

Pregunta 3

Considere el siguiente modelo de regresión lineal múltiple estimado sobre la base de datos de salarios del sector público:

$$y = \beta_0 \mathbf{1} + \beta_1 \text{male} + \beta_2 \text{salud} + \beta_3 \text{profesional} + \varepsilon,$$

donde $y = \log(\text{rem_mes_inf})$ corresponde al logaritmo del salario imponible mensual informado, male es una variable indicadora que vale 1 si el individuo es hombre y 0 si es mujer, salud es una variable indicadora que vale 1 si el individuo trabaja en el sector salud y 0 en otro sector, y profesional es una variable indicadora que vale 1 si el individuo pertenece al estamento profesional y 0 en otro caso. Responda:

- a) Usando la descomposición de Frisch–Waugh–Lovell (FWL), obtenga el estimador de β_1 mostrando los tres pasos: (i) residualizar y respecto de salud y profesional , (ii) residualizar male respecto de esas mismas covariables, y (iii) estimar una regresión bivariada entre ambos residuos.

Solución: Sea n el número de observaciones. Definimos los vectores (columna) observados:

$$y \equiv \log(\text{rem_mes_inf}) \in \mathbb{R}^n, \quad x \equiv \text{male} \in \mathbb{R}^n,$$

y las matrices de covariables indicadoras

$$Z \equiv [\mathbf{1} \quad \text{salud} \quad \text{profesional}] \in \mathbb{R}^{n \times 3}.$$

En consecuencia, la matriz de regresores completa es

$$X \equiv [\mathbf{1} \quad \text{male} \quad \text{salud} \quad \text{profesional}] = [x_0 \quad x \quad Z] \in \mathbb{R}^{n \times 4},$$

donde $x_0 = \mathbf{1}$ es el vector constante.

El modelo lineal múltiple es

$$y = \beta_0 \mathbf{1} + \beta_1 x + Z\gamma + \varepsilon,$$

que en forma matricial se escribe $y = X\beta + \varepsilon$ con $\beta = (\beta_0, \beta_1, \gamma')' \in \mathbb{R}^4$. Bajo rango completo de X , el estimador MCO de β es

$$\hat{\beta} = (X'X)^{-1}X'y.$$

Sea

$$P_Z \equiv Z(Z'Z)^{-1}Z', \quad M_Z \equiv I - P_Z.$$

Nótese que P_Z y M_Z son simétricas e idempotentes: $P_Z^2 = P_Z$, $M_Z^2 = M_Z$, y $P_Z M_Z = 0$.

Para obtener β_1 vía FWL, se emplean tres regresiones:

i) **Regresión de y sobre Z** (para limpiar el efecto de Z en y):

$$y = Z\delta + u_y, \quad \hat{\delta} = (Z'Z)^{-1}Z'y, \quad \tilde{y} \equiv \hat{u}_y = M_Z y.$$

ii) **Regresión de x sobre Z** (para limpiar el efecto de Z en x):

$$x = Z\pi + u_x, \quad \hat{\pi} = (Z'Z)^{-1}Z'x, \quad \tilde{x} \equiv \hat{u}_x = M_Z x.$$

iii) **Regresión bivariada de residuos:**

$$\tilde{y} = \beta_1 \tilde{x} + \tilde{\varepsilon}, \quad \hat{\beta}_1 = \frac{\tilde{x}'\tilde{y}}{\tilde{x}'\tilde{x}} = \frac{(M_Z x)'(M_Z y)}{(M_Z x)'(M_Z x)}.$$

Estas tres regresiones son algebraicamente equivalentes a estimar el modelo completo $y = \beta_0 \mathbf{1} + \beta_1 x + Z\gamma + \varepsilon$ por MCO y luego tomar su componente $\hat{\beta}_1$.

Derivación de la igualdad de $\hat{\beta}_1$ (vía ecuaciones normales particionadas).

1) Al particionar y sobre $[x, Z]$, las ecuaciones normales son

$$\begin{pmatrix} x'x & x'Z \\ Z'x & Z'Z \end{pmatrix} \begin{pmatrix} \beta_1 \\ \gamma \end{pmatrix} = \begin{pmatrix} x'y \\ Z'y \end{pmatrix}.$$

2) De la segunda fila, resolviendo γ en función de β_1 ,

$$Z'x \beta_1 + Z'Z \gamma = Z'y \quad \Rightarrow \quad \gamma = (Z'Z)^{-1}(Z'y - Z'x \beta_1).$$

3) Luego, sustituyendo γ en la primera fila y reagrupando,

$$\begin{aligned} x'x\beta_1 + x'Z(Z'Z)^{-1}(Z'y - Z'x\beta_1) &= x'y, \\ \underbrace{[x'x - x'Z(Z'Z)^{-1}Z'x]}_{x'M_Zx} \beta_1 &= \underbrace{[x'y - x'Z(Z'Z)^{-1}Z'y]}_{x'M_Zy}. \end{aligned}$$

Aquí usamos $M_Z = I - Z(Z'Z)^{-1}Z'$, de modo que

$$x'M_Zx = x'x - x'Z(Z'Z)^{-1}Z'x, \quad x'M_Zy = x'y - x'Z(Z'Z)^{-1}Z'y.$$

4) Notando que M_Z es simétrico e idempotente y definiendo $\tilde{x} := M_Zx$, $\tilde{y} := M_Zy$,

$$x'M_Zy = (M_Zx)'(M_Zy) = \tilde{x}'\tilde{y}, \quad x'M_Zx = (M_Zx)'(M_Zx) = \tilde{x}'\tilde{x},$$

por lo que

$$\boxed{\hat{\beta}_1 = \frac{\tilde{x}'\tilde{y}}{\tilde{x}'\tilde{x}} = \frac{(M_Zx)'(M_Zy)}{(M_Zx)'(M_Zx)}}$$

que es exactamente la pendiente de la regresión bivariada de $\tilde{y}$ sobre $\tilde{x}$.

b) Compare el valor e interpretación de β_1 con el coeficiente que se obtendría en una regresión bivariada de y sobre male sin controles.

Solución:

1. *Modelo verdadero (con todos los regresores).*

$$y = \beta_0 + \beta_1x + \beta_2z_1 + \beta_3z_2 + \varepsilon,$$

donde x = male, z_1 = salud y z_2 = profesional.

2. *Modelo estimado (omitidos z_1, z_2).* Si se corre la regresión bivariada:

$$y = \alpha + \tilde{\beta}_1x + u,$$

el estimador es

$$\tilde{\beta}_1 = \frac{\text{Cov}(y, x)}{\text{Var}(x)}.$$

3. *Sustitución del modelo verdadero.*

$$\text{Cov}(y, x) = \text{Cov}(\beta_0 + \beta_1x + \beta_2z_1 + \beta_3z_2 + \varepsilon, x).$$

Como $\text{Cov}(\beta_0, x) = 0$ y $\text{Cov}(\varepsilon, x) = 0$, se obtiene:

$$\text{Cov}(y, x) = \beta_1\text{Var}(x) + \beta_2\text{Cov}(x, z_1) + \beta_3\text{Cov}(x, z_2).$$

4. División por la varianza de x .

$$\tilde{\beta}_1 = \frac{\beta_1 \text{Var}(x) + \beta_2 \text{Cov}(x, z_1) + \beta_3 \text{Cov}(x, z_2)}{\text{Var}(x)}.$$

Simplificando:

$$\tilde{\beta}_1 = \beta_1 + \beta_2 \frac{\text{Cov}(x, z_1)}{\text{Var}(x)} + \beta_3 \frac{\text{Cov}(x, z_2)}{\text{Var}(x)}.$$

Interpretación.

- $\hat{\beta}_1$ (con FWL) mide la *brecha neta de género*, controlando por sector y estamento.
 - $\tilde{\beta}_1$ (bivariada) mide la *brecha bruta*: la diferencia promedio de log-salario entre hombres y mujeres sin controles.
 - La diferencia entre ambos está dada por los términos de sesgo: si x está correlacionada con z_1 o z_2 y estos afectan y , entonces $\tilde{\beta}_1 \neq \beta_1$.
- c) Explique cómo la descomposición FWL ayuda a entender el sesgo por variables omitidas en la estimación de la brecha de género.

Solución: La descomposición de FWL muestra que el coeficiente de una variable x en una regresión múltiple puede obtenerse en dos pasos: (i) eliminando de y toda la parte explicada por los controles Z , y (ii) eliminando de x toda la parte explicada por esos mismos controles, para luego (iii) correr una regresión simple de los residuos.

Esto implica que $\hat{\beta}_1$ mide la relación entre y y x *únicamente en la parte de cada variable que es ortogonal a los controles*. Geométricamente, se trabaja en el subespacio perpendicular al generado por Z .

En contraste, si se omiten Z de la regresión, el estimador bivariado $\tilde{\beta}_1$ incorpora no solo el efecto directo de x sobre y , sino también la parte de y que en realidad se explica por Z pero que se correlaciona con x . Este es precisamente el **sesgo por variables omitidas**.

Por lo tanto, FWL aclara que:

- El sesgo aparece porque al no proyectar sobre Z , x mantiene correlación con las omitidas y transmite sus efectos a y .
- Al usar FWL, residualizamos y y x respecto de Z , rompiendo esa correlación y aislando el efecto neto de x .
- En el caso aplicado, $\hat{\beta}_1$ entrega la brecha salarial de género *dentro de grupos homogéneos* de sector y estamento, mientras que el coeficiente bivariado $\tilde{\beta}_1$ entrega la brecha bruta, sesgada por diferencias de composición entre hombres y mujeres en esos grupos.