



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2

Profesor: PATRICIO DOMÍNGUEZ

Ayudante: GONZALO AGUILAR (GONZALO.AGUILAR@UC.CL)

Ayudantía 5

Simulación

12 de septiembre de 2025

Proceso Generador de Datos (DGP)

El Proceso Generador de Datos (DGP, por sus siglas en inglés *Data Generating Process*) se refiere al modelo teórico que describe cómo se generan los datos en un estudio. Es esencial para entender la relación entre las variables y para realizar inferencias estadísticas y predicciones.

Ejemplo:

Suponga que se quiere estudiar la relación entre el ingreso y el gasto en consumo de los hogares. Un modelo simple podría ser:

$$\text{Gasto en consumo} = \beta_0 + \beta_1 \text{Ingreso} + \epsilon$$

Para simular datos bajo el Proceso Generador de Datos (DGP) definido, el primer paso es generar un conjunto de ingresos Ingreso que siguen una distribución normal con media μ y desviación estándar σ . Una vez generados los ingresos, se utiliza el modelo lineal especificado para calcular el gasto en consumo para cada valor de ingreso. Finalmente, se añade un término de error ϵ que sigue una distribución normal con media cero y desviación estándar σ_ϵ para completar la simulación de los datos.

Muestra Aleatoria

Una muestra aleatoria es un subconjunto seleccionado de una población de tal manera que cada individuo o elemento de la población tiene la misma probabilidad de ser incluido en la muestra.

Ejemplo:

Imagine que se quiere estudiar la estatura promedio de los estudiantes de una escuela. Si la población total de la escuela es de 1000 estudiantes, se podría tomar una muestra aleatoria

de 100 estudiantes. En la muestra aleatoria, cada uno de los 1000 estudiantes tiene la misma probabilidad de ser seleccionado para formar parte de la muestra de 100 estudiantes.

Sesgo

El sesgo en estadística se refiere a la tendencia o inclinación sistemática de los datos hacia una dirección específica, lo que puede llevar a errores en las estimaciones o inferencias. Un sesgo puede ser positivo o negativo, dependiendo de si las estimaciones tienden a sobreestimar o subestimar el parámetro de interés, respectivamente.

Ejemplo:

Imagine que se quiere estimar la estatura promedio de todos los estudiantes de una escuela. Sin embargo, se decide hacerlo únicamente midiendo a los estudiantes que participan en el equipo de basketball de la escuela, ya que se cree que tienen una estatura significativamente más alta que el estudiante promedio.

En este caso, la estimación de la estatura promedio estará sesgada hacia arriba debido a que la muestra seleccionada (los estudiantes del equipo de basketball) no es representativa de toda la población estudiantil.

Pregunta 1: Error clásico en la variable dependiente

Considere el modelo verdadero

$$Y_i^* = \alpha + \beta X_i + \varepsilon_i, \quad \mathbb{E}[\varepsilon_i | X_i] = 0,$$

pero suponga que en la práctica observamos

$$Y_i = Y_i^* + v_i, \quad \mathbb{E}[v_i] = 0, \quad v_i \perp (X_i, \varepsilon_i).$$

a) Demuestre que, al estimar

$$Y_i = \alpha + \beta X_i + u_i, \quad u_i = \varepsilon_i + v_i,$$

el estimador MCO de β es insesgado, es decir,

$$\mathbb{E}[\hat{\beta}] = \beta.$$

Solución: El estimador MCO de β en una regresión simple se puede escribir como

$$\hat{\beta} = \frac{\text{Cov}(X_i, Y)}{\text{Var}(X_i)}.$$

Sustituimos $Y = \alpha + \beta X_i + \varepsilon + v$:

$$\text{Cov}(X_i, Y) = \text{Cov}(X_i, \alpha + \beta X_i + \varepsilon + v).$$

Como $\text{Cov}(X_i, \alpha) = 0$, $\text{Cov}(X_i, \varepsilon) = 0$ y $\text{Cov}(X_i, v) = 0$, queda

$$\text{Cov}(X_i, Y) = \beta \text{Var}(X_i).$$

Luego,

$$E[\hat{\beta}] = \frac{\beta \text{Var}(X_i)}{\text{Var}(X_i)} = \beta.$$

b) Muestre que, en este caso, la varianza del término de error es mayor que en el modelo sin error de medida.

Solución: El error compuesto es

$$u_i = \varepsilon_i + v_i.$$

Entonces

$$\text{Var}(u_i) = \text{Var}(\varepsilon_i) + \text{Var}(v_i) + 2\text{Cov}(\varepsilon_i, v_i).$$

Como $v_i \perp \varepsilon_i$, se cumple $\text{Cov}(\varepsilon_i, v_i) = 0$. Así,

$$\text{Var}(u_i) = \text{Var}(\varepsilon_i) + \text{Var}(v_i).$$

-
- c) Concluya a partir de lo anterior por qué el estimador es menos preciso que en ausencia de error de medida.

Solución: El estimador sigue centrado en β , pero la varianza de los errores es mayor (por lo demostrado en b)). Esto implica que la dispersión de $\hat{\beta}$ es más alta $\Rightarrow$ menor precisión.

Pregunta 2: Error clásico en la variable independiente

Considere ahora el modelo verdadero

$$Y_i = \alpha + \beta X_i^* + \varepsilon_i, \quad \mathbb{E}[\varepsilon_i | X_i^*] = 0,$$

pero suponga que en la práctica sólo observamos

$$X_i = X_i^* + u_i, \quad \mathbb{E}[u_i] = 0, \quad u_i \perp (X_i^*, \varepsilon_i).$$

- a) Demuestre que la varianza de X_i se puede descomponer como

$$\text{Var}(X_i) = \text{Var}(X_i^*) + \text{Var}(u_i).$$

Solución: Sea $X_i = X_i^* + u_i$. La varianza es

$$\text{Var}(X_i) = \text{Var}(X_i^* + u_i).$$

Usando propiedades:

$$\text{Var}(X_i) = \text{Var}(X_i^*) + \text{Var}(u_i) + 2\text{Cov}(X_i^*, u_i).$$

Como $u_i \perp X_i^*$, se anula la covarianza. Por tanto,

$$\text{Var}(X_i) = \text{Var}(X_i^*) + \text{Var}(u_i).$$

- b) Utilizando este resultado, muestre que el estimador MCO de β está sesgado y que

$$\mathbb{E}[\hat{\beta}] = \frac{\beta \text{Var}(X_i^*)}{\text{Var}(X_i^*) + \text{Var}(u)}$$

Solución: El estimador es

$$\hat{\beta} = \frac{\text{Cov}(X_i, Y)}{\text{Var}(X_i)}.$$

Sustituimos $X_i = X_i^* + u$ y $Y = \alpha + \beta X_i^* + \varepsilon$:

$$\text{Cov}(X_i, Y) = \text{Cov}(X_i^* + u, \alpha + \beta X_i^* + \varepsilon).$$

Como $u \perp (X_i^*, \varepsilon)$ y α es constante:

$$\text{Cov}(X_i, Y) = \beta \text{Var}(X_i^*).$$

Usando el resultado anterior demostrado en a):

$$E[\hat{\beta}] = \frac{\beta \text{Var}(X_i^*)}{\text{Var}(X_i^*) + \text{Var}(u_i)}.$$

- c) Interprete el resultado anterior y explique por qué este fenómeno se denomina *sesgo de atenuación*.

Solución: El factor $\frac{\text{Var}(X_i^*)}{\text{Var}(X_i^*) + \text{Var}(u)}$ es menor que 1. Esto implica que $E[\hat{\beta}]$ es menor que el verdadero valor β en magnitud. A este sesgo se le conoce como *sesgo de atenuación*: efecto que disminuye el efecto causal de X sobre Y .

Pregunta 3: Simulación en R del error clásico de medida

Considere el siguiente proceso generador de datos (DGP):

$$Y_i^* = \alpha + \beta X_i^* + \varepsilon_i, \quad i = 1, \dots, n,$$

donde

$$X_i^* \sim N(0, 1), \quad \varepsilon_i \sim N(0, 1),$$

con $\alpha = 1$, $\beta = 2$ y $n = 1000$.

- a) Genere una muestra simulada en R a partir del DGP anterior y estime el modelo

$$Y_i^* = \alpha + \beta X_i^* + \varepsilon_i$$

mediante MCO. Compare el valor estimado de $\hat{\beta}$ con su valor real.

Solución: Los resultados entregan $\hat{\alpha} = 0,978$ y una pendiente de $\hat{\beta} = 2,022$. Ambos valores son muy cercanos a los parámetros verdaderos, lo cual confirma que en ausencia de error de medida el estimador MCO recupera correctamente los coeficientes poblacionales.

La ligera diferencia respecto a los valores verdaderos se debe a la variabilidad muestral introducida por el término de error ε_i .

- b) Ahora introduzca error clásico de medida en la variable dependiente:

$$Y_i = Y_i^* + v_i, \quad v_i \sim N(0, \sigma_v^2), \quad \sigma_v^2 = 4.$$

Estime nuevamente el modelo y compare los resultados con el caso sin error de medida. ¿Qué ocurre con el sesgo y qué ocurre con la dispersión de las estimaciones?

Solución: La estimación por MCO da como resultado $\hat{\alpha} = 1,024$ y $\hat{\beta} = 1,985$, ambos muy cercanos a los valores verdaderos $\alpha = 1$ y $\beta = 2$. Esto confirma que el error de medida en Y no introduce sesgo en los estimadores: en promedio, $\hat{\beta}$ sigue recuperando el valor verdadero de β .

Sin embargo, el efecto del error adicional es claro en la varianza. El error estándar de los coeficientes casi se duplica respecto al caso sin error. Esto refleja que la dispersión de los estimadores es mayor, lo que se traduce en menor precisión en las inferencias.

En conclusión, cuando el error de medida está en la variable dependiente, el estimador sigue siendo insesgado, pero pierde eficiencia debido al aumento en la varianza de los errores.

- c) Repita el experimento, pero ahora introduzca error clásico en la variable independiente:

$$X_i = X_i^* + u_i, \quad u_i \sim N(0, \sigma_u^2), \quad \sigma_u^2 = 4.$$

Estime el modelo usando X_i en lugar de X_i^* y compare con el valor verdadero de β . Interprete el resultado a la luz del *sesgo de atenuación*.

Solución: La estimación por MCO da como resultado $\hat{\alpha} = 1,002$ y $\hat{\beta} = 0,417$, siendo este último valor muy inferior al verdadero $\beta = 2$. Esto refleja que el error de medida en X sí introduce sesgo en los estimadores: en promedio, $\hat{\beta}$ se atenúa, mostrando así el fenómeno conocido como *sesgo de atenuación*.

La teoría indica que

$$E[\hat{\beta}] = \frac{\beta \text{Var}(X_i^*)}{\text{Var}(X_i^*) + \text{Var}(u_i)},$$

de modo que mientras mayor sea la varianza del error en la variable independiente, más pequeño será el valor esperado de la pendiente estimada.

En conclusión, cuando el error de medida afecta a la variable independiente, el estimador pierde validez: aunque sigue siendo estadísticamente significativo, su magnitud está distorsionada y no representa el verdadero efecto causal de X sobre Y .

- d) Repita el ejercicio anterior muchas veces (por ejemplo, 1000 simulaciones) y grafique la distribución de los estimadores $\hat{\beta}$ en los tres escenarios:
- sin error de medida,
 - error en Y ,
 - error en X .

¿Qué diferencias se observan en la ubicación (sesgo) y en la dispersión de las distribuciones?

Solución: A continuación se tiene el gráfico pedido:




Figura 1: Distribuciones de $\hat{\beta}$ en los diferentes escenarios.

Del gráfico, se observa que:

- **Sin error de medida (azul):** la distribución se concentra en torno al valor verdadero $\beta = 2$, con baja dispersión. Esto confirma que en ausencia de error de medida, el estimador MCO es insesgado y preciso.
- **Error en Y (verde):** la distribución sigue centrada cerca de $\beta = 2$, lo que confirma que el estimador es insesgado. Sin embargo, la curva es más ancha, reflejando mayor varianza y, por tanto, menor precisión.
- **Error en X (rojo):** la distribución se desplaza fuertemente hacia la izquierda, alrededor de 0,4, muy lejos del valor verdadero $\beta = 2$. Esto ilustra el *sesgo de atenuación*: el estimador ya no recupera el verdadero parámetro, sino que sistemáticamente lo subestima en magnitud.

En conclusión, las simulaciones confirman lo anticipado en la teoría: el error en la variable dependiente no sesga pero aumenta la dispersión, mientras que el error en la variable independiente genera un sesgo claro hacia cero.