



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2

Profesor: PATRICIO DOMÍNGUEZ

Ayudantes: GONZALO AGUILAR (GONZALO.AGUILAR@UC.CL) Y LUZ MARÍA INFANTE (LINFANTEK@UC.CL)

Ayudantía 6

POF y RCT

26 de septiembre de 2025

Potential Outcome Framework

Esta metodología corresponde en realidad a establecer la terminología a utilizar durante todo el capítulo de causalidad. Para ello, suponemos que queremos obtener cómo un tratamiento afecta a cierta situación, que corresponde a la variable dependiente. Así, suponiendo que tratamos con n unidades experimentales, tenemos la siguiente notación para $i \in \{1, \dots, n\}$.

- $D_i := \{0, 1\}$: Corresponde a una variable binaria, que indica si la unidad experimental i obtuvo el tratamiento.
- Y_i : Corresponde a la variable dependiente, que en nuestra nueva notación llamaremos *outcome*, de la unidad experimental i .
- Y_{1i} e Y_{0i} : Corresponde al *outcome* del individuo i , pero esta vez considera si fue tratado Y_{1i} o si no fue tratado Y_{0i} . Una notación equivalente es $Y_{1i} = Y_i(1)$ y $Y_{0i} = Y_i(0)$. **Nótese que nunca ocurrirá en la realidad que el individuo sea tratado y a la vez no sea tratado.**
- $\tau_i = Y_{1i} - Y_{0i} = Y_i(1) - Y_i(0)$: Corresponde al efecto del tratamiento D_i , en el individuo i . **Nótese que como nunca se observará Y_{0i} e Y_{1i} a la vez, nunca se podrá observar τ_i .**

Por lo tanto, bajo la notación anterior, y como en la realidad un individuo no puede estar tratado y no tratado a la vez, se puede escribir el *outcome* que nos interesa, y que es el observado:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i \quad \forall i \in \{1, \dots, n\} \quad (1)$$

Toda la notación anterior es conocida como notación de Neyman-Rubin, y particularmente la ecuación (1) corresponde a cómo se escribiría la variable dependiente en esta notación.

Finalmente, dado un tratamiento D_i , lo que podemos conocer es:

$$\begin{aligned}
 \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada}} &= \mathbb{E}[Y_{1i} | D_i = 1] + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{Equivalente a sumar 0}} - \mathbb{E}[Y_{0i} | D_i = 0] \\
 &= \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{ATT}} + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección}} \quad (2)
 \end{aligned}$$

De la ecuación (2) se puede desprender el *Average Treatment on the Treated* (ATT), o efecto promedio sobre los tratados, así como el sesgo de selección. Particularmente, se puede notar que

$$\text{ATT} = \mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1] = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 1] = \mathbb{E}[\tau_i | D_i = 1]$$

Pero ya vimos que el τ_i no es observable. Nos interesa entonces estimar el valor esperado de τ_i , aún sin condicionar por tratados y no tratados, es decir, nos interesa el *Average Treatment Effect* (ATE), o efecto promedio del tratamiento, y se define según:

$$\text{ATE} = \mathbb{E}[\tau_i] = \mathbb{E}[Y_{1i} - Y_{0i}]$$

¿Cómo podemos obtenerlo, si sabemos que no podemos observar τ ?

Grupos de tratamiento, control, y contrafactuales

Antes de obtener la respuesta a la pregunta anterior, vale la pena definir a la unidades experimentales desde cierta perspectiva. Consideraremos **grupo de tratamiento** a todas aquellas unidades experimentales que hayan sido efectivamente tratadas, es decir, Y_{1i} sea observable. Por otra parte, definiremos **grupo de control** a todas aquellas unidades experimentales que no hayan sido tratadas en la realidad, es decir, Y_{0i} sea observable.

Ahora bien, un contrafactual corresponde al *qué pasaría si*, es decir, aún sabiendo que una unidad pertenece al grupo de tratamiento o control, el contrafactual es exactamente la misma unidad experimental, pero considerada en el grupo al que no pertenece. Así:

- Si Y_i está en el grupo de tratamiento, entonces sabemos que Y_{1i} es observable. Llamaremos **contrafactual** de esta unidad a Y_{0i} , que no es observable y pertenece al grupo de control.
- Si Y_i está en el grupo de control, entonces sabemos que Y_{0i} es observable. Llamaremos **contrafactual** de esta unidad a Y_{1i} , que no es observable y pertenece al grupo de tratamiento.

Randomized Controlled Trials

Ahora si podemos responder a la pregunta previa. Para ello, definimos la metodología RCT. RCT hace referencia a la sigla en inglés de *Randomized Controlled Trials*, o Ensayo Clínico

Aleatorizado, y corresponde a una metodología que permite recuperar el efecto causal en un estudio. Su fundamento de basa en el mismo problema presentado anteriormente, donde tenemos un *outcome* y un tratamiento que asignar. La clave, es que en RCT el tratamiento es asignado de manera aleatoria, es decir, no nos interesa cuál de los individuos fue tratado y cual no.

Bajo RCT, y la notación de Neyman-Rubin, notemos que D_i es asignado de manera aleatoria, por lo tanto no depende de i , lo que permite establecer la siguiente igualdad:

$$\mathbb{E}[Y_{0i} | D_i = 0] = \mathbb{E}[Y_{0i} | D_i = 1] \wedge \mathbb{E}[Y_{1i} | D_i = 0] = \mathbb{E}[Y_{1i} | D_i = 1]$$

De esta manera, el grupo de control es un válido contrafactual del grupo de tratamiento y viceversa. Por lo tanto, en nuestra definición de ATT, se puede notar que bajo RCT se tiene

$$ATT = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 1] = \mathbb{E}[\tau_i | D_i = 0] = \mathbb{E}[\tau_i] = \mathbb{E}[Y_{1i} - Y_{0i}] = ATE$$

y por la propiedad lineal del operador esperanza, se tiene que

$$ATE = \mathbb{E}[Y_{1i}] - \mathbb{E}[Y_{0i}]$$

que ahora si puede estimarse, porque los grupos de control y tratamiento son, entre sí, contrafactuales.

Tablas de balance

Una tabla de balance es útil para comprender cómo se relacionan los grupos de tratamiento y control en distintas variables. En términos prácticos, una tabla de balance presenta la siguiente estructura:

Variable	Tratamiento	Control	Valor-p para la diferencia
Nombre variable 1	Promedio de la variable 1 en el grupo de tratamiento	Promedio de la variable 1 en el grupo de control	Valor-p que indica la diferencia entre medias
$\vdots$	$\vdots$	$\vdots$	$\vdots$

La tabla de balance pretende presentar el promedio entre los grupos de tratamiento y control, y a partir del valor-p, hacer notar que la diferencia de media entre las variables es o no significativa. Así, el valor-p es para el siguiente test de hipótesis:

$$H_0 : promedio(variable_i)_{tratamiento} = promedio(variable_i)_{control}$$

$$v/s$$

$$H_a : promedio(variable_i)_{tratamiento} \neq promedio(variable_i)_{control}$$

Por lo tanto, para un nivel de significancia α , rechazamos H_0 si $valor - p < \alpha$.

Pregunta 1

En un colegio se implementó un programa de tutorías en matemáticas dirigido a estudiantes con bajo rendimiento. El director quiere evaluar su efectividad a partir de los resultados obtenidos en la última prueba.

- a) Se observa que los estudiantes que asistieron a la tutoría obtuvieron, en promedio, peores resultados que quienes no participaron. Ante esto, el director está considerando cancelar el programa. Utilizando POF explique por qué cancelar el programa podría no ser adecuado.
- b) Imagine que usted es un observador omnisciente¹, capaz de conocer tanto los resultados potenciales de cada estudiante bajo tutoría (Y_1) como sin tutoría (Y_0), además de su decisión efectiva de asistir al programa. La información se resume en la siguiente tabla.

Estudiante	Nota si asiste (Y_1)	Nota si no asiste (Y_0)	Asistencia a la tutoría (D_i)
Mariana	6.5	6.0	No
Ignacio	5.5	5.0	Si
Diego	6.2	6.5	No
Trinidad	5.3	5.2	Si

- c) Calcule el efecto causal individual de asistir a tutorías para cada estudiante y, a partir de ello, obtenga el efecto promedio del tratamiento (ATE). Luego, estime la diferencia observada en promedios entre quienes asistieron y quienes no asistieron. Compare sus resultados y discuta el rol que cumple el sesgo de selección.
- d) ¿Qué supuesto debería cumplirse para que el estimador de la diferencia de medias observada coincida con el efecto causal? Exprese la condición en términos del marco de Resultados Potenciales y comente si le parece razonable en este contexto.
- e) ¿Cómo estimaría este efecto mediante una regresión lineal? Especifique el modelo y el coeficiente que capturaría el efecto de las tutorías.
- f) A usted le informan que, para motivar la asistencia a las tutorías, el colegio le entregará un premio a todos los estudiantes que vayan. ¿Esto afectaría su estimación del efecto causal? Usando el marco de resultados potenciales, explique en que término podría verse reflejado este premio y cómo lo incluiría.

¹En esta pregunta observamos Y_1 y Y_0 para cada estudiante, algo imposible en la práctica. Esto permite ilustrar con claridad la diferencia entre efecto causal y sesgo de selección. En la realidad, nunca se observan ambos resultados potenciales al mismo tiempo (Problema Fundamental de la Inferencia Causal)

Pregunta 2: Neyman–Rubin y el Problema Fundamental de la Inferencia Causal

Considere el *Problema Fundamental de la Inferencia Causal*. Este señala que nunca es posible observar el efecto causal individual

$$\tau_i = Y_{1i} - Y_{0i}$$

para un mismo individuo, ya que en la práctica solo es observable uno de los dos resultados potenciales. A partir de esto, responda:

- a) Explique por qué no es posible observar τ_i en la práctica y qué implicancias tiene esto para el análisis causal. A partir de esta discusión, defina y distinga formalmente dos alternativas de efectos promedio que sí pueden analizarse: el *Efecto Promedio del Tratamiento (ATE)* y el *Efecto Promedio del Tratamiento sobre los Tratados (ATT)*.
- b) Considere la diferencia de medias observada entre los grupos tratado y control:

$$\delta_{obs} = E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0].$$

Demuestre que esta expresión puede descomponerse como

$$\delta_{obs} = ATT + \text{sesgo de selección}.$$

- c) Indique bajo qué condiciones se cumple que $\delta_{obs} = ATT$ y relacione este resultado con el concepto de *contrafactual válido*.
- d) Explique en qué escenario particular se cumple que $ATE = ATT = \delta_{obs}$.

Pregunta 3

Se dispone de la base de datos `salud_programa.dta` con información de $N = 1000$ individuos. El objetivo es evaluar el impacto de un programa de chequeos médicos preventivos sobre el índice de salud, medido en una escala de 0 a 100. El interés radica en determinar si la participación en el programa genera mejoras en la salud promedio de los individuos, y bajo qué condiciones puede interpretarse esta diferencia como un efecto causal. Para ello, la base incluye dos posibles protocolos de asignación al tratamiento:

- **Treat1**: participación asignada de manera aleatoria.
- **Treat2**: participación determinada en función del nivel de ingresos.

Responda:

- a) Utilizando **Treat1**, estime la diferencia de medias en el índice de salud entre tratados y controles. Interprete el resultado como estimador del efecto promedio del tratamiento (ATE).

-
- b) Estime el modelo de regresión lineal simple e interprete el coeficiente asociado al impacto del tratamiento **Treat1**. Relacione su resultado del inciso anterior.
 - c) Incluya las covariables **Edad**, **Ingreso** y **Fuma** en la regresión anteriormente utilizada. Analice si el coeficiente de **Treat1** cambia respecto a sus resultados anteriores. Explique por qué.
 - d) Repita los incisos (a), (b) y (c) utilizando ahora **Treat2**. Compare los resultados y discuta el rol del sesgo de selección en este escenario.
 - e) Construya una tabla de balance para las covariables (**Edad**, **Ingreso**, **Fuma**) según cada definición de tratamiento (**Treat1** y **Treat2**). ¿Qué puede concluir respecto de la validez del contrafactual en ambos casos?