



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS
ICS2563 ECONOMETRÍA APLICADA - 2025'2

Profesor: PATRICIO DOMÍNGUEZ

Ayudantes: GONZALO AGUILAR (GONZALO.AGUILAR@UC.CL) Y LUZ MARÍA INFANTE (LINFANTEK@UC.CL)

Ayudantía 6

POF y RCT

26 de septiembre de 2025

Potential Outcome Framework

Esta metodología corresponde en realidad a establecer la terminología a utilizar durante todo el capítulo de causalidad. Para ello, suponemos que queremos obtener cómo un tratamiento afecta a cierta situación, que corresponde a la variable dependiente. Así, suponiendo que tratamos con n unidades experimentales, tenemos la siguiente notación para $i \in \{1, \dots, n\}$.

- $D_i := \{0, 1\}$: Corresponde a una variable binaria, que indica si la unidad experimental i obtuvo el tratamiento.
- Y_i : Corresponde a la variable dependiente, que en nuestra nueva notación llamaremos *outcome*, de la unidad experimental i .
- Y_{1i} e Y_{0i} : Corresponde al *outcome* del individuo i , pero esta vez considera si fue tratado Y_{1i} o si no fue tratado Y_{0i} . Una notación equivalente es $Y_{1i} = Y_i(1)$ y $Y_{0i} = Y_i(0)$. **Nótese que nunca ocurrirá en la realidad que el individuo sea tratado y a la vez no sea tratado.**
- $\tau_i = Y_{1i} - Y_{0i} = Y_i(1) - Y_i(0)$: Corresponde al efecto del tratamiento D_i , en el individuo i . **Nótese que como nunca se observará Y_{0i} e Y_{1i} a la vez, nunca se podrá observar τ_i .**

Por lo tanto, bajo la notación anterior, y como en la realidad un individuo no puede estar tratado y no tratado a la vez, se puede escribir el *outcome* que nos interesa, y que es el observado:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i \quad \forall i \in \{1, \dots, n\} \quad (1)$$

Toda la notación anterior es conocida como notación de Neyman-Rubin, y particularmente la ecuación (1) corresponde a cómo se escribiría la variable dependiente en esta notación.

Finalmente, dado un tratamiento D_i , lo que podemos conocer es:

$$\begin{aligned}
\underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada}} &= \mathbb{E}[Y_{1i} | D_i = 1] + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{Equivalente a sumar 0}} - \mathbb{E}[Y_{0i} | D_i = 0] \\
&= \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{ATT}} + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección}} \quad (2)
\end{aligned}$$

De la ecuación (2) se puede desprender el *Average Treatment on the Treated* (ATT), o efecto promedio sobre los tratados, así como el sesgo de selección. Particularmente, se puede notar que

$$\text{ATT} = \mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1] = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 1] = \mathbb{E}[\tau_i | D_i = 1]$$

Pero ya vimos que el τ_i no es observable. Nos interesa entonces estimar el valor esperado de τ_i , aún sin condicionar por tratados y no tratados, es decir, nos interesa el *Average Treatment Effect* (ATE), o efecto promedio del tratamiento, y se define según:

$$\text{ATE} = \mathbb{E}[\tau_i] = \mathbb{E}[Y_{1i} - Y_{0i}]$$

¿Cómo podemos obtenerlo, si sabemos que no podemos observar τ ?

Grupos de tratamiento, control, y contrafactuales

Antes de obtener la respuesta a la pregunta anterior, vale la pena definir a la unidades experimentales desde cierta perspectiva. Consideraremos **grupo de tratamiento** a todas aquellas unidades experimentales que hayan sido efectivamente tratadas, es decir, Y_{1i} sea observable. Por otra parte, definiremos **grupo de control** a todas aquellas unidades experimentales que no hayan sido tratadas en la realidad, es decir, Y_{0i} sea observable.

Ahora bien, un contrafactual corresponde al *qué pasaría si*, es decir, aún sabiendo que una unidad pertenece al grupo de tratamiento o control, el contrafactual es exactamente la misma unidad experimental, pero considerada en el grupo al que no pertenece. Así:

- Si Y_i está en el grupo de tratamiento, entonces sabemos que Y_{1i} es observable. Llamaremos **contrafactual** de esta unidad a Y_{0i} , que no es observable y pertenece al grupo de control.
- Si Y_i está en el grupo de control, entonces sabemos que Y_{0i} es observable. Llamaremos **contrafactual** de esta unidad a Y_{1i} , que no es observable y pertenece al grupo de tratamiento.

Randomized Controlled Trials

Ahora si podemos responder a la pregunta previa. Para ello, definimos la metodología RCT. RCT hace referencia a la sigla en inglés de *Randomized Controlled Trials*, o Ensayo Clínico

Aleatorizado, y corresponde a una metodología que permite recuperar el efecto causal en un estudio. Su fundamento de basa en el mismo problema presentado anteriormente, donde tenemos un *outcome* y un tratamiento que asignar. La clave, es que en RCT el tratamiento es asignado de manera aleatoria, es decir, no nos interesa cuál de los individuos fue tratado y cual no.

Bajo RCT, y la notación de Neyman-Rubin, notemos que D_i es asignado de manera aleatoria, por lo tanto no depende de i , lo que permite establecer la siguiente igualdad:

$$\mathbb{E}[Y_{0i} | D_i = 0] = \mathbb{E}[Y_{0i} | D_i = 1] \wedge \mathbb{E}[Y_{1i} | D_i = 0] = \mathbb{E}[Y_{1i} | D_i = 1]$$

De esta manera, el grupo de control es un válido contrafactual del grupo de tratamiento y viceversa. Por lo tanto, en nuestra definición de ATT, se puede notar que bajo RCT se tiene

$$ATT = \mathbb{E}[Y_{1i} - Y_{0i} | D_i = 1] = \mathbb{E}[\tau_i | D_i = 0] = \mathbb{E}[\tau_i] = \mathbb{E}[Y_{1i} - Y_{0i}] = ATE$$

y por la propiedad lineal del operador esperanza, se tiene que

$$ATE = \mathbb{E}[Y_{1i}] - \mathbb{E}[Y_{0i}]$$

que ahora si puede estimarse, porque los grupos de control y tratamiento son, entre sí, contrafactuales.

Tablas de balance

Una tabla de balance es útil para comprender cómo se relacionan los grupos de tratamiento y control en distintas variables. En términos prácticos, una tabla de balance presenta la siguiente estructura:

Variable	Tratamiento	Control	Valor-p para la diferencia
Nombre variable 1	Promedio de la variable 1 en el grupo de tratamiento	Promedio de la variable 1 en el grupo de control	Valor-p que indica la diferencia entre medias
$\vdots$	$\vdots$	$\vdots$	$\vdots$

La tabla de balance pretende presentar el promedio entre los grupos de tratamiento y control, y a partir del valor-p, hacer notar que la diferencia de media entre las variables es o no significativa. Así, el valor-p es para el siguiente test de hipótesis:

$$H_0 : promedio(variable_i)_{tratamiento} = promedio(variable_i)_{control}$$

$$v/s$$

$$H_a : promedio(variable_i)_{tratamiento} \neq promedio(variable_i)_{control}$$

Por lo tanto, para un nivel de significancia α , rechazamos H_0 si $valor - p < \alpha$.

Pregunta 1

En un colegio se implementó un programa de tutorías en matemáticas dirigido a estudiantes con bajo rendimiento. El director quiere evaluar su efectividad a partir de los resultados obtenidos en la última prueba.

- a) Se observa que los estudiantes que asistieron a la tutoría obtuvieron, en promedio, peores resultados que quienes no participaron. Ante esto, el director está considerando cancelar el programa. Utilizando POF explique por qué cancelar el programa podría no ser adecuado.

Solución: Usando el marco de resultados potenciales podemos plantear la siguiente ecuación:

$$\underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada en notas}} = \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{Efecto causal promedio por asistir a la tutoría (ATT)}} + \underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección de ir a la tutoría}}$$

Donde Y_i son las notas obtenidas en la prueba por el estudiante i , D_i indica si el estudiante i fue a la tutoría (1 si fue, 0 si no), Y_{1i} es la nota del estudiante i que si fue a la tutoría, Y_{0i} es la nota del estudiante i si no fue.

En realidad nos interesa saber el efecto que tuvo el tratamiento sobre los niños que si fueron, pero no conocemos las notas que se hubiesen sacado esos niños de no haber ido. Hay un sesgo de selección en la asistencia a la ayudantía, suelen ir niños con peor promedio.

- b) Imagine que usted es un observador omnisciente¹, capaz de conocer tanto los resultados potenciales de cada estudiante bajo tutoría (Y_1) como sin tutoría (Y_0), además de su decisión efectiva de asistir al programa. La información se resume en la siguiente tabla.

Estudiante	Nota si asiste (Y_1)	Nota si no asiste (Y_0)	Asistencia a la tutoría (D_i)
Mariana	6.5	6.0	No
Ignacio	5.5	5.0	Si
Diego	6.2	6.5	No
Trinidad	5.3	5.2	Si

Calcule el efecto causal individual de asistir a tutorías para cada estudiante y, a partir de ello, obtenga el efecto promedio del tratamiento (ATE). Luego, estime la diferencia

¹En esta pregunta observamos Y_1 y Y_0 para cada estudiante, algo imposible en la práctica. Esto permite ilustrar con claridad la diferencia entre efecto causal y sesgo de selección. En la realidad, nunca se observan ambos resultados potenciales al mismo tiempo (Problema Fundamental de la Inferencia Causal)

observada en promedios entre quienes asistieron y quienes no asistieron. Compare sus resultados y discuta el rol que cumple el sesgo de selección.

Solución: En primer lugar calculamos el efecto del tratamiento para cada persona y lo promediamos para obtener el ATE.

Estudiante	Efecto del tratamiento τ_i
Mariana	0.5
Ignacio	0.5
Diego	-0.3
Trinidad	0.1

$$ATE = (0.5 + 0.5 - 0.3 + 0.1)/4 = 0.2$$

Luego calculamos la diferencia observada en promedios entre quienes asistieron y quienes no.

$$\underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada en notas}} = 5,4 - 6,25 = -0,85$$

En este caso el sesgo de selección tiene un efecto grande. Incluso el ATE y la diferencia observada cambia de signo. Esto se explica porque los niños que van a la tutoría son justamente quienes tenían más problemas con la materia.

- c) ¿Qué supuesto debería cumplirse para que el estimador de la diferencia de medias observada coincida con el efecto causal? Exprese la condición en términos del marco de Resultados Potenciales y comente si le parece razonable en este contexto.

Solución: El supuesto que debe cumplirse es que el sesgo de selección sea cero.

$$\underbrace{\mathbb{E}[Y_{0i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Sesgo de selección de ir a la tutoría}} = \mathbb{E}[NotaSinTutoría_i | Fue] - \mathbb{E}[NotaSinTutoría_i | No fue] = 0$$

Es decir, que si no existiesen las tutorías, las notas promedio de quienes fueron y no fueron a la tutoría hubiesen sido iguales entre si. En este caso ese supuesto se rechaza.

- d) ¿Cómo estimaría este efecto mediante una regresión lineal? Especifique el modelo y el coeficiente que capturaría el efecto de las tutorías.

Solución: En el contexto de un experimento aleatorio, la especificación debiera ser de la misma forma:

$$Y_i = \alpha + \tau D_i + \nu_i$$

donde Y_i son las notas del estudiante i , D_i indica si el estudiante i fue a la tutoría (1 si fue, 0 si no). El efecto causal de interés está estimado por el coeficiente τ .

- e) A usted le informan que, para motivar el que los estudiantes estudien, el colegio le entregará un premio a todos quienes traigan firmado por los papás un informativo explicando la existencia de tutorías. ¿Esto afectaría su estimación del efecto causal? Usando el marco de resultados potenciales, explique en que término podría verse reflejado este premio y cómo lo incluiría.

Solución: Si es que el premio afecta el rendimiento del grupo de tratamiento y de control por igual, esto no afectaría la estimación del efecto causal, que proviene del hecho que los grupos de tratamiento y control son similares en todo excepto el tratamiento debido a una buena aleatorización. En términos del marco de resultados potenciales, esto podría verse reflejado en el término de sesgo de selección:

$$\underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 0]}_{\text{Diferencia observada en notas}} = \underbrace{\mathbb{E}[Y_{1i} | D_i = 1] - \mathbb{E}[Y_{0i} | D_i = 1]}_{\text{Efecto causal promedio (ATT)}} + \underbrace{(\mathbb{E}[Y_{0i} | D_i = 1] + \mathbb{E}[Y_{\text{premio}} | D_i = 1]) - (\mathbb{E}[Y_{0i} | D_i = 0] + \mathbb{E}[Y_{\text{premio}} | D_i = 0])}_{\text{Sesgo de selección}}$$

Si el premio tiene un efecto sobre los resultados de los niños diferente entre quienes van y quienes no van a la tutoría, esto puede afectar el sesgo de selección.

Pregunta 2: Neyman–Rubin y el Problema Fundamental de la Inferencia Causal

Considere el *Problema Fundamental de la Inferencia Causal*. Este señala que nunca es posible observar el efecto causal individual

$$\tau_i = Y_{1i} - Y_{0i}$$

para un mismo individuo, ya que en la práctica solo es observable uno de los dos resultados potenciales. A partir de esto, responda:

- a) Explique por qué no es posible observar τ_i en la práctica y qué implicancias tiene esto para el análisis causal. A partir de esta discusión, defina y distinga formalmente dos alternativas de efectos promedio que sí pueden analizarse: el *Efecto Promedio del Tratamiento (ATE)* y el *Efecto Promedio del Tratamiento sobre los Tratados (ATT)*.

Solución: El *Problema Fundamental de la Inferencia Causal* establece que para cada individuo i sólo puede observarse uno de los dos resultados potenciales: Y_{1i} , correspondiente

al resultado si el individuo recibe el tratamiento, o Y_{0i} , correspondiente al resultado si no lo recibe. En la práctica, lo que se observa es

$$Y_i = D_i Y_{1i} + (1 - D_i) Y_{0i}, \quad D_i \in \{0, 1\}.$$

Esto significa que si $D_i = 1$ se observa Y_{1i} pero no Y_{0i} , mientras que si $D_i = 0$ se observa Y_{0i} pero no Y_{1i} . Como consecuencia, nunca es posible calcular directamente el efecto causal individual

$$\tau_i = Y_{1i} - Y_{0i},$$

ya que siempre falta uno de los dos términos.

La implicancia central de este problema es que el análisis causal debe trasladarse desde los efectos individuales, que son inobservables, hacia efectos promedio en la población. En este contexto, existen dos objetos de interés principales:

- **El Efecto Promedio del Tratamiento (ATE)**, definido como

$$ATE = E[Y_{1i} - Y_{0i}],$$

que mide la diferencia esperada en el resultado si toda la población recibiera el tratamiento en comparación con el escenario en que nadie lo recibe.

- **El Efecto Promedio del Tratamiento sobre los Tratados (ATT)**, definido como

$$ATT = E[Y_{1i} - Y_{0i} \mid D_i = 1],$$

que mide el efecto causal promedio entre quienes efectivamente participaron en el tratamiento.

En síntesis, mientras que el ATE es una medida de política general que sirve para evaluar qué pasaría si extendemos el programa a toda la población, el ATT se centra en los individuos que participaron y refleja el beneficio promedio que recibieron.

- b) Considere la diferencia de medias observada entre los grupos tratado y control:

$$\delta_{obs} = E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0].$$

Demuestre que esta expresión puede descomponerse como

$$\delta_{obs} = ATT + \text{sesgo de selección}.$$

Solución: Considere la diferencia de medias observada entre los grupos tratado y control:

$$\delta_{obs} = E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0].$$

Para descomponer esta expresión, recordemos que el resultado observado puede escribirse como $Y_i = D_i Y_{1i} + (1 - D_i) Y_{0i}$. De este modo, la esperanza condicional para los

tratados es $E[Y_i | D_i = 1] = E[Y_{1i} | D_i = 1]$, mientras que para los controles es $E[Y_i | D_i = 0] = E[Y_{0i} | D_i = 0]$. Reemplazando en la expresión inicial se obtiene

$$\delta_{obs} = E[Y_{1i} | D_i = 1] - E[Y_{0i} | D_i = 0].$$

A partir de aquí, se suma y se resta $E[Y_{0i} | D_i = 1]$ con el fin de aislar el efecto causal sobre los tratados. Así,

$$\delta_{obs} = (E[Y_{1i} | D_i = 1] - E[Y_{0i} | D_i = 1]) + (E[Y_{0i} | D_i = 1] - E[Y_{0i} | D_i = 0]).$$

El primer término corresponde a

$$E[Y_{1i} - Y_{0i} | D_i = 1] = ATT,$$

que representa el efecto promedio del tratamiento sobre los tratados. El segundo término mide la diferencia en los resultados potenciales sin tratamiento entre quienes participaron y quienes no participaron, esto es,

$$E[Y_{0i} | D_i = 1] - E[Y_{0i} | D_i = 0],$$

lo que corresponde al *sesgo de selección*.

En consecuencia, la diferencia observada en medias puede expresarse como

$$\delta_{obs} = ATT + \text{sesgo de selección}.$$

- c) Indique bajo qué condiciones se cumple que $\delta_{obs} = ATT$ y relacione este resultado con el concepto de *contrafactual válido*.

Solución: La igualdad $\delta_{obs} = ATT$ se cumple cuando el sesgo de selección es igual a cero. Formalmente, esto requiere que

$$E[Y_{0i} | D_i = 1] = E[Y_{0i} | D_i = 0],$$

es decir, que el resultado potencial sin tratamiento sea el mismo en promedio para quienes fueron tratados y para quienes no lo fueron. Bajo esta condición, los grupos tratado y control son comparables en ausencia del programa, de modo que los no tratados constituyen un *contrafactual válido* para los tratados.

Este supuesto se interpreta como una situación en la que la participación en el tratamiento es independiente de los resultados potenciales sin tratamiento. En otras palabras, la decisión de recibir el programa no está correlacionada con factores no observados que también afectan los resultados. Cuando este supuesto se cumple, la simple diferencia de medias entre tratados y controles puede interpretarse como una estimación causal válida del efecto promedio sobre los tratados.

d) Explique en qué escenario particular se cumple que $ATE = ATT = \delta_{obs}$.

Solución: La igualdad $ATE = ATT = \delta_{obs}$ se cumple en un escenario particular donde la asignación al tratamiento es completamente aleatoria. En este caso, la probabilidad de recibir el tratamiento no depende de las características observadas ni de los resultados potenciales de los individuos. La aleatorización garantiza que, en promedio, los grupos tratado y control son idénticos en todo salvo en la recepción del programa.

Bajo este diseño, el grupo control constituye un contrafactual válido del grupo tratado, lo que implica que la diferencia observada en medias δ_{obs} coincide con el efecto causal promedio sobre los tratados (ATT). Además, como la aleatorización asegura representatividad para toda la población, este valor coincide también con el efecto promedio del tratamiento en la población (ATE). Por lo tanto, en un experimento aleatorio ideal se cumple que

$$\delta_{obs} = ATT = ATE.$$

Pregunta 3

Se dispone de la base de datos `salud_programa.dta` con información de $N = 1000$ individuos. El objetivo es evaluar el impacto de un programa de chequeos médicos preventivos sobre el índice de salud, medido en una escala de 0 a 100. El interés radica en determinar si la participación en el programa genera mejoras en la salud promedio de los individuos, y bajo qué condiciones puede interpretarse esta diferencia como un efecto causal. Para ello, la base incluye dos posibles protocolos de asignación al tratamiento:

- **Treat1:** participación asignada de manera aleatoria.
- **Treat2:** participación determinada en función del nivel de ingresos.

Responda:

- a) Utilizando **Treat1**, estime la diferencia de medias en el índice de salud entre tratados y controles. Interprete el resultado como estimador del efecto promedio del tratamiento (ATE).

Solución: Al calcular la diferencia de medias del índice de salud entre tratados y controles bajo **Treat1**, se obtiene que los tratados tienen en promedio alrededor de 5.8 puntos más en el índice de salud que los no tratados. Dado que **Treat1** corresponde a una asignación aleatoria, esta diferencia puede interpretarse como un estimador insesgado del efecto causal promedio del tratamiento (ATE).

- b) Estime el modelo de regresión lineal simple e interprete el coeficiente asociado al impacto del tratamiento **Treat1**. Relacione su resultado del inciso anterior.

Solución: En el modelo de regresión lineal

$$Y_i = \alpha + \beta \text{Treat1}_i + \varepsilon_i,$$

el intercepto representa el promedio de salud de los no tratados, mientras que el coeficiente $\hat{\beta}$ corresponde a la diferencia en promedios entre tratados y controles. Los resultados muestran que el tratamiento tiene un efecto de 5.8, idéntico a lo obtenido en el inciso (a). Por lo tanto, en este caso el estimador de regresión reproduce la diferencia de medias.

- c) Incluya las covariables **Edad**, **Ingreso** y **Fuma** en la regresión anteriormente utilizada. Analice si el coeficiente de **Treat1** cambia respecto a sus resultados anteriores. Explique por qué.

Solución: Al incluir las covariables **Edad**, **Ingreso** y **Fuma** en la regresión, el coeficiente de **Treat1** se mantiene en torno a 5.1, muy cercano al valor estimado en los incisos (a) y (b). Este resultado muestra que, bajo asignación aleatoria, el tratamiento no está correlacionado con las características individuales, de modo que controlar por covariables no modifica de manera relevante la magnitud del efecto estimado.

La diferencia con los modelos anteriores radica en la precisión: la inclusión de covariables reduce la varianza residual, lo que se traduce en menores errores estándar para el coeficiente de interés. En consecuencia, la regresión con controles no corrige sesgo —pues en el escenario aleatorio no lo había—, sino que simplemente mejora la eficiencia de la estimación.

- d) Repita los incisos (a), (b) y (c) utilizando ahora **Treat2**. Compare los resultados y discuta el rol del sesgo de selección en este escenario.

Solución: Cuando se repite el análisis utilizando **Treat2**, los resultados cambian de manera sustancial. En primer lugar, la diferencia de medias muestra que los tratados tienen en promedio 17.5 puntos adicionales en el índice de salud en comparación con los no tratados. De forma consistente, la regresión simple con **Treat2** arroja un coeficiente de magnitud similar (17.5). A primera vista, estos resultados sugieren un impacto mucho mayor del programa que el encontrado con **Treat1**.

Sin embargo, al incorporar las covariables en la regresión, el coeficiente de **Treat2** se vuelve estadísticamente no significativo y cercano a cero (-0.079). Esto indica que la aparente ventaja inicial de los tratados no corresponde a un efecto causal del programa, sino a diferencias sistemáticas en características de los individuos, particularmente en el nivel de ingresos.

La comparación entre los dos escenarios ilustra el rol del sesgo de selección: cuando la participación en el tratamiento no es aleatoria, la diferencia observada en resultados refleja tanto el efecto causal como las diferencias preexistentes entre tratados y controles. En este caso, la mayor parte de la diferencia se debe al ingreso más alto de los participantes, lo que genera una sobreestimación del efecto si no se controla por covariables.

- e) Construya una tabla de balance para las covariables (**Edad**, **Ingreso**, **Fuma**) según

cada definición de tratamiento (**Treat1** y **Treat2**). ¿Qué puede concluir respecto de la validez del contrafactual en ambos casos?

Solución: A continuación se tiene la Tabla de Balance para **Treat1**:

	Controles ($D = 0$)	Tratados ($D = 1$)	p-valor
n	511	489	
Edad (media, SD)	44.31 (15.06)	43.36 (14.86)	0.317
Ingreso (media, SD)	24696.67 (12809.56)	25601.43 (14443.21)	0.294
Fuma (media, SD)	0.26 (0.44)	0.26 (0.44)	0.931

Cuadro 1: Balance de covariables bajo Treat1 (asignación aleatoria)

Y para **Treat2**:

	Controles ($D = 0$)	Tratados ($D = 1$)	p-valor
n	935	65	
Edad (media, SD)	43.73 (15.00)	45.52 (14.46)	0.350
Ingreso (media, SD)	22815.61 (9612.49)	58561.57 (18426.06)	< 0,001
Fuma (media, SD)	0.26 (0.44)	0.26 (0.44)	0.978

Cuadro 2: Balance de covariables bajo Treat2 (asignación sesgada)

El análisis de balance permite evaluar si los grupos tratado y control son comparables en sus características antes del tratamiento. Bajo la definición de tratamiento **Treat1**, que corresponde a una asignación aleatoria, las medias de **Edad**, **Ingreso** y **Fuma** son muy similares entre tratados y controles, y las pruebas estadísticas no detectan diferencias significativas. Esto sugiere que los grupos están balanceados y que el contrafactual es válido: los no tratados constituyen una buena aproximación de lo que habría ocurrido con los tratados en ausencia del programa.

En contraste, bajo la definición de tratamiento **Treat2**, los grupos muestran una diferencia marcada en el nivel de ingresos: los individuos tratados tienen ingresos sustancialmente mayores que los controles, mientras que las otras covariables permanecen similares. Esta falta de balance invalida al grupo control como contrafactual, ya que la diferencia de ingresos está correlacionada con los resultados de salud y distorsiona la estimación del efecto causal.

En consecuencia, mientras que **Treat1** garantiza la validez del contrafactual gracias a la aleatorización, **Treat2** introduce sesgo de selección al generar un tratamiento dependiente de una covariable clave.